


QUANTITATIVE GENETICS

数量遗传学

—— 从孟德尔群体到基因组育种

From Mendelian Populations to Genomic Breeding



梅步俊 著

MEI BUJUN




数量遗传学

QUANTITATIVE GENETICS

数量遗传学

—— 从孟德尔群体到基因组育种

Quantitative Genetics: From Mendelian Populations to Genomic Breeding



梅步俊 著

书名 数量遗传学——从孟德尔群体到基因组育种

英文书名 *Quantitative Genetics: From Mendelian Populations to Genomic Breeding*

著者 梅步俊

结构 十篇 三十七章 附录三种

配套资源 各章计算程序与资料按章独立组织，与本书正文分离提供

完稿 二〇二六年十月

本书全部数值例题均可由配套程序复算。书中模拟资料为教学构造，仅用于说明机制，不代表任何真实群体的参数。引用研究结果时，请以原始文献为准。

内容提要

本书系统阐述数量遗传学的理论、方法与应用，以孟德尔遗传在群体中的推演为起点，以育种决策为主线，贯通群体遗传结构、基因定位、遗传方差与亲属相似性、遗传参数估计、选择理论与选择指数、近交与杂交、混合模型与遗传评定、基因组预测以及全基因组序列、多组学、基因与环境互作和深度学习等前沿领域。

全书共十篇三十七章。第一篇建立概率、矩阵与统计推断的共同语言；第二、三篇讨论单位点与多位点群体模型、连锁不平衡、连锁图谱、杂交群体的数量性状位点定位、远交群体的连锁分析与全基因组关联研究；第四篇从基因型值与方差分解出发，建立亲属相似性的因果模型，并讨论遗传参数的经典估计与试验设计；第五篇讨论育种者方程、Bulmer 效应、相关反应、长期选择，以及单性状与多性状选择指数、约束决策与长期遗传多样性；第六篇讨论遗传漂变、有效群体大小、近交衰退、杂种优势与杂交育种体系；第七篇从最小二乘走向最佳线性无偏预测，深入动物模型、方差组分与复杂表型模型；第八篇讨论基因组时代的遗传力与多基因架构、基因组关系矩阵、GBLUP 与贝叶斯方法、单步评定和预测验证；第九篇讨论全基因组序列与泛基因组、多组学与因果推断、基因与环境互作和智能育种模型；第十篇以可复算的教学实验、多性状配种决策和模型诊断，把全书方法落实为从资料到决策的完整流程。

各章兼顾理论推导、数值算例与研究辨析，配有大量插图、习题与参考解答；关键结论均附有可独立运行的计算程序，程序与资料按章组织，单独提供。本书适合动物、植物遗传育种与数量遗传学、统计基因组学相关专业的高年级本科生和研究生学习，也可供从事遗传评定、育种计划设计、种质资源保护与复杂性状遗传研究的科研人员参考。

序言

一个多世纪以前，数量遗传学从一个看似矛盾的观察出发：子女像父母，又不同于父母。高尔顿用回归描述了这种“既相似又不同”，孟德尔用分离与自由组合解释了离散性状的传递，而费希尔在 1918 年证明，大量孟德尔因子的累加作用加上环境的影响，足以解释连续性状在亲属之间的全部相关。从那时起，数量遗传学便以一种独特的方式工作：先把生物学机制写成精确的数学模型，再从模型推演出关于群体的种种结论，最后用资料检验这些结论，并把它们用于改良动植物。福尔克纳称之为“孟德尔遗传推广到群体性质及多位点同时分离时的后果推演”。这一推演的成果之丰富，远远超出了它的创立者所能预见的范围：二十世纪动植物产量的大幅增长，在相当程度上要归功于建立在这一理论之上的育种实践。

今天的数量遗传学正处在一个前所未有的时代。高密度分子标记与全基因组测序使我们能够直接观察过去只能通过亲属间协方差间接推断的遗传相似性；数以百万计的个体资料使我们能够检测效应只占千分之一方差的位点；基因组选择把奶牛的世代间隔缩短了一半，把遗传进展提高了一倍；多组学、高频传感器与深度学习不断扩展着可利用信息的边界。然而，新的数据与新的方法并没有使数量遗传学的基本问题消失。恰恰相反，当标记更多、模型更复杂、计算规模更大时，我们更需要追问那些看似朴素的问题：所估计的究竟是哪个群体、哪种环境下的参数？标记捕获的是致因变异，还是与之处于连锁不平衡的替身？一个预测在训练群体中准确，能否迁移到明天的候选个体？一种方法在模拟中占优，是否在育种决策中真正带来了收益？回答这些问题，离不开对群体遗传、方差分解、亲属相似性与选择理论的透彻理解。

本书正是试图在经典理论与现代方法之间建立一座连续的桥梁。全书以“从孟德尔群体到基因组育种”为线索展开。第一篇建立概率、矩阵与统计推

断的共同语言，并回顾数量遗传学的学术谱系。第二、三篇从单个位点的等位基因频率出发，讨论 Hardy-Weinberg 平衡与改变频率的进化力量，多位点的单倍型与连锁不平衡，连锁图谱的构建，以及杂交群体与远交群体中数量性状位点的定位与全基因组关联研究。第四篇上升到性状层次，讨论基因型值、育种值与遗传方差的分解，亲属相似性的因果模型，系谱关系与近交，以及遗传参数的估计与试验设计。第五篇讨论选择：从育种者方程与 Bulmer 效应，到单性状与多性状选择指数、限制指数与稳健决策，再到长期选择与遗传多样性。第六篇讨论有限群体中的漂变与近交，以及近交的反面——杂种优势与杂交育种。第七篇从最小二乘出发，建立最佳线性无偏预测与混合模型的理论，深入动物模型、方差组分与复杂表型。第八篇进入基因组时代，从“缺失遗传力”的讨论入手，系统阐述基因组关系矩阵、GBLUP 与贝叶斯方法、单步评定与预测验证。第九篇讨论全基因组序列与泛基因组、多组学与因果推断、基因与环境互作以及深度学习等前沿方向。第十篇把全书的方法落实到可复算的教学实验与育种决策中。

在写作上，本书努力做到以下几点。其一，**推导完整**。凡是重要的公式，尽可能给出从定义出发的推导，说明每一步所依赖的条件，区分恒等式、特定分布下的结论与近似。读者若愿意随推导一步步演算，便能理解公式为什么成立，以及在什么条件下不再成立。其二，**算例具体**。每一章都配有可以手算的数值例子，以及由模拟或真实资料得到的计算结果；书中的数值都可以由配套程序独立复算。其三，**辨析审慎**。对每一种方法，既说明它解决了什么问题，也指出它的假设、局限与常见的误用；对每一项研究证据，说明它来自什么物种、群体、资料与验证设计。其四，**新旧贯通**。对经典理论，力求用现代的观点重新阐释；对新方法，力求把它们放回经典理论的框架中理解。例如，基因组关系矩阵被理解为“实际的”亲缘系数，基因组遗传力被理解为由远古亲缘的微小变异所提供的信息，全基因组关联研究被理解为一种利用历史重组的连锁不平衡定位。

本书的写作参考并融汇了多方面的材料。数量遗传学与群体遗传学的基本框架，参考了福尔克纳与麦凯的《数量遗传学导论》、林奇与沃尔什的《数量性状的遗传与分析》等经典著作，以及爱荷华州立大学数量遗传学研究生

课程的系统讲授；选择指数与混合模型的部分，承接了亨德森与范弗莱克以期望、协方差与遗传传递解释预测问题的教学传统；基因组与前沿部分，吸收了近年来国际学术界的重要进展。书中的案例既包括经典的教学资料，也包括国内学者在猪肉质性状全基因组关联分析等方面的研究工作。在此谨向这些著作与课程的作者致以敬意。

全书配有大量插图、习题与参考解答。每章的计算程序与所用资料按章单独组织，读者可以在阅读正文的同时运行程序、改变参数、观察结果，从而对理论获得更具体的感受。程序中的模拟资料均为教学构造，用于隔离和说明机制，而不代表任何真实群体的参数。

本书适合动物、植物遗传育种、数量遗传学与统计基因组学相关专业的高年级本科生与研究生阅读，也可供从事遗传评定、育种计划设计、种质资源保护与复杂性状遗传研究的科研人员参考。阅读本书需要基础遗传学、微积分与初步线性代数的知识；概率、矩阵分解与似然推断在相应章节中有系统的介绍。不同背景的读者可以按照“阅读指南”中建议的路线选择阅读顺序。

一本学术著作的价值，最终在于它能否帮助读者提出更准确的问题、作出更可靠的推断。面对一个新的性状、一种新的数据或一个新的模型，若读者能够说明目标是什么、信息从何而来、假设是否成立、计算是否正确、结果能否推广，并最终评估它对育种决策的影响，本书的写作目的便达到了。

限于作者的学识与精力，书中难免存在疏漏与不妥之处，恳请读者与同行批评指正。

梅步俊

二〇二六年十月

阅读指南与符号约定

十篇内容与知识连接

表 1 全书结构

篇次	章节	核心问题	阅读收获
第一篇 数学、统计与遗传学基础	第 1—3 章	预测对象是什么，信息怎样度量与推断	期望、协方差、矩阵计算与似然推断
第二篇 群体遗传结构与遗传图谱	第 4—6 章	位点在群体中怎样分布与变化	平衡、进化力量、连锁不平衡与连锁图谱
第三篇 数量性状基因定位	第 7—8 章	影响性状的位点在哪里、有多大	区间作图、连锁分析与全基因组关联研究
第四篇 数量性状的遗传模型与参数估计	第 9—13 章	遗传方差怎样分解，亲属为何相似	方差组分、关系矩阵与遗传参数估计
第五篇 选择理论与选择指数	第 14—18 章	选择怎样改变群体，怎样最优地选择	育种者方程、选择指数、约束与长期选择
第六篇 遗传漂变、近交与杂交	第 19—20 章	小群体与交配体系有何遗传后果	有效群体大小、近交衰退与杂种优势
第七篇 混合模型与遗传评定	第 21—24 章	怎样同时校正环境并预测遗传	BLUP、动物模型、REML 与复杂表型模型

篇次	章节	核心问题	阅读收获
第八篇 基因组遗传学与基因组预测	第 25—29 章	基因组信息增加了什么，怎样验证	基因组遗传力、GBLUP、单步评定与验证
第九篇 前沿数据与智能育种	第 30—33 章	新数据与新模型解决了哪些问题	序列、多组学、环境互动与表示学习
第十篇 计算实践与研究设计	第 34—37 章	怎样把理论转化为可复算的决策	数据组织、教学实验、配种决策与诊断

全书遵循“机制层级”的顺序：先在位点层次理解等位基因与单倍型在群体中的行为（第二、三篇），再上升到以均值、方差与协方差为构件的性状层次（第四、五篇），然后讨论交配体系（第六篇），最后在混合模型与基因组框架下把这些理论用于预测与决策（第七至十篇）。前后各篇之间有大量交叉引用，读者可以沿着引用在不同层次之间往返。

不同读者的学习路线

初次系统学习数量遗传学。建议按顺序阅读第一至六篇。其中第 3 章的似然与 EM 算法、第 4 章的 Hardy–Weinberg 定律与进化力量、第 5 章的连锁不平衡、第 9—11 章的方差分解与亲属相似性、第 14 章的育种者方程，是理解后续各章的关键。每章的习题宜动手完成，并运行配套程序。

侧重基因定位与复杂性状遗传。可以从第 3 章的统计推断与多重检验出发，依次阅读第 5—8 章，再进入第 25 章与第 30—31 章。需要特别留意连锁分析与关联分析所利用的连锁不平衡在性质上的差别，以及群体分层、赢家诅咒与不完全连锁不平衡对结论的影响。

侧重遗传评定与基因组选择。可以先读第 1—2 章与第 9—12 章，建立期望、协方差与关系矩阵的基础；然后阅读第 15 章与第 21—24 章，把选择

指数与混合模型方程联系起来；再进入第 25—29 章。第 29 章的验证设计与第 37 章的模型诊断，对于在实际资料中正确评价方法尤为重要。

负责育种计划与种质资源管理。建议重点阅读第 14 章、第 16—20 章与第 34—37 章，明确经济目标、选择强度、准确度、世代间隔与有效群体大小之间的权衡，并按所用评定模型查阅第七、八篇的相应章节。

准备研究论文与学位课题。建议交叉阅读第 13 章、第 29 章与第 37 章，掌握参数估计的精度、验证设计与模拟研究的规划，再进入拟研究的专题。先说明新方法试图解决哪个已知问题、在什么条件下应当有效、在什么条件下可能失效，再安排推导、模拟与真实资料验证。

主要符号

表 2 主要符号及其含义

符号	含义	使用注意
p, q	等位基因频率, $q = 1 - p$	相对于指定群体与世代
a, d	单位点模型中纯合子半差与显性偏离	以纯合子中点为原点
α	等位基因平均替代效应	依赖于等位基因频率
D, D', r^2	连锁不平衡的度量	r^2 决定标记对致因变异的预测能力
c, d (图距)	重组率与图距	经作图函数相互换算
V_G, V_A, V_D, V_I, V_E	遗传、加性、显性、上位与环境方差	均为群体参数
h^2, H^2	狭义与广义遗传力	需说明群体、环境与测定单位
r (重复力)	同一个体重复测定间的相关	遗传力的上限

符号	含义	使用注意
f_{xy}, r_{xy}, u_{xy}	亲缘系数、加性关系、显性关系	相对于基础群体定义
F	近交系数	系谱、纯合片段或基因组估计各有含义
$N_e, \Delta F$	有效群体大小与近交速率	$\Delta F = 1/(2N_e)$
i, S, R	选择强度、选择差与选择反应	截断选择下 $i = z/p$
L	世代间隔	后代出生时亲本的平均年龄
y	观测表型或记录向量	校正状态、量纲与记录时点须说明
u	加性育种值向量	相对于指定群体与遗传基准
β	固定效应参数	可估性取决于设计矩阵与约束
X, Z	固定与随机效应设计矩阵	行列顺序必须与资料一致
P, C, b	选择指数中的记录协方差、记录与目标的协方差、指数权重	由同时使用的全部信息决定
H	综合育种目标	通常为性状育种值的经济加权和
A, G, H_{rel}	系谱、基因组与单步关系矩阵	基准、频率与尺度须交代
Σ_u, G (性状间)	性状间遗传协方差矩阵	与个体间关系矩阵角色不同, 依上下文区分
PEV	预测误差方差	应说明是否条件于估计的方差参数

同一个字母在不同语境中可能有不同含义，例如 d 在单位点模型中表示显性偏离，在连锁图谱中表示图距； $\mathbf{G}$ 在第 10、14 章表示性状间的遗传协方差矩阵，在第八篇表示个体间的基因组关系矩阵。本书在每个符号首次出现的章节给出局部定义。转置用撇号表示，逆矩阵只在存在时使用，广义逆与数值近似均在相关位置说明条件。

怎样阅读推导和例题

每个推导可以分三遍阅读。第一遍只确认它回答的问题，例如怎样最小化预测误差，或怎样在限制近交的条件下提高遗传进展。第二遍追踪随机量与确定量，分清重复抽样意义上的平均与给定资料之后的条件判断。第三遍再检查代数运算、求导与特殊情形。若一个一般公式在方差为零、样本完全重复或矩阵退化时产生明显矛盾，就应回到其可逆性与可识别条件。

数值例题应先做量纲检查。以千克计的性状改为克以后，育种排序不变，但相应的权重与协方差必须一起改变。表格中保留的小数位是为了便于核算，并不意味着实际参数具有相应的精度。教学例题使用已知参数，可以检验数学关系；实际资料使用估计参数，还需要考虑参数误差、资料偏倚与环境变化。书中标有“例”的方框为可以手算或由配套程序复算的数值例题，标有“推导”的方框为完整的数学推导，标有“学术史话”的方框介绍重要概念的历史背景。

证据与研究边界

本书把理论推导、教学构造、模拟实验与真实研究证据按其性质呈现。理论结论依赖明确的假设；教学构造用于隔离某一机制；模拟实验描述指定生成模型与评价程序下的行为；真实资料研究则受其物种、群体、表型、抽样与验证设计的约束。四者可以相互支持，却不能相互替代。参考文献采用作者与年份制，提供可以继续追踪的原始研究与经典来源。本书文献资料更新至 2026 年 10 月。

目 录

内容提要	v
序言	vii
阅读指南与符号约定	xi

第一篇 数学、统计与遗传学基础

第 1 章	概率、期望与遗传预测问题	3
1.1	从育种决策辨认真正的预测对象	3
1.2	随机试验、事件与条件信息	4
1.3	从离散分布到连续分布	6
1.4	期望、方差与单位的账本	8
1.5	协方差、相关与不相关的边界	9
1.6	抽样、独立信息与大样本近似	10
1.7	条件分布与贝叶斯更新的手算结构	12
1.8	条件期望为何是平方误差下的最佳预测	13
1.9	最佳线性预测与选择指数的入口	15
1.10	正态模型、收缩与预测区间	16
1.11	重复记录、永久环境与信息收益上限	18
1.12	准确度、可靠度、预测能力与校准	20
1.13	选择、缺失与数据被观察到的机制	21
1.14	测量误差、层次结构与分布变化	23
1.15	顺序更新与新增信息的决策价值	25
1.16	平方可积空间中的预测几何	27
1.17	信息增加为何不保证每只动物的条件风险都下降	29
1.18	从原始记录到非线性特征的正交展开	31

1.19	损失函数改变时最优预测如何改变	33
1.20	校准、投影与跨群体风险分解	35
1.21	综合练习与解答	37
第 2 章	矩阵方法与稳定计算	41
2.1	从记录表到模型矩阵	41
2.2	向量、内积与线性投影的几何意义	42
2.3	秩、参数约束与可估计函数	43
2.4	对称矩阵、正定性与合法协方差	45
2.5	线性方程、消元与为何不必显式求逆	46
2.6	Cholesky 分解、白化与概率生成	48
2.7	QR 分解与最小二乘的稳定求解	49
2.8	奇异值分解、主方向与低秩近似	50
2.9	条件数与扰动传播	52
2.10	正则化、收缩与改变后的统计问题	53
2.11	广义逆与奇异协方差的相容条件	55
2.12	分块矩阵 Schur 补与混合模型的计算桥梁	57
2.13	迹、行列式与协方差参数的导数	58
2.14	稀疏结构与迭代求解	60
2.15	单位变换、中心化与协方差的一致更新	62
2.16	一个完整的计算核验流程	63
2.17	常见误解与研究判断	64
2.18	从整体条件数走向具体目标的误差控制	65
2.19	协方差相对扰动与预测风险的二阶结构	68
2.20	谱滤波的偏差、方差与目标方向	70
2.21	可估函数的对偶表述与约束不变性	72
2.22	单条记录的更新、删除与信息饱和	74
2.23	综合练习与解答	76
第 3 章	统计推断、似然与数量遗传学方法	81
3.1	数量遗传学的问题意识与学术谱系	81

3.2	统计模型：从生物学机制到可估计参数	84
3.3	样本、估计量与抽样分布	85
3.4	回归、相关与预测的准确度	88
3.5	似然原理与最大似然估计	91
3.6	似然比检验、LOD 值与区间估计	92
3.7	EM 算法：不完全资料的最大似然	94
3.8	线性模型、最小二乘与方差分析	97
3.9	Delta 方法、自助法与比值参数的标准误	99
3.10	检验功效与样本量	100
3.11	多重检验：族错误率与错误发现率	101
3.12	贝叶斯推断的基本结构	103
3.13	模型比较与信息准则	104
3.14	离散资料的检验：拟合优度、列联表与精确检验	104
3.15	二分类与计数性状：广义线性模型与阈值模型	106
3.16	固定效应、随机效应与收缩：混合模型的预告	107
3.17	统计推断中的常见陷阱	108
3.18	置换检验与重抽样推断	109
3.19	本章小结	110
3.20	习题	110
3.21	习题解答	111

第二篇 群体遗传结构与遗传图谱

第 4 章	单基因座群体模型与等位基因频率的演变	115
4.1	群体、位点与等位基因：三个基本概念	115
4.2	基因型频率与等位基因频率	116
4.3	Hardy-Weinberg 定律	117
4.4	Hardy-Weinberg 平衡的检验	119
4.5	Hardy-Weinberg 定律的应用	122
4.6	偏离随机交配：近交、同型交配与群体结构	123

4.7	改变等位基因频率的系统力量	125
4.8	遗传漂变	129
4.9	溯祖理论：向过去看的漂变	132
4.10	平衡理论：多种力量之间的稳态	133
4.11	漂变的扩散近似	134
4.12	由分子资料估计群体遗传参数	135
4.13	多等位基因标记的信息量	136
4.14	多种力量的共同作用与数量性状位点	137
4.15	本章小结	137
4.16	习题	138
4.17	习题解答	139
第 5 章	多基因座单倍型、连锁不平衡与重组	141
5.1	从等位基因频率到单倍型频率	141
5.2	连锁不平衡的度量	142
5.3	有序基因型、无序基因型与相位	144
5.4	由无序基因型估计单倍型频率	145
5.5	重组与连锁不平衡的衰减	147
5.6	产生连锁不平衡的机制	148
5.7	漂变与重组的平衡	150
5.8	杂交群体与远交群体中的连锁不平衡	152
5.9	单倍型块、重组热点与标签 SNP	153
5.10	连锁不平衡在基因组育种中的意义	153
5.11	深入专题	154
5.12	本章小结	157
5.13	习题	157
5.14	习题解答	158
5.15	补充习题	159
5.16	补充习题解答	159
第 6 章	遗传连锁与连锁图谱的构建	161

6.1	重组、交换与连锁	161
6.2	重组率与图距	162
6.3	作图函数	163
6.4	两点连锁的检测与估计	164
6.5	连锁图谱的构建	166
6.6	多点连锁分析的似然: 隐马尔可夫模型	169
6.7	遗传图谱与物理图谱	171
6.8	偏分离与分型错误	171
6.9	深入专题	172
6.10	本章小结	174
6.11	习题	175
6.12	习题解答	175
6.13	补充习题	176
6.14	补充习题解答	176

第三篇 数量性状基因定位

第 7 章	杂交群体的数量性状位点定位	179
7.1	从“黑箱”到基因组区域	179
7.2	单位点数量遗传模型	180
7.3	单标记分析	181
7.4	区间作图	183
7.5	显著性阈值	186
7.6	多个 QTL: 幽灵 QTL 与复合区间作图	187
7.7	定位精度与提高分辨率的设计	188
7.8	品种杂交的 QTL 定位	190
7.9	选择性基因分型与 DNA 混池	191
7.10	Beavis 效应	191
7.11	从 QTL 到 QTN	192
7.12	QTL 定位结果的解释	193

7.13	本章小结	194
7.14	习题	194
7.15	习题解答	195

第8章 远交群体的连锁分析、关联定位与全基因组关联研究 197

8.1	远交群体中定位 QTL 的基本困难	197
8.2	半同胞家系设计	198
8.3	扩展系谱与方差组分连锁分析	200
8.4	候选基因与连锁不平衡定位	201
8.5	全基因组关联研究的统计模型	202
8.6	群体分层与隐性亲缘	203
8.7	显著性标准与多重检验	208
8.8	效应估计、重复与荟萃分析	208
8.9	精细定位与因果变异	209
8.10	案例	210
8.11	从关联分析到基因组选择	212
8.12	本章小结	213
8.13	习题	213
8.14	习题解答	214

第四篇 数量性状的遗传模型与参数估计

第9章 数量遗传与群体依赖性 219

9.1	从基因型表现到可传递的遗传贡献	219
9.2	孟德尔分离与 Hardy-Weinberg 结构	220
9.3	基因型值、群体均值与平均替代效应	221
9.4	加性与显性偏差的正交分解	223
9.5	频率变化、漂变与有限群体	224
9.6	偏离随机交配时重新定义统计投影	225
9.7	显性、近交衰退与杂种优势	227
9.8	多等位基因与更一般的基因型值表	228

9.9	多位点加性值与连锁不平衡	229
9.10	选择形成的关联与 Bulmer 效应	231
9.11	上位性与统计方差的群体背景	232
9.12	遗传力描述的是指定群体中的变异比例	234
9.13	亲属相似怎样连接遗传方差与数据	235
9.14	基因与环境互动、尺度变化和排序改变	237
9.15	从因果变异到标记预测的群体迁移	239
9.16	多性状遗传结构与可实现的改良方向	241
9.17	建立可检验的数量遗传解释	242
9.18	遗传分解作为带有群体权重的投影	243
9.19	二位点互作的完整正交分解	245
9.20	连锁不平衡中的边际效应与偏回归效应	248
9.21	从选择协方差到下一代改变的传递分解	250
9.22	群体混合中的遗传回归与基准迁移	252
9.23	练习、推导与答案	254
第 10 章	遗传方差组分、重复力与性状间相关	259
10.1	方差为什么是数量遗传学的中心	259
10.2	单位点的遗传方差	259
10.3	多位点的遗传方差	262
10.4	表型方差与环境效应	264
10.5	重复测定性状与重复力	266
10.6	基因型与环境的相关和互作	268
10.7	性状之间的相关	269
10.8	尺度、变换与非正态性状	271
10.9	深入专题	272
10.10	本章小结	274
10.11	习题	274
10.12	习题解答	275
10.13	补充习题	276
10.14	补充习题解答	276

第 11 章	亲属间的相似性与遗传协方差	277
11.1	因果模型与观察模型	277
11.2	同状态与同祖同源	277
11.3	遗传协方差的因果模型	281
11.4	基于育种值传递的推导	283
11.5	共同环境与母体效应	284
11.6	一组亲属表型均值的方差	286
11.7	期望关系与实际关系：基于标记的亲缘	287
11.8	双生子设计与人类数量遗传学	289
11.9	深入专题	290
11.10	本章小结	291
11.11	习题	292
11.12	习题解答	292
11.13	补充习题	293
11.14	补充习题解答	293
第 12 章	系谱亲缘、近交与遗传连接	295
12.1	同祖同源是一种有基准的概率	295
12.2	从一代传递推导矩阵递推	296
12.3	一个五动物系谱的完整计算	298
12.4	通径法提供直观核对而非机械数路径	299
12.5	孟德尔抽样连接个体差异与家系平均	300
12.6	局部亲子关系怎样生成稀疏逆矩阵	302
12.7	未知亲本、无记录祖先与信息边缘化	303
12.8	基础群体同时决定均值与关系尺度	305
12.9	基因传递枚举解释期望关系与实际共享	306
12.10	系谱审计是模型建立的一部分	308
12.11	遗传连接使场间比较拥有共同参照	309
12.12	比较精度由误差协方差共同决定	311
12.13	连接设计需要可靠桥梁和冗余路径	312

12.14	系谱关系与基因组关系各观察什么	314
12.15	亲本贡献与具体配对是两个决策层次	315
12.16	多代近交增长与有效群体大小	317
12.17	从关系数据到可审计的评定流程	318
12.18	创新分解中的行列式与条件遗传信息	319
12.19	父母身份不确定时必须保留混合方差	322
12.20	相关基础个体的块创新结构	324
12.21	从共同父本设计推导连接图的信息矩阵	326
12.22	桥梁的边际价值、失效风险与相关记录	328
12.23	练习、计算与答案	330

第 13 章 遗传参数的经典估计方法与试验设计 335

13.1	从观察统计量到因果参数	335
13.2	亲子回归	336
13.3	套式同胞分析	337
13.4	一个套式设计资料的完整分析	339
13.5	析因交配设计	342
13.6	估计的精度与试验设计	343
13.7	遗传相关的估计	344
13.8	不平衡资料与似然方法的地位	345
13.9	用蒙特卡洛模拟检验估计方法	346
13.10	深入专题	347
13.11	本章小结	349
13.12	习题	349
13.13	习题解答	350
13.14	补充习题	351
13.15	补充习题解答	351

第五篇 选择理论与选择指数

第 14 章 选择反应的数量遗传理论 355

14.1	从静态的遗传结构到群体的改变	355
14.2	育种者方程	355
14.3	选择反应的遗传基础	358
14.4	选择对遗传方差的影响: Bulmer 效应	360
14.5	选择反应的协方差表述	362
14.6	相关选择反应	363
14.7	选择反应的测定	364
14.8	长期选择反应与选择极限	368
14.9	本章小结	370
14.10	习题	371
14.11	习题解答	371

第 15 章 单性状选择指数与信息融合 373

15.1	从一条记录到一个可解释的预测	373
15.2	为什么最优权重满足指数方程	374
15.3	例 15.1 自身记录与母亲记录怎样共同起作用	375
15.4	例 15.2 重复测定为什么存在收益上限	376
15.5	基因组时代的信息融合及其边界	377
15.6	把指数理解为投影, 而不只是加权平均	378
15.7	从生物学假设构造协方差矩阵	380
15.8	同胞信息: 样本很多, 独立遗传信息未必很多	382
15.9	后代测定: 通过下一代观察亲本	383
15.10	不等质量重复记录: 为什么不能总用算术平均	385
15.11	传统评定与基因组信息如何融合	386
15.12	负权重、共线性与稳定化	388
15.13	缺失记录、不平衡与选择性测定	390
15.14	信息的经济价值: 什么时候值得再测一次	391
15.15	验证: 从理论准确度走向可用证据	393
15.16	选择指数、回归与混合模型之间的联系	395
15.17	综合案例: 青年种羊的三来源评定	396
15.18	成组新增记录的创新分解与信息归属	400

15.19	把测定次数写入精度矩阵的采样设计	402
15.20	未知批次效应如何改变测定的有效信息	405
15.21	从误差减少到两候选者的精确信息价值	407
15.22	参数估计误差为何使名义信息增益落空	409
15.23	习题、推导训练与参考解答	410
第 16 章	多性状育种目标与经济权重	413
16.1	先定义想改变什么，再决定测量什么	413
16.2	多性状指数的推导与响应分解	414
16.3	例 16.1 目标中惩罚耗料，耗料仍可能增加	415
16.4	例 16.2 经济权重来自生产系统的边际变化	416
16.5	从经济目标走向可审查的多目标育种	417
16.6	育种目标首先是一个生产系统的定义	418
16.7	生物经济模型与边际经济价值	420
16.8	多性状响应的几何结构	421
16.9	单位、标准化与相对重要性的正确解释	423
16.10	饲料效率、比率、残差和真实成本	425
16.11	母系与终端父系需要不同目标	426
16.12	奶牛系统：产量、健康、繁殖与寿命的共同价值	428
16.13	猪、家禽与水产：不同生物学改变目标结构	429
16.14	健康与繁殖性状的尺度转换	431
16.15	环境目标：绝对排放、强度与资源效率	432
16.16	未来价格、环境变化与目标不确定性	434
16.17	综合算例：饲料成本改变后如何解释排名	436
16.18	生产平衡的隐函数与总经济导数	438
16.19	最优管理下的一阶价值与二阶适应收益	441
16.20	胎次状态与折现收益的矩阵推导	443
16.21	不确定价格与遗传表达不能分别取平均	445
16.22	目标误设的响应损失与局部敏感性	447
16.23	习题、案例讨论与参考解答	449

第 17 章	限制指数、非线性目标与稳健决策	453
17.1	将“不能恶化”写成数学约束	453
17.2	例 17.1 保持耗料不变, 需要付出多少代价	454
17.3	例 17.2 目标存在最适值时, 预测均值并不够	455
17.4	例 17.3 不确定的权重与不确定的育种值	456
17.5	边界、可行性与透明的取舍	456
17.6	限制指数的投影解释与损失分解	458
17.7	多个约束、冗余约束与可行性	459
17.8	期望改良量与响应方向	461
17.9	独立淘汰、门槛与补偿性选择	462
17.10	非线性价值与局部线性化	464
17.11	联合预测误差与组合风险	466
17.12	稳健决策与不确定性集合	467
17.13	尾部风险与条件风险价值	470
17.14	概率约束与可兑现的承诺	471
17.15	先获取信息还是立即选择	473
17.16	多目标前沿与决策图的解释	475
17.17	一个从目标讨论到实施复核的完整案例	477
17.18	不等式限制的活跃集合与最优性证书	479
17.19	非零响应限制的白化空间解	482
17.20	遗传联系不确定时的稳健零响应限制	484
17.21	条件风险价值的对偶解释与情景权重	486
17.22	只有均值与方差时的概率保障边界	488
17.23	习题与解答	490
第 18 章	选择反应、世代间隔与长期遗传多样性	495
18.1	一代进展、年度进展与选择强度	495
18.2	例 18.1 准确度较低的方案为何可能进展更快	496
18.3	为什么不能把第一代响应一直线性外推	497
18.4	例 18.2 从挑选最优秀个体到优化亲本贡献	497

18.5	基因组关系、配种优化与长期验证	499
18.6	实际选择强度与繁殖成功	500
18.7	世代重叠与四条选择路径	502
18.8	遗传扩散、时间价值与产业层级	503
18.9	选择如何改变遗传方差	505
18.10	有效群体大小与遗传漂变	507
18.11	最优贡献的几何与约束	508
18.12	从贡献比例到配种计划	510
18.13	系谱、基因组与近交指标的基准	513
18.14	不同畜种与育种系统的长期设计	514
18.15	多样性的时间尺度与未来适应	516
18.16	测定预算与长期计划的共同优化	518
18.17	多代模拟、验证与可复现报告	520
18.18	年龄结构中的遗传传播与生殖价值	522
18.19	多层群体传播的卷积与折现算子	524
18.20	准确度内生变化时的 Bulmer 递推	526
18.21	当代贡献如何转化为长期祖先贡献	529
18.22	多代最优贡献的状态价值与时间预算	531
18.23	习题与解答	534

第六篇 遗传漂变、近交与杂交

第 19 章	遗传漂变、有效群体大小与近交	539
19.1	小群体育种的遗传后果	539
19.2	理想群体中的近交与漂变	539
19.3	有效群体大小	541
19.4	近交对均值的影响：近交衰退	543
19.5	近交对遗传方差的影响	546
19.6	基因组近交	547
19.7	近交在育种中的管理	548

19.8	深入专题	549
19.9	本章小结	551
19.10	习题	552
19.11	习题解答	552
19.12	补充习题	553
19.13	补充习题解答	553

第 20 章 杂种优势、配合力与杂交育种体系 555

20.1	杂种优势：近交衰退的反面	555
20.2	特定杂交组合的杂种优势	556
20.3	杂交育种体系	557
20.4	一般配合力与特殊配合力	560
20.5	杂种优势群与相互轮回选择	561
20.6	纯种选择与杂种表现	562
20.7	杂交种表现的基因组预测	562
20.8	深入专题	563
20.9	本章小结	565
20.10	习题	566
20.11	习题解答	566
20.12	补充习题	567
20.13	补充习题解答	567

第七篇 混合模型与遗传评定

第 21 章 从最小二乘到最佳线性无偏预测 571

21.1	从种畜比较出发理解统计校正	571
21.2	最小二乘的几何意义与正规方程	572
21.3	广义最小二乘为什么需要协方差加权	574
21.4	可估计性、约束与遗传连通	575
21.5	固定效应与随机效应的实质区别	576
21.6	从均方误差最小推导 BLUP	578

21.7	无偏、收缩与条件偏差并不矛盾	579
21.8	混合模型方程与惩罚最小二乘	581
21.9	平衡与不平衡资料的完整手算	582
21.10	预测误差协方差与方程尺度	583
21.11	准确度、可靠度与比较风险	585
21.12	预测育种值、未来表型与综合目标	586
21.13	奇异协方差、极限模型与正则化	588
21.14	异质残差、稳健性与模型失配	590
21.15	选择、资料保留与两阶段分析	591
21.16	从已知参数的 BLUP 到经验 BLUP	593
21.17	把数学模型转化为可靠计算	595
21.18	固定与随机混合目标的统一最优预测	596
21.19	联合误差矩阵与交叉项的实际含义	599
21.20	用新增信息的创新量分解精度增益	601
21.21	多维可靠度与最难预测的遗传方向	603
21.22	线性最优与条件均值最优的精确差别	605
21.23	遗漏均值方向的偏差与有界稳健预测	607
21.24	习题、推导练习与研究设计	609

第 22 章 动物模型与复杂遗传效应 613

22.1	从个体表型走向遗传信息网络	613
22.2	亲本平均、孟德尔抽样与关系递归	614
22.3	无记录动物、信息回传与吸收	616
22.4	公畜模型与动物模型之间的尺度桥梁	617
22.5	母体遗传效应与直接遗传效应	619
22.6	母体模型的协方差展开与手算	620
22.7	母体永久环境、共同窝与识别设计	621
22.8	母体性状中的选择目标与代际表达	623
22.9	显性与上位效应：从基因作用到群体方差	625
22.10	社会遗传效应：一个动物也改变别人的表型	626
22.11	社会模型的协方差、选择方向与手算例	628

22.12	群体规模、稀释假设与社会资料的实验设计	629
22.13	杂交均值、品种组成与杂种优势	630
22.14	纯种与杂种表现：相关可以小于一	632
22.15	基础群体、未知亲本与遗传基准	633
22.16	复杂模型的选择：从可解释结构到可检验预测	634
22.17	从新研究到可迁移应用的完整案例	636
22.18	在去除固定均值后检验遗传来源的可分离性	637
22.19	相关遗传效应的正交分解与条件解释	639
22.20	不规则社会网络中的贡献与反馈	641
22.21	不可分方差下哪些预测仍然稳定	643
22.22	杂交均值模型中的互交信息与剩余混淆	645
22.23	以遗传目标误差选择后续测定设计	646
22.24	练习与详解	648

第 23 章 方差组分、限制似然与贝叶斯推断 653

23.1	方差参数为什么决定预测的力度	653
23.2	从平方和到方差分解	654
23.3	最大似然及固定效应的代价	655
23.4	限制似然来自消去均值的独立对比	656
23.5	用平衡模型看懂 REML 的谱分解	658
23.6	得分方程：观察到的波动与模型期望之差	659
23.7	信息矩阵、平均信息与数值步长	660
23.8	EM 更新：稳定直观，但不能代替识别	662
23.9	参数边界与约束下的重新优化	664
23.10	可识别性：从矩阵方向到真实资料	665
23.11	标准误、轮廓似然与方差比的不确定性	666
23.12	固定效应比较、随机结构比较与预测用途	668
23.13	贝叶斯方差推断的层次结构	669
23.14	先验尺度、相关矩阵与敏感性分析	670
23.15	条件采样、参数化与蒙特卡洛诊断	671
23.16	方差不确定性如何进入育种值与决策	673

23.17	一套可以审计的方差分析流程	674
23.18	非线性协方差参数化中的完整曲率	676
23.19	消除干扰方差后的有效信息	678
23.20	方差边界的有限样本实验	680
23.21	经验预测的参数敏感度与附加误差	682
23.22	一个可精确积分的方差后验实验	684
23.23	协方差失配时得分平衡意味着什么	686
23.24	练习与详解	688

第 24 章 多性状、阈值、生存与纵向遗传模型 693

24.1	从单个数值走向相互关联的生命过程	693
24.2	多性状动物模型的堆叠与协方差	694
24.3	二性状预测：缺失不等于没有信息	695
24.4	多性状协方差的维度、降秩与缺失模式	696
24.5	重复测量模型与重复力的含义	697
24.6	时间相关残差与不规则测量	698
24.7	二元阈值模型与潜在尺度识别	699
24.8	阈值模型的似然、潜在抽样与稀少事件	700
24.9	有序类别、计数和尺度之间的联系	702
24.10	生存资料：时间、事件与删失	703
24.11	比例风险、遗传脆弱性与生存育种值	704
24.12	竞争风险、信息性退出与联合模型	706
24.13	随机回归：用少数系数表示整条遗传曲线	707
24.14	截距—斜率模型的完整手算	708
24.15	从时点育种值到全期目标：持续力与稳健性	709
24.16	基函数选择、边界行为与信息分布	712
24.17	新进展、验证边界与综合应用	714
24.18	阈值记录的信息量与非正态后验	716
24.19	事件富集抽样与总体风险的恢复	718
24.20	纵向与生存联合似然的动态更新	719
24.21	延迟入组与竞争风险改变了条件总体	721

24.22	遗传曲线与暂时环境的状态空间分解	723
24.23	删失下的动态评分与模型组合	725
24.24	练习与详解	727

第八篇 基因组遗传学与基因组预测

第 25 章 基因组时代的遗传力：缺失遗传力与多基因架构 735

25.1	遗传力概念的再审视	735
25.2	缺失遗传力问题	736
25.3	由全基因组 SNP 估计遗传力	736
25.4	LD 分数回归	739
25.5	复杂性状的遗传架构	741
25.6	缺失遗传力的其他解释	742
25.7	多基因预测	743
25.8	家畜中的基因组遗传力	744
25.9	遗传力的正确解释	744
25.10	本章小结	745
25.11	习题	745
25.12	习题解答	746

第 26 章 基因型质量控制与基因组关系矩阵 747

26.1	从实验读数到可解释的基因型	747
26.2	个体身份、亲子关系与样本链条	748
26.3	频率、杂合度与平衡检验的统计解释	750
26.4	缺失机制、概率判型与不确定性传播	753
26.5	基因型填充、单倍型与参考群体设计	755
26.6	从芯片到低深度测序的测量模型	757
26.7	从中心化基因型推导关系矩阵	759
26.8	算例一：四只动物、三个位点	761
26.9	位点加权、稀有变异与正定性	762
26.10	基群频率、中心化与跨批次可比性	764

26.11	连锁不平衡、群体结构与关系的有效维度	766
26.12	算例二：矩阵尺度相容与适度混合	768
26.13	选择性分型、代表性与质量门槛的设计	769
26.14	大矩阵构建、诊断与可复现计算	770
26.15	关系测量的进展：相似、同祖与可预测性	772
26.16	关系矩阵的测量误差：先辨认条件方向	773
26.17	频率误差的低维传播与尺度不确定性	776
26.18	从关系扰动到预测扰动：哪些方向最脆弱	778
26.19	矩阵尺度匹配的合法性与不可识别方向	781
26.20	以目标对比设计复测：质量投入的边际价值	783
26.21	本章练习与参考答案	785

第 27 章 GBLUP、岭回归、贝叶斯与核方法 789

27.1	同一个预测问题的两种表示	789
27.2	固定效应、残差投影与可识别的遗传差异	791
27.3	算例一：从标记效应走到动物育种值	792
27.4	谱收缩、有效自由度与样本外误差	793
27.5	不等精度表型、重复记录与代理育种值	795
27.6	贝叶斯方法改变了什么	797
27.7	层级先验、稀疏混合与连锁不平衡	798
27.8	后验计算、预测区间与参数不确定性	800
27.9	核方法：把相似性写进协方差	801
27.10	样本外核预测与训练参照的一致性	802
27.11	加性、显性与互作预测的传递含义	804
27.12	多核模型、功能注释与方差分解的可识别性	806
27.13	超参数估计、模型选择与公平比较	809
27.14	从后验预测到候选排序与选种决策	811
27.15	选择方法的证据顺序	813
27.16	广义岭回归的度量与训练外等价条件	815
27.17	面向目标群体的预测风险分解	818
27.18	稀疏先验下的非线性收缩与局部不确定性	820

27.19	核方法的表示定理与新动物协方差的合法性	823
27.20	留组误差的精确恒等式与相关验证的边界	825
27.21	本章练习与参考答案	827
第 28 章	单步基因组评定与大规模计算	831
28.1	为什么需要统一关系系统	831
28.2	条件分布、精度更新与单步方程的推导	832
28.3	算例一：一只未分型动物如何获得新信息	834
28.4	选择历史、未分型记录与信息完整性	836
28.5	基群、选择与未知亲本	838
28.6	元基础群体、未知亲本组与跨群体基准	839
28.7	系谱子矩阵的逆、舒尔补与隐式运算	841
28.8	算例二：APY 近似究竟省略了什么	843
28.9	核心组选择、条件残差与 APY 误差诊断	843
28.10	迭代求解、预条件与误差预算	845
28.11	标记效应单步模型与未观测基因型的条件表示	847
28.12	多性状、重复记录与复杂随机结构的扩展	850
28.13	可靠度、预测误差协方差与大规模近似	852
28.14	生产系统、增量更新与可追溯评定	854
28.15	大规模计算应保持的统计不变量	856
28.16	单步关系更新的相对误差怎样跨动物传播	858
28.17	APY 近似的条件相关与信息损失	860
28.18	核心选择的目标加权准则	863
28.19	对候选比较有意义的求解残差	865
28.20	分离模型近似与数值近似的误差预算	867
28.21	本章练习与参考答案	870
第 29 章	验证设计、准确性、校准与跨群体迁移	873
29.1	先定义预测对象，再划分数据	873
29.2	验证目标、损失函数与目标群体的定义	874
29.3	随机、家系、时间与环境划分的实验含义	876

29.4	泄漏的来源与完整训练流程的隔离	878
29.5	准确性、预测能力与可靠度	880
29.6	不可观测育种值、代理真值与误差分解	880
29.7	算例一：相关等于 1，为什么仍然预测失准	882
29.8	校准、收缩与选择后的条件解释	883
29.9	算例二：用早期与后期评定检验模型	885
29.10	LR 验证的条件期望基础与分母选择	887
29.11	相关动物中的标准误、区间与重抽样	889
29.12	模型比较、学习曲线与参考群体建设	891
29.13	跨群体迁移与近期方法进展	893
29.14	迁移机制、局部适配与跨品种信息共享	894
29.15	前瞻监测、模型更新与完整研究方案	896
29.16	LR 更新量的协方差与选择后的条件解释	899
29.17	LR 协方差统计的抽样波动与平方根偏差	901
29.18	模型损失差的依赖结构与真正的推广单位	903
29.19	从条件分布变化推导迁移风险	906
29.20	本地适配的借力强度与负迁移条件	908
29.21	本章练习与参考答案	910

第九篇 前沿数据与智能育种

第 30 章	全基因组序列、泛基因组与结构和稀有变异	915
30.1	序列时代的育种问题：测得更多之后还缺少什么	915
30.2	变异是生物事件，也是统计编码	916
30.3	从读段到基因型：似然、先验和剂量	918
30.4	关系矩阵怎样传播基因型不确定性	919
30.5	低覆盖测序与插补：评价的单位决定结论	920
30.6	泛基因组的表示：从一条参考到多条可追踪路径	922
30.7	结构变异的证据链：发现不等于可靠分型	923
30.8	稀有变异为什么难：数量、亲缘与效应可识别性	925

30.9	集合检验：把稀少信息聚合到有意义的单位	927
30.10	序列与结构变异进入混合模型	928
30.11	单倍型、连锁不平衡与定位分辨率	930
30.12	跨品种和跨世代预测：可迁移性的三个来源	931
30.13	参考群体怎样选：覆盖染色体，而不是只数动物	933
30.14	从准确率到净收益：序列方案的经济评估	934
30.15	可复现的证据链与下一阶段研究	936
30.16	概率基因型的似然与缺失信息	938
30.17	稀有变异的信息由哪些独立对照产生	940
30.18	联合基因型不确定性怎样进入遗传协方差	943
30.19	参考面板设计是覆盖概率与边际收益问题	945
30.20	由后验概率走向配种风险与检测价值	947
30.21	综合练习与解答	949

第 31 章 多组学、功能先验与因果推断 953

31.1	先定义信息进入决策的时间	953
31.2	分子测量的尺度、批次与重复性	954
31.3	用遗传协方差连接辅助性状与目标性状	955
31.4	从分子通路到总育种值：不要丢掉间接遗传作用	957
31.5	高维组学的降维：保留什么变异	958
31.6	多核整合：相似性可以有不同来源	959
31.7	功能先验怎样改变标记效应的收缩	961
31.8	注释权重的学习、重叠与泄漏	962
31.9	分子数量性状位点与共定位	964
31.10	因果图：哪些变量应当调整	965
31.11	遗传工具变量：比值容易，识别困难	966
31.12	中介分析：总效应、直接效应与路径特异效应	968
31.13	微生物组：组成数据与宿主遗传的边界	969
31.14	纵向多组学：把稳定差异与短期状态分开	971
31.15	验证设计：区分表型预测与育种值预测	972
31.16	有限预算下的组学设计	973

31.17	从关联网络走向可积累的生物知识	975
31.18	分子测量误差的衰减与联合模型	977
31.19	辅助组学的价值是条件遗传信息	979
31.20	有误差中介与工具变量的识别边界	981
31.21	功能加权后验如何同时表达效应与不确定性	983
31.22	多核方差分解的可识别性与预测边界	986
31.23	综合练习与解答	988
第 32 章	基因与环境互动、韧性和可持续育种	993
32.1	育种值为什么总有环境背景	993
32.2	环境测量、暴露、反应与管理不能混为一谈	994
32.3	离散环境作为相关性状	995
32.4	连续反应规范的基本推导	997
32.5	目标环境分布决定怎样选择	998
32.6	互动模型的识别与验证	1000
32.7	韧性、抵抗性与恢复性的不同含义	1001
32.8	高频表型：从传感器信号到育种性状	1002
32.9	从偏离曲线计算韧性指标	1003
32.10	遗传的均匀性与残差方差	1005
32.11	资源分配与终生稳健性	1006
32.12	排放性状的定义改变选择方向	1008
32.13	遗传残差排放：控制生产的一个线性构造	1009
32.14	多目标选择、约束与稳健方案	1010
32.15	疾病、耐受与群体传播	1012
32.16	遗传多样性、近交与环境压力	1013
32.17	一个可部署的环境与韧性评定方案	1015
32.18	对环境分布积分后的目标与预测误差	1017
32.19	阈值反应与环境测量决定暴露权重	1020
32.20	从恢复曲线推导累计损失与遗传目标	1022
32.21	状态估计把测量噪声与真实恢复分开	1023
32.22	群体传播的遗传目标来自传播算子	1025

32.23	可持续目标中的比值、寿命与不确定性	1027
32.24	综合练习与解答	1029

第 33 章 深度学习与基因组基础模型 1033

33.1	三类任务，三种不同的预测对象	1033
33.2	线性模型、核方法与表示学习的桥梁	1034
33.3	样本量不是文件中的行数	1035
33.4	神经网络的基本计算与正则化	1036
33.5	卷积结构与基因组局部性	1038
33.6	注意力、长序列与计算边界	1039
33.7	自监督预训练学到了什么	1040
33.8	变异评分：从两条序列的差异到统计特征	1042
33.9	AlphaGenome 与 AlphaGenome Atlas 的证据位置	1043
33.10	跨物种迁移需要哪些一致性	1045
33.11	混合模型与深度模型的联合使用	1046
33.12	公平验证：把完整学习流程放进边界	1047
33.13	相关、误差与校准分别说明什么	1049
33.14	模型组合的收益来自误差互补	1050
33.15	预测不确定性与分布外输入	1052
33.16	可解释性：归因不是因果	1053
33.17	从研究模型到常规评定	1054
33.18	从基础模型分数到可校准的分子效应	1057
33.19	类别概率的先验变化与绝对风险校准	1059
33.20	统计可迁移性是分布条件而不是模型称号	1060
33.21	功能评分进入育种值时必须传播校准参数	1062
33.22	深度表示与混合模型的联合目标和公平比较	1064
33.23	共同偏差、预测区间与有条件的可信范围	1066
33.24	综合练习与解答	1068

第十篇 计算实践与研究设计

第 34 章	从数据字典到可重复遗传评定	1073
34.1	先把育种任务变成可检查的问题	1073
34.2	从总体定义到观测单位	1074
34.3	性状定义是模型的一部分	1076
34.4	身份、主键与连接错误的数值后果	1077
34.5	信息截止日与双时间记录	1079
34.6	重复测定为何不能简单增加样本量	1080
34.7	系谱资料的拓扑、基准与不确定性	1082
34.8	基因型资料的编码、参考与质量	1083
34.9	缺失不是一个统一的数字	1084
34.10	环境分组与遗传连通性	1086
34.11	协方差、派生变量与合法矩阵	1087
34.12	从原始记录到分析表的可追溯变换	1089
34.13	数据契约与可复用研究资料	1090
34.14	可复现包含资料、算法和数值三个层次	1091
34.15	验证切分必须跟随部署场景	1093
34.16	评定批次的版本、发布与解释	1094
34.17	综合教学案例：把三张表变成一个可审计问题	1095
34.18	新增记录的条件创新与逐目标信息增量	1097
34.19	删除记录与降权操作的影响函数	1099
34.20	有效信息必须扣除相关和待估环境方向	1101
34.21	新测定的价值取决于条件方向和成组冗余	1103
34.22	身份不确定性和版本变化的概率传播	1105
34.23	习题与详细解答	1107
第 35 章	从系谱 BLUP 到 GBLUP：一个可复算的肉羊教学实验	1111
35.1	用一个已知真值的世界检验预测	1111
35.2	群体结构与世代生成	1112
35.3	双等位标记与孟德尔抽样	1113
35.4	从标记效应生成真实育种值	1115

35.5	系谱关系矩阵的逐项构造	1116
35.6	表型模型与已知参数的教学条件	1118
35.7	单个体例子：收缩不是把信息丢掉	1119
35.8	双个体例子：亲缘怎样改变信息权重	1120
35.9	一般 BLUP 与固定效应不确定性	1122
35.10	计算实现与独立等价核验	1124
35.11	三十次重复的主要结果	1125
35.12	校准、误差尺度与个体比较	1127
35.13	减少可观测标记：信息损失与模型错设要分开	1128
35.14	方差比错设如何改变排序与幅度	1130
35.15	八只候选者错配：合法矩阵仍会产生错误预测	1132
35.16	怎样把教学实验扩展为严谨研究	1133
35.17	复算路径与结果解释的工作顺序	1135
35.18	把预测损失分成不可约误差与方法额外损失	1137
35.19	嵌套重复怎样分离遗传抽样与算法随机性	1139
35.20	用完整因素设计识别观测信息与噪声的交互	1141
35.21	同样协方差可以对应不同的遗传分布	1143
35.22	初筛之后怎样解释相关下降与尾部损失	1145
35.23	习题与详细解答	1147
第 36 章	多性状目标与约束配种的完整决策算例	1151
36.1	从预测个体转向设计下一代	1151
36.2	三性状候选资料怎样生成	1152
36.3	单位、经济权重与时间范围	1153
36.4	三种目标情景与响应的解释	1155
36.5	候选资料与信息可靠性的阅读	1156
36.6	基因贡献、亲本使用份额与后代均值	1158
36.7	群体共祖与后代近交不是同一个量	1159
36.8	最优贡献问题与可行性边界	1160
36.9	四亲本算例与解析贡献前沿	1161
36.10	十六候选群体的三情景结果	1163

36.11	配种分配作为运输问题	1165
36.12	连续最优解怎样转为整数方案	1167
36.13	将实际约束写成明确条件	1168
36.14	方案不确定性与均值—方差权衡	1170
36.15	下尾风险、机会约束与近期方法进展	1173
36.16	当前配种与长期遗传结构	1175
36.17	从计算结果到可审阅决策	1176
36.18	最优贡献的乘子条件与约束边际代价	1178
36.19	禁配网络的可行性与运输问题的对偶证据	1180
36.20	整数后代数如何改变连续贡献前沿	1182
36.21	多个底线的联合风险与参数范围稳健性	1184
36.22	追加信息何时能够改变配种并抵偿成本	1186
36.23	习题与详细解答	1188
第 37 章	模型诊断、失败分析与可检验的研究设计	1191
37.1	诊断的起点是区分错误层次	1191
37.2	表型残差、育种值误差与未来结果	1192
37.3	残差经过拟合以后为何不再独立	1193
37.4	相关很高为什么仍可能严重失准	1195
37.5	预测区间覆盖率的一个精确算例	1196
37.6	参数不确定性与插件式 PEV	1198
37.7	方差分量边界与弱信息	1199
37.8	可识别性、连通性与数值病态	1200
37.9	无信号负对照揭示预处理泄漏	1202
37.10	非高斯性状、极端值与稳健处理	1204
37.11	群体变化、环境变化与模型迁移	1205
37.12	数值失败与统计失败的分离	1206
37.13	把方法想法写成可证伪的研究问题	1208
37.14	模拟设计中的因素、层次与停止规则	1209
37.15	相关个体下的标准误与重抽样	1211
37.16	真实资料验证与后续评定的使用	1212

37.17 四个可继续推进的研究方向	1213
37.18 后验复制必须对应真正要预测的未来对象	1216
37.19 条件创新诊断与严格预测评分	1218
37.20 离散表型的随机化分位残差与条件校准	1219
37.21 模拟校准检验算法, 也必须检验信息是否被使用	1221
37.22 研究功效、蒙特卡洛精度与等效性必须分别规划	1223
37.23 习题与详细解答	1225
附录 A 扩展模型与补充推导	1229
附录 B 术语对照与概念辨析	1235
附录 C 按问题查阅的方法索引	1245
参考文献	1251
索 引	1271
后记	1275

第一篇

PART I

数学、统计与遗传学基础

概率、矩阵与统计推断是数量遗传学的共同语言。本篇从育种决策中的预测问题出发，建立期望与协方差的账本、稳定的矩阵计算以及似然推断的基本框架。

第 1 章 概率、期望与遗传预测问题

第 2 章 矩阵方法与稳定计算

第 3 章 统计推断、似然与数量遗传学方法

概率、期望与遗传预测问题

1.1 从育种决策辨认真正的预测对象

一只羊的断奶重已经称出，为什么还要预测它的遗传潜力？称重回答的是这只动物在既定生长历史、饲养管理和测量条件下表现如何，留种决策关心的却是它成为亲本后，能够给未来后代群体带来怎样的平均改变。两者有关联，却不相同。补饲、胎次、出生日期、疾病和母羊泌乳能力都能改变断奶重，其中只有部分差异按特定遗传规律传给后代。如果不先区分观察对象与决策对象，即使采用很复杂的统计程序，也可能只是在精确地回答另一个问题。

本书将单性状的加性育种值记为 u ，表型记为 y 。最简单的教学模型是 $y = \mu + u + e$ ，其中 μ 表示指定群体的期望水平， e 汇集尚未单独表示的其他偏差。这个表达是模型，不是把现实任意切成两块的许可。若母体效应、永久环境、胎次或基因型与环境互作对问题重要，就应进一步分解。每增加或合并一个成分，都要回答其均值、方差、与其他成分的关系，以及它属于个体、家庭、场次还是记录层次。

预测对象有时是潜在的育种值，有时是未来表型，有时是某个事件发生的概率。对青年公羊预测成年繁殖力，目标可能是特定年龄环境下的加性贡献；对商品羔羊预测出栏重，目标则包括能够预见的环境过程；对一次配种预测隐性缺陷后代的风险，需要的是后代基因型概率。把这几种结果都称为“预测分数”会失去关键含义。报告中应明确目标、单位、时间点、环境边界和信息截止时间，让使用者知道一个数值可以支持什么决策。

还要区分参数估计与随机量预测。遗传方差、环境方差和固定效应是模

型中的参数；某只动物尚未观察到的育种值是需要预测的随机量。随机并不意味着动物的基因组每次分析都重新产生，而是指在指定群体分布下，未完全获知的个体差异被概率模型描述。固定效应 β 也不是永不改变的效应，而是当前模型不为其指定群体随机分布的参数。把固定与随机简单理解为“重要与不重要”或“稳定与不稳定”，会妨碍后续混合模型学习。

一个育种计划通常具有多个目标性状。若 $\mathbf{u}$ 收集这些性状的育种值， $\mathbf{a}$ 表示已明确的经济或价值权重，则综合目标为 $H = \mathbf{a}^T \mathbf{u}$ 。记录向量却不必包含这些性状的直接测定。廉价的早期生长记录可能帮助预测终生生产，活动传感器可能帮助预测健康，亲属资料可能帮助预测只能在另一性别表达的性状。因而“测量了什么”与“最终想改良什么”必须分别定义，信息性状的重要性也不能直接替代目标性状的价值。

本章采取从问题到概率、从概率到期望、从期望到最优预测的路线。这一顺序延续了经典选择指数教材的教学思想（Van Vleck, 1993），但把数据时间边界、预测校准、分布变化和信息价值同时纳入讨论。它们并不是新算法出现后才附加的要求，而是概率推理原本就包含的条件。掌握这些条件，读者才能判断一个计算结果究竟来自已观察的信息、群体假设，还是尚未验证的外推。

1.2 随机试验、事件与条件信息

概率模型首先描述一个可重复设想的过程。随机抽取一只候选羊、从双亲各抽取一个配子、在同样管理条件下重复一次测定，都可以构成随机试验。所有可能结果组成样本空间，所关心的结果集合称为事件。例如“羔羊携带某等位基因”“体重超过留种阈值”“在观察期内出现疾病”分别是不同事件。模型必须说明抽取来自哪个群体、如何抽取以及观察到何时；否则同一个概率符号可能隐含不同分母。

事件概率在零与一之间，整个样本空间概率为一。互不相容事件的并集概率等于各自概率之和。这里的互不相容表示不能同时发生，不能与独立混淆。一只动物在同一时刻处于两种互斥基因型是不相容事件；两次独立配子

抽样却可以同时抽到某个等位基因。两个有正概率的不相容事件不可能独立，因为知道其中一个发生，就确定另一个不发生。这种最基础的辨析，对理解家系中不同后代的遗传抽样十分有帮助。

已知事件 B 发生后，事件 A 的条件概率定义为 $\Pr(A | B) = \Pr(A \cap B) / \Pr(B)$ ，其中 $\Pr(B) > 0$ 。条件化改变了参考范围：分母从全部可能结果缩小到符合已知信息的结果。某缺陷在全群体中的发生率，与在两只携带者交配后代中的发生率，显然不同。条件概率不等于时间上的因果顺序；可以讨论给定父母基因型的后代概率，也可以讨论观察到某个后代之后父母为携带者的概率。

若事件 $B_1, \dots, B_k$ 构成互不相容且穷尽全部情况的划分，则有全概率公式 $\Pr(A) = \sum_j \Pr(A | B_j) \Pr(B_j)$ 。它告诉我们，混合群体中的风险是各亚群条件风险的加权平均。某牧场总体疾病率升高，可能来自每个年龄组的风险都升高，也可能仅因为高风险年龄组比例增加。把总体变化直接解释为生物机制变化，会忽略群体组成这一层。遗传评定中的场年组校正和跨群体比较，都离不开这种分层思维。

贝叶斯公式交换了条件方向： $\Pr(B_j | A) = \Pr(A | B_j) \Pr(B_j) / \Pr(A)$ 。例如某检测的敏感度很高，仍不等于阳性动物很大概率确实患病，因为后一个概率还取决于基础发生率。类似地，一个遗传标记在病例中常见，不意味着携带者必定发病。诊断、预测和遗传关联所涉及的条件方向不同，应把分子与分母都写清楚，不要仅凭一句“相关性很强”跨越这些问题。

在育种数据中，信息集合可以比一个事件复杂得多。我们可能已经知道父母身份、出生场、年龄和部分基因型，却还不知道成年记录。用 $\mathcal{I}$ 表示当前可用信息，预测就是在这个信息集合下讨论目标分布。信息必须带有时戳：在三月作出的留种决策，不能使用六月才测得的记录，即使回顾性数据库已经把它们放在同一行。时间边界不是文件整理问题，而是条件概率中“已经知道什么”的数学定义。

1.3 从离散分布到连续分布

随机变量把试验结果映射为数字。基因拷贝数、窝产仔数和疾病指示属于离散变量，体重、产奶量和连续时间测定通常用连续变量近似。离散分布给每一个可能数值分配概率；连续分布以密度描述概率在区间中的分布，单个精确点的概率通常为零。密度可以大于一而不违反概率规律，因为概率等于区间上的面积，不等于密度高度。把密度曲线的纵轴直接解释为某个点发生的概率，是初学者常见错误。

对于取值零或一的疾病指示 D ，若发生概率为 p ，则 $E(D) = p$ 、 $\text{Var}(D) = p(1-p)$ 。均值就是风险，方差却受到均值约束。发生率接近零或一时，观察尺度上的变异很小；这并不说明潜在生物风险因素一定不重要。两个群体基础发生率不同，即使潜在作用相似，观察尺度上的遗传方差也可能不同。后面讨论阈值模型时，还会回到概率尺度与潜在责任度尺度的区别。

若 n 次独立、成功概率相同的零一试验相加，得到二项分布，期望为 np ，方差为 $np(1-p)$ 。独立性与相同概率都是条件。把同一窝羔羊的成活数当作简单二项变量，隐含了在模型已控制信息之外不存在共同母体、共同感染和其他剩余关联。若实际存在共同风险，则观察方差可能大于二项方差。解决办法不是机械增加样本量，而是考虑分层概率、共同随机效应或其他适合过度离散的模型。

泊松分布常用作计数的起点，其均值与方差同为 λ 。它适合描述相应独立事件机制下某个观察窗口中的发生次数，却不能覆盖所有动物生产计数。零值特别多、存在上限、事件相互促进或个体暴露时间不同时，都需要额外建模。研究者应说明一次计数对应多长时间、多少风险暴露和哪种记录制度。把每月疾病次数与全年疾病次数直接放在同一模型中而不处理暴露量，得到的差异首先反映观察机会。

正态分布由均值 μ 与方差 σ^2 描述，密度关于均值对称。标准化变量 $z = (y - \mu)/\sigma$ 的标准正态分布使不同单位下的偏离可以比较。约有 68.27% 的概率位于均值上下一个标准差之间，约有 95.45% 位于上下两个标准差之间。常用的 1.96 对应双侧约 95% 的区间。应用时不应把这些近似比例记成

任何分布都成立的规律，更不能把均值与标准差已知的概率区间直接当成未知均值的置信区间。

许多正态近似来自大量小贡献的累加，但“由许多基因决定”不是正态性的充分证明。少数大效应、稀有严重变异、混合群体、截留和边界都可能产生偏态或多峰。对数正态变量则常用于正值且右偏的量：若 z 正态、 $y = \exp(z)$ ，则 $E(y) = \exp(\mu_z + \sigma_z^2/2)$ ，而不是 $\exp[E(z)]$ 。这一差别说明，变换尺度上的平均再反变换，通常不等于原尺度的平均。后续预测和经济评价必须与最终需要的尺度对齐。

本章不要求为每个性状立即挑选最复杂的分布，而要求形成核对习惯：可能取值是否符合模型，均值与方差是否存在结构关系，零值和极端值是否有明确机制，群体是否由多个分布混合。分布假设是压缩信息的工具，简化越强，越要知道它排除了哪些现象。若主要目标只是最佳线性预测，二阶矩可能已足够；若要讨论尾部风险、阈值概率或预测区间，完整分布的形状就更加重要。

边际分布与条件分布还可能具有不同形状。例如每个场内部的体重近似正态，而不同场的均值差异很大，合并后的体重可能呈多峰；在控制场次以后，残差又可能接近正态。因此，检验“表型是否正态”不能替代检验模型条件残差的结构。随机效应模型正是通过层次结构描述某些混合分布：给定个体效应时记录较简单，对未观察个体效应积分后，记录之间产生相关。后续混合模型的协方差并非凭空指定，而是这些共同潜在成分形成的边际结果。

不同参数化还可能表示同一分布。泊松模型可以用均值或其对数作参数，正态模型可以用方差、标准差或精度作参数。变换有助于保证正值和改善计算，但报告结果时必须回到清楚的尺度。尤其对概率和方差的变换，变换后参数的线性变化不对应原尺度上的等幅变化。理解这个事实，能够避免把回归系数直接解释为风险或遗传方差的绝对变化。

1.4 期望、方差与单位的账本

期望是按概率加权的平均。若离散变量 x 以概率 p_j 取值 x_j , 则 $E(x) = \sum_j p_j x_j$; 连续变量使用相应积分。期望不一定是变量能够实际取得的数。以相同概率取负一或正一的变量, 期望为零, 但单次结果永远不是零。因此, “后代预期育种值为三” 不表示每只后代的育种值都等于三, 而表示在规定条件下重复遗传抽样所得后代的平均。把平均预期当作个体保证, 会系统低估分离和环境变异。

常数能够移出期望, 和的期望等于期望的和, 而且不要求独立性。对于常数 a_0, a_1 , 有 $E(a_0 + a_1 x) = a_0 + a_1 E(x)$ 。但是一般不能把函数移出期望: $E[g(x)]$ 通常不等于 $g[E(x)]$ 。例如平均体重相同的两个群体, 若一个群体体重更分散, 按偏离加工最适体重的平方处罚时, 其平均损失会更高。这个差别将成为非线性育种目标和风险决策的基础。

方差定义为 $\text{Var}(x) = E[(x - Ex)^2]$ 。展开平方, 可得 $\text{Var}(x) = E(x^2) - [E(x)]^2$ 。前一个形式直接表达围绕均值的偏离, 后一个形式常便于代数推导。数值计算中, 如果两个很大的数相减得到很小的方差, 后一个形式可能遭受严重消减误差; 这时应采用中心化或稳定的递推算法。数学恒等式与浮点实现具有不同层次的风险, 不能认为代数相等就保证计算精度相同。

方差的单位是原变量单位的平方, 标准差与原变量单位相同。体重从千克改为克, 均值扩大一千倍, 方差扩大一百万倍; 相关系数却保持不变。线性变换满足 $\text{Var}(a_0 + a_1 x) = a_1^2 \text{Var}(x)$, 常数平移不改变变异。若把不同性状的方差直接相加而不说明权重单位, 所得数值通常没有清楚意义。综合目标中, 经济权重既表达价值, 也承担把不同性状转换到共同评价尺度的作用。

设独立同分布样本为 $x_1, \dots, x_n$, 其均值为 $\bar{x}$ 。因为 $E(\bar{x}) = \mu$, 样本均值是总体均值的无偏估计; 又因交叉协方差为零, $\text{Var}(\bar{x}) = \sigma^2/n$ 。这里标准误差随 $\sqrt{n}$ 下降, 不是随 n 下降。要把标准误差减半, 在同等独立信息条件下通常需要四倍样本。若新增记录高度相关, 这个收益还会降低。因此成本比较应使用有效信息增长, 不能只比较数据库中的行数。

为什么样本方差常除以 $n - 1$? 恒等式 $\sum_i (x_i - \bar{x})^2 = \sum_i (x_i - \mu)^2 -$

$n(\bar{x} - \mu)^2$ 给出答案。取期望后，右边为 $n\sigma^2 - n\text{Var}(\bar{x}) = (n-1)\sigma^2$ ，所以除以 $n-1$ 才在上述抽样条件下无偏。如果样本相关、具有不同方差或经过复杂选择，简单公式的期望就会改变。自由度不是在任何问题里都减一的口诀，而是均值估计与残差空间结构的结果。

一个有用的小算例是三条记录 2, 4, 6。均值为四，平方离差和为八，按总体描述除以三得到 $8/3$ ，按独立同分布样本估计未知总体方差则除以二得到四。两者针对的问题不同，并非其中一个算错。若这三条记录恰好是同一只动物连续三分钟的测量，使用样本方差估计群体间体重差异就没有合理性。算式正确只是起点，抽样单位正确才使这个数成为所需统计量。

1.5 协方差、相关与不相关的边界

协方差定义为 $\text{Cov}(x, z) = E[(x - Ex)(z - Ez)]$ ，等价于 $E(xz) - E(x)E(z)$ 。当两个变量倾向于一起高于各自均值时，协方差为正；一个高而另一个低时，可能为负。协方差为零只表示线性共同变化抵消，不表示完全没有依赖。对于关于零对称的变量， x 与 x^2 可以协方差为零，但知道 x 就完全知道 x^2 。联合正态分布中的零协方差进一步意味着独立，是特殊性质而非普遍规律。

线性组合的方差展开为

$$\text{Var}(a_1x + a_2z) = a_1^2 \text{Var}(x) + a_2^2 \text{Var}(z) + 2a_1a_2 \text{Cov}(x, z).$$

这里的交叉项不能省略。两只亲属记录的平均、两个性状的综合分数和同一动物重复测定的平均，都依赖该项。若两条方差均为十六的记录相关为一半，它们平均值的方差为十二；若误当作独立，就会得到八，从而夸大信息。反过来，某些负关联设计能使差异或平均更精确，但这种负关联必须来自真实设计或合法模型，不能为了获得较小标准误而随意指定。

相关系数为 $\rho = \text{Cov}(x, z) / (\sigma_x \sigma_z)$ ，前提是两个标准差均为正。由非负方差 $\text{Var}(x - \rho z) \geq 0$ 可以推出协方差的绝对值不超过两个标准差的乘积，因此 $-1 \leq \rho \leq 1$ 。达到边界时，中心化变量之间存在线性确定关系。若输入

两个方差和一个协方差后得到相关绝对值大于一，问题不是“生物关联特别强”，而是数据尺度、估计或矩阵拼接不相容。

相关不提供因果方向。母羊记录与羔羊记录相关，可能来自遗传传递、母体环境、共同饲养、选择性配种以及测量过程。只把相关称作遗传联系，会高估可传递部分；只因存在环境因素就否认遗传联系，同样不对。合理模型要利用不同关系和不同环境组合产生的协方差差异区分来源。亲属结构、跨场连接和重复记录的作用，正是为这些区分提供信息，而不是仅仅扩大样本量。

边际相关与条件相关也可能有很大差异。设两个年龄组各自内部的营养指标与体重正相关，但较大年龄组恰好总体营养指标较低且体重较高，混合之后的相关可能改变方向。这个现象说明，分析时的比较范围非常重要。不能把调整某个协变量后的关联自动称为“更真实”，因为调整变量可能是混杂来源，也可能是中介或选择形成的结果。统计校正应服从明确的研究与预测问题，而不是把所有可获得变量都加入模型。

在遗传预测中，记录间协方差表示信息重叠，记录与目标的协方差表示有用联系。两条记录都与目标高度相关，仍可能几乎提供同一份信息；另一条单独相关较小的记录，可能因携带独有成分而值得采集。因此，不能按单变量相关大小直接排列所有数据源的价值。后面将用条件残差和选择指数方程精确计算新增信息的作用，这也是从描述统计走向预测设计的关键一步。

协方差矩阵把这些两两关系放在同一整体中。每一个对角元素非负、每一对相关在负一与一之间，仍不足以保证整个矩阵合法；所有线性组合的方差还必须非负。例如三个变量两两相关不能任意各自指定而不顾共同实现的可能性。第2章将以正定性、特征值和矩阵分解说明这一要求。理解协方差的概率来源，能够防止把矩阵检查误当成与生物学无关的软件步骤。

1.6 抽样、独立信息与大样本近似

统计推断不是只处理已经观察到的一组数，还要说明这些数怎样进入样本。简单随机抽样、按家系抽样、按场分层抽样和仅保留优秀个体，会产生

不同的重复抽样分布。一个动物在数据库中有十条记录，不等于十只动物各有一条记录；十只全同胞也不等于十只互不相关的个体。若模型目标是个体间遗传变异，抽样单位与分析单位不一致可能造成伪重复，标准误即使计算到很多小数也不具有相应可信度。

大数定律在适当条件下保证样本平均趋向期望，但它并不承诺每增加一条记录，误差都按同一方向缩小。中心极限定理描述标准化样本均值的分布在适当条件下趋近正态，也不是任何原始数据到了某个固定数量就自动正态。重尾、极端不平衡、强相关和混合分布都会影响近似质量。分析稀有事件时，样本总数很大而实际事件数很少，常规正态近似仍可能表现很差。因此应检查与估计目标有关的信息量，而不是使用一个统一样本量阈值。

如果每组有 m 条等方差记录，同组任意两条记录相关为 ρ ，组间独立，则所有 n 条记录均值的方差为 $\sigma^2 [1 + (m - 1)\rho] / n$ 。括号内的量常称设计效应。它描述相对于独立抽样，相关性使均值估计方差扩大多少。若以相同方差的独立记录数作比较，可定义相应有效样本量 $n_{eff} = n / [1 + (m - 1)\rho]$ 。这个有效数量只针对该均值估计问题，不能认为它自动适用于所有遗传参数和预测目标。

算例：成组记录的数量与信息。设有十个独立群组，每组十条记录，单条记录方差为十六，同组相关为四分之一。总记录数为一百，设计效应为 $1 + 9/4 = 3.25$ ，均值方差为 $16 \times 3.25/100 = 0.52$ ，有效独立记录数约为 30.77。若错误地视为一百个独立记录，会得到方差 0.16。同样记录数下，扩大独立群组数量有时比继续增加同组重复更有效，但若目标是组内差异或个体轨迹，设计收益还需重新计算。

抽样权重也会影响所代表的群体。若为了捕获稀有品种而过度抽取该品种，未经加权的总体均值代表样本组成，不一定代表目标生产群体。逆抽样概率加权可以在一定条件下恢复目标总体的平均，但过大的权重会增加方差。遗传预测则还涉及训练群与候选群之间的亲缘和遗传结构，不能仅靠一个总体抽样权重解决所有可迁移性问题。抽样设计、参数估计和预测验证需要围绕同一个部署群体相互衔接。

有限总体抽样与超总体模型也应区分。如果目标只是当前圈舍中固定的

一百只动物的平均体重，对其中九十只无放回测量，抽样误差会比从无限总体独立抽取九十只更小；这是有限总体修正的来源。如果目标是未来多年的后代生产水平，当前动物只是更广泛过程的一次实现，有限总体中的高覆盖率并不消除未来遗传和环境不确定性。说明推断面向当前清单还是未来过程，可以避免把“基本普查”误解释为“未来没有误差”。

观察到异常值时，也要从抽样与测量过程出发。异常记录可能来自录入错误、设备故障或单位错误，也可能是真实罕见个体。仅因为某个值影响均值就删除它，会改变目标分布；不加核验地保留所有极端值，也可能让技术错误主导结果。合适流程是追溯原始记录，依据预先合理的规则处理，并检查结论对处理方式的敏感性。稳健估计可以减弱少数观测的影响，但不能替代对异常来源的识别。

1.7 条件分布与贝叶斯更新的手算结构

预测从无条件群体分布出发，在观察数据后更新为条件分布。离散情形可以直接列出联合概率；连续情形则把先验密度与似然相乘，再除以归一化常数。这里的先验可以来自明确的群体模型、历史数据或研究设计，并不等于主观随意猜测。反过来，任何先验都应说明来源与适用群体，尤其当新数据很少时，结果可能对先验有明显依赖。将这种依赖公开，比把模型假设隐藏在软件默认参数中更可审查。

例 1.1 离散遗传信号的非线性预测。设教学目标 u 以相同概率取 -2 或 2 ，独立环境误差 e 分别以四分之一、二分之一、四分之一概率取 $-2, 0, 2$ ，观察 $y = u + e$ 。观测可能为 $-4, -2, 0, 2, 4$ ，概率依次为八分之一、四分之一、四分之一、四分之一、八分之一。观察为零时，正育种值配合负误差与负育种值配合正误差同样可能，因而条件期望为零；观察为二或四时，育种值必为二；负值情况对称。

这个例子能够完整展示“数据改变概率”的过程。总体方差为 $\text{Var}(u) = 4$ 、 $\text{Var}(e) = 2$ ，观测方差为六。观察绝对值越大，并不意味着目标育种值可以无限增大，因为先验模型只允许两个目标取值。条件期望在观测为二与四

时同为二，是非线性并且饱和的。任何线性规则都只能折中拟合这些可能结果，不能同时达到所有条件均值。

条件方差也随观测改变。观察零时，目标仍以相同概率取正负二，方差为四；其他观测下目标已确定，方差为零。所以平均条件方差为 $\Pr(y = 0) \times 4 = 1$ 。这里某些数据给出完全确定的信息，另一些数据留下较大不确定性。连续正态模型中条件方差可能不随观测值改变，但那是特殊分布结构，不能推广为所有预测对象都只需要一个统一误差条。

例 1.2 基础频率决定阳性结果的解释。设某遗传携带状态的群体频率为十分之一，一项教学检测对携带者给出阳性的概率为 0.95，对非携带者给出阳性的概率为 0.10。阳性总概率为 $0.95 \times 0.10 + 0.10 \times 0.90 = 0.185$ ，阳性个体确为携带者的概率为 $0.095/0.185 = 19/37$ ，约为 0.5135。虽然敏感度较高，阳性之后仍有接近一半概率来自非携带者，原因是后者在群体中更常见。

若同样检测用于携带频率为二分之一的群体，阳性后携带概率变为 $0.475/(0.475 + 0.05) = 19/21$ 。检测机制没有改变，解释却明显变化。这个教学算例不提供任何具体检测方案建议，而是说明预测概率必须结合基础群体。标记关联、风险评分和疾病检测的外部应用都应检查基础频率与选择制度是否变化，不能把训练集中的阳性预测值当作检测本身永远不变的属性。

连续参数的贝叶斯更新同样遵循这一结构，但需要注意密度不能直接当成概率。一个参数在某精确点的后验密度较高，不意味着该点具有相应的点概率；区间概率要通过积分获得。最大后验点、后验均值和后验中位数分别服务于不同损失或摘要目的，也可能明显不同。后续复杂遗传模型即使依赖数值抽样，其逻辑仍是把联合模型与观察信息结合，计算目标条件分布。

1.8 条件期望为何是平方误差下的最佳预测

设可用信息为 y ，目标 u 有有限二阶矩，定义 $m(y) = E(u | y)$ 。考虑任何利用相同信息、具有有限均方的预测函数 $g(y)$ 。将误差分成 $u - g(y) = [u - m(y)] + [m(y) - g(y)]$ ，展开平方后，交叉项的期望为零。这是因为给

定 y 后，第二个因子已知，而第一个因子的条件期望为零。由此得到

$$E[(u - g(y))^2] = E[\text{Var}(u | y)] + E[(m(y) - g(y))^2].$$

右边第一项是在当前信息下无法由任何预测函数消除的平均不确定性，第二项是偏离条件期望所额外付出的代价。由于平方非负，条件期望使总体均方预测误差最小。这个结论不要求正态，也不要求线性，更不依赖某一种机器学习算法。它提供了比较算法的共同基准：算法只能尝试从有限数据估计这个条件结构，不能超过模型所给信息中的理论最优者。

这个推导也揭示最优的相对性。如果损失为绝对误差，最优预测通常是条件中位数；如果错误低估的代价高于高估，最优预测可能是一个条件分位数；如果决策是超过某阈值才留种，就应考虑与该决策相关的条件概率和收益。一个算法在均方误差上更好，不必在所有经营损失上都更好。应先明确目标损失，再选择概率摘要，而不是先得到一个分数再寻找适合它的解释。

条件期望还具有正交投影的含义。把所有平方可积随机变量看作一个以 $E(xz)$ 为内积的空间，所有由 y 决定的平方可积函数构成一个子空间。条件期望是 u 在这个子空间中的投影，预测误差与任何该信息下可计算的函数正交。读者不必先掌握完整的泛函分析，也能使用这一图景：最优预测保留现有信息能够解释的部分，剩余误差不再与任何可用信息函数存在线性内积。

由正交性可推出全方差公式： $\text{Var}(u) = E[\text{Var}(u | y)] + \text{Var}[E(u | y)]$ 。总体变异被分成已进入预测的差异和平均仍未解释的差异。在例 1.1 中，条件均值取零的概率为四分之一、取正负二的总概率为四分之三，所以条件均值方差为三；平均条件方差为一，二者相加恰为总体目标方差四。这是一项直接可核验的账本关系。

增加信息不会增加最优预测的平均均方误差，因为利用新旧信息的函数类至少包含只利用旧信息的全部函数。但是这一结论并不保证每个具体新观测都让条件方差下降。某些新观测可能揭示该个体属于更加不确定的亚群，使它的条件方差反而升高；平均意义下的信息收益仍可为正。更不能把理论总体已知时的投影结论，替换成有限样本下“加入越多变量越好”，因为估计复杂条件结构本身会产生额外误差。

当两个信息集合嵌套时, 迭代期望满足 $E[E(u | y, z) | y] = E(u | y)$ 。在尚未看到新信息 z 之前, 对未来更新后预测再取平均, 会回到当前预测。若某项新检测的模型在预先平均后总能让所有候选动物的预测同时提高, 就应检查基准是否改变或概率计算是否有误。真正的信息通常重新分配个体之间的判断, 并降低平均决策误差, 而不是无条件创造额外遗传优势。

1.9 最佳线性预测与选择指数的入口

完整条件分布很难已知, 记录与目标的二阶矩往往更容易建立。因此我们先把预测限制在线性函数中。设目标均值为零, 记录向量 $\mathbf{y}$ 的均值为 $\boldsymbol{\mu}$, 记录协方差为 P , 记录与标量目标的协方差向量为 C 。令 $\hat{u} = \mathbf{b}^T (\mathbf{y} - \boldsymbol{\mu})$, 则均方预测误差为

$$Q(\mathbf{b}) = \sigma_u^2 - 2\mathbf{b}^T C + \mathbf{b}^T P \mathbf{b}.$$

当 P 正定时, 对权重求导并令其为零, 得到 $P\mathbf{b} = C$ 。该二次函数具有唯一最小点, 所以解是所有线性预测中最优的。预测值的单位由目标确定, 权重则承担记录单位到目标单位的转换。若目标为向量, $C = \text{Cov}(\mathbf{y}, \mathbf{u})$, 预测为 $C^T P^{-1} (\mathbf{y} - \boldsymbol{\mu})$ 。在实际计算中应解方程而不必显式求逆, 具体原因留待第2章。

将最优权重代回, 可以得到 $\text{Cov}(\hat{u}, u) = \text{Var}(\hat{u}) = C^T P^{-1} C$, 预测误差方差为 $\sigma_u^2 - C^T P^{-1} C$ 。误差与每条记录不相关, 是线性投影的正交条件。若仍有某个线性组合与误差相关, 就能沿该方向调整预测而降低均方误差, 因此原预测不可能已经线性最优。这一反证思路比单纯记住求导公式更能帮助理解模型诊断。

最佳线性预测不一定等于条件期望。在例1.1中, $P = 6$ 、 $C = 4$, 所以线性权重为 $2/3$, 均方误差为 $4 - 16/6 = 4/3$ 。完整条件期望的均方误差为一, 因此非线性结构确实提供了额外收益。观测为二时, 线性预测为 $4/3$, 条件期望却为二; 观测为四时, 线性预测为 $8/3$, 已经超出目标允许的取值, 而条件期望仍为二。这不是代数错误, 而是线性函数类的限制。

例 1.3 两条记录的不同权重。设 $P = \begin{pmatrix} 10 & 2 \\ 2 & 5 \end{pmatrix}$, $C = (3, 1)^T$, 目标方差为

二。联立 $10b_1 + 2b_2 = 3$ 与 $2b_1 + 5b_2 = 1$, 得到 $\mathbf{b} = (13/46, 4/46)^T$ 。两条记录离均值为 $(2, -1)^T$ 时, 预测为 $11/23$, 预测误差方差为 $49/46$ 。第二条记录虽然与目标正相关, 但该动物的第二条离均记录为负, 因此在本次预测中下调结果。

这里需要区分权重的含义与单个记录的贡献。正权重不意味着该记录总使预测升高, 记录低于基准时其贡献仍为负; 负权重也不意味着某个性状生物学上不利, 它可能用来扣除共享环境或其他冗余成分。判断权重应同时查看 P 、 C 和记录尺度。若协方差估计存在误差, 极端正负权重可能不稳定, 但不能仅因权重符号不符合直觉就随意改写。

线性方法的优点是结构清楚、参数较少、容易检查和推广到大规模亲缘模型。非线性方法的潜在优点是捕获线性投影遗漏的结构。两者的比较不能停留在模型名称, 也不能把训练拟合提高当成未来预测提高。必须在同一目标、同一可用信息和合适验证设计下比较。当信息主要是家系相关而不是稳定的非线性机制时, 更复杂函数未必具有可迁移优势。

1.10 正态模型、收缩与预测区间

设 $u \sim N(0, \sigma_u^2)$, 独立误差 $e \sim N(0, \sigma_e^2)$, 观测 $y = u + e$ 。给定观测后, 后验密度与 $\exp[-u^2/(2\sigma_u^2) - (y - u)^2/(2\sigma_e^2)]$ 成正比。把关于 u 的二次项配方, 可得到条件方差 $v = (\sigma_u^{-2} + \sigma_e^{-2})^{-1}$, 条件均值 $m = vy/\sigma_e^2$ 。等价地,

$$m = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_e^2} y, \quad v = \frac{\sigma_u^2 \sigma_e^2}{\sigma_u^2 + \sigma_e^2}.$$

这个推导显示正态条件期望与最佳线性预测相同。权重等于信号方差在总方差中的比例, 因此观测偏离被缩向群体均值。若误差很小, 系数趋近一, 观测受到较高信任; 若误差很大, 系数趋近零, 当前记录几乎不能区分目标, 预测更多依赖群体中心。收缩不是把所有动物强行改得相似, 而是按照信息质量控制记录中噪声被误当成信号的程度。

例 1.4 单次生长记录的收缩。取 $\sigma_u^2 = 4$ 、 $\sigma_e^2 = 12$ ，记录已扣除已知均值，观察值为六。条件均值为 1.5，条件方差为三，预测值的总体方差为一。目标与预测的相关为二分之一，可靠度为四分之一。遗传力在这个特定模型中也为四分之一，但这只是单次自身记录、已知均值和参数条件下的巧合，不能推论所有遗传评定的可靠度都等于遗传力。

给定这条观测，育种值的正态条件区间可写为 $1.5 \pm 1.96\sqrt{3}$ 。如果希望预测未来一次相同条件下的表型 $y_{new} = u + e_{new}$ ，并假定新误差与已有数据独立、方差仍为十二，则条件均值仍为 1.5，条件方差却为十五。未来表型区间明显更宽，因为它同时包含育种值尚未确定的部分和未来环境误差。把育种值区间直接作为未来表型区间，是将两个目标混淆。

收缩与无偏的关系需要小心解释。本例总体上 $E(\hat{u} - u) = 0$ ，但给定真实育种值 u 后， $E(\hat{u} | u) = u/4$ 。因此，真实极端个体在重复测定下的预测会向均值偏移。与此同时，给定预测分数，在模型成立时有 $E(u | \hat{u}) = \hat{u}$ ，因为分数与原观测之间是一一线性关系。两种条件方向不同，并不矛盾。一个关系解释收缩，另一个关系解释校准。

若总体均值并非已知，直接把样本均值当作无误差常数会少算不确定性。在群体很小、比较组不平衡或个体与均值估计共享记录时，这一遗漏可能明显。后续混合模型通过同时估计固定效应和预测随机效应处理这种结构。此处保留均值已知假设，是为了隔离预测的基本逻辑，而不是建议生产评定忽略环境效应估计。

正态模型也有边界。若存在明显离散目标、零膨胀、截留或强偏态，条件分布未必对称，统一的均值加减标准差区间可能不适当。参数由有限数据估计时，条件方差还未必包括参数估计的不确定性。报告区间时应说明它针对哪个潜在量、条件于哪些已知参数和模型。区间是模型下的概率陈述，不能当作对所有可能建模错误的保证。

图 1.1 左侧对应离散例题：蓝点是每种可能记录下的条件期望，点面积表示记录发生概率；橙线是在全部直线中平方误差最小的预测。两者在部分记录处不同，说明最佳线性预测未必等于所有可测函数中的最佳预测。这里连接蓝点并不表示中间的记录值也有正概率，图中只有五种离散记录可能出




图 1.1 条件期望与正态信息更新的教学模型

现。

右侧使用本节独立的正态例题，灰线为观察前育种值分布，蓝线为观察到记录六之后的条件分布。均值由零移到一点五，方差由四降至三；阴影为该条件正态分布约百分之九十五的中心区间。两个面板描述不同模型，目的是比较非线性条件期望与正态收缩，而不是把左侧离散分布近似成右侧正态分布。

1.11 重复记录、永久环境与信息收益上限

同一动物重复测定可以减少某些误差，但不能自动增加独立遗传个体的数量。先考虑 $y_j = u + e_j$ ，其中临时误差彼此独立且与 u 独立，方差均为 σ_e^2 。平均记录与育种值的协方差仍为 σ_u^2 ，其方差为 $\sigma_u^2 + \sigma_e^2/n$ 。因此最佳线性预测为 $\hat{u} = \sigma_u^2 \bar{y} / (\sigma_u^2 + \sigma_e^2/n)$ 。每条记录权重相同，是等方差与交换对称结构的结果，不是所有纵向数据都应该简单平均。

例 1.5 三次记录的两种环境模型。仍取育种值方差四、单次环境方差十二。若三次临时误差独立，则平均记录方差为八，预测系数为二分之一，平均离均值六对应预测三，误差方差为二。相比单次记录的预测一点五和误差方差三，重复测定提高了目标信息。这里假定同一潜在育种值在三次记录中以相同系数出现，并且均值已经针对时间和其他系统差异正确校正。

现在将记录改写为 $y_j = u + c + \varepsilon_j$ ，永久环境 c 的方差为三，临时误差

的方差为九，所有成分互不相关。单次记录方差仍为十六，但三次平均方差为 $4 + 3 + 9/3 = 10$ ，预测系数降为 0.4，同样均值六对应预测 2.4，预测误差方差为 2.4。如果误把永久环境当成三次独立误差，就会报告过高的可靠度。两个模型对单次方差完全一致，却对新增重复记录的价值作出不同判断。

当重复次数趋于无穷，临时误差平均趋于零，记录只能精确揭示 $u + c$ ，不能单凭同一个体的数据区分其两个组成。极限预测系数为 $4/7$ ，极限误差方差为 $12/7$ ，可靠度上限为 $4/7$ 。上限来自可识别性，而不是数值算法不够强大。增加亲属、跨环境或直接遗传信息可能帮助区分，但能提高多少仍取决于新的协方差结构。一个常见的数据投资误区，是不断购买更高频率的同类记录，却没有改善限制目标识别的主要信息缺口。

重复力通常记为 t 。在只有加性育种值、永久环境和临时环境的模型下， $t = (\sigma_u^2 + \sigma_c^2) / \sigma_y^2$ ，遗传力为 $h^2 = \sigma_u^2 / \sigma_y^2$ ，因此 $0 \leq h^2 \leq t \leq 1$ 。平均记录的可靠度为 $nh^2 / [1 + (n-1)t]$ ，在 $t > 0$ 时极限为 h^2/t 。当 $h^2 = t > 0$ ，理论极限为一；若两者都为零，目标本身没有正方差，相关意义上的准确度不能照常定义。边界条件虽简单，却能防止公式被机械外推。

实际重复测定常不满足等相关。相邻两天记录可能比相隔半年更相似，幼龄体重和成年体重的遗传相关未必为一。若残差相关随时间间隔衰减，完整协方差矩阵中的每个元素都应反映间隔；若性状本身随年龄变化，应考虑随机回归或多性状模型。把不同年龄记录先求平均，会丢失轨迹形状，也可能把长期趋势与短期偏差混在一起。选择模型前，应先问决策关心平均水平、增长速度、极端时点还是整个生产曲线。

记录次数也可能与动物潜力相关。高产动物被保留更久，因而拥有更多后期记录；低产动物早期淘汰，后期信息缺失。若只对多记录动物求均值并与少记录动物比较，差异可能包含选择过程。正确处理取决于淘汰依据是否被记录，以及缺失机制是否能够在模型中说明。重复记录的数学价值与记录能够被观察到的机制，需要同时讨论。数据越长，并不意味着选择偏倚越小，有时恰恰意味着幸存者选择越强。

设计新测定方案时，可比较三种投资：增加同一动物的重复次数、增加独立动物数量、增加新的信息来源。第一种主要减少临时噪声，第二种扩大

群体覆盖与参数估计信息，第三种可能改善原本难以区分的成分。三者没有固定的优先顺序。若目前临时误差占主导，少量复测可能很划算；若永久环境与遗传混杂严重，再多复测也难突破上限；若参考群与候选群距离很大，增加更相关群体的记录可能更有价值。

1.12 准确度、可靠度、预测能力与校准

遗传预测研究中，一些表面相似的指标实际上回答不同问题。准确度通常指预测育种值与真实育种值的相关 $r_{u,\hat{u}}$ ，可靠度为其平方。在均值与协方差已知、预测按最佳线性尺度校准时，有 $r^2 = 1 - PEV/\sigma_u^2$ 。这个关系来自预测与误差正交，不能对任意分数直接套用。若把一个最优预测乘以十，相关不变，预测误差却显著改变；因此相关优良并不保证数值可以按原单位解释。

预测能力常用预测值与观察到的后续表型的相关衡量。在简单模型中，若后续表型为 $y_{new} = u + e_{new}$ ，新误差与预测独立且均值正确校正，则 $\text{Corr}(\hat{u}, y_{new}) = r_{u,\hat{u}}\sqrt{h^2}$ 。后续表型中的噪声压低观察相关。因此，不同性状的预测能力不能在不考虑遗传力和验证目标质量的情况下直接比较。反过来，若预测与后续记录共享环境或资料，观察相关又可能虚高，简单除以遗传力平方根也无法自动修复。

真实育种值通常不可观察，所以实际准确度估计依赖替代目标、子代信息、交叉验证或模型理论误差。每种办法都需要说明验证目标的误差、数据重叠和群体选择。用模拟中已知真实育种值检查算法，是验证计算与统计性质的有力方式；它不能证明模拟遗传架构就等于真实群体。现实验证则必须说明预测时哪些信息可用，以及验证个体与训练个体的亲缘关系。模拟与实证各有作用，不能互相冒充。

校准讨论预测值的数值是否对应真实平均。一个常见检查是在合适验证设计下回归验证目标对预测值，考察截距与斜率。理想的同尺度预测通常希望截距接近零、斜率接近一，但结论依赖验证目标和选择过程。若预测整体放大两倍，相关保持不变，校准斜率可能接近二分之一。若只存在固定基准

偏移, 排序相关可能很好, 却会在阈值决策中造成系统错误。因此, 评价至少应同时考虑排序、尺度与平均偏移。

均方预测误差可分解为平均偏差的平方加误差方差。对两个预测方法, 一个可能排序略好却具有严重尺度偏差, 另一个相关略低却在真实单位上更准确。生产场景决定哪种差异更重要: 如果只按固定比例选留, 排序较关键; 如果要预测后代收益、设定最低生产阈值或组合多个性状, 尺度校准不可忽略。仅报告一个相关系数, 往往不足以判断模型能否支持预期用途。

概率预测还需要概率校准。若模型把一批动物的事件概率都预测为百分之二十, 在长期同等条件下, 这批动物中事件发生比例应接近百分之二十。把所有对象都预测为总体发生率可能具有较好总体校准, 却缺乏区分能力; 把高低风险分得很开也可能系统过度自信。Brier 分数等平方概率损失同时评价预测概率与实际零一结果, 而对数评分对极端错误概率更敏感。具体评分应与研究目的和事件频率相匹配。

区间评价同样包含两个方面: 覆盖率与宽度。过宽的区间容易覆盖真值, 却缺乏决策价值; 过窄的区间看似精确, 却可能漏掉大量真实目标。比较区间时, 应在相同目标群体和相同名义水平下同时报告覆盖与长度, 必要时按可靠度、场次、家系或时间分组检查。总体覆盖率合格, 不保证每个子群都合格。若某个新场系统偏离训练条件, 总体平均可能掩盖该场的严重失准。

校准也会随部署环境变化。训练时期的均值、方差、管理和遗传结构与未来不同, 可能使原预测仍有一定排序能力却需要重新校准。更新应使用当时能够取得的独立信息, 不能先看未来结果再回头选择最有利的校准方案, 然后把同一批结果称为外部验证。研究者应保存原始预测、更新规则与评估时间, 使方法更新与事后解释能够区分。可追溯的评估流程, 是把统计指标变成长期育种证据的重要条件。

1.13 选择、缺失与数据被观察到的机制

育种数据库通常不是从基础群体中完全随机收集的。优秀动物更容易被测定、被基因分型、被保留到成年, 也更可能留下大量后代。记录是否出现,

本身可能携带与目标有关的信息。把这种选择当作无关的数据清洗细节，会改变均值、方差和协方差的解释。合适的分析不是要求所有资料都必须随机，而是明确选择规则，尽可能保留被选择前的信息，并使用与数据形成过程相容的模型。

考虑一个最简单的截留例子。若标准正态表型只保留大于零的个体，保存样本的平均值不再为零，而为 $\sqrt{2/\pi}$ ；其方差也低于一。若用保存样本直接估计原群体的表型均值和方差，就会得到偏移和压缩。这不是测量误差，而是条件分布发生了改变。对同一截留样本计算出的遗传相关和回归关系，也可能不同于原群体，尤其当选择涉及多个相关变量时。

选择造成的关联还可能发生在原本独立的成分之间。设表型是独立遗传与环境贡献之和，选择表型很高的个体后，遗传贡献稍低的入选者往往需要较高环境贡献才能达到阈值，因此在入选群中可能出现负的遗传—环境关联。由此不能反推基础群体中二者原本相关。这个现象提醒我们，给定一个共同结果进行选择，会改变其原因之间的统计关系；研究观察性资料时应说明分析群体是怎样被筛出的。

缺失机制通常需要相对于已观察资料来描述。若记录缺失与所有有关变量无关，是很强的完全随机缺失假设；若给定已观察协变量后，缺失与尚未观察的目标无关，可能在适当模型中得到可忽略机制；若缺失仍依赖未观察结果，就需要更强假设、补充设计或敏感性分析。这些术语不是给数据库贴上永久标签，同一缺失过程在不同已观察信息集合下可能具有不同可处理性。

例如，成年体重因动物提前出售而缺失。如果出售完全依据已经记录的早期体重、年龄和明确管理规则，在模型纳入这些信息后，处理可能相对可行；如果饲养者根据未记录的健康状况决定出售，缺失还携带隐含健康信息，仅靠观察到的体重难以恢复。补录出售原因、销售去向和健康事件，可能比更复杂的插补算法更有价值。缺失数据方法的能力，受到原始记录制度所保留信息的限制。

均值插补尤其需要谨慎。把所有缺失记录填成同组均值，会人为减少方差，并可能低估个体差异；将插补值当作真实观察，还会夸大信息量。多重

插补或联合模型可以传播部分插补不确定性，但仍依赖模型和缺失假设。用于预测时，插补模型只能在训练数据中建立，再按预定规则应用于验证对象。若利用验证结果或未来数据选择插补方式，就会把本不应可用的信息带入预测。

基因分型选择是现代育种中特别常见的问题。青年候选者可能按早期表现或系谱预测进入分型，高价测序可能集中于少数精英公畜。分型子集的遗传方差、频率和亲缘结构可能不同于全群体。将其当作基础群体来估计频率或验证模型，必须说明目标是否也仅限于同样的选择子集。统一评定方法能够利用更多记录，但它们仍需要正确的数据结构和选择信息，并不会自动消除所有选择造成的模型错误。

研究设计应优先保留选择前的候选清单、选择指标、测定资格、淘汰原因和实际繁殖贡献。这些字段使后来能够重建“在当时信息条件下发生了什么”，比仅保存最终优秀个体名单更有科学价值。对于已经无法恢复的缺口，应通过不同合理机制或参数范围检验结论敏感性，而不应宣称数据已经充分证明某种唯一解释。透明地呈现不可识别部分，有助于下一轮测定改进。

1.14 测量误差、层次结构与分布变化

表型记录首先是一个测量结果。真实生产量、测量设备读数与数据库存储值之间，可能经历校准、取整、单位换算、人工录入和质量筛选。经典加性误差模型把观测写成真实量加均值零的独立误差，只适合其中一部分情形。若设备偏差随体重增大，误差可能具有异方差；若所有同批记录共同偏高，则存在批次效应；若低于检测限的值被统一填为零，则是截断或删除，而不只是普通噪声。

测量误差对不同分析目标的影响不同。若作为结果变量的误差与预测信息独立，它通常增加不可解释方差，降低观察相关；若作为解释变量的误差未建模，回归系数可能向零衰减。设真实解释变量 x 与目标满足线性关系，观察为 $w = x + \delta$ ，独立误差方差为 σ_δ^2 ，则简单回归对 w 的斜率含有 $\text{Var}(x) / [\text{Var}(x) + \sigma_\delta^2]$ 的衰减因子。这与育种值预测中的收缩形式相似，来

源却是解释变量被污染，不能把两者概念混用。

重复技术测定可以帮助估计设备误差，但不能自动区分所有生物成分。对同一份样品重复检测主要揭示技术重复性；对同一动物不同时间重新采样，同时包含生物波动；对不同动物测量又增加个体差异。研究报告中若只说“重复三次”，读者无法判断误差层次。应说明重复发生在采样、实验、仪器还是动物层面，并在模型中保留相应嵌套或交叉结构。这能防止把技术重复误当成独立生物样本。

当多个实验室或设备合并数据时，单位一致不代表尺度已完全一致。两台设备都报告千克，却可能具有不同零点和比例误差。安排重叠样本、共同参考材料或交叉测定，可以估计校准关系；没有重叠时，设备差异可能与群体遗传差异混杂。把设备编号作为一个固定效应可能纠正均值差异，却未必纠正比例偏差、非线性和不同误差方差。数据合并前的可比性设计，是模型能够识别相关差异的前提。

分布变化可以发生在多个层次。群体均值变化可能主要影响截距，方差变化影响收缩程度，记录与目标的协方差变化影响权重方向，目标定义变化则意味着原模型正在回答旧问题。一个预测器在新环境中准确度下降，不能仅归结为算法落后。先检查变化属于哪一层，有助于选择重新校准、重新估计参数、增加新群体记录或重新定义目标。不同问题需要不同更新，而不是所有情况下都重新训练一个更复杂模型。

训练集与验证集的标准化也属于测量与信息边界。训练均值、标准差、缺失填充值和特征筛选规则，都应在训练资料中确定并保存，再应用到验证对象。若把所有数据一起标准化，虽然不总造成严重偏差，但已改变了预测时可获得的信息；若标准化涉及结果或未来环境，信息泄漏可能明显。最清楚的操作是模拟真实部署流程：先固定过去可见资料，再产生未来预测，最后仅用未来结果评价。

对于肉羊等强家系结构群体，随机拆分动物常让训练与验证包含大量近亲。这样的设计可以回答“在同一体系中预测与训练动物关系密切的候选者”这一问题，却不能自动回答跨家系、跨世代或跨地区迁移。验证划分应与未来用途一致，并说明为何选择该划分。多个验证方案不是为了挑出最好看的

数字，而是分别测量不同预测距离下的信息保持程度。后续章节将把这一点放到基因组模型与真实数据流程中具体讨论。

数据质量改进与模型改进应同时评价成本和可持续性。减少一次身份错配可能比增加一个复杂特征更有价值；保留原始时间戳可能使未来能够识别设备漂移；记录未测原因可能使缺失分析成为可能。高质量数据不是把所有不整齐的值删去，而是使每条记录的来源、变换和适用范围可追踪。概率模型依赖可解释的随机过程，数据治理则负责让这个过程在实际工作中保留下来。

1.15 顺序更新与新增信息的决策价值

预测往往不是一次完成的。青年动物先有系谱和早期记录，随后获得基因型、成年表现和后代信息，每次新增信息都更新对目标的判断。若使用正态独立误差模型，后验精度具有可加性：先验精度加上各条独立观测的测量精度，得到更新后的精度。对同一目标 u 的观测 $y_j = u + e_j$ ，误差方差为 v_j ，则条件方差为 $\left[\sigma_u^{-2} + \sum_j v_j^{-1}\right]^{-1}$ ，条件均值是以相应精度加权的总和。

这个规则不能用于共享误差而不作修改。若两条预测都已经利用同一批亲属资料，把它们各自的可靠度转换为精度后相加，会重复计算共同信息。信息来源不同的文件或平台，不意味着统计独立。应建立联合协方差，或者明确提取尚未利用的新增部分。单步和多源遗传评定的困难之一，就是在保留各类数据价值的同时处理这种重叠，而不是简单增加权重。

新增一条记录的线性价值可以通过条件残差计算。设已有记录为 $\mathbf{y}_1$ ，协方差为 P_1 ，与目标协方差为 C_1 ；新增标量记录为 z ，其方差为 v ，与旧记录协方差为 p ，与目标协方差为 d 。从新记录扣除旧信息能解释的部分，得到 $z - p^T P_1^{-1} \mathbf{y}_1$ 。它的剩余方差为 $v - p^T P_1^{-1} p$ ，与目标的剩余协方差为 $d - p^T P_1^{-1} C_1$ 。

当剩余方差为正时，新增记录带来的预测方差增量为

$$\Delta V = \frac{(d - p^T P_1^{-1} C_1)^2}{v - p^T P_1^{-1} p}.$$

这同时给出平均预测误差方差的减少量。若分子为零，新记录虽然含有未被旧记录解释的波动，却没有额外目标信号；若分母也为零，新记录只是旧记录的确定性线性组合，应删除冗余或使用相容的广义逆表示，不能把零除零解释为无限信息。这个公式把“新平台是否值得”转化为一个具体问题：它新增的是有用目标信号，还是已有信息与独立噪声的重新包装？

统计信息价值不完全等于经济决策价值。若两只候选公羊的预测差距远大于不确定性，新增检测虽降低误差，却很少改变留种选择；若两只候选者很接近，少量信息就可能改变决策并带来较大期望收益。正式的信息价值应比较观察新信息后采用最优决策的期望收益，与当前信息下最优决策的收益，再扣除采集成本和等待成本。降低均方误差是一个有用代理，但不是所有经营问题的最终目标。

等待本身也有代价。后代测定可能显著提高准确度，却延长世代间隔；青年期低成本数据可能准确度略低，却允许更早更新亲本。第1章只说明这种权衡来自信息与时间的共同作用，后续选择反应章节将把准确度、选择强度、遗传标准差和世代间隔放进同一个框架。对育种计划，最优信息不是越晚越完整越好，而是在未来遗传增益、成本和风险之间合理配置。

顺序设计还可以优先测定最需要新信息的对象。较低可靠度、与训练群距离较远或处于关键决策边界的动物，可能具有较高边际测定价值；但如果只测定这些动物，后续评估又必须考虑选择性测定。一个可持续方案通常同时保留代表性样本和有针对性的加测：前者支持群体监测与参数更新，后者服务即时决策。如何分配比例取决于目标与预算，需要明确模拟和实际记录支持，不能从一般原则直接给出通用百分比。

本章建立的概率工具最终都回到同一个工作顺序：明确目标和决策，界定可用信息，写出联合结构，计算条件判断，再用符合未来用途的资料检验。遵守这个顺序并不使问题变得简单，却能把不确定性放在应有的位置。它让读者知道何时可以手算，何时需要矩阵，何时必须改进数据设计，以及何时一个精确数字其实超出了现有信息所能支持的范围。

1.16 平方可积空间中的预测几何

有限个记录的最佳线性预测，可以通过解一组正规方程得到。但是，允许使用记录的平方、阈值指示或任意非线性函数后，候选预测规则变成无限多维，为什么仍然存在一个共同的最优原则？关键在于把随机变量本身视为几何空间中的向量。这里的长度不是一张数据表中若干数的平方和，而是在规定总体分布下的平均平方。这个区别使总体预测理论与有限样本拟合既能联系，又不会混为一谈。

设所有变量定义在同一概率空间中，目标育种值满足二阶矩有限。将几乎处处相等的随机变量视为同一个元素，定义

$$L^2 = \{v : E(v^2) < \infty\}, \quad \langle v, w \rangle = E(vw).$$

相应范数为

$$\|v\|_2 = \{E(v^2)\}^{1/2}.$$

两个变量的差在此范数下为零，只要求它们在概率一的集合上相等，不要求在不可能发生的情形中也逐点相同。这正好符合概率预测的含义：模型不通过一个零概率例外判定两种规则有不同风险。另一方面，平方可积是实质条件；若目标没有有限二阶矩，均方误差可能对所有规则都无穷大，以下最优性比较便不能原样使用。

用信息集合所生成的事件结构表示已知资料，记为 $\mathcal{I}$ 。所有能够仅由该信息决定、且平方可积的随机变量，组成子空间 $L^2(\mathcal{I})$ 。它不仅对加法和倍数封闭，而且对均方收敛封闭。因此它是闭子空间，任意平方可积目标在其中都有唯一的正交投影。关于条件期望的这一几何表述，可与 Williams (1991) 的概率论体系对照阅读；以下直接给出预测中所需的论证。

若 m 是投影，任取 $h \in L^2(\mathcal{I})$ ，沿方向 h 微调得到

$$\|u - m - th\|_2^2 = \|u - m\|_2^2 - 2tE[(u - m)h] + t^2E(h^2).$$

由于零点必须使该二次式最小，一阶项必须消失，即

$$E[(u - m)h] = 0 \quad \text{对所有 } h \in L^2(\mathcal{I}).$$

特别取任何已知事件的指示函数 $h = 1_B$, 就有 $E(u1_B) = E(m1_B)$ 。这正是条件期望的积分刻画, 因而投影为 $m = E(u | \mathcal{I})$ 。反过来, 若条件期望存在, 上述等式先对指示函数成立, 再对简单函数和其适当极限成立, 从而建立整个闭子空间中的正交性。这个证明说明, 最优性来自所有可用方向上的剩余平均信号为零, 远不只是残差与某一系列记录不相关。

于是对任意可用预测 g , 有勾股分解

$$E[(u - g)^2] = E[(u - m)^2] + E[(m - g)^2].$$

第二项描述规则本身相对最优条件均值的距离。它并不因为预测使用更多变量、更高次数或更复杂函数而自动减少。只有新增规则更接近当前真实条件均值时, 风险才会下降。这个判断针对总体; 从有限数据估计规则又增加了一层误差。把理论上更大的函数空间与样本中更可靠的估计等同起来, 正是过度拟合问题的起点。

手算例: 分组信息对应哪个子空间。设四种等可能状态中的育种值依次为负二、零、二、四, 观察只告诉我们属于前两种还是后两种。无信息时最佳常数为—; 知道组别后, 两个组的最佳预测分别为负一和三。直接枚举可得

$$E(u) = 1, \quad \text{Var}(u) = 5, \quad E[(u - m)^2] = 1, \quad \text{Var}(m) = 4.$$

这里组别函数空间只有两个自由水平, 却已经解释了五分之四的总体变异。若另一规则把两组分别预测为零和二, 其风险为二; 它与最优预测之差在每个组内绝对值均为一, 所以额外风险恰好为一。四个状态逐项平方即可验证, 无须正态假设, 也无须把组别人为编码成某个特定数字后解释编码系数。

值得进一步辨析的是, 残差与信息正交, 不意味着残差独立于信息。可以在一个组中令残差取正负一, 在另一组中取正负三, 组内均值仍为零, 条件均值预测仍然最优, 但是观察组别会改变误差大小。条件方差不同并不推翻投影结论, 只说明“预测中心”和“预测风险”是两个需要同时建模的对象。一个只报告条件均值的系统, 可能已经把均值预测做到最优, 却仍遗漏对测定资源分配十分重要的异方差信息。

闭子空间还解释了逐步增加函数的极限。若一系列有限维空间逐层包含，并且其并集在全部可用平方可积函数中稠密，则相应投影在均方意义下趋近条件期望。稠密是逼近能力的条件，有限样本稳定性则是另一个条件。实际育种研究往往能够不断增加基因型特征，但不能同时无限增加独立训练动物；因此无限维投影提供的是目标和误差分解，不能被误读成一个不需要正则化或外部验证的拟合方案。

1.17 信息增加为何不保证每只动物的条件风险都下降

设今天可见的信息为 $\mathcal{I}$ ，明天补充测定后可见的信息为 $\mathcal{J}$ ，且前者包含在后者之中。定义两个条件均值 m_I 和 m_J 。这里要求预测目标、参考群体和概率模型保持相同；如果明天顺便改了目标单位或群体基准，两个预测的差就不再单纯表示新增信息。信息嵌套这一条件，使前一节的几何图景成为两层嵌套投影。

首先由迭代期望得

$$E(m_J | \mathcal{I}) = m_I.$$

所以更新量在旧信息条件下平均为零。若一种所谓更新在每个旧预测水平上都系统性上调，应先考虑模型基准、参数或目标定义是否改变，而不能直接将这种统一上调归因于信息变多。新测定可以使某只动物上调、另一只下调；在同一正确模型下，事前不能预知更新的有利方向。

把总误差拆成尚未解释的部分与更新量，可得

$$u - m_I = (u - m_J) + (m_J - m_I),$$

$$E[(u - m_I)^2] - E[(u - m_J)^2] = E[(m_J - m_I)^2] \geq 0.$$

这是总体平均风险的单调性。更细致地，对旧信息条件化，有

$$\text{Var}(u | \mathcal{I}) = E[\text{Var}(u | \mathcal{J}) | \mathcal{I}] + \text{Var}(m_J | \mathcal{I}).$$

等号中对新条件方差还保留了一次平均。漏掉这次平均，直接写成“每个新条件方差都不大于旧条件方差”，便得到一个通常不成立的结论。新信

息可能把原来混在一起的低风险和高风险个体区分开,从而让高风险个体获得更宽的区间。这不是预测失败,而是原来的平均风险不再适合描述该个体。

手算例:发现高变异亚群。令新检测结果为零或一,两者各占一半。结果为零时育种值恒为零;结果为一时育种值等可能取负二和二。在检测前,全体均值为零、方差为二;检测后的两个条件均值仍都为零,但条件方差分别为零和四。因此

$$E(u | J) = 0, \quad E[\text{Var}(u | J)] = \frac{1}{2}(0 + 4) = 2.$$

这项检测完全没有改善平方损失下的点预测,却明确指出哪些对象的不确定性更高。若后续昂贵测定只能分配给一半动物,应优先考虑有剩余变异的一组。是否最终值得检测还取决于成本和后续行动;但是将“均方误差没有降低”解释成“任何决策中都没有信息价值”,显然过强。中心信息与风险分层信息可以在同一个数据源中具有不同作用。

若信息按时间形成序列 $\mathcal{I}_0 \subseteq \mathcal{I}_1 \subseteq \dots$, 令 $m_t = E(u | \mathcal{I}_t)$, 则各期更新量在均方意义下互相正交。对于较早更新量,它已经属于较晚时期的旧信息,而后一个更新量对旧信息的条件均值为零。因此

$$E[(m_t - m_{t-1})(m_s - m_{s-1})] = 0, \quad s < t.$$

$$\text{Var}(m_T) = \text{Var}(m_0) + \sum_{t=1}^T E[(m_t - m_{t-1})^2].$$

这一关系把累计解释变异分配给各阶段真正新增的信息,避免重复计算旧记录的贡献。它也给出监测思路:大量动物在某次更新中反复呈现同方向偏差,可能提示基准、选择记录或模型发生了系统变化。但实际预测使用估计参数时,并不严格等于上述真实条件期望,故偏离此关系只能作为诊断线索,不能单凭一个经验相关就断定某类生物机制存在。

实际发布的可信区间还可能因参数不确定性扩大。某个新批次暴露了原来未被充分识别的场效应,重新估计后,部分个体区间变宽完全合理。此时不仅信息集合改变,对未知模型参数的判断也在改变。正确报告应说明是新增表型、补全身份、重新估计方差还是重新规定目标导致变化,让使用者能够区分合理更新与流程错误。

1.18 从原始记录到非线性特征的正交展开

最佳线性预测的“线性”总是相对于事先选定的特征而言。对原始记录的平方使用线性系数，仍属于扩展特征空间中的线性投影，却是原始记录的非线性函数。这个观察提供一条理解复杂预测的清楚路径：先明确允许使用哪些函数，再研究这些函数能够解释多少目标变异，最后讨论有限样本能否可靠估计其系数。不能仅凭模型名称判断它是否利用了非线性信息。

设记录 y 在负一与一之间均匀分布。其奇数次矩为零，偶数次矩满足

$$E(y^{2k}) = \frac{1}{2k+1}.$$

从常数、一阶项和二阶项出发，扣除重复方向，定义

$$\phi_0 = 1, \quad \phi_1 = y, \quad \phi_2 = y^2 - \frac{1}{3}.$$

直接积分可得各项两两正交，而

$$E(\phi_1^2) = \frac{1}{3}, \quad E(\phi_2^2) = \frac{4}{45}.$$

这里二阶项减去三分之一，并非形式上的中心化习惯，而是确保它不再重复解释截距。一般分布不对称时，二阶项还需要扣除对一阶项的投影。将某套正交多项式从一个群体机械搬到另一个群体，正交性可能消失，原来能够分别计算的贡献便出现交叉项。这与后面遗传效应编码依赖频率的现象具有同样的数学根源。

手算例：遗漏弯曲信号的代价。设目标满足 $u = y + y^2 + \varepsilon$ ，误差与记录独立、均值为零、方差为十分之一。只使用常数和一阶记录时，最优预测为三分之一加记录；加入中心化二次项后，得到完整条件均值。两种风险分别为

$$R_1 = \frac{1}{10} + \frac{4}{45} = \frac{17}{90}, \quad R_2 = \frac{1}{10}.$$

风险减少量恰好等于遗漏二阶方向的方差。这个结果不是来自二次模型在当前样本中拟合更好，而是从总体分布和生成结构直接算出。若真实目标

只有一阶信号、而二次系数从小样本估计，新增项可能增加未来风险。理论表达能力与估计误差需要放在同一个账本中，不能只展示训练残差减少。

一般地，设中心化特征 ϕ_j 两两正交且方差为正。目标在前若干个方向上的投影系数为

$$\gamma_j = \frac{E[(u - Eu)\phi_j]}{E(\phi_j^2)}, \quad m_K = Eu + \sum_{j=1}^K \gamma_j \phi_j.$$

由正交性得到

$$E[(u - m_K)^2] = \text{Var}(u) - \sum_{j=1}^K \frac{\text{Cov}(u, \phi_j)^2}{\text{Var}(\phi_j)}.$$

每项贡献非负，但是某一项记录方差很大，并不保证其分子大。相反，一个变化范围很小却与目标高度对应的方向，仍可提供重要预测信息。将“记录空间中占据主要变异”与“目标预测中最有用”区分开，是理解主成分回归、核方法和其他特征模型时应保留的基本判断。

另一个非线性来源是预测对象本身发生变换。若 $u | y$ 为均值 m 、方差 v 的正态分布，对平方育种值的最佳预测为

$$E(u^2 | y) = m^2 + v,$$

其条件方差为

$$\text{Var}(u^2 | y) = 2v^2 + 4m^2v.$$

手算例：先预测再平方为何不够。令先验育种值服从均值零、方差四的正态分布，记录为育种值加独立的均值零、方差四的正态误差，观察值为二。正态更新给出条件均值一、条件方差二。因此平方目标的条件均值是三，而不是一；其条件方差为十六。两只均值预测相同但条件方差不同的动物，对平方目标的预测也不同。这里平方目标仅用来揭示变换效应，并不表示育种计划应该最大化育种值平方。

同理，预测超阈值概率时，需要积分条件分布的尾部，而不是只比较条件均值与阈值。一个高度不确定的动物可能具有较高超阈值概率，同时也有

较大不利尾部风险。是否值得使用它取决于损失函数。非线性预测的价值必须连同目标尺度和决策后果解释，不能只用一个更复杂的函数替换线性指数就宣称完成了科学改进。

1.19 损失函数改变时最优预测如何改变

条件均值的最佳性质始终带有平方损失这一前提。育种决策有时重视绝对偏差，有时低估产能与高估产能造成不同代价，还有时关注灾难性结果的概率。不同损失对应不同最优行动，不能要求一个数同时代表条件均值、保守保障值和最佳经营决策。本节将预测动作记为 d ，以免与显性偏差或育种值混淆。

先考虑加权平方损失。给定信息后的条件风险为

$$R(d | \mathcal{I}) = E[w(u)(u - d)^2 | \mathcal{I}],$$

其中权重非负，相关条件矩有限，而且 $E[w(u) | \mathcal{I}] > 0$ 。将二次式展开并对动作求导，得到

$$d^* = \frac{E[w(u)u | \mathcal{I}]}{E[w(u) | \mathcal{I}]}.$$

若权重已经由已知信息确定，它在给定信息后只是正常数，便约去，最优行动仍是条件均值。只有权重在同一信息条件下还依赖未观察目标，才改变最优点。这一区分很实用：给高价值动物更高的评估权重，会改变总体评价对各对象的重视程度，却未必改变每个对象在平方损失下的最佳条件预测。

手算例：状态代价不对称的加权预测。目标等可能取零和二，对应权重分别为一和三。普通条件均值为1，加权最佳动作则为一.5。代入两种动作，有

$$R(1) = 2, \quad R(1.5) = 1.5.$$

一点五不是对真实目标均值更无偏的估计，而是在所指定损失下更合适的行动。若把它仍标注为普通育种值预测并用于其他线性目标，就会混淆预

测与风险偏好。信息相同而行动不同，不一定意味着双方对遗传规律有不同判断，也可能只意味着双方承担的错误代价不同。

绝对损失给出另一个重要例子。对连续条件分布，在可微点有

$$\frac{\partial}{\partial d} E[u - d | \mathcal{I}] = 2F(d | \mathcal{I}) - 1.$$

因此最优动作是条件中位数。存在概率质量点时，导数需改用左右导数，中位数集合仍给出最优解。比如目标以十分之九概率为零、十分之一概率为十，均值为十，中位数为零。动作零的平均绝对误差为一，动作一则为一点八；但是平方损失下动作一优于动作零。最优性并不存在脱离损失函数的统一排序。

若低估一单位的损失为高估一单位的若干倍，可用分位数损失表示。设 $0 < \tau < 1$ ，定义

$$\rho_{\tau}(r) = r\{\tau - 1(r < 0)\}, \quad r = u - d.$$

最优动作满足条件分布在点达到分位水平。连续情形下为

$$F(d^* | \mathcal{I}) = \tau.$$

分位水平越高，对低估的处罚相对越重，选择的保障值越高。对于有限离散分布，应使用分位数的区间定义，而不能强求等式恰好成立。将上下不同代价明确写入损失，比凭经验在均值预测上统一加一个“安全系数”更可解释，也更容易检查单位与决策后果是否一致。

还有一类常见决策并不要求预测某个连续数，而是决定是否采取行动。设不采取行动时发生不利事件造成损失 L ，采取行动支付确定成本 c 且完全避免该事件，则最优规则为

$$\text{采取行动} \Leftrightarrow \Pr(\text{不利事件} | \mathcal{I}) > c/L.$$

这里阈值来自损失比，不是来自习惯上的二分之一。如果行动只能部分降低风险、还存在副作用或资源限制，应把这些后果分别写入条件期望再比

较。概率预测是否校准与行动阈值是否合理，是两项独立工作；将分类准确率最高的阈值直接用于经营决策，未必符合真实损失。

对选种而言，若目标收益对育种值线性、亲本贡献固定且没有其他约束，按条件期望排序具有明确的期望收益依据。引入非线性健康损失、群体多样性或配种相容性以后，单个条件均值排序便未必充分。此时应保留目标的联合条件分布和协方差，将统计预测传递给决策层，而不是要求一个育种值分数承担全部风险管理职责。

1.20 校准、投影与跨群体风险分解

一个分数能够很好地区分高低对象，却可能系统放大或压缩差异。最清楚的校准对象，是给定该分数之后真实目标的条件平均。设任意平方可积分数为 s ，它可以来自线性模型、神经网络或经验评分，定义校准函数 $h(s) = E(u | s)$ 。只要评价群体的联合分布明确，这个定义不依赖评分算法的名称。

由同一个投影恒等式，有

$$E[(u - s)^2] = E[(u - h(s))^2] + E[(h(s) - s)^2].$$

第二项是分数尺度与目标尺度不一致所造成的额外平方风险。重新校准可以消除这一部分，但不能恢复评分时已经丢失的信息。如果两种完全不同的记录状态被压缩成同一个分数，而它们具有不同条件均值，任何仅依赖该分数的校准都不能再次区分它们。因此校准与信息充分性应分别评价。

若只允许仿射校准，最优截距与斜率为

$$b = \frac{\text{Cov}(u, s)}{\text{Var}(s)}, \quad a = E(u) - bE(s),$$

其中分数方差须为正。仿射校准后残差与分数正交，但仍可能与分数平方或某个区间指示相关。因此“回归截距为零、斜率为一”只检查均值和线性尺度，不能完整证明条件校准。检验不同分数区间的偏差、不同家系或环境中的偏差，往往能揭示总体线性回归掩盖的问题，但分组检验也需要足够样本与不确定性表达。

手算例：完全校准的常数预测仍可能无区分力。若全体目标均值为零，恒等于零的分数满足 $E(u | s) = s$ ，因而完全校准，却完全不能区分候选者。相反，把正确条件均值扩大两倍，排序和相关不变，均方风险却增加其自身方差。一个评价体系至少需要同时说明区分力、目标单位和误差水平，单独宣布“已经校准”不足以支持优良选种能力。

群体迁移时，再增加一层分布区分。以 P_0 表示训练群体分布， P_1 表示应用群体分布，两者不是本书观测协方差矩阵 P 。设各自条件均值为 $m_0(y)$ 和 $m_1(y)$ ，应用群体中的风险恒等式为

$$E_1 \left[(u - g(y))^2 \right] = E_1 [\text{Var}_1(u | y)] + E_1 \left[(m_1(y) - g(y))^2 \right].$$

若旧预测器就是 m_0 ，新增风险来自两个群体条件均值之间的差。这解释了为什么训练群体中最优的模型，在新环境中可以系统失准；最优性始终相对于特定联合分布，不是算法永久携带的属性。

手算例：关系反向时仅改截距无效。令两群体中记录都等可能取负一和一，训练目标为 $u = y + \varepsilon$ ，应用目标为 $u = -y + \varepsilon$ ，误差独立、均值为零且方差为四分之一。旧预测在应用群体中的误差为负二倍记录加误差，故

$$R_{old} = 4 + \frac{1}{4} = \frac{17}{4}, \quad R_{new} = \frac{1}{4}.$$

两群体记录均值与方差完全一致，简单标准化检测不出这种条件关系变化，截距校准也不能修复。这个构造并不声称真实育种体系常发生全部效应反向，而是清楚展示：只检查输入分布相似，不能证明预测联系保持。标记与目标之间关联因群体结构改变而变化，正需要这种条件层面的诊断。

若只有记录分布改变而条件目标分布保持，则在共同支持集上可用密度比重写应用风险。记 $w(y) = p_1(y)/p_0(y)$ ，有

$$E_1 \left[(u - g(y))^2 \right] = E_0 \left[w(y) (u - g(y))^2 \right].$$

这个等式要求应用群体出现的记录状态在训练群体中也有正概率，而且条件目标分布确实相同。若新群体出现训练资料从未覆盖的遗传背景，权重不能创造缺失的目标信息；若密度比极不均衡，估计又可能被少数对象主导。

明确这些边界后，重加权才是一个有条件的统计工具，而不是把任何跨群体问题化约为重新调整样本权重。

由此可见，投影语言把本章几个看似分散的问题连接起来：预测是在可用信息中选取目标的条件平均，校准是在已有分数中再次投影，新增信息扩大可用子空间，而群体迁移改变内积所依赖的概率分布。相同代数形式能够出现在不同问题中，但只要信息、损失或分布改变，最优规则与误差含义就必须重新检查。这也为后续选择指数和混合模型提供了比记忆一个矩阵公式更稳固的理解基础。

1.21 综合练习与解答

练习一：预测对象辨析。某育种场报告青年公羊“预测值为八，误差标准差为二”，并据此承诺其每只后代的出栏重都比群体平均高八千克。指出至少四个需要补充或纠正的地方，并说明哪些属于定义问题，哪些属于概率解释问题。

解答。首先需说明八的单位和目标，究竟是公羊自身加性育种值、传递能力、综合指数还是未来表型；这是目标定义问题。若八为加性育种值，在母本随机且其他条件相当时，其对子代平均的贡献通常为二分之一，不能直接把八作为每只后代的改变量。其次应说明比较基准、适用年龄和环境。再次，误差标准差二通常描述育种值尚未确定的部分，后代还存在配偶贡献、孟德尔抽样和环境变异。最后，“每只后代都达到”把条件平均误当成确定保证。正确报告应明确预测对象，再给出与后代目标相匹配的分布或区间。

练习二：条件概率与基础频率。某教学检测的敏感度为 0.9，非携带者阳性率为 0.05。当携带频率为 0.02 时，求阳性后携带概率；当频率提高到 0.20 时重新计算。解释为什么同一检测会产生不同结果。

解答。第一群体中，真阳性概率为 0.018，假阳性概率为 0.049，因此阳性后携带概率为 $18/67$ ，约为 0.2687。第二群体中，相应概率为 0.18 与 0.04，阳性后携带概率为 $9/11$ ，约为 0.8182。检测条件概率没有变化，变化来自先验基础频率。敏感度回答携带者有多大概率阳性，阳性预测值回答阳性者有

多大概率携带，两个条件方向不同。该计算不能替代具体检测性能的实际验证。

练习三：独立性与协方差。令 x 以相同概率取 $-1, 0, 1$, $z = x^2$ 。求二者均值、方差和协方差，并判断是否独立。若只报告相关为零，可能遗漏什么？

解答。 $E(x) = 0$, $E(z) = 2/3$, $\text{Var}(x) = 2/3$, 因为 z 为零一变量, $\text{Var}(z) = 2/9$ 。有 $E(xz) = E(x^3) = 0$, 所以协方差和相关均为零。但观察 $z = 0$ 就确定 $x = 0$, 观察 $x = 1$ 就确定 $z = 1$, 两者显然不独立。零相关只排除了线性共同变化, 没有排除确定性的非线性联系。这也是评估非线性预测潜在价值时需要考虑的基本例子。

练习四：线性预测与单位。设 $y = u + e$, 两者不相关, 方差分别为九和十六, 观测离均值为五。求最佳线性预测、误差方差、准确度与可靠度。若记录单位扩大一千倍而目标单位不变, 权重应怎样改变？

解答。观测方差为二十五, 记录与目标协方差为九, 权重为 $9/25 = 0.36$, 预测值为 1.8。预测误差方差为 $9 - 81/25 = 5.76$, 可靠度为 0.36, 准确度为 0.6。将记录扩大一千倍后, 记录方差扩大一百万倍, 记录与目标协方差扩大一千倍, 所以权重缩小一千倍, 预测值保持不变。如果权重数值不变, 就把单位变化误当成信息变化。

练习五：条件期望的最优性。不使用正态假设, 证明任意平方可积预测 $g(y)$ 的均方误差等于条件期望的均方误差, 加上它与条件期望之间平方差的期望。说明这个证明中最关键的条件化步骤。

解答。写 $m(y) = E(u | y)$, 将误差拆为 $u - m(y) + m(y) - g(y)$ 。平方展开的交叉项为 $2E[(u - m(y))(m(y) - g(y))]$ 。先对 y 条件化, 第二个因子已知, 可以移出内部期望; 第一个因子的条件期望为零, 因此交叉项消失。剩余第一项为 $E[\text{Var}(u | y)]$, 第二项非负。关键不是两个部分独立, 而是条件均值为零所带来的正交性; 独立性并非本证明所需。

练习六：重复测定的上限。设 $y_j = u + c + e_j$, 三类成分方差依次为四、二和六, 临时误差独立。求两次平均记录的方差、育种值预测系数、误差方差及无限次记录的可靠度极限。如果永久环境与育种值相关, 原公式能否直

接使用?

解答。两次平均方差为 $4 + 2 + 6/2 = 9$, 与育种值协方差为四, 预测系数为 $4/9$, 误差方差为 $4 - 16/9 = 20/9$ 。无限重复后只能观察到 $u + c$, 可靠度极限为 $4/(4 + 2) = 2/3$ 。若二者相关, 记录方差还含两倍协方差, 记录与育种值的协方差也不再只是四, 必须重新构造分子和分母。简单沿用独立成分公式会同时错估权重和不确定性。

练习七: 分组抽样设计。计划收集一百条方差为十六的记录, 同组相关为四分之一, 组间独立。比较十组每组十条与二十组每组五条时总体均值的方差。为什么这个比较不能直接决定最佳基因组参考群设计?

解答。前一种方差为 $16[1 + 9/4]/100 = 0.52$, 后一种为 $16[1 + 4/4]/100 = 0.32$ 。增加独立群组提高了本例总体均值的估计精度。但基因组参考群还服务于标记效应、遗传参数和具体候选者预测, 信息价值取决于亲缘、等位基因覆盖、环境连接及候选群结构。针对一个均值的有效样本量, 不是所有遗传任务的共同充分统计量, 应在明确目标下进一步比较。

练习八: 准确度与校准。某最优预测 $\hat{u}$ 的准确度为 0.7。研究者把所有预测乘以二, 得到分数 $s = 2\hat{u}$, 声称准确度提高了一倍。判断该说法, 并说明与原尺度真实育种值的回归校准会怎样变化。

解答。正常数缩放不改变相关, 因此新分数准确度仍为 0.7, 不可能因数值放大而变为 1.4。若原预测满足 $E(u | \hat{u}) = \hat{u}$, 则 $E(u | s) = s/2$, 回归校准斜率为二分之一。排序不变, 均方预测误差与原单位解释改变。这个例子说明准确度、可靠度和尺度校准是相关但不同的指标, 报告分数时必须保留目标单位和校准定义。

练习九: 验证设计。一批动物每只都有多次记录, 研究者将记录行随机分成训练与验证两部分, 并用训练部分中的个体身份预测验证记录。这样的验证回答什么问题? 若目标是预测下一代尚无记录的候选动物, 应怎样修改设计?

解答。行级随机划分可能让同一动物同时进入训练与验证, 主要评价对已知个体新增记录的预测, 其中共享育种值、永久环境和身份信息。它不等

于预测新动物，更不等于跨世代遗传预测。若未来对象是下一代候选者，应按个体和时间隔离训练与验证，并明确允许保留哪些祖先和亲属信息。标准化、参数调优及特征筛选也应只在训练期内完成。还可补充家系隔离验证，测量更远预测距离下的表现。

练习十：数据收集方案。某场已有少数优秀公羊的大量重复记录，但年轻母羊、早期淘汰个体和另一生产环境几乎没有数据。预算只允许新增一千次测定。请设计一个有原则的分配思路，并说明不能仅凭本题给出唯一最优比例的原因。

解答。先明确未来候选群与目标性状，再识别当前预测受限于临时误差、永久环境混杂、家系覆盖还是环境迁移。可安排一部分代表性样本补齐青年、淘汰和新环境信息，以支持参数估计和外部监测；另一部分用于决策边界附近或可靠度低对象的定向加测。设计应保留选择与缺失原因，避免新增偏倚。唯一比例还需要测定成本、遗传相关、记录误差、候选结构和预期决策收益，现有文字条件不足以识别这些量。合理答案应给出需要补充的数据与比较方法，而不是编造一个看似精确的最优百分比。

矩阵方法与稳定计算

2.1 从记录表到模型矩阵

矩阵并不是把简单问题写得抽象，而是让大量相同结构的等式能够同时表达和检查。一条表型记录可以写为均值、场次、动物育种值与误差的和，一百万条记录仍遵守这些规则。令 $\mathbf{y}$ 为 $n \times 1$ 的记录向量， $\mathbf{X}$ 为 $n \times p$ 的固定效应设计矩阵， $\mathbf{Z}$ 为 $n \times q$ 的随机效应设计矩阵，则模型写为 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \mathbf{e}$ 。每一个维数都有实际含义：记录数、需要估计的固定参数数，以及需要预测的随机量数。

设计矩阵的每一行对应一条记录，每一列对应一个效应或协变量。若一条记录来自甲场、雄性、第二胎母本，其相应分类列可以填一，其他水平列填零；年龄协变量列则填实际年龄或按约定中心化后的年龄。随机动物设计矩阵通常在对应动物列填一，但母体效应列要连接到母本，重复记录要连接到同一个动物。所有矩阵相乘的结果都可能具有正确维数，即使这些连接实际上填错，因此维数检查不能替代身份核验。

例 2.1 三条记录与两个场。前两条记录来自甲场，第三条来自乙场，只拟合两个场均值时， $\mathbf{X}$ 的三行为 $(1, 0)$, $(1, 0)$, $(0, 1)$ 。若固定效应为 $(10, 13)^T$ ，则 $\mathbf{X}\boldsymbol{\beta} = (10, 10, 13)^T$ 。如果改为截距与乙场相对甲场差异，设计行变为 $(1, 0)$, $(1, 0)$, $(1, 1)$ ，参数为 $(10, 3)^T$ ，拟合值完全相同。不同编码可以表达同一个均值空间，参数名称和数值却随编码改变。

若两个场指示列之外再加全为一的截距列，该截距列等于两个场列之和，三个参数不能唯一识别。软件可能自动删除一列、施加和为零约束或返回某个广义逆解。不能把不同软件得到不同场系数立即当作结果冲突，应先

比较编码和可估计对比。甲乙场差异及拟合值可能完全一致，单个参数却因基准不同而不同。理解参数化与模型空间的区别，是解释复杂分类模型的起点。

矩阵乘法要求相邻维数相容。若 B 为 $m \times n$ 、 D 为 $n \times k$ ，则 BD 为 $m \times k$ ，其第 i, j 个元素为 $\sum_l B_{il}D_{lj}$ 。通常 $BD \neq DB$ ，后一个乘法甚至可能没有定义。记录与育种值协方差 $C = \text{Cov}(\mathbf{y}, \mathbf{u})$ 为 $n \times q$ ，因而 $C^T P^{-1} \mathbf{y}$ 才给出 $q \times 1$ 的预测。写公式时先标注维数，可以在求解前发现许多转置错误。

行序和列序应通过标识保存，而不能依赖文件当前恰好一致。关系矩阵按甲、乙、丙排列，表型却按乙、甲、丙排列时，矩阵仍能相乘且可能正常分解，但结果已把亲缘信息连接给错误个体。建立统一个体字典、检查重复标识、确认缺失编码并保存模型矩阵的映射，是统计工作的组成部分。计算规模越大，越需要把这些规则自动化并留下可追踪记录，而不是希望人工排序永远正确。

2.2 向量、内积与线性投影的几何意义

向量可以表示多个观测，也可以表示一个效应在全部记录中的作用方向。向量 $\mathbf{x}$ 的欧氏长度为 $\|\mathbf{x}\| = \sqrt{\mathbf{x}^T \mathbf{x}}$ ，两个向量的内积衡量其方向一致程度。若内积为零，称二者正交。这里的正交是向量几何关系，与概率变量不相关具有相似代数结构，但需要区分对象：样本向量的内积由实际数值计算，随机变量的内积通常是乘积的期望。

一个向量在非零方向 $\mathbf{z}$ 上的投影为 $\mathbf{z}(\mathbf{z}^T \mathbf{x}) / (\mathbf{z}^T \mathbf{z})$ 。投影残差与 $\mathbf{z}$ 正交，因此再沿同一方向调整不能进一步减少平方距离。普通最小二乘将这个过程推广到 X 的列空间：寻找该空间中最接近 $\mathbf{y}$ 的向量。拟合值属于设计矩阵能够表达的均值模式，残差则是当前设计无法解释的部分。

若 X 满列秩，投影矩阵为 $H_X = X(X^T X)^{-1} X^T$ 。它满足对称性 $H_X^T = H_X$ 和幂等性 $H_X^2 = H_X$ ；已经投影到该空间后再次投影不会改变结果。残差投影为 $M_X = I - H_X$ ，并有 $X^T M_X = 0$ 。这些关系能够解释为什么最小二乘残差与设计列正交，也能帮助检查程序输出是否与所拟合模型相容。

算例：只拟合一个共同均值。对记录 $(2, 4, 6)^T$ ，设计列为全一向量。投影得到 $(4, 4, 4)^T$ ，残差为 $(-2, 0, 2)^T$ 。残差和为零，平方和为八。若增加线性趋势列 $(-1, 0, 1)^T$ ，这三条记录能被完全拟合，残差平方和为零。但完美拟合不意味着未来预测完美，它仅表明三个数恰好落在当前两维模型空间中；参数估计与未来噪声仍需讨论。

不同记录误差方差不同时，欧氏距离未必是合适尺度。广义最小二乘最小化 $(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^T \mathbf{R}^{-1} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$ ，相当于在由误差协方差定义的度量下寻找最近点。低误差记录受到较高信任，相关记录则不会被当成完全独立的信息。通过白化变换可以把问题转换为普通最小二乘，但白化只是重新表达同一信息，不会增加样本或消除模型错误。

几何图景还能澄清“控制某个变量”意味着什么。将结果和解释变量都从一组协变量的列空间中投影出去，再分析剩余部分，等价于在完整线性模型中考察相应效应。这是部分回归思想的基础。但剩余关联是否具有因果意义，仍取决于协变量角色与研究设计。投影可以精确完成代数扣除，不能决定应该扣除哪些变量。这个决定必须来自问题本身，而不是只看相关矩阵。

正交化常能改善计算和解释，却可能改变系数所对应的方向。原始性状经过旋转后，新的正交轴通常是多个性状的组合。如果这些轴用于预测，可以方便地计算；如果要解释生物作用，就要转换回原尺度，并考虑旋转是否随样本而变化。主成分、奇异向量和独立性状并不是同一个概念。正交只保证在指定数据或协方差尺度上的不重叠，不保证不同轴具有独立生物机制。

2.3 秩、参数约束与可估计函数

矩阵的秩表示列空间的维数，也等于行空间的维数。列数多于秩时，存在非零向量 $\mathbf{v}$ 使 $\mathbf{X}\mathbf{v} = 0$ ，于是参数 $\boldsymbol{\beta}$ 与 $\boldsymbol{\beta} + \mathbf{v}$ 产生相同拟合值。数据无法区分这些参数组合，称参数不可识别。不可识别不一定让所有科学问题都无法回答：某些线性对比仍由数据唯一确定，这些对比称为可估计函数。

对比 $\mathbf{l}^T \boldsymbol{\beta}$ 可估计的一个等价条件是 $\mathbf{l}$ 属于 $\mathbf{X}$ 的行空间，或者它与 $\mathbf{X}$ 的零空间中的所有方向正交。如果沿某个不可识别方向移动参数会改变该对比，

则数据无法确定它。用这一条件检查比简单询问“矩阵是否可逆”更有意义。分类模型即使采用冗余编码，许多组间差异仍可估计；反过来，删掉一列使程序给出唯一系数，也不一定让原本缺少数据支持的跨组比较获得信息。

以截距加两个场指示列为例，参数为 μ, h_A, h_B ，任意将截距增加常数、两个场效应同时减少该常数，拟合值不变。单独的截距和场效应不唯一，但 $h_B - h_A$ 不受这种变换影响，因此可以估计。设 $h_A = 0$ 、设 $h_A + h_B = 0$ 或使用最小范数解，都只是选择一个代表参数化。报告结果应说明约束，尤其当比较不同批次或软件输出时，不能把基准差异解释成遗传趋势变化。

更实质的不可识别来自设计断裂。若甲场只使用公羊 S，乙场只使用公羊 T，表型差异只提供场差加遗传差的一个组合。增加每组记录可以提高该组合的精度，却不能分开两部分。给随机遗传效应指定方差后，混合模型通常能产生唯一预测，但那部分分解依赖模型假设和亲缘信息，而不是新出现了直接对照。第 24 章将用遗传连接详细解释这一问题。

约束分为识别约束与科学约束。把一个分类水平设为零，通常只是使同一个模型参数化唯一；要求某个性状响应为零，则改变实际可行决策集合。两者不能混淆。识别约束不应改变可估计拟合值或对比，科学约束则可能牺牲目标响应。若改变基准水平导致同一可估计遗传比较发生变化，应检查软件实现、数据处理或约束是否意外改变了模型，而不是把这种变化当作正常现象。

在数值计算中还存在近似秩不足。两列不完全相同，却高度接近，数学上满秩但有限精度下难以稳定分开。秩判断依赖尺度、容差和奇异值分布，不应采用脱离单位的固定阈值。例如一列以克记录、另一列以千克记录时，原始尺度差异会影响数值诊断。应先理解列的含义与合理缩放，再利用稳定分解判断哪些方向具有足够信息。

对不可识别参数，最不合适的做法是 把一个软件返回值当成数据已经精确支持的事实。更有用的报告包括可识别对比、相应不确定性、造成缺口的设计模式，以及补充何种记录可以改善识别。连接两个环境需要跨环境遗传信息，区分两个高度相似协变量需要能够改变它们相对变化的设计，增加完全重复数据则无济于事。秩分析因此不仅用于排错，也能指导下一轮测定。

2.4 对称矩阵、正定性与合法协方差

协方差矩阵天然对称，因为交换两个变量不会改变协方差。对任意向量 $\mathbf{v}$ ，二次型 $\mathbf{v}^T P \mathbf{v}$ 等于线性组合 $\mathbf{v}^T \mathbf{y}$ 的方差，因此必须非负。满足这一条件的矩阵称为半正定；若对所有非零向量都严格大于零，则称正定。正定表示没有非零线性组合被记录结构确定为常数，半正定则允许完全冗余或其他确定关系。

二阶矩阵 $P = \begin{pmatrix} a & c \\ c & d \end{pmatrix}$ 正定需要 $a > 0$ 且 $ad - c^2 > 0$ 。这相当于两个方

差为正、相关绝对值小于一。对更高维矩阵，仅检查每对相关并不够。例如三个标准化变量，若第一与第二相关很高、第二与第三也很高，而第一与第三强烈负相关，这组三个关系可能无法同时实现。协方差合法性是整体约束，不能把每个元素看成彼此独立的自由参数。

对称矩阵可以作谱分解 $P = Q \Lambda Q^T$ ，其中 Q 的列为正交特征向量， Λ 对角线为特征值。正定等价于全部特征值为正，半正定等价于全部非负。将观测旋转到特征向量方向后，协方差变为对角矩阵，每个特征值表示该方向的变异。很小的特征值说明某种记录组合几乎没有变化，而非整个数据集没有信息；预测稳定性取决于目标是否需要利用这一方向。

一个合法的记录协方差 P 与目标方差 σ_u^2 还不足以保证任意 C 都合法。

联合矩阵 $\begin{pmatrix} P & C \\ C^T & \sigma_u^2 \end{pmatrix}$ 也必须半正定。当 P 正定时，这等价于 $\sigma_u^2 - C^T P^{-1} C \geq 0$ 。

这个余量正是最佳线性预测误差方差。若计算得到负 PEV 或可靠度超过一，应首先检查输入联合协方差是否相容，而不是把不可能的结果解释为超高预测能力。

实际协方差可能由不同来源拼接。一个性状方差来自成年群体，遗传相关来自青年群体，另一环境方差来自不同管理制度，单独看每项都有文献依据，合在一起却未必是同一联合分布。四舍五入也可能把接近边界的合法矩阵推到不定区域。应尽量采用共同数据和具有正定约束的参数化估计；必须拼接时，应核对群体、单位、基准和矩阵合法性，并评估合理修正对结论的

影响。

把负特征值截成一个小正数是一种数值修补，但它改变了模型。修补后某些相关和方差方向会变化，不能声称仍完全使用原始参数。对极小负特征值，应区分浮点舍入与实际不相容；前者可能只需对称化和适当容差，后者需要重新评估输入。加入对角扰动也有不同解释：可能是为独立测量误差增加方差，也可能只是为了计算稳定。应把统计含义写清楚，而不只说“为避免报错加一个小数”。

正定性还为优化提供保障。预测误差关于权重的二次函数，其曲率矩阵为 $2P$ ，所以正定意味着唯一全局最小值。若矩阵不定，沿某些方向二次函数可下降而没有合理方差解释，问题已经不再是合法的概率预测。线性代数因此不是附加在统计模型外面的技术，它把概率定义的基本约束转化为可检查的计算条件。

2.5 线性方程、消元与为何不必显式求逆

方程 $P\mathbf{b} = \mathbf{C}$ 描述最佳线性权重，理论上写成 $\mathbf{b} = P^{-1}\mathbf{C}$ 很简洁，但计算上通常不应先构造整个逆矩阵。求解只需要逆矩阵作用于特定右端，显式求逆却计算了大量并不需要的元素，增加运算、存储和舍入机会。对多个右端，可以先分解矩阵，再重复三角求解；矩阵分解的成本被共享，通常更有效。逆矩阵仍有理论和特定误差计算用途，但不应成为默认求解步骤。

高斯消元通过逐步消去变量，把方程化为三角形式。若主元过小，除法会放大舍入误差，因此一般需要适当选主元。对称正定矩阵具有更好结构，可采用不需普通行交换的 Cholesky 分解；一般非对称或不定系统则需要其他分解。算法选择取决于矩阵性质，不应看到“都是线性方程”就使用同一个求解接口而不检查假设。

手算两元方程时，消元过程能够揭示信息扣除。设 $p_{11}b_1 + p_{12}b_2 = c_1$ ，第二式为 $p_{12}b_1 + p_{22}b_2 = c_2$ 。从第二式减去第一式的 p_{12}/p_{11} 倍，得到 $(p_{22} - p_{12}^2/p_{11})b_2 = c_2 - p_{12}c_1/p_{11}$ 。左边系数是第二条记录扣除第一条后剩余的方差，右边是剩余目标协方差。消元不仅是算术技巧，也正对应条件

信息的逐步提取。

算例：原始协方差不等于新增信息。取 $P = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}$, $C = (2, 1)^T$ 。消元后第二个方程系数为二，右端为零，因此第二权重为零，第一权重为二分之一。第二条记录单独与目标有正协方差，但给定第一条后没有额外线性目标信号。若观测为三与二，预测为一点五。这个结果比简单比较两个协方差大小更能说明信息融合的逻辑。

求解之后，应检查残差 $\mathbf{r} = \mathbf{C} - P\tilde{\mathbf{b}}$ ，其中 $\tilde{\mathbf{b}}$ 为计算解。绝对残差大小受到单位与矩阵规模影响，通常还要考察相对残差或后向误差。较小残差表示计算结果近似满足方程，却不一定表示权重接近真解；如果矩阵病态，小方程扰动就可能对应大解变化。第2章后续将用条件数把这两个层次联系起来。

某些应用除了预测均值，还需要逆矩阵的特定对角元或某些对比误差。此时也不必自动计算整个逆：一个指定列可以通过以相应单位向量为右端求解得到，一个二次型则可通过一次针对该对比的求解计算。若需要全部个体的误差，成本可能明显高于只求预测均值，应在任务规划时单独估计。不能因为均值计算很快，就承诺同样速度得到所有精确可靠度；均值与完整误差输出对线性代数的需求并不相同。

对于需反复处理新候选数据的系统，矩阵不变而右端改变时，保存可复用分解往往比每次重新求解更重要。若矩阵参数更新，则旧分解不能不加检查地继续使用；若只是新增少量记录，可以考虑分块更新，但应核对数值稳定和模型是否同步变化。所谓高效实现，不只是把单次循环写快，而是识别哪些结构真正保持不变，避免重复计算，同时保证更新后的结果仍对应当前模型。

在教学程序中，显式逆矩阵有时便于展示公式和对照小例子；在生产程序中，应优先调用经过验证的稳定分解与求解例程。两者目的不同，可以并存。最重要的是保留一个低维、可独立手算的案例，使软件版本、矩阵编码或数据连接改变时能够核对核心结果。大样本运行成功并不能代替这个核

对，因为某些身份错位和转置错误在大样本中也可能产生表面合理的数值。

2.6 Cholesky 分解、白化与概率生成

对称正定矩阵可以唯一分解为 $P = LL^T$ ，其中 L 为对角线正的下三角矩阵。对二阶矩阵，先取 $l_{11} = \sqrt{p_{11}}$ ，再取 $l_{21} = p_{21}/l_{11}$ ，最后取 $l_{22} = \sqrt{p_{22} - l_{21}^2}$ 。每个新对角元都对应在扣除前面方向之后剩余方差的平方根，因此正定性保证根号内为正。这种递推将概率上的条件剩余与计算上的三角结构紧密联系起来。

例 2.2 完整三角求解。对上一节的 $P = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}$ ，有 $L = \begin{pmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{pmatrix}$ 。先解 $Lz = C$ ，由 $2z_1 = 2$ 得 $z_1 = 1$ ，再由 $z_1 + \sqrt{2}z_2 = 1$ 得 $z_2 = 0$ 。随后解 $L^Tb = z$ ，得到 $b_2 = 0$ 、 $b_1 = 1/2$ 。如果目标方差为二，PEV 为 $2 - C^Tb = 1$ 。每一步都能手算，也能与程序结果逐项对照。

白化变换令 $w = L^{-1}(y - \mu)$ ，则 $\text{Var}(w) = I$ 。这表示新变量具有单位方差且两两不相关；只有在联合正态等适当条件下，才进一步独立。白化后的平方长度为 $(y - \mu)^T P^{-1}(y - \mu)$ ，因此它自然出现在广义最小二乘、正态似然和马氏距离中。将相关数据变成不相关方向，是这些方法共享的几何结构。

白化也可用于产生具有指定协方差的教学数据。若 z 的分量独立且均为标准正态，令 $y = \mu + Lz$ ，则均值为 μ ，协方差为 P 。这种生成方式能够检查软件是否恢复理论矩，但一次有限模拟的样本协方差不会精确等于目标矩阵。报告模拟时应区分设计参数、随机实现值和重复模拟平均，不能因为某次样本偏差就判断生成公式错误，也不能只选最接近理论的一次结果报告。

正态密度涉及行列式 $|P|$ ，Cholesky 分解使对数行列式可稳定计算为 $2 \sum_i \log l_{ii}$ 。直接先求行列式再取对数，可能因大量特征值相乘而上溢或下溢，即使最终对数本身处于合理范围。类似地，二次型可以通过三角解后的向量平方和计算，而不显式形成逆矩阵。许多看似复杂的似然计算，实际上重复使用这两项稳定操作。

Cholesky 失败需要解释。若输入矩阵理论上应正定，失败可能来自数据错配、协方差估计不相容、尺度极端或浮点误差；若输入本来只是半正定，失败则符合预期。不能一律自动加对角数直到成功而不记录变化。可先检查对称性、最小特征值和输入量纲，再判断是否需要重新建模、删去冗余方向或采用适合半正定矩阵的分解。软件错误信息是诊断线索，不是必须掩盖的障碍。

在大型关系模型中，分解顺序影响稀疏填充，也影响实际内存与时间。改变变量排列不改变数学解，却可能显著改变分解中产生的非零元素数量。利用合适重排可以节省计算，但必须在解回原始个体顺序时恢复映射。若只保存数值矩阵而丢失排列信息，得到的预测可能被赋给错误个体。数值算法与数据标识管理在这里再次相遇，二者共同决定结果是否可用。

2.7 QR 分解与最小二乘的稳定求解

普通最小二乘通常由正规方程 $X^T X \hat{\beta} = X^T y$ 引出，这有利于理解导数和残差正交，但并不意味着数值实现必须先形成 $X^T X$ 。若 X 的列接近线性相关，交叉乘积会使条件数平方化，放大有限精度影响。QR 分解将 X 写为正交列矩阵 Q 与上三角矩阵 R_X 的乘积，直接在原设计矩阵上进行正交变换，通常更适合普通最小二乘求解。

对满列秩矩阵， $Q^T Q = I$ ，于是平方误差分为投影到 Q 列空间中的部分和与之正交的部分。最优参数满足 $R_X \hat{\beta} = Q^T y$ ，只需要一个上三角求解。理论上可以通过逐列 Gram-Schmidt 正交化理解这一过程；实际高精度实现通常采用更稳定的正交变换。学习算法时应区分用于直观推导的步骤与适合有限精度实现的版本，不能因为手算简单就认定它在所有规模上最好。

例 2.3 直线拟合的 QR 手算。 设解释变量为 0, 1, 2，记录为 1, 2, 2，拟合截距与斜率。设计矩阵第一列为全一向量，第二列为解释变量。第一正交方向为 $(1, 1, 1)^T / \sqrt{3}$ ；从第二列扣除均值后，得到 $(-1, 0, 1)^T$ ，标准化为第二方向。于是 R_X 的两行为 $(\sqrt{3}, \sqrt{3})$ 与 $(0, \sqrt{2})$ ，投影记录为 $(5/\sqrt{3}, 1/\sqrt{2})^T$ 。

从第二个三角方程得到斜率二分之一，第一个方程得到截距 7/6。拟合

值为 $7/6, 5/3, 13/6$, 残差为 $-1/6, 1/3, -1/6$, 平方和为 $1/6$ 。残差与全一列及解释变量列都正交。这个例子表明, QR 分解不是另一种统计模型, 它与正规方程针对同一个最小二乘问题, 只是计算路径不同。若两个实现结果明显不同, 应检查精度、秩判断和输入, 而不是把差异解释为统计观点不同。

带列主元的 QR 可以把较有独立信息的列优先排列, 并辅助识别数值秩。排列改变后, 参数必须按相反排列还原。对于高度相关协变量, 软件自动保留哪一列可能因尺度和容差改变, 单列系数解释因而不稳定; 可估计组合与拟合值可能更稳定。报告中应避免仅以某列被删除就断言其生物作用为零, 删除通常反映当前设计下无法独立估计。

加权最小二乘也可先白化再 QR。若误差协方差 $R = L_R L_R^T$, 令 $\tilde{X} = L_R^{-1} X$, $\tilde{y} = L_R^{-1} y$, 然后拟合变换后的普通最小二乘。这样保留原模型中不同记录质量与相关性, 同时利用稳定正交求解。不能仅把结果变量除以标准差而不变换设计矩阵, 因为那会改变模型含义; 同样, 存在残差相关时只按对角标准差加权还没有完成白化。

在实际研究中, QR 最适合解决的并不是所有问题, 而是明确的最小二乘与秩判断任务。大型混合模型可能更适合稀疏分解或迭代法, 基因组模型可能需要矩阵—向量操作。理解 QR 能够帮助我们识别正规方程的数值风险, 并为低维基准提供稳定参考。方法选择应基于矩阵结构、精度需求和可用内存, 而不是依据某个算法名称是否新颖。

2.8 奇异值分解、主方向与低秩近似

任意实矩阵都可以作奇异值分解 $X = USV^T$, 其中非零奇异值为对角矩阵 S 的正元素, U 与 V 给出相应正交方向。它将一个线性映射拆为输入空间旋转、沿不同方向伸缩、输出空间旋转。与只适用于方阵的特征分解相比, 奇异值分解适用于长方形设计矩阵, 因此在秩判断、广义逆、最小二乘和维数压缩中具有统一作用。

非零奇异值的数量等于秩。很小奇异值对应的方向在输出中几乎被压平, 反推输入系数时需要除以小数, 从而放大观测或舍入误差。若把这些方

向截掉,可以获得较稳定的低秩近似,但也删除了某些可能信号。截断阈值应依据噪声、目标和验证,而不是仅按累计解释变异达到某个固定比例。对于预测,低方差方向仍可能与目标高度相关,不能只因它解释的记录方差较小就认定无用。

主成分分析常以中心化数据的奇异值分解或协方差特征分解实现。它寻找记录中变异最大的正交方向,却不直接使用预测目标。因此,主成分适合描述结构、压缩冗余或检查异常,但前几个主成分不一定是最适合预测育种值的信息。某个大主成分可能主要反映设备批次或场次,而较小主成分可能携带关键遗传区分。使用主成分进入模型时,要解释其来源与是否可能吸收需要保留的遗传信号。

低秩表示在大规模关系矩阵中可能节省计算。例如用少量方向近似主要群体结构,再以对角或其他稀疏成分表示剩余关系。它改变的是协方差表示,误差大小应围绕预测任务评价。矩阵元素平均误差很小,不保证稀有家系、远缘候选者或关键对比的误差也小。若近似专门服务于某批候选动物,应检查这些对象的 PEV、校准或排序是否受到系统影响。

奇异向量的符号本身不唯一。将某一列 U 与对应列 V 同时乘以负一,重建矩阵不变。因此,不同软件输出的主成分符号相反通常没有实质差异。若奇异值重复或非常接近,对应方向还可以在该子空间内旋转,单个向量不稳定而整个子空间仍稳定。解释主成分载荷时,应避免把这种任意方向当成独立发现,比较时更应关注所张成空间和重建效果。

缺失数据与中心化会影响奇异值分解的含义。把缺失值填成零,只有在零恰好表示相应中心化均值且处理适当时才具有某种简化解释;否则可能制造虚假群体结构。按全体样本估计中心化与主成分后再进行训练验证,也可能提前使用验证群结构。若目标是未来部署,应保存训练中心与投影方向,再把未来记录映射到同一空间;重新计算主成分意味着更新模型,需要重新评估。

对教学而言,奇异值分解最重要的启发是区分“许多列”与“许多独立方向”。百万标记矩阵的列数很大,却受样本数、连锁不平衡和群体结构限制;重复变量能够增加文件体积,却不增加秩。与此同时,低秩也不等于没

有价值，它可能正反映有效遗传结构。应把维数、有效信息和计算表示分开讨论，才能合理选择精确或近似算法。

当特征数远大于样本数时，样本内存在许多能产生相同拟合值的系数向量。一个正则化规则会从中选择特定解，但不同规则可能给出相近预测而很不同的单标记系数。因而预测成功不能直接证明每个系数都被准确识别，也不能把系数大小无条件解释为因果效应。若研究目标从预测转为解释，需要额外的遗传设计、关联结构分析和不确定性评估。矩阵的行空间与零空间明确揭示了这种区别：数据只约束它能够观察到的系数组合，零空间方向上的解释主要来自所施加的结构。

2.9 条件数与扰动传播

条件数描述问题本身对输入扰动的敏感程度，不是某个求解器运行是否成功的指标。对可逆矩阵，在二范数下 $\kappa(P) = \|P\|_2 \|P^{-1}\|_2$ ；对称正定时等于最大与最小特征值之比。条件数很大，意味着存在某些方向，输入的相对小变化可能导致解的较大相对变化。实际误差是否达到这个最坏界，还取决于扰动方向，因此条件数提示风险，却不能独自决定所有预测都不可用。

若矩阵固定、右端由 C 变为 $C + \delta C$ ，解变化为 $\delta b = P^{-1} \delta C$ ，相对误差可以由条件数与右端相对扰动联系起来。若矩阵本身也被估计，影响更复杂，尤其当扰动使小特征值改变时。遗传模型中的协方差参数通常来自有限样本，所以病态性不只是浮点问题。即使使用无限精度算术，估计误差仍可能使权重不稳定；稳定求解不能代替可靠参数。

例 2.4 两条高度相关记录。 设 $P = \begin{pmatrix} 1 & 0.99 \\ 0.99 & 1 \end{pmatrix}$ ， $C = (0.20, 0.18)^T$ ，目标方差为一。公共方向 $(1, 1)$ 的特征值为 1.99，差异方向 $(1, -1)$ 的特征值为 0.01，条件数为一百九十九。解为 $b \approx (1.095477, -0.904523)^T$ 。两条记录大部分同步变化，模型却利用它们很小的差异区分目标，因此出现相反的大权重。

将权重分成公共与差异方向，可以写为 $b = (19/199)(1, 1)^T + (1, -1)^T$ 。

若输入误差主要沿共同方向,影响相对温和;若协方差差值略有变化,差异权重就可能明显变动。不能只看到大权重就认定模型错误,因为在确知总体协方差时它仍是最优解。真正需要判断的是这些微小差异是否被足够准确地测量和估计,以及未来环境中是否保持。

本例预测方差约为 0.0562814, PEV 约为 0.9437186。权重看似很大,目标信息却并不多,因为记录高度相关且目标联系较弱。这再次说明权重绝对大小不是信息量。若把同一记录换成不同单位,权重还会相应缩放。应同时检查预测方差、误差、参数敏感性和目标解释,而不能用某个系数超过一就作出结论。

数值稳定算法通常具有较小后向误差,即计算结果是一个与原输入很接近问题的精确解。若问题本身病态,这仍可能产生较大前向误差。区分前向与后向误差,能够解释为何一个高质量求解器不能保证所有系数都精确。实际报告可考察关键预测、对比或入选名单对合理输入扰动的变化,避免仅围绕无法稳定解释的单个系数争论。

缩放可以改善由单位造成的病态,却不能消除真实的近线性相关。把每列除以合适尺度,使数值量级相近,可能让算法更有效;若两列本质上记录同一信息,标准化后仍会高度相关。应先分辨病态来自单位差异、重复信息、弱识别还是不合理模型,再选择处理方法。删除变量、加惩罚和重新设计测定分别改变不同层面,不能当作可互换的修复按钮。

2.10 正则化、收缩与改变后的统计问题

正则化在原目标函数中加入对参数或函数复杂度的约束,以减少不稳定的影响。对线性权重,岭式问题可写为最小化 $b^T Pb - 2b^T C + \lambda b^T b$, 得到 $(P + \lambda I)b_\lambda = C$ 。在特征方向上,原来的倒数特征值变为 $1/(\lambda_j + \lambda)$, 因此小特征值方向受到相对更强的抑制。这是稳定性的来源,也是偏差的来源。

沿用例 2.4, 取 $\lambda = 0.1$, 得到 $b_\lambda = (2/11, 0)^T$, 明显小于原来的相反大权重。但若原始 P 与 C 就是真值, 必须仍用原模型计算预测误差: $\sigma_u^2 - 2b_\lambda^T C + b_\lambda^T P b_\lambda$ 。结果约为 0.960331, 高于不加惩罚时的 0.943719。这不是岭方法失效, 而是

提醒正则化不能在已知正确总体最优解之外凭空创造信息。

当协方差由有限样本估计时，未正则化解可能对估计误差非常敏感，适当惩罚有机会降低总体预测风险。收益取决于方差与偏差的权衡，需要符合未来目标的验证或有依据的概率模型。不能在训练集上选择使拟合最好看的惩罚，再用同一训练拟合声称外部改进；也不能仅因系数更平滑就断言生物解释更正确。稳定性是必要的考虑，但最终仍要看目标预测和决策表现。

一个常见错误是对惩罚权重继续使用 $\sigma_u^2 - C^T b_\lambda$ 作为原模型中的 PEV。该简式依赖最优方程 $Pb = C$ ，加惩罚后一般不再成立。正确误差要完整展开平方，或者在明确改变后的概率模型下重新推导。类似地，把原误差模型解释为加入独立测量噪声，与把同一矩阵扰动仅作为数值正则化，虽然可能产生相同代数解，其预测不确定性的含义却不同。

惩罚还与单位相关。若记录从千克改成克，权重缩小一千倍，直接惩罚权重平方的力度随之改变。保持相同数值的 λI 不会自动保持同一统计问题。可先在明确规则下标准化，也可采用与尺度相匹配的惩罚矩阵。无论哪种做法，都应保存尺度变换，并在报告中把系数和预测还原到可解释单位。所谓一个通用最优惩罚参数，离开变量尺度通常没有意义。

正则化也可以来自概率建模。例如在回归系数上赋正态先验，后验均值与岭解具有对应关系；不同系数方差或结构先验产生不同惩罚。这种对应有助于解释收缩，但不能把任何方便的惩罚都称为经过生物验证的先验。先验结构应与目标群体、效应分布或研究设计相联系，并接受敏感性分析。现代基因组模型中的许多差异，可以从它们如何分配不同方向的先验变异来理解。

选择正则化程度时，也应考虑实际决策稳定性。两个惩罚值可能具有相近均方误差，却在少数边界候选者上给出不同排名；另一些惩罚值看似让名单稳定，却只是过度收缩到几乎无法区分。可同时报告预测误差、校准、关键对比与入选稳定性，避免只优化单一表面指标。稳定而无信息的预测同样不能支持有效遗传改良。

图 2.1 左侧画出 $x'P^{-1}x = 1$ 的椭圆，其中两记录方差均为一、相关为零




图 2.1 近共线协方差的几何形状与预测权重敏感性

点九九。长轴和短轴所对应特征值为一点九九和零点零一；椭圆很薄，表示记录差异方向的变异很小。它是一条固定二次型等值线，并非本书另行指定覆盖概率的置信椭圆，不能把图形边界直接解释为百分之九十五区间。

右侧保持协方差向量共同部分不变，只让两项差异在很小范围变化。实线使用 $P^{-1}C$ ，虚线使用 $(P + 0.1I)^{-1}C$ 。前者沿小特征值方向放大扰动，后者明显降低敏感性，但改变了预测规则。图形说明稳定性收益，是否改善真实均方误差仍需在原模型中计算完整风险；权重曲线更平缓本身不是预测更优的充分证据。

2.11 广义逆与奇异协方差的相容条件

奇异矩阵没有通常意义下的逆，但某些线性方程仍有解，而且预测值可能唯一。广义逆提供一种表示这些解的工具。Moore–Penrose 广义逆可以通过奇异值分解，将非零奇异值取倒数、零奇异值保持为零得到。它给出最小范数最小二乘解，但最小范数是相对于当前参数尺度的数学选择，不自动具有特殊生物意义。使用广义逆之前，应先理解奇异性从何而来以及目标是否仍可识别。

例 2.5 完全重复的记录。设两条记录恒等，协方差为 $P = \begin{pmatrix} 4 & 4 \\ 4 & 4 \end{pmatrix}$ ，与目标协方差为 $C = (2, 2)^T$ 。方程只要求 $b_1 + b_2 = 1/2$ ，所以有无穷多组权重。

最小欧氏范数解为 $(1/4, 1/4)^T$ ，也可以取 $(1/2, 0)^T$ 。由于两条记录相同，这些权重给出完全相同的预测 $y_1/2$ 。参数权重不唯一，预测却唯一。

若把目标协方差改成 $(2, 1)^T$ ，方程就不相容。原因不是广义逆不够强，而是相同随机变量不可能与同一个目标具有不同协方差。差异方向 $(1, -1)$ 对记录而言恒为零，它与目标的协方差也必须为零。广义逆可以返回某个折中数值，却无法使不可能的联合概率结构成立。软件产生输出不等于输入统计模型合法，这在拼接多个来源协方差时尤需注意。

一般地，若 P 半正定， C 必须属于 P 的列空间，才能与记录的确立关系相容。对任何满足 $P\mathbf{v} = 0$ 的向量，都应有 $\mathbf{v}^T C = 0$ 。同时目标方差需足够大，使联合协方差半正定。在这些条件下，最佳线性预测可由广义逆表示，且不同相容广义逆产生相同的可预测量。应重点报告可识别预测与误差，而不是过度解释某一组任意权重。

奇异性还可能由中心化造成。若从一组记录中减去它们自身的样本均值，中心化残差之和恒为零，其协方差在全空间上奇异。把这个矩阵当作未约束原始记录协方差再求逆，就会产生问题。可以在去掉一个冗余方向后的子空间中工作，或显式使用投影结构。关键是保持中心化操作与协方差定义一致，不要把统计预处理当作不改变概率结构的简单格式转换。

在基因组关系中，标记数、样本数和中心化也可能使矩阵低秩。加入残差方差后，观测总协方差仍可正定，因此不一定需要单独对基因组关系矩阵求逆。选择适合的模型表达，有时能避免不必要的奇异逆问题。后续将看到标记效应模型与关系矩阵模型在适当条件下的等价性；二者计算规模和可逆性要求不同，可以根据数据结构选择，而不改变预测目标。

退化情形的处理应成为方法说明的一部分。相同个体重复编号、克隆、完全共线协变量与真正低秩遗传结构，虽然都可能导致奇异，却需要不同解释。删除一条完全重复记录通常不会损失信息，删除一个具有独立误差的技术复测却可能损失信息。是否冗余必须根据随机结构判断，不能只凭两行数值偶然相同。确定性重复与随机结果巧合相等，是两个不同概念。

2.12 分块矩阵 Schur 补与混合模型的计算桥梁

复杂模型常由几个信息块构成。将协方差写成 $P = \begin{pmatrix} P_{11} & P_{12} \\ P_{21} & P_{22} \end{pmatrix}$, 对第一块消元后, 第二块的剩余协方差为 $S = P_{22} - P_{21}P_{11}^{-1}P_{12}$, 称为 Schur 补。它是第二组记录扣除第一组线性解释后剩余变异的矩阵推广。若整体正定, 则第一块和 Schur 补都正定; 这一性质连接了分块消元、条件分布和新增信息价值。

若目标协方差对应分块为 C_1, C_2 , 第二块的新增目标联系为 $C_2 - P_{21}P_{11}^{-1}C_1$ 。计算可以先预测第二块可由第一块解释的部分, 再利用剩余部分更新目标预测。这样的顺序不改变联合最优结果, 但使信息重叠的来源更清楚。对于重复利用传统育种值和基因组预测的融合问题, 这种结构提示必须知道两类信息的共同部分, 不能仅凭各自可靠度做独立加权。

例 2.6 新记录的边际价值。取第一记录方差四、新记录方差三、二者协方差二; 第一记录与目标协方差为二, 新记录与目标协方差为一点五, 目标方差为二。新增残差方差为 $3 - 2^2/4 = 2$, 新增目标协方差为 $1.5 - 2 \times 2/4 = 0.5$, 所以预测方差增量为 $0.5^2/2 = 0.125$ 。原记录单独提供预测方差一, 联合后为 1.125, PEV 为 0.875。

直接求解得到权重 $(3/8, 1/4)^T$ 。若新记录与目标协方差改回一, 新增目标协方差为零, 就回到例 2.2 的零权重情形。两个算例只有一个输入差异, 却说明新记录的价值取决于条件目标联系, 而不是单独方差或记录数量。采购新测定时, 需要估计它与已有体系的联合结构; 只报告单个平台内部重复性, 不能证明其带来新增育种信息。

另一个重要恒等式处理低秩协方差更新。若 R 与随机效应协方差 K 正定, 观测协方差为 $P = R + ZKZ^T$, 则

$$P^{-1} = R^{-1} - R^{-1}Z(K^{-1} + Z^TR^{-1}Z)^{-1}Z^TR^{-1}.$$

这个表达说明, 可以在记录空间求解, 也可以转到随机效应空间中的一个系统; 哪一个更小、更稀疏, 取决于数据结构。它是连接边际模型与混合

模型方程的重要代数桥梁。这里写逆矩阵是说明恒等关系，实际仍可用分解和线性求解实现。若某个协方差仅半正定，需要另行考虑相容表示，不能无条件使用含普通逆的公式。

以三条同一动物记录为例， $R = 12I$ ， Z 为三维全一列， $K = 4$ 。则 $P = 12I + 4\mathbf{1}\mathbf{1}^T$ ，其逆可写为 $I/12 - \mathbf{1}\mathbf{1}^T/72$ 。与目标协方差为 $4I$ ，因此每条记录权重为六分之一，预测为三条记录和除以六，等于平均记录的一半。分块恒等式与第 1 章重复记录推导给出完全一致结果，提供了跨表达的核验。

分块方法还适合顺序增加数据或分布式计算，但必须保留块间协方差。把场次分开分析再简单平均，只有在相应条件下才等价于联合模型；若跨场亲缘和共同信息被忽略，分块只是数据切割，不是正确的分块代数。真正的计算分解应在重新组合时恢复联合结构。如何在效率、隐私和信息完整性之间取舍，需要具体模型与协议，不能从一个恒等式直接推导出任意分布式方案都精确。

2.13 迹、行列式与协方差参数的导数

矩阵的迹是对角元素之和，记为 $\text{tr}(B)$ 。对于相容矩阵，有 $\text{tr}(BD) = \text{tr}(DB)$ ，更长乘积可以循环移动因子，但不能任意交换顺序。这个性质常将标量二次型写成迹： $\mathbf{y}^T B \mathbf{y} = \text{tr}(B \mathbf{y} \mathbf{y}^T)$ 。若 $E(\mathbf{y}) = 0$ 、协方差为 P ，取期望得到 $E(\mathbf{y}^T B \mathbf{y}) = \text{tr}(BP)$ 。它是推导方差估计和检验量期望的基本工具。

若均值不为零，还要加上 $\mu^T B \mu$ 。忽略这一项，相当于把系统均值差异当作随机变异。对残差平方和使用迹公式时，投影矩阵和真实协方差都必须与模型相符。简单独立同方差情形下，残差平方和期望等于误差方差乘残差自由度；相关或异方差情况下，期望变为更一般的迹。由此可以理解为什么复杂遗传资料不能直接套用平衡方差分析的全部均方公式。

行列式刻画线性变换对体积的缩放。正定协方差的行列式等于特征值之积，在多元正态密度中控制分布占据的尺度。一个方向变异很大、另一个方向很小，可能与各方向都中等的矩阵具有相同迹，却有不同行列式和条件结构。只比较总方差不足以描述多维不确定性，似然同时使用对数行列式和

观测二次型，正是为了平衡分布体积与数据适合程度。

设 P 依赖参数 θ ，记 $P_\theta = \partial P / \partial \theta$ 。由 $PP^{-1} = I$ 求导，得到 $\partial P^{-1} / \partial \theta = -P^{-1}P_\theta P^{-1}$ 。在正定和可微条件下，还有 $\partial \log |P| / \partial \theta = \text{tr}(P^{-1}P_\theta)$ 。这些公式可以直接通过小扰动展开理解，但实现时仍不必形成完整逆矩阵，可以使用线性求解、迹计算或适当随机近似。

当均值已知为零，多元正态对数似然除常数外为 $\ell = -\frac{1}{2} \log |P| - \frac{1}{2} \mathbf{y}^\top P^{-1} \mathbf{y}$ 。其导数为

$$\frac{\partial \ell}{\partial \theta} = \frac{1}{2} \mathbf{y}^\top P^{-1} P_\theta P^{-1} \mathbf{y} - \frac{1}{2} \text{tr}(P^{-1} P_\theta).$$

第一项衡量观察数据在该协方差方向上的平方信号，第二项衡量模型预期的相应变异。若模型成立，其得分函数期望为零，因为二次型期望恰与迹项相抵消。这个结构将第1章期望规则与数值优化连接起来，也是理解方差组分估计的有效入口。固定效应未知时还要处理其估计与自由度，不能把这里的已知均值似然直接当作限制最大似然。

算例：重复记录方差的得分。取 $P = 12I + \theta \mathbf{1}\mathbf{1}^\top$ ，三条记录为六、四、八，在 $\theta = 4$ 时， $P^{-1} = I/12 - \mathbf{1}\mathbf{1}^\top/72$ 。观测二次型为 $31/6$ ，对数行列式为 $\log(3456)$ 。有 $\mathbf{1}^\top P^{-1} \mathbf{y} = 3/4$ ，以及 $\mathbf{1}^\top P^{-1} \mathbf{1} = 1/8$ ，因此得分为 $\frac{1}{2} [(3/4)^2 - 1/8] = 7/32$ 。正得分表示在该点沿增加参数的方向，已知均值似然局部上升，并不意味着参数已经估计完成。

参数化会改变导数尺度。若用 $\eta = \log \theta$ 保证方差正值，则由链式法则，关于 η 的导数等于 θ 乘关于 θ 的导数。协方差矩阵可用 Cholesky 参数化保证正定，但每个参数对原方差与相关的影响会更复杂。优化器收敛检查应在合理参数尺度下进行，并在结果报告时转换回原方差和相关。参数值接近边界时，常规对称标准误与正态近似可能不可靠。

数值导数可以作为实现校验，但步长需要选择。步长太大产生截断误差，太小则因相近函数值相减产生舍入误差。对低维教学例，可将解析导数与多种合理步长下的中心差分比较；在大型模型中，还应检查方向导数和目标函数变化是否一致。一次梯度很小并不保证全局最优，也不保证模型可识别，仍需结合边界、曲率和不同初值结果判断。

大型模型中,精确计算某些迹可能很昂贵。若随机向量 z 满足 $E(zz^T) = I$, 则 $E(z^T B z) = \text{tr}(B)$, 因此可以用多个随机二次型平均近似迹。这个估计引入额外蒙特卡洛误差, 需要与优化容差协调; 不能把含明显随机噪声的目标或梯度当作完全精确函数。固定随机种子有助于复现某一次计算, 却不会消除估计误差。报告时应说明随机向量数、误差控制和对最终参数的影响, 并在可精确计算的小模型上核对其平均行为。

2.14 稀疏结构与迭代求解

动物模型的设计矩阵通常非常稀疏。一条记录只连接少数固定水平和一个动物, 母体模型再连接一个母本, 不需要为每条记录保存与所有动物的零关系。稀疏存储只保留非零位置及数值, 可以大幅降低内存, 但乘法和索引必须与稀疏格式相匹配。若在某一步无意把稀疏矩阵转成稠密, 前面节省的内存可能立即失去。高效程序应从完整计算流程检查结构, 而不是只看输入文件采用什么格式。

系谱逆矩阵也具有局部亲子结构, 可以直接累加构建, 这一思想是大规模遗传评定的重要基础 (Henderson, 1976)。但基因组关系往往稠密, 不能期待同样的存储优势。某些模型可以改写为标记矩阵乘法或低秩结构, 从而避免显式形成完整关系矩阵。哪种表达最合适, 取决于动物数、标记数、记录数和所需输出; 数学上等价的模型可能具有很不一样的计算代价。

共轭梯度法适用于对称正定系统, 它通过一系列矩阵—向量乘法逐步逼近解, 不必显式分解矩阵。在精确算术下, 至多经过矩阵维数次迭代可以得到解; 有限精度和大规模应用中, 实际更关心在合理迭代次数内达到所需预测精度。算法利用相对于矩阵度量的共轭方向, 避免简单最速下降不断沿近似相同方向来回修正。条件数越大, 通常越需要有效预条件。

例 2.7 两步共轭梯度。 求解 $Bx = d$, 其中 $B = \begin{pmatrix} 4 & 1 \\ 1 & 3 \end{pmatrix}$ 、 $d = (1, 2)^T$, 从零向量开始。初始残差和方向均为 d , 第一步长为 $d^T d / (d^T B d) = 1/4$, 得到 $x_1 = (1/4, 1/2)^T$, 残差为 $(-1/2, 1/4)^T$ 。新方向为该残差加初始方向的 $1/16$

倍, 即 $(-7/16, 3/8)^T$ 。

第二步长为 $4/11$, 于是得到 $x_2 = (1/11, 7/11)^T$, 代回方程精确成立。这个例子能检查方向、内积、步长和更新顺序。它也说明迭代法不是简单反复套用同一修正, 而是使用相应共轭结构。在大型问题中, 浮点误差可能破坏精确共轭, 停止标准和预条件因此十分重要, 不能把低维精确两步收敛当作所有模型的表现。

预条件通过一个容易求解、能够近似原矩阵的系统改善谱结构。对角预条件最简单, 可以校正部分尺度差异; 分块预条件能够利用固定效应、随机效应或家系结构。预条件改变计算路径, 但正确实现应保留原方程的目标解。不能把预条件矩阵直接替换原协方差并称为同一模型, 除非明确采用了近似。要区分“用近似帮助求解精确问题”与“直接求解近似问题”。

停止标准应与决策精度有关。相对残差达到某个阈值是基础检查, 但病态系统中还应观察关键预测、目标函数或对比在后续迭代中的变化。若不同容差导致入选名单在关键边界上改变, 应了解差异是否小于统计预测误差, 必要时继续求解。计算误差通常应控制在不影响科学结论的范围, 但无需把所有问题都求到远低于数据精度的程度。合理精度是有目标的, 而不是越多小数越好。

并行计算还涉及归约顺序。浮点加法不满足严格结合律, 不同线程或硬件上的求和顺序可能产生极小差异。稳定累加、确定性设置和容差比较可以帮助复核, 但不应要求所有平台输出逐位完全相同而忽略真正重要的误差尺度。另一方面, 若差异大到改变模型结论, 就不能简单归咎于硬件, 应追查算法、随机种子、数据顺序和收敛条件。

矩阵无显式存储的计算进一步利用“只需乘法”的事实。若关系矩阵由标准化标记矩阵构成 $G = MM^T/s$, 计算 Gv 可以先算 $M^T v$, 再算 $M(M^T v)/s$, 无需保存整个 G 。这种表达在动物数很大时可能节省内存, 但每次迭代仍需访问标记数据, 时间成本取决于存储布局、缓存和矩阵规模。若标记数也极大, 分块读写可能成为瓶颈。评估算法时应同时记录峰值内存、数据读写与实际求解时间, 避免只比较理论乘法次数。

预条件和无显式存储方法还应核对算子对称性。一个实现若在左右乘法中采用不同标准化、不同缺失填充或不一致样本顺序，可能不再对应同一个对称矩阵，即使每一步维数都正确。可以用若干独立向量检查 $v^T(Bw)$ 与 $w^T(Bv)$ 是否相符，并在小样本中与显式矩阵对照。这类检查直接针对实现可能破坏的数学结构，比只重复相同输入看输出是否一致更能发现实质问题。

2.15 单位变换、中心化与协方差的一致更新

线性尺度变换必须同时作用于记录、协方差和目标联系。设 $\mathbf{y}^* = S\mathbf{y}$, S 为可逆尺度矩阵，则 $P^* = SPS^T$ 、 $C^* = SC$ 。为了保持同一预测，权重应变为 $b^* = S^{-T}b$ ，从而 $b^{*T}\mathbf{y}^* = b^T\mathbf{y}$ 。这条恒等式提供一个很有辨识度的软件核实验：改变单位并相应变换所有输入后，预测应保持不变。

算例：体重单位改变。取 $P = \begin{pmatrix} 9 & 3 \\ 3 & 4 \end{pmatrix}$ 、 $C = (3, 2)^T$ ，目标方差为二，原记录为 $(2, 1)^T$ 。权重为 $(2/9, 1/3)^T$ ，预测为 $7/9$ ，PEV 为 $2/3$ 。将第一记录扩大一千倍，新的第一权重缩小一千倍，预测和 PEV 不变。若只改记录而忘记改协方差，或只改对角方差而漏掉非对角协方差，都会破坏这个一致性。

中心化与缩放不同。减去已知常数均值不改变协方差，但减去同一批样本估计出的均值，会在有限样本中引入约束和共享估计误差。若预处理直接移除了每个场的平均，后来又希望估计场间遗传均值差异，就可能已经丢失所需信息。中心化应与模型中的固定效应结构协调，不能把“所有列均值为零”当作无条件正确的目标。某些比较所需的均值差异，本来就是科学对象的一部分。

标准化后的系数便于比较数值尺度，但并不自动代表可比的生物重要性。把各性状除以自身标准差，相当于以一个标准差为单位；原经济权重必须相应转换，才能保持目标不变。若直接对标准化性状赋相同权重，就改变了价值判断。对于基因型计数，按频率方差标准化还会改变不同频率位点的相对先验贡献，后续基因组模型将说明这种选择的统计后果。

数据合并时还要同步变量定义。日增重与总增重、活重与胴体重、疾病

计数与发生指示、原始值与对数值，都不是仅凭单位标签相近就能合并的变量。若确有可验证的变换关系，可在模型中处理；若关系依赖年龄或环境，应保留这些信息。矩阵运算无法判断变量列是否语义一致，因此建立数据字典和转换规则与计算本身同样重要。

一个可复现分析应保存原始单位、中心化常数、标准化因子、训练期范围和输出还原规则。未来候选者进入时，采用训练阶段确定的变换，还是按新群体重新估计，代表不同部署策略。前者保持模型坐标一致，后者可能适应新的分布但也改变基准，需要重新评估。任何更新都应有版本，避免同一动物分数变化后无法分辨是新资料、参数更新还是尺度定义改变。

2.16 一个完整的计算核验流程

一套可审查的预测计算，应从问题说明而不是从求解器开始。首先明确目标变量、观测范围、固定效应与随机成分；然后建立个体和记录标识，检查单位与时间顺序；接着构造均值、协方差和目标联系，确认矩阵维数与排列；最后选择适合矩阵结构的求解方法。每一步输出都应能追溯到前一步，使错误能够定位，而不是在最终排名异常时只能反复更换算法。

矩阵检查包括对称性、对角量级、有限数值、正定或半正定要求，以及联合协方差相容性。近似对称矩阵可以因浮点误差出现极小偏离，但较大不对称通常意味着构造或对齐错误。检查最小特征值时应结合矩阵尺度和容差，不能把任何负的小数都同样处理。对大型矩阵，可以使用针对性的谱估计或分解诊断，但应了解检查本身的近似性。

之后用低维解析例题核对核心路径。例 2.2 检查 Cholesky 与目标协方差方向，例 2.3 检查 QR、截距与趋势编码，例 2.5 检查重复记录和广义逆，例 2.7 检查迭代更新。这些例子各自针对不同风险，不是把同一实现抄成另一段测试代码。有效核验应具有独立依据，例如手算、不同数学表达或解析极限，才能发现共同实现错误。

在真实规模上，应检查求解残差和关键输出的一致性。若两种数学等价表达可行，可以在一个中等子集上比较；若使用近似算法，应量化近似对预

测、PEV 或决策的影响。对实际数据进行一次完整求解并不等于证明任何未来输入都正确，但可以验证该数据结构下的计算路径。遇到具体剩余风险再扩大测试，比无目的地重复同类检查更有效。

报告结果时，应把数值误差与统计误差区分。求解器容差、矩阵近似和浮点舍入属于计算层面；有限样本方差参数、模型错设和目标群体变化属于统计层面。前者通常可以通过改进算法进一步降低，后者需要数据和研究设计。一个模型可以被计算得非常精确，却预测得并不好；也可能统计模型合理，但求解过早停止破坏结果。两层都应达到与用途相适应的要求。

最后，应保存足够的复现材料：数据版本标识、变量映射、参数、随机种子、软件版本、主要求解设置和输出摘要。若涉及隐私或不能共享的原始数据，可以提供可运行的教学数据、数据字典和核验案例，但不能把教学验证称为真实数据复现。复现材料的目标是让其他人知道结果如何形成，以及哪些部分已经验证、哪些部分依赖无法公开的资料。

对持续更新的遗传评定，还应建立前后版本的差异核对。新增记录后，预测变化应能够追溯到新信息、参数或基准更新；若所有动物同时发生异常跳变，应优先检查均值和尺度。保存少量固定参考个体、关键对比和模型摘要，可以帮助识别身份错配或系统性漂移。版本核对不是要求预测永不变化，而是要求变化有可解释来源。随着数据规模增长，这种持续审计往往比一次性的漂亮运行结果更能保证系统可靠。

2.17 常见误解与研究判断

第一类误解是把可逆性当作科学信息充分性的同义词。加一个小对角数通常能使矩阵可逆，却没有补充缺失的跨场对照；对参数施加惩罚能得到唯一解，却不意味着每个效应都被数据独立识别。应区分数据支持、先验约束与数值正则化三种来源。唯一的数值答案可以很有用，但它的解释必须包含产生唯一性的条件。

第二类误解是把更高精度或更大算力当作对模型错误的补救。双精度甚至更高精度能够降低舍入误差，却不能纠正错配的亲子关系、错误单位或来

自不同群体的协方差。更快的求解器也不能改变目标定义。计算投入应优先针对当前瓶颈：若矩阵构造错误，先改数据；若估计不稳定，先研究参数与设计；若算法耗时阻碍合理验证，再优化实现。

第三类误解是把某个矩阵元素或系数的变化直接归因于生物变化。关系矩阵的基准频率、标准化、样本组成和变量编码都能改变数值。若比较两个版本，首先应将它们放在相同尺度与基准下，再讨论差异。对于预测分数，正常数缩放不改变排序，却改变原单位校准；对于协方差，尺度变化会同时影响行列与交叉项。忽略这些关系容易制造虚假的方法优势或遗传趋势。

第四类误解是认为稀疏一定优于稠密、迭代一定优于直接分解。稀疏优势取决于非零模式与填充，迭代优势取决于条件结构与所需精度，直接分解则可能在多个右端复用时更划算。一个小而稠密的系统可能比一个庞大稀疏系统更容易处理，某种低秩近似也可能使关键候选者失准。应围绕具体规模、结构和输出需求比较，不宜用算法标签替代实测与误差评估。

第五类误解是将任何数值差异都视为不可复现。浮点计算、随机模拟和优化容差可能导致最后若干位不同，重要的是差异是否在预先合理的数值范围内，是否影响统计结论和决策。相反，若差异具有系统性、随群体或家系集中，或超过预测误差所允许的范围，就值得深入检查。可复现性不是所有机器输出逐字节相同，而是清楚定义的过程能产生相容的科学结果。

这些判断构成数值线性代数与统计建模之间的接口。经典矩阵教材和数值稳定性专著对分解、条件数与误差分析提供了系统论述（Golub 与 Van Loan, 2013; Higham, 2002）。对育种研究者，最重要的不是记住每种算法全部推导，而是知道自己的模型需要什么结构、求解器依赖什么假设，以及哪些诊断能够发现对科学结论有实质影响的问题。

2.18 从整体条件数走向具体目标的误差控制

一个线性系统可能包含上百万个未知量，研究者最终却只关心某两个候选者的差异，或某个场的平均遗传水平。此时，全部系数向量的相对误差并不完全等同于科学问题的误差。整体条件数给出最坏方向的警示，而具体目

标是否敏感,还取决于目标方向、右端扰动方向和弱识别方向是否相互重合。把这一点写成公式,能够使停止迭代和模型敏感性分析更有针对性。

设对称正定系统为 $Bx = d$, 需要报告的标量目标为 $q = l^T x$ 。数值解为 $\tilde{x}$, 以原方程计算残差

$$r = d - B\tilde{x}.$$

再解一个同矩阵、不同右端的伴随系统

$$Bz = l.$$

由于 $x - \tilde{x} = B^{-1}r$, 有精确恒等式

$$q - \tilde{q} = l^T B^{-1}r = z^T r.$$

右端把残差按照目标真正关心的方向重新加权。某些方程残差虽很小,若伴随权重很大,对目标仍可能重要;另一些残差较大,却与目标方向正交,完全不影响该对比。伴随向量不是新的统计数据,也不会降低原模型的预测误差,它只是说明计算误差如何传递到报告量。

手算例: 很小残差隐藏一个完整单位的差异。令 B 的两个对角元为一和万分之一,右端为一和万分之一,则精确解为两个一。若迭代暂时给出一和零,残差只有第二个分量为万分之一,整体相对残差约为万分之一。但是第二个系数的误差仍为一。取第一坐标为目标时,伴随向量为一和零,目标误差为零;取第二坐标为目标时,伴随向量为零和一万,目标误差正好为一。

这个例子说明,采用同一个残差阈值比较所有模型,可能遗漏重要方向。若第二个系数只代表一个没有实际用途的冗余参数,继续高精度求解未必值得;若它恰好决定跨场关键对比,则必须进一步计算。需要控制的不是抽象的小数位,而是科学结论对计算误差的容许程度。Higham (2002) 对前向误差、后向误差与条件性的区分,为这种目标导向判断提供了系统基础。

还可利用矩阵诱导范数给出界。定义 $\|v\|_B^2 = v^T B v$, 由 Cauchy 不等式得

$$|q - \tilde{q}| \leq \sqrt{l^T B^{-1} l} \sqrt{r^T B^{-1} r}.$$

第一个因子描述目标在该方程度量下的敏感程度，第二个因子描述残差对应的能量误差。若只知道普通欧氏残差，可再用最小特征值给出保守界，但这会丢失方向信息。实际可用已经建立的预条件系统近似这些量；近似界若要作为严格保证，还需说明预条件矩阵与原矩阵之间的谱界，不能把经验上接近的量当成已证明上界。

输入矩阵本身也可能受到扰动。令新系统为 $(B + E)(x + \Delta x) = d + f$ ，直接整理得到

$$\Delta x = (B + E)^{-1}(f - Ex).$$

当扰动较小时，保留一阶项有

$$\Delta q \approx z^T f - z^T E x.$$

这一式区分了记录或右端变化与系数矩阵变化。若某个方差参数影响许多矩阵元素，应该通过其整体导数作用计算，不能将每个元素的最坏扰动独立叠加后称为实际误差。相反，身份顺序错配可能造成有结构的大扰动，即使若干元素的平均差很小，也不能由一般小扰动公式为它提供保证。

在遗传预测中，权重敏感与预测敏感也应分开。若某一记录方向在应用群体中几乎没有变异，沿该方向的系数可以变化很大，而实际预测变化较小。设两组权重相差 δb ，中心化应用记录协方差为 P ，则

$$E[(\delta b^T y)^2] = \delta b^T P \delta b.$$

例如 P 的对角元为一和万分之一，权重第二分量改变一，预测变化方差只有万分之一。这个结果不允许忽略所有大系数，因为应用群体的协方差若改变，原来低变异方向可能不再低变异。它只是要求评价稳定性时把权重、记录分布和最终目标同时放入问题，而非只看系数表中的绝对差。

因此，一个有解释力的数值核验应首先列出少数重要目标对比，再区分计算残差、输入估计误差与模型错设。第一类可以通过更精确求解降低；第二类需要参数敏感性和更多数据；第三类需要重新审视生成结构。三个层面都可能改变最后一个数字，却不应采用同一种补救措施。多运行几轮求解器，只能解决其中一部分问题。

2.19 协方差相对扰动与预测风险的二阶结构

协方差矩阵来自估计或近似时，直接报告最大元素差往往难以判断影响。同样增加零点零一，对原来方差为一的方向很小，对原来方差为百万分之一方向却极大。更有用的尺度是先用原协方差白化，再测量扰动在各个标准化方向上的幅度。这样讨论的相对误差才与所有线性组合的方差一致。

设原观测协方差 P 正定，替代矩阵为 $Q = P + \Delta P$ 。定义对称相对扰动

$$E = P^{-1/2} \Delta P P^{-1/2}, \quad Q = P^{1/2} (I + E) P^{1/2}.$$

若其谱范数不超过 $\varepsilon < 1$ ，每个特征值都落在正负该界之间，因此

$$(1 - \varepsilon)P \preceq Q \preceq (1 + \varepsilon)P.$$

符号 $\preceq$ 表示两个矩阵之差半正定。也就是说，每个可能线性组合在新矩阵下的方差，都位于原方差的同一比例区间内。这比逐元素近似更强，也更贴近协方差的统计含义。它同时保证新矩阵正定，故不能只把该界看成求逆之后的误差估计。

对正定矩阵求逆会反转上述次序，得到

$$\frac{P^{-1}}{1 + \varepsilon} \preceq Q^{-1} \preceq \frac{P^{-1}}{1 - \varepsilon}.$$

若目标协方差向量 C 保持不变，预测信息二次型因此满足相同比例界。这里“保持不变”是明确的敏感性设定，不意味着真实资料中估计 P 的误差与估计 C 的误差一定独立。联合估计时两者往往同时变化，应保留它们的相关结构；本节先隔离协方差扰动以看清代数机制。

原最优权重为 $b = P^{-1}C$ ，替代权重为 $\tilde{b} = Q^{-1}C$ ，有

$$\tilde{b} - b = -Q^{-1} \Delta P b.$$

转换到白化尺度，可以推出

$$\|\tilde{b} - b\|_P \leq \frac{\varepsilon}{1 - \varepsilon} \|b\|_P.$$

这个界在接近奇异边界时迅速变大，恰好对应协方差某些方向失去稳定支撑。不能以平均误差很小为由跳过小特征值检查。不过该界仍是最坏方向界，若实际扰动没有作用于目标相关方向，真实变化可以小得多。合理报告可以同时给出保守界和与具体目标相匹配的直接计算。

更值得注意的是，权重误差对真实预测风险具有二阶形式。对任何候选权重 a ，在原联合模型中展开平方并使用 $Pb = C$ ，得

$$\begin{aligned} R(a) &= \sigma_u^2 - 2a^\top C + a^\top Pa, \\ R(a) - R(b) &= (a - b)^\top P(a - b). \end{aligned}$$

一阶项在最优点消失。因此当权重接近最优点时，预测风险增加可能比系数变化看上去温和。这并不保证排序稳定，因为两个候选者的真实分数差也可能很小；它也不说明不确定性报告可以直接采用新模型的简式。评估“真实风险”必须始终使用评价对象的真实联合矩，而不是把近似矩阵自行宣布为真值。

手算例：二成方差扰动如何传递到风险。设 P 为对角元四和一的矩阵， C 为二和二分之一，目标方差为二。原最优权重为两个二分之一，预测方差为一点二五，误差方差为零点七五。现在第一方向方差增加二成，第二方向减少二成，得到对角元四点八和零点八的新矩阵。新权重为十二分之五和八分之五，因此

$$R(\tilde{b}) - R(b) = 4\left(-\frac{1}{12}\right)^2 + \left(\frac{1}{8}\right)^2 = \frac{25}{576}.$$

新规则在原模型中的风险约为零点七九三四。直接将新权重代入完整风险，与上式计算必须一致。若错误采用“目标方差减去新权重与目标协方差的内积”，会漏掉不满足原正规方程造成的差别。对任何近似算法，这种交叉核验都比仅检查权重变化方向更有说服力。

当协方差扰动来自有限样本时，还可在适当正则条件下对参数误差作局部展开，再计算上述二次风险的期望。由此出现的额外项取决于参数估计协方差以及最优权重对参数的导数。它解释了为何经验预测需要考虑参数不确

定性，也说明简单给每个方差参数“上下浮动一个百分比”并不是完整概率评估。局部敏感性、保守扰动集和参数抽样分布服务不同问题，应明确选择其中哪一种。

2.20 谱滤波的偏差、方差与目标方向

小奇异值方向难以估计，并不意味着必须全部删除。保留多少、缩小多少，应由该方向的信号与噪声共同决定。为了将这一权衡写得完全透明，考虑经白化和奇异向量旋转后的线性模型。在每个可识别方向上，未经收缩的估计可以表示为真实系数加噪声，各方向噪声不相关。这种表示不是新模型，而是原线性问题在适当正交坐标中的分解。

设信息矩阵的正特征值为 λ_j ，残差方差尺度为 σ^2 ，则

$$t_j = \theta_j + \eta_j, \quad E(\eta_j) = 0, \quad \text{Var}(\eta_j) = \frac{\sigma^2}{\lambda_j}.$$

采用确定滤波因子 f_j ，令 $\hat{\theta}_j = f_j t_j$ 。条件于固定真实参数，偏差和方差分别为

$$\text{Bias}_j = (f_j - 1) \theta_j, \quad \text{Var}(\hat{\theta}_j) = f_j^2 \frac{\sigma^2}{\lambda_j}.$$

于是总系数平方风险为

$$R = \sum_j \left\{ (1 - f_j)^2 \theta_j^2 + f_j^2 \frac{\sigma^2}{\lambda_j} \right\}.$$

当一个方向的信息极弱，其无偏估计方差很大，适当引入偏差可能显著减少总风险。但若真实信号也特别大，全部删除又可能代价很高。只按奇异值大小决定截断，实际上隐含了关于信号规模的判断；数学分解能显示噪声放大，却不能替使用者判断哪个方向具有科学重要性。

若暂时知道真实信号平方，逐项微分给出理想滤波因子

$$f_j^* = \frac{\theta_j^2}{\theta_j^2 + \sigma^2/\lambda_j}.$$

它不能直接作为可实施估计，因为包含未知参数；其作用是揭示最佳收缩的信噪比结构。若改为给参数指定均值零、方差 τ_j^2 的先验并计算平均风险，式中的真实信号平方由该方差替换，便得到相应最佳线性收缩；若参数与噪声联合正态，它也等于后验均值。这说明数值正则化与统计先验之间可以建立联系，但只有同时说明风险是条件于参数还是对参数分布平均，二者的解释才一致。

手算例：相同噪声尺度，不同方向的最佳处理。取两个真实系数为三和一，对应噪声方差为一和九。完全不收缩时总风险为十，全部设为零时总风险也为十，但两者错误来源完全不同。理想滤波因子为零点九和零点一，两个方向风险各为零点九，总风险为一点八。只保留第一方向、删除第二方向时，总风险为二，已经远低于两种极端方案。

岭滤波使用同一个惩罚强度，却并非在所有方向使用同一个缩小比例。其因子为

$$f_j = \frac{\lambda_j}{\lambda_j + \alpha}.$$

在上例取 $\sigma^2 = 1$ 、信息特征值为一和九分之一，并令惩罚为一，则因子为二分之一和十分之一。第一方向风险为二点五，第二方向风险为零点九，总风险为三点四。它明显改善了无收缩风险，却不等于不可实施的理想值。这个结果有助于避免把“存在最佳收缩”误写成“某个统一惩罚必然最佳”。

若真正关心的是 $q = l^T \theta$ ，而不是整个系数向量，风险还会改变。由于各方向噪声不相关，目标风险为

$$R_q = \left[\sum_j l_j (f_j - 1) \theta_j \right]^2 + \sum_j l_j^2 f_j^2 \frac{\sigma^2}{\lambda_j}.$$

第一项是偏差总和的平方，并非各方向偏差平方的简单加权和；不同方向的偏差可以相互抵消，也可以相互增强。因而为恢复整个系数向量选择的惩罚，不一定最适合一个经济目标或候选对比。若所谓最优方法的评价指标悄悄从系数误差换成了预测误差，结论可能改变，必须明确比较对象。

此外，上面的风险表达将滤波因子视为事先固定。若根据同一数据选择截断点或惩罚，因子本身是随机量，不能不加说明地继续使用固定因子方差

公式。可以通过独立验证、嵌套评估或明确的联合概率分析处理选择过程。对小样本而言，这一层不确定性有时与原估计误差同样重要，平滑曲线并不等于已经可靠识别了最佳复杂度。

谱分解还提供一个实用的解释尺度：强方向可能由大量重复信息支撑，弱方向可能对应罕见家系差异。削弱后者可能改善总体平均误差，却牺牲少数重要对象。因此当模型服务于多样性维持或小群体评价时，应同时检查分组风险。总体最优与每一亚群都改善之间没有必然等号，决定使用哪种权衡需要回到育种计划目标。

2.21 可估函数的对偶表述与约束不变性

处理秩亏模型时，最直接的问题不是“哪一个广义逆是正确的”，而是“能否用观测的某个线性组合无偏地估计所关心对比”。这种从参数空间转到观测空间的思路，称为可估性的对偶表述。它把设计、误差协方差与目标连接在一起，也使最优估计具有一个清楚的最小方差问题。

设 $E(y) = X\beta$ ，误差协方差 R 正定，需要估计 $l^T\beta$ 。若使用 w^Ty ，对所有参数值均无偏的充要条件是

$$X^Tw = l.$$

因此目标可估，当且仅当该约束有解，也就是 l 属于 X^T 的列空间。这个条件不含广义逆，也不依赖软件如何删除参考水平。它直接回答：现有观测布局中是否存在某个加权比较能够消除所有不需要的参数，同时留下所关心的对比。

在所有可行权重中，最小化 w^TRw 。引入乘子 a ，对权重求导得到

$$Rw = Xa, \quad X^TR^{-1}Xa = l.$$

令 $K = X^TR^{-1}X$ ，对可估目标，可用 Moore–Penrose 逆表示

$$w_* = R^{-1}XK^+l, \quad \text{Var}(w_*^Ty) = l^TK^+l.$$

虽然乘子可能不唯一,最优观测权重却唯一。若另一个可行权重为 $w_* + v$, 则 $X^T v = 0$, 交叉项为零, 故

$$(w_* + v)^T R (w_* + v) = w_*^T R w_* + v^T R v.$$

这给出最小方差性质的直接证明。它与第1章投影勾股式具有相同结构, 只是几何度量由误差协方差决定。证明同时说明, 额外使用一个均值为零但与目标无关的线性组合, 只会增加方差; 当然, 若模型遗漏了系统偏差, 所谓均值为零的前提可能不成立, 最优结论也就需要重新评估。

手算例: 冗余场效应编码中的唯一对比。三条记录分别为四、六、九, 前两条来自甲场, 第三条来自乙场。采用截距加两个场效应的冗余编码, 误差方差分别为一、四、一。甲场均值的精度加权估计为四点四, 乙场为九, 故乙减甲为四点六。它对应观测权重

$$w = \left(-\frac{4}{5}, -\frac{1}{5}, 1 \right)^T, \quad \text{Var}(w^T y) = \frac{9}{5}.$$

检查权重总和为零, 甲场两条记录权重和为负一, 乙场权重为一, 因此截距被消去而场差被保留。若强行等权平均甲场两条记录, 仍然无偏, 但方差变为二点二五, 高于一点八。这个差异来自已知测量精度, 而不是来自对某个观测数值大小的偏好。

若设甲场效应为零, 得到截距四点四、乙场效应四点六; 若设两个场效应和为零, 得到截距六点七、甲场效应负二点三、乙场效应二点三。两套参数都产生同样拟合均值和场差。尤其应注意, 六点七是两个场水平的等权平均, 不自动等于按动物数量或未来生产规模加权的总体均值。一个方便的识别约束不能替代科学上真正需要的平均对象定义。

约束不变性可以用零空间表达。若 N 的列张成 X 的零空间, 所有等价参数写成 $\beta + Na$ 。目标在这些代表之间保持不变, 当且仅当

$$N^T l = 0.$$

因此, 检查不同约束下可估对比是否一致, 是比比较所有参数是否逐项相同更合理的核验。若一个目标不满足该条件, 某种约束仍然可以给出数值,

但这个数含有约束施加的额外信息。不能因为标准误能够被程序计算，就宣称原设计已经独立识别了该参数。

在混合模型中，随机效应的先验精度使一些原本由数据难以区分的方向得到稳定预测，但不改变固定效应可估性的基本逻辑。将某个来源从固定改为随机，会改变科学假设与误差定义，而不只是换一种求解方法。正确做法是分别说明哪些信息来自观测对比，哪些来自亲缘结构，哪些来自分布约束，使一个可计算答案的依据清楚可追溯。

2.22 单条记录的更新、删除与信息饱和

新增记录往往只向信息矩阵增加一个低秩项。充分理解这一点，可以不重新求解完整问题就看出新记录作用于哪些目标，也可以解释为什么某一记录删除后会显著改变结果。这里先假设原信息矩阵正定；若原系统秩亏，应先限制到可估子空间或保留一致约束，不能直接使用含普通逆的公式。

设原正规方程为 $B\hat{\beta} = d$ ，新增独立记录的设计向量为 x ，观测为 y_* ，已知误差精度为 $w > 0$ 。更新后

$$B_+ = B + wxx^T, \quad d_+ = d + wxy_*.$$

将旧解代入新系统，再求解差值，可得

$$\hat{\beta}_+ - \hat{\beta} = \frac{wB^{-1}x}{1 + wq} (y_* - x^T\hat{\beta}), \quad q = x^TB^{-1}x.$$

括号内是新记录相对旧预测的创新。新观测即使数值很大，若旧模型早已预测它同样大，更新仍可能很小。相反，一个与旧预测明显不符但精度很低的记录，也不会无限支配结果。分母同时体现新记录自身误差与旧预测不确定性，是信息重叠和适度修正的代数表现。

通过验证乘积为单位矩阵，可得对应逆矩阵更新

$$B_+^{-1} = B^{-1} - \frac{wB^{-1}xx^TB^{-1}}{1 + wq}.$$

若原逆矩阵确实表示当前参数估计协方差，某个目标对比的方差减少量

为

$$\Delta V_l = \frac{w(l^\top B^{-1}x)^2}{1+wq}.$$

新记录作用很大与它对某个特定目标作用很大，显然不是同一句话。当 $l^\top B^{-1}x = 0$ 时，该记录可以提高其他参数的精度，却不降低此目标的误差。式中协方差角色与第1章新增信息公式一致，不过现在已经把新信息放到了参数方程的空间中。

手算例：一条测定主要改善哪个组合。取原信息矩阵对角元二和一，原右端为四和零，故原估计为二和零。新增记录测量两参数之和，观测为三、误差方差为一。此时 $x = (1, 1)^\top$ 、 $q = 1.5$ ，创新为一，更新后估计为二点二和零点四。逆矩阵变为

$$B_+^{-1} = \begin{pmatrix} 0.4 & -0.2 \\ -0.2 & 0.6 \end{pmatrix}.$$

原来两参数之和与差的方差都为一点五；增加记录后，和的方差降为零点六，差的方差只降为一点四。新记录直接测量和，因此主要改善和；但由于两个参数原来精度不同，和与差在旧协方差尺度下不正交，差也获得少量收益。仅凭设计向量的普通欧氏角度，不能完整判断信息传递方向。

若让同方向测定精度无限增大，目标方差减少量趋于

$$\lim_{w \rightarrow \infty} \Delta V_l = \frac{(l^\top B^{-1}x)^2}{x^\top B^{-1}x}.$$

即使把某个线性组合测得完全准确，与它正交的其他不确定性仍然保留。这为测定设计提供一个上限：一再提高同一方向的精度可能接近饱和，而新增不同方向的测定仍有价值。实际重复记录若共享环境误差，精度甚至不能按独立误差规则无界增加，应先将共享部分纳入模型再使用更新式。

删除已经加入的一条独立记录则是负的低秩更新。以删除前的信息矩阵 B_+ 为起点，定义该记录杠杆量

$$h = wx^\top B_+^{-1}x.$$

若 $h < 1$, 删除后的逆为

$$B^{-1} = B_+^{-1} + \frac{wB_+^{-1}xx^TB_+^{-1}}{1-h}.$$

上例中杠杆量为零点六, 分母为零点四, 代回便恢复原逆。当杠杆量接近一, 说明删除会使某个方向失去大部分支撑; 若达到一, 可能使系统降秩。高杠杆不等于记录错误, 只表示其设计位置重要。判断是否剔除还需要身份、测量和生物机制证据, 不能因为记录影响大就自动删除。

最后, 行列式更新为 $\det(B_+) = \det(B)(1+wq)$ 。它描述整体信息体积的改变, 适合某些设计准则; 目标方差减少则描述特定比较的收益, 适合另一些设计准则。两者可能推荐不同的新记录。把“总体信息最大”与“最重要育种决策最精确”混为一谈, 会在有限测定预算下产生错误优先级。后续光谱连接与参考群设计, 都应先定义关键比较, 再选择相应的信息衡量方式。

2.23 综合练习与解答

练习一：矩阵维数。有五条记录、三个动物、两个场。固定效应只含两个场均值, 随机效应含三个动物育种值。写出 y, X, Z, β, u, P, C 的维数, 并说明若预测目标改为两个性状的六个育种值, 哪些维数需要改变。

解答。单性状时依次为 $5 \times 1, 5 \times 2, 5 \times 3, 2 \times 1, 3 \times 1, 5 \times 5, 5 \times 3$ 。若记录仍是原五条、目标改为六维, 则目标向量与记录—目标协方差分别为 6×1 和 5×6 。随机效应设计矩阵是否扩为六列取决于观测模型是否也显式包含六个随机效应, 不能只因目标扩大就机械改变全部记录结构。维数必须与模型定义一起确定。

练习二：可估计性。截距加甲、乙两场指示列构成冗余设计。说明为什么截距与两个场效应不唯一, 给出两种识别约束, 并证明场差保持不变。

解答。对任意常数 c , 把截距增加 c 、两个场效应都减少 c , 拟合值不变。可令甲场效应为零, 或者令两个场效应之和为零。两种约束选择不同参数代表, 但乙减甲中的共同平移抵消, 因此同一个可估计场差保持不变。若两场还分别只出现不同公畜, 则场差与遗传差可能进一步混杂, 这属于设计信息缺口, 不能只靠上述编码约束解决。

练习三：合法联合协方差。记录方差为四，目标方差为一。记录与目标协方差能否为三？若不能，允许的绝对上限是多少？用相关与预测误差两个角度解释。

解答。不能。协方差绝对值至多为两个标准差乘积，即二；取三会使相关为一点五，超过一。最佳线性公式也给出 PEV 为 $1 - 9/4 = -5/4$ ，负方差不可能。两种诊断是同一个半正定约束的不同表达。把负 PEV 截成零不能修复原输入，应追查单位、参数来源或协方差估计。

练习四：三角求解。取 $P = \begin{pmatrix} 9 & 3 \\ 3 & 4 \end{pmatrix}$, $C = (3, 2)^T$ 。求 Cholesky 分解、权重，并在目标方差为二、观测为 $(2, 1)^T$ 时计算预测与 PEV。

解答。下三角因子为 $L = \begin{pmatrix} 3 & 0 \\ 1 & \sqrt{3} \end{pmatrix}$ 。先解得 $z_1 = 1, z_2 = 1/\sqrt{3}$ ，再反代得 $b_2 = 1/3, b_1 = 2/9$ 。预测为 $7/9$ ，预测方差为 $C^T b = 4/3$ ，PEV 为 $2/3$ 。可以用直接消元核对，但实际大型求解不必形成整个逆矩阵。

练习五：正规方程与条件数。若满列秩设计矩阵的二范数条件数为一千，其交叉乘积矩阵的条件数是多少？这是否表示 QR 分解能够消除原问题对数据扰动的全部敏感性？

解答。交叉乘积条件数为一百万，因为其特征值为设计矩阵奇异值的平方。QR 避免进一步通过交叉乘积恶化数值求解，但不能消除原问题本身的条件数。若数据中两个协变量几乎相同，参数仍会对真实测量误差敏感。稳定算法减少额外计算损失，不会创造设计中不存在的独立信息。

练习六：正则化后的 PEV。对任意给定权重 b_λ ，从平方误差展开推导 PEV，并说明什么时候可以简化为 $\sigma_u^2 - C^T b_\lambda$ 。如果使用岭方程，简化式一般还成立吗？

解答。在均值已正确中心化时，PEV 为 $\sigma_u^2 - 2b_\lambda^T C + b_\lambda^T P b_\lambda$ 。只有当权重满足相应正交关系，例如 $P b_\lambda = C$ ，才可把后二项合并。岭解满足 $(P + \lambda I) b_\lambda = C$ ，一般不满足原方程，因此直接使用简式会错估原模型下的误差。若将岭处理解释为新的概率模型，则应根据新模型重新定义协方差与 PEV。

练习七：冗余记录。两条记录完全相同，方差均为四，与目标协方差均为二。给出两组不同最优权重，并证明预测相同。如果两条记录只是这一次恰好数值相同，是否也能删除一条而保证无信息损失？

解答。 $(1/2, 0)$ 与 $(1/4, 1/4)$ 都满足权重和为二分之一，在确定性相同记录条件下均给出 $y_1/2$ 。若只是一次观测巧合相等，它们可能具有独立测量误差，联合信息仍多于单条，不能据数值相等判定冗余。冗余是随机结构中的确定关系，必须依据记录来源和协方差判断。

练习八：Schur 补。已有记录方差四，新记录方差三，协方差二；它们与目标的协方差分别为二和一点五。求新记录剩余方差、剩余目标协方差、预测方差增量及联合权重。

解答。剩余方差为二，剩余目标协方差为二分之一，增量为八分之一。联合权重为 $(3/8, 1/4)$ 。新记录不是完全独立，但其未被旧记录解释部分仍含目标信息。若仅按新记录与目标的单独相关评价，无法得到这个边际增量，也无法正确调整旧记录的权重。

练习九：迭代停止。一个病态系统的相对残差已经很小，但两个更严格容差下某些系数变化明显，而最终候选排序几乎不变。应如何报告与处理？

解答。首先确认系数变化是否沿弱识别方向，检查关键预测、目标函数和对比，而不是只看系数最大差异。如果决策结果和原单位预测稳定，当前精度可能已经满足用途，但应记录容差与敏感性。若后续需要解释单个系数，则不能以排序稳定代替系数可靠性。还应区分数值误差与参数估计误差，必要时重新参数化或改善数据设计。

练习十：研究设计与矩阵诊断。某基因组预测程序出现非正定协方差，开发者自动逐步增加对角数直到 Cholesky 成功，并报告可靠度提高。请提出一个更可审查的诊断流程。

解答。先核对样本身份、单位、中心化、矩阵对称性及缺失处理，再检查特征值相对于矩阵尺度的大小，区分舍入负值与实质不相容。追查各协方差是否来自同一群体和基准，明确对角增加代表测量噪声、先验收缩还是纯数值修补。修正后按相应模型重新计算误差，并用独立验证检查校准与预测

能力。不能把求解成功当成模型正确，更不能把由定义改变产生的可靠度变化直接称为信息增加。

统计推断、似然与数量遗传学方法



3.1 数量遗传学的问题意识与学术谱系

数量遗传学研究的是“程度上的差异，而非种类上的差异”。体重、产奶量、窝产仔数、株高、籽粒重、血压和身高之类的性状，在群体中呈现连续或近似连续的分布。一个个体为什么比另一个个体重？亲属为什么彼此相似却又各不相同？一个群体经过选择以后为什么会改变？这三个问题——个体间变异、亲属间相似和群体随时间演变——构成了数量遗传学的基本问题意识。前两章已经从育种决策出发，建立了期望、协方差与矩阵计算的语言；本章把视野向前推一步，讨论这门学科如何从历史中形成自己的推理方式，以及支撑这种推理的统计推断原理。

数量遗传学的基本模型在一百多年里没有根本改变，却被极为细致地展开。它的出发点是孟德尔提出的两条规律：其一，每个性状受一对等位基因控制，个体随机地把其中之一通过配子传给后代，即分离定律；其二，不同遗传因子的等位基因在配子中独立组合，即自由组合定律。数量遗传模型进一步假定，影响连续性状的遗传因子与控制豌豆花色的因子遵从相同的传递规律，只是数目众多、各自效应较小；环境因素同时作用于表型，使表型并非基因型的忠实翻译；而这些因子排列在染色体上，因而同一染色体上的位点并不完全独立组合，亲本型组合比重组型组合出现得更频繁。

从达尔文到费希尔：连续变异如何与孟德尔遗传统一

达尔文(1809—1882)把“实际生物之间的实际变异”置于自然界最重要事实的位置。自然选择学说要求三个条件：个体之间存在变异；变异中有一部分能在亲属之间传递；不同类型个体留下的后代数量不同。然而，变异与亲子相似似乎相互矛盾：前者强调差异，后者强调恒定。在达尔文的时代，没有一个遗传理论能同时容纳这两点。

孟德尔(1822—1884)在1866年依据离散性状的杂交试验提出分离与自由组合规律。他受过物理学训练，善于用比例和概率处理观察，并且一次观察大量个体，隐含地提出同一规律并不保证每个后代得到同样结果，机会在遗传中起作用。但当时生物学家习惯整体地观察生物，也普遍认为受精需要多个精子或花粉粒，整齐的分离比因而难以被接受。直到受精过程中单个配子结合、有丝分裂与减数分裂的配对与分离被细致观察，1900年德弗里斯、柯伦斯和丘歇马克才重新发现孟德尔的论文。

与此同时，高尔顿(1822—1911)研究人类身高等连续性状，发现子女虽比他人更像父母，但高个父母的子女平均矮于父母，矮个父母的子女平均高于父母。他在1889年称之为“向平庸回归”，统计学中的“回归”一词由此而来。这种趋势若普遍存在，变异将在若干代后消失，高尔顿只好设想进化依赖于突变产生的“突变体”。约翰森在1903年用自交菜豆证明，纯系内部选择大粒和小粒种子，其后代粒重并无差异，纯系内变异全部来自环境。他创造了“基因型”和“表型”两个术语，但同样把基因型视为不可分割的整体。

突破来自多因子假说。尤尔在1902年指出，若身高由多个遗传因子与环境共同决定，既能产生连续变异，又能再现高尔顿的回归现象：父母可能部分因为环境而高，而环境并不传递给子女。尼尔松—埃勒观察到红粒与白粒小麦杂交后 F_2 中白粒仅占六十四分之一，推断有三个独立因子参与。伊斯特与埃默森在玉米中发现，不同品种杂交的 F_1 变异并不比亲本大，而 F_1 自交后的 F_2 变异骤增，这正是多个因子在 F_1 中汇集、在 F_2 中独立分离的结果。

1918年，费希尔发表《基于孟德尔遗传假设的亲属间相关》，证明大量孟德尔因子的累加作用加上环境效应，可以完全解释生物统计学派观察到的亲属间相关，并首次把遗传方差分解为加性、显性与上位成分。他为此引入了“方差”一词，奠定了方差分析的基础。赖特发展了通径分析与近交系数，霍尔丹建立了选择与突变的数学理论。三人共同完成了进化论与遗传学的“现代综合”。此后，勒什把这一理论系统地引入动物育种，黑泽尔在1943年提出选择指数，亨德森在1949年至

1975年间发展出混合模型方程与最佳线性无偏预测。数量性状位点（QTL）定位与全基因组关联分析则是二十世纪后期以来的新分支。

把这段历史“按今天的学科结构重新书写”，可以分出两条线索。一条关注单个遗传因子及其在群体中的传递，后来发展成群体遗传学；另一条关注受遗传与环境共同影响的连续变异，即数量遗传学。两者处于一种“机制层级”之中。若关心某个性状在群体中的均值和方差如何变化，可以使用数量遗传理论，其基本构件是均值、方差和协方差，许多预测公式只含这些参数，而不出现具体位点、随机分离或自由组合；若要理解这些均值和方差从何而来，就必须下降到位点层次，以具有具体效应的等位基因为构件，这就是群体遗传学的领域。前者的参数是后者各位点效应的综合结果。本书的结构正是沿着这一层级展开：第二篇讨论单位点和多位点的群体结构，第三篇讨论如何借助分子标记定位具体位点，第四篇再上升到性状层次的方差、协方差与亲属相似性。

这一层级还有第三个层面：理论与真实世界之间的接口。理论从模型出发推演出种种结论，但要把结论付诸实践，就需要估计代入公式的参数。哪些资料能够通过统计方法加以汇总，从而估计那些无法直接观察的量？这是统计遗传学的任务，其主要对象是方差和育种值。本章讨论的统计推断原理——估计量、似然、检验、区间和多重比较——就是这一接口的通用工具。

数量遗传学处在科学方法的什么位置？科学方法通常包括四步：观察现象；提出能够解释观察的理论，最好同时提出几个相互竞争的理论；从理论推演可在新情形中检验的预测；设计试验检验这些预测。数量遗传学的基本模型已经在第一、二步取得了巨大成功，学科主要活动于第三步，即从孟德尔遗传推演其在群体和多位点同时分离时的后果。正如福尔克纳与麦凯所说，数量遗传理论“是孟德尔遗传推广到群体性质及多位点同时分离时的后果推演”。这决定了本学科高度偏重理论：我们常用很长篇幅精确地写出模型，再通过代数和微积分推演其推论，而不立即引用经验事实。但推演的价值最终要靠第四步检验。随着分子标记、全基因组序列与大规模表型资料的出现，第四步的能力大大增强，理论推演与经验检验之间的往返也更加频繁。

3.2 统计模型：从生物学机制到可估计参数

数量遗传学最基本的模型把个体 i 的表型值写为

$$P_i = \mu + G_i + E_i, \quad (3.1)$$

其中 μ 为群体均值, G_i 为影响该性状的全部基因的综合效应, 即基因型值, E_i 为全部环境因素的综合效应。最简单的遗传传递模型则把后代的基因型值写成父母基因型值与孟德尔抽样项之和:

$$G_o = \frac{1}{2}G_s + \frac{1}{2}G_d + RA_s + RA_d. \quad (3.2)$$

这里 RA_s 与 RA_d 表示父母随机传递一半等位基因造成的随机分离偏差。式 (3.2) 在严格意义上只对加性部分成立, 第 9 章将说明, 显性和上位作用不能这样简单地按一半传递; 但它已经包含了数量遗传学最核心的思想: 后代既像父母 (前两项), 又与父母不同 (后两项)。

把生物学机制写成统计模型, 需要明确三件事。第一是**估计对象**, 即研究真正关心的量。它可能是群体参数, 如加性遗传方差 σ_A^2 、遗传力 h^2 或某位点的替代效应 α ; 也可能是个体随机变量的实现值, 如某头公牛的育种值。前者称为参数估计, 后者称为预测。第二是**资料生成机制**, 即在什么假设下, 观察资料与估计对象发生联系。第三是**推断程序**, 即怎样从资料计算估计值, 以及怎样表达其不确定性。三者缺一不可。许多争议并非来自计算错误, 而是来自估计对象没有说清楚。例如“某性状的遗传力是多少”, 若不指明群体、环境、测定方法与参照世代, 这个问题并没有唯一答案。

模型总是对现实的简化。式 (3.1) 把基因型与环境写成相加形式, 隐含着二者不相关且无互作的假设; 而现实中, 优秀个体可能获得更好的饲养条件, 同一基因型在不同环境中也可能有不同表现。统计学家博克斯的名言“所有模型都是错的, 但有些是有用的”在这里尤其恰当。判断一个模型是否有用, 要看它能否在指定用途上给出足够可靠的推论, 以及它的失败方式是否可以被诊断。本书始终强调, 对每一个公式都应问一句: 它是恒等式、特定分布下的结论, 还是近似?

3.3 样本、估计量与抽样分布

3.3.1 随机变量与概率分布

第1章已经系统讨论了随机变量、期望和方差，这里只从推断的角度补充几点。设随机变量 X 表示某个体某标记位点上等位基因 A 的拷贝数，可以取 0、1、2。在 50 个随机个体中观察到 aa 、 Aa 、 AA 分别为 8、24、18 个，则三种基因型的样本频率为 0.16、0.48、0.36，这也是从该群体随机抽取一个个体时得到各基因型的概率估计。于是

$$E(X) = 0 \times 0.16 + 1 \times 0.48 + 2 \times 0.36 = 1.20, \quad E(X^2) = 1.92,$$

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = 1.92 - 1.44 = 0.48.$$

期望值 1.2 并不属于任何一个基因型类别，个体总是携带整数个等位基因；期望是对分布位置的概括，而不是某个典型个体的值。若该群体处于 Hardy-Weinberg 平衡，等位基因频率 $p = 1.2/2 = 0.6$ ， $\text{Var}(X) = 2pq = 0.48$ 恰好与上式相同。这一巧合并非偶然：这组数据正是按 $p = 0.6$ 的平衡比例构造的。第4章将系统讨论这种结构。

3.3.2 联合分布、条件分布与独立性

若对同一批个体再分型另一位点 B ，可以得到两位点基因型的联合概率表（表 3.1）。

表 3.1 两位点基因型的联合概率

A 位点基因型	bb	Bb	BB	边际概率
aa	0.10	0.04	0.02	0.16
Aa	0.14	0.18	0.16	0.48
AA	0.06	0.10	0.20	0.36
边际概率	0.30	0.32	0.38	1.00

边际概率由联合概率按行或列求和得到，这是全概率公式的直接应用。

条件概率

$$\Pr(G_A = Aa \mid G_B = BB) = \frac{\Pr(G_A = Aa, G_B = BB)}{\Pr(G_B = BB)} = \frac{0.16}{0.38} = 0.421,$$

小于边际概率 0.48；已知个体为 BB，它是 Aa 的可能性下降了。以 X、Y 分别表示 A 与 B 的拷贝数，条件期望

$$E(X \mid G_B = BB) = 0 \times \frac{0.02}{0.38} + 1 \times \frac{0.16}{0.38} + 2 \times \frac{0.20}{0.38} = 1.474,$$

高于无条件期望 1.20。由表 3.1 还可算得 $E(Y) = 1.08$ ， $E(XY) = 1.50$ ，于是

$$\text{Cov}(X, Y) = 1.50 - 1.20 \times 1.08 = 0.204, \quad \text{Var}(Y) = 0.6736,$$

$$r_{XY} = \frac{0.204}{\sqrt{0.48 \times 0.6736}} = 0.359.$$

两位点基因型并不独立：若独立，联合概率应等于边际概率之积，例如 $\Pr(Aa, BB)$ 应为 $0.48 \times 0.38 = 0.1824$ ，而观察值为 0.16。第 5 章将把两个位点之间的这种非独立性称为**连锁不平衡**，它是数量性状位点定位和全基因组关联分析的基础：正因为标记与致病位点之间存在关联，我们才能通过观察标记推知不可见的致病变异。

需要强调，协方差为零并不等价于独立。独立要求联合分布处处分解为边际分布之积，而协方差只度量线性关联。两个位点的基因型可能通过非线性方式相关而协方差恰好为零。第 1 章已经从投影几何解释了这一区别；在遗传资料中，它意味着用相关系数检验位点关联可能遗漏某些模式，而以列联表为基础的检验则更一般。

3.3.3 估计量的偏差、方差与均方误差

参数 θ 的估计量 $\hat{\theta}$ 是样本的函数，因而本身是随机变量，其分布称为抽样分布。评价估计量的三个基本指标是：

$$\begin{aligned} \text{Bias}(\hat{\theta}) &= E(\hat{\theta}) - \theta, & \text{Var}(\hat{\theta}) &= E[\hat{\theta} - E(\hat{\theta})]^2, \\ \text{MSE}(\hat{\theta}) &= E(\hat{\theta} - \theta)^2 = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2. \end{aligned} \quad (3.3)$$

最后一个等式只需在 $\hat{\theta} - \theta$ 中加减 $E(\hat{\theta})$ 并展开, 交叉项期望为零。式 (3.3) 说明, 无偏并不保证均方误差最小; 适度的偏差若能大幅降低方差, 总误差反而更小。这正是收缩估计与 BLUP 的统计思想, 第 21 章将在混合模型中再次遇到它。

样本方差的除数问题是理解偏差的经典例子。对 N 个独立同分布观察,

$$E\left[\sum_{i=1}^N (x_i - \bar{x})^2\right] = \sum_i E(x_i - \mu)^2 - N E(\bar{x} - \mu)^2 = N\sigma^2 - \sigma^2 = (N-1)\sigma^2.$$

因此除以 N 得到的“总体方差”公式作为总体参数的估计是有偏的, 除以 $N-1$ 才无偏。直观上, 用样本均值代替真实均值, 离差平方和必然偏小, 因为样本均值恰是使离差平方和最小的那个点; 损失的一个自由度正对应估计均值所消耗的信息。电子表格中的协方差函数若按 N 求平均, 在小样本中会系统地低估总体协方差, 这在计算遗传参数时须特别留意。

以 10 名成年男性的身高与体重为例 (表 3.2)。身高均值 172.4 厘米, 按 N 计算的方差为 51.64, 按 $N-1$ 为 57.38; 体重均值 97.2 千克, 两种方差分别为 72.56 与 80.62; 协方差分别为 48.02 与 53.36。无论采用哪种除数, 相关系数都等于 0.784, 因为分子分母的除数相互抵消。

表 3.2 十名男性的身高与体重

个体	1	2	3	4	5	6	7	8	9	10
身高/cm	180	175	185	169	172	161	174	163	178	167
体重/kg	99	107	110	91	103	85	92	95	105	85

一致性是另一个重要性质: 当样本量趋于无穷时, 估计量依概率收敛于参数真值。除以 N 与除以 $N-1$ 的两个方差估计都是一致的, 其差别随 N 增大而消失。在遗传参数估计中, 真正困难的往往不是这种小的有限样本偏差, 而是资料结构造成的系统偏差, 例如选择后的样本、未模拟的共同环境或亲属间相关被误当作独立观察。这些偏差不会随样本量增大而消失, 反而会在大样本中以更窄的置信区间被“精确地”报告出来。

3.4 回归、相关与预测的准确度

3.4.1 回归是条件期望

数量遗传学的一个反复出现的主题，是估计无法直接观察的个体量或群体参数。最典型的例子是：只观察到个体表型，却想估计其基因型值或育种值。回归正是为这种估计而生。 Y 对 X 的回归定义为给定 X 时 Y 的期望值：

$$\hat{y} = E(Y | X = x).$$

当二者服从二元正态分布，条件期望恰为线性：

$$E(Y | X = x) = \mu_Y + b_{YX}(x - \mu_X), \quad b_{YX} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = r_{XY} \frac{\sigma_Y}{\sigma_X}. \quad (3.4)$$

不服从正态时，式 (3.4) 仍是所有线性预测中均方误差最小者，即最佳线性预测（第 1 章 1.9 节）。由样本数据用最小二乘拟合 $y = \mu_Y + b(x - \mu_X) + e$ ，得到的斜率估计 $\hat{b} = \sum(x_i - \bar{x})(y_i - \bar{y}) / \sum(x_i - \bar{x})^2$ ，正是样本协方差与样本方差之比。

对身高体重资料， $\hat{b} = 48.02/51.64 = 0.930$ 千克/厘米，回归方程为 $\hat{W} = 97.2 + 0.930(H - 172.4)$ ，等价于 $\hat{W} = -63.1 + 0.930H$ 。身高 180 厘米者的预测体重为 104.3 千克，而其实际体重为 99 千克，预测误差为 -5.3 千克。十个预测误差的均值为零，说明预测在平均意义上无偏；但没有一个预测完全正确。斜率的标准误为

$$SE(\hat{b}) = \sqrt{\frac{\sum \hat{e}_i^2 / (N - 2)}{\sum (x_i - \bar{x})^2}} = 0.260,$$

在仅有 10 个观察时，斜率的不确定性相当大。

3.4.2 准确度与决定系数

预测的准确度用预测值与真实值的相关来度量。对简单回归，

$$\text{Cov}(Y, \hat{Y}) = b_{YX} \text{Cov}(X, Y) = r_{XY}^2 \sigma_Y^2, \quad \text{Var}(\hat{Y}) = b_{YX}^2 \sigma_X^2 = r_{XY}^2 \sigma_Y^2,$$

于是

$$r_{Y\hat{Y}} = \frac{r_{XY}^2 \sigma_Y^2}{\sqrt{r_{XY}^2 \sigma_Y^2 \cdot \sigma_Y^2}} = |r_{XY}|. \quad (3.5)$$

单变量回归预测的准确度等于两变量相关系数的绝对值; 决定系数 $R^2 = \text{Var}(\hat{Y}) / \text{Var}(Y) = r_{XY}^2$ 表示预测值解释的方差比例。身高体重例中准确度为 0.784, $R^2 = 0.615$ 。

3.4.3 遗传力的两种统计含义

把上述结果应用于式 (3.1)。设基因型与环境不相关, 则

$$\text{Cov}(P, G) = \text{Cov}(G + E, G) = \sigma_G^2, \quad r_{PG} = \frac{\sigma_G^2}{\sigma_G \sigma_P} = \frac{\sigma_G}{\sigma_P}.$$

表型与基因型值之间的相关等于遗传标准差与表型标准差之比, 其平方

$$r_{PG}^2 = \frac{\sigma_G^2}{\sigma_P^2} = H^2$$

就是广义遗传力。同时, 基因型值对表型值的回归系数

$$b_{GP} = \frac{\text{Cov}(G, P)}{\text{Var}(P)} = \frac{\sigma_G^2}{\sigma_P^2} = H^2.$$

于是遗传力有两种统计含义: 它既是表型与基因型值相关的平方, 又是基因型值对表型的回归斜率。若把 G 换成加性育种值 A , 同样的推导得到狭义遗传力 $h^2 = \sigma_A^2 / \sigma_P^2$, 于是由个体自身表型预测育种值为

$$\hat{A}_i = h^2(P_i - \mu_P), \quad r_{A\hat{A}} = h. \quad (3.6)$$

例 3.1 由产奶量记录预测育种值

某奶牛 305 天产奶量 6500 千克, 所在牛群均值 6000 千克。设该性状遗传力 0.3, 表型标准差 1200 千克, 则遗传标准差 $\sigma_A = \sqrt{0.3} \times 1200 = 657.3$ 千克。由式 (3.6),

$$\hat{A} = 0.3 \times (6500 - 6000) = +150 \text{ 千克},$$

即预测该牛的育种值比牛群平均高 150 千克；预测准确度 $r = \sqrt{0.3} = 0.548$ 。

这个例子有两个值得注意之处。第一，500 千克的表型优势只有 150 千克被预测为可遗传的优势，其余 350 千克被归于环境和非加性效应；这种“向均值回归”正是高尔顿观察到的现象，其数量遗传解释由式 (3.6) 给出。第二，准确度仅约 0.55，意味着预测误差标准差为 $\sigma_A \sqrt{1 - h^2} = 550$ 千克，比预测值本身大得多。第 15 章将说明，利用重复记录和亲属记录可以大幅提高这一准确度。

3.4.4 亲子回归：从资料估计遗传力

上面的预测需要已知遗传力。幸运的是，亲属间的相似性本身就包含估计遗传力的信息。设有子代表型 P_o 与其父亲表型 P_s 的成对资料，回归模型 $P_o = \mu_o + b_{OP}(P_s - \mu_s) + e$ 的斜率为

$$b_{OP} = \frac{\text{Cov}(G_o + E_o, G_s + E_s)}{\sigma_P^2} = \frac{\text{Cov}(G_o, G_s)}{\sigma_P^2}.$$

最后一步假定父子之间无共同环境，且父子环境与对方基因型不相关。在只有加性作用时，由式 (3.2) 得 $\text{Cov}(G_o, G_s) = \frac{1}{2}\sigma_A^2$ ，于是

$$b_{OP} = \frac{1}{2}h^2, \quad \hat{h}^2 = 2\hat{b}_{OP}. \quad (3.7)$$

若对子代与双亲均值回归，则斜率直接等于 h^2 。第 11 章将推导一般亲属间的遗传协方差，第 13 章将系统比较亲子回归、同胞分析和似然方法的统计效率。这里先指出一个看似矛盾的事实：用单亲回归估计遗传力，即使亲本是经过选择的个体，斜率仍然无偏，因为回归是以亲本表型为条件的，选择只改变了自变量的分布；反之，若按子代表型选择，回归斜率就会有偏。这一性质使亲子回归在选择试验资料中尤其有用。

3.5 似然原理与最大似然估计

3.5.1 似然函数

设资料 $\mathbf{y}$ 的概率（或概率密度）依赖于参数 θ ，记为 $f(\mathbf{y} | \theta)$ 。把它看作 θ 的函数、而资料固定为已观察到的值时，称为**似然函数**：

$$L(\theta | \mathbf{y}) = f(\mathbf{y} | \theta), \quad \ell(\theta) = \ln L(\theta | \mathbf{y}).$$

似然不是参数的概率分布，它对 θ 积分一般不等于一。似然的含义是比较：若 $L(\theta_1) > L(\theta_2)$ ，则在 θ_1 下观察到当前资料的概率较大，资料对 θ_1 的支持较强。费希尔在 1922 年系统提出这一思想，并以使似然最大的参数值作为估计，即最大似然估计（MLE）：

$$\hat{\theta} = \arg \max_{\theta} \ell(\theta).$$

在正则条件下，MLE 满足**得分方程**

$$S(\theta) = \frac{\partial \ell(\theta)}{\partial \theta} = 0. \quad (3.8)$$

得分函数在真实参数处的期望为零： $E[S(\theta)] = \int \frac{\partial f / \partial \theta}{f} f d\mathbf{y} = \frac{\partial}{\partial \theta} \int f d\mathbf{y} = 0$ 。其方差称为**费希尔信息**：

$$\mathcal{I}(\theta) = \text{Var}[S(\theta)] = -E\left[\frac{\partial^2 \ell}{\partial \theta^2}\right]. \quad (3.9)$$

第二个等号来自对恒等式 $\int (\partial \ln f / \partial \theta) f d\mathbf{y} = 0$ 再对 θ 求导。

3.5.2 大样本性质

在正则条件下，MLE 具有三项重要的大样本性质。其一，一致性。其二，渐近正态性与渐近有效性：

$$\hat{\theta} \sim N(\theta, \mathcal{I}(\theta)^{-1}),$$

而任何无偏估计的方差不能小于 $\mathcal{I}(\theta)^{-1}$ （Cramér–Rao 下界），所以 MLE 在大样本中达到最小可能方差。其三，**不变性**：若 $\hat{\theta}$ 是 θ 的 MLE，则对

任意函数 g , $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE。不变性在遗传学中十分方便：由方差组分的 MLE 直接得到遗传力的 MLE，由重组率的 MLE 直接得到图距的 MLE。

需要注意，“正则条件”并非总是满足。参数位于参数空间边界（如方差组分为零、重组率为 0.5），参数个数随样本量增加（如每个家系一个固定效应），或模型不可识别时，上述性质都可能失效。遗传学中的许多关键检验恰恰处于这些非正则情形，下文将逐一指出。

推导：二项比例的最大似然估计与信息量

在一个测交群体中检查两个位点是否连锁。 m 个配子中观察到 k 个重组型，重组率 c 的似然为

$$L(c) = \binom{m}{k} c^k (1-c)^{m-k}, \quad \ell(c) = \text{常数} + k \ln c + (m-k) \ln(1-c).$$

得分函数 $S(c) = k/c - (m-k)/(1-c)$ ，令其为零得 $\hat{c} = k/m$ 。二阶导 $-k/c^2 - (m-k)/(1-c)^2$ 的期望为 $-m/[c(1-c)]$ ，因此

$$\mathcal{I}(c) = \frac{m}{c(1-c)}, \quad \text{SE}(\hat{c}) \approx \sqrt{\frac{\hat{c}(1-\hat{c})}{m}}.$$

信息量与样本量成正比，并在 c 接近 0 或 1 时增大。对连锁分析而言，紧密连锁（ c 小）时重组率估计相对容易；但在 c 接近 0.5 时，每个配子提供的信息最少，而这恰好是判断“是否连锁”最需要信息的区域。

3.6 似然比检验、LOD 值与区间估计

3.6.1 三种大样本检验

检验零假设 $H_0: \theta = \theta_0$ 有三种基于似然的大样本方法。似然比检验比较约束与无约束下的最大似然：

$$\Lambda = 2[\ell(\hat{\theta}) - \ell(\theta_0)] \sim \chi_d^2, \quad (3.10)$$

其中 d 为零假设所施加的独立约束数，这一渐近分布由威尔克斯 (1938) 证明。**Wald 检验** 利用 $(\hat{\theta} - \theta_0)^2 \mathcal{I}(\hat{\theta})$ ；**得分检验** 利用 $S(\theta_0)^2 / \mathcal{I}(\theta_0)$ ，只需在零假设下计算。三者在大样本下等价，小样本中似然比检验通常表现最好，

而且对参数变换不变。得分检验在全基因组扫描中有计算优势：零模型只需拟合一次，对每个标记只计算一个得分统计量。

3.6.2 LOD 值

遗传连锁分析中习惯使用以 10 为底的似然比对数，称为 LOD 值 (logarithm of odds)：

$$\text{LOD} = \log_{10} \frac{L(\hat{\theta})}{L(\theta_0)} = \frac{\Lambda}{2 \ln 10} = \frac{\Lambda}{4.605}. \quad (3.11)$$

在上面的测交例中，设 $m = 100$ ， $k = 30$ ，则 $\hat{c} = 0.30$ ，

$$\ell(0.30) - \ell(0.5) = 30 \ln 0.3 + 70 \ln 0.7 - 100 \ln 0.5 = 8.228,$$

$\Lambda = 16.46$ ， $\text{LOD} = 3.57$ 。按自由度 1 的卡方分布， $p = 5.0 \times 10^{-5}$ 。LOD 为 3 意味着在备择假设下观察到当前资料的概率是零假设下的一千倍。莫顿 (1955) 提出以 $\text{LOD} \geq 3$ 作为人类连锁的显著标准，其理由并非 p 值本身，而是贝叶斯式的考虑：两个随机位点连锁的先验概率很小（约百分之二到五），需要约一千倍的似然比，才能使连锁的后验概率达到约百分之九十五。本章后文讨论贝叶斯推断时还将回到这一点。

还有一个技术细节。连锁检验的零假设 $c = 0.5$ 位于参数空间 $[0, 0.5]$ 的边界，单侧备择下 Λ 在零假设下的渐近分布不是 χ_1^2 ，而是一半概率为零、一半概率为 χ_1^2 的混合分布，记为 $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ 。同样的问题出现在检验方差组分是否为零时（第 23 章）。忽略边界会使 p 值加倍，检验偏于保守。

3.6.3 区间估计

参数的 95% 置信区间可以由 Wald 方法得到： $\hat{\theta} \pm 1.96 \text{SE}(\hat{\theta})$ 。对测交例， $\text{SE} = 0.0458$ ，区间为 $[0.210, 0.390]$ 。另一种方法是似然区间：收集所有满足 $2[\ell(\hat{\theta}) - \ell(\theta)] \leq 3.84$ 的 θ ，即检验不被拒绝的参数值的集合。测交例的似然区间为 $[0.216, 0.394]$ ，比 Wald 区间略向右偏，反映了似然函数在 c 较大一侧较平缓的不对称形状。连锁与 QTL 定位中常用“LOD 下降一个单位”的支持区间，即 $\log_{10} L$ 比最大值低 1 的范围，对应 Λ 下降 4.6；测交例中为

[0.209, 0.403], 约相当于 96.8% 的置信水平。似然区间对参数变换不变, 在小样本和边界附近通常优于 Wald 区间。

3.7 EM 算法: 不完全资料的最大似然

3.7.1 问题的结构

遗传资料中常有一些“本该观察却没有观察到”的信息: 显性使得表型相同的个体可能有不同基因型; 未分相的双杂合子无法区分两条单倍型; 数量性状位点的基因型本身无法直接观察, 只能从侧翼标记推断。这类问题的似然往往难以直接最大化, 但若缺失信息已知, 问题就变得十分简单。登普斯特、莱尔德和鲁宾 (1977) 统一表述的期望最大化 (EM) 算法正是利用这种结构: 在 E 步计算给定当前参数时完全资料对数似然的条件期望, 在 M 步最大化这个期望。两步交替进行, 直到收敛。

3.7.2 ABO 血型频率的 EM 估计

ABO 血型由一个位点上的三个等位基因 A、B、O 决定, A 与 B 对 O 为显性, A 与 B 共显性。四种表型与基因型的关系为: A 型包括 AA 与 AO, B 型包括 BB 与 BO, AB 型为 AB, O 型为 OO。设在 2128 个随机个体中观察到 A 型 725 人、B 型 258 人、AB 型 72 人、O 型 1073 人, 在 Hardy-Weinberg 平衡下估计三个等位基因频率 p_A 、 p_B 、 p_O 。

观察资料的对数似然为

$$\ell = n_A \ln(p_A^2 + 2p_A p_O) + n_B \ln(p_B^2 + 2p_B p_O) + n_{AB} \ln(2p_A p_B) + n_O \ln p_O^2.$$

对它直接求导并求解是可能的, 但方程是非线性的。设想我们知道 A 型个体中有 n_{AA} 个 AA、 n_{AO} 个 AO, B 型同理, 则等位基因计数立即给出频率:

$$p_A = \frac{2n_{AA} + n_{AO} + n_{AB}}{2N}, \quad p_B = \frac{2n_{BB} + n_{BO} + n_{AB}}{2N}. \quad (3.12)$$

E 步: 给定当前频率 $p^{(t)}$, A 型个体为 AA 的条件概率为 $p_A^2 / (p_A^2 + 2p_A p_O)$,

因此

$$E(n_{AA} | \text{资料}, p^{(t)}) = n_A \frac{p_A^{(t)2}}{p_A^{(t)2} + 2p_A^{(t)}p_O^{(t)}}, \quad E(n_{AO}) = n_A - E(n_{AA}),$$

B 型同理。**M 步**：把期望计数代入式 (3.12) 得到新频率。

从均匀初值 $p_A = p_B = p_O = 1/3$ 开始, 第一次迭代的期望计数为 $n_{AA} = 725 \times \frac{1/9}{1/9+2/9} = 241.7$, 于是 $p_A^{(1)} = (2 \times 241.7 + 483.3 + 72) / 4256 = 0.2440$ 。表 3.3 列出前几次迭代。约十次迭代后, 频率稳定在 $\hat{p}_A = 0.2091$, $\hat{p}_B = 0.0808$, $\hat{p}_O = 0.7101$ 。

表 3.3 ABO 血型频率的 EM 迭代

迭代	p_A	p_B	p_O	对数似然
0	0.3333	0.3333	0.3333	-3545.85
1	0.2440	0.0977	0.6582	-2327.07
2	0.2139	0.0817	0.7044	-2303.86
3	0.2097	0.0809	0.7094	-2303.555
4	0.2092	0.0808	0.7100	-2303.5505
收敛	0.2091	0.0808	0.7101	-2303.5505

以收敛频率计算的期望表型数为 725.1、258.1、71.9、1072.9, 与观察值几乎完全一致, 拟合优度卡方仅为 0.0001 (自由度 $4 - 1 - 2 = 1$)。这样好的拟合在真实资料中并不常见, 提示读者这组计数可能经过整理; 但它恰好说明了 EM 的逻辑。由观察信息矩阵的逆求得 $SE(\hat{p}_A) = 0.0066$, $SE(\hat{p}_B) = 0.0043$ 。

3.7.3 为什么 EM 总是上升

EM 算法最重要的性质是每次迭代都不会降低观察资料的似然。设完全资料为 $(\mathbf{y}, \mathbf{z})$, 其中 $\mathbf{z}$ 未观察。由条件概率,

$$\ln f(\mathbf{y} | \theta) = \ln f(\mathbf{y}, \mathbf{z} | \theta) - \ln f(\mathbf{z} | \mathbf{y}, \theta).$$




图 3.1 ABO 血型等位基因频率估计中的 EM 算法。A 图为对数似然（相对最大值）的等高线与 EM 迭代轨迹；B 图为各次迭代的对数似然与最大值之差，在对数尺度上近似直线下降，表明线性收敛

两边对 $f(\mathbf{z} | \mathbf{y}, \theta^{(t)})$ 取期望，左边不变，得到

$$\ell(\theta) = Q(\theta | \theta^{(t)}) - H(\theta | \theta^{(t)}),$$

其中 $Q(\theta | \theta^{(t)}) = E[\ln f(\mathbf{y}, \mathbf{z} | \theta) | \mathbf{y}, \theta^{(t)}]$ 正是 E 步计算的量， $H(\theta | \theta^{(t)}) = E[\ln f(\mathbf{z} | \mathbf{y}, \theta) | \mathbf{y}, \theta^{(t)}]$ 。由詹森不等式，对任何 θ ,

$$H(\theta | \theta^{(t)}) - H(\theta^{(t)} | \theta^{(t)}) = E\left[\ln \frac{f(\mathbf{z} | \mathbf{y}, \theta)}{f(\mathbf{z} | \mathbf{y}, \theta^{(t)})}\right] \leq \ln E\left[\frac{f(\mathbf{z} | \mathbf{y}, \theta)}{f(\mathbf{z} | \mathbf{y}, \theta^{(t)})}\right] = 0.$$

M 步选择 $\theta^{(t+1)}$ 使 Q 不减少，于是

$$\ell(\theta^{(t+1)}) - \ell(\theta^{(t)}) = [Q(\theta^{(t+1)}) - Q(\theta^{(t)})] - [H(\theta^{(t+1)}) - H(\theta^{(t)})] \geq 0. \quad (3.13)$$

单调性保证了 EM 的数值稳定，但不保证收敛到全局最大值。似然有多个局部极值时（例如多位点单倍型频率估计），应从多个初值出发比较结果。

3.7.4 收敛速度与缺失信息比例

EM 的收敛是线性的：靠近极值点时，每次迭代的误差近似按固定比例 λ 缩小。可以证明， λ 等于缺失信息比例，即完全资料信息中因资料缺失而损失的那一部分：

$$\lambda \approx \frac{\mathcal{I}_{\text{缺失}}}{\mathcal{I}_{\text{完全}}} = 1 - \frac{\mathcal{I}_{\text{观察}}}{\mathcal{I}_{\text{完全}}}.$$

ABO 例中, 相邻迭代误差之比稳定在 0.12 左右, 表示约 12% 的完全资料信息因显性而丢失; 这与直觉相符: O 频率很高, 大多数 A 型个体其实是 AO, 但这部分不确定性需要从其他类别的计数中“借回”。缺失信息比例越高, EM 越慢。在 QTL 区间作图中, 当标记稀疏时缺失信息比例可能高达百分之九十以上, EM 需要大量迭代; 这时可以用牛顿法、拟牛顿法或 EM 加速方法。路易斯 (1982) 给出了从 EM 计算观察信息矩阵的方法, 从而得到标准误。

EM 还有一层更深的意义: 它把一个困难的推断问题分解为两个直观的步骤——“猜测缺失的东西”与“当作完全资料来估计”。第 5 章估计单倍型频率、第 7 章的区间作图、第 23 章方差组分的 EM-REML, 都遵循同一逻辑。理解了 ABO 例, 就理解了这些方法的骨架。

3.8 线性模型、最小二乘与方差分析

3.8.1 一般线性模型

数量遗传学中的大多数统计模型可以写成线性模型的形式:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad E(\mathbf{e}) = \mathbf{0}, \quad \text{Var}(\mathbf{e}) = \sigma^2 \mathbf{I}. \quad (3.14)$$

最小二乘估计使残差平方和 $(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$ 最小, 满足正规方程 $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{y}$ 。高斯—马尔可夫定理指出, 在式 (3.14) 的二阶矩条件下, 最小二乘估计是所有线性无偏估计中方差最小的。若误差服从正态分布, 最小二乘估计同时也是最大似然估计。第 2 章已从几何角度讨论了正规方程的求解, 第 21 章将把它推广到误差相关、含随机效应的混合模型。

3.8.2 单因素随机模型与期望均方

估计遗传参数的经典方法是方差分析。设有 s 头公畜, 每头公畜有 n 个半同胞后代, 后代表型模型为

$$y_{ij} = \mu + s_i + e_{ij}, \quad s_i \sim (0, \sigma_s^2), \quad e_{ij} \sim (0, \sigma_e^2), \quad (3.15)$$

其中公畜效应 s_i 与残差相互独立。与固定效应模型不同, 这里关心的不

是某头具体公畜的效应，而是公畜效应在群体中的方差 σ_s^2 。组间平方和与组内平方和为

$$SS_B = n \sum_i (\bar{y}_{i.} - \bar{y}_{..})^2, \quad SS_W = \sum_i \sum_j (y_{ij} - \bar{y}_{i.})^2.$$

推导：期望均方

组内： $y_{ij} - \bar{y}_{i.} = e_{ij} - \bar{e}_{i.}$ ，公畜效应被消去。由样本方差的无偏性，每头公畜内 $E \sum_j (e_{ij} - \bar{e}_{i.})^2 = (n-1)\sigma_e^2$ ，于是

$$E(MS_W) = E\left[\frac{SS_W}{s(n-1)}\right] = \sigma_e^2.$$

组间： $\bar{y}_{i.} = \mu + s_i + \bar{e}_{i.}$ ，各公畜均值相互独立，方差为 $\sigma_s^2 + \sigma_e^2/n$ 。把它们看成 s 个独立观察，

$$E \sum_i (\bar{y}_{i.} - \bar{y}_{..})^2 = (s-1)\left(\sigma_s^2 + \frac{\sigma_e^2}{n}\right), \quad E(MS_B) = \sigma_s^2 + n\sigma_e^2.$$

于是方差组分的矩估计为

$$\hat{\sigma}_e^2 = MS_W, \quad \hat{\sigma}_s^2 = \frac{MS_B - MS_W}{n}. \quad (3.16)$$

组内相关系数 $t = \sigma_s^2 / (\sigma_s^2 + \sigma_e^2)$ 度量同组观察的相似程度。对半同胞家系， $\sigma_s^2 = \frac{1}{4}\sigma_A^2$ （第 11 章），因此 $h^2 = 4t$ 。检验 $\sigma_s^2 = 0$ 用 $F = MS_B/MS_W$ ，在零假设和正态条件下服从 $F_{s-1, s(n-1)}$ 分布；在 $\sigma_s^2 > 0$ 时， $F/(1 + n\sigma_s^2/\sigma_e^2)$ 服从同一分布，由此可得 t 的精确置信区间：

$$\frac{F/F_U - 1}{F/F_U - 1 + n} \leq t \leq \frac{F/F_L - 1}{F/F_L - 1 + n},$$

其中 F_U 、 F_L 分别为 F 分布的上、下 2.5% 分位数。

模拟一个例子：40 头公畜，各 8 个后代，真实 $\sigma_s^2 = 0.25$ ， $\sigma_e^2 = 0.75$ ($t = 0.25$ ，对应 $h^2 = 1.0$ ，这只是为了演示统计量，并非真实性状的典型取值)。一次模拟得到 $MS_B = 2.149$ ， $MS_W = 0.686$ ， $F = 3.13$ ($p = 2 \times 10^{-8}$)， $\hat{\sigma}_s^2 = 0.183$ ， $\hat{t} = 0.210$ ，95% 置信区间为 $[0.114, 0.349]$ 。即使有 320 条记录，

组内相关的区间仍相当宽，换算为遗传力时宽度再乘以四。这说明遗传参数估计需要大量资料，也说明报告点估计时必须同时报告不确定性。第13章将讨论如何通过设计提高估计效率。

方差分析估计量 $\hat{\sigma}_s^2$ 可能为负，这发生在 $MS_B < MS_W$ 时。负估计并不是计算错误，而是无偏性的代价：要使估计量的期望恰好等于一个可能很小的正数，它的抽样分布就必须有一部分落在零以下。把负值截为零可以得到更合理的点估计，但会引入正偏差；限制最大似然（REML）在参数空间内求解，自然地给出非负估计，第23章将系统讨论。

3.9 Delta 方法、自助法与比值参数的标准误

遗传力、遗传相关和重复力都是方差组分的比值或非线性函数，其标准误不能直接从组分的标准误读出。两种通用方法是 Delta 方法与自助法。

3.9.1 Delta 方法

若 $\hat{\theta}$ 近似服从 $N(\theta, \mathbf{V})$ ， g 可微，则一阶泰勒展开给出

$$g(\hat{\theta}) \approx g(\theta) + \nabla g'(\hat{\theta} - \theta), \quad \text{Var}[g(\hat{\theta})] \approx \nabla g' \mathbf{V} \nabla g. \quad (3.17)$$

对比值 $g = X/Y$,

$$\text{Var}\left(\frac{X}{Y}\right) \approx \left(\frac{\mu_X}{\mu_Y}\right)^2 \left[\frac{\text{Var}(X)}{\mu_X^2} + \frac{\text{Var}(Y)}{\mu_Y^2} - \frac{2\text{Cov}(X, Y)}{\mu_X \mu_Y} \right].$$

应用于组内相关 $t = \sigma_s^2 / (\sigma_s^2 + \sigma_e^2)$ ，并利用平衡资料中均方的抽样方差 $\text{Var}(MS) \approx 2E(MS)^2/df$ ，可导出经典近似

$$\text{SE}(\hat{t}) \approx \sqrt{\frac{2(1-t)^2[1+(n-1)t]^2}{n(n-1)(s-1)}}. \quad (3.18)$$

半同胞设计中 $\text{SE}(\hat{h}^2) = 4\text{SE}(\hat{t})$ 。式 (3.18) 显示，在总记录数固定时，标准误还依赖于家系大小 n 的选择。第13章将由此推导最优设计。

3.9.2 自助法

埃夫龙(1979)的自助法用重抽样代替解析推导：从原始资料中有放回地抽取同样大小的样本，重新计算统计量，重复许多次，用自助样本统计量的标准差估计标准误，用其分位数构造区间。对亲子回归，抽样单位应是“亲本—子代对”，不能把亲本与子代分别抽样；对家系资料，抽样单位应是整个家系。抽样单位选错，会破坏资料中的相关结构，低估标准误。

模拟 200 对亲子资料（真实 $h^2 = 0.4$ ），一次实现中回归斜率为 0.247， $\hat{h}^2 = 0.494$ 。由回归斜率标准误换算的解析标准误为 0.126，2000 次自助法得到的标准误为 0.117，百分位区间为 [0.269, 0.707]。两种方法相当接近；这次估计值高于真值，但真值落在区间内。读者可以重复模拟，体会 200 对资料估计遗传力的实际精度。

3.10 检验功效与样本量

显著性检验控制的是在零假设成立时错误拒绝的概率；**功效**则是在备择假设成立时正确拒绝的概率。功效分析回答的问题是：若真实效应为某个大小，需要多少资料才能以较高概率发现它？这对基因定位研究的设计尤为重要。

在大样本下，似然比统计量在备择假设下近似服从非中心卡方分布，非中心参数 λ_{NC} 近似等于把真实参数值代入后的期望统计量。对一个标记的单位点回归检验 $y = \mu + \beta x + e$ ，若 x 为等位基因拷贝数，

$$\lambda_{NC} \approx \frac{N\beta^2 \text{Var}(x)}{\sigma_e^2} = N \frac{q_{\text{解释}}^2}{1 - q_{\text{解释}}^2} \approx Nq_{\text{解释}}^2, \quad (3.19)$$

其中 $q_{\text{解释}}^2 = \beta^2 \text{Var}(x) / \sigma_y^2$ 是该位点解释的表型方差比例。功效为 $\Pr(\chi_1^2(\lambda_{NC}) > c_\alpha)$ 。式 (3.19) 有一个简洁而深刻的含义：检验功效只通过“样本量乘以解释方差比例”这一乘积依赖于效应大小与等位基因频率。一个解释千分之一方差有位点，在 $\alpha = 5 \times 10^{-8}$ 的全基因组显著水平下要达到 80% 功效，需要约 $\lambda_{NC} = 39.5$ ，即约四万个个体。第 8 章与第 25 章将看到，人类身高研究从数千人扩展到数百万人，正是为了发现这些微小效应的

位点。

3.11 多重检验：族错误率与错误发现率

3.11.1 问题

全基因组扫描对成千上万个标记进行检验。若每个检验都在 $\alpha = 0.05$ 水平进行，即使没有任何真实效应，一万次检验中也会平均出现五百个“显著”结果。必须调整显著性标准，但调整方式取决于想控制什么样的错误。

设进行 M 次检验，其中 M_0 个零假设为真。按检验结果和真实状态可分为四类：真实零假设中被拒绝的数目 V （假阳性），未被拒绝的 U ；非零假设中被拒绝的数目 S （真阳性），未被拒绝的 T 。总拒绝数 $R = V + S$ 。

族错误率(FWER)是至少出现一个假阳性的概率 $\Pr(V \geq 1)$ 。Bonferroni 校正以 α/M 作为每次检验的界限，由并集不等式 $\Pr(\cup A_i) \leq \sum \Pr(A_i)$ 保证 $\text{FWER} \leq \alpha$ ，对检验间的任意相关结构都成立。若检验独立，Šidák 校正 $1 - (1 - \alpha)^{1/M}$ 精确控制 FWER，数值上与 Bonferroni 非常接近。对高度相关的标记，Bonferroni 过于保守；置换检验通过打乱表型与基因型的对应关系，在保持标记间相关结构的同时得到全基因组最大统计量的零分布，是连锁与 QTL 定位中确定阈值的标准方法（第 7 章）。

3.11.2 错误发现率

当研究目的是筛选候选位点供后续验证时，控制“至少一个错误”过于严格。本雅米尼与霍赫贝格（1995）提出控制**错误发现率**（FDR），即拒绝中假阳性所占比例的期望：

$$\text{FDR} = E\left[\frac{V}{\max(R, 1)}\right]. \quad (3.20)$$

BH 程序如下：把 M 个 p 值从小到大排序为 $p_{(1)} \leq \dots \leq p_{(M)}$ ，找到满足

$$p_{(k)} \leq \frac{k}{M}\alpha$$

的最大 k ，拒绝 $p_{(1)}, \dots, p_{(k)}$ 对应的全部假设。若检验相互独立（或满足正相关依赖条件），该程序保证 $\text{FDR} \leq \frac{M_0}{M}\alpha \leq \alpha$ 。

为什么 BH 程序控制错误发现率（独立情形的简要证明）

对每个真实零假设 i ，其 p 值 $p_i \sim U(0,1)$ 且与其余 p 值独立。可以证明，在 BH 规则下，

$$E\left[\frac{\mathbf{1}(i \text{ 被拒绝})}{\max(R, 1)}\right] = \sum_{k=1}^M \frac{1}{k} \Pr(p_i \leq \frac{k\alpha}{M}, R = k) = \frac{\alpha}{M}.$$

关键一步是：固定其余 p 值时，若 p_i 被拒绝且总拒绝数为 k ，则将 p_i 换成任何不超过 $k\alpha/M$ 的值，拒绝数仍为 k ；因此 $\Pr(p_i \leq k\alpha/M, R = k) = \frac{k\alpha}{M} \Pr(R^{(i)} = k)$ ，其中 $R^{(i)}$ 是令 $p_i = 0$ 时的拒绝数，各 k 的概率之和为一。对全部 M_0 个真实零假设求和，即得 $FDR = M_0\alpha/M$ 。

斯托雷与蒂布希拉尼（2003）进一步提出 q 值：某个检验的 q 值是把它判为显著时所能达到的最小 FDR。由于 BH 程序的 FDR 上界是 $\pi_0\alpha$ ，其中 $\pi_0 = M_0/M$ ，估计 π_0 可以提高功效。利用零假设 p 值均匀分布的性质，

$$\hat{\pi}_0(\lambda) = \frac{\#\{p_i > \lambda\}}{M(1 - \lambda)},$$

常取 $\lambda = 0.5$ 。 p 值直方图在接近零处的“尖峰”来自真实效应，右侧平坦部分的高度反映 π_0 。

模拟一万个检验，其中 200 个有真实效应 ($\pi_0 = 0.98$)。未校正的 $p < 0.05$ 给出 690 个显著结果，其中 514 个是假阳性，错误比例约四分之三。Bonferroni 校正给出 32 个显著结果，全部为真；BH 程序在 $\alpha = 0.05$ 下给出 98 个显著结果，其中 2 个为假，实际错误发现比例约 2%。估计的 $\hat{\pi}_0 = 0.979$ ，与真值非常接近。可见，FDR 控制在可接受的假阳性代价下，比 FWER 控制多发现了约两倍的真实信号。

FDR 与 FWER 并无绝对优劣，关键是与研究目的相符。用于向产业推荐标记辅助选择的位点，或在论文中宣称“新发现”的位点，需要较严格的族错误控制和独立验证；用于富集分析或优先排序候选基因的位点，则可以采用 FDR。还应注意，FDR 是对一批发现的整体陈述，不是关于某个具体位点为假阳性概率的陈述；后者称为局部 FDR，需要另行估计。




图 3.2 多重检验的模拟示例（一万个检验，其中两百个具有真实效应）。A 图为 p 值直方图，右侧平坦部分的高度反映真实零假设比例；B 图为排序后 p 值与 BH 阶梯界限及 Bonferroni 界限的比较

3.12 贝叶斯推断的基本结构

贝叶斯推断把参数也视为随机变量，用先验分布 $\pi(\theta)$ 表示资料之前的知识，用贝叶斯定理把先验与似然结合为后验分布：

$$\pi(\theta | \mathbf{y}) = \frac{f(\mathbf{y} | \theta) \pi(\theta)}{\int f(\mathbf{y} | \theta) \pi(\theta) d\theta} \propto L(\theta) \pi(\theta). \quad (3.21)$$

最简单而极为重要的例子是正态—正态模型。设育种值先验 $A \sim N(0, \sigma_A^2)$ ，表型 $P | A \sim N(A, \sigma_E^2)$ ，则后验

$$A | P \sim N\left(\frac{\sigma_A^2}{\sigma_A^2 + \sigma_E^2} P, \frac{\sigma_A^2 \sigma_E^2}{\sigma_A^2 + \sigma_E^2}\right) = N(h^2 P, (1 - h^2) \sigma_A^2).$$

后验均值正是式 (3.6) 的回归预测，后验方差正是预测误差方差。由此可见，选择指数和 BLUP 既可以理解为频率学派的最佳线性预测，也可以理解为正态先验下的后验均值；先验方差 σ_A^2 决定“收缩”的强度。第 1 章已从条件期望讨论过这一点，第 27 章的贝叶斯基因组预测方法则通过改变先验形状（如混合先验、重尾先验）来改变收缩方式。

贝叶斯框架也澄清了 LOD 值 3 的含义。设两个位点连锁的先验概率为 π_L ，则连锁的后验比数为

$$\frac{\Pr(\text{连锁} | \mathbf{y})}{\Pr(\text{不连锁} | \mathbf{y})} = \frac{\pi_L}{1 - \pi_L} \times \frac{\Pr(\mathbf{y} | \text{连锁})}{\Pr(\mathbf{y} | \text{不连锁})}.$$

人类基因组中两个随机位点位于同一染色体且距离在可检测范围内的先验概率约为 0.05，先验比数约为 1/19；似然比为 1000 (LOD=3) 时，后验比数约为 53，即连锁的后验概率约为 98%。若用最大化后的似然比代替边缘似然比，后验概率会略被高估，这也是要求 LOD 达到 3 而非更低的原因之一。全基因组关联研究中 5×10^{-8} 的显著标准，同样可以从“任意一个常见变异与性状有真实关联的先验概率很低”这一角度理解。

3.13 模型比较与信息准则

许多数量遗传学问题需要在多个模型之间选择：是否包含母体效应？QTL 是加性的还是有显性？一个位点还是两个连锁位点？嵌套模型可以用似然比检验比较；非嵌套模型或需要兼顾拟合与复杂度时，常用信息准则：

$$AIC = -2\ell(\hat{\theta}) + 2k, \quad BIC = -2\ell(\hat{\theta}) + k \ln N, \quad (3.22)$$

k 为参数个数， N 为样本量，取值较小的模型较优。AIC 近似最小化对新资料的预测误差（以 KL 散度衡量），BIC 近似最大化模型的后验概率。BIC 对复杂度的惩罚随样本量增大，在大样本中倾向于选择较简单的模型，并在真实模型位于候选集中时具有一致性；AIC 则倾向于选择预测效果好的较复杂模型。两者回答的问题不同。

对预测问题，最直接的方法是交叉验证：把资料分成训练集与验证集，在训练集上拟合，在验证集上评价。在遗传资料中，训练集与验证集之间的亲缘关系、共同环境与时间结构决定了交叉验证究竟检验了什么，这是第 29 章的主题。这里只需记住一条原则：模型选择的全部步骤，包括特征筛选与参数调整，都必须只用训练资料完成，否则验证结果会因信息泄漏而过于乐观。

3.14 离散资料的检验：拟合优度、列联表与精确检验

遗传资料中有大量计数：基因型数、表型类别数、重组型与亲本型配子数、病例与对照中的等位基因数。这类资料的推断以多项分布为基础。设 N

个个体落入 K 个类别, 观察数为 $O_1, \dots, O_K$, 模型给出的类别概率为 $\pi_k(\theta)$, 期望数为 $E_k = N\pi_k(\hat{\theta})$ 。皮尔逊卡方统计量与似然比统计量

$$X^2 = \sum_k \frac{(O_k - E_k)^2}{E_k}, \quad G^2 = 2 \sum_k O_k \ln \frac{O_k}{E_k} \quad (3.23)$$

在模型成立时近似服从自由度为 $K - 1 - r$ 的卡方分布, r 为由资料估计的独立参数个数。两者在大样本中等价, G^2 正是式 (3.10) 的似然比统计量在多项模型中的形式; 当期望数较小时, 二者的近似都变差。

3.14.1 孟德尔比例的检验

F_2 群体中一个共显性标记的三种基因型理论比例为 $1 : 2 : 1$ 。若在 200 株中观察到 AA 42 株、 Aa 110 株、 aa 48 株, 期望数为 50、100、50,

$$X^2 = \frac{8^2}{50} + \frac{10^2}{100} + \frac{2^2}{50} = 1.28 + 1.00 + 0.08 = 2.36,$$

自由度 2 (理论比例完全给定, 无需估计参数), $p = 0.31$, 不拒绝 $1 : 2 : 1$ 。标记的偏分离在作图群体中并不罕见, 可能来源于配子或合子选择、分型错误或群体结构; 第 6 章将讨论偏分离对连锁估计的影响。

3.14.2 Hardy-Weinberg 平衡检验

在随机抽样的群体中, 检验基因型频率是否符合 Hardy-Weinberg 比例时, 需要先由资料估计等位基因频率, 因而自由度为 $3 - 1 - 1 = 1$ 。对上一节表 3.1 中 A 位点的 50 个个体 (aa 8、 Aa 24、 AA 18), $\hat{p} = 0.6$, 期望数为 8、24、18, 卡方恰好为零。在真实资料中, 双等位标记的 Hardy-Weinberg 检验常用精确检验, 即在给定等位基因计数下杂合子数的条件分布:

$$\Pr(n_{Aa} = h \mid n_A, N) = \frac{N! n_A! n_a! 2^h}{n_{AA}! h! n_{aa}! (2N)!}. \quad (3.24)$$

把概率不大于观察构型的全部构型概率相加即得精确 p 值。精确检验对稀有等位基因尤其重要, 因为此时期望的稀有纯合子数远小于 5, 卡方近似会严重失真。第 4 章与第 26 章将从群体遗传与质量控制两个角度讨论平衡偏离的来源。

3.14.3 列联表的独立性检验

病例—对照关联研究中，最基本的分析是 2×2 等位基因计数表或 2×3 基因型计数表的独立性检验。设病例与对照中 A 等位基因计数分别为 a 与 c ，非 A 计数为 b 与 d ，比值比

$$OR = \frac{ad}{bc}, \quad SE(\ln \widehat{OR}) \approx \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}.$$

等位基因计数检验把每个个体的两条染色体当作独立观察，这在病例与对照两组都满足 Hardy–Weinberg 平衡时成立；否则应采用基于基因型的 Cochran–Armitage 趋势检验，它对加性剂量编码作线性趋势检验，对平衡偏离稳健。第 8 章将把这些检验放到全基因组关联研究的完整框架中，并讨论群体分层带来的混杂。

3.15 二分类与计数性状：广义线性模型与阈值模型

许多重要性状并非连续：发病与否、难产与否、受胎与否、窝产仔数。线性模型直接用于这些资料会遇到两个问题：预测值可能超出合理范围，方差依赖于均值。**广义线性模型**通过连接函数 g 把期望与线性预测量相连：

$$g(E(y_i)) = \mathbf{x}_i' \boldsymbol{\beta},$$

二分类资料用 logit 连接 $\ln \frac{\pi}{1-\pi}$ 或 probit 连接 $\Phi^{-1}(\pi)$ ，计数资料用对数连接。参数由最大似然估计，迭代加权最小二乘是其标准算法。

数量遗传学对二分类性状有一个独特而深刻的解释：**阈值模型**。设每个个体有一个不可观察的连续“易感性” (liability) $\lambda_i = \mu + A_i + E_i$ ，服从正态分布，当 λ_i 超过阈值 T 时个体表现为患病。这样，二分类表型的发病率 K 由阈值在易感性分布中的位置决定， $\Pr(y = 1) = 1 - \Phi(T)$ （以标准化易感性计）。这一模型由赖特于 1934 年用于豚鼠多趾性状，福尔克纳于 1965 年用于人类疾病的遗传分析，是 probit 连接的遗传学解释。

阈值模型把二分类性状的遗传参数定义在连续的易感性尺度上，使不同发病率的群体之间可以比较。观察尺度 (0/1 尺度) 上的遗传力 h_o^2 与易感性

尺度上的遗传力 h_l^2 之间有 Dempster–Lerner 近似关系：

$$h_o^2 = h_l^2 \frac{z^2}{K(1-K)}, \quad (3.25)$$

其中 $z = \phi(T)$ 是标准正态密度在阈值处的高度。发病率为 10% 时, $T = 1.2816$, $z = 0.1755$, 换算因子为 $0.0308/0.09 = 0.342$; 发病率为 50% 时换算因子为 0.637。同一易感性遗传力, 在发病率较低时对应低得多的观察尺度遗传力。这解释了为何很多疾病性状在 0/1 尺度上的遗传力很低, 却不代表其遗传基础不重要。第 12 章与第 24 章将推导该关系并讨论阈值模型的估计。

3.16 固定效应、随机效应与收缩：混合模型的预告

在式 (3.15) 中, 公畜效应 s_i 被视为随机效应, 我们关心它们的方差; 但有时我们也想知道某头具体公畜的效应。在固定效应模型中, 公畜效应的估计是其后代均值减去总均值: $\hat{s}_i = \bar{y}_{i.} - \bar{y}_{..}$ 。在随机效应模型中, 给定方差组分, s_i 的最佳线性预测为

$$\tilde{s}_i = \frac{n\sigma_s^2}{n\sigma_s^2 + \sigma_e^2} (\bar{y}_{i.} - \mu) = \frac{n}{n+k} (\bar{y}_{i.} - \mu), \quad k = \frac{\sigma_e^2}{\sigma_s^2}. \quad (3.26)$$

预测值是后代均值离差向零“收缩”的结果, 收缩程度取决于后代数 n 和方差比 k 。后代少的公畜收缩较多, 后代多的公畜几乎不收缩。半同胞情形下 $k = (4 - h^2)/h^2$, 这正是亨德森公畜模型中的方差比。式 (3.26) 与例 3.1 中的 $h^2(P - \mu)$ 有完全相同的结构: 两者都是“回归到均值”, 只是信息来源不同。

固定效应与随机效应的区分并不在于效应本身是否“真正随机”, 而在于推断的范围和信息的使用方式。若把公畜视为来自某个群体的样本, 并希望推断推广到这个群体, 或者希望各公畜效应之间相互“借用信息”, 就应视为随机效应; 若只关心这几头公畜, 且每头都有充分资料, 二者差别很小。随机效应模型的真正优势出现在资料不平衡时: 信息少的个体被适度收缩, 避免因偶然的高表现而被高估。这一思想由亨德森发展为混合模型方程, 第 21 至 24 章将系统讨论。

3.17 统计推断中的常见陷阱

遗传资料的特殊结构使得一些统计陷阱格外常见。认识它们，往往比掌握更复杂的方法更能提高研究质量。

3.17.1 赢家诅咒

在全基因组扫描中，只有统计量超过阈值的位点被报告。由于估计值含有抽样误差，被选出的位点往往恰好是抽样误差为正的那些，其效应估计系统性地偏高。这种选择后偏差称为“赢家诅咒”，在 QTL 定位中称为比维斯效应（第 7 章）。设真实效应为 β ，估计量 $\hat{\beta} \sim N(\beta, \sigma^2)$ ，仅当 $|\hat{\beta}|/\sigma > c$ 时报告，则

$$E(\hat{\beta} \mid |\hat{\beta}| > c\sigma) > \beta \quad (\beta > 0).$$

功效越低，偏差越大。当功效只有百分之二三十时，报告的效应可能比真实效应高出一倍以上。纠正的方法包括在独立样本中重新估计效应、条件似然校正以及贝叶斯收缩。

3.17.2 向均值回归

高尔顿最早观察到的回归现象，在育种资料中随处可见：首次测定表现最好的个体，复测时往往表现下降；选择后代的均值低于选中亲本的均值。这不一定意味着“退化”，而是表型中非遗传部分不能传递或不能重复的必然结果。若把复测下降误判为处理无效或环境恶化，就会得出错误结论。对照组与随机化是区分回归效应与真实效应的根本手段。

3.17.3 混杂与辛普森悖论

两个变量之间的关联可能完全来自第三个变量。在群体遗传资料中，最典型的混杂来自群体结构：若病例主要来自某个亚群，而该亚群中某等位基因频率恰好较高，则该等位基因与疾病呈现关联，即使它与疾病毫无因果联系。在合并资料中观察到的关联方向，甚至可能与各亚群内部的方向相反，这就是辛普森悖论。第 8 章将讨论用主成分和混合模型校正群体分层的方法。

3.17.4 确证偏倚与选择性样本

医学遗传研究中的家系常因先证者患病而被纳入，这种“确证”改变了家系内发病率的分布；育种资料中的记录往往来自经过选择的个体，例如只有通过初选的公牛才有后代测定资料。在这些情况下，样本统计量不再是总体参数的无偏估计。处理方法取决于选择机制：若选择仅依赖于已纳入模型的可观察变量，基于似然的方法（如利用全部相关资料的混合模型）可以给出有效推断；若选择依赖于未观察的量，则需要显式建模选择过程。第21章将从混合模型的角度讨论选择对BLUP的影响。

3.17.5 统计显著与生物学重要

一个效应在统计上显著，只说明它不太可能是零，而不说明它大到值得关注；在大样本中，极小的效应也会高度显著。反之，不显著也不等于没有效应，可能只是功效不足。报告效应大小及其置信区间，比只报告 p 值更有信息。对育种决策而言，真正重要的是效应在经济目标上的价值和估计的不确定性，这将在第五篇详细讨论。

3.18 置换检验与重抽样推断

当检验统计量的零分布难以推导时，置换检验提供了一种几乎不依赖分布假设的方法。在零假设“表型与基因型无关”下，表型与基因型的配对是可交换的。把表型随机重排若干次，每次重新计算统计量，得到的经验分布就是条件零分布。观察统计量在这一分布中的位置给出 p 值：

$$\hat{p} = \frac{1 + \#\{T^{(b)} \geq T_{\text{obs}}\}}{1 + B}.$$

分子分母各加一保证 p 值不为零，并使检验在有限置换次数下仍然有效。

置换检验在基因组扫描中有一个特别重要的用途：确定全基因组显著阈值。每次置换后对全部标记计算统计量，记录其最大值； B 次置换的最大值分布的第 $1 - \alpha$ 分位数，就是控制全基因组族错误率为 α 的阈值。由于每次置换保留了标记之间的全部相关结构，这一阈值自动适应标记密度和连锁不

平衡模式，不像 Bonferroni 校正那样过于保守。丘吉尔与多尔格（1994）把这一方法引入 QTL 定位，现已成为标准做法。

置换检验也有前提：零假设下观察必须可交换。若资料中存在家系结构、固定效应或群体分层，简单的全体重排会破坏这些结构，导致错误的零分布。此时应在层内置换，或对残差置换，或采用基于模型的参数自助法。重抽样方法的力量来自于它对资料生成机制的忠实模仿，模仿得不对，结论也就不可靠。

3.19 本章小结

数量遗传学的理论推演最终要通过资料检验和参数估计与现实相连。本章从学科历史出发，说明了数量遗传学如何把孟德尔的离散遗传与生物统计学派的连续变异统一起来，以及它在群体遗传学与统计遗传学之间的位置。随后讨论的统计工具贯穿全书：估计量的偏差与均方误差解释了收缩预测的合理性；回归与相关给出了遗传力的两种统计含义；似然原理与似然比检验是连锁分析和 QTL 定位的基础，LOD 值只是以 10 为底的似然比对数；EM 算法用“填补—估计”的循环处理显性、单倍型相位和 QTL 基因型等缺失信息；方差分析的期望均方连接了家系资料与方差组分；Delta 方法与自助法给出比值参数的标准误；功效分析与多重检验决定了基因定位研究的规模与显著性标准；贝叶斯推断则把预测、收缩与先验知识统一起来。

这些工具都有自己的适用条件。边界上的参数、相关的检验、选择后的样本、亲属间的相关结构，是遗传资料中最常见的“非标准”情形。正确的推断不仅在于套用公式，更在于识别何时公式的前提不再成立。

3.20 习题

习题 3.1 在表 3.1 中计算 $\Pr(G_B = Bb \mid G_A = AA)$ 与 $E(Y \mid G_A = AA)$ ，并判断 A 位点为 AA 的个体相对于群体平均携带的 B 等位基因是多还是少。

习题 3.2 证明：对 N 个独立观察， $\frac{1}{N} \sum (x_i - \bar{x})(y_i - \bar{y})$ 作为 $\text{Cov}(X, Y)$ 的估计量，其期望为 $\frac{N-1}{N} \text{Cov}(X, Y)$ 。

习题 3.3 某性状遗传力为 0.25, 表型标准差为 10。个体表型高于群体均值 15。求其育种值的预测值、预测准确度和预测误差标准差。若改用该个体的 4 次独立重复记录的平均值 (重复力 0.4), 结果如何变化?

习题 3.4 测交群体中 200 个配子有 40 个重组型。计算重组率的 MLE、标准误、LOD 值以及 LOD 下降 1 的支持区间端点所满足的方程。

习题 3.5 用 ABO 资料, 从初值 $p_A = 0.3$ 、 $p_B = 0.1$ 、 $p_O = 0.6$ 手算一次 EM 迭代。

习题 3.6 在单因素随机模型中, 设 $s = 50$, $n = 10$, $MS_B = 3.0$, $MS_W = 1.5$ 。求 $\hat{\sigma}_s^2$ 、 $\hat{t}$; 若为半同胞家系, 求 $\hat{h}^2$ 及其由式 (3.18) 给出的近似标准误。

习题 3.7 某次扫描检验了五个标记, p 值为 0.001、0.008、0.039、0.041、0.6。在 $\alpha = 0.05$ 下, 分别用 Bonferroni 与 BH 程序判断哪些显著。

习题 3.8 一个位点解释表型方差的 0.5%。在显著水平 5×10^{-8} 下, 需要多少个体才能达到约 80% 的功效? (提示: χ_1^2 在 5×10^{-8} 处的临界值约为 29.7, 80% 功效所需非中心参数约为 39.5。)

3.21 习题解答

3.1 $\Pr(G_B = Bb | AA) = 0.10/0.36 = 0.278$ 。 $E(Y | AA) = (0 \times 0.06 + 1 \times 0.10 + 2 \times 0.20)/0.36 = 1.389$, 高于群体平均 1.08, 说明 AA 个体平均携带较多 B 等位基因, 与两位点正协方差一致。

3.2 $\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum (x_i - \mu_x)(y_i - \mu_y) - N(\bar{x} - \mu_x)(\bar{y} - \mu_y)$ 。前一项期望为 $N\sigma_{XY}$, 后一项期望为 $N \cdot \sigma_{XY}/N = \sigma_{XY}$, 故期望为 $(N-1)\sigma_{XY}$, 除以 N 即得。

3.3 单次记录: $\hat{A} = 0.25 \times 15 = 3.75$, 准确度 $\sqrt{0.25} = 0.5$, $\sigma_A = 5$, 预测误差标准差 $5\sqrt{1-0.25} = 4.33$ 。4 次平均: 回归系数 $b = \frac{nh^2}{1+(n-1)r} = \frac{4 \times 0.25}{1+3 \times 0.4} = 0.4545$, 若平均表型优势仍为 15, $\hat{A} = 6.82$ 。由于 $\text{Var}(\hat{A}) = \text{Cov}(A, \hat{A}) = b h^2 \sigma_P^2$, 准确度的平方 $r^2 = b h^2 \sigma_P^2 / \sigma_A^2 = b$, 故 $r = \sqrt{0.4545} = 0.674$; 预测误差标准差 $5\sqrt{1-0.4545} = 3.69$ 。第 15 章将系统推导这些公式。

3.4 $\hat{c} = 0.2$, $SE = \sqrt{0.2 \times 0.8/200} = 0.0283$ 。 $\ell(0.2) - \ell(0.5) = 40 \ln 0.2 + 160 \ln 0.8 - 200 \ln 0.5 = 37.68$, $LOD = 37.68 / \ln 10 = 16.36$ 。支持区间端点满足 $40 \ln c + 160 \ln(1 - c) = 40 \ln 0.2 + 160 \ln 0.8 - \ln 10$ 。

3.5 $E(n_{AA}) = 725 \times 0.09 / (0.09 + 0.36) = 145$, $n_{AO} = 580$; $E(n_{BB}) = 258 \times 0.01 / (0.01 + 0.12) = 19.85$, $n_{BO} = 238.15$ 。 $p_A = (290 + 580 + 72) / 4256 = 0.2213$, $p_B = (39.69 + 238.15 + 72) / 4256 = 0.0822$, $p_O = 0.6965$ 。

3.6 $\hat{\sigma}_s^2 = (3.0 - 1.5) / 10 = 0.15$, $\hat{t} = 0.15 / 1.65 = 0.0909$, $\hat{h}^2 = 0.364$ 。由式 (3.18), $SE(\hat{t}) = \sqrt{2(0.9091)^2(1.818)^2 / (10 \times 9 \times 49)} = 0.0352$, $SE(\hat{h}^2) \approx 0.141$ 。

3.7 Bonferroni 界限 0.01: 前两个显著。BH 界限依次为 0.01、0.02、0.03、0.04、0.05; $p_{(2)} = 0.008 \leq 0.02$, $p_{(3)} = 0.039 > 0.03$, $p_{(4)} = 0.041 > 0.04$, $p_{(5)} = 0.6 > 0.05$, 最大满足条件的 $k = 2$, 同样只有前两个显著。

3.8 $Nq^2 / (1 - q^2) \approx 39.5$, $N \approx 39.5 \times 0.995 / 0.005 \approx 7860$ 。

第二篇

PART II

群体遗传结构与遗传图谱

数量性状的遗传分析以孟德尔位点在群体中的频率、组合与传递为起点。本篇讨论单位点与多位点群体模型、连锁不平衡的形成与衰减，以及连锁图谱的构建原理。

第 4 章 单基因座群体模型与等位基因频率的演变

第 5 章 多基因座单倍型、连锁不平衡与重组

第 6 章 遗传连锁与连锁图谱的构建

单基因座群体模型与等位基因频率的演变

4.1 群体、位点与等位基因：三个基本概念

孟德尔告诉我们，个体的性状受成对等位基因影响，亲本把每对等位基因中随机的一个传给后代。数量遗传学的“现代综合”则把这一思想推广到受许多位点和环境共同影响的连续性状。在进入多位点与数量性状之前，必须先把单个位点在群体中的行为弄清楚。本章讨论的就是这一层次：一个位点上的等位基因在群体中有多常见，它们怎样组合成基因型，以及这些频率在突变、迁移、选择和随机漂变作用下怎样随世代改变。

三个概念需要先界定。**位点** (locus) 是基因组上的一段 DNA，其长度与功能在不同语境中可以相当含糊：它可能是一个基因、一个单核苷酸多态位点 (SNP)、一个微卫星重复，也可能只是一个尚未被精确定位的数量性状位点区间。**等位基因** (allele) 是同一位点上可区分的不同序列类型。**群体** (population) 则是在研究者看来具有某种内聚性的一群个体，通常指能够相互交配、共享一个基因库的个体集合。群体的边界并不总是清楚的：一个品种、一个育种核心群、一个商品场、一个地方类群，都可能被当作“群体”，而不同的界定会得到不同的频率。

由此可以看到群体遗传学的第一个基本立场：频率是群体的属性，不是等位基因本身的属性。同一个等位基因，在一个品种中可能接近固定，在另一个品种中却很稀少；在核心群中常见，在商品代中可能少见。第9章将反复强调，等位基因的平均效应、加性方差和遗传力都依赖于这些频率，因此都是“群体参数”。本章为这一立场提供最基本的群体遗传学基础。

4.2 基因型频率与等位基因频率

4.2.1 计数估计

考察冰岛人群中的 MN 血型。MN 血型由一个位点上的两个共显性等位基因 M 与 N 决定，三种基因型可直接由血清学分型区分。在 747 人中观察到 MM 233 人、MN 385 人、NN 129 人。基因型频率记为

$$P = \frac{233}{747} = 0.312, \quad H = \frac{385}{747} = 0.515, \quad Q = \frac{129}{747} = 0.173.$$

747 人携带 $2 \times 747 = 1494$ 个等位基因，其中 M 的数目为 $2 \times 233 + 385 = 851$ 。于是等位基因 M 的频率

$$p = \frac{2n_{MM} + n_{MN}}{2N} = P + \frac{1}{2}H = 0.570, \quad q = Q + \frac{1}{2}H = 0.430. \quad (4.1)$$

式 (4.1) 的“计数估计”也是最大似然估计： $2N$ 个等位基因中 M 的数目服从二项分布 $B(2N, p)$ (假定等位基因独立抽样)，对数似然 $n_M \ln p + (2N - n_M) \ln(1 - p)$ 的最大值点正是 $n_M/2N$ 。其标准误为 $\sqrt{pq/2N} = 0.0128$ 。需要提醒的是，二项抽样的前提是等位基因相互独立；若群体中存在近交或亚群结构，同一个体的两个等位基因正相关，有效的独立等位基因数小于 $2N$ ，标准误会被低估。在 F 为近交系数时，频率估计的方差为 $pq(1 + F)/2N$ 。

4.2.2 多等位基因

对 k 个等位基因 $A_1, \dots, A_k$ ，等位基因 A_i 的频率等于纯合子 $A_i A_i$ 频率加上所有含 A_i 的杂合子频率的一半：

$$p_i = P_{ii} + \frac{1}{2} \sum_{j \neq i} H_{ij}.$$

k 个等位基因可构成 $k(k+1)/2$ 种基因型，其中 k 种纯合子、 $k(k-1)/2$ 种杂合子。微卫星标记常有十个以上的等位基因，基因型类别多达数十种，许多类别的观察数很小，这给后面的平衡检验带来困难。

4.3 Hardy-Weinberg 定律

4.3.1 推导

1908 年, 英国数学家哈代与德国医生温伯格各自独立地证明了一个后来以他们命名的结论: 在一个大的随机交配群体中, 若没有选择、突变和迁移, 等位基因频率与基因型频率在世代间保持不变, 且基因型频率由等位基因频率以简单的二项式关系决定。

推导的关键是独立性。随机交配意味着一个个体从父本获得的等位基因与从母本获得的等位基因相互独立。设雌雄配子中 A_1 的频率均为 p , A_2 的频率均为 $q = 1 - p$, 后代基因型的联合概率等于两个边际概率之积 (表 4.1)。

表 4.1 随机交配下合子基因型的形成

母本配子 \ 父本配子	$A_1 (p)$	$A_2 (q)$
$A_1 (p)$	$A_1A_1: p^2$	$A_1A_2: pq$
$A_2 (q)$	$A_2A_1: qp$	$A_2A_2: q^2$

合并两种杂合子, 后代基因型频率为

$$A_1A_1: p^2, \quad A_1A_2: 2pq, \quad A_2A_2: q^2. \quad (4.2)$$

后代中 A_1 的频率为 $p^2 + \frac{1}{2}(2pq) = p(p + q) = p$, 与亲代相同。因此一旦达到式 (4.2) 的比例, 在没有扰动力量时它将永远保持。

一个重要而常被忽视的推论是: 亲本本身不必处于平衡。只要雌雄亲本群体中的等位基因频率相同并随机交配, 一代之后后代即处于 Hardy-Weinberg 平衡。若雌雄频率不同 (如 $p_f \neq p_m$), 后代基因型频率为 $p_f p_m$ 、 $p_f q_m + q_f p_m$ 、 $q_f q_m$, 杂合子比例高于以平均频率计算的 $2\bar{p}\bar{q}$; 再经一代随机交配, 雌雄频率相同, 平衡在第二代实现。杂交育种中两个品种杂交的 F_1 代正是这种情形: F_1 全部杂合, 远离平衡; F_1 个体间随机交配产生的 F_2 才回到平衡比例。

对多等位基因, 随机交配下纯合子 A_iA_i 的频率为 p_i^2 , 杂合子 A_iA_j 的频

率为 $2p_i p_j$ 。群体期望杂合度

$$H_e = 1 - \sum_{i=1}^k p_i^2 \tag{4.3}$$

是衡量遗传多样性最常用的指标，也称基因多样性。等位基因数相同时，频率越均匀杂合度越高；双等位位点的最大杂合度为 0.5，在 $p = 0.5$ 时达到。

4.3.2 平衡的条件

Hardy–Weinberg 比例成立需要以下条件：雌雄亲本等位基因频率相同；雌雄亲本随机交配；不存在分离偏差，杂合亲本以各二分之一的概率传递两个等位基因；在对基因型计数之前不存在选择，例如不同基因型的胚胎存活率相同；分型错误不依赖于基因型。另外，经典表述还要求群体足够大、无突变和迁移，这些条件影响的是频率在世代间的变化，而不是给定世代内基因型比例与频率之间的关系。




图 4.1 Hardy–Weinberg 比例。A 图为三种基因型频率随等位基因频率的变化，虚线与点线表示近交系数为 0.25 与 0.5 时杂合子频率的下降；B 图为 de Finetti 三角图，每一点表示一组基因型频率，平衡群体位于抛物线上，冰岛 MN 血型资料几乎落在曲线上，略偏向杂合子过剩一侧

实际群体中这些条件很少严格满足，但对影响数量性状的大多数位点，偏离通常很小，因为这些位点各自受到的选择很弱。正因为如此，数量遗传学常常假定 Hardy–Weinberg 平衡，它使模型与计算大为简化。第 9 章计算

加性方差 $2pq\alpha^2$ 时, 所用的 $2pq$ 正是平衡下的剂量方差; 第3章已经指出, 偏离平衡会改变剂量方差, 从而改变遗传方差的计算。

一个“显而易见”的定律

哈代在1908年致《科学》杂志的短信中写道, 他本不愿意介入一个自己并非专家的领域, 但这个问题“简单到数学家都会觉得无需说明”。起因是英国遗传学家庞尼特被统计学家尤尔问到: 既然短指症是显性性状, 为什么它没有在人群中逐渐增加到占四分之三? 哈代证明, 显性与频率无关, 任何频率在随机交配下都会保持不变。温伯格同年在德国独立得到同样结果, 并进一步讨论了多等位基因与双胞胎研究, 但他的工作在英语世界长期被忽视, 直到二十世纪四十年代才以“Hardy-Weinberg”的并称得到承认。这个定律在形式上极为简单, 却奠定了群体遗传学的“零模型”地位: 只有先知道没有任何进化力量时群体会怎样, 才能识别和度量各种进化力量的作用。

4.3.3 性连锁位点

对X连锁(或鸟类Z连锁)位点, 雄性只有一个拷贝。设雌性中 A_1 频率为 p_f , 雄性中为 p_m 。雄性后代的X染色体全部来自母亲, 雌性后代则各从父母获得一条, 于是

$$p'_m = p_f, \quad p'_f = \frac{1}{2}(p_f + p_m).$$

两性频率之差每代变号并减半: $p'_f - p'_m = -\frac{1}{2}(p_f - p_m)$ 。群体平均频率 $\bar{p} = \frac{2}{3}p_f + \frac{1}{3}p_m$ (雌性携带三分之二的X染色体) 保持不变, 两性频率围绕它振荡收敛。平衡时雌性基因型频率为 p^2 、 $2pq$ 、 q^2 , 雄性为 p 、 q 。X连锁隐性性状因此在雄性中的发生率为 q , 在雌性中为 q^2 , 例如色盲在男性中常见得多。

4.4 Hardy-Weinberg 平衡的检验

4.4.1 卡方拟合优度检验

检验观察基因型计数是否符合平衡比例, 可用第3章的皮尔逊卡方统计量。对冰岛MN资料, 以 $\hat{p} = 0.5696$ 计算期望计数:

表 4.2 冰岛 MN 血型的 Hardy-Weinberg 检验

基因型	观察数	期望频率	期望数	卡方贡献
MM	233	$p^2 = 0.3245$	242.4	0.362
MN	385	$2pq = 0.4903$	366.3	0.959
NN	129	$q^2 = 0.1852$	138.4	0.634
合计	747	1.0000	747	1.956

自由度为观察基因型类别数 3 减去由资料估计的参数数（总数 N 与频率 p 共 2 个），即 1。 χ^2_1 在 0.05 水平的临界值为 3.84，观察值 1.956 对应 $p = 0.16$ ，不能拒绝平衡假设。

杂合子过剩或不足可以用固定指数概括：

$$\hat{F} = 1 - \frac{H_{\text{观察}}}{H_{\text{期望}}} = 1 - \frac{385}{366.3} = -0.051.$$

$\hat{F}$ 为负表示杂合子略多于期望。对双等位点，可以证明 $X^2 = N\hat{F}^2$ ，即卡方检验等价于检验 $F = 0$ ： $747 \times 0.0512^2 = 1.96$ ，与上表一致。

4.4.2 多等位基因与微卫星

某育种群体中一个三等位基因微卫星的分型结果如表 4.3 所示。由计数得等位基因频率 $\hat{p}_1 = 0.161$ ， $\hat{p}_2 = 0.486$ ， $\hat{p}_3 = 0.353$ 。

表 4.3 三等位基因微卫星的 Hardy-Weinberg 检验

基因型	观察数	期望频率	期望数	卡方贡献
A_1A_1	14	$p_1^2 = 0.026$	4.6	19.30
A_1A_2	19	$2p_1p_2 = 0.156$	27.7	2.73
A_1A_3	10	$2p_1p_3 = 0.114$	20.1	5.10
A_2A_2	54	$p_2^2 = 0.236$	41.8	3.57
A_2A_3	45	$2p_2p_3 = 0.343$	60.7	4.08

基因型	观察数	期望频率	期望数	卡方贡献
A_3A_3	35	$p_3^2 = 0.125$	22.1	7.58
合计	177	1.000	177	42.35

自由度为 $6 - 1 - 2 = 3$ (估计总数与两个独立频率)。 $\chi_3^2 = 42.35$ 远超临界值 7.81, $p = 3 \times 10^{-9}$, 平衡被明确拒绝。三种纯合子都多于期望, 三种杂合子都少于期望; 观察杂合度 0.418, 期望杂合度 0.613, $\hat{F} = 0.318$ 。

是什么造成了如此大的偏离? 可能的原因至少有四种。其一, **无效等位基因**: 引物结合位点的突变使某个等位基因无法扩增, 携带它的杂合子被误判为纯合子, 这是微卫星中纯合子过剩最常见的技术原因。其二, **近交**: 育种群体中有亲缘的个体交配, 使后代纯合概率增加。其三, **群体分层** (瓦隆效应, 见 4.6 节): 样本混合了频率不同的亚群。其四, **选择**。区分这些原因需要额外信息: 若偏离集中于某一个等位基因的纯合子, 提示无效等位基因; 若多个独立标记同时表现杂合子不足, 提示近交或分层; 若偏离只出现在某个年龄组, 提示选择。仅凭一个位点的检验无法辨别。

4.4.3 精确检验与稀有等位基因

卡方近似要求每个类别的期望数不太小, 通常要求不低于 5。对稀有等位基因, 稀有纯合子的期望数往往远小于 1, 近似失效。双等位位点的精确检验以等位基因计数为条件, 杂合子数 h 的条件分布为式 (3.24)。设 100 个个体中观察到 1 个稀有纯合子、10 个杂合子、89 个常见纯合子, 稀有等位基因频率 0.06, 期望稀有纯合子 0.36 个。卡方检验给出 $X^2 = 1.29$ 、 $p = 0.26$; 精确检验给出 $p = 0.30$ 。本例中二者结论一致, 但在更极端的情形下, 卡方近似可能给出严重偏小的 p 值, 导致大量位点被错误剔除。全基因组分型的质量控制因此普遍采用精确检验 (第 26 章)。

Hardy-Weinberg 检验的功效通常很低。要检测 $F = 0.05$ 的偏离, 需要 $NF^2 \approx 7.85$ (80% 功效、5% 水平), 即 $N \approx 3140$ 。在常见的数百个体样本中, 只有相当大的偏离才能被发现。反过来, 在数万个体的样本中, 极小的、

生物学上无关紧要的偏离也会显著。把检验结果当作质量控制的依据时，应同时考虑效应大小与样本量。

4.5 Hardy-Weinberg 定律的应用

4.5.1 隐性有害基因的携带者频率

苯丙酮尿症（PKU）是一种常染色体隐性遗传病， A_1A_1 与 A_1A_2 正常， A_2A_2 患病。若群体发病率为万分之一，在平衡假设下 $q^2 = 10^{-4}$ ， $q = 0.01$ 。一个表型正常的人携带 A_2 的概率为

$$\Pr(A_1A_2 \mid \text{正常}) = \frac{2pq}{p^2 + 2pq} = \frac{2q(1-q)}{(1-q)(1+q)} = \frac{2q}{1+q} \approx 2q. \quad (4.4)$$

代入 $q = 0.01$ 得 0.0198，约每 50 个正常人中就有一个携带者，而患者只占万分之一，携带者是患者的约 200 倍。这一结论对理解隐性有害基因的淘汰极为重要：绝大多数有害等位基因“隐藏”在杂合子中，对隐性纯合子的选择很难把它们从群体中清除。动物育种中的遗传缺陷（如牛的复合脊椎畸形、猪的应激综合征）也遵循同样的规律；在基因检测普及之前，一头广泛使用的携带者公牛可以使缺陷等位基因在整个品种中迅速扩散。

由隐性纯合子频率估计等位基因频率 $\hat{q} = \sqrt{n_{aa}/N}$ 依赖于平衡假设，其方差由 Delta 方法为

$$\text{Var}(\hat{q}) \approx \frac{1-q^2}{4N},$$

比能直接计数等位基因时的 $pq/2N$ 大得多，尤其当 q 很小时。显性掩盖了杂合子，大量信息因而丢失，这与第 3 章 ABO 例中 EM 算法的缺失信息是同一回事。

4.5.2 由不完全分型资料估计频率

当某些基因型不能区分时，Hardy-Weinberg 比例提供了把表型类别拆分为基因型的依据。第 3 章的 ABO 血型例完整展示了这一过程：表型 A 包括 AA 与 AO ，按平衡比例 $p_A^2 : 2p_Ap_O$ 分配；EM 算法交替执行“按当前频率分配”与“按分配结果计数”，收敛于最大似然估计 $\hat{p}_A = 0.2091$ 、 $\hat{p}_B = 0.0808$ 、

$\hat{p}_O = 0.7101$ 。一个简单的初值是 $\hat{p}_O = \sqrt{1073/2128} = 0.7101$ ，它几乎就是最终估计，因为 O 型个体的计数直接提供了 p_O^2 的信息。现代基因型填充与低深度测序资料的分型（第 26 章、第 30 章）在本质上是同一类问题的高维推广：利用群体频率与单倍型结构，为不确定的基因型赋予后验概率。

4.6 偏离随机交配：近交、同型交配与群体结构

4.6.1 近交系数与基因型频率

若交配个体之间存在亲缘关系，后代从父母获得的两个等位基因可能来自同一个祖先等位基因的拷贝，称为**同祖同源**（identical by descent, IBD）。赖特与马莱科定义的**近交系数** F 是个体某位点上两个等位基因同祖同源的概率。在一个等位基因频率为 p 的群体中，个体的两个等位基因以概率 F 同祖同源（因而必然相同，纯合概率由该祖先等位基因的频率决定），以概率 $1 - F$ 独立地从群体中抽取。于是

$$\begin{aligned}\Pr(A_1A_1) &= Fp + (1 - F)p^2 = p^2 + Fpq, \\ \Pr(A_1A_2) &= (1 - F)2pq = 2pq - 2Fpq, \\ \Pr(A_2A_2) &= Fq + (1 - F)q^2 = q^2 + Fpq.\end{aligned}\tag{4.5}$$

近交不改变等位基因频率，但把杂合子按比例 F 转为纯合子，两种纯合子各增加 Fpq 。由式 (4.5)， $F = 1 - H_{\text{观察}}/2pq$ ，这正是上一节的固定指数。完全近交（ $F = 1$ ）的群体只含纯合子，频率分别为 p 与 q 。

近交的数量遗传后果，包括近交衰退和遗传方差的重新分配，将在第 19 章系统讨论；系谱中近交系数的计算方法见第 12 章。这里只指出一点：近交与随机交配并非对立的两极，任何有限群体中随机交配本身也会因祖先共享而产生近交，这一“不可避免的近交”与有效群体大小相联系（4.9 节）。

4.6.2 同型交配与异型交配

同型交配（assortative mating）指表型相似的个体倾向于相互交配，例如人类身高、智力和教育程度上的正向配偶相关。若交配依据的是某个位点本身的表型，效果与近交类似，增加纯合子比例；但与近交不同，同型交配

只影响与选择表型相关的位点，而近交影响全基因组。对受许多位点控制的数量性状，正向同型交配使不同位点上同方向的等位基因倾向于集中在一个个体中，从而在位点之间产生正关联，增加群体的遗传方差。这一效应在人类身高与教育程度的遗传分析中相当重要，它会使基于双生子或家系的遗传力估计与基于群体的估计产生差异（第 25 章）。**异型交配**则相反，在自交不亲和植物与某些性别决定系统中可以维持等位基因的多态。

4.6.3 群体分层与瓦隆效应

设一个大群体由 k 个亚群组成，各亚群内部随机交配并处于平衡，但亚群间等位基因频率不同，记为 $p_1, \dots, p_k$ ，权重为 c_i 。合并群体的平均频率 $\bar{p} = \sum c_i p_i$ ，频率的方差 $\sigma_p^2 = \sum c_i (p_i - \bar{p})^2$ 。合并群体中纯合子 A_1A_1 的频率为

$$\sum c_i p_i^2 = \bar{p}^2 + \sigma_p^2, \quad (4.6)$$

多于以平均频率计算的 $\bar{p}^2$ ；同样 A_2A_2 多出 σ_p^2 ，杂合子少 $2\sigma_p^2$ 。这就是**瓦隆效应**：即使每个亚群内部都完全随机交配，把亚群混合在一起观察也会表现出杂合子不足，其形式与近交完全相同，等效近交系数为

$$F_{ST} = \frac{\sigma_p^2}{\bar{p}(1 - \bar{p})}. \quad (4.7)$$

4.6.4 赖特的 F 统计量

赖特把群体中的近交与分层统一在一个层级框架中。设个体 (I)、亚群 (S) 与总群体 (T) 三个层次，定义三个固定指数： F_{IS} 度量亚群内个体相对于亚群随机交配期望的杂合子不足， F_{ST} 度量亚群间分化， F_{IT} 度量个体相对于总群体的杂合子不足。以杂合度表示：

$$F_{IS} = 1 - \frac{H_I}{H_S}, \quad F_{ST} = 1 - \frac{H_S}{H_T}, \quad F_{IT} = 1 - \frac{H_I}{H_T},$$

其中 H_I 为观察杂合度的平均， H_S 为各亚群期望杂合度的平均， $H_T = 2\bar{p}\bar{q}$ 。三者满足

$$(1 - F_{IT}) = (1 - F_{IS})(1 - F_{ST}). \quad (4.8)$$

F_{ST} 是度量群体间遗传分化最常用的统计量。人类大陆群体之间的 F_{ST} 约为 0.10 至 0.15；家畜品种之间通常更高，牛的不同品种间可达 0.1 至 0.3，这反映了品种形成过程中的强烈奠基效应与长期隔离。在关联研究中， F_{ST} 决定了群体分层可能造成的假关联强度（第 8 章）；在跨品种基因组预测中，它影响参考群体中的标记—QTL 关联能否迁移到目标群体（第 29 章）。

4.7 改变等位基因频率的系统力量

Hardy–Weinberg 定律描述的是“没有进化”的群体。现实群体中，等位基因频率在四种力量的作用下改变：突变、迁移、选择和遗传漂变。前三种是**系统力量**，在给定条件下其方向与大小可以预测；漂变是**随机力量**，只能预测其方差与概率分布。本节讨论系统力量，下一节讨论漂变。

4.7.1 突变

设每代 A_1 突变为 A_2 的速率为 u ，回复突变速率为 v 。一代后 A_2 的频率变化

$$\Delta q = up - vq. \quad (4.9)$$

令 $\Delta q = 0$ 得平衡频率 $\hat{q} = u/(u + v)$ 。由于突变率通常在每代每位点 10^{-8} （单核苷酸）至 10^{-5} （某些基因整体）量级，趋近平衡需要的世代数在 $1/(u + v)$ 量级，即数万至数亿代。因此在育种的时间尺度上，突变对等位基因频率的直接作用可以忽略。

然而突变对数量性状的长期作用不容忽视。每代由新突变产生的加性方差 σ_M^2 通常约为环境方差的千分之一（ $\sigma_M^2/\sigma_E^2 \approx 10^{-3}$ ），这一看似微小的输入，在长期选择中足以维持持续的选择反应（第 14 章、第 18 章）。突变还是有害等位基因的持续来源，它与选择之间的平衡决定了群体的遗传负荷（4.8.4 节）。

4.7.2 迁移

设一个群体每代有比例 m 的个体来自另一个等位基因频率为 q_m 的群体, 则

$$q_1 = (1 - m)q_0 + mq_m, \quad \Delta q = -m(q_0 - q_m). \quad (4.10)$$

两群体频率之差每代按比例 $1 - m$ 缩小, t 代后 $q_t - q_m = (1 - m)^t(q_0 - q_m)$ 。与突变不同, 迁移率可以很大, 因而迁移是改变频率最快的力量之一。

在育种实践中, 迁移以引种和杂交的形式出现。用外来品种公畜对本地母畜进行连续级进杂交, 每代外来血统比例增加一半, 相当于 $m = 0.5$ 的单向迁移: n 代后外来血统比例为 $1 - (1/2)^n$, 五代后达到 96.9%。中国许多地方猪种和黄牛在二十世纪后期经历了大量外来血统的导入, 其基因组中可以检测到外来单倍型的片段, 而片段长度分布又记录了导入发生的时间 (第 5 章)。

4.7.3 选择: 一般框架

设三种基因型的**适合度** (相对生存与繁殖能力) 为 w_{11} 、 w_{12} 、 w_{22} 。选择发生在合子形成之后、下一代配子形成之前。选择前基因型频率为 p^2 、 $2pq$ 、 q^2 , 选择后与适合度成正比, 群体平均适合度

$$\bar{w} = p^2w_{11} + 2pqw_{12} + q^2w_{22}.$$

选择后 A_2 的频率为

$$q' = \frac{pqw_{12} + q^2w_{22}}{\bar{w}},$$

于是频率变化可以写成一个十分优美的一般形式:

$$\Delta q = \frac{pq}{\bar{w}} [p(w_{12} - w_{11}) + q(w_{22} - w_{12})] = \frac{pq}{2\bar{w}} \frac{d\bar{w}}{dq}. \quad (4.11)$$

最后一个等号可通过对 $\bar{w}$ 关于 q 求导直接验证。式 (4.11) 称为赖特公式, 它说明选择推动频率沿平均适合度上升的方向变化, 变化幅度与杂合度 pq 成正比。频率接近 0 或 1 时, 即使适合度差异很大, 频率变化也很慢, 因

为群体中几乎没有可供选择的变异。这一结论在数量遗传学中有直接的对应：选择反应正比于加性方差，而加性方差正比于 $2pq$ （第9章、第14章）。

方括号中的量有一个重要的数量遗传含义。把适合度看作一个“性状”，以基因型值 w_{11} 、 w_{12} 、 w_{22} 计算 A_2 替代 A_1 的平均效应（第9章式），恰好得到 $\alpha_w = p(w_{12} - w_{11}) + q(w_{22} - w_{12})$ 。于是

$$\Delta q = \frac{pq\alpha_w}{\bar{w}}.$$

频率变化等于杂合度乘以等位基因对适合度的平均替代效应。由此可以导出费希尔的**自然选择基本定理**：平均适合度的变化率等于适合度的加性遗传方差除以平均适合度， $\Delta\bar{w} \approx \sigma_{A,w}^2/\bar{w}$ 。这一定理把群体遗传学与数量遗传学连接起来，也说明为何自然群体中适合度本身的加性方差往往较小：只要有加性方差，选择就会迅速把它消耗掉。

4.7.4 几种典型的选择方式

把适合度写成相对形式，以最适基因型为1，选择系数 s 表示适合度的相对降低，显性度 h 表示杂合子受到选择的程度。表4.4列出几种典型情形。

表4.4 不同显性方式下的选择

选择方式	w_{11}	w_{12}	w_{22}	Δq
对隐性纯合子	1	1	$1-s$	$-\frac{sq^2(1-q)}{1-sq^2}$
部分显性	1	$1-hs$	$1-s$	$-\frac{spq[q+h(p-q)]}{1-2pqhs-sq^2}$
加性 ($h=1/2$)	1	$1-s/2$	$1-s$	$-\frac{\frac{1}{2}spq}{1-sq}$
对显性等位基因	1	$1-s$	$1-s$	$-\frac{sp^2q}{1-s(1-p^2)}$
超显性	$1-s_1$	1	$1-s_2$	$\frac{pq(s_1p-s_2q)}{1-s_1p^2-s_2q^2}$

对隐性纯合子的选择最能说明“隐藏变异”的含义。 $\Delta q \approx -sq^2$ 在 q 较

小时与 q^2 成正比，频率下降极为缓慢。若隐性纯合子完全致死 ($s = 1$)， $q_{t+1} = q_t / (1 + q_t)$ ，由此

$$\frac{1}{q_t} = \frac{1}{q_0} + t, \quad t = \frac{1}{q_t} - \frac{1}{q_0}. \quad (4.12)$$

从 $q_0 = 0.5$ 降到 0.01 需要 98 代，降到 0.001 需要 998 代。即使对一种致死性遗传缺陷实行彻底淘汰，在其频率已经较低时，靠淘汰患病个体也几乎无法进一步降低其频率。现代遗传缺陷管理因此依赖于携带者检测：一旦能识别杂合子，就可以直接对杂合子施加选择，使频率迅速下降。

对显性有害等位基因的选择在开始时较慢，因为有害等位基因频率高时大多数个体都受影响而选择差异不大；随后加速；当有害等位基因变得稀少时，几乎全部存在于杂合子中并直接暴露于选择，于是很快被清除。**加性选择**介于二者之间，其轨迹呈对称的 S 形。图 4.2A 比较了这几种情形。

超显性（杂合子优势）维持稳定的平衡多态。令 $\Delta q = 0$ ，平衡频率

$$\hat{q} = \frac{s_1}{s_1 + s_2}. \quad (4.13)$$

$s_1 = 0.1$ 、 $s_2 = 0.3$ 时 $\hat{q} = 0.25$ ，无论从何处出发，频率都收敛于此（图 4.2A）。人类镰状细胞贫血等位基因在疟疾流行区的维持是超显性的经典例子。反过来，**低显性**（杂合子劣势）的内部平衡不稳定，频率会离开平衡点走向固定或丢失，取决于起点在平衡点的哪一侧。

4.7.5 突变—选择平衡与遗传负荷

有害突变不断产生，选择不断清除，二者达到平衡时有害等位基因维持在低频。对完全隐性有害等位基因，突变每代增加 u ，选择每代减少约 sq^2 ，令二者相等：

$$\hat{q} \approx \sqrt{\frac{u}{s}}. \quad (4.14)$$

若有害效应部分显性 ($h > 0$ 且不太小)，稀有等位基因主要存在于杂合子中，选择清除速率约为 hsq ，于是 $\hat{q} \approx u / (hs)$ 。以 $u = 10^{-5}$ 、 $s = 0.1$ 为例，完全隐性时 $\hat{q} = 0.01$ ， $h = 0.1$ 时 $\hat{q} = 0.001$ 。隐性有害等位基因的平衡频率




图 4.2 单基因座群体的确定性选择与随机漂变。A 图为不同显性方式下有害等位基因频率的变化 ($s = 0.1$)，以及超显性下向平衡点的收敛；B 图为 30 个大小为 20 的 Wright-Fisher 群体中等位基因频率的随机游走 (细线)，以及 4000 个重复群体平均杂合度与理论值的比较

高得多，这正是近交时隐性有害效应集中暴露、造成近交衰退的群体遗传基础 (第 19 章)。

群体由于有害等位基因的存在而导致的平均适合度下降称为**遗传负荷**。突变—选择平衡下，每个位点的负荷约为 $L \approx u$ (完全隐性) 或 $2u$ (部分显性)，与选择强度无关，这是霍尔丹—穆勒原理。全基因组上数千个位点的负荷累加起来，使每个个体都携带若干有害等位基因。

4.8 遗传漂变

4.8.1 抽样的随机性

在有限群体中，下一代的等位基因是从当前一代的配子库中随机抽取的有限样本，频率因此在世代间随机波动。这种由抽样造成的频率变化称为**遗传漂变**。最简单的模型是 **Wright-Fisher 模型**：群体有 N 个二倍体个体，世代不重叠，每代 $2N$ 个等位基因从上一代的等位基因库中以有放回方式独立抽取。若当前频率为 p ，下一代 A_1 的拷贝数服从二项分布 $B(2N, p)$ ，因此

$$E(p_{t+1} | p_t) = p_t, \quad \text{Var}(p_{t+1} | p_t) = \frac{p_t(1 - p_t)}{2N}. \quad (4.15)$$

漂变没有方向，频率的期望不变，但方差每代增加。经过足够多世代，

每个位点最终都会固定或丢失。由于期望不变，最终固定 A_1 的概率等于其初始频率 p_0 ；一个新突变的初始频率为 $1/2N$ ，因此中性新突变最终被固定的概率只有 $1/2N$ 。

4.8.2 杂合度的衰减

漂变最重要的后果是遗传多样性的丢失。设 $H_t = E[2p_t(1 - p_t)]$ 为第 t 代的期望杂合度（跨重复群体平均）。由式 (4.15)，

$$E[p_{t+1}(1-p_{t+1}) | p_t] = p_t - E(p_{t+1}^2) = p_t - p_t^2 - \frac{p_t(1-p_t)}{2N} = p_t(1-p_t)\left(1 - \frac{1}{2N}\right),$$

于是

$$H_t = H_0 \left(1 - \frac{1}{2N}\right)^t \approx H_0 e^{-t/2N}. \quad (4.16)$$

杂合度每代按比例 $1/2N$ 丢失，半衰期约为 $1.39N$ 代。图 4.2B 中 $N = 20$ 的模拟显示，4000 个重复群体的平均杂合度与式 (4.16) 几乎完全重合：第 10 代模拟值为 0.389，理论值 0.388；第 50 代分别为 0.146 与 0.141；到第 100 代，88% 的重复群体已经固定，其中固定 A_1 的比例为 43%，接近于初始频率 0.5 的期望（有限重复次数下的抽样波动所致）。

从另一个角度看，式 (4.16) 正是近交系数的增长：在大小为 N 的理想群体中，每代近交增量 $\Delta F = 1/2N$ ，

$$F_t = 1 - \left(1 - \frac{1}{2N}\right)^t, \quad H_t = H_0(1 - F_t).$$

因此漂变与近交是同一过程的两种描述：在跨重复群体的层次上，等位基因频率方差增加、群体间分化加大；在单个群体内部，个体之间的亲缘关系增加、纯合度上升。重复群体间频率方差 $\sigma_p^2 = p_0 q_0 F_t$ ，代入式 (4.7) 即得 $F_{ST} = F_t$ 。这一统一视角是第 19 章讨论有效群体大小与近交速率的基础。

4.8.3 有效群体大小

真实群体很少符合 Wright-Fisher 模型：两性数目不等、家系大小不均、群体大小随时间波动、世代重叠。为了用理想模型描述真实群体，定义**有效群体大小** N_e ：一个理想群体若与真实群体具有相同的漂变速率（频率方差

增加速率或近交增长速率), 其大小即为真实群体的有效大小。两个最常用的结果是: 两性数目为 N_m 与 N_f 时,

$$N_e = \frac{4N_mN_f}{N_m + N_f}; \quad (4.17)$$

群体大小在各世代为 $N_1, \dots, N_t$ 时, N_e 近似为各世代大小的调和平均数。家畜育种群体中公畜数目远少于母畜, 有效大小主要由公畜数决定: 10 头公畜与 1000 头母畜组成的群体, $N_e \approx 39.6$ 。调和平均数对小值敏感, 群体经历一次瓶颈后, 即使迅速恢复规模, 有效大小仍长期偏低。许多品种当前有数百万头个体, 但有效群体大小只有一百左右, 这是由于人工授精使少数公畜贡献了大部分后代。第 19 章将系统推导有效群体大小, 并讨论它在育种计划中的控制。

4.8.4 选择与漂变的共同作用

当选择与漂变同时存在时, 哪一种力量占主导取决于 $N_e s$ 的大小。木村资生用扩散近似推导出加性选择下等位基因的固定概率:

$$u(p_0) = \frac{1 - e^{-4N_e s p_0}}{1 - e^{-4N_e s}}, \quad (4.18)$$

其中杂合子与纯合子的适合度优势分别为 s 与 $2s$ 。对一个新突变 $p_0 = 1/2N$, 当 $4N_e s \gg 1$ 时 $u \approx 2s$ (若 $N_e = N$), 即一个有利新突变即使选择优势达到百分之几, 被固定的概率也只有百分之几, 绝大多数有利突变在稀有时被漂变丢失。当 $4N_e s \ll 1$ 时 $u \approx p_0$, 选择几乎不起作用, 等位基因表现为“有效中性”。

用 $N = 50$ 的 Wright-Fisher 群体模拟单个新突变的命运, 每种选择强度各模拟四万个重复群体 (表 4.5), 模拟结果与式 (4.18) 高度吻合。

表 4.5 单个新突变的固定概率 ($N = 50$)

选择系数 s	0	0.005	0.01	0.02	0.05
模拟固定比例	0.0112	0.0151	0.0234	0.0403	0.0936

选择系数 s	0	0.005	0.01	0.02	0.05
木村公式	0.0100	0.0157	0.0229	0.0399	0.0952

这一结果对育种有直接启示。小群体中，选择对效应较小的等位基因几乎无能为力，它们的命运主要由漂变决定；有利等位基因可能被丢失，有害等位基因可能被固定。罗伯逊（1960）据此推导了有限群体中选择极限的理论：长期选择所能达到的总进展取决于 $N_e i$ （有效大小与选择强度之积），而不只取决于选择强度（第 14 章、第 18 章）。

4.9 溯祖理论：向过去看的漂变

以上的讨论都是“向前看”的：给定当前频率，预测未来。溯祖理论（coalescent）由金曼于 1982 年系统提出，采取“向后看”的视角：从当前群体中抽取若干个等位基因，追溯它们的祖先谱系，直到所有谱系汇合于最近共同祖先（MRCA）。

在 Wright-Fisher 群体中，两个等位基因在上一代来自同一个亲本等位基因的概率为 $1/2N_e$ 。因此两个谱系向过去追溯时，等待汇合的代数服从均值为 $2N_e$ 的几何分布。若同时追溯 n 个谱系，任意两个谱系汇合的速率为 $\binom{n}{2}/2N_e$ ，于是从 n 个谱系减为 $n-1$ 个的期望时间为 $4N_e/[n(n-1)]$ 。整个样本的 MRCA 的期望时间为

$$E(T_{\text{MRCA}}) = 4N_e \left(1 - \frac{1}{n}\right),$$

即使样本很大，也不超过 $4N_e$ 代，且其中约一半时间花在最后两个谱系的汇合上。

溯祖理论把遗传多样性与群体历史联系起来。若每代每位点的突变率为 μ ，两条序列之间的期望差异位点数为

$$\pi = 2\mu \cdot 2N_e = 4N_e \mu \equiv \theta. \tag{4.19}$$

测定核苷酸多样性 π 并已知突变率，就可以估计有效群体大小。家牛的核苷酸多样性约为千分之一至千分之二，以每代每位点约 10^{-8} 的突变率计，

对应的长期有效群体大小为数万；这远大于现代品种基于系谱或连锁不平衡估计的近期有效大小（约一百），说明牛在驯化与品种形成过程中经历了大幅度的有效群体收缩。第5章将说明，不同距离标记之间的连锁不平衡记录了不同时期的有效群体大小，从而可以重建群体历史。

4.10 平衡理论：多种力量之间的稳态

单一力量的分析告诉我们频率变化的方向；而真实群体中，长期观察到的频率分布往往是两种相反力量达成平衡的结果。下面三种平衡在育种与保种中尤其重要。

4.10.1 突变—漂变平衡

漂变使杂合度每代按比例 $1/2N_e$ 丢失，突变则不断产生新的等位基因。在无限等位基因模型中，每个新突变都产生一个群体中前所未有的等位基因。两个随机抽取的等位基因不同（即杂合）的概率在下一代满足

$$1 - H' = \left[\frac{1}{2N_e} + \left(1 - \frac{1}{2N_e}\right)(1 - H) \right] (1 - u)^2.$$

方括号表示两个等位基因来自同一亲本拷贝，或者来自不同拷贝但原本就相同； $(1 - u)^2$ 表示两者都没有发生突变。令 $H' = H$ ，忽略高阶小量，得到平衡杂合度

$$\hat{H} = \frac{4N_e u}{1 + 4N_e u} = \frac{\theta}{1 + \theta}. \quad (4.20)$$

当 $\theta = 4N_e u \ll 1$ 时，群体几乎单态；当 $\theta \gg 1$ 时，杂合度接近 1。微卫星的突变率高达 10^{-4} 至 10^{-3} ，即使有效群体大小只有数百， θ 也可以大于 1，因此微卫星通常高度多态，非常适合亲子鉴定和连锁作图；SNP 的突变率约 10^{-8} ，在多数物种中 θ 远小于 1，单个 SNP 位点很少有两个以上的等位基因，几乎都是双等位标记。

4.10.2 迁移—漂变平衡

赖特的岛屿模型假设一个大群体分为许多大小为 N 的亚群，每代每个亚群有比例 m 的个体从一个公共迁移库中随机迁入。漂变使亚群分化，迁

移使亚群趋同。与上一小节完全类似的推导给出平衡时

$$F_{ST} \approx \frac{1}{1 + 4Nm}. \quad (4.21)$$

这里决定分化程度的是 Nm ，即每代迁入的个体数，而不是迁移率本身。一个令人惊讶的推论是：每代只要有一个迁入个体 ($Nm = 1$)， F_{ST} 就降到 0.2；每代数个迁入个体就足以阻止亚群之间发生显著分化，无论亚群大小如何。这一“每代一个迁移者”的经验法则在保种群体管理中有直接意义：若一个品种被划分为若干相对隔离的保种场，各场之间每代适当交换少量种畜，就能在保持整体多样性的同时防止各场独立漂变至固定。反过来，若目的是维持各地方类群的独特性，就必须严格限制交流。

4.10.3 选择—迁移平衡与地方适应

若某等位基因在一个环境中受到有利选择，而邻近群体不断迁入不利等位基因，二者可以在 $s \approx m$ 的量级上达成平衡。当选择强于迁移，地方适应得以维持；当迁移强于选择，地方适应等位基因被稀释。高原家畜的低氧适应、热带牛的耐热适应等都是选择—迁移平衡的实例。在用高产外来品种改良地方品种时，大量导入外来血统可能稀释地方适应性等位基因，这正是第 32 章讨论的基因—环境互动与适应性育种的群体遗传背景。

4.11 漂变的扩散近似

Wright–Fisher 模型是离散的马尔可夫链，当群体较大时可以用连续的扩散过程近似。设 $x = p$ ，单代频率变化的均值为 $M(x)$ 、方差为 $V(x)$ ；对中性漂变 $M = 0$ 、 $V = x(1 - x)/2N_e$ ；对加性选择 $M \approx sx(1 - x)$ 。扩散近似把频率分布 $\phi(x, t)$ 的演变写为柯尔莫哥洛夫前向方程

$$\frac{\partial \phi}{\partial t} = -\frac{\partial}{\partial x}[M(x)\phi] + \frac{1}{2}\frac{\partial^2}{\partial x^2}[V(x)\phi].$$

许多重要的量都可以由对应的后向方程直接求得，而无需求解整个分布。例如，固定概率 $u(p)$ 满足常微分方程

$$M(p)u'(p) + \frac{1}{2}V(p)u''(p) = 0, \quad u(0) = 0, u(1) = 1,$$

其解即为式 (4.18)。类似地, 中性等位基因从频率 p 出发、以固定为条件的平均固定时间约为

$$\bar{t}_1(p) \approx -4N_e \frac{(1-p) \ln(1-p)}{p}.$$

当 $p \rightarrow 0$ 时, $\bar{t}_1 \rightarrow 4N_e$: 一个最终被固定的中性新突变, 平均需要约 $4N_e$ 代才能完成固定。对 $N_e = 100$ 的家畜品种约为 400 代, 远超育种的时间尺度; 而一个受强选择的有利等位基因, 固定时间约为 $(2/s) \ln(2N_e)$ 代, $s = 0.1$ 、 $N_e = 100$ 时约 106 代。可见, 在育种时间尺度上, 频率的显著变化主要来自选择, 而非中性漂变; 但漂变决定了哪些小效应等位基因会被随机丢失, 以及近交如何累积。

4.12 由分子资料估计群体遗传参数

分子标记使群体遗传参数的直接估计成为可能。下面三类估计在育种与保种中最为常用。

由时间间隔样本估计有效群体大小。在同一群体中相隔 t 代取两个样本, 测定许多中性标记的频率。由式 (4.15), 频率方差每代增加约 $pq/2N_e$, 因此标准化的频率变化

$$\hat{F}_c = \frac{1}{K} \sum_{k=1}^K \frac{(p_{0k} - p_{tk})^2}{\bar{p}_k(1 - \bar{p}_k)}$$

在扣除两次抽样误差后, 期望值约为 $t/(2N_e)$, 于是 $\hat{N}_e = t/[2(\hat{F}_c - 1/2S_0 - 1/2S_t)]$, S_0 、 S_t 为样本个体数。这一“时间法”对抽样误差敏感, 需要较多标记或较长的间隔。

由连锁不平衡估计有效群体大小。有限群体中, 即使没有选择, 漂变也会在连锁位点之间产生随机的关联。第 5 章将推导, 距离为 c 的两个位点间 r^2 的期望约为 $1/(1 + 4N_e c)$ 。由不同距离标记对的 r^2 可以估计不同历史时期的 N_e : 紧密连锁的位点对反映较久远的群体大小, 松散连锁的位点对反映近期的群体大小。这一方法已广泛用于估计家畜品种的有效群体大小。

由纯合片段估计近交。个体基因组中长的连续纯合片段 (runs of homozygosity, ROH) 往往来自近期共同祖先的两份拷贝。片段总长度占基因

组的比例 F_{ROH} 是对个体近交系数的直接基因组估计；片段长度则指示共同祖先的远近，因为重组每代把祖先片段打断，来自 g 代前共同祖先的片段平均长度约为 $100/(2g)$ 厘摩。第 19 章将详细讨论 F_{ROH} 与系谱近交系数的关系。

群体遗传参数在育种中的用途

等位基因频率决定加性方差与平均效应，是基因组关系矩阵中心化的依据（第 26 章）；Hardy-Weinberg 偏离是分型质量控制与群体结构的诊断工具； F_{ST} 衡量品种间分化，影响跨品种预测与群体分层校正；有效群体大小与近交速率决定长期选择的潜力与遗传多样性的损失速度（第 18—19 章）；突变—选择平衡与隐性有害等位基因的频率决定近交衰退的大小与遗传缺陷管理的策略（第 19 章）。理解单位点的群体遗传学，是理解这些多位点与数量性状结论的前提。

4.13 多等位基因标记的信息量

在利用分子标记进行亲子鉴定、连锁作图和群体分析时，一个标记能提供多少信息，取决于其等位基因数与频率分布。除了期望杂合度 H_e 之外，还有两个常用指标。

有效等位基因数 $n_e = 1 / \sum p_i^2 = 1 / (1 - H_e)$ ，表示具有相同杂合度的、频率均等的等位基因数目。三等位微卫星例中， $H_e = 0.613$ ， $n_e = 2.58$ ，比实际等位基因数 3 略少，因为频率不均匀。

多态信息含量 (PIC) 由博特斯坦等 (1980) 提出，是在连锁分析中一个亲本为杂合子、且其后代能够明确判断从该亲本获得哪一个等位基因的概率：

$$PIC = 1 - \sum_i p_i^2 - \sum_{i < j} 2p_i^2 p_j^2.$$

第二个求和项扣除的是双亲为相同杂合子、后代也为该杂合子时无法判断等位基因来源的情形。双等位标记的 PIC 最大为 0.375 ($p = 0.5$)，而多等位微卫星的 PIC 可以超过 0.8。这就是为什么在 SNP 芯片出现之前，连锁图

谱主要依靠微卫星构建；而高密度 SNP 以数量弥补了单个标记信息量的不足（第6章）。

排除概率是亲子鉴定中一个标记能够排除错误亲本的概率，它同样随等位基因数增加而增大。一组独立标记的总排除概率为 $1 - \prod_k (1 - E_k)$ ，由十余个高度多态的微卫星或一百余个 SNP 就可以使排除概率超过 0.9999。第26章将讨论基于 SNP 的亲子核查在基因组评定质量控制中的作用。

4.14 多种力量的共同作用与数量性状位点

真实群体中，各种力量同时起作用，它们的相对重要性取决于各自的强度。下面的比较给出一个粗略的尺度：突变率约 10^{-8} 至 10^{-5} ；迁移率可达 10^{-2} 至 10^{-1} ；漂变的强度约 $1/2N_e$ ，对 $N_e = 100$ 的品种约为 5×10^{-3} ；对数量性状位点的选择，单个位点所受的选择系数通常很小。当某种力量的强度远大于其他力量，频率动态主要由它决定；当两种力量量级相当，它们之间的平衡决定频率的分布。

对数量遗传学而言，这一图景有三个重要推论。第一，**影响数量性状的位点大多接近 Hardy-Weinberg 平衡**，因为单个位点所受的选择很弱。这使加性方差的计算可以采用平衡下的 $2pq$ 。第二，**等位基因频率分布决定遗传结构**。在突变—选择—漂变的平衡中，有较大效应的位点往往受较强选择而处于低频，较常见的变异多为小效应。第8章与第25章将看到，这一预期与全基因组关联研究的发现相符：常见变异效应很小，大效应变异往往稀有。第三，**选择改变频率，从而改变方差**。人工选择首先作用于等位基因频率，加性方差随 $2pq$ 改变；当中间频率的有利等位基因被推向固定，加性方差下降，选择反应逐渐减慢。这为第14章的长期选择理论提供了位点层次的解释。

4.15 本章小结

本章建立了单基因座群体遗传的基本框架。等位基因频率是群体的属性，由计数直接估计，其最大似然性质与抽样误差依赖于等位基因的独立性。

Hardy-Weinberg 定律指出, 在大的随机交配群体中, 基因型频率由等位基因频率按二项式决定, 且一代随机交配即可达到平衡; 它是识别各种进化力量的“零模型”。平衡偏离可以用卡方检验或精确检验检测, 其原因包括近交、群体分层、选择与分型错误, 单个位点的检验无法区分。近交按比例 F 把杂合子转为纯合子; 群体分层通过瓦隆效应产生同样的模式, 并由赖特的 F 统计量统一描述。突变、迁移与选择以可预测的方式改变频率, 选择推动频率沿平均适合度上升的方向变化, 其速率与杂合度成正比; 隐性有害等位基因在低频时几乎不受选择, 杂合子优势维持稳定多态。遗传漂变使杂合度每代按 $1/2N_e$ 的比例丢失, 与近交是同一过程的两种描述; 选择与漂变的相对强度由 $N_e s$ 决定。溯祖理论从向后看的角度把多样性与有效群体大小联系起来。这些结论构成后续多位点、数量性状和长期选择理论的基础。

4.16 习题

习题 4.1 某猪群中一个 SNP 的基因型计数为 AA 360、AG 480、GG 160。估计等位基因频率及其标准误, 检验 Hardy-Weinberg 平衡, 并计算 $\hat{F}$ 。

习题 4.2 证明: 对双等位位点, Hardy-Weinberg 检验的皮尔逊卡方统计量等于 $N\hat{F}^2$ 。

习题 4.3 某隐性遗传缺陷在新生犊牛中的发生率为 $1/2500$ 。估计该缺陷等位基因的频率、表型正常个体中携带者的比例。若从现在起淘汰全部患病犊牛, 需要多少代才能使缺陷等位基因频率减半?

习题 4.4 某品种由两个亚群等量混合而成, 某位点在两亚群中的频率分别为 0.2 与 0.6, 亚群内部随机交配。求合并群体的基因型频率、观察杂合度、期望杂合度与 F_{ST} 。

习题 4.5 一个本地母牛群体某位点等位基因频率 $q = 0.1$ 。用该位点频率为 0.8 的外来品种公牛连续级进杂交三代, 求第三代后代的频率。

习题 4.6 某位点存在超显性, $w_{11} = 0.9$, $w_{12} = 1$, $w_{22} = 0.6$ 。求平衡频率及平衡时的平均适合度; 若 $q = 0.1$, 计算一代后的频率变化。

习题 4.7 一个保种群体有 4 头公猪和 20 头母猪。计算有效群体大小、每代近交增量与 20 代后预期保留的杂合度比例。

习题 4.8 某物种的核苷酸多样性 $\pi = 0.0012$ ，突变率为每代每位点 1.2×10^{-8} ，估计长期有效群体大小。若一个有利突变的选择优势 $s = 0.01$ ，按木村公式估计其固定概率，并与中性突变比较。

4.17 习题解答

4.1 $N = 1000$, $\hat{p}_A = (720 + 480)/2000 = 0.6$, $SE = \sqrt{0.6 \times 0.4/2000} = 0.011$ 。期望计数为 360、480、160，与观察值完全一致， $X^2 = 0$, $\hat{F} = 0$ 。

4.2 在平衡偏离可用 F 描述时，观察计数与期望计数之差为：AA 与 aa 各为 $+NFpq$ ，杂合子为 $-2NFpq$ 。于是

$$X^2 = \frac{(NFpq)^2}{Np^2} + \frac{(2NFpq)^2}{2Npq} + \frac{(NFpq)^2}{Nq^2} = NF^2(q^2 + 2pq + p^2) = NF^2.$$

4.3 $\hat{q} = \sqrt{1/2500} = 0.02$ ，携带者比例 $2q/(1+q) = 0.0392$ 。频率减半到 0.01，由式 (4.12)， $t = 1/0.01 - 1/0.02 = 50$ 代。

4.4 $\bar{p} = 0.4$, $\sigma_p^2 = 0.04$ 。合并群体 AA 频率 $(0.04 + 0.36)/2 = 0.20 = \bar{p}^2 + \sigma_p^2 = 0.16 + 0.04$ ；杂合子 $(0.32 + 0.48)/2 = 0.40$ ；aa 0.40。期望杂合度 $2 \times 0.4 \times 0.6 = 0.48$, $F_{ST} = 0.04/0.24 = 0.167$ 。

4.5 每代 $q_{t+1} = \frac{1}{2}q_t + \frac{1}{2} \times 0.8$: 0.45、0.625、0.7125。

4.6 $s_1 = 0.1$, $s_2 = 0.4$, $\hat{q} = 0.1/0.5 = 0.2$, $\bar{w} = 1 - s_1\hat{p}^2 - s_2\hat{q}^2 = 1 - 0.064 - 0.016 = 0.92$ 。当 $q = 0.1$ 时 $\Delta q = pq(s_1p - s_2q)/\bar{w} = 0.09 \times (0.09 - 0.04)/(1 - 0.081 - 0.004) = 0.0049$ 。

4.7 $N_e = 4 \times 4 \times 20/24 = 13.3$, $\Delta F = 1/26.7 = 0.0375$, 20 代后 $H_{20}/H_0 = (1 - 0.0375)^{20} = 0.47$ 。

4.8 $N_e = \pi/(4\mu) = 0.0012/(4.8 \times 10^{-8}) = 25000$ 。新突变的初始频率 $p_0 = 1/(2N)$ ，取 $N = N_e$ ，则 $4N_e sp_0 = 2s = 0.02$ ，而 $4N_e s = 1000$ ，分母近似为 1，于是 $u \approx 1 - e^{-0.02} = 0.0198 \approx 2s$ 。中性突变的固定概率为 $1/(2N) = 2 \times 10^{-5}$ ，有利突变的固定概率约为其一千倍，但绝对值仍不到百

分之二。

多基因座单倍型、连锁不平衡与重组

5

5.1 从等位基因频率到单倍型频率

第4章讨论了单个位点上的等位基因与基因型。但染色体并不是彼此独立的等位基因的集合，而是沿着DNA分子排列的一串位点。一条染色体（或其一段）上各位点等位基因的组合称为**单倍型**。两个位点各有两个等位基因时，共有四种单倍型： A_1B_1 、 A_1B_2 、 A_2B_1 、 A_2B_2 ，其频率分别记为 r 、 s 、 t 、 u ，满足 $r + s + t + u = 1$ 。等位基因频率是单倍型频率的边际和：

$$p_{A_1} = r + s, \quad p_{B_1} = r + t.$$

单倍型频率与等位基因频率之间的关系取决于两个位点的等位基因是否相互独立。若独立，则联合概率等于边际概率之积， $r = p_{A_1}p_{B_1}$ ，依此类推。这种状态称为**连锁平衡**。若不独立，单倍型频率就偏离边际乘积，称为**连锁不平衡**（linkage disequilibrium, LD）。

“连锁不平衡”这个名称其实有些误导。不平衡可以发生在不连锁的位点之间（例如群体混合产生的关联），而连锁位点之间也可以处于平衡。更准确的名称是**配子相不平衡**（gametic phase disequilibrium）：“配子相”指染色体的单倍体状态，“不平衡”指当前一代单倍型中各位点等位基因之间的依赖关系，而这些单倍型来源于其亲本产生的单倍体配子。不过由于连锁位点之间的不平衡更常见、也更持久，“连锁不平衡”一名已经约定俗成。

第3章表3.1中两个位点的基因型并不独立，就是连锁不平衡在基因型层次的表现。本章系统讨论连锁不平衡的度量、估计、产生与衰减。理解这些内容是第7章QTL定位、第8章关联分析与第26—27章基因组预测的共

同前提：所有这些方法都依赖于这样一个事实——可观察的标记与不可观察的致因变异之间存在关联，而关联的强度与稳定性由连锁不平衡决定。

5.2 连锁不平衡的度量

5.2.1 不平衡系数 D

最基本的度量是不平衡系数

$$D = r - p_{A_1}p_{B_1}. \quad (5.1)$$

由四种单倍型频率可以证明一个等价且对称的表达式

$$D = ru - st. \quad (5.2)$$

证明只需把 $p_{A_1}p_{B_1} = (r+s)(r+t) = r^2 + rt + rs + st = r(r+s+t) + st = r(1-u) + st$ 代入式 (5.1)。式 (5.2) 显示， D 是“同相”单倍型 (A_1B_1 与 A_2B_2) 频率乘积与“异相”单倍型 (A_1B_2 与 A_2B_1) 频率乘积之差。在连锁平衡下 $ru = st$, $D = 0$ 。

有了 D ，四种单倍型频率都可以由等位基因频率与 D 表示：

$$r = p_1p_2 + D, \quad s = p_1q_2 - D, \quad t = q_1p_2 - D, \quad u = q_1q_2 + D, \quad (5.3)$$

其中 p_1 、 p_2 分别为 A_1 、 B_1 的频率， $q_i = 1 - p_i$ 。

设两个位点的等位基因频率均为 0.5， A_1B_1 单倍型频率为 0.4。若连锁平衡， A_1B_1 的频率应为 0.25；实际为 0.4， $D = 0.4 - 0.25 = 0.15$ 。由式 (5.3)，其余三种单倍型频率为 0.1、0.1、0.4。

5.2.2 标准化的 D'

D 的取值范围依赖于等位基因频率，不便于比较。由于各单倍型频率非负，式 (5.3) 要求

$$D \leq D_{\max} = \begin{cases} \min(p_1q_2, q_1p_2), & D > 0, \\ \min(p_1p_2, q_1q_2), & D < 0. \end{cases}$$

勒沃汀 (1964) 定义标准化的不平衡系数

$$D' = \frac{D}{D_{\max}}, \quad (5.4)$$

取值在 -1 与 1 之间。上例中 $D_{\max} = \min(0.25, 0.25) = 0.25$, $D' = 0.6$, 即 D 达到当前等位基因频率下最大可能值的 60%。 $|D'| = 1$ 意味着四种单倍型中至少有一种不存在, 称为“完全不平衡”; 这常常发生在两个位点之间自突变产生以来没有发生过重组 (或重组后的单倍型已丢失) 的情形, 因此 D' 被广泛用于识别单倍型块与推断重组历史。但 D' 在小样本或稀有等位基因时有严重的向上偏差: 只要某种稀有单倍型恰好未被抽到, $|D'|$ 就等于 1。

5.2.3 相关系数平方 r^2

另一种标准化是把两个位点的等位基因指示变量看作随机变量, 计算它们的相关系数。设 $X = 1$ 表示单倍型携带 A_1 , $Y = 1$ 表示携带 B_1 , 则 $\text{Cov}(X, Y) = \text{Pr}(A_1 B_1) - p_1 p_2 = D$, $\text{Var}(X) = p_1 q_1$, 于是

$$r_{LD}^2 = \frac{D^2}{p_1 q_1 p_2 q_2}. \quad (5.5)$$

上例中 $r^2 = 0.15^2 / 0.0625 = 0.36$ 。为避免与单倍型频率 r 混淆, 本书在不引起歧义时用 r^2 表示 LD 的相关系数平方。

r^2 在关联研究与基因组预测中的意义最为直接。设 A 是可观察的标记, B 是影响性状的致因位点, 二者处于连锁不平衡。用个体在标记上的基因型预测其在致因位点上的基因型, r^2 恰好是标记所能预测的致因位点变异的比例, 即回归中的 R^2 。这一事实有两个重要推论。第一, 若致因位点解释的表型方差为 q_{QTL}^2 , 则标记“捕获”的方差仅为 $r^2 q_{\text{QTL}}^2$; 由第 3 章式 (3.19), 检验标记的非中心参数相应缩小为 $N r^2 q_{\text{QTL}}^2$ 。要以标记达到直接检验致因位点的同样功效, 样本量须增大为 $1/r^2$ 倍。第二, r^2 同时受等位基因频率的约束: 即使 $|D'| = 1$, 若两个位点的等位基因频率相差很大, r^2 仍可能很小。例如稀有致因变异 (频率 0.01) 与常见标记 (频率 0.3) 之间, r^2 最大只有约 0.024。这正是常见 SNP 芯片难以捕获稀有变异效应的原因, 也是第 25 章讨论“缺失遗传力”的一条重要线索。

三种度量的用途

D 是最基本的量，进入单倍型频率与遗传方差的表达式； D' 反映重组历史，适合描述单倍型块与识别历史重组； r^2 衡量一个位点对另一个位点的预测能力，决定关联研究的功效与基因组预测中标记捕获的遗传方差，是育种应用中最常用的指标。对多等位位点（如微卫星），也有相应推广，但解释需更加谨慎。

5.3 有序基因型、无序基因型与相位

5.3.1 两位点基因型的频率

一个二倍体个体携带两条单倍型，一条来自父本、一条来自母本。若知道每个等位基因位于哪一条染色体上，称为**有序基因型**或已知相位的基因型，例如 A_1B_1/A_2B_2 ；若只知道两个位点各自的基因型而不知等位基因如何组合在染色体上，称为**无序基因型**，例如 $A_1A_2B_1B_2$ 。

在亲本随机交配的条件下，个体的父源与母源单倍型相互独立，有序基因型的频率等于两条单倍型频率之积。例如 A_1B_1/A_1B_1 的频率为 r^2 ， A_1B_1/A_2B_2 （同相双杂合，或称相引相）为 $2ru$ ， A_1B_2/A_2B_1 （异相双杂合，或称相斥相）为 $2st$ 。九种无序基因型中，只有双杂合子 $A_1A_2B_1B_2$ 对应两种有序基因型；其余八种基因型由于至多一个位点杂合，其两条单倍型可以唯一确定。

5.3.2 双杂合子的相位概率

对一个无序基因型为 $A_1A_2B_1B_2$ 的个体，它是相引相的条件概率为

$$\Pr(A_1B_1/A_2B_2 \mid A_1A_2B_1B_2) = \frac{2ru}{2ru + 2st} = \frac{ru}{ru + st}. \quad (5.6)$$

若 $D = 0$ ，则 $ru = st$ ，两种相位各占一半； $D > 0$ 时相引相占多数。式 (5.6) 正是单倍型频率 EM 算法中 E 步的核心。

相位信息对许多分析都至关重要。在一个家系中，若知道公畜在两个位点上的相位，就能判断其每个后代获得的是亲本型还是重组型配子，这是连

锁分析的基础(第6章);在群体水平上,相位决定单倍型频率的估计,也决定基于单倍型的关联分析与基因型填充(第26章)。相位可以由三种信息推断:一是家系信息,即利用亲本基因型直接确定后代各等位基因的来源;二是群体信息,即利用群体单倍型频率按式(5.6)给出概率;三是分子信息,例如长读长测序直接读出同一DNA分子上的等位基因组合。现代相位推断软件综合利用前两种信息,并通过隐马尔可夫模型把短片段单倍型拼接起来。

5.4 由无序基因型估计单倍型频率

5.4.1 简单方法

考察200个个体两个位点的无序基因型(表5.1)。其中只有双杂合子的相位未知。

表5.1 两位点无序基因型计数 ($N = 200$)

基因型	B_1B_1	B_1B_2	B_2B_2
A_1A_1	35	19	0
A_1A_2	10	72	16
A_2A_2	0	20	28

对于非双杂合子,单倍型可以直接计数。例如 $A_1A_1B_1B_1$ 贡献两个 A_1B_1 , $A_1A_1B_1B_2$ 贡献一个 A_1B_1 与一个 A_1B_2 。72个双杂合子则需要分配。最简单的做法是假定两种相位各占一半,于是每个双杂合子向四种单倍型各贡献0.5个。这样得到

$$\hat{r} = 0.3375, \quad \hat{s} = 0.1775, \quad \hat{t} = 0.165, \quad \hat{u} = 0.32,$$

$$\hat{D} = 0.3375 \times 0.32 - 0.1775 \times 0.165 = 0.0787, \quad D' = 0.32, \quad r^2 = 0.099.$$

但“各占一半”的假定恰恰等于假定双杂合子中没有连锁不平衡,与估计的目的自相矛盾。从计数结果已经可以看到 $\hat{D} > 0$, 相引相应占多数。

5.4.2 EM 算法

改进的方法是第 3 章介绍的 EM 算法。E 步按式 (5.6) 用当前单倍型频率计算双杂合子为相引相的概率 $w = ru/(ru + st)$ ，把 $72w$ 个双杂合子分配给 A_1B_1 与 A_2B_2 各一个， $72(1 - w)$ 个分配给 A_1B_2 与 A_2B_1 各一个；M 步把这些期望计数与非双杂合子的确定计数相加，除以 $2N = 400$ 得到新的单倍型频率。从均等初值出发，第一次迭代正好得到上面的“简单方法”结果；继续迭代，相引相的比例逐步增加：

表 5.2 单倍型频率的 EM 迭代

迭代	A_1B_1	A_1B_2	A_2B_1	A_2B_2
1	0.3375	0.1775	0.1650	0.3200
2	0.3891	0.1259	0.1134	0.3716
3	0.4113	0.1037	0.0912	0.3938
4	0.4176	0.0974	0.0849	0.4001
收敛	0.4194	0.0956	0.0831	0.4019

约二十次迭代后收敛。最终 $\hat{D} = 0.1606$ ， $\hat{D}' = 0.659$ ， $\hat{r}^2 = 0.413$ ；一个双杂合子为相引相的后验概率为 0.955。与简单方法相比，EM 估计的不平衡程度高了一倍。可见，忽略相位不确定性中的信息，会严重低估连锁不平衡。

5.4.3 由基因型相关估计 r^2

在大规模资料中，常用一个更简便的方法：直接计算两个位点基因型剂量 (0、1、2) 之间的相关系数平方，称为基因型 r^2 或复合 LD。在 Hardy-Weinberg 平衡且亲本随机交配时，可以证明基因型剂量的协方差等于 $2D$ ，方差分别等于 $2p_1q_1$ 与 $2p_2q_2$ ，因此基因型相关与单倍型相关在期望上相等。表 5.1 资料的基因型 $r^2 = 0.438$ ，与 EM 估计的 0.413 接近。基因型 r^2 无需相位推断，计算极为迅速，被广泛用于全基因组的 LD 修剪与 LD 分数计算 (第 8 章、第 25 章)。但在小样本、偏离平衡或近交的群体中，它会把位点内

与位点间的非随机结合混在一起，解释时需谨慎。

单倍型与相位推断已经发展出许多专门方法。斯蒂芬斯等的 PHASE 使用贝叶斯溯祖先验，能同时估计重组率；fastPHASE 与 Beagle 用隐马尔可夫模型把个体单倍型表示为若干“祖先单倍型簇”的镶嵌，可以处理数十万标记和数千个体，并同时完成缺失基因型的填充。家畜中，由于有大量半同胞与亲子关系，基于家系的长片段相位推断（如利用公畜的大量后代）往往比纯群体方法更准确。

5.5 重组与连锁不平衡的衰减

5.5.1 一代随机交配后的 D

设两个位点之间的重组率为 c ，即一个双杂合子产生重组型配子的概率。考察下一代中 A_1B_1 单倍型的频率。一个配子中的 A_1B_1 单倍型可以有两种来源：以概率 $1-c$ ，配子是亲本某一条染色体的未重组拷贝，此时它是 A_1B_1 的概率等于当前单倍型频率 r ；以概率 c ，配子是重组产物，其 A 位点等位基因来自亲本的一条染色体、 B 位点等位基因来自另一条染色体，在随机交配下两条染色体相互独立，于是携带 A_1B_1 的概率为 p_1p_2 。因此

$$r' = (1-c)r + cp_1p_2.$$

两边减去 p_1p_2 （等位基因频率不随重组改变）得到

$$D'_{t+1} = (1-c)D_t, \quad D_t = (1-c)^t D_0. \quad (5.7)$$

连锁不平衡按几何速率衰减，每代减少比例 c 。对不连锁的位点 ($c = 0.5$)， D 每代减半，五代后只剩约 3%；对 $c = 0.01$ （约 1 厘摩）的紧密连锁位点， D 的半衰期约为 69 代；对 $c = 0.001$ ，半衰期约为 690 代（图 5.1A）。这就是连锁不平衡能够用于基因定位的根本原因：一段连锁不平衡在多少代内被重组打散，取决于位点之间的距离；因此一个群体中仍然存在的 LD，在很大程度上反映了位点之间的物理邻近关系。

需要强调，式 (5.7) 说明的是：随机交配本身并不能在一代内消除连锁不平衡。这与第 4 章 Hardy-Weinberg 平衡的情形截然不同——单位点的基

因型比例一代随机交配即可达到平衡，而两位点之间的单倍型平衡则需要许多代，且速率取决于重组率。混淆这两种平衡，是初学者常见的错误。

5.5.2 有限群体中的“平衡”并非零

式 (5.7) 预测在没有其他力量时 D 最终衰减为零。但在有限群体中，漂变会不断产生新的随机 LD，因此观察到的 LD 是“产生”与“衰减”之间平衡的结果。即使对不连锁位点，有限样本中的 r^2 期望也不为零：样本中两个独立位点的 r^2 期望约为 $1/n$ (n 为样本单倍型数)，群体本身的漂变还会贡献约 $1/(1 + 2N_e)$ 量级的 LD。在小的育种群体中，不连锁位点间的背景 LD 可能达到不可忽略的程度，这是群体分层与亲缘结构在 LD 中的反映。

5.6 产生连锁不平衡的机制

连锁不平衡是多种进化过程留下的痕迹。理解它从何而来，才能判断它是否能被用于定位或预测。

5.6.1 突变

每一个新突变都产生于某一条特定的染色体上，与该染色体在邻近位点上的等位基因“绑定”在一起。在突变刚出现时，新等位基因只存在于一种单倍型背景中，与周围所有多态位点都处于完全不平衡 ($|D'| = 1$)。此后，重组逐代把它与远处的位点“解绑”，而近处位点的关联可以保持很久。因此新突变周围的 LD 区域长度可以指示突变的“年龄”：年轻的突变周围有长的、保守的单倍型，古老的突变周围只剩很短的关联片段。

5.6.2 遗传漂变

有限群体中，单倍型频率因随机抽样而波动，即使初始时处于连锁平衡，漂变也会随机产生非零的 D 。漂变产生 LD 的速率与 $1/N_e$ 成正比，在小群体中尤其重要。这是大多数家畜与作物群体中 LD 的主要来源，下一节将定量讨论。

5.6.3 选择

选择可以通过多种途径产生 LD。其一，**选择性清除**（搭便车效应）：当一个有利突变受到强选择而迅速升高频率时，与它连锁的中性等位基因也被一同带到高频，在其周围形成一段低多样性、高 LD 的区域。家畜驯化与品种形成过程中的许多选择信号就是这样识别的。其二，**上位选择**：若两个位点的特定等位基因组合具有较高适合度，选择会偏好这些组合，在两位点之间产生 LD。其三，**对数量性状的选择**：在多基因性状上进行截断选择时，被选中的个体倾向于在许多位点上同时携带增效等位基因，这在增效等位基因之间产生负的 LD（因为在给定总值下，一个位点上携带增效等位基因，就降低了其他位点也携带增效等位基因的必要性）。这种由选择产生的负协方差会减少加性遗传方差，称为 **Bulmer 效应**，是第 14 章与第 18 章的重要内容。

5.6.4 迁移与群体混合

两个频率不同的群体混合时，即使各自内部都处于连锁平衡，混合群体中也会出现 LD。设两个群体以比例 c_1 与 c_2 混合， A_1 的频率分别为 $p_{A,1}$ 、 $p_{A,2}$ ， B_1 的频率分别为 $p_{B,1}$ 、 $p_{B,2}$ ，则混合后

$$D = c_1 c_2 (p_{A,1} - p_{A,2})(p_{B,1} - p_{B,2}). \quad (5.8)$$

当两个位点的频率差方向相同时 $D > 0$ 。例如等量混合两个群体， A_1 频率分别为 0.9 与 0.1， B_1 频率分别为 0.8 与 0.2，则 $D = 0.25 \times 0.8 \times 0.6 = 0.12$ 。这种 LD 与位点是否连锁无关；不连锁位点的混合 LD 在随机交配下每代减半，很快消失，而连锁位点的混合 LD 则保留较久。群体分层导致的关联研究假阳性，本质上正是这种“混合 LD”在表型与标记之间的表现（第 8 章）。另一方面，混合 LD 也可以被利用：在近期混合的群体中，祖先来源片段很长，可以用相对稀疏的标记进行“混合作图”，寻找祖先成分与性状相关的区域。

5.6.5 近交系杂交

两个近交系杂交是产生 LD 最有效的方式。设近交系 I 在两个位点上都固定为 A_1B_1 ，近交系 II 固定为 A_2B_2 。 F_1 个体全部为相引相双杂合子 A_1B_1/A_2B_2 。 F_1 产生的配子中，亲本型 A_1B_1 与 A_2B_2 各占 $(1-c)/2$ ，重组型各占 $c/2$ ；等位基因频率均为 0.5。于是 F_1 配子中

$$D = \frac{1-c}{2} - \frac{1}{4} = \frac{1-2c}{4}. \quad (5.9)$$

对不连锁位点 ($c = 0.5$)， $D = 0$ ；对连锁位点， $D > 0$ 且随距离增加而减小。由 F_1 配子随机结合形成的 F_2 或回交群体，其 LD 只存在于连锁位点之间，并且延伸范围可达数十厘摩。这一特性使杂交群体成为检测 QTL 的有力工具：标记即使离 QTL 较远，也与 QTL 有强的关联，因而只需要稀疏的标记就能发现 QTL；但正因为关联延伸很远，QTL 定位的分辨率很低，置信区间常常长达二三十厘摩（第 7 章）。

5.7 漂变与重组的平衡

5.7.1 Sved 公式

大多数远交的家养动植物群体，其历史有效群体大小都较小，漂变与重组之间的平衡是其 LD 的主要来源。斯韦德（1971）基于同祖同源的概率论证得到一个简洁的近似：在有效群体大小为 N_e 、长期稳定的群体中，距离为 c 的两个位点之间

$$E(r^2) \approx \frac{1}{1 + 4N_e c}. \quad (5.10)$$

推理的思路是： r^2 可以近似理解为，在一个位点上同祖同源的两个单倍型，在另一个位点上也同祖同源的条件概率。两个单倍型的共同祖先片段在每代以概率 $1/2N_e$ 汇合、以概率约 $2c$ 被重组打断，二者竞争的结果给出式 (5.10) 的形式。希尔与罗伯逊（1968）用矩方程得到了类似的结果，有限样本时还应加上约 $1/n$ 的抽样偏差。

式 (5.10) 有两个关键特征。第一，LD 只通过乘积 $N_e c$ 依赖于群体大小与距离：有效大小增大十倍，LD 衰减到同样水平所需的距离缩短十倍。第

二，它反映的是“历史”有效群体大小：距离为 c 的位点对之间的 LD，主要由约 $1/(2c)$ 代以前的群体大小决定。因此紧密连锁位点的 LD 反映的是久远的历史，松散连锁位点的 LD 反映的是近期的历史。




图 5.1 连锁不平衡的衰减。A 图为不同重组率下 D 随随机交配世代的几何衰减；B 图为溯祖模拟的一个有效群体大小为 100 的群体中，一千五百个 SNP 两两之间 r^2 随距离的变化，以及 Sved 近似与 $N_e = 1000$ 时期望的比较

图 5.1B 用溯祖模拟展示了这一关系。在 $N_e = 100$ 的群体中模拟一段 20 厘摩的染色体，取 1500 个频率在 0.05 以上的 SNP，计算两两之间的 r^2 。各距离区间平均 r^2 在 0.5 厘摩处约为 0.24，1.5 厘摩处约为 0.11，5 厘摩以上降到 0.05 以下，与 Sved 近似的走势一致，只是在最短距离处略低于近似值。这一偏差有两个来源：式 (5.10) 是比值期望的近似，并未考虑等位基因频率谱的影响；而且只选取常见 SNP 会改变 r^2 的分布。作为对比，若 $N_e = 1000$ ，0.5 厘摩处的期望 r^2 仅约 0.05。

5.7.2 家畜与人类的对比

大多数人类群体的历史有效大小约为一万，LD 在数十千碱基 (kb) 内即衰减到较低水平；而家畜品种由于驯化瓶颈、品种形成时的奠基效应和现代人工授精造成的公畜高度集中，近期有效大小常常只有几十到一百多，LD 可以延伸到数百 kb 甚至数兆碱基 (Mb)。荷斯坦牛中，相距 100 kb 的 SNP 对 r^2 平均约为 0.2，相距 1 Mb 仍在 0.1 左右；而在人类欧洲群体中，相距 100 kb 的 r^2 平均已降至 0.05 以下。这一差别决定了两个领域截然不同的策

略：家畜中数万个 SNP 的中等密度芯片即可捕获大部分 QTL 变异，用于基因组选择；而人类关联研究需要数十万到数百万个 SNP，并借助填充才能达到相近的覆盖。

真实育种群体的 LD 与距离关系往往在短距离处低于用当前 N_e 由式 (5.10) 预期的值，因为短距离的 LD 反映的是久远历史中较大的有效群体，而当前的 N_e 只在近几十代才变小。利用不同距离的 LD 与式 (5.10) 倒推，就可以重建有效群体大小随时间的变化轨迹；许多研究据此发现，家畜品种的有效群体大小在近一二百年内急剧下降，与品种登记、选育强化和人工授精推广的历史相吻合。

5.8 杂交群体与远交群体中的连锁不平衡

把前面的结论放在一起，可以比较两类定位群体的 LD 结构（表 5.3）。

表 5.3 两类群体中连锁不平衡的比较

特征	近交系杂交的 F_2 或回交群体	远交群体
LD 的来源	一次杂交产生的最大不平衡	长期漂变、选择、混合与突变的累积
不连锁位点之间	为零	小但可能不为零（漂变、分层、混合）
连锁位点间 LD 的延伸	数十厘摩	由 $N_e c$ 决定，通常为 kb 至 Mb 量级
标记—QTL 相位	全群一致	不同家系可能不同
检测所需标记密度	低	高
定位分辨率	低	高

在 F_2 中，所有个体的“标记—QTL”相位都相同，因为它们都来自同一对近交系，所以全群的平均标记效应就反映 QTL 效应。远交群体则不同：家系内的连锁信息依赖于每个亲本自己的相位（第 7 章半同胞设计中，每头公

畜的标记—QTL 相位可能不同，必须在公畜内部分析)，而群体水平的关联则依赖于跨家系一致的群体 LD，后者只在紧密连锁时才存在（第 8 章）。这一区别决定了“连锁分析”与“关联分析”的本质差异：前者利用最近几代家系内发生的少数重组，分辨率低但不需要群体 LD；后者利用群体历史上发生的大量重组，分辨率高但需要标记与致因变异非常接近。

5.9 单倍型块、重组热点与标签 SNP

高密度分型揭示，基因组中的 LD 并不是随距离平滑衰减的。人类基因组中存在许多长度为数 kb 至一百多 kb 的**单倍型块**：块内位点之间 LD 很强、单倍型多样性有限；块与块之间 LD 急剧下降。这一结构的主要原因是重组并非均匀分布，而是集中于宽度仅 1 至 2kb 的**重组热点**。在哺乳动物中，PRDM9 蛋白通过识别特定 DNA 序列模体决定热点的位置；PRDM9 的快速进化使不同物种乃至同一物种不同群体的热点位置不同。家畜中也发现了 PRDM9 变异与重组率的遗传差异。

单倍型块结构使得**标签 SNP** 策略成为可能：在每个块内只需分型少数几个 SNP，就能以较高的 r^2 代表块内其他大多数 SNP。人类 HapMap 计划正是基于这一思想，以数十万个标签 SNP 覆盖基因组中绝大多数常见变异。与之相应，**LD 修剪**是从高度冗余的标记集合中选出近似独立子集的常用步骤，例如主成分分析与亲缘估计前，按窗口剔除 r^2 超过某阈值的位点之一。

5.10 连锁不平衡在基因组育种中的意义

连锁不平衡是标记能够“代表”致因变异的唯一途径，因此它决定了基因组方法的能力边界。这里先给出三个在后续章节中反复使用的结论。

第一，标记捕获的遗传方差。若一个 QTL 的加性方差为 $2pq\alpha^2$ ，与之 r^2 为 ρ^2 的单个标记所能解释的加性方差为 $\rho^2 \cdot 2pq\alpha^2$ 。对许多 QTL 与高密度标记，全部标记共同捕获的遗传方差比例取决于每个 QTL 与标记的 LD 程度。若致因变异的频率分布与标记的频率分布不同（例如致因变异偏向稀有），即使标记很密，也只能捕获部分遗传方差（第 25 章）。

第二，有效独立片段数。在有效大小为 N_e 、基因组总长度为 L 摩尔根的群体中，基因组可以近似看作约 $M_e \approx 2N_e L / \ln(4N_e L)$ 个独立的染色体片段（戈达德，2009）。 M_e 越小，每个片段平均包含的变异越多、需要估计的“有效参数”越少，基因组预测越容易达到较高准确度。家畜品种 N_e 小、 M_e 小，这是基因组选择在奶牛中迅速成功的群体遗传原因（第 27 章）。

第三，跨群体的可迁移性。标记与 QTL 之间的 LD 相位在不同群体中可能不同：在品种 A 中与 QTL 正相关的标记等位基因，在品种 B 中可能是负相关或无关的。只有非常紧密连锁的标记，其相位才可能在跨越数百代的品种分化中保持一致。这就是为什么由一个品种训练的基因组预测方程用于另一个品种时准确度大幅下降，以及为什么高密度乃至全序列资料有望改善跨品种预测（第 29—30 章）。

5.11 深入专题

5.11.1 有限样本中 r^2 的偏差与 LD 法有效群体大小

由样本估计的 r^2 即使在群体中两位点完全独立，其期望也不为零。设样本有 n 条单倍型（或 n 个个体的基因型），独立位点间样本相关系数的平方的期望约为 $1/n$ ；因此观察到的 r^2 可近似分解为

$$E(\hat{r}^2) \approx \frac{1}{1 + 4N_e c} + \frac{1}{n}. \quad (5.11)$$

希尔（1981）与韦尔、希尔（1980）系统地推导了有限群体与有限样本下 r^2 的矩，并据此提出由 LD 估计有效群体大小的方法：对一组距离为 c 的位点对，先扣除样本偏差 $1/n$ ，再由式（5.11）解出

$$\hat{N}_e = \frac{1}{4c} \left(\frac{1}{\hat{r}^2 - 1/n} - 1 \right).$$

在 c 较小时，这一估计反映约 $1/(2c)$ 代以前的群体大小。因此把位点对按距离分组，可以得到有效群体大小随时间的“轨迹”。实际应用中还需注意： r^2 的期望对频率较低的位点有偏，通常只用频率大于 0.05 的 SNP；连锁图距的误差会传递到 N_e 的估计；而选择、迁移与群体结构都会使 LD 偏离

漂变—重组平衡的预期。对于不连锁位点 ($c = 0.5$), $E(r^2) \approx 1/(3N_e) + 1/n$ (对不同模型略有差异), 这是沃普尔斯等提出的“LD 单样本法”的依据, 常用于保种群体的近期有效大小估计。

5.11.2 高阶不平衡与多位点单倍型

两位点的 D 不足以完全描述三个及以上位点的单倍型分布。三个位点的单倍型频率除了三个等位基因频率与三对两位点 D 之外, 还需要一个三位点不平衡系数 D_{ABC} :

$$D_{ABC} = \Pr(A_1B_1C_1) - p_Ap_Bp_C - p_AD_{BC} - p_BD_{AC} - p_CD_{AB}.$$

在大的随机交配群体中, 高阶不平衡的衰减速率取决于把相应位点全部分开所需的重组事件, 它可以与两位点不平衡相当不同。对育种而言, 高阶不平衡意味着一个单倍型可能比组成它的任何单个标记都更好地标记致因变异: 若致因变异只出现在某个特定的多位点单倍型背景中, 单个 SNP 的 r^2 可能都很低, 而单倍型指示变量的 r^2 却很高。这是单倍型关联分析与基于单倍型的基因组预测的理论依据, 也是基因型填充能够“推断”未分型变异的基础: 填充本质上是利用参考面板中的多位点单倍型结构, 把稀疏芯片的信息投影到高密度变异上 (第 26 章)。

5.11.3 选择留下的 LD 痕迹

第二节指出, 强的正选择会使有利突变连同其周围的单倍型迅速升高频率。由于时间短, 重组来不及打散该单倍型, 于是在选择位点周围形成**异常长的单倍型**。萨贝蒂等 (2002) 提出的扩展单倍型纯合度 (EHH) 正是度量这一特征: 从核心位点出发, 计算随距离增加, 携带同一核心等位基因的两条随机染色体在整个区间上单倍型完全相同的概率。在中性条件下, EHH 随距离迅速下降; 在近期受到强选择的等位基因周围, EHH 下降缓慢。由此衍生的 iHS (整合单倍型得分) 比较同一位点上两个等位基因周围 EHH 曲线下的面积, XP-EHH 比较两个群体中同一位点的 EHH。结合群体间分化指数 F_{ST} 的全基因组扫描, 这些方法已经在家畜中识别出大量与驯化和品

种选育相关的区域，例如与毛色、体型、产奶、繁殖力与环境适应相关的基因区域。

需要提醒的是，群体瓶颈、混合与群体结构同样会产生单倍型与高 F_{ST} ，选择信号扫描的假阳性率可能很高。可靠的结论需要依据群体历史的零模型（例如用溯祖模拟产生符合该品种历史的中性分布）来判断统计量是否异常，并尽可能结合功能证据。

5.11.4 LD 与基因组预测的准确度

基因组预测的准确度在很大程度上取决于标记与 QTL 之间的 LD。戈高德（2009）与达特韦勒等（2008）的理论把基因组看作 M_e 个独立片段，每个片段的效应需要由训练资料估计（第 25 章式 (25.5)）。 M_e 与有效群体大小和基因组长度有关： $M_e \approx 2N_eL / \ln(4N_eL)$ 。对 $N_e = 100$ 、 $L = 30$ 摩尔根的牛品种， $M_e \approx 6000 / \ln 12000 \approx 640$ ；若用另一种常见的近似 $M_e = 2N_eL$ ，则为 6000。两种近似相差一个数量级，反映了“有效片段数”这一概念的模糊性，但它们都表明： N_e 越小、LD 越强，所需的训练群体越小。这也解释了为什么在多个品种合并的训练群体中，只有当标记足够密、使标记与 QTL 在不同品种间保持一致的 LD 相位时，跨品种的信息才能有效地共享。

5.11.5 例题

例 5.1 由 LD 推断近期有效群体大小

在某地方猪种中分型了 600 个个体 ($n = 1200$ 条单倍型的等价信息)，取相距约 0.5 厘摩 ($c = 0.005$) 的大量 SNP 对，平均 $\hat{r}^2 = 0.12$ 。扣除样本偏差 $1/n \approx 0.0008$ ，得 $r^2 \approx 0.1192$ ，于是

$$\hat{N}_e = \frac{1}{4 \times 0.005} \left(\frac{1}{0.1192} - 1 \right) = 50 \times 7.39 \approx 370.$$

这一估计对应约 $1/(2c) = 100$ 代以前的群体大小。若相距 10 厘摩 ($c = 0.1$) 的位点对平均 $\hat{r}^2 = 0.012$ ，扣除样本偏差后为 0.0112， $\hat{N}_e = 2.5 \times (89.3 - 1) \approx 221$ ，对应约 5 代以前。两个估计显示该品种的有效群体大小在近期有所下降，这与品种近几十年的规模萎缩相符。实际分

析中应同时报告估计的不确定性，并考虑基因组位置与重组率变异的影响。

5.12 本章小结

单倍型频率是理解多位点遗传结构的基本量。两个位点的等位基因若不独立，就存在连锁不平衡，最基本的度量是 $D = ru - st$ ； D' 把 D 标准化到最大可能值，反映重组历史； r^2 是两位点等位基因的相关系数平方，度量一个位点对另一个位点的预测能力，直接决定关联研究的功效与标记捕获的遗传方差。无序基因型中双杂合子的相位是单倍型估计的核心困难，EM 算法利用群体单倍型频率给出相位的后验概率；忽略相位信息会严重低估 LD。随机交配并不能在一代内消除 LD， D 每代按比例 c 衰减；突变、漂变、选择、混合与杂交是产生 LD 的主要机制。在有限群体中，漂变与重组的平衡使 $E(r^2) \approx 1/(1 + 4N_e c)$ ，因此 LD 的范围由有效群体大小决定，并记录了群体的历史。杂交群体的 LD 只存在于连锁位点之间且延伸很远，适合以稀疏标记检测 QTL；远交群体的 LD 范围较短，适合高分辨率定位。这些性质构成了后续连锁作图、QTL 定位、关联分析与基因组预测的群体遗传基础。

5.13 习题

习题 5.1 两位点等位基因频率分别为 $p_1 = 0.7$ 、 $p_2 = 0.4$ ， $D = 0.05$ 。写出四种单倍型频率，并计算 D' 与 r^2 。

习题 5.2 证明：在 Hardy-Weinberg 平衡且父母源单倍型独立时，两个位点基因型剂量之间的协方差等于 $2D$ 。

习题 5.3 当前一代 $D = 0.2$ 。求重组率分别为 0.5、0.1、0.01 时，经过 10 代随机交配后的 D 。

习题 5.4 用表 5.1 资料，从初值 $r = u = 0.4$ 、 $s = t = 0.1$ 出发，手算一次 EM 迭代。

习题 5.5 两个群体以 0.3 : 0.7 混合， A_1 频率分别为 0.2 与 0.6， B_1 频率分别为 0.1 与 0.5。求混合后的 D 与 r^2 ；若两位点不连锁，经过 3 代随机

交配后 D 为多少?

习题 5.6 某品种 $N_e = 150$ 。按 Sved 公式估计相距 0.1、1 与 10 厘摩的标记对的期望 r^2 。若希望相邻标记之间平均 r^2 达到 0.2, 标记平均间距应约为多少?

习题 5.7 一个致因变异的频率为 0.05, 附近一个标记的频率为 0.5。证明即使 $|D'| = 1$, 二者之间的 r^2 也不超过 0.053。

习题 5.8 说明为什么在 F_2 群体中, 用一个距 QTL 20 厘摩的标记仍能检测到显著的关联, 而在一个 $N_e = 100$ 的远交群体中几乎不能。

5.14 习题解答

5.1 $r = 0.28 + 0.05 = 0.33, s = 0.42 - 0.05 = 0.37, t = 0.12 - 0.05 = 0.07, u = 0.18 + 0.05 = 0.23$ 。 $D > 0, D_{\max} = \min(0.7 \times 0.6, 0.3 \times 0.4) = 0.12, D' = 0.417; r^2 = 0.0025 / (0.21 \times 0.24) = 0.0496$ 。

5.2 个体剂量 $x_A = X_1 + X_2, x_B = Y_1 + Y_2$, 下标 1、2 分别表示父源和母源单倍型。同一单倍型内 $\text{Cov}(X_i, Y_i) = D$, 不同单倍型间独立, 协方差为零。故 $\text{Cov}(x_A, x_B) = \text{Cov}(X_1, Y_1) + \text{Cov}(X_2, Y_2) = 2D$ 。

5.3 $0.2 \times 0.5^{10} = 0.0002; 0.2 \times 0.9^{10} = 0.070; 0.2 \times 0.99^{10} = 0.181$ 。

5.4 $w = 0.16 / (0.16 + 0.01) = 0.941$ 。由非双杂合子得确定计数: A_1B_1 $2 \times 35 + 19 + 10 = 99, A_1B_2$ $19 + 16 = 35, A_2B_1$ $10 + 20 = 30, A_2B_2$ $16 + 20 + 2 \times 28 = 92$ 。加入双杂合子: $A_1B_1 = 99 + 67.8 = 166.8, A_2B_2 = 92 + 67.8 = 159.8, A_1B_2 = 35 + 4.2 = 39.2, A_2B_1 = 30 + 4.2 = 34.2$ 。除以 400 得 0.417、0.098、0.086、0.400。

5.5 $D = 0.3 \times 0.7 \times (0.2 - 0.6)(0.1 - 0.5) = 0.0336$ 。混合后 $p_A = 0.48, p_B = 0.38, r^2 = 0.0336^2 / (0.48 \times 0.52 \times 0.38 \times 0.62) = 0.0192$ 。三代后 $D = 0.0336 / 8 = 0.0042$ 。

5.6 $c = 0.001: 1/1.6 = 0.625; c = 0.01: 1/7 = 0.143; c = 0.1: 1/61 = 0.016$ 。令 $1/(1 + 600c) = 0.2, c = 0.0067$, 约 0.67 厘摩。

5.7 $D > 0$ 时 $D_{\max} = \min(0.05 \times 0.5, 0.95 \times 0.5) = 0.025, r^2 \leq$

$$0.025^2 / (0.05 \times 0.95 \times 0.25) = 0.0526。$$

5.8 F_2 中标记与 QTL 之间的 LD 由一次杂交产生, $D = (1 - 2c)/4$, $c = 0.2$ 时 $r^2 = (0.6)^2 = 0.36$ (等位基因频率均为 0.5), 关联仍很强。远交群体中, 由式 (5.10), $E(r^2) \approx 1/(1 + 400 \times 0.2) = 0.012$, 标记几乎不携带 QTL 信息。

5.15 补充习题

习题 5.9 某品种由 LD 估计的有效群体大小在 100 代以前约为 1000, 在 10 代以前约为 150。说明这种变化可能的历史原因, 以及它对该品种基因组选择所需的标记密度与训练群体规模的含义。

习题 5.10 证明式 (5.11) 中, 当 $c = 0$ 时 $E(r^2) \rightarrow 1 + 1/n$ 并不合理, 说明 Sved 近似在极短距离上的局限。

习题 5.11 说明为什么单倍型可以比单个 SNP 更好地标记一个致因变异, 并举一个三位点的例子。

5.16 补充习题解答

5.9 有效群体大小的下降可能来自品种标准化登记、强化选择、人工授精推广导致的公畜集中, 以及品种规模的萎缩。较小的近期 N_e 意味着 LD 范围更长, 中等密度的芯片即可捕获大部分 QTL 变异, 所需的训练群体也较小; 但遗传多样性的丢失加快, 需要控制近交。

5.10 式 (5.11) 是近似, r^2 不能超过 1; 在极短距离上, r^2 的期望受突变 (以及等位基因频率谱) 的限制, 并不趋于 1。更完整的公式应加入突变项, 例如 $E(r^2) \approx 1/(2 + 4N_e c)$ (考虑突变的修正形式在 $c \rightarrow 0$ 时趋于 0.5)。

5.11 设致因变异 Q 只出现在单倍型 $A_1B_2C_1$ 上, 而 A_1 、 B_2 、 C_1 各自都常见且出现在许多其他单倍型中。每个单独的 SNP 与 Q 的 r^2 都很低, 而“是否携带 $A_1B_2C_1$ 单倍型”这一指示变量与 Q 完全相关。

遗传连锁与连锁图谱的构建

6

6.1 重组、交换与连锁

孟德尔的自由组合定律假定不同位点的等位基因在配子中独立组合。1905年贝特森、桑德斯与庞尼特在香豌豆中发现，花色与花粉形状两对性状的组合并不符合9:3:3:1，亲本型组合明显过多。1911年摩尔根在果蝇中证明，这种偏离是因为两个位点位于同一条染色体上，并提出：减数分裂时同源染色体之间发生**交换**，交换使连锁位点上的等位基因重新组合；两个位点在染色体上相距越远，其间发生交换的机会越大。他的学生斯特蒂文特在1913年据此构建了第一张遗传连锁图——六个果蝇X染色体基因的线性排列，并以重组百分率作为距离的度量。一百多年后，这一思想仍然是遗传作图的基础。

需要区分两个概念。**交换**是减数分裂中同源染色体（非姐妹染色单体）之间的物理交换事件；**重组**是配子中两个位点的等位基因组合不同于亲本组合的结果。两个位点之间若发生奇数次交换，配子为重组型；若发生偶数次交换（包括零次），配子仍为亲本型。因此重组是可以从后代基因型中观察到的现象，而交换的次数一般观察不到。

考察一个双杂合个体 A_1B_1/A_2B_2 （相引相）。设 A 、 B 两位点之间的重组率为 c ，它产生四种配子的频率为

表 6.1 双杂合子产生的配子

配子	A_1B_1	A_1B_2	A_2B_1	A_2B_2
频率	$\frac{1}{2}(1-c)$	$\frac{1}{2}c$	$\frac{1}{2}c$	$\frac{1}{2}(1-c)$
类型	亲本型	重组型	重组型	亲本型

重组型配子的总频率为 c 。若两个位点完全连锁, $c = 0$; 若位于不同染色体或同一染色体上相距很远, $c = 0.5$, 两位点自由组合。重组率在 0 与 0.5 之间。只有双杂合个体的减数分裂才能“显示”重组: 若亲本在某一位点上纯合, 重组照样发生, 但其后代的基因型无法区分重组型与亲本型。能够提供重组信息的减数分裂称为**信息性减数分裂**, 作图的设计在很大程度上就是设法增加信息性减数分裂的数目。

6.2 重组率与图距

6.2.1 重组率不可加

我们希望遗传距离具有可加性: 若 A 、 B 、 C 依次排列, 则 A 到 C 的距离应等于 A 到 B 与 B 到 C 之和。重组率并不满足这一性质。两个相邻区间的重组事件有四种组合: $A-B$ 与 $B-C$ 都不重组; 只有 $B-C$ 重组; 只有 $A-B$ 重组; 两者都重组。只有第二、三种情形下 A 与 C 之间表现为重组, 第四种情形中两次重组相互抵消。若两个区间的重组相互独立, 则

$$c_{AC} = (1 - c_{AB})c_{BC} + c_{AB}(1 - c_{BC}) = c_{AB} + c_{BC} - 2c_{AB}c_{BC}. \quad (6.1)$$

例如 $c_{AB} = 0.2$ 、 $c_{BC} = 0.3$, 则 $c_{AC} = 0.38$, 而非 0.5。差额 0.12 恰好是两倍的双重重组频率 $2 \times 0.2 \times 0.3$ 。

6.2.2 干涉

式 (6.1) 假定相邻区间的交换相互独立。实际上一处交换往往会抑制其附近再次发生交换, 这种现象称为**交叉干涉**。设符合系数 γ 为实际双重重组频

率与独立期望之比, 干涉强度 $\delta = 1 - \gamma$, 则

$$c_{AC} = c_{AB} + c_{BC} - 2(1 - \delta)c_{AB}c_{BC}.$$

$\delta = 0$ 为无干涉, 回到式 (6.1); $\delta = 1$ 为完全干涉, 此时 $c_{AC} = c_{AB} + c_{BC}$, 重组率可加。大多数生物存在部分干涉, 相距十几厘摩以内的双交换很少见。

6.2.3 图距的定义

为了得到可加的距离, 摩尔根学派把两位点间的**图距** d 定义为一次减数分裂中两位点之间交换次数的期望值, 单位为摩尔根 (M), 1 摩尔根 = 100 厘摩 (cM)。由于期望具有可加性——无论各区间的交换是否独立——图距总是可加的:

$$d_{AC} = E(\text{交换数}_{AC}) = E(\text{交换数}_{AB}) + E(\text{交换数}_{BC}) = d_{AB} + d_{BC}.$$

图距为 1 摩尔根意味着每次减数分裂在该区间平均发生一次交换。牛基因组的连锁图总长约 30 摩尔根 (3000 厘摩), 即每次减数分裂全基因组平均约有 30 次交换, 大约每条染色体臂一次。由于偶数次交换不产生重组, $c \leq d$; 当距离很短时, 多次交换几乎不可能, $c \approx d$ 。

6.3 作图函数

连接重组率与图距的函数称为**作图函数**。不同的作图函数对应不同的干涉假设。

霍尔丹作图函数 (1919) 假定无干涉, 即交换沿染色体按泊松过程发生。在图距为 d 的区间内交换数服从均值为 d 的泊松分布, 重组率等于交换数为奇数的概率:

$$c = \sum_{k \text{ 奇}} \frac{e^{-d} d^k}{k!} = e^{-d} \sinh d = \frac{1}{2}(1 - e^{-2d}), \quad d = -\frac{1}{2} \ln(1 - 2c). \quad (6.2)$$

科萨姆比作图函数 (1944) 允许部分干涉, 其形式为

$$c = \frac{1}{2} \tanh(2d) = \frac{e^{4d} - 1}{2(e^{4d} + 1)}, \quad d = \frac{1}{4} \ln \frac{1 + 2c}{1 - 2c}. \quad (6.3)$$

它对应的三点关系为 $c_{AC} = (c_{AB} + c_{BC}) / (1 + 4c_{AB}c_{BC})$ ，干涉随距离增加而减弱，比较符合许多生物的实际情况。

完全干涉时 $c = d$ (只在 $d \leq 0.5$ 时有意义)。以 $d = 0.2$ 摩尔根为例，霍尔丹函数给出 $c = 0.165$ ，科萨姆比函数给出 0.190 ，完全干涉为 0.200 。在短距离上三者几乎一致，差别随距离增大而显著 (图 6.1A)。同一套重组率资料用不同作图函数换算，得到的图谱总长可以相差百分之十至二十，比较不同研究的图谱长度时必须注意所用函数。

还需要注意，重组率在两性之间常常不同。多数哺乳动物雌性减数分裂的重组率高于雄性，人类女性连锁图约比男性长 60%，猪、羊中也有类似的性别差异；而在某些染色体区段，例如端粒附近，雄性的重组率反而更高。动物遗传图谱往往需要分性别估计，这对后续利用公畜家系的 QTL 定位尤为重要，因为公畜后代资料只反映雄性减数分裂中的重组。

6.4 两点连锁的检测与估计

6.4.1 回交群体的似然

最简单的作图群体是近交系回交：两个近交系杂交得到 $F_1 (A_1B_1/A_2B_2)$ ， F_1 再与纯合亲本之一回交。回交后代的基因型直接反映 F_1 配子的类型，因此每个后代都是一次信息性减数分裂的结果，重组型与亲本型可以直接计数。

设 n 个后代中有 n_2 个重组型、 $n_1 = n - n_2$ 个亲本型。重组数服从二项分布，对数似然为

$$\ell(c) = n_1 \ln(1 - c) + n_2 \ln c + \text{常数},$$

最大似然估计 $\hat{c} = n_2/n$ ，标准误 $\sqrt{\hat{c}(1 - \hat{c})/n}$ (第 3 章)。检验连锁即检验 $H_0: c = 0.5$ ，似然比统计量 $LR = 2[\ell(\hat{c}) - \ell(0.5)]$ ，或以 LOD 值表示：

$$\text{LOD} = \log_{10} \frac{L(\hat{c})}{L(0.5)} = n_1 \log_{10}(1 - \hat{c}) + n_2 \log_{10} \hat{c} - n \log_{10} 0.5. \quad (6.4)$$

例 6.1 回交群体中两点连锁的检验

$A_1A_1B_1B_1 \times A_2A_2B_2B_2$ 的 F_1 与 $A_2A_2B_2B_2$ 回交, 100 个后代中, 四种 F_1 配子类型的计数为 A_1B_1 38、 A_1B_2 16、 A_2B_1 10、 A_2B_2 36。于是 $n_1 = 74$, $n_2 = 26$, $\hat{c} = 0.26$, $SE(\hat{c}) = 0.044$ 。

$$\ell(0.26) = 74 \ln 0.74 + 26 \ln 0.26 = -57.31, \quad \ell(0.5) = 100 \ln 0.5 = -69.31.$$

似然比统计量为 $2 \times 12.01 = 24.02$, $p = 9.5 \times 10^{-7}$; $LOD = 12.01 / \ln 10 = 5.22$, 远超常用的连锁阈值 3。按霍尔丹函数换算, 图距约 36.7 厘摩; 按科萨姆比函数约 28.8 厘摩。两种换算之差反映了在这一距离上干涉假设的影响。

两点检验在构建图谱时需要对所有标记对进行。 m 个标记有 $m(m-1)/2$ 个标记对, 一百个标记就有 4950 对。如此多的检验使得 LOD 阈值不能太低; 在人类遗传学中, LOD 为 3 对应的全基因组假阳性率约为 5%, 这一阈值的贝叶斯依据见第 3 章。

6.4.2 F_2 互交群体与相位未知的资料

F_2 互交群体中, 每个后代携带两个来自 F_1 的配子, 其中都可能发生重组。对共显性标记, 两个位点的九种基因型中, 只有双杂合子的配子组成不能确定: 它可能由两个亲本型配子组成 (概率正比于 $(1-c)^2$), 也可能由两个重组型配子组成 (概率正比于 c^2)。这又是一个不完全资料问题, 可以用 EM 算法: E 步按 $w = (1-c)^2 / [(1-c)^2 + c^2]$ 计算双杂合子的期望重组配子数 $2(1-w)$, 与其他基因型中确定的重组配子数相加; M 步以期望重组配子数除以 $2n$ 更新 c 。模拟一个真实 $c = 0.2$ 、300 个后代的 F_2 群体, EM 估计为 $\hat{c} = 0.214$ 。 F_2 中每个后代提供两次减数分裂, 在同样后代数下比回交的信息更多; 但若标记为显性 (如 AFLP 标记只能区分“有”与“无”), 某些基因型类别合并, 信息大为减少。

在远交动物群体中, 作图通常依赖家系, 例如三代家系或大的半同胞家系。困难在于: 亲本的连锁相位未知, 而且并非所有亲本在所有标记上都是

杂合的。对一个双杂合公畜，若其相位已知（例如可由其父母推断），每个后代都可以归类为重组或非重组；若相位未知，似然就是两种相位假设下似然的平均：

$$L(c) = \frac{1}{2}c^k(1-c)^{n-k} + \frac{1}{2}(1-c)^kc^{n-k},$$

其中 k 是在某一相位假设下的重组型后代数。这种“相位未知”的似然在 c 与 $1-c$ 之间对称，必须把参数限制在 $[0,0.5]$ 内。早期用于家畜作图的 CRI-MAP 程序正是处理这类家系资料的。

6.5 连锁图谱的构建

由大量标记构建连锁图谱包括三个步骤：把标记分为连锁群；确定每个连锁群内标记的顺序；估计相邻标记之间的图距。

6.5.1 分组

计算所有标记对的两点 LOD 值，按以下方式分组：以 LOD 值最高的标记对构成一个群；若某个群外标记与群内任一标记的 LOD 值超过阈值，则把它加入该群；重复直到没有标记可以加入；再从剩余标记中开始新的群。理想情况下，连锁群数目等于单倍体染色体数。阈值过高会把一条染色体分裂成多个连锁群；阈值过低则可能把不同染色体上的标记错误地合并。

表 6.2 五个标记的两点 LOD 值

	A	B	C	D	E
A	—	0.4	9.0	2.9	0.6
B	0.4	—	0.6	0.4	11.7
C	9.0	0.6	—	7.8	0.7
D	2.9	0.4	7.8	—	0.3
E	0.6	11.7	0.7	0.3	—

以 LOD 阈值 5 为标准，B 与 E 构成一个连锁群，A、C、D 构成另一个。

注意 A 与 D 之间的 LOD 只有 2.9, 未达阈值, 但它们通过共同与 C 连锁而进入同一群: A-C 与 C-D 的连锁都很强, 说明 A 与 D 可能相距较远, 处于 C 的两侧。这正体现了分组的传递性, 也提示两点 LOD 值低并不意味着位于不同染色体。

6.5.2 排序

确定连锁群内的标记顺序是构图中计算量最大的一步。对三个标记, 只有三种本质不同的顺序 (ABC、ACB、BAC); 对 m 个标记, 有 $m!/2$ 种顺序, 十个标记即超过一百八十万种。

最大似然排序。以三点为例, 给定顺序 1-2-3, 每个回交后代可按两个区间是否重组分为四类: 两区间都不重组、只有 2-3 区间重组、只有 1-2 区间重组、两区间都重组 (双重重组)。在无干涉假设下, 四类的概率为 $(1-c_{12})(1-c_{23})$ 、 $(1-c_{12})c_{23}$ 、 $c_{12}(1-c_{23})$ 、 $c_{12}c_{23}$, 对数似然为

$$\ell = n_1 \ln p_1 + n_2 \ln p_2 + n_3 \ln p_3 + n_4 \ln p_4. \quad (6.5)$$

对每一种可能的顺序, 把观察到的单倍型类别分配到相应的四类, 代入各自的_{最大似然重组率}, 比较似然的大小。

例 6.2 三点排序

在 ABC/abc 回交的 100 个后代中观察到: ABC+abc 50 个, ABc+abC 7 个, Abc+aBC 32 个, AbC+aBc 11 个。两两重组率估计为 $\hat{c}_{AB} = 0.43$, $\hat{c}_{AC} = 0.39$, $\hat{c}_{BC} = 0.18$ 。

若顺序为 ABC, 第二类 (只有 B-C 重组) 为 7 个, 第三类 (只有 A-B 重组) 为 32 个, 双重重组为 11 个; 若顺序为 ACB, 原来的 “ABc+abC” 需要 A-C 与 C-B 两个区间都重组才能产生, 变为双重重组类 (7 个), 而 “AbC+aBc” 只需 C-B 区间重组 (11 个)。各顺序下的对数似然为:

顺序	n_1	n_2	n_3	n_4	对数似然
ABC	50	7	32	11	-115.5

ACB	50	11	32	7	-114.0
-----	----	----	----	---	--------

BAC	50	7	11	32	-135.2
-----	----	---	----	----	--------

ACB 的似然最大，比 ABC 高 1.46 个自然对数单位（约 0.63 个 LOD 单位，似然比约 4.3 倍）。这也是双重重组数最少的顺序。

当标记数目较多时，穷举所有顺序不可行，需要启发式方法与优化准则。常用的替代准则有：**相邻重组率之和最小**（类似旅行商问题中的最短路径），**相邻 LOD 之和最大**（兼顾估计的精度），以及**隐含重组数最少**（对每个个体，统计给定顺序下所需的最少交换数）。搜索策略包括：先以少数高信息标记建立可靠的骨架图，再逐个插入其余标记；对局部区段进行“翻转”与“滑动”（类似 2-opt 算法）以改进顺序；用模拟退火或遗传算法跳出局部最优。早期的 MapMaker 与 CRI-MAP、后来的 JoinMap、MSTMap 与 Lep-MAP 都采用了这些策略的不同组合。MSTMap 利用了一个巧妙的性质：在资料无误时，以标记为节点、两点距离为边权的最小生成树正是一条路径，其顺序即为正确的标记顺序。

6.5.3 图距估计

确定顺序后，需要估计相邻标记之间的图距。两点估计只利用一对标记的资料，而多点估计同时利用一段区间上的所有标记，信息更充分，并能更好地处理缺失资料。斯塔姆（1993）在 JoinMap 中提出了一种实用的加权最小二乘方法：把每一对（不一定相邻的）标记的两点重组率经作图函数换算为图距 $\hat{d}_{ij}$ ，在给定顺序下，它们应等于其间相邻区间图距之和；以 LOD 值的平方为权重，求使加权残差平方和最小的相邻区间图距：

$$Q = \sum_{i < j} w_{ij} \left(\hat{d}_{ij} - \sum_{k=i}^{j-1} d_{k,k+1} \right)^2. \quad (6.6)$$

例如顺序为 ABC 时，有三个两点估计 $\hat{d}_{AB}$ 、 $\hat{d}_{BC}$ 、 $\hat{d}_{AC}$ ，而只有两个未知数 d_{AB} 与 d_{BC} ：

$$Q = w_{AB}(\hat{d}_{AB} - d_{AB})^2 + w_{BC}(\hat{d}_{BC} - d_{BC})^2 + w_{AC}(\hat{d}_{AC} - d_{AB} - d_{BC})^2.$$

权重使精度高的估计在拟合中占更大比重。残差平方和本身也可作为顺序优劣的度量。




图 6.1 作图函数与模拟回交群体的两点 LOD 矩阵。A 图比较完全干涉、霍尔丹与科萨姆比三种作图函数；B 图为按估计顺序排列后的 12 个标记的两点 LOD 矩阵，对角线附近的高值带表明顺序恢复正确

图 6.1B 与图 6.2 展示了一个完整的构图模拟。在一条 120 厘摩的染色体上随机放置 12 个标记，模拟 150 个回交后代（霍尔丹无干涉），随后打乱标记顺序，再按“相邻重组率之和最小”的准则重建顺序，以斯塔姆方法估计图距。估计顺序中只有一对相距不到 1 厘摩的标记互换了位置——在 150 个后代中，二者之间很可能没有观察到任何重组，因此其相对顺序在资料中本来就无法确定。重建的图谱总长约 101 厘摩，短于真实的 120 厘摩。主要差别来自末端一个约 37 厘摩的长区间：该区间两点重组率估计约为 0.23，换算后被明显低估。长区间的重组率估计方差大，作图函数在 c 接近 0.5 处又非常陡峭，小的抽样误差就会造成大的图距误差；若改用科萨姆比函数换算，全长只有约 85 厘摩。这提醒我们：图谱的总长度对标记密度、群体大小与作图函数都很敏感，稀疏标记的图谱长度不宜直接比较。

6.6 多点连锁分析的似然：隐马尔可夫模型

当标记很多、资料中有缺失或分型错误时，两点方法的局限更加明显。多点连锁分析把一个个体沿染色体的“遗传来源状态”看作一个隐马尔可夫




图 6.2 模拟回交群体中图谱的重建。上方为 12 个标记的真实位置，下方为估计位置，连线连接同一标记

链，这一框架由兰德与格林（1987）引入，是现代连锁分析、QTL 区间作图与基因型填充的共同数学基础。

以回交为例，每个后代在每个位点上的状态为“从 F_1 获得了亲本 1 的等位基因”或“获得了亲本 2 的等位基因”。沿染色体从一个标记到下一个标记，状态以概率 $c_{k,k+1}$ 改变（发生重组），以概率 $1 - c_{k,k+1}$ 保持不变；在无干涉时，这是一个马尔可夫链。观察到的标记基因型是状态的“发射”：若无分型错误，观察与状态一一对应；若有错误率 ϵ ，则观察以概率 ϵ 与真实状态不符。一个个体的观察资料的似然为

$$L = \sum_{s_1, \dots, s_m} \Pr(s_1) \prod_{k=1}^{m-1} \Pr(s_{k+1} | s_k) \prod_{k=1}^m \Pr(o_k | s_k),$$

求和遍及所有可能的状态序列。直接求和的计算量随标记数指数增长，但前向—后向算法利用马尔可夫性质，把计算量降为与标记数成线性。同一算法还能给出每个位点处于各状态的后验概率，即使该位点的标记缺失或位于两个标记之间。正是这一性质，使第 7 章的区间作图能够在标记之间的任意位置计算 QTL 基因型的条件概率。

兰德—格林算法的计算量与标记数成线性，但与家系中减数分裂数目成指数关系，适合标记多、家系小的情形；与之互补的埃尔斯顿—斯图尔特算法（1971）沿家系结构递归，计算量与家系大小成线性，但与标记数成指数关系，适合大家系、少标记。人类大家系的多点连锁分析曾长期受制于这一“维数灾难”，各种近似与马尔可夫链蒙特卡洛方法由此发展起来。

6.7 遗传图谱与物理图谱

连锁图谱给出的是以重组为尺度的距离，物理图谱给出的是以碱基对为尺度的距离。二者之比——每兆碱基的厘摩数——在不同物种、不同染色体乃至同一染色体的不同区段差异很大。全基因组平均而言，人类约为 1.2 cM/Mb，牛约为 1 cM/Mb，猪约为 0.6 cM/Mb，鸡约为 3 cM/Mb（鸡有大量重组率很高的微染色体）。在染色体内部，着丝粒附近的重组率常常很低，端粒附近较高；重组热点则使重组集中于很窄的区域（第 5 章）。

在参考基因组组装完成之前，连锁图谱是定位基因与标记的主要坐标系；组装完成之后，连锁图谱的角色转变为：辅助把序列片段定位、定向到染色体上；检测组装错误（若相邻序列片段的标记表现为松散连锁或顺序矛盾，提示组装可能有误）；估计重组率在基因组上的分布与个体间差异；以及为 QTL 区间作图提供以厘摩为单位的坐标。对家畜而言，利用大量家系的高密度 SNP 资料，可以直接在群体中计数每头动物每次减数分裂的交换位置，从而估计个体的重组率并研究其遗传基础。在奶牛和猪中已经证明，全基因组重组率本身是一个可遗传的数量性状，并与 *RNF212*、*PRDM9* 等基因的变异有关。

6.8 偏分离与分型错误

两个现实问题常常影响连锁图谱的质量。

偏分离指标记的基因型比例偏离孟德尔期望，如 F_2 中偏离 1:2:1、回交中偏离 1:1。其原因包括配子选择、合子选择、减数分裂驱动以及分型错误。偏分离本身不影响以重组型配子比例估计的重组率，前提是偏离只作用于一个位点；但若两个连锁位点都发生偏分离，或偏分离由与之连锁的选择位点造成，则二项似然的假设被破坏，可能产生虚假连锁或扭曲图距。偏分离区域在植物远缘杂交中尤为常见，有时恰恰指示了与生殖隔离相关的基因。

分型错误对图谱的影响更为严重：一个错误的基因型会在两侧各制造一次表观重组，形成“双重组”。在高密度图谱中，相邻标记间的真实双重组几乎不可能，因此单个标记处孤立的双重组强烈提示分型错误。每个位点 1%

的错误率，在标记间距 1 厘摩时会使表观重组数增加约一倍，图谱总长度严重膨胀。现代构图软件把错误率作为隐马尔可夫模型中的发射概率加以估计，或者在构图前识别并剔除可疑基因型。

6.9 深入专题

6.9.1 干涉的统计模型

霍尔丹函数假定交换沿染色体按泊松过程发生，相邻交换的位置相互独立。实际的减数分裂中，一个交换会在其附近抑制另一个交换，交换之间的距离比泊松过程更“均匀”。描述干涉的一个成功模型是**计数模型**（或称卡方模型，福斯与斯塔耳，1993）：设染色体上沿着某种“前体事件”的泊松过程，每隔 m 个前体事件才有一个形成交换，于是相邻交换之间的距离服从参数为 $m + 1$ 的伽马分布。 $m = 0$ 退化为霍尔丹的无干涉模型； m 越大，干涉越强。更一般的**伽马模型**允许形状参数取非整数值。对许多物种的高密度资料，伽马模型的形状参数估计在 4 至 10 之间，说明干涉相当强。现代家畜研究还发现，交换可分为两类：受干涉约束的一类（占多数）与不受干涉约束的一类（占少数），由不同的分子通路产生，称为“双通路模型”。

干涉对作图的影响主要体现在两个方面：多点似然中相邻区间的重组不再独立，严格的似然需要考虑相邻区间的联合分布；把重组率换算为图距时，不同的干涉强度对应不同的作图函数。在标记很密时（相邻标记间重组率很小），这些差别对图谱的影响很小；但在估计长区间的图距与图谱总长度时不可忽视。

6.9.2 前向—后向算法的递推

以回交为例，把一个后代在第 k 个标记处的来源状态记为 $s_k \in \{1, 2\}$ （获得 F_1 的亲本 1 或亲本 2 的等位基因），观察到的标记基因型记为 o_k 。定义前向概率

$$\alpha_k(s) = \Pr(o_1, \dots, o_k, s_k = s),$$

后向概率

$$\beta_k(s) = \Pr(o_{k+1}, \dots, o_m | s_k = s).$$

由马尔可夫性质可得递推：

$$\alpha_{k+1}(s') = \left[\sum_s \alpha_k(s) T_k(s, s') \right] e(o_{k+1} | s'), \quad \beta_k(s) = \sum_{s'} T_k(s, s') e(o_{k+1} | s') \beta_{k+1}(s'),$$

其中转移概率 $T_k(s, s') = 1 - c_k$ ($s = s'$) 或 c_k ($s \neq s'$)， $e(o | s)$ 为发射概率（无分型错误时为 0 或 1，有错误率 ϵ 时为 $1 - \epsilon$ 或 ϵ ）。资料的似然为 $L = \sum_s \alpha_m(s)$ ，任一位置的后验状态概率为

$$\Pr(s_k = s | o_1, \dots, o_m) = \frac{\alpha_k(s) \beta_k(s)}{L}.$$

计算量为 $O(mS^2)$ ， S 为状态数。对 F_2 ，每个个体在每个位置有四种有序状态（父源与母源各两种）， $S = 4$ ；对一个有 n 次减数分裂的家系，状态是全部减数分裂的“继承向量”， $S = 2^n$ ，这就是兰德—格林算法计算量随家系大小指数增长的原因。重组率的最大似然估计可以把上述算法嵌入 EM：E 步由前向—后向概率计算每个区间的期望重组次数，M 步以期望重组次数除以减数分裂数更新重组率。这是隐马尔可夫模型的鲍姆—韦尔奇算法在遗传作图中的具体形式。

6.9.3 家系资料的作图与相位推断

家畜作图群体通常是大的半同胞或全同胞家系，亲本的相位未知，部分标记在部分亲本中不杂合。实际流程通常包括：利用祖代基因型（若有）确定亲本的连锁相位；对缺乏祖代资料的亲本，利用其大量后代推断相位——在一个有一百个后代的公畜家系中，对相邻两个标记，按两种相位分别计数重组型后代，重组数少的相位几乎必然正确；然后以已知相位计数每个后代在每个区间的重组。高密度 SNP 资料使这一过程可以在全基因组自动完成，进而直接识别每次减数分裂中的交换位置。

6.9.4 个体重组率的遗传变异

利用大规模家系的高密度 SNP 资料，可以统计每头动物每次减数分裂的交换总数，即“全基因组重组率”。在荷斯坦牛、猪、羊与鸡中，研究者统计

了数以万计减数分裂中的交换，发现个体重组率存在可观的遗传变异，遗传力约为 0.1 至 0.2；关联分析把其遗传基础定位到 *RNF212*、*CPLX1*、*MSH4*、*PRDM9* 等与减数分裂相关的基因。重组率还存在明显的性别差异与年龄效应。由于重组产生新的单倍型组合、为选择提供新的变异，个体重组率的遗传改良在理论上可能影响长期选择反应，这是育种研究中一个新兴的问题。

6.9.5 遗传图与物理图的整合

参考基因组组装以后，遗传图的主要用途转变为组装的验证与改进，以及为遗传分析提供以厘摩为单位的坐标。整合两种图谱时需注意：在重组冷区（如着丝粒附近），物理距离很大的一段可能只有很短的遗传距离，大量标记聚集在同一厘摩位置，其顺序只能由物理图确定；在重组热区，物理距离很短的区间可能对应较大的遗传距离。基于物理位置的线性插值（以局部的厘摩/兆碱基比率换算）是为未作图标记赋予遗传坐标的常用方法。对 QTL 定位与基因组预测而言，以遗传距离而非物理距离描述 LD 的衰减更为合理，因为 LD 的形成与衰减由重组决定。

6.10 本章小结

连锁源于位于同一染色体上的位点不独立分离；重组是偶数次交换之外的奇数次交换所产生的可观察结果。重组率不可加，而以交换次数期望定义的图距是可加的；作图函数在不同干涉假设下连接二者，霍尔丹函数假定无干涉，科萨姆比函数允许部分干涉，短距离上二者与重组率几乎相同。两点连锁由二项似然估计重组率，以 LOD 值检验； F_2 与相位未知的家系资料需要用 EM 或混合似然处理。构图包括分组、排序与图距估计：分组依赖 LOD 阈值与传递性；排序是一个组合优化问题，可用似然、相邻距离之和或隐含重组数等准则，配合启发式搜索；图距可由多点似然或斯塔姆加权最小二乘估计。隐马尔可夫模型为多点分析提供了统一框架，其前向—后向算法给出任意位置遗传来源状态的后验概率，是 QTL 区间作图的数学基础。遗传图谱与物理图谱之比在基因组上变化很大；偏分离与分型错误是影响图谱质量的两个主要因素。

6.11 习题

习题 6.1 三个位点依次为 A、B、C, $c_{AB} = 0.1$, $c_{BC} = 0.15$ 。分别在无干涉与符合系数为 0.5 时计算 c_{AC} 。

习题 6.2 由霍尔丹作图函数, 证明重组率为 0.5 时图距为无穷大, 并计算 $c = 0.1$ 、0.3、0.45 时的图距。比较科萨姆比函数的结果。

习题 6.3 回交群体 200 个后代中观察到 48 个重组型。计算重组率、标准误、LOD 值以及以霍尔丹函数换算的图距。

习题 6.4 在一个相位未知的公畜半同胞家系中, 公畜在两个标记上双杂合。20 个后代中, 在一种相位假设下有 4 个重组型、16 个亲本型。写出似然函数, 求重组率的最大似然估计与 LOD 值, 并与相位已知时比较。

习题 6.5 对例 6.2 的资料, 计算按“相邻重组率之和最小”准则得到的顺序, 并与最大似然顺序比较。

习题 6.6 顺序为 ABC, 两点图距估计为 $\hat{d}_{AB} = 12$ 、 $\hat{d}_{BC} = 20$ 、 $\hat{d}_{AC} = 28$ 厘摩, 权重分别为 9、4、1。用斯塔姆方法求 d_{AB} 与 d_{BC} 。

习题 6.7 一个回交后代在依次相距 1 厘摩的五个标记上的基因型为“亲 1、亲 1、亲 2、亲 1、亲 1”。给出这一资料的两种解释, 并在分型错误率为 1% 时比较二者的概率。

6.12 习题解答

6.1 无干涉: $0.1 + 0.15 - 2 \times 0.015 = 0.22$ 。 $\gamma = 0.5$: $0.1 + 0.15 - 2 \times 0.5 \times 0.015 = 0.235$ 。

6.2 $d = -\frac{1}{2} \ln(1-2c)$, $c \rightarrow 0.5$ 时 $d \rightarrow \infty$ 。霍尔丹: $c = 0.1$, $d = 0.112$; $c = 0.3$, $d = 0.458$; $c = 0.45$, $d = 1.151$ 摩尔根。科萨姆比: 0.101、0.347、0.736 摩尔根。

6.3 $\hat{c} = 0.24$, $SE = \sqrt{0.24 \times 0.76/200} = 0.030$ 。 $LOD = 48 \log_{10} 0.24 + 152 \log_{10} 0.76 + 200 \log_{10} 2 = -29.75 - 18.12 + 60.21 = 12.34$ 。 $d = -\frac{1}{2} \ln 0.52 = 0.327$ 摩尔根, 即 32.7 厘摩。

6.4 $L(c) = \frac{1}{2}[c^4(1-c)^{16} + c^{16}(1-c)^4]$ 。在 $[0, 0.5]$ 内最大值点非常接近 $0.2, \hat{c} \approx 0.2$ (第二项在 $c = 0.2$ 处可忽略)。 $L(0.2) \approx \frac{1}{2} \times 0.2^4 \times 0.8^{16} = 2.25 \times 10^{-5}$, $L(0.5) = 0.5^{20} = 9.54 \times 10^{-7}$, $\text{LOD} = \log_{10}(23.6) = 1.37$ 。相位已知时 LOD 为 $\log_{10}[0.2^4 \times 0.8^{16} / 0.5^{20}] = 1.67$, 相位未知损失 $\log_{10} 2 \approx 0.30$ 个 LOD 单位。

6.5 三种顺序的相邻重组率之和: ABC 为 $0.43 + 0.18 = 0.61$, ACB 为 $0.39 + 0.18 = 0.57$, BAC 为 $0.43 + 0.39 = 0.82$ 。最小者为 ACB , 与最大似然顺序一致。

6.6 令 $\partial Q / \partial d_{AB} = 0$ 与 $\partial Q / \partial d_{BC} = 0: 9(12 - d_{AB}) + (28 - d_{AB} - d_{BC}) = 0, 4(20 - d_{BC}) + (28 - d_{AB} - d_{BC}) = 0$ 。即 $10d_{AB} + d_{BC} = 136, d_{AB} + 5d_{BC} = 108$ 。解得 $d_{AB} = 11.67, d_{BC} = 19.27$ 。

6.7 解释一: 第三个标记两侧各发生一次真实重组 (双重重组), 概率约 $0.01 \times 0.01 = 10^{-4}$ (乘以其他区间不重组的概率, 近似为 1)。解释二: 第三个标记分型错误, 概率约 0.01。分型错误的可能性约为真实双重重组的一百倍。

6.13 补充习题

习题 6.8 在计数模型中, 若 $m = 4$, 相邻交换之间的距离服从什么分布? 说明为什么 m 越大, 短距离上的双交换越少。

习题 6.9 写出回交中三个标记的前向递推, 并在 $c_{12} = 0.1, c_{23} = 0.2$ 、观察为“亲 1、亲 2、亲 1”且无分型错误时, 计算资料的似然。

6.14 补充习题解答

6.8 交换之间的距离 (以前体事件的泊松过程计) 服从形状参数为 5 的伽马分布 (埃尔朗分布)。形状参数越大, 分布越集中于其均值附近, 短距离的取值概率越小, 因而短距离上的双交换越少。

6.9 $\alpha_1(1) = \frac{1}{2}, \alpha_1(2) = 0, \alpha_2(2) = \frac{1}{2} \times 0.1 = 0.05, \alpha_2(1) = 0, \alpha_3(1) = 0.05 \times 0.2 = 0.01$ 。似然为 0.01, 即 $\frac{1}{2}c_{12}c_{23}$ 。

第三篇

PART III

数量性状基因定位

借助分子标记，数量遗传学从“黑箱”式的方差分析走向具体基因组区域。本篇系统阐述杂交群体的区间作图、远交群体的连锁分析与全基因组关联研究。

第 7 章 杂交群体的数量性状位点定位

第 8 章 远交群体的连锁分析、关联定位与全基因组关联研究

杂交群体的数量性状位点定位

7.1 从“黑箱”到基因组区域

经典数量遗传学把基因型当作一个“黑箱”：我们知道许多基因共同影响性状，能够估计它们的综合方差，却不知道这些基因在哪里、有多大效应。分子标记的出现改变了这一局面。若一个标记与影响性状的位点紧密连锁，或者二者在群体中处于连锁不平衡，那么标记的不同基因型就会伴随着不同的平均表型。反过来，通过比较不同标记基因型个体的表型，就可以推断附近存在影响性状的位点。基因组上与数量性状遗传差异相关的位置称为**数量性状位点**（quantitative trait locus, QTL）。

能被观察的分子位点有两类。一类是**功能突变**本身，即直接改变性状的DNA变异；它们最有用、最容易应用，但最难找到。另一类是**匿名标记**，它们本身不影响性状，只是与QTL连锁；它们容易获得，但其用途受到连锁不平衡的限制，因为标记与QTL的关联可能因群体与世代而改变。QTL定位的目标，是从匿名标记出发，逐步缩小QTL所在区域，最终找到致因变异，即**数量性状核苷酸**（QTN）。

举一个简单的例子。若标记M的三种基因型MM、Mm、mm个体的平均表型分别为20、18与14，说明等位基因M与提高表型的QTL等位基因相关联，因此可以利用标记进行选择：选择MM个体，或者选择从某个亲本获得M等位基因的后代。这种标记—表型关联的前提是标记与QTL之间存在连锁不平衡（第5章）。不同的QTL定位策略，本质上是利用不同类型的连锁不平衡：

- **人为创造的 LD**：近交系或品种杂交产生的 F_2 、回交群体，以及经多代杂交积累重组的高世代互交系与重组自交系；
- **家系内的 LD**：远交群体中，半同胞或全同胞家系内的亲本连锁相位所产生的关联；
- **群体中已存在的 LD**：远交群体在历史上由漂变、突变、选择与迁移形成的关联。

三类策略的差别在于自 LD 产生以来经历了多少轮重组，这决定了标记需要多靠近 QTL 才能保持足够的 LD，从而决定所需的标记密度、分析方法与定位分辨率。本章讨论第一类，即杂交群体的 QTL 定位；第 8 章讨论后两类。

7.2 单位点数量遗传模型

7.2.1 基因型值

为了描述 QTL 的效应，先回顾单位点模型。把表型分解为 $P = \mu + G + E$ ，基因型 T 的**基因型值**定义为具有该基因型的个体的期望表型， $G_T = E(P | T)$ 。福尔克纳以两个纯合子的中点为原点，把三种基因型的值记为

$$A_1A_1 : +a, \quad A_1A_2 : d, \quad A_2A_2 : -a,$$

其中 a 为加性效应（两纯合子差异的一半）， d 为显性效应（杂合子对中点的偏离）。在 Hardy-Weinberg 平衡下，群体平均基因型值为

$$M = p^2a + 2pqd - q^2a = a(p - q) + 2pqd. \quad (7.1)$$

例 7.1 小鼠的侏儒基因

小鼠的侏儒基因 pg 是一个大效应位点。设野生型等位基因 $+$ 的频率 $p = 0.7$ ，三种基因型 $++$ 、 $+pg$ 、 $pgpg$ 的平均体重分别为 14、12 与 6 克。纯合子中点 $\mu = (14 + 6)/2 = 10$ ，于是 $a = 4$ ， $d = 2$ 。由式 (7.1)， $M = 4 \times 0.4 + 2 \times 0.21 \times 2 = 2.44$ ，群体平均体重为 $10 + 2.44 = 12.44$ 克，与按基因型频率直接加权计算的 $0.49 \times 14 + 0.42 \times 12 + 0.09 \times 6 = 12.44$

相同。

以群体均值为原点时，三种基因型的值为 +1.56、-0.44、-6.44；以中点为原点时为 +4、+2、-4。原点的选择不影响任何关于个体间差异的结论，因为它只是给每个个体加上同一个常数。

大多数 QTL 的效应远小于侏儒基因，无法通过表型直接看出其分离，只能借助标记统计地检测。第 9 章将从单位点模型出发，系统推导平均效应、育种值与遗传方差。本章只需要 a 与 d 两个参数。

7.3 单标记分析

7.3.1 回交群体

设近交系 P_1 的基因型为 MQ/MQ ， P_2 为 mq/mq ， Q 为提高表型的 QTL 等位基因。 F_1 为 MQ/mq ，与 P_2 回交。设标记与 QTL 之间的重组率为 c 。回交后代按 F_1 配子分为四类（表 7.1）。

表 7.1 回交群体中的标记基因型与 QTL 基因型

F_1 配子	频率	后代基因型	期望表型
MQ	$\frac{1}{2}(1-c)$	$MmQq$	$\mu + d$
mq	$\frac{1}{2}(1-c)$	$mmqq$	$\mu - a$
Mq	$\frac{1}{2}c$	$Mmqq$	$\mu - a$
mQ	$\frac{1}{2}c$	$mmQq$	$\mu + d$

按标记基因型分组，

$$\bar{Y}_{Mm} = \mu + (1-c)d - ca, \quad \bar{Y}_{mm} = \mu - (1-c)a + cd,$$

$$\bar{Y}_{Mm} - \bar{Y}_{mm} = (1-2c)(a+d). \quad (7.2)$$

标记基因型均值之差是 QTL 效应 $(a+d)$ 乘以衰减因子 $(1-2c)$ 。若标记与 QTL 不连锁 ($c = 0.5$)，差异为零；若标记正好位于 QTL 处 ($c = 0$)，

差异等于 QTL 效应。由于回交群体只经历了一轮重组，即使 $c = 0.2$ ，标记仍显示 60% 的 QTL 效应。这就是杂交群体中“稀疏标记即可检测 QTL”的原因；通常建议每 20 厘摩一个标记，使任何 QTL 与最近标记的距离不超过 10 厘摩。

7.3.2 F_2 群体

在 F_2 中，每个后代携带两个 F_1 配子，标记三种基因型的期望值可以通过列举十六种配子组合得到：

$$\bar{Y}_{MM} = \mu + (1 - c)^2 a + 2c(1 - c)d - c^2 a,$$

$$\bar{Y}_{Mm} = \mu + [c^2 + (1 - c)^2]d,$$

$$\bar{Y}_{mm} = \mu + c^2 a + 2c(1 - c)d - (1 - c)^2 a.$$

由此可以构造两个对比：

$$\frac{\bar{Y}_{MM} - \bar{Y}_{mm}}{2} = (1 - 2c)a, \quad \bar{Y}_{Mm} - \frac{\bar{Y}_{MM} + \bar{Y}_{mm}}{2} = (1 - 2c)^2 d. \quad (7.3)$$

加性效应按 $(1 - 2c)$ 衰减，显性效应按 $(1 - 2c)^2$ 衰减，显性效应在标记处更难检测。以三组均值的单因素方差分析（自由度 2）或以两个对比为自变量的回归检验标记效应。

7.3.3 单标记分析的局限

式 (7.2) 与 (7.3) 揭示了单标记分析的根本缺陷：**QTL 的位置与效应是混杂的**。若 F_2 中某标记的加性对比为 10 千克，可能是 QTL 恰在标记处、 $a = 10$ ；也可能 QTL 在 $c = 0.25$ 处、 $a = 20$ ；还可能在两者之间的任何组合；而且 QTL 可能在标记的任一侧。只用一个标记无法区分这些可能。

若对一条染色体上的多个标记分别分析，得到加性对比依次为 5、10、10、5、2.5，则可以推断 QTL 最可能位于第二与第三个标记之间——尽管不能排除多个 QTL 的可能。这一直观推理正是区间作图的出发点：同时利用 QTL 两侧的侧翼标记，把位置与效应分开估计。

7.4 区间作图

7.4.1 侧翼标记给出的 QTL 基因型概率

设 QTL 位于标记 M 与 N 之间, $M-Q$ 的重组率为 c_1 , $Q-N$ 为 c_2 , $M-N$ 为 θ 。在无干涉时 $\theta = c_1 + c_2 - 2c_1c_2$ 。以回交为例, F_1 产生的配子按 M 、 Q 、 N 三个位点的组合分为八类, 其频率为

$$\frac{1}{2}(1-c_1)(1-c_2), \frac{1}{2}c_1c_2, \frac{1}{2}(1-c_1)c_2, \frac{1}{2}c_1(1-c_2) \text{ 等.}$$

在已知侧翼标记基因型的条件下, 后代为 Qq 的概率为

$$\begin{aligned} \Pr(Qq | MN) &= \frac{(1-c_1)(1-c_2)}{1-\theta}, & \Pr(Qq | Mn) &= \frac{(1-c_1)c_2}{\theta}, \\ \Pr(Qq | mN) &= \frac{c_1(1-c_2)}{\theta}, & \Pr(Qq | mn) &= \frac{c_1c_2}{1-\theta}. \end{aligned}$$

其中 MN 表示后代从 F_1 获得了 M 与 N (两侧均为亲本 P_1 型), 依此类推。两侧标记都为 P_1 型的个体, 除非发生双重重组, 几乎必然携带 Q ; 两侧标记类型不同的个体 (侧翼标记之间发生了重组), 其 QTL 基因型的概率取决于 QTL 在区间中的相对位置。对 F_2 , QTL 三种基因型在九种侧翼标记基因型下的条件概率可以用同样的方法推导, 或者由第 6 章的隐马尔可夫模型统一计算, 后者还能处理缺失标记与非完全信息标记。

7.4.2 回归区间作图

哈利与诺特 (1992) 提出了一种简单而高效的方法。以回交为例, 设在某一假定位置, 个体 i 为 Qq 的条件概率为 X_i , 则

$$E(Y_i | \text{标记}) = (\mu + d)X_i + (\mu - a)(1 - X_i) = (\mu - a) + (a + d)X_i.$$

于是可以拟合线性回归 $Y_i = m + b_Q X_i + e_i$, 回归系数的期望为 $a + d$ 。对 F_2 ,

$$Y_i = \mu + b_a X_{a,i} + b_d X_{d,i} + e_i, \quad X_{a,i} = \Pr(QQ) - \Pr(qq), \quad X_{d,i} = \Pr(Qq), \quad (7.4)$$

$E(b_a) = a$, $E(b_d) = d$ 。在染色体上以 1 厘摩为步长, 对每个假定位置拟合式 (7.4), 计算检验 QTL 存在的 F 统计量或 LOD 值

$$\text{LOD}(x) = \frac{N}{2} \log_{10} \frac{\text{RSS}_0}{\text{RSS}(x)},$$

把 LOD 对位置作图, 得到 **LOD 剖面**。LOD 最大的位置即 QTL 位置的估计, 对应的回归系数为效应估计。

回归方法的优点是计算极为简便, 可以直接扩展到多个 QTL、协变量与固定效应, 也易于进行置换检验。其代价是: 式 (7.4) 的残差方差实际上随个体而异——侧翼标记信息完全时 QTL 基因型几乎确定, 残差方差接近 σ_e^2 ; 信息不完全时, QTL 基因型的不确定性额外增加残差变异——而普通最小二乘忽略了这种异方差。在标记密度适中、QTL 效应不很大时, 这一近似的影响很小。

7.4.3 最大似然区间作图

兰德与博特斯坦 (1989) 最早提出的区间作图使用最大似然法。在假定位置, 个体的 QTL 基因型未知, 其表型分布是以各 QTL 基因型条件概率为权重的正态混合:

$$f(Y_i | \text{标记}) = \sum_{k \in \{QQ, Qq, qq\}} \text{Pr}(k | \text{标记}_i) \phi(Y_i; \mu_k, \sigma^2). \quad (7.5)$$

似然是所有个体混合密度的乘积。这又是一个缺失资料问题: 若 QTL 基因型已知, 问题只是三组均值与一个公共方差的估计。EM 算法的 E 步计算每个个体属于各 QTL 基因型的后验概率

$$w_{ik} = \frac{\text{Pr}(k | \text{标记}_i) \phi(Y_i; \mu_k, \sigma^2)}{\sum_{k'} \text{Pr}(k' | \text{标记}_i) \phi(Y_i; \mu_{k'}, \sigma^2)},$$

M 步以 w_{ik} 为权重更新 μ_k 与 σ^2 。注意后验概率 w_{ik} 不同于先验的条件概率 $\text{Pr}(k | \text{标记})$: 它还利用了个体自身的表型。表型很高的个体, 属于高值 QTL 基因型的后验概率就大。这正是最大似然法比回归法多利用的信息: 回归只利用了各标记类别的表型均值, 而似然还利用了表型分布的形状。当

QTL 效应很大、表型分布呈明显多峰时，这部分信息有用；对大多数效应中等的 QTL，两种方法的结果几乎相同，而回归法对非正态残差更稳健、计算快得多。

7.4.4 一个模拟的 F_2 资料

模拟 500 个 F_2 个体，一条 50 厘摩的染色体上每 10 厘摩一个标记，QTL 位于 23 厘摩， $a = 1$ 、 $d = 0.5$ ，环境标准差为 2。QTL 解释的表型方差为 $(\frac{1}{2}a^2 + \frac{1}{4}d^2)/(\frac{1}{2}a^2 + \frac{1}{4}d^2 + 4) = 12.3\%$ 。

单标记分析中，六个标记的加性对比依次为 0.63、0.77、0.79、0.75、0.66、0.57，与理论期望 $(1 - 2c)a$ 的 0.63、0.77、0.94、0.87、0.71、0.58 大体一致；所有标记都显著，最强的是 20 与 30 厘摩处的标记，提示 QTL 位于二者之间。Haley-Knott 区间作图的 LOD 剖面（图 7.1A）在 16 厘摩处达到最大值 9.31，估计 $\hat{a} = 0.87$ 、 $\hat{d} = 0.28$ ；LOD 下降 1 的支持区间为 11 至 27 厘摩，包含真实位置。同一位置的最大似然估计为 $\hat{a} = 0.88$ 、 $\hat{d} = 0.30$ ，LOD 为 9.49，与回归法非常接近。




图 7.1 F_2 群体的区间作图。A 图为一次模拟 ($N = 500$) 的 Haley-Knott LOD 剖面、单标记分析结果、置换检验阈值与 LOD-1 支持区间；B 图为同一染色体上两个连锁 QTL 时的区间作图（同相与反相）以及复合区间作图结果，绿色点线为真实 QTL 位置

为了看清定位的精度，重复模拟十次。估计位置的均值为 22.1 厘摩，标准差 3.0 厘摩； $\hat{a}$ 的均值 1.02、标准差 0.12； $\hat{d}$ 的均值 0.48、标准差 0.15。效应估计平均而言是准确的，而位置估计在不同重复间相差可达十厘摩以上。

这一结果说明了杂交群体 QTL 定位的典型特征：**检测容易，定位粗糙。**

7.5 显著性阈值

7.5.1 多重检验问题

区间作图在每个位置都进行一次检验，全基因组以 1 厘摩为步长有数千次检验。若以逐点的 5% 水平为标准，即使没有任何 QTL，也几乎必然出现若干“显著”位置。但由于同一染色体上相邻位置的检验高度相关，Bonferroni 校正又过于保守。

兰德与克鲁格利亚克（1995）基于连续参数随机过程的极值理论，给出了在密集标记下的全基因组阈值。对小鼠大小的基因组，回交群体显著连锁（全基因组 5% 错误率）的 LOD 阈值约为 3.3， F_2 群体（加性与显性两个自由度）约为 4.3；“提示性连锁”（每次全基因组扫描期望出现一次假阳性）的阈值分别约为 1.9 与 2.8。这些数值依赖于基因组长度、群体类型和标记密度，在其他物种中需要相应调整。

7.5.2 置换检验

丘吉尔与多尔格（1994）的置换检验（第 3 章）是确定阈值最通用的方法：随机打乱表型与个体的对应，保持标记资料不变，对置换后的资料进行完整的区间作图扫描，记录全染色体（或全基因组）的最大 LOD；重复数百至数千次，取最大 LOD 分布的 95% 分位数作为 5% 阈值。在上面的模拟中，300 次置换得到单条 50 厘摩染色体的 5% 阈值为 LOD 1.96，1% 阈值为 2.39；而逐点检验的 5% 阈值仅为 1.30（图 7.2A）。全基因组阈值则需要在每次置换中记录全部染色体的最大值，通常比单条染色体的阈值高出一至两个 LOD 单位。

置换检验自动适应资料的实际情况：标记密度与信息量、缺失资料、表型分布的偏态，乃至群体大小。它的前提是零假设下个体可交换；若资料中存在家系结构或必须校正的固定效应，应在层内置换或对残差置换。




图 7.2 置换检验与 Beavis 效应。A 图为 300 次置换资料中全染色体最大 LOD 的分布及其 95% 分位数，与逐点 5% 界限比较；B 图为不同群体大小下检测一个解释 1.5% 表型方差的 QTL 的功效，以及显著结果中效应估计相对真值的高估倍数

7.6 多个 QTL：幽灵 QTL 与复合区间作图

7.6.1 单 QTL 模型的偏差

区间作图假定染色体上只有一个 QTL。当同一染色体上有两个连锁 QTL 时，这一假定会导致严重的偏差。在回交中，标记的期望对比是两个 QTL 效应的加权和：

$$E(\bar{Y}_{Mm} - \bar{Y}_{mm}) = (1 - 2c_1)(a_1 + d_1) + (1 - 2c_2)(a_2 + d_2).$$

若两个 QTL 处于同相（增效等位基因来自同一个亲本），位于它们之间的标记同时捕获两个 QTL 的效应，LOD 峰值可能出现在两个 QTL 之间的位置，形成并不存在的“幽灵 QTL”；若处于反相，两个效应相互抵消，可能一个 QTL 也检测不到。

图 7.1B 中，在一条 100 厘摩的染色体上于 25 厘摩与 65 厘摩处各放置一个 $a = 0.6$ 的加性 QTL。同相时，区间作图的 LOD 在整个 20 至 70 厘摩范围内都非常高，最大值出现在 35 厘摩，即两个 QTL 之间；在两个 QTL 之间的 45 厘摩处 LOD 仍高达 25.0。反相时，最大 LOD 只有 4.7，且位置不准。

7.6.2 复合区间作图

曾昭邦(1994)与扬森(1993)各自独立提出的**复合区间作图**(CIM)或多 QTL 模型(MQM)在区间作图模型中加入其他位置的标记作为协变量,以吸收其他 QTL 的效应:

$$Y_i = \mu + b_a X_{a,i} + b_d X_{d,i} + \sum_{k \in C} \beta_k M_{k,i} + e_i. \quad (7.6)$$

协变量集合 C 通常由前向逐步回归在全基因组标记中选出,检验某个位置时剔除距离该位置一定窗口(如 10 厘摩)以内的协变量,以免它们“吸收”待检 QTL 本身的效应。协变量的作用有两方面:控制同一染色体上其他连锁 QTL 造成的偏差;吸收其他染色体上 QTL 的效应,降低残差方差,提高检测功效。

在图 7.1B 的例子中,逐步回归选出 30 与 60 厘摩处的标记为协变量。CIM 剖面在两个 QTL 附近各出现一个峰(约 33 厘摩与 65 厘摩),LOD 分别约为 6.5 与 7.8,而在 45 厘摩处 LOD 降至 0.36,幽灵峰消失。协变量剔除窗口的边界在剖面上造成了不连续的跳跃,这是 CIM 的一个已知特征。

CIM 的局限在于协变量选择没有唯一最优方案,结果对窗口大小和协变量数目有一定敏感性。考、曾与蒂斯代尔(1999)提出的**多区间作图**(MIM)把多个 QTL 同时纳入模型,用最大似然估计所有 QTL 的位置、效应及其上位互作,并以信息准则或置换检验决定 QTL 个数。贝叶斯方法则把 QTL 个数也视为未知参数,用可逆跳跃马尔可夫链蒙特卡洛对模型空间进行抽样。这些方法在概念上更为完整,在计算上则更为复杂。

7.7 定位精度与提高分辨率的设计

7.7.1 置信区间的近似

QTL 位置估计的不确定性可以用 LOD 下降 1 或 1.5 的支持区间表示,也可以用自助法估计。达尔瓦西与索勒(1997)给出了一个简单的近似:在标记无限密集时,95% 置信区间的长度(厘摩)约为

$$CI_{95} \approx \frac{3000}{kN\delta^2}, \quad (7.7)$$

其中 N 为群体大小, δ 为以表型标准差为单位的 QTL 替代效应, 回交 $k = 1$, F_2 $k = 2$ 。对 $N = 500$ 、 $\delta = 0.5$ 的 F_2 群体, 置信区间约 12 厘摩; 回交约 24 厘摩。对效应较小的 QTL, 区间迅速变宽。

式 (7.7) 中没有标记密度。原因在于, F_2 与回交个体只经历了一轮重组, 每个个体从 F_1 继承的都是很长的染色体片段, 相邻位置的 QTL 基因型几乎相同; 即使标记无限密集, 也无法区分 QTL 究竟在片段中的哪个位置。提高分辨率的唯一途径是增加有效的重组事件: 要么增大群体, 要么让群体经历更多轮重组。

7.7.2 积累重组的群体

高世代互交系 (AIL) 由 F_2 个体随机交配多代形成。 t 代后, F_t 个体之间的重组率相当于经历了约 $t/2$ 轮减数分裂的累积, 相当于把遗传图谱“拉长”。达尔瓦西与索勒估计, F_{10} 高世代互交系的置信区间约缩短为 F_2 的五分之一。

重组自交系 (RIL) 由 F_2 个体经连续自交或同胞交配至纯合形成。每个 RIL 是两个亲本基因组的一个固定镶嵌, 可以无限复制并在多个环境中重复测定。在重组自交系中, 两个位点最终为重组型的概率高于单次减数分裂的重组率: 自交系为 $R = 2c/(1 + 2c)$, 同胞交配系为 $R = 4c/(1 + 6c)$ 。相应地, RIL 群体的图谱约扩展为原来的 2 倍 (自交) 或 4 倍 (同胞交配)。

更进一步, **多亲本群体** 如小鼠的协作杂交 (Collaborative Cross)、玉米的巢式关联作图群体 (NAM)、拟南芥与小麦的 MAGIC 群体, 把多个亲本的等位基因组合到同一个群体中, 既保留了杂交设计的高检测功效与平衡的等位基因频率, 又通过多世代互交积累重组, 提高了分辨率, 同时扩大了等位基因多样性。

这些群体在提高分辨率的同时也缩短了 LD 的范围, 因此需要更高的标记密度才能保持检测功效。连锁不平衡的范围、标记密度与分辨率之间的这种权衡, 贯穿于所有基因定位设计之中。

7.8 品种杂交的 QTL 定位

家畜中无法获得近交系，QTL 定位常常利用差异很大的两个品种之间的 F_2 杂交。一个典型的设计是猪的伯克夏 × 约克夏杂交：2 头伯克夏公猪与 9 头约克夏母猪交配产生 F_1 ，再由 8 头 F_1 公猪与 26 头 F_1 母猪互交，产生 525 头 F_2 。其他著名的例子包括欧洲野猪 × 大白猪、梅山猪 × 大白猪、白洛克 × 红色原鸡等杂交，许多影响生长、脂肪沉积和肉质的 QTL 最初就是在这类群体中发现的。

品种杂交与近交系杂交有两个重要区别。

第一，品种内不纯合。品种并非在标记与 QTL 上都固定，同一个标记等位基因可能同时存在于两个品种中，此时 F_2 个体的某个等位基因究竟来自哪个品种并不确定。哈利、诺特与艾尔森（1994）提出的方法利用 F_0 与 F_1 的基因型以及侧翼标记的信息，为每个 F_2 个体在每个位置计算“品种来源概率”： P_{BB} 、 P_{BY} 、 P_{YB} 、 P_{YY} ，其中 P_{BY} 表示父源等位基因来自伯克夏、母源来自约克夏的概率。随后以与近交系 F_2 完全相同的方式，用 $P_{BB} - P_{YY}$ 与 $P_{BY} + P_{YB}$ 作为加性与显性协变量进行回归区间作图。

第二，品种内 QTL 可能仍在分离。设 QTL 等位基因 Q 在两个品种中的频率分别为 p_B 与 p_Y ，则品种杂交区间作图估计的“加性效应”实际上是

$$a_{\text{杂交}} = (p_B - p_Y)a + (p_Bq_B - p_Yq_Y)d, \quad d_{\text{杂交}} = (p_B - p_Y)^2d,$$

这可以通过分别计算 F_2 中“两个等位基因都来自伯克夏”“都来自约克夏”与“各来自一个品种”三类个体的期望基因型值直接推导。显性可以忽略时， $a_{\text{杂交}} = (p_B - p_Y)a$ ，比较的是“平均伯克夏等位基因”与“平均约克夏等位基因”的效应差异。只有两个品种之间频率差异较大的 QTL 才能被检测到；在两个品种中频率相近的 QTL，即使效应很大也检测不到。这一性质决定了品种杂交 QTL 的应用价值：它们解释品种之间的差异，但不一定在商业品系内部分离。要把品种杂交中发现的 QTL 用于品系内的标记辅助选择，必须在品系内部重新验证其分离与效应，并通过连锁分析或关联分析进一步精细定位（第 8 章）。

品种杂交的标记往往并非完全信息，复合区间作图中以标记为协变量的

做法因而不易实施。替代方法是直接拟合两 QTL 模型：固定第一个 QTL 于最佳位置，扫描第二个 QTL 的位置，以似然比检验比较二 QTL 与一 QTL 模型。

7.9 选择性基因分型与 DNA 混池

QTL 定位的大部分信息来自表型极端的个体：若 QTL 增加表型，则表型高的个体携带增效等位基因的概率较大，与之连锁的标记等位基因频率也随之升高。**选择性基因分型**只对群体两端（如最高与最低各 10% 至 20%）的个体分型，就能保留大部分检测功效，从而大幅降低分型成本。以表型标准化后的期望信息计算，对上下各 25% 的个体分型，可保留全部分型约 80% 至 90% 的功效。代价是：效应估计必须用考虑选择的似然方法，否则因只用极端个体而被高估；且这些个体的基因型资料不能直接用于其他性状的分析。

DNA 混池（或称集团分离分析，BSA）更进一步：把高表型组与低表型组个体的 DNA 分别等量混合，只测定两个混池中标记等位基因的频率差异。在植物中，BSA 与高通量测序结合（如 QTL-seq 方法）可以快速定位影响质量性状或效应较大的数量性状的区域。混池方法的误差来源包括混池时各个体 DNA 量的不均与测序抽样，需要设置技术重复。

7.10 Beavis 效应

QTL 定位文献中一个反复出现的现象是：最初报告的 QTL 效应，往往在后续研究中无法重复，或者效应大幅缩小。比维斯（1994）用模拟清楚地揭示了其原因：在功效较低的研究中，只有那些因抽样误差而效应被高估的 QTL 才能超过显著阈值，因此被报告的 QTL 效应系统性偏高。这正是第 3 章讨论的“赢家诅咒”在 QTL 定位中的具体表现。

图 7.2B 模拟了一个解释 1.5% 表型方差的 QTL 在回交中的检测（以 $p < 0.001$ 为显著标准）。100 个后代时功效仅 2%，而显著结果中效应估计的平均值是真实值的近三倍；200 个后代时功效 6%，高估约一倍；500 个后代

时功效 32%，高估约 40%；1000 个后代时功效 75%，高估降至约 10%。功效越低，被报告的效应越夸大。比维斯指出，当群体只有 100 个个体时，即使真实 QTL 只解释很小的方差，检测到的 QTL 也常常被报告为解释 10% 以上的方差。

Beavis 效应有几个重要推论。其一，早期小群体研究报告的“少数大效应 QTL”图景，在相当程度上是统计假象；后来的大样本研究与全基因组关联研究揭示，大多数数量性状受大量小效应位点控制（第 8 章、第 25 章）。其二，由检测样本估计的 QTL 效应不能直接用于预测标记辅助选择的效果，否则会高估选择反应。其三，可靠的效应估计需要在独立样本中验证，或者采用条件似然、收缩估计等方法校正选择偏差。

7.11 从 QTL 到 QTN

区间作图得到的 QTL 区域通常长达十几至数十厘摩，包含数百个基因。从 QTL 区域到致因突变，需要一系列逐步缩小范围的工作：在大群体、高世代互交群体或远交群体中进行精细定位；利用 LD 与单倍型共享缩小候选区间；结合比较基因组学、功能注释与表达资料筛选候选基因；最后通过功能试验（如基因编辑、等位基因特异表达、报告基因试验）确认因果关系。这一过程可能需要十年以上，但已经在家畜中取得了若干经典的成功。

家畜中从 QTL 到 QTN 的经典案例

猪的氟烷基因 (RYR1)。猪应激综合征表现为应激时的恶性高热与肉质变差 (PSE 肉)，曾以氟烷麻醉试验检测。1991 年藤井等证明，骨骼肌钙释放通道基因 *RYR1* 上的一个点突变 (Arg615Cys) 是其致因，从此可以直接进行 DNA 检测，许多种猪公司很快把这一等位基因从种群中清除。

牛的 *DGAT1* K232A。在奶牛第 14 号染色体着丝粒附近，多个研究检测到对乳脂率有巨大效应的 QTL。2002 年格里萨尔等证明，*DGAT1* 基因的一个赖氨酸到丙氨酸的替换 (K232A) 是致因变异：K 等位基因提高乳脂率，降低产奶量与乳蛋白量。这是最早在家畜中被确认的数量性状核苷酸之一。

猪的 *IGF2* 内含子突变。在野猪 × 大白猪杂交中发现的一个影响肌肉生长与背膘的 QTL 表现出父系印记，即只有从父本遗传时才表达效应。2003 年范拉尔等证

明，致因是 *IGF2* 第 3 内含子中一个高度保守的核苷酸替换，它破坏了一个转录抑制因子的结合位点，使出生后肌肉中 *IGF2* 表达上调约三倍。

双肌性状与肌肉生长抑制素 (*MSTN*)。比利时蓝牛、皮埃蒙特牛等品种的“双肌”表型，由肌肉生长抑制素基因的不同功能缺失突变造成；特克赛尔绵羊的肌肉发达则由 *MSTN* 3' 非翻译区的一个突变产生了新的微 RNA 结合位点所致。

这些案例有一个共同特点：致因变异的效应都相当大。对效应小的大多数 QTL，逐个定位到核苷酸既不现实，也未必必要；第 26—27 章的基因组选择正是绕开这一步、直接利用全基因组标记预测遗传价值的策略。

7.12 QTL 定位结果的解释

QTL 定位的结果需要在几个层次上谨慎解释。

群体特异性。QTL 的效应是相对于特定杂交组合、特定遗传背景与环境而言的。一个在某杂交组合中显著的 QTL，在另一组合中可能不分离；一种在一种环境中表现显著的 QTL，在另一环境中可能效应不同。QTL× 背景与 QTL× 环境互作在植物多环境试验中普遍存在。

多效性与紧密连锁。若一个区域同时影响多个性状，可能是一个基因的多效性，也可能是几个紧密连锁基因各自的效应。在杂交群体有限的分辨率下，这两种情形无法区分，但对育种的意义截然不同：多效性意味着性状之间存在不可分离的遗传相关；紧密连锁则可以通过重组打破。

方差解释比例。一个 QTL“解释的表型方差”依赖于它在该群体中的等位基因频率、该群体的总方差以及估计偏差。 F_2 中等位基因频率为 0.5，方差解释比例最大；同一 QTL 在频率不同的商业群体中解释的方差可能小得多。

未检测到不等于不存在。QTL 研究只能检测到效应超过一定大小的位点。被检测到的 QTL 的总效应通常只能解释遗传方差的一部分，其余部分来自大量效应低于检测阈值的位点。这正是第 25 章讨论的“缺失遗传力”问题的早期版本。

7.13 本章小结

QTL 定位利用标记与 QTL 之间的连锁不平衡, 通过比较不同标记基因型个体的表型来推断 QTL 的存在、位置与效应。近交系或品种杂交一次产生延伸很远的 LD, 使稀疏标记即可检测 QTL。单标记分析中, 回交的标记对比为 $(1-2c)(a+d)$, F_2 的加性与显性对比分别按 $(1-2c)$ 与 $(1-2c)^2$ 衰减, 位置与效应混杂。区间作图利用侧翼标记计算 QTL 基因型的条件概率, 回归法以这些概率为自变量, 最大似然法把表型建模为正态混合, 二者通常给出相近的结果。显著性阈值应控制全染色体或全基因组的错误率, 置换检验是最通用的方法。连锁 QTL 会造成幽灵峰或相互抵消, 复合区间作图与多区间作图通过引入协变量或同时拟合多个 QTL 解决这一问题。杂交群体的定位精度主要受重组事件数目限制, 置信区间常达十至数十厘摩, 高世代互交系、重组自交系与多亲本群体可以提高分辨率。品种杂交只能检测品种间频率不同的 QTL; Beavis 效应使低功效研究中报告的 QTL 效应系统偏高。从 QTL 到 QTN 需要精细定位与功能验证, 家畜中已有若干经典成功案例。

7.14 习题

习题 7.1 在回交群体中, 标记 Mm 与 mm 两组的平均表型分别为 52.4 与 49.0。若 QTL 恰在标记处, $a+d$ 为多少? 若 QTL 与标记的重组率为 0.15, $a+d$ 为多少?

习题 7.2 推导 F_2 群体中标记基因型 MM 的期望表型 $\bar{Y}_{MM} = \mu + (1-c)^2a + 2c(1-c)d - c^2a$ 。

习题 7.3 回交群体中, 侧翼标记 M 、 N 相距 20 厘摩, QTL 位于距 M 8 厘摩处。按霍尔丹函数计算 c_1 、 c_2 、 θ , 并求四种侧翼标记类型下后代为 Qq 的条件概率。

习题 7.4 说明为什么在回归区间作图中, 标记位置处的检验与单标记分析等价, 而在标记之间的位置则不同。

习题 7.5 某 F_2 群体有 800 个个体, QTL 的替代效应为 0.3 个表型标准差。按达尔瓦西—索勒近似, 95% 置信区间约多长? 若要把区间缩短到 5

厘摩，需要多大的群体？

习题 7.6 品种 A 与 B 中某 QTL 增效等位基因的频率分别为 0.9 与 0.3，真实加性效应 $a = 2$ 。品种杂交 F_2 区间作图估计的加性效应期望约为多少？若两个品种的频率均为 0.5 呢？

习题 7.7 设计一个模拟试验，说明为什么在群体较小时报告的 QTL 效应会偏高，并给出纠正这一偏差的两种方法。

7.15 习题解答

7.1 QTL 在标记处： $a + d = 3.4$ 。 $c = 0.15$ 时， $(1 - 0.3)(a + d) = 3.4$ ， $a + d = 4.86$ 。

7.2 MM 个体的两个配子都携带 M。每个配子携带 Q 的概率为 $1 - c$ ，携带 q 的概率为 c ，两个配子独立。因此 QQ 的概率为 $(1 - c)^2$ ，Qq 为 $2c(1 - c)$ ，qq 为 c^2 ，期望表型即为所给表达式。

7.3 $c_1 = \frac{1}{2}(1 - e^{-0.16}) = 0.0739$ ， $c_2 = \frac{1}{2}(1 - e^{-0.24}) = 0.1067$ ， $\theta = \frac{1}{2}(1 - e^{-0.4}) = 0.1648$ （亦可由 $c_1 + c_2 - 2c_1c_2$ 验证）。 $\Pr(Qq | MN) = 0.9261 \times 0.8933 / 0.8352 = 0.991$ ； $\Pr(Qq | Mn) = 0.9261 \times 0.1067 / 0.1648 = 0.600$ ； $\Pr(Qq | mN) = 0.0739 \times 0.8933 / 0.1648 = 0.400$ ； $\Pr(Qq | mn) = 0.0739 \times 0.1067 / 0.8352 = 0.0094$ 。

7.4 在标记位置处，QTL 基因型的条件概率由该标记的基因型唯一确定（若标记完全信息，概率为 0 或 1），回归模型退化为以标记基因型为自变量的方差分析，与单标记分析相同。在标记之间，条件概率同时依赖两个侧翼标记，提供了关于 QTL 位置的额外信息。

7.5 $CI \approx 3000 / (2 \times 800 \times 0.09) = 20.8$ 厘摩。要求 $3000 / (2N \times 0.09) = 5$ ， $N \approx 3333$ 。

7.6 $(0.9 - 0.3) \times 2 = 1.2$ 。频率相同时期望为零，QTL 无法在该杂交中检测到。

7.7 在一个已知真实效应的模型下重复模拟许多次小样本资料，只记录显著结果的效应估计，比较其平均值与真值，即可看到高估（参见图 7.2B）。

纠正方法包括：在独立的验证样本中重新估计效应；使用以显著性为条件的条件似然估计或贝叶斯收缩估计。

远交群体的连锁分析、关联定位与全基因组关联研究

8.1 远交群体中定位 QTL 的基本困难

家畜、人类、野生动物以及许多异交植物都是远交群体，无法像近交系那样设计杂交。第 7 章的方法在这里不能直接套用，原因可以从第 5 章的连锁不平衡理论得到清楚的解释：在一个经历了许多世代随机交配的群体中，除非标记与 QTL 非常紧密地连锁，二者在群体水平上处于近似连锁平衡；一个随机选取的标记，其等位基因与 QTL 等位基因之间几乎没有关联。即使标记与 QTL 相距只有几厘摩，在群体中按标记基因型分组比较表型，也往往看不到差异。

然而，连锁不平衡总是存在于**家系内部**。考虑一头在标记与 QTL 上都杂合的公畜 MQ/mq 。它的后代从它那里获得的配子中，亲本型 MQ 与 mq 占 $1-c$ ，重组型占 c 。在这一公畜的后代中，获得 M 的个体倾向于获得 Q ——这与回交群体完全相同，只经历了一轮重组，因而在相当远的距离上保持着关联。另一头公畜若为 Mq/mQ ，其后代中获得 M 的个体则倾向于获得 q 。这就是远交群体中两类定位策略的根本差别：

连锁分析利用家系内近期产生的 LD，经历的重组轮数少，LD 范围大，标记可以稀疏，但定位分辨率低，且标记—QTL 的相位因家系而异；

关联分析 (LD 定位)利用群体中历史形成的 LD，经历了大量重组，LD 范围小，需要很高的标记密度，但定位分辨率高，且关联在群体中具有一致的方向。

这两种策略并非互斥。连锁分析可以在较大区域内确认 QTL 的存在，关联分析在该区域内进一步精细定位；而结合连锁与 LD 信息的方法，可以同

时利用两者的优势。本章依次讨论家系设计的连锁分析、扩展系谱的方差组分方法与全基因组关联研究。

8.2 半同胞家系设计

8.2.1 公畜内嵌套的区间作图

家畜中最常见的连锁分析资料是大的半同胞家系：每头公畜通过人工授精产生数十至数百个后代，而每个后代的母亲各不相同。对每头公畜，可以把它看作一个“回交的 F_1 ”：后代从公畜获得的单倍型，相当于回交后代从 F_1 获得的配子。母亲贡献的单倍型对于检测公畜的 QTL 杂合性而言只是背景噪声。

关键的区别在于：不同公畜的标记—QTL 相位不同，甚至有的公畜在 QTL 上是纯合子而根本不分离。因此 QTL 效应必须在公畜内估计。设第 i 头公畜的第 j 个后代的表型为 Y_{ij} ，在假定 QTL 位置，后代从公畜获得公畜第一条单倍型上 QTL 等位基因的条件概率为 $P_{Q,ij}$ （由公畜的相位与后代的侧翼标记基因型计算，方法与回交完全相同），则模型为

$$Y_{ij} = \mu_i + \alpha_{Q,i}P_{Q,ij} + e_{ij}, \quad (8.1)$$

其中 μ_i 为公畜家系均值， $\alpha_{Q,i}$ 为第 i 头公畜两条单倍型上 QTL 等位基因的替代效应。若公畜在 QTL 上纯合， $\alpha_{Q,i} = 0$ ；若杂合，其符号取决于相位。检验“所有公畜的 $\alpha_{Q,i}$ 都为零”，即嵌套在公畜内的 QTL 效应的 F 检验，分子自由度等于公畜数。在染色体上逐个位置扫描，就得到半同胞设计的区间作图（诺特等，1996）。

模拟 10 头公畜、每头 100 个后代，QTL 位于 47 厘摩，替代效应 0.5 个残差标准差，QTL 等位基因频率 0.5，因此约一半公畜为杂合子。区间作图的 F 统计量在 46 厘摩达到最大 ($F = 4.12$, $p = 1.4 \times 10^{-5}$)。表 8.1 列出各公畜在该位置的效应估计：真实杂合的六头公畜，效应估计的绝对值都在 0.38 至 0.79 之间，符号有正有负，反映了不同的连锁相位；四头纯合公畜中有三头的估计接近零，另一头由于抽样误差达到 -0.37 ，单凭这一头公畜的资料很难判断它是否杂合。




图 8.1 十头公畜、各一百个半同胞后代的公畜内嵌套回归区间作图。真实 QTL 位于 47 厘摩，约一半公畜在 QTL 上杂合

表 8.1 半同胞设计中各公畜的 QTL 替代效应估计

公畜	1	2	3	4	5	6	7	8	9	10
QTL 杂合	是	否	否	是	是	是	是	否	是	否
效应估计	-0.59	-0.02	-0.37	-0.60	0.43	-0.42	0.38	-0.01	0.79	0.04
标准误	0.20	0.19	0.25	0.21	0.22	0.21	0.23	0.22	0.25	0.20

这一例子揭示了家系内连锁分析结果在育种应用中的局限：有利的标记等位基因因家系而异，每个家系必须单独估计效应，而每个家系的估计精度有限。这正是标记辅助选择在二十世纪九十年代至二十一世纪初未能广泛应用的主要原因之一。

8.2.2 女儿设计与孙女儿设计

奶牛的产奶性状只能在母牛上测定, 但 QTL 定位关心的往往是公牛。韦勒、卡希与索勒 (1990) 比较了两种设计。**女儿设计**对杂合公牛及其女儿分型, 以女儿的产奶记录为表型; **孙女儿设计**对杂合祖父公牛及其儿子分型, 以儿子的后裔测定成绩 (基于大量女儿的平均) 为表型。由于儿子的后裔测定成绩是数十至数百个女儿的平均, 其遗传力远高于单个女儿的记录, 孙女儿设计在分型数量相同的情况下功效高得多。早期奶牛 QTL 研究——包括第 7 章提到的 *DGAT1* 区域的发现——大量采用了孙女儿设计。

8.2.3 各种设计的功效

在分型个体数相同时, 各设计的功效大致为: $F_2 > \text{回交} > \text{全同胞} > \text{半同胞}$ 。远交设计功效较低的原因有三: 亲本并非都在 QTL 上杂合, 杂合比例只有 $2pq$, 纯合亲本对检测该 QTL 毫无信息; 亲本的标记也不一定都是杂合的, 即标记信息不完全; 以及只有一个亲本 (半同胞设计) 的分离可以被追踪。因此, 远交群体的连锁分析通常需要一千个以上的分型个体。

8.3 扩展系谱与方差组分连锁分析

8.3.1 同祖同源与 QTL 方差

当资料来自多代、结构复杂的系谱时, 按家系嵌套的回归方法难以实施。另一种思路是把 QTL 效应视为随机效应, 利用标记推断的**位置特异同祖同源概率**来建模。设在假定位置 x , 个体 i 与 j 在该位置上同祖同源的等位基因比例的期望为 $\hat{\pi}_{ij}(x)$ (由标记与系谱计算), 则表型的协方差可以写为

$$\text{Cov}(Y_i, Y_j) = \hat{\pi}_{ij}(x)\sigma_q^2 + a_{ij}\sigma_A^2, \quad \text{Var}(\mathbf{Y}) = \mathbf{\Pi}(x)\sigma_q^2 + \mathbf{A}\sigma_A^2 + \mathbf{I}\sigma_e^2, \quad (8.2)$$

其中 σ_q^2 为该位置 QTL 的加性方差, $\mathbf{A}$ 为系谱加性关系矩阵, σ_A^2 为其余多基因方差。检验 QTL 即检验 $\sigma_q^2 = 0$, 用似然比统计量, 其零分布为 $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ 的混合 (第 3 章)。式 (8.2) 的思想是: 在 QTL 所在位置, 同祖同源比例高于系谱期望的亲属对, 若表型也更相似, 就说明该位置存在 QTL。

这一框架有三个优点：它不需要知道 QTL 等位基因的数目与相位，自然地适应多等位 QTL；它可以处理任意复杂的系谱与不平衡资料；它与第 21—23 章的混合模型和 REML 估计完全一致。阿尔梅西与布兰杰罗（1998）的 SOLAR 程序与乔治等的家畜方法都属于这一类。

8.3.2 Haseman–Elston 回归

方差组分方法的一个简化先驱是哈斯曼与埃尔斯顿（1972）的同胞对方法。对一对同胞，在 QTL 位置上同祖同源的等位基因比例 π 可以是 0、二分之一或 1。设只有加性 QTL 效应，两同胞表型差的平方的期望为

$$E[(Y_1 - Y_2)^2 | \pi] = 2\sigma_Y^2(1 - r_{\text{其余}}) - 2\sigma_q^2\pi + \text{常数} = \beta_0 - 2\sigma_q^2\pi. \quad (8.3)$$

同祖同源越多，表型差越小。于是把表型差的平方对标记推断的 $\hat{\pi}$ 回归，斜率显著为负即提示连锁，斜率的绝对值的一半估计 QTL 方差。这一方法在人类同胞对研究中曾被广泛使用，它直观地展示了基于同祖同源的连锁分析的本质。

8.3.3 植物育种群体的系谱分析

植物 QTL 定位主要基于单个近交系杂交，但实际的植物育种群体由多个亲本杂交组合构成，并具有多代系谱。把这些相互关联的杂交组合放在一起，用基于系谱的 QTL 分析方法联合分析，有几个好处：利用全部资料，提高检测与定位的功效；直接在优良的育种群体中检测 QTL；在相关的遗传背景中估计 QTL 的全部变异；并可分析 QTL 与遗传背景、QTL 与环境的互动。这一思路与多亲本群体（第 7 章）在本质上是一致的。

8.4 候选基因与连锁不平衡定位

家系内连锁分析的根本限制在于：有利的标记等位基因因家系而异，无法在整个群体中统一使用。要找到在全群体中都与 QTL 有一致关联的标记，标记必须非常接近 QTL。寻找这样的标记有两条途径。

候选基因途径依据生物学知识选择可能影响性状的基因，例如已知的生

理通路、在 QTL 区域内的位置、比较基因组学证据或表达资料，在基因内或其附近寻找多态性并检验其与表型的关联。猪的 *PRKAG3* 基因就是一个经典例子：汉普夏猪中的 RN^- 等位基因（R200Q）使肌糖原含量大幅升高、终点 pH 下降，是通过连锁分析与候选基因结合发现的。候选基因途径的成功依赖于生物学知识的准确性；在数量性状中，大量效应位点并不位于事先能够猜到的基因中。

高密度分型途径不依赖于事先的生物学假设，而是在全基因组放置足够的标记，使每个 QTL 附近都至少有一个标记与它处于足够的 LD 中。2000 年以后，测序与分型技术的革命使这一途径成为现实：人类单核苷酸多态图谱鉴定了数百万个 SNP；猪、牛、鸡等家畜的基因组测序完成后，商业化的 SNP 芯片可以在一次试验中分型五万至数十万个 SNP，成本迅速降到每个样本数十美元。全基因组关联研究（GWAS）由此诞生。

8.5 全基因组关联研究的统计模型

8.5.1 单标记回归

GWAS 的基本做法很简单：在从群体中随机抽取的个体上测定表型与全基因组标记，逐个标记检验基因型与表型的关联。对连续性状，最常用的模型是把等位基因拷贝数 $x_{ik} \in \{0, 1, 2\}$ 作为协变量：

$$y_i = \mu + \mathbf{w}_i' \boldsymbol{\gamma} + x_{ik} \beta_k + e_i, \quad (8.4)$$

$\mathbf{w}_i$ 为需要校正的固定效应（性别、批次、场等）， β_k 为标记 k 的加性效应，用 t 检验或 F 检验判断其是否为零。也可以把基因型作为三水平的分类变量，以 2 个自由度同时检验加性与显性；还可以用显性编码（携带与否）或隐性编码。加性编码的检验在多数情况下功效最高，因为它只消耗一个自由度，而且即使真实作用有显性，加性编码仍能捕获大部分效应（显性的一部分会进入平均效应，第 9 章）。

对二分类性状，常用逻辑斯蒂回归，或者在病例—对照设计中使用第 3 章的等位基因计数检验或 Cochran–Armitage 趋势检验。普塞尔等（2007）

开发的 PLINK 软件把这些检验与质量控制、群体结构分析统一在一个高效的框架中，成为人类与动植物 GWAS 中使用最广泛的工具之一。

8.5.2 标记效应与 QTL 效应的关系

由第 5 章，若标记 k 与 QTL 之间的 LD 为 r^2 ，QTL 的替代效应为 α ，则在只有一个 QTL 的简单情形下，标记的回归系数期望为

$$E(\hat{\beta}_k) = \alpha \frac{D}{p_k q_k} = \alpha r \sqrt{\frac{p_Q q_Q}{p_k q_k}},$$

标记解释的方差为 QTL 解释方差的 r^2 倍，检验的非中心参数为 $Nr^2q_{\text{QTL}}^2$ (式 (3.19))。这一关系给出了 GWAS 功效的基本规律。按式 (3.19) 计算，在 $\alpha = 5 \times 10^{-8}$ 的全基因组显著水平下：一个解释 1% 表型方差的 QTL，若有一个与它完全 LD 的标记，一千个个体的检测功效仅约 1%，一万个个体时接近 100%；若最好的标记只有 $r^2 = 0.5$ ，一万个个体的功效降到约 95%。解释 0.1% 方差的 QTL，即使有十万个个体，在 $r^2 = 0.5$ 时功效也只有约 95%。可见，检测小效应位点所需的样本量远超早期研究者的预期，这是人类 GWAS 样本从数千迅速增长到数百万的根本原因。

8.6 群体分层与隐性亲缘

8.6.1 假阳性的来源

关联分析最大的威胁来自**群体结构**。若样本由若干亚群组成，而亚群之间既有等位基因频率的差异，又有表型均值的差异（无论这种差异来自遗传还是环境），那么即使一个标记与性状毫无因果关系，它也会因为“在高表型亚群中频率较高”而表现出关联。这正是第 5 章式 (5.8) 所描述的混合 LD，只是这里的“另一个位点”换成了表型。家畜中，品种、品系、场、引种来源与大家系都可以构成这样的结构；作物关联群体中，不同杂种优势群与地理来源的种质也形成明显的亚群。

即使没有明显的亚群，个体之间不同程度的亲缘关系（**隐性亲缘**）也会造成类似问题：亲缘近的个体共享大量染色体片段，也共享多基因背景，一

个标记若在某个大家系中频率偏高，就可能与表型产生虚假关联。在家畜群体中，少数公畜往往有大量后代，这种问题尤其突出。

8.6.2 一个模拟的分层群体

为了说明这些问题，用溯祖模拟产生两个在 150 代前分化的亚群（各自有效大小 500），分别抽取 600 与 400 个个体，在十条各 10 兆碱基的染色体上得到约五万五千个频率在 0.05 以上的 SNP，亚群间平均 F_{ST} 约 0.18。随机选取 20 个 SNP 作为 QTL，使遗传方差占表型方差的 30%；此外让第二个亚群的表型均值高出 0.8 个单位，模拟管理条件或其他与亚群混杂的差异。

表 8.2 比较了四种分析方法。Bonferroni 阈值为 $0.05/54761 \approx 9.1 \times 10^{-7}$ 。

表 8.2 分层群体中不同 GWAS 方法的比较

方法	λ_{GC}	显著 SNP 数	位于 QTL 附近	远离 QTL (假阳性)
简单回归	6.83	516	222	294
基因组控制校正	1.00	0	0	0
5 个主成分为协变量	1.37	195	195	0
混合模型	0.89	139	139	0

简单回归的结果充满假阳性：超过一半的显著 SNP 远离任何 QTL（图 8.2A）。QQ 图（图 8.1A）显示，观察到的 $-\log_{10} p$ 从一开始就系统性地高于期望，这是群体分层的典型特征：真实的关联只应在分布尾部偏离对角线，而分层使整个分布膨胀。

8.6.3 基因组控制

德夫林与罗德（1999）提出的**基因组控制**假定分层对所有标记的检验统计量造成相同比例的膨胀。以全部标记卡方统计量的中位数除以零假设下的期望中位数（0.455），得到膨胀因子

$$\lambda_{GC} = \frac{\text{median}(\chi_k^2)}{0.455}, \tag{8.5}$$




图 8.2 群体分层的诊断。A 图为四种方法的 QQ 图及基因组控制因子；B 图为基因组关系矩阵前两个主成分，两个亚群清楚分离




图 8.3 模拟分层群体的曼哈顿图。A 图为未校正群体分层的简单回归，大量显著信号并不对应真实 QTL；B 图为混合模型分析，橙色圆圈为模拟的 QTL，虚线为 Bonferroni 阈值

再把每个统计量除以 λ_{GC} 。在人类研究中 λ_{GC} 通常在 1.0 至 1.1 之间, 基因组控制是一种简便的保守校正。但当分层很强时, 均匀校正的假定不成立: 与亚群分化程度高的标记, 其膨胀远大于平均水平; 而真正的关联信号却被一同削弱。上例中 $\lambda_{GC} = 6.83$, 基因组控制把所有信号——包括真实的——都消除了。基因组控制更适合作为诊断指标, 而非主要的校正手段。还需注意, 在真正的多基因性状中, 大量微小的真实效应本身也会使 λ_{GC} 大于 1; 在样本量很大的研究中, λ_{GC} 偏大并不一定意味着存在分层, 第 25 章的 LD 分数回归可以区分这两种来源。

8.6.4 主成分校正

普赖斯等 (2006) 提出的 EIGENSTRAT 方法对标准化基因型矩阵做主成分分析, 把前若干个主成分作为协变量加入式 (8.4)。主成分捕获的是全基因组尺度上的频率差异轴, 即群体结构的主要方向; 把它们作为协变量, 相当于在每个“结构背景”内部比较基因型与表型。图 8.1B 中第一个主成分就把两个亚群清楚地分开, 它解释了基因组关系矩阵约 15% 的变异。加入 5 个主成分后, λ_{GC} 降到 1.37, 假阳性全部消失, 同时保留了 195 个位于 QTL 附近的显著 SNP。主成分方法计算快、易于理解, 对离散的亚群与连续的地理梯度都有效; 但它不能很好地处理细致的家系结构与隐性亲缘, 后者需要大量主成分才能描述。

8.6.5 混合模型

最一般的方法是把多基因背景作为随机效应纳入模型。于等 (2006) 提出了 Q+K 混合模型:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\gamma} + \mathbf{Q}\mathbf{v} + \mathbf{x}_k\boldsymbol{\beta}_k + \mathbf{u} + \mathbf{e}, \quad \mathbf{u} \sim N(\mathbf{0}, \mathbf{K}\sigma_u^2), \quad (8.6)$$

其中 $\mathbf{Q}$ 为群体结构 (亚群成员比例或主成分) 矩阵, $\mathbf{K}$ 为由标记或系谱计算的亲缘矩阵, $\mathbf{u}$ 为多基因效应。混合模型同时校正了大尺度的群体结构与细致的亲缘关系, 在玉米、拟南芥、家畜等具有复杂结构的群体中表现最好。斯蒂希等 (2008) 在小麦中比较了多种混合模型方法, 发现以 REML 估

计的同态非同祖同源概率构建的亲缘矩阵效果良好,并比较了先校正试验设计再作关联分析的“两步法”与同时拟合的“一步法”。

式(8.6)对每个标记都需要拟合一个混合模型,若每次都重新估计方差组分,计算量与 n^3 乘以标记数成正比。几项计算上的进展使大规模混合模型 GWAS 成为可能。康等(2008)的 EMMA 方法利用亲缘矩阵的谱分解,把方差组分估计化为一维优化问题。基于“方差组分对单个标记不敏感”的观察,康等(2010)的 EMMAX 与张等(2010)的 P3D 方法只在零模型(不含标记)下估计一次方差组分,之后对每个标记只需一次广义最小二乘,计算量大为降低。之后的 GEMMA 实现了每个标记的精确检验, BOLT-LMM 与 REGENIE 等方法则使混合模型能够应用于数十万人的生物样本库资料。

在上述模拟中,混合模型在零模型下估计的 SNP 遗传力约为 0.26,所有标记的检验中无一假阳性, $\lambda_{GC} = 0.89$ 。混合模型检测到的显著 SNP (139 个)比主成分方法(195 个)少,这反映了混合模型的一个已知问题——**近端污染**:被检验的 SNP 及与之处于 LD 的 SNP 本身也参与了亲缘矩阵的计算,其效应被部分地“吸收”进多基因随机效应,导致检验统计量偏小、 λ_{GC} 小于 1。常用的解决方法是“留一条染色体”(LOCO):检验某条染色体上的标记时,用其余染色体的标记构建亲缘矩阵。

8.6.6 混合模型中的解释方差

在固定效应模型中,常用决定系数 R^2 表示一个标记解释的表型变异。混合模型中没有现成的 R^2 。孙等(2010)比较了若干种类似 R^2 的统计量,建议使用基于似然比的

$$R_{LR}^2 = 1 - \exp\left[-\frac{2}{n}(\ell_1 - \ell_0)\right], \quad (8.7)$$

ℓ_1 与 ℓ_0 分别为含与不含该标记的模型的对数似然。在没有随机效应时, R_{LR}^2 退化为普通的 R^2 ;在混合模型中,它满足 R^2 应有的若干性质,并能解释群体结构、亲缘与标记解释方差之间的重叠。由于标记效应与群体结构往往部分混杂,在加入 $\mathbf{Q}$ 与 $\mathbf{K}$ 之后,一个标记“额外”解释的方差通常小于它单独解释的方差。

8.7 显著性标准与多重检验

GWAS 中检验的标记数以万计乃至百万计，多重检验的处理与第 3、7 章的原则相同，但有自己的特点。人类遗传学中广泛采用的全基因组显著标准 5×10^{-8} ，来自对欧洲人群中常见变异“有效独立检验数”约为一百万的估计，即 $0.05/10^6$ 。家畜群体的 LD 范围大、有效独立片段数少，同样的 Bonferroni 逻辑会给出较宽松的阈值；但为了与标记芯片的密度相匹配，许多家畜研究直接以芯片上的标记数作 Bonferroni 校正，或者以“每次全基因组扫描期望一个假阳性”作为提示性阈值 ($1/M$)。

在相关性很强的标记集合中，Bonferroni 校正过于保守。可以由标记相关矩阵的特征值估计有效独立检验数，再据此校正；也可以用置换检验，但当个体之间存在亲缘或群体结构时，简单的置换不再保持零假设下的可交换性，需要基于模型的模拟。用于筛选候选区域时，第 3 章的错误发现率控制也很常见。

对显著性的判断还应考虑信号的形态。一个真实的 QTL 通常伴随着相邻标记的一簇信号，其强度随与峰值标记的 LD 而递减；孤立的、相邻标记均不显著的单个高峰值，往往提示分型错误、稀有等位基因的极端值或批次效应，应检查原始的分型图与基因型分布。

8.8 效应估计、重复与荟萃分析

GWAS 发现的显著标记，其效应估计同样受到第 3、7 章所述的赢家诅咒影响。只有在独立的样本中重复检测到同方向的效应，才能确认关联的真实性。人类遗传学已经把“发现—重复”的两阶段设计作为发表的基本要求。

当多个研究分别对同一性状做了 GWAS，可以合并它们的汇总统计量进行荟萃分析，而不需要共享个体资料。最常用的是逆方差加权的固定效应荟萃分析：

$$\hat{\beta}_{\text{合并}} = \frac{\sum_s w_s \hat{\beta}_s}{\sum_s w_s}, \quad w_s = \frac{1}{\text{SE}_s^2}, \quad \text{SE}(\hat{\beta}_{\text{合并}}) = \left(\sum_s w_s \right)^{-1/2}. \quad (8.8)$$

各研究的效应应以同一参考等位基因表示，标记应在同一参考基因组坐

标上对齐。研究之间效应的异质性可以用科克伦 Q 统计量或 I^2 指数度量；异质性大时，应考虑随机效应荟萃分析，或探究异质性的来源，例如群体之间 LD 结构的差异、性状定义与测定方法的差异，或基因与环境的互作。人类身高、体重指数等性状的大型国际协作，以及奶牛、肉牛的多品种多国联合 GWAS，都依赖这一方法。

8.9 精细定位与因果变异

GWAS 的显著区域通常包含许多处于高 LD 的标记，峰值标记本身未必是致因变异，只是恰好与致因变异的 LD 最强，或者由于抽样误差而略胜一筹。从关联信号到致因变异，需要精细定位。

条件分析把峰值标记作为协变量加入模型，再检验区域内其余标记。若信号消失，说明该区域可能只有一个独立的关联；若仍有显著标记，则提示存在第二个独立信号。逐步条件分析可以识别一个区域内的多个独立关联，这在许多复杂性状的位点中都很常见。

贝叶斯精细定位为区域内每个变异计算其为致因变异的后验概率。在“区域内恰有一个致因变异”的简单假定下，后验包含概率正比于每个变异的近似贝叶斯因子，由效应估计、标准误与先验效应方差即可计算（韦克菲尔德，2009）。按后验概率从高到低累加，直到总和达到 95%，得到 **95% 可信集**——以 95% 的概率包含致因变异的最小变异集合。可信集的大小取决于该区域的 LD 结构与样本量：LD 越强，可信集越大。整合多个群体的资料（尤其是 LD 结构不同的群体）能显著缩小可信集，因为在一个群体中高度相关的变异，在另一个群体中可能可以区分。功能注释（如是否位于编码区、调控区、保守元件）可以作为先验进一步加权，第 31 章将系统讨论功能先验。

单倍型分析把一个区域内的多个标记组合为单倍型，检验单倍型与表型的关联。当致因变异未被分型、但存在于特定的单倍型背景中时，单倍型比单个标记能更好地标记它。这在家畜中尤为有用，因为家畜的单倍型多样性有限、单倍型块较长。

8.10 案例

8.10.1 大白猪肉质性状的全基因组关联分析

肉质性状是猪育种中重要而难以改良的性状：它们只能在屠宰后测定，候选个体本身无法获得记录，传统选择只能依靠同胞或后代测定。董倩等（2014）对 231 头约克夏（大白）阉公猪的五个肉质性状——肌内脂肪含量、宰后 45 分钟与 24 小时的 pH、24 小时滴水损失与系水力——进行了全基因组关联分析，使用 Illumina 猪 60K SNP 芯片分型。在 $P < 10^{-4}$ 的水平下，共检测到 344 个与五个性状显著关联的 SNP，其中 323 个位于已报道的肉质 QTL 区域内，21 个为新发现；158 个 SNP 位于已知肉质相关基因的邻近区域。研究还基于 116 个 SNP 识别出 25 个单倍型块，展示了不同性状的 SNP 组合模式。

这一研究体现了中等规模家畜 GWAS 的典型特征与局限。其一，样本量较小（两百余头），检测功效有限，显著阈值采用了较宽松的 10^{-4} ，因此结果更适合作为候选区域的筛选，而非确定的因果位点；据赢家诅咒原理，显著 SNP 的效应估计可能偏高，需要独立群体验证。其二，大量显著 SNP 落在先前由杂交群体连锁分析发现的 QTL 区域中，说明在大白猪品系内部，这些区域确实存在分离的变异，这为把品种杂交 QTL 转化为品系内可用的标记提供了证据。其三，单倍型块的分析利用了猪基因组中较长的 LD，为进一步的单倍型关联与精细定位提供了线索。

8.10.2 玉米铁稳态的关联作图

本克、乌尔班尼与斯蒂希（2015）研究了玉米对缺铁的适应。缺铁影响全世界约 30% 的耕地，他们在铁供应受限与充足两种条件下测定了形态与生理性状，结合两类群体进行定位：在 B73×Mo17 互交系（IBM）群体先前检测到的 QTL 置信区间内做精细定位，以及在玉米关联群体中做全基因组关联分析。在错误发现率 5% 的标准下，精细定位在缺铁条件下检测到 13 个、在铁充足条件下检测到 2 个显著 SNP，涉及细胞色素 P450 94A1、不溶性转化酶同工酶 6 与一个低温诱导蛋白；全基因组关联分析在两种条件下分

别检测到 18 与 17 个显著 SNP, 其中多个位于基因内部或转录调控因子的识别位点。这一研究展示了植物遗传学中“连锁群体定位区间 + 关联群体精细定位”的组合策略, 也说明了同一性状在不同环境下关联位点的差异——基因与环境互作在定位层面的直接表现 (第 32 章)。

8.10.3 猪繁殖与呼吸综合症的宿主抗性

猪繁殖与呼吸综合征 (PRRS) 是全球养猪业损失最大的疾病之一。美国 PRRS 宿主遗传联盟对数千头人工感染 PRRS 病毒的生长猪测定了病毒载量与增重, 用 50K SNP 芯片进行全基因组分析。博迪克等 (2012) 采用贝叶斯 B 方法, 把所有 SNP 同时纳入模型, 以连续若干个 SNP 组成的窗口为单位估计其解释的遗传方差。结果在猪第 4 号染色体上发现一个主效区域: 该区域的一个窗口解释了病毒载量约 15%、感染期增重约 11% 的遗传方差。后续研究把致病变异定位于鸟苷酸结合蛋白 5 (GBP5) 基因的一个剪接位点突变。这一案例的方法学意义在于: 贝叶斯全基因组模型既用于预测, 也用于定位, 它以窗口解释的遗传方差比例代替单标记的 p 值, 自然地处理了 LD 造成的信号分散。

8.10.4 人类身高: 从二十个位点到饱和

人类身高是数量遗传学的经典性状, 遗传力约为 0.8。2008 年的第一批 GWAS (样本数万) 发现了约四十个与身高相关的位点, 它们合计只解释约 5% 的表型方差。随着样本量的增加, 2010 年兰戈·艾伦等以约十八万人发现了一百八十个位点, 2014 年伍德等以约二十五万人发现了近七百余个变异; 到 2022 年, 延戈等合并了约五百四十万人的资料, 识别出一万二千余个独立的显著 SNP, 它们集中于约占基因组五分之一的区域内, 在欧洲血统人群中合计解释了约 40% 至 45% 的表型方差, 接近常见 SNP 所能捕获的遗传力上限, 身高的常见变异关联研究可以说已接近“饱和”。这一历程生动地说明了数量性状的多基因本质, 也揭示了“缺失遗传力”问题如何随样本增大而逐步得到解答 (第 25 章)。

8.11 从关联分析到基因组选择

逐个标记的关联分析有两个内在的缺点。其一，大多数数量性状受大量小效应位点控制，单个标记的检验功效有限，被检测到的显著标记只能解释遗传方差的一小部分；其二，显著标记的效应因赢家诅咒而被高估，直接用它们预测育种值效果不佳。

麦维森、海斯与戈达德（2001）提出了另一种思路：不再逐个检验标记，而是把全部标记同时纳入模型，并把标记效应视为随机效应，按估计精度向零收缩：

$$y_i = \mu + \sum_{k=1}^M g_{ik}\beta_k + e_i, \quad \text{GEBV}_i = \sum_k g_{ik}\hat{\beta}_k. \quad (8.9)$$

由于不经过显著性筛选，所有标记都按其信息量贡献于预测，Beavis 效应大为减轻；收缩又像高尔顿的“向均值回归”一样，防止了对小样本中偶然大效应的过度信任。这就是**基因组选择**。例如，三个 SNP 的效应估计分别为 +10、+5、-10（每个 A 等位基因相对于参照的偏离，以杂合子为零），基因型为 AA、AA、BB 的个体，其基因组育种值为 $10 + 5 + 10 = 25$ ；基因型为 AB、BB、AA 的个体为 $0 - 5 - 10 = -15$ 。

基因组选择在奶牛中最先得到大规模应用。美国荷斯坦牛自 2009 年起正式发布基因组评定，最初的参考群体由三千五百余头经后裔测定的公牛组成；对年轻公牛，基因组预测使产奶性状的可靠度比仅用系谱指数提高了二三十个百分点，乳脂率、乳蛋白率的可靠度更高。由于年轻公牛在出生后即可获得较可靠的基因组评定，人工授精公司开始直接销售未经后裔测定的年轻公牛，世代间隔大幅缩短，遗传进展显著加快。到 2015 年，美国已有数十万头荷斯坦牛（以母犊为主）被基因组分型。第 26 至 29 章将系统讨论基因组预测的理论与方法。从这个意义上说，GWAS 与基因组选择是同一类资料的两种用途：前者问“哪里”，后者问“多少”；前者追求发现，后者追求预测。

8.12 本章小结

远交群体中，群体水平的 LD 只存在于紧密连锁的位点之间，而家系内部总是存在跨越较大距离的 LD。连锁分析利用家系内的 LD：半同胞设计中 QTL 效应必须嵌套在公畜内估计，各公畜的效应符号因相位而异；孙女儿设计利用后裔测定成绩提高功效；方差组分方法利用标记推断的位置特异同祖同源概率，适用于任意系谱。关联分析利用群体中历史形成的 LD，需要高密度标记，但定位精细、效应方向在群体中一致。GWAS 的功效由样本量与标记—QTL 的 r^2 及 QTL 解释方差之积决定，检测小效应位点需要很大的样本。群体分层与隐性亲缘是关联分析最主要的假阳性来源；基因组控制适用于轻微的分层，主成分校正适用于大尺度结构，混合模型同时处理结构与亲缘，是家畜与作物 GWAS 的标准方法，并需注意近端污染。显著性判断应控制多重检验，显著结果应在独立样本中重复；荟萃分析合并多项研究的汇总统计量；条件分析与贝叶斯精细定位把关联信号缩小到可信集。大白猪肉质、玉米铁稳态、猪 PRRS 抗性与人类身高等案例展示了 GWAS 在不同物种与性状中的应用与局限。基因组选择把全部标记同时纳入收缩模型，绕开了显著性筛选，是关联资料用于育种预测的主要形式。

8.13 习题

习题 8.1 一头公畜在标记 M 与 QTL 上的基因型为 Mq/mQ ，标记与 QTL 的重组率为 0.1，QTL 替代效应为 α 。求其后代中获得 M 与获得 m 的两组个体的期望表型之差。另一头公畜为 MQ/mq 呢？若把两头公畜的后代合并而不区分家系，标记效应的期望是多少？

习题 8.2 说明为什么在孙女儿设计中，以儿子的后裔测定成绩作为表型，比女儿设计中以女儿的单次记录作为表型具有更高的功效。设产奶量遗传力 0.3，每头儿子有 100 个女儿，计算两种表型的“遗传力”（即育种值方差占表型方差的比例）。

习题 8.3 两个亚群等量组成一个样本。某 SNP 在两亚群中的频率分别为 0.2 与 0.6，与性状无关；两亚群表型均值相差 1 个表型标准差（亚群内

标准差为 1)。求合并样本中该 SNP 与表型的相关系数, 以及在 1000 个个体中检验的期望卡方统计量。

习题 8.4 某研究的 $\lambda_{GC} = 1.08$, 样本量 10 万。说明这一膨胀可能来自哪两种不同的原因, 以及如何区分。

习题 8.5 三项独立研究对某 SNP 的效应估计 (标准误) 分别为 0.12 (0.05)、0.08 (0.04)、0.20 (0.10)。用逆方差加权求合并效应及其标准误, 并计算合并的 z 统计量。

习题 8.6 一个区域内有四个 SNP, 其近似贝叶斯因子分别为 200、150、30、20。在区域内恰有一个致因变异的假定下, 计算各 SNP 的后验包含概率, 并给出 95% 可信集。

习题 8.7 为什么说 GWAS 与基因组选择是“同一类资料的两种用途”? 说明二者在模型、目标与对 Beavis 效应的敏感性上的差别。

8.14 习题解答

8.1 Mq/mQ 公畜: 获得 M 的后代以概率 0.9 获得 q , 获得 m 的后代以概率 0.9 获得 Q 。期望差 $\bar{Y}_M - \bar{Y}_m = (0.1 - 0.9)\alpha = -0.8\alpha$ 。 MQ/mq 公畜为 $+0.8\alpha$ 。合并后期望为零: 两个家系的标记效应相互抵消, 这正是必须在家系内估计效应的原因。

8.2 女儿单次记录: $h^2 = 0.3$ 。儿子后裔测定成绩为 100 个女儿均值的两倍 (或按女儿均值计), 女儿均值的方差为 $\frac{1}{4}\sigma_A^2 + \frac{1}{100}(\sigma_P^2 - \frac{1}{4}\sigma_A^2)$, 其中公畜传递的遗传方差为 $\frac{1}{4}\sigma_A^2$ 。以 $\sigma_P^2 = 1$ 、 $\sigma_A^2 = 0.3$ 代入: 公畜效应方差 0.075, 女儿均值方差 $0.075 + 0.00925 = 0.0843$, 公畜效应占 89%。以公畜的育种值 (其两倍) 而言, 表型“遗传力”约为 0.89, 远高于 0.3。

8.3 合并样本中 SNP 剂量的方差: 各亚群内 $2pq$ 分别为 0.32 与 0.48, 均值 0.40; 亚群间剂量均值 0.4 与 1.2, 方差 0.16。总方差 0.56。表型方差 $1 + 0.25 = 1.25$ 。协方差为亚群间部分: $\frac{1}{2}(0.4 - 0.8)(0 - 0.5) + \frac{1}{2}(1.2 - 0.8)(1 - 0.5) = 0.2$ 。相关 $r = 0.2 / \sqrt{0.56 \times 1.25} = 0.239$, 期望卡方约 $1000r^2 / (1 - r^2) \approx 60.6$, 远超全基因组阈值。

8.4 可能来自残余的群体分层或隐性亲缘，也可能来自真实的多基因信号（大量微小效应使统计量普遍略大）。可以用 LD 分数回归区分：多基因信号使统计量与 LD 分数成正比，而分层主要提高截距（第 25 章）。

8.5 权重为 400、625、100，合并效应 $(48 + 50 + 20)/1125 = 0.1049$ ，标准误 $1/\sqrt{1125} = 0.0298$ ， $z = 3.52$ 。

8.6 总和 400；后验包含概率为 0.50、0.375、0.075、0.05。按序累加：0.50、0.875、0.95，95% 可信集为前三个 SNP。

8.7 二者使用相同的基因型与表型资料。GWAS 逐个标记检验固定效应，目标是发现与定位，需控制多重检验，显著标记的效应受赢家诅咒影响；基因组选择同时拟合全部标记的随机效应，目标是预测个体遗传价值，不经显著性筛选，效应按精度收缩，受 Beavis 效应影响小得多。

第四篇

PART IV

数量性状的遗传模型与参数估计

从基因型值到育种值，从方差分解到亲属相似性，本篇建立经典数量遗传学的核心理论，并讨论遗传参数的估计方法与试验设计。

第 9 章 数量遗传与群体依赖性

第 10 章 遗传方差组分、重复力与性状间相关

第 11 章 亲属间的相似性与遗传协方差

第 12 章 系谱亲缘、近交与遗传连接

第 13 章 遗传参数的经典估计方法与试验设计

数量遗传与群体依赖性



9.1 从基因型表现到可传递的遗传贡献

数量遗传学讨论连续或复杂性状的遗传差异，但它并不要求每个性状都由无限多个、完全相同的小效应基因决定。生长、繁殖、健康和适应性可以同时受到常见小效应、少数较大效应、显性、互作和环境影响。数量遗传模型的任务，是在明确群体和生产条件下，把这些复杂作用转化为可估计的均值、方差、协方差及选择反应。模型的统计简化是否有用，要看它能否回答目标问题，而不是看它是否逐一描述所有分子过程。

首先区分表型、基因型值与育种值。表型是具体个体在具体环境和测量过程中的实现；基因型值是某个基因型在约定环境分布下的平均表现；加性育种值则是相对于指定群体的可加遗传贡献。基因型值很高的个体，可能部分得益于杂合优势或特定基因组合，这些优势未必按同样程度稳定传给后代。亲本选择、商品个体表现预测和配种组合优化因此需要不同目标，不能用一个“遗传优良”概念覆盖全部决策。

加性育种值具有统计投影含义：在指定群体分布下，将基因型值对等位基因计数进行最佳线性投影，得到可以按等位基因贡献相加的部分。这不要实际生物作用完全线性。显性和上位性的一部分，可以通过群体中的平均背景进入等位基因平均效应。因而生物学上发现互作，并不自动否定加性预测；反过来，加性模型预测成功也不证明生物系统不存在复杂互作。统计表示与生物机制处于不同解释层次。

Fisher (1918) 将孟德尔遗传与连续性状亲属相关联系起来，为这种数量化思想奠定基础。后续理论不断区分基因作用、群体频率和统计方差的角度

色。对今天的基因组研究，关键启发仍然是：亲属相似性和群体变异需要通过具体遗传模型解释，不能只凭表型连续就假定某个简单方差分解必然成立。经典理论的价值在于给出可推导、可反驳的条件结构，而不是提供脱离条件的万能公式。

本章把群体依赖性作为贯穿线索。相同基因型值，在不同等位基因频率、连锁不平衡和交配结构下，可以对应不同平均替代效应与加性方差；相同遗传结构，在不同环境方差下，可以得到不同遗传力；相同标记，在不同群体中与因果变异的关联也可能改变。明确这些依赖，才能理解为何训练群中的遗传参数不能总被直接搬到未来群体，也才能设计真正检验可迁移性的研究。

模型中的基准同样重要。把群体育种值均值设为零，是相对于某个参考群体的中心化，并不表示群体没有遗传优势；更新基准可能让全部估计育种值同时平移，而实际遗传差异未变。比较品种、年份和评定体系时，应说明基准、单位与目标环境。否则某个群体平均分数较高，可能只是报告尺度不同，不能直接解释为可实现的生产增益。

9.2 孟德尔分离与 Hardy-Weinberg 结构

单基因座模型从两个等位基因开始。设等位基因 A 的频率为 p ， a 的频率为 $q = 1 - p$ 。若配子按这些频率随机结合，后代基因型 AA, Aa, aa 的概率为 $p^2, 2pq, q^2$ 。这里的随机结合是关键条件，它说明从父母两方进入合子的等位基因在所考虑层面按频率独立抽取。观测到这些比例与随机交配相容，但不能仅凭一个位点接近平衡就断言整个群体没有选择、结构或记录问题。

把 A 的拷贝数记为 x ，取值二、一、零。在上述分布下， $E(x) = 2p$ 、 $\text{Var}(x) = 2pq$ 。这可以通过基因型频率加权计算，也可以把 x 看成两个独立伯努利等位基因指示之和。第二种方法清楚显示：一旦父母来源相关、群体混合或存在近交，两拷贝的协方差不再为零，剂量方差就会改变。后续所有加性方差公式都依赖这个剂量分布，不能只看效应大小。

频率是在某个群体和时间点定义的，不是等位基因本身永久具有的属性。一个变异在核心群中常见，在商业群中可能稀少；在某品种几乎固定，在

杂交群中可能具有较高杂合度。测定样本中的频率还受到抽样和选择影响。若用精英公畜样本估计基础群体频率，可能改变中心化和关系矩阵尺度。应说明频率来自哪些动物、是否代表预测目标群体，以及是否按家系或抽样设计加权。

Hardy-Weinberg 偏离也有多种来源。近交通常增加相同来源的纯合，群体混合可以因不同亚群频率形成总体杂合不足，分型错误或等位基因丢失也可能制造偏离。单个位点的检验结果不直接识别原因。对于育种群体，强亲缘和选择可能使简单独立个体检验假设不成立；把所有显著偏离位点机械删除，可能丢失真实选择信息，也可能保留未显著但质量较差的位点。质量控制应结合技术证据和群体结构。

随机交配与连锁平衡不是同一概念。前者描述配子如何结合成为个体，后者描述同一配子上不同位点等位基因是否独立组合。群体可以在单个位点达到 Hardy-Weinberg 比例，却在不同位点之间存在明显连锁不平衡。把两个概念混用，会误以为随机交配一代就消除所有标记关联。实际重组消除位点关联的速度取决于重组率，近距离位点关联可以维持较久。

在教学推导中先采用随机交配和无结构基础群体，是为了把遗传效应与频率关系清楚分开。进入实际资料时，应逐项检查这些简化是否影响目标结论。如果只需要短期同群体预测，某些偏离可能被经验协方差吸收；如果要解释遗传方差来源、比较群体或预测长期选择反应，就需要更明确的遗传模型。假设的必要程度由问题决定，而不由公式是否熟悉决定。

9.3 基因型值、群体均值与平均替代效应

设三个基因型 AA , Aa , aa 的值分别为 k , d , $-k$ ，其中 k 为两个纯合子差异的一半， d 为杂合子偏离纯合子中点的程度。为避免与综合育种目标的经济权重 a 混淆，本章不用字母 a 表示纯合子半差。这个编码可以通过平移基因型值获得，不损失一般性，因为整体常数只改变均值，不改变遗传差异和方差。

在 Hardy-Weinberg 分布下，基因型均值为 $\mu_g = p^2k + 2pqd - q^2k =$

$k(p - q) + 2pqd$ 。均值由纯合子差异、显性偏离和频率共同决定。杂合子值高于两个纯合子中点时，杂合比例越高，显性对群体均值的贡献通常越大。相同基因型值在不同群体频率下产生不同均值，是遗传组成变化能够影响生产水平的最直接例子。

将基因型值 g 对剂量 x 作最佳线性回归，平均替代效应为 $\alpha = \text{Cov}(x, g) / \text{Var}(x)$ 。由于 $E(xg) = 2p^2k + 2pqd$ ，代入均值并化简得到

$$\alpha = k + d(q - p).$$

这个式子说明，等位基因替代效应不总等于纯合子差的一半。存在显性时，替代一个等位基因所处的另一个拷贝背景随群体频率变化，因此平均结果也变化。频率依赖不是统计上的麻烦附加项，而是“平均替代”定义的直接后果。

如果 $d = 0$ ，则 $\alpha = k$ ，不随频率改变；即便如此，加性方差仍因 $2pq$ 改变。若完全显性 $d = k$ ，则 $\alpha = 2qk$ ，当有利等位基因接近固定时，替代效应趋近零，因为大多数背景中替代不再改变基因型表现。若存在超显性，平均替代效应甚至可能随频率改变符号。不能把某个等位基因在一个频率背景下的正效应当作在所有群体中永远有利。

平均效应也不同于某一次具体交配中的替代结果。某个亲本把 A 而非 a 传给后代，其后果取决于配偶提供的等位基因；平均替代效应是对规定配偶背景分布取平均。若实际进行定向配种，配偶分布不同于定义育种值的群体，后代平均表现可能需要重新计算。亲本一般配合力与特定组合表现因此有关却不同，后面讨论杂交和配种优化时必须保留这一层区别。

当 p 为零或一时，群体中剂量没有变异，回归斜率不能由该群体数据识别。理论公式在趋近边界时可能有极限，但不能因此声称在固定群体中已经观察到替代效应。要估计该变异的作用，需要引入其他基因型、跨群体证据或实验设计，并处理背景差异。固定有利基因可能对群体当前水平十分重要，却不再贡献群体内部的选择区分信息。

9.4 加性与显性偏差的正交分解

定义加性育种值 $u = (x - 2p)\alpha$ 。三个基因型的育种值依次为 $2q\alpha$, $(q - p)\alpha$, $-2p\alpha$ 。它们按基因型频率加权均值为零, 表示相对于当前群体均值的加性差异。显性偏差定义为 $\delta = g - \mu_g - u$, 代入可得 AA , Aa , aa 分别为 $-2q^2d$, $2pqd$, $-2p^2d$ 。每个基因型都满足基因型值等于群体均值、加性值和显性偏差之和。

由于 u 来自对剂量的最佳线性投影, 剩余显性偏差与中心化剂量不相关, 也与 u 不相关。直接按频率加权, 可以验证 $E(u) = 0$ 、 $E(\delta) = 0$ 、 $E(u\delta) = 0$ 。于是基因型方差分解为两项之和, 而没有协方差项。这种正交性依赖于所用群体分布和投影编码, 不是说显性生物作用与加性生物作用在任何层面都独立。

相应方差为

$$\sigma_u^2 = 2pq\alpha^2, \quad \sigma_\delta^2 = (2pqd)^2.$$

第一式来自剂量方差乘斜率平方, 第二式来自三个显性偏差平方按频率加权。式中显性参数 d 不为零, 并不意味着显性方差一定很大: 当某等位基因稀少时, $2pq$ 很小, 显性方差可能很低。生物作用幅度与群体方差贡献不能直接等同, 研究功能基因与预测群体差异也因此需要不同证据。

例 9.1 相同基因作用, 不同群体方差。取 $k = 2$, $d = 1$ 。当 $p = 0.5$ 时, 群体均值为 0.5, 平均替代效应为二, 加性育种值为二、零、负二, 显性偏差为负二分之一、二分之一、负二分之一。加性方差为二, 显性方差为四分之一, 总遗传方差为 2.25。这些数值全部来自明确设定的基因型值与频率, 不是任何实际品种的估计参数。

保持三个基因型值不变, 将 p 改为 0.8。均值变为 1.52, 平均替代效应为 1.4, 三个加性值为 0.56, -0.84 , -2.24 , 显性偏差为 -0.08 , 0.32 , -1.28 。加性方差为 0.6272, 显性方差为 0.1024, 总遗传方差为 0.7296。群体均值提高了, 而内部遗传方差下降了, 这两个变化完全可以同时发生。

逐项相加可以核对分解。例如 aa 在第二个群体中有 $1.52 - 2.24 - 1.28 = -2$, 仍等于原基因型值; 杂合子有 $1.52 - 0.84 + 0.32 = 1$ 。同一个杂合子在

两个群体中的育种值不同，不是基因型值被随意修改，而是它相对于不同群体背景的平均加性贡献不同。这一解释能帮助读者理解跨品种效应变化，以及为何育种值必须附带参考群体。

如果报告只列“某基因贡献多少遗传方差”，就应进一步问方差针对哪个频率、哪种交配结构和哪个环境。某变异在一个群体中解释大量差异，在另一个接近固定的群体中几乎解释不了内部差异，完全可能由相同生物作用产生。高方差不是功能重要性的唯一证据，低方差也不是功能无关的证明。功能、可预测变异与可实现选择响应，需要分开评估。

9.5 频率变化、漂变与有限群体

等位基因频率会因选择、迁移、突变和随机遗传漂变变化。选择改变不同基因型进入繁殖的概率，迁移引入不同来源频率，突变产生新的变异，漂变则来自有限繁殖抽样。它们可以同时发生，观测到频率变化本身通常不能唯一识别机制。若某标记在几代中迅速升高，可能是与有利位点关联，也可能由少数公畜广泛使用造成家系频率改变，必须结合谱系、生产记录与遗传背景分析。

在理想随机抽样模型中，下一代从 $2N$ 个基因拷贝抽样形成，给定当前频率 p ，下一代频率期望仍为 p ，条件方差为 $pq/(2N)$ 。这说明中性漂变在一步期望上不偏向某个等位基因，却会增加不同重复群体之间的差异。反复漂变最终可能使变异丢失或固定；总体期望频率保持并不意味着每个群体都保持多样性。期望与单次历史之间的区别在这里非常直观。

实际育种群体不能简单用在群头数代替上述理想规模。性别比例、亲本贡献差异、家系相关、世代重叠和选择都会改变漂变强度。有效群体大小针对特定遗传过程定义，是把真实群体与某个理想模型匹配的概念；不同估计方法可能关注不同时间尺度。用一条通用公式得出的有效大小，应说明其假设与数据来源，而不是将其视为群体永久不变的属性。

算例：相同头数，不同亲本贡献。若四只公畜的贡献完全相等，随机抽到同一父本来源的机会与一只公畜承担大多数后代时不同。即使当代母羊很

多，父系来源高度集中仍会增加下一代候选者之间的亲缘。这个算例不在此直接指定一个唯一有效大小，而强调繁殖贡献分布必须进入模型。后续最优贡献选择将把预测遗传值与关系结构一起用于决定使用比例。

稀有变异尤其容易受到抽样影响。一个变异频率很低，样本中没有观察到它，不等于目标群体中绝对不存在；样本中只出现一次，也难以稳定估计其效应。对稀有有害变异，单个携带者的家系背景可能与效应混杂；对稀有有利变异，过早高强度使用携带亲本可能同时放大不利背景。解释稀有变异需要关注有效携带者数量、独立家系数和真实遗传传递，而不是只看总体样本量。

频率变化还会改变预测模型的适用性。按训练频率中心化的标记，在未来群体中可能具有非零均值；效应本身若受显性或互作背景影响，也可能变化。更新频率可以调整某些尺度，却不自动修复全部效应迁移。应区分基准变化、遗传结构变化与信息关联衰减，采用跨世代验证检查实际后果。模型更新需要连续数据支持，不能只靠把旧频率替换为新频率就宣称完成适应。

保留遗传变异并不意味着阻止所有频率改变。改良本来就需要有利变异增加，同时要避免不必要的随机流失和过度家系集中。短期增益、长期变异与适应性之间的取舍，需要明确目标和时间尺度。数量遗传理论提供评估这些后果的语言，具体策略则依赖群体资源、繁殖技术和管理限制，不能从某个单基因座曲线直接得出普遍育种方案。

9.6 偏离随机交配时重新定义统计投影

存在近交系数 F 的简化单基因座分布可写为 AA 频率 $p^2 + Fpq$ 、杂合子频率 $2pq(1 - F)$ 、 aa 频率 $q^2 + Fpq$ 。这种表达将杂合比例减少与相应纯合增加联系起来，但它仍是一个特定模型，不能用单个位点杂合不足就直接断言真实系谱近交等于某个数。群体混合和分型误差也可能产生类似频率模式，解释需要更多信息。

在这个分布下，剂量均值仍为 $2p$ ，方差变为 $2pq(1 + F)$ 。基因型均值为 $k(p - q) + 2pq(1 - F)d$ 。重新计算剂量与基因型值的协方差，得到统计回归

斜率

$$\alpha_F = k + d(q - p) \frac{1 - F}{1 + F}.$$

它与随机交配时的平均替代效应不完全相同。这里的回归加性部分首先是当前分布下的统计投影，其与未来随机配偶后代平均的关系还需要说明繁殖模型。不能把改变分布后的投影系数无条件解释为原来同一个育种值定义。

例 9.2 近交分布中的回归变化。取 $p = 0.8, F = 0.2, k = 2, d = 1$ ，三个基因型频率为 0.672, 0.256, 0.072。均值为 1.456，剂量方差为 0.384，回归斜率为 1.6。统计加性投影方差为 $0.384 \times 1.6^2 = 0.98304$ 。直接计算总基因型方差为 1.112064，剩余方差为 0.129024。这与原随机交配群体的加性和显性公式不同，必须重新计算而不能只替换一个频率。

这个例子还有一个容易误解之处：近交使杂合度下降，但某种统计加性方差可能上升。因此“近交使所有遗传方差都下降”不是准确陈述。当前个体分布中的方差、配子传递的分离方差、群体长期可利用变异和近交衰退，分别针对不同对象。第 24 章将在系谱模型中说明，近交动物的关系矩阵对角元与近交亲本的孟德尔抽样方差具有不同变化方向，并不矛盾。

非随机交配还包括同类交配和按预测值定向配种。若高值亲本更常互配，亲本育种值之间可能产生正相关，后代均值与方差结构随之改变。若为了互补或控制近交而安排配对，又产生另一种组合分布。平均替代效应和亲属协方差公式通常在某些随机交配或基准条件下推导，实际方案改变这些条件时，应研究哪些结果仍可近似使用，哪些需要重新建模。

重新投影并不意味着遗传机制改变，也不意味着可以随意选择一种编码获得想要的方差。合理做法是先说明目标群体分布和科学对象，再使用与它相容的定义。不同研究若采用不同频率、编码和交配背景，方差组分不一定直接可比。比较时应尽可能转换到共同定义，或者明确说明它们描述的是不同群体中的不同统计量。

对实际研究，这一节给出一个操作原则：当标准假设明显不成立，不要先寻找一个记忆中的修正式，而应回到期望、协方差和投影定义。低维模型

可以逐基因型枚举，高维模型则需要相应概率结构或模拟。这样得到的表达通常更长，却能清楚展示每一个假设进入何处，也更容易发现哪些结论只在特殊条件下成立。

9.7 显性、近交衰退与杂种优势

显性描述杂合子偏离两个纯合子中点，并不意味着其中一个等位基因在所有层面压倒另一个。参数 d 可以为正、负或零，不同性状和环境下也可能具有不同意义。显性方差衡量群体中这些偏离所形成的变异，而平均显性贡献涉及群体均值。一个群体可能具有明显平均杂合优势，但显性方差相对较小；也可能存在较大显性差异而各位点方向抵消，平均近交衰退不明显。不能用一个概念替代另一个。

在上一节简化近交分布下，保持等位基因频率和基因型值不变，均值为 $\mu_g(F) = k(p - q) + 2pq(1 - F)d$ 。与不近交群体相比，均值变化为 $-2pqdF$ 。若多个位点的定向显性倾向于使杂合子在有利方向偏离，近交增加就可能降低总体表现。这个表达解释了近交衰退的一种经典机制，但实际性状还可能涉及多位点、选择、环境和频率变化，不能把单基因座斜率直接当作真实群体通用系数。

算例：近交增加与均值变化。取 $p = 0.5, k = 2, d = 1$ ，不近交时均值为二分之一；若 $F = 0.2$ ，杂合比例从二分之一降到 0.4，均值变为 0.4，下降 0.1。如果显性参数为零，在这一固定频率模型中近交不会直接改变均值，但会改变基因型比例和某些方差结构。由此可见，近交与均值下降之间需要相应遗传作用，不能仅从近交系数本身推导所有性状的损失。

杂种优势通常定义为杂交后代表现相对于规定亲本群体基准的偏离。必须说明比较的是双亲均值、较优亲本还是其他商业基准，也要保持环境、年龄和管理可比。以下用 η 表示相对于双亲群体均值的优势。若两个随机交配亲本群体的等位基因频率分别为 p_1, p_2 ，基因型值在两个群体中相同，F1 由两群体各提供一个配子，则单基因座有

$$\eta = d(p_1 - p_2)^2.$$

推导来自 F1 杂合概率 $p_1q_2 + q_1p_2$ 与双亲平均杂合概率 $p_1q_1 + p_2q_2$ 的差。加性均值部分相抵消，剩余正好为显性参数乘频率差平方。若两群体频率相同，这个模型下没有由该位点产生的杂种优势；若分别固定不同等位基因，优势为 d 。因此，杂种优势需要群体差异与非加性作用相结合，而不是只要跨两个名称不同的品种就必然出现。

取 $p_1 = 0.8, p_2 = 0.2, d = 1$ ，单基因座优势为 0.36。若 $k = 2$ ，两个亲本群体均值分别为 1.52 和 -0.88，双亲均值为 0.32；F1 均值为 0.68，差为 0.36。F1 提高并不意味着其每个后代都优于双亲，也不意味着继续自交或同类杂交后优势完全保持。后续分离和交配结构改变会改变杂合与组合，必须按具体代次计算。

近交衰退和杂种优势常被放在同一理论框架中理解，但二者并非所有情况下都能由一个参数精确互推。群体间基因频率差、上位性、母体效应和环境适应差异都会影响杂交表现。设计杂交试验时，应区分直接品种效应、母体品种效应、互交方向和杂种优势，避免把母本环境或生产制度差异全部归为非加性遗传优势。对肉羊生产，选择亲本一般配合力与优化商品杂交组合可以互补，却不能相互替代。

9.8 多等位基因与更一般的基因型值表

真实位点可能有两个以上等位基因，结构变异和单倍型也常需要多状态表示。双等位公式容易记忆，但一般思想并不局限于二元情形。设等位基因 i 的频率为 p_i ，对称基因型值为 $g_{ij} = g_{ji}$ ，随机配子结合时群体均值为 $\mu = \sum_i \sum_j p_i p_j g_{ij}$ 。定义一个等位基因在随机配偶背景下的边际均值 $m_i = \sum_j p_j g_{ij}$ ，其平均效应为 $\alpha_i = m_i - \mu$ 。

因为 $\sum_i p_i \alpha_i = 0$ ，基因型 ij 的加性值可写为 $u_{ij} = \alpha_i + \alpha_j$ 。显性剩余为 $\delta_{ij} = g_{ij} - \mu - \alpha_i - \alpha_j$ 。对任一固定等位基因 i ，按配偶频率平均的显性剩余为零，因此该剩余与加性部分正交。加性方差为 $2 \sum_i p_i \alpha_i^2$ 。这个表达把双等位模型推广为完整的基因型值表，也显示平均效应依赖整个配偶频率分布。

例 9.3 三等位基因的投影。设 A、B、C 频率为 0.5, 0.3, 0.2，先给每个等

位基因原始加性贡献一、零、负一，再额外令 AB 杂合子的基因型值增加一。于是 AA、AB、AC、BB、BC、CC 的基因型值为二、二、零、零、负一、负二。对 A 背景平均得到 $m_A = 1.6$ ，对 B 为 0.8，对 C 为 -0.7 ；群体均值为 0.9，平均效应为 0.7, -0.1 , -1.6 。

加性方差为 $2[0.5(0.7)^2 + 0.3(-0.1)^2 + 0.2(-1.6)^2] = 1.52$ 。按六种基因型频率计算，总基因型方差为 1.67，剩余显性方差为 0.15。注意 AB 的额外生物作用不仅进入显性剩余，也改变了各等位基因的平均效应，因此加性方差从纯加性表中的 1.22 变为 1.52。这再次说明“生物显性作用”与“统计显性方差”不是一一对应的两个抽屉。

若改变 C 的频率，即使所有六个基因型值保持不变，A 和 B 的平均效应也可能改变，因为它们遇到 C 的概率变化。多等位情况下，这种背景依赖更明显。实际单倍型分析若把多个等位状态合并为“其他”，隐含了合并状态之间作用可以被某种平均近似。合并有助于应对稀疏样本，却可能掩盖相反效应或不同遗传来源，应说明合并依据与剩余不确定性。

低频等位基因的平均效应很难单独估计。若某状态只出现在一个家系，它与家系背景、环境和其他连锁变异高度混杂。正则化或层次模型可以借助结构信息稳定估计，但结果部分依赖先验与编码。不能把一个很大的估计值直接解释为已确认的大效应，也不能因标准误差大就断言该变异无功能。研究需要更多独立携带家系、传递记录或功能证据，具体证据应与所声称的结论相匹配。

对多等位模型，最好的检查仍是回到频率加权账本：效应均值是否为零，基因型分解能否逐项重建，加性与剩余是否按所用分布正交，方差是否相加为总方差。只要这些关系透明，模型即使比双等位形式复杂，也能够手算部分例子并独立核验。复杂遗传编码不应成为省略基本一致性检查的理由。

9.9 多位点加性值与连锁不平衡

将多个位点的中心化剂量收集为 $\mathbf{z}$ ，平均效应收集为 $\boldsymbol{\alpha}$ ，加性值为 $u = \mathbf{z}^\top \boldsymbol{\alpha}$ 。若剂量协方差为 Σ_z ，则加性方差为 $\boldsymbol{\alpha}^\top \Sigma_z \boldsymbol{\alpha}$ 。展开后包括每个位点方差

贡献,也包括所有位点对的协方差项。只有在相应位点不相关时,才可以把总方差写成各位点方差的简单和。省略连锁不平衡交叉项,可能明显高估或低估当前群体方差。

对两个双等位位点,设 AB 单倍型频率为 f_{AB} , 定义 $D = f_{AB} - p_A p_B$ 。它描述同一配子上两个等位基因共同出现相对于独立组合的偏离。随机配子结合形成二倍体时,两个剂量的协方差为 $2D$ 。连锁不平衡可以由物理连锁、选择、漂变、混合或共同历史产生;“连锁不平衡”一词不意味着所有关联位点必然距离很近。物理距离和重组率影响关联如何随世代衰减。

例 9.4 正连锁不平衡增加加性方差。两个位点有利等位基因频率均为二分之一, AB、Ab、aB、ab 单倍型频率为 0.4, 0.1, 0.1, 0.4, 剂量效应均为一。此时 $D = 0.15$, 每个位点剂量方差为二分之一, 剂量协方差为 0.3。总加性方差为 $0.5 + 0.5 + 2 \times 0.3 = 1.6$, 而忽略关联只会得到一。较大的方差来自有利等位基因更常在同一背景中共同出现。

若单倍型频率交换为 0.1, 0.4, 0.4, 0.1, 则 $D = -0.15$, 总方差变为 0.4。各位点频率和效应完全一样, 总方差却相差四倍。这个对照说明, 用单个位点频率和效应列表不足以重建多位点群体方差, 还要知道位点之间如何组合。对长期育种模拟, 重组、选择和群体结构共同改变这种组合, 因此初代方差不能简单保持不变。

在无选择、迁移等其他作用的理想条件下, 若重组率为 c_r , 下一代 $D' = (1 - c_r) D$ 。例 9.4 取 $c_r = 0.5$, 关联减半为 0.075, 方差变为 1.3。频率没有改变, 均值也未因纯加性编码改变, 遗传方差却改变了。重组并不创造新的等位基因, 而是重新组合已有变异, 从而改变群体中可表现的差异。

标记预测还涉及标记与因果位点之间的连锁不平衡。一个标记本身没有因果作用, 也可以因与因果变异相关而具有预测系数。当群体、世代或品种改变, 关联可能减弱甚至反向, 标记效应的可迁移性就受影响。因此, 训练群中的预测系数应被解释为该信息结构下的统计效应, 而不是自动解释为可直接干预的分子作用。更接近因果变异的测量有潜在优势, 但实际收益还依赖效应估计和遗传背景。

群体混合能够产生长距离关联。两个亚群若在很多位点频率不同,即使各亚群内位点独立,合并后也可能出现相关,因为位点都携带亚群来源信息。模型可能利用这种结构预测表型,但如果亚群来源又与环境差异重合,预测联系未必能迁移。控制群体结构、使用家系设计和跨环境连接,目的不是删除所有遗传差异,而是区分可传递目标信号与不稳定的群体标签。

9.10 选择形成的关联与 Bulmer 效应

选择不仅改变等位基因频率,还可以在短期内改变遗传成分之间的关联。以总值很高为条件入选时,一个成分较低的个体需要另一个成分较高才能达到阈值,入选群中的成分可能因此产生负关联。这个条件化机制与第1章讨论的选择偏倚相通,在数量遗传中表现为选择诱导的连锁不平衡。Bulmer (1971) 的经典分析说明,在相应多基因模型下,短期遗传方差变化可以由这种关联解释。

为了把机制隔离出来,考虑两个独立标准正态遗传成分 u_1, u_2 , 按总值 $I = u_1 + u_2$ 上端一半入选。总值方差为二,入选后的标准化总值方差为 $1 - 2/\pi$ 。利用联合正态条件协方差,可以得到入选群中两个成分各自方差为 $1 - 1/\pi$, 二者协方差为 $-1/\pi$ 。于是入选群总值方差为 $2 - 4/\pi$, 约为 0.7268, 低于选择前的二。

这个教学例子使用连续正态成分,不是某两个真实二倍体位点的直接遗传模拟。它的用途是展示选择条件如何产生负协方差。若忽略交叉项,只把两个入选成分方差相加,会得到约 1.3634, 仍显著高于真正总值方差。遗传方差减少并不完全来自每个成分自身变化,成分之间新形成的关联也很重要。多位点理论将这一思想与孟德尔传递、重组和持续选择联系起来。

重组可以削弱部分选择产生的关联,因此停止选择后,某些短期方差减少可能逐步恢复;由等位基因固定、变异丢失和长期频率变化造成的减少则不能仅靠重组恢复。两类变化具有不同时间尺度和可逆性。把所有遗传方差下降都称为 Bulmer 效应,会掩盖漂变、固定和模型基准变化。研究长期趋势时,应尽可能区分基因频率层面与关联层面的贡献。

选择方式也影响关联方向。定向或稳定化选择在经典相应条件下常导致负关联，分裂选择可能产生不同结果。多性状选择、非线性目标、家系选择和不等繁殖贡献，会形成更复杂的结构。因此，不能从一个单性状截留公式直接推论所有育种方案的方差变化。若要预测多代响应，应使用与实际选择路径、重组和目标更新相符的模型，并检查参数敏感性。

对遗传参数估计，选择信息是否被正确纳入同样关键。仅分析被选中后代的表型，可能把条件群体方差当成基础群体参数；如果选择所依据的全部信息在联合模型中可用，则在相应条件下可以更合理地处理。现代评定中保存历史记录与未入选个体信息，既服务预测，也服务理解选择造成的结构变化。数据管理与数量遗传理论在这里有直接联系。

对育种计划管理者，最实际的含义是不要把第一代响应一直线性外推。当前遗传标准差、准确度和选择强度都可能随计划推进而变化。较短世代间隔提高年度进展的同时，也可能加速频率与亲缘结构变化；高强度使用少数亲本则增加长期变异损失风险。短期预测公式有明确作用，但长期方案需要跟踪群体结构和多代数据，而不是只放大第一轮结果。

9.11 上位性与统计方差的群体背景

上位性描述不同基因座之间的组合效应。分子通路中一个基因的作用依赖另一个基因，是生物互作的一种表现；统计模型中的上位方差，则是在指定编码、频率和模型主效应之后，互作项所解释的群体变异。两者有关，却不具有简单一一对应关系。统计加性部分可以吸收复杂生物作用在当前背景中的平均影响，剩余互作方差则反映未被这些平均主效应解释的组合差异。

例 9.5 同一互作机制产生不同加性方差。用两个独立二元遗传因子 x, z 各取正一或负一，定义基因型作用为 $g = xz$ 。这是用于说明投影的抽象遗传因子模型，不直接代表完整二倍体基因型。若两因子均以相同概率取正负一，均值都为零， g 与任一单独因子协方差为零，全部方差一表现为互作。线性主效应模型无法预测，而乘积项能够完全重建。

现在保持函数 $g = xz$ 不变，只令 $E(x) = 0.6$ 、 $E(z) = 0$ ，即 x 取正一概

率为 0.8, z 仍均衡。写 $x = 0.6 + (x - 0.6)$, 则 $g = 0.6z + (x - 0.6)z$ 。两部分正交, 第一部分是对 z 的平均主效应, 方差为 0.36; 剩余互作方差为 0.64。生物函数没有变化, 但群体频率改变后, 原来纯互作结构中出现了可由线性主效应捕获的方差。

这个例子帮助解释一个看似矛盾的现象: 生物系统存在广泛互作, 加性模型仍可能具有很好的预测能力。加性模型描述的是当前群体中可利用的平均线性关系, 不宣称基因作用机制只有相加。Hill、Goddard 与 Visscher (2008) 讨论了复杂性状遗传方差为何常以加性成分为主的理论与证据。将这一结论理解为“互作不存在”是不准确的, 将发现互作理解为“加性模型必然无效”也不准确。

互作检测面临组合数快速增加、低频组合稀疏和主效应混杂等问题。两个位点的显著乘积项可能来自真实互作, 也可能来自未处理的群体结构、编码不当或单个位点非线性主效应。研究应明确零假设, 保留必要主效应, 检查多重检验和样本独立性, 并在独立群体或实验中验证。只报告一个很小的显著性数值, 不能替代对效应可重复性和预测价值的判断。

互作预测与互作解释也应分开。一个非线性模型可能提高外部预测, 却未能唯一识别哪些基因对具有因果互作; 多个不同函数可以在有限数据中产生相近预测。若目标是生物机制, 需要额外实验或遗传设计; 若目标是育种决策, 需证明增益在未来候选群中保持, 并计算它是否改善可实现遗传响应。模型复杂度增加后, 验证设计的重要性通常更高, 而不是更低。

上位性还影响跨群体迁移。同一个等位基因在不同背景下的平均作用不同, 可能使标记效应跨品种或跨环境变化。把所有迁移失败归为连锁不平衡衰减并不充分, 背景依赖也是可能来源; 但二者在观察资料中往往难以区分。研究应设计能够改变背景而保留目标变异、或保持背景而改变目标变异的比较, 避免仅根据两个群体回归系数不同就断言已证明某种具体机制。

9.12 遗传力描述的是指定群体中的变异比例

在最基本的模型中，表型为总体均值、加性育种值、显性偏差与环境残差之和。如果这些成分按所用群体分解相互正交，表型方差为相应方差之和。狭义遗传力定义为 $h^2 = V_A/V_P$ ，广义遗传力则以所定义的总基因型方差为分子。前者与随机交配下平均传递的加性贡献联系更直接，后者可以描述克隆或固定基因型重复所涉及的遗传差异。两种定义服务不同问题，不能只因其中一个较大便选择报告较大的数值。

遗传力不是某一个体表型中“由遗传决定的百分比”。个体只呈现一个实现值，而方差比例比较的是群体内不同个体之间的差异来源。假如所有动物获得相同且优良的饲养条件，环境差异减少可能使遗传力上升；这并不意味着营养对生长失去作用。反过来，环境异质性扩大可以降低遗传力，而不改变任一基因型对环境改善的反应。将群体变异的分解误写为个体原因的分解，是遗传力解释中最应避免的错误。

例 9.6 频率和环境都能改变遗传力。继续采用例 9.1 的单位点群体，令环境方差为三，并假设与基因型独立。频率 $p = 0.5$ 时， $V_A = 2$ 、 $V_D = 0.25$ ，故 $V_P = 5.25$ ，狭义遗传力约为 0.3810。频率变为 $p = 0.8$ 时， $V_A = 0.6272$ 、 $V_D = 0.1024$ ，故 $V_P = 3.7296$ ，狭义遗传力约为 0.1682。基因型数值及环境方差都没有改变，但遗传力因群体频率变化而下降。

再固定第一个群体，将环境方差由三减为一，狭义遗传力变成 $2/3.25 \approx 0.6154$ 。若此时只报告遗传力从约零点三八升至零点六二，读者容易误以为遗传变异增加；实际上分子仍为二，变化全部来自环境方差减少。因此，遗传力报告最好同时给出遗传方差、残差方差、单位和分析群体。一个无量纲比例具有便利性，也会隐藏对育种响应十分重要的绝对尺度。

上述分解依赖独立或正交假设。若遗传优良动物系统地获得较好饲养， $\text{Cov}(u, e)$ 可能不为零，直接写 $V_P = V_A + V_E$ 会漏掉两倍协方差。实际混合模型通常通过固定环境效应、随机管理效应和适当设计减少这种混杂；它并不能仅凭模型名称保证已经分开所有因果来源。遗传与环境相关、基因与环境互动、残差异方差，都是需要具体说明的不同现象。

记录单位也决定遗传力的含义。日增重的单次记录、多个阶段平均值、整窝平均值和个体终生累计产量具有不同的误差结构。平均多个独立误差可以提高记录层面的遗传力，而永久环境或家系共同环境不会按相同速度平均消失。若两项研究使用不同记录单位，即使都把性状简称为“产量”，遗传力也未必能直接比较。第1章关于重复记录的信息上限，在这里表现为性状定义与方差组成之间的联系。

对于二元性状，观察尺度上的方差为发生率乘其补数；改变群体发生率就会改变这一尺度。潜在责任尺度模型把二元结果理解为连续潜变量超过阈值，但潜变量的方差规范、阈值、抽样方式及病例比例必须明确。观察尺度与责任尺度的遗传力转换需要相应假设，不能将一个线性模型输出任意命名为潜在遗传力。本章不把某个转换公式作为通用捷径；后续广义混合模型将从观测机制推导适用关系。

遗传力估计还带有抽样不确定性。两个点估计零点三与零点四可能在各自置信区间内高度重叠；来自相同群体但不同模型的差别，也可能反映随机项归属改变。研究报告应区分“参数在生物学上不同”和“估计数值不同”。在样本有限、亲缘类型单一或环境与家系重合时，识别不同方差成分尤其困难，给出更多小数位不能补偿不足的设计信息。

Falconer 与 Mackay (1996) 将遗传力放在群体参数、亲属相似及选择响应的共同框架中讨论；Lynch 与 Walsh (1998) 进一步系统处理数量性状的统计分析。这一传统最有价值的部分不是把某个性状归入固定的“高遗传力”类别，而是要求每一个比例都能追溯到明确群体、明确表型与明确模型。这样的解释也适用于今天的基因组参数。

9.13 亲属相似怎样连接遗传方差与数据

如果无法直接观察每个基因的作用，就需要利用亲属之间的协方差推断遗传变异。在简单的非近交、随机交配模型中，亲子共享一半加性来源，父系半同胞的加性协方差为四分之一加性方差，全同胞则为二分之一加性方差。这里的系数是相对指定基础群体的期望共享程度，不表示每对全同胞在有限

基因组上恰好共享同样比例。第 24 章会把这些系数组织成系谱关系矩阵。

显性偏差的亲属协方差涉及两个等位基因同时同祖的概率。在上述基础条件、没有上位性与共同环境时，全同胞协方差包含四分之一显性方差，亲子和父系半同胞协方差则不包含这一项。因此有

$$\begin{aligned}\text{Cov}(y_P, y_O) &= \frac{1}{2}V_A, \\ \text{Cov}(y_{H1}, y_{H2}) &= \frac{1}{4}V_A, \\ \text{Cov}(y_{F1}, y_{F2}) &= \frac{1}{2}V_A + \frac{1}{4}V_D.\end{aligned}$$

这里 P 与 O 分别指亲本与后代，H1 与 H2 指一对半同胞，F1 与 F2 指一对全同胞。这些式子没有宣称亲子在生物作用上完全不存在显性。它们表达的是，在所假定随机群体中，显性偏差的跨代协方差为零。特定配对、近交、群体分层或不同基准能够改变相应关系。使用一个熟悉公式之前，先理清亲缘结构和随机交配条件，比事后给异常结果补充解释更可靠。

例 9.7 相同亲属相关可以具有不同来源。设 $V_A = 8$ 、 $V_D = 4$ ，独立环境方差为八，故表型方差为二十。亲子、半同胞、全同胞协方差分别为四、二、五，相关分别为零点二、零点一、零点二五。若只看到全同胞相关零点二五而套用“相关等于半数遗传力”，就会推得狭义遗传力零点五，超过真实值零点四，因为全同胞还共享显性来源。

现在另设每窝共同环境方差为三，个体独立环境方差由八减为五，使总表型方差仍为二十。全同胞协方差上升为八，其相关变为零点四；分窝饲养且不共享该环境的亲子与半同胞关系不受这个额外共同项影响。若把全同胞协方差八完全解释为一半加性方差，会推得 $V_A = 16$ 。同一观察相关可能同时包含加性、显性与共同环境，识别它们需要不同类型的亲属或不同的环境安排。

一个有用的设计是在多个父本内包含多个母本，并让不同家系后代分散到多个栏舍。父系半同胞比较主要提供父本共同遗传来源，母本内额外相似则可能涉及母体、窝效应和显性。若每个家系永远只在一个栏舍，同一组记录无法告诉我们家系优势来自遗传还是栏舍；增加每栏动物数主要提高栏内

均值精度，并不自动消除家系与栏舍混杂。设计中的交叉与重复承担不同作用。

交叉寄养或胚胎移植在适当物种与条件下能够分离部分产前、产后和遗传来源，但它们也产生新的操作与选择机制。寄养并非随机时，强壮幼体可能更容易被转移，模型仍需考虑分配规则。研究设计应从目标因果路径出发，而不是认为某个技术名称本身已经保证完全解混。即使不做干预，保存出生母体、哺育母体、管理群与时间信息，也能显著改善后续模型的可解释性。

母体遗传效应更需要区分。母体基因通过泌乳、育幼或产前环境影响后代，与后代自身直接育种值不是同一个随机量。两者可能存在遗传协方差；母体还可能具有非遗传的永久环境效应。把所有母体作用塞入残差，会改变对直接遗传力和家系表现的解释。后续多性状和母体模型将把这些来源显式写入设计矩阵，本章只强调其识别依赖跨代及多种关系的信息。

亲属协方差也可用于诊断。若模型预测父系半同胞间协方差为二，而在相似环境中长期观察到远高于这一水平的相关，应考虑共同管理、系谱错误、选择和群体结构，而不立即断言加性方差大幅增加。反过来，实际共享基因组偏离系谱期望也可能产生个体层面的差异。诊断应结合关系、环境与测量过程，逐项检验可解释路径。

9.14 基因与环境互作、尺度变化和排序改变

同一个基因型在不同环境中可以具有不同表现。若所有基因型的遗传差异仅按相同正比例放大，优秀个体排序不变，变化主要是尺度；若不同基因型反应方向或速度不同，则可能发生排序改变。两种现象都与环境依赖有关，但对育种方案有不同含义。仅比较两个环境的遗传方差不足以判断是否存在重新排序，还需要跨环境遗传协方差或遗传相关。

把环境指标记为 w ，用反应规范 $u_i(w) = a_i + b_i w$ 描述个体的遗传截距和遗传斜率。本节局部的 a_i 是随机截距，不是全书选择目标中的经济权重向量。将截距、斜率视为随机效应，设方差分别为 σ_a^2, σ_b^2 ，协方差为 σ_{ab} ，则环

境 w 下加性方差为

$$V_A(w) = \sigma_a^2 + 2w\sigma_{ab} + w^2\sigma_b^2.$$

两个环境之间的遗传协方差为

$$C_A(w_1, w_2) = \sigma_a^2 + (w_1 + w_2)\sigma_{ab} + w_1w_2\sigma_b^2.$$

这两式来自协方差的双线性，不需要记忆专门口诀。将协方差除以两个遗传标准差的乘积，才得到跨环境遗传相关。若某环境遗传方差为零，相关没有通常定义，但协方差仍有意义。这说明相关系数是方便的尺度化表达，不是全部统计结构。

例 9.8 方差相同仍可以重新排序。 设 $\sigma_a^2 = 1$ 、 $\sigma_b^2 = 0.25$ 、 $\sigma_{ab} = 0$ ，比较环境指标负一与正一。两个环境的遗传方差均为 1.25，遗传协方差为 0.75，故遗传相关为 0.6。遗传标准差相同并未保证遗传排序稳定。若只比较两环境的遗传力，也可能完全漏掉这种差异，因为两个环境还可能具有相同残差方差。




图 9.1 群体频率与环境背景改变遗传变异的两种方式

图 9.1 左图保持纯合子半差 $k = 1$ ，分别令显性偏差 $d = 0, 0.5, 1$ ，画出 $2p(1-p)[1 + d(1-2p)]^2$ 。每一条曲线都是改变频率时的加性方差，而不是三个真实品种的测定结果。没有显性时曲线关于频率二分之一对称；有显性时，等位基因替代的平均作用随频率变化，曲线通常不再对称。纯合子效应保持不变，不足以保持群体加性方差不变。

图的右侧画出三个教学基因型的反应规范, 截距和斜率分别为 $(1, -0.5)$ 、 $(0.2, 0.1)$ 、 $(-0.5, 0.7)$ 。环境指标负一时, 三个遗传值为 1.5, 0.1, -1.2; 环境指标正一时变为 0.5, 0.3, 0.2; 环境进一步升高时, 第三个基因型可以超过第一个。曲线交点表达具体基因型排序的改变; 它并不单独估计整个群体的遗传相关, 因为三个示例个体不是总体随机样本。

环境指标的定义不能草率。温度、营养水平、疾病压力和群体平均产量衡量不同过程。若以同一批动物的平均表型定义环境, 又用它解释这些动物的表型, 可能引入统计依赖; 若群体平均产量本身受遗传水平影响, 环境指标还可能夹杂遗传差异。研究应说明指标来自独立测量、外部记录还是群体表型, 并通过设计或模型处理由此形成的关联。

反应规范的中心点影响截距含义。把 w 改写为 $w - c$ 后, 新截距是原截距加 c 倍斜率, 因此截距方差与截距斜率协方差都会改变。实际环境下的预测值和协方差在正确变换后保持不变。比较两个研究报告的截距遗传力时, 如果环境中心不同, 直接比较可能没有意义; 比较共同环境值上的遗传方差则更可解释。这与第2章单位转换的原则一致。

对育种决策, 首先要明确未来后代将进入哪些环境。如果目标环境有稳定比例, 可定义这些环境遗传值的加权平均目标; 如果目标是降低极端环境损失, 也可以把稳健性或斜率纳入目标, 但经济权重需要单独论证。把斜率绝对值越小自动视为越好, 会忽略环境改善时高响应可能具有经济价值。统计模型估计反应, 育种目标决定哪些反应值得追求。

9.15 从因果变异到标记预测的群体迁移

基因组预测常用标记而非全部因果变异。标记可以因为靠近因果位点、标识家系片段或反映群体来源而与目标相关。对一个中心化标记 m 和因果成分 q , 若真实遗传值为 γq , 单标记最优线性系数为 $\gamma \text{Cov}(m, q) / \text{Var}(m)$ 。这一个式子已经说明, 即使因果效应 γ 不变, 标记频率或标记与因果位点的关联改变, 也会使标记回归系数改变。

举一个纯教学的二元例子。令中心化标记与因果因子均取正负一、方差

均为一，因果遗传值就是该因子。在参考群体中，两者相关为 0.8，单标记系数是 0.8；在目标群体中，若相关变为 -0.2 ，原系数的预测与目标真实值负相关。原模型计算正确、训练样本无限大，也不能避免这种迁移失败，因为训练和应用的联合分布不同。更多训练记录只能更精确地估计原群体的关系。

若目标群体只有标记频率改变而条件因果结构保持适当稳定，重新中心化、重新标定或调整基准可能有帮助；若连锁相位反转，则仅平移均值无法修复系数方向。若因果效应本身因遗传背景或环境而变化，识别因果位点也不自动保证完美迁移。因此，“使用更密标记”“加入更多品种”“使用功能注释”都需要对应具体误差来源，不能被当作不附条件的解决方案。

多群体训练具有信息增加和异质性增加两面。目标群体样本少时，其他群体可帮助估计共有结构；但强行要求所有标记效应完全相同，也可能使目标群体的特异部分被过度平均。合理模型可以允许相关而不完全相同的群体效应，或区分共同与特异成分。增加参数后需要足够交叉信息，否则模型只是把原来的不确定性换成更多难以识别的参数。后续多群体预测将具体讨论这种权衡。

验证设计应模拟真正的迁移路径。随机把近亲分到训练和验证中，主要检验已知家系内部的预测；跨世代验证同时涉及频率、选择与家系结构变化；跨品种验证还涉及更深的连锁与基准差异。它们回答的问题不同，数值不能简单排成一张“模型优劣排行榜”。报告应明确验证个体与训练个体的关系、出生时间、管理环境以及所用目标表型。

选择还会改变验证样本的范围。如果候选群已经被早期指数预选，验证集中的遗传方差可能小于原候选群；同样大小的预测误差会表现为较低相关。另一种情况是模型把入选路径中使用的记录间接带入验证信息，造成信息泄漏。区分这些机制需要追踪数据产生时间和筛选条件，而不是只看到相关下降就判断算法退步。

从基础理论到近期基因组方法，持续不变的问题是：模型学习的是哪个联合分布，应用时哪个部分能够保持。大量数据、复杂算法和功能信息可以改变答案的质量，却不会取消这个问题。将频率、连锁、遗传背景、环境和

选择机制分别列出，是制定迁移研究的有效起点，也为后续章节理解单步评定与多组学预测提供共同语言。

9.16 多性状遗传结构与可实现的改良方向

一个性状的加性方差不能完整描述育种群体。若同时关心生长、繁殖与健康，需要遗传协方差矩阵 Σ_u 。任意线性目标 $H = a'u$ 的遗传方差是 $a'\Sigma_u a$ ，其中 a 为经济权重向量。协方差可以使某个方向具有较大变异，也可以使另一个方向几乎没有可利用的差异。因此，选择目标的困难不仅来自单个性状遗传力低，还可能来自目标方向与群体遗传结构不匹配。

考虑两个标准化遗传性状，其遗传协方差矩阵为

$$\Sigma_u = \begin{bmatrix} 1 & -0.8 \\ -0.8 & 1 \end{bmatrix}.$$

若目标是二者之和，目标方差为 0.4；若目标是二者之差，目标方差为 3.6。每个性状自身方差均为一，却不意味着各个组合方向都同样容易改良。矩阵的两个特征方向正对应共同增加和一增一减。这里负相关不等于完全不可能同时改良，因为和方向的方差仍大于零；它意味着可供选择的共同改良差异相对较小。

如果遗传相关恰为负一，且两个方差相同，则和方向方差为零。在该理想模型与当前群体中，遗传上增加一个性状必然等量减少另一个。改变经济权重不能创造不存在的遗传差异。实际估计得到接近边界的相关时，首先应检查样本、模型和不确定性，而不是把边界估计立即当作严格生物约束。小样本下协方差估计尤其容易不稳定。

多性状结构也具有群体依赖性。不同性状可以由共同位点作用产生相关，也可以由不同位点间的连锁不平衡产生相关；选择和重组改变这些来源的方式不同。观察到遗传相关变化，不能单凭变化方向唯一判定是哪一种机制。多代资料、重组设计或分子证据可以帮助区分，但每类证据仍有其假设。把遗传相关看成永恒物种常数，会低估育种计划实施后目标结构可能发生的变化。

性状的数学定义还能引入相关。若饲料效率定义为产出除以投入，比例性状的分布与分子分母相关结构密切相关。简单地在比例上选择，可能同时改变产出和投入，并产生不希望的相关响应。定义残差类性状时，所用回归群体和调整变量也会进入其含义。因此，在建立多性状目标以前，先明确原始计量、转换及调整程序，常比直接套用一个现成相关矩阵更重要。

选择指数理论将把这些结构变成具体权重，但它不能代替目标定义。统计协方差告诉我们哪些差异可由哪些记录预测，经济权重告诉我们哪些后代变化有价值。若把容易预测误当成值得改良，就可能偏离生产目标；若把经济价值很高误当成一定可迅速改良，则会忽略遗传结构限制。数量遗传基础的作用，是把这两层问题清楚连接而不相互替代。

9.17 建立可检验的数量遗传解释

面对一组实际数据，建议先写出性状、群体与观察过程三个对象。性状包括单位、年龄、重复记录规则及是否经过调整；群体包括出生世代、品种组成、选择历史与基础频率；观察过程包括哪些个体有记录、谁被淘汰、管理安排以及测量误差。只有这三者清楚，方差分解才有确定对象。许多看似统计方法之间的争论，实际上来自分析对象不同。

其次，画出需要分开的来源。直接加性、显性、母体遗传、共同窝环境与个体残差，不必在每项研究中全部拟合，但应说明哪些被忽略、哪些被合并以及理由。一个模型能顺利收敛，只说明算法找到了某种数值解，不能证明所有成分都被数据识别。若两个随机效应始终具有相同设计结构，它们的方差可能只能识别总和，单独解释各项会超出数据的信息。

再把主要结论写成能够被反驳的预测。例如，“全同胞相似主要来自共同环境”预示同窝分散饲养后相关应下降；“跨群体预测下降主要来自连锁相位差异”预示更接近因果变异的标记可能改善迁移，但该推断仍需排除频率和背景差异。把解释连接到可观察后果，可以避免只在结果出来后选择一个听起来合理的遗传故事。

敏感性分析应围绕实质不确定性开展。可以改变基础群体定义、加入合

理的共同环境项、分开世代或管理水平、比较不同亲缘类型支持的估计。若主要结论在这些合理变化下稳定，其可信度增加；若方向随模型轻微变化而改变，应如实把它表述为依赖假设的结果。敏感性分析不应变成从许多模型中挑选最显著结果的途径。

参数估计与机制论证需要不同证据。一个加性模型可以准确预测而不识别具体因果位点，一个已验证因果位点也可能解释很少群体方差。预测性能、方差解释比例和机制重要性不必按同一顺序排列。研究报告应明确自己证明的是哪一层，避免用预测准确度替代机制证据，或用机制新颖性替代生产中的预测价值。

最后，应保留能够重新定义群体和目标的原始信息。随着育种计划推进，频率、环境和经济目标可能改变；只有保存原始表型、测量时间、系谱、管理及选择记录，才可能在新问题下重建一致分析。数量遗传学中的“群体依赖”并不是理论缺陷，而是说明遗传作用通过具体群体与环境实现。承认这种依赖，使模型更贴近真实决策，也使不同研究之间的比较更严谨。

数量遗传基础在基因组时代仍持续整理和扩展。Walsh、Visscher 与 Lynch (2025) 的新版基础著作，把经典方差分解、亲属相似与标记关系放在同一体系，并进一步连接数量性状定位、关联分析和数量基因组学。读者可以据此拓展本章涉及的问题，但理解新数据层次时仍需保持这里反复强调的区分：遗传机制、群体统计参数和可用于预测的信息，彼此联系而各有定义。

9.18 遗传分解作为带有群体权重的投影

同一张基因型值表，可以在不同群体中产生不同的加性与非加性方差。要把这一事实理解到底，需要将“基因型值如何产生”和“在当前群体中怎样最佳线性描述这些值”明确分开。前者规定一个函数，后者还需要各基因型发生的概率。Fisher (1918) 将孟德尔遗传与亲属间统计变异联系起来；从现代投影观点看，统计遗传效应的定义始终包含所用的概率权重。

设有限种基因型的值组成列向量 g ，频率为 π_i ，且所有频率为正、和为

一。用 W 表示频率组成的对角矩阵，以设计矩阵 X 收集截距和允许的加性编码。寻找系数 θ 使

$$Q(\theta) = (g - X\theta)^T W (g - X\theta)$$

最小，得到加权正规方程

$$X^T W X \theta = X^T W g.$$

这里每一行不是一只实际测定动物，而是一种可能基因型；权重代表总体频率。若改用实际样本频率，则得到相应样本分布中的投影，还必须考虑抽样和选择过程。把抽到的精英个体频率直接当作基础群体频率，并不只是换了一种计算方便的权重，而是改变了分解所针对的总体。

记剩余项为 $\delta = g - X\theta$ ，则

$$X^T W \delta = 0.$$

如果设计包含截距，剩余均值为零；若还包含中心化剂量，剩余与该剂量正交。因此加性投影与剩余遗传偏差之间没有协方差，方差能够相加。这个结论并不要求剩余项在生物机制上独立，也不要求基因型值一定由简单加性作用生成；它来自所选空间中的最佳逼近条件。

单个位点的剂量记为 x ，总体均值记为 μ_x ，则一般分布下有

$$\alpha = \frac{\text{Cov}(x, g)}{\text{Var}(x)}, \quad u_{proj} = \alpha (x - \mu_x).$$

为强调定义，此处将统计投影写为 u_{proj} 。只有进一步规定繁殖和配偶背景，才能判断它是否等于所需的可传递育种值。如果当前基因型分布受强选择或非随机交配影响，对现存动物的最佳线性描述，与面向未来随机配偶后代的平均贡献，可能具有不同系数。两者都可以精确定义，却不能仅因为形式相似就互相替代。

手算例：离开随机交配分布后重新计算。令剂量零、一、二的基因型值为零、一、四，频率分别为二分之一、五分之一、十分之三。由枚举得到剂

量均值五分之四，方差二十五分之十九；基因型均值为五分之七，剂量与基因型值的协方差为二十五分之三十七。因此

$$\alpha = \frac{37}{19}, \quad \hat{g} = -\frac{3}{19} + \frac{37}{19}x.$$

三个剩余偏差依次为十九分之三、十九分之负十五、十九分之五。频率加权后，其均值以及与剂量的交叉矩都为零。进一步计算得到

$$\text{Var}(g) = \frac{76}{25}, \quad \text{Var}(u_{proj}) = \frac{1369}{475}, \quad \text{Var}(\delta) = \frac{3}{19}.$$

后两项相加恰好等于第一项。这个核对同时检查基因型顺序、频率和编码，任何一处不一致都容易使正交性破坏。该群体等位基因频率为零点四；如果只把这个频率代入随机交配公式，就会得到斜率一点八，而不是十九分之三十七。原因是本例杂合子频率为零点二，明显不同于随机交配时的零点四八。

基因型频率接近零时，还会出现另一种边界。一个类别没有观察支持，就无法从该群体单独识别其表型值；即使仍保留外部规定的值表，统计投影也只能按有概率的类别计算。当某个剂量方向完全没有变异，斜率不再可识别，广义逆只能选择表达，不能创造基因型对照。把“系数存在一个代数极限”与“数据能够估计它”区分开，对稀有变异分析十分重要。

从这个角度看，遗传方差并不是贴在基因上的永久标签，而是某个函数在某个概率分布中的平方长度。研究者可以为了比较而重新规定共同参考分布，但必须清楚地说明这种标准化。先指定统一基因型频率，再比较不同环境中的值表，回答的是机制差异；保留各群体实际频率比较方差，回答的是各自当前可利用变异。两种比较都有用途，却不能用同一结论概括。

9.19 二位点互作的完整正交分解

“上位性可以转化为加性方差”有时被表述得过于简略，好像互动机制在选择之后自动消失。更准确的说法是，固定的基因作用函数在不同遗传背景分布中具有不同的平均主效应。本节使用两个完整二倍体剂量，展示均值、两个主效应和剩余互动如何逐项构造，使这种转化成为可核验的统计等式。

先设两个遗传变量 X 与 Z 独立, 基因型值为任意平方可积函数 $g(X, Z)$ 。定义总体均值 $\mu = E(g)$, 两个条件主效应为

$$g_X(X) = E(g | X) - \mu, \quad g_Z(Z) = E(g | Z) - \mu.$$

再定义互作剩余

$$g_{XZ} = g - \mu - g_X - g_Z.$$

独立性使一个变量的条件化不改变另一个主效应的平均, 于是

$$E(g_{XZ} | X) = 0, \quad E(g_{XZ} | Z) = 0.$$

故三个中心化成分两两正交, 并有

$$\text{Var}(g) = \text{Var}(g_X) + \text{Var}(g_Z) + \text{Var}(g_{XZ}).$$

这个分解允许每个位点主效应本身是非线性的, 所以它还不是通常的“加性加显性”完整命名。若要进一步拆分某个位点主效应, 可再对该位点剂量投影, 形成层层正交的结构。先划分信息子空间, 再赋予生物名称, 有助于避免把统计成分与某种单一分子机制强行对应。

现在设 X 与 Z 分别为独立的二项剂量, 等位基因频率为 p 和 q , 每个位点都有两个拷贝。取基因作用函数

$$g = bX + cZ + dXZ.$$

这里 b, c, d 是固定的作用参数, 其中 d 表示两位点剂量乘积的系数, 不是前述单个位点显性偏离。定义中心化剂量 $\xi = X - 2p$ 、 $\zeta = Z - 2q$, 直接展开得

$$\begin{aligned} g &= \mu + (b + 2dq)\xi + (c + 2dp)\zeta + d\xi\zeta, \\ \mu &= 2bp + 2cq + 4dpq. \end{aligned}$$

由于两个中心化剂量独立且均值为零, 三个变动项正交。平均线性效应

分别为 $b + 2dq$ 与 $c + 2dp$ ；它们包含另一位点背景的平均贡献。相应方差为

$$\begin{aligned} V_A &= 2p(1-p)(b + 2dq)^2 \\ &\quad + 2q(1-q)(c + 2dp)^2, \\ V_{AA} &= 4d^2p(1-p)q(1-q). \end{aligned}$$

手算例：纯乘积作用产生多少线性变异。取两个直接主效应都为零、乘积系数为一。两位点频率均为二分之一时，均值为一，两个平均线性效应均为一，加性投影方差为一，剩余互作方差为四分之一。虽然函数只写了乘积项，当前群体的大部分遗传变异仍落在线性主效应空间中。它说明作用函数的表达式与方差分解不能直接按项名称对应。

保持作用函数不变，只将第一位点频率降为十分之一、第二位点仍为二分之一。均值降为五分之一，两个平均线性效应分别为一和五分之一，加性方差变为五分之一，互作方差变为百分之九，总方差为零点二九。改变的是背景概率，既没有删除乘积机制，也没有添加新的分子作用。Hill、Goddard 与 Visscher (2008) 讨论的生物互作与统计加性方差之间的区别，可以在这个完整枚举例中直接看到。

独立性是上述分解的重要边界。如果两个位点存在连锁不平衡，中心化乘积未必与单个位点剂量正交，均值也未必只由两个边际均值相乘得到。此时继续使用相同四项并把平方分别相加，会遗漏交叉协方差。可以对联合基因型分布重新作加权投影，或按明确顺序构造正交基；但是各部分的分配会依赖所定义的子空间，不能再宣称独立位点分解无需修改。

一个极端反例是两个二元遗传变量完全相同，且只取零或一。此时乘积等于变量本身，所谓互作与主效应在所有实际出现的基因型上完全一致。无论增加多少同样结构的样本，都不能把它们区分开。需要能够打破这种关联的重组、家系或群体设计，才可能识别不同作用。复杂模型给出的某个互作系数，不会自动解决没有基因型支持的问题。

推广到多个独立位点时，可以按位点集合递归扣除所有较低阶条件平均，得到不同阶数的正交分解。其价值在于精确说明“已被主效应解释的部分”与“主效应之外的剩余部分”，而不是主张应把所有高阶项都投入小样本

预测。参数数目迅速增长、低频组合缺失与群体迁移仍然限制实际估计。理论上可以分解，与统计上能够可靠估计，是两个需要分别回答的问题。

9.20 连锁不平衡中的边际效应与偏回归效应

在连锁不平衡存在时，单独分析一个标记所得到的回归系数，通常包含其他相关位点的贡献。多个单标记系数因此不能直接相加成一个联合预测器；它们可能重复解释同一部分变异。理解这一问题不需要立即进入大规模基因组算法，两个位点已经足以展示边际联系、独有信息和联合效应之间的区别。

令两个中心化剂量为 x, z ，方差分别为 v_x, v_z ，协方差为 s ，基因型值为

$$g = \alpha x + \gamma z.$$

单独对第一位点回归的边际系数为

$$b_x = \frac{\text{Cov}(x, g)}{v_x} = \alpha + \gamma \frac{s}{v_x}.$$

第二项是相关背景通过第一位点传递的统计联系。它可以增强、削弱甚至改变边际系数符号。因此，一个没有直接作用的标记也可能有显著系数，一个具有明确作用的位点也可能因相关背景抵消而呈现很小边际关联。显著性大小、预测作用和因果效应，不能凭一个回归结果互相替代。

若联合剂量协方差正定，同时回归两个位点，可恢复所规定线性作用函数的两个系数。先将第二剂量中可由第一剂量解释的部分扣除，得到

$$z_{\perp} = z - \frac{s}{v_x} x, \quad \text{Var}(z_{\perp}) = v_z - \frac{s^2}{v_x}.$$

再计算它与基因型值的协方差，可得

$$\text{Cov}(z_{\perp}, g) = \gamma \left(v_z - \frac{s^2}{v_x} \right).$$

所以只要剩余方差为正，偏回归系数恰为 γ 。这个推导揭示了“控制其他标记”的确切含义：使用第二位点没有被第一位点线性解释的变异来估计

其独有贡献。剩余方差越小，可用于区分两个效应的独立信息越少，有限样本系数通常越不稳定。

手算例：边际效应为何不同于联合效应。设配子中四种单倍型频率为零点三、零点一、零点二、零点四，按 AB, Ab, aB, ab 排列。于是两个等位基因频率为零点四与零点五，连锁不平衡系数为零点一。随机配子结合后，中心化剂量方差为零点四八和零点五，协方差为零点二。设作用系数为二和负一，则

$$\begin{aligned} \text{Cov}(x, g) &= 0.76, & \text{Cov}(z, g) &= -0.10, \\ b_x &= \frac{19}{12}, & b_z &= -\frac{1}{5}. \end{aligned}$$

第二位点的边际系数绝对值远小于真实联合系数，因为它所携带的第一位点正作用抵消了部分负作用。联合方程仍给出二和负一。若把两个边际系数直接作为联合权重，既没有等价地恢复原函数，也没有一般最优性，原因正是共享信息被错误分配。

本例第二剂量的剩余方差为十二分之五，剩余目标协方差为十二分之负五，故偏回归系数为负一。完整基因型方差为一点六二；只用第一位点时解释方差为三百分之三百六十一，遗漏方差为十二分之五。这个遗漏量也等于第二位点剩余方差乘其效应平方，提供了从协方差计算到遗传结构解释的两条核验路径。

$$\text{Var}(g) - \frac{\text{Cov}(x, g)^2}{v_x} = \gamma^2 \left(v_z - \frac{s^2}{v_x} \right).$$

群体迁移还可能改变关联相位。保持两个等位基因频率和两个作用系数不变，将连锁不平衡系数改为负零点一；相应单倍型频率仍合法。此时第一位点的最佳边际系数变为十二分之二十九。旧系数与新系数相差六分之五，在新群体中额外造成的预测风险为

$$\left(\frac{5}{6} \right)^2 (0.48) = \frac{1}{3}.$$

新群体的最佳单标记剩余方差仍为十二分之五，直接使用旧系数则达到四分之三。这里没有任何因果效应改变，迁移损失完全来自标记背景关联改

变。它说明为什么仅发现训练群体中的稳定关联，仍不足以证明跨品种或跨世代可直接移植同一标记权重。

边界情形同样有教学意义。当 $s^2 = v_x v_z$ 时，两剂量完全线性相关，剩余方差为零，联合效应不能分别识别，但某个加权和仍可能被精确预测。算法用正则化选择一组系数，并不证明该组系数就是唯一生物解释。若研究目标是预测，保留可识别组合可能已经足够；若目标是定位作用，则必须补充打破关联的信息。

9.21 从选择协方差到下一代改变的传递分解

亲本群体经过选择后平均表现提高，并不等于下一代平均值提高同样多。选择改变哪些个体贡献后代，而传递决定这些个体的哪些特征能够进入下一代。将这两个环节分开，可以精确辨认显性、重组、环境和群体频率变化在何处进入结果。Price (1970) 的协方差恒等式提供了一个一般表达，但它本身并不替代具体遗传机制。

设亲本类型的初始频率为 p_i ，性状值为 z_i ，期望繁殖贡献为 w_i ，平均贡献为 $\bar{w} = \sum p_i w_i$ 。被贡献加权后的亲本均值为

$$\bar{z}_s = \frac{E(wz)}{\bar{w}}.$$

与原均值相减并展开协方差，得到

$$\bar{z}_s - \bar{z} = \frac{\text{Cov}(w, z)}{\bar{w}}.$$

如果该类型对所分配后代性状的平均值为 $z'_i = z_i + \Delta z_i$ ，则下一代均值改变满足

$$\bar{z}' - \bar{z} = \frac{\text{Cov}(w, z)}{\bar{w}} + \frac{E(w\Delta z)}{\bar{w}}.$$

第一项为贡献重新分配造成的改变，第二项为传递过程中的平均改变。该式只是对加权平均的恒等分解，可以适用于不同层次的实体；应用时必须明确谁是实体、贡献怎样计数、后代怎样分配。没有这些定义，只说“协方差解释进化”并不能产生具体数值预测。

对于等位基因剂量，在无突变、无传递偏倚且两性具有相同选择后频率的随机交配模型中，下一代等位基因频率由被选亲本的平均配子频率决定。若亲本剂量为 x ，则

$$p' = \frac{E(wx)}{2\bar{w}}, \quad \Delta p = \frac{\text{Cov}(w, x)}{2\bar{w}}.$$

这里的二来自二倍体拷贝数。若两性选择不同，应分别计算父本与母本配子频率，再求其平均；若遗传传递偏离孟德尔期望，应增加相应传递项。公式越简短，越应保留这些机制条件，否则容易把一种特定繁殖制度下的结果当成普遍规律。

手算例：亲本差、频率差与后代差并不相同。令剂量零、一、二的初始频率为四分之一、二分之一、四分之一，基因型值为零、一、四，繁殖贡献分别为一、一、二。平均贡献为四分之五，原基因型均值为一点五。选择后频率为零点二、零点四、零点四，故被选亲本均值为二，亲本选择差为零点五；等位基因频率由二分之一升为五分之三。

若被选亲本随后随机交配，下一代三种基因型频率为零点一六、零点四八、零点三六，因此

$$\bar{g}' = 0.48 + 4(0.36) = 1.92, \quad \bar{g}' - \bar{g} = 0.42.$$

亲本选择差为零点五，后代提高零点四二，中间差额为负零点零八。选择后亲本杂合子比例为零点四，随机交配后恢复为零点四八，而本例杂合子低于两个纯合子中点；这种组合分布改变降低了相对被选亲本的平均基因型值。它不表示等位基因选择无效，而是显示非加性表现不能原封不动传递。

还可从频率函数验证同一答案。在随机交配群体中，本例基因型均值为

$$\mu(p) = 2p + 2p^2.$$

在原频率二分之一处，平均替代效应为二，一阶近似给出 $2\alpha\Delta p = 0.4$ ；精确展开还有二倍频率变化平方，故

$$\mu(p + \Delta p) - \mu(p) = 2\alpha\Delta p + 2(\Delta p)^2 = 0.42.$$

由此可以区分三种数：亲本表型或基因型选择差、由当前平均效应给出的局部响应近似，以及更新频率后精确计算的后代均值。它们可以接近，也可以因强选择或非线性而明显不同。把线性响应式一直用于很大的频率改变，会遗漏曲率；把曲率遗漏再称为算法偏差，则混淆了模型近似与数值误差。

多位点情形还加入重组对连锁不平衡的改变。选择协方差可以同时包含等位基因频率与组合结构信息，下一代重组则重新分配部分组合。因此，短期方差变化与长期均值变化需要分别追踪。前述恒等式帮助组织这些来源，但要计算每一项仍需遗传模型；它不是只凭当前一张表就能无条件预测所有未来世代的公式。

9.22 群体混合中的遗传回归与基准迁移

跨群体研究常同时面对频率差异、遗传背景差异与环境差异。将全部动物合并后拟合一个回归系数，得到的是混合分布中的最佳线性联系，未必等于任何一个群体内部的平均效应。要判断合并是否合理，首先应把总体协方差拆成群体内与群体间两部分，而不是只比较样本量增加了多少。

以 S 表示群体来源，对任意两个变量有

$$\text{Cov}(x, y) = E[\text{Cov}(x, y | S)] + \text{Cov}(E[x | S], E[y | S]).$$

同样，剂量方差分解为

$$\text{Var}(x) = E[\text{Var}(x | S)] + \text{Var}(E[x | S]).$$

第一项来自各群体内部的个体差异，第二项来自群体平均的差异。如果频率较高的群体恰好处于较差环境，群体间协方差可以与群体内协方差方向相反。扩大同样混杂的数据，会更精确地估计这个混合联系，却不会自动消除其解释歧义。

手算例：群体内正效应被合并成负系数。取两个等量群体，用一个零一遗传指标 x 作简化，发生频率分别为零点二与零点八。表型模型为 $y = x + a_S$ ，两个环境截距为零与负二，且暂不加随机误差。每个群体内部的真实斜率均

为一，群体内方差均为零点一六；两个表型均值则为零点二和负一点二。因此

$$\begin{aligned}\text{Cov}(x, y) &= 0.16 + \frac{1}{4}(0.6)(-1.4) = -0.05, \\ \text{Var}(x) &= 0.16 + \frac{1}{4}(0.6)^2 = 0.25, \quad b_{\text{pooled}} = -0.2.\end{aligned}$$

合并系数为负，与两个群体内部的作用方向都相反。将群体截距纳入模型后，利用群体内变化可以恢复斜率一。但这里之所以能够恢复，是因为两群体内部都保留了零一变化；若每个群体各固定一个状态，环境与遗传指标完全重合，仅增加固定效应就无法识别遗传系数。这再次说明，统计调整依赖实际对照，不能代替设计。

如果允许不同群体具有不同斜率，却仍拟合一个共同斜率并同时拟合群体截距，得到的通常是按群体内剂量方差及样本权重加权的平均，而不是简单算术平均。等样本并不代表等信息，接近固定的位点在某一群体内几乎不能帮助估计斜率。报告共同效应时，应说明它主要由哪些群体中的哪些基因型对照支撑。

频率改变还会同时改变育种值的零点与尺度。设同一剂量 x 在两个随机交配参考群体中的定义为

$$u_0 = (x - 2p_0) \alpha_0, \quad u_1 = (x - 2p_1) \alpha_1.$$

相减并整理，得到

$$u_1 - u_0 = (x - 2p_1) (\alpha_1 - \alpha_0) - 2(p_1 - p_0) \alpha_0.$$

后一项对所有剂量相同，属于零点改变；前一项依赖个体剂量，属于效应尺度改变。只有平均效应保持相同，迁移才可以完全由一个常数平移描述。存在显性、上位性或背景关联改变时，仅调整发布均值未必足够，个体间差异也可能改变。

手算例：统一减去一个常数无法完成转换。取纯合子半差为二、显性偏离为一，参考频率由零点二变为零点八。平均替代效应分别为二点六与一点四。剂量为一的个体，育种值由一点五六变为负零点八四，差为负二点四；

剂量为二的个体，由四点一六变为零点五六，差为负三点六。不同个体需要不同改变量，所以这不是单纯基准平移。

$$\alpha(p) = 2 + (1 - 2p), \quad \alpha(0.2) = 2.6, \quad \alpha(0.8) = 1.4.$$

这个构造也提示，跨版本育种值差异不能一概解释为“增加数据后预测更准确”。差异可能包含参考群体重新中心化、遗传方差重新缩放，以及目标背景下平均效应重新定义。实际评定通常采用明确且稳定的发布基准，以便追踪遗传趋势；当科学上确需更新群体定义时，应保存转换依据，而不是把不同定义下的数字直接拼成一条时间序列。

群体混合并非只能产生问题。若记录跨越足够遗传和环境背景，且来源与测定制度得到清楚保留，它能够提供单一群体没有的基因型对照，帮助检验效应是否可迁移。关键在于将群体来源当作需要解释的结构，而不是只当作可以删除的标签。频率、连锁不平衡、配偶背景和环境条件共同决定统计效应，明确这些层次，才能把大型联合资料转化为可信的数量遗传知识。

9.23 练习、推导与答案

练习一：区分三种量。一个位点的基因型值为 $2, 1, -2$ 。有人说“有利等位基因的作用永远等于二，因此所有群体的加性方差相同”。指出其中混淆，并分别在 $p = 0.5$ 与 $p = 0.8$ 时计算等位基因替代平均效应。

答案。纯合子半差 $k = 2$ 是给定基因型值的参数，杂合子相对两纯合子中点的偏差为 $d = 1$ 。平均替代效应 $\alpha = k + d(1 - 2p)$ 则依赖群体频率，分别为二和一点四。加性方差还乘以剂量方差 $2p(1 - p)$ ，分别为二和零点六二七二。即使没有显性而使平均替代效应恒定，剂量方差仍随频率变化。固定生物数值、固定平均效应和固定群体方差是三个不同命题。

练习二：推导正交。在随机交配双等位基因群体中，证明显性偏差均值为零，且与加性育种值协方差为零。说明该结论为什么不能直接照搬到任意非随机基因型频率。

答案。将三个显性偏差 $-2q^2d, 2pqd, -2p^2d$ 分别乘 $p^2, 2pq, q^2$ 相加，三项为 $-2p^2q^2d, 4p^2q^2d, -2p^2q^2d$ ，总和为零。再分别乘育种值 $2q\alpha, (q - p)\alpha$,

$-2p\alpha$ 后加权求和, 所得公因子 $4p^2q^2d\alpha$ 乘括号 $-q + (q-p) + p$, 也等于零。频率改变为非随机交配分布时, 原来权重不再成立, 需要重新定义投影及相应残差; 不能只保留公式名称而丢掉推导条件。

练习三: 固定频率下的近交。对 $p = 0.8, k = 2, d = 1$ 的群体, 比较近交系数零与零点二时的杂合子频率和基因型均值。能否把均值下降全部解释为加性育种值下降?

答案。非近交杂合子频率为 $2pq = 0.32$, 近交后为 $2pq(1 - F) = 0.256$ 。均值由 1.52 下降至 1.456, 差为负零点零六四, 等于 $-2pqdF$ 。这里频率保持不变, 变化来自基因型组成和显性贡献; 若仍用原随机交配基础的加性定义, 等位基因平均剂量没有改变, 不能将全部均值变化称为加性改良倒退。实际群体中近交还常伴随漂变和选择, 应分别分析这些来源。

练习四: 计算杂种优势。两个随机交配亲本群体的有利等位基因频率分别为零点九和零点三, 位点显性偏差为一点五。假设相同环境、相同基因型值且不存在母体效应, 求一代杂交相对亲本均值的杂种优势。若显性偏差为零, 频率差异是否仍保证该指标为正?

答案。单位点杂种优势为 $\eta = d(p_1 - p_2)^2 = 1.5 \times 0.6^2 = 0.54$ 。这是绝对性状单位, 若要报告百分比, 还需要确定非零且有意义的亲本均值分母。显性偏差为零时该项为零, 频率差异本身不保证正杂种优势; 若显性方向相反, 该项还可能为负。多位点、母体或上位性情形需要增加相应结构, 不能把单位点结果直接等同于所有杂交表现。

练习五: 连锁不平衡与方差。两个位点剂量方差均为零点五, 剂量协方差为负零点二, 效应分别为一和二。计算加性方差, 并与忽略连锁不平衡的结果比较。

答案。方差为 $1^2 \times 0.5 + 2^2 \times 0.5 + 2 \times 1 \times 2 \times (-0.2) = 1.7$ 。忽略协方差会得到二点五, 高估零点八。该剂量协方差矩阵特征值为零点三和零点七, 因此在协方差层面合法; 相应二倍体随机配子模型中单倍型不平衡为负零点一, 也在两个频率均为二分之一的可行范围内。先检查参数组合是否可实现, 再解释方差, 是建立教学算例和模拟的共同要求。

练习六：比较遗传力。群体甲的 $V_A = 4, V_E = 6$ ，群体乙的 $V_A = 2, V_E = 2$ ，均忽略其他成分。哪个群体遗传力更高？如果直接按真实育种值以相同标准化选择强度选择，哪个群体的一代加性响应较大？

答案。甲的遗传力为零点四，乙为零点五，因此乙的比例更高。但真实育种值选择的响应为选择强度乘加性遗传标准差，甲为 $2i$ ，乙为 $\sqrt{2}i$ ，甲更大。这里假设相同繁殖与遗传传递条件，并且目标是同一性状单位。遗传力用于描述比例与记录的信息价值，遗传标准差决定可利用变异的绝对尺度，二者不能相互替代。

练习七：识别共同环境。某数据集每个父本只有一个母本，每个全同胞家系只在一个独立栏舍。拟同时估计加性、显性与栏舍方差。为什么增加每栏个体数仍可能无法可靠区分三者？提出两个能改善设计的具体改变。

答案。家系与栏舍完全重合，栏舍共同效应和全同胞共享来源具有高度重叠的记录结构；又缺乏同父异母关系，无法利用半同胞协方差单独提供加性尺度。更多栏内个体有助于估计家系总均值和个体残差，却不创造新的关系类型。可让每个父本与多个母本配种，并将各家系后代随机分散到多个栏舍；也可增加跨代记录与合理的交叉寄养信息。每项改变都应使原来重合的遗传或环境来源在数据中出现不同组合。

练习八：反应规范中心。设 $u(w) = a + bw$ ， $\text{Var}(a) = 1$ 、 $\text{Var}(b) = 0.25$ 、 $\text{Cov}(a, b) = 0$ 。改用 $v = w - 2$ 后，求新截距及其方差、与斜率协方差，并验证原环境 $w = 0$ 的遗传方差不变。

答案。写成 $u = (a + 2b) + bv$ ，新截距 $a^* = a + 2b$ 的方差为二，与斜率协方差为零点五。原环境 $w = 0$ 对应 $v = -2$ ，代入新参数得到 $2 + 2(-2)(0.5) + (-2)^2(0.25) = 1$ ，与原结果一致。截距方差改变反映环境基点改变，并非群体遗传机制发生变化。若只比较报告表中的截距参数而不核对环境编码，就可能形成错误生物解释。

练习九：群体迁移。标记和因果因子均中心化且方差为一，训练群体协方差为零点八，目标群体为负零点二，真实遗传值等于因果因子。训练得到的预测为零点八倍标记。求其在目标群体中的均方误差，并与恒预测零比较。

答案。目标群体误差方差为 $1 + 0.8^2 - 2(0.8)(-0.2) = 1.96$ ，而恒预测零的均方误差为一。训练群体最优线性模型迁移后可能比只用总体均值更差。若获得足够目标群体资料，目标系数为负零点二，其最优均方误差为零点九六。这个例子没有测量误差、算法失败或样本不足，失败源于联合分布变化，因此单纯提高训练群体拟合精度不能修复。

练习十：多性状目标与研究方案。对本章 Σ_u 的两个标准化性状，比较目标 $u_1 + u_2$ 与 $u_1 - u_2$ 的方差。若研究声称某项饲养改进使两性状的遗传相关由负零点八变为负零点二，应提出哪些核查问题？

答案。两个目标方差分别为零点四和三点六。核查应从群体是否相同、频率与选择是否改变、性状测量及单位是否一致、固定环境与共同环境是否正确处理开始，再检查协方差估计的不确定性及样本关系结构。饲养改变可能通过基因与环境互作改变遗传表达，但观察前后估计不同还不足以唯一证明这一机制。适宜设计是在多个遗传家系内随机或合理交叉安排环境，并估计跨环境的遗传协方差，从而把环境效应与群体组成变化分开。

遗传方差组分、重复力与性状间相关

10.1 方差为什么是数量遗传学的中心

第9章从单位点模型出发，推导了基因型值、平均替代效应、育种值与显性偏差，并说明这些量都依赖于群体的等位基因频率。本章把注意力转向这些量在群体中的**变异**。数量遗传学之所以以方差为中心，原因有三：其一，个体间差异是选择得以进行的前提，没有变异就没有改良；其二，亲属之间的相似程度由不同类型遗传方差的组合决定，方差分解是解释亲属相关的钥匙（第11章）；其三，选择反应、预测准确度与育种计划的设计都依赖于遗传方差与表型方差的比例（第14—18章）。福尔克纳曾说，数量遗传学的核心问题之一，就是把表型方差剖分为具有不同遗传意义的组分。

本章依次讨论：遗传方差在单位点与多位点上的分解，包括加性、显性与上位方差；连锁不平衡怎样改变遗传方差；表型方差中的环境组分与遗传力；重复测定性状的方差结构与重复力；以及两个性状之间的遗传、环境与表型相关。

10.2 单位点的遗传方差

10.2.1 加性方差与显性方差

沿用福尔克纳的记号，三种基因型 A_1A_1 、 A_1A_2 、 A_2A_2 的值为 $+a$ 、 d 、 $-a$ ，频率为 p^2 、 $2pq$ 、 q^2 。第9章已经给出平均替代效应 $\alpha = a + d(q - p)$ ，以及各基因型的育种值与显性偏差（表10.1）。

表 10.1 单位点的基因型值、育种值与显性偏差（以群体均值为原点）

基因型	频率	育种值 A	显性偏差 D
A_1A_1	p^2	$2q\alpha$	$-2q^2d$
A_1A_2	$2pq$	$(q-p)\alpha$	$2pqd$
A_2A_2	q^2	$-2p\alpha$	$-2p^2d$

育种值与显性偏差的均值都为零。加性遗传方差是育种值的方差：

$$V_A = p^2(2q\alpha)^2 + 2pq[(q-p)\alpha]^2 + q^2(2p\alpha)^2 = 2pq\alpha^2. \quad (10.1)$$

另一种推导更能揭示其含义：育种值是个体所携两个等位基因平均效应之和， $A = \alpha_i + \alpha_j$ 。随机交配下两个等位基因独立，每个等位基因效应的方差为 $p(q\alpha)^2 + q(p\alpha)^2 = pq\alpha^2$ ，于是 $V_A = 2pq\alpha^2$ 。这说明加性方差恰好是“等位基因效应方差”的两倍，也说明在偏离随机交配时（父母源等位基因相关）， V_A 会改变：近交使它增加到 $2pq\alpha^2(1+F)$ 。

显性方差是显性偏差的方差：

$$V_D = p^2(2q^2d)^2 + 2pq(2pqd)^2 + q^2(2p^2d)^2 = (2pqd)^2. \quad (10.2)$$

由于育种值与显性偏差在随机交配群体中不相关（第 9 章的投影性质），总遗传方差为

$$V_G = V_A + V_D = 2pq\alpha^2 + (2pqd)^2. \quad (10.3)$$

以小鼠侏儒基因为例，若 $p = 0.6, a = 4, d = 2$ ，则 $\alpha = 4 + (0.4 - 0.6) \times 2 = 3.6$ ， $V_A = 0.48 \times 12.96 = 6.22$ ， $V_D = 0.96^2 = 0.92$ ， $V_G = 7.14$ 。遗传标准差 $\sigma_G = 2.67$ ，其中加性标准差 2.49，显性标准差 0.96。

10.2.2 方差随频率的变化

式 (10.1) 与 (10.2) 都依赖于等位基因频率。图 10.1 展示了三种典型情形。

无显性 ($d = 0$): $\alpha = a$, $V_A = 2pqa^2$, $V_D = 0$, 加性方差在 $q = 0.5$ 时达到最大值 $a^2/2$ 。

完全显性 ($d = a$): $\alpha = 2qa$, $V_A = 8pq^3a^2$ 在 $q = 0.75$ 时最大; $V_D = 4p^2q^2a^2$ 在 $q = 0.5$ 时最大。当隐性等位基因频率很低时, 大多数个体携带显性等位基因, 加性与显性方差都很小; 当隐性等位基因频率很高时, 加性方差占绝大部分。

超显性 ($a = 0$, $d > 0$): 此时两个纯合子的值相同, $\alpha = d(q - p)$, 在 $p = q = 0.5$ 时为零, 此时全部遗传方差都是显性方差 $V_D = d^2/4$; 但在其他频率下, 加性方差不为零。




图 10.1 单位点的遗传方差组分随等位基因频率的变化。A 图无显性; B 图完全显性; C 图超显性。粗线为总遗传方差, 细线为加性方差, 虚线为显性方差

图 10.1C 传达了一个重要的观念: **加性方差的存在并不要求等位基因具有“加性的”生物学作用**。即使两个纯合子完全相同 ($a = 0$), 只要频率偏离 0.5, 替代一个等位基因仍会平均地改变基因型值, 因而产生加性方差。反过来, 即使一个位点具有很强的显性作用, 在多数频率下它的遗传方差仍主要表现为加性方差。这正是第 9 章所强调的: 加性方差是一种统计投影, 而非生物学作用方式的直接描述。

10.3 多位点的遗传方差

10.3.1 无上位时的可加性

设两个位点 A 、 B 独立作用于性状，基因型值为 $G = G_A + G_B$ 。若两位点处于连锁平衡， $\text{Cov}(G_A, G_B) = 0$ ，于是

$$V_G = V_{G_A} + V_{G_B} = (V_{A_A} + V_{A_B}) + (V_{D_A} + V_{D_B}).$$

推广到许多位点，在无上位且连锁平衡时，

$$V_A = \sum_k 2p_k q_k \alpha_k^2, \quad V_D = \sum_k (2p_k q_k d_k)^2. \quad (10.4)$$

性状的加性与显性方差分别是各位点加性与显性方差的简单相加。

例 10.1 两个位点的方差分解

位点 A : $a_A = 4$, $d_A = 2$, $p_A = 0.6$; 位点 B : $a_B = 3$, $d_B = -1$, $p_B = 0.3$ 。
两位点连锁平衡，无上位。

位点 A 前已算得 $\alpha_A = 3.6$, $V_{A_A} = 6.221$, $V_{D_A} = 0.922$ 。位点 B :
 $\alpha_B = 3 + (0.7 - 0.3)(-1) = 2.6$, $V_{A_B} = 2 \times 0.3 \times 0.7 \times 6.76 = 2.839$,
 $V_{D_B} = (2 \times 0.21 \times (-1))^2 = 0.176$ 。

合计 $V_G = 10.158$ ，其中 $V_A = 9.060$ (89.2%)， $V_D = 1.098$ (10.8%)。

尽管位点 A 有明显的显性，整个性状的遗传方差仍以加性方差为主。

10.3.2 上位方差

若位点之间存在互作，基因型值不能写成各位点值之和： $G = G_A + G_B + I_{AB}$ 。科克汉姆 (1954) 与肯普索恩 (1954) 系统地发展了上位效应的统计分解：在随机交配、连锁平衡的群体中，可以把两位点基因型值依次投影到单位点的加性与显性效应上，残差再分解为加性 $\times$ 加性 (AA)、加性 $\times$ 显性 (AD) 与显性 $\times$ 显性 (DD) 三类正交的互作偏差：

$$V_G = V_A + V_D + V_{AA} + V_{AD} + V_{DD}. \quad (10.5)$$

对更多位点，还有三位点及更高阶的互作方差。各组分之间相互正交，因而方差可以相加。第 9 章 9.19 节给出了二位点互作的完整正交分解。

在例 10.1 的基础上, 设只有双纯合子 $A_1A_1B_1B_1$ 额外增加 3 个单位 (一种局部的上位作用), 其余基因型值不变。重新计算得到 $V_G = 11.774$, 其中 $V_A = 10.384$, $V_D = 1.220$, 上位方差 $V_I = 0.170$, 仅占遗传方差的 1.4%。上位作用本身相当可观 (3 个单位, 与位点 B 的加性效应相当), 但由于它只作用于频率为 $0.36 \times 0.09 = 0.032$ 的一种基因型, 其大部分效应被投影到了两个位点的平均效应之中: α_A 由 3.6 增加到 3.76, α_B 由 2.6 增加到 2.92。

这一例子是一个普遍规律的缩影。希尔、戈达德与维舍尔 (2008) 从理论与资料两方面论证: 在大多数等位基因频率分布下, 即使生物学上普遍存在显性与上位作用, **群体中的遗传方差也主要是加性的**。原因在于, 处于极端频率 (稀有) 的等位基因占多数, 而在极端频率下, 显性与上位的作用主要通过平均效应表现为加性方差。只有当许多位点处于中间频率、且互作方式特殊时, 非加性方差才可能占较大比例。这一结论为育种中以加性模型为主的实践提供了理论依据, 但它并不否认非加性作用在杂种优势、近交衰退与配合力中的重要性 (第 20 章)。

10.3.3 连锁不平衡对遗传方差的影响

以上推导都假定位点之间处于连锁平衡。若两个位点处于连锁不平衡, 同一配子上两个位点的等位基因效应不再独立。设个体从父本获得的配子对育种值的贡献为 $\alpha_{A,p} + \alpha_{B,p}$, 则

$$\text{Var}(\alpha_{A,p} + \alpha_{B,p}) = \frac{1}{2}V_{A_A} + \frac{1}{2}V_{A_B} + 2\text{Cov}(\alpha_{A,p}, \alpha_{B,p}).$$

同一配子上两个位点等位基因指示变量的协方差正是 D_{AB} , 因此 $\text{Cov}(\alpha_{A,p}, \alpha_{B,p}) = D_{AB}\alpha_A\alpha_B$ 。父母源配子在随机交配下独立, 于是

$$V_A = V_{A_A} + V_{A_B} + 4D_{AB}\alpha_A\alpha_B. \quad (10.6)$$

显性方差也受影响, 但涉及的是同一个体两个配子之间的组合, 结果为 $V_D = V_{D_A} + V_{D_B} + 8D_{AB}^2d_Ad_B$ 。

在例 10.1 中, 若 $D_{AB} = +0.1$ (增效等位基因 A_1 与 B_1 倾向于位于同一配子上, 即相引相), $V_A = 6.221 + 2.839 + 4 \times 0.1 \times 3.6 \times 2.6 = 12.804$, $V_D = 0.938$,

$V_G = 13.742$ ；若 $D_{AB} = -0.1$ （相斥相）， V_A 降为 5.316， $V_G = 6.254$ 。可见，各位点自身的方差不受 LD 影响，但跨位点的协方差可以使总加性方差显著增加或减少：增效等位基因处于相引相时增加，处于相斥相时减少。

这一结果有深远的意义。第 14 章将说明，对数量性状进行截断选择时，被选中的个体倾向于在许多位点上同时携带增效等位基因，但由于选择是基于总值，一个位点上的增效等位基因会“减轻”对其他位点的需求，因而在选择后的群体中产生负的 LD（相斥相占优），使加性方差下降。这就是 Bulmer 效应。由于随机交配使不连锁位点的 LD 每代减半，这部分方差的减少在停止选择后可以较快恢复；而由频率改变造成的方差变化则是永久的。

在全基因组层面，式 (10.6) 的推广为

$$V_A = \sum_k 2p_k q_k \alpha_k^2 + \sum_{k \neq l} 2D_{kl} \alpha_k \alpha_l.$$

第一项称为“遗传方差” (genetic variance)，第二项称为“不平衡协方差”。基因组预测中基于标记估计的遗传方差，是否包含以及在多大程度上包含不平衡协方差，取决于所用模型与标记的密度，这是第 25 章讨论“SNP 遗传力”时需要注意的问题。

10.4 表型方差与环境效应

10.4.1 系统环境效应与随机环境效应

表型 $P = \mu + G + E$ 中的“环境”包括两类性质不同的因素。**系统环境效应**是可以识别、因而可以在统计分析中校正的因素，例如场、田块、区组、年份、季节、年龄、性别与胎次。它们通常作为固定效应纳入模型，其影响被并入 μ 中。**随机环境效应**则是在相同系统环境下，仍然造成个体间差异的不可识别的非遗传因素：同一牛场中奶牛之间营养、健康与微气候的细微差异，同一田块中植株之间土壤与光照的差异，以及测量误差。它们不受试验控制，不能通过统计分析去除，最终进入模型的残差项。

经系统效应校正后，表型方差为

$$V_P = \text{Var}(G + E) = V_G + V_E + 2\text{Cov}(G, E).$$

若个体的基因型相对于随机环境是随机分配的, $\text{Cov}(G, E) = 0$, 于是

$$V_P = V_G + V_E = V_A + V_D + V_I + V_E. \quad (10.7)$$

10.4.2 遗传力的两种定义

遗传方差占表型方差的比例称为**广义遗传力** $H^2 = V_G/V_P$, 加性方差所占的比例称为**狭义遗传力** $h^2 = V_A/V_P$ 。广义遗传力度量表型差异中由基因型决定的程度, 适用于无性繁殖或自交系, 此时整个基因型可以完整地传递; 狭义遗传力度量表型差异中可以通过有性繁殖传递给后代的部分, 决定了选择反应与亲属相似性, 是动物育种与异交植物育种中最重要的参数。

两种遗传力都是**群体特异的**: 它们依赖于遗传方差的大小, 而遗传方差依赖于等位基因频率; 也依赖于随机环境方差的大小, 而环境方差取决于环境条件的一致程度和测定的精确程度。在环境较为一致、测定较为精确的群体中, 遗传力较高。动物育种中通常以单个个体作为测定单位; 植物育种中则常以遗传上一致的一个小区为测定单位, 小区越大、重复越多, 环境方差被平均得越充分, 以小区均值为单位的遗传力就越高。因此, 比较不同研究的遗传力时, 必须说明测定单位。

估计遗传与环境方差有几种基本途径。其一, 利用遗传上一致的群体: 近交系或近交系杂交的 F_1 个体之间的差异全部来自环境, 其表型方差估计 V_E ; 与随机交配群体的表型方差 $V_G + V_E$ 相减即得 V_G 。这假定两个群体的环境方差相同, 而近交个体往往对环境更敏感 (发育稳定性较差), F_1 则常常更稳定, 这会带来偏差。其二, 在多个近交系各有多次观察的试验中, 把品系作为随机效应, 品系间方差估计 V_G 。其三, 利用亲属之间的相似性, 这是最一般的方法, 它还能把遗传方差进一步分解为加性、显性等组分 (第11章、第13章)。

常见性状的遗传力范围

遗传力因物种、群体、环境与测定方法而异, 但不同性状类型的大致范围相当稳定: 与适合度密切相关的繁殖与存活性状遗传力低, 通常为 0.02 至 0.15, 如受胎率、产仔数、产犊间隔与寿命; 生产性状居中, 通

常为 0.2 至 0.4, 如奶牛产奶量、猪与肉牛的日增重、饲料转化率; 胴体与体型性状较高, 常为 0.3 至 0.6, 如背膘厚、眼肌面积、体高与乳脂率、乳蛋白率。这一模式与费希尔自然选择基本定理的预期一致: 与适合度关系越密切的性状, 其加性方差越多地被自然选择消耗, 而非加性方差与环境方差的比重相对越大。低遗传力并不意味着性状不能改良: 只要加性遗传标准差相对于均值足够大, 并利用亲属信息、基因组信息与重复记录提高选择准确度, 低遗传力性状同样可以取得可观的进展。

10.5 重复测定性状与重复力

10.5.1 一般环境效应与特殊环境效应

许多性状可以在同一个体上多次测定, 例如奶牛各胎次的产奶量、母猪各胎的产仔数、赛马的多次比赛成绩、羊毛的逐年产量。此时随机环境效应可以进一步分为两部分: 对同一个体所有测定都相同的一般环境效应 E_g , 例如幼年期营养对体格发育的永久影响; 以及只影响某一次测定的特殊环境效应 E_s , 例如某一胎次的季节、疾病或临时管理条件。于是第 i 个个体的第 j 次测定为

$$P_{ij} = G_i + E_{g,i} + E_{s,ij}, \quad V_P = V_G + V_{E_g} + V_{E_s}. \quad (10.8)$$

G_i 与 $E_{g,i}$ 使不同个体之间产生差异, $E_{s,ij}$ 使同一个体的不同测定之间产生差异。

10.5.2 重复力

重复力是同一个体两次测定之间的相关系数。假定各次测定的方差相同,

$$r = \frac{\text{Cov}(P_{ij}, P_{ik})}{V_P} = \frac{V_G + V_{E_g}}{V_P}. \quad (10.9)$$

重复力度量的是表型方差中在各次测定之间保持一致的部分, $1-r$ 则是每次测定特有的部分。由于 $V_{E_g} \geq 0$, 重复力是广义遗传力的上限: $H^2 \leq r$,

从而也是狭义遗传力的上限。若测得某性状的重复力仅为 0.2，就可以断定其遗传力不会超过 0.2，这在缺乏亲属资料时是一个有用的约束。

在奶牛的例子中，一头母牛三个胎次的产奶量分别为 6500、6750 与 6700 千克，牛群均值 7000 千克。若其基因型值为 -280 ，一般环境效应为 -150 ，则三个胎次的特殊环境效应为 -70 、 $+180$ 、 $+130$ 。这头牛各胎次的表现相互接近，因为 $G + E_g$ 在各胎次相同；它们又各不相同，因为 E_s 每胎独立。实际资料中 G 与 E_g 无法分开：每头母牛只有一个一般环境效应，二者完全混杂。只有借助亲属资料（不同个体共享基因而不共享 E_g ），才能把它们区分开来，这正是混合模型中“永久环境效应”（第 22 章、第 24 章）所要处理的。

10.5.3 多次测定的收益

当表型以 n 次测定的平均值表示时，只有特殊环境效应被平均：

$$\bar{P}_{(n)} = G + E_g + \frac{1}{n} \sum_j E_{s,j}, \quad V_{P(n)} = V_G + V_{E_g} + \frac{1}{n} V_{E_s}.$$

于是以均值为表型的广义遗传力与单次测定的遗传力之比为

$$\frac{H_{(n)}^2}{H^2} = \frac{V_P}{V_{P(n)}} = \frac{1}{r + (1-r)/n}. \quad (10.10)$$

图 10.2A 显示，重复力越低，多次测定的收益越大： $r = 0.2$ 时，测定 5 次可使遗传决定程度提高到约 2.8 倍； $r = 0.8$ 时，测定 10 次也只能提高约 22%。重复测定的收益存在上限 $1/r$ ，因为一般环境效应不能被平均掉。在植物试验中，同样的逻辑适用于小区数与每小区株数的配置：若小区间方差大，增加小区数比增加每小区株数更有效；若株间方差大，则反之。

10.5.4 重复力与预测

由第一次测定预测第二次测定的回归系数，在两次测定方差相同时恰为重复力：

$$\hat{P}_2 - M_2 = r(P_1 - M_1).$$

由于 $r < 1$ ，预测值总比第一次测定更接近均值。这又是一次“向均值回归”：第一次测定特别高的个体，可能部分地得益于一个特别有利的特殊环




图 10.2 重复测定与性状间相关。A 图为不同重复力下多次测定的平均值相对于单次测定在遗传决定程度上的提高倍数；B 图为一个两百位点的多效性模拟中两个性状育种值的散点，遗传相关由共享效应的位点决定

境效应，而特殊环境效应在下一次测定中并不重复，其期望为零。重复力越低，回归越强。这一简单关系在实践中常被忽视：根据第一胎表现淘汰母牛，或根据首次试验选择品种，都应预期被选个体在下一次测定中表现回落。

需要指出，“重复力”的概念在植物多层次试验中常常需要推广。若 300 个自交系种植于 5 个地点、每系 10 个小区、每小区 20 株，那么“个体”是自交系，它在多个地点、小区与植株层次上被重复测定，每个层次都有各自的方差组分。与其使用一般与特殊环境效应的二分法，不如直接估计地点、小区与植株的各层方差，再据此设计最经济的重复方案。与奶牛不同，自交系在每个小区都获得一个新的“一般”环境效应，因此它们能够被平均掉，遗传效应与小区效应可以分开估计。

10.6 基因型与环境的相关和互作

10.6.1 基因型—环境相关

式 (10.7) 假定 $\text{Cov}(G, E) = 0$ 。在实际中，这一假定可能被违反。若优秀公畜的女儿受到特别照顾，它们的表现会好于其基因型所决定的水平，以女儿均值估计的公畜育种值就会偏高；若“按产量饲喂”使高产母牛得到更多精料，或长势好的品种得到更多肥料，环境也与基因型正相关。但需要分辨：若这种非随机的管理已成为标准做法，那么把基因型值定义为“标准管

理下该基因型的期望表型”，这种管理就已经被包含在基因型值之中，并不构成 $\text{Cov}(G, E)$ 。问题只出现在对不同个体采取不同于标准的优待或歧视时。在人类遗传学中，父母既提供基因也提供环境，基因型—环境相关几乎无法避免，这是由家系资料解释遗传力时最大的困难之一。

10.6.2 基因型与环境互作

若遗传效应与环境效应不是简单相加，而是存在互作， $P = G + E + I_{GE}$ ， $V_P = V_G + V_E + V_{GE}$ 。互作有两种类型：**尺度效应**，即基因型差异在不同环境中大小不同但排序不变；与**排序改变**，即在一个环境中最好的基因型在另一个环境中不再最好。后者对育种的影响更大：在一个环境中选出的种畜或品种，未必在另一个环境中表现最好。这里的“环境”通常指系统环境，例如不同的场、地区、饲养体系或气候带。基因型与环境互作的建模、估计与在育种目标中的处理，将在第32章系统讨论。

10.6.3 母体效应

哺乳动物的许多性状，尤其是幼畜的生长与存活，不仅受自身基因型影响，还受母亲提供的子宫环境、泌乳与哺育能力影响。母亲提供的这部分环境本身又部分地由母亲的基因型决定，因而具有遗传性，称为**母体遗传效应**。母体效应使母亲与后代之间的相似性高于由直接遗传效应所预期的程度，也使同胞之间产生共同环境。它的存在使亲属相似性的解释更加复杂，第11章将推导其对亲属协方差的贡献，第22章将讨论含母体效应的动物模型。

10.7 性状之间的相关

10.7.1 三种相关

育种中很少只关心一个性状。体重与饲料消耗、产奶量与乳脂率、生长速度与繁殖力、产量与抗病性，彼此之间都存在关联。两个性状 X 、 Y 的表型都可以分解为遗传与环境部分： $P_X = G_X + E_X$ ， $P_Y = G_Y + E_Y$ 。在只考虑加性部分时，定义三种相关：

- **表型相关** $r_P = \text{Cov}(P_X, P_Y) / (\sigma_{P_X} \sigma_{P_Y})$, 可以直接由资料计算;
- **遗传相关** $r_A = \text{Cov}(A_X, A_Y) / (\sigma_{A_X} \sigma_{A_Y})$, 即两性状育种值之间的相关;
- **环境相关** $r_E = \text{Cov}(E_X, E_Y) / (\sigma_{E_X} \sigma_{E_Y})$, 此处 E 包括全部非加性部分。

若遗传与环境部分不相关, 表型协方差等于遗传协方差与环境协方差之和。除以表型标准差之积, 并记 $h_X = \sigma_{A_X} / \sigma_{P_X}$ 、 $e_X = \sqrt{1 - h_X^2}$, 得到

$$r_P = h_X h_Y r_A + e_X e_Y r_E. \quad (10.11)$$

式 (10.11) 说明, 表型相关是遗传相关与环境相关的加权组合, 权重由两个性状的遗传力决定。遗传力低时, 表型相关主要反映环境相关; 遗传力高时, 主要反映遗传相关。遗传相关与环境相关可以符号相反: 例如奶牛的产奶量与受胎率, 遗传上呈不利的负相关 (高产遗传潜力伴随较低的繁殖力), 环境中则可能正相关 (良好的饲养管理同时提高产奶与繁殖), 表型相关因而可能接近零, 掩盖了遗传上的拮抗。仅凭表型相关推断选择的后果是危险的。

10.7.2 遗传相关的来源: 多效性与连锁不平衡

遗传相关有两个来源。**多效性**指同一个基因同时影响两个性状。在单位点上, 若该位点对两个性状的平均效应分别为 α_X 与 α_Y , 则两性状育种值的协方差为

$$\text{Cov}(A_X, A_Y) = 2pq \alpha_X \alpha_Y.$$

多个位点 (连锁平衡) 时,

$$r_A = \frac{\sum_k 2p_k q_k \alpha_{X,k} \alpha_{Y,k}}{\sqrt{\sum_k 2p_k q_k \alpha_{X,k}^2 \sum_k 2p_k q_k \alpha_{Y,k}^2}}. \quad (10.12)$$

遗传相关是各位点效应向量之间的、以 $2pq$ 加权的“余弦相似度”。它取决于有多少位点同时影响两个性状、效应方向是否一致以及各位点的频率。若一部分位点使两个性状同向变化、另一部分反向变化, 遗传相关可能接近零, 尽管每个位点都具有强的多效性。图 10.2B 来自一个模拟: 两百个位点中, 约 40% 的位点对两个性状的效应相关, 其余位点的效应各自独立, 且约

30% 的位点不影响性状 X 。由式 (10.12) 计算的遗传相关为 0.146, 由模拟个体的育种值直接计算为 0.147; 环境相关设为约 0.29, 两性状遗传力分别约 0.40 与 0.30, 按式 (10.11) 预期的表型相关为 0.236, 模拟值为 0.238。

连锁不平衡是遗传相关的第二个来源: 影响 X 的位点与影响 Y 的另一个位点紧密连锁且处于 LD, 也会使两性状的育种值相关。由 LD 产生的遗传相关是暂时的: 随机交配会逐渐消除 LD, 除非位点非常紧密地连锁。由多效性产生的遗传相关则是持久的。在杂交群体与近期经历过选择或混合的群体中, LD 产生的遗传相关可能相当可观。区分二者对育种有实际意义: 若不利的遗传相关来自紧密连锁而非多效性, 原则上可以通过选择重组型个体打破它。

10.7.3 遗传相关的意义

遗传相关在育种中有三个层面的意义。第一, 它决定**相关选择反应**: 对性状 X 选择时, 性状 Y 的期望变化为 $CR_Y = ih_X h_Y r_A \sigma_{P_Y}$ (第 14 章)。第二, 它决定**多性状选择指数**中各性状信息的权重与综合育种目标的可实现方向 (第 16—17 章)。第三, 它可以用来理解**基因型与环境互作**: 同一性状在两个环境中的表现可以看作两个性状, 二者的遗传相关若明显小于 1, 说明存在排序改变的互作 (福尔克纳, 1952; 第 32 章)。

遗传相关的估计比遗传力更困难, 其标准误通常很大。在半同胞设计中, 遗传相关的抽样方差近似为

$$\text{Var}(\hat{r}_A) \approx \frac{(1 - r_A^2)^2}{2} \cdot \frac{\text{SE}(\hat{h}_X^2) \text{SE}(\hat{h}_Y^2)}{h_X^2 h_Y^2},$$

当遗传力低时, 即使有数千个个体, 遗传相关的标准误也可能在 0.2 以上。第 13 章将讨论遗传相关的估计方法与试验设计。

10.8 尺度、变换与非正态性状

方差分解的结果依赖于测定尺度。一个在原始尺度上存在显性或互作的系统, 在对数尺度上可能变得可加: 若两个位点的效应是相乘的, 例如每个增效等位基因使体重增加一定百分比, 那么在原始尺度上表现为互作, 在对

数尺度上则完全可加。在许多生长与产量性状中，均值较高的群体方差也较大，变异系数近似稳定，这种情况下对数变换往往能使方差齐性、减少非加性方差。尺度效应也是基因型与环境互作的一个来源：在高产环境中所有基因型差异按比例放大，在原始尺度上表现为互作，在对数尺度上却消失了。

选择分析尺度时有两个考虑：统计的考虑是使模型假定（加性、方差齐性、正态性）更好地成立；育种的考虑是使分析尺度与经济价值的尺度相一致。二者有时冲突，例如经济价值通常是原始尺度上的线性函数。一种常见的折中是在变换尺度上估计参数与预测育种值，再换算回原始尺度计算经济价值。

二分类与有序类别性状的方差分解，需要借助第 3 章介绍的阈值模型，在潜在的易感性尺度上进行。计数性状（如产仔数、乳房炎发病次数）可以采用泊松或负二项模型，也可以近似地视为连续性状。第 24 章将系统讨论这些非正态性状的遗传模型。

10.9 深入专题

10.9.1 遗传协方差矩阵与可实现的改良方向

把多个性状的加性遗传方差与协方差排成矩阵 $\mathbf{G}$ ，它是多性状数量遗传学的核心对象。 $\mathbf{G}$ 必须是半正定的：任何性状线性组合的遗传方差 $\mathbf{w}'\mathbf{G}\mathbf{w}$ 都不能为负。由小样本分别估计的遗传相关拼成的矩阵，常常违反这一条件，例如三个性状两两遗传相关都为 -0.7 在数学上是不可能的（相关矩阵的最小特征值为负）。处理方法包括同时估计所有性状的多性状模型、对估计矩阵做“弯曲”（把负特征值调整为小的正数并重构矩阵），或者对矩阵施加降秩结构（第 24 章）。

$\mathbf{G}$ 的特征分解揭示了群体中遗传变异的主要方向。设 $\mathbf{G} = \sum_k \lambda_k \mathbf{v}_k \mathbf{v}_k'$ ，最大特征值 λ_1 对应的方向 $\mathbf{v}_1$ 是遗传变异最多的性状组合，称为“最小遗传阻力方向”。在许多多性状资料中，少数几个特征值就解释了大部分遗传变异，而一些方向上的遗传变异几乎为零。这意味着，若育种目标要求在一个几乎没有遗传变异的方向上改良，即使选择强度很大，进展也很慢。第 14 章

的多元育种者方程 $\Delta \bar{z} = G\beta$ 表明, 选择反应的方向是选择梯度经 G “扭转”后的方向, 会偏向变异较多的方向。第 16—17 章讨论的多性状育种目标与限制指数, 正是在这一几何结构下求解最优的选择方向。

10.9.2 遗传协方差的稳定性

G 是否随世代保持稳定, 决定了能否用当前估计预测长期的多性状反应。理论与资料都表明, G 会因选择 (频率改变与 Bulmer 效应)、漂变、突变与迁移而改变。由 LD 产生的遗传协方差在随机交配下衰减; 由多效性产生的协方差, 在等位基因频率变化时也会改变, 因为协方差 $\sum 2pq\alpha_X\alpha_Y$ 依赖于频率。特别地, 对两个性状同时进行正向选择, 会优先固定对两者都有利的等位基因, 留下效应方向相反的等位基因仍在分离, 使遗传相关逐渐变得更负——这一现象可以解释为什么在长期选择的群体中, 生产与适应性性状之间常出现不利的遗传相关。因此, 多性状育种计划应定期重新估计遗传参数。

10.9.3 遗传方差的异质性

经典理论假定遗传方差与环境方差在群体中是常数。实际资料常常显示方差的异质性: 不同场、年份、季节或管理水平下, 性状的表型方差不同, 遗传方差也可能不同。高产场的产奶量方差通常大于低产场。若忽略这种异质性, 高变异环境中的个体会在评定中被过度地“拉向”极端。处理方法包括在分析前按环境标准化资料, 在模型中为不同环境设定不同的方差 (异质方差模型), 或把性状在不同环境中的表现作为相关性状处理 (第 32 章)。

更进一步, 环境方差本身可能具有遗传基础: 一些基因型对环境扰动更敏感, 表现的变异更大; 另一些基因型更稳定, 变异更小。这种“环境方差的遗传变异”可以用双层次的分层模型估计: 个体的均值与方差都包含遗传效应。在许多物种中, 环境方差的遗传系数 (遗传标准差与平均环境标准差之比) 可以达到 0.2 至 0.5, 说明一致性与稳健性本身是可以选择的性状。这与第 32 章讨论的韧性育种密切相关。

10.10 本章小结

单位点的遗传方差可以分解为加性方差 $2pq\alpha^2$ 与显性方差 $(2pqd)^2$ ，二者都随等位基因频率变化；即使两个纯合子相同，频率偏离 0.5 时也存在加性方差，说明加性方差是统计投影而非生物学作用方式的直接写照。多位点在上位与连锁平衡时，各组分可简单相加；上位方差可以按科克汉姆—肯普索恩方法正交分解为加性 $\times$ 加性等组分，但在大多数频率分布下，上位与显性作用主要通过平均效应表现为加性方差。连锁不平衡不改变单个位点的方差，却通过跨位点协方差 $4D\alpha_A\alpha_B$ 改变总加性方差，这是 Bulmer 效应的机制。表型方差还包括系统与随机环境方差；广义与狭义遗传力都是群体与环境特异的，并依赖测定单位。重复测定性状的随机环境可分为一般与特殊两部分，重复力是遗传力的上限，多次测定的收益上限为 $1/r$ ；第一次测定的极端表现在第二次测定时向均值回归。基因型—环境相关与互作、母体效应使简单的方差分解复杂化。性状之间的表型相关是遗传相关与环境相关的加权组合；遗传相关来自多效性与连锁不平衡，前者持久，后者暂时；遗传相关决定相关选择反应与多性状选择的可行方向。分析尺度的选择影响方差分解的结果，变换可以减少非加性方差与尺度型互作。

10.11 习题

习题 10.1 某位点 $a = 2$ 、 $d = 1$ 。分别计算 $p = 0.2$ 、 0.5 、 0.8 时的 α 、 V_A 、 V_D 及 V_A/V_G 。

习题 10.2 证明完全显性 ($d = a$) 时，加性方差在隐性等位基因频率 $q = 0.75$ 处最大，并求此时的 V_A 与 V_D 。

习题 10.3 例 10.1 中若两位点的 LD 为 $D = 0.05$ ，求总加性方差；若希望通过 LD 使加性方差比连锁平衡时减少 20%， D 应为多少？这样的 D 在给定等位基因频率下是否可能？

习题 10.4 某性状重复力 0.35，遗传力 0.25。求一般环境方差占表型方差的比例。若以 4 次测定的均值作为表型，该均值的遗传力是多少？

习题 10.5 某母猪第一胎产仔数比群体均值多 3 头，产仔数的重复力

为 0.15。预测其二胎的产仔数比均值多多少?

习题 10.6 两个性状的遗传力分别为 0.4 与 0.1, 遗传相关为 -0.4 , 环境相关为 0.3。求表型相关, 并讨论仅观察表型相关可能导致的误判。

习题 10.7 三个位点对两性状的平均效应分别为 $(1, 1)$ 、 $(1, -1)$ 、 $(0.5, 0.5)$, 频率分别为 0.5、0.5、0.2。求两性状的加性方差与遗传相关。

10.12 习题解答

10.1 $p = 0.2$: $\alpha = 2 + 0.6 = 2.6$, $V_A = 0.32 \times 6.76 = 2.163$, $V_D = 0.32^2 = 0.102$, $V_A/V_G = 0.955$ 。 $p = 0.5$: $\alpha = 2$, $V_A = 2$, $V_D = 0.25$, 比例 0.889。 $p = 0.8$: $\alpha = 2 - 0.6 = 1.4$, $V_A = 0.32 \times 1.96 = 0.627$, $V_D = 0.102$, 比例 0.860。

10.2 $V_A = 2pq(2qa)^2 = 8a^2(1-q)q^3$, 对 q 求导得 $8a^2(3q^2 - 4q^3) = 0$, $q = 0.75$ 。此时 $V_A = 8 \times 0.25 \times 0.4219a^2 = 0.844a^2$, $V_D = (2 \times 0.25 \times 0.75a)^2 = 0.141a^2$ 。

10.3 $V_A = 9.06 + 4 \times 0.05 \times 3.6 \times 2.6 = 10.932$ 。要减少 20% (1.812), 需 $4D \times 9.36 = -1.812$, $D = -0.0484$ 。 $D < 0$ 时 $|D| \leq \min(p_A p_B, q_A q_B) = \min(0.18, 0.28) = 0.18$, 可能。

10.4 $V_{E_g}/V_P = r - H^2$; 若只有加性遗传方差, $= 0.35 - 0.25 = 0.10$ 。4 次均值的表型方差为 $0.35 + 0.65/4 = 0.5125$ (以 V_P 为 1), 遗传力 $0.25/0.5125 = 0.488$ 。

10.5 $0.15 \times 3 = 0.45$ 头。

10.6 $r_P = \sqrt{0.4 \times 0.1} \times (-0.4) + \sqrt{0.6 \times 0.9} \times 0.3 = -0.080 + 0.220 = 0.140$ 。表型上二者呈弱正相关, 掩盖了不利的遗传负相关; 若据此认为对一个性状的选择不会损害另一性状, 将导致误判。

10.7 $2pq$ 分别为 0.5、0.5、0.32。 $V_{A_x} = 0.5 + 0.5 + 0.32 \times 0.25 = 1.08$, $V_{A_y} = 1.08$, 协方差 $0.5 - 0.5 + 0.08 = 0.08$, $r_A = 0.074$ 。尽管每个位点都具有多效性, 遗传相关却接近零。

10.13 补充习题

习题 10.8 三个性状两两之间的遗传相关为 -0.6 。判断这个相关矩阵是否合法，并说明理由。

习题 10.9 两个性状的遗传协方差矩阵为 $\mathbf{G} = \begin{pmatrix} 4 & 3 \\ 3 & 4 \end{pmatrix}$ 。求其特征值与特征向量，并说明哪个方向的遗传改良最难。

10.14 补充习题解答

10.8 三阶等相关矩阵的特征值为 $1 + 2\rho$ 与 $1 - \rho$ (二重)。 $\rho = -0.6$ 时 $1 + 2\rho = -0.2 < 0$ ，矩阵不是半正定的，不合法。直观上，三个变量不可能两两都强烈负相关。

10.9 特征值为 7 与 1，对应特征向量 $(1, 1)/\sqrt{2}$ 与 $(1, -1)/\sqrt{2}$ 。沿 $(1, -1)$ 方向 (一个性状提高、另一个降低) 的遗传方差只有 1，改良最难；同时提高两性状的方向遗传方差为 7，最容易。

亲属间的相似性与遗传协方差

11.1 因果模型与观察模型

“种瓜得瓜，种豆得豆”。亲属之间的相似性是遗传最直观的证据，也是数量遗传学最重要的资料来源。高尔顿测量父母与子女的身高，费希尔在 1918 年论文的标题中直接写明“亲属间的相关”，勒什把亲属记录引入动物选择，亨德森的混合模型则把整个系谱的亲属关系写进一个协方差矩阵。可以说，数量遗传学的大部分推断，都建立在对亲属相似性的理解之上。

利用亲属相似性的分析包含两个互补的部分。第一是**观察模型**或统计模型：从资料中度量亲属之间表型的相似程度，例如亲属表型之间的协方差或相关、子代表型对亲本表型的回归。若亲属的表型比非亲属更相似，就说明性状具有遗传基础。第二是**因果模型**：根据数量遗传理论，预测亲属之间应当有多大程度的相似，这取决于他们之间的遗传关系——即共享了多大比例的同祖同源等位基因——以及遗传方差及其各组分的大小。把观察到的相似性与因果模型的预期联系起来，就能够估计遗传力与遗传方差（第 13 章），预测个体的育种值（第 15 章、第 21 章），检测与评价 QTL（第 8 章），并预测选择反应（第 14 章）。本章建立因果模型。

11.2 同状态与同祖同源

亲属之所以在基因型上相似，是因为他们从共同祖先那里获得了一些相同的等位基因。判断两个等位基因是否“相同”有两种含义。

同状态 (identity by state, IBS)：若能对两个个体的某个位点分型，就

可以直接判断他们携带的等位基因在序列上是否相同。例如两个个体都携带 SNP 的 A 等位基因，它们在该位点同状态。

同祖同源 (identity by descent, IBD): 两个等位基因是同一个祖先等位基因的拷贝。通常无法直接观察致因位点，但若两个个体有共同祖先，就可以依据系谱计算他们的等位基因来自同一祖先拷贝的概率。同祖同源的等位基因必然同状态（忽略突变），而同状态的等位基因未必同祖同源——它们可能只是恰好在群体中都很常见。

同祖同源总是相对于某个**基础群体**定义的：假定基础群体中所有个体的等位基因都不同祖同源，再追踪此后系谱中的传递。基础群体的选择是一种约定，改变它会改变所有的同祖同源概率（第 12 章）。

11.2.1 亲缘系数、加性关系与显性关系

设个体 o 的父本为 s 、母本为 d ，其父源与母源等位基因分别记为 o_p 与 o_m ；个体 o' 的等位基因记为 o'_p 与 o'_m 。两个个体之间有四对等位基因： (o_p, o'_p) 、 (o_m, o'_m) 、 (o_p, o'_m) 、 (o_m, o'_p) 。由它们的同祖同源概率可以定义三个关系度量。

亲缘系数 (coefficient of coancestry, 或称共祖系数、亲属系数) $f_{oo'}$: 从 o 随机抽取一个等位基因、从 o' 随机抽取一个等位基因，二者同祖同源的速率，即四个同祖同源速率的平均：

$$f_{oo'} = \frac{1}{4} [\Pr(o_p \equiv o'_p) + \Pr(o_m \equiv o'_m) + \Pr(o_p \equiv o'_m) + \Pr(o_m \equiv o'_p)]. \quad (11.1)$$

亲缘系数恰好等于 o 与 o' 交配所产生的后代的近交系数，因为后代的两个等位基因正是从双亲各随机抽取的一个。

加性遗传关系 (加性关系系数) $r_{oo'} = 2f_{oo'}$: 两个个体共享等位基因的平均比例。对非近交个体， $r_{oo'}$ 等于四个同祖同源速率之和的一半。

显性关系系数 $u_{oo'}$: 两个个体在该位点上的两个等位基因都同祖同源，即共享整个基因型的速率：

$$u_{oo'} = \Pr(o_p \equiv o'_p) \Pr(o_m \equiv o'_m) + \Pr(o_p \equiv o'_m) \Pr(o_m \equiv o'_p). \quad (11.2)$$

式 (11.2) 假定父源与母源两侧的同祖同源事件独立, 这在双亲之间无亲缘时成立。

表 11.1 给出了常见亲属的同祖同源概率与关系系数。以全同胞为例: 两人的父源等位基因都来自父亲, 以概率二分之一是父亲的同一个等位基因; 母源同理; 父源与母源之间 (若父母无亲缘) 不可能同祖同源。于是 $f = \frac{1}{4}(\frac{1}{2} + \frac{1}{2}) = \frac{1}{4}$, $r = \frac{1}{2}$, $u = \frac{1}{2} \times \frac{1}{2} = \frac{1}{4}$ 。半同胞只共享父亲 (或母亲), 只有一对等位基因可能同祖同源, $f = \frac{1}{8}$, $r = \frac{1}{4}$, $u = 0$ 。

表 11.1 常见亲属的同祖同源概率与关系系数 (非近交、双亲无亲缘)

亲属 关系	$o_p \equiv o'_p$	$o_m \equiv o'_m$	$o_p \equiv o'_m$	$o_m \equiv o'_p$	f	r	u
父— 子	$\frac{1}{2}$	0	0	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{2}$	0
母— 子	0	$\frac{1}{2}$	$\frac{1}{2}$	0	$\frac{1}{4}$	$\frac{1}{2}$	0
父系 半同 胞	$\frac{1}{2}$	0	0	0	$\frac{1}{8}$	$\frac{1}{4}$	0
全同 胞	$\frac{1}{2}$	$\frac{1}{2}$	0	0	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$
同卵 双生	1	1	0	0	$\frac{1}{2}$	1	1
祖孙、 叔侄	—	—	—	—	$\frac{1}{8}$	$\frac{1}{4}$	0
堂 (表) 兄弟 姐妹	—	—	—	—	$\frac{1}{16}$	$\frac{1}{8}$	0

亲属 关系	$o_p \equiv o'_p$	$o_m \equiv o'_m$	$o_p \equiv o'_m$	$o_m \equiv o'_p$	f	r	u
双重 堂表 兄弟 姐妹	—	—	—	—	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{16}$

用基因下落法可以对任意系谱数值地验证这些系数：给基础个体的每个等位基因一个唯一的标签，按孟德尔规律随机地向下传递，重复许多次，统计两个个体之间等位基因标签相同的频率。对一个包含亲子、全同胞、半同胞、祖孙、叔侄与堂表兄弟的系谱，二十万次基因下落给出的亲缘系数与表 11.1 的理论值在千分之一以内一致（全同胞 $f = 0.2499$ 、 $u = 0.2503$ ；堂表兄弟 $f = 0.0624$ ）。第 12 章将给出计算整个系谱关系矩阵的递推算法。

11.2.2 同一性状态与雅卡尔系数

更一般地，两个个体的四个等位基因之间的同祖同源关系，可以分为十五种可能的“同一性状态”；若不区分父源与母源，可以合并为九种“压缩的同一性状态”，其概率记为 $\Delta_1, \dots, \Delta_9$ （雅卡尔，1974）。例如 Δ_7 是两个个体共享两个同祖同源等位基因、且各自不近交的概率， Δ_8 是只共享一个、各自不近交的概率， Δ_9 是什么也不共享的概率。前六种状态都涉及至少一个个体近交。对非近交个体，

$$f = \frac{1}{2}\Delta_7 + \frac{1}{4}\Delta_8, \quad u = \Delta_7.$$

在近交个体之间，遗传协方差需要用全部九个系数表示，并会出现新的方差与协方差组分（例如近交个体中加性效应与纯合显性偏差之间的协方差）。这使近交群体中的亲属相似性理论相当复杂，第 19 章将在讨论近交时回到这一点。

11.3 遗传协方差的因果模型

11.3.1 单位点推导

设性状受一个位点影响，个体 o 的基因型值写为两个等位基因平均效应与显性偏差之和：

$$G_o = \alpha_{o_p} + \alpha_{o_m} + \delta_{o_{pm}}, \quad G_{o'} = \alpha_{o'_p} + \alpha_{o'_m} + \delta_{o'_{pm}}.$$

由于加性效应与显性偏差在定义上不相关，

$$\text{Cov}(G_o, G_{o'}) = \sum_{x,y \in \{p,m\}} \text{Cov}(\alpha_{o_x}, \alpha_{o'_y}) + \text{Cov}(\delta_{o_{pm}}, \delta_{o'_{pm}}).$$

考察第一项中的一对，例如 (o_p, o'_p) 。它们要么同祖同源，要么不同祖同源。若同祖同源，二者是同一个等位基因的拷贝，平均效应相同；若不同祖同源，二者是从群体中独立抽取的两个等位基因，平均效应不相关。由于平均效应的期望为零，

$$\text{Cov}(\alpha_{o_p}, \alpha_{o'_p}) = E(\alpha^2) \Pr(o_p \equiv o'_p) = \Pr(o_p \equiv o'_p) \cdot \frac{1}{2} V_A,$$

这里用到了第 10 章的结果：单个等位基因效应的方差为 $pq\alpha^2 = \frac{1}{2} V_A$ 。对四对等位基因求和，

$$\sum \text{Cov}(\alpha, \alpha') = \frac{1}{2} V_A \sum \Pr(\equiv) = \frac{1}{2} V_A \cdot 4f_{oo'} = r_{oo'} V_A.$$

显性偏差依赖于两个等位基因的组合，只有当两个个体的两个等位基因都同祖同源（按任一种配对方式）时，二者的显性偏差才相同；否则不相关。于是 $\text{Cov}(\delta, \delta') = u_{oo'} V_D$ 。合并得到

$$\text{Cov}(G_o, G_{o'}) = r_{oo'} V_A + u_{oo'} V_D. \quad (11.3)$$

式 (11.3) 对每个位点都成立；对多个连锁平衡的位点求和，它同样适用于总的加性与显性方差。其含义十分清晰：亲属共享比例 r 的等位基因，因而共享比例 r 的加性方差；共享概率为 u 的完整基因型，因而共享比例 u 的显性方差。

用单位点模拟可以直接检验式 (11.3)。取 $p = 0.3$ 、 $a = 1$ 、 $d = 0.8$ ， $V_A = 0.732$ ， $V_D = 0.113$ 。四十万组模拟中，亲子之间基因型值的协方差为 0.3653（理论 $\frac{1}{2}V_A = 0.3659$ ），全同胞之间为 0.3935（理论 $\frac{1}{2}V_A + \frac{1}{4}V_D = 0.3941$ ），半同胞之间为 0.1839（理论 $\frac{1}{4}V_A = 0.1830$ ）。

11.3.2 上位方差的系数

肯普索恩 (1954, 1955) 把式 (11.3) 推广到存在上位的情形。在随机交配、连锁平衡且无近交时，

$$\text{Cov}(G_o, G_{o'}) = rV_A + uV_D + r^2V_{AA} + ruV_{AD} + u^2V_{DD} + r^3V_{AAA} + \dots \quad (11.4)$$

其中 $r = 2f$ 。各上位组分的系数是相应加性与显性系数的乘积：加性 $\times$ 加性互作需要在两个位点上都共享等位基因，概率为 $r \cdot r$ ；依此类推。表 11.2 列出了几种亲属的系数。

表 11.2 亲属间遗传协方差的组成系数（科克汉姆—肯普索恩）

亲属	V_A	V_D	V_{AA}	V_{AD}	V_{DD}
亲子	$\frac{1}{2}$	0	$\frac{1}{4}$	0	0
半同胞	$\frac{1}{4}$	0	$\frac{1}{16}$	0	0
全同胞	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{16}$
同卵双生	1	1	1	1	1
一般公式	r	u	r^2	ru	u^2

表 11.2 揭示了用亲属资料分解遗传方差的困难：不同亲属的系数组合高度相关，要把上位方差与加性、显性方差分开，需要多种亲属类型的大量资料，而估计误差往往大到难以得出可靠结论。在实践中，上位方差通常被并入加性或显性方差中。注意，半同胞与亲子协方差中各含 $\frac{1}{16}V_{AA}$ 与 $\frac{1}{4}V_{AA}$ ，因此由这些亲属估计的“加性方差”实际上略包含了上位方差，用于长期预测时可能偏高。

11.4 基于育种值传递的推导

11.4.1 孟德尔抽样

式 (11.3) 也可以用另一种方式推导, 它更贴近育种实践。由第 3 章式 (3.2), 后代的育种值可以写为

$$A_o = \frac{1}{2}A_s + \frac{1}{2}A_d + R_{A_s} + R_{A_d}, \quad (11.5)$$

其中 R_{A_s} 、 R_{A_d} 是孟德尔抽样项, 反映父母在减数分裂中随机传递两个等位基因之一所造成的偏差。孟德尔抽样项与父母的育种值独立, 均值为零。其方差可以用单位点模型计算: 纯合亲本总是传递同一个等位基因, 没有孟德尔抽样偏差; 杂合亲本 A_1A_2 以各二分之一的概率传递 A_1 或 A_2 , 后代均值相对于亲本育种值的一半分别偏离 $+\frac{1}{2}\alpha$ 与 $-\frac{1}{2}\alpha$ 。于是

$$\text{Var}(R_A) = 2pq \cdot \frac{1}{2} \left[\left(\frac{1}{2}\alpha \right)^2 + \left(-\frac{1}{2}\alpha \right)^2 \right] = \frac{1}{2}pq\alpha^2 = \frac{1}{4}V_A.$$

若亲本近交系数为 F , 其杂合概率降为 $2pq(1-F)$, 孟德尔抽样方差相应降为 $\frac{1}{4}(1-F)V_A$ 。在无近交、无选择时,

$$\text{Var}(A_o) = \frac{1}{4}V_A + \frac{1}{4}V_A + \frac{1}{4}V_A + \frac{1}{4}V_A = V_A,$$

一半加性方差来自父母育种值的平均, 另一半来自孟德尔抽样。这一分解是动物模型中关系矩阵逆矩阵的结构基础 (第 12 章、第 22 章): 已知双亲时, 个体育种值中真正“新”的信息只有孟德尔抽样部分, 其方差为 $\frac{1}{2}V_A$ 乘以 $1 - \frac{1}{2}(F_s + F_d)$ 。

11.4.2 若干亲属协方差的直接推导

由式 (11.5), 只考虑加性效应, 且假设父母无亲缘、无共同环境:

亲子: $\text{Cov}(P_o, P_s) = \text{Cov}(\frac{1}{2}A_s + \dots, A_s + E_s) = \frac{1}{2}V_A$ 。

半同胞 (共同父亲): $\text{Cov}(P_o, P_{o'}) = \text{Cov}(\frac{1}{2}A_s, \frac{1}{2}A_s) = \frac{1}{4}V_A$ 。

全同胞: $\text{Cov}(P_o, P_{o'}) = \text{Cov}(\frac{1}{2}A_s, \frac{1}{2}A_s) + \text{Cov}(\frac{1}{2}A_d, \frac{1}{2}A_d) = \frac{1}{2}V_A$ 。

两种推导的结果一致，但它们侧重不同：同祖同源推导揭示了协方差的遗传机制，并能自然地扩展到显性与上位；育种值传递推导则给出了预测育种值所需的递推结构。

11.4.3 由协方差到回归与相关

亲属协方差直接决定了第 13 章用于估计遗传参数的统计量。

子代对单亲的回归： $b_{OP} = \frac{\text{Cov}(P_o, P_s)}{V_P} = \frac{\frac{1}{2}V_A}{V_P} = \frac{1}{2}h^2$ 。显性方差不进入亲子协方差，因此亲子回归估计的是狭义遗传力。

子代对双亲均值的回归：双亲均值的方差为 $\frac{1}{2}V_P$ ，与子代的协方差为 $\frac{1}{2}V_A$ ， $b_{OP} = h^2$ 。

半同胞组内相关： $t_{HS} = \frac{1}{4}V_A/V_P = \frac{1}{4}h^2$ 。

全同胞组内相关： $t_{FS} = (\frac{1}{2}V_A + \frac{1}{4}V_D)/V_P = \frac{1}{2}h^2 + \frac{1}{4}V_D/V_P$ 。显性方差进入全同胞协方差，因此由全同胞资料估计的遗传力往往偏高。

同卵双生的相关： $t_{MZ} = V_G/V_P = H^2$ ，估计广义遗传力。

11.5 共同环境与母体效应

11.5.1 共同环境

亲属之间的相似不仅来自共享的基因，也可能来自共享的环境：同窝仔猪共同的母猪哺育环境，同栏饲养的个体，在同一家庭成长的兄弟姐妹。设 E_c 为家系成员共同的环境效应， E_w 为个体独有的环境效应：

$$P = A + E_c + E_w, \quad V_P = V_A + V_{E_c} + V_{E_w}.$$

对在共同环境中成长的全同胞，

$$\text{Cov}(P_o, P_{o'}) = \frac{1}{2}V_A + V_{E_c}, \quad t_{FS} = \frac{1}{2}h^2 + c^2, \quad c^2 = \frac{V_{E_c}}{V_P}. \quad (11.6)$$

共同环境使全同胞相关高于遗传所预期的水平，进一步加剧了用全同胞资料估计遗传力的偏差。共同环境的协方差也可能为负：例如同窝个体对有限资源的竞争、群养动物之间的争斗，会使家系成员的表现呈现负相关。第 22 章讨论的社会遗传效应是这一问题的遗传版本。

11.5.2 母体效应

哺乳动物幼畜的生长与存活很大程度上受母亲影响。母亲提供的子宫环境、泌乳量与哺育行为构成后代表型的一部分，而这部分本身又部分地由母亲的基因型决定。威尔汉姆（1963, 1972）建立了母体效应的数量遗传模型：个体 i 的表型由自身的直接遗传效应 $A_{o,i}$ 、其母亲的母体遗传效应 $A_{m,dam(i)}$ 、母体永久环境效应与个体环境效应组成：

$$P_i = A_{o,i} + A_{m,dam(i)} + E_{m,dam(i)} + E_i.$$

直接效应与母体效应来自同一组基因对两种不同“性状”（自身生长能力与哺育后代的能力）的作用，它们之间存在遗传协方差 $\sigma_{A_o A_m}$ ，并且常常为负：生长快的个体作为母亲时哺育能力反而可能较差。在这一模型下，不同亲属之间的表型协方差为：

表 11.3 母体效应模型中的亲属协方差（威尔汉姆模型，忽略显性）

亲属	$\sigma_{A_o}^2$	$\sigma_{A_o A_m}$	$\sigma_{A_m}^2$	$\sigma_{E_m}^2$
父系半同胞	$\frac{1}{4}$	0	0	0
母系半同胞	$\frac{1}{4}$	1	1	1
全同胞	$\frac{1}{2}$	1	1	1
父—子	$\frac{1}{2}$	$\frac{1}{4}$	0	0
母—子	$\frac{1}{2}$	$\frac{5}{4}$	$\frac{1}{2}$	0

以母—子协方差为例：母亲自身的表型包含其直接效应 $A_{o,dam}$ 与外祖母的母体效应；后代的表型包含其直接效应 $A_{o,i}$ （与母亲直接效应的协方差为 $\frac{1}{2}\sigma_{A_o}^2$ ）与母亲的母体效应 $A_{m,dam}$ （与母亲自身直接效应的协方差为 $\sigma_{A_o A_m}$ ，与外祖母母体效应的协方差为 $\frac{1}{2}\sigma_{A_m}^2$ ），再加上后代直接效应与外祖母母体效应之间的 $\frac{1}{4}\sigma_{A_o A_m}$ ，合计 $\frac{1}{2}\sigma_{A_o}^2 + \frac{5}{4}\sigma_{A_o A_m} + \frac{1}{2}\sigma_{A_m}^2$ 。

这张表说明了母体效应造成的主要困难与机会。困难在于：母系半同胞、全同胞与母—子的相似性都被母体效应“抬高”了，若忽略母体效应而用这些资料估计直接遗传力，会得到偏高的结果。机会在于：比较父系与母系半

同胞、父—子与母—子的协方差，可以分离出母体方差与直接—母体协方差。实际中，多代系谱与动物模型使这种分离成为可能（第 22 章）。范弗莱克（1993）还讨论了更复杂的情形：外祖母效应（母亲的母亲影响母亲的母体能力）、胎儿父本效应（胎儿的基因型影响母体妊娠表现，如难产）以及经母系传递的细胞质效应。

11.5.3 性连锁与细胞质遗传

X 连锁位点的遗传协方差有其特殊的模式。父亲把 X 染色体全部传给女儿而不传给儿子，因此父亲与女儿之间的 X 连锁协方差相当可观，父亲与儿子之间为零；母亲则以各一半的概率把两条 X 染色体之一传给儿女。在鸟类中，性染色体为 ZW 型，模式与哺乳动物相反。线粒体等细胞质遗传因子只经母系传递，使母系亲属之间产生额外的相似性，而父系亲属之间没有。这些特殊的协方差模式，可以作为检测性连锁或细胞质遗传效应的依据。

11.6 一组亲属表型均值的方差

许多选择方法利用的不是单个亲属的表型，而是一组亲属的平均表型，例如一头公畜所有女儿的平均产奶量、一窝仔猪的平均日增重。设 n 个亲属的表型两两之间的相关（组内相关）为 t ，表型方差为 V_P ，则它们均值的方差为

$$\text{Var}(\bar{P}_n) = \frac{1}{n^2} [nV_P + n(n-1)tV_P] = \left[t + \frac{1-t}{n} \right] V_P. \quad (11.7)$$

当 $t = 0$ 时，均值的方差为 V_P/n ，随 n 增大而趋于零；当 $t > 0$ 时，均值的方差不能低于 tV_P ，因为组内共同的部分无法通过平均来消除（图 11.1A）。对全同胞， $t = \frac{1}{2}h^2 + c^2$ ；对半同胞， $t = \frac{1}{4}h^2$ 。这一简单公式贯穿于家系选择、后裔测定与同胞测定的理论之中：后裔测定中女儿数从 10 头增加到 100 头，公畜评定的准确度大幅提高；但增加到 1000 头，收益已经很小（第 15 章）。




图 11.1 亲属均值的方差与实际遗传关系。A 图为组内相关为 t 的 n 个个体表型均值的方差（以表型方差为单位）；B 图为模拟的全同胞之间实际同祖同源比例的分布，分别对应人类基因组（22 条常染色体，约 35 摩尔根）与一个约 30 摩尔根的家畜基因组

11.7 期望关系与实际关系：基于标记的亲缘

11.7.1 关系的随机性

表 11.1 中的关系系数都是**期望值**。全同胞之间共享等位基因的期望比例为二分之一，但具体到某一对全同胞，由于孟德尔抽样与染色体上有限次数的交换，他们实际共享的比例可能是 0.45，也可能是 0.55。在一个无限多独立位点的基因组中，实际共享比例会无限接近期望值；而真实的基因组由几十条染色体组成，每条染色体每次减数分裂只有约一两次交换，同一染色体上相邻位点的同祖同源状态高度相关，因此实际关系围绕期望值有相当的离散。

图 11.1B 模拟了全同胞之间同祖同源比例的分布。对人类基因组（22 条常染色体，约 35 摩尔根），实际共享比例的标准差约为 0.039，95% 的全同胞对落在 0.42 至 0.57 之间；对一个约 30 摩尔根的家畜基因组，标准差约 0.040。希尔与韦尔（2011）给出了近似公式：实际关系的方差与基因组总长度大致成反比，并依赖于染色体数目。维舍尔等（2006）利用这一自然的“随机化”，在三千余对澳大利亚同胞中用标记估计每对同胞的实际共享比例，仅利用同胞内实际关系的差异来估计身高的遗传力，得到约 0.8 的估计。由于同胞对的实际共享比例在家庭内部是随机的，与共同环境无关，这一方法规避了双

生子与家系研究中“遗传与共同环境混杂”的困难，为人类身高的高遗传力提供了独立的证据。

11.7.2 基因组关系

利用全基因组标记，可以直接估计任意两个个体之间的实际遗传关系，而不必依赖系谱。在单个 SNP k 上，两个个体 o 、 o' 的关系可以写成类似相关系数的形式：

$$r_{oo',k} = \frac{(x_{ok} - 2p_k)(x_{o'k} - 2p_k)}{2p_kq_k},$$

其中 x_{ok} 为个体 o 在该位点上某一等位基因的拷贝数， p_k 为该等位基因在参照群体中的频率。对 m 个位点平均，

$$\hat{r}_{oo'} = \frac{1}{m} \sum_{k=1}^m \frac{(x_{ok} - 2p_k)(x_{o'k} - 2p_k)}{2p_kq_k} \quad \text{或} \quad \hat{r}_{oo'} = \frac{\sum_k (x_{ok} - 2p_k)(x_{o'k} - 2p_k)}{\sum_k 2p_kq_k}. \quad (11.8)$$

前者对每个位点标准化后平均，稀有等位基因的位点获得较大权重；后者先对分子分母分别求和，相当于以 $2p_kq_k$ 为权重的加权平均，这是范雷登 (2008) 提出的基因组关系矩阵的常用形式。两种方法哪种更好，取决于标记效应方差与等位基因频率之间的关系，至今仍有讨论（第 26 章）。

基因组关系有几个重要性质。第一，它度量的是相对于参照群体等位基因频率的相似性：两个个体若都携带群体中较少见的等位基因，它们的关系值为正且较大；若一个携带常见、一个携带稀有等位基因，关系值为负。负的关系值并不意味着“负的共同祖先”，只表示二者比群体中随机两个个体更不相似。第二，它不仅捕获系谱记录内的近期亲缘，也捕获系谱之外更久远的共同祖先关系，以及系谱错误。第三，它的期望在系谱完整且频率取自基础群体时与系谱关系相同，但每一对个体的实际值围绕期望波动，波动的大小正是上面讨论的孟德尔抽样造成的实际关系的离散。在蛋鸡等家禽品系中比较系谱关系与基因组关系，可以清楚地看到：系谱关系相同的全同胞，其基因组关系从约 0.35 到 0.65 分布，而系谱上无关的个体之间也普遍存在 0.05 至 0.15 的基因组关系，后者反映了系谱基础群体之前的共同祖先。

鲍威尔、维舍尔与戈达德 (2010) 系统地讨论了“同祖同源”与“同状

态”在基因组时代的含义：严格意义上的同祖同源依赖于一个任意选定的基础群体，而基于标记的关系实质上是相对于参照频率的“相关”；对于预测与参数估计而言，重要的不是名称，而是所用的关系矩阵与资料的生成过程是否相容。这一观点贯穿本书第八篇。

11.8 双生子设计与人类数量遗传学

在不能进行实验交配的人类中，双生子提供了一个天然的试验。同卵双生（MZ）共享全部基因，异卵双生（DZ）与普通全同胞一样平均共享一半的等位基因。若两类双生子共享相同程度的共同环境，则

$$t_{MZ} = h^2 + d^2 + c^2, \quad t_{DZ} = \frac{1}{2}h^2 + \frac{1}{4}d^2 + c^2,$$

其中 $h^2 = V_A/V_P$, $d^2 = V_D/V_P$, $c^2 = V_{E_c}/V_P$ 。忽略显性，得到福尔克纳公式

$$\hat{h}^2 = 2(t_{MZ} - t_{DZ}), \quad \hat{c}^2 = 2t_{DZ} - t_{MZ}, \quad \hat{e}^2 = 1 - t_{MZ}. \quad (11.9)$$

例如，若身高的同卵与异卵双生相关分别为 0.86 与 0.47，则 $\hat{h}^2 = 0.78$, $\hat{c}^2 = 0.08$, $\hat{e}^2 = 0.14$ 。现代分析采用结构方程模型同时拟合加性遗传（A）、共同环境（C）或显性（D）以及独有环境（E）组分，称为 ACE 或 ADE 模型，并用似然比检验比较模型。

西尔文托宁等（2003）比较了八个国家双生子队列的成人身高，发现身高的遗传力在男性中约为 0.87 至 0.93，在女性中约为 0.68 至 0.84，各国之间相当一致，而共同环境的作用在女性中略大。这些高遗传力估计后来成为全基因组关联研究“缺失遗传力”讨论的起点（第 25 章）。

双生子设计依赖于几个关键假定：同卵与异卵双生所处的共同环境程度相同（等环境假定）；双生子在性状上可以代表一般人群；父母之间没有同型交配（同型交配会提高异卵双生的相关，使 $\hat{h}^2$ 偏低、 $\hat{c}^2$ 偏高）；没有基因与环境的相关和互作。这些假定都可能被违反，因此双生子遗传力应当被理解为特定人群、特定时代条件下的估计。家畜中虽然少有双生子，但胚胎分

割与克隆提供了类似的“遗传一致”个体，可以用于估计广义遗传力与环境方差。

11.9 深入专题

11.9.1 近交个体之间的遗传协方差

式(11.3)假定两个个体都不近交。当个体近交时，同一个体的两个等位基因可能同祖同源，显性偏差不再只是等位基因组合的“杂合”效应，还包括纯合效应，遗传协方差需要更多的组分来描述。哈里斯(1964)与科克汉姆(1971)证明，在只有加性与显性作用时，两个近交个体之间的遗传协方差可以写为雅卡尔九个压缩同一性系数的线性组合：

除了 $2\theta_{xy}\sigma_A^2$ 与 $\Delta_7\sigma_D^2$ 两项之外，还出现加性效应与纯合显性偏差之间的协方差 D_1 、纯合显性偏差的方差 D_2^* 以及与近交衰退平方有关的项 H^* ，它们的系数是 $\Delta_1, \dots, \Delta_8$ 的不同线性组合。这些额外的组分在随机交配群体中不出现，在高度近交的群体（如自交作物、近交实验动物）中则可能相当重要。它们的估计需要包含不同近交程度个体的复杂资料，实践中较少使用；但它们提醒我们：在近交群体中，以非近交理论解释亲属相似性可能是不完整的。

11.9.2 标记推断的同祖同源片段

第11章的基因组关系度量的是全基因组的平均相似性。另一种方法是直接识别两个个体之间共享的**同祖同源片段**：若两个个体在一段较长的染色体区域上共享一条单倍型，该片段很可能来自一个近期的共同祖先。片段的长度携带了共同祖先远近的信息：来自 g 代前共同祖先的片段，经过两条谱系上共 $2g$ 次减数分裂的切割，其长度近似服从均值为 $100/(2g)$ 厘摩的指数分布。由全部共享片段的总长度可以估计两个个体的实际亲缘系数，由片段的长度分布可以推断亲缘的类型（例如区分祖孙、叔侄与半同胞，三者的期望亲缘系数相同，但共享片段的数目与长度分布不同）。

同祖同源片段的识别在人类遗传学中用于检测隐性亲缘与远亲关系、推

断群体历史；在家畜中，用于系谱核查、识别未记录的亲缘、估计个体近交程度（第 19 章的纯合片段即同一个体两条单倍型之间的同祖同源片段），以及进行基于单倍型共享的关联分析。与基于频率的基因组关系相比，基于片段的关系对等位基因频率的选择敏感，更接近“同祖同源”的本义。

11.9.3 亲属相似性的完整概率框架

把以上各种情形统一起来，亲属表型的协方差矩阵可以写为若干“关系矩阵”与相应方差组分的线性组合：

$$\text{Var}(\mathbf{y}) = \mathbf{A}\sigma_A^2 + \mathbf{D}\sigma_D^2 + \mathbf{A}\#\mathbf{A}\sigma_{AA}^2 + \mathbf{Z}_m\mathbf{A}\mathbf{Z}_m'\sigma_{A_m}^2 + \cdots + \mathbf{Z}_c\mathbf{Z}_c'\sigma_c^2 + \mathbf{I}\sigma_e^2,$$

$\mathbf{A}$ 为加性关系矩阵， $\mathbf{D}$ 为显性关系矩阵（元素为 u_{xy} ）， $\mathbf{A}\#\mathbf{A}$ 为加性 $\times$ 加性上位的关系矩阵（阿达马积）， $\mathbf{Z}_m$ 把个体连接到其母亲， $\mathbf{Z}_c$ 把个体连接到共同环境。这一框架就是混合模型的协方差结构：表 11.1—11.3 中的各种系数，都是这些矩阵中相应元素的特例。第 21—24 章将在这一框架下讨论参数估计与育种值预测；第 27 章将把 $\mathbf{A}$ 换成基因组关系矩阵 $\mathbf{G}$ ，并用 $\mathbf{G}\#\mathbf{G}$ 等核矩阵描述上位。

11.10 本章小结

亲属相似性的分析由观察模型与因果模型两部分组成，前者度量相似程度，后者依据遗传关系与方差组分预测相似程度。同祖同源是相对于基础群体定义的；亲缘系数是两个个体各随机抽取一个等位基因而同祖同源的的概率，加性关系为其两倍，显性关系是共享完整基因型的概率。亲属间的遗传协方差为 $rV_A + uV_D$ ，存在上位时还包括 r^2V_{AA} 、 ruV_{AD} 、 u^2V_{DD} 等项；亲子与半同胞协方差只含加性与加性 $\times$ 加性组分，全同胞协方差还含显性组分。育种值可以分解为双亲育种值的平均与孟德尔抽样，后者的方差为 $\frac{1}{4}(1-F)V_A$ ，这是关系矩阵逆矩阵的结构基础。共同环境与母体效应使某些亲属的相似性高于遗传预期，母体效应模型给出不同亲属类型的协方差系数，可用于分离直接与母体方差。 n 个相关个体均值的方差为 $[t + (1-t)/n]V_p$ ，存在不可平均的下限。期望关系与实际关系不同，全同胞的实际共享比例标

准差约为 0.04；基因组关系以参照群体频率为基准度量实际相似性，可以捕获系谱之外的亲缘与孟德尔抽样的实现。双生子设计以福尔克纳公式估计遗传力，其结论依赖于等环境等若干假定。

11.11 习题

习题 11.1 计算以下亲属的亲缘系数、加性关系与显性关系：外祖母与外孙；同父异母兄弟的子女之间；双重堂表兄弟。

习题 11.2 由式 (11.4)，写出祖孙、叔侄与堂表兄弟之间遗传协方差中 V_A 、 V_D 、 V_{AA} 的系数，并说明为什么叔侄与祖孙的系数相同。

习题 11.3 设 $V_A = 40$ 、 $V_D = 10$ 、 $V_{E_c} = 8$ 、 $V_{E_w} = 42$ 。计算全同胞（共同环境中长大）与半同胞的组内相关，以及由全同胞相关按 $2t_{FS}$ 估计的“遗传力”与真实遗传力之差。

习题 11.4 某性状表型方差为 100，全同胞组内相关为 0.3。求 10 个与 50 个全同胞平均表型的方差；若为半同胞且组内相关为 0.08 呢？

习题 11.5 在威尔汉姆母体效应模型中，设 $\sigma_{A_o}^2 = 0.30$ ， $\sigma_{A_m}^2 = 0.10$ ， $\sigma_{A_o A_m} = -0.06$ ， $\sigma_{E_m}^2 = 0.05$ ，表型方差为 1。计算父系半同胞、母系半同胞与母—子之间的协方差。

习题 11.6 两个个体在 4 个 SNP 上的基因型为 (2,1,0,1) 与 (1,1,0,2)，参照频率为 (0.5,0.3,0.2,0.6)。分别用式 (11.8) 的两种形式计算它们的基因组关系。

习题 11.7 某性状同卵与异卵双生相关分别为 0.60 与 0.40。按福尔克纳公式估计 h^2 、 c^2 、 e^2 。若父母之间存在正向同型交配，这些估计会怎样偏差？

11.12 习题解答

11.1 外祖母与外孙： $f = \frac{1}{8}$ ， $r = \frac{1}{4}$ ， $u = 0$ 。同父异母兄弟的子女：唯一的共同祖先是祖父，从一方经其父亲到祖父有 2 代、从另一方同样有 2 代，按通径法 $f = (\frac{1}{2})^{2+2+1} = \frac{1}{32}$ ， $r = \frac{1}{16}$ ， $u = 0$ 。双重堂表兄弟： $f = \frac{1}{8}$ ， $r = \frac{1}{4}$ ，

$$u = \frac{1}{16}。$$

11.2 三者 $u = 0$ 。祖孙与叔侄 $r = \frac{1}{4}$ ：系数为 V_A 的 $\frac{1}{4}$ 、 V_{AA} 的 $\frac{1}{16}$ ；堂表兄弟 $r = \frac{1}{8}$ ： $\frac{1}{8}$ 与 $\frac{1}{64}$ 。叔侄与祖孙的加性关系相同，且都只能共享一个同祖同源等位基因，故系数相同。

11.3 $V_P = 100$ 。 $t_{FS} = (20 + 2.5 + 8)/100 = 0.305$, $t_{HS} = 10/100 = 0.10$ 。
 $2t_{FS} = 0.61$ ，真实 $h^2 = 0.40$ ，高估 0.21，来自显性方差与共同环境。

11.4 全同胞： $n = 10$, $(0.3 + 0.07) \times 100 = 37$; $n = 50$, $(0.3 + 0.014) \times 100 = 31.4$ 。半同胞： $n = 10$, $(0.08 + 0.092) \times 100 = 17.2$; $n = 50$, $(0.08 + 0.0184) \times 100 = 9.84$ 。

11.5 父系半同胞： $\frac{1}{4} \times 0.30 = 0.075$ 。母系半同胞： $0.075 - 0.06 + 0.10 + 0.05 = 0.165$ 。母—子： $0.15 + \frac{5}{4} \times (-0.06) + 0.05 = 0.125$ 。

11.6 中心化值：个体一 $(2 - 1, 1 - 0.6, 0 - 0.4, 1 - 1.2) = (1, 0.4, -0.4, -0.2)$ ；个体二 $(0, 0.4, -0.4, 0.8)$ 。 $2pq$ ： $(0.5, 0.42, 0.32, 0.48)$ 。逐点乘积： $(0, 0.16, 0.16, -0.16)$ 。第一种： $\frac{1}{4}(0 + 0.381 + 0.5 - 0.333) = 0.137$ ；第二种： $0.16/1.72 = 0.093$ 。

11.7 $h^2 = 0.40$, $c^2 = 0.20$, $e^2 = 0.40$ 。正向同型交配使异卵双生共享的加性遗传多于二分之一， t_{DZ} 升高，因而 $\hat{h}^2$ 偏低、 $\hat{c}^2$ 偏高。

11.13 补充习题

习题 11.8 祖孙、叔侄与（父系）半同胞的加性关系都是 $\frac{1}{4}$ 。说明为什么它们共享的同祖同源片段的平均数目与平均长度不同，从而可以由基因组资料区分。

习题 11.9 写出一个全同胞家系（4 个后代）在只有加性、显性与共同环境效应时表型协方差矩阵的形式。

11.14 补充习题解答

11.8 三者共享的同祖同源片段的期望总长度相同（约为基因组的四分之一），但片段在两条谱系上经历的减数分裂次数与方式不同：半同胞的共

享片段各经一次减数分裂、来自共同亲本的同一条单倍型；祖孙的共享片段是祖辈传给父母的那条染色体再经一次减数分裂传给孙辈，片段数目较少而较长；叔侄的共享片段需要先在叔叔与侄子的父亲（全同胞）之间共享，再经一次减数分裂传给侄子，片段数目较多而较短。因此片段的数目与长度分布不同，可以由高密度标记资料区分。

11.9 $\text{Var}(\mathbf{y}) = \sigma_P^2 \mathbf{I} + (\frac{1}{2}\sigma_A^2 + \frac{1}{4}\sigma_D^2 + \sigma_c^2)(\mathbf{J} - \mathbf{I})$ ，其中 $\mathbf{J}$ 为全 1 矩阵，对角元素为 $\sigma_P^2 = \sigma_A^2 + \sigma_D^2 + \sigma_c^2 + \sigma_e^2$ 。

系谱亲缘、近交与遗传连接

12

12.1 同祖同源是一种有基准的概率

两只动物在一个位点上具有相同等位基因，可能因为它们从共同祖先继承了同一个遗传拷贝，也可能只是该等位基因在群体中很常见。前一种关系称为同祖同源，后一种观察只能说明状态相同。若一个等位基因在群体中频率很高，两只无已知近亲关系的动物也很容易状态相同。用状态相同代替同祖同源，会把群体频率、历史共享与近期亲缘混为一谈。

同祖同源必须相对于一个基础群体定义。追溯足够久，许多个体终究具有共同祖先；实际分析不可能无限回溯，而是在指定时间或来源群体设置基础。把记录最早的一批动物当作无亲缘创始者，是一种模型假设，不是对其全部生物历史的断言。因此，“近交系数为零”通常表示相对于所采用系谱基础未发现同祖同源，不保证动物在无限历史尺度上没有共同遗传来源。

Wright (1922) 系统建立了近交与亲缘系数的经典概率框架。它的重要性在于把一张亲子关系图转变为可计算的遗传共享概率，使亲属相似、近交累积与数量性状协方差能够使用同一语言。今天拥有基因组数据后，这一框架仍然有用，因为分子指标也需要回答“相对于什么基准比较共享”这一问题，只是所能观察的遗传细节和时间深度发生了变化。

定义共祖系数 f_{ij} 为从个体 i 与 j 各随机抽取一个等位基因拷贝时，两拷贝同祖同源的概率。对于两个不同个体，抽取过程各在其两个拷贝中等概率选择。定义个体近交系数 F_i 为其同一位点上来自父方和母方的两个拷贝同祖同源的概率。一个描述个体之间共享，一个描述个体内部两拷贝的共享，虽然有关联，却不能只因名称相近而互相替换。

当 $i = j$ 时, 共祖抽样仍进行两次, 并允许两次抽到同一拷贝。两次抽到同一拷贝的概率为二分之一, 这时必然同祖同源; 抽到不同拷贝的概率也为二分之一, 这时同祖同源概率为 F_i 。因此

$$f_{ii} = \frac{1}{2} (1 + F_i).$$

加性关系矩阵或分子亲缘矩阵定义为 $A_{ij} = 2f_{ij}$, 故 $A_{ii} = 1 + F_i$ 。不近交个体的对角线是一, 不是零, 也不是二分之一。若读者在不同资料中看到“亲缘系数”分别指 f 或 A , 必须先核对定义再比较数值。共同术语并不保证共同缩放, 许多计算相差一倍正是由这一步引起。

在标准加性遗传模型中, 以基础群体的加性方差为 σ_u^2 , 有 $\text{Var}(u) = A\sigma_u^2$ 。这是把系谱概率转化为统计协方差的关键连接。它依赖加性遗传表示及相应基础假设; 强烈选择、频率改变或复杂遗传结构可能要求更精细处理。把 A 看成只由编号生成的通用相关矩阵, 会忽略其背后的遗传与群体含义。

近交存在时, A_{ij} 也不应直接称为育种值相关。相应相关为 $A_{ij} / \sqrt{A_{ii}A_{jj}}$, 因为两只动物的边际方差可能不同。矩阵元素可以大于一般非近交亲子关系的一半, 而相关仍保持合法。整个关系矩阵还必须半正定; 逐个元素看起来像合理亲缘, 并不能保证合起来对应一个一致的遗传共享结构。第 2 章的协方差几何在这里有直接遗传解释。

12.2 从一代传递推导矩阵递推

构建系谱矩阵之前, 先把个体按祖先先于后代的次序排列。若个体 i 的父母为 s, d , 从后代随机抽一个拷贝, 有二分之一概率来自父亲, 也有二分之一概率来自母亲。对已进入矩阵的个体 j , 由全概率公式得到 $f_{ij} = (f_{sj} + f_{dj}) / 2$, 因此

$$A_{ij} = \frac{1}{2} (A_{sj} + A_{dj}).$$

这个递推只求新个体与已知个体之间的非对角关系。对角线不能简单把同一个式子中的 j 设为 i 而不作解释, 因为后代的两个拷贝来自两个不同亲

本。后代近交等于双亲共祖，即 $F_i = f_{sd} = A_{sd}/2$ ，所以

$$A_{ii} = 1 + \frac{1}{2}A_{sd}.$$

在程序中计算新行后，还应把它复制到相应新列，以保持对称。若一个亲本未知，标准基础假设将该未知亲本与现有动物的关系视为零；若两个亲本都未知，则常设新动物对角线为一、与其他创始者关系为零。这里的零来自缺失信息后的模型约定，不能在输出报告中被转换为“已证实无亲缘”。

父母之间的关系决定后代近交，父母自身近交则影响其他协方差和分离方差。这一差别可以从递推直接看出： F_i 只涉及 A_{sd} ，并不等于父母近交系数的平均。两个自身高度近交、但来自彼此无共同基础来源的亲本，可以生出相对于该基础不近交的后代；两个自身不近交的全同胞交配，则会产生近交后代。近交不是像体重那样简单取双亲均值的性状。

当一方亲本是另一方的祖先时，递推仍然成立。例如非近交亲本与其由无亲缘配偶所生后代的关系为二分之一，这一对再交配时，新后代近交为四分之一。无需为每一种亲属名称另外记一个公式，只要基础和亲子关系正确，逐代递推就能得到一致结果。亲属名称在复杂系谱中可能有多重路径，而矩阵递推自动合并这些路径。

系谱排序不是单纯按编号大小排序。编号可以代表耳标、登记号或导入顺序，与出生时间无关。可靠实现应根据有向亲子图进行拓扑排序，同时检查是否存在环。任何个体经若干代回到自身成为自己的祖先，都违背普通二倍体系谱的时间结构，通常提示身份或亲子记录错误。若数据包含克隆、胚胎拆分或其他特殊复制关系，应使用明确扩展结构，而不伪装成普通父母关系。

矩阵递推还提供局部审计方法。对每个新个体，可以检查对称性、对角线范围、近交与双亲关系的等式，并抽查若干亲属关系。大规模软件的数值输出可能难以逐项阅读，但这些局部恒等式仍然容易执行。发现异常时，应追溯到第一次违反递推的记录，而不是在整个矩阵上无目标地搜索。可解释的递推是数据审计与统计计算共享的基础。

12.3 一个五动物系谱的完整计算

例 12.1 全同胞交配的逐步结果。动物一、二为无亲缘且不近交的创始者, 动物三、四均为一与二的后代, 动物五为三与四的后代。首先, 两创始者之间关系为零, 各自对角线为一。动物三与一的关系为 $(1 + 0)/2 = 0.5$, 与二同样为零点五; 由于双亲无亲缘, 它自身不近交。动物四与创始者的关系相同, 与三的关系为 $(0.5 + 0.5)/2 = 0.5$ 。

前四只动物的矩阵因此为

$$A_{1:4,1:4} = \begin{bmatrix} 1 & 0 & 0.5 & 0.5 \\ 0 & 1 & 0.5 & 0.5 \\ 0.5 & 0.5 & 1 & 0.5 \\ 0.5 & 0.5 & 0.5 & 1 \end{bmatrix}.$$

动物五的双亲三与四具有关系零点五, 因此 $F_5 = 0.25$, $A_{55} = 1.25$ 。它与前四只动物的关系依次为 0.5, 0.5, 0.75, 0.75。这些值连同已有四阶矩阵完全指定了五阶关系矩阵, 无需把全部元素挤入一张宽表。特别地, $A_{35} = (A_{33} + A_{43})/2 = 0.75$, 高于通常不近交亲子之间的零点五。

这个较高关系有明确来源: 动物五从三直接继承一半, 同时另一半来自与三有关系的动物四。如果只记住“亲子永远为零点五”, 就会漏掉后一条共同来源。动物三与五育种值的相关是 $0.75/\sqrt{1.25} \approx 0.6708$, 而非零点七五。其加性协方差则为 $0.75\sigma_u^2$, 单位是性状单位的平方。关系、相关与协方差这三个量, 应在解释中始终区分。

可以再增加动物六, 令其父母为三与五。因为 $A_{35} = 0.75$, 动物六的近交为零点三七五。若只根据“父母属于亲子”套用四分之一, 会低估近交, 因为这里已有祖先重复。动物六对角线为一点三七五, 与动物三关系为 $(1 + 0.75)/2 = 0.875$ 。递推充分利用已有结构, 亲属名称本身则不足以唯一确定复杂系谱中的数值。

例 12.2 半同胞与无亲缘后代。改用三个互无亲缘、不近交创始者一、二、三。动物四来自一与二, 动物五来自一与三。二者只通过共同父亲一共享基

础来源，故关系为零点二五，若四与五交配，其后代近交为零点一二五。再令动物六来自两个全新无亲缘创始者，则四与六关系为零。比较这两个配对，有助于理解近交取决于双方共同来源，而非每只候选者分别拥有多少代完整系谱。

如果把例 12.2 中未知的两个母亲错误地编码成同一个“零号动物”，就可能把本来没有证据共享的母系来源强行合并，制造额外关系。正确的未知标志通常表示“未提供这一亲本”，不是代表一个真实共同亲本。相反，如果两个实际相同父亲被登记成两个编号，就会切断真实共同来源。编号处理看似数据清洗细节，实际直接决定协方差模型。

这些例子还说明，增加深度不一定总让每个数值变化。若新补充祖先与其余基础动物确实无关系，某些近交值可以保持不变；若发现原先两个创始者有共同祖先，许多后代关系会同时上升。比较不同年份公布的近交系数时，应确认是否使用了相同系谱深度和基础。否则变化既可能来自新一代配种，也可能来自历史信息补全，二者具有不同管理含义。

12.4 通路法提供直观核对而非机械数路径

矩阵递推适于完整计算，通路法则有助于理解一个关系来自哪些共同祖先。对后代近交系数，可以沿父方与母方分别追溯到共同祖先 a 。若两条路径除了该共同祖先外不再重复个体，路径贡献为 $2^{-(n_s+n_d+1)}(1+F_a)$ ，其中 n_s, n_d 分别是父母到共同祖先的代数。将有效路径贡献相加得到近交系数。这是 Wright 框架的经典表达方式。

全同胞父母具有两个共同祖先，每个共同祖先到双亲的路径长度都为一，且祖先不近交。每条有效路径贡献为八分之一，两条合计四分之一。半同胞父母只共享一个相应祖先，所以后代近交为八分之一。堂表同胞在四个祖辈均无其他关系的简单情形中，共享一对祖父母，每条路径长度各为二，每条贡献三十二分之一，两条合计十六分之一。

路径法最容易出错的地方不是二的幂，而是路径独立性条件。若父方与母方路径在到达所列共同祖先前已经相交，再把更远祖先路径重复加入，就

会重复计算同一同祖事件。复杂系谱中的共同祖先数量可以很大，但“每看到一个相同名字就加一次”并不成立。手算应明确画出两条路线，并检查它们是否除共同端点外还共享其他个体。

共同祖先自身近交时，贡献中的 $1 + F_a$ 不能遗漏。因为从该祖先两次传出的拷贝，除了抽到同一个祖先拷贝，还可能抽到其两个已经同祖的拷贝。这个因子与本章第一节的自身共祖推导一致，并非人为修正。若共同祖先的近交值本身来自更早系谱，则应先一致地算出它，再计算后代，避免把不同基础下的系数拼在同一个通径式中。

通径方法也能解释亲子关系为何不总是零点五。直接传递是一条路径，另一亲本与该亲本之间的关系提供额外路径，亲本自身近交还会改变自身共祖。矩阵递推把这些贡献合并成一个简洁式子，因此在生产计算中通常更稳健。教学上先用通径理解概率，再用矩阵保证不漏不重，是比同时记忆大量亲属名称系数更有效的学习方式。

对一个复杂系谱，应选择少量有代表性的关系进行独立通径核对，而不是把全矩阵都手工重算。可抽查一对普通半同胞、一对多重亲缘个体和一个高近交后代，核对它们是否与递推一致。若不一致，优先检查路径重复、祖先近交与基础定义，再检查数值运算。这样的独立核对利用不同表达方式检验同一概率对象，具有实际诊断价值。

12.5 孟德尔抽样连接个体差异与家系平均

父母育种值已知时，后代的加性条件平均通常由双亲均值表示，但后代并不都是均值的复制。写 $u_i = (u_s + u_d) / 2 + m_i$ ，其中 m_i 是相对于系谱线性条件结构的孟德尔抽样项。它概括配子分离和组合使后代偏离双亲平均的部分。在标准系谱模型中，该项与祖先育种值不相关；正态近似下还可获得相应条件独立表示。只有不相关而没有正态假设时，不应自动扩大为完整独立结论。

令 $\text{Var}(m_i) = d_i \sigma_u^2$ 。双亲均值的方差为

$$\text{Var}\left(\frac{u_s + u_d}{2}\right) = \frac{2 + F_s + F_d + 2A_{sd}}{4} \sigma_u^2.$$

后代方差为 $(1 + A_{sd}/2) \sigma_u^2$ 。两者相减，双亲之间关系项抵消，得到

$$d_i = \frac{1}{2} - \frac{1}{4} (F_s + F_d).$$

这个结果明确区分父母之间关系与父母自身近交。例 12.1 中动物五自身近交为零点二五，但其父母三、四均不近交，所以其孟德尔抽样方差仍为基础方差的一半。动物六的父母为三与五，后者近交为零点二五，故 $d_6 = 0.4375$ 。若机械写成 $0.5(1 - F_i)$ ，动物五便会得到错误的零点三七五，这是一种常见混淆。

为什么近交后代的边际加性方差可以较大，而近交亲本使后代分离方差减少？前者比较基础群体随机遗传来源在个体中重复出现造成的方差，后者是在亲本遗传值已有条件下考察新组合的波动。边际与条件两个层次不同，并不矛盾。第 1 章的全方差公式提供了一般解释：条件均值之间的方差与条件内部方差可以朝不同方向变化。

这个抽样方差是给定系谱及基础模型的平均结果，不表示对每一对已知完整基因型亲本，所有性状都具有同样的分离方差。若父母在某个位点都纯合，该位点没有相应分离；若父母携带不同杂合组合，后代变异不同。基因组信息能够进一步区分同一家系和不同配对的实际遗传结构。但在没有这些分子细节时，系谱平均提供了合理、可计算的起点。

选拔同胞的价值也由此显现。若只知道双亲平均，所有全同胞的先验预测相同；其个体表型、后代记录或基因组信息可以揭示不同孟德尔抽样结果。增加家系数量主要扩展家系间变异，增加每家系个体数则增加观察家系内分离的机会。两种投入对选择响应、近交和测定成本的影响不同，不能只用总候选数概括。

如果只知道一个亲本，并把未知亲本视为无亲缘、不近交基础个体，将未知亲本贡献并入创新项后，有 $d_i = 0.75 - 0.25F_k$ ，其中 F_k 是已知亲本的近交系数。这一项不再是严格意义上只由双亲已知后的孟德尔抽样，因为它还含未知亲本的一半育种值。若双亲均未知，普通独立创始者的创新系数为一。命名为“创新项”可以提醒读者，不同缺失模式下其中包含的信息来源不完全相同。

12.6 局部亲子关系怎样生成稀疏逆矩阵

将每个个体已知亲本位置写入系数二分之一，组成严格下三角矩阵 T 。若一个亲本未知，其位置不写入矩阵。整个系谱可写成 $u = Tu + m$ ，或 $(I - T)u = m$ 。在标准基础模型中，各创新项协方差矩阵为对角阵 $D\sigma_u^2$ 。由于 $I - T$ 对角线为一且下三角，它可通过前代入求解，表示每个个体由祖先创新贡献逐代累积而来。

令 $B = I - T$ ，则

$$A = B^{-1}DB^{-T},$$

$$A^{-1} = B^TD^{-1}B.$$

第一式解释关系矩阵为何通常稠密：远祖的遗传贡献可以传到许多后代。第二式解释逆矩阵为何可以局部构建：每行 B 只涉及个体自身和至多两个亲本。Henderson (1976) 的经典工作使这种结构成为大规模育种值预测的重要计算基础。实际应用无需先存储整个稠密关系矩阵，再调用通用求逆算法。

例 12.3 三动物家系的逆矩阵。两个互无亲缘创始者一、二生出动物三，故 D 对角线为 1, 1, 0.5。创始者分别向逆矩阵的对应对角位置贡献一；动物三的创新方程为 $u_3 - 0.5u_1 - 0.5u_2 = m_3$ ，其逆方差系数为二。因此把向量 $(-0.5, -0.5, 1)$ 的外积乘二，加到三个位置，得到

$$A^{-1} = \begin{bmatrix} 1.5 & 0.5 & -1 \\ 0.5 & 1.5 & -1 \\ -1 & -1 & 2 \end{bmatrix}.$$

对应关系矩阵为对角线全一、创始者间零、亲子关系零点五。直接相乘可验证单位矩阵。逆矩阵中亲本之间出现正零点五，尽管其边际关系为零，这并不矛盾：逆协方差描述条件结构，而关系矩阵描述边际结构。观察共同后代会使两个亲本贡献在条件分析中相互制约；不能把逆矩阵非零元素直接解释为原来的共祖概率。

对每只双亲已知动物，局部贡献的一般形式是 $d_i^{-1}vv'$ ，其中 v 在个体位置为一、两个亲本位置各为负二分之一。它向子代对角贡献 $1/d_i$ ，向每个亲本对角及亲本间位置贡献 $1/(4d_i)$ ，向亲子位置贡献 $-1/(2d_i)$ 。单亲已知时删去未知亲本位置，双亲未知时只有自身对角贡献。这个统一外积规则比记忆多张加数表更不容易错。

稀疏不表示每行都只有三个非零元素。一个父本可能拥有许多后代，累加后其行会涉及许多配偶与后代；进一步矩阵分解还可能产生填充。局部贡献限制的是每个家系加入的结构，而不是最终每行固定长度。排序和稀疏分解策略因此仍影响内存与计算时间。第2章关于避免显式求逆与利用结构的原则，在这里转化为具体的遗传计算收益。

若某创新方差为零，不能直接计算其倒数。完全复制、某些退化遗传结构或不一致输入可能产生奇异性，需要使用约束、合并或适当广义模型。给对角线随意加一个很小数虽然可能使程序运行，却改变了遗传假设，必须有明确解释。对普通无特殊复制的有限系谱，只要基础协方差和创新方差正定，构造出的关系矩阵也正定，这一性质可以作为数值检查依据。

系谱逆还说明为什么只分析有表型动物而删除全部无表型祖先需要谨慎。祖先虽没有直接观测，仍传递后代间关系。可以通过数学边缘化消去其未知量，但删除记录后把后代重新当创始者不是同一操作。前者保留边缘协方差，后者改变了模型。数据规模压缩应保持遗传关系，而不能只按是否有表型决定保留哪些个体。

12.7 未知亲本、无记录祖先与信息边缘化

系谱缺失至少有三种不同情形：亲本真实存在但身份未登记；亲本身份已知却没有表型；亲本来自一个具有已知群体来源但个体身份不明的群体。第一种涉及关系缺失，第二种不妨碍关系传播，第三种还可能提供基础均值或群体协方差信息。将三者统称为“缺失”并使用同一处理，会丢失可利用结构或引入未经支持的共同来源。

例 12.4 只有一方亲本已知。某后代的父亲近交系数为零点二，母亲按与

现有动物无亲缘且不近交的基础个体处理。父亲对角线为一点二，后代与父亲关系为零点六；父母间关系为零，因此后代自身近交为零，对角线为一。创新方差系数为 $0.75 - 0.25(0.2) = 0.7$ 。检查方差分解：父亲一半贡献的方差为 $0.25(1.2) = 0.3$ ，加创新方差零点七，恰好等于后代边际方差系数一。

这里创新项由未知母亲的一半育种值和完整双亲条件下的孟德尔抽样组成。后者系数为 $0.5 - 0.25(0.2 + 0) = 0.45$ ，未知母亲贡献方差系数为零点二五，两者相加为零点七。这个分解解释了为什么单亲缺失时不能仍用双亲均已知的二分之一规则。它也说明，今后补上母亲信息会重新分配可解释来源，但不必改变已正确边缘化模型下后代的总先验方差。

如果多个后代实际上共享同一个未知母亲，把每个缺失位置都当作独立基础动物会漏掉它们之间的母系关系；如果只有来源群体相同而不是同一个体，给它们分配同一虚拟母亲又会夸大关系。正确处理取决于已知事实。某个编号究竟表示“这一只未知身份但确定相同的母体”，还是“这一类来源”，必须在数据字典中清楚区分。

无记录祖先的边缘化可以用小矩阵说明。例 12.3 中只保留两个创始者，其边缘关系矩阵是二阶单位阵，逆也为单位阵；但完整 A^{-1} 左上角为对角一点五、非对角零点五，直接截取该块并不等于边缘逆。要从完整精度矩阵消去后代，应作 Schur 补，减去经后代产生的相应项，才恢复单位阵。第 2 章关于分块矩阵的结论，在这里避免一种常见数据压缩错误。

反过来，只保留一个有表型后代而删除其父母，若它与其他保留动物没有任何共享来源，其边缘方差可能仍为一，重新作为独立动物碰巧给出相同边缘结构。但一旦它与另一保留个体共享祖先，这种简化就失效。因此，是否可以剪枝不能只看某个祖先自己有没有表型，而要看它是否连接保留对象，或影响它们的近交与基础来源。

在工程实现中，可以保留全部祖先以利用稀疏逆，也可以采用经过证明的压缩或吸收算法。二者选择取决于规模和求解方式，核心要求是预测对象的边缘协方差及观测关联保持一致。对压缩前后的一组小样本，直接比较关系块、预测和误差方差，是有意义的实现检查。只比较运行时间或最终排名前几名，可能漏掉系统性的结构变化。

未知亲本还可能与选择有关。某些来源群体登记完整、另一些大量缺失,或只有优秀动物追溯完整,会使系谱深度与遗传水平相关。此时把缺失亲本全部归为同一均值为零的基础,可能把来源差异吸收到后代育种值或环境效应中。数据分析应描述缺失率随出生年、来源和表现的变化,并考虑适当群体结构,而不是只报告一个全场总完整率。

12.8 基础群体同时决定均值与关系尺度

基础群体有两个经常被混淆的作用:它规定遗传值的参考均值,也规定共同来源和遗传方差的尺度。给全部育种值减去同一个常数,只改变报告零点,不改变动物间差异或协方差;改变哪些祖先被视为无亲缘创始者,则可能改变关系矩阵。前者是位置变换,后者是随机结构改变。二者有时同时发生,但不能因为都称为“调整基准”就认为数学效果相同。

假设两个来源群体在引入时具有不同遗传均值。可将个体育种值表示为已知祖源比例乘群体均值,加上相对于群体均值的随机偏差。用矩阵表示为 $u = Qg + v$, 其中 Q 为群体来源比例、 g 为群体均值参数、 v 为偏差。本式只说明均值结构,不自动给出 v 的协方差;后者仍需根据各来源关系、杂交和基础方差作一致规定。

例 12.5 群体来源不是一个真实亲本。若某后代父方来自群体甲、母方来自群体乙,来源比例为各二分之一。其与纯甲个体再交配,下一代来源比例为甲四分之三、乙四分之一。若两群体基础均值分别为二与负二,两个后代的基础均值部分分别为零与一。这种祖源比例递推与遗传来源的平均传递一致,但并不意味着全部甲群体动物之间具有某个固定近亲关系。

若把群体甲当成一只虚拟公畜,并让所有甲来源个体共享它,会将均值来源误变成个体共祖,产生过大的协方差。群体均值参数和真实亲本随机育种值在模型中承担不同角色。需要同时描述基础关系时,可以采用相应的群体协方差模型,但必须明确参数含义和缩放,不应通过重复一个父母编号暗中实现。

群体均值还可能与当代群效应混杂。若来源甲永远只出现在甲场、来源

乙永远只出现在乙场，数据很难区分来源遗传均值与场效应；增加两场内部记录仍不能自动解决。把群体均值当作固定参数后，设计矩阵可能秩亏；把它设为随机则引入分布约束，可能得到唯一预测，但跨来源比较会更依赖假设。是否有真实连接，必须回到记录布局判断。

任何群体划分都有精细度权衡。过粗划分可能把不同年代、来源和选择历史混在一起；过细划分会使每组支持很少，并与其他固定效应高度重合。合理划分应基于可解释的遗传来源和生产历史，辅以模型比较与敏感性分析。不能只按使某项显著性最强或某个动物排名最高的方式选择分组。

报告育种值时，可选择一個固定出生期或参考群体的平均值作为零点，以方便长期比较。但若每次发布都将当期候选群均值设为零，历史遗传进展会被部分隐藏；若参考群体组成变化，也应说明基准更新。不同发布版本比较需要保存基准说明、方差尺度和版本转换，不能仅凭相同单位就假设数值直接可比。

基因组关系通常根据某批动物的等位基因频率中心化，系谱关系则相对于历史创始者。两者的均值和对角尺度可能天然不同。这不是说明其中一个必然错误，而是说明合并前必须建立兼容解释。后续单步关系矩阵章节将处理这一问题；本章先要求读者识别位置零点、方差单位与祖先基础这三个不同层次。

12.9 基因传递枚举解释期望关系与实际共享

系谱关系对未观察的减数分裂取平均，实际基因组则是某一次传递结果。为了看清两者差别，可以进行基因传递枚举：给每个创始者的两个拷贝赋不同标签，后代从每个亲本随机继承一个标签，逐代向下传递。标签相同表示相对于所设创始者基础同祖同源。单个位点不需要复杂软件，少量家系甚至可以列出全部可能传递路径。

例 12.6 六十四种传递路径。对例 12.1，给创始者一的拷贝标为甲、乙，创始者二的拷贝标为丙、丁。动物三有四种等概率组合，动物四也有四种，二者条件独立产生十六种组合；动物五再从三、四各选一个拷贝，共四种选

择。因此完整传递历史共有六十四种等概率情况。逐一枚举可得，其中十六种使动物五两个拷贝标签相同，故其近交概率为十六除六十四，即四分之一。

动物三与四在该位点可以共享零、一个或两个标签，相应概率为四分之一、二分之一、四分之一。若把每个个体对四个创始者标签的拷贝数写成向量 z_i ，定义该位点关系实现值为 $z'_i z_j / 2$ ，则这对全同胞的实现值分别为零、零点五和一，期望为零点五。这个定义依赖本例中创始者标签全不相同，不能直接用常见等位基因状态替代标签。

同一枚举也得到动物三与五实现关系的平均为零点七五，动物五自身实现对角线的平均为一点二五。动物五非近交时，两种标签各一份， $z'_5 z_5 / 2 = 1$ ；同祖时同一标签两份，值为二。因此其对角期望为 $0.75 \times 1 + 0.25 \times 2 = 1.25$ 。对角线与近交的关系在标签层面变得十分直观。

这个精确枚举是教学计算，不是某个真实畜群的测量结果，也没有模拟采样误差。如果通过随机抽样近似枚举，随着重复次数增加，平均结果会接近期望，并有相应蒙特卡洛误差。报告模拟时应区分理论值、一次模拟估计与重复间波动。给模拟结果保留很多小数位，并不能让随机误差消失；使用固定随机种子只使特定实现可重复。

多位点情形还需要考虑连锁。若把每个位点独立传递，相当于采用独立位点近似；真实染色体上相邻位点常随片段共同传递，重组决定片段长度和变化。有限染色体数使全同胞实际共享比例围绕期望波动，且不同片段并非独立。准确的基因组模拟应说明遗传图谱、重组模型和创始单倍型，而不是只把许多独立硬币结果称为真实染色体传递。

基因传递还可以研究某个创始来源在后代群中保留的概率、后代近交的分布或配种方案的比较。若所有创始标签被赋相同状态，就无法再区分来源；若只关注部分祖先标签，则应明确其余来源如何合并。一个模拟是否有用，取决于标签和传递机制是否对应研究问题，而不取决于生成了多少数据行。

系谱期望与基因组实际共享的差别不应被简单称为“系谱误差”。正确系谱本来就只描述传递的期望。但是当基因组共享显著不符合可能的亲子关系时，身份或系谱错误又是重要解释。实际审计需要先区分允许的孟德尔波

动与不可能的传递,再判断模型基础、基因型错误或关系登记是否存在问题。

12.10 系谱审计是模型建立的一部分

一份可用系谱至少需要稳定个体身份、明确父母字段、统一缺失编码和可解释时间顺序。相同耳标在不同场或不同年份可能重复使用,因此全局身份常需结合场号或登记体系;同一个体更换耳标时,又不能拆成两个遗传实体。身份合并与拆分都应保存映射和依据,方便今后核对。仅把字符串转换成整数并不等于完成身份标准化。

出生日期能发现明显不可能的亲子,但日期错误与亲子错误必须分开。某亲本记录晚于后代出生,可能是父母填错,也可能是导入日期被误当出生日期。审计应保留原字段及来源,避免在没有证据时自动修改成“合理”顺序。若时间缺失,可以使用亲子有向图检查环;若时间存在,则进一步检验生物上可行的年龄范围,具体阈值应依物种与生产资料确定。

父母性别字段也是有用约束,但不能替代身份核实。性别录错可能与亲本角色错误、样品交换或特殊数据编码有关。自动规则应产生待核查项,不能在不知事实时交换父母以使表格通过检查。在普通常染色体关系计算中交换同一对双亲不改变 A ,但母体效应、性连锁和线粒体分析会受到影响,因此“矩阵没变”不等于错误无关紧要。

重复个体和克隆需要不同处理。重复记录通常是同一个体有多次表型,应共享一个育种值而使用不同观测行;两个真实克隆个体则可能共享相同遗传值但具有不同环境和生理过程。若把同一动物重复登记成两个无亲缘个体,会低估记录依赖;若把两个同胞误合并成同一身份,会高估一致性。数据结构应忠实表达实体与记录的层次。

基因型亲子核验可提供强证据,但其结论依赖标记质量、错误率、候选亲本范围和样本身份。某个位点不符合孟德尔传递可能是基因型错误,多个高质量位点持续冲突则更值得核查。不能把没有冲突直接解释为在所有可能候选中唯一确定亲本,特别是在近亲候选众多或信息标记很少时。亲子排除与亲子确认是不同强度的结论。

缺失模式应按来源、年代和选择阶段汇总。若高产个体系谱完整而普通个体缺失严重，关系信息不均衡可能影响可靠度和比较；若某场只登记父亲，另一场双亲齐全，两场近交系数分布差异部分可能来自记录深度。比较近交风险时应同时报告完整代数或其他适当完整度摘要，避免把信息少导致的低估视为管理优势。

对不确定亲本，可以保留候选及概率用于适当模型或敏感性分析，但不能随意挑一个使系谱最整齐的候选。若最终采用最可能亲本，应记录置信依据并评估关键预测对替代关系的敏感性。对于连接两个大群体的少数桥梁动物，亲子不确定性尤其重要，因为一个错误关系可能影响大量跨群比较，超过它对单个动物近交的局部影响。

审计结束不意味着数据永远固定。新测序、旧档案补录和身份更正会改变关系。应保存系谱版本、变更记录及由此产生的评定版本，并能够解释某个预测变化是新增表型、参数更新还是关系修正所致。可追溯的系谱管理使遗传评定能够持续更新，也使实际生产者理解为什么动物排名有时会发生合理变化。

12.11 遗传连接使场间比较拥有共同参照

设两场各有一组后代，甲场仅使用种公畜 S，乙场仅使用种公畜 T。乙场均值比甲场高七，可能因为环境更好、父本更优、母本来源不同或其组合。若没有任何连接信息，增加同样结构的记录只会更精确地估计总差异，并不能把原因自动分开。遗传连接的核心，是让遗传来源与环境水平在数据中形成可比较的交叉，而非仅使两个场在同一数据库中出现。

例 12.7 四个后代组的交叉设计。为手算，假设其他因素已处理，母本群遗传均值可比较，四组均值遵循 $\bar{y}_{js} = h_j + u_s/2 + e_{js}$ 。甲场 S、甲场 T、乙场 S、乙场 T 的均值分别为十、十四、十三、十七。同一场内父本组差均为四，因此父本育种值差为八；同一父本跨场差均为三，因此场效应差为三。两种交叉比较提供相互核对的共同参照。

若四组误差独立、方差均为一，场差估计为两项同父本跨场差的平均，

系数向量为 $(-0.5, -0.5, 0.5, 0.5)$ ，方差为一。父本育种值差估计为两项场内后代差之和，系数为 $(-1, 1, -1, 1)$ ，方差为四。若只用一个场的两组后代估父本差，需要将该差乘二，误差方差为八。连接不仅使比较有意义，也可通过重复路径提高精度。

如果删去乙场 T 组，剩余三组仍形成一条连接路径。场差可由乙场 S 减甲场 S 估计，方差为二；父本差可由甲场两组之差乘二估计，方差为八。缺失的乙场 T 均值可在无交互模型下预测为十四加十三减十，即十七，误差方差为三。增加第四组不仅增加信息，还形成一个可检查的闭环：四组交叉差应在抽样误差内接近零。

若只留下甲场 S 和乙场 T，则仅有 $h_B - h_A + (u_T - u_S) / 2 = 7$ ，无限多组场差与遗传差满足该式。规定 S 的育种值为零只能固定一个参数位置，不能凭空提供缺失的比较信息。给随机效应加上已知分布约束可能得到唯一预测，但其中环境与遗传的分配依赖模型假设。可计算、可估计与由设计充分支持，是需要区分的层次。

图论可以简洁表达这种结构：把环境和父本分别作为两类节点，有观测组合时连边。每个独立连通分量都存在自己的整体水平约束。对于纯加性双因素固定效应模型，在适当非空条件下，设计矩阵秩为环境数加父本数减连通分量数。一个全局约束只能消除共同零点，不能连接本来分离的分量。这个秩结论是第 2 章可估函数概念的具体实例。

现实动物模型中的连接不只来自同一父本。亲缘个体跨场分布、跨场测定、共同参考群和基因组关系都可能提供信息。但关系越远、记录越少或误差越大，桥梁通常越弱；模型还必须正确处理母本差异、年龄及管理。若把环境组划得过细，原有桥梁可能在统计上分裂；划得过粗，又可能把环境异质性误归于遗传。因此，连接设计与当代群定义需要共同考虑。

共同种公畜的使用也不能保证无条件可比。如果 S 在甲场配普通母本，在乙场只配高遗传水平母本，后代组差还包含母本差异；如果同一精液批次与特殊饲养绑定，也会增加混杂。连接方案应安排足够交叉并记录配偶和管理过程。真正的共同参照是由设计、关系和记录共同支持的，而不是表格中出现相同父本编号就自动获得。

12.12 比较精度由误差协方差共同决定

选种通常需要比较两只动物或两组候选者。单个动物的可靠度描述其自身预测不确定性，不能完全回答差异是否精确。令预测误差 $\hat{u} - u$ 的协方差矩阵为 K ，任意线性对比 $c'u$ 的预测误差方差为 $c'Kc$ 。对两动物之差，取一正一负的对比如向量，得到

$$\text{PEV}(u_i - u_j) = K_{ii} + K_{jj} - 2K_{ij}.$$

例 12.8 相同边际可靠度，不同比较能力。两动物的预测误差方差都为四。若误差协方差为三，差异误差方差为二；若误差协方差为零，差异误差方差为八。前者可能有一个共同的水平不确定性，比较时相互抵消；后者的误差彼此独立，无法抵消。因此，两只动物各自预测尚有不小误差，仍可能拥有很精确的相对排序。反过来，个体边际精度高也不保证某个跨组差异特别精确。

在适用的最优线性预测模型下，差异可靠度可写成一减差异 PEV 除真实差异方差。系谱基础模型的分母为

$$\text{Var}(u_i - u_j) = \sigma_u^2 (A_{ii} + A_{jj} - 2A_{ij}).$$

两个近亲的真实差异方差通常小于两个无亲缘个体的差异方差，因此相同绝对 PEV 对应的差异可靠度也可能不同。比较精度至少有绝对误差尺度和相对于遗传变异的尺度两种表达，二者服务不同决策。若差异先验方差为零，比例没有通常意义，应直接说明模型认定该差异不存在，而不是强行报告一个可靠度。

例如，两动物不近交、关系为零点二五，基础加性方差为十，则真实差异方差为十五。若各自 PEV 为五、误差协方差为二，差异 PEV 为六，可靠度为零点六。两个个体各自可靠度均为零点五，简单平均仍为零点五，明显不同于差异可靠度。可见比较可靠度必须使用完整误差协方差，不能从个体可靠度列表唯一恢复。

对两个场的候选平均值，也可构造对比向量，在甲场动物位置放正的平均权重，在乙场位置放负权重，再计算 $c'Kc$ 。若一个场所有动物具有共同预

测误差，增加该场动物数不一定按独立误差规则降低平均误差。这与第1章的聚类抽样设计效应同理。评价连接性应关注实际要比较的个体或群体，而不是只用一个与决策无关的全局数值。

PEV 本身来自所拟合模型。把方差参数当已知时计算的 PEV，通常没有完整包含方差估计、关系错误、模型偏差或环境遗漏的不确定性。它可以准确描述模型内部的比较精度，却不保证现实中所有误差都被覆盖。若桥梁动物系谱不确定，或群体基准有争议，应通过敏感性分析或更完整模型补充评估。不能把软件输出的小 PEV 当作排除系统误差的证据。

还应区分误差协方差与预测值协方差。若直接从某次发布的育种值表计算两动物预测的样本相关，通常不能得到这里所需的 K_{ij} ；后者涉及预测与真实值之差，依赖模型信息矩阵。用一种协方差替代另一种，可能产生负的差异 PEV 或不合法可靠度。出现这类结果时应检查对象和公式，而不是立即把数值截断到看似合理的区间。

连接评估的目的最终是改善决策。如果多数关键跨场比较的 PEV 很大，可以优先增加共同父本后代或其他有效桥梁记录；如果某些场内比较已经精确，继续增加相同布局记录的边际收益可能较小。把比较目标写成对比向量，使设计投入能够围绕真正需要减少的不确定性安排，而不只追求总记录数增长。

12.13 连接设计需要可靠桥梁和冗余路径

连接方案首先应确定需要支持哪些比较。一个地方群体若主要在场内留种，场内家系交叉可能是优先目标；一个跨地区联合育种计划则需要可靠的场间或区域间比较。目标不同，最佳记录配置也不同。不能只把所有场连成一个图就宣布设计完成，因为图的连通只是一种最低结构条件，桥梁精度与关键对比的误差仍可能差异很大。

一条桥梁容易受偶然误差影响。假设两个大场只有一只共同种公畜，而且每场只有少数后代；它的后代可能恰好遭遇特殊疾病或测量问题，使场间差异主要由这一小组决定。增加多个独立共同父本、不同时间批次和适当配

偶交叉,可以形成多条比较路径。冗余路径既提高精度,也使彼此不一致成为可诊断信号,而不是让一个局部异常支配整个联合评定。

记录数量应与有效独立信息区分。某共同父本在一个场拥有一百个同窝或同栏后代,未必等价于分布于多个母本与管理组的一百个后代。如果共同环境很强,简单增加同一小环境中的数量主要减少个体残差,无法消除共同组偏差。设计应尽量使遗传来源与母体、窝、栏舍及时间交叉,并在分析中保留这些层次。信息多样性与信息总量相辅相成。

连接动物还要覆盖应用群体。只在少数高管理水平核心场使用共同父本,可能很好地连接核心场,却不能保证它们与广泛生产环境同样可比。若存在基因与环境互作,某父本在核心环境中的后代优势未必代表其他环境。连接设计可以同时服务跨环境遗传相关的估计,但需要在每种重要环境中配置相应遗传来源和足够记录。

时间上的连接与空间连接同样重要。不同出生年若完全使用不同且无关系的父母,同时管理水平逐年改变,就很难分开遗传趋势与环境趋势。跨年使用部分共同亲本、保留相互重叠世代和长期稳定测量,可以提供参照。长期不变的亲本也有机会成本,因此实际方案应权衡测定精度、遗传更新与世代间隔,不能把维持连接误解为无限期重复使用旧遗传材料。

当代群定义需要遵循真实可比条件。同一场同一年未必同环境,不同栏舍也未必必须完全分开;适当划分应结合饲养、季节、年龄和记录制度。过度细分可能出现每个群只有一个家系,造成遗传与环境重合;过度合并则使未校正环境差异进入遗传比较。可先根据生产机制提出候选定义,再检查每组大小、家系覆盖与跨组连接,而不只依据某种软件默认编码。

对于已有数据,可以进行“去掉一条桥梁”的敏感性检查。如果删去某个共同父本或某个小批次就使跨场排名大幅改变,说明比较高度依赖该路径,应优先核查其身份、表型和管理信息。这里的目标不是随意删除不符合预期的数据,而是识别影响结构。所有剔除都应有事先规则或明确证据,并报告对主要结论的影响。

设计评价可用预测误差对比、预期可靠度和成本共同表达。若两种方案

成本相同,一种增加已有强连接组内记录,另一种建立薄弱场的第二条桥梁,后者可能更有效降低关键跨场对比误差。但这种结论依赖方差和实际布局,应使用计划中的模型作前瞻计算。设计是对未来信息的投资,最有价值的计算是预测哪种配置能减少真正影响决策的不确定性。

12.14 系谱关系与基因组关系各观察什么

系谱描述父母是谁,从而给出遗传传递的期望;基因组标记记录个体实际携带的等位基因,能够部分揭示孟德尔抽样与共享片段。两者不是同一种信息的简单重复。正确系谱中的全同胞可以具有不同基因组关系,这种差异可能反映真实传递;错误系谱也可以造成二者差异,此外还有频率基准、标记抽样与基因型误差。解释差异需要按这些可能来源逐层核查。

一个常见标记关系形式是中心化剂量矩阵的交叉乘积除以适当缩放常数。中心化使用哪个频率,直接影响数值基准;缩放采用平均杂合度、逐位点标准化或其他权重,也会改变不同变异的贡献。因此,看到两个软件输出的 G 不同,不能只比较文件中同一位置的小数,需要先核对编码、频率样本、标记集合及缩放定义。后续基因组章节将给出具体推导。

系谱 A 的非对角元素在普通无亲缘基础下非负,而中心化标记关系可以为负。负值通常表示相对于所用参考频率的相似程度低于某种平均水平,不表示两个动物存在“负的同祖概率”。关系矩阵的名字相似,元素解释未必完全相同。若直接把负的 $G_{sd}/2$ 当成严格概率意义上的后代近交,会超出该数值定义;用于配种管理时应明确所采用指标和基准。

系谱近交、纯合位点比例、纯合片段近交及基于 G 对角线的指标,衡量对象不同。纯合位点比例容易受常见等位基因频率影响;连续纯合片段利用相邻标记的结构,通常与共享片段的历史有关;系谱近交依赖记录深度和基础;矩阵对角指标依赖中心与尺度。指标相关并不保证可互换,不相关也不自动说明其中一个无效。

片段长度携带时间信息,但不能脱离重组和检测规则作过度精确解释。长片段通常更符合较近共同来源的情形,短片段可能反映更久历史,也更容

易受到标记密度与阈值影响。若比较不同群体的片段近交，应尽量保持检测参数与覆盖度可比，并报告对阈值的敏感性。把所有纯合片段总长度压成一个数后，原来时间层次的信息也会部分丢失。

基因组亲缘并不能补齐所有历史信息。例如两个动物可能表现相似共享，却不能仅由此唯一确定具体祖先路径；多个不同系谱可以产生相近标记关系。系谱则记录了方向和时间，能够明确父母到后代的传递。因此，结合两者的价值不仅是提高预测精度，也包括用不同信息相互审计。对有争议关系，应保留原记录、分子证据与修订依据，而不是覆盖后只留下最终编号。

基因组连接也需要可靠表型支持。大量无表型动物之间的关系可以帮助传播已有信息，但不能创造从未测量过的性状信号。如果训练群体与应用群体在频率、环境或性状定义上不同，关系强度并不保证模型无偏。第21章的迁移问题在这里继续存在。评价基因组加入后的连接改善，应同时检查比较误差、校准与合适的外部验证。

混合使用 A 与 G 时，核心要求是对相同动物的遗传值给出兼容的均值和协方差解释。单步方法以此为基础，而不是把两个看起来相似的矩阵任意平均。即便暂时不做单步分析，保存频率计算样本、标记筛选版本和系谱基础，也能避免以后难以追溯的尺度问题。关系矩阵应是有定义的数据产品，而非没有来源说明的数字文件。

12.15 亲本贡献与具体配对是两个决策层次

对候选父母 s, d ，后代的预期加性育种值为双亲育种值平均，预期近交为 $A_{sd}/2$ ，前提是沿用相同基础模型。两个高育种值近亲交配可以具有较高加性期望，同时增加同祖风险。是否值得这样配对，还要考虑近交衰退、遗传缺陷、后代变异与长期多样性。单一加性期望不能回答全部配种问题，近交指标本身也不是全部经济目标。

例 12.9 相同贡献，不同配对。两只公畜 S_1 、 S_2 的育种值为十、八，两

只母畜 D1、D2 为六、四。公畜与母畜之间的关系块为

$$A_{SD} = \begin{bmatrix} 0.25 & 0 \\ 0 & 0.25 \end{bmatrix}.$$

每只亲本各承担一半本性别的繁殖贡献。若配 S1 与 D1、S2 与 D2，两类后代的加性期望为八、六，平均为七，各类预期近交均为零点一二五。若交叉配 S1 与 D2、S2 与 D1，两类后代期望均为七，平均仍为七，但预期近交均为零。固定亲本贡献后，重新配对没有改变后代总体加性均值，却改变了近交与家系均值分布。

如果未来只从最高家系中留种，两种方案的长期表现还会受到家系内分离、选择强度和留种规则影响，因此不能仅凭平均值相同就宣称一切相同。这个例子只严格证明当前加性均值在固定贡献下不变。它帮助把“选择谁以及用多少”与“把这些贡献如何配对”分开，避免在一个笼统的配种目标中混淆不同作用机制。

令公畜贡献向量 p 、母畜贡献向量 q 各自和为一，若两个性别内按这些比例独立随机配对，平均后代近交为 $p'A_{SD}q/2$ 。例 12.9 中该值为零点零六二五，处于两种有目的配对方案之间。改变实际配对联合分布时，平均近交应对每一配对概率乘相应关系后求和；不能仍用独立配对的乘积分布公式。

群体层面的平均共祖常用统一遗传贡献向量 c 表达为 $c'Ac/2$ ，其中贡献总和为一。该量考察从贡献池中抽取两份遗传来源的共享，包含自身和同性来源等项。对雌雄分开的实际交配群体，它一般不等于当代配种后的平均近交。例 12.9 若同性个体互无亲缘、不近交，四个统一贡献均为四分之一，则平均共祖为零点一五六二五，而随机雌雄配对的后代近交是零点零六二五。两个量回答不同抽样问题。

因此，当代后代近交很低，不等于未来群体关系一定低。若一只优秀公畜与许多无近亲母畜配种，当代可以避免近交，但下一代大量候选成为半同胞，未来可用配对减少。控制当前配对关系与控制亲本贡献集中程度需要同时进行。最优贡献选择利用预测遗传值与关系约束安排贡献，具体配对再在这些贡献下管理后代近交及其他目标；后续章节将详细推导相应优化。

贡献还有整数和生产约束。理论向量可能要求某亲本产生小数个后代,而实际只能安排整数配种,且繁殖能力、性别比例和配偶可用性有限。实施时应把连续最优方案转成可行配置,再重新计算均值、关系与近交,不能只报告连续优化目标值。对小群体,整数化造成的差异可能明显,尤其当少数亲本接近上限时。

预测本身有误差,也会影响贡献决策。给可靠度低而估计值极高的个体过大贡献,可能承担较高遗传风险;但把所有低可靠度个体完全排除,又可能延长世代间隔并损失年轻遗传进展。合理方案应明确如何对待预测不确定性及长期目标,而不是用一个固定阈值取代所有权衡。关系矩阵提供多样性结构,不能替代对目标和风险偏好的说明。

12.16 多代近交增长与有效群体大小

近交管理关心的不只是某一代平均水平,还包括增长速度。若上一代平均近交为 F_{t-1} , 本代为 F_t , 常用相对于尚未同祖部分的增长率 $\Delta F_t = (F_t - F_{t-1}) / (1 - F_{t-1})$ 。这个定义把绝对增加放在仍可丧失的非同祖部分上衡量。简单用两个近交均值之差代替增长率,在近交已经较高时会产生明显区别。

例 12.10 相同定义下的增长率。平均近交从零点一升至零点一一八,绝对增加为零点零一八,而标准化增长率为零点零二。若在相应理想化条件下以 $N_e \approx 1/(2\Delta F)$ 定义近交有效群体大小,得到二十五。直接把绝对增加代入会得到约二十七点八,二者不是同一指标。实际世代重叠群体还需要明确世代划分和时间尺度,不能将年度增长率直接当代际增长率。

有效群体大小不是当前圈舍里动物的头数。繁殖贡献不均、雌雄数量不平衡、世代结构及选择都能使遗传漂变或近交的有效规模小于登记数量。在一个理想分性别随机繁殖近似中, $N_e \approx 4N_m N_f / (N_m + N_f)$ 。若四只公畜与一百只母畜等机会繁殖,近似值仅约十五点四,远小于总头数一百零四;增加大量母畜而不改变极少数公畜的瓶颈,收益有限。

这个公式的前提十分具体,不能用来替代真实育种方案的多代评估。不

等家系大小、强选择、非随机配种、重叠世代和亲本关系会改变结果。不同定义的有效大小可能根据近交、方差或连锁结构估计，时间尺度也不同。报告时应写清指标定义与估计方法，不宜把所有带有 N_e 符号的结果视为可以直接比较。

创始贡献的有效数量是另一个有用但不同的摘要。若无亲缘创始者对当前群体贡献比例为 q_k ，可用 $1/\sum q_k^2$ 描述贡献集中程度。三位创始者贡献为二分之一、四分之一、四分之一时，该值为三分之二，而不是三。它反映来源不均衡，但没有完整包含后续漂变、亲缘路径与世代结构，因此不应直接称为近交有效群体大小。

多代优化还需要区分预期与实现。计划中的每个亲本贡献可能因繁殖失败、性别比例和存活差异而偏离；后续留种又会改变实际遗传贡献。跟踪实际出生与留种记录，更新关系与贡献，是长期管理不可缺少的环节。一个在计划表上非常均衡的方案，若执行中少数家系持续失败，仍可能快速丧失来源多样性。

短期增益与长期变异之间并非只有一种固定折中。保存更多家系、降低贡献集中、利用冻存遗传材料或调整世代结构，都可能影响未来选择机会，同时伴随成本与当期进展变化。基础理论提供衡量共同来源和近交增长的工具，具体策略则需结合生产目标、可用资源与可接受风险。把长期管理简化为“所有配对近交都低于某数”会遗漏群体层面的主要问题。

12.17 从关系数据到可审计的评定流程

建立评定前，应先确定动物集合、表型集合和预测目标集合。三者可以不同：没有表型的祖先可能只用于关系传播，没有自身记录的年轻候选可能是主要预测对象，历史个体可能只为校正选择与连接提供信息。把这些角色明确分开，有助于解释为什么某些无表型动物必须保留，也有助于控制不必要的计算规模。

第二步是统一身份与基础，检查亲子图并确定排序。随后构建关系或逆关系，核对典型亲缘、近交和创新方差。对极端近交、异常大量后代或突然

出现的跨群关系，应回到原始记录审查。数值合法不是生物事实正确的充分条件：一个错误亲本仍可能生成完全正定的矩阵，因此数学检查与资料核验必须并行。

第三步是把关系与观察设计放在一起看。检查亲缘家系是否跨当代群分布，哪些比较由直接共同父本支持，哪些主要依赖更远关系，哪些几乎完全依赖先验。计算一组对生产决策真正重要的对比 PEV，而不是只输出所有个体可靠度。如果关键比较薄弱，应在结论中体现，并将其转化为下一轮测定或配种的改进目标。

第四步是解释预测变化。新增表型、修正系谱、调整固定效应和改变基础，可能分别改变某个动物的育种值。应尽量通过分步版本比较区分来源，避免把所有变化都归为“算法升级”。对外报告不必展示每一矩阵细节，但应能回答数值基准、使用信息、主要不确定性及版本差异这些实质问题。

最后，把预测用于贡献与配对时，应重新核对关系定义和尺度。用于统计预测的某个基因组矩阵，不一定可以不加说明地当作概率近交；用于报告的平移育种值则不影响同一目标下的相对加性贡献。每个量进入决策公式之前，都应检查单位、基准和抽样含义。贯通这些定义，能防止在数据、模型与生产之间转换时产生看似微小而后果显著的错误。

经典系谱方法的持续价值，在于使共同来源、传递和比较信息具有可追溯结构。基因组时代增加了真实共享和分离的观察，但没有取消基础、环境与选择问题。能够从小家系推导关系、从局部创新构建逆矩阵，并解释一个跨场差异为何可比，便拥有理解后续动物模型、基因组评定和长期育种方案的坚实起点。

12.18 创新分解中的行列式与条件遗传信息

系谱矩阵递推给出动物之间的边际协方差，亲子创新分解则回答每一只新动物在已有祖先信息之外还带来多少遗传变异。两种表达等价，但揭示的问题不同。尤其当某只后代近交时，其边际遗传方差可能增加，而出生时相对于亲本的创新方差未必同时增加。将矩阵分解、行列式和条件分布联系起

来, 可以把这种看似矛盾的现象解释得更完整。

按祖先在前、后代在后的顺序排列动物, 令严格下三角矩阵 T 在已知父母位置放置二分之一, 其余位置为零。对已中心化的加性育种值, 定义创新向量

$$\eta = (I - T)u.$$

在标准系谱加性模型下, 创新彼此不相关, 设其协方差为 $\sigma_u^2 D$, 其中 D 为正对角矩阵。于是

$$A = (I - T)^{-1}D(I - T)^{-\top}.$$

这里三角矩阵 $I - T$ 的对角元全部为一, 行列式也为一, 故

$$\det(A) = \prod_i d_i, \quad \log \det(A) = \sum_i \log d_i.$$

这个结果非常有解释力: 遗传关系造成的共同变动已经通过传递结构表示, 整体协方差体积只需由各阶段新增的不确定性相乘得到。它同时提供一种稳定计算途径, 避免直接计算一个巨大且可能跨越许多数值量级的行列式。需要注意的是, 行列式反映所有方向的联合体积, 并不等于任何单个候选对比的误差。

逆矩阵也由局部创新给出

$$A^{-1} = (I - T)^{\top}D^{-1}(I - T).$$

所以任意育种值向量的二次型可以改写为

$$u^{\top}A^{-1}u = \sum_i \frac{\{u_i - \frac{1}{2}u_{s_i} - \frac{1}{2}u_{d_i}\}^2}{d_i},$$

其中未知亲本须按模型约定处理, 不能把不存在的数值随意填成实际动物的育种值。该局部平方和解释了直接构造稀疏系谱逆矩阵的原理, 和 Henderson (1975b) 的快速计算思想相衔接。它也说明先验惩罚并非一律把每只动物拉向零, 而是把后代相对于其亲本平均的偏离按创新方差加权。

手算例：后代自身近交与出生创新的区别。设动物一、二是无亲缘创始者，动物三是其后代，动物四由动物一与动物三交配产生。关系矩阵为

$$A = \begin{pmatrix} 1 & 0 & \frac{1}{2} & \frac{3}{4} \\ 0 & 1 & \frac{1}{2} & \frac{1}{4} \\ \frac{1}{2} & \frac{1}{2} & 1 & \frac{3}{4} \\ \frac{3}{4} & \frac{1}{4} & \frac{3}{4} & \frac{5}{4} \end{pmatrix}.$$

动物四的近交系数为四分之一，对角元为四分之五。但它的两个亲本自身都不近交，所以创新方差系数仍为二分之一，与动物三相同。四个创新系数为一、一、二分之一、二分之一，因此行列式为四分之一。动物四增加的边际方差来自父母平均中包含的相关遗传贡献，并不是出生时凭空产生了更多独立遗传创新。

再设动物四与一只无亲缘且不近交的新创始者交配，则新后代的创新系数为

$$d_{new} = \frac{1}{2} - \frac{1}{4} \left(\frac{1}{4} + 0 \right) = \frac{7}{16}.$$

这一次亲本自身近交进入孟德尔抽样方差，创新小于二分之一。前一只动物的自身近交与后一只动物的创新减少发生在不同层次，不能用一句“近交增加方差”或“近交减少方差”概括。必须说明讨论的是哪一代、边际遗传差异还是给定亲本之后的分离差异。

取四动物育种值为二、零、一、二，创新依次为二、零、零、二分之一。在基础方差为一的单位下，二次型为四点五。这个数可以通过完整矩阵逆计算，也可以通过四个局部平方直接得到。两种路径相符，使它成为检查动物排序、亲本索引和创新方差计算的一个简洁例子。

如果进一步采用联合正态模型，创新不相关便意味着独立，联合密度可分解为各个条件正态密度的乘积；负对数密度包含上述局部平方和与对数行列式。但在有限位点的真实遗传抽样中，不相关不自动意味着独立，实际给定亲本基因型的分离方差还可能依基因型而变。系谱模型的创新方差通常是对未观察遗传状态平均后的二阶描述。正态密度分解属于附加分布假设，不

能从亲缘递推本身无条件推出。

12.19 父母身份不确定时必须保留混合方差

一个缺失父本可以被当作未知来源处理，而一个父本在两只已知候选者之间不确定，则具有更多可利用信息。最自然的做法是对可能系谱建立概率混合。然而，平均亲缘矩阵、平均育种值与平均精度矩阵不是同一个操作。若忽略身份不确定本身带来的变异，即使每个候选系谱单独都正确，合并后的预测误差仍可能偏小。

用 S 表示可能系谱状态，状态概率为 q_s 。若给定状态时育种值均值为 m_s 、协方差为 Σ_s ，全概率方差公式给出

$$\bar{m} = \sum_s q_s m_s,$$

$$\Sigma = \sum_s q_s \Sigma_s + \sum_s q_s (m_s - \bar{m})(m_s - \bar{m})^T.$$

只有各状态均值相同，混合协方差才等于条件协方差的加权平均。即使这个条件成立，混合分布一般也不再正态。对于只要求最佳线性预测的任务，正确的一阶、二阶矩可能已经足够；若要计算尾部风险或完整后验概率，则还需保留分布混合，不能把平均协方差当成原混合模型的全部内容。

手算例：两只等可能父本。设两只候选父本与已知母本都无亲缘且不近交，基础加性方差为一。父本一的概率为 q ，父本二的概率为 $1 - q$ ，且这些概率来自独立于本例遗传值的身份信息。对后代 c ，有

$$\text{Cov}(u_c, u_1) = \frac{q}{2}, \quad \text{Cov}(u_c, u_2) = \frac{1 - q}{2}, \quad \text{Cov}(u_c, u_m) = \frac{1}{2}.$$

后代边际方差仍为一。给定三个亲本育种值时，后代条件均值为

$$E(u_c | u_1, u_2, u_m) = \frac{1}{2}u_m + \frac{1}{2}\{qu_1 + (1 - q)u_2\}.$$

但是其条件方差还包含候选父本均值的混合差异。在每个候选系谱中都采用创新方差二分之一的正态模型，则

$$\text{Var}(u_c | u_1, u_2, u_m) = \frac{1}{2} + \frac{1}{4}q(1 - q)(u_1 - u_2)^2.$$

第二项在两个候选父本育种值相同或身份完全确定时为零；父本差异越大、身份越含糊，额外方差越大。这是身份信息是直接统计价值，而不是对孟德尔抽样方差做任意膨胀。该式也说明，即使平均亲本权重固定，混合模型的条件方差仍可能随已知亲本值而变化。

对亲本遗传值再取平均，两个无亲缘候选父本差异方差为二，得到相对于三个亲本线性预测的平均剩余方差

$$d_{mix} = \frac{1}{2} + \frac{1}{2}q(1-q).$$

当两者等可能时，它为八分之五。若错误地把后代写成四分之一父本一、四分之一父本二、二分之一母本，再只加二分之一的创新，其总方差只有八分之七，低于正确的一。漏掉的八分之一正是身份混合造成的额外变异。这说明“按父本概率平均传递系数”可以给出正确均值，却未必给出正确方差。

若不同可能系谱还对应不同遗传均值，遗漏会更明显。假设两候选父本均值为二与负二、母本均值为零，身份仍等可能，并且每个条件模型的后代方差为一。两个后代条件均值分别为一与负一，混合均值为零，混合方差为二。只平均两个关系矩阵只能得到方差一，还必须加入状态均值差异的方差一。

此外，一般不能把各可能系谱的精度矩阵取平均作为混合协方差的逆。求逆是非线性操作，且平均条件精度对应的概率对象与混合分布不同。预测时可以明确积分各状态，也可以在清楚说明近似层次后使用匹配二阶矩的模型；两者产生相同线性矩结构时，最佳线性结果可以一致，但完整概率区间未必一致。

身份概率也需要随证据更新。若新增基因型或亲属资料已经用于更新候选父本概率，再把同一证据以独立观测方式重复加入，可能重复计算信息。更完整的分析把身份、基因型与表型放在同一个联合结构中；简化分析则应清楚记录每个概率使用了哪些证据。这里的主要原则是保留不确定性来源，而不是把最高概率父本直接当成完全已知。

12.20 相关基础个体的块创新结构

把所有无已知亲本动物设为互不相关，通常是一种基准假设，未必是历史事实。若创始者来自共享祖先、已知相关来源或更早的基因组信息，基础协方差应作为一个完整矩阵进入模型。此时后代局部传递仍可以保持简单，而创始者创新不再各自独立。将基础块与后代块分开，能够避免用错误的虚拟亲本关系去表达群体来源。

设创始者向量为 u_F ，其关系尺度协方差为正定矩阵 K_F ，后代创新组成对角矩阵 D_N 。以同样的单位基础方差表示，有

$$\text{Var} \begin{pmatrix} u_F \\ \eta_N \end{pmatrix} = \sigma_u^2 \begin{pmatrix} K_F & 0 \\ 0 & D_N \end{pmatrix}.$$

令下三角传递矩阵为 L ，则完整关系矩阵为

$$A = L \begin{pmatrix} K_F & 0 \\ 0 & D_N \end{pmatrix} L^T,$$

相应行列式分解为

$$\det(A) = \det(K_F) \prod_{i \in N} d_i.$$

这不是在通常对角创新矩阵上随便添加几条相关，而是把基础个体作为一个共同概率块处理。后代创新与基础块不相关，保证传递结构具有一致的协方差来源。如果既在基础块中加入共同来源，又通过虚拟共同亲本重复加入同一关系，就会重复计算祖先贡献。

手算例：两只相关创始者的共同后代。设两创始者各自不近交，关系为零点四，有

$$K_F = \begin{pmatrix} 1 & 0.4 \\ 0.4 & 1 \end{pmatrix}.$$

其共同后代的孟德尔创新系数仍为二分之一，后代与每位亲本的关系为零点七，后代自身关系对角为一点二。因此

$$A = \begin{pmatrix} 1 & 0.4 & 0.7 \\ 0.4 & 1 & 0.7 \\ 0.7 & 0.7 & 1.2 \end{pmatrix}, \quad \det(A) = 0.42.$$

后代近交系数为零点二，来自父母之间的相关。若错误地把两创始者设为独立，既会漏掉它们之间的协方差，也会把后代对角降为一，并改变后代与亲本的关系。这种差异不可能通过对所有育种值减去同一个均值来修复，因为被改变的是协方差结构，而非报告零点。

基础块的逆为对角元二十一分之二十五、非对角元二十一分之负十。再累加后代局部创新外积，得到

$$A^{-1} = \begin{pmatrix} \frac{71}{42} & \frac{1}{42} & -1 \\ \frac{1}{42} & \frac{71}{42} & -1 \\ -1 & -1 & 2 \end{pmatrix}.$$

一个细节值得观察：完整精度矩阵中两个创始者之间的非对角元为正，尽管它们边际关系为正零点四。精度矩阵的非对角结构对应给定其他变量之后的联系，不能直接按边际亲缘系数的符号解释。对同一个共同后代条件化，会改变两个亲本之间剩余遗传信息的关系。这与只看边际相关无法理解条件相关是同一个概率问题。

均值也应独立处理。若创始者遗传均值分别为二和负一，后代的基础均值部分为二分之一。把各动物减去其由祖源比例递推的期望之后，以上协方差仍可用于剩余育种值；但均值差异不能通过基础相关系数替代。来源均值决定整体水平，基础协方差决定围绕水平的共同变异，二者在模型中承担不同功能。

并非任何数值上正定的基础矩阵都自动具有所声称的同祖同源含义。正定性保证二阶概率结构合法，而特定关系解释还要求与基础定义、对角尺度

及来源信息一致。若基础矩阵来自中心化基因组相似度，其元素可能具有不同于传统谱系同祖概率的含义；合并时应说明缩放和参考频率，不能仅因矩阵都记作关系矩阵便直接互换。

当基础来源之间关系本身不确定时，可以对多个合理矩阵作敏感性分析，观察关键跨来源对比和趋势是否稳定。把所有基础相关强制设为零，可以使计算简单，却不代表这一假设不会影响结果；反过来，任意增加相关以缩小预测误差，同样缺乏依据。基础块是模型的一部分，应像遗传方差和固定效应一样具有明确来源与可检验后果。

12.21 从共同父本设计推导连接图的信息矩阵

图上的两个场连通，只说明存在比较路径，还没有说明比较有多精确。要将结构连通转化为定量设计，需要给每条路径赋予由记录误差决定的信息强度。对于一个适当简化的共同父本模型，可以从正规方程直接推导加权图，而不是凭记录数随意定义连接指标。这一模型也为理解更一般动物模型中的跨场比较提供清楚起点。

设已经控制母本来源和其他系统因素，父本在各场的后代组均值满足

$$y_{js} = h_j + v_s + e_{js}, \quad v_s = \frac{1}{2}u_s.$$

为研究设计可估性，暂把场效应与父本贡献都视为固定未知量。各组误差独立，精度为 w_{js} 。用 H 和 S 分别表示场与父本设计矩阵，以 W 收集精度。消去父本后，场效应的信息矩阵为

$$L = H^T W H - H^T W S (S^T W S)^{-1} S^T W H.$$

若某父本在若干场都有记录，记其总精度为 $w_{\cdot s}$ ，则它对场 j, k 之间贡献的连接权重为

$$\gamma_{jk,s} = \frac{w_{js} w_{ks}}{w_{\cdot s}}.$$

把各父本贡献相加，得到对角元为相邻权重之和、非对角元为负权重的图拉普拉斯矩阵。它自然满足 $L\mathbf{1} = 0$ ，因为全部场效应共同平移可由父本水平反向平移补偿；可估的是场间差异，而非没有基准约束的绝对水平。

只有两个场共享某父本时，连接权重简化为

$$\gamma = \frac{1}{v_1 + v_2},$$

其中两组均值误差方差为 v_1, v_2 。这正是同父本跨场差的误差精度。如果两个场的组记录同样精确，增加任一侧记录都有收益；若一侧已经极精确，另一侧仍很粗糙，继续增加前者的收益有限。桥梁强度由两端共同决定，不能仅以总后代数判断。

对和为零、且在同一连通分量内的场对比 c ，最优线性无偏估计方差为

$$\text{Var}(c^T \hat{h}) = c^T L^+ c.$$

该二次型也具有电阻网络中的有效电阻形式，但这里其单位是场差估计误差的方差。使用图的类比是为了理解独立信息路径如何组合，不意味着真实遗传传递就是电流。特别是完整动物模型具有亲缘、随机效应和复杂残差时，应由实际信息矩阵计算，不能未经推导把所有关系边都直接当成独立导电边。

手算例：一条长路径与一条直接桥梁。设三个场只在甲乙、乙丙之间各有一条独立比较，误差方差均为一。甲丙差等于两条差之和，方差为二。再增加甲丙直接比较，误差方差也为一；此时一条直接路径方差为一，原间接路径方差为二，二者独立并联，故

$$V_{AC} = \left(1 + \frac{1}{2}\right)^{-1} = \frac{2}{3}.$$

假设两条原比较观测分别为一和二，直接比较为二，则间接估计为三，精度加权后的甲丙差为三分之二。闭环差为一，其误差方差为三，可作为一个一致性诊断。单独一条树状路径没有闭环，任何观测值都能被某组场效应完全解释；增加闭环不仅提高精度，还产生检验可加模型的剩余信息。

固定总连接精度时，设计目标会影响最佳分配。若只有甲乙、乙丙两条边，总精度为 W_0 ，甲丙差方差为两边精度倒数之和，在均分时最小，为 $4/W_0$ 。若把全部精度用于甲丙直接边，该对比方差可降为 $1/W_0$ ，但乙场将

失去连接。因此最小化一个对比与保障所有场联合比较并非同一目标，不能用一个全局连通指标替代实际决策要求。

对于三条边均匀分配总精度的三角形，每对场差方差为 $2/W_0$ 。它没有把单一目标做到极限，却使所有场之间具有对称精度和替代路径。现实方案还须考虑共同父本使用成本、后代测定等待时间、近交和环境覆盖；图上的权重只是从已规定统计模型导出的信息量，应与这些成本共同优化。

12.22 桥梁的边际价值、失效风险与相关记录

新增桥梁应该放在哪里，不能只看哪个场记录最少。对于某个关键跨场对比，最有价值的桥梁是其两端仍具有与目标相关的不确定差异的地方。这个判断可以由信息矩阵的一次低秩更新精确表达，并进一步用于识别现有比较对某条桥梁的依赖。与简单统计共享父本数量相比，它同时利用结构和精度。

在已经连通的场网络中，将共同平移方向去除，在对比子空间上工作。设原信息矩阵为 L ，新增边的方向向量为 $b = e_j - e_k$ ，精度为 γ ，则

$$L_+ = L + \gamma b b^T.$$

对目标对比 c ，由该子空间内的逆矩阵更新得到

$$\Delta V_c = \frac{\gamma (c^T L + b)^2}{1 + \gamma b^T L + b}.$$

这个式子有两个值得分开的部分。分子表示新增边与目标当前不确定性的联系；分母限制重复加强同一路径的收益。因此，在一个已经很强的桥梁上增加大量后代，可能不如在一个关键薄弱方向上增加少量独立记录。只按某场自身平均可靠度低就决定加测位置，可能错过真正支配跨场比较的路径。

当新增精度很小时，边际导数为

$$-\frac{\partial V_c}{\partial \gamma} = (c^T L + b)^2.$$

若不同方案每增加一单位精度的成本不同，应再除以相应边际成本比较。这里导数是在当前设计处计算的局部收益；增加一条边会改变其他边的价值，所以不能把第一步收益排序固定后一直用到全部预算耗尽。顺序设计需要更新信息矩阵，并检查多个关键对比之间是否存在冲突。

手算例：三角形中删掉哪条边影响最大。在前节三条边精度均为一的网络中，甲丙差方差为三分之二。若删除甲丙直接边，只剩间接路径，方差升为二；若删除甲乙或乙丙中的一条，甲丙仍可由直接边比较，方差为一。因此同样精度的一条记录，其价值随目标不同而不同。不能给每条桥梁一个脱离目标的永久重要性排名。

对于已有边，定义 $q_b = b^T L + b$ 。删除后原网络仍保持连通时，方差增加为

$$V_{c,-} - V_c = \frac{\gamma (c^T L + b)^2}{1 - \gamma q_b}.$$

三角形直接边的 q_b 为三分之二，分母为三分之一，对甲丙差的方差增加为四分之三，正好从三分之二升为二。若某条边是连接两个大分量的唯一桥梁，则其杠杆量 γq_b 达到一，删除使跨分量对比不可估。分母趋近零不是浮点异常，而是在揭示设计支撑即将消失。

如果加入随机场效应先验，断裂设计也可能给出有限误差和唯一预测。但这种有限性来自先验约束，不能被解释为实际桥梁仍然存在。对设计评价，应分别报告数据支持的连接和依赖分布假设的比较。否则一个强收缩模型可能在表面上使断裂网络看起来十分稳定，却掩盖跨场遗传与环境分解缺乏直接对照的问题。

桥梁的系统偏差同样可以通过目标方向传播。设某边差观测具有偏差 δ ，而模型仍按无偏处理，则目标估计偏差为

$$\text{Bias}_c = \gamma c^T L + b \delta.$$

在等精度三角形中，甲丙直接比较的一单位偏差会使甲丙估计偏移三分之二；间接路径提供了一定抵消，但不能完全消除。闭环不一致能够提示某条路径或可加假设存在问题，却不能仅凭一个闭环唯一断定哪一组记录错

误。还需要身份核查、管理记录、重复测定或额外独立路径来定位来源。

设计冗余的价值还体现在失效后是否可继续比较。仍以三角形为例，如果恰有一条边失效，且三种失效等可能，甲丙差的平均误差方差为四分之三；完整网络时为三分之二。若只设计一条树状路径，任一关键桥梁失效都可能使相应跨场对比不可估。这里的等概率只是一种明确的教学情景，实际失效概率应由记录制度和历史资料确定。

最后必须检查边是否真的独立。若甲乙差和乙丙差使用同一父本的同一乙场组均值，设三个组均值误差独立，则两条差的误差协方差为

$$\text{Cov}(e_B - e_A, e_C - e_B) = -\text{Var}(e_B).$$

两条差相加后，乙场误差抵消，甲丙差的方差只有甲场与丙场误差方差之和。若把两条差当作独立，便错误保留了两次乙场误差。反过来，其他共享设计可能形成正相关。因而不能从图上有几条路径直接推断有几份独立信息；正确权重必须由原始记录的联合误差结构消元得到。

系谱连接设计的质量，最终体现在目标对比由哪些可核查的遗传与环境交叉支持、这些支持有多精确、失去一部分后能否保持比较，以及结论对基础关系假设有多敏感。将这些问题逐一转化为协方差与信息矩阵，既能使设计投入具有可计算依据，也能明确哪些不确定性仍需通过更好的身份登记和测定安排解决。

12.23 练习、计算与答案

练习一：自身共祖。从一个近交系数为零点二的动物中独立抽取两个等位基因拷贝，允许抽到同一拷贝。求两次抽样同祖同源概率、关系矩阵对角线，并解释为什么两者都不等于零点二。

答案。两次抽到同一拷贝的概率为二分之一，此时必然同祖；抽到不同拷贝的概率为二分之一，此时同祖概率为零点二。因此自身共祖为零点六，关系对角线为一点二。个体近交系数只比较其两个不同的父母来源拷贝，共祖抽样则包含抽到同一拷贝的情况。差别来自抽样事件定义，并非两种计算互相冲突。

练习二：半同胞后代。创始者一、二、三互无亲缘且不近交，四为一与二的后代，五为一与三的后代，六为四与五的后代。求四与五关系、六近交、六与创始者一的关系。

答案。四与五共享父亲一，关系为零点二五；六近交为零点一二五，对角线为一点一二五。四、五与一的关系都为零点五，因此六与一的关系仍为零点五。这说明祖孙关系未必是普通单一路径的零点二五，本例有两条经四、五通向同一祖先的路径。计算应追踪实际系谱，而不能只看某一亲属名称。

练习三：复杂亲子关系。在例 12.1 中，动物六由三与五所生。求六的近交、六与三关系、孟德尔抽样方差系数，并解释后者为何不等于二分之一乘一减六的近交。

答案。三与五关系为零点七五，因此六近交为零点三七五。六与三关系为 $(A_{33} + A_{53}) / 2 = 0.875$ 。三不近交、五近交零点二五，因此创新系数为 $0.5 - 0.25(0 + 0.25) = 0.4375$ 。创新方差由双亲自身近交决定，六近交则由双亲之间共祖决定。使用后代近交会把条件分离与边际同祖混淆。

练习四：逆矩阵局部贡献。一个后代双亲已知，双亲近交系数分别为零点二和零点四。求其创新系数、子代对角、每个亲本对角、亲本间和亲子位置的局部逆矩阵增量。这里问的是该后代贡献，不是完整矩阵最终元素。

答案。创新系数为 $0.5 - 0.25(0.2 + 0.4) = 0.35$ 。其倒数为二十除七。子代对角增加二十除七，每个亲本对角及亲本间位置增加五除七，两个亲子位置及对称位置增加负十除七。其他后代和创始者还会向相同位置加入贡献，因此不能将这些局部值直接当作完整逆矩阵。外积表达能够同时保证对称与一致加数。

练习五：未知亲本与边缘方差。已知父亲近交为零点二，母亲按独立、不近交基础动物处理。分别在保留母亲和将母亲边缘化时写出后代创新方差系数，验证后代总方差一致。

答案。双亲保留时，严格孟德尔抽样系数为零点四五；父方贡献方差零点三，母方贡献方差零点二五，总计一。母亲边缘化后，创新项合并母方贡献，系数变成零点七，再加父方零点三仍为一。不同创新系数对应不同条件

信息，不代表两种模型对同一边缘遗传方差得出矛盾结论。若母亲与其他动物有关系，则不能简单用独立零点二五合并。

练习六：基因传递分布。在两个无亲缘、不近交亲本的一对全同胞中，对一个具有不同创始标签的位点，求共享零、一、两个标签的概率。若关系实现值定义为共享标签数的一半，求其期望和方差。

答案。父方两次传递选中相同拷贝的概率为二分之一，母方也相同，且本例两方独立。共享数服从两次、成功率二分之一的二项分布，概率为四分之一、二分之一、四分之一。关系实现值为零、零点五、一，期望零点五，方差零点一二五。系谱给的是期望；单个位点实现波动很大，多位点平均的波动还取决于连锁与有效独立片段数。

练习七：三组连接。只观察甲场 S 为十、甲场 T 为十四、乙场 S 为十三，组均值独立误差方差均为二。求场差、父本育种值差及未观测乙场 T 均值的无交互线性预测，并给各自误差方差。

答案。场差为三，系数对应乙场 S 减甲场 S，误差方差为四。父本育种值差为八，将甲场两组之差乘二，误差方差为十六。乙场 T 预测为十四加十三减十，即十七，预测该无误差均值的误差方差为六；若问一个额外、独立误差方差也为二的未来组观测，预测误差还需加二，成为八。区分潜在均值与未来观测目标，与第 1 章的预测目标区分一致。

练习八：差异可靠度。两动物都不近交，关系为零点二五，基础方差为十，各自预测误差方差为五，误差协方差为二。计算差异 PEV 及相应可靠度；说明若只给个体可靠度，缺少什么信息。

答案。差异 PEV 为 $5+5-2\times 2=6$ ，真实差异方差为 $10(1+1-2\times 0.25)=15$ ，可靠度为 $1-6/15=0.6$ 。个体可靠度各为零点五，却不能推出差异可靠度，因为缺少误差协方差。若关系基础或预测目标改变，还要相应调整分母，不能把零点六视为脱离模型的永久比较指标。

练习九：贡献与配对。采用例 12.9 的育种值和关系，四种雌雄配对各占四分之一。求后代平均加性期望和平均近交。若改为两种交叉配对各占二分之一，哪些量保持、哪些量改变？

答案。四种配对的后代均值依次为八、七、七、六，平均七；两种对角配对近交为零点一二五，另两种为零，平均为零点零六二五。交叉配对后总体均值仍为七，平均近交降为零，亲本贡献保持不变。当前配对近交下降不等于统一贡献池的平均共祖下降，因为后者由亲本贡献和完整关系矩阵决定。长期后果还取决于后代留种与实际繁殖贡献。

练习十：近交增长的时间尺度。平均近交从零点一升至零点一一八，但两个观测时间相隔两年，而平均世代间隔为四年。能否直接用这两年的标准化增长率零点零二代入代际公式得到有效大小二十五？应补充什么分析？

答案。不能直接把两年变化当作一代变化。需要说明世代重叠和各出生群体构成，并在适当模型下估计代际增长，或先估计连续时间/年度增长再按明确规则转换。若仅为粗略说明且假设稳定增长，四年累计增长与两年并不完全线性，应基于剩余非同祖比例的乘积关系处理。真实资料还需排除系谱补全、基础改变和样本构成变化。有效大小的精确小数不应掩盖时间定义不清。

练习十一：研究设计辨析。两个育种场分别使用不同父本，最近加入基因组关系后，软件能够输出唯一跨场排名。研究者据此声称环境与遗传已经完全分开。请评价，并提出一项数据设计改进和一项模型检验。

答案。唯一解说明模型与约束确定了一个预测，不证明数据具有充分独立信息。基因组关系可能提供有效连接，但仍需检查参考基础、关系强度、母本来源及环境模型。设计上可在两场交叉使用多个共同父本并合理分配母本、管理组；模型检验可评估关键跨场对比 PEV，开展桥梁敏感性分析，并用后续独立后代记录检查校准。应把结构连接、模型内部精度与现实验证分层报告，避免以算法收敛代替实证支持。

第五篇选择与决策

遗传参数的经典估计方法与试验设计

13.1 从观察统计量到因果参数

遗传参数——遗传力、遗传方差与协方差、遗传相关、重复力——是预测育种值、预测选择反应与设计育种计划的基础。它们不能直接观察，只能从资料中估计。第 11 章建立了因果模型：亲属之间表型的协方差可以用遗传与环境方差组分表示。本章讨论观察模型与估计方法：怎样从资料中度量亲属的相似程度，怎样把这些统计量与因果组分对应起来，估计的精度有多高，以及怎样设计试验才能以有限的资源获得可靠的估计。

基本思路可以用一个三段式表示：**资料 → 观察方差组分（或回归、相关） → 因果方差组分**。第一步用线性模型与方差分析（或似然方法）把表型方差分解为可以由资料直接估计的“观察组分”，例如公畜间方差、母畜间方差与后代内方差；第二步利用第 11 章的因果模型，把观察组分解释为加性方差、显性方差与共同环境方差的组合；第三步由此求出遗传力等参数。表 13.1 汇总了几种常用亲属类型的对应关系。

表 13.1 由亲属相似性估计遗传力（不含上位）

用于度量相似性 的亲属	协方差的因果组 成	回归 (b) 或相关 (t)	遗传力估计
子代对单亲	$\frac{1}{2}V_A$	$b = \frac{1}{2}h^2$	$2b$
子代对双亲均值	$\frac{1}{2}V_A$	$b = h^2$	b
半同胞	$\frac{1}{4}V_A$	$t = \frac{1}{4}h^2$	$4t$

$$\text{全同胞} \quad \frac{1}{2}V_A + \frac{1}{4}V_D + V_{E_c} \quad t > \frac{1}{2}h^2 \quad < 2t$$

13.2 亲子回归

13.2.1 单亲与双亲均值

最直接的方法是把子代表型对亲本表型回归：

$$P_o = \text{固定效应} + b(P_p - \mu) + e, \quad E(\hat{b}_{OP}) = \frac{1}{2}h^2.$$

若双亲都有记录，把子代对双亲均值 $\bar{P}_p = \frac{1}{2}(P_s + P_d)$ 回归，由 $\text{Cov}(P_o, \bar{P}_p) = \frac{1}{2}V_A$ 与 $\text{Var}(\bar{P}_p) = \frac{1}{2}V_P$ （双亲无亲缘、无同型交配），斜率的期望就是 h^2 。

若每个家系有多个子代，可以用子代均值代替单个子代，因为 $\text{Cov}(\bar{P}_o, P_p) = \text{Cov}(P_o, P_p)$ ：平均不改变协方差，只减少因变量的方差。但需注意，以单个子代为观察单位时，同一亲本的多个子代并不独立，普通最小二乘给出的标准误偏小；正确的做法是以家系为单位分析子代均值，家系大小不等时用加权最小二乘，权重与子代均值的方差 $[t + (1 - t)/n_i]^{-1}$ 成正比。

若两性的表型方差不同，例如雄性体重的方差大于雌性，应在合并分析前把各性别的表型标准化，或者分别对父本与母本估计回归系数再按方差比例校正。

13.2.2 亲子回归的稳健性

亲子回归有两个重要的优点。其一，**对亲本的选择不引起偏差**。回归是以自变量（亲本表型）为条件的，若亲本按表型被选择，只改变了自变量的分布范围，回归斜率的期望不变——这是线性回归的一般性质。这使亲子回归在育种群体中特别有用，因为种用亲本几乎总是经过选择的。反之，若按子代表型选择或剔除记录，斜率就会有偏。其二，**亲子之间通常没有共同的环境**，也不含显性方差，因此亲子回归估计的是相对“干净”的加性方差。但母—子回归可能受母体效应影响：母亲提供的子宫与哺育环境使母子相似性高于加性预期（第 11 章表 11.3）。父—子回归则基本不受母体效应影响，是

最可靠的亲子统计量之一。

亲子回归的主要缺点是精度不高。在 N 个亲子对中，单亲回归遗传力估计的标准误约为

$$SE(\hat{h}^2) \approx 2\sqrt{\frac{1 - (\frac{1}{2}h^2)^2}{N}} \approx \frac{2}{\sqrt{N}}, \quad (13.1)$$

一千对资料的标准误约为 0.063；双亲均值回归约为 $\sqrt{2/N}$ ，一千个家系约为 0.045。若每个家系测定多个子代，标准误进一步降低，但收益受到组内相关的限制。正向同型交配会使亲本之间的表型相关为正，双亲均值的方差增大，从而使双亲均值回归低估遗传力，单亲回归则会高估（因为配偶的遗传贡献通过同型交配与所回归的亲本相关）。

13.3 套式同胞分析

13.3.1 线性模型与方差分析

家畜中最常用的经典设计是套式（等级）交配设计： s 头公畜各与 d 头母畜交配，每头母畜产生 k 个后代。于是每头公畜有 dk 个半同胞后代，其中又分为 d 个全同胞家系。只在后代上测定表型，线性模型为

$$P_{ijl} = \text{固定效应} + S_i + D_{j(i)} + e_{ijl}, \quad (13.2)$$

公畜效应 S_i 、公畜内母畜效应 $D_{j(i)}$ 与后代内残差 e_{ijl} 都作为随机效应。表型方差（校正固定效应后）被分解为三个**观察方差组分**：

$$\sigma_T^2 = \sigma_S^2 + \sigma_D^2 + \sigma_W^2.$$

方差分析表（表 13.2）给出各均方的期望，推导方法与第 3 章的单因素模型相同。

表 13.2 平衡套式设计的方差分析

变异来源	自由度	均方	期望均方
公畜间	$s - 1$	MS_S	$\sigma_W^2 + k\sigma_D^2 + dk\sigma_S^2$
公畜内母畜间	$s(d - 1)$	MS_D	$\sigma_W^2 + k\sigma_D^2$
后代内	$sd(k - 1)$	MS_W	σ_W^2

由此得到观察组分的估计：

$$\hat{\sigma}_S^2 = \frac{MS_S - MS_D}{dk}, \quad \hat{\sigma}_D^2 = \frac{MS_D - MS_W}{k}, \quad \hat{\sigma}_W^2 = MS_W. \quad (13.3)$$

13.3.2 观察组分的因果解释

把观察组分与亲属协方差联系起来，关键是一个简单而深刻的原理：**组内成员之间的协方差等于组间方差**——使组内成员相似的东西，正是使各组之间不同的东西。同一公畜的两个后代（半同胞）只共享公畜效应，

$$\text{Cov}(HS) = \text{Cov}(S_i + D_{j(i)} + e, S_i + D_{j'(i)} + e') = \sigma_S^2;$$

同一母畜的两个后代(全同胞)共享公畜与母畜效应, $\text{Cov}(FS) = \sigma_S^2 + \sigma_D^2$ 。代入第 11 章的因果模型：

表 13.3 套式设计观察组分的因果解释

观察组分	亲属协方差	因果组成
σ_S^2	$\text{Cov}(HS)$	$\frac{1}{4}V_A$
σ_D^2	$\text{Cov}(FS) - \text{Cov}(HS)$	$\frac{1}{4}V_A + \frac{1}{4}V_D + V_{E_c}$
σ_W^2	$V_P - \text{Cov}(FS)$	$\frac{1}{2}V_A + \frac{3}{4}V_D + V_{E_w}$
$\sigma_S^2 + \sigma_D^2$	$\text{Cov}(FS)$	$\frac{1}{2}V_A + \frac{1}{4}V_D + V_{E_c}$
σ_T^2	V_P	$V_A + V_D + V_{E_c} + V_{E_w}$

（上表忽略上位与母体遗传效应；母体效应若存在，会进入 σ_D^2 。）

由此可以用三种方式估计遗传力：

- 公畜组分: $\hat{h}_S^2 = 4\hat{\sigma}_S^2/\hat{\sigma}_T^2$, 无偏;
- 母畜组分: $\hat{h}_D^2 = 4\hat{\sigma}_D^2/\hat{\sigma}_T^2$, 偏高 $(V_D + 4V_{E_c})/V_P$;
- 公畜与母畜组分合并: $\hat{h}_{S+D}^2 = 2(\hat{\sigma}_S^2 + \hat{\sigma}_D^2)/\hat{\sigma}_T^2$, 偏高 $(\frac{1}{2}V_D + 2V_{E_c})/V_P$ 。

比较 $\hat{\sigma}_D^2$ 与 $\hat{\sigma}_S^2$ 还能检验非加性与共同环境的存在: $\sigma_D^2 - \sigma_S^2 = \frac{1}{4}V_D + V_{E_c}$, 但无法把显性方差与共同环境方差分开。

用哪个估计取决于偏差与精度之间的权衡。公畜组分无偏, 但只利用了公畜间的变异, 自由度少、标准误差大; 合并估计利用了更多的信息, 精度较高, 但可能有偏。若有理由相信显性与共同环境方差都很小 (例如在不同窝中分开饲养的个体), 合并估计更好; 否则应以公畜组分为准。

13.4 一个套式设计资料的完整分析

下面用一个完整的教学资料集说明上述方法。资料来自一个套式交配设计: 40 头公畜各与 5 头母畜交配, 每次交配产生 6 个后代, 共 1200 个后代, 全部在同一场饲养; 资料中同时记录了每个后代、其父本与母本的表型。下面依次用七种方法估计狭义遗传力。

13.4.1 亲子回归

子代对父本回归。以单个后代为观察单位, 斜率 $\hat{b} = 0.236$, $\hat{h}^2 = 0.473$ 。普通最小二乘给出的斜率标准误差为 0.033, 相应 $SE(\hat{h}^2) = 0.067$ 。但同一公畜的 30 个后代共享同一个自变量值, 彼此并不独立, 这一标准误差严重偏小。

公畜后代均值对公畜回归。以公畜为单位, 把每头公畜 30 个后代的平均表型对公畜表型回归 (图 13.1A), 斜率仍为 0.236——平均不改变协方差, 点估计与前者完全相同——但标准误差为 0.064, $SE(\hat{h}^2) = 0.129$, 约为前者的两倍。只有 40 个独立的公畜, 信息量有限。这一比较清楚地说明: **观察单位必须与独立的抽样单位一致**, 否则标准误差会给人虚假的精确印象。

子代对母本回归。斜率 0.346, $\hat{h}^2 = 0.691$, 显著高于父本回归的估计。**子代对双亲均值回归**, 斜率 0.563, 即 $\hat{h}^2 = 0.563$, 介于二者之间。母本回归明显高于父本回归, 提示母子之间存在加性遗传之外的相似性, 最可能的来




图 13.1 套式设计资料的亲子回归与半同胞设计的最优家系大小。A 图为 40 头公畜的后代均值对公畜表型的回归；B 图为总记录数为 2000 时，不同遗传力下公畜组分遗传力估计的标准误随每头公畜后代数的变化，圆点为最优家系大小

源是母体效应（第 11 章）：母亲提供的子宫与哺育环境同时影响了母亲本身（通过外祖母）与其后代。资料中公畜表型的方差（284）明显小于后代表型的方差（388），可能反映公畜是经过选择的个体，但如前所述，这并不使父本回归产生偏差。

13.4.2 套式方差分析

表 13.4 为方差分析结果。公畜与公畜内母畜两个来源都高度显著。

表 13.4 套式设计资料的方差分析

变异来源	自由度	均方	F	p
公畜间	39	1815.4	3.02	6×10^{-7}
公畜内母畜间	160	601.3	2.02	1×10^{-10}
后代内	1000	297.8		

由式 (13.3), $\hat{\sigma}_S^2 = (1815.4 - 601.3)/30 = 40.47$, $\hat{\sigma}_D^2 = (601.3 - 297.8)/6 = 50.58$, $\hat{\sigma}_W^2 = 297.83$, 表型方差 $\hat{\sigma}_T^2 = 388.9$ 。于是：

- 公畜组分： $\hat{h}_S^2 = 4 \times 40.47/388.9 = 0.416$ ，近似标准误 0.139；
- 母畜组分： $\hat{h}_D^2 = 4 \times 50.58/388.9 = 0.520$ ，近似标准误 0.117；

- 合并: $\hat{h}_{S+D}^2 = 2 \times (40.47 + 50.58) / 388.9 = 0.468$ 。

半同胞组内相关 $\hat{t}_{HS} = 0.104$, 全同胞组内相关 $\hat{t}_{FS} = 0.234$ 。母畜组分高于公畜组分, 差值 $4(\hat{\sigma}_D^2 - \hat{\sigma}_S^2) / \hat{\sigma}_T^2 = 0.104$ 估计了 $(V_D + 4V_{E_c}) / V_P$, 与亲子回归中母本回归偏高的现象相互印证: 资料中存在母体效应或共同窝环境, 或者存在显性方差。

13.4.3 哪个估计最好

七个估计从 0.416 到 0.691 不等。哪一个最可信? 从偏差的角度看, 父本回归 (0.473) 与公畜组分 (0.416) 不受母体效应、共同环境与显性的影响, 是两个无偏估计; 母本回归 (0.691)、母畜组分 (0.520)、双亲均值回归 (0.563) 与合并估计 (0.468) 都可能因母体效应而偏高。从精度的角度看, 两个无偏估计的标准误都在 0.13 左右, 相差不大; 二者都依赖于 40 头公畜, 彼此并不独立。综合而言, 以公畜组分或父本回归为准, 遗传力约为 0.42 至 0.47, 标准误约 0.13。若要分离母体效应, 需要更多代的资料与包含母体效应的动物模型 (第 22—23 章)。

这个例子还说明了一个容易被忽视的事实: 在实际资料中, 不同方法给出的估计常常相差较大, 这种差异本身就是有价值的信息, 它揭示了简单加性模型之外的变异来源。

13.4.4 似然方法

对平衡资料, 若所有方差组分的方差分析估计都为正, 限制最大似然 (REML) 估计与方差分析估计完全相同。对本例资料, 以平衡套式模型的 REML 似然数值求解, 得到 $\hat{\sigma}_S^2 = 40.47$ 、 $\hat{\sigma}_D^2 = 50.58$ 、 $\hat{\sigma}_W^2 = 297.83$, 与方差分析估计一致到小数点后多位。REML 的价值在资料不平衡时才真正显现: 此时方差分析的平方和不再有唯一的分解方式, 各种方法 (亨德森方法 I、II、III) 给出不同的估计, 而 REML 给出唯一的、具有良好统计性质的估计, 并自然地限制在参数空间内。REML 还能利用资料中的全部亲缘关系, 同时估计直接与母体效应等多个组分, 并在一定条件下不受基于资料的选择所造成的偏差影响。第 23 章将系统讨论 REML 与贝叶斯方差组分估计。

13.5 析因交配设计

套式设计无法把显性方差与共同环境方差分开，因为每头母畜只与一头公畜交配。在植物以及某些可以多次交配的动物（如鱼类、可控制交配的家禽）中，可以采用析因设计，让每头公畜与每头母畜都交配。

13.5.1 北卡罗来纳设计

科克汉姆与鲁滨逊在美国北卡罗来纳州为玉米育种发展了三种经典设计。**设计 I**即上面的套式设计。**设计 II**是完全析因设计： s 个父本与 d 个母本两两交配，每个组合测定 k 个后代。线性模型为

$$P_{ijl} = \text{固定效应} + S_i + D_j + I_{ij} + e_{ijl},$$

I_{ij} 为父本 $\times$ 母本互作，反映了来自父本与母本的等位基因之间的非加性作用，即显性。方差分析的期望均方为：

表 13.5 北卡罗来纳设计 II 的方差分析

变异来源	自由度	期望均方	因果解释
父本	$s - 1$	$\sigma_e^2 + k\sigma_I^2 + dk\sigma_S^2$	$\sigma_S^2 = \frac{1}{4}V_A$
母本	$d - 1$	$\sigma_e^2 + k\sigma_I^2 + sk\sigma_D^2$	$\sigma_D^2 = \frac{1}{4}V_A + V_{E_c}$
父本 $\times$ 母本	$(s - 1)(d - 1)$	$\sigma_e^2 + k\sigma_I^2$	$\sigma_I^2 = \frac{1}{4}V_D$
误差	$sd(k - 1)$	σ_e^2	$\frac{1}{2}V_A + \frac{3}{4}V_D + V_{E_w}$

设计 II 可以分别估计 V_A （由父本组分）、 V_D （由互作组分）、 V_{E_c} （由母本组分减父本组分）与 V_{E_w} 。在一个 30×30 、每组合 4 个后代的模拟中（真实 $V_A = 40$ 、 $V_D = 16$ 、 $V_{E_c} = 8$ 、 $V_{E_w} = 36$ ），200 次重复的平均估计为 42.5、15.4、7.8 与 35.4，都接近真值；但标准差分别为 11.8、4.7、6.6 与 7.6，即使有 3600 个后代，各组分的估计仍有相当的不确定性，其中共同环境方差的相对误差最大。**设计 III** 把 F_2 个体与两个亲本自交系回交，用于估计 F_2 群体中的加性与显性方差以及平均显性度。

13.5.2 双列杂交

双列杂交是一组亲本之间所有可能杂交组合的设计，可以包括或不包括自交与反交。格里芬（1956）系统地地区分了四种双列方法，并给出了一般配合力（GCA）与特殊配合力（SCA）的估计方法：

$$Y_{ij} = \mu + g_i + g_j + s_{ij} + r_{ij} + e_{ij},$$

g_i 为亲本 i 的一般配合力， s_{ij} 为组合 (i, j) 的特殊配合力， r_{ij} 为反交效应。在随机交配群体的亲本中，一般配合力方差对应于 $\frac{1}{4}V_A$ ，特殊配合力方差对应于 $\frac{1}{4}V_D$ ；在自交系亲本中，二者分别对应 V_A 与 V_D 的相应倍数。双列杂交在作物杂交种选育中有广泛应用，第20章将从杂种优势与配合力的角度进一步讨论。

13.6 估计的精度与试验设计

13.6.1 遗传力估计的标准误

遗传力估计的标准误取决于所用的亲属类型、家系数目与家系大小。对同胞分析， $\hat{h}^2 = \hat{t}/r$ ，其中 r 是同胞之间的加性关系（半同胞 $\frac{1}{4}$ ，全同胞 $\frac{1}{2}$ ），因此 $SE(\hat{h}^2) = SE(\hat{t})/r$ 。由第3章式（3.18），

$$SE(\hat{t}) \approx \sqrt{\frac{2(1-t)^2[1+(n-1)t]^2}{n(n-1)(s-1)}}, \quad (13.4)$$

s 为家系数， n 为家系大小。半同胞的 $r = \frac{1}{4}$ ，因此其遗传力估计的标准误是组内相关标准误的四倍，这是半同胞分析需要大量资料的原因。

13.6.2 最优家系大小

在总记录数 $T = sn$ 固定时，应当测定较多的小家系，还是较少的大家系？家系太少，家系间方差的估计自由度不足；家系太大，每个家系内的额外后代只能提高该家系均值的精度，而家系均值的精度受组内相关的限制。罗伯逊（1959）证明，使组内相关估计的标准误最小的家系大小近似为

$$n_{\text{opt}} \approx \frac{1}{t}. \quad (13.5)$$

对半同胞, $t = \frac{1}{4}h^2$, 于是 $n_{\text{opt}} \approx 4/h^2$: 遗传力为 0.1 时每头公畜约 40 个后代, 0.25 时约 16 个, 0.5 时约 8 个。在总记录数 2000 的数值计算中, 最优家系大小分别为 39、17 与 9 (图 13.1B), 与近似公式非常吻合。最优点附近曲线相当平坦, 适度偏离最优值损失不大; 但家系过小 (如每公畜 2 至 3 个后代) 或过大 (如每公畜数百个后代) 都会显著增大标准误。由于设计时遗传力未知, 罗伯逊建议以对遗传力的先验估计设计, 并宁可家系略大, 因为低估 t 时的损失小于高估时的损失。

在相同记录数下, 不同设计的精度也不同。粗略地说, 若遗传力不太低, 全同胞分析的精度高于半同胞分析, 因为全同胞相关是半同胞的两倍; 但全同胞估计受显性与共同环境的影响。亲子回归在每家系只有一个子代时, 标准误约为 $2/\sqrt{N}$, 与合理设计的半同胞分析相当。实际选择还要考虑成本: 家畜中测定公畜比测定后代昂贵得多, 而植物中控制授粉的成本可能决定了能产生多少家系。

13.6.3 偏差的来源

遗传参数估计的偏差主要来自以下几个方面, 设计与分析时都应当考虑: 共同环境 (全同胞、同窝、同圈) 使全同胞与母畜组分偏高; 显性与上位方差使全同胞估计偏高, 上位方差也会少量进入半同胞与亲子估计; 母体效应使母系亲属的估计偏高; 选择——若按子代表型选择或剔除, 或者资料中只包括存活到测定年龄的个体——会使方差组分偏低; 同型交配与近交改变亲属之间的遗传关系; 基因型与环境互作, 若亲属分布在不同环境中, 其表型相似性会被低估。总体而言, 父本回归与半同胞相关是偏差最小的估计, 但未必是标准误最小的。

13.7 遗传相关的估计

遗传相关的估计以协方差代替方差, 原理完全相同。

亲子交叉协方差。在亲本与子代上都测定两个性状 X 与 Y 。子代 X 与亲本 Y 的协方差期望为 $\frac{1}{2} \text{Cov}(A_X, A_Y)$, 子代 Y 与亲本 X 亦然; 子代 X 与

亲本 X 的协方差为 $\frac{1}{2}V_{A_X}$ 。于是

$$\hat{r}_A = \frac{\text{Cov}(X_o, Y_p) + \text{Cov}(Y_o, X_p)}{2\sqrt{\text{Cov}(X_o, X_p) \text{Cov}(Y_o, Y_p)}}. \quad (13.6)$$

协方差分析。在同胞设计中，对两个性状同时做方差分析，并以交叉乘积代替平方和，得到“协方差分析”（ANCOVA）。半同胞设计中，公畜间的协方差组分估计 $\frac{1}{4}\text{Cov}(A_X, A_Y)$ ，于是

$$\hat{r}_A = \frac{\hat{\sigma}_{S_{XY}}}{\sqrt{\hat{\sigma}_{S_X}^2 \hat{\sigma}_{S_Y}^2}}.$$

遗传相关的估计远比遗传力不精确。罗伯逊（1959）给出了半同胞分析中遗传相关标准误的近似：

$$\text{SE}(\hat{r}_A) \approx \frac{1 - r_A^2}{\sqrt{2}} \sqrt{\frac{\text{SE}(\hat{h}_X^2) \text{SE}(\hat{h}_Y^2)}{h_X^2 h_Y^2}}. \quad (13.7)$$

在一个 200 头公畜、每头 20 个后代的模拟中 ($h_X^2 = 0.3$, $h_Y^2 = 0.2$, $r_A = 0.5$, $r_E = -0.2$)，300 次重复的遗传相关估计平均为 0.508，标准差 0.114，式 (13.7) 的近似为 0.096。四千个后代的资料，遗传相关估计的标准误差仍在 0.1 左右；若遗传力更低或资料更少，标准误轻易超过 0.3，估计几乎没有用处。遗传相关的这种不精确性，是多性状选择指数中参数误差的主要来源（第 15—17 章）。

13.8 不平衡资料与似然方法的地位

上述方差分析方法要求资料平衡，即每个公畜的母畜数、每个母畜的后代数都相同。实际育种资料几乎总是不平衡的：公畜的后代数从几头到几千头不等，固定效应（场、年、季）与遗传效应交叉分布，资料中还有多代系谱。亨德森（1953）提出了三种适用于不平衡资料的方差组分估计方法（方法 I、II、III），它们都是基于二次型的矩估计，在混合模型方法发展之前被广泛使用，但对资料结构敏感，可能产生负估计，也无法充分利用系谱信息。

帕特森与汤普森 (1971) 提出的限制最大似然 (REML) 解决了这些问题：它利用资料中全部的亲缘关系，适用于任意不平衡的资料与复杂模型，自然地给出参数空间内的估计，并在一定条件下不受基于资料的选择所造成的偏差影响。随着动物模型与平均信息算法的发展，REML 已经成为估计遗传参数的标准方法，经典的方差分析方法主要用于平衡试验与教学。但经典方法的价值并没有消失：它们揭示了“哪些资料提供了关于哪些组分的信息”，这正是理解 REML 结果、诊断识别问题和设计试验所需的直觉。第 23 章将从似然的角度重新审视本章的平衡资料，读者会看到，平衡套式模型的 REML 恰好可以写成三个均方的独立似然之和。

13.9 用蒙特卡洛模拟检验估计方法

本章多次使用了模拟：在已知真实参数的模型下产生大量资料集，用某种方法估计参数，比较估计值的分布与真值，从而得到估计的偏差与标准误。这种**蒙特卡洛模拟**是研究估计方法性质的有力工具，尤其是在解析结果难以得到时，例如不平衡资料、选择后的资料、非正态分布或复杂的系谱。

生成模拟资料的基本工具是正态随机数。最经典的方法之一是博克斯—穆勒变换：若 U_1, U_2 为独立的 $(0, 1)$ 均匀随机数，则

$$Z_1 = \sqrt{-2 \ln U_1} \cos(2\pi U_2), \quad Z_2 = \sqrt{-2 \ln U_1} \sin(2\pi U_2)$$

是独立的标准正态随机数。要产生具有协方差矩阵 $\mathbf{V}$ 的多元正态向量，可以对 $\mathbf{V}$ 做 Cholesky 分解 $\mathbf{V} = \mathbf{L}\mathbf{L}'$ ，令 $\mathbf{x} = \mathbf{L}\mathbf{z}$ (第 2 章)。对系谱资料，可以利用式 (11.5) 的递推：基础个体的育种值直接抽取，后代的育种值为双亲育种值的平均加上方差为 $\frac{1}{2}(1 - \bar{F})\sigma_A^2$ 的孟德尔抽样项。

设计模拟研究时应当注意：明确所要回答的问题与所比较的方法；重复次数要足以使蒙特卡洛误差小于所关心的差异；参数设置要覆盖实际情形的合理范围；随机数种子应当记录以保证可重复；结果应同时报告偏差、标准误与均方误差，并给出它们的蒙特卡洛标准误。第 37 章将从研究设计的角度系统讨论模拟研究。

13.10 深入专题

13.10.1 重复力的估计

重复力由同一个体多次测定之间的组内相关估计。设 s 个个体各有 k 次测定, 单因素随机模型 $y_{ij} = \mu + a_i + e_{ij}$ 中, a_i 包括遗传与一般环境效应, e_{ij} 为特殊环境效应。方差分析给出个体间方差组分 $\hat{\sigma}_a^2 = (MS_B - MS_W)/k$ 与个体内方差组分 $\hat{\sigma}_e^2 = MS_W$, 重复力为

$$\hat{r} = \frac{\hat{\sigma}_a^2}{\hat{\sigma}_a^2 + \hat{\sigma}_e^2}.$$

其标准误可用第 3 章式 (3.18) 计算。由于每个个体都提供多次测定, 重复力的估计通常比遗传力精确得多: 重复力描述的是个体之间的差异, 所有个体都提供信息; 而遗传力描述的是亲属之间的协方差, 只有亲属之间的关系提供信息。实际资料中, 各次测定的条件可能不同 (如胎次、年龄), 应先校正这些系统效应; 若方差随测定次序改变, 或者不同测定之间的相关并不恒定 (例如相邻胎次更相关), 简单的重复力模型就不再充分, 需要用多性状模型或随机回归模型 (第 24 章)。

13.10.2 二分类性状的遗传力: 易感性尺度上的估计

对二分类性状 (发病与否), 福尔克纳 (1965) 提出了一种由群体发病率与亲属发病率估计易感性尺度遗传力的方法。设群体发病率为 q_g , 先证者的亲属中发病率为 q_r 。在易感性服从正态分布、阈值固定的模型下, 以 x_g 、 x_r 分别表示一般群体与亲属群体中阈值相对于各自均值的标准化距离, $a_g = \phi(x_g)/q_g$ 为发病个体易感性均值相对于群体均值的偏离 (以标准差计), 则亲属易感性均值的偏离约为 $x_g - x_r$, 于是易感性对先证者的回归系数为

$$b = \frac{x_g - x_r}{a_g}. \quad (13.8)$$

遗传力为 $h^2 = b/R$, R 为亲属关系系数 (全同胞或亲子 $R = \frac{1}{2}$, 半同胞 $\frac{1}{4}$)。例如某病群体发病率 1%, 先证者的全同胞中发病率 5%。由正态分位数, $x_g = 2.326$, $x_r = 1.645$, $a_g = \phi(2.326)/0.01 = 2.665$, $b =$

$(2.326 - 1.645)/2.665 = 0.256$, $h^2 = 0.51$ 。这种方法假定亲属之间只有加性遗传的相似性, 没有共同环境; 在家畜中, 更常用的是直接拟合阈值动物模型 (第 24 章), 或者先估计观察尺度遗传力, 再用第 3 章式 (3.25) 换算到易感性尺度。

13.10.3 选择资料中的参数估计

育种资料几乎总是选择的结果: 只有表现好的个体留下后代, 只有被选中的公畜进行后裔测定。选择对参数估计的影响取决于选择的依据与分析所用的资料。亲子回归以亲本表型为条件, 亲本选择不造成偏差 (第 13.2 节)。方差分析方法对选择敏感: 若后代资料中只包括存活到测定年龄的个体, 而存活与被测性状相关, 方差组分会被低估。亨德森 (1975) 与戈菲内 (1983) 证明, 在混合模型框架中, 若选择所依据的全部资料都包含在分析中, 并且模型正确、使用了完整的系谱, REML 与 BLUP 可以给出不受选择偏差影响的估计与预测。这一结论的条件在实践中难以完全满足——选择常常部分依据未记录的信息——但它说明了在评定与参数估计中保留全部历史资料与完整系谱的重要性。

13.10.4 实现遗传力与估计遗传力的比较

第 14 章的选择试验给出的实现遗传力, 常被用来检验由亲属相似性估计的遗传力能否预测实际的选择反应。法尔科纳与麦凯总结的大量选择试验表明, 二者在多数情况下大体一致, 但实现遗传力在长期选择中往往逐代下降, 这与 Bulmer 效应、频率改变与近交一致; 在某些试验中, 实现遗传力在向上与向下两个方向上不对称 (第 14 章)。在实践中, 这一比较是检验遗传模型有效性的重要手段: 若实现遗传力显著低于估计遗传力, 提示模型遗漏了某些重要因素, 如自然选择的对抗、基因型与环境互作, 或者估计遗传力受到了共同环境或母体效应的高估。

13.11 本章小结

遗传参数通过“资料—观察组分—因果组分”三步估计。亲子回归以亲本表型为条件，对亲本的选择不引起偏差，单亲回归斜率估计 $\frac{1}{2}h^2$ ，双亲均值回归估计 h^2 ；分析时观察单位应与独立抽样单位一致，否则标准误被低估。套式同胞分析把表型方差分解为公畜、母畜与后代内组分，公畜组分估计 $\frac{1}{4}V_A$ ，母畜组分还包括显性与共同环境，因此公畜组分给出无偏但精度较低的估计。一个 $40 \times 5 \times 6$ 的教学资料集显示，父本回归与公畜组分的估计约为 0.42 至 0.47，而母本相关的估计因母体效应而偏高。北卡罗来纳设计 II 与双列杂交可以分离加性、显性与共同环境方差，但各组分的估计仍有相当的不确定性。遗传力估计的精度取决于家系数与家系大小，半同胞设计的最优家系大小约为 $4/h^2$ 。遗传相关的估计远不如遗传力精确。对不平衡资料，REML 已成为标准方法，而经典方法提供了理解信息来源与设计试验的直觉。蒙特卡洛模拟是研究估计方法性质的通用工具。

13.12 习题

习题 13.1 在一个亲子回归资料中，300 头公畜各有 1 个后代测定，子代对父本回归斜率为 0.18。估计遗传力及其近似标准误。若改为每头公畜测定 10 个后代并对后代均值回归（组内相关 0.05），标准误大约变为多少？

习题 13.2 某套式设计有 50 头公畜、每头公畜配 4 头母畜、每头母畜 6 个后代。方差分析得 $MS_S = 420$ 、 $MS_D = 180$ 、 $MS_W = 100$ 。估计三个观察组分、三种遗传力，以及 $(V_D + 4V_{E_c})/V_P$ 。

习题 13.3 说明为什么“组内成员之间的协方差等于组间方差”，并用单因素随机模型证明。

习题 13.4 在北卡罗来纳设计 II 中， $MS_S = 300$ 、 $MS_D = 380$ 、 $MS_I = 120$ 、 $MS_e = 80$ ， $s = d = 20$ ， $k = 5$ 。估计 V_A 、 V_D 、 V_{E_c} 、 V_{E_w} 与遗传力。

习题 13.5 计划估计一个遗传力约为 0.2 的性状，总共可测定 3000 个后代。半同胞设计中每头公畜应测定多少后代？估计的标准误约为多少？

习题 13.6 两性状 X 、 Y 的亲子资料中， $\text{Cov}(X_o, X_p) = 12$ ， $\text{Cov}(Y_o,$

$Y_p) = 3$, $\text{Cov}(X_o, Y_p) = 2.5$, $\text{Cov}(Y_o, X_p) = 3.5$ 。估计遗传相关。

习题 13.7 设计一个蒙特卡洛模拟, 比较套式设计中公畜组分与合并组分两种遗传力估计在存在共同窝环境 ($c^2 = 0.1$) 时的偏差与均方误差。列出模拟的步骤与需要报告的统计量。

13.13 习题解答

13.1 $\hat{h}^2 = 0.36$, $\text{SE} \approx 2/\sqrt{300} = 0.115$ 。后代均值的方差为 $[0.05 + 0.95/10]V_P = 0.145V_P$, 回归斜率的方差约为 $0.145/300$ (以 $V_P = 1$ 计), $\text{SE}(\hat{b}) = 0.022$, $\text{SE}(\hat{h}^2) \approx 0.044$ 。

13.2 $\hat{\sigma}_S^2 = (420-180)/24 = 10$, $\hat{\sigma}_D^2 = (180-100)/6 = 13.33$, $\hat{\sigma}_W^2 = 100$, $V_P = 123.33$ 。 $\hat{h}_S^2 = 0.324$, $\hat{h}_D^2 = 0.432$, $\hat{h}_{S+D}^2 = 0.378$; $(V_D + 4V_{E_c})/V_P = 4(13.33 - 10)/123.33 = 0.108$ 。

13.3 模型 $y_{ij} = \mu + a_i + e_{ij}$, 同组两成员的协方差 $\text{Cov}(a_i + e_{ij}, a_i + e_{ij'}) = \text{Var}(a_i) = \sigma_a^2$, 恰为组间方差组分。直观上, 组间差异正来自组内成员共享的那部分效应。

13.4 $\hat{\sigma}_S^2 = (300 - 120)/100 = 1.8$, $\hat{\sigma}_D^2 = (380 - 120)/100 = 2.6$, $\hat{\sigma}_I^2 = (120 - 80)/5 = 8$ 。 $V_A = 7.2$, $V_D = 32$, $V_{E_c} = 0.8$, $V_{E_w} = 80 - 3.6 - 24 = 52.4$ 。 $V_P = 92.4$, $h^2 = 0.078$ 。本例显性方差很大, 读者可以思考这样的结果在实际资料中是否可信。

13.5 $n_{\text{opt}} \approx 4/0.2 = 20$, 即 150 头公畜。由式 (13.4), $t = 0.05$, $\text{SE}(\hat{t}) = \sqrt{2 \times 0.9025 \times 1.95^2 / (20 \times 19 \times 149)} = 0.0109$, $\text{SE}(\hat{h}^2) \approx 0.044$ 。

13.6 $\hat{r}_A = (2.5 + 3.5)/(2\sqrt{12 \times 3}) = 6/12 = 0.5$ 。

13.7 步骤: 设定公畜数、母畜数、后代数与参数 (h^2 、 c^2); 按式 (13.2) 及因果解释产生公畜效应 (方差 $\frac{1}{4}V_A$)、母畜效应 (方差 $\frac{1}{4}V_A + V_{E_c}$) 与后代内效应; 做方差分析, 计算两种估计; 重复至少一千次。报告各估计的平均值、偏差、标准差、均方误差及其蒙特卡洛标准误, 并讨论在什么 c^2 下合并估计的均方误差开始超过公畜组分估计。

13.14 补充习题

习题 13.8 100 头母牛各有 3 个胎次的产奶记录，方差分析得个体间均方 $MS_B = 2.4 \times 10^6$ ，个体内均方 $MS_W = 0.8 \times 10^6$ （单位千克²）。估计重复力，并说明这一估计是否可以作为遗传力的上限。

习题 13.9 某疾病群体发病率 2%，患病个体的半同胞中发病率 3.5%。按式（13.8）估计易感性尺度的遗传力。

13.15 补充习题解答

13.8 $\hat{\sigma}_a^2 = (2.4 - 0.8) \times 10^6 / 3 = 0.533 \times 10^6$, $\hat{r} = 0.533 / (0.533 + 0.8) = 0.40$ 。重复力包括遗传与一般环境方差，是广义遗传力的上限，因而也是狭义遗传力的上限。

13.9 $x_g = 2.054$, $x_r = \Phi^{-1}(0.965) = 1.812$, $a_g = \phi(2.054) / 0.02 = 0.0484 / 0.02 = 2.42$, $b = (2.054 - 1.812) / 2.42 = 0.100$, $h^2 = 0.100 / 0.25 = 0.40$ 。

第五篇

PART V

选择理论与选择指数

选择是育种改良的发动机。本篇从育种者方程与 Bulmer 效应出发，进入单性状与多性状选择指数、约束决策和长期选择的系统理论。

第 14 章 选择反应的数量遗传理论

第 15 章 单性状选择指数与信息融合

第 16 章 多性状育种目标与经济权重

第 17 章 限制指数、非线性目标与稳健决策

第 18 章 选择反应、世代间隔与长期遗传多样性

选择反应的数量遗传理论

14

14.1 从静态的遗传结构到群体的改变

前面各章讨论的是一个群体在某一时刻的遗传结构：等位基因频率、单倍型与连锁不平衡、遗传方差及其组分、亲属间的相似性。这些可以称为“静态的”数量遗传学。从本章开始，我们转向“动态的”数量遗传学：群体的遗传组成怎样随世代改变，尤其是在选择作用下怎样改变。育种者的目标，是使群体的遗传组成朝期望的方向变化，其手段有两个：选择哪些个体作为下一代的亲本，以及怎样安排被选亲本之间的交配（近交、杂交或随机交配）。本章讨论第一个手段的理论基础：选择反应怎样预测，取决于哪些因素，它在位点层次上的机制是什么，选择怎样改变遗传方差，实际的反应怎样测定，为什么实际反应往往偏离预测，以及长期的反应有没有极限。第15至18章将在此基础上讨论选择指数、多性状选择与长期育种计划的设计；第19至20章讨论交配体系。

标准的选择理论是针对随机交配的远交群体发展起来的，但其原理同样适用于在自交系或无性系之间进行选择的情形，只是需要把“育种值”换成相应的遗传值。

14.2 育种者方程

14.2.1 选择差与选择反应

设在一个群体中，按表型选择一部分个体作为亲本。被选亲本的平均表型与全部候选个体平均表型之差称为**选择差** S ；亲本产生的后代的平均表型

与亲本世代全体平均表型之差称为**选择反应** R 。

预测选择反应最简洁的方法是利用第 13 章的亲子回归。子代表型对双亲均值的回归斜率为 h^2 ：

$$E(P_o) = M + b_{OP}(\bar{P}_p - M) = M + h^2(\bar{P}_p - M).$$

对被选亲本求平均, $\bar{P}_p - M$ 正是选择差 S , 于是

$$R = h^2 S. \quad (14.1)$$

这就是**育种者方程**。它说明, 选择差中只有遗传力所占的比例能够传递给下一代, 其余部分是环境与非加性效应造成的、不能遗传的优势。这又是一次“向均值回归”: 被选亲本表型优秀, 部分因为它们的环境好, 而环境优势不会遗传。

若雌雄两性分别选择, 子代对父本与母本各以 $\frac{1}{2}h^2$ 回归,

$$R = \frac{1}{2}h^2 S_m + \frac{1}{2}h^2 S_f = h^2 \frac{S_m + S_f}{2}. \quad (14.2)$$

14.2.2 选择强度

要在选择之前预测反应, 需要预测选择差。若选择标准服从正态分布、实行**截断选择** (表型超过某个阈值的个体全部入选, 其余全部淘汰), 则选择差与表型标准差之比只取决于留种率 p :

$$S = i\sigma_P, \quad i = \frac{z}{p}, \quad (14.3)$$

i 称为**选择强度**, z 是标准正态密度在标准化截断点 x 处的高度, x 满足 $\Pr(Z > x) = p$ 。式 (14.3) 的推导只需一步积分: 截断点以上部分的均值为

$$E(Z | Z > x) = \frac{1}{p} \int_x^\infty z\phi(z)dz = \frac{1}{p} [-\phi(z)]_x^\infty = \frac{\phi(x)}{p}.$$

表 14.1 列出了常用留种率对应的选择强度。留种率为 50% 时 $i = 0.80$, 20% 时 1.40, 10% 时 1.75, 5% 时 2.06, 1% 时 2.67, 0.1% 时 3.37。选择强

度随留种率下降而增加，但增速递减：从10%降到1%，留种个体减少为十分之一，选择强度只提高约50%。

表 14.1 截断选择的选择强度与方差缩减系数

留种率 p	0.5	0.3	0.2	0.1	0.05	0.02	0.01	0.001
截断点 x	0	0.52	0.84	1.28	1.64	2.05	2.33	3.09
选择强度 i	0.80	1.16	1.40	1.75	2.06	2.42	2.67	3.37
$k = i(i - x)$	0.64	0.74	0.78	0.83	0.86	0.89	0.90	0.93

式(14.3)假定候选个体无限多。在有限群体中，选择强度要小一些：从 N 个个体中选出 n 个，其平均值是正态次序统计量中最大 n 个的期望之平均。从10个中选1个，期望选择强度为1.53，而按无限群体公式 ($p = 0.1$) 为1.75；从100个中选10个为1.73；从200个中选20个为1.74。候选群体在数十个以下时，修正不可忽略。伯罗斯(1972)给出了有限群体选择强度的近似公式。

把式(14.3)代入(14.1)，并注意 $h^2\sigma_P = h\sigma_A$ ，得到

$$R = ih^2\sigma_P = ih\sigma_A. \quad (14.4)$$

14.2.3 一般形式：强度、准确度、遗传变异与时间

在式(14.4)中， h 恰好是选择标准（个体表型）与育种值之间的相关 r_{AP} 。若选择不是依据个体自身表型，而是依据某个一般的选择标准 I ——例如后代测定成绩、选择指数、BLUP 估计育种值或基因组育种值——则只需把 h 换成**选择准确度** r_{AI} ，即选择标准与真实育种值之间的相关：

$$R = \frac{1}{2}(i_m r_m + i_f r_f)\sigma_A.$$

推导很直接：由第11章，后代育种值 $A_o = \frac{1}{2}A_s + \frac{1}{2}A_d + R_{A_s} + R_{A_d}$ ，孟德尔抽样项期望为零，因此后代平均育种值的改变等于被选父本与母本平均育种值改变的一半之和；而依据 I 截断选择使被选个体的平均育种值提高 $E(A | I \text{ 入选}) - \mu_A = b_{AI} S_I = r_{AI} \frac{\sigma_A}{\sigma_I} \cdot i\sigma_I = ir_{AI}\sigma_A$ 。

育种计划关心的是单位时间的进展。设世代间隔 L 为后代出生时亲本的平均年龄，则年遗传进展为

$$\Delta G_{\text{年}} = \frac{i_m r_m + i_f r_f}{L_m + L_f} \sigma_A. \quad (14.5)$$

式 (14.5) 是动物育种中最重要的公式之一，它把遗传进展分解为四个可以操控的因素：选择强度 i 、选择准确度 r 、加性遗传标准差 σ_A 与世代间隔 L 。几乎所有育种技术的价值都可以通过它们对这四个因素的影响来理解：人工授精与胚胎移植提高了选择强度；后裔测定、BLUP 与基因组选择提高了准确度；基因组选择还大幅缩短了世代间隔；引入新的遗传变异或保持遗传多样性则维持了 σ_A 。这四个因素之间常常相互制约：提高准确度的后裔测定延长了世代间隔，提高选择强度的少数优秀亲本加快了近交、降低了未来的 σ_A 。第 18 章将系统讨论这些权衡。

例 14.1 绵羊断奶重的年遗传进展

某绵羊群体断奶重遗传力 0.3，表型标准差 3.6 千克， $\sigma_A = \sqrt{0.3} \times 3.6 = 1.97$ 千克。公羊在 9 月龄按自身表型选择最好的 5%，母羊选择最好的 60%；妊娠期 5 个月，因此后代出生时亲本的年龄为 14 个月， $L_m = L_f = 1.17$ 年。查表得 $i_m = 2.06$ ， $i_f = 0.64$ ，准确度 $r = h = 0.548$ 。

$$\Delta G_{\text{年}} = \frac{2.06 + 0.64}{1.17 + 1.17} \times 0.548 \times 1.97 = 1.25 \text{ 千克/年}.$$

公羊的选择贡献了约四分之三的进展。若母羊也能更严格地选择，进展可进一步提高；但母羊的留种率受到群体更新需要的限制——必须留下足够的母羊来维持群体规模。

14.3 选择反应的遗传基础

14.3.1 等位基因频率的变化

选择改变群体均值，归根结底是因为它改变了影响性状的等位基因的频率。考察一个加性位点，基因型值为 $+a$ 、 0 、 $-a$ ，增效等位基因频率为 p 。在依据表型的截断选择下，被选个体中增效等位基因的频率提高。可以证明，

对效应较小的位点, 频率的变化近似为

$$\Delta p \approx i \frac{a}{\sigma_P} p(1-p). \quad (14.6)$$

推导思路如下: 个体携带增效等位基因的数目 x 与表型的协方差为 $\text{Cov}(x, P) = \text{Cov}(x, ax) = 2pqa$, 因此 x 对表型的回归系数为 $2pqa/\sigma_P^2$; 截断选择使被选个体的表型提高 $i\sigma_P$, 于是 x 的均值提高约 $i\sigma_P \cdot 2pqa/\sigma_P^2$, 等位基因频率提高其一半, 即 $ipqa/\sigma_P$ 。这与第4章的选择公式 $\Delta q = pq\alpha_w/\bar{w}$ 在形式上完全一致: 这里的“适合度”是被选中的概率, 它对等位基因的平均效应正比于 ia/σ_P 。

对效应很小的位点, 单代的频率变化非常小。例如遗传力 0.25、 $p = 0.5$ 、选择强度 1.4 时, 一个效应为 0.1 个表型标准差的位点, 频率每代只改变约 0.035。

14.3.2 小的频率变化如何累积成可观的反应

若频率的变化这么小, 选择怎样改变均值? 关键在于位点数目众多。加性位点对群体均值的贡献为 $a(2p-1)$, 频率改变 Δp 使均值改变 $2a\Delta p$ 。代入式 (14.6),

$$\Delta M_k \approx 2a_k \cdot i \frac{a_k}{\sigma_P} p_k q_k = \frac{i}{\sigma_P} \cdot 2p_k q_k a_k^2 = \frac{iV_{A_k}}{\sigma_P}.$$

对所有位点求和,

$$\Delta M = \sum_k \frac{iV_{A_k}}{\sigma_P} = \frac{iV_A}{\sigma_P} = ih^2\sigma_P. \quad (14.7)$$

这正是育种者方程。可见, **育种者方程预测的反应, 是许多位点上微小频率变化的总和**。每个位点对反应的贡献与其加性方差成正比。这一推导在位点层次上解释了为什么育种者方程只依赖于加性方差, 也为下面讨论的长期反应埋下伏笔: 频率变化虽然在单代中很小, 但会逐代累积, 最终改变加性方差本身。

14.4 选择对遗传方差的影响：Bulmer 效应

14.4.1 频率变化对方差的影响很小

既然选择改变等位基因频率，它也就改变每个位点的加性方差 $2p_kq_ka_k^2$ 。但在选择的最初几代，这种变化是微不足道的：方差的变化量与 $a^2\Delta p$ 同阶，而 a 很小， a^2 更小；加之有的位点频率向 0.5 靠近、方差增加，有的远离 0.5、方差减少，总体上相互抵消。因此，在短期内，由频率变化引起的加性方差改变可以忽略。

14.4.2 选择产生的负连锁不平衡

然而，实际的选择试验与模拟都显示，加性方差在选择开始后的一两代内就会明显下降。原因不是频率的改变，而是选择在位点之间制造了**负的连锁不平衡**。

考虑两个不连锁的加性位点，依据两位点基因型值之和进行截断选择。在选择前，两位点处于连锁平衡，其效应不相关。截断线是一条斜线：位点 1 上不太好的个体，只有在位点 2 上特别好时才能入选；反之亦然。于是在被选个体中，两个位点的效应呈负相关——一个位点上的优势“补偿”了另一个位点上的劣势。由第 10 章式 (10.6)，这种负的跨位点协方差使加性方差下降：

$$V_A = \text{Var}(A_1 + A_2) = \text{Var}(A_1) + \text{Var}(A_2) + 2\text{Cov}(A_1, A_2),$$

被选个体中 $\text{Cov}(A_1, A_2) < 0$ 。即使两个位点不连锁，选择也会在它们之间产生 LD；在许多位点上，这种由选择诱导的负 LD 累积起来，可以使加性方差显著下降。

14.4.3 被选个体中方差的缩减

在正态分布与截断选择下，被选个体的表型方差为

$$V_P^* = (1 - k)V_P, \quad k = i(i - x), \quad (14.8)$$

k 的数值见表 14.1，留种率为 5% 时 $k = 0.86$ ，即被选个体的表型方差

只有全体的 14%。由于育种值与表型的回归系数为 h^2 ，被选个体中育种值的方差为

$$V_A^* = (1 - kh^2)V_A. \quad (14.9)$$

这一结论来自多元正态分布的条件方差公式：在表型方差被缩减到 $(1 - k)V_P$ 时，与表型相关的育种值的方差按 $1 - kr_{AP}^2$ 的比例缩减。

14.4.4 Bulmer 递推

被选亲本的方差缩减并不完全传递给后代。孟德尔抽样项的方差不受亲本选择的影响，而由不连锁位点之间的 LD 每代通过重组减半。布尔默 (1971) 在“无限小模型”——无限多个效应无穷小的不连锁位点——下推导了加性方差的递推关系。把加性方差写成遗传方差（连锁平衡下的部分，在无限小模型中保持不变） $V_{A,0}$ 与不平衡协方差 d_t 之和： $V_{A,t} = V_{A,0} + d_t$ 。则

$$d_{t+1} = \frac{1}{2}d_t - \frac{1}{2}kh_t^2V_{A,t}, \quad (14.10)$$

其中 $h_t^2 = V_{A,t}/(V_{A,t} + V_E)$ 。第一项表示上一代的不平衡被重组减半，第二项表示本代选择新产生的不平衡（父母双方各贡献一半）。从 $d_0 = 0$ 开始迭代， d_t 迅速收敛到平衡值 $\hat{d}$ ，满足 $\hat{d} = -kh^2(\hat{d})V_A(\hat{d})$ 。

设基础群体遗传力 0.5、表型方差 200 ($V_A = 100$)，两性都选 5%。迭代得到 V_A 依次为 100、78.5、74.4、73.5、73.3，此后稳定在 73.3，平衡遗传力约 0.42（图 14.1B）。加性方差在两三代内下降了约 27%，选择反应相应减少约 21%（反应与 $h\sigma_A = V_A/\sigma_P$ 成正比）。由 200 个不连锁位点、有效群体约 33 的个体模拟得到的方差下降更快更持续：第 1 代下降约 18%，第 3 代下降约 33%。这既反映了 Bulmer 效应，也反映了有限群体中的漂变与频率变化，后者是无限小模型所忽略的。

Bulmer 效应有几个实际含义。其一，用基础群体参数预测多代选择反应会高估反应，应当使用平衡时的方差。其二，停止选择后，由 LD 造成的方差减少会在几代内恢复（不连锁位点的 d 每代减半），而由频率变化造成的减少则不会恢复。其三，选择越强、遗传力越高、准确度越高，Bulmer 效应越明显。基因组选择使选择准确度大幅提高，因而也加剧了 Bulmer 效应；




图 14.1 选择强度与 Bulmer 效应。A 图为截断选择的选择强度随留种率的变化；B 图为 Bulmer 递推给出的加性方差变化（遗传力 0.5，两性各选 5%），以及 200 个不连锁位点的个体模拟结果（按初始方差换算到同一尺度）

第 18 章将在“准确度内生变化时的 Bulmer 递推”中进一步讨论。其四，连锁位点之间由选择产生的 LD 衰减较慢，在紧密连锁的区域中，Bulmer 效应会持续更久。

14.5 选择反应的协方差表述

14.5.1 罗伯逊—普赖斯恒等式

育种者方程假定截断选择与正态分布。一个更一般、不依赖于分布与选择方式的表述来自罗伯逊 (1966) 与普赖斯 (1970)。设每个个体 j 有一个“相对适合度” w_j ，即其后代数相对于平均后代数的比值（被淘汰的个体 $w = 0$ ）。被选亲本的平均育种值为以 w 为权重的平均，其与全体平均之差为

$$\Delta \bar{A} = \frac{\sum_j w_j A_j}{\sum_j w_j} - \bar{A} = \frac{\text{Cov}(w, A)}{\bar{w}}. \quad (14.11)$$

选择反应等于相对适合度与育种值之间的协方差。这一“罗伯逊次级定理”是一个恒等式，不需要任何分布假设；它把选择反应归结为一个问题：适合度（无论来自人工选择还是自然选择）与育种值的相关有多大。在截断选择下， $\text{Cov}(w, A) = i r_{AI} \sigma_A$ ，回到育种者方程。在自然群体中，适合度的变异来自存活与繁殖的差异，式 (14.11) 可以用来理解自然选择对数量性状

的作用。普赖斯方程的完整形式还包括一个“传递偏差”项，反映后代与亲本之间育种值的系统差异，例如由突变或减数分裂驱动造成的差异。

14.5.2 选择梯度与多性状反应

兰德与阿诺德(1983)把这一思想推广到多个性状。设性状向量 $\mathbf{z}$ ，选择差向量 $\mathbf{s} = \text{Cov}(w, \mathbf{z})$ ，定义**选择梯度** $\boldsymbol{\beta} = \mathbf{P}^{-1}\mathbf{s}$ ，即相对适合度对各性状的偏回归系数， $\mathbf{P}$ 为表型协方差矩阵。在适当的线性条件下，多性状的选择反应为

$$\Delta \bar{\mathbf{z}} = \mathbf{G}\boldsymbol{\beta} = \mathbf{G}\mathbf{P}^{-1}\mathbf{s}, \quad (14.12)$$

$\mathbf{G}$ 为加性遗传协方差矩阵。这一**多元育种者方程**表明，一个性状的反应不仅取决于对它本身的选择，还取决于对其他性状的选择以及性状之间的遗传协方差。选择梯度区分了“直接作用于某性状的选择”与“由于相关性状受选择而产生的间接选择差”。在进化生物学中，式(14.12)被广泛用于测量自然选择；在育种中，它与多性状选择指数理论本质上相同(第16章)，只是视角不同：前者从已发生的选择推断其作用，后者设计选择以达到期望的反应。

若适合度与性状之间存在二次关系，例如中间表型适合度最高，则存在**稳定化选择**；反之，若两端都有利，则为**歧化选择**。二次选择梯度描述的是这类非线性选择，它们主要改变遗传方差与协方差，而不是均值。许多与适合度相关的性状在自然群体中受到稳定化选择，这是第4章讨论的突变—选择平衡在数量性状层次上的对应。

14.6 相关选择反应

对性状 X 选择时，与 X 遗传相关的性状 Y 也会发生变化，称为**相关选择反应**。由回归，被选个体在性状 Y 上的平均育种值改变为

$$CR_Y = b_{A_Y P_X} \cdot i\sigma_{P_X} = \frac{\text{Cov}(A_Y, P_X)}{\sigma_{P_X}^2} i\sigma_{P_X} = ih_X r_{A\sigma_{A_Y}} = ih_X h_Y r_{A\sigma_{P_Y}}. \quad (14.13)$$

相关反应依赖于遗传相关、两个性状的遗传力（或 h_X 与 σ_{A_Y} ）以及选择强度。比较对 X 选择引起的 Y 的相关反应与直接对 Y 选择的反应，

$$\frac{CR_Y}{R_Y} = \frac{i_X h_X r_A}{i_Y h_Y}. \quad (14.14)$$

若 $h_X r_A > h_Y$ ，间接选择比直接选择更有效。这种情形发生在：目标性状 Y 遗传力很低，而辅助性状 X 遗传力高且与之高度遗传相关；或者 Y 只能在一个性别、晚期或屠宰后测定，而 X 可以在候选个体本身早期测定（此时 i_X 与世代间隔都更有利）；或者 X 的测定比 Y 便宜得多。在肉质性状、疾病抗性与饲料效率的育种中，间接选择一直是重要的策略；而分子标记与基因组信息，可以看作一种遗传力为 1、在出生时即可测定的辅助“性状”（第 18 章、第 31 章）。

相关反应还是理解育种副作用的关键。长期对奶牛产奶量的高强度选择，伴随着繁殖力与健康性状的下降；对肉鸡生长速度的选择，伴随着腿病与代谢疾病的增加；对猪瘦肉率的选择，一度伴随着肉质与应激敏感性的问题。这些不利的相关反应，大多是可以由遗传相关事先预测的。现代育种目标因此普遍包含繁殖、健康与福利性状，以平衡生产性状的选择（第 16 章、第 32 章）。

14.7 选择反应的测定

14.7.1 世代均值与对照群体

选择反应最直接的度量是世代均值随世代的变化。但世代均值不仅受遗传改变影响，也受环境变化影响：饲料、气候、管理与测定方法的年度变化都会使均值波动，甚至产生趋势。区分遗传反应与环境变化的标准方法是设立**对照群体**：从同一基础群体中建立一个随机交配、不加选择的群体，与选择群体在同一环境中饲养测定。选择群体与对照群体均值之差，扣除了共同的环境变化。另一种做法是**双向选择**：同时进行向上与向下的选择，两个方向的均值之差约为单向反应的两倍，且环境变化相互抵消。冷冻精液或胚胎保存的基础群体遗传物质，也可以在后代中“复活”作为对照。

14.7.2 实际选择差与实现遗传力

选择差也需要实际测定。**期望选择差**是被选亲本平均表型与全体候选个体平均表型之差，分别对两性计算后平均。但被选亲本留下的后代数并不相同，有的亲本繁殖力高，有的低，有的甚至没有后代。以每个亲本实际测定的后代数为权重计算的选择差称为**有效选择差**。有效选择差与期望选择差之比反映了自然选择的作用：若繁殖力与被选性状正相关，比值大于 1，自然选择帮助了人工选择；若负相关，比值小于 1，自然选择与人工选择相互抵消。

由育种者方程， $h^2 = R/S$ 。在多代选择试验中，把累积反应对累积选择差回归，斜率即为**实现遗传力**。实现遗传力是对选择群体中实际有效遗传力的直接度量，它综合了 Bulmer 效应、选择差的实际变化等因素，比由亲属相似性估计的遗传力更能反映选择的实际效果。

例 14.2 一个十代选择试验的分析

从同一基础群体建立三个重复的选择系与三个重复的对照系，在同一环境中饲养。每个系每代用 5 头公畜与 10 头母畜随机交配，每头母畜产 5 个后代（雌雄各半），全部测定，因此每代 50 个个体。选择系按个体表型选择：25 个雄性中选 5 个（留种率 20%， $i_m = 1.40$ ），25 个雌性中选 10 个（40%， $i_f = 0.97$ ）。基础群体表型标准差为 10。表 14.2 列出了各系 0 至 10 代的世代均值。

表 14.2 选择试验的世代均值

世代	C1	C2	C3	S1	S2	S3
0	58.4	57.9	59.8	59.6	58.3	57.9
1	61.5	57.7	63.7	67.0	65.9	69.3
2	54.3	53.6	60.5	61.3	68.2	65.1
3	45.5	50.0	51.1	58.5	64.4	63.0
4	57.6	61.2	62.0	80.5	76.6	80.2

5	47.0	50.0	52.4	73.1	72.8	76.6
6	54.0	54.5	60.5	86.5	82.9	85.3
7	55.6	56.6	58.9	96.0	86.0	90.8
8	51.6	51.9	58.9	98.2	88.5	86.4
9	40.8	38.9	47.7	94.2	81.7	79.5
10	55.8	53.7	64.2	108.4	95.0	94.4

对照系均值在各代之间大幅波动（如第 3 代与第 9 代明显偏低），这些波动在选择系中同步出现，说明是环境造成的（图 14.2A）。以选择系与对照系平均值之差作为反应：第 1 代为 6.4（以三个重复作 t 检验， $t = 3.19$ ， $p = 0.033$ ），第 10 代为 41.4（ $t = 7.41$ ， $p = 0.0018$ ）。

每代的期望选择差为 $S = \frac{1}{2}(1.40 + 0.97) \times 10 = 11.8$ 。把第 t 代的选择—对照差对累积选择差 $11.8t$ 作过原点回归，得到实现遗传力 $\hat{h}_R^2 = 0.387$ ，标准误 0.008（图 14.2B）。注意这个标准误只反映了各代均值围绕回归线的离散，没有充分考虑各代之间因漂变而产生的相关，实际不确定性要大得多。

每个系的有效群体大小为 $N_e = 4 \times 5 \times 10/15 = 13.3$ ，每代近交增量 $\Delta F = 1/(8 \times 5) + 1/(8 \times 10) = 0.0375$ 。由下一小节的公式，第 10 代各重复系均值之间的期望方差约为 $100 \times (10 \times 0.387/13.3 + 1/50) = 31.0$ 。对照系第 10 代三个重复的观察方差为 30.9，与预期一致；选择系为 62.7，大于预期，提示各选择系之间存在额外的变异来源，例如有效群体大小因选择而小于 13.3，或者选择本身放大了漂变的影响。

14.7.3 选择反应的变异性

重复的选择系即使从同一基础群体出发、使用相同的选择强度，其反应也各不相同。第 t 代重复系均值之间的方差有两个来源。其一是**抽样方差**：以 M 个个体的平均表型估计世代均值的误差，约为 V_P/M 。其二是**漂变方差**：有限亲本数造成的等位基因频率随机变化，使各系的真实遗传均值逐渐




图 14.2 十代选择试验。A 图为三个重复选择系与三个重复对照系的世代均值；B 图为选择系与对照系均值之差对累积选择差的过原点回归，斜率为实现遗传力

分化，第 t 代约为 $2F_t V_A$ ， $F_t \approx t/(2N_e)$ 。于是

$$\text{Var}(\bar{P}_t) \approx V_P \left(\frac{th^2}{N_e} + \frac{1}{M} \right). \quad (14.15)$$

若以向上与向下两个方向之差度量反应，方差加倍。式 (14.15) 严格地说是在无选择时推导的，但只要用考虑了选择的有效群体大小，它在有选择时也是合理的近似。它对选择试验的设计有直接意义：要可靠地检测反应、比较不同处理，需要足够大的有效群体与足够多的重复系。仅有一个选择系与一个对照系的试验，即使反应看起来很大，也可能主要是漂变的结果。在育种实践中，式 (14.15) 提醒我们，小群体育种计划的实际进展具有相当的风险：预期进展只是许多可能结果的平均。

14.7.4 不对称的反应

育种者方程预测向上与向下选择的反应对称： $R_{\uparrow} = ih^2\sigma_P = -R_{\downarrow}$ 。但许多双向选择试验观察到不对称的反应，常见的原因有：随机漂变（只有通过重复系才能判断）；两个方向的选择差不同，例如自然选择帮助一个方向而阻碍另一个方向，或者选择改变了繁殖力；近交衰退，它使所有系的均值下降，表现为向上的反应小于向下的反应；遗传不对称，即增效等位基因的初始频率偏离 0.5，使一个方向的加性方差随选择增加而另一个方向减少，在存在大效应位点时尤为明显；以及尺度不对称，即遗传与环境变异的偏态方

向不同, 或存在尺度效应, 使遗传力在分布两端不同。若不对称来自选择差的差异, 按 $R/\sum S$ 估计的实现遗传力仍然对称; 其他原因则使实现遗传力本身不对称。在实践中, 往往难以确定哪种原因起主导作用。

14.8 长期选择反应与选择极限

14.8.1 育种者方程只适用于短期

$R = ih^2\sigma_p$ 严格地说只对一个世代成立, 对多个世代只是近似, 因为选择改变了等位基因频率, 从而改变了遗传方差 $V_A = \sum 2p_kq_k a_k^2$ 。长期反应依赖于影响性状的基因数目、效应大小与初始频率, 这些通常不知道, 因此长期反应本质上难以精确预测。但理论可以给出若干一般性的结论。

14.8.2 无突变时的选择极限

若没有新的突变, 所有位点最终会固定, 加性方差耗尽, 反应停止, 达到**选择极限**。罗伯逊 (1960) 在效应较小的加性位点、有限群体的条件下推导出两个著名的结果: 总反应的上限约为第一代反应的 $2N_e$ 倍; 反应的“半衰期”(达到总反应一半所需的世代数) 不超过 $1.4N_e$ 代。直观上, $2N_e$ 代表等位基因在漂变下平均能够“停留”的世代数: 在小群体中, 许多增效等位基因在选择能把它们带到固定之前就被漂变丢失, 因而极限较低; 在大群体中, 选择有更多时间作用, 极限较高。罗伯逊的理论表明, **选择极限取决于 $N_e i$ 的乘积**, 而不只取决于选择强度: 为了提高当前一代的反应而过度减少亲本数, 可能以牺牲长期极限为代价。

当位点效应较大时 ($N_e ia/\sigma_p$ 不小), 选择在漂变起作用之前就能把增效等位基因推向固定, 极限接近“所有增效等位基因都固定”时的最大可能值, 而达到极限的速度也较快。在一个 200 个不连锁位点、有效群体约 33 的模拟中 (八个重复的平均), 第一代反应约为 7.7 个单位, 按罗伯逊公式 $2N_e R_1$ 的极限约为 560, 但实际在 60 代内的总反应约为 143, 已经达到所有增效等位基因都固定时最大可能值 (约 160) 的 89%; 此时只有约五分之一的位点仍在分离, 加性方差降到初始值的 2% (图 14.3)。这是因为模拟中不少位点效应较大, 罗伯逊的小效应近似不再适用; 同时也说明, 即使在大效应的情

形下，漂变仍使约十分之一的潜在反应因增效等位基因丢失而永久损失。




图 14.3 有限位点与有限群体中的长期选择。实线为累积反应（以初始加性标准差为单位），虚线为加性方差相对于初始值的比例

14.8.3 突变与持续的反应

实际的长期选择试验很少观察到真正的极限。最著名的伊利诺伊玉米籽粒含油量与蛋白质含量选择试验始于 1896 年，经过一百多代选择，向上选择的系仍在持续反应，含油量与蛋白质含量已经远远超出了基础群体的变异范围。小鼠体重、果蝇刚毛数与肉鸡生长速度的长期选择也显示出持续的反应。持续反应的主要原因是**新突变**不断产生新的加性变异。每代由突变产生的加性方差 V_M 通常约为环境方差的千分之一，虽小，但在长期中不可忽视。在突变—选择—漂变的平衡下，希尔（1982）证明，渐近的年反应率约为

$$R_{\infty} \approx 2N_e \frac{iV_M}{\sigma_P}. \quad (14.16)$$

即渐近反应与有效群体大小成正比：较大的群体不仅能更好地保留原有的变异，也能更有效地利用新突变。新突变初始频率仅为 $1/2N$ ，大多数在稀有时被漂变丢失；选择强度越大、有效群体越大，有利突变被保留的机会越多（第 4 章式 (4.18)）。

14.8.4 选择平台

一些长期选择试验在若干代后出现反应停滞的“平台”，但这往往不是遗传变异耗尽的结果。可能的原因包括：自然选择与人工选择的对抗——被选性状的极端值降低了繁殖力或存活率，使有效选择差趋于零；与繁殖力的不利遗传相关；增效等位基因的纯合子不利（如某些大效应位点在纯合时致死）；以及近交衰退的累积。在平台期放松选择或停止选择，若均值回落，说明自然选择在起作用；若在平台期仍然存在可观的加性方差，说明平台并非遗传极限。

长期选择的理论对现代育种有重要启示：在追求短期最大反应的同时，必须管理有效群体大小与遗传多样性，保持长期改良的潜力。第 18 章的最优贡献选择正是为了在当前反应与长期多样性之间求得最优的平衡。

14.9 本章小结

育种者方程 $R = h^2S = ih^2\sigma_P$ 由亲子回归直接导出，选择强度 $i = z/p$ 由截断选择的正态理论给出，有限群体中需要修正。一般形式 $\Delta G = (i_m r_m + i_f r_f)\sigma_A / (L_m + L_f)$ 把年遗传进展分解为选择强度、准确度、遗传标准差与世代间隔四个因素。在位点层次上，选择反应是许多位点上微小频率变化之和，每个位点的贡献与其加性方差成正比。短期内频率变化对方差的影响很小，但选择在位点间诱导负的连锁不平衡，使加性方差在两三代内显著下降，即 Bulmer 效应；其平衡值可由递推关系求出。罗伯逊—普赖斯恒等式把反应表示为适合度与育种值的协方差，兰德—阿诺德的选择梯度把它推广到多性状。相关选择反应由遗传相关与两性状的遗传力决定，间接选择在目标性状遗传力低或难以测定时可能更有效，而不利的相关反应解释了许多育种副作用。实际反应需要用对照群体或双向选择测定，实现遗传力由累积反应对累积选择差回归得到；反应的变异来自抽样与漂变，不对称反应有多种可能原因。长期反应受频率改变与漂变的限制，罗伯逊理论给出了与 $N_e i$ 相关的选择极限，而新突变使长期选择试验很少达到真正的极限。

14.10 习题

习题 14.1 某性状遗传力 0.35, 表型标准差 20。公畜从 200 头候选中选 10 头, 母畜从 200 头中选 100 头, 均按自身表型选择。预测一代的选择反应。若用有限群体选择强度, 结果如何变化?

习题 14.2 由正态分布的截断理论, 证明被选个体的表型方差为 $(1 - k)V_P$, $k = i(i - x)$ 。

习题 14.3 按 Bulmer 递推 (式 (14.10)), 设基础遗传力 0.3、两性各选 10%, 迭代三代, 求每代的加性方差与遗传力。

习题 14.4 性状 X 遗传力 0.5, 性状 Y 遗传力 0.1, 遗传相关 0.6。若两性状可以同样强度选择, 对 X 的间接选择相对于对 Y 的直接选择效率如何? 若 X 可以在候选个体本身测定、Y 只能在同胞测定 (准确度 0.25), 结论如何?

习题 14.5 在例 14.2 中, 若每个系每代用 10 头公畜与 20 头母畜, 其余不变, 第 10 代重复系均值之间的期望方差为多少?

习题 14.6 某小群体 $N_e = 25$, 第一代选择反应为 2 个单位。按罗伯逊理论, 选择极限与半衰期上限约为多少? 若 N_e 增加到 100、第一代反应因选择强度降低而降为 1.6, 极限如何变化?

习题 14.7 某长期选择群体 $N_e = 50$, 每代由突变产生的加性方差为 $V_M = 0.001V_E$, $V_E = 100$, 表型标准差 12, 选择强度 1.5。估计渐近的每代反应。

14.11 习题解答

14.1 $i_m = i(0.05) = 2.06$, $i_f = i(0.5) = 0.80$, $R = \frac{1}{2}(2.06 + 0.80) \times 0.35 \times 20 = 10.0$ 。有限群体中从 200 选 10 约为 2.03, 从 200 选 100 约为 0.80, 反应约 9.9, 差别很小。

14.2 截断以上部分 $E(Z^2 | Z > x) = 1 + x\phi(x)/p = 1 + xi$, 于是 $\text{Var}(Z | Z > x) = 1 + xi - i^2 = 1 - i(i - x)$ 。

14.3 $p = 0.1$ 时 $k = 0.831$ 。设 $V_P = 100$, $V_A = 30$, $V_E = 70$ 。

$$d_1 = -\frac{1}{2} \times 0.831 \times 0.3 \times 30 = -3.74, V_A = 26.26, h^2 = 0.273; d_2 = -1.87 - \frac{1}{2} \times 0.831 \times 0.273 \times 26.26 = -4.85, V_A = 25.15, h^2 = 0.264; d_3 = -2.43 - \frac{1}{2} \times 0.831 \times 0.264 \times 25.15 = -5.19, V_A = 24.81, h^2 = 0.262。$$

14.4 $CR_Y/R_Y = h_X r_A / h_Y = 0.707 \times 0.6 / 0.316 = 1.34$, 间接选择更有效。若直接选择的准确度为 0.25 而非 $h_Y = 0.316$, 比值为 $0.424 / 0.25 = 1.70$ 。

14.5 $N_e = 4 \times 10 \times 20 / 30 = 26.7$, 期望方差 $100 \times (10 \times 0.387 / 26.7 + 1/50) = 16.5$ 。

14.6 极限约 $2 \times 25 \times 2 = 100$, 半衰期不超过 35 代。 $N_e = 100$ 时极限约 $2 \times 100 \times 1.6 = 320$ 。

14.7 $R_\infty \approx 2 \times 50 \times 1.5 \times 0.1 / 12 = 1.25$ 单位/代。

单性状选择指数与信息融合

15

15.1 从一条记录到一个可解释的预测

育种者面对的常常不是“有没有数据”，而是“哪些数据值得相信，应该相信多少”。一只青年种羊的自身生长记录、母亲的生产记录、同胞记录和基因组预测，可能同时指向它的遗传潜力；这些信息又彼此重叠。如果直接求平均，同一份家系信息可能被重复计算。如果只采用看起来最精确的一项，又可能丢掉其他信息中独有的部分。选择指数把这两个问题合并为一个问题：如何用可获得的记录，构造对目标育种值误差尽可能小的线性预测？

本章的目标只有一个性状，记候选个体的加性育种值为标量 u 。设记录向量 y 有 m 个元素，已减去适当的期望值； $P = \text{Var}(y)$ 是 $m \times m$ 表型协方差矩阵， $C = \text{Cov}(y, u)$ 是 $m \times 1$ 向量。这里的“记录”可以来自不同亲属、不同年龄或不同测定方法，不要求它们具有相同单位。指数写成

$$I = b'y = \sum_{j=1}^m b_j y_j. \quad (15.1)$$

所谓中心化，必须针对适当的比较群体。如果某一批羔羊比另一批多补饲一个月，直接减去全场均值仍不能消除系统性环境差异。简单指数通常假定期望值已知或已可靠校正；当场、年、季、性别等效应需要与育种值一起估计时，应转向后续章节的混合模型。将明显错误的校正值代入一个正确的指数方程，不会产生正确的遗传评定。

本章沿用经典教材从期望和协方差出发的路线，但所有例题数据均为本书构造的教学数据。它们用于说明计算，不是某个牧场的实测结果，也不代表某一品种的遗传参数。读者首先应练习把每个协方差说清楚，再使用矩阵

运算。一个无法解释的矩阵元素，往往比一个没有求出的方程更危险。

15.2 为什么最优权重满足指数方程

用均方预测误差衡量指数的好坏。在 $E(u) = 0$ 、 $E(y) = 0$ 条件下，展开平方即可得到

$$Q(b) = E[(u - b'y)^2] = \sigma_u^2 - 2b'C + b'Pb. \quad (15.2)$$

对 b 求导，令梯度为零，得到 $Pb = C$ 。若 P 正定， $Q(b)$ 严格凸，因此这个驻点就是唯一最小点：

$$b = P^{-1}C, \quad I = C'P^{-1}y. \quad (15.3)$$

实际计算应解线性方程 $Pb = C$ ，不必显式求逆。写成逆矩阵只是为了揭示代数关系。指数理论的关键并非“会求逆”，而是将记录之间的信息重叠写入 P ，将每条记录对目标的联系写入 C 。Smith (1936) 与 Hazel (1943) 的经典工作奠定了这一框架，Van Vleck (1993) 的教材进一步展示了如何从具体亲缘和记录结构构造方程。

把式 (15.3) 代回可得三个重要性质：

$$\text{Var}(I) = \text{Cov}(I, u) = C'P^{-1}C, \quad \text{MSE}(I) = \sigma_u^2 - C'P^{-1}C. \quad (15.4)$$

由于预测值与预测误差正交， $\text{Cov}(I, u - I) = 0$ 。这说明在线性空间内，预测误差已经不能再由现有记录的任何线性组合改进。若 u 与 y 联合正态， I 还等于条件期望 $E(u | y)$ ；若不满足正态，它仍是最佳线性预测，但不一定是所有可能预测函数中最好的一个。

准确度与可靠度应严格区分。对尺度校准正确的最优指数，

$$r_{u, \hat{u}} = \sqrt{\frac{C'P^{-1}C}{\sigma_u^2}}, \quad \text{Rel} = r_{u, \hat{u}}^2. \quad (15.5)$$

把 b 乘以正常数不改变候选个体的排序，也不改变相关意义上的准确度，却会改变指数的数值尺度。因此，“排序指数”与“以育种值单位报告的预测”

不是同一个要求。若要将指数解释为后代预期改良、构造区间或计算预测误差，必须保留正确的校准。对任意随手加权的分数，不能直接用 $\text{Var}(I)/\sigma_u^2$ 声称其可靠度。

15.3 例 15.1 自身记录与母亲记录怎样共同起作用

设某生长性状的表型方差为 100，加性遗传方差为 25；以同一性状自身记录和母亲记录预测候选个体育种值。忽略母体效应、共同环境和近交，母子间加性亲缘系数为 $1/2$ ，因此两条表型记录的协方差为 12.5。母亲表型与候选个体育种值的协方差也为 12.5，而自身表型与自身育种值的协方差为 25。于是

$$P = \begin{pmatrix} 100 & 12.5 \\ 12.5 & 100 \end{pmatrix}, \quad C = \begin{pmatrix} 25 \\ 12.5 \end{pmatrix}. \quad (15.6)$$

解方程得到 $b_1 = 0.238095$ 、 $b_2 = 0.095238$ 。若个体自身记录比适当比较群体均值高 8 个单位，母亲记录高 4 个单位，则

$$I = 0.238095 \times 8 + 0.095238 \times 4 = 2.285714. \quad (15.7)$$

这个预测不是两条离差的简单平均。自身记录对目标更直接，因此得到较大权重；母亲记录含有一部分独立信息，因此仍有正权重。同时，自身权重小于只使用自身记录时的遗传力 $25/100 = 0.25$ ，因为它与母亲记录携带的部分家系信息重叠。加入母亲记录后，原信息的权重略有下降，这是避免重复利用信息的正常结果。

该指数的预测方差为 7.142857，均方预测误差为 17.857143，可靠度为 0.285714，准确度为 0.534522。只使用自身记录时，准确度为 0.5。母亲记录带来的提高是真实的，但远不是“多一条记录，准确度加倍”。如果存在母体遗传效应或母子共同环境，式 (15.6) 的非对角元素需要重写；将所有相似性都视为直接加性遗传相似性，会高估家系记录的价值。

进一步可问：能否在重新求解整个指数之前，预先衡量一条新增记录的价值？设原有记录为 y_1 ，新增记录为标量 z ，记 $p = \text{Cov}(y_1, z)$ ， $v = \text{Var}(z)$ ，

$d = \text{Cov}(z, u)$ 。先从 z 中扣除可由旧记录线性预测的部分, 得残差信息 $z - p'P_1^{-1}y_1$ 。新增记录带来的预测方差增量为

$$\Delta \text{Var}(I) = \frac{(d - p'P_1^{-1}C_1)^2}{v - p'P_1^{-1}p}. \quad (15.8)$$

只要分母大于零, 这个增量不会为负。例 15.1 中增量为 0.892857, 恰等于 $7.142857 - 6.25$ 。分子衡量新增记录尚未被旧数据解释的目标信号, 分母衡量该记录尚未被旧数据解释的总变异。一个数据量很大的新平台, 如果新增的主要是重复信息, 仍可能只有很小的边际价值。

15.4 例 15.2 重复测定为什么存在收益上限

考虑同一个体的 n 次重复记录。每次表型方差均为 σ_p^2 , 任意两次记录的相关为重复力 t , 每次记录与育种值的协方差均为 σ_u^2 。在等方差、等相关条件下, 记录均值 $\bar{y}$ 已汇集全部线性信息, 其方差为

$$\text{Var}(\bar{y}) = \sigma_p^2 \frac{1 + (n-1)t}{n}, \quad I = \frac{nh^2}{1 + (n-1)t} \bar{y}, \quad h^2 = \frac{\sigma_u^2}{\sigma_p^2}. \quad (15.9)$$

取 $\sigma_p^2 = 100$ 、 $h^2 = 0.30$ 、 $t = 0.50$ 。一次记录的准确度为 0.547723; 四次记录均值的方差为 62.5, 指数权重为 0.48, 准确度为 0.692820; 二十次记录时准确度为 0.755929。记录从一次增加到四次很有价值, 从四次增加到二十次则要付出更高成本才能获得较小提高。

在 $t > 0$ 的条件下, 当 n 趋于无穷, 可靠度趋向 $h^2/t = 0.6$, 准确度趋向 0.774597。这个上限不是数学缺陷, 而是生物学信息结构的反映: 反复测量可以削弱暂时环境噪声, 却无法仅凭同一个体的记录把加性遗传效应与永久环境效应完全分开。要突破这一限制, 可能需要亲属数据、不同环境下的记录, 或者具有新增遗传信息的基因型。

不能将式 (15.9) 用于任意纵向数据。幼龄和成年体重的遗传相关未必等于一, 疾病进程可能改变方差, 选择性淘汰会使晚期记录缺失与个体潜力相关。此时应使用多性状或随机回归模型, 而不是把所有时点当作同一个性

状的等质量复测。连续传感器每秒提供记录，也不等于每秒增加一次独立测定；若忽略时间相关性，软件会给出十分精确、实际却过度自信的预测。




图 15.1 相关记录的信息增量与重复测定可靠度

图 15.1 左图为等相关记录的相对有效信息量 $n/[1+(n-1)\rho]$ ；右图为重复测定模型可靠度 $nh^2/[1+(n-1)t]$ 。右图三组参数分别为 $(h^2, t) = (0.1, 0.4), (0.3, 0.4), (0.6, 0.6)$ ，不同遗传力曲线并非保持相同重复力。两图是各自假设下的教学曲线，不是实测精度。

15.5 基因组时代的信息融合及其边界

现代育种的新增信息可以来自基因型、图像、活动轨迹、采食行为或代谢表型，但它们进入选择指数时仍必须回答两个旧问题：与目标有多少联系，与已有信息有多少重叠。数据名称带有“基因组”或“智能”并不自动保证信息独立。一个基因组预测若已使用候选个体亲属的表型，再与相同亲属形成的传统育种值简单相加，就可能重复计算证据。

已经校准的估计育种值也可以作为信息变量，但应使用它们实际的联合协方差和与目标的协方差。各候选个体可靠度不同、亲属资料重叠不同，意味着“每个来源一个固定权重”的简化可能不成立。单步基因组评定之所以重要，正是因为它能在统一模型中描述系谱、基因型和表型之间的依赖；这将在后续章节讨论。这里需要记住，信息融合的目标是增加独有信号，而非使来源清单更长。

从理论到应用还存在参数估计的距离。式 (15.3) 假定 P 和 C 已知；实际它们通常由有限样本估计。两个记录高度相关时，矩阵会接近奇异，微小的参数误差可能引起很大的正负权重。负权重本身并不表示性状有害，它可能承担扣除冗余环境信号的作用；但极端权重必须接受单位核对、条件数检查和独立验证。使用岭式稳定化或删除重复变量，应说明改变了什么预测问题，并重新校准结果。

另一个边界是“更多已知信息不降低理论最优准确度”不等于“更多估计变量必然提高外部预测”。前者是总体协方差已知时的投影性质，后者同时受到参数误差、分布变化和过拟合影响。教学计算应验证矩阵正定性，生产评定则还要验证跨家系、跨年度和跨环境的准确度及回归校准。只有把信息价值放到未来候选群体中检验，指数的精确数字才具有决策意义。

验证准确度时还要注意，真实育种值通常不可观察。预测值与随后表型的相关并不直接等于育种值准确度：后续表型包含环境噪声，可能与用于预测的数据共享环境，也可能受到选择性记录影响。在理想的独立环境、正确校正与同一性状条件下，才可借助遗传力进行相应转换。对去回归育种值、子代偏差等替代验证目标，也必须说明它们自身的误差和资料重叠。课堂中的已知育种值模拟适合检查公式，但不能替代现实数据中的外部验证。

一个实用的信息采集问题是：预算有限时，应给少数个体增加重复测定，还是给更多家系补充一次测定？前者主要降低个体暂时环境噪声，后者可能扩大群体覆盖并改善遗传联系。式 (15.8) 提供了边际信息价值的入口，最终决策仍应把测定费用、未来候选群分布和可提高的响应结合起来。记录设计与选择指数并不是先后分离的两个工作，它们可以相互反馈。

15.6 把指数理解为投影，而不只是加权平均

15.6.1 预测空间与没有利用的信息

为进一步理解指数的最优性，可以暂时不谈动物，把所有具有有限二阶矩、均值为零的随机变量看作一个几何空间中的元素。定义两个变量的内积为它们乘积的期望，则变量与自身的内积就是方差。记录向量的各个分量形

成若干方向，所有线性指数构成这些方向张成的空间。选择指数所做的是，把无法直接观察的育种值投影到这个可利用空间。投影长度反映被现有资料解释的遗传变异，垂直于资料空间的剩余部分则是预测误差。这个几何解释的价值在于，它把准确度不足解释为信息限制，而不单是某种算法计算不够精细。

最优指数的误差与每一条已有记录都不相关。令 $e_u = u - I$ ，则 $\text{Cov}(y, e_u) = C - Pb = 0$ 。如果某一条记录仍与误差相关，就可以沿着该记录方向稍微修正指数，减少均方误差，因而原预测不可能已经最优。注意这里的正交是随机变量之间的总体关系，并不表示在每个有限样本中预测误差与记录的样本相关都严格等于零。用同一批资料估计权重时，拟合残差的代数正交还可能是模型构造造成的，不能因此证明对未来动物也预测良好。

对于任意其他线性预测 $J = d'y$ ，把误差写成 $u - J = (u - I) + (I - J)$ ，由正交性得到

$$E[(u - J)^2] = E[(u - I)^2] + E[(I - J)^2].$$

第二项非负，因而证明 I 不会比任何其他线性组合差。这一证明不需要求导，也不需要正态分布。它同时表明所谓最优，是相对于指定目标、指定信息和指定总体分布的最优。若目标从直接育种值改为永久生产能力，或者未来候选群体与参数估计群体不同，投影方向也会改变。不同研究声称各自方法最优时，首先应核对这三个对象是否相同。

15.6.2 排名相同不代表预测同样正确

把指数乘以正常数确实不改变排序，但校准关系会改变。设正确指数为 I ，另一个软件发布 $J = 2I$ 。由于 $\text{Cov}(u, I) = \text{Var}(I)$ ，真实育种值对 J 的回归斜率为一半。这说明 J 的高低方向正确，却把个体间遗传差异夸大了。若根据这个分数估算引进种公畜后的后代优势，预测收益也会被夸大。选择名单相同只能说明两种分数用于该次截留时一致，不能说明它们可用于同样的经济解释、风险计算和跨群比较。

这一点还能用平方误差精确说明。记 $V_I = \text{Var}(I)$ ，对任意常数 k 有

$$E[(u - kI)^2] = \sigma_u^2 - V_I + (k - 1)^2 V_I.$$

当 $k = 1$ 时误差最小；即使相关系数始终不变，只要尺度偏离一，误差都会增加。在例 15.1 中， $V_I = 7.142857$ ，把正确指数加倍使均方误差从 17.857143 增至 25，已经丢失了在原尺度上减少平方误差的全部净优势。这个看似反直觉的结果提醒读者：相关只检查方向与相对起伏，均方误差同时检查偏差、尺度和噪声。

还有一种常见尺度变化是加上基准常数。若所有个体加同一个常数，排序不变，但预测的零点改变。跨年度发布育种值时，通常会选择一个固定出生群体或基础群作为零点。更新基准并不是遗传退步；然而，把不同基准的数值直接相减，会产生虚假的趋势。指数报告应同时给出计量单位、基础群和是否进行了标准化，使使用者知道一个差值究竟代表什么。

15.7 从生物学假设构造协方差矩阵

15.7.1 每一个矩阵元素都应有来源

构造指数时，最难的往往不是线性方程，而是描述数据如何产生。以两个个体的同一性状记录为例，若模型为 $y_j = u_j + c_j + e_j$ ，其中 c_j 是共同或永久环境部分，那么两条记录的协方差既可能来自亲缘，也可能来自共同饲养、共同母体或重复测量。将非对角元素全部写成亲缘系数乘以遗传方差，隐含了环境互不相关这一强假设。这个假设在来自不同独立场所的成年动物之间可能较合理，在同窝仔猪、同池鱼或同批孵化家禽中却需要格外谨慎。

正确的方法是先写出能够解释各记录的随机效应，再利用协方差双线性展开。例如，若两只同胞共享窝环境 c ，且窝环境方差为 σ_c^2 ，则它们记录协方差含有 σ_c^2 。但若目标仍是某一候选个体的直接加性育种值，这个窝环境通常不进入记录对目标的协方差。因此，共同环境可以增加记录彼此的相似性，却不增加其对遗传目标的独立信息。忽视这一差别，正是家系均值准确度被高估的重要来源。

同样的逻辑适用于母体作用。候选羔羊的断奶记录可能同时反映自身生长遗传潜力与母亲泌乳和照料能力。若当前目标只是直接生长育种值，母体遗传部分不是简单的环境噪声，因为它可能与直接遗传部分相关；若目标是未来作为母羊的综合价值，母体能力又可能成为目标的一部分。应先决定目标，再决定各协方差项。仅凭“断奶重”这个记录名称，不能自动确定一个适用于所有用途的指数。

15.7.2 协方差矩阵是否合法

各条相关系数单独位于负一与一之间，并不保证拼接后的矩阵合法。三个变量之间的相关必须能够同时存在。若任意线性组合都应有非负方差，那么协方差矩阵必须正半定。实际资料中，遗传相关可能分别来自不同研究和不同群体，将它们拼在一起时，可能出现一个方向上的负方差。此时没有真实随机变量能具有这组联合参数，继续求指数权重没有合理的概率解释。

不仅 P 要合法，记录与目标的联合协方差也必须合法。单性状目标下应检查

$$\Omega = \begin{pmatrix} P & C \\ C' & \sigma_u^2 \end{pmatrix}.$$

当 P 正定时，这一要求等价于 $\sigma_u^2 - C'P^{-1}C \geq 0$ 。也就是说，预测误差不能为负，可靠度不能超过一。如果算出准确度大于一，应先排查参数和矩阵构造，不应把它解释为预测能力突破了普通方法。对估计误差导致的轻微非正定，可以采用有依据的参数化或协方差平滑，但应说明调整幅度，并检验调整后决策是否敏感。

矩阵合法性并不是全部。一个完全正定的矩阵仍可能描述错误的生物学系统。举例说，把同窝环境遗漏后，得到的矩阵也可能正定；软件照样能够给出稳定结果，但遗传信息的解释已发生偏差。因此，数值检查与设计审查应分开进行。数值检查回答矩阵能否代表某个联合分布，设计审查回答它是否代表当前记录和育种目标。

单位检查是成本最低而经常最有效的一步。 P_{jk} 的单位应为第 j 条记录单位乘以第 k 条记录单位， C_j 的单位应为记录单位乘以育种值单位， b_j 则

把记录单位转换为目标单位。如果一项记录从克改为千克而协方差未同步改变,结果可能数值上仍然平滑,却毫无意义。任何生产评定系统都应把单位作为变量定义的一部分,而不能只写在表格标题里。

15.8 同胞信息:样本很多,独立遗传信息未必很多

15.8.1 家系均值为何不能无限精确

考虑用一个候选个体的 n 个全同胞记录预测它的加性育种值,候选个体本身没有记录。为便于推导,设所有全同胞表型方差为 σ_p^2 ,彼此具有相同表型相关 ρ ,每个同胞记录与目标育种值的协方差为 $k\sigma_u^2$ 。对于无近交、无显性混杂且目标为直接加性育种值的全同胞, $k = 1/2$; 表型相关 ρ 却可能同时包含共同环境和其他效应,不能自动取作 $h^2/2$ 。

在这种交换对称结构下,同胞均值 $\bar{y}_s$ 已汇集这些记录中的全部线性信息,其方差为 $\sigma_p^2 [1 + (n-1)\rho] / n$,对目标的协方差仍为 $k\sigma_u^2$ 。因此

$$I_s = \frac{nk h^2}{1 + (n-1)\rho} \bar{y}_s, \quad r_s^2 = \frac{nk^2 h^2}{1 + (n-1)\rho}.$$

公式中最值得注意的是,记录数量增加没有把目标协方差乘以 n 。均值包含更多同胞,却仍只是在观察候选个体的家系背景,而不是直接观察其独有的孟德尔抽样。即使家系均值测得极其准确,同一家系内的未测候选者仍可能具有相同预测,不能据此区分谁继承了更有利的基因组。

15.8.2 教学例:同窝环境怎样改变家系测定价值

设 $\sigma_p^2 = 100$ 、 $\sigma_u^2 = 30$, 候选个体有八个全同胞记录。同胞间加性协方差为十五;若还共享方差为十的窝环境,则同胞表型相关为 0.25。同胞均值的方差为 34.375,对目标的协方差为十五,指数系数为 0.436364,可靠度为 0.218182,准确度约为 0.467099。如果同胞均值高于适当基准五个单位,预测育种值为 2.181818。

若错误地忽略窝环境,就会把同胞相关写成 0.15,均值方差降为 25.625,计算出的可靠度变成 0.292683,准确度约为 0.541002。记录没有改变,所谓

精度提高完全来自过于乐观的模型假设。这种误差可能尤其影响家系规模大的候选者，使某些共同环境优越的家系在选择中占据不合理优势，进一步放大亲本贡献集中。

在含窝环境的正确模型中，当同胞数无限增加，可靠度极限为 $k^2h^2/\rho = 0.3$ ，准确度极限为 0.547723。增加到很多同胞仍无法消除家系共同环境和候选个体孟德尔抽样带来的限制。如果能够在不同窝、不同母体或不同场地分散同胞测定，改变的不只是样本数量，还包括协方差结构；其价值可能比在同一环境中增加更多记录更大。

这个思路可迁移到多种生产系统。家禽和猪的同窝、同批记录容易获得，水产育种中早期家系分养也可能产生强共同环境。将家系混养并通过分子标记恢复身份，可以改变家系效应与环境效应的混杂程度，但前提是身份恢复准确、混养管理可行，而且疾病传播等生产条件受到考虑。这里的统计原则是明确的：优良设计通过降低无关的共同变异，提高同样记录数量中的独有遗传信息；它并不是要求所有物种采用同一测定模式。

15.9 后代测定：通过下一代观察亲本

15.9.1 从遗传传递系数推导公畜指数

公畜某些目标性状只能在雌性后代或屠宰后代中测量，因此后代测定曾长期处于动物育种的中心位置。它不是一种与选择指数不同的统计原理，而是记录和目标之间的亲缘结构不同。设有 n 个后代，每个后代来自与公畜无关、彼此也无关的随机母畜，后代在相互独立的环境中测定，亲本无近交，性状只考虑加性遗传效应。在这些简化条件下，每个后代记录与公畜育种值的协方差是 $\sigma_u^2/2$ ，两个父系半同胞记录的协方差是 $\sigma_u^2/4$ 。

若后代表型方差为 σ_P^2 ，平均记录的方差可以分成一个不会随后代数消失的公畜共同成分，以及逐渐被平均掉的个体成分：

$$\text{Var}(\bar{y}_o) = \frac{\sigma_u^2}{4} + \frac{\sigma_P^2 - \sigma_u^2/4}{n}.$$

用后代均值预测公畜育种值时，最优权重和可靠度分别为

$$b_o = \frac{2nh^2}{4 + (n-1)h^2}, \quad r_o^2 = \frac{nh^2}{4 + (n-1)h^2}.$$

当后代数很大时，权重趋向二而不是一，因为后代平均只接受父方一半加性遗传贡献。将后代偏差直接当作公畜完整育种值，会在数值尺度上少一半；反过来，把已经报告为育种值的评定结果再乘以二，则会多一倍。不同评定体系使用育种值、传递能力或后代差等术语，应用前必须核对其定义。

15.9.2 教学例：后代数量的边际收益

设遗传力为 0.30。十个独立后代时，公畜可靠度为 0.447761，指数系数为 0.895522；四十个独立后代时，可靠度为 0.764331，指数系数为 1.528662。如果十个后代的平均校正离差为三，预测公畜育种值为 2.686567。随着资料增加，指数对同样大小的后代均值更加信任，也更接近把完整的父方遗传差异恢复到原尺度。

这里不能机械地认为四十个后代一定比十个后代更值得等待。若获得后四十个后代需要额外数年，延长世代间隔可能抵消准确度收益；如果公畜已被大量使用，得到更精确的评定也未必还能改变已经发生的配种。因此，后代资料的价值取决于它到达的时间和能够影响的未来决策。遗传评定精度与育种计划效率之间，必须通过实际使用时间连接起来。

后代数量还应区分名义数量和有效数量。若多个后代由同一母畜产生，或共同生活于同一栏舍，它们之间除父方遗传联系外还有额外联系。若所有后代只在一个管理优越的场中出现，公畜效应与场效应也可能难以分离。把这些后代当作相互独立的随机母本后代，会过度估计精度。有效的后代测定设计通常需要跨母系、跨管理单元的连接，而不只是追求一个较大的后代头数。

对屠宰性状，后代测定还涉及不能同时保留测定个体繁殖的特点；对产乳性状，则涉及性别限制和较长的表达时间。对抗病性状，后代记录可能来自自然暴露而暴露风险不均等。不同畜种和性状的这些差异，都会改变可用记录与目标的协方差及记录到达时间。指数方程形式可以相同，生物学假设

却必须逐项重建。

15.10 不等质量重复记录：为什么不能总用算术平均

15.10.1 均值充分利用信息需要对称条件

前面的重复测定公式建立在每次记录等方差、等相关、与目标协方差相同的结构上。这种对称性使每次记录获得相同权重，因此只保留算术平均不会损失线性信息。现实中，同一动物在不同年龄、不同设备或不同健康状态下的记录，可能具有不同测量误差。如果某一次测定质量明显较差，简单平均等于强迫它与优质记录具有相同作用，通常不是最优选择。

考虑两次记录都测量同一个体的长期水平，写为 $y_1 = u + p + e_1$ 、 $y_2 = u + p + e_2$ 。其中加性方差为四，永久环境方差为六，第一次残差方差为十，第二次残差方差为四十，残差彼此独立。于是两次记录方差分别为二十和五十，协方差为十，记录对育种值的协方差都为四。这个例子把“长期共同成分”与“每次测定质量”分开，便于观察不等质量如何影响权重。

15.10.2 教学例：低质量复测应占多少权重

本例指数方程为

$$\begin{pmatrix} 20 & 10 \\ 10 & 50 \end{pmatrix} \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} 4 \\ 4 \end{pmatrix}.$$

解得 $b_1 = 0.177778$ 、 $b_2 = 0.044444$ ，第一次记录的权重是第二次的四倍。如果记录离差分别为六和九，预测育种值为 1.466667。第二次记录虽然数值更高，但噪声也更大，因此不能仅因偏差更大就给予更大影响。联合指数的可靠度为 0.222222，而只用第一次记录的可靠度为 0.2。新增低质量记录确实提供了一点信息，但贡献有限。

若强制先取算术平均，两次记录均值的方差为 22.5，与育种值的协方差为四，所得可靠度只有 0.177778。这甚至低于只保留第一次记录。它并不与“增加记录不会降低理论最优准确度”矛盾，因为强制平均限制了允许使用的线性组合；一旦压缩成均值，原始记录的质量差异就无法恢复。正确保存

原始记录和质量标识，比事后寻找更复杂的算法更重要。

在生产实践中，设备校准、采样时间、样品降解和人工操作可能导致异方差。可以将经过验证的质量信息写入残差方差模型，而不是任意给记录打一个主观分数。质量标签本身也可能存在误差；若低质量标记恰好更常出现于生病或极端表现动物，删除这些记录还可能改变目标群体。处理测量质量时，应同时检查精度问题和选择性缺失问题。

15.10.3 时间相关并不等于永久环境

当记录密集分布在时间轴上，相邻测量可能共享短期波动，例如同一次疾病过程、同一天温度或同一设备漂移。永久环境表示跨全部重复的持续个体差异，短期序列相关则随时间距离变化。把二者全部塞进一个等相关参数，可能误判长期信息上限。简单近似适合教学和初步分析，正式模型则应根据记录间隔与生物过程决定是否引入时间相关残差或随机回归。

同时，不能仅因时间曲线平滑就断定记录质量高。一个持续偏高的传感器可以产生非常平滑的错误曲线。多设备交叉校准、人工抽查和独立测量对识别系统误差有直接价值，而增加同一设备的采样频率未必有帮助。选择指数中的协方差结构应反映误差产生机制；否则，密集数据会使错误的均值看起来更加可信。

15.11 传统评定与基因组信息如何融合

15.11.1 两个预测并不等于两份独立证据

设同一只候选种畜有传统预测和基因组预测。最直观的做法是按各自可靠度加权平均，但这一做法只有在非常特定的误差结构下才成立。传统预测可能使用亲本和同胞记录，基因组参考群也可能使用这些亲属的表型，两种预测因此共享信息。更进一步，基因组预测往往以父母平均为一部分背景，并不是与家系信息完全无关的新测定。忽略这种重叠，既可能夸大可靠度，也可能使同一方向的家系误差被重复放大。

一种清楚的教学模型是把两个来源写成带测量误差的育种值观测 $z_1 =$

$u + \epsilon_1$ 、 $z_2 = u + \epsilon_2$ 。这与已经收缩的正式估计育种值不同，但便于展示误差相关的后果。若 $\sigma_u^2 = 1$ ，两种误差方差都为一，误差彼此独立，则 P 的对角为二、非对角为一， $C = (1, 1)'$ 。最优权重均为三分之一，可靠度为三分之二，而不是把两项单独可靠度二分之一相加得到一。

若两种误差的协方差为 0.8，记录之间的非对角协方差变为 1.8。最优权重均为 $1/3.8 = 0.263158$ ，联合可靠度为 0.526316。与单一来源的 0.5 相比，增加第二来源只提高少量信息。两个系统给出很相似的分值，既可能因为它们都抓住真实遗传信号，也可能因为它们共享同一组资料和同一类错误；仅看二者相关很高，不能判断是哪一种情况。

15.11.2 已收缩预测的再次组合

正式评定结果通常已包含先验、关系结构和收缩。若把它们当成 u 加独立噪声而再次套用上述公式，可能产生二次收缩或尺度错误。一个已经校准的最佳线性预测满足预测值与预测误差正交，但它并不满足预测值等于真实育种值加一个与真实育种值独立的噪声。这两种误差分解方向不同，混淆它们会改变应当使用的协方差。

如果能够获得两个预测值与目标的联合协方差，可以直接把预测值视为记录，重新构造指数；如果只能得到可靠度，则还需要关于共同信息和误差协方差的额外假设。资料重叠复杂时，统一分析原始表型、系谱和基因型，通常比在结果层面手工拼接更容易保持概率结构一致。单步方法的意义之一就在于让这些信息在同一模型中流动，而不是在最终名单上把几个分数相加。

现实系统有时无法交换原始资料，只能交换评定结果。这时可以采用经过推导的结果组合或去回归办法，但必须保留基准、尺度、可靠度、资料截止时间和已使用信息的范围。去回归不是简单把预测除以可靠度；还可能涉及亲本贡献、误差相关和有效记录贡献。对于可靠度极低的个体，任何逆收缩都可能放大噪声，应设定清楚的适用条件。

最新模型的评定报告尤其应避免“融合后准确度必然提高”这种未经检验的承诺。理论上已知联合协方差的最优融合不降低信息，但在有限样本中估计这些协方差本身就有误差。应在未参与融合权重训练的未来出生群体

中，同时检查预测相关、回归校准与排序稳定性，并比较统一模型、单一来源和融合模型的实际表现。

15.12 负权重、共线性与稳定化

15.12.1 负权重可以是一种校正

看到一条记录获得负权重，育种者常会问：是不是该性状越低越好？这个问题把记录的预测作用与目标的生物学价值混在一起。在单性状指数中，目标已经固定为某个育种值。记录权重可能为负，是因为在其他记录给定后，这条记录提供了反方向的剩余信息，也可能是因为它帮助扣除另一条记录中的共同环境噪声。只有目标中的经济权重才直接表达性状改变的价值方向。

构造一个标准化教学例，令目标遗传方差为一，两条记录的协方差矩阵为

$$P = \begin{pmatrix} 2 & 1.5 \\ 1.5 & 2 \end{pmatrix}, \quad C = \begin{pmatrix} 1 \\ 0.2 \end{pmatrix}.$$

第一条记录对目标联系较强，第二条记录对目标联系较弱，但两条记录彼此高度相关。解得 $b_1 = 0.971429$ 、 $b_2 = -0.628571$ 。当两条记录离差都为 1 时，指数为 0.342857。第二条记录的高值提示第一条记录的一部分高值可能来自两者共有而与目标关系较弱的成分，因此在联合预测中起扣除作用。本例预测方差为 0.845714，可靠度也为该值，联合协方差合法。

用偏回归的语言可以看得更清楚。先用第一条记录预测第二条，再看第二条残差与目标的协方差。本例这一剩余协方差为 $0.2 - (1.5/2) \times 1 = -0.55$ ，所以新增记录的最优系数必然为负。单看 $\text{Cov}(y_2, u) > 0$ ，无法判断其联合权重的符号；决定符号的是控制已有信息后的剩余联系。这也是为什么不能凭经验强迫所有记录权重非负，除非这种约束本来就是决策设计的一部分。

15.12.2 什么时候负权重应引起警惕

负权重具有合理解释，不意味着任何负权重都可信。当两条记录几乎完全相同时，矩阵沿着它们差值方向的方差很小。若估计的目标协方差略有差

别，求解器可能用很大的正负系数利用这个差值。数学上它是在寻找一个看似噪声很小的信号方向，实际中这个方向可能主要由抽样误差、不同批次校准或单位舍入造成。最终指数在训练数据上表现很好，换一批设备或一个年度便剧烈失效。

因此，应同时检查记录相关结构、矩阵条件数、权重对参数扰动的敏感性，以及单条记录的原始定义。简单地按权重绝对值删除变量并不可靠，因为权重大小受单位影响。可以先将记录转换到标准化尺度，再考察特征方向和剩余信号；也可以在独立验证中比较删除冗余记录、协方差收缩和岭式稳定化的效果。每种方案都改变了允许使用的信息或参数估计方式，应透明报告。

一种常见稳定化写为 $b_\lambda = (P + \lambda D)^{-1}C$ ，其中 D 是指定尺度的正定矩阵， λ 控制惩罚强度。如果直接取单位矩阵，而各记录单位相差很大，惩罚会对不同变量产生不等价影响；因此需要先明确标准化或采用与记录尺度相容的 D 。稳定化后 $\text{Cov}(I, u)$ 不再必然等于 $\text{Var}(I)$ ，准确度应按一般相关公式计算，并在需要时重新校准分数。

在实际育种服务中，稳定可解释的轻度近似有时比参数敏感的名义最优方案更有价值。但这种取舍应由外部预测和决策损失支持，而不是因为大权重“看起来不舒服”。最优性的数学结论与参数估计的可靠性是两个层次；识别这两个层次，有助于避免在盲目信任复杂模型与凭直觉弃用统计方法之间摇摆。

Cerón-Rojas 等 (2026) 进一步研究了 Smith 指数系数估计的抽样性质，在联合多元正态等设定下讨论最大似然估计及其不确定性。其意义是提醒使用者：总体协方差已知时的最优系数，与有限资料下估计出来的系数是不同对象。把估计矩阵代入指数方程以后，仍需要评价参数误差对外部预测和选择响应的影响，不能仅凭形式相同就宣称获得了总体最优表现。

15.13 缺失记录、不平衡与选择性测定

15.13.1 不同个体可以具有不同指数

传统教材常让所有候选个体拥有同样数量的记录，便于用同一个权重向量计算。实际群体中，有的个体有自身记录，有的只有亲本信息，有的已有少量后代。若对缺失项简单填零，就相当于假定这些记录恰好等于已知群体期望，并把不存在的信息也计入精度。正确做法是针对实际可用记录提取相应的协方差子矩阵与目标协方差，或使用能够自动处理不平衡信息的混合模型。

这意味着两个个体即使指数数值相同，也可能具有不同可靠度。一个个体的分数来自大量独立后代记录，另一个来自较少亲属资料；对风险中性的当前线性目标，校准后的预测均值可以直接比较，但对后代收益区间、最优贡献和进一步测定价值，误差差异很重要。报告应将预测均值和可靠度并列，而不是用可靠度作为一个未经推导的乘数，再把预测育种值随意折减一次。

缺失并不总是随机发生。体弱动物可能更早淘汰，生长过慢动物可能不进入性能测定，昂贵基因分型可能优先用于外观优秀的候选者。于是拥有完整记录的动物不能代表初始候选群。若评定模型没有保留使其进入测定的预选信息，可能出现选择偏差。把缺失记录看作纯粹的技术问题，会忽略真正改变样本分布的育种流程。

15.13.2 缺失机制需要与生产流程对照

判断缺失是否会造成偏差，不能只检查缺失比例高不高。关键是，在模型已有信息给定后，是否还存在与未观察记录或目标遗传值有关的缺失原因。如果优先给父母平均较高的青年公畜做基因分型，而完整保留父母平均和选择流程，在适当模型下可能处理这种条件选择；如果只保留最终优秀个体而丢失其预选依据，补救就困难得多。模型名称本身不能弥补关键历史信息缺失。

可以从记录生成日志入手，区分未达到测定年龄、设备故障、样品失败、提前淘汰和主动不测。不同原因对应不同概率机制。对设备随机故障造成的

缺失，主要关注有效信息减少；对疾病和死亡导致的缺失，则需要考虑它们与目标性状的共同遗传基础。必要时可将生存或测定进入状态纳入联合模型，但复杂模型能否识别仍取决于数据设计，不能仅凭多加一个随机效应就宣称问题解决。

教学中可以用一个简化思考实验说明这一点。设只给自身表现超过某门槛的个体测定昂贵性状，随后用这批个体估计两性状相关。由于选择压缩了第一性状的变异，样本协方差与总体协方差一般不同。如果把它直接代回针对全部候选群的指数，权重会偏离目标群体需要。即使测定技术完全准确，选择样本仍可能使遗传参数解释失真。

15.13.3 连接性比记录总数更接近问题核心

不平衡不仅表现为记录数量不同，也表现为不同场群之间是否有共同遗传联系。两个场分别饲养完全不同的家系，场均值差异就难以与家系均值差异区分。为每个场增加许多同一家系的记录，未必解决这一问题；安排共同参考公畜或其他合理连接设计，可能更有效。此时一个记录的价值取决于它在整体信息网络中的位置，而不是仅取决于测定精度。

选择指数的小型公式可以帮助理解局部信息，但大规模不平衡评定通常需要混合模型统一估计环境与遗传效应。两者之间的衔接并不是从简单方法换成完全不同的思想，而是把原先假定已知的环境校正、不平衡记录和亲缘连接显式写进模型。掌握指数之后再学习混合模型，能够清楚看见新增复杂性究竟解决了哪一种现实限制。

15.14 信息的经济价值：什么时候值得再测一次

15.14.1 精度收益必须通过未来决策兑现

一个测定方案把准确度提高若干百分点，并不能单独说明它值得投资。信息只有改变有价值的决策时，才产生经济收益。如果某只种公畜已经完成全部计划配种，再增加记录只能改善历史描述，未必改变未来收益；如果另一只青年公畜正处于是否大量使用的边界，同样的精度增量可能十分有价

值。信息采集应与留种、淘汰和配种决策的时间表一起设计。

在一个简化的候选群层面比较中，假定选择强度和遗传标准差不变，准确度从 r_0 提高到 r_1 ，则选中亲本平均育种值的预期增加为 $i\sigma_u(r_1 - r_0)$ 。若只改变父方选择，随机母方保持不变，后代平均遗传优势只获得其一半。这个二分之一因子不是统计收缩，而是遗传传递；成本收益计算若漏掉它，会把单方选择收益高估一倍。

构造一个完全教学性的预算例： $i = 1.4$ 、 $\sigma_u = 5$ ，准确度由 0.50 增至 0.65。选中父方平均育种值增加 1.05，后代平均增加 0.525 个单位。若未来两百只后代各单位改良带来五个约定价值单位，总毛收益为 525。若新增测定总成本为六百，则在这个单代、无贴现、无额外收益的简化范围内，净收益为负七十五。准确度确实提高了，但这个使用规模不足以支付测定费用。

若同一遗传优势会传递至后续世代，或有更多后代实际表达收益，信息价值可能更高；若提高准确度需要推迟使用，收益又会因时间和较长世代间隔下降。因此，上述算例不是完整商业估值，而是说明为什么必须把准确度、遗传传递、表达数量和成本放在同一个计算中。所有金额均为教学设定，不代表现实价格或投资回报。

15.14.2 个体层面的信息价值与排序不确定性

在候选个体层面，更严格的信息价值定义是：获得新记录之后最优决策的期望价值，减去未获得新记录时最优决策的价值，再减测定成本。这里先在每一种可能的新数据下重新决策，再对新数据求期望，通常不同于仅用平均准确度增量计算。一个预测明显高于所有竞争者的个体，新增记录可能只在极少数情形改变使用；一个接近选择门槛的个体，则更可能因新信息改变命运。

这并不意味着只给门槛附近个体测定就总是最优。参考群建设还有群体覆盖、长期模型更新和估计遗传参数的价值，不能完全由当前一轮入选名单衡量。对稀有家系或代表性不足的环境进行测定，短期可能很少改变当前前十名，却能改善未来跨家系、跨环境预测。短期决策价值和长期基础信息价值应分别列出，再按育种计划目标权衡。

15.14.3 测定分配的机会成本

预算固定时，给一只动物增加复测，意味着少给另一只动物或另一个家系采集信息。可以比较各方案新增的独有目标协方差、剩余记录方差和费用，而不能只比较单项测定单价。昂贵的深度测定如果针对关键参考个体，可能对许多未来候选者产生影响；便宜但高度重复的记录，单位成本虽低，总体增益却有限。

实际分配还受实验条件约束。例如代谢室、采食设备或屠宰测定有固定容量，同一天测量的个体可能共享批次误差。预算模型应同时决定测准、测多少次和如何分批，避免把高价值家系全部放在一个无法与其他批次连接的测定单元。记录设计的统计效率、设备利用率与动物管理条件需要共同讨论，不能在各自最优后简单拼接。

15.15 验证：从理论准确度走向可用证据

15.15.1 为什么表型相关不是准确度本身

真实育种值通常不可直接观察，因此实际验证必须使用带误差的替代目标。若未来校正表型为 $y_f = u + e_f$ ，并且未来残差与预测指数独立，则

$$\text{Corr}(I, y_f) = r_{u,I} \sqrt{h_f^2}.$$

因此，准确度为 0.70 的预测，在未来表型遗传力为 0.25 时，预测与表型的相关只有 0.35。较低的表型相关不一定表示遗传预测很差，而较高的表型相关也可能来自共享环境。使用遗传力进行校正之前，必须检查独立残差、相同性状和相同目标群体等条件；若验证表型本身经过选择或校正误差很大，简单相除也不一定得到正确准确度。

后代均值、去回归育种值和部分资料评定都可作为验证目标，但它们各自包含误差和资料重叠。若验证目标使用了训练模型已经使用的亲属信息，相关会受到共同信息影响。一个高质量验证设计首先要画清资料流向：哪些记录用于模型拟合，哪些用于超参数选择，哪些只在最后评价时出现。只写“进行了交叉验证”不足以证明没有信息泄漏。

15.15.2 验证切分应对应实际使用场景

随机把同一家系的动物分到训练集和验证集，可能很好地评价有近亲资料时的插值能力，但不能自动代表预测全新家系或未来世代的能力。如果育种任务是预测下一出生年度，就应保留时间顺序；如果任务是推广到新的场区或管理环境，还应进行相应的场区或环境外推验证。不同切分回答不同问题，没有一种切分方案能同时证明所有使用场景。

验证中也应区分排序和校准。相关系数描述共同变化，真实或替代目标对预测的回归斜率检查尺度，平均差检查基准偏差。对于留种决策，还可以比较接近实际选择比例时的入选重叠和后代预期表现，但这些指标对样本数量和门槛很敏感。尤其当只挑选极少数公畜时，一个偶然高估个体可能显著影响平均收益，不能只报告全体候选者的整体相关。

15.15.3 不确定性也要接受验证

可靠度或预测误差方差是模型对自身不确定性的描述。若模型参数被当作已知，它们可能没有包含方差分量估计和模型选择的不确定性。验证时可以观察预测区间的覆盖、不同可靠度组的实际误差，以及误差是否随家系、年度或环境系统变化。但真实育种值不可见时，区间检验还需要考虑验证目标自身噪声，不能直接把表型落在育种值区间之外当作预测失败。

对于青年动物，随后资料增加提供了评定更新的机会。应检查初期预测与后期资料评定之间的平均变化和回归关系，同时承认两次评定并不独立。资料越完整的后评定通常更接近目标，却仍不是无误差真值。一个透明的验证报告会把这些限制与结果一起说明，使读者知道证据支持的是当前模型内的一致性，还是更强的外部预测能力。

验证还可以反过来指导信息采集。如果误差集中在某些家系，可能需要增加遗传覆盖；如果误差集中在特定饲养环境，可能需要环境交互建模或跨环境记录；如果整体排序良好但尺度膨胀，则重点可能是校准与参数估计。把验证仅当作发表论文前的一张结果表，会错过其对育种系统持续改进的价值。

15.16 选择指数、回归与混合模型之间的联系

15.16.1 同一个线性预测问题的不同入口

从代数上看,指数方程与多元回归正规方程具有相同形状。但普通监督回归通常假定训练样本中能够观察响应变量,选择指数的目标育种值却不可直接观察。因此,指数中的记录对目标协方差往往来自数量遗传模型与亲缘关系,而不是直接计算表型对真实育种值的样本协方差。这一差别解释了为什么动物育种不能把一般回归软件的输出不加处理地当作遗传评定。

如果训练响应是个体表型,回归模型学到的可能同时包含遗传信号和环境结构。即使未来表型预测很好,也不自动意味着模型能够预测可传递给后代的部分。只有明确分解哪些变异属于遗传目标、哪些属于系统环境和残差,才可以把结果用于遗传选择。基因型输入可以帮助识别遗传关联,但若基因型与场群、品种或管理条件混杂,模型仍可能利用环境替代信号。

混合模型把环境效应和遗传随机效应共同写入观察方程,利用关系矩阵描述个体间遗传共享。若固定效应已知,且协方差参数给定,最佳线性预测可以写成目标与全部记录的协方差乘以记录协方差逆矩阵,再乘以校正记录。这正是选择指数的总体形式。因此,学习混合模型并不是抛弃指数理论,而是把指数推广到未知环境均值、不平衡记录和大规模亲缘结构中。

当固定效应需要估计时,预测误差还包含这一步的不确定性。把从少量同期记录估计出的环境均值当作完全已知,会使精度看起来过高。若家系和场群缺乏连接,环境与遗传差异甚至可能难以区分。这说明在小型手算例中省略环境估计是为了突出信息结构,而不是意味着生产应用可以忽视环境校正。

15.16.2 非线性预测的改进来自哪里

选择指数在所有线性组合中最优,并不排除非线性方法进一步改进。如果目标对记录的条件期望明显非线性,例如类别性状、混合群体或复杂基因型组合,线性投影可能留下可利用的结构。然而,一个非线性算法在训练样本中拟合更好,并不能说明它捕捉到了可遗传且可推广的关系。额外灵活性

既可能描述真实生物学，也可能拟合噪声和数据收集方式。

可以把非线性方法理解为先从原始记录构造一组特征，再对这些特征进行预测。若特征包括平方、交互或局部模式，其协方差结构与原始记录不同，目标联系也需要重新估计。原始数据量相同并不表示有效参数量相同；高维特征可能需要更强正则化和更严格验证。指数的投影思想仍然有用，因为它提醒我们检查新增特征是否提供了超出现有信息的独有信号。

对于基因组预测，非加性特征的预测价值还要与可传递性区分。显性效应可以改善某个配种组合后代表现的预测，但个体的显性偏差不会像加性育种值那样完整、稳定地传递。若用总遗传值模型直接给种畜排序，而目标实际是长期加性改良，就需要说明目标转换。一个模型可以对商品动物表现很有用，却未必是选择核心群亲本的最佳评分。

15.16.3 简单方法为何仍有教学和生产价值

小型指数能够逐项解释记录作用，适合检查复杂软件的方向与尺度。假如一个大型模型声称加入完全重复的资料后可靠度显著上升，简单指数的冗余信息性质就提示应检查资料重复利用；假如同一记录换单位后排序变化，单位变换不变性就提供明确诊断。这种基准不要求小模型完全替代复杂模型，而是用已知答案的小问题约束实现错误。

生产系统还需要可维护性。一个稍复杂但输入定义清楚、资料流向可追溯的模型，通常比一个依赖许多未经验证特征的模型更容易持续运行。每次数据升级应说明新增了什么信息、改变了什么协方差假设、产生了何种外部验证证据。把模型改进解释为这些具体变化，有助于育种者理解评定更新，也使后续研究可以累积，而不是每次都从新的算法名称重新开始。

15.17 综合案例：青年种羊的三来源评定

15.17.1 定义资料与目标

下面将本章几种思想放入同一个完整算例。假设一个教学群体需要预测青年种羊某生长性状的直接加性育种值。资料包括自身校正记录、母亲同一

性状记录，以及一个已转换到目标单位的独立测量型遗传信号。第三项仅为教学构造的 $z = u + \epsilon$ ，误差方差为二十五，且误差与前两项记录独立；它不代表现实中已收缩的正式基因组育种值，也不能直接据此处理任何商业产品。

仍取遗传方差二十五、自身和母亲记录方差各一百，母子加性协方差为十二点五。第三项方差为五十，与自身记录的协方差为二十五，与母亲记录的协方差为十二点五。于是

$$P = \begin{pmatrix} 100 & 12.5 & 25 \\ 12.5 & 100 & 12.5 \\ 25 & 12.5 & 50 \end{pmatrix}, \quad C = \begin{pmatrix} 25 \\ 12.5 \\ 25 \end{pmatrix}.$$

这个矩阵的构造比直接写出三个经验权重更重要。它说明第三来源与前两来源并非总体上独立，因为它们共享真实遗传信号；独立的是第三来源的额外测量误差。把“误差独立”误写成“记录协方差为零”，会把共同遗传信号也删除，得到另一个错误问题。

15.17.2 求解、解释和排序变化

实际求解得到 $b = (0.138889, 0.055556, 0.416667)'$ ，可靠度为 0.583333，准确度为 0.763763，均方预测误差为 10.416667。相比只使用自身与母亲记录，前两项权重均下降，因为第三项已解释了更多共同遗传信号；与此同时，整体准确度上升。旧权重下降并不表示旧记录失去生物学价值，而是说明在新信息给定后，它们剩余的独有贡献变小。

考察四只候选羊，其三项记录如下。

候选羊	自身离差	母亲离差	独立遗传信号	三来源指数
甲	8	4	3	2.583333
乙	5	8	5	3.222222
丙	10	0	1	1.805556

候选羊	自身离差	母亲离差	独立遗传信号	三来源指数
丁	2	2	7	3.305556

若只看前两项，分数依次为 2.285714、1.952381、2.380952、0.666667，排名为丙、甲、乙、丁。加入第三来源后，排名变为丁、乙、甲、丙。这个变化显示，外观或自身表现一般的个体可能具有较好遗传潜力，而高表现个体也可能主要受益于环境。它并不说明新增来源永远比表型更可信，而是当前设定的协方差结构赋予它较高独有信息价值。

15.17.3 从排名到实际使用仍有距离

在这个例子中四只动物具有相同信息结构，因此可靠度相同。如果丁的第三项来自高质量测量，而乙的第三项噪声更大，就需要分别构造记录协方差，不能沿用同一个权重。即使预测均值不同，也要考虑差值的不确定性；若候选者有亲缘，差值误差还受到预测误差协方差影响。仅用两只动物各自标准误平方相加，可能高估或低估二者差异的不确定性。

如果计划只留一只公畜，点预测排序在风险中性线性目标下具有直接意义；如果计划配种大量母羊，则还要考虑公畜之间的亲缘、繁殖上限和长期遗传多样性。把排名第一的个体无限量使用，可能在短期提高预测均值，却提高后续群体关系和近交风险。这些因素将在最优贡献章节中处理。当前指数负责提供遗传信息，不应被要求独自解决全部繁殖决策。

在实施前，还应把参数扰动作为一次压力检验。若第三来源误差方差增加，或它与已有资料共享额外误差，其边际价值会下降，前两项权重会相应恢复。一个使用者应能够回答：排名改变来自什么新增证据，哪些假设使这份证据可信，以及什么情况下排名可能改变。可解释性不是要求每个复杂模型都只有三个参数，而是要求关键决策能够追溯到资料和假设。

这样的核对能够发现符号、单位或算术错误，却不能把教学参数变成真实生产证据。若用于一个实际肉羊群体，需要重新估计协方差、评估母体与共同环境、核实第三来源定义，并在独立候选群体中检验校准。

15.17.4 将一个正确算例变成可复核的评定流程

一个能够复算的评定文件至少需要同时保存记录定义、环境校正规则、参数版本、候选个体资料截止时间和输出尺度。只保存最后一列分数，未来很难判断排序变化是因为新增记录、单位转换、基础群变化，还是算法调整。对相同输入和相同参数，确定性的指数程序应重复得到同一结果；如果不能，应先检查数据排序、缺失编码和数值精度，再讨论生物学原因。

计算顺序也应清楚。首先按照候选者实际可用资料建立记录向量；其次核对协方差矩阵的维度、对称性和联合合法性；然后求解线性方程，计算分数与预测误差；最后进行排序和决策解释。每一步都可以输出少量足以复查的诊断量，例如方程残差、最小特征值与权重尺度。诊断不是为了制造冗长日志，而是为了在结果异常时定位错误发生在哪个层次。

候选名单还应与输入身份保持稳定连接。亲本编号、出生日期或样本编号发生一次错位，可能使所有矩阵元素仍然合法，数值结果也看似合理，却预测了错误个体。应通过独立身份核对、亲缘一致性和抽样复查保证记录连接正确。统计程序不能从一个内部完全一致但身份错配的数据表中自动恢复真实动物。

在发布前，可以选取若干代表性候选者进行人工复算：信息很少者、记录较齐全者、预测极端者以及排序变化较大者。复算应追问权重变化是否符合信息来源，而不是仅核对软件是否再次输出同一数字。如果增加一条重复记录后预测均值大幅反向变化，应检查该记录是提供了真实的新证据，还是因协方差估计不稳定导致。对资料质量存在疑问的个体，可以暂缓高强度使用并优先核实，而不必把所有不确定性都转化为全群统一降权。

这种流程将教材中的方程与实际育种责任连接起来。可靠的遗传评定既依赖正确数学，也依赖记录管理、版本保存和可解释的使用规则。它们共同决定指数能否在连续多个年度保持一致含义，并为后续混合模型和基因组方法提供可信的输入基础。

15.18 成组新增记录的创新分解与信息归属

单条新记录的增益公式揭示了信息重叠，但实际采购或测定常以一组记录为单位。例如一次代谢测定同时得到采食量、体重变化和呼吸指标，一次亲属补测又可能增加来自多个家系的记录。逐条孤立估价后相加，会遗漏新记录之间的依赖。本节把问题写成分块形式，并区分总体上新增多少信息与应把收益归属于哪个来源。这两个问题相近，却没有同一个唯一答案。

设旧记录为 m 维向量 y ，新记录为 k 维向量 z ，目标仍为标量育种值 u 。所有变量已按同一基础群中心化，协方差视为已知。定义 $Q = \text{Cov}(y, z)$ 、 $R = \text{Var}(z)$ 、 $D = \text{Cov}(z, u)$ ，其中 Q 为 $m \times k$ ， D 为 $k \times 1$ 。在 $P = \text{Var}(y)$ 正定时，先进行不涉及目标的记录变换：

$$z^* = z - Q'P^{-1}y, \quad \text{Cov}(y, z^*) = 0.$$

$$S = \text{Var}(z^*) = R - Q'P^{-1}Q, \quad d = \text{Cov}(z^*, u) = D - Q'P^{-1}C.$$

S 是新记录在旧记录之外的剩余协方差，即相应的 Schur 补。注意，剩余记录不是把每条新记录减去自己的均值，而是扣除旧资料能够共同预测的部分。它可以包含正值、负值和相关结构。由于旧空间与剩余空间正交，均方误差的最小化可以分别进行，从而得到

$$\hat{u}_{new} = C'P^{-1}y + d'S^{-1}z^*, \quad V_{new} = V_0 - d'S^{-1}d,$$

其中 $V_0 = \sigma_u^2 - C'P^{-1}C$ 为旧预测误差方差。这个表达不仅少解一个大方程，而且把更新解释为“旧预测加创新”。把第二项重新展开，原记录系数也会改变：

$$b_y = P^{-1}C - P^{-1}QS^{-1}d, \quad b_z = S^{-1}d.$$

因此，新记录进入后旧权重下降，不等于旧记录的质量下降；旧权重是在补偿新记录已携带的那部分旧信号。若省略这一步，仅把新记录的得分加到原指数上，通常破坏校准与预测误差计算。

看一个可以完整手算的例子。令 $P = 4$ 、 $C = 2$ 、 $\sigma_u^2 = 6$ ，新旧记录协方

差 $Q = (1, 2)$ ；设剩余矩阵和剩余目标协方差为

$$S = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}, \quad d = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad S^{-1}d = \begin{pmatrix} 0.2 \\ 0.6 \end{pmatrix}.$$

由定义反推 R 的两行分别为 $(2.25, 1.5)$ 和 $(1.5, 4)$, $D = (1.5, 3)'$ 。旧误差为 5，成组新增信息减少误差 1.4，新误差为 3.6。当 $y = 2$ 、 $z = (1, 3)'$ 时，旧预测为 1，创新为 $(0.5, 2)'$ ，更新量为 1.3，新预测为 2.3。也可用最终系数 $(0.15, 0.2, 0.6)$ 直接验证。完整联合协方差合法，因为旧记录与创新已正交，且最终剩余目标方差仍为正。

现在只加入第一项创新，增益为 $1^2/2 = 0.5$ ；只加入第二项，增益为 $2^2/3 = 4/3$ 。两项孤立增益相加为 $11/6$ ，超过真正的成组增益 1.4。先加第一项，再加第二项，第二步增加 0.9；顺序反过来，第一项最后只增加 $1/15$ 。总增益不随顺序改变，单项“贡献”却改变。这不是计算不稳定，而是共享信息没有天然唯一的所有者。若管理上必须分摊联合收益，可以明确约定对两种顺序取平均；这里两项分摊分别为 $17/60$ 与 $67/60$ ，两者相加仍为 1.4。这样的分摊是会计约定，不应称为性状本身固有的信息量。

当 S 奇异时，一些新记录仍彼此完全重复。可以删除冗余方向，或在 d 位于 S 列空间的条件下用广义逆。若 d 含有 S 零空间中的非零分量，就意味着一个方差为零的随机变量却与目标协方差非零，联合参数不可能成立。故不能把非常小的分母一概解释为高价值信息；它也可能在提醒我们，记录重复、参数拼接或精度舍入已经造成矛盾。

这种分解尤其适合审查共享资料的预测产品。供应方若只说明“新增若干万条数据”，无法回答剩余目标信号 d 有多大。更有用的说明是：新增记录在已有亲属、环境和基因组资料之外保留什么差异，哪些误差仍然共享，以及联合协方差如何得到验证。这里讨论的是已知参数下的信息容量；有限样本中估计一个大的 S 本身也需要资料，不能把总体增益无条件当作实际外部收益。

15.19 把测定次数写入精度矩阵的采样设计

分块指数回答给定记录怎样使用，采样设计则反过来问记录应怎样产生。要使后一个问题可计算，可以先规定有限维遗传状态向量 g ，再把每一类测定看成对它的一个线性观察。虽然 g 可以包含多个家系或多个遗传分量，本节最终目标仍是单一育种值 $u = \ell'g$ ；引入向量只为明确每次测定究竟观察哪个方向。

假定 g 先验均值为零，协方差 V_g 正定。第 j 类测定的一次记录为 $x_j'g + e_j$ ，独立残差方差为 $r_j > 0$ 。若该类重复 n_j 次且残差确实独立，则平方误差项累加，在正态模型下得到后验精度与目标误差

$$J(n) = V_g^{-1} + \sum_j \frac{n_j}{r_j} x_j x_j', \quad Q(n) = \ell' J(n)^{-1} \ell.$$

这也可作为只依赖二阶矩的线性预测误差公式。与直接把“次数”填入可靠度公式相比， x_j 说明了信息方向：两种测定即使单次误差相同，也可能分别观察目标的重要方向和几乎无关的方向。信息矩阵累加的前提是给定 g 之后残差独立；共享批次误差不能通过虚增 n_j 来消除。

暂把次数放松为连续变量，令 $v = J^{-1}\ell$ 。对恒等式 $JJ^{-1} = I$ 求导，得到

$$\frac{\partial J^{-1}}{\partial n_j} = -J^{-1} \frac{x_j x_j'}{r_j} J^{-1}, \quad \frac{\partial Q}{\partial n_j} = -\frac{(x_j' v)^2}{r_j}.$$

这里的平方表明，信息沿正方向或负方向联系目标都可降低误差。绝对相关的方向比记录本身数值正负重要。若测定单价为 c_j ，总预算为 B ，内点最优分配满足

$$\sum_j c_j n_j = B, \quad \frac{(x_j' v)^2}{r_j c_j} = \lambda \quad (n_j > 0).$$

每一个实际投入的方向，其最后一个预算单位带来的误差降低应相同。若某类测定从零开始的边际收益都低于这个水平，它就暂不应进入方案。这个条件不是要求各类记录数量相等，而是要求边际价值经过误差、目标方向和费用共同调整后相等。

数值例中, 设两个独立遗传分量方差分别为 4 与 1, 目标 $u = g_1 + 2g_2$, 两类测定分别直接观察对应分量, 单次残差方差为 4 与 1。于是

$$Q(n_1, n_2) = \frac{4}{1+n_1} + \frac{4}{1+n_2}.$$

两类单价相同、总共六次时, 最优连续与整数设计均为各三次, 目标误差为 2。若全测第一类, 误差为 $4/7 + 4 = 32/7$ 。第一分量自身方差更大, 并不意味着它应独占预算; 第二分量在目标中的系数为二, 使两者对目标初始不确定性的贡献相同。初始目标方差为 8, 均衡设计可靠度为 0.75, 集中设计只有 $3/7$ 。

若第二类价格变为第一类的四倍, 预算仍为六, 则条件给出 $1+n_1 = 2(1+n_2)$, 与预算联立得到 $n_1 = 8/3$ 、 $n_2 = 5/6$, 误差为 $36/11$ 。真实次数必须取整数; 可行的 $(2, 1)$ 方案误差为 $10/3$, 而 $(6, 0)$ 仍为 $32/7$ 。连续解提供了搜索位置和理想下界, 却不是可以直接下达的测定计划。取整后应重新计算预算与误差, 不能仅把两项分别四舍五入后假定仍然最优。

如果已经安排某次标量测定, 其残差方差为 r , 方向为 x , Sherman-Morrison 更新给出更直接的单步收益:

$$(J + xx'/r)^{-1} = J^{-1} - \frac{J^{-1}xx'J^{-1}}{r + x'J^{-1}x},$$

$$Q_{old} - Q_{new} = \frac{(\ell'J^{-1}x)^2}{r + x'J^{-1}x}.$$

这说明每追加一次测定, 都应使用更新后的误差结构评价下一次。一次性按初始边际收益排序, 可能持续给已被测得很清楚的方向投入。另一方面, 逐次贪心也不普遍保证全局最优: 设备启动费、必须成组进行的测定以及不同测定间的互补关系都可能使目标不具有简单的递减收益结构。小规模问题可枚举整数设计, 大规模问题可在连续解附近优化, 但应把实施限制保留在最终评价中。

设计还应针对未来使用群体, 而非只针对今天恰好拥有记录的动物。若目标是未来许多候选者, 可用加权误差和替代单一 Q , 但权重必须来自预期使用范围。为一个稀有家系增加记录, 可能对当前平均误差帮助有限, 却对

保持未来遗传覆盖十分重要。这是目标选择的差别，不能靠一个默认的平均可靠度指标自动解决。

多目标资料建设中，常把“整体不确定性减少”当作不言自明的标准，其实误差总和、误差体积与某个关键育种值的误差并不等价。若未来目标向量为 Lg ，权重矩阵为 W ，一种可解释的损失是各目标平方误差的加权和：

$$Q_W(n) = \text{tr}\{WLJ(n)^{-1}L'\}.$$

它逐项指定谁的预测误差需要付出代价。若权重随未来使用频率确定，则常用父系或大规模扩繁家系会获得较高权重；若公共项目要求各家系平等覆盖，则可采用不同权重。后一种规则未必最大化眼前利润，却能准确表达项目的覆盖目标。应先公开这一选择，再比较设计优劣，而不是在看到结果后改变平均方法。

另一种标准是最小化后验协方差行列式，等价于缩小联合误差椭球的体积。在联合正态且目标维度固定时，它还与熵的减少相联系。对于标量目标，旧误差方差为 V_0 、新误差方差为 V_1 ，条件互信息为

$$\mathcal{I}(u; z | y) = \frac{1}{2} \log \frac{V_0}{V_1}.$$

这个量没有育种值的单位，适合描述相对不确定性减少，却不能自动代替经济收益。例如误差从一百降至五十，与从一降至零点五具有相同互信息；若目标单位与每单位损失相同，前者减少的平方误差却大一百倍。将信息论指标直接当作利润排序依据，需要额外说明损失函数与使用规模。

更具体地，设两种方案得到对角误差矩阵 $\text{diag}(0.1, 4)$ 与 $\text{diag}(1, 1)$ 。第一方案的误差体积更小，因为行列式为零点四而不是一；第二方案的误差总和更小，因为二小于四点一。若关键目标只是第二分量，第二方案同样更好。三个判断都符合各自定义，冲突来自目标不同，而非某种方法计算错了。对于必须保持最低精度的育种计划，还可对每个目标设置误差上界，再在可行范围内优化费用。这样的约束能防止平均指标很好、某个重要家系却长期没有足够信息的情况。

在本节两个独立方向的预算例中，若给第二目标设置误差上限，连续最优分配可能不再满足所有方向边际收益相等；落在精度边界的方向由约束决定。由此可见，边际等价条件是内部自由调整的结果，不能在存在最低样本数、精度底线或设备配额时生搬硬套。把科学目标、损失单位和实际约束写清楚，才是信息设计最重要的起点。




图 15.2 成组信息共享与测定预算配置。左图对应 15.18 的协方差算例，成组信息的收益不能用两项孤立收益相加；右图对应 15.19 中两类同价测定，总共六次，目标误差在各三次时达到最小值

15.20 未知批次效应如何改变测定的有效信息

上一节把均值校正当作已知。若一组新记录全部来自同一台仪器或同一测定批次，则批次水平需要估计，此时部分表面信息必须用于区分环境与遗传。为了看清这一损失，设新测定模型为 $z = X\gamma + Zg + e$ ，其中 γ 为未知固定效应， g 具有给定协方差 V_g ， $\text{Var}(e) = R$ 。假定 g, e 均值为零且互不相关，预测须对任意固定的 γ 保持无偏。这里 X, Z 分别说明批次与遗传状态如何进入每一条记录。

把加权平方误差对 γ 最小化，得到消去固定效应后的残差精度算子

$$M_R = R^{-1} - R^{-1}X(X'R^{-1}X)^{-1}X'R^{-1}.$$

$$J_g = V_g^{-1} + Z'M_R Z, \quad \text{PEV}_g = J_g^{-1}.$$

这里的 PEV_g 是已知方差参数时最佳线性无偏预测的误差协方差, 并未给未知固定效应指定概率分布。若设计存在冗余固定效应, 应在可估计空间内使用广义逆; 这里暂定相关逆存在。 $M_R X = 0$ 意味着与未知批次完全相同的记录方向不能提供遗传识别。原本看似可增加的 $Z'R^{-1}Z$ 中, 必须扣去一块用于估计固定效应的信息。相应的正半定差为

$$Z'R^{-1}Z - Z'M_R Z = Z'R^{-1}X(X'R^{-1}X)^{-1}X'R^{-1}Z.$$

这个差不是简单等于固定效应的个数, 也不能用把记录头数统一减一来充分描述; 它取决于遗传方向与批次方向的重合程度。一个批次内全部是同一家系, 损失可能集中在家系均值方向; 批次内包含多个共同参考家系, 则家系间对照能够保留。

考虑两个无关个体, 遗传方差均为一, 每个只有一条记录, 残差方差均为一, 且两条记录共享一个未知批次均值。此时 $Z = I$ 、 $X = (1, 1)'$, 从而

$$M_R = \frac{1}{2} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}, \quad PEV_g = \begin{pmatrix} 0.75 & 0.25 \\ 0.25 & 0.75 \end{pmatrix}.$$

若目标是两者差值, 初始方差为 2, 记录差的方差为 4, 预测为 $(z_1 - z_2)/2$, 误差降至 1。若目标是两者平均, 初始方差为 0.5, 更新后仍为 0.5: 未知批次使共同遗传平均无法从这两条记录中识别。资料对排名有价值, 却对绝对水平没有新增信息。因此“新增记录提高了准确度”必须补充究竟提高了哪个线性函数的准确度。

引入一个已知标准的校准记录, 可以恢复被批次占用的方向。设校准读数为 $z_0 = \gamma + e_0$, 其残差方差为 r_0 , 并假定 e_0 均值为零, 与 g 及原记录误差 e 不相关。将原记录减去 z_0 后, 批次被消去, 但两条校正记录共享误差 $-e_0$ 。不能把它们当作独立。对两者平均, 等效观测噪声方差是 $0.5 + r_0$, 所以

$$PEV_{\bar{g}} = \left\{ 2 + \frac{1}{0.5 + r_0} \right\}^{-1}.$$

若 $r_0 = 0.5$, 误差由 0.5 降至 $1/3$; 若校准近乎无误差, 极限为 0.25。即使批次完全已知, 两个个体自身残差仍然存在, 校准不会使育种值完全准确。

差值方向则不受共同校准误差影响，所以该校准对差值预测并无额外帮助。校准的投资价值取决于目标是跨批次水平比较、群体趋势，还是同批次内部排序。

这个例子还解释了为什么某些便宜的参考记录可能比昂贵的重复个体记录更重要。重复同一批次内部的测定，主要压低个体残差；跨批次共享参考动物或稳定标准，则提供原来缺失的连接。前者和后者不能仅以单次记录误差大小比较。设计时可以先计算各目标方向的误差，再决定资金用于高精度设备还是连接性样本。

现实中的标准样品未必具有完全已知的长期水平，参考动物本身也有育种值不确定性和年龄变化。此时应把标准的不确定性纳入随机效应，重新构造联合协方差。若直接宣布某只参考动物“没有误差”，其信息会被过度传递给所有批次。连接设计能够减少混杂，却不能免除对参考对象稳定性、测量协议和身份一致性的核实。

15.21 从误差减少到两候选者的精确信息价值

误差减少衡量预测质量，购买信息还要看它能否改变行动。考虑只保留甲、乙之一的决策，使用同一线性经济尺度，以 H_A 和 H_B 分别表示甲、乙的真实目标值，令差值为 $D = H_A - H_B$ 。当前资料记为 $\mathcal{F}$ ，假定 $D | \mathcal{F}$ 服从均值 m 、方差 v 的正态分布。以乙为相对基准，立即选择的最大期望优势为 $\max(m, 0)$ ；没有理由把 D 真实实现为正的的概率直接当作期望收益。

拟采购记录 $W = D + \epsilon$ ，独立误差方差为 s 。这是特定教学测量模型，不等同于把已经收缩的育种值再测一次。正态更新给出

$$m_W = m + \frac{v}{v+s}(W - m), \quad v_W = \frac{vs}{v+s}.$$

在尚未看到 W 时，未来后验均值 m_W 本身也随机，其均值仍为 m ，方差为

$$\tau^2 = \text{Var}(m_W | \mathcal{F}) = \frac{v^2}{v+s} = v - v_W.$$

这里出现一个容易误读的现象：更好的新信息使未来预测均值的分散程度增大，同时使预测误差减小。原来被收缩在相近分数的候选者会被资料区

分开来,这不是模型变得不稳定。均值在潜在数据之间的变化,正是未来可以改变选择的来源。

令 ϕ 、 Φ 分别为标准正态密度和分布函数。对 $\max(m_W, 0)$ 积分可得

$$E\{\max(m_W, 0) \mid \mathcal{F}\} = \tau\phi(m/\tau) + m\Phi(m/\tau).$$

$$EVSI = \tau\phi(m/\tau) + m\Phi(m/\tau) - \max(m, 0).$$

$EVSI$ 为尚未扣除测定费的样本信息期望价值。当 $\tau = 0$ 时按连续极限取零。推导可从正态密度上半轴积分开始: 将积分变量写为 $m + \tau z$, 常数项给出 $m\Phi(m/\tau)$, 而 $z\phi(z)$ 的积分给出 $\tau\phi(m/\tau)$ 。它是逐种可能数据重新选择后求平均, 不是把预测误差减少直接乘以一个任意价格。

教学例取 $m = 0.5$ 、 $v = 4$ 、 $s = 4$, 则 $v_W = 2$ 、 $\tau = \sqrt{2}$, 信息价值约为 0.3491 个目标价值单位。若每个单位的亲本差异会通过已核定的遗传传递和实际表达规模转为一千个收益单位, 毛价值约为 349.1; 若新增测定费为 400, 则该范围内不应采购。如果这些传递因素尚未计算, 不能直接给出商业投资结论。

保持 v 与 s 不变, 把当前均值差改为零, 信息价值变为 $1/\sqrt{\pi} \approx 0.5642$; 均值差改为三时, 信息价值只有约 0.0086。同样减少两个单位的预测误差, 对接近选择边界的比较最有用。这里必须注意, 比较的方差 v 已经包含甲乙之间的预测误差协方差: 若两者误差高度正相关, 差值可能比各自标准误所暗示的更清楚, 盲目补测会高估价值。

完美信息的价值是把 s 降到零, 即以 $\sqrt{v}$ 代替 τ 。由此可给任何实际测定的费用设置一个理论上限。若某方案声称毛价值超过同一决策范围下的完美信息价值, 应检查是否混入了额外后代规模、不同目标或重复收益。对于三个以上候选者, 相关后验均值的最大值通常不再有这么简洁的公式, 但仍可依据同一“先更新、再行动、最后平均”的顺序数值计算。

该结果只处理线性收益和两候选者的当前选择。若存在配种上限、多样性限制或非线性疾病损失, 最优行动不再只是判断差值正负。测量还可能改变其他候选者的预测, 或者为未来参考群提供公共价值。此时不能强行把全部信息价值压进两者差值模型, 而应将更完整的行动集合写入计算。

15.22 参数估计误差为何使名义信息增益落空

上述推导给定了总体协方差。现实中参数需要估计，新平台的记录数量很大也未必意味着其目标协方差估得准确。为了把这种风险定量化，设真实最优权重为 $b_* = P^{-1}C$ ，实际使用估计权重 $\hat{b}$ ，且评估对象是与参数训练样本独立的未来记录。对固定的一组估计权重，平方误差有精确分解

$$Q(\hat{b}) = Q(b_*) + (\hat{b} - b_*)' P (\hat{b} - b_*).$$

这说明使用错误权重的损失由 P 度量，而非由系数欧氏距离直接度量。两个系数差很大，若差异只沿几乎没有记录变异的方向，当前总体的损失可能小；但那个方向一旦在新环境中增加变异，损失就可能突然放大。因此，系数稳定性和跨环境误差需要联系起来分析。

对指数方程作一阶扰动。设估计矩阵为 $P + \delta P$ 、 $C + \delta C$ ，忽略两个扰动相乘的二阶项，则

$$\delta b \approx P^{-1}(\delta C - \delta P b_*).$$

记 $q = \delta C - \delta P b_*$ ，其均值为 μ_q 、协方差为 Ω_q 。在小扰动近似下，额外外部预测风险为

$$E(\delta b' P \delta b) \approx \text{tr}(P^{-1} \Omega_q) + \mu_q' P^{-1} \mu_q.$$

这两个项分别对应估计波动和系统偏差。只给相关矩阵的每个元素一个标准误仍不足以计算它们，因为 δP 与 δC 常由同一批动物估计，彼此相关。假定它们独立有时会高估、有时会低估风险，具体取决于共同抽样结构。

看标准化两记录例子。设 P 的对角均为一，相关系数为 0.98，于是和方向与差方向的特征值分别为 1.98 和 0.02。若 q 仅沿单位差方向发生大小 0.01 的确定扰动，权重扰动长度约为 0.5，额外误差为 0.005；若相同扰动沿和方向，额外误差仅约 0.0000505。同样的参数误差在弱方差方向被放大约九十九倍。这是检查特征结构比只看相关系数符号更有用的原因。

若估计扰动每次沿差方向具有零均值、方差 0.0001，则平均风险同样为 0.005。假如一个新增来源在总体已知参数下只能减少 0.003 的误差，而为了

使用它引入的新增系数估计风险超过 0.003，外部预测就可能退步。总体投影的单调性没有被推翻；改变的是权重已从已知常数变成带误差的估计对象。判断新增来源是否值得使用，应比较两种完整训练程序的未来误差，而不是把名义可靠度相减。

参数误差还会改变记录采购的排序。一个方向在名义矩阵下有巨大增益，却依赖非常精确的抵消；另一个方向增益略小，但在合理参数区间内一直稳定。可以对每个候选设计 d 同时报告名义误差与参数情景损失，并定义

$$\mathcal{R}(d) = E_{\theta}\{Q_d(\hat{b}_d; \theta)\}, \quad \mathcal{R}_{\max}(d) = \sup_{\theta \in \Theta} Q_d(\hat{b}_d; \theta).$$

前者需要可辩护的参数分布，后者需要可辩护的不确定性集合；两者回答不同决策问题。不能先选出结果最漂亮的情景，再称其为稳健评价。对于参数资料薄弱的新性状，优先开展能识别协方差的先导试验，可能比立刻扩大同一种重复测定更有效。

实际核验可按两个层次组织。第一层固定总体参数，通过已知答案的小例检查指数、创新和误差公式；第二层反复生成参数估计样本，再把所估权重应用于独立未来样本，观察理论增益有多少被估计风险抵消。两层混在一起时，训练资料中的高精度可能掩盖外部风险。只有把这一区分保留下来，信息增量才从一个漂亮的 Schur 补数字，转化为可在后续出生群体中兑现的遗传预测改进。

15.23 习题、推导训练与参考解答

习题 15.1：单条记录与尺度。某性状表型方差八十、加性方差二十，候选动物校正记录离差为十二。求最优指数、准确度、可靠度与均方预测误差。若把指数乘以十，哪些量保持不变，哪些解释失效？

解答。权重为二十除以八十，即 0.25，预测育种值为三。预测方差为五，均方误差为十五，可靠度为 0.25，准确度为 0.5。乘以十不改变排序和相关，但不再以原始育种值单位校准。若仍用变换后指数方差除以遗传方差，会得到不合理的可靠度；应使用一般相关定义，并在经济解释前恢复尺度。

习题 15.2: 新增信息的零价值。原记录向量为 y_1 , 新增标量记录为 z 。证明当 $d = p'P_1^{-1}C_1$ 且剩余记录方差大于零时, 新记录不改进最优线性预测。若剩余方差也为零, 应如何处理?

解答。将新增记录残差化为 $z^* = z - p'P_1^{-1}y_1$, 它与原记录正交, 与目标的协方差为零。因此沿着这一新方向不能减少目标预测误差, 最优新增系数为零。若剩余方差也为零, 新增记录完全由旧记录线性决定, 应删除冗余项或使用适当广义逆; 不能把零除以零当作无限信息。这里说的是已知总体协方差下的结论, 不排除有限样本中出现非零估计系数。

习题 15.3: 重复记录的上限。证明在正的遗传力与重复力相等时, 无限次重复记录的可靠度极限为一。说明这一数学极限需要哪些假设, 为什么不等于实际育种可以承诺完全准确?

解答。将重复记录可靠度的分子分母同时除以记录数, 极限为 h^2/t , 二者相等时为一。假设包括目标在重复间不变、残差可平均掉、没有额外永久环境、方差参数已知且校正正确。实际中存在系统测量误差、纵向性状变化与选择性缺失, 都会破坏这些条件。极限只是指定模型下的信息边界, 不能替代测定系统验证。

习题 15.4: 公畜后代测定。在随机无关母畜和独立环境条件下, 遗传力为 0.20, 公畜有二十个后代。求公畜可靠度与后代均值权重。如果同一母畜产生了大部分后代, 能否继续使用结果?

解答。可靠度为 $20 \times 0.20 / [4 + 19 \times 0.20] = 0.512821$, 均值权重为其两倍, 即 1.025641。若大量后代共享母畜, 半同胞独立结构不成立, 母方遗传及可能的母体环境引入额外协方差。应按真实亲缘与环境构造矩阵; 名义后代数不再足以决定精度, 也不能通过把头数直接代入公式修正。

习题 15.5: 负权重辨析。一条记录与目标的协方差为正, 但在多信息指数中权重为负, 这是否一定说明程序错误? 请从偏回归角度说明, 并提出两项必要检查。

解答。不一定。其权重取决于扣除其他记录可解释部分后的目标协方差, 该剩余协方差可以为负。必要检查包括联合协方差是否正半定, 以及权重是

否对小幅参数扰动极敏感。还应核对单位、共同环境与资料重复。若负权重有稳定的残差信息解释且外部验证支持，可以合理使用；若由近共线性和估计噪声产生，则需稳定化或改进设计。

习题 15.6：预测相关与遗传准确度。某模型预测与未来校正表型的相关为 0.30，未来表型遗传力为 0.36。在适当独立残差假设下，估计遗传准确度。若训练记录与验证表型共享同一栏舍环境，为什么这个换算可能失效？

解答。遗传准确度为 $0.30/\sqrt{0.36} = 0.50$ 。换算依赖预测与未来环境残差不相关。若共享栏舍效应未被正确校正，预测可能同时利用环境，观察到的相关包含非遗传部分，简单除以遗传力平方根会高估准确度。应调整验证设计或联合建模共享环境，不能只换用另一个相关指标。

习题 15.7：测定预算研究设计。一个教学项目可以给一百只动物各测两次，也可以给两百只动物各测一次，费用相同。没有其他信息时，能否断言哪一种设计更优？请给出完成比较必须补充的条件。

解答。不能。需要知道重复力、遗传力、家系覆盖、候选与参考群关系、记录误差、目标表达时间及未来选留规模。重复测定降低个体暂时环境噪声，扩大个体数量可能改善遗传覆盖与参数估计。应按两种设计分别构造信息结构，比较未来候选群体预测和预期决策收益，并考虑设备批次与环境连接。只比较平均每只动物记录数，会遗漏设计最重要的差异。

习题 15.8：综合案例复算与审计。对三来源种羊例，验证权重满足指数方程，并解释为什么丁从旧排名末位升至新排名首位。若第三来源实际已经使用母亲记录，其误差与母亲记录不独立，应如何修改分析？

解答。将给出的权重乘以三行协方差矩阵，应依次得到二十五、十二点五和二十五，舍入只产生微小误差。丁在独有遗传信号上较高，新来源权重较大，足以抵消其自身与母亲记录较低的影响。如果第三来源已使用母亲记录，现有非对角元素遗漏额外资料重叠，应重新估计记录之间及对目标的联合协方差，或在统一模型中分析原始资料。不得只调低第三项权重后仍沿用原可靠度。

多性状育种目标与经济权重

16

16.1 先定义想改变什么，再决定测量什么

一个育种计划很少真正只关心一个性状。提高生长速度可能增加成熟体重和维持需要，改善繁殖力可能改变管理成本，降低发病风险既影响经济收益，也影响动物福利。若只对一个容易测量的指标排序，实际上就是在默认其他性状的后果不重要。这种默认往往比写错一个统计模型更难被发现。

多性状选择的起点是育种目标。设 $u = (u_1, \dots, u_q)'$ 是候选个体对 q 个目标性状的加性育种值， a 为相应经济权重或明确约定的价值权重，综合育种目标为

$$H = a'u, \quad \sigma_H^2 = a'\Sigma_u a, \quad \Sigma_u = \text{Var}(u). \quad (16.1)$$

本章用 Σ_u 表示性状间加性遗传协方差矩阵，避免与后续章节的个体间基因组关系矩阵混淆。目标性状与记录性状不必相同。例如商业群关心终生健康费用，但核心群能够较早获得的是体细胞、活动模式或病原检测记录；这些指标可以帮助预测健康目标，却不因此自动成为需要独立赋予经济权重的目标。

经济权重 a 回答“目标性状改变一个单位有多大价值”，指数权重 b 回答“某条记录对于预测综合目标应占多大作用”。两者不能互换。遗传力较低的性状不一定不重要；它可能具有很大的经济价值，只是当前难以准确预测。反过来，一个高度可遗传且容易测量的指标，如果对目标没有价值，也不应仅因“容易改良”而获得目标权重。

为每个目标建立清楚的定义尤其重要：是每只母畜每年，还是每只出栏

动物；是活重还是胴体重；是日排放、终生排放还是单位产品排放；是发病概率还是潜在责任度。单位、观察窗口和生产边界不明确，即使所有矩阵运算正确，最后也可能把无法相加的量相加。

16.2 多性状指数的推导与响应分解

记录向量 y 的长度为 m ，目标向量 u 的长度为 q 。因此 $P = \text{Var}(y)$ 为 $m \times m$ ， $C = \text{Cov}(y, u)$ 为 $m \times q$ ，并有 $\text{Cov}(y, H) = Ca$ 。最小化 $E[(H - b'y)^2]$ 得到

$$Pb = Ca, \quad b = P^{-1}Ca. \quad (16.2)$$

若记录恰好是候选个体所有目标性状的自身表型，并且表型等于加性遗传部分加独立环境部分，则 $C = \Sigma_u$ 。这只是一个特殊情况。当记录来自亲属、指示性状或重复测定时，不能机械地把 Σ_u 填到方程右端。

设按指数上端截留个体，标准化选择差为 i 。在目标育种值对指数的条件均值为线性、选留只依赖该指数等条件下，各性状的预期选择差为

$$\Delta u = i \frac{C'b}{\sqrt{b'Pb}}, \quad \Delta H = a'\Delta u. \quad (16.3)$$

若父母双方使用相同的选留规则，且忽略非加性和其他传递偏差，这也给出下一代相对选择前群体的预期加性均值变化；若只选择一方，另一方随机留种，则应考虑该方只贡献后代一半基因。后续的选择反应计算必须说清是在讨论选中亲本的平均育种值，还是后代群体的实际预期变化。

式 (16.3) 把“综合目标提高”拆成可检查的生物学后果。一个指数的目标值上升，并不要求每个有利性状都上升、每个不利性状都下降。遗传相关使性状之间存在交易；最优指数最大化的是既定权重下的总响应，而不是同时实现所有愿望。报告各性状响应是判断目标是否合理的必要步骤。

16.3 例 16.1 目标中惩罚耗料，耗料仍可能增加

构造两个性状：第一性状表示产品产出，第二性状表示一个耗料指标。二者均按各自原始单位记录。设

$$P = \begin{pmatrix} 100 & 6 \\ 6 & 4 \end{pmatrix}, \quad C = \Sigma_u = \begin{pmatrix} 30 & 2 \\ 2 & 1 \end{pmatrix}, \quad a = \begin{pmatrix} 2 \\ -3 \end{pmatrix}. \quad (16.4)$$

这些数值仅用于教学。“2”和“-3”是约定价值单位，不是市场价格。右端向量为 $Ca = (54, 1)'$ ，解得 $b = (0.576923, -0.615385)'$ 。对三只候选个体，计算如下。

候选个体	产出记录离差	耗料记录离差	综合指数
甲	8	1	4.000000
乙	5	-1	3.500000
丙	10	2	4.538462

丙的耗料记录最不理想，但产出信息带来的优势更大，因此位居第一。这不是计算错误，而是当前目标与信息结构下的明确取舍。仅观察 b_2 为负，并不能断言选择后第二性状的均值一定下降。

本例 $\sigma_I = 5.526162$ ， $\sigma_H^2 = 105$ ，综合准确度为 0.539298。取 $i = 1.4$ ，式 (16.3) 给出产出响应 4.072934、耗料响应 0.136414，综合响应为 7.736626。耗料尽管在目标中受到惩罚，仍因与产出存在正遗传协方差而发生小幅增加。如果管理者真正要求耗料不能增加，就应将这一要求写成限制条件，而不能寄希望于“负经济权重应该足够”。下一章将解决这一问题。

本例也可以用来检验单位变换。若把产出记录除以十，令 $y^* = Dy$ ，其中 $D = \text{diag}(0.1, 1)$ ，则 $P^* = DPD'$ 、 $C^* = DC$ ，新指数权重为 $b^* = (5.769231, -0.615385)'$ 。尽管第一个权重扩大十倍， $b^{*'}y^* = b'y$ ，三只个体的分数完全不变。权重的数值大小不能脱离单位比较。

16.4 例 16.2 经济权重来自生产系统的边际变化

设生产系统的收益减成本函数为 $\Pi(\mu_1, \dots, \mu_q; \theta)$ ，其中 μ_j 为性状均值， θ 表示价格、管理和资源条件。局部经济权重定义为

$$a_j = \left. \frac{\partial \Pi}{\partial \mu_j} \right|_{\mu=\mu_0, \theta=\theta_0}. \quad (16.5)$$

这个导数的含义是：在约定的系统边界和其他条件下，该性状小幅改变一个单位对净收益的影响。若生产系统允许随遗传改良重新优化管理，还应说明是固定管理下的偏导数，还是最优管理下价值函数的导数。所谓“经济权重”，并不是把销售单价直接复制到每个性状后面。

假设一个教学系统的单位动物净收益为 $\Pi = 20W - 2F - C_0$ ， W 为出售产品量， F 为饲料量， C_0 为不随这两个性状改变的费用。则局部权重为 $(20, -2)'$ 。如果目标已经同时包含 W 和 F ，再把“饲料转化率”赋一个独立经济权重，就可能重复计算相同的产出和耗料后果。比率指标可以用来沟通或监测，但作为目标时必须核对其与组成性状的关系。

同样的问题存在于环境目标。设总排放为 M 、产品量为 Y ，排放强度为 $Q = M/Y$ ，则小变化满足

$$\Delta Q \approx \frac{1}{Y} \Delta M - \frac{M}{Y^2} \Delta Y. \quad (16.6)$$

教学基线为 $M = 400$ 、 $Y = 40$ ，排放强度为 10。若总排放不变而产量增至 44，强度降为 9.090909；若产量不变而总排放降为 380，强度降为 9.5。两种方案均改善强度，但只有第二种降低了单只动物的绝对排放。更大的生产系统还可能通过改变饲养数量而改变总排放。因此，目标到底是单位产品效率、单只动物排放，还是固定总产品需求下的系统排放，必须先确定。

对未来才表达的收益，应统一时间基准。若目标性状在不同年份产生价值，可写成 $a_j^{eff} = \sum_{\tau} d_{\tau} a_{j\tau}$ ，其中 d_{τ} 同时反映贴现和该性状在后代中的表达次数。一个寿命较长、后期收益较大的性状，不应与当年即可表达的性状在未经调整的金额上简单比较。这是从单只动物的即时账目走向育种计划长期价值的必要步骤。

16.5 从经济目标走向可审查的多目标育种

当目标包含健康、福利、气候适应和遗传资源保存时，部分价值无法用稳定的市场价格表示。可以采用约束、期望改良量或多目标前沿，而不应把缺乏共识的价值强行包装成精确货币数字。经济权重可以明确地服务于某个企业目标；社会或公共项目则需要说明不同利益相关者的边界和权重来源。

目标权重的稳健性至少应接受三类检查。第一是价格或成本情景：饲料、产品和排放成本变化后，入选名单和性状响应是否大幅改变。第二是遗传参数情景：遗传相关估计的误差是否改变响应方向。第三是生产制度情景：同一基因型在舍饲、放牧或高温环境下是否具有相同价值。对这些情景作敏感性分析，比宣称存在“长期永久正确”的指数更有用。

还要区分“改良目标”与“评定模型更新”。新增一种传感器可能提高健康性状的预测准确度，却不必改变健康在目标中的价值；饲料成本长期变化可能要求更新经济权重，却不必改变遗传评定模型。把两种更新分开记录，有助于解释为什么同一只种畜的综合排序改变，也便于复核遗传进展是来自预测能力提高，还是来自价值标准变化。

现代多性状育种的进展不只是增加目标数量，而是更清楚地表达生产系统、预测误差和决策约束。目标越多，越要警惕稀释解释性：一张总分排名表不应掩盖关键性状的方向变化。一个可以审查的评定报告，应同时提供目标定义、权重单位、各性状预测、准确度或误差、预期响应，以及在主要情景下的稳定性。综合指数是压缩决策信息的工具，不是取消解释的理由。

另一个常见做法是先把各性状育种值标准化，再赋予看似便于解释的百分比权重。这可以用于表达偏好，但必须承认它改变了问题。若原目标为每单位实际产量或成本的经济收益，标准化后的正确权重应乘以相应遗传标准差，才能保持原目标不变。将所有标准化性状简单平均，实际上等价于人为赋予每一个遗传标准差相同价值，而不是一种不带价值判断的“客观综合”。

百分比重要性的解释还受到相关性的影响。总目标方差为对角贡献与非对角协方差贡献之和；当性状相关时，不能把每个性状的平方权重乘以遗传方差后除以总方差，便宣称这些比例必定加和为百分之百。若为了沟通需要

分摊相关项，应说明采用了哪种分配约定。用于决策的权重可以很清楚，所谓“贡献百分比”却未必只有一个唯一答案。

目标与数据之间还应保留可追溯的版本关系。例如，某年度改变了经济权重，应同时保存旧权重下的分数，以区分真正的遗传评定变化与指数定义变化；某次更新了性状定义，则应检查旧记录能否直接合并。对跨地区联合育种，局部生产条件差异可能需要地区化权重或多个公开指数，而不是由一个全国总分承担所有用途。让使用者选择符合其生产边界的目标，比隐藏差异更有助于合作。

16.6 育种目标首先是一个生产系统的定义

16.6.1 同一只动物可以面对不同价值边界

讨论经济权重之前，应把育种计划的服务对象说清楚。种畜企业出售遗传材料，养殖者生产商品，屠宰加工者关心可利用产品和加工性能，消费者还关心质量与安全。这些主体的收入和成本不完全相同。某个性状对加工者很有价值，但若支付制度没有把这一价值传递给养殖者，它在养殖场即时利润中的权重可能很小。育种目标可以选择服务全产业链，但必须明确这种选择，而不能把不同主体的收益不加区分地重复相加。

时间边界同样重要。以育肥结束为终点的目标，容易忽略母畜维持、繁殖失败和后备更新；以母畜终生为边界，则需要考虑不同胎次的产出、健康和存活。对终端杂交公畜与保留母系的公畜，后代在哪一环节表达性状也不同。一个统一的“增重价值”未必能同时用于两种用途，因为成年母畜体重的维持成本在终端后代与留种女儿中具有不同表达。

应将系统边界落实为明确的计量单位。例如，每只配种母羊每年、每只断奶羔羊、每只出栏动物和每千克产品都是合理单位，但会给繁殖力、存活率和体重不同的解释。采用每只出栏动物利润作为目标，可能把未出栏动物的损失隐藏在分母之外；采用每只配种母畜利润，则能把空怀和死亡后果纳入。没有一种单位天然适合所有问题，关键是与实际决策一致。

16.6.2 固定动物数量与固定资源产生不同权重

设一个放牧系统有固定饲草资源，成熟母畜体型增加后，每只母畜需要更多维持饲料。如果保持母畜数量不变，计算会表现为额外购买饲料的成本；如果保持土地与草料总量不变，计算则表现为可饲养母畜数量下降。两种边界都可能合理，但对应不同管理选择。经济权重之所以不能脱离生产系统复制，就在于性状变化会触发这些资源调整。

构造一个教学情景：年度可用于物质十万单位，每只母畜消耗五百单位，可养两百只；每只母畜净贡献三百，系统净贡献六万。如果改良后每只母畜消耗五百五十单位，净贡献仍为三百，则只能养约一百八十一只，系统净贡献降至约五万四千五百四十五。即使个体产出没有下降，资源约束下的系统收益仍然降低。若每只母畜净贡献同时提高到三百三十，系统净贡献恰好恢复六万。

这一算例没有说明大体型一定不利，而是说明应比较产出收益与资源占用。若大体型伴随更高商品后代价值，可能仍值得选择；若饲草充足且新增购买成本低，结果也会不同。对固定总产品需求的系统，还可能通过减少动物数量改变总排放。目标构造应允许这些管理响应，而不是在不自觉中固定某些变量、又让另一些变量自由变化。

16.6.3 目标定义是可检验的假设

生产系统模型应能解释基线，而不只是给出一个导数。若设定的基线收入、成本、繁殖数量和更新率不能与所描述系统相容，由它计算的经济权重再精确也缺乏依据。对于真实应用，应核对会计记录、生产记录和模型中的数量平衡；对于教学模型，应清楚标明哪些费用随性状变化、哪些被暂时固定。这样读者才能知道权重来自什么机制，而不是把它当作专家给出的神秘常数。

16.7 生物经济模型与边际经济价值

16.7.1 用一个母羊系统逐项推导

考虑一个简化的母羊年度系统。令 l 为每只配种母羊平均出生羔羊数, s 为羔羊从出生到出售的存活比例, W 为出售活重, p 为单位活重价格, c_l 为每只出售羔羊的相关变动费用, C_e 为母羊年度其他费用。年度净收益写为

$$\Pi = ls(pW - c_l) - C_e.$$

这里没有把所有真实成本都纳入, 而是建立一个可以完整解释的教学边界。出生后死亡羔羊的专门费用、胎次结构、后备更新和不同饲养阶段可以在后续模型中扩展, 但不能在本例导数中被隐含计算两次。经济权重是对指定模型求局部变化, 不是声称现实生产只由这几个变量决定。

取 $l = 1.4$ 、 $s = 0.9$ 、 $W = 40$ 、 $p = 25$ 、 $c_l = 300$ 、 $C_e = 700$ 。销售收入与羔羊变动费用的净额为 $1.26 \times 700 = 882$, 扣除母羊费用后净收益为一百八十二个价值单位。分别对三个生物性状求导, 得到

$$a_l = s(pW - c_l) = 630, \quad a_s = l(pW - c_l) = 980, \quad a_W = lsp = 31.5.$$

存活率的权重九百八十是每增加一个完整概率单位的价值, 而增加一个百分点对应 9.8。如果把百分数编码与比例编码混用, 会造成一百倍差异。平均窝产羔数提高 0.1 的局部价值为六十三, 而出售体重提高一单位的局部价值为三十一.五。不同性状单位不同, 不能直接比较六百三十与三十一.五的大小来判断哪个性状更重要。

16.7.2 局部导数与有限变化

导数适合描述小幅变化。若同时把产羔数提高 0.1、存活率提高 0.02, 线性近似收益为 $630 \times 0.1 + 980 \times 0.02 = 82.6$ 。准确计算还包括交叉项 $700 \times 0.1 \times 0.02 = 1.4$, 总增加八十四。这个差别来自多出生羔羊也受益于更高存活率。改良幅度越大、相互作用越强, 线性育种目标与真实收益函数之间的差距越需要检查。

若提高出售体重还增加饲料成本, c_l 就不能继续当作常数。可以令 $c_l(W)$ 随体重变化, 此时体重经济权重变为 $ls[p - c'_l(W)]$ 。这说明销售单价只给出新增收入, 而经济权重还要扣除实现该性状变化的边际成本。某个性状具有很高销售价值, 并不意味着每增加一单位都带来同样高的净收益。

16.7.3 管理优化后的权重

遗传改变有时会促使管理者调整出售年龄、饲料配方或后备比例。如果原管理制度并非最优, 固定管理导数可能与调整后价值不同。可以将管理变量记为 x , 定义价值函数 $V(\mu) = \max_x \Pi(\mu, x)$ 。在适当光滑和最优条件下, 局部导数可利用包络性质计算, 但约束激活、离散管理选择或多个局部最优会使问题更复杂。这里的关键不是引入更高级术语, 而是明确遗传改良后的管理是否允许变化。

生产者能够采取的调整也不是无限的。设备容量、合同、劳动力和饲草季节性都可能限制最优响应。因此, 经济模型应反映实际可行的管理范围。把一个可以自由调整全部投入的模型权重应用到资源受限的小规模养殖场, 可能低估适应性、稳定性和低投入维持能力的价值。育种目标需要与可实施的生产技术共同定义。

16.8 多性状响应的几何结构

16.8.1 为什么综合最优不意味着每项都最优

设 $g = Ca$ 。对于任意非零指数权重 b , 目标的标准化响应为 $ib'g/\sqrt{b'Pb}$ 。把记录协方差看作衡量指数长度的尺度, 就会发现优化实际上是在寻找与目标协方差方向最接近的记录组合。利用柯西不等式, 可以得到

$$\frac{b'g}{\sqrt{b'Pb}} \leq \sqrt{g'P^{-1}g}.$$

等号在 b 与 $P^{-1}g$ 成正比例时成立。这从选择响应角度再次证明指数方程, 而不依赖均方误差展开。两种推导得到相同方向, 是因为在线性目标和相同选择强度下, 最佳线性预测与最大化预期目标响应具有一致结构。

各性状响应却由 $C'b$ 决定。改变某一经济权重，会通过全部协方差影响整个向量，而不是只改变相应性状。一个健康性状的权重增加，可能同时影响产量、寿命和繁殖力；其后果取决于遗传联系和信息质量。因此，经济权重敏感性分析应重新计算完整响应向量，不应只把旧响应乘以新的权重。

16.8.2 准确度与目标难度

综合目标本身也有遗传方差 $a'\Sigma_u a$ 。若两个性状高度正相关而权重方向相反，目标可能主要是二者较小的差异部分。这种目标即使在单性状预测都较准确时，也可能难以预测，因为需要准确区分两个相关信号。反之，若目标方向与主要遗传变异方向一致，综合预测可能相对容易。目标的统计难度不能由各性状准确度简单平均得到。

例如产出和耗料高度相关时，选择低耗料且高产出的个体依赖于对条件效率差异的识别。只分别报告产出准确度和耗料准确度，不足以说明综合效率目标可靠度；还需要二者预测误差的协方差。若两个预测误差同方向变化，在差值目标中可能部分抵消；若误差反方向变化，则可能放大。多性状精度分析必须保留联合结构。

16.8.3 改变目标与改变信息的不同作用

增加一种指示性状，主要改变 P 与 C ；改变价值取舍，主要改变 a 。这两种改进都可能改变最终排序，但含义不同。前者试图更好地识别当前目标，后者重新定义什么叫优秀。评定服务若在同一次版本更新中同时改变数据、参数和目标，却只发布一张新排名表，使用者很难判断变化来源。

可以通过反事实计算分解版本差异：用旧数据和新目标重新计算，用新数据和旧目标重新计算，再与完全更新结果比较。这种分解不一定唯一，因为变化之间可能存在交互，但能提供可解释的主要来源。特别是在引入健康或环境性状时，应让使用者看到为新目标付出的产出响应变化，以及新增测定提高了多少信息，避免把价值调整误称为预测能力提升。

16.9 单位、标准化与相对重要性的正确解释

16.9.1 权重必须随单位同步变化

假设目标性状从原单位变换为 $u^* = Du$, 其中 D 是可逆的对角单位转换矩阵。要保持同一综合目标, 应令 $a^* = D^{-1}a$, 于是 $a^{*'}u^* = a'u$ 。遗传协方差也应变换为 $D\Sigma_u D'$ 。如果仅标准化育种值而不调整权重, 得到的是一个新目标, 不是旧目标的另一种显示形式。

将每个性状除以其遗传标准差是常见标准化。若 $z_j = u_j/\sigma_{u_j}$, 原目标可写为 $H = \sum_j (a_j \sigma_{u_j}) z_j$ 。因此, 标准化尺度上正确的权重是经济权重乘以遗传标准差。这个乘积也常用于表达每个遗传标准差的经济价值, 但它仍不是该性状对总响应的独立贡献, 因为性状之间存在协方差。

16.9.2 为什么贡献百分比可能超过百分之百

沿用本章两性状例, $a = (2, -3)'$, 遗传方差分别为三十和一, 遗传协方差为二。忽略相关项时, 两个平方权重贡献分别为一百二十和九, 总和一百二十九; 真实目标方差却为一百零五, 因为交叉项为负二十四。如果把一百二十和九分别除以一百零五, 得到的比例加和超过一。问题不在算术, 而在于把相关性贡献遗漏后仍要求部分之和等于整体。

一种沟通方式是按 $|a_j| \sigma_{u_j}$ 归一化得到相对强调比例。它可以描述权重在标准化尺度上的绝对大小, 但不应被称为方差解释率, 也不保证与实际响应贡献一致。另一种方式是将协方差项按约定分摊给各性状, 但分摊规则带有约定性。无论采用哪一种, 都应说明定义, 使百分比不会制造不存在的唯一答案。

16.9.3 标准化参数也会随群体改变

如果每年用当年候选群遗传标准差重新标准化, 同一个原始经济目标在标准化图表中的权重可能变化; 如果反过来固定标准化百分比而不断更新标准差, 原始单位上的经济目标也会变化。两种做法都可能服务某种管理目的, 但必须区分。育种计划希望比较长期趋势时, 通常需要保留稳定的原始单位与基准, 而不能只看每年均值为零、标准差为一的分数。

标准化还不能消除群体可比性问题。两个品种分别标准化后的高分个体，并不一定在同一生产环境中具有相同价值；品种均值、适应性和杂交用途仍需要单独处理。将不同来源的百分位排名直接拼在一起，只是让显示形式相似，并没有建立共同遗传尺度。多性状目标的清晰表达始终要回到原始生物量、生产边界与价值定义。

16.9.4 从经验评分反推隐含的价值取舍

有些育种计划在正式建立经济模型之前，已经长期使用一套经验评分。例如按若干记录各给固定分值，再相加决定留种。可以反过来问：如果这套评分确实是某个线性目标的最优指数，它隐含了怎样的目标权重？记经验权重为 b_0 ，则需要找到满足 $Ca = Pb_0$ 的目标权重。这个逆问题能够帮助识别经验制度中未被明确表达的价值取舍，但并不证明这些取舍合理。

当记录和目标维度相同且 C 可逆时，可以形式上求得 $a = C^{-1}Pb_0$ 。如果只关心排序，整体正比例尺度不可识别，因此通常还要约定一个权重作为基准。当 C 不满秩或记录多于目标时，可能有多个目标产生相同评分，也可能根本不存在与经验评分完全对应的目标。此时应报告剩余差异，而不是强行给出一个看似精确的经济解释。

反推结果有时会出现令人意外的符号。例如经验评分原本声称重视低耗料，但在考虑记录相关和预测信息后，其隐含目标可能仍鼓励耗料增加。这可以提示评分设计者重新审查是否混淆了记录权重与经济权重。也可能是目标性状遗漏了某个真正关心的结果，导致现有目标集合无法解释长期选择行为。逆向分析的作用是揭示假设和遗漏，而不是用数学给既有制度作无条件背书。

经验选择结果还可能受到门槛、疾病排除、配种限制和人工判断影响，因而不一定对应一个全局线性评分。若直接用最终入选名单拟合隐含权重，得到的参数可能同时混合经济偏好、风险厌恶和可行性约束。应先记录实际决策流程，再判断线性目标是否是适当近似。只有在选择依据明确且候选资料完整时，反推权重才具有较清楚的解释。

对一个准备升级的育种系统，可以将经验指数与生物经济指数放在相同

验证数据上比较：它们选择哪些个体，各目标性状预期怎样变化，哪一种方案在实际生产边界下更有价值。若二者表现接近，经验规则可能已近似捕捉主要取舍；若差异很大，则应追查原因，而不是直接认为新方法必然优越。使用共同的目标定义与外部检验，可以把专家经验转化为可讨论的假设，也让统计改进接受同样的证据要求。

16.10 饲料效率、比率、残差和真实成本

16.10.1 比率改善可以由不同路径实现

饲料转化率通常把耗料量与产品或增重相除，直观而便于管理，但作为育种目标必须识别分子和分母的作用。令 $Q = F/W$ ，小变化满足 $\Delta Q \approx \Delta F/W - F\Delta W/W^2$ 。因此，同样的比率改善既可能来自减少耗料，也可能来自增加产出，或者两者同时改变。若只报告比率，容易把不同的资源与经济后果混在一起。

构造两种教学生产结果：甲消耗三百单位饲料，产生一百单位产品，比率为三；乙消耗三百三十单位饲料，产生一百二十单位产品，比率为 2.75。乙的比率较好，但总耗料更多。若产品单价为四、饲料单价为 0.8，不计其他费用，甲的贡献为一百六十，乙为二百一十六。乙在这个边界下更有利；若系统受严格饲料总量限制，则还要比较给定资源下可生产的总产品，而不是只比较单只动物贡献。

比率目标还会产生非线性和分布问题。群体平均耗料除以平均产出，不等于个体比率的平均；低产出个体可能具有极端比率，对平均造成很大影响。若死亡个体没有最终产品，比率可能无法定义，但其饲料消耗仍然真实发生。系统目标应保留这些损失，避免只在成功出栏动物中计算效率，从而高估整体生产表现。

16.10.2 固定终重下生长速度的经济价值

生长速度的价值常通过缩短达到目标体重的时间表达。设需要增加的体重为 D_W ，日增重为 g ，所需天数为 D_W/g 。如果每日维持饲料为 m ，每单

位增重的额外饲料为 k ，总饲料可写为

$$F = m \frac{D_W}{g} + k D_W.$$

取 $D_W = 40$ 、 $m = 2$ 、 $k = 3$ 。日增重为一时需要四十天，总耗料二百；日增重为 1.2 时需要约三十三点三天，总耗料约一百八十六点六七。这里效率改善来自缩短维持时间，而不是假定组织沉积本身完全不耗能。若实际快速生长还改变体组成、疾病风险或出栏规格，模型需要增加相应后果。

固定日龄出售则是另一个问题。更快生长会增加出售体重，收入和饲料成本同时变化；固定终重出售时，则主要改变时间、维持耗料和设施周转。把两种边界下导出的权重相互套用，会造成明显错误。经济模型应与养殖者真实使用的出栏规则一致，并考虑体重或日龄上限是否在当前群体中经常成为约束。

16.10.3 剩余采食量不是自动独立的遗传目标

剩余采食量通过从实际采食中扣除由产出、体重或维持需要预测的部分构造，适合描述给定生产水平下的耗料差异。但如果扣除系数来自表型回归，残差在表型层面与所用预测变量不相关，并不保证其加性遗传值也与这些性状不相关。表型协方差与遗传协方差一般不同，因此遗传选择的相关响应仍需计算。

若已经在目标中对产品产出、成熟体重和实际耗料分别计价，再额外加入一个由这些变量线性构成的效率指标，可能重复计价。可以选择组成性状目标，也可以选择等价的转换目标，但应通过代数证明两者表达同一价值。统计上构造一个残差不会自动创造新的经济价值；它只是重新组织了已有性状，可能有利于解释和预测。

16.11 母系与终端父系需要不同目标

16.11.1 遗传优势在何处表达

终端父系的主要任务通常是提高商品后代表现，而母系还要承担繁殖、哺育、存活和重复生产。即使两类群体测量相同的生长记录，目标中各性状

的表达次数与后果也不同。若终端后代全部用于商品生产，公畜女儿的长期母性能力可能没有直接表达；若女儿被保留为母畜，同一公畜的母系遗传贡献就可能影响多个繁殖周期。

因此，构造目标不能只列出性状名称，还应列出性状在哪一代、哪种性别、哪一生产阶段表达。对直接与母体效应并存的性状，可把目标写为 $H = v_d u_d + v_m u_m$ ，但 v_d 与 v_m 的含义必须来自遗传传递和生产表达，而不能因为两个效应都与断奶重有关就简单相加。同一条断奶记录可能为两种遗传效应提供信息，模型预测与目标计价需要分别处理。

16.11.2 保留女儿改变了公畜价值

考虑一个教学比较：两只公畜在直接生长育种值上相差两单位，在女儿繁殖能力上相差一个方向相反的单位。如果后代全部终端出售，第二项可能不进入当前商品后代收益；如果计划保留大量女儿，未来多胎次繁殖收益可能抵消当前生长优势。两种用途给出不同排名并不矛盾，而是目标表达路径不同。报告一个不区分用途的统一总分，可能让使用者误以为某只公畜在所有系统中都更优秀。

保留女儿还会改变成熟体重与维持成本的价值。大体型商品后代可能提高出售重量，但大体型母畜需要更高维持投入。在饲草受限系统中，母系目标可能更强调适宜体型、繁殖稳定和低投入适应；在高投入终端育肥系统中，增长潜力和胴体价值可能获得更高权重。这里的“适宜”应由系统收益和约束定义，而不等于任意追求小型化。

16.11.3 杂交体系中的目标与评定

核心群可能在纯种环境中测定，商品群却在杂交条件下表达收益。纯种表现与杂交表现的遗传联系若不完全一致，选择目标就应明确面向哪一种表现。不能只因为记录都称作日增重，就假定纯种和杂交中的加性效应完全相同。相关性不足可能来自遗传背景、显性作用和环境差异，需要数据与模型识别，而不是仅靠理论命名解决。

杂种优势也不应被重复计入个体加性育种值。它通常与配种组合和群体

背景有关，个体选择与配种设计承担不同作用。一个合理的体系可以先评价个体在目标杂交背景下的可传递贡献，再在配种层面考虑杂种优势和互补性。把所有杂交收益都归到某只亲本的总分上，会妨碍不同组合之间的公平比较。

对实际母系和终端体系，最好同时提供用途清楚的多个指数，而不是让一个指数承担所有目标。多个指数应共享透明的单性状评定基础，区别在于目标权重、表达路径和约束。这样使用者可以根据是否保留女儿、饲养资源和产品合同选择适当目标，也能看见不同目标下排名变化的原因。

16.12 奶牛系统：产量、健康、繁殖与寿命的共同价值

16.12.1 产量不能脱离产品组成与支付规则

奶牛生产提供了理解多性状目标的典型情境。销售收益可能取决于奶量、脂肪量、蛋白量或质量门槛；不同支付方式会改变边际价值。若按乳成分支付，单纯增加稀释性奶量与增加有价值成分并不具有相同收益。即使销售合同相同，饲料、运输和加工容量也会改变额外液体体积的成本。目标需要反映实际产品价值，而不能仅依据哪个性状最容易提高。

乳成分百分比与成分产量之间同样存在比率关系。提高蛋白百分比可能来自蛋白量增加，也可能来自奶量下降。若目标已经对奶量和蛋白量分别计价，再给百分比一个独立权重，应检查是否重复或改变了原有支付逻辑。对存在等级门槛的支付制度，局部线性权重可能在门槛附近失效，需要计算达到不同等级的概率及其不确定性。

16.12.2 健康损失不止治疗费用

疾病的经济后果可能包括治疗、弃奶、产量下降、繁殖延迟、额外劳动、提前淘汰和死亡。若模型分别计入疾病损失与其造成的产量、寿命变化，必须区分直接费用和间接后果，避免重复计价。例如临床疾病的权重可以只包括在控制其他目标性状之后仍存在的额外成本，也可以使用总损失，但两种定义不能与同一组其他权重任意混合。

健康还具有无法完全由现金费用覆盖的福利价值。商业经济目标可以清楚描述企业收益，但公共或行业育种计划可能需要额外的健康约束或明确的社会价值权重。应承认这种价值选择，而不能声称所有福利后果已经被一个平均治疗费完整表达。对发生率低但后果严重的疾病，均值经济价值也可能不足以反映管理者的风险偏好。

16.12.3 寿命与更新率的边际解释

长寿可以减少后备更新需求并增加多胎次产出，但不是简单地让所有动物活得越久越好。低产、患病或繁殖困难动物被长期保留，可能降低系统收益。应区分总寿命、生产寿命和在一定生产水平下的功能性存活。寿命价值还取决于后备成本、淘汰残值、不同胎次产量以及更新带来的遗传进展。

一个教学系统有一百只成年母牛，后备育成净成本每头一千，年度更新率从0.30降至0.25，仅在这一成本项目上每年可少支出五千。但这不是完整寿命经济价值，因为淘汰牛残值、后备多余处置、老龄牛产量与健康、遗传更新速度都可能变化。这个算例展示了更新率的规模效应，也提醒我们不要把一个成本项目的节省当作总利润增量。

繁殖力与寿命相互联系，却不是同一性状。繁殖失败可能导致淘汰，延迟受胎可能影响产奶周期；若把这些后果全部分别计价，容易重叠。生物经济模型应追踪事件与现金流，让每项损失只出现一次。统计模型中的性状相关反映遗传联系，经济模型中的成本联系则反映同一后果如何记账，两种联系需要同时清楚。

16.13 猪、家禽与水产：不同生物学改变目标结构

16.13.1 猪的繁殖与商品性能

在猪的育种体系中，母系繁殖性状与商品生长、胴体和肉品质具有不同表达阶段。提高每窝出生数的价值取决于出生后存活、母乳资源、人工辅助和后续饲养容量；如果只增加出生数而没有改善成活与均匀度，收益可能低于按平均售价直接计算的结果。因此，产仔数、成活、母体能力和商品产出

应放在同一数量平衡中，不能把每个新增出生仔猪都假定为完整出售产品。

肉品质和加工适宜性可能具有最适区间或门槛，不一定越高越好。若某些指标影响产品等级，目标需要连接支付规则和消费者接受，而不是仅追求易测的化学成分。核心群中的快速生长也可能与群养行为、肢蹄健康和环境适应相联系。引入这些性状的目的应来自明确后果，避免把所有能测量的变量都列为独立育种目标。

16.13.2 家禽的短周期与性别、品系分工

家禽较短的生产周期使遗传改良可以较快表达，但同时对于繁殖、孵化和商品性能之间的分工提出要求。肉用体系的亲本繁殖能力与商品代生长效率并非同一任务；蛋用体系则要同时考虑产蛋数量、蛋重、蛋壳质量、存活和饲料投入。一个指标的单位价值会随产品规格和生产周期变化，不能把不同周龄的表现简单求和而忽略表达时间。

群养环境还可能使个体对同群伙伴产生影响。如果某种遗传倾向提高个体竞争能力，却损害同群总产出，仅按个体直接表现选择可能偏离群体收益目标。是否需要考虑间接遗传效应，取决于行为机制和数据设计；不能把所有群体差异都归为社会遗传作用。但从目标层面看，应先决定关心个体收益还是群体总收益，再选择能够识别相关效应的模型。

16.13.3 水产的家系测定与群体收益

水产育种常面临个体识别、共同养殖环境和破坏性测定等设计问题。若病害挑战或品质测定导致测定个体不能成为亲本，可通过同胞信息预测候选者，但目标仍需与实际养殖环境对应。挑战条件下的存活与生产环境中的长期抗病表现可能有关，却未必完全等同；将其作为指示性状时，需要估计目标联系，而不能仅因实验可重复就直接替代生产目标。

生长、成活与收获体重之间也存在系统数量关系。若只在存活动物中测量体重，平均体重提高可能伴随较高死亡损失，单位水体总产量未必增加。目标可以采用每投放单位的净收益，将成活、饲料、养殖时间和产品等级统一计算。不同密度下资源竞争会改变性状表达，经济模型与遗传评价都应说

明目标养殖条件。

这些畜种比较揭示了一条共同原则：选择指数的代数形式具有普适性，目标内容却由繁殖方式、生产组织和产品价值决定。借鉴成熟行业的方法时，应该迁移定义目标、构造协方差和验证响应的步骤，而不是照搬一组百分比权重。只有这样，跨物种学习才能增加解释力，而不会掩盖关键生物学差异。

16.14 健康与繁殖性状的尺度转换

16.14.1 一个概率单位不等于一个百分点

健康和繁殖记录常为是否发病、是否受胎或是否存活。它们可以在观察概率尺度上描述，也可以通过阈值模型在潜在责任度尺度上分析。两种尺度都合理，但经济价值最终通常表现为发生或不发生某个事件带来的后果。若估计育种值报告在责任度尺度，而经济权重按发病概率单位定义，二者不能直接相乘。

设疾病发生概率为 $p = 1 - \Phi(t_0 - \mu)$ ，其中 μ 为责任度均值， t_0 为阈值，残差尺度已标准化。如果每次疾病事件的净损失为 L ，期望损失为 Lp ，则责任度的小幅增加所对应的局部经济权重为

$$a_\mu = -L\phi(t_0 - \mu).$$

权重取决于当前发生率，因为正态密度在不同位置不同。同样大小的责任度改良，在疾病已经很少发生的群体和发生率居中的群体中，对概率的影响并不相同。若把责任度育种值看作一个跨所有群体都对应固定百分点的数值，会误导收益解释。

16.14.2 教学例：发生率改变后的价值

设基线发病概率为 0.10，每次事件损失一千个约定价值单位。相应阈值约为 1.281552，局部密度约为 0.175498，因此责任度增加一个单位的局部权重为约负一百七十五点五。责任度增加 0.1 的局部期望损失约为十七点五五。准确的概率变化则应重新通过分布函数计算，而不是假定线性关系对大幅变化也成立。

如果发病概率已降到很低,进一步减少同样责任度可能对应较少的可避免事件,但仍可能有重要的福利或生物安全意义。这时单纯按平均直接经济损失赋权,未必符合项目目标。可以增加明确的风险约束或社会价值,而不是把责任度尺度任意放大来达到想要的排名。统计尺度转换与价值判断应分别说明。

16.14.3 繁殖事件具有连续的系统后果

受胎、产仔与后代存活相互衔接,一个阶段失败会改变后续能够表达的收益。若把受胎率、产仔数和断奶数都赋予基于完整后代售价的权重,就可能把同一只后代的价值计算多次。应从状态转移或数量平衡出发,例如配种母畜数量乘以受胎率、每胎产仔数和后代存活率,再计算最终产品与各阶段成本。局部导数自然会反映每个环节的条件作用。

同时,繁殖性状改良可能改变后备需求和选择强度。更高繁殖率产生更多候选者,可能让育种场更严格选择;但这些长期遗传计划收益与当前商品后代收益不同。若在经济目标中纳入,应明确它们通过什么路径和多长时间表达,避免把一次繁殖改良的直接产出与其潜在选择收益混作同一项。

疾病与繁殖记录还受管理干预影响。更积极治疗可能提高记录到的病例数,却降低真实损失;更严格监测可能使同一病理状态更容易被发现。因此,目标定义应区分疾病生物学状态、诊断记录和治疗决策。用于预测的记录可以是诊断次数,但经济目标应连接真实生产与福利后果,必要时对不同场区记录制度进行校正。

16.15 环境目标:绝对排放、强度与资源效率

16.15.1 三种环境问题不能用同一个数字替代

减少单只动物的日排放、减少每单位产品的排放强度,以及减少一个固定产品需求系统的总排放,是相关但不同的目标。提高产量可能增加单只动物排放,同时降低单位产品强度;若因此减少需要饲养的动物数量,系统总排放还可能下降。反过来,强度下降若伴随总产量大幅扩张,总排放未必下

降。育种目标必须说明正在优化哪一种量。

环境评估的系统边界还包括饲料生产、粪污处理、后备更新与淘汰等环节。直接测量的肠道甲烷是一个重要性状，但不等于完整碳足迹。寿命和繁殖力改善可能通过减少后备需求影响系统排放，即使没有改变单只成年动物的甲烷。把一个生命期环境指标与若干组成性状同时加入目标，应核对是否重复计算相同减排后果。

16.15.2 用碳价格表达价值时应写清转换

如果决策者选择用一个假定碳价格给甲烷排放赋权，设价格为每吨二氧化碳当量 p_C ，采用的甲烷当量转换参数为 k_M ，则每千克甲烷的直接价值权重为 $-p_C k_M / 1000$ 。取教学参数 $p_C = 80$ 、 $k_M = 28$ ，权重为负 2.24。这里的转换参数仅是情景设定，不代表任何现行政策强制口径；真实应用应采用项目要求的时间尺度和核算规范。

甲烷也可被视为动物能量损失，但如果目标已对实际饲料耗用完整计价，再把全部甲烷能量折成饲料成本追加一次，可能重复计算。碳外部成本与饲料内部成本可以同时存在，因为它们对应不同后果；前提是各自的会计边界清楚。把所有能找到的负面影响都折成钱后简单相加，会制造看似全面、实际重叠的权重。

16.15.3 文献证据与生产实施要分开

González-Recio 等（2020）用西班牙奶牛的生物经济与指数情景分析说明，给甲烷负经济权重并不必然使单牛排放响应转负；与生产性状的相关可以使绝对排放仍增加，而强度指标改善。这与本章两性状教学例具有相同逻辑：惩罚某一性状并不等于施加禁止增加的约束。研究中的情景预测也不应被转述为已实施多年后的实测减排。

Ryan 等（2025）以一千五百零八头肉牛的甲烷表型资料估计参数，再模拟爱尔兰终端指数的不同情景。加入直接甲烷性状后，预测日排放响应随碳价情景由下降 0.22 克到 4.20 克不等。这个结果支持直接目标定义与权重情景的重要性；它仍是参数支持下的选择响应预测，不能等同于实际育种计

划已经实现同样幅度。

这些研究表明,环境性状进入目标需要同时解决测定、遗传关联和价值定义。它们并不提供一个可以不加修改地移植到所有肉羊、奶牛或放牧系统的统一权重。生产条件、产品结构和记录质量改变时,应重新评估响应与机会成本,尤其关注健康、繁殖和资源利用是否受到不利影响。

16.15.4 指示性状与直接测定的关系

昂贵或难以大规模测量的环境性状可以由指示性状辅助预测,但代理变量与目标之间的关系必须在目标群体中验证。一个与排放相关的采食或行为指标,可能主要反映动物大小或产量;如果直接选择该指标,未必得到希望的条件减排。应区分降低总采食导致的排放下降,与在相同产出条件下改善生物效率所产生的下降。

目标可以对直接环境性状赋值,同时把较容易测量的代理变量仅作为信息来源。这样便能避免把代理变量本身误当作环境价值。随着直接测定资料增多,更新的是代理与目标的协方差和预测精度;若政策或社会价值变化,更新的则是目标权重。把这两条更新路径分开,有助于持续积累证据。

16.16 未来价格、环境变化与目标不确定性

16.16.1 育种面向未来而不是只面向当期账目

遗传选择的后果通常在未来多个生产周期中表达,目标权重应考虑这一时间差。直接使用某一周的饲料价格,可能让指数在短期波动中频繁改变;完全忽略长期成本趋势,又可能使目标落后于未来生产条件。合理做法是建立具有依据的长期基准和若干情景,并检查排名与响应对关键价格比的敏感性。

贴现把不同时间的收益转换到共同基准,但不能代替对未来生产制度的判断。若一种性状的优势多年后才表达,其权重会受到贴现和存活概率影响;若未来管理技术可能显著改变它的经济作用,还需要情景分析。贴现率是价值与资本机会成本的假设,不是遗传参数,应与遗传协方差估计的不确定性

分开报告。

16.16.2 平均权重与稳健目标

如果未来情景具有可接受的概率，风险中性决策可以使用期望收益目标。在性状价值线性的情况下，平均权重等于按情景概率加权的权重；但若生产收益非线性、约束随情景改变，先平均权重未必与对完整收益求期望等价。下一章将更详细讨论稳健与非线性选择，这里首先强调目标不确定性需要有清楚来源。

若概率缺乏依据，可以报告多个情景下的结果，而不必伪造精确概率。一个方案可能在所有合理情景中都表现较好，另一个方案则只在高产品价格、低饲料成本时占优。决策者可以据此选择更稳定的目标，或保留具有不同优势的遗传材料。对未来不确定性作透明分析，比给出一个小数点很多的单一权重更有决策价值。

16.16.3 环境变化会同时改变价值和遗传表达

气候、饲草和管理变化不仅改变某性状的经济价值，还可能改变基因型的表现。若高投入环境下的生长育种值与低投入环境下的生长育种值相关不完全一致，应将它们作为相关但不同的目标，或使用反应规范描述环境梯度。简单地给同一个育种值换一组权重，只解决价值变化，不能解决遗传表达变化。

设两个未来环境分别占比例 w_1 、 w_2 ，目标可以写为 $H = w_1 a'_1 u^{(1)} + w_2 a'_2 u^{(2)}$ 。这要求掌握环境间遗传协方差，并说明环境比例来自何种生产规划。若某个极端环境发生概率低但损失很大，平均目标可能还需要最低适应性约束。稳定性和平均产出并不是同个性状，应根据实际用途决定如何表达。

16.16.4 目标更新应保持可追踪性

过于频繁改变目标可能使长期遗传方向反复摇摆，但拒绝更新同样可能积累偏差。可以设定常规评审周期，同时对重大生产制度变化保留临时评审。每次更新应保存旧目标下的评分与新目标下的评分，量化排名改变、各性状

响应和机会成本。这样才能判断变化是必要的价值调整，还是对短期噪声的过度反应。

目标更新还应与群体已经达到的水平相联系。某个健康性状从高发生率改善到低发生率后，局部边际价值和可用遗传变异可能改变；某个体型性状接近适宜范围后，继续单方向选择可能不再有利。线性目标是局部工具，长期计划需要周期性检查其仍然代表真实生产价值，而不能把最初的权重永久固定为生物学常数。

16.17 综合算例：饲料成本改变后如何解释排名

16.17.1 固定评定，只改变目标

重新使用本章两性状数据，保持 P 与 C 不变，让第一性状权重固定为二，第二性状权重分别为负一、负三和负六。这相当于改变成本性状的相对价值，而不改变遗传信息。这样可以清楚分离目标更新与评定更新。三组指数权重分别约为 $(0.587912, -0.131868)$ 、 $(0.576923, -0.615385)$ 和 $(0.560440, -1.340659)$ 。

对应原来甲、乙、丙三只候选个体，结果如下。

成本性状权重	甲指数	乙指数	丙指数	第一名
-1	4.571429	3.071429	5.615385	丙
-3	4.000000	3.500000	4.538462	丙
-6	3.142857	4.142857	2.923077	乙

成本惩罚较轻时，丙的产出优势占主导；惩罚较重时，乙较低的成本性状获得更高价值。没有任何新记录进入模型，排名已经改变。这说明综合排名不是个体固有且永不变化的属性，而是遗传预测与特定目标共同决定的结果。

16.17.2 用单性状预测解释切换点

这三只个体的两性状预测值依次为甲 (2.428571, 0.285714)、乙 (1.428571, -0.214286)、丙 (3.076923, 0.538462)。甲相对乙在第一性状上高一单位, 在第二性状上高半单位。若第一性状权重为二, 第二性状权重为 a_2 , 二者综合差为 $2 + 0.5a_2$ 。当 $a_2 = -4$ 时二者恰好相同; 成本惩罚更强时乙占优。

这个切换点比仅报告某次排名更有解释力。使用者可以将自己的成本条件与目标假设比较, 判断哪一个个体更符合生产系统。它也说明单性状预测值应当保留: 如果只公布总分, 使用者无法理解价格变化为何改变选择, 更难构造适合自身条件的目标。

16.17.3 比较响应而不只比较候选名单

取相同选择强度 $i = 1.4$, 当成本权重为负一时, 第一性状响应约为 4.189694, 第二性状响应约为 0.251753; 权重为负三时分别为 4.072934 与 0.136414; 权重为负六时分别为 3.637565 与负 0.056572。随着成本惩罚增强, 第一性状进展减慢, 第二性状从增加转为小幅下降。这是可以量化的取舍, 而不是“全面提高”四个字能够代替的结果。

不同权重下综合响应使用的是不同价值定义, 不能仅比较它们的数值大小, 便判定哪个方案更好。更公平的做法是用同一个外部评价目标重新衡量各方案, 或者把各性状响应和各自系统收益并列。若管理者要求成本性状绝不能增加, 负六只是当前参数下使响应略为负的一个权重; 参数改变后仍可能转正, 明确限制通常更符合这一要求。

16.17.4 参数不确定性与决策稳定性

现实中 P 和 C 也是估计值。若第二性状遗传协方差不确定, 成本响应的符号可能在合理参数范围内改变。尤其在本例负六情景中, 下降幅度较小, 更应检查方向是否稳健。可以对合法协方差情景重新计算权重与响应, 记录约束违背概率或最差结果; 不能只对一个相关系数上下浮动而忽略整个矩阵的正半定要求。

经济权重不确定性与遗传参数不确定性还可能交互。高饲料成本情景下，对成本性状预测误差更加敏感，因此同样的遗传参数误差会造成更大的价值损失。一个完整评估可以先在每个生产情景下重算目标，再对遗传参数联合抽样，最后比较方案的平均收益与不利尾部。研究设计应保持情景来源清楚，并避免把训练数据中的最优结果当作外部保证。

本例所有数值均来自教学协方差与实际线性方程计算。其意义是展示如何解释目标变化、切换点与响应方向，不是给出任何真实畜种的推荐价格权重。实际应用需要先估计适用群体参数，并确认目标性状单位、资料基准和生产费用之间相容。




图 16.1 固定第 29.3 节教学协方差矩阵和选择强度 $i = 1.4$ ，令目标权重为 $(2, -k)'$ 。成本权重增加会改变两性状响应；即使 $k > 0$ ，耗料仍可能通过相关响应上升。曲线表示所选亲本平均育种值差，在两性状采用相同规则时亦为预期子代加性均值响应

16.18 生产平衡的隐函数与总经济导数

经济权重的定义看似只是一个偏导数，困难却经常藏在“其他条件不变”之中。遗传改良改变存活、产出或生长时间后，养殖数量、后备需要和设施周转可能被数量平衡强制改变。这些变量不是完全自由的管理选择，也不是可以任意固定的常数。若先把它们从模型中省略，再对利润求导，就可能遗漏最重要的系统效应。本节用隐函数把这种关系写清楚。

设目标性状均值为 q 维向量 μ ，由生产平衡决定的系统变量为 p 维向量

x 。基线满足 p 个方程 $F(x, \mu) = 0$ ，且对 x 的 Jacobian 矩阵 F_x 可逆。这里的可逆性表示在基线附近，给定性状均值确实可以唯一确定局部系统状态。对平衡方程微分得到

$$F_x dx + F_\mu d\mu = 0, \quad \frac{\partial x}{\partial \mu'} = -F_x^{-1} F_\mu.$$

设系统净收益为 $\Pi(x, \mu)$ ，用列向量表示梯度，则经济权重为

$$a = \Pi_\mu - F'_\mu F_x^{-T} \Pi_x.$$

第一项是系统状态固定时的直接作用，第二项是为维持生产平衡而发生的间接作用。两项都来自同一个利润函数，所以可以逐笔检查收益与成本是否重复。这个公式没有使用遗传协方差；它描述的是生产后果，而非性状之间的遗传相关。只有随后把 a 代入选择指数，才进入遗传预测问题。

手算例考虑固定年度产品需求 Q 的系统。投产动物数为 n ，存活率为 s ，每只存活动物产出为 W ，故 $nsW = Q$ 。每只投产动物承担固定投入 c_0 ，每单位最终产品承担变动成本 c_w ，产品单价为 p 。全部金额均为教学单位。数量平衡与利润为

$$n = \frac{Q}{sW}, \quad \Pi = pQ - \frac{Qc_0}{sW} - Qc_w.$$

$$a_s = \frac{Qc_0}{s^2W}, \quad a_W = \frac{Qc_0}{sW^2}.$$

取 $Q = 10000$ 、 $s = 0.8$ 、 $W = 50$ 、 $c_0 = 100$ 、 $c_w = 3$ 、 $p = 10$ ，系统需投产二百五十只动物，利润为四万五千，权重分别为 31250 与 500。存活率提高一个百分点的线性价值为 312.5；按新数量平衡准确计算，利润增加约 308.642。单只产品量提高一单位的线性价值为 500，准确增益约为 490.196。两项权重主要来自为满足固定需求而减少的前期投入，不是额外产品销售收入，因为总产品量已经固定。

若边界改为投产动物数 n 固定，则利润为 $n\{sW(p - c_w) - c_0\}$ ，此时

$$a_s = nW(p - c_w), \quad a_W = ns(p - c_w).$$

在同一基线下，两项权重变为 87500 与 1400。两套数值没有谁天然更正确；它们分别描述固定需求与固定投产规模。拿前一套的存活价值与后一套的产出价值拼成一个指数，就会形成没有共同生产边界的目标。选择响应计算得再精细，也无法修补这种定义矛盾。

隐函数还可处理较复杂的循环。例如后备数量依赖淘汰率，淘汰率又受繁殖失败和后备供应影响。此时 F_x^{-1} 汇集多条反馈路径，不能只保留一条直观因果链。如果 F_x 接近奇异，小幅性状改变可能引起很大系统调整，这提示基线处于不稳定或约束切换附近。经济权重异常大时，应先检查这种结构，而不应立刻宣称该性状具有极高育种价值。

在实际应用中，连续 n 只是大群体期望规模。小群体存在整数头数，固定需求也可能允许缺货或超产；增加这些规则后，利润可能分段光滑。局部导数只能描述同一段内的变化。应报告基线、允许调整的变量和触发下一分段的条件，再用有限变化复算检验导数适用范围。这样的权重才具有可解释的经济单位。

在含大量系统变量的模型中，不必为每个性状分别显式求一个逆矩阵。先解伴随方程 $F'_x \lambda = \Pi_x$ ，便可写成 $a = \Pi_\mu - F'_\mu \lambda$ 。一个伴随向量就能计算许多目标性状的权重；它还给每条平衡方程提供了边际解释。若某条平衡的右端允许小幅放宽，相应乘子描述利润对这种放宽的敏感性。但乘子的符号依赖方程写法，把同一方程整体乘以负一会使乘子反号，真实经济导数则不变。报告乘子时必须同时给出原方程。

检查导数最直接的方法，是用同一模型的有限差分与解析结果比较。中心差分可写为

$$a_j^{(\epsilon)} = \frac{V(\mu + \epsilon e_j) - V(\mu - \epsilon e_j)}{2\epsilon}.$$

这里每次扰动后都必须重新满足数量平衡；若只修改性状而沿用旧动物数量，核验的是另一个导数。步长太大会混入曲率，步长太小则放大数值误差，可以比较几个递减步长是否在稳定范围内一致。差分是实现核验，不是对模型经济边界的验证；一个边界错误的模型同样可以通过差分检查。

还有一个容易混淆的层次：计算 a_s 时固定其他性状，是为了分清存活

率的独立生产后果，并不假定遗传选择只改变存活率。真正的遗传响应可以同时改变多个性状，届时用 $a'\Delta u$ 聚合它们。若在计算存活经济权重时先把与产量的遗传相关响应折成收入，然后又在综合目标中给产量赋权，就可能把同一产量后果算两次。经济模型里的生物数量关系和遗传模型里的相关响应各司其职。

16.19 最优管理下的一阶价值与二阶适应收益

生产平衡决定某些变量，管理者还可以主动选择饲喂水平、出栏时间和后备比例。若遗传改良后允许重新优化这些决策，应研究最优价值函数，而不能把原管理方案永久固定。与此同时，也不能把管理优化带来的全部收益归因于遗传改良：比较前后两种遗传水平时，双方都应获得同样的管理优化机会。

设管理向量为 x ，光滑利润为 $\Pi(\mu, x)$ ，基线最优解 $x^*(\mu)$ 位于内部，且 Π_{xx} 负定。最优条件及其微分为

$$\Pi_x(\mu, x^*) = 0, \quad \frac{\partial x^*}{\partial \mu'} = -\Pi_{xx}^{-1} \Pi_{x\mu}.$$

定义 $V(\mu) = \Pi\{\mu, x^*(\mu)\}$ 。链式法则中的管理调整项因 $\Pi_x = 0$ 消失，从而得到包络公式

$$V_\mu = \Pi_{\mu'}, \quad V_{\mu\mu} = \Pi_{\mu\mu} - \Pi_{\mu x} \Pi_{xx}^{-1} \Pi_{x\mu}.$$

一阶导数可以在最优管理点直接求偏导，并不意味着管理反应没有价值。它的影响明确出现在二阶曲率中。由于 Π_{xx}^{-1} 负定，后面被减去的矩阵为负半定，因此允许重新优化增加了局部二阶适应收益。这个结果成立于同一光滑内部最优分支；它不是对任何管理制度变化都成立的全局结论。

构造单性状单管理变量的教学利润

$$\Pi(\mu, x) = 6\mu + 4x + 2\mu x - x^2.$$

最优管理为 $x^* = 2 + \mu$ ，最优价值为

$$V(\mu) = 6\mu + (2 + \mu)^2, \quad V'(0) = 10, \quad V''(0) = 2.$$

基线 $\mu = 0$ 时利润为四。遗传均值增加 0.5，若管理固定为二，利润增加五；若管理调整到 2.5，利润增加 5.25。初始经济权重都是十，差异出现在有限变化的二阶项 0.25。因此，一个只根据初始权重比较短期小幅选择的指数可以合理；若计划累积很大改良，则需要重算管理与边际价值。

加入设备约束 $x \leq 2$ 后，正向遗传变化不能继续增加管理投入。此时 $\mu \geq 0$ 范围内 $x^* = 2$ ，价值函数为 $4 + 10\mu$ ； $\mu < 0$ 附近仍可沿内部最优分支调整。两侧一阶导数在零点相同，二阶导数不同。若同时存在离散饲料配方或最低开工量，连一阶导数也可能出现跳跃。不能把某一分支上的导数跨越制度边界长期使用。

约束最优值的一阶导数还可以借助乘子解释。设资源要求 $h(x, \mu) \leq B$ ，在收益最大化约定下令

$$\mathcal{L} = \Pi(x, \mu) - \lambda\{h(x, \mu) - B\}, \quad \lambda \geq 0.$$

$$a = \Pi_{\mu} - \lambda h_{\mu}, \quad \frac{\partial V}{\partial B} = \lambda.$$

若遗传改良增加资源占用， $h_{\mu} > 0$ ，即使直接收入为正，也必须扣除按影子价格计算的资源机会成本。乘子并非额外真实支付的一张账单，而是当前最优方案中一单位稀缺资源的边际价值；只有它与市场价格恰好一致时，二者才能替换。若资源约束不紧，乘子为零，就不应继续追加一项假定稀缺成本。

例如利润为 $4\mu x - x^2$ ，管理上限为 $x \leq 3$ ，在 $\mu = 2$ 时无约束最优 $x = 4$ 不可行，实际取三。资源乘子为 $4\mu - 2x = 2$ ，经济权重为 $4x = 12$ 。若错误地允许无限设备，权重会用 $x = 4$ 得到十六。设备容量差异在同一遗传水平下已经改变权重，因此跨场移植目标前必须核对管理可行域。

这种推导也给出一个防止重复计价的办法：若性状改良改变饲料需要，而饲料费用已经进入利润函数，资源约束的影子价值应只反映额外稀缺性，不能把完整市场饲料成本再加一次。固定投入、可变成本和约束机会成本各有不同角色。建立可逐项复核的经济模型，比把每一个可能的后果都附加一个独立权重更可靠。

16.20 胎次状态与折现收益的矩阵推导

寿命、繁殖和健康的价值经常跨多个生产周期表达。逐年列现金流可用于小问题，但胎次、健康状态与淘汰相互作用后，列表迅速变得复杂。一个紧凑的办法是用暂态状态转移矩阵描述动物仍留在生产系统中的路径，再对每条路径的收益折现。这里讨论单个遗传单位在产生命期中的价值；亲本基因向后代群体扩散的路径，将在长期选择中另行处理。

设共有 p 个生产状态，矩阵 T 的元素 T_{ij} 表示当前处于 i 、下一期仍在系统且进入 j 的概率，因此行和可以小于一，缺口表示退出。每期开始处于状态 i 时获得净收益 r_i 。记折现因子为 $\delta = 1/(1+d)$ ，初始状态分布为列向量 α 。从每个状态出发的价值向量满足

$$v = r + \delta T v, \quad v = (I - \delta T)^{-1} r.$$

$$V = \alpha' v = \sum_{t=0}^{\infty} \delta^t \alpha' T^t r.$$

逆矩阵存在需要 $\rho(\delta T) < 1$ 。有正折现且 T 为次随机矩阵时通常满足；即使没有折现，只要最终必然退出且期望生产期有限，也可以成立。若模型让动物以概率一永久留存、每期又得到正收入，则不折现的终生价值发散，不能把这个无穷数当作寿命性状的经济权重。

若遗传均值 μ_j 既改变当期收益又改变状态转移，对价值方程求导得

$$v_j = (I - \delta T)^{-1} \{r_j + \delta T_j v\},$$

$$a_j = \alpha' v_j + \alpha'_j v.$$

其中 $r_j = \partial r / \partial \mu_j$ 、 $T_j = \partial T / \partial \mu_j$ ， α_j 表示初始分布也随该性状变化时的导数。 r_j 是当前每次进入某状态的直接价值， $T_j v$ 是改变后续路径的价值。若疾病已经通过降低当期产出和增加退出概率进入这两处，就不能再把包括同样损失的疾病总费用追加一次。

两状态例中，状态一表示首次生产，状态二表示后续生产；退出后不再

产生收益。取

$$T = \begin{pmatrix} 0 & s \\ 0 & q \end{pmatrix}, \quad r = \begin{pmatrix} 100 \\ 140 \end{pmatrix}, \quad \alpha = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \delta = 0.95.$$

当 $s = 0.8$ 、 $q = 0.6$ 时, $v_2 = 140/(1 - 0.95q) \approx 325.5814$, $v_1 = 100 + 0.95sv_2 \approx 347.4419$ 。首次之后多存留一个完整概率单位的权重为

$$a_s = \frac{0.95 \times 140}{1 - 0.95q} \approx 309.3023,$$

后续每期存留概率的权重则为

$$a_q = \frac{0.95^2 s \times 140}{(1 - 0.95q)^2} \approx 546.6739.$$

第二个权重较大, 是因为 q 改变的不仅是下一期, 还反复影响所有更晚生产期。若简单把两种存留改善都乘以“下一胎利润一百四十”, 就会漏掉这种递归作用。对后续状态每期净收益增加一个单位, 其有效权重为 $0.95s/(1 - 0.95q) \approx 1.7674$, 不是把无限多个胎次直接相加。

有限年限与无限年限也不能混用。若项目只支付前 L 期收益, 应采用

$$v^{(L)} = \sum_{t=0}^{L-1} (\delta T)^t r, \quad v - v^{(L)} = (\delta T)^L v.$$

尾项可以帮助选择足够长的计算期限, 但仍需确认模型在较晚胎次是否可信。用前两胎估计的固定 q 无限外推, 可能得到精确却缺乏生物学依据的寿命价值。年龄相关风险、繁殖状态和健康费用可以增加为更多状态; 增加状态是否值得, 取决于它们是否改变重要现金流并获得足够数据支持。

退出以后若立即补入后备, 研究对象就从“单只动物终生价值”变为“固定栏位长期价值”。后备成本、空栏期和下一只动物的遗传水平都要进入新模型。两种价值可以服务不同决策, 却不能在一个指数内重复累加。把退出视为零收益的暂态模型, 适合本例定义的个体生命期边界; 它没有声称长期养殖场退出后永远停止生产。

16.21 不确定价格与遗传表达不能分别取平均

未来目标常同时面临价格变化与环境变化。如果高价格恰好出现在性状表达较弱的年份，或者高产出需要更多昂贵投入，那么“平均价格乘以平均表达”就不等于期望价值。对已有指数只替换一组均价，并不能自动处理这种相关。为了保持概念清楚，应把外部情景、遗传表达和个体预测误差分成不同层次。

设情景 s 发生概率为 π_s ，目标原始遗传向量为 u ，在该情景中的生物学表达为 $B_s u$ ，局部经济系数为 p_s ，表达时间的折现因子为 δ_s 。线性收益下，情景目标与平均有效权重为

$$H_s = \delta_s p'_s B_s u, \quad \bar{a} = \sum_s \pi_s \delta_s B'_s p_s.$$

这里矩阵 B_s 既可表示不同性状之间的转换，也可表示同一遗传单位在不同环境下的表达幅度。它不能在没有遗传证据时任意指定。如果不同环境中的表现需要作为不同育种值估计，则应扩大 u ，而不是假设所有环境只差一个已知比例。

对一个标量目标，设情景价格为 p 、表达系数为 β 、折现因子固定，便有

$$\bar{a} = \delta E(p\beta) = \delta \{E(p)E(\beta) + \text{Cov}(p, \beta)\}.$$

教学例中，两种等概率情景的价格分别为十与三十，遗传表达系数分别为二与一，暂不折现。正确权重为 25，均价乘平均表达则得到 30，高估百分之二十。差异完全来自负协方差；即使两组均值都估得无误，分开取平均仍然不对。若未来生产条件使高价格与高表达同时出现，误差方向会反过来。

这类相关还会影响目标的不确定性。若外部权重 a_s 与个体育种值不确定性独立，育种值在当前资料下均值为 $\hat{u}$ 、误差协方差为 V_u ，令权重均值为 $\bar{a}$ 、协方差为 V_a ，则全方差分解得到

$$E(H | \mathcal{F}) = \bar{a}' \hat{u},$$

$$\text{Var}(H | \mathcal{F}) = \bar{a}' V_u \bar{a} + \hat{u}' V_a \hat{u} + \text{tr}(V_a V_u).$$

第一项是固定平均目标下的遗传预测风险，第二项是已知遗传均值在不同价格中的价值变化，第三项是二者共同不确定时的交叉贡献。只计算第一项，会把未来价值波动全部误当作已经被可靠度覆盖；只计算第二项，则忽略候选者遗传评定本身并不确定。这些方差是情景模型中的数量，不等于真实生产一定遵循某个正态收益分布。

例如单性状预测均值为二、误差方差为一，未来价格均值为三、方差为四，且两类不确定性独立，则期望价值为六，价值方差为 $9 + 16 + 4 = 29$ 。把预测均值直接乘平均价格后，仅报告标准误三，会遗漏大部分价值变化。若当前决策只优化风险中性期望，可以仍按平均权重排序；若还要求控制不利尾部，就要使用更完整的分布或情景，而不能用“可靠度高”代替风险分析。

独立假设需要审查。若高温情景既提高投入价格，又改变育种值表达与预测误差，那么 a_s 和 u_s 不再按上述简式分离。正确做法是逐情景计算条件均值与条件方差，再在情景之间聚合：

$$\text{Var}(H) = \sum_s \pi_s \text{Var}(H | s) + \sum_s \pi_s \{E(H | s) - E(H)\}^2.$$

这个公式仍然成立，但条件内的模型必须与情景对应。不能先让价格和遗传表达分别随机，再假定它们通过抽样自动形成真实相关。若相关证据不足，可以展示几个有解释的联合情景，并说明它们是压力检验，而非已估计的发生概率。

长期折现也具有同样结构。若现金流发生时间随性状变化，折现因子本身对遗传均值求导；只给最终权重乘一个固定折现系数，会漏掉提前表达的价值。反过来，若发生时间已经进入状态转移模型，就不应在有效权重上再重复扣减等待时间。生产概率、遗传传递和时间价值应分别定位到模型的一处，使每个因子只作用一次。

外部情景的不确定性还应与经济模型参数的估计误差区分。前者表示未来确实可能处于不同价格或环境，后者表示我们尚未准确知道某个长期平均参数。若权重由参数向量 θ 通过 $a = f(\theta)$ 产生，局部估计协方差可近似为

$$\text{Var}(\hat{a}) \approx D_f \text{Var}(\hat{\theta}) D_f', \quad D_f = \frac{\partial f}{\partial \theta}.$$

这个量描述权重估计的证据精度，并不意味着未来市场必然按同一协方差变化。对一个均价估计采用更大的样本，可以降低估计误差，却不能因此消除未来年度价格波动。将两种方差混成一项，会让测定项目看起来能够解决它实际上无法控制的外部风险。

例如前面固定需求系统的存活权重同时依赖固定投入、存活率与产品量。即使固定投入的估计相当准确，存活率基线稍有偏差也会通过平方分母影响权重。可以联合抽样这些参数后重算完整目标，但每次抽样都应满足存活率位于零与一之间、数量平衡合法等条件。分别给每个权重随意加减一个百分比，未必对应任何可实现的生产系统，也可能破坏原本应共享的价格比与成本约束。

若不同主体对同一后果的价值判断不同，这又是第三类差异。它不一定会随增加样本而消失，不能把所有分歧都描述为统计不确定性。企业现金收益、公共健康价值与遗传资源保存可以分别形成透明目标或约束，再比较共同可行方案。数据帮助判断后果，却不能替代对价值边界的选择。

16.22 目标误设的响应损失与局部敏感性

讨论经济权重时，人们常问“权重估错一点是否严重”。答案不由权重的相对误差单独决定，而取决于错误发生在什么遗传信息方向。假设 P 、 C 已知，记

$$B = C'P^{-1}C.$$

B 是目标育种值被现有记录线性预测的协方差矩阵。它与真实遗传协方差 Σ_u 不同，包含当前信息限制。用估计目标权重 $\tilde{a}$ 构造最优指数，但用真实权重 a 评价其选择响应，在相同选择强度 i 下得到

$$R(a, \tilde{a}) = i \frac{a' B \tilde{a}}{\sqrt{\tilde{a}' B \tilde{a}}},$$

$$R(a, a) = i \sqrt{a' B a}, \quad \frac{R(a, \tilde{a})}{R(a, a)} = \frac{a' B \tilde{a}}{\sqrt{a' B a} \sqrt{\tilde{a}' B \tilde{a}}}.$$

当相关分母非零时，最后一个量就是以 B 为度量的夹角余弦。因此，正比例地放大全部权重不会损失排序响应；改变相对方向才会。这个几何关系

还说明, 权重误设甚至可能产生负响应: 若错误目标与真实目标在可预测空间中反向, 准确地选择错误目标会使真实价值下降。

令 $B = \text{diag}(4, 1)$, 真实权重为 $(1, 1)'$, 错误权重为 $(1, -1)'$, 并取 $i = 1$ 。真实最优响应为 $\sqrt{5} \approx 2.2361$, 错误目标获得 $3/\sqrt{5} \approx 1.3416$, 损失 $2/\sqrt{5} \approx 0.8944$, 即最优响应的百分之四十。两种指数各自预测方差都是五, 仅比较“指数变异大不大”不能发现错误。必须始终用同一个真实评价目标衡量方案。

对于小误差, 令 $\tilde{a} = a + \varepsilon$, 并记 $s^2 = a'Ba$ 。把误差分为沿目标方向和与目标正交的部分:

$$\varepsilon_{\perp} = \varepsilon - a \frac{a'B\varepsilon}{s^2}, \quad a'B\varepsilon_{\perp} = 0.$$

在 $s > 0$ 且扰动足够小时, 响应损失的二阶近似为

$$R(a, a) - R(a, a + \varepsilon) \approx \frac{i}{2s} \varepsilon'_{\perp} B \varepsilon_{\perp}.$$

一阶损失为零, 因为正确目标已经是最优方向; 小幅权重误差往往只产生二阶损失。这不能用来证明任何权重都“差不多”, 因为大误差、响应硬约束和候选名单离散变化可能使局部近似失效。前面的反号例就不属于可以随意忽略的微小扰动。

各性状响应向量本身也能求导。由 $\Delta u = iBa/s$ 得到

$$\frac{\partial \Delta u}{\partial a'} = i \left\{ \frac{B}{s} - \frac{(Ba)(Ba)'}{s^3} \right\}.$$

这个 Jacobian 乘以 a 为零, 表示权重整体尺度不改变响应。它的非对角元素则说明, 提高某项价值会同时改变其他性状响应。教学例中仍取 $B = \text{diag}(4, 1)$ 、 $a = (1, 1)'$, 有

$$\frac{\partial \Delta u}{\partial a'} = \frac{1}{5\sqrt{5}} \begin{pmatrix} 4 & -4 \\ -4 & 4 \end{pmatrix}.$$

第二权重略增, 会降低第一性状响应、提高第二性状响应; 取舍幅度可以在重算完整方案前局部估计。若存在某个性状响应不得变坏的要求, 离限

制边界越近,就越不能只根据综合损失很小来接受权重误差。综合价值的二阶损失可能很小,而某个具体响应方向的一阶变化已足以越界。

当 B 奇异时,一些经济方向目前无法由记录预测。沿这些方向改变权重可能完全不改变指数,不意味着相应性状没有经济价值。它意味着信息系统尚未提供选择该方向的能力。此时应分别报告目标价值与信息缺口,并考虑增加直接测定或相关记录。若把“权重改变没有影响”解释为“该性状不重要”,就会把预测限制误写成价值判断。

最后,目标审查可以用三种相互补充的输出结束:明确生产边界下的经济导数,权重变化导致的各性状响应,以及统一评价目标下的响应损失。前两者解释价值从哪里来,第三者量化错误取舍的代价。这样,权重讨论便不再停留在一个难以辩护的百分比清单,而成为可以随生产条件和遗传信息更新的定量分析。

16.23 习题、案例讨论与参考解答

习题 16.1: 目标性状与指示性状。一个肉羊计划希望改善商品胴体价值,但活体只能获得体重、超声测量和生长过程记录。有人主张凡是进入评定模型的变量都应赋予经济权重。请判断这一说法,并说明目标矩阵与信息矩阵分别应包含什么。

解答。说法不成立。经济权重属于真正要改良的目标性状,记录变量可以只承担预测作用。目标向量可包含胴体产出与有价值的品质性状,信息向量可包含体重、超声和纵向记录。 C 描述这些记录对目标育种值的协方差, P 描述记录彼此的协方差;二者维度可以不同。若超声指标仅是胴体组成的代理,再给它独立经济权重可能重复计价。应先确定目标,再评价代理的预测价值;不能让测定方便程度代替生产价值判断。

习题 16.2: 单位变换。原目标为 $H = 2u_1 - 3u_2$ 。如果第一性状从千克改为克,第二性状保持不变,新的经济权重是多少?如果把两个性状都标准化为一个遗传标准差,权重又应怎样变?

解答。第一性状数值扩大一千倍,因此相应权重应从二变为 0.002,第

二权重仍为负三。若标准化为 $z_j = u_j/\sigma_{u_j}$, 权重分别为 $2\sigma_{u_1}$ 与 $-3\sigma_{u_2}$ 。只改性状数值而不改权重, 会改变目标。验证等价性的方法是对任意候选个体计算变换前后总目标, 二者应相同; 同时协方差矩阵也必须按单位变换, 不能只修改显示标签。

习题 16.3: 母羊生物经济模型。在本章教学母羊系统中, 同时将平均出生羔羊数从 1.4 提高到 1.5, 存活率从 0.90 提高到 0.92, 其余参数不变。计算净收益准确变化及一阶近似, 解释差额来源。

解答。原净收益为 $1.4 \times 0.9 \times 700 - 700 = 182$ 。新净收益为 $1.5 \times 0.92 \times 700 - 700 = 266$, 准确增加八十四。一阶近似为 $630 \times 0.1 + 980 \times 0.02 = 82.6$, 差额 1.4 来自产羔数与存活率共同增加的交叉项。这个差额在本例较小, 但若变化更大或收益函数弯曲更强, 局部线性目标需要重新检查。计算也假定每只出售羔羊费用和母羊费用不随两性状改变; 若管理投入变化, 应修改收益函数。

习题 16.4: 资源约束。一个系统有十万单位饲草, 原来每只母畜消耗五百、贡献三百。新遗传类型每只消耗五百五十、贡献三百二十。比较固定资源下总贡献, 说明为何单只动物贡献提高仍可能不利。

解答。原系统可养两百只, 总贡献六万。新系统可养约 181.818182 只, 总贡献约 58181.818182, 低于原系统约 1818.181818。单只贡献提高不足以抵消资源占用增加。若资源能够按合理价格增加购买, 问题应改为固定数量并计入边际饲料成本; 不能把固定资源结论直接用于资源不受限情景。这个比较也未计整数头数、季节波动和其他设施约束, 正式方案应进一步细化。

习题 16.5: 响应方向。本章例 16.1 对耗料赋予负权重, 但预期耗料响应为正。请用矩阵表达说明原因, 并提出两种符合不同管理意图的解决方法。

解答。第二性状响应为 $i(C'b)_2/\sqrt{b'Pb}$, 不是第二经济权重的符号直接决定的。产出选择通过正遗传协方差带来耗料增加, 可能超过直接惩罚效果。如果管理者只是希望在收益中计入耗料成本, 可以重新核对经济权重并接受总收益最优下的取舍; 如果明确要求耗料不增加, 应施加响应限制。提高负权重与设置硬约束不完全等价, 前者在参数变化时仍可能出现正响应, 后者

则明确限制可行域，但也需评估参数不确定性。

习题 16.6：相关贡献。已知两性状遗传方差为三十和一、协方差为二，权重为二和负三。计算综合目标方差，并解释为何把两个对角贡献除以总方差后比例和大于一。

解答。方差为 $4 \times 30 + 9 \times 1 + 2 \times 2 \times (-3) \times 2 = 105$ 。对角项合计一百二十九，而交叉项为负二十四。因此仅用对角项计算的“贡献比例”遗漏了负协方差作用，比例和超过一并非计算器错误。若需要展示相对重要性，可以采用明确约定的标准化强调比例或分摊相关项，但不能把某一种约定说成唯一的方差解释。实际响应贡献也要另行计算，因为它依赖信息矩阵而不只依赖目标方差。

习题 16.7：目标的时间表达。某性状在未来三个年度各表达十个价值单位，发生概率分别为一、0.9 和 0.8，贴现率为 0.05。写出有效权重公式，并说明为何不能简单相加为三十。

解答。以当前为基准、三个年度分别在一年后至三年后表达，有效价值为 $10/1.05 + 9/1.05^2 + 8/1.05^3$ 。这同时考虑表达概率与时间折现，因而小于三十。若十个单位已包含存活概率，就不能再乘一次；如果遗传效应在后代中的传递比例也尚未计入，还需另外处理。时间、概率和遗传表达次数各有不同含义，应通过清楚的现金流与基因流定义避免重复折扣。

习题 16.8：排放边界。两种方案都使每千克产品排放下降百分之十，能否判断它们对总排放的效果相同？如果一个方案主要提高产量，另一个主要降低单只动物排放，还需要哪些信息？

解答。不能。需要知道动物数量、总产品需求、后备更新、生产扩张以及其他系统排放。提高产量可在固定产品需求下减少动物数量，但若产量扩张，总排放可能不降。降低单只动物排放也可能伴随产量或存活改变。应在共同系统边界下计算总排放与产品产出，分别报告绝对量和强度。环境指标之间的关系需要数量平衡支持，不能用一个改善百分比代替完整系统结果。

习题 16.9：价格切换点。对综合案例中的甲与乙，第一性状预测差为一，第二性状预测差为 0.5，第一性状权重固定为二。求第二权重的排名切换点，

并说明如果两个预测差都有误差，切换点应怎样报告。

解答。综合差为 $2 + 0.5a_2$ ，切换点为负四。若预测差有误差，切换点本身也不确定，尤其当成本性状差接近零时，其比值可能非常不稳定。可以基于预测误差联合分布或有依据的参数情景，报告不同权重下甲优于乙的概率或稳定范围，而不是给出一个没有误差说明的精确临界价格。还应避免把候选者的点预测差解释为已知真实遗传差。

习题 16.10：研究设计。为一个没有完整环境性状记录的地方肉羊群设计“高产、健康、低排放”目标研究。要求说明目标定义、测定资料、经济或社会权重、验证与证据边界，不能直接复制其他国家某个指数的百分比。

解答。首先明确是终端还是母系用途，以及按母羊年度、商品后代或固定产品需求核算。分别定义产出、健康事件与环境目标，避免把代理指标直接当作目标。建立能连接家系和环境的代表性测定样本，记录直接排放或经过验证的代理、采食、产量、繁殖与健康。经济模型使用本地生产边界和透明情景，公共价值可用约束或明确权重表达。随后估计合法的遗传与残差协方差，计算各性状响应和机会成本，并在未来年度或独立场群验证。初期情景模拟应称为预测分析，只有连续实施与监测才能支持实际遗传进展结论。

目标研究的最终产品不应只有一个权重表。还应包括变量定义、计量单位、生产边界、参数来源、敏感性分析和更新条件。这样，即使未来价格或测定技术改变，后续研究者也能明确修改哪一部分，而不是重新发明一套无法比较的总分体系。

限制指数、非线性目标与稳健决策

17.1 将“不能恶化”写成数学约束

第 16 章的例题表明，负经济权重并不保证某个性状下降。实际育种还可能要求成年体重基本不变、难产风险不增加、特定适应性性状保持稳定。这类要求不是对目标的模糊偏好，而是可行域的一部分。限制性选择指数把这种边界直接写入优化问题，经典形式可追溯到 Kempthorne 与 Nordskog (1959)。

继续设 y 为 m 维记录， u 为 q 维目标育种值， C 为 $m \times q$ 。令 L 为 $q \times k$ 矩阵，每一列指定一个需要保持零响应的目标线性组合。例如只限制第二性状时， L 就是第二个单位向量。约束为 $L'\Delta u = 0$ 。由式 (16.3) 可知，在指数方差为正时，这等价于

$$L'C'b = 0. \quad K = CL \in \mathbb{R}^{m \times k}, \quad K'b = 0. \quad (17.1)$$

这里必须注意矩阵方向： C 是记录对目标的协方差，不能把 $C'L$ 当作约束矩阵，除非重新定义了维度。明确每个矩阵的行列含义，常能在数值计算前发现错误。

设 $g = Ca$ ，在约束下最小化 $E[(H - b'y)^2]$ 。引入乘子 λ ，得到方程

$$\begin{pmatrix} P & K \\ K' & 0 \end{pmatrix} \begin{pmatrix} b_R \\ \lambda \end{pmatrix} = \begin{pmatrix} g \\ 0 \end{pmatrix}. \quad (17.2)$$

若 K 的约束列相互独立且 P 正定，可写出

$$b_R = P^{-1}g - P^{-1}K(K'P^{-1}K)^{-1}K'P^{-1}g. \quad (17.3)$$

第二项从原指数中移除了违反限制的成分。它并不代表新增了关于目标的信息，而是牺牲一部分原本可获得的响应以满足约束。若限制过多，使剩余记录空间无法预测目标，可能出现 $b_R = 0$ ；此时指数无法形成有效排序，不能继续把零除以零的响应公式当作结果。

17.2 例 17.1 保持耗料不变，需要付出多少代价

沿用例 16.1 的 P 、 C 与 a ，要求第二性状的预期响应为零。于是 $L = (0, 1)'$ 、 $K = (2, 1)'$ ，约束是 $2b_1 + b_2 = 0$ 。解式 (17.2) 得到

$$b_R = \begin{pmatrix} 0.565217 \\ -1.130435 \end{pmatrix}, \quad \lambda = 2.130435. \quad (17.4)$$

耗料记录的负权重比不受限制时更大，用来抵消产出选择带来的相关增长。取相同选择强度 $i = 1.4$ ，产出响应为 3.794962，耗料响应在舍入误差范围内为零，综合响应为 7.589925。不受限制时综合响应为 7.736626，施加限制损失约 1.8962%。

这个结果说明，限制的代价应计算，而不是凭直觉判断。在本例中保持耗料不变的目标代价较小，因此可能很有吸引力。但若两个性状的遗传相关更强、有效信息更少，限制可能极其昂贵。一个稳健的报告应画出或列出允许耗料响应从负到正变化时的目标响应前沿，让决策者看到每一项要求的边际代价。

还应区分“零预期响应”与“所有后代不变”。限制指数控制的是模型中的群体均值变化，不控制每只后代的表现，也不消除抽样波动、孟德尔抽样和环境变化。若育种场提出“下一代平均耗料绝不能增加”的确定性承诺，仅凭一个点估计的限制指数是不够的；需要描述参数和实现过程的不确定性，并在连续世代监测中调整。

对于“最多增加某个数量”这类非零限制，不能直接把式 (17.2) 的零替换为目标响应值。原因在于真实响应还要除以 $\sqrt{b'Pb}$ 。一种清楚的表达是规定 $b'Pb = 1$ ，在此单位方差尺度下最大化目标协方差，并写入 $iL'C'b \leq d$ 等响应约束。这形成带二次等式约束的优化问题，不应未经证明就声称它为凸

问题；也可直接对原始标准化响应做数值优化。期望改良量指数需说明控制的是响应方向还是绝对大小，后者同时受选择强度与可用信息限制。

17.3 例 17.2 目标存在最适值时，预测均值并不够

有些性状不是越大越好。过大的初生重可能增加难产风险，过低的初生重可能降低成活率；产品组成也可能存在加工最适区间。若经济价值在当前均值附近近似线性，可使用局部经济权重；若候选个体跨越最适点，线性近似可能给出错误排序。

设未来目标性状 U 的理想值为 u_0 ，价值函数为 $V(U) = -(U - u_0)^2$ 。在给定数据后，候选个体的预测均值为 m 、预测方差为 s^2 。利用平方偏差分解，有

$$E[V(U) | y] = -(m - u_0)^2 - s^2. \quad (17.5)$$

令 $u_0 = 5$ 。候选甲的条件均值为 3、条件方差为 1；候选乙的条件均值为 6、条件方差为 16。如果只看均值，乙距最适值更近；计算期望价值，甲为 -5，乙为 -17，甲反而更好。差异来自不确定性：在弯曲的价值函数下，预测方差本身会影响期望收益。

这不是“任何情况下都惩罚不确定个体”的普遍规则。若价值函数在有关范围内是凸的，方差项可能增加期望价值；若价值函数线性，风险中性的期望收益只取决于条件均值。应先说明价值函数，再推导不确定性的作用。对一般平滑价值函数 $V(u)$ ，二阶近似为

$$E[V(u) | y] \approx V(\hat{u}) + \frac{1}{2} \text{tr}\{\nabla^2 V(\hat{u}) \text{Var}(u | y)\}. \quad (17.6)$$

式 (17.6) 同时要求预测误差的协方差，而不仅是每个性状一个标准误。对于阈值处罚、死亡风险或其他非平滑目标，后验抽样或数值积分通常比二阶展开更合适。若关心后代表型而不是亲本育种值，还必须在预测分布中加入配偶遗传贡献、孟德尔抽样和环境变异，不能把亲本育种值的误差方差误作后代表型方差。

17.4 例 17.3 不确定的权重与不确定的育种值

稳健决策至少面对两种不同不确定性。第一种是价值权重不确定，例如未来饲料成本变化；第二种是个体育种值不确定，例如青年种畜资料较少。二者的来源和处理方法不同，应分开表达，再在需要时联合分析。

构造两只候选个体的预测目标值：甲为 $(4, 2)'$ ，乙为 $(3, 0.5)'$ ，第一性状有利，第二性状为成本性状。情景一权重为 $(2, -1)'$ ，甲、乙的综合值分别为 6、5.5；情景二权重为 $(2, -4)'$ ，综合值分别为 0、4。若两个情景等概率，甲的平均值为 3，乙为 4.75，乙更优；若只知道两种情景都有可能，按最差情景保护原则，乙仍更优，因为其最差值为 4，甲为零。

这个例子说明稳健选择可以改变入选对象，但不能证明“保守永远更好”。如果情景二实际极不可能，且避免它的代价很大，过度保守也会损失期望进展。风险偏好不是可由遗传参数自动估计出的生物学常数。决策者必须说明愿意为更稳定的结果放弃多少平均收益。

对于预测误差，可以在候选群体综合育种值向量 $\hat{h}$ 上附加联合预测误差矩阵 V_e 。若贡献向量为 c ，组合预测误差标准差为 $\sqrt{c'V_e c}$ 。在正态近似下，以 $\hat{h}'c - \kappa\sqrt{c'V_e c}$ 作为下置信型目标，可以表达一定程度的风险保护，但 κ 的统计解释取决于模型和选择过程；优化后再将其不加调整地解释成严格覆盖率并不稳妥。尤其不能忽略亲属共享资料引起的误差相关。

近年来的研究开始把完整联合后验带入贡献优化。Ahlander 与 Waldmann (2026) 将条件风险价值用于最优贡献选择，在模拟数据和两种林木数据中评估了下尾收益保护。该研究提供了可借鉴的方法方向，但没有因此证明其在肉羊等家畜中的长期优势。它也提示我们，应同时检验均值收益、尾部风险、近交积累和多世代结果，而不只比较一轮入选名单。

17.5 边界、可行性与透明的取舍

限制、非线性和稳健方法的共同目标，是让优化问题更接近真正的育种决策。然而，更复杂的目标不一定更可信。若基础遗传评定存在环境混杂、目标权重缺乏依据或关系矩阵基准不清，精细的优化器只会更高效地利用这

些错误。实际应用应先核对输入，再讨论求解器。

约束之间还可能冲突。例如要求产出大幅增加、耗料显著下降、成熟体重不变，并同时限制少量亲本的使用次数，在当前遗传协方差和候选群体下可能不可行。不可行是决策信息，而不是必须隐藏的软件失败。应识别造成冲突的约束，给出最小放宽幅度，或说明需要增加哪些信息和候选资源。通过悄悄改变容差得到一个“成功解”，会使结果失去可审查性。

对参数不确定性，至少应提供一种超出单一最佳估计的评估。可以在有依据的参数区间内做情景分析，或者由遗传参数的联合后验产生情景。独立地将每个相关系数随意上下浮动，可能得到并非正半定的协方差矩阵；这类情景在数学上就不可能存在。应采用能保持矩阵合法性的抽样或参数化方式。

最终报告宜回答三个具体问题：在现有假设下选择了谁、哪些约束真正限制了结果、若关键假设改变选择是否仍然稳定。对稳健方案，还应给出与风险中性方案相比放弃了多少预期收益。将价值判断、统计假设和计算结果放在不同层次说明，才便于科研人员、育种者和管理者共同审查。

参数敏感性与预测误差也不能混为一谈。前者涉及模型中的方差、协方差或权重可能取错了值；后者是在这些参数给定后，仍然无法完全确定候选个体的真实育种值。一个拥有很小个体标准误的模型，仍可能因为目标环境改变而系统失准。反之，模型参数估计稳定，也不意味着每只青年种畜都已得到充分观察。可以先固定一组参数分析预测误差，再在外层改变参数情景，避免同一不确定性被重复计入。

在非线性目标中，还需要明确优化的是个体价值的平均，还是群体平均性状的价值。例如，所有动物体重都接近加工最适点，与一半过轻、一半过重但平均值恰好合适，并不是同样的生产结果。一般而言，先对个体计算价值再求平均，与先求性状平均再计算价值不相等。用于惩罚个体偏离的二次损失需要个体分布；用于控制群体均值的约束则只限制平均方向。混淆这两种目标，会使一个数学上合格的方案在生产端无法兑现。

评价稳健方法时，训练阶段用于产生不确定性情景的数据也应与最终检

验阶段分开。若用观察到的未来结果反复调整风险系数，再在同一批个体上报告收益，得到的稳定性会偏乐观。较可信的设计是在历史时期确定模型和风险偏好，在随后时期检验，并同时报告风险中性基线。这样才能区分方法本身的改进与针对某批数据的事后调优。

17.6 限制指数的投影解释与损失分解

17.6.1 为什么约束改变了最优方向

普通指数把目标投影到全部记录张成的线性空间，限制指数则只允许使用满足 $K'b = 0$ 的方向。可以把这些方向看作记录空间中的一个子空间：任何指数沿着它变化，都不会使被限制的目标组合产生预期响应。新的最优指数是目标在这个较小空间中的投影。由于允许利用的方向减少，最优预测方差不会增加，目标响应也不会超过同一条件下的不受限制最优值。

从拉格朗日函数出发，令目标均方误差加上 $2\lambda'K'b$ 。对权重求导得到 $Pb + K\lambda = g$ ，对乘子求导得到 $K'b = 0$ 。先用前式写出 $b = P^{-1}g - P^{-1}K\lambda$ ，再代入约束，即得乘子方程 $K'P^{-1}K\lambda = K'P^{-1}g$ 。这个逐步消元过程揭示了式 (17.3) 的来源，也说明为什么约束之间线性独立很重要。

令普通指数权重为 $b_0 = P^{-1}g$ ，受限权重为 b_R ，二者差为 $d_b = b_0 - b_R$ 。约束投影具有正交性质 $b_R'Pd_b = 0$ ，因此

$$b_0'Pb_0 = b_R'Pb_R + d_b'Pd_b.$$

最后一项衡量因约束而移除的预测变异。它不是实际经济损失的全部表达，但提供一个清楚的统计分解：约束损失取决于原目标方向中有多少信息恰好落在被禁止的方向，而不是简单取决于限制了几个性状。两个看起来同样严格的零响应要求，可能具有完全不同的代价。

17.6.2 教学例：同一个约束可以很便宜，也可以使目标无法改良

设记录协方差为二阶单位矩阵，目标协方差为 $g = (1, 1)'$ ，约束禁止使用第一条记录方向，即 $K = (1, 0)'$ 。普通权重为 $(1, 1)'$ ，受限权重为 $(0, 1)'$ 。

指数标准差从 $\sqrt{2}$ 降为一，在相同选择强度下目标响应变为原来的 $1/\sqrt{2}$ 。如果目标与两条记录联系相近，禁止一条方向就损失一部分信息。

若目标协方差改成 $g = (1, 0)'$ ，同样约束会得到零指数。目标的全部可预测信息都位于被禁止方向，因此剩余空间没有可用于改良目标的信号。此时不能说“选择反应为零所以仍可任意排序”，因为任何额外排序都已依赖目标之外的信息或任意规则。应说明约束与目标在现有资料下冲突，并讨论是否需要新增独立信息、放宽限制或改变目标。

反过来，若普通指数本来就满足 $K'b_0 = 0$ ，施加约束不会改变结果。一个限制写在方案里看起来很重要，却可能在当前参数下完全不活跃。报告时应说明哪些约束实际决定了方案，哪些只是保留的边界。这样能够避免把所有目标变化都归因于某个政策性要求，也有助于识别真正值得增加信息的性状。

Satoh (2024) 从线性代数和几何角度研究限制指数与限制育种值，讨论零改变约束和相对期望改变之间的联系。这类结果有助于把不同名称的方法放到同一空间框架中比较。阅读时仍应核对各文献的约束矩阵、性状空间和评价目标；限制后的遗传方向与原始综合目标不是可以随意互换的量，模拟中也应使用与约束意图一致的评价标准。

17.7 多个约束、冗余约束与可行性

17.7.1 约束数量不等于独立要求数量

如果要求第二性状零响应，同时又要求它的两倍零响应，这两条限制表达同一件事。把它们作为两列放入 K ，会使乘子方程奇异，但不意味着原育种问题不存在解。应识别并删除冗余约束，或者使用适当的秩分解。反之，若两个约束看起来名称不同，却因目标性状定义而高度相关，也可能造成数值不稳定。

约束的有效数量由 K 的秩决定。记录空间只有 m 个独立方向，不可能在不损失全部信息的情况下同时保持任意多个独立组合零响应。若约束秩等于记录维度，唯一满足齐次约束的权重可能是零。增加目标性状列表不会自

动增加可控制的维度，只有新增能够区分这些目标方向的信息才可能扩大可行空间。

这在生产中具有直接含义。若只拥有体重和一个体尺记录，却要求同时精确控制成熟体重、耗料、脂肪、繁殖和抗病五个方向，模型可能无法提供足够独立信息。应先检查信息矩阵的秩与不确定性，而不是把所有要求写入软件后期待自动找到理想答案。不可行有时是信息不足，有时是生物学相关过强，两种原因需要不同改进。

17.7.2 软限制与硬限制

硬限制把某些结果排除在可行域外，软限制则允许偏离并给予代价。例如可以在原目标中加入偏离零响应的二次惩罚，或对超出允许范围的部分收费。软限制通常让权重和响应随惩罚强度连续变化，便于展示取舍，但它不保证限制一定满足。若管理要求具有明确不可逾越的边界，不能用一个未经校核的惩罚系数代替硬约束。

同时，硬限制也可能过于精细。实际参数有误差，要求数学上恰好零响应未必比允许一个小范围更有生产意义。可以根据可接受的生物学变化设定区间，并同时评估参数不确定性下的违背风险。区间宽度应来自生产或保育要求，而不是为了让优化器容易收敛随意决定。将数值容差与生物学容许量分开，是可审查方案的基本条件。

17.7.3 乘子的解释需要尺度一致

拉格朗日乘子反映在当前最优点附近放宽某项约束可能带来的目标改善，常被称为影子价格。然而其数值依赖约束的单位和标准化方式。把约束两边乘以十，乘子通常会除以十，实际问题没有改变。因此，不能比较两个未统一单位的乘子大小，便断言哪一项要求更昂贵。

对育种者更直观的表达，是在一个有意义的变化范围内重新求解，例如允许成熟体重增加一个单位会获得多少产出响应。有限变化结果还能揭示约束活跃状态变化和非线性，通常比只给出局部乘子更容易理解。乘子适合诊断边际取舍，完整方案仍应展示可行的响应前沿和关键场景。

17.8 期望改良量与响应方向

17.8.1 指定方向不等于指定任意大小

有时经济权重难以达成一致，育种计划转而提出希望各性状按某个比例改良。例如希望产出与健康指标分别改善某个标准化幅度。令期望方向为 d ，可以寻找一个指数，使记录对目标的协方差满足 $C'b = d$ ，同时使指数方差最小。在矩阵满秩等适当条件下，解为

$$b = P^{-1}C(C'P^{-1}C)^{-1}d.$$

然而实际选择响应并不等于 d ，而是

$$\Delta u = \frac{id}{\sqrt{d'(C'P^{-1}C)^{-1}d}}.$$

这意味着 d 控制响应方向，整体大小由选择强度和可用信息决定。把 d 全部乘以十，权重也乘以十，但标准化响应不变。因此，“要求每个性状都改良十倍”不能通过把期望向量放大来实现。若希望更大进展，需要更高选择强度、更准信息、更大的遗传变异或更短的时间周期，而不只是修改输入数字。

17.8.2 教学例：均衡响应需要付出什么

设两个记录方差为一且互不相关，目标遗传方差矩阵为单位矩阵，记录对目标协方差为对角矩阵，对角分别为 0.8 和 0.4。第一目标较容易预测，第二目标较难。若要求两个目标响应相同，取 $d = (1, 1)'$ ，得到权重 $(1.25, 2.5)'$ 。较难预测的目标需要更大记录权重，才能实现同等响应方向。

指数标准差约为 2.795085。取 $i = 1.4$ ，两个目标的实际响应均约为 0.500879。若改为等经济权重最大化两目标之和，普通指数权重为 $(0.8, 0.4)'$ ，响应分别约为 1.001758 与 0.250440。均衡方案把一部分容易获得的第一性状进展转移到较难获得的第二性状，目标总和下降，但响应分配更接近指定愿望。

这个例子解释了期望改良量方法的价值与局限。它能表达非货币化的方向要求，却不免除价值判断：为什么两个目标必须相同，为什么要用原始单位而不是遗传标准差，仍需解释。等幅度在不同单位下并不具有客观性。使用期望方向时应说明尺度，并报告为了实现该方向放弃了多少其他可获得的进展。

17.8.3 当期望方向不在信息可达空间中

若 $C'P^{-1}C$ 不满秩，某些目标方向无法被记录独立识别。此时不是简单求逆失败，而是期望向量可能超出当前信息能够支持的范围。可以投影到可达空间、放宽方向要求或补充有针对性的记录，但应说明修改后的目标与原愿望之间的差异。用广义逆得到一个数值答案，不自动保证原期望方向完全满足。

实际设计还应考虑参数误差。期望方向依赖于 C 的估计，若某个目标协方差接近零，为强行实现响应而给其记录极大权重，方案可能非常不稳定。应同时检查权重敏感性、预测校准和外部实现结果。期望改良量指数适合明确表达取舍，但不能让缺乏信息的性状凭空变得可控。

17.9 独立淘汰、门槛与补偿性选择

17.9.1 两类规则表达不同价值观

综合指数允许一个性状的优势补偿另一个性状的不足，而独立淘汰要求每个关键指标都达到门槛。若某种缺陷具有不可接受后果，门槛规则可能合理；若只是一般经济取舍，硬门槛可能浪费可由其他优势补偿的价值。不能只比较两种规则的“严格程度”，应先确定不足是否真的可以补偿。

例如某只公畜的生长优势很大，但繁殖能力低于可实际使用的最低要求，综合经济分数再高也无法兑现。这是可行性门槛。另一方面，若一个体尺只是与产出相关的代理变量，给它设置硬门槛可能排除真正目标优秀的个体。门槛应尽量作用于明确的功能或风险，而不是因为某个表型容易观察就把它当作不可妥协的标准。

17.9.2 同样选留比例下比较才有意义

比较指数选择与独立淘汰时，应保持总选留比例或繁殖规模一致。若一个方案留百分之十，另一个只留百分之一，响应差异同时包含选择强度差异，不能全部归因于规则优劣。多个门槛的联合通过比例还取决于性状相关，不能把各自通过比例简单相加。相关强时，几个门槛可能主要重复筛选同一方向；相关弱时，组合门槛可能急剧减少候选数量。

对独立标准正态的两个记录，若都要求大于零，联合通过比例为四分之一，每个记录在通过群中的均值约为 0.797885。若使用两记录之和的标准化指数并保留上端四分之一，每个记录的预期均值约为 0.898808。在等权线性目标和这些理想条件下，指数利用补偿性取舍获得更高总响应；但它会保留少数一个记录低于零、另一个很高的个体，因此不满足原来的逐项门槛要求。

这个教学结果不是取消所有淘汰标准的理由。它说明效率比较依赖目标定义：若目标确实是两性状之和，硬门槛会损失一些可补偿的优秀组合；若任一性状低于零都不可接受，则这些组合本来就不属于可行方案。统计优化不能替管理者决定哪些风险可以补偿，只能把不同决定的后果算清楚。

17.9.3 门槛附近应考虑测量误差

实际门槛常作用于带误差的记录。一个测量值刚好低于标准的动物，真实功能未必比刚好高于标准者差。可以通过复测、预测概率或不确定性区间处理边界个体，而不是把一次偶然误差变成永久淘汰。若涉及严重功能风险，复测规则和保守边界应预先制定；若涉及一般排名，连续评分可能更有效利用信息。

多个门槛还可能与近交控制发生冲突。过度严格地排除某些家系，可能降低可用遗传多样性。决策流程应先明确不可接受的缺陷，再在可行候选群中优化目标与贡献，同时记录因门槛排除造成的候选覆盖变化。把门槛、指数和配种顺序写清楚，能使不同方法各自承担合适的任务。

17.10 非线性价值与局部线性化

17.10.1 为什么经济权重可能随群体均值变化

线性综合目标假定一个性状的边际价值在考察范围内近似固定。实际价值函数往往带有平台、峰值或交互作用。例如产品质量接近合格边界时，小幅改进可能明显降低降级概率；超过需求范围后，同样改进未必增加收入。繁殖率和存活率共同决定出售头数，一个性状的价值也依赖另一个性状处于什么水平。因此，经济权重通常是某一生产状态附近的局部导数，而不是超越时间、群体和管理制度的自然常数。

设目标状态向量为 x ，实际价值为 $V(x)$ ，以当前状态 x_0 为基点。对较小改变 d ，一阶近似为

$$V(x_0 + d) - V(x_0) \approx a'd.$$

其中 a 是 V 在 x_0 的梯度。这个公式解释了线性指数为什么有用：即使原始价值复杂，在一个足够小而平滑的邻域内，也可以用边际权重给改良方向排序。但若计划跨越很长时间、进展幅度很大，或者候选方案位于价格断点两侧，应重新计算原始价值函数，不能把局部权重无限外推。

例如肉羊教学系统中，出售数量正比于产羔数与存活率的乘积。若基线产羔数较低，提高存活率的绝对收益受到出生数量限制；提高产羔数以后，同样的存活率改良可以保护更多羔羊。第 16 章算例中的交叉项正是这种互补关系。忽略交叉项在小步决策中未必造成严重误差，但多代规划若长期固定同一权重，就可能偏离新的经济最优方向。

17.10.2 二阶项同时涉及均值和方差

令 B 为价值函数的二阶导数矩阵。若遗传结果 U 的条件均值为 m 、条件协方差为 S ，在 m 附近展开并取期望，有

$$E\{V(U) | \mathcal{D}\} \approx V(m) + \frac{1}{2} \text{tr}(BS).$$

这里的 S 应与问题对应：可以是候选真实育种值的预测不确定性，也可以是后代遗传分离造成的分布，二者不应混用。对于凹价值函数，相关方向

的方差通常降低期望价值；对于凸价值函数，方差可能提高期望价值。由此不能笼统声称“风险越小越好”或“变异越大越有利”，应先检查价值曲率及其作用范围。

以最适目标 T 和二次损失 $V(U) = -(U - T)^2$ 为例，期望价值有精确表达式：

$$E\{V(U) | \mathcal{D}\} = -(m - T)^2 - s^2.$$

第 30.3 节的最适值案例已经表明，离最适点较近的预测均值未必带来较小期望损失。另一个不同机制是性状间交互：若价值为 $V(U) = U_1 U_2$ ，则期望价值精确等于 $m_1 m_2 + \text{Cov}(U_1, U_2 | \mathcal{D})$ 。构造甲的条件均值为 (2, 3)、协方差为 -0.4，乙为 (2, 2.9)、协方差为 0.2，两者各性状方差均为一。甲的均值乘积为 6，高于乙的 5.8；期望价值却分别为 5.6 和 6.0，乙更高。两组条件协方差矩阵均正定。这个例子说明，弯曲价值不仅需要各性状标准误，还可能需要它们的联合变化结构。

17.10.3 合格概率与均值排名可能不同

另一类非线性目标是达到门槛的概率。设某候选后代的可交付指标服从均值 m 、标准差 s 的正态分布，最低合格标准为 T ，则合格概率是 $1 - \Phi((T - m)/s)$ 。这里的分布必须说明是否包含环境方差；若顾客按实际产品判级，只使用育种值的预测误差会严重低估产品分布的宽度。

构造两种产品方案：甲的指标均值为 11、标准差为 1，乙均值为 12、标准差为 3，合格线为 10。甲的合格概率约为 0.841345，乙约为 0.747507。乙平均指标更高，却有更大比例落到合格线下。若只对合格产品支付固定收入，甲可能更有利；若超额指标持续获得足够溢价，乙仍可能胜出。因此应计算完整支付规则下的期望净收益，而不是先确定喜欢的统计量再为它寻找经济解释。

当质量有上下双侧边界时，概率是两个累积分布值之差。若不同产品批次存在共同环境冲击，合格事件之间还会相关，全年总收入的波动不等于单件收入方差除以独立样本数。非线性价值把统计建模与经营过程更紧密地连在一起，也要求研究者更清楚地交代随机变量究竟代表动物、产品、批次还

是整个育种计划。

17.11 联合预测误差与组合风险

17.11.1 个体可靠度不能替代协方差矩阵

两个公畜各自的可靠度相同，并不意味着把它们组合使用具有相同风险。如果二者来自同一家系、共享大量参考记录或受到相同模型偏差，其预测误差可能高度相关。设候选真实目标值向量的条件均值为 $\hat{h}$ ，预测误差协方差为 V_e ，贡献向量为 c 。对组合目标 $c'h$ ，条件均值与方差分别为

$$E(c'h | \mathcal{D}) = c'\hat{h},$$

$$\text{Var}(c'h | \mathcal{D}) = c'V_e c.$$

只保存每个候选的标准误，会丢失决定分散使用效果的非对角元素。在大型评价中完整矩阵可能难以存储，可以保存与决策相关的子矩阵、低秩近似或联合抽样，但近似必须保留主要共同误差结构。把所有非对角元素设为零虽然方便，却通常隐含比数据支持更强的独立性假设。

17.11.2 一个可直接手算的分散使用例子

设甲、乙公畜的目标预测均值分别为 10 和 9，预测误差方差都为 4。若只用甲，组合均值为 10、误差标准差为 2；若各使用一半且误差相关为零，组合均值为 9.5、误差方差为 2、标准差约为 1.414214。分散使用降低了平均预测值，却减少了目标不确定性。

若误差相关为 0.75，协方差为 3，平均使用的误差方差变为 3.5、标准差约为 1.870829。平均值仍是 9.5，但分散使用的风险收益显著缩小。若相关为 1 且误差方差相同，等量组合的误差标准差仍为 2，完全不能通过平均消除共同误差。这个例子不涉及实际近交，也不意味着同一家系必然完全相关；它仅说明应根据联合预测分布计算风险。

若决策者采用教学效用 $J(c) = c'\hat{h} - 0.4c'V_e c$ ，只用甲的值为 8.4。在零相关情况下，平均使用的值为 8.7，优于只用甲；在相关为 0.75 时，平均使

用的值为 8.1，低于只用甲。同样的个体均值和可靠度可以导致不同组合选择，区别完全来自误差相关。系数 0.4 具有与目标尺度相关的单位，它表达风险偏好，不能从统计模型自动推导为通用常数。

17.11.3 预测风险、孟德尔抽样与环境风险

组合预测风险是对父母真实遗传水平不知道多少；后代孟德尔抽样则是即使父母真实基因型已知，配子传递仍存在随机性；经营环境风险来自价格、疾病、气候和饲养条件。这些来源有不同的可控方式。增加亲属记录可能减少预测风险，却未必减少每个后代的分离变异；增加后代数量能稳定群体平均分离结果，却不能消除共同市场冲击。

在多代策略评价中，三类风险可能相互作用。例如新环境下某类基因型性能下降，同时价格冲击提高了相关投入成本；这种共同情景不能通过把各方差独立相加来表达。应先写出结果生成过程，再决定哪些量条件独立、哪些量共享同一情景。清楚的分层建模比在最终目标函数中加入一个含义模糊的“风险系数”更重要。

此外，可靠度高不等于没有系统偏差。若训练群与目标群不同，所有候选预测可能在某个方向共同偏离真实值，而常规预测误差矩阵未必包含这种模型失配。风险分析应在模型内不确定性之外，加入合理的外部压力情景，例如环境转移、遗传参数变化和记录定义变更。由数据不能识别的系统风险，不能靠增加小数位数来消除。

17.12 稳健决策与不确定性集合

17.12.1 先区分概率不知道和参数不知道

当未来价格有可信概率分布时，可以计算期望收益或尾部损失；当只有一个合理范围而缺乏可信概率时，稳健优化更适合表达谨慎原则。稳健目标关注在指定不确定性集合内的最不利结果。它不声称最坏情景一定发生，而是要求方案在该集合中保持最低保障。集合过窄可能遗漏真正风险，过宽又会导致过度保守，所以集合的科学依据与优化求解同样重要。

以经济权重不确定为例, 设预期响应向量为 $d(c)$, 经济权重属于集合 A , 稳健收益为

$$W(c) = \min_{a \in A} a' d(c).$$

如果只给每项权重独立上下界, 最坏权重会针对响应符号逐项取不利端点。这种矩形集合容易解释, 却可能组合出经济上不可能同时发生的极端价格。若饲料价格、肉价与副产品价格存在关联, 应使用保持关联的联合情景或经过论证的相关结构。

17.12.2 椭球不确定性产生方向性惩罚

设权重围绕中心 a_0 波动, 可写为 $a = a_0 + Tz$, 其中 $z'z \leq \rho^2$, T 表示不确定性的尺度和关联。由柯西不等式, 对于给定响应 d , 最不利经济值为

$$\min_{z'z \leq \rho^2} (a_0 + Tz)' d = a_0' d - \rho \|T' d\|_2.$$

这不是任意给各性状加罚分, 而是把响应在不确定价格方向上的暴露转化为惩罚。若 d 与不确定性较大的方向对齐, 稳健值下降较多; 若一个方案的净收益由多个相关价格相互抵消, 其风险大小取决于整个 T , 不能只看单个价格方差。

构造二维例子, 中心权重为 $(2, -2)'$, T 为单位矩阵, $\rho = 0.5$ 。方案甲的响应为 $(4, 2)'$, 中心价值为 4, 稳健价值约为 1.763932; 方案乙的响应为 $(3, 0.5)'$, 中心价值为 5, 稳健价值约为 3.479309。乙在中心和此集合最坏情景下都更好。这个结果只涉及已给定的两个方案, 不能据此证明乙在所有未考察方案中最优。

17.12.3 稳健性也包括遗传参数误设

指数中的 P 、 C 和目标协方差同样可能不确定。若先按估计参数求权重, 再在不同参数情景下计算响应, 得到的是固定决策的压力测试; 若每个情景都重新优化并取最佳结果, 得到的则是假设提前知道真实参数时的表现。后者常显著乐观, 不能用于评价今天必须作出的同一个选择。

遗传参数情景还必须保持联合协方差合法。例如随意把某个遗传相关改为很大正值，而其余元素不变，可能使矩阵不再半正定；此时算出的“极端响应”没有对应的随机模型。可以通过协方差矩阵的分解参数、合理先验或从实际估计的联合不确定性中抽样来保持可行。敏感性分析的目标是暴露可信风险，而不是制造数学上不成立的惊险场景。

稳健方案通常以损失部分中心情景收益为代价，换取较小最坏损失。报告时应并列展示中心表现、最坏表现、限制是否满足和保守程度参数的变化。仅报告稳健目标值会遮住代价，仅报告中心收益又无法解释为什么选择了较低排名个体。好的决策报告让取舍可见，而不是把取舍藏在算法名称后面。

17.12.4 用误设后的实际表现衡量稳健性

稳健指数的检验应把设计参数与真实生成参数分开。先按一组估计协方差得到固定权重，再在另一组合法协方差下计算其真实目标相关和预期响应。如果只在设计参数下比较指数方差，实际上没有检验参数误设。对线性指数，给定真实协方差 P_* 、 C_* 时，实际目标响应为 $ib'C_*a/\sqrt{b'P_*b}$ 。这个表达允许研究者明确回答：原来预计最有价值的方向发生变化后，今天采用的权重还剩多少效果。

压力测试的强度不宜只用“相关改变百分之十”来定义。接近零的相关在相同相对变化下几乎没有改变，而接近边界的相关稍作绝对变化就可能影响矩阵条件数。可以围绕参数估计的标准误、跨环境已观察到的差异或者专家给出的合理范围建立情景，同时报告每个情景的具体参数。若根本没有依据，应将其标为探索性分析，而不把某个任意范围包装成可信区间。

方案之间的稳健性也应在相同信息预算下比较。一个新方法若使用更多记录、更强先验或额外环境信息，表现改善不能全部归于优化准则。理想比较应分别控制资料、预测模型和决策规则，逐步考察各部分贡献。这样即使最后方案没有胜出，也能知道应改进测定设计、模型校准还是目标设定，避免以一次总分胜负掩盖真正原因。

17.13 尾部风险与条件风险价值

17.13.1 平均收益可能掩盖少数严重失败

假设两个育种方案平均收益相同，一个在大多数环境中稳定获利，另一个通常略好但在特定疾病或市场状态下出现很大损失。若失败会影响育种群存续，仅比较平均收益可能不够。尾部风险指标专门描述坏结果的一部分，却需要明确坏结果的方向、概率以及损失单位。把“较低遗传进展”和“经营亏损”混为同一个尾部，容易使目标函数失去可解释性。

令损失随机变量为 L ，高分位水平为 α 。沿用 Rockafellar 与 Uryasev (2000) 的思路，条件风险价值的一种通用优化表达是

$$CVaR_{\alpha}(L) = \min_{\eta} \left\{ \eta + \frac{E[(L - \eta)_+]}{1 - \alpha} \right\}.$$

其中 $(x)_+$ 表示 x 与零中的较大者。该表达也适用于离散分布，并妥善处理分位点处的概率质量。对连续分布，可以把它理解为最坏 $1 - \alpha$ 比例中的平均损失。研究中应说明采用的是损失的上尾，还是收益下尾的相应变换，否则相同符号可能代表相反优化方向。

17.13.2 四情景教学例

考虑四个等概率情景，方案甲收益为 12, 12, 12, -4，方案乙为 7, 7, 7, 7。甲的平均收益为 8，高于乙的 7；但甲最差四分之一收益为 -4，乙为 7。以损失等于负收益、 $\alpha = 0.75$ 计算，甲的条件风险价值为 4，乙为 -7。负损失表示仍有正收益，因此不应为了让指标看起来直观而把负值截为零。

若使用目标“平均收益减去 λ 倍条件风险价值”，甲的目标为 $8 - 4\lambda$ ，乙为 $7 + 7\lambda$ 。两者在 $\lambda = 1/11$ 时相同；风险厌恶参数更大时偏向乙。这个阈值揭示了决策切换的条件，却不替代对 λ 的讨论。若极端失败的代价具有不可补偿性，应直接设置损失上限或存续约束，而不是用一个很大的但含义不明的惩罚系数。

四个等概率情景只是说明计算原理。实际尾部估计需要足够多且相关结构可信的样本；当关注很罕见的失败时，少量模拟中可能根本没有出现该事

件。应检查尾部样本量、情景生成机制和估计稳定性。把少量常见情景平均后称为“极端风险控制”，会给决策者错误的安全感。

17.13.3 从联合后验到育种组合

Ahlinder 与 Waldmann (2026) 把联合后验抽样与风险敏感的最优贡献选择结合，讨论了预测不确定性如何改变育种决策。该研究提供的方法学启发是：候选值不是一组互相独立的点估计，可以在同一次后验抽样中保留它们的联合变化，再评价一个固定贡献方案的收益分布。相关研究使用模拟及林木资料，其结论不能直接等同于畜牧群体已经实现的多代收益。

在抽样应用中，每一个后验样本代表一组可能同时成立的真实遗传值。应让所有候选在同一个样本索引下形成组合，不能分别打乱个体样本后再相加；后者会破坏联合相关，可能夸大分散使用效果。对每个样本算组合价值，再由这些值计算均值、分位数或尾部指标，才能使风险计算与原始模型一致。

还应区分“优化一次，然后在全部样本中评价”与“每个样本优化一次，再平均最优值”。后者描述拥有完全信息的理想上界，并不是一个今天可执行的贡献方案。研究报告若展示理想上界，应明确其用途是衡量信息价值，而非声称现实育种计划已经获得这些收益。

17.14 概率约束与可兑现的承诺

17.14.1 从平均不恶化到高概率不恶化

期望响应满足零限制，并不表示每次实现都不恶化。如果一个健康性状的预测平均改变为零，但不确定性很大，那么实际向坏方向变化的概率仍可能接近一半。期望约束回答平均方向，概率约束回答失败机会，两者适用的管理承诺不同。决策者应在设定限制时说明要求的是长期平均、某一代实际群体，还是每个个体的最低功能。

假设某组合在不利指标上的真实改变 D 条件服从均值 m_D 、标准差 s_D 的正态分布，要求不超过上限 d_{max} 的概率至少为 $1 - \alpha$ ，则等价条件为

$$m_D + z_{1-\alpha} s_D \leq d_{max}.$$

该条件依赖正态分布假设以及 s_D 所包含的不确定性。若分布偏斜、有厚尾或存在模型失配,直接使用正态分位数可能过于乐观;可以用经验后验分位数或可信的情景近似,并报告其模拟误差。

17.14.2 一个健康限制的数值说明

设教学性状以不利方向为正,容许上限为零,要求达到百分之九十五的单侧保障。方案甲的预测均值为 -0.20 , 标准差为 0.15 ; 方案乙均值为 -0.15 , 标准差为 0.05 。甲预测改善更多,但正态近似下其上侧界限为 $-0.20 + 1.644854 \times 0.15 = 0.046728$, 不能达到该保障。乙的上侧界限约为 -0.067757 , 满足要求。

这不是认为甲一定更差,而是说明甲的预测证据不足以支持同样强的承诺。如果甲的额外潜力很重要,可以增加记录、降低使用比例或调整配对后重新评价。概率约束使研究者明确区分“看起来有利”与“在给定模型和置信要求下有足够把握有利”。

若同时约束多个健康和繁殖指标,分别给每项百分之九十五保障,不意味着整体也有百分之九十五保障。失败事件可能重叠,也可能累积。可以直接计算联合概率,或者用保守的误差分配保证整体水平。后一种方法容易实现,但可能牺牲较多收益;应说明这种保守性来自方法设计,而不是数据本身证明所有组合都危险。

17.14.3 不要承诺模型没有覆盖的风险

概率陈述总是相对于信息和模型的。把记录误差、参数估计误差和环境转移误差全部忽略,再给出很高的成功概率,不能形成可靠承诺。特别是低发生率疾病,如果参考群中病例少、诊断定义变化或环境暴露不足,预测分布可能严重低估风险。此时应优先改善资料和验证设计,而不是通过更复杂的优化器提高名义概率。

可执行方案还需要明确监测规则。若下一代实际表现持续越过预设警戒线,应怎样暂停某些父本使用、补充检测或更新权重?预先规定这些响应,能把概率约束从一次性计算变成持续管理制度。统计保证不能替代后续观察;

它的价值恰恰在于说明观察应集中在哪些最可能改变决策的地方。

17.15 先获取信息还是立即选择

17.15.1 信息价值来自改变决策的机会

育种者经常面临这样的选择：现在使用预测排名最高的公畜，还是等待补充检测后再决定。新信息能够减少不确定性，却需要时间和费用，甚至错过一个繁殖季。因此信息价值不是可靠度增加多少的同义词，而是信息到来后有机会调整行动所带来的期望价值增量。若无论结果怎样都必须使用同一个候选，那么一次昂贵检测即使显著提高准确度，其直接选择价值也可能很小。

设当前可选行动为 c ，未知状态为 θ ，决策价值为 $V(c, \theta)$ ，新信息为 Z 。忽略费用和延迟时，样本信息的期望价值为

$$EVSI = E_Z \left[\max_c E\{V(c, \theta) | Z\} \right] - \max_c E\{V(c, \theta)\}.$$

其中外层期望必须在看到新信息之前计算。先观察某个特别有利的检测结果，再把该结果带来的收益称为检测的期望价值，会产生事后选择偏差。实际净价值还需减去检测费用、延迟损失与实施成本；若新信息同时改善将来多个周期的决策，这些后续价值也应计入一致的时间框架。

17.15.2 两候选、两状态的完整例子

设公畜甲的真实使用价值只有两种可能：以相同概率取 14 或 6；公畜乙的使用价值确定为 9。没有额外信息时，甲的期望值为 10，因此选甲。若可以免费获得甲状态的完全信息，高状态选择甲得 14，低状态改选乙得 9，期望价值为 11.5，完全信息的价值为 1.5。这个上界帮助判断检测报价是否可能合理：若只考虑这一次决策且费用超过 1.5，任何不完全检测都不可能仅靠此次选择收益收回成本。

现在假设检测在两种状态下都以 0.8 的概率给出正确信号。由于先验对称，阳性和阴性信号各占一半。阳性后甲的后验期望值为 $0.8 \times 14 + 0.2 \times 6 =$

12.4, 仍选甲; 阴性后为 $0.2 \times 14 + 0.8 \times 6 = 7.6$, 改选乙。检测前期望价值为 $(12.4 + 9)/2 = 10.7$, 所以样本信息价值为 0.7。

若检测费用为 0.4, 且没有其他损失, 其净价值为 0.3; 若延迟又损失 0.5, 净价值变为 -0.2, 立即选择更有利。这里所有金额都是构造的统一价值单位, 不代表任何实际检测报价。例子的重点是把准确度、决策切换、成本和时间连接起来, 而不是用检测的统计性能单独决定是否购买。

17.15.3 分阶段测定与停止规则

很多育种计划先用低成本资料粗筛, 再对少量候选进行高成本测定。分阶段策略之所以有效, 是因为昂贵信息主要用于仍可能改变最终选择的边界候选。一个明显落后的候选通常无需继续投入, 而一个明显优秀且已满足风险限制的候选也未必需要相同强度的追加验证。不过, 如果追加记录有维护参考群覆盖或识别新缺陷的公共价值, 不能仅按本轮个体排名来分配。

停止规则应在研究开始前明确。例如, 当某候选相对于可用替代者的期望增益小于追加检测与等待成本时停止; 或者, 当关键健康门槛的失败概率已经足够低时进入使用阶段。规则不必复杂, 但必须考虑未来记录可能带来的正反两种结果。只在看到不利结果后临时延长试验, 而在看到有利结果时立即结束, 会扭曲最终证据。

分阶段选择还改变资料分布。第二阶段记录只来自第一阶段通过者, 若分析时忽略第一阶段使用的信息, 可能发生选择偏差。正确做法是在可行范围内保留和利用决定进入第二阶段的记录, 或者显式建模选拔过程。运营上“只给好个体测定”是合理资源配置, 统计上却意味着不能把后续资料当作原群体随机样本。

17.15.4 学习与利用之间的跨代取舍

立即大量使用当前最优家系有助于短期提高均值, 但可能减少对其他遗传背景的了解。保留少量探索性使用, 可以获得不同家系或环境下的新记录, 从而改进未来选择。这里的探索价值与遗传多样性价值有关却不完全相同: 一个遗传上独特的候选可能提供重要信息, 也可能由于记录极少而暂时难以

证明其潜力。

探索应有明确设计，例如给某个证据不足但合理有希望的家系安排受控数量的后代，并设置记录完整、环境可比的评价方案。它不是把所有低排名候选平均保留，也不是用“未来可能有用”替任何选择辩护。长期决策需要估计学习可能改变哪些后续行动，并把探索成本与未来收益放在同一模型中。对于难以准确量化的部分，可以提供不同探索比例的情景结果而不假装存在唯一精确答案。

17.16 多目标前沿与决策图的解释

17.16.1 支配关系先于综合打分

当收益、健康、排放和遗传多样性都受到关注时，直接给出一个总分可能掩盖利益分配。帕累托支配提供了较弱却清晰的比较：如果方案甲在所有关注指标上都不差于乙，并至少在一项上严格更好，乙被甲支配。删除被支配方案不需要确定各指标的交换比率；剩余的非支配方案才构成需要价值判断的取舍集合。

例如四个教学方案的经济收益与环境负担分别为甲(10,8)、乙(9,5)、丙(8,6)、丁(7,3)，其中收益越高越好、负担越低越好。乙在收益与负担两项上都优于丙，因此丙可被排除；甲、乙、丁互不支配。选择哪一个，取决于环境负担的价值或约束。若只公布综合分数而不公布原始两项，读者难以判断排名来自性能本身还是权重设定。

加入第三个指标以后，二维图上的支配可能消失。例如丙的健康风险若明显低于乙，两者在完整目标空间中未必存在支配关系。因此每一幅前沿图都应说明纳入哪些指标、遗漏哪些重要约束，以及不同方案是否在同一个繁殖规模和成本边界下比较。图形越直观，越需要避免用简化画面替代完整问题。

17.16.2 加权和方法有用但并非总能找到全部前沿

通过改变经济或偏好权重，可以生成一系列最优方案，观察响应如何沿前沿移动。在连续凸问题中，加权和是方便的方法；在含整数使用次数、离散家系、固定检测费用或非线性价值时，可行集合可能非凸，一部分非支配方案未必能被任何简单正权重加权和选中。这时可使用逐个固定某项最低要求的约束方法，或者直接枚举有限可行方案。

对育种决策尤其要注意，贡献比例连续可取并不保证最终配种方案连续。理论贡献 0.073 可能需要转换为整数配种次数，候选数量小或使用规模小的时候，取整会使原来的健康、近交或成本限制发生变化。因此应在最终可实施方案上重新计算目标和约束，而不能只展示连续松弛问题的漂亮前沿。

前沿附近还可能有大量表现几乎相同的方案。若收益差异远小于参数不确定性，选择实施更简单、记录更完整或家系覆盖更稳的方案可能合理。此时应报告近似最优区间，而不是把小数点后第三位的优势描写成科学上的决定性差别。数值求解误差与模型不确定性是不同层次的误差，都应与实际差异相比较。

17.16.3 横轴纵轴应使用可解释单位

以标准化分数画图便于比较不同性状，却不直接告诉生产者一代以后会发生什么。教学和实践可以同时展示遗传标准差单位与生产单位，例如每代产量变化、疾病风险百分点变化和每天排放量变化。若图中使用成本惩罚系数作为横轴，应另给出它对应的实际响应，否则读者只看到算法参数而看不到育种后果。

误差带也需要说明来源。对一条预计响应曲线，带状区域可能来自遗传参数估计误差、个体育种值预测误差或模拟重复间随机波动。把这些不同来源混合成一条未标注的灰带，会使“可信区间”失去明确含义。若同时考虑多种来源，应说明抽样顺序和条件结构，并避免把单点区间解释为整条曲线同时覆盖的保证。

前沿图适合用来组织讨论，却不能单独证明方案公平或可持续。一个收

益更高的方案可能把成本转移到另一个生产环节；一个平均排放更低的方案可能增加脆弱环境中的失败风险。应在明确系统边界后作图，并把不能由两个坐标表达的重要限制放在图注或伴随说明中。

17.17 一个从目标讨论到实施复核的完整案例

17.17.1 设定候选策略与共同评价边界

构造三个可行育种策略，用四个等概率未来情景评价其净价值。甲在四种情景下的价值为 16, 12, 8, -4；乙为 11, 10, 9, 6；丙为 9, 9, 8, 8。这些值已经在同一价格单位和同一实施规模下扣除了测定与繁殖成本。我们暂时假定各策略均满足功能性门槛，再依次考察平均表现、尾部表现和风险偏好。它们不是来自真实场的预测，目的是展示一个可以复算的决策过程。

甲的平均值为 8，乙为 9，丙为 8.5。按总体情景概率计算，方差分别为 56, 3.5, 0.25。甲既没有最高平均收益，又有最大的情景波动；但它在最好情景中获得 16，如果只展示最有利场景会显得十分吸引人。这个简单例子说明，选择宣传材料中的最高结果与评价一个事前决策是两回事。

在最坏四分之一情景下，收益分别为 -4, 6, 8。乙提供最高期望值，丙提供最好的尾部保障，两者之间存在清楚的取舍。对目标“期望收益减去 λ 倍收益方差”，乙的值为 $9 - 3.5\lambda$ ，丙为 $8.5 - 0.25\lambda$ 。当 $\lambda = 2/13$ 时二者相同；更大的方差惩罚偏向丙。由于价值尺度变化会改变方差尺度，使用该阈值前必须统一单位。

17.17.2 检查限制与组合的可行性

现在增加一个健康限制：三策略对应不利健康指标的预测改变分别为 0.02, -0.03, -0.01，上限为零。若采用平均不恶化限制，甲被排除，乙与丙保留。若这些改变带有预测误差，还应按上一节的概率原则判断保障程度；没有标准误和联合分布，不能直接宣称乙必然比丙安全。

假设允许把乙与丙按比例混合，且四情景中的价值能按贡献线性合成。令乙比例为 w ，则混合均值为 $8.5 + 0.5w$ 。乙与丙的情景协方差为 0.75，混

合方差为

$$V(w) = 0.25 + w + 2.25w^2.$$

这条曲线说明混合并不总能降低相对于所有端点的风险：因为丙已非常稳定，加入乙会提高均值，也会提高方差。若风险惩罚系数取 0.2，目标为 $8.5 + 0.5w - 0.2V(w)$ ，其内部最优解为 $w = 1/3$ ，即乙占三分之一、丙占三分之二。此时均值约为 8.666667，方差约为 0.833333，目标值为 8.5，高于只用乙的 8.3 和只用丙的 8.45。

线性混合假设在实际应用中必须验证。若两种策略共享固定成本、使用不同繁殖设施，或者存在互相影响的疾病风险，混合价值未必等于端点价值的加权平均。若策略实际上代表两个互斥育种目标而非可组合贡献，计算一个分数混合也可能没有操作意义。一个数学上漂亮的内部解，只有对应清楚的实际动作才有价值。

17.17.3 记录决策理由而非只保存最优结果

最终报告应写明：采用什么系统边界、哪些情景、各情景为何赋予这些概率、哪些限制是硬要求、哪些只是偏好，以及哪项不确定性最可能改变结论。还应保存被排除方案及原因。这样在未来价格或健康证据变化时，可以知道需要更新的是输入、约束还是价值判断，而不必从头重新争论所有问题。

对上述教学案例，一个合理结论可能是选择混合方案，并在下一轮重点收集能够区分乙与丙收益差异的信息。另一个同样合理的治理选择可能要求最坏情景收益至少为 8，从而选择丙。两种结论表达不同承诺，并非其中一个必然计算错误。学术分析的责任是证明每个结论与其前提一致，并把前提暴露给真正承担后果的人。

实施以后，应按照预先定义的指标监测实际表现，同时考虑随机波动。一次不利结果不自动否定期望收益较高的策略；长期系统偏离则可能表明参数、环境或模型结构需要更新。尤其在育种这样反馈缓慢的领域，保持审计记录与版本信息，是连接统计模型、实际决策和后续学习的重要环节。

17.17.4 数学最优之外的实施审计

完整决策还需要检查优化对象是否对应实际可控制的行动。育种值排序可以控制入选名单，最优贡献可以控制平均遗传份额，配种分配可以控制父母组合，但任何一个步骤都不能直接保证每头后代的实际表现。如果把群体平均限制解释为个体保证，或者把父本精液订单比例当作最终出生后代比例，就会在模型与执行之间留下缺口。受胎率、淘汰、性别比例和胚胎存活都会改变实际贡献，必须通过后续记录重新计算。

实施审计应至少保留候选身份、评价日期、指数版本、目标权重、约束版本、计划贡献和实现贡献。对于特殊候选的人工调整，也应记录调整理由及其对目标和限制的影响。人工判断不一定低于模型判断；问题在于它是否基于模型未覆盖的真实信息，以及是否被纳入可追踪的计算。无记录的临时调整会使事后评价无法区分模型不足和执行偏离。

当不同生产环节承担不同成本时，单一净收益目标还可能缺少执行激励。例如种畜提供方承担新性状测定费用，而商品生产者获得饲料节省收益；若双方没有合适的定价或合作安排，社会总体有利的指数也未必得到采用。这里需要分析收益归属与交易条件，而不是继续微调统计权重。经济目标的科学性包含系统边界和激励结构，不能仅以一个总利润导数代表所有参与者的现实选择。

最后应明确何时重新制定目标。每一批新记录都微调经济权重，可能造成目标漂移、难以解释的排名变化和用户信任下降；多年完全不调整，则可能脱离生产需求。可以定期评审主要目标，并在价格制度、健康风险或产品标准发生实质变化时启动特别修订。每次修订保留旧版与新版的并行结果，解释排名变化来自新证据还是新价值判断。这样的制度安排使统计优化成为持续、可理解的育种决策过程。

17.18 不等式限制的活跃集合与最优性证书

零响应限制可以一次投影求解，但“最多增加一点”或“至少保留某种能力”通常表现为不等式。此时首先要区分哪些限制真正卡住最优解，哪些

虽然列在方案中却没有影响。活跃集合方法把这一判断转化为可检验的代数条件。它还提供一张最优性证书，使研究者能够独立核对求解器输出，而不是只接受“求解成功”的提示。

先研究一个尺度已经明确的二次问题。令 $g = Ca$, P 正定, K 为 $m \times k$ 限制矩阵, h 为 k 维上界向量:

$$\min_b f(b) = \frac{1}{2} b' P b - g' b, \quad K' b \leq h.$$

此处 f 是目标均方预测误差去掉常数后的一半。 K 与 h 必须说明是在限制系数、协方差, 还是经另外处理后的响应。对于齐次零响应限制, 可直接取 $K = CL$, $h = 0$; 对于非零遗传响应, 不能把原始响应数字直接填进 h , 因为真实响应还需要除以指数标准差。下一节专门解决这个尺度问题。

定义拉格朗日函数 $f(b) + \lambda'(K'b - h)$ 。可行且满足适当约束资格条件时, 最优点满足

$$Pb - g + K\lambda = 0, \quad K'b \leq h,$$

$$\lambda \geq 0, \quad \lambda_j (k'_j b - h_j) = 0 \quad \text{对每个 } j.$$

第一式检查目标梯度与限制梯度是否平衡; 第二行说明只有贴住边界的限制才可能有正乘子。对于这个严格凸问题, 这些条件不只必要, 而且足以确认唯一的最优权重。乘子未必唯一, 因为可能存在冗余约束; 但只要 P 正定, 可行域非空, 最优权重本身仍唯一。

假定活跃列组成 K_A , 对应上界为 h_A , 其列线性独立。由驻点式消去 b 可得

$$M_A = K'_A P^{-1} K_A, \quad \lambda_A = M_A^{-1} (K'_A P^{-1} g - h_A),$$

$$b_A = P^{-1} g - P^{-1} K_A \lambda_A.$$

计算这个候选解后, 必须检查 $\lambda_A \geq 0$ 与全部非活跃限制是否满足。若某个活跃乘子为负, 它说明该边界以错误方向限制了目标, 不能保留为最优活跃集; 若遗漏的限制被违反, 就必须将其加入。小问题可枚举活跃集合, 大问题使用专门算法, 但最终检查完全相同。

教学例取 $P = \text{diag}(2, 1)$ 、 $g = (2, 1)'$ ，限制为 $b_2 \leq 0.3$ 。这里它被明确解释为已定尺度下的系数上限，而不是遗传响应上限。无限制权重为 $(1, 1)'$ ；上限活跃后，权重为 $(1, 0.3)'$ 、乘子为 0.7。目标 f 由 -1.5 升至 -1.255 ，增加 0.245。这个数是半均方误差目标的损失，完整均方误差增加 0.49，不能混用两种尺度。

固定活跃集时，最优值对上界的导数为

$$\frac{\partial f^*}{\partial h_A} = -\lambda_A, \quad \frac{\partial^2 f^*}{\partial h_A \partial h'_A} = M_A^{-1}.$$

因此，把上限从 0.3 放宽到 0.4，一阶近似目标改善 0.07，准确改善为 0.065；差额来自正的二阶曲率。当上限达到一以后，约束不再活跃，乘子变为零，不能继续按原斜率计算收益。影子价格适合局部变化，完整取舍仍需要追踪活跃集切换。

若再加 $b_1 \leq 0.8$ ，第二个上限也活跃，得到 $(0.8, 0.3)'$ ，两乘子分别为 0.4 与 0.7。这不表示第二约束必定更重要，因为两系数的记录单位可能不同。对有实际意义的放宽幅度计算收益变化，直接比较乘子数值更稳妥。把限制乘以十而上界也乘以十，问题不变，乘子却会缩小十倍。

可行性检查与最优性检查应分别报告。若限制互相冲突，梯度残差很小也不能使结果变得可行；若约束满足而驻点残差很大，方案可能只是一个合法但低效的点。实际计算可记录最大原始约束违反量、最负乘子、互补残差和驻点残差，并按变量尺度归一化。容差是数值精度要求，不应被拿来偷偷放宽生物学上限。

最优性还可以用原问题与对偶问题的差距独立核验。对给定非负乘子最小化拉格朗日函数，得到对偶下界

$$q(\lambda) = -\frac{1}{2}(g - K\lambda)'P^{-1}(g - K\lambda) - \lambda'h.$$

对任一可行 b 和 $\lambda \geq 0$ ，令 $\bar{b} = P^{-1}(g - K\lambda)$ ，有

$$f(b) - q(\lambda) = \frac{1}{2}(b - \bar{b})'P(b - \bar{b}) + \lambda'(h - K'b) \geq 0.$$

第一项是驻点不满足造成的差距，第二项是互补条件不满足造成的差距。两项都很小时，就获得一个可量化的全局误差界，而不是只知道迭代变

化很小。一个算法可能因为步长设置过小而几乎不再移动，却仍远离最优；原始与对偶差距能够识别这种停滞。

例如前面的单上限算例中，代入 $b = (1, 0.3)'$ 、 $\lambda = 0.7$ ，两项都为零。若误把乘子取成零，约束仍满足，但第一项揭示该权重不满足无约束驻点。这样的核验适合写进遗传决策计算流程，特别是在求解器、变量单位或约束数量改变以后。它不需要重新相信另一个优化软件，而只需要代入明确的矩阵表达。

17.19 非零响应限制的白化空间解

非零响应的关键是指数尺度不具有生物意义。同一组权重乘十，指数标准差也乘十，选择响应保持不变。因而在对非零响应设限前，最好先消除这个自由尺度。假设 P 正定，定义对称平方根并令

$$w = \frac{P^{1/2}b}{\sqrt{b'Pb}}, \quad w'w = 1, \quad \tilde{g} = P^{-1/2}g.$$

取需要控制的 $q \times k$ 性状组合矩阵 L ，并令 $D = P^{-1/2}CL$ 。要求这些组合的响应等于给定向量 d ，相当于

$$D'w = h, \quad h = d/i.$$

在这个坐标系中，指数方差归一化为一，目标响应为 $i\tilde{g}'w$ 。注意 i 必须与真正的选留比例和分数分布一致；若不同方案使用不同选择强度，下面的几何比较就不再是同一个问题。

先求满足线性等式的最小长度解。假定 D 列满秩，定义

$$w_0 = D(D'D)^{-1}h, \quad N = I - D(D'D)^{-1}D'.$$

N 是投影到 D' 零空间的正交算子。任何满足等式的向量都可写为 $w = w_0 + Nz$ ，且两项正交，因此

$$w'w = \|w_0\|^2 + \|Nz\|^2.$$

如果 $\|w_0\| > 1$, 要求的响应超过可用信息和选择强度支持的范围, 问题不可行。如果 $\|w_0\| \leq 1$ 且零空间非平凡, 就有剩余长度可以分配给目标; 在 $N\tilde{g} \neq 0$ 时, 最优方向为

$$w^* = w_0 + \sqrt{1 - \|w_0\|^2} \frac{N\tilde{g}}{\|N\tilde{g}\|}.$$

$$R^* = i \left\{ \tilde{g}' w_0 + \sqrt{1 - \|w_0\|^2} \|N\tilde{g}\| \right\}.$$

这个解把响应分成“为满足指定变化必须付出的方向”与“剩余空间中的最有利方向”。若 $N\tilde{g} = 0$, 剩余长度不影响目标, 最优解可能不唯一; 若零空间为空, 必须恰有 $\|w_0\| = 1$ 才满足单位长度, 不能仅凭小于一就宣布可行。这样的退化情形往往对应控制要求已经耗尽全部记录自由度。

数值例取 $P = I$, $\tilde{g} = (2, 1)'$, 只规定第二方向的响应, $i = 1$ 。令 $w_2 = d$, 便有

$$w^* = \left(\sqrt{1 - d^2}, d \right)', \quad R(d) = 2\sqrt{1 - d^2} + d, \quad |d| \leq 1.$$

要求第二方向零响应时, 目标响应为二; 允许 $d = 0.3$ 时, 权重方向约为 $(0.953939, 0.3)'$, 目标为 2.207878; 指定 $d = 0.6$ 时目标为 2.2。无限制最优第二方向为 $1/\sqrt{5} \approx 0.447214$ 。这说明“允许更多第二性状变化”与“强制它达到更大变化”不同: 前者扩张可行域, 后者可能把方案推过最优点, 使综合价值下降。

在内部区间, 响应曲线的导数为

$$R'(d) = 1 - \frac{2d}{\sqrt{1 - d^2}}, \quad R''(d) = -\frac{2}{(1 - d^2)^{3/2}}.$$

靠近极限 $|d| = 1$ 时, 剩余自由空间趋零, 边际代价急剧变化。单独给出一个边界解而不展示附近曲率, 容易让使用者低估要求再严格一点的成本。参数估计误差也会在这里产生更明显的可行性风险, 因此不宜把理论极限当作毫无余量的生产承诺。

有时为方便计算, 把 $w'w = 1$ 放松为 $w'w \leq 1$, 再称所得问题为同一选择问题。这个做法必须检验最优解是否达到边界。一个一维反例是 $0 \leq w \leq 0.2$:

单位球松弛有解，但单位长度要求 $w = 1$ ，完全不可行。若松弛解长度小于一，事后归一化可能违反非零响应上限。对于齐次约束、存在正目标改良方向的情况，缩放通常能证明边界饱和；非齐次限制没有这种自动保证。

对于非零不等式，等式公式仍可用于计算某个候选活跃集，但必须先检查无限制单位方向是否已经满足上限。以上例为例，若要求第二响应不超过零点六，无限制方向的第二分量约为零点四四七，原本就可行，因此最优综合响应仍为根号五。强行令第二分量等于零点六，反而把“不超过”误改成“必须达到”，损失了可以保留的收益。

多个限制并存时，可以在白化空间中枚举可能贴住的边界，用剩余球面上的投影求候选方向，再检查未贴住的全部不等式。边界之间可能发生切换，所得响应曲线可以分段光滑。对长期目标更新，保存这些切换位置比保存某一个参数值下的权重更有用，因为它们指出何时一个目前无影响的健康或资源要求会开始限制进展。

17.20 遗传联系不确定时的稳健零响应限制

限制指数往往使用估计的遗传协方差。若某个被限制性状的目标协方差列略有误差，名义零响应可能在实际总体中变为正值。稳健限制要求同一个指数在一组可信参数下都满足方向要求。它与重新对每一种参数求一个最优指数不同：今天必须采用同一权重，不能预知哪组参数为真。

设限制方向的记录协方差列为 $k = k_0 + Tz$ ，其中 T 为 $m \times r$ 矩阵， $\|z\| \leq \rho$ ，要求所有情景下 $k'b \leq 0$ 。最大化这个线性表达可得

$$\sup_{\|z\| \leq \rho} k'b = k'_0 b + \rho \|T'b\|,$$

$$k'_0 b + \rho \|T'b\| \leq 0.$$

这是一个齐次凸锥约束，可以表达相关系数误差的方向结构。球形半径不是一个自动的置信水平；若要给概率解释，必须说明 T 、 ρ 如何由联合参数估计得到。特别是仅把每个遗传相关独立上下浮动，可能产生不合法联合协方差，不能作为真实生物学情景。

在 P 和目标协方差 g 已知时, 可通过凸二次问题求最优稳健方向:

$$\min_b \left\{ \frac{1}{2} b' P b - g' b \right\}, \quad b \in \mathcal{K},$$

其中 $\mathcal{K}$ 是上述稳健限制形成的锥。为什么这个不含单位方差的目标仍能找到最大标准化响应? 沿任一可行射线 $b = tw$ 、 $t \geq 0$, 有

$$\max_{t \geq 0} \{ t g' w - \frac{1}{2} t^2 w' P w \} = \frac{\{\max(g' w, 0)\}^2}{2 w' P w}.$$

只要存在正改良方向, 最大化右侧就等价于最大化 $g' w / \sqrt{w' P w}$ 。因此齐次性恢复了尺度等价。若最优结果为零, 则所有可行方向都没有正目标改良, 不能再将零权重标准化, 也不能宣布算法“找到了一个可靠但不改良的指数”。

二维例取 $P = I$ 、 $g = (2, 1)'$, 名义限制只要求 $b_2 \leq 0$; 现在假定限制协方差第一分量存在正负 0.2 的不确定性。稳健条件为

$$b_2 + 0.2 |b_1| \leq 0.$$

最优正改良射线满足 $b_2 = -0.2b_1$, 归一化方向与目标响应为

$$w^* = \frac{(1, -0.2)'}{\sqrt{1.04}}, \quad R^* = \frac{1.8}{\sqrt{1.04}} \approx 1.765045.$$

相比名义零响应方案 $(1, 0)'$ 的目标响应二, 稳健方案付出约 0.234955, 换取整个指定区间内不向坏方向变化。这里的保护来自主动向有利方向留出余量, 而不是让预测误差神奇消失。如果将不确定半径不断扩大, 直至正目标方向也被排除, 结果会变为零; 这表示承诺与可获得信息冲突, 应重新收集资料或讨论允许的保障范围。

若目标协方差也不确定, $g = g_0 + Uz$ 、 $\|z\| \leq \rho$, 其最坏分子为 $g'_0 b - \rho \|U' b\|$ 。若记录协方差满足相对于正定尺度矩阵 W 的谱范数界, 则可有

$$b' P b \leq b' P_0 b + \eta b' W b.$$

在分子非负、两个不确定集合独立且保持概率合法的条件下，一个保守响应界为

$$R_{low}(b) = i \frac{g'_0 b - \rho \|U'b\|}{\sqrt{b'P_0b + \eta b'Wb}}.$$

这个界把信号可能减弱和记录变异可能增大同时考虑。若分子允许变负，不能仍按“分母越大越坏”的规则机械推导；负响应除以更大标准差反而更接近零。符号检查是稳健分式问题的重要一环。联合协方差合法性可能还让两个最坏情景无法同时发生，此时上式作为扩大集合后的保守界可以使用，但必须承认其保守来源。

实际报告应并列给出中心情景的收益、稳健界和名义方案在同一情景集下的表现。只报告稳健界低于原最优值，并不能判断方法是否值得；这个差值正是保护的成本。更关键的是不确定集合是否覆盖真正关心的误设，而非包含大量不可能状态后得到一个过度谨慎的结果。

17.21 条件风险价值的对偶解释与情景权重

条件风险价值常被介绍为“最坏一部分结果的平均”，但离散情景在分位点上存在概率质量时，这个说法需要精确化。对偶形式能够揭示其含义：风险评价者可以重新加重不利情景，但加重幅度有明确上限。它把尾部风险与稳健优化连接起来，也说明为什么不能只删除好情景、对剩余几条记录随意取平均。

设固定方案 c 在情景 s 下的损失为 $L_s(c)$ ，概率为 π_s ，置信水平为 α 。引入阈值 η 与超额变量 ξ_s ，原问题为

$$\min_{\eta, \xi} \left\{ \eta + \sum_s \frac{\pi_s \xi_s}{1 - \alpha} \right\},$$

$$\xi_s \geq L_s(c) - \eta, \quad \xi_s \geq 0.$$

对第一组限制引入乘子 $q_s \geq 0$ ，对 η 、 ξ_s 取下确界。有限下界分别要求 $\sum_s q_s = 1$ 与 $q_s \leq \pi_s / (1 - \alpha)$ ，从而得到

$$CVaR_\alpha(L(c)) = \max_q \sum_s q_s L_s(c),$$

$$\sum_s q_s = 1, \quad 0 \leq q_s \leq \frac{\pi_s}{1 - \alpha}.$$

尾部评价不是任意挑一个最坏情景，除非概率上限允许全部权重集中于它。 α 越高，允许放大的倍数越大，评价越接近极端损失。若 $\alpha = 0$ ，上限为原概率，唯一可行 q 就是 π ，因而退化为期望损失。这些极限有助于核验程序与符号方向。

教学损失取 $(-4, 0, 2, 10)$ ，概率为 $(0.1, 0.2, 0.5, 0.2)$ ，令 $\alpha = 0.7$ 。最坏百分之三十概率包含损失十的全部百分之二十，再包含损失二的百分之十。故

$$CVaR_{0.7} = \frac{0.2 \times 10 + 0.1 \times 2}{0.3} = \frac{22}{3}.$$

最坏重加权为 $q = (0, 0, 1/3, 2/3)$ 。原期望损失只有 2.6；若把所有严格大于百分之七十分位数二的情景平均，就会得到十，错误地忽略分位点处应承担的部分概率。原始优化式和对偶式都能正确处理这种原子概率，不需要临时修改尾部定义。

若贡献方案 c 使每个情景损失都是仿射函数 $L_s(c) = \ell'_s c + d_s$ ，则尾部损失是仿射函数族的上确界，因此为凸函数。若还要求 c 位于凸贡献可行域，最小化尾部损失或将其作为凸惩罚可以得到有全局意义的优化问题。此时活跃的 q 还给出一个次梯度：

$$\partial_c CVaR_\alpha \ni \sum_s q_s^* \ell_s.$$

它告诉研究者，当前风险主要由哪些情景及哪些候选贡献驱动。风险敏感性不再只是一个难以解释的总数，可以追溯到实际的高温、疾病或价格情景。但这些情景的名称必须与产生 L_s 的模型一致，不能把一组任意抽样结果事后附会成具体风险来源。

对偶权重随方案改变，是进一步的重要含义。某个组合能够减少原先最坏情景的损失，新的最坏情景就可能出现，目标在切换处不可微。因此，沿固定最坏情景的梯度走到底，未必得到最优组合。可靠求解必须持续更新尾部集合，或者直接使用带 η, ζ 的整体优化形式。

尾部中的少量情景也会放大抽样误差。当情景来自蒙特卡洛模拟时，高置信水平可能只利用极少数样本。增加候选方案数量后，优化器还有机会利

用这少量样本的偶然性。可以用独立情景集评价已固定的方案，并报告尾部有效样本数与估计波动。增加模拟次数减少的是数值抽样误差；若情景生成机制漏掉某种共同疾病风险，再多模拟也无法弥补结构遗漏。

17.22 只有均值与方差时的概率保障边界

正态概率约束十分方便，但厚尾或混合环境下的失败概率未必由均值与标准差唯一决定。若资料只足以支持这两个矩，而无法合理确定分布，可以使用对所有有限方差分布成立的单侧界。它通常比正态要求更保守；这种代价应明确展示，而不是把不同假设下的“百分之九十五保障”混为同一证据。

令不利结果 L 具有均值 m 与方差 s^2 ，阈值为 $h > m$ 。取 $X = L - m$ ，对任意 $t > 0$ ，在事件 $X \geq a = h - m$ 上有 $(X + t)^2 \geq (a + t)^2$ 。由非负变量的期望界得到

$$\Pr(X \geq a) \leq \frac{E\{(X + t)^2\}}{(a + t)^2} = \frac{s^2 + t^2}{(a + t)^2}.$$

对 t 最小化，最优 $t = s^2/a$ ，于是

$$\Pr(L - m \geq a) \leq \frac{s^2}{s^2 + a^2}.$$

要求失败概率不超过 α ，一个分布无关的充分条件为

$$m + \sqrt{\frac{1 - \alpha}{\alpha}} s \leq h.$$

在均值和方差集合下，该单侧界可以由两点分布达到或任意逼近，所以不能在有限分布信息时普遍换成更小系数。若讨论严格超过阈值而非达到阈值，原子恰落边界时的等号情况要相应处理；实际风险模型应预先定义边界事件，不能利用符号差别人为获得保障。

当 $\alpha = 0.05$ 时，系数为 $\sqrt{19} \approx 4.3589$ ，明显大于正态单侧系数 1.6449。教学方案 $m = -0.3$ 、 $s = 0.1$ 、 $h = 0$ 在正态假设下满足保障，上侧值约为 -0.1355 ；只依据均值方差时，上界表达为 0.1359，不能确认同样保障。若均值固定，需将标准差降至不超过 $0.3/\sqrt{19} \approx 0.06882$ 。这并不证明该方案真实失败率高，而是说明较弱的信息不足以排除不利厚尾分布。

对于联合健康限制, 设第 j 个失败事件为 A_j , 无论事件怎样相关, 都有

$$Pr\left(\bigcup_j A_j\right) \leq \sum_j Pr(A_j).$$

若希望总体失败概率不超过 α , 可以分配 $\alpha_j \geq 0$ 、 $\sum_j \alpha_j \leq \alpha$, 逐项满足相应概率限制。这种方法不需要假定独立, 但可能保守。每项都给百分之五失败概率, 五项合起来只能由该界保证失败概率不超过百分之二十五, 不能宣布整体仍有百分之九十五保障。

风险预算不必平均分配。某个性状增加少量允许失败概率即可释放大目标收益, 另一个性状对预算不敏感, 可以在总预算固定下共同优化各 α_j 。但这种分配必须符合实际风险的可替代性: 如果某种严重缺陷具有独立不可突破的标准, 就不能因为经济回报较高而把其他性状的风险预算转给它。数学能够计算取舍, 是否允许取舍仍需由目标定义决定。

最后要区分条件后验保障与重复抽样覆盖。若整个联合后验分布被视为给定且模型正确, 依据当前资料选出的方案仍可计算其条件后验失败概率; 选择本身不会自动使这一条件概率失去定义。可是, 把同一数值宣称为跨数据集的频率保证, 需要另外证明校准、参数估计和选择过程的影响。反过来, 使用估计均值方差构造分布无关界, 也不自动包含这些矩估计的不确定性。给矩本身设置可信范围并在范围内取最坏值, 是更严格但也更保守的另一层问题。

把这个分布无关界用于贡献优化时, 若不利遗传值向量的均值为 m 、误差协方差为 V , 组合贡献为 c , 便得到

$$c'm + \sqrt{\frac{1-\alpha}{\alpha}} \sqrt{c'Vc} \leq h.$$

只要 V 正半定且均值对 c 线性, 这个条件定义凸可行域。它并不要求各候选误差独立; 非对角协方差直接决定可行组合是否存在。若把 V 分解为 RR' , 第二项可以写成常数乘 $\|R'c\|$, 从而使用标准二阶锥约束。正半定性在这里不仅关系数值稳定, 也关系标准差是否具有概率意义。

一个两候选教学例中, 不利方向的预测均值分别为负零点四和负零点二, 误差标准差分别为零点一与零点零五, 先假定误差独立, 要求百分之九

十五的分布无关不恶化保障。两者单独使用都不能通过，因为上界分别约为零点零三五九与零点零一七九。各使用一半时，均值为负零点三，误差方差为零点零零三一二五，上界约为负零点零五六三，反而可行。这个例子显示，个体不满足组合风险门槛，不意味着所有包含它们的组合都不可行。

若二者误差相关改为零点八，平均使用的误差方差增为零点零零五一二五，上界转为约零点零一二零，保护失效。候选均值、各自可靠度和贡献比例都没有变化，结论却因共同误差改变。这再次说明不能把标准误差表当作完整组合风险资料。若错误地把亲属共享误差删去，优化器很可能通过大量近亲平均得到虚假的安全方案。

稳健保障应始终与可执行的监测相连。若某项风险限制所需标准差远低于现有资料可能达到的水平，应讨论增加测定、降低贡献或改变行动，而不是把置信系数改小直到方案“通过”。约束的价值在于让证据缺口与机会成本显现出来，使育种者清楚知道哪些收益可以争取、哪些承诺尚无足够信息支持。

风险限制最终还要回到所承诺的随机对象。如果这里的方差只表示亲本真实育种值的预测误差，那么组合通过条件只约束该遗传均值的不确定性。后代数量有限带来的孟德尔抽样、出生比例变化以及共同环境冲击，仍需按实际目标另行加入。尤其当承诺针对下一年度的生产指标时，遗传上稳定的组合也可能受到天气或疫情共同影响。应先建立从亲本贡献到最终指标的随机分解，再决定哪些方差可由增加后代数降低、哪些不会随规模消失。把这些层次说明白，比单纯提高名义保障百分比更能形成可信方案。

17.23 习题与解答

习题一：限制为何降低可利用信息。设 P 正定，无限制最优权重为 $b_0 = P^{-1}g$ ，限制最优权重为 b_R ，限制为 $K'b_R = 0$ 。证明两者差向量与 b_R 在 P 内积下正交，并说明如何理解目标响应损失。

解答：由限制指数公式， $d_b = b_0 - b_R = P^{-1}K\lambda$ 。于是 $b'_R P d_b = b'_R K\lambda = 0$ ，从而 $b'_0 P b_0 = b'_R P b_R + d'_b P d_b$ 。由于 $g = P b_0$ ，还得到 $b'_R g = b'_R P b_R$ 。在相同

截留强度下,按最优尺度计算的目标响应正比于相应指数标准差,因此比值为 $\sqrt{b'_R P b_R / (b'_0 P b_0)}$ 。限制剔除了与禁改方向有关的那部分可用信号;若该部分原本不帮助目标,则损失为零。

习题二:冗余限制。假设两个限制列向量分别为 k 和 $2k$,直接计算 $K'P^{-1}K$ 的逆会出现什么问题?应如何处理?

解答:两列线性相关,矩阵秩不足,普通逆不存在。第二个限制与第一个表达同一要求,因此保留一个独立限制即可。也可以在正确检查一致性后使用广义逆,但应说明实际约束空间的秩。给矩阵对角线随意加一个很小常数虽然可能得到数值解,却改变了严格限制问题,不应把它当作没有代价的修复。

习题三:期望方向。在 $P = I_2$ 、 $C = \text{diag}(0.8, 0.4)$ 、 $d = (1, 1)'$ 的例子中,求权重、指数方差和 $i = 1.4$ 时的实际响应,并解释为什么把 d 加倍不使实际响应加倍。

解答: $C'P^{-1}C$ 的对角元素为 0.64, 0.16, 所以 $b = (1.25, 2.5)'$, 指数方差为 7.8125。实际响应的两个分量都是 $1.4/\sqrt{7.8125} \approx 0.500879$ 。若 d 加倍,权重和指数标准差都加倍,响应分子与分母同步变化,排序及实际响应保持不变。期望改良量方法固定的是方向,规模仍受到选择强度和可用信息约束。

习题四:最适目标。三候选后验均值为 4, 5, 6, 方差为 1, 4, 0.5, 最适点为 5。按二次损失选谁?如果只看均值,结论有什么不同?

解答:期望损失分别为 2, 4, 1.5, 应选第三个。只看后验均值会选择第二个,因为它正好位于最适点,但其较大不确定性提高了偏离最适点的期望平方距离。这里方差是目标遗传值的后验方差;若评价的是后代表型质量,还应加入相应分离和环境变异,且不能重复计算已经包含的部分。

习题五:组合相关。两公畜误差方差均为 9, 各用一半,误差相关分别为零、二分之一和一。计算组合误差方差,解释哪些风险能通过分散使用降低。

解答:方差为 $0.25 \times 9 + 0.25 \times 9 + 0.5 \times 9\rho = 4.5(1 + \rho)$, 分别为 4.5, 6.75, 9。相关越高,平均化能够消除的独立部分越少;完全共同的误差不能通过这种

组合减小。此结论针对预测误差，不直接等于后代近交水平，也不保证不同公畜在环境响应上的风险独立。

习题六：信息价值。沿用甲可能为 14 或 6、乙确定为 9 的例子，若对称检测正确率降为 0.6，检测是否仍有选择价值？

解答：阳性后甲的期望值为 10.8，选甲；阴性后为 9.2，仍高于乙，也选甲。因此不论检测结果如何都采取同一行动，检测前后的最优期望值均为 10，此次选择的信息价值为零。检测可能具有其他科学或后续用途，但不能把这些尚未建模的用途混入本轮选择收益。这也说明检测准确率与实际决策价值不是线性关系。

习题七：概率限制。某不利性状改变预测均值为 -0.12 ，标准差为 0.08，要求百分之九十五概率不超过零。它是否满足正态概率限制？若均值不变，标准差需降至多少以下？

解答：上侧界限为 $-0.12 + 1.644854 \times 0.08 \approx 0.011588$ ，所以不满足。需要 $s_D \leq 0.12/1.644854 \approx 0.072955$ 。这是假设均值与标准差模型正确时的计算要求，不保证通过任意新增测定都能达到；新增信息也可能改变均值。若无法降低标准差，可以减少该方案贡献或选择其他组合，再重新评估联合不确定性。

习题八：尾部与期望。两方案四情景收益分别为 $(12, 12, 12, -4)$ 和 $(7, 7, 7, 7)$ 。计算平均值、最坏四分之一平均收益，并解释为什么不存在不依赖偏好的唯一优胜者。

解答：平均值分别为 8 与 7，最坏四分之一平均收益为 -4 与 7。前者提供更高均值，后者提供更高最低保障。若决策目标只最大化期望，选前者；若要求所有给定情景下不亏损，前者不可行。不同选择来自不同目标与约束，不能把风险偏好差异归结为计算精度问题。还应检查四情景是否充分代表实际风险。

习题九：固定决策与完全信息。某研究在每次参数抽样后都重新优化，随后报告最优目标值的平均数，称之为实际可达到的期望收益。这一说法有什么缺陷？

解答：研究允许决策随着未被现实观察到的真实参数变化，实际上使用了完全信息。现实在决策时只能选择一个依赖当前资料的方案。由于先逐情景取最大值再平均，结果通常不低于先选同一个方案再平均，因而构成理想上界。应把每个候选固定方案在所有参数样本下评价，或建立明确可实施的信息获取与更新规则。

习题十：设计稳健验证。为一个包含生长、繁殖和排放三目标的育种计划设计验证方案，要求区分预测模型问题与经济偏好问题。

解答：先固定性状定义、目标环境和预测时点，按未来时间段或独立家系留出验证资料，评估每个性状的偏差、校准和相关表现，同时检查联合误差结构。再用预先给定的多组价格与环境情景评价同一个贡献方案，报告平均收益、尾部表现、约束违反率和与现行方案差异。若预测系统失准，应更新数据或模型；若预测合理但排名随价格大幅变化，应改进经济情景与治理规则。最后在可实施整数配种方案上复算限制，并持续监测实际后代结果。

选择反应、世代间隔与长期遗传多样性

18.1 一代进展、年度进展与选择强度

遗传改良既是统计预测问题，也是时间问题。一种评定方法可能每一代更准确，却需要等待多年；另一种方法准确度略低，却能在青年阶段决定留种。比较这两种方法，不能只比较准确度，也不能只比较单代响应，而应明确时间尺度和选择路径。

当目标育种值为单性状 u ，指数准确度为 $r_{u,\hat{u}}$ ，选择强度为 i ，加性遗传标准差为 σ_u 时，在 u 对实际选择指数的条件均值为线性且选留仅依赖该指数的条件下，单个选中亲本群体相对候选群体的预期育种值差为

$$S_u = i r_{u,\hat{u}} \sigma_u. \quad (18.1)$$

若两个性别同等贡献且遵循相同选择规则，子代均值变化为该值；一般情况下则为父方与母方选择差的平均。当实际用于截留的指数或分数服从正态分布时，上端保留比例 p 对应的选择强度为

$$z_p = \Phi^{-1}(1 - p), \quad i = \frac{\phi(z_p)}{p}. \quad (18.2)$$

其中 Φ 和 ϕ 分别为标准正态分布函数和密度函数。 i 是标准化选择差，不是“淘汰比例”的另一个名字。保留 10% 时，截点为 1.281552，选择强度为 1.754983。有限候选数量、亲属聚集、多个门槛和不等繁殖成功，都会使实际选择强度偏离这个理论值。

在平稳、近似离散世代的简化下，年度遗传进展为

$$\Delta G_{\text{year}} \approx \frac{i r_{u,\hat{u}} \sigma_u}{L}, \quad (18.3)$$

L 为世代间隔, 即产生下一代替代亲本时的亲本平均年龄。它不是简单的初配年龄, 也不是个体平均寿命。对世代重叠群体, 应依据实际出生、留种和繁殖贡献计算, 必要时使用基因流模型。

18.2 例 18.1 准确度较低的方案为何可能进展更快

设两套教学方案都保留上端 10%, $\sigma_u = 10$ 。方案甲通过等待后代资料达到准确度 0.90, 世代间隔为五年; 方案乙在较早阶段达到准确度 0.65, 世代间隔为两年。由式 (18.3), 甲的年进展为 3.158970, 乙为 5.703696 个性状单位。乙的单代选择差较小, 但较短的更新周期使年度进展较大。

这个算例解释了青年期基因组选择的一个重要机制, 却不是任何物种采用基因组选择后都能获得相同比例提高的承诺。预测准确度可能因参考群更新不及时而下降, 繁殖生物学可能限制最短世代间隔, 较强选择也可能加快近交积累。真实方案比较还应计入基因分型、记录、繁殖和管理成本, 以及达到新制度稳定状态所需的过渡期。

对于家畜, 常把基因传递分为父传子、父传女、母传子和母传女四条路径。若各路径的选择强度、准确度和世代间隔分别为 i_k 、 r_k 、 L_k , 在标准平稳路径近似下,

$$\Delta G_{year} \approx \frac{\sigma_u \sum_{k=1}^4 i_k r_k}{\sum_{k=1}^4 L_k}. \quad (18.4)$$

取 $i = (1.76, 1.40, 0.80, 0.60)$ 、 $r = (0.70, 0.60, 0.50, 0.50)$ 、 $L = (2, 2.5, 3, 3)$ 、 $\sigma_u = 10$, 年进展为 2.64。该式不能改写成“分别计算四个年度响应再简单平均”, 因为各路径在世代更新中的时间权重不同。若某些路径来自外部引种、胚胎移植或极端不平衡贡献, 应使用符合该群体结构的模型。

在阅读实际遗传趋势时, 还应区分预测进展与观察到的变化。某年度平均表型上升可能来自环境改善, 平均估计育种值上升可能受到基准调整或数据选择影响。评估方案实现效果应保持评价基准一致, 检查遗传趋势、环境趋势和验证样本, 并说明参考群体是否随时间变化。

18.3 为什么不能把第一代响应一直线性外推

式 (18.1) 将遗传标准差看作给定量, 但持续选择会改变它。短期内, 选择可在多基因位点间形成负连锁不平衡, 降低可观察的加性遗传方差; 重组能够恢复其中一部分, 这一动态通常称为 Bulmer 效应 (Bulmer, 1980)。更长期的等位基因频率变化、遗传漂变和有利等位基因固定, 则会改变基础遗传变异本身。二者的时间尺度和可逆性不同。

例如, 一个选择计划第一代确有较高响应, 并不意味着十代累计进展等于第一代响应的十倍。多性状目标还可能随市场和环境改变, 近交衰退可能抵消部分加性进展, 参考群与候选群之间的关系也可能变化。因此, 长期设计通常需要前向模拟, 并对遗传架构、重组、繁殖限制和预测更新方式进行情景分析。模拟能比较假设的后果, 但不能把未知的真实遗传架构变成已知。

近交系数 F 描述个体同一位点两个等位基因相对参考基础群同祖的概率。以世代为单位的近交增量可定义为

$$\Delta F = \frac{F_t - F_{t-1}}{1 - F_{t-1}}, \quad N_e \approx \frac{1}{2\Delta F}. \quad (18.5)$$

后一关系适用于相应理想群体或适当有效大小近似, 不能把群体头数直接当成 N_e 。少数种公畜产生大量后代、家系规模差异很大或世代重叠, 都可能使有效大小远低于在群数量。同样, 系谱近交、不同基因组近交指标和纯合片段指标有各自的参考和尺度, 不能不加校准就直接比较。

若初始 $F_0 = 0$ 且每代 ΔF 恒定, 则 $F_t = 1 - (1 - \Delta F)^t$ 。每代近交增量为 0.5% 时, 十代近交约为 4.8890%; 增量为 1% 时, 十代约为 9.5618%。相应理想近似有效大小分别为 100 和 50。这个简单计算揭示了小幅年度或世代差异的累积后果, 但没有计入选择、迁入和非平稳贡献, 不能替代实际群体监测。

18.4 例 18.2 从挑选最优秀个体到优化亲本贡献

截留选择回答“哪些个体入选”, 最优贡献选择还回答“每只入选个体使用多少”。令候选亲本的综合预测育种值组成向量 $\hat{h}$, c_j 为第 j 个体对下一代

基因库的遗传贡献比例, A 为分子加性关系矩阵。一个基础问题为

$$\max_c \hat{h}'c, \quad \mathbf{1}'c = 1, \quad c \geq 0, \quad \frac{1}{2}c'Ac \leq \theta. \quad (18.6)$$

其中 θ 限制群体共祖水平。对公母分开的动物育种, 应进一步要求公畜贡献总和为 $1/2$ 、母畜贡献总和为 $1/2$, 并加入个体可实现的繁殖上限。Meuwissen (1997) 确立的最优贡献框架把遗传增益与相关性控制放在同一优化问题中。

考虑两只公畜和两只母畜, 预测综合育种值依次为 $(12, 11, 8, 7)'$ 。两只公畜的加性关系系数为 0.5 , 即 $A_{12} = A_{21} = 0.5$, 其余非对角关系均为零, 各对角为一。若四只个体等贡献, $c = (0.25, 0.25, 0.25, 0.25)'$, 目标均值为 9.5 , 群体共祖为 0.15625 。若只用最高分公畜和最高分母畜, 贡献为 $(0.5, 0, 0.5, 0)'$, 目标均值为 10 , 群体共祖升至 0.25 。

设群体共祖上限为 0.18 , 并分别固定公母贡献总和为一半, 数值优化得到

$$c = (0.427951, 0.072049, 0.338976, 0.161024)', \quad \hat{h}'c = 9.766927. \quad (18.7)$$

该方案优先使用高分个体, 同时保留其他个体的贡献, 恰好达到 0.18 的共祖上限。结果说明, 控制多样性不必等同于所有家系等比例繁殖, 也不必等同于固定选出若干头公畜; 连续贡献优化能在同一约束下寻找更有效的折中。实际落地时还需把连续比例转换为可执行的配种或后代数量, 并检查取整后的约束。

这里最容易出现一个概念混淆: $\frac{1}{2}c'Ac$ 是被选贡献组合的群体共祖, 不是任意配种方案下一代个体平均近交的直接数值。若公畜 s 与母畜 d 配对, 其后代近交为 $A_{sd}/2$; 给定配种比例 m_{sd} 且其和为一, 后代平均近交为 $\sum_{sd} m_{sd} A_{sd}/2$ 。本例所有公母间关系都为零, 因此三种方案第一代后代的平均近交均为零, 尽管群体共祖不同。共祖差异反映未来后代之间的相关性和后续近交风险, 这正是贡献优化与配种优化需要区分的原因。

18.5 基因组关系、配种优化与长期验证

系谱关系给出基于祖先信息的预期共享，基因组关系可以反映实际遗传片段共享和孟德尔抽样差异。然而，将 A 替换为某个基因组关系矩阵并不自动产生最优的长期保护。基因组矩阵的等位基因频率基准、缩放、选定位点和与目标位点的联系，都会影响受控制的量。Gautason 等（2023）的模拟研究专门比较了最优贡献选择中亲缘矩阵选择的影响，提示需要围绕实际控制目标检验矩阵，而不能只凭“基因组更精细”作结论。

近年的方法进展也在改进可执行性。Waldmann（2025）将基因组贡献优化与后续配种分配组合，在 Julia/JuMP 框架中使用确定性优化方法，并以模拟数据展示计算方案。这类进展的意义是把连续贡献转化为有整数与配种约束的计划；其具体计算时间和收益比较仍依赖数据规模、约束及求解器，不能直接移植为所有生产场景的承诺。

长期育种计划应区分三个环节。遗传评定产生带误差的育种值；贡献优化确定各亲本的使用量；配种优化决定谁与谁交配。前者决定预测信息，第二环节影响遗传增益和群体关系，第三环节直接影响后代近交分布、互补性和特定有害隐性组合。将三者混为一个“综合评分”，很难发现风险究竟来自哪一环。

对肉羊等存在强家系结构、繁殖季节和公畜利用上限的群体，方案评估至少需要跟踪年度进展、目标各性状变化、近交与共祖、家系贡献、淘汰和繁殖失败，以及稀有遗传资源的流失。保种与高强度商业改良的目标不同，也不应共享一套未经说明的约束。采用新方法时，可先用历史数据重演和向前模拟筛选方案，再在明确规模的实际群体中检验；长期优势最终需要连续世代证据。

长期多样性保护还不等同于让每个位点频率保持不变。遗传改良本来就需要某些有利等位基因频率变化，完全冻结频率会阻止进展。需要控制的是过快的随机流失、不必要的家系集中，以及可能损害未来适应性的变异损失。对已知严重隐性缺陷，可通过配种避免产生受影响后代，同时结合携带者的其他遗传价值分阶段调整频率；这与不加区分地淘汰所有携带者具有不同的

多样性后果。

育种方案还应保存可恢复资源。冷冻精液、胚胎与代表性家系的保存,使未来目标改变时可能重新利用已减少的遗传成分,但保存材料并不会自动补偿活群中快速积累的近交。应记录材料的身份、亲缘、健康检测及可用数量,并将恢复所需的繁殖时间纳入应急方案。日常贡献管理和遗传资源保存具有互补关系,任何一项都不能成为忽略另一项的理由。

18.6 实际选择强度与繁殖成功

18.6.1 正态公式只是一个参照

选择强度来自实际入选群与候选群的标准化均值差。正态截留公式建立在分数近似正态、按单一分数严格截留和候选规模足够大等条件上。若先按健康门槛淘汰,再从剩余群按指数选留,整体入选群的分数分布已受到第一次筛选影响,应从完整联合分布或实际候选数据计算选择差。若候选来自少数高度相关家系,把每头动物当作独立抽样也会高估可实现的极端个体数量。

有限群体中,即使保留比例相同,实际最大值和入选均值仍有随机性。一个群体从十头中选一头,与从一千头中选一百头,在无限正态近似下具有相同保留比例,但前者的选择差变异更大,且有限样本期望存在差异。育种计划规模较小时,应通过相应有限样本分布或重复模拟评价选择强度,而不是把大群体常数视为每年必然实现的值。

候选群的定义也直接影响选择强度。若只把最终进入测定站的动物视为候选,会忽略此前农场预选;若把所有出生动物都算作候选,却没有记录早期淘汰和繁殖资格限制,则无法重建完整选择过程。合理报告应说明从出生、存活、测定、达到资格到最终使用的各阶段数量,以及每一阶段采用的信息。这样才能区分遗传筛选强度与疾病、事故或管理淘汰造成的减少。

18.6.2 入选名单不等于实现贡献

设入选公畜的真实育种值为 u_j ，实际父方贡献比例为 q_j ，且 $\sum q_j = 1$ 。父方传递给后代的平均育种值贡献为 $\frac{1}{2} \sum q_j u_j$ ，而不是入选公畜简单平均值的一半。受胎率、精液可用性、疾病淘汰、运输和农户偏好都会使 q_j 偏离计划。若高预测值公畜繁殖成功较低，实际遗传响应会小于根据入选名单预测的结果。

构造三只入选公畜，育种值分别为 12, 8, 4。等量使用时父本平均为 8，传递部分为 4；若实际贡献为 0.2, 0.3, 0.5，父本平均降至 6.8，传递部分为 3.4。两种方案使用完全相同的三只公畜，但实际响应不同。若母方均值相同，后代整体均值的差为 0.6。因此评价育种计划必须同时保存选择结果与繁殖结果。

相反，如果因推广宣传而过度使用最高分公畜，短期响应可能高于等量使用预期，却增加未来亲缘集中。某一年的“超额进展”未必说明方案整体更优，可能只是提前消耗了多样性预算。实际贡献偏离还应反馈到下一轮优化中，不能每年都按上一年计划贡献更新关系和目标，忽略已经发生的集中。

18.6.3 性别、繁殖技术与选择强度的联系

在许多家畜群体中，少数公畜可以产生大量后代，因此父方选择强度可能高于母方。胚胎移植等繁殖技术可提高优秀母畜的贡献，但也会改变家系规模、相关结构和所需候选数量。技术提高繁殖能力，并不自动提高可持续遗传进展；若记录和近交控制没有同步改进，较大的家系可能加快共同误差与相关性的扩散。

对水产或多胎动物，一个配对可以产生很多后代，但实际有效家系数仍可能很少。大量幼体不等于大量独立遗传机会，尤其在共同养殖、家系存活差异很大或亲子鉴定不完整时。设计者应把繁殖技术、家系代表性和个体记录能力一起考虑。选择强度的上限不只由出生数量决定，也由候选独立性、测定资源和可允许的贡献集中决定。

18.7 世代重叠与四条选择路径

18.7.1 计算世代间隔需要追踪替代关系

世代间隔是亲本产生下一代替代亲本时的平均年龄。若某公畜在两岁时产生大量商品后代，却在五岁时才产生进入核心群的替代公畜，父传子路径的世代间隔应反映后者。把商品后代出生年龄当作所有路径的间隔，会低估核心遗传更新所需时间。对母畜同样如此，第一胎年龄与产生最终留种女儿时的年龄可能不同。

可以按实际替代后代的遗传贡献加权计算路径平均年龄。若一个父传子路径中，百分之六十的替代公畜来自两岁父亲，百分之四十来自五岁父亲，则该路径平均年龄为 $0.6 \times 2 + 0.4 \times 5 = 3.2$ 年。若只是数父亲头数而忽略其留下的替代子代数量，得到的平均年龄未必对应实际基因流。

青年期预测的价值常在于让有潜力个体更早产生替代亲本，而不仅是更早获得一个分数。如果养殖制度规定所有替代只能在某个固定季节产生，提前几个月完成评价未必能缩短一个完整繁殖周期；反之，刚好赶上本季配种可能节约接近一年。时间收益因此可能呈现跳跃，不能一律按检测提前的天数连续折算。

18.7.2 四路径公式的分母为什么是间隔之和

在标准平稳模型中，父传子、父传女、母传子和母传女共同形成持续更新的遗传网络。每条路径提供遗传选择差，也占用相应更新时间。式 (18.4) 把四条路径的标准化遗传增量汇总，再除以更新所需的总时间指标。它依赖稳定年龄结构、路径定义和适当的遗传传递假设，不是把四个互不相关的育种群体做算术平均。

以上述四路径教学参数为例，分子中 $\sum i_k r_k = 2.772$ ，分母为 10.5 年，乘以遗传标准差 10 得年进展 2.64。如果把四个 $10i_k r_k / L_k$ 再平均，会得到约 2.963333，与正确路径近似不一致。这个差异来自时间加权方式，而不是四舍五入。实际资料若不满足平稳模型，应建立年龄或群体分层递推，而不是在两个公式中挑选更乐观的一个。

缩短某一条路径的间隔,其收益也依赖其他路径是否已经成为瓶颈。若父传子很快,但优秀遗传在母方替代中传播缓慢,整体年度趋势仍受到后者影响。方案分析可以逐项改变各路径参数,计算边际收益,并同时考虑提高准确度、增加候选数量和缩短间隔所需成本。这样才能知道资源应投向哪一环,而不是笼统要求所有路径都达到最大强度。

18.7.3 转型期与稳态的差别

从传统后裔测定转向青年选择时,群体不会在下一年立即进入新稳态。原有老龄亲本仍在使⽤,青年候选的参考信息与验证资料需要逐步积累,推广和繁殖安排也有惯性。过渡期可能出现年龄结构混合、评价尺度变化和一次性成本。若用新制度稳态公式解释第一年实际趋势,很容易误判成功或失败。

应至少区分启动期、过渡期和稳定运行期。在启动期记录建设和基因分型成本可能较高;过渡期需要比较新旧亲本的实际贡献;稳定期才较接近固定路径参数的长期近似。对制度变更的经济评价应累计各年的成本与收益,而不把长期年收益直接乘以运行年数。过渡过程越长,贴现和风险的重要性越大。

18.8 遗传扩散、时间价值与产业层级

18.8.1 核心群进展不会立即到达全部商品群

核心育种群产生新遗传水平后,种公畜、种母畜或繁殖材料还要经过扩散和推广才能影响商品生产。不同层级的替代速度和来源比例决定传播滞后。若核心群每年进步,但商品群长期使用较老遗传材料,商品层平均遗传水平可能保持一个稳定但较大的滞后差距。改进推广速度有时能够提高产业收益,即使核心群的选择准确度没有改变。

可用简单递推说明这一过程。设某层级每年用比例 r 的新遗传材料替代,来源层当年的遗传均值为 B_t ,本层原有均值为 M_t 。在简化且忽略其他流动的条件下,下一年的均值为 $M_{t+1} = (1-r)M_t + rB_t$ 。这不是完整动物世代

模型，而是一个遗传材料更新的教学近似，帮助识别替代率和来源水平的作用。

若来源遗传水平突然提高到 10，本层初始均值为零，年替代比例为 0.25，则四次更新后的均值为 $10(1 - 0.75^4) = 6.835938$ ，仍未达到来源水平。若替代比例提高到 0.5，四次更新后为 9.375。更快更新可能需要更高采购与淘汰成本，所以传播速度也应与收益和实施约束共同优化。

18.8.2 贴现反映时间和机会成本

一个遗传改进可能在很多未来年份持续产生收益，而测定或选育成本在今天发生。若第 t 年净收益为 B_t ，贴现率为 d ，现值为 $\sum_t B_t / (1 + d)^t$ 。贴现率是经济评价假设，不是遗传参数。应明确它是实际还是名义、对应何种价格基准，并通过敏感性分析反映其不确定性。

构造一个教学改良项目，当前成本为 1000，从第二年至第六年，每年产生 300 的净收益。以 5% 贴现，五笔收益现值约为 1236.993334，净现值约为 236.993334。如果相同收益整体延迟两年，现值降为约 1121.989419，净现值约为 121.989419。遗传总收益金额没有变化，延迟却明显减少今天的价值。

若遗传改进会自我延续，收益年限应根据遗传传递、替代和市场持续性建模，而不是任意设为无限。若未来目标改变导致原改良方向价值下降，长期收益也会改变。对于健康、环境和遗传资源价值，未被当前市场充分定价的部分应单独说明，可以作多准则或不同社会评价情景，但不能把所有未计价收益默认为零且称之为完整社会价值。

18.8.3 利益归属决定项目能否持续

测定组织、种畜企业、繁殖推广者和商品生产者可能分别承担成本并获得收益。一个从全产业看净现值为正的计划，若负责记录的主体无法分享收益，仍可能缺乏持续投入。育种经济学因此需要分析收益传播和资金回流，而不仅计算总额。数据共享、种畜定价、合作社安排和公共测定支持，都可能改变计划的可实施性。

对稀有地方品种，短期商品收益未必足以覆盖保护成本，但其适应性、

文化价值和未来选育选择权可能具有公共价值。保护计划的评价不应照搬高产商业品系的收益边界；同时也需要透明的目标和可核查的成本。承认多种价值不意味着免除分析，而是要求把不同价值的来源、受益者和不确定性分别交代清楚。

18.9 选择如何改变遗传方差

18.9.1 入选亲本的方差与候选群方差不同

选择响应公式使用选择发生前候选群中的加性遗传标准差。入选群只占分布的一部分，其遗传方差通常较小，而且与指数相关的方向被压缩得更多。若育种值和指数联合正态，指数在上端截留后，育种值方差可写为 $\sigma_u^2(1 - kr_{u,l}^2)$ ，其中 $k = i(i - z_p)$ ， z_p 为标准化截点。准确度越高，同样截留对真实遗传分布的压缩越明显。

这一表达不意味着入选群只保留原有遗传方差的某个固定百分比。压缩程度取决于选择比例、信息准确度和真实联合分布。多性状指数会主要减少综合方向及与之相关方向的变异，不同单性状的方差和协方差可以发生不同变化。因此持续选择后的参数可能不同于基础群参数，使用长期不更新的方差组分需要谨慎。

例如某性状基础遗传方差为 100，若教学参数取 $k = 0.8$ 、准确度为 0.5，入选亲本方差为 $100(1 - 0.8 \times 0.25) = 80$ 。这个减少包括选择造成的关联结构变化，并不等于已有百分之二十的等位基因永久消失。要理解后代还能恢复多少变异，需要进一步区分基因频率部分与位点间关联部分。

18.9.2 基因频率方差与连锁不平衡

在一个加性位点、等位基因频率为 p 、替代效应为 α 的简化下，该位点对基因频率方差的贡献为 $2p(1 - p)\alpha^2$ 。跨位点求和得到基因频率所支持的变异；若位点之间存在统计关联，总加性方差还包括协方差项。选择多基因总和时，入选个体中一个位点较弱的有利状态可能由另一个位点较强的状态补偿，从而形成负关联，降低总体方差。

重组能够打破一部分这种负关联，使后代重新出现新的有利组合。这就是 Bulmer 效应的重要机制。它不同于等位基因已经固定后的变异损失：若某个等位基因在封闭群中完全消失，仅靠重组不能把它重新创造出来。把短期方差降低一律解释为遗传资源永久枯竭，或者反过来认为所有损失都能由重组恢复，都是错误的。

位点连锁程度决定恢复速度。对不连锁位点，每代重组对关联的削弱较快；紧密连锁片段可能保留较长时间。真实群体还受到有限群体漂变、选择干扰和不同染色体结构影响。简单无限小模型有助于建立方向判断，但精确长期预测需要反映遗传图谱与繁殖设计的模型。

18.9.3 一个可手算的短期动态近似

为分离机制，设基因频率方差保持为 $V_g = 100$ ，父母两侧采用相同选择规则，忽略近交并假定不连锁无限小模型。若每代准确度与截留参数固定，候选方差的教学递推可写为

$$V_{t+1} = \frac{1}{2}(1 - kr^2)V_t + \frac{1}{2}V_g.$$

第一项来自亲本平均值的变化，第二项代表这一近似中的孟德尔抽样变异。取 $k = 0.8, r = 0.5$ ，递推为 $V_{t+1} = 0.4V_t + 50$ 。从 $V_0 = 100$ 开始，前两代为 90 和 86，平衡值为 83.333333。即使位点频率完全不变，选择仍使可观察加性方差低于基础值；但它不会在这个模型中无限衰减到零。

若此后停止选择，同样的简化给出 $V_{t+1} = 0.5V_t + 0.5V_g$ ，方差逐步回向 100。如果同时发生等位基因固定， V_g 本身已降低，停止选择只能恢复关联造成的部分，不能恢复频率损失。这个对照帮助理解为什么长期监测既要看实际遗传方差，也要看基因频率、家系贡献和关系变化。

上述递推把准确度固定，只用于教学。实际准确度依赖遗传方差、记录结构和参考群，随着群体改变通常也会改变。若每一代都更新预测模型，选择还可能改变误差相关。因此不能把这个手算递推直接作为真实育种计划的十代预测；它的用途是拆解机制，为更完整模拟提供检查基准。

18.10 有效群体大小与遗传漂变

18.10.1 一个名词可能对应不同过程

有效群体大小是与某个遗传过程等效的理想群体规模。常见定义关注近交积累速度或等位基因频率漂变速度，在非平稳、受选择和世代重叠的群体中，不同定义的估计不一定相同。因此报告一个 N_e 数值时，应说明它根据近交增量、连锁不平衡、时序频率变化还是其他资料估计，并交代时间尺度和参考群体。

近交有效大小关系 $N_e \approx 1/(2\Delta F)$ 提供了直观解释：较快的相对近交累积对应较小有效大小。这里分母使用的是相对于尚未同祖部分的增量，而不是简单相邻代 F 的差。若初始近交已较高，忽略分母 $1 - F_{t-1}$ 会低估相对累积速度。不同基础年份的近交指标也不能未经转换直接拼接为一条趋势。

在理想的独立世代、随机交配、每性别内贡献相近等条件下，性别数不平衡近似给出 $N_e = 4N_mN_f / (N_m + N_f)$ 。若有十只繁殖公畜和一百只母畜，近似有效大小仅为 36.363636，远低于总头数一百一十。这个式子不能捕捉公畜贡献高度不均、亲缘结构或重叠世代，但已经说明增加母畜数量不能无限补偿极少公畜造成的瓶颈。

18.10.2 贡献集中是一个可直接监测的信号

令 c_j 为个体遗传贡献且总和为一，可定义贡献数指标 $N_c = 1 / \sum c_j^2$ 。若所有贡献相同， N_c 等于贡献个体数；若高度集中， N_c 变小。例如三个贡献者的比例为 0.5, 0.25, 0.25，则 $N_c = 2.666667$ 。该指标只描述贡献均匀程度，并未考虑个体间亲缘，因此不能直接标为有效群体大小。

两个方案可以有相同 N_c ，却使用完全不同的家系结构。若一组贡献者彼此无关，另一组全部近亲，后者的群体共祖更高。相反，适度不均等地使用遗传上独特的优秀个体，可能比机械等量使用一组近亲更好。因此贡献均匀度是诊断信息，关系矩阵才使贡献管理与共同祖先联系起来。

实际记录中还应区分计划贡献、出生贡献、存活贡献和进入下一代繁殖群的贡献。某家系幼龄死亡较多，会在最后一层明显减少；某家系被集中留

种则会增加。对长期多样性最有直接意义的是实际替代亲本的遗传贡献，而不是最初精液销售份额。不过，较早阶段的信息可以帮助及时发现偏离，避免等到下一代留种时才意识到某些家系已经消失。

18.10.3 漂变、选择与小群体适应

遗传漂变是在有限传递中由抽样造成的频率变化，与等位基因是否有利没有必然关系。小群体中，一个有利但稀少的等位基因仍可能丢失；一个轻微不利的等位基因也可能因偶然而升高。选择可以改变其期望方向，却不能消除随机性。长期方案应比较多次重复的结果分布，而不是只展示一条看起来平滑的模拟轨迹。

强选择与小有效大小还可能互相强化。若少数家系因一次有利预测而大量使用，其后代成为下一代参考和候选的主要来源，后续选择可能继续围绕这些家系进行。限制贡献可以减缓这种路径依赖，但不意味着所有家系必须永久保留相同比例。关键在于对获得的目标收益与失去的未来选择空间作有依据的取舍。

引入外来遗传材料可能恢复变异、降低某些关系指标，却也可能带来适应性下降、目标差异或新疾病风险。群体外源不是无条件有益的“多样性加法”。应评价来源适应性、遗传距离、杂交后分离和后续留种策略，并说明保护品种身份是否属于目标。对封闭品系、开放核心群和地方品种保护，合理迁入规则可以完全不同。

18.11 最优贡献的几何与约束

18.11.1 为什么关系矩阵进入二次项

对贡献向量 c ，群体共祖 $\frac{1}{2}c'Ac$ 汇总从所选基因库抽取两个基因拷贝时的预期共同祖先程度。高贡献个体的自身项按贡献平方进入，两个相关个体的共同使用则通过交叉项进入。因此把一个公畜使用比例加倍，带来的关系代价不只是线性加倍；与它相关的其他公畜使用多少也会影响边际代价。

在 A 半正定时，这一二次量形成凸的关系约束区域。线性目标 $\hat{h}'c$ 在贡

献总和、性别总和、非负和上限限制下寻求最大值。该结构使基础最优贡献问题具有清楚的数学性质，但如果加入整数配种次数、互斥候选组或非线性后代价值，问题结构会改变，不能沿用所有连续凸问题的保证。

若暂时只有贡献总和为一、没有非负边界且 A 正定，最小共祖方向与 $A^{-1}\mathbf{1}$ 成比例。归一化得到 $c = A^{-1}\mathbf{1} / (\mathbf{1}'A^{-1}\mathbf{1})$ ，最小共祖为 $1 / (2\mathbf{1}'A^{-1}\mathbf{1})$ 。若某个分量为负，这个代数解不符合真实遗传贡献，必须加入非负约束重新求解。不能把负贡献解释为“少用一点”而继续当作可实施方案。

18.11.2 收益与关系的边际平衡

也可以通过惩罚形式理解最优贡献，最大化 $\hat{h}'c - \frac{1}{2}\lambda c'Ac$ ，同时保持贡献总和等约束。在没有活动边界的内部，某个候选是否值得增加贡献，取决于它的目标预测值与其对当前组合增加的关系代价。边际关系代价由 $(Ac)_j$ 给出，说明一个候选的价值不能脱离当前已经使用的其他个体来评价。

这与简单给每个个体加一个固定近交罚分不同。个体自身近交高，不必然意味着它与当前候选组合关系最高；一个自身不近交的动物，也可能与大量已选个体共享祖先。贡献优化利用的是整个群体关系结构。实践中如果只按个体近交排序后截留，可能错过更好的目标与多样性折中。

惩罚参数 λ 与共祖上限可以生成同一类取舍，但解释方式不同。上限适合表达不可超过的多样性预算；惩罚参数适合表达边际交换价值。报告时最好同时给出实际达到的共祖和目标均值，不只公布参数。若不同群体的关系矩阵基准不同，使用相同 λ 或相同数值上限也未必代表相同生物学压力。

18.11.3 四亲本例子的完整可行范围

在例 18.2 中，两性贡献各为一半，公畜之间关系为 0.5，母畜彼此无关。由于各性别内部对称，等量贡献给出最小共祖 0.15625。因此若有人设置上限 0.15，问题没有可行解。求解器返回失败可能反映真实约束矛盾，不能总是归因于算法不好。首先应计算最小可达到的共祖，再讨论收益目标。

当共祖上限从最小值放宽到 0.25，最优目标均值从 9.5 增加到 10，贡献逐步向最高分公畜与母畜集中。上限为 0.18 时的贡献解位于两端之间，体现

了同一群体内部连续的交换关系。若进一步放宽到超过 0.25，目标不会继续提高，因为当前候选中已经没有更高分组合。约束不活动时，继续放宽它没有收益。

在实际大群体中，前沿可能出现拐点：某个亲本达到使用上限，或者另一个候选开始进入最优组合。拐点往往具有操作意义，说明再追求一点收益需要增加一个新家系、改变某个繁殖上限或承担明显更多关系。用前沿图展示这些变化，比只报告单一最优解更有助于育种者理解方案。




图 18.1 四亲本贡献优化的目标与共祖前沿

图 18.1 依据例 18.2 四亲本目标值与关系矩阵绘制。两性遗传贡献各合计二分之一；左图为不同共祖上限下的最优目标值，右图为相应贡献。上限低于 0.15625 不可行，达到 0.25 时只使用两性各最高分个体。本例全部公母间关系为零，所以图中群体共祖不能解释为当代后代近交。

18.12 从贡献比例到配种计划

18.12.1 两个优化问题的输入输出不同

贡献优化决定每个亲本在下一代基因库中的份额，配种优化决定哪些父母配对以及每个配对产生多少后代。若公畜 s 和母畜 d 的配种比例为 m_{sd} ，所有配种比例之和为一，则公畜遗传贡献为该行和的一半，母畜遗传贡献为该列和的一半。因而配种矩阵的边际和必须与预定贡献一致。若配种阶段随意改变边际和，就已经修改了贡献优化的结果。

给定边际贡献，可以在许多配对矩阵之间选择。加性遗传均值在理想传递下只依赖边际贡献，但后代近交、特定隐性缺陷风险以及非加性互作可能依赖配对方式。这正是第二阶段仍有优化空间的原因。若目标包含明显的配对特异价值，分两阶段优化可能不是全局最优，需要联合考虑贡献与配对，或者在两者间进行有明确收敛标准的迭代。

实际母畜通常每个繁殖期只能安排一次或少数几次有效繁殖，公畜则可能有更高但仍有限的使用上限。配种计划还受地理位置、发情时间、精液批次和健康隔离限制。这些限制不属于遗传关系矩阵本身，却决定一个数学方案能否执行。设计时应尽早把它们转为明确可行集合，避免在最后人工大量修改而破坏原有保障。

18.12.2 同样贡献可以产生不同后代近交

考虑两只公畜和两只母畜，四者贡献均为四分之一。设公母关系中，公畜一与母畜一、公畜二与母畜二的加性关系均为 0.25，另外两种交叉配对的关系为零。若只安排两个对应配对，各占一半，则每个后代的近交为 0.125，平均也为 0.125；若安排两个交叉配对，各占一半，平均后代近交为零。

两种计划具有完全相同的亲本贡献和群体共祖，只是配对不同。因此不能仅凭最优贡献已经控制关系，就认为所有配种安排都同样安全。这个教学关系矩阵可以由相应亲缘结构构造，完整矩阵取对角为一、只保留上述公母非零关系时是正定的，故不只是随意填入不可能的关系数字。

如果把两种配对各安排四分之一，后代平均近交为 0.0625，但后代之间并不均匀：一半为 0.125，一半为零。只报告均值会遮住个体风险分布。如果育种计划要求每个后代近交不超过某一上限，应对每个允许配对设约束；如果只控制平均值，应同时报告最大值或高分位数，使风险集中可见。

18.12.3 隐性缺陷与携带者管理

对已知常染色体隐性有害变异，在完全外显且没有其他复杂因素的简单模型下，两个杂合携带者配对产生受影响后代的概率为四分之一；携带者与经过可靠检测的非携带者配对不会产生该位点的隐性纯合受影响后代。由此

可以在保留携带者其他优良遗传价值的同时，避免高风险配对，并逐步降低不利等位基因频率。

立即淘汰所有携带者可能在某些情形下合理，但若携带率高或集中于重要家系，也可能明显减少遗传多样性。决策应比较缺陷严重性、检测准确性、可用替代者、繁殖规模以及频率降低时间。不能因为理论上可避免携带者互配就忽略样本身份错误和检测不确定性，也不能因为缺陷有害就把所有关联遗传背景一并永久丢弃。

多个隐性位点同时存在时，配种可行性会更加复杂。一个公畜可能适合某些母畜而不适合另一些，简单按总指数排序后随机配对可能失效。应保存位点状态、检测置信度和亲本身份，并在配种优化中计算相关风险。对未知隐性负荷，关系与基因组纯合指标仍有辅助价值，但不能把它们当作已知每个致病变异的替代信息。

18.12.4 连续比例取整后的重新校核

例 18.2 的最优贡献中，公畜份额约为 0.427951, 0.072049，对应父方使用比例约为 0.855903, 0.144097；母方使用比例约为 0.677951, 0.322049。若计划一百个后代，按最近整数取父方 86, 14，母方 68, 32，遗传贡献变为 (0.43, 0.07, 0.34, 0.16)′。此时目标均值为 9.77，共祖约为 0.18055，已经略高于原上限 0.18。

这个偏离很小，却说明四舍五入不能被视为自动保持约束。若改为父方 85, 15、母方 68, 32，贡献为 (0.425, 0.075, 0.34, 0.16)′，目标为 9.765，共祖约为 0.1796625，满足上限。这里只比较了两个附近方案，没有声称后者是所有整数方案中的唯一最优；完整整数优化可以系统寻找更好的可实施组合。

实际出生数还会偏离计划配种数。若不同配对受胎率明显不同，可以按预期成功数设定计划，并在出生后更新实际贡献；如果受胎率未知，应作敏感性分析并留出调整空间。最优计划不是一次打印后永远不变的清单，而是包含执行反馈的决策流程。核心原则是每次实质修改后重新核算目标和约束。

18.13 系谱、基因组与近交指标的基准

18.13.1 预期共享与实现共享

系谱加性关系矩阵根据已知祖先计算遗传共享的期望。同胞具有相同的系谱期望关系，但由于孟德尔抽样，实际共享染色体片段不同。基因组资料能够区分这种实现差异，为贡献与配种决策提供更细信息。然而，基因组矩阵并不是不依赖定义的唯一真值；其构造使用了特定标记、等位基因频率和缩放方式，反映的是相对于这些基准的相似程度。

若以当前群体频率中心化，矩阵可能把当前常见状态视为基准；若使用历史基础群频率，所表达的累积变化不同。两个矩阵数值都可能合理，但适合回答不同问题。将某个矩阵直接代入既有共祖阈值前，应检查对角与非对角尺度、基础群假定及与系谱的相容性。否则相同数值上限可能对应完全不同的实际约束。

Gautason 等（2023）以模拟评价亲缘矩阵选择对最优贡献表现的影响，强调矩阵定义会影响受控制的遗传变异。它支持“应检验控制目标与矩阵是否一致”这一方法学判断，并不证明某一种矩阵在所有物种、选择目标和时间跨度下普遍最佳。实际应用应在相同资料和可执行约束下比较长长期响应、基因频率变异和近交，而不是只比较第一代目标值。

18.13.2 纯合片段提供不同时间尺度的信息

连续纯合片段可以反映共同祖先传递的染色体区段。较长片段通常与较近的共同祖先有关，因为经历的重组机会较少；较短片段可能来自更久远共享，但其检测也更易受标记密度、分型误差和算法阈值影响。不能只凭“长”或“短”作绝对年代判断，应说明所用遗传图谱、片段阈值和数据质量。

以纯合片段总长度除以被评价基因组长度可形成一种近交指标。分母必须明确，例如是否排除低覆盖区、性染色体或难以检测的区域。不同芯片或测序平台若覆盖范围不同，直接比较指标可能混入技术差异。长期监测最好维持可比计算流程，或者在方法更新时用共同样本建立转换和敏感性检查。

纯合片段既可用于总体近交监测，也可帮助发现局部同质化。但不能把

所有纯合都等同于有害：一些区域可能因有利选择而趋于固定，另一些可能携带不利隐性负荷，含义需结合功能证据和群体历史。育种计划应避免在缺乏证据时给每个纯合片段统一经济惩罚，也不能因为某个区域与产量有关就忽略其健康关联。

18.13.3 控制中性多样性与保持目标潜力

全基因组关系控制主要反映广泛共享，而未来选择潜力还取决于与目标有关的变异。在某些遗传架构下，中性标记多样性与目标性状变异并不完全同步。可能保留较多中性变异，却在关键适应性位点失去重要等位基因；也可能因某些有利位点固定而降低局部多样性，同时提高当前目标水平。

这并不意味着应完全放弃整体关系控制，而是说明它是可操作的代理目标。若已知重要功能位点或适应性单倍型，可以在总体关系约束之外增加明确的保留要求，并评估对当前进展的代价。对未知未来性状，保持广泛遗传背景仍有价值，但应将其表述为降低不可逆损失风险，而不是保证任何未来目标都能迅速改良。

18.14 不同畜种与育种系统的长期设计

18.14.1 奶牛核心群与广泛公畜使用

人工授精使优秀奶牛公畜能够影响大量后代，因而提高青年公畜评价效率和缩短父方路径具有潜在价值。同时，少数公畜的广泛使用使家系集中具有较强传播效应。计划应把候选公畜的独立家系来源、青年预测校准、后续女儿验证和实际精液使用共同纳入管理。只按发布时的最高指数推广，可能把共同预测误差放大到很大范围。

对一个构造的奶牛教学系统，可以比较成熟公畜较高准确度与青年公畜较短间隔，并为青年公畜设置单头使用上限，以控制尚未验证的信息风险。使用上限应根据后代规模、联合误差和参考更新能力设置，而不是任意固定一个通用数目。随着新后代记录到来，可以更新贡献，但应保存每个决策时点可用的信息，避免事后用完全资料评价当初的判断。

母方路径同样重要。若核心供体集中于少数高排名母牛，胚胎技术可能同时提高选择强度和家系相关。长期设计应比较供体数量、单头后代数、体外繁殖成功和实际留种比例对整体响应的影响。繁殖技术的价值来自改变可实现的遗传传递，而不是技术名称本身。

18.14.2 肉牛肉羊与分散生产环境

肉牛和肉羊常面临季节繁殖、牧场环境差异和自然交配比例较高等条件。一个高预测值公畜若难以适应目标环境或无法在规定季节提供足够有效配种，其理论贡献难以兑现。选择计划应把环境适应、繁殖能力、运输与隔离条件纳入可行性，同时努力维持场间遗传联系，以免某些家系的高分主要反映有利管理环境。

在分散小群体中，单场独立追求最大短期进展可能造成公畜重复使用和近亲累积。跨场协调交换遗传材料有助于扩大候选来源，但需要准确身份、亲子记录和一致的健康管理。轮换公畜并不自动避免近交：若不同场引入的是同一热门祖先的后代，表面上换了个体，遗传上仍可能高度相关。

地方适应型品种还可能承担粗饲利用、耐热、抗病和低投入系统功能。若直接套用高投入环境的目标，短期商品性状改良可能伴随适应能力下降。应以实际生产环境中的净收益和生存繁殖表现制定目标，并在多环境验证中检查遗传相关。保护与改良不是必然对立，但需要明确哪些特征是品种持续价值的一部分。

18.14.3 猪禽商业品系与交叉配套

猪禽往往具有较短世代间隔和较高繁殖率，能够较快积累进展，也可能较快积累关系。核心纯系选育与商品杂交生产之间存在不同目标层级：纯系内的育种值预测、杂交表现以及父母系在配套中的功能需要区分。某一纯系单性状进展很快，并不保证整个商品组合的净收益最大。

母系常强调繁殖、成活和母性功能，父系可能更强调生长、胴体和效率；具体目标取决于系统边界。长期比较应追踪各系内部近交、跨系互补和杂交后代表现，而不是只监测商品群平均杂合度。商品杂交并不会自动修复核心

纯系中已经丢失的变异，纯系自身仍需合理贡献管理。

高繁殖率也提供了家系均衡和分阶段测定机会。可以在早期保留足够家系覆盖，再以个体资料提高后期准确度。不过，若后期只在少数家系中高强度选择，早期均衡未必转化为最终多样性。应以最终替代亲本贡献作为长期评估依据，并研究不同阶段的信息分配与家系保留如何共同影响效率。

18.14.4 水产繁殖与家系存活差异

水产物种的高产卵量容易给人候选数量无限的印象，但有效家系数量和真实亲本贡献可能受到受精、早期存活和养殖环境强烈影响。如果只有少数家系在共同养殖中大量存活，名义上使用很多亲本也可能形成较小有效群体。亲子鉴定、家系追踪和代表性取样因而对长期管理十分重要。

单独家系养殖便于记录来源，却可能把家系遗传效应与共同环境混淆；尽早混养可以减小某些环境差异，但需要可靠身份识别。不同方案应同时比较记录成本、遗传评价偏差、候选覆盖和实际贡献。家系数、每家系测定数和进入下一代比例是三个不同控制量，不能只用其中一个描述整个设计。

这些畜种差异说明，长期育种方法应保持统一的遗传逻辑，但实施参数必须来自具体繁殖与生产制度。把一种物种的最短间隔、最高选择强度或推荐近交上限直接移植到另一种系统，通常缺乏充分依据。教材公式是组织问题的工具，实际方案还需要生物学和运营约束共同限定。

18.15 多样性的时间尺度与未来适应

18.15.1 每代控制与每年控制不能混同

同样的每代近交增量，在不同世代间隔下意味着不同年度累积速度。缩短世代间隔通常提高年度遗传进展，也让更多代繁殖在相同日历时间内发生。如果维持原有每代近交增量不变，二十年后的累积近交可能明显增加。因此比较快速与缓慢更新方案时，应同时报告每代和每年指标，并明确控制约束针对哪一种尺度。

构造两个近似离散世代方案。甲每四年一代，每代近交增量为 0.005；乙

每两年一代，每代增量为 0.01。从零基础近交出发，二十年后甲经历五代，近交约为 0.024751；乙经历十代，近交约为 0.095618。如果只比较甲乙某一代的遗传响应而忽略代数差异，就无法判断相同时间跨度内的多样性代价。

假设同一教学模型中，甲准确度为 0.8，乙为 0.65，选择强度均为 1.4，遗传标准差为 10。固定方差近似下，年度进展分别为 2.8 和 4.55。乙短期更快，但上述近交轨迹提示其长期收益需要同时考虑变异损失和可能的近交衰退。这个例子没有给出后者参数，所以不能据此计算净长期优势；它说明应把比较问题完整地提出。

18.15.2 近交衰退不是加性响应的简单反号

近交衰退常与隐性不利效应暴露和其他非加性机制有关，其大小依赖性状、群体历史和环境。加性遗传进展则来自所选择等位基因的平均传递效应。两者可以同时发生：群体在某些生产性状上持续获得加性改良，生存或繁殖表现却因近交而受到抵消。不能以一个总表型趋势证明不存在近交衰退，也不能把所有不利趋势归因于近交。

若某个经过独立估计的教学模型规定，每增加一个百分点近交，某净收益指标下降 2 个单位，那么近交从零升至百分之五会对应 10 单位的预测损失。这个线性换算只在规定范围和模型成立时适用，不应把某一群体的回归系数推广到所有物种。估计时还要控制世代、遗传趋势、环境和选择偏差，因为高近交个体可能同时属于高产家系。

“清除遗传负荷”不能作为放任近交的普遍理由。选择有时能够降低严重隐性有害等位基因的频率，但清除过程可能伴随死亡、繁殖失败和不可逆变异损失，而且对轻微有害变异未必高效。长期管理应依据实际证据评价负荷变化，而不是预期未来自然清除会自动补偿今天的风险。

18.15.3 未来目标改变时保留选择空间

育种目标可能因气候、资源价格、消费者需求或疾病压力而改变。当前不占优势的遗传背景，在另一环境中可能提供有用适应性。保持多样性可以降低某些不可逆损失的风险，但并不意味着每个低值个体都具有无限未来价

值。合理方法是保留足够广泛且有代表性的遗传来源，并为已知重要适应性建立明确记录和评价。

冷冻资源库为未来恢复提供机会，却受到材料数量、繁殖技术、健康状况和恢复时间限制。保存一支精液不等于已经保住一条可迅速恢复的完整母系或群体结构。应设计代表性采样、重复保存和可追踪身份，并定期评估材料可用性。资源库与活体群的贡献管理互为补充：前者提供恢复可能，后者维持持续演化与现实生产能力。

对未来目标高度不确定的系统，可以比较多组目标转换情景，计算不同当前策略在转换后的适应速度。评价指标不只包括转换前累计收益，还包括转换后达到新目标所需代数、剩余遗传方差和恢复成本。这类分析把“为未来保留潜力”变成可讨论的具体问题，同时承认未来情景本身仍有不确定性。

18.16 测定预算与长期计划的共同优化

18.16.1 候选规模、准确度和时间相互竞争

固定预算下，测定更多候选可以提高选择强度，测定更深入可能提高准确度，等待更多资料可能延长世代间隔。三者不能分别推至最高再相乘，因为它们共享资源并相互制约。一个较便宜但适度准确的方案，可能通过扩大候选群和缩短等待提高年度进展；一个较贵方案则可能通过更可靠的健康和繁殖评价减少失败。应在共同预算和相同实施目标下比较。

构造预算为 30000 的两种教学测定策略。甲对二百个候选各花费 150，最终选十个，准确度为 0.55，世代间隔为 2.5 年；乙对一百个候选各花费 300，同样选十个，准确度为 0.70，间隔为三年。假定实际选择分数正态、候选近似独立、遗传标准差为 10，两者选择强度分别约为 2.062713 和 1.754983，年度进展约为 4.537968 和 4.094961。

在这些假设下，甲较低准确度被更高选择强度和更短间隔补偿。但此比较尚未加入家系相关、长期多样性、测定对公共参考群的价值和实际繁殖上限。如果甲的二百个候选高度相关，或低成本资料遗漏关键健康风险，其优势可能缩小或消失。因此这一算例展示的是资源交换机制，不是低价测定优

于高质量测定的普遍结论。

18.16.2 公共信息价值与个体选择价值

某些测定的直接受益者不只被测动物。对一个代表性家系进行高质量饲料或排放测定，可以提高很多亲属和未来候选的预测准确度。其成本收益应按影响范围与持续时间评价。如果仅把全部成本归到该动物当年的选留价值，可能低估参考群建设；若把所有未来候选收益无条件归给一个测定，又可能重复计算。

可以将收益分为本轮个体选择、同代亲属预测、未来模型更新和性状定义改进等部分，再检查是否重叠。对参考群，资料多样性与代表性往往和样本数量同样重要。不断重复测定高度相似家系，可能增加名义样本量却较少提高目标环境的有效信息。第 15 章的信息增量原则在这里延伸为育种计划的长期投资问题。

信息会随群体变化而贬值。标记效应、连锁不平衡、亲缘结构和环境关系变化可能降低旧参考对新候选的预测能力。长期预算必须安排持续更新，而不是一次建立参考群后永远使用相同准确度。应在时间外验证中估计准确度衰减，并比较不同更新规模 and 家系覆盖策略对年度响应的影响。

18.16.3 联合评价成本、收益与失败风险

完整计划比较应把测定、分型、繁殖、数据管理、推广和多样性保护成本纳入同一时间框架。收益应来自相同系统边界下的实际目标变化，并包含传播滞后。若某一方案需要新设施，启动投资与运行费用应区分；若能够共享现有资源，也应明确机会成本，而不是把已有设施视为完全免费。

除了净现值，还可以报告单位预算年度进展、达到某目标所需时间、约束违反概率和最坏合理情景损失。不同指标回答不同问题，不能通过任意标准化后相加制造一个看似客观的总分。若计划受到硬预算或存续风险限制，应先判断可行性，再比较剩余方案的经济与遗传表现。

实际实施通常适合逐步扩展。先在足够代表性的候选和环境验证测定流程、预测校准与繁殖可执行性，再扩大规模。试点不是为已选方案寻找支

持，而应事先规定什么结果会支持扩展、修改或停止。这样可把不可逆的大规模家系集中风险降到可管理程度，同时为后续优化提供真实反馈。

18.17 多代模拟、验证与可复现报告

18.17.1 模拟必须明确遗传与运营过程

长期模拟至少需要描述基础群体、遗传架构、重组、表型生成、预测更新、选择规则、贡献与配种、出生及存活，以及进入下一轮的条件。如果只把每代均值增加一个固定数，就无法研究 Bulmer 效应、漂变、预测误差相关或近交控制。模型复杂度应由研究问题决定，但决定结论的机制不能被省略后又在讨论中声称已经考虑。

对比较两种选择策略，最好在相同基础群和共同环境随机数下成对运行，使差异更集中反映策略。每个重复仍需保持遗传与繁殖过程的一致性。共同随机数有助于降低比较噪声，但不能消除模型结构错误。研究者还应检查极端或简单情形，例如无选择时均值是否按预期稳定、随机交配的关系递推是否正确、完美预测是否达到合理上界。

模拟参数应覆盖合理范围。一个方法在单一遗传架构下胜出，不能直接推广到多基因、寡基因、不同标记密度和不同环境相关。可以分层改变关键条件，展示方法优势出现或消失的区域。参数空间不必无限扩张，但应针对可能改变结论的具体风险，而不是机械增加大量无关情景。

18.17.2 多代结果应展示分布和分解

每代应至少跟踪目标均值、各性状均值、加性方差、基础基因频率方差或其他适当变异指标、近交、群体共祖、家系贡献和实际繁殖成功。只展示总目标均值可能掩盖某个健康性状持续恶化；只展示最终近交可能掩盖中间某代出现严重瓶颈。时间轨迹与最终汇总应互相补充。

不同重复间的差异尤其重要。某策略平均收益较高，但少数重复发生极端家系流失，其风险可能不符合实际计划要求。应报告适当分位数或失败比例，并说明重复数对尾部估计的限制。若某种失败极少见，观察到零次不等

于概率严格为零；可以给出有限重复下的统计不确定性，而不是作绝对安全承诺。

对遗传进展还应分解为选择强度、预测准确度、世代间隔和可用方差的变化。在新方法收益下降时，分解能够帮助识别是参考群衰减、贡献约束变紧、繁殖失败还是遗传变异减少。仅比较最终均值差通常不足以指导改进，也容易把机制不同的方案误认为可以互相替代。

18.17.3 历史重演与真实前瞻验证

历史重演应在每个历史时点只使用当时能够获得的资料。若把后来出生的后代记录用于早期候选评价，再声称该策略当年就能作出更好选择，便发生信息泄漏。需要按时间截断资料、重建当时可行候选和繁殖约束，并区分实际已观察后代与反事实无法观察的后代。历史数据能够检验部分预测与运营问题，不能完全观察未实施策略的真实多代结果。

前瞻验证则需要预先设定评价目标、对照和随访时间。长期遗传优势可能需要多个世代才能显现，短期试验应选择能够检验关键机制的中间指标，例如预测校准、贡献实现、后代近交分布和记录覆盖。不能把一个短期计算速度改进直接等同于长期遗传收益，也不能因为第一代差异不显著就断言长期贡献控制没有价值。

Waldmann (2025) 等关于贡献与配种优化工具的研究，为提高计划可执行性提供了新方法；Ahlander 与 Waldmann (2026) 进一步将联合预测不确定性纳入风险敏感决策。这些进展值得作为研究方向，但其在不同家畜生产体系中的长期表现仍需要相应数据、约束和连续世代检验。教材应把已经证明的计算或统计性质，与尚需验证的生产外推分开。

18.17.4 保存足以重建结论的材料

可复现报告应保存参数来源、代码版本、随机种子、基础群生成方法、求解容差和主要输出，并对无法公开的个体资料提供结构说明或可运行教学替代数据。随机种子只能重现同一伪随机序列，不能弥补缺失的算法版本或输入数据。对优化结果，还应记录求解状态、可行性误差以及连续与整数方

案的差异。

文章或报告正文不必展示所有技术日志，但应给出读者判断可信度所需的信息：用了多少重复、比较是否公平、最重要假设是什么、哪些结论对参数敏感、是否存在未收敛或不可行情景。把失败运行静默删除会偏移结果分布，尤其当失败与极端关系或风险条件相关时。应说明排除规则，并分析这些失败本身是否具有科学含义。

长期育种设计最终是一项持续修订的工程。模型提供明确预测，实际记录检验预测，新的证据再更新目标和方案。高质量方法不要求一开始知道所有未来条件，而要求每个阶段都能解释决策依据、识别偏离并保留调整能力。这种可学习、可追踪的制度，比一次性得到一个看似精确的最优数值更有持久价值。

18.18 年龄结构中的遗传传播与生殖价值

把选择差除以平均世代间隔，可以得到稳定条件下的年度进展，但这一步掩盖了一个过程：某年出生的优秀个体并不会立即以固定比例进入所有年龄组，它们的后代也可能在若干年后才成为亲本。Hill (1974) 用年龄组和性别之间的遗传传播矩阵研究这种过渡及其折现收益。下面从一个能够手算的年龄模型出发，推导平均世代间隔为什么会出现在长期斜率的分母，并说明短期进展为何可能围绕这个斜率波动。

先考虑已经合并父母两条传递路径的教学群体。每年只有一龄和二龄亲本繁殖，两年龄组对新生个体基因库的比例分别为 w_1, w_2 ，两者非负且和为一。比例已经包含亲本使用数量、繁殖成功和父母各传递一半的权重，不是存栏头数的比例。令 x_t 记录当前一龄与二龄组的平均加性育种值，令 S 为每年新生一代相对于未选择亲本加权均值的遗传优势，则

$$x_{t+1} = Mx_t + e_1 S, \quad M = \begin{pmatrix} w_1 & w_2 \\ 1 & 0 \end{pmatrix}, \quad e_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

第一行表示亲本来源的加权平均，再加上当年选择带来的新优势；第二行表示原来的一龄组进入二龄组。这里假设组内存活不会再次改变育种值均

值, 年龄贡献和选择优势不随时间变化。若保留阶段还进行了遗传选择, 就必须给相应年龄转换添加选择项。 M 的行和为一, 因为它传递的是遗传均值而不是个体数量, 因此不能直接用一个未经归一化的人口数量增长矩阵替代它。

长期进展可以借助一个特殊加权平均来识别。寻找非负向量 π , 使

$$\pi' M = \pi', \quad \pi' \mathbf{1} = 1.$$

这意味着在没有新选择优势时, $\pi' x_t$ 不随年龄转换改变。它给各年龄组的权重取决于其遗传成分在未来传播的机会, 称为这里的生殖价值权重。对两年龄模型直接解方程可得

$$\pi_1 = \frac{1}{1+w_2}, \quad \pi_2 = \frac{w_2}{1+w_2}, \quad \pi' x_{t+1} - \pi' x_t = \pi_1 S.$$

由于平均亲本年龄为 $L = w_1 + 2w_2 = 1 + w_2$, 每年生殖价值加权均值增加 S/L 。如果除特征值一以外的其他特征值绝对值均小于一, 各年龄组最终具有相同的线性增长斜率, 年龄组之间保留稳定的水平差。因此“除以世代间隔”不是对时间的随意换算, 而是年龄传播结构在长期状态下的结果。

取 $w_1 = 0.25, w_2 = 0.75, S = 1.4$, 初始两个年龄组均值都为零。连续六年的新生均值为 1.4, 1.75, 2.8875, 3.434375, 4.424219, 5.081836。第一年的跃升明显大于长期年进展, 而第二年的新增只有 0.35; 这些起伏不说明选择方法忽然有效又忽然无效。矩阵另一个特征值为 -0.75 , 它使初始年龄结构偏离产生逐步衰减的交替波动。稳定斜率为 $1.4/1.75 = 0.8$, 生殖价值权重为 $(4/7, 3/7)'$ 。

这个结果可推广到最高繁殖年龄为 A 的更新模型。若年龄 a 的基因贡献比例为 w_a , 则新生均值满足

$$u_t = \sum_{a=1}^A w_a u_{t-a} + S, \quad \sum_{a=1}^A w_a = 1.$$

把长期形式 $u_t = gt + d$ 代入, 时间项抵消后得到

$$g = \frac{S}{L}, \quad L = \sum_{a=1}^A a w_a.$$

相应年龄状态矩阵的左特征向量为

$$\pi_j = \frac{\sum_{a=j}^A w_a}{L}, \quad j = 1, \dots, A.$$

验证只需注意：每个 w_a 在归一化求和中出现 a 次。因此年龄越小，未来仍能经过的繁殖机会通常越多，但具体权重不能仅由年龄大小判断，还依赖贡献分配。若所有繁殖只在同一个固定年龄发生，矩阵可能具有其他模为一的特征值，群体存在持续周期，不能把“每个日历年的增量都收敛”作为必然结论。此时跨周期平均斜率仍有意义，短期逐年预测则要保留年龄递推。

在奶牛更新、母猪胎次保留和种禽批次轮换中，这个模型提示了相同的操作原则：记录实际形成后代的年龄贡献，而不是用一个计划年龄替代全部过程。繁殖失败集中于某些年龄或家系时，贡献比例和选择优势会同时变化。若高遗传值的年轻候选使用不足、较老亲本反复补位，真正的传播矩阵会偏离设计值。评估制度变化，应先把基准年龄结构作为初始状态输入，再比较完整轨迹；从第一年就强制套用稳定斜率，会把过渡效应误归为遗传准确度的变化。

18.19 多层群体传播的卷积与折现算子

核心群的遗传优势还要经过扩繁层、商品层和生产年龄组，才成为可观察的产业收益。不同传播阶段的滞后能够叠加，而且“一次性使用优良亲本”和“从此永久提高核心群水平”是两种不同输入。把这两种输入混为一谈，会使收益持续年限出现成倍差异。下面采用线性传播模型，把遗传输入、传递速度与经济折现分开，再通过一个共同公式连接起来。

令 B_t 表示第 t 年核心来源的遗传水平， x_t 包含扩繁层和商品层的平均遗传水平。规定当年来源在下一年进入接收层，模型为

$$x_{t+1} = Tx_t + qB_t, \quad x_0 = 0.$$

T 记录旧遗传成分的保留和下游传递， q 记录核心来源的输入比例。若所有遗传成分最终可以被持续输入替代， T 的谱半径小于一。在来源恒定且

各层最终追上该来源的封闭比例模型中，还应满足 $T\mathbf{1} + q = \mathbf{1}$ 。反复代入得到

$$x_t = \sum_{j=0}^{t-1} T^{t-1-j} q B_j.$$

右侧是每年输入经过不同传播年数后贡献的总和，称为卷积表示。它允许同时分析多次核心改良：早年的改良传播得更充分，较新的改良更多停留在上游。若使用年度新进展作为输入，则应先将这些增量累计成核心遗传水平，或者相应改变传播模型，不能既把进展累计一次，又在传播公式中把同一进展当成永久阶跃累计第二次。

考虑扩繁层每年替换一半遗传来源，商品层每年从前一年的扩繁层更新四分之一。按此时间约定，

$$T = \begin{pmatrix} 0.5 & 0 \\ 0.25 & 0.75 \end{pmatrix}, \quad q = \begin{pmatrix} 0.5 \\ 0 \end{pmatrix}.$$

如果核心来源从零永久升至一，第一年扩繁层达到 0.5 而商品层仍为零，第二年商品层达到 0.125。两层最终都趋近一，但“最终达到相同水平”不等于“短期收益相同”。更快的更新可以减少传播滞后，却也可能提高更新成本、改变寿命结构或减少已投入生产个体的使用价值；这些后果应进入同一个计划比较。

若核心群长期每年进步 g ，即 $B_t = gt$ ，尝试将下游长期轨迹写为 $x_t = gt\mathbf{1} - g\ell$ 。代回递推并利用行和条件，可得

$$(I - T)\ell = \mathbf{1}, \quad \ell = (I - T)^{-1}\mathbf{1}.$$

本例 $\ell = (2, 6)'$ 。按照已经规定的年度输入时点，扩繁层长期相当于落后核心两年，商品层落后六年；后一数字包含两级更新过程，不只是商品层四年更新速度的倒数。如果把来源进入接收层的时间定义改成当年，滞后常数也会改变。因此报告遗传滞后时必须同时给出时间索引和传播路径，而不能只公布一个没有时点定义的年数。

再令 $0 < \delta < 1$ 为年折现因子, v 为各层每单位遗传水平的年度价值向量。对只有 $B_0 = 1$ 、其后为零的脉冲输入, 第 $t \geq 1$ 年状态为 $T^{t-1}q$, 总折现价值为

$$\begin{aligned} V_{imp} &= \sum_{t=1}^{\infty} \delta^t v' T^{t-1} q \\ &= \delta v' (I - \delta T)^{-1} q. \end{aligned}$$

矩阵逆汇集了所有未来传播路径, 并不是额外的收益来源。对于从第零年开始每年都有 $B_t = 1$ 的永久水平提高, 利用线性性可得

$$V_{step} = \frac{V_{imp}}{1 - \delta}.$$

取 $\delta = 0.95$ 、只评价商品层, 即 $v = (0, 1)'$, 上述两种价值分别为 0.747412 和 14.948240。它们以“每年一个商品层遗传单位所值的收益”为计价基础, 没有假定任何实际货币收益。二者相差二十倍, 来自输入持续时间, 而不是预测准确度。如果只保存一次优良亲本的使用记录, 却把其效果当成永久核心水平改变, 就会错误地采用第二个数。

这一工具还可计算传播参数的边际价值。若参数 θ 只改变 T 而不改变 q 和 v , 令 $R_\delta = (I - \delta T)^{-1}$, 则

$$\frac{\partial V_{imp}}{\partial \theta} = \delta^2 v' R_\delta \frac{\partial T}{\partial \theta} R_\delta q.$$

如果更新率改变的同时也改变外部输入比例, 就必须另外加入 $\delta v' R_\delta \partial q / \partial \theta$ 。遗漏这个项可能错误判断更新提速的方向, 因为增加新来源通常伴随减少旧来源保留。在封闭商业体系外, 外购来源质量、扩繁规模、价格和需求也可能随时间变化, 此时使用逐年的矩阵乘积, 而不是固定矩阵幂。线性模型仍是透明的起点, 但只有在线性传递、参数稳定和收益可加的范围, 才能把无限期折现值解释为实际计划价值。

18.20 准确度内生变化时的 Bulmer 递推

前面采用固定准确度的递推, 能够清楚显示选择诱发的连锁不平衡。更深入的问题是: 如果候选加性方差已经改变, 而环境方差保持不变, 以自身

表型作选择的准确度还会保持不变吗？答案通常是否定的。将准确度与当前方差联立，可以揭示固定准确度近似遗漏的反馈，也有助于区分选择所压低的总加性方差与长期基因频率决定的可恢复方差。Bulmer (1971) 所强调的选择诱发不平衡，是建立这种分析的理论基础。

设候选育种值 u 与环境偏差 e 独立，方差分别为 V_t 和 E ，实际选择分数为 $y = u + e$ 。在联合正态模型下，条件均值为线性回归：

$$E(u | y) = \frac{V_t}{V_t + E}y, \quad \text{Var}(u | y) = \frac{V_t E}{V_t + E}.$$

截留标准化表型上部比例，使所留表型方差成为原方差的 $1 - k$ 倍，其中 $k = i(i - z)$ ， z 是截留点、 i 是相应选择强度。利用条件方差分解，所留亲本的育种值方差为

$$\begin{aligned} V_t^s &= \frac{V_t E}{V_t + E} + \frac{V_t^2}{V_t + E}(1 - k) \\ &= V_t - \frac{k V_t^2}{V_t + E}. \end{aligned}$$

被扣去的方差取决于当前 V_t ，不能将初始遗传力代入后永远不变。环境方差越大，表型排序越难压缩真正的遗传差异；随着遗传方差下降，同一测定体系的表型选择准确度也下降。这里的准确度平方是 $V_t / (V_t + E)$ ，它是当前候选群的量，不是某个独立参考基础群的固定参数。

进一步采用两性受到相同选择、亲本随机配对、无连锁的无限小模型近似，并把基因频率方差 V_{genic} 视为恒定。子代方差由所留亲本方差的一半与孟德尔抽样恢复项构成：

$$V_{t+1} = \frac{1}{2} \left(V_t - \frac{k V_t^2}{V_t + E} \right) + \frac{1}{2} V_{genic}.$$

平衡方差满足

$$(1 + k) V_*^2 + (E - V_{genic}) V_* - V_{genic} E = 0.$$

取非负根，得到

$$V_* = \frac{V_{genic} - E + \sqrt{(E - V_{genic})^2 + 4(1 + k) V_{genic} E}}{2(1 + k)}.$$

这一表达式把方差、环境噪声和选择程度之间的反馈明确放在同一方程中。它不是对所有实际育种群体都成立的经验公式；持续有限群体选择还会改变基因频率方差，亲本相关、非随机配种及紧密连锁也会改变恢复项。对于不同性别采用不同选择制度的情形，父母贡献应分别递推，不能直接把二者选择系数作没有权重的平均。

教学例取 $V_0 = V_{genic} = 100, E = 100, k = 0.8$ 。这里先指定方差压缩系数研究递推，若另需计算实际选择强度，应再由截留比例确定相容的 i, z 。第一代方差为 80，第二代为 75.777778，以后趋于 $100/\sqrt{1.8} = 74.535599$ 。当前准确度平方由初始 0.5 降至约 0.427051。当选择强度保持相同时，响应除以选择强度的量为

$$\frac{\Delta \bar{u}_t}{i} = \frac{V_t}{\sqrt{V_t + E}},$$

其值由初始 7.071068 降为平衡时的 5.641853。因此不仅方差下降，准确度也同时下降。若只把遗传标准差降低、仍把原准确度固定，就会高估平衡响应。反过来，如果实际信息来源是高可靠度亲属与基因组联合预测，准确度随方差变化的机制就不再等于自身表型公式，需要新的联合协方差结构下重新计算。

局部稳定性可以通过递推函数 $f(V)$ 的导数检查：

$$f'(V) = \frac{1}{2} \left[1 - k \frac{V(V + 2E)}{(V + E)^2} \right].$$

在 $E > 0, 0 \leq k \leq 1$ 时，该导数介于零和二分之一之间，说明此教学递推不会产生发散振荡。数值运行如在这些条件下出现负方差或发散，首先应检查公式、单位和程序，而不是立即赋予新的生物学解释。若停止选择， k 变为零，模型向固定的基因频率方差恢复；若该方差已经实际流失，恢复目标必须随之下调。

多性状时也能用同样的条件分解。令候选加性协方差为 Σ_t , $c_t = \text{Cov}(u, I)$ ，指数方差为 $\sigma_{I,t}^2$ ，在联合正态条件下

$$\Sigma_t^s = \Sigma_t - k \frac{c_t c_t'}{\sigma_{I,t}^2}, \quad \Sigma_{t+1} = \frac{1}{2} \Sigma_t^s + \frac{1}{2} \Sigma_{genic}.$$

这是一项秩一压缩，但会同时改变方差与协方差。取 $\Sigma_t = \Sigma_{genic} = I_2$ 、 $c_t = (0.6, 0.3)'$ 、 $\sigma_{I,t}^2 = 1$ 、 $k = 0.8$ ，下一代协方差为

$$\Sigma_{t+1} = \begin{pmatrix} 0.856 & -0.072 \\ -0.072 & 0.964 \end{pmatrix}.$$

两个原来不相关的性状出现约 -0.079261 的遗传相关，并不需要假设发生新的拮抗突变；同时选择所诱发的不平衡已能产生这种现象。矩阵特征值为 1 与 0.82，仍为正定。不过，不能无限重复使用最初的 c_t ，因为指数信息与遗传结构会共同变化。持续递推时应更新协方差并检查联合矩阵的合法性，否则一个形式简单的扣减式也可能被错误参数推成非正定矩阵。

18.21 当代贡献如何转化为长期祖先贡献

一只亲本今年留下的后代比例，是一个即时贡献；它的后代以后有多少再次成为亲本，则决定这项贡献能否长期保存。长期贡献把谱系发展与遗传进展联系起来。Woolliams、Bijma 与 Villanueva (1999) 研究了选择条件下预期长期贡献及其与遗传进展的关系。这里先推导已知谱系上的条件期望传播，再讨论它与长期选择过程之间的差别，避免把一个短期配种比例当作不再变化的祖先份额。

令 Q_t 的第 i 行记录第 t 代个体 i 来自基础祖先的期望遗传份额，基础群 $Q_0 = I$ 。令 M_{t+1} 为子代到上一代亲本的传递矩阵：双亲已知时，每一行在父母两列各有二分之一。于是

$$Q_{t+1} = M_{t+1}Q_t, \quad Q_t \mathbf{1} = \mathbf{1}.$$

在暂不考虑选择偏倚的中性遗传来源解释下，这些是谱系条件下的期望份额，单个真实基因组的实现比例还会因孟德尔抽样而偏离它们。若第 t 代个体对待评价基因库的贡献为 c_t ，且 $\mathbf{1}'c_t = 1$ ，基础祖先的综合份额就是

$$r_t = Q_t'c_t, \quad \mathbf{1}'r_t = 1.$$

注意 c_t 是在当代个体之间分配, r_t 是在基础祖先之间分配; 两向量可能维度不同。即使每一轮都使当代贡献尽量平均, 过去已经占优势的家系仍可能通过多条亲缘路径累积较大的祖先份额。因此只报告今年选用了多少亲本, 不能判断长期谱系是否均衡。

构造四个互不相关基础来源、三个后继个体的例子, 已知谱系给出

$$Q = \begin{pmatrix} 0.5 & 0.5 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 \\ 0 & 0 & 0.5 & 0.5 \end{pmatrix}.$$

若后继个体未来贡献为 $(0.6, 0.3, 0.1)'$, 祖先份额为 $(0.45, 0.30, 0.20, 0.05)'$, 份额集中指标 $1/\sum_j r_j^2$ 约为 2.985075。若三个后继个体等量贡献, 祖先份额则为 $(1/3, 1/6, 1/3, 1/6)'$, 该指标为 3.6。这仍不是近交有效群体大小, 因为它只描述基础份额的集中, 并未包含后续孟德尔抽样、选择和各祖先之间的关系。它的用途是辨认哪一层谱系在集中, 而不是取代近交率定义。

还需要区别“基础遗传份额”与“完整加性关系”。用 A_t 表示相同基础下的关系矩阵, 子代育种值可分解为亲本平均与孟德尔抽样偏差。于是

$$A_{t+1} = M_{t+1}A_tM'_{t+1} + D_{t+1}.$$

在标准谱系递推假设下, D_{t+1} 为对角阵, 第 i 个双亲已知子代的对角元为

$$D_{ii} = 1 - \frac{1}{4}(A_{ss} + A_{dd}) = \frac{1}{2} - \frac{1}{4}(F_s + F_d).$$

这个恢复项不可省略。亲本平均的对角元为 $\frac{1}{4}(A_{ss} + A_{dd} + 2A_{sd})$, 加上 D_{ii} 后, 子代对角元为 $1 + \frac{1}{2}A_{sd}$, 恰好对应其近交系数 $F_i = A_{sd}/2$ 。若只用祖先份额重构关系矩阵, 就会遗漏子代所携带的新孟德尔抽样差异。

把递推展开, 令 $R_{t,k}$ 表示第 k 代遗传成分传至第 t 代的矩阵, 且 $R_{t,t} = I$, 则

$$A_t = Q_t A_0 Q'_t + \sum_{k=1}^t R_{t,k} D_k R'_{t,k}.$$

因此群体共祖分解为

$$\frac{1}{2}c'_t A_t c_t = \frac{1}{2}r'_t A_0 r_t + \frac{1}{2} \sum_{k=1}^t c'_t R_{t,k} D_k R'_{t,k} c_t.$$

第一项只衡量基础祖先成分引起的共祖，第二项包含后来形成并被共同继承的孟德尔抽样成分。这个分解说明了一个常见反例：两个群体可以具有相近的基础祖先份额，却因为中间使用少数特定后代而形成很不相同的关系结构。保存全部基础家系的名录，并不等于其实际遗传变异已被完整保留。

长期选择还会使未来传递矩阵与当前遗传优势相关。优秀个体的后代更可能在下一轮获选，因而预期长期贡献不只是把当前使用比例不断乘一个与遗传值无关的固定矩阵。选择前可以在模型中预测这种相关，选择后可以用实现谱系核对，但不能将二者混称为同一个确定值。对于与被选择位点连锁的实际染色体片段，中性谱系份额也未必等于真实基因组来源，需要借助分型或基因传递模拟分析。实践中应同时保留当代贡献、基础祖先份额、完整关系矩阵和实际近交轨迹，才能识别遗传集中发生在何处，并制定有针对性的后续调整。

18.22 多代最优贡献的状态价值与时间预算

单代最优贡献选择回答：在当前候选、当前关系和当前限制下，应怎样分配繁殖机会。多代问题还要回答：这一分配将给下一轮留下怎样的候选、遗传方差、年龄结构和信息条件。一个当前均值略高的方案，可能使未来可行域显著缩小；另一个方案的价值可能主要在未来目标改变时才出现。要讨论这种差别，就必须把未来机会明确写成状态价值，而不是把“长期”简单解释为多重复几次同一个单代目标。

令 s_t 包含当前候选遗传分布、关系、年龄构成和可用信息；控制 d_t 同时描述亲本贡献、配种及允许改变的测定投资。令 $R_t(s_t, d_t)$ 为当期收益，状态按随机转移 $s_{t+1} = \mathcal{I}(s_t, d_t, \xi_t)$ 更新。有限期价值函数为

$$V_t(s) = \max_{d \in \mathcal{D}(s)} \{R_t(s, d) + \delta E[V_{t+1}(\mathcal{I}(s, d, \xi)) | s, d]\},$$

$$V_T(s) = \Psi(s).$$

终端价值 Ψ 描述研究期结束时仍留在群体中的遗传资源和未来收益。将它直接设为零，等于假定期限结束之后再没有任何价值；这可能使最后几轮过度消耗多样性。反过来，随意给剩余方差一个很大的系数，也会人为偏向保守策略。因此终端价值应有明确的近似依据，并通过延长计算期限或改变终端设定检查结果是否稳定。

如果暂时只以贡献 c 为控制，在可微的确定性近似中，当期目标为 $g'c$ 、共祖限制为 $\frac{1}{2}c'Ac \leq \theta$ 、总贡献为一，那么内部最优解满足

$$g + \delta \nabla_c V_{t+1} - \lambda Ac - \nu \mathbf{1} = 0.$$

这里 $\nabla_c V_{t+1}$ 包含贡献对下一轮候选与状态的全部影响。它通常不是一个固定常数，也不必与 Ac 同方向。因此把共祖罚系数调大，虽可改善某种长期权衡，却并不自动等价于求解完整多代最优问题。固定罚系数方法的意义，应通过它近似的未来价值和适用范围来说明。

考虑一个刻意简化的两遗传来源代理模型。令 x 为第一来源贡献，其当期平均价值为 $1+x$ ；把两来源保留程度用 $D(x) = 2x(1-x)$ 表示，并假定终端价值为 $\kappa D(x)$ 。这只是说明未来机会如何改变决策的教学目标，不把 D 直接宣称为真实群体的全部遗传方差。在单位关系矩阵的抽象来源模型中，它还满足 $D = 1 - 2f$ ，其中 $f = \frac{1}{2}[x^2 + (1-x)^2]$ 。目标为

$$J(x) = 1 + x + 2\delta\kappa x(1-x), \quad 0 \leq x \leq 1.$$

当内部解存在时，

$$x^* = \frac{1}{2} + \frac{1}{4\delta\kappa}, \quad J''(x) = -4\delta\kappa < 0.$$

取 $\delta = 0.9, \kappa = 2$ ，最优贡献为 0.638889，当期价值为 1.638889，保留程度约为 0.461420，总目标约为 2.469444。只看当期会选择 $x = 1$ ，当期价值为二，但代理目标也只有二。这里的改变来自事先规定的未来价值，不是因为第二来源突然获得更高当期育种值。若 $\delta\kappa \leq 1/2$ ，内部公式超出区间，最优解回到 $x = 1$ 。这个边界明确说明：多样性是否足以改变选择，取决于它

在模型中的实际边际价值，不能只凭一个正的保护系数断言必然保留每个来源。

对于家畜的真实应用，上述两个来源不能直接当成没有性别限制的两只亲本。应分别规定父方和母方贡献、繁殖上限及配种可行性；同一祖先来源还可能分布在许多个体中。代理函数也不区分有利变异、有害变异和对未来环境有用的变异，因而只能作为透明的机制演示。正式计划可比较多个候选终端函数，并检查其是否能预测更长时期模拟中的收益排序。

多代规划还需要统一近交的时间预算。设 ΔF_t 为相对于上一期尚未近交部分的新增比例，则

$$1 - F_T = (1 - F_0) \prod_{t=1}^T (1 - \Delta F_t).$$

因此给定末期近交上限 $F_{\max}$ ，可以转换为可加的对数预算：

$$\sum_{t=1}^T -\log(1 - \Delta F_t) \leq -\log\left(\frac{1 - F_{\max}}{1 - F_0}\right).$$

这比直接相加近交增量更准确，并让不同年度的多样性消耗有一个共同尺度。例如从 $F_0 = 0$ 出发，十年近交上限为 0.10，均匀年度增量应为 $1 - 0.9^{1/10} = 0.010481$ 。若用理想离散世代近似，两年一代和五年一代相应的每代增量分别为 $1 - 0.9^{2/10} = 0.020852$ 与 $1 - 0.9^{5/10} = 0.051317$ 。两个数不同，却对应相同的十年累计上限。真实世代重叠时应直接按年度关系过程计算，不能把一个平均世代间隔当成精确的离散代钟表。

是否均匀分配预算，则取决于各期遗传收益和未来状态。有时早期引入较广泛来源有助于后来持续选择；有时某年候选特别优秀，可以在不破坏末期约束的前提下使用更多当期预算。模型应说明这些调整怎样影响后续可行域，并对预测误差保留余量。若每年只追求当前允许的最大共祖，又将下一年的上限机械地从新高点继续外推，就可能与最初的长期累计目标偏离。定期重新优化时，应始终对照同一基础和原定时间终点，才能把滚动决策与长期承诺连接起来。

18.23 习题与解答

习题一：准确度与时间。沿用例 18.1，青年方案准确度降为 0.50，世代间隔仍为两年，其年度进展是多少？在其他参数固定时，青年准确度至少达到多少才与准确度 0.90、间隔五年的方案相等？

解答：年进展为 $1.754983 \times 0.50 \times 10/2 = 4.387458$ ，仍高于原成熟方案的 3.158970。等效准确度满足 $r/2 = 0.9/5$ ，所以为 0.36。这个阈值只针对相同选择强度、遗传方差和稳定间隔；没有包含成本、近交和准确度随代数改变，不能直接作为所有生产系统的采用标准。

习题二：实际贡献。三只公畜育种值为 12,8,4，计划父方比例为 0.5,0.3,0.2，实际比例为 0.2,0.3,0.5。若母方平均不变，实际后代均值比计划少多少？

解答：计划父本均值为 9.2，实际为 6.8，相差 2.4。父方只贡献后代加性遗传的一半，因此后代均值差为 1.2。直接把父本均值差当作后代差会遗漏二分之一传递系数。若不同公畜与不同母畜配对且母方贡献也改变，应同时计算母方部分。

习题三：时间尺度。每代近交增量为 0.005，世代间隔从四年缩短为两年。二十年后近交分别是多少？该结果对约束设计有什么启示？

解答：从 $F_0 = 0$ 出发，五代后为 $1 - 0.995^5 \approx 0.024751$ ，十代后为 $1 - 0.995^{10} \approx 0.048890$ 。每代控制相同，单位日历时间累积却不同。若目标是维持相同二十年近交水平，快速方案需要更严格的每代增量，或用直接针对年度过程的控制模型。

习题四：Bulmer 递推。在 $V_{t+1} = 0.4V_t + 50$ 、 $V_0 = 100$ 的教学模型中，求第三代方差及平衡值。若第三代后停止选择，下一代按 $V_{t+1} = 0.5V_t + 50$ 变化，是多少？

解答：依次为 90,86,84.4，平衡满足 $V = 0.4V + 50$ ，故为 83.333333。停止选择后的下一代为 92.2。这种恢复来自固定基因频率方差假设下连锁不平衡的消散；如果基因频率方差已因漂变或固定下降，恢复目标也会降低。

习题五：共祖与配种。两种计划使用相同亲本贡献，但一者平均父母加

性关系为 0.20, 另一者为 0.08。下一代平均近交分别是多少? 群体共祖是否必然不同?

解答: 后代平均近交分别为 0.10 和 0.04, 因为单个配对后代近交为父母加性关系的一半。若亲本贡献和完整关系矩阵相同, 群体共祖相同, 配种改变的是父母配对的组合。后续世代的关系发展仍可能因此受影响, 应在长期模拟中继续跟踪。

习题六: 最小可行共祖。例 18.2 的四亲本问题把共祖上限设为 0.15, 求解器报告不可行。为什么不能通过增加迭代次数解决?

解答: 在各性别贡献各一半的约束下, 最小共祖为等量贡献时的 0.15625, 高于上限。不存在符合所有条件的贡献向量, 因此更换求解器或增加迭代不能创造可行解。应增加合适的候选来源、修改上限或调整其他允许改变的约束, 并明确这些修改的生物学含义。

习题七: 取整检查。将例 18.2 的连续最优比例转为一百个后代, 采用父方 86, 14、母方 68, 32 的整数边际, 是否满足共祖上限? 说明检查步骤。

解答: 先把父母使用比例各除以二, 得到遗传贡献 (0.43, 0.07, 0.34, 0.16)', 再用原关系矩阵计算 $0.5c'Ac = 0.18055$, 超过 0.18。不能把父方使用比例直接放入总和为一的贡献公式, 也不能仅检查每性别数目之和。附近方案父方 85, 15、母方 68, 32 给出 0.1796625, 可作为可行替代候选。

习题八: 有效大小与贡献数。十只公畜与一百只母畜按理想性别比公式得到的有效大小是多少? 为什么该值与 $1/\sum c_j^2$ 以及实际近交有效大小不一定相同?

解答: 性别比近似为 $4 \times 10 \times 100/110 = 36.363636$, 建立在特定理想繁殖假设上。贡献数指标只描述比例集中, 不包含亲缘、选择和年龄结构。实际近交有效大小还受祖先共享、贡献方差及世代重叠影响。因此三个量可以相互提供线索, 但必须保留各自定义, 不能挑其中最大一个作为群体安全程度。

习题九: 预算选择。在第 31.16 节两个同预算策略中, 若甲准确度从 0.55 降为 0.45, 其他条件不变, 哪一个年度进展更高?

解答：甲变为 $2.062713 \times 0.45 \times 10/2.5 \approx 3.712883$ ，低于乙的 4.094961。这说明较多候选并不总能补偿较低准确度。方案结论可能在可信参数范围内切换，因此应估计准确度不确定性，并把敏感性结果与点估计一起报告。

习题十：设计长期比较。比较普通截留与最优贡献选择，为什么不能只让二者选择相同数量亲本，然后比较十代均值？应怎样完善研究？

解答：相同亲本数不保证相同贡献集中或近交压力，也不保证繁殖成本相同。应明确共同候选、预测资料、繁殖上限和时间尺度，比较相同近交或共祖约束下的收益，或展示完整收益与多样性前沿。多次重复跟踪各性状均值、方差、实际贡献、近交、共祖和家系流失，并检查预测模型更新与整数配种可执行性。若策略之一使用额外信息或承担更高成本，也应在报告中显式分离这些差异。

第七篇混合模型

第六篇

PART VI

遗传漂变、近交与杂交

有限群体中的随机漂变、近交衰退与杂种优势共同决定交配体系的设计。本篇讨论有效群体大小、近交的遗传后果以及杂交育种体系的数量遗传基础。

第 19 章 遗传漂变、有效群体大小与近交

第 20 章 杂种优势、配合力与杂交育种体系

遗传漂变、有效群体大小与近交

19.1 小群体育种的遗传后果

育种群体总是有限的。即使一个品种有数百万头个体，真正作为下一代亲本、尤其是作为种公畜的个体往往只有数十到数百头。在有限群体中繁殖，必然产生两类相互关联的后果：一是**近交**，即有亲缘关系的个体相互交配；二是**随机漂变**，即由于配子抽样，等位基因频率发生随机的改变。二者进一步影响性状的均值（近交衰退）与方差（系内方差减少、系间方差增加），从而影响选择反应与群体的一致性。

第4章已在单位点层次讨论了漂变与杂合度的丢失，第11、12章讨论了个体层次的亲缘与近交系数。本章把这些内容整合起来，系统地讨论：理想群体中近交的积累；真实群体的有效群体大小及其影响因素；近交对均值的影响——近交衰退及其遗传基础；近交对遗传方差的影响；以及近交在育种中的管理。第20章将讨论近交的“反面”——杂交与杂种优势。

19.2 理想群体中的近交与漂变

19.2.1 理想群体

为了建立清晰的理论，先考虑一个“理想群体”：从一个大的、非近交的基础群体中建立许多个子群体，每个子群体每代随机地选出 N 个个体作为亲本，它们代表了某个位点上的 $2N$ 个等位基因；子群体内随机交配，允许自交；除随机外没有选择，没有突变，也没有子群体之间的迁移；各子群体在各世代的大小相同；世代不重叠。

19.2.2 近交系数的递推

近交系数 F 是个体在一个随机位点上的两个等位基因同祖同源的概率 (第 11 章)。在随机交配群体中, 所有个体的期望近交程度相同, F 也等于从群体中随机抽取两个等位基因而同祖同源的概率。

从非近交的基础群体 ($F_0 = 0$) 出发。第 1 代的个体, 若两个等位基因是同一个亲本等位基因的两份拷贝, 就是近交的; 从 $2N$ 个等位基因中有放回地抽两次, 抽到同一个的概率为 $1/2N$, 因此 $F_1 = 1/2N$ 。到第 2 代, 个体的两个等位基因同祖同源有两种可能: 一是抽到了同一个等位基因, 概率 $1/2N$, 这是“新的近交”; 二是抽到两个不同的等位基因 (概率 $1 - 1/2N$), 但它们在第 1 代已经同祖同源 (概率 F_1), 这是“旧的近交”。于是一般地

$$F_t = \frac{1}{2N} + \left(1 - \frac{1}{2N}\right)F_{t-1}. \quad (19.1)$$

定义**近交速率**为每代新产生的近交占尚未近交部分的比例:

$$\Delta F = \frac{F_t - F_{t-1}}{1 - F_{t-1}} = \frac{1}{2N}. \quad (19.2)$$

由式 (19.1), $1 - F_t = (1 - \Delta F)(1 - F_{t-1})$, 逐代相乘得

$$F_t = 1 - (1 - \Delta F)^t \approx 1 - e^{-t/2N}. \quad (19.3)$$

19.2.3 近交与漂变是同一现象

在每个子群体中, 下一代的等位基因频率由 $2N$ 个等位基因的二项抽样决定。第 1 代各子群体频率的方差为 $p_0q_0/2N = p_0q_0F_1$ 。此后每个子群体从自己的频率出发继续漂变, 子群体之间逐渐分化。可以证明, 第 t 代子群体间频率的方差为

$$\sigma_{q_t}^2 = p_0q_0 \left[1 - \left(1 - \frac{1}{2N}\right)^t\right] = p_0q_0F_t, \quad (19.4)$$

而各子群体频率的平均仍为 q_0 。当 $t \rightarrow \infty$, $F \rightarrow 1$, $\sigma_q^2 \rightarrow p_0q_0$: 比例为 p_0 的子群体固定于 A_1 , 比例为 q_0 的子群体固定于 A_2 。式 (19.3) 与 (19.4) 表明, **近交与随机漂变是同一过程的两个侧面**: 在子群体之间看, 是频率的分化; 在子群体内部看, 是同祖同源的积累。

19.2.4 漂变对基因型频率的影响

在每个子群体内部，交配是随机的，基因型频率符合 Hardy-Weinberg 比例 p_i^2 、 $2p_iq_i$ 、 q_i^2 。但把所有子群体合在一起看，纯合子 A_2A_2 的平均频率为

$$E(q_i^2) = [E(q_i)]^2 + \text{Var}(q_i) = q_0^2 + p_0q_0F,$$

多于基础群体的 q_0^2 ；同样 A_1A_1 多出 p_0q_0F ，杂合子少了 $2p_0q_0F$ 。这与第 4 章式 (4.5) 完全相同：跨子群体的基因型频率等同于一个近交系数为 F 的群体，也正是第 4 章的瓦隆效应与 F_{ST} 。完全近交时，只剩两种纯合子，频率分别为 p_0 与 q_0 。

19.3 有效群体大小

19.3.1 定义

真实群体很少满足理想群体的假定。为了仍能使用上面的公式，定义**有效群体大小** N_e ：与真实群体具有相同近交速率（或相同漂变方差增长速率）的理想群体的大小。一旦求得 N_e ，就可以用 $\Delta F = 1/2N_e$ 与 $F_t = 1 - (1 - \Delta F)^t$ 预测近交的积累。推导各种情形下 N_e 的公式，不仅能预测近交，也揭示了在给定亲本数下降低近交速率的策略。

19.3.2 常见情形

避免自交与近亲交配。理想群体允许自交。若不允许自交， $N_e \approx N + \frac{1}{2}$ ；若既不允许自交也不允许全同胞交配， $N_e \approx N + 2$ 。在实际规模的群体中，这些修正很小。

两性数目不等。若作为亲本的雄性与雌性数目分别为 N_m 与 N_f ，每个后代的两个等位基因分别来自一个父本与一个母本，

$$\frac{1}{N_e} \approx \frac{1}{4N_m} + \frac{1}{4N_f}, \quad N_e \approx \frac{4N_mN_f}{N_m + N_f}, \quad \Delta F \approx \frac{1}{8N_m} + \frac{1}{8N_f}. \quad (19.5)$$

有效大小总小于亲本总数，并主要由数目较少的一方决定。1 头公畜配 100 头母畜， $N_e \approx 4$ ；5 头公畜， $N_e \approx 19$ ；10 头公畜， $N_e \approx 36$ ；即使母畜

增加到 1000 头, 10 头公畜的群体有效大小也只有约 40。人工授精使家畜群体中种公畜极度集中, 这是许多品种有效大小很小的主要原因。

各世代大小不同。若群体大小在各世代为 $N_1, \dots, N_t$, 长期的有效大小近似为各世代大小的调和平均:

$$\frac{1}{N_e} = \frac{1}{t} \sum_{j=1}^t \frac{1}{N_j}. \quad (19.6)$$

若群体在五个世代中依次为 50、100、200、400、500, 算术平均为 250, 调和平均只有约 127。调和平均受最小值支配: 一次瓶颈的影响会持续很久。

家系大小的方差。设群体大小恒定、雌雄各半, 每个个体留下的、本身成为亲本的后代数 (家系大小) 为 k , 其方差为 V_k , 则

$$N_e \approx \frac{4N}{V_k + 2}. \quad (19.7)$$

在理想群体中, 由于有放回的抽样, 家系大小近似服从泊松分布, $V_k \approx 2$, 于是 $N_e = N$ 。若部分家系留下很多后代、部分家系没有后代, $V_k > 2$, N_e 减小; 选择通常使优秀家系贡献更多, 因此增大 V_k 。反之, 若育种者使每个亲本贡献相同数目的种用后代, 例如从每个全同胞家系中各选一公一母, $V_k = 0$, $N_e \approx 2N$, 有效大小是实际大小的两倍。这是保种群体管理中“等量留种”策略的理论依据。

亲属的共选。选择本身会降低有效群体大小。对遗传力较高的性状进行个体选择时, 表现好的个体往往有表现同样好的全同胞, 亲属倾向于一同入选; 依据家系信息的估计育种值 (如 BLUP) 更是使同一家系的成员得到相近的评分, 从而大大增加了共选的概率。共选使下一代亲本之间的平均亲缘关系升高, 近交速率加快。罗伯逊 (1961) 与雷等 (1990) 发展了预测选择群体近交速率的理论。BLUP 选择比个体表型选择提高了准确度, 但若不加控制, 其近交速率可能高出一倍以上; 基因组选择缩短了世代间隔, 单位时间的近交速率也随之提高。第 18 章的最优贡献选择正是为了在获得遗传进展的同时控制近交速率。




图 19.1 规则近交体系与近交使遗传方差的再分配。A 图为自交、全同胞交配、半同胞交配以及有效大小为 10 与 50 的随机交配群体中近交系数随世代的增长；B 图为由同一基础群体建立的大量小近交系中，系内加性方差与系间方差随近交系数的变化及其在无显性时的理论值

19.3.3 规则近交体系

在植物育种与实验动物中，常用规则的近交体系快速获得纯合的系。由通径分析可以得到近交系数的递推（第 12 章）：

- 自交： $F_t = \frac{1}{2}(1 + F_{t-1})$ ，每代杂合度减半， $\Delta F = 0.5$ ，5 代后 $F = 0.969$ ；
- 全同胞交配： $F_t = \frac{1}{4}(1 + 2F_{t-1} + F_{t-2})$ ，渐近 $\Delta F = 0.191$ ，10 代后 $F = 0.886$ ；
- 半同胞交配： $F_t = \frac{1}{8}(1 + 6F_{t-1} + F_{t-2})$ ，渐近 $\Delta F = 0.110$ ，10 代后 $F = 0.691$ 。

近交小鼠品系通常经过二十代以上的连续全同胞交配，近交系数超过 0.98。玉米自交系通过六至八代自交获得；现代育种中，单倍体诱导与染色体加倍技术可以在一两代内直接获得完全纯合的“双单倍体”系。

19.4 近交对均值的影响：近交衰退

19.4.1 单位点的推导

考虑由同一非近交基础群体经漂变建立的许多近交系，其平均近交系数为 F ，跨系的平均等位基因频率仍为基础群体的 p_0 、 q_0 。由上节，跨系的基

因型频率为 $p_0^2 + p_0q_0F$ 、 $2p_0q_0(1-F)$ 、 $q_0^2 + p_0q_0F$ 。以福尔克纳的基因型值 $+a$ 、 d 、 $-a$ 计算平均值：

$$M_F = a(p_0^2 + p_0q_0F) + 2p_0q_0(1-F)d - a(q_0^2 + p_0q_0F) = a(p_0 - q_0) + 2p_0q_0d(1-F).$$

基础群体的均值为 $M_0 = a(p_0 - q_0) + 2p_0q_0d$ (第7章式 (7.1))，因此

$$M_F = M_0 - 2p_0q_0dF. \quad (19.8)$$

近交衰退为 $M_F - M_0 = -2p_0q_0dF$ 。这一简洁的结果有三个要点：近交衰退需要显性 ($d \neq 0$)，纯加性位点没有近交衰退，因为近交使两种纯合子以同等程度增加，其效应相互抵消；衰退的大小依赖于等位基因频率，在 $p_0 = q_0 = \frac{1}{2}$ 时最大；在只有显性 (无上位) 时，衰退与近交系数成线性关系。

19.4.2 多位点与方向性显性

对多个位点 (无上位)，

$$M_F = M_0 - 2F \sum_k d_k p_k q_k. \quad (19.9)$$

要使群体表现出近交衰退，各位点的显性效应 d_k 必须在方向上一致，即平均而言杂合子偏向某一方向 (通常是适合度高的方向)；若有的位点 $d > 0$ 、有的 $d < 0$ ，衰退会相互抵消。大量实验表明，与适合度密切相关的性状 (繁殖力、存活、抗病力、生长) 普遍存在明显的近交衰退，说明这些性状存在方向性显性。这与第4章的群体遗传学预期一致：有害突变大多是部分隐性的，在突变—选择平衡下以低频存在，近交使它们以纯合状态暴露出来。

在一个由 300 个位点、方向性显性构成的模拟中，由同一基础群体建立 2000 个有效大小为 10 的小系，各系内随机交配。系的平均表现随近交系数呈线性下降，模拟斜率与式 (19.9) 的理论斜率 $-2 \sum dpq$ 十分吻合 (图 19.2)。

若存在上位，近交衰退与 F 的关系可以是非线性的，例如加性 $\times$ 加性上位使高近交程度下的衰退加速或减缓。在许多实验中，近交衰退在中等近交程度内近似线性，这被视为显性是近交衰退主要原因的证据。




图 19.2 方向性显性造成的近交衰退。点为由同一基础群体建立的大量小近交系的平均表现，线为理论预测

19.4.3 近交衰退的大小

近交衰退通常以每增加 1% 的近交系数，性状均值下降的绝对量或相对量表示。综合大量家畜研究，生产性状的近交衰退大约为每 1% 近交系数使均值下降 0.1% 至 0.4%，繁殖、存活与健康性状的相对衰退更大。在奶牛中，近交系数每增加 1%，305 天产奶量约下降二三十千克，首次产犊年龄与产犊间隔延长，生产寿命缩短。在猪与羊中，产仔数与断奶存活率对近交尤其敏感。由于多个性状的衰退叠加，整体经济效益的损失相当可观，因此控制近交是育种计划设计的重要内容。

19.4.4 近交衰退的遗传基础：显性与超显性

关于近交衰退与杂种优势的遗传基础，历史上有两种假说。**显性假说**认为，衰退主要来自许多部分隐性的有害等位基因在近交下的纯合暴露。**超显性假说**认为，在许多位点上杂合子本身就优于两种纯合子 ($d > a$)，近交降低了杂合度，因而降低了表现。二者的预测在近交衰退层面相同，但对育种的含义不同：若为显性，原则上可以通过选择把有害等位基因清除，获得表现不亚于杂交种的纯系；若为超显性，则纯系永远无法达到杂合子的水平，杂交种是唯一的出路。

大量证据支持显性假说是主要机制：有害突变的显性程度通常较低；近

交系可以通过选择逐步改良；“清除”现象（见下文）确实存在。但在某些位点，确实观察到真正的超显性；此外，**假超显性**——两个紧密连锁、各自部分隐性的有害等位基因处于相斥相，使杂合子在两个位点上至少有一个正常拷贝——会在连锁群体中模拟出超显性的表现。现代玉米研究表明，杂种优势很可能是大量位点上部分显性与互补作用的综合结果。

19.4.5 清除

在缓慢近交的群体中，近交使有害隐性等位基因更多地以纯合状态出现，从而更有效地被自然或人工选择清除，这一过程称为**清除**（purging）。对致死性隐性等位基因（ $s = 1$ ，显性度很低），在随机交配下它们几乎完全“隐藏”在杂合子中，频率下降极慢；而在近交速率每代 5% 的群体中，同样的等位基因很快被清除。数值上，初始频率 0.05 的近致死隐性等位基因（ $h = 0.02$ ），在随机交配下 40 代后频率仍约为 0.0096；在每代近交增量 0.05 的群体中，40 代后已几乎完全消失。清除对强效的有害等位基因有效，对效应微弱的有害等位基因则作用很小，因为后者的选择强度不足以克服漂变。因此，清除只能部分减轻近交衰退，近交速率越快，漂变越强，清除越不完全。保种群体与小种群中，缓慢的近交比快速的近交更有利于清除而少积累衰退。

19.5 近交对遗传方差的影响

19.5.1 无显性时的再分配

漂变使各系的等位基因频率趋向固定，但不同系固定的等位基因不同。因此近交使系内的遗传方差减少，系间的遗传方差增加。在无显性时，单位点的基础群体遗传方差为 $V_G = V_A = 2p_0q_0a^2$ 。

系内方差：系 i 内随机交配，方差为 $2p_iq_ia^2$ 。跨系平均， $E(2p_iq_i)$ 等于跨系杂合子频率 $2p_0q_0(1 - F)$ ，于是系内平均方差为 $(1 - F)V_G$ 。

系间方差：系 i 的均值为 $a(p_i - q_i) = a(1 - 2q_i)$ ，其方差为 $4a^2 \text{Var}(q_i) = 4a^2p_0q_0F = 2FV_G$ 。

于是，近交把遗传方差重新分配为：

表 19.1 近交系内与系间的遗传方差（无显性）

部分	遗传方差
系间	$2FV_G$
系内	$(1 - F)V_G$
合计	$(1 + F)V_G$

总遗传方差随近交增加为 $(1 + F)$ 倍，完全近交时系间方差为基础群体的两倍，系内方差为零。图 19.1B 的模拟（近交系数约 0.40 时，系内加性方差约为基础的 60%）与理论一致。系内的遗传力相应降低：

$$h_w^2 = \frac{(1 - F)V_G}{(1 - F)V_G + V_E} = \frac{h_0^2(1 - F)}{1 - h_0^2F}. \quad (19.10)$$

这对小群体中的选择有直接意义：近交不仅降低均值，也降低系内的遗传方差，从而降低进一步选择的反应。另一方面，系间方差的增加正是“系间选择”的基础：在大量近交系中挑选最好的系，可以利用这部分方差。

19.5.2 有显性时

存在显性时，方差的再分配复杂得多。系内的加性方差与显性方差都依赖于各系的等位基因频率，而跨系平均时会出现新的组分，例如近交个体中加性效应与纯合显性偏差的协方差。一个重要的现象是：在中等近交程度下，系内的加性方差可能**暂时增加**，因为漂变使低频的隐性等位基因在某些系中频率升高，而在中间频率下隐性等位基因贡献的加性方差最大。这解释了为什么某些种群瓶颈之后，部分数量性状的加性方差反而上升。

19.6 基因组近交

系谱近交系数是期望值，依赖于系谱的深度与准确性，也依赖于基础群体的选择。基因组资料使我们能够直接度量个体的实际纯合程度，主要有三类基因组近交系数。

基于纯合片段的近交系数 F_{ROH} ：个体基因组中长度超过某一阈值（如 1 或 2 兆碱基）的连续纯合片段的总长度占常染色体总长度的比例。由于共同祖先遗留下来的同祖同源片段会被逐代重组切短，长的纯合片段指示近期的共同祖先，短的片段指示较远的共同祖先。按长度分层统计，可以区分近期与远期的近交。

基于基因组关系矩阵对角元素的近交系数 $F_{GRM} = G_{ii} - 1$ ：反映个体相对于参照群体等位基因频率的纯合程度，可以为负值。

基于观察与期望纯合度的近交系数 $F_{HOM} = (O_{hom} - E_{hom}) / (M - E_{hom})$ ：与第 4 章的固定指数相同。

三者衡量的是近交的不同侧面，彼此相关但不相等。在育种中， F_{ROH} 与近交衰退的关系通常比系谱近交系数更紧密，因为它反映了个体实际的纯合程度，而不是期望值。基因组资料还使研究者能够定位近交衰退的具体区域：比较在某区域纯合与杂合个体的表现，可以找到含有有害隐性等位基因的“近交衰退热点”。在许多家畜品种中，人们还发现了一些从未以纯合状态出现的单倍型——这些“纯合缺失单倍型”往往携带胚胎致死突变，它们是导致受胎率下降与早期胚胎死亡的原因，已被纳入奶牛的遗传缺陷检测与配种管理。

19.7 近交在育种中的管理

近交是一把双刃剑。一方面，它造成近交衰退、降低遗传变异、增加遗传缺陷的发生；另一方面，它是固定优良性状、建立一致的近交系与杂交亲本、暴露并清除有害等位基因的手段。育种计划中对近交的管理包括以下几个层次。

控制近交速率。家畜育种界普遍认为，为了维持群体的长期适应性与选择潜力，每代近交速率应不超过 0.5% 至 1%，相当于有效群体大小 50 至 100。这需要限制个别优秀种公畜的使用，并在选择中考虑亲属的共选。

最优贡献选择。在给定的近交速率约束下，最大化下一代的平均遗传价值，由此确定每个候选个体的最优贡献（第 18 章、第 36 章）。这是兼顾遗

传进展与近交控制的最系统的方法。

配种计划。在确定了每个亲本的贡献后，通过配种安排使后代的近交系数最小，即避免有近亲缘的个体交配。注意，配种只能影响当代后代的近交，不能改变群体的平均亲缘关系；长期的近交速率由亲本的选择与贡献决定。

遗传缺陷管理。利用基因检测识别携带者，在配种中避免两个携带者交配，而不是简单地淘汰所有携带者，以免损失携带者的其他优良遗传。

保种群体。对地方品种与珍稀遗传资源，以最大化有效群体大小为目标：等量留种、轮换配种、扩大公畜数量，并利用冷冻精液与胚胎延长世代间隔、减缓漂变。

19.8 深入专题

19.8.1 选择群体中近交速率的预测

式 (19.5) — (19.7) 都是在无选择的条件下推导的。在选择群体中，亲本对后代的贡献依赖于它们的遗传价值，而遗传价值在亲属之间相关，因此近交速率高于由亲本数预测的值。罗伯逊 (1961) 指出，选择对近交的影响可以看作家系大小方差的增加，而且这一增加会在后代中累积：一个被选中的个体，其后代因遗传了较高的育种值而更可能被选中，其“家系”在多代中持续扩张。伍利亚姆斯与贝杰 (1995) 把这一思想形式化为**长期遗传贡献理论**：个体 i 的长期贡献 r_i 是它在遥远的未来世代中所占的基因比例，近交速率可以写为

$$\Delta F \approx \frac{1}{4}(1 - \alpha) \sum_i r_i^2, \quad (19.11)$$

其中求和遍及同一世代的全部个体，各个体长期贡献之和为 1（雄性与雌性各占二分之一）， α 为偏离随机交配的程度。若 N 个个体的长期贡献完全相等， $\sum r_i^2 = 1/N$ ， $\Delta F = 1/(4N)$ ，与式 (19.7) 中 $V_k = 0$ 时 $N_e = 2N$ 的结论一致；在随机的家系大小下，长期贡献本身有变异， $\sum r_i^2$ 的期望约为 $2/N$ ，回到 $\Delta F = 1/(2N)$ 。在有选择时， r_i 与个体的育种值正相关， $\sum r_i^2$ 增大，近交速率加快。与此同时，遗传进展可以写为 $\Delta G = \sum_i r_i a_i$ ， a_i 为个体的孟德尔抽样项。这两个公式揭示了遗传进展与近交速率的统一来源：都取

决于长期贡献的分布。最优贡献选择的本质，就是在约束 $\sum r_i^2$ （近交速率）的同时最大化 $\sum r_i a_i$ （遗传进展）（第 18 章、第 36 章）。

19.8.2 近交衰退的估计方法

实际资料中，近交衰退通常以个体表型对其近交系数的回归估计：

$$y_i = \mathbf{x}_i' \boldsymbol{\beta} + bF_i + u_i + e_i,$$

b 即每单位近交系数的衰退量（通常报告为每 1% 近交的变化 $b/100$ ）。在模型中同时拟合加性遗传效应 u_i 很重要，否则近交与遗传趋势（近交个体常常是较新出生、遗传水平较高的个体）混杂，衰退估计会有偏。系谱近交系数的准确性依赖于系谱的深度与完整性：浅系谱会低估近交，并使衰退估计偏离。基因组近交系数（ F_{ROH} 、 F_{GRM} 等）避免了系谱错误与系谱深度的问题，许多研究发现以 F_{ROH} 估计的近交衰退更显著；进一步按纯合片段的长度（年龄）分层，可以比较近期与远期近交对表型的不同影响——由于清除，远期近交积累的纯合片段中有害变异较少，其衰退效应往往较弱。在基因组的局部层次上，对每个区段检验“该区段是否处于纯合片段中”与表型的关联，可以定位含有有害隐性等位基因的区域。

19.8.3 保种遗传学中的有效群体大小标准

保种遗传学中常引用一组经验标准：短期内避免明显的近交衰退，有效群体大小应不小于约 50；长期维持数量性状的进化潜力，使突变产生的加性方差能补偿漂变的损失，有效群体大小应达到约 500，后来的研究者认为可能需要更大。这一“50/500 规则”由富兰克林（1980）提出。第二个数字来自突变—漂变平衡：漂变每代使加性方差减少 $V_A/(2N_e)$ ，突变每代增加 $V_M \approx 10^{-3}V_E$ ；二者平衡时 $V_A \approx 2N_e V_M$ ，要使 V_A 与 V_E 相当（遗传力约 0.5），需 $N_e \approx 500$ 。这些数字是数量级的指引，而非精确的阈值。家畜育种组织常以每代近交速率不超过 1%（ $N_e \geq 50$ ）作为最低要求，并建议在可能时保持更低的近交速率。

19.8.4 例题

例 19.1 一个肉牛核心群的近交速率与近交衰退

某肉牛核心群每年使用 5 头公牛、200 头母牛，世代间隔约 5 年。由式 (19.5)， $N_e = 4 \times 5 \times 200 / 205 = 19.5$ ， $\Delta F = 1/39 = 0.0256$ ，每年约 0.5%。若断奶重的近交衰退为每 1% 近交下降 1.2 千克，十年（两个世代）后近交系数约增加 5.1%，断奶重因近交约下降 6.1 千克。若核心群的年遗传进展为每年 2 千克，十年的遗传进展为 20 千克，近交衰退抵消了约 30%。

若把公牛数增加到 15 头， $N_e = 4 \times 15 \times 200 / 215 = 55.8$ ， $\Delta F = 0.009$ ，十年近交约 1.8%，衰退约 2.1 千克。由于公牛选择强度下降（例如从前 5% 变为前 15%， i 从 2.06 降至 1.55），遗传进展约降至每年 1.6 千克，十年约 16 千克。扣除衰退后，两种方案十年的净进展都约为 13.9 千克，几乎相同；但后者保留了更多的遗传多样性与长期潜力。这一权衡正是最优贡献选择试图系统解决的问题。

19.9 本章小结

有限群体中的繁殖必然产生近交与漂变，二者是同一过程的两个侧面：子群体之间等位基因频率的方差为 $p_0q_0F_t$ ，子群体内部同祖同源的概率为 $F_t = 1 - (1 - \Delta F)^t$ ，理想群体中 $\Delta F = 1/2N$ 。真实群体用有效群体大小描述，两性数目不等时 $N_e = 4N_mN_f/(N_m + N_f)$ ，各世代大小不同时取调和平均，家系大小方差增大时 N_e 减小，等量留种可使 N_e 加倍，选择与亲属共选会降低 N_e 。规则近交体系可以迅速提高近交系数。近交衰退为 $-2F \sum dpq$ ，需要方向性显性，与近交系数成线性关系；显性假说是近交衰退与杂种优势的主要解释，超显性与假超显性在部分位点上存在；清除可以部分减轻强效有害等位基因造成的衰退。近交把遗传方差从系内重新分配到系间：无显性时系内为 $(1 - F)V_G$ ，系间为 $2FV_G$ 。基因组近交系数可以直接度量实际的纯合程度。育种中应控制近交速率，以最优贡献选择、配种计划与遗传缺陷管理兼顾进展与多样性。

19.10 习题

习题 19.1 某理想群体 $N = 25$ 。计算第 1、5、10、20 代的近交系数, 以及近交系数达到 0.25 所需的世代数。

习题 19.2 某猪核心群每代使用 8 头公猪与 120 头母猪。计算有效群体大小与每代近交速率。若改为 20 头公猪, 近交速率降为多少?

习题 19.3 一个保种群体在五代中的繁殖个体数为 30、30、10、30、30。求有效群体大小, 并与算术平均比较。

习题 19.4 某位点 $a = 2$ 、 $d = 1.5$ 、 $p_0 = 0.5$ 。求近交系数为 0.25 时的均值变化。若另一个位点 $a = 1$ 、 $d = -0.5$ 、 $p_0 = 0.3$, 二者合计的近交衰退为多少?

习题 19.5 某性状基础遗传力 0.4, 无显性。由基础群体建立许多近交系, 当 $F = 0.5$ 时, 系内遗传力、系间遗传方差与总遗传方差各为多少 (以基础群体遗传方差为单位)?

习题 19.6 说明为什么基于 BLUP 估计育种值的选择通常比基于个体表型的选择产生更高的近交速率, 并提出两种控制方法。

习题 19.7 若每个全同胞家系恰好留下一头公畜与一头母畜作为下一代亲本, 群体有 20 个家系, 有效群体大小约为多少?

19.11 习题解答

19.1 $\Delta F = 0.02$; $F_1 = 0.02$, $F_5 = 1 - 0.98^5 = 0.096$, $F_{10} = 0.183$, $F_{20} = 0.332$ 。 $1 - 0.98^t = 0.25$, $t = \ln 0.75 / \ln 0.98 = 14.2$ 代。

19.2 $N_e = 4 \times 8 \times 120 / 128 = 30.0$, $\Delta F = 1/60 = 0.0167$ 。20 头公猪: $N_e = 4 \times 20 \times 120 / 140 = 68.6$, $\Delta F = 0.0073$ 。

19.3 $1/N_e = \frac{1}{5}(4/30 + 1/10) = 0.0467$, $N_e = 21.4$, 算术平均 26。

19.4 第一位点: $-2 \times 0.25 \times 1.5 \times 0.25 = -0.1875$ 。第二位点: $-2 \times 0.21 \times (-0.5) \times 0.25 = +0.0525$ 。合计 -0.135 。

19.5 系内遗传方差 $0.5V_G$, 系内遗传力 $0.4 \times 0.5 / (1 - 0.2) = 0.25$; 系

间方差 $1.0V_G$ ；总遗传方差 $1.5V_G$ 。

19.6 BLUP 利用家系信息，同一家系的成员估计育种值相近，倾向于一同入选，增加了下一代亲本之间的亲缘关系。控制方法：在选择中限制每个家系的入选数目；采用最优贡献选择，在约束平均亲缘的条件下最大化遗传进展；或在估计育种值中适度降低家系信息的权重。

19.7 共 40 个亲本， $V_k = 0$ ， $N_e \approx 2N = 80$ 。

19.12 补充习题

习题 19.8 证明当 N 个个体（雌雄各半）的长期贡献完全相等且随机交配时，式 (19.11) 给出 $\Delta F = 1/(4N)$ ，并与式 (19.7) 比较。

习题 19.9 某品种有效群体大小为 40，加性方差的突变输入为 $V_M = 0.001V_E$ 。估计突变—漂变平衡下的遗传力，并说明为什么在实际中该品种的遗传力可能高于这一平衡值。

19.13 补充习题解答

19.8 每个个体 $r_i = 1/N$ ， $\sum r_i^2 = 1/N$ ， $\alpha = 0$ ， $\Delta F = 1/(4N)$ 。式 (19.7) 中 $V_k = 0$ 时 $N_e = 2N$ ， $\Delta F = 1/(2N_e) = 1/(4N)$ ，二者一致。

19.9 $V_A \approx 2N_e V_M = 0.08V_E$ ， $h^2 \approx 0.08/1.08 = 0.074$ 。实际品种的加性方差主要是从其祖先群体继承的“存量”变异，而非突变—漂变平衡下的“流量”，只要品种形成时间不长，加性方差远未降到平衡水平。

杂种优势、配合力与杂交育种体系

20.1 杂种优势：近交衰退的反面

两个不同的系、品种或群体杂交，其后代的表现常常优于双亲的平均，甚至优于较好的亲本，这一现象称为**杂种优势**或杂交优势。达尔文在《植物界异花受精与自花受精的效果》(1876)中已经系统地记录了异交后代的活力优势；1908年舒尔与伊斯特各自在玉米中观察到自交系的衰退与自交系杂交后活力的恢复，舒尔据此提出了利用自交系单交种生产商品玉米的设想。二十世纪三十年代以后，杂交玉米在美国迅速推广，单产在其后几十年间成倍增长，成为二十世纪农业科学最成功的范例之一。动物育种中，肉牛、猪、家禽与绵羊的商品生产也普遍采用杂交体系，以同时利用杂种优势与不同品种的互补性。

杂种优势通常以**中亲杂种优势**度量：

$$H = \bar{P}_{F_1} - \frac{1}{2}(\bar{P}_{P_1} + \bar{P}_{P_2}),$$

也常以相对于中亲值的百分比表示。若杂交种优于较好的亲本，称为**超亲优势**。在商业上，真正有意义的往往是杂交种与最好纯种或现有品种的比较。

第19章已经从近交的角度给出了杂种优势的基本理论：由同一基础群体建立的大量近交系，其平均表现为 $M_F = M_0 - 2F \sum dpq$ ；若随机地在近交系之间杂交，杂交后代的近交系数回到零，平均表现回到 M_0 。因此，跨

所有杂交组合平均的杂种优势为

$$\bar{H} = M_0 - M_F = 2F \sum_k d_k p_k q_k,$$

杂种优势在平均意义上恰好是近交衰退的恢复。二者具有相同的遗传基础——方向性显性——也受相同的因素影响。

20.2 特定杂交组合的杂种优势

20.2.1 单位点推导

对一个特定的杂交组合，杂种优势取决于两个亲本在等位基因频率上的差异。设亲本群体 P_1 中等位基因 A_1 的频率为 p ， P_2 中为 $p - y$ ， y 为两亲本群体的频率差。两亲本群体内部随机交配时的均值分别为

$$M_{P_1} = a(p - q) + 2dpq, \quad M_{P_2} = a(p - q - 2y) + 2d(p - y)(q + y).$$

F_1 由 P_1 的配子与 P_2 的配子随机结合产生，其基因型频率为 A_1A_1 : $p(p - y)$ ， A_1A_2 : $2pq + y(p - q)$ ， A_2A_2 : $q(q + y)$ ，于是

$$M_{F_1} = a(p - q - y) + d[2pq + y(p - q)].$$

中亲杂种优势经化简为

$$H_{F_1} = M_{F_1} - \frac{1}{2}(M_{P_1} + M_{P_2}) = dy^2. \quad (20.1)$$

对多个位点（无上位），

$$H_{F_1} = \sum_k d_k y_k^2. \quad (20.2)$$

式 (20.2) 给出了杂种优势的两个必要条件：**存在显性** ($d \neq 0$)，而且显性在方向上一致；**亲本之间存在等位基因频率差异** ($y \neq 0$)。杂种优势与频率差的平方成正比，因此遗传距离越大的两个群体，杂交后的杂种优势通常越大——但并非无限增大，因为距离很远的群体之间可能存在不利的上位

互作。不同杂交组合的杂种优势各不相同，因为各位点的频率差 y_k 因组合而异。

以一个位点为例： $a = 2$ ， $d = 1.5$ ，两个亲本群体的频率分别为 0.9 与 0.3 ($y = 0.6$)。两个亲本的均值分别为 1.87 与 -0.17 ，中亲值 0.85； F_1 的均值为 1.39；杂种优势 0.54，恰为 $dy^2 = 1.5 \times 0.36$ 。

20.2.2 F_2 与后续世代的杂种优势

F_1 个体间随机交配产生 F_2 。 F_2 的等位基因频率为两亲本的平均 $\bar{p} = p - \frac{1}{2}y$ ，基因型频率回到 Hardy-Weinberg 比例，可以证明

$$H_{F_2} = \frac{1}{2}H_{F_1} = \frac{1}{2}dy^2. \quad (20.3)$$

F_2 损失了一半的杂种优势，因为 F_1 中杂合子的比例 $2pq + y(p - q)$ 高于 F_2 中的 $2\bar{p}\bar{q}$ ，二者之差恰为 $\frac{1}{2}y^2$ 。此后若继续随机交配，在无上位时杂种优势稳定在 F_2 的水平，不再继续下降，因为随机交配的群体已经达到 Hardy-Weinberg 平衡。这是合成品种（由多个品种杂交后闭锁繁育形成的新品种）能够永久保留部分杂种优势的理论基础。

若存在上位， F_2 及以后世代还会损失 F_1 中由亲本品种内部有利的上位组合所带来的效应，这部分称为**重组损失**：亲本品种在长期选择中可能积累了相互适应的基因组合，杂交使这些组合在 F_2 中被重组打散。重组损失在不同性状与不同品种组合中大小不一，通常小于杂种优势本身，但在某些性状（如适应性与繁殖性状）中不可忽视。

20.3 杂交育种体系

20.3.1 品种组合效应的迪克森模型

动物杂交中，后代的表现不仅取决于其自身的基因型，还取决于其母亲的母体能力，后者本身又受母亲的品种组成与杂合状态影响。迪克森（1969, 1973）提出了一个把杂交群体平均表现分解为若干遗传参数的模型：

$$\bar{P} = \sum_i p_i^I g_i^I + \sum_i p_i^M g_i^M + h^I h_{\text{系数}}^I + h^M h_{\text{系数}}^M + r^I r_{\text{系数}}^I + \dots, \quad (20.4)$$

其中 g_i^I 为品种 i 的直接（个体）加性效应， p_i^I 为后代中品种 i 的比例； g_i^M 为品种 i 的母体加性效应， p_i^M 为母亲中品种 i 的比例； h^I 为个体杂种优势，其系数为后代个体中来自不同品种的父亲与母亲等位基因组合的概率， $1 - \sum_i p_i^{\times} p_i^{\text{母}}$ ； h^M 为母体杂种优势，其系数为母亲个体的杂合程度； r^I 为重组损失，其系数与亲本配子中非亲本组合的比例有关。式 (20.4) 把每一种杂交方案的期望表现写成少数几个品种参数的线性组合，这些参数可以由包含纯种与各种杂交组合的试验资料估计，然后用于比较不同杂交体系的效益。

20.3.2 主要的杂交体系

终端杂交。用两个品种（或品系）杂交产生 F_1 ， F_1 全部作为商品个体出售，不再用于繁殖。例如以一个生长与胴体性状优秀的父系品种的公畜，配一个繁殖性能优秀的母系品种的母畜。 F_1 获得 100% 的个体杂种优势，并能利用父系与母系在性状上的互补；但母畜是纯种，得不到母体杂种优势，而且需要另外维持两个纯种群体来生产亲本。

三元与四元杂交。以两个母系品种杂交产生 F_1 母畜，再与第三个父系品种的公畜交配，商品代为三元杂交种。这种体系同时获得 100% 的个体杂种优势与 100% 的母体杂种优势（ F_1 母畜是完全杂合的），是现代商品猪生产的主流模式，例如“杜洛克 ×（长白 × 大白）”。四元杂交以两个 F_1 互交，父本也是杂种，可以获得父本的杂种优势（如繁殖力与性欲），但父系性状的一致性降低。

轮回杂交。在一个群体中轮流使用不同品种的公畜，杂交母畜留作下一代的母本。两品种轮回杂交中，后代的品种组成在两个品种之间振荡，平衡时个体杂种优势保持率为

$$\text{两品种: } \frac{2}{3}, \quad \text{三品种: } \frac{6}{7}, \quad n\text{品种: } \frac{2^n - 2}{2^n - 1}. \quad (20.5)$$

轮回杂交的优点是只需购买公畜，母畜由群体自身更新，同时保留了大部分的个体与母体杂种优势；缺点是品种组成逐代变化，产品一致性较差，而且需要同时管理多个品种的公畜。

合成系（综合品种）。把若干品种杂交后闭锁繁育，形成一个新的群体。

由于随机交配下杂种优势稳定在 F_2 的水平, 等比例的 n 品种合成系保持的个体杂种优势比例为

$$1 - \sum_i p_i^2 = 1 - \frac{1}{n}. \quad (20.6)$$

三品种等比例合成系约保持 67%, 四品种 75%, 八品种约 88%。合成系的优点是管理简单, 像纯种一样繁育, 同时永久保留了相当比例的杂种优势, 并可以在其中进行选择; 缺点是可能有重组损失, 以及在建系初期需要较大的群体以避免近交。美国农业部肉用动物研究中心育成的若干肉牛合成系, 以及许多热带地区由本地品种与外来品种合成的新品种 (如“婆罗福特”“圣格特鲁迪斯”等), 都属于此类。




图 20.1 杂种优势的保持与配合力方差。A 图为两、三、四品种轮回杂交各世代个体杂种优势的保持率及其平衡值, 并与等比例合成系比较; B 图为亲本系近交系数不同时一般配合力与特殊配合力方差的变化

图 20.1A 显示了轮回杂交中杂种优势的振荡与收敛: 两品种轮回在约四五代后稳定于三分之二附近, 三品种轮回稳定于约 86%, 四品种轮回约 93%。

20.3.3 杂交方案的比较

选择杂交体系需要综合考虑: 个体与母体杂种优势的利用程度; 品种之间在加性效应上的互补; 纯种与父母代群体的维持成本; 替换母畜的来源与成本; 产品的一致性; 以及管理的复杂程度。在肉牛中, 杂交母牛的母体杂种优势可以使每头母牛断奶犊牛总重提高约 20% 甚至更多, 其中相当部分来自母体杂种优势 (繁殖力、母性、长寿)。在猪中, 三元杂交商品猪的窝

产仔数、存活率与生长速度都显著优于纯种。在家禽中，商业蛋鸡与肉鸡几乎全部是专门化品系间的多元杂交种，杂交亲本由育种公司严格控制，这也构成了一种天然的知识产权保护。

20.4 一般配合力与特殊配合力

20.4.1 定义

当一组系（自交系、品系或品种）相互杂交时，每个杂交组合的表现可以分解为两部分。斯普拉格与塔图姆（1942）在玉米中提出：**一般配合力**（GCA）是某个系在与其他各系杂交时的平均表现相对于全部杂交组合总平均的偏差；**特殊配合力**（SCA）是某个特定杂交组合的表现相对于由双亲一般配合力所预期的表现的偏差。设 X_{AB} 为系 A 与系 B 杂交后代的平均表现， $\bar{X}_{A\cdot}$ 为系 A 所有杂交组合的平均， $\bar{X}_{\cdot\cdot}$ 为全部组合的总平均，则

$$GCA_A = \bar{X}_{A\cdot} - \bar{X}_{\cdot\cdot}, \quad SCA_{AB} = X_{AB} - (\bar{X}_{\cdot\cdot} + GCA_A + GCA_B), \quad (20.7)$$

$$X_{AB} = \bar{X}_{\cdot\cdot} + GCA_A + GCA_B + SCA_{AB} + E.$$

一般配合力类似于个体育种值的一半：育种值的一半是个体与群体中随机个体交配时后代的期望表现偏差，一般配合力则是一个系与其他系“随机交配”时后代的期望表现偏差。因此一般配合力主要反映加性效应，杂交组合的期望表现由双亲一般配合力之和预测，正如后代的期望值由双亲育种值的平均预测。特殊配合力则反映非加性效应（显性与上位）：某些组合因为等位基因之间特殊的互补而表现得比预期更好或更差。

20.4.2 双列杂交的估计

在一组 n 个系的双列杂交中（不含自交与反交，即格里芬方法 4），每个系与其余 $n-1$ 个系杂交。一般配合力的最小二乘估计为

$$\widehat{GCA}_i = \frac{T_i}{n-2} - \frac{2T}{n(n-2)},$$

T_i 为系 i 所有杂交组合观察值之和， T 为全部组合观察值之和。模拟一个 6 个自交系的双列杂交（15 个组合），以真实一般配合力（标准差 2）、特

殊配合力（标准差 1.2）与试验误差产生资料，由上式估计的一般配合力与真实值的相关约为 0.95 以上。表现最好的单个杂交组合，并不总是由一般配合力最高的两个系组成，因为特殊配合力也有相当的贡献。这说明在一般配合力差异之外，还需要直接测定候选组合的表现。

20.4.3 配合力方差与近交程度

由一个非近交基础群体建立的近交系，其一般与特殊配合力的方差与基础群体的方差组分之间存在如下关系（考虑到二阶上位）：

$$\sigma_{GCA}^2 = \frac{1}{2}FV_A + \frac{1}{4}F^2V_{AA} + \dots, \quad \sigma_{SCA}^2 = \frac{1}{2}F^2V_{AA} + F^2V_D + F^3V_{AD} + F^4V_{DD} + \dots \quad (20.8)$$

一般配合力的方差主要来自加性方差，并随近交系数近似线性增加；特殊配合力的方差来自非加性方差，随近交系数的更高次方增加。因此（图 20.1B），在近交程度较低时，杂交组合之间的差异主要来自一般配合力，选择一般配合力高的系相互杂交即可得到好的组合；在近交程度较高时（如完全纯合的自交系），特殊配合力的相对重要性增加，必须直接测定特定组合的表现才能找到最好的杂交种。这为杂交玉米育种的历史实践提供了理论解释：早期以顶交（用一个共同测验种测定自交系）评价一般配合力，随后在优选的系之间测定单交组合的特殊配合力。

20.5 杂种优势群与相互轮回选择

为了持续地改良杂交种，需要同时改良两个亲本群体，使它们杂交的表现不断提高。科姆斯托克、鲁滨逊与哈维（1949）提出了**相互轮回选择**：设立两个群体 A 与 B，以 A 群体的个体与 B 群体的测验种杂交、以 B 群体的个体与 A 群体的测验种杂交，依据杂交后代的表现分别在两个群体内选择，被选个体在各自群体内互交形成下一轮。相互轮回选择同时利用了加性效应与非加性效应：它选择的是在与对方群体杂交时表现好的等位基因，在超显性或部分显性下，会推动两个群体在相关位点上的频率向相反方向分化，从而增大 y ，提高杂种优势。

现代玉米育种中，种质被划分为若干“杂种优势群”，例如美国的“硬秆综合种（SSS）”群与“非硬秆综合种（NSS）”群；中国玉米育种中也形成了若干杂种优势群与杂种优势模式。杂交种总是在不同杂种优势群的自交系之间组配，各群内部分别选育。长期的群内选育与群间杂交，使不同杂种优势群之间的等位基因频率差异逐渐增大，这在全基因组标记资料中得到了清楚的证实：群间的 F_{ST} 随育种年代增加，与杂种优势的提高相一致。家禽与猪的商业育种中，专门化父系与母系的分化与之类似。

20.6 纯种选择与杂种表现

在动物的杂交体系中，选择通常在纯种的核心群中进行，而经济效益体现在杂交商品代的表现上。纯种中的选择能否有效地改良杂种的表现，取决于纯种表现与杂种表现之间的遗传相关 r_{pc} 。若存在杂种优势，同一个体在纯种背景与杂种背景中的加性效应并不完全相同，因为等位基因的平均效应依赖于与之配对的等位基因的频率：

$$\alpha_{\text{杂种}} = a + d(q_{\text{配偶群体}} - p_{\text{配偶群体}}),$$

而在纯种中配偶群体就是纯种本身。当两个品种频率差异大、显性程度高时， r_{pc} 可能明显小于 1。此外，纯种核心群与商品场的环境差异也会降低 r_{pc} 。猪与家禽的研究中， r_{pc} 估计值常在 0.5 至 0.9 之间。当 r_{pc} 不够高时，单纯依据纯种表现选择会损失相当的杂种改良潜力，因此需要把商品杂交后代的表现资料纳入种畜的评定，即“合并纯种与杂种资料的选择”。基因组技术使这一点更为可行：利用对杂交后代分型与测定，可以估计纯种亲本的等位基因在杂种背景中的效应，甚至估计品种来源特异的标记效应。第 22 章讨论了杂种与纯种表现的遗传相关在动物模型中的处理。

20.7 杂交种表现的基因组预测

在植物中，可能的单交组合数目随亲本系数目的平方增长，不可能逐一田间测定。基因组预测为此提供了新的途径：用已测定的杂交组合训练模型，

以亲本系的基因型预测未测定组合的表现。模型可以写为

$$y_{ij} = \mu + g_i + g_j + s_{ij} + e_{ij},$$

一般配合力 g_i 与 g_j 的协方差由各自杂种优势群内的基因组关系矩阵描述, 特殊配合力 s_{ij} 的协方差由两个关系矩阵的 Hadamard 积描述。研究表明, 在亲本系与训练组合有亲缘关系时, 杂交种表现的基因组预测可以达到相当的准确度, 其中一般配合力部分的预测通常比特殊配合力部分更准确。这一方法已经成为玉米、水稻、小麦等杂交育种中筛选组合的常规工具。在动物中, 类似的思想用于预测不同品种组合的杂交效果, 并估计品种来源特异的基因组育种值。

20.8 深入专题

20.8.1 迪克森模型的数值示例

用一组教学参数说明式(20.4)怎样比较杂交方案。设三个品种 A、B、C 的直接加性效应(相对于品种 A)分别为 0、2、6, 母体加性效应分别为 3、1、-2——A 是母性优良的母系品种, C 是生长快、母性较差的父系品种; 个体杂种优势 $h^I = 4$, 母体杂种优势 $h^M = 6$, 重组损失 $r^I = -1$ (均以同一性状单位计)。

- 纯种 A: $0 + 3 = 3$; 纯种 C: $6 - 2 = 4$ 。
- C 公 $\times$ A 母的 F_1 : 直接效应 $\frac{1}{2}(6 + 0) = 3$, 母体效应 3 (A 母), 个体杂种优势系数 1, 合计 $3 + 3 + 4 = 10$ 。
- C 公 $\times$ (A $\times$ B) 母的三元杂交: 直接效应 $\frac{1}{2} \times 6 + \frac{1}{4} \times 0 + \frac{1}{4} \times 2 = 3.5$, 母体效应 $\frac{1}{2}(3 + 1) = 2$, 个体杂种优势 4, 母体杂种优势 6, 重组损失系数约 $\frac{1}{2}$ (母本配子中有一半为跨品种的非亲本组合), 合计 $3.5 + 2 + 4 + 6 - 0.5 = 15$ 。

三元杂交的优势有三个来源: 父系品种 C 贡献了高的直接效应, 母系的 A、B 贡献了好的母体效应, F_1 母本贡献了完全的母体杂种优势。这一分解清楚地说明了“专门化父系与母系”杂交体系的逻辑: 把在直接效应与母体效应上各有所长的品种, 放在杂交体系中各自最能发挥作用的位置上。在真

实育种中，这些参数需要由包含纯种、 F_1 、回交、三元杂交等多种组合的试验资料估计，参数的估计误差会传递到方案比较中，因而方案优劣的判断应同时考虑不确定性。

20.8.2 杂种优势的分子基础

杂种优势的数量遗传理论（式（20.2））只要求方向性显性与频率差异，并不涉及具体的分子机制。分子水平的研究揭示了几种可能的机制。

互补与存在—缺失变异。玉米的不同自交系之间存在大量的结构变异，一些基因在一个自交系中存在、在另一个中缺失。杂交种同时携带双亲的基因，相当于“补全”了各自缺失的部分。这是显性假说在分子层次上的一种具体实现：部分缺失或功能减弱的等位基因相对于功能正常的等位基因是隐性的。

表达的加性与非加性。全转录组研究表明，杂交种中大多数基因的表达水平介于双亲之间（加性表达），一部分基因表现出偏离中亲值的非加性表达，包括超亲表达。等位基因特异性表达分析可以区分顺式调控（双亲等位基因在杂交种中表达不同）与反式调控的贡献，后者可能是非加性表达的重要来源。

有害突变的屏蔽。每个自交系都携带若干在纯合状态下有害的变异，杂交使这些变异处于杂合状态而被屏蔽。玉米自交系之间有害变异的分布不同，杂交种的优势与双亲携带的有害变异的互补程度相关。这为通过基因组选择或基因编辑减少自交系中的有害变异、缩小近交系与杂交种的差距提供了思路。

20.8.3 遗传距离能否预测杂种优势

由式（20.2），杂种优势与频率差的平方 y^2 成正比，人们自然希望以亲本之间的遗传距离（如标记计算的 F_{ST} 或罗杰斯距离）预测杂种优势。研究表明，在同一杂种优势群内部，亲本遗传距离与杂种优势或杂交种产量的相关通常较弱；在不同杂种优势群之间，相关较强。原因在于：式（20.2）中的 y_k^2 必须以显性效应 d_k 加权，而全基因组的遗传距离对所有标记等权，大

部分标记与杂种优势无关；此外，不同群体间的上位与重组损失也会抵消部分杂种优势。因此，遗传距离只能作为粗略的筛选指标，更有效的方法是第四节所述的基因组预测模型，它利用实际测定的杂交组合资料学习哪些区域的差异与杂种优势有关。

20.8.4 品种来源特异的基因组模型

在杂交动物（如三元杂交商品猪、杂交肉牛）中，个体基因组的不同片段来自不同品种。若某个 QTL 的等位基因效应依赖于其品种来源（例如由于品种间 LD 相位不同，标记在不同品种中代表不同的 QTL 等位基因），把所有片段按同一效应建模会损失准确度。**品种来源等位基因（BOA）**模型利用相位与系谱信息，推断杂交个体每个标记等位基因来自哪个品种，然后为每个品种分别估计标记效应。这一模型自然地把纯种与杂种资料联合起来，估计纯种亲本的等位基因在杂交后代中的效应，从而直接以杂种表现为选择目标。当品种间遗传距离大、纯种与杂种表现的遗传相关较低时，BOA 模型相对于忽略品种来源的模型优势较明显。

20.9 本章小结

杂种优势在平均意义上是近交衰退的恢复，两者都需要方向性显性。特定杂交组合的中亲杂种优势为 $\sum dy^2$ ，正比于亲本群体等位基因频率差的平方； F_2 损失一半的杂种优势，此后在随机交配下保持稳定，存在上位时还有重组损失。迪克森模型把杂交群体的表现分解为品种的直接与母体加性效应、个体与母体杂种优势以及重组损失，用于比较杂交体系。终端杂交与三元杂交充分利用个体与母体杂种优势及品种互补；两、三品种轮回杂交分别保持约三分之二与七分之六的杂种优势；等比例 n 品种合成系保持 $1 - 1/n$ 。一般配合力主要反映加性效应，特殊配合力反映非加性效应；其方差随亲本近交程度增加，后者增加得更快，因此高度近交的系之间需要直接测定组合。相互轮回选择与杂种优势群的分化推动杂种优势持续提高。纯种选择改良杂种表现的效率取决于纯种与杂种表现的遗传相关，把杂种资料纳入评定可以提高这一效率；基因组预测使大规模筛选杂交组合成为可能。

20.10 习题

习题 20.1 某位点 $a = 1$ 、 $d = 0.8$ ，两个品种中 A_1 的频率分别为 0.8 与 0.2。求两品种的均值、 F_1 与 F_2 的均值，以及 F_1 与 F_2 的中亲杂种优势。

习题 20.2 证明式 (20.1)： $H_{F_1} = dy^2$ 。

习题 20.3 推导两品种轮回杂交中个体杂种优势的平衡保持率为三分之二。

习题 20.4 某性状个体杂种优势为 10%，母体杂种优势为 8%（均相对于纯种均值）。比较纯种、 F_1 终端杂交、三元杂交（ F_1 母本）、两品种轮回杂交与四品种合成系的期望杂种优势总和（不考虑重组损失）。

习题 20.5 在一个 5 个自交系的双列杂交（方法 4）中，10 个组合的产量如下：AB 98、AC 102、AD 95、AE 100、BC 104、BD 97、BE 99、CD 101、CE 106、DE 96。估计各系的一般配合力与组合 CE 的特殊配合力。

习题 20.6 说明为什么纯种表现与杂种表现的遗传相关可能小于 1，并讨论这对纯种核心群选择的影响。

20.11 习题解答

20.1 品种 1: $1 \times 0.6 + 2 \times 0.8 \times 0.16 = 0.856$; 品种 2: $-0.6 + 0.256 = -0.344$; 中亲 0.256。 F_1 : $a(0.16 - 0.16) + 0.8(0.64 + 0.04) = 0.544$, $H_{F_1} = 0.288 = 0.8 \times 0.36$ 。 F_2 : $\bar{p} = 0.5$, 均值 $0 + 0.8 \times 0.5 = 0.4$, $H_{F_2} = 0.144$ 。

20.2 见正文推导: $M_{F_1} - \frac{1}{2}(M_{P_1} + M_{P_2})$ 中加性部分为 $a(p - q - y) - \frac{1}{2}a(2p - 2q - 2y) = 0$, 显性部分为 $d[2pq + y(p - q)] - d[pq + (p - y)(q + y)] = d[2pq + yp - yq - pq - pq - py + qy + y^2] = dy^2$ 。

20.3 设某代母畜中品种 A 的比例为 x , A、B 两品种公畜交替使用。用 A 公畜时, 后代中 A 的比例为 $\frac{1}{2} + \frac{1}{2}x$; 用 B 公畜时为 $\frac{1}{2}x$ 。经过“B 公畜—A 公畜”两代, $x \mapsto \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2}x = \frac{1}{2} + \frac{x}{4}$, 平衡时 $x = \frac{2}{3}$; 相应地, 在另一相位上 $x = \frac{1}{3}$ 。于是用 A 公畜配 A 比例为 $\frac{1}{3}$ 的母畜, 后代的个体杂种优势系数为 $1 - 1 \times \frac{1}{3} = \frac{2}{3}$; 用 B 公畜配 B 比例为 $\frac{1}{3}$ 的母畜同样为 $\frac{2}{3}$ 。

20.4 纯种: 0。 F_1 终端: 个体 100%, 母体 0, 合计 10%。三元: 个体

100%、母体 100%，合计 18%。两品种轮回： $\frac{2}{3} \times (10 + 8) = 12\%$ 。四品种合成系： $0.75 \times 18 = 13.5\%$ 。

20.5 $T_A = 395, T_B = 398, T_C = 413, T_D = 389, T_E = 401, T = 998$ 。
 $\widehat{GCA}_i = T_i/3 - 2 \times 998/15 = T_i/3 - 133.07$: A -1.40, B -0.40, C 4.60, D -3.40, E 0.60。总平均 99.8, $\widehat{SCA}_{CE} = 106 - 99.8 - 4.60 - 0.60 = 1.0$ 。

20.6 等位基因的平均效应依赖于配偶群体的等位基因频率，纯种背景与杂种背景中配偶频率不同，存在显性时平均效应不同；纯种核心群与商品场的环境也不同。 $r_{pc} < 1$ 时，纯种中的选择对杂种表现的改良打折扣，应把杂种资料纳入评定，或直接以杂种表现为选择目标。

20.12 补充习题

习题 20.7 用正文的迪克森模型参数，计算 B 公 $\times$ A 母 F_1 与 (C 公 $\times$ A 母 F_1) 的轮回杂交母本再配 B 公时后代的期望表现（重组损失系数按母本杂合度的一半计）。

习题 20.8 为什么同一杂种优势群内部的遗传距离与杂种优势的相关往往较弱？从式 (20.2) 出发给出解释。

20.13 补充习题解答

20.7 B 公 $\times$ A 母：直接 $\frac{1}{2}(2 + 0) = 1$ ，母体 3，个体杂种优势 4，合计 8。(C $\times$ A) F_1 母配 B 公：直接 $\frac{1}{2} \times 2 + \frac{1}{4} \times 6 + \frac{1}{4} \times 0 = 2.5$ ，母体 $\frac{1}{2}(-2 + 3) = 0.5$ ，个体杂种优势 4，母体杂种优势 6，重组损失 -0.5，合计 12.5。

20.8 杂种优势是各位点 $d_k y_k^2$ 之和，只有存在方向性显性的位点的频率差有贡献；全基因组遗传距离对所有标记等权，主要反映中性位点的分化，与功能位点的分化相关性弱。同一群体内部的亲本频率差较小、差异主要来自漂变，这种噪声进一步削弱了相关。

第七篇

PART VII

混合模型与遗传评定

混合模型把未知环境效应、复杂亲缘与不平衡资料纳入同一方程体系。本篇从最小二乘走向 BLUP，深入动物模型、方差组分估计与复杂表型模型。

第 21 章 从最小二乘到最佳线性无偏预测

第 22 章 动物模型与复杂遗传效应

第 23 章 方差组分、限制似然与贝叶斯推断

第 24 章 多性状、阈值、生存与纵向遗传模型

从最小二乘到最佳线性无偏预测

21.1 从种畜比较出发理解统计校正

育种工作经常从一个很朴素的问题开始：两头种公羊，究竟哪一头更值得保留？第一头公羊的后代平均增重较高，第二头公羊的后代平均增重较低，看起来只要比较两个均值就能作出判断。然而，第一头公羊可能主要用于精料供应稳定的大场，第二头公羊可能主要用于放牧条件波动的小场；第一头只有少量经过精心照料的后代，第二头却有大量来自不同批次的后代。原始均值同时反映遗传潜力、环境条件、样本构成和偶然误差。统计校正的目的，是明确这些来源怎样共同产生观测记录，再在模型允许的范围内提取关于遗传差异的信息。

这个问题包含两种性质不同的工作。一种工作是估计环境均值差异，例如不同场、年份、性别或饲养批次平均会产生多少差别；另一种工作是预测尚不能直接观察的育种值。前者不能简单地通过把每个场减去自己的平均数完成，因为场内动物的遗传水平也可能不同。后者也不能把校正后的表型全部归因于遗传，因为单次表现中仍有环境误差。混合模型把两项工作放在同一个统计系统里，使环境校正与遗传预测相互协调，而不是把一次可能带偏的预校正永久固定下来。

从生产角度看，模型还承担信息整合的任务。一头没有自身记录的年轻公羊，可以通过父母、同胞和其他亲属获得预测；一头有很多后代记录的公羊，获得的信息通常更充分。不同来源的信息可能相关，例如母羊的自身记录和女儿记录共享遗传因素，多个同胞又共享家系背景。只把若干已经计算好的均值相加，容易把同一来源的信息重复使用。一个合理的协方差模型既

说明哪些资料能相互支持，也说明哪些资料不是独立的新证据。

本章使用统一的线性混合模型

$$y = X\beta + Zu + e.$$

其中， y 是长度为 n 的表型向量， β 是固定效应参数， u 是随机效应向量， e 是残差。 X 和 Z 分别把每条记录连接到相应固定效应和随机效应。遗传评定中， u 常表示加性育种值；在推导一般理论时，它也可以包括按顺序堆叠的多个随机效应。模型首先要求

$$E(u) = 0, \quad E(e) = 0, \quad \text{Cov}(u, e) = 0.$$

记 $\Sigma_u = \text{Var}(u)$ 、 $R = \text{Var}(e)$ ，则表型的边际协方差为

$$V = Z\Sigma_u Z' + R.$$

这里撇号表示转置。 V 与选择指数中记录协方差矩阵 P 承担相近的数学角色，但本章保留混合模型习惯使用的 V ，并用 Q 表示随后出现的加权残差投影算子，避免把投影算子也称为 P 。明确符号并非形式上的细节：同一个矩阵究竟是关系、协方差还是投影，决定了它的量纲、可逆性和能够进行的运算。

初学时可以把方差参数视为已知，先理解数据怎样被加权。真正应用中通常需要从资料估计方差，这会引入额外不确定性，下一章及方差推断章节将逐步处理。为了避免在同一段推导中混入多个困难，本章的基本结果先假定 V 正定，必要处再讨论奇异结构。教学中分步引入假设的用意，是让每个结论都能找到成立的依据，而不是暗示现实资料天然满足这些条件。

21.2 最小二乘的几何意义与正规方程

先去掉随机效应，只考虑 $y = X\beta + e$ ，并假定残差互不相关、方差相同。最小二乘法选择使残差平方和最小的参数。设残差为 $r = y - X\beta$ ，目标函数为 $r'r$ 。展开以后，与参数有关的部分是 $-2\beta'X'y + \beta'X'X\beta$ 。对参数求导，得

到正规方程

$$X'X\hat{\beta} = X'y.$$

这个方程也有清楚的几何含义。 $X\hat{\beta}$ 位于设计矩阵各列张成的空间中, 而最小二乘残差与该空间正交, 即 $X'(y - X\hat{\beta}) = 0$ 。因此拟合值是把观测向量投影到模型能够表达的均值空间。只要这个空间相同, 更换一套不冗余的参数表示不会改变拟合值。统计解释中的基准组选择, 可以改变某个回归系数的数值, 却不应改变同一个可估计的组间对比。

例如, 两个饲养组的记录分别为 8、10 和 12、14。用两个组均值作为参数, 设计矩阵每行只在所属组列上取 1, 最小二乘解为 9 和 13。若改用一个截距和第二组指示变量, 截距为 9, 组效应为 4; 若改用总体水平加和为零的组偏差, 则总体水平为 11, 组偏差为 -2 与 2。三个参数化得到相同的四个拟合值。不能因为三个模型输出的“截距”不同, 就认为它们得出了不同的生产结论。

最小二乘的平方损失对大的残差施加更大代价, 这有利于处理近似对称、尺度稳定的误差, 但也意味着少数极端值可能对解有很大影响。极端记录不应自动删除: 它可能是真实的生物学极端, 也可能是称量单位、动物身份或日期错误。正确的顺序是检查来源, 再决定是否修正记录、调整误差模型或使用稳健分析。先删除所有不符合预期的点, 再宣称模型稳定, 会把需要解释的现象提前排除掉。

正规方程的推导不需要正态分布。高斯—马尔可夫意义下的线性无偏最优性, 依赖均值结构正确、残差零均值以及协方差与所使用的权重相容, 而不要求每条误差都严格正态。正态假设在建立完整似然、推导某些精确分布和进行条件概率计算时才发挥额外作用。把“计算最小二乘解”和“假定正态似然”分开, 有助于理解同一组方程为何可以出现在不同统计框架中。

实际求解时, 正规方程适合推导, 却未必是最稳定的数值路线。若设计矩阵列之间高度相关, 形成 $X'X$ 会平方放大条件数。可以通过正交分解求最小二乘解, 或者使用带主元的分解识别近似线性依赖。这里的数值困难不能靠增加输出小数位解决。输入的信息在某个方向上很弱, 即使计算器给出

很多数字，相应的参数也可能极不稳定。

21.3 广义最小二乘为什么需要协方差加权

当记录精度不同，或者误差之间相关时，普通的欧氏距离不再合理。假定残差协方差为已知正定矩阵 R ，广义最小二乘最小化

$$J(\beta) = (y - X\beta)'R^{-1}(y - X\beta).$$

相应正规方程为 $X'R^{-1}X\hat{\beta} = X'R^{-1}y$ 。当 X 满列秩时，解为

$$\hat{\beta} = (X'R^{-1}X)^{-1}X'R^{-1}y.$$

权重矩阵不是把每条记录机械地乘上“重要程度”。它表示在给定误差结构下，哪一种残差方向更罕见、更值得模型解释。一个误差方差很小的方向，同样大小的偏差更难归因于随机误差，因此获得较大权重。若两条记录高度相关，它们共同变化的方向可能包含大量共同噪声，而它们的差异方向反而可能很精确。

可以通过白化变换看清这一点。取 $R = LL'$ 为 Cholesky 分解，左乘 L^{-1} ，得到 $y_* = L^{-1}y$ 、 $X_* = L^{-1}X$ ，新误差协方差为单位矩阵。对变换后的资料做普通最小二乘，正好得到广义最小二乘解。所谓加权几何，就是在原始空间中按误差协方差重新衡量距离。实现时用三角方程求解即可，不必显式形成 L^{-1} 。

教学例 21.1：两条精度不同的记录。假定两条记录测量同一个未知均值，数值为 10 和 14，误差方差分别为 1 和 9，且互相独立。广义最小二乘均值是 $\{10 + 14/9\}/\{1 + 1/9\} = 10.4$ ，估计方差为 $1/\{1 + 1/9\} = 0.9$ 。普通平均数为 12，其方差为 $(1 + 9)/4 = 2.5$ 。两种估计都对真实均值无偏，但利用已知精度差异可以显著减少方差。这里的权重来自测量方差，而不是分析者对较小观测值的主观偏好。

再考虑方差都为 4、相关系数为 0.75 的两条记录。由于二者对称，最优均值仍是算术平均，但均值方差为 $4(1 + 0.75)/2 = 3.5$ 。若误以为二者独立，会把方差算成 2，从而夸大精度。增加一条与原记录高度相似的记录，可能

只增加少量独立信息。重复称量、同一日相邻时间测定, 以及从同一原始信号计算的多个指标, 都容易产生这种情况。

协方差加权也会影响固定效应之间的比较。某个场有很多记录, 如果这些记录共享同一批次误差, 它的有效信息不等于原始记录数。相反, 记录总数不多但覆盖多个独立批次的场, 可能提供更可靠的均值比较。设计资料时, 应尽量增加能够分离不同误差来源的重复, 而不是只在一个已经高度重复的条件下持续收集同类数据。这个原则与后续遗传参数识别的讨论是相通的。

当 R 未知而以估计值代替时, 所得结果常称可行广义最小二乘。若方差估计可靠, 方法通常有效; 在样本小或误差结构复杂时, 权重估计本身也会波动。报告标准误时, 需要说明是否把估计的权重当作已知。迭代估计均值和协方差并不是多余步骤, 而是承认环境校正与误差结构之间存在相互依赖。

Aitken (1936) 关于最小二乘与观测线性组合的工作, 是理解广义最小二乘历史发展的重要原始文献。这里的推导着重展示加权几何, 使读者能够从协方差假设直接判断估计的适用条件。

21.4 可估计性、约束与遗传连通

设计矩阵列满秩并不是所有应用都自然满足的条件。最常见的冗余是同时放入总体均值和全部组指示变量, 因为指示变量之和就是总体均值列。此时不同参数向量可能给出完全相同的拟合均值。判断一个函数 $c'\beta$ 是否可估计, 关键在于它是否能够由模型均值 $X\beta$ 唯一决定; 等价地, c' 应位于 X 的行空间内。

若存在向量 v 使 $Xv = 0$, 那么 β 与 $\beta + v$ 产生相同的均值。可估计函数必须满足 $c'v = 0$, 否则两组统计上无法区分的参数却会产生不同目标值。这个简单的零空间论证比记忆某一种约束规则更重要。设置参考组、让组效应之和为零或删除冗余列, 只是在同一个可识别空间内选择坐标, 不能使原本不可估计的函数突然获得信息。

考虑两个场, 每个场只使用一头公羊, 而且两头公羊之间没有亲缘和共

享后代。若场效应和公羊效应都作为不受约束的固定效应，公羊差异与场差异完全混杂：第一场表现高，可以由场效应解释，也可以由公羊效应解释。改用随机公羊效应以后，模型可能给出唯一预测，是因为随机效应协方差及其中心约束提供了额外结构；这并不表示数据已经像交叉使用公羊的设计那样直接区分了场与遗传。

遗传连通强调不同管理组之间有多少可以用于比较遗传水平的联系。共享公羊、亲属跨场分布、重复使用的参照动物，以及相容的基因组关系都可能提供联系。但“图上有一条线”只说明存在连接，不说明连接足够强。很少的共同亲属、非常久远的关系或高度不平衡的使用模式，可能仍使组间遗传对比误差很大。实际评价应关注目标对比的预测误差方差，而不只统计是否共享过公羊。

例如，在两个场各测一头不同动物，设场效应自由、动物效应相互独立。观测可以完全由场均值吸收，动物的表型偏差没有独立于场的信息。再多测同一动物许多次，只会精确估计场与动物的合成水平，并不能创造跨场连接。若增加一头在两个场都有可比较记录的参照动物，或者让有已知遗传联系的后代跨场测定，模型才获得新的区分方向。设计的价值来自新增的对比，而不仅是新增的行数。

模型输出中的标准误也要与约束保持相容。单个“总体均值”或“场效应”的标准误可能随参数化改变，而同一个可估计场差的标准误不应改变。若更换参考组后，某个明确可估计对比的结果出现实质变化，应检查设计、约束实现或数值秩判断。把这种不变性作为小规模程序核验，比只检查迭代是否成功更能发现概念性错误。

21.5 固定效应与随机效应的实质区别

固定效应与随机效应不是自然界给每个因素贴好的永久标签。把年份作为固定效应，表示允许本次研究涉及的各年份拥有自由的未知均值，不要求这些均值围绕一个共同分布收缩；把年份作为随机效应，则需要用某种方差结构描述年份差异，通常意味着在信息不足时进行部分汇聚。两种选择对应

不同的信息利用方式和外推目标, 应由设计、科学问题及分布假设共同决定。

“随机抽样的因素一定设为随机, 没有随机抽样的因素只能设为固定”是一种过于机械的理解。动物育种值通常不是从一个完全随机抽样群体中获得, 却仍可在适当群体模型下设为随机, 以利用遗传协方差。与此同时, 一个因素即使来自随机抽样, 如果研究只需要严格控制本次特定水平的均值差, 也可能采用固定效应处理。关键是写清楚所假定的条件分布, 以及目标结论要推广到哪里。

随机效应的均值为零是相对于模型基准的表述。它不表示每一批动物的真实育种值之和必须恰为零, 也不表示经过选择的下一代平均遗传水平不会提高。在存在遗传趋势、基础群体差异或未知亲本来源时, 应通过相应均值结构、关系定义或遗传组处理基准。若把所有出生世代都强行作为独立零均值群体, 可能把需要估计的遗传趋势吸收掉。

可交换性是理解简单随机效应的重要概念。若几头互不相关动物在先验上具有同一分布, 模型不因它们的编号不同而偏好某一头。加入系谱后, 动物之间不再完全可交换, 但共同关系结构仍规定了哪些方向的遗传差异更可能出现。随机效应方差不是给每头动物设一个独立可调的惩罚强度, 而是表达总体变异以及信息共享方式。对于多性状或亲缘效应, 非对角协方差同样重要。

固定效应处理也有代价。一个管理组只有一条记录, 而模型为每个组设置独立固定均值时, 该记录在组内没有剩余对比, 可能不能直接提供个体育种值信息。将管理组改为随机后, 它可能提供信息, 但所得增益依赖组效应分布和其与遗传水平独立等假设。如果优秀动物被优先分配到某些管理组, 这种独立性可能失效。此时所谓更高精度可能来自不恰当的共享, 而不是来自真实新证据。

在小样本场景中, 模型选择应尽量避免由结果倒推假设。例如, 不能因为固定场效应使预测差异变小, 就把场改为随机以得到更大的遗传进展。可以比较两种设定下关键对比、外部预测和校准的变化, 检查结果是否由少数弱连通组驱动。必要时报告敏感性分析, 让读者看见结论对管理结构假设有多的依赖。

21.6 从均方误差最小推导 BLUP

现在回到混合模型，并把协方差参数视为已知。为了理解“最佳线性无偏预测”每个词的含义，先预测随机效应的一个线性函数 $T = l'u$ 。考虑形如 $a'y$ 的线性预测量。其期望为 $a'X\beta$ ，而 $E(T) = 0$ 。要使预测误差的期望对任意固定参数 β 都为零，必须满足 $a'X = 0$ 。这就是随机效应预测中无偏约束的具体内容。

在这一约束下，均方预测误差可以展开为

$$\text{MSE}(a) = a'Va - 2a'Z\Sigma_u l + l'\Sigma_u l.$$

最后一项与所选择的预测系数无关。对前两项求导，并以拉格朗日乘子处理无偏约束，得到 $Va + X\lambda = Z\Sigma_u l$ 。左乘 $X'V^{-1}$ 后，结合 $X'a = 0$ ，可解出乘子，再代回得到 $a = QZ\Sigma_u l$ 。这里

$$Q = V^{-1} - V^{-1}X(X'V^{-1}X)^{-}X'V^{-1}.$$

因此，把所有随机效应同时写出，其预测为

$$\hat{u} = \Sigma_u Z'Qy.$$

这个推导说明，最佳是相对于给定协方差和指定的线性无偏预测量集合而言。它不意味着在所有可能的数据机制、所有损失函数和所有非线性方法中都占优势。若研究目标是预测极端尾部风险、分类决策或非对称经济损失，均方误差最优未必直接对应最终决策最优。BLUP的重要性在于它给出了一个结构清楚、可以检验假设的基准，而不是一个不需要说明条件的优越性称号。

算子 Q 有两个关键性质： $QX = 0$ ，以及 $QVQ = Q$ 。第一个性质表示它消除了固定效应均值方向；第二个性质表示它在协方差加权意义下具有投影作用。一般而言， Q^2 并不等于 Q ，因此不能把它当作普通欧氏投影矩阵。只有在误差尺度和变换已适当标准化的特殊情形中，熟悉的正交投影形式才直接出现。

利用广义最小二乘估计

$$\hat{\beta} = (X'V^{-1}X)^{-1} X'V^{-1}y,$$

还可以把预测写成

$$\hat{u} = \Sigma_u Z'V^{-1}(y - X\hat{\beta}).$$

这个表达更贴近育种解释：先在同一协方差模型下确定系统性均值，再用随机效应与记录的交叉协方差解释剩余偏差。但计算顺序不应被误读为两个完全独立的分析。 $\hat{\beta}$ 使用了随机效应协方差，随机效应预测又使用校正后的记录；二者来自一个联合系统。

推导本身只需要一、二阶矩，不需要正态分布。若进一步假定随机效应与残差联合正态、固定均值已知，最佳线性预测也等于条件均值，因此在平方损失下对所有可测预测函数最优。固定效应未知时，BLUP 可由适当的广义贝叶斯表达获得，但应分清频率学派的线性无偏准则与贝叶斯先验解释。两种语言在某些条件下给出相同数值，并不意味着它们提出的是完全相同的问题。

21.7 无偏、收缩与条件偏差并不矛盾

初学 BLUP 时最常见的疑问是：既然叫无偏预测，为什么优秀动物的预测值往往被拉向平均？答案在于讨论偏差时所固定的对象不同。BLUP 满足的是对随机效应和残差共同取期望的边际无偏，即 $E(\hat{u} - u) = 0$ 。若把一头动物的真实育种值固定下来，只反复改变它的环境误差，通常并没有 $E(\hat{u} | u) = u$ 。

教学例 21.2：收缩带来的条件偏差与总体收益。 设总体均值已知为零，一头动物只有一条记录 $y = u + e$ ，遗传方差为 4，残差方差为 12。线性预测系数为 $4/(4 + 12) = 1/4$ ，所以观察到 4 时预测育种值为 1。若这头动物的真实育种值恰好就是 4，反复改变环境误差后，预测均值仍是 1，条件偏差为 -3。这不是计算错误，而是收缩所产生的条件性质。

为了评价这种做法,需要比较整个目标群体上的预测误差。预测误差为 $u - \hat{u} = (3/4)u - (1/4)e$, 所以均方误差为 $(3/4)^2 \times 4 + (1/4)^2 \times 12 = 3$ 。直接用表型预测育种值虽在固定 u 时条件无偏,却有均方误差 12。收缩允许对极端真实值产生条件偏差,以换取在所假定群体分布中更小的平均预测错误。

这也解释了为什么不应仅用少数事后确认特别优秀的动物评价预测偏差。先依据后续真值选择极端个体,再观察它们早期预测是否偏低,改变了评价群体。一个对所有候选动物合理校准的模型,在事后筛选出的极端真值群中仍可能表现为明显收缩。若育种决策真正只关心某个被选择的子群,应明确该子群如何形成,并分析选择条件是否改变了需要评价的概率分布。

收缩系数也不是一个固定的“遗传折扣率”。在最简单的单条自身记录情形,它可能等于遗传力;在多条记录、亲属资料、不同精度和未知均值的模型中,它由整个协方差系统决定。一头动物自己的表型为零,仍可能因亲属资料获得非零育种值预测;一头表型很高的动物,也可能因为同场环境效应较高而获得不高的遗传预测。逐只把表型乘以同一个遗传力,只是很特殊的选择指数。

预测的中心同样需要解释。在独立同分布的随机效应模型中,缺乏资料的动物被拉向总体基准;有亲缘时,它可能被拉向由父母和亲属信息决定的条件均值;存在基础群体差异时,还需要相应遗传均值结构。中心不是分析者任意指定的“中庸水平”,而是模型对缺少个体信息时能够作出的最佳基准预测。

在沟通结果时,可以用“预测为多少、仍有多少不确定性、再增加哪类资料最有价值”替代对收缩的价值判断。较大的收缩通常表明个体信息不足或者噪声较强,不表示动物一定普通。对于早期选种,低可靠度但高预测的个体可能值得保留一定使用机会,同时通过分散配种降低风险。是否采用它,还要结合近交、经济权重和可接受风险,而不仅是预测排名。

21.8 混合模型方程与惩罚最小二乘

BLUP 的边际表达涉及 V^{-1} ，但当记录数很大时，直接形成和求逆 V 通常不经济。Henderson (1975a) 讨论的混合模型方程从条件残差和随机效应惩罚出发，给出等价而更适合利用稀疏结构的求解形式。假定 R 与 Σ_u 正定，考虑

$$J(\beta, u) = (y - X\beta - Zu)'R^{-1}(y - X\beta - Zu) + u'\Sigma_u^{-1}u.$$

第一项衡量拟合记录所需承担的残差代价，第二项衡量随机效应偏离其先验中心的代价。分别对固定效应和随机效应求导，得到

$$\begin{bmatrix} X'R^{-1}X & X'R^{-1}Z \\ Z'R^{-1}X & Z'R^{-1}Z + \Sigma_u^{-1} \end{bmatrix} \begin{bmatrix} \hat{\beta} \\ \hat{u} \end{bmatrix} = \begin{bmatrix} X'R^{-1}y \\ Z'R^{-1}y \end{bmatrix}.$$

这些方程中的“惩罚”来自协方差假设，不是为了让预测值尽量接近零而随意添加的技巧。遗传方差较大时，随机效应偏离零的代价较小；残差方差较大时，追随单条记录的收益较小。有亲缘关系时，惩罚还涉及多个动物的联合组合。例如父母与后代之间符合遗传关系的共同变化，与孤立且缺乏资料支持的剧烈变化，可以承担不同的代价。

若 $R = \sigma_e^2 I$ ，且 $\Sigma_u = A\sigma_u^2$ ，把整组方程乘以残差方差后，随机效应块需要加入 λA^{-1} ，其中 $\lambda = \sigma_e^2 / \sigma_u^2$ 。这里必须加入完整的亲缘逆矩阵，而不是只在每个动物对角线上加同一个数。亲缘逆矩阵的非对角项正是连接不同动物遗传信息的重要部分。遗漏这些项会把动物模型变成另一种独立随机效应模型。

可以通过消元证明混合模型方程与边际 BLUP 等价。先从随机效应方程表示 $\hat{u}$ ，代入固定效应方程，再利用矩阵求逆引理得到广义最小二乘形式。反过来，把边际形式代入混合模型方程也能验证两块等式。理论上写出逆矩阵方便说明，但程序实现应优先使用分解、三角求解或适当迭代方法；为获得预测值，通常不需要形成完整逆矩阵。

如果固定效应存在冗余，整体系数矩阵也可能奇异。随机效应的正定惩罚不会自动消除固定效应参数化中的线性依赖。应使用一套满秩固定效应表

示，或在可估计空间中求解，确保约束只改变坐标而不改变统计目标。随意在所有固定效应对角线上增加很小常数，虽然可能让矩阵可逆，却相当于改变模型，不能仅称为没有统计影响的数值修复。

这一推导也连接了统计遗传学与正则化回归。若随机效应是大量标记效应，独立同方差正态先验对应岭型惩罚；若通过一个关系矩阵描述动物效应，则得到关系形式的预测。两种形式是否等价，取决于编码、尺度、协方差与固定效应处理是否一致。不能只因为两个程序都使用“BLUP”名称，就假定它们输入相同数据必然得到相同结果。

21.9 平衡与不平衡资料的完整手算

教学例 21.3：四条记录的联合校正与预测。两头无亲缘动物各有两次记录，第一头为 12 和 10，第二头为 9 和 7。只设一个未知总体均值，随机动物方差与残差方差均为 4。两头动物的记录均值为 11 与 8，但未知总体水平需要与随机效应一起估计。把混合模型方程乘以残差方差后，得到

$$\begin{bmatrix} 4 & 2 & 2 \\ 2 & 3 & 0 \\ 2 & 0 & 3 \end{bmatrix} \begin{bmatrix} \hat{\mu} \\ \hat{u}_1 \\ \hat{u}_2 \end{bmatrix} = \begin{bmatrix} 38 \\ 22 \\ 16 \end{bmatrix}.$$

解为 $\hat{\mu} = 9.5$ 、 $\hat{u}_1 = 1$ 、 $\hat{u}_2 = -1$ 。每头动物的均值偏差分别为 1.5 和 -1.5，由于两次记录给出的收缩系数为 $2/(2+1)$ ，得到上述预测。把结果代入第一条方程， $4 \times 9.5 + 2 - 2 = 38$ ；代入第二条， $2 \times 9.5 + 3 = 22$ 。逐条代入比只观察软件是否输出数字更能帮助理解方程。

如果不考虑随机效应收缩，而把两个动物效应都作为固定差异，观测组均值差为 3；混合模型预测差为 2。这里不是把三分之一的真实遗传差异故意删除，而是承认表型均值差中还有环境噪声。随着每头动物有更多独立重复，均值残差方差下降，收缩会减弱。若所谓重复只是同一原始测量的不同副本，残差并不独立，这种信息增长不会成立。

教学例 21.4：一个记录很多的动物为什么仍不能确定总体均值。第一头

动物只有记录 14，第二头有三条记录 9、10、11。仍取动物方差和残差方差均为 4，只有一个未知固定均值。相应缩放方程为

$$\begin{bmatrix} 4 & 1 & 3 \\ 1 & 2 & 0 \\ 3 & 0 & 4 \end{bmatrix} \begin{bmatrix} \hat{\mu} \\ \hat{u}_1 \\ \hat{u}_2 \end{bmatrix} = \begin{bmatrix} 44 \\ 14 \\ 30 \end{bmatrix}.$$

解为总体均值 11.6，两个随机效应为 1.2 和 -1.2。总样本均值为 11，而不是 11.6。原因在于三个来自同一动物的记录共享同一个随机效应，不能在估计总体均值时当成三个独立动物。组均值的边际方差分别为 8 与 16/3，使用其逆方差加权，恰得到 11.6。这为混合模型结果提供了另一条直观核验路线。

在这个只有两头独立动物、总体均值未知的特殊模型中，尽管记录数不等，两头动物的 PEV 对角元都为 2.8，非对角元为 1.2。第二头更多的记录帮助确定两头之间的差异，却不能单独解决总体遗传基准的不确定性。若总体均值事先已知，第一头和第二头的 PEV 分别为 2 和 1，差异就会直接体现出来。这个反例说明，个体精度不是仅由自己的记录数决定的，它还受到固定效应估计及整个数据结构的限制。

上述两个例子中随机效应解之和为零，是独立同方差动物效应与共同截距结构带来的结果，不应作为所有遗传评定必须再施加的一条约束。有亲缘、不同先验方差或多种遗传来源时，相应性质可能改变。检查求解结果时，应依据模型推导应有的不变量，而不是把在某个教材例子里观察到的现象当成普遍规则。

21.10 预测误差协方差与方程尺度

一个育种值预测只有与精度信息一起出现，才足以支持风险判断。定义预测误差协方差矩阵为 $C_e = \text{Var}(u - \hat{u})$ 。把 $\hat{u} = \Sigma_u Z' Q y$ 代入，并利用 $QX = 0$ 、 $QVQ = Q$ ，可得

$$C_e = \Sigma_u - \Sigma_u Z' Q Z \Sigma_u.$$

这个结果不仅给出每头动物的 PEV，还给出不同动物预测误差之间的协方差。后一部分在比较动物、计算综合目标或分析群体遗传趋势时不可忽略。两头动物可能共享同一个不确定的环境校正，也可能共享父母信息，因此它们的预测误差不必独立。只保存对角元可以满足部分个体报告，却不足以完成所有决策分析。

混合模型方程提供了另一种计算 PEV 的方式。若直接使用未缩放的系数矩阵，也就是保留 R^{-1} 和 Σ_u^{-1} 的形式，在正确处理固定效应秩亏后，其逆矩阵的随机效应块就是 C_e 。若把整组方程乘以 σ_e^2 ，相应系数矩阵记为 C_* ，则必须将其逆矩阵随机块再乘以残差方差，才能得到有正确单位的 PEV：

$$C_e = \sigma_e^2 (C_*^{-1})_{uu}.$$

这个尺度问题看似简单，却是实现和阅读软件输出时常见的错误来源。有的软件输出的是未缩放逆块，有的输出经过残差尺度调整后的 PEV，还有的软件只给近似可靠度。使用者必须查明输出定义，不能在不明尺度的数值上再次乘或除残差方差。量纲检查很有帮助：若性状单位为千克，PEV 应为平方千克，而可靠度应无量纲。

例 21.3 的预测误差协方差为

$$C_e = \begin{bmatrix} 8/3 & 4/3 \\ 4/3 & 8/3 \end{bmatrix}.$$

若只看两头动物各自的误差方差，二者相同。但若目标是比较差值 $u_1 - u_2$ ，其 PEV 为 $8/3 + 8/3 - 2(4/3) = 8/3$ ，不是简单相加得到的 $16/3$ 。共同基准的不确定性在差值中部分抵消。反过来，若目标是两头动物的平均遗传水平，共同误差不会像独立误差那样充分平均掉；必须使用完整二次型计算。

一般地，对目标 $T = l'u$ ，预测误差方差为 $l'C_e l$ 。这个统一公式可以处理亲本平均、个体间差值、群体平均和多性状经济目标。若目标还包含固定效应的线性函数，应使用固定效应估计误差、随机效应预测误差及其交叉协方差构成的完整矩阵，不能只取随机效应块。预测未来表型时，还须增加未来残差及可能的相关项。

PEV 是模型内部的精度描述。它以指定的协方差、设计和估计目标为条件，不自动包括错误系谱、遗漏环境效应、测定制度改变或参数估计不确定性。PEV 很小意味着在当前模型内部信息很充分，不等于模型假设已经得到独立验证。实际使用应同时考察模型内部精度和外部校准，特别是跨场、跨代和跨品种部署时。

21.11 准确度、可靠度与比较风险

准确度通常定义为真实育种值与其预测值之间的相关系数，可靠度是准确度的平方。在已知参数、模型正确的线性预测系统中，预测值与预测误差正交，因此 $\text{Cov}(u_i, \hat{u}_i) = \text{Var}(\hat{u}_i)$ 。由方差分解可以得到个体模型可靠度

$$r_i^2 = 1 - \frac{\text{PEV}_i}{\text{Var}(u_i)}.$$

准确度是这个量的非负平方根。需要注意，该公式中的方差是同一随机模型下个体育种值的先验方差。动物模型中可能是 $A_{ii}\sigma_u^2$ ，基因组模型中可能是 $G_{ii}\sigma_u^2$ ，但实际评定体系也可能采用某种统一报告基准。必须按定义解释分母，而不能把不同系统输出的可靠度直接混合。

可靠度不是“预测值正确的概率”。例如可靠度 0.64 表示相关系数 0.8，并不表示该动物有 64% 的概率被预测准确，也不表示预测值的 64% 是真实遗传、其余 36% 是环境。连续参数几乎不可能恰好等于一个点预测。可靠度衡量的是误差相对于先验变异的比例，它没有直接给出经济上超过某个门槛的概率。后者需要预测误差分布、目标门槛以及可能的多性状关联。

教学例 21.5：相同预测值，不同风险。两头候选公羊都预测比基准高 2 个性状单位，先验育种值方差均为 4。若第一头 PEV 为 1，第二头 PEV 为 3，则可靠度分别为 0.75 和 0.25。它们的点预测相同，但第一头的预测误差尺度较小。若采用联合正态模型并将固定效应及方差视为适当已知，能够据此计算超过指定目标的条件概率。真实部署中若方差参数不稳定，这种条件概率还可能低估额外不确定性，因而要说明所包含的误差来源。

个体模型可靠度与群体准确度不能随意互换。群体准确度指某一批候选动物之间真实值和预测值的相关，它受群体的遗传变异、家系结构及选择条

件影响。一批全同胞如果只依据完全已知的父母平均评定，所有预测值都一样，无法区分同胞之间的孟德尔抽样；但单个个体相对于基础群体的预测不确定性已经减少。这说明较高的个体可靠度并不保证在任何子群中都有同样高的排序能力。

预测值差异是否足以影响选择，也要看对比误差而不是单个误差。设两头动物预测差为 1，差值 PEV 为 4，那么该差异相对于误差标准差 2 很小；若差值 PEV 为 0.04，则差异相对于标准差 0.2 很大。即便如此，育种决策也不一定采用统计显著性门槛。大规模选择的期望收益可以在不确定性存在时为正，关键是正确比较预期收益、风险和多样性，而不是把“不显著”理解为“没有任何选择价值”。

模型准确度还会受到候选群范围影响。若把许多历史优秀与普通动物一起计算相关，遗传范围较宽，相关可能很高；若只在经过预选的相近优良动物间计算，范围受限，相关可能下降。后一种评价对最终选留可能更相关，却需要更精确的真值代理和更大的样本。报告验证结果时，应描述动物来自哪个世代、经历过何种选择，以及相关计算使用的是哪些个体。

可靠度接近 1 也不意味着未来后代表现几乎没有变异。亲本育种值即使已知，后代仍有来自另一亲本的贡献、孟德尔抽样及环境误差。若目标是预测一头具体后代的表型，必须把这些来源加进预测分布。亲本平均后代表现的长期预期与某一只后代的实际结果，是不同层面的随机量。向生产人员解释可靠度时，明确这一点可以避免把高可靠度误认为个体结果保证。

21.12 预测育种值、未来表型与综合目标

一个统计模型可以用于多个预测目标，但同一组输出不能在改变目标后原封不动使用。预测加性育种值关注可传递的遗传贡献；预测动物下一次生产记录还要考虑永久环境；预测后代表型涉及配偶、传递系数和新残差；预测经济目标则需要把多个性状按相容权重组合。先写出目标随机变量，是避免概念混淆最有效的一步。

设未来观测为 $y_* = x'_* \beta + z'_* u + e_*$ 。若新残差独立于已有随机效应和




图 21.1 记录次数、收缩与预测误差。均值已知，遗传方差 4、单次独立残差方差 12；橙线另含方差 6 的持续个体环境。平均记录系数为 $4 / (4 + \sigma_p^2 + 12/n)$ ，误差为 4 乘以一减该系数。虚线为持续环境情形的极限；永久环境的完整遗传解释见第 24 章

观测残差，且固定效应已知，最佳线性预测为 $x'_*\beta + z'_*\hat{u}$ ，预测误差方差为 $z'_*C_e z_* + \text{Var}(e_*)$ 。如果固定效应也需要估计，还要加入其估计误差和与随机效应预测误差的交叉项。不能将遗传 PEV 直接称为未来表型预测误差。

若未来记录与已有记录共享永久环境或连续相关残差， e_* 与已有数据的协方差可能不为零。此时应从完整交叉协方差推导预测，而不是自动把新残差视为不可预测噪声。例如同一动物相邻几天的产量偏差可能含有持续健康状态；这些信息对短期生产预测有用，却不一定属于遗传改良目标。模型应区分可用于预测的持续环境与可传递给下一代的遗传部分。

对多性状总育种目标 $H = v'u$ ，若所有性状育种值已按相同动物顺序堆叠，预测为 $\hat{H} = v'\hat{u}$ ，误差方差为 $v'C_e v$ 。当不同性状的预测误差正相关时，某些同向加权的综合目标误差会累积；当权重相反时，可能部分抵消。因此，不能把各性状可靠度按经济权重简单平均，作为总目标可靠度。目标的方差也应由同一权重作用于遗传协方差计算。

教学例 21.6：相同单性状精度下的两种目标。设两个性状的预测误差协方差为 $C_e = \begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix}$ 。对总和目标，误差方差为 3.2；对差值目标，误差

方差为 0.8。两性状单独 PEV 完全相同，但目标方向不同，综合误差相差四倍。这个例子可以对应同时增加两个产量性状，或在提高某性状时限制另一性状的育种目标。精度永远是目标特异的。

预测一个随机效应的非线性函数时，还需警惕“先预测再变换”与“变换后的条件均值”不同。若条件分布近似正态， $E(u^2 | y)$ 等于条件均值平方加条件方差，而不是只取 $\hat{u}^2$ 。类似地，把对数尺度预测直接指数变换，通常不等于原尺度条件均值。增长率、风险和成本等非线性目标，不能只凭输出单位相似便忽略这种差异。

对阈值或截断决策，可以围绕后验或预测分布计算损失。假设把一头不够优秀的公羊大量使用会带来较大损失，而错过一头优秀公羊的代价较小，最优决策门槛可能高于只比较点预测的门槛。反之，在探索新家系、保持多样性或建立后备群时，接受一定不确定性可能合理。这些选择属于决策层，不应通过随意改动遗传评定模型来暗中实现。

同一个预测对象还需要固定遗传基准。把某出生年度的平均育种值设为零，会使所有报告值整体平移，但不会改变动物间差值。若跨年调整基准，必须在分析遗传趋势前恢复共同尺度。把基准平移与模型更新、资料增加和参数重估分别记录，可以解释为何同一头动物的发布值随时间变化，而不把所有变化都归因于其遗传表现被重新发现。

21.13 奇异协方差、极限模型与正则化

许多混合模型推导假定协方差正定，但现代遗传资料经常产生半正定结构。例如中心化标记矩阵生成的基因组关系可能有零特征值，多性状协方差在某个线性组合上可能没有变异，或者某一随机效应方差估计为零。半正定并不自动表示模型无效，它表示随机效应只在某个子空间内变化。真正的问题是能否在这个支持空间上清楚定义模型与计算。

一种处理方式是写 $\Sigma_u = LL'$ ，其中 L 只包含非零特征方向，再设 $u = Lv$ 、 $\text{Var}(v) = I$ 。模型转为 $y = X\beta + ZLv + e$ ，不需要对奇异 Σ_u 求普通逆。另一种方式是在满足必要相容条件时使用广义逆，但必须确保结果对应同一个受

限随机空间。直接把所有无法求逆的矩阵都交给通用伪逆函数，可能掩盖模型基准或约束处理的不一致。

当某随机效应方差趋向零，它的预测也应趋向其先验中心，模型等价于去掉这一变异来源。当方差非常大，相应惩罚趋弱，预测接近不受收缩的拟合方向。但后一极限不总是安全：若随机效应设计与固定效应重叠，弱惩罚可能使分解高度不稳定。有限方差提供的结构一旦消失，原先被惩罚分开的成分可能重新混杂。

教学例 21.7：只有共同遗传方向的两头动物。 设 $\Sigma_u = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ ，意味着模型规定 $u_1 = u_2$ ，只有一个共同随机效应。用两个独立残差方差均为 1 的记录，均值已知为零时，可以把两条记录看作同一个遗传效应的重复测定。若记录为 2 和 0，共同预测为 $2/(1+2) = 2/3$ 。这里无法预测两头动物之间的遗传差，因为模型先验规定该差恒为零；加更多同类记录也不会改变这一限制。

在矩阵对角线上加一个很小正数，通常能改善可逆性，但它也改变了零特征方向的方差。上述例子若加 δI ，就允许两个动物有独立差异。这个改变也许符合实际需要，却应被理解为模型修订或数值近似，而不是完全没有统计影响的“修复”。应说明所加量相对于矩阵尺度有多大，并检验预测和目标对比对它是否敏感。

大规模关系矩阵常通过与系谱关系或单位矩阵混合获得正定性。混合比例的意义取决于具体模型：它可能表示未被标记解释的多基因成分，也可能主要为了稳定计算。两种解释不能随意互换。若把一个数值稳定参数写成明确的生物学方差占比，就需要额外依据。反过来，若它确实是模型中的变异成分，也不应仅按计算速度随意调整。

判断一个微小特征值是否应视为零，还涉及测量尺度和数值容差。性状单位改变、矩阵整体缩放或不同精度存储，都可能改变绝对特征值大小。稳健的判断应使用相对尺度，并考察该方向是否有明确结构来源。对教学小矩阵可以直接查看全部特征值；对大型系统则需要结合条件数估计、迭代行为

和代表性子问题检查。

正则化的最终目的不是保证所有矩阵都能被某个函数求逆，而是获得与科学目标相容、数值上稳定的预测。一个明确承认低维支持的模型，可能比一个人为加满小方差却解释不清的模型更诚实。相反，当现实中确实存在被简化矩阵遗漏的个体差异时，增加适当残余遗传成分可能更合理。决定依据应是目标、数据与机制，而非对奇异矩阵的形式性恐惧。

21.14 异质残差、稳健性与模型失配

残差协方差是混合模型的信息权重系统，也是容易被简化过度的部分。不同场的称量设备、不同日龄的生长变异和不同生产阶段的记录精度都可能不同。若所有记录被赋予相同残差方差，噪声较大的组可能得到过多权重，噪声较小的组则没有充分贡献。异质残差模型可以按已知组别设置方差，也可以用连续协变量描述方差随环境变化，但新增参数必须有足够数据支持。

一条记录来自三次独立测定的均值，与来自一次测定的记录，其残差方差未必相同。若每次测定方差为 σ_e^2 且独立，均值方差为 $\sigma_e^2/3$ ；若有共同批次误差，平均只能减少独立部分。给均值记录按次数加权之前，应明确重复结构。否则，某些多次测量的动物可能被给予虚假的高精度，进而影响亲属和整个评定网络。

遗漏残差相关的影响不仅是标准误偏小。由于预测系数依赖协方差，育种值本身也可能改变。若同一家系集中在同一栏舍，而栏舍效应未进入模型，家系共同环境可能被误认为遗传相似。增加基因组关系并不自动解决这个问题，因为基因组相似性与家系环境仍可能相关。合理的交叉分配设计、完整管理记录和明确的共同环境效应，对遗传识别仍然重要。

模型失配下，使用真实协方差的 BLUP 最优性不再直接成立。设实际表型协方差为 V_0 ，模型使用 V ，得到线性预测矩阵 L 。实际均方误差应依据 V_0 和真实交叉协方差重新展开，而不是继续引用基于 V 的 PEV。即便固定效应均值结构正确，预测仍可能因为权重失配而效率降低；若均值结构也错了，还会出现系统性偏差。

稳健方法试图降低个别异常记录或尾部失配的影响。例如可采用重尾残差分布,或通过迭代权重减小极大残差的作用。但异常值也可能来自真实大效应遗传变异,过度稳健会削弱有用信号。应比较异常记录是否在同一动物、同一家系、同一设备或同一时间批次集中,并尽量用原始测量和身份资料区分技术错误与生物现象。统计权重不能替代数据核查。

残差图应围绕模型结构解释。按预测值、日龄、场和时间绘图,可以发现尺度变化与系统趋势;按亲缘或家系检查残差,可能揭示遗漏的遗传或共同环境结构。由于混合模型已经对随机效应进行了收缩,直接使用条件残差时,其方差和相关结构并不等于原始 R 。标准化残差应考虑杠杆和拟合带来的影响,不能机械地把所有残差都与同一个标准正态阈值比较。

研究者有时希望用稳健标准误解决全部模型问题。对固定效应的某些推断,夹心协方差可以在适当大样本与聚类条件下提高对协方差失配的容忍度;但它不会自动修正错误的育种值预测、错误的遗传分解或不足的连通。少数大聚类下,所谓稳健标准误本身也可能不稳定。需要区分“改进某个估计量的不确定性计算”与“使整个遗传模型正确”这两件事。

一套有用的敏感性分析应改变最有理由怀疑的假设,而不是随意尝试大量模型后挑选最好结果。可以比较同方差与分场方差、独立与连续相关残差、是否加入共同栏舍效应,并观察主要候选动物、遗传趋势和外部校准是否稳定。如果结论仅在一种狭窄设定下成立,报告这种依赖性比给出单一精确排名更有价值。

21.15 选择、资料保留与两阶段分析

育种资料几乎总是经过选择产生的。优秀动物更可能被留种、获得后代记录或接受更昂贵的测定;表现不佳的动物可能早期淘汰,未来记录因此缺失。选择本身并不意味着任何混合模型都失效,但它要求明确选择依据是否被模型和资料系统充分包含。若选择完全依据已经纳入联合分析的信息,在相应条件下可以建立适当的条件推断;若选择依据没有记录的性状或被删除的历史评定值,标准模型可能无法重建资料产生过程。

一个简单例子是只给幼龄预测较高的动物测成年性状。如果幼龄表型与成年性状遗传相关，而分析成年性状时完全不保留幼龄资料，那么成年记录来自一个非随机子群。其均值和方差都可能不同于原候选群。把这些动物当作随机抽样，并不能因为使用了动物模型就自动恢复基础群体参数。多性状模型、选择信息保留或明确的抽样机制模型，可能成为必要步骤。

现代基因组预选使这个问题更加突出。未被选中的动物可能没有成年表型，却已经有基因型和早期评定值。保留完整候选群的身份、基因型、系谱和选留依据，可以帮助联合模型利用选择时的信息；只保存最终入选个体则会丢失关键背景。单步基因组方法提供统一利用资料的框架，但未记录的管理决策、错误亲子关系和未知选择性状仍可能造成偏差，不能把方法名称当成选择偏差的保证书。

两阶段分析尤其需要谨慎。第一阶段先校正场、年份或其他环境效应，第二阶段再把校正后的表型用于遗传预测，计算上很方便，但校正值本身来自数据估计。若不传递第一阶段的不确定性和残差相关，第二阶段可能把估计的校正值当成真值，夸大信息量。若第一阶段用全体资料，包括未来验证记录，还会发生信息泄漏，使第二阶段的外部验证偏乐观。

在某些条件下，两阶段分析可以与联合分析相容。例如第一阶段提供适当的充分统计量、协方差和权重，第二阶段正确处理它们，就可能保持关键信息。但这要求严密的推导，而不是简单地说“先消除环境影响”。去回归育种、后代偏差和其他伪表型各有定义及适用条件，不能把不同来源的伪表型当作独立同精度的原始记录。其亲缘信息是否已包含、是否被重复使用，都需要核查。

一个有教育意义的反例是：先在全部动物中拟合每个场的平均数，再随机留出部分动物验证基因组模型。留出动物的表型已经影响场平均数，因此也影响训练动物的校正表型。即使第二阶段没有直接读取留出表型列，信息仍通过预处理流入训练过程。严格验证应在每个训练划分中重新拟合所有依赖表型的步骤，并仅用训练所得参数处理验证数据。

遗传趋势分析也与选择和基准密切相关。随着育种推进，年轻动物可能在更好的环境中被测定，环境与出生年份的遗传水平同时改变。若场年效应

和遗传趋势之间缺乏连接,模型可能把一部分遗传进展归给环境,或反过来。长期保留参照公羊、跨年亲属联系和稳定测定制度,可以增加区分两者的能力。趋势曲线平滑并不代表趋势已经被可靠识别。

外部校准是检查这些问题的重要补充。可以在历史信息截点上冻结可用资料,预测当时的候选动物,再观察后续资料到来后的均值、尺度和排序变化。Legarra 与 Reverter (2018) 提出的 LR 框架利用部分资料与完整资料的评定比较,提供了有条件的偏差与离散度诊断;阅读时应同时注意 Legarra 与 Reverter (2019) 的勘误,不沿用原摘要关于小或相关验证群导致理想斜率期望低于 1 的错误表述。两套模型若共同遗漏同一环境因素,也可能彼此吻合,因此 LR 不能替代所有外部证据。

资料保留政策应被视为方法的一部分。保存被淘汰个体的早期记录、原始身份连接、测定日期和版本信息,常常比事后增加一个复杂算法更有价值。没有这些资料,许多选择机制无法重建,任何方法都只能依赖较强假设。透明说明资料如何进入系统,是高质量遗传评定不可省略的内容。

21.16 从已知参数的 BLUP 到经验 BLUP

理论推导中把 Σ_u 和 R 当作已知,是为了明确最优加权的结构。实际中它们通常由同一批或相关资料估计,再代入方程,得到经验 BLUP。代入估计是合理而广泛使用的做法,但预测系数因此成为数据的函数,严格的“线性”与“已知协方差下最佳”性质不能无条件照搬。尤其在小样本、多个弱可识别方差和边界估计时,参数不确定性可能是主要误差来源。

最简单的示例仍是单条记录预测 $\hat{u} = ky$, 其中 $k = \sigma_u^2 / (\sigma_u^2 + \sigma_e^2)$ 。若 k 固定,预测误差可以直接计算;若从很少的动物中估计 k ,每次重复取样时它都会变化,并且可能与观测 y 相关。把估计值代入已知参数 PEV,仅反映“假定这次估计值就是真值”时的条件精度,没有自动包括权重估计造成的波动。

这个问题并不意味着必须放弃经验 BLUP。大规模、结构良好的资料可能使关键方差比估计得足够稳定,额外误差相对较小。需要做的是判断它在

当前问题中是否重要。可以比较不同合理参数值下预测排序和目标收益的变化,检查似然剖面、标准误和边界情况。若预测对一个很不稳定的相关参数极其敏感,单次代入结果不宜被解释为精确的生物学等级。

参数自助法提供一种可操作的评估路线。先指定拟合模型和参数,再按原设计生成随机效应和残差;对每套模拟资料重新估计方差、重新预测,最后比较预测与模拟真值。这样能够把参数估计环节纳入误差评价。但结果仍以生成模型为前提,不能检验模型外的所有失配。若真实应用有选择、缺失或测定门槛,自助模拟也应尽量重现这些过程,否则得到的误差可能过于乐观。

另一条路线是在贝叶斯模型中对方差参数积分。条件于给定方差时,随机效应后验可能有简单形式;对方差的不确定性积分后,总后验方差包含平均条件方差和条件均值随参数变化的方差。这是全概率方差公式的直接应用。它清楚地说明为什么只固定一组估计参数可能低估不确定性。不过贝叶斯结果也依赖先验、采样质量和模型结构,不应把“积分了参数”当成所有风险均已覆盖。

对重要选择决策,可以把参数敏感性转化为可理解的稳定性指标。例如,在一组有依据的参数范围内,某头公羊是否始终位于候选前列,某个跨场比较是否改变方向,某种配种组合是否稳定优于另一组合。这样的分析不必为了追求一个漂亮区间而引入过复杂模型,它直接回答决策对不确定参数有多敏感。若许多候选的相对次序频繁变化,应考虑分散使用或继续测定。

方差参数还可能随群体和环境变化。经过持续选择,等位基因频率、连锁不平衡和遗传变异可能改变;测定制度升级也会改变残差结构。长期固定一组历史参数有利于发布稳定性,却可能逐渐偏离当前目标群体。频繁重估又会把抽样波动引入每次发布。因此需要预先规定参数检查与更新机制,结合足够资料、外部校准和业务时点作出调整。

经验 BLUP 的报告应把“本次参数来自哪里”说清楚。参数可能来自本群体历史资料、外部文献、前一轮正式评定或当前联合估计。不同来源有不同的可迁移性与不确定性。如果小群体使用外部遗传参数,至少应核对性状定义、年龄、品种和测定环境,并通过敏感性分析说明主要结论是否依赖某

个狭窄数值。一个来源明确的近似，通常比一个没有解释的高精度数字更可靠。

Harville (1977) 系统讨论了方差组分似然估计与混合模型计算之间的联系。这个联系提醒我们，预测与参数估计虽然可以分步实施，统计上却共享同一协方差结构；第 23 章将进一步推导其中的限制似然与不确定性。

21.17 把数学模型转化为可靠计算

混合模型计算的第一项任务不是调用求解器，而是保证每条数据被连接到正确的动物和效应。动物编号、父母编号、场年批次和测定日期应经过一致性检查；同一动物在不同文件中的顺序不必相同，但映射必须相同。把文件行号当作身份，可能生成维度正确、数值看似平滑却完全错误的关系结构。此类错误通常不会触发求解器异常。

建立设计矩阵时，应检查每行表示了什么。一条单性状动物记录通常在动物效应设计矩阵中只有一个 1，多性状、母体或社会效应模型则可能有不同的连接。数值为 1 并不具有固定含义：它可能表示自身、母亲或同组伙伴。保存清楚的列索引和效应名称，可以使方程构造被独立复核。对于手算小例子，应能够从每条记录逐项解释左端系数与右端和数。

求解大规模对称正定系统时，稀疏分解或预条件共轭梯度等方法可以利用结构降低成本。预条件的作用是改善数值尺度，而不改变统计目标。若原系统为 $Cx = d$ ，好的预条件使不同方向的有效尺度更接近，从而减少迭代。若算法直接替换了关系矩阵或删除某些协方差，则属于另一种模型或矩阵近似，不能与单纯的数值预条件混为一谈。

停止准则应同时关注方程残差与目标量变化。相邻两次育种值差异很小，可能表示接近解，也可能表示数值停滞。可以检查相对残差 $\|d - Cx_k\| / \|d\|$ ，并对重要候选或综合目标设置适当精度要求。容差应相对于实际选择差异有意义；把数值误差降低到远小于模型误差以后，继续追求更多小数通常不会改善育种决策。

小型等价问题是核验实现的有力工具。对同一教学数据，可以分别用边

际协方差公式和混合模型方程求预测；对于具有标记表示的模型，还可以用标记效应和关系矩阵两条路线比较。两条路线应在相同固定效应、方差尺度和约束下相容。若不相容，应先查维度、排序、缩放和子矩阵操作，而不是把差异归因于“软件算法不同”。

本章的平衡与不平衡例子提供了几种不同检查。例 21.3 验证未知均值与动物效应的联合解；例 21.4 验证组内重复对总体均值的信息权重；PEV 例子验证缩放逆块与边际公式的一致；奇异例子验证在受限随机空间中求解。每项检查针对一个具体风险，而不是仅把同一段代码换个函数再运行一次。实际软件还需针对缺失记录、无记录祖先和异常输入作独立检查。

大型系统不一定需要完整逆矩阵。若只需要育种值，求解方程即可；若需要少数目标对比的 PEV，可以求解相应线性系统；若需要全部个体可靠度，才需要选择逆元素或适当近似。明确输出需求可以节省大量计算。近似可靠度应与精确可计算的小问题比较，并说明近似误差，不宜因为预测值本身计算精确，就默认可靠度也同样精确。

复现记录应包括数据版本、动物排序规则、模型定义、方差参数、软件版本和求解容差。随机近似或重抽样还应保存种子和重复次数。只保存最终育种值表，无法解释日后为什么某些动物的评定改变。模型更新、资料新增、参数变化和基准平移应分别记录，这既服务学术复现，也服务生产系统中的责任追溯。

计算成功与科学有效是不同关口。一个方程可以被求解到机器精度，但其变量身份可能错误；身份正确的模型可能仍遗漏关键环境；模型结构合理也可能缺乏跨场连通。质量控制必须从数据、统计和数值三个层面共同进行。对用户发布结果时，应提供与实际使用有关的精度和适用范围，而不是以“程序正常结束”作为可靠性的主要证明。

21.18 固定与随机混合目标的统一最优预测

估计场间差异与预测育种值可以放进同一个问题，但必须先说明目标中哪些成分是固定未知量，哪些成分是随机量。设观测模型仍为 $y = X\beta + Zu + e$,

随机效应与残差不相关, 协方差已知, 且 $V = Z\Sigma_u Z' + R$ 正定。现在不只预测一个育种值, 而考虑 $T = k'\beta + l'u$ 。例如, 在指定场条件下预测一头动物的潜在生产水平, 就同时包含场均值与个体遗传偏差。Harville (1976) 对高斯—马尔可夫结论的扩展, 为这样同时处理固定与随机效应提供了统一理论; 以下直接从预测误差推导其可计算形式。

为减少长式, 定义目标随机部分与观测的协方差, 以及固定效应的信息矩阵:

$$c = \text{Cov}(y, l'u) = Z\Sigma_u l, \quad F = X'V^{-1}X.$$

考虑线性预测量 $\hat{T} = a'y$ 。其无偏条件必须对每一个可能的固定参数成立, 因此有

$$E(\hat{T} - T) = (X'a - k)'\beta = 0, \quad X'a = k.$$

这一条件揭示了可估函数与随机预测之间的界限。若 k 不属于 X' 的列空间, 就没有任何线性权重能够满足约束; 即使随机部分的信息非常丰富, 也不能补足一个未被设计识别的固定均值方向。随机效应分布所带来的借用信息, 与任意固定参数下的无偏要求, 是两种不同的逻辑。给一个原本固定的场效应增加收缩先验, 确实可以产生数值预测, 但这已经改变了问题, 不能称为在原模型内修复不可估性。

在可行约束下, 均方误差为

$$M(a) = l'\Sigma_u l + a'Va - 2a'c.$$

设拉格朗日函数为 $M(a) + 2\lambda'(k - X'a)$ 。对权重求导, 得到 $Va = c + X\lambda$ 。再代入无偏约束, 可解出

$$d = k - X'V^{-1}c, \quad \lambda = F^{-1}d,$$

$$a_0 = V^{-1}c + V^{-1}XF^{-1}d.$$

这里的广义逆仅用于固定效应的冗余坐标。因为 d 属于 F 的列空间, 不同合适广义逆给出的预测相同。若设计满列秩, 可直接把 F^{-1} 写成普通逆。将

权重与观测相乘，并利用广义最小二乘解，可得熟悉而更一般的形式：

$$\hat{T} = k'\hat{\beta} + c'V^{-1}(y - X\hat{\beta}).$$

最优性不必只靠驻点来保证。任取另一个可行权重 $a = a_0 + h$ ，都有 $X'h = 0$ 。利用 $Va_0 - c = X\lambda$ ，两种误差之差正好是

$$M(a) - M(a_0) = h'Vh \geq 0.$$

因此正定协方差保证权重层面的唯一最优解。这一证明只使用二阶矩，没有要求正态。正态性在计算完整条件分布和尾部概率时才承担额外作用。代回最优权重，还得到误差的两部分分解：

$$M(a_0) = l'\Sigma_u l - c'V^{-1}c + d'F^{-1}d.$$

第一部分是假定固定参数已知时仍不能消除的随机预测误差；第二部分是固定参数必须从现有资料中估计的代价。它非负，却不是任意加上的保守系数，而由目标的固定部分与观测中可用于解释该目标的均值方向之差决定。若 $d = 0$ ，未知固定参数在这一特定目标上不增加误差；这并不表示所有固定效应都估得很准。

独立教学例：预测包含总体均值的个体水平。两只无亲缘动物各有一条记录，记录为二与四；遗传方差分别为一与四，残差方差均为一，只设未知总体均值。此时 $V = \text{diag}(2, 5)$ ，总体均值估计为 $18/7$ 。预测第一只动物的总体水平 $T = \mu + u_1$ ，有 $c = (1, 0)'$ 、 $d = 1/2$ ，于是

$$\hat{T} = \frac{6}{7}y_1 + \frac{1}{7}y_2 = \frac{16}{7}, \quad M(\hat{T}) = \frac{1}{2} + \frac{5}{14} = \frac{6}{7}.$$

第二只动物虽然并非目标，也能通过帮助确定总体均值进入预测。若错误地把总体均值设为零，预测变为一，误差公式也只剩二分之一；后一个数描述的是另一个拥有额外已知信息的实验，并非本实验的精度。反过来，若目标是一个完全没有观察过且无连接的新场固定均值，上述无偏约束可能根本不可行。正确结果应指出目标不可估，而不是把软件给出的某个零约束解当成具有有限精度的场外预测。

可以再用一个秩亏的小设计检验“有唯一数值”和“有可估目标”的区别。设两个观测均含总体截距，分别属于甲组与乙组，同时把两个组效应全部列入参数，设计为

$$X = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}, \quad v = (1, -1, -1)', \quad Xv = 0.$$

甲组与乙组差异的权重为 $k = (0, 1, -1)'$ ，满足 $k'v = 0$ ，所以组差可估；单独的总体截距权重为 $(1, 0, 0)'$ ，不满足这一条件。把甲组效应设为零后，总体截距等于甲组均值；把两组效应之和设为零后，总体截距等于两组均值的平均。两种数值不同，恰恰说明“总体截距”在冗余参数化中没有独立确定的含义。若在报告中只写截距而不写约束，就可能使读者把坐标变化误解为群体水平变化。相反，甲组的拟合均值由总体截距与甲组效应之和组成，在两种约束下应完全一致。

这个检验同样适用于混合目标。把一个不可估固定方向加上一个随机育种值，不会自动使固定方向可估，因为随机部分的边际期望为零，无法抵消任意固定参数沿零空间的变化。若采用适当固定效应先验，所得后验目标可以存在，但应解释先验提供了什么基准信息。区分这些情况，可以避免把广义逆返回结果的能力误当成资料识别目标的能力。

21.19 联合误差矩阵与交叉项的实际含义

上一节的分解还可以从固定效应与随机效应的联合误差出发理解。为避免符号方向造成混乱，本节始终把误差写成“估计或预测减去真实值”： $b_e = \hat{\beta} - \beta$ ， $u_e = \hat{u} - u$ 。假定 X 满列秩，并记 $B = (X'V^{-1}X)^{-1}$ 。使用其他误差方向时，两个分量必须同时改变；如果只改变其中一个，交叉协方差的符号就会反转。

广义最小二乘估计误差可写为

$$b_e = BX'V^{-1}(Zu + e), \quad \text{Var}(b_e) = B.$$

定义消除固定均值的精度算子

$$Q = V^{-1} - V^{-1}XBX'V^{-1}, \quad QX = 0, \quad QVQ = Q.$$

随机效应预测为 $\hat{u} = \Sigma_u Z'Qy$ 。计算交叉协方差时，一个容易漏掉的事实是 $\text{Cov}(\hat{\beta}, \hat{u}) = 0$ ，但 $\text{Cov}(\hat{\beta}, u)$ 一般不为零。前者由 $X'Q = 0$ 得到，后者来自估计总体均值时不可避免地混入样本动物的遗传偏差。因此

$$\text{Cov}(b_e, u_e) = -BX'V^{-1}Z\Sigma_u.$$

把各块合起来，联合误差协方差为

$$C = \begin{bmatrix} B & -BX'V^{-1}Z\Sigma_u \\ -\Sigma_u Z'V^{-1}XB & C_u \end{bmatrix},$$

$$C_u = \Sigma_u - \Sigma_u Z'QZ\Sigma_u.$$

对于 $T = k'\beta + l'u$ ，应使用完整二次型，而不是把两个边际方差机械相加：

$$\text{Var}(\hat{T} - T) = k'Bk + 2k'C_{\beta u}l + l'C_u l.$$

负交叉项常有清楚的统计意义。如果某次抽样中总体均值被估得偏高，个体偏差就倾向于被估得偏低；把两者重新相加预测该个体的总体水平时，部分误差会相互抵消。这不是人为调小误差，而是同一批资料同时决定均值与偏差的结果。若把两个阶段独立计算后只传递对角标准误，就会丢失这种依赖；再大的样本输出表也无法从两个对角数恢复交叉项。

继续使用上一节两条记录的教学参数，可以得到

$$B = \frac{10}{7}, \quad C_u = \frac{1}{7} \begin{bmatrix} 6 & 4 \\ 4 & 12 \end{bmatrix},$$

$$C_{\beta u} = \begin{bmatrix} -5/7 & -8/7 \end{bmatrix}.$$

因此第一只动物总体水平的误差为 $10/7 + 6/7 - 10/7 = 6/7$ 。若忽略交叉项，会误报为 $16/7$ ；若只拿育种值的误差代替总体水平误差，本例恰好也是

6/7, 但那只是数值巧合。第二只动物总体水平的误差为 $10/7 + 12/7 - 16/7 = 6/7$, 而其育种值误差为 $12/7$, 立即说明两个目标不能通用一个标准误。

对未来观测还要多加一层。若未来残差 e_* 与训练资料独立, 预测未来记录的误差等于潜在均值误差加 $\text{Var}(e_*)$; 如果残差相关, 就必须重新形成目标与训练资料的交叉协方差。本节公式适用于目标为固定与现有随机效应的线性组合, 不能把有相关性的未来残差偷偷塞进独立噪声项。短期生产预测与遗传评价在这一点上尤其容易混淆, 因为健康冲击能够帮助预测明日表现, 却不属于传递给后代的遗传贡献。

联合误差矩阵也解释了为什么更换固定效应约束后, 单个冗余系数的标准误可能变化, 而可估目标的误差应保持不变。若两种坐标由可逆变换连接, 误差矩阵要作相同的左右变换, 目标权重则按反方向变换。目标二次型不变才是可重复性的检查对象。比较不同软件时, 应先对齐目标与约束, 而不是直接逐项比较参考组系数。

21.20 用新增信息的创新量分解精度增益

一次遗传评定不是孤立事件。新表型、新后代或新环境记录到来以后, 原预测如何更新? 在方差参数与模型结构固定时, 可以把更新写成一个很直观的误差校正。先讨论均值已知, 或者已经在共同模型中合法处理均值后的随机向量; 这一步条件很重要, 不能把用未来资料估出的校正值当成事先已知。

令旧资料为 y_o , 新增资料为 y_n , 其协方差分块为 V_{oo}, V_{on}, V_{nn} 。把新增资料中能够由旧资料线性解释的部分去掉, 得到创新量

$$v = y_n - V_{no}V_{oo}^{-1}y_o,$$

$$S = \text{Var}(v) = V_{nn} - V_{no}V_{oo}^{-1}V_{on}.$$

创新量与旧资料不相关。若联合分布正态, 还具有独立性; 只有二阶矩条件时, 线性最优更新仍成立, 但不能把不相关自动说成独立。设目标与新

旧资料的协方差分别为 c_n, c_o ，则真正新增的目标信息为

$$g = \text{Cov}(v, T) = c_n - V_{no} V_{oo}^{-1} c_o.$$

因此完整资料预测可分为旧预测与创新校正：

$$\hat{T}_{o+n} = \hat{T}_o + g' S^{-1} v,$$

$$PEV_o - PEV_{o+n} = g' S^{-1} g \geq 0.$$

这个表达把“新增记录有多少”改写为更有用的问题：新增记录中尚未被旧资料解释的部分，与目标还保留多少协方差。若 $g = 0$ ，新资料可以有很大波动，却不改善这个目标；若创新方差很小但目标协方差也同步缩小，也不能仅凭精度高就声称信息巨大。完全重复复制一条旧记录时，创新恒为零，不能使用普通逆，正确处理是删去零创新方向，所得信息增益为零。

独立教学例：一次高精度复测。设育种值方差为四，旧记录残差方差为十二，旧记录为四，且均值已知。旧预测为一，误差方差为三。现在增加一条独立残差方差为一、数值为三的新记录。给定旧资料，新记录围绕旧预测的创新为二，创新方差为四；目标与创新的条件协方差为三。因此

$$\hat{u}_{new} = 1 + \frac{3}{4}(3 - 1) = 2.5, \quad C_{new} = 3 - \frac{3^2}{4} = 0.75.$$

若新记录残差方差改为十二，创新方差为十五，增益就从 $9/4$ 降为 $9/15$ 。新观测值决定更新朝哪个方向移动，设计与协方差决定预计精度改善多少。即使新记录恰好等于旧预测，点预测完全不动，误差仍会下降；“评定值没有变化”不等于“新增记录没有信息”。这一差别适合用来解释生产者对稳定发布值的疑问。

对于未知固定效应，可以在完整混合目标空间中构造创新，或者直接比较两个设计下的最优预测类。只要新分析保留旧资料、采用相同已知参数并允许旧权重补零，新线性无偏预测类包含旧预测类，因此最小误差不会增加。这个集合包含论证比硬套均值已知公式更一般。然而，如果更新时重新估计方差、删除历史资料、改变场组定义或更换目标，误差的单调结论就不再由

上述证明保证。经验可靠度下降不一定是程序错误，首先应辨认究竟有哪些统计条件改变。

创新量还提供一项数据质量诊断。新记录相对旧模型异常大时，可以检查其与既有信息是否相容，但异常创新既可能来自记录错误，也可能来自真实环境变化或遗传极值。仅因与原预测不一致就删除记录，会人为保护旧模型。合理做法是依据独立质量规则核查，并将预测更新与异常来源调查分别记录。

如果新增资料主要用于估计一个共同环境效应，它对目标的帮助还可能通过减少旧资料中的校正误差实现，而不是通过直接遗传协方差实现。例如旧资料只有一只候选动物在某场的一次表现，新资料是同场多只低亲缘动物的表现；新增动物与候选者的遗传协方差很小，但它们共同帮助辨认场均值。均值已知模型会把这条信息路径预先删除，所以在设计比较时不能一方面假定场效应已知，另一方面又用计算结果评价同场对照动物的价值。

这一点可以用嵌套线性空间描述。记旧资料可形成的全部线性无偏预测为集合 $\mathcal{L}_0$ ，完整资料相应集合为 $\mathcal{L}_f$ 。如果固定设计的参数定义保持不变，旧权重在新增位置补零仍无偏，于是

$$\mathcal{L}_0 \subseteq \mathcal{L}_f, \quad \inf_{a \in \mathcal{L}_f} M(a) \leq \inf_{a \in \mathcal{L}_0} M(a).$$

若新增了一个自由的固定组效应，两个集合便可能不再具有这种包含关系；观察到精度下降，可能来自对环境异质性的更诚实表示。这里需要比较的是两种科学假设，而不是把精度较高的一种自动视为正确。评定系统的更新报告若能分清“资料增加”和“允许更多环境差异”两项，就更容易解释表面上反常的精度变化。

21.21 多维可靠度与最难预测的遗传方向

多性状或多随机效应模型经常为每个分量报告一个可靠度，但实际选择目标往往位于分量的某个组合方向。两个边际可靠度都较高，并不能保证所有组合都同样精确。为了把单位不同的遗传方向放在同一尺度上比较，设目

标向量 u 的先验协方差为正定 Σ_u , 预测误差协方差为 C_u 。在已知参数的正确线性模型中, 二者满足半正定次序 $0 \leq C_u \leq \Sigma_u$ 。

用先验标准化坐标 $z = \Sigma_u^{-1/2}u$, 其协方差为单位矩阵。标准化误差矩阵为

$$D = \Sigma_u^{-1/2}C_u\Sigma_u^{-1/2}.$$

对任意非零目标权重 l , 该目标可靠度等于

$$r^2(l) = 1 - \frac{l'C_u l}{l'\Sigma_u l}.$$

令 $w = \Sigma_u^{1/2}l$, 上式中的误差比例变为 $w'Dw/(w'w)$ 。因此, 只需对称特征分解, 就能找出整个目标空间里最好与最差的预测方向:

$$Dv_j = \delta_j v_j, \quad 0 \leq \delta_j \leq 1,$$

$$1 - \delta_{\max} \leq r^2(l) \leq 1 - \delta_{\min}.$$

这些方向对应标准化后的组合, 而不是原单位下最大方差的主成分。主成分回答哪里有多遗传变异, 这里的特征方向回答哪里有较大比例的未消除误差。两类方向可能一致, 也可能完全不同。若资料主要测定一个性状, 遗传相关可以帮助预测另一个性状, 但某个两性状差异方向仍可能几乎没有直接证据。

独立教学例: 相同边际表格隐藏的弱方向。取

$$\Sigma_u = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}, \quad C_u = \begin{bmatrix} 1 & 0.3 \\ 0.3 & 0.5 \end{bmatrix}.$$

两个分量可靠度分别为零点七五和零点五。标准化后有

$$D = \begin{bmatrix} 0.25 & 0.15 \\ 0.15 & 0.50 \end{bmatrix}, \quad \delta_{1,2} = 0.179744, 0.570256.$$

所以某些组合可靠度可达到约零点八二, 而另一些仅约零点四三。最弱方向在标准化坐标中约为 $(0.4242, 0.9056)'$; 转换回原目标权重, 要再左

乘 $\Sigma_u^{-1/2}$, 得到约 $(0.2121, 0.9056)'$ 。若直接把特征向量当作原单位经济权重, 就会混淆标准化与实际目标, 这正是矩阵方法虽简洁却需仔细解释单位的原因。

该分析也可以用于决定新增测定资源投向哪里。若某个经济目标与弱方向相近, 优先采集能够降低该方向误差的记录, 比只追求群体平均边际可靠度可能更有效。但特征方向由当前协方差与设计决定, 并非永久的生物学分类; 资料更新、目标群体变化或新增性状都会改变它。实际资源分配还要结合成本、动物福利与测定可行性, 而不能仅按一个特征值排序。

当 Σ_u 奇异时, 应先限制在其非零支持空间, 再作同样分析。先验方差为零的组合是模型规定没有变异的方向, 不应将零除以零解释为可靠度百分之百。另一方面, 如果数值近似给出负特征误差或超过一的误差比例, 需要先检查尺度、近似逆块与参数条件; 不能只把异常值裁剪到零至一而隐藏问题。




图 21.2 组合目标的可靠度随方向变化。标准化目标方向以角度表示, 蓝线包含误差交叉项, 灰线只保留对角项; 先验与误差协方差采用 21.21 的教学算例

21.22 线性最优与条件均值最优的精确差别

最佳线性预测并不要求随机效应正态, 但“最佳”明确限定在线性预测类中。平方损失下, 允许所有可测函数时的最优预测是条件均值。在均值已知的联合正态模型中, 二者重合; 若均值也设随机先验, 则需明确完整的联合正态结构。原因是正态条件均值恰好线性, 而不是线性代数定理自动保证

所有遗传分布都如此。对于未知的固定均值，BLUP 还承担无偏估计均值的约束，不能等同于把真实均值视为已知时的条件期望。对于混合群体、主效应位点或明显非正态的随机效应，这个区别可以产生可见差异。

令 $m(y) = E(u | y)$ 。对任意预测函数 $f(y)$ ，把误差写成 $u - f(y) = u - m(y) + m(y) - f(y)$ ，对资料条件取期望，交叉项消失，得到

$$E\{[u - f(y)]^2\} = E\{\text{Var}(u | y)\} + E\{[m(y) - f(y)]^2\}.$$

因此非线性预测的潜在收益，正是线性预测没有表示出的条件均值曲率。这个恒等式并没有说更复杂的拟合算法一定更好；真实条件均值未知时，估计曲率需要资料，过度拟合又会增加误差。它说明的是在分布已知的理论实验中，哪一种函数具有最小平方损失。

独立教学例：只有两个可能遗传状态。为把区别算清，设 u 等概率取一与负一，残差 e 独立服从标准正态，观察 $y = u + e$ 。这不是连续多基因育种值的普遍分布，而是一个两状态机制的数学实验。由于 $\text{Var}(u) = \text{Var}(e) = 1$ ，最佳线性预测仍为

$$\hat{u}_L = \frac{1}{2}y, \quad E[(u - \hat{u}_L)^2] = \frac{1}{2}.$$

根据两个正态似然之比，后验优势比为

$$\frac{P(u = 1 | y)}{P(u = -1 | y)} = \exp(2y).$$

于是条件均值与条件方差具有显式表达：

$$m(y) = \frac{e^{2y} - 1}{e^{2y} + 1} = \tanh(y),$$

$$\text{Var}(u | y) = 1 - \tanh^2(y).$$

观察到一时，线性预测为零点五，条件均值约为零点七六一六；观察到三时，线性预测为一点五，已经超过模型允许的两种遗传状态，而条件均值约为零点九九五一。线性预测越过状态边界，并不违反它的最优性定义，它

仍是全部线性函数中平均平方误差最小者。若研究者把这种越界单独裁剪, 又得到另一种非线性规则, 其性质应重新分析。

将条件方差对观测的混合密度积分, 有

$$MMSE = \int \left[1 - \tanh^2(y) \right] \frac{\varphi(y-1) + \varphi(y+1)}{2} dy \approx 0.449600.$$

理论上比线性误差零点五降低约一成。这里所有数值都来自事先规定的分布, 不是训练样本上选择出的最好结果。若真实随机效应其实是正态, 两状态先验可能造成不必要的非线性与失配; 若残差厚尾, 极端记录也不一定代表几乎确定的遗传状态。因此使用复杂先验前, 应辨明它改变了哪些可检验预测, 而不是仅把非线性称为先进。

还应区分后验均值与后验众数。在本例中, 众数只能是一或负一, 接近零的观测也会被硬分类; 条件均值则通过两种状态概率表达不确定性。若最终损失是分类错误, 众数可能合适; 若损失是育种值平方误差, 条件均值更合适。统计输出的形式应服从损失函数, 而不是让所有任务都沿用同一个“最可能个体值”。

21.23 遗漏均值方向的偏差与有界稳健预测

常规 PEV 只衡量指定模型内的随机误差。若真实均值还包含一个遗漏环境方向 $D\gamma$, 一个数值很小的模型 PEV 仍可能伴随系统偏差。为具体说明, 设真实观测为 $y = X\beta + D\gamma + Zu + e$, 目标仍为 $T = k'\beta + l'u$, 并保持随机协方差正确。预测权重满足 $X'a = k$, 但没有对遗漏方向作约束, 则

$$\text{Bias}(a'y - T) = a'D\gamma,$$

$$MSE_{\gamma}(a) = l'\Sigma_u l + a'Va - 2a'c + (a'D\gamma)^2.$$

偏差不会因为多计算几次随机效应逆块而消失。它来自均值空间定义错误, 而不是随机误差估计不够精确。若 γ 完全不受限制, 除非额外要求 $D'a = 0$, 最坏均方误差可以无穷大; 然而同时满足两组约束可能使目标不可估, 或者丢掉大量真实目标信息。这解释了为什么无限制地加入细分场组并不总是有效解决方案。

一种明确而有限的敏感性分析，是规定遗漏效应落在椭球范围 $\gamma'W^{-1}\gamma \leq \rho^2$ ，其中 W 正定，单位与遗漏参数相容。柯西—施瓦茨不等式给出

$$\sup_{\gamma'W^{-1}\gamma \leq \rho^2} (a'D\gamma)^2 = \rho^2 a'DWD'a.$$

于是最坏风险最小化，等价于把权重目标中的观测二次项改为

$$V_\rho = V + \rho^2 DWD',$$

$$\min_{X'a=k} \{l'\Sigma_u l + a'V_\rho a - 2a'c\}.$$

这个形式像增加一个随机环境核，但解释不同：这里的椭球描述允许的固定偏移范围，并没有断言遗漏效应服从某个概率分布。稳健权重的目标是控制该范围内的最坏风险。若把椭球尺度凭结果反复调整到最喜欢的排序，它就失去预先限定风险的意义；范围应来自测量知识、独立环境比较或明确展示的一组情景。

独立教学例：两只动物的差值。设遗传方差与独立残差方差均为一，未知共同均值，目标为 $u_1 - u_2$ 。通常权重为 $(1/2, -1/2)$ ，PEV 为一。假设第一条记录可能另有大小不超过二的环境偏移，第二条没有；则最坏偏差平方为一，最坏总风险为二。允许该情景后，把权重限制为 $(b, -b)$ ，最坏风险为

$$M_{max}(b) = 2 + 4b^2 - 4b + 4b^2.$$

求导得到稳健权重 $b = 1/4$ ，其随机误差为一点二五，最坏偏差平方为零点二五，总计一点五。相对于原权重，它牺牲了模型完全正确时的部分精度，换取对规定偏移的较低最坏风险。若环境实际上没有偏移，原 BLUP 更好；若偏移超出二，既定保证也不再适用。这些条件应与结果同时说明。

该思路适合评估模型选择的后果，却不能替代修复已知错误。若已经确认第一条记录有某个可校正的设备偏移，应直接校正并传播校正误差；若发现遗漏重要场效应，应回到设计和均值模型。稳健情景针对的是尚不确定但有合理边界的失配。它将“结果可能受环境影响”变成可计算、可讨论的风险范围，也让读者看到精度与抗偏差之间究竟交换了多少。

21.24 习题、推导练习与研究设计

习题 1: 精度加权。三条相互独立的记录 10、12、16 测量同一个未知均值, 误差方差为 1、4、4。求广义最小二乘均值及其方差, 并解释为何不是按原始记录数平均。

解答。逆方差权重为 1、1/4、1/4, 总权重为 1.5。估计均值为 $(10 + 3 + 4)/1.5 = 34/3$, 方差为 $1/1.5 = 2/3$ 。普通平均值为 $38/3$, 其方差为 $(1 + 4 + 4)/9 = 1$ 。两者针对同一个均值, 但利用已知精度得到更小方差。这里没有根据记录的大小决定权重, 权重由独立测量误差的方差预先确定; 若方差来自同一小样本估计, 还需考虑权重的不确定性。

习题 2: 相关重复。两条记录误差方差均为 9, 相关系数为 0.8。计算它们平均数的误差方差。若错误地视为独立, 精度会被怎样误判?

解答。平均数方差为 $9(1 + 0.8)/2 = 8.1$, 独立假设下会算成 4.5。相关重复平均以后只比单条记录的方差 9 略小。它们主要共享同一噪声来源, 因此新增记录没有带来第二个完整的独立信息单位。若需要降低方差, 应增加不同时间、不同批次或不同误差来源的独立重复, 而不是复制同一测量过程。

习题 3: 边际无偏。在均值已知为零的单记录模型中, $\sigma_u^2 = 6$ 、 $\sigma_e^2 = 18$, 观察值为 8。求育种值预测、PEV、准确度与可靠度。若真实育种值固定为 8, 预测的条件偏差是多少?

解答。收缩系数为 1/4, 预测为 2, PEV 为 $6 - 36/24 = 4.5$ 。可靠度为 0.25, 准确度为 0.5。固定真实育种值为 8 时, 预测条件均值为 2, 条件偏差为 -6。这个结果与边际无偏并不矛盾, 因为后者还对随机育种值的群体分布取平均。若只选取真实值特别大的动物评价, 就已经改变了边际期望的对象。

习题 4: 证明投影性质。假定 X 满列秩, 证明本章定义的 Q 满足 $QX = 0$, 并说明为何通常不能声称 $Q^2 = Q$ 。

解答。将 Q 右乘 X , 第二项包含 $(X'V^{-1}X)^{-1}(X'V^{-1}X) = I$, 恰好抵消第一项, 所以 $QX = 0$ 。白化后, 普通残差投影矩阵可写为一个对称幂等矩阵, 而 Q 是它经两端 $V^{-1/2}$ 变换回原尺度的结果。因此正确的关系是

$QVQ = Q$ 。除非协方差尺度具备特殊形式，否则再乘一个 Q 不会自动恢复自身。

习题 5：PEV 缩放。某程序把整组混合模型方程乘以残差方差 25 后求解，并报告逆矩阵随机块某个对角元为 0.12。该动物 PEV 是多少？若先验育种值方差为 5，其可靠度是多少？

解答。PEV 为 $25 \times 0.12 = 3$ ，可靠度为 $1 - 3/5 = 0.4$ 。若误把 0.12 当成 PEV，会得到 0.976 的虚高可靠度。正确操作取决于方程究竟采用何种尺度，不能仅根据输出字段名称猜测。可通过一个小型已知答案的问题核实软件文档与实际输出是否一致。

习题 6：比较两个候选。两头动物 PEV 均为 2，预测误差协方差为 1.5。求差值和平均值的 PEV。解释为什么平均误差没有像独立误差那样大幅下降。

解答。差值 PEV 为 $2 + 2 - 2 \times 1.5 = 1$ ；平均值 PEV 为 $(2 + 2 + 2 \times 1.5)/4 = 1.75$ 。共同误差在差值中抵消，在平均值中保留。若只保存两个对角 PEV，会分别误算成 4 和 1。共享环境校正或共享亲属信息会形成这种误差联系，因此群体遗传均值与个体差异的精度必须分别计算。

习题 7：识别与约束。两个场各使用一头不同公羊，所有后代只在本场测定，两头公羊互不相关。把场和公羊都设为固定效应，能否从资料中唯一估计公羊差异？把其中一头公羊效应设为零是否解决科学问题？

解答。不能。场差异与公羊差异完全混杂，改变其中一个并反向改变另一个可以保持相同拟合值。设置一个公羊效应为零只是选择参数表达或施加额外限制，不能创造跨场对比。可通过共享公羊、亲属跨场分布或其他有依据的连接改善设计；若采用随机效应结构获得预测，应说明结果对所加分布假设的依赖。

习题 8：奇异先验。两个动物的随机效应被模型规定完全相等，先验共同方差为 2；两条独立记录的残差方差均为 4，观测为 6 和 2，固定均值已知为零。求共同随机效应的预测和 PEV。

解答。两条记录均值为 4，均值残差方差为 2。共同随机效应预测为

$2/(2+2) \times 4 = 2$, PEV 为 $2 - 2^2/4 = 1$ 。两个动物的差异在模型中恒为零, 不能根据这两条表型差异 6 与 2 就分别预测不同遗传值。若科学上认为它们确有独立遗传差异, 应该修订协方差模型, 而不是对奇异矩阵随意求逆。

习题 9: 未来表型。固定均值已知, 某动物育种值 PEV 为 1.2, 未来一次记录残差方差为 4.8, 且未来残差独立于已有信息。预测未来表型的误差方差是多少? 若另有未被预测的永久环境方差 2, 怎样修改?

解答。前一种情形为 6。若永久环境是未来记录中的额外独立来源, 且没有已有信息可预测, 则再加 2, 得到 8。若永久环境已由重复记录部分预测, 则应加入其剩余 PEV 及与育种值预测误差的协方差, 不能直接加原始方差 2。先把目标记录分解清楚, 再计算其误差二次型, 是通用方法。

习题 10: 设计独立验证。一个研究先用全体资料选择显著标记并校正场效应, 再把个体随机分成训练和验证集, 报告很高预测相关。请指出信息泄漏路径, 并提出与下一出生年度选种相匹配的方案。

解答。验证表型影响了标记筛选, 也影响了场效应校正, 因此它通过两个预处理环节进入训练。应按历史选种日期截断全部信息, 在训练期资料内完成表型依赖的质量筛选、固定效应估计和超参数选择, 再预测下一出生年度当时可获得基因型的候选动物。后续表型仅用于最终评价, 同时报告均值偏差、尺度校准、预测能力和家系构成。若调参后又反复查看同一测试集, 仍会产生适应性选择偏差, 需要保留最终独立测试时期。

习题 11: 参数不确定性。已知参数 BLUP 与经验 BLUP 的 PEV 有何不同? 为什么把方差估计值代入经典 PEV 公式不能自动反映全部不确定性?

解答。经典 PEV 把协方差权重视为固定。经验 BLUP 的权重由数据估计, 会随样本变化, 并可能与记录相关, 因此实际预测误差还包含参数估计引起的波动。可以用包含重新估计步骤的参数自助法或对方差参数积分的概率模型评估, 但都需说明所依赖的生成模型或先验。不能仅把一组参数标准误单独加到 PEV 上, 因为不同参数对预测的影响相互关联。

习题 12: 计算审查。两个程序对同一数据的育种值相关为 0.9999, 能否认定它们实现同一模型? 列出至少三项应继续检查的量, 并说明理由。

解答。不能。相关对整体平移和正比例缩放不敏感，应检查均值差、回归斜率、最大绝对差和关键候选对比；还应核对固定效应约束、遗传基准、方差尺度、动物排序及方程残差。若一个程序使用矩阵近似，另一个使用精确矩阵，即使相关很高也不是严格同一个模型。是否可接受需要根据实际选择阈值和风险判断，而不只依据一个整体相关系数。

动物模型与复杂遗传效应

22

22.1 从个体表型走向遗传信息网络

动物模型最重要的思想，是不再把每头动物当成彼此孤立的观测对象。父母、后代、同胞与远亲之间的遗传联系，被写入一个共同的随机效应协方差系统。某头动物没有自身记录，并不意味着没有关于它的信息；某头动物有很多记录，也不意味着其资料只影响自己。联合模型使每条记录沿着明确的遗传关系传递，同时避免把共享来源的信息反复计算。

最简单的单性状动物模型为 $y = X\beta + Zu + e$ ，其中 u 为全部相关动物的加性育种值向量， $\text{Var}(u) = A\sigma_u^2$ 。 A 是系谱加性关系矩阵， σ_u^2 是指定基础群体的加性遗传方差。关系矩阵无性状单位，乘以遗传方差后才成为育种值协方差。把 A 本身称为“遗传方差矩阵”，会掩盖这个尺度区别。

一条记录在 Z 中对应的是被测动物，而不是默认对应父亲、母亲或家系。后续公畜模型、母体模型和社会效应模型会改变连接方式，因此模型名称不能代替设计矩阵定义。读者在检查任何复杂模型时，都应能够回答：这一条表型连接到哪些动物，它们以什么系数进入记录，它们之间的协方差由什么结构决定？这三个问题比记忆模型缩写更能帮助发现错误。

加性育种值是相对于群体遗传背景和平均配偶条件定义的统计量，不等于动物携带的全部生物学遗传效应。显性、互作、母体环境和社会作用可能影响表型，但它们如何传递给下一代、如何进入选择目标，需要分别说明。动物模型可以扩展以包含这些成分，但不能因为某个随机效应与动物编号相连，就把它自动解释为可传递的加性遗传价值。

在纯加性模型中，亲缘关系体现的是给定系谱下的期望遗传共享。同父

同母的两个后代具有相同的期望关系，却可能通过孟德尔分离获得不同实际染色体片段。系谱动物模型利用这种期望协方差进行预测；基因组模型进一步利用实现的基因型相似性。二者各自的基础和尺度必须保持清楚，否则很容易把期望近交、标记纯合和预测协方差混成一个概念。

建立动物模型也要求认真定义基础群体。传统关系递归通常把未知祖先视为无亲缘、无近交且来自共同基群。对于长期选择、多个引种来源或多品种资料，这个假设可能过于简单。此时需要遗传组、来源结构或更一般的基础关系模型。把所有缺失父母都写成同一个“未知”编号，更是错误的身份处理：未知不是一头共同的真实动物，除非模型明确把它定义为某种群体效应。

本章将从亲本平均和孟德尔抽样开始，逐步加入母体、永久环境、社会与杂交效应。每次扩展都遵循同一原则：先写记录形成机制，再写随机效应协方差，最后讨论哪些数据能够分离这些来源。复杂性应服务于科学问题，而不是把尽可能多的随机效应放进软件后等待算法自动解释。

22.2 亲本平均、孟德尔抽样与关系递归

若动物 i 的父亲和母亲分别为 s 与 d ，加性遗传效应可写为

$$u_i = \frac{1}{2}u_s + \frac{1}{2}u_d + \delta_i.$$

δ_i 是孟德尔抽样偏差。它表示在给定双亲遗传贡献后，后代因随机分离而获得的额外偏离。在线性加性系谱模型中， δ_i 与祖先育种值不相关，不同个体的抽样偏差在相应假设下也不相关。这种递归把整个亲缘网络分解为祖先基础变异与逐代新增的分离变异。

与任何较早动物 j 的协方差由线性展开得到 $A_{ij} = (A_{sj} + A_{dj})/2$ 。对角元满足 $A_{ii} = 1 + F_i$ ，而后代近交系数为 $F_i = A_{sd}/2$ 。因此，双亲之间的关系影响后代的对角元，双亲自身的近交则影响孟德尔抽样方差。它们是两个不同位置的量，不能只用一个“家系近交水平”代替。

当双亲都已知时, 抽样方差为

$$\text{Var}(\delta_i) = \left(\frac{1}{2} - \frac{1}{4}F_s - \frac{1}{4}F_d \right) \sigma_u^2.$$

可以直接检验这个式子。双亲平均的方差为 $\{A_{ss} + A_{dd} + 2A_{sd}\}\sigma_u^2/4$, 再加上抽样方差, 恰得到 $(1 + A_{sd}/2)\sigma_u^2$ 。这与后代对角关系一致。若双亲无近交, 抽样方差为一半基础遗传方差; 即使双亲育种值完全已知, 后代仍存在这部分遗传不确定性。

只知道一个亲本时, 未知亲本的遗传贡献被并入剩余项。在未知亲本与已知亲本及祖先无关、基础方差相同的假设下, 剩余方差为 $(3/4 - F_s/4)\sigma_u^2$ 。双亲均未知的基础动物则具有规定的基础方差。若未知亲本实际上来自不同来源或与群体有关, 这些简单公式需要修改, 不能把缺失信息等同于真实无关系。

将全部递归写成 $Tu = \delta$, 其中 T 为下三角、对角为 1 的传递矩阵, $\text{Var}(\delta) = D\sigma_u^2$, 于是 $A = T^{-1}D(T^{-1})'$, 进而 $A^{-1} = T'D^{-1}T$ 。这个分解说明为什么关系逆矩阵可以由每头动物的局部亲本信息累加得到, 而不必先形成稠密关系矩阵。计算优势来自遗传递归结构, 不是一般稠密矩阵求逆的特殊捷径。

对双亲已知、均无近交的动物, $D_{ii} = 1/2$ 。把该动物对应的向量中自身系数 1、双亲系数各 $-1/2$ 作外积, 再乘 2, 就得到它对 A^{-1} 的局部贡献。若只有一个无近交亲本, 系数权重变为 $4/3$ 。这些规则适合手算和理解, 但实际程序必须正确处理近交、排序和未知亲本结构。祖先应先于后代, 或者通过明确的拓扑排序整理。

这套递归还提供了一种模拟思路: 先生成基础动物育种值, 再按双亲平均加独立孟德尔抽样逐代生成后代。模拟得到的经验协方差应接近 $A\sigma_u^2$ 。然而, 小规模模拟的随机误差不能作为解析关系正确性的唯一证明; 最好同时用确定性的矩阵分解检验。模拟适合展示分离与选择过程, 解析恒等式适合核查计算定义。

22.3 无记录动物、信息回传与吸收

教学例 22.1：一条后代记录能告诉双亲什么。三头动物中，1 和 2 是无亲缘且无近交的双亲，3 是它们的后代，关系矩阵为

$$A = \begin{bmatrix} 1 & 0 & 0.5 \\ 0 & 1 & 0.5 \\ 0.5 & 0.5 & 1 \end{bmatrix}.$$

设总体均值已知，只有动物 3 有一条校正后的记录 6，遗传方差为 4，残差方差为 12。记录方差为 16，三头动物与该记录的协方差依次为 2、2、4。因此预测值依次为 0.75、0.75、1.5，PEV 依次为 3.75、9.75、3。双亲没有自身记录，却通过后代获得了信息；其精度低于后代自身，是因为只有一半的期望遗传联系。

这个例子也提醒读者，信息可以沿系谱双向使用。遗传传递的生物学方向是祖先到后代，但统计推断可以用后代资料更新祖先，也可以通过共同祖先在同胞之间共享信息。统计回传不表示遗传物质逆向传递，只表示观察到相关随机变量以后，对未观察变量的认识发生改变。区分生物因果方向与统计条件推断方向，是理解复杂关系模型的重要基础。

假设两头双亲育种值原来完全未知，后代表现高，并不能确定优势主要来自父亲还是母亲。对称关系使二者获得相同更新。若父亲已有大量后代记录，母亲资料很少，同一条新记录的更新分配会不同：它可能主要改变对母亲或后代孟德尔抽样的认识。联合模型自动依据剩余不确定性分配信息，而不是把每条后代偏差固定地一半加给父亲、一半加给母亲。

模型通常需要包括连接目标动物所需的无记录祖先。有些祖先虽然不在最终报告名单中，却把多个后代家系连接起来。删除它们后若直接把相关后代当作新的无关基础动物，就会破坏协方差。可以通过严格的方程吸收减少计算维度，但必须把被消去效应产生的影响保留在剩余系数矩阵中。“不输出某个动物的育种值”与“不需要其遗传联系”不是同一件事。

分块吸收的数学形式很简单。若方程按保留效应与待消去效应分成两

块，消去第二块后，第一块系数变为原第一块减去交叉块、第二块逆和转置交叉块的乘积。这就是 Schur 补。它保留了第二块对第一块的统计约束。反之，直接删去第二块的行列，只是把它们的作用丢弃，通常不等价。实际大规模软件中的减少动物模型，也必须遵循这种信息保持原则。

没有记录又没有连接到任何有记录动物的个体，在零均值模型中通常只能得到基准预测，PEV 保持先验水平。为它增加一个编号和方程不会创造信息。类似地，一个家系如果完全与其他家系隔离，家系内部比较可能有一定信息，但其相对于共同遗传基准的位置可能很不确定。报告精度时应区分组内排序与组间比较。

对年轻候选动物而言，亲本平均通常是早期预测的重要部分，却无法区分没有自身或基因组信息的同胞。增加一条可靠的自身记录、后代记录或能识别孟德尔抽样的基因组信息，才可能产生同胞间排序。选择计划中的测定资源应据此分配：若大量同胞拥有相同亲本平均，继续增加远亲重复资料可能不如获得个体特异信息有价值。

22.4 公畜模型与动物模型之间的尺度桥梁

公畜模型用父亲的传递效应解释后代记录，是动物模型的一种有条件简化。假定配偶来自同一随机群体，父母不相关，没有母体和共同环境混杂，后代遗传值可分为父亲贡献、母亲贡献和孟德尔抽样。父亲传递效应定义为 $s_i = u_i/2$ ，所以公畜效应方差为 $\sigma_s^2 = \sigma_u^2/4$ 。

未被父亲效应解释的剩余，不只是环境残差。它还包括母亲遗传贡献和后代孟德尔抽样，在上述简单条件下合计为 $3\sigma_u^2/4$ 。因此公畜模型剩余方差为 $\sigma_w^2 = 3\sigma_u^2/4 + \sigma_e^2$ ，而其收缩方差比为

$$\lambda_s = \frac{\sigma_w^2}{\sigma_s^2} = \frac{4 - h^2}{h^2}.$$

这里的 h^2 是对应动物模型的遗传力。这个公式只在所述假设下成立，不能用于存在显著母体、共同窝或相关配种影响的任意资料。

教学例 22.2：为什么不能把动物残差直接搬进公畜方程。取加性遗传方差 9，环境残差方差 16，总表型方差 25，遗传力 0.36。公畜方差为 2.25，公

畜模型剩余方差为 22.75，方差比为 10.1111。若错误地用 16 除以 2.25，会低估剩余噪声、减弱应有的收缩。两个模型都在分析同一性状，但随机效应吸收的遗传部分不同，所以剩余方差定义不同。

若公畜预测以传递能力表示，转换为育种值要乘 2，相应 PEV 要乘 4，准确度在共同尺度变换下不变。把一个系统的育种值与另一个系统的传递能力直接比较，会产生两倍差异的假象。后代差异还可能相对于特定配偶群或环境定义，因此发布术语必须与模型一致。名称相似并不保证统计尺度相同。

在有父系半同胞设计且母亲随机分配的经典情形中，组间相似性可以帮助估计父亲方差。但是，若同一父亲后代集中在同一场或栏舍，父亲效应就可能与共同环境混杂。若优秀父亲优先配优秀母亲，父亲效应还会吸收配偶选择差异。动物模型利用母亲系谱和记录能够处理更多信息，但仍依赖正确的均值、协方差和资料保留，不能自动消除所有非随机配种问题。

公畜模型的优点是维度较小、解释直观，特别适合展示后代测定的基本原理。在资料只保留父亲身份、母亲信息极少的历史系统中，它也可能是可行选择。然而，当雌性记录、复杂亲缘和基因组资料充分时，动物模型通常能更完整地利用信息。选择模型不应仅看计算快慢，还应看简化是否丢失目标决策所需要的联系。

对同一数据比较两种模型时，应先统一目标。例如，一种模型报告父亲传递能力，另一种报告动物育种值，需要先换到相同尺度；同时核对剩余方差、母亲贡献和固定效应处理。若动物模型加入了更多信息，其结果不同可能有统计理由；若声称完全等价，则必须列出等价所需的设计和参数条件，并在小例子中验证。

公畜模型还说明了一条通用原则：把某一随机来源移出模型以后，它往往并没有从现实中消失，而是进入剩余项及其相关结构。简化模型时，不能只删除一个效应而保持其余协方差原封不动。下一节母体与共同环境模型的比较同样需要遵循这一原则。

22.5 母体遗传效应与直接遗传效应

羔羊断奶重不仅取决于自身生长基因，也取决于母亲提供的泌乳、子宫和育幼条件。对羔羊而言，这些条件是外部环境；对母羊群体而言，形成这些条件的能力又可能有遗传基础。这就是母体遗传效应的核心：一个个体的基因通过影响另一个个体的表型发挥作用。它不同于把母羊自身表型作为协变量，也不同于所有母羊共享的固定效应。

设直接加性效应为 u ，母体加性效应为 m ，母体永久环境为 c ，模型为

$$y = X\beta + Z_d u + Z_m m + Wc + e.$$

Z_d 把记录连接到被测后代， Z_m 把记录连接到其母亲；母亲即使没有自己的直接性状记录，也可能作为母体效应进入方程。若直接与母体效应按同一动物顺序排列，其联合协方差可写为一个两性状块矩阵，每块都是系谱关系 A 乘以相应方差或协方差。

$$\text{Var} \begin{bmatrix} u \\ m \end{bmatrix} = \begin{bmatrix} A\sigma_u^2 & A\sigma_{um} \\ A\sigma_{um} & A\sigma_m^2 \end{bmatrix}.$$

同一个体的直接与母体遗传效应协方差为 σ_{um} 。它可以为正、零或负，但必须满足 $\sigma_{um}^2 \leq \sigma_u^2 \sigma_m^2$ 。两项方差均正且不等式严格成立时，性状协方差块正定。某个估计相关靠近 -1 可能反映拮抗，也可能反映弱识别、遗漏环境或边界问题，不能仅凭符号就提出确定的生物学机制。

Willham (1972) 的经典母体效应工作强调，应从相关个体对性状的共同贡献出发推导亲属协方差。本书沿用这一建模原则，但将直接效应记作统一符号 u ，避免与全书其他遗传目标符号混淆。母体效应可以扩展到外祖母或更早的跨代来源，但每增加一层，都需要新的关系结构和能够区分效应的数据。层次更多并不必然使解释更真实。

一个容易混淆的概念是母体遗传与母体遗传物质传递。母体效应不一定来自线粒体或母系遗传位点；常染色体基因影响母羊泌乳，也可以形成母体遗传效应。反过来，母系遗传标记与后代表型相关，也不自动证明其作用路

径是育幼环境。模型中的效应定义依据作用对象和记录形成机制，而不是仅依据遗传物质来源。

母体效应的预测目标还受性别和生产角色影响。公羊不会泌乳，但可携带影响女儿母体能力的基因，因此其母体育种值仍有选择意义。终端父系主要通过商品后代直接生长产生收益，母系品种则可能更重视后备母羊未来育幼能力。不能因为某个性状只在雌性表达，就认为雄性没有相应遗传价值；也不能把不同繁育角色的经济权重简单设为相同。

母体模型需要准确记录母亲身份、胎次、窝大小、寄养和测定时间。若实际哺育母亲与生物学母亲不同，子宫环境与出生后哺育环境可能需要分别连接。将寄养后代仍只连接到生物学母亲，会把不同作用路径混在一起。数据记录越能贴近真实生物过程，统计模型越有机会作出可解释分解。

22.6 母体模型的协方差展开与手算

对后代 i 和 j ，母亲分别为 d_i 与 d_j ，遗传部分的协方差可按四个交叉项展开。直接—直接贡献为 $A_{ij}\sigma_u^2$ ，母体—母体贡献为 $A_{d_id_j}\sigma_m^2$ ，两种直接—母体交叉贡献合计为 $(A_{id_j} + A_{jd_i})\sigma_{um}$ 。若共享母亲，还可能有共同母体永久环境；若同窝，还可能有额外窝环境。每一项都对应明确的共享来源。

这种逐项展开比直接记忆某种亲属协方差公式更可靠。父系半同胞、母系半同胞和全同胞的遗传与环境共享不同，不能只用一个亲缘系数概括全部相似性。特别是母系半同胞，共享同一母亲的母体遗传效应和永久环境，即使父亲完全无关，表型相似也可能很强。把全部相似性乘以 4 解释为直接遗传方差，会产生明显偏差。

教学例 22.3：交叉协方差如何进入单条记录。取直接遗传方差 9、母体遗传方差 4、直接—母体协方差 -3、母体永久环境方差 2、独立残差方差 16。若后代与母亲均无近交且亲子关系为 0.5，单条记录的方差为 $9 + 4 + 2 + 16 + 2 \times 0.5 \times (-3) = 28$ 。交叉项的总贡献是 -3，而不是 -6，因为直接效应属于后代，母体效应属于母亲，二者之间还要乘亲缘系数。

在这个模型下，直接遗传方差占比为 $9/28 = 0.3214$ ，母体遗传方差占比

为 $4/28 = 0.1429$ 。这些比值描述相应方差来源相对于记录方差的大小，但不能不加条件地将它们相加作为某种通用“总遗传力”。选择响应涉及效应如何进入后代、何时表达以及选择目标权重，可能需要不同的组合。不同文献中的总遗传力定义也应先核对，不能只比较名称。

再看两只共享母亲、父亲彼此无关且与母亲无关的母系半同胞。直接遗传关系为 0.25，母体遗传效应完全共享，两项直接—母体关系之和为 1。因此其协方差为 $0.25 \times 9 + 4 - 3 + 2 = 5.25$ 。若两只还共享同一窝，而模型有窝方差，则需继续加上该项；若来自不同窝，则不加。这个区分能够帮助设计跨窝资料来识别母体永久环境与窝环境。

对于全同胞，直接关系在简单无近交情形下为 0.5，其他共享母体项类似，因此协方差为 $0.5 \times 9 + 4 - 3 + 2 = 7.5$ ，仍未加入可能的共同窝效应。对于父系半同胞，如果母亲无关、且相关交叉关系为零，则主要遗传协方差为 $0.25 \times 9 = 2.25$ 。不同亲属类型提供不同协方差方向，联合分析它们比只收集一种家系结构更有助于分离来源。

负的直接—母体协方差会降低某些记录方差和亲属协方差，但不能使合法模型的总体协方差变成负定。单个协方差可以为负，整体矩阵仍须半正定。如果参数组合违反这一要求，问题是模型参数不合法，而不是发现了某种特殊生物学规律。正定参数化可以防止计算越界，但无法保证数据足以精确估计相关。

手算例子还有一个重要用途：核验复杂设计矩阵。可以先按亲属关系逐项计算两条记录协方差，再与 $Z\Sigma Z' + R$ 的相应元素比较。若不同，常见原因是把母体效应连到了后代自己、母亲排序不一致、遗漏交叉协方差或把同窝与同母混为一类。这种局部检查比查看整个大矩阵是否对称更有针对性。

22.7 母体永久环境、共同窝与识别设计

母亲相同不等于遗传原因相同。一只母畜持续具有较好的泌乳条件，可能源于自身基因，也可能源于幼年营养形成的长期体况；同一窝后代同时遇到感染，则属于更局部的共同环境。母体遗传效应通过亲缘矩阵在不同母亲

之间建立协方差，母体永久环境仅在同一母亲的记录之间建立协方差，共同窝效应仅连接同一窝的记录。三者的概念可以分别定义，资料却未必能够将三者分别识别。判断可识别性时，应观察这些协方差模式在现有记录中是否真的不同。

令母体永久环境设计为 W ，窝设计为 L ，则额外协方差可写为 $WW'\sigma_c^2 + LL'\sigma_l^2$ 。如果每只母亲只有一窝后代，且所有记录来自该窝，母亲分类与窝分类完全一致，便有 $WW' = LL'$ 。无论样本有一千条还是一百万条，似然都只能辨认 $\sigma_c^2 + \sigma_l^2$ ，无法仅凭这些资料决定其中的比例。扩大同样结构的样本可以提高总和估计的精度，却不会创造缺失的设计方向。这是结构性不可识别，不是计算速度不够。

若每只母亲有多窝记录，同母异窝后代共享永久环境而不共享窝环境，这一比较有助于分离两者。如果再有多只互有亲缘的母亲分布在不同管理单元，遗传母体协方差便能够跨母亲出现。父系连接同样重要：不同母亲所生后代共享父亲，可以帮助估计直接遗传差异；母亲自己及其亲属的直接性状记录，则有助于估计直接—母体相关。各类记录并非机械地越多越好，关键是它们是否新增了区分参数的协方差模式。

交叉哺育实验提供另一种信息。后代的生物学母亲决定遗传来源，哺育母亲决定某些出生后的母体环境；二者分离后，设计矩阵也必须分离。产前子宫环境、初乳、持续哺育、社会照护不能统一改挂到养母名下。研究者应根据交换发生的时间定义效应。如果只在出生数日后交换，已有的产前和早期母体影响仍属于生母路径。精确记录处理时点比为模型增加一个“交叉哺育”标签更有价值。

选择性淘汰还会改变能够观察的母亲群体。只有首窝表现较好的母畜才留到第二窝时，跨窝记录并非来自随机母亲样本。如果首窝信息完整保留，并且留种机制可由模型已包含信息解释，联合分析通常比只分析存留母畜更合理；若淘汰还依赖未记录疾病或照护水平，就需要承认相应缺失机制的不确定性。母体模型不能自动把所有留种偏差都消除。

教学例 22.4：重复结构胜过记录数量。设计甲有 100 只母亲，每只一窝，每窝 10 条记录，共 1000 条。设计乙有 100 只母亲，每只两窝，每窝 5 条，同

为 1000 条。若其他条件相同，甲不能凭母亲与窝的分类分离永久环境和窝方差；乙存在同母异窝配对，至少获得了这一分离所需的结构信息。乙也并不因此保证精确估计，仍要考虑窝内残差、遗传关系、批次混杂和第二窝缺失。但在设计阶段，这个结构差异比简单比较总记录数更有决策意义。

在正式分析前，可以制作四类配对的数量表：同窝、同母异窝、相关母亲不同窝、无关母亲不同窝。再把父系关系和批次交叉进去，检查关键类别是否几乎为空。这张表不能代替完整似然分析，却能及时发现模型设计缺少支撑。若某些来源确实无法分开，合并效应并解释其混合含义，常比保留多个边界参数而宣称揭示了复杂生物学更可靠。




图 22.1 母亲与窝分类的协方差模式。上排两只母亲各一窝、每窝两条记录，两个环境核相同；下排各两窝、每窝两条，出现同母异窝对比。深色为共享该来源，浅色为不共享。图示是设计结构教学例，不是实际资料

22.8 母体性状中的选择目标与代际表达

预测模型告诉我们记录如何产生，育种目标告诉我们应该希望后代怎样改变。二者不能混为一谈。对于直接和母体效应同时重要的性状，候选者具有

直接育种值 u_i 和母体育种值 m_i 。雄性虽然不亲自哺育，也可以向女儿传递影响母体能力的等位基因；雌性的母体效应则可能在下一次繁殖立即表现。性别影响表达和时间，并不意味着相应遗传值在另一性别不存在。

一个明确的线性目标可以写为 $H_i = a_d u_i + a_m m_i$ ，其中两个权重应反映后代类别、表达次数、经济后果与时间折现。如果目标只关心下一批市场后代自身生长，直接效应权重可能较大；如果候选者将产生大量替代母畜，母体能力就会在后续繁殖周期反复表达。不能因为母体方差估计较大，就直接把它赋予较大经济权重；方差描述群体可供选择的变异，经济权重描述单位变化的价值。

在无近交、以本章协方差参数定义效应时，候选者目标方差为

$$\text{Var}(H_i) = a_d^2 \sigma_u^2 + 2a_d a_m \sigma_{um} + a_m^2 \sigma_m^2.$$

若有联合预测误差矩阵 C_i ，目标的预测误差方差则为 $a' C_i a$ ，这里 $a = (a_d, a_m)'$ 。两种计算都需要交叉项。分别报告直接和母体可靠度还不足以确定目标可靠度，因为同样的边际误差可以具有不同的误差相关。目标排序也可能对经济权重和负遗传相关敏感，因而应同时呈现候选者的分量预测与综合目标。

教学例 22.5：相同总分背后的不同路线。仍取直接方差 9、母体方差 4、协方差 -3，令权重均为 1，则目标方差为 7。若候选甲预测为 (3, -1)，候选乙为 (1, 1)，两者目标都为 2。甲适合通过直接表现获得收益，乙的收益分布更均衡；若未来母体表达权重提高到 2，甲目标变为 1，乙变为 3。排序改变源于目标改变，不能称为前一次预测“失效”。

设两分量预测误差方差分别为 2 和 1，预测误差协方差为 -0.5，则等权目标误差方差为 2，可靠度为 $1 - 2/7 = 0.7143$ 。若忽略误差协方差，会误算为 3 并得到 0.5714。负的生物学遗传协方差与负的预测误差协方差来自不同矩阵，数值也不必相同。将二者都笼统称为“相关影响”容易掩盖计算错误。

当目标涉及真实后代平均表现时，还须明确配偶群体。固定且随机抽样的配偶群体使候选者对下一代的平均加性贡献约为自身育种值的一半；非随机配种、近交控制或特定杂交体系会改变具体期望。直接与母体效应的表达

还分布在不同代际。因此, 对一个候选公畜简单计算 $u_i + m_i$ 可以作为事先定义的遗传目标, 却不能未经推导就称为所有生产制度下的下一代收益。

育种计划设计可以把这些表达路径写为逐年预期数量, 再乘单位价值与折现因子, 得到权重。这样做也允许敏感性分析: 当替代母畜比例下降、繁殖寿命缩短或断奶前饲养方式改变时, 目标应怎样变化。模型预测的不确定性与制度未来变化的不确定性应分别讨论, 前者由统计资料改善, 后者需要生产情景和经济判断。

22.9 显性与上位效应: 从基因作用到群体方差

基因座的显性作用与统计模型中的显性方差不是同一层次的概念。前者描述杂合子基因型值是否等于两个纯合子的平均, 后者描述在指定群体基因频率和交配结构下, 扣除平均加性效应后还剩多少可归于显性的变异。相同的基因型值在不同群体中可以产生不同的加性方差和显性方差。因此, 估计结果总应带有参考群体含义, 而不能把一个方差比例当作物种永久不变的常数。

在单个双等位基因座, 以两个纯合子值为 a 与 $-a$ 、杂合子值为 d , 等位基因频率为 p 和 $q = 1 - p$, 随机结合及相应正交分解条件下, 平均等位基因替代效应为 $\alpha = a + d(q - p)$ 。加性方差为 $2pq\alpha^2$, 显性方差为 $(2pqd)^2$ 。这些式子说明, 即使生物学显性参数 d 不变, 频率变化仍会改变统计上的加性与显性贡献。选择不断改变频率时, 方差参数也可能随世代变化。

教学例 22.6: 同一作用模式, 不同方差构成。取 $a = 1, d = 1$ 。当 $p = q = 0.5$ 时, 替代效应为 1, 加性方差 0.5, 显性方差 0.25。若 $p = 0.8, q = 0.2$, 替代效应降为 0.4, 加性方差为 0.0512, 显性方差为 0.1024。后一群体显性方差相对于加性方差更大, 并不是显性机制变强, 而是群体频率改变了统计分解。这也提醒我们, 跨群体比较遗传力必须同时考虑频率、环境方差和资料定义。

在数量遗传混合模型中可加入显性效应 d_g , 写为 $y = X\beta + Zu + Z_d d_g + e$, 并规定 $\text{Var}(d_g) = D\sigma_d^2$ 。这里 D 是显性关系矩阵, 与前文孟德尔抽样方差对角矩阵若同章出现应加文字区分或改写为 D_{dom} 。显性关系的定义依赖谱

系或基因组编码及基准群体；不能直接把加性关系矩阵平方逐元素操作后，不经说明就宣称得到通用显性关系。

经典无近交关系下，全同胞可以共享一部分显性偏差，而父系半同胞的显性共享通常为零。可是在实际资料中，全同胞还常共享窝环境、早期饲养和母亲。若这些环境项缺失，所谓显性方差可能吸收共同环境。基因组数据增加了同一家系成员之间实际共享的差异，有助于分离某些来源，但并不会消除批次和家系完全混杂所造成的困难。

上位效应进一步涉及不同基因座作用之间的偏离。统计模型可以定义加性 $\times$ 加性等分量，但其正交性通常依赖随机结合、连锁平衡及明确的中心化方式。许多育种资料不严格满足这些条件。把多个关系核一起放入模型后得到正方差，不等于证明了对应的分子机制；相似的核可能在有限样本中相互替代，预测性能改善也不必能唯一归因于某一种生物学相互作用。

对繁殖决策而言，非加性效应有两个不同用途。一是预测某个个体自身的生产表现，二是预测特定配对后代的平均价值。前者可以利用个体显性预测，后者必须考虑父母基因型组合与后代分离。高显性表现并不以同样方式稳定传给下一代。选择育种值、选择商品个体与设计配种组合，应当使用分别定义的目标，不能用一个“总遗传值”包办所有决策。

22.10 社会遗传效应：一个动物也改变别人的表型

群养条件下，个体的采食、攻击、疾病传播或合作行为可能影响同伴表现。仅用自己的基因解释自己的记录，会遗漏这一遗传路径。社会遗传效应又称间接遗传效应，指个体基因通过改变其社会环境而影响其他个体表型的可遗传部分。这个定义不要求个体具有某种主观意图，也不能把所有群体差异都归为社会遗传效应；管理者分群、栏舍条件和同伴数量同样会产生非遗传影响。

在大小为 n 的群体中，一个基本模型为

$$y_i = x_i' \beta + u_{Di} + \sum_{j \neq i} u_{Sj} + c_g + e_i.$$

其中 u_{Di} 是个体的直接育种值, u_{Sj} 是同伴对每一个接触个体的社会育种值, c_g 是群体共同环境。遗传分量联合协方差可以设为 $\Sigma_{DS} \otimes A$, 其中二阶矩阵包括直接方差、社会方差与直接—社会协方差。将所有记录堆叠后, 直接设计和社会设计分别指出“谁拥有该条记录”与“谁影响该条记录”。这两张映射表不同, 是整个模型最基本的结构。

Bijma、Muir 与 Van Arendonk (2007) 将此类效应纳入遗传与选择响应的统一讨论。其关键启示是, 遗传贡献的表达范围超过个体自身。以下推导采用固定群体大小、每一社会效应对各同伴以同一单位表达的教学设定。对于接触强度不等、网络不断变化或疾病具有非线性传播的情形, 需要另行定义作用权重, 不能把本节公式直接作为通用传播模型。

若每只动物影响其余 $n - 1$ 只同伴, 那么它对本群总表型的遗传贡献为

$$T_i = u_{Di} + (n - 1)u_{Si}.$$

因此总育种值方差为

$$\sigma_T^2 = \sigma_D^2 + 2(n - 1)\sigma_{DS} + (n - 1)^2\sigma_S^2.$$

它是按上述表达定义的遗传贡献方差, 不是单个记录的直接遗传方差。社会方差在该式中乘以群体规模的平方项, 说明小的社会效应方差也可能对群体遗传改良有明显意义。但规模项只有在“每个同伴的效应保持相同”这一生物学假设下成立; 资源总量固定造成的稀释可能使效应随群体大小降低。

如果群内个体彼此无关, 单条记录的遗传方差为 $\sigma_D^2 + (n - 1)\sigma_S^2$, 因为自己的直接效应与其他无关个体社会效应没有协方差。它与 σ_T^2 的结构不同: 一个是某条记录接收的遗传影响, 另一个是某个个体向整个群体输出的遗传影响。分清“接收端”和“贡献端”, 就能理解为何以自身表型选择有时未必改善群体总产出。

社会效应也可能表现为疾病易感性与传染性。感染记录既受自己的易感基因影响, 也受同伴感染状态和传染性影响。由于感染状态随时间反馈变化, 线性社会模型只是某些情形下的近似。记录接触网络、发病时间和治疗过程

能使模型更接近机制；仅用期末存活与否难以分离所有路径。育种学上的直接与间接效应应与流行过程共同定义。

22.11 社会模型的协方差、选择方向与手算例

两只无关但同群的动物也可能因社会遗传路径而具有相关表型。以固定群体大小且独立残差为例，个体 i 与 k 的记录各自包含对方的社会效应。 u_{Di} 与记录 k 中的 u_{Si} 产生一个 σ_{DS} ，另一个方向再产生一个。其余 $n-2$ 个共同同伴的社会效应同时进入两条记录，贡献 $(n-2)\sigma_S^2$ 。加上群体共同环境，得到

$$\text{Cov}(y_i, y_k) = 2\sigma_{DS} + (n-2)\sigma_S^2 + \sigma_c^2.$$

这个式子建立在群内无亲缘的简化条件上。有亲缘时，自己的直接效应与同伴社会效应之间还出现更多遗传协方差，必须依据 A 和两个设计矩阵完整计算。不能只把亲缘系数乘在上式整体外面，因为不同路径涉及不同个体配对。手算无亲缘特例可以验证程序，却不能替代一般模型。

教学例 22.7：直接表现优良可能伴随群体损失。取群体大小 4、直接遗传方差 4、社会遗传方差 1、直接—社会协方差 -1 。二阶遗传矩阵的行列式为 3，为合法正定矩阵。总育种值方差为 $4 - 6 + 9 = 7$ ；单条记录遗传方差为 $4 + 3 = 7$ ，两者本例恰好相等，但来源不同。两个同伴的社会遗传协方差为 $-2 + 2 = 0$ ；若有群环境方差，则它们仍会相关。

设候选甲的直接预测为 2、社会预测为 -1 ，候选乙为 1 和 0.5。只看直接值，甲高于乙；按四只一群的总贡献，甲为 $2 + 3(-1) = -1$ ，乙为 $1 + 3(0.5) = 2.5$ 。这里负社会值可以代表挤占同伴资源造成的损失。不能由此笼统断言直接选择总会失败，而应指出：当目标是群体总产出且社会遗传作用存在时，排序应依据与目标一致的贡献。

进一步令残差方差 9 且无群环境，单条记录方差为 16。候选者总育种值与自身记录的协方差是 $\sigma_D^2 + (n-1)\sigma_{DS} = 1$ ，所以仅凭自身记录预测总育种值的线性系数为 $1/16$ 。其可靠度为 $1/(7 \times 16) = 0.00893$ 。单条记录对直接育种值可能仍有一定信息，却几乎没有揭示目标总贡献。这是记录与目标

关系决定选择效率的具体例子。

如果把同一群的总记录作为信息，目标与记录之间的协方差结构会改变。群选择可以捕捉群体总贡献，但同时会受群环境、组间数量、亲缘和分群规则影响。随机分群、亲缘组群和家系混合组群分别形成不同的信息结构；不存在不依赖条件的最优方式。设计应同时考虑估计社会方差和长期控制近交，而不是只最大化一次试验中的显著性。

社会总育种值的预测误差同样由分量组合。设直接和社会预测误差矩阵为 C_i ，则 $PEV(T_i) = w'C_iw$ ，其中 $w = (1, n-1)'$ 。当群体大小变化时，即使分量预测不变，总值与其误差也同时变化。报告社会模型结果时，应给出采用的参考群体大小及作用单位；若只报告一个没有群体定义的总值，生产者难以判断能否用于自己的饲养制度。

22.12 群体规模、稀释假设与社会资料的实验设计

社会影响是否随群体扩大而累加，是需要数据和生物学知识回答的问题。若每只动物持续以同样强度影响所有同伴，前节的求和模型适用；若一个动物总共只能占用有限的饲槽时间，其对单个同伴的平均影响可能随同伴数降低。可以将作用权重写为 w_{ij} ，模型社会项改为 $\sum_{j \neq i} w_{ij}u_{Sj}$ 。此时总贡献取决于该动物对所有接受者的权重之和，而不必等于 $n-1$ 。

例如采用完全稀释权重 $w_{ij} = 1/(n-1)$ ，个体向群体输出的社会权重总和为 1，目标成为 $T_i = u_{Di} + u_{Si}$ 。部分稀释可以设权重为 $(n-1)^{-d}$ ，但参数 d 只有在群体大小有足够变化、且规模不与管理完全混杂时才可能估计。给每一种群体大小都添加独立参数，会迅速消耗资料中的信息。选择参数化应遵循作用机制与数据支持的平衡。

教学例 22.8：同一预测在两种尺度下的含义。设直接值 2、社会值 -0.5。无稀释且群体大小 5 时，总贡献为 0；大小 10 时为 -2.5。若社会值是按完全稀释单位定义，总贡献在两种群体大小下都为 1.5。两种结果没有数学矛盾，因为社会值单位不同。如果估计时使用总和，应用时却按平均值解释，会人为制造巨大的群体规模效应。

社会设计矩阵需要完整记录同栏历史。动物在试验中途转栏，意味着它在不同时间与不同同伴相遇。简单使用最终栏位可能把早期作用错误归给后来同伴。可按观察区间建立记录，把共同接触天数或预先定义的暴露权重写入设计。若转栏由疾病、攻击行为或生长缓慢触发，这一过程本身也可能与遗传效应相关；模型应至少保留触发前的信息，并明确分群机制的限制。

识别直接与社会效应的一项困难，是某些规则群组中两个设计高度相关。例如一个家系的成员总被放在同一栏，其直接遗传差异、社会遗传差异和共同环境都按相似方式出现。随机交换部分家系成员、让同一家系分散到多个栏，以及让不同家系在多种组合中相遇，有助于产生区分来源的对照。但这些设计也要考虑动物福利、病原传播及可实施性；统计效率只是实验设计的一个目标。

群环境的定义也须精细。栏舍固定位置、一次试验的共同饲料、稳定同伴关系，以及短期温度波动未必属于同一个时间尺度。若仅加一个栏随机截距，可能吸收部分社会信号，也可能遗漏随时间变化的共同冲击。纵向数据允许比较换栏前后和同伴更替后的变化，但必须注意这些事件通常不是随机发生。因果解释应比方差分解更审慎。

在应用报告中，建议同时回答三个问题：模型中的社会效应以什么为单位；它对应哪一种群体规模与接触结构；目标中的社会贡献通过多少接受者表达。只有这三项一致，估计、预测和选择响应才能连成同一条逻辑链。社会模型的价值并非仅仅多估一个方差，而是使育种目标能够包含动物对群体共同生产环境的遗传贡献。

22.13 杂交均值、品种组成与杂种优势

杂交资料包含两个容易混淆的层面：群体平均水平随品种组成和杂合背景改变，个体又围绕所属群体均值存在可遗传差异。前者可以通过固定回归或明确的群体效应处理，后者进入动物遗传模型。如果不先定义品种组成与基准群体，动物效应可能被迫吸收系统性品种均值差异，结果的零点、尺度和跨群体比较都会变得含混。

对于两个来源品种,可以定义个体来自品种 B 的期望比例 q_i 。父母品种组成分别为 q_s, q_d 时,后代期望比例为 $(q_s + q_d) / 2$ 。在只追踪两个来源、忽略更复杂祖源和某些重组效应的教学框架下,可定义预期品种间杂合系数

$$\eta_i = q_s (1 - q_d) + (1 - q_s) q_d.$$

这里 η 专门表示杂种优势相关的设计系数,不能与全书的总育种目标 H 混用。它描述两条亲本来源分别来自不同品种的期望,不等同于全基因组实际杂合率。两个品种内部也具有多态性,而相同品种来源并不意味着相同等位基因。

一个最简均值模型为 $E(y_i) = \mu + q_i \Delta + \eta_i \gamma$, 其中 Δ 是两纯种均值差, γ 是在此编码下的直接杂种优势参数。该模型的可解释性取决于纯种、正反交和后续杂交类型的分布。若资料只有一种 F1 类型,品种比例和杂合系数可能都是常数,就不能同时从这些记录中估计纯种差和杂种优势。增加个体数并不能弥补缺少杂交类别的问题。

教学例 22.9: F1 与回交的期望。设品种 A 均值 100、品种 B 均值 120,直接杂种优势参数 8。A 与 B 交配的 F1 有 $q = 0.5, \eta = 1$, 期望为 118。F1 与 A 回交有 $q = 0.25, \eta = 0.5$, 期望为 109; F1 与 B 回交有 $q = 0.75, \eta = 0.5$, 期望为 119。回交到 B 的期望超过 F1, 并不说明它具有更多杂种优势,而是较高的品种 B 比例抵消了部分杂种优势损失。

F1 互交形成的后代期望品种比例仍为 0.5, 按上述简化系数其期望品种间杂合为 0.5, 均值为 114。实际复杂性状可能还受重组损失、连锁、上位作用、母体杂种优势与环境差异影响。简化模型提供的是清楚可检验的基线,不是对所有杂交世代的完整遗传解释。若出现偏离,应首先检查模型假设与试验可比性,而不是把全部差异归于一个未测量的机制。

母体杂种优势需要另设系数。例如后代本身为某一固定杂交类型,但母亲是纯种或杂种,哺育与繁殖环境可能不同。母体品种组成、母体杂合系数和直接系数应分别进入设计。正反交差异可能来自母体遗传、细胞质、性连锁或管理过程,单独观察到正反交均值不同,不能唯一证明某一种来源。设计充分的跨代和母体类型组合有助于区分这些解释。

22.14 纯种与杂种表现：相关可以小于一

纯种候选者自身的生产表现与其杂交后代表现，是两个可以高度相关但不必完全相同的遗传目标。环境不同、等位基因频率不同、显性导致的替代效应改变，以及遗传背景相互作用，都可能使纯种表现与杂种表现的遗传相关小于一。将二者作为两个性状联合建模，可以避免预先强迫它们完全一致。这里的“性状”是统计上的表达环境和遗传背景组合，并不要求测量单位不同。

令同一起来源品种个体对纯种表现和杂种表现的加性贡献分别为 u_P, u_C ，并设遗传协方差矩阵为 Σ_{PC} 。在关系结构合适时，联合动物效应可用 $\Sigma_{PC} \otimes A$ 描述。纯种—杂种遗传相关为 $r_{PC} = \sigma_{PC} / (\sigma_P \sigma_C)$ 。如果杂种群体的基因组关系和来源编码不同，不能机械地使用同一个谱系矩阵；上述结构是便于说明信息传递的基线，实际模型必须与来源贡献的定义一致。

教学例 22.10：相关决定间接信息的上限。假定候选者纯种育种值已被完全知道，纯种方差 4、杂种目标方差 9、相关 0.6，则协方差为 3.6。根据纯种值预测杂种值的回归系数为 0.9，条件预测误差方差为 $9 - 3.6^2/4 = 5.76$ ，可靠度仅为 0.36。即使纯种评价无限准确，也不能突破由相关不完全造成的这一信息上限。增加目标杂种记录或与之相关的新信息，才可能进一步降低误差。

若纯种值本身只有一定可靠度，能够传递的信息更少。在理想校准、相同模型基准及没有其他信息的简单设定下，杂种目标可靠度可以表达为纯种可靠度乘 r_{PC}^2 。但在复杂多来源评价中，不应把这个简式当成通用换算，因为纯种预测可能已经间接包含杂种数据，且误差之间存在依赖。最稳妥的方法是根据联合模型直接计算目标预测误差。

Wientjes 等 (2017) 关于多群体基因组关系的研究指出，关系矩阵所对应的基准群体会影响方差与相关参数的解释。对杂交研究而言，这一问题尤为重要：估计较低的纯种—杂种相关之前，应确认比较的是相容的遗传贡献尺度，而不是矩阵中心化差异或缺失亲本来源造成的混合结果。遗传相关的标准误和区间也应一起报告，避免把一个不稳定的点估计用于重大制度变

更。

基因组资料可以追踪染色体片段的品种来源，但来源推断本身也可能有误差。相近品种、短片段、缺少祖先基因型或复杂多代杂交时，来源不一定能够明确划分。一个诚实的模型应承认来源概率与不确定性，或至少通过替代编码分析结果敏感性。不能把计算程序输出的确定标签当成无误差的生物学事实。

数据采集策略应围绕目标展开。若商业杂种表现是最终目标，而核心群与商业群环境差异明显，仅继续扩大核心群相同类型记录可能收益递减。适量、准确连接到亲本且覆盖实际生产环境的商业后代记录，可能提供此前缺少的目标信息。但这些记录常伴随管理异质、身份错误和非随机采样，因而采集质量与连接设计应同规模一起考虑。

22.15 基础群体、未知亲本与遗传基准

动物模型必须回答“相对于谁定义遗传偏差”。当全部基础个体被假定为互不相关且来自同一零均值群体时， A 的构建十分清楚。但是长期育种资料常从不同年代、不同地区或不同来源群体引入动物，未知亲本不一定来自同一个遗传水平。将所有未知亲本都视为同一基准，可能把群体来源均值差异错误地归给可观察动物的遗传偏差或固定环境。

遗传组模型通过为不同未知亲本来源定义期望均值，补充这一层信息。例如按引入年代与来源定义组，将动物遗传值写为可追踪的组贡献加围绕组均值的随机偏差。组别应依据记录产生前可确定的来源信息设置，避免按观察到的优劣事后分组。过细的组别会与批次、场和品种固定效应高度混杂，导致估计不稳定；过粗则可能无法表达真实的基准差异。

遗传组不仅是普通的环境校正项。组贡献通过谱系传递到后代，系数代表祖先来源比例；一个动物的组设计行通常由父母贡献递归形成。因此组均值与个体随机偏差在概念上有关联，实施时应明确使用的参数化及约束。如果只给每条记录贴一个“出生来源”标签，却忽略其后代继承路径，就未必是在拟合遗传组模型。

另一条路线是用相关的基础代表群体描述创始者之间的关系。Legarra 等 (2015) 提出的 *metafounder* 框架, 将基础群体之间的相关和群体内部的基础关系纳入相容的谱系与基因组关系构建。它提供了一种处理多群体基准的模型方式, 但参数仍需资料支持; 不能因为允许估计群体关系, 就认为少量基因型足以精确恢复全部历史人口过程。

直观地说, 把两个基础群体视为完全独立, 与允许它们共享更早祖源, 会改变后代关系矩阵的尺度。如果同时使用谱系和基因组信息, 这一改变必须贯穿两者。后续第 26—29 章将讨论 H_{rel} 的统一关系构建。本章只强调一个原则: 均值基准、方差尺度和关系矩阵必须相互协调。局部调整一个矩阵而保持所有其他参数解释不变, 可能产生看似收敛却难以解释的评价。

未知亲本还可能是资料错误, 而非真实未知。父母编号缺失、性别错误、后代出生早于父母, 以及同一身份重复录入, 都会影响关系传播。基因组亲子核验能发现部分问题, 但采样身份错误也会同时污染基因型与表型。模型不能取代身份管理。修订谱系后, 应重新构建关系并记录版本, 而不是只在结果表中手工更换某些动物的父母名称。

评价基准随时间更新时, 育种值的零点可能移动。两个版本整体相差一个常数, 并不意味着所有动物生物学表现同时变化; 方差尺度变化则还可能造成成比例的差异。比较版本时, 应在共同参考动物集合上检查均值、尺度、排序与差值结构, 区分基准变更和新增信息效应。跨场、跨国或跨品种直接拼接育种值尤其需要这种基准审查。

22.16 复杂模型的选择: 从可解释结构到可检验预测

增加随机效应可以使模型更接近某些生物学过程, 也会增加参数之间竞争解释同一协方差的可能。选择模型时, 应先定义要估计的目标与资料生成机制, 再决定哪些来源必须分开。若目标是短期预测商品个体表现, 合并某些难分的环境来源有时已经足够; 若目标是跨代选择母体能力, 混合遗传与永久环境就会损害遗传解释。模型复杂度应服务于问题, 而不是作为学术深度的代替品。

一项实用检查是写出每个随机来源对应的观测协方差核。例如直接遗传为 $Z_dAZ'_d$ ，母体遗传为 $Z_mAZ'_m$ ，交叉来源为 $Z_dAZ'_m + Z_mAZ'_d$ ，母体环境为 WW' ，窝为 LL' 。将这些核视为矩阵空间中的方向，可以理解识别：如果某个方向恰好由其他方向线性表示，参数无法唯一分离；如果方向几乎相同，参数可能可识别但估计极不稳定。

数值上，观察信息矩阵的小特征值、方差参数的高度相关、不同初值产生相近似然而不同参数，以及轮廓似然的平坦区域，都是弱识别的信号。这些诊断不能被“优化成功”取代。优化器只说明它在规定容差内停止，可能停止在一条平坦山脊、参数边界或不适当的局部区域。第 23 章将进一步区分收敛、合法性和识别。

预测验证应按实际部署任务划分资料。若要预测新出生后代，训练集不能含其未来表型；若要推广到新群体，随机拆分同栏记录会过度利用共同环境；若目标是未知母亲的新窝表现，应避免训练和验证共享该窝。验证单元的选择决定问题本身。一个在随机记录拆分中表现良好的复杂模型，未必能准确预测真正的未来世代。

复杂遗传效应的存在也不自动构成因果证据。例如显著母体遗传方差说明在给定模型与关系结构下，跨亲属的母体相关有统计支持，但不能独自证明某个特定哺育机制。社会效应预测可能吸收与基因型相关的分群过程；杂种优势项可能与特定场的管理方式混杂。通过随机化、交叉设计、外部数据与生物学测量加强解释，通常比仅增加参数显著性标记更有价值。

结果报告可以沿着“定义—证据—用途”展开。先说明各效应的单位、参考群体和作用路径，再给出方差、相关、区间以及识别诊断，最后说明哪些选择或配种决策可据此支持。对于无法分开的来源，明确报告其合并含义。这样的报告允许后续研究积累可比较证据，也使生产者知道模型在哪些条件下可以使用。

22.17 从新研究到可迁移应用的完整案例

近年的复杂模型研究继续把遗传效应与环境梯度、群体结构及纵向过程结合。Jahnel 与 Langhammer (2026) 以小鼠窝总重为对象, 使用随机回归描述相关遗传效应随窝大小变化。这一研究提示: 母体与后代相关性状的遗传表达可能随生物学负荷改变, 固定的单一方差有时不足以概括全过程。但小鼠的具体估计不是其他多胎家畜的参数, 迁移应用需要对应物种的资料、单位和生产机制检验。

将这一思路用于教学设计, 可以考虑一个羊群断奶总产出问题。研究者记录羔羊体重、生物学母亲、哺育母亲、窝大小、寄养时间、母亲体况、批次和父系。目标不是单独提高每只羔羊体重, 而是在母体负担和成活约束下提高每只母羊的可持续产出。由此, 直接生长、母体照护、窝大小和成活都是相关的目标或预测成分, 不能把窝大小仅作为一个需要机械消除的环境变量。

第一步应明确调整目标。若把窝大小作为固定协变量, 模型比较的是相同窝大小下的生长差异; 若窝大小本身具有遗传性且属于总产出的一部分, 这种调整可能去除一条真实的目标路径。可以同时分析窝大小与生长, 或分别报告条件性生长和综合繁殖产出。协变量是否应该校正, 取决于想估计的量, 而不是取决于它与记录是否显著相关。

第二步建立最小可解释动物模型, 包含必要的场年季、性别和年龄曲线, 再逐步检查母体遗传、母体永久环境和窝环境。每次增加来源, 都应核对它由哪些亲属或重复结构识别。若全部母亲只有一窝, 不能强行分离母亲永久环境与窝环境; 若父系仅在一个场出现, 父系与场的连接不足也应先报告。先画出资料关系, 再求解方程, 往往能节省大量无意义的优化工作。

第三步把母体反应写为负荷函数。例如以中心化窝大小 z 建立 $m_i(z) = m_{0i} + m_{1i}z$, 其协方差为 K_m 。截距描述参考负荷下能力, 斜率描述随负荷变化的遗传反应。候选母亲甲在小窝中领先, 却可能在大窝中落后; 这可以是生物学上有意义的反应差异, 也可能是极端窝大小资料稀少导致的外推。应同时给出对应位置的预测误差, 避免只展示交叉曲线而不展示不确定性。

第四步按时间保留下一繁殖季作验证,并预先定义评价指标。对连续产出关注校准、预测误差和排序;对成活概率关注概率校准及适当的评分;对综合目标关注权重变化下的稳定性。每个指标都对应不同用途。若生产环境将在下一季发生明显改变,还应承认验证环境与部署环境之间的差异,而不能把一次历史验证视为永久质量保证。

最终决策应结合遗传进展与管理改进。若窝环境方差很大,改善哺育和疾病控制可能立即提高产出;若某些母体反应具有稳定遗传差异,长期选择可以逐步改变群体。统计分解并不要求管理与育种二选一。它使我们能区分哪些变化可通过当季资源安排实现,哪些需要跨代积累,并据此设计协调的生产策略。

22.18 在去除固定均值后检验遗传来源的可分离性

生物学上可以明确区分的效应,在观察资料中未必产生可区别的协方差。已有亲缘连接也不自动保证每一个遗传来源可估,因为固定效应可能消去恰好用于区分来源的方向。将母体遗传、母体永久环境和残差同时放入模型时,真正需要检查的是:消除均值以后,还剩下多少互不相同的协方差变化。Willham (1963) 从不同个体贡献的性状组分推导亲属协方差,提示我们应沿着贡献路径建立模型;这里进一步把这些路径放到实际设计的可识别空间中检验。

考虑简化的高斯方差组分模型 $y = X\beta + Z_m m + Z_c c + e$, 各随机来源相互独立。母体遗传效应协方差为 $A_m \sigma_m^2$, 母体永久环境协方差为 $I \sigma_c^2$, 残差独立同方差。观测协方差为

$$V = K_m \sigma_m^2 + K_c \sigma_c^2 + I \sigma_e^2,$$

$$K_m = Z_m A_m Z_m', \quad K_c = Z_m Z_m'.$$

取列满秩的对比矩阵 L , 使 $L'X = 0$, 并让其列覆盖全部均值正交空间。误差对比 $z = L'y$ 的协方差为 $L'VL$ 。三个方差可被分别识别的必要结构条件, 是下列三个矩阵线性无关:

$$\tilde{K}_m = L'K_m L, \quad \tilde{K}_c = L'K_c L, \quad \tilde{K}_e = L'I L.$$

若存在不全为零的实数 b_m, b_c, b_e , 使三个矩阵的加权和为零, 那么沿该方向改变参数, 只要仍留在合法区域内, 误差对比的分布就完全相同。扩大相同结构的记录数量, 可能缩小某些方差组合的区间, 却不能自动使这个零方向消失。判断中用完整对称矩阵向量化即可; 为方便手算, 也可以用普通正交投影 J 在原观察空间检验 JK_rJ 的线性关系。

独立教学例: 两只相关母亲仍不足以分解。两只母亲各有两条后代记录, 母亲间加性关系为二分之一, 只有一个固定截距。令 Z_m 的前两行连接母亲一, 后两行连接母亲二, 则

$$A_m = \begin{bmatrix} 1 & 1/2 \\ 1/2 & 1 \end{bmatrix}, \quad J = I - \frac{1}{4}\mathbf{1}\mathbf{1}'.$$

母体关系矩阵可写成 $A_m = \frac{1}{2}I + \frac{1}{2}\mathbf{1}\mathbf{1}'$ 。因为 $Z_m\mathbf{1} = \mathbf{1}$, 去除总体截距后第二项消失, 因而

$$JK_mJ = \frac{1}{2}JK_cJ.$$

即使两只母亲确有亲缘, 限制似然仍只能从母亲间对比识别 $\sigma_c^2 + \sigma_m^2/2$ 。这里的困难不是亲缘系数为零, 而是唯一的母亲间对比只有一种关系模式。若把“母亲有关联”当成母体方差必然可分的充分条件, 就会漏掉这个反例。

现在增加第三只母亲, 与前两只均无亲缘, 每只仍有两条记录。母体关系矩阵中只有第一、第二母亲之间的非对角元为二分之一, 其余为零。用六维中心化矩阵, 三个投影核的向量化列秩变为三。若以矩阵元素内积构成一个简单结构诊断矩阵, 其特征值约为零点四九九、二点六二零和十六点三二六, 均为正。这个诊断只说明结构上出现了三个不同方向, 不等于用六条记录便能精确估计三个方差; 实际限制似然信息还需要按当前协方差加权。

另一个边界更严厉: 若把每只母亲的自由均值都作为固定效应, 令 $X = Z_m$, 则 $L'Z_m = 0$, 两个母体核都被消除。给母亲设固定效应以“充分校正母亲差异”, 与同时用这些差异估计随机母体方差, 在此设计中互相冲突。是否需要这种固定校正取决于研究目标; 计算上不能同时要求同一个观察方向既完全自由又提供随机分布信息。

实际资料检查可以按亲属关系类型、跨窝重复与管理单元建立少量代表性子设计,再检查去均值后的核秩。若发现秩不足,应指出具体缺失的对比,而不只说模型复杂。补充第三类亲缘模式、让相关母亲跨场分布、增加同母异窝记录,各自修复的是不同信息方向。只有明确这一点,后续扩大测定才可能增加真正需要的遗传证据。

结构秩检验还需要区分精确为零与数值上很小。如果不同方差以不同单位表达,未经缩放的核列范数可以相差很大,直接对一个固定绝对容差判秩可能误把小单位当成缺乏信息。可以先把各核按明确尺度标准化,再检查线性组合,并将可疑方向代回原矩阵验证。标准化不能把完全重合的核变成独立,却能避免由单位造成的假象。对于只有极少非零差异的两个核,即使计算秩为满秩,估计仍可能非常不稳定,应继续检查按协方差加权的信息特征值与轮廓形状。

此外,新增亲缘记录只有在身份和来源记录可靠时才提供相应方向。若母亲编号混乱、寄养母与生母互换,模型可能生成看似不同的核,却不对应真实路径。此时满秩只是错误设计的代数属性。因此设计检查应同时包含“矩阵是否区分来源”和“来源是否被正确记录”两层。对代表性记录手工展开亲属协方差,再与矩阵元素核对,是连接这两层的有效方法。

22.19 相关遗传效应的正交分解与条件解释

直接遗传效应与母体遗传效应相关时,参数表中的负协方差经常被过度解释为两种生物学作用彼此抵消。实际上,协方差描述同一遗传来源在两个表达途径中的线性共变,不直接说明某条因果通路。通过条件投影,可以把母体效应分成与直接效应共享的一部分和剩余遗传部分,使模型中每一个来源的含义更清楚。

设同一组动物具有直接效应 u 和母体效应 m , 联合协方差为

$$\text{Var} \begin{pmatrix} u \\ m \end{pmatrix} = \begin{bmatrix} \sigma_u^2 & \sigma_{um} \\ \sigma_{um} & \sigma_m^2 \end{bmatrix} \otimes A.$$

假定直接遗传方差为正, 定义

$$b = \frac{\sigma_{um}}{\sigma_u^2}, \quad \eta = m - bu.$$

逐项计算协方差可得

$$\text{Cov}(u, \eta) = 0, \quad \text{Var}(\eta) = A\sigma_{m|u}^2,$$

$$\sigma_{m|u}^2 = \sigma_m^2 - \frac{\sigma_{um}^2}{\sigma_u^2} \geq 0.$$

因此原记录模型可以重写为

$$y = X\beta + (Z_u + bZ_m)u + Z_m\eta + e.$$

如果联合正态, u 与 η 不仅不相关, 而且独立; 此时 $E(m|u) = bu$, 剩余项是给定直接遗传效应后仍无法预测的母体遗传变化。没有正态假设时, 上述表达仍是最佳线性投影, 但一般不能把 bu 称为完整条件均值。这个限定使矩阵分解与分布解释保持一致。

剩余项虽然与直接效应正交, 却仍通过 A 在亲属之间相关。它不是母体环境, 也不是不遗传的噪声。把统计正交性解释为生物学独立机制, 或把条件遗传方差直接改名为环境方差, 都会改变模型含义。正交分解只是换一种坐标表达同一联合遗传结构, 在某些问题中更便于分析信息来源, 也可能改善计算条件。

独立教学例: 负相关不等于负总遗传方差。取直接方差九、母体方差四、协方差负三。则 $b = -1/3$, 条件母体遗传方差为三。若同一个体的组合目标为 $H = u + 2m$, 在原坐标中

$$\text{Var}(H) = 9 + 4 \times 4 + 4(-3) = 13.$$

在新坐标中, $H = u/3 + 2\eta$, 两部分正交, 所以

$$\text{Var}(H) = \frac{1}{9} \times 9 + 4 \times 3 = 13.$$

两个结果相同, 说明分解没有创造或损失遗传变化。但后代表型中的直接效应来自后代, 母体效应来自其母亲, 二者的相关还要乘亲子关系; 无近

交亲子条件下，这条记录的遗传方差是 $9 + 4 - 3 = 10$ ，并非同一个体 $u + m$ 的方差七。目标权重与效应归属都必须先写清楚，不能只见到两个方差名称就按相同公式相加。

当条件母体方差接近零时，母体效应几乎由直接效应的线性函数决定。这个低维边界可能来自真实遗传结构，也可能反映资料无法分辨两个方向。若条件方差恰为零，模型应在较低维支持空间求解，不必为两个完全关联的随机向量各自求逆。若直接方差也接近零，比例 b 本身不稳定，此时原协方差或特征分解比回归系数更适合报告。

不同坐标下的标准误也需要同步转换。设 T 为把原效应转成 (u, η) 的矩阵，预测误差变为 $TC_u T'$ ，目标权重按逆变换处理。如果只变换点预测，不变换预测误差，就可能误判某个母体方向已被精确分离。正交化不能解决上一节的核混淆：数据对某个方差组合没有信息时，换一组互不相关的潜在坐标仍然没有增加一个观察对比。

22.20 不规则社会网络中的贡献与反馈

固定栏大小下的社会模型可以扩展到不等接触强度的网络，但此时“每头动物影响多少同伴”必须从设计矩阵读出。设直接遗传效应为 d ，社会遗传效应为 s ，记录的遗传部分为 $g = d + Ws$ 。矩阵 W 的第 i 行、第 j 列表示动物 j 对接受者 i 的预先定义暴露权重，通常对角元为零。行描述接受了谁的影响，列描述向谁输出了影响，这一区别决定了选择目标的正确方向。

若目标是所有接受者的总产出，社会总贡献为

$$\mathbf{1}'g = \mathbf{1}'d + \mathbf{1}'Ws = \sum_j (d_j + q_j s_j), \quad q = W'\mathbf{1}.$$

因此动物 j 的总育种贡献是 $T_j = d_j + q_j s_j$ 。总贡献使用列和，而不是行和。若接受者产出具有不同经济价值，令其权重为 v ，则应改成

$$v'g = v'd + (W'v)'s.$$

Bijma、Muir 与 van Arendonk (2007) 强调间接遗传作用会改变遗传总贡献及选择响应的定义。网络表达把这种思想进一步写成可以逐个接触关

系检查的形式，但权重是否代表因果社会作用，仍取决于接触记录、分群过程与模型假设。

若同一个体的直接与社会遗传方差分别为 σ_d^2, σ_s^2 ，协方差为 σ_{ds} ，不同个体通过关系矩阵连接，则记录遗传协方差为

$$\begin{aligned}\text{Var}(g) = & A\sigma_d^2 + WAW'\sigma_s^2 \\ & + (AW' + WA)\sigma_{ds}.\end{aligned}$$

这是由四个协方差乘积逐项展开的结果。矩阵 W 不对称时，不能把交叉项简化成两倍某一个非对称乘积。个体总贡献的方差在无近交条件下为

$$\text{Var}(T_j) = \sigma_d^2 + 2q_j\sigma_{ds} + q_j^2\sigma_s^2.$$

独立教学例：接受影响多与输出贡献大不同。三只无亲缘动物的接触矩阵为

$$W = \begin{bmatrix} 0 & 1/2 & 1/2 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \quad q = (1, 1.5, 0.5)'.$$

取直接遗传值均为一，社会遗传值依次为零点五、负零点四和零点八。三只动物各自记录中的遗传部分为一点二、一点五、零点六，总和三点三；三只动物向总体提供的贡献则为一九五、零点四、一点四，总和仍为三点三。第二只动物自身表现最好，却因为它的负社会效应传递给较多接受者，总贡献最低。这不是用一种指标否定另一种指标，而是说明个体表现和对总体的贡献本来就是不同目标。

若直接方差四、社会方差一、协方差负二分之一，则三种位置的总贡献方差分别为四、四点七五和三点七五。位置造成的差异来自表达权重，不代表动物的基础遗传分布因编号改变。若比较将来可能被安排在同一种位置的候选者，应使用同一个目标网络或参考暴露；直接沿用当前栏位权重，会把安排差异混入遗传比较。

还要区别“伙伴遗传效应进入表型”与“伙伴表型同时反馈”。后一种机制可写成 $y = a + \rho W y + e$, 在 $I - \rho W$ 可逆时有

$$y = (I - \rho W)^{-1}(a + e).$$

若谱半径满足 $|\rho| \rho(W) < 1$, 逆矩阵可展开为 $I + \rho W + \rho^2 W^2 + \dots$, 体现多轮反馈。对于上例行和为一的网络, 若 $a = \mathbf{1}$ 、残差为零、反馈系数为零点二, 平衡表现为每只一点二五。这个放大来自反馈轮次, 与一次性的 $d + Ws$ 模型不是同一机制。若把同时发生的伙伴表型当作普通外生协变量, 估计还可能受到内生性影响; 观察到网络相关, 不能自动选择反馈模型或将其参数解释为因果传染强度。

22.21 不可分方差下哪些预测仍然稳定

参数不可识别并不意味着所有预测都毫无用途, 但必须区分“可观察综合状态的预测”与“遗传来源的分配”。设每只动物的持续状态为 $r = u + p$, 其中遗传效应 u 与永久环境 p 独立, 并且在当前资料中二者具有相同的跨记录核。若它们的方差分别为 θ_u, θ_p , 似然可能只依赖总和 $\tau = \theta_u + \theta_p$ 。此时模型对下一次同类表现的预测可以稳定, 而对可传递遗传值的预测仍随分配比例变化。

以一条均值已知的记录 $y = u + p + e$ 为例, 残差方差为 r_e , 二阶矩计算给出

$$\begin{aligned} \hat{r} &= \frac{\tau}{\tau + r_e} y, & \text{PEV}(r) &= \tau - \frac{\tau^2}{\tau + r_e}, \\ \hat{u} &= \frac{\theta_u}{\tau + r_e} y, & \text{PEV}(u) &= \theta_u - \frac{\theta_u^2}{\tau + r_e}. \end{aligned}$$

综合状态的预测只依赖已识别总和; 遗传预测既依赖总和, 也依赖未被数据决定的分配。该区别不是哲学措辞, 而会直接改变发布的遗传单位和预计选择响应。同一动物再做许多次测量, 可以越来越清楚地知道它的持续状态, 但若缺少亲属连接或独立遗传信息, 仍不能仅凭自身轨迹知道其中哪一部分能够传递。

独立教学例：排序稳定而改良幅度不稳定。假定总持续方差为十，残差方差为二，一条校正记录为六。若合理外部情景允许遗传方差在二至六之间，综合状态预测始终为五，误差方差始终为 $5/3$ ；遗传预测却从一变到三，遗传预测误差分别为 $5/3$ 与三。若所有动物使用同一种信息结构，它们可能在所有情景下保持相同排序，因为预测只乘以一个正比例；然而选择差异的遗传单位可以相差三倍。

当信息结构不同时，连排序也未必稳定。记录来自自身重复表现的动物，较依赖遗传与永久环境的分配；主要依靠不同亲属记录的动物，则可能由另一条协方差路径预测。因此，一个整体排序相关很高的敏感性结果不能替代逐类检查。应特别查看只有自身记录、有多个亲属、来自特殊母系或社会位置的候选者，辨认究竟哪些动物承受未识别方向的影响。

可以把稳定性条件推广到任意协方差路径。设合法参数沿 $\theta(t)$ 变化，观测协方差始终相同。对于均值已知的目标 T ，有

$$\hat{T}(t) = c_T(t)'V^{-1}y, \quad c_T(t) = \text{Cov}_{\theta(t)}(y, T).$$

若 $c_T(t)$ 也不变，点预测不受该参数路径影响；若目标方差 $v_T(t)$ 同时不变，预测误差也保持不变：

$$PEV_T(t) = v_T(t) - c_T(t)'V^{-1}c_T(t).$$

这给出了比“模型参数不稳定所以一切都不能用”更精确的判断。不可识别路径可能影响某些科学解释，却不影响某个特定预测；也可能不影响点预测而影响目标方差与可靠度。报告时应分别考察这三个对象，而不是用其中一个替代另外两个。

一个常见反例是目标改成下一代新个体的表现。永久环境通常不沿遗传路径传给后代，综合持续状态的稳定预测不能直接用于下一代。若根据当前生产预测良好就断言遗传评价已经充分识别，就把个体内重复性与跨代传递混为一谈。模型简化可以服务于短期管理，但当任务转为种用选择，应重新确认目标与数据之间的遗传协方差是否真正得到支持。

22.22 杂交均值模型中的互交信息与剩余混淆

杂交设计既要描述均值，也要避免把亲本来源、母体环境与杂种优势压缩成一个无法解释的差异。考虑两个品种，令 q 为后代来自品种甲的期望基因组比例， q_m 为母亲来自品种甲的比例， h_{cross} 为来自不同品种的亲本等位基因配对概率。一个用于说明识别问题的均值模型为

$$E(y) = \mu + \delta_a q + \delta_m q_m + \eta h_{cross}.$$

这里 δ_a 表示在其余列控制下的品种组成差异， δ_m 表示与母亲品种组成共同变化的差异， η 为本模型定义的杂种优势系数。仅凭该均值模型，不应把 δ_m 自动解释为纯粹母体遗传效应；它也可能包含母源环境、细胞质来源或其他与互交方向一起改变的因素。

若父母的甲品种组成分别为 q_s, q_d ，在采用品种来源随机配对的简化期望下，后代组成及杂交系数为

$$q = \frac{q_s + q_d}{2}, \quad h_{cross} = q_s(1 - q_d) + (1 - q_s)q_d.$$

该系数衡量品种来源的组合，不等于直接从少数标记观察到的个体杂合率。历史混合、连锁与品种内多态性都会影响两者之间的关系。若模型采用实测基因组杂合度，需要重新定义系数及其解释，而不是只替换列名。

独立教学例：四类交配的均值分解。假定甲纯种均值为十二，乙纯种为八，甲父乙母的一代杂种为十三，乙父甲母的一代杂种为十五。四类交配在模型中的系数行依次为

$$\begin{aligned} x'_{AA} &= (1, 1, 1, 0), & x'_{BB} &= (1, 0, 0, 0), \\ x'_{AB} &= (1, 1/2, 0, 1), & x'_{BA} &= (1, 1/2, 1, 1). \end{aligned}$$

从互交差得到 $\delta_m = 15 - 13 = 2$ ；乙纯种给出 $\mu = 8$ ；纯种差给出 $\delta_a = 12 - 8 - 2 = 2$ ；再由一个杂种均值得到 $\eta = 13 - 8 - 1 = 4$ 。所以

$$\mu = 8, \quad \delta_a = 2, \quad \delta_m = 2, \quad \eta = 4.$$

两个互交杂种平均为十四，两纯种平均为十，差四，与模型中的杂种优势一致。然而单独拿乙父甲母的十五减去亲本平均十，所得五还包含互交方向的一半差异，不能当成与方向无关的杂种优势。这个例子展示了互交记录对均值分解的直接作用。

如果没有乙父甲母这一类交配，只剩三种均值，四个系数就不能由三条独立均值方程唯一决定。增加同样三类的个体数可以更准地估计各类均值，却不能分开所有四个模型系数。若四类交配又各自只出现在不同场，加入自由场固定效应后，原本满秩的交配均值设计也可能失去有效连接。识别依赖交配类型与环境的交叉，而不仅依赖表格中出现几个品种名称。

回交记录能够检验更强的模型限制。例如甲纯种父本与一代杂种母本交配时， $q = 3/4$ 、 $q_m = 1/2$ 、 $h_{cross} = 1/2$ ，上述参数预测均值为十二点五。这个值是模型外推，不是回交资料尚未观察时的实证事实。若实际回交均值系统偏离，可考虑杂交后代的母体杂种优势、重组损失或其他结构，但每增加一个项都应指出新增哪些交配类型能够识别它，不能让模型只靠更多名称解释任意均值。

22.23 以遗传目标误差选择后续测定设计

复杂遗传模型的资料采集不应只追求估计每个方差的显著性。若育种目标已经确定，可以直接计算一种新记录预计减少多少目标误差。这个计算将试验设计与选择决策连接起来，同时保留“参数已知、模型正确”的条件。它尤其适合比较几种可实施的小规模设计，而不是在完成试验后用同一批结果倒推所谓最优方案。

设现有资料下效应向量 b 的预测误差协方差为 C ，目标为 $H = h'b$ 。新测定在扣除现有信息的可预测部分以后，等于 $z'b$ 的剩余误差加独立噪声，噪声方差为 r 。新记录的创新方差为 $z'Cz + r$ ，与目标剩余误差的协方差为 $h'Cz$ 。因此其预计误差减少量为

$$\Delta_H(z) = \frac{(h'Cz)^2}{z'Cz + r}, \quad C_{H,new} = h'Ch - \Delta_H(z).$$

若一次获得多条相关新记录, 令其设计为 Z_n 、噪声协方差为 R_n , 则

$$\Delta_H = h' C Z_n' (Z_n C Z_n' + R_n)^{-1} Z_n C h.$$

这个公式不能通过把单条增益全部相加来替代, 因为新增记录之间可能重复提供相同方向的信息。顺序更新时, 应在每加一条后更新剩余误差, 再评价下一条的边际价值。若测定费用不同, 可以比较单位成本误差减少量, 但同时获得多条记录时, 组合最优设计仍可能不同于逐条贪心选择。

独立教学例: 母体目标未必最需要自身记录。假设对某候选者直接与母体效应的现有误差矩阵为

$$C = \begin{bmatrix} 4 & -1.5 \\ -1.5 & 2 \end{bmatrix}, \quad h = (1, 2)', \quad h' C h = 6.$$

比较三种假定能够通过预先设计的亲属对比获得的新信息, 噪声方差均为一: 只测直接方向, 设计 $z = (1, 0)'$; 只测母体方向, 设计 $z = (0, 1)'$; 测两者之和, 设计 $z = (1, 1)'$ 。三个增益分别为

$$\Delta_D = \frac{1}{5} = 0.2, \quad \Delta_M = \frac{2.5^2}{3} = 2.083333,$$

$$\Delta_{D+M} = \frac{3.5^2}{4} = 3.0625.$$

直接方向的单独误差方差最大, 却不提供最大的目标增益, 因为目标同时高度重视母体方向, 且两个误差负相关。测定两者之和的新信息最接近目标所需的剩余方向。这里的设计是明确规定的教学对比, 现实中不能直接量到“纯遗传母体值”; 应通过后代、互交或重复记录建立具有相应期望设计和噪声结构的实际观察, 并把其实现成本纳入比较。

如果新测定共享现有资料的环境噪声, 上述独立噪声条件不成立, 需要先构造正确创新。若计划的亲属对比依赖尚未估计准确的方差, 增益本身也有不确定性; 可在若干合理参数情景下计算它, 寻找对情景稳定的设计。一个只在非常精确的负相关假设下最优的方案, 可能不如略次优却稳健的方案适合实际投入。

最后，目标精度改进与参数识别改进可以分开考虑。某项设计对眼前候选者的目标误差减少不大，却能提供此前缺少的母体与环境分离方向，因而改善长期评定体系；另一项设计可能迅速提高少数精英动物精度，却几乎不帮助新家系。把短期选择收益与长期学习价值分别表达，能够避免所有测定资源都集中在已有信息最丰富的动物上，也使复杂遗传模型从事后解释工具转为可规划的知识积累体系。

22.24 练习与详解

练习 1：亲缘递推。已知父母均无近交，二者加性关系为 0.2。求后代近交系数和关系矩阵对角元；若父母各自近交系数改为 0.1 和 0.2，求孟德尔抽样方差相对于基础加性方差的系数。解释这两个计算为什么用到不同的亲缘信息。

解答。后代近交为父母加性关系的一半，即 0.1，对角元为 1.1。孟德尔抽样方差系数为 $0.5 - 0.25(0.1 + 0.2) = 0.425$ 。前者衡量父母向后代传递同源等位基因的可能性，依赖父母彼此的关系；后者衡量给定父母遗传值后后代仍有的分离变异，依赖父母各自的近交。不能把父母彼此关系直接替换进后一个公式。后代总方差还包含父母平均的方差，两部分合起来才得到正确的对角尺度。

练习 2：只有后代记录。两个无关亲本及其后代均无近交，只有后代表型偏差 8，均值已知，加性方差 6、残差方差 18。求三个动物育种值预测和后代可靠度。

解答。后代表型方差 24，与两个亲本育种值的协方差分别为 3，与自身为 6。因此两个亲本预测各为 $3 \times 8/24 = 1$ ，后代为 2。后代误差方差 $6 - 36/24 = 4.5$ ，可靠度 0.25。亲本没有自身记录却能够从后代得到信息，但不能把后代预测 2 完整复制给亲本；亲缘路径使信息按协方差传递。

练习 3：公畜尺度。动物加性方差 16、独立环境方差 24，简单随机父系半同胞结构下求公畜效应方差、模型内残差方差与方差比。公畜效应预测为 1.5、其误差方差为 0.8 时，完整育种值与误差方差是多少？

解答。公畜效应是传递给单个后代的平均一半育种值，方差为 4；残差包括未由父系解释的加性部分 12 与环境 24，共 36；比值为 9。完整育种值预测为 3，误差方差为 $4 \times 0.8 = 3.2$ 。方差必须随线性尺度的平方变化。若只把预测乘二而不调整误差，可靠度与区间都会被误报。

练习 4：母体协方差合法性。直接方差 9、母体方差 4，协方差取 -7 是否可行？若改为 -3，无近交后代记录另有母体环境 2 与残差 16，求单条记录方差。

解答。合法协方差绝对值不能超过 $\sqrt{9 \times 4} = 6$ ，所以 -7 不可行；二阶矩阵会有负特征值。取 -3 时，亲子关系 0.5 使交叉总项为 $2 \times 0.5 \times (-3) = -3$ ，总方差为 28。直接—母体相关为 $-3/6 = -0.5$ ，不是 $-3/28$ ；后者没有相关系数的定义依据。

练习 5：不能分离的两个环境。一项研究有 500 只母亲，每只只产一窝，每窝记录六只后代，拟合母体永久环境与共同窝两个随机项。优化器返回两个正方差并宣布收敛，是否可以据此报告二者已被识别？

解答。不可以。母亲与窝的分类一一对应，两项设计核相同，似然只依赖方差总和。不同方差组合可能得到完全相同的目标函数，算法输出其中一个组合只是数值路径的结果。应合并该项，或引入同母异窝记录等真正新增的信息。更多同窝后代不能解决该结构问题，因为它们仍沿同一个协方差方向增加观察。

练习 6：母体目标误差。目标为 $H = u + 2m$ ，预测误差方差为 2 和 1，协方差为 -0.5。求目标误差方差；若遗传方差仍为 9、4 及协方差 -3，求目标可靠度。

解答。误差为 $2 + 4 \times 1 + 4(-0.5) = 4$ 。目标遗传方差为 $9 + 4 \times 4 + 4(-3) = 13$ ，可靠度为 $1 - 4/13 = 0.6923$ 。目标权重同时进入遗传方差与预测误差方差，不能只在分子中调整。这里的可靠度是在方差参数已知且联合预测正确校准的模型意义下计算。

练习 7：社会作用规模。直接方差 4、社会方差 1、协方差 -1，群体大小 6 且无稀释。求总育种值方差、单记录遗传方差及两只无关同伴的遗传协

方差。

解答。总方差为 $4 - 10 + 25 = 19$ ；单记录遗传方差为 $4 + 5 = 9$ ；两个同伴协方差为 $-2 + 4 = 2$ 。三个结果不同，分别对应个体对群体的总贡献、某条记录接收的遗传作用以及两条记录共享的遗传路径。如果另有群环境方差，应给两条记录协方差再加该项，而不是加到遗传协方差定义中。

练习 8：杂交均值。两纯种均值分别 80 和 100，直接杂种优势 10。求 F1、向低均值品种回交及 F1 互交后代的简化期望；说明为什么 F1 互交不能仍给杂合系数 1。

解答。F1 为 $80 + 0.5 \times 20 + 10 = 100$ ；回交为 $80 + 0.25 \times 20 + 0.5 \times 10 = 90$ ；F1 互交为 $80 + 0.5 \times 20 + 0.5 \times 10 = 95$ 。F1 双亲各自都有两种来源，后代两条来源相同的机会不再为零，因此期望品种间杂合系数降为 0.5。这是来源层面的简化概率，不等于所有标记实际杂合率都精确减半。

练习 9：纯种信息上限。纯种—杂种遗传相关为 0.5，纯种育种值已完全知道，能否得到杂种目标可靠度 0.8？若纯种可靠度为 0.6，采用本章简单单一信息设定时，目标可靠度是多少？

解答。不能，完全知道纯种值时上限为相关平方 0.25。纯种可靠度 0.6 时为 0.15。需要增加直接与杂种目标相关的独立信息，才能提高这一可靠度。这里的乘法建立在单一信息、相同基准和正确协方差定义上；若纯种评价已含杂种后代记录，不能不加区分地再次套用并重复计算信息。

练习 10：协变量改变了什么目标。研究总窝产出，分析单只断奶重时将窝大小作为固定协变量。所得育种值是否直接代表提高每只母羊总产出的遗传能力？

解答。未必。该育种值主要描述在同一窝大小条件下的生长差异，而总产出同时受后代数、成活和个体重量影响。窝大小若有遗传性，调整它会改变所估计的路径。应先定义综合目标，再通过多性状、联合模型或明确的经济组合把各来源联系起来。条件性生长值仍然有用，但必须按其条件含义解释。

练习 11：直接选择与社会目标。四只一群时，候选甲直接值 3、社会值

-0.8, 乙直接值 1、社会值 0.4。按直接值和总贡献各如何排序? 若使用完全稀释社会单位, 结果如何?

解答。直接值甲优于乙; 无稀释总贡献甲为 0.6、乙为 2.2, 乙优于甲。若给定的社会数值本来就是完全稀释单位, 则总贡献甲为 2.2、乙为 1.4, 甲较高。但不能把同一模型估计的社会值任意换单位而保持数字不变; 练习比较的是两个明确不同的设定。真实换尺度时, 社会值、协方差及误差都要一致变换。

练习 12: 设计一个最小验证方案。目标是在下一繁殖季评价新出生后代的断奶表现, 现有记录跨五年, 包含母亲重复窝和父系连接。如何划分验证, 并检查复杂母体模型是否真正有用?

解答。以最后一年或预先指定的未来繁殖季作为验证期, 训练仅使用预测时点前可获得记录, 并保留母亲历史表现和当时已知谱系。比较基础动物模型与加入母体来源后的模型, 检查误差、均值偏差、回归校准及目标排序; 同时分层查看新母亲、已有记录母亲和不同场的表现。不能随机拆分同一窝的后代并把所得结果解释为预测未来新窝。若要判断母体遗传与永久环境是否分别有价值, 还需检查跨亲属和跨窝信息, 而非只看总预测误差略有下降。

本章由关系传递进入多种遗传表达路径, 核心始终是把每一条记录连接到真正发挥作用的个体与环境。只有作用对象、尺度、基准和目标一致, 动物模型的广泛适应性才能转化为可信的育种决策。

模型的可扩展性还取决于记录规范能否同步扩展。新增一个效应之前, 应确认身份、作用对象、时间和暴露信息均能稳定采集; 若这些基础字段长期缺失, 再精细的协方差结构也只能对缺失机制做强假设。把模型需求转化为可执行的数据采集规范, 是复杂遗传评价从研究走向常规应用的必要步骤。

方差组分、限制似然与贝叶斯推断

23.1 方差参数为什么决定预测的力度

第 21 章在协方差已知的条件下推导了 BLUP，第 22 章将协方差结构扩展到母体、社会和杂交资料。然而实际评价很少事先知道加性方差、永久环境方差与残差方差。它们需要从样本估计，而估计结果又决定记录之间如何加权、随机效应收缩多少、亲属信息怎样传递以及预测误差多大。方差组分不是求育种值之前可有可无的技术附件，而是连接生物学假设与统计预测的核心参数。

考虑最简单的随机截距模型 $y_{ij} = \mu + u_i + e_{ij}$ 。如果遗传方差很大而残差较小，一只动物的记录偏离总体均值就更可能反映持续遗传差异，预测保留较多偏离；如果残差很大，同样的表型偏离会更强地向总体收缩。没有足够资料估计这两个来源时，预测力度本身也不确定。把估计的方差当作已知，可以作为常规计算近似，但需要认识这种近似忽略了参数估计带来的额外不确定性。

方差参数同时规定总体协方差 $V(\theta) = Z\Sigma_u(\theta)Z' + R(\theta)$ 。参数向量 θ 可以包括方差、协方差、相关、残差衰减率或随机回归曲线的系数协方差。不同参数化描述同一个合法协方差集合时，应得到相同的最大似然拟合协方差；数值稳定性却可能不同。一个直接估计相关和标准差的程序，与一个估计 Cholesky 因子的程序，可能沿不同路径达到同一模型。

估计方差有三项彼此独立的要求。首先，参数必须使模型协方差合法，通常要求相关随机块半正定、观测协方差正定。其次，数据应能区分待估来源，即参数具有足够识别信息。最后，计算应真正达到所定义准则的合适解。

合法不等于可识别，可识别也不等于算法已经求对；优化器显示成功，更不能反过来证明前两项。贯穿本章的一个基本习惯，就是把这三个问题分开检查。

本章先从可以手算的样本方差进入最大似然和限制最大似然，再推导得分、信息与常用迭代方法，随后讨论边界、区间和贝叶斯方差推断。所有小数据均为教学构造，不代表任何真实畜群估计。例题的作用是让读者看到公式中每一个自由度、迹项和约束怎样影响结果，从而具备审查大规模分析输出的能力。

23.2 从平方和到方差分解

独立同分布正态记录 $y_i = \mu + e_i$ 提供了最简单的起点。给定真实均值时，平方偏差和的期望为 $n\sigma_e^2$ ；均值用样本平均估计后，残差满足总和为零，失去一个独立方向，所以残差平方和期望变为 $(n-1)\sigma_e^2$ 。自由度不是为了使公式看起来熟悉而添加的修正，它描述估计均值后仍可用于观察随机波动的独立方向数量。

如果均值结构是秩为 p 的矩阵 X ，同方差线性模型中的残差投影为 $M = I - X(X'X)^{-1}X'$ 。因为 M 对称幂等、 $MX = 0$ 、 $\text{tr}(M) = n - p$ ，有 $E(y'My) = \sigma_e^2(n - p)$ 。这里的 p 指列空间秩，而不是输入软件的列数；若截距和全部分类虚拟变量同时出现，冗余列不会额外消耗新的均值方向。

对于平衡随机组模型，每组 m 条、共 a 组，组内差异消去共享随机效应，因而组内均方的期望为残差方差。组平均之间的差异同时包含随机组方差与平均残差，因此组间均方期望为 $\sigma_e^2 + m\sigma_u^2$ 。由两个期望方程得到矩估计。这种方法清楚地揭示识别来源：组内对比识别残差，组间对比在扣除平均残差后识别持续组差异。

教学例 23.1：平衡资料的两种波动。三组记录分别为 (8, 10)、(12, 14)、(10, 12)。组平均为 9、13、11，总平均 11。组内平方和为 6，自由度 3，均方 2。组间平方和为 $2[(9-11)^2 + (13-11)^2 + (11-11)^2] = 16$ ，自由度 2，均方 8。因此组方差估计为 $(8-2)/2 = 3$ ，残差方差为 2。

这组数可以进一步解释收缩。组平均的残差方差为 1，组方差为 3；若总体均值已知，预测组效应的权重为 $3/(3+1) = 0.75$ 。但实际均值由同一组资料估计，预测误差还包含均值估计的影响。方差分解提供了收缩强度所需的参数，不能省略第 21 章关于未知固定效应的完整计算。

不平衡资料中，不同组平均具有不同残差精度，简单用平均组大小替代 m 常常不能保持矩估计的良好性质。复杂谱系、交叉环境、多性状和缺失记录又使平方和不再自然分成独立块。最大似然与限制似然的价值就在于使用完整协方差结构，系统地处理这些不平衡，而非为每一种设计另找一个经验自由度。

矩估计仍有用途。它可以提供初始值、检查数量级、发现明显数据错误，并在小型平衡例子中验证复杂软件。若算法给出的估计与可手算的平衡模型不一致，应先核对参数定义、约束、似然常数和数据排列，而不是默认软件规模更大就一定正确。数学上透明的小问题，是审查大规模计算最可靠的参照之一。

23.3 最大似然及固定效应的代价

在正态模型 $y \sim N(X\beta, V(\theta))$ 下，忽略与参数无关的常数，对数似然为

$$\ell(\beta, \theta) = -\frac{1}{2} \{ \log |V| + (y - X\beta)' V^{-1} (y - X\beta) \}.$$

给定 θ ，最大化关于固定效应的部分得到广义最小二乘解。将它代回似然，形成关于方差参数的剖面对数似然。这个过程正确地找到原始联合似然的最大值，但它并不会自动补偿固定效应估计占用的信息。小样本中，某些方差最大似然估计因此偏小；偏差大小和方向在复杂模型中不能只凭一个普遍系数概括。

在独立同方差模型中，最大似然均值为样本平均，方差估计为残差平方和除以 n 。其期望为 $(n-p)\sigma_e^2/n$ ，清楚显示固定均值参数增加时方差被低估的原因。一个具有大量小当代组的育种资料，虽然总记录数很大，每组均值估计仍可能消耗相当比例的信息。因此不能只用总样本量判断固定效应估计代价是否可忽略。

教学例 23.2：三条记录中的一个自由度。记录 8、10、12 的平均为 10，残差平方和为 8。最大似然方差为 $8/3 = 2.6667$ ；使用两个剩余方向的方差估计为 4。二者之差并非优化精度问题，而是估计准则不同。若均值事先真被外部知识固定为 10，方差最大似然仍为 $8/3$ ，此时却没有估计均值造成的同一自由度损失。是否知道均值，是模型条件，不是记录平均恰好等于某个整数就能决定的。

剖面似然中需要区分“优化掉参数”与“积分掉参数”。前者对每一个方差参数取最优固定效应；后者在指定测度或先验下对固定效应积分。二者会产生不同的行列式项。这一区别是理解限制似然以及贝叶斯分析关系的关键。把所有消除固定效应的方法都称为“控制了均值”，会掩盖它们对方差推断的不同影响。

最大似然仍有明确用途。若比较的模型具有不同固定效应空间、但相同响应数据及适当嵌套结构，可以在相应条件下比较最大似然拟合。限制似然基于不同的残差空间，通常不能直接这样比较。模型选择还需考虑边界、样本依赖及固定设计条件，不能把软件输出的两个似然数机械相减便套用任意卡方自由度。

似然也不是数据之外的真理。其概率解释依赖正态或其他分布、协方差结构、观测机制和记录单位。对偏态或离群记录，方差可能被少量极端点显著影响。判断模型是否适合，既要检查参数估计，又要查看残差、分层变异和预测表现。改变分布或稳健分析应围绕具体证据展开，而不是把所有不理想结果都归咎于正态假设。

23.4 限制似然来自消去均值的独立对比

设 X 满列秩为 p ，取一个 $n \times (n-p)$ 的满列秩矩阵 L ，满足 $L'X = 0$ 。向量 $L'y$ 的均值为零，协方差为 $L'VL$ 。它包含了不受固定效应影响的误差对比。对这些对比建立似然，就得到限制最大似然，通常记为 REML。Patterson 与 Thompson (1971) 在不等区组信息恢复问题中建立了这一重要方法，后续混合模型将其广泛用于方差与协方差估计。

不同的合法对比基底只会改变与方差参数无关的常数，因为它们表示同一个残差子空间。因此 REML 的估计不应依赖研究者恰好选了哪一组误差对比。实际计算通常也不显式形成庞大的 L ，而使用与其等价的矩阵表达。定义

$$Q = V^{-1} - V^{-1}X(X'V^{-1}X)^{-1}X'V^{-1}.$$

于是忽略不依赖 θ 的常数，限制对数似然为

$$\ell_R(\theta) = -\frac{1}{2}\{\log|V| + \log|X'V^{-1}X| + y'Qy\}.$$

若需要完整的某一种规范化表达，可再加入 $(n-p)\log(2\pi)$ ；不同对比基底还可能带来仅依赖 X 的常数。因此比较不同软件的绝对 REML 数值之前，应先核对它们采用的常数约定。对于同一数据、相同固定效应空间和相同规范化方式，似然差才具有直接可比意义。

第二个行列式项是固定效应信息调整，它不是经验惩罚。把 $V = \sigma_e^2 I$ 代入，第一项含 $n \log \sigma_e^2$ ，第二项含 $-p \log \sigma_e^2$ ，合起来正好剩下 $(n-p) \log \sigma_e^2$ 。最大化后得到残差平方和除以 $n-p$ 。一般协方差情形中，固定效应与方差之间的关系更复杂，但同一几何逻辑仍然成立。

Q 不是通常意义下的欧氏正交投影，因为一般有 $Q^2 \neq Q$ 。它满足 $QX = 0$ 、对称以及 $QVQ = Q$ ，表示在协方差加权空间中消去固定效应后的精度算子。将其称为“残差加权算子”比直接称作普通投影更准确。后面的得分与信息推导都依赖这些恒等式，尤其是 $QVQ = Q$ ，而非错误地使用 $Q^2 = Q$ 。

若固定效应设计有冗余，应先选取满秩表示，或在广义逆与广义行列式的约定下计算。不同约束应保留相同列空间，估计才能一致。随意删除某些观测后再复用原来的秩和固定设计，会使自由度和似然都不正确。数据筛选、缺失处理与模型矩阵构建应作为同一版本流程保存。

限制似然改善了许多方差估计的有限样本性质，却不保证每个参数无偏，也不保证所有模型正确。约束边界、选择性资料、非正态分布、弱连接和高度相似的协方差核仍可造成困难。REML 是一种明确的推断准则，其优势来自对固定效应空间的处理，而不是来自对全部统计问题的自动修复。

23.5 用平衡模型看懂 REML 的谱分解

回到 a 个组、每组 m 条记录的随机截距模型。残差空间可以分为两部分：每组内部的 $m - 1$ 个对比，共 $a(m - 1)$ 个方向，其方差为 σ_e^2 ；组平均之间的 $a - 1$ 个对比，经适当标准化后方差为 $\sigma_e^2 + m\sigma_u^2$ 。两个子空间正交且在正态条件下独立，限制似然因此可以写成两类一维正态似然之和。

令组内平方和为 SS_W 、组间平方和为 SS_B ，则略去常数，负二倍限制对数似然为

$$a(m - 1) \log \sigma_e^2 + SS_W / \sigma_e^2$$

再加

$$(a - 1) \log (\sigma_e^2 + m\sigma_u^2) + SS_B / (\sigma_e^2 + m\sigma_u^2).$$

若不受边界约束，分别最优化两个特征方差，得到 $\hat{\sigma}_e^2 = MS_W$ 及 $\hat{\sigma}_e^2 + m\hat{\sigma}_u^2 = MS_B$ ，正好恢复前面的方差分析估计。这个等价只在适当的平衡正交结构下成立；不能据此断言 REML 总是某个简单均方差。

对例 23.1，两类自由度分别为 3 和 2，平方和为 6 和 16，最优特征方差为 2 和 8，于是随机组方差 3、残差 2。可以先通过这个低维表达验证估计，再使用完整的 V 和 Q 计算相同结果。两个实现依赖不同的计算路径，若均吻合，就比仅重复调用同一优化函数更有说服力。

这一分解还解释为什么有些资料对某一方差信息薄弱。只有少数家系但每家系很多后代时，组内残差可以估得较精确，组间遗传方差却仍主要依赖有限的家系对比。总记录数增加很多，不意味着遗传方差有效信息同幅增加。育种试验设计需要同时考虑家系数、每家系后代数、跨环境连接与目标性状成本。

谱分解的思想可以推广到一般模型。不同协方差来源在观测空间中改变不同方向的方差；如果两个来源在所有可观察方向上产生完全相同的变化，就不可分。若它们仅在少数低信息方向上有差异，估计便可能很不稳定。这个几何视角为后面关于识别和信息矩阵的讨论提供了直观基础，也解释了为什么高质量设计比单纯增加重复数更重要。

23.6 得分方程：观察到的波动与模型期望之差

令 $V_k = \partial V / \partial \theta_k$ 。矩阵微分恒等式给出 $d \log |V| = \text{tr}(V^{-1} dV)$ 、 $dV^{-1} = -V^{-1}(dV)V^{-1}$ 。对固定设计保持不变的限制似然求导，并结合 $QX = 0$ ，可以得到 $dQ = -Q(dV)Q$ 。因此第 k 个参数的得分为

$$s_k = \frac{1}{2} \{y' Q V_k Q y - \text{tr}(Q V_k)\}.$$

第一项衡量经过固定效应校正的记录，在协方差变化方向 V_k 上呈现多少平方波动；第二项是当前模型预期的相应波动。得分为正，意味着在该方向增大协方差可能提高似然；得分为负则相反。这一解释比把得分仅当作优化器输入更有用：方差估计是在平衡资料展示的随机波动与模型所期待的波动。

为什么正确参数下得分期望为零？由于 $E(y) = X\beta$ 且 $QX = 0$ ，二次型期望为 $\text{tr}(Q V_k Q V)$ 。通过迹的循环性质和 $QVQ = Q$ ，它等于 $\text{tr}(Q V_k)$ ，恰好抵消第二项。这个推导也说明，在均值模型错误或协方差结构错误时，得分的平衡不再保证参数对应真实生物学来源；算法仍可能找到一个拟合最好的近似协方差。

对随机组模型，若 $\theta_1 = \sigma_u^2, \theta_2 = \sigma_e^2$ ，则 $V_1 = ZZ'$ ， $V_2 = I$ 。如果使用对数方差参数 $\phi_k = \log \theta_k$ ，新得分为 $\partial \ell_R / \partial \phi_k = \theta_k s_k$ 。变量变换不能只改变约束而保留原得分。错误的链式法则可能使程序在简单例子中仍似乎收敛，却在尺度悬殊或接近边界时产生明显偏差。

教学例 23.3：检验得分的方向。对例 23.1，取候选方差 $\sigma_u^2 = 2.5, \sigma_e^2 = 2.5$ 。两个特征方差分别为 2.5 和 17.5。由平衡表达直接求导，组方差得分为 $-2/7.5 + 16/7.5^2 = 0.0177778$ ；残差得分为 $-3/(2 \times 2.5) + 6/(2 \times 2.5^2) - 2/(2 \times 7.5) + 16/(2 \times 7.5^2) = -0.1111111$ 。这提示应适当增加组方差、降低残差方差，但实际迭代步还取决于两参数之间的曲率耦合。

在最优点 (3, 2)，两个得分均为零。我们可以再用中心有限差分近似对数似然导数，与解析结果比较。这一检查应选择相对于参数尺度合适的步长，太大带来截断误差，太小则受浮点消减影响。有限差分是核验解析导数的工具，不应只在某一个恰好为零的最优点检查；在一般内部点比较更容易暴露

符号和尺度错误。

对协方差参数, V_k 不一定半正定, 例如直接—母体交叉协方差的导数可以包含正负方向。得分仍使用同一公式, 但单个参数的可行变化受整个协方差矩阵约束。不能因为某个协方差得分为正, 就无限增加该参数而忽略相关界限。优化必须在合法参数空间中协调所有方向。

23.7 信息矩阵、平均信息与数值步长

得分说明提高似然的局部方向, 信息矩阵说明曲率和参数之间的耦合。在正态模型及常规条件下, 限制似然的期望信息为

$$\mathcal{I}_{kl} = \frac{1}{2} \text{tr}(QV_k QV_l).$$

它不显式依赖观察到的 y , 却依赖设计、关系结构和当前方差参数。若某个线性组合的协方差变化在残差空间中近乎为零, 对应信息就很小, 参数组合难以估计。信息矩阵的小特征值因此具有统计意义, 不只是数值线性代数中的麻烦。

当 V 对方差组分线性时, 观察信息可以写为

$$\mathcal{J}_{kl} = y' QV_k QV_l Qy - \frac{1}{2} \text{tr}(QV_k QV_l).$$

这里二次型在标量意义下对 k, l 对称。观察信息与期望信息的平均为

$$\mathcal{I}_{AI,kl} = \frac{1}{2} y' QV_k QV_l Qy.$$

Gilmour、Thompson 与 Cullis (1995) 提出的平均信息 REML 方法, 利用这一结构建立高效的方差参数迭代。其重要计算优势之一, 是避免在某些更新步骤中显式处理昂贵的二阶迹表达, 同时保留有用的曲率信息。具体大规模实现还依赖稀疏分解、方程求解和所用协方差结构, 不能仅凭公式短就认为全部计算成本已经消失。

线性方差参数化条件值得特别强调。如果 V 对参数非线性, 例如自回归相关、标准差与相关的组合、Cholesky 因子或对数方差, 二阶导数还会

出现 V_{kl} 相关项。可以在原始方差参数中构造近似信息，再通过雅可比变换，或使用完整链式法则推导。把线性组分的观察信息公式直接照搬到所有参数化，是常见而隐蔽的错误。

一次更新可写成 $\theta_{new} = \theta + \delta$ ，其中信息矩阵乘 δ 等于得分向量。若完整步长使方差越界或似然下降，就需要缩短步长、信赖域或其他受约束策略。靠事后把负方差改成极小正数并继续计算，可能破坏更新方向和收敛判断。合法性应在步骤选择中被处理，而不是作为输出表最后的格式修补。

信息矩阵接近奇异时，直接求逆会放大数值误差。实际程序通常求解线性方程，并考虑尺度变换或稳定化。稳定化可以帮助找到合理迭代方向，但如果问题来自真实的弱识别，给信息矩阵加一小块对角并不会增加数据证据。需要在最终报告中检查未被人为稳定化掩盖的原始曲率，并通过轮廓或敏感性分析揭示不确定性。

Gilmour (2019) 讨论了平均信息方法在实践中的推广与实现，提醒我们算法名称并不意味着所有协方差模型都使用完全相同的导数细节。新近的大规模改进，例如 Strandén 等 (2024) 围绕平均信息计算效率的工作，也主要解决计算组织问题。更快地求解相同准则很有价值，但计算效率和统计识别属于两条需要分别验证的证据链。

23.7.1 将总体尺度从相关形状中剥离

某些模型可以写成 $V = sV_0(\psi)$ ，其中 $s > 0$ 是总体尺度， ψ 描述方差比或相关形状。给定 ψ ，定义基于 V_0 的残差精度算子 Q_0 ，则 $Q = Q_0/s$ 。限制对数似然关于尺度的部分为 $-\frac{1}{2}\{(n-p)\log s + y'Q_0y/s\}$ ，因此条件最优尺度为 $\hat{s}(\psi) = y'Q_0y/(n-p)$ 。把它代回后，只需优化较少的形状参数。这个剥离既能降低维度，也能让总变异与分配比例的不同信息来源更清楚。

例如随机组模型可令 $s = \sigma_e^2$ 、 $\psi = \sigma_u^2/\sigma_e^2$ ，于是 $V_0 = I + \psi ZZ'$ 。给定方差比，残差尺度由上述式子确定。需要注意，若残差方差真在边界为零，这种参数化不适合直接表示该边界；若模型有多个无法共同提取的尺度约束，也不能任意套用。剥离是一种建立在明确代数结构上的优化简化，不是对所有方差模型都有效的捷径。

比较不同形状下的剖面时，每一点都重新估计尺度，因而与固定残差方差的切片不同。它可能显示：资料对总变异非常敏感，对遗传与环境的分配却相当宽容。这正是许多小样本遗传力估计区间较宽、表型方差却较稳定的原因。画图时应同时标明优化的是方差比还是遗传力，以及哪些参数已被重新估计。

23.7.2 协方差的合法参数化与其限制

对二性状协方差，可以用标准差和相关表示，也可以令下三角矩阵 B 满足 $\Sigma = BB'$ 。若 B 的对角为正，所得协方差正定；对角允许零则可能表示半正定边界。Cholesky 表示将合法性转为对少数对角参数的简单限制，适合数值优化与采样。但不同变量顺序对应不同因子，若直接给因子元素独立先验，诱导的协方差先验也可能随顺序改变，必须认识这种统计后果。

以 B 的两行分别为 $(a, 0)$ 和 (b, c) 为例，第一性状方差为 a^2 ，协方差为 ab ，第二性状方差为 $b^2 + c^2$ 。当 c 接近零且 a, b 非零，相关接近正负一。优化器可以用合法因子顺利到达这一附近，但资料是否支持近完全相关仍需检查轮廓与信息。合法参数化解决的是可行集合问题，没有解决识别问题。

尺度标准化还能改善条件数。如果两个性状分别以数千单位和小数单位测量，未经变换的方差参数与导数数量级可能差异极大。先按固定已知常数缩放性状，再拟合并反变换，通常不会改变模型实质；按数据估计标准差缩放时则应记录该过程，并在需要时考虑其不确定性。不能只反变换育种值而忘记协方差、预测误差和经济权重也需一致转换。

这些数值选择应写入分析说明。读者不必看到每一次迭代的内部细节，却需要知道参数是方差、标准差、对数方差还是某个矩阵因子；是否剥离总体尺度；如何处理零边界和相关极限。明确这些条件，才能把不同软件的估计、标准误和收敛报告放在同一数学框架中比较。

23.8 EM 更新：稳定直观，但不能代替识别

除了得分和信息方法，还可以把随机效应视为未观测数据，构建期望最大化迭代。以 $u \sim N(0, A\sigma_u^2)$ 为例，若暂把其他条件明确给定，完整数据中

关于遗传方差的二次型是 $u'A^{-1}u$ 。在当前参数下，对其取条件期望，得到预测均值二次型加预测误差的迹项。这个结构说明：方差估计不能只用收缩后的育种值平方平均，否则会系统遗漏尚未被资料解释的遗传变异。

在适当的完整数据似然或限制似然推导下，典型更新包含

$$E(u'A^{-1}u | y) = \hat{u}'A^{-1}\hat{u} + \text{tr}(A^{-1}C_{u|y}).$$

这里 $C_{u|y}$ 必须与所处理的固定效应条件一致。若固定效应被视为已知，使用相应条件后验协方差；若要实现 REML，则需采用与消去固定效应一致的版本。不能将一个含未知固定效应的 MME 逆块、一个固定效应已知的分母和一个普通 ML 更新随意拼接。

教学例 23.4：收缩平方不等于方差。假设三个独立随机效应的条件均值分别为 $-1, 0, 1$ ，各条件方差均为 2，先验关系为单位阵。条件期望平方和为 $1 + 0 + 1 + 3 \times 2 = 8$ 。若相应完整数据更新分母为 3，得到 $8/3$ ；若只平均预测值平方，则为 $2/3$ ，低估了尚不确定的部分。这个教学算例只展示条件二次型恒等式，具体 REML 更新仍须按所用模型推导自由度。

EM 在很多方差模型中能保持非负性并提高目标函数，但接近最优点或方差来源高度混淆时可能很慢。慢收敛有时来自缺失信息比例高，有时来自似然本身平坦。换用平均信息或加速方法可以缩短计算，却不能把平坦似然变得尖锐。若多个方差组合拟合几乎相同，算法越快也只是越快到达其中某个区域。

实际流程可先用较稳健的步骤获得合法起点，再使用曲率方法提高效率。无论使用哪种组合，都应记录目标函数、参数、得分或约束残差的变化，防止仅凭连续两次参数变化很小判断收敛。如果步长被不断压缩到几乎为零，参数当然变化很小，但此时可能远未满足最优性条件。

EM 视角还有一个概念价值：它清楚地区分随机效应的实现值与总体方差参数。当前样本恰好出现几个很高的育种值，不等于总体遗传方差精确等于它们的经验方差；预测值已被资料质量和先验结构共同收缩。要从预测结果反推总体变异，必须把未观测的不确定性一起带回，这也是可靠度校正和二阶段分析中反复出现的主题。

23.9 参数边界与约束下的重新优化

方差不能为负，协方差矩阵必须半正定，这使参数空间具有边界。无约束矩估计出现负组方差，通常表示组间波动没有超过组内噪声所能解释的程度，而不是发现了负的生物学方差。约束估计可把该方差放在零边界，但其余参数必须在这个边界模型内重新最优化。只截断一个负值并保留其他无约束估计，通常不是约束最大似然或 REML 解。

教学例 23.5：零方差时残差也要重估。三组记录均为 (9,11)，每组平均 10。组内平方和 6，组间平方和 0；无约束方差分析给残差 2、组方差 -1。约束组方差为零后，模型退化为六条独立记录共享一个均值，限制似然残差估计应为 $6/(6-1) = 1.2$ 。把组方差改为零而仍用残差 2，未达到边界模型的最优点。

几何上，内部最优点各参数得分为零；边界最优点却可以在不可行方向上存在提高似然的趋势。对于限制为非负的方差，若最优点为零，向合法正方向的导数通常不应为正。检查边界解时，应使用相应约束最优性条件，而不是要求所有原始得分都等于零。协方差矩阵边界还可能意味着某个特征方差为零，条件比逐个参数非负更复杂。

对数方差参数化保证严格正值，却无法在有限参数值真正到达零边界。当最优解在零处时，对数参数可能不断向负无穷移动，软件最终以一个很小的数停止。这个数不应被解释为精确估计到一个微弱但非零的遗传来源。可以比较显式边界模型、检查轮廓似然，并报告资料是否支持将该分量与零区分。

相关系数接近正负一时，协方差矩阵同样靠近奇异边界。直接—母体、截距—斜率或高度相近性状之间出现极端相关，可能是真实的低维遗传结构，也可能来自资料不足、尺度不当或模型过度复杂。仅因估计合法就认定生物学相关“几乎完美”，证据不足。需要观察区间、信息矩阵以及替代参数化的稳定性。

边界还改变假设检验的参考分布。经典似然比卡方近似通常要求真实参数位于内部、模型可识别且其他正则条件成立。检验一个非负方差是否为零

时，这些条件不满足；在某些简单条件下会出现混合卡方分布，但多方差、未知相关或弱识别时不能机械使用同一个混合比例。Self 与 Liang (1987) 的非标准似然理论为这种现象提供了基础框架，实际应用仍须核对具体条件。

边界估计也不意味着该机制永远不存在。有限资料可能没有足够信息发现小方差，特定环境可能抑制其表达，模型中其他项也可能吸收相似信号。报告应区分“当前资料与模型的估计为零”“区间允许较大的正值”和“有充分精度支持方差很小”。这三种情形对未来数据采集与育种策略具有不同含义。




图 23.1 内部解与零方差边界的限制似然轮廓。左图使用例 23.1，右图使用例 23.5；每一个组方差值下都重新优化残差。纵轴以各自最优点为零，展示的是轮廓而非固定其他参数的切片

23.10 可识别性：从矩阵方向到真实资料

在固定效应空间相同的条件下，方差参数能否识别，取决于不同参数是否产生可区别的残差协方差。若有非零系数向量 c 使 $L'(\sum_k c_k V_k)L = 0$ ，则沿该方向改变参数不会改变误差对比的分布，局部信息为零。对线性组分模型，这个条件直接展示结构性混淆。一个满秩的观测协方差矩阵，并不意味着其中每一个组成方差都能独立估计。

教学例 23.6：一个无法拆开的总和。 每只动物只有一条记录、个体之间

无亲缘, $Z = I, A = I$, 则 $V = (\sigma_u^2 + \sigma_e^2)I$ 。任意保持总和不变的非负组合具有相同分布。遗传方差 3、残差 7 与遗传方差 6、残差 4 无法凭这些资料区分。优化器可能返回某个组合, 贝叶斯后验也可以在加入先验后看似集中, 但数据本身只提供总和信息。

加入每只动物重复记录后, 两次记录共享遗传效应而残差独立, 协方差结构改变, 便可能区分两者; 然而如果同时加入个体永久环境, 其设计又与遗传效应相同, 且动物之间仍无亲缘, 则只能识别遗传加永久环境的总和。谱系或基因组关系提供跨个体协方差, 才可能进一步区分可遗传与不可遗传的持续差异。每增加一个来源, 都应重新检查所需连接。

弱识别与完全不可识别之间没有绝对清晰的经验界线。两个核虽然不完全相同, 却可能在现有样本中非常相近, 导致似然呈狭长山脊。参数单独区间很宽, 而某个总和却估得较准。此时应报告可被可靠估计的组合, 而不只展示两个不稳定的点估计。将高负相关的参数估计解释为生物学上的负相互作用, 尤其需要谨慎, 因为估计误差相关与遗传相关并非同一概念。

识别检查可从小规模设计诊断开始: 查看亲属类型、重复次数、母亲跨窝结构、跨场连接和缺失模式, 再检查导数核的线性相关以及信息矩阵。对大规模资料不必形成所有稠密核, 可以通过矩阵作用、抽样配对或降维诊断判断主要方向。计算方法可以变化, 但要回答的统计问题始终相同: 哪一类观察对比在区分这些来源?

当识别不足时, 合理选择包括简化模型、合并来源、固定有充分外部依据的参数、使用明确的先验或重新设计资料采集。每一种选择都会改变结论的条件。固定一个参数并不会让它成为已知真值, 先验使后验适定也不等于数据已经识别该参数。应把依赖外部信息的程度说清楚, 才能使结果可复现、可更新。

23.11 标准误、轮廓似然与方差比的不确定性

内部正则情形下, 可以用信息矩阵逆近似方差参数估计的协方差。该近似依赖样本信息足够、参数远离边界、局部曲率能够代表整体似然形状。对

于小家系数、极端遗传相关或零方差附近的估计，正态区间可能延伸到非法区域，也可能严重低估一侧的不确定性。把负下限简单改成零只是改变显示，并未建立正确的区间覆盖率。

轮廓似然提供另一种观察。对感兴趣参数固定一系列值，每次重新优化其余参数，得到一条一维剖面。它能显示左右不对称、平坦区、边界峰值及多个局部峰。固定其他参数不动而只改变一个值，得到的是切片而非轮廓；切片通常低估其他参数能够补偿变化的程度，因而看起来比真正轮廓更尖锐。这个区别在混淆严重的方差组分中尤其重要。

若感兴趣的是遗传力 $h^2 = \sigma_u^2 / (\sigma_u^2 + \sigma_e^2)$ ，可以在内部使用 delta 方法。梯度为 $(\sigma_e^2, -\sigma_u^2)' / (\sigma_u^2 + \sigma_e^2)^2$ ，近似方差为梯度左乘与右乘参数估计协方差矩阵。遗传方差与残差方差估计的协方差不能省略；二者常因共同解释总变异而负相关，这种相关会影响比值精度。

教学例 23.7：遗传力的 delta 近似。设遗传方差估计 4、残差 6，估计协方差矩阵对角元分别为 1 和 2，交叉元为 -0.5。遗传力为 0.4，梯度为 $(0.06, -0.04)'$ 。近似方差为 $0.0036 + 0.0032 + 0.0024 = 0.0092$ ，标准误约 0.0959。若忽略交叉项，得到 0.0825，低估了本例的不确定性。该结果只是局部近似，不能据此保证小样本区间具有准确覆盖率。

对遗传相关同样可以推导 delta 近似，但方差接近零时分母不稳定，相关本身可能缺乏有用解释。此时与其报告一个巨大标准误或贴近边界的相关，不如优先报告协方差与各方差的联合不确定性。相关是标准化量，标准化所需的两个方差若不确定，相关不会因此变得更可靠。

参数自助法可在拟合模型下反复模拟资料、重新估计参数，观察估计分布和边界频率。它能传播实际优化流程的影响，但结论仍以所模拟模型为条件。若原始设计缺乏识别，模拟更多次不会补足现实数据的信息；若模型遗漏重要环境结构，参数自助法可能重复遗漏同一种来源。计算重复次数影响蒙特卡洛误差，模型合理性影响推断对象，两者不能混淆。

非参数重抽样则应尊重依赖单位。随机逐条抽样相关后代记录会破坏家系和群环境结构，产生不合适的方差。可以考虑家系、场、群或时间块，但

具体单位取决于希望推广到哪一种总体。多层且交叉依赖的动物资料常没有一个简单通用的重抽样单位，设计与模型知识仍然不可替代。

23.12 固定效应比较、随机结构比较与预测用途

不同固定效应模型通常对应不同残差空间，因而 REML 数值不能直接当作同一数据似然比较。若要检验是否加入一个固定年龄曲线或管理效应，需使用适当的最大似然比较、固定效应检验或预测验证，并核对相应条件。固定效应是否保留还涉及混杂控制与目标定义，不能完全交给一个机械的显著性阈值。

当固定效应空间一致时，可以比较不同随机协方差结构的限制似然，但检验的参考分布仍取决于嵌套关系和边界。加入一个方差来源往往将零置于边界；加入随机截距和斜率同时引入方差与协方差，零假设下某些相关参数可能根本没有定义。这些情形不满足普通卡方自由度等于新增参数个数的简单规则。

信息准则还涉及有效参数数目与似然版本。边际似然关注对新群体或新随机效应的预测，条件似然关注已观察群体内的响应，二者面向不同任务。复杂模型的有效自由度也不总等于随机效应个数，因为随机效应受到收缩。使用某个准则前，应确认它与软件给出的似然和目标预测单位相匹配，而不是把不同类型的数值放进同一个公式。

预测验证提供直接的应用证据，却不能自动回答全部生物学问题。两个模型预测误差相近，可能具有不同的方差解释；一个模型提高随机记录拆分中的表现，可能只是更好地利用同一环境内的信息。若将要部署到未来世代或新场，应按该任务划分验证。参数估计、预测校准与因果解释是相互关联但不等同的评价层次。

在方差结构选择中，可采用逐步建立证据的方式。先以明确生物学机制和设计支持确定少量候选模型，再检查合法性、识别与收敛，最后比较拟合、区间和预先定义的预测表现。这样可以避免在大量任意结构中寻找偶然最优结果。若模型探索范围很大，最终验证应保留独立资料，防止反复调试把验

证集也变成训练信息。

模型简化不一定损害科学深度。一个只估计遗传加永久环境总和、却诚实说明不能进一步分离的模型，可能比报告两个高度不稳定参数更有价值。相反，当目标需要跨代传递解释时，简单总和又可能不足。合理复杂度并无固定答案，它取决于资料能够区分什么，以及决策需要区分什么。

23.13 贝叶斯方差推断的层次结构

贝叶斯分析将未知固定效应、随机效应和方差参数放入联合概率模型。基本结构可写为 $p(y | \beta, u, \theta)p(u | \theta)p(\beta)p(\theta)$ ，后验分布与该乘积成比例。与把方差估计代入 BLUP 相比，完整后验允许对方差不确定性积分，从而使育种值和目标预测反映参数层面的不确定性。它也要求明确先验，而不是把先验选择隐藏在优化约束中。

对于独立残差方差 $s = \sigma_e^2$ ，一种便于手算的先验是逆伽马分布，采用密度 $p(s) \propto s^{-(a+1)} \exp(-b/s)$ ，其中 $a, b > 0$ 。必须声明参数化，因为不同软件可能使用尺度、逆尺度或自由度表达。同样名称的先验若参数含义不同，会产生完全不同的后验。写出密度或明确转换关系，是避免误用的最简办法。

给定均值与随机效应，若残差平方和为 S 、独立残差数为 n ，则后验为 $IG(a + n/2, b + S/2)$ 。后验均值在形状参数大于 1 时等于尺度除以形状减一；众数等于尺度除以形状加一。均值和众数不同，反映逆伽马分布常有右偏。报告哪一种总结，应与用途和损失函数相匹配，不能把所有“后验估计”当成同一个数。

教学例 23.8：同一后验的两种总结。假定均值已知，四个独立残差的平方和为 12，先验 $IG(2, 3)$ 。后验为 $IG(4, 9)$ ，均值为 3，众数为 1.8。先验均值也是 3，但数据和先验共同使后验形状更加集中；相同均值不意味着数据没有贡献。若均值未知且采用相应平坦先验积分，残差自由度与平方和的定义会改变，不能继续把已知均值的更新直接照抄。

在正态线性模型中，给定方差参数、使用适当的平坦固定效应先验时，随机效应后验均值与 BLUP 相联系。对固定效应积分会出现与 REML 相同

形式的行列式调整,但方差后验还乘以所指定的先验。REML 估计、方差后验众数和后验均值一般不相同;参数变换后,众数还会因密度的雅可比而改变。把 REML 简单称为“无先验贝叶斯”会掩盖这些条件。

不适定先验需要特别检查后验是否适定。形式上可以写出条件分布或运行采样器,并不保证联合后验能够归一化。资料不足、方差边界、完全混淆和过多平坦参数都可能造成问题。应先依据模型与先验检查数学条件,再解释数值输出。一个在有限迭代中没有明显发散的轨迹,并不能证明不存在不可积的尾部。

23.14 先验尺度、相关矩阵与敏感性分析

方差先验不能脱离测量单位选择。体重以千克或克表示,方差相差一百万倍;对两种单位使用同一组数值超参数,会表达完全不同的实质知识。较稳妥的做法是先确定性状的合理变异范围,或对数据作明确可逆的尺度标准化,再给标准差指定可解释先验。分析完成后,预测和不确定性都应按同一规则转换回原单位。

逆伽马先验在某些层次模型中便于条件采样,但把极小形状和尺度一律称为“无信息”并不可靠。它们可能在零附近或尾部产生出乎意料的影响,尤其当数据对方差很弱时。Gelman (2006) 讨论了层次方差先验的这一问题,并提出以标准差为尺度考虑更稳健的选择。具体先验仍应结合实际量纲和合理范围,而不是用一个默认分布替代所有科学判断。

标准差的半正态或半 t 先验可以直接表达“较小值较常见,但允许一定大值”的知识。它们同样不是自动客观;尺度过小会过度收缩,尺度过大可能保留极重尾部并使计算困难。应通过先验预测分布检查其含义:从先验生成遗传与残差效应,看看得到的表型范围是否与可行生物学尺度相容。先验预测检验发生在利用具体结果调参之前,有助于避免事后迎合。

多性状协方差可以分解为标准差对角矩阵与相关矩阵的乘积,即 $\Sigma = D_s \Omega D_s$ 。分别为标准差和相关结构建模,常比直接给全部协方差一个难解释的联合先验更透明。Lewandowski、Kurowicka 与 Joe (2009) 提出的相关

矩阵分布与生成方法，为后来广泛使用的相关矩阵先验提供了基础。相关先验的集中程度应明确报告，特别是在性状数多而重叠记录少时。

先验能够稳定弱识别模型，但不能创造数据中没有的区分。若 V 只依赖遗传与永久环境方差的总和，后验中两者如何分配将显著依赖先验。此时应展示不同合理先验下的结果，并指出哪一些目标组合对先验稳定、哪一些不稳定。把先验敏感性视为结果的一部分，有助于确定未来应采集哪类新资料。

教学例 23.9：总和已知，分配仍由先验决定。假设资料几乎精确确定 $\sigma_u^2 + \sigma_p^2 = 10$ ，却无法区分两者。若先验偏好两项相近，后验可能集中在 5 与 5 附近；若外部资料支持遗传较小，后验可能集中在 2 与 8 附近。两种分析对记录总协方差预测相近，却给出不同遗传力。这个例子没有唯一的数据驱动答案，应明确承认外部知识承担了分解任务。

敏感性分析不需要无穷多个先验。选择少数在生物学上合理、但在关键弱信息方向上有不同偏好的方案，比较遗传力、相关、目标预测与决策稳定性即可。若候选者排序在合理先验下基本一致，而方差分量不同，可以分别报告这一稳定性与不确定性；不能因为最终名单相似，就宣称所有参数也已被精确识别。

23.15 条件采样、参数化与蒙特卡洛诊断

正态层次模型常允许交替抽样固定与随机效应、再抽样方差参数。给定方差，效应的联合条件分布为正态，其精度矩阵与混合模型方程密切相关；给定效应，某些方差在共轭先验下具有逆伽马条件分布。逐步条件抽样构成 Gibbs 方法的一种基本实现。Sorensen 等（1994）将 Gibbs 抽样用于遗传参数和选择响应推断，是动物育种贝叶斯计算发展的重要工作之一。

联合抽样与逐个效应抽样在理论目标上可以相同，混合效率却差异明显。当固定效应与随机效应高度相关，或方差很小时，逐个更新可能沿狭窄相关方向缓慢移动。重新参数化、分块更新、中心化与非中心化表示，可以改变计算效率，但应保持同一目标后验。若参数化同时改变了先验的实际含

义,就不再只是计算调整。

中心化模型直接抽样 $u \sim N(0, A\sigma_u^2)$; 非中心化模型可写为 $u = \sigma_u L_A z$, $z \sim N(0, I)$ 。资料对个体效应弱时, 后者有时减轻效应与尺度之间的依赖; 资料很强时, 前者可能更高效。没有一种参数化对所有数据都最佳。理解依赖来源比盲目增加采样迭代更有帮助。

采样收敛应从多条分散初值的链、轨迹、有效样本量、尾部行为和关键函数的蒙特卡洛误差综合判断。只看总体平均稳定, 可能遗漏某个方差分量仍在缓慢漂移; 只看单个常用诊断阈值, 也不能证明所有目标量都已精确。对于育种决策, 目标总值、极端分位数、超过阈值概率和排序差异都可能比单个参数均值更难估计。

教学例 23.10: 迭代数不等于有效样本数。若一条平稳链近似具有滞后一阶相关 0.9 且相关按幂衰减, 10000 次保留抽样的均值有效样本量约为 $10000(1 - 0.9)/(1 + 0.9) = 526.3$ 。这只是简化自相关结构下的说明, 真实链需估计更完整的相关序列。把 10000 直接作为独立样本数计算蒙特卡洛标准误, 会显著夸大精度。

后验预测检查则问模型生成的资料是否类似实际资料。可以比较组内与组间变异、尾部比例、不同亲属类型的协方差、时间变化以及缺失模式相关的统计量。模型即使采样充分, 也可能不能再现关键数据结构; 反之, 某些总体统计量拟合良好也不足以证明全部遗传解释正确。计算诊断验证“是否充分探索指定后验”, 预测检查验证“指定模型是否与资料相容”, 二者缺一不可。

为了可复现, 应保存先验参数化、随机种子、链数、抽样长度、丢弃阶段、软件版本和关键诊断, 同时记录数据与设计矩阵版本。随机种子只能重现某一次计算路径, 不能替代模型和资料记录。若换一组合理初值便得到明显不同的结论, 应先解决混合或多模态问题, 再给出生物学解释。

23.16 方差不确定性如何进入育种值与决策

常规经验 BLUP 先求 $\hat{\theta}$ ，再计算 $\hat{u}(\hat{\theta})$ 与把参数视为已知的预测误差。这一流程便于大规模实施，但后者通常不是包含参数估计误差的完整均方误差。对于资料丰富、方差估计稳定的性状，近似可能实用；对于新性状、少数家系或接近边界的协方差，差异可能明显。应根据实际信息判断，而不是一概认为代入误差可忽略或必然巨大。

在贝叶斯框架中，全方差分解给出清楚表达：

$$\text{Var}(u | y) = E_{\theta}\{\text{Var}(u | y, \theta) | y\} + \text{Var}_{\theta}\{E(u | y, \theta) | y\}.$$

第一项平均了各个参数条件下的个体育种值不确定性，第二项描述不同合理参数会给出不同预测均值。这两个部分都属于完整后验不确定性。只在后验平均参数处计算一次条件方差，既遗漏第二项，也未必等于第一项，因为条件方差通常是参数的非线性函数。

教学例 23.11：两个可能方差情景的混合。为说明全方差公式，假设后验以相同权重支持两个简化情景；某候选者在情景一中的条件均值为 1、方差为 2，在情景二中均值为 3、方差为 4。总体后验均值为 2，平均条件方差为 3，条件均值之间的方差为 1，因此总体方差为 4。将两个条件方差直接平均只得到 3，低估了由参数情景改变预测而产生的额外不确定性。

混合后的后验分布未必正态。上例是两个正态的混合，即使可以报告均值 2、方差 4，也不能未经检验就用单一正态尾部概率代替真实混合概率。对选择阈值附近的动物、极端风险决策或非线性经济损失，尾部形状可能重要。可以从完整后验抽样直接计算超过阈值概率、候选者差值概率和目标损失，而不强迫所有结论都压缩成一个可靠度。

频率学派也可以通过参数自助法或适当的均方误差修正纳入方差估计影响。一个可操作方案是在拟合模型下模拟训练资料，每次重新估计方差并预测，比较预测与模拟真值。关键是每次都重新进行方差估计；若模拟后继续固定原来的参数，只是在验证已知参数 BLUP。模拟应保持原来的设计、亲缘和资料选择机制，否则所得误差对应另一个问题。

对选择排序，参数不确定性的影响可能集中在特定动物。记录少、亲属结构特殊或依赖某个弱信息协方差的候选者，预测随参数变化更明显；拥有大量高质量直接信息的动物，可能相对稳定。因此一个群体平均可靠度无法代表每只动物的风险。可将合理参数区域内的预测变化、目标差值分布与常规条件 PEV 结合查看。

参数方差与环境变化还应区分。对当前总体方差估计不确定，是统计知识不足；下一代或下一环境真实方差发生变化，是模型转移问题。前者可以通过更多同类资料缩小，后者需要跨环境或跨时间模型及外部验证。如果生产制度改变导致遗传表达变化，即使旧参数估得极精确，也可能不能用于新的条件。

对非线性目标，平均参数、平均育种值与平均目标通常不能互换。例如成活概率为 $\Phi(\eta)$ 时， $E\{\Phi(\eta) | y\}$ 一般不同于 $\Phi(E(\eta | y))$ ；成本含阈值或惩罚时也如此。选择决策应尽量在目标尺度上整合不确定性，而不是先将所有未知量压缩成点估计，再对其作非线性变换。

在报告中，可同时给出常规条件可靠度与参数敏感性结果，清楚注明各自条件。对于研究阶段新性状，也可报告完整后验区间或自助法预测区间。不要把两类区间混用：频率置信区间描述重复抽样覆盖性质，贝叶斯可信区间描述给定模型、先验与资料的后验概率。二者可能数值接近，但解释并不相同。

23.17 一套可以审计的方差分析流程

一个可审计分析从资料定义开始。首先明确性状单位、记录时间、个体身份、当代组、亲属结构和缺失规则。对连续性状检查分布及异常范围，对重复记录检查同一个体内时间顺序，对谱系检查循环和亲子日期。所有修订都应保留规则与版本。方差估计对异常身份和错误重复尤其敏感，因为这些错误直接制造或破坏相关结构。

随后依据机制写出均值和协方差模型。每一个固定项说明它调整什么比较，每一个随机项说明它连接哪些记录。先在小子集上核验设计矩阵的行列

含义和若干手算协方差，再扩大到全体资料。若母体、社会或多性状模型中动物排序不一致，矩阵仍可能对称正定，程序也能收敛，但结果对应错误的生物学映射；单纯检查矩阵合法性无法发现这种问题。

初始值可以来自描述统计、简单平衡估计、较小模型或外部研究，但外部参数需要核对单位与基准。应使用多个有意义的起点，特别是在相关参数、随机回归或高维协方差中。若不同起点得到相同拟合协方差和相近目标函数，是稳定性证据；若参数差异大却似然相近，要进一步判断弱识别，而不是只挑选数字最符合预期的那一次。

优化过程应保存目标函数、参数、梯度或得分、步长与约束状态。停止标准可以同时关注相对似然变化、参数变化和适当缩放的最优性残差。不同量纲参数必须进行尺度处理，否则体重方差和概率潜在尺度参数的绝对变化不可直接比较。达到最大迭代次数应作为未充分收敛报告，不能因最后两行看起来接近就悄悄改成成功。

解的复核包括对称性、正定或半正定条件、边界状态、信息矩阵和关键轮廓。对简单模型可与独立手算或另一实现比较；对复杂模型可用有限差分核验导数、用随机向量检验矩阵作用、用模拟数据检查能否在合理精度内恢复已知结构。验证应针对具体风险，不能用大量与实际模型无关的小测试替代关键协方差映射检查。

教学例 23.12：已知真值模拟应怎样解释。假设按例 23.1 的三组两记录设计反复生成资料，真实组方差 3、残差 2。即便程序完全正确，每次估计也会有相当波动，部分样本可能落在零边界。不能要求每一次都精确返回 3 和 2；应检查许多重复中的偏差、分布、边界频率和区间覆盖。相反，如果每次都精确返回真值，倒应怀疑程序是否错误地复用了生成参数。

模拟中的参数恢复失败也需要区分来源。有限小样本导致宽分布是统计信息不足；系统性偏差可能来自估计准则或边界；不同初值停在不同目标函数可能是优化问题；得到完全错误的协方差模式则可能是设计或索引错误。保留每一重复的状态与诊断，有助于定位，而不是只报告一个平均误差掩盖失败样本。

估计完成后, 进行与目标一致的验证和敏感性分析。改变合理的固定效应、残差结构或关键先验, 观察方差解释和预测是否稳定。对已知异常批次, 可比较包含、校正和排除的结果, 但不能按是否得到期望结论来决定最终保留方案。资料处理原则应具有可说明的测量或设计依据。

最后报告估计值、单位、标准误或区间、协方差参数化、算法与收敛标准、边界和识别问题, 以及结果对预测的实际影响。附带可运行的小型教学脚本, 能够帮助读者核验公式尺度; 完整生产数据如不能公开, 也应提供足够的设计描述和计算版本。可复现不等于必须暴露受限制个体资料, 而是让合法获得同类数据的人能够理解并重建分析逻辑。

分层残差检查尤其应避免循环论证。某组残差较小, 可能因为该组拟合了更多参数、拥有较强亲属信息或随机效应收缩不同, 并不立即意味着真实环境方差较小。应使用与模型杠杆和预测误差相适应的诊断, 或比较模型下模拟资料的同类统计量。对于遗传趋势, 还应同时绘制出生年固定环境、记录完整度和基因型选择比例, 防止把资料组成改变误读为方差随年代变化。

方差参数的更新频率也是实施问题。每次新增少量记录都重新估计, 可能增加计算负担并使发布尺度波动; 长期固定参数, 又可能忽视群体与环境变化。可以预先制定定期重估规则, 并通过代表性窗口检查参数、预测校准和目标排序。更新应由资料积累与明确诊断触发, 不能只因为某次新估计更符合期望。对外发布时记录参数版本, 才能区分新增表型、关系更新和方差重估分别造成的改变。

23.18 非线性协方差参数化中的完整曲率

方差优化中, 得分可以通过一阶链式法则转换, 观察信息却还包含二阶变换项。这个差别在对数方差、相关系数以及协方差因子参数化中很重要。如果把线性方差组分的平均信息公式照搬到所有坐标, 迭代可能仍能运行, 但其结果已不再等于所声称的观察与期望曲率的平均。把完整推导写清, 可以区分数学定义、数值近似与最终标准误所需的信息。

固定设计 X 的列空间保持不变, 记 $V_i = \partial V / \partial \theta_i$ 、 $V_{ij} = \partial^2 V / (\partial \theta_i \partial \theta_j)$,

并用前文定义的 Q 消除固定均值。限制似然得分为

$$s_i = \frac{1}{2} \{y' Q V_i Q y - \text{tr}(Q V_i)\}.$$

因为 $dQ = -Q(dV)Q$, 对得分再次求导时, 既要两个 Q 求导, 也要对中间的 V_i 求导。将负导数整理为观察信息, 得到

$$\begin{aligned} \mathcal{J}_{ij} = & y' Q V_i Q V_j Q y - \frac{1}{2} \text{tr}(Q V_i Q V_j) \\ & - \frac{1}{2} \{y' Q V_{ij} Q y - \text{tr}(Q V_{ij})\}. \end{aligned}$$

第一个二次型在标量意义下对两个参数对称, 因为转置后交换次序但标量不变。最后一行是非线性协方差参数化特有的项; 若 V 对参数线性, 它才严格消失。取期望时, 利用 $QX = 0$ 和 $QVQ = Q$, 最后一行期望为零, 所以期望信息仍为

$$\mathcal{J}_{ij} = \frac{1}{2} \text{tr}(Q V_i Q V_j).$$

因此真实的观察与期望信息平均, 在一般非线性参数化下为

$$\begin{aligned} \frac{\mathcal{J}_{ij} + \mathcal{J}_{ij}}{2} = & \frac{1}{2} y' Q V_i Q V_j Q y \\ & - \frac{1}{4} \{y' Q V_{ij} Q y - \text{tr}(Q V_{ij})\}. \end{aligned}$$

Gilmour、Thompson 与 Cullis (1995) 的平均信息方法在方差组分线性表示下具有特别简洁的形式。对于非线性结构, 实际算法可以选择保留部分曲率、采用期望信息或使用其他正定近似, 但应说明使用的究竟是哪一个矩阵。一个方便求解的近似矩阵, 并不自动等于用于标准误的精确信息。

设原参数为 θ , 新坐标为 ϕ , 雅可比为 $D_{ia} = \partial \theta_i / \partial \phi_a$ 。直接由链式法则可得

$$\begin{aligned} s_\phi &= D' s_\theta, \quad \mathcal{J}_\phi = D' \mathcal{J}_\theta D, \\ \mathcal{J}_{\phi,ab} &= (D' \mathcal{J}_\theta D)_{ab} - \sum_i s_i \frac{\partial^2 \theta_i}{\partial \phi_a \partial \phi_b}. \end{aligned}$$

在内部驻点, 所有得分为零, 观察信息可以仅按雅可比变换; 在一般迭代点或边界附近, 不能省略最后一项。很多导数检查只在最优点进行, 恰好

会掩盖这种错误。应至少选一个得分明显非零的合法内部点，同时比较解析得分与中心差分曲率。

独立教学例：一个正态误差对比。设误差对比为二，方差写成 $v = \exp(\phi)$ ，当前取 $v = 1$ 。关于对数方差的对数似然为 $-\frac{1}{2}\{\phi + 4e^{-\phi}\}$ ，所以得分为一点五、观察信息为二、期望信息为二分之一，真正的二者平均为一点二五。若先在方差坐标中求观察信息，得到三点五，再仅乘雅可比平方，就会误报三点五；减去得分乘二阶变换的一点五后，才恢复为二。

这个反例没有复杂遗传关系，因而可以作为所有参数化实现的最小检查。它也说明观察信息可能与期望信息相差很大，因为当前观测的平方波动远离模型期望。若只有少量独立对比，单次观察曲率不必稳定；数值上选用期望信息有时更平滑，却不增加真实样本信息。对极小样本，轮廓形状通常比只读一个局部曲率更有解释价值。

23.19 消除干扰方差后的有效信息

一个方差参数看似有很尖的似然切片，却可能在允许其他参数重新调整以后变得很不确定。其原因可以用信息矩阵的舒尔补准确表达。设感兴趣参数为 ψ ，其余干扰参数为 λ 。在正则内部区域，将期望信息分块为

$$\mathcal{I} = \begin{bmatrix} \mathcal{I}_{\psi\psi} & \mathcal{I}_{\psi\lambda} \\ \mathcal{I}_{\lambda\psi} & \mathcal{I}_{\lambda\lambda} \end{bmatrix}.$$

把关于干扰参数的得分贡献线性投影出去，得到有效得分

$$s_{\psi\cdot\lambda} = s_{\psi} - \mathcal{I}_{\psi\lambda} \mathcal{I}_{\lambda\lambda}^{-1} s_{\lambda}.$$

它与干扰得分不相关，方差为

$$\mathcal{I}_{\psi\cdot\lambda} = \mathcal{I}_{\psi\psi} - \mathcal{I}_{\psi\lambda} \mathcal{I}_{\lambda\lambda}^{-1} \mathcal{I}_{\lambda\psi}.$$

减去的部分正是参数之间能够互相补偿的局部信息。对于一个标量目标，估计方差的常规近似是有效信息的倒数，而不是单独拿原矩阵对角元求

倒数。若两参数高度相关，忽略非对角元会明显低估不确定性；若干扰信息本身奇异，则应先处理识别问题，不能把普通逆换成任意小正数后继续宣称获得常规标准误。

总体尺度与协方差形状提供一个特别清楚的例子。在包含 m 个独立误差对比的空间里，写 $V_z = e^\eta B(\psi)$ ，其中 η 是对数尺度。用 B 白化后，形状的局部导数为 $D = B^{-1/2} B_\psi B^{-1/2}$ 。对数尺度的导数方向是单位矩阵，因此

$$\mathcal{I}_{\eta\eta} = \frac{m}{2}, \quad \mathcal{I}_{\eta\psi} = \frac{1}{2} \text{tr}(D), \quad \mathcal{I}_{\psi\psi} = \frac{1}{2} \text{tr}(D^2).$$

消去尺度以后，形状信息只剩去平均后的矩阵方向：

$$\mathcal{I}_{\psi\cdot\eta} = \frac{1}{2} \text{tr} \left[\left(D - \frac{\text{tr}(D)}{m} I \right)^2 \right].$$

若形状变化只是把所有特征方差乘以同一个比例， D 与单位矩阵成比例，有效信息为零，因为所谓形状变化与总体尺度完全相同。这个结论把协方差可识别性转化为一个几何事实：能够被尺度吸收的方向，不再提供独立形状信息。

独立教学例：固定尺度产生过度乐观的形状精度。设三个独立对比的协方差为 $s \text{diag}(1, 1 + \psi, 1 + 3\psi)$ ，在 $\psi = 1$ 处，白化形状导数对角为零、二分之一和四分之三。于是尺度已知时的形状信息为 $13/32 = 0.40625$ ；尺度未知时，需要减去 $25/96$ ，有效信息变为 $7/48 = 0.145833$ 。对应局部标准误分别约为一点五六九和二点六一九。

三个对比的例子本来就很少，局部正态近似不宜当成精确区间；它的目的，是展示同一个参数在两种条件下为什么会得到截然不同的精度。实际分析若画固定残差方差的曲线，只能称为切片。真正的轮廓曲线应在每一点重新估计尺度及其他干扰参数，否则看见的尖峰可能主要来自人为禁止补偿。

设计改进也可以围绕有效信息进行。增加所有方向完全相同的高精度重复，有利于估计尺度，却不一定改善形状；补充新的时间间隔、亲属关系或跨性状配对，可能改变 D 的特征方向，从而更有效地分离相关或方差比。把测定数目与信息方向一起考虑，才能理解为什么某些规模较小但结构多样的设计，对复杂协方差更有价值。

信息正交也可以用来选择报告参数。如果两个原始方差的估计高度负相关，而它们的和与比例相对更容易解释，可以把结果转换为总体尺度和分配比例，同时保留相应联合区间。变换不会使数据更丰富，却可能把资料真正支持的方向显示出来。例如总方差被估得很准、遗传比例区间很宽时，只报两个方差的点估计会掩盖最重要的结果：观测变异已经相当清楚，遗传归属仍不确定。这个结论对后续试验很有指导性，意味着应增加能区分遗传与环境的关系结构，而不是只继续增加同一类型的记录。

还应注意，有效信息依赖当前参数位置。同一个设计在遗传方差很小时可能难以识别相关，在遗传方差较大时则有明显信息。设计阶段通常不知道真实参数，可以选择若干科学上合理的位置，检查最弱方向是否在整个范围都保持可接受。若只在某个最有利参数点最大化信息，实际试验可能遭遇远低于预期的精度。参数情景的范围应说明依据，不应从已经观察的显著结果反向挑选。

23.20 方差边界的有限样本实验

零方差边界常被简化成“似然比服从一半零点质量加一半卡方”。这个结论需要渐近正则条件，在有限样本中，甚至最简单的单方差实验也不一定恰好有一半估计落在零点。通过一个具有精确分布的小模型，可以看清边界、样本信息与参考分布之间的关系，而不依赖软件输出的默认概率。

设经过均值消除后，有 m 个独立正态对比 z_j ，其方差为 $v = r + \theta$ ，其中残差基准 $r > 0$ 已知，新增方差 $\theta \geq 0$ 。本节把 r 视为确实已知；如果它也未知且没有其他结构提供信息，就只能识别总方差，以下单参数检验不再成立。记 $S = \sum_j z_j^2$ ，对数似然为

$$\ell(\theta) = -\frac{1}{2} \left\{ m \log(r + \theta) + \frac{S}{r + \theta} \right\} + C.$$

无约束最优总方差为 S/m ，所以约束估计及零点得分为

$$\hat{\theta} = \max \left(0, \frac{S}{m} - r \right), \quad s(0) = \frac{1}{2} \left(\frac{S}{r^2} - \frac{m}{r} \right).$$

当 $S \leq mr$, 从零向合法正方向移动不能提高似然, 边界就是最优点; 无需求边界得分恰好等于零。令 $x = S/(mr)$, 似然比统计量为

$$D = \begin{cases} 0, & x \leq 1, \\ m(x - 1 - \log x), & x > 1. \end{cases}$$

零假设下 S/r 精确服从自由度为 m 的卡方分布, 因此零点质量为 $P(\chi_m^2 \leq m)$ 。它随自由度变化, 并非固定二分之一。随着独立对比数增加, 中心化平方和趋于对称正态, 才出现熟悉的半质量极限。Self 与 Liang (1987) 的非标准似然理论解释了边界为何改变常规参考分布, 但具体有限样本实验仍应根据自身结构判断。

独立教学例：四个对比的边界检验。取 $m = 4$ 、 $r = 2$, 观察到平方和十六。则新增方差估计为二, $x = 2$, 似然比为

$$D = 4(1 - \log 2) = 1.227411.$$

零假设下, 超过这一正值阈值与 $\chi_4^2 \geq 8$ 等价, 精确尾概率约为零点零九一五八。采用半零点质量、半一自由度卡方的渐近近似, 则尾概率约为零点一三三九六。二者差异来自样本小与分布偏斜, 不是两套程序算错了同一个概率。本例零方差估计的精确概率约为零点五九三九九, 也清楚地偏离二分之一。

若同样四个对比的平方和为六, 约束估计落在零点, 但这不表示已证明新增方差不存在。小样本下很多正方差也可能产生较小平方和; 判断能够排除多大的正值, 需要上限或完整轮廓。边界点估计与上限精度应同时报告, 尤其不能把打印为零的小数解释成生物学效应永久消失。

多随机效应的边界会更复杂。例如检验一个二维遗传协方差矩阵中第一方差为零时, 正半定约束同时迫使相关协方差为零; 相关系数在该零方差处本身也失去定义。此时并不是“一个普通参数等于零, 其余参数照常”的实验。若有多个边界方向、弱识别或零假设下不存在的相关参数, 不能未经推导就继续套同一混合比例。

参数自助法能够在指定零模型与实际设计下校准统计量,但每次模拟必须重新完成零模型与备择模型的约束拟合,包括边界上的干扰参数重估。若把备择模型拟合固定在原始数据得到的某个局部解附近,模拟分布可能只反映优化路径。可检查多初值一致性和模拟边界频率,同时清楚说明校准仍以所指定的零协方差与均值模型为条件。

23.21 经验预测的参数敏感度与附加误差

已知方差下的预测误差并不自动包含方差估计的代价。要把这项代价算得更清楚,可以先求预测对参数的导数,再区分哪些随机性来自训练资料,哪些来自外部参数估计。Kackar 与 Harville (1984) 系统研究了混合模型固定与随机效应估计标准误的近似;这里用隐式微分展示敏感度怎样从原方程获得,并用独立校准参数的例子说明一阶误差传播的含义。

设经可识别约束处理后的混合模型方程为 $M(\theta)b(\theta) = r(\theta)$, 其中 b 同时含固定效应估计与随机效应预测。对第 j 个参数求导,不需要显式求整个逆矩阵,而只需解同一个左端矩阵的新右端:

$$M \frac{\partial b}{\partial \theta_j} = \frac{\partial r}{\partial \theta_j} - \frac{\partial M}{\partial \theta_j} b.$$

令真实目标为 $H = h'b_{true}$, 其中 b_{true} 收集真实固定效应与随机效应;在指定参数下的预测为 $\tilde{H}(\theta) = h'b(\theta)$ 。预测的参数敏感度为 $j'_H = h' \partial b / \partial \theta'$ 。在给定资料下,若参数估计误差协方差近似为 Ω , 局部传播项为

$$Var_{\theta}\{\tilde{H}(\hat{\theta})\} \approx j'_H \Omega j_H.$$

这个量首先描述固定当前资料时,参数扰动如何改变预测。要把它直接加到频率均方误差上,还需处理预测误差与参数估计误差之间的交叉项。一般分解为

$$\begin{aligned} E\left[(\hat{H} - H)^2\right] &= E\left[(\tilde{H} - H)^2\right] \\ &\quad + E\left[(\hat{H} - \tilde{H})^2\right] \\ &\quad + 2E\left[(\tilde{H} - H)(\hat{H} - \tilde{H})\right], \end{aligned}$$

其中 $\tilde{H}$ 使用真实参数, $\hat{H}$ 使用估计参数。最后一项是否为零依赖模型与估计规则, 不能在一般情形下默默删掉; 同一小样本中估计的方差与极端表型常相互依赖。某些正态混合模型与适当不变估计规则具有更强的正交性质, 但这些条件应由理论确认。

独立教学例：外部校准的遗传方差。 设 $y = u + e$, 真实遗传方差为四、残差方差为六, 均值已知。方差估计来自与这一动物及记录独立的校准实验, 只代入遗传方差 t , 预测系数为

$$k(t) = \frac{t}{t+6}, \quad k'(4) = \frac{6}{10^2} = 0.06.$$

真实参数预测为 $0.4y$, 误差方差二点四, 且其预测误差与 y 不相关。由于校准实验独立, 任意估计系数 $\hat{k}$ 与当前记录独立, 故交叉项精确为零, 并有

$$\text{MSE}(\hat{k}y) = 2.4 + 10\text{E}\left[(\hat{k} - 0.4)^2\right].$$

若外部遗传方差估计近似无偏、方差为一, 局部近似给出系数误差平方均值 0.06^2 , 附加误差约为零点零三六, 总误差约二点四三六。这是重复校准实验与重复个体记录的平均误差。若当前观察恰为五, 固定该记录时预测对参数的导数为零点三, 参数传播方差近似零点零九; 它与前一个平均附加误差不同, 因为一个固定了当前资料, 另一个对资料一起平均。

这个例子还展示了“参数估得不准”不能简单转换成给所有动物同加一个常数。预测对参数的导数依赖资料值与信息结构, 家系信息、母体协方差或社会方向的变化会以不同方式影响不同动物。对于一个候选者差值, 应先对差值求导, 或使用两者敏感度的协方差; 分别计算两个附加方差后相加, 可能遗漏共同参数扰动在差值中的抵消。

当参数靠近零边界, 线性泰勒近似可能失效, 因为估计分布偏斜、带点质量, 甚至某个随机效应维度会消失。此时适当的参数自助法或完整后验积分通常更有解释力。每次重复都要重新估计参数与预测, 保留同样的约束规则, 才能传播经验评定流程本身的不确定性; 只围绕最终育种值加正态噪声不能替代这一过程。

隐式微分还有一个实施边界：方程的可识别坐标必须在扰动前后保持一致。若一次扰动把某个方差压到零并删除相应随机效应，或者改变了固定效应约束，不能简单把两次解逐坐标相减称为导数。应先在共同目标空间比较，或者承认目标函数在边界处只能作单侧变化分析。对近奇异方程，即使原预测目标稳定，冗余系数的导数也可能极大；因此敏感度应优先报告经济目标、个体差值或其他可解释线性函数。

可用独立有限差分检查目标导数：在合法内部点分别向两侧轻微改变一个参数，每次完整重解方程，再计算目标差值。解析导数与差分一致，只证明局部实现正确；若沿更大合理参数范围出现明显弯曲，则一阶传播仍不足够。把局部误差近似与范围敏感性结合，既能减少盲目模拟的成本，也能识别哪些候选者或目标最需要完整积分。

23.22 一个可精确积分的方差后验实验

后验积分并不总需要复杂采样。一个共轭小模型能够精确展示“代入方差”“对方差积分”与“预测未来记录”三者的区别。设同一个潜在效应 u 有 n 次独立记录 $y_j = u + e_j$ ，给定公共尺度 s^2 ，残差服从方差为 s^2 的正态分布；效应先验为 $u | s^2 \sim N(m_0, s^2/\kappa_0)$ ，其中 $\kappa_0 > 0$ 。这规定了效应与残差的方差比，不是同时自由估计两种方差的普通动物模型。

尺度采用逆伽马先验，其密度明确写成

$$p(s^2) \propto (s^2)^{-(a_0+1)} \exp\left(-\frac{b_0}{s^2}\right), \quad a_0, b_0 > 0.$$

将记录平方和与先验平方项配方，得到

$$\begin{aligned} \kappa_n &= \kappa_0 + n, & m_n &= \frac{\kappa_0 m_0 + \sum_j y_j}{\kappa_n}, \\ a_n &= a_0 + \frac{n}{2}, & b_n &= b_0 + \frac{1}{2} \left(\sum_j y_j^2 + \kappa_0 m_0^2 - \kappa_n m_n^2 \right). \end{aligned}$$

于是 $s^2 | y$ 仍为逆伽马分布，参数为 a_n, b_n ；给定尺度， $u | s^2, y$ 为均值 m_n 、方差 s^2/κ_n 的正态分布。积分掉尺度，得到自由度为 $2a_n$ 的学生分布，

其位置与尺度平方为

$$u | y \sim t_{2a_n} \left(m_n, \frac{b_n}{a_n \kappa_n} \right).$$

这里第二个参数表示学生分布的尺度平方，并非方差。若 $a_n > 1$ ，真实后验方差为

$$\text{Var}(u | y) = \frac{b_n}{(a_n - 1) \kappa_n}.$$

独立教学例：两次记录产生的厚尾后验。取记录二与四，先验位置零， $\kappa_0 = 1$ 、 $a_0 = 2$ 、 $b_0 = 2$ 。计算得 $\kappa_n = 3$ 、 $m_n = 2$ 、 $a_n = 3$ 、 $b_n = 6$ 。效应后验为位置二、尺度平方三分之二的六自由度学生分布，方差为一。尺度后验众数为一点五，若只代入众数，效应条件方差为二分之一，明显低于积分后的方差。

本例尺度后验均值为三，将这个均值代入条件方差恰好得到一。这不是所有模型都可以用平均参数替代积分的证明，而是因为条件均值 m_n 不随尺度变化、条件方差又对尺度线性。尽管方差数值恰好相同，单一正态分布仍没有学生分布的厚尾。决策依赖极端阈值时，仅匹配均值和方差不足以保证尾概率正确。

未来一次记录还含新的残差，其后验预测尺度平方为 $b_n (1 + 1/\kappa_n) / a_n$ ，因此

$$y_* | y \sim t_6(2, 8/3), \quad \text{Var}(y_* | y) = 4.$$

效应方差一与未来记录方差四回答的是不同问题。若把前者发布为下一次生产表现的全部预测误差，就漏掉未来环境；若把后者当作育种值不确定性，又会把不可传递的新残差全部算进遗传评价。

后验适定也不能消除数据的结构性不足。假设另一模型只识别总方差 τ ，分配比例为 ω ，且先验分解为 $p(\tau)p(\omega)$ 。因为似然只依赖总和，联合后验满足

$$p(\tau, \omega | y) \propto p(y | \tau) p(\tau) p(\omega), \quad p(\omega | y) = p(\omega).$$

一个平滑、有限且看似集中的比例后验，仍可能完全来自先验。应检查更新前后分布，而不只展示最终后验图。若先验把总方差与比例关联起来，

数据可通过总方差间接改变比例后验，但那条信息路径依旧依赖先验关联；不能把它说成观测已单独辨认遗传与环境来源。

23.23 协方差失配时得分平衡意味着什么

方差估计得到零得分，只表示指定协方差族在当前资料上达到平衡。若真实模型不在这一族中，所估参数可能是某种最接近的替代结构，未必对应各个生物学方差。把得分的期望在失配情形下展开，可以看到遗漏均值与遗漏协方差怎样进入同一估计过程，也能解释为什么残差看起来正常仍不足以验证遗传分解。

设拟合模型采用均值 $X\beta$ 、协方差 V ，真实均值额外含偏移 δ ，真实协方差为 V_* 。对方差方向 V_i ，二次型期望给出

$$E_*(s_i) = \frac{1}{2} \text{tr}\{QV_iQ(V_* - V)\} + \frac{1}{2} \delta' QV_iQ\delta.$$

第一项是协方差差异在该可见方向上的投影，第二项是遗漏均值形成的额外平方波动。当所有拟合方向的期望得分均为零时，只能说明真实差异与这些方向正交，不能推出 $V_* = V$ 。有限模型族可以同时遗漏多个无法由现有方向检测的结构。尤其是 $Q\delta = 0$ 的偏移落在固定均值空间中，限制似然本身无法借残差对比识别它。

即使均值正确，失配下得分波动也不再等于正确模型的期望信息。在正态真实模型下，且 $Q\delta = 0$ 时，二次型协方差为

$$\text{Cov}_*(s_i, s_j) = \frac{1}{2} \text{tr}(QV_iQV_*QV_jQV_*).$$

在具有足够独立重复单位的正则估计问题中，可以用平均负得分导数与得分协方差构造夹心形式的参数误差近似。但这种修正主要改变不确定性描述，不会把一个错误的生物学分解变成正确分解。若缺少独立家系或群组，夹心矩阵本身也可能估得不稳，不能把“稳健标准误”当成所有模型问题的补救。

独立教学例：共同环境被自由均值掩盖。四条记录共享一个未知总体均值，真实协方差为方差四、组内相关二分之一的等相关结构，即

$$V_* = 2I + 2\mathbf{1}\mathbf{1}'.$$

若误拟合为独立同方差模型 vI ，限制似然估计为 $\hat{v} = y'Jy/3$ 。由于 $J\mathbf{1} = 0$ ，有

$$E_*(\hat{v}) = \frac{\text{tr}(JV_*)}{3} = 2.$$

残差方差估计会稳定地指向独立部分二，而共同环境完全被均值方向消去。拟合模型给总体均值的方差约为二除以四，即二分之一；真实均值方差却为

$$\text{Var}_*(\bar{y}) = \frac{1}{16}\mathbf{1}'V_*\mathbf{1} = 2.5.$$

两者相差五倍。增加同一群内记录时，独立残差平均的误差继续下降，但共同环境的不确定性不会消失；只有增加适当的独立群、对照或外部基准，才可能估计这部分。一个群内非常整齐的残差图，不能检验已经被总体均值吸收的共同波动。

这个例子也提醒我们区分固定场效应的条件推断与跨场推广。若只关心本次特定场内的动物差值，共同环境可能在差值中抵消，独立部分确实是主要误差；若关心未来场的绝对平均表现，遗漏共同环境就严重低估风险。因此同一个简化协方差模型，对某个差值目标可能可用，对跨群绝对目标却不合适。模型评价需要围绕发布的具体目标，而不能仅根据一个总体拟合分数决定适用范围。

在实证分析中，可以沿着参数解释最依赖的路径安排检查：母体来源需要跨母亲亲缘与跨窝比较，社会来源需要分群与接触结构，纵向相关需要不同时间间隔，跨场推广需要独立环境信息。得分、曲率与残差诊断为这些检查提供量化入口，但最终仍要回答同一个问题：现有资料究竟在哪些对比中看见了所宣称的遗传来源，哪些结论仍由不可检验的模型条件承担。

23.24 练习与详解

练习 1: ML 与 REML。五条独立正态记录的样本平均已从资料估计, 残差平方和 20。分别求方差的最大似然与限制最大似然估计。若均值真由外部完全确定, 且对应平方和仍为 20, 分母如何变化?

解答。未知均值情形, ML 为 4, REML 为 5。外部已知均值时没有估计均值占用的方向, 通常似然方差估计为 4。不能因为样本平均等于外部均值就把未知均值模型当作已知均值模型; 关键是分析前是否把均值作为未知参数估计。对于一般秩为 p 的同方差固定设计, REML 分母为 $n - p$ 。

练习 2: 平衡方差分解。四组、每组三条, 组内平方和 24、组间平方和 30。求无约束的组方差与残差方差, 并说明两个估计分别依赖哪类对比。

解答。组内自由度为 8, 均方 3; 组间自由度为 3, 均方 10, 因此组方差为 $(10 - 3)/3 = 7/3$ 。组内对比消去共享组效应, 估计残差; 组间对比包含组差异及组平均残差, 扣除后者后识别组方差。若组数保持四个却继续增加每组记录, 残差可以更精确, 但组间信息仍受少数组数限制。

练习 3: 边界重新优化。三组各两条, 记录均为 (4, 6)。无约束组方差为多少? 约束为零后的 REML 残差方差是多少? 为什么不能保留原组内均方?

解答。组内平方和 6、均方 2, 组间均方 0, 所以无约束组方差为 -1。零组方差模型有六条记录与一个未知均值, 残差估计为 1.2。约束使组间与组内方向共享同一残差方差, 必须利用全部五个残差方向重新最优化。原组内均方 2 只使用三个方向, 未利用零组方差条件新增的共同尺度信息。

练习 4: 残差算子。解释为什么一般的 Q 满足 $QVQ = Q$, 却不必满足 $Q^2 = Q$ 。在 $V = 2I$ 且仅含截距时, 写出 Q 与普通残差投影 M 的关系。

解答。 Q 是协方差加权的精度算子, 白化后对应普通投影, 因此组合中需要插入 V 才恢复幂等结构。在本例 $Q = M/2$, 所以 $Q^2 = M/4 = Q/2$, 并非 Q ; 但 $QVQ = (M/2)(2I)(M/2) = M/2 = Q$ 。误用欧氏幂等性会使得分期望和信息推导的尺度错误。

练习 5: 得分期望。对正确模型, 证明 $E(y'QV_kQy) = \text{tr}(QV_k)$ 。说明固定均值若遗漏重要项, 推导中哪一步不再成立。

解答。二次型期望等于 $\text{tr}(QV_k QV) + (X\beta)' QV_k Q(X\beta)$, 后一项因 $QX = 0$ 为零; 前一项用迹循环与 $QVQ = Q$ 化简为目标。若真实均值不在 X 列空间, 均值二次型可能不为零, 方差得分会吸收一部分系统均值偏离。因此正确估计随机变异依赖合理的均值结构。

练习 6: 参数变换。某方差 $\theta = 4$, 原参数得分为 0.3。若改用 $\phi = \log \theta$, 新得分是多少? 若原期望信息为 2, 新期望信息在一维局部变换下是多少?

解答。新得分为 $\theta s = 1.2$, 期望信息按雅可比平方变换为 $\theta^2 \mathcal{I} = 32$ 。观察二阶导数还可能包含得分与变换二阶导数相关的项, 不能把期望信息的简单变换一律当作观察 Hessian。参数化改变数值步长尺度, 但不应改变同一合法协方差模型的似然最大值。

练习 7: 遗传力 delta 方差。遗传方差估计 3、残差 7, 其估计协方差矩阵为对角元 0.5 与 1、交叉元 -0.2 。求遗传力的近似标准误。

解答。遗传力 0.3, 梯度为 $(0.07, -0.03)'$ 。近似方差为 $0.0049 \times 0.5 + 0.0009 + 2(0.07)(-0.03)(-0.2) = 0.00419$, 标准误约 0.0647。交叉项为正, 因为梯度方向相反而估计协方差为负。这个近似建立在内部正则情形, 不应用于方差接近零且分布强烈偏斜时的精确概率解释。

练习 8: 切片与轮廓。为研究母体方差, 将它固定为不同值, 却始终保留直接与残差方差为原最优估计。这能否称为轮廓似然? 会怎样影响不确定性判断?

解答。这只是似然切片。真正轮廓需要在每一个固定母体方差值下重新优化其余参数。其他来源可能补偿母体方差改变, 所以轮廓的下降通常不会比固定其他参数的切片更快。使用切片作为轮廓可能夸大曲率、低估可接受参数范围, 尤其在直接与母体来源高度混淆时。

练习 9: 结构识别。所有动物无亲缘、每只两次记录, 模型含动物遗传、个体永久环境与独立残差。哪些组合能够被资料识别? 增加每只记录到十次能否分开前两项?

解答。重复记录可以区分持续个体差异总和 $\sigma_u^2 + \sigma_p^2$ 与独立残差, 但遗传与永久环境设计相同, 无法分别识别。增加重复次数提高总和与残差的精

度，仍不能产生跨个体遗传协方差。需要亲属或合适基因组连接，或明确外部信息，才能支持进一步分解。

练习 10：逆伽马更新。采用本章密度参数化，先验为 $IG(3,4)$ ，给定均值与随机效应后六个独立残差平方和为 16。求后验分布、均值与众数。

解答。后验为 $IG(6,12)$ ，均值为 $12/(6-1) = 2.4$ ，众数为 $12/(6+1) = 1.7143$ 。二者不同并非计算误差，而是后验偏斜。若软件的第二参数定义为逆尺度，输入 12 会产生另一分布，必须核对密度约定。若均值没有给定，需将其不确定性按联合模型处理。

练习 11：混合后验。两个方差情景的后验权重为 0.25 与 0.75，对某育种值的条件均值为 0 与 4，条件方差为 1 与 3。求总体均值与方差。

解答。总体均值为 3。平均条件方差为 2.5，条件均值方差为 $0.25(0-3)^2 + 0.75(4-3)^2 = 3$ ，总体方差为 5.5。只采用权重较大情景的方差 3，或只平均条件方差 2.5，都遗漏参数情景带来的部分不确定性。若关心尾部概率，应直接对两个条件分布加权。

练习 12：收缩值平方。四个独立随机效应的条件均值为 -2, -1, 1, 2，条件方差均为 1.5。求平方和的条件期望，与单纯均值平方和比较。

解答。条件均值平方和为 10，条件方差总和 6，故真实随机效应平方和的条件期望为 16。仅使用预测值会遗漏未被数据确定的变异。这个恒等式帮助理解 EM 的迹修正；它本身不决定某个 REML 算法的完整分母，后者仍取决于固定效应处理与所用完整数据表示。

练习 13：边界检验。检验一个随机斜率方差为零时，原模型还含截距—斜率相关。为什么不能简单说新增两个参数，所以似然比服从两自由度卡方？

解答。零斜率方差位于非负边界，且在该零假设下斜率与截距的相关没有常规定义。普通内部、可识别、光滑参数空间的正则条件不成立。应使用与具体模型对应的非标准理论、恰当模拟或其他有效方法，而不是把参数个数直接当作自由度。即便某些简单方差检验使用混合卡方，其混合结构也不能普遍照搬。

练习 14：先验与数据证据。一个模型的似然只依赖两个方差之和，加入

强先验后各方差后验区间很窄。能否说资料已经精确分离两个来源？应怎样报告？

解答。不能。窄区间可能主要由先验约束产生。应说明资料识别的是总和，分配依赖哪些外部假设，展示少数合理替代先验下的结果，并优先报告对先验稳定的目标组合。贝叶斯方法可以合法地结合外部知识，但不能把外部知识的贡献误称为当前样本提供的证据。

练习 15：采样精度。两条后验链均值相似，但一条持续停在低遗传方差区域，另一条在高方差区域，且残差方向反向变化。只增加每条链最后一位输出精度能否解决问题？

解答。不能。问题可能是强后验相关、多模态或弱识别导致的混合不足，数字显示精度无关。应检查联合轨迹和目标函数，考虑参数化、分块更新与识别结构，并比较关键目标量的有效样本量。若数据只识别总和，重新采样也不会创造分量信息；可能需要改为报告可识别组合。

练习 16：固定效应模型比较。两个模型使用相同记录，一个含场年效应，另一个只含场效应。其 REML 值分别为 -100 与 -105 。能否据此直接作常规似然比检验并选择前者？

解答。不能。两个模型的固定效应空间不同，限制似然基于不同残差对比，绝对数值不能如此直接比较。可以在适当条件下使用普通最大似然、有效的固定效应推断或预先定义的预测验证，同时考虑场年混杂的科学必要性。模型中一个重要环境项即使预测增益不大，也可能是避免遗传趋势混杂所必需。

练习 17：模拟恢复的标准。用只有三组的设计模拟 1000 次，正确算法有一部分组方差估计为零。是否说明算法错误？怎样区分统计波动和计算失败？

解答。零边界可能是有限样本下合法的统计结果。应检查每次拟合的约束最优性、目标函数和状态，并在已知模型下分析偏差、边界频率与区间覆盖。若不同初值在同一模拟资料上得到显著不同目标函数，或返回非法协方差，则提示计算问题。把全部边界样本删除后再报告恢复精度，会人为制造

过于乐观的结论。

练习 18：把不确定性用于决策。两只候选者的目标均值分别 2.1 和 2.0，差值的后验标准差为 1。是否有充分依据声称第一只确定优于第二只？还需要什么信息？

解答。均值差只有 0.1，相对于差值不确定性很小，不能声称确定优越。若差值近似正态，优于概率约为 $\Phi(0.1) = 0.5398$ ；若分布非正态，应直接计算后验概率。最终选择还可结合成本、近交、多个候选者组合和长期目标。这里需要的是差值误差，不能把两只个体标准误独立相加而忽略其预测误差协方差。

方差推断最终应回到可验证的育种问题：资料支持哪些变异来源，尚未确定的部分有多大，它们会不会改变实际选择。把这三个问题和计算结果一起呈现，才能使精细的估计方法转化为透明而可更新的科学判断。

多性状、阈值、生存与纵向遗传模型

24.1 从单个数值走向相互关联的生命过程

一只动物的遗传价值很少能由一个时点的一条连续记录完整表达。生长、繁殖、健康和寿命彼此关联，同一性状也会随年龄、泌乳阶段和环境改变。某些记录是连续重量，某些是是否患病，某些是从出生到事件的时间，还有许多记录只在个体仍存活或仍被保留时出现。将这些资料都压成一个普通连续性状，会丢失信息，并可能把观察机制误作生物学差异。

本章沿着两条线索扩展混合模型。第一条是把多个性状或多个时点联合起来，以协方差描述信息如何相互借用；第二条是改变响应分布，使概率、类别和事件时间按照自身结构进入似然。二者可以结合：多性状模型可以同时含连续与二元响应，纵向轨迹可以与生存过程共享遗传效应。复杂性增加后，定义目标、识别尺度和尊重资料产生机制仍然是最重要的步骤。

需要先区分重复测量、多性状与函数性状。重复测量模型通常假定同一遗传效应在各次记录中以相同单位表达，持续个体环境也保持不变；多性状模型允许每个时点或性状有独立遗传分量，并估计它们的协方差；随机回归则用少数系数表达连续曲线，使相邻时点的关系具有平滑结构。三者代表不同假设，不是同一模型的不同名称。

选择模型的起点是科学问题。例如，若目标是提高整个泌乳期总产出，单次峰值不是充分目标；若目标是改善长期健康，期末无病与推迟发病时间也不完全相同；若目标是降低死亡风险，分析时把早死动物全部删去，会改变所研究的总体。只有先定义目标与时间原点，才能决定需要怎样的记录、协方差和似然。

本章所有数字均为教学构造。我们先用二性状和重复记录展示信息传递，再进入阈值与生存模型，最后将轨迹、曲线目标和不确定性连起来。每一步都尽量从低维可手算情形出发，使读者能判断复杂程序的输出究竟回答了哪个问题。

24.2 多性状动物模型的堆叠与协方差

设每只动物有两个潜在育种值 u_{1i}, u_{2i} ，群体遗传协方差矩阵为 Σ_u 。若先堆叠全部动物的性状 1 育种值，再堆叠性状 2，联合协方差为 $\Sigma_u \otimes A$ ；若按动物逐只堆叠两个性状，则为 $A \otimes \Sigma_u$ 。两种排列通过置换矩阵相联系，表达同一个模型。错误地把一种排列的设计矩阵与另一种排列的协方差搭配，会改变模型，而不只是改变计算效率。

第 k 个性状可写为 $y_k = X_k \beta_k + Z_k u_k + e_k$ 。不同性状可以有不同固定效应、不同记录数和不同观测个体。联合模型不要求每只动物所有性状都齐全；它要求我们清楚哪些观察存在，并为这些观察构建正确的设计与协方差子矩阵。缺失性状不能填零当作真实记录，因为零是一个数值，不是“未观察”的标记。

遗传协方差描述两个性状育种值共同变化，残差协方差则描述给定遗传和固定效应后，记录仍共同变化的部分。两个性状同时在同个体同一时段测量时，可能具有残差相关；如果分别在不同动物或不同时段测量，残差共享结构需要另行定义。不能仅因为两个性状名称不同就假设残差独立，也不能把所有跨性状记录都赋予相同残差协方差。

以完整同个体二性状记录为例，表型协方差为遗传与残差协方差之和。若加性方差分别为 4 和 9、协方差 2，遗传相关为 $2/\sqrt{4 \times 9} = 1/3$ 。即使残差协方差为零，表型相关仍受各性状残差方差影响，通常不同于遗传相关。育种目标的信息传递依赖遗传协方差，而观察记录的冗余程度依赖完整表型协方差，两者都进入预测公式。

Henderson 与 Quaas (1976) 的多性状评价工作将不同性状记录放入共同混合模型框架，提供了系统利用相关信息的方法。其优势不是把缺失性状

凭空补齐，而是依据群体协方差和亲缘连接，将已观察性状对目标育种值所包含的信息传递过去。若相关估计不稳定，这种信息借用也有不确定性，因此多性状模型未必在所有有限样本中都优于谨慎的简化模型。

在大规模分析中，记录顺序、动物顺序和性状顺序应明确保存。可选取一个拥有两性状记录的动物及一个只观察一性状的亲属，手工列出几项期望协方差，检查程序是否对应。对多性状模型而言，这种局部映射核验比单纯检查最终矩阵维数更有针对性。

24.3 二性状预测：缺失不等于没有信息

设均值已知为零，某个体遗传协方差为

$$\Sigma_u = \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix}, \quad R = \begin{bmatrix} 6 & 0 \\ 0 & 16 \end{bmatrix}.$$

若只观察性状 1，值为 5，则观察方差为 10。性状 2 育种值与该记录协方差为 2，因此预测为 $2 \times 5/10 = 1$ ，预测误差方差为 $9 - 2^2/10 = 8.6$ 。这个个体虽然没有性状 2 记录，仍获得一点信息；但可靠度仅为 $1 - 8.6/9 = 0.0444$ ，不能因为预测非零就认为评价已很准确。

教学例 24.1：增加第二性状记录。若两个记录都为 5，则表型协方差为 $V = \Sigma_u + R$ ，即对角元 10 和 25、交叉元 2。其行列式 246。联合预测为 $\hat{u} = \Sigma_u V^{-1}y$ ，计算得到两个育种值约为 2.1951 和 2.3984。误差协方差为 $\Sigma_u - \Sigma_u V^{-1}\Sigma_u$ ，对角约为 2.3415 与 5.5935，交叉为 0.7805。

与单独分析相比，新增记录不仅改善性状 2，也改善性状 1，因为两种育种值相关。可是在不同数据情形下，一个性状的高记录也可能通过残差相关改变另一个性状的校正方向；预测系数不一定全为正。解释系数时要同时考虑遗传协方差和记录之间的冗余，不能仅凭遗传相关为正就断言每一条相关记录的系数必定为正。

上述推导使用均值已知。实际场年、性别和年龄效应需要估计时，完整预测误差还要考虑这些估计的代价。两个性状如果在不同场测量，或某个性

状只在少数当代组有记录，跨性状借用可能与固定效应连接紧密相关。先中心化每个性状并把均值视为无误差，通常不足以替代联合模型。

遗漏某些性状的机制也很重要。若昂贵性状只在根据已记录生长成绩选出的动物上测量，完整保留生长资料并联合分析，在适当的可忽略选择条件下有助于处理选择；若只保留被选动物的两性状资料，选择所依赖的信息被截断，协方差估计可能改变。多性状模型需要相关记录本身，不能仅靠模型名称恢复已经丢失的数据。

联合目标 $H = a_1 u_1 + a_2 u_2$ 的误差为 $a' C_u a$ 。在本例中，等权重的误差约为 9.4960，差值的误差约为 6.3740。只相加两个边际误差会漏掉交叉项，也无法解释为什么同一组分量对不同目标具有不同精度。确定目标权重后再计算整体不确定性，是多性状选择与统计预测之间的必要连接。

24.4 多性状协方差的维度、降秩与缺失模式

若有 q 个性状，无结构对称遗传协方差需要 $q(q+1)/2$ 个参数；残差协方差还可能再增加同样数量。十个性状的一个协方差块就有 55 个参数，而不是十个。记录总数看似很大，也可能缺少某些性状配对的重叠与亲属连接，使相应协方差估计很弱。模型复杂度应与有效协方差信息匹配。

缺失模式决定哪些关系可估。例如性状 1 只在甲场测量、性状 2 只在乙场测量，且两场无亲缘连接，就难以区分跨性状遗传相关与群体差异。若有共享公畜或基因组连接，遗传协方差可能得到信息；同个体残差协方差却不能凭跨场亲属记录直接识别。不同协方差来源需要不同类型的重叠，不能用“有连接”一词笼统概括。

降秩模型可以将遗传效应写成少数潜在因子的线性组合，例如 $u_i = \Lambda f_i + \delta_i$ ，从而把协方差表示为 $\Lambda \Lambda' + \Psi$ 。它用较少参数概括共同遗传方向，也可能改善稳定性。但载荷与因子存在旋转或尺度不唯一，必须设置识别约束；因子名称应依据明确测量与外部证据解释，不能仅因载荷较大就给潜在方向赋予具体生物学机制。

特征分解同样可以展示主要遗传变化方向。大的特征值对应群体中较多

变异的组合，小特征值表示某些组合变化有限。保留主要方向是一种近似，是否合适取决于育种目标。若一个经济重要但变异很小的性状组合恰好落在被删除方向，简单按解释方差百分比截断就可能损害目标预测。统计方差大小与经济价值不是同一尺度。

协方差收缩与先验是另一种处理高维估计的方法，可以把极端相关向较温和结构收缩。其效果应通过预测、区间与敏感性分析验证，尤其要观察稀少性状是否被其他性状过度主导。联合模型借用信息是一种有条件的优势；当相关结构错误或群体差异未被处理时，也可能将错误信息传播到本来资料较好的性状。

多性状结果报告不应只给一张相关矩阵。还应说明性状定义、单位、样本与重叠数、固定效应、参考群体、残差共享规则，以及关键相关的不确定性。若多个性状其实是同一原始记录的确定变换，协方差可能奇异，应重新定义独立信息，而不是强行拟合一个满秩矩阵。

24.5 重复测量模型与重复力的含义

对于同一个体多次测量，可设 $y_{ij} = x'_{ij}\beta + u_i + p_i + e_{ij}$ ，其中 u_i 是加性育种值， p_i 是永久环境， e_{ij} 是每次独立残差。在最简同方差设定下，单条记录方差为 $\sigma_u^2 + \sigma_p^2 + \sigma_e^2$ ；同一个体两条记录协方差为 $\sigma_u^2 + \sigma_p^2$ 。遗传力与重复力分别为

$$h^2 = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_p^2 + \sigma_e^2}, \quad t = \frac{\sigma_u^2 + \sigma_p^2}{\sigma_u^2 + \sigma_p^2 + \sigma_e^2}.$$

重复力描述经过固定效应校正后个体之间持续差异的比例，包含遗传与非遗传来源；它不是准确度，也不是遗传力。用同一个字母表示重复力和时间时应避免歧义，本章时间通常写为 s 或在局部清楚声明。重复测量模型还隐含任意两次记录具有相同持续协方差，这对相隔一天与相隔数年的记录未必合理。

教学例 24.2：三次记录不能当成三只独立动物。 取遗传方差 4、永久环境 6、残差 10，总方差 20，遗传力 0.2、重复力 0.5。某动物三次校正记录平均偏差为 6，其平均记录方差为 $4 + 6 + 10/3 = 40/3$ 。育种值预测系数为

$4/(40/3) = 0.3$ ，预测为 1.8；可靠度为 $4/(40/3) = 0.3$ 。本例系数与可靠度数值相同，是该单一直接平均记录设定的结果。

如果错误地把永久环境也随次数平均掉，会使用 $4 + (6 + 10)/3$ ，得到更强的收缩保留和过高可靠度；如果进一步把每条记录当作互不相关、照搬单记录权重相加，则可能把预测算成 3.6。错误来源都是忽略持续个体环境。反之，预测该动物持续表现 $u_i + p_i$ 时，系数为 $10/(40/3) = 0.75$ ，预测 4.5。持续生产能力与可传递育种值并非同一个目标。

当记录次数趋于无穷，平均残差趋近零，但单靠该动物自身重复记录，遗传可靠度上限为 $\sigma_u^2 / (\sigma_u^2 + \sigma_p^2)$ 。本例上限 0.4。无限测量能够知道持续个体差异，却不能从同一个体内独自区分遗传与永久环境。亲属记录或其他遗传信息可以突破这个仅使用自身重复记录的限制。

重复次数不等还会引入观察机制问题。高产或健康动物可能被保留更久，拥有更多记录；记录次数因此包含生产者选择与健康过程的信息。若只比较平均值而忽略为什么某些个体停止记录，就可能产生幸存者偏差。纵向模型与生存模型的联合考虑，正是本章后半部分要解决的重要问题之一。

24.6 时间相关残差与不规则测量

永久环境随机截距使同一个体任意两次记录具有相同协方差，但很多短期冲击会随间隔增长而衰减。一次感染、饲料调整或仪器偏移可能连续影响附近几次测量，却不持续整个生命。若所有时间相关都由永久环境承担，模型可能高估持续性、误分遗传与环境，并低估某些局部变化的不确定性。因此纵向模型常需把长期个体效应与短期残差相关分开。

等间隔测量可以采用一阶自回归残差结构， $\text{Cov}(e_{ij}, e_{ik}) = \sigma_e^2 \rho^{|j-k|}$ ，要求 $|\rho| < 1$ 。这个表达中的距离是测量序号，只有在间隔相同或有明确离散过程解释时才合适。若两次相邻记录相隔一天与三个月都被赋予同样相关，就可能违背生物学含义。不规则时间可以考虑按实际间隔衰减，例如 $\sigma_e^2 \exp(-\phi |s_j - s_k|)$ 、 $\phi > 0$ 。

教学例 24.3：记录靠得太近，新增信息有限。两次测量仅含同一个持续

效应与残差, 残差方差为 10、相关 0.8, 则平均残差方差为 $10(1+0.8)/2 = 9$, 仅比单条的 10 略低; 若残差独立, 平均残差方差为 5。密集采集并不自动等于大量独立信息。传感器每分钟产生一条记录时, 数据存储规模和统计有效信息之间尤其需要区分。

若采用指数衰减, 取半衰间隔为 7 天, 则 $\phi = \log 2/7$ 。相隔 7 天的相关为 0.5, 相隔 14 天为 0.25, 相隔 1 天约 0.9057。参数的单位是天的倒数; 把时间改为周时应同步换算, 否则同一数值代表完全不同的持续性。对于状态变化突然或周期性强的过程, 单一指数也可能不足, 需要依据残差诊断选择结构。

遗传曲线与残差相关可能竞争解释平滑变化。若遗传随机回归阶数过高, 可能吸收短期噪声; 若残差过于自由, 也可能吸收真实的个体轨迹差异。亲属在不同时间的共同变化提供遗传识别, 同一个体短间隔的额外相关提供环境识别。设计中跨亲属与跨时间的覆盖, 比单纯增加一个个体极密集的记录更有助于分离这两类来源。

残差方差也可能随年龄、泌乳阶段或环境改变。可以分阶段设不同方差, 或用平滑函数描述尺度变化。过多小阶段会产生不稳定参数, 过粗分组又可能掩盖重要异质性。应检查每个阶段记录量、家系覆盖和测量误差, 再选择适度结构。高峰期方差较大不一定意味着遗传变异更大, 也可能仅仅是测量误差或环境敏感性增大。

24.7 二元阈值模型与潜在尺度识别

患病与否、受胎与否或是否存活到某个年龄, 是二元事件。线性模型可以作为近似, 但它的恒定残差方差与无界预测不完全符合概率结构。阈值模型假定一个连续潜在倾向 $\ell_i = x_i'\beta + z_i'u + e_i$, 当潜在值越过阈值时观察到事件。对于 probit 链接, 取 $e_i \sim N(0, 1)$ 并把二元阈值固定为零, 则事件概率为 $\Phi(x_i'\beta + z_i'u)$ 。

潜在尺度的单位无法仅凭二元观察同时确定。若把潜在均值、阈值和残差标准差共同乘以一个正数, 二元分类不变。因此必须固定一个尺度, 常见

做法是将残差方差设为 1；位置也要通过阈值或截距约束确定。这个固定是识别约定，不是实验发现所有疾病的残差方差恰好等于 1。跨论文比较潜在遗传方差前，应先核对链接和尺度。

Gianola 与 Foulley (1983) 将有序类别的公畜评价置于阈值框架中，推动了混合模型对离散响应的扩展。其基本贡献是把观测分类与潜在连续遗传结构联系起来，允许亲缘信息参与概率预测。与正态连续模型不同，边际似然需要对随机效应积分，通常不能通过一次线性方程直接得到完整解；线性化或后验近似的精度需要结合资料稀疏程度检验。

教学例 24.4：潜在改进不等于概率的固定增量。在阈值为零、残差方差 1 的设定下，潜在线性预测值为 0 时事件概率 0.5，提高到 0.5 时概率为 0.69146，增加约 0.19146。如果原值为 2，提高同样 0.5，概率从 0.97725 变为 0.99379，只增加约 0.01654。相同潜在遗传差异在不同基础风险群体中产生不同概率变化。

若潜在加性方差为 0.5 且没有其他随机来源，潜在遗传力为 $0.5/(0.5 + 1) = 1/3$ 。这不是观察到的零一记录方差中简单同样比例。观察尺度的遗传表达还依赖发生率、固定环境分布和所采用的近似定义。在低发生率性状中，潜在遗传力较大也可能对应很有限的观察尺度变异，不能直接与连续性状遗传力作数值排名。

疾病编码方向必须明确。如果 1 表示患病，正潜在育种值意味着更高患病风险，通常不是有利方向；如果 1 表示健康，则解释相反。发布时可以把符号转换为“越高越好”，但必须同时转换目标、概率表达与相关方向。一个没有说明编码方向的阈值育种值，对实际选择几乎没有可解释性。

24.8 阈值模型的似然、潜在抽样与稀少事件

给定随机效应，二元记录的似然贡献为 $p_i^{y_i} (1 - p_i)^{1-y_i}$ ，其中 $p_i = \Phi(\eta_i)$ 。遗传评价还需乘以随机效应分布并积分或进行后验推断。每条记录提供的信息取决于其概率位置，极端概率附近的观察通常对某些方向信息较弱；一个全部为零的小家系，既可能代表低风险，也可能只是事件稀少和样本不足。

潜在变量方法可在二元观察条件下抽样截断正态倾向。若 $y_i = 1$, 潜在值需大于阈值; 若为 0, 则小于阈值。给定这些潜在值, 效应更新类似正态混合模型; 但潜在值并非真实测量, 不能将其后验均值当作新增独立表型再次分析。它们是计算中引入的未观测变量, 所有不确定性需在联合模型内传递。

Albert 与 Chib (1993) 的数据增强方法为 probit 模型的贝叶斯计算提供了重要基础。在遗传应用中, 还要加入亲缘协方差、复杂固定效应和可能的多性状潜在相关。给潜在残差任意估计一个尺度, 同时保留自由阈值和截距, 会重新引入不可识别性; 采样代码能够生成数值并不意味着模型已被正确定义。

稀少事件与完全分离是实际困难。某个小当代组可能全患病或全不患病, 无惩罚固定效应估计会向极端移动; 随机效应与适当先验可以稳定, 但结果也更依赖层次假设。应检查事件数在场、年份、家系和性别中的分布, 避免使用过细固定组把所有事件分割成无法比较的小块。合并应基于合理环境定义, 而非仅为了让程序不报错。

教学例 24.5: 十次没有事件意味着什么。某组十只动物均未出现事件, 简单二项最大似然发生率为 0, 但真实发生率并不能因此确定为 0。若只为教学说明采用均匀 $Beta(1, 1)$ 先验, 则后验为 $Beta(1, 11)$, 均值为 $1/12 = 0.0833$ 。这个算例没有包含遗传关系, 不能直接替代阈值动物模型; 它强调零事件样本仍具有有限信息, 极端经验比例不是确定概率。

概率预测还应区分条件和边际。给定某动物潜在育种值与固定环境的概率为 $\Phi(\eta)$; 若要预测尚未知遗传值的新个体, 需对遗传分布积分。若 $u \sim N(m, s^2)$ 且残差标准差为 1, 则 $E\{\Phi(\eta_0 + u)\} = \Phi\left((\eta_0 + m) / \sqrt{1 + s^2}\right)$ 。在不确定性较大时, 这个边际概率与将均值直接代入不同。

验证阈值模型时, 应检查概率校准、适当评分和不同风险层的表现, 而不只看分类准确率。对于发生率 1% 的事件, 永远预测无事件便有 99% 分类正确率, 却不能识别高风险或支持育种决策。验证还应保持真实发生率或正确校正抽样设计, 避免在人工平衡病例对照样本上直接解释绝对风险。

24.9 有序类别、计数和尺度之间的联系

对于容易产、轻度困难、严重困难等有序类别，可设阈值 $\tau_0 = -\infty < \tau_1 < \dots < \tau_K = \infty$ ，第 k 类概率为 $\Phi(\tau_k - \eta_i) - \Phi(\tau_{k-1} - \eta_i)$ 。阈值必须保持顺序，位置与尺度仍需约束。类别编码 1、2、3 只是顺序，不能默认 1 到 2 与 2 到 3 具有相同数量差异。

教学例 24.6：三分类概率。取两个有限阈值 0 与 1，潜在均值 0、残差方差 1，三类概率分别为 0.5、0.34134、0.15866。若潜在均值提高到 0.5，三类概率为 0.30854、0.38292、0.30854。中间类别的概率不一定单调随潜在均值变化；它会先上升后下降。因此解释一个育种值时应联系整个类别分布，而不只看中间类别的发生率。

不同评分者可能使用不同阈值。若某场对轻微症状更容易记为患病，观察到的发生率差异既可能是环境风险，也可能是测量规则。设置评分者或场的均值效应可以吸收某些差异，但不能自动区分真实倾向变化与阈值变化。建立统一评分规范、交叉评分样本与重复测量，能提供仅靠模型难以获得的校准信息。

计数性状如每胎活仔数、一定期间发病次数，又具有不同结构。Poisson 模型假定条件均值等于条件方差，链接常为对数；实际资料可能过度离散、零膨胀或具有有限上界。负二项模型可描述某些额外变异，但新增离散参数仍需识别。把所有整数性状都放进阈值模型或 Poisson 模型，没有依据；应从计数产生机制和观测窗口定义出发。

暴露时间必须进入计数分析。观察 30 天内两次发病与观察 300 天内两次发病代表不同率；可以将暴露量的对数作为已知 offset，但前提是事件率与暴露的关系符合所设模型。反复事件若导致个体状态改变，简单独立 Poisson 也可能不足。生存与重复事件模型能够显式利用时间顺序，下一节将展示其基本结构。

跨响应类型的多性状模型可以通过相关随机效应建立联系，例如连续生长与二元成活共享遗传协方差。但遗传相关定义在相应潜在尺度或链接尺度上，不能当作观察记录的普通相关。解释经济目标时，通常需要把预测转换

到实际概率、产量或事件率，并对不确定性积分。统一统计框架并不消除各响应尺度的差别。

24.10 生存资料：时间、事件与删失

生存分析研究从明确起点到事件的时间。事件可以是死亡、首次患病、首次受胎或退出生产群。对于仍未发生事件的个体，截止观察时只知道事件时间大于已观察时长，这叫右删失。删失个体提供了“至少存活到此时”的信息，不应直接删除，也不能把截止日当作真实事件日。两种错误都会扭曲寿命或风险估计。

设事件时间为 T ，生存函数 $S(s) = P(T > s)$ ，密度为 $f(s)$ ，风险率 $\lambda(s) = f(s)/S(s)$ 。风险率是已经存活到 s 条件下，单位时间内事件发生的瞬时强度，不是一个 0 到 1 之间的概率。累计风险 $\Lambda(s) = \int_0^s \lambda(v)dv$ 与生存函数满足 $S(s) = \exp\{-\Lambda(s)\}$ 。这个关系使我们可以从风险模型推导整个生存曲线。

若观察到 $t_i = \min(T_i, C_i)$ 及事件指示 δ_i ，在适当的条件独立删失假设下，关于事件过程的似然贡献可写为 $f(t_i)^{\delta_i} S(t_i)^{1-\delta_i}$ ，也即 $\lambda(t_i)^{\delta_i} S(t_i)$ 。发生事件的记录包含瞬时事件和此前存活两部分，删失记录仅包含此前存活部分。删除删失记录等于丢掉后者。

教学例 24.7：删失记录也贡献暴露时间。假定指数风险恒定为 λ ，五只动物观察时长为 2、3、4、5、6，前三只发生事件，后两只右删失。总事件数 3，总暴露 20，似然关于风险为 $\lambda^3 \exp(-20\lambda)$ ，最大似然风险为 0.15。若只保留事件个体，得到 $3/9 = 0.3333$ ，明显夸大风险。此例的单位随时间单位变化，例如以年计则风险单位为每年。

删失独立性通常是条件性的。行政截止造成的删失相对容易解释，因健康恶化出售、未记录死亡或生产者选择淘汰造成的退出，可能与事件过程相关。如果将淘汰本身定义为研究事件，问题与把淘汰视为死亡分析的删失不同。研究目标必须明确：是在预测实际生产寿命、自然生存能力，还是排除某些管理原因后的功能寿命。

左截断与右删失也不同。若研究只纳入已经活到首次登记年龄的动物, 样本条件是它们此前已经存活; 似然需对进入时点条件化, 通常包含除以 $S(a_i)$ 的调整。忽略左截断会让长寿个体过度代表早期风险。记录进入、退出、事件原因和时间原点, 是生存分析不可省略的资料基础。

24.11 比例风险、遗传脆弱性与生存育种值

Cox (1972) 的比例风险模型将风险写为 $\lambda_i(s) = \lambda_0(s) \exp(x_i' \beta)$, 把基准时间形状与协变量的乘法作用分开。遗传模型可以进一步加入随机效应 u_i , 得到 $\lambda_i(s | u_i) = \lambda_0(s) \exp(x_i' \beta + u_i)$, 并用亲缘结构描述 u 。这里随机效应位于对数风险尺度, 正值表示较高事件风险; 若事件是不利淘汰或死亡, 育种上的有利方向通常为负。

同一时点、其他条件相同时, 两个个体的条件风险比为 $\exp(u_i - u_j)$ 。它不是寿命比, 也不是累积死亡概率比。比例风险假设要求该条件风险比随时间保持不变; 如果遗传作用在幼年和成年方向不同, 就需要时间交互、分段效应或其他结构。对随机效应积分后, 群体边际风险比也未必仍保持简单比例, 因为高风险个体会较早退出风险集。

教学例 24.8: 风险比与生存概率。取基准指数风险每年 0.1, 两个候选遗传值为 0 与 $\log 2$, 则条件风险分别 0.1 与 0.2, 风险比 2。三年生存概率分别为 $e^{-0.3} = 0.7408$ 与 $e^{-0.6} = 0.5488$, 不是简单的一半。若发布的目标是降低三年淘汰概率, 应该在该时间和基准条件下转换, 而不能直接把风险比当作概率差。

Weibull 模型可令累计基准风险为 $(s/a)^k$, 其中 $a > 0$ 为时间尺度、 $k > 0$ 为形状。风险为 ks^{k-1}/a^k ; $k = 1$ 退化为指数模型, $k > 1$ 时风险随时间增加, $k < 1$ 时下降。加入线性预测值后, 生存函数为 $\exp\{-(s/a)^k \exp(\eta_i)\}$ 。参数化有多种等价写法, 报告时必须说明尺度和形状定义。

Ducrocq 等 (1988) 将生存方法用于奶牛群体生产寿命评价, 展示了删失与随时间变化因素在遗传分析中的重要性。后续应用可以使用不同基准风险与随机效应分布, 但同一解释问题始终存在: 寿命既反映动物健康与适应

性，也受到生产者淘汰规则影响。调整产量后得到的功能寿命，是一个条件性目标，不能自动等同于不受管理影响的生物学寿命。

时间变化协变量必须只使用该时点之前或当时可获得的信息。若用最终整个生产期平均产量解释早期淘汰风险，会把未来信息带入过去风险集。生存模型虽能接受时间变化输入，却不会自动阻止这种信息泄漏。将记录切分为风险区间时，应明确每个区间的协变量何时测量、何时开始生效。

遗传方差位于对数风险或脆弱性尺度，其“遗传力”定义可能依赖模型与转换。不要把某个寿命模型输出的遗传力直接与连续寿命天数的线性模型值比较。更有用的应用输出可能是参考环境下的生存曲线、特定年龄存活概率、限制平均寿命或其遗传目标预测，并同时给出不确定性。

24.11.1 风险集为何保留时间顺序

在没有并列事件的基本比例风险设定中，条件于某个事件时点恰有一只发生事件，个体 i 被观察为该事件者的相对概率，与 $\exp(\eta_i)$ 成正比，分母是当时仍在风险集中的所有个体权重之和。共同的基准风险在这个条件比值中消去，由此形成 Cox 部分似然的核心结构。风险集随进入、事件与删失更新，因此只知道最终事件总数不能重建同样的信息。

例如某一时点有三只动物仍在风险集中，其风险乘子为 1、2、1，第二只发生事件的条件概率为二分之一。若第一只此前已被删失，它不再属于该时点风险集，条件概率改为三分之二。删失并不产生一次事件，但会改变后续比较对象。并列事件需要相应处理，遗传随机效应又需要积分或惩罚推断；不能将基础固定效应部分似然直接当作所有混合生存模型的完整似然。

如果事件只知道发生在两次检查之间，观察贡献应是 $S(a) - S(b)$ ，其中事件区间为 $(a, b]$ 。把事件一律放在区间中点是一种近似，其误差取决于区间长度、风险变化和协变量更新。对于周检发现的疾病，声称估计了精确到小时的遗传发病时间通常缺少资料支持。区间删失模型承认观测精度，而不会因为时间不精确就丢弃全部事件信息。

这些表达也说明，生存模型的有效信息来自事件次序、风险集和暴露结构共同作用。延长随访可以增加事件与暴露，但若后期只剩极少数特定家系，

遗传比较仍可能薄弱。随访设计应兼顾持续时间、身份追踪和亲属覆盖，不能只以观察结束时的总记录数衡量质量。

24.12 竞争风险、信息性退出与联合模型

生产动物可能因疾病、繁殖失败、低产或意外事故退出。将这些全部合成为一个事件，有利于预测实际总退出，却可能掩盖不同原因的遗传关系；分别研究原因时，又要面对竞争风险。某只动物因一种原因退出后，便不再有机会以原来的过程发生另一种首次退出。简单把竞争事件当作普通独立删失，并直接用一减生存函数解释某原因累积概率，通常不正确。

原因别风险可以分别建模，而某原因的累积发生概率取决于所有原因共同决定的总体存活以及该原因风险。即使某个基因降低目标原因的瞬时风险，若它同时大幅降低其他退出风险，个体有更长时间暴露于目标原因，累计概率的变化也可能复杂。因此“原因别风险比”与“某期限累积发生率差”应分别命名和解释。

反复事件又增加了历史依赖。一次乳房炎可能改变后续感染风险、产量和淘汰概率；把每次事件当成独立新个体会忽略这种依赖。可以考虑间隔时间、事件次数、共享随机效应或多状态模型，但应根据记录精度与研究目标选择。记录只给出一年总次数时，不应虚构精确事件时点去拟合连续时间模型。

纵向性状与退出过程常互相联系。体重下降可能预示死亡，死亡又使后续体重永远无法观察。仅对存活动物拟合轨迹，估计的后期均值会受到幸存者组成影响。联合模型可让纵向过程与生存过程共享随机效应，或让风险依赖潜在当前水平与变化率。这样能够表达依赖，但仍依赖共享结构和分布假设，不能保证非随机缺失被无条件解决。

教学例 24.9：均值上升可能只是低值退出。设两个动物真实连续表现一直为 10 和 20，初期都被观察，平均 15；后期低值动物退出，仅高值动物留下，观察平均变为 20。没有任何个体实际提高，截面均值却增加 5。这个极简例子说明，后期记录均值变化同时包含个体内变化与样本组成变化。随机

回归可以描述个体曲线，但若退出依赖未建模状态，仍需额外处理。

对信息性退出，可做情景敏感性分析。例如比较在已观察协变量条件下可忽略退出的模型、共享随机效应联合模型，以及对未观察后期表现作合理偏移的模式混合情景。目的不是从资料中神奇地辨认所有缺失值，而是展示结论对不可检验部分依赖多大。若某个选择结论在合理情景下稳定，应用信心较强；若高度敏感，应优先改进追踪资料。

疾病、繁殖和生产之间还可能形成动态反馈。把当前产量作为淘汰模型协变量，可能是在校正管理选择，也可能阻断遗传作用通过产量影响寿命的一条路径。是否应调整，应由所需目标决定。实际寿命目标、条件性功能寿命目标与健康机制研究可以各有合理模型，但必须清楚说明条件，避免让相同名称掩盖不同估计对象。

24.13 随机回归：用少数系数表示整条遗传曲线

设标准化时间为 s ，取基函数向量 $\phi(s)$ ，个体遗传轨迹写为 $u_i(s) = \phi(s)'a_i$ 。随机系数 a_i 具有协方差矩阵 K_u ，个体之间通过 A 相联系。观察模型可以同时包括总体平均曲线、个体遗传曲线、永久环境曲线和短期残差。随机回归的关键不在于使用某一种多项式，而在于用共享随机系数在时间之间建立有结构的协方差。

遗传协方差函数为

$$\text{Cov}\{u_i(s), u_j(v)\} = A_{ij}\phi(s)'K_u\phi(v).$$

对同一个体，无近交时 $A_{ii} = 1$ ，时间 s 的遗传方差为 $\phi(s)'K_u\phi(s)$ 。两个时点的遗传相关由该协方差除以对应标准差得到。它可以随时间间隔和位置改变，因而比重复测量模型的恒定遗传效应更灵活。若只含常数基函数，则退化为随机截距结构。

Kirkpatrick、Lofsvold 与 Bulmer (1990) 把生长轨迹等函数性状的遗传分析置于协方差函数框架。Van der Werf、Goddard 与 Meyer (1998) 进一步展示了协方差函数与随机回归在测定日产奶遗传评价中的联系。这些工

作强调的是对整个连续过程的遗传变异建模，而不是把每个年龄都作为完全无关的性状。

基函数可以是低阶多项式、正交多项式或样条。原始年龄数值很大时，高次幂容易造成病态，应先把时间映射到合理区间；正交基可改善某些数值性质，但不保证实际不平衡数据下参数完全不相关。样条通过局部基函数提高灵活性，节点位置与平滑惩罚仍需选择。不存在对全部生长与泌乳过程都最佳的固定阶数。

平均曲线与随机曲线不必使用同样形式。总体平均可能具有较复杂的系统形状，个体偏离却可以用少数平滑方向表达；也可能不同性别或管理组需要不同平均曲线。若平均曲线过于简单，随机效应会吸收系统偏差；若平均曲线过度灵活且与家系分布混杂，又可能吸收遗传趋势。模型应结合年龄覆盖与亲属分布检查。

随机系数的数值依赖基函数选择，曲线本身才是稳定的科学对象。换一个等价基底，截距、斜率及其协方差可能改变，但任意时点的预测和协方差函数应保持不变。比较研究时，与其直接比较不同基底下的系数，不如比较共同时间位置的遗传方差、相关、目标积分与预测误差。

24.14 截距—斜率模型的完整手算

教学例 24.10：同一动物在不同年龄的价值。取 $\phi(s) = (1, s)'$ ，标准化时间范围为 $[-1, 1]$ ，随机系数协方差为

$$K_u = \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix}.$$

于是遗传方差为 $4 + 2s + s^2$ ，在早期 $s = -1$ 、中期 0、晚期 1 分别为 3、4、7。早晚协方差为 $[1, -1]K_u[1, 1]' = 3$ ，遗传相关为 $3/\sqrt{21} = 0.65465$ 。不同年龄不是完全相同的遗传性状，尽管它们由同一组两个随机系数生成。

某候选者系数预测为 $(2, -1)'$ ，其遗传轨迹为 $2 - s$ ，早中晚预测分别为 3、2、1。它具有较高早期水平，但相对于总体平均的优势随时间降低。另

一候选者若系数为 $(1, 1)'$ ，轨迹为 $1 + s$ ，二者在 $s = 0.5$ 相交。选择早期表现、晚期表现或全期平均，会得到不同排序；曲线交叉本身不说明哪个模型错，而说明目标必须带有时间权重。

给定第一候选者系数预测误差矩阵

$$C_a = \begin{bmatrix} 1 & 0.2 \\ 0.2 & 0.4 \end{bmatrix},$$

任意时点的误差为 $PEV(s) = 1 + 0.4s + 0.4s^2$ 。早中晚分别为 1、1、1.8。对应模型条件可靠度分别为 $1 - 1/3 = 0.6667$ 、0.75 与 $1 - 1.8/7 = 0.7429$ 。晚期误差更大，却不一定可靠度更低，因为可靠度还以该时点遗传方差标准化。只画标准误或只画可靠度，表达的信息不同。

早晚预测误差协方差为 $[1, -1]C_a[1, 1]' = 0.6$ 。因此晚减早差值误差为 $1.8 + 1 - 2(0.6) = 1.6$ ，也等于斜率误差方差乘 4。使用两个时点误差独立相加会得到 2.8，夸大曲线变化的不确定性。纵向目标的误差必须利用整条轨迹之间的误差协方差，而不是只读取图上各点误差棒。

一个点估计曲线及逐点区间，也不等于整条曲线同时覆盖的区间带。逐点 95% 区间保证的是每个指定时点各自的覆盖性质，许多时点同时查看时，整条真实曲线落在所有区间内的概率通常较低。若目标是判定全期都高于某水平，需要同时推断、后验函数抽样或预先定义的整体函数指标，不能把逐点区间的名称直接扩大解释。

本例采用直线以便手算，不代表真实生长过程应当线性。直线可以表示一个局部年龄窗口或相对总体曲线的低阶偏离。将其外推到 $s = 3$ 、远超观察范围，虽然公式仍能产生数值，却没有相同的数据支持。随机回归的平滑性是模型约束，不是远期外推准确性的证据。

24.15 从时点育种值到全期目标：持续力与稳健性

一条遗传曲线本身不是最终选择目标。生产系统可能关心指定年龄的体重、整个泌乳期总量、晚期相对于早期的持续力，或高温阶段的最低表现。




图 24.1 随机回归轨迹及其不确定性。矩阵采用例 24.10 的设定；甲的阴影为点预测加減 1.96 倍预测误差标准差，在正态近似下表示逐点区间，并非整条曲线的同时置信带

这些目标对应不同的曲线函数。先定义目标，再对随机系数线性组合，可以将第 16—18 章的选择指数思想自然延伸到函数性状，而不必为每一种曲线目标重新建立独立预测理论。

若目标为加权积分 $H_i = \int w(s)u_i(s)ds$ ，代入随机回归表达后得到 $H_i = l'a_i$ ，其中 $l = \int w(s)\phi(s)ds$ 。遗传方差为 $l'K_u l$ ，预测为 $l'\hat{a}_i$ ，误差为 $l'C_{a,i}l$ 。权重既可以代表经济价值，也可以代表实际时间单位和暴露长度。若标准化时间由日龄线性变换而来，积分时必须包含相应尺度因子，否则“全期总量”会与“标准化平均”混淆。

教学例 24.11：平均曲线与后期表现。对例 24.10，在 $[-1,1]$ 上取均匀平均权重 $w(s) = 1/2$ ，有 $l = (1,0)'$ 。候选者全期平均遗传值为 2，遗传方差 4，误差 1，可靠度 0.75。斜率不进入对称区间的平均，是因为正负时间权重恰好抵消；这并不意味着斜率生物学不重要，只说明这个特定目标对早晚变化不敏感。

若目标改为后半期 $[0,1]$ 的平均，则 $l = (1,1/2)'$ ，候选者预测为 1.5，遗

传方差为 $4 + 1 + 0.25 = 5.25$, 误差为 $1 + 0.2 + 0.1 = 1.3$, 可靠度约 0.75238。若目标是晚减早, $l = (0, 2)'$, 预测为 -2、遗传方差 4、误差 1.6, 可靠度 0.6。相同资料对不同目标提供的精度不同, 不能给一条曲线附一个通用可靠度后用于所有决策。

持续力也需要具体定义。晚期减早期、晚期相对于总量的残差、峰后下降斜率以及某一时间比值, 都可能被称为持续力, 却具有不同遗传含义。比值目标往往是非线性函数, 分母接近零时不稳定, 也可能与总产出产生机械相关。若希望在保持总量条件下改善曲线形状, 可以定义与总量适当正交的线性对比, 但正交性依赖所用协方差和基准群体, 应明确说明。

曲线的导数表示变化速度。对可微基函数, $u'_i(s) = \phi'(s)'a_i$, 其方差与误差分别用 $\phi'(s)$ 代入相同二次型。标准化时间上的导数需要换回实际天数单位。若 $s = (d - d_0)/c$, 则对实际日龄 d 的导数为标准化导数除以 c 。忽略这个换算会使不同观察窗口中的生长速度育种值无法比较。

非线性目标如峰值时间、最大产量或超过阈值的持续天数, 通常不能只用一个固定线性向量计算。可以在后验或近似联合正态的系数抽样下生成曲线, 逐次计算目标, 再汇总分布。这样自然传播系数相关与目标非线性。若曲线峰值落在观察边界, 所谓峰值时间可能只是外推方向, 应报告这一事实, 而不能给出过度精确的小数日龄。

环境反应规范与时间随机回归具有相同数学形式, 但解释不同。自变量可以是温度、营养水平或群体负荷, 斜率描述遗传敏感性。环境指标若由同一批动物表型估计, 会带来内生性与测量误差; 若仅使用场平均产量作为环境轴, 遗传组成也可能影响该平均。独立环境测量或明确的联合模型有助于避免把遗传差异误作环境梯度。

稳健性目标可以同时奖励平均表现并限制不利环境下的损失。例如在线性反应规范中定义参考环境值和低环境值的组合, 比笼统选择“小斜率”更清楚。斜率小可能意味着稳定高产, 也可能意味着在良好环境中缺乏响应; 目标权重决定哪一种更有价值。统计上估计到反应差异, 并不能替生产系统决定理想反应曲线。

24.15.1 由离散权重逼近连续目标

实际生产账目通常按天或按阶段计量，不需要强行使用解析积分。可取网格点 s_j 与权重 w_j ，令 $l = \sum_j w_j \phi(s_j)$ 。只要网格与权重具有明确单位，这就是一个可复现目标。数值积分精度应相对于曲线平滑程度和目标用途检查；密集网格并不增加遗传资料，只是更精确地计算已拟合曲线的函数。

如果两项经济权重随未来市场情景改变，可以保留随机系数预测和误差矩阵，在不同情景下重新组合目标，无需重新拟合全部遗传模型。这样使评价与决策分层：统计模型提供曲线和不确定性，经济情景决定如何使用它们。若目标情景包含观察范围外的年龄或环境，则仍受到外推限制，不能因重新组合计算容易就忽略证据边界。

24.16 基函数选择、边界行为与信息分布

选择随机回归阶数时，需要同时考虑拟合偏差、参数数量和观察覆盖。含 k 个基函数的一个无结构系数协方差需要 $k(k+1)/2$ 个参数；若遗传与永久环境都采用高阶，再加母体曲线，参数数目迅速增长。更多基函数能更贴合样本，却可能产生极端边界振荡、接近奇异的协方差和不稳定外推。应以预测与可解释结构为准，而不是追求曲线图最弯曲。

正交多项式在预定区间和权重下具有数学正交性，但实际记录常集中在某些年龄，且每只动物测量时点不同。在这种不平衡资料下，设计列之间未必近乎正交。基函数缩放仍有数值帮助，却不能代替信息检查。若某个高阶方向只在少数边界记录中得到识别，其系数方差和相关可能非常不稳定。

样条把曲线表示为局部基函数组合，可以让某个时间区域的改变较少影响远处，但节点数量和位置仍决定灵活度。惩罚样条将粗糙度限制转化为额外收缩，其惩罚参数具有统计含义。若对遗传曲线与永久环境曲线采用不同平滑程度，应说明依据；否则一个来源可能仅因更灵活而吸收另一个来源的变异。

教学例 24.12：中心区记录不能确定远端曲率。假设所有动物只在标准化时间 $-0.1, 0, 0.1$ 有记录，却拟合 $1, s, s^2$ 并预测 $s = 1$ 。在观察区间内，二

次项最大只有 0.01, 资料对其系数很弱; 在目标点二次项变为 1, 其影响扩大百倍。即使中心区拟合误差很小, 远端预测仍可高度不确定。这个例子说明, 训练拟合优良与远端遗传评价可靠是两种不同证据。

边界信息稀少还可能与选择性观察相连。晚期记录往往来自更健康、更高产或被特意保留的个体, 遗传组成与早期不同。随机回归中的高龄方差变化既可能反映遗传表达, 也可能受到选择、退出机制和模型假设影响。对后期曲线应同时报告记录数、家系数、存留比例及预测误差, 而不能只画一条方差曲线并赋予机制解释。

时间测量误差也值得重视。日龄通常较准确, 生理阶段、发病起点或受胎时间却可能区间不确定。把不确定时间当作精确自变量, 会平滑或扭曲真实轨迹。若时间误差相对于过程变化很小, 可作近似并说明; 若事件仅在定期巡检时发现, 区间删失或潜在时间模型可能更合适。模型应匹配记录精度, 不能反向从粗糙资料制造精细生物学时间。

不同基底之间的等价性可以作为程序核验。设新基函数满足 $\tilde{\phi}(s) = B\phi(s)$, 则为保持曲线不变, 新系数需为 $\tilde{a} = B^{-T}a$, 协方差与误差也按同一线性变换处理。转换后任意共同网格点的预测、遗传方差与误差应一致。若不一致, 常见原因是变换方向、系数排序或尺度矩阵使用错误。

模型选择可以先以低阶结构建立可靠基线, 再逐渐增加有数据支持的方向。比较时保持目标、训练截止时间和验证资料一致, 观察新增方向是否改善外部预测或揭示稳定的曲线特征。仅因为限制似然提高就保留高阶模型, 并不足够; 边界与有效参数问题还需按第 23 章处理。

24.16.1 不规则记录的设计价值

每只动物不必在完全相同时间测量, 随机回归可以按实际时间构建设计。但整个群体应覆盖目标范围, 并有亲属跨时间连接。如果早期只测某几个家系、晚期只测另几个家系, 年龄变化与家系差异会混杂。安排少量连接性重复测量, 有时比在已有密集时段继续加测更有价值。

测量资源有限时, 可根据目标误差和预计协方差设计采样时点。若目标是全期平均, 均匀或按经济权重分配的记录可能有效; 若目标是斜率, 时间

跨度与两端覆盖更重要；若目标是局部疾病前变化，关键窗口的密集记录更有价值。最优方案依赖成本、残差相关、退出概率和亲属结构，不能用“越密越好”概括。

24.17 新进展、验证边界与综合应用

随机回归与多性状模型的比较已从仅比较拟合优度，逐渐转向实际前向预测。Paneru、Moghaddar 与 van der Werf (2024) 在澳大利亚肉羊体重资料中比较两类模型，发现所研究阶段的前向预测准确性没有显著优势，同时指出随机回归在处理实际测量年龄和多次记录方面更灵活。这一结果很有教育意义：更连续、更灵活的描述能够带来使用便利，却不保证在每一种资料设计中提高预测准确性。

Bermann 等 (2024a) 研究了随机回归单步基因组 BLUP 可靠度的近似计算。大规模模型难以获得每个动物全部系数误差协方差的精确逆块，近似方法有助于将曲线评价与实际发布相连接。但近似应在有代表性的子集或可计算条件下与精确结果比较，并检查年龄、信息量与基因型状态分层的误差，不能只报告全体平均相关很高。

Jahnel 与 Langhammer (2026) 对小鼠窝总重的随机回归研究，将窝大小作为相关遗传表达变化的重要轴。它扩展了随机回归的理解：自变量不仅可以是时间，也可以是生物学负荷。将该思路迁移到多胎家畜时，需要重新定义母体与后代效应、窝大小是否具有遗传性，以及调整后目标究竟是条件性表现还是总产出；原研究的参数和结论不能直接视为其他物种的已验证结果。

截至 2026 年 10 月 1 日，这些进展支持一种更明确的评价思路：模型应能够表达目标所需的动态结构，同时接受与部署任务一致的验证。最新方法的价值需要从数据需求、预测校准、计算可行性和决策收益共同判断。一个方法在某项研究中有效，是有条件的证据，不能被扩写成所有性状和群体的通用优势。

纵向验证至少要区分三种任务。第一是已观察个体在已有时间范围内的

缺失时点插值；第二是使用早期记录预测同一个体未来；第三是预测下一代或新个体的完整轨迹。随机抽掉部分记录主要回答第一种问题，保留未来时间回答第二种，按出生批次与亲属信息截止划分更接近第三种。把最容易的插值结果当作未来世代准确性，会明显夸大应用能力。

生存验证也必须尊重删失。用所有未到目标年龄的个体直接标为未发生事件，会把尚未充分观察的人群当作长期幸存者；只保留已知结局者，又可能选择性偏倚。可以采用与删失机制假设相适应的时间依赖评价和概率校准，同时报告目标年龄前的有效观察覆盖。风险排序良好与绝对生存概率校准良好并不相同，两者都可能影响生产决策。

阈值与连续性状联合应用时，综合目标通常非线性。例如某年龄预期商品产出可以近似由存活概率乘条件体重构成，但若存活与体重相关，不能简单把两个边际均值相乘。应明确体重是对所有潜在个体定义，还是只对存活者定义，并根据联合分布计算期望。这个问题连接了统计目标定义与真实生产流程，无法通过多添加一个相关系数自动解决。

教学例 24.13：生存与产量的联合期望。设两个情景各占一半；情景甲存活概率 0.9、存活时产量 20，情景乙存活概率 0.5、存活时产量 10。总期望产出为 $0.5 \times 0.9 \times 20 + 0.5 \times 0.5 \times 10 = 11.5$ 。平均存活概率 0.7 与情景平均条件产量 15 相乘仅为 10.5。差异来自情景之间的相关结构；若要用“总体存活者平均产量”，则需按存活概率重新加权，不能使用简单 15。

一个完整应用可以从分开模型开始，再逐步联合。先核实每个性状的定义与观察机制，建立稳定的连续、多类别或生存基线；然后检查哪些共同遗传或永久环境路径有资料支持；最后把目标转换到生产尺度，并验证其预测。直接从最大最复杂模型开始，容易使数据错误、尺度问题和识别困难同时出现，反而难以判断哪一部分需要改进。

模型输出也应适应使用者。研究者需要系数协方差、方差函数和诊断，育种者可能更需要早期、全期及不利环境下的目标值和可靠度。两类输出可以来自同一模型，但展示层次不同。不给生产者看大量难解释系数，不意味着隐藏模型条件；应将参考环境、时间范围、目标单位和不确定性清楚写在发布说明中。

长期更新中，还要检查目标范围是否改变。若新品系成熟更早、生产周期缩短或监测设备改变，原有时间标准化、经济权重和残差结构可能需要更新。保持旧模型能够运行不等于保持其目标适用。定期对照生产制度、记录定义与外部验证，能使动态遗传模型真正服务于持续改良。

24.18 阈值记录的信息量与非正态后验

潜在变量方法使阈值模型可以借助正态条件更新进行计算，但观察到二元结果以后，育种值的边际后验通常不是正态。把一次线性化得到的方程逆直接当作精确 PEV，容易忽略这种变化。本节从一条二元记录的得分开始，再构造一个可以精确积分的例子，比较线性化、后验众数与后验均值分别回答什么问题。

设 $Y \in \{0, 1\}$ ，事件概率为 $p = \Phi(\eta)$ ，其中 η 包含固定效应与潜在遗传效应， Φ 和 φ 分别为标准正态分布函数与密度。单条记录的对数似然和关于潜在线性预测值的得分为

$$\ell(\eta) = Y \log p + (1 - Y) \log(1 - p),$$

$$s(\eta) = \frac{(Y - p)\varphi(\eta)}{p(1 - p)}.$$

利用二项方差 $p(1 - p)$ ，得分方差即期望信息为

$$\mathcal{I}(\eta) = \frac{\varphi(\eta)^2}{p(1 - p)}.$$

在当前迭代值附近，可以构造工作响应与权重

$$z = \eta + \frac{Y - p}{\varphi(\eta)}, \quad w = \frac{\varphi(\eta)^2}{p(1 - p)}.$$

工作响应不是新测量的潜在性状，而是使当前得分与加权线性方程相匹配的局部构造。随着参数更新，概率、工作响应和权重都要改变。若把最终工作响应另存为没有误差的真实表型，再作一次普通动物模型分析，会重复使用同一二元信息并忽略线性化过程中的不确定性。

在潜在均值为零时，单条记录信息为 $2/\pi \approx 0.636620$ ；潜在均值很极端时，事件或非事件对不同方向的信息变得不对称。一个全部无事件的小组可能主要限制风险不要太高，却不能精确确定风险究竟多低。大样本近似方程与稀少事件后验的区别，需要用概率尺度诊断和适当先验共同评估。

独立教学例：一次阳性记录的精确后验。设遗传效应 u 与潜在残差 e 独立且均服从标准正态，观察到 $Y = 1\{u + e > 0\}$ ，总体截距已知为零。先验事件概率为二分之一，因此观察阳性后的效应密度为

$$p(u | Y = 1) = 2\varphi(u)\Phi(u).$$

这个密度不是正态。令潜在总值 $L = u + e$ ，则 L 方差为二，且 $u | L$ 的均值为 $L/2$ 、方差为二分之一。对正半轴截断的 L 积分，可以得到

$$E(u | Y = 1) = \frac{1}{\sqrt{\pi}} = 0.564190,$$

$$\text{Var}(u | Y = 1) = 1 - \frac{1}{\pi} = 0.681690.$$

后验众数则满足 $u = \varphi(u)/\Phi(u)$ ，约为零点五零六零五四。以众数附近二阶曲率作拉普拉斯近似，方差约为零点六六一二九六，与精确方差不同。从零点只作一次牛顿更新，又得到另一个数值，约为零点四八七五二。三种结果分别是一次局部迭代、后验密度峰值和平方损失最优均值，不能因为都叫“遗传估计”就互相替代。

现在预测同一动物下一次独立潜在残差下是否出现事件。两次潜在总值的相关为二分之一，二维正态正象限概率给出

$$P(Y_2 = 1 | Y_1 = 1) = 2 \left\{ \frac{1}{4} + \frac{\arcsin(1/2)}{2\pi} \right\} = \frac{2}{3}.$$

若只把后验均值代入 Φ ，则得到约零点七一三六八七，偏离精确预测。前文的正态积分恒等式也不能直接套在这里，因为这一后验并非正态。Albert 与 Chib (1993) 的潜在数据增强提供了处理这类后验的计算途径；无论使用采样还是数值积分，最终概率都应对完整遗传不确定性平均，而不是只变换一个点预测。

24.19 事件富集抽样与总体风险的恢复

疾病或繁殖失败等稀少事件常采用富集抽样：尽量纳入发生事件的动物，只抽取一部分未发生事件的动物。这能提高研究某些关联参数的效率，却改变样本中的绝对发生率。若直接把样本事件比例或未经校正的概率模型用于总体，会把抽样设计造成的高风险当成真实群体特征。阈值模型的概率单位应与目标总体一致，不能仅根据分类表现良好就忽略这一点。

设总体在协变量 x 下的事件概率为 $p(x)$ ，事件与非事件个体被纳入样本的概率分别为 s_1, s_0 。假定在给定事件状态与 x 后，抽样不再依赖其他未知变量，样本中的事件概率为

$$q(x) = \frac{s_1 p(x)}{s_1 p(x) + s_0 [1 - p(x)]}.$$

因此样本优势与总体优势之间有简单关系：

$$\frac{q(x)}{1 - q(x)} = \frac{s_1}{s_0} \frac{p(x)}{1 - p(x)}.$$

对于逻辑链接，抽样相当于在对数优势上增加已知偏移：

$$\text{logit}q(x) = \text{logit}p(x) + \log(s_1/s_0).$$

对于 probit 链接，一般不存在一个对所有 x 都相同的截距平移，使 $\Phi^{-1}(q)$ 等于 $\Phi^{-1}(p)$ 加常数。因此不能把逻辑回归中的截距修正原封不动移到阈值 probit 模型。应直接在抽样似然中使用上述概率变换，或采用适当的加权与总体发生率信息，并说明所需条件。

独立教学例：发生率百分之五的动物疾病。假设所有事件个体都被纳入，未事件个体只抽十分之一。总体发生率为零点零五时，样本发生率为

$$q = \frac{0.05}{0.05 + 0.1 \times 0.95} = 0.344828.$$

样本中约三分之一出现事件，并不意味着总体疾病风险接近三分之一。若样本某一特征组的事件概率为二分之一，反解总体概率得到

$$p = \frac{s_0 q}{s_1(1 - q) + s_0 q} = \frac{1}{11} = 0.090909.$$

已知抽样比例是恢复绝对风险的重要信息；若只知道样本比例而不知道两类抽样概率，总体发生率并不能凭该样本唯一决定。外部患病率可以补充基准，但它本身也有时间、品种和管理范围，应与部署总体匹配。

抽样改变还会影响评分。若总体真实发生率为零点零五，却把样本概率零点三四四八二八作为所有动物的预测，总体均方概率误差为

$$E[(Y - q)^2] = p(1 - q)^2 + (1 - p)q^2 = 0.134423.$$

使用真实总体概率时，最小误差为 $p(1 - p) = 0.0475$ 。二者之差等于 $(q - p)^2$ ，完全来自基准概率失准，即使模型没有任何排序任务也会产生损失。这说明高分类正确率或较好的区分能力不能代替概率校准；绝对风险对群体发生率尤其敏感。

在家系相关资料中，抽样机制还可能改变随机效应分布。例如先选择出现至少一个病例的家系，再从家系内抽动物，纳入概率依赖整个家系事件向量，不能用单条记录的两个常数概括。若把被富集的家系仍视为原总体的随机样本，遗传方差和家系风险都可能受到影响。应写出实际纳入单位的概率，或明确把推断范围限制在被抽样的家系类型。

另一个边界是抽样依赖尚未观察的潜在严重度，即使二元事件相同，严重个体更容易被登记。此时条件抽样假设不成立，仅校正事件比例不足以恢复总体概率。可以利用独立登记审计、重复筛查或敏感性分析评估这条缺失路径。抽样校正的价值在于将资料来源纳入模型，而不是提供一个不依赖实际记录机制的万能权重。

24.20 纵向与生存联合似然的动态更新

联合模型最有用的地方之一，是把“仍然存活”和“新近测量的表现”都视为关于潜在状态的信息。若一头动物一直没有退出生产群，这个事实本身可能更新其风险相关随机效应；新体重或健康评分到来以后，又会进一步更新。同一动物在不同评定时点的生存概率，应该条件于各时点真正可获得的历史，而不是始终使用出生时的风险分布。

设纵向潜在均值为 $m_i(t) = x_i(t)' \beta + z_i(t)' b_i$, 记录在给定随机效应后独立, 测量误差与事件过程条件独立。风险可以通过当前水平与变化率关联:

$$\lambda_i(t | b_i) = \lambda_0(t) \exp\{\gamma' x_i + \alpha m_i(t) + \zeta m_i'(t)\}.$$

这里的关联参数描述给定模型下的风险联系, 不能仅凭它显著就把纵向性状解释为可干预的因果中介。当前水平、斜率与累计暴露往往相关, 是否同时纳入需要足够时间覆盖与事件信息。Tsiatis 与 Davidian (2004) 从联合似然结构讨论这些条件; Rizopoulos (2011) 进一步将其用于随历史更新的预测。

记观察终止时间为 T_i 、事件指示为 d_i , 累积风险为 Λ_i 。给定随机效应的一只动物贡献为

$$L_i(b_i) = f(y_i | b_i) \lambda_i(T_i | b_i)^{d_i} \exp\{-\Lambda_i(T_i | b_i)\}.$$

若动物间通过亲缘共享随机效应, 完整似然应对联合遗传分布积分:

$$L = \int \left\{ \prod_i L_i(b_i) \right\} \varphi(b; 0, \Sigma_b) db.$$

不能把相关动物的积分随意拆成各自边际似然的乘积, 否则便删除了亲缘传递的信息。只有随机效应在相应分组之间独立时, 才可以按那些独立组分解。计算可以利用条件结构加速, 但分解方式必须与统计独立性一致。

设当前时点为 s , 动物仍未发生事件, 已获得纵向历史 y_s 。其后验随机效应密度包含截至当前的生存权重:

$$p(b_i | y_s, T_i > s) \propto f(y_s | b_i) S_i(s | b_i) p(b_i),$$

其中为突出单个体记号, 先假定其他相关动物资料已适当整合。预测再存活到 $t > s$ 的概率是

$$\pi_i(t | s) = \int \frac{S_i(t | b_i)}{S_i(s | b_i)} p(b_i | y_s, T_i > s) db_i.$$

这不是把一个估计风险代入生存函数那么简单。分布更新使用已经存活到当前的证据, 未来生存再条件于该分布平均, 两步分别承担不同作用。

独立教学例：两个潜在风险状态。为能手算，设状态 b 等概率为零或一，相应恒定年风险为零点一与零点二；一次纵向测量满足 $y | b \sim N(b, 1)$ 。观察到 $y = 1$ 时，高风险与低风险状态的纵向似然比为 $e^{0.5}$ 。若动物已存活两年，生存似然比为 $e^{-0.2}$ ，故后验优势为 $e^{0.3}$ ，高风险状态概率约为零点五七四四三。

再存活三年的预测为

$$\pi = (1 - 0.574443)e^{-0.3} + 0.574443e^{-0.6} = 0.630521.$$

若忽略已存活两年的信息，高风险概率仍为零点六二二四五九；若只用存活而忽略纵向测量，又会得到另一个方向的更新。两种历史都应进入同一个条件问题。即使使用正确的平均风险，直接指数变换也只得到约零点六二三五四六，因指数函数非线性而与混合预测不同。

真实应用还需对方差、风险基线和关联参数积分，或者解释代入估计所忽略的部分。新测量若是因为病情恶化才被触发，测量时点本身也可能含信息；只在给定随机效应后假定固定测量计划，未必充分描述这种观察过程。联合模型可以扩展，但每增加一条依赖路径，都要说明对应记录是否存在，避免把模型复杂度当成已经解决信息性缺失的证据。

24.21 延迟入组与竞争风险改变了条件总体

存活到测定年龄才进入研究的动物，与出生时随机抽取的动物不是同一个风险总体。延迟入组也称左截断：在入组时间以前已发生事件的个体根本不会出现在数据中。它与右删失不同，右删失个体已经被观察并贡献一段暴露；左截断则改变哪些个体有机会进入样本。若忽略这种选择，长寿或低风险状态可能被过度代表。

先设入组年龄 L 给定，事件时间在给定随机效应下具有密度 $f(t | b)$ 、生存函数 $S(t | b)$ ，原总体效应密度为 $p(b)$ 。入组者的效应分布为

$$p(b | T > L) = \frac{S(L | b)p(b)}{\int S(L | b)p(b) db}.$$

给定效应，观察到入组以后事件或删失的贡献要除以 $S(L | b)$ ；但是再积分时，必须使用已被入组选中的效应分布。将二者结合，边际贡献为

$$L_{entry} = \frac{\int \lambda(T | b)^d S(T | b) p(b) db}{\int S(L | b) p(b) db}.$$

如果只把条件似然除以生存函数，却继续对原始效应分布积分，一般并不等价。分母位于积分外还是积分内，反映不同的抽样条件，不能视为数值积分的可交换操作。这里仍假定入组安排没有在存活之外额外依赖未建模状态；若生产者按未登记体况挑选入组，需进一步表示这一机制。

独立教学例：入组者的风险组成。原总体有两类动物，各占一半，恒定风险为零点一与零点三。研究只在五岁时纳入存活动物，则高风险类型的比例为

$$w_H = \frac{e^{-1.5}}{e^{-0.5} + e^{-1.5}} = 0.268941.$$

这批入组动物再存活两年的概率约为

$$(1 - w_H) e^{-0.2} + w_H e^{-0.6} = 0.746138.$$

若仍用出生时各半的组成，会得到约零点六八三七七一，低估入组后存活。较高的入组后存活不一定是管理改善，而可能只是高风险个体已在入组前退出；遗传参数与预测验证都应说明从哪个时点、哪个风险集开始。

竞争风险则改变事件概率的分母过程。设原因一与原因二的原因别风险为 $\lambda_1(t), \lambda_2(t)$ ，总体生存由两者共同决定。原因一的累积发生概率为

$$F_1(t) = \int_0^t S(v) \lambda_1(v) dv, \quad S(t) = \exp \left[- \int_0^t \{ \lambda_1(v) + \lambda_2(v) \} dv \right].$$

若两种风险恒定为零点一与零点二，五年内原因一的概率为

$$F_1(5) = \frac{0.1}{0.3} (1 - e^{-1.5}) = 0.258957.$$

忽略竞争事件而直接计算 $1 - e^{-0.5}$ ，会得到零点三九三四六九。后一个值对应没有竞争退出的不同过程，不是同一群体的原因一真实累积概率。原

因别风险模型可以将竞争退出从该原因的风险集中移除，但把拟合结果转成绝对累积概率时，仍须纳入所有退出原因。

如果遗传改良只降低原因二风险，原因一的瞬时风险不变，动物活得更久后，原因一累积发生率反而可能增加。这并不表示对原因一的内在抗性下降。选择目标若同时关心寿命与特定病因，应分别表达总体存活、原因别风险及给定期限累积发生率，避免单看一个比例就产生错误方向的育种解释。

24.22 遗传曲线与暂时环境的状态空间分解

随机回归用少数固定于个体的随机系数表示遗传轨迹；短期环境则可能在每个时点产生新的冲击。把二者放进状态空间模型，可以逐次更新预测，同时防止把环境波动误当成基因型在不断改变。这里的“状态”是计算中用于承载信息的随机向量，不意味着所有状态分量都具有相同生物学性质。

设个体遗传轨迹为 $a_0 + a_1 t$ ，短期环境为 w_t 。取状态 $b_t = (a_0, a_1, w_t)'$ ，遗传系数不随测量次数改变，而环境满足一阶动态过程：

$$b_{t+1} = F_t b_t + \xi_t, \quad F_t = \text{diag}(1, 1, \rho_t),$$

$$\text{Var}(\xi_t) = \text{diag}(0, 0, q_t), \quad y_t = (1, t, 1)b_t + e_t.$$

在不规则间隔 Δ_t 下，若短期环境为平稳指数衰减过程，可以令

$$\rho_t = e^{-\phi \Delta_t}, \quad q_t = \sigma_w^2 (1 - e^{-2\phi \Delta_t}).$$

这保证环境边际方差保持 σ_w^2 。如果无论间隔多长都使用同一个相关系数，就把日与月的信息距离混为一谈。遗传系数的跨动物协方差仍可由亲缘矩阵建立；状态更新只是组织同一个高斯模型的条件计算，并不会自动忽略相关动物。

设新记录到来前状态预测均值与误差为 m^-, C^- ，观察行为 H_t 、测量残差方差为 r_t 。高斯条件分布给出创新及更新增益

$$v_t = y_t - H_t m^-, \quad S_t = H_t C^- H_t' + r_t, \quad K_t = C^- H_t' S_t^{-1},$$

$$m^+ = m^- + K_t v_t, \quad C^+ = C^- - K_t S_t K_t'.$$

随后用转移矩阵推进到下一时点, 得到 $m_{next}^- = F_t m^+$ 、 $C_{next}^- = F_t C^+ F_t' + \text{Var}(\xi_t)$ 。已知参数、线性高斯条件下, 这些递推与一次分析全部记录的条件预测等价; 对阈值或非线性风险记录, 只能采用适当近似或积分, 不能无条件保留精确等价的表述。

独立教学例：一次持续遗传效应与衰减环境。为缩短手算, 先去掉遗传斜率。遗传效应方差四, 当前环境方差二, 测量误差方差一, 三者独立, 第一条记录为三。观察行为 (1, 1), 更新后遗传均值为 12/7, 环境均值为 6/7, 误差矩阵为

$$C^+ = \frac{1}{7} \begin{bmatrix} 12 & -8 \\ -8 & 10 \end{bmatrix}.$$

假定下一时点环境相关为二分之一, 平稳过程创新方差为一点五。下一时点预测均值为 (12/7, 3/7)', 误差矩阵为

$$C_{next}^- = \frac{1}{7} \begin{bmatrix} 12 & -4 \\ -4 & 13 \end{bmatrix}.$$

第二条记录为四时, 记录预测为 15/7, 创新为 13/7, 创新方差为 24/7。遗传更新增益为三分之一, 因此第二次遗传预测为七分之十二加二十一分之十三, 即三分之七, 遗传误差方差降为四分之三。环境更新均值为八分之九, 故对当时潜在生产水平的预测还需把两者相加, 而向后代传递的遗传评价只使用遗传分量。

这个例子中, 第一条较好表现被分配给遗传与环境两部分, 并产生负的后验交叉误差; 等待一段时间后环境证据衰减, 新记录对持续遗传部分又提供信息。若强行把所有持续差异视为遗传, 会过度利用短期好环境; 若把每条偏差都视为独立噪声, 又浪费了邻近时间的状态信息。

预测与平滑还应区分。实时预测只能使用当前及以前的记录; 回顾性平滑可以使用后来记录重新解释早期状态。两者用于不同任务, 不能用平滑后的早期遗传或健康状态冒充当时已经可获得的实时预测。在前向验证中应

冻结历史信息，否则一个看似准确的动态系统可能主要依靠未来资料解释过去。

24.23 删失下的动态评分与模型组合

动态预测需要在固定评定时点与预测期限上评价。设在时点 s 仍处于风险集的动物，模型给出存活至 $t > s$ 的概率 p_i 。完整数据下，概率平方损失为 $[1\{T_i > t\} - p_i]^2$ 。但在预测期限以前失访的动物，其最终二元结果未知，不能一律当作存活，也不能简单删除而把剩余样本视为原风险集的随机代表。

设删失时间为 C_i ，观察时间为 $\tilde{T}_i = \min(T_i, C_i)$ ，事件指示为 d_i 。记 $G_i(v)$ 为给定时点 s 已知历史且尚未删失条件下，继续未删失至 v 的概率。以下采用连续时间且事件与删失没有并列的简化条件；存在离散时点或并列时，需要依照事件与删失的先后约定，在事件项中使用相应左极限概率。在条件独立删失与正概率覆盖假设下，一个逆删失概率加权评分为

$$B_i(t) = \frac{1\{\tilde{T}_i > t\}(1-p_i)^2}{G_i(t)} + \frac{1\{s < \tilde{T}_i \leq t, d_i = 1\}p_i^2}{G_i(\tilde{T}_i)}.$$

其依据是给定真实事件时间与已知历史，仍被观察到相应时点的指示除以对应概率，其条件期望为一。对真实存活者，第一项恢复完整平方损失；对期限内事件者，第二项恢复相应损失；对期限内提前删失者，本次贡献为零，但其他仍可观察个体通过权重代表同类信息。这个论证要求删失模型使用的条件足以使独立性成立。

独立教学例：四只动物的加权评分。四只动物预测存活概率均为零点八，其中两只被完整随访至期限且存活，一只在期限前发生事件，一只提前删失。假定独立外部资料给出期限未删失概率零点八、事件时点未删失概率零点九，则平均评分为

$$\hat{B} = \frac{1}{4} \left\{ \frac{2(0.2)^2}{0.8} + \frac{0.8^2}{0.9} \right\} = 0.202778.$$

若删掉提前删失者，在另外三只上直接平均，得到零点二四，对应不同的观察样本。这个小例子仅演示权重计算，不能用四只动物证明评分估计稳

定；删失概率来自外部的设定也应与实际风险集相容。若某一类动物几乎必然提前失访，权重会很大，数据无法凭公式凭空恢复充分证据。

还应避免让预测模型与删失权重共同使用验证动物未来信息调参。可以在训练资料或适当交叉拟合中估计必要部分，并按实际决策时点冻结协变量。家系相关与多次预测窗口产生的评分依赖，需在区间估计时保留；把同一动物每天生成的预测视为独立测试样本，会严重夸大验证规模。

联合模型中，轨迹形状与纵向—风险关联形式均可能不确定。Rizopoulos 与 Taylor (2024) 研究了通过交叉验证选择多个联合模型预测的组合权重，使用平方预测误差及预测交叉熵作为准则。其思路可以写为

$$p_i^{ens}(t|s) = \sum_{k=1}^K w_k p_{ik}(t|s), \quad w_k \geq 0, \quad \sum_k w_k = 1.$$

权重必须由训练内部的验证确定，再到独立测试动物上评价，不能在测试结果上挑最好的组合。组合概率不等于将各模型风险系数先平均再生成概率，因为生存函数与参数的关系非线性。该研究来自联合预测方法学背景，迁移到育种资料还需要处理亲缘依赖、选择记录与世代时间，不能把原研究中的模拟表现视为家畜系统的直接证据。

在固定当前时点下，如果组合权重不随未来期限改变，而每个组成模型给出合法生存曲线，凸组合仍然单调不增且位于零至一之间。若对每一个预测期限独立挑选权重，这一基本性质可能丢失。考虑两个模型在先后两个期限的存活概率分别为零点九与零点八、零点六与零点五，各自都合法；若较早期限只选第二个模型、较晚期限只选第一个，组合概率就从零点六上升到零点八，不再是一条生存曲线。因此多期限模型组合需要保持联合相容性，或者明确只发布分别定义的单期限预测，不能未经检查把它们连成概率曲线。

这个单调条件针对同一个已知历史和同一个当前评定时点。若一天后获得新的健康记录，针对同一个未来期限的条件存活概率可以升高，也可以降低，因为条件信息已经改变；这与固定条件下生存函数不得随期限升高没有矛盾。实际界面若连续显示动态风险，应同时标明评定日期和预测期限，避免把信息更新误读为同一条生存曲线的反常上升。模型评估也应按这些条件

分层，而不能把不同预测窗口的概率全部混在一张未经调整的校准图上。

对育种应用，验证报告最好同时给出几个预先确定的时间目标：短期生产或健康风险、指定期限存活以及跨代遗传贡献。短期风险可以利用不可遗传的当前环境状态，跨代选择则需明确分离遗传部分。一个联合模型能够产生多个有用预测，但这些预测拥有不同的信息条件、误差来源与决策单位；将它们分别定义和验证，才真正发挥联合建模的价值。

24.24 练习与详解

练习 1：排列与 Kronecker 积。三只动物、两个性状，若按“动物 1 的两个性状、动物 2 的两个性状、动物 3 的两个性状”排列育种值，协方差应写为什么？若改成性状优先，怎样保证预测不变？

解答。动物优先为 $A \otimes \Sigma_u$ ，性状优先为 $\Sigma_u \otimes A$ 。改变排列时，应同时用同一个置换关系变换育种值、设计矩阵和协方差，而不能只交换协方差公式。预测的标签和数值对应应保持一致。程序可选一个跨动物、跨性状元素核验，例如动物 1 性状 1 与动物 2 性状 2 的协方差应为 $A_{12}\sigma_{u,12}$ 。

练习 2：只有相关性状记录。某目标育种值方差 9，与一个已观察记录协方差 3，记录方差 12、校正值 8 且均值已知。求目标预测、误差方差与可靠度。

解答。预测为 $3 \times 8/12 = 2$ ，误差方差为 $9 - 9/12 = 8.25$ ，可靠度为 $1 - 8.25/9 = 0.08333$ 。记录值较高不等于目标预测可靠；可靠度取决于协方差相对于记录与目标变异的比例。若记录均值需要估计，还要加入固定效应估计代价，不能直接使用已知均值结果作为完整 PEV。

练习 3：多性状目标误差。两个性状育种值预测误差矩阵对角元为 2 和 3，交叉元 1。求等权和、差值及平均值的预测误差方差。为什么这三者不能共享一个误差数值？

解答。和的误差为 7，差值为 3，平均值为 $7/4 = 1.75$ 。交叉误差在和中增加不确定性，在差值中抵消共同部分；平均值还改变整体单位。任何目标都应把权重左乘和右乘完整误差矩阵。只报告两个边际可靠度不足以计算这

些结果，因为它们没有包含交叉误差信息。

练习 4：重复力与可靠度上限。遗传方差 3、永久环境 2、独立残差 5。求单记录遗传力、重复力、五次平均记录预测自身育种值的可靠度，以及只增加自身记录时的无限次数上限。

解答。单记录遗传力 0.3, 重复力 0.5; 五次平均记录方差为 $3+2+5/5 = 6$, 可靠度为 $3/6 = 0.5$; 无限上限为 $3/(3+2) = 0.6$ 。这个上限不限制加入亲属或基因组等其他信息后的可靠度，它只针对单个体自身重复记录。永久环境不能通过同一个体内无限重复自动消除。

练习 5：短间隔相关。四次等间隔残差方差均为 4，自回归相关参数 0.5。求四次平均的残差方差，并与独立残差比较。

解答。总和方差为 $4[4 + 2(3 \times 0.5 + 2 \times 0.25 + 1 \times 0.125)] = 33$ ，平均方差为 $33/16 = 2.0625$ 。独立时平均方差为 1。正相关使重复记录有效信息减少。计算时必须计入不同间隔的配对数量，不能把所有六对都当作相邻相关 0.5，也不能只取一次相关系数代入两记录公式。

练习 6：连续时间衰减。指数残差相关的半衰间隔为 10 天。求相隔 5 天和 20 天的相关。如果时间单位改为周，衰减参数怎样转换？

解答。每天衰减参数为 $\log 2/10$ ，5 天相关为 $2^{-1/2} = 0.7071$ ，20 天为 0.25。以周为单位时，参数为原来的 7 倍，因为一周包含七天；相同物理间隔的相关应保持不变。单位变换是模型一致性的要求，不能只改变横轴标签而保留原参数数值。

练习 7：潜在尺度。二元 probit 模型将残差方差固定为 1、阈值固定为 0。若有人同时把残差方差、所有固定效应和阈值都作为自由参数，为什么会出现识别问题？

解答。对潜在量、阈值和标准差共同作正比例变换，观测分类概率可以保持不变；位置平移也可能由截距与阈值相互抵消。因此观测二元数据不能同时确定这些位置与尺度。必须设置约束，常见为固定残差方差和一个阈值。这个约束不提供额外生物学证据，只是定义潜在单位与原点。

练习 8：概率尺度的非线性。在 probit 模型中，潜在值由 -0.5 增加到

0, 事件概率改变多少? 由 1.5 增加到 2 又改变多少? 能否把同一潜在育种值增量解释为固定百分比提高?

解答。第一种由 0.30854 到 0.5, 增加 0.19146; 第二种由 0.93319 到 0.97725, 增加 0.04406。不能用固定概率增量概括, 因为正态累积分布函数非线性。还需说明事件 1 是有利还是不利结果; 概率升高是否有利取决于编码与目标, 而非取决于潜在值正负本身。

练习 9: 边际概率。已知固定部分为 1, 某候选者潜在遗传值后验为均值 0、方差 1 的正态分布, 潜在残差方差 1。求整合育种值不确定性后的事件概率, 与直接代入均值比较。

解答。边际概率为 $\Phi(1/\sqrt{2}) \approx 0.76025$, 直接代入为 $\Phi(1) = 0.84134$ 。不确定性使此例的边际概率向 0.5 靠近。公式利用正态潜在效应与独立正态残差的卷积; 如果后验明显非正态, 应数值积分或抽样, 不能只用均值方差强行套用。

练习 10: 有序类别。阈值为 -1 与 1, 潜在均值 0、残差标准差 1。求三个类别概率。若评分者把所有阈值同时提高, 是否必然说明动物遗传风险降低?

解答。概率为 0.15866、0.68269、0.15866。评分阈值提高会改变观察分类, 即使潜在动物分布完全不变; 因此观察到高风险类别减少不必代表遗传改良。需要统一评分规范或通过交叉评分资料识别测量变化。阈值与潜在均值的解释必须结合位置约束, 不能同时任意移动。

练习 11: 指数生存似然。四只动物总暴露时间 30 年, 发生两次目标事件, 其余右删失。求恒定风险的最大似然估计及参考个体五年生存概率。说明删失个体贡献什么。

解答。风险估计为 $2/30 = 1/15$ 每年, 五年生存概率为 $e^{-1/3} = 0.71653$ 。删失个体提供截止前仍未发生事件的暴露时间, 使似然包含相应生存因子。它们没有贡献一次事件, 但绝非没有信息。该计算依赖恒定风险与适当独立删失; 不能直接用于风险强烈随年龄改变的过程。

练习 12: 风险比不是概率比。基准累计风险在两年为 0.4, 某候选者对

数风险效应为 $\log 1.5$ 。求其两年生存概率和事件概率，并与基准比较。

解答。基准生存为 $e^{-0.4} = 0.67032$ ，候选者为 $e^{-0.6} = 0.54881$ ；事件概率分别 0.32968 与 0.45119。风险比为 1.5，但事件概率比约 1.3686，并非 1.5。随时间延长，概率比还会改变。发布育种结果应标明对数风险、风险比或具体期限概率是哪一种尺度。

练习 13：左截断。动物只有活到两岁才进入研究，之后观察至事件或删除。为什么不能把它们从出生起的全部时间都当作普通无条件观察？

解答。入样本以活到两岁为条件，早于两岁发生事件的动物无法进入。似然应条件于进入年龄存活，相关贡献含对 $S(2)$ 的除法调整。忽略这一选择会过度代表长寿个体，并扭曲早期风险。若目标总体只定义为两岁仍存活者，也应明确这一条件性研究对象，而非声称代表全部出生动物。

练习 14：随机回归方差。取 $\phi(s) = (1, s)'$ 、系数协方差对角元 3 和 2、交叉元 -1 。求 $s = -1, 0, 1$ 的遗传方差及早晚协方差，检查协方差矩阵是否合法。

解答。方差函数为 $3 - 2s + 2s^2$ ，三点分别 7、3、3；早晚协方差为 $3 - 2 = 1$ ，交叉截距—斜率项在对称端点间抵消。二阶矩阵行列式 $3 \times 2 - 1 = 5 > 0$ 且首对角正，故正定。早晚相关为 $1/\sqrt{21}$ ，不能用截距与斜率相关代替时点之间相关。

练习 15：曲线差值误差。随机系数误差矩阵为对角元 1 和 0.5、交叉元 0.1。求 $s = 1$ 与 $s = -1$ 的误差方差、二者误差协方差，以及晚减早的误差方差。

解答。晚期为 1.7，早期 1.3，交叉为 0.5；差值误差为 $1.7 + 1.3 - 1 = 2$ ，也等于斜率误差 0.5 乘 4。差值只依赖斜率，截距误差完全抵消。若把两个时点看作独立，会错误得到 3。曲线内误差相关是计算持续力和变化速度精度的必要信息。

练习 16：积分目标。对例 24.10 的候选者与协方差，定义目标为 $[-1, 0]$ 上的平均遗传值。求目标预测、遗传方差、误差和可靠度。

解答。权重向量为 $(1, -1/2)'$ ，预测为 2.5，遗传方差为 $4 - 1 + 0.25 = 3.25$ ，

误差为 $1 - 0.2 + 0.1 = 0.9$ ，可靠度为 $1 - 0.9/3.25 = 0.72308$ 。前半期与后半期平均具有不同目标精度，尽管使用同一条曲线。权重向量必须从实际积分区间得到，不能沿用全期对称平均的 $(1, 0)'$ 。

练习 17：单位与导数。标准化时间为 $s = (d - 100)/50$ ，候选者曲线为 $u(s) = 2 + 0.5s$ 。对实际日龄的遗传变化速度是多少？从日龄 50 到 150 的总遗传变化是多少？

解答。对日龄导数为 $0.5/50 = 0.01$ 单位每天；该 100 天区间对应标准化时间从 -1 到 1 ，变化为 1 。直接把 0.5 报告为每天变化，会夸大 50 倍。遗传变化速度的方差及其预测误差方差，均需按 $1/50^2$ 转换；单位变换应贯穿预测与不确定性。

练习 18：逐点区间与全曲线结论。一条曲线在 20 个时点都有逐点 95% 区间，能否说真实整条曲线以 95% 的概率完全落在这些区间构成的带内？

解答。不能直接这样解释。逐点覆盖针对每一个预先指定时点，多个时点同时覆盖属于联合事件，其概率通常不同。需要构造同时置信带、用后验曲线抽样评价整体事件，或预先定义一个整体目标。时点之间相关会影响联合概率，不能简单按独立事件相乘，也不能忽略多点查看。

练习 19：验证任务。某模型随机删除每只动物 20% 的中间测定日，预测非常准确。是否已经证明它能在出生时准确预测整条成年曲线？怎样改进验证设计？

解答。没有。该验证主要衡量已有动物、已有时间范围内的插值，训练仍包含这些动物其他甚至后期记录。出生时预测应限制为出生时已知的谱系、基因组及祖先资料，按出生批次设置未来个体验证，并保留相应时间截止。早期预测未来则可允许早期自身记录，但仍须排除未来信息。三种任务应分别报告。

练习 20：联合产出。两个同权情景中，存活概率分别 0.8 与 0.4，存活条件产量分别 30 与 10。求总期望产出、总体存活概率以及总体存活者的平均产量。

解答。期望产出为 $0.5 \times 0.8 \times 30 + 0.5 \times 0.4 \times 10 = 14$ ；存活概率 0.6；存

活者平均产量为 $14/0.6 = 23.3333$ 。它不是两情景条件产量的简单平均 20, 因为存活个体更常来自高存活情景。将 0.6 乘 20 会低估真实期望。这说明在多过程综合目标中必须使用相容的条件分布与权重。

练习 21: 复杂度与实证优势。随机回归比离散多性状模型更灵活, 是否必然具有更高未来预测准确性? 如何解释某项研究中二者准确性接近?

解答。不必然。灵活性可能改善年龄处理与曲线输出, 也增加参数估计负担; 若原多性状模型已充分利用主要信息, 或资料不足以支持新增方向, 外部准确性可能接近。应比较相同任务、相同信息截止与合理调参下的预测, 不能因理论表达更丰富就预先宣布优越。某研究的相近结果也不证明所有其他资料中都相同。

练习 22: 不利环境下的稳健性。候选甲反应规范为 $2 + 2s$, 乙为 $1 + 0.2s$, 环境范围 $[-1, 1]$ 。若目标只看参考环境 $s = 0$, 谁更优? 若强调最低环境表现, 结果怎样? 能否简单选择斜率最小者?

解答。参考环境甲为 2、乙为 1, 甲较优; 不利端点甲为 0、乙为 0.8, 乙较优。斜率较小可代表稳定, 但还须考虑平均水平、环境出现概率和经济权重。一个始终低产的平坦曲线也具有小斜率, 不能据此认为最理想。目标应明确综合水平与敏感性, 并纳入对应误差, 而不是使用一个脱离生产情景的“稳定”标签。

第八篇基因组评定

第八篇

PART VIII

基因组遗传学与基因组预测

高密度标记改变了遗传相似性的观测精度。本篇讨论基因组遗传力与多基因架构、基因组关系矩阵、GBLUP 与贝叶斯方法、单步评定以及预测验证。

第 25 章 基因组时代的遗传力：缺失遗传力与多基因架构

第 26 章 基因型质量控制与基因组关系矩阵

第 27 章 GBLUP、岭回归、贝叶斯与核方法

第 28 章 单步基因组评定与大规模计算

第 29 章 验证设计、准确性、校准与跨群体迁移

基因组时代的遗传力：缺失遗传力与多基因架构

25.1 遗传力概念的再审视

遗传力是数量遗传学中最常用、也最常被误解的概念。第 10 章给出了它的定义：广义遗传力 $H^2 = V_G/V_P$ 是表型方差中由基因型决定的比例，狭义遗传力 $h^2 = V_A/V_P$ 是其中可以通过育种值传递的比例。第 13 章讨论了怎样由亲属资料估计它。在这些经典框架中，遗传力是一个群体参数，依赖于等位基因频率、环境方差与测定方法；它描述的是群体中的变异来源，而不是个体表型中有多少“由基因决定”。

全基因组标记的出现，使遗传力有了新的含义与新的估计方法。我们不仅可以问“表型方差中有多少是遗传的”，还可以问“遗传方差中有多少能被现有标记捕获”“这些方差分布在基因组的哪些区域”“由多少个、何种频率、何种效应大小的变异贡献”。维舍尔、希尔与雷（2008）在《基因组时代的遗传力：概念与误解》一文中系统梳理了这些问题，强调必须区分几种不同的“遗传力”：

- **系谱遗传力**：由亲属资料（双生子、家系、系谱）估计，包含全部加性遗传方差，但可能受共同环境、显性与上位、基因型—环境相关等因素影响；
- **SNP 遗传力** h^2_{SNP} ：由无亲缘个体的全基因组 SNP 估计，是全部所分型 SNP 通过与致因变异的连锁不平衡所能捕获的加性方差占表型方差的比例；
- **GWAS 显著位点解释的方差**：只计入达到全基因组显著水平的位点。

三者的关系一般为：显著位点解释的方差 $\leq h_{\text{SNP}}^2 \leq h_{\text{系谱}}^2$ 。理解它们之间的差距，就是理解“缺失遗传力”问题，也是理解复杂性状遗传架构的关键。

25.2 缺失遗传力问题

人类身高是一个理想的例子。双生子与家系研究一致表明，成人身高的遗传力约为 0.8（第 11 章）。2007 至 2008 年，第一批身高 GWAS 在数万人中发现了约四十至五十个显著位点；然而这些位点合计只解释了约 5% 的表型方差。马赫（2008）在《自然》上以“遗传力消失之谜”为题报道了这一困惑；马诺利奥等（2009）在《寻找缺失的遗传力》一文中系统列举了可能的解释：大量效应过小、未达显著的常见变异；芯片未能很好标记的稀有变异；结构变异与拷贝数变异；基因与基因、基因与环境的互作；表观遗传；以及家系研究高估了遗传力。这些解释并不互斥，问题在于各自贡献多少。

缺失遗传力在许多复杂性状与疾病中普遍存在：二型糖尿病、克罗恩病、精神分裂症等疾病的早期 GWAS 位点只能解释其遗传易感性的一小部分。在家畜中情况类似：奶牛产奶性状除了 *DGAT1* 等少数大效应位点外，大量显著位点的效应很小，合计远不能解释全部遗传方差。

25.3 由全基因组 SNP 估计遗传力

25.3.1 基本思想

杨剑等（2010）在《常见 SNP 解释了人类身高遗传力的很大一部分》一文中提出了一个改变研究方向的思路：不再逐个检验 SNP，而是把全部 SNP 的效应同时作为随机效应，估计它们共同解释的方差。模型为

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{g} + \mathbf{e}, \quad \mathbf{g} \sim N(\mathbf{0}, \mathbf{G}\sigma_g^2), \quad \mathbf{e} \sim N(\mathbf{0}, \mathbf{I}\sigma_e^2), \quad (25.1)$$

其中 $\mathbf{G}$ 是由 SNP 计算的基因组关系矩阵（第 11 章式 (11.8)、第 26 章），

$$G_{jk} = \frac{1}{M} \sum_{i=1}^M \frac{(x_{ij} - 2p_i)(x_{ik} - 2p_i)}{2p_i(1 - p_i)}.$$

用限制最大似然 (REML) 估计 σ_g^2 与 σ_e^2 , SNP 遗传力为 $h_{\text{SNP}}^2 = \sigma_g^2 / (\sigma_g^2 + \sigma_e^2)$ 。这一方法称为 GREML, 由 GCTA 软件实现。

式 (25.1) 与第 21—23 章的动物模型在形式上完全相同, 只是把系谱关系矩阵换成了基因组关系矩阵。关键的差别在于样本: 杨剑等只使用**无亲缘关系的个体**——剔除任何一对基因组关系大于 0.025 的个体中的一个。在无亲缘个体中, 系谱期望关系都为零, 基因组关系的微小变异 (围绕零的标准差约为 0.004 至 0.005) 来自远古的共同祖先, 与共同环境无关。正是这些微小的“遥远亲缘”的变异, 在数千个个体的大量配对中提供了估计遗传方差的信息。由于没有近亲, 共同环境、显性与上位方差 (它们只在近亲之间产生可观的协方差) 基本不会进入估计。

25.3.2 Haseman–Elston 回归的视角

GREML 的信息来源可以用一个更直观的方法理解。对标准化的表型, 个体 j 与 k 表型乘积的期望为

$$E(y_j y_k) = G_{jk} h_{\text{SNP}}^2 \quad (j \neq k). \quad (25.2)$$

于是把所有个体对的表型乘积对基因组关系回归, 斜率即为 h_{SNP}^2 。这正是第 8 章 Haseman–Elston 回归的推广: 在那里是同胞对表型差的平方对位置特异的同祖同源比例回归, 这里是任意个体对的表型乘积对全基因组关系回归。HE 回归计算简单, 在大样本中与 REML 给出相近的估计, 但效率略低。

25.3.3 估计的精度

由式 (25.2) 可以得到估计精度的近似。 n 个个体共有约 $n^2/2$ 对, 回归斜率的抽样方差约为

$$\text{Var}(\hat{h}_{\text{SNP}}^2) \approx \frac{2}{n^2 \text{Var}(G_{jk})}. \quad (25.3)$$

在人类欧洲血统的无亲缘样本中, 常见 SNP 计算的基因组关系非对角元素方差约为 2×10^{-5} , 于是 $\text{SE}(\hat{h}_{\text{SNP}}^2) \approx 316/n$ 。杨剑等的样本为 3925 人,

标准误约 0.08。要使标准误降到 0.01, 需要三万余个无亲缘个体。式 (25.3) 说明, 样本中“遥远亲缘”的离散程度越大, 估计越精确; 在有效群体较小、LD 范围较大的家畜群体中, 基因组关系的方差大得多, 同样的精度所需的个体少得多。在本章的溯祖模拟中 (有效大小 5000、十条短染色体), 非对角元素方差约为 0.001, 3000 个个体的标准误约为 0.015。

25.3.4 杨剑等 (2010) 的结果

研究使用了 3925 名澳大利亚无亲缘个体的 294831 个常见 SNP。估计的 SNP 遗传力为 0.45 (标准误约 0.08), 即全部常见 SNP 共同解释了约 45% 的身高方差——比当时全部显著位点解释的约 5% 高出近十倍。这有力地表明, 大部分“缺失”的遗传力并没有真正缺失, 而是“隐藏”在大量效应过小、无法达到全基因组显著水平的常见变异中。

但 0.45 仍低于约 0.8 的系谱遗传力。研究者认为, 剩余的差距主要来自所分型 SNP 与致因变异之间不完全的连锁不平衡: 基因组关系矩阵是在 SNP 上计算的, 而遗传相似性体现在致因变异上, 二者不完全一致。他们把分型的 SNP 按频率分为两组, 用一组模拟“致因变异”, 校正了 SNP 关系对致因变异关系的预测误差。若致因变异的频率谱与所分型 SNP 相同, 校正后的估计约为 0.54; 若致因变异主要是频率低于 0.1 的较稀有变异, 校正后的估计约为 0.84, 已接近系谱遗传力。他们还证明, 经过预测误差校正后, 估计不依赖于所用 SNP 的数目; 未经校正的估计则随 SNP 数目增加而增加。

这一结论引出了一个关键问题: 致因变异的频率分布是怎样的? 在下面的模拟中可以清楚地看到它的影响。

25.3.5 一个模拟: 致因变异的频率决定被捕获的遗传力

用溯祖模拟产生 3000 个无亲缘个体十条染色体的完整变异 (约九万个多态位点), 把其中频率不低于 0.05 的变异随机抽取约三万个作为“芯片”SNP, 用于计算基因组关系矩阵。性状的真实遗传力设为 0.5, 由 500 个致因变异决定, 考虑两种情形: 致因变异从常见变异中抽取, 或者从频率低于 0.01 的稀有变异中抽取。每种情形重复十次 (表 25.1)。

表 25.1 致因变异频率对 SNP 遗传力估计的影响（真实 $h^2 = 0.5$ ）

致因变异	GREML估计（均值）	标准差	HE 回归估计（均值）
常见变异（MAF ≥ 0.05 ）	0.500	0.018	0.501
稀有变异（MAF < 0.01 ）	0.137	0.022	0.096

致因变异为常见变异时，芯片 SNP 几乎完全捕获了遗传方差，估计无偏；致因变异为稀有变异时，芯片 SNP 只捕获了约四分之一的遗传方差。原因在第 5 章已经说明：稀有变异与常见 SNP 之间的 r^2 受到频率差异的严格限制，即使二者完全连锁 ($|D'| = 1$)， r^2 也很小。因此 h_{SNP}^2 与系谱遗传力之间的差距，在很大程度上反映了致因变异的频率谱：稀有变异贡献的遗传方差越多，“缺失”的部分越大。

25.3.6 全基因组测序的答案

如果稀有变异是缺失遗传力的主要来源，那么直接测定全部变异就应当能“找回”它们。温施泰因等（2022）利用美国精准医学计划（TOPMed）中约两万五千名无亲缘欧洲血统个体的全基因组测序资料，估计身高的遗传力约为 0.68，体重指数约为 0.30，接近相应的系谱估计；其中频率较低的变异贡献了相当可观的部分，且这些稀有变异往往位于 LD 较低的区域。几乎同时，延戈等（2022）以 540 万人的 GWAS 资料识别出一万二千余个常见变异关联，在欧洲血统人群中合计解释了约 40% 至 45% 的身高方差，基本达到常见 SNP 的遗传力上限。两项研究共同表明：身高的遗传力基本可以由常见变异与稀有变异的加性效应解释，“缺失”的遗传力主要源于早期研究的样本量不足与芯片对稀有变异标记的不完全。

25.4 LD 分数回归

25.4.1 原理

GREML 需要个体水平的基因型资料，而许多大型研究只公开 GWAS 的汇总统计量。布利克—沙利文等（2015）提出的 **LD 分数回归**（LDSC）只需

要汇总统计量与参照群体的 LD 结构, 就可以估计 SNP 遗传力, 并区分多基因信号与群体分层造成的统计量膨胀。

定义 SNP j 的 **LD 分数**为它与周围全部 SNP 的 r^2 之和: $\ell_j = \sum_k r_{jk}^2$ 。在多基因模型下, 每个 SNP 的检验统计量不仅反映它自身的效应, 也反映与之处于 LD 的所有致因变异的效应; LD 分数越高的 SNP, “标记”的致因变异越多, 其检验统计量的期望越大。可以证明

$$E(\chi_j^2) = \frac{Nh_{\text{SNP}}^2}{M} \ell_j + Na + 1, \quad (25.4)$$

N 为样本量, M 为 SNP 数, a 度量群体分层或隐性亲缘造成的混杂。把各 SNP 的 χ^2 统计量对其 LD 分数回归: 斜率给出 h_{SNP}^2 , 截距 $1 + Na$ 反映混杂。若统计量的膨胀来自真实的多基因信号, 它与 LD 分数成正比, 截距接近 1; 若来自群体分层, 它与 LD 分数关系不大, 截距大于 1。这就解决了第 8 章遗留的问题: 大样本 GWAS 中 λ_{GC} 大于 1, 究竟是分层还是多基因信号。

在本章的模拟中, 对一个由 1000 个常见致因变异决定、遗传力 0.5 的性状, 在 3000 个个体中计算各芯片 SNP 的关联统计量 (平均 χ^2 约 2.38), 以样本内的 LD 计算 LD 分数, 加权回归得到截距 0.96、遗传力估计 0.45 (图 25.1A)。截距接近 1, 说明统计量的膨胀几乎全部来自多基因信号。




图 25.1 LD 分数回归与多基因预测。A 图为按 LD 分数分组的平均关联统计量及加权回归直线; B 图为 Daetwyler 公式给出的多基因预测期望 R^2 随训练群体大小的变化 (遗传力 0.5, 不同有效独立片段数 M_e)

25.4.2 扩展

LD 分数回归有几个重要的扩展。**跨性状 LD 分数回归**用两个性状汇总统计量的乘积对 LD 分数回归，估计两性状之间的遗传相关，且不受样本重叠的影响（样本重叠只影响截距）。它已经被用来系统地绘制数百种人类性状与疾病之间的遗传相关图谱。**分层 LD 分数回归**把 LD 分数按功能注释分类（如编码区、增强子、保守区域、特定组织的调控元件），估计每类注释对遗传力的富集程度，从而揭示与性状相关的组织与生物学通路（第 31 章）。

25.5 复杂性状的遗传架构

GREML 与 LD 分数回归使我们能够超越“遗传力是多少”，进一步回答“遗传方差是怎样组织的”。若干一般规律已经相当清楚。

高度多基因性。对身高、体重指数、精神分裂症等性状，遗传方差分布在成千上万个位点上。按染色体划分的遗传力与染色体长度近似成正比（杨剑等，2011）：较长的染色体含有较多的致因变异，贡献较多的方差。这正是第 14 章“无限小模型”在基因组层次上的近似体现。博伊尔、李与普里查德（2017）进一步提出“全基因（omnigenic）模型”：由于细胞内基因调控网络高度互联，几乎所有在相关组织中表达的基因都可能通过网络对性状产生微小的影响，“核心基因”只贡献了遗传方差的一小部分。

效应大小与等位基因频率的关系。负选择使大效应的变异难以达到高频。因此，常见变异的效应普遍很小，而效应较大的变异往往是稀有的。在估计 h^2_{SNP} 时，基因组关系矩阵对 SNP 的加权方式（例如每个 SNP 标准化后等权，还是按频率与 LD 加权）隐含了对效应—频率关系的假设，会影响估计结果。一些方法（如 LDAK）因此引入频率与 LD 相关的加权，以更好地匹配实际的遗传架构。

大效应位点与多基因背景并存。在许多家畜性状中，少数大效应位点（如奶牛的 *DGAT1*、猪的 *IGF2*、鸡的若干羽色与体型基因）与大量小效应位点共同决定遗传方差。第 27 章的贝叶斯方法正是为了刻画这种“稀疏 + 多基因”的混合架构。

非加性方差的贡献有限。基于基因组资料对显性方差的估计普遍较小,大多数性状的显性方差约为加性方差的十分之一到三分之一;对上位方差的估计更为困难,但在大样本中通常未发现明显的上位方差。这与第 10 章希尔等(2008)的理论预期一致。

25.6 缺失遗传力的其他解释

尽管稀有变异与样本量不足能解释大部分缺失遗传力,其他几种机制也值得认真对待,因为它们揭示了遗传力估计本身的局限。

稀有变异与常见变异之争。普里查德(2001)从群体遗传学的角度论证,复杂疾病的易感变异可能有相当部分是稀有的。吉布森(2012)系统地比较了“常见变异—小效应”与“稀有变异—大效应”两种模型的二十条论据,指出二者并不互斥:真实的遗传架构是各种频率与效应的连续谱,其相对贡献依性状的进化历史与选择压力而异。

幻影遗传力。祖克、海希特、桑亚耶夫与兰德(2012)指出,若性状由若干“限制性通路”中最弱的一环决定(一种特殊的上位),则由亲属资料按加性模型估计的遗传力会高于真实的加性遗传力,造成“幻影遗传力”:即使找到了所有加性效应,也无法解释按家系估计的“遗传力”。这一论证提醒我们,系谱遗传力本身依赖于模型假设,未必是可以“找回”的确定目标。

表观遗传。若某些表观遗传状态(如 DNA 甲基化)可以跨代稳定传递,并影响性状,它们会在亲属之间产生相似性,而这种相似性不能被 DNA 序列变异解释。约翰内斯等(2008, 2009)在拟南芥表观重组自交系中证明,可遗传的表观变异确实能影响开花期、株高等数量性状;斯拉特金(2009)则从理论上分析了表观遗传对缺失遗传力的可能贡献,认为只有当表观状态的传递相当稳定时,其贡献才有意义。在哺乳动物中,跨代表观遗传的证据要有限得多。

系谱遗传力的高估。双生子研究的等环境假定、同型交配、基因型—环境相关,以及家系中共同环境的未建模,都可能使系谱遗传力偏高(第 11 章)。若真实的加性遗传力低于传统估计,缺失的部分也就随之缩小。

25.7 多基因预测

25.7.1 预测的准确度

把全基因组 SNP 的效应同时纳入模型，就可以对个体的遗传易感性或育种值进行预测。雷、戈达德与维舍尔（2007）较早论证了利用全基因组 SNP 预测复杂疾病个体遗传风险的可能性；国际精神分裂症协作组（2009）用大量未达显著水平的 SNP 构建“多基因得分”，证明了精神分裂症的多基因本质，并发现它与双相情感障碍共享相当部分的遗传基础。

多基因预测的期望准确度可以由一个简洁的公式近似（达特韦勒等，2008）：

$$r_{\hat{g}g}^2 \approx \frac{Nh_{\text{SNP}}^2}{Nh_{\text{SNP}}^2 + M_e}, \quad (25.5)$$

N 为训练群体大小， M_e 为有效独立的染色体片段数（第 5 章）。预测解释的表型方差为 $r_{\hat{g}g}^2 h_{\text{SNP}}^2$ ，其上限为 h_{SNP}^2 。式（25.5）的含义十分直观：要准确估计 M_e 个独立片段的效应，需要远大于 M_e/h^2 的训练样本。人类群体 M_e 约为数万到十万，因此即使 h_{SNP}^2 为 0.5，也需要数十万个体才能接近上限；家畜品种 M_e 只有一千至数千，数千个有记录的个体就能达到可观的准确度（图 25.1B）。这正是基因组选择在奶牛中率先成功、而人类疾病风险预测长期进展缓慢的原因之一。

25.7.2 预测的陷阱

雷等（2013）在《从 SNP 预测复杂性状的陷阱》中总结了多基因预测研究中的常见问题：训练集与验证集之间的样本重叠或亲缘关系使准确度虚高；用全部资料筛选 SNP 后再在其中划分验证集，造成信息泄漏（第 29 章、第 37 章）；群体分层使预测反映的是祖先成分而非个体遗传差异；以及在不同祖先群体之间，由于 LD 结构与等位基因频率的差异，预测准确度大幅下降——以欧洲血统资料训练的多基因得分，在非洲血统人群中的准确度可能只有其几分之一。这些问题在家畜的跨品种基因组预测中有完全对应的表现（第 29 章）。

25.8 家畜中的基因组遗传力

与人类相比，家畜品种有效群体大小小、LD 范围大、近缘个体多，基因组遗传力的估计与解释有几个特点。第一，由于 LD 延伸较远，中等密度的 SNP 芯片就能捕获大部分加性方差， h_{SNP}^2 往往接近系谱遗传力。第二，样本中通常包含大量近亲，基因组关系的方差大，估计精度高，但近亲之间的共同环境、显性与母体效应也可能进入估计，需要在模型中分别处理。第三，基因组关系捕获了孟德尔抽样的实现（第 11 章），海斯、维舍尔与戈达德（2009）证明，利用实际关系代替系谱期望关系，可以提高选择的准确度，这正是基因组选择的核心机制之一。第四，大效应位点与多基因背景并存，用贝叶斯方法（如麦维森等 2009 年提出的快速贝叶斯 B 算法）估计的标记效应分布，常常显示少数区域解释了相当比例的遗传方差，这为育种中的标记辅助选择与基因编辑提供了靶点。

25.9 遗传力的正确解释

在基因组时代，遗传力被广泛报道，也被广泛误读。几个基本原则值得反复强调。

遗传力描述群体，不描述个体。遗传力 0.8 并不意味着某个人身高的 80% 由基因决定；对一个个体而言，基因与环境的作用是不可分割的。

遗传力不意味着不可改变。高遗传力的性状可以因环境改变而大幅变化：二十世纪以来许多国家的人均身高显著增加，主要来自营养与健康条件的改善，而身高的遗传力始终很高。

群体内的遗传力不能解释群体间的差异。两个群体之间的均值差异可能完全来自环境，即使两个群体内部的遗传力都很高。

遗传力是特定条件下的估计。它依赖于所研究的群体、环境、时代与测定方法，也依赖于估计所用的模型与资料（系谱、SNP、序列）。报告遗传力时，应当说明它是哪一种遗传力、在什么样本中、用什么方法估计的。

25.10 本章小结

基因组资料使遗传力有了更细的划分：系谱遗传力、SNP 遗传力与显著位点解释的方差依次递减，其差距构成“缺失遗传力”。GREML 以无亲缘个体的基因组关系矩阵估计全部 SNP 共同解释的方差，其信息来自远古共同祖先造成的微小关系差异，标准误约为 $316/n$ （人类常见 SNP）。杨剑等（2010）发现常见 SNP 解释了身高约 45% 的方差，校正不完全 LD 后可达 0.54 至 0.84；模拟显示，致因变异越稀有，芯片 SNP 捕获的遗传方差越少；全基因组测序与超大样本 GWAS 基本找回了身高的遗传力。LD 分数回归仅用汇总统计量估计遗传力、遗传相关与功能富集，并区分多基因信号与群体分层。复杂性状高度多基因，效应大小与频率负相关，非加性方差贡献有限；稀有变异、幻影遗传力、表观遗传与系谱遗传力高估等也是缺失遗传力讨论中的重要议题。多基因预测的准确度由 $Nh^2/(Nh^2 + M_e)$ 决定，存在样本重叠、信息泄漏、分层与跨祖先迁移等陷阱。家畜中 LD 范围大、近亲多，SNP 遗传力接近系谱遗传力，基因组关系捕获孟德尔抽样提高了选择准确度。遗传力描述群体中的变异来源，不描述个体，也不意味着不可改变。

25.11 习题

习题 25.1 说明系谱遗传力、SNP 遗传力与 GWAS 显著位点解释的方差三者的含义与一般大小关系，以及造成差距的主要原因。

习题 25.2 某研究有 12000 个无亲缘个体，基因组关系非对角元素的方差为 2×10^{-5} 。估计 h_{SNP}^2 的标准误。若要标准误降至 0.02，需要多少个体？

习题 25.3 为什么 GREML 分析通常要剔除亲缘关系大于 0.025 的个体？若保留大量近亲，估计可能受哪些因素影响？

习题 25.4 某 GWAS 的平均 χ^2 为 1.5，LD 分数回归的截距为 1.02。判断统计量的膨胀主要来自群体分层还是多基因信号，并说明理由。

习题 25.5 某奶牛品种 $M_e \approx 1000$ ，产奶量遗传力 0.3。按式 (25.5)，训练群体分别为 1000、5000、20000 头时，基因组预测的期望准确度为多少？若用于一个 $M_e \approx 60000$ 的人类性状呢？

习题 25.6 解释“幻影遗传力”的含义，并说明它对“找回缺失遗传力”这一研究目标意味着什么。

习题 25.7 某人说：“身高遗传力为 0.8，所以营养改善对身高影响不大。”指出这一推理的错误。

25.12 习题解答

25.1 系谱遗传力包含全部加性方差（可能受共同环境等影响而偏高），SNP 遗传力是芯片 SNP 通过 LD 捕获的加性方差，显著位点解释的方差只计入达到显著阈值的位点。一般 $h_{\text{GWAS}}^2 \leq h_{\text{SNP}}^2 \leq h_{\text{系谱}}^2$ 。前一差距来自大量小效应位点未达显著（样本量不足）；后一差距主要来自致因变异与 SNP 之间不完全的 LD（尤其是稀有变异），以及系谱估计可能的偏高。

25.2 $SE \approx \sqrt{2/(n^2 \times 2 \times 10^{-5})} = 316/n = 0.026$ 。要 0.02，需 $n \approx 15800$ 。

25.3 近亲之间共享共同环境，并共享显性与上位效应，其表型相似性不全来自 SNP 捕获的加性效应；近亲之间的关系主要由系谱决定，估计会接近系谱遗传力而非 SNP 遗传力。剔除近亲使估计只依赖远古关系的微小变异，避免了这些混杂。

25.4 截距接近 1，说明混杂很小，膨胀主要来自多基因信号。

25.5 $h^2 = 0.3$, $M_e = 1000$: $N = 1000$, $r^2 = 300/1300 = 0.23$, $r = 0.48$;
 $N = 5000$, $r^2 = 0.6$, $r = 0.77$; $N = 20000$, $r^2 = 0.857$, $r = 0.93$ 。 $M_e = 60000$:
 $r = 0.07$ 、0.16、0.30。

25.6 若性状存在特定类型的上位（如限制性通路），由亲属资料按加性模型估计的遗传力高于真实的加性遗传力，多出的部分即使找到全部加性位点也无法解释。因此“缺失遗传力”的目标本身可能被高估，不应把系谱遗传力视为必须由加性位点全部解释的确定值。

25.7 遗传力描述的是在当前环境分布下，群体内身高差异有多大比例来自遗传差异；它不说明环境整体改变时均值会怎样变化。营养改善使全体人群的身高普遍增加，而群体内的遗传力可以保持很高。

基因型质量控制与基因组关系矩阵

同父同母的两只羔羊，在系谱关系矩阵中具有相同的期望亲缘关系；它们实际获得的染色体片段却不完全相同。基因组评定的入口，正是把“平均而言继承多少”推进到“这个个体实际携带什么”。然而，芯片产生的数字并不天然等于可用于预测的遗传信息。个体身份、等位基因方向、参考群体以及缺失处理中的一个错误，都可能沿关系矩阵传播到所有育种值。

本章从数据的单位开始，建立关系矩阵，解释其尺度，再讨论近年的关系测量进展。全部小型数据均为本书构造的教学数据，不代表任何真实品种的参数或表现。

26.1 从实验读数到可解释的基因型

二倍体常染色体双等位位点的基因型可以编码为所指定等位基因的拷贝数：0、1、2。数字2并不表示该基因型优良，数字0也不表示缺失。一个可复核的数据集至少需要动物唯一编号、采样编号、位点编号、染色体与坐标、参考基因组版本、被计数等位基因以及记录生成时间。表型、系谱与基因型必须通过同一个身份系统连接；不能按文件中的行号直接拼接。

质量控制首先处理“这是谁”，然后才处理“这个位点能否使用”。个体层面考察检出率、重复样本一致性、性别信息一致性、异常杂合度与亲子冲突；位点层面考察缺失比例、次等位基因频率、聚类或测序质量、位置重复以及跨平台方向一致性。异常应形成可追溯记录。重复样本一致性高并不能证明父母关系正确；亲子关系合理也不能证明表型日期没有错位。

哈代—温伯格平衡检验需要结合设计解释。选育群体中的近交、混合品

种、选择和家系抽样都可能造成偏离。因此，不能把很小的检验概率一律当作技术错误。较合理的做法是先分品种、分批次、分群体结构检查，再结合聚类图、深度和亲子冲突判定原因。固定采用某一检出率或频率阈值，可能在保留常见位点的同时删除研究所需的稀有变异；阈值应服务于分析目的并进入敏感性分析。

缺失同样是信息。某一芯片批次恰好对应某一养殖场，若批次缺失模式明显不同，模型可能学到实验流程而非遗传信号。检查缺失与场、年份、表型和被选择状态的联系，比只报告总体缺失百分比更有价值。训练集与验证集应使用相容的质量规则；涉及表型的筛选必须限制在训练数据之内。

硬判型与剂量也应区分。若一个位点的基因型概率为 $(0.2, 0.1, 0.7)$ ，则剂量是 $0 \times 0.2 + 1 \times 0.1 + 2 \times 0.7 = 1.5$ ，而不是最可能基因型 2。其条件方差是 $0.1 + 4 \times 0.7 - 1.5^2 = 0.65$ 。两份数据都可以写成剂量 1.5，但判型不确定性可能相差很大；只保留剂量会丢失这一差别。低深度测序的评定流程因而需要明确：不确定性是被忽略、通过填充质量过滤间接处理，还是在模型中显式传播。

26.2 个体身份、亲子关系与样本链条

26.2.1 身份正确是所有矩阵运算的前提

一个关系矩阵的第十五行并没有脱离元数据的生物学意义；只有当第十五行始终对应同一动物时，矩阵才可与表型相乘。真实项目常同时使用耳标号、电子耳标号、采样管号、实验室编号和育种数据库编号。它们之间可能是一对一，也可能由于重复采样形成多对一。数据管理的第一步不是把这些编号替换为同一列，而是建立有生效日期、来源和核实状态的对应表。重复采样应保留样本身份，动物身份则必须唯一；两份样本相似能够支持它们来自同一个体，却不能允许两条不同表型记录被无意合并。

身份错误具有传播性。若甲、乙两只公羊的血样被对调，直接受影响的是两只动物的基因型；随后它们与所有后代的亲子关系、与其他候选羊的关系以及各自标记效应回算都可能异常。如果只删除异常父子对而不追溯采样

来源, 真实父亲可能被错误地改成未知, 系谱信息反而进一步损失。因此, 对一组同时出现的亲子冲突, 应优先寻找共同原因, 例如同一天采样、相邻孔位、同批上传或同一识读设备。高维统计不能代替从现场到数据库的基本记录制度。

可以为身份核查设计三种相互补充的对照。第一种是同一样本在不同实验批次的技术重复, 主要检测实验一致性; 第二种是同一动物在不同时间的独立采样, 能够进一步发现采样和登记错误; 第三种是具有可靠生殖记录的亲子三联体, 检验遗传传递是否合理。这三种对照所覆盖的错误环节不同。来自同一管样本的技术重复几乎完全一致, 并不能排除这管样本从一开始就贴错标签; 已知父亲与后代相容, 也不能证明母亲编号正确。

26.2.2 相容、排除与归属概率

对于无突变、无判型错误的常染色体双等位位点, 亲本的等位基因必须能够解释子代。若父亲为 0 而后代为 2, 二者不相容; 若父亲为 1, 仅凭该位点通常不能排除父子关系。父母都是 0 而子代为 1 或 2, 也不相容。亲子核查中的一个基本量是受检查有效位点数中的不相容比例, 但它并不是关系真实性的后验概率。几万个位点的极小冲突率仍可能包含局部技术问题, 而只用少数常见位点的零冲突率也未必提供强证据。

更完整的表述比较两个假设下的基因型概率。设 D 为亲本与子代的基因型资料, H_1 为所提亲子关系成立, H_0 为某种明确的替代关系, 则似然比为 $L(D|H_1)/L(D|H_0)$ 。在考虑多个候选父亲时, 替代假设应反映它们的亲缘, 而不是一律假设随机无关动物。两个全同胞公羊可能在大量位点上十分相似, 不能把用于排除随机公羊的阈值直接当作区分这对全同胞的证据。频率参照和错误模型也会影响似然比。

若要从似然比得到归属概率, 还需候选范围和先验概率。假如真正父亲根本没有分型, 在现有候选者中似然最高的个体仍可能是错误答案。应允许“候选集合之外”或“资料不足”这一结果, 而不是强制给每只羔羊指定父亲。对人工授精、自然交配和混群繁殖, 候选父亲集合的可靠程度不同; 出生日期、配种日期和生理可行性可缩小候选集合, 但这些信息只能在记录可信时

使用。遗传数据与生产记录彼此核对，比让其中一方无条件覆盖另一方更稳妥。

26.2.3 一个亲子冲突的分层算例

设一对登记父子在 1000 个可靠位点中有 20 个不相容。按染色体检查发现，其中 18 个位点集中在同一小区段，且这些位点在许多无关亲子对中也出现冲突；其余 2 个位点分散。这个模式首先提示区域分型或定位问题。若把该区段作为待核实位点暂时排除，剩余 982 个位点中有 2 个冲突，比例约为 0.204%。这个比例下降不能直接证明关系正确，却说明原始 2% 的指标被少数系统性位点主导。

再考虑另一对动物，也在 1000 个位点出现 20 个冲突，但均匀分散到多个染色体，并且样本在独立重复中十分一致。两对动物的总体冲突率相同，最值得追查的原因却不同。后一种情况更需要核对身份和候选亲本关系。该例说明，质量诊断应保留位点位置和样本层级，不能只把所有信息压成一个通过或失败标签。最终处理可以是确认错误并更正、重新采样、排除部分位点，或者保留“待核实”状态；每种处理都应保留原始记录与理由。

26.3 频率、杂合度与平衡检验的统计解释

26.3.1 频率是估计量，不是位点的永久属性

等位基因频率取决于群体、时间与抽样方式。同一位点在核心育种群、商品群和地方保种群中可以有不同频率；同一育种群经过若干代选择和漂变后也可能改变。因此，数据字典中只存一个不带群体标签的“频率”，通常不能满足跨群体分析。基因型质量控制采用的频率可以来自当前数据，而关系矩阵中心化采用的频率可能需要固定于某个参照群体；两者必须分别说明，避免在不同步骤中悄悄改变遗传基准。

在简单随机抽取且彼此无亲缘的二倍体样本中，频率估计为 $\hat{p} = (\sum_i M_i) / (2n)$ 。若等位基因拷贝可近似看作独立伯努利变量，则 $\text{Var}(\hat{p}) = p(1 - p) / (2n)$ 。这只是一个起点。在育种资料中，若大量动物来

自少数父母, 拷贝数之间具有相关, 频率估计精度会低于同等数量独立拷贝的情形。一个拥有一千只全同胞或半同胞的样本, 不等价于从整个品种独立抽取一千只动物。有效样本量应结合实际相关结构理解。

在估计罕见等位基因频率时, 报告观察到的拷贝数往往比单独报告小数更有帮助。频率 0.005 可能来自 100 个个体中 1 个拷贝, 也可能来自 10000 个个体中 100 个拷贝; 两者的抽样不确定性和可用于效应估计的信息相差很大。若所有替代等位基因恰来自一个父系家族, 还需要考虑该家族的背景与环境。对低频变异直接套用渐近检验或建立精细分层模型, 常会超出数据真正支持的范围。

26.3.2 观察杂合度与期望杂合度

在频率为 p 的随机结合群体中, 期望杂合度为 $2p(1-p)$ 。观察杂合度则是样本中杂合基因型所占比例。两者不同可能来自近交、选择、群体混合或技术错误, 因此必须先解释样本如何形成。若一个位点在两个互不交配的群体中频率分别为 0.1 和 0.9, 各群体内部满足平衡且样本数相同, 则各自期望杂合度为 0.18; 合并后频率为 0.5, 用合并频率计算的期望杂合度却为 0.5。观察杂合度仍接近 0.18, 出现明显不足, 这正体现了群体混合的影响。

把这一差异直接解释为严重个体近交会产生错误。正确的比较需要在合适层级内计算频率与杂合度, 再研究群体之间的差异。近交和群体结构在真实资料中还可能同时存在, 分层也并非万能; 小群体的频率估计会变得不稳定。较稳妥的流程是结合已有品种来源、主成分、亲缘和生产记录, 提出能够被数据支持的分层, 而不是按想要得到的杂合度结果事后任意切群。

平衡检验的样本量依赖性也值得重视。相同程度的偏离, 在极大样本中可能得到非常小的概率值, 在小样本中却不显著。统计显著不等于技术上不可接受, 统计不显著也不等于没有错误。对于实际质量控制, 应同时考察效应大小, 如观察杂合度与期望值的差距, 以及偏离是否集中于某个实验批次。研究目的不同, 处理可以不同: 一个需要可靠关联检验的位点与一个用于识别品种来源的位点, 并不一定适用相同筛选策略。

26.3.3 逐步过滤为何会改变结论

假如第一次计算频率时保留所有动物，随后删除大量来自某一品种的低质量样本，再以新的频率过滤位点，最终留下的位点集合可能不同于一次性按原频率过滤。这个过程未必错误，但必须清楚其统计定义。样本过滤会改变位点统计，位点过滤又会改变个体检出率和杂合度，因而可以形成反馈。流程应预先规定迭代顺序、停止规则以及是否固定参照频率，而不能因为每一步都使用常见命令就认为整个流程有唯一结果。

PLINK 项目 (2026) 的 PLINK 2 官方文档明确提示，多轮过滤中的频率等统计可能变化，可以保存初始统计并在需要时重新读取。这里真正值得学习的是保持统计参照的原则，而不是记住一组永远不变的软件参数。软件功能会更新，项目应保存执行版本、命令、输入校验值与各轮保留数。若重跑流程后保留动物和位点数变化，需要解释是数据更新、版本差异还是规则改变。可重复质量控制是一个带版本的决策过程，而不是运行结束时一行“全部通过”。

设 100 只动物在某位点的基因型计数为 64、32、4，则替代等位基因频率为 $(32 + 8)/200 = 0.2$ ，随机结合下期望计数也为 64、32、4。若另有 10 只动物因为一个与该位点无关的原因被删除，删除者恰好含较多替代纯合子，新样本偏离平衡并不必然说明检测出了错误；随机删样本本身会引起波动。这个小例要求研究者把“检验所针对的群体”与“筛选留下的样本”分开，而不是把所有变化都归因于实验质量。

Wigginton、Cutler 与 Abecasis (2005) 给出了哈代—温伯格平衡精确检验及高效实现的原始方法，提醒研究者注意稀少等位基因下渐近检验的误差。检验算法正确与随机结合假设适当是两件事；即使使用精确检验，分层和家系抽样仍需根据研究设计解释。Purcell 等 (2007) 的 PLINK 工作为大规模基因型分析提供了重要工具基础，具体过滤行为则应以所用版本的官方文档为准。

26.4 缺失机制、概率判型与不确定性传播

26.4.1 三种缺失问题具有不同含义

一个空白基因型可能表示该样本在该位点没有足够实验信号，也可能表示该芯片根本没有检测该位点，还可能是软件把不可靠结果主动置为缺失。这三种情况不应混在一起。第一类主要是测量不确定性，第二类是设计性缺失，第三类是质量决策的结果。若低密度芯片只给幼龄动物使用，设计性缺失便与出生年份高度相关；如果把缺失指示直接放入模型，模型可能利用年份识别候选批次。即使预测相关提高，也需要追查这种增益是否能在未来继续成立。

缺失完全随机、依赖已观测变量和依赖未观测信息，是帮助组织判断的理论分类。实际项目很少能够证明某一种机制完全成立，但可以通过批次、DNA 质量、组织类型、场区、年龄和表型检查明显违背。比如，病弱动物的样本 DNA 质量较差，删除低检出率样本可能改变健康性状分布；高产种畜获得高密度分型，低产动物只做低密度分型，则测量精度本身反映了选择过程。研究者不能只在结果表中注明删除了多少样本，还应说明删除发生在哪些群体中。

均值填补把缺失基因型替换为 $2p$ ，其优点是简单且使中心化后数值为零。它也隐含了强假设：在可用信息下，该个体没有偏离平均基因型的证据。若缺失是随机的且很少，这可能是可以接受的近似；若一个家系在某一区域集中缺失，均值填补会人为削弱它与亲属的局部相似性。对已经知道亲本和邻近标记的动物，群体均值显然没有使用全部信息，因此需要填充方法进一步利用遗传传递与连锁结构。

26.4.2 全概率与全方差给出清楚的分工

设真实基因型计数为 x ，实验数据为 D ，位点效应暂视为已知常数 a 。条件预测为 $E(ax | D) = aE(x | D)$ ，而不确定性为 $a^2 \text{Var}(x | D)$ 。这两部分分别来自基因型概率的均值和分散程度。若再把 a 视为需要估计的随机量，贡献方差不再只有第一项。特别在基因型与效应后验相关时，不能把二者方差

简单相加；完整推断需要联合后验或明确的条件近似。

用全方差公式可以理解剂量矩阵为何常低估原始基因型的变异。对于随机抽取的动物， $\text{Var}(x) = \text{Var}E(x | D) + E\text{Var}(x | D)$ 。只有当实验信息几乎确定基因型时，第二项才接近零。直接把剂量当作确定值构建关系矩阵，使用的主要是第一项。它可以是合适的预测输入，却不等同于知道了完整基因型。如果训练集与候选集的分型精度不同，关系矩阵对角元的差异中可能含有测量精度差异，需要单独诊断。

设一个位点在一组动物中的真实基因型方差为 0.5，而平均后验方差为 0.15，则剂量方差为 0.35。在该理想设定下，剂量方差占真实方差的比例为 0.7。这个比例描述了基因型信息被实验数据解析的程度，不是性状育种值的可靠度；两种可靠度分别对应不同对象。如果同一个位点的性状效应很小，即使基因型解析度很高，对整体预测也可能贡献有限；反过来，一个关键缺陷位点可能需要极高判型确定性，即使它对普通生产性状预测相关的影响很小。

26.4.3 判型阈值应与损失函数对应

把后验概率最大的类别作为硬判型，是在各类判错损失相同的条件下最小化分类错误率的规则。育种决策中的损失通常并不对称。把隐性缺陷携带者误判为非携带者，可能导致高风险配种；把非携带者误判为携带者，则可能不必要地限制优秀亲本使用。合理阈值需结合两类错误后果、检测可重复性和后续确认手段。这样的风险决策不应由软件默认的最大概率阈值替代，也不应把不确定个体直接写成确定携带者。

例如，某动物携带者后验概率为 0.08。若把携带者误判为非携带者的相对损失设为 20，而反向错误损失为 1，则判为非携带者的期望损失为 $20 \times 0.08 = 1.6$ ，判为携带者的期望损失为 $1 \times 0.92 = 0.92$ 。在这个教学损失设定下，保守分类较优；但实际更合理的行动可能是补做确认检测，因为它能够降低不确定性而不立即牺牲亲本利用。损失数字只是说明决策规则，不是任何遗传病的临床或生产推荐阈值。

在研究报告中，应同时保留剂量、判型概率或相关质量指标，说明哪些

分析使用硬判型，哪些使用剂量，哪些额外传播了不确定性。对测序或填充流程作比较时，不能让一个流程输出剂量而另一个只输出最可能基因型，再把二者差异全部归因于算法优劣。输入信息形式、阈值与输出目标相同，才有可解释的比较基础。

26.5 基因型填充、单倍型与参考群体设计

26.5.1 填充不是从无到有创造基因型

基因型填充利用已观测位点、参考单倍型以及有时可用的系谱信息，推断未观测位点的条件分布。它之所以可能，是因为染色体沿线的位点并非独立，群体成员共享由历史祖先和重组塑造的单倍型片段。低密度芯片或低深度测序只观察其中一部分，参考群体帮助判断目标动物更可能携带哪些片段。若一个稀有单倍型从未出现在参考群体、现有标记又无法区分其来源，软件再复杂也不能可靠恢复它的全部特有变异。

相位推断与填充紧密相关，却是不同任务。对于两个杂合位点，未相位基因型可能都是 1、1，但两条染色体可以是 00 与 11，也可以是 01 与 10。两种组合的个体拷贝数相同，传给后代的单倍型分布不同。相位错误可能对某些逐位点加性预测影响较小，却影响局部同祖片段、隐性缺陷组合和重组解释。因此，评价填充时不能只检查剂量相关；如果下游任务依赖相位，还应考察相位切换错误或相关的传递一致性。

隐马尔可夫模型可把这一思想写得清楚：沿染色体的隐状态描述当前由哪些参考单倍型提供信息，转移概率表达片段切换的可能，观测概率描述芯片或测序读段在给定状态下出现的概率。位点之间距离越远，通常允许更大切换机会；实验误差则使观测不必与某个参考序列完全一致。这里只需要理解条件概率的分解，而不应把参考单倍型的统计复制理解为真实系谱中唯一祖先的身份证明。

26.5.2 谁进入参考群体比总人数同样重要

参考群体可以优先覆盖主要祖先、不同品种来源、不同地域和稀有单倍型。若预算只允许增加少量高密度分型，继续测量已经被大量近亲代表的家系，边际收益可能低于测量一个资料薄弱的支系。另一方面，若部署对象主要来自一个高度闭锁核心群，对其关键祖先补充分型可能有很高价值。不存在独立于目标群体的最优参考面板；优化目标可以是平均填充质量，也可以是最弱亚群质量、特定位点恢复或亲子核查能力。

一个简单的资源配置例子有助于澄清这种选择。设候选群体一半来自家系甲，一半来自家系乙；现有参考资料已充分覆盖甲，却几乎没有乙。若新增十只个体都来自甲，甲的填充质量只略改善，而乙仍差；若一部分分配给乙，总体改善可能更大。真实优化需要利用单倍型频率、亲缘、现有参考覆盖和测定成本，而不是按家系人数机械平均。但这个例子揭示，参考面板扩充应围绕缺口设计，不能只把“人数翻倍”作为有效性的证据。

外部大参考群体可以带来更多单倍型，也可能与本地群体存在较大差异。增加远缘群体不必然降低结果，但也不必然改善稀有变异填充；算法是否能够识别相关参考片段、群体中是否存在相同变异、坐标和等位方向是否一致，都会影响结果。对于杂交动物，还需关注两个或多个祖源的覆盖。只在某一纯种中验证通过的面板，不能自动视为对所有杂交比例都同样可靠。

26.5.3 设计可解释的填充验证

验证可在有高质量基因型的独立动物上模拟低密度观察：遮蔽一部分位点，以剩余信息填充，再与遮蔽前的高质量结果比较。遮蔽模式应模拟真正芯片或测序的设计，而不是只随机删除少量位点。随机遮蔽会保留均匀而丰富的邻近信息，可能高估特定低密度面板的表现。参考群体与验证动物的亲缘也应对应部署；把某动物的重复样本留在参考面板中，会使验证失去原本意义。

总体基因型一致率、剂量与真值相关、非参考等位基因恢复能力以及概率校准，分别反映不同方面。一个频率极低的位点，即使对所有动物都预测为常见纯合子，总一致率也可能很高，但没有正确识别任何少见携带者。因

此应按频率层级报告，并至少给出替代等位基因相关指标。若某层只有几个真实少见拷贝，相关系数本身可能极不稳定；此时应同时列出计数和不确定性，避免用一个漂亮的小数掩盖样本不足。

近期方法进一步提高了大参考群体下的低深度填充能力。Rubinacci 等 (2023) 提出的 GLIMPSE2 主要在人类大规模参考资料中验证；Li 等 (2026, 2025 年在线发表) 的 QUILT2 强调读取层面信息的灵活利用。两者提示，应保留测序不确定性并利用参考结构，而不是过早硬判型。其在人类资料中的性能数值不能直接移植为牛羊项目的承诺，家畜仍需针对群体历史、亲缘和实验平台进行独立比较。软件和参考资源的发展降低了计算门槛，并没有取消目标群体验证。

Li 与 Stephens (2003) 的单倍型复制模型是理解现代填充方法的重要理论入口：一个目标单倍型沿染色体近似复制参考单倍型，允许复制来源改变与观测不一致。这个概率表示把局部连锁结构纳入推断，并不声称真实染色体由软件中少数参考个体直接拼成；算法中的状态是统计近似，生物祖先解释需要额外条件。

26.6 从芯片到低深度测序的测量模型

26.6.1 测序深度为什么不能单独代表信息

平均深度表示读段覆盖的总体程度，但位点覆盖并不均匀。某个样本平均深度相同，在重复区域、GC 含量异常区域或比对困难区域的信息质量仍可能不同。读段错误、等位基因平衡、比对质量与重复读段都会影响基因型似然。把“平均深度达到某个数值”作为全部质量判断的替代，会忽视这些异质性。一个合理报告应说明深度分布、缺失区域、批次差异，以及关键变异类型的有效可判定比例。

在最简模型中，给定某位点真实替代等位基因比例 q_g ， d 条独立读段中替代读段数 k 可近似服从二项分布。对基因型 0、1、2，若每条读段错误率为 ϵ 且无偏倚，可分别取 $q_g = \epsilon, 0.5, 1 - \epsilon$ 。于是每种基因型的似然为 $\binom{d}{k} q_g^k (1 - q_g)^{d-k}$ 。这并非生产软件的完整模型，却展示了观测读段怎样支

持不同基因型：少量读段通常无法给出确定结论，杂合子也可能因抽样恰好只看到一种等位基因。

若真实为杂合子且读段独立无偏，深度 2 时两条读段恰来自同一等位基因的概率为 $2(1/2)^2 = 0.5$ ；深度 6 时为 $2(1/2)^6 = 0.03125$ 。这解释了为什么少量“全部支持某一等位基因”的读段并不等于纯合。若存在等位偏倚，风险还会改变。填充方法利用邻近位点和参考单倍型，可以在低深度条件下补充信息，但补充的是有模型依据的条件推断，并不是把少数读段自动变成高深度实验结果。

26.6.2 似然、先验与后验要分开

基因型似然 L_g 描述在基因型为 g 时观测读段的可能性；基因型先验 π_g 描述在观察这些读段之前对基因型的概率判断；后验则满足 $\Pr(g | D) \propto L_g \pi_g$ 。同样的读段，在不同频率或单倍型背景下可以得到不同后验。这种差异不是随意性，而是条件信息不同的结果。不过，若先验来自不适合的群体，对稀有等位基因的支持就可能被过度压缩。解释结果时应清楚保存原始证据与参考信息各自的作用。

例如，深度为 2、两条读段都支持参考等位基因，令错误率为 0.01。忽略共同二项系数时，三种基因型的似然为 0.9801、0.25 和 0.0001。如果群体频率为 0.5 并采用平衡先验 (0.25, 0.5, 0.25)，未标准化后验为 0.245025、0.125 和 0.000025，归一化后约为 0.6621、0.3378 和 0.0001。尽管两条读段一致，杂合仍有约三分之一概率。若改用少见替代等位基因的先验，后验会更偏向参考纯合；这一改变来自群体信息，而不是新增了实验读段。

这个例子还说明，不同软件输出的“质量分数”可能针对不同事件。有的描述变异存在的证据，有的描述最优基因型与其他基因型的差距，有的描述填充剂量质量。数值同为二十或三十，不表示信息相同。项目必须根据字段定义解释，而不能把不同文件中同名或相似名的列直接合并。对发生版本变化的输出格式，应先用小样本核对含义，再批量导入数据库。

26.6.3 成本设计应围绕最终任务

固定总预算下, 更少动物的高深度测序与更多动物的低深度测序, 各有可能更适合某一任务。高深度有利于发现和确认部分少见变异, 更多动物则有利于估计效应、代表目标群体和扩大参考资料。若下游主要是已知常见位点的加性预测, 高质量参考面板加低成本目标测量可能有效; 若下游是发现尚未进入参考面板的复杂结构变异, 则不能只依赖同样策略。决策应区分发现、填充、预测和风险位点确认四种目的。

对肉羊项目, 可以先进行一个小规模分层试验: 选取多个主要家系和不同来源群体, 在同一批动物上保留高质量比较资料, 再评估若干成本水平的输入方案。评价不应只到填充相关结束, 而应继续追踪关系矩阵差异、候选动物预测变化、校准及关键配种决策。若低成本方案使总体预测几乎不变, 但对极少数风险位点不可靠, 可以采用普通预测测量加关键位点补充检测的组合。这样的分层测量常比要求所有任务都由一种平台完成更符合实际。

当测序信息与芯片资料混合使用时, 还需防止平台成为群体标签。假如历史种畜全部来自芯片, 新候选动物全部来自测序, 观测误差、缺失和剂量分布会与世代重合。应设置跨平台重复样本, 检查等位方向、剂量尺度和关系矩阵对角元, 评估是否需要调整过滤或模型。不应通过事后强行对齐所有统计分布来抹去真实遗传变化; 正确目标是辨别技术差异和群体差异, 并保存能够区分二者的对照资料。

图 26.1 先验为 0.25、0.50、0.25, 观察两个参考等位基因读段且单读段错误率为 0.01 时的后验概率。依据本章独立位点教学模型计算; 不是真实测序项目性能。

26.7 从中心化基因型推导关系矩阵

设 M 为 $n \times m$ 基因型矩阵, 第 j 个位点所计数等位基因频率为 p_j 。令 $\mathbf{1}$ 为 n 维全 1 向量, p 为 m 维频率向量。本章以 W 表示中心化基因型矩阵, 以




图 26.1 低深度观测前后的基因型概率

免与混合模型的随机效应设计矩阵 Z 混淆。中心化矩阵及尺度因子为

$$W = M - 2\mathbf{1}\mathbf{p}^T, \quad s = 2 \sum_{j=1}^m p_j (1 - p_j).$$

在随机结合、位点基因型方差为 $2p_j(1 - p_j)$ 的参照下，一个常用构造是

$$G = \frac{WW^T}{s}.$$

上述内积构造属于 VanRaden (2008) 讨论的基因组关系构造。它把个体间的中心化基因型内积换算到一个共同尺度；尺度与中心化所参照的频率必须共同说明。这里关注的是该构造的含义，不应把它视为所有关系矩阵的唯一标准。

为什么这种内积能进入混合模型？设标记效应向量为 α ，相互独立且方差相同，即 $\text{Var}(\alpha) = I\sigma_\alpha^2$ ，动物的标记遗传值为 $u = W\alpha$ 。由协方差运算，

$$\text{Var}(u) = WW^T\sigma_\alpha^2 = G\sigma_a^2, \quad \sigma_a^2 = s\sigma_\alpha^2.$$

因此， G 并不是先验存在、等待机器读出的唯一生物学事实。它与标记编码、频率参照、位点权重以及随机效应模型共同定义协方差。若先把每个位点除以自身基因型标准差，再平均内积，就相当于改变了原始拷贝数尺度

上的效应方差假定。两种方式都可以建模，但其隐含权重不同，不能只凭矩阵名称判断等价。

任意向量 v 满足 $v^T G v = \|W^T v\|^2 / s \geq 0$ ，故 G 为半正定。若频率由同一批动物估计，则 $W^T \mathbf{1} = 0$ ，从而 $G \mathbf{1} = 0$ 。即使没有重复个体，矩阵也可能奇异；这不是程序错误。非对角元为负也不表示“负的亲属”，而是相对于当前频率参照的基因型偏离方向相反。

26.8 算例一：四只动物、三个位点

考虑下列基因型。所有位点均为常染色体，所计数等位基因方向已经统一。

动物	位点 1	位点 2	位点 3
甲	0	0	0
乙	0	1	1
丙	1	1	2
丁	1	2	1

第一步求频率。三个列和为 2、4、4，共有 8 个等位基因拷贝，所以 $p = (0.25, 0.50, 0.50)^T$ 。第二步从各列减去 $2p_j$ ，得到

$$W = \begin{bmatrix} -0.5 & -1 & -1 \\ -0.5 & 0 & 0 \\ 0.5 & 0 & 1 \\ 0.5 & 1 & 0 \end{bmatrix}, \quad s = 1.375.$$

第三步求内积。甲的对角元为 $(0.25 + 1 + 1)/1.375 = 1.6364$ ；甲与乙的关系为 $0.25/1.375 = 0.1818$ ；甲与丙的关系为 $(-0.25 - 1)/1.375 = -0.9091$ 。

完整结果为

$$G = \begin{bmatrix} 1.6364 & 0.1818 & -0.9091 & -0.9091 \\ 0.1818 & 0.1818 & -0.1818 & -0.1818 \\ -0.9091 & -0.1818 & 0.9091 & 0.1818 \\ -0.9091 & -0.1818 & 0.1818 & 0.9091 \end{bmatrix}.$$

每行之和约为 0，符合前面的推导。四个特征值约为 0、0.1949、0.7273 和 2.7142，因而这是半正定而非正定矩阵。乙在多数位点接近样本均值，所以对角元很小。仅用三个位点时，不能把它机械解释为乙具有极低的近交水平。关系估计的随机波动、标记的代表性和参考群体都限制了这样的解释。

现在把第一个位点的所计数等位基因交换： $M_{i1}^* = 2 - M_{i1}$ ，同时 $p_1^* = 1 - p_1$ 。新的中心化列恰为旧列的负数，其外积不变，故 G 不变。这给出了一个非常有用的程序检查：同步翻转编码和频率应保持关系矩阵；只翻转其中一个则会改变结果。A/T 或 C/G 位点跨平台合并时尤其需要先解决链方向问题。

如果甲在第三个位点缺失，以训练群体均值 $2p_3 = 1$ 填入，其该列中心化值成为 0。均值填补可用于简单教学或低缺失情形，但会缩小相关个体的基因型偏离，不能替代高质量单倍型填充。验证时允许使用哪些候选个体基因型来估计频率或做填充，也应与实际部署保持一致；候选基因型通常可在评定日取得，候选的未来表型则不可取得。

26.9 位点加权、稀有变异与正定性

26.9.1 两种标准化回答不同的问题

设第 j 个位点的中心化剂量列为 w_j ，常见的加性关系构造可写为 $G = c^{-1} \sum_j d_j w_j w_j'$ ，其中 d_j 是非负权重， c 是明确指定的尺度常数。当所有 $d_j = 1$ 且 $c = \sum_j 2p_j(1 - p_j)$ 时，各标记效应在同一等位基因替代单位上具有相同的先验方差。另一种构造先把每列除以 $\sqrt{2p_j(1 - p_j)}$ ，再平均标准化列的外积，它相当于对较低频位点给予较大的替代效应方差。两者不是同一算法的

两个无关实现，也不能仅按所得矩阵对角线是否接近一来判断优劣；它们对应不同的遗传结构假设。对于低频位点，两种矩阵间的差异尤其明显，而恰好这些位点的频率估计与判型误差可能最不稳定。

例如两个相互独立的位点频率分别为 0.5 与 0.01，其二倍体基因型方差为 0.5 与 0.0198。在未经逐列标准化的构造中，频率较高位点对群体平均遗传方差的贡献约为后者的 25.25 倍；在逐列标准化且等权的构造中，两列预期贡献相同。这并不意味着后一方法发现了稀有变异有更大的生物作用，只意味着模型允许稀有等位基因具有更大的替代效应。若只有少数携带者，权重的增加可能同时放大真实信号与某一批次的技术误差。选择构造方式前，应先说明目标是一般加性关系、特定注释富集的预测协方差，还是显式针对稀有变异的研究假设。

26.9.2 权重是先验信息，也是需要验证的选择

非负权重确保半正定性，因为任意向量 v 均有 $v'Gv = c^{-1} \sum_j d_j (w_j'v)^2 \geq 0$ 。因此，给功能注释、测量精度或关联证据赋予权重时，首先要维持这一代数条件。若为了“校正背景”直接设置负位点权重，所得矩阵未必能够作为随机效应协方差。需要表达对比时，可把对比写进固定效应或单独的参数约束，不能默认任何经过解释的相似度都可用于高斯随机效应。即使所有权重非负，训练样本少于有效标记数、样本中心化或家系结构也会造成秩不足；半正定不等于数值上可直接求逆。

权重由训练表型估计时，模型已使用了监督信息。若随后在包含这些训练动物的验证集中宣布加权关系优于等权关系，会把选择权重的收益与泛化能力混在一起。合适的比较应把权重估计、标记筛选、收缩强度与最终预测置于同一训练流程中，在未参与这些步骤的动物上评估。对于来自外部关联研究的权重，也要审查其与本群体是否存在样本重叠、性状定义是否相同、发现研究的效应是否经过独立收缩。所谓外部信息并非天然独立，商业联合育种资料尤其可能在不同项目名称下共享动物。

26.9.3 剂量的不确定性不能靠一项对角修补包办

若 D 表示测序资料，潜在完整基因型为 x ，使用后验均值 $\bar{x} = E(x | D)$ 构建关系具有清楚的测量含义。完整基因型二阶矩满足 $E(xx' | D) = \bar{x}\bar{x}' + \text{Var}(x | D)$ 。当条件误差在个体间独立时，后一个矩阵主要影响对角项；但共享参考单倍型、家系联合判型或批次误差可以产生非对角条件协方差。因此，“剂量关系加上每个动物的后验方差”只在明确的条件独立假设下才有完整解释。实际预测还涉及标记效应不确定性与训练资料的不确定性，不能把这一修正等同于育种值预测误差方差的完整修正。

一个有用的诊断是同时计算剂量矩阵的列方差、平均后验方差与硬判型后的列方差。若硬判型方差显著增大而与高质量验证资料的一致性下降，说明离散化可能把模糊概率变成了虚假的极端基因型。若剂量方差很小，则可能是低覆盖资料缺乏信息，也可能是该群体本来接近单态，必须结合频率和覆盖度辨别。测量信息不足可以通过更好的数据或更合适的测量模型处理，不能靠把矩阵重新缩放到单位对角线宣称问题已被消除。

26.10 基群频率、中心化与跨批次可比性

26.10.1 育种值总是相对于某个参照来表达

一个动物的加性遗传值可以写为若干等位基因替代效应的加总，但把它报告为高于或低于群体多少，必须指定参照。关系矩阵中的中心化也承担这一参照作用。如果每次新增一批候选动物使用全体当前样本重新估计频率，历史动物之间的关系数值也会改变。这种改变不一定是计算错误，而可能源自坐标原点发生变化。问题在于，若未保存频率版本，评定者无法区分本次育种值变化来自新表型、新亲缘信息、参数重估还是参照移动。生产系统应把基群定义、频率来源及报告基准一起管理。

令 p 与 q 为两套频率向量， $W_p = M - 2\mathbf{1}p'$ ，则 $W_q = W_p + 2\mathbf{1}(p - q)'$ 。因此，更换频率不仅改变对角线，也给行列相似度加入与动物平均基因型有关的项。展开外积可以得到原矩阵、两个交叉项及一个常数矩阵项。在尺度常数相同的条件下，这些变化处于由 $\mathbf{1}$ 和 $W_p(p - q)$ 张成的低维空间；若分

母也改变，还要额外考虑整体尺度变化。这个推导说明为什么不同频率下的关系差异常呈现系统性的群体结构，而不是独立的随机噪声。它也提示，简单比较两张关系矩阵的单元格相关系数可能掩盖影响评定的重要低维偏移。

26.10.2 当前样本频率与历史基群频率各有代价

当前样本频率容易取得，且使样本中心化矩阵的列和为零，但它受分型选择和群体构成影响。历史基群频率在理论上更容易与系谱基群相接，却常常没有直接观测，只能通过代表性旧样本、家系模型或祖先信息估计。用少数现存优秀种公畜去代表几十年前的完整基群，会把选择后的频率当成选择前的频率。两者都不是普遍最优的默认值。应根据评定目标、系谱覆盖、数据形成历史和可识别性，明确哪一种参照更合适，再用独立诊断检验其后果。

跨品种分析更需要区分群体均值与群体内偏差。设两个群体的等位基因频率分别为 0.2 与 0.8。基因型为一的杂合个体相对于各自群体中心的值分别为 0.6 与 -0.6，相对于混合群体频率 0.5 则都为零。相同观测基因型并不保证相同的相对编码。若把所有差异都解释为个体加性偏差，模型可能混淆品种均值、等位基因频率与不同环境的平均表现。加入群体固定效应可以控制部分平均差异，却不能自动修复关系矩阵的全部尺度不相容，也不能保证跨品种标记效应相同。

26.10.3 参照变换应保持预测问题的完整性

在纯标记回归中，若含有合适的截距，并对新中心化引起的均值变化同时作出变换，改变编码原点并不必然改变拟合的表型。然而，在随机效应方差被固定、关系被与系谱混合、未知亲本组被约束或者训练与验证使用不同参照时，这种简单的不变性条件可能不成立。因此，不应把“截距能够吸收均值变化”推广为“任何关系基准都不影响评定”。分析者需要指出哪一些量随坐标变换同时调整，哪一些量被人为固定，进而判断这次变化属于等价重参数化还是不同的统计模型。

教学中可用两套频率分别计算同一批动物的 G ，再进行三个比较：矩阵差异、在各自完整模型中的拟合表型差异、用错误参照编码验证动物后的预

测差异。前两个比较可能在适当重参数化下接近，第三个却会暴露实际部署中的偏移。生产流程因此应把训练频率作为模型文件的一部分，并让验证和候选动物调用同一份频率。对于单步评定，还须保存与 A_{22} 匹配的调整系数及混合比例；否则即便标记顺序完全一致，也无法重建过去的关系系统。

26.11 连锁不平衡、群体结构与关系的有效维度

26.11.1 标记数增加不等于独立遗传信息等量增加

相邻标记常因连锁和共同祖先而相关。若连续加入很多几乎重复的列， WW' 会增加这些片段的权重，却未必引入新的预测方向。极端地，把每个位点复制十遍，同时把分母也乘十，关系矩阵完全不变。这个例子表明芯片位点总数不是独立信息量的直接度量。另一方面，删除高度相关位点也未必无害：如果删除方式不均匀，某些染色体或低重组区的相对权重会改变；对于低频变异，表面相关度还可能因样本稀少而不稳定。是否进行剪枝应由关系估计、关联分析或计算压缩等具体目的决定。

关系矩阵的谱提供另一种观察方式。设非负特征值为 $\lambda_1, \dots, \lambda_n$ ，可以定义描述性的有效维度 $d_{eff} = (\sum_i \lambda_i)^2 / \sum_i \lambda_i^2$ 。它在所有非零特征值相等时等于秩，在少数方向占据大部分变异时明显降低。这个指标不是有效群体大小，也不是可以直接代入任何准确性公式的独立染色体片段数；它只描述当前样本、当前编码与当前权重下的矩阵谱集中程度。不同中心化、近亲比例和样本大小会改变它，跨研究比较时必须报告这些条件。

例如三个非零特征值为 4, 1, 1，则 $d_{eff} = 36/18 = 2$ ，尽管矩阵秩为三。若三个值均为二，有效维度则为三。两者具有相同迹，却把相似度分配给不同数量的主要方向。前一种数据中，某一明显的家系或品种对比可能主导预测；若验证集来自同一结构，随机交叉验证可能表现良好，但把模型移到缺少该结构的群体时，收益不一定保留。谱分析因此是理解验证结果的辅助工具，而不是单独决定模型是否可靠的证明。

26.11.2 主成分能指出结构，不能替代生物学调查

基因型主成分常用于显示群体分层、离群样本与批次聚集。一个明显分离的点可能是错样、杂交个体、稀有家系或者测序平台差异；一条连续梯度可能对应地理来源，也可能对应缺失率逐渐变化。给每个点同时标注家系、场群、采样时间和平台，比只依据图形形状作解释更稳妥。主成分的正负号本身任意，重算后符号翻转不代表群体关系逆转；近似相等的特征值还允许对应特征向量在子空间内旋转，因此应该比较子空间与可解释结构，而不只逐列比较相关系数。

在关联研究中控制主成分，通常意在减少群体分层引起的混杂；在育种值预测中，群体结构可能本来就是未来可用的遗传信息。是否作为固定效应调整，要取决于目标是预测全部可遗传差异、仅预测群体内部偏差，还是估计特定位点效应。若机械地把主要遗传方向全部剔除，再报告个体预测能力，可能改变了被预测的对象。反之，若品种与饲养环境完全重合，模型也可能借助遗传结构预测环境差异。区分这些情况需要连接设计和跨环境资料，单凭更高的交叉验证相关不能确定来源。

26.11.3 局部关系与全基因组关系的用途不同

可以为染色体、功能区或单倍型块分别构建关系矩阵。这使研究者能够询问不同区域是否提供额外协方差信息，但多个局部矩阵可能高度相关，方差分量就难以区分。某一区域估计方差较大，既可能表示真实作用，也可能反映它与未建模区域或群体结构的相关。必须检查标准误、边界估计与模型对分区方式的敏感性。基因组划分越精细，参数数目越多，不能把每个小区域的点估计都读成精确的生物学贡献。

关联分析有时把待检验染色体从背景关系中排除，以缓和该区域信号被背景随机效应吸收的问题。这种做法服务于局部检验，并不自动意味着预测候选动物时也应排除同一染色体。预测任务通常希望利用所有在部署时可获得的信息；检验任务则要明确零假设与控制结构。相同的基因型矩阵可以支持不同统计问题，但每个问题对关系构造的要求必须分别说明，不能仅因为软件提供一个选项便跨任务套用其解释。

26.12 算例二：矩阵尺度相容与适度混合

单步评定需要把 G 与已分型动物的系谱子矩阵 A_{22} 结合。若二者参考基群或尺度不同，直接相减其逆矩阵可能引入均值与方差不相容。一个简单的诊断是比较平均对角元与平均非对角元；一种常见调整写成 $G_t = a\mathbf{1}\mathbf{1}^T + \kappa G$ 。令两种平均值分别用 d 与 o 表示，可得

$$\kappa = \frac{d_A - o_A}{d_G - o_G}, \quad a = o_A - \kappa o_G.$$

此式只是两个矩条件的解，并不能自动修复错误系谱、品种差异或选择性分型造成的问题。尤其需要检查调整后的特征值；对矩阵加上负的常数项，不一定保持正定。

设两只动物的原始 G 对角元为 1.3 和 1.1，非对角元 0.1； A_{22} 对角元均为 1，非对角元 0.25。于是 $d_G = 1.2$ 、 $o_G = 0.1$ 、 $d_A = 1$ 、 $o_A = 0.25$ 。代入得 $\kappa = 0.681818$ 、 $a = 0.181818$ ，因此

$$G_t = \begin{bmatrix} 1.068182 & 0.25 \\ 0.25 & 0.931818 \end{bmatrix}.$$

调整保留了两只动物对角元之间的差异，同时让总体尺度与系谱对齐。若为数值稳定或未被标记解释的多基因成分再采用 $G_b = 0.95G_t + 0.05A_{22}$ ，则两个对角元变为 1.064773 与 0.935227，非对角元仍为 0.25。这里的 0.05 只是教学设定，不是普遍最优比例。其值应由建模目的、矩阵稳定性和部署验证共同决定。

“调尺度”与“混合”是两个操作：前者处理均值与量纲参照，后者改变协方差假定并可能改善条件数。报告只写“采用标准基因组矩阵”，而不写频率、权重、调尺度与混合方式，通常不足以复现实验。

26.13 选择性分型、代表性与质量门槛的设计

26.13.1 谁进入基因型数据库本身是一项抽样机制

在育种实践中，分型往往优先覆盖优秀候选、核心种公畜、高价值家系或疑似遗传缺陷个体。这意味着基因型数据库不是总体的简单随机样本。由该数据库计算的频率、亲缘分布和缺失模式，首先描述的是已分型动物。若目标总体包括普通母畜、商品代及淘汰个体，直接将已分型样本的分布外推可能造成偏差。抽样机制尤其会影响罕见等位基因的频率估计、群体间比较以及对“所有动物平均关系”的解释。样本量巨大也不能自动消除这种代表性问题。

一个简单的分层例子可以说明原因。某群体中精英家系占百分之十，其某等位基因频率为 0.4；其余家系频率为 0.1。总体频率为 0.13。若分型数据库中两类各占一半，未经加权的频率为 0.25，差异来自抽样比例而非基因型读数错误。若抽样概率已知且每层均有足够覆盖，可利用分层权重估计总体频率；但当某类动物从未被分型时，没有观察支持的部分不能由权重凭空恢复。质量控制报告应把实验准确性与群体代表性分开，避免把“通过全部位点筛选”误解为“足以代表整个育种群体”。

26.13.2 门槛应从错误后果与信息用途推导

最低判型率、最低频率或最大亲子冲突率都常以固定阈值实施，但阈值不是脱离任务的自然常数。亲本鉴定需要少量信息充分、误差可控的标记；一般加性关系估计更关心大规模位点的总体一致性；致病变异报告则可能要求独立验证和极低的特定位点错误风险。一个对全基因组预测影响很小的错误，若恰好落在用于淘汰种畜的单个位点上，后果可能很大。因此，同一批数据可以有不同用途的质量分层，而不是只有单一的合格或不合格标签。

设严格门槛使一批样本保留率从百分之九十五降至百分之八十五，并使保留样本的技术错误率下降。仅观察保留集内部的准确性，会遗漏被删除动物是否集中于某品种、某场群或低投入养殖系统。如果删除与目标性状相关，严格过滤甚至可能减少模型对最需要预测的群体的适用性。合理比较应同时

报告错误改善、样本损失、结构变化与后续预测影响。对于可补采的高价值样本，重新检测可能优于直接删除；对于不可补采的历史样本，则可考虑以更大的测量不确定性纳入模型，而不是把其信息全部抹去。

26.13.3 数据冻结与未来更新应有明确接口

建立评定模型时，通常需要冻结某一时点可用的表型、系谱和基因型资料。若在验证过程中根据后来的判型版本修正训练动物，却仍声称模拟了当时的预测条件，验证问题就发生了变化。科学研究可以评估使用最终清洗数据的模型，也可以评估生产系统在真实历史信息下的表现，两者都合理，但应分别命名和解释。保留时间戳、软件版本、重判型原因和更改前后记录，使这两种评估成为可能。

更新机制还应区分可追踪修正与不可逆覆盖。一个动物被确认错样后，应记录原关联失效及新关联生效的日期，使历史报告能够解释为何发生变化。参考基因组坐标转换、正反链调整和等位基因规范化也应保存映射表。对于回文型单核苷酸位点，频率相近时仅凭等位基因字母可能无法决定方向，需借助参考链、上下游序列或可信平台注释。不能把模糊位点强行对齐后依靠总体相关较高来掩盖局部错误，因为少数方向颠倒的位点仍可能影响重点性状或缺陷判定。

26.14 大矩阵构建、诊断与可复现计算

26.14.1 精确分块计算与统计近似应分开描述

当个体数为 n 、标记数为 m 时，直接保存双精度稠密关系矩阵约需 $8n^2$ 字节，尚未计入因子分解、临时副本和软件开销。对于十万只动物，单份完整矩阵约为八十吉字节的十进制容量；即使利用对称性，后续求解也可能需要更大内存。这说明瓶颈不仅是标记扫描速度，还包括个体维度上的平方增长。把任务分块可以控制峰值内存，但不能改变最终稠密矩阵的存储阶数。若系统改用低秩表示、稀疏近似或条件独立近似，才是在改变计算对象，必须另行评估近似误差。

按标记把 W 分成 $W_1, \dots, W_B$, 有 $WW' = \sum_b W_b W_b'$ 。只要各块使用同一套样本顺序、频率与权重, 逐块累加是同一个关系矩阵的精确计算, 差异仅来自浮点运算次序。按个体分块则可逐块生成 $W_a W_b'$ 并写入对称位置。最危险的实现错误往往不是矩阵乘法本身, 而是某一块缺少样本、等位基因方向改变、频率被局部重算或者分母重复累计。每块数据应带有明确的样本与位点索引校验, 而不能只凭数组维度恰好相同便相乘。

26.14.2 一组代数不变量能发现高代价错误

关系矩阵应对称, 且在理论允许的舍入误差内半正定。交换个体顺序后, 矩阵应按相同顺序交换行列; 把某个位点的参考等位基因翻转并同步令 p_j 变为 $1 - p_j$, 其中心化列改变符号, 外积应保持不变; 复制全部标记并同步调整分母, 结果也应不变。这些检查不依赖某个具体生物群体, 能够发现方向、分母和索引方面的实现错误。它们不能证明所有样本标签正确, 却能排除一类常被较高总体相关掩盖的技术问题。

样本内频率中心化时还应满足 $W'1 = 0$, 从而 $G1 = 0$, 除非使用了另外定义的缺失处理、加权中心化或附加正则项。此时最小特征值为零具有结构原因, 不能机械判定为数据损坏。相反, 明显负特征值值得调查。一个常见诱因是每一对动物按各自共同非缺失位点计算相似度, 再用不同分母拼成整张矩阵; 每个单元格看似合理, 却未必对应某个统一特征映射的内积。矩阵

$\begin{bmatrix} 1 & 0.9 & 0.9 \\ 0.9 & 1 & -0.9 \\ 0.9 & -0.9 & 1 \end{bmatrix}$ 的特征值为 $1.9, 1.9, -0.8$, 表明逐对合法范围不保证整体协方差合法。

26.14.3 算例：从诊断记录走向研究结论

假设同一批四只动物有两份矩阵, 其中一份在重排样本后与另一份对角线相同, 但非对角元明显不同。首先应根据永久个体标识重建行列映射, 而不是立即调整方差比例。若映射修正后差异消失, 问题属于数据连接; 若仍存在, 再比较频率文件、位点集合与等位基因方向。若差异只出现在低判型

率个体，检查缺失处理和剂量版本；若所有单元格几乎呈线性变换，则检查尺度和基群调整。按这种顺序诊断能够减少把工程错误误判为遗传学发现的风险。

可复现报告至少应保存输入数据的不可混淆标识、样本和位点过滤数量、频率来源、缺失处理、关系公式、矩阵调整、求解精度与模型参数。对于受限的商业或保种资料，不必公开个体原始基因型才能实现方法透明，可以公开字段定义、模拟示例、完整算法和经授权的汇总诊断。教学数据上的正确结果证明实现能处理该例，并不能替代真实生产数据的代表性和安全审查。本章的所有小算例用于解释计算结构，其数字不对应任何真实品种的遗传参数估计。

26.15 关系测量的进展：相似、同祖与可预测性

系谱关系刻画给定系谱下的期望同祖共享；标记内积通常刻画相对于频率参照的共变；连续纯合片段描述沿染色体的纯合结构。这些指标回答的问题不同。近交系数、分子共祖、同祖共享以及预测协方差可能相关，却不能不加定义地互换。育种计划若关心近期近交，可能更关注长纯合片段；若关心加性预测，需要关系矩阵与效应模型匹配。

Meuwisen、Yu 和 Berg (2026) 研究了利用连锁信息近似计算大规模同祖关系的方法，并在模拟和挪威红牛资料中比较不同关系测量。其意义在于用标记辅助区分染色体的亲本来源，使关系信息不再仅依赖每代平均各传递一半的期望。不能由此推论某一种关系矩阵在全部性状和品种中都最优。

对研究者而言，合适的后续问题是：新增的关系信息究竟改善了什么？可以分别检验亲子冲突识别、近期近交测量、跨家系预测以及跨代校准。如果只展示两个矩阵的相关很高，并不足以证明新的矩阵具有实际育种价值；如果预测相关提升很小，却显著改善了近交风险识别，也可能有明确用途。评价指标应先于模型选择确定。

大规模测序还带来一个容易忽略的变化：增加位点数不等于同比增加独立遗传信息。高连锁不平衡区域的重复位点可能主要增加计算量；对少见品

种，芯片设计偏向常见商业品种还可能改变关系估计的代表性。位点密度、频率分布、群体结构和测序不确定性应共同进入数据说明。

开始一次正式评定前，可以从原始数据随机抽取少量动物，沿样本编号、实验批次、基因型、系谱与表型逐项追溯，形成贯通检查。再选取亲子、全同胞、重复样本和不同群体动物，查看它们在关系矩阵中的相对位置是否符合基本预期。这些检查不用于凭经验修改结果，而用于发现编号错位或系统性技术错误。只有数据身份能够追溯，复杂模型的精度才有可信的基础。

26.15.1 从关系改进到预测价值的证据链

同祖关系利用染色体来源的定义，内积关系利用所观察等位基因的共变定义；在有限标记和不完整系谱下，两者都含有估计误差。评价新测量时，应把目标关系的定义、算法近似误差与有限数据误差分开。用模拟资料可知道真实继承片段，因而比较估计关系与真实关系；在真实动物中，往往只能借助可靠家系、重复测序或外部预测结果作间接评估。模拟中较小的关系误差并不必然在每个性状上转化为较大预测收益，因为收益还取决于训练规模、表型质量与遗传结构。

另一项应预先指定的选择是时间尺度。共同祖先较近的长片段更容易被现有标记识别，远古共有片段的识别则依赖更密集信息与更强的模型假设。不同方法若隐含不同的祖先时间范围，所得关系不同可能反映定义差异，而非一方失败。将近期近交控制、长期多样性保存与当代性状预测放在同一评价表中时，必须给每个目标单独定义指标和决策作用。育种管理需要可解释的证据组合，不能让一张综合相关系数表替代对各目标的判断。

26.16 关系矩阵的测量误差：先辨认条件方向

关系矩阵由许多个体的基因型共同计算，一个位点上的测量错误会同时进入多个关系单元。要研究这种传播，首先必须说明哪个量被视为固定、哪个量在重复测量中变化。下面将真实中心化基因型矩阵记为 W ，测量矩阵记为 $\tilde{W}$ ，尺度常数 $s > 0$ 暂时固定。这个处理把基因型测量与频率估计分开，便于辨认两类不确定性。VanRaden (2008) 的内积构造给出了关系与标记

效应模型连接；在此基础上，还需要研究输入内积的随机性。

经典加性测量模型假定

$$\widetilde{W} = W + E, \quad E(E | W) = 0.$$

条件于真实基因型，展开矩阵乘积得到

$$E(\widetilde{W}\widetilde{W}^T | W) = WW^T + \Omega, \quad \Omega = E(E E^T | W).$$

于是直接用测量内积所估计的关系平均多出一项：

$$E(\widetilde{G} | W) = G + \frac{\Omega}{s}, \quad G = \frac{WW^T}{s}.$$

这里的零均值假定相当强。错误若更容易把少见纯合子判为杂合子，测量误差通常依赖真实基因型，其条件均值未必为零。上式不能直接作为所有判型错误的校正公式。然而，它揭示一个清楚的机制：独立个体误差主要抬高对角线，共同批次误差则可能同时抬高非对角关系。仅检查平均对角线是否接近一，无法区分两者。

考虑一个位点、两只动物，取 $s = 1$ ，真实中心化基因型为 $(-0.5, 0.5)^T$ 。设测量误差包含个体独立成分与两动物共同成分：

$$\Omega = 0.09I + 0.04\mathbf{1}\mathbf{1}^T = \begin{bmatrix} 0.13 & 0.04 \\ 0.04 & 0.13 \end{bmatrix}.$$

真实关系与测量关系的条件期望分别为

$$G = \begin{bmatrix} 0.25 & -0.25 \\ -0.25 & 0.25 \end{bmatrix}, \quad E(\widetilde{G} | W) = \begin{bmatrix} 0.38 & -0.21 \\ -0.21 & 0.38 \end{bmatrix}.$$

共同误差把两只动物推向同一方向，独立误差则增加各自的偏离。对差值方向 $c = (1, -1)^T$ ，共同成分被抵消，额外二次型为 $c^T \Omega c = 0.18$ ；对和方向 $(1, 1)^T$ ，额外二次型为 0.34。同一质量缺陷对群体均值与动物比较影响不同，不能把一个平均错误率理解为所有育种任务共同承担的风险。

现在改变条件方向。测序与填充常输出给定实验资料 $\mathcal{D}$ 后的基因型概率。令 $\bar{W} = E(W | \mathcal{D})$, 则真实内积的后验期望为

$$\begin{aligned} E(WW^T | \mathcal{D}) &= \overline{WW}^T + \Psi, \\ \Psi &= E\{(W - \bar{W})(W - \bar{W})^T | \mathcal{D}\}. \end{aligned}$$

这是对潜在真实量取条件期望, 因而需要向剂量内积加回条件方差; 前面的经典测量模型则是对重复测量取期望, 若要去偏, 需要减去测量方差。两式一加一减并不矛盾, 所条件的对象不同。把二者混用, 会产生方向相反的修正。

例如某个中心化位点的剂量均值为 $(-0.4, 0.6)^T$, 其条件协方差为

$$\Psi = \begin{bmatrix} 0.24 & 0.08 \\ 0.08 & 0.24 \end{bmatrix}, \quad E(WW^T | \mathcal{D}) = \begin{bmatrix} 0.40 & -0.16 \\ -0.16 & 0.60 \end{bmatrix}.$$

只补对角线会把非对角元保留为 -0.24 , 遗漏共享参考信息带来的 0.08 。这里给定的是一个相容的二阶矩教学模型; 用于离散基因型时, 还须确保均值与协方差来自合法的联合概率分布, 而不能任意指定。

还有一个计算边界值得强调。经典去偏矩阵 $\hat{W}\hat{W}^T - \Omega$ 虽可无偏, 却未必半正定。若某次测量恰好得到零矩阵而 Ω 正定, 去偏结果就是负定。无偏性是重复抽样的平均性质, 协方差合法性是每次使用时的整体约束。可采用潜变量模型、受约束估计或有明示含义的正则化; 把负特征值删除属于进一步估计步骤, 应重新评价其偏差。相反, 完整的后验二阶矩天然半正定, 但把它代入预测方程仍只是某种矩估计方案, 通常不等于对所有可能基因型进行完整后验积分。

这个条件分布可以由合法离散状态直接构成。以计数减一为中心化规则, 让第一只动物只取零或一个拷贝, 第二只只取一个或两个拷贝。四种联合计数状态依次为零与一、零与二、一与一、一与二, 概率分别为零点二四、零点一六、零点一六、零点四四。分别求边际均值、方差与交叉矩, 即得到上述剂量和协方差。由此可见, 个体后验方差相同并不表示个体后验误差独

立。若填充程序只输出边际概率，丢失的联合结构不能从这些边际值唯一恢复；需要联合模型输出、适当的后验样本或明确的近似假定。

测量校正还受到可识别性限制。仅观察一份有噪声基因型，通常无法把真实群体差异与系统技术偏差唯一分开。跨平台重复样本提供了比较依据，但若两个平台共享同一个参考比对错误，它们的一致仍可能掩盖共同偏差。最有价值的对照往往同时改变能够产生错误的环节，并覆盖不同家系与频率层级，而不只是把同一输入文件重复运行。关系矩阵的统计模型必须与实验对照相互配合，才有条件判断应该校正什么。

26.17 频率误差的低维传播与尺度不确定性

基群频率不仅决定编码原点，还决定关系矩阵的分母。频率估计的轻微变化因此可以产生两种效应：若干共同方向的平移，以及所有方向的统一缩放。将二者分开，可以解释为什么某些动物比较对频率十分稳定，而整体遗传方差却明显改变。

记

$$\begin{aligned} W(p) &= M - 2\mathbf{1}p^T, \\ s(p) &= 2 \sum_j p_j (1 - p_j), \\ G(p) &= \frac{W(p)W(p)^T}{s(p)}. \end{aligned}$$

设频率扰动为小向量 h 。用微分表示一阶变化，有

$$dW = -2\mathbf{1}h^T, \quad ds = 2 \sum_j (1 - 2p_j) h_j.$$

对分子和分母同时求导，可得

$$\begin{aligned} dG &= -\frac{2}{s} \{ \mathbf{1}h^T W^T + W h \mathbf{1}^T \} \\ &\quad - \frac{ds}{s} G. \end{aligned}$$

第一行的变化至多落在一个很低维的空间中，第二行则影响整个关系矩阵。若只检查关系单元之间的相关，统一缩放很容易被忽略；若只检查最大特征值，低维的基准移动又可能被误认为广泛的遗传结构改变。

令 c 为总权重为零的动物对比, 即 $c^T \mathbf{1} = 0$ 。于是中心化频率从对比分子中严格消失:

$$c^T G(p) c = \frac{\|M^T c\|^2}{s(p)}, \quad d\{c^T G c\} = -\frac{ds}{s} c^T G c.$$

这个结果比“截距吸收中心化变化”更具体。它只说明零和对比的分子不受原点影响; 分母仍可能变化, 关系与系谱混合时也还有其他约束。若同时调整遗传方差, 使 $G\sigma_a^2$ 保持相同, 对比协方差才可能不变。因此, 应追踪协方差乘积, 而不能只看关系矩阵一个部件。

取一个位点, 两只动物基因型为零和一。使用 $p = 0.25$ 时, $s = 0.375$ 。对单位长度对比 $c = (1, -1)^T / \sqrt{2}$, 有

$$c^T G c = \frac{0.5}{0.375} = 1.333333.$$

若参照频率改为 0.30, 分子仍为 0.5, 分母变为 0.42, 故

$$c^T G(0.30) c = 1.190476.$$

在 $p = 0.25$ 处, $ds/dp = 1$, 一阶导数为 $-0.5/0.375^2 = -3.555556$ 。用线性近似预测频率增加 0.05 后的值, 得到 1.155556, 与精确值相差约 0.034921。这个差距来自二阶项, 提醒读者: 导数揭示局部敏感方向, 却不保证对较大变动仍精确。接近单态时分母很小, 同样的频率误差会被进一步放大。

如果频率来自独立参考样本, 且其估计协方差为 V_p , 可以把一个关系函数 $t(p)$ 的抽样不确定性近似写为

$$\text{Var}\{t(\hat{p})\} \approx \nabla t(p)^T V_p \nabla t(p).$$

这里必须保留频率之间的协方差。连锁位点、共同家系与不等抽样权重都会使 V_p 不是对角矩阵。把每个位点的标准误分别计算后相加, 默认了额外的独立性; 在长连锁片段中, 这个默认可能明显低估共同漂移。

更困难的是频率由参与关系计算的同一批动物估计。此时 $\hat{p}$ 与 M 相关, 不能把 M 固定后套用独立参考样本的公式来得到完整抽样方差。样本中心

化会产生确定约束 $G1 = 0$ ，也是这种依赖的直接表现。若研究对象是给定当前动物的关系比较，可以条件于其基因型；若研究对象是随机抽取另一个育种群体后的关系估计，则需要对样本形成过程一起建模。条件分析与总体分析各有用途，但它们不能共用一个未经说明的标准误。

从设计上看，补充分型未充分代表的基础来源，可能比在已经很密集的家系里增加更多近亲，更能减少频率参照的不确定性。不过，改变参考资料同时也改变了估计对象的代表性。应先给基群下定义，再讨论精度；大量精确测定的当前精英个体，不能仅凭数量充足就自动代表未选择的历史基群。

频率误差还可能与选择目标方向一致。若分型优先覆盖高指数动物，许多位点的小频率偏移会共同沿选择轴累积。此时每个位点偏移都不大，但其在动物间投影形成的低维结构可以很明显。用全体位点平均绝对频率误差衡量这一问题，可能忽略方向性。可以同时考察基群对比、出生年份和选择分层上的矩阵二次型，判断差异是否集中在有明确生物学意义的方向。这样的诊断描述的是选择与测量共同造成的结果，不应直接将所有年份关联解释为真实遗传趋势。

若希望把频率文件冻结以便长期比较，还应区分冻结参照与冻结信息。固定参照能够保证报告坐标一致，却不禁止新增样本改善基因型判断或关系估计。反之，每次重新估计频率也不必然错误，只是需要明确转换规则和相应方差尺度。稳定的参照使变化更容易解释，并不意味着生物群体停止进化。研究者应在固定旧参照的比较和更新参照的正式分析之间保留可计算的映射。

26.18 从关系扰动到预测扰动：哪些方向最脆弱

关系矩阵元素相差很小，不保证预测差异小；反过来，某些明显的关系变化也可能几乎不影响当前预测。原因是预测同时依赖关系、残差和观测向量的方向。以下在均值已知、残差同方差的模型中建立一个可以直接计算的灵敏度表达式。

令 K 表示已经包含遗传尺度的协方差，残差协方差为 λI ，其中 $\lambda > 0$ 。

预测算子为

$$B(K) = K(K + \lambda I)^{-1} = I - \lambda(K + \lambda I)^{-1}.$$

另一套测量产生 $K + E$ 。用逆矩阵差的恒等式, 得到精确关系

$$\begin{aligned} B(K + E) - B(K) &= \lambda(K + E + \lambda I)^{-1} \\ &\quad \cdot E(K + \lambda I)^{-1}. \end{aligned}$$

因此, 一阶预测变化为

$$d\hat{u} = \lambda(K + \lambda I)^{-1} E(K + \lambda I)^{-1} y.$$

扰动并非只乘一次表型, 而是在两侧受到信息精度的过滤。若误差集中于强信息方向, 两个逆矩阵会压低其影响; 若集中于弱信息方向, 影响可能较大。还要看观测是否在该方向上有分量, 没有被当前右端项激发的方向, 可能对点预测影响很小, 却仍影响预测误差方差。

取两个正交方向, 协方差特征值分别为 2 与 0.1, 令 $\lambda = 0.5$ 、观测方向分量均为一。原预测为

$$\hat{u} = \left(\frac{2}{2.5}, \frac{0.1}{0.6} \right)^T = (0.8, 0.166667)^T.$$

若只把第二个特征值增加 0.05, 第二个预测变为 $0.15/0.65 = 0.230769$, 变化为 0.064103。若把同样大小的扰动加到第一个特征值, 第一预测变为 $2.05/2.55 = 0.803922$, 只变化 0.003922。两个扰动的矩阵范数完全相同, 预测后果却相差十余倍。讨论“质量控制后关系只改变很少”时, 应检查变化落在哪些遗传方向。

只要新旧协方差均半正定, 算子范数可以给出保守上界:

$$\begin{aligned} a &= \lambda_{\min}(K + E) + \lambda, \\ b &= \lambda_{\min}(K) + \lambda, \\ \|B(K + E) - B(K)\|_2 &\leq \frac{\lambda \|E\|_2}{ab}. \end{aligned}$$

最小特征值越小，上界越可能宽；它能排除某些大误差，却不提供逐动物的紧确保证。如果协方差近似产生明显负特征值，首先应解决模型合法性，而不能继续将上述半正定前提下的界当作充分保障。

对具体选择问题，往往更关心候选差值。令 c 为一个固定对比，则

$$|c^T d\hat{u}| \leq \lambda \| (K + \lambda I)^{-1} c \|_2 \cdot \| E \|_2 \| (K + \lambda I)^{-1} y \|_2 .$$

这把资料质量与决策连接起来：同一关系误差，对连接充分的候选比较与跨弱连接群体比较，容忍度不应相同。可针对实际重要的差值或经济目标检查扰动，而不是只追求整张矩阵一个漂亮的平均相关。

还应区分测量误差和模型定义差异。一个按频率标准化的关系与一个按等替代效应方差构造的关系，差异未必是“错误”；二者可能代表不同先验。2026 年 Meuwisen、Yu 与 Berg 关于大规模同祖关系估计的研究，进一步说明利用连锁与祖先来源可以改变关系信息的表达。评价此类改变，需要先固定希望预测的随机量，再比较信息支持与校准。上述扰动公式可以量化两个协方差方案的局部后果，却不能决定哪一个更接近真实遗传机制。

点预测对某次扰动不敏感，也不能证明预测区间安全。一个恰好与观测正交的方向可能没有改变当前均值，但其先验方差与后验方差仍会变化；下一批动物或另一个性状的观测一旦投影到该方向，均值差异就会出现。因而测量方案比较至少需要一个代表性的观测集合，不能只选一个使两模型特别接近的右端向量。对于多性状资料，还要关注经济权重较大而表型较稀缺的方向，它们可能对关系失配尤为敏感。

灵敏度分析可以分成全局界与局部实算两步。全局界帮助确认极端误差是否可能，局部实算则使用实际候选对比说明其数量级。当全局界很宽而局部差异很小时，应报告二者各自含义，不能把宽界写成必然损失，也不能把一次小差异写成普遍保证。若扰动很大，应直接求解新模型；把一阶近似无限外推会遗漏逆矩阵自身改变造成的非线性效应。

26.19 矩阵尺度匹配的合法性与不可识别方向

把两张关系矩阵匹配到相同的平均对角与平均非对角，是常见的初步处理，但两个矩条件不能保证所有方向都相容。尤其当调整包含负的常数项时，正定性可能被破坏。需要把矩匹配看作一个明确的低维变换，再检查它在整个空间中的后果。

设原关系 G 正定，考虑

$$G_t = bG + a\mathbf{1}\mathbf{1}^T, \quad b > 0.$$

用合同变换白化原矩阵，令 $v = G^{-1/2}\mathbf{1}$ ，可得

$$G^{-1/2}G_tG^{-1/2} = bI + avv^T.$$

在与 v 正交的方向上，特征值都是 b ；在 v 方向上，特征值为 $b + av^Tv$ 。因此正定的充要条件为

$$b + a\mathbf{1}^TG^{-1}\mathbf{1} > 0.$$

这比“调整系数看起来不大”更有判断力。原矩阵在共同方向越缺少方差，负的秩一调整越危险。若 G 本来奇异，上述逆矩阵表达不能直接使用，应先在可支持子空间内分析，并单独检查零空间与 $\mathbf{1}$ 的关系。

以 $G = I_2$ 、 $b = 0.8$ 、 $a = -0.45$ 为例，调整后为

$$G_t = \begin{bmatrix} 0.35 & -0.45 \\ -0.45 & 0.35 \end{bmatrix}, \quad \lambda(G_t) = (0.8, -0.1).$$

所有对角元都为正，却存在负方差方向。若把 a 改为 -0.30 ，两个特征值变为 0.8 与 0.2 ，才得到正定矩阵。这个反例也说明，逐元素的合理范围无法代替整体检验；两只动物的和具有何种方差，与两只动物各自有正方差是不同的问题。

对任何零和对比 c ，常数项仍会被抵消：

$$c^TG_tc = bc^TGc.$$

于是两个矩阵可以在所有动物差值上只相差一个比例，却在共同均值方向上完全不同。若模型包含自由截距且只评价中心化对比，某些共同方向可能没有被表型识别；若随后把矩阵接入系谱、元基础群体或遗传趋势评估，它们又可能变得相关。因此，“当前预测几乎相同”不能推出所有后续用途均等价。

纯尺度转换还有一个容易被忽略的不识别性。若模型遗传协方差为 $G\sigma_a^2$ ，对任意 $c_0 > 0$ ，

$$\begin{aligned} G^* &= c_0 G, & (\sigma_a^2)^* &= \frac{\sigma_a^2}{c_0}, \\ G^* (\sigma_a^2)^* &= G\sigma_a^2. \end{aligned}$$

只要其他定义同步，表型协方差与预测保持不变。遗传方差参数从一点二变为零点六，可以仅仅是关系尺度翻倍，不能据此宣布生物学变异减少。相反，若关系翻倍而方差参数被固定，模型确实改变了，收缩通常随之变化。研究比较必须说明被保持不变的是参数数值、协方差乘积还是发布单位。

在有固定效应的模型里，可取满足 $LX = 0$ 的满行秩对比矩阵 L 。限制似然通过 Ly 获得的信息只涉及

$$\text{Var}(Ly) = L(G\sigma_a^2 + R)L^T.$$

若一个协方差改动 Δ 满足 $L\Delta L^T = 0$ ，仅凭这些对比无法识别它。这不是软件不足，而是模型中没有相应信息。不能通过优化器返回了唯一小数，就推断共同遗传基准已被精确估计。需要额外连接、外部参照或明示约束，才能把这一方向固定下来。

进一步看，多群体尺度匹配不能只靠全体平均完成。两组的对角均值可以在总体上恰好抵消，却分别偏高和偏低；总体非对角均值也可能主要由人数最多的群体决定。此时两个全局矩条件虽满足，少数群体的对比方差仍然失配。应针对预先定义的群体内与群体间对比检查相容性，并说明参数是否足以表达这些差异。增加调整参数可以提高拟合自由度，也会增加估计不确定性；应依靠外部信息或独立验证决定复杂度，而不是不断调到现有输出看起来最平滑。

矩阵合法性也不等于遗传解释充分。任意正定矩阵都可作为某个高斯向量的协方差，但不必符合亲子传递、基群关系或目标性状的效应结构。正定检查是必要的数学入口，后面仍要核对参照、单位与生物连接。把数值修正视为最终解释，会让关系矩阵承担它没有获得的数据证据；把每个修正写成模型中的具体假设，则可以让读者判断其适用边界。

26.20 以目标对比设计复测：质量投入的边际价值

质量控制常被组织为一系列统一阈值，但复测预算真正需要回答的是：再测哪只动物、哪个位点或哪个批次，能最多降低当前重要目标的不确定性？这个问题可以在一个线性测量模型中明确计算。下面暂把中心化遗传特征视为连续量，以便展示信息更新；离散基因型的精确设计应使用其相应概率模型。

设尚不确定的特征向量为 x ，当前条件协方差为 V 。新增测量为

$$z = h^T x + \eta, \quad E(\eta | x) = 0, \quad \text{Var}(\eta) = r > 0.$$

若联合正态，测量后的协方差为

$$V_{new} = V - \frac{V h h^T V}{h^T V h + r}.$$

对目标 $t = c^T x$ ，复测带来的方差减少恰为

$$\Delta_t = \frac{(c^T V h)^2}{h^T V h + r}.$$

分子表示待测方向与目标尚未解释部分的联系，分母包含该方向自身不确定性和测量噪声。单独选择当前方差最大的样本，并不总能最有效改善目标；与目标几乎无关的高方差方向，可能更适合其他研究，却不能为眼前候选比较提供很多信息。

考虑两只动物的某个遗传特征，当前协方差为

$$V = \begin{bmatrix} 0.36 & 0.12 \\ 0.12 & 0.25 \end{bmatrix}.$$

希望准确比较两动物，取 $c = (1, -1)^T$ ，则当前差值方差为 0.37。若以误差方差 $r = 0.04$ 复测第一只动物， $h = (1, 0)^T$ ，有

$$\Delta_1 = \frac{(0.36 - 0.12)^2}{0.36 + 0.04} = 0.144.$$

复测第二只动物则得到

$$\Delta_2 = \frac{(0.12 - 0.25)^2}{0.25 + 0.04} = 0.058276.$$

两种方案的测量精度相同，前者对差值的收益更大。第一方案后差值方差降为 0.226，第二方案后为 0.311724。若第一方案价格为四个成本单位、第二方案为一个成本单位，则每单位成本收益分别为 0.036 与 0.058276；预算有限且测量可独立选择时，结论又可能改变。不能只比较一次测量的绝对收益而忽略资源约束。

若目标换成两动物的平均值，取 $c = (1, 1)^T/2$ ，分子分别使用 0.24^2 与 0.185^2 ，所得收益与差值目标不同。这说明质量投入应服务于明确任务。用于高风险隐性位点确认、群体频率估计和候选经济指数比较的复测清单，不必相同。

对于同一线性测量方向、固定噪声方差且误差相互独立的重复测量，连续复测的边际收益递减。不同测量方向则可能互相补充，不能无条件宣称其收益递减：一条对目标边际上无信息的测量，在另一条混合方向测量加入以后，可能通过分离干扰成分而变得有用。每加入一条测量，都应更新 V ，再计算下一次边际减少；把第一次的收益乘以复测次数，会忽略新旧资料的重叠。若两次实验共享提取或比对误差，还应把它们的噪声协方差写入模型；同一份样本在同一流程下重复运行，可能无法揭示样本身份错误或共同平台偏差。

在关系矩阵任务中，目标常为二次函数而非线性 $c^T x$ 。可先在当前均值附近线性化，用关系函数对潜在基因型的梯度作为设计方向；若概率质量分布在不同基因型状态且明显非线性，应直接计算各结果下的预期决策损失。线性化提供容易解释的起点，不构成对低深度离散判型的普遍保证。

这种设计思想把质量与代表性连接起来。一个来自稀少家系的样本，可能通过条件协方差改善整个家系的关系估计；一个重复很多的核心家系样本，新增信息可能很少。但是，某些重大错误后果具有不对称性，例如把缺陷携带者误作安全亲本，此时平方误差不一定是合适损失，应采用相应风险概率。合理的质量投入既要回答“平均误差减少多少”，也要回答“哪些具体决策因此得到更可靠的依据”。

26.21 本章练习与参考答案

练习 26.1 某位点在 10 只二倍体动物中的拷贝数总和为 6，求频率、中心化时应减去的量以及该位点对尺度因子 s 的贡献。

答案： $p = 6/20 = 0.3$ ，每个基因型减去 0.6，尺度贡献为 $2 \times 0.3 \times 0.7 = 0.42$ 。分母 20 来自等位基因拷贝数，不能误用个体数 10。

练习 26.2 说明为什么用本批样本频率中心化所得 G 可能不可逆，而 $G + 0.01I$ 可逆；后一个操作是否完全没有统计影响？

答案：全 1 向量属于 G 的零空间；增加 $0.01I$ 把全部特征值提高 0.01，因此成为正定矩阵。此操作同时增加了独立个体方差成分，改变了协方差模型和预测收缩，不能只称作“消除误差”。

练习 26.3 两个群体的 G 对角元均值不同，能否据此断定一个群体近交更严重？

答案：不能。须先统一频率参照、位点集合、编码、缺失处理与尺度，再明确所用近交定义；标记抽样与群体差异也会影响比较。即使完成统一，不同近交指标仍可能反映不同时间尺度。

练习 26.4 两个各含五百只动物的亚群，在某位点均满足随机结合，等位基因频率分别为 0.2 与 0.8。求各亚群期望杂合比例、混合后的真实期望杂合比例，以及把混合群体视为单一随机结合群体时的期望杂合比例。偏离能否直接证明实验错误？

答案：每个亚群的杂合比例均为 $2 \times 0.2 \times 0.8 = 0.32$ ，故混合后的期望仍为 0.32。混合频率为 0.5，若错误套用单群体平衡，则得到 0.5。预计观察

到的杂合动物为三百二十只，而错误参照为五百只。差异由群体分层即可产生，无须假设任何判型错误。应先按亚群检验，同时调查混合比例、近交及实验批次；若批次与亚群完全重合，还应通过跨批次重复样本区分技术与生物来源。

练习 26.5 一个低深度样本在某个位点有两个参考等位基因读段，测序错误率为 0.01，三个基因型先验概率为 0.25, 0.5, 0.25。计算后验概率和剂量。为什么不能因为两个读段一致就认定参考纯合？

答案：三个似然分别为 $0.99^2, 0.5^2, 0.01^2$ ，乘先验后的权重为 0.245025, 0.125, 0.000025，权重总和为 0.37005。归一化后约为 0.662140, 0.337792, 0.000068，剂量约为 0.337927。即使忽略测序错误，杂合个体产生两个相同方向读段的概率也不为零。先验及附近单倍型信息会继续改变后验，因此这只是独立位点教学模型，不能把结果当作某软件的实际判型值。若先验来自不匹配群体，也要进一步评估先验敏感性。

练习 26.6 关系矩阵的四个特征值为 3, 1, 0, 0。求秩、迹和本章定义的有效维度。如果给矩阵加上 $0.1I$ ，这三个量怎样变化？这种改变是否增加了实测标记信息？

答案：原秩为二，迹为四，有效维度为 $16/10 = 1.6$ 。加对角项后特征值为 3.1, 1.1, 0.1, 0.1，秩为四，迹为 4.4，有效维度为 $19.36/10.84 \approx 1.7860$ 。这些变化来自协方差正则化，并没有增加任何新测量。矩阵变得可逆及描述性有效维度上升，不应被宣传为获得了新的独立遗传证据；它改变的是模型在原先缺少支持的方向上分配的方差。

练习 26.7 某育种群体中两类家系分别占 0.2 和 0.8，目标等位基因频率分别为 0.6 和 0.1。分型样本却来自两类各一半。求总体频率与分型样本期望频率，并提出一个估计总体频率的设计。

答案：总体频率为 0.2，样本期望频率为 0.35。若两类内样本具有代表性且群体比例已知，可以先估计各类频率，再按总体比例加权。更好的前瞻设计是保证每类及主要家系均有随机或可追踪概率的分型样本，同时保留精英动物的业务分型。若类内仍按表型选择，简单分层权重未必足够；应记录

选择规则并考虑更细分层或模型。总体频率的标准误还要考虑家系相关，不能把所有等位基因拷贝视为独立重复。

练习 26.8 拟比较芯片与低深度测序对基因组关系和育种值预测的影响。请设计一个能够分别识别平台测量差异、参考群体差异和验证泄漏的研究。

答案：先在代表主要家系、频率范围与实验批次的同一批动物上取得两种测量，并用独立高质量资料核验部分位点。固定基因组版本、方向、训练频率与目标动物集合，比较剂量误差及关系谱，再单独改变参考面板研究填充影响。表型预测采用时间或家系隔离的验证，所有依赖表型的权重和参数只在训练内部估计。候选基因型是否参与填充应按部署情境预先规定。结果同时报告预测能力、校准、低频携带者错误与成本，而不能用总体基因型一致率替代全部结论。真实生物性状和品种外推只对实际覆盖的资料范围成立。

GBLUP、岭回归、贝叶斯与核方法

许多基因组预测方法看起来使用不同语言：有的估计数十万个标记效应，有的只处理动物间关系，有的讨论先验分布，有的讨论相似性函数。把这些方法放回“协方差决定信息如何传递”的框架中，会发现它们既有等价之处，也有不可忽略的差别。本章首先建立一个可以手算的桥梁，再讨论什么时候改变先验或核函数有实际意义。

27.1 同一个预测问题的两种表示

设 W 为经过明确编码与尺度化的 $n \times m$ 标记矩阵， X 为固定效应设计矩阵。标记模型写作

$$y = X\beta + W\alpha + e, \quad \alpha \sim N(0, I\sigma_\alpha^2), \quad e \sim N(0, I\sigma_e^2).$$

令 $u = W\alpha$ ，则 $\text{Var}(u) = WW^T\sigma_\alpha^2$ 。在固定均值已知或已在同一模型中正确处理的条件下，标记效应后验均值也是岭回归解：

$$\hat{\alpha} = (W^TW + \lambda I)^{-1} W^T(y - X\beta), \quad \lambda = \sigma_e^2/\sigma_\alpha^2.$$

这里先把 β 视为已知，是为看清标记部分；实际有场年季、性别或日龄效应时，应联立估计，不能先用全体数据消除固定效应后再声称完成了独立验证。未作惩罚的截距还应与标记中心化约定一致。

使用恒等式 $(W^TW + \lambda I)^{-1} W^T = W^T (WW^T + \lambda I)^{-1}$ ，即可得到

$$\hat{u} = K(K + \lambda I)^{-1}(y - X\beta), \quad K = WW^T.$$

上面的岭方程按标记求解,核方程按个体求解;在同一编码、同一尺度、同一方差比以及同一固定效应处理下,两者给出相同预测。若 K 进一步除以常数 c 作为 G ,遗传方差和惩罚参数必须同步换算。只替换矩阵而不改变方差定义,就不再是同一个模型。

从选择指数的观点看, $\text{Cov}(u, y) = \text{Var}(u)$, $\text{Var}(y) = \text{Var}(u) + I\sigma_e^2$, 于是最优线性预测仍然是交叉协方差乘以信息协方差的逆,再乘以观测偏差。基因组标记改变的是协方差来源,而非这个基本逻辑。Meuwissen、Hayes 和 Goddard (2001) 把密集标记的全基因组联合预测推进为系统方法,是本章讨论的历史起点。

还可把这种收缩放在关系矩阵的特征方向上理解。设 $K = U \text{diag}(d_i) U^T$, 其中 U 正交, $d_i \geq 0$ 。将观测转到这些方向后,第 i 个方向乘以 $d_i / (d_i + \lambda)$ 。例如, $d_i = 9$ 而 $\lambda = 1$ 时保留 90% 的观测分量; $d_i = 0.1$ 时只保留约 9.09%。模型保留的是有协方差结构支持的方向,而不是按表型大小逐只动物判断可信程度。零特征值方向完全被移除,说明标记模型不能创造标记空间之外的遗传信息。

这个解释也说明正则化为什么必要。两个几乎相同的标记列可以用许多互相抵消的效应组合得到近似相同的训练拟合。无惩罚估计可能产生很大、符号相反的系数;它们对新数据中的微小差异极为敏感。适当收缩降低这种不稳定性,但过强收缩又会压缩真实差异。偏差与方差的权衡是方法选择的实质,训练残差最小并不是最终目标。

实际记录的精度可能不同。例如,一个母羊的性状来自一次测定,另一只来自多次重复测定后的均值。若它们具有不同残差方差,就应使用相应的残差协方差矩阵 R ,标记方程中的信息矩阵变为 $W^T R^{-1} W$ 。观测越精确,通常得到越大信息权重;但同一动物或同一家系记录存在相关时,简单按记录次数加权仍可能重复计算信息。重复力和永久环境应在模型中处理。

27.2 固定效应、残差投影与可识别的遗传差异

27.2.1 不惩罚的均值与受惩罚的标记承担不同任务

育种资料中的场年季、性别、胎次和测定日龄既影响表型均值，也与遗传来源存在联系。标记回归若忽略这些因素，可能把饲养管理差异分配给标记；若先用全体资料回归掉这些因素，再进行交叉验证，又可能让验证表型参与训练。正确处理不只意味着模型中出现若干固定效应名称，还意味着这些效应在每次训练和预测中的信息来源清楚。对于一个训练中从未出现的新场，任意场固定效应无法从已有数据直接估计；必须另设可外推的协变量、层级结构或明确的预测基准。

设 R 为已知正定残差协方差，固定效应设计矩阵 X 列满秩。对给定标记效应 α ，最小化加权残差平方得到 $\hat{\beta}(\alpha) = (X'R^{-1}X)^{-1}X'R^{-1}(y - W\alpha)$ 。将其代回目标函数，可定义残差投影算子

$$Q = R^{-1} - R^{-1}X(X'R^{-1}X)^{-1}X'R^{-1}.$$

于是岭方程为 $(W'QW + I/\sigma_\alpha^2)\hat{\alpha} = W'Qy$ 。这里 R 已经含残差方差，不能再无理由重复乘一个残差精度。 $QX = 0$ 说明固定效应方向不会进入标记信息； Q 通常是半正定而非可逆矩阵，因此不应把它当作一张完整的残差协方差再求逆。若 X 不满秩，应明确约束或使用广义逆，使可估计函数保持一致。

27.2.2 算例：家系与环境完全重合时能识别什么

设四只动物分别来自两个场，前两只均在场一，后两只均在场二。某一标记列为 $w = (0, 0, 2, 2)'$ 。若 X 含截距和场二指示变量，那么 w 完全处于 X 的列空间，故 $Qw = 0$ 。无论表型差异多大，数据都不能把这个位点的效应与场差异分开。加入正态先验可给出数值上唯一的标记估计，但这个估计的分配受到先验或约束决定，不能宣称观察已经分离遗传与环境。只有增加跨场连接，例如相同家系在两个场均有后代，或者引入独立的环境实验，才可能增加区分两种来源的信息。

若改为 $w = (0, 1, 1, 2)'$ ，在各场内去均值后得到 $(-0.5, 0.5, -0.5, 0.5)'$ 。取残差方差一，并设场内表型偏差为 $(-1, 1, -0.5, 0.5)'$ ，则 $w'Qw = 1$ 、 $w'Qy = 1.5$ 。先验方差一时，标记估计为 $1.5/(1+1) = 0.75$ 。这个数字只利用场内对比；场间平均差异没有被误当作额外标记证据。它说明良好的实验连接不是矩阵计算之后的附属讨论，而直接决定似然究竟能支持哪一些遗传差异。

27.2.3 预校正只有在信息边界一致时才可等价

在线性模型、相同权重且同一数据子集下，通过适当投影消去固定效应可以与联合求解等价。但实际常见的“先校正后预测”并不满足这些条件：有时先用全数据估计环境效应，有时对表型作复杂平滑后忽略平滑估计误差，有时使用另一套动物和权重构造校正值。此时第二步所用残差不再具有原先假定的独立同方差结构。对于大型生产流程，分步法可以因计算便利而合理使用，但应明确其近似和误差传播，而不能仅凭形式上都写成 $y - X\hat{\beta}$ 就宣布完全等价。

验证中的新动物还涉及固定效应预测误差。若验证动物所在场年组在训练中有大量同期记录，环境均值相对精确；若该组完全未知，预测表型需额外承担环境不确定性。两类情境可以拥有相同的育种值模型，却有不同表型预测误差。报告应分别说明评价的是环境校正后表现、原始表型，还是加性育种值的代理变量，并把对应的可用环境信息固定下来。

27.3 算例一：从标记效应走到动物育种值

设三个个体、两个已经中心化的标记特征为

$$W = \begin{bmatrix} -1 & 0 \\ 0 & -1 \\ 1 & 1 \end{bmatrix}, \quad y = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}.$$

为突出算法等价性，设固定均值已知为 0，两个方差均为 1，所以 $\lambda = 1$ 。

有 $W^T W = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$, $W^T y = (2, 1)^T$ 。岭方程因此为

$$\begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \hat{a} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \hat{a} = \begin{bmatrix} 0.625 \\ 0.125 \end{bmatrix}.$$

乘回标记矩阵，三个动物的预测值依次为 -0.625 、 -0.125 和 0.750 。它们并不等于表型。第二个动物的表型虽然为 0，却因与另外两个动物共享标记结构而得到负的预测值。BLUP 利用的是整个协方差系统，不能简单理解为每个动物各自乘上同一个遗传力。

现在改为关系表示。 $K = WW^T$ ，其行分别为 $(1, 0, -1)$ 、 $(0, 1, -1)$ 和 $(-1, -1, 2)$ 。解 $(K + I)c = y$ ，再计算 Kc ，得到完全相同的三个预测值。这是检查软件实现的一项强有力的数值测试：在小型例子中，应同时实现两种求解路线并比较结果；大规模程序的速度不能代替这种正确性检查。

还可以求预测误差协方差：

$$V_\delta = K - K(K + I)^{-1}K.$$

其对角元为 0.375、0.375 和 0.500。相应先验方差为 1、1 和 2，因此已知均值、已知方差下的可靠度 $1 - V_{\delta,ii}/K_{ii}$ 分别为 0.625、0.625 和 0.750。第三只动物预测误差方差较大，却有更高可靠度，因为可靠度比较的是误差与自身先验方差的比例。若均值和方差需要估计，尤其样本极少时，这一条件性计算不能当作无条件保证。

27.4 谱收缩、有效自由度与样本外误差

27.4.1 从奇异值分解看两种求解为何等价

把标记矩阵写为 $W = UDV'$ ，其中只保留非零奇异值 d_i 。标记岭估计在每个方向上乘以 $d_i / (d_i^2 + \lambda)$ ，动物拟合值则乘以 $d_i^2 / (d_i^2 + \lambda)$ 。这两个系数不同，因为前者把表型映射到标记效应，后者又乘回一个标记矩阵。混淆

奇异值与核矩阵特征值，会使收缩因子误差达到平方量级。动物间关系的特征值是 d_i^2 ，因此上一节关系表示的收缩公式与此完全一致。零奇异值方向不被数据识别，正态先验把相应标记分量的后验均值固定在零，但仍允许其后验不确定性存在。

在线性平滑形式 $\hat{y} = Sy$ 下，可用 $\text{tr}(S)$ 描述拟合的有效自由度。已知均值且 $R = I\sigma_e^2$ 时，它等于 $\sum_i d_i^2 / (d_i^2 + \lambda)$ 。这个量可以是非整数，并随惩罚增加而减小。若还估计一个不受惩罚截距，通常需要计入该截距的自由度，但要避免与已经中心化的特征方向重复计算。有效自由度不是被选择的标记个数：即使所有标记效应都非零，强收缩模型也可能只消耗较少的拟合自由度。

27.4.2 算例：同一总信号下不同方向的偏差与方差

考虑两个正交特征方向，核特征值为九与一，残差方差为一，采用 $\lambda = 1$ 。两个方向的保留比例为 0.9 与 0.5，有效自由度为 1.4。若在这两个方向上把真实信号暂时固定为二与二，则估计的条件偏差分别为 -0.2 与 -1，估计方差分别为 0.81 与 0.25，相应均方误差为 0.85 与 1.25。后一个方向的方差更小，却因收缩偏差较大而有更大误差。由此可见，单独比较估计值稳定性不能决定预测质量。

这里的偏差是把真实信号固定后的频率学条件偏差；在随机效应模型下，对先验分布再平均时，后验均值具有另一种校准解释。两种论述并不矛盾，只是平均所针对的对象不同。育种文献中的“无偏”也需要说明是在整个随机动物总体、给定真实育种值、给定被选择状态，还是给定预测值的条件下。收缩估计可在某一种定义下无偏，同时在另一种定义下呈现向总体均值靠拢的条件偏差。准确使用条件符号，比简单给方法贴上有偏或无偏标签更有价值。

27.4.3 训练拟合越好为什么仍可能预测越差

当 λ 趋近于零，非零方向的训练拟合几乎不收缩；若矩阵秩足够大，训练残差可很小。但新的动物只在训练特征空间中获得支持，低信息方向的大

幅估计会把噪声传递给新样本。另一方面,若 λ 过大,所有动物的预测接近均值,训练与验证都可能丧失有用差异。最佳惩罚依赖真实信号分布、噪声、训练规模和部署群体,不能仅由特征值大小唯一确定。谱图可以显示模型可能在哪些方向不稳定,却不能替代独立验证选择复杂度。

在多品种或强家系结构中,最大特征方向常对应群体之间差异。如果主要表型差异同时来自未充分校正的管理条件,模型沿大特征方向保留的信息可能含有环境信号。相反,某些真实群体内遗传差异可能处在较小特征方向而被强烈压缩。解决办法不是把大特征值一律删除,而是改进固定效应和连接设计,并用符合目标的验证评估。只有在因果问题被明确提出且具备额外识别条件时,才能进一步讨论这些方向是否代表特定遗传机制。

计算上还应避免为画一张完整谱图而进行不必要的全矩阵分解。大型数据可以用针对主要特征方向的迭代分解,或以迹估计和随机投影作诊断;这些近似应报告误差或稳定性。若近似仅用于诊断,而正式预测仍求解原系统,则不能把诊断近似误差误当作预测近似误差。区分数学对象与计算用途,是评价任何加速技术的基本习惯。

27.5 不等精度表型、重复记录与代理育种值

27.5.1 信息权重来自方差而非记录名称

测定制度常把不同资料都整理成每只动物一行:有的是一次直接测定,有的是多次记录均值,有的是后裔均值或既有育种值。如果把这些量放进同一个同方差回归,就默认它们对遗传效应提供同样精度且互不重复的信息,这通常不成立。应先写出每种记录与目标遗传值的关系。例如均值记录可能为 $\bar{y}_i = \mu + u_i + p_i + \bar{e}_i$, 其中 p_i 为永久环境;重复测定次数增加只能降低暂时环境部分的方差,不能消除 p_i 。权重若简单与记录次数成正比,会让多记录个体被过度信任。

设永久环境方差为四,单次暂时残差方差为六。一次记录相对育种值的环境方差为十;四次均值的方差为 $4 + 6/4 = 5.5$ 。信息精度增加到原来的 $10/5.5 \approx 1.818$ 倍,而不是四倍。若两只动物的记录还共享同一测定日环境,

则它们的残差存在非零协方差。只给每行一个独立权重无法表示这种共享,必须用残差块结构或额外随机效应描述。增加数据行数并不总能等量增加独立信息,这一原则同样适用于重复基因型和多个高度相关的组学测量。

27.5.2 已有评定值不能当作未经加工的表型

传统评定值包含亲属资料、模型收缩和共同参数估计。把它们直接作为基因组训练响应,可能让高可靠度与低可靠度动物承担同样权重,也可能使训练动物之间共享的信息被重复计算。Garrick、Taylor 与 Fernando (2009) 系统推导了去回归与不等精度加权的联系。去回归或其他代理响应构造的目的,是把既有收缩和信息量转成可处理的响应与权重;不同方案对亲本平均、共同资料与可靠度有不同假设。使用者应明确代理量近似什么、其误差是否相关、权重是否来自与本次模型独立的信息,而不能把“已经去回归”视为所有依赖已被消除的保证。

一个极简一维模型有 $z = u + e$, $\text{Var}(u) = 1$, $\text{Var}(e) = 3$, 则基于 z 的 BLUP 为 $\hat{u} = z/4$, 可靠度为 0.25。若把 $\hat{u}$ 作为新回归的直接响应,响应方差为 0.25, 且已被明显压缩。将其除以 0.25 可以回到 z , 但前提是这确实是单一独立记录模型。真实评定中含亲本均值、关系耦合和多性状信息,逐个动物照用同一公式未必恢复正确的响应协方差。因此,教学反演只说明收缩需要考虑,不是通用业务去回归方案。

27.5.3 缺失性状、选择记录与联合模型

不同性状具有不同的记录覆盖。奶量可能广泛记录,而某项疾病或饲料效率仅在小部分动物中测定。把没有记录的动物删除,可能损失连接信息并改变训练总体;把缺失值填成均值则会创造不存在的观测。多性状或多层级混合模型可以利用真实记录之间的遗传与环境协方差,但其预测能力取决于这些协方差是否可识别、是否稳定,以及测定选择机制是否被合理处理。若只有表现优良的动物进入高成本测定,联合模型还需要包含导致选择的可观测信息或对选择过程作敏感性分析。

面对这类资料,实践中可先建立记录形成流程图:哪些动物在什么年龄、

因什么条件获得哪种测量, 哪些信息在选种时已经可用。随后才决定直接记录模型、代理响应模型或多性状模型。流程中的时间顺序尤其关键。用候选动物后来发生的疾病记录来构建当前可用的校正育种值, 再把其当作独立训练输入, 会改变原本的前瞻预测问题。计算上的方便不能覆盖信息时间边界。

对于模型比较, 所有方法应尽量共享同一响应定义和信息权重。若一个方法使用多性状原始记录, 另一个只使用低可靠度单性状代理值, 差异不能全部归因于岭先验与贝叶斯先验的优劣。必要时可以比较完整工作流程, 但应明确结论是流程的综合收益, 并同时提供能够分离数据与算法贡献的辅助分析。这样才能把研究结论转化为可执行的育种改进。

27.6 贝叶斯方法改变了什么

岭回归对应正态、独立、同方差的标记效应先验。它允许每个标记都贡献微小效应, 并把不充分支持的估计拉向 0。贝叶斯扩展常改变三件事: 允许不同标记具有不同方差; 允许部分标记效应严格为 0; 允许多个尺度的混合分布。共同之处是都在有限表型信息下约束大量未知量。

设单个位点的近似观测效应为 $\tilde{\alpha}$, 条件于真实效应有 $\tilde{\alpha} | \alpha \sim N(\alpha, s_{\alpha}^2)$; 先验为 $\alpha \sim N(0, \tau^2)$ 。将两个正态密度相乘并完成平方, 后验均值为

$$E(\alpha | \tilde{\alpha}) = \frac{\tau^2}{\tau^2 + s_{\alpha}^2} \tilde{\alpha}.$$

这不是神秘的“先验压过数据”, 而是方差相加后的信息权衡。观测精确时 s_{α}^2 较小, 收缩较弱; 观测不稳定时收缩较强。先验方差的尺度必须与基因型编码一致, 频率标准化后沿用原先先验会改变模型。

算例二: 相同观测精度, 不同效应尺度。两个位点的近似效应为 1.0 和 0.2, 观测方差均为 0.25。若先验方差分别为 1.0 和 0.1, 则后验均值为 $1/(1 + 0.25) \times 1 = 0.8$, 以及 $0.1/(0.1 + 0.25) \times 0.2 = 0.05714$ 。若两者都用先验方差 1.0, 第二个位点会得到 0.16。不同结果直接来自对遗传结构的不同约束。

这个算例用于解释一维收缩, 不能照搬为多位点联合分析公式。存在连

锁不平衡时，标记效应的似然相互联系，一个位点的较大效应可能被邻近标记分担。后验包含概率也不等于该位点具有生物学因果效应的概率，除非模型、候选变量集合与因果识别条件另有充分论证。

采样方法还需要检查链的混合、有效样本量、对初值与先验的敏感性，以及不同链间的一致性。迭代次数很大不必然意味着后验已充分探索。对于预测任务，最值得比较的仍是未来数据上的损失和校准，而不是训练数据拟合得是否更紧。

27.7 层级先验、稀疏混合与连锁不平衡

27.7.1 改变先验相当于改变什么样的效应更常见

正态同方差先验在所有标记上给予相同尺度的连续收缩。层级先验允许 $\alpha_j | \tau_j^2 \sim N(0, \tau_j^2)$ ，再对 τ_j^2 指定分布；积分掉局部方差后，可以得到比正态分布更厚的尾部，使少数大效应受到较弱收缩。另一类模型引入指示变量 γ_j ，当其为零时效应固定为零，为1时来自连续分布。还有模型让效应在几个不同方差的正态分布间混合。它们分别表达连续异质性、显式变量选择以及多尺度效应结构，并不只是给同一个岭回归换名称。

这些先验所作用的单位是经过编码的标记效应。一个真实因果变异可能被很多连锁标记共同标记，因而“只有少数因果位点”并不必然意味着所用芯片上只有少数非零回归效应。反过来，真实遗传结构高度多基因时，在小训练样本中只有少数区域获得可识别信号，稀疏模型也可能有预测用途。应该把生物学稀疏性、统计回归稀疏性与有限样本可识别性分开。仅凭某个稀疏模型预测较好，不能断言已证实性状由少数基因决定。

27.7.2 算例：后验包含概率依赖似然与先验两部分

考虑一个近似独立的效应观测 z ，误差方差为 s^2 。零效应模型为 $z \sim N(0, s^2)$ ，非零模型在积分掉效应后为 $z \sim N(0, s^2 + \tau^2)$ 。两模型的密度比为

$$BF = \sqrt{\frac{s^2}{s^2 + \tau^2}} \exp \left\{ \frac{z^2}{2} \left(\frac{1}{s^2} - \frac{1}{s^2 + \tau^2} \right) \right\}.$$

若非零先验概率为 π ，后验概率为 $\pi BF / (1 - \pi + \pi BF)$ 。取 $z = 1$ 、 $s^2 = 0.25$ 、 $\tau^2 = 1$ ，贝叶斯因子约为 2.2151。当 $\pi = 0.1$ 时后验包含概率约为 0.1975；当 $\pi = 0.5$ 时则约为 0.6890。同一观测证据并不产生唯一的包含概率，差异来自稀疏程度的事前假定。

这并不表示先验可以任意操纵结果。一个可辩护的分析应说明先验来源，检查它在合理范围变化时预测与解释是否稳定，并用数据量足够的层级结构更新共享参数。若对几十万个标记同时赋予很大的非零先验概率，先验预期非零数也会很大；如果不检查这一总体含义，单个位点看似温和的先验可能累积成强烈假设。先验预测检查可以先模拟表型尺度或总遗传方差，判断先验是否与研究问题的合理数量级一致。

27.7.3 连锁块内变量竞争限制单个位点解释

当两个标记列完全相同，似然主要识别 $\alpha_1 + \alpha_2$ ，而难以区分各自贡献。稀疏先验可能偏好只选择其中一个，后验采样可能在两个等价解释之间切换。此时单个位点的包含概率可以各约一半，而该区域至少一个位点有作用的后验概率接近一。把单个位点阈值用于筛选，可能错误地认为整个区域缺少证据。对于解释任务，应考虑区域汇总、联合可信集合及其假设；对于预测任务，则应检查不同等价分配是否影响候选动物的预测。

训练与部署群体的连锁结构改变时，这种等价性也可能消失。训练中两个标记完全相关，部署群体却出现新的重组单倍型，那么相同训练拟合的两组效应会给出不同预测。这个现象为跨群体预测提供了具体机制：问题不只是平均频率变化，还包括训练数据未能区分的标记解释在新群体中发生分离。增加有代表性的训练单倍型、整合可信功能信息或直接测量因果变异可能帮助，但每一种改进都需要实际外部验证，不能由模型名称保证。

27.8 后验计算、预测区间与参数不确定性

27.8.1 后验均值、后验众数和一次迭代不是同一个量

正态线性模型中，后验均值与众数相同，因此岭解既可以从平方惩罚优化得到，也可以从正态后验得到。进入稀疏混合、非正态先验或非线性模型后，这一等价通常消失。后验均值对多种可能的效应配置取平均；众数选择密度最高的配置；一个迭代算法停止时的状态则未必对应其中任何一个。若研究报告只写“贝叶斯估计”，却没有说明输出是均值、众数、中位数还是某种近似，读者无法准确重建预测和区间的含义。

在平方误差损失下，条件后验均值是贝叶斯最优点预测；在绝对误差损失下，后验中位数更合适；在具有不对称损失的管理决策中，则需要相应后验分位数或直接最小化期望损失。育种目标常涉及多性状经济收益、淘汰风险与长期多样性，单个育种值均值不一定足以完成全部决策。先把预测分布估计清楚，再根据实际损失选择决策规则，比把某一个点估计称作普遍最优更严谨。

27.8.2 计算诊断关心的是有效探索而非迭代总数

后验采样产生相关序列。十万次高度相关的抽样可能比几千次混合良好的抽样提供更少信息。应检查多条链的分布是否一致、关键预测量的有效样本量是否足够、蒙特卡洛标准误是否小于决策容忍度，以及不同初值是否进入相同的后验区域。连锁块中个体标记效应交换会导致某些参数混合缓慢，但动物总预测可能已经稳定；反过来，少数高价值候选的尾部概率也可能比总体平均更难估计。因此，诊断应覆盖最终用于决策的量，而不只展示一个总体遗传方差的轨迹。

若采用变分近似或确定性迭代，速度可能明显提高，但应区分优化收敛与后验逼近准确。目标函数不再变化只能说明算法在当前近似族中稳定，不能证明后验方差正确，也不能证明没有局部最优。可以在可计算的小子集或模拟问题中与更精确方法比较，重点考察预测均值、区间覆盖和候选排序是否受到近似影响。近似偏差如果远小于生产允许误差，可能完全可以接受；

如果影响稀有缺陷携带者的风险判断，则需要更谨慎的局部核验。

27.8.3 算例：方差参数的不确定性也会进入预测区间

设某动物在两个可能的超参数状态下，育种值条件后验分别为 $N(1, 0.2)$ 和 $N(2, 0.3)$ ，两种状态后验概率各一半。总体后验均值为 1.5。由全方差公式，总体后验方差为条件方差均值 0.25 加上条件均值的方差 0.25，合计 0.5。如果只选择一个平均参数状态并报告接近 0.25 的条件方差，就可能遗漏相当一部分不确定性。这里的混合仅为教学构造，但清楚显示参数估计并非总可忽略。

真实模型中还要区分育种值区间与未来表型区间。若未来表型含独立环境方差一，在上述例子中其总预测方差为 1.5；若预测的是多次记录均值，则新增环境方差应按重复结构计算。若未来动物与训练资料共享场效应，还应包括相应协方差，而不能简单相加。区间的覆盖对象、信息时点与是否条件于估计参数必须写明，否则不同研究报告的百分之九十五区间并不可直接比较。

后验区间是否在频率学重复抽样意义下达到标称覆盖，还取决于模型和先验是否适当。模型错设、选择性记录或群体迁移可以使很窄的后验区间系统性偏离真实值。独立验证因此不仅用于选择均方误差最低的方法，也用于检查不确定性报告是否可信。对于无法观察真实育种值的生产资料，可以借助后期独立记录、设计良好的模拟和分层校准诊断形成互补证据，避免把任何单一代理当作真值。

27.9 核方法：把相似性写进协方差

关系矩阵本身就是一种线性核。更一般地，给定特征向量 w_i, w_j ，可用正半定核函数 $k(w_i, w_j)$ 构造 K 。例如，高斯核为

$$K_{ij} = \exp\{-h \|w_i - w_j\|^2\}, \quad h > 0.$$

随后仍可使用前述核预测公式的形式求预测，但此时 K 所表达的相似性已经不局限于线性标记组合。带宽 h 小，距离差异被压缩，个体看起来更

相似； h 大，只有十分接近的个体之间保留较强信息共享。带宽与惩罚参数共同决定函数的平滑程度，应在训练数据内部选择。

考虑一维特征位置 0、1、2，取 $h = 1$ 。相邻个体的核值为 $e^{-1} = 0.3679$ ，两端之间为 $e^{-4} = 0.0183$ ，对角元均为 1。核在这里表达的是“特征近者预测相互借力较多”，而不是断言相邻个体的系谱亲缘系数为 0.3679。若另一个模型把这些核预测值直接称为加性育种值，就必须补充遗传传递含义。

Gianola 与 van Kaam (2008) 系统讨论了再生核希尔伯特空间方法在基因组辅助数量性状预测中的使用。核方法提供灵活函数类；它并不保证在样本有限、跨群体或跨代预测时优于线性模型。

对育种而言尤其要区别总遗传表现与可遗传的加性部分。包含显性或互作的预测可能更适合某一既定杂交组合的商品表现，而育种值通常用于预测随机配偶条件下的后代平均贡献。模型复杂度提高以后，预测目标的定义应更加严格。可以显式设 $y = X\beta + u_a + u_d + u_{aa} + e$ ，分别配置加性、显性与互作核；但多个核高度相似时，方差分解可能弱可识别，预测稳定也不代表各方差分量大准确。

27.10 样本外核预测与训练参照的一致性

27.10.1 训练核只是联合协方差的一部分

在训练动物上得到一张拟合良好的核矩阵，并不自动定义对任意新动物的预测。还需要新动物与训练动物之间的交叉核，以及新动物自己的先验核值。设训练核为 K ，新动物交叉核列为 k_* ，均值已知且残差方差比为 λ ，则预测为 $\hat{f}_* = k'_*(K + \lambda I)^{-1}y$ 。在相应高斯模型中，条件预测方差与 $k_{**} - k'_*(K + \lambda I)^{-1}k_*$ 成比例。这个表达式把均值预测与不确定性同时连接到训练资料覆盖，而不是只依赖新动物自身的表型或特征大小。

如果一个新动物与所有训练动物的核相似度都很小，预测会回到先验均值，条件方差则接近先验方差。这是模型承认资料支持不足的合理表现。某些外推算法在训练范围外仍给出很大的确定性数值，看起来更有区分度，却未必更准确。育种部署应识别哪些候选处在训练信息边界之外，并把低支持

与低遗传价值分开。预测接近均值可能意味着信息不足，并不等于该动物真实价值平庸。

27.10.2 核中心化必须使用训练定义

若要在特征空间中去除训练均值，训练核可写为 $K_c = JKJ$ ，其中 $J = I - \mathbf{1}\mathbf{1}'/n$ 。新动物与训练动物的中心化核，不能仅从 k_* 减去它自己的平均值，还需要减去训练核的列均值并加回训练总体均值。对第 i 个训练动物，其中心交叉核为

$$k_{c,*i} = k_{*i} - \frac{1}{n} \sum_j k_{*j} - \frac{1}{n} \sum_j K_{ji} + \frac{1}{n^2} \sum_{j,l} K_{jl}.$$

若在候选批次内部另行中心化，相同动物的预测可能随同时提交的其他候选变化。某些联合评定确实允许这种依赖，但应把它作为明确的转导式信息使用，而不能与固定训练模型的独立部署混为一谈。对模型服务而言，保存训练均值和尺度通常是保证单个预测可重现的必要条件。

27.10.3 算例：线性外推与局部相似性产生不同预测

考虑训练位置 $x_1 = -1, x_2 = 1$ ，观测 $y = (-1, 1)'$ ，均值已知零，惩罚参数为一。线性核 $K_{ij} = x_i x_j$ 给出 $K = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$ ，解系数为 $(-1/3, 1/3)'$ 。在新位置 $x_* = 2$ ，交叉核为 $(-2, 2)'$ ，预测为 $4/3$ 。线性模型把训练趋势沿相同方向延伸，位置距离增大时预测绝对值也可增加；其遗传解释依赖这一线性特征是否对应适当的效应编码。

若改用高斯核 $\exp\{-(x_i - x_j)^2\}$ ，训练非对角核为 e^{-4} ，系数为 $(-a, a)'$ ，其中 $a = 1/(2 - e^{-4}) \approx 0.504621$ 。在 $x_* = 2$ ，与两个训练点的核值分别为 e^{-9} 与 e^{-1} ，预测约为 0.185578。在更远的位置，两个交叉核都趋近零，预测趋近均值。两种模型的差异不是谁在数值计算上出错，而是一个假设全局线性延伸，另一个假设局部相似性支持。真正的优劣只能在目标群体与合适损失下判断。

27.10.4 距离的单位决定带宽的含义

高斯核中的距离若由几十万个未经处理的基因型列构成，其量级会随标记数、频率、缺失处理和特征尺度改变。因此，带宽数值一不能跨数据集直接比较。常见策略是按特征数、平均距离或特定尺度归一化，但每一种都改变可解释的相似性单位。归一化统计应从训练数据计算，并应用于验证数据；若使用全体候选基因型估计无监督尺度，应说明这符合部署信息条件，而不能把未来表型混入同一步骤。

高维空间中的距离还可能高度集中，使所有非对角核值接近相同水平。这时调整带宽只是把矩阵从近似常数核推向近似单位核，中间可区分的几何结构有限。可以先检查距离分布、核特征值及其与家系和批次的联系，再决定是否进行特征选择或分区建核。把更多组学列直接并入距离并不总能增加信息，若多数列是噪声或平台效应，反而可能淹没已有遗传结构。核灵活性需要与特征质量共同评价。

对于多种测量平台，核函数还隐含对缺失和尺度差异的处理。若训练有全部特征而部署缺少某一组测量，简单把缺失组置零可能改变整个距离几何。应在训练时模拟实际可用模式，或者建立可处理模态缺失的联合模型。模型的输入契约是统计定义的一部分，而不是软件上线时才考虑的工程细节。

27.11 加性、显性与互作预测的传递含义

27.11.1 预测个体表现与预测亲本贡献必须区分

加性育种值的核心是特定参考群体与交配制度下，个体等位基因平均替代效应的加总。显性偏差取决于同一位点两个等位基因的组合，互作偏差还取决于不同位点组合。一个动物自身表现受这些成分共同影响，但它向后代传递的是配子，后代的组合又由另一亲本决定。因此，包含显性与互作的总遗传预测可帮助选择商品杂交组合，却不能未经转换就代替亲本加性贡献。预测精度越高，越需要确认预测的对象与育种决策目标一致。

加性与非加性分解并非完全脱离群体频率的固定属性。在给定基因型效

应下, 平均替代效应可以随频率和交配结构改变。一个位点在某群体内表现出的加性方差, 可能在另一群体中不同, 即使分子机制未变。因而“这个性状显性很强”需要说明是基因型效应层面的论断, 还是特定群体方差分解的估计。把一个群体的方差比例直接用于另一个频率差异很大的群体, 会忽略这种参照依赖。

27.11.2 一个可以手算的正交编码

在单个位点随机结合且等位基因频率为 p 、 $q = 1 - p$ 时, 加性编码可取 $a(g) = g - 2p$, 其中 $g = 0, 1, 2$ 。一种显性编码依次取 $-2p^2, 2pq, -2q^2$ 。按基因型概率 $q^2, 2pq, p^2$ 加权, 两种编码均值均为零, 交叉乘积均值也为零; 加性编码方差为 $2pq$, 显性编码方差为 $4p^2q^2$ 。由此可以构造在该参考条件下正交的加性与显性关系。正交来自特定频率及随机结合假设, 不应把公式名称当作任何样本中都正交的保证。

取 $p = 0.5$, 基因型概率为 $0.25, 0.5, 0.25$, 加性编码为 $-1, 0, 1$, 显性编码为 $-0.5, 0.5, -0.5$ 。交叉乘积均值为 $0.25 \times 0.5 + 0.25 \times (-0.5) = 0$, 两种方差为 0.5 与 0.25 。若样本只保留两个纯合基因型而缺少杂合个体, 显性编码在样本内变为常数, 便无法与截距区分。这个极端例子说明理论编码不能替代数据中实际基因型组合的覆盖。

27.11.3 互作核的统计含义与限制

对两个正半定核作逐元素乘积仍得到正半定核, 因而可以使用加性核的逐元素平方构造某种互作协方差。这一操作在特征空间中对应成对特征乘积, 但可能同时包含自乘项、重复项以及与低阶效应相关的成分。若希望把所得方差精确解释为某一遗传分解中的纯加性乘加性方差, 还需要检查编码中心化、频率假设与正交化条件。预测核可用不等于其方差分量具有唯一的经典遗传解释。

例如模型含 $u_a \sim N(0, G\sigma_a^2)$ 与 $u_{aa} \sim N(0, (G \circ G)\sigma_{aa}^2)$, 其中 $\circ$ 表示逐元素乘积。若当前动物关系大多接近零且对角线接近一, 两张矩阵可能都近似单位矩阵, 残差又含单位矩阵, 于是三种方差来源难以区分。增加一个核

并不能凭空创造区分它与残差的信息。重复记录、跨环境设计、更多亲缘等级和更大样本可能改善识别，但必须在具体资料中检查似然曲面、标准误或后验相关。

27.11.4 从候选动物到配对决策

若目标是选种亲本，可以以加性预测为主体，再在配种阶段利用显性、互作或特定位点信息评价组合。若目标是预测某一确定杂交组合的商品后代表现，则应直接定义组合期望，并考虑双亲基因型、配子分离与环境。仅把两亲本总遗传预测相加，通常不能正确表示后代显性与互作组成。特别是隐性缺陷，双亲各自表现正常不意味着配对风险低，需基于携带状态和遗传传递计算。

非加性模型的验证也应服从这一决策单位。如果实际用途是未见过的双亲组合，随机把同一组合的后代分到训练和验证，会测试组合内再预测而不是新组合外推。如果用途是跨代亲本选择，则要观察配偶群变化后预测是否保持校准。一个模型在当前商品代获得较高相关，是有价值的证据，但它的可迁移范围由验证设计决定。应避免将有限场景的成功扩大成对所有育种目标的普遍优势。

27.12 多核模型、功能注释与方差分解的可识别性

27.12.1 把多种信息写成协方差的加和

假设有编码区、调控区和其余标记等多个特征集合，可分别构造 K_1, K_2, K_3 ，并设 $y = X\beta + u_1 + u_2 + u_3 + e$ ，其中各 u_l 相互独立，方差为 $K_l\theta_l$ 。于是表型协方差为 $\sum_l K_l\theta_l + R$ 。这种模型允许不同区域拥有不同平均效应尺度，也允许把基因组、转录组或其他测量作为独立核加入。但数学上的独立随机效应假定并不表示这些生物过程真正独立，更不证明某组学层处于从基因到性状的因果中介位置。

各核的尺度必须先明确。若一张核的平均对角线为十，另一张为一，相同方差参数并不表示相同平均贡献。可以将核按迹或特定参照规范化，再解

释参数；也可以保留原尺度，但应报告平均贡献 $\theta_l \text{tr}(K_l)/n$ 。对于存在固定效应投影的模型，实际可识别的是投影后的协方差方向，未经投影的迹比例不一定等于可估计遗传方差比例。规范化是帮助解释的约定，不能消除核之间的相关。

27.12.2 算例：相同核使方差参数不可分别识别

设 $K_2 = 2K_1$ ，模型总遗传协方差为 $K_1(\theta_1 + 2\theta_2)$ 。只要组合 $\theta_1 + 2\theta_2$ 相同，任何非负参数对都会给出相同的似然。比如 $(\theta_1, \theta_2) = (1, 0)$ 与 $(0, 0.5)$ 完全等价。即使样本很大，也无法仅凭这两张核分离各自贡献；需要不同的数据结构或外部约束。软件可能返回一个边界解或某个稳定数值，但数值收敛不能证明统计可识别。

若两张核只是近似成比例，问题变为弱可识别：总体预测可能稳定，方差分配却对轻微数据变化很敏感。应检查核相关、投影后矩阵的线性依赖、参数估计相关和重抽样稳定性。可以合并高度重复的信息源，使用较强且透明的先验，或将研究目标限定为预测收益而不解释精细方差比例。参数较少的模型不一定生物学描述更丰富，却可能对当前资料给出更可靠的结论。

27.12.3 功能注释带来的先验需要避免循环论证

功能注释可以来自独立实验、跨物种保守性或既有分子研究。它们帮助构造标记组或连续权重，但注释正确并不保证其对所研究动物性状具有稳定预测贡献。某些注释覆盖常见变异更多，某些区域的标记密度和连锁结构不同，因此观察到的方差富集可能部分反映测量设计。应考虑对频率、区域长度和连锁结构的敏感性，并避免把单一富集结果直接解释为分子机制证实。

若先在本数据中筛选关联最强的标记，再把它们划为“重要功能组”，最后在同一数据中估计该组解释更多方差，就形成了循环选择。合适做法是使用独立注释，或把筛选嵌入外层验证的训练部分，评估整个筛选流程的泛化收益。即便某组确实提升预测，结论也应表述为该信息源在当前任务中 useful；要确认具体变异因果作用，仍需定位、功能与设计层面的额外证据。

MacLeod 等（2016）提出的 BayesRC 是把独立生物知识转为变异类别

先验的一个原始研究入口。该研究结合奶牛基因型、模拟表型和真实产奶性状进行评估,说明注释可以进入联合估计而非只在分析后解释结果。其结论应限于研究所覆盖的资料和比较条件,不能推出任何注释都能增加准确性。对新研究而言,更有意义的问题是注释提供了哪些独立于频率和连锁结构的信息,以及这些信息在外部候选群体中是否仍有价值。

27.12.4 数据可用性决定多模态模型能否部署

组学数据常来自成年、采样或屠宰后的动物,而育种决策可能发生在出生或青年期。如果模型需要部署时不存在的测量,它可以作为机制研究工具或上界分析,却不能直接称为早期选种模型。可以考虑以少量有组学的参考动物帮助估计遗传结构,再对只有基因型的候选预测;也可以建立允许部分模态缺失的联合模型。但这类用途与“每只候选都有完整组学”的验证应分别报告。

另外,组学特征可能受到疾病、营养或测定批次影响。它们对当前表型具有较强关联,不一定代表稳定的遗传信息。将组学核加入模型后提高表型预测能力,可能来自更准确的环境状态测量。对于管理预警,这可能十分有价值;对于亲本选择,需要区分可传递与不可传递部分。模型使用者必须先确定目标,再决定哪些信息进入遗传部分、哪些进入环境或状态部分,不能仅凭相关高就把全部信息称作育种值。

多核比较宜保留简单基准并逐步增加信息源。可以报告每增加一个数据源所需成本、缺失比例、预测收益及校准变化,判断其边际价值是否稳定。若多个核一起加入才产生收益,应研究其互补条件;若收益只在同批次随机划分中出现,而在跨批次验证消失,应优先调查技术依赖。这样的证据链比列出很多模型名称更能帮助育种机构决定是否投入新的测量体系。

27.13 超参数估计、模型选择与公平比较

27.13.1 方差估计和预测损失选择回答不同问题

岭模型的惩罚强度可以来自估计的遗传方差与残差方差比，也可以通过训练内部交叉验证选择。前者试图在给定概率模型下解释数据协方差，后者直接针对某种预测损失及验证分布优化。模型正确且资料充足时，两者可能得到相近选择；模型错设、训练目标与部署目标不同或样本有限时，两者可能明显不同。因此，不能把交叉验证选择的参数直接解释为无偏遗传力，也不能认为似然最大的模型一定在所有外推场景中预测最好。

限制最大似然通过处理固定效应估计所消耗的信息来估计方差分量，但它仍依赖所指定协方差结构、资料形成机制及选择处理。若基因组关系尺度改变，相应方差参数也要改变；比较不同关系矩阵下的原始遗传方差数值时，必须先统一解释尺度。贝叶斯层级模型则把方差参数的不确定性纳入后验，但先验会在小样本或边界问题中产生明显影响。不同估计方法的优缺点应围绕特定资料和目标讨论，不能由“频率学”或“贝叶斯”标签决定。

27.13.2 嵌套验证如何隔离选择与评价

假设候选模型包括三种核、五个带宽和六个惩罚强度，共九十种配置。如果在同一验证集上选最高相关并把该最高值当作最终性能，就利用了验证集中的随机波动。配置越多、结果噪声越大，选择偏差通常越值得关注。嵌套设计在外层保留测试动物，在内层训练资料中选择配置，然后用选定流程对外层测试作一次预测。外层结果评价的是整个调参程序，而不是某个事先固定参数的模型。

对于时间预测，内外层也应尊重时间顺序。不能外层按未来年份测试，内层却随机混合各年份且使用后来才能获得的注释或表型版本，再宣称完全模拟历史部署。若计算预算有限，可以用较少但有代表性的内层划分、预先设定的参数范围和顺序搜索，关键是把所有监督选择留在训练边界内。反复查看外层结果后继续调整模型，也会逐渐把外层变成训练信息，需要保留新的最终测试或明确探索性质。

27.13.3 损失函数应与育种决策保持一致

相关系数对线性缩放不敏感，适合描述排序的一部分，却不足以评价绝对育种值尺度。均方误差惩罚较大的数值误差，平均绝对误差对极端误差较不敏感，校准斜率揭示预测分散程度是否合适。若实际只选前百分之一，整体相关的改善未必与高端候选识别一致；但直接优化很少个体的极端选择命中率又可能产生很大抽样波动。可以把主要损失预先指定，并辅以与决策相关的分层指标和不确定性，而不是事后选择最有利的指标。

例如模型甲预测为真实育种值的两倍，模型乙在正确尺度上加入少量噪声。模型甲相关可以等于一，却在经济指数计算时把某性状贡献放大，改变多性状排序。若各性状的误差和尺度不同，单性状相关表不能保证综合目标表现良好。应该在统一经济权重与遗传尺度下检查预测的联合协方差和指数校准。模型选择需要从单个性状延伸到实际使用方式，这并不是要求每次研究都完成全部经济分析，而是避免把有限指标的结论扩大。

27.13.4 公平计算预算与不确定性报告

不同方法的比较还应说明搜索预算。给复杂模型数百次调参机会而只给基准模型一个任意默认值，可能使差异反映调参投入；反过来，给需要合理带宽选择的核模型一个明显失配值，也不能证明其原理无效。可以采用相近的计算预算、明确的参数范围和可复现的停止条件，并报告各方法的实际时间、内存和失败次数。运行失败和收敛不稳定是部署性能的一部分，不应在结果表中悄然删除。

同一测试动物上的模型误差通常相关，所以模型比较宜使用配对差异。把两种方法各自的标准误简单相加，既可能过于保守，也可能忽略共享训练不确定性。按独立家系、场群或时间批次进行配对汇总，有助于反映目标部署单位的变化。若性能差异小于抽样不确定性，应诚实报告证据不足；这不等于两模型理论上完全相同，只说明当前实验无法支持稳定的优劣排序。

最终模型的选择可以综合预测损失、校准、计算成本和解释需求。若两方法表现相近，较易维护、较易审计且能及时完成评定的方法可能更合适；若复杂方法在高价值群体中有稳定收益，则额外成本也可能合理。研究应给

出使这种权衡可判断的信息，而不是用一行最高平均相关替代全部讨论。

27.14 从后验预测到候选排序与选种决策

27.14.1 排名不确定性与单个可靠度不同

两个候选育种值各有预测误差，比较它们时真正需要的是差值误差方差。若预测误差协方差为 V_δ ，则差值误差方差为 $V_{\delta,ii} + V_{\delta,jj} - 2V_{\delta,ij}$ 。近亲或共享记录的动物可能具有较大的误差相关，使差值比各自绝对值估计更精确；也可能因其他结构出现不同方向的相关。只公布每只动物的可靠度，通常不足以计算它们谁更优的概率。群体排序、亲本组合和遗传趋势对比都需要关注误差协方差，而不只是对角线。

设两动物的预测差为 0.4，各自后验方差均为 0.25。若后验协方差为 0.2，差值方差为 0.1，正态模型下前者优于后者的概率为 $\Phi(0.4/\sqrt{0.1}) \approx 0.8970$ 。若协方差为零，该概率降为 $\Phi(0.4/\sqrt{0.5}) \approx 0.7142$ 。两种情形具有完全相同的个体边际方差，却支持不同强度的排序证据。报告高精度小数的育种值并不能替代这种不确定性解释。

27.14.2 选择后的表现与选择前的校准

模型在总体上校准，并不意味着每一个极端候选的误差都会很小。按预测值选择最高个体时，选择组往往包含预测噪声恰好偏高的动物；适当收缩正是处理这一问题的一部分。但如果模型仍存在未校正的尺度扩张、家系偏差或特定批次误差，极端选择会放大它们对决策的影响。因此，应专门检查高预测组的后期表现和组成，而不能仅凭总体相关决定是否放心使用尾部排序。

这种检查必须避免再次用相同噪声定义真值。例如把原模型高度共享信息的后期评定当作完全独立真值，可能低估原排序误差。可以结合新增后裔信息、未来时间窗口或适当的部分与完整评定方法，但每一种代理都应交代依赖结构。若真正目标是未来选择反应，则还要考虑被选动物是否实际繁殖、贡献是否均衡、配偶分配与代际间隔，而不能把一次候选排序变化直接等同

于实现遗传进展。

27.14.3 多性状目标需要联合预测与风险表达

设总育种目标为 $H = a'u$ ，其中 a 为预先指定的经济权重向量。后验均值为 $a'E(u | y)$ ，后验方差为 $a' \text{Var}(u | y)a$ 。这要求保留性状间预测误差协方差；若只把各性状标准误平方后加权相加，会遗漏交叉项。性状遗传相关、共同记录和联合参数估计都可能产生非零误差相关。一个性状的高可靠度不能保证综合目标高可靠度，特别是经济权重集中在记录稀缺的性状上时。

举例而言，两性状权重均为一，后验方差均为 0.2。若误差协方差为 0.15，总目标方差为 0.7；若为 -0.15，则为 0.1。单性状精度完全相同，却对应截然不同的综合目标不确定性。若目标还含某性状不得低于阈值的限制，决策需要联合分布或可靠的近似，而不只是总目标均值。独立假设在没有证据时可能严重误判同时满足多个条件的概率。

27.14.4 预测模型与长期育种政策的接口

高预测值动物若来自很少家系，集中使用可能提高近期收益，同时增加近交和降低未来可选变异。预测模型提供的是个体或组合的条件信息，贡献优化与配种设计还需要关系、繁殖能力及管理约束。把这两层问题分开有助于透明决策：先说明在当前模型下哪些动物具有怎样的遗传预测和不确定性，再根据育种计划的收益与多样性目标确定使用比例。不能让模型内部某个隐含惩罚替代公开的育种政策选择。

模型更新也应关注决策稳定性。新增资料后，某些动物排序发生变化可能是合理的信息更新；若变化集中于某芯片批次或某一频率版本，则可能反映流程问题。可以记录候选预测变化、主要贡献来源、校准变化和选择名单重叠，但名单重叠高也不必然代表模型正确，旧模型与新模型可能共享同一偏差。监测的目的不是强迫每次评定都保持旧排名，而是让变化能够由新信息和模型定义解释。

在生产交流中，应把预测值、参照群体、信息截止日和精度层级一并呈现。对低精度青年动物，可以说明它们的潜在价值与不确定性，并在贡献分

配中分散风险；对高精度成熟种畜，也应避免把历史精度视为所有未来环境下的保证。统计预测的责任是使不确定性可理解、可用于决策，而不是用单一分数制造不存在的确定性。

27.15 选择方法的证据顺序

面对 GBLUP、贝叶斯、核回归或更复杂的机器学习，第一项工作是建立具有合理固定效应、相同训练样本和可靠数据处理的基准模型。随后一次改变一个有解释的因素：效应先验、特征权重、非线性结构或外部注释。若同时更换训练群体、质量阈值、验证划分和模型，性能差异就难以归因。

模型比较应按部署单位汇报。预测下一批同场候选动物，可以采用时间前推验证；预测没有训练近亲的新家系，应使用家系隔离；预测新地区，还需要环境外推。复杂模型在随机个体划分中稍优，不足以证明其在跨家系场景有优势。超参数搜索得到的最大验证分数含有选择偏差，最终评估应保留独立外层测试。

精度之外还要核算成本。某种方法增加十倍计算量，只提高极少的预测相关，是否值得采用，取决于候选动物数量、世代间隔、经济权重以及改进是否稳定。相反，如果计算能在选种前及时完成，使原本来不及使用的信息进入决策，计算效率本身就具有育种价值。

关联、预测和因果解释在这里必须分开。一个标记可因连锁不平衡而具有稳定预测作用；环境混杂也可能产生表面预测能力；只有额外设计和证据才能把关联转换为因果解释。推荐把模型输出写成“在给定参考群体和信息条件下的预测”，避免把每一个高权重标记都描述为已经证实的功能基因。

同一预测函数还可能对应许多组标记效应。当标记列完全重复时，交换两个效应的分配并不改变动物预测值。由此不能根据软件输出的一组数值就宣称识别了唯一的位点贡献。加上先验或惩罚可以使解在数学上唯一，却不等于数据已经提供生物学上的唯一解释。报告重点应与研究任务一致：预测研究首先展示外部误差，位点机制研究则需要额外的定位、实验和因果证据。




图 27.1 岭惩罚对不同特征方向的收缩。图中以核矩阵特征值 d 为横轴，展示三种惩罚强度下的保留比例，未对真实数据作性能比较

27.15.1 遗传结构、训练规模与方法优势的条件性

一种方法是否受益于大效应先验，取决于效应是否能被当前标记和样本辨认。如果大效应变异未被测量，且与已测标记的连锁在各群体间不稳定，允许某些标记拥有厚尾效应未必能找回真正的信号。相反，若有经过独立证据确认的大效应位点，可以考虑将其作为单独的效应或核建模，再让其余标记承担多基因背景。此时也需防止把发现研究中高估的效应原样带入预测，并检查它在目标群体中的频率和方向是否一致。

训练规模增加往往使更复杂的遗传结构更可估计，但增加的是哪些动物比数量本身更重要。新增同一小家系的大量近亲可能主要提高该家系内精度，新增跨群体动物则可能帮助区分标记与因果位点的连锁解释，同时引入新的环境异质性。学习曲线应尽量按实际新增资料方式构造，而不只是从全数据随机抽取不同数量的行。后者回答的是同分布样本扩充，未必预测未来跨地区扩群的收益。

比较模型时可以把差异分解为三个层次：特征表示是否包含目标信号，先验或惩罚是否适合有限样本，训练分布是否覆盖部署对象。岭模型可能因

均匀收缩而遗漏少数大信号，也可能因稳健性在小样本中胜出；稀疏模型可能提高区域信号提取，也可能在强连锁块间不稳定；局部核可拟合非线性，却可能在远距离外推中迅速回归均值。每个结论都应通过可检验的资料条件连接到模型机制，避免只给方法排一个永久顺序。

27.15.2 灵活算法的新进展怎样进入育种证据链

Wang 等 (2024) 把生物注释神经网络框架用于中国荷斯坦牛多个性状，并在其交叉验证条件下与常用基准比较。这为利用注释组织特征提供了一个动物资料中的研究实例。这里应注意，论文中的随机交叉验证收益与跨场、跨家系或跨代部署收益是不同的证据层次；原研究支持其已测试情境，进一步迁移需新的验证。本章不把这种实例解释为神经网络普遍超过线性模型，而把它作为如何提出可验证扩展假设的入口。

从工程实现看，复杂网络、贝叶斯混合和核方法都可以先在相同的训练与验证边界内进行小规模受控比较。要记录输入特征、参数数量、优化或采样规则、随机种子以及每次调参使用的信息。不同随机初始化的结果差异若接近方法间差异，就应把算法随机性纳入报告。若只有最好一次运行被保留，所呈现的是选择过的表现，而非实际可重复的部署表现。对于需要定期更新的评定系统，失败率和运行稳定性同样有经济后果。

模型选择的最终证据还应包括更新后的持续表现。一次优秀的回顾性结果可以支持试运行，却不能说明在数据平台、饲养制度和群体结构变化后仍然有效。可以预先规定何时重新估计方差、何时重做特征筛选、何时仅更新训练记录，并保留简单基准作为持续参照。这样，方法演进成为可审计的累积学习过程，每一次复杂化都有明确的动机、代价和验证结果，而不是随新算法名称不断更换评定体系。

27.16 广义岭回归的度量与训练外等价条件

岭回归的惩罚不是附加在数据之外的一项形式修饰，它规定了效应空间中哪些方向更容易出现大幅变化。Hoerl 与 Kennard (1970) 讨论的偏差与方差权衡，进入基因组预测后仍然成立，但标记编码、残差权重和效应协方

差使这一权衡具有更具体的遗传含义。Strandén 与 Garrick (2009) 给出了基因组预测及可靠度的等价计算路线；理解其条件，可以避免把训练动物上的数值一致扩大为任意部署情境的等价。

以下推导条件于已知的固定均值，或条件于一个给定的固定效应向量，记减去该均值后的响应为 y_0 。本节所写后验协方差和新动物条件方差均在这一条件下成立。若固定效应也由同一份资料估计，不能只把估计均值代入而继续沿用这些条件方差；应从完整混合模型求出相应预测误差，并计入固定效应估计及其与随机效应预测的联合影响。令残差协方差为正定 R ，标记效应先验协方差为正定 D 。目标函数为

$$J(\alpha) = (y_0 - W\alpha)^T R^{-1} (y_0 - W\alpha) + \alpha^T D^{-1} \alpha.$$

分别求导并令导数为零，得到后验精度与均值：

$$C^{-1} = D^{-1} + W^T R^{-1} W, \quad \hat{\alpha} = C W^T R^{-1} y_0.$$

把 D 的平方根并入特征，可以写成白化模型。令 $F = R^{-1/2} W D^{1/2}$ 、 $z = R^{-1/2} y_0$ ，并令 $\gamma = D^{-1/2} \alpha$ ，则

$$J(\gamma) = \|z - F\gamma\|^2 + \|\gamma\|^2.$$

这说明一般协方差先验仍可转成普通岭问题，但所用欧氏长度已经是在变换后的空间中度量。原始标记相差一个计数单位，与标准化后相差一个标准差单位，不是同一个效应单位。若改变特征单位而仍保持相同的单位阵先验，改变的是模型，而非单纯改写坐标。

定义训练协方差 $K = W D W^T$ 。从矩阵恒等式可得

$$\hat{\alpha} = D W^T (K + R)^{-1} y_0, \quad \hat{u} = K (K + R)^{-1} y_0.$$

对具有特征列向量 w_* 的新动物，均值与条件方差为

$$\begin{aligned} \hat{u}_* &= w_*^T D W^T (K + R)^{-1} y_0, \\ v_* &= w_*^T D w_* - w_*^T D W^T (K + R)^{-1} W D w_*. \end{aligned}$$

训练预测只使用 K ，新动物预测还需要交叉协方差与自身先验方差。因此，两种方案即使具有完全相同的训练核，也未必定义相同的训练外模型。这个区别在训练资料中标记高度共线、部署群体出现新单倍型时尤其重要。

考虑只有一个训练动物、两个特征， $W = (1, 1)$ ，响应为二，残差方差为一。第一种先验取 $D = \text{diag}(1, 4)$ ，有 $K = 5$ ，训练预测为 $5 \times 2/6 = 5/3$ ，两个效应后验均值为 $(1/3, 4/3)^T$ 。新动物若为 $w_* = (1, -1)^T$ ，则

$$\hat{u}_* = -1, \quad v_* = 5 - \frac{(-3)^2}{6} = 3.5.$$

第二种先验把两个方差交换，取 $D^* = \text{diag}(4, 1)$ 。训练核仍为五，训练拟合完全相同，但新动物预测变成一，条件方差仍为三点五。训练资料只能识别两个效应的和，无法区分它们怎样分配；新动物的差值方向则恰好需要这种分配。例中差异由先验决定，不是数据已经证明两套相反的遗传机制。

若确实只是重参数化，变换必须连同先验一起进行。设 $\alpha = T\gamma$ ，其中 T 可逆，则

$$W^* = WT, \quad D_\gamma = T^{-1}DT^{-T}.$$

此时 $W^*D_\gamma(W^*)^T = WDW^T$ ，新动物的特征也按同样规则变换，所有联合协方差保持不变。只改变训练矩阵而遗漏候选转换，会破坏等价；只改变编码而保持原先验，也会破坏等价。判断两个程序是否实现同一模型，应比较联合协方差、固定效应处理和预测误差，而不仅比较训练相关。

如果 D 半正定而非正定，可以通过它的有效特征空间建立同样推导，但不能直接使用 D^{-1} 。零方差方向表示被先验排除的效应，并不等同于资料暂时不足。对于完全重复的标记，后验预测可以很稳定，而每个位点的分配仍由先验度量决定。把数值唯一性写成生物学可识别性，会超出模型所提供的证据。

这种等价条件同样适用于改变标记权重后的可靠度报告。若只是给全部特征乘一个常数，同时按其平方反向调整效应方差，预测与条件误差应完全一致；若预测不变而可靠度变了，通常意味着二阶矩转换没有同步。对具有多个随机成分的模型，还要逐项追踪交叉协方差。把剩余系谱成分加到动物

核以后, 标记效应回算应使用标记部分与总遗传值的协方差, 不能把混合后的全部方差都重新归到标记上。

实际数据里先验协方差也可以由外部注释或训练表型估计。前者需要说明外部资料的适用范围, 后者则使模型成为自适应过程。给定已估计先验时的代数等价仍可成立, 但无条件预测误差应包含先验估计的不确定性。代数恒等式不会自动消除估计流程产生的随机性, 更不能使在验证资料上选择权重变成合法的独立验证。

27.17 面向目标群体的预测风险分解

岭惩罚通常由一个全局参数控制, 但“最佳”必须依附于具体损失和未来动物分布。训练空间中某一方向估计得很好, 如果未来动物在该方向几乎没有差异, 其价值可能有限; 训练中较弱的方向若恰好是目标群体主要的变化方向, 则可能主导部署风险。下面暂把真实效应视为固定参数, 直接计算条件风险, 以区别于对先验再平均的贝叶斯风险。

设

$$y = W\beta + e, \quad E(e) = 0, \quad \text{Var}(e) = \sigma^2 I,$$

并记 $S = W^T W$ 、 $A_\lambda = S + \lambda I$ 。岭估计为 $A_\lambda^{-1} W^T y$, 其偏差为

$$b_\lambda = E(\hat{\beta}) - \beta = -\lambda A_\lambda^{-1} \beta.$$

其抽样协方差为

$$V_\lambda = \sigma^2 A_\lambda^{-1} S A_\lambda^{-1}.$$

令未来动物中心化特征的二阶矩为 $T = E(w_* w_*^T)$, 并假定它与训练误差独立。对潜在信号 $w_*^T \beta$, 预测风险为

$$\begin{aligned} \mathcal{R}_T(\lambda) &= E[\{w_*^T (\hat{\beta} - \beta)\}^2] \\ &= b_\lambda^T T b_\lambda + \text{tr}(T V_\lambda). \end{aligned}$$

若预测未来表型, 还要加上未来残差方差; 若新动物与训练记录共享环境, 则独立性不成立, 还需交叉协方差。把目标明确为潜在遗传信号, 使我们能够单独观察估计误差, 而不把不可消除的环境噪声混入惩罚比较。

当 S 与 T 在同一正交基下为对角矩阵, 记其元素为 s_j 和 t_j , 真实效应分量为 β_j , 则

$$\mathcal{R}_T(\lambda) = \sum_j t_j \frac{\lambda^2 \beta_j^2 + \sigma^2 s_j}{(s_j + \lambda)^2}.$$

分母说明惩罚削弱不稳定性, 分子同时记录由此产生的偏差。目标群体通过 t_j 决定各方向的重要性。这个风险是条件于当前训练设计的量; 当训练动物也随机变化时, 还应对设计分布再取期望。两种层次的风险不能混为同一个样本量函数。

考虑两方向训练信息为 $S = \text{diag}(9, 1)$, 真实效应 $\beta = (1, 0)^T$, 残差方差为一。若目标群体主要在第二方向变化, 取 $T = \text{diag}(1, 9)$, 则

$$\mathcal{R}_T(\lambda) = \frac{\lambda^2 + 9}{(9 + \lambda)^2} + \frac{9}{(1 + \lambda)^2}.$$

逐项计算, $\lambda = 1, 3, 9$ 时风险分别为 2.35、0.6875、0.367778。第一方向有真实信号, 强收缩增加其偏差; 第二方向没有信号, 强收缩减少大量目标群体中的噪声预测, 因此后三者的综合权衡明显不同。

若未来群体改为 $T_{src} = \text{diag}(9, 1)$, 相同三种惩罚的风险变为 1.15、1.1875、2.51。第一个群体里较有利的强惩罚, 在第二个群体里代价很高。训练数据和真实效应均未变化, 变化的是未来特征分布。这个例子不是建议按未知真效应选择惩罚, 而是说明源群体验证的最佳值为何未必在目标群体中最佳。

如果再把 β 视为零均值随机量、真实协方差为 D_0 , 风险的偏差项对先验平均后为

$$E_\beta(b_\lambda^T T b_\lambda) = \lambda^2 \text{tr}(T A_\lambda^{-1} D_0 A_\lambda^{-1}).$$

在正确先验模型中, 后验均值对每一个给定的新动物均最小化后验平方误差; 这与前面固定效应风险随目标变化不矛盾。前者利用正确的整个概率分布, 后者考察某个固定信号。实际经验贝叶斯需要估计先验, 真实结构也可能不等方差, 因此不能用理想最优性替代外部检验。

若训练与目标空间的特征方向不一致, S 与 T 一般不能同时对角化。此

时风险仍由矩阵公式给出，却不应把每个主成分的单独误差直接相加；旋转后的交叉项可能重要。它也提示，目标群体主成分和训练群体主成分相似，并不足以证明效应与噪声方向完全匹配。对跨品种使用，应同时考察特征覆盖、效应稳定性和表型精度。

目标二阶矩可以由决策时已经取得的候选基因型估计，但这只提供目标分布信息，没有提供未知的目标效应或环境关系。若允许联合使用候选输入，模型选择属于明确的转导场景；若未来动物逐只到来，训练时通常还需要一个代表部署总体的参照样本。无论哪一种场景，都不能用候选未来表型来选择惩罚后再声称预测发生于原来的时间点。

对多个性状的经济目标，方向权重还由经济系数与性状协方差共同决定。一个单性状均方误差较小的模型，可能因另一重要性状的尺度失准而产生更大的经济风险。应先在统一单位下定义联合损失，再计算各模型的风险差。独立地把每个性状相关最高的方法拼接起来，未必得到综合目标最优的预测；共同误差与跨性状校准会影响最终权衡。

27.18 稀疏先验下的非线性收缩与局部不确定性

正态先验的收缩系数固定，稀疏混合先验则让收缩随观测强度变化。理解这种非线性，不能仅比较哪个模型留下更多非零效应；需要区分效应大小证据与是否存在效应的证据，并把二者的不确定性合并。下面使用一个独立正态效应观测模型，作为联合标记模型的局部教学近似。

设 $z | \alpha \sim N(\alpha, s^2)$ ，先验为零点质量与正态分布的混合：

$$\alpha \sim (1 - \pi)\delta_0 + \pi N(0, \tau^2).$$

非零与零模型的边际密度比为

$$BF(z) = \sqrt{\frac{s^2}{s^2 + \tau^2}} \exp \left\{ \frac{z^2 \tau^2}{2s^2 (s^2 + \tau^2)} \right\}.$$

后验非零概率与非零状态内的收缩系数分别为

$$q(z) = \frac{\pi BF(z)}{1 - \pi + \pi BF(z)}, \quad k = \frac{\tau^2}{s^2 + \tau^2}.$$

因此，无条件于状态的后验均值为

$$m(z) = q(z)kz.$$

这个均值经历两层收缩：在非零状态内部按正态精度收缩，再按该状态的后验概率加权。把后验包含概率超过某阈值的标记留下并直接使用其非零状态均值，得到的是另一种决策规则，并不等于后验均值。阈值规则可能适合特定选择任务，但不能仍援引平方损失下后验均值最优性的结论。

由全方差公式，后验方差为

$$\text{Var}(\alpha | z) = q(z) \frac{s^2 \tau^2}{s^2 + \tau^2} + q(z) \{1 - q(z)\} (kz)^2.$$

第一项是非零状态内不确定性，第二项是零与非零解释之间的不确定性。临近两状态竞争最明显的区域时，第二项可能很大；一个看似较强的效应观测，不一定对应很窄的后验区间。

取 $s^2 = 0.25$ 、 $\tau^2 = 1$ 、 $\pi = 0.05$ 、 $z = 1.5$ 。贝叶斯因子约为 16.367228，后验非零概率约为 0.462779，非零状态均值为 1.2。合并后的后验均值约为 0.555335，后验方差约为 0.450561。虽然观测方差只有 0.25，后验方差反而更大，因为数据把原来很稀疏的先验推到了两个解释势均力敌的位置。这不违反贝叶斯更新的平均信息增益；后验方差对所有可能观测取平均后会降低，但并非对每一次观测都逐点降低。

还可从一般先验推导收缩的几何。令 $p(z)$ 为积分掉效应后的边际密度，在可交换积分和求导的条件下，

$$\frac{d}{dz} \log p(z) = \frac{E(\alpha | z) - z}{s^2}.$$

由此得到

$$m(z) = z + s^2 \frac{d}{dz} \log p(z).$$

边际密度的局部斜率决定观测被拉向何处。继续求导，可以得到另一个有用恒等式：

$$m'(z) = \frac{\text{Var}(\alpha | z)}{s^2}.$$

因此后验均值对观测的局部敏感度，直接反映条件不确定性。在刚才的状态竞争区域，斜率约为 1.802244，可以大于一；这不表示全局取消收缩，而表示两个模型解释的权重在该处快速变化。总体上均值仍小于正的观测值，但在某一局部区间，观测的小幅增加能引发更大的预测变化。

这种现象有助于理解标记筛选的不稳定性。近似独立模型中，变化发生在零与非零状态之间；强连锁的联合模型中，还可能发生在不同标记配置之间。个别位点包含概率变化很大而动物预测几乎不变，是因为若干配置产生相近的总遗传值。评价采样是否充分，应同时观察位点解释与目标预测，而不能只用一个参数的轨迹替代全部判断。

最后，局部正态观测近似不自动适用于稀有变异、极少携带者或完全共线标记。此时似然可能不接近正态，观测标准误也可能高度依赖模型。应返回联合似然与先验，不能把上述一维表达当成对所有位点独立套用的完整基因组算法。后验包含概率仍属于指定回归模型中的状态概率，没有额外因果设计时，不等于分子因果作用被证实的概率。

稀疏程度本身也可以未知。给包含概率设置层级先验后，一个位点的更新会通过共同超参数影响其他位点，后验便不能写成完全独立的一维乘积。若许多弱信号共同支持较低稀疏程度，所有局部收缩都可能发生变化；反过来，小样本中先验对非零比例的约束可能主导结果。分析应检查总遗传方差、非零区域数和候选预测的先验敏感性，避免只对一个看起来温和的局部参数作说明。

在解释中还需区分后验方差与蒙特卡洛误差。前者是给定资料后仍然存在的科学不确定性，后者是有限计算对后验摘要的估计误差。增加采样次数只能减少后者。若两个状态具有相近后验质量却切换缓慢，单条链看起来稳定可能意味着只探索了一个状态；应使用多个初值并检查状态概率和目标预测的有效样本量。不能以运行时间很长代替对后验探索的实质诊断。

27.19 核方法的表示定理与新动物协方差的合法性

核方法允许在很高维甚至无限维的函数空间中拟合，但其计算之所以可行，来自一个有限表示原理。Gianola 与 van Kaam (2008) 将再生核希尔伯特空间回归系统引入基因组辅助预测。这里进一步从空间分解出发，解释为什么训练核能够控制复杂度，以及为什么新动物的交叉核不能随意拼接。

设函数空间为 $\mathcal{H}$ ，核具有再生性质

$$f(x_i) = \langle f, k(x_i, \cdot) \rangle_{\mathcal{H}}.$$

将任意函数分解为训练核张成空间内的部分与其正交补：

$$f = f_{\parallel} + f_{\perp}, \quad f_{\perp} \perp \text{span}\{k(x_i, \cdot)\}_{i=1}^n.$$

由再生性质， $f_{\perp}(x_i) = 0$ ，因此正交补不改变任何训练拟合；另一方面，范数满足

$$\|f\|_{\mathcal{H}}^2 = \|f_{\parallel}\|_{\mathcal{H}}^2 + \|f_{\perp}\|_{\mathcal{H}}^2.$$

在训练平方损失加正范数惩罚的目标下，保留非零正交补只会增加目标函数，故最优解可写为

$$f(\cdot) = \sum_{i=1}^n a_i k(x_i, \cdot).$$

代回目标并在适当的支持空间求解，即得到熟悉的核岭预测。这个证明说明有限表示为何充分，却不说明核选择为何符合遗传传递。核函数决定了哪些训练外方向被视为相似；表示定理解决计算结构，生物学与外部验证决定用途。

更具体地，令训练核为正定 K ，新动物交叉核为 k_* ，自身核值为 k_{**} 。联合协方差必须满足

$$\begin{bmatrix} K & k_* \\ k_*^T & k_{**} \end{bmatrix} \succcurlyeq 0.$$

由舒尔补，其合法性等价于

$$k_{**} - k_*^T K^{-1} k_* \geq 0.$$

如果训练核只是半正定, 还必须要求 k_* 属于 K 的列空间, 再用广义逆计算二次型。一个训练中方差严格为零的方向, 不能同时与新动物存在非零协方差。否则不存在具有这些协方差的联合随机向量, 即使程序仍能利用加残差后的矩阵完成求解。

考虑

$$K = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}, \quad k_* = (1, 1)^T, \quad k_{**} = 1.$$

有 $K^{-1}k_* = (2/3, 2/3)^T$, 因此舒尔补为 $1 - 4/3 = -1/3$ 。每个单独相关都没有超过一, 联合结构却非法。若再取训练残差方差 0.25, 形式上的条件方差甚至成为

$$1 - k_*^T (K + 0.25I)^{-1} k_* = 1 - \frac{2}{1.75} = -\frac{1}{7}.$$

负结果不是新动物“特别精确”, 而是输入协方差不相容。若将交叉核改为 $(0.8, 0.8)^T$, 保留自身核为一, 原始舒尔补变为 $1 - 0.853333 = 0.146667$, 联合结构才合法。

这种问题可能出现在分别对训练、候选与交叉关系作独立缩放时。每张矩阵各自看起来尺度合理, 但它们未必对应同一特征映射。稳妥做法是从共同特征变换生成三者, 或从一个完整联合概率模型推导。若必须使用近似交叉核, 应连同自身方差一起检查, 而不是只把预测公式的结果截断为可接受范围。

核中心化、低秩近似和不同平台缺失处理都应维持这个联合条件。仅在训练矩阵上修正负特征值, 随后沿用旧交叉核, 可能再次破坏新动物联合合法性。另一方面, 新动物与训练空间不完全重合产生正的舒尔补, 是合理的未解释方差; 不应为了取得更高可靠度把它强行设为零。承认资料支持之外的方向, 是可信外推的一部分。

合法联合核还给出一个关于覆盖的几何解释。新动物特征可以分解为训练特征张成空间内的投影和正交残余; 舒尔补就是残余长度的平方。在训练空间内, 观测能够按精度更新预测; 在正交残余方向, 没有训练表型能够直

接辨认其效应。增加很多完全重复的训练动物可以改善已有方向的精度，却不会自动扩展覆盖空间。新增具有不同单倍型或遗传来源的动物，才可能增加这些方向的支持。

这个解释不意味着只要几何覆盖就保证迁移。即使候选处于训练特征空间内，性状定义、环境反应或标记关联改变，也会使同一函数不再适合目标。核覆盖检查发现的是表示与协方差问题，外部表型检验研究的是预测关系是否稳定。把两种证据结合，才能区分训练资料缺少方向与已有方向的效应已经改变。

27.20 留组误差的精确恒等式与相关验证的边界

核岭与广义岭都是线性平滑器。固定设计、固定惩罚和固定预处理时，可以利用平滑矩阵得到留一或留组误差，而不必把每个子模型完全重算。这种恒等式很有计算价值，但它只在对应的信息边界下成立；尤其不能把留一条记录的误差当作新家系误差。

设当前拟合为 $\hat{y} = Sy$ ，残差为 $e = y - \hat{y}$ 。对留出集合 B ，记其对应平滑矩阵块为 S_{BB} ，则在可逆条件下，留组预测残差为

$$e_{(-B),B} = (I - S_{BB})^{-1} e_B.$$

其推导可以从参数更新得到。设岭系统为 $A\hat{\beta} = W^T y$ ，删去 B 后，左端减少 $W_B^T W_B$ ，右端减少 $W_B^T y_B$ 。两式相减并整理，有

$$\hat{\beta} - \hat{\beta}_{(-B)} = A^{-1} W_B^T e_{(-B),B}.$$

再乘 W_B ，得到 $e_{(-B),B} = e_B + S_{BB} e_{(-B),B}$ ，从而得到上式。这里只展示同方差情形；不等权模型可以先白化，但若误差跨组相关，留组条件预测的定义还需要单独处理，不能机械删除若干白化行就声称对应删除原始动物。

单个动物留出时，公式简化为

$$e_{(-i),i} = \frac{e_i}{1 - S_{ii}}.$$

当杠杆值接近一时, 极小训练残差也可能对应很大训练外误差。训练数据在该动物方向上几乎完全拟合, 并不意味着删去其表型后仍有独立支持。若留组包含一个强相关家系, 决定放大程度的是整个 $I - S_{BB}$ 的谱, 而不仅是各个对角元。

考虑四只动物组成两个互不相关家系, 每家两只, 家系内核均为一。取残差方差一, 则

$$K = \text{diag}(\mathbf{1}_2 \mathbf{1}_2^T, \mathbf{1}_2 \mathbf{1}_2^T), \quad S = \text{diag}\left(\frac{\mathbf{1}_2 \mathbf{1}_2^T}{3}, \frac{\mathbf{1}_2 \mathbf{1}_2^T}{3}\right).$$

令观测为 $(1, 1, -1, -1)^T$, 训练拟合为 $(2/3, 2/3, -2/3, -2/3)^T$, 每个残差绝对值为三分之一。留一动物时, 每个残差绝对值变为二分之一, 故

$$MSE_{LOO} = 0.25.$$

若整家系留出, 目标家系与训练家系之间交叉核为零, 预测回到已知零均值, 留组残差绝对值为一, 于是

$$MSE_{family} = 1.$$

两种误差都由同一模型精确计算, 却对应不同部署任务。留一动物利用了它同家系另一只的表型; 整家系留出没有这条信息。这里零均值被视为已知, 以排除均值重估的额外影响; 真实应用若估计固定效应, 必须在完整平滑器中计入相应作用。

常用广义交叉验证以平均杠杆代替个体杠杆:

$$GCV = \frac{\|y - \hat{y}\|^2 / n}{\{1 - \text{tr}(S)/n\}^2}.$$

本例各个杠杆相同, 广义交叉验证恰为 0.25, 与留一误差相同, 却仍然不能代表新家系误差。这个反例说明, 计算近似准确与验证目标正确是两个判断。改进杠杆近似不能修复错误的留出单位。

另一个有用关系是固定线性平滑器的信号风险估计。已知均值模型 $y = f + e$, $\text{Var}(e) = R$ 下,

$$E \|Sy - f\|^2 = E\{\|y - Sy\|^2 + 2\text{tr}(SR) - \text{tr}(R)\}.$$

它由展开平方并计算交叉项得到，反映训练拟合中的乐观程度。该式评估同一设计点上的信号估计风险，不自动等于新群体风险；若 S 由同一响应调参、筛选或自适应构造，右侧还需要处理这种依赖。把搜索后的平滑器当作事先固定，会低估完整选择程序的复杂度。

因此，快速留出恒等式适合在固定候选参数下计算明确任务的误差。若每次留组都要重新估计频率、方差或监督特征，完整流程可能需要实际重拟合。可以在内层使用这些高效公式节省计算，再以符合目标的外层设计评价整个程序。数学捷径应保持被评估问题不变；只有这样，计算速度才会转化为可信的模型比较。

27.21 本章练习与参考答案

练习 27.1 W 有 10 万列而只有 3000 行，为什么关系表示可能更方便？如果个体数远大于标记数，又该如何判断？

答案：前者可把核心线性系统从标记维度转到个体维度。后者可能适合标记方程或迭代方法。但内存、稀疏性、固定效应和计算硬件也影响选择；不能只按维度给出统一结论。

练习 27.2 一个效应的观测值为 0.6，观测方差 0.2，先验方差 0.3，求后验均值和后验方差。

答案：均值为 $0.3/(0.3+0.2) \times 0.6 = 0.36$ ；方差为 $(1/0.3+1/0.2)^{-1} = 0.12$ 。后验方差同时小于两个信息来源各自的方差。

练习 27.3 一个含互作的核模型具有最高随机划分预测相关，能否立即替代加性育种值用于选留种公羊？

答案：不能。应核对其预测对象是否为加性传递贡献，检验跨代和配偶改变后的校准，并评估家系泄漏与超参数选择偏差。商品个体表现预测与亲本育种价值评价可以需要不同模型。

练习 27.4 设两个场各有两只动物，标记列为 $(0, 1, 1, 2)'$ ，校正场均值后的表型为 $(-1, 1, -0.5, 0.5)'$ ，残差方差为一。分别求无惩罚估计与标记先验方差一时的岭估计，并说明有效信息来自哪里。

答案：去掉场均值后的标记列为 $(-0.5, 0.5, -0.5, 0.5)'$ ，其平方和为一，与表型的乘积和为 1.5。无惩罚估计为 1.5，岭估计为 $1.5/(1+1) = 0.75$ 。有效信息来自两个场内的基因型差异，场间均值差异已经进入固定效应。若每个场的标记完全相同，场内信息为零；惩罚虽然给出数值解，却不能创造遗传与场效应的可识别性。

练习 27.5 某核的非零特征值为四与一，残差方差比为二。求两个方向的收缩比例及有效自由度。若某方向的核特征值为零，增加训练表型精度能否单独恢复该方向的标记遗传信号？

答案：比例分别为 $4/6 = 2/3$ 与 $1/3$ ，有效自由度为一。零特征值方向在当前核下没有先验遗传变异，降低残差方差仍不能使该核在该方向产生预测。可以改变标记集合或协方差模型以增加表示能力，但那已经是一个新模型。若零方向来自中心化截距，则应由固定均值处理，不能简单称为遗漏了一个生物学遗传方向。

练习 27.6 某候选的后验分布是两个正态分布的等权混合，均值分别为零与二，条件方差均为 0.5。求总体后验均值和方差。若未来表型还有独立残差方差二，求表型预测方差。

答案：后验均值为 1，条件方差均值为 0.5，条件均值方差为一，故总体方差为 1.5。未来表型预测方差为 3.5。直接平均两个条件标准差，或只平均方差而忽略状态间均值变化，都会低估不确定性。混合分布未必正态，因此用均值加减两倍标准差作为区间只是近似；精确区间应从混合累积分布或后验样本求取。

练习 27.7 两张核满足 $K_2 = 3K_1$ ，估计得到方差参数 (0.3, 0.4)。找出另一组产生相同协方差的非负参数，并说明能否据此宣称第二信息源贡献占优势。

答案：总系数为 $0.3 + 3 \times 0.4 = 1.5$ ，例如 (1.5, 0) 和 (0, 0.5) 均完全等价。因此，当前数据无法分别识别两个核的贡献，软件返回的分配不能支持信息源优劣解释。可以报告合并核的预测表现，或者引入具有独立根据的约束；不能把约束所决定的分配写成数据独立证明的事实。若两核仅近似相关，还

应考察参数标准误及重抽样稳定性。

练习 27.8 某研究在一个测试集上比较一百组超参数，选出相关最高者，并报告该相关和极窄置信区间。请指出至少三个问题，并给出可执行的改进设计。

答案：第一，测试集被用于参数选择，最高值存在选择偏差；第二，置信区间若把超参数视为事先固定，未包含选择过程的不确定性；第三，动物之间若有家系或场群相关，独立个体公式会低估抽样误差。可在外层按目标部署单位保留测试，在训练内进行超参数选择，并对所有方法使用相同外层动物。以家系或批次配对汇总损失差异，报告相关、均方误差和校准。若研究者已经反复观察现有测试结果，应使用新的时间窗口或明确声明当前结果为探索性，不宜靠更换统计公式恢复其未使用状态。

单步基因组评定与大规模计算

实际育种资料往往包含大量有表型而未分型的动物，也包含已分型但尚无表型的幼龄候选动物。如果分别计算系谱育种值和基因组育种值再简单平均，共享信息可能被重复使用，未分型亲属的信息也难以完整传递。单步基因组评定的基本任务，是在一个模型中保持系谱、基因型与表型之间的条件关系。

28.1 为什么需要统一关系系统

把动物分成未分型组 1 和已分型组 2，系谱关系矩阵按组分块为 $A_{11}, A_{12}, A_{21}, A_{22}$ 。先暂时把育种值方差单位设为 1。在系谱高斯模型下，未分型组在给定已分型组后的条件均值与条件方差为

$$E(u_1 | u_2) = Bu_2, \quad B = A_{12}A_{22}^{-1},$$

$$S_1 = \text{Var}(u_1 | u_2) = A_{11} - A_{12}A_{22}^{-1}A_{21}.$$

现在保留这套条件模型，但把 u_2 的边际协方差从 A_{22} 替换为相容尺度上的 G 。则 $u_1 = Bu_2 + \zeta$ ，其中 ζ 与 u_2 独立，协方差为 S_1 。由方差展开可得统一关系矩阵

$$H_{rel} = \begin{bmatrix} S_1 + BGB^T & BG \\ GB^T & G \end{bmatrix}.$$

恢复遗传方差尺度后， $\text{Var}(u) = H_{rel}\sigma_a^2$ ，其中 σ_a^2 是在相容遗传基准下定义的加性方差参数。因此，混合模型方程中的随机效应精度项为 H_{rel}^{-1}/σ_a^2 ；

若残差协方差为 $I\sigma_e^2$ 并将整组方程乘以 σ_e^2 , 该项写为 $(\sigma_e^2/\sigma_a^2)H_{rel}^{-1}$ 。这里的关系矩阵本身不携带性状量纲。

这种条件分布观点说明, 基因组信息不仅更换右下角, 也通过亲缘关系改变未分型动物之间以及两组之间的协方差。若仅把 A 的右下角换成 G 而不调整其他块, 通常不能得到一致的联合模型。

更适合混合模型方程计算的形式是

$$H_{rel}^{-1} = A^{-1} + \begin{bmatrix} 0 & 0 \\ 0 & G^{-1} - A_{22}^{-1} \end{bmatrix}.$$

该式要求涉及的矩阵在所用空间上可逆; 实际可使用经过合理混合的正定 G 。Christensen 与 Lund (2010) 给出了同时处理已分型与未分型动物的联合建模路线, 是理解单步方法的重要原始文献。

单步逆矩阵公式中的 A_{22}^{-1} 是先取 A 的子矩阵再求逆, 不是先求 A^{-1} 再取右下块。二者一般不相等。这个次序错误足以使程序产生看似平滑、实际不符合模型的育种值。

28.2 条件分布、精度更新与单步方程的推导

28.2.1 用一个生成模型保证所有分块彼此相容

设未分型动物条件残差为 ξ , 满足 $u_1 = Bu_2 + \xi$, $\text{Var}(\xi) = S_1\sigma_a^2$, 且 ξ 与 u_2 独立。令 $\text{Var}(u_2) = G\sigma_a^2$, 那么联合模型由两个独立随机来源生成, 天然具有合法的协方差。对于任意向量 v_1, v_2 , 联合二次型等于 $v_1'S_1v_1 + (B'v_1 + v_2)'G(B'v_1 + v_2)$ 再乘遗传方差, 因此当 S_1 与 G 正定时, H_{rel} 也正定。这个证明比逐个检查分块元素是否像亲缘系数更有力, 因为协方差合法性是整体性质。

相应联合负对数密度中, 与 u 有关的二次惩罚为 $(u_1 - Bu_2)'S_1^{-1}(u_1 - Bu_2) + u_2'G^{-1}u_2$, 暂省略共同方差尺度。若仍使用系谱边际, 则最后一项为 $u_2'A_{22}^{-1}u_2$, 前一项不变。两种联合精度之差因此只出现在已分型组块, 恰为 $G^{-1} - A_{22}^{-1}$ 。单步逆矩阵公式由此直接得到, 而不需要把整个 H_{rel} 展开后作稠密求逆。这

一推导同时解释了为什么是替换信息，而不是在系谱信息上无条件再加一份基因组信息。

28.2.2 加入表型后仍是同一个混合模型

设表型模型为 $y = X\beta + Zu + e$, $R = \text{Var}(e)$, 遗传协方差为 $H_{rel}\sigma_a^2$ 。混合模型方程的随机效应块是 $Z'R^{-1}Z + H_{rel}^{-1}/\sigma_a^2$, 交叉块为 $X'R^{-1}Z$, 右端随机块为 $Z'R^{-1}y$ 。这里 Z 把记录连接到动物, 既可一只动物多条记录, 也可某些动物完全没有记录; 它与第 26 章的基因型矩阵 W 承担不同作用。把分型矩阵直接放到这个位置而仍声称求动物效应, 会产生维度和模型意义的双重混乱。

由于基因组信息进入先验精度, 未分型动物的表型也可经由整个方程影响已分型亲属及标记支持的遗传方向。这种双向连接是单步方法的重要特点。但模型不会把没有任何亲缘连接、没有表型且没有基因型的个体神奇地估计得很精确; 它最多获得相应基础群体或先验均值信息。数据连通性决定实际信息路径, 统一方程只是使这些路径被一致表达。

28.2.3 算例：错误的右下角替换会破坏正定性

考虑两只动物的系谱矩阵 $A = \begin{bmatrix} 1 & 0.8 \\ 0.8 & 1 \end{bmatrix}$, 第二只已分型, 取其新边际方差为 $G = 0.5$ 。若只把右下角从一改成 0.5, 行列式为 $0.5 - 0.64 = -0.14$, 所得矩阵不再是合法协方差。按条件模型, $B = 0.8$, $S_1 = 0.36$, 正确新矩阵为 $\begin{bmatrix} 0.68 & 0.4 \\ 0.4 & 0.5 \end{bmatrix}$, 行列式为 0.18, 保持正定。变化不仅发生于已分型动物自身, 也发生于交叉关系和未分型动物方差。

这个人为构造的边际变化较大, 目的是显露代数差别, 并不表示实际评定应把某一动物方差任意改成一半。真实 G 必须先有清楚的基群和尺度解释, 调整也需经过诊断。小算例的价值在于提供反例: 即便原 A 和新 G 各自都正定, 机械拼接仍可能失败。因此, 任何新的关系融合策略都应从联合模型或合法矩阵构造出发, 不能仅凭单元格经验修改。

这一条件分布解释还适用于缺失组学、部分测定和多群体信息整合。关键问题始终是保留哪些条件关系、替换哪些边际关系，以及替换后整个模型是否一致。单步评定提供了一个具体范例，但把其公式推广到别的资料时，仍需要重新核对随机变量、量纲和条件独立假设。

28.2.4 精度差允许正负，整体模型仍须合法

单步修正块 $G^{-1} - A_{22}^{-1}$ 本身不一定半正定。原因在于它先移去系谱模型已经包含的边际精度，再加入基因组边际精度，是两个信息描述的替换差，而不是一份独立新观测的精度。若 G 在某个方向上的方差大于 A_{22} ，其逆在该方向可能更小，修正便为负。只要完整条件模型合法，不能因为修正块出现负特征值就判定单步方法错误；应检查整体 H_{rel} 或完整方程，而不是错误地要求每一个加减项都单独代表协方差。

标量例子中， $A_{22} = 1$ 而 $G = 2$ ，精度差为 -0.5 。这表示基因组参照认为该方向遗传变异更大，先验收缩应相应减弱。若 $G = 0.5$ ，精度差为一，收缩反而增强。两种情况都可以是数学上合法的模型，是否具有合理生物解释则取决于尺度相容性。数值合法、模型一致和生物合理是三个递进的判断，不能彼此替代。

28.3 算例一：一只未分型动物如何获得新信息

设动物 1 和 2 无亲缘，动物 3 为它们的后代，系谱矩阵为

$$A = \begin{bmatrix} 1 & 0 & 0.5 \\ 0 & 1 & 0.5 \\ 0.5 & 0.5 & 1 \end{bmatrix}.$$

只有动物 2 和 3 已经分型。教学用的相容基因组矩阵取为 $G = \begin{bmatrix} 1.1 & 0.6 \\ 0.6 & 1.2 \end{bmatrix}$ 。由条件回归公式， $B = (-1/3, 2/3)$ ，且 $S_1 = 2/3$ 。

这里的负系数并不表示动物 1 与动物 2“负亲缘”，而是在已知动物 3 后，对动物 2 的信息作条件校正。

计算 $BG = (0.033333, 0.600000)$ ，再计算 $S_1 + BGB^T = 1.055556$ ，得到

$$H_{rel} = \begin{bmatrix} 1.055556 & 0.033333 & 0.600000 \\ 0.033333 & 1.100000 & 0.600000 \\ 0.600000 & 0.600000 & 1.200000 \end{bmatrix}.$$

没有分型的动物 1，其对角元和与另外两只动物的关系都发生了变化。这就是统一模型的信息传递作用。并非给动物 1 凭空增加了基因型，而是在共同系谱条件下，用已分型亲属提供的更具体协方差信息更新联合描述。

分别由单步逆矩阵公式和对上面完整关系矩阵直接求逆，得到相同结果：

$$H_{rel}^{-1} = \begin{bmatrix} 1.5 & 0.5 & -1 \\ 0.5 & 1.416667 & -0.958333 \\ -1 & -0.958333 & 1.8125 \end{bmatrix}.$$

本书数值程序比较两条路线，最大绝对差小于 3×10^{-16} 。该检验只证明这个小例子的矩阵恒等式与程序实现一致，不证明真实育种群体的模型假设已经成立。

从这里还能得到一个解释性检查：若 $G = A_{22}$ ，则 $H_{rel} = A$ ，单步模型应退化为系谱模型。若程序在这种设定下仍产生不同结果，应首先检查动物排序、尺度和子矩阵索引。




图 28.1 单步关系更新传播到未分型动物

图 28.1 使用第 28.3 节三动物教学数据，对比系谱关系、单步关系及其差值。三图使用同一色阶；只有动物 2 和 3 分型，动物 1 的方差与交叉协方差也被条件模型更新。

28.4 选择历史、未分型记录与信息完整性

28.4.1 单步方法为什么关心过去被用于选择的资料

育种群体经历连续选择，当前获得表型或基因型的动物往往由过去的记录筛选而来。在经典可忽略选择的论证中，若选择由已纳入模型的信息决定，且模型正确描述联合分布，条件于这些信息进行推断可避免某些选择偏差。若决定分型的是未保留的内部指数、未记录的疾病表现或场主主观判断，条件信息并不完整。单步模型把更多相关表型和系谱连接起来，有助于保留选择依据，却不能使从未记录的决定因素自动出现。

因此，资料截断不是纯粹的计算操作。删除早代低价值动物、只保留近年优秀亲本的后裔，可能改变对基础均值和选择差异的识别。另一方面，非常古老且记录制度不可比的数据也可能增加噪声与模型错设。合理取舍需要结合选择历史、连接结构和模型复杂度，比较不同截断方案对遗传趋势、候选校准和方差估计的影响。不能以“数据越多越好”代替评估，也不能以“旧资料离当前候选很远”为由默认其毫无统计作用。

28.4.2 未分型动物的价值不只在于增加表型行数

一只未分型母畜可以连接多个已分型后代，帮助区分共同亲本贡献与孟德尔抽样；一个未分型同期群可以帮助估计场年环境，使已分型动物的表型校正更可靠；历史未分型亲属还能提供选择前分布的部分信息。这些作用不同于把同样数量的独立表型简单加入训练。评估未分型资料的价值时，应看它们连接哪些遗传与环境方向，而不只看记录总数。

设同一场内有一只分型动物和九只未分型同期动物。即使后九只与候选没有近亲关系，它们的记录仍可能提高场效应估计，从而间接改善分型动物的遗传信息。如果把所有未分型动物删除，场均值可能几乎由那一只分型动

物的表型决定，使遗传与环境难以区分。相反，若未分型记录来自完全不相连的场且模型为每场独立固定效应，其对目标候选的贡献可能很小。信息增益依赖设计和连接，不能由分型状态单独决定。

28.4.3 算例：遗漏选择指标怎样改变条件推断

考虑两个标准化遗传量 u 与 v ，相关为 0.5。若只保留 v 较高的动物，而在分析 u 时没有记录 v 或其选择代理，入选群体的 u 均值通常也会升高。即使目标性状本身没有直接被选择，相关性也会传递选择影响。若 v 服从标准正态并按 $v > 0$ 截断，则 $E(v | v > 0) = \sqrt{2/\pi} \approx 0.797885$ ，因此 $E(u | v > 0) = 0.398942$ 。这一均值变化由联合分布和选择规则产生，与实验测量是否准确无关。

如果分析者误把入选动物当作未选择总体来估计均值与方差，可能得到错误参照；如果保留 v 并正确建模，可以条件于实际选择信息解释变化。真实育种中的选择往往基于有误差的指数、多性状约束和繁殖机会，情形比这个截断模型复杂，但基本逻辑相同。算例不提供普遍的偏差修正系数，而说明为什么保留选择依据、淘汰原因和历史评定版本具有统计价值。

28.4.4 历史连接也有边界与代价

系谱错误可能把本来独立的资料错误连接，造成看似精确但不可信的信息传递。对父母来源不确定的历史记录，可以采用明确的未知亲本处理或概率亲缘模型，不能因为单步方法需要连接就强行指定某个父亲。跨国或跨品种资料还可能存在重复动物编号、性状单位差异和不同遗传基准，合并前应解决身份与定义问题。统一矩阵不能补救不一致的输入语义。

对大规模系统，可把资料保留政策与验证计划一起制定：保留哪些历史表型、哪些选择指标、哪些错误修正记录，以及哪些动物即使没有当前表型仍应作为系谱连接节点存在。每次截断都应报告删除的动物类别及对连接的影响。这样的政策使统计模型能够利用真实存在的信息，同时控制存储和维护成本，避免在每次计算压力上升时临时删除最难处理却可能最关键的资料。

28.5 基群、选择与未知亲本

统一关系的困难常常不在求逆，而在“相对于谁”。传统系谱通常假定基础动物相互无关；近年的已分型动物却经历了多代选择。基因组矩阵若以当前样本频率为参照，直接与以早期基础动物为参照的系谱矩阵比较，就可能混入基群差异。加权或调尺度能够处理部分不相容，却不能替代对群体历史的理解。

未知亲本组以固定或其他指定方式描述不同来源、时期的平均遗传水平；元基础群体（metafounders）则进一步为基础群体之间与群体内部配置关系结构。它们不是可以随意互换的“批次校正”。分组过细而资料稀少时，参数可能缺乏支持；分组过粗又可能把实际群体差异强行压在一起。

Legarra 等（2024a）用等位基因频率的交叉乘积重新阐释元基础群体关系，使其对参考等位基因的同步翻转保持不变。其伴随研究（Legarra 等，2024b）提出适用于不平衡资料及复杂基础群体的关系估计方法。关键进展是把基群关系的定义与估计分开处理，而不是为每个未知亲本任意设定一个常数。

为理解定义，假设两个基础群体在两个位点的频率分别为 (0.2, 0.7) 和 (0.3, 0.8)。以所有位点频率 0.5 的概念群体为参照，构造行向量 $2p_b - \mathbf{1}$ ，得到 (-0.6, 0.4) 和 (-0.4, 0.6)。采用 $2/m$ 倍交叉乘积，得 $\Gamma = \begin{bmatrix} 0.52 & 0.48 \\ 0.48 & 0.52 \end{bmatrix}$ 。同步翻转任一位点的参考等位基因只改变该列符号，故 Γ 不变。这个教学矩阵描述的是群体参照关系，不能把 0.52 读作某只个体的系谱近交。

另一个问题是选择。如果只有被选中的动物进入数据，模型要处理的是经历选择的信息系统。单步方法可以帮助把选择时可用的遗传信息纳入统一分析，却不自动消除全部选择偏倚。选择所依据而未记录的性状、被丢弃的历史表型、错误父母以及不可比的测定制度，仍会影响评定。资料保留政策也是统计方法的一部分。

28.6 元基础群体、未知亲本组与跨群体基准

28.6.1 均值差异与祖先关系是两个层面

未知亲本组通常把来源、时期或品种不同的基础动物归入若干组，以表示其平均遗传水平差异。元基础群体还为这些群体配置随机关系，使基础来源的相关性向后代传播。前者主要解决均值结构，后者还改变协方差结构；两者在特定参数化下可以联系，但不应把任意组固定效应直接读成群体关系。Legarra 等（2015）提出的元基础群体框架，为有限祖先群体与群体间关系提供了明确的建模入口。其适用价值取决于基群定义及资料能否支持相应参数。

传统无关基础动物假设是一种参照约定，并不表示历史上它们真的没有共同祖先。对同一封闭育种群体，深度系谱可能使该近似在某些任务中足够有用；对多个品种或大量未知亲本，忽略基础关系可能更明显地影响尺度匹配。元基础群体并不要求追溯全部遥远祖先，而以低维结构近似表示它们的平均联系。近似的合理性应通过遗传基准一致性、预测校准和敏感性分析检验。

28.6.2 关系参数必须保持整体合法

元基础群体关系矩阵 Γ 应为对称半正定，不能逐对独立估计后随意拼接。若两个群体各有一个自关系参数和一个互关系参数，必须满足 $\Gamma_{12}^2 \leq \Gamma_{11}\Gamma_{22}$ 。当两群体频率向量几乎相同，矩阵可能接近奇异，说明数据很难把它们当作独立祖先来源区分。此时加小对角项虽能改善计算，却改变了群体关系假设，应说明其大小及影响。

以本章两群体示例 $\Gamma = \begin{bmatrix} 0.52 & 0.48 \\ 0.48 & 0.52 \end{bmatrix}$ 为例，两个特征值为一和 0.04，分

别对应共同方向和群体对比方向。相近频率使两群体共享方向很强，而群体间差异较小。若把非对角元误写成 0.60，则第二特征值为 -0.08 ，关系矩阵非法。这个例子说明，估计误差不能只通过把每个元素裁剪到零与一之间处理；合法范围受到整个矩阵共同约束。

28.6.3 分组过细未必增加生物学分辨率

把每一年、每个地区和每个品种交叉后建立大量基群，形式上很精细，但可能使每组只有少数有效后代。群体参数与年度环境效应、遗传趋势或未知父母比例之间容易混淆。若某一来源只在一个场出现，均值差异可能无法与场效应分开；若相邻年份几乎由同一批亲本贡献，逐年独立估计关系也可能过度参数化。应先检查分组依据是否具有遗传学意义，再检查连接与有效样本量，而不是让软件允许的组数决定模型复杂度。

一种可行的建模思路是从较少且可解释的基础来源开始，检查残差、遗传趋势和候选校准，再增加确有证据支持的分组。另一种思路是为相邻时期或相似来源设置平滑或层级约束，使资料不足的组共享信息。这些约束应公开，因为它们会影响结果。若研究目标只是稳健预测，适度合并可能优于不稳定的精细分解；若目标是估计历史群体关系，则需要为该目标设计额外样本和更充分的不确定性分析。

28.6.4 基群关系估计与预测应避免隐藏循环

频率或基群关系可以从后代基因型反推，但后代经过选择且家系贡献不均，简单算术平均未必代表基础频率。Legarra 等（2024b）讨论的似然及相关估计路线，针对的正是复杂资料中基群关系的估计问题。使用这些方法时，应分别记录定义、估计数据、约束和评定参数化，不能只报告最终一张 Γ 。若研究还根据验证表现选择了基群分法，这一选择也应纳入训练流程，而不能视为与预测无关的预处理。

跨品种或杂交分析还需明确遗传方差尺度。把频率统一设为某个概念参照以后，方差参数的意义随之改变；基础关系和孟德尔抽样方差也应采用相容的参数化。不能在某一步使用元基础群体关系，另一步仍沿用不相关基础动物下的公式，然后仅靠最终均值对齐掩盖不一致。最可靠的实施方式是先在系谱上写出生成模型，验证每个后代的方差与亲子协方差，再扩展到生产规模。

对最终用户，元基础群体的复杂参数通常不必全部进入日常报表，但其影响应能追溯。若跨品种育种值基准发生明显改变，应说明变化来自哪些基

础关系或方差定义，并通过共同候选及后期资料检查。方法增加的并不是无条件“公平性”，而是更明确地表达不同遗传来源的机会；是否改善具体群体的可比性，仍由数据与验证决定。

28.7 系谱子矩阵的逆、舒尔补与隐式运算

28.7.1 取子矩阵与求逆为什么不能交换

把完整系谱逆矩阵分块为 $A^{-1} = \begin{bmatrix} F_{11} & F_{12} \\ F_{21} & F_{22} \end{bmatrix}$ 。对未分型动物积分消去

后，已分型组的边际精度是 $A_{22}^{-1} = F_{22} - F_{21}F_{11}^{-1}F_{12}$ 。因此，右下精度块 F_{22} 描述的是给定未分型组后的条件精度， A_{22}^{-1} 描述的是未分型组未被固定时的边际精度。两者差异来自被消去变量传递的不确定性。理解条件与边际，比记忆一个禁止事项更有助于在复杂分块模型中避免同类错误。

对于本章三只动物的系谱，完整逆矩阵右下两只动物的块为 $\begin{bmatrix} 1.5 & -1 \\ -1 & 2 \end{bmatrix}$ ，

而 $A_{22}^{-1} = \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix}$ 。前者的对角线更大，因为它假定另一只动物的遗传值已知。若误用前者进入单步扣除项，会扣除过多且结构不同的系谱信息，

所得结果不再对应前面定义的联合模型。这个错误可能不引起程序崩溃，因此必须通过明确的矩阵恒等式检查。

28.7.2 不形成稠密逆也能计算其乘积

对向量 v ，先计算 $F_{12}v$ ，解稀疏系统 $F_{11}z = F_{12}v$ ，再得到 $A_{22}^{-1}v = F_{22}v - F_{21}z$ 。如果 F_{11} 可高效分解或迭代求解，这种隐式运算可以避免显式保存完整 A_{22}^{-1} 。但每次外层求解都调用内层求解时，内层误差会影响外层迭代，应协调容差和对称性。把所有内部系统都解到机器精度可能浪费时间，解得过粗又可能破坏外层收敛和最终精度。

这里的计算节省取决于系谱结构及所需乘积次数。稀疏分解可能产生填充，即原矩阵零位置在分解因子中变为非零。合理重排序能够减少填充，改

善内存和速度；这种重排序只改变计算顺序，不应改变动物身份对应的模型。若在重排序后忘记逆映射，得到的数值也许满足方程，却会被赋给错误动物。工程上的索引契约与统计方程同样重要。

28.7.3 系谱裁剪何时是精确化简，何时是近似

某些没有记录、没有分型且不连接任何目标动物的枝条，可以在明确边际化规则下移除而不改变目标预测。另一些看似无记录的祖先却连接多个家系，删除它们会改变关系与条件分布。是否可以裁剪，不能只看该动物是否拥有自己的表型。应判断它是否处于目标变量与观测资料之间的信息路径上，以及删除后是否保留了等价的边际关系。把整个家系压缩成某种边界信息也可以是精确操作，但需要正确传递消元后的精度和右端项。

在动态数据库中，某只动物当前没有直接用途，将来可能因后代分型而成为关键连接。因此，生产数据保存与某次求解用的精简视图应分开管理。可以为本次评定生成最小相关系谱，同时保留完整可追溯原始系谱。若为节省存储永久删除祖先，未来重建关系可能无法恢复。统计计算的局部便利不应决定原始资料是否可继续用于新的研究问题。

28.7.4 稀疏、低秩和条件独立是不同结构

系谱逆稀疏来源于亲子传递的局部递归，基因组关系的低有效维度来源于有限遗传方向，APY 的稀疏精度则来自给定核心组后的条件近似。这些结构可以组合使用，但不能互相替代解释。一个矩阵低秩并不意味着其逆稀疏；一个矩阵稀疏也不意味着容易分解；一个近似精度具有许多零，也不表示原始动物之间没有边际亲缘。清楚区分这些概念，有助于理解为何不同算法在不同群体规模与结构下表现不同。

在方法报告中，建议把“精确代数变换”“数值近似求解”和“统计结构近似”分别列出。读者由此可以判断误差可能来自哪里，以及提高资源能否减少误差。若一种方法只是把同一系统写成适合稀疏求解的形式，它的预测差异应仅为数值精度；若删去了条件协方差，则即便无限计算也不会自动回到原模型。下一节的 APY 正需要在这一个框架下理解。

28.8 算例二：APY 近似究竟省略了什么

当分型动物极多时，稠密 G^{-1} 的存储和计算成为瓶颈。把分型动物分成核心组 c 与非核心组 n ，设

$$T = G_{nc}G_{cc}^{-1}, \quad S = G_{nn} - G_{nc}G_{cc}^{-1}G_{cn}.$$

精确条件模型为 $u_n = Tu_c + \varepsilon$ ，其中 $\text{Var}(\varepsilon) = S$ 。APY 一类近似的关键，是用 $D = \text{diag}(S)$ 替代完整 S ，忽略给定核心组之后非核心动物残差之间的协方差。其近似逆矩阵为

$$G_{APY}^{-1} = \begin{bmatrix} G_{cc}^{-1} + T^T D^{-1} T & -T^T D^{-1} \\ -D^{-1} T & D^{-1} \end{bmatrix}.$$

考虑 G 的三行依次为 $(1, 0.6, 0.4)$ 、 $(0.6, 1, 0.3)$ 和 $(0.4, 0.3, 1)$ ，只取动物 1 为核心。此时 $T = (0.6, 0.4)^T$ ， S 的对角元为 0.64、0.84，非对角元为 $0.3 - 0.6 \times 0.4 = 0.06$ 。APY 把最后这个 0.06 置为 0，因此近似 G 的动物 2、3 关系从 0.30 变成 0.24，而其他元素不变。

为看清影响，设已知均值为 0、残差方差为 1，观测 $y = (1, 0, -1)^T$ 。精确 G 给出的预测约为 $(0.345754, 0.103986, -0.384749)^T$ ，上述近似给出 $(0.339310, 0.124138, -0.382759)^T$ 。变化不大但并非零。若把动物 2 也放入核心组，只剩一只非核心动物，其条件协方差天然为一维，此例就恢复精确。

因此，核心动物越多通常能更充分覆盖遗传信息，但“核心越多越好”还受成本限制。应考察核心组对主要遗传方向、不同品种与世代的覆盖，验证不同核心选择下的预测、校准和近似误差。不能只看迭代是否收敛，因为一个近似方程可以收敛得很好，却稳定地偏离原模型。

28.9 核心组选择、条件残差与 APY 误差诊断

28.9.1 核心组的作用是覆盖遗传方向

APY 名称中的“已验证与年轻”来自早期分组背景，但核心动物不必仅按年龄或已有可靠度定义。核心组承担的是提供能够解释非核心动物遗传协

方差的基底。若只选择一个高度近亲家系，即使每只动物都有高可靠度，也可能遗漏其他品种或家系方向；若核心覆盖充分，一些青年动物也可提供有用的独特遗传信息。Misztal、Legarra 与 Aguilar (2014) 给出了递归构造的原始路线，后续研究进一步考察核心规模与定义，不能把最初名称误读为永久固定的生物分类规则。

在条件分布中，核心不足主要表现为非核心残差协方差 S 仍含明显非对角结构。APY 保留每只非核心动物尚未被核心解释的方差，却把这些剩余部分视为相互独立。若被遗漏结构恰好对应一个重要群体或家系，近似可能在总体相关很高时仍对该群体产生系统性影响。核心组诊断应包含分群体、分世代和分家系的误差，而不是只计算所有动物的一个相关系数。

28.9.2 从条件方差看新增核心的边际作用

假设现有核心为 c ，考虑把一个非核心动物 k 加入。对于另一个非核心动物 i ，在原核心条件下，其残差方差为 S_{ii} ，与 k 的残差协方差为 S_{ik} 。加入 k 后，条件方差减少 S_{ik}^2/S_{kk} ，前提是 $S_{kk} > 0$ 。因此，一个动物是否有价值，不只看其自身条件方差大不大，还看它与其他未解释方向的联系。若它的残差与所有其他动物独立，加入核心只改变自身表示，对其余动物帮助很小。

在三动物例子中，原非核心残差块为 $\begin{bmatrix} 0.64 & 0.06 \\ 0.06 & 0.84 \end{bmatrix}$ 。把原第二只动物加

入核心后，最后一只动物条件方差为 $0.84 - 0.06^2/0.64 = 0.834375$ 。原先其未解释方差为 0.84，减少仅 0.005625；但由于非核心只剩一只，所有非对角条件协方差都已被消除，此小例的 APY 因此精确。这个结果说明“方差解释增加很小”与“某种结构近似变成精确”并不矛盾，两者衡量的对象不同。

28.9.3 核心大小与抽样规则应共同验证

可比较随机核心、按群体分层核心、谱或条件方差驱动的核心，以及生产中方便维护的固定核心。Abdollahi-Arpanahi、Lourenco 与 Misztal (2022) 在大规模杜洛克猪资料中系统研究多种核心定义与规模，为这种比较提供了原始研究实例。其结果不能直接转成所有物种的统一核心比例，因为有效群

体大小、历史重组、分型密度和群体混合都会改变所需方向数量。应用时应在本群体中设置规模梯度，并观察预测和校准何时趋于稳定。

只以累计特征值解释比例选择核心也有局限。较小特征方向可能包含少数群体特有信息，虽然对全体矩阵迹贡献小，却对这些候选很重要。可以在总体谱标准之外增加代表性约束，并对重点群体单独检查误差。核心组更新还应考虑新引入品种或长期未覆盖家系；若总动物数增长主要来自已有方向，核心可能不必同比扩大，若新增遗传多样性明显，固定核心则可能逐渐失配。

28.9.4 近似误差不是单一矩阵距离

可以比较 G 与 G_{APY} 的最大元素差、谱范数或特征结构，但预测误差还取决于表型信息和残差方差。设精确系统矩阵为 L 、近似为 $L + E$ ，小扰动下解差约为 $-L^{-1}E\hat{\theta}$ 。同样大小的 E 若落在信息薄弱方向，影响可能更大；若被大量高精度记录约束，影响可能较小。由此不能仅凭关系矩阵差异小就保证所有性状预测差异小，也不能仅凭某一性状结果稳定就证明所有下游分析稳定。

在可精确求解的代表性子集上，可同时比较关系近似、育种值均值与尺度、重点候选差异、可靠度以及关联效应回算。全量资料则可通过多个核心方案、局部精确核验和残差结构诊断补充证据。应特别记录是否存在对某些动物近似条件方差极小的情况，因为其倒数会形成很大精度，放大数值误差。必要的稳定化应被视为明确模型选择，并检验其对候选排序的后果。

28.10 迭代求解、预条件与误差预算

28.10.1 方程残差与育种值误差不是同一个量

令整个受约束混合模型系统为 $L\theta = d$ ，其中 θ 同时包含固定和随机效应。第 k 次迭代解为 θ_k ，方程残差 $r_k = d - L\theta_k$ ，解误差则为 $\theta - \theta_k = L^{-1}r_k$ 。若 L 的条件数较大，即使残差相对右端项已经很小，某些弱信息方向上的解误差仍可能明显。因此，停止规则应结合相对残差、关键育种值变化和模型

结构，而不能只报告迭代次数。不同方程缩放还会改变残差数值，比较两个程序的容差时必须明确所用范数和尺度。

设 $L = \text{diag}(1, 0.0001)$ ，真实解为 $(1, 1)'$ ，某次近似解为 $(1, 0)'$ 。右端项为 $(1, 0.0001)'$ ，方程残差只有第二维的 0.0001，相对残差约为 10^{-4} ，但第二维解误差仍为一。这个例子没有复杂遗传结构，却清楚显示了“残差很小”不能脱离条件数解释。实际评定中，连接薄弱的固定效应、尺度悬殊的性状和近似奇异的关系方向都可能造成类似数值困难。

28.10.2 预条件的目标是改变求解几何

对称正定预条件矩阵 B_0 应易于求解并近似 L 的主要结构。将系统变换为 $B_0^{-1/2}LB_0^{-1/2}$ 后，理想情况是特征值更集中，从而加速共轭梯度等方法。对角预条件便宜，能处理不同效应的基本尺度差异；按动物、性状或效应组构造块预条件可保留更多相关结构，却增加建立和应用成本。预条件质量与总体时间应一起评估，不能只因迭代次数减少就宣布更高效。

如果预条件只用于求解，最终充分收敛后应回到相同统计解。若把预条件近似直接代替模型精度而不继续修正，则变成另一个统计近似。两者在代码中可能只差几行，解释却完全不同。报告中应说明哪些矩阵只是帮助迭代，哪些矩阵实际定义了最终协方差。对于内外层迭代或近似矩阵向量乘积，还要检查是否保持所需对称性及误差控制，避免名义上使用某算法但破坏其适用条件。

28.10.3 数值精度应与育种决策精度匹配

遗传参数估计、数据测量和模型近似都含有不确定性，把线性系统解到远小于这些误差的最后若干位小数，未必有实际收益。但过早停止可能让重要候选在选择阈值附近发生不稳定交换。可以先在代表性评定上用严格容差得到参考，再逐步放宽，观察候选育种值、经济指数、群体校准和选择名单的变化。由此确定生产容差，使数值误差相对于实际决策尺度可忽略。这个标准应随模型和数据规模更新，而不是长期沿用未经解释的默认值。

使用较低精度存储或混合精度运算时，也应区分数据输入量化、矩阵乘

积累和最终迭代修正。基因型整数可以压缩保存而不损失其原始离散信息，关系矩阵转为低精度则会产生舍入误差。对于接近奇异的矩阵，小误差可能影响正定性和条件方差，不能只看平均元素误差。可以在关键分解或残差重计算阶段使用较高精度，在大规模乘积阶段使用经验证的较低精度，从而平衡速度与稳定性。

28.10.4 热启动与更新应防止旧解掩盖新问题

相邻评定期的数据差异较小时，使用上一期解作为初值通常能减少迭代。但旧解也可能使相邻迭代变化一开始就很小，而新的方程残差仍未达到要求，特别是新加入一批遗传来源不同的动物时。因此，热启动必须根据新系统检查残差，不能只看与旧结果接近。固定效应水平新增、动物重排序或基准变换也需要正确映射旧解；把上一期数组按位置直接复制，是常见而难以从总体相关发现的错误。

稳定的求解日志应记录右端项尺度、初始与最终残差、迭代次数、预条件设置、异常值和停止原因。达到最大迭代数与达到收敛阈值必须有不同状态。若某一性状持续难以收敛，应调查数据连接、参数边界和关系尺度，而不能仅增加迭代次数。数值困难有时是统计可识别性问题的信号，求解器日志因此也是模型诊断资料。

28.11 标记效应单步模型与未观测基因型的条件表示

28.11.1 从动物效应切换到标记效应并未改变信息原则

单步思想不必只能通过显式 H_{rel} 实施。可以把已分型动物的遗传值写成 $W_2\alpha$ 加适当的剩余遗传成分，再用系谱条件关系表示未分型动物。Fernando、Dekkers 与 Garrick (2014) 提出了一类把已分型与未分型动物统一纳入的贝叶斯回归模型，为这一方向提供原始方法。其关键不只是给未分型动物填上一张标记表，还要保留真实基因型偏离条件预测的残余遗传不确定性。忽略这部分会让未分型动物被误当作拥有精确基因型。

设条件预测的标记协变量为 $\widetilde{W}_1 = BW_2$ 。若写 $u_1 = \widetilde{W}_1\alpha + \zeta$ ，其中 ζ 的

协方差与条件遗传残差相容，就可以在标记效应与动物残差之间传递信息。这里的系谱条件预测不等同于利用密集单倍型完成的生物学基因型填充；它是给定模型下的线性条件表示。预测值可能不是整数，也不应直接被用于个体缺陷判型或亲子鉴定。相同术语“填充”在不同任务中代表的随机对象不同，必须说明。

28.11.2 条件残差为何不能删除

考虑一只未分型后代，双亲遗传值都已知。在不近交的简单加性模型下，后代仍有孟德尔抽样方差；知道双亲平均并不等于知道它实际继承哪一套染色体。若把后代基因型或遗传值完全替换成亲本条件均值，所有同父同母未分型后代在遗传上都会被当成完全相同，而且其自身表型难以合理更新独特偏差。保留条件残差使模型承认这些未观察的传递差异，并让表型在适当精度下提供信息。

在本章三动物示例中，未分型动物的条件方差为 $2/3$ 。若错误地删除它， H_{11} 会从 1.055556 降为 0.388889，且联合矩阵秩受已分型组限制。这个改变不是无害的内存压缩，而是声称未分型动物的全部遗传差异都能由已分型亲属精确解释。真实资料中这种过度确定性会影响收缩、可靠度和跨家系信息传播，即便部分预测排序表面相近，也不能认为模型等价。

28.11.3 剩余多基因成分与基因组混合相互对应

标记未能捕获的遗传变化可通过额外的系谱随机效应表示。若各成分独立，已分型动物的遗传协方差可以写为 $WW'\sigma_a^2 + A_{22}\sigma_r^2$ ，相当于某种基因组与系谱关系混合，但必须在同一尺度上匹配系数。这里 σ_r^2 表示剩余加性成分，不是环境残差方差。将它加入模型可能改善标记覆盖不足时的描述，却也增加与标记成分的区分困难，尤其两张关系矩阵高度相关时。

Taskinen、Mäntysaari 与 Strandén (2017) 研究了带在线填充及剩余多基因效应的单步 SNP-BLUP，展示了标记表示与计算组织可以共同发展。对使用者而言，重要的是明确未分型协变量如何形成、剩余成分如何设置、方差如何与动物模型匹配，而不是把所有名为单步的实现视为自动相同。小型

问题中比较等价参数化的育种值与预测误差,是确认实现与推导一致的有效方法。

28.11.4 效应回算与关联检验需要额外说明

在正态标记模型中,可以由动物效应预测回算一组标记效应,例如在相容条件下使用 $\hat{a} = \sigma_a^2 W_2' G^{-1} \hat{u}_2 / \sigma_a^2$ 。公式中各尺度必须根据实际 G 定义调整,若 G 已混合剩余多基因成分,则回算需要针对标记部分的交叉协方差。不能忽略混合后直接套用未混合公式,再把所得效应解释为唯一的遗传作用。回算预测是一种条件分配,连锁不平衡仍限制单个位点的可识别性。

关联检验还需要效应估计的标准误、零假设与多重比较处理。育种值高度相关并不保证回算效应在每个位点都稳定,因为相近预测函数可能对应不同系数组合。APY、低秩或其他近似若用于关联任务,应独立检查局部效应和检验校准。预测研究与机制研究可以共享计算框架,但后者的证据要求不会因前者计算成功而自动满足。

标记表示还为非正态先验提供扩展空间。若采用稀疏混合或不同区域效应方差,关系协方差可能随参数更新而变化,简单固定 G 的动物模型未必与其等价。说明等价需要哪些正态性、独立性和方差条件,能够避免把某个线性恒等式扩大为所有贝叶斯单步模型都相同的错误结论。

28.11.5 存储协变量与按需生成的权衡

若未分型动物很多,显式保存每只动物每个位点的条件协变量会形成巨大的稠密数组。按需计算可以把这部分转成稀疏系谱求解与标记矩阵乘积,节省存储,但每轮迭代可能重复执行某些运算。是否值得取决于动物数、标记数、迭代次数和数据读取速度。比较时应把初始化、重复乘积和最终回算都计入成本,不能只展示省掉某个文件后的内存下降。

缓存部分中间量可以折中,但缓存必须随系谱、基因型方向或频率版本变化而失效。错误缓存常给出非常快速且看似平稳的结果,因为程序确实在重复计算旧模型。可在小型资料中逐一改变亲子关系、标记方向和新增动物,检查隐式与显式表示是否同步更新。这样的扰动检查针对真实的连接风险,

比单纯在不变输入上重复运行许多次更有验证价值。

28.12 多性状、重复记录与复杂随机结构的扩展

28.12.1 同一关系系统可以连接不同性状

若每只动物有 q 个加性育种值，以动物为主顺序排列，则联合遗传协方差可写为 $H_{rel} \otimes \Sigma_u$ ，其中 Σ_u 为性状间遗传协方差矩阵。其逆在两部分可逆时为 $H_{rel}^{-1} \otimes \Sigma_u^{-1}$ 。如果改用性状为主顺序，克罗内克积的顺序相应交换，实际矩阵由一个置换联系。很多多性状实现错误来自排列约定不一致，而非协方差理论错误。应在两个动物、两个性状的小例子中逐项检查，再扩展到大系统。

设两动物关系为 0.4，某性状遗传方差为四，另一性状为九，遗传相关为 0.5，则性状间协方差为三。同一动物两性状协方差为三，两动物同一第一性状协方差为 1.6，两动物跨性状协方差为 1.2。这些量来自关系系数与性状协方差的乘积，单位也不同。把遗传相关 0.5 直接当作协方差放进矩阵，会改变量纲和预测权重。多性状系统越大，越应在输入阶段检查标准差、相关与协方差之间的转换。

28.12.2 缺失模式影响跨性状信息的实际价值

多性状模型可以让记录丰富的性状帮助记录稀缺的性状，但收益依赖遗传相关和数据连接。若两个性状从未在任何有连接的动物或环境中共同观察，遗传协方差可能主要由先验或外部估计决定。若缺失由疾病、淘汰或测定选择引起，简单把缺失视为随机也可能不合适。应该报告每个性状的记录数、共同记录数、家系和场群覆盖，以及协方差估计的不确定性，而不能只展示一张高遗传相关的点估计表。

同一动物不同性状的环境误差也可能相关，尤其测量来自同一次采样、相同饲料试验或共同评估人员。残差矩阵不能只根据动物关系构造，而应按真实记录配对和时间结构定义。遗传相关与残差相关在连接不足时容易互相补偿，使预测看似合理而分解不稳定。额外重复测量、跨环境后代或更好的

实验设计有助于区分这些来源，单步基因组信息能增加遗传连接，但不能替代所有设计条件。

28.12.3 重复记录和随机回归增加的不只是方程数

对纵向生长、泌乳或连续传感器记录，遗传效应可随年龄或时间变化，用随机回归系数表示曲线。此时关系矩阵连接不同动物的遗传曲线系数，而系数协方差控制曲线形状。永久环境曲线通常还需单独建模。某一时间点预测精确，并不意味着整个生涯曲线或外推阶段同样精确；边界时间缺少记录时，基函数可能产生较大外推不稳定。计算规模取决于动物数、基函数阶数和多个随机部分，不能直接沿用单性状动物模型的资源估计。

如果把高频传感器记录逐条视为独立残差，信息量可能被严重高估。测量连续性、共同设备漂移和动物永久环境会造成相关。可通过适当聚合、残差时间结构或状态模型表达，但每种方案都改变信息权重。选择聚合窗口时应考虑实际生物过程和决策时间，而不是只以减少行数为目标。对这些复杂模型，先验证记录层面协方差，再验证遗传关系融合，能更清楚地定位问题。

28.12.4 多性状计算的瓶颈需要分阶段识别

关系构建通常与性状数无关，但混合模型随机块、残差块和方差估计随性状数增加。计算一组育种值、估计完整协方差参数和求可靠度可能有完全不同的资源需求。若有十个性状，遗传协方差就有五十五个不同元素；再加入残差和永久环境结构，参数数目迅速增长。适当约束、因子结构或分组分析可能有用，但应确认它们保留了目标决策所需的遗传方向。

多性状参数矩阵必须保持正定或合法半正定。逐个估计相关后拼接，可能得到不合法矩阵；把负特征值简单裁剪虽然能继续求解，却改变了模型和相关结构。更透明的做法是在参数化中维持合法性，例如使用三角分解或明确的低秩结构，并对边界估计给出解释。估计接近奇异既可能反映真实高度相关，也可能反映资料不足，需结合标准误、似然与敏感性判断。

部署报告还应说明性状之间的预测变化。更新一个记录丰富性状后，另一个记录稀缺性状的育种值可能通过遗传协方差发生变化，这可以是合理的

信息传递。若协方差参数本身同时重估，变化来源则更复杂。通过固定参数与更新参数两套比较，可以区分新增记录与参数学习的贡献，让评定结果更容易被育种管理者理解。

28.13 可靠度、预测误差协方差与大规模近似

28.13.1 求出育种值不等于已经求出可靠度

线性系统只需一个右端项即可得到点预测，而精确预测误差协方差通常涉及混合模型系数矩阵逆的相关块。大型系统中，显式计算完整逆远比求一个解昂贵。可靠度因此常成为独立的计算任务，需要选定逆元素、近似信息量或随机化估计。应明确报告可靠度是精确条件计算、近似计算还是基于经验验证的群体指标，不能因为点预测来自同一软件就默认所有精度指标具有同样准确性。

在已知参数、适当处理固定效应的线性混合模型中，个体育种值可靠度常写为 $1 - PEV_i / (H_{rel,ii}\sigma_a^2)$ 。分母是该个体在模型参照下的先验方差，不能一律用同一个 σ_a^2 而忽略关系对角元。对于群体平均或对比，可靠度应由相应线性组合的方差计算，而非平均各个体可靠度。若参数由数据估计，这个公式通常给出条件于估计参数的近似，未必包含全部参数不确定性。

28.13.2 算例：群体对比比个体绝对值更精确

设两只动物先验方差均为一、先验协方差为 0.5；评定后预测误差方差均为 0.4、误差协方差为 0.3。单只动物可靠度均为 0.6。差值的先验方差为一，误差方差为 $0.4 + 0.4 - 2 \times 0.3 = 0.2$ ，所以差值可靠度为 0.8。两只动物的平均值先验方差为 0.75，误差方差为 0.35，其可靠度约为 0.5333。同样的个体信息，对比较和平均两种任务提供不同精度。

这个例子对跨场遗传比较尤其有启发。共同误差会在差值中部分抵消，却在均值中保留；如果不同场之间缺少连接，其群体平均误差可能相关很弱或具有难以估计的系统部分。不能用场内平均可靠度来证明场间育种值完全可比。连接性诊断需要针对实际比较的线性函数，计算其预测误差方差或相

应近似, 结合固定效应和数据设计解释。

28.13.3 随机化求逆诊断的基本思想

对可逆系数矩阵 L , 若随机向量 z 各分量独立取正负一且均值零, 则 $E(zz') = I$ 。解 $Lx = z$ 后, 有 $E(z_i x_i) = (L^{-1})_{ii}$ 。多次独立重复并平均, 可以估计逆矩阵对角线而不显式形成整个逆。类似地, $z'x$ 可估计迹。这里随机性来自计算探针, 不是生物数据抽样; 重复次数增加减少蒙特卡洛误差, 却不能修复模型错设或输入错误。

以 $L^{-1} = \begin{bmatrix} 2 & 0.6 \\ 0.6 & 1 \end{bmatrix}$ 为例, 单次对角估计为 $2 + 0.6z_1z_2$ 与 $1 + 0.6z_1z_2$,

各自围绕真实值波动 0.6。若只用很少探针, 某些个体可靠度可能显得不稳定, 甚至因估计误差落到理论范围之外。直接裁剪到零与一可隐藏问题, 应先报告随机误差并增加必要的重复。对于关键候选, 可进一步进行精确选定元素或更高精度局部核验。

28.13.4 近似可靠度需要独立校准

经验信息量近似通常利用记录数、后裔贡献、家系结构或矩阵对角块减少成本。它们在某些常规资料中可能十分实用, 但遇到多性状、不均衡连接、强基因组预选或新群体时, 需要重新检查。点预测的 APY 误差很小, 不保证可靠度近似也同样小, 因为二阶不确定性可能对被忽略方向更敏感。研究报告应分别验证点预测与精度指标, 不把二者捆绑成一个成功结论。

可以按可靠度分层, 比较预测更新幅度和后期资料中的实际误差, 检查高精度组是否确实更稳定。同时需要考虑后期资料本身的不确定性及其共同信息, 否则观察到的更新小可能仅因两次评定高度共享数据。模拟资料提供真值、真实资料提供部署相关性, 两者结合比任何单一证据更有说服力。对于外部群体, 可靠度应反映迁移风险, 而不能只沿用训练群体内部的条件计算。

最终报告宜把可靠度解释为在指定模型、参照和信息条件下的精度度量。它不是动物遗传价值的大小, 也不是所有未来环境中成功的概率。高可靠度的低育种值动物仍可能稳定地较差, 低可靠度的高育种值动物则可能值

得进一步测定。预测精度应进入风险分散和信息采集决策，而不应被误当作另一个性状直接追求最大化。

28.14 生产系统、增量更新与可追溯评定

28.14.1 一次评定是有时间边界的数据产品

生产评定通常按周、月或季度运行，数据来自多个场站、实验室与注册系统。必须规定某次评定包含哪些截至日期的表型、系谱修正和基因型版本，并保存输入快照或可重建的版本记录。否则，研究人员几个月后即使使用同一程序和参数，也可能因数据库已经更新而无法重现结果。时间边界还决定验证是否真实：用后来修正的父母关系重建过去预测，可以评估最终清洗资料下的方法，却不等于当时实际部署的表现。

样本唯一标识应贯穿原始采样、实验批次、动物登记和报告。对同一动物多个基因型版本，可以保存置信度与取用规则，不能让最新文件无提示地覆盖旧数据。位点排序、参考等位基因、频率文件和关系混合参数也应进入模型版本。育种值突然改变时，系统应能追踪是新表型、新亲缘修正、方差更新还是算法修改造成，而不是只能回答“重新运行后的结果如此”。

28.14.2 增量更新不应默认等同于重新评定

新增一批动物后，可以更新关系块、标记效应或方程右端项，而不必从头读取全部资料。但精确增量更新需要满足明确条件，例如旧参数、旧编码和旧资料保持不变，并正确处理新旧动物的交叉关系。如果同时重新估计频率、改变核心组或修正大量系谱，旧分解可能不再对应新模型。近似增量可以节省时间，但应定期与完整重算比较，确认误差不会逐期累积。

一个简单的更新实验可把同一资料分成若干批次，以不同顺序加入，最后与一次性分析全部资料的结果比较。若方法在理论上应精确且参数固定，最终结果应在数值容差内一致；若不一致，需检查缓存、顺序依赖和隐藏参数更新。若方法本身具有在线近似或遗忘机制，则顺序依赖可能是设计的一部分，但必须说明它如何影响当前候选及历史遗传趋势，不能把顺序差异当

作不可解释的随机波动。

28.14.3 故障处理需要区分数据、模型与求解三层

输入层故障包括身份重复、非法基因型、未来日期和系谱环；模型层故障包括不相容基群、不可识别固定效应、负方差或不合法协方差；求解层故障包括内存不足、迭代停滞和数值溢出。三类问题需要不同处理。对输入错误应返回可追踪的记录清单，对模型问题应调整定义或约束并重新验证，对纯求解问题才考虑预条件和资源。把所有失败统一称为软件报错，会掩盖真正原因并促使使用者随意放宽参数。

生产流程可以设置少量有明确意义的自动检查，例如总动物数与上期差异、基因型频率漂移、亲子冲突分布、关系对角线范围、候选均值变化和方程残差。阈值应从历史正常变化与决策容忍度制定，而不是使用无依据的统一数值。检查触发后需要调查，不应自动把异常动物删除或把预测拉回旧值。真正的遗传引入、疫情或管理改变也可能造成分布变化，监测应帮助解释而非强迫数据保持不变。

28.14.4 发布基准与模型基准应分别管理

报告时常把某一出生年或参考群体均值设为零，并用遗传标准差或经济单位表达结果。这是发布尺度转换。内部模型的基群关系、遗传方差和协方差则决定实际信息权重。两者都可能更新，但应分别记录。若只改变发布零点，个体差值和排序不变；若改变遗传尺度或性状经济权重，综合指数排序可能改变。用户需要知道自己看到的是哪一种变化，才能正确比较历史报告。

跨机构交换育种值时，还要说明是完整育种值还是预期传递能力、是否已经除以二、性状方向是越大越好还是越小越好、以及基准年份和单位。数学上很小的量纲差异可能在配种或经济计算中产生巨大后果。单步方法处理信息融合，但外部接口仍需明确这些定义。自动化传输并不会降低语义核对的重要性，反而要求更严格的字段和版本契约。

28.14.5 计算透明性与资料保密可以同时实现

育种企业或保种群体的个体数据可能不能公开，但仍可以提供算法定义、软件版本、模拟示例、汇总诊断和可授权的验证设计。外部研究者可根据此理解模型如何处理选择、基群和近似，并用公开教学资料复现关键恒等式。不能以商业保密为由只报告一个预测相关而不解释模型，也不必为了方法透明公开未经授权的个体身份与基因型。可复现性有多个层次，应明确哪些层次已经实现，哪些受资料访问条件限制。

评定系统的长期维护还需要把统计知识写进可执行说明：变量单位、缺失编码、动物排序、参数约束、容差和失败状态都应有稳定定义。人员交接后能够重建一次历史结果，比保存一份庞大但无人理解的输出目录更有价值。大型计算的最终质量不仅取决于速度，也取决于结果是否可解释、可检查，并能在新的资料条件下持续接受验证。

28.15 大规模计算应保持的统计不变量

计算优化的第一原则是避免不必要的逆矩阵。求 $Lx = d$ 通常应使用分解或迭代求解，而不是显式构造 L^{-1} 。系谱逆矩阵可利用稀疏结构，标记矩阵可以按块读入，关系乘积可按需计算。不同精度的数值存储也需要通过预测差异和收敛稳定性验证，不能只报告文件缩小比例。

若核心规模为 c 、总分型数为 n ，APY 有关步骤的主要成本可包含 c^3 及 nc^2 量级，存储可利用 nc 结构。当 c 固定时，随 n 增加的部分近似线性；当群体扩大导致所需 c 同时增加时，不能继续把总成本简单宣称为线性。多品种、复杂家系和更大有效群体可能需要不同核心规模。

迭代求解时，预条件的作用是改善方程的数值几何，而不是改变目标统计模型。以正定系统 $Lx = d$ 为例，可用容易求解的近似矩阵 B_0 作预条件，使变换后的系统各方向尺度更接近。迭代过程中应监测相对方程残差 $\|d - Lx_k\| / \|d\|$ ，同时抽查育种值变化。仅监测相邻两次解的差异有时不够，因为停止更新可能来自数值停滞而非真正求解充分。

考虑一个极简例子：两维对角系统的系数为 1 和 10000。两个方向的曲

率相差很大,简单固定步长方法可能收敛缓慢。若以相同对角系数构造预条件矩阵,变换后两个方向的尺度都是 1。真实混合模型并不如此简单,但这个例子说明,好的预条件利用方程结构降低计算难度,并未更改育种目标、遗传方差或观测资料。

还需要区别两种近似误差。第一种来自用 APY 等方法替换精确协方差,属于模型或矩阵近似;第二种来自未完全解出所指定方程,属于数值求解误差。收紧迭代容差只能减少第二种,无法补回第一种。实践中可先在能精确计算的代表性子样本上确定矩阵近似的影响,再选取使数值误差明显小于近似误差的求解容差,避免把大量计算花在没有实际收益的最后几位小数上。

对于多性状和重复记录,动物数之外还有性状数、永久环境效应数和固定效应水平数。单性状程序能够处理大量动物,并不表示多性状方差估计也具有相同能力。计算报告应分别给出关系矩阵构造、方程求解、方差估计以及可靠度计算的时间与内存;把这些阶段合成一个总时长,会掩盖真正的瓶颈,也不利于其他研究者判断能否部署。

2025 年的一项 Nellore 牛研究 (Ogunbawo 等, 2025) 将 APY 用于大规模全基因组关联分析,说明其应用正从常规预测向效应回算等任务扩展。预测用近似在关联分析中还需要额外评价效应分配和检验性质;不能仅凭育种值相关很高,就认定全部关联结论不受近似影响。

一个可部署的评定系统还应固定动物与位点排序、记录软件和数据版本、保存方差参数及求解容差,并把异常退出与成功收敛明确区分。增量更新时要检验旧动物的变化是否可解释;否则,新一批基因型进入后出现的整体漂移可能被误认为遗传进展。

计算结果至少需要通过四类检查:矩阵对称与正定性;小型问题中等价算法的一致性;残差或方程误差达到预设阈值;独立数据中的预测与校准。前两项检查代数实现,第三项检查求解程度,第四项检查模型用途。它们不能相互替代。

生产系统中还应区分年度遗传基准调整与模型变化。为了展示方便,可以把某个出生年度的平均育种值设为零;这种报告尺度平移与重新估计遗传

协方差并非同一操作。比较两次评定时,先统一报告基准,再分解新增记录、参数更新和算法变化的贡献。否则,一次纯粹的零点调整也可能被误读为整个群体育种值突然下降。

评定更新时还可保留一组覆盖主要家系和遗传水平的固定监测动物,以共同尺度比较历次预测。监测动物不是人为固定不变的标准答案,而是帮助识别变化来源的观察窗口。应同时允许新信息带来合理修正,并对无数据依据的整体漂移进行追查。监测组若长期只包含高精度老动物,也应补充青年和新来源候选,以免遗漏系统在新群体中的问题。

28.16 单步关系更新的相对误差怎样跨动物传播

单步模型把已分型动物的边际遗传协方差,经由系谱条件关系传递给未分型动物。已有推导说明这一传播为何一致;进一步的问题是,如果已分型关系存在测量或近似误差,哪些未分型比较会受到影响,影响是否一定随动物数量放大?回答需要区分绝对误差与相对于原遗传变异的误差。

沿用条件表示 $u_1 = Bu_2 + \zeta$, 暂令加性方差单位为一,并记 $S_1 = \text{Var}(\zeta)$ 。定义

$$L_G = \begin{bmatrix} B \\ I \end{bmatrix}, \quad H_{rel} = L_G G L_G^T + \begin{bmatrix} S_1 & 0 \\ 0 & 0 \end{bmatrix}.$$

这一表示将基因组支持的部分与剩余系谱条件变异明确分开。若 G 变为 $G + \Delta G$, 而系谱条件模型保持不变,则关系更新的误差精确等于

$$\Delta H_{rel} = L_G \Delta G L_G^T.$$

从分块看,

$$\Delta H_{11} = B \Delta G B^T,$$

$$\Delta H_{12} = B \Delta G,$$

$$\Delta H_{22} = \Delta G.$$

未分型动物之间的误差由条件回归两次传递,交叉组关系则只传递一

次。普通谱范数给出 $\|\Delta H\|_2 \leq \|L_G\|_2^2 \|\Delta G\|_2$, 但这个界受到变量尺度影响, 可能显得很大。它不能单独回答生物学上重要的相对误差。

假定原 G 正定, 且测量误差满足

$$-\varepsilon G \leq \Delta G \leq \varepsilon G, \quad 0 \leq \varepsilon < 1.$$

这个条件等价于白化误差 $G^{-1/2} \Delta G G^{-1/2}$ 的谱范数不超过 ε 。合同变换保持半正定次序, 而剩余条件方差半正定, 故

$$-\varepsilon H_{rel} \leq \Delta H_{rel} \leq \varepsilon H_{rel}.$$

因此, 在固定正确条件模型的前提下, 单步传播不会把这种相对协方差误差界放大。绝对元素变化可以较大, 却仍可能只是原来大方差方向上相同比例的变化。这个结论不适用于同时改变系谱、条件回归或遗传方差的情形; 如果误差也进入 B 与 S_1 , 必须增加相应项。

对具体候选对比, 把 $c = (c_1^T, c_2^T)^T$ 分组, 得到更有解释力的表达式:

$$c^T \Delta H_{rel} c = (B^T c_1 + c_2)^T \Delta G (B^T c_1 + c_2).$$

真正进入基因组误差的, 是整个候选对比在已分型空间中的投影。如果这一投影为零, 该对比完全由保留的系谱条件残差决定, 对当前基因组扰动不敏感。它不意味着对比没有遗传方差, 而是其方差来自另一随机部分。

取一只未分型动物与两只分型动物, 条件回归为 $B = (-1/3, 2/3)$ 。让已分型关系误差只沿 $v = (1, -1)^T$ 方向出现, 取 $\Delta G = 0.04vv^T$ 。由于 $Bv = -1$,

$$\Delta H_{rel} = 0.04aa^T, \quad a = (-1, 1, -1)^T.$$

第一与第三只动物的差值对应 $c = (1, 0, -1)^T$, 有 $c^T a = 0$, 故误差为零。第一与第二只动物的差值对应 $(1, -1, 0)^T$, 二次型误差为 $0.04 \times (-2)^2 = 0.16$ 。三只动物处在同一个系统中, 却不是所有比较都同样受影响。

还可以把相对协方差界转换为精度界。若 $(1 - \varepsilon)H \leq \tilde{H} \leq (1 + \varepsilon)H$ 且均正定, 则逆矩阵的次序反向:

$$\frac{1}{1 + \varepsilon} H^{-1} \leq \tilde{H}^{-1} \leq \frac{1}{1 - \varepsilon} H^{-1}.$$

这说明小相对误差通常产生可控精度误差，但当误差界接近一时，上界迅速变宽。对接近奇异的关系方向，仅控制原始单元格的绝对误差可能远远不够，因为白化会强调那些原先方差很小的方向。实际诊断应结合基群尺度、候选对比和矩阵支持空间，而不是只报告关系元素平均差。

这一推导也有助于定位数据责任。若固定系谱条件模型后扰动尚可控制，而修正父母身份后预测变化很大，后者属于信息连接变化，不应归因于基因组求逆精度。反之，若同一条件模型下某个罕见家系方向高度敏感，应优先调查其分型质量与参考覆盖。把不同误差来源写到不同矩阵位置，可以让诊断从笼统的“评定不稳定”变为具体可检查的问题。

相对界还有一个实用含义：如果两种关系在白化空间中差异可控，且表型信息仍增加非负精度，某些稳定性结果可以继续向混合模型方程传递。但是当固定效应与遗传方向高度混淆时，不能仅用随机效应先验的界判断整个方程的条件数。场群连接不足可能成为更主要的薄弱环节。关系检查 and 设计检查应分别进行，再研究它们在完整系统中的共同作用。

如果只希望知道一个未分型群体平均的误差，不必计算整张关系差矩阵。可以先将该群体权重经条件回归投影到分型空间，再计算一个二次型。这个做法是精确代数化简，不是进一步统计近似；它使针对实际目标的误差分析能够在大系统中实施。必须保存正确的动物排序与群体权重，否则形式正确的乘积也会对应错误目标。

28.17 APY 近似的条件相关与信息损失

Misztal、Legarra 与 Aguilar (2014) 提出的递归计算路线，为大规模基因组关系处理提供了重要基础。APY 的关键条件近似可以写为：给定核心动物后，把非核心动物残差的协方差 S 替换为其对角矩阵 D 。仅检查被忽略协方差的绝对大小还不充分，因为相同的协方差在不同条件方差尺度下代表不同强度的依赖。

为使用下述非退化高斯密度和有限相对熵公式，假定条件协方差 S 正定，因而所有条件方差均为正。仅各对角元为正不足以保证这一条件；若 S

奇异而近似条件分布仍非退化, 精确分布集中于低维子空间, 不能直接沿用有限对数行列式公式。定义条件相关矩阵

$$C = D^{-1/2}SD^{-1/2}, \quad D = \text{diag}(S).$$

矩阵 C 的对角线都是一。APY 在这个白化空间中用单位阵替代 C , 因此真正被忽略的是标准化后的非对角依赖。条件方差很小并不必然使近似良好; 若相关仍强, 残余方向之间可能仍有重要结构。

在核心边际分布与条件均值完全相同的高斯模型下, 可以用相对熵描述精确条件分布与 APY 条件分布的差异。按精确分布对数密度比的期望, 得到

$$\begin{aligned} \mathcal{D}_{KL} &= \frac{1}{2} \{ \text{tr}(D^{-1}S) - m + \log |D| - \log |S| \} \\ &= -\frac{1}{2} \log |C|. \end{aligned}$$

这里 m 是非核心动物数, 第二步使用对角匹配产生的迹等式。该量非负, 且只有条件相关矩阵为单位阵时为零。它是整个条件高斯分布的信息距离, 不是某一性状的均方预测误差, 也没有一个可直接通用于所有育种项目的合格阈值。

取两个标准化条件残差, 相关为 0.6:

$$C = \begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix}, \quad |C| = 0.64.$$

相对熵为

$$\mathcal{D}_{KL} = -\frac{1}{2} \log(0.64) = 0.223144.$$

在单位长度的共同方向与差值方向上, 精确条件方差分别为 1.6 与 0.4, APY 均取一。因此它压低了共同方向的条件方差, 却抬高了差值方向的条件方差。忽略协方差并不是简单地“少用了资料, 所以所有误差都更保守”; 不同线性组合上的不确定性变化可以方向相反。

精度方向更能显示这一点：

$$C^{-1} = \frac{1}{0.64} \begin{bmatrix} 1 & -0.6 \\ -0.6 & 1 \end{bmatrix}.$$

精确精度特征值为 0.625 与 2.5, 近似精度均为一。若表型主要支持共同方向, 近似可能收缩过强; 若主要支持差值方向, 近似则可能收缩过弱。具体预测还要结合表型精度, 不能只从条件相关的符号直接判断某只动物育种值会上升还是下降。

当 $C = I + F$ 、 $\|F\|_2 \leq \delta < 1$, 且 $\text{tr}(F) = 0$ 时, 可以对对数行列式展开。若 μ_j 为 F 的特征值, 则

$$\mathcal{D}_{KL} = \frac{1}{2} \sum_j \{\mu_j - \log(1 + \mu_j)\}.$$

一阶项因迹为零而抵消, 主导项为平方量:

$$\mathcal{D}_{KL} \approx \frac{1}{4} \|F\|_F^2.$$

利用标量函数二阶导数的界, 还可给出

$$\frac{\|F\|_F^2}{4(1 + \delta)^2} \leq \mathcal{D}_{KL} \leq \frac{\|F\|_F^2}{4(1 - \delta)^2}.$$

这说明许多较小条件相关也可能累积成不可忽略的整体差异。只检查最大一对相关, 可能遗漏广泛弱依赖; 只检查平均相关, 又可能让正负抵消。谱范数、平方和与有实际意义的对比各自反映不同方面, 应根据计算资源选用互补诊断。

如果条件相关矩阵接近奇异, 相对熵可能很大, 局部展开也不再可靠。这意味着精确模型几乎排除了某个方向, 而对角近似重新赋予它明显方差。此时应扩大或改进核心覆盖, 或者明确接受一个不同的协方差模型, 而不能用更多迭代试图消除结构误差。迭代充分只会更准确地求出近似模型。

对于非常大的非核心组, 直接形成完整条件相关矩阵可能违背采用 APY 的初衷。可以在有代表性的群体分层、时间批次和候选子集中进行条件结构

检查, 或使用矩阵乘积估计某些谱摘要。抽查结论应注明覆盖范围: 一个主流品种子集中的良好近似, 不足以保证少数来源群体也被核心充分覆盖。统计诊断的样本设计与计算近似本身同样重要。

相对熵具有方向性, 交换精确模型与近似模型后一般得到不同数值。上述表达按精确模型对近似模型的对数损失取期望, 所以不能把它当作对称距离使用。若研究目标是预测表现, 还应同时观察具体线性组合的误差与尺度; 信息距离很小并不排除某个少数群体存在较集中差异。对总体平均的良好近似与对全部个体的最坏情况保证, 应在报告中明确区分。

28.18 核心选择的目标加权准则

选择核心动物常按随机、分层或谱覆盖组织。更深入的理解是: 新增一个核心动物, 究竟消除了哪些条件残差方向? 把这一减少写成矩阵形式, 可以区分总体方差覆盖和具体候选目标, 两者的最优选择未必相同。

给定当前核心, 设非核心条件协方差为 S 。将其中第 k 只动物加入核心, 且 $S_{kk} > 0$, 则剩余条件协方差由条件高斯公式更新。若仍在原维度表示, 把已条件化动物的残差设为零, 可写为

$$S^{(k)} = S - \frac{S_{:k}S_{k:}}{S_{kk}}.$$

这里 $S_{:k}$ 为第 k 列。对总体残差迹, 减少量为

$$\Delta_{tr}(k) = \frac{\|S_{:k}\|^2}{S_{kk}}.$$

最大条件方差只看 S_{kk} , 最大迹减少还考虑该动物与其他未解释方向的协方差。一个动物自身方差很大却与其他动物几乎独立, 作为核心主要解释自己; 另一个方差稍小但代表一整片未覆盖家系, 可能减少更多总残差。

若真正关心某个目标对比 $t = c^T u_n$, 其条件方差减少为

$$\Delta_c(k) = \frac{(c^T S_{:k})^2}{S_{kk}}.$$

对多个目标 c_l ，以预定非负权重 ω_l 汇总，令 $M = \sum_l \omega_l c_l c_l^T$ ，得到

$$\Delta_M(k) = \frac{S_{k:}MS_{:k}}{S_{kk}}.$$

这给出了一个透明的目标加权准则。权重可以反映候选数量、实际经济比较或对少数保种群体的关注，但它属于育种计划的明确选择，不能隐藏在所谓自动算法中。若研究声称评价一般总体近似，权重也应对应其总体，而不能事后只强调表现最好的候选。

考虑三个条件残差：

$$S = \begin{bmatrix} 1 & 0.8 & 0 \\ 0.8 & 1 & 0 \\ 0 & 0 & 0.9 \end{bmatrix}.$$

选择第一或第二只动物，迹减少为 $1 + 0.8^2 = 1.64$ ；选择第三只为 0.9。以总方差覆盖为目标，前两只更有利。但若目标是第三只动物或其代表的独立家系，取 $c = (0, 0, 1)^T$ ，前两只带来的目标收益为零，第三只带来的收益为 0.9。总体准则与重点群体准则并无代数冲突，它们优化的是不同损失。

将第一只纳入核心后，第二只剩余条件方差降为

$$1 - \frac{0.8^2}{1} = 0.36,$$

第三只仍为 0.9。若允许再加一只，条件方差准则就会转向第三只。每一步必须使用更新后的条件结构，不能将初始排序一次计算后永久使用；新增核心之间可能高度冗余。

这里的“已知核心遗传值”是条件分布的数学表示，不表示核心动物实际拥有无误差的育种值。APY 利用核心协方差来组织随机模型，核心遗传值仍由完整表型系统共同估计。若把这一核心设计公式用于真实新增测定，还必须在分母加入测量误差，并考虑测量后对遗传值的有限认识。混淆模型条件化与实验直接观测，会夸大单只新增测定的收益。

迹减少准则也不等于直接最小化 APY 误差。APY 保留对角条件方差, 主要忽略非对角结构; 某个核心使总残差大幅减少, 却未必最有效消除关键的剩余相关。可以把目标方差准则作为覆盖工具, 再用条件相关、预测差异及可靠度进行验证。一个单一准则不必同时优化所有方面, 清楚说明其作用比宣称普遍最优更可靠。

批量核心选择还涉及组合优化。逐步最大化边际收益是容易实施的策略, 但没有额外结构时不能据此宣称找到全局最优集合。代表性约束、旧核心保留、跨期稳定性和计算成本都可能限制可选组合。可以比较少量有明确目的的方案, 并报告重点目标的最大差异; 不断试验很多核心直到验证分数最好, 会使核心选择本身成为需要独立评价的训练步骤。

核心随评定期更新时, 还需平衡近期最优与跨期可比较性。频繁更换核心会改变近似残差结构, 使动物预测变化同时包含新增信息与近似方案变化。可以保留一个稳定的基础核心, 再为新来源增补代表动物, 并定期与重新设计的核心比较。这是一种可检验的维护策略, 不是固定比例的普遍准则。只要改变了近似定义, 就应保留能够分离其影响的参照分析。

28.19 对候选比较有意义的求解残差

求解器通常以整个方程的相对残差停止, 而育种决策往往只需要若干特定差值或经济指数。全局残差小并不保证所有目标误差小, 但反过来, 也不必为了少数不相关方向把整个系统求到极高精度。对称正定系统的对偶关系可以把残差直接转换为目标误差。

设经过约束消除不可识别方向后的方程为 $L\theta = d$, 近似解为 θ_k , 残差为 $r_k = d - L\theta_k$ 。对固定线性目标 $t = c^T\theta$, 定义对偶解

$$Lz = c.$$

由对称性, 精确目标误差为

$$t - c^T\theta_k = c^TL^{-1}r_k = z^Tr_k.$$

因此, 与其只检查残差长度, 还可以检查残差在目标敏感方向上的投影。

若一个目标比较连接薄弱, 对偶解可能很大, 使很小残差仍产生明显目标误差。对偶方程不改变统计模型, 只帮助度量计算尚未完成的部分。

利用 L 所定义的能量内积, 得到

$$|t - c^T \theta_k| \leq \sqrt{c^T L^{-1} c} \sqrt{r_k^T L^{-1} r_k}.$$

第一项描述目标本身对系统的敏感性, 第二项描述当前求解剩余误差。若已知预条件矩阵 M 满足 $aM \leq L$, 其中 $a > 0$, 可以使用较易计算的界:

$$|t - c^T \theta_k| \leq \frac{1}{a} \sqrt{c^T M^{-1} c} \sqrt{r_k^T M^{-1} r_k}.$$

这里 a 需要可辩护的谱下界; 不能把经验观察到的平均收敛速度直接当作严格下界。没有可靠界时, 对偶实算仍可提供有用诊断, 但报告应区分严格保证与经验容差。

考虑

$$L = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}, \quad d = (1, 2)^T.$$

精确解为 $(1/11, 7/11)^T$ 。假设当前近似解为 $(0.09, 0.63)^T$, 则残差为 $(0.01, 0.02)^T$ 。对差值目标 $c = (1, -1)^T$, 对偶解为

$$z = (4/11, -5/11)^T.$$

由此直接得到

$$z^T r_k = -0.00545455.$$

近似差值为 -0.54 , 精确差值为 $-6/11 = -0.54545455$, 两者恰相差上述数值。若选择阈值要求差值精确到百分之一, 这次计算可能已经够用; 若目标是辨别千分之一单位的差异, 则还需要继续求解。容差应和实际单位联系, 不能仅用一个不带量纲说明的数字。

对偶系统也可以近似求解。令 $\tilde{z}$ 的残差为 $s = c - L\tilde{z}$, 则

$$t - c^T \theta_k = \tilde{z}^T r_k + s^T L^{-1} r_k.$$

第二项可用能量范数或预条件界控制。以上例取 $\tilde{z} = (0.36, -0.45)^T$, 则 $s = (0.01, -0.01)^T$, 首项为 -0.0054 , 遗漏修正约为 -0.00005455 。适度精确的对偶解已能很好描述目标误差, 不必把每个辅助系统都求至机器极限。

这种方法尤其适合少量重要候选比较、群体平均或固定经济权重的指数。若目标数量与动物数量同阶, 逐一求对偶系统可能成本太高, 可以选择代表性目标、成批求解或采用明确的近似。但是目标如果根据当前迭代输出不断变化, 例如每次只检查暂列前十名, 可能遗漏尚未收敛而错误排在后面的动物。应同时保留全局停止条件与预先定义的目标检查。

最后, 方程必须在可识别空间上正定。含未约束固定效应的奇异系统, 需要先指定可估计目标与约束; 对于不定增广系统, 直接使用正定能量界不成立。实际数值方法的适用条件应来自所求系统, 而不是来自软件名称。统计约束、预条件与目标单位都核对清楚后, 残差才真正成为可解释的决策精度。

在多性状系统中, 目标向量还包括性状经济权重, 因此对偶敏感度随权重变化。把所有性状都按相同的原始数值容差检查, 可能对单位很大的性状过严、对经济影响很大的小单位性状过松。先统一量纲, 再以经济或遗传标准差单位设置目标容差, 能够使不同方程规模下的停止规则更可解释。若经济权重本身尚未确定, 可以选取若干有代表性的目标方向, 避免让数值标准过度依赖某一个临时指数。

残差应使用当前完整方程重新计算。迭代递推保存的残差在有限精度下可能与真实残差逐渐分离, 特别是在大量迭代或混合精度乘积之后。定期重算有助于发现这种偏离, 但其成本也应记录。重算不会修复错误矩阵或动物索引; 它只确认输出是否满足当前所指定的方程, 因此仍需要独立的小型等价检验。

28.20 分离模型近似与数值近似的误差预算

APY、低秩关系或近似基群参数改变了所求系统; 迭代提前停止则留下求解误差。二者可能在某次结果中恰好抵消, 使与参考解的差异很小。若只

报告最终差值,可能误把这种偶然抵消当作近似可靠。先建立原系统传播的恒等式,再以近似系统的精确解为界,才能区分两种分解的含义。

设目标系统为 $L\theta = d$, 实际近似系统为 $\tilde{L} = L + E$, 输出为 $\tilde{\theta}$, 在近似系统中的剩余残差为

$$\tilde{r} = d - \tilde{L}\tilde{\theta}.$$

把它代回原系统, 有

$$d - L\tilde{\theta} = \tilde{r} + E\tilde{\theta}.$$

因此总体误差精确分解为

$$\theta - \tilde{\theta} = L^{-1}\tilde{r} + L^{-1}E\tilde{\theta}.$$

对目标对偶解 $Lz = c$,

$$c^T(\theta - \tilde{\theta}) = z^T\tilde{r} + z^TE\tilde{\theta}.$$

这里第一项是经原系统逆矩阵传播的残差项, 第二项是经原系统传播的矩阵扰动项; 二者都使用当前输出, 因而会随迭代停止点耦合变化。第一项不能直接称为近似系统自身的纯数值误差, 后者必须由近似系统的逆矩阵传播残差。假定两系统均可逆, 定义近似系统的精确解 $\tilde{\theta}^* = \tilde{L}^{-1}d$, 便有另一种精确分解:

$$\begin{aligned}\theta - \tilde{\theta} &= (\theta - \tilde{\theta}^*) + (\tilde{\theta}^* - \tilde{\theta}) \\ &= L^{-1}E\tilde{\theta}^* + \tilde{L}^{-1}\tilde{r}.\end{aligned}$$

现在第一项才是在近似系统充分求解后仍留下的模型或矩阵近似误差, 第二项才是当前迭代相对于该精确解的数值误差。缩紧迭代容差可以使第二项趋于零, 却不能消除第一项。两项符号相反时, 继续求解甚至可能暂时增大与原解的差异, 但这不意味着求解器变坏, 而是原先抵消正在消失。第一种传播分解适合用同一个原系统对偶解诊断, 第二种分解适合解释误差来源, 不能混用二者的分项名称。

以单维系统说明：原系统系数为二、右端为一，精确解为二分之一。近似系数为二点二，若提前输出二分之一，表面上与原解完全一致，但其近似系统残差为负零点一。在第一种传播分解中，残差项为负零点零五，矩阵扰动项为正零点零五，恰好抵消。在第二种来源分解中，近似系统精确解为 $1/2.2 = 0.454545$ ，模型近似误差为正 0.045455 ，当前纯数值误差为负 0.045455 ，也恰好抵消。充分求解使纯数值误差消失，才暴露近似模型自身的影响；两种分解的总和相同，分项数值却不同。

点预测误差之外，可靠度还需要另一项检查。近似模型给出的后验方差，不一定等于该预测器在真实协方差下的均方误差。设真实模型为 $y = Zu + e$ ，遗传协方差为 K 、残差协方差为 R ，某个线性预测器为 My 。其真实误差协方差为

$$\begin{aligned} \text{MSE}(My) = & K - MZK - KZ^T M^T \\ & + M(ZKZ^T + R)M^T. \end{aligned}$$

这个公式可以检验任意线性近似预测器，而不假定它恰好是正确模型的 BLUP。若用近似协方差计算 M ，却仍把同一近似模型内部后验方差称为真实误差，就遗漏了协方差错设的影响。

在标量例中，真实遗传与残差方差均为一，正确预测系数为二分之一，真实均方误差为二分之一。若误设遗传方差为二分之一，预测系数变为三分之一；其模型内后验方差为三分之一，但真实均方误差为

$$(1 - 1/3)^2 + (1/3)^2 = \frac{5}{9}.$$

近似报告比真实误差小，而点预测仍可能与正确预测具有完全相关。相关系数不能发现这种尺度与不确定性差异。这里的例子只研究已知均值和固定方差；估计固定效应、参数与选择机制会增加进一步条件，不能因标量结果清楚就忽略它们。

令正确线性最优预测器为 $M_0 = KZ^T V^{-1}$ ，其中 $V = ZKZ^T + R$ 。利用最优预测误差与观测正交，可将任意线性预测器的误差写为

$$\text{MSE}(My) = \text{MSE}(M_0 y) + (M - M_0) V (M - M_0)^T.$$

第二项半正定，说明正确协方差下的线性最优性。它也给出一个较强的比较原则：要评价近似是否足够，关心的是预测算子的差在观测分布下有多大，而不仅是某一份表型向量恰好产生多小的差。代表性的多性状、时间与群体资料能够帮助覆盖不同观测方向。

误差预算最终应落在实际目标单位上。可以先设定候选差值允许的计算误差，再分配给关系近似和求解残差，并给参数估计与真实预测误差留出明确的不同解释。后两者往往远大于数值误差，但这不意味着可以忽略前两者；尤其在选择阈值附近，很小的系统变化也可能影响资源分配。清楚分层的误差预算，使大规模计算的效率改进能够被评价，而不只是被相信。

28.21 本章练习与参考答案

练习 28.1 如果 $G = A_{22}$ ，单步逆矩阵公式退化为什么？这一性质可用来检查哪些程序错误？

答案：退化为 $H_{rel}^{-1} = A^{-1}$ 。可发现已分型动物顺序不一致、子矩阵抽取错误、频率或尺度转换没有同步，以及把 A_{22}^{-1} 误当作 $(A^{-1})_{22}$ 等问题。

练习 28.2 在第 28.8 节例子中，被忽略的条件协方差是多少？为什么增加一个核心动物后能够恢复精确？

答案：为 0.06。增加后非核心组只有一只动物，其条件协方差矩阵只有一个对角元，没有可被忽略的非对角项，因而对角近似等于精确矩阵。

练习 28.3 两套单步程序的育种值相关为 0.9999，是否足以认定两者完全等价？

答案：不足以。相关不受整体加常数和正比例缩放影响，应比较均值差、回归斜率、最大绝对差、重要候选动物排序及方程误差。近似是否可接受还取决于实际选择阈值。

练习 28.4 两只动物的系谱关系为 $A = \begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix}$ ，第二只已经分型，其

相容基因组边际方差为 1.2。求 B 、条件方差和正确的单步关系矩阵，并与只替换右下角的做法比较。

答案： $B = 0.6$, $S_1 = 1 - 0.6^2 = 0.64$ 。正确矩阵的未分型方差为 $0.64 + 0.6^2 \times 1.2 = 1.072$ ，交叉协方差为 0.72，已分型方差为 1.2。只替换右下角会保留原交叉关系 0.6 与原方差一，因此不是同一个条件模型。两者在此都可能正定，但合法性并不等于符合预定统计定义。应通过条件分布与边际方差共同核验，而非只检查能否求逆。

练习 28.5 核心组条件下，两只非核心动物的残差协方差为 $S = \begin{bmatrix} 0.5 & 0.2 \\ 0.2 & 0.8 \end{bmatrix}$ 。APY 忽略什么？把第一只非核心动物加入核心后，另一只的条件方差是多少？

答案：对角近似忽略非对角协方差 0.2，保留边际条件方差 0.5 与 0.8。加入后，剩余动物的条件方差为 $0.8 - 0.2^2/0.5 = 0.72$ 。这一减少来自新增核心对原残差方向的解释。因为此例只剩一只非核心动物，其残差块已天然对角，近似恢复精确。若仍有很多非核心动物，新增一只核心并不能保证其余所有条件协方差都变成零。

练习 28.6 三个基础群体关系矩阵的对角线均为一，非对角元分别为 0.9, 0.9, -0.9。每个元素都在负一到一之间，能否作为合法协方差？应怎样处理估计中出现这种结果的问题？

答案：不能，该矩阵特征值为 1.9, 1.9, -0.8，存在负方差方向。逐个元素落在合理区间只是必要条件的一部分，整体半正定性仍不可缺少。应检查频率方向、群体定义、估计误差及是否分别独立估计了各对关系。可以采用保持半正定的联合参数化或有明确依据的正则化，并报告其影响；不能默默裁剪负特征值后仍宣称使用了原估计矩阵。

练习 28.7 某系统两只候选先验方差均为二、先验协方差为一，预测误差方差均为 0.8、误差协方差为 0.5。求各自可靠度、差值可靠度与平均值可靠度。

答案：个体可靠度为 $1 - 0.8/2 = 0.6$ 。差值先验方差为二，误差方差为 $1.6 - 1 = 0.6$ ，可靠度为 0.7。平均值先验方差为 $(2 + 2 + 2)/4 = 1.5$ ，误差方差为 $(0.8 + 0.8 + 1)/4 = 0.65$ ，可靠度约为 0.5667。不能以两个相同个体

可靠度的平均来替代后两者，因为线性组合的精度依赖协方差。这里所有值均条件于所给模型与参数，未包含参数估计误差。

练习 28.8 一家育种机构计划把每月完整单步评定改为每周增量评定，并使用固定核心 APY 和较宽迭代容差。设计一项能够分离三类误差来源的验证。

答案：在同一冻结资料上先建立严格容差的完整关系参考，再只改变 APY 核心以估计矩阵近似影响；固定 APY 后改变迭代容差，估计数值求解误差；固定模型与容差后按实际时间分批更新，并与同一终点一次性重算比较，估计增量流程误差。三类比较均检查均值、尺度、重点候选差异与运行成本，并按品种、家系和新加入动物分层。最后在未来资料中检验预测与校准。若同时改变三项而只报告最终相关，将无法知道性能变化来自哪一环，也难以决定应增加核心、收紧容差还是修复更新流程。

验证设计、准确性、校准与跨群体迁移

模型总能给每只候选动物一个数字。验证要回答的是：在真正做决定的那个时间点，利用当时能够取得的信息，这个数字有多可靠？因此，验证首先是一种信息时间表，其次才是一组统计量。把未来后代资料、全数据校正或近乎重复的亲属记录放入训练流程，即使无意，也会改变所回答的问题。

29.1 先定义预测对象，再划分数据

至少需要区分三种目标：未来个体表型、同一动物的潜在育种值、与某种配偶或环境组合有关的后代表现。表型包含环境噪声，育种值通常不可直接观察，杂交表现还可能包含显性和特定组合效应。不同目标对应不同验证资料与损失函数。

随机个体划分衡量的是在现有家系和环境构成中补预测一部分动物的能力；按父系家族隔离更接近新家系预测；按时间前推更接近选种时的实际信息；整场、整地区或整品种留出则检验更远距离的外推。没有一种划分天然“最严格”，关键在于是否对应预期用途。过度隔离到与部署完全不同的群体，也可能得到没有决策意义的悲观评价。

以肉羊选种为例，若每年秋季根据幼龄候选羊基因型和此前资料选留公羊，验证应在历史秋季设置信息截点，保留当时实际可获得的系谱与基因型，截去未来增重记录、成年繁殖资料及后代表型。次年取得的基因型若在原决策日尚不可得，也要明确是否允许使用。验证表不仅应写“训练年限”，还应写各类信息何时可用。

质量控制、特征筛选、表型校正和超参数调节都是模型的一部分。凡依

赖表型的信息处理，必须在训练数据中完成。利用全数据选出显著位点，再做交叉验证，测试表型已经影响了输入特征，所得分数会偏乐观。若预先在独立外部研究中固定特征，则属于另一种可明确说明的设计。

29.2 验证目标、损失函数与目标群体的定义

29.2.1 先把要估计的性能写成一个总体量

设训练流程生成预测函数 f ，未来目标动物来自分布 $\mathcal{D}_{tar}$ ，预测损失为 ℓ 。希望估计的量可以写为 $E_{tar}\{\ell(Y, f(x_{in}))\}$ ，其中 x_{in} 表示决策时可用输入。这个总体期望包含三个需要明说的选择：未来动物如何产生、决策时有哪些输入、怎样衡量错误。若三者没有定义，所谓模型准确性就只是某一现有数据表上的统计摘要。

还要决定是否对训练资料随机性平均。固定已经部署的模型，评估它对未来动物的性能，是条件于当前训练集的问题；评估一个训练算法在反复采样资料时的平均性能，则还要对训练集变化取期望。前者适合决定现有模型能否使用，后者适合比较研究方法的稳定性。一次固定训练后的测试置信区间，通常不能自动代表重新训练整个算法的全部不确定性。报告中说明这一层次，有助于解释不同重抽样设计为何给出不同宽度的区间。

29.2.2 目标总体决定样本应如何加权

如果未来候选中小场动物占多数，而测试集中大场动物占多数，未经加权的平均损失主要反映大场表现。可以按预先确定的部署构成进行分层加权，估计目标总体损失；但权重必须来自真实或合理预期的群体比例，而不能根据测试表现选择。对于育种业务，候选动物、实际留种动物和下一代贡献动物是三个不同总体。一个模型在所有出生动物上表现良好，未必在高度选择的候选尾部具有相同精度。

教学例子中，模型在大场和小场的均方误差分别为一与四。测试样本有百分之八十大场动物，未经加权损失为 $0.8 \times 1 + 0.2 \times 4 = 1.6$ ；若部署群体比例恰好相反，目标损失为 3.4。两个数字都可以正确计算，却回答不同的

问题。不能把差异称为模型忽然退化，因为预测函数并未变化，变化的是被平均的对象。分层结果和目标权重使这一点透明，也有助于判断应把新增测定资源投向哪里。

29.2.3 排序、尺度与决策效用各有适用指标

相关系数描述线性关联，均方误差同时受均值、尺度和随机误差影响，平均绝对误差对大偏差的惩罚较缓，校准截距与斜率分别指出某些系统偏移。若只关心某一阈值以上的动物，还可研究阈值附近的误选与漏选；若关心多性状经济目标，则应使用共同尺度的经济损失或目标遗传值。不同指标不是彼此竞争的唯一答案，而是从不同方面描述预测。主要指标应在分析前根据用途选择，其余指标用于诊断。

极端选择指标尤其需要足够样本。若验证集只有二十只动物，前百分之五实际上只有一只，其是否命中受到很大随机波动影响。多次改变阈值直到某模型表现最好，会产生新的选择偏差。可以预先设定与业务一致的选择比例，并结合较平滑的整体损失和排序不确定性解释。即使头部名单发生变化，也应检查这些动物的预测差是否大于其误差，而不是把每次名次交换都视为实质性改进或失败。

29.2.4 验证报告中的基准必须具有现实意义

一个合理基准可以是亲本平均、传统系谱 BLUP 或当前正式使用的基因组模型，具体取决于新方法将替代什么。与完全不使用已有资料的均值预测比较，通常只能证明数据含有信息，不能说明新算法值得部署。各基准还应拥有相同的可用资料和适当调参。若某方法使用额外组学或未来表型，应该把比较解释为信息体系的差异，而非纯算法优势。

在保种和小群体中，部署目标还可能包括维持家系覆盖和限制近交。此时最高短期预测相关并非唯一目标，但也不能因此忽略预测误差。可以先报告遗传预测性能，再在给定贡献约束下比较预期收益与多样性后果。把统计估计与政策约束分别呈现，使不同育种计划能够根据自身目标使用同一证据，而无需把某一价值选择隐藏在模型评分中。

29.3 随机、家系、时间与环境划分的实验含义

29.3.1 划分规则是对未来部署的模拟

随机个体划分使训练和验证通常共享品种、场群、年份和近亲结构，适合评估在现有体系内补预测新个体的能力。按父系家族隔离减少近亲信息共享，更接近某些新家系进入场景，但母系和更远亲缘仍可能跨组。按时间截断则模拟未来候选，却可能同时改变遗传水平、测定制度和可用信息量。整场或整地区留出测试环境外推，同时也可能改变遗传来源。研究者必须解释划分带来的多重变化，不能把性能下降全部归因于某一个因素。

这些设计不是一条从宽松到严格的单一等级。若实际每年新候选都有大量已测近亲，完全隔离所有亲缘会低估业务性能；若要推广到没有任何训练近亲的地方品种，随机划分又会过于乐观。可以设定几个明确场景，分别估计同家系内、跨家系、跨时间和跨环境表现。场景之间的差异本身有研究价值，能够显示模型依赖哪些信息，但不应将最高的一个数字单独用于描述全部用途。

29.3.2 算例：重复记录跨组会改变被测试的问题

设一只动物有十次记录，表型模型为 $y_{it} = u_i + p_i + e_{it}$ ，遗传方差为一，永久环境方差为一，暂时残差方差为二。如果把每条记录随机分组，同一动物很可能同时出现在训练和验证。模型或特征可以借助该动物训练记录估计 $u_i + p_i$ ，验证相关因而包含对永久环境的预测。若业务目标是出生时仅凭基因型预测新动物，这种验证就提供了不属于部署条件的信息。

即使模型没有显式动物编号，基因型几乎唯一地标识个体，灵活算法仍可能识别重复样本。正确划分应以动物为最小不可拆单位；若目标是新家系，还需进一步按家系分组；若同窝共享环境很强，也应评估窝或群组跨界的影响。记录数量可以很大，但独立预测单位仍可能很少。所谓一百万条验证记录，不应掩盖它们实际上来自几千只甚至更少动物。

29.3.3 时间验证必须分别冻结各类信息

表型、基因型、系谱和辅助注释不总在同一天可得。某只动物出生时有父母登记，三个月后取得基因型，一岁时取得生长记录，三岁后才有繁殖或后代表现。模拟三个月选种就应在三个月信息边界上构建输入。若后来的系谱更正来自基因型亲子鉴定，也应说明历史版本是否已经知道该更正。可以开展理想完整数据与真实历史流程两套分析，但不能把两者混为同一个验证。

对已分型候选，联合填充使用其自身基因型通常可以符合实际部署；使用它后来才测得的表型指导位点筛选则不符合。源于公开外部研究的功能注释也有时间版本：某项注释在历史评定日尚未公开，回顾性研究若使用它，应解释是在评估当前技术用于类似未来场景，而非重演当时的实际决策。信息边界的清晰定义比笼统宣布“没有使用测试数据”更准确。

29.3.4 划分不确定性与重复实验的组织

单次随机划分可能偶然使某些大父系家族集中于某一组，从而影响结果。重复划分可以显示这种变化，但多个重复共享大量动物和训练资料，不能当作完全独立研究来计算极小标准误。应报告每次划分规则、群体组成和配对模型差异，并根据真正独立的抽样层次构建区间。时间验证中的多个滚动窗口同样共享训练历史，窗口间误差也相关。

若研究资源允许，可以采用少量预先定义且有实际意义的外层场景，再在各场景训练部分调参。对于非常小的地方群体，整品种留出可能没有足够训练信息支持同一性状模型，这一失败也是有意义的结果，但需区分样本不足与不可迁移的遗传机制。可以通过加入少量本地记录的学习曲线，研究怎样的资料投入能够使模型达到可用水平，而不是只比较零本地资料时谁的分数稍高。

划分还应保存为固定的动物标识清单，便于所有方法共享。使用相同随机种子却在过滤后不同顺序的数据上重新划分，可能使测试动物不一致。比较模型前应核对实际验证集合，而不仅核对程序参数。公平的实验首先是一组共同的预测任务，然后才是不同算法对这些任务的答案。

29.4 泄漏的来源与完整训练流程的隔离

29.4.1 泄漏常发生在模型拟合之前

特征筛选、缺失填充、表型校正和异常值处理都可能使用响应信息。若先在全部动物上计算关联统计，再选最显著位点进行交叉验证，验证表型已经决定哪些输入被保留。即使后续回归严格只在训练动物上拟合，也无法恢复独立性。类似地，用全部数据估计场年效应后产生校正表型，会让验证动物影响训练响应。评估对象应是从原始数据到预测的完整流程，而不是只隔离最后一个拟合函数。

无监督处理则需要更细致判断。利用部署时可获得的候选基因型进行共同填充或频率估计，不必然属于不合法泄漏，但它定义了允许使用候选输入分布的预测情景。如果未来部署逐只到来且不会重估训练尺度，而验证却联合使用整个未来批次，则二者仍不一致。应该明确是固定模型的样本外预测，还是允许联合利用未标记候选输入的转导预测。关键不在某步骤是否被称为无监督，而在其信息是否真实可得。

29.4.2 算例：全数据中心化响应带来的依赖

考虑四个纯噪声表型，前两只训练、后两只验证。若以全体均值 $\bar{y}$ 校正每个表型，训练响应中包含 $-(y_3 + y_4)/4$ ，因此直接依赖验证表型。随后模型即使只使用前两行，也已间接看到验证噪声。这种依赖未必总使每一种指标向同一方向偏移，但它破坏了原本的独立测试解释。若固定总体均值本来已知，减去已知均值没有问题；若均值未知，应在训练中估计，并按部署方式用于验证。

复杂预校正更加隐蔽。一个全数据混合模型可能利用验证动物的后代记录、近亲记录和自身表型形成去回归值；再把这些值分组用于另一个模型，会出现多层共享信息。仅删除验证动物自己的原始表型可能不够，因为它的信息已进入亲属评定或环境校正。研究者需要追踪派生变量的来源，而不只检查最终训练表是否含验证动物编号。

29.4.3 超参数、校准和报告选择都可能泄漏

如果根据外层测试结果选择先验、核、核心规模或基群分组，外层测试就参与了模型开发。之后再给同一分数套用独立测试的置信区间，不能消除选择偏差。校准截距和斜率同样属于学习参数，应在独立校准集或训练内交叉预测上估计。报告时从多个性状、多个划分和多个指标中只挑最好结果，也会造成选择性呈现，即使每个单独计算没有代码错误。

可执行的改进是把资料角色事先确定为训练、调参与校准、最终评价，并允许这些角色通过嵌套设计轮换。对于数据稀少任务，不一定要永久浪费一大块资料，而可以采用外层交叉验证、内层调参和交叉拟合构造训练外预测。重要的是每一个最终评价动物的表型不能影响为它产生预测所用的任何监督选择。所有模型应遵守同一边界，以保证性能差异具有可解释性。

29.4.4 泄漏排查应从因果时间路径而非文件名出发

一个文件叫作“历史资料”并不保证其中没有未来修正，一个变量叫作“基因组特征”也可能由全数据关联筛选得到。可以为关键变量记录生成时间、依赖数据和更新规则，形成简洁的数据血缘说明。排查时间：如果把某只验证动物的未来表型替换为另一个值，它在评定日的输入或训练模型会不会改变？如果会，而该信息当时不可得，就存在需要解释的信息路径。这种反事实式检查能够发现很多仅靠目录分离无法发现的问题。

泄漏与合理亲缘信息也应区分。训练动物与验证动物有亲缘关系本来就是育种预测的重要信息来源，不应一概称为泄漏；只有当划分声称评估无近亲外推，却实际保留近亲，或者使用了不应可得的响应信息时，解释才失配。把所有亲缘信息都删除可能偏离实际任务。严谨验证需要精确描述允许的依赖，而不是追求一个模糊的“完全独立”口号。

最终报告可以用短表列出表型校正、位点筛选、频率估计、填充、参数选择和校准各自使用的数据范围。这个表比一句“采用五折交叉验证”提供更多判断依据。流程一旦清楚，读者便能区分结果是适用于同群体补预测、历史前瞻模拟，还是真正的外部迁移，研究也更容易被重复和改进。

29.5 准确性、预测能力与可靠度

真实育种值 u 可得时, 准确性定义为 $\text{Corr}(u, \hat{u})$, 可靠度为其平方。在真实数据中, u 通常不可观测, 因此常报告预测值与经合理调整表型 y^* 的相关, 即预测能力。

若 $y^* = u + e$, e 与 $\hat{u}$ 独立, 且遗传力 $h^2 = \text{Var}(u) / \text{Var}(y^*)$ 与验证目标群体相符, 则

$$\text{Corr}(y^*, \hat{u}) = \text{Corr}(u, \hat{u}) \sqrt{h^2}.$$

推导只需注意 $\text{Cov}(y^*, \hat{u}) = \text{Cov}(u, \hat{u})$, 再分别除以标准差。于是常见的“表型相关除以遗传力平方根”并不是无条件定义, 而是依赖误差独立、正确校正与匹配方差的推论。共享环境、重复记录、选择性留存、错误固定效应或不同验证群体遗传力, 都可能破坏这一换算。

可靠度也不能直接与模型输出的某个标准误混为一谈。给定正确模型与参数时, 个体预测误差方差可用于条件可靠度; 在实际评定中, 参数估计、错误系谱和环境外推造成的不确定性可能未包含其中。实践中应同时保留模型内可靠度与模型外验证结果。

预测相关必须附带样本构成与不确定性。1000 只动物若主要来自少数父系家族, 其有效信息量不能按 1000 个独立观测理解。按动物独立自助抽样可能破坏家系相关结构; 按家系或场年分组重采样更接近某些设计, 但组数太少时区间仍不稳定。区间方法要与抽样单位一致。

29.6 不可观测育种值、代理真值与误差分解

29.6.1 代理量越精确越好, 但独立性同样重要

真实育种值在生产资料中不可直接观察, 常用后裔均值、去回归评定或后期育种值作为代理。若代理可写为 $z = u + \delta$, 且 δ 与预测值独立, 则预测与代理的相关会因代理噪声而衰减。若 δ 同时与 u 独立且方差已知, 衰减因子可由代理可靠度描述。但是, 已有育种值通常已经收缩, 其误差与真值的关系不同于简单独立测量误差; 不能对所有代理统一套用同一个衰减修正。

更严重的问题是共享信息。若候选预测与代理评定使用大量相同亲属记录，它们的误差可能正相关，表面相关会高于真正独立证据所支持的程度。高可靠度代理可以减少其自身噪声，却不能自动消除共享误差。验证报告应说明代理所用记录与训练记录的重叠、亲本信息是否剥离、环境校正是否共享，以及代理是否在模型选择过程中被使用。

29.6.2 算例：共享误差怎样抬高验证相关

设真实育种值方差为一，两个估计分别为 $\hat{u} = u + \epsilon$ 和 $z = u + \delta$ ，两种误差方差均为一，且均与 u 独立。若误差彼此独立， $\text{Corr}(\hat{u}, z) = 1/2 = 0.5$ ，而预测与真值相关为 $1/\sqrt{2} \approx 0.7071$ 。若两种误差协方差为 0.5，估计间相关变为 $1.5/2 = 0.75$ ，但预测对真值的准确性仍为 0.7071。代理相关提高并非模型变好，而是两把尺子共享了部分错误。

这个例子中的估计采用无收缩加噪声形式，为便于展示协方差；它不是 BLUP 的完整随机误差结构。其结论是一般的：任何验证相关都由真实信号协方差和共享误差共同构成。后期评定和早期评定之间的高相关因此需要特定理论解释，不能直接读作早期预测接近真值。LR 方法正是利用嵌套信息关系构造不同的统计解释，但仍要求模型和信息条件适当。

29.6.3 对表型误差的校正应与验证群体匹配

如果验证使用多次记录均值，其环境方差不同于单次表型，遗传力也不同。设加性方差一，永久环境方差一，单次暂时残差方差二，则单次记录遗传力为 $1/4$ ；四次均值的方差为 $1 + 1 + 2/4 = 2.5$ ，相应遗传力为 0.4。若把与四次均值的相关仍除以 $\sqrt{0.25}$ ，会夸大准确性。应根据实际代理和残差结构计算相匹配的信噪比例，而不能引用一个文献中的单次遗传力作为通用常数。

选择也会改变验证集内方差。若只验证优秀候选，真实育种值范围可能缩窄，相关系数因范围限制而下降，即使绝对预测误差未增加。相反，混合差异很大的品种可能提高总体相关，因为品种均值差异占据大部分变异，但品种内排序仍可能较差。报告应明确相关是在全体、品种内还是经某种中心

化后计算，并结合均方误差和校准判断。仅比较不同研究的相关数值而忽略方差范围，容易形成错误的优劣排序。

29.6.4 不确定性无法由不合适的代理完全消除

当代理误差方差、共享协方差或选择机制未知时，真实准确性可能无法从现有资料唯一识别。此时可以报告可直接观察的预测能力，并进行合理范围的敏感性分析，而不是给出看似精确的真实准确性。模拟能够检验方法在已知机制下是否恢复真值，但模拟结论的范围取决于设定。真实资料能检验实际部署，却缺少真值。两类证据各有作用，不能把模拟中的完美识别条件默默带到生产数据解释中。

研究设计可以改善这一局面。例如为部分候选安排不依赖原预测值的后期测定，保留低预测动物的随机子样本，或者在跨场连接良好的后裔中收集独立记录。这些资料可能比再增加大量高度选择且共享信息的记录更有验证价值。验证不只是分析已有数据的技巧，也是一项可以前瞻设计的信息采集任务。

对育种机构而言，保留一个持续且有代表性的监测群体，有助于估计模型在实际候选范围中的误差。监测群体不应只由最终留种的顶端动物组成，否则很难判断被淘汰者的预测是否准确，也难以估计总体校准。适当的随机或分层测定投入，可以换取对长期模型表现更可靠的证据。

29.7 算例一：相关等于 1，为什么仍然预测失准

假设一个教学验证集的目标值为 $(-1, 0, 1, 2)$ ，模型预测为 $(-2, 0, 2, 4)$ 。它们的相关系数恰为 1，排序也完全一致；但预测的尺度扩大了一倍。将目标值对预测值回归，

$$y^* = a + \beta_{cal} \hat{u} + \varepsilon, \quad \beta_{cal} = \frac{\text{Cov}(y^*, \hat{u})}{\text{Var}(\hat{u})},$$

得到 $a = 0$ 、 $\beta_{cal} = 0.5$ 。按这个回归方向， $\beta_{cal} < 1$ 说明预测离散程度过大； $\beta_{cal} > 1$ 说明预测差异被压缩。若把回归方向反过来，解释也会随之变化，因此报告中必须写明横轴和纵轴。

原预测误差为 $(1, 0, -1, -2)$ ，均方根误差为 $\sqrt{6/4} = 1.2247$ 。把预测乘 0.5 后误差变为 0。这不是说明实际遗传预测可以零误差，而是说明相关对正比例缩放完全不敏感。若这些目标是真实表型，还应区分表型噪声与遗传预测误差。

再假设另一模型给出的预测是 $(-1.5, -0.5, 0.5, 1.5)$ ，相对于原目标整体低 0.5。相关仍为 1，斜率为 1，但截距为 0.5。由此可见，排序、均值和尺度是三个不同维度。用于选留排名时，整体平移可能不改变顺序；用于估计遗传趋势、跨场比较或经济收益时，平移同样重要。

在真实验证资料上估计校准参数后，不能在同一资料上重新校准并把改善后的分数当作独立验证表现。校准也是训练步骤，应另留测试时间段，或放在嵌套验证中。目标群体改变后，过去估计的截距和斜率还需要重新检查。




图 29.1 相关相同而校准不同

图 29.1 以四个教学真值负 1、0、1、2 构造三种预测，横轴为预测、纵轴为目标。橙线为目标对预测回归，虚线为完全校准线；三图相关均为 1，斜率或截距仍可不同。

29.8 校准、收缩与选择后的条件解释

29.8.1 正确收缩与过度压缩应如何区分

在线性高斯模型且参数正确时，BLUP 可等于条件均值 $\hat{u} = E(u | \mathcal{I})$ ，因此 $E(u | \hat{u}) = \hat{u}$ 。这表示按预测值分组后，真实育种值的条件平均应与预

测值一致，目标对预测的总体校准斜率为一。另一方面，给定真实 u 考察 $E(\hat{u} | u)$ ，往往可见向均值收缩。两种结论没有矛盾：它们条件于不同随机变量。把“BLUP 收缩”直接解释为目标对预测回归斜率必然大于一，是常见误解。

校准评价还取决于截距和参照。若预测已按某一基准群体平移，而验证目标按另一个基准，截距差可能主要是报告尺度不一致。应先统一合法的单位和零点，再检验均值偏倚。若在验证数据上自由选择平移量，使平均误差强制为零，然后不说明这一校准步骤，便无法再用同一资料评价原模型均值偏倚。对历史遗传趋势，基准一致性尤其重要，因为简单平移可以改变表现趋势的起点。

29.8.2 线性校准不能修复所有预测问题

设验证关系呈曲线：中间预测范围较准，极高预测被系统高估。单一斜率可能接近一，却掩盖尾部失准。可以按预先设定的预测分位组比较平均目标与平均预测，或用平滑校准曲线辅助诊断，同时给出各组样本数和区间。组数过多会使曲线主要反映噪声，事后选择分组边界也可能放大偶然模式。校准图应服务于具体诊断，而不是寻找最显著的偏离。

若误差来自未建模场效应，整体线性校准可能让平均表现改善，却仍保留场间系统偏差。若效应方向在目标品种改变，缩放也无法修复排序错误。校准的作用通常是调整某些低维偏移，重新训练或改变模型结构才可能处理更复杂失配。应通过独立测试比较未校准、只调截距、调截距和斜率以及重新训练的收益，避免把所有适配都统称为模型可直接迁移。

29.8.3 算例：校准估计本身也有抽样误差

假设一个独立校准集拟合得到 $z = 0.2 + 0.8\hat{u} + \varepsilon$ 。对新候选原预测 1.5，校准预测为 1.4。若截距和斜率估计的方差分别为 0.01 与 0.04，协方差为 -0.01，则这两个参数带来的新预测方差为 $0.01 + 1.5^2 \times 0.04 + 2 \times 1.5 \times (-0.01) = 0.07$ 。这还没有包括原预测误差与未来目标噪声。若仅报告校准后的点值而忽略小校准集的不确定性，可能制造虚假的精确度。

这个公式将原预测值暂视为给定，适用于说明校准参数传播。若校准集与训练集共享信息，或原预测本身随训练变化，需要加入相应协方差，不能简单把所有方差独立相加。小群体中可通过层级校准共享部分信息，但应防止较大群体完全压过地方群体特有偏移。是否采用共同斜率、群体特异截距或完整群体特异斜率，应由资料支持与部署目标决定。

29.8.4 选择尾部的校准与经济后果

当只留用最高预测的少数动物，整体平均误差为零并不足以保证留用组平均准确。可以在预先规定的选择比例下，检查留用组后期目标均值与预测均值的差，并与全体校准一起报告。若实际选择还受到近交、体型或繁殖约束，验证应按真实选择规则构造组，而不是仅按一个性状的预测排序。选择规则改变，条件目标群体也随之改变。

预测尺度失准会影响多性状指数。假设两个性状经济权重相同，其中一个预测被放大两倍，即使它各自相关不变，综合目标会对该性状给予过大实际权重。若性状之间存在不利遗传相关，后果可能更明显。校准因此不仅是美化散点图，而是保证经济权重作用于正确遗传单位。对外发布标准化指数时，仍应保存原始单位和转换规则，便于发现尺度错误。

校准改善也不等于因果解释改善。一个模型可以在当前环境中完美预测管理差异，却把这些差异错误归入遗传值；线性校准可能在同样环境分布下很好，在环境改变后迅速失效。把遗传与环境信息分开需要设计、连接和模型依据。校准是必要的性能维度，但不能单独证明预测来源符合生物学目标。

29.9 算例二：用早期与后期评定检验模型

线性回归验证法通常简称 LR 方法。对同一批目标动物，计算只使用早期或部分资料的 $\hat{u}_p$ ，以及包含新增资料的 $\hat{u}_w$ 。下标 p 与 w 分别表示 partial 和 whole，并非两个不同动物集合。常用统计量包括

$$\Delta = \overline{\hat{u}_p} - \overline{\hat{u}_w}, \quad \beta_{w,p} = \frac{\text{Cov}(\hat{u}_w, \hat{u}_p)}{\text{Var}(\hat{u}_p)}.$$

这里按“早期减后期”定义均值差。理想的均值一致对应 $\Delta = 0$ ，理想

离散度对应斜率接近 1。理论基础是, 正确 BLUP 模型下, 新增信息所带来的更新与已有预测具有特定正交关系。后期评定仍有误差, 但它不必被当作完美真值, 便可以形成具有理论解释的比较。关于斜率期望, 应同时阅读 Legarra 与 Reverter (2018) 的原文与 2019 年勘误; 不能沿用原摘要中小或相关验证集会期望斜率低于 1 的说法。

取四只动物的早期预测为 $(-1, 0, 1, 2)$, 后期预测为 $(-0.8, 0.2, 1.2, 2.4)$ 。两组均值分别为 0.5 与 0.75, 所以 $\Delta = -0.25$ 。早期样本方差为 5/3, 两组样本协方差为 5.3/3, 所以 $\beta_{w,p} = 1.06$ 。两组相关约为 0.998934。三个数字共同说明: 更新前后排序几乎一致, 但早期评定平均偏低, 离散程度略小。

在模型条件成立、目标群体的中心化真实育种值方差 V_{tar} 得到正确处理时, LR 准确性估计可用

$$\hat{r}_p = \sqrt{\frac{\text{Cov}(\hat{u}_w, \hat{u}_p)}{V_{tar}}}.$$

若仅为展示计算而设 $V_{tar} = 2$, 上例给出 $\hat{r}_p = 0.939858$ 。这只是附加假设下的教学数值; 由两列预测本身无法识别目标方差, 更不能确认模型正确。相关 0.998934 反映两套评定彼此接近, 不等于早期育种值对真值的准确性。目标动物存在近交、亲缘、选择或群体分层时, 分母不能简单换成任意历史基础群体的遗传方差。

Bermann 等 (2024b) 推导了资料截断验证统计量的标准误与区间, 并强调目标动物之间的关系及预测误差协方差会影响不确定性。Pardo 等 (2024) 的模拟则表明, 严重系谱问题或群体连通不足时, LR 均值偏倚统计可能未能揭示真实偏倚。因此, LR 是有条件的诊断工具, 不是对模型正确性的通行证。

还可以从反例理解 LR 的局限。如果早期与后期模型都漏掉了同一个场的环境优势, 两套育种值可能共同高估该场动物。它们的均值差接近零, 并不意味着相对于真值没有偏倚; 两把刻度同样错误的尺子仍可彼此吻合。因此, 应把 LR 与场间遗传连通检查、模型残差诊断、信息截点核查以及可获得的外部后代证据结合使用。模型在两次分析中保持一致有助于解释信息更新, 却也可能让共同错误在比较中抵消。

29.10 LR 验证的条件期望基础与分母选择

29.10.1 嵌套信息为何产生正交更新

令早期信息为 $\mathcal{I}_p$ ，后期完整信息为 $\mathcal{I}_w$ ，且 $\mathcal{I}_p \subseteq \mathcal{I}_w$ 。若两次预测都是同一个正确模型下的条件均值， $\hat{u}_p = E(u | \mathcal{I}_p)$ 、 $\hat{u}_w = E(u | \mathcal{I}_w)$ ，则由迭代期望有 $E(\hat{u}_w | \mathcal{I}_p) = \hat{u}_p$ 。因此，更新量 $\hat{u}_w - \hat{u}_p$ 与任何由早期信息确定且二阶矩存在的量正交，特别是与早期预测正交。这是 LR 比较能够不把后期预测当作完美真值的核心原因。

若固定一批目标动物，并用中心化矩阵 $J = I - \mathbf{1}\mathbf{1}'/n$ 计算跨动物协方差，则早期预测给定后， $E(\hat{u}_p' J \hat{u}_w | \mathcal{I}_p) = \hat{u}_p' J \hat{u}_p$ 。只要分母非零，目标对早期预测的回归斜率在这一理想条件期望模型下的条件期望为一。这个论证不要求动物之间完全无亲缘。现实 BLUP 常包含估计固定效应、估计方差和模型近似，因而应用时仍需按具体理论条件解释。Legarra 与 Reverter (2019) 的勘误对原始斜率讨论作了修正，阅读早期文献时应使用更新后的结论。

29.10.2 均值差、斜率和相关测量不同性质

均值差 Δ 描述预测更新的整体方向，斜率描述与早期预测大小相关的系统更新，相关则描述两次评定的线性一致程度。若完整模型只给全部动物加同一常数，相关和斜率都不变，均值差会变化；若完整预测是早期预测的两倍，相关仍为一但斜率为二；若新增信息主要提供与早期预测正交的个体差异，斜率可接近一而相关下降。相关下降在这种情况下不一定表示模型变差，也可能表示后期获得了真实新信息。

在理想嵌套预测下，有 $\text{Cov}(\hat{u}_p, \hat{u}_w) = \text{Var}(\hat{u}_p)$ ，所以两次预测相关与早期、后期预测方差的比值有关。后期信息越多，其预测方差通常越接近目标遗传方差，更新带来更充分的个体区分。若把两次相关直接称作早期准确性，就忽略了后期预测仍未达到完全信息以及验证群体的中心化结构。只有在额外条件下才能建立相应换算，不能从“相关很高”单独推出“接近真值”。

29.10.3 目标方差如何受到亲缘和中心化影响

对零均值目标遗传向量 u , 其跨动物样本方差的期望为 $\text{tr}\{J\text{Var}(u)\}/(n-1)$ 。若 $\text{Var}(u) = K_u \sigma_a^2$, 则分母参照应考虑 K_u 的平均对角与平均非对角关系, 而非机械使用基础方差。若各动物均值不同, 还要加入中心化均值向量的平方项, 或者先明确希望评价的是群体内偏差还是群体间差异。选择后的条件分布也可能与未选择基群不同, 因此公式中的协方差必须与目标群体和条件信息匹配。

算例中, 四只目标动物先验方差均为一, 任意两只协方差为 0.5。其协方差为 $0.5I + 0.5\mathbf{1}\mathbf{1}'$, 中心化会消去共同方向, 故期望样本方差为 0.5 而非一。如果用于 LR 准确性分母的目标是这一中心化群体差异, 直接用一会改变尺度。这个例子并不提供所有家系验证的通用修正, 因为真实亲缘并非等相关, 选择还可能改变分布; 它说明分母必须从被评价的随机量推导。

29.10.4 部分与完整评定应控制哪些变化

若想检验新增资料带来的更新, 两次评定最好保持性状定义、固定效应结构、基准和参数处理相容。若同时更换遗传参数、关系构造和资料范围, LR 统计仍可描述两次输出差异, 却不再只反映信息增加。可以另外开展固定模型与更新模型的比较, 分别回答旧模型是否校准以及新模型是否改善。真实生产系统的变化往往不可避免, 关键是把变化因素记录并分解。

当完整与部分模型共享同一错误, 如错误父亲、遗漏场效应或不正确的基群, 两者可能一起偏离真值而彼此一致。Pardo 等 (2024) 的模拟研究为系谱错设与连通不足下的诊断局限提供了直接证据。应结合外部后代资料、连接分析和残差检查, 特别关注均值偏倚可能被共同错误抵消的情况。LR 通过不需要直接真值而扩大了可验证范围, 但其可靠解释仍建立在明确的统计模型之上。

如果估计的准确性平方超出零到一, 不应立即截断并当作正常值报告。可能原因包括有限样本波动、分母不匹配、共同偏差或理论条件不成立。应先展示原统计量及不确定性, 检查数据和尺度, 再决定是否给出受约束估计。异常结果通常是诊断机会, 隐藏它会使读者无法判断方法在当前资料中的适

用性。

29.11 相关动物中的标准误、区间与重抽样

29.11.1 独立观测公式为什么容易过于乐观

同父系后代、同窝动物和同场同期记录常共享遗传或环境信息，它们的预测误差也可能相关。把一千只动物当作一千个独立重复，会低估某些总体均值和模型差异的不确定性。对等大小组、组内相关为 ρ 的简单均值问题，设计效应为 $1 + (m - 1)\rho$ ，其中 m 为每组大小；等效独立样本量约为总数除以该效应。这只是特定等相关均值模型的结果，不可直接当作所有预测相关的标准误公式。

例如一百个家系、每家十只动物，若误差组内相关为 0.2，均值的设计效应为 2.8，一千条记录对应的均值精度约相当于 357.1 个独立观测。若仍按一千独立动物计算区间，标准误会小约 $\sqrt{2.8}$ 倍。实际家系大小不均、跨家系仍有亲缘、场群与家系交叉时，需要更完整的协方差或合适的聚类方法。简化算例用于显示问题数量级，而非提供可直接复制的生产公式。

29.11.2 分组重抽样应匹配希望推广的单位

若目标是未来新父系家族，按父系家族重抽样比按单只动物重抽样更接近任务；若目标是新场年批次，应考虑场年或更适当的层级。一个父系可能跨多个场，场与家系并非总可简单嵌套，此时单一分组重抽样未必捕捉全部依赖。可以通过模型化协方差、多层或交叉聚类方法处理，但需要足够组数和明确假设。组数极少时，无论每组动物多少，都不能制造大量独立推广证据。

还要决定每次重抽样是否重新训练。固定预测只重抽样测试组，主要估计当前模型在目标测试总体中的抽样不确定性；重抽样训练与测试并重新选择参数，才更接近整个学习流程的变异。后者计算成本更高，也可能在稀疏群体中出现无法估计的参数。应根据问题选择，而不是把任何自助法的过程都当作同一置信区间。模型比较时应在同一重抽样单位上同时计算两种方

法，保留配对相关。

29.11.3 二次型观点帮助理解 LR 区间

LR 方差和协方差统计可写成预测向量的二次型或双线性型。它们的不确定性取决于完整的协方差矩阵，包括动物间关系、两次预测之间的相关及预测误差协方差。对于零均值正态向量 x 和对称矩阵 B ，有 $\text{Var}(x'Bx) = 2\text{tr}(BVBV)$ ，其中 $V = \text{Var}(x)$ 。若均值非零，还会出现均值相关项。这个通用公式说明为什么只知道每只动物的边际可靠度，未必足以得到群体 LR 统计的标准误。

Bermann 等（2024b）对资料截断验证统计量的区间作了专门推导，为在相关动物中进行不确定性评估提供了原始方法入口。应用时需要核对所用统计量、参数条件和协方差输入，不能把某一公式移到不同回归方向或不同目标集合而不调整。解析区间通常比大量重新拟合更节省计算，但其准确性依赖模型和近似；重抽样区间也不是无假设，两者可在可计算资料上互相检查。

29.11.4 算例：配对比较可以比单独区间更精确

设十个独立测试家系上，两模型的平均损失估计方差均为 0.04，两者协方差为 0.035。差值方差为 $0.04 + 0.04 - 2 \times 0.035 = 0.01$ ，标准误为 0.1。若错误地把两估计视为独立，则标准误为 $\sqrt{0.08} \approx 0.2828$ 。同一动物对两种模型都较难预测，往往造成误差正相关，配对设计因此能更清楚地比较方法。这里给定的是损失估计的方差，不是个体表型方差，不能在应用中混淆层次。

相反，若两模型在不同测试动物上评价，配对优势消失，群体组成差异还会引入额外混杂。为了提高比较精度，优先让所有方法预测同一批外层目标，并保留逐组损失，而不只是最终一个平均值。这样可以检查改进是否分布广泛，还是仅由少数特殊家系驱动。若多数家系无改善、少数家系改善很大，总体平均仍可能有用，但应说明适用范围。

置信区间包含零不等于证明两个方法完全相同；它表示当前证据不能明确排除无差异。若决策关心是否至少改善某一有意义的幅度，应直接围绕该

幅度报告区间或预先设计等效性问题。统计显著而极小的收益也未必值得昂贵部署。区间的价值在于帮助判断可能的收益范围及风险，而不是把研究结论压缩成显著与不显著两个词。

29.12 模型比较、学习曲线与参考群体建设

29.12.1 把方法差异分成数据、模型和计算三个来源

基因组预测研究常同时改变训练动物数、标记密度、表型处理和算法。若新方法获益，无法知道是哪一部分起作用。可以先以相同数据建立基准，再逐步改变标记集合、先验或关系结构；另外比较完整生产流程，估计现实综合收益。前者有助于解释机制，后者有助于部署决策，两种结果应互相补充。只做受控小比较可能忽略流程优势，只做全流程比较又容易夸大算法贡献。

模型比较的随机性也有多个来源：训练抽样、验证抽样、超参数搜索、贝叶斯采样或优化初值。重复运行同一训练集上的算法，只能评估算法随机性；重复划分资料还涉及数据变异。应根据研究问题分层记录这些来源，并避免把所有重复混在一起计算一个看似精确的标准误。若某复杂方法只在少数初始化中表现优良，平均部署性能与最好一次性能可能相差很大。

29.12.2 学习曲线应反映可实现的数据投入

学习曲线展示训练规模增加时性能如何变化，但横轴应说明增加的是动物、独立家系、高可靠度后裔信息还是新环境覆盖。增加一万只同家系低精度动物，与增加一千只不同家系高精度动物，可能带来不同收益。可以把数量、信息精度和遗传覆盖分别作为设计因素，构建现实可实现的资料投入方案。这样的曲线比任意套用一个样本量准确性公式更适合预算规划。

教学上可设预测均方误差由不可消除部分 0.4 和估计部分 $6/(n+10)$ 组成，则 $n=20, 50, 100$ 时误差为 0.6, 0.5, 0.4545。这只是人为学习曲线，说明收益可能递减，并不代表任何品种的真实规律。若新增动物来自新群体，误差曲线甚至可能先升后降，因为模型开始面对更复杂分布。不能用同分布随

机子样本拟合的曲线保证跨品种扩充收益。

29.12.3 参考动物选择不应只追求与当前候选最接近

与当前候选近亲的参考动物通常提供直接信息，但长期只测最接近的精英家系，可能使数据库越来越窄，削弱对新家系和保种群体的覆盖。参考群体建设需要平衡近期预测与未来多样性。可以保留业务驱动的高价值测定，同时设置代表性抽样部分，覆盖少见家系、不同环境和低预测动物。后一部分对校准和迁移诊断尤其重要，即使短期看不到最大的预测相关收益。

选择哪些动物新增表型还应考虑测量可靠度。一个高成本性状若可通过重复测定显著降低残差，给已有动物增加测量可能优于新增很多噪声极大的单次记录；若永久环境占比很大，继续重复同一动物的边际收益则有限。结合重复力、遗传关系和目标候选分布，可以估计不同采集方案对信息矩阵的影响。最终方案还受到伦理、生产和成本约束，应把这些约束与统计收益同时呈现。

29.12.4 负结果与失败案例同样构成有效证据

若加入测序变异、组学或复杂先验后没有稳定收益，应报告资料规模、变异质量、验证场景和不确定性，而不是只说方法无用。结果可能表示新增信息与现有标记高度重复，也可能表示样本不足以估计额外参数，或者部署群体缺少相同测量。明确失败条件能指导后续研究改变哪一环。反复尝试许多配置却只发表唯一正结果，会使领域对预期收益形成系统性乐观印象。

同样，某方法在一个品种中成功而在另一个失败，可能揭示遗传结构或数据形成机制差异。研究应优先分析这些可解释因素，而不是用平均分数掩盖异质性。可以考察家系距离、频率范围、标记覆盖、表型一致性和环境连接是否与收益相关，但这些事后分析应标注探索性质，并在新资料中验证。预测性能的解释也需要防止把相关模式当作因果机制。

部署前的决策可以使用收益区间与成本区间，而不必等待某个方法在所有条件下绝对获胜。若方法在主要候选群体中有稳定、具有经济意义的收益，并且计算可及时完成，可进行受控上线；若收益不确定而维护成本高，继续

收集验证资料可能更合理。这里的判断基于具体任务，不形成永久的算法等级。研究的贡献在于提供可判断的证据，而不是替所有育种体系作同一个选择。

29.13 跨群体迁移与近期方法进展

跨群体性能下降至少可能来自四类变化：等位基因频率变化，标记与因果位点之间连锁不平衡变化，效应或遗传背景变化，以及表型测定和环境变化。增加源群体样本数只能缓解部分估计误差，不能保证克服目标定义不同或效应方向改变。所谓迁移能力应写明从哪里迁往哪里、哪些信息在目标群体可用。

一个实用的递进方案是先固定源群体模型，取得完全外部的目标群体验证；随后分别加入少量目标群体表型用于截距校准、尺度校准或重新训练，绘制性能随目标样本增加的变化。这样能区分“模型可直接迁移”和“少量本地资料即可适配”。把所有目标样本参与调参，再称为外部验证，会混淆这两种结论。

选择还会使方差和相关随时间变化。Gowane 等（2026a）研究了利用预测能力关系估计遗传参数的 GPP 方法，并在持续基因组选择的模拟情景中比较动态参数。论文为大型资料的参数更新提供了新的计算思路；其证据主要来自所设模拟，且跨性状估计存在方向差异，不能据此宣布传统方差组分估计已被普遍替代。

该文 2026 年 9 月 23 日的勘误将图 12 和图 13 纵轴由“遗传力”更正为“遗传相关”，原文已更新；引用这些图时应采用更正后的量名（Gowane 等，2026b）。

这一进展提示一个更一般的原则：模型参数不应被永久冻结。实际评定可设定定期检查，而不是每次看到波动就立即改模型。检查应包括各出生年份的均值变化、校准斜率、预测误差、遗传参数估计和数据构成。当这些量共同指向系统变化时，再考虑更新参考群体、模型结构或参数。

完整验证报告应能让读者重建决策场景：目标动物是谁，资料截点在哪

里, 哪些步骤使用了哪些数据, 超参数如何确定, 比较模型是否共享相同资料, 误差区间如何获得, 以及结果适用于哪些群体。重要候选动物的选择一致性、遗传多样性变化和实际测定成本也应与统计性能并列报告。预测方法最终服务于可持续改良, 单个相关系数无法承担全部评价任务。

总体性能还可能掩盖目标群体内部的差别。若训练资料主要来自大场, 总体相关很高, 而小场或地方品种的校准明显较差, 直接用总体分数推广会误导使用者。应在预先定义且有足够资料的亚群中检查均值、尺度与误差, 并注明样本不足的范围。亚群不能根据测试表现反复切分来挑选有利结果; 分层分析和多重比较的不确定性也需要进入解释。

29.14 迁移机制、局部适配与跨品种信息共享

29.14.1 不同分布变化需要不同应对

协变量分布变化是指输入特征的分布改变而条件目标关系保持; 条件关系变化是指相同输入在新群体中对应不同目标分布; 测量变化则可能让同一生物性状被不同单位、仪器或定义记录。动物育种中这些变化常同时存在, 例如新地区引入不同品种、采用新饲料制度并更换测定设备。只观察总体预测下降无法唯一定位原因, 需要结合遗传与环境资料进行分解。

在理想协变量变化条件下, 可以用目标与源输入密度之比作为权重, 把源群体损失重加权为目标损失。但这要求目标范围被源资料覆盖, 并且条件关系确实相同。若目标群体携带源群体从未观察的单倍型, 权重不能创造该区域信息; 若效应方向因连锁或环境改变, 重加权也不能修复条件失配。应把重要性加权视为有明确假设的方法, 而不是通用的跨品种校正按钮。

29.14.2 算例: 权重集中会减少有效信息

若四个源样本的目标权重为 1, 1, 1, 7, 总权重为十, 常用的权重有效样本量描述为 $(\sum_i w_i)^2 / \sum_i w_i^2 = 100/52 \approx 1.9231$ 。尽管有四个样本, 目标风险估计主要依赖最后一个, 因而不确定性很大。这个量描述权重集中, 不包含家系相关或训练误差, 不能直接当作完整有效动物数。若再存在近亲依赖,

实际信息还可能更少。

截断极端权重可以降低方差，却引入对目标分布的近似偏差。应报告截断规则并作敏感性分析，而不能只展示最有利的权重设置。更根本的解决方式通常是增加目标群体中缺少覆盖的样本，特别是同时拥有可靠表型和基因型的动物。迁移方法可以提高有限资料利用效率，但不能替代对新遗传背景 and 环境的实际观察。

29.14.3 共享效应、群体特异效应与层级借力

跨品种模型可以假设所有标记效应相同，也可以允许每个品种完全独立，或者通过层级结构让品种效应围绕共同均值变化。完全共享降低参数数量、提高小群体信息量，但在效应不一致时产生偏差；完全独立减少错误借力，却可能因小样本而不稳定；部分共享在两者之间折中，其强度需要数据或透明先验支持。模型中允许群体特异效应，并不证明各群体机制确实不同，只是为差异提供表达空间。

Sahana 等（2025）以印度本地牛资料研究了共享关系、品种特异关系及元基础群体方案，小规模 Kankrej 群体在所比较的多品种参考设计中获得收益。这是目标品种资料有限时借助相关群体的实际研究实例，但不同来源组合的表现并不一致。其证据支持针对具体群体选择参考来源，不能推出所有小品种都应直接合并，也不能把该研究的精度指标当作本地新群体的预期值。

29.14.4 连锁相位变化使关联标记难以直接迁移

设一个未观测因果位点效应为正，源群体中某标记与该位点正相关，目标群体中却因历史重组或不同单倍型背景而负相关。源群体估计的标记效应可以准确预测源动物，却在目标群体方向错误。增加源群体样本只能更精确地估计源关联，不能自动改正目标相位。直接观察因果变异、增加目标单倍型或利用可靠生物注释可能有帮助，但每一步都需要证据确认，不能仅凭跨群体相关下降就断言已找到相位变化。

频率变化还会改变某些变异是否提供足够估计信息。源群体常见的等位

基因在目标群体几乎固定，其效应即使真实相同，对目标群体内排序也贡献有限；目标特有变异则可能在源训练中没有任何效应估计支持。报告跨品种模型时，应同时看共同变异覆盖和目标特有信息，而不只比较平均关系或主成分距离。遗传距离是有用描述，但不是跨群体预测能力的完整充分统计量。

29.14.5 本地适配的评价必须保留真正外部测试

可以按目标资料投入依次比较零本地表型、少量本地校准、少量本地重训和较大大本地参考四种阶段。每一阶段都应保留未参与适配的目标动物，并让最终测试覆盖预期未来家系和环境。若用同一批本地动物反复调参、校准和评估，就无法区分真实迁移收益与对小样本噪声的拟合。小群体可采用严格嵌套或前瞻时间窗口，但应诚实报告区间宽度。

适配效果还应按亚群检查。总体截距调整可能改善平均值，却对某一地方家系继续失准；强烈借力大品种可能提高平均相关，却压缩目标品种特有的遗传差异。应把目标群体自身的育种目标、多样性和测定条件纳入判断。跨群体预测的成功不是让所有群体输出看起来相似，而是在各自明确参照和实际决策中提供可信的信息。

29.15 前瞻监测、模型更新与完整研究方案

29.15.1 监测需要同时观察输入和结果

部署后的输入漂移可以表现为基因型频率、缺失率、年龄构成、品种比例或测定平台变化；结果漂移可以表现为校准截距、斜率、误差和选择反变化。输入变化不一定导致性能下降，性能下降也不一定伴随明显输入变化。两类监测应结合，而不能仅凭一个总体分布检验决定是否重训。大量样本会使很小的分布变化统计显著，是否具有育种意义还要看其对预测和决策的影响。

后期结果往往延迟到来。青年公畜的后裔信息需要多年积累，某些终生性状更慢，因此监测可分短期技术指标、中期表型校准和长期遗传结果。短期指标能快速发现样本错位和平台故障，却不能证明长期育种值准确；长期

指标更贴近目标，却受到选择和配种制度影响。明确各层指标的作用，可以避免用容易获得的技术一致率替代难以获得但更重要的生物学验证。

29.15.2 更新规则应预先规定而不是追逐随机波动

可以设定固定周期检查遗传参数与校准，并在出现持续、跨指标一致的偏移时启动深入调查。一次小样本斜率偏离一，可能只是抽样波动；频繁据此调整模型会把噪声写入评定过程。另一方面，长期忽略明确的测定制度变化也会让旧参数失效。合理规则应结合最小数据量、实际偏移幅度和业务风险，并保留原模型作为受控比较基准。

更新可有不同层级：只加入新记录、重估固定效应和方差、重新选择核心或参考动物、改变特征与模型结构。越高层级的变化，越需要新的独立验证。记录每次更新的动机和结果，使系统能够学习哪些变化真正有帮助。若更新后只保留最终版本而删除比较记录，将难以判断后续性能波动来自数据环境还是模型选择。

29.15.3 算例：连续查看结果会增加误报机会

若每月独立进行一次显著性水平 0.05 的检验，在完全没有真实变化的理想情形下，一年十二次至少一次误报的概率为 $1 - 0.95^{12} \approx 0.4596$ 。真实月度数据通常相关，因此这个数字不直接适用，但它说明反复查看不能按单次检验解释。监测应使用适合连续观察的规则、控制重复比较，或把触发视为调查提示而非立即宣布模型失效。

同样，研究过程中每增加一批数据就检验两模型差异，并在第一次显著时停止，会改变名义区间与错误概率。可以事先规定分析时点、样本规模或顺序分析方法；若属于探索性监测，则应保留完整轨迹，并在新时间窗口确认。统计方法的目的是不是阻止及时行动，而是让证据强度与实际观察过程一致。

29.15.4 一个可执行的基因组预测研究方案

以某地方肉羊群体青年公羊选择为例，研究首先定义目标为选种日可获得信息下的加性育种值预测，并明确主要性状单位和育种目标。训练资料包

括截点前表型、当时已知系谱与基因型；验证动物按未来出生批次确定。建立系谱 BLUP 与标准 GBLUP 或单步基准，再分别研究低深度测序、先验加权或外部群体加入的增益。所有监督筛选与参数选择在训练内完成，最终测试只使用一次。

验证同时报告预测能力、校准、均方误差及按家系或场群构造的不确定性；若使用 LR，说明部分与完整评定的资料差异、模型一致性和目标方差定义。对重点亚群预先规定分层，对样本不足群体明确不确定范围。经济分析使用相同权重和选择规则，另外检查近交与家系贡献。计算报告分开记录数据处理、关系构建、拟合和精度估计成本，便于判断能否在实际选种前完成。

研究还应保留失败结果和敏感性分析，例如不同频率参照、核心规模、残差结构及外部参考组合。敏感性不是无限尝试直到得到理想结论，而是围绕已识别的关键假设设置有限、有解释的替代方案。若主要结论只在一个非常特殊设置下成立，应缩小适用范围；若在多个合理设置下稳定，则证据更有说服力。每种解释都要区分真实生产资料、教学模拟与方法推断。

29.15.5 预测证据的边界与科学积累

截至本书资料核验时，2024—2026 年的 LR 区间、元基础群体关系及动态参数研究，继续推动评定从单一相关比较走向更完整的模型诊断。这些进展并没有取消基本要求：目标明确、信息时间一致、关系与尺度相容、误差结构合理，以及外部结果可复核。新方法应放入这一连续证据链中理解，而不是每出现一个新术语便重新定义成功标准。

一次验证给出的结论总有群体、时间和信息范围。把这些范围写清楚不会削弱研究价值，反而使其他机构知道何时可以借鉴、何时需要补充本地资料。高质量育种预测研究不追求每个指标都最好，而追求结论能够经受不同信息条件下的检验，并让后续研究准确知道还缺少哪些证据。这样的累积过程，才能把数学模型转化为可持续的遗传改良。

29.16 LR 更新量的协方差与选择后的条件解释

LR 验证的基础是嵌套信息下的正交更新，而不是把后期评定当成无误差真值。进一步深入，可以把均值变化和尺度变化的不确定性直接写成新增信息的协方差。Legarra 与 Reverter (2018、2019) 为这种比较提供了理论框架及勘误；Bermann 等 (2024b) 进一步研究了资料截断验证统计量的区间。下面从已知参数的条件均值模型推导，以明确哪些结论依赖理想条件，哪些诊断可以在相关动物中继续使用。

令早期预测向量为 f ，后期预测为 g ，信息集合满足 $\mathcal{I}_p \subseteq \mathcal{I}_w$ 。定义

$$f = E(u | \mathcal{I}_p), \quad g = E(u | \mathcal{I}_w), \quad d = g - f.$$

迭代期望给出

$$E(d | \mathcal{I}_p) = 0.$$

对于任意由早期信息确定、二阶矩存在的向量函数 $a(\mathcal{I}_p)$ ，有 $E\{a^T d\} = 0$ 。因此，即使目标动物是按早期指数选择出来的，只要选择集合和权重完全由早期信息决定，条件正交性仍然保留。选择本身并不自动破坏这一性质；关键是是否引入了早期信息之外的条件。

在联合正态、固定设计和已知参数下，设两次预测误差协方差分别为 C_p 与 C_w ，则

$$V_d = \text{Var}(d) = C_p - C_w \geq 0.$$

新增信息减少预测误差，却增加了可以辨认的个体差异。该式要求两次分析来自同一相容概率模型；如果同时重估方差、改变关系定义或修正大量系谱，两个软件输出之差仍可计算，却未必满足上述协方差恒等式。模型更新应与信息增加分别比较。

令 $J = I - \mathbf{1}\mathbf{1}^T/n$ ，且 $f^T J f > 0$ 。后期对早期的样本回归斜率为

$$\hat{b} = \frac{f^T J g}{f^T J f} = 1 + \frac{f^T J d}{f^T J f}.$$

给定早期信息，其条件期望为一；在上述高斯设置下，条件方差为

$$\text{Var}(\hat{b} | \mathcal{I}_p) = \frac{f^T J V_d J f}{(f^T J f)^2}.$$

这不仅需要更新的个体方差，还需要动物之间的更新协方差。若给定的早期预测几乎没有差异，分母很小，斜率可以极不稳定。扩大验证动物数未必解决问题，如果新增动物只是重复相近预测而没有增加有效差异，回归的信息仍然有限。

均值差使用另一方向。按早期减后期定义 $\hat{\Delta} = -\mathbf{1}^T d/n$ ，其方差为

$$\text{Var}(\hat{\Delta}) = \frac{\mathbf{1}^T V_d \mathbf{1}}{n^2}.$$

因此，共同更新方向会影响均值差，却可能在斜率中心化时被消除。把一个统计量的稳定误认为所有验证方面都稳定，会遗漏这种结构。

取四只动物的早期预测 $f = (-1, -1, 1, 1)^T$ ，更新协方差为 $V_d = 0.2I + 0.3\mathbf{1}\mathbf{1}^T$ 。由于 $Jf = f$ ，斜率方差为 $0.2 \times 4/16 = 0.05$ ，标准误为 0.223607。均值差方差则为

$$\text{Var}(\hat{\Delta}) = \frac{0.2 \times 4 + 0.3 \times 16}{16} = 0.35.$$

其标准误为 0.591608。若只保留更新协方差对角元 0.5，错误地按四只独立动物计算，会得到均值差方差 0.125。同一个遗漏协方差的做法，对不同统计量不一定产生相同方向的误差；应先写明统计量所考察的线性方向。

如果目标集合根据后期信息选择，例如只保留后来表现好的动物，选择事件不再由 $\mathcal{I}_p$ 决定。条件于这个事件，更新均值通常不再为零。此时观察到斜率或均值变化，不必全是早期模型失准，也可能来自验证对象选择。可以固定决策日的候选清单，再收集其后期资料；对因淘汰而缺失的结果，则需要说明缺失机制与可识别范围。

共同模型错误仍可能在两次预测中抵消。正交更新理论不是对未知模型正确性的检验替代，而是说明在模型成立时哪些现象应出现。若早期与后期都把同一个场效应误归为遗传，它们可能保持高度一致。应把上述协方差诊

断与外部后代证据、连接检查和不同来源的误差诊断结合，避免让两次评定的一致性承担它无法证明的因果解释。

如果不同候选使用不等权重，还应先确定权重是在决策日固定，还是根据后期精度选择。前者可以纳入早期可测的统计量，后者可能依赖新增信息。按后来后裔数筛选验证动物，既改变遗传精度，也可能改变实际繁殖机会和选择结构。不能仅因为权重看起来代表“可靠信息”就忽略它的形成时间。可以将决策日固定清单的结果与后期资料充分分子集的结果分别报告，说明两个总体的区别。

29.17 LR 协方差统计的抽样波动与平方根偏差

LR 准确性常通过两次预测的协方差及目标方差构造，但协方差本身是随机二次型。验证集合较小或亲缘集中时，其波动可能很大；对这个随机量再开平方，又引入非线性变换的偏差。这里推导一个可手算的高斯例子，以区别总体恒等式与有限样本统计量。

继续写 $g = f + d$ ，假定 f 与 d 为相互独立的零均值正态向量，协方差分别为 V_f 与 V_d 。中心化样本协方差为

$$N = \frac{f^T J g}{n-1} = \frac{f^T J f + f^T J d}{n-1}.$$

第一项是早期预测的样本方差，第二项是新增信息与早期预测的有限样本交叉波动。因此

$$E(N) = \frac{\text{tr}(J V_f)}{n-1}.$$

利用高斯二次型公式，且交叉项与第一项协方差为零，有

$$\text{Var}(N) = \frac{2 \text{tr}(J V_f J V_f) + \text{tr}(J V_d J V_f)}{(n-1)^2}.$$

第一部分来自早期预测本身的抽样变化，第二部分来自新增信息带来的随机更新。若只在固定早期预测上回归并使用普通独立残差公式，就可能忽略需要对训练与验证总体平均的那部分变化。条件区间与无条件区间各有对应问题，不能在解释时互换。

若目标真实遗传向量协方差为 V_u 、均值相同，匹配的中心化方差为

$$V_{tar} = \frac{tr(JV_u)}{n-1}.$$

暂把这个分母视为已知，定义 $R_{LR} = N/V_{tar}$ ，则

$$\begin{aligned} E(R_{LR}) &= \frac{E(N)}{V_{tar}}, \\ \text{Var}(R_{LR}) &= \frac{\text{Var}(N)}{V_{tar}^2}. \end{aligned}$$

如果目标方差也由同一资料估计，还需引入分母方差与协方差；简单代入点估计通常低估总不确定性。特别是强选择群体中，目标方差的定义本来就不同于历史基群方差，不能通过增加小数位数消除这种概念不确定性。

取三只动物，设

$$\begin{aligned} V_f &= 0.4I + 0.211^T, \\ V_d &= 0.3I + 0.111^T, \\ C_w &= 0.5I. \end{aligned}$$

令 $u = f + d + \eta$ ，其中 η 独立且协方差为 C_w ，于是这是一个相容的嵌套高斯模型。中心化会消去所有共同项，故 $E(N) = 0.4$ 、 $V_{tar} = 1.2$ ，相应可靠度比值的期望为三分之一。协方差统计的方差却为

$$\text{Var}(N) = \frac{2(0.4)^2 + 0.3 \times 0.4}{3-1} = 0.22.$$

其标准差约为 0.469042，甚至大于期望。可靠度比值的标准差约为 0.390868。有限样本中出现负协方差，并不在逻辑上自动证明程序错误；它可能来自抽样波动，但仍需检查模型与尺度。三只动物的教学例有意突出小样本的不稳定，不代表生产验证应接受如此薄弱的证据。

把动物数增加到二十一且保持同类协方差结构， $\text{Var}(N) = 0.022$ ，可靠度比值标准差降至 0.123603。共同方向并没有增加中心化信息，起作用的是独立对比方向数。实际家系相关并非简单共同项，增加更多近亲时，误差下降可能远慢于这个等结构例子。

准确性通常还要取平方根。对一个均值为 $\mu > 0$ 、波动较小的可靠度估计 R ，二阶展开给出

$$E(\sqrt{R}) \approx \sqrt{\mu} - \frac{\text{Var}(R)}{8\mu^{3/2}}.$$

平方根的凹性造成向下的变换偏差。这个展开只在负值概率可忽略、方差足够小时适用，不能套到刚才三动物的高度不稳定情形。先将负值截为零再开平方，会引入另一种截断偏差，并改变抽样分布；应报告原统计量及采用的约束规则。

在研究报告中，可以先展示协方差、目标方差与可靠度（准确性的平方）的区间，再给出在适用条件下的准确性区间。若区间跨越不合法边界，应解释是资料不足、尺度不匹配还是理论条件失效，而不是只显示截断后的漂亮范围。Bermann 等（2024b）的区间工作支持把这些统计量当作需要不确定性评估的估计对象；具体公式仍须匹配其模型、选择条件和参数处理。

方差参数估计会使解析区间进一步复杂。若部分与完整模型分别重估参数，更新向量同时包含新增表型信号与参数变化，其分布不再由两个条件预测误差矩阵的简单差充分描述。可以在固定参数下研究信息增加，再单独比较重新估计的生产流程。若目标是完整算法的不确定性，则重抽样或模拟必须重演参数估计步骤，而不能只对已经算出的两列育种值进行独立抽样。

对非零遗传趋势，也应先明确是否希望把趋势本身包含在准确性中。如果不同年份的真实均值不同，中心化后的协方差既包含年份间差异，也包含年份内动物差异。总体相关可能被明显趋势抬高，而同年候选区分仍然有限。按预定年份分层并报告整体与层内指标，可以说明模型利用了哪些信息；事后选择最有利的去趋势方式，则会改变评价对象并产生新的选择空间。

29.18 模型损失差的依赖结构与真正的推广单位

比较两个模型时，关心的不是两个单独相关系数是否各自显著，而是它们在同一目标群体上的损失差有多大、波动来自哪里。家系、场群和共享训练资料会同时关联动物与模型误差。配对比较能够利用共同难度，但它不会自动消除动物之间的依赖。

令两个模型在动物 i 上的误差为 e_{Ai} 与 e_{Bi} , 平方损失差为

$$d_i = e_{Ai}^2 - e_{Bi}^2.$$

暂假定两组误差联合零均值正态。记跨动物协方差为 C_{ij}^{AA} 、 C_{ij}^{BB} 、 C_{ij}^{AB} 与 C_{ij}^{BA} 。由正态四阶矩分解,

$$\begin{aligned} \text{Cov}(d_i, d_j) = 2\{ & (C_{ij}^{AA})^2 + (C_{ij}^{BB})^2 \\ & - (C_{ij}^{AB})^2 - (C_{ij}^{BA})^2 \}. \end{aligned}$$

共同的难预测动物使两模型误差相关, 可能降低损失差方差; 家系内共同误差则使多只动物的损失差仍相关。若误差均值不为零, 还要加入均值与协方差形成的项。特别是模型存在群体偏倚时, 不能仅凭零均值公式给出过窄区间。

对权重满足 $\sum_i w_i = 1$ 的目标平均差 $\bar{d}_w = \sum_i w_i d_i$,

$$\text{Var}(\bar{d}_w) = w^T V_d w,$$

其中 V_d 是完整损失差协方差。这个公式表达了真正需要估计的量; 独立动物标准误相当于删除所有非对角元。是否允许删除, 应由资料形成和目标推广单位决定, 而不是由样本表中是否每只动物占一行决定。

先看更简单的误差均值。设家系间独立, 个体误差方差为 σ^2 , 同家系相关为 ρ 。对任意权重,

$$\text{Var}(\bar{e}_w) = \sigma^2 \left\{ (1 - \rho) \sum_i w_i^2 + \rho \sum_g \left(\sum_{i \in g} w_i \right)^2 \right\}.$$

第二项由各家系的总权重平方决定, 说明大父系家族可以主导不确定性。仅用平均家系大小代入等组公式, 在家系规模很不均衡时可能误导。

例如两个家系分别有二只和八只动物, 取个体等权、 $\rho = 0.5$ 。则

$$\frac{\text{Var}(\bar{e})}{\sigma^2} = \frac{0.5}{10} + \frac{0.5(2^2 + 8^2)}{10^2} = 0.39.$$

十只动物在这个均值问题中的等效独立数量为 $1/0.39 = 2.564103$ 。若错误套用两家平均每家五只的等大小设计效应，会得到另一数值，因为平均大小没有保留平方和。

若改成每个家系平均值各占一半，方差变为

$$\frac{1}{4} \left\{ 0.5 + \frac{0.5}{2} + 0.5 + \frac{0.5}{8} \right\} = 0.328125.$$

这个方差较小，但目标也从“随机动物的平均误差”变为“随机家系的平均误差”。当家系平均表现不同，两者期望可以不同。因此，不能为了得到较小标准误而事后更换权重；权重应来自希望推广的总体。

现实中家系与场群常交叉。设误差具有随机分解

$$e_i = a_{g(i)} + b_{h(i)} + \epsilon_i,$$

三类成分相互独立，方差分别为 σ_a^2 、 σ_b^2 与 σ_ϵ^2 。记家系总权重为 W_g 、场群总权重为 U_h ，则

$$\text{Var}(\bar{e}_w) = \sigma_a^2 \sum_g W_g^2 + \sigma_b^2 \sum_h U_h^2 + \sigma_\epsilon^2 \sum_i w_i^2.$$

只按父系家族重抽样，可能保留部分家系依赖，却没有正确处理跨家系的共同场群变化。只按场群重抽样也可能遗漏跨场家系联系。应采用与实际交叉结构相容的协方差模型或多维聚类设计，并说明独立组数与近似条件。组数很少时，无论组内动物有多少，都缺少对新组变化的精确证据。

此外，固定当前模型的测试重抽样与重新训练算法的重抽样估计不同不确定性。前者条件于已经获得的训练集，后者还包含重新抽取资料、调参和拟合的变动。研究比较若声称算法普遍优于另一方法，应尽量考察训练变化；生产验收若只关心当前冻结模型，则条件性能也有明确价值。把两者分别命名，有助于避免一个窄区间被错误解释为全流程稳定。

重抽样还需保留模型之间的配对关系。每次抽取同一批家系或场群后，应同时计算两个模型的损失，再形成差值；分别抽样两个模型会丢失共享难度，改变差值的不确定性。若某些家系在一个模型中无法得到预测，不能仅

从该模型的结果中删除它们，再与另一模型不同的集合比较。应说明失败规则，并在共同任务或完整流程层面进行一致评价。

反复随机划分产生许多个分数，并不等于获得许多个独立群体。它们往往共享大部分训练资料和验证动物，因此简单用分数标准差除以重复次数平方根，可能制造不合理的窄区间。重复划分有助于观察划分敏感性，但要推断未来新场或新家系，还需相应的独立结构。明确推广单位，比增加看似很多的随机重复更能改善证据质量。

29.19 从条件分布变化推导迁移风险

跨群体迁移不佳有时源于输入比例改变，有时源于同一输入与目标之间的关系改变。重要性加权只能处理满足条件不变假定的那部分。要判断它能修复什么，可以把源群体与目标群体的条件均值和条件方差分别写出。

令源群体条件均值为 $m_S(x)$ ，目标群体为 $m_T(x)$ ，定义差异

$$\delta(x) = m_T(x) - m_S(x).$$

对固定预测函数 $f(x)$ ，目标平方风险为

$$\mathcal{R}_T(f) = E_T\{\text{Var}_T(Y | X)\} + E_T[\{f(X) - m_T(X)\}^2].$$

将 $m_T = m_S + \delta$ 代入，得到

$$\begin{aligned}\mathcal{R}_T(f) = & E_T(v_T) + E_T[\{f - m_S\}^2] \\ & + E_T(\delta^2) - 2E_T\{(f - m_S)\delta\}.\end{aligned}$$

这里各函数均在目标输入分布下积分。最后的交叉项说明，源模型已有的误差有时会与条件变化部分抵消，因此迁移后的风险变化不必总是简单地增加某个正数。但若源模型已经精确等于 m_S ，目标条件均值变化的额外代价就是 $E_T(\delta^2)$ 。

当目标输入密度被源输入支持覆盖，令权重 $w(x) = p_T(x)/p_S(x)$ 。源群体损失重加权得到

$$E_S\{w(X)(Y - f(X))^2\} = E_T\{v_S + (m_S - f)^2\}.$$

它与真正目标风险的差为

$$\begin{aligned}\mathcal{R}_T(f) - \mathcal{R}_{weighted} = & E_T(v_T - v_S) + E_T(\delta^2) \\ & - 2E_T\{(f - m_S)\delta\}.\end{aligned}$$

所以，输入分布完全对齐，也不能保证条件关系已经对齐。若源与目标输入分布相同，所有权重都为一，条件变化仍然可以很大。这个公式明确了重加权的能力边界，而不仅是笼统地说“跨群体很困难”。

一个遗传学例子可以把条件变化连接到连锁。设标准化标记 x 与标准化因果遗传量 q 均方差为一，目标信号为 βq 。在某群体内，用单标记作最佳线性预测时，系数为

$$b = \beta \frac{\text{Cov}(x, q)}{\text{Var}(x)}.$$

即使因果效应 β 完全相同，标记系数仍取决于该群体的关联结构。Habier、Fernando 与 Dekkers (2007) 研究了遗传关系信息对基因组辅助预测的作用，为理解预测信息来源提供了原始入口；不能将稳定的群体内预测直接等同于稳定的跨群体标记效应。

取 $\beta = 1$ ，源群体相关为 0.8，目标群体相关为 -0.2 。源模型使用 $b_S = 0.8$ ，目标最佳线性系数为 $b_T = -0.2$ 。目标最优线性预测的残余风险为 $1 - (-0.2)^2 = 0.96$ ；直接迁移的额外风险为

$$\text{Var}_T(x) (b_S - b_T)^2 = 1.$$

于是迁移风险为 1.96，而源群体中的相应风险为 $1 - 0.8^2 = 0.36$ 。增加源样本只能更精确地估计 0.8，不能把它自动变成目标所需的 -0.2 。这里两个变量的标准化边际可相同，变化发生在联合关联，单独匹配频率或方差可能发现不了问题。

这个例子描述的是关联标记的线性预测，不是已经识别某个真实因果变异。若直接观测因果变异且效应与环境作用稳定，某些迁移障碍可以减轻，但仍需考虑目标方差、非加性背景和测量定义。把“可能更易迁移”写成“必然跨群体有效”，同样超出推导。

当目标条件差异不可直接估计时,可作有依据的敏感性分析。由柯西不等式,交叉项的绝对值至多为

$$2\sqrt{E_T\{(f - m_S)^2\}}\sqrt{E_T(\delta^2)}.$$

这提供了在给定条件变化幅度下的风险范围,而不能给出唯一修正。真正减少不确定性仍需要具有代表性的本地资料,尤其要覆盖源模型未辨认的单倍型、环境和性状测定范围。迁移分析的价值在于指出应补充什么信息,不是把资料缺口转成一个无法核验的精确系数。

目标测定制度改变也是条件变化的一部分。相同性状名称下,不同年龄窗口、仪器校正、饲养阶段或淘汰定义,可能改变条件均值与残差。此时仅调整遗传频率不会恢复可比性,应该先建立测量对照和性状映射。若映射需要目标表型估计,它属于适配步骤,应在训练边界内完成,再用独立目标记录检验。把测量校正默认为无误差,可能低估后续迁移风险。

当目标输入范围没有源样本覆盖时,密度比本身不能提供答案。无穷或极大的权重意味着支持不足,而不是计算精度不够。截断权重可以降低方差,却改变目标风险;应说明哪些区域被弱化,并保留相应不确定范围。增加源群体内部已有类型的动物,未必比测量少量具有新遗传背景的本地动物更有用。覆盖缺口需要数据设计回应,而不只是更复杂的拟合。

29.20 本地适配的借力强度与负迁移条件

源群体资料可以为小目标群体提供有用先验,但借力过强会把源偏差带入本地预测。局部校准只调整少数均值与尺度参数,效应层面的适配则允许遗传方向发生变化。两者应按目标数据能支持的程度选择,而不应以模型名称替代偏差与方差计算。

设目标数据满足 $y_T = X_T b_T + e_T$, 残差方差为 $\sigma^2 I$ 。将源估计 b_S 暂视为给定先验中心, 令

$$b_T \sim N(b_S, \tau^2 I).$$

后验均值可以写为源效应加本地修正：

$$\hat{b}_T = b_S + (X_T^T X_T + \lambda I)^{-1} X_T^T (y_T - X_T b_S), \quad \lambda = \frac{\sigma^2}{\tau^2}.$$

相应后验协方差为

$$C_T = \sigma^2 (X_T^T X_T + \lambda I)^{-1}.$$

当本地资料信息充分时，修正主要由本地残差决定；当某方向完全没有本地变化时，该方向的均值停留在源中心，方差则仍保留先验不确定性。小样本适配并没有在所有方向上同时学会本地效应。应检查信息矩阵的有效方向，而不仅报告本地动物总数。

在一维情形，设本地无偏效应观测为 z ，方差为 v 。后验均值为

$$\hat{b} = (1 - w)b_S + wz, \quad w = \frac{\tau^2}{\tau^2 + v}.$$

暂把真实目标效应 b_T 固定，记源偏差为 $\Delta = b_S - b_T$ 。这个估计的重复抽样风险为

$$\mathcal{R}(w) = (1 - w)^2 \Delta^2 + w^2 v.$$

第一项是借用源偏差的代价，第二项是本地测量噪声的代价。若知道真实偏差，最优权重为

$$w_{\text{oracle}} = \frac{\Delta^2}{\Delta^2 + v}.$$

它是帮助理解的理论参照，不能直接用于实际选择，因为目标效应未知。实际需要可靠层级模型、独立适配验证或对偏差幅度的敏感性分析。

取源效应 $b_S = 1$ ，本地观测 $z = 0.2$ ，观测方差 $v = 0.04$ ，先验偏移方差 $\tau^2 = 0.09$ 。则 $w = 9/13$ ，适配均值为

$$\hat{b} = \frac{4}{13} \times 1 + \frac{9}{13} \times 0.2 = 0.446154.$$

模型内后验方差为 $0.09 \times 0.04 / 0.13 = 0.027692$ 。若真实目标效应恰为 0.2，在重复本地抽样下，源偏差为 0.8，实际均方误差为

$$\left(\frac{4}{13}\right)^2 (0.8)^2 + \left(\frac{9}{13}\right)^2 (0.04) = 0.079763.$$

它大于只使用本地无偏观测的风险 0.04。较窄的模型内后验方差没有保护分析免受错误先验中心影响。该例说明负迁移可以在完全正常的数值计算中出现，不能只靠收敛诊断发现。

对 $0 \leq w < 1$ ，借力优于仅用本地观测的条件可由 $\mathcal{R}(w) < v$ 整理为

$$\Delta^2 < \frac{1+w}{1-w}v.$$

刚才的权重使右侧为 0.22，而实际偏差平方为 0.64，条件不成立。若源与目标十分接近，借力则可能显著降低噪声。这个明确边界使“共享还是分开”的争论转化为对效应差异与本地精度的估计，而不是一种永久适用的策略。

源估计本身若也不确定，不能再把 b_s 视为常数。可以将源估计协方差加入层级模型，并保留与目标资料的可能重叠；同一批动物在源与目标数据库重复出现时，独立先验与似然的表达会重复使用信息。多群体联合模型有助于一致处理，但其群体间协方差仍需数据或透明约束支持。

最后，本地适配的性能必须由未参与适配的目标动物检验。可以分别比较只调截距、调截距与斜率、共享效应加本地修正和完全本地模型，并在相同未来家系或时间窗口评价。若资料极少，应承认区间较宽，并用新增本地测定逐步更新证据。适配成功的含义，是在明确目标、资料成本与独立验证下获得可重复收益，而不是把源模型输出调整得更像本地已知结果。

29.21 本章练习与参考答案

练习 29.1 验证集中预测值与校正表型的相关为 0.30，匹配遗传力为 0.25。在表型相关换算公式的条件下，估计准确性是多少？如果残差与预测值相关，还能这样换算吗？

答案： $0.30/\sqrt{0.25} = 0.60$ 。若残差与预测相关，协方差分解出现额外项，换算不再成立；应追查共享环境、表型校正或信息泄漏。

练习 29.2 目标值对预测值回归的斜率为 0.8，是否意味着预测差异过小？

答案：不是。在所述回归方向下，预测差异偏大，需要乘约 0.8 才与目标尺度相符。若回归方向写反，不能沿用同一解释。

练习 29.3 某模型在随机划分中相关 0.65, 在整父系家族留出中相关 0.35, 应选择哪个数字用于宣传?

答案: 应同时报告并解释其用途。若部署目标是新家系, 0.35 更接近相关场景; 若是现有家系内补预测, 随机划分可能更相关。不可挑选较高数字而隐去划分条件, 还应提供不确定性和家系构成。

练习 29.4 某模型在两个目标亚群的平均绝对误差分别为一和三。验证集中二者各占一半, 实际部署中分别占 0.2 与 0.8。求未经加权和面向部署的损失, 并说明需要哪些条件才能用重加权替代新验证。

答案: 未加权损失为二, 部署损失为 $0.2 \times 1 + 0.8 \times 3 = 2.6$ 。重加权要求各亚群内部测试动物能够代表部署动物, 测定定义及条件预测关系相容, 并且所有重要目标范围都有测试覆盖。若第二亚群的环境或单倍型在部署时又发生变化, 仅改比例不能修复失配。应同时报告分层结果与权重来源, 不能根据模型表现选择更有利的部署比例。

练习 29.5 设 u 、 ϵ 与 δ 均零均值, $\text{Var}(u) = 2$, 两种误差方差均为二, 与 u 独立, 误差间协方差为一。预测为 $u + \epsilon$, 代理为 $u + \delta$ 。求预测对真值的准确性及预测与代理的相关。

答案: 预测方差为四, 与真值协方差为二, 所以准确性为 $2/\sqrt{4 \times 2} = 1/\sqrt{2}$ 。预测与代理协方差为三, 两者方差均为四, 故相关为 0.75。较高代理相关的一部分来自共享误差。若误差协方差改为零, 代理相关降至 0.5, 预测本身的真实准确性不变。因此, 选择代理时既要考虑其精度, 也要检查它与预测的信息重叠。

练习 29.6 五只目标动物的遗传协方差为 $0.7I + 0.311'$, 均值相同。求跨动物样本方差的期望。能否直接使用个体方差一作为中心化群体差异的方差?

答案: 中心化矩阵满足 $J\mathbf{1} = 0$ 、 $\text{tr}(J) = 4$, 故期望样本方差为 $\text{tr}(J \times 0.7I)/4 = 0.7$ 。共同方向被中心化消去, 个体边际方差一不等于群体内部差异方差。这个结果依赖所给等相关结构与共同均值; 真实选择群体还应考虑不均等亲缘、不同均值及条件分布, 不能把 0.7 当作一般修正系数。

练习 29.7 某验证有五十个独立家系，每家二十只动物，研究误差均值时组内相关为 0.1。在等组大小模型下求设计效应和近似有效样本量。如果把一千只动物独立自助抽样，可能发生什么？

答案：设计效应为 $1 + 19 \times 0.1 = 2.9$ ，近似有效样本量为 $1000/2.9 \approx 344.83$ 。独立个体抽样会破坏家系内依赖，通常低估该均值的不确定性。可按家系重抽样或使用相容协方差模型，但该设计效应不能直接套给所有相关系数和 LR 比值统计。若家系跨场且有额外环境相关，还需处理交叉结构，五十家系也不是在所有意义下完全独立。

练习 29.8 拟把大商业品种模型用于只有三百只有表型动物的地方品种。请提出能够区分直接迁移、校准适配和重新训练收益的研究设计，并说明怎样避免夸大外推。

答案：先固定源模型，在未参与任何适配的目标动物上评估直接迁移。再在目标训练部分按预定规模取样，分别只估计截距、估计截距与斜率、以及进行部分共享或本地重训；所有调参在目标训练内部完成。使用相同外层目标动物比较，并按未来家系或时间划分，报告宽度适当的区间。检查频率、单倍型、表型定义和环境覆盖，不能仅凭总体遗传距离判断可迁移性。若资料太少，可开展严格嵌套的探索分析，同时安排新的前瞻批次确认。所得结论限定于实际覆盖的地方品种和管理条件，不能据此承诺其他物种或完全未测环境的表现。

第九篇研究前沿

第九篇

PART IX

前沿数据与智能育种

全基因组序列、多组学、高频表型与深度学习正在扩展可利用信息的边界。本篇把这些新数据与新方法放回可识别、可验证的统计框架。

第 30 章 全基因组序列、泛基因组与结构和稀有变异

第 31 章 多组学、功能先验与因果推断

第 32 章 基因与环境互动、韧性和可持续育种

第 33 章 深度学习与基因组基础模型

全基因组序列、泛基因组与结构和稀有变异

30.1 序列时代的育种问题：测得更多之后还缺少什么

一位育种工作者已经拥有覆盖主要家系的芯片参考群体，并建立了稳定的基因组评定。如果再获得全基因组序列，首先应当期待什么？最直接的答案是看见更多变异；更重要的问题却是，这些新增变异是否改变了对候选动物可遗传差异的判断。芯片标记可以通过连锁不平衡间接追踪未测因果位点，所以直接测到某个因果变异，并不必然使同一群体内的预测明显改善。另一方面，短期内没有改善排序也不意味着序列没有价值。它可能帮助识别致死隐性缺陷，区分跨品种改变连锁相位的信号，或者揭示影响未来选择反应的稀有遗传来源。序列资料的价值必须相对于一个明确决策来界定。

可以把研究目标分成测量、定位、解释和决策四层。测量层关心某动物到底携带什么变异，错误率多高。定位层关心哪些变异与性状差异相关，以及能否把多个连锁候选缩小为较小集合。解释层关心变异怎样影响表达、剪接、蛋白或发育。决策层则关心在成本、时间、近交和生产目标约束下，利用这些信息是否改善选择与配种。四层之间存在联系，但没有自动通道。较高的比对率可以支持更可靠的测量，不能单独证明经济收益；细胞中的功能效应可以支持机制，却不能直接代表复杂性状在整个育种群体中的替代效应。

讨论“全基因组”还要区分测序与完整观测。测序仪提供的是带有误差的局部读段；它们经过比对、组装、变异识别和分型，才成为分析矩阵。重复区域、拷贝数复杂区、性染色体及结构重排区可能仍然缺少可靠信息。覆盖度也不是均匀分布的：平均覆盖足够，并不保证某个关键区域具有同样的数据质量。因此，不能把文件名中的“全基因组”当作每个位点无缺失、无

误差的保证。一个谨慎的数据说明应陈述可以可靠评价的区域，以及被流程系统排除的区域。

统计上，新增位点同时带来信息和参数。假设一组芯片已经能近似表示群体主要遗传关系，新加入数百万高度相关位点可能主要重复已有方向，而少数真正新增方向又可能包含较大测量误差。若所有效应采用相同弱收缩，估计方差会增加；若使用过强且不合适的功能先验，则可能放大错误注释。这解释了为什么“更多变异”不是“更高准确度”的同义词。研究设计应分别衡量覆盖改善、测量可靠性、独立信息及计算代价，而不以位点数作唯一成功标准。

本章沿一条具体路线展开：先辨认变异的对象与表示，再讨论不确定性如何进入模型，随后研究泛基因组、稀有变异与多核预测，最后把证据转为可验证的育种方案。贯穿全章的尺度是加性育种值 u ，但在隐性缺陷、结构效应和群体资源保护中，有些重要决定并不能只由 u 概括。理解何时应扩展模型，何时应保留一个独立的风险约束，比把所有信息压成一个综合分数更为重要。

30.2 变异是生物事件，也是统计编码

单核苷酸变异通常以一个位置上的等位基因替换表示；插入和缺失涉及一段序列的有无；倒位改变方向；重复和拷贝数变异改变片段数量；复杂重排可能同时涉及多个变化。结构变异常以 50 bp 作为操作性长度界限，但这个界限服务于工具与研究之间的交流，并不是生物学效应突然改变的边界。一个短小调控插入可以有显著功能影响，一个很长且位于冗余区域的变异也可能几乎不改变研究性状。长度、功能和可分型程度应分别记录。

把结构变异编码为 0、1、2，必须说明它数的是什么。对于一个明确的双等位缺失，可以令 x_i 表示缺失等位基因拷贝数；对于某基因区域的拷贝数，则总拷贝数可能为 0、1、2、3 或更多，其测量误差和效应关系都不同。两个动物总拷贝数相同，也可能具有不同的单倍型组成。例如一个动物的两个同源染色体各有两份拷贝，另一个是一份与三份，总数都为四，但分离后

代时的结果不同。忽略相位可能不影响某些当代表型回归，却会影响配种风险与传递预测。

统计编码还决定了参数解释。若一个双等位位点的计数从替代等位基因改为参考等位基因， $x_i^* = 2 - x_i$ ，则相应线性效应符号反向，而预测在截距同时调整后完全可以相同。若只改编码而没有改效应符号，就会得到相反的选择结论。参考等位基因并不等于有利、常见或祖先等位基因，它只是相对于所用参考序列的命名。合并不同队列时，必须检查组装版本、正负链、参考和替代方向，尤其不能只凭染色体与位置相同认定位点一致。

多等位变异需要避免不必要的线性依赖。设一个位点有三个等位基因，计数为 x_{i1}, x_{i2}, x_{i3} ，二倍体条件下三者之和恒为 2。若模型同时包含截距和三个自由效应，参数便不可唯一识别。可以选择一个基准等位基因，或者施加适当的和为零约束；两种参数化可以产生相同拟合，却给出不同表面数值。推断时应讨论可估的等位基因差异，而不要解释一个在任意约束下产生的孤立系数。

显性与非线性拷贝效应也不能通过“标记多一些”自动处理。若杂合缺失对功能有补偿，而纯合缺失导致严重后果，简单加性剂量会把两种变化强行放在同一条直线上。用于平均育种值预测时，加性近似可能仍有意义；用于携带者配种时，必须显式考虑后代基因型概率。对于拷贝数，可以先比较类别模型、线性趋势和有生物依据的分段关系，再判断数据是否支持额外复杂度。若某一拷贝类别只有极少动物，漂亮的非线性曲线往往只是外推。

一份可以用于长期评定的变异记录，至少应把“事件描述”和“分析编码”分开保存。事件描述保留序列、断点或不确定区间、来源和分型方法；分析编码则保留用于当前模型的剂量、中心化频率及效应方向。这样，在参考组装更新或模型改变后，不必把原始生物事实重新猜测一遍。数据可追踪性不是附加行政负担，而是让统计结果仍能对应到真实动物和真实遗传事件的必要条件。

30.3 从读段到基因型：似然、先验和剂量

测序分型的逻辑可以从一个二等位点讲起。假设某动物有若干读段覆盖此处，其中一部分支持参考等位基因，一部分支持替代等位基因。杂合子不必正好出现一半一半，因为抽样误差、读段质量和比对偏好都会改变观察。基因型似然回答的是：如果真实计数 x 分别为 0、1 或 2，当前读段出现的可能性各是多少。把这个似然与基因型先验相乘并归一化，得到后验基因型概率。似然描述测量证据，先验描述观察前的知识，两者不能混为一谈。

令全部测量信息为 D ，则剂量为

$$d = E(x | D) = P(x = 1 | D) + 2P(x = 2 | D).$$

剂量是一种有用压缩，因为在给定线性效应时，后验均值可以直接由它计算。但它并不是全部分布。后验概率 (0.5, 0, 0.5) 与 (0, 1, 0) 的剂量都是 1，前者在两个纯合子之间完全不确定，后者明确支持杂合子。若任务是预测一个加性均值，两者可能给出相同中心值；若任务是判断是否存在隐性致死纯合风险，二者的决策含义截然不同。

例 30.1 剂量相同不等于信息相同。某缺失位点的后验概率为 (0.10, 0.70, 0.20)。剂量为 1.10，后验二阶矩为 $0.70 + 4 \times 0.20 = 1.50$ ，故后验方差为 $1.50 - 1.10^2 = 0.29$ 。若位点效应暂视为已知的 2 个单位，则位点贡献均值为 2.20，因基因型不确定性而产生的贡献方差为 1.16。硬判为杂合子会把均值改成 2，同时把这一误差来源人为设为零。这里尚未计入效应估计误差和其他位点的不确定性。

先验选择在低覆盖数据中尤其重要。若先验频率来自与目标动物明显不同的品种，少量读段可能不足以抵消不合适的先验。采用家系信息可以显著缩小基因型可能性，但错误亲本也可能把错误系统地传播给后代。因此，分型流程中的家系校正应与亲子关系核验共同使用。对某些稀有位点，完全按照全群体频率先验收缩，还可能使真正的地方品种特有等位基因更难被识别，这正是参考代表性影响下游推断的一条路径。

剂量不确定性还可能在个体之间相关。多个亲属共享参考单倍型，或者同一批次的比对错误作用于相同区域时，错误不再像独立测量噪声那样简单

抵消。把每个剂量看作独立且无偏的连续观测，是计算方便的近似，而不是由“剂量”这个名称保证的事实。对家系内聚集的稀有信号，应特别检查是否存在共同技术来源，并比较不同分型证据是否支持同一传递模式。

在研究报告中，同时提供概率与硬判结果往往比只给一种编码更有信息。群体预测可以使用剂量；关键隐性缺陷可以设定更严格的后验阈值并安排独立检测；低置信位点可以保留为未定，而不是被迫分入普通类别。未定并不是分析失败，它是对当前信息边界的准确表达。后续是否值得补测，应由误判代价和额外检测价值决定。

30.4 关系矩阵怎样传播基因型不确定性

经典基因组关系矩阵通常由中心化基因型的外积形成。对于第 j 个位点，设基准频率为 p_j ，中心化计数为 $w_{ij} = x_{ij} - 2p_j$ 。在分型完全确定时， $w_i w_i^T$ 可以直接计算；分型不确定时，正确的条件期望涉及二阶矩，而不仅是把 x 换成剂量 d 。对一个个体、一个位点，有

$$E[(x - 2p)^2 | D] = (d - 2p)^2 + \text{Var}(x | D).$$

这个恒等式解释了为什么仅采用剂量外积可能降低关系矩阵的对角线。剂量越接近基准均值，外积越小，但这既可能因为动物确实接近均值，也可能因为测量信息很少、后验被收缩到均值。两种情况对应不同的不确定性。如果把信息不足误当作遗传差异很小，就会影响遗传方差尺度和预测误差的解释。

对两个个体 i 和 k ，相应二阶矩为

$$E[(x_i - 2p)(x_k - 2p) | D] = (d_i - 2p)(d_k - 2p) + \text{Cov}(x_i, x_k | D).$$

若后验基因型在个体间条件独立，非对角修正项为零；如果利用共同家系或共享单倍型进行联合插补，这个条件未必成立。进一步考虑不同位点效应和相位时，误差还可能跨位点相关。因此，完整地不确定基因型积分，与在每个单元格中保存一个方差然后简单相加，也不是完全同一件事。实际大规模流程可以采用近似，但应说明忽略了哪些依赖。

从预测角度看,若已知标记效应向量为 a ,位点贡献为 $u = w^T a$,则其条件均值为 $E(w | D)^T a$,条件方差为 $a^T \text{Var}(w | D) a$ 。这说明相同平均剂量的两个动物,仍可能需要不同的预测区间。若效应 a 也由有限训练集估计,还需要同时考虑其后验或抽样不确定性。一般不能把基因型方差和效应方差各算一次后完全独立相加,因为它们可能通过共同数据相关。

教学上可以用多次后验抽样理解积分:每次按照联合后验产生一份可能的基因型矩阵,完成同一分析,再汇总预测均值与分布。这个思路强调了不确定性,而不是把一份插补矩阵当作唯一真相。不过,多重抽样的正确性依赖生成的分布是否校准。若插补模型漏掉了某类变异,重复抽样也只会错误模型内表现得很稳定。计算次数不能修复系统遗漏。

在例行育种评定中,完全联合积分可能代价过高。可以针对不同用途采用分层策略:普通位点以剂量近似进入预测,低质量区域在关系计算中降权或排除,影响重大配种风险的位点使用独立高置信检测。降权规则应依据测量质量和训练内验证,而不是依据最终测试表现反复改变。还应检查降权是否系统性削弱某一品种或某类动物的信息,以免技术质量差异转化为不公平的评定精度差异。

30.5 低覆盖测序与插补:评价的单位决定结论

低覆盖测序与参考面板插补的组合,将大量个体的少量直接信息与参考单倍型结合起来。它的优势主要在于资源分配:同样预算下,可以扩大被分型动物数,并借助已有群体结构恢复部分未直接观测位点。但是,插补并不创造参考面板中不存在的可靠单倍型。对于地方品种、稀有家系或新突变,参考覆盖不足仍是根本限制。大量常见位点插补良好,也不能推出这些特殊对象同样可靠。

评估指标必须与用途相配。总体基因型一致率容易被常见纯合子主导。假设某稀有替代等位基因频率为 0.005,在随机交配近似下,杂合子比例约为 0.00995,替代纯合子比例为 0.000025。若一个毫无识别能力的算法把所有动物都判为参考纯合子,它仍可取得约 99.0% 的总体一致率,但对真正携

带者的灵敏度为零。这个例子表明,对于风险位点,携带者识别、阳性预测值和未定比例往往比总体一致率重要。

例 30.2 相同一致率背后的不同决策。在 1000 头动物中,真实携带者有 20 头。流程甲识别出 18 头真实携带者,同时误报 12 头;流程乙识别出 14 头,同时误报 2 头。甲的携带者灵敏度为 90%,阳性预测值为 60%;乙分别为 70% 和 87.5%。若漏掉携带者的代价很高,甲可能适合初筛,再对 30 头阳性者复核;若检测用于直接淘汰且复核不可行,甲的误报代价就更突出。不能脱离后续处理方式,仅以某一个准确率给两流程排序。

剂量相关的平方常用于评价插补,但要明确其计算对象。利用软件内部模型得到的质量估计,不等于与独立高质量基因型逐一比较得到的经验相关。不同频率类别中的相关也可能具有很大抽样波动;若一个位点在验证集中几乎不分离,相关系数甚至难以稳定定义。报告时应同时给出频率、有效携带者数量和分层结果,而不是把所有位点合并为一个漂亮均值。

插补验证还应避免亲缘与时间条件过于理想。若验证动物的近亲全都出现在参考面板中,结果可以很好地代表当前核心育种群,却未必适用于远缘引入群体。可以设置符合部署目的的留出:留个体评价已有家系中的年轻候选者,留家系评价新家系,留品种评价跨品种迁移。三种结果并不矛盾,它们衡量的是不同程度的信息共享。参考面板不断更新时,还要记录每次评定使用的版本,避免把后来的信息带回过去。

在实际方案选择中,测序深度、参考面板规模和直接表型测定共同竞争预算。增加深度可能改善难分型区域,但减少了能覆盖的动物;增加面板动物可以覆盖更多单倍型,但如果它们高度近亲,新增信息可能有限;扩大表型参考群体则可能比追求极高密度更直接地提高效应估计。合理设计应围绕目标性状、群体结构和误判代价比较完整方案,而不仅比较单份基因型的价格。

30.6 泛基因组的表示：从一条参考到多条可追踪路径

单一参考把每条染色体表示为一条线性序列，所有样本的读段都要映射到这套坐标。这个方式便于计算与交流，却把不存在于参考中的序列置于困难位置。若某品种有一个参考中没有的插入，来自该插入的读段可能无法比对，也可能被放到相似区域。随后形成的缺失、深度或 SNP 信号会同时受到生物差异与参考偏好影响。泛基因组的基本思想，是用多个个体的序列共同描述群体变异，而不是要求所有差异都服从单一序列的表达能力。

泛基因组可以采取不同形式。最简单的补充序列集合把参考之外的序列附加进来，有助于发现过去遗漏的内容，但不一定提供完整的相位与染色体路径。图表示则用节点和边组织共有片段及替代连接，每个已组装单倍型可被表示为一条路径。这里的图首先是序列数据结构，并不直接等于遗传调控网络。图上的相邻关系说明序列如何连接，不说明哪个基因调控另一个基因。把这两类“网络”混淆，会导致不恰当的机制解释。

一个好的图参考既要表达差异，也要保留可解释的对应关系。如果同一复杂事件被拆成多个图分支，下游分析应知道这些分支是否属于同一个生物变异。若在群体矩阵中把完全共现的分支当作独立位点重复计数，就可能给某一事件过高权重。相反，过度合并也会把功能不同的等位形式混为一类。图构建、变异导出和统计建模之间需要明确约定：分析单元是图分支、标准化变异、基因片段还是完整单倍型。

对育种群体而言，图参考的代表性至少有三个维度。第一个是主要品种与地理来源，第二个是群体内部的家系和单倍型，第三个是技术上难以表达的区域。只增加同一主流品种中的近亲组装，可以改善该群体内的细节，却不能充分代表地方品种的特有序列。只按表型极端挑选组装个体，也可能使图资源偏向与当前生产性状有关的家系。构建资源时，应在遗传多样性覆盖与育种用途之间作出明确取舍。

Azam 等（2025）以印度地方牛的短读长资料构建补充非参考序列的泛基因组，说明主流参考之外仍有值得记录的群体差异。这个结果支持改善代表性，而不意味着短读长补充序列集合已经解决全部复杂结构和相位问题。

研究中使用的“新增序列”也应结合污染排除、重复折叠及独立组装支持解释。对于任何新资源，新增内容的可靠性比新增碱基数本身更接近后续育种价值。

泛基因组更新还改变了版本管理问题。在线性参考中，一个位点通常可用染色体、位置和等位序列标识；图版本更新后，节点编号可能改变，某条路径也可能被重新组织。因此，不能把易变的内部节点编号直接当作长期唯一生物标识。应保存原始等位序列、所在单倍型上下文和跨版本映射，并在数据合并时检查一对多、多对一或无法映射的情况。少量无法可靠转换的变异应明确保留其状态，避免静默删除后改变分析集合。

从教学角度可以把图参考理解为“更宽的测量语言”。它允许研究者表达单一参考较难描述的差异，却不会自动保证每条表达都正确，也不会自动给出每个差异的效应。后续仍要评估分型、频率、遗传关联和预测增量。对一个尚无丰富测序资源的地方肉羊群体，先建立可靠身份、表型与核心家系测序，可能比立即追求最复杂图结构更有成效；技术路线应服务于数据能够回答的问题。

30.7 结构变异的证据链：发现不等于可靠分型

结构变异检测往往综合多种信息。读段深度可提示拷贝数变化，跨断点的读段可支持连接改变，成对读段的距离或方向异常可提供重排线索，长读段和组装可以更直接地跨越复杂区域。每种证据都有自己的失败方式：深度受到 GC 组成与扩增偏差影响，短读段在重复区可能多重比对，组装可能把相近重复折叠，断点附近的小差异又可能改变事件表示。因此，多种证据一致比单个得分很高更有说服力，但一致也必须来自真正不同的信息来源。

一个发现流程擅长判断“群体中存在某事件”，不一定同样擅长判断“每个个体有几份该事件”。将发现集导入更多动物后，分型误差可能成为限制因素。尤其是复杂插入和多等位区域，事件边界不一致会使同一变异在不同样本中被拆成不同条目。随后计算频率时，研究者可能误以为发现了多个稀有变异，实际上它们只是同一事件的不同表示。标准化与聚类规则必须在关

联分析前确定，并保留原始证据供检查。

家系传递是重要的质量证据，但不能简单把所有违反孟德尔规律的记录都认定为技术错误。少数真实新突变、性染色体的特殊传递、嵌合或亲本未被准确分型，都可能产生表面不一致。反过来，一种系统性错误也可能在整个家系中一致出现，从而通过传递检查。因此，应将家系一致性、覆盖证据、独立平台复测和序列上下文联合使用。对于将直接影响种畜淘汰或禁配的位点，确认标准应高于探索性关联研究。

结构变异的效应可能跨越多个层次。删除一个调控片段可能改变组织特异表达，基因重复可能改变剂量，也可能被调控补偿；倒位可以改变重组模式或把原本相距很远的片段连接起来。这些机制提示我们寻找更合适的性状和组织，却不能代替效应估计。即使某变异影响一个关键基因，生产性状上的方向仍可能受到生理反馈和其他位点背景影响。把功能注释中的“损失”直接翻译为经济性状上的“负效应”，是常见而危险的跨尺度推断。

例 30.3 结构变异复核中的条件概率。假设某初筛检测对携带者的灵敏度为 0.95、特异度为 0.98，目标群体携带者比例为 0.02。10000 头动物中，期望真实携带者 200 头，初筛阳性携带者 190 头；其余 9800 头中期望误报 196 头。因此，初筛阳性者真正携带的概率仅为 $190/(190 + 196) = 0.4922$ 。虽然两个检测性能数字都很高，稀有性仍使误报占据大量阳性。若阳性必须进一步独立复核，应按照两个检测误差是否相关计算联合结果，不能不加检查地把假阳性率相乘。

这类计算有直接管理意义。若仅凭初筛阳性淘汰动物，不仅可能损失有价值的种畜，还可能因某些家系的技术质量较差而造成偏向。更合理的流程是把初筛用于缩小复核范围，把独立复核用于支持高代价决策。若复核证据仍不一致，可以保留不确定分类，并通过配种安排暂时降低风险。统计上承认未定，比把不充分证据包装成确定结论更能保护长期育种资源。

Yang L 等（2026）将荷斯坦泛基因组结构变异扩展到大规模插补与性状关联，展示了从组装资源走向群体分析的路线。其研究涉及 50,299 头公牛和 43 个复杂性状，并对候选结构变异进行优先排序。这里的关联与候选证据不能直接当作跨世代选择增益。对育种应用，仍需独立检验新增变异是否

改善校准、迁移或特定风险决策。




图 30.1 稀有携带者检测的阳性预测值。灵敏度固定为 95%，曲线由贝叶斯公式计算；真实携带率越低，对特异度的要求越高。橙色点对应例 30.3 的教学参数

30.8 稀有变异为什么难：数量、亲缘与效应可识别性

稀有变异的困难不是位点标签中写着“稀有”，而是携带信息集中在很少的独立遗传背景中。二倍体样本量为 n 、等位基因频率为 p 时，期望替代等位基因数为 $2np$ 。但这个数量只是第一步：十个拷贝分布在十个不相关家系，与十个拷贝全部来自同一祖先的后代，提供的效应识别能力不同。后者可能与该家系的共同环境、其他连锁位点和管理历史难以区分。有效信息取决于可比较的遗传背景，而不仅是总拷贝数。

稀有性也影响统计检验的参照分布。一个位点只有两三个携带者时，连续表型的极端值、亲子关系错误或一次测定批次异常，都可能主导结果。即使混合模型在总体上控制了亲缘，局部稀有信号仍可能对单个家系非常敏感。研究者应检查移除某个携带家系后结论是否完全消失，并考察效应估计的区间，而不是只看最显著的 p 值。这样的敏感性分析不是事后否定结果，而是明确结果依赖哪些信息。

频率与效应之间还存在一个统计尺度问题。在简单加性模型中，一个双

等位位点的方差贡献为 $2p(1-p)a^2$ 。若 p 很小, 较大的替代效应也可能只贡献少量当前群体方差; 但对携带动物或未来频率改变后的群体, 它仍可能重要。反过来, 常见小效应位点可以共同贡献大量方差。不能仅根据某个位点的效应绝对值排列其群体育种价值, 也不能仅根据当前方差贡献忽略严重隐性缺陷。

例 30.4 效应大与方差大是两回事。位点甲频率为 0.01、加性效应为 2, 方差贡献为 $2 \times 0.01 \times 0.99 \times 4 = 0.0792$ 。位点乙频率为 0.30、效应为 0.5, 方差贡献为 $2 \times 0.30 \times 0.70 \times 0.25 = 0.105$ 。甲的效应是乙的四倍, 当前方差贡献却更小。若甲的频率以后升到 0.10, 在效应保持不变的假设下, 其方差贡献变为 0.72; 这一计算说明频率改变会改变群体方差, 不代表效应一定能跨背景保持稳定。

稀有变异的选择还会与保护多样性发生联系。一个携带不利隐性等位基因的优秀公畜, 可能同时携带有价值且稀缺的遗传组合。直接淘汰全部携带者可以降低风险, 却可能缩小有效群体并损失其他有利信息。另一种策略是在可靠检测基础上避免携带者之间的高风险交配, 逐步降低不利等位基因频率, 同时限制个体贡献。两种策略的优劣取决于缺陷严重性、检测可靠性、携带率、可替代亲本和长期群体目标, 不能用单一口号处理。

对于新突变, 还应区分“首次在本数据中观察到”与“真正的新生突变”。一个变异未出现在参考面板, 可能只是面板规模不足; 亲本中未检测到, 也可能由于低覆盖或组织嵌合。真正的新突变确认需要更强的家系和测量证据。若把所有数据库中未收录的变异都称为新突变, 会同时夸大发现的生物学意义和对育种潜力的解释。

稀有变异研究的合理目标往往是建立可积累的证据。第一批样本可以形成候选和检测方法, 后续家系提供传递与重复性信息, 再结合功能数据与独立群体评价。对尚无足够样本估计稳定效应的位点, 可以保留其风险级别与不确定范围, 而不强行给出精确育种权重。承认当前数据只能支持候选优先级, 是严谨研究的一部分。

30.9 集合检验：把稀少信息聚合到有意义的单位

当单个位点信息不足时，可以把多个变异按基因、调控区域、通路或其他生物定义组成集合。聚合的好处是减少需要分别估计的参数，可能把若干弱信号合成可检测的总体信号；代价是引入集合结构假设。若集合中多数位点没有作用，聚合会稀释信号；若有作用位点方向不同，简单相加可能互相抵消；若集合边界按观察到的结果反复调整，则显著性评估会受到选择偏差影响。集合本身因此是模型的一部分。

最简单的负荷变量为 $B_i = \sum_j w_j x_{ij}$ ，再将 B_i 与性状关联。它相当于假定集合内效应与预定权重具有共同方向和相对结构。若不利功能缺失大多使某种功能下降，这种假设可能有生物依据；若同一基因中不同变异可以提高或降低表达，假设就可能不合适。权重可以体现频率、注释或测量质量，但每种权重都改变了检验目标。不能把加权后较显著当作该权重必然正确的独立证据。

核或方差分量型方法将集合效应视为可以异号的随机量。若中心化集合基因型为 W ，预定非负权重矩阵为 D ，可构造 $K = WDW^T$ ，检验该集合对应的方差分量是否为零。这类方法不要求所有效应同向，但对效应分布、核选择和协变量处理仍有假设。负荷与核方法没有脱离遗传结构的普遍优劣；一个对同向稀疏效应有效的方法，在正负混合且多数无效的集合中可能表现不同。

一个小例能说明抵消机制。设两个位点对性状的真实效应分别为 1 和 -1，如果某动物在两位点各多一个替代等位基因，真实净贡献为 0。无差别负荷把两个计数相加，会把这种动物排在高负荷端，但高负荷不一定对应更高性状。核方法关注多维基因型相似性与性状相似性的关系，能够容纳这种方向差异。不过，如果样本中两个位点总是完全共现，任何方法都无法单独识别它们相反的效应；统计灵活性不能突破没有观察对比的信息限制。

亲缘群体中的集合检验还要控制背景遗传结构。若某基因集合主要区分两个品种，而两个品种在饲养场区上也不同，集合关联可能只是群体差异的代理。可以在混合模型中加入全基因组背景关系，并注意目标集合附近的标

记是否导致近端信号被背景过度吸收。不同背景处理回答的条件问题不同，应在设计时说明，并通过模拟或适当校准检查错误发现率。单纯把群体主成分加得越多，并不保证所有混杂都被消除。

检验和预测的目标也必须分开。一个集合检验回答“是否存在某种非零关联”，并不直接提供最适合预测的位点效应收缩。显著集合可以用于功能解释或外部验证，也可以在训练内构造先验，但若先用全部样本筛选集合，再在同一批测试个体上评估预测，就会发生信息泄漏。若某集合只有探索性支持，应把其权重当作需要学习的量，而不是在所有后续模型中无条件强化。

报告集合结果时，应列明集合定义版本、变异纳入规则、频率阈值、功能分组、携带者分布和多重检验范围。一个基因显著不意味着该基因中每个变异都有效，也不意味着邻近基因完全无关。能够在独立资料中重现集合层面的方向或关联，通常比从同一数据中挑出一个最漂亮单个位点更有累积价值。

30.10 序列与结构变异进入混合模型

序列数据可以通过标记效应模型进入评定，也可以先构造关系矩阵。设 W_s 和 W_v 分别为中心化 SNP 与双等位结构变异矩阵，采用明确的基准频率，可写

$$G_k = \frac{W_k W_k^T}{2 \sum_{j \in k} p_j (1 - p_j)}, \quad k \in \{s, v\}.$$

这个标准化与二等位计数的方差尺度相联系，不是所有多等位或拷贝数变量的通用公式。对于不同编码，应按相应方差或其他明确规则归一化。关键是让随机效应方差具有可解释尺度，并保证训练与候选个体使用同一基准。如果每次只对新候选群体重新中心化，就可能把真实代际变化混入基准变化。

双核模型可写为 $y = X\beta + u_s + u_v + e$ ，并令两部分协方差分别为 $G_s \sigma_s^2$ 与 $G_v \sigma_v^2$ 。在假设两随机部分独立时，总育种值为 $u_s + u_v$ ，总协方差为两者之和。这里的独立是模型中的效应分布假设，不意味着两类基因型不相关。即使效应先验独立，两个核也可以因为连锁不平衡而高度相似，使方差分量

难以分别识别。

如果 G_s 和 G_v 几乎成比例，资料可能足以估计合并遗传方差，却不能稳定地判断各来源占多少。某个方差分量贴近零，可能说明新增核的信息已经被另一核表达，而不是说明该类变异在生物学上没有作用。相反，把品种差异集中到一个结构变异核，也可能使其分量吸收未建模的环境差异。解释核方差时，应关注核之间的几何相似性、样本设计与固定效应，而不仅关注估计值大小。

例 30.5 合法的核组合与非法的负权强化。 两个个体的 SNP 计数矩阵为 $\begin{bmatrix} 0 & 1 \\ 2 & 1 \end{bmatrix}$ ，两个位点基准频率均为 0.5，得到 $G_s = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$ 。另一个结构变异的计数为 $(0, 1)^T$ ，同一频率基准下得到 $G_v = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}$ 。非负组合 $0.8G_s + 0.2G_v$ 的两个特征值约为 1.8246 与 0.1754，因此可作为协方差核。若人为改为 $1.2G_s - 0.2G_v$ ，行列式为 -0.48，便不再半正定。这个例子的频率来自外部基准，不是由两个示例动物估计。

只要权重非负，半正定核的加权和仍半正定，因为任意向量的二次型都是非负项的加和。这个性质支持多核建模，但不保证权重容易估计，更不保证预测改善。模型选择应把权重学习限制在训练过程，并对外部性能进行独立评价。若样本不足以同时估计很多核，减少核数量或采用层级收缩，通常比保留大量极不稳定方差分量更易解释。

还可以把已知大效应变异作为固定或单独随机效应，同时用全基因组核描述背景。固定处理强调单个位点效应的自由估计，适合信息较充分且需要明确解释的场景；单独随机效应则保留收缩。若位点稀有，固定处理容易过拟合；若其作用在不同群体或环境中改变，统一效应又可能不合适。因此，“因果位点应固定拟合”并不是普遍规则，处理方式仍要服从预测目标、信息量与效应稳定性。

30.11 单倍型、连锁不平衡与定位分辨率

单个标记的计数没有完整表达染色体上的相位信息。同为两个位点的双杂合子，一个个体可能携带 AB/ab ，另一个可能携带 Ab/aB ；两者逐位点的等位基因计数相同，传给后代的组合却不同。当目标涉及复合杂合、顺式调控或某个缺失与邻近替代的共同作用时，相位就成为必要信息。对于一般加性预测，密集标记和关系核有时已能间接利用大部分单倍型关联，因此引入单倍型是否有益仍需验证。

相位可由亲子传递、群体连锁不平衡或长读段提供。三类证据的适用范围不同：亲子信息特别有利于确定跨越长区间的来源，群体方法利用常见组合的频率，长读段则提供同一分子上的局部连接。相位错误会把真实的单倍型拆散或创造不存在的组合，影响稀有复合变异的判断。若一个结论依赖两个远距离变异处于同一条染色体，应明确连接证据跨越了多大区间，而不能把统计相位当作没有误差的直接观察。

设两个双等位位点的等位基因频率分别为 p_A 和 p_B ，单倍型 AB 的频率为 p_{AB} ，则连锁不平衡系数为 $D = p_{AB} - p_A p_B$ 。常用的平方相关为

$$r_{AB}^2 = \frac{D^2}{p_A(1-p_A)p_B(1-p_B)}.$$

它衡量一个位点对另一个位点线性预测的程度。两个位点物理距离很近，仍可能因为频率差异而只有有限 r_{AB}^2 ；没有观察到重组，也不等于一个常见标记能准确区分稀有致因等位基因。对于稀有变异，“在同一单倍型上”与“被高相关标记充分标记”不是同一个命题。

例 30.6 稀有致因变异为什么难被常见标记代替。设致因等位基因频率为 0.01，某标记等位基因频率为 0.50；所有致因等位基因都在该标记等位基因所在染色体上。此时 $p_{AB} = 0.01$ ， $D = 0.005$ ，故

$$r_{AB}^2 = 0.000025 / (0.01 \times 0.99 \times 0.5 \times 0.5) \approx 0.0101$$

尽管致因变异没有出现在另一类标记背景上，标记携带的染色体中仍有大量不含致因变异，故线性标记能力很低。这个例子解释了某些稀有变异直

接分型的价值，也提醒我们不要把“完全同相出现”误读成预测信息完全等价。

高密度序列扩大候选变异集合，却不会自动提高定位分辨率。若一段区域内二十个变异在所有观察动物中具有相同基因型列，任何仅使用这些动物表型的回归模型都无法区分它们的独立效应。增加同样单倍型背景的动物可以提高该区域总体关联的显著性，却不一定拆开候选集合。来自不同重组历史的群体、携带独特重组的家系以及独立功能证据，才可能增加区分这些变异的实质信息。

精细定位通常把区域内候选变异的可能性分配为后验概率，并形成可信集合。可信集合的含义依赖模型是否允许多个因果变异、是否正确描述连锁不平衡以及先验是否合理。当真实结构变异未被纳入候选集合时，后验概率仍会被分配给已观察标记；数值很高并不能修复候选集合缺失。跨群体联合定位也应允许效应或连锁结构差异，不能强迫所有群体共享不适当的单一模型。

功能注释能够帮助区分统计上接近的候选变异，但要避免循环证据：若用某注释定义优先变异，再把优先变异的富集作为该注释正确的独立证明，就重复使用了同一假设。较有力的证据链是先在明确的资料中提出候选，再用独立组织、独立群体、分子实验或预先规定的预测任务检验。对于实际育种，即使具体因果碱基尚未确定，稳定且成本适宜的局部单倍型仍可具有预测价值；然而这种价值对群体背景的依赖必须明确。

30.12 跨品种和跨世代预测：可迁移性的三个来源

序列层面的优势常被表述为“更接近因果，所以更容易跨品种预测”。这个推理有合理部分，但包含三个不同条件。首先，目标群体确实存在该变异，而且测量与编码一致。其次，变异对相关生物过程的作用在目标群体中保留。最后，该生物过程对经济性状和综合目标的贡献仍相近。三个条件中任何一个失效，都可能使源群体的预测规则失准。

标记效应包含致因效应与标记—致因关联的混合。若一个标记在源群体

与有利致因等位基因同相，在目标群体却反相，标记回归系数可以改变符号。直接测得致因变异能减少这一层关联依赖，却不能消除基因互作、环境作用、等位基因替代效应随频率变化等问题。尤其在存在显性和上位性时，用于加性评定的平均替代效应是特定群体背景下的统计量，并非永远不变的分子常数。

一个简单分解有助于理解这些差别。设两个群体的同一位点真实替代效应为 a_1 和 a_2 ，而可测标记与致因变异的相关分别为 r_1 和 r_2 。在单标记近似下，预测效果同时受效应相似性与关联相似性约束。测序主要可能改善后一部分，功能和环境信息则有助于判断前一部分。把“所有变异相同”直接转换为“所有标记效应相同”，会把需要验证的假设当成结论。

对于基因组关系矩阵，中心化基准的选择也影响跨群体解释。若所有个体都使用一个共同频率基准，群体间频率差异会进入关系结构；若各群体分别中心化，群体间的均值差异被去除，矩阵更接近描述群体内部偏离。哪一种更合适取决于固定效应如何定义、育种值相对哪个基准以及是否需要比较群体均值。不能仅凭哪一种让矩阵更接近单位阵，就判定其生物学上更正确。

在混合群体中，可以让不同群体拥有相关但不完全相同的随机效应。例如把源群体和目标群体的效应视为两个性状，使用遗传相关控制信息借用。相关接近一时，源群体信息较容易转移；相关较低时，应允许目标群体获得更多独立参数。这个模型思路与多性状评定相通，但需要足够跨群体连接才能估计相关。样本极少时，复杂群体特异模型容易把噪声解释为真实差异。

例 30.7 参考群体增大不等于可转移信息成比例增加。为教学目的，设目标群体直接训练得到一个无偏育种值估计，误差方差为 4；从外部群体迁移得到另一无偏估计，误差方差为 9，两者误差协方差为 2。组合权重为 $(9 - 2)/(4 + 9 - 4) = 7/9$ 时，误差方差为 $(4 \times 9 - 2^2)/(4 + 9 - 4) = 32/9 \approx 3.556$ 。外部资料确有增益，但远小于把两个样本量简单相加所暗示的增益。若外部估计在目标群体存在系统偏差，还须把偏差平方纳入评价，以上无偏组合公式便不足以决定使用方式。

跨世代预测还受选择引起的频率变化、家系贡献变化和重组影响。模型在同代随机划分中表现优秀，可能主要因为训练集与测试集共享近亲和管理

环境。真正评价将来应用时，应把较早出生的动物用于训练，把之后出生并在当时尚无表型的动物用于测试；必要时还应隔离核心家系或场区。时间外推的性能下降不是模型失败的唯一证据，它也可能揭示原本被随机划分掩盖的任务难度。

最后，迁移评价不能只报告一个总体相关。目标群体中的稀有携带者、不同祖源比例和不同测序批次可能有不同误差分布。总体性能相似时，某些关键家系的系统低估仍会改变选择机会。应在样本量允许的范围内报告分组偏差、尺度和不确定性，并明确小组估计的宽区间。对小群体的尊重不是机械地要求每组结果相同，而是检查模型是否把缺乏代表性的资料当成充分知识。

30.13 参考群体怎样选：覆盖染色体，而不是只数动物

测序参考群体的设计应从其用途出发。如果主要用于提高某个大群体的常见变异插补，代表该群体中广泛传播的单倍型是重要目标；如果主要用于发现地方品种特有变异，则需要覆盖不同祖源和较少代表的家系；如果主要用于验证稀有致死变异，携带者及其亲属的定向测序可能更有效。一个样本集合通常无法同时最优地满足这些目标，因此需要在设计前写清主要用途和次要用途。

按系谱或基因组关系选择不太近亲的个体，可以扩大遗传多样性，但“最不相关”不等于“最有插补价值”。一头极独特且后代很少的动物可能增加新变异发现，却对大量候选动物的插补帮助有限；一头具有广泛后代的祖先即使与现有样本有些相关，也可能覆盖目标群体中重要的单倍型。较合理的设计将多样性、单倍型频率、后代贡献和测序质量放在同一决策框架内。

设目标群体中单倍型类别为 h ，其权重为 w_h ；候选测序动物 i 是否携带该单倍型记为 c_{ih} 。一个简化的覆盖目标是最大化被至少一个入选动物覆盖的加权总量。这个问题与集合覆盖有关，其边际收益通常递减：首次测得一个常见单倍型价值较高，再测一个几乎相同的动物，新增覆盖就较小。实际工作还要考虑双倍体相位、测序深度、单倍型错误和稀有变异，所以该目标

只是设计辅助，而非最终质量保证。

例 30.8 四个候选参考动物的边际覆盖。目标单倍型甲、乙、丙、丁的权重分别为 0.40、0.30、0.20、0.10。动物甲携带前两类，动物乙携带甲与丙，动物丙携带乙与丁，动物丁携带丙与丁。若只能测序一头，选择动物甲覆盖 0.70；若可测两头，再加入动物丁，覆盖达到 1.00。按单头覆盖从高到低直接选择甲与乙，只能达到 0.90。例题说明逐步考虑新增覆盖比简单挑选单头得分前两名更合适；在更复杂问题中，逐步贪心选择也不保证全局最优，应把它作为可解释的近似策略。

参考群体不仅有数量，还有时间结构。持续补充最近世代、具有新重组或新祖源的动物，可能比反复加深已有祖先的测序更有用。另一方面，低质量的新样本会给插补面板引入错误。新增样本必须经过亲缘、性别、样本身份和序列质量检查，且面板版本应可追溯。否则插补质量的变化无法归因于样本增加、算法更新还是编码改变。

参考面板中的缺失不是随机的：某些复杂区域、重复序列和品种特有片段更难组装或分型。这使所谓“全基因组覆盖率”容易掩盖重要盲区。应分别报告变异类型、频率范围和基因组区域的覆盖，而不是只给出一个总体比例。对于商业应用中具有高损失风险的位点，即使总体插补质量很好，也可能需要直接分型或独立实验复核。

参考资源的共享能减少重复投入，但也带来元数据和版本协调问题。品种名称、个体身份、家系关系、测序技术和参考组装版本必须尽量一致。Schlüter-Bartram 等 (2026) 针对 1000 Bull Genomes 资源开展的研究提示，基因组信息本身可以辅助检查部分元数据不一致。这里的启示是把元数据视为需要验证的数据层，而不是将其当作不会出错的标签；统计模型无法自动补救身份错配造成的全部后果。

30.14 从准确率到净收益：序列方案的经济评估

技术方案的价值最终取决于它改变了什么决策。一个模型的相关提高 0.01，可能在大量年轻候选动物的早期筛选中产生可观累积收益，也可能因

为费用过高或无法及时返回结果而没有实际优势。相反, 对一个罕见但高损失的隐性缺陷实现可靠携带者识别, 即使几乎不改变总体育种值相关, 也可能很有价值。因此, 序列方案的经济评估应区分连续性状选择收益、缺陷风险管理和资源保存等用途。

对于连续性状, 简化的每代选择反应表达式仍提供有用起点: $\Delta H = ir\sigma_H$, 单位时间反应再除以世代间隔。测序可能影响准确度 r , 也可能因为费用改变候选数量和选择强度 i , 因为周转时间改变世代间隔, 甚至因为某些家系更容易获得数据而改变有效群体大小。只比较准确度这一项, 容易错过这些相互作用。多阶段选择时, 还应计算早期筛选造成的候选范围限制。

例 30.9 同一预算下的两个测量方案。 设年度用于新增基因型的预算为 60 万元, 方案甲每头 300 元, 可测 2000 头; 方案乙每头 600 元, 可测 1000 头。为隔离不同因素, 假定两方案最终都选留 100 头, 育种目标标准差为 100 单位, 准确度分别为 0.60 与 0.68, 世代间隔相同。在正态截断选择近似下, 选留比例 0.05 与 0.10 的选择强度分别约为 2.063 与 1.755, 故预期反应约为 123.8 与 119.3 单位。尽管方案乙准确度较高, 候选数量减少后总反应反而略低。本例忽略固定成本、亲缘约束和多阶段筛选, 只用于说明准确度必须与选择强度共同评价。

如果序列信息同时减少有害隐性配种, 就需要另外计算风险。设某种高风险配种产生患病后代的概率为四分之一, 单个患病后代的平均损失为 4000 元; 每识别并合理替换一次这样的配种, 理论预期避免损失为 1000 元。但替换配种可能降低综合育种值或增加其他近交风险, 所以净收益并不等于 1000 元。应在配种优化中同时考虑生产目标、遗传多样性和缺陷风险, 而不是简单把所有携带者淘汰。

携带者管理与长期选择尤其需要区分。一头优秀携带者与经可靠检测的非携带者配种, 可以避免该隐性缺陷的患病后代, 同时保留其其他有利遗传背景。若短期内一律淘汰全部携带者, 可能加剧少数非携带家系的贡献集中。长期可逐步降低有害等位基因频率, 但速度应与遗传进展和有效群体大小一起评估。这个判断依赖遗传方式与外显率的可靠证据, 不能对所有“预测有害”变异一概应用。

成本还包括计算、储存、数据治理、样本复采和模型维护。一次性测序费用可能随时间下降，但一个可用于生产的流程必须能重复运行、追踪版本并解释异常个体。算法结果无法在选种时间窗内交付，或者质量报告过于复杂而无法转化为决策，都会降低实际收益。经济评估因而应记录从采样到可行动结果的全过程，而不仅记录每个样本的实验报价。

风险评估宜使用场景或分布。对准确度增益、测序失败率、候选数量和经济权重分别设置合理范围，可以看出方案的优劣是否稳健。如果方案只在极乐观条件下占优，就应先小规模试点；如果在多数合理场景下均有净收益，则可逐步扩大。这样的分析不是替代实验，而是帮助确定实验最值得测量哪些不确定参数。

30.15 可复现的证据链与下一阶段研究

一个可信的序列育种研究，应从变异发现一直追踪到选择决策。第一层是样本和测量证据，包括来源、家系、平台、深度、参考版本和质量控制。第二层是统计证据，包括变异编码、频率基准、模型、超参数、训练测试划分及误差评估。第三层是应用证据，包括在什么候选群体、什么时间点、以何种成本使用结果。任何一层不清楚，后续的高相关或小显著性概率都很难独立解释。

特别需要区分“发现了新的变异”“改进了变异分型”“解释了部分遗传方差”“提高了外部预测”和“实现了育种收益”五种结论。它们可以形成逐步推进的证据链，但后一层并不由前一层自动推出。泛基因组研究发现大量线性参考遗漏的序列，首先证明表示空间更完整；只有进一步证明这些序列被准确分型、与目标性状有关并带来可重复预测增益，才能支持育种应用的更强结论。

研究比较应控制可控条件。若新方法使用更大的训练群体、更严格的表型清洗和不同的测试集，而基线方法没有获得同样条件，则改进不能全部归因于变异类型或算法。较清楚的比较是在同一训练资料、同一测试个体和同一评价标准下，逐步加入序列、结构变异或功能信息；再单独分析数据量和

数据质量变化的贡献。这种逐层比较比一次比较两个完全不同的流程更有解释力。

对于稀有变异，评价中可能只出现少量携带者。此时，一个动物的误判就能明显改变灵敏度或阳性预测值。应提供分母和区间，并在可能时进行跨批次、跨家系或跨平台验证。用总体平均数掩盖稀有事件的不确定性，会使读者误以为高精度已在所有频率范围得到证实。反过来，样本有限导致区间较宽，也不等于方法没有潜力，只说明证据尚不足以支持精确的生产承诺。

模型输出还应允许审计到具体输入版本。一个候选动物的预测改变，可能因为加入了新表型、参考频率更新、组装坐标转换、结构变异重编码或模型重估。保留版本信息和关键中间量，能够区分合理更新与技术异常。对于重要种畜，若预测变化主要由少数不确定变异驱动，应触发数据复核，而不是直接把变化解释为新的生物发现。

未来值得深入的方向包括更完整的品种与单倍型覆盖、结构变异和重复区域的可靠分型、对基因型不确定性的联合建模，以及把功能证据引入可检验的先验。这里的共同主题不是无限增加特征，而是提高每一条信息与育种目标之间的可追踪性。序列技术最有价值的使用方式，可能是对不同问题采用不同层次的精度：常规评定依靠稳定的大规模资料，对关键稀有位点采用精确检测，对机制研究采用高质量组装和实验验证。

从实证研究走向生产系统，还需要区分个体预测的不确定性与模型总体性能的不确定性。前者回答某头动物的育种值可能偏离预测多少，后者回答在当前验证样本下对方法准确度知道多少。为所有动物报告同一个验证相关，不能替代个体育种值的误差方差；为每头动物给出较窄的模型内区间，也不能证明模型没有共同的系统偏差。两类不确定性应分别估计，并通过独立资料检查是否具有合理覆盖。

结构变异的基因型不确定性可能在家系内相关。例如某个重复区域在同一测序平台上普遍被低估，亲子动物会同时出现类似错误。此时增加同平台家系成员并不能按独立样本速度减少误差。可以利用不同技术、不同实验批次或独立分子证据检验这种共同误差。把所有后验剂量当作独立且精确的输入，可能在关系矩阵中制造过强的家系信号，并让预测可靠性显得过高。

对模型改进的统计检验，应利用同一测试动物上的配对结构。两个方法的预测通常高度相关，比较它们的误差差值比把两组误差当独立样本更有效。不过动物间又可能有亲缘或场区依赖，简单逐动物重抽样会低估不确定性。可以按适当家系、出生批次或场区进行分块重抽样，并说明分块选择对应哪一类推广目标。若测试集只有很少独立家系，任何精细区间都应保持谨慎解释。

此外，模型更新后需要检查选择排序的稳定性。整体相关的小幅变化，可能主要影响中间动物而不改变选留名单；也可能在选留阈值附近显著改变候选身份。应记录前若干比例动物的重合度、换入换出动物的预测差异及其不确定性，同时避免只追求名单稳定而拒绝真实信息。若新模型改变排序，关键问题是改变是否有独立证据支持，而不是变化本身大或小。

一个切实可行的试点可以采用预先冻结模型、盲法保留后续表型和事先指定评价指标的方式。先确定候选群体、主要经济性状、允许成本与交付时间，再比较芯片基线、加入序列以及加入结构变异三个层次。对关键稀有位点另外安排直接检测，确保全局预测评价与局部风险评价都得到关注。试点结束后按照预设标准决定扩大、修订或停止，而不是事后更换最有利的性状和分组来证明成功。

最后，序列研究的开放性应服务于可核查性。即使个体基因型因资源协议不能公开，也可以公开变量定义、数据处理版本、模型公式、评价程序和不涉及身份的汇总统计。对于图参考和复杂变异，提供能够把结果定位回具体路径与等位基因的标识尤为重要。只有当其他研究者能够判断两个研究讨论的是不是同一个生物事件，累积证据才有可能形成。

30.16 概率基因型的似然与缺失信息

前面用剂量概括了基因型后验分布，现在进一步追问：保留概率与把剂量当作真值，究竟会在何处产生不同的统计结果？设一个双等位位点的真实替代等位基因计数为 $x_i \in \{0, 1, 2\}$ ，读段及插补参考信息记为 r_i 。先假定分型过程不使用当前性状表型，且读段给定真实基因型后与表型独立。把已经

计算的三种基因型概率写成

$$q_{ig} = \Pr(x_i = g | r_i), \quad \sum_{g=0}^2 q_{ig} = 1.$$

这些概率是条件于某个频率先验、参考面板和误差模型的结果，不能脱离这些条件解释。一个频率严重失配的面板可能给出十分集中的错误概率。以下推导首先研究概率校准正确时的信息损失，再讨论失配；这样才能区分不可避免的低覆盖不确定性与可以改进的流程偏差。

在已去除已知固定效应的教学模型中，令 $y_i = \beta x_i + e_i$ ， e_i 独立服从方差为 σ_e^2 的正态分布。将不可观察的基因型积分出去，单个动物的观测似然为

$$L_i(\beta) = \sum_{g=0}^2 q_{ig} \frac{1}{\sqrt{2\pi\sigma_e^2}} \exp \left\{ -\frac{(y_i - \beta g)^2}{2\sigma_e^2} \right\}.$$

这是三个正态密度的混合。即使读段后验的剂量相同，不同概率组合也可以产生不同的似然曲率和尾部。把它改成均值为 βd_i 、方差固定为 σ_e^2 的一个正态密度，通常不是同一个模型。其中剂量及其条件方差分别为

$$d_i = \sum_{g=0}^2 g q_{ig}, \quad v_i = \sum_{g=0}^2 g^2 q_{ig} - d_i^2.$$

给定读段以后，表型的条件均值和方差可以直接由全期望与全方差公式得到：

$$E(y_i | r_i) = \beta d_i, \quad \text{Var}(y_i | r_i) = \sigma_e^2 + \beta^2 v_i.$$

剂量正确表达了这个线性模型的条件均值，却没有自动表达其方差。新增的 $\beta^2 v_i$ 说明，同样的分型不确定性在大效应位点上会产生更明显的表型不确定性。若 $\beta = 0$ ，这部分方差消失；若位点效应较大，它便不宜被忽略。该结论也解释了为什么在微效位点的总体预测中，剂量近似可能足够，而在一个隐性缺陷或大效应拷贝变异上，需要保留更完整概率。

进一步对观测对数似然求导。在 $\beta = 0$ 时，各个基因型分量的表型密度相同，求和中的权重不再被表型重新分配。因此得分为

$$U_i(0) = \left. \frac{\partial \log L_i}{\partial \beta} \right|_{\beta=0} = \frac{d_i y_i}{\sigma_e^2}.$$

如果模型还估计截距，应先将剂量对截距残差化。独立同分布动物的大样本局部信息量于是为

$$\mathcal{I}_{obs} = \frac{n\text{Var}(d)}{\sigma_e^2}, \quad \mathcal{I}_{full} = \frac{n\text{Var}(x)}{\sigma_e^2}.$$

这里的信息量针对零效应附近的斜率，不是一个适用于任意遗传架构的统一准确度公式。由于 $d = E(x | r)$ ，全方差分解给出

$$\text{Var}(x) = \text{Var}(d) + E(v), \quad \frac{\mathcal{I}_{obs}}{\mathcal{I}_{full}} = 1 - \frac{E(v)}{\text{Var}(x)}.$$

这一步把“不确定”转换成了可解释的信息比例：未被读段区分的基因型方差不能用于局部关联估计。仅报告最大后验概率，会掩盖群体内剂量是否仍有足够变异；仅报告剂量相关，又会掩盖概率是否校准。两个质量指标对应不同任务。

推导例：相同剂量，不同误差预算。动物甲的概率为 (0.5, 0, 0.5)，乙为 (0, 1, 0)，两者剂量都为 1。甲的条件方差为 1，乙为 0。若效应 $\beta = 2$ 、环境方差为 3，两者条件表型均值都为 2，条件方差却分别为 7 与 3。这不是给甲较低育种值的理由，而是给甲更宽预测分布的理由。若一个群体真实基因型方差为 0.32，平均后验方差为 0.08，则局部信息比例为 0.75；把一千个这样的独立动物近似比作七百五十个完全分型动物，只对这里规定的局部斜率问题成立。

若读段质量与表型或家系系统相关，上述独立条件便可能失败。以患病动物获得的组织较差为例，测序深度低既与疾病有关又改变剂量分布，简单地把后验方差加进残差，并不能消除选择偏差。还应记录样本取得过程，并在适当设计中检验同一真实基因型的分型概率是否随病例状态改变。概率模型的价值，在于让这些条件可以被写清并接受检验，而不是让一个复杂文件格式替代质量控制。

30.17 稀有变异的信息由哪些独立对照产生

稀有度同时改变观察机会、效应精度和误分类的后果，但这三者不能用一个最小等位基因频率阈值概括。先考虑独立随机抽取的 n 头二倍体动物，

等位基因频率为 p ，各条染色体独立。样本中没有观察到该等位基因的概率和至少观察到一次的概率分别为

$$P_0 = (1 - p)^{2n}, \quad P_{\geq 1} = 1 - (1 - p)^{2n}.$$

对很小的 p ，以 $\log(1 - p) \approx -p$ 近似，便得到

$$P_{\geq 1} \approx 1 - \exp(-2np).$$

要使发现概率至少为 η ，样本量条件为

$$n \geq \frac{\log(1 - \eta)}{2 \log(1 - p)}.$$

分母和分子都为负，所以不等式右侧为正。若 $p = 0.001$ 且要求发现概率达到 0.95，需要至少 1498 头满足假设的独立动物。这个数目只保证大概率看见一次，不保证能估计效应，更不保证能发现纯合后果。频率很低时，“已被发现”与“已有足够信息”之间仍可能相差很远。

设一个位点真实计数被准确观察，且表型模型为 $y = Xb + x\beta + e$ ，残差协方差为已知正定矩阵 V 。消去固定效应后，关于 β 的信息为

$$\begin{aligned} P_V &= V^{-1} - V^{-1}X(X^T V^{-1}X)^{-1}X^T V^{-1}, \\ \mathcal{I}_\beta &= x^T P_V x. \end{aligned}$$

这里 P_V 是用于广义最小二乘消元的矩阵，不是普通欧氏投影；在一般 V 下不应误写为 $P_V^2 = P_V$ 。其关键含义是，只能使用未被固定效应解释的基因型对比，并按协方差结构折减重复信息。若所有携带者来自一个家系，而模型又需调整该家系共享背景，原始携带者数量可能大于真正独立的比较数量。

在残差独立、只含截距、且没有纯合替代个体的简化情形下，设 n 头动物中有 k 个杂合携带者，则

$$\sum_i (x_i - \bar{x})^2 = k - \frac{k^2}{n}, \quad \text{Var}(\hat{\beta}) = \frac{\sigma_e^2}{k - k^2/n}.$$

推导例：六个携带者是否足够。令 $n = 100$ 、 $k = 6$ 、 $\sigma_e^2 = 9$ ，则基因型离差平方和为 5.64，效应标准误约为 1.2632。增加九百个不携带者而仍只有六个携带者，离差平方和仅升至 5.964，标准误约为 1.2284。总样本量扩大十倍，效应精度却只略有改善。这说明瓶颈主要在携带者一侧，不能用总动物数掩盖信息结构。若六个携带者全处在一个只包含携带者的批次，而其他批次都没有携带者，基因型列可能完全落入批次设计矩阵的列空间，此时 $\mathcal{I}_\beta = 0$ ，无限增大求解器迭代次数也无济于事。

聚合集合内的稀有变异可以增加信息，但聚合的权重就是模型假设。设独立变异的中心化计数为 z_j 、方差为 s_j^2 ，真实遗传信号为 $u = \sum_j a_j z_j$ ，负荷分数为 $B = \sum_j w_j z_j$ 。则

$$\text{Cov}(B, u) = \sum_j w_j a_j s_j^2, \quad \text{Var}(B) = \sum_j w_j^2 s_j^2.$$

在其余噪声不变时，使负荷信噪比最大的方向与真实效应方向一致。若真实效应未知，就需要通过功能信息、预先定义类别或训练资料提出可验证的权重，而不能在同一测试样本中挑选最有利符号。

$$\frac{\text{Cov}(B, u)^2}{\text{Var}(B)} \leq \sum_j a_j^2 s_j^2.$$

这个柯西不等式的等号在 w_j 与 a_j 成比例时成立。若两个独立位点的方差均为 0.02、效应分别为 1 和 -1，等权负荷与真实遗传信号的协方差恰为零，虽然两位点合计遗传方差为 0.04。此时失败的是方向一致的负荷构造，并不是证明这个基因没有作用。允许异号效应的核或方差分量集合检验回答另一个问题，应与负荷检验区分。

真实序列位点常有连锁不平衡，上式中的对角方差必须换成完整协方差矩阵。即使所有功能评分都为正，两个高度连锁的变异仍可能只是重复记录一个单倍型事件。一个可靠集合分析应把基因边界、功能类别、频率规则和连锁处理在观察最终结果前写明，并对家系独占携带者单独展示；否则集合越灵活，越容易把有限信息误装成丰富证据。

30.18 联合基因型不确定性怎样进入遗传协方差

把每个位点的后验均值相乘，得到的不是后验乘积均值。这个差别在构造关系矩阵时尤其重要。设 $z_{ij} = x_{ij} - 2p_j$ ，且频率 p_j 在本节视为固定参考量。令 $d_{ij} = E(x_{ij} | \mathcal{R})$ ，其中 $\mathcal{R}$ 代表所有可用分型资料。两个动物在同一位点的联合后验协方差为

$$C_{ik,j} = \text{Cov}(x_{ij}, x_{kj} | \mathcal{R}).$$

于是

$$E(z_{ij}z_{kj} | \mathcal{R}) = (d_{ij} - 2p_j)(d_{kj} - 2p_j) + C_{ik,j}.$$

若各动物独立分型、先验也不连接它们，非对角 $C_{ik,j}$ 可以为零；但利用家系传递、共享单倍型或联合相位推断时，这个条件通常需要检查。把所有不确定性一律加在关系矩阵对角线上，只是某些模型下的简化，不是通用传播规则。

令 a_j 为独立、零均值的标记效应，先验方差为 τ_j^2 ，且在给定分型资料后与真实基因型独立。定义 $u_i = \sum_j z_{ij}a_j$ ，再对效应和未知基因型同时积分，可得

$$\text{Cov}(u_i, u_k | \mathcal{R}) = \sum_j \tau_j^2 \{ (d_{ij} - 2p_j)(d_{kj} - 2p_j) + C_{ik,j} \}.$$

因此，概率基因型产生一个由剂量组成的项和一个联合不确定性项。后者并不是“额外发现的遗传变异”，而是当前资料尚未确定的遗传状态在模型中的传播。若已经用另一随机效应表达了同一未知背景，再把全部修正无条件加入，可能重复计算。模型的随机对象和条件信息必须保持一致。

还要区分用后验平均剂量作固定参照，与用未知真实基因型的样本均值中心化。给定分型资料以后，平均剂量 $\bar{d}_j$ 已是固定数；若定义 $\tilde{\mathbf{z}}_j = \mathbf{x}_j - \bar{d}_j \mathbf{1}$ ，其后验协方差仍为 C_j ，减去固定参照不会改变方差。另一种目标是把潜在真实基因型本身按其随机样本均值中心化，即 $\mathbf{z}_j = J\mathbf{x}_j$ ，其中

$$J = I - \frac{\mathbf{1}\mathbf{1}^\top}{n}.$$

后一目标的条件均值为 $J\mathbf{d}_j$ 。若原始后验协方差矩阵为 C_j ，其中心化后的协方差才是

$$C_j^{cen} = JC_jJ.$$

即使 C_j 最初为对角矩阵，后一种随机中心化以后一般也不再对角。这不是人为制造生物关系，而是各动物同时减去同一个未知真实样本均值所产生的统计依赖。对于两个动物，各自独立后验方差均为 v 时，

$$C_j^{cen} = \frac{v}{2} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}.$$

推导例：中心化为什么改变非对角项。两动物的剂量均为 1，后验方差均为 0.4 且原本条件独立。以它们共同的未知样本均值中心化后，不确定性矩阵的对角为 0.2、非对角为 -0.2。若仅把 0.4 加到两个对角而忽略中心化，就会使总和方向保留本应被去除的方差。这个小例子并不建议用两个动物估计实际频率，而是让读者看清矩阵运算与统计定义必须一致。

已知效应与随机效应的预测误差还须分开。若某候选动物的效应向量后验均值为 m 、协方差为 S ，中心化基因型后验均值为 d_z 、协方差为 C_x ，暂时假设两组后验独立，则乘积 $u = z^T a$ 满足

$$E(u | \mathcal{R}, \mathcal{D}) = d_z^T m,$$

$$\text{Var}(u | \mathcal{R}, \mathcal{D}) = d_z^T S d_z + m^T C_x m + \text{tr}(S C_x).$$

第一项是效应估计不确定性，第二项是基因型不确定性作用于平均效应，第三项是两种不确定性的乘积。遗漏第三项会在剂量均值与效应均值都很小的时候尤为明显，因为前两项可能很小，真实乘积却仍有变异。例如单个位点 $d_z = 0.5$ 、 $m = 2$ 、 $S = 0.25$ 、 $C_x = 0.2$ ，预测均值为 1，方差为

$$0.0625 + 0.8 + 0.05 = 0.9125$$

将基因型当作已知，只保留 0.0625，会严重夸大精度。

当同一表型参与基因型更新和效应估计时，后验独立假设可能不成立，以上三项公式就需增加交叉依赖，或直接对联合后验积分。多重插补的意义正是对多个合理遗传状态重复分析并汇总两层变异，但插补样本必须来自相容模型；重复复制同一个最高概率基因型不会传播任何不确定性。

30.19 参考面板设计是覆盖概率与边际收益问题

泛基因组增加了可表示的路径，参考面板决定哪些路径可以被实际观察和追踪。两者都不是简单的样本计数问题。Yang 等在二〇二六年的奶牛泛基因组研究中，分别研究了分相组装驱动的结构变异分型和泛基因组辅助的结构变异插补。这些工作为从图结构连接群体分型提供了实证依据，但不能把结构变异检出或关联能力的改善直接换算成选种收益（Yang 等，2026a，2026b）。下面的面板设计是独立教学推导，不是对这些研究样本的重新分析。

令某个目标单倍型在独立染色体中的概率为 f_h 。随机纳入 k 条染色体时，至少覆盖一次的概率为

$$P_h(k) = 1 - (1 - f_h)^k.$$

新增一条随机染色体的覆盖增量为

$$\Delta_h(k) = f_h (1 - f_h)^k.$$

这说明边际收益递减：已经容易被覆盖的常见单倍型，随着样本扩大，很快不再贡献很多新覆盖；稀有单倍型的单次命中率低，却可能长期未被覆盖。若按目标价值 v_h 加权，面板的期望覆盖价值为

$$V(k) = \sum_h v_h \{1 - (1 - f_h)^k\}.$$

价值可以代表目标群体频率、关键区域的重要性或对风险配种的意义，不应把互相重复的单倍型标签都赋予完整独立价值。频率权重与保护稀有资源的权重体现不同目的，设计者需要说明正在优化哪一个目的。

推导例：均匀随机与有目的补充。对频率为 0.01 的单倍型，随机选择 100 条独立染色体时，覆盖概率约为 0.6340；增加到 200 条时约为 0.8660。第

二个一百条带来的增量约为 0.2321。如果已经通过家系和芯片单倍型锁定一头很可能携带目标片段的动物，对其进行高质量组装可能比继续随机取样更有效。但这种有目的抽样适合补充参考路径，不应未经抽样权重校正就用于估计全群体频率。

更现实地，候选动物 i 对目标路径 h 的覆盖概率为 p_{ih} 。在条件独立近似下，选择集合 S 后的未覆盖概率与价值为

$$P_h(\text{未覆盖} | S) = \prod_{i \in S} (1 - p_{ih}),$$

$$V(S) = \sum_h v_h \left\{ 1 - \prod_{i \in S} (1 - p_{ih}) \right\}.$$

新增动物 a 的边际贡献为

$$\Delta_a(S) = \sum_h v_h p_{ah} \prod_{i \in S} (1 - p_{ih}).$$

公式可以直观解释去冗余：一头动物拥有很多路径，如果这些路径几乎都已在面板中，其新增价值可能低于一头只补上少数空白的动物。在非负权重和上述条件下，随着集合扩大，新增同一动物的边际贡献不会增加；这一递减结构为逐步选择提供了依据。但逐步选择不等于在所有预算和关联条件下都找到精确最优解。

假定有两条等权路径，现有面板对它们尚未覆盖的概率分别为 0.1 和 0.8。候选甲的覆盖概率为 (0.9, 0.1)，乙为 (0.2, 0.6)。甲的新增价值为 0.17，乙为 0.50，应优先乙。若甲乙高度近亲，独立乘积近似还会高估同时选入的收益，需要利用联合单倍型分布或保守情景计算。把同一父系的多头动物当作互不相关的抽样，容易产生虚假的覆盖信心。

面板选择还应区分发现、分型和预测三个阶段。用于发现结构路径的高质量组装动物可以很少但多样；用于估计图中路径频率的群体需要代表性；用于学习复杂性状效应的参考群体还需要可靠表型与目标环境连接。三类样本可以重叠，但没有理由要求它们完全相同。扩大组装面板若不能改善关键动物的可靠分型，便可能没有直接预测收益；反之，一个较小但与目标品种

紧密匹配的面板，可能对实际插补更有帮助。最有说服力的比较应保留相同目标动物、相同测试位点和相同误差定义，让面板变化成为主要差别。

30.20 由后验概率走向配种风险与检测价值

基因型不确定性最终常表现为一个行动问题：是否需要复检，是否允许某一配对，是否愿意承担漏判风险。不同错误的损失通常不对称，因此不宜统一用最大后验概率作所有决策。设某动物为目标隐性缺陷携带者的后验概率为 π 。将其判为携带者而实际不是，损失为 C_{FP} ；判为非携带者而实际是，损失为 C_{FN} 。两种行动的后验期望损失为

$$R_{\text{携带}} = (1 - \pi)C_{FP}, \quad R_{\text{非携带}} = \pi C_{FN}.$$

选择较小损失的行动，得到阈值

$$\pi > \frac{C_{FP}}{C_{FP} + C_{FN}}.$$

阈值由用途决定，不一定是 0.5。若漏判可能产生患病后代，而误判只导致一次较低成本复检，阈值可以很低；若错误剔除会损失珍贵遗传来源，则误判成本又可能很高。把携带者识别与永久淘汰绑定，也会不必要地混合两种行动；通过合理配种保留优良携带者，在某些已知隐性遗传机制下是独立可选策略。

设两亲本只可能是非携带者或杂合携带者，携带概率分别为 π_s, π_d 。若两者在给定资料后条件独立，且隐性等位基因的传递符合孟德尔规律，则一胎患病概率为

$$p_{\text{患病}} = \frac{1}{4} \pi_s \pi_d.$$

若由于共同家系信息使携带状态仍相关，则应使用联合概率：

$$p_{\text{患病}} = \frac{1}{4} \Pr(C_s = 1, C_d = 1 \mid \mathcal{D}).$$

后一式不能被任意两个边际概率的乘积替代。对 N 个独立后代，至少出现一个患病后代的概率，在亲本携带状态已知且单胎风险固定时为 $1 -$

$(1 - p_{\text{患病}})^N$ ；但如果亲本状态本身未知，后代之间共享同一个潜在状态，不应先边缘化单胎风险再错误地当作独立。

在上述仅杂合或非携带的情境下，正确的边缘概率是

$$\Pr(\text{至少一胎患病}) = \Pr(C_s = C_d = 1 | \mathcal{D}) \left\{ 1 - \left(\frac{3}{4} \right)^N \right\}.$$

推导例：重复后代并非独立证据。设两亲本携带概率为 0.8 与 0.5 且条件独立。单胎患病概率为 0.10。四胎中至少一胎患病的真实边缘概率为 $0.4(1 - 0.75^4) = 0.2734375$ ，而把四胎误作风险恒为 0.10 的独立试验会得到 $1 - 0.9^4 = 0.3439$ 。两者均值的单胎风险相同，差别来自共享亲本状态造成的相关性。若四胎都未患病，还会反过来降低双亲均为携带者的后验概率；后续风险应当更新，不能继续机械使用初始概率。

检测价值可以在相同框架下计算。当前最优期望损失为

$$R_0(\pi) = \min\{(1 - \pi)C_{FP}, \pi C_{FN}\}.$$

若新检测结果 t 将概率更新为 π_t ，检测成本为 c ，则其净信息价值为

$$VOI = R_0(\pi) - \sum_t \Pr(t) R_0(\pi_t) - c.$$

这里的检测价值来自它可能改变行动，并不等于检测准确率本身。假定先验携带概率为 0.2，漏判损失为 20，误判损失为 2，当前应判为携带者，损失为 1.6。一项灵敏度为 0.9、特异度为 0.95 的检测，阳性概率为 0.22，阳性后验约为 0.8182，阴性后验约为 0.02564。依据同一阈值作决定，检测后的平均损失为 0.48，故检测的毛信息价值为 1.12；只在成本低于这个值时才产生正净价值。这些损失单位可以是货币或预先定义的目标损失，但不可混用。

检测并非总越精密越值得。若无论检测结果如何都选择同一个安全配对，额外检测在当前行动上的价值可能为零，却仍可能对下一代面板建设有长期价值。反过来，处在行动阈值附近的动物，即使已有较高分型质量，少量新增信息也可能改变配种。由此形成一个完整逻辑：先定义损失和行动，再确定需要区分的概率范围，最后选择测序深度、复检方法和参考面板。技术指标只有通过这一链条，才能与育种决策中的实际收益建立明确联系。

后代信息更新可以写得更明确。令 J 表示双亲均为携带者，初始概率为 ρ ；观察到前 N 胎都未患病，且假定发病状态被无误检测、不同胎次给定亲本状态后独立。贝叶斯公式给出

$$\Pr(J | N \text{胎均正常}) = \frac{\rho(3/4)^N}{1 - \rho + \rho(3/4)^N}.$$

在刚才的例子中， $\rho = 0.4$ 、 $N = 4$ ，更新后的联合携带概率约为 0.1742，下一胎患病概率约为 0.04355。这不意味着正常后代证明亲本没有携带，而是说正常后代与“双亲均携带”相比更支持其他状态。若患病后代在出生前死亡，观测到的“全部正常”只针对存活者，就不能直接使用这条更新式；需要把受胎、胚胎损失和检测过程放入似然。这一细节在隐性致死缺陷中尤其重要，因为选择性缺失恰恰可能消除最有诊断价值的记录。

同理，多项检测不能无条件把似然比相乘。若两种检测都依赖同一套短读段、同一参考路径和同一比对错误，它们在给定真实基因型后仍可能相关。将其误当作独立复检，会把相同证据使用两次，得到过度集中的后验。真正有价值的确认往往来自不同信息来源，例如独立采样、另一种读段结构或针对关键断点的检测；但这些来源是否足够独立仍需研究设计支持。决策模型应区分增加新证据与重复计算旧证据，否则越复杂的检测组合反而可能越自信地犯同一个错误。

30.21 综合练习与解答

练习 1. 某动物一个位点的后验基因型概率为 $(0.25, 0.50, 0.25)$ ，另一个动物为 $(0, 1, 0)$ 。求两者剂量与条件方差，并说明为何仅保留剂量会丢失信息。

解答. 两者剂量均为 1。第一个动物的二阶矩为 $0.5 + 4 \times 0.25 = 1.5$ ，条件方差为 0.5；第二个动物方差为 0。相同剂量表示相同条件均值，但前者仍有两种纯合状态的可能，后者完全确定。对于平方项、隐性缺陷概率和育种值不确定性，两者不应视为相同观察。

练习 2. 某隐性缺陷等位基因的后验计数概率为 $(0.05, 0.90, 0.05)$ 。若只保留剂量 1，能否断言它是携带者？若需要避免患病配种，应保留哪类信息？

解答。不能。剂量是计数期望，不是最可能基因型，更不是确定的生物状态。该动物杂合概率为 0.90，风险纯合概率为 0.05。配种风险应结合两个亲本的基因型后验、遗传方式及可能相关的分型误差计算；在后果严重时，应考虑独立检测。把剂量直接四舍五入会抹去这部分风险。

练习 3。某检测在两万头动物中使用，真实携带率为 1%，灵敏度为 0.95，特异度为 0.995。求预期真阳性、假阳性与阳性预测值。若携带率降为 0.1%，其余条件不变，阳性预测值如何变化？

解答。第一种情形真阳性 190，假阳性 99，阳性预测值 $190/289 \approx 0.6574$ 。第二种情形真阳性 19，假阳性 99.9，阳性预测值约 0.1598。检测的灵敏度与特异度相同，阳性结果的可信程度仍随基础频率显著改变。这也是稀有高风险变异需要独立复核的重要原因。

练习 4。两个变异在研究中所有动物的基因型列完全相同，其中一个注释为错义变异，另一个位于调控区域。仅凭同一批表型能否确定哪一个因果？功能注释应如何使用？

解答。不能，两个解释在该设计中不可识别。注释可作为有根据但仍可修正的先验，不能把统计不可区分变成数据已经区分。可寻找具有不同重组背景的个体，补充独立分子证据，或报告包含两者的可信集合。若用于近期预测，可保留区域标记，但应避免把预测有效等同于因果已确定。

练习 5。一组稀有变异中，两个标准化变量相互独立，真实效应为 +1 与 -1。等权负荷为两者之和。求负荷与真实遗传分量的协方差，并解释集合检验选择。

解答。设变量为 x_1, x_2 ，方差均为 1，则负荷为 $x_1 + x_2$ ，真实分量为 $x_1 - x_2$ ，协方差等于 $1 - 1 = 0$ 。负荷检验可能失去这组异向效应的信息。允许效应异号的核或方差分量集合检验更符合这里的备择假设，但其优势仍受样本量、权重与误差结构影响，并非所有情形都优于负荷检验。

练习 6。两个半正定核的非负加权和不必然半正定？若一个权重为负，是否一定不合法？

解答。非负加权和不必然半正定，可由任意向量的二次型证明。存在负权

重时不再有一般保证，但也不必然非法：例如两个相同核取权重 1.2 与 -0.2，结果仍是原核。实际协方差模型必须对最终矩阵进行数学约束，不能因为一个具体负权例子恰好合法，就认为任意负权组合都可用。

练习 7。某致病等位基因频率为 0.02，标记等位基因频率为 0.20，且所有致病等位基因都位于标记等位基因背景。求两者平方相关，并比较例 30.6。

解答。 $D = 0.02 - 0.02 \times 0.20 = 0.016$ ，平方相关为

$$0.016^2 / (0.02 \times 0.98 \times 0.20 \times 0.80) \approx 0.08163$$

它高于例 30.6 的 0.0101，但仍远低于 1，因为标记等位基因中多数不携带致病变异。频率匹配程度是标记能力的重要限制。

练习 8。某新序列模型在随机划分测试集中的相关提高 0.04，在按出生年份划分的测试集只提高 0.005，且置信区间覆盖零。写出恰当结论，并提出下一步研究。

解答。可以说随机划分条件下观察到改进，但对未来世代预测的增益尚无明确证据。应检查训练测试亲缘连接、变异质量、样本量与时间漂移，在预先定义的后继世代继续验证；也可研究改进是否集中于特定变异携带者。不能把随机划分中的提高直接宣传为未来育种收益，也不能仅凭一次不显著结果认定序列信息永远无用。

练习 9。一个有害隐性等位基因携带者具有很高综合育种值。提出同时控制缺陷风险与保持遗传进展的原则，并说明为什么“清除携带者”不必是第一步。

解答。首先确认变异与疾病的因果关系、遗传方式和分型可靠性；随后优先安排与可靠非携带者配种，控制该家系贡献并逐步降低有害等位基因频率。在综合目标中考虑优秀遗传背景、近交与长期多样性。立即清除所有携带者可能损失有利基因并集中少数家系贡献，是否值得取决于风险严重程度、携带频率与替代资源。

练习 10。为一个地方品种设计仅能新增测序五十头的参考群体方案，说明主要目标、入选信息和验证方式。

解答。先区分主要目标是常见变异插补、稀有变异发现还是缺陷管理；

再结合群体内单倍型覆盖、祖源、家系贡献和现有参考缺口选择个体。保留一批独立直接分型个体评价不同频率和变异类型的插补质量，记录版本、样本身份与相位信息。五十头只是预算约束，方案好坏应由覆盖新增信息和目标群体中的验证结果判断。

多组学、功能先验与因果推断

31

31.1 先定义信息进入决策的时间

多组学并不是把多张数据表连接起来之后自动产生的更高层次知识。基因组、转录组、表观组、蛋白组、代谢组和微生物组分别观察生物系统的不同侧面，其稳定性、测量误差和获得时间明显不同。育种研究首先要回答：预测的是当时表型、未来个体表现、可传递育种值，还是某项干预的效果？同一分子指标对这些问题的价值可能完全不同。

设想两头遗传潜力相近的猪，一头因为短期感染而减少采食，另一头健康。某些代谢物可以清楚区分它们的当时状态，这对健康预警有用；但是，如果目标是在出生时选择父母，那么育肥末期的代谢谱既尚不可获得，也包含大量非遗传信息。把这种状态预测的高相关直接解释为幼龄育种值准确度提高，混淆了任务、时间和信息来源。

在研究计划中，最好把每条信息标注为“选择时已知”“选择后才知”或“仅研究样本可测”。同一组学可能在母本上可获得，却无法在年轻公畜上测量；乳腺转录信息可能只来自泌乳雌性，屠宰后组织信息则不能直接用于该动物的繁殖决策。这些限制不使数据失去价值，但决定它更适合作为亲属辅助性状、功能先验还是机制发现资源。

组学信息进入育种至少有三条主要路径。第一，把分子指标作为辅助性状，利用遗传协方差改进目标育种值评定。第二，把功能测量转化为位点注释，改变标记效应的先验收缩。第三，建立分子过程与目标性状之间的因果模型，研究遗传效应如何传递。三条路径可以相互支持，但预测准确并不能证明路径方向，机制合理也不能保证新增预测信息足够大。

还应区分群体平均资源与个体测量。某种组织的染色质开放图谱可以作为对所有候选动物共享的注释，而每头动物自己的代谢谱则是个体层面的新记录。前者通常不随候选动物的当时环境变化，却可能与目标组织或发育阶段不匹配；后者更接近个体状态，却更容易混入环境。二者都被称为多组学整合，但它们在模型中承担的统计角色并不相同。

本章沿着“测量—分解—预测—因果—决策”的顺序讨论。贯穿其中的问题是：新增数据提供了哪部分独立信息，这部分信息能否在目标群体、目标时间和目标用途上保留？回答这一问题需要设计与模型共同工作，不能只依靠增加潜在层、特征数量或算法复杂度。

31.2 分子测量的尺度、批次与重复性

转录读数、蛋白丰度和代谢峰强度不是天然处在可直接比较的尺度上。读数受到文库大小、测序深度、提取效率和仪器响应影响；某些值具有明显偏态或检测下限；同一代谢物还可能产生多个相关峰。建模前必须区分生物学单位和技术单位，否则“增加一单位表达”的效应可能只是某个处理流程中的数值变化。

归一化的目标也不唯一。有的步骤调整样本间总体测量量，有的步骤校正特征间不同的变异尺度，有的步骤消除批次差异。中心化和标准化可以改善数值计算，却不能自动去除混杂。若某个品种全部在第一批测定、另一个品种全部在第二批测定，品种差异与批次差异完全重合；没有额外连接或实验信息，任何算法都无法从同一观测中唯一拆开二者。

较好的批次控制从采样开始。把不同家系、品种、处理和出生批次尽可能交叉分配到实验批次，在不同板或仪器运行中加入参考样本，记录采样时间、空腹状态、冻融次数和保存过程。技术重复用于估计测量误差，生物重复用于估计个体随时间变化，两者不能互相替代。一份样本反复测十次，并不等于观察十个独立生物时点。

例 31.1 技术误差怎样限制辅助性状的信息。设一个真实分子指标的个体方差为 4，独立技术误差方差为 1，单次测量的可靠程度为 $4/(4+1) =$

0.80。对同一样本独立测两次后取平均，误差方差降为 0.5，可靠程度变为 $4/4.5 \approx 0.8889$ ；测四次则为 $4/4.25 \approx 0.9412$ 。收益递减说明经费未必都应投入技术重复。若两次误差相关为 0.5，平均误差方差为 0.75，两次重复的可靠程度只有 $4/4.75 \approx 0.8421$ ，共同批次误差不会被简单平均充分消除。

测量误差还会使普通回归斜率衰减。在一个只有分子指标作为解释变量、误差与真实指标和目标独立的线性教学模型中，观察值回归斜率等于真实斜率乘以测量可靠程度。因此，用噪声较大的指标得到较小效应，并不必然说明真实生物作用很弱。反过来，如果误差与目标共同受批次影响，回归可能被放大或反向，简单衰减公式就不再成立。

重复性不等于遗传率。一个稳定的个体差异可能由永久环境、早期营养或长期管理造成，因而重复测量相关很高，却不能充分传递给后代。只有引入亲缘连接、基因组关系和适当环境设计，才可能进一步区分遗传与其他稳定来源。研究中应避免把“跨时间稳定”直接写成“具有遗传基础”。

当测量值用于后续外部预测，所有可学习的处理步骤都需要遵循训练边界。特征筛选、批次校正参数、标准化均值和方差通常应由训练资料确定，再按既定规则应用于测试资料。对于真实生产中可以共同处理一批无表型候选数据的情形，可以设计相应的传导式流程，但必须明确该流程能够获得哪些信息，不能把测试表型或未来批次的信息悄悄用于校正。

31.3 用遗传协方差连接辅助性状与目标性状

设分子指标 m 与生产性状 y 分别满足 $m = X_m\beta_m + Z_mu_m + e_m$ 和 $y = X_y\beta_y + Z_yu_y + e_y$ 。若二者的加性遗传效应共享同一基因组关系结构，则可写

$$\text{Var} \begin{pmatrix} u_m \\ u_y \end{pmatrix} = \begin{pmatrix} \sigma_m^2 & \sigma_{my} \\ \sigma_{my} & \sigma_y^2 \end{pmatrix} \otimes G.$$

这里 σ_{my} 是遗传协方差，不是两个原始测量值的表型协方差。若同一个体在同一天同时测量两种性状，残差还可能相关；若两种记录来自不同个体或不同时间，残差连接又可能不同。正确设置这些结构，是把状态信息与可

传递信息区分开的基础。

一个辅助指标的价值不仅取决于其遗传相关，还取决于它的遗传率、测量成本、可获得个体数和目标性状已有信息。高遗传相关但几乎无可可靠测量的指标可能帮助有限；中等遗传相关、成本很低且能在大量年轻动物上测量的指标可能更有用。对已有高准确度育种值的候选群体，新指标的增量也往往小于对完全缺少目标记录的群体。

在最简选择指数中，若只有一个标准化分子记录 m 用于预测目标育种值 u_y ，最优线性系数为 $\text{Cov}(m, u_y) / \text{Var}(m)$ 。这说明信息价值由协方差决定，而不由“组学”这个名称决定。加入已有基因组预测后，应考虑分子记录在控制已有信息后剩余的协方差；如果它主要重复已有遗传信号，单独相关很高也可能只有很小增量。

例 31.2 辅助记录的高表型相关与低遗传贡献。 设 m 和 y 的表型方差都为 1，遗传方差分别为 0.20 与 0.40，遗传协方差为 0.10，残差协方差为 0.40。两者表型相关为 0.50，但遗传相关只有 $0.10 / \sqrt{0.20 \times 0.40} \approx 0.3536$ 。仅用 m 预测 u_y 的最优系数为 0.10，预测方差为 0.01，可靠性为 $0.01 / 0.40 = 0.025$ 。因此，表型相关 0.50 并不意味着该记录对育种值具有 0.50 的准确度。

这个例子也提示另一种情况：残差协方差可能与遗传协方差异号，使表型相关接近零，而遗传相关仍有意义。例如某分子指标的遗传升高有利于生长，但短期疾病同时提高该指标并降低生长，两个来源在表型上抵消。仅按原始表型相关筛选辅助指标，会漏掉某些具有遗传价值的指标。因此，筛选标准应与最终育种任务相匹配。

当辅助指标很多时，无约束估计完整遗传协方差矩阵很快变得困难。十个性状已有五十五个不同遗传协方差参数，数千分子特征不可能简单照搬。可以采用少量预先定义通路、因子结构、稀疏协方差或层级收缩，但这些方法都要保留遗传与残差两个层次。只对原始组学做主成分分析，得到的最大变异方向可能主要是批次或环境，而非最有价值的遗传方向。

31.4 从分子通路到总育种值：不要丢掉间接遗传作用

为了理解组学的遗传贡献，考虑一个教学性线性系统：分子表型 $m = u_m + e_m$ ，目标性状为 $y = u_0 + \theta m + e_y$ 。若 u_0 和 u_m 分别表示不经该分子路径与经该路径作用的遗传成分，则目标的总育种值是 $u = u_0 + \theta u_m$ ，而不是仅仅 u_0 。分子表型中的环境成分 e_m 可以影响当时的 y ，却不会因为进入同一回归式而变成可遗传成分。

这一分解需要明确的模型假设。若 m 与 y 还受到未测共同原因影响，或 y 反过来改变 m ，回归系数就不一定具有中介路径含义。即使结构方向正确， u_0 和 u_m 也可能相关，因为同一基因通过多条路径作用。因此，总遗传方差一般为

$$\text{Var}(u) = \sigma_0^2 + \theta^2 \sigma_m^2 + 2\theta \text{Cov}(u_0, u_m).$$

把最后一项强制设为零，是一个需要证据或设计支持的简化，不是代数要求。

例 31.3 分子表型贡献中有多少可传递。设 $\text{Var}(u_0) = 3$ 、 $\text{Var}(u_m) = 4$ 、 $\theta = 0.5$ ，且两遗传成分独立，则总遗传方差为 $3 + 0.25 \times 4 = 4$ 。若 $\text{Var}(e_m) = 5$ ，分子表型路径对当时性状贡献的方差为 $0.25 \times 9 = 2.25$ ，其中遗传部分只有 1，环境部分为 1.25。若再设 $\text{Cov}(u_0, u_m) = 0.4$ ，总遗传方差变为 4.4。不能把 2.25 全部称为分子遗传贡献，也不能忽略遗传成分间协方差。

这种区分直接影响模型输出的名称。把目标表型同时回归于基因组和个体分子测量时，基因组部分可能更接近控制分子记录后的剩余遗传效应；若最终育种目标是总遗传潜力，就需要把经分子遗传成分传递的部分适当加回。否则，一个通过提高有利代谢过程而改善生产的基因，可能因为该过程被当作协变量控制而在总育种值中被削弱。

相反，如果研究问题本来就是寻找不通过某路径的直接遗传作用，那么控制中介可能具有意义。但此时需要承认估计目标改变了，并且满足相应因果识别条件。所谓“更充分地校正组学”并不总是更接近育种目标。一个协变量究竟是混杂因素、中介还是结果的反映，需要从生物过程和采样时间判断，不能仅凭与目标相关就一律调整。




图 31.1 分子通路中的遗传与环境来源。箭头表达例 31.3 的教学模型，未宣称真实生物系统已经满足因果识别条件。总育种值只包含遗传路径，分子表型的环境贡献另行计算

实际多组学模型可以通过联合混合模型、结构方程或分阶段计算实现上述思想。分阶段计算本身不必然错误，关键在于它是否对应明确的联合模型、是否传播第一阶段不确定性以及是否正确恢复总育种值。用于堆叠预测或残差学习的两阶段算法则另有验证要求，应避免第一阶段对训练个体的过度拟合在第二阶段被当成真实信号。这些不同计算目的不能混为一谈。

31.5 高维组学的降维：保留什么变异

在组学数据中，特征数常远大于动物数，而且特征间高度相关。一个代谢物可能产生多个峰，同一调控过程可能影响许多基因，一个技术批次也可能同时改变大量测量。降维的目的不是简单减少列数，而是选择一种可估计、可解释并能推广的表示。不同降维方法保留的信息不同，因此不存在脱离任务的最佳低维空间。

主成分分析寻找表型变异最大的方向。若最大方向是共同采样环境，它可能对预测当时表型有用，却对遗传改良贡献有限。监督降维寻找与目标相

关的方向，更贴近预测任务，但必须在训练资料内完成，且容易在小样本中追逐偶然相关。遗传因子模型则尝试在遗传协方差层面提取共有方向，需要亲缘连接及可识别的方差结构，不能把普通主成分直接改名为遗传因子。

设组学向量写为 $m = \Lambda f + \delta$ ，其中 f 是少量潜在因子， Λ 是载荷。这个表示可以描述协方差，但因子方向往往不是唯一：对因子做适当旋转，同时调整载荷，可以得到相同拟合。因子的生物学命名因此需要外部依据。把一个因子称为“免疫能力”或“饲料效率通路”，应有稳定载荷、相关实验或独立性状支持，而不能只依据少数显眼特征。

例 31.4 两个相关特征的平均值能做什么。假设两个标准化分子指标的相关为 0.80，平均值的方差为 $(1 + 1 + 2 \times 0.8)/4 = 0.90$ ，差值的一半的方差为 0.10。平均方向保留了大部分表型变化，但若目标育种值恰好与两特征的协方差分别为 0.20 与 -0.20 ，则它与平均值的协方差为零，与差值一半的协方差为 0.20。解释最多表型方差的方向，未必最能预测目标遗传成分。

降维还要考虑跨批次和跨群体稳定性。在训练样本中得到的因子，如果在新平台上载荷关系改变，就可能失去原有含义。对新样本重新计算因子又可能改变坐标，使新旧预测不能直接比较。较实用的做法是冻结训练阶段的变换，在独立资料中检查其表现，并在确需更新时明确版本转换和重新校准过程。

缺失组学也是常态。某些动物只有基因组，某些有代谢组，另一些有转录组。只保留所有组学齐全的动物会损失样本，并可能选择出特殊子群。联合模型可以利用部分记录，但依赖缺失机制和跨组学连接；简单填补也需要评估不确定性。如果某类组织只能在患病或屠宰个体获得，缺失往往与状态相关，不能默认随机缺失。设计中增加有代表性的连接样本，常比事后复杂补全更有价值。

31.6 多核整合：相似性可以有不同来源

将每组学转换为个体间相似性矩阵，是连接高维数据与混合模型的一种自然方法。若标准化后的分子特征矩阵为 M ，可构造 $Q = MM^T/q$ ，其中 q

是特征数。模型 $y = X\beta + u + v + e$ 可以分别令 $\text{Var}(u) = G\sigma_u^2$ 、 $\text{Var}(v) = Q\sigma_v^2$ 。这个模型把基因组相似性与分子相似性分开表达，但 v 仍只是与分子核相关的表型分量，并不自动等于分子遗传育种值。

关键在于 Q 的来源。若两头动物因饲料相同而代谢谱相似， Q 会连接它们，即使它们没有较近亲缘；若分子指标受宿主基因控制， Q 也会包含遗传相似性。一个核可能混合这些来源，因而其方差分量的名称应谨慎。将 σ_v^2 称为“代谢组解释的方差”尚需说明标准化，而称为“经代谢遗传的方差”则需要进一步遗传分解。

核矩阵的尺度影响方差分量数值。如果把 Q 乘以十，同时把相应方差参数除以十，模型协方差不变。因此，比较不同研究中的核方差比例之前，需要核对中心化、对角均值和特征标准化规则。特征数很多也不意味着独立信息很多；重复的高度相关特征可能反复强化某个方向，改变核的几何结构。按通路或测量单位合理加权，有时比简单平均所有列更符合研究目的。

当两个核高度相似时，数据可能只能识别它们的和。考虑 $Q = G$ 的极端情形，协方差中出现 $G(\sigma_u^2 + \sigma_v^2)$ ，任何具有相同总和的非负参数组合产生相同拟合。此时不能凭优化器给出的某个拆分，宣称某类组学贡献更大。实际核不完全相同也可能接近这种状态，因此应检查参数不确定性、边界估计和对标准化的敏感性。

例 31.5 解释方差很多，却不一定带来增量。 已有信息 I 与目标育种值 u 的相关为 0.70，新分子评分 M 与 u 相关为 0.60， I 与 M 相关为 0.80，三者均标准化。两信息联合预测的可靠性为

$$(0.70^2 + 0.60^2 - 2 \times 0.80 \times 0.70 \times 0.60) / (1 - 0.80^2) = 0.4944$$

只略高于原来的 0.49。新评分单独看相关不低，但其与目标有关的内容几乎都被已有信息覆盖。这里的相关矩阵合法，结论建立在线性最优预测及相关已知的教学假设上。

对生产应用，还必须检查测试动物是否拥有分子记录。如果模型在测试时使用动物自己的代谢谱，它解决的是“基因组加当时分子测量”的任务；如果候选动物只有基因组，则需要通过训练资料学习可遗传部分或借助亲属信

息。两种结果不可直接比较。研究报告应明确测试时信息集合，最好同时给出候选动物有、无个体组学记录的不同情景。

复杂核不一定更好。非线性核可以表示更复杂的分子相似性，却也可能更强地捕捉批次、疾病状态或局部群体结构。选择核形式和带宽时，应与基线方法共享同一验证框架。若新核的主要价值只是识别一个已知管理组，加入适当管理变量可能更透明。模型复杂度应对应新增可推广信息，而不是对应特征矩阵的规模。

31.7 功能先验怎样改变标记效应的收缩

功能注释的作用可以用一个简单贝叶斯模型说明。设标记效应为 a_j ，观察到的粗略效应估计为 $\tilde{a}_j$ ，其标准误平方为 s_j^2 。若采用 $a_j \sim N(0, \tau_j^2)$ 和 $\tilde{a}_j | a_j \sim N(a_j, s_j^2)$ ，则后验均值和方差分别为

$$E(a_j | \tilde{a}_j) = \frac{\tau_j^2}{\tau_j^2 + s_j^2} \tilde{a}_j, \quad \text{Var}(a_j | \tilde{a}_j) = \frac{\tau_j^2 s_j^2}{\tau_j^2 + s_j^2}.$$

功能证据在这里通过 τ_j^2 进入。较大先验方差允许较大的效应，也减少向零收缩；它不是宣布该位点必然有作用。

例 31.6 同一数据在两种先验下的结果。两个位点粗略效应估计都为 0.6，标准误都为 0.4。对功能证据较强的位点设先验方差 0.16，其后验均值为 0.30，后验方差为 0.08；对另一位点设先验方差 0.04，后验均值为 0.12，后验方差为 0.032。第一个位点的后验均值较大，同时后验不确定性也较大。放宽先验不会凭空增加数据精度，只是改变先验与似然的相对权重。

这个单变量公式忽略了连锁不平衡，适合展示收缩原理，不能逐位点机械套用于高度相关标记。联合模型中，某个位点的后验效应还受到其他位点编码和先验影响。若两个标记几乎相同而注释不同，先验可能把较多效应分配给被优先的标记；这有助于预测或候选排序，却不构成新的独立因果证据。

先验还可以作用于非零概率，而不只作用于方差。例如一类注释可能提高位点属于有效成分的概率，另一类可能改变有效成分的效应分布。这两种机制代表不同生物假设：前者强调作用位点数量，后者强调作用强度。有限

样本往往难以同时精确区分二者，因此模型应控制复杂度，并检查结果是否对先验结构过度敏感。

合理的功能先验通常保留所有区域的基本机会。未被注释并不意味着没有功能，可能只是相关组织尚未测量、技术分辨率有限或注释数据库偏向某些群体。若把所有未注释位点的先验方差固定为零，就把资源缺口变成生物学排除。保留非零背景成分，允许数据修正注释偏见，往往更符合复杂性状的知识状态。

功能证据本身也有层级。直接观察到的剪接改变、相关组织的开放染色质、跨物种保守性和通用序列模型分数，并非等价信息。它们可能支持不同作用机制，也可能彼此高度相关。把所有证据简单相加会重复计数；把所有证据压成一个分数又可能失去组织和方向信息。可以采用分组先验或层级模型，但应保持对每类证据来源和适用范围的可追踪性。

评价功能先验时，至少应比较无功能信息的基线、仅用外部注释的模型以及加入目标性状关联信息的模型。这能区分真正外部功能资源的增量与从同一性状发现大效应区域的增量。若只报告完整复杂模型优于基线，无法判断改进究竟来自生物注释、数据驱动筛选还是更灵活的效应分布。

31.8 注释权重的学习、重叠与泄漏

当注释种类很多时，手工为每类指定固定权重往往不够灵活。一个常见思路是用注释向量 z_j 解释先验方差，例如 $\log \tau_j^2 = z_j^T \gamma$ 。指数链接保证方差为正，参数 γ 表示某类注释与效应尺度的关系。这个表达式并不要求某注释必然有利，它允许资料显示较弱或相反的倾向；但高维注释仍需要收缩和可识别性检查。

注释重叠会使参数解释复杂。某个位点可能同时属于外显子、保守区域和某组织表达基因附近，三类标签共同解释相同信号。如果这些标签高度共现，单独权重不稳定并不意味着总预测不稳定。此时可以合并近乎重复注释、引入层级结构，或把解释重点放在组合预测而非单个系数。对高度相关标签逐一排序并赋予强烈生物结论，容易超出数据分辨能力。

功能富集与预测增益也不同。某类注释每个位点平均解释更多遗传方差,说明它在当前模型与群体中富集;但如果这些位点已经被普通标记充分捕捉,额外加权带来的预测增益可能有限。反之,一类注释不具有很强总体富集,却可能帮助少数稀有或跨群体难以标记的变异。研究应同时报告所检验的富集问题与实际预测问题,不能用其中一个替代另一个。

最常见的泄漏来自使用全部表型发现关联位点,再把这些位点包装成固定注释用于交叉验证。即使后续每折重新估计标记效应,测试表型已经通过位点选择进入模型。正确做法是在每个训练折内重建所有依赖当前表型的注释、阈值和权重;真正独立的外部注释可以预先固定。若外部关联研究与当前样本重叠,也应记录重叠及其可能影响,不能仅凭文件来自另一项目就视为独立。

例 31.7 重复使用测试集会产生什么问题。假设一个完全没有真实增益的方法有二十种注释阈值,研究者在同一个测试集上比较后只报告最高准确度。即使每种估计单独无偏,最大值也通常偏高,因为选择过程偏向正向噪声。解决办法不是简单把最高值减去一个固定常数,而是用内层验证选择阈值,再在从未参与选择的外层测试集评估完整流程。报告二十次结果的分布可以说明敏感性,但不能替代独立最终评价。

Tang 等 (2026) 的 IFAM 研究在多类资料中把大量功能注释纳入多随机效应框架。值得关注的是,作者区分了包含性状特异 GWAS 注释的完整模型与仅使用功能注释的情形;后者在所研究家畜和作物资料中的增益较有限。这个结果支持一个具体判断:功能资源的数量并不等于其对目标物种、组织和性状的有效信息量。它并不能推出所有功能注释都无用,也不能把完整模型增益全部归功于外部组学。

在应用中,可以先用少量解释明确的注释构成稳健基线,再逐步增加复杂层次。每次增加都应说明新增假设、额外计算和独立性能变化。如果模型需要大量不稳定注释权重才能获得很小改进,维护成本可能超过收益。相反,若某类注释在跨世代验证中持续改善校准或稀有携带者预测,即使平均相关增幅有限,也可能值得保留。

31.9 分子数量性状位点与共定位

表达数量性状位点、蛋白数量性状位点和代谢数量性状位点，把遗传差异与分子表型联系起来。靠近被测基因的局部作用常被称为顺式关联，远距离或跨染色体作用常被归入反式关联。这里的距离分类是研究操作定义，不等于已证实分子机制；一个附近标记可能只是与真实调控变异连锁，一个远处信号也可能反映细胞组成或其他间接过程。

组织和细胞状态决定关联能否被观察到。某基因只在特定细胞或发育阶段表达，其遗传调控可能在其他组织中难以检测。混合组织测量还受到细胞比例影响：某变异若改变细胞组成，会使大量基因的总体表达随之变化，而不一定直接改变每个细胞内的转录。单细胞资料能够帮助区分这些层次，但有自身测量稀疏、批次和细胞选择问题，不能自动消除所有混杂。

当一个区域同时与分子性状和生产性状关联，共定位分析试图比较“同一个关联来源”与“不同来源恰好位于同一区域”等解释。它利用两个性状的关联模式及连锁结构，而不只是检查最显著标记是否相同。若区域包含多个因果变异，或两个研究群体的连锁不平衡差异很大，简单因果模型可能误导，因此需要与研究设计匹配的共定位方法。

例 31.8 相同峰顶不等于相同因果。设区域内两个因果变异 x_1, x_2 高度相关， x_1 影响表达， x_2 影响生长。若所有观察动物中二者基因型几乎相同，两项关联研究都可能在附近同一个标记达到峰值。这个现象与“表达中介生长”产生相似统计图形。增加具有不同重组背景的样本、进行条件分析或补充分子扰动，才可能区分解释；只比较峰顶坐标无法完成识别。

即使强证据支持共享因果变异，也仍有至少两种可能：该变异改变分子性状，分子性状进而影响生产；或者该变异通过两条独立路径分别影响二者。前者是中介，后者属于水平多效性。共定位可以降低由不同连锁变异造成的假联系，却不能单独确定路径方向。这一边界对后续工具变量分析尤其重要。

共定位结论依赖先验概率、区域范围和关联统计质量。低功效可能导致“不支持共享”，但并不等于证明不存在共享；某个后验概率很高，也应检查是否由极强先验或不完整候选集合驱动。报告时应说明证据支持哪一类假

设、使用了哪些变异、是否允许多因果来源，以及两项研究的样本和祖源关系。把复杂后验压成一个“共定位是或否”的标签，会丢失重要不确定性。

对育种预测而言，共定位信息可以作为功能先验或候选实验排序依据，但未必需要把所有候选路径都宣称为因果。最有效的研究链条往往是：统计关联提出区域，分子关联缩小机制范围，共定位评估共享来源，独立实验检验方向，最后在目标群体评价预测或选择价值。每一步回答不同问题，清楚区分反而有利于累积可靠证据。

31.10 因果图：哪些变量应当调整

因果推断关心的是改变一个变量会怎样改变另一个变量，而不仅是两者如何共同变化。一个有向无环图可以把研究假设写清楚：遗传变量 g 可能影响分子性状 m ， m 影响生产性状 y ，管理因素 c 同时影响 m 与 y 。在这个图中，若要估计 m 对 y 的作用，应处理共同原因 c ；若要估计 g 对 y 的总作用，则不应无条件把中介 m 当作普通混杂因素调整。

调整变量没有“越多越安全”的一般规律。控制真正的共同原因有助于阻断非因果关联；控制中介会改变估计目标；控制共同结果还可能打开原本不存在的关联通路。后者称为碰撞结构。例如遗传潜力和管理质量都影响是否入选核心群，如果只分析入选动物，入选条件可能使两者在样本中相关，即使在原群体中相互独立。

例 31.9 选择样本怎样制造关系。 设遗传潜力和管理条件各为高或低，两者在原群体独立且各占一半。研究只纳入至少有一项为高的动物，于是低遗传、低管理组合被排除，剩下三种组合各占三分之一。在入选样本中，遗传低的动物必定管理高，而遗传高的动物管理高的概率只有二分之一，于是出现负关联。这种关联来自入选规则，不能解释为高遗传动物天然需要较差管理。

同样，按目标表型极端值采集组学样本可以提高某些发现研究的效率，却改变了数据分布。若随后直接用这批样本估计总体分子—表型关系或预测准确度，可能产生选择偏倚。需要在模型或抽样权重中反映选择机制，或者

用独立代表性样本验证。极端抽样本身并非错误，错误在于忘记了结论需要对应抽样设计。

时间顺序是因果方向的重要线索，但不是充分条件。出生时的遗传变量先于成年分子表型，可以排除成年状态改变胚胎基因型的某些解释；然而群体结构、母体效应和连锁多效性仍可能混杂遗传工具与目标关系。分子测量早于生产记录，也不能排除某个更早的共同原因同时影响二者。因此，因果图应结合生物知识、采样流程与潜在选择过程。

图中未画出的变量不等于不存在。研究者应主动列出可能的共同原因，例如年龄、组织组成、采食、药物、疾病状态和场区。并非所有变量都能测量或可靠调整，但明确缺口有助于设计敏感性分析。对于不能直接检验的因果假设，应把它们写成结论成立的条件，而不是隐藏在“校正后显著”这类表述中。

因果图的教学价值还在于区分问题。预测模型可以利用疾病引起的代谢变化预测当前疾病，而不要求代谢物导致疾病；干预模型若据此建议改变代谢物，则需要更强证据。育种模型关心可传递遗传部分，又与两者不同。一个指标可以是优秀预测标志物、差的干预靶点，同时仍具有有限辅助育种价值，这三种评价并不矛盾。

31.11 遗传工具变量：比值容易，识别困难

工具变量方法试图利用某个外部变化来源识别分子性状对目标的作用。若遗传变量 g 与分子性状 m 相关， g 与 $m \rightarrow y$ 关系中的未测混杂独立，并且 g 仅通过 m 影响 y ，则在适当线性条件下可用关联效应的比值估计路径系数：

$$\hat{\theta}_{IV} = \frac{\hat{\beta}_{gy}}{\hat{\beta}_{gm}}.$$

三个条件分别涉及相关性、独立性与排除限制。第一个可以部分由数据检验，后两个通常需要领域知识、设计和敏感性分析支持。

遗传变量在减数分裂中的传递具有随机成分，但这并不意味着任意群体层面的遗传工具天然满足独立性。品种、家系和管理可能相关，父母基因型可

能通过母体环境影响后代，选择也可能改变观察样本中的关联。混合模型控制亲缘有帮助，却不是对所有因果假设的证明。家系内比较能够减少某些群体混杂，同时通常牺牲统计功效并保留其他假设。

例 31.10 水平多效性造成的偏差。某工具对分子指标的关联效应为 0.20，对生产性状为 0.10，比值估计为 0.50。若该工具还通过另一通路直接影响生产性状 0.04，那么真正经分子路径传递的效应只有 0.06，对应系数为 0.30。忽略直接通路使估计高出 $0.20/0.30 \approx 66.7\%$ 。直接作用相对总关联看起来不大，却足以明显改变因果解释。

弱工具使问题进一步恶化。分母接近零时，小幅抽样波动便会造成很大的比值变化，区间可能不对称甚至难以用普通正态近似描述。多个工具可以增加信息，但如果它们由于连锁不平衡高度相关，不能按独立工具处理。工具选择还可能产生赢家偏差，尤其当发现分子关联和估计因果效应使用同一小样本时。独立发现与估计资料、合理弱工具诊断和与相关结构一致的方法都有助于控制风险。

单工具比值的不确定性可以用近似传播理解。若两项关联估计近似独立，方差约为 $\text{Var}(\hat{\beta}_{gy})/\beta_{gm}^2 + \beta_{gy}^2 \text{Var}(\hat{\beta}_{gm})/\beta_{gm}^4$ 。分母的四次方出现在第二项，说明工具弱时分母不确定性不能忽略。样本重叠会产生两项估计的协方差，需要加入相应项；把分母当作精确已知通常会低估区间。

多个工具之间的一致性是有用诊断，但不是因果正确性的保证。如果所有工具都受同一种水平多效性影响，它们可以给出一致却有偏的结果。不同稳健方法各自依赖不同条件，例如大部分工具有效或工具强度与直接效应之间具有特定关系。这些条件在家畜中未必自然成立，因此不应把“多种方法显著”当作已经排除全部偏差。

共定位与工具变量分析可以互补：前者帮助检查分子与生产关联是否可能来自不同连锁变异，后者在额外条件下估计作用方向和大小。但共享变异仍可能水平多效，因而组合两种分析也不是最终证明。若一个候选分子指标具有实际干预意义，适当的随机化扰动、时间序列或组织特异实验，可以补充单纯遗传关联无法提供的证据。

对于育种实践,工具变量结果最适合帮助组织机制假设、识别潜在不良相关反应和优先安排验证。它不能直接决定经济权重,也不能保证改变分子指标的任何方式都等同于改变遗传工具所作用的路径。遗传终生暴露、短期饲料干预和特定组织编辑可能具有不同作用范围,需要分别评价。

31.12 中介分析:总效应、直接效应与路径特异效应

考虑线性系统 $m = \alpha g + \varepsilon_m$ 、 $y = cg + \theta m + \varepsilon_y$ 。在误差结构及因果条件成立时, g 对 y 的总效应为 $c + \theta\alpha$, 直接效应为 c , 经 m 的间接效应为 $\theta\alpha$ 。这个代数分解清楚,但从观察资料识别每一项需要额外条件,尤其是中介与结果之间没有未控制的共同原因,以及调整变量没有受到暴露影响而引入新的偏倚。

例 31.11 一个遗传效应可以被中介分解。设 $\alpha = 0.40$ 、 $\theta = 0.50$ 、 $c = 0.10$, 总效应为 0.30, 其中间接效应为 0.20, 占总效应的三分之二。若将 m 加入普通回归后只报告 g 系数 0.10, 就描述了该模型中的直接部分, 而不是总遗传效应。若育种目标关心后代整体表现, 应保留 0.30 这一总路径; 若研究目的是寻找绕开该分子过程的独立作用, 0.10 才是相关参数。

中介比例并不总是适合解释。直接与间接效应可能异号, 导致比例超过一或为负; 总效应接近零时比例极不稳定。此时应分别报告路径效应及区间, 而不是强行把结果转成“百分之多少由某组学解释”。多中介情况下, 相关分子指标之间的路径可能难以区分, 简单把各自中介比例相加还会重复计数。

高维中介分析有两层选择问题: 哪些分子指标受遗传影响, 哪些与目标有关。若在同一批数据中筛出最强关联后再估计间接效应, 结果容易夸大。需要把筛选、估计与验证的边界说清, 或者采用能够反映选择过程的推断方法。独立样本中的方向重现通常比在同一小样本中构造非常精细的路径图更有说服力。

测量误差对中介分析的影响不只是降低功效。对 m 的噪声会使估计的中介路径衰减, 并可能使原本经 m 传递的部分残留在 g 的直接系数中。于是“存在直接效应”可能部分反映中介测量不完整。若一个生物过程由多个

有误差指标共同反映，潜变量模型或重复测量可以改善估计，但仍需注意模型可识别性和假设。

还要警惕跨层次推断。血液中的代谢物可以反映全身状态，却不一定是相关组织中的因果浓度；整体组织表达可以反映细胞组成，而不一定是单个细胞内调控。即使分子指标是真实中介，测量它的组织和时刻也可能只捕捉部分路径。中介分析应说明“哪个组织、哪个阶段、哪一种测量尺度”的路径，而不是把一个变量名当作完整机制。

干预研究可以帮助检验中介，但干预本身也可能产生额外通路。例如提高某代谢物的饲料处理同时改变采食和微生物组成，结果不能全部归因于目标代谢物。较有力的设计使用不同机制的干预、适当对照和时间顺序测量，观察是否产生一致路径。对家畜研究，还要把实验动物的性别、发育阶段和管理条件与实际育种群体联系起来。

最终，机制解释与预测用途可以分开推进。一个分子评分即使未被证明为中介，也可能作为辅助性状改善评定；一个已验证的中介如果测量成本高、遗传变异小或与已有信息重叠，也未必适合常规选择。把这两种价值分别评价，有助于避免以机制故事代替经济可行性，也避免因为短期预测增益有限而忽视重要生物发现。

31.13 微生物组：组成数据与宿主遗传的边界

微生物组测量常以相对丰度呈现，所有比例之和为一。这一封闭约束意味着一类群比例上升会使其他类群比例相对下降，即使后者绝对数量没有改变。直接把全部比例当作互不相关的自由变量，会把这种数学关系误读为生态作用。分析前需要明确研究对象是相对组成、绝对负荷还是某些功能基因的数量，三者回答的问题不同。

例 31.12 相对下降不等于绝对减少。初始时两类微生物绝对数量分别为 100 与 100，相对丰度各为 0.50。处理后第一类增至 200，第二类仍为 100，第二类相对丰度降为三分之一。若只观察比例，会说第二类下降了约三分之一；实际它的绝对数量没有变化。总负荷测量或适当外部标准可以帮助区分

这两种解释，但也带来额外测量误差。

对数比表示直接关注组成之间的相对关系。例如 $\log(x_1/x_2)$ 在总体测量量同时乘以常数时保持不变。中心化对数比则把每个组分与样本几何均值比较，但所得变量总和为零，存在秩约束，不能无条件视为全秩独立变量。选择参考组分、平衡结构或降维方式，应与生物问题和统计模型一致，而不是仅为得到显著结果。

零值特别需要解释。它可能表示真实不存在，也可能是检测深度不足或过滤阈值造成。简单加一个伪计数可以让对数可计算，却可能对稀有组分产生较大影响。研究应检查不同零值处理和过滤规则的敏感性，报告测序深度与检测限制。把所有零都当作生物学缺失，或者都当作技术噪声，同样缺乏依据。

微生物群落受宿主遗传、饲料、年龄、场区、接触环境和随机定殖共同影响。某些群落特征具有宿主遗传成分，并不意味着整个微生物组像 DNA 序列一样按孟德尔方式传递。若利用微生物信息预测育种值，需要区分宿主可传递作用与可通过管理改变的生态状态。两者都可能具有改良价值，但应分别通过选择与干预评价。

母子共居和共同饲养会使亲属具有相似微生物组，这种相似性不一定由宿主基因造成。跨场亲缘连接、适当重复采样以及不同饲养条件下的亲属比较，可以帮助分离来源。单一场区内的高度相关资料很难支持普遍遗传结论。即使模型拟合了场区固定效应，场区内细微共环境仍可能存在，需要结合设计而非仅依赖一个校正项。

在预测模型中，微生物核可以与基因组核一起使用，但解释仍遵循前述多核原则。较大的微生物方差分量可能代表当时饲料或健康状态；若候选动物未来饲养条件变化，预测关系可能改变。真正的育种验证应尽可能使用后代或后续世代资料，检查宿主遗传部分的可传递性，而不是只评价同批次个体表型。

微生物功能信息有时比分类组成更接近目标过程，但“功能基因存在”与“功能正在以相同强度运行”也不同。转录、底物供应和群落互作都会影

响实际代谢通量。因此，微生物组可以为机制提供线索，也可以作为低成本辅助测量的候选来源；它的价值需要在明确的层次上检验，不能从相关功能名直接跳到稳定生产效果。

31.14 纵向多组学：把稳定差异与短期状态分开

一次采样只观察动物生命过程中的一个切片。对于受日龄、采食、疾病或生殖周期影响的分子指标，纵向资料可以帮助区分稳定个体差异与短期状态。一个基础模型可写为 $m_{it} = \mu(t) + u_i + p_i + q_{it} + \varepsilon_{it}$ ，其中 u_i 为遗传部分， p_i 为稳定非遗传个体部分， q_{it} 为随时间变化的状态， ε_{it} 为测量误差。各部分的分离依赖亲缘、重复次数和时间结构。

重复时间不应只按方便选择。若目标是热应激恢复，应在应激前、期间和恢复期测量；若目标是生殖状态，应与生理阶段对齐；若目标是早期预测，则必须评估早期可获得信号，而不能用末期测量补充。不同动物在不同阶段采样，如果仅按日历日期合并，可能把发育差异误认为遗传差异。

例 31.13 重复测量能减少哪些误差。 设遗传方差为 1，稳定永久环境方差为 1，独立短期状态与测量误差合计方差为 3。单次分子记录的遗传率为 $1/5 = 0.20$ 。四次独立时点平均后，遗传率为 $1/(1 + 1 + 3/4) = 0.3636$ ，而不是接近 1，因为永久环境不能由时间平均消除。若四次短期误差两两相关 0.5，平均误差方差为 $3[1 + 3 \times 0.5]/4 = 1.875$ ，平均记录的遗传率只有 $1/3.875 \approx 0.2581$ 。

时间相关可以通过自回归、平滑曲线、随机回归或其他结构描述，但模型选择应服从采样密度和生物过程。只有两三个稀疏时点时，拟合非常复杂的动态网络往往缺乏识别力。相反，高频数据也不意味着每个时点都提供独立样本，邻近时点的强相关需要进入不确定性评估。把一百次同体测量当作一百头动物，会严重夸大有效信息量。

不同组学的时间尺度也可能不同。转录变化先于蛋白积累，代谢物又受到即时底物供应影响；同时采样未必最有利于识别路径。可以依据生物假设设计滞后测量，但观察到先后关联仍不等于因果。共同外部冲击可以按不同

速度影响多类组学，产生貌似逐层传递的时间图形。动态模型需要考虑这些共同输入。

纵向预测应严格避免未来信息进入早期决策。例如使用完整生长曲线估计一个“早期分子因子”，再声称它能在出生时预测成年表现，就可能泄漏未来观测。正确评价需要在每个预测时点截断资料，只使用当时可得到的信息。对缺失值的平滑也应注意，双向平滑会借用未来观测，实时部署则通常只能采用单向更新。

纵向资料还可能受到信息性退出影响。疾病严重或提前淘汰的动物后期没有样本，留下来的动物并非随机子集。只分析完整轨迹可能低估不良状态及其遗传关联。应记录退出原因，必要时联合建模生存或退出过程，或者进行合理敏感性分析。保留失败和异常样本的信息，常比只保留整齐完整的数据更接近真实生产条件。

31.15 验证设计：区分表型预测与育种值预测

在多组学研究中，测试目标的定义尤其重要。预测同一个体已采样时的表型，可以利用其环境和状态信息；预测未采样后代的平均表现，则更直接检验可传递信息。两种任务都合理，但准确度数值不能不加说明地横向比较。对育种值的验证还需要考虑目标记录本身含有环境噪声，不能把与原始表型的相关直接等同于与真实育种值的相关。

一种有价值的设计是后代验证：在不使用验证亲本目标记录的条件下预测其育种值，再用后代经适当校正的记录评价。这个设计仍需处理配偶贡献、后代数量差异和共同环境，但比单纯预测亲本当时表型更接近遗传传递问题。若后代记录也被用于模型训练或方差参数选择，应明确这种信息使用，避免无意的循环验证。

Guo 等 (2026) 在 8174 头杜洛克猪的研究中使用后代资料评价料重比育种值。加入代谢组后，单性状模型准确度由 0.385 变为 0.394，双性状模型由 0.427 变为 0.432；作者认为增益较小且统计上不显著。该研究的单时点血液测量提醒我们，组学是否增加遗传预测信息是具体设计问题。结果既不能

推广成“代谢组无效”，也不能解释为已经证实显著育种收益。

模型比较应采用相同训练动物、相同测试动物和相同目标。若新方法额外使用候选动物的分子记录，而基线只使用基因型，可以报告它在该信息条件下的改进，但不能把差异全部归因于算法。最好分别比较数据增量与方法增量：先固定方法增加组学，再固定数据比较模型。这样才能判断资源应投入新测量还是新算法。

需要同时检查相关、误差和校准。预测值扩大一倍不会改变相关，却会影响选择指数权重和风险判断。分子数据可能提高排序，同时引入批次相关均值偏差；也可能总体误差下降，却对某类群体系统低估。应报告目标回归于预测的斜率、平均偏差和适合任务的损失，并在有足够样本时评价关键分组。

对于堆叠或残差学习，第一阶段生成的训练预测应采用与第二阶段应用一致的方式。若第一阶段在某动物自己的结果上过度拟合，再把该动物的拟合值交给第二阶段，后者学习到的误差结构与新动物不同。交叉拟合可以减少这一问题：在训练内部对每个动物生成不使用其结果的预测，再训练融合层。这个要求针对相应分阶段学习流程，不意味着所有联合混合模型都必须采用交叉拟合。

最后，外部验证应反映部署边界。按场区、出生年份、品种或实验平台划分的测试，分别考察不同迁移能力；没有一种划分能回答所有问题。若目标是在同一育种体系下一代使用，时间验证通常更直接；若目标是推广到新场或地方品种，则需要相应外部连接。研究者应先定义推广范围，再选择验证方式，而不是从多个划分中挑最漂亮的结果。

31.16 有限预算下的组学设计

多组学项目常面临一个根本选择：把更多种测量施加于少数动物，还是对更多动物进行较少种测量。前者有利于研究同一个体内多层关系，后者通常有利于估计群体遗传效应。最佳方案取决于主要任务。若要识别一个特定生物路径，需要足够精细的组织和时间信息；若要提高全群体育种值准确度，

广泛且代表性的表型与基因型往往不可替代。

可以把预算分为发现、连接和验证三部分。发现样本提供深度组学与机制线索；连接样本同时具有多类测量，用于把不同资料来源放在共同尺度；验证样本则检验候选指标在目标群体中的表现。若全部预算用在发现样本，可能得到许多漂亮关联却无法验证；若没有连接样本，不同组学可能在不同群体中测得，难以区分组学差异与群体差异。

例 31.14 新增指标在选择指数中的经济意义。设现有标准化信息 I 与目标育种值 u 相关 0.60, 新指标 M 与 u 相关 0.50, 二者相关 0.30, 目标遗传方差为 1。联合可靠性为 $(0.36 + 0.25 - 2 \times 0.30 \times 0.60 \times 0.50) / (1 - 0.09) = 0.4725$, 准确度约 0.6874, 相比 0.60 增加 0.0874。在选择强度 1.4、目标标准差 100 的简化条件下, 每代预期反应增加约 12.24 单位。若新增指标只能在少量已成年动物上测量, 或增加世代间隔, 这个反应差还需进一步调整; 它不是完整经济收益。

同样的预算还可以增加常规目标记录或扩大基因组参考群体。比较方案时, 应把成本换成对最终选择反应的影响, 而不是只比较每项技术的相关。若组学费用较高, 可以先筛选稳定候选特征, 再开发便宜的靶向测量。然而, 从高维平台转向靶向平台后, 尺度、检测限和批次结构可能改变, 必须重新校准并独立验证, 不能假定原模型直接可用。

采样个体的选择也影响价值。只测最优秀种畜可以服务特定管理, 但不利于估计完整群体关系; 只测极端表型可以提高发现效率, 却需要适当分析和代表性验证。对于辅助性状遗传参数估计, 跨家系、跨场区和具有目标记录的连接个体尤其重要。测量数量相同的两种设计, 其有效遗传信息可能相差很大。

重复时点与动物数量之间也有权衡。若主要误差来自短期状态, 适当重复能提高稳定指标精度; 若主要不确定性来自遗传样本不足, 增加独立动物可能更有效。可以用先导研究估计遗传、永久环境、短期和技术方差, 再比较不同预算分配的预期信息。先导参数有误差, 因此设计不宜只依赖一个点估计, 应评估合理范围内方案是否稳健。

还需考虑交付时间。一个在选种之后才完成的多组学评分，即使准确度较高，也不能改善已经发生的决策。实验周转、数据清洗、模型运行和质量复核都属于实际成本。生产系统可能更需要一个较简单、稳定且准时的指标，而不是一个复杂但经常迟到的模型。学术研究应把这种约束作为应用问题的一部分，而不是留到最后讨论。

试点阶段可以预先设定继续标准，例如在时间外验证中达到某个误差改善范围，且测量失败率和交付时间可接受。标准应包括不确定性，避免因一次偶然正结果就全面推广，也避免因一次不显著就永久放弃。对于结果接近的方案，还可以考虑可解释性、平台稳定性和未来可扩展性。这些因素不替代统计证据，但会影响相同证据下的实际选择。

31.17 从关联网络走向可积累的生物知识

多组学图谱常产生复杂网络：基因连接转录本，转录本连接蛋白，蛋白连接代谢物，代谢物再连接生产性状。这种组织方式有助于提出假设，但边的含义必须明确。相关网络的边表示共同变化，条件依赖网络的边表示在模型中控制其他变量后的关系，因果网络的箭头则提出干预方向。把三者画成同一种箭头，会让视觉复杂度掩盖证据层级。

网络结构尤其容易受样本量和预处理影响。高相关特征、批次效应以及小样本噪声都可能创造稳定外观的模块。对同一批数据反复改变阈值，可以获得许多看似生物合理的图。较可靠的做法是先明确网络构建规则，报告边或模块对重抽样和独立数据的稳定性，再利用外部知识解释。生物解释应帮助检验网络，而不是只用来为任何结果寻找故事。

在遗传学中，方向证据可以来自等位基因特异表达、家系传递、组织特异扰动和时间顺序，但每种证据有局限。等位基因特异信号有助于识别顺式作用，却可能受到比对偏倚；细胞扰动直接改变某个靶点，却可能使用与真实组织不同的环境；动物实验更接近整体系统，却受样本和伦理约束。把多种独立证据串联起来，通常比把一种证据测得无限精细更有说服力。

研究应区分发现性与确认性阶段。在发现阶段，可以广泛探索特征、组

织和模型，但应如实说明探索范围。确认阶段则应预先固定主要假设、分析方法和评价标准，避免根据结果不断重新定义成功。对于高维数据，单个显著性阈值并不足以反映全部探索自由度，独立重现仍是重要保障。

负结果也能推动设计。某组学未提高预测，可能因为测量时点不合适、遗传信号弱、已有数据已充分覆盖或样本量不足。区分这些解释需要比较测量可靠性、遗传参数、信息重叠和外部误差，而不是简单归因于算法不够先进。若连基础遗传协方差都无法稳定估计，增加更复杂网络未必解决问题；若信号明确但传统模型受表示限制，则新方法才有更清楚的切入点。

功能资源还存在物种与组织的不均衡。某些模式生物具有丰富实验注释，地方畜种和特殊生产阶段则资料有限。跨物种注释可以提供有用先验，但保守序列不保证相同数量效应，同源基因也不保证相同组织调控。应把跨物种信息作为可检验迁移假设，并保留物种特异数据修正的空间。对人类疾病训练出的功能评分，更不能直接当作家畜经济性状效应。

从可复现角度看，组学研究需要保存的不只是最终特征表。样本处理记录、原始测量映射、归一化参数、特征注释版本、训练划分和代码环境都可能改变结果。特别是同名基因、不同转录本或不同代谢峰的合并规则，应足够明确。若两个研究使用同一个“分子指标”名称却测量不同对象，表面上的不一致可能来自定义而非生物差异。

最后，组学知识与育种行动之间应保持可追踪连接。一个候选通路进入选择指数，需要说明它通过什么可测指标、遗传参数和经济权重影响综合目标；一个候选变异进入功能先验，需要说明注释如何改变收缩及其外部表现；一个干预建议需要说明因果证据。把这些连接写清楚，多组学才能从数据丰富走向决策有效，也才能在新证据出现时知道应更新哪一部分。

研究团队还应保留对原假设不利的结果，包括未重现的候选指标、质量较差但有代表性的样本和不同批次中的性能下降。它们能够揭示模型的适用边界，并指导下一轮采样。只积累显著发现而丢弃这些信息，会使资源选择长期偏向被偶然高估的方向。

31.18 分子测量误差的衰减与联合模型

分子表型进入模型之前，先要区分真正的分子状态与仪器读数。设中心化的真实状态为 m ，测量值为 $w = m + \delta$ ，目标表型为 $y = \theta m + \varepsilon$ 。本节先假定 m, δ, ε 相互独立，均值为零，方差分别为 $\sigma_m^2, \sigma_\delta^2, \sigma_\varepsilon^2$ ；测量误差不受基因型、批次和目标表型影响。这是经典测量误差模型，适合解释基本机制，但不覆盖检测下限、浓度依赖误差和病例差异性误差。

观测协方差可以逐项展开：

$$\text{Cov}(w, y) = \theta \sigma_m^2, \quad \text{Var}(w) = \sigma_m^2 + \sigma_\delta^2.$$

于是将 y 直接对 w 回归所得的总体斜率为

$$\theta_{naive} = \theta \lambda, \quad \lambda = \frac{\sigma_m^2}{\sigma_m^2 + \sigma_\delta^2}.$$

λ 称为测量可靠程度，位于零与一之间。斜率变小不是生物作用必然弱，而是每单位观测变化同时混入了真实变化与误差变化。若样本量趋于无穷，朴素回归仍收敛到 $\theta \lambda$ ；增加动物数只能缩小围绕这个有偏极限的抽样误差，不能自动修正衰减。只有额外结构，例如重复测量、已知误差方差或独立校准样本，才能区分两种变异。

在联合正态假设下，真实分子状态给定观测值的条件分布为

$$E(m | w) = \lambda w, \quad \text{Var}(m | w) = \frac{\sigma_m^2 \sigma_\delta^2}{\sigma_m^2 + \sigma_\delta^2}.$$

将这个分布代入表型模型，便得到

$$\begin{aligned} E(y | w) &= \theta \lambda w, \\ \text{Var}(y | w) &= \sigma_\varepsilon^2 + \theta^2 \frac{\sigma_m^2 \sigma_\delta^2}{\sigma_m^2 + \sigma_\delta^2}. \end{aligned}$$

因此，对有误差读数作最佳表型预测时，衰减后的斜率可以是正确预测系数；若问题是估计真实分子状态的生物作用，衰减又是需要修正的偏差。同一个数值是否“有偏”，必须相对于估计目标判断。把所有小斜率都校正放大，可能改善机制参数解释，却破坏以同样有误差读数为输入的实际预测。

推导例：作用系数与预测系数。设真实分子方差为 4，技术误差方差为 5，真实作用为 0.8，其余表型误差方差为 1。观测回归斜率为 $3.2/9 = 0.3556$ 。对读数 $w = 3$ ，真实分子状态的条件均值为 $4/3$ ，表型预测为 1.0667，条件表型方差约为 2.4222。若直接用 0.8×3 预测，会把仪器噪声当作生物状态，得到过大的 2.4。这个例子说明，机制模型与部署预测可以使用不同形式，却共同来自同一个相容的概率模型。

如果获得 r 次独立技术重复，平均误差方差降为 σ_δ^2/r ，可靠程度变为

$$\lambda_r = \frac{\sigma_m^2}{\sigma_m^2 + \sigma_\delta^2/r}.$$

但技术重复也可能共享样本处理偏差。令 $\delta_t = b + \eta_t$ ，其中 b 是各次重复共同的偏差， η_t 彼此独立，则

$$\text{Var}(\bar{\delta}) = \sigma_b^2 + \frac{\sigma_\eta^2}{r}, \quad \text{Cov}(w_1, w_2) = \sigma_m^2 + \sigma_b^2.$$

若将第二式的协方差全部归为真实分子方差，会高估可靠程度。令共同误差方差为 2、独立误差方差为 3，两次重复平均后的误差方差是 3.5，不是 2.5；相应可靠程度为 $4/7.5 = 0.5333$ ，而非 $4/6.5 = 0.6154$ 。共享偏差即使重复无数次仍不会消失。跨日独立制样、标准样本与不同测量平台能提供不同的识别信息，不能把同一提取物的重复进样与独立生物重复视为等价。

多维组学中的衰减更复杂。令真实分子向量协方差为 Σ_m ，测量误差协方差为 Σ_δ ，则朴素回归向量满足

$$\theta_{naive} = (\Sigma_m + \Sigma_\delta)^{-1} \Sigma_m \theta.$$

右边是一个矩阵变换，某些单独系数可能变大、改变符号或在相关指标间重新分配，并非每个坐标都乘同一个小于一的数。高度相关的代谢峰尤其如此。研究者若要解释某个单峰的作用，必须关注误差相关和指标共线性；若只要一个稳定预测分数，则可以直接评价整个观测层模型的外部性能。测量模型由实验设计提供支撑，统计模型负责传播其后果，两者缺一不可。

还需区分另一类误差：研究者可能按一个设定值分配暴露，而个体真实状态围绕设定值波动。若设定值为 w ，真实状态为 $m = w + \delta$ ，且 δ 与 w 独

立，则称为伯克森型误差。在简单线性模型中，

$$E(y | w) = \theta w, \quad \text{Var}(y | w) = \sigma_\varepsilon^2 + \theta^2 \sigma_\delta^2.$$

此时线性斜率不会出现前述经典衰减，但残差方差增大。检测仪器给出的有噪声读数与按饲料处理指定的暴露水平，可能对应不同误差机制。若把后者也机械除以一个可靠程度，反而会过度放大作用。非线性反应下即使伯克森误差也可以改变条件均值，因为一般有 $E\{f(w + \delta)\} \neq f(w)$ 。因此，决定校正方法之前应先画清真实量、观测量和设定量之间的生成顺序，而不是看到“误差”二字就使用同一系数。

31.19 辅助组学的价值是条件遗传信息

分子性状与目标性状高度相关，并不意味着在已有基因组预测之外仍有很大增益。设目标育种值为 u ，已有信息向量为 b ，新增组学向量为 m 。所有变量先在同一基群和单位下中心化。以下推导只用二阶矩，因此可解释为最佳线性预测；若进一步假定联合正态，它同时是精确条件期望。

令已有信息的协方差为 V_b ，新增信息协方差为 V_m ，交叉协方差为 C_{mb} ，目标与两类信息的协方差分别为 c_b 与 c_m 。先把组学对已有信息作线性残差化：

$$r_m = m - C_{mb} V_b^{-1} b.$$

其协方差与目标交叉协方差为

$$S_m = V_m - C_{mb} V_b^{-1} C_{mb}^\top,$$

$$c_{u,r} = c_m - c_b V_b^{-1} C_{mb}^\top.$$

若 S_m 正定，增量预测与预测误差方差下降量为

$$\hat{u}_{new} = c_b V_b^{-1} b + c_{u,r} S_m^{-1} r_m,$$

$$\Delta PEV = c_{u,r} S_m^{-1} c_{u,r}^\top.$$

这正是选择指数中舒尔补结构在多组学中的具体应用。真正决定增益的是组学残余部分与目标遗传值的协方差，而不是组学与目标原始表型的边际相关。若 S_m 奇异，应在其可估子空间中求解，并检查 $c_{u,r}$ 是否与该空间相容；用数值脊项绕过奇异性会改变模型，应当被明确说明。

推导例：边际正相关也能得到负增量权重。令 $\text{Var}(u) = 4$ 、 $\text{Var}(b) = 1$ 、 $\text{Var}(m) = 2$ ，并设 $\text{Cov}(u, b) = 1.2$ 、 $\text{Cov}(u, m) = 1$ 、 $\text{Cov}(m, b) = 1.1$ 。组学与目标的边际协方差为正，但残余协方差为 $1 - 1.2 \times 1.1 = -0.32$ ，残余方差为 $2 - 1.1^2 = 0.79$ 。新增系数为 $-0.32/0.79 = -0.4051$ ，误差方差下降约为 0.1296 。原有误差方差为 $4 - 1.2^2 = 2.56$ ，新增后约为 2.4304 。负权重是在纠正已有预测中与组学共同变化的部分，并不证明提高这个分子指标会使动物遗传潜力下降。

若新增测量还有与所有真实变量独立的技术误差，协方差向量 $c_{u,r}$ 不变，而 S_m 增加误差协方差 Ω 。增量变为

$$\Delta \text{PEV}_{\text{noisy}} = c_{u,r} (S_m + \Omega)^{-1} c_{u,r}^T.$$

当 Ω 半正定时，这个值不会大于无误差情形，体现信息在测量中的损失。在前例中增加方差为 0.5 的独立技术误差，增量降为 $0.1024/1.29 \approx 0.07938$ 。改善组学平台可提高这个增量，但若 $c_{u,r} = 0$ ，再精密的测量也不能提供当前线性目标的额外信息。此时真正需要改变的可能是组织、时间点或目标定义，而不只是仪器精度。

这里的协方差必须针对目标育种值。设 $m = u_m + e_m$ ，目标原始表型为 $y = u + e_y$ 。则

$$\text{Cov}(m, y) = \text{Cov}(u_m, u) + \text{Cov}(e_m, e_y)$$

在遗传与环境交叉独立条件下成立。疾病状态、饲料或采样时间可以使环境协方差很大，从而形成很好的当代表型预测，却不相应增加后代遗传预测。Guo 等 (2026) 对猪饲料转化率的研究区分了单性状、双性状以及代谢与基因组联合模型，报告的代谢信息贡献有限。这类结果提示应核对目标和条件增量；不能从有限增益推断代谢机制不重要，也不能从代谢—表型相关较高推断育种值精度必然明显提高。

实际中,协方差通常需要估计,代入公式所得增益容易偏乐观。尤其是先用同一批表型筛选分子指标,再估计 $c_{u,r}$, 会系统挑中偶然较大的协方差。外层验证应包含整个筛选和协方差估计过程;训练中可用适当收缩稳定 S_m , 但必须重新计算目标与信息对应关系。把已由表型选择过的组学评分命名为“外部功能特征”,并不会消除依赖。

信息增量还与候选阶段是否能获得组学测量有关。如果参考动物有分子记录,而候选动物没有,不能直接把上式中的候选 m 代入为零;零代表一个观察到的平均水平,缺失代表尚未观察。应通过候选与参考动物的遗传联系预测分子遗传部分,并重新计算交叉协方差。若用候选已有的 b 先线性预测 m , 再把这个预测值作为所谓新增信息,在预测映射固定的条件下,新增残差恰为零。这样复制已有信息可能改变数值权重,却不能凭空增加信息。只有外部训练资料确实改变了已知映射,或者候选新增真实测量,才可能产生相应增益。

另一个设计差异是先测全部动物再选择,与先按已有预测选择少数动物再测组学。第二种策略可以把预算集中于最可能影响决策的区域,但所得样本不再代表整个群体。估计全群体协方差时需要处理选择机制;评价方案收益时则应按整套两阶段规则计算。只在已入选的高预测动物中报告相关,可能同时受到范围压缩和选择条件诱导的关联影响。新数据是否“有价值”,应分别回答参数学习价值、候选区分价值和最终行动价值。

31.20 有误差中介与工具变量的识别边界

前面的中介分解需要扩展到中介测量有误差的现实条件。令遗传变量 g 的方差为一,真实分子中介为 $m = \alpha g + \eta$, 生产性状为 $y = cg + \theta m + \varepsilon$, 观测中介为 $w = m + \delta$ 。先假定 $g, \eta, \delta, \varepsilon$ 相互独立, $\text{Var}(\eta) = v_\eta$ 、 $\text{Var}(\delta) = v_\delta$ 。总遗传作用由代入得到:

$$y = (c + \theta\alpha)g + \theta\eta + \varepsilon.$$

因此,不调整中介时, y 对 g 的总体斜率为

$$\beta_{total} = c + \theta\alpha.$$

要研究同时回归 y 对 g, w 的系数, 可以先把二者对 g 残差化。中介残差为 $\eta + \delta$, 结果残差为 $\theta\eta + \varepsilon$, 所以观测中介系数为

$$\theta_w = \theta \frac{v_\eta}{v_\eta + v_\delta}.$$

再由总斜率分解, 遗传变量的调整后系数为

$$c_w = \beta_{total} - \alpha\theta_w = c + \theta\alpha \frac{v_\delta}{v_\eta + v_\delta}.$$

测量误差不仅把中介系数向零拉, 还把一部分真实间接效应留在“直接”系数中。这里的残余方差 v_η 决定衰减, 而不是中介的总方差 $\alpha^2 + v_\eta$, 因为遗传解释部分已经在多元回归中被调整。这是把单变量可靠程度机械用于中介校正时经常遗漏的一步。

推导例：直接效应如何被夸大。取 $\alpha = 0.5$ 、 $\theta = 0.8$ 、 $c = 0.2$ 、 $v_\eta = 1$ 、 $v_\delta = 3$ 。真实总效应为 0.6, 直接效应为 0.2, 间接效应为 0.4。有误差中介回归给出 $\theta_w = 0.2$ 、 $c_w = 0.5$ 。朴素分析会把直接效应报告为真实值的两点五倍, 并把间接部分缩至 0.1。总效应仍等于 $0.5 + 0.5 \times 0.2 = 0.6$, 所以只检查总效应是否一致不能发现路径分配错误。重复中介测量若有助于估计 v_δ , 可以改善分解, 但不能替代对中介—结果混杂的识别。

现在允许 η 与 ε 存在协方差 κ 。同样残差化后得到

$$\theta_w = \frac{\theta v_\eta + \kappa}{v_\eta + v_\delta}.$$

即使技术误差趋于零, 系数仍趋于 $\theta + \kappa/v_\eta$, 而不是 θ 。这表明测量误差校正与因果混杂校正解决两个独立问题。在前例若 $\kappa = -0.8$ 且相应联合误差协方差矩阵合法, 观测中介系数可以等于零, 尽管真实路径系数为 0.8; 若 κ 与真实路径同号, 又可以掩盖技术误差的衰减。单凭一个回归系数大小, 无法判断哪一种机制在起作用。

工具变量试图利用外部变化识别路径。在各变量已中心化的约定下, 设工具 z 与中介相关, $E(zm) \neq 0$, 并满足完整排除条件 $E\{z(cg + \varepsilon)\} = 0$ 。这一条件不仅排除工具对结果的直接作用, 还排除它通过与 g 相关而携带未调

整直接路径。另一种处理是先对 g 及其他允许协变量作正确调整，再对残差化后的工具、中介和结果使用下列矩条件；此时仍须检查残余工具的相关性及排除限制，不能只凭调整动作宣称识别成立。

$$E\{z(y - \theta m)\} = 0, \quad \theta = \frac{E(zy)}{E(zm)}.$$

如果观测中介误差与 z 独立， $E(zw) = E(zm)$ ，工具变量比值可以避免经典中介测量误差引起的衰减。但一旦工具存在直接作用 dz ，其极限就变为

$$\theta_{IV} = \theta + \frac{dE(z^2)}{E(zm)}.$$

分母越小，同样的直接作用造成的偏差越大。若工具就是上例的 g ，则因为 $c = 0.2$ 并不满足排除限制，比值为 $0.6/0.5 = 1.2$ ，不是 0.8 。遗传变量出生前已经确定，只能支持时间顺序的一部分，不能自动证明它仅通过所研究的一个代谢物影响生产。

多中介、多工具情形还需要秩条件。令工具对 q 个中介的关联矩阵为 Γ ，工具对结果的关联向量为 γ ，有效工具假设下有

$$\gamma = \Gamma\theta, \quad \text{rank}(\Gamma) = q.$$

若两个工具对两中介的效应向量分别为 $(0.3, 0.1)$ 和 $(0.6, 0.2)$ ，两行成比例，只有一个独立方向，无法分别识别两个路径。所有 $\theta + t(1, -3)^T$ 都产生相同关联结果。增加更多具有相同比例的工具不会修复这一问题；需要在生物作用方向上提供新的独立变化。这个条件把“工具数量多”与“识别信息足够”明确区分开来。

因果结论应当把这些条件写在效应解释旁边。功能实验可以支持某条路径，遗传关联可以提供群体中的变化来源，重复测量可以约束技术误差，但三者分别提供不同证据。只有当它们共同覆盖目标物种、组织、时期和选择机制时，路径解释才有可能稳定迁移到育种问题。

31.21 功能加权后验如何同时表达效应与不确定性

功能注释最稳妥的作用之一，是改变效应分布的先验，而不是把注释分数直接当作效应值。设中心化模型 $y = Za + e$ ，残差协方差为已知 R ，标记

效应先验为 $a \sim N(0, D)$, 其中 D 为正定的功能加权先验协方差。将似然与先验的二次型相加:

$$\begin{aligned} -2\log p(a | y) = & (y - Za)^T R^{-1} (y - Za) \\ & + a^T D^{-1} a + \text{与 } a \text{ 无关的常数.} \end{aligned}$$

整理二次项与一次项并完成平方, 得到后验协方差和均值:

$$\begin{aligned} S_a &= (Z^T R^{-1} Z + D^{-1})^{-1}, \\ m_a &= S_a Z^T R^{-1} y. \end{aligned}$$

这两式说明先验同时改变收缩方向和不确定性; 若只报告加权后的点估计而继续使用未加权模型的误差方差, 便会破坏相容性。连锁不平衡通过 $Z^T R^{-1} Z$ 的非对角项进入, 功能信息不能绕过它直接识别各位点作用。两个近乎相同的标记, 即使获得不同注释, 也可能主要依赖先验来分配效应。

推导例: 忽略连锁会改变效应方向。 设 $R = I$, 两个标记的交叉乘积矩阵对角均为 10、非对角为 8, $Z^T y = (4, 2)^T$, 先验方差分别为 0.25 和 1。后验精度矩阵与其逆为

$$S_a^{-1} = \begin{pmatrix} 14 & 8 \\ 8 & 11 \end{pmatrix}, \quad S_a = \frac{1}{90} \begin{pmatrix} 11 & -8 \\ -8 & 14 \end{pmatrix}.$$

于是后验均值为 $(28/90, -4/90)^T$, 即约 $(0.3111, -0.04444)^T$ 。如果错误地忽略非对角关联, 第二个效应会被算成 $2/11 = 0.1818$, 连符号都不同。这里不是功能注释改变了真实生物方向, 而是两个相关标记竞争解释相同表型信息; 只有结合设计与先验, 才能解释条件效应。

对一个候选动物的确定标记向量 z_* , 遗传预测及条件误差方差为

$$\hat{u}_* = z_*^T m_a, \quad PEV_* = z_*^T S_a z_*.$$

若某一候选注释只是有一定概率可信, 固定一个加大后的方差并不完整表达注释不确定性。可令 $A_j \in \{0, 1\}$ 表示潜在功能类别, 先验概率为 π_j , 并

写成

$$a_j | A_j = k \sim N(0, \tau_k^2), \quad \Pr(A_j = 1) = \pi_j.$$

在独立单标记教学模型 $\tilde{a}_j | a_j \sim N(a_j, s_j^2)$ 下, 两个类别的边缘似然比为

$$B_{10} = \sqrt{\frac{s_j^2 + \tau_0^2}{s_j^2 + \tau_1^2}} \exp \left[\frac{\tilde{a}_j^2}{2} \left\{ \frac{1}{s_j^2 + \tau_0^2} - \frac{1}{s_j^2 + \tau_1^2} \right\} \right].$$

后验类别概率由先验赔率乘以证据更新:

$$\Pr(A_j = 1 | \tilde{a}_j) = \frac{\pi_j B_{10}}{1 - \pi_j + \pi_j B_{10}}.$$

因此, 高功能先验只是起点, 数据仍可降低其权重; 反之, 一个注释并不显著的位点, 也可能因独立强证据获得较大后验概率。类别内的正态后验均值为 $\tau_k^2 \tilde{a}_j / (\tau_k^2 + s_j^2)$, 总后验均值是按更新后类别概率加权, 而非按最初的 π_j 加权。总方差还包含类别均值之间的差异, 不能只平均类别内方差。

Tang 等 (2026) 的 IFAM 研究把多种功能注释纳入多随机效应框架, 并在若干资料中比较包含性状特异关联注释与只用功能注释的情形。这一设计提醒我们, 信息来源与效应分布假设应分别评价。上述混合先验是用来解释这一类思想的教学模型, 并不等于 IFAM 的具体算法; 其单标记独立似然也不能直接用于具有强连锁的全基因组分析。转向实际应用时, 需要把连锁、注释重叠和权重估计的不确定性放回联合模型。

推导例: 注释证据与数据证据怎样合并。为便于手算, 将弱效类别简化为效应恰为零的点质量, 强效类别方差设为 0.16, 先验强效概率为 0.1。某位点粗略效应为 0.6, 标准误为 0.2。将 $\tau_0^2 = 0$ 代入边缘似然比可得约 16.367, 更新后的强效概率约为 0.6452。强效类别内的后验均值是 0.48, 总后验均值约为 0.3097。因此, 观察到较大效应并没有使强效类别概率自动变成一; 用最大后验类别作硬分类会丢掉剩余类别不确定性。

本例强效类别内后验方差为 0.032, 混合后验方差还包括零类别与非零类别均值不同所产生的变异:

$$\text{Var}(a | \tilde{a}) = p_1 (0.032 + 0.48^2) - (0.48p_1)^2.$$

结果约为 0.07339，大于只看强效类别时的 0.032。这就是“某类注释很可信”与“已经确定每个位点属于该类”的差别。若注释概率由当前表型拟合，还需传播其参数不确定性；本例把先验概率视为已知，只用于展示类别更新，并未声称这些数值适用于某一真实变异。

31.22 多核方差分解的可识别性与预测边界

组学整合常用多个核矩阵描述不同来源的相似性。令

$$V = \sigma_1^2 K_1 + \sigma_2^2 K_2 + \sigma_e^2 I.$$

这个表达式保证模型可以把不同协方差形状放在一起，却不保证资料能够唯一分解其来源。如果 $K_2 = 2K_1$ ，模型只通过组合 $\sigma_1^2 + 2\sigma_2^2$ 决定 V ：

$$V = (\sigma_1^2 + 2\sigma_2^2) K_1 + \sigma_e^2 I.$$

于是 $(\sigma_1^2, \sigma_2^2) = (0.6, 0.2)$ 与 $(0.8, 0.1)$ 具有相同观测分布。再复杂的优化算法也不能从同一个似然辨别它们。两个核对应不同的生物名称并不改变这个数学事实；如果它们在当前样本中表示同一种关系方向，分量解释需要更多设计信息。

在正态混合模型中，可以通过方差参数的期望信息理解近似不可识别。令 P_V 为消去固定效应后的广义残差矩阵， $K_r = \partial V / \partial \sigma_r^2$ 。限制似然的期望信息为

$$\mathcal{I}_{rs} = \frac{1}{2} \text{tr} (P_V K_r P_V K_s).$$

若两个核在这一加权几何下近乎成比例，相应信息矩阵便接近奇异。某分量的巨大标准误或边界估计，可能来自无法区分的形状，而非它代表的生物过程不存在。可以计算加权核相关作为诊断：

$$\rho_K = \frac{\text{tr} (P_V K_1 P_V K_2)}{\sqrt{\text{tr} (P_V K_1 P_V K_1) \text{tr} (P_V K_2 P_V K_2)}}.$$

这个诊断量不是性状的遗传相关，也不是证明某组学没有新增信息的最终检验。它只描述在当前固定效应和协方差尺度下，两种核形状有多难区分。

较高相似度可能使分量归属不稳定，而总预测仍稳定；相反，核形状不同也不意味着新增核对目标遗传值有帮助。

一个常见做法是先把组学特征 M 对基因组特征 Z 作残差化：

$$M_{\perp} = (I - P_Z) M, \quad P_Z = Z (Z^T Z)^{-1} Z^T.$$

由此构造 $M_{\perp} M_{\perp}^T$ 可以降低样本内重叠，但同时改变了问题。若组学中真正有用的遗传信号恰位于 Z 张成的方向，残差化也会把这部分信号删除。样本内正交只保证矩阵内积性质，不保证生物过程独立，更不保证在新动物上仍正交。新动物的投影必须使用训练中确定的映射，不能重新借助测试表型选择残差方向。

推导例：完美重复信息的两种解释。假定一个分子特征恰为某标记的两倍，即 $m = 2z$ 。将两个特征同时放进固定效应回归，只有 $a_z + 2a_m$ 可估；把它们作为两个随机核，只有对应方差组合可估；先将 m 对 z 残差化，则 $m_{\perp} = 0$ 。三个结果彼此一致，说明当前样本没有额外统计方向。它们都不能否定该分子状态参与真实生物通路，因为遗传作用可以完全通过该状态传递，却仍无法从重复测量中分离路径。

对预测任务，合理报告可以包含总遗传预测、增量误差下降和分量敏感性，而对机制任务，应增加跨组织、跨时间或干预设计来区分来源。不要把方差比例的名称自动转换成因果解释，例如“代谢核解释的方差”未必等于“由代谢中介的遗传方差”。尤其当组学同时含遗传和环境成分时，前者可以吸收共同饲养、批次甚至测量误差。

最后，核的构造与方差估计属于同一学习流程。中心化、缺失填补、特征筛选、尺度标准化以及超参数选择都应在训练资料中确定。若多个核需要合并，应依据清楚的预测目标和稳定性证据，而不是只为了让方差分量看起来漂亮。一个可解释的多组学模型，不是要求所有分量都显著，而是能够说明哪些方向被资料区分、哪些结论依赖先验、以及这些不确定性怎样影响最终育种决策。

核的任意尺度还会改变方差参数的表面数值。若把 K_2 改为 $K_2^* = cK_2$,

同时令 $\sigma_2^{2*} = \sigma_2^2/c$, 则 V 完全不变:

$$\sigma_2^{2*} K_2^* = \sigma_2^2 K_2.$$

所以比较不同核的方差大小之前, 必须核对是否按相同的平均对角或其他明确规则标准化。一个分量数值增大, 可能只因核缩小, 不能被解释为生物重要性上升。若仅给总预测, 尺度相容的转换可以完全等价; 若给每种组学分配独立功劳, 结论便可能非常依赖参数化。

更严重的是, 协方差分量不能识别时, 分量预测也可能不能识别。给定固定均值已知, 第一分量的条件均值为

$$\hat{u}_1 = \sigma_1^2 K_1 V^{-1} y.$$

在前述成比例核的例子中, 两个合法分解产生相同 V 和相同总预测, 却产生不同 $\hat{u}_1$ 。因此, “总预测在外部验证中稳定” 不足以证明 “代谢遗传分量已被准确分离”。如果实际选择目标只包括其中一个可传递分量而排除环境分量, 来源不可识别将直接影响决策, 并非仅仅影响论文中的方差饼图。

31.23 综合练习与解答

练习 1. 某分子指标真实方差为 9, 独立技术误差方差为 3。求单次、两次平均和三次平均测量的可靠程度。若经费只够增加一次测量, 说明技术重复与增加一个独立动物各自解决什么问题。

解答. 三种可靠程度分别为 $9/12 = 0.75$ 、 $9/10.5 \approx 0.8571$ 和 $9/10 = 0.90$ 。技术重复主要减少该样本的测量误差, 独立动物主要增加群体效应和协方差估计的信息。若误差主要是共同批次来源, 技术重复收益更小; 若目标是精确检测少数关键样本, 重复可能更有价值。不能仅凭可靠程度较高就决定全部预算投向重复。

练习 2. 分子指标与目标性状的遗传方差分别为 0.25 和 0.36, 遗传协方差为 0.12。求遗传相关。若表型方差均为 1, 残差协方差为 -0.10 , 表型相关是多少? 说明只按表型相关筛选的风险。

解答。遗传相关为 $0.12/\sqrt{0.25 \times 0.36} = 0.40$ ，表型相关为 0.02。环境层面的负协方差几乎抵消遗传正协方差，因此原始表型相关很小。只根据表型相关可能丢弃一个具有遗传辅助价值的指标，但是否值得测量仍需结合成本、已有信息和参数不确定性。

练习 3。在总育种值 $u = u_0 + 0.5u_m$ 中，两个成分方差分别为 3 与 4，协方差为 0.4。求总遗传方差。若分子环境方差为 5，能否把分子表型路径的全部方差计入育种值？

解答。总遗传方差为 $3 + 0.25 \times 4 + 2 \times 0.5 \times 0.4 = 4.4$ 。分子表型路径方差为 $0.25 \times 9 = 2.25$ ，其中 1.25 来自环境，不应因进入路径模型就计为遗传方差。协方差项也不能被忽略，除非模型或设计支持独立假设。

练习 4。某位点粗略效应估计为 0.5，标准误为 0.1，先验方差为 0.09。求后验均值和后验方差。如果先验来自同一批全体表型挑出的显著位点，交叉验证还缺少什么步骤？

解答。后验均值为

$$0.09/(0.09 + 0.01) \times 0.5 = 0.45$$

后验方差为

$$0.09 \times 0.01/0.10 = 0.009$$

若注释由当前表型产生，应在各训练折内重新进行发现与选择，并把所有阈值调优限制在训练过程。仅在最后重新拟合效应不能消除先前通过位点筛选引入的测试信息。

练习 5。两个组学核完全相同，模型分别给出方差分量 0.2 与 0.8。能否得出第二组学的生物贡献是第一组学四倍？

解答。不能。若两个核相同，资料只识别总方差 1.0，不能唯一识别拆分。优化器可能因初值或约束返回某一组合，但该数值不具有独立生物解释。需要不同信息结构、额外假设或重新定义模型；也可以诚实地只报告合并分量。

练习 6。某遗传工具对分子指标效应为 0.25，对目标效应为 0.15。比值

估计是多少？若工具另有直接效应 0.05，真实中介系数是多少？列出不能由比值计算本身证明的两个条件。

解答。比值为 0.60；扣除直接通路后系数为 $(0.15 - 0.05)/0.25 = 0.40$ 。计算本身不能证明工具与未测混杂独立，也不能证明排除限制。工具强度、连锁结构、样本重叠和选择过程还会影响估计及其不确定性。

练习 7。某研究发现表达性状与生长性状高度共定位，随后写道“提高该基因表达必然提高生长”。指出缺失的推断环节，并提出至少两类补充证据。

解答。共定位主要支持共享关联来源，不排除水平多效性，也不自动确定表达对生长的方向和干预效果。可补充组织与时间合适的扰动实验、具有明确假设的遗传工具分析、独立群体重现或等位基因特异功能研究。不同证据回答不同问题，不能简单以证据数量代替假设检查。

练习 8。两类微生物绝对数量从 (50, 150) 变为 (100, 150)。求第二类的相对丰度变化，并说明直接比较比例可能造成什么误解。

解答。第二类比例从 0.75 变为 0.60，相对比例下降 20%，绝对数量却未改变。变化来自第一类增加后总量变大。应根据问题考虑绝对负荷、对数比或其他组成分析，并明确零值和测量深度的处理；不能把比例下降直接解释为第二类被抑制。

练习 9。某模型用动物育肥末期血液代谢谱预测其同日采食量，相关达到 0.8。研究者希望将其用于出生时公畜选择。需要补充哪些验证？

解答。首先明确出生时是否能获得相同或可替代信息；若不能，应建立只用出生时可得资料的模型。其次区分代谢谱中的遗传与环境部分，评价与目标育种值的遗传协方差，并采用后代或后续世代资料验证。最后比较成本、世代间隔和已有基因组信息后的增量。原相关 0.8 仅支持当前信息条件下的表型预测。

练习 10。两个模型在同一测试集中的相关分别为 0.62 和 0.64，但第二个模型在测试动物自己的组学记录上预测，第一模型只用基因型。怎样报告比较才恰当？

解答。应说明这是两个信息方案的比较，不能把 0.02 差异全部归因于模型算法。可以在同样输入下比较算法，再分别评估增加组学的效果；同时给出配对不确定性、校准和成本。若实际候选动物没有组学记录，还必须评价相应缺失信息情景。

练习 11。某高维分子网络在训练集具有清晰模块，换一个实验批次后模块大幅变化。写出三种可能原因，并说明下一步如何区分。

解答。原因可能包括技术批次效应、真实生物状态差异和小样本估计不稳定。可以使用跨批次参考样本检查测量偏移，比较采样组织与状态，采用预先固定的处理和重抽样评估稳定性，再在代表性独立资料中验证。不能仅凭原模块具有生物学名称就认定新批次错误，也不能仅凭变化就断言全部网络无效。

练习 12。设计一个小型多组学试点，目标是改进年轻候选动物某难测性状的育种值。说明发现、连接、验证样本应各自承担什么功能。

解答。发现样本用于深度测量并提出候选指标或功能先验；连接样本同时具备基因型、关键组学与目标或亲属记录，用于估计遗传关系及平台转换；验证样本在模型冻结后检验候选阶段可得信息的预测表现。应预先确定时间边界、主要评价指标和资源约束，并保留独立后续资料，避免把所有样本都用于反复筛选。

基因与环境互作、韧性和可持续育种

32.1 育种值为什么总有环境背景

育种值不是脱离群体和环境的永久标签。它描述特定条件下可由加性遗传差异预测的后代平均优势。高营养投入下生长快的动物，在长期热负荷、饲草波动或病原压力下未必仍然领先；一个地区的最佳种畜，也未必适合另一个生产体系。环境改变性状的表达方式，可能改变遗传差异的大小，甚至改变动物的相对排序。

必须区分环境主效应与基因和环境互作。如果高温使所有动物产量都下降相同数值，环境主要改变平均值，适当固定效应即可描述；如果不同基因型下降程度不同，就存在互作。互作又可表现为尺度变化或重新排序：遗传差异整体放大而排序保持，属于前者；反应曲线交叉使优势动物改变，则属于后者。它们对数据标准化、评定和选种的意义不同。

例 32.1 尺度变化并不必然改变排序。两头动物在温和环境中的遗传值为1与2，在优质环境中变为2与4。遗传差异扩大一倍，但排序未变。若在应激环境中变为1.5与0.5，则排序反转。只比较环境间平均数不能发现第二种现象；只报告方差差异也不能判断是否重排。需要在有遗传连接的资料中估计跨环境协方差或个体反应。

环境的范围取决于问题。饲料、温湿度、海拔、管理水平、病原暴露和社会竞争都可能构成环境；同一因素在不同生命阶段的作用又可能不同。把所有不由基因解释的差异统称为环境，对基础方差分解有用，却不足以设计适应性选择。研究需要把可测暴露、可改变管理与无法直接测量的背景区分开来。

基因与环境互作也不是高投入体系独有的问题。地方品种在低投入条件下的适应优势，可能在统一高营养试验中被削弱或看不见；另一方面，观察到地方品种在原产地表现较好，也可能包含长期管理匹配和群体历史差异。比较应尽量安排跨环境连接，避免把品种与场区完全重合后将全部差异归为遗传适应。

对育种决策，问题不是是否存在任何统计互作，而是它是否足以改变目标和选择方案。遗传相关略低于一并不必然要求建立两个育种群；维持独立群体的费用、目标环境比例、可用遗传连接和预测精度都需要考虑。一个统一群体配合环境特异育种值，可能比完全分开更合适；强烈重排且环境长期分离时，专门化策略才可能更有优势。

因此，本章从环境测量开始，逐步讨论反应规范、动态韧性、资源分配和可持续目标。共同原则是把“动物在何种条件下表现好”转化为可估计参数，再把这些参数与明确的未来使用环境和长期目标连接起来。只增加一个“抗逆”或“绿色”标签，无法完成这一过程。

32.2 环境测量、暴露、反应与管理不能混为一谈

一个好的环境指标应尽量描述动物受到的外部暴露，而不是直接重复目标性状。气象站温度可以反映外部热条件，却未必代表圈舍微环境；圈舍传感器更接近动物，但位置和通风差异仍重要；体温是动物对暴露的反应，已经同时受到遗传和生理状态影响。将体温直接作为外部环境变量，可能控制掉部分需要研究的遗传响应。

时间窗口也很关键。当天温度、过去三天平均热负荷和整个妊娠阶段的累积热暴露，代表不同生物问题。窗口应根据生理机制和实际记录确定，再通过合理验证比较。若反复试验许多窗口后只报告最显著者，应把这种搜索纳入验证，而不能将窗口看作事先确定。对极端暴露，持续时间和夜间恢复可能比日均值更有解释力。

环境测量误差会降低斜率估计精度，也可能使反应规范衰减。若测量误差与场区、品种或生产水平相关，偏差更复杂。传感器故障期间的插补、室

外到圈内暴露的映射以及不同设备之间的校准，都应有明确记录。对于无法准确测量的综合管理水平，可以采用潜在环境指标，但解释应限于其所代表的统计梯度。

生产群平均值常被用作环境质量指标，因为它整合了许多难测条件。然而，群平均值也包含遗传组成和目标记录本身。若优秀家系集中在某些场区，这些场区的高均值不完全是环境；若某头动物自己的记录参与其环境指标计算，还会产生信息重复。可以利用独立群体记录、适当剔除自身贡献或联合模型缓解，但不能把这种指标视为纯外生暴露。

例 32.2 同一热环境下的不同实际暴露。圈舍甲与乙的室外日均温度都为 30 摄氏度，甲具有良好通风且夜间降温，乙则夜间持续闷热。若仅以室外日均温度作环境，两舍被归入同一水平，真实暴露差异会进入残差或错误的家系效应。增加圈内温湿度、持续高温时长和管理记录，可以帮助区分。例题没有规定某个通用热阈值，因为阈值应随物种、阶段和测量定义确定。

暴露缺失与未暴露也必须区分。没有记录疾病并不一定表示没有感染，没有热应激事件标签也不表示环境温和。对韧性研究尤其如此：一个动物没有产量下降，可能因为抗性强，也可能从未遭受挑战。记录暴露发生与强度，能够把“有没有机会表现抗性”与“表现得怎样”分开。

环境数据的收集还需要与个体身份和时间对齐。动物转栏、转场、设备更换和时钟偏移，都可能造成错误连接。高频环境与低频表型之间的汇总规则应可复现，不能在不同动物上使用不同且未说明的窗口。一个数学上精细的反应规范，如果暴露匹配错误，可能比简单而可靠的分组模型更差。

32.3 离散环境作为相关性状

当环境具有清楚类别，例如两个饲养体系或两个气候区，可以把同一生产指标在不同环境中视为不同但相关的性状。设环境甲、乙的遗传效应为 u_A, u_B ，遗传协方差矩阵为

$$\Sigma_u = \begin{pmatrix} \sigma_A^2 & \sigma_{AB} \\ \sigma_{AB} & \sigma_B^2 \end{pmatrix}, \quad r_g = \frac{\sigma_{AB}}{\sigma_A \sigma_B}.$$

同一动物不必在两种环境都被测量，只要亲属和基因组连接足够，仍可能估计跨环境关系；但连接不足会使相关估计不稳定。

遗传相关接近一表示两个环境中的加性遗传排序高度一致，但不要求方差相同。相关明显低于一说明只能部分借用另一环境的信息。负相关则意味着提高一个环境中的表现可能损害另一个环境，但这种强结论尤其需要充足资料和不确定性评估。边界估计或很宽区间往往提示数据不足，不能仅凭点估计决定育种体系重组。

例 32.3 借用另一环境的记录能达到什么程度。假设两个环境遗传方差均为 1，遗传相关为 0.60。即使环境甲的育种值被无误差地知道，仅据它线性预测环境乙的育种值，准确度也只有 0.60，可靠性为 0.36。若甲环境育种值本身准确度为 0.80，且其预测误差满足相应独立条件，则对乙环境的间接准确度约为 $0.80 \times 0.60 = 0.48$ 。这说明大量源环境信息不能无限替代目标环境记录。

模型应允许环境间残差方差不同。高应激环境可能产生更大短期波动，若强制残差方差相同，某些差异会被错误分配到遗传部分。相反，只做环境内标准化也可能抹去实际有意义的尺度变化。是否标准化取决于目标单位：若育种目标以实际产量计价，环境间方差大小本身可能影响预期反应，不应为了数值方便全部消除。

跨环境评定需要合理的固定效应与基准。不同环境的品种组成、年龄和管理可能不同，模型必须明确哪些差异属于比较目标。若两个环境没有共享家系或其他连接，环境均值与遗传均值难以分离。此时再复杂的协方差结构也无法替代设计。引入共同公畜后代、交叉安排家系或联合基因组资料，可以改善连接，但仍应检查其强度。

离散环境模型的优势是解释直接，不要求环境响应为线性。其局限是环境类别增多后参数迅速增加，且类别内差异被压缩。若温度是连续梯度，随意划成高低两组会损失信息并依赖切点；但在记录稀疏、机制存在明显状态差异时，分组也可能比复杂曲线更稳健。模型选择应考虑信息量与研究问题，不能以连续模型必然先进作判断。

在应用报告中,可以同时提供各环境育种值及环境加权综合值。这样用户能看到动物的专门优势与总体表现。若只发布一个平均值,强烈的环境差异可能被隐藏;若发布很多环境值而不说明权重与不确定性,又可能使选择者无从判断。评定系统应把环境目标与预测精度一并呈现。

32.4 连续反应规范的基本推导

当环境指标 q 连续变化时,最简单的反应规范是 $u_i(q) = u_{0i} + qu_{1i}$ 。截距 u_{0i} 表示参考环境 $q = 0$ 下的遗传水平,斜率 u_{1i} 表示环境指标每增加一单位时遗传值的变化。表型模型还需要共同环境趋势 $\mu(q)$ 及其他固定和随机效应,不能把所有平均环境响应都交给遗传斜率解释。

若截距方差、斜率方差和协方差分别为 $\sigma_0^2, \sigma_1^2, \sigma_{01}$, 则由线性组合的协方差规则可得

$$\text{Cov}[u(q), u(q')] = \sigma_0^2 + (q + q')\sigma_{01} + qq'\sigma_1^2.$$

令 $q' = q$ 便得到环境特异遗传方差;再除以两个环境标准差乘积即可得到遗传相关。反应规范因此不只是为每头动物画一条线,它同时规定了整个群体跨环境协方差如何变化。

例 32.4 从截距与斜率方差推导重排。 设 $\sigma_0^2 = 4$ 、 $\sigma_1^2 = 1$ 、 $\sigma_{01} = 0.5$ 。在 $q = -1$ 时方差为 $4 - 1 + 1 = 4$, 在 $q = 1$ 时为 $4 + 1 + 1 = 6$; 两环境协方差为 $4 - 1 = 3$, 故遗传相关为 $3/\sqrt{24} \approx 0.6124$ 。若动物 A 的截距和斜率为 $(2, 1)$, B 为 $(1, -0.5)$, A 在 $q = -1$ 时为 1, B 为 1.5; 在 $q = 1$ 时 A 为 3, B 为 0.5, 排序发生反转。

截距与斜率的解释依赖环境中心。把 q 改成 $q^* = q - c$, 同一反应函数可以写成 $u_i(q) = u_{0i}^* + q^*u_{1i}$, 其中 $u_{0i}^* = u_{0i} + cu_{1i}$ 。新的截距方差和截距—斜率协方差都会变化,但同一真实环境下的预测不变。因此,比较两个研究中的截距遗传率或协方差之前,必须核对环境单位与中心化规则。

在例 32.4 中若以原 $q = 1$ 为新参考,即 $c = 1$, 新截距方差为 6, 新截距与斜率协方差为 $0.5 + 1 = 1.5$ 。这不是生物系统发生改变,而是参数坐标改

变。类似地，将环境单位扩大十倍会使斜率数值相应缩小。斜率绝对值大或小只有结合环境尺度才有意义。

反应规范可以扩展为多项式、分段线性或平滑基函数，但每增加一个自由度都需要相应信息。高阶曲线在观察范围内可能拟合更好，在边界外却容易出现不合理弯曲。对于热负荷等存在阈值的过程，分段模型可能比全范围高阶多项式更符合机制；阈值是否固定或估计，也应纳入验证和不确定性。

还要区分遗传反应斜率与个体表型斜率。一个动物反复测量得到的斜率同时包含永久环境和短期状态，只有通过亲缘结构和模型分解才能估计其加性遗传部分。若每头动物只经历很窄环境范围，其遗传斜率主要依靠亲属与群体协方差预测，应如实报告精度，避免把平滑曲线看作充分的个体证据。

32.5 目标环境分布决定怎样选择

反应规范提供环境特异遗传值，但选种仍需回答未来动物将在哪些环境中生产。若目标环境分布为 $f(q)$ ，线性反应规范的平均遗传值为

$$E_q[u_i(q)] = u_{0i} + E(q)u_{1i}$$

因此，平均环境决定线性目标中的斜率权重。对于非线性反应规范，则需要整个环境分布的相应矩，而不只是均值。

例 32.5 环境概率改变优选动物。延续例 32.4，若 $q = -1$ 的概率为 0.70， $q = 1$ 的概率为 0.30，则 $E(q) = -0.40$ ，A 的平均遗传值为 1.60，B 为 1.20。若不利环境概率升为 0.90，则平均环境为 -0.80 ，A 为 1.20，B 为 1.40，B 成为平均更优者。排序变化来自目标环境权重改变，并非模型重新估计或动物遗传潜力突然变化。

环境权重可以来自现有生产记录，也可以来自未来情景，两者应分开报告。历史分布适合描述当前体系，未来分布则可能受气候、饲料供应、管理技术和市场改变影响。对于未来不确定性，最好使用多套明确情景，而不是给出一个貌似精确但缺乏依据的概率。选择方案在不同情景下是否仍可接受，是稳健决策的重要信息。




图 32.1 未来环境权重改变选择排序。两条曲线依据例 32.5 计算；不利环境概率超过五分之六时，动物 B 的环境平均育种值高于 A。图示比较的是目标权重，不是参数重新估计

环境平均表现并不是唯一合理目标。某些系统更关心最差条件下不低于最低生产或福利标准，此时可设置环境特异约束；另一些系统愿意牺牲少量平均产量以减少波动。若使用均值减风险惩罚的目标，应明确风险指环境导致的表现变动、预测不确定性还是经济损失，三者不能混用。斜率较小也不必然更好，因为它可能意味着无法利用优质环境。

对于线性反应规范，环境变化造成的个体遗传表现方差为 $u_{1i}^2 \text{Var}(q)$ ，这是给定个体参数后在环境分布中的变动，不等于群体遗传方差。把二者混淆，会误解稳定性目标。如果采用 $u_{0i} + E(q)u_{1i} - \lambda u_{1i}^2 \text{Var}(q)$ ，目标已经包含非线性惩罚，需要说明权重 λ 及其经济或风险含义。

评定不确定性也应进入决策。一个看似在极端环境中最优的动物，可能只是斜率估计很不精确。比较时应同时考虑预测均值和误差，而不是把极端预测当作确定优势。对资料稀缺环境，可以优先安排验证或保留多样化候选，而不是立即把全部贡献集中到少数外推最优个体。

环境适应还可以通过配套管理实现。某些遗传类型适合高质量饲料，另一些更适合波动环境，适当匹配可能提高体系总体表现。但匹配策略要求生

产者能够稳定识别和提供相应环境，并考虑物流与管理成本。若环境频繁且不可预测地变化，广泛适应性可能比高度专门化更有价值。

32.6 互作模型的识别与验证

观察到家系在不同环境中的表现差异，并不自动证明遗传互作。优秀家系可能被优先分配到优质场区，不同品种可能只出现在各自地区，或者某种设备只用于特定管理体系。这些结构会让遗传、环境和测量效应相互混杂。模型可以利用已有连接调整，但不能从完全没有交叉的设计中创造信息。

有效设计应尽量让同一公畜或相近家系的后代分布在多个环境，并让每个环境包含多个遗传来源。生产条件下无法完全随机时，可以通过人工授精连接、多场协作和连续环境记录改善覆盖。对极端环境，少量高质量挑战资料可能特别有价值，但其与常规群体的遗传连接和测量定义必须一致。

例 32.6 缺少连接时为何无法分离。假设家系 A 全部在优质场，平均表现 120；家系 B 全部在差场，平均表现 100。差异 20 既可能全部来自家系，也可能全部来自环境，或由二者任意组合造成。若再让两家系的后代都在两场测量，才有机会分离主效应并估计差异响应。增加原有两个完全混杂组内的动物数量，可以更精确地估计组均值，却不能消除根本不可识别性。

模型验证应与用途匹配。同一环境内随机留出个体，主要评价已知环境中的预测；留出年份检验时间迁移；留出场区检验新管理条件；同时留出家系和环境则考查更严格的外推。不同验证的结果不能简单放在一张排名表中比较，因为任务难度和信息条件不同。较完整研究可以报告多个互补场景，并说明每个场景对应哪种应用。

应按环境检查均值偏差和尺度。模型可能在温和环境总体准确，却在热负荷最高区间系统高估；总体相关会因温和环境样本多而掩盖这种问题。环境分层过细又会导致区间很宽，因此可以结合平滑校准曲线与明确样本量。对观察范围之外的环境，应标为外推，而不是因为公式可以计算就视为已验证。

互作方差的显著性也不等于决策重要性。大样本可能检测到很小的斜率

方差，而选留名单几乎不变；小样本则可能无法显著检出具有潜在经济意义的互作。应结合遗传相关、预期选择响应、环境权重和不确定性判断。单一显著性阈值不能替代应用评估。

参数更新需要保持基准可追踪。环境指标重新中心化、传感器更换或气候分布变化，都会影响参数表达。更新后应检查旧动物在相同真实环境下的预测是否一致，区分正常信息增量与尺度转换。一个能持续维护的环境评定系统，比一次性得到漂亮反应曲线更接近实际育种价值。

32.7 韧性、抵抗性与恢复性的不同含义

韧性通常关注动物遭受扰动后维持功能或恢复到适当状态的能力，但这个宽泛概念包含多个可区分过程。抵抗性主要描述扰动造成多大损害，恢复性描述损害发生后多快恢复，稳健性还可能涉及长期健康、繁殖和存活。若研究只测量一个时间序列的波动，最好称为与韧性相关的指标，避免把全部生物能力都包含在一个名称里。

一个动态过程至少需要基线、扰动、响应和恢复四个要素。基线是没有该扰动时预期达到的状态，通常无法直接观察，需要由挑战前资料、适当对照或模型估计。扰动包括发生时间与强度，响应包括最大下降和持续损失，恢复则需要一个明确判据。不同判据会改变数值，因此应在分析前定义，而不是根据结果选择最有利指标。

例 32.7 相同累计损失可以对应不同韧性。挑战后四天，动物 A 相对于基线的每日损失为 (6, 4, 2, 0)，B 为 (3, 3, 3, 3)。简单累计损失都为 12 单位日，但 A 首日下降更大、第四天已恢复，B 首日较稳定却持续受损。若生产系统最重视早期最低产出，B 可能更合适；若重视恢复时间，A 更合适。一个累计量无法同时表达两种目标。

基线定义会显著影响韧性指标。若把包含应激期的全部数据拟合成平滑曲线，长期损失可能被吸收到“正常水平”中，使受损动物看起来残差很小。若使用群体平均曲线，原本生产潜力较低的动物也可能出现系统负偏离。应明确基线是个体潜力、同龄群平均还是某个高分位轨迹，并解释指标相对于

哪种参照。

韧性并不等于产量不变。某些适应性反应通过暂时降低产出保护健康和未来繁殖，短期“损失”可能是长期有利调整。另一些动物维持高产却过度动用体储备，随后出现疾病或繁殖问题。只选择短期产出稳定，可能奖励不恰当的资源分配。因此，韧性目标应与体况、健康和终生表现一起解释。

也应区分一般韧性与特定挑战抗性。对热应激表现好，不一定意味着对寄生虫或饲料短缺同样好；不同挑战可能共享部分生理能力，也可能要求不同资源分配。若希望构建一般韧性指标，需要多个挑战或长期自然环境资料支持，不能从一次特定试验直接推广。统计上多个指标相关，也不等于它们具有完全相同机制。

对遗传改良而言，最终需要估计这些过程的加性遗传变异及其与生产、健康的协方差。一个生理指标可以很好描述个体恢复，却遗传率很低或测量成本很高；另一个间接指标机制不够直观，却可能在大量动物上稳定获得。两者可以结合：精细试验帮助定义和验证，规模化记录支持评定和选择。

32.8 高频表型：从传感器信号到育种性状

自动采食器、活动计、视觉跟踪、体温和反刍传感器扩展了可观测性状，但原始信号并不是最终表型。识别算法、设备位置、个体佩戴、遮挡和采样频率都会影响记录。必须区分设备观察到的变化与动物真实行为变化，特别是将算法输出用于遗传分析时，任何与家系或体型相关的识别误差都可能形成虚假的遗传信号。

例如视觉系统更容易识别某种羽色或体型的动物，检测次数就可能带有遗传相关，但它首先反映检测过程，而不一定反映活动能力。移动距离也受到视野覆盖和跟踪中断影响。新表型开发应同时评价识别率、缺失机制、行为定义和遗传参数，不能因算法准确率较高就跳过表型验证。

Osorio-Gallardo 等 (2026) 利用 ArUco 标记蛋鸡的自动跟踪数据开展检测与运动性状的遗传分析，展示了图像信息进入育种评定的一条具体路径。这里值得保留的界限是：检测性状与运动性状需要分别定义，自动获得

的记录仍依赖系统观察条件。它为新表型提供证据，并不意味着任何视频活动量都已成为普遍有效的福利或韧性指标。

数据清洗应与研究目标一致。传统质量控制可能删除极端低采食或低活动记录，因为它们看起来像异常；但这些记录也可能恰好是疾病和应激反应。应结合设备状态、同栏动物、重复测量和人工复核区分技术异常与生物异常。机械删除所有极端值，会把研究最关心的扰动过程一起删掉。

例 32.8 平滑会改变恢复指标。假设真实每日损失为 $(0, 0, 6, 0, 0)$ ，一个短暂事件的最大损失为 6。若用三日移动平均，中心附近的损失变为 2、2、2，最大值降为 2，事件持续时间却变长。累计量在适当边界处理下可能近似保留，但抵抗性和恢复性指标明显改变。由此可见，平滑参数属于性状定义的一部分，而不只是无关紧要的数据处理选择。

高频资料还存在伪重复。每天一千条传感器记录并不等于一千个独立遗传观测，许多信息只是对同一状态的重复测量。遗传参数估计需要考虑个体内相关、永久环境和设备误差。增加采样频率能改善事件识别，却不必按同样比例增加独立遗传信息；研究设计应同时关注动物数量和时间覆盖。

部署时需要冻结或记录表型算法版本。视觉模型更新后，过去的移动距离与新的距离可能不在同一尺度；设备更换也可能改变缺失率。可以通过重叠运行和参考样本建立转换，必要时重新计算历史表型。若把版本变化误当作遗传趋势，育种评定会产生系统偏差。

最后，新表型应接受生物与应用双重验证。它是否与已知挑战、健康或福利记录相符？是否具有可利用遗传变异？是否在不同场区和设备中稳定？是否在综合目标中提供独立信息？这四个问题比单纯展示高频曲线更接近育种价值。算法的技术表现与性状的遗传价值应分别报告。

32.9 从偏离曲线计算韧性指标

设动物在时点 t 的观察值为 y_t ，期望基线为 $\hat{\mu}_t$ ，偏离为 $d_t = y_t - \hat{\mu}_t$ 。平均绝对偏离、残差方差、负偏离面积、最大下降和恢复时间分别概括不同方面。没有一种指标能代表全部动态过程，因此应根据目标选择少量互补指标，

并避免把高度冗余指标重复计入选择指数。

残差方差反映围绕基线的离散程度，但对偏离方向不敏感。持续低于基线的动物可能残差方差很小，却损失严重；平均平方偏离则同时包含均值偏移和波动。二者关系为平均平方偏离等于按相应分母定义的方差加平均偏离平方。这个基本分解有助于理解不同“稳定性”指标为什么可能给出相反排序。

例 32.9 低方差不等于低损失。动物甲的偏离为 $(-3, -3, -3, -3)$ ，动物乙为 $(-1, 1, -1, 1)$ 。用总体分母计算，甲的偏离方差为 0，平均平方偏离为 9；乙的方差为 1，平均平方偏离为 1。若只选择最低方差，会优先甲，尽管它始终低于基线。若基线适当且负偏离代表损失，平均水平和波动应共同考虑。

不等间隔记录下，简单求和不能代表时间累计损失。可以按时间间隔计算梯形面积，但稀疏记录之间真实轨迹未知，所得面积是近似。若两个观测相隔数月，不能把线性连接当作已经观察到的恢复过程。需要明确指标是对稀疏轨迹的描述，还是对高频事件的直接估计，两者证据强度不同。

Santana 等 (2026) 在巴西 Angus-Brangus 资料中，从稀疏体重记录构建与生长韧性和均匀性相关的指标，并估计遗传参数。研究展示了有限常规记录的利用潜力，同时其指标依赖群体参考轨迹与稀疏观测。这里不能把推导的恢复指标等同于连续监测到的全部应激事件；更合适的下一步是与高频和已知挑战资料连接验证。

自相关用于描述偏离的持续性。正自相关较高可能意味着一个损失持续多天，也可能只是基线未去除的缓慢趋势；负自相关可能来自补偿性波动，也可能来自设备或处理算法。解释前应检查时间尺度和残差平稳性。不同采样频率下的自相关不能直接比较，因为一天间隔与一小时之间隔代表不同过程。

恢复时间需要规定恢复到什么水平以及维持多久。若只要一次记录回到基线就算恢复，测量噪声可能造成过早判定；若要求连续多天恢复，又会受缺失影响。可以采用阈值与持续时间结合的规则，并对合理规则范围进行敏

感性分析。无论采用哪种规则，都应在比较动物前固定，避免因不同动物轨迹而改变标准。

对于多个扰动事件，可以分别估计事件内反应，再分析动物平均能力与事件差异。将所有时间序列压成一个总体方差，可能混合暴露次数、强度和恢复性。若暴露有记录，模型可以把这些因素分开；若暴露未知，应对“普遍韧性”作较弱解释。指标的名字应反映实际观察范围，而不是替代缺失的暴露信息。

32.10 遗传的均匀性与残差方差

除了平均水平，动物或家系也可能在环境敏感性上存在遗传差异。一种建模思路是同时描述性状均值与残差方差，让残差方差的对数含有遗传效应。例如 $\log \sigma_{e,i}^2 = \mu_v + u_{v,i}$ ，可以在保证方差为正的同时表示遗传异质性。这里 u_v 与平均性状育种值是不同参数，二者可能相关。

该模型需要特别注意可识别性。每头动物只有一个观测时，个体残差平方具有极大噪声，通常需借助大量亲属、重复记录和结构假设才能估计方差遗传效应。若某家系恰好处于更不稳定的场区，模型可能把环境异质性误判为遗传均匀性。均值模型未拟合好的趋势也会进入残差方差，因此方差模型不能独立于均值模型评价。

例 32.10 对数方差参数的实际含义。两个候选动物的残差方差遗传效应分别为 0 与 -0.20，在同一基准下，后者对应方差比例 $\exp(-0.20) \approx 0.8187$ ，即约低 18.13%；残差标准差比例为 $\exp(-0.10) \approx 0.9048$ ，约低 9.52%。方差降低百分比与标准差降低百分比不同，不能混用。这个转换表达模型尺度，不保证实际后代表现恰好按该比例改变，因为预测和遗传传递仍有不确定性。

均匀性可能具有生产价值，例如减少出栏体重差异、提高产品一致性或降低极端不良表现风险。但均匀不一定等于健康或适应好。若所有动物都稳定地处于低产或不良状态，波动很小也没有优势；若某些环境变化需要灵活调整，过度追求不变可能不合适。均值与方差应共同进入目标，而不是只最

小化波动。

在近似正态条件下，平均值和标准差共同决定低于阈值的概率。例如平均 100、标准差 10 时，低于 80 的概率约 2.28%；平均 100、标准差 8 时降至约 0.62%。这说明降低波动可能减少尾部风险。然而，真实分布可能偏态、具有混合状态或重尾，单纯正态方差模型未必准确描述极端事件。对福利或存活等重要阈值，应直接验证尾部校准。

遗传均匀性与反应规范有联系但不同。反应规范描述对已测环境梯度的系统遗传响应，残差方差模型描述在均值模型之后剩余变异的差异。若把重要环境指标加入反应规范，原先的方差遗传信号可能减弱，因为部分不稳定性已被解释。这种变化有助于理解来源，并不意味着两模型之一必然错误。

选择方差性状时也需考虑长期相关反应。如果低波动与较低平均生产潜力相关，应在综合目标中权衡；若二者可以独立改良，则有机会提高均匀性而不牺牲均值。遗传参数通常不够精确，建议以稳健范围进行情景分析，并持续收集后代表现验证。复杂方差模型的应用价值最终取决于是否改善实际风险，而非仅在拟合优度上占优。

32.11 资源分配与终生稳健性

动物在有限能量和营养条件下，需要在维持、免疫、生长、繁殖和储备之间分配资源。短期某项表现提高，可能来自摄入增加，也可能来自其他功能投入减少或体储备消耗。观察到某个体同时高产、健康且长寿并不违反资源约束，因为它可能具有更高资源获取能力或更有效利用；不能从个体内资源竞争直接推出群体间所有性状必然负相关。

这一区分对遗传解释很重要。若个体间差异主要来自获取资源能力，许多功能可能正相关；若差异主要来自固定总量下的分配比例，则可能出现负相关。实际群体同时存在两类变异，因此遗传协方差需要估计，不能仅凭生理直觉指定符号。机制模型可以帮助提出假设，但参数的遗传基础仍需实证支持。

例 32.11 获取能力改变相关方向。动物甲每天可利用能量 100 单位，

分配 60 给生产、40 给维持；乙可利用 120，分配 72 给生产、48 给维持。两功能随获取能力一起增加。若在总量 100 固定时比较分配 60/40 与 70/30，则生产增加伴随维持减少。前一种群体差异与后一种个体内权衡并不矛盾，不能用其中一个替代另一个。

Hiltpold 等 (2026) 用耦合母羊与羔羊的生物能量模型研究不同饲草情景下的终生表现。模拟显示资源分配与环境可以造成个体类型重排；作者也明确，只有相关机制参数受遗传控制时，这些机制才可能构成可利用的遗传互作。该研究是机制与情景证据，并非已经实现多代选择反应的现场试验。

终生目标应整合多次繁殖、存活和生产，而不是只看某一高峰阶段。母畜在一次泌乳中维持高产，若导致后续空怀或提前淘汰，终生收益可能下降。反之，短期稍低产但健康、繁殖稳定的动物可能具有更高累计价值。经济核算需要考虑时间折现、更新成本和生产体系，而遗传分析则需要正确处理不同观察长度。

淘汰造成的信息缺失通常不是随机。低产、患病或繁殖失败的动物更早离群，后续记录缺失正是其表现的一部分。只分析完成完整生产周期的动物，会选择出较健康子群并低估不良过程。可以使用生存、离散时间风险或联合纵向模型，也可以定义清楚的阶段性性状；选择何种方法取决于目标和记录质量。

体况变化提供资源储备的线索，但也需要结合阶段解释。妊娠、泌乳和育肥阶段适当的储备动用不同，固定一个全年不变的“越高越好”目标可能不合理。更有意义的是适当阶段的水平、变化速度以及恢复能力，并与健康和繁殖结果连接。精细表型可以帮助理解过程，但常规评定仍需可规模化记录。

长期稳健性还包含反复挑战的累积效应。一次恢复快，不一定意味着多次应激后仍能维持功能；某些损伤可能延迟显现。因此，短期挑战试验应与长期生产记录互补。试验提供明确暴露和精细响应，生产资料提供真实复杂环境与终生后果。二者通过亲缘或共同个体连接，才能更好地服务育种目标。

32.12 排放性状的定义改变选择方向

可持续育种需要明确系统边界。每日甲烷总量、单位采食甲烷、单位产品排放、整个生产周期排放和生命周期总排放，分别描述不同问题。降低一个比值可以通过分子下降，也可以通过分母上升；降低每头动物排放不一定降低为满足固定产品需求所需的总排放。没有统一边界，两个研究的“减排百分比”可能无法比较。

例 32.12 总量与强度给出不同排序。动物 A 每日甲烷 200 克、产出 10 单位，排放强度为 20 克每单位；B 每日甲烷 180 克、产出 8 单位，强度为 22.5。按每日总量 B 较低，按单位产出 A 较低。若生产系统需要固定 80 单位产品，按这种静态比例计算，A 需要 8 头、总排放 1600 克，B 需要 10 头、总排放 1800 克。该例忽略维持、更新和其他排放，只说明目标边界会改变结论。

比值性状具有统计困难。分母测量误差会进入比值，分子分母相关使遗传参数不易解释，而且选择比值可能产生意料之外的分母变化。可以直接把分子和分母作为多性状目标，或构造有明确解释的残差性状，并计算相关反应。选择哪种表达应依据目标，而不是因为某个指标数值更容易下降。

Madsen 等（2026）研究不同排放输出定义与育肥场生产性状的遗传关系，进一步说明排放定义本身属于育种目标设计的一部分。这里可推广的是方法原则：应同时检查绝对量、强度及其与采食和生长的联系。具体遗传参数仍属于所研究群体与记录条件，不能直接代入所有肉牛体系。

排放测量也有时间代表性问题。短时间仪器测量可能受采食时刻、饲料和动物行为影响，重复测量有助于提高代表性，但仍需跨日、跨阶段和设备校准。代理指标如光谱、呼吸特征或微生物信息可能降低成本，却需要验证它们对目标排放的遗传协方差，而不只是同日表型相关。

生命周期核算还涉及母畜维持、替换率、饲料生产、粪污和产品分配。一个提高繁殖或存活的遗传改良，可能通过减少更新需求降低单位产品排放；这些间接收益不一定被单头育肥期甲烷测量捕捉。另一方面，提高产量也可能增加资源使用，因此不能只看某一环节。应在明确边界内建立经济与环境

权重, 避免重复计价。

环境权重可能随政策、技术和价格变化, 但教材中的基本原则不依赖某个当前价格。研究者可以设置多套透明情景, 报告选择方案对权重的敏感性。若某方案只有在极高碳价或极端饲料价格下才有优势, 应如实说明; 若在广泛情景下均改善综合目标, 则其应用更稳健。

减排目标还应与健康、福利和遗传多样性共同考虑。通过减少采食和生长降低排放可能损害生产效率, 通过过度集中少数家系追求短期改良可能增加长期风险。可持续性不是给传统指数增加一个负排放系数就完成, 而是检查整个系统中收益、代价和约束是否一致。

32.13 遗传残差排放: 控制生产的一个线性构造

若希望减少排放而尽量避免通过降低生产实现, 可以在遗传水平定义残差排放。设甲烷育种值为 u_M , 生产育种值为 u_P , 定义

$$u_R = u_M - ku_P, \quad k = \frac{\text{Cov}(u_M, u_P)}{\text{Var}(u_P)}.$$

由协方差代数可知, 在所用群体和参数模型下, $\text{Cov}(u_R, u_P) = 0$ 。这表示排放中不能由该生产遗传差异线性解释的部分, 并不意味着生物过程被完全分离。

例 32.13 总排放与残差排放的排序。 设甲烷和生产遗传方差分别为 100 与 25, 遗传协方差为 30, 则 $k = 1.2$, 残差排放方差为 $100 - 30^2/25 = 64$ 。候选 A 的 $(u_M, u_P) = (10, 8)$, 候选 B 为 $(5, 1)$, 其残差值分别为 0.4 与 9.8。B 的总甲烷遗传值更低, A 相对于生产潜力的残差甲烷更低。两种排序对应不同目标, 不应简单说其中一种“更正确”。

表型残差与遗传残差一般不同。若直接把表型排放对表型生产回归, 系数包含环境协方差, 得到的残差可能仍与生产育种值相关。以一个教学例说明: 甲烷表型方差 200, 生产表型方差 100, 表型协方差 50, 则表型回归系数为 0.5; 沿用上例遗传参数, 该残差与生产育种值的协方差为 $30 - 0.5 \times 25 = 17.5$, 并未消除遗传相关。

多个生产性状时，可以用向量扩展。设生产育种值向量为 u_P ，协方差矩阵为 Σ_{PP} ，与排放的协方差向量为 Σ_{PM} ，则系数向量为 $k = \Sigma_{PP}^{-1}\Sigma_{PM}$ ，残差为 $u_M - k^T u_P$ 。这个构造需要矩阵可逆或采用适当广义逆与约束，高度相关生产性状会使系数不稳定。参数误差应通过敏感性分析或后验分布传播。

零协方差只是给定线性模型中的性质。若预测准确度不同、选择规则非线性、参数估计有误或群体改变，实际生产响应仍可能偏离零。尤其当使用估计育种值而不是真实育种值选择时，误差协方差影响响应。因此，残差目标可以帮助组织取舍，却不能替代完整选择指数和后代验证。

Nguyen 等 (2026) 把瘤胃微生物信息与生产性状结合，比较肉牛甲烷选择情景，展示排放下降与生产相关反应之间的权衡。该研究主要依据估计遗传参数推演响应，残差或约束目标改变了取舍。应把它理解为选择方案分析，不能写成已经完成的多世代实际减排；微生物信息的宿主遗传部分和跨饲料粮稳定性仍需关注。

残差定义还涉及价值判断。控制哪些生产性状，实际上决定哪些排放变化被视为“合理随生产变化”的部分。控制体重、生长或采食的不同组合，会产生不同目标。研究应说明这些选择的生物与经济理由，并比较由此带来的长期响应。数学上的正交化不等于社会或经济上的最优。

在实际评定中，通常应同时保留原始性状和派生残差的结果。这样可以追踪选择是否通过预期路径实现，并在经济权重变化时重新构建目标。若只发布一个残差评分而不说明参数、单位与原始表现，使用者很难理解其含义，也难以识别某些极端但不合理的候选动物。

32.14 多目标选择、约束与稳健方案

设多个目标性状的育种值为 u ，综合目标为 $H = a^T u$ 。环境和福利性状可以通过权重进入，也可以通过约束进入。权重表达连续取舍，例如减少一单位排放愿意牺牲多少产量收益；约束表达某些最低要求，例如健康响应不得低于某值。二者不是互相排斥，但需要避免同一收益或损失被重复计算。

如果某项福利要求不允许被其他收益抵消，单纯给它一个有限价格可能

不合适，应设置明确约束。约束会缩小可行选择空间，通常牺牲一些无约束综合响应，这种代价应透明报告。不能把受约束方案宣传为在所有维度都免费改进；真正有意义的是说明牺牲多少当前收益换取什么风险降低或最低保障。

例 32.14 简单候选方案的取舍。三个选择方案在生产与减排两个标准化目标上的预期响应分别为 A(1.0,0.2)、B(0.8,0.6)、C(0.5,0.9)，两目标均越大越好。若综合权重为生产 1、减排 0.5，得分依次为 1.10、1.10、0.95；若减排权重为 1，则为 1.20、1.40、1.40。若另要求生产响应至少 0.7，C 不再可行，第二套权重下 B 最好。权重和约束明确后，选择才有清楚含义。

帕累托有效方案是无法在不损害另一目标的条件下改善某一目标的方案。它帮助识别不值得保留的被支配方案，却不能自动决定最终选择，因为有效前沿上仍存在价值取舍。绘制前沿时应使用同一资源约束和可比预测精度；若某方案额外投入大量测量费用，其位置不能与低成本方案直接比较。

未来环境和经济权重不确定时，可以比较方案在多种情景下的表现。平均最优方案可能在不利情景中很差，保守方案则可能牺牲少量平均收益以避免严重损失。可以使用最差情景约束、后悔值或风险惩罚等方法，但每种准则都体现不同偏好。研究者应说明所选择准则，而不是用“稳健”一词掩盖其代价。

参数不确定性与情景不确定性也不同。前者来自遗传协方差和准确度估计有限，后者来自未来环境或价格未知。可以分别变化两类因素，观察哪个最影响方案排序。如果主要风险来自遗传相关不确定，最有价值的下一步可能是增加连接记录；如果主要风险来自未来环境，则保留多样化适应类型可能更有帮助。

在群体层面，多目标还与亲缘约束相连。即使某一候选动物在多个目标上都优秀，过度使用仍可能增加近交和减少未来适应空间。优化贡献可以在综合响应与群体关系之间取舍，配种阶段再控制具体后代近交和缺陷风险。环境适应目标应进入这套长期框架，而不是只改变单头动物的排名。

多目标方案的沟通宜保留几个可解释结果：各主要性状预期响应、使用

资源、近交或关系变化以及关键情景下的表现。一个总分便于排序，却无法替代这些信息。特别是环境和福利权重具有政策或价值选择时，透明展示比追求一个看似客观的唯一指数更重要。

32.15 疾病、耐受与群体传播

疾病相关育种需要区分抗感染、耐受和恢复。抗感染或抗性关注降低感染概率或病原负荷，耐受关注在给定感染程度下减少健康或生产损失，恢复关注感染后清除或恢复功能的速度。某动物感染后仍保持产量，可能耐受较好，却未必减少病原传播。因此，以生产损失作为唯一疾病指标，可能漏掉群体层面的传染风险。

一个耐受反应规范可以把生产或健康结果对病原负荷的变化作为斜率，但病原负荷本身也受宿主基因和测量误差影响。把它当作完全外生环境变量，可能产生解释偏差。需要同时考虑感染暴露、抵抗能力与负荷测量，必要时联合建模。观察到较平缓的生产下降，只有在暴露与负荷可比时才支持较高耐受的解释。

例 32.15 个体表现与群体风险可能不同。动物甲感染后产量损失 2 单位、排出病原量较高；乙损失 4 单位、排出病原量较低。只按个体产量损失选择会偏向甲，但在传染性疾病系统中，甲可能给同群动物带来更多风险。这个例子不规定两者的最终经济排序，而是说明目标需要同时考虑个体损失与传播外部效应。

群体传播使遗传效应超出个体自身。一个动物的易感性影响它是否感染，感染后的传染性影响其他动物，接触行为也会改变传播机会。传统只拟合个体直接效应的模型可能无法完整描述这些间接遗传作用。设计上需要接触群、感染时间和适当家系分布，统计上需要与传播过程相容的模型。

疾病记录还受到检测策略影响。只检测有症状动物，会漏掉无症状携带者；检测频率不同会改变发现概率；治疗又会改变后续病原和生产轨迹。把“未确诊”当作“未感染”，可能产生误分类。研究应记录检测机会、方法与治疗，并明确分析对象是临床疾病、感染状态还是病原负荷。

选择疾病抗性不能替代合理防疫。遗传改良通常是渐进过程，与疫苗、卫生、隔离和管理共同发挥作用。若管理改善显著降低暴露，抗性指标的观察机会也会减少，这需要在评定设计中处理，而不是为了获取记录而故意维持不良环境。自然暴露资料、适当挑战研究和机制测量可以互补。

对可持续目标，降低疾病可能同时改善福利、减少药物使用、提高存活和资源效率，但这些收益可能在经济核算中重叠。例如存活改善已体现在终生收益中，再重复加入同一损失避免值会过度计价。应建立清楚的因果与核算链，区分直接收益、间接收益和独立约束。

疾病相关遗传改良也需要监测长期变化。病原群体可能变化，生产体系和接触结构也可能改变，原有抗性并非对所有未来病原都有效。保持遗传多样性、持续记录和更新验证，有助于降低依赖单一路径的风险。对复杂疾病，广泛健康与特定抗性可以同时纳入目标，而不是寻找一个永远适用的单分数。

32.16 遗传多样性、近交与环境压力

遗传多样性为未来选择提供原料，也影响近交和有害隐性变异表达。面对尚不确定的未来环境，不能仅依据当前环境下最高的短期预测值集中使用少数家系。多样性的价值难以全部通过一个当前价格表达，但可以通过亲缘、近交和有效群体大小约束进行管理。保护多样性并不意味着放弃遗传进展，而是对进展速度与长期选择空间作取舍。

近交衰退可能随环境压力变化，因为较差条件下某些有害效应更容易表达。不过这种关系需要具体资料支持，不能先验假定所有性状在所有应激下都同样增强。Tiezzi 等（2026）研究意大利荷斯坦牛生产性状的热负荷依赖近交衰退，提供了环境与近交共同建模的近期实证例子。结论应限于其性状、群体和暴露定义，不能直接推广成通用倍数。

例 32.16 环境特异近交效应的解释。假设一个教学模型中，每增加一个百分点近交，温和环境产量下降 2 单位，高压环境下降 5 单位。某配种方案使后代近交增加 2 个百分点，则两环境预期损失分别为 4 与 10 单位。若

目标环境中高压比例 0.30，平均损失为 $0.7 \times 4 + 0.3 \times 10 = 5.8$ 单位。这里的系数是假设值，用于说明环境权重如何进入近交代价，不能作为真实畜群参数。

地方品种和稀有群体可能携带与特殊环境适应有关的变异，但“稀有”本身不是有利的证明。资源保护需要结合群体历史、遗传独特性、生产用途和未来选择价值，避免只按某一个当前性状筛选。对小群体，测序和表型资源尤其有限，共享参考与针对性记录可能提高评定能力，同时需要尊重其环境和遗传背景。

杂交可以利用互补性和杂种优势，但其环境适应并非自动发生。某些组合在高投入环境表现好，在低投入条件下可能因体型、营养需求或繁殖特点不匹配。应区分品种加性贡献、杂种优势 η 和特定环境响应，并评价实际商业群体。不能把纯种核心群中的预测直接视为所有杂交后代的表现。

长期模拟可以比较不同贡献与环境情景下的遗传进展、近交和适应性，但结果依赖遗传架构、选择制度和未来环境假设。模拟适合识别风险和设计试验，不能替代现场验证。尤其对未知未来环境，任何精确预测都具有条件性；保留多样性是一种管理不确定性的手段，而不是保证未来一定成功的承诺。

环境适应目标还可能改变哪些家系值得保留。一个在平均环境中排名一般、但在关键压力环境中表现稳定的家系，可能为群体提供互补价值。贡献优化可以把这种多环境价值与亲缘同时考虑，避免只按平均总分淘汰所有专门化资源。实际决策仍需衡量维持成本和证据精度。

最终，可持续育种需要同时看动物、生产系统和群体三个尺度。动物尺度关注健康与适应，系统尺度关注资源和排放，群体尺度关注长期遗传基础。一个方案在某一尺度优秀，并不保证在其他尺度同样有利。把这些尺度的参数和约束明确连接，是比增加更多口号更实质的进展。

32.17 一个可部署的环境与韧性评定方案

设计环境评定时，可以从一个明确生产问题开始，例如提高季节性饲草波动条件下母畜终生断奶产出。首先定义目标环境范围与主要损失，再决定需要记录哪些暴露、动态指标和终生结果。这样能够避免先收集大量传感器数据，最后再寻找一个可以称为韧性的指标。

资料结构应同时支持均值、响应和长期后果。环境记录用于描述暴露，重复表型用于识别响应过程，健康和繁殖记录用于检查代价，亲缘与基因组信息用于分离遗传部分。家系在多环境中的交叉覆盖是核心连接。若某一环节缺失，应明确结论限制，并优先补充最有价值的连接资料。

模型可以从简单基线逐步扩展：先拟合合理的环境主效应与异质残差，再加入离散环境相关性状或线性反应规范，最后在证据支持时增加非线性和动态结构。每一步都应检查参数可识别性、外部误差与选择结果变化。复杂模型若没有增加可推广信息，就没有必要仅为形式先进而保留。

例 32.17 有限采样如何补最弱环境。假设现有三类环境中的有效连接记录分别为 5000、2000 和 200，最极端环境仅占后者。新增三百条高质量记录若继续全部投入第一类，可能主要提高已较精确的主效应；若有共同家系的条件下补充第三类，可能更有效地约束极端环境斜率。这里不能仅凭记录数计算精确收益，但可以通过预期误差方差或设计模拟比较方案，并检查新增记录是否确实覆盖关键家系。

验证阶段应冻结模型和主要指标，在后续出生或新场区资料上评价。对于韧性指标，应同时检查基线拟合、暴露可比性和长期健康相关；对于环境育种值，应按环境区间检查偏差与校准；对于综合目标，应计算各主要性状的响应，而不只报告总分提高。若后续资料显示某个指标只在原设备或原饲料粮下有效，应调整适用范围。

部署输出要让育种者能理解。可以提供参考环境育种值、关键环境预测、稳定性或恢复指标及其可靠性，并说明综合目标使用的环境权重。对外推环境或低精度斜率，应给出清楚标识。过多互相相关的评分会增加误用风险，因此应保留最有决策价值的一组结果，同时允许专业人员追踪底层参数。

持续更新需要监测环境分布、表型算法和遗传结构。气候或管理改变后,旧环境权重可能过时;传感器升级后,指标尺度可能变化;长期选择后,协方差和变异频率也可能改变。更新不应只重跑模型,还应检查这些定义是否仍与目标一致。版本化记录使预测变化能够被解释和审计。

韧性育种的目的,是在合理饲养和福利条件下提高面对真实波动的能力,而不是让动物承担本可避免的不良管理。改善环境与遗传改良通常相互补充:较好的管理降低不必要损失,遗传选择提高对剩余波动的适应。研究和应用应把这两种贡献分别评价,才能形成长期有效的生产体系。

在试点的统计计划中,还应预先区分主要与次要指标。假设主要目标是减少扰动后的累计生产损失,恢复时间和最大下降可以作为解释性次要指标;若试点结束后主要指标没有改善,而某个次要指标偶然显著,不能直接把项目目标改写成后者。可以据此提出下一轮假设,但确认性结论应对应预先规定的问题。这样既保留探索价值,也避免不断更换成功标准。

指标的不确定性应贯穿整个分析链。基线曲线是估计的,事件起点可能有误差,遗传参数也是估计的,最终综合目标又使用不确定环境权重。若只在最后育种值预测中计算一个条件误差方差,会忽略前面各层的不确定性。可通过分层重抽样、参数抽样或合理情景分析传播主要误差来源,同时说明哪些来源尚未纳入。并非每个项目都能完成最复杂联合模型,但应知道简化发生在哪里。

对于自然扰动,匹配对照能够帮助解释损失。若同一时间所有动物都因饲料改变而下降,个体相对于自身基线的偏离包含共同冲击;若某个体下降而同栏动物稳定,则可能存在个体疾病或设备问题。结合群体同步模式与个体记录,可以改进事件识别。然而,同栏动物也可能共享遗传背景,不能把同栏均值视为完全独立环境。设计中保持家系混合有助于减少这一问题。

一个实用输出还应区分预测的平均遗传优势与单个后代的实际范围。即使某公畜在热环境下的育种值较好,其后代仍会因孟德尔抽样、母本与环境产生变异。预测区间通常比育种值均值的置信或可信区间宽得多。向生产者说明这一点,有助于避免把遗传评价误解为对每一头后代的保证,也有助于安排合理的管理缓冲。

当环境极端到超出基本生存或福利条件时，反应规范的线性外推尤其不合理。生物系统可能出现阈值、不可逆损伤或不同机制主导，原有排序也可能改变。对这类范围，模型应承认资料不足，并通过适当环境改善和专门研究处理。遗传选择能够提高适应能力，但不能使任何生产条件都变得可接受。

系统评价可以在固定产品需求、固定动物数量和固定土地资源三种边界下分别计算结果。这三种边界可能给出不同总排放和资源变化，因此应与决策者实际约束一致。例如提高每头产出在固定动物数量下可能增加总产量和部分资源使用，在固定产品需求下则可能减少动物数量。明确边界比报告一个脱离背景的效率百分比更有助于行动。

最后，研究过程应让现场人员参与性状定义。养殖者、兽医与设备人员能够指出某些曲线异常的实际原因，也能判断指标是否在选种时间可获得。统计模型提供一致推断，现场知识提供情境，两者共同减少把设备故障、管理事件或正常生理变化误认成遗传韧性的风险。参与并不意味着以经验替代证据，而是使收集到的证据真正对应生产问题。

对已部署方案，应定期比较预期响应与实际后代表现，并记录环境和管理同时发生的变化。观察到总体改善不能全部归功于遗传选择，观察到短期波动也不必然说明评定无效。通过合适基准、遗传趋势估计和连续验证，才能逐步判断方案的真实贡献。

32.18 对环境分布积分后的目标与预测误差

环境特异育种值是一条函数，实际选种通常需要一个可比较目标。设动物 i 在环境 q 下的反应规范为 $u_i(q) = \phi(q)^T a_i$ ，其中 $\phi(q)$ 是预先确定的基函数向量， a_i 是动物的随机回归系数。目标生产体系的环境密度为 $f(q)$ ，先假定它与动物基因型独立，并已经由外部情景确定。定义环境平均遗传目标为

$$H_i = \int u_i(q) f(q) dq = m_\phi^T a_i, \quad m_\phi = \int \phi(q) f(q) dq.$$

这个积分先于排序；它把未来环境范围转换成系数权重。若反应规范是二次式， $\phi(q) = (1, q, q^2)^T$ ，环境均值和方差为 μ_q, σ_q^2 ，则

$$m_\phi = (1, \mu_q, \mu_q^2 + \sigma_q^2)^T.$$

因此,相同平均环境而波动不同的两个体系,对弯曲反应的选择权重不同。只把平均温度或平均营养代入非线性曲线,计算的是平均环境下的表现,一般不等于环境平均表现。二者的差异不是数值误差,而是目标定义差异。

假定系数预测为 $\hat{a}_i$, 其预测误差协方差为 C_i , 则目标预测与误差方差为

$$\hat{H}_i = m_\phi^\top \hat{a}_i, \quad \text{PEV}(H_i) = m_\phi^\top C_i m_\phi.$$

环境平均可以降低某些系数误差的影响,也可能放大不利相关。例如截距与斜率预测误差的协方差为负,在正平均环境下可以相互抵消;在负平均环境下反而可能叠加。只把三个系数标准误分别乘权重后相加,既不等于方差传播,也会忽略相关结构。

推导例:环境波动改变非线性排序。动物甲的系数为 $(2, 1, -0.5)$, 乙为 $(1.8, 0.2, 0)$ 。若环境均值为零、方差为 0.2, 甲的目标为 1.9, 乙为 1.8; 若均值不变而方差升为 1, 甲降为 1.5, 乙仍为 1.8。环境越波动, 甲的不利弯曲越重要。设甲的系数误差协方差为对角矩阵 $\text{diag}(0.1, 0.04, 0.01)$, 相应目标误差方差分别为 0.1004 与 0.11。排序变化与精度变化都来自环境目标的改变, 并非偷偷重估动物参数。

若未来环境分布本身未知, m_ϕ 也有不确定性。令其均值为 $\bar{m}$ 、协方差为 Ω , 动物系数后验均值为 $\bar{a}$ 、协方差为 C , 且暂时假定二者后验独立, 则

$$E(H) = \bar{m}^\top \bar{a},$$

$$\text{Var}(H) = \bar{m}^\top C \bar{m} + \bar{a}^\top \Omega \bar{a} + \text{tr}(C\Omega).$$

第一项来自遗传评定, 第二项来自未来环境权重, 第三项来自两者同时不确定。它们是环境平均目标的不确定性; 如果要预测某一头后代在某一次实际环境中的表现, 还要加入环境抽样与个体残差, 不能把这里的目标区间当作单头表现区间。

同一未来情景会同时作用于所有候选者, 因此比较甲乙时应对差值积分。令 $\bar{d} = \bar{a}_A - \bar{a}_B$, 由系数后验均值决定的情景项为 $\bar{d}^\top \Omega \bar{d}$, 而不是两头动物各自情景方差的简单相加。但这并非全部环境相关不确定性。若 C_{AB} 表

示两动物系数的后验交叉协方差, 令 $C_{\Delta} = C_A + C_B - C_{AB} - C_{AB}^T$, 在共同环境权重与系数差后验独立的条件下, 完整差值方差为

$$\begin{aligned} \text{Var}(H_A - H_B) &= \bar{m}^T C_{\Delta} \bar{m} + \bar{d}^T \Omega \bar{d} \\ &\quad + \text{tr}(C_{\Delta} \Omega). \end{aligned}$$

即使两条预测曲线相同, 即 $\bar{d} = 0$, 只要真实系数差仍未知, 最后的交互项仍可能为正。只有差值本身也较确定时, 几乎平行的曲线才支持相应的排序稳定解释; 斜率差异很大时, 即使当前评定很精确, 未来情景仍可能决定优劣。报告选择方案时展示这种共同情景相关, 比只给每头动物一个孤立误差条更有意义。

环境积分还能指导测定资源分配。先看两个或多个离散环境的简化设计: 环境 e 的目标权重为 w_e , 在其中配置 n_e 个独立信息单位后, 环境特异遗传对比的估计方差近似为 s_e^2/n_e , 各环境对比估计暂时视为独立。则积分目标方差为

$$V_H = \sum_e \frac{w_e^2 s_e^2}{n_e}.$$

若每个信息单位成本为 c_e 、总预算为 B , 拉格朗日一阶条件给出

$$n_e = \frac{B |w_e| s_e / \sqrt{c_e}}{\sum_f |w_f| s_f \sqrt{c_f}}.$$

这里分配依据同时包含目标权重、测定噪声和成本。环境越常见通常越值得投入, 但低频且非常难以估计的环境, 也可能需要超过其目标频率的测定份额。令两环境权重为 0.8, 0.2, 标准差参数为 1, 3, 成本相同, 预算为一百个信息单位。连续最优分配约为 57.14, 42.86, 目标方差为 0.0196; 按环境频率分配为 80, 20, 方差为 0.026。后者忽略了第二环境的较大噪声。

这个算例没有计入跨环境遗传相关、共享亲本和场区聚集, 所以不是实际动物数量的处方。真实设计应使用完整信息矩阵评价目标对比, 并处理整数、最低家系覆盖和连通性约束。它说明一个容易混淆的原则: 生产环境的目标比例决定怎样平均遗传表现, 却不必等于研究样本的最佳分配比例。设计可以有目的地过度采样稀少挑战环境, 只要分析时仍明确目标权重, 便不

构成目标变更。若把研究样本频率直接当作未来生产环境概率，才会让方便抽样悄然改变选种方向。

32.19 阈值反应与环境测量决定暴露权重

很多生物反应不在整个环境范围内保持线性。例如温度低于某阈值时动物几乎没有热损失，高于阈值后损失才增加。令 $h_c(q) = \max(q - c, 0)$ ，反应规范写成

$$u_i(q) = a_i + b_i h_c(q).$$

其中 c 是本节视为已知的共同阈值， b_i 描述阈值以上每单位暴露的遗传响应。这个模型的环境平均为 $a_i + b_i E\{h_c(q)\}$ ，真正的斜率权重是超阈暴露的平均强度，而不是平均环境减阈值后简单截断。

若 $q \sim N(\mu, \sigma^2)$ ，令 $k = (\mu - c)/\sigma$ ，通过对阈值以上的正态密度积分可得

$$E\{h_c(q)\} = (\mu - c)\Phi(k) + \sigma\varphi(k).$$

推导可从 $q = \mu + \sigma z$ 开始，把积分分为常数项和 z 项，并使用

$$\int_a^\infty z\varphi(z) dz = \varphi(a)$$

这条结果让均值与波动的作用清楚分开：

$$\frac{\partial E(h_c)}{\partial \mu} = \Phi(k), \quad \frac{\partial E(h_c)}{\partial \sigma} = \varphi(k).$$

在其他条件固定时，均值升高和波动扩大都会增加平均超阈负荷。波动效应在均值接近阈值时最明显，因为这时更多环境实现会被推过阈值。仅记录季节平均温度，会漏掉对这种反应最重要的信息。

推导例：平均气候相同不代表遗传目标相同。取 $\mu = c$ ，则 $E(h_c) = \sigma/\sqrt{2\pi}$ 。当标准差为 1 时，平均超阈负荷约为 0.3989；标准差为 2 时约为 0.7979。动物甲 $a = 3, b = -2$ ，乙 $a = 2.5, b = -0.5$ 。两种波动条件下，甲的环境目标约为 2.2021 与 1.4042，乙约为 2.3005 与 2.1011。即使在恰好等于

阈值的平均环境中甲表现更高，真正积分后的选择可以偏向乙。这个例子只说明阈值与波动的作用，正态环境假设并非对所有气候记录的经验描述。

环境传感器也有测量误差。若观察的是 $w = q + \delta$ ，误差独立且方差为 σ_δ^2 ，在线性反应中直接用 w 回归会使斜率衰减。在阈值反应中，问题更复杂：误差会把阈值两侧的暴露相互混淆。一般有

$$E\{h_c(q) | w\} \neq h_c\{E(q | w)\}.$$

假定 q 与 δ 正态，条件均值和方差为

$$\begin{aligned}\mu_{q|w} &= \mu + \frac{\sigma_q^2}{\sigma_q^2 + \sigma_\delta^2}(w - \mu), \\ v_{q|w} &= \frac{\sigma_q^2 \sigma_\delta^2}{\sigma_q^2 + \sigma_\delta^2}.\end{aligned}$$

把这两个条件参数代入超阈期望公式，就能对真实暴露积分。若只在仪器读数超过阈值时记为受损，将同时造成漏判和误判，而且其比例取决于群体环境分布。更换精度更高的传感器后，估计斜率可能变大，这未必表示动物生物学响应发生变化。

阈值还可能因动物而异，但同时估计个体截距、斜率和阈值需要更丰富的暴露范围。若某家系只经历低于阈值的环境，资料几乎不能识别其超阈斜率；若所有记录都高于阈值，截距与阈值又可能混淆。测量更多相似的舒适期记录，不能替代跨阈值的有效观察。应以自然暴露和合乎动物福利的研究设计增加支持范围，而不是为了统计识别制造不必要的伤害。

在实际群体中，环境也可能受到管理对动物反应的调整。例如高产动物被安排更强降温，其观察暴露就与遗传潜力相关。此时把暴露直接视作外生协变量，需要额外设计支持。明确记录降温、转群和治疗规则，可以帮助区分外部挑战与管理响应；单纯把一个更复杂的温度曲线放进模型，并不能自动解决这种内生性。

32.20 从恢复曲线推导累计损失与遗传目标

韧性包含受损幅度和恢复速度两个维度。设一次短暂冲击在 $t = 0$ 造成产量损失 $A > 0$ ，此后按恢复速率 $\kappa > 0$ 指数衰减：

$$d(t) = A \exp(-\kappa t).$$

这个表达式可由微分方程 $d'(t) = -\kappa d(t)$ 和初始条件 $d(0) = A$ 直接求得。它没有假定所有真实恢复过程都指数变化，而是提供一个可估、可解释的基线。累计损失与半恢复时间分别为

$$L_{\infty} = \int_0^{\infty} d(t) dt = \frac{A}{\kappa}, \quad t_{1/2} = \frac{\log 2}{\kappa}.$$

若观察窗口只有 T ，窗口内损失为

$$L_T = \frac{A}{\kappa} \{1 - \exp(-\kappa T)\}.$$

因此，短窗口可以偏重受损幅度，长窗口更能体现恢复速度。不同研究如果一个只追踪三天、另一个追踪数周，累计损失指标就不具有相同含义。恢复尚未完成就结束记录，会使慢恢复动物的总损失被系统低估；直接将窗口内面积命名为终生韧性，超过了观察范围。

推导例：较小的初始下降仍可能损失更多。动物甲 $A = 10, \kappa = 0.5$ ，乙 $A = 6, \kappa = 0.2$ 。甲初始损失较大，但总损失为 20，乙为 30；半恢复时间分别约为 1.3863 和 3.4657。在两天窗口内，甲累计损失约为 12.6424，乙约为 9.8904，短期排序与无限窗口排序相反。选择目标必须先确定关心哪段时间及其经济权重，否则不同韧性分数之间的争论可能只是评价窗口不同。

可令遗传效应作用于对数幅度和对数恢复率，以保证参数为正：

$$\log A_i = \alpha_0 + u_{A,i}, \quad \log \kappa_i = \kappa_0 + u_{\kappa,i}.$$

在忽略其他变动的教学条件下，累计损失的对数为

$$\log L_{\infty,i} = \alpha_0 - \kappa_0 + u_{A,i} - u_{\kappa,i}.$$

其遗传方差因而为

$$\text{Var}(\log L_\infty) = \sigma_A^2 + \sigma_\kappa^2 - 2\sigma_{A\kappa}.$$

有利方向是降低受损幅度并提高恢复率，但两者的遗传相关决定可同时改善的程度。若幅度较大的动物也恢复更快，负担中的两部分可能抵消；只按幅度选择会遗漏这种补偿。反之，如果降低幅度同时显著降低恢复率，某个表面有利指标可能使总损失变化很小。

指数曲线也可以由离散时间状态表示。相邻记录间隔为 Δ 时，

$$d_{t+\Delta} = \rho_\Delta d_t, \quad \rho_\Delta = \exp(-\kappa\Delta).$$

因此，不同采样间隔下的自相关不能直接比较为恢复速度。每天记录的 $\rho = 0.8$ 与每两天记录的 $\rho = 0.8$ 对应不同 κ ；相同生物恢复率在两天间隔下应产生每日系数的平方。把时间间隔写进模型比对所有动物强行填成相同日数更可靠。

持续外部挑战则会改变输入。若 $d'(t) = -\kappa d(t) + s(t)$ ，其中 $s(t)$ 为随时间变化的损伤输入，观察到的缓慢恢复可能来自较低 κ ，也可能来自仍未结束的 $s(t)$ 。没有独立暴露信息，两者难以区分。Hiltpold、Trépos 和 Douhard (2026) 的绵羊稳健性研究以母羊—羔羊生物能量模拟讨论获取与分配之间的取舍，表明长期表现应放在完整资源过程内解释。该研究属于有明确生成假设的模拟证据；这里的指数恢复是另一种简化教学结构，不能被当作其真实动物参数或普遍恢复规律。

32.21 状态估计把测量噪声与真实恢复分开

高频传感器记录不是生理状态的直接复制。令潜在损失状态为 x_t ，观察为 $y_t = x_t + e_t$ ，并假定

$$x_t = \rho x_{t-1} + b_t + \eta_t, \quad \eta_t \sim N(0, Q), \quad e_t \sim N(0, R).$$

这里 b_t 是已知外部输入，过程误差 η_t 描述状态演变中的未解释变化，测量误差 e_t 描述仪器读数偏离真实状态；两者独立。固定参数时，这是线性高

斯状态空间模型，可以逐步更新潜在状态，而不是先对原始轨迹任意平滑再把平滑结果当作无误差表型。

若上一时点状态条件均值和方差为 $\hat{x}_{t-1}$ 与 P_{t-1} ，预测步骤为

$$\hat{x}_t^- = \rho \hat{x}_{t-1} + b_t, \quad P_t^- = \rho^2 P_{t-1} + Q.$$

当前创新，即实际观察与预测观察的差，为

$$v_t = y_t - \hat{x}_t^-, \quad \text{Var}(v_t) = P_t^- + R.$$

根据二元正态条件分布，更新权重和后验为

$$K_t = \frac{P_t^-}{P_t^- + R},$$

$$\hat{x}_t = \hat{x}_t^- + K_t v_t, \quad P_t = (1 - K_t) P_t^-.$$

每一步都有明确的信息含义：测量越精确，越相信新观察；状态预测越不确定，也越依赖新观察。若把所有记录用同一个固定平滑权重处理，就隐含各时点预测误差相同，这在缺失、冲击和不同测量精度下通常不成立。

推导例：一次观察和一次缺失。取 $\rho = 0.8$ 、 $Q = 0.36$ 、 $R = 1$ ，上一时点均值为 2、方差为 1，当前输入为零。预测均值为 1.6、方差为 1。若当前读数为 3，更新权重为 0.5，状态均值变为 2.3、方差变为 0.5。下一时点若没有观察，只能传播得到均值 1.84、方差 0.68；再缺失一次，方差变为 0.7952。缺失不等于观察到零损失，后者会把状态均值向零拉并缩小方差，而真正缺失应当保留更大的不确定性。

若模型达到平稳且无输入，潜在状态方差及观测滞后协方差为

$$\text{Var}(x_t) = \frac{Q}{1 - \rho^2},$$

$$\text{Cov}(y_t, y_{t-1}) = \rho \frac{Q}{1 - \rho^2}, \quad \text{Var}(y_t) = \frac{Q}{1 - \rho^2} + R.$$

由此可见，原始观察的一阶自相关比潜在状态的 ρ 小，因为测量误差增加零滞后方差，却不增加跨时协方差。在上例中潜在方差为 1，观测方差为

2, 原始一阶自相关为 0.4, 只有真实状态持续系数的一半。直接以原始自相关比较恢复, 会把设备噪声较大的动物误判为恢复更快。

遗传分析还需把个体状态估计误差传递到下一层。若先为每头动物估计恢复率, 再把这些估计作为同精度表型, 会让记录少、缺失多的动物与高质量轨迹获得同样权重。可以采用联合层次模型, 或者在适当近似下使用每个估计的误差协方差。后者仍需检查两阶段估计是否共享同一批基线参数, 因而具有跨动物相关; 一组独立标准误未必足够。

参数 Q, R, ρ 本身未知时, 上面的条件方差只反映固定参数下的状态不确定性。应通过参数后验、重复抽样或其他相容方法传播额外变异。若检测概率由状态决定, 例如动物不进食时就不产生自动采食记录, 缺失又不是随机的; 仅运行状态滤波不能解决这个选择过程。应同时建模记录机会, 或在独立观测中验证缺失机制。高频资料的价值在于支持动态辨别, 而不是把更多时间点自动视为更多独立动物。

32.22 群体传播的遗传目标来自传播算子

抗感染、传染性与恢复速度通过不同路径改变群体疾病。考虑早期流行、易感动物尚未明显耗竭的阶段, 令 K_{ab} 表示一个来自类型 b 的感染者, 在平均感染期内产生类型 a 新感染者的期望数。矩阵 K 称为下一代矩阵, 其主特征值

$$R_0 = \rho(K)$$

描述线性早期增长阈值。这里的 ρ 表示谱半径, 与上一节的时间持续系数不是同一参数。若 $R_0 < 1$, 小规模输入在模型条件下不能持续扩大; 若 $R_0 > 1$, 存在扩张潜力, 但实际疫情大小仍依赖初始状态、接触结构和随机性。这个阈值不能代替具体防疫风险评价。

在一个比例混合的教学模型中, 类型 a 的群体比例为 π_a 、易感程度为 s_a , 类型 b 的传染强度为 f_b 、平均感染期为 d_b , 共同接触系数为 β , 则

$$K_{ab} = \beta \pi_a s_a f_b d_b.$$

这是一个秩一矩阵，非零特征值可直接求得：

$$R_0 = \beta \sum_b \pi_b s_b f_b d_b.$$

平均易感性、传染性和感染期的乘积一般不等于乘积的平均，所以三个性状之间的联合分布也重要。若高易感者同时更容易传播且感染期更长，单独改善某个平均指标可能低估群体尾部风险。比例混合只是便于推导的情境，圈舍分群、亲缘聚集和接触行为会改变矩阵结构。

对于近似同质群体，令恢复率为 $\gamma = 1/d$ ，则

$$\log R_0 = \log \beta + \log s + \log f - \log \gamma.$$

对小遗传改变线性化，得到

$$\Delta \log R_0 \approx \Delta \log s + \Delta \log f - \Delta \log \gamma.$$

这指出有利遗传方向同时包括降低易感、降低感染后的传染能力与加快恢复。只记录个体是否患病，主要直接观察易感和恢复的后果；某动物的传染性主要改变其他动物的感染，属于间接作用。把它们全部压成个体产量损失，会遗漏传播外部效应。

一般接触结构下，可用主特征值对参数的导数定义局部权重。若主特征值简单，左右特征向量分别为 ℓ, r ，则

$$\frac{\partial R_0}{\partial \theta} = \frac{\ell^\top (\partial K / \partial \theta) r}{\ell^\top r}.$$

这条公式说明同样降低某类动物的传染性，在不同接触位置上可能有不同群体收益。网络中的作用不能仅凭个体感染次数推断；左右特征向量分别反映进入和继续传播的结构。对强烈时变接触过程，还需要时变传播模型，静态矩阵只是局部近似。

推导例：降低一个群体的传染性。 设

$$K = \begin{pmatrix} 1.2 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}.$$

主特征值约为 1.3583。若第二类型的传染性减半，应把第二列减半，得到主特征值约为 1.2623；不是把第二行减半，因为行表示受感染者类型，列表示感染来源。这个改变降低了传播潜力，但仍未越过阈值一。提高个体耐受而不改变易感、传染性或感染期，在该模型中不会降低 R_0 ，即使它确实改善个体福利或产量。

Pooley 等 (2020) 利用时间疫情资料研究个体遗传与非遗传的易感、传染和恢复效应，强调接触群与事件时间为这些来源提供不同信息。这里的矩阵推导解释其背后的传播目标，并非假定所有畜群都满足同一种接触模型。识别传染性需要群间重复、适当遗传连接和感染来源信息；增加同一个圈舍内的密集记录，可能仍不能替代更多独立接触群。遗传改良应与疫苗、卫生和接触管理相配合，模型给出的群体收益始终要在相应病原和管理条件下验证。

32.23 可持续目标中的比值、寿命与不确定性

单位产品排放把资源使用与生产连接起来，但比值的遗传响应不能只看分子。令排放为 M 、产品为 $Y > 0$ ，强度为 $I = M/Y$ 。在参考均值 (M_0, Y_0) 附近，一阶展开为

$$\Delta I \approx \frac{\Delta M}{Y_0} - \frac{M_0}{Y_0^2} \Delta Y.$$

等价地，对数强度变化近似为

$$\Delta \log I \approx \frac{\Delta M}{M_0} - \frac{\Delta Y}{Y_0}.$$

这两个表达式说明，提高产出可以降低强度，而不一定降低每头排放。若政策或生产目标关心总排放，还必须规定群体规模或产品需求怎样变化。同样的遗传响应，在固定头数与固定产品量下会对应不同总量，不能使用同一个百分比概括。

固定需求 D 时，所需动物数近似为 $N = D/Y$ ，总排放为

$$E_{total} = NM = D \frac{M}{Y}.$$

这时强度与总量在规定边界内直接相连。若遗传改良同时改变存活、更新母畜需求和饲养阶段,就应扩展分子。一个稳态教学模型设成畜年排放为 M , 每次更新的培育排放为 E_{rep} , 平均有效生产寿命为 L 年, 年产出为 Y , 则

$$I_{life} = \frac{M + E_{rep}/L}{Y}.$$

这里假定成年群规模稳定、更新率可近似为 $1/L$, 且培育排放已按同一系统边界计算。寿命的边际权重为

$$\frac{\partial I_{life}}{\partial L} = -\frac{E_{rep}}{L^2 Y}.$$

寿命越短, 略微延长寿命所减少的更新负担可能越大; 但这不意味着无条件延长所有动物寿命, 因为老龄产量、健康、繁殖和饲养资源也可能变化。若这些变化没有进入 M, Y, L 的联合模型, 单独的导数只能用于局部说明。

推导例: 更新负担改变减排判断。取 $M = 100$ 、 $E_{rep} = 300$ 、 $Y = 50$ 、 $L = 3$, 排放强度为 4。若其他条件不变、寿命延长至 5 年, 强度降至 3.2。在 $L = 3$ 处, 一阶寿命权重约为 -0.6667 ; 用它乘两年会预测下降 1.3333, 大于精确下降 0.8, 因为两年已不是很小的局部改变。非线性目标的选择方案应回代原函数核验, 不能把参考点权重永久固定后对远期结果作精确宣称。

预测的不确定性也应传播。若 $\widehat{M}, \widehat{Y}$ 的误差协方差为 C , 一阶近似为

$$\text{PEV}(I) \approx g^T C g, \quad g = \begin{pmatrix} 1/Y_0 \\ -M_0/Y_0^2 \end{pmatrix}.$$

正的排放—产出误差协方差在这里可能降低比值误差, 因为分子分母共同偏高有部分抵消。忽略协方差既可能高估也可能低估风险。若分母靠近零、可能为负, 或者不确定性很大, 一阶近似可能失效; 此时应采用符合正值支持的联合分布, 直接计算目标分布, 并检查其矩是否存在。

比值的期望与均值之比也不同。二阶展开给出

$$E\left(\frac{M}{Y}\right) \approx \frac{\mu_M}{\mu_Y} - \frac{\text{Cov}(M, Y)}{\mu_Y^2} + \frac{\mu_M \text{Var}(Y)}{\mu_Y^3}.$$

这说明产出波动本身可以抬高期望强度，即使平均产出不变。环境韧性与可持续性因此可以通过减少低产尾部相联系，但这个联系依赖系统边界与联合分布，不能由一个残差方差指标自动推出。若平均强度是按动物计算，而实际目标是全群总排放除以全群总产出，两者权重也不同：后者相当于按产品量加权的个体强度。

最终育种目标应在一个一致账本中合并生产、排放、健康和寿命。若延长寿命带来的培育排放减少已经计入生命周期分子，再添加一个完整“寿命减排奖励”，可能重复记账；若产量提高已降低固定需求下所需头数，也不应再次把相同头数下降作为独立收益。清楚定义功能单位、时间范围与更新过程，比给一个宽泛“可持续分数”赋予漂亮名称更能支持长期选择。

32.24 综合练习与解答

练习 1. 反应规范 $u(q) = u_0 + qu_1$ 中，截距方差为 9，斜率方差为 1，协方差为 -1 。求 $q = q' = 0$ 时的遗传方差，以及 $q = 1$ 时的遗传方差。

解答. 同一参考环境 $q = q' = 0$ 下方差为 9； $q = 1$ 时为 $9 + 2 \times (-1) + 1 = 8$ 。必须同时指定两个环境相同才能把协方差解释为方差。截距方差只对应选定参考环境，改变环境中心后其数值会改变。

练习 2. 在练习 1 参数下，求 $q = -1$ 与 $q = 1$ 两环境遗传相关。

解答. 两方差分别为 12 与 8，协方差为 $9 + 0 - 1 = 8$ ，相关为

$$8/\sqrt{96} \approx 0.8165$$

相关小于一表明遗传排序并非完全一致，但是否需要分环境育种仍取决于目标权重、评价精度与体系成本。

练习 3. 动物 A 反应规范为 $2 + q$ ，B 为 $1 - 0.5q$ 。目标环境只有 $q = -1$ 和 $q = 1$ ，不利环境概率为 p 。求两者平均表现相等时的 p 。

解答. $E(q) = 1 - 2p$ ，A 平均值为 $3 - 2p$ ，B 为 $0.5 + p$ 。令两者相等得 $p = 2.5/3 \approx 0.8333$ 。当不利环境概率高于该值，B 平均更优；低于该值则 A 更优。这个阈值建立在已知线性反应规范和同一性状单位上。

练习 4。某动物五天偏离为

$$(-2, -2, -2, -2, -2)$$

另一动物为

$$(-2, 0, 2, 0, -2)$$

哪一头残差方差更小？这能否独立决定韧性排序？

解答。第一头方差为 0，第二头按总体分母方差为 2.24，但第一头持续低于基线。单靠方差不能决定韧性，还需考虑平均损失、暴露、恢复和长期代价。如果基线估计不适当，两种偏离的解释也会改变。

练习 5。某时间序列只有出生、断奶和成年三个体重记录。研究者据此声称已经精确测量每次短期应激的恢复速度。指出问题，并提出恰当表述。

解答。三个稀疏时点不能直接观察每次短期事件及其恢复轨迹，期间可能发生多次未记录扰动。可以构建相对于参考生长曲线的恢复或稳定性相关指标，并估计其遗传参数，但应明确这是稀疏轨迹代理。进一步需要高频或已知挑战资料验证生物含义。

练习 6。残差方差的对数遗传效应下降 0.10，对应方差和标准差分别变化多少？

解答。方差乘以 $\exp(-0.10) \approx 0.9048$ ，降低约 9.52%；标准差乘以 $\exp(-0.05) \approx 0.9512$ ，降低约 4.88%。这两个比例不同，且都只是给定模型尺度下的转换，实际选择响应还取决于遗传传递与预测精度。

练习 7。甲烷与生产遗传方差分别为 80 和 20，协方差为 20。求遗传残差甲烷的回归系数、方差及其与生产的协方差。

解答。系数为 1，残差方差为 $80 - 20^2/20 = 60$ ，与生产协方差为 $20 - 1 \times 20 = 0$ 。若使用的是表型回归系数，通常不能得到同样遗传正交性质。参数估计误差和实际选择方式仍可能使生产出现非零响应。

练习 8。动物甲日排放 150 克、产出 6 单位，乙日排放 180 克、产出 9 单位。按总量与强度分别如何排序？若固定需求为 18 单位，静态比例计算的总排放是多少？

解答。总量甲较低，强度甲为 25、乙为 20 克每单位，故乙较低。固定需求下甲需 3 头、排放 450 克，乙需 2 头、排放 360 克。这个结果仅对应教学中的线性比例边界，完整生命周期还需考虑维持、更新、饲料和其他排放。

练习 9。一个新模型在同场随机测试中表现很好，在留出整个场区后明显失准。列出可能原因，并说明该如何报告。

解答。可能存在管理与家系混杂、环境范围外推、设备差异或训练测试近亲带来的信息优势。应分别报告两种任务，不能只保留随机测试结果。下一步可补充跨场连接、核对环境与表型尺度，并在目标新场验证校准；不能未经证据把全部下降归因于某一原因。

练习 10。为什么感染后产量损失小的动物未必最有利于群体防病？

解答。它可能具有较强耐受，却仍携带或排出较多病原，增加同群传播。群体目标需要考虑易感性、传染性、接触行为和个体损失。仅用自身产量稳定性无法完整描述这些间接影响，需结合感染和传播资料。

练习 11。一项资源分配模拟显示某类母畜在干旱情景下终生表现更好。能否直接宣布已找到可用于选择的遗传类型？

解答。不能。模拟个体类型由参数设定定义，必须进一步证明关键参数具有可利用遗传变异，并在实际群体、环境和记录条件下验证。模拟可以提出机制假设、识别敏感参数和指导采样，但不是实际遗传响应的替代证据。

练习 12。为一个未来环境不确定的地方品种设计选择原则，要求兼顾生产、韧性和多样性。

解答。采用多套明确环境情景评价关键性状，保留跨环境预测与不确定性；在综合目标中设置健康或最低表现约束，并通过贡献和亲缘约束控制近交。优先补充资料稀缺环境中的连接记录，避免把资源全部集中到当前平均环境最优的少数家系。随着新数据更新权重与参数，同时保留可追踪的版本和验证结果。

深度学习与基因组基础模型

33

33.1 三类任务，三种不同的预测对象

深度学习进入基因组研究，最重要的变化是能够从复杂输入中学习表示，而不是取消统计推断和实验设计的基本要求。模型仍需明确预测目标、信息取得时间、训练与测试边界以及适用群体。更灵活的函数能够描述复杂关系，也更容易学习批次、家系和环境中的偶然捷径。模型规模本身不能保证生物学正确，更不能保证育种收益。

首先应区分 SNP 到性状的预测、DNA 序列到分子功能的预测，以及自监督序列表示学习。第一类通常使用许多动物的基因型和表型，学习群体中的统计遗传关系；第二类使用序列与表达、剪接或染色质实验信号，学习分子测量的序列基础；第三类从大量序列本身的规律学习表示，再用于不同下游任务。三类任务可以串联，但输出单位和证据范围不同。

一个表达变化分数并不是育种值。它可能说明某变异在某组织中改变转录的方向，却没有说明这种变化对生长、繁殖、健康和经济目标的综合作用。一个序列概率也不是适合度，更不是某畜种的选留价值。将分子预测转化为育种决策，还需要物种、组织、性状、遗传协方差和目标权重等层次的证据。

“基础模型”强调预训练表示能够服务多个下游任务，而不是说明模型已掌握全部生命规律。预训练可以降低特定任务对标注数据的需求，但迁移效果取决于训练资料覆盖、模型目标与下游问题的一致性。一个在人类调控任务上表现好的模型，可以为家畜提出候选假设，却不能未经验证就宣称提高牛、羊或猪的育种准确度。

对于育种研究者，最有用问题不是哪一种模型名称最先进，而是哪一

种信息过去难以利用、新表示是否保留了它、以及它是否在独立目标群体中减少预测误差。某些问题确实需要复杂非线性表示，例如原始图像、长序列和多模态信号；另一些高度多基因性状，在有限样本下线性收缩模型已经具有很好的偏差—方差平衡。

因此，本章把深度模型放在前面各章建立的数量遗传框架中讨论。模型可用于构建表型、学习功能注释、改进预测或提出机制假设，每一种用途都有不同验证标准。只有明确其位置，才能判断一次技术进展究竟推进了整条育种证据链的哪一段。

33.2 线性模型、核方法与表示学习的桥梁

设每头动物的输入为 x_i ，一个特征映射把它变为 $\phi(x_i)$ 。若采用线性输出 $\hat{y}_i = \phi(x_i)^\top w$ 并对 w 施加平方惩罚，就得到特征空间中的岭回归。即使输出形式是线性的，只要特征映射非线性，原始输入到预测的关系仍可非线性。这说明线性与非线性的区别不仅在最后一层，也在输入表示。

将所有特征堆成矩阵 Φ ，岭回归解为 $\hat{w} = (\Phi^\top \Phi + \lambda I)^{-1} \Phi^\top y$ 。在适当可逆条件或广义形式下，训练预测也可写成 $K(K + \lambda I)^{-1} y$ ，其中 $K = \Phi \Phi^\top$ 。任意向量 v 满足 $v^\top K v = \|\Phi^\top v\|^2 \geq 0$ ，因此 K 是半正定核，可与随机效应协方差联系。

这个桥梁把基因组 BLUP、核岭回归和表示学习放在同一语言中。经典基因组核来自中心化标记，其他核可以来自功能注释、组学或学习到的嵌入。给定核时，预测仍可采用熟悉的收缩形式；学习核本身则增加了新的估计层次和过拟合风险。若嵌入使用目标表型训练，必须在验证边界内重新学习，不能把它当作完全外部特征。

例 33.1 一个非线性特征改变可表达关系。输入 x 取 $-1, 0, 1$ ，目标为 x^2 。只用截距和线性 x 时，最小二乘斜率为 0，截距为 $2/3$ ，平均平方误差为 $2/9 \approx 0.2222$ 。加入特征 x^2 后，可以精确表达三个点。这个例子说明特征表示的重要性，但没有证明复杂特征在新样本中总有益；若真实目标是线性加噪声，额外特征也可能只拟合噪声。

深度网络可以看作同时学习多个层次的特征。早期层组合输入局部模式，后续层组合更复杂关系，最后输出目标。与手工指定多项式相比，它能在大量数据中自动寻找有用表示；但参数多、优化复杂，且许多不同参数组合可以产生相似预测。模型解释不能直接把每个参数当作遗传效应。

在数量遗传背景下，还要区分总遗传值与加性育种值。非线性基因型模型可能捕捉显性或上位性对个体表现的贡献，这对预测杂交个体表型有用；但这些贡献不一定按同样方式传给后代。若目标是育种值，需要说明如何从模型中得到平均可传递效应，或通过后代验证确认。更高表型预测精度不自动意味着更高加性育种值准确度。

深度表示与混合模型的组合可以保留某些优势：使用网络处理原始复杂输入，再用明确的遗传关系和方差结构连接群体；或者保留线性基因组部分，增加受约束的非线性残差。组合的价值应由独立增量判断。若两部分反复解释同一信号，复杂性可能增加而信息没有增加。

33.3 样本量不是文件中的行数

基因组数据往往特征极多、独立遗传样本有限。上万头动物可能主要来自少数家系，数百万序列窗口可能包含重复和同源片段，数千组织轨迹也可能来自有限细胞系。训练文件的行数不等于独立信息量。模型容量应与有效信息、目标噪声和推广范围相匹配，而不是只与总数据量比较。

家系结构对预测具有双重作用。近亲信息是实际育种评定的重要资源，合理利用并非泄漏；但若研究声称能推广到全新家系，却在测试中保留大量近亲，就高估了对应任务的能力。因此，是否隔离近亲取决于部署目标。未来同一核心群体的年轻动物通常有训练亲属，而跨品种迁移则需要更严格的边界。

例 33.2 重复记录如何改变有效样本量。为直观说明，假设一百个独立组，每组十条记录，组内相关均为 0.5，且使用一个简单等相关近似。总记录数为 1000，设计效应为 $1 + (10 - 1) \times 0.5 = 5.5$ ，近似有效样本量为 $1000/5.5 \approx 181.8$ 。这个公式不是复杂家系基因组数据的通用有效样本量计

算，但说明强相关记录不能按独立样本计数。

目标质量同样限制学习。表型包含环境误差，校正表型或去回归育种值又可能具有不同精度和依赖结构。若把这些标签一律当作同等可靠的真实值，网络可能过度学习低精度记录。可以使用适当权重、显式噪声模型或联合遗传模型，但权重定义应与标签生成过程一致，不能为了提高测试相关随意调整。

样本代表性比数量更难补救。一个模型在某品种、某年代和某管理体系中有大量训练资料，仍可能对地方品种或新环境缺乏信息。增加同一起来源的更多样本可能继续改善内部预测，却不一定改善外部迁移。设计中应识别最缺乏覆盖的遗传与环境区域，并评估补充这些样本的边际价值。

高维特征的冗余也影响学习。连锁不平衡使许多 SNP 携带近似信息，网络可能用不同参数表达同一遗传信号。某些方法通过局部结构、稀疏化或低维嵌入减少冗余，但错误的压缩也可能丢掉稀有变异。应比较压缩前后的外部表现，尤其检查稀有携带者和跨群体任务，而不是只看训练速度。

数据量曲线有助于判断瓶颈。用不同训练规模重复评价，可以观察性能是否仍随样本增加、是否已趋于平台，以及复杂模型是否只在较大规模后显示优势。曲线应使用相同测试任务和合理重复，不应把不同群体或不同噪声水平的数据点混在一起。学习曲线提供设计信息，但不能无条件外推到远超观察范围的样本量。

在报告中，应同时描述动物数、家系数、场区数、年代范围、表型精度和基因型覆盖。对于序列模型，还应描述物种与同源结构。这样的数据说明比仅列“数十亿特征”更能帮助读者判断模型能学到什么，以及哪些应用仍缺乏证据。

33.4 神经网络的基本计算与正则化

一个前馈层可写为 $h = \rho(Wx + c)$ ，其中 W 和 c 为参数， ρ 是非线性函数。多层组合扩大可表达函数范围，训练则通过损失对参数的梯度更新。这个计算机制本身不包含遗传学知识；遗传结构只能通过输入、网络设计、损

失、先验或数据分布进入。若不显式考虑，网络可能把最容易降低训练损失的任何关联都当作信号。

例 33.3 一个小网络如何表示阈值响应。设 $\rho(z) = \max(0, z)$ ，模型 $f(x) = 2\rho(x - 1)$ 。当 $x = 0, 1, 2, 3$ 时，输出分别为 0、0、2、4，表示超过阈值 1 后线性增加。这个结构适合表达某些分段关系，但阈值和斜率需要从数据估计，不能因为网络允许阈值就断言发现了真实生理临界点。不同网络参数可能在观察范围内产生相似函数。

正则化用于限制模型在有限数据中的不稳定性。平方惩罚倾向于缩小参数，稀疏惩罚倾向于减少活跃特征，提前停止限制训练对噪声的追逐，随机失活则改变训练过程中的特征依赖。它们并非彼此等价，也不保证必然改善。正则化强度需要在训练内部选择，并与合理基线比较。

损失函数决定模型优先解决什么误差。均方误差对大偏差敏感，绝对误差更关注中位数型目标，排序损失直接强调相对顺序。育种选择确实关心排序，但只优化排序可能牺牲尺度校准，影响多性状指数和预期响应。因此，即使采用排序目标，也应独立检查预测单位、偏差和误差分布。

训练过程具有随机性。初始化、批次顺序和硬件数值行为可能造成不同结果，尤其在小样本中。报告最好一次运行会夸大表现，应在合理重复中说明均值与变异，并保留失败或不收敛情况。若方法对随机种子极敏感，其生产稳定性需要额外处理，而不是只增加一次挑选机会。

超参数搜索也是学习过程的一部分。网络宽度、层数、学习率和惩罚强度都可能影响性能，搜索越广，使用同一验证集反复选择的偏差越大。嵌套验证可以把选择与最终评价分开。计算预算有限时，应优先定义有意义的小范围搜索，而不是无边界尝试后只呈现最优组合。

输入尺度尤其影响优化。不同 SNP 编码、缺失值和连续组学特征若尺度差异很大，训练可能偏向某些变量。标准化应使用训练参数，并保留基因型方向与参考频率。缺失值不能简单用一个恰好也是合法基因型的数值而不加说明，否则模型可能把缺失模式误当作生物信号；必要时使用缺失指示或不确定性表示。

神经网络的灵活性最适合被视为一项可检验能力：它可以表达某些传统模型难以表达的关系，但是否学到了这些关系，需要消融、外部验证和适当解释。把网络拟合成功直接解释为发现上位性或复杂调控，是从函数形式跳到了机制结论，缺少中间证据。

33.5 卷积结构与基因组局部性

卷积通过共享局部参数识别重复出现的模式。在 DNA 序列中，一个短模体可以出现在不同位置，参数共享有助于用较少参数检测它；在图像中，局部边缘和形状也具有类似性质。对 SNP 数组，卷积则隐含相邻输入具有某种局部关联，需要核对输入顺序与生物距离是否一致。

芯片位点通常不等间距。把相邻十个 SNP 视为同样宽度的窗口，某些区域可能覆盖几千碱基，另一些覆盖很长区间。卷积核看到的是索引邻近，不一定是物理距离或重组距离邻近。可以加入位置编码、按区间聚合或采用适合不规则位置的结构，但这些设计需要验证，不能假定一般图像卷积直接适合所有基因型矩阵。

例 33.4 感受野的扩展。在步长为 1、无池化且不使用膨胀的简化网络中，连续三层长度为 3 的卷积，其感受野为 $1 + 3 \times (3 - 1) = 7$ 个输入位置。若这七个 SNP 位于不同密度区域，实际覆盖距离可能明显不同。使用膨胀或池化可以扩大范围，但也可能损失精细位置信息。感受野是模型能够利用的范围，并不证明它实际学会了该范围内的生物互作。

DNA 具有方向与互补结构。一个调控模体在反向互补序列中可能具有相应表示，因此数据增强或架构可以考虑这种对称性。但并非所有输出都完全方向不变，转录和剪接常具有链特异性。模型需要把输入变换与输出变换一起定义，不能只翻转序列而保留不恰当标签。

局部模式还受到更长背景影响。一个短模体是否发挥作用，可能依赖邻近模体组合、染色质状态和远端调控。卷积可以逐层组合局部特征，但有限感受野会限制上下文；扩大感受野又增加计算和学习难度。选择结构时，需要在分辨率、上下文和样本信息之间取舍。

对于基因型到性状预测，局部窗口也可能主要识别单倍型和家系背景，而非分子功能。这个能力可以提升同群体预测，但跨品种时连锁结构变化可能削弱效果。应通过跨家系或跨群体验证判断其迁移性，并与明确的单倍型或局部核基线比较，避免把所有局部增益都称为生物机制发现。

卷积模型的可解释性通常从激活模式、输入扰动或特征归因入手。某个卷积核与已知模体相似，可以支持其学习了相关序列模式；但一个模体匹配不等于该核在所有预测中都具有相同作用。多个核可能共同表示同一过程，单个核也可能混合多种模式。解释需要结合实际输出任务和背景。

Gsformer 等近期模型把卷积与注意力组合，体现了局部与远程表示共同使用的思路。Yang T 等 (2026) 的研究在多种动植物资料中比较了相关架构，提供了具体任务中的预测证据。应按其数据和划分理解结果，不能据模型名称推导对所有育种群体的优势，更不能把表型预测比较当作已实现长期遗传增益。

33.6 注意力、长序列与计算边界

自注意力让一个位置根据与其他位置的关系汇集信息。常见表达式为 $\text{softmax}\left(QK^T/\sqrt{d}\right)V$ ，其中查询、键和值来自输入表示， d 是相应维度。注意力权重描述模型在当前输入和参数下如何组合信息，而不是直接测量染色体接触或因果调控强度。

全注意力的一个困难是位置两两比较带来平方规模。若序列长度从一千增加到一万，成对项数量从一百万增加到一亿；长度再扩大时，内存与计算很快成为限制。稀疏注意力、分块、低分辨率表示和其他长序列结构试图降低成本，但每种近似都可能限制可表达关系，需要与目标任务相匹配。

例 33.5 压缩分辨率的收益与代价。一段一百万碱基的序列若每个碱基一个位置，完整成对矩阵有 10^{12} 个元素；若每一千碱基汇总成一个位置，则只剩一千个位置、 10^6 个成对元素，规模降低一百万倍。但这种压缩可能失去单碱基和剪接位点分辨率。多尺度结构尝试在长范围与局部分辨率之间连接信息，而不是无代价地同时获得两者。

位置表示也不是细节。模型需要知道两个序列片段的距离、方向和所属染色体，或者至少学习与这些属性一致的关系。若把来自不同染色体的末尾与开头直接拼接，可能制造不存在的邻接。对个体 SNP 数据，位点缺失或过滤还会改变索引，训练与部署必须保持一致映射。

长上下文只表示模型有机会利用远端信息，不保证它能准确识别每一种远程调控。训练标签可能缺少相关细胞状态，远端效应也可能被其他信号淹没。评价应按距离、组织和变异类型分层，检查性能如何变化。一个总体平均指标容易被大量近端或容易预测任务主导。

注意力还可能学习群体捷径。例如某些标记组合高度识别品种，而品种又与场区相关，模型可以通过品种背景预测表型。若实际目标就是同体系内预测，这种信息可能有用；若声称发现位点间生物互作或跨群体能力，就需要额外验证。结构允许全局关联，并不自动赋予这些关联机制含义。

对于有限家畜样本，庞大注意力模型可能需要预训练、参数共享或强正则化才能稳定。是否值得使用，应与简单线性、局部核和较小网络比较，同时考虑调参成本。若性能差异很小但维护复杂度大幅增加，较简单方法可能更适合常规评定；复杂模型仍可用于探索或功能注释等其他任务。

理解计算边界有助于合理设定研究目标。不是所有问题都需要直接把整套个体基因组送进一个巨大模型。可以先对相关区域学习分子表示，再在群体层面聚合；也可以用多尺度模型保留局部与全局信息。关键是每次压缩或聚合后，清楚知道保留了什么、丢失了什么，以及如何用独立数据检验。

33.7 自监督预训练学到了什么

自监督学习从数据本身构造训练目标，例如预测被遮盖的碱基或根据前文预测下一个符号。它不需要为每条序列提供生产性状标签，因此可以利用大量基因组资源。模型通过完成这些任务学习序列规律，但预训练目标与育种目标之间仍有距离：能预测序列中的常见模式，并不等于能预测某个变异对特定畜种经济性状的作用。

序列表示可以包含组成、重复、进化约束和局部结构等信息。哪些信息

被保留，取决于训练物种、分词方式、上下文长度和目标函数。若使用固定长度片段作为符号，模型计算更便宜，却可能模糊单碱基变化；若逐碱基表示，分辨率高但序列更长。不同选择影响下游变异评分，不能只比较参数数量。

例 33.6 序列概率不是有利效应。假设模型在某背景下给参考碱基的概率为 0.8，替代碱基为 0.1，对数概率差为 $\log(0.1) - \log(0.8) = \log(0.125) \approx -2.0794$ 。这个分数说明替代在模型学习的序列分布中较不典型，不能直接解释为生产下降 2.0794 单位。少见序列可能有害、中性，也可能在特定育种目标下有利，效应方向和单位需要下游证据。

预训练数据覆盖也可能产生偏差。资料丰富物种和参考基因组会贡献更多模式，地方畜种特有序列可能覆盖不足；重复序列和组装错误若未处理，也会进入学习。跨物种大数据增加广度，却不保证每个物种的调控机制都被同样准确表示。评价应关注目标物种和区域，而不是只引用总体训练规模。

Brix 等（2026）发表的 Evo 2 展示了跨生命域的大规模 DNA 基础模型，使用长上下文并服务多类序列预测与设计任务。这类研究说明自监督表示可以跨任务使用，但其发表证据并不等于家畜育种值的直接验证。对本书问题，较合理的应用是把表示作为候选特征或先验，在目标物种和明确预测任务中进行独立检验。

下游使用大体有冻结表示与微调两种方式。冻结表示只学习较小预测层，所需样本较少且便于比较；微调允许模型适应新任务，却增加过拟合和忘记原有知识的风险。参数高效微调限制更新范围，但仍需要调参和验证。不能因为只更新少量参数就认为没有泄漏或过拟合可能。

零样本预测意味着不使用该下游任务的训练标签，并不意味着没有任何相关信息进入预训练。若测试序列或高度同源区域已在预训练中出现，任务独立性需要明确。对某些应用，利用公开参考序列本来就是允许的信息；但若声称推广到全新物种或区域，就需要相应隔离。评价应依据具体主张，而不是把“零样本”作为普遍质量保证。

预训练是否有用，可以通过与随机初始化、简单序列统计和传统注释比

较来判断。如果复杂嵌入只重复 GC 含量、保守性或已知基因位置，仍可能有预测价值，但贡献应准确说明。最有意义的证据是它在控制这些基线后提供稳定增量，并且这种增量在目标群体和任务中保留。

33.8 变异评分：从两条序列的差异到统计特征

序列到功能模型常通过比较参考与替代序列的预测得到变异分数。若某一输出轨迹为 $f(s)$ ，可定义差值 $\Delta = f(s_{alt}) - f(s_{ref})$ 。这个分数依赖输出类型、汇总窗口、组织、序列背景和模型版本。一个变异可能同时改变多个输出，不能无条件压成单一“好坏”标签。

有些任务使用原始差值，有些使用对数差、最大变化或区域积分。不同汇总方式强调不同生物作用：最大变化可能突出局部剪接位点，积分可能反映总表达，绝对值则丢失方向。选择评分规则应根据问题，并在独立数据中校准。若在最终测试结果上挑选最有利汇总方式，仍属于调参泄漏。

例 33.7 差值与相对变化并不等价。对基因甲，参考与替代预测表达为 100 与 110，差值 10，相对增加 10%；对基因乙为 1 与 3，差值 2，相对增加 200%。若按绝对差值排序，甲更强；按相对变化排序，乙更强。哪一种与目标功能更相关取决于测量尺度、基线表达和生物机制，不能只凭分数大小跨基因比较。

背景单倍型影响变异评分。把一个变异放在参考基因组上计算，得到的是该参考背景下的模型变化；真实动物可能同时携带其他附近变异，使组合效应不同。对常见独立变异，参考背景评分可能是实用近似；对复合杂合、结构变异或强局部互作，可能需要相位与个体序列。模型能够接受替代序列并不自动解决相位不确定性。

插入、缺失和结构变异还会改变坐标与上下文。删除一段序列后，同一输出位置可能不再对应相同生物区域；倒位改变方向，重复改变拷贝数，长变异可能超出输入窗口。评分流程必须定义如何对齐参考与替代结果，哪些变异类型在训练和验证范围内。只把长变异截断成可输入长度，可能改变问题本身。

模型分数的校准应使用目标物种中的实测功能或可靠变异集合。可以检查方向、效应大小、区分能力和分层表现，但每种指标回答不同问题。区分有作用与无作用的能力高，不代表效应量准确；方向预测好，也不代表能区分大效应与小效应。将分数用于功能先验时，可以只要求它改善相对优先级，而不必假装具有生产性状单位。

评估负例也需要谨慎。未被发现有关联的变异可能只是功效不足，并不是真正无效；常见良性集合与罕见候选集合在频率、距离和测量机会方面可能不同。若这些差异本身容易被模型识别，分类性能会夸大实际机制能力。使用匹配负例、实验验证集和明确抽样范围有助于解释。

最终进入育种模型时，序列分数可以作为注释改变先验、构造核或筛选实验候选。每种用途都需要保留原始分数含义和不确定性。不能把“预测分子影响大”直接等同于“应优先选择”或“必须淘汰”；作用方向、多效性、频率和综合目标仍需由数量遗传与生物证据共同决定。

33.9 AlphaGenome 与 AlphaGenome Atlas 的证据位置

Avsec 等（2026）的 AlphaGenome 将约一百万碱基上下文与多类分子输出结合，涵盖表达、剪接和染色质等任务，训练资料来自人和小鼠。它说明长上下文与较高分辨率可以在统一序列模型中结合，并为调控变异提出可检验预测。其分子基准结果不应转换成牛、羊或猪的育种值准确度，也不应把多种输出都理解为同一分辨率和同一质量。

2026 年 9 月公布的 AlphaGenome Atlas 把大量人类单核苷酸变异的预测预先计算，并提供综合变异影响评分及相关解释。Cheng 等（2026）的相关稿件在本书资料截止日仍为预印本，应与已同行评议的 AlphaGenome 原论文区分。Atlas 覆盖约九十亿种人类单碱基替代的计算预测；“覆盖”指模型已计算，不表示每种变异均已实验验证，更不表示已经建立家畜应用证据。

这两项进展适合放在“序列到分子功能”的证据层。对于育种，一条更完整链条是：序列变化影响特定组织和阶段的分子过程，分子过程在环境与发育背景下影响性状，性状中的可传递部分形成育种值，多个育种值再按目

标权重组成 H 。模型加强了链条中的某些环节，却没有替研究者完成所有连接。

基础模型输出多种分子轨迹，为解释一个变异的可能作用提供了丰富线索。例如同一变异可能同时改变局部开放性和剪接，但这些输出之间并不独立，不能把多个变化简单当作多份完全独立证据。模型共享表示也可能共享误差。后续实验应优先区分竞争机制，而不是只挑最符合故事的一条输出。

预计算资源降低了大规模使用的门槛，也增加了误用的可能。数十亿分数容易让人误以为不确定性已经被穷尽，实际上每个分数仍继承模型训练范围、标签噪声和评分规则的限制。资料库的广度解决了计算可获得性问题，不能替代目标群体中的校准。越容易批量使用，越需要明确过滤、版本和证据边界。

例 33.8 分子评分如何作为可调先验。假设一个家畜研究把经本物种初步验证的序列分数分为高、低两组，并分别设标记先验方差 0.08 与 0.02。某位点粗略效应估计 0.4、标准误 0.2，高先验组的后验均值为

$$0.08/(0.08 + 0.04) \times 0.4 \approx 0.2667$$

低先验组的后验均值为

$$0.02/(0.02 + 0.04) \times 0.4 \approx 0.1333$$

分数在这里改变收缩程度，并没有直接赋予效应方向或经济价值。权重仍应在训练资料内学习和验证。

实际转化可以采用分阶段策略。先在目标物种已知功能变异上检查评分是否有意义，再用独立分子资料评价组织和效应方向，之后进入基因组预测比较，最后才考虑生产部署。若第一阶段表现不佳，应检查组装、同源映射和任务不匹配，而不是直接扩大样本寻找偶然相关。

对学术写作而言，近期模型最值得借鉴的是问题分解与评价设计，而不是只复制性能标题。应清楚区分原论文的实测基准、作者的潜在应用设想和本书提出的育种应用推论。任何从人类分子研究延伸到家畜的讨论，都应标为需要验证的迁移路径，避免跨越证据层级。

33.10 跨物种迁移需要哪些一致性

跨物种迁移首先要求序列与坐标一致。参考组装版本、染色体命名、链方向和变异表示错误，都可能使模型评分针对错误序列。同源基因名称相同也不保证调控区域一一对应；插入、缺失、重复和物种特有序列会使简单坐标转换失效。应保留映射质量和无法对应区域，而不是强行给所有位点一个来源分数。

第二层是一致的生物任务。某模型在人类血液细胞中的表达预测，不一定适合反刍动物瘤胃上皮或家禽胚胎组织。即使细胞类型大体相似，发育阶段、激素状态和营养条件仍可能不同。选择最接近的任务输出可以作为起点，但需要本物种测量检验。模型输出能被读取，不代表其生物含义已经迁移。

第三层是统计校准。分数与实测功能之间的关系可能在物种间改变，既可能整体尺度偏移，也可能仅某些变异类型有效。可以先冻结模型，使用目标物种资料拟合简单校准层，再比较微调是否带来额外收益。若目标样本很少，复杂微调容易过拟合，简单外部评分或传统注释可能更稳健。

例 33.9 分数方向正确仍需尺度校准。某外部模型对四个家畜变异给出分数 (1,2,3,4)，实测功能变化为 (0.2,0.4,0.6,0.8)。相关为 1，但需要乘 0.2 才能进入实测功能单位。若另一组织中变化为 (0.2,0.4,0.1,-0.1)，则单一尺度校准也无法解决任务不一致。相关与校准应在适当组织和变异范围内分别检查。

跨物种保守性提供合理先验，但不能成为无条件保证。保守编码区域可能更容易迁移某些功能，物种特有调控和重复区域则更难；然而特定育种性状恰好可能依赖后者。若只在最保守、最容易预测区域验证，就不能代表全基因组表现。评价集合应覆盖实际应用中的主要变异类型和频率范围。

还需要考虑训练资料可能包含目标物种序列，但没有目标物种功能标签的情形。这与完全未见物种不同，也与具有大量目标物种实验标签不同。报告应说明预训练、监督训练和下游微调分别使用了什么资料。模糊地称为跨物种预测，会掩盖不同信息条件。

在家畜中，品种内与品种间迁移也应分开。一个模型在某物种参考基因

组上有效，仍可能对地方品种特有单倍型或结构变异失准。泛基因组资源可以改善输入表示，但功能标签覆盖不足仍是另一问题。第 30 章的变异可靠性与本章的模型迁移是相互补充的环节，不能互相替代。

最稳健的结论应精确到任务：“在某物种、某组织、某类变异和某种划分中，外部表示提供了多少增量”。这样的限定不是削弱研究，而是使下一步可以明确扩大范围。泛泛宣称模型理解所有生命或直接适用于所有育种体系，反而无法指导可靠实验。

33.11 混合模型与深度模型的联合使用

一种实用策略是保留线性基因组部分，再用非线性模型补充未被表达的关系： $y = X\beta + u + f_{\theta}(x) + e$ 。这里 u 可具有 $G\sigma_u^2$ 协方差， f_{θ} 学习其他模式。但两部分可能竞争解释同一信号，参数分解未必唯一。联合正则化、适当约束或预先定义不同输入可以帮助稳定，仍需通过外部增量判断价值。

另一种策略是网络先从图像、序列或组学中生成低维表示，再把表示用于多性状或多核混合模型。它有利于将复杂测量与亲缘结构连接，但表示学习是否使用目标表型决定验证方式。若表示来自完全外部预训练，可在下游固定；若利用当前性状训练，则必须限制在训练边界内。不能把经过全数据监督学习的嵌入当作无泄漏的“原始特征”。

两阶段残差学习尤其容易出现误解。先在训练集拟合基线，再用剩余误差训练网络，可能帮助网络关注增量；但若基线已过度拟合某些训练动物，训练残差结构与新动物不同。对堆叠或残差学习，可以采用交叉拟合生成训练内部的留出预测，再训练第二阶段。这个要求针对相关学习流程，不意味着所有联合混合模型都必须分拆计算。

例 33.10 训练残差过小为何误导第二阶段。假设一个灵活基线在训练动物上几乎完全拟合，训练残差接近零，但对新动物的误差标准差为 2。若第二阶段只看到近零残差，它会学到几乎没有可改进空间；若使用训练内部留出预测，残差更接近部署时误差，才有机会学习稳定补充信号。交叉拟合的目的不是制造更大误差，而是使第二阶段所见信息条件与实际应用一致。

联合模型还需要明确输出目标。若非线性部分包含个体显性或环境相关信息，总预测可以改善表型，但其全部数值未必属于育种值。可以通过模型结构限制、遗传分解或后代验证评价可传递部分。将联合输出统一命名为基因组育种值之前，应说明这种命名的依据。

基线质量必须公平。一个弱基线可能因错误固定效应、遗漏近交或不合理方差参数而表现差，新网络则间接补上这些缺陷。改进仍可能有用，但不能全部归因于深度表示。应先建立符合数量遗传常规的稳健基线，再比较新增部分。对生产评定，最有价值的创新可能是更好的数据处理，而不一定是更大的模型。

模型组合的计算也应考虑更新频率。基因组评定可能每周或每月更新，网络预训练则可能耗时很长。可以冻结外部表示并定期重估小型遗传层，但需要监测表示是否随新群体失准；也可以较低频率更新网络，保持版本间校准。一个可维护方案应说明哪些部分何时更新，以及如何追踪预测变化。

联合使用最合理的判断标准是互补性。新增部分是否在独立资料中降低误差、改善校准或帮助特定信息不足群体？若只改变内部方差分配而不改善这些结果，复杂性价值有限。模型间没有必要建立身份对立，真正需要比较的是相同任务与资源下的信息利用能力。

33.12 公平验证：把完整学习流程放进边界

一个公平比较至少需要相同预测目标、相同可用信息和合理调参机会。若深度模型使用额外组学或全数据关联筛选，而基线只用芯片，差异属于数据与方法共同变化；若基线未经调优而新模型尝试上百组合，比较也不对称。应明确每种方法的输入、预处理、搜索范围和计算预算。

训练、内部验证和最终测试承担不同功能。训练用于估计参数，内部验证用于选择结构、惩罚、提前停止和组合权重，最终测试用于评价完整流程。只要最终测试结果被反复用于修改模型，它就逐渐变成内部验证集。需要新的独立资料或外层验证，才能恢复对最终泛化性能的可信评价。

例 33.11 相关个体的随机划分回答什么问题。假设一千头动物来自五

十个父系家系，每家二十头。随机划分后，每个测试动物很可能有同父半同胞在训练中，评价的是有近亲连接的任务。若把十个完整家系留出，任务变为对新家系的推广。两种划分都可以合理，但不能用第一种结果支持第二种主张。是否需要家系隔离，应由实际部署决定。

序列到功能任务的独立单位也不同。相邻窗口可能重叠，重复序列和同源基因可能跨染色体存在，随机切片会使近乎相同内容出现在训练与测试。按染色体或区域划分可以减少部分泄漏，但不必然消除同源重叠。更严格的任务需要按序列相似性和生物对象设计隔离，并清楚说明剩余信息共享。

模拟比较可以控制真实遗传结构，帮助理解模型何时优势，但结论只适用于设定范围。Yang J 等 (2026) 的研究比较 QTL 数量、遗传率和参考群体规模变化下的机器学习与 GBLUP，显示某些方法的优势依赖较少 QTL 和足够样本等情景，GBLUP 在校准方面保持竞争力。它支持条件化比较，而不是证明任何模型永远最好。

对模拟资料，必须报告数据生成过程与拟合模型之间的关系。如果真实表型由与某网络完全相同的结构生成，该网络的优势可能部分来自结构匹配；如果所有效应均独立加性正态，线性收缩方法具有相应优势。多种合理生成情景可以扩大解释范围，但不能把有限情景当作全部现实。真实资料与模拟应互相补充。

评价不应只列平均相关。需要报告重复运行、配对误差差异、校准、分组表现和计算成本。测试动物有亲缘时，区间应考虑依赖结构；数据集很少时，跨数据集平均也具有不确定性。某方法在多数任务略好但个别任务明显失准，与始终接近基线的方法具有不同风险，应让使用者看到这种分布。

完整流程还包括缺失处理、标准化、特征筛选和标签生成。每一步只要使用目标信息，都必须处在相应训练边界内。模型代码正确并不足以保证评价正确，流程中的信息路径同样重要。最好的验证设计，是读者能够清楚追踪每条测试信息在预测之前是否已被允许使用。

33.13 相关、误差与校准分别说明什么

相关系数描述两个变量线性变化的一致程度，对平移和正比例缩放不敏感。因此，一个模型可以具有很高相关，同时存在严重均值偏差或尺度错误。育种选择确实关注排序，但多性状指数、预期响应和风险判断还依赖单位与校准。评价应把这几种性质分开，而不是用一个相关代表全部质量。

例 33.12 相关为一仍然不是完美预测。四个教学个体真实育种值为 $(-2, -1, 1, 2)$ ，预测为 $(-4, -2, 2, 4)$ 。相关为 1，真实值对预测值的回归斜率为 0.5，平均平方误差为 $(4 + 1 + 1 + 4)/4 = 2.5$ 。预测差异被放大一倍，属于过度离散。若再给所有预测加 100，相关仍为 1，但平均偏差增加 100，误差会更大。

回归方向必须明确。真实值对预测值的回归斜率与预测值对真实值的回归斜率不是同一个指标，也不总互为倒数，因为两者都可能含噪声。真实育种值在实证资料中不可直接观察，使用后代均值、去回归证明或其他代理时，还需考虑其精度与依赖。不能把原始表型对预测值的任何斜率都直接解释为育种值校准。

均方误差可以分解为偏差与离散部分，但不同任务的可达到误差下限不同。若测试目标是含环境噪声的表型，即使真实育种值已知，仍有不可预测环境误差。若目标是模拟真实育种值，则没有同样的标签噪声。跨论文比较误差或相关之前，必须核对目标、单位和校正方式。

例 33.13 表型相关受遗传率限制。在简化模型 $y = u + e$ 中， u 与 e 独立，遗传率为 0.25。即使预测等于真实 u ，它与表型 y 的相关也只有 $\sqrt{0.25} = 0.5$ 。若一个模型还利用当时环境信息，它与表型的相关可能超过 0.5，但这不表示育种值准确度超过 1，而是预测目标与信息来源不同。这个例子说明表型预测与育种值预测不能混用术语。

校准也可能随群体变化。一个模型总体均值正确，但对某品种偏高、另一品种偏低；总体斜率接近一，却在高风险尾部过度自信。应在样本允许范围内检查群体和环境分层，同时报告小样本区间。过细分组可能产生噪声，因此分组应有实际意义，不能事后挑选最好或最差小组制造结论。

排名指标可以补充应用解释,例如选留前百分之十的重合度、换入动物的平均真实优势或选择后悔值。但这些指标受选择比例和目标噪声影响,不应只报告最有利阈值。若真实育种值未知,名单差异本身不能证明新模型更好,需要后续记录或合理代理验证。

模型校准可在独立训练内部资料上进行,例如修正均值和尺度,但不能用最终测试真值重新拟合后再报告同一测试性能。校准层也是模型的一部分,应在最终测试前冻结。生产中定期校准则需要明确更新时间、基准和新数据范围,保证跨批次预测可比较。

33.14 模型组合的收益来自误差互补

组合多个模型可以减少误差,但关键是错误是否互补,而不是名称是否不同。两个模型若利用同一信息并犯同样错误,平均不会产生多少增益;一个单独较弱模型若提供独立信息,也可能有价值。组合应针对同一目标和单位,并先处理系统偏差,再讨论误差方差。

设两个无偏预测误差方差为 v_1, v_2 , 协方差为 c , 组合为 $\hat{u} = w\hat{u}_1 + (1 - w)\hat{u}_2$, 则

$$V(w) = w^2v_1 + (1 - w)^2v_2 + 2w(1 - w)c.$$

当 $v_1 + v_2 - 2c > 0$ 时, 无约束最优权重为 $(v_2 - c) / (v_1 + v_2 - 2c)$ 。若要求非负且和为一, 需要把超出区间的解限制在边界。

例 33.14 互补模型能够超过单个模型。 设 $v_1 = 4, v_2 = 9, c = 1$, 最优权重为 $8/11 \approx 0.7273$, 组合误差方差为 $35/11 \approx 3.1818$, 低于 4 与 9。若协方差改为 5, 无约束权重为 $4/3$; 在凸组合约束下最优为 $w = 1$, 组合不再优于第一个模型。两种情形的协方差矩阵都合法, 差别来自误差相关, 而不是模型标签。

若误差存在偏差, 均方误差还包含组合偏差平方。一个方差较小但系统偏移的模型可能需要校准后才能组合; 不同群体的偏差又可能不同。简单等权平均有时稳健, 但不能保证消除偏差。应在训练内部估计组合规则, 并在独立资料中检验, 而不是针对最终测试集手工挑权重。




图 33.1 模型组合的价值取决于误差互补。两模型误差方差固定为 4 和 9，权重限制在零至一。左图可由组合降低误差；右图的最优凸组合退化为只使用模型 1

多个模型时，可以使用误差协方差矩阵决定线性权重，但矩阵估计本身可能不稳定。模型数量接近验证样本有效数量时，权重容易极端；高度相关模型使矩阵接近奇异。非负约束、收缩协方差或限制模型数量可以提高稳健性。理论最优权重在真实误差矩已知时成立，实际估计误差可能抵消收益。

组合还应考虑成本。一个模型贡献极小增量，却需要昂贵组学或大量推理资源，未必值得保留。可以计算移除某模型后性能与成本变化，识别真正有价值的互补来源。若多个网络只是不同随机种子，集成可能降低训练不稳定性；若模型使用不同信息，则可能增加实质信息，二者应区分。

例 33.15 独立与完全相关误差的极端。两个模型误差方差均为 4，若协方差为 0，等权平均误差方差为 2；若协方差为 4，平均后仍为 4。若有十个完全相同错误的模型，数量增加也不能降低误差。模型多样性应通过实际错误结构衡量，不能通过架构名称数量代替。

对育种部署，组合模型还要保持版本同步。某个组成模型更新后，原组合权重可能不再合适，因为误差方差与协方差变化。应重新校准并验证组合，而不是只替换一个模型文件。记录每个组成版本、权重来源和适用群体，才能解释后续预测变化。

33.15 预测不确定性与分布外输入

一个点预测不能表达模型知道多少。预测不确定性至少包括目标本身的随机变异、有限训练资料导致的参数不确定性，以及输入质量和分布变化带来的不确定性。深度模型常能给出分数，却不一定给出可靠区间；即使输出方差，也需要检查其覆盖是否与实际误差一致。

模型内不确定性与模型外偏差不同。多个随机初始化网络预测接近，可能说明优化稳定，也可能因为它们共享相同错误假设。集成分歧小不能证明输入处于训练范围，更不能排除共同偏差。对新物种、新品种或新环境，应直接检查输入分布和外部性能，而不是只依赖模型自己报告的信心。

例 33.16 均值区间与个体预测区间。假设某动物目标均值估计为 10，均值估计标准误为 1，未来个体额外随机标准差为 3，且两来源独立、近似正态。均值的近似 95% 区间为 10 ± 1.96 ，即 8.04 至 23.96；个体预测区间使用标准差 $\sqrt{1^2 + 3^2} = \sqrt{10}$ ，约为 3.80 至 29.20。两种区间回答不同问题，不能把较窄均值区间当作每头后代的表现范围。

分布外输入可能来自等位基因频率变化、缺失模式改变、测序平台更新或新的环境组合。一个简单诊断是比较输入特征与训练分布的距离，但高维距离本身也可能难以解释。更有用的是结合遗传关系、祖源、质量指标和关键环境范围，识别模型缺少代表性的区域，并在这些区域安排验证。

共形预测等方法可以在明确交换性条件下提供覆盖保证，但家系依赖、时间漂移和群体分布变化可能破坏这些条件。若使用分组或加权扩展，也应说明其假设和校准资料。不能把某种区间方法的理论保证直接移植到任意育种部署。覆盖应在目标场景中实证检查，特别关注高选择强度下的尾部候选。

个体育种值可靠性还需要与遗传模型一致。混合模型的预测误差方差具有明确条件结构，深度预测的误差估计则可能来自重抽样、集成或校准模型，两者不一定具有相同解释。若统一发布为可靠性 r^2 ，应说明如何估计、是否校准以及是否包含模型选择不确定性。相同数字不能掩盖不同定义。

不确定性可以指导数据收集。对重要但精度低的候选家系增加目标表型、对关键稀有位点直接分型、对新环境增加连接记录，可能比继续扩大同

质训练集更有效。主动学习策略也需要防止只采集模型最不确定但与育种目标无关的样本，应把信息价值与决策价值结合。

在实际输出中，可以同时提供预测、适用范围与质量标记。对于明显超出训练范围的输入，系统应允许暂缓强结论或回退到更稳健基线，而不是强行返回一个看似精确的分数。这样做不是否定模型，而是把其能力边界转化为可管理的流程。

33.16 可解释性：归因不是因果

特征归因描述某个模型在某个输入背景下如何使用变量。梯度表示局部微小变化的敏感性，遮盖或替换表示较大输入扰动的结果，Shapley 类方法尝试分配预测贡献。它们各有定义和计算假设，不能互相替代，更不能直接等同于自然群体中的因果效应。

连锁不平衡使归因尤其不唯一。两个高度相关标记可以互相替代，模型可能把权重集中到其中一个，另一种训练则分配给另一个，而预测几乎相同。此时单标记归因不稳定并不一定表示模型预测不可靠，但说明数据不足以精确定位作用位点。区域或集合层面的解释可能更稳健。

例 33.17 相同预测可以有不同归因。若所有观察中 $x_1 = x_2$ ，模型 $f_1 = x_1$ 与 $f_2 = 0.5x_1 + 0.5x_2$ 给出完全相同预测。前者把全部贡献归于 x_1 ，后者平分。仅凭这些观察无法判定哪个变量具有因果作用。增加能够区分两个变量的背景或独立实验，才可能提高机制分辨率。

输入扰动还必须保持生物合理性。把一个 SNP 独立改变而不考虑附近单倍型，可能构造在真实群体中极少出现的组合；随机打乱序列可能同时破坏许多背景结构。模型在这些输入上的变化有助于分析函数，但不一定对应可实现的生物干预。解释应说明扰动方式和参考背景。

注意力权重更不能直接当作调控网络。一个位置获得高权重，可能因为它提供了品种识别、序列重复或其他统计线索；权重还受到归一化和多头组合影响。若要支持某个增强子—基因关系，应结合独立实验、距离与组织证据，而不是只展示注意力热图。视觉上清晰的图并不自动具有因果含义。

解释的稳定性可以通过重复训练、替代模型和背景样本检查。如果一个候选区域在多种合理设置下都重要，证据更有累积价值；若排名随随机种子大幅改变，应报告不确定性。稳定也不是因果证明，因为共同混杂可以稳定存在，但不稳定通常提醒我们不要作过强机制主张。

可解释性还包括错误解释。研究者应分析模型在哪些动物、变异类型或环境中失败，以及失败是否对应缺失数据、低频等位基因或训练覆盖不足。只解释成功案例容易形成选择性故事。失败案例能帮助改进数据设计，并揭示模型是否依赖不可迁移捷径。

对育种使用者，最有价值的解释往往不是数千个归因值，而是预测主要由哪些已知信息支撑、在哪些条件下可靠、以及哪些新增测量会改变决策。机制研究需要精细归因，生产决策需要清楚证据与不确定性。根据用途选择解释形式，比追求一个适用于所有人的“可解释模型”更实际。

33.17 从研究模型到常规评定

部署首先需要一个清楚的数据契约：输入参考组装、位点顺序、等位基因方向、缺失编码、标准化参数和允许群体范围。一个等位基因翻转就可能改变标记效应方向，位点顺序错位则可能破坏整个网络输入。数据契约应可自动检查，并记录异常处理；不能只保存模型权重而忽略生成输入的流程。

模型版本应同时包含训练数据范围、预处理、超参数和输出定义。更新后需要比较旧与新预测，检查均值、尺度、关键家系排序和异常个体。变化可能来自新表型、模型结构或输入资源更新，应该能够追踪原因。对生产体系，稳定可解释的更新过程通常与少量准确度增益同样重要。

计算成本应分为预训练、调参、更新和推理。一次性大型预训练可能由公共资源承担，但下游每次更新仍需时间与设备；一个较小模型也可能因为反复搜索而耗费大量计算。比较应报告完整研究和部署成本，而不是只报告一次最终推理速度。相同预算下能够运行多少独立验证，也是方法可信度的一部分。

例 33.18 小幅增益需要放回资源约束。假设方法甲每月更新需 2 小时，

方法乙需 40 小时，准确度分别为 0.650 与 0.655。如果乙的增益在独立时间验证中稳定，且不会延迟选种，它可能值得使用；若额外计算导致错过决策窗口或减少必要质量检查，净价值可能下降。这个例子不规定某个统一接受阈值，而是要求把统计增益与实际流程联系。

模型监测应包括输入漂移和结果漂移。输入方面关注品种组成、缺失率、平台和环境范围；结果方面关注预测均值、方差、后续误差与校准。仅监测平均分数可能漏掉某个小群体失准，完全依赖分布距离又可能对无害变化过度反应。应结合实际后续记录与预设触发条件决定何时重新训练或调整范围。

一个有用的研究路线是逐层证明增量：先展示新表示在相关分子或表型任务上有效，再证明它在严格训练边界内改善遗传预测，随后评价成本、校准和跨世代稳定性，最后观察实际选择响应。并非每篇研究都能完成全部层次，但应准确说明已完成哪一步，并为下一步提供可复现接口。

截至本书资料截止日，深度学习与基础模型已经显著扩展可处理的数据形式和分子预测范围，但不存在对所有畜种、性状和资料规模都通用的优胜架构。持续进展更可能来自模型、数据和设计的共同改进：更可靠的表型、更具代表性的群体、更明确的功能任务以及更公平的验证。把这些要素连接起来，才可能将表示能力转化为长期遗传改良。

学术质量也体现在结论的精度。应把模型实测表现、合理推论和未来设想分别写清，尤其对于最新预印本与跨物种应用。承认边界并不会降低研究价值，反而让读者知道何处已经可靠、何处最值得进一步投入。复杂模型应接受与经典方法同样严格的证据要求，并在能够增加真实信息的地方发挥作用。

生产部署还会反过来改变数据。模型决定哪些动物被选留、哪些进入测定站，后续可观察表型因此受到旧模型选择的影响。如果只用被选动物更新，新模型看到的范围逐渐收窄，对未被选择类型的误差难以评估。应保留适当的代表性测定或探索性样本，并在模型中考虑选择过程。预测系统不是面对永远固定的数据分布，它参与塑造下一轮数据。

选择阈值附近的误差尤其重要。总体均方误差下降，可能主要发生在大

量中间动物，而对最终选留前少数个体没有帮助；也可能因为更准确识别极端候选而产生显著经济价值。可以在预先规定选择比例下计算预期选择响应或后悔值，同时保持总体指标，避免仅选择有利阈值。若实际选留还受亲缘和配种约束，评价应尽可能模拟完整决策，而不只比较单头排名。

例如，假设两个方案都从十头候选中选两头，真实综合育种值最高的两头为 10 和 9，最优平均为 9.5。方法甲选到 10 和 8，平均 9，后悔值 0.5；方法乙选到 9 和 7，平均 8，后悔值 1.5。这个指标直接描述该选择任务，但只有在真实值或可靠后续代理可得时才能估计。一次小样本名单比较噪声很大，应通过重复设计或较大后代资料获得不确定性。

模型压缩和蒸馏可以降低部署成本。一个较小模型学习较大模型的输出，可能保留大部分预测性能并加快推理；但它继承的首先是教师模型的函数，包括教师的偏差，而不是新增生物证据。压缩后应重新检查关键群体、稀有变异和尾部预测，不能只比较平均输出差异。某些总体很小的近似误差，仍可能改变选择阈值附近的决策。

可重复研究还需要保存随机种子之外的信息。数据版本、软件依赖、数值精度、硬件以及非确定性算子都可能影响训练。对于大型模型，完全逐位复现可能困难，但至少应能够重建主要分析并得到相近结论。发布训练配置、评价脚本和不涉及受限个体信息的汇总结果，有助于其他研究者区分真正方法增益与偶然实现差异。

在资源共享中，应明确模型和数据的使用范围。公开权重不必然意味着所有训练资料可公开，公开分数也不必然允许任意商业用途。研究者需要依据相应资源条款安排使用，并在学术报告中说明版本与来源。这里的重点是保证研究可追踪和可维护，而不是把软件可下载误当作数据、证据和应用条件都已经解决。

对下一代研究，最有价值的基准应包含多个现实难度层次：近亲连接充分的常规评定、新家系推广、新环境和跨品种迁移，以及稀有变异或低质量输入。每个层次都应规定允许的信息与主要指标。一个模型可能在其中某些层次有明确优势，这已经具有学术与应用价值，无须把结论扩大为所有任务通胜。

消融比较应尽量只改变一个关键因素。例如检验长上下文价值时，若同时增加参数量、训练时间和标签数量，性能变化无法唯一归因于上下文。可以设计参数与计算预算尽量匹配的比较，并报告无法完全匹配的部分。消融的目的在于解释贡献，而不是为完整模型寻找更多胜利记录。

模型研究还应允许诚实的停止决定。当新增结构在独立任务中没有稳定增量，而数据质量仍有明确缺口时，把资源转向表型、连接群体或实验验证，可能比继续增加网络复杂度更有效。这种判断同样属于方法学进展，因为它明确了当前问题真正的信息瓶颈。

33.18 从基础模型分数到可校准的分子效应

基础模型对序列给出的数值，首先属于它训练时定义的输出空间。某个分数可能是表达变化、剪接轨迹差异、染色质信号变化，或由多个输出组合而成的排序量。Avsec 等（2026）的 AlphaGenome 研究在人和小鼠分子资料上发展了长序列到多模态功能预测；Cheng 等的 AlphaGenome Atlas 则在二〇二六年九月二十日发布的第一版预印本中提供人类全基因组变异的预计算解释资源。截至本书资料截止日，后者仍应按预印本引用。这些进展支持分子任务中的方法与资源讨论，不能直接提供牛、羊、猪生产性状的育种值单位或准确度。

设某一固定版本、固定组织输出的变异分数为 s_j ，目标物种独立实验测得的分子效应为 d_j 。最简单的校准层为

$$d_j = \alpha + \beta s_j + \varepsilon_j, \quad \text{Var}(\varepsilon_j) = v_j + \tau^2.$$

v_j 是实验效应估计的已知或另行估计的测量方差， τ^2 表示不能由当前分数线性解释的真实效应差异。二者不是同一来源：增加实验重复主要降低 v_j ，改变输出或校准函数才可能降低 τ^2 。若忽略实验精度差异，少数噪声很大的测定结果可能不成比例地影响斜率。

令设计矩阵第 j 行为 $(1, s_j)$ ，记为 X_s ，权重矩阵为

$$W = \text{diag}\{(v_j + \tau^2)^{-1}\}.$$

在误差独立且权重视为已知时, 广义最小二乘解及协方差为

$$\hat{b} = (X_s^T W X_s)^{-1} X_s^T W d, \quad b = (\alpha, \beta)^T, \\ \text{Var}(\hat{b}) = (X_s^T W X_s)^{-1}.$$

若实验误差在同一基因、同一批次或同一细胞系中相关, 应使用完整误差协方差的逆, 不能继续把各行当作独立标签。数千个变异来自少数实验批次时, 行数远大于独立校准信息; 特别是同一基因附近的高度相似编辑, 可能主要重复一种局部效应尺度。

推导例: 加权校准与外推精度。三个分数为 (0, 1, 2), 实验效应为 (0.2, 0.5, 1.4), 测量方差为 (0.1, 0.025, 0.1), 并令 $\tau^2 = 0$ 。加权计算给出截距 0、斜率 0.6; 等权计算的斜率也是 0.6, 截距却为 0.1。较精确的中间标签使整体位置发生变化。对新分数 $s_* = 3$, 加权预测为 1.8, 仅由校准参数估计产生的方差约为 0.2167; 在 $s_* = 1$ 处这一方差只有 0.01667。相同的模型相关程度并不意味着各个分数区域具有同样精度。

新分数处的平均分子效应预测方差为

$$V_{mean}(s_*) = (1, s_*) \text{Var}(\hat{b}) (1, s_*)^T.$$

若预测一个新的真实分子效应, 还应增加 τ^2 ; 若预测一次新的实验读数, 还应再增加相应 v_* 。三个区间的对象不同。把高精度均值校准区间误作为单变异功能区间, 会低估位点之间未解释的差异。校准层本身若需要选择变换、阈值或组织输出, 这些选择也应在独立验证边界内完成。

方向编码同样属于校准条件。令 $s(A \rightarrow B)$ 表示同一背景下由等位基因 A 改为 B 的差值; 若评分来自同一标量函数的差, 它应满足

$$s(A \rightarrow B) = -s(B \rightarrow A).$$

然而绝对值、最大变化和复杂分类评分未必满足这个反对称性。对没有方向含义的分数拟合带符号遗传效应先验, 需要额外证据; 不能因为分数较高就指定增加产量或减少疾病。坐标、背景单倍型、组织与汇总规则应与校准样本一致, 否则统计上估得精确的斜率也可能描述错误的生物问题。

33.19 类别概率的先验变化与绝对风险校准

另一类模型给出某变异属于“有功能影响”类别的概率。类别定义必须明确：特定实验中的显著变化、临床致病标签和家畜生产性状的大效应，不是可互换标签。即使评分能够稳定区分两类，目标群体中类别比例改变时，输出概率仍可能失准。下面只研究类别先验改变而类内分数分布保持不变的情形，称为标签比例变化；这比一般跨物种迁移是强得多的假设。

设来源资料的阳性比例为 π_S ，目标资料为 π_T ，模型在来源中已校准，输出 $p_S(s)$ 。由贝叶斯赔率公式，

$$\frac{p_S(s)}{1 - p_S(s)} = \frac{f(s | Y = 1)}{f(s | Y = 0)} \frac{\pi_S}{1 - \pi_S}.$$

若两个类内密度在目标中保持不变，就可以消去同一个似然比，得到

$$\frac{p_T(s)}{1 - p_T(s)} = \frac{p_S(s)}{1 - p_S(s)} \frac{\pi_T / (1 - \pi_T)}{\pi_S / (1 - \pi_S)}.$$

相应的对数几率校正为

$$\text{logit} p_T = \text{logit} p_S + \text{logit} \pi_T - \text{logit} \pi_S.$$

这个校正只改变截距，因此可以保留排序，却显著改变绝对概率。来源研究若人为富集已知功能变异，使两类各占一半，训练输出便不能未经处理就作为全基因组自然变异的发生概率。标签来源是如何被抽样进入资料的，与模型架构同样重要。

推导例：良好排序不等于高阳性预测值。来源阳性比例为 0.5，某变异来源概率为 0.8，其来源后验赔率为 4。若目标阳性比例只有 0.01，目标赔率为 4/99，目标概率约为 0.03883。这并非评分突然失去区分能力，而是同样的似然比作用于不同先验。若目标比例为 0.05，则概率约为 0.1739。以来源概率 0.8 直接声称目标中有八成可能发生某种功能后果，会混淆训练抽样和目标发生率。

校准与区分可通过平方概率损失分别理解。设目标中给定分数后的真实概率为 $q(s)$ ，报告概率为 $p(s)$ ，则

$$E\{(Y - p)^2 | s\} = q(s)\{1 - q(s)\} + \{p(s) - q(s)\}^2.$$

第一项是即使知道真实概率仍存在的伯努利波动，第二项才是校准错误。一个分数可以具有良好排序但第二项很大，也可以通过只报告全群平均比例获得整体校准，却几乎没有个体区分能力。因此应联合报告分层校准、排序与适合目标比例的精确率，不能只选择最漂亮的一个指标。

当研究标签有误分类时，输出还可能只校准到观测标签。若观测标签的灵敏度为 Se 、特异度为 Sp ，并且误分类给定真实类别后不依赖分数，则

$$p_{obs}(s) = (1 - Sp) + (Se + Sp - 1)q(s).$$

在 $Se + Sp > 1$ 且参数已知时可以反解 $q(s)$ ，但估计误差会随分母变小而放大。实验中“未达到显著”并不一定等于没有功能作用，因为检测功效还随效应大小、测量深度和变异类型改变。把低功效阴性当作无误差真值，会让模型学习实验容易发现什么，而不是学习全部真实作用。

跨物种任务往往同时改变类内分布、标签定义和先验，因此不能仅用上式改一个截距就声称已经完成迁移。应先明确实验类别是否相同，再检验类内分数分布是否有支持；若条件不成立，就需要目标物种独立标签和更一般的校准模型。人类变异解释资源可以帮助提出候选排序，但其中的类别概率不能直接命名为畜种经济性状的不良后果概率。

33.20 统计可迁移性是分布条件而不是模型称号

一个模型能否迁移到新群体，取决于训练与目标分布的关系。令来源联合密度为 $p_S(x, y)$ ，目标密度为 $p_T(x, y)$ ，损失函数为 $\ell\{f(x), y\}$ 。如果只有输入分布变化，而条件结果分布保持一致，即

$$p_T(y | x) = p_S(y | x),$$

并且目标输入支持范围包含在来源支持范围中，则目标风险可改写为

$$R_T(f) = E_S [w(x)\ell\{f(x), y\}], \quad w(x) = \frac{p_T(x)}{p_S(x)}.$$

推导只需在目标风险积分中乘除 $p_S(x)$ 。这个看似简单的恒等式揭示两个边界：没有来源支持的目标区域无法靠有限权重补出；条件规律改变时，

输入加权也不能修复。一个人类序列模型进入反刍动物组织，既可能发生输入分布变化，也可能发生调控机制或测量任务变化，不能先验假定只有第一种。

在 n 个独立来源样本中，如果真实权重已知，可以用

$$\hat{R}_T = \frac{1}{n} \sum_{i=1}^n w_i \ell_i$$

估计目标风险。实践中常使用自归一化估计 $\sum_i w_i \ell_i / \sum_i w_i$ ，它可减小某些数值波动，但有限样本下一般不是严格无偏。若只报告一个加权准确度而不说明权重来源、极端程度和支持范围，就可能把少数样本的偶然结果当作整个目标群体表现。

权重集中度可由描述性的有效样本量指标观察：

$$n_{eff} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2}.$$

推导例：四条记录未必提供四条记录的信息。四个相对权重为 (1, 1, 1, 9)，则 $n_{eff} = 144/84 \approx 1.7143$ 。这不是一条适用于所有损失分布的精确方差公式，但清楚显示最后一条记录主导结果。若最后一条恰好来自难以测量的稀有变异，目标风险估计会极不稳定。截断权重可以减小方差，却会改变估计偏差；应报告截断规则和对应敏感性，而不能把稳定数字等同于无偏目标评价。

密度比可通过区分来源与目标的分类器估计。令 $D = 1$ 表示来自目标样本，合并抽样中目标比例为 ρ ，则

$$\frac{p_T(x)}{p_S(x)} = \frac{\Pr(D = 1 | x)}{\Pr(D = 0 | x)} \frac{1 - \rho}{\rho}.$$

这里的 ρ 是研究者构造合并样本时的比例，不一定等于任何自然群体比例。分类器应只使用允许的输入信息；若把目标结果标签或测试后才知道的变量用于估计权重，又会引入泄漏。高维序列中密度比估计本身可能很困难，降维表示需要保留与迁移误差相关的方向，不能仅选择最容易使两群“看起来接近”的表示。

无法完全验证条件不变时，可以把剩余差异显式写出。令来源和目标给定 x 后的条件损失之差为 $\delta_f(x)$ ，则

$$R_T(f) = E_S\{w(x)\ell_f\} + E_T\{\delta_f(x)\}.$$

第二项无法仅凭未标记目标序列识别。它可能来自组织差异、变异作用改变、测量尺度变化或选择过程不同。研究者可以提出有领域依据的敏感性范围，但不能因为一个网络表示使来源与目标分类困难，就宣称第二项为零。分布对齐是方法步骤，生物规律可迁移仍是需要验证的假设。

对于家畜，跨品种、跨场区和跨世代应分别构造验证任务。若新世代与训练群体仍共享大量近亲，随机留出可能主要评价插值；若目标是一个从未出现的品种，则需要更严格的支持检查。统一的基础模型名称不能把这些任务变成同一个统计问题。最有意义的报告，应说明实际希望迁移哪个条件关系，目标中哪些范围已有标签支持，哪些范围仍属外推。

研究案例：比较基因组结构怎样增加有效信息。 Ye 等于二〇二六年九月九日正式发表的 GPN-Star，将全基因组多序列比对和物种树纳入系统发育感知结构，并比较不同进化时间尺度。论文在人类编码与非编码变异解释、遗传力富集和稀有变异关联检验中提供评价，还分别为小鼠、鸡、果蝇、线虫和拟南芥训练模型（Ye 等，2026）。这些是论文实际覆盖的任务，不是家禽生产性状育种值的验证。本书据此作出的推论是：有效增益可以来自同源关系、进化距离与任务相符的数据组织，不能只按参数规模预测性能。用于畜种时，应检查目标区域的比对支持、谱系选择和突变背景，再以本物种功能标签校准。保守性所反映的自然选择约束，也不自动等于人工选择目标中的效应方向；从功能约束到经济性状的映射仍须独立建立。比较方法时，还应让传统保守性评分使用相同的比对资料，以区分新增数据与网络结构各自的贡献。

33.21 功能评分进入育种值时必须传播校准参数

从分子分数到加性育种值至少跨过两层映射：序列变化对分子输出的作用，以及分子变化对目标性状的统计作用。若缺少第二层，不能把功能分数

直接相加并命名为育种值。一个保守用途是让无方向的功能分数 s_j 调整效应先验方差, 例如

$$a_j | s_j \sim N(0, \tau_j^2), \quad \log \tau_j^2 = \gamma_0 + \gamma_1 s_j.$$

该模型允许分数较高位点具有更大效应幅度, 但不预先指定效应正负。若分数真实含方向且在目标性状中有独立校准证据, 才可考虑非零先验均值:

$$a_j | s_j, \kappa \sim N(\kappa s_j, \tau^2).$$

κ 将分数单位转换成目标性状每等位基因效应单位。它必须由与任务相符的资料估计, 而不是从模型输出名称猜测。若分数是绝对变化或综合异常程度, κs_j 通常缺乏有符号生物解释, 更适合方差或类别先验。

在单标记正态似然 $\tilde{a}_j | a_j \sim N(a_j, v_j)$ 下, 固定 κ 的后验均值为

$$E(a_j | \tilde{a}_j, s_j, \kappa) = \lambda_j \tilde{a}_j + (1 - \lambda_j) \kappa s_j, \quad \lambda_j = \frac{\tau^2}{\tau^2 + v_j}.$$

后验方差为

$$V_j = \frac{\tau^2 v_j}{\tau^2 + v_j}.$$

位点效应数据精确时, λ_j 接近一, 功能先验影响减小; 位点信息稀少时, 先验影响较大。后者既是功能资料可能有用的原因, 也是错误跨物种先验风险较大的原因。稀有位点没有足够本地数据纠正错误方向, 因此应格外检查先验依据和校准范围。

若 κ 本身有后验方差 v_κ , 且为了教学暂时把它与各位点似然误差独立处理, 令 $c_j = (1 - \lambda_j) s_j$, 则校准不确定性在不同位点间产生

$$\text{Cov}(a_j, a_k | \mathcal{D}) \supset c_j c_k v_\kappa.$$

对候选动物的中心化基因型 z_* , 这部分遗传预测方差为

$$V_{cal}(u_*) = v_\kappa \left(\sum_j z_{*j} c_j \right)^2.$$

共享一个校准参数造成的误差会一起移动，不能像独立位点噪声一样随标记数增加而平均消失。一个非常大的评分面板，仍可能受少量目标物种校准样本限制。

推导例：共同尺度误差不会被位点数抵消。设两个位点 $c_1 = c_2 = 1$ ，校准参数方差为 0.04。对 $z_* = (1, 1)$ ，校准方差为 0.16；若错当两位点独立，只会得到 0.08。对 $z_* = (1, -1)$ ，该共同尺度误差完全抵消，方差为零；独立误差近似却仍给出 0.08。因此，同样的单点标准误不能决定所有动物的综合不确定性，必须保留跨位点相关结构。这里的零只针对共同校准误差，不代表候选动物整体育种值无误差。

先验尺度还与基因型编码有关。若将原始计数 x_j 标准化为

$$z_j = (x_j - 2p_j) / \sqrt{2p_j(1 - p_j)}$$

两种系数满足

$$a_j^{std} = a_j^{count} \sqrt{2p_j(1 - p_j)}.$$

对标准化系数设置相同方差，等价于对每等位基因效应设置随频率改变的方差。功能富集与稀有度效应若都通过先验权重进入，应检查是否重复赋予稀有位点过大权重。模型定义中的频率来自哪个基群，也会影响跨品种解释。功能评分并不能消除数量遗传尺度的这些要求。

最后，分子模型的输出若含显性、背景依赖或细胞状态作用，线性每等位基因先验只是近似。用于后代加性遗传评定时，应与目标群体的等位基因频率、连锁和性状定义相容；用于特定编辑或配种风险时，则可能需要保留个体背景和非线性作用。两种用途可以共享评分资源，但不应共享未经检验的最终解释。

33.22 深度表示与混合模型的联合目标和公平比较

深度表示可以与亲缘协方差联合，而不必先把所有关系压成相互独立的样本。设序列或多模态输入为 S ，网络输出为 $f_\theta(S)$ ，模型为

$$y = Xb + f_\theta(S) + u + e, \quad u \sim N(0, \sigma_u^2 G), \quad e \sim N(0, R).$$

在网络参数固定时积分掉 u ，得到 $V = \sigma_u^2 G + R$ 。忽略与参数无关的常数，边缘负对数似然为

$$\mathcal{L} = \frac{1}{2} \log |V| + \frac{1}{2} r_\theta^\top V^{-1} r_\theta, \quad r_\theta = y - Xb - f_\theta(S).$$

这与把普通平方误差简单加上一个亲缘惩罚不同。 V^{-1} 改变各残差方向的权重， $\log |V|$ 则约束协方差规模。若网络和协方差参数共同估计，只降低残差平方而忽略行列式，会使方差模型失去正确的似然权衡。

当 V 暂时固定，网络雅可比矩阵为 $J_\theta = \partial f_\theta / \partial \theta^\top$ ，梯度为

$$\nabla_\theta \mathcal{L} = -J_\theta^\top V^{-1} r_\theta.$$

近亲共享方向上的残差因此不会被当作完全独立重复证据。另一方面，网络若也从基因型学习群体关系，它与随机效应可能竞争相同方向。联合拟合可以给出稳定总预测，却未必把两者的“贡献”唯一分开。比较时应关注目标预测、校准和新群体表现，而不要把网络解释的拟合份额直接叫作非加性遗传方差。

联合模型的条件随机效应预测为

$$\hat{u} = \sigma_u^2 G V^{-1} \{y - X\hat{b} - f_{\hat{\theta}}(S)\}.$$

这个条件表达式把网络参数视为已经给定；若网络由同一资料学习，完整预测不确定性还应包含其估计误差。直接套用固定网络时的混合模型误差方差，可能低估总体不确定性。是否需要交叉拟合取决于具体两阶段或堆叠流程；不能据此断言所有联合模型必须分拆拟合，也不能断言端到端训练天然免于验证泄漏。

推导例：比较单位改变结论精度。假设两个方法在每个独立家系上的平均损失差为 d_g ，共有 J 个家系，每个家系先按预定规则汇总动物损失。以家系为等权部署单位时，

$$\bar{d} = \frac{1}{J} \sum_g d_g, \quad \text{SE}(\bar{d}) = \frac{s_d}{\sqrt{J}}.$$

若四个家系差值为 $(0.1, 0.2, -0.1, 0)$ ，均值为 0.05，样本标准差约为 0.1291，标准误约为 0.06455。每个家系增加大量几乎重复的个体，不应把这个标准误机械除以新增个体数的平方根。若实际部署以随机动物为单位，家系权重又应反映动物份额，不能事后在等家系与等动物之间挑选有利结果。

公平比较还需保持输入和调参预算可审阅。若网络使用外部功能标签而基线没有，差异属于信息与方法共同变化；可以增加一个使用相同功能评分的线性或加权混合模型，判断非线性结构是否提供额外收益。若只比较最弱的基因组基线，会把错误固定效应、缺少环境校正或未调方差比例造成的损失误认为深度模型优势。

验证的分组还应符合预期外推层级。同一基因的近邻变异可能共享序列窗口，同一家系动物可能共享较长染色体片段，随机分行会同时泄漏分子背景和遗传背景。外部预训练是否包含目标物种序列、是否包含相同实验标签，也应分别说明；看到过无标签序列与看到过当前性状结果不是同一种信息条件。比较的目标是隔离真正新增的证据，而不是用一个“预训练”或“外部”名称替代数据来源说明。

33.23 共同偏差、预测区间与有条件的可信范围

多个网络给出相近结果，不足以说明其共同结果正确。令第 b 个模型的预测误差为 e_b ，具有相同偏差 μ_e 、方差 σ^2 ，两两误差相关为 ρ 。等权平均 B 个模型后，

$$E(\bar{e}) = \mu_e, \quad \text{Var}(\bar{e}) = \sigma^2 \left\{ \rho + \frac{1-\rho}{B} \right\}.$$

因此均方误差为

$$E(\bar{e}^2) = \mu_e^2 + \sigma^2 \left\{ \rho + \frac{1-\rho}{B} \right\}.$$

增加随机初始化可以降低不共享的波动，却不能消除共同偏差和共享误差。模型都用同一个错误组织输出、同一个偏差标签或同一个参考坐标时，彼此一致甚至可能是重复相同错误的表现。集合分歧是一个诊断信号，并非完整的不确定性定义。

推导例：很稳定的集合仍可能不准确。设 $B = 10$ 、 $\sigma^2 = 4$ 、 $\rho = 0.8$ 、共同偏差为 1.5。平均误差方差为 3.28，均误差为 5.53。若误当模型独立，会把方差算成 0.4。在交换对称假设下，单次任务中模型间样本方差的期望为 $\sigma^2(1 - \rho) = 0.8$ ；它既不包含共同偏差，也不等于平均预测误差方差。因而不能把十个网络的标准差直接解释为真实育种值预测误差标准差。

独立校准数据可以帮助构造覆盖率有明确条件的区间。以分割共形预测的简单绝对残差形式为例 (Lei 等, 2018)，先在训练资料中固定点预测 f ，再在 n 个独立校准样本上计算

$$r_i = |y_i - f(x_i)|.$$

对目标误差覆盖率 α ，取排序位置

$$k = \lceil (n+1)(1-\alpha) \rceil, \quad q = r_{(k)},$$

其中当 $k > n$ 时按无穷上界处理。对新样本给出

$$C(x_*) = [f(x_*) - q, f(x_*) + q].$$

在校准样本与新样本可交换、模型训练独立于这些标签等条件下，可获得边际覆盖保证。这一保证针对 y_* ，并不自动针对潜在育种值 u_* ；若校准标签是原始表型，区间同时包含不可预测环境波动。把区间名称换成“育种值置信区间”不会改变它实际覆盖的对象。

例如 $n = 19$ 、 $\alpha = 0.1$ ，应取第十八个排序残差。若残差依次为 0.05, 0.10, ..., 0.95，半宽为 0.90。这不是对每个品种、每个频率区间都分别保证九成覆盖；总体覆盖可以掩盖某个稀有亚群严重不足。若把同一家系中的十九头近亲当作十九个独立可交换校准单位，而新样本来自新家系，基本条件也可能不成立。分组或加权扩展各自需要额外假设，不能用方法名称绕过亲缘与分布变化。

输入本身不确定时，还可用局部传播理解误差来源。若输入表示均值为 $\bar{x}$ 、协方差为 C_x ，函数可微，则一阶近似为

$$\text{Var}\{f(x)\} \approx \nabla f(\bar{x})^\top C_x \nabla f(\bar{x}).$$

这个量只反映给定网络参数下的输入扰动，对离散大结构变异、跨阈值反应或明显非线性可能不可靠。它也不包含模型偏差和校准参数不确定性。将多个来源分别估计后相加，仍需要核对是否相关；同一参考面板错误可以同时影响输入、功能评分和遗传评定，简单相加可能重复计算或遗漏共享项。

最后，可信范围应围绕实际任务表达：目标物种和组织中哪些变异有校准标签，哪些频率范围有独立覆盖，哪些家系和环境已接受外推检验。对于超出支持范围的候选，可以报告较粗的功能类别、保留更宽不确定性，或要求新的实验与分型证据。这样的限制不是否定基础模型的价值，而是把它的丰富分子信息放在可检验的遗传推断链条中，使预测随着新资料逐步可靠地改进。

33.24 综合练习与解答

练习 1. 设特征映射 $\phi(x) = (1, x^2)^T$ ，两个输入为 -1 和 2 。写出核矩阵，并证明它半正定。

解答。 特征矩阵为 $\Phi = \begin{pmatrix} 1 & 1 \\ 1 & 4 \end{pmatrix}$ ，核为 $K = \begin{pmatrix} 2 & 5 \\ 5 & 17 \end{pmatrix}$ 。其行列式为 9、首个主子式为 2，故正定；更一般地， $v^T K v = \|\Phi^T v\|^2 \geq 0$ 。学习非线性特征后仍可构造合法核，但特征学习必须遵守验证边界。

练习 2. 某数据有 200 个独立组，每组 5 条记录，组内相关 0.25。按等相关近似求设计效应与有效样本量，并说明该数值的限制。

解答。 设计效应为 $1 + 4 \times 0.25 = 2$ ，总记录 1000，有效样本量近似 500。这个简化只用于展示相关记录的信息折损，真实家系结构和基因组预测的信息量不一定能由单一组内相关描述，不能把 500 当作通用精确参数。

练习 3. 一个序列模型认为参考碱基概率 0.6、替代概率 0.2。对数概率差是多少？能否据此认定替代使产量下降？

解答。 差为 $\log(0.2/0.6) = \log(1/3) \approx -1.0986$ 。它描述模型中的相对序列概率，不能直接说明生产效应方向或单位。需要目标物种的功能和性状证据，最多可作为候选注释或优先级信息。

练习 4. 三层长度为 5、步长为 1、无池化与膨胀的卷积，其感受野是多少个位置？若 SNP 间距不均匀，这个数值能否直接换成固定碱基距离？

解答。 感受野为 $1 + 3 \times (5 - 1) = 13$ 个位置。不能直接换成固定距离，因为输入位点间距不均匀。需要使用实际坐标计算覆盖，并考虑模型是否适当表达距离；十三个位置只描述索引范围。

练习 5. 真实值为 $(-1, 0, 1)$ ，预测为 $(8, 10, 12)$ 。求相关、平均偏差和均方误差。

解答。 预测等于 $2u + 10$ ，相关为 1，平均偏差为 10，误差为 $(9, 10, 11)$ ，均方误差为 $(81 + 100 + 121)/3 \approx 100.6667$ 。高相关没有反映均值与尺度错误，实际应用需要校准并在独立资料中验证。

练习 6. 两个无偏模型误差方差分别为 4 与 9，协方差为 1。求最优凸组合权重与误差方差。若协方差为 5，结果如何？

解答。 第一情形第一个模型权重为 $8/11$ ，误差方差为 $35/11 \approx 3.1818$ 。第二情形无约束权重 $4/3$ 超出区间，凸组合最优取 1，误差方差为 4。实际误差矩需在训练内部估计，估计噪声可能削弱理论增益。

练习 7. 某模型在全数据上先筛选与表型最相关的一千个 SNP，再进行十折交叉验证。为什么后续分折不能消除泄漏？

解答。 测试表型已通过 SNP 筛选影响输入集合，即使每折重新拟合网络，信息路径仍存在。应在各训练折内重做筛选和阈值选择，或使用真正独立外部注释。所有依赖目标的处理都属于学习流程，而不只是网络参数估计属于训练。

练习 8. 一个在人和小鼠分子资料上训练的模型能对绵羊序列返回分数。写出在宣称改善绵羊育种值预测前至少需要的三个验证层次。

解答。 首先核对序列、同源与变异表示；其次在绵羊相关组织和变异类型中校准分子功能评分；最后把评分按明确方法进入遗传预测，并在独立群体或后续世代检验育种值增量。还需比较传统注释基线、成本和校准。能返回数值只是计算可行，不是应用有效。

练习 9. 两个高度连锁 SNP 的归因排名随随机种子交换，但模型预测几

乎不变。应如何解释？

解答。数据中两个 SNP 可能具有可替代信息，单个位点归因不易识别。可以报告区域层面稳定性，并通过不同重组背景或独立功能证据进一步区分。不能仅据一次归因排名宣布某 SNP 因果，也不应仅因排名交换就认定全部预测无效。

练习 10。一个模型的均值估计标准误为 2，未来个体随机标准差为 4，二者独立。求均值与个体预测区间所用的标准差，并说明区别。

解答。均值区间使用 2，个体预测区间使用 $\sqrt{2^2 + 4^2} = \sqrt{20} \approx 4.4721$ 。前者描述平均目标估计的不确定性，后者还包含个体随机变异。若近似正态，分别乘 1.96 得到 95% 区间半宽约 3.92 与 18.77。

练习 11。某预印本报告大规模人类变异预计算资源。教材应怎样描述其状态和应用边界？

解答。明确作者、年份、预印本状态与资料截止日，区分模型预测覆盖和实验验证覆盖。仅按已核实任务描述结果，不将人类分子证据扩展成家畜育种有效性。可以提出候选迁移路线，但应标为需要本物种与育种任务验证的推论。

练习 12。为一个加入序列嵌入的基因组预测模型设计公平比较。

解答。使用相同训练与测试动物、目标和可得信息，建立合理 GBLUP 与传统注释基线；把嵌入训练、筛选、校准和超参数选择放在内部边界；按实际用途采用时间、家系或群体验证；报告相关、误差、校准、重复变异和成本。若嵌入来自外部预训练，应说明其资料范围与测试对象可能的重叠。

第十篇计算与应用

第十篇

PART X

计算实践与研究设计

本篇把全书方法落实到数据组织、可复算的教学实验、多性状配种决策与模型诊断之中，形成从资料到决策的完整闭环。

第 34 章 从数据字典到可重复遗传评定

第 35 章 从系谱 BLUP 到 GBLUP：一个可复算的肉羊教学实验

第 36 章 多性状目标与约束配种的完整决策算例

第 37 章 模型诊断、失败分析与可检验的研究设计

从数据字典到可重复遗传评定

34

34.1 先把育种任务变成可检查的问题

设想一个肉羊育种团队准备在秋季配种前决定年轻公羊的使用份额。它可以得到耳号、出生日期、父母信息、早期生长记录和部分基因型，却看不到这些公羊未来后代的育肥表现。如果只把任务写成“建立高准确度预测模型”，几乎任何一个与生产记录相关的算法都可以声称完成了任务。真正需要回答的是：在确定的决策日期，面对确定的候选群体，依靠当时已经形成的信息，预测哪些遗传性状，并将预测转化成什么行动。时间、对象、信息和行动缺少任何一项，后面的准确度都可能失去明确含义。

研究问题与计算任务应当分别表述。计算任务可以是求解一组混合模型方程，研究问题则可能是“新增基因型能否改善未来一代年轻公羊的选择”。同一组方程可以服务于不同研究问题，同一个研究问题也可以用若干方法回答。把二者混为一谈，容易造成模型一旦成功运行就宣布研究成功。求解收敛只能说明程序找到了某种数值结果，不能说明输入身份正确、验证资料独立、目标性状符合生产需要，更不能证明预期遗传进展会在真实群体中实现。

一个可检查的任务说明应包含目标群体的进入规则。例如，候选群体是所有达到某日龄的健康公羊，还是已经通过外貌评审的公羊；母羊是初配母羊还是全部繁殖母羊；预测适用于同一场站下一年度，还是推广到从未参与训练的场站。进入规则会改变性状分布、亲缘结构和决策难度。若模型只在已经通过严格初筛的候选者中使用，验证也应尽量模拟这一条件；把全部出生个体上的相关系数直接作为初筛后候选群体的准确度，往往忽略了选择造成的范围缩窄。

随后要明确结果的使用方式。只用于安排后续测定的模型，可以容忍与正式留种不同的误差代价；用于决定大规模冻精推广的模型，则需要更加关注校准、家系覆盖和长期亲缘集中。两个模型的预测相关相同，如果一个主要在低使用价值的个体上出错，另一个主要把少数高风险个体排到最前，其实际后果可能很不一样。因此，数据准备之初就应列出主要决策损失，而不是等得到一个漂亮的相关系数以后再寻找应用理由。

本篇以完全模拟的肉羊教学群体贯穿这些环节。模拟不是某个牧场的脱敏资料，数值也不代表某个品种的生产水平。我们知道生成过程中的真实育种值，因而能够把模型误差、抽样波动和决策约束分开研究。现实数据通常看不到真实育种值，这个差别将在后面的验证章节中反复发挥作用。教学实验的作用是建立一套清楚的检查逻辑，再把逻辑带到现实资料中，绝不是把模拟条件包装成已经发生的生产事实。

问题说明还需要规定什么证据会改变结论。若新增基因型只提高随机切分验证的相关，却不能提高按出生代验证的表现，那么“适用于未来一代”的主张就需要调整。若平均表现改善，但某个主要家系的系统偏差扩大，也不能只公布整体均值。事先规定失败条件能够减少结果出来之后随意改变目标的空间，并帮助团队把有限经费用在最有信息价值的检查上。

可以把整个任务压缩为一句工作定义：在信息截止日 t_0 ，对满足资格条件的候选集合 C ，用可用资料 $\mathcal{F}_{t_0}$ 预测目标向量 $\mathbf{u}_C$ ，并在既定约束下选择行动 $\mathbf{d}$ 。这句话不是形式主义，它把后续每个字段、每次切分和每项检验都连接到一个共同对象。面对新的数据源时，首先问它改变了哪一部分；面对新的算法时，首先问它改善了哪一个可检验环节。

34.2 从总体定义到观测单位

遗传评定常以动物为中心，但数据表的每一行不一定代表一个动物。一行可能是一次称重、一段采食访问、一个配种事件、一窝产羔、一个乳样，或者一个基因分型批次。观测单位与预测单位不一致并不是问题，问题在于没有明确它们之间的关系。重复测定模型正是通过设计矩阵把多条记录映射到

同一个个体；若在合并资料时把这种关系丢失，再复杂的随机效应也无法恢复。

以生长测定为例，出生重、断奶重和测定结束重属于不同时间和管理条件下的记录。若把它们都堆进一列“体重”，同时只保留个体编号，就把年龄效应与遗传差异混在一起。即使后续加入一个粗略年龄协变量，也不能补回已经丢失的测定间隔、转群或疾病信息。较稳妥的资料结构应保留原始事件：谁在何时、何处、用什么设备、按照什么规则测得什么数值。分析性状则由明确的派生规则从事件表形成。

总体定义还涉及“本来应当被记录但没有出现的对象”。如果只保存成功完成育肥测定的羊，就不知道退出者是死亡、疾病、提前出售还是身份丢失。完成测定本身可能与遗传潜力和环境条件有关。一个只包含结果值的表不能区分这些机制，因此最小数据体系应同时保存资格名册、进入时间、退出时间和退出原因。这样才能判断缺失是否与研究目标有关，而不是把没有数据的动物当作从未存在。

对于繁殖性状，分母定义尤其关键。窝产羔数以实际分娩母羊为单位，年度产羔数可能以年初在群母羊为单位，繁殖成功率则需要记录暴露于配种机会的全部母羊。若只观察已经分娩者，无法直接估计配种后妊娠概率；若只记录活羔，又把流产和死胎混入零值，模型中的零便不再有单一含义。研究者必须先确定生物学过程和风险集合，再决定使用连续、二项、计数或阈值模型。

观察单位不同，也会改变误差相关。一个栏位的总采食量分摊给十只羊，不会产生十个相互独立的个体采食量。若分摊规则以体重为依据，再将分摊结果与体重共同用于估计饲料效率，还可能在数据构造阶段引入机械相关。应把实际测量层级写进字典：个体实测、栏位汇总、模型推算不能只用一个“耗料”字段掩盖。必要时将栏位作为观测单位建立模型，而不是以虚假的个体精度换取更大的样本量。

在联合育种计划中，登记个体、已分型个体、具有目标表型的个体和候选个体通常是相交但不相同的集合。应分别记录集合成员资格，不用一个“有效样本”标志混合所有含义。一个没有表型的个体可以通过系谱连接训

练群体，一个没有分型的个体可以进入单步评定，而一个已经死亡的动物可能仍为后代提供历史信息。删除规则若只依据当前是否候选，会破坏这些有用关系。

在本篇教学实验中，主表每行代表一只动物，表型恰好每只一条，因此设计矩阵中的个体关联可以写成单位映射。这是为便于解释而作的简化。读者应始终记住，公式中的简洁并不意味着生产资料天然具有同样结构。把复杂资料投影成分析表时，最好先画出观测、动物、母体、家系、栏位、场站和时间之间的关系，再决定哪些关系通过固定效应表示，哪些通过随机效应或残差协方差表示。

34.3 性状定义是模型的一部分

性状名称只是入口，完整定义至少包括生物学对象、测量窗口、单位、方向、处理状态和派生公式。同样叫“断奶重”，可能在实际断奶日测定，也可能校正到统一日龄；前者带有不同断奶管理的影响，后者依赖校正规则。若两个场站采用不同定义，合并后的数值即使都以千克表示，也不必是同一个统计性状。数据字典需要记录这种差异，而不只是提供一系列简短中文释义。

派生性状应能追溯到原始量。例如平均日增重可以写为

$$g_i = \frac{w_{i,2} - w_{i,1}}{a_{i,2} - a_{i,1}}.$$

这个式子要求两次体重与两次日龄一一对应，日龄差为正，单位一致。如果把出生日期修订了，却没有重新计算日龄和日增重，派生性状就与原始记录不一致。若测定期间发生转群、饲养方案变化或明显疾病，该平均值所代表的环境窗口也需要说明。把这些情况一概称为噪声，会掩盖管理过程对遗传评定的影响。

比值性状需要额外谨慎。料重比由耗料和增重构成，两个组成性状都可能受遗传影响，也都带有测量误差。比值的分布和经济解释不等同于任一组成性状；当增重接近零时，比值还可能非常不稳定。如果育种目标是降低达到同等增重所需的耗料，可以考虑在明确生物学假设下建立组成性状联合模型或残差采食量模型，但不能仅因为某个比值更容易计算就把它当作唯一正

确目标。对使用者而言，知道一个数值究竟是直接测量还是条件校正，比记住它的名称更重要。

尺度转换应同时作用于记录、方差和经济权重。若把千克改为克，表型与育种值乘以一千，方差乘以一百万；为了保持同一经济目标，每克的权重应是每千克权重的千分之一。只改变数值列而保留原方差参数，等于改变收缩强度；只改变性状单位而保留原经济权重，则改变了选择目标。单位是模型的组成部分，不能在结果排版阶段才补充。

一个可手算的例子是，某动物在 70 日龄体重为 24 千克，100 日龄为 33 千克，平均日增重为 0.3 千克每日。若另一条记录把结束体重记为 33000 克，则首先统一为 33 千克，而不是将 33000 直接代入公式。若把年龄间隔误记为 20 天，日增重就变为 0.45 千克每日，增幅达百分之五十。这个错误未必表现为极端异常值，却足以改变留种排序。因此，检查派生量与组成量的代数一致性，比仅对派生量设一个宽泛范围更有效。

还要区分校正性状和原始性状。事先根据全体资料估计性别、年龄或场站效应，再将校正后的值交给验证模型，可能把验证信息带入训练。即使校正公式本身合理，估计公式所使用的数据范围也必须符合信息截止日。如果某些校正系数来自独立且事前固定的外部标准，可以作为既定规则使用；如果来自当前研究资料，则应在训练循环内重新估计，并记录估计不确定性。

数据字典最好保留“原始名称”和“分析名称”的明确映射。例如，原始称重事件可以派生为某个统一日龄区间的增长指标，但不能覆盖原始体重。以后目标改变、校正方法更新或发现设备漂移时，仍可从原始记录重新形成性状。一个只能继续使用既有派生数值、无法回到测量事实的数据体系，会把早期假设固定成无法检查的前提。

34.4 身份、主键与连接错误的数值后果

模型可以处理缺失表型，却不能自动识别一个被错误贴上身份表型的表型。身份错误的危险在于它往往保留所有表面结构：样本量没有减少，矩阵仍然对称，算法仍然收敛，结果甚至看起来平滑。对遗传分析而言，表型、系谱

和基因型之间的正确对应，比增加某个复杂模型项更基础。因此应将身份管理视为统计设计的一部分，而不是数据导入之后的临时整理。

主键应在规定范围内唯一且稳定。耳号可能只在一个场内唯一，芯片号可能在更大范围内唯一，历史记录还可能存在换标和重复使用。可以设置内部不可变的动物标识，并以映射表保存各时期耳号、样本号和检测号。映射需要有效时间，避免把一个停用耳号后来分配给另一只动物时合并成同一个体。修改显示名称不应改变内部主键，纠正身份对应则应留下旧关系和更正依据。

考虑三个个体，真实预测值为 $(-1, 0, 1)$ ，相应真实育种值也为 $(-1, 0, 1)$ 。正确连接时相关为一。如果基因型表按另一种顺序排列，错误地把预测连接成 $(1, 0, -1)$ ，相关立即变为负一。这里没有任何遗传模型错误，仅仅是行序改变造成了完全相反的结论。现实中随机的少量错位不会总是产生如此明显的负相关，更常见的是性能缓慢下降，并被误认为性状难预测或标记面板质量不够。

连接时不能默认“两个文件都是按耳号排序，所以行序一致”。字符串排序与数值排序可能不同，前导零可能被表格软件删除，中文空格和英文空格可能混用，大小写转换也可能改变标识。可靠做法是显式按主键匹配，并在连接后验证每一行的身份，而不是直接把数值矩阵并列拼接。若需要把主键转换为矩阵索引，应保存双向映射，保证预测结果能无歧义地返回原动物。

一对多连接也可能悄悄制造伪重复。设主表有四只动物，每只一个体重；另一个检测表中某只动物有三次重复检测。若直接连接而不指定检测事件或选择规则，该动物的体重会复制成三行。此时总行数增至六，但并未增加两个独立体重观测。将这些行当作独立记录会给该个体及相关家系更大权重。正确方法是保留检测层级，或者在预定规则下选用、合并检测结果，并在模型中反映重复测定相关。

教学数据从零开始编号，零是有效动物，未知父母记为负一。实际系统可以采用空值或专门编码，但任何方案都必须唯一解释。若某张表用零代表未知父本，而另一张表把零作为一个真实公羊，连接会给大量动物制造共同父本。由此得到的关系矩阵仍可能正定，模型也可能顺利运行，然而家系结

构已被根本改变。检查未知编码与有效编号不相交，应成为资料进入评定前的必做步骤。

身份核查可以形成分层证据。第一层检查主键唯一性和引用完整性；第二层检查出生日期、性别和父母角色等逻辑关系；第三层在有基因型时检查孟德尔相容性、性别标记和亲缘一致性。遗传证据可以提示登记错误，却不应由程序未经复核就覆盖历史身份。样本污染、双胞胎关系、低质量分型和参考频率问题也可能产生异常，最终更正需要明确依据和可追溯记录。

34.5 信息截止日与双时间记录

令 t_0 为作出选择决策的时点， $\mathcal{F}_{t_0}$ 为该时点已经可用且允许使用的信息。前瞻性育种值预测应满足

$$\hat{u}_i = f_i(\mathcal{F}_{t_0}).$$

这个表达式的关键是“可用”，而不只是“事件已经发生”。一只羊可能在六月完成称重，但七月才补录到系统。如果研究回顾六月底能够作出的决策，就不能默认当时已经看到了这条迟报记录。因此，一个可靠的数据体系至少区分事件发生时间和系统获知时间，必要时再记录复核通过时间与更正时间。

双时间记录使研究者能够回答两个不同问题：某一天实际发生了什么，以及当时的决策者知道什么。前者适用于生物学过程分析，后者适用于部署条件下的模型验证。若只保留最新修正后的表格，就可能用后来确认的亲本、后来修正的体重和后来取得的检测结果重建过去预测，从而得到过于乐观的历史表现。回顾性验证应明确采用“最终清理资料下的理想预测”还是“当时真实可用资料下的运行预测”，两者都可以研究，但不能混称。

本篇实验把前四十只基础个体和随后一百六十只第一代个体作为训练，第二代八十只作为未来候选。所有候选基因型在预测时可用，第二代表型和真实育种值只用于模拟验证。使用候选基因型构造关系矩阵不自动构成泄漏，因为分型是决策前可获得的信息；使用候选未来生产记录选择模型、校正表型或估计参数则不符合这一设定。是否泄漏必须根据部署场景判断，不

能简单地按“验证集的任何信息都不能使用”作机械区分。

信息边界还包括无监督处理。用全体基因型估计频率、做主成分分析或建立填充参考，虽然没有直接使用未来表型，仍会改变部署场景。如果现实评定时候选群体基因型确实已在手，这种处理可以属于合法的联合预测；若目标是逐个接收未来新动物，则使用整个未来群体分布可能提供当时不具备的信息。研究报告应明确是批量预测还是逐个外推，并按相应流程验证。

一个具体时间例子能够帮助辨析。某公羊在三月分型，五月完成生长测定，六月形成第一版评定，十一月得到第一批后裔记录。若研究六月的公羊选择，三月基因型和五月已审核的自身记录可以进入，十一月后裔记录只能作为后续验证信息。若五月测定结果直到七月才复核通过，则是否允许六月使用必须与实际工作制度一致。把所有日期压缩为“本年度数据”会抹掉这些重要差别。

时间切分还要防止同一生物学事件的派生信息跨界。例如，未来疾病诊断可能已经被编码进后来补录的淘汰原因；未来产羔数可能影响“优秀母羊”标志；用全年资料形成的标准化分数也含有后半年的分布信息。删除显眼的未来结果列并不足以消除泄漏，需要检查每个输入的生成过程。对复杂特征，最好记录其上游字段和计算时间，使依赖关系能够被审计。

34.6 重复测定为何不能简单增加样本量

同一只动物测量五次通常比测量一次更有信息，但五次记录并不等于五只独立动物。考虑简化模型 $y_{ij} = \mu + u_i + p_i + e_{ij}$ ，其中 u_i 为加性育种值， p_i 为个体永久环境， e_{ij} 为每次测量的暂时误差。设三者相互独立，方差分别为四、三和五。一次记录的总方差为十二，重复力为 $(4 + 3)/12$ ，而记录与育种值的联系只来自方差为四的遗传部分。

对同一个体的 n 次记录取平均，暂时误差可以被平均削弱，永久环境却不会消失，因此

$$\text{Var}(\bar{y}_i) = 4 + 3 + \frac{5}{n}.$$

如果总体均值已知且仅用该个体平均记录线性预测育种值, 其可靠度为

$$r_n^2 = \frac{4}{4 + 3 + 5/n}.$$

一次记录的可靠度为三分之一; 五次记录时为二分之一; 即使测量次数无限增加, 可靠度也只趋近于 $4/7$ 。这个上限来自遗传与永久环境在同一个体内部无法仅凭重复记录完全分离, 而不是测量设备还不够精确。

若错误地把全部非遗传方差都当作每次独立误差, 就会写成 $4/[4 + (3 + 5)/n]$ 。在五次记录时, 这个错误公式给出约零点七一四的可靠度, 比正确值零点五高出很多。数据量看似增加, 实际只是把永久环境信息重复计算。大量自动传感器记录尤其容易出现这种错觉: 分钟级记录数可以非常大, 但对遗传评定有用的独立环境和家系信息并没有按同样速度增加。

这个算例还说明了为什么平均方式需要依据目标。若测量误差方差随时间变化, 简单平均未必最有效; 若记录之间有自相关, 平均残差方差不能用单一方差除以次数。一般地, 若记录残差协方差为 $\mathbf{R}_i$, 平均权重为 $\mathbf{w}_i$ 且权重和为一, 残差贡献是 $\mathbf{w}_i' \mathbf{R}_i \mathbf{w}_i$ 。当相邻时点高度相关时, 密集地增加相邻测量可能不如覆盖不同生理阶段更有价值。

在肉羊生长资料中, 重复体重还包含真实生长轨迹。把全部体重平均成一个数字, 会失去早熟、后期补偿和环境响应等信息。若研究目标是某一规定日龄的体重, 随机回归或纵向模型可能更合适; 若目标是整个育肥周期的表现, 曲线积分或阶段性目标可能更有解释力。选择模型之前, 应先说明希望保留哪种生物学信息, 而不是仅因为长表更方便就保留全部点, 或仅因为宽表更简单就强行求平均。

数据体系应保存测量事件编号、设备编号、测定顺序、操作者和校准记录。这些字段未必全部进入最终模型, 却有助于解释异常。例如某台秤在更换电池后整体漂移, 会在连续记录中形成共同偏差; 如果设备信息已被丢弃, 研究者可能把它误认为某批动物的遗传进步。保留元数据并不是预先假设所有细节都重要, 而是为以后识别重要细节保留证据。

34.7 系谱资料的拓扑、基准与不确定性

系谱不是一张只有父号和母号的普通表，它规定了一种有方向的遗传来源结构。父母必须先于后代存在，个体不能成为自己的祖先，父本与母本角色必须与记录制度相容。构造关系矩阵前应先验证这种结构，而不是遇到矩阵分解失败才回头检查。对有明确出生日期的动物，还应检查亲子年龄间隔；日期缺失并不意味着亲缘关系错误，但会降低可以用于核验的信息。

计算上常把系谱按祖先先于后代的拓扑顺序排列。这个顺序是矩阵索引，不是身份本身，重新排序不应改变动物的实际关系。若程序把排序后的行号写回原表而没有保留映射，会制造难以察觉的身份错误。每次生成关系矩阵时，应同时保存行列主键，矩阵文件只含数字却没有可核验的个体顺序，不能算完整的分析输入。

基础个体的定义决定了系谱关系的零点。把未记录亲本动物视为互不相关且不近交，是一种模型基准，不是关于真实祖先的事实陈述。某些基础个体可能来自同一小群体，实际上存在未被记录的亲缘。若不同来源群体在遗传均值和关系上不同，还需要适当的基础群体表示。不能用增加系谱代数的方式自动解决所有基础差异，也不能把基因组关系与系谱关系对角线不一致立即解释为某一方出错。

部分亲本未知时，应保留“未知”的具体含义。父本未知可能是自然交配群中未做亲子鉴定，母本未知可能来自寄养或登记遗失，两者对信息结构的影响不一样。有时已知候选父本集合，但不知唯一父本；将其中一个概率最大的个体直接当作确定父本，会忽略身份不确定性。如果最终模型不支持概率系谱，也应在资料层保存候选集合与证据，而不是把暂时推断变成不可追溯的确定事实。

基因型能够提供亲子相容性证据，但检查规则需要考虑错误机制。少量孟德尔不一致可能来自分型误差、样本交换、等位基因编码或极少量生物学事件；大量一致也不一定唯一确定父本，尤其候选父本彼此高度相关时。应把“排除不相容关系”和“确认唯一关系”区分开。前者通常比较容易，后者需要足够信息以及对其他候选的比较。

一个简单系谱说明了未知基准的重要性。两只基础公羊若在数据中无共同祖先，其系谱关系被设为零；它们各自产生一批后代，跨家系关系也可能为零。若后来发现两只基础公羊实际为半同胞，关系矩阵的多个区块都要更新，变化不限于两只公羊自身。预测结果随之改变不是模型不稳定，而是输入亲缘信息发生了实质修订。报告需要指出这种改变属于资料版本变化，避免被误读为算法版本改进。

系谱清理应形成可以回放的操作记录。删除重复个体、合并别名、补入祖先和更正父母都有不同统计后果。比较两版评定时，可以先在同一模型下只更新系谱，再保持系谱固定只更新模型，从而分离变化来源。若同时改变全部环节，个体名次升降虽容易观察，却很难解释。可解释的版本比较从资料变更的可分解性开始。

34.8 基因型资料的编码、参考与质量

基因型矩阵中的零、一、二并不是抽象数字，而是针对某个指定等位基因的剂量。不同实验平台可能使用不同参考方向，某些标记的等位基因还存在正负链歧义。合并面板前应核对标记位置、参考基因组版本、等位基因标签和方向。只按标记名称连接而忽略编码规则，可能把相同生物学基因型变成不同数值，或者把相反方向误当作一致。

对于关系矩阵，如果所有个体在某个位点同时翻转编码，并同步更新参考频率，中心化后的该列只是乘以负一，外积贡献不变。因此全体一致的方向改变未必影响关系矩阵。真正危险的是只有某个批次翻转，或者频率没有同步改变；这会制造批次特异的相似性和差异。这个代数性质有助于把编码问题分成可容忍的统一变换与会破坏分析的局部不一致。

本篇把中心化标记矩阵记为 $\mathbf{W}$ ，以避免与随机效应关联矩阵 $\mathbf{Z}$ 混淆。令 $\mathbf{M}$ 为剂量矩阵， $\mathbf{p}$ 为参考频率，则

$$\mathbf{W} = \mathbf{M} - 2\mathbf{1}\mathbf{p}'.$$

参考频率可以来自基础群体、训练群体或另一个明确的参考集合。不同选择改变基准，进而影响关系矩阵和遗传均值的解释。没有一种频率选择可

以脱离研究目标而被宣布永远正确，但每一种选择都应当被记录，并在比较模型时保持相容。

缺失基因型的处理也属于模型流程。简单均值填补把未知剂量替换为 $2p_j$ ，中心化后为零；它没有恢复个体真实的孟德尔差异。基于亲缘或单倍型的填充可以提供更多信息，但填充模型的参考资料和运行时点也要符合验证场景。将后代或未来群体的高密度分型用于历史填充，可能适合某种回顾性重建，却不等同于当时可部署的预测。

分型质量不应由单一缺失率概括。低频等位基因、批次差异、重复样本一致性、性别相容性和亲缘一致性各自检查不同问题。某个位点总体缺失率很低，但在某个场站或表型极端组中系统缺失，仍可能引入结构性偏差。质控阈值应根据测定过程和分析用途预先确定，并报告剔除前后的样本与标记构成，而不是只报告最终剩余多少个位点。

等位基因频率极低时，标准化方案会显著影响该位点的权重。如果将每列都除以自身标准差，稀有变异中的少数剂量差可能获得很大数值权重；如果使用共同的总杂合度尺度，其贡献方式又不同。这些选择涉及遗传效应方差假设，不能只视为方便计算的技术步骤。资料准备阶段应保存原始剂量和频率，使其他合理标准化方案能够被复核。

在多平台长期育种计划中，最好将分型事件与动物主表分开。一个动物可以有多次分型，每次有平台、批次、样本来源和质控状态。最终用于评定的共识基因型应由明确规则形成，出现冲突时保留冲突证据。把新检测直接覆盖旧检测，会丢掉识别样本交换和设备问题的重要线索，也使历史评定无法按原资料复现。

34.9 缺失不是一个统一的数字

空白单元格可能表示尚未测量、测量失败、不适用、动物已经退出、结果待复核或原始记录丢失。这些情况的统计含义不同。把它们统一编码成零，会把缺失混入性状分布；统一编码成负九十九而忘记在某个环节转换，则可能制造极端值。更合适的体系是将数值与状态分开保存：数值列记录确有定

义的测量，状态列记录为什么没有数值。

缺失机制应围绕观测过程讨论。完全随机缺失是一种较强假设，要求缺失与相关观测量和未观测量都无关；在给定已观测信息后与缺失值独立的条件，允许更广泛的建模处理；若缺失还直接依赖未观测结果，则需要额外假设、敏感性分析或补充资料。名称本身不会告诉我们实际数据属于哪一种，必须结合测量安排、淘汰规则和生产过程判断。

例如，某场规定只对早期生长最快的一部分公羊做昂贵的饲料效率测定。后期耗料缺失显然不是完全随机，因为进入测定取决于已观察生长。若早期生长记录和选择规则完整保留，模型有机会利用这些信息解释选择过程；若只留下完成耗料测定者，研究者便无法知道它们是如何从总体中选出的。额外保存一列“是否具备测定资格”和“未测原因”，可能比事后使用更复杂的插补算法更有价值。

对结构性不适用的数值，不宜进行普通缺失插补。公羊没有产羔数，尚未达到繁殖年龄的母羊没有本年度繁殖结果，这些不是同一种随机丢失。可以在多性状模型中允许某些个体没有某性状记录，但应保持生物学定义。若为了形成一个完整矩阵而给公羊插补产羔表型，再把它作为真实记录使用，就改变了数据生成含义。

多重插补、似然方法和贝叶斯方法都需要条件模型及假设。它们能在合适条件下传播缺失不确定性，但不能凭空恢复从未记录的关键选择机制。插补后的多个完整数据集也不是多批独立生产资料。报告应说明哪些变量被插补、使用了哪些辅助信息、插补发生在验证循环的哪个环节，以及最终不确定性如何合并。

实际遗传评定中，还要区分缺失表型和没有测定计划。如果某一场站从未测过某个性状，跨场预测主要依赖其他性状、亲缘和模型假设；如果只是随机丢失少量记录，信息状况完全不同。把这两种情形合成一个总体缺失百分比，会掩盖模型需要进行的外推程度。应按场站、出生批次、性别和家系报告缺失分布，优先识别系统性的空白区。

敏感性分析可以从简单情景开始。假定退出测定动物的未观测结果比模

型预测平均低一个合理幅度，再检查育种值排序或遗传趋势是否改变；也可以改变缺失选择模型的参数，考察结论依赖程度。这里的目的不是证明某一种假定真实，而是揭示在什么范围内结论仍然稳定。若很小的合理偏离就会改变主要决策，应优先补充资料，而不是把不确定性藏在一个单一插补值后面。

34.10 环境分组与遗传连通性

当不同家系主要生活在不同场站或栏位时，环境差异与遗传差异可能难以分离。固定效应可以在模型中写出来，却不保证数据有足够信息估计它们。假如公羊甲的全部后代都在高营养场站，公羊乙的全部后代都在低营养场站，观察到的后代平均差既可能来自父系，也可能来自场站。增加一个场站固定效应并不会自动创造原本不存在的比较。

遗传连通性的实质，是不同环境组之间存在能够支持遗传比较的信息桥梁。共同使用的公羊、跨组分布的亲缘个体、共同测定制度和足够的交叉设计都可能提供连接。连接不是简单计算每组有多少只动物；一个很大的孤立家系仍可能与其他组难以比较，而几个分布合理的连接个体有时比大量组内重复更有价值。

可用一个最小例子理解混淆。两组记录的均值分别为三十和二十六，若第一组全部来自家系一，第二组全部来自家系二，就只有“组别加家系”的总差四可被观察。无论把差解释为环境四、遗传零，还是环境零、遗传四，都能拟合同样均值。只有引入交叉家系、重复使用亲本或外部信息，才能进一步分解。软件给出一个解，可能只是施加了约束或先验，并不意味着数据单独识别了每个分量。

设计矩阵的秩是识别问题的一个入口。若某两列完全相同，或某一列是其他列的线性组合，参数无法按原参数化唯一估计。重新设定参考水平、使用广义逆或增加约束可以得到可计算表达，但必须解释哪些对比仍然可估。秩满并不意味着估计稳定；当两列几乎相同，问题可能数值上可解但标准误很大，结果对少数记录十分敏感。

环境组不宜为了获得更好拟合而无限细分。每个动物单独一个固定组可以吸收几乎所有表型变化，却也消除了用于遗传比较的资料。反过来，把明显不同的测定批次全部合并，则可能把环境变化归到遗传。合理分组需要结合生产制度、时间窗口、饲养条件和样本连接，而不是仅依据统计显著性逐项筛选。

当新候选群体属于训练中从未出现的固定效应水平时，预测还涉及一个实际问题：该组效应从哪里来。若目标是育种值，模型可以利用关系信息预测随机遗传分量，但未来表型预测还需要对新环境均值作假设。将新场站效应默认为零，实际上是在使用某种参考环境；这个选择应公开说明。不能因为预测程序能输出数值，就认为已经解决了跨环境迁移。

数据采集设计能够主动改善连通性。可以在多个场站使用一部分共同公羊，安排适度的跨组后代测定，或在新设备启用时保留一段重叠校准期。这样的设计需要额外成本，却可能大幅减少环境与遗传混淆。遗传评定不应只在数据产生后被动处理，统计人员应尽早参与测定计划，使未来数据能够回答计划中的比较问题。

34.11 协方差、派生变量与合法矩阵

多性状分析常从一张协方差表开始，但每个元素看起来合理并不保证整张矩阵合理。协方差矩阵必须对称且半正定，因为任何线性组合的方差都不能为负。这个要求是概率模型的基本约束，不是某个求解器的特殊偏好。若不同相关系数分别来自不同样本、不同缺失处理或不同研究，拼接后尤其需要检查整体合法性。

考虑三个标准化性状，分别估得相关系数为 $r_{12} = 0.9$ 、 $r_{13} = 0.9$ 、 $r_{23} = -0.9$ ，并把对角设为一。每个相关都在负一与一之间，似乎没有单项越界，但矩阵

$$\mathbf{S} = \begin{bmatrix} 1 & 0.9 & 0.9 \\ 0.9 & 1 & -0.9 \\ 0.9 & -0.9 & 1 \end{bmatrix}$$

的特征值为负零点八、一点九和一点九。存在某个线性组合，其按该矩阵计算的方差为负，所以它不能成为合法协方差矩阵。

直观上，如果性状一与二、性状一与三都高度正相关，那么二与三不可能同时高度负相关到上述程度。成对相关来自不同动物子集时，每一对可以在自身子集中成立，却不一定对应同一个总体的联合分布。合并文献参数时也有类似问题：品种、年龄、环境和性状定义不同，单个研究中合理的参数不能随意拼成统一模型。

发现非法矩阵后，最近半正定修正可以使计算继续，但它改变了输入参数。应报告修正幅度，检查哪些方向受影响，并优先追查来源。若一个微小的舍入误差使最小特征值为负十的负十四次方，修正与处理明显负特征值的情况不同。后者可能意味着参数来源不相容、估计误差很大或数据本身存在问题，不能一概当作数值噪声。

派生变量还可能使协方差矩阵天然奇异。若第三个性状严格等于前两个性状之和，三个变量不提供三维独立信息。奇异在这里不是错误，而是代数关系的结果。模型应通过减少冗余变量、使用适当分块或广义逆处理，并保持目标可估性。给每个对角随意添加一个较大常数虽然能够求逆，却同时虚构了不存在的独立变异。

单位变化应通过线性变换传播到整个矩阵。若 $\mathbf{y}^* = \mathbf{D}\mathbf{y}$ ，其中 $\mathbf{D}$ 为单位缩放对角矩阵，则协方差变为 $\mathbf{DSD}'$ 。只修改对角方差而保留协方差，会改变相关结构，甚至破坏半正定性。这个规则适用于表型协方差、遗传协方差和预测误差协方差，数据字典中记录单位可以帮助检查这种一致性。

建立矩阵时应同时保存估计样本、估计方法、参数化方式和不确定性。两张数值相近的矩阵可能来自完全不同证据：一张由大规模连接良好的资料估计，另一张由很少家系估计后强制修正。决策者需要知道二者的证据强度不同。矩阵不是一组可以脱离来源长期沿用的常数，而是某个总体、某个模型和某段资料的概括。

34.12 从原始记录到分析表的追溯变换

一个可复核的数据流程通常至少区分三层。原始层保存测量和登记事实，尽量不覆盖；清理层保存经过规则处理的记录及其状态；分析层按具体模型和信息截止日生成矩阵。三层并不是为了增加文件数量，而是为了让每个分析值都能回答“它从哪里来、经历了什么变化、为什么被保留”。若直接在原始表格里反复修改，最终只剩一个没有历史的结果，就很难分辨数据修正与分析选择。

每项变换应明确输入、输出和理由。单位转换可以是确定的代数操作，异常记录标记可以是规则操作，人工复核则需要责任人和证据。删除与更正应分开记录：删除意味着该记录不再参与当前分析，更正意味着确认另一数值更接近原事实。用群体均值替换异常值不能称为更正原始事实，它是一种统计处理，应保留原值并标明处理方式。

考虑四只动物的测定表，其中一只结束体重缺失，一只具有重复上传记录，一只单位为克，另一只日期顺序错误。一个合理流程会先处理身份和事件唯一性，再统一单位，核对日期，最后形成派生性状。若先计算日增重并按范围删除，可能把单位错误当作极端生物学表现删除，却未发现重复上传；若先平均重复记录，又可能把同一事件误当作重复测量。处理顺序本身具有统计后果，应写入流程说明。

自动检查最好分为阻断性错误和提示性异常。主键重复导致歧义、亲本循环、负时间间隔或无法解析的单位，通常应阻止分析继续；罕见但可能真实的极端体重，则应触发复核而不是自动删除。把所有异常都作为硬性删除规则，会系统性排除罕见但重要的生物学现象。把所有异常都只作提示而不处理，也会让流程失去约束作用。

分析表的生成应尽量是确定性的：同一输入版本、同一规则和同一配置得到同一输出。若需要随机抽样或随机插补，应保存种子和随机数算法，并说明哪些结果允许数值容差。不能依赖电子表格当前显示顺序、人工临时筛选状态或文件夹中碰巧最新的文件。这样的隐含状态在一台计算机上看似方便，在团队复核或半年后重跑时往往成为主要障碍。

确定性并不要求所有处理都自动化。某些身份冲突和异常记录必须由专业人员判断，但判断应形成可保存的裁决表，下一次运行从裁决表读取，而不是再次依靠记忆修改。这样既保留了人的专业判断，也避免每次重跑得到不同资料。对于无法判定的记录，可以保留多个合理方案进行敏感性分析，而不是强行赋予不具备的确定性。

最终分析表应带有简洁的生成报告：起始动物数、记录数、各规则影响数量、各阶段保留情况、训练与候选集合大小，以及关键分布变化。报告不应仅列一个“删除百分比”，因为删除少量具有连接作用的家系可能比删除大量重复上传行影响更大。把数量变化与结构变化同时呈现，才能判断清理是否无意中改变了目标群体。

34.13 数据契约与可复用研究资料

数据契约是提供者和使用者共同遵守的明确约定。它规定字段的含义、类型、单位、允许范围、缺失规则、主键关系和更新时间，还规定发现违反约定的情况如何处理。契约不必是一套复杂系统，一张认真维护的字典和一组机器可检查的规则就可以发挥作用。关键在于规则应先于分析结果，而不是每次为了让某个模型顺利运行临时改变。

例如，体重字段可以规定为以千克计的正实数，但范围检查只能发现一部分问题。更强的关系规则包括结束日期晚于开始日期、父母出生早于后代、分析日龄由出生日期与测定日期一致计算、同一事件的单位转换前后对应。关系规则往往比单列范围更接近生物学事实。它们也更容易解释：一条记录为什么被阻断，是因为违反了哪一项可核查关系。

资料复用需要的不只是文件可下载。使用者还要知道变量是什么意思、记录如何形成、允许怎样使用以及哪些假设不能改变。Wilkinson 等提出的 FAIR 原则强调可发现、可获取、可互操作和可复用，这为研究资料管理提供了一个通用方向 (Wilkinson 等, 2016)。在遗传评定中，可以把这些原则具体化为稳定标识、机器可读字典、明确版本、标准单位和完整来源说明，而不必把开放共享误解为无条件公开所有个体资料。

动物生产资料可能涉及商业合作、品种资源和机构约定。共享方式应与授权一致，但受限共享并不妨碍做好内部可复现。可以将受限原始数据与公开的生成器、数据字典、分析脚本和合成示例分开。外部研究者无法取得原始记录时，仍然可以检查模型实现、理解字段含义，并在获得授权后复用相同流程。保密要求不应成为缺乏版本记录和计算说明的理由。

数据契约还应说明“不承诺什么”。某个字段可能只保证登记值完整，不保证已经由基因型确认；某批历史体重可能缺少设备校准信息；某个家系的出生日期可能只精确到月份。把这些限制明确写出，有助于使用者选择合适模型。看似完整却掩盖不确定来源的数据表，通常比诚实标明精度边界的表更容易造成错误。

跨机构合并时，宜先建立概念映射，再转换字段名称。两个机构都使用“出生重”一词，仍需要比较测定时间窗口和是否包含估测；一个机构的“断奶”可能指离母，另一个可能指停止补乳。若概念不完全一致，可以保留来源特异定义，使用分层模型或限制合并范围，而不是简单改成相同列名。互操作不仅是文件格式能否打开，更是含义能否被正确传递。

一个数据契约的成熟标志，是新批次资料进入时能够自动指出哪些约定被违反，并由负责人作出明确处理。它不应依赖某位长期工作人员记得所有特殊情况。随着人员更替、测定设备更新和研究问题扩大，书面与机器可检查的规则共同构成知识的连续性。对长期育种计划而言，这种连续性直接影响遗传趋势能否跨年度比较。

34.14 可复现包含资料、算法和数值三个层次

资料可复现意味着能够重建当时使用的分析样本，算法可复现意味着能够按同一模型和配置重新计算，数值可复现则涉及软件版本、计算环境和舍入误差。三者相关但不相同。保存一份最终育种值表可以冻结结果，却不能说明它如何得到；保存代码而没有输入版本，也无法保证重跑的是同一个问题。

随机种子是必要信息，但不是完整的复现说明。同一个种子在不同随机

数算法、不同并行分配或不同调用顺序下可能生成不同样本。模拟研究最好明确随机数生成器，并把独立重复与场景的种子分配规则写出。若新增一个随机操作就改变后面所有场景，比较可能难以追踪；可以为不同随机模块设置可管理的独立随机流，同时保持需要成对比较的部分一致。

本篇基础实验使用种子二一零零一至二一零三零，每次重新生成基础群体、孟德尔传递、标记效应和残差。每次重复中，系谱 BLUP 与 GBLUP 使用完全相同资料，因而方法差异是成对的。三性状决策另用种子二三零零一，使目标权重变化不会伴随随意重抽的候选数据。种子是设计的一部分，不是结果不理想时可以不断更换的调参旋钮。

数值容差应与问题尺度一致。协方差矩阵由于浮点舍入出现极小负特征值，与出现实质性负特征值不同；最优贡献约束在十的负十二次方量级偏离，与超过规定上限千分之一也不同。报告“检查通过”时应说明检查对象和容差，不能一方面打印很多小数，另一方面用很宽的阈值掩盖重要误差。对涉及排序边界的动物，还应考察微小数值差是否会改变离散选择。

独立实现可以检查关键恒等式，而不是重复一遍同样代码。本篇用标记效应岭回归方程与基因组协方差形式的 BLUP 分别计算，核对预测和 PEV 的一致性；二者表达不同而理论等价，能够发现矩阵尺度、固定效应处理或误差方差公式中的错误。仅将同一函数复制后改名再比较输出，不能提供同样强度的证据。

边界情形同样有价值。残差方差非常大时，预测应明显收缩；没有可用记录且遗传均值定义为零时，不应凭空产生个体差异；完全相同的输入身份排列经过正确映射后，应得到相同结果。边界检查不必覆盖所有可能程序路径，但应针对真正会改变科学结论的风险。过多只检查格式的测试，不能代替对模型逻辑的核验。

可复现也不等于理论正确。错误的模型、泄漏的切分和不合理的经济目标都可以被稳定重现。因此，复现材料应同时包含假设说明、验证设计和适用边界。最有价值的复现不是让另一台计算机打印同样数字，而是让另一位研究者能够检查这些数字是否回答了原定问题，并能有控制地改变某个假设观察后果。

34.15 验证切分必须跟随部署场景

随机个体切分适合某些已有群体内的补充预测问题，但它可能让训练和验证之间保留大量近亲。如果实际任务是预测下一代或新家系，这种验证会回答一个较容易的问题。按出生代切分、按家系切分、按场站切分和外部群体验证分别控制不同的信息联系，不能依据哪个结果最好而事后选用。验证设计应从未来使用方式向后推导。

同一动物的重复记录尤其不能随意分到训练与验证两侧。若用早期记录预测后期表现，可以按时间有意识地划分，并明确允许使用同一个体早期信息；若声称预测从未观测的新个体，就必须把该个体相关记录一起留出。把同一个体的两条几乎重复记录分别放在两侧，模型可能主要识别永久环境或个体身份，得出的高相关并不能支持对新动物的预测。

超参数选择与最终评估需要分开。内部验证用于选择正则化强度、特征集合或模型结构，外部留出用于估计锁定流程的性能。若反复查看外部结果后调整处理，外部集就逐渐变成了开发资料。嵌套验证可以在资料有限时组织这两种任务，但仍要保持家系和时间结构，而不是机械地把普通随机折数增加。

数据预处理应位于合适的循环内部。均值、标准差、插补模型、特征筛选和方差参数如果从全体表型估计，再用于每个训练折，会把验证信息传播到训练。某些完全由外部规则确定的变换可以在循环外完成，例如已知单位换算；依赖当前样本结果的处理则应谨慎。区分确定规则与数据估计步骤，有助于避免把所有预处理都笼统视为无害。

验证指标需要配合目标。相关对整体平移和正比例缩放不敏感，不能检查绝对水平与幅度；均方根误差受性状单位和总体分布影响；校准斜率需要足够变化范围，初筛后的狭窄候选群体可能使估计不稳定。区间覆盖率则检验不确定性表达是否合适。一个完整验证报告应解释这些指标各自检查什么，而不是把它们混合成一个无法解释的总分。

如果最终行动是选出少量公羊，还可以报告入选集合重叠、目标均值、错误选择的预期损失和亲缘集中，但应避免只看排名最前的少数个体而忽略

估计不确定性。小幅预测差异可能不足以可靠区分候选者。对最优贡献方案而言,某个模型略高的相关未必转化为明显更好的约束后目标值,必须通过实际决策计算检验。

验证方案应保存为可执行的索引或规则。只写“按百分之八十训练、百分之二十验证”不足以复现,因为不同抽样会给出不同亲缘结构。保存每个动物的角色、切分种子、截止日期和排除理由,可以让方法比较使用完全相同的问题。当任务更新为新的部署场景时,可以创建新方案,但不应悄悄覆盖旧方案后沿用旧的性能结论。

34.16 评定批次的版本、发布与解释

一次遗传评定批次可以看作一个有明确输入和输出的研究对象。它应记录表型版本、系谱版本、基因型版本、模型配置、参数估计方式、软件环境和信息截止日。不同资料源更新频率不同,因此单一“数据日期”通常不够。表型增加了一批记录、系谱更正了几个亲本、参考频率改用了另一群体,都会对结果产生不同性质的影响。

为了比较两个批次,可以依次固定其他条件,只改变一个组成部分。先用旧模型处理新资料,估计资料更新带来的变化;再在同一新资料上比较新旧模型,观察方法变化;若遗传基准发生平移,还应把两批结果转换到可比较尺度。直接比较名次升降而忽略基准变化,容易把整群均值调整误认为个体遗传潜力突然改变。

结果发布不仅需要育种值,还需要解释其参照。零点相对于哪个基础群体,单位是什么,准确度或可靠度如何定义,是否包括参数估计不确定性,候选者间差异如何理解,都应清楚说明。一个数值后面保留三位小数,不意味着第三位具有实际决策意义。应避免把报告精度与统计精度混为一谈。

对重要名次变化,应允许追溯主要原因。例如,新增加了自身表型、后代记录、分型信息,或更正了亲本,可能解释预测变化;整体参数更新也可能改变收缩程度。并非每个变化都能唯一分解,但至少应区分资料增加、资料更正、模型变化和基准变化。这样既有助于专业人员复核,也能减少养殖

者把正常统计更新误解为结果不可靠。

发布前可以设置分级检查。资料检查确认身份和时间；数值检查确认收敛、矩阵和预测有限；统计检查比较分布、遗传趋势、校准和主要亚群；业务检查确认单位、候选资格和决策限制。各层检查应由相应证据支持，不能用某一层通过替代其余层。例如模型收敛不等于配种名单满足母羊数量和禁配规则。

出现问题时，保留旧批次比直接覆盖更有价值。若新批次发现身份错误，可以撤回或更正相应结果，同时保留变更说明和受影响范围。恢复旧版本并不意味着旧结果永远正确，而是确保任何已执行决策都能追溯当时使用的依据。长期育种计划中的可追溯性既服务研究，也服务管理与合作信任。

批次管理还可以支持持续监测。随着新记录到来，比较预测与后续信息，观察某些场站、家系或性状的偏差是否累积。若偏差只在特定设备更新后出现，首先检查测定过程；若跨群体迁移持续失效，则需要重新评估参考群体构成。持续监测的目的不是每天重新挑选表现最好的模型，而是发现部署条件何时已超出最初验证范围。

34.17 综合教学案例：把三张表变成一个可审计问题

设一个教学项目收到动物登记表、体重事件表和基因型样本表。登记表含四只动物甲、乙、丙、丁，其中丙和丁具有已知父母；体重表按事件记录测定日期和数值；基因型表按实验室样本号排序。项目目标是在某年六月三十日之前选择进入后续测定的候选者。第一步不是计算关系矩阵，而是建立动物编号与样本号的显式映射，并确认映射在该截止日前已经核实。

体重事件中，甲有两次有效记录，分别为七十日龄二十四千克和一百日龄三十三千克；乙的结束体重以克记录；丙有一条重复上传；丁的第二次测定发生在七月。对甲可以形成日增重零点三千克每日；对乙先转换单位再计算；丙的重复上传经事件编号确认后只保留一个测量事实；丁的七月记录不进入六月决策。这里没有使用模型，却已经决定了哪些信息在统计上存在。

随后检查系谱与身份。假设丁的父本在登记表中为未知，但七月取得的

亲子鉴定给出确定父本。若研究当时实际可部署的六月预测，应保留六月的未知状态；若另行研究最终清理资料下的理想预测，可以使用七月更正，但应作为另一个场景。两个场景的结果可以比较，比较的含义是后补身份信息价值，而不是把理想场景结果冒充当时已经达到的性能。

分析表应同时保留训练角色和候选角色。甲、乙的历史记录可以进入训练，丙、丁作为候选接受预测；候选者的基因型若在六月已完成审核，可以参与关系构造。不能因为某个候选缺少结束体重就删除其基因型，也不能因为训练个体已经不在当前种羊群就删除其历史表型。记录是否可用由信息与模型需求决定，个体是否参与选择由当前资格决定。

再考虑重复测量的错误处理。若甲的两次体重被误当作同一性状的两个独立动物记录，个体关联矩阵就会错误；若丙的重复上传没有去重，模型会给一个事实重复权重。前面的永久环境算例表明，这类误处理会导致信息被夸大。正确流程不只是最后把标准误调大，而是在数据结构和协方差模型中从一开始表达真实记录关系。

项目可以生成一页审计摘要：四只登记动物、多少个原始事件、多少个独立测量、哪些记录因时间边界不进入、哪些记录经单位转换、哪些身份尚不确定，以及分析采用何种系谱基准。摘要中的每个数量都应能由规则重新计算。若另一位研究者得到不同的训练行数，应能沿变换记录找到差异，而不是靠双方记忆解释。

最后才进入模型比较。先建立一个解释清楚的系谱基准，再评估加入基因型是否改变候选排序、校准和后续测定决策。若发现性能下降，优先检查身份映射、编码方向和时间边界，再考虑遗传架构。这个顺序体现了一条实用原则：越靠近数据生成过程的错误，越应早于复杂模型讨论得到处理。

本案例没有声称四只动物足以估计真实遗传参数，它的目的是把通常隐藏在“数据清理”四个字后面的统计选择展开。大型项目只是把同样的问题扩展到更多事件、更多关系和更多版本。若小例子中无法清楚解释每一行的含义，增加十万行资料也不会自动使研究问题变得明确。

34.18 新增记录的条件创新与逐目标信息增量

资料更新的统计意义, 不是把新行数加入旧行数, 而是判断新记录中还有多少尚未被旧资料解释、并且与目标育种值有关的部分。这个问题可以在不重新推导整个混合模型的情况下精确回答。设旧资料为 D , 待预测育种值向量为 $\mathbf{u}$ 。在协方差参数固定、均值结构已经适当处理的高斯模型中, 旧评定给出条件均值 $\mathbf{m}$ 和条件协方差 $\mathbf{C}$ 。这里的条件协方差包含当前分析所承认的预测不确定性; 若固定效应采用不适当的插件处理, 下面的递推不能替它补上遗漏。

$$\mathbf{u} | D \sim N(\mathbf{m}, \mathbf{C}).$$

现在得到一批新记录 $\mathbf{z}$ 。先用旧资料预测这批记录, 再从实际值中减去预测值, 得到条件创新。它与原始新记录不同: 新记录即使数值很大, 也可能完全符合旧资料已经作出的预期; 反过来, 一条绝对数值普通的记录, 也可能对某个低信息家系形成很大的新证据。把创新、创新协方差和目标与创新的交叉协方差分别写为

$$\mathbf{v} = \mathbf{z} - E(\mathbf{z} | D),$$

$$\mathbf{S} = \text{Var}(\mathbf{z} | D),$$

$$\mathbf{K} = \text{Cov}(\mathbf{u}, \mathbf{z} | D).$$

对联合条件正态分布配方, 或者对创新作最小均方线性投影, 得到新增资料后的评定。后一种推导只依赖二阶矩, 因而也说明了高斯条件期望与最佳线性更新之间的联系和区别。

$$\mathbf{m}_+ = \mathbf{m} + \mathbf{KS}^{-1}\mathbf{v},$$

$$\mathbf{C}_+ = \mathbf{C} - \mathbf{KS}^{-1}\mathbf{K}^\top.$$

均值变化取决于实际看到的创新, 协方差减少量则在观察新数值以前就能计算。对于指定目标 $T = \mathbf{a}^\top \mathbf{u}$, 信息价值首先表现为该目标误差方差的减少, 而不是所有个体平均可靠度的增加。

$$\Delta_a = \mathbf{a}^\top \mathbf{KS}^{-1} \mathbf{K}^\top \mathbf{a} \geq 0.$$

设旧条件均值为 $(1, 0)^T$ ，条件协方差为下式，新增记录测量第一只动物的育种值加一个方差为一的独立误差。新记录观察为四，因此创新为三、创新方差为三。

$$\mathbf{C} = \begin{bmatrix} 2 & 1/2 \\ 1/2 & 1 \end{bmatrix}, \quad \mathbf{K} = \begin{bmatrix} 2 \\ 1/2 \end{bmatrix}.$$

代入更新式，得到新均值 $(3, 1/2)^T$ 以及

$$\mathbf{C}_+ = \begin{bmatrix} 2/3 & 1/6 \\ 1/6 & 11/12 \end{bmatrix}.$$

第二只动物没有新增自身记录，仍通过原有条件关联得到更新。但是，两只动物之差的误差方差只从二降到一点二五，减少四分之三。这与第一只动物自身误差方差减少四分之三不同。若育种任务是比较两只公羊，就应报告前一个对比量；若任务是预测第一只公羊的绝对遗传水平，才采用后一个对象。相同数据没有一个脱离目标的统一信息增量。

从原始协方差分块出发，也能直接计算这些量。设旧记录协方差为 $\mathbf{V}_D$ ，新旧记录交叉协方差为 $\mathbf{V}_{zD}$ ，则创新协方差是一个舒尔补。

$$\mathbf{S} = \mathbf{V}_z - \mathbf{V}_{zD} \mathbf{V}_D^{-1} \mathbf{V}_{Dz}.$$

交叉协方差也要扣除经由旧资料已经建立的联系，不能直接把原始目标与新记录协方差放进更新式。这样做会重复计算已有证据。若新记录是旧记录的完全复制，创新方差为零，而不是一个独立测量误差；这时应识别确定性关系并移除冗余，不能为了使用逆矩阵而随意添加噪声，再宣称复制资料提高精度。

实际批次中，新增记录的顺序不应改变最终高斯条件结果，只要每一步使用正确的条件协方差。顺序改变却得到不同结果，常提示残差相关没有同步更新，或者某一步把旧条件均值当成无误差真值。另一方面，若每加入一批资料便重新估计方差参数，最终结果可能依赖估计流程；此时变化已经包含模型更新，不能全部解释为固定模型下的信息增加。把两个层次拆开，才可能审计一个评定版本究竟改变了什么。

判断一条记录是否具有新信息，还应区分统计重复与技术重复。对同一份生物样本重新读数，可能主要减少检测噪声；对同一动物不同生理阶段重新测量，则同时包含新的阶段效应。即使两类记录采用同一个单位，创新协方差也不能照搬。前一种设计若共享样本污染，重复次数增加并不能消除污染；后一种设计若环境发生变化，记录间差异也不能全部视为独立误差。可以先在少数具有完整重复结构的动物上估计相应协方差，再明确哪些分量能够推广到大规模资料。这样得到的条件信息增量具有测量机制的支持，而不是仅由分析软件默认的残差形式决定。

34.19 删除记录与降权操作的影响函数

新增资料有时能够用低秩更新处理，删除和纠错也有相应的精确表达。为了把核心问题说清楚，考虑一个已白化的线性高斯子问题。参数向量 $\mathbf{b}$ 可以包含适当约束后的固定效应与随机效应坐标，记录模型为 $y_i = \mathbf{x}_i^T \mathbf{b} + e_i$ ，误差方差为一。随机部分的先验精度记为 $\mathbf{J}$ ，并假设总精度矩阵正定。令记录权重为 w_i ，则

$$\begin{aligned}\mathbf{H} &= \mathbf{J} + \sum_i w_i \mathbf{x}_i \mathbf{x}_i^T, \\ \mathbf{q} &= \sum_i w_i \mathbf{x}_i y_i, \quad \hat{\mathbf{b}} = \mathbf{H}^{-1} \mathbf{q}.\end{aligned}$$

将某条记录权重作一个微小改变，对正规方程直接微分。由于该记录同时改变左侧精度与右侧信息向量，不能只对右侧求导。整理后得到

$$\frac{\partial \hat{\mathbf{b}}}{\partial w_i} = \mathbf{H}^{-1} \mathbf{x}_i (y_i - \mathbf{x}_i^T \hat{\mathbf{b}}).$$

这个式子把影响分为三部分：记录的拟合残差、它在参数空间中的方向，以及当前资料对该方向的支撑。残差大不是高影响的充分条件；某条记录残差不大，却可能位于几乎没有其他资料支持的方向。对于具体目标 $\mathbf{a}^T \mathbf{b}$ ，只需左乘 $\mathbf{a}^T$ ，便得到直接面向遗传比较的影响函数，无须把所有参数变化压成一个无法解释的总距离。

设原权重为一，令 $\mathbf{P} = \mathbf{H}^{-1}$ 、 $r_i = y_i - \mathbf{x}_i^T \hat{\mathbf{b}}$ ，并定义条件杠杆量。完整

删除的效应可以用秩一求逆恒等式精确表示。

$$h_i = \mathbf{x}_i^T \mathbf{P} \mathbf{x}_i,$$

$$\hat{\mathbf{b}}_{-i} - \hat{\mathbf{b}} = -\frac{\mathbf{P} \mathbf{x}_i r_i}{1 - h_i}.$$

相应的条件协方差增量为

$$\mathbf{P}_{-i} - \mathbf{P} = \frac{\mathbf{P} \mathbf{x}_i \mathbf{x}_i^T \mathbf{P}}{1 - h_i}.$$

分母揭示了一个重要边界：当杠杆量接近一时，该记录可能接近某个方向的唯一信息来源。删除它并非普通的小幅扰动，局部一阶近似也可能失效。若删除后精度矩阵不再可逆，应把结果报告为识别结构发生变化，而不是将发散数值当作特别大的普通影响值。对于未加先验的固定效应，删除唯一一个场站连接记录尤其可能触发这种情况。

独立手算例采用两个参数、单位先验精度和三条设计行，观测分别为二、四、一。

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{H} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

全部资料给出的均值为 $(1.625, 1.125)^T$ 。第二条记录的拟合值为二点七五，残差一点二五，杠杆量二分之一；将其删除，均值变化为 $(-0.625, -0.625)^T$ ，新均值为 $(1, 0.5)^T$ 。直接只用第一、第三条记录重新求解也得到相同结果。这种双路径计算验证了删除公式的方向和分母，优于只看两次软件运行是否都报告收敛。

如果只把第二条记录从四纠正为三，设计和方差不变，则变化直接为 $-\mathbf{P} \mathbf{x}_2$ ，不用删除分母。纠正数值与删除整条记录改变的是不同对象：前者保持信息精度，后者同时失去一个约束方向。把二者混为同一类“异常值处理”，会误解纠错之后可靠度应否变化。对于批次错误，应使用对应记录块进行联合删除；逐条影响很小，并不保证一个高度相关批次的联合影响也小。

Cook 关于线性回归影响诊断的经典研究说明，残差与杠杆需要共同考虑 (Cook, 1977)。本节在明确的惩罚二次型下直接推导面向预测目标的更新，而不把某个通用距离阈值当作删除规则。高影响可以来自正确且稀缺的桥梁记录，删除它反而损害评定。影响分析的科学用途是定位需要核验的证据及其作用路径，是否更正或剔除仍应依靠测量事实、身份记录和事前质量规则。

对相关残差进行白化时，还存在一个解释上的陷阱。白化后的某一行通常是多条原始记录的线性组合；删除这条白化行，并不等于删除一只动物的原始称重。因此，上面的逐行公式只有在行对应所研究的删除单位时才能直接使用。若原始误差相关而目标是删除一整个栏位，应在原始协方差分块后作条件消元，或者重新形成保留资料的似然。保留资料的精度矩阵通常不是完整精度矩阵的相应主子块。这个差别与系谱边际化完全同源：逆矩阵描述条件联系，删除变量要求边际化。忽视这一步，会使看似精确的快速影响诊断回答另一个问题。

34.20 有效信息必须扣除相关和待估环境方向

“有效样本量”只有在规定目标、误差尺度和估计方式之后才有清楚含义。考虑多条记录共同测量一个未知均值，模型为 $\mathbf{y} = \mathbf{1}\mu + \boldsymbol{\epsilon}$ ，误差协方差 $\mathbf{R}$ 已知且正定。最大似然和广义最小二乘给出相同均值估计，其信息量与方差分别为

$$\mathcal{I}_{\mu} = \mathbf{1}^{\top} \mathbf{R}^{-1} \mathbf{1}, \quad \text{Var}(\hat{\mu}) = \mathcal{I}_{\mu}^{-1}.$$

记录的实际权重不是由行数直接决定，而是由精度矩阵行和决定。

$$\hat{\mu} = \mathbf{w}^{\top} \mathbf{y}, \quad \mathbf{w} = \frac{\mathbf{R}^{-1} \mathbf{1}}{\mathbf{1}^{\top} \mathbf{R}^{-1} \mathbf{1}}.$$

若两条记录方差都是四，协方差为二，则每条权重为二分之一，平均值方差为三，信息量为三分之一。以一条方差为四的独立记录作为比较单位，等效独立记录数为四分之三的倒数，即四除以三，而不是二。这里的“等效”只针对共同均值；同一协方差对两条记录之差提供的精度不同，不能把这个

数字用于所有遗传对比。

$$\mathbf{R} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}, \quad n_{eq} = 4\mathcal{I}_\mu = \frac{4}{3}.$$

在交换相关结构下，可以把这个结果推广到任意记录数。设每条记录方差为 σ^2 ，任意两条相关为 ρ ，且相关矩阵正定，则共同均值信息量为

$$\mathcal{I}_\mu = \frac{n}{\sigma^2\{1 + (n-1)\rho\}}.$$

当正相关固定时，增加同类记录的边际收益递减。负相关在合法范围内则可以提高共同均值精度，因为误差具有抵消结构；因此“相关一定减少信息”也不是无条件真理。需要问相关沿着哪个目标方向、由什么测量机制产生，不能只将相关系数绝对值代入一个折损公式。接近奇异边界时，某些线性组合可能几乎无误差，另一些方向却信息很弱。

更实际的障碍来自待估环境效应。设关注参数为 γ ，同时需要估计环境参数 η ，观测均值为 $\mathbf{X}\gamma + \mathbf{Z}\eta$ 。完整信息矩阵分块以后，消去环境参数所剩的有效信息为

$$\mathcal{I}_{\gamma \cdot \eta} = \mathcal{I}_{\gamma\gamma} - \mathcal{I}_{\gamma\eta}\mathcal{I}_{\eta\eta}^{-1}\mathcal{I}_{\eta\gamma}.$$

这个舒尔补表达的不是资料被机械丢掉，而是同一变化可能同时由遗传与环境解释，因此不能全部算给关注参数。若两参数的完整信息矩阵为 $\begin{bmatrix} 5 & 4 \\ 4 & 4 \end{bmatrix}$ ，把环境当作已知会给关注参数信息五；正确允许环境未知后，信息只剩一，对应方差从五分之一增至一。数值完全相同的一批记录，因为需要回答的估计问题不同，精度可以相差五倍。

这种计算还能判断何时允许压缩记录。在已知协方差、共同均值是唯一未知量的高斯模型中，精度加权和及其精度构成充分的信息摘要。以这两个量代替整组记录，不损失该均值的似然信息；只保存普通平均而不保存误差方差，一般做不到这一点。

$$q = \mathbf{1}^T \mathbf{R}^{-1} \mathbf{y}, \quad J = \mathbf{1}^T \mathbf{R}^{-1} \mathbf{1}, \quad \ell(\mu) = \mu q - \frac{1}{2} J \mu^2 + \text{常数}.$$

一旦还要估计年龄趋势、设备漂移或组内方差，原来的两项摘要通常不再充分。压缩是否安全必须相对于后续模型判断。把每只动物全年传感器记录预先压成一个均值，可能保留全年平均的信息，却删除疾病前后变化和测量精度变化的信息。可重复评定的数据体系应保存能够重新形成所需充分统计量的原始记录，或者明确声明已经不可逆地放弃了哪些研究对象。

当一项环境效应本身具有随机先验时，扣除公式的环境信息块需要加上相应先验精度。先验越强，环境越接近已知，关注参数得到的有效信息越接近未扣除的上界；先验越弱，结果越接近完全依靠设计分离环境的情形。这个连续变化说明，数据支持与先验支持可以在同一个公式里被区分。对于跨场比较，不能因为强先验下标准误较小，就声称已经建立了更多遗传连接。报告时应说明精度改善来自新增交叉记录，还是来自对场效应施加了更强的分布约束；二者对未来新场的可迁移性具有不同含义。

34.21 新测定的价值取决于条件方向和成组冗余

信息增量公式可以进一步变成测定设计准则。假设旧资料下目标育种值 u 的条件方差为一，新测定直接观察 u 加方差为四的独立误差。在获得 n 次这样的记录后，后验精度等于旧精度加记录精度之和，因此

$$C_n = \left(1 + \frac{n}{4}\right)^{-1}.$$

第一条记录使误差方差从一降至零点八，第二条使其降至三分之二。两次的减少量分别为五分之一与十五分之二。这个简单例子说明，新测定的价值应在已经拥有的信息条件下计算，不能把每条记录的首次价值重复相加。对资源规划而言，平均每条记录的收益与下一条记录的边际收益也不是同一个数。

$$C_n - C_{n+1} = \frac{1/4}{(1 + n/4)[1 + (n + 1)/4]}.$$

如果两次新测定受到共同批次影响，其残差协方差改为上一节的矩阵，联合新记录的信息量为三分之一，更新后目标方差为四分之三，明显大于独立测量时的三分之二。两条记录的边际方差完全一样，差别全部来自共同误

差。若供应商只提供“测量重复性高”的摘要而不说明批次相关，便不足以估计新增测定对遗传评定的真实价值。

$$C_{batch} = (1 + \mathbf{1}^T \mathbf{R}^{-1} \mathbf{1})^{-1} = \frac{3}{4}.$$

对于多个候选测定和多个目标，可以给定对称半正定权重矩阵 $\mathbf{W} \succeq 0$ ，以目标加权总误差减少作为准则。这里的非负性是二次型非负，并非要求每个矩阵元素非负。它只衡量所规定的平方损失，并不自动等于经济价值。

$$V(\mathcal{B}) = \text{tr}(\mathbf{W} \mathbf{K}_{\mathcal{B}} \mathbf{S}_{\mathcal{B}}^{-1} \mathbf{K}_{\mathcal{B}}^T).$$

如果只关心几个核心公羊之间的差， $\mathbf{W}$ 应由这些对比向量构造；若关心全群遗传趋势，则需要对应的加权平均方向。用单位矩阵作为默认权重，相当于对所有坐标误差同等重视，这是一项实质选择。候选群体大小改变时，迹的数值也会改变，比较不同方案前应固定目标集合或说明标准化方式。

考虑两个候选新测定都与同一家系均值高度相关。单独评价时，两者都可能显示较大收益；联合购买后，第二个的条件创新却很小。相反，两项测定可能各自不直接预测目标，但合在一起能够消除干扰。例如 $z_1 = u + v$ 和 $z_2 = v$ ，其中 u, v 独立且方差均为一，目标为 u 。单独观察第二项对目标没有信息，联合观察却能用差值完全恢复目标。这个无测量误差的教学例子展示了互补性。

$$\text{Cov}(u, z_2) = 0, \quad u = z_1 - z_2.$$

因此，按单项收益从高到低选测定并不在所有协方差结构下保证最优。要获得贪心算法的保证，需要额外的结构条件；没有这些条件时，应直接评价候选批次，或者至少检查关键测定之间的条件互补。将测定费用纳入以后，最简单的净收益准则为价值减费用，但应让两者处于同一损失或货币尺度。

$$\mathcal{B}^* \in \arg \max_{\mathcal{B} \in \mathcal{A}} \{V(\mathcal{B}) - \lambda \text{cost}(\mathcal{B})\}.$$

还应区分预测精度的价值与改变行动的价值。某项测定可以显著降低一个已确定不会使用个体的误差，却几乎不改变最终配种；另一项只略微改善

两个边界候选的比较, 就可能改变大量后代的亲本配置。前者适合以误差减少衡量, 后者需要第 36 章的决策信息价值。资料建设由此形成两个连续层次: 先证明新增测定提供了目标相关的条件信息, 再判断这些信息能否改变受约束行动并抵偿成本。

测定分配还受到信息到达时间限制。一个预期信息价值很高、但只能在配种结束后获得结果的检测, 对当前决策没有同样价值。可以先按截止日前成功获得结果的概率折算预期收益, 但这种简单乘法仅在成功到达与潜在结果独立、失败时处理规则固定时成立。若困难样本更容易延迟或检测失败, 到达机制本身具有选择性, 应将成功与失败两种结果都纳入设计分布。对同一预算, 增加动物数、增加技术重复、改善身份核验和缩短回报时间分别改变不同的信息环节。比较方案时保持这些环节可见, 比以一个总检测量概括投入更能解释最终评定改善。

34.22 身份不确定性和版本变化的概率传播

当一份样本可能属于两只不同动物时, 不能将身份概率直接当作普通记录权重。记录权重描述同一观测方程的精度, 身份概率描述不同观测方程之间的不确定性。两种处理只有在特殊近似条件下才可能接近。设离散身份状态为 M , 其在全部现有证据下的概率为 π_m , 每种身份状态给出目标育种值条件均值 $\mathbf{m}_m$ 和协方差 $\mathbf{C}_m$, 则完整条件分布是混合。

$$p(\mathbf{u} | D) = \sum_m \pi_m p(\mathbf{u} | D, M = m).$$

对混合分布先求条件期望, 再用全方差分解, 得到

$$\bar{\mathbf{m}} = \sum_m \pi_m \mathbf{m}_m,$$

$$\text{Var}(\mathbf{u} | D) = \sum_m \pi_m \mathbf{C}_m + \sum_m \pi_m (\mathbf{m}_m - \bar{\mathbf{m}}) (\mathbf{m}_m - \bar{\mathbf{m}})^\top.$$

第二项反映不同身份解释之间的分歧。只把各身份模型的 PEV 平均, 会遗漏这部分不确定性; 只选择最可能身份, 则同时丢掉其他解释及其后果。

这里的概率必须已经考虑可用身份和表型证据。如果先依据条码给出概率,随后使用表型而不更新概率,还需明确这是一种近似而非完整贝叶斯处理。

独立手算例设两只动物先验独立、方差均为一,一条数值为二、测量误差方差为一的记录,属于第一只或第二只的后验身份概率分别为四分之三和四分之一。两种身份状态下的育种值均值分别为 $(1,0)$ 和 $(0,1)$,协方差分别为 $\text{diag}(1/2,1)$ 和 $\text{diag}(1,1/2)$ 。混合均值为 $(3/4,1/4)$,而完整协方差为

$$\mathbf{C}_{mix} = \begin{bmatrix} 13/16 & -3/16 \\ -3/16 & 17/16 \end{bmatrix}.$$

负的误差协方差有明确来源:当这条高记录属于第一只时,对第二只的证据就消失;属于第二只时则相反。它不是两只动物真实加性关系为负。第二只的条件方差还略大于其先验方差,这并不违反平均信息增加规律,因为给定一个具体数据结果时,身份混合可能增大某个坐标的不确定性;将结果再对数据分布平均,才恢复预期风险不会因正确使用信息而增加的结论。

版本变化也需要类似的对象分离。设旧资料 and 旧参数为 (D_0, θ_0) ,新版为 (D_1, θ_1) ,预测记为 $m(D, \theta)$ 。总变化可以沿两条顺序路径分解:先更新资料再更新参数,或者先更新参数再更新资料。两条路径的分项通常不同,因为资料与参数存在交互。

$$\Delta = m(D_1, \theta_1) - m(D_0, \theta_0).$$

为了避免解释完全取决于先后顺序,可以对两种顺序的边际贡献取平均。资料归因与参数归因分别为

$$\begin{aligned} \Delta_D &= \frac{1}{2}\{m(D_1, \theta_0) - m(D_0, \theta_0)\} \\ &\quad + \frac{1}{2}\{m(D_1, \theta_1) - m(D_0, \theta_1)\}, \\ \Delta_\theta &= \Delta - \Delta_D. \end{aligned}$$

例如育种值先验方差为一,预测为 $y/(1+r)$ 。记录由二纠正为四,残差方差由三改为一,预测由零点五变为二,总变化一点五。两种顺序平均后,

资料和参数各归因零点七五。这是对指定反事实计算的对称记账，不是因果效应证明。若还改变了关系基准、候选集合或目标定义，必须增加对应状态，或者承认版本之间并非同一个统计对象。只有输入状态和计算规则都能重建，育种值变化才能被解释为可复核的证据变化。

这种概率传播也给数据审核提供了优先级依据。如果两种可能身份在关键目标上给出几乎相同的预测，身份不确定性对该次决策的影响可能很小；如果它们把高使用份额分配给完全不同的家系，重复采样核验的价值就可能很高。审核资源应根据目标相关分歧安排，而不能只按总体错误率平均投入。与此同时，不能把低决策影响解释为身份事实已经明确：历史系谱、疾病追踪和后续研究仍可能需要准确身份。统计影响分析决定的是当前核验优先顺序，身份管理则保留真实实体的一致记录，二者服务范围相交但不相同。

34.23 习题与详细解答

习题 34.1 时间边界辨析。候选羊在三月分型，五月称重，七月复核体重，十一月获得后裔记录。若目标是重建六月末实际可作出的选择，哪些资料可以使用？若目标改为研究“完整清理后的理想六月预测”，结论是否相同？

解答。三月已经可得并通过所需审核的基因型可以使用。五月体重是否可用取决于六月时是否允许使用未复核记录；如果制度要求七月复核后才进入评定，就不能当作六月已知。十一月后裔记录不得进入六月预测。理想清理场景可以使用后来确认的身份或纠正后的历史测量，但必须明确这是一种回顾性理想条件，不能用其性能宣称当时系统已经达到同样水平。两个场景应分别保留。

习题 34.2 主键错误计算。三只动物的真实育种值为负一、零、一，模型正确预测相同数值。若连接时首尾两只动物交换，相关系数是多少？这能否通过检查预测均值和方差发现？

解答。错配预测为一、零、负一，与真实值的相关为负一。预测均值仍为零，方差也保持不变，因此只检查总体分布无法发现这一交换。必须核对

身份映射，或利用独立的亲缘、性别和样本证据检查连接。这个例子说明总体统计摘要不能代替逐对象对应关系。

习题 34.3 重复记录的可靠度。在 $y_{ij} = \mu + u_i + p_i + e_{ij}$ 中，三个方差依次为四、三、五，均值已知。求一次记录、五次记录均值和无限多次记录对应的育种值预测可靠度，并解释极限。

解答。可靠度为 $4/(4 + 3 + 5/n)$ 。三种情形分别为三分之一、二分之一和七分之四。暂时误差随次数增加而减少，永久环境不会被平均消除，所以无限多次记录也不能仅凭个体均值完全分离遗传与永久环境。若将永久环境错误地当作每次独立误差，五次记录的可靠度会被高估为约零点七一四。

习题 34.4 单位变换。将两个性状从千克和日改为克和小时，写出协方差矩阵的变换，并说明经济权重如何调整才能保持总目标不变。

解答。取 $\mathbf{D} = \text{diag}(1000, 24)$ ，新协方差为 $\mathbf{DSD}'$ 。若原目标为 $\mathbf{a}'\mathbf{u}$ ，新育种值为 $\mathbf{u}^* = \mathbf{D}\mathbf{u}$ ，则新权重为 $\mathbf{a}^* = \mathbf{D}^{-1}\mathbf{a}$ ，从而 $(\mathbf{a}^*)'\mathbf{u}^* = \mathbf{a}'\mathbf{u}$ 。只改变对角方差或只改变记录值都不完整。

习题 34.5 非法相关矩阵。三个相关系数分别为零点九、零点九和负零点九，为什么它们不能与单位对角组成合法相关矩阵？是否可以简单删除负相关项？

解答。该矩阵具有负零点八的特征值，存在负方差方向，违反半正定性。任意删除某个相关会改变科学假设，不能作为无说明的修复。应核查三项估计是否来自相同总体和相容资料，考虑联合估计、带约束估计或明确报告的矩阵修正，并评估修正对目标的影响。

习题 34.6 验证方案设计。一个模型计划用于从未合作的新场站，但研究者随机把已有各场站动物分成训练和验证。这个设计主要评估什么？如何补充更相关证据？

解答。随机切分主要评估已知场站分布内、通常仍保留家系与环境联系的个体预测，不能充分代表新场站迁移。应增加整场站留出或独立新场站验证，保留真实可用的亲缘与分型信息，并说明新场站固定环境效应如何处理。可以同时报告两种设计，但不能用较容易的设计替代部署问题。

习题 34.7 可复现与正确性。某程序在两台计算机上给出完全相同的育种值，是否足以证明模型正确？提出三项能提供不同证据的检查。

解答。不足以。相同输入和相同错误也能稳定复现。可以检查身份与时间边界，确认数据回答正确问题；用理论等价但实现不同的方程核验关键预测与 PEV；在已知真值的模拟或可手算边界例子中检查偏差和覆盖。三项分别针对输入、数值实现和统计行为，互相不能替代。

习题 34.8 资料更新解释。两次评定中某公羊排名上升，同时新增了后裔记录、更正了父本、改变了参考群体均值和方差参数。如何设计比较，避免把全部变化归因于新算法？

解答。应建立逐项更新的对照批次：先在旧模型下加入新记录，再更新系谱，再在共同基准上调整参数或模型，并记录每一步的预测变化。顺序可能影响非线性分解，所以不必宣称得到唯一因果贡献，但可以明确主要变化来源。至少应把资料增加、资料更正、模型变化和基准平移分开，不直接把最终名次变化当作算法改进证据。

从系谱 BLUP 到 GBLUP：一个可复算的肉羊教学实验

35.1 用一个已知真值的世界检验预测

在真实育种资料中，研究者通常只能看到表型和逐步增加的后代信息，看不到动物的真实加性育种值。这使模型比较面临一个根本困难：模型之间的差异可能来自预测水平，也可能来自验证代理量的误差与信息重叠。模拟实验通过人为规定遗传结构和环境过程，创造一个真实育种值已知的世界，使某些问题可以得到直接检验。但这个优势伴随明确边界：模拟结论依赖生成条件，不能自动代表真实群体。

本章比较两种共享其他条件的预测方法。系谱 BLUP 以系谱关系矩阵 $\mathbf{A}$ 表示加性协方差，GBLUP 以基因组关系矩阵 $\mathbf{G}$ 表示协方差。训练个体、表型、固定效应和方差尺度保持相同，主要差别来自遗传关系信息。这样的对照比同时更换资料、模型和调参规则更容易解释：若表现不同，可以更直接地讨论实际标记相似性所增加的信息。

实验面向一个肉羊育种场景，但不使用真实牧场观测。这里的生长表型以标准化连续性状表示，不对应某个规定品种的千克体重；基础加性方差和残差方差是教学设定，不是生产估计。模型中没有疾病淘汰、选择性分型、饲养阶段转换和染色体图谱。省略这些因素不是认为它们不重要，而是先把一条基础推断链条做清楚，再逐项研究设定偏离的后果。

本章有三个层次的检验。第一层是可手算的单个体和双个体例子，用来理解收缩与亲缘借用；第二层是两百八十只动物、三十次重复的完整实验，用来观察预测与校准的抽样分布；第三层是标记缺失、方差错设和身份错配等控制扰动，用来区分“模型有用”和“模型在什么条件下会失败”。三个层

次互相补充，小例子揭示逻辑，重复实验展示波动，扰动实验检验边界。

模拟设计遵循一个简单原则：每次只改变能够明确解释的条件。研究标记数量时，保持真实育种值仍由完整的二百四十个位点生成；研究残差方差错设时，保持原始表型不变，只改变拟合假设；研究样本错配时，改变关系矩阵与个体身份的对应，而不改变矩阵自身的数值谱。这样才能知道性能变化源于什么，而不是把所有困难混成一个笼统的“复杂场景”。

读者不应把本章当成寻找最高相关系数的竞赛。对育种决策而言，排序、预测幅度、误差尺度和不确定性都有意义。一个模型可能保持较高相关，却给出过于分散的 EBV 和过窄的区间；另一个模型可能相关略低，但在某个受限决策中更稳妥。因此每一步都需要同时问：预测了什么、使用了哪些信息、误差如何计量，以及这些结果能支持哪一种后续行动。

35.2 群体结构与世代生成

教学群体共两百八十只动物，包括四十只基础个体、一百六十只第一代和八十只第二代。基础群体公母各二十只，后续两代也保持公母数量相同。第一代的父母从基础群体按性别随机抽取，第二代父母从第一代按性别随机抽取。同一亲本可以产生多个后代，因此自然形成半同胞和全同胞关系。这个结构足以展示家系信息如何进入预测，又能在普通计算机上快速复算。

个体编号依生成顺序从零到二百七十九。基础个体为零至三十九，第一代为四十至一百九十九，第二代为二百至二百七十九。所有亲本编号都早于后代编号，因此系谱天然具有合法拓扑顺序。程序仍保留检查这一条件的意识，因为在真实资料中不能假定文件顺序总是正确。性别编码仅服务本例，零表示公、一个表示母，不意味着零是缺失。

父母随机抽取没有施加遗传选择。若高育种值公羊被赋予更高繁殖份额，后代遗传分布和家系大小会改变，系谱与表型资料也会带有选择历史。本章先排除这一因素，以便解释关系信息的作用。后续研究可以加入选择，但必须同时保存用于选择的信息，否则很难判断模型是否恰当地利用了选择依据。

基础个体在系谱意义上被设为互不相关且不近交。这规定了 $\mathbf{A}$ 的基准。基因型则从参考频率随机生成, 因此有限标记下基础个体之间的 $\mathbf{G}$ 非对角元素不会恰好全为零。两者之间的差异并不构成矛盾: 系谱提供对遗传抽样取平均后的期望关系, 标记记录一次实际抽样的相似性。随着位点和群体设定变化, 这种实际偏离的规模也会变化。

训练集包含基础群体和第一代, 共两百只; 验证集为第二代八十只。训练个体有表型, 验证个体的表型在程序中虽然已经生成, 却不参与拟合。验证时使用其真实育种值计算指标。这个时间划分对应“已有父母及相关群体记录, 预测下一代年轻个体”的任务, 不代表跨品种或完全无亲缘新群体预测。

本章允许所有动物在预测时已有基因型, 包括第二代候选者。这符合一种常见的决策前分型场景。如果实际任务只能分型少数候选者, 或者某些历史动物没有基因型, 模型和验证流程需要相应调整。不能先在全分型条件下得到表现, 再把它称作部分分型系统的预期结果。单步方法可以处理更复杂的信息结构, 但并不消除对资料可用时点的要求。

群体规模并不是为了代表最佳育种方案。四十只基础个体和两代后代使家系关系较近, 训练信息能够通过直接亲缘传递给候选者。若增加世代间隔或引入外来动物, 基因组与系谱方法的相对表现可能改变。读者应把群体结构视为实验条件, 而不是某种建议的生产种群规模。

35.3 双等位标记与孟德尔抽样

每个位点 j 的参考等位基因频率 p_j 从零点一五至零点五的均匀分布抽取。基础个体的剂量 M_{ij} 服从参数为二和 p_j 的二项分布, 因此剂量可以为零、一或二。其期望为 $2p_j$, 方差为 $2p_j(1-p_j)$ 。这一步提供了一个清楚的参考总体, 不需要从有限基础样本中重新估计频率, 从而暂时隔离频率估计误差。

子代从父母各获得一个等位基因。若父本剂量为 m_s , 它传递参考等位基因的概率为 $m_s/2$; 母本同理。条件于父母剂量, 子代剂量的期望为

$(m_s + m_d)/2$ ，但实际结果仍有抽样差异。两个剂量均为一的杂合亲本交配，子代剂量为零、一、二的概率分别为四分之一、二分之一和四分之一。全同胞因此不必拥有同样的位点组合。

条件方差同样可以直接推导。父母传递独立时，子代剂量的条件方差为

$$\frac{m_s}{2} \left(1 - \frac{m_s}{2}\right) + \frac{m_d}{2} \left(1 - \frac{m_d}{2}\right).$$

若两亲本都纯合，方差为零；若一方杂合，方差为四分之一；若双方都杂合，方差为二分之一。这个简单结果说明孟德尔抽样大小取决于亲本的具体基因型，而系谱关系矩阵通常以平均意义表示这种遗传抽样。

本章位点之间独立生成并独立传递，没有使用染色体位置或重组率。因此，它不模拟真实群体中由连锁、选择和历史重组形成的单倍型结构。随着后代由共同亲本产生，样本层面仍可能出现位点关联，但它不是根据真实染色体图谱构建的连锁模型。将本实验用于比较实际低密度芯片设计时，必须认识到这个限制。

独立位点模型的教学优点是容易追踪方差来源。每个位点对总加性方差的贡献可以由频率与效应方差说明，未观测位点的贡献也可以被明确保留。若在减少可观测标记时同时删去这些位点的真实效应，便把“信息减少”误写成“遗传结构变简单”。本章后面的密度实验坚持保留完整真实结构，避免这种混淆。

位点剂量本身不是育种值。一个参考等位基因可能增加或降低目标性状，取决于其效应符号；频率高也不意味着有利。生成器会为每个位点抽取具有正负可能的加性效应，再把中心化剂量与效应相乘。把剂量简单求和只在所有位点等效且方向一致的特殊设定下才有生物学意义。

对于真实分型资料，参考频率还涉及群体基准和可用信息。本章从生成器直接知道 p_j ，是一种理想条件。如果改用训练样本频率，应重新计算中心化矩阵并检查基准变化；若用全部候选频率，则需要说明部署时这些基因型是否可用。频率选择不是一个可以从文稿中省略的小细节，因为它参与定义关系矩阵和遗传均值。

35.4 从标记效应生成真实育种值

为避免与随机效应关联矩阵混淆，本章用 $\mathbf{W}$ 表示中心化标记矩阵。设

$$\mathbf{W} = \mathbf{M} - 2\mathbf{1}\mathbf{p}', \quad s = \sum_j 2p_j(1 - p_j).$$

标记效应独立服从均值零、方差 $1/s$ 的正态分布，真实育种值为

$$\alpha \sim N(\mathbf{0}, \mathbf{I}/s), \quad \mathbf{u} = \mathbf{W}\alpha.$$

在给定全部基因型时，育种值协方差恰好为 $\mathbf{W}\mathbf{W}'/s$ ，因此定义 $\mathbf{G} = \mathbf{W}\mathbf{W}'/s$ 。这个等式把生成模型与 GBLUP 的协方差假设直接连接起来。

为什么用 s 作尺度？对基础参考群体，单个位点中心化剂量的方差是 $2p_j(1 - p_j)$ ，乘以效应方差 $1/s$ 后，所有位点贡献相加为一。因此基础尺度上的加性方差期望为一。有限样本中实际育种值的样本方差不会精确等于一，基因组关系对角也不必完全相同；它们随实际剂量抽样和效应抽样而变化。

这里所有二百四十个位点都具有随机加性效应，且完整 GBLUP 使用了这些位点。模型因此享有一个有利条件：观测标记与生成效应的位点完全对应，效应分布也与高斯协方差假设一致。这并不是为了证明 GBLUP 在所有情形下优越，而是先确认在它适用的理想条件下能否按理论工作。若连这一层都不能复现，就没有必要立即讨论更复杂遗传结构。

给定基因型时的高斯性与仅给定系谱时的分布不同。条件于 $\mathbf{W}$ ， $\mathbf{u}$ 是正态效应的线性变换，所以严格服从相应多元正态分布；若把有限位点基因型也积分掉，得到的是不同协方差条件分布的混合，不必严格等于高斯无穷小模型。这个区别会影响预测区间的精确解释，后面讨论 ABLUP 覆盖率时需要保留。

加性育种值的零点由参考频率决定。某一有限群体的平均育种值可以偏离零，并不说明生成器出错。若改成按每次样本均值强制中心化真实育种值，就改变了重复实验的随机结构，也可能掩盖整群平均偏移。为研究校准截距，本章保留相对于统一生成基准的育种值，不对每个验证群体单独重新归零。

效应方差设为相同是另一项简化。真实遗传结构可能包含少数大效应位点、不同频率与效应之间的关系、优势或上位互作。可以在后续模拟中改变 α 的分布，但应保持所比较模型的假设清楚。如果新生成器恰好与某个新方法的先验完全一致，应把它列为该方法的有利场景，并同时设置偏离场景，避免以单一匹配条件作普遍性能结论。

生成真实育种值以后，不应把它用于训练、质控或模型选择。它是模拟研究的验证工具，不是部署输入。程序可以保存它供检查，但分析函数的接口最好只接收表型、设计矩阵和关系矩阵。将真实值与可用资料明确分开，有助于防止在复杂模拟开发中无意使用“现实里不可能知道”的信息。

35.5 系谱关系矩阵的逐项构造

基础个体的系谱关系矩阵为单位矩阵。对父母分别为 s 和 d 的个体 i ，与先前个体 j 的加性关系递推为

$$A_{ij} = \frac{A_{sj} + A_{dj}}{2}, \quad j < i.$$

其对角为 $A_{ii} = 1 + A_{sd}/2$ ，并利用对称性填入 $A_{ji} = A_{ij}$ 。这两个式子分别描述后代与既有个体的平均遗传联系，以及父母亲缘导致的自身近交。它们要求亲本已经出现在计算顺序中。

一个四个体例子可以手算。设个体一和二是无关基础亲本，个体三和四是它们的两个后代。每个后代与每个亲本的关系为二分之一，两个后代之间的关系也为二分之一，四个对角均为一。矩阵中后代之间的二分之一是全同胞期望关系，不表示每个位点都共享恰好一半等位基因。有限基因组中的实际共享比例会围绕这个期望变化。

若两个无关亲本各自与同一个公羊产生后代，这些后代为半同胞，期望加性关系为四分之一。若父母本身有亲缘，后代对角大于一，系谱近交系数为 $A_{sd}/2$ 。这个系数相对于指定基础群体定义；基础祖先中的未记录亲缘不会因为对角设为一就真实消失。解释近交与共祖时，始终需要说明基准。

系谱矩阵可以作为一种信息压缩：它把所有已记录祖先路径对加性协方差的影响汇总到两两关系中。对于经典加性动物模型，不需要在预测方程里

逐条展开祖先路径。但这种压缩依赖模型范围；母体效应、共同窝环境或优势关系不能自动由同一 $\mathbf{A}$ 完全表示。若生物学问题需要这些分量，应建立相应结构而不是让加性关系承担所有家系相似性。

在本实验中， $\mathbf{A}$ 与 $\mathbf{G}$ 都为两百八十阶矩阵。二者对角附近和家系区块都会出现相似结构，但 $\mathbf{G}$ 包含更多连续变化，也可能出现负非对角值。负值表示相对于指定参考基准的相似性低于平均，并不是生物学上存在“负祖先”。直接将所有负值截成零会改变协方差模型，不能作为常规清理动作。

关系矩阵的行列顺序必须与表型和个体映射一致。即使同时置换行与列，矩阵仍然对称，特征值也不变；如果忘记对对应动物身份作同样置换，预测就会使用错误关系。这种错误不能靠正定性检查发现。本章后面的错配实验专门利用这个性质，展示为什么数值合法性与生物学身份正确性是两项不同检查。




图 35.1 第一个预定重复的系谱与基因组关系。细线分开前两百只训练动物和八十只候选动物；图源为本章实际生成数据，颜色采用共同尺度

系谱关系与基因组关系的比较应围绕预测用途展开。矩阵之间相关很高，不意味着对某个年轻候选者提供相同信息；总体差异很大，也不一定都对目标性状有用。关键是关系矩阵怎样把训练表型与候选遗传值联系起来，以及这种联系是否与真实生成过程相容。下一步的 BLUP 表达式会把这一点直接写成矩阵乘积。

35.6 表型模型与已知参数的教学条件

表型由固定效应、真实育种值和独立残差相加而成：

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u} + \mathbf{e}.$$

本章 $\mathbf{X}$ 有三列，分别为截距、性别和两类饲养方案；固定效应向量取 $(10, 0.4, -0.3)'$ ，残差服从 $N(\mathbf{0}, 1.5\mathbf{I})$ 。饲养方案随机分配，并在各代出现相同类别，因此验证个体没有遇到训练中完全不存在的固定效应水平。

截距只是给表型提供一个易读的平均尺度，不影响加性方差的基础定义。性别效应零点四和方案效应负零点三是人为设置的系统差异。模型从训练表型估计这些效应，而不直接使用生成真值。即使模拟者知道真实参数，也应按照拟定部署方式估计，否则会把固定效应不确定性从实验中不当地删除。

基础加性方差期望为一，残差方差为一点五，所以参考遗传力为 $1/(1 + 1.5) = 0.4$ 。这个数值是生成尺度上的比率，不要求每个重复中样本育种值方差与残差样本方差之比都恰好相同。若人为把每次生成的 $\mathbf{u}$ 重新缩放到样本方差一，就会改变它相对于给定 $\mathbf{G}$ 的条件分布，本章不进行这种后处理。

两个比较模型都使用已知方差尺度一和一点五。这使实验主要聚焦关系结构，而不是小样本方差估计误差。在真实项目中，方差分量通常需要估计，可能落在边界，或者在不同群体间不稳定。把已知参数结果理解为实际评定可直接达到的精度是不恰当的；它更接近一个受控参照，后面再考察方差错设的影响。

如果省略性别固定效应，模型可能把公母平均差的一部分分配给遗传预测，尤其当性别与家系结构不平衡时。若饲养方案只出现在某个家系，也会出现环境与遗传混淆。本章通过随机分配和各代共享类别减少这种困难，但并未证明真实场站可以忽略它们。一个方法在平衡教学设计下工作良好，不能替代对真实数据连通性的检查。

残差独立同方差也属于简化。真实体重误差可能随日龄、设备或管理组变化，同窝个体还可能共享未建模环境。增加这些因素时，应明确它们进入

哪一层：个体永久环境、母体效应、栏位随机效应，还是残差相关。把所有家系相似性都交给 **A** 或 **G**，可能夸大遗传方差并改变预测解释。

本章特意生成了验证个体的表型，但拟合函数只接收训练索引对应的记录。一个简单的泄漏检查是，把全部验证表型替换为极大的任意数，再重新预测；若预测发生变化，就说明流程使用了不该使用的信息。在本章实现中，这种替换对育种值预测的影响为零。该检查只覆盖直接表型泄漏，仍需另外检查预处理和参数选择是否使用了未来信息。

35.7 单个体例子：收缩不是把信息丢掉

先暂时忽略亲缘和未知固定效应，只看一个已经扣除总体均值的记录 $y = u + e$ 。设加性方差为四，残差方差为六，观察到记录偏离均值三。线性预测系数为 $\text{Cov}(u, y) / \text{Var}(y) = 4/10$ ，因此预测育种值为一点二。模型没有把记录三全部解释为遗传，因为表型变异中还包括方差为六的环境分量。

预测误差方差为

$$PEV = 4 - \frac{4^2}{4 + 6} = 2.4.$$

相对于原先方差四，记录减少了一点六的不确定性。可靠度为 $1 - 2.4/4 = 0.4$ ，准确度为其平方根。这个结果与记录被乘以零点四的收缩系数在此特殊模型下相同，但不能因此把所有复杂模型的可靠度都等同于某个表面回归系数。

收缩的目的不是让预测接近某个管理者喜欢的平均值，而是在信息有限时平衡信号与噪声。若把表型偏差三直接当作育种值，个体层面的预测误差方差是残差方差六，比 BLUP 的二点四更大。若完全忽略记录预测为零，误差方差为四，也高于二点四。最优线性预测位于二者之间，利用信息但不把噪声当成确定事实。

这里的“最优”有明确范围：它针对给定均值、方差和线性预测类，以均方误差为准则。在联合正态条件下，这个线性预测也等于条件期望；若分布非正态，最佳线性预测仍可定义，但不一定等于所有可能函数中的最佳预测。区分这两个层次，可以避免把协方差推导的结论无条件推广到任意复杂

遗传结构。

当残差方差改变时，收缩也改变。残差越大，同样偏差三包含的遗传证据越弱，预测越接近零；残差越小，记录越接近真实育种值，预测越接近三。若使用错误方差比，预测可能依然与真值高度相关，却在幅度上系统失准。这为后面的方差错设实验提供了直观基础。

未知总体均值会改变问题。只有一个个体和一个记录，却同时要估计截距与该个体育种值时，资料无法像已知均值例子那样提供相同信息。混合模型通过随机效应均值和方差结构施加约束，但固定效应估计的不确定性仍应进入 PEV。将“总体均值已知”的手算公式直接套到只有很少组内比较的实际数据，会过度乐观。

生产解释也需要基准。预测一点二表示相对于指定基础均值的加性遗传偏离，不是保证后代体重一定增加一点二。如果该动物与平均水平配偶交配，在简单加性模型下，它对后代平均育种值的贡献是一半；实际表型还包含配偶遗传值、环境与其他模型分量。把个体 EBV 直接当作每只后代的确定增量，会把统计预测和遗传传递混淆。

单个体算例适合用于程序的最低检查。给定方差四和六以及记录三，独立实现应得到一点二和二点四。若结果不同，首先检查方差比、残差单位、目标定义和均值处理，而不应立即用更大的随机数据集掩盖差异。一个清楚的小例子常比一份复杂的收敛日志更能定位错误。

35.8 双个体例子：亲缘怎样改变信息权重

现在考虑两只有亲缘的动物，已扣除的固定均值视为已知。它们的遗传协方差矩阵为

$$\mathbf{K} = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix},$$

残差协方差为 $1.5\mathbf{I}$ ，表型偏差为 $(2, -1)'$ 。两个个体各自的表型噪声较大，但遗传值具有正相关。预测不是分别把每个记录乘以同一个系数，而是同时使用两条记录及其相关结构。

总表型协方差为对角二点五、非对角零点五的矩阵。其逆矩阵可以直接求得, 再乘以 $\mathbf{K}$, 得到预测权重矩阵

$$\mathbf{K}(\mathbf{K} + 1.5\mathbf{I})^{-1} = \begin{bmatrix} 0.375 & 0.125 \\ 0.125 & 0.375 \end{bmatrix}.$$

第一只预测为 $0.375 \times 2 + 0.125 \times (-1) = 0.625$, 第二只为 $0.125 \times 2 + 0.375 \times (-1) = -0.125$ 。

如果忽略亲缘, 两个记录会分别乘以 $1/(1 + 1.5) = 0.4$, 预测为零点八和负零点四。引入正亲缘以后, 第二只较高的亲属记录提供向上的信息, 第一只较低的亲属记录则提供向下的信息, 因此两个预测差异减小。这种变化不是简单把两只动物平均, 而是按遗传相关与残差大小决定借用权重。

两只动物的 PEV 对角均为零点五六二五。它们的预测误差还存在协方差, 不能只保存两个对角就认为差异分析已经完整。若要判断两只动物的真实育种值差, 需计算 $\text{Var}[(u_1 - \hat{u}_1) - (u_2 - \hat{u}_2)]$, 其中包含负的两倍误差协方差项。误差正相关时, 差值可能比把两个 PEV 独立相加得到的结果更精确。

亲缘借用也说明为什么重复信息必须被正确建模。如果两条表型来自同一记录的重复上传, 却被误认为两个相关动物的独立记录, 模型就会错误地增加信息。如果它们共享栏位环境而模型只给遗传协方差, 模型可能把共同环境解释成遗传联系。关系矩阵能利用正确的亲缘信息, 但不能辨别记录过程中的所有相似来源。

若其中一只动物没有自身表型, 它仍可通过与另一只的遗传关系得到预测。只有第一只记录二时, 第二只预测为 $0.5/(1 + 1.5) \times 2 = 0.4$ 。这个结果体现了系谱评定的基本能力: 未测个体可以借助亲属记录。但预测精度受到关系强度限制, 亲缘较远时, 同样记录提供的信息更少。

全同胞在没有自身或后代记录时, 若对训练群体的关系行完全相同, ABLUP 可能给出相同预测; 基因型则能够使它们的实际关系行不同, 从而区分一部分孟德尔抽样。区分的程度取决于标记信息和训练记录, 不是分型一完成就能确定全部真实差异。双个体例子把“借用亲属信息”和“识别个

体遗传抽样”这两种作用分开，为理解 GBLUP 的增量价值提供基础。

35.9 一般 BLUP 与固定效应不确定性

对任一种关系结构，令 $\mathbf{K}$ 表示全体动物的加性协方差，训练索引为 t 。训练表型协方差为 $\mathbf{V}_t = \mathbf{K}_{tt} + 1.5\mathbf{I}$ 。固定效应采用广义最小二乘估计：

$$\hat{\beta} = (\mathbf{X}_t' \mathbf{V}_t^{-1} \mathbf{X}_t)^{-1} \mathbf{X}_t' \mathbf{V}_t^{-1} \mathbf{y}_t.$$

随后全体动物的预测为

$$\hat{\mathbf{u}} = \mathbf{K}_{:t} \mathbf{V}_t^{-1} (\mathbf{y}_t - \mathbf{X}_t \hat{\beta}).$$

这个式子直接说明候选者如何从训练记录获得信息：候选与训练的协方差行先确定可借用的遗传联系，总表型协方差再处理训练记录之间的冗余和噪声，最后扣除估计固定效应。

将 $\mathbf{K}$ 换成 $\mathbf{A}$ 或 $\mathbf{G}$ ，其他步骤相同。GBLUP 并不是把每个标记单独检测后把显著位点加起来，而是通过整体关系结构进行联合收缩。它可以与标记效应模型在特定先验尺度下等价，但这种等价依赖正确的标准化和惩罚参数。忽略尺度对应，会得到看似相似但并不相同的预测。

令 $\mathbf{B} = (\mathbf{X}_t' \mathbf{V}_t^{-1} \mathbf{X}_t)^{-1}$ ， $\mathbf{Q} = \mathbf{K}_{:t} \mathbf{V}_t^{-1} \mathbf{X}_t$ ，则预测误差协方差为

$$\mathbf{E}_u = \mathbf{K} - \mathbf{K}_{:t} \mathbf{V}_t^{-1} \mathbf{K}_{t:} + \mathbf{Q} \mathbf{B} \mathbf{Q}'.$$

前两项是在固定均值已知时的信息更新，最后一项补回固定效应需要估计带来的不确定性。若把最后一项漏掉，模型可能仍给出相同 EBV，却低估 PEV。

这个公式中的 $\mathbf{K}$ 已经包括加性方差尺度，因此不能再随意乘一次遗传方差。本章尺度为一，使形式简洁；若实际模型写为 $\sigma_u^2 \mathbf{A}$ ，则应在全部相关位置使用这个协方差，而不是一部分使用关系、一部分使用协方差。很多实现错误不是矩阵维度不匹配，而是维度相同但单位和尺度不一致。

PEV 对角提供单个动物预测误差的方差，非对角提供误差之间的关联。对综合育种目标或亲本贡献组合，误差方差一般为相应权重向量的二次型。

只用个体 PEV 加权相加会忽略共享信息带来的误差相关。这个问题在第 36 章讨论方案不确定性时尤为重要, 因为多个候选者可能来自同一家系并共享同一组训练证据。

公式成立需要相应的线性模型假设。若方差参数由数据估计后代入, 得到的是条件于估计参数的插件式 PEV, 未必完整包含方差估计误差。若关系矩阵本身有身份错误或频率基准不相容, 代数运算也不会自动修复。应把“公式在指定模型下正确”与“指定模型充分描述现实”分开判断。

对于 GBLUP, 本章给定全部基因型后采用高斯标记效应和高斯残差, 因此模型条件分布与 PEV 解释相容。对于 ABLUP, 有限位点基因型被积分后的边际分布不必严格高斯, 基于正态分位数的区间具有近似性质。因此, 重复模拟的覆盖率是必要证据, 而不能仅因 PEV 公式形式正确就宣布每种区间精确有效。

35.9.1 从预测误差而不是估计量方差理解可靠度

容易混淆的另一个量是预测值本身在重复抽样中的方差。PEV 描述真实值与预测值之差, 而 $\text{Var}(\hat{\mathbf{u}})$ 描述预测值怎样随资料变化。在正确 BLUP 条件下, 二者与遗传协方差具有特定分解关系; 但不能在任意失准预测中直接用预测方差替代可靠度。把所有预测乘以二, 会使预测方差乘以四, 却显然不能凭空增加真实信息。

对单个目标, 在线性无偏预测及相应投影条件下, 误差与预测正交, 因而真实遗传方差可以分成预测方差与误差方差。这个几何关系使可靠度能够写成一减 PEV 与遗传方差之比。如果模型协方差错误、预测经过任意后处理, 或者目标基准发生变化, 这种关系需要重新检查。公式不是一个对任何数字列表都有效的可靠度定义器。

在本章, $\mathbf{G}$ 的对角随个体变化。若按给定基因型的条件模型解释单个目标, 相应基础方差是该个体的 G_{ii} , 不能无条件用统一的一代样本方差替代。另一方面, 生产报告中的可靠度可能采用统一群体尺度, 便于跨个体比较。两种约定需要明确说明, 不应一边使用个体条件 PEV, 一边又在没有解释的情况下更换分母。

固定效应估计会使某些总体方向的信息有限。若所有记录都同时提高一个常数，模型可能主要把它归入截距，而不是给所有动物增加同样育种值。这体现了固定均值与遗传基准之间的可识别结构。观察预测均值不随表型均值一比一变化，并不一定表示模型错误；应先检查参数化和基础群体定义，再判断是否存在不合理漂移。

35.10 计算实现与独立等价核验

数学记号写出逆矩阵，并不意味着程序应显式计算大型逆矩阵。对训练协方差 $\mathbf{V}_t$ ，采用 Cholesky 分解后求解多个右端，通常比形成完整逆矩阵更稳定，也能复用分解结果。固定效应部分只有三列，因此对应的小矩阵处理成本很低。实现应让数值结构服务模型，而不是机械地逐字翻译公式。

本实验标记数二百四十、动物数二百八十， $\mathbf{G}$ 的秩不超过二百四十，所以全矩阵可以奇异。这并不妨碍本章预测，因为需要求解的是训练协方差 $\mathbf{G}_{tt} + 1.5\mathbf{I}$ 。对任意非零向量 $\mathbf{a}$ ，其二次型至少为 $1.5\mathbf{a}'\mathbf{a}$ ，严格大于零。因此无须为了求 $\mathbf{G}^{-1}$ 而添加任意较大的对角修正。

如果改用需要关系逆矩阵的另一种实现，必须合理处理低秩结构，而不能假设所有表达在数值上具有同样条件。两种理论等价形式可能在规模、稀疏性和秩上具有不同优势。选择实现时应说明所解决的线性系统，尤其当记录数、动物数与标记数相差很大时，计算成本可能相差明显。

为了核验 GBLUP，本章另外求解标记效应的混合方程。将训练中心化剂量记为 $\mathbf{W}_t$ ，标记效应先验方差为 $\mathbf{I}/s$ ，残差方差为一点五，则标记块的惩罚为 $1.5s\mathbf{I}$ 。与固定效应共同求解后，计算 $\mathbf{W}\hat{\mathbf{a}}$ ，应与协方差形式的 $\hat{\mathbf{u}}$ 一致。

这项核验不仅比较预测，还比较 PEV。标记方程逆矩阵相应分块乘以残差尺度，再通过 $\mathbf{W}$ 映射到动物空间，应得到相同预测误差协方差。实际计算中，育种值最大绝对差小于七乘十的负十四次方，PEV 最大绝对差约二乘十的负十五次方，均属于浮点舍入范围。两个不同表达的一致性为尺度和固定效应处理提供了独立检查。

另一项检查针对信息边界：将全部验证表型替换为十的十次方，预测完

全不变。因为训练索引固定，拟合函数没有使用这些记录。这不能排除所有可能的间接泄漏，却能快速发现某些误用全体表型的实现错误。模型代码应尽量把训练资料访问集中到明确接口，使这类检查简单可行。

数值检查还包括矩阵对称、设计矩阵秩、预测有限和 PEV 非负。对 PEV，只允许非常小的负数作为舍入后截零，实质性负值应触发错误，而不是被无条件截断隐藏。对优化程序，成功状态也应伴随实际约束残差检查。一个可运行程序与一个可靠计算实验之间的差别，就体现在这些与科学含义相连的核验上。

程序实现的最后一项要求是输出足够的中间证据。只保存最终均值会使异常重复难以追踪；保存每次种子、各模型指标和必要预测，可以在发现问题时定位是哪一个场景或哪一类个体。输出不必无限膨胀，但应足以重建表格与图形，并验证文稿中的数值没有在手工整理时发生变化。

35.11 三十次重复的主要结果

每次重复使用一个预定种子，重新生成全部随机资料；两个模型在同一重复内使用相同群体。这样得到三十对性能指标，而不是两组彼此无关的结果。方法差应先在每个重复内计算，再汇总其均值与蒙特卡洛标准误，以利用共享随机条件减少比较噪声。

下表中的“均值 $\pm$ 标准差”描述三十次重复之间的波动，不是均值的置信区间，也不是未来所有实际牧场的性能范围。相关与真实育种值直接比较，仅因模拟中真值可见；在真实资料中不能用普通表型相关替代而仍称为同一种准确度。

指标	系谱 BLUP	GBLUP
验证相关	0.514 $\pm$ 0.100	0.625 $\pm$ 0.107
均方根误差	0.866 $\pm$ 0.088	0.775 $\pm$ 0.079
校准斜率	1.041 $\pm$ 0.198	0.991 $\pm$ 0.173
校准截距	-0.005 $\pm$ 0.240	0.003 $\pm$ 0.189

指标	系谱 BLUP	GBLUP
九成区间覆盖率	89.58%±3.82 个百分点	90.25%±4.14 个百分点




图 35.2 三十次独立群体重复的验证相关与均方根误差。每个点为一次重复，箱体表示重复间分布；这不是现实牧场的性能范围

完整标记 GBLUP 在本设定下平均相关较高、RMSE 较低。三十次中有二十九次相关高于系谱 BLUP，平均相关差约零点一二，成对差的蒙特卡洛标准误约零点零一二。这个结果支持“在本生成条件与未来一代任务中，实际标记关系提供了有用信息”，却不支持“任何小面板、任何群体、任何性状都能得到同样改善”。

重复间标准差并不小。GBLUP 的相关在不同重复中受基础基因型、标记效应、家系抽样和残差共同影响。若只展示一个表现最好的种子，可以轻易夸大方法效果；如果只选择一个不利种子，也可能低估方法。预定种子与完整报告是为了避免这种选择性叙述。散点图应按事先规定的代表规则选取，本章固定展示第一个重复。

为什么系谱 BLUP 仍有相当的预测能力？第二代候选者与训练第一代存在直接亲缘，亲本和其他亲属的表型已经传递了遗传信息。GBLUP 的优势不是从零开始创造预测，而是在已有家系信息上增加实际遗传抽样的辨识。

因此，当亲缘更远、标记与因果位点关系不同或训练群体改变时，优势大小需要重新评估。

两个模型平均区间覆盖率均接近名义九成，不能据此认为它们对每只动物都同样精确。覆盖率只检查区间是否包含真值的频率，区间宽度和个体 PEV 也应关注。一个很宽的区间容易达到覆盖，却可能不足以支持精细排序；一个较窄区间如果覆盖不足，则可能让选择决策过于自信。准确与诚实表达不确定性需要同时满足。

本章没有估计遗传方差、没有缺测、没有选择性分型，并且全部真实加性位点都被观测。它更像一个模型行为的基准实验，而不是生产性能试验。读者应把这些条件与数值一起记住。只有当后续研究逐项放宽这些条件，并在独立真实资料中获得相容证据时，才能把结论扩展到具体育种计划。

35.12 校准、误差尺度与个体比较

相关系数主要描述线性排序关系，对整体平移和正比例缩放不敏感。若把所有 EBV 乘以二，相关不变，实际幅度却明显改变。因此本章同时拟合真实育种值对预测值的回归 $u = a + b\hat{u} + \varepsilon$ 。在适当条件下，截距接近零、斜率接近一表示平均水平和尺度较为相容；斜率明显低于一通常提示预测过于分散。

这项回归的方向不能随意交换。回归真实值对预测值与回归预测值对真实值得到的斜率通常不互为倒数，因为两侧都有未解释变化。报告时应写清响应和自变量。特别在真实资料中使用后续评定作代理真值时，还需要考虑代理自身的误差与共享信息，不能直接沿用模拟中真值已知的简单解释。

第一个预定重复中，GBLUP 相关约零点七四九，校准斜率约一点一三七，截距约负零点三九零。单次群体出现一定平均偏移，与三十次平均截距接近零并不矛盾。有限家系群体可以整体抽到偏高或偏低的遗传水平，固定效应估计也有波动。评价单次结果时应同时考虑样本量、亲缘相关和重复实验的总体行为。

均方根误差把偏差和离散误差综合到原尺度。若比较不同性状或不同标

准化方式, RMSE 不能直接按数值大小判断优劣; 需要相同目标单位或明确标准化。对于育种决策, 原单位误差通常更容易与经济后果联系, 但它也依赖目标群体的遗传变异范围。因此完整报告应同时给出尺度说明和验证群体定义。

预测区间采用 $\hat{u}_i \pm 1.64485\sqrt{PEV_i}$ 。这里是个体育种值预测区间, 不是未来表型区间; 后者还应包括未来环境及相应固定效应不确定性。若直接把 PEV 用于预测某只羔羊将达到的体重, 会遗漏重要变异。模型输出同样的“标准误”字样并不能消除目标差别, 报告需要明确区间包围的随机量。

个体间比较还要使用误差协方差。对两个候选者差值, 预测误差方差为 $PEV_i + PEV_j - 2PEC_{ij}$ 。共享训练资料和亲缘可使误差相关, 因此把两个区间是否重叠作为唯一比较规则并不可靠。若需要比较一个亲本组合的总目标, 则应直接计算组合误差的二次型, 而不是逐个看 EBV 小数点后的差别。

校准检查最好兼顾整体和重要亚群。平均截距为零可能掩盖某些家系高估、另一些家系低估; 总体覆盖率达标也可能掩盖某一类低信息动物区间不足。但亚群越小, 估计越不稳定, 不能把每个细分结果都当作确定结论。应事先选择与部署相关的分层, 例如性别、出生代、场站和信息量, 而不是事后搜索最显著的异常。

最后, 校准是模型与目标群体的关系, 不是算法永久拥有的标签。训练样本改变、参考基准更新、性状定义变化和选择历史累积, 都可能改变校准。一个在本章模拟中斜率接近一的模型, 进入真实新群体仍需重新验证。可靠实践应把校准作为持续检查的对象, 而不是一次通过后永久免检的证书。

35.13 减少可观测标记: 信息损失与模型错设要分开

现在保留原来由二百四十个位点生成的真实育种值, 只允许预测模型观察前面三十、六十或一百二十个位点。由于生成位点独立, 这不是现实芯片的连锁标记设计, 而是一个控制信息量的实验。每次重复的群体、真实效应和表型保持不变, 所以性能差异确实来自可用标记及其协方差表达的改变。

首先考虑一种常见但有风险的做法: 只用少数观测标记构造关系矩阵,

仍把这个矩阵当作全部加性方差的完整描述。若观测位点集合为 J ，定义 $s_J = \sum_{j \in J} 2p_j(1-p_j)$ ，构造 $G_J = W_J W_J' / s_J$ ，再继续使用加性尺度一和残差一点五。这个模型不仅信息减少，还错误地把未观测的真实遗传部分排除在协方差之外。

在本生成器中，可以构造一个更相容的教学参照。观测位点占基础遗传方差的比例为 $f = s_J / s$ ，它们贡献 fG_J ；未观测位点在对遗传传递取平均后仍保留系谱协方差 $(1-f)A$ 。因此使用

$$K_{mix} = fG_J + (1-f)A.$$

这里的 f 由已知生成机制给出，不是从实际育种资料中免费获得的参数。这个构造用于区分“少量标记提供多少信息”与“误把少量标记当成全部遗传协方差”的后果。

三十次成对重复得到如下结果。表中简单标记模型指前述全部方差由少量标记关系承担的设定，混合参照保留未观测遗传部分的系谱协方差。覆盖率均针对名义九成区间。

观测位点数	简单模型相关	混合参照相关	简单模型覆盖率	混合参照覆盖率
30	0.290	0.518	53.21%	90.04%
60	0.402	0.536	68.88%	89.96%
120	0.532	0.573	81.67%	90.17%
240	0.625	0.625	90.25%	90.25%

简单模型在三十个位点时不仅相关下降，校准斜率也降至约零点四四二，区间覆盖严重不足。这不是一个“少量标记一定无用”的普遍结论，而是模型遗漏了大量真实遗传协方差后仍以过强确定性作预测的结果。混合参照在三十个位点时保持接近系谱 BLUP 的相关，并随着观测位点增加逐步改善，说明未观测部分不能被当成不存在。

这个实验还展示了为什么比较模型时要分析误差来源。若只报告第一列简单模型结果，可能得出必须达到某个标记数才值得分型的粗糙结论；加




图 35.3 观测位点减少时的相关与覆盖。实线比较简单标记模型和保留未观测系谱背景模型；相关面板虚点线为 ABLUP 均值，覆盖面板虚线为名义九成

入正确协方差参照后，可以看到少量标记在保留背景亲缘信息时仍有增量价值。真实群体中的标记与因果位点并非独立，实际面板还能通过连锁不平衡捕捉未直接观测位点，所以本表不能用于确定商业面板阈值。

在真实研究中，混合权重需要估计、校准或依据模型设定确定，系谱与基因组基准还必须相容。把两张矩阵任意加权并不自动正确。若基础群体不同、尺度不一致或其中存在身份错误，混合可能只是在掩盖问题。这个教学参照的意义是提醒研究者保留合理的未解释遗传结构，并用覆盖和校准检查模型是否过度自信。

35.14 方差比错设如何改变排序与幅度

保持完整二百四十位点关系、真实表型和训练集不变，分别把拟合残差方差设为零点三七五、一点五和六。真实残差方差仍为一点五。三个值分别表示低估四倍、正确设定和高估四倍，因而是一个只改变模型噪声假设的控制实验。不能把这些拟合值误认为从资料估计出的不同真实遗传力。

低估残差会使模型把更多表型差异解释为遗传，收缩减弱；高估残差则加强收缩。对于多维关系结构，这种改变不一定只把所有 EBV 乘以一个共同常数，因为不同遗传特征方向具有不同信息强度。因而相关也可能变化，

但幅度校准通常比相关更直接地揭示方差比错误。

拟合残差方差	验证相关	RMSE	校准斜率	九成覆盖率
0.375	0.607	0.871	0.614	76.83%
1.500	0.625	0.775	0.991	90.25%
6.000	0.602	0.847	1.852	90.92%




图 35.4 真实残差方差固定为一点五、拟合方差改变时的校准和覆盖。横轴为对数尺度，虚线分别标示理想斜率一和名义覆盖九成

低估残差时，相关仍超过零点六，乍看并不差，但斜率约零点六一四，说明预测幅度过大，覆盖率也降至约百分之七十七。如果只用相关选择模型，可能忽视这种对决策十分重要的失准。高估残差时，斜率约一点八五二，预测幅度明显偏小，RMSE 也比正确模型高；覆盖率接近九成并不能弥补预测效率损失。

为什么高估残差的覆盖率没有严重失效？较强收缩同时伴随较大的模型不确定性，区间可能较保守或在此设定下接近名义覆盖。但这不是高估方差总能保证安全的定理。不同群体、固定效应结构和误设方向可能产生不同后果，尤其当某些系统偏差没有被区间宽度吸收时，覆盖仍会不足。

从谱角度可以进一步理解。若暂不考虑固定效应，把遗传协方差分解为

特征方向，每个方向的收缩因子形如 $\lambda_k / (\lambda_k + \sigma_e^2)$ 。遗传变异很强的方向即使噪声增加仍保留较多信息，弱方向则更快被压缩。因此错误方差比会改变不同方向之间的相对权重，而不只是整体缩放。这也解释了为什么排序与校准可能同时变化。

实际方差估计误差往往不像本例这样由研究者明确指定。小样本、选择性记录、共同环境遗漏和基准不相容都可能使估计偏离目标。应将参数估计纳入验证流程，必要时进行参数自助法或敏感性分析。直接把一次 REML 结果当作没有误差的真值，会低估整个评定流程的不确定性。

这个实验给出一个实用检查方向：当相关尚可而校准斜率长期远离一时，除了怀疑算法本身，也应检查关系矩阵尺度、遗传与残差方差比、性状单位和固定效应处理。先核对这些基础量，往往比立即增加非线性模型更有解释力。模型复杂度不能替代尺度一致性。

35.15 八只候选者错配：合法矩阵仍会产生错误预测

为研究身份错配，本章在每次重复中把前八只验证动物对应的基因组关系行列顺序倒置，其他动物保持不变。也就是说，矩阵仍然同时置换行与列，但表型与真实育种值的动物标签不作同样置换。八十只候选者中有八只使用了别人的关系信息，恰占十分之一。这个人为错误模拟的是候选样本与动物身份之间的错接。

这种置换保留矩阵对称性、特征值、半正定性和全部元素分布。训练矩阵也不改变，因为被交换者都在验证集。因此固定效应估计与训练解保持一致，未受影响候选者的预测也保持原样。常见的数值合法性检查全部可能通过，错误只存在于“这一行究竟属于哪只动物”的生物学对应关系。

三十次重复中，完整正确 GBLUP 平均相关约零点六二五、RMSE 约零点七七五；错配后平均相关降至约零点五七零，RMSE 升至约零点八一七，校准斜率约零点九零六，覆盖率约百分之八十八点七。总体变化没有夸张到让每个人立即怀疑资料，但对被错配动物而言，预测依据已经错误。少量身份问题可以被总体平均掩盖。

这个结果不应被解释为“十分之一错配总使相关下降多少”。错配对象是否近亲、原预测差异大小以及候选群体结构都会影响后果。若交换的是关系和预测非常接近的全同胞，总体损失可能较小；若交换的是差异很大的个体，后果更严重。模拟的价值在于证明一种可能性：矩阵完全合法不意味着身份正确，而不是给所有项目提供一个固定折损系数。

对于选择决策，平均相关下降还可能低估风险。如果被错配者恰好处于入选边界或被赋予很高使用份额，少量错误可以影响较多后代。应在关键候选者上加强样本链核验和必要的重复检测，而不是仅依据全群指标决定是否检查。身份质量与遗传价值使用强度之间存在实际管理联系。

错配也可能制造误导性的研究结论。若新方法恰好对错配不那么敏感，可能在脏资料上表现更好，但不能因此声称它更准确刻画遗传规律；如果旧方法使用已核验身份而新方法使用未经核验批次，比较又会不公平。方法评估应尽量共享同样的资料版本，并把身份修正作为独立因素记录。

这一案例提示，程序测试应包含有意破坏对应关系的负向检查。可以确认模型结果确实随身份错误变化，同时确认普通正定性检查不会误称已经覆盖这一风险。负向检查不是为了模拟所有现实错误，而是帮助团队理解每项检查的能力边界。知道检查不能发现什么，与知道它能发现什么同样重要。

35.16 怎样把教学实验扩展为严谨研究

从本章出发，可以构造许多研究问题，但应保持明确的估计对象。若研究标记密度，终点可以是未来候选群体真实育种值相关、校准和成本约束下目标值；若研究预测区间，终点应包括覆盖率、宽度和亚群行为；若研究配种决策，终点应包括真实遗传目标与亲缘后果。不同终点可能对同一方法给出不同评价，不能在结果出来后只保留最有利的一项。

模拟因素应区分科学因素和数值因素。遗传架构、群体历史、训练规模和表型缺失属于科学设定；迭代容差、矩阵求解方式和随机数实现属于计算设定。前者决定方法适用范围，后者决定是否正确实现。若计算失败率随某种科学场景增加，应将失败本身纳入结果，而不是删除失败重复后只比较幸

存结果。

设计可以从少量具有明确解释的场景开始。例如保留本章基础场景，再分别引入稀疏大效应、未观测加性背景、共同窝环境和选择性分型。每个场景都应说明哪些假设被改变、哪些保持不变。只有在单因素行为已经理解后，才适合研究多个困难共同出现的情形。否则复杂场景中的优劣很难归因。

重复次数应根据所需精度规划。本章三十次足以展示明显的平均差异和重复波动，但不适合估计很低的失败概率。若目标是判断覆盖率是否从百分之九十降到百分之八十九，需要远多于三十次独立重复。独立单位也要明确：同一重复中的八十只验证动物共享家系和拟合模型，不能当作八十个独立试验估计方法比较的标准误。

方法比较应尽量成对。对同一生成资料运行所有方法，可以减少由群体难度差异带来的比较噪声。若某个方法需要随机初始化，可以在每个资料重复内再设置算法随机层，区分数据抽样变异与优化随机变异。把两种变异混在一个总标准差里虽然容易，但不利于理解方法究竟在哪一层不稳定。

研究还应保留合理基准。系谱 BLUP 不是为了被新方法击败而故意弱化的对照，应使用相同资料、适当固定效应和合理参数估计。若新方法享有真实生成参数，而基准只能从小样本估计，比较回答的是信息条件不同的问题。理想参数方法可以作为上界参照，但应明确标识，不与可部署方法混在一起宣称公平竞争。

Morris 等提出的模拟研究组织框架强调先说明目标、生成机制、估计对象、方法和性能度量 (Morris 等, 2019)。在本章语境中，这意味着把“想检验什么”写在生成代码之前，并让每个图表能够回到相应问题。框架不能代替专业判断，却能减少常见遗漏，例如没有说明真值、没有报告失败或没有计算蒙特卡洛误差。

真实资料验证仍然不可替代。模拟可以检验在某些条件下程序是否按理论行为，却不能证明这些条件足够接近真实育种群体。进入真实资料时，应核对性状定义、信息截止日、亲缘跨度和表型代理，必要时安排前瞻性测定。最强的研究不是只拥有一个很复杂模拟，而是让理论、受控模拟和独立现实

证据互相校验。

35.16.1 对失败重复与计算预算的处理

如果一种方法在部分重复中不收敛，不能简单删除这些重复后与基准比较平均精度。失败可能集中在小家系、极端表型或弱连通场景，删除后得到的其实是有条件的较容易样本。应同时报告失败比例、失败条件，以及对失败时实际会采取的后备策略。若生产系统会退回系谱评定，研究也可以评价这一完整策略，而不是只评价成功运行的新算法。

调参预算是比较公平性的一部分。一个方法尝试许多参数组合并选择验证中最好者，另一个只使用随意设定的默认值，差异不能全归因于模型类别。应给出相近的开发机会，或明确研究的是包括调参成本在内的完整流程。最终外部评估不能再次参与选择，否则报告会同时包含调参收益和选择偏倚。

计算效率也需要条件化陈述。一次小矩阵实验中的用时不能直接推断到百万动物；稠密求解、稀疏方程、迭代方法与标记低秩表达的规模规律不同。可以报告本实验的运行环境与任务规模，但不应据此宣布某种方法普遍最快。效率研究应独立设计多个规模层次，并核对不同实现达到相当的数值精度。

研究者还应保存无效尝试的原因。某个模型失败可能因为理论不适用，也可能因为实现尚未优化、参数边界处理不正确或输入尺度错误。清楚区分这些原因，有助于后续研究判断值得改进的是统计思想还是工程实现。科学比较的目标是识别可重复的条件规律，而不是通过隐藏困难让某个方法显得无所不能。

35.17 复算路径与结果解释的工作顺序

复算本章首先固定输入设计：动物数、世代结构、位点数、频率范围、效应分布、残差方差和随机种子。随后运行一个重复，检查基础个体数量、父母范围、基因型剂量和设计矩阵维度。只有这个最小运行通过，才扩展到三十次重复。直接运行大量重复而不查看第一批输入，可能让一个简单错误被成千上万次稳定复制。

第一步输出可以包括系谱关系与基因组关系的热图，但图形只是检查入口。应确认对称性、对角范围、训练与验证分块，并查看少数已知亲属的关系值是否符合生成逻辑。不能因为图像有漂亮的家系区块就认为矩阵正确，也不能因 **G** 出现负值就擅自改动。图形帮助提出问题，具体判定仍需代数与资料定义。

第二步核对单个体和双个体例子。它们给出不依赖随机种子的明确数值，可以检查方差尺度和权重方向。再用标记方程与协方差方程比较完整 GBLUP。若这两种形式不一致，应先解决实现差异，不应继续用某一个结果作为研究发现。关键等价核验比增加更多拟合指标更能保护基础正确性。

第三步保存每次重复的相关、RMSE、斜率、截距和覆盖率。汇总时同时报告均值和重复间波动，并对方法差计算成对标准误。箱线图或散点图应显示重复，而不是只画两根平均柱。若某个重复异常，应保留它并调查原因，只有在预定规则认定为计算失败或生成错误时才按规则处理，不能因为结果不支持预期就删除。

第四步运行控制扰动。标记数量实验要保留完整真实育种值；方差错设实验要保留同一表型；身份错配实验要明确哪些候选受影响。每次改变都应能用一句话描述。如果一个实验同时改变三种因素，就把它作为新的联合场景，而不是继续解释成单一因素作用。这样得到的结果才具有可迁移的逻辑价值。

第五步将预测结果送入第 36 章的选择与配种问题。先固定候选集合和目标权重，再比较贡献方案；不要每种方法都挑选对自己最有利的候选群体。对于低信息个体，可以考察方案对 EBV 扰动的敏感性。预测表现与决策表现应分别报告，因为前者的微小改善可能在约束作用下被放大，也可能几乎不影响实际行动。

本章全部主要数值均由公开的教学程序实际运行得到。这样的复算只证明指定程序、种子和模型条件下的可重复行为，不意味着所有潜在错误已被逻辑上排除。科学计算的可靠性来自多种相互独立的检查，而不是一句绝对保证。读者应保留能够重新运行和修改的代码，而不只保存最终表格截图。

若将本章作为研究生课程实训, 可以让不同小组负责不同检查层: 一组核对遗传生成与系谱, 一组推导 PEV, 一组实施等价方程, 一组设计扰动与解释结果。各组共享固定基础资料, 再比较结论是否一致。这样的安排能让学生看到统计遗传学不仅是套用一个软件命令, 而是把生物学定义、概率模型、数值计算和决策解释连成一条可核验的链。

35.18 把预测损失分成不可约误差与方法额外损失

已知真实育种值的教学实验, 最有价值的用途不是给算法排一个名次, 而是找到损失产生的具体位置。为此先固定一个生成场景, 把目标育种值向量记为 $\mathbf{u}$, 训练记录记为 $\mathbf{y}$ 。二者均已按真实均值中心化, 真实二阶矩分别为 Σ_u 、 $\mathbf{V}$ 以及 $\mathbf{C} = \text{Cov}(\mathbf{u}, \mathbf{y})$ 。暂设 $\mathbf{V}$ 正定, 任何固定系数的线性预测写为 $\tilde{\mathbf{u}} = \mathbf{L}\mathbf{y}$ 。这里的“固定”表示在计算本次理论风险时, 系数不是由同一随机机记录再次选择出来的。

$$\mathbf{E}(\mathbf{L}) = \Sigma_u - \mathbf{L}\mathbf{C}^\top - \mathbf{C}\mathbf{L}^\top + \mathbf{L}\mathbf{V}\mathbf{L}^\top.$$

最佳线性预测系数为 $\mathbf{L}_* = \mathbf{C}\mathbf{V}^{-1}$ 。把任意系数写成最佳系数加偏离量, 展开后交叉项抵消, 得到一个精确的平方配方。

$$\begin{aligned}\mathbf{E}(\mathbf{L}) &= \mathbf{E}(\mathbf{L}_*) + (\mathbf{L} - \mathbf{L}_*)\mathbf{V}(\mathbf{L} - \mathbf{L}_*)^\top, \\ \mathbf{E}(\mathbf{L}_*) &= \Sigma_u - \mathbf{C}\mathbf{V}^{-1}\mathbf{C}^\top.\end{aligned}$$

第二项半正定, 所以错设系数不会在真实总体的平方风险意义下超过最佳线性规则。对于对称半正定的目标权重矩阵 $\mathbf{W} \succeq 0$, 额外风险是上述矩阵的加权迹。它可以直接定位到具体遗传对比, 而不必只报告所有动物平均误差。

$$\mathcal{R}_{extra} = \text{tr} \left\{ \mathbf{W}(\mathbf{L} - \mathbf{L}_*)\mathbf{V}(\mathbf{L} - \mathbf{L}_*)^\top \right\}.$$

一个独立标量例子设真实育种值方差为二, 独立残差方差为三, 因此记录方差为五、目标与记录协方差为二。最佳权重为零点四, 风险为一点二。若错误使用零点七, 实际风险为一点六五, 额外风险零点四五, 恰好等于记

录方差乘系数偏差的平方。若再额外加上零点五的固定偏移，风险增加零点二五，成为一点九。

$$R(b, d) = 2 - 4b + 5b^2 + d^2 = 1.2 + 5(b - 0.4)^2 + d^2.$$

这个分解明确区分了信息不足、权重错误和均值偏移。三者都可能使 RMSE 增大，却需要不同的修复：信息不足需要新的目标相关资料；权重错误需要改进协方差和估计；均值偏移需要检查基准或环境校正。只看到总风险降低，无法知道改善是否来自真正新增的信息，还是从一个故意设差的基准回到正确尺度。

若不限制在线性规则中，可以把条件期望 $\mathbf{m}(\mathbf{y}) = E(\mathbf{u} | \mathbf{y})$ 作为更一般的参照。对任何由当前信息形成的预测 $\mathbf{f}(\mathbf{y})$ ，条件正交性给出

$$\begin{aligned} E \|\mathbf{u} - \mathbf{f}(\mathbf{y})\|^2 &= E \|\mathbf{u} - \mathbf{m}(\mathbf{y})\|^2 \\ &\quad + E \|\mathbf{m}(\mathbf{y}) - \mathbf{f}(\mathbf{y})\|^2. \end{aligned}$$

在线性高斯场景中，这个参照与最佳线性参照重合；在非高斯场景中，二者可以不同。把真实生成参数代入最佳线性方法，称作理想线性参照是合适的，但不能在任意遗传架构下称作所有方法的绝对上界。复杂模型若超过它，可能来自非线性条件均值，也可能来自比较规则不公平，需要进一步区分。

实际教学实验中的系数还会受到训练资料、估计参数和调参过程影响。这时将随机系数直接代入固定系数风险公式，再对所有记录一起平均，可能遗漏依赖项。可靠做法是条件于训练过程产生的预测规则，用独立未来资料评价条件风险，再对训练资料积分；或者在每次重复中保留一个足够明确的理想参照，直接计算配对损失差。训练集拟合残差不能替代这个步骤。

尤其要区分“同一群体内估计误差”和“未来群体分布改变”。前者是在同一个真实协方差下系数偏离最优，后者会改变风险公式本身所用的 $\mathbf{V}$ 和 $\mathbf{C}$ 。某个系数在训练总体中完全正确，也可能在未来总体中产生额外风险。这样组织实验后，模型错设、参数估计和群体迁移可以成为不同因素，而不是都被放入一个笼统的“泛化能力”指标。

风险分解还可以检验评价代码本身。在固定线性高斯场景中，将解析风险与足够多独立模拟误差平均比较，应在蒙特卡洛误差范围内一致。如果模拟均值持续低于理论最优风险，应检查验证真值是否被重新缩放、是否遗漏失败重复、是否以同一噪声构造了目标代理。理论参照在这里不是为了证明某种方法必胜，而是提供一个不能被任意突破的核验界限。只要生成条件与评价损失保持一致，这种独立依据比重复调用同一个预测函数更有诊断力。

35.19 嵌套重复怎样分离遗传抽样与算法随机性

肉羊教学实验包含多个随机层：基础群体基因型、亲本选择与传递、标记效应、环境误差，以及某些算法的初始化或抽样。改变哪个层，就改变重复实验回答的问题。固定一次基因型，只反复生成环境误差，回答的是给定遗传构型下的方法稳定性；每次重新生成整个系谱和基因组，则还包含不同群体结构之间的变化。两种平均值都可以有意义，但必须写出条件对象。

令 D_r 表示第 r 次外层数据生成， L_{rk} 为其上第 k 次独立算法运行的损失。以 $\mu_r = E(L_{rk} | D_r)$ 表示该资料上的算法平均损失，假设条件运行独立，则总变异可分为

$$\text{Var}(L) = \text{Var}_D(\mu_D) + E_D\{\text{Var}(L | D)\}.$$

将前一项记为 σ_D^2 、后一项记为 σ_A^2 。每个外层资料运行相同的 K 次，外层独立重复 R 次，总平均的方差为

$$\text{Var}(\bar{L}) = \frac{\sigma_D^2}{R} + \frac{\sigma_A^2}{RK}.$$

内层重复只能减少算法噪声，不能减少抽到一个困难群体造成的外层不确定性。因此，一个数据集运行一千次随机初始化，并不等价于一千个独立育种群体。若算法完全确定，则内层方差为零，增加初始化次数没有统计收益；若数据生成昂贵而算法噪声很大，适当增加内层重复则可能节省预算。

可以把这个取舍直接推导为计算分配问题。设生成并准备一个外层资料的成本为 a ，每次内层运行成本为 b ，总预算为 B 。忽略整数取整，外层次数的

为 $B/(a + bK)$ ，代入平均方差后，对 K 求导得到

$$K_* = \sqrt{\frac{a\sigma_A^2}{b\sigma_D^2}}.$$

这个结果适用于各层方差和成本近似稳定、内层运行独立的设定。若算法链存在自相关，必须用有效独立运行数替代名义次数；若大多数时间花在一次可复用矩阵分解上，成本也不能简单设为线性。公式的价值是给出判断方向，实际分配仍需考虑整数限制和少量试运行提供的方差估计。

独立算例取外层方差零点零四、内层方差零点零九，外层准备成本九、内层成本一，总预算九百。连续最优内层次数为四点五。枚举可行整数后，取每资料四次运行、六十九份独立资料，预算使用八百九十七，平均方差约零点零零零九零五八。取每资料一次、九十份资料时，平均方差约零点零零一四四四；取五次、六十四份资料则约零点零零零九零六三，与四次方案非常接近。

$$\text{Var}(\bar{L})_{K=4} = \frac{0.04 + 0.09/4}{69} \approx 0.0009058.$$

两个方法比较时，应优先在同一个外层资料上计算损失差。若它们的损失分别为 L_1, L_2 ，配对差的方差是

$$\text{Var}(L_1 - L_2) = \text{Var}(L_1) + \text{Var}(L_2) - 2\text{Cov}(L_1, L_2).$$

共享数据通常使两者同时受到群体难度影响，产生正协方差，从而降低比较噪声。共享随机数并非无条件有利；若一种算法的随机机制与另一种方向相反，协方差也可能为负。正确的做法是明确定义共享哪些随机层，并在试验中检查配对差的稳定性，而不是只因为两个程序使用相同种子就宣布已经完成公平配对。

记录设计也应保留嵌套索引。外层编号指向一套完整群体和表型生成，内层编号指向算法运行；任何失败必须回到相应层。若同一数据集上所有运行都失败，可能是场景结构问题；若只有部分初始化失败，则更接近优化稳定性问题。把两类失败混为一个百分比，会妨碍诊断，也使后续改进无法知道应投入在模型还是计算上。

估计外层和内层方差时, 可以先求每个资料内部的样本方差, 再对资料平均, 估计内层变异; 外层均值之间的样本方差则仍包含有限内层次数留下的噪声, 需要扣除相应部分。若扣除结果为负, 应报告方差估计在有限试运行下不稳定, 不能将一个精确零值解释为群体间完全没有变化。计算分配可以用合理范围进行敏感性分析, 而无需假定少量试运行已经给出了精确成本和方差。最优预算附近的方差通常变化平缓, 选择容易执行、同时保留足够外层重复的整数方案往往更稳妥。

35.20 用完整因素设计识别观测信息与噪声的交互

单因素实验能够解释局部变化, 却可能错过两个因素之间的关键交互。标记信息更充分时是否一定获得相同增益, 取决于表型噪声和目标联系; 增加训练记录是否值得, 也取决于新记录是否覆盖新的遗传方向。为了让交互可以手算, 考虑真实目标 u 与可观测遗传摘要 g 均值均为零、方差均为一, 二者协方差为 q 。记录为 $y = g + e$, 独立误差方差为 r 。

$$\text{Var}(y) = 1 + r, \quad \text{Cov}(u, y) = q.$$

这里 q 描述观测摘要与完整目标之间的联系, 可代表标记遗漏或跨群体联系减弱; r 描述观测噪声。最佳线性预测及其风险为

$$\hat{u} = \frac{q}{1+r}y, \quad R(q, r) = 1 - \frac{q^2}{1+r}.$$

取 q 为零点四或零点八, r 为一或四, 形成四个明确场景。风险依次为: 弱联系、低噪声时零点九二; 强联系、低噪声时零点六八; 弱联系、高噪声时零点九六八; 强联系、高噪声时零点八七二。每个场景都使用相应真参数, 因此这些差异来自观测条件, 而不是拟合算法犯错。

$$r = 1 \quad r = 4$$

$$q = 0.4 \quad 0.920 \quad 0.968$$

$$q = 0.8 \quad 0.680 \quad 0.872$$

将目标联系从弱改为强，在低噪声下减少风险零点二四，在高噪声下只减少零点零九六。两者差零点一四四，就是本例中可以直接解释的交互。它说明高质量遗传信息的作用会被劣质表型限制；反过来，改善测量精度在强联系场景下也更有价值。

$$\begin{aligned}\Delta_{q \times r} &= \{R(0.4, 1) - R(0.8, 1)\} \\ &\quad - \{R(0.4, 4) - R(0.8, 4)\} = 0.144.\end{aligned}$$

如果只在低噪声场景估计标记改善的收益，再把这个收益外推到所有场站，会高估噪声较大场站的预期效果。若只在高噪声场景比较两种遗传信息来源，又可能错误地认为改善基因组表示没有价值。因素设计不是为了列出尽可能多组合，而是为了让这样的条件依赖能够被直接观察和估计。

接着增加一个独立的拟合因素：真实联系为零点四、噪声为一，却按联系零点八形成权重零点四。实际风险变为一，比正确风险零点九二高零点零八。于是同一个“低密度方案表现差”的结果，可以分为信息本身减少和对剩余信息过度自信两个后果。

$$R_{mis} = 1 - 2(0.4)(0.4) + 2(0.4)^2 = 1.$$

在完整肉羊模拟中，可以同样设置生成端因素和拟合端因素。生成端改变完整位点集合、连锁或残差结构；观测端决定哪些位点或表型可见；拟合端决定如何处理遗漏成分。只有把三个端点区分开，才能解释某个方法的改善究竟来自新增信息、正确建模还是更有利的真值定义。

交互估计仍应在每个重复内配对。四个场景可以共享基础随机量，再通过预定变换形成不同水平，这有助于降低比较噪声；但不同水平必须确实对应所宣称的生成机制。例如，直接把同一次噪声乘以二能够改变噪声方差，同时保留配对结构；把筛选后的动物重新当成随机候选，则改变了目标总体，不能继续解释为纯噪声因素。

对更大的设计，应优先预设少数具有科学意义的交互，而不是在许多组合中寻找最显著的一项。某个方法只在一种架构、一种频率和一种验证切分下获胜，说明其优势有条件，不意味着实验失败。真正需要避免的是把条件

优势平均成一个没有适用范围的“总体最好”，或因某个场景不利而事后把它从研究对象中删去。

交互的标准误也应按整个差中之差计算。如果四个场景共享随机量，它们的结果彼此相关，不能分别估计四个标准误后假装独立相加。应在每个外层重复中先形成一个交互值，再对这些独立交互值求均值和标准误。这样的分析单位与科学问题一致，也允许直接画出交互在不同群体构型中的分布。若平均交互较小但正负差异很大，进一步分析哪些群体特征决定方向，通常比只给一个总体显著性更有解释价值。

35.21 同样协方差可以对应不同的遗传分布

本章原有教学生成采用高斯标记效应，使给定基因型后的育种值具有明确的高斯条件分布。为了研究非高斯架构，可以改变效应分布，同时保持相同均值和方差；但这样只固定了二阶结构，不固定条件期望、尾部概率或选择后的行为。区分这些层次，才能解释为什么某些方法在平均平方风险上相近，却给出不同区间和极端候选判断。

设固定标记矩阵为 $\mathbf{W}$ ，真实育种值为 $\mathbf{u} = \mathbf{W}\boldsymbol{\alpha}$ ，标记效应均值为零、协方差为 $\mathbf{D}$ 。无论效应是否正态，只要二阶矩存在，均有

$$\text{Var}(\mathbf{u} | \mathbf{W}) = \mathbf{W}\mathbf{D}\mathbf{W}^T.$$

因此，固定系数线性预测的总体平方风险只依赖这些二阶矩。若两种遗传架构具有相同的条件协方差和记录误差协方差，最佳线性预测系数相同，其期望平方风险也相同。这不是两种架构在所有统计问题上等价，而是特定损失与预测类别所带来的矩等价。

最小反例只需一个目标。令 u 以相同概率取正一、负一，误差 e 为独立标准正态，观测 $y = u + e$ 。目标方差和误差方差都为一，所以最佳线性预测仍为 $y/2$ ，总体平方风险为二分之一。但完整条件期望可以通过两个正态似的比值求出。

$$\frac{P(u = 1 | y)}{P(u = -1 | y)} = \exp(2y).$$

$$E(u | y) = \frac{e^{2y} - 1}{e^{2y} + 1} = \tanh(y).$$

在 $y = 2$ 时, 条件期望约零点九六四, 线性预测为一; 在 $y = 4$ 时, 条件期望约零点九九九三, 线性预测却为二, 已经超出目标可能取值的范围。后一个现象不表示线性公式计算错误, 它表明仅使用二阶矩的规则没有利用真实分布的有限支持。非线性规则的风险优势来自额外分布知识, 比较时应明确谁被允许知道这种知识。

条件方差也随观测改变。由于 u^2 恒等于一, 有

$$\text{Var}(u | y) = 1 - \tanh^2(y).$$

高斯模型在相同二阶矩下会给出恒定条件方差二分之一。于是, 固定线性 PEV 可以正确描述总体平均线性预测误差, 却不能直接充当这个离散遗传架构下每个观测值对应的真实后验方差。使用高斯分位数构造的个体区间也不再具有同样条件概率解释。检验二阶风险和检验条件分布, 需要不同的实验终点。

将这个思想用于多位点架构, 可以用标准化的稀疏混合效应、重尾效应或两点效应替代正态效应, 同时保持每个位点预定方差。效应很稀疏时, 应区别随机决定非零位点和固定非零位点位置; 前者还包含遗传架构抽样, 后者是给定架构的条件比较。若每次生成后都把已实现育种值强制缩放到同一样本方差, 会额外引入跨个体依赖, 已经不再只是保持总体二阶矩。

遗漏位点时, 真实协方差可分为可观测成分与遗漏成分。在两组效应独立的设定下为

$$\Sigma_u = \mathbf{W}_o \mathbf{D}_o \mathbf{W}_o^T + \mathbf{W}_m \mathbf{D}_m \mathbf{W}_m^T.$$

如果两组效应或背景机制相关, 还应加入交叉项。仅把可见标记重新缩放到总遗传方差, 未必恢复遗漏部分的关系方向; 缩放只能改变量级, 不能创造原来不存在的协方差结构。这个区别解释了为何标记减少实验既要保持完整真值, 又要明确遗漏背景的模式, 而不能把缺失的位点信息通过事后标准化悄悄补成另一个生成世界。

设计这类实验时, 一个有用次序是先保持二阶矩比较线性风险, 再比较非线性条件预测, 最后研究尾部和选择决策。这样能够逐层识别优势来源。若在第一层就出现理论不应存在的差异, 应优先检查有限重复误差、参数估计和实现; 只有这些层次清楚以后, 才把差异归因于对复杂遗传架构的适应。

矩等价有一个不可忽略的前提: 相关矩必须存在。若效应分布具有无限二阶矩, 遗传方差和均方风险本身不再按上述方式定义, 不能继续用有限样本方差看起来稳定作为理论依据。即使二阶矩存在而四阶矩很大, 平方损失的蒙特卡洛误差也可能由少数极端重复主导。应检查生成分布的矩条件, 必要时增加重复并报告稳健位置摘要作为补充, 但不能用中位误差替换平均风险之后仍沿用原来的最优性结论。损失函数改变, 理论参照也随之改变。

35.22 初筛之后怎样解释相关下降与尾部损失

未来候选常常已经经过早期筛选。一个模型在全部出生个体上的相关, 不一定等于它在入选候选者中的相关, 即使条件预测规则完全没有改变。为了精确区分范围缩窄与模型失效, 令标准化预测分数为 Z , 真实育种值为

$$u = rZ + \sqrt{1 - r^2} \epsilon, \quad Z, \epsilon \stackrel{ind}{\sim} N(0, 1).$$

此时正确育种值预测为 $\hat{u} = rZ$, 总体相关为 r , 预测误差与 Z 独立, 误差方差为 $1 - r^2$ 。假设只保留 $Z > t$ 的动物, 保留比例为 $p = 1 - \Phi(t)$ 。截断正态的均值和方差为

$$\begin{aligned} i &= \frac{\phi(t)}{p}, \\ E(Z | Z > t) &= i, \\ v_t = \text{Var}(Z | Z > t) &= 1 + ti - i^2. \end{aligned}$$

选择后真实育种值方差等于分数方向变异与独立剩余变异之和, 相关相应变为

$$\text{Corr}(u, Z | Z > t) = \frac{r\sqrt{v_t}}{\sqrt{r^2 v_t + 1 - r^2}}.$$

取 $r = 0.6$ ，只保留最高十分之一，截断点约一点二八一六，选择强度约一点七五五，保留分数方差约零点一六九一。真实育种值在入选群体中的均值约一点零五三、方差约零点七零零九，而相关下降到约零点二九四七。这个下降不需要任何数据泄漏、模型错设或未来环境变化，仅由候选范围改变产生。

与此同时，正确预测的条件误差方差仍为零点六四，因为选择事件只依赖 Z ，而误差与它独立。

$$E\{(u - rZ)^2 \mid Z > t\} = 1 - r^2 = 0.64.$$

因此，在这种严格限定的情形下，相关明显下降而误差尺度保持正确，两者并不矛盾。若根据相关下降立即放大或压缩所有 EBV，反而可能破坏原本正确的校准。应先问比较群体是否改变，以及使用的误差指标是否针对同一目标分布。真实资料中选择可能还依赖未纳入的健康、外貌或家系信息，此时误差独立性可能不成立，不能机械照搬本例结论。

尾部对幅度错设更加敏感。若错误使用 $\tilde{u} = bZ$ ，选择仍按同一分数进行，则额外条件风险为系数误差平方乘入选分数的二阶矩。

$$\begin{aligned} R_t(b) &= 1 - r^2 + (b - r)^2 E(Z^2 \mid Z > t), \\ E(Z^2 \mid Z > t) &= 1 + ti. \end{aligned}$$

仍取真实 $r = 0.6$ ，若使用 $b = 0.8$ ，全部群体中的额外风险为零点零四；最高十分之一内却增至约零点一三，因为被选中的分数绝对值更大。同一个比例失准，在重点使用的动物上会产生更大的平方损失。只报告总体 RMSE，可能低估实际留种边界和重点公羊的误差后果。

这个例子还给出了验证设计的明确要求。首先应保存未筛选群体与最终候选群体的进入规则；其次分别估计全群表现、条件候选表现和实际决策损失；最后说明用于筛选的分数是否与被验证模型共享信息。如果筛选规则本身由当前验证结果调整，条件总体也在事后改变，简单截断模型不再描述完整流程。

对于有限候选数，保留最高若干头意味着随机阈值，而不是固定阈值。其精确分布涉及次序统计量，固定分位数公式只提供大群体近似。小群体教学实验可以直接在每个重复内按实际规则入选，并保存真实入选目标与误差；不能为了使结果接近理论值，事后把每次候选分数强行调整为同一个截断分布。理论算例用于解释机制，有限样本复算用于量化实际规则下的偏离，两者应相互补充。

对候选尾部的分析还需要足够的独立群体，而不仅是足够多出生动物。一千只动物中最高百分之一只留下十只，家系集中可能使这些个体的误差高度相关。如果在每次模拟中只保留一个极端公羊，最终风险估计的独立单位就是每次群体重复；一次群体内更多技术测定不能增加独立的极端选择事件。事先确定尾部比例和最低精度要求，可以避免得到一个偶然优秀的极端个体之后才把评价改成“最优公羊表现”。

35.23 习题与详细解答

习题 35.1 位点传递。父本剂量为一、母本剂量为二时，求子代剂量的分布、期望与条件方差。说明为什么它不等同于把父母剂量平均后赋给每个子代。

解答。母本必传一个参考等位基因，父本以二分之一概率传参考等位基因，所以子代剂量为一或二，各占二分之一。期望为一点五，方差为四分之一。父母平均剂量只给出期望，实际子代仍具有孟德尔抽样差异；把所有子代赋为一点五还会产生不合法的整数基因型。

习题 35.2 基础方差尺度。已知 α_j 独立且方差为 $1/s$ ，基础个体剂量方差为 $2p_j(1-p_j)$ ，说明为什么加性方差期望为一。有限样本育种值方差不等于一是否表示程序错误？

解答。位点独立时，各贡献相加得到 $\sum_j 2p_j(1-p_j)/s = 1$ 。这是一种生成总体或重复抽样意义上的尺度，不强制每个有限样本恰好具有方差一。基因型、效应和家系抽样都会引起样本波动；不应为了凑成一而事后重新缩放，除非明确把这种处理作为另一生成机制。

习题 35.3 单记录预测。已知总体均值，遗传方差四、残差方差六，表型偏差三。求 EBV、PEV、可靠度和准确度，并解释哪个量可以用百分比表达。

解答。EBV 为一点二，PEV 为二点四，可靠度为零点四，准确度为 $\sqrt{0.4}$ 约零点六三二。可靠度或准确度可以按各自定义表达成百分比，但二者不能互换；EBV 保留性状单位，PEV 为单位平方。把“可靠度百分之四十”说成“育种值有百分之四十是真的”没有统计意义。

习题 35.4 亲属信息。在双个体算例中，只有第一只记录二可用时，第二只 EBV 是多少？若两者关系由二分之一降至四分之一，其他条件不变，结果怎样变化？

解答。前者为 $0.5 \times 2/2.5 = 0.4$ ，后者为 $0.25 \times 2/2.5 = 0.2$ 。关系较弱时，同一亲属记录提供的遗传证据减少。这一比较假设自身遗传方差和记录残差不变，并且固定均值已知；不能在未知均值或更复杂多记录情形中忽略其他信息结构。

习题 35.5 秩与正定性。两百八十只动物、二百四十个标记构成的 $\mathbf{G}$ 为何可能奇异？为什么本章仍能预测？是否必须对 $\mathbf{G}$ 加一个很大的对角修正？

解答。 $\mathbf{G}$ 的秩不超过标记矩阵秩，最多二百四十，小于动物数。预测求解的是训练协方差加正残差方差的矩阵，其任意非零方向二次型严格为正，所以可用 Cholesky 分解。无须仅为了求逆而改变 $\mathbf{G}$ ；若采用另一需要其逆的实现，应处理低秩结构并解释任何修正。

习题 35.6 PEV 中的固定效应。为什么在一般 PEV 公式中需要 $\mathbf{QBQ}'$ ？漏掉它会改变 EBV 吗？

解答。该项反映固定效应由同一训练资料估计带来的额外不确定性。若 EBV 公式仍正确，单独漏掉 PEV 公式中的这一项通常不改变点预测，却使误差方差偏小。只有固定效应真正已知时才可去掉。模拟者知道生成参数，不等于部署模型可以把它们当作已知。

习题 35.7 标记减少的公平比较。若只保留三十个位点作预测，同时也

把真实育种值改为这三十个位点生成，能否把性能变化解释为芯片密度减少的作用？

解答。不能。这样同时改变了信息量和真实遗传结构。研究观测密度应保留原完整真实育种值，只减少预测端可见位点，并说明未观测遗传部分怎样进入协方差。若确实研究不同遗传架构，可以另外设置该场景，但应使用不同问题名称并分别解释。

习题 35.8 相关与校准。拟合残差方差低估四倍时，相关仍约零点六零七，校准斜率却约零点六一四、覆盖率约百分之七十七。怎样向育种管理者解释？

解答。模型仍保留一定排序信息，但预测幅度被放大，且对误差过于自信。不能只以相关尚可作为大规模使用的依据。应检查方差尺度与模型设定，重新评估区间和约束后决策。高相关不保证收益预测或个体差异的尺度正确。

习题 35.9 身份错配检测。同时置换关系矩阵的行列为什么不能靠特征值检查发现身份错误？应增加什么证据？

解答。同时行列置换只是矩阵的相似变换，保留特征值和正定性；错误在于置换后行列与动物标签不再对应。需要显式主键映射、样本链记录、性别与亲子相容性等独立证据。数值合法性检查只能回答矩阵是否可作为某种协方差，不能回答它是否属于正确动物。

习题 35.10 研究设计。新方法比 GBLUP 平均相关高零点零二，但只在一个有利种子上演示，且使用了真实生成方差而 GBLUP 从小样本估计方差。提出一个更公平的比较方案。

解答。预先规定多个独立重复，在每个重复中共享生成资料和验证集；两种方法使用相同可得信息，或者分别设置已知参数与估计参数两个层次。报告成对差、蒙特卡洛标准误、校准、RMSE、覆盖及失败情况。真实参数方法可作为理想参照，但不应与信息较少的部署方法混在一起宣称算法本身优越。

多性状目标与约束配种的完整决策算例

36.1 从预测个体转向设计下一代

遗传评定回答某个动物在指定目标上的遗传水平可能怎样，育种决策还要回答使用谁、使用多少以及怎样交配。三个问题不能合成一张简单排名表。排名最高的公羊可能与大量候选母羊近亲，也可能来自已经占据很大份额的家系；一个综合得分略低的个体，却可能提供稀缺的遗传背景或补足繁殖性状。决定下一代时，个体价值与组合价值需要同时考虑。

截留选择通常先确定入选集合，再给入选者相同或预定份额。最优贡献选择则把份额本身作为变量，让高遗传目标和亲缘控制在同一个问题中权衡。Meuwissen 的经典研究建立了在预定近交约束下优化选择反应的框架 (Meuwissen, 1997)。本章在这个思想基础上，从能手算的四亲本例子出发，再进入十六只模拟候选羊的多性状决策。

预测值不是已经实现的收益。将 EBV 送入优化器，只能得到条件于这些预测和约束的推荐方案；真实后代还会经历孟德尔抽样、繁殖成败和环境变异。优化器也不负责替决策者选择价值判断。如果繁殖优先与生长优先得到不同方案，这是目标不同的正常结果，而不是某个求解器发现了唯一正确方向。

本章把决策分为两层。第一层确定亲本对后代基因库的贡献，使目标均值较高且群体共祖受控；第二层在给定贡献下安排公母配对，降低具体后代的近交期望并满足禁配等条件。两层可以分开求解，也可以建立联合模型。分开求解便于解释，但必须认识到某些实际约束可能使第一层给出的贡献在第二层无法执行。

所有候选资料都来自第 35 章的模拟生成器，绝非实际种羊名单。三个性状用基础遗传标准差表示，目标权重是教学偏好，不能直接解释为市场利润。通过这种简化，可以清楚观察改变目标、亲缘上限和不确定性处理怎样改变方案。进入真实生产时，需要重新核定性状单位、经济关系、繁殖能力和管理约束。

一个完整决策报告至少应同时给出目标定义、候选资格、贡献方案、亲缘基准、配种表及敏感性。只给出“最优目标值”不足以执行，也不足以审阅；只给配种表而不说明它优化了什么，则无法判断取舍是否合理。最终方案的质量不在于小数位多，而在于每个选择都能连接到明确目标和可检查约束。

本章还将区分三种经常混用的量：贡献组合的群体共祖、某一配种方案下的后代平均近交，以及长期每代近交增长率。它们彼此相关，却没有可以不加条件地互换的数值关系。许多看似矛盾的育种建议，正是在讨论中把这三个对象混成了一个“近交水平”。

36.2 三性状候选资料怎样生成

从第 35 章第一个模拟群体中，按预定编号选取八只公羊和八只母羊。公羊为二百、二百零二直至二百一十四的偶数编号，母羊为二百零一、二百零三直至二百一十五的奇数编号。候选资格不依据本章 EBV，所以不存在先挑选表现有利的动物再展示优化效果。固定候选集合也使三种目标情景可以直接比较。

另用随机种子二三零零一生成生长、繁殖和耗料三个标准化遗传性状。标记效应在性状间具有相关结构，其协方差尺度矩阵为

$$\Sigma_u = \begin{bmatrix} 1 & -0.2 & 0.3 \\ -0.2 & 1 & -0.1 \\ 0.3 & -0.1 & 1 \end{bmatrix}.$$

在本生成器中，生长与繁殖略呈负相关，生长与耗料呈正相关，繁殖与

耗料略呈负相关。这些是教学设定，不是某一肉羊品种的参数估计，也不意味着真实遗传相关必须取这些数值。

生长与繁殖定义为越高越好，耗料定义为在本教学目标中越低越好。这里没有把耗料解释为已经校正到相同产出的残差采食量，也没有把繁殖性状限定为某种具体计数。它们是用于说明目标权衡的连续遗传量。若转向真实育种，必须重新定义测量窗口和经济含义，特别要避免把降低耗料误解为无条件减少所有摄食而不考虑产出与健康。

三个性状分别使用单性状 GBLUP 预测，再将三个 EBV 合成多性状目标。因此本章展示的是多性状决策，而不是声称已经利用全部性状协方差完成多性状联合评定。若进行联合评定，性状间信息借用会改变 EBV 和误差协方差，后续优化步骤仍可使用，但输入必须重新计算。

这个安排有一个教学好处：可以把“怎样预测性状”与“怎样给性状价值”分开。遗传相关影响资料和预测，目标权重表达育种偏好，二者不是同一个量。一个与生长高度相关的性状，不因此自动获得较高经济权重；一个遗传力低但重要的繁殖目标，也不应因为预测较难就被赋予零价值。

候选者的三个 EBV 以同一基础标准差尺度表示，但它们的估计误差仍可能不同。标准化单位只使数值便于比较，不会让每个性状同样可靠。若把三个标准化预测直接相加，仍然隐含了特定价值判断；若再按可靠度随意乘权，则可能把预测不确定性与目标价值混在一起。本章先固定明确目标，再在后面单独研究不确定性。

资料生成的可复算性使读者能够替换相关结构或训练规模，观察方案变化。改变这些条件时，应保留候选定义和目标规则，或者明确说明哪些也随之改变。否则一个方案改善可能来自候选群体更有利，而非优化方法本身。比较优化策略与比较遗传评定方法一样，需要相同问题下的公平对照。

36.3 单位、经济权重与时间范围

综合育种目标写为 $H_i = \mathbf{a}'\mathbf{u}_i$ ，其中 $\mathbf{a}$ 表达目标性状每单位变化的价值。若性状具有不同单位，权重也必须具有相应倒数单位，才能让各项进入同一

个价值尺度。经济权重不是遗传相关、遗传力或预测可靠度，也不是对某个指标“重视程度”的随意百分比。真实经济目标需要从生产系统的收益与成本关系推导。

假设一个纯教学的边际价值系统，将生长每单位的价值设为二十、繁殖每单位设为三百、耗料每单位成本设为二点五，并假定三者已经统一到同一生产周期和同一计价基数。如果三个性状的遗传标准差分别为三、零点一五和二十五，则标准化性状上的权重为六十、四十五和负六十二点五。这个变换来自单位换算，而不是重新估计遗传参数。

如果把这些权重按绝对值总和归一化，可以得到约零点三五八、零点二六九和负零点三七三。归一化不改变线性目标下的最优排序，因为所有权重同时乘以一个正常数；但单独把每个权重变成同样大小，则改变了目标。经济指数中常见的百分比表达必须说明归一化方式，否则不同报告之间难以比较。

这个例子的数值不是当前市场价格，也不是对某地肉羊产业的盈利判断。实际生长、繁殖和耗料往往存在数量联系：多一个羔羊可能同时增加收入、饲料、人工和母羊负担；提高出栏重也可能延长饲养时间。若把这些成本收益分别计入多个性状而没有统一生产模型，就可能重复计价。边际权重应围绕明确基准系统求导，并说明其他条件如何保持。

时间范围同样重要。某项遗传改良在早期产生收益，另一项通过母羊使用年限多年累积；把它们直接相加需要明确折现、年龄结构和表达次数。若只研究下一批后代，可以采用较短目标；若评价公羊长期推广价值，则应考虑多个世代和生产阶段。没有一种经济权重能够脱离系统和时间永久适用。

非市场目标也可以进入决策，例如动物健康、福利、资源效率或维持某种适应性，但应明确采用约束、影子价格还是多目标偏好。不能因为某个目标难以货币化就自动忽略，也不能随意给它一个经济数字后声称已经完成客观测算。透明地展示多个合理目标情景，往往比隐藏价值判断更利于管理者讨论。

本章因此采用三组明确的标准化效用权重，作为可比较的教学情景。它

们的作用是展示取舍，不是推荐某个实际经济指数。读者在真实应用中可以把经过测算的经济权重代入同样框架，也可以增加最低繁殖水平或最高耗料水平等约束，但应重新检查单位、时间范围和可行性。

36.4 三种目标情景与响应的解释

三种目标分别称为生长优先、均衡目标和繁殖优先。相应权重如下，耗料权重为负表示减少耗料在这些教学情景中具有正价值。

目标	生长	繁殖	耗料
生长优先	0.75	0.10	-0.15
均衡目标	0.40	0.35	-0.25
繁殖优先	0.20	0.65	-0.15

给定候选 EBV 矩阵 $\mathbf{E}$ ，每一行对应一个动物，每一列对应一个性状，综合预测为 $\hat{\mathbf{H}} = \mathbf{E}\mathbf{a}$ 。改变 $\mathbf{a}$ 会改变综合得分，但不会改变候选者已经估计的各性状 EBV。这个分离使目标讨论不必每次都重新拟合遗传模型，也有助于识别某个名次变化究竟来自新信息还是新价值判断。

目标之间的权衡不是由遗传相关单独决定。候选群体的具体组合、预测误差、亲缘约束和使用上限共同决定可达到的结果。即使两个性状总体负相关，也可能存在兼顾二者的优秀个体；但如果这些个体彼此高度相关，群体方案仍可能需要作出取舍。优化器处理的是当前候选集合中的可行组合，而不是抽象无限总体中的理想反应。

预期后代平均育种值为 $\mathbf{E}'\mathbf{c}$ ，其中 $\mathbf{c}$ 是亲本基因贡献。这个量相对于 EBV 所用基础基准定义。如果要称为相对于某个现有群体的遗传增益，应再减去该参考群体的平均水平。把正的后代均值自动称为增益，可能忽略参考群体本来已经为正；把负均值自动称为退步，也可能忽略实际参考群体更低。

本例等贡献使用十六只候选者时，三个后代均值约为负零点零六三、零点零五七和负零点零七三。均衡优化后的均值约为零点一零五、零点一零二

和负零点二四零。因此相对于等贡献参考，改变分别约为零点一六八、零点零四五和负零点一六七。报告基础水平与相对改变，可以帮助读者避免将两个概念混为一谈。

不同目标的综合数值不能直接互相比大小来宣布哪个目标更好，因为权重本身不同。生长目标值零点一八与均衡目标值零点一四不在同一种价值定义下。可以在共同目标下评价不同方案，也可以并列展示各性状后果，但不能把不同效用函数的最大值当作同一尺度的比赛成绩。

情景分析最好让决策者看到可接受与不可接受的变化。例如某方案提高生长却使繁殖低于规定基准，若繁殖下降不能接受，应把它写成约束或调整权重，而不是事后口头要求“再兼顾一点”。明确的偏好和底线能够进入计算，含糊的愿望只能在结果出来以后反复争论。

36.5 候选资料与信息可靠性的阅读

下表列出均衡目标计算所用的候选 EBV 和最终贡献。偶数编号为公羊，奇数编号为母羊；表中数值为便于阅读的四舍五入值，优化使用完整精度。贡献是后代总基因来源的份额，不是直接的配种百分比。

个体	生长 EBV	繁殖 EBV	耗料 EBV	贡献
200	0.914	−0.046	0.474	0.0793
202	0.275	−1.036	0.443	0.0493
204	−0.219	0.358	0.747	0.0573
206	−1.369	0.698	0.025	0.0356
208	−0.356	0.207	0.380	0.0171
210	0.838	0.391	−0.289	0.0870
212	0.338	0.937	−0.365	0.1025
214	0.926	−0.940	0.294	0.0719
201	−0.879	−0.410	−1.434	0.0434
203	−0.372	−0.272	0.994	0.0158

个体	生长 EBV	繁殖 EBV	耗料 EBV	贡献
205	0.586	-0.002	-0.723	0.1139
207	-0.901	0.405	-0.812	0.0686
209	0.077	0.053	-0.451	0.0917
211	-0.324	0.609	-0.598	0.0687
213	-0.122	0.095	1.182	0.0272
215	-0.425	-0.139	-1.041	0.0706

阅读这张表时，首先不要把正负号当作简单优劣标签。耗料为负在本目标中有利，生长或繁殖为负则相对于基础均值偏低。一个动物可能在多个方向上各有优劣，综合得分由目标权重决定。例如公羊二一二兼有较高繁殖与较低耗料，均衡情景下获得较高份额；但若只关注生长，其他候选者可能更具优势。

其次，最终贡献并不按综合得分机械排序。亲缘较高的动物同时大量使用会占用共祖预算，某个得分略低但关系结构有价值的个体可以保留份额。相反，多个优秀全同胞之间可能需要分配而非全部高强度使用。要解释一个贡献方案，必须同时查看目标得分与关系矩阵，单看 EBV 表无法判断优化器是否合理。

表中的贡献没有直接显示预测不确定性。在基础方案中，优化器把 EBV 当作给定点估计，这使问题清晰，也暴露一个限制：两个得分接近但可靠度不同的候选者可能被同样对待。后面将讨论如何通过方案误差方差或后验情景表达不确定性，而不是简单把所有低可靠度动物删除。

候选资格应在计算前确定。某只动物若存在健康、繁殖能力或资源限制，应通过资格或约束表达；不能先优化，再发现最高贡献个体无法使用，随意把份额分给下一名而不重算。临时替换会改变亲缘和性状组合，原来的最优性与约束满足可能都不再成立。

候选数量也影响结论。十六只动物只是一个小型教学集合，不能代表实

际计划中所有可能遗传来源。若扩大候选群体或引入外部亲本，目标与亲缘前沿可能改善，但也可能增加适应性和资料可比性问题。新候选者的加入应伴随同一尺度评定和资格核查，而不只是把一行高 EBV 数字添加到表中。

最后，表格保留四位贡献小数是为了核对连续解，不意味着生产现场可以执行如此精细份额。实际后代数有限，需要转为整数配种或后代数，并重新检查约束。本章将专门展示独立四舍五入如何使原本可行的方案超出共祖上限。

36.6 基因贡献、亲本使用份额与后代均值

本章定义 c_i 为亲本 i 占下一代总基因来源的比例，所有贡献和为一。对常规公母分开的加性遗传系统，父系贡献和为二分之一，母系贡献和也为二分之一。如果公羊 $c_i = 0.08$ ，它承担的父亲配种份额为 $2c_i = 0.16$ ，在一百个成功后代中对应期望十六个，而不是八个。

这个系数二来自每个后代一半基因来自父本、一半来自母本。若用 n_i 表示某亲本产生的后代数，总后代数为 N ，则基因贡献为 $n_i/(2N)$ 。不同文献或软件可能使用性别内归一化贡献，使公羊份额和为一、母羊份额和为一；两种定义都可以，但公式中的系数必须相应变化。混用定义会使共祖和目标计算出现成倍错误。

在纯加性模型下，给定配种对的后代期望育种值为父母育种值平均。对全部配种加权后，下一代平均目标恰好为 $\hat{\mathbf{H}}'\mathbf{c}$ 。因此第一层优化可以只用贡献，而不必先知道每一个具体配对。这一性质依赖加性均值与固定贡献；若目标包括优势、特定组合能力、隐性缺陷风险或其他配对特异效应，配种方式也可能影响目标均值。

贡献还可以区分计划值与实现值。计划安排某公羊完成百分之二十配种，不保证最终成功后代也占百分之二十。受胎率、胚胎存活和后代淘汰会改变实际贡献。若这些差异可预测，可以在计划中加入成功率或风险约束；若未知，则应监测实现贡献并在后续周期调整。只保存计划表而不记录实际后代，会使长期亲缘管理失去依据。

贡献上限限制个体使用强度。例如本例 $c_i \leq 0.125$ 意味着单一公羊最多承担四分之一父系后代，单一母羊同理。这是教学中的对称限制，不符合某些真实繁殖系统中公母能力差别很大的情况。实际公羊可服务多只母羊，而母羊后代数受生理与繁殖技术限制，约束应按具体系统分别设置。

最低贡献约束也需要谨慎。为了保留某个家系或稀缺来源，可以规定一定份额，但这可能降低短期目标并增加其他约束压力。若只要求“每个家系都保留”，应明确按哪些家系定义、是否允许多个亲缘很近的支系重复满足，以及最低份额对应多少真实后代。没有精确定义的保种要求容易在计算中产生形式合规而实质无效的结果。

有时使用贡献平方和的倒数作为描述性“有效贡献者数量”。它能反映份额集中程度，但不等于有效群体大小，因为后者还受亲缘、世代重叠、性别比例和繁殖方差影响。两个方案具有相同贡献平方和，若亲本关系不同，其长期遗传多样性后果仍可能不同。可以报告这种简洁指标，但必须保留正确名称和解释边界。

36.7 群体共祖与后代近交不是同一个量

设候选者的系谱加性关系矩阵为 $\mathbf{A}_c$ ，则亲缘系数矩阵为 $\mathbf{A}_c/2$ 。按基因贡献加权的群体共祖定义为

$$q(\mathbf{c}) = \frac{1}{2} \mathbf{c}' \mathbf{A}_c \mathbf{c}.$$

它考虑从贡献组合中抽取两个基因来源时的共同祖先概率，并包含同一个体的对角贡献。这个量适合描述亲本组合的集中程度，但不等于某个具体公母配种表下的平均后代近交。

最简单的区别来自完全无关且不近交的亲本。此时 $\mathbf{A}_c = \mathbf{I}$ ，群体共祖为贡献平方和的一半，只要使用有限数量亲本就大于零；然而任意不同公母之间的亲缘为零，它们的当前后代近交期望可以为零。因此，“群体共祖为正而当前后代近交为零”并不矛盾，也不表示优化公式有误。

群体共祖包含公公、母母和公母之间的关系，还包含对角；实际后代近交只取决于真正发生的公母配对。改变配种方式可以在保持所有贡献不变时

改变后代近交，但不会改变 $q(\mathbf{c})$ 。反过来，降低 q 通常有利于长期多样性，却不自动给出每一对配种的近交上限，仍需要第二层配对约束。

同样不能把绝对 q 上限直接叫作每代近交增长率。增长率涉及相邻世代、基准和归一化方式，常与当前近交水平共同定义。一个基础关系不同的群体，绝对共祖数值也会不同。真实计划应根据历史、世代结构和长期目标选择控制指标，而不是把本章某个教学数值当成普遍推荐标准。

如果采用基因组关系替代系谱关系，解释还取决于标记基准和尺度。某些 $\mathbf{G}$ 具有负非对角值，表示相对于参考频率的低于平均相似性；直接把它除以二并当作绝对身份同源概率，需要特别谨慎。可以用相容的基因组关系控制相对多样性，但应明确它与系谱近交、纯合度或连续纯合片段指标之间的区别。

本章使用系谱 $\mathbf{A}_c$ 控制贡献，并用同一系谱计算配种后代近交，使两个层次的基准一致。基础个体被假定互不相关，因此所有数值都相对于这个有限系谱基准。优化得到某些配对近交为零，只说明记录范围内父母无共同祖先贡献，不能证明整个真实基因组不存在远祖共享。

对于管理者，最有用的报告往往不是只给一个“近交指数”，而是并列给出群体共祖、当前配种平均近交、最高单配对近交及其基准，再说明长期监测安排。这样可以看出方案是否通过少数高风险配对换取较低平均值，也能防止把眼前避免近亲交配误认为已经解决长期遗传集中。

36.8 最优贡献问题与可行性边界

本章基础优化为最大化 $\hat{\mathbf{H}}'\mathbf{c}$ ，满足群体共祖不超过 $q_{\max}$ 、公母贡献各为二分之一，以及个体上下限。写成紧凑形式为

$$\max_{\mathbf{c}} \hat{\mathbf{H}}'\mathbf{c}, \quad \frac{1}{2}\mathbf{c}'\mathbf{A}_c\mathbf{c} \leq q_{\max}.$$

再加上 $\mathbf{Lc} = \mathbf{d}$ 表示性别总量等线性等式， $\mathbf{l} \leq \mathbf{c} \leq \mathbf{h}$ 表示使用限制。模型中的每个约束都应对应实际理由，不能只因为求解软件支持就任意添加。

若 $\mathbf{A}_c$ 半正定，共祖约束定义凸集合，目标为线性函数，所以该连续问题具有良好的凸优化结构。局部最优与全局最优的关系在适当条件下较清楚，

但这并不意味着任何求解器返回成功就已经充分验证。仍应检查等式残差、上下限、共祖值和数值容差，必要时比较不同初值或利用问题结构核验。

建立目标最大化问题前，可以先在相同线性约束下最小化共祖，得到 $q_{\min}$ 。若设定的 $q_{\max} < q_{\min}$ ，问题没有可行解；这是一种目标冲突，不是求解器运行不够久。先求可行边界能够让管理者知道现有候选群体和使用限制最低能达到什么水平，再决定是否增加候选来源或调整其他条件。

拉格朗日乘子提供一种解释：当共祖约束紧约束时，其乘子反映在局部范围内放宽共祖预算可能换来多少目标提升。它不是某种永恒经济价格，而是当前候选、目标和其他约束下的边际取舍。若个体使用上限也紧约束，放宽共祖未必都用于同一个优秀动物，方案可能在多个限制之间切换。

目标权重统一乘以一个正数不会改变最优贡献，但会改变目标值和对应乘子尺度。把遗传目标单位从元改为百元时，方案应保持一致；若发生变化，应检查是否还有未同步缩放的风险惩罚或软约束。这种尺度检查在把经济目标与方差惩罚合并时尤其重要，因为两个项的单位不同。

严格的最低贡献可能使可行集合变小甚至为空。比如要求八只公羊都至少贡献零点零八，父系总贡献已超过二分之一，根本不可能满足。这样的错误可以在优化前通过简单加和发现。另一些冲突来自关系结构，需要计算 $q_{\min}$ 才能识别。把可行性检查作为独立步骤，能避免将输入矛盾误判为算法失败。

连续解有时不唯一。若多个候选者目标相同且关系结构对称，很多贡献分配都能达到同样目标。不同求解器可能返回不同但等价的方案，不能仅凭逐项贡献不同就认定某个实现错误。应首先比较目标值、共祖和约束，再根据管理偏好选择更易执行或更稳定的等价方案。

36.9 四亲本算例与解析贡献前沿

考虑两只公羊和两只母羊，综合 EBV 分别为十二、十一、八、七。两只公羊为全同胞，加性关系为零点五，其余非对角关系均为零，所有对角为一。公母总贡献各为二分之一，每只最多零点五。这个小例子既能数值优化，也

能通过两变量代换直接推导，适合检查最优贡献的几何意义。

令贡献为 $(0.25 + x, 0.25 - x, 0.25 + y, 0.25 - y)'$ 。在不触及上下限时，目标变为 $9.5 + x + y$ ，群体共祖为

$$q = 0.15625 + 0.5x^2 + y^2.$$

等贡献对应 $x = y = 0$ ，目标九点五，共祖零点一五六二五。增加优秀公羊和优秀母羊的贡献都会提高目标，但由于公羊之间有亲缘，两个方向的共祖代价不同。

设允许的额外共祖预算为 $\delta = q_{\max} - 0.15625$ 。在内部解中，最大化 $x + y$ 且 $0.5x^2 + y^2 \leq \delta$ 。一阶条件给出 $x = 2y$ ，于是 $y = \sqrt{\delta/3}$ 、 $x = 2\sqrt{\delta/3}$ 。这说明最优方向由目标梯度和关系几何共同决定，不是把两只最优秀亲本的贡献增加相同幅度。

当 $q_{\max} = 0.18$ 时， $\delta = 0.02375$ ，得到 $x \approx 0.177951$ 、 $y \approx 0.088976$ 。贡献约为零点四二八、零点零七二、零点三三九和零点一六一，目标约九点七六六九三。数值优化与解析结果一致。方案保留了次优公羊和次优母羊，因为完全集中使用最佳者会超过共祖预算。

共祖上限	最佳公羊贡献	最佳母羊贡献	最优目标
0.15625	0.2500	0.2500	9.5000
0.16000	0.3207	0.2854	9.6061
0.18000	0.4280	0.3390	9.7669
0.20000	0.4915	0.3708	9.8623
0.25000	0.5000	0.5000	10.0000

表中目标随共祖预算增加而提高，但边际收益并不恒定。接近最小共祖点时，允许少量偏离等贡献就能获得一定目标提升；接近个体上限时，新的约束开始起作用。优秀公羊贡献达到零点五以后，继续增加目标只能主要通过母羊方向调整，前沿表达随之分段变化。

这个算例还展示了“约束紧”与“方案脆弱”不是同一概念。最优解通常




图 36.1 四亲本例子的连续目标前沿与核验点。绿色菱形表示共祖上限零点一八时二十后代整数问题的最优目标，横坐标是允许上限而非某一等价整数解的实际共祖

用尽给定共祖预算，但只要候选目标或关系发生变化，最优位置就会移动。管理者应查看预算附近的前沿，而不是只盯住一个点。如果将上限从零点一八改为零点一七九就需要完全不同的亲本集合，执行时应特别关注整数化和预测误差。

由于本例所有公母之间关系为零，无论怎样安排当前配对，第一代后代近交期望都为零；群体共祖却明显不同。这再次表明贡献控制服务于遗传来源集中与后续群体结构，不只是避免眼前近亲交配。如果只用当前后代近交作为唯一指标，就会看不出完全使用两只最佳亲本带来的长期集中。

解析小例子还有程序核验价值。若数值解在零点一八上限下给出目标超过十，或者贡献和不符合公母各半，显然存在错误；若给出比等贡献还低的目标，也应检查求解方向和约束。可解释的界限比仅看“优化成功”提示更有用。

36.10 十六候选群体的三情景结果

对十六只候选羊，首先在性别贡献各半和单个贡献不超过零点一二五的条件下最小化群体共祖，得到 $q_{\min} \approx 0.045315$ 。再把上限设为 $q_{\min} + 0.008 \approx$

0.053315。这个增量是预设的教学预算，用来形成可观察的目标与亲缘取舍，不是针对实际肉羊群体的推荐近交标准。

三个目标的最优解都达到这一共祖上限。它们使用相同候选者、相同关系矩阵和相同能力限制，差别只在性状权重。预期后代平均 EBV 如下，全部相对于生成基础基准，单位为各性状遗传标准差。

目标	生长均值	繁殖均值	耗料均值	群体共祖
生长优先	0.232	-0.046	-0.094	5.331%
均衡目标	0.105	0.102	-0.240	5.331%
繁殖优先	-0.078	0.239	-0.182	5.331%




图 36.2 同一候选群体、相同共祖约束下三种目标的预期后代性状水平。耗料保留原方向，负值表示相对于基础减少

生长优先使生长平均水平最高，但繁殖相对于基础略为负；繁殖优先使繁殖最高，同时接受生长均值为负。均衡目标在本候选群体中获得较明显耗料下降，也兼顾了正的生长与繁殖均值。没有一个方案可以脱离目标被称为普遍最好，因为三者体现不同价值判断。

相对于等贡献参考，生长优先的繁殖改变约为负零点一零三，而繁殖优先的生长改变约为负零点零一五。后一个数值比其相对于基础的负零点零七

八更接近零,说明基准选择会显著影响“代价”的口头解释。报告应同时说明从什么群体出发、改变了多少,以及绝对水平相对于哪个遗传零点。

均衡情景十六只候选者都保留了正份额,生长优先有十五只获得实质份额。这个结果不是最优贡献必然要求尽量多使用动物的规则。若目标差异很大、共祖预算宽松或使用上限不同,最优解可能集中于较少亲本;若预算更严格或稀缺家系具有优势,也可能保留更多。应让约束和关系结构决定结果,而不是预先把“人人有份”当作优化目标。

贡献平方和倒数在三种方案中约为十二点六、十三点二和十三点七,可以作为使用集中程度的简要描述。它不能替代真实有效群体大小,也不能比较不同关系基准下的长期遗传风险。共同报告 q 和贡献分布,有助于看出相同共祖上限下仍然存在不同的个体集中方式。

这些结果只使用点估计 EBV。真实育种值已知于生成器,但没有进入优化,因此可以在进一步研究中评价预测方案与真值最优方案之间的差距。本章没有把预测目标值当作已经实现的真实遗传收益。区分“优化器对给定预测做得多好”与“预测本身多接近真值”,是评估整个育种决策链的关键。

36.11 配种分配作为运输问题

给定贡献后,令 P_{sd} 为公羊 s 与母羊 d 这一组合占全部配种的比例。它满足行和 $\sum_d P_{sd} = 2c_s$, 列和 $\sum_s P_{sd} = 2c_d$, 以及非负约束。所有单元之和为一。行列边际固定了各亲本使用份额,单元内部的分配决定谁与谁交配。

对于子代而言,父母亲缘系数为其系谱近交期望。因此总体平均为

$$\bar{F} = \frac{1}{2} \sum_s \sum_d P_{sd} A_{sd}.$$

在固定边际下最小化这个线性目标,是一个运输型线性规划。随机配种取 $P_{sd} = (2c_s)(2c_d)$, 满足相同边际,但不主动避免有亲缘的配对。优化配种则利用边际内部的自由度降低近交。

一个独立的四亲本例子可以直接看出差别。设公羊一与母羊一的关系为零点二五,公羊二与母羊二同样为零点二五,两个交叉组合关系为零,同性

别之间也无关系。四个亲本等贡献时，群体共祖为零点一五六二五。随机配种的四个组合各占四分之一，后代平均近交为零点零六二五。

若只安排两个无亲缘交叉组合，各占二分之一，后代平均近交为零；若只安排两个有亲缘的对角组合，各占二分之一，平均近交为零点一二五。三种配种具有完全相同亲本贡献和后代加性目标均值，却有不同近交后果。这个例子也表明，单看贡献方案无法知道实际后代近交。

若管理限制禁止一个无亲缘交叉组合，原来的零近交方案可能不再可行。固定边际可能迫使一部分有亲缘配对出现，甚至迫使全部使用对角组合。禁配、精液可用性、母羊繁殖时点和场站隔离都可能改变运输问题的可行集合。因此在第一层确定贡献后，应立即检查第二层是否可执行，必要时联合调整。

对十六候选教学群体，三种目标的随机配种平均近交分别约为百分之零点九二零、一点二五七和一点六零零。最低亲缘配种均可达到零，因为该小群体仍有足够的已知无亲缘公母组合满足边际。这不是对现实群体的保证，而是当前关系矩阵与份额下的计算结果。




图 36.3 均衡目标下的随机与最低亲缘配种比例。两图行列边际相同，变化来自配对安排；右图为众多可能等价低成本解中的一个

零的含义必须保持限定：它相对于已记录系谱和基础不相关假设，表示有正配种份额的公母组合可选为 $A_{sd} = 0$ 。它不表示基因组绝对无共享，不

保证未来世代仍可零近交，也不改变亲本组合群体共祖为百分之五点三三一的事实。过度解释这个零，会把短期配对优化误当作长期多样性问题的终点。

运输问题通常存在多个同样低成本的解。若很多配对关系都为零，求解器可能返回较稀疏的配种矩阵，另一求解器返回不同的零成本分配。二者可以同样正确。实际选择可以进一步考虑场站、运输、繁殖批次或管理便利，但这些次级目标应明确加入或在等价解中选择，而不应假定某一数值输出具有唯一生物学优越性。

36.12 连续最优解怎样转为整数方案

连续贡献适合分析目标与亲缘前沿，但实际后代数有限，不能执行零点七次配种。将连续份额转为整数时，最危险的做法是逐个独立四舍五入，然后假定原约束仍然成立。总数、性别份额、使用上限和群体共祖都可能改变，尤其最优连续解通常恰好位于共祖边界附近。

回到 36.9 节四亲本贡献优化例子，设计产生二十个后代，共祖上限零点一八。连续最优公羊后代数约为十七点一二和二点八八，母羊约为十三点五六和六点四四。若直接取公羊十七与三、母羊十四与六，贡献为零点四二五、零点零七五、零点三五和零点一五，群体共祖变为零点一八一五六二五，已经超过上限。

这个超限不大，却不能因为数值接近就忽略。若上限具有明确管理含义，应在整数方案中真正满足。对两公两母、二十个后代的所有可能计数进行穷举，可以得到可行最优目标九点七五，略低于连续上界九点七六六九三。连续最优给出的是整数问题的参照上界，不是保证能够原样执行的方案。

第一公羊后代数	第一母羊后代数	目标值	群体共祖
15	15	9.7500	0.17969
16	14	9.7500	0.17750
17	13	9.7500	0.17719
18	12	9.7500	0.17875

表中四种方案具有相同目标，却有不同共祖。若其他条件相同，管理者可以选择共祖较低或更易执行的一种；这说明整数优化也可能存在多个等价目标解。未经说明地只保留求解器给出的第一种，并不代表其他方案没有价值。

对较大群体，可以使用混合整数优化或先舍入再修复的明确算法。修复应以实际约束为准，重新计算目标损失和共祖，而不是只修正总配种数。若先固定各亲本整数后代数，再求整数运输配种，在标准运输结构下具有有利的整数性质；但加入复杂逻辑约束以后，不能继续假定所有线性松弛解自然为整数。

后代数与配种次数也不相同。若受胎和成活不确定，一次配种可能没有后代或产生多个后代。可以把整数计划解释为预期成功后代数，也可以直接建立配种事件计划并模拟实现贡献。二者对应不同实施层次，报告需要说明单位。把实际多胎繁殖简化为每次恰好一个后代，是教学便利而非生产事实。

整数化之后还应复核禁配、亲本最大使用次数、母羊可用时段和场站能力。连续模型中的一种公平分配可能在整数层面让某些小家系完全消失，或使某个亲本超过实际服务能力。最终可执行方案应以整数层的检查为准，并保留与连续参照之间的目标和亲缘差异，便于理解实施成本。

36.13 将实际约束写成明确条件

育种计划中的约束可以分为生物学能力、遗传底线和组织实施三类。生物学能力包括繁殖年龄、精液供应、母羊可繁殖次数和健康资格；遗传底线包括近交上限、禁配、特定性状最低水平或保留稀缺来源；组织条件包括场站容量、运输限制、测定安排和预算。分类不是为了让每类分别优化，而是帮助判断约束来源、是否可调整以及调整会产生什么后果。

硬约束表示不能违反的条件，软约束表示可以付出一定代价后放宽的偏好。两者不应随意互换。若某个已确认的遗传缺陷组合必须避免，就应将相应配种单元设为零；若只是希望减少运输，可以把运输成本作为次级目标或惩罚。用一个较小惩罚替代真正禁配，可能使优化器为了目标收益主动接受

本来不允许的组合。

性状底线可以直接写为 $\mathbf{e}_k' \mathbf{E}' \mathbf{c} \geq r_k$, 其中 $\mathbf{e}_k$ 选择第 k 个性状。这样可以要求繁殖平均水平不低于某个参照, 同时继续优化综合目标。底线应说明相对于基础均值、现有群体还是某个外部标准。若把三种基准混用, 约束数值虽然形式正确, 生物学解释却会发生改变。

家系保留也需要精确定义。若要求每个父系家族至少保留一定份额, 可以用家系成员贡献之和表示; 若要求保留不同创始来源, 则仅按最近父号分组可能不够, 因为多个父系家族可能共享更早祖先。某些稀缺来源与目标性状不利相关时, 保留要求会产生可见成本, 应通过目标前沿展示, 而不是把成本隐藏在“综合考虑”四个字中。

性别约束不一定对称。公羊服务能力可能高, 母羊份额由实际繁殖数量限制; 胚胎移植又可能改变母系上限。模型应按使用技术设定, 不应为了数学整齐强行给两性相同上限。若允许跨场冻精共享却不允许活体母羊转移, 配种可达性也具有方向与地点结构, 需要在第二层明确表达。

隐性缺陷管理需要区分个体携带与配对风险。一个携带者不必在所有情况下被完全排除, 关键取决于目标、遗传方式、可检测程度和管理要求; 但这里不能仅凭一般优化框架作具体疾病决策。数学上可以将禁止组合、最大风险或特定基因型比例写入模型, 生物学与管理参数则需要相应专业证据。错误的风险输入会让精确求解产生错误方案。

约束增加后, 应重新求最小共祖和最大可达性状水平。若要求繁殖达到某个底线、同时生长与耗料也各自达到候选极值, 往往没有可行组合。优化器报告无可行解是在揭示条件冲突, 不能通过放宽数值容差掩盖。可以逐项计算约束的最小放宽量, 让决策者看到冲突来自哪里。

对于可以协商的条件, 情景表比一次性给出一个折中解更有用。例如依次提高繁殖底线, 记录综合目标损失与使用家系变化; 或者比较允许与不允许外部公羊时的共祖边界。这样的结果把组织选择转化为透明取舍, 使讨论集中在真正可改变的条件, 而不是反复争论某个候选者应该多用还是少用。

实施约束还应考虑结果更新。配种开始后若某只公羊无法使用, 不应简

单按原比例分摊其份额，因为替代者关系和性状不同。应在剩余可用集合与已经完成的配种条件下重新优化，把已发生部分作为固定历史。动态调整需要保存实时实现贡献，这也是数据体系与优化模型必须连接的原因。

36.14 方案不确定性与均值—方差权衡

基础 OCS 把 EBV 作为确定输入，但 EBV 本身只是未知遗传值的预测。设综合遗传值在给定资料下的均值为 μ ，误差或后验协方差为 Σ_H ，则贡献方案的目标均值为 $\mu'c$ ，不确定性方差为 $c'\Sigma_Hc$ 。后一个量包含候选误差相关，不能只把各个体 PEV 乘贡献平方后相加，除非误差确实不相关。

一种透明的教学扩展是最大化

$$\mu'c - \lambda c'\Sigma_Hc,$$

并保留原亲缘和能力约束。参数 λ 表达对方案不确定性的厌恶，具有与目标尺度相容的单位。它不是遗传方差，也不是近交惩罚，两种二次型控制不同对象：关系矩阵描述遗传来源集中，误差协方差描述我们对方案结果知道多少。

考虑一个独立的两候选父本例子，使用性别内份额 p ，两份额和为一。目标预测均值分别为一点二和一，误差标准差分别为零点八和零点二，并暂设误差独立。若只最大化均值，会全部使用第一只；如果重视不确定性，第二只虽然均值略低，却能够降低方案方差。这里的均值是父系候选平均水平，若母系目标为零，后代均值还要乘二分之一。

令第一只份额为 x ，则均值为 $1 + 0.2x$ ，误差方差为 $0.64x^2 + 0.04(1 - x)^2$ 。在内部解中，对均值减风险惩罚求导即可得到最优 x ，并根据零至一边界截取。数值结果如下。

风险权重	第一只份额	目标均值	误差方差
0	1.0000	1.2000	0.6400
0.25	0.6471	1.1294	0.2729

风险权重	第一只份额	目标均值	误差方差
0.50	0.3529	1.0706	0.0965
1.00	0.2059	1.0412	0.0524

这个例子显示，风险控制并不是简单选择“可靠度最高”的动物。即使风险权重为一，仍保留第一只部分份额，因为它提供较高均值，而分散使用能够折中。若两只误差高度正相关，分散的风险降低作用会减弱；若误差负相关，则可能更强。因此方案不确定性必须使用完整协方差结构，单个可靠度列表不足以描述组合风险。

风险参数如何选择是价值判断与证据问题，不能由优化器自动决定。可以报告一系列 λ 对应的均值与方差前沿，让决策者看到为降低不确定性付出了多少预期目标。若目标单位改变， λ 也要按相应关系调整，否则会无意改变偏好。把不同单位下同一个数值 λ 称为相同风险厌恶，是不正确的。

这种方法仍依赖不确定性估计是否校准。如果 PEV 严重偏小，风险惩罚也会偏弱；如果遗漏共同家系误差，方案可能看似分散却仍暴露于同一信息偏差。第 35 章的方差错设实验说明，点预测相关尚可时，误差尺度也可能明显错误。稳健决策不能建立在未经检查的不确定性矩阵上。

均值—方差目标还把上行与下行波动对称处理。某些决策者主要担心结果低于最低繁殖水平，而不反对超出预期的好结果，这时方差惩罚未必最贴合偏好。可以使用下尾风险或机会约束，但每种形式都需要清楚说明它控制哪一种失败。模型越复杂，越需要用小例子确认其价值含义。

对于已有亲缘约束的 OCS，增加误差风险惩罚后可能出现两种不同的分散：为了保护遗传多样性而分散祖先，为了减少预测不确定性而分散信息来源。二者有时一致，有时冲突。例如一个稀缺家系可能资料很少，保留它有利于多样性却增加短期不确定性。把两种理由分别报告，有助于理解为什么方案没有简单集中于最高可靠度家系。

36.14.1 共享信息怎样改变组合风险

两个候选者各自 PEV 相同, 并不表示它们组成的方案具有相同风险。若它们的预测依赖同一批高信息亲属, 一次家系均值误判可能同时影响两者, 误差因而正相关; 若模型中存在某些对比约束, 也可能出现负相关方向。方案风险需要完整的误差协方差, 这与群体关系矩阵虽然有关, 却不能直接互相替代。

继续使用两候选例子, 在对角方差零点六四和零点零四不变的条件下, 将误差协方差分别设为负零点一二、零和正零点一二。三张矩阵均为正定, 风险权重固定为零点五。负协方差时, 第一只最优份额约零点三九一, 方案误差方差约零点零五六; 独立时份额约零点三五三, 方差约零点零九六; 正协方差时份额约零点二七三, 方差约零点一一六。相同个体误差摘要可以产生不同组合。

这个算例没有证明实际家系误差一定具有某个符号, 而是说明遗漏非对角元素可能改变决策。若只保存每只动物的可靠度, 后来就无法精确重建任意亲本组合的风险。对于需要风险优化的评定系统, 应在可行计算范围内保留或能够求得相关误差协方差, 或者明确采用何种近似及其验证结果。

此外, 方案目标的不确定性与未来后代个体的孟德尔抽样不是同一个量。即使亲本真实育种值完全已知, 单个后代仍会围绕父母平均发生遗传抽样; 如果评价的是有限后代群体平均, 还需考虑这种抽样和繁殖数量。本文均值—方差例子主要描述亲本遗传目标预测的不确定性, 不能直接作为所有未来产出变异的总和。

当后代数很大时, 独立抽样部分可以在群体平均中减弱, 而由共同亲本预测偏差产生的误差不会按同样速度消失。这解释了为什么大规模推广一个信息不足的公羊可能放大决策风险: 增加后代数量提高了影响范围, 却不自动增加作出原决策时对亲本遗传值的认识。风险评估应把使用规模与信息可靠性连接起来。

36.15 下尾风险、机会约束与近期方法进展

当决策关注较差情景时，可以直接研究方案目标分布的下尾，而不只看方差。设从合理的条件遗传值分布中得到 L 个情景，每个情景给出 $\mathbf{H}^{(\ell)}$ ，某一贡献方案的目标为 $(\mathbf{H}^{(\ell)})' \mathbf{c}$ 。这些情景可以来自后验抽样或经过校准的误差生成，但不能只是对 EBV 任意加独立噪声而忽略家系和性状相关。

对下尾比例 α ，一个常用表达通过辅助变量 τ 写成

$$\max_{\mathbf{c}, \tau} \left[\tau - \frac{1}{\alpha L} \sum_{\ell=1}^L \max\{0, \tau - (\mathbf{H}^{(\ell)})' \mathbf{c}\} \right].$$

它强调较差部分的平均目标，而不是全部情景的简单均值。实际优化可以再引入非负辅助变量表示正部，从而得到适合数值求解的形式。符号方向需要特别注意：最大化收益下尾与最小化损失上尾在写法上相反，不能把风险公式照搬而不核对目标方向。

一个离散教学例子最容易解释。方案甲在十个等概率情景中，九次目标为一点二，一次为负零点八，平均恰为一；方案乙在所有情景中目标都为零点九。只看均值，甲更好；看最差十分之一情景，甲为负零点八，乙为零点九。选择哪一个取决于能否承受少量很差结果，而不是某个方案在所有意义上支配另一个。

Ahlinder 和 Waldmann 于二〇二六年发表的研究将 EBV 后验不确定性通过条件风险度量纳入最优贡献目标，提出关注较差结果的决策框架 (Ahlinder 和 Waldmann, 2026)。这表明最优贡献研究正在从仅使用点估计，扩展到明确处理预测分布。该论文的实例与本书肉羊教学群体不是同一资料，本章不把其具体性能当作肉羊现场应用证据。

与风险目标不同，机会约束可以要求某个性状达到底线的概率不低于规定水平。如果方案繁殖目标在条件模型下近似正态，其均值为 $m_f(\mathbf{c})$ 、标准差为 $s_f(\mathbf{c})$ ，则要求 $m_f - z_{1-\alpha} s_f \geq r_0$ 能够表达一个单目标下尾保证。这个形式依赖分布和方差估计，不能在明显偏态或未校准情形中只凭正态分位数宣称精确保证。

多个性状各自满足九成概率，不意味着全部同时满足的概率也为九成。

联合事件取决于性状相关，还涉及多重约束的组合。可以直接用联合情景检查，或采用明确的保守分配方法，但必须说明控制的是单项还是整体失败概率。把每个约束单独漂亮地写出，不能代替对联合决策风险的分析。

近期计算工具也更加重视贡献与配种的连接。Waldmann 在二〇二五年的研究中讨论了基因组最优贡献和配种分配的两阶段优化，并区分二元与整数配种形式 (Waldmann, 2025)。对于实际使用者，重要启示是配种事件与连续贡献需要不同层次的变量和约束；不能因为第一阶段得到了连续最优份额，就认为第二阶段已经自动完成。

新风险形式不应成为绕过基础核验的理由。后验抽样需要检查收敛和有效样本量，情景优化需要检查情景数量与尾部估计稳定性，最终整数方案还需要重新计算风险。如果下尾比例很小而只有很少情景，目标可能由一两个抽样值决定，方案会非常不稳定。应把数值抽样误差与真正的遗传不确定性分开。

在实务上，可以从基础点估计方案开始，再给出均值—方差和下尾方案作为敏感性比较。如果三者贡献接近，说明当前决策对风险形式较稳健；若差异很大，则需要讨论是偏好不同、误差结构不确定，还是少数候选者信息不足。风险分析的价值在于使这些原因可见，而不是给普通 OCS 加上一个更复杂名称。

36.15.1 情景频率不是新的真实性保证

在后验情景中被经常选中，可以说明某个候选在当前模型与资料条件下较稳定，但不等于它具有同样数值的“真实优秀概率”，更不等于经典可靠度。选择频率还取决于其他候选、目标权重、亲缘约束和求解规则。一个很可靠但被近亲替代的动物，可能很少被选中；一个资料较少却处于稀缺来源的动物，可能因约束经常被保留。

如果每个情景都重新选择贡献，再把贡献平均，得到的是一种随机最优方案的平均描述，不必等于在共同约束下最优的单一可执行方案。凸约束下平均贡献可能仍可行，但其风险目标和整数可执行性需要重新检查；存在非凸、整数或禁配逻辑时，更不能直接把情景平均当作最终计划。

较稳妥的研究应区分“在不确定性下评价一个固定方案”和“每个情景知道真值以后重新优化”。后者可以作为理想参照，衡量完美信息的潜在价值，却不是现实决策者能提前实现的策略。把两者混用，会夸大所谓稳健优化的收益。所有方案都应在同一未知未来条件下、以相同可用信息进行比较。

情景样本还要独立保留一部分用于评价，特别当方案是针对有限情景集合优化得到时。否则优化器可能对抽样尾部的偶然形状过度适应。可以增加情景数或重新抽取评价情景，观察目标和贡献是否稳定；这种检查针对数值情景误差，不替代对原遗传模型和后验校准的验证。

36.16 当前配种与长期遗传结构

一代最优不一定等于长期最优。大量使用少数高 EBV 亲本，可以提高当前后代均值，却会使下一代候选者广泛共享祖先，未来可选择的独立来源减少。配种优化即使当前避免了近亲，也不能消除这种贡献集中。长期育种计划需要跟踪祖先贡献、遗传变异和近交增长，而不只检查当年的配种平均值。

假设每代近交增长率固定为 ΔF ，从初始近交零出发，简化递推给出 $F_t = 1 - (1 - \Delta F)^t$ 。这个式子可用于说明累积效应，但不替代真实群体动态。若每代增长百分之一，五代累积约百分之四点九零，十代约百分之九点五六；即使每代变化看似很小，长期也可能形成明显差异。

世代间隔使年度目标更加复杂。同样十年内，较短世代间隔可以经历更多选择轮次，也可能经历更多次近交累积。缩短世代间隔通常有利于加快年度遗传进展，但若每代亲缘控制保持不变，年度多样性消耗也可能增加。评估新技术时，应同时比较年度收益与年度遗传结构变化，不能只用每代指标判断。

选择还会改变未来方差。目标相关的等位基因频率、连锁不平衡和家系构成都会随使用份额变化，使当前估计的遗传协方差不再永久固定。若长期模拟每一代都机械沿用同一协方差和同一候选分布，可能低估选择反馈。教学静态模型适合解释一次决策，长期研究需要明确遗传传递与选择过程。

重叠世代进一步改变贡献含义。不同年龄亲本的遗传价值、已实现后代和未来可用年限不同，某个当年份额未必等于长期基因贡献。将同龄离散世代公式直接用于所有年龄结构，需要谨慎。长期计划应根据实际更新制度定义贡献时窗，并记录已经形成的祖先集中，避免每年都从零重新计算而忽略历史。

外部引种可以增加遗传来源，也可能带来环境适应性、遗传基准和资料可靠性问题。一个外部公羊在原群体的高 EBV 不能未经尺度转换就与本群体比较；较低系谱关系也可能部分来自系谱记录不完整。增加来源是否改善长期目标，需要同时评估真实亲缘、性状适应和预测可迁移性，而不是只追求关系矩阵中的零。

可以采用滚动决策：每个周期根据新记录更新评定，以已实现贡献和剩余能力为条件重新优化，同时保持长期多样性目标。滚动方式允许纠正早期不确定性，但也可能造成目标频繁摇摆，因此经济权重和核心底线不宜随着短期噪声任意变化。资料更新与价值目标更新应分别管理。

长期监测至少应记录计划贡献、实际成功后代、家系存续、近交分布和主要性状趋势。平均值之外，还要关注少数高近交个体、稀缺来源丢失和某些家系过度集中。若实际结果长期偏离计划，原因可能在繁殖成功率、选择执行或资料记录，而不一定是优化模型本身。决策链的每一环都需要相应反馈。

36.17 从计算结果到可审阅决策

一个可以交付实施的方案应先说明本次决策范围：候选集合、配种期、计划后代数和目标。随后列出资料版本、EBV 基准、关系矩阵及其基础假设，保证审阅者知道数值来自哪里。没有这些信息，同一份贡献表可能在不同群体或不同年度被错误复用，形成表面精确而实质失配的计划。

方案正文可以从几个关键结果开始：各性状预期后代水平、相对于参照的改变、群体共祖、平均及最高配对近交、亲本使用集中程度。详细个体贡献与配种矩阵放在相应表中。把目标、亲缘和执行放在同一视野内，比单独

展示一个综合指数最高值更便于判断取舍。

重要约束应标明是否紧约束。若共祖恰好达到上限，整数化和临时替换就需要格外谨慎；若某公羊达到使用上限，增加其可用精液可能改善目标，但还要看其他约束；若繁殖底线紧约束，则目标权重变化可能迅速改变方案。紧约束信息帮助管理者识别真正限制当前计划的因素。

至少准备一个有实际意义的替代情景。例如某高贡献公羊不可用、某批母羊退出、繁殖底线提高或共祖预算收紧。替代方案不应只是把同一结果换个颜色，而应重新求解并报告变化。若主要目标几乎不变，却能显著降低实施难度，管理者可以选择更稳妥的方案；如果目标损失很大，也能提前理解关键资源的重要性。

对不确定性，宜报告敏感性而非假装精确。可以对 EBV、权重或方差参数作合理扰动，记录贡献和目标的变化。如果贡献变化很大而目标几乎不变，说明存在近似等价的决策自由度；如果小扰动导致目标或亲缘明显恶化，则需要进一步核查模型与资料。两种情况不能都笼统称为“方案不稳定”。

实施前应由熟悉繁殖流程的人核对个体身份、健康资格、场站可达性和配种时点。优化结果中的编号必须回到真实动物主键，不能只依赖表格行号。尤其在使用冻精、胚胎或跨场资料时，样本编号与动物编号的对应需要清楚。第 34 章的数据治理在这里直接关系到方案是否真正执行在正确对象上。

实施后要记录实际配种与成功后代，而不是只保存原计划。偏离计划的原因应分类：资源不可用、受胎失败、管理调整、个体淘汰或资料更正。下一周期可以据此更新能力和风险假设。若持续出现某类偏差，应调整模型输入或实施流程，而不是每年重复产生同样难以执行的“最优方案”。

本章的十六候选例子完整展示了从多性状 EBV 到贡献再到配种的链条，但只在模拟、加性、连续目标和简化能力条件下成立。其可迁移部分是问题表达、基准区分、约束检查和不确定性分析；不可直接迁移的是候选数值、教学权重和具体共祖上限。把这两部分分清，才能让计算示例真正成为专业判断的工具。

36.18 最优贡献的乘子条件与约束边际代价

连续最优贡献不仅要给出一组数值，还应能解释为什么不能沿某个方向继续改进。设候选综合遗传值预测为 $\mathbf{h}$ ，贡献为 $\mathbf{c}$ ，加性关系矩阵 $\mathbf{A}$ 半正定，公母贡献和等线性等式写为 $\mathbf{Bc} = \mathbf{b}$ 。个体上限为 $\mathbf{d}$ ，共祖上限为 q_0 。在本节中，预测输入视为固定，风险传播留到后面讨论。

$$\max_{\mathbf{c}} \mathbf{h}^T \mathbf{c}, \quad \frac{1}{2} \mathbf{c}^T \mathbf{A} \mathbf{c} \leq q_0, \quad \mathbf{Bc} = \mathbf{b}, \quad 0 \leq \mathbf{c} \leq \mathbf{d}.$$

把它写成最小化负收益问题，分别给共祖、等式、下限和上限配置乘子。拉格朗日函数为

$$\begin{aligned} \mathcal{L} = & -\mathbf{h}^T \mathbf{c} + \lambda \left(\frac{1}{2} \mathbf{c}^T \mathbf{A} \mathbf{c} - q_0 \right) \\ & + \nu^T (\mathbf{Bc} - \mathbf{b}) - \alpha^T \mathbf{c} + \beta^T (\mathbf{c} - \mathbf{d}). \end{aligned}$$

在适当约束资格条件下，最优解满足驻点、原始可行性、对偶非负性和互补条件；对于这个凸问题，这些条件还提供全局最优的证据。

$$-\mathbf{h} + \lambda \mathbf{A} \mathbf{c} + \mathbf{B}^T \nu - \alpha + \beta = \mathbf{0}.$$

$$\lambda, \alpha, \beta \geq 0,$$

$$\lambda (q - q_0) = 0,$$

$$\alpha_i c_i = 0, \quad \beta_i (c_i - d_i) = 0.$$

这些式子说明，内部候选的边际遗传值必须由共祖边际代价和性别等式的机会成本平衡。零贡献候选不是简单地“遗传值低”，而是其遗传值不足以抵偿它在当前组合中的关系代价；达到上限的候选则可能仍有进一步使用价值，只是被能力或管理约束限制。乘子把这种解释从口头判断变成可核对的最优性关系。

独立算例设两公两母彼此无亲缘且不近交，因而 $\mathbf{A} = \mathbf{I}$ ，综合预测为 $(4, 2, 3, 1)^T$ ，两性各贡献二分之一。用 x, y 表示各性别内由低分个体转向高分个

体的份额, 则

$$\begin{aligned} \mathbf{c} &= (1/4 + x, 1/4 - x, 1/4 + y, 1/4 - y)^T, \\ q &= 1/8 + x^2 + y^2, \\ H &= 5/2 + 2x + 2y. \end{aligned}$$

共祖上限零点一四五时, 允许的平方半径为零点零二。由柯西不等式或二变量驻点条件, 最优 $x = y = 0.1$, 贡献为 $(0.35, 0.15, 0.35, 0.15)$, 目标为二点九。这里所有内部个体上限暂取零点五, 未起作用。共祖乘子为十, 表示在当前光滑区间内, 共祖上限增加一个很小单位, 目标最优值约增加十个目标单位。

$$H_*(q_0) = \frac{5}{2} + 2\sqrt{2(q_0 - 1/8)}, \quad \frac{dH_*}{dq_0} = \frac{\sqrt{2}}{\sqrt{q_0 - 1/8}}.$$

若再限制第一只公羊贡献不超过零点三二, 则 $x = 0.07$, 最优 $y = \sqrt{0.02 - 0.07^2} \approx 0.122882$, 目标降为约二点八八五七六四。共祖乘子变为约八点一三七九, 第一只公羊上限的乘子约零点八六零七。后一个数说明, 在保持其他条件局部不变时, 稍微放宽该能力上限仍有收益; 它不是该公羊本身的经济价值, 也不能外推到任意大的放宽幅度。

在最小可达共祖处, 严格可行点可能不存在, 常规乘子解释需要谨慎; 当活跃约束集合改变时, 前沿也可能出现折点。数值报告应同时核对可行残差、驻点残差和互补乘积, 并明确乘子对应的是哪个目标单位。若把经济目标整体乘以一百, 最优贡献应保持不变, 而相应收益乘子也乘以一百。乘子尺度变化并不表示遗传约束突然变得更重要。

当关系矩阵只有半正定性时, 最优贡献不一定唯一。如果某个可行方向既不改变共祖, 也不改变目标, 则沿该方向移动会得到多个等价解。不同求解器返回不同贡献, 并不一定表示有一个算法错误; 应先比较目标、约束和关系零空间。若实施需要唯一方案, 可以明确增加次级准则, 例如在同等最优收益下减少配种变更或接近既定管理计划。这属于新的决策偏好, 应与原目标分层处理。为了强行获得唯一数字而偷偷在目标中添加惩罚, 会改变原问题, 尤其可能在遗传信息较弱的方向上决定大部分最终贡献。

36.19 禁配网络的可行性与运输问题的对偶证据

给定亲本贡献之后，配种分配是另一个问题。设公羊使用比例为 $\mathbf{p}$ 、母羊比例为 $\mathbf{q}$ ，二者各自和为一，配对比例矩阵为 $\mathbf{P}$ 。每条允许配对边的代价 F_{sd} 可以是该配对后代的预期近交系数，也可以是明确定义的其他线性配对代价。固定边际贡献时，运输问题为

$$\begin{aligned} \min_{\mathbf{P} \geq 0} \quad & \sum_{s,d} F_{sd} P_{sd}, \\ \sum_d P_{sd} &= p_s, \quad \sum_s P_{sd} = q_d. \end{aligned}$$

对完全允许的二分配对网络，只要两边总量一致就存在分配；存在禁配边后，仅检查总量远远不够。一组公羊只能使用其允许邻居中的母羊资源，因此对每个公羊子集 S ，必须满足容量条件

$$\sum_{s \in S} p_s \leq \sum_{d \in N(S)} q_d.$$

在只有这些边际约束、没有额外边容量的运输网络中，这组条件连同总量相等刻画可行性。它将“求解失败”转化为具体资源解释：哪一组公羊要求的总份额超过它们可配母羊的总份额。若还存在每对最大次数，则需要相应网络割容量条件；不能继续只用无边容量的简化形式。

独立例子取两只公羊比例零点六、零点四，两只母羊比例均为零点五，配对近交代价为

$$\mathbf{F} = \begin{bmatrix} 0.2 & 0 \\ 0 & 0.1 \end{bmatrix}.$$

令第一行第一列比例为 t ，其他元素由边际约束唯一确定。

$$\mathbf{P}(t) = \begin{bmatrix} t & 0.6 - t \\ 0.5 - t & t - 0.1 \end{bmatrix}, \quad 0.1 \leq t \leq 0.5.$$

总代价为 $0.3t - 0.01$ ，所以最优 $t = 0.1$ ，配对比例为 $\begin{bmatrix} 0.1 & 0.5 \\ 0.4 & 0 \end{bmatrix}$ ，平均预期近交零点零二。如果为了完全避免第一对近交而直接禁止第一条边，就要

求第一只公羊全部零点六份额使用第二只母羊，而后者只有零点五份额，因此问题不可行。禁止一个高风险配对可能需要同时降低某只公羊的贡献，不能只在既定贡献后增加一个禁配标志。

线性规划对偶进一步提供最优性的独立证据。为公羊边际设置势 α_s 、母羊边际设置势 β_d ，则对偶问题为

$$\max_{\alpha, \beta} \left(\sum_s \alpha_s p_s + \sum_d \beta_d q_d \right), \quad \alpha_s + \beta_d \leq F_{sd}.$$

本例取公羊势 $(0, -0.2)$ ，母羊势 $(0.2, 0)$ ，所有边的约束都满足，对偶目标为零点零二，与上述实际配种代价相同，所以已经证明全局最优，无须依赖求解器的状态字符串。实际使用的三条边上约束取等号，未使用的第二行第二列边有正的约化代价，反映在保持边际时启用它需要付出额外成本。

如果总共安排十个后代，本例比例直接对应整数次数矩阵 $\begin{bmatrix} 1 & 5 \\ 4 & 0 \end{bmatrix}$ 。一般而言，当边际后代数为整数且只含标准运输约束时，存在整数最优极点；但加入共祖二次约束、家系最低数量或复杂逻辑后，这种整数性质可能失去。不能因为基础运输问题容易，就默认所有配种模型都可以先连续求解再四舍五入。

近交代价矩阵还应来自同一关系基准下的完整合法关系结构。本例的数值可对应两对公母加性关系分别零点四和零点二，其余交叉关系为零的一个简单正定系统。若只任意填一个低代价矩阵，它仍能形成运输问题，却未必代表可实现的遗传群体。优化可行性与遗传输入合法性是两种检查，必须分别通过。

运输势也有基准不唯一性：把所有公羊势加同一常数、所有母羊势减同一常数，不改变边约束或总对偶目标。因此单个势的绝对大小不能脱离规范直接解释，真正可比较的是保持总量平衡时的边际组合。网络出现退化时，还可能存在多组最优势和多种最优配种。此时可在最小近交代价保持不变的条件下，再优化操作成本、栏位安排或配种次数集中度。与贡献问题一样，次级管理目标最好显式分层，以便说明某个配对被选择是出于遗传差异，还

是出于多个遗传等价方案之间的实施便利。

36.20 整数后代数如何改变连续贡献前沿

连续贡献允许把一个亲本的后代数写成小数，真实实施则通常要求整数。假设每个后代由一公一母产生，总后代数为 N ，第 i 个亲本的后代计数为 k_i ，则统一基因贡献为 $k_i/(2N)$ ；两性后代计数分别和为 N 。这个二分之一来自每个后代的两份亲本来源，不能与性别内使用比例混淆。

$$c_i = \frac{k_i}{2N}, \quad \sum_{i \in S} k_i = N, \quad \sum_{i \in D} k_i = N, \quad k_i \in \mathbb{Z}_+.$$

继续采用上一节之前的无亲缘四亲本贡献例子，但将共祖上限改为零点一三八，并固定十个后代。连续最优的性别内偏移为 $\sqrt{0.0065} \approx 0.080623$ ，高分公羊和高分母羊都应产生约六点六一二个后代，连续目标约二点八二二四九。

$$x_* = y_* = \sqrt{\frac{0.138 - 0.125}{2}}, \quad H_{cont} \approx 2.822490.$$

分别取最近整数会把两只高分亲本都安排七个后代，即贡献为 $(0.35, 0.15, 0.35, 0.15)$ ，共祖为零点一四五，超过上限。每一只的四舍五入都看起来只改了不到半个后代，但两个方向同时向外移动，造成二次约束明显违反。正确处理必须在整数空间中联合决定，而不是逐个修正后默认仍然可行。

十个后代的四亲本例子只需枚举两只高分亲本的计数，各有零至十共十一种，合计一百二十一种组合。把每个组合重新换算贡献、共祖和目标，最优整数解是高分公羊七个、高分母羊六个，或者两者交换。相应共祖均为零点一三七五，目标均为二点八，连续到整数的损失约零点零二二四九。

$$\begin{aligned} \mathbf{c}_{int} &= (0.35, 0.15, 0.30, 0.20)^T, \\ q_{int} &= 0.1375, \quad H_{int} = 2.8. \end{aligned}$$

连续解在这里提供一个严格的目标上界，因为整数可行集包含在连续可行集内。找到整数可行方案后，上界与实际目标之差就是可核验的最优性缺

口；若已经枚举全部可行整数点，缺口不再表示求解不足，而是实施离散化的真实代价。大型问题不能全枚举时，也应尽可能保留上界，使“足够好”具有明确尺度。

设整数化导致贡献变化 δ ，两性贡献和保持不变。共祖的变化有一个无需近似的展开。

$$q(\mathbf{c} + \delta) - q(\mathbf{c}) = \mathbf{c}^T \mathbf{A} \delta + \frac{1}{2} \delta^T \mathbf{A} \delta.$$

即使一阶项很小，二阶项仍可能使边界解越界。因此，可以在连续阶段预留适当余量，但余量应根据实际取整规则和关系尺度计算，而不是固定扣除一个随意百分比。目标变化则精确等于 $\mathbf{h}^T \delta$ 。为了给出保守误差界，可以利用等式约束从目标向量中减去不影响可行方向的常数。

$$|\Delta H| \leq \min_v \|\mathbf{h} - \mathbf{B}^T \mathbf{v}\|_{\infty} \|\delta\|_1.$$

这个界说明，取整损失由性别内真正的遗传差异驱动，而不是由所有 EBV 共同的基准水平驱动。若给全部公羊同时加一百，最优计数不应因此改变，取整误差界也不应被这个无关基准任意放大。利用约束消去共同水平，可以获得更有解释力的数值界。

计数可行不保证配对可行。先得到公母整数使用次数后，还要检查禁配网络能否实现这些边际；若不能，应回到联合计数与配种问题，而不是在实施端临时更改亲本使用。受胎失败还会使实际后代数偏离计划计数，属于另一个随机执行层。连续、计划整数和实际实现应分别保存，下一年度关系更新应使用真实出生亲本记录，不能把计划比例当作已经实现的遗传事实。

有些生产约束还要求“使用某只公羊就至少产生若干后代”。这类条件需要一个是否使用的离散变量，把零贡献和最低正贡献分开；它不能用简单的统一下限表示，否则会强迫全部候选都被使用。若还限制使用公羊总数，可行集合将由多个不相连部分组成，连续平均两个可行方案可能落入不可执行区域。整数求解返回的结果应同时检查这些逻辑条件。特别在极小群体中，一个亲本的最低后代数就可能决定整个前沿形状，不能以大群体下取整误差很小的经验判断替代实际枚举或可行性证明。

36.21 多个底线的联合风险与参数范围稳健性

一个配种方案可能同时需要满足生长、繁殖和健康底线。逐项达到某个成功概率，并不自动给出同样的联合成功概率。设固定贡献方案下的多目标遗传结果为 $\mathbf{T}$ ，条件均值为 $\mathbf{m}$ 、协方差为 $\mathbf{S}$ ，底线为 $\mathbf{l}$ 。联合机会约束真正要求的是

$$P(T_j \geq l_j \text{ 对所有 } j | D) \geq 1 - \alpha.$$

如果只知道各边际分布，最简单的保守处理是分配失败概率 α_j ，使其总和不超过总失败预算，再分别控制每项。

$$\sum_j \alpha_j \leq \alpha, \quad P(T_j < l_j | D) \leq \alpha_j.$$

该保证来自事件并集上界，不要求目标独立。若边际为正态，可以转为均值减分位数乘标准差的确定约束；但这只是当前分布模型下的保证，参数和模型错设仍需额外研究。

$$m_j - z_{1-\alpha_j} \sqrt{S_{jj}} \geq l_j.$$

独立两目标算例取均值 (1, 0.6)、标准差 (0.2, 0.1)，底线为 (0.6, 0.45)。两项失败概率分别约零点零二二七五和零点零六六八一，其和约零点零八九六；若目标确实独立，联合成功概率为约零点九一一九六。若未知相关，仅凭边际仍可保证联合成功至少约零点九一零四四。

$$P(\text{联合成功}) = \Phi(2)\Phi(1.5) \approx 0.911963.$$

如果两项真实标准差都是报告值的两倍而均值保持不变，独立条件下联合成功概率降为 $\Phi(1)\Phi(0.75) \approx 0.650673$ 。点预测完全没有变化，实际失败风险却显著增加。这个例子把第 35 章的区间校准问题直接连接到配种约束：一个看起来精确的机会约束求解器，不能抵消输入不确定性矩阵的系统偏小。

还应区分随机遗传误差和参数范围不确定性。前者可以在指定条件模型下用概率分布描述；后者有时只有一个可信范围，而没有足够依据给每个参

数情景赋概率。若目标均值向量可能落在椭球范围内

$$\mathcal{U} = \{\boldsymbol{\mu}_0 + \boldsymbol{\Omega}^{1/2} \mathbf{v} : \|\mathbf{v}\|_2 \leq \delta\},$$

则固定贡献的最坏均值可由柯西不等式直接求出。

$$\min_{\boldsymbol{\mu} \in \mathcal{U}} \boldsymbol{\mu}^T \mathbf{c} = \boldsymbol{\mu}_0^T \mathbf{c} - \delta \sqrt{\mathbf{c}^T \boldsymbol{\Omega} \mathbf{c}}.$$

椭球半径描述允许的参数偏离，不是一个自动成立的正态分位数。如果另外有条件遗传误差协方差 $\mathbf{S}_u$ ，可以再扣除相应概率风险项，但应明确这是对参数范围内每个模型施加的条件保证，而不是把两个标准差随意相加后声称得到一个精确后验概率。模型范围与概率来源的解释不同，不能用同一个“置信度”名称覆盖。

多目标风险分配还可以反映实际代价。繁殖底线失败的后果可能高于轻微生长不足，因而允许的失败概率可以不同；但这种分配应在看到候选结果前讨论，避免优化后只放松最难满足的一项。报告应同时给出边际余量、联合计算方法和主要风险相关。若方案只有在假定所有误差独立时才可行，而真实家系信息明显共享，应把它作为需要补充证据的脆弱方案。

对稀有尾部事件，有限情景数尤其容易产生虚假的零风险。如果一百个后验情景都没有失败，只能说明这批情景没有观察到失败，不能证明真实概率为零。评估情景应与用于优化的情景独立或采用合适的样本外验证，并报告尾部概率的抽样精度。风险形式的复杂化只有在不确定性估计和评价设计同时可靠时才具有实际价值。

联合风险的统计对象必须与生产解释一致。亲本贡献所形成的平均遗传目标，和有限数量后代的实际平均表型，具有不同协方差；后者还包含孟德尔抽样、环境以及受胎成功的不确定性。如果底线指实际出栏表现，只传播亲本 EBV 误差会漏掉这些执行层来源。相反，若底线指长期平均遗传方向，将所有独立环境噪声都混入遗传目标风险又可能过于保守。应先用条件全方差分解列出各层，再决定哪些随后代数增加而平均减少、哪些作为共同亲本或批次误差持续存在。只有统计对象明确，成功概率才有可操作的含义。

36.22 追加信息何时能够改变配种并抵偿成本

预测更精确是否值得付费，最终取决于新信息能否改变受约束行动。设当前可行方案集合为 A ，方案 a 的真实目标收益为 U_a 。风险中性的当前最优期望收益为各方案条件均值的最大值；如果可以在行动前观察完整真实遗传值，则能选择真实收益最高的方案。

$$V_0 = \max_{a \in A} E(U_a | D), \quad V_{PI} = E\{\max_{a \in A} U_a | D\}.$$

完全信息价值是两者之差。由最大值函数的凸性，这个差非负，但它尚未扣除任何获取信息的成本。

$$EVPI = V_{PI} - V_0 \geq 0.$$

如果只能得到一项有噪声的新测定 Z ，每个可能结果都会更新各方案的条件均值，再选择一个实际可执行方案。样本信息价值因此为

$$EVSI = E_{Z|D} \left[\max_{a \in A} E(U_a | D, Z) \right] - V_0.$$

这里必须在每个可能信息结果后重新优化；先把新信息平均成一个值，再优化，通常会抹去改变行动的机会。反过来，假设每个结果后都能选择一个不同方案，再把这些方案平均成当前可执行方案，也不等价于真正的先测定后决策流程。信息到达顺序是这个价值定义的组成部分。

独立两方案例子设收益差 $\Delta = U_1 - U_2$ 在当前资料下服从均值零点二、标准差零点五的正态分布。当前应选择第一方案。完美知道收益差以后，只在它为负时改选第二方案，因此完全信息价值可以从正态正部期望求得。

$$EVPI = s\phi(m/s) - m\Phi(-m/s), \quad m = 0.2, s = 0.5.$$

结果约零点一一五二一九个目标单位。这个数是在现有可行集合和当前信息下，任何完美遗传信息能够带来的最大平均改进；若某项检测费用已经超过它，就不能仅从本次风险中性决策收益来证明该检测划算。当然，检测还可能服务未来多代、疾病管理或其他目标，这些价值需要另外纳入，不能偷偷包含在当前数字中。

设可购买测定为 $Z = \Delta + \varepsilon$ ，测量误差方差零点二五，且独立于真实收益差。正态更新后的收益差方差为零点一二五；在观察结果之前，未来后验均值本身也具有方差零点一二五。

$$\begin{aligned}\text{Var}(\Delta | Z, D) &= (0.25^{-1} + 0.25^{-1})^{-1} = 0.125, \\ \text{Var}\{E(\Delta | Z, D) | D\} &= 0.25 - 0.125.\end{aligned}$$

将前式的信息价值公式中的标准差替换为未来后验均值的标准差 $\sqrt{0.125}$ ，样本信息价值约零点零六三零三二。因此费用零点零六时净收益略为正，费用零点零七时净收益为负。这一比较已明确目标单位、测量机制和两方案可行性，读者可以逐步复算，完全不需要虚构真实牧场收益。

收益差的误差方差必须包含两个方案之间的共享预测误差。若两个方案高度相似，它们可能各自收益不确定，却差异很确定，追加信息价值很低。若单个方案标准误不大，但两者均值接近、误差方向不同，信息仍可能频繁改变选择。由此可见，按照个体可靠度从低到高安排测定，与按照决策信息价值安排测定，通常不是同一个排序。

在多方案和整数配种中，解析正态正部公式不再直接适用，但定义不变：从合理条件分布生成可能的新信息，更新预测，在同一可行约束下重新选择方案，再用独立评价计算收益。应区分外层遗传不确定性、测定误差和内部优化误差，避免把求解噪声误认为信息价值。若新信息来不及用于当前配种，或者行动早已锁定，当前价值应相应减少；信息是否有价值，不能脱离获得信息以后还能做什么。

上述信息价值界限还假定两个方案的可行性不会因为新增测定而改变。如果检测不仅更新育种值，还发现禁配缺陷、样本身份错误或亲本无法使用，那么信息同时改变可行集合，需要在每个信息状态下重新定义可行动作。若检测可能导致当前计划暂停，延误成本也应进入收益。研究中应先把“改进排序的信息”和“发现不可执行方案的信息”分开建模，再研究它们的联合价值。这样才能避免把一次风险排除带来的价值全部归因于预测准确度提高，也能解释为何某些身份核验即使几乎不改变总体相关，仍然值得优先投入。

36.23 习题与详细解答

习题 36.1 贡献尺度。公羊的基因贡献为零点零八，计划一百个成功后代。它的父系份额和期望后代数分别是多少？若某软件输出的公羊份额和为一，怎样与本章比较？

解答。父系份额为零点一六，期望十六个后代。若软件在公羊内部归一化，其份额应除以二转换成本章总基因贡献；母系同理。转换以后再计算 $c'Ac/2$ ，不能把两种归一化混用，否则目标和共祖尺度都会错误。

习题 36.2 目标与参照。均衡方案后代生长均值为零点一零五，等贡献参照为负零点零六三。相对于等贡献的改变是多少？为什么不能把零点一零五直接称为这次选择的全部增益？

解答。改变约为零点一六八个遗传标准差。零点一零五是相对于基础基准的后代水平，等贡献群体本来不在基础零点，因此二者差才是相对于该参照的改变。若使用另一参考群体，增益定义也相应改变，必须在报告中说明。

习题 36.3 四亲本解析解。在四亲本例子中，推导 $q = 0.15625 + 0.5x^2 + y^2$ ，并解释为什么内部最优满足 $x = 2y$ 。

解答。两只公羊的关系为零点五，代入其贡献后，公羊关系二次型为零点一八七五加 x^2 ；母羊部分为零点一二五加 $2y^2$ ，整体再乘二分之一得到所示结果。最大化 $x + y$ 的拉格朗日一阶条件为 $1 = \lambda x$ 和 $1 = 2\lambda y$ ，故 $x = 2y$ 。边界生效后需分段求解。

习题 36.4 两种亲缘量。四只完全无关亲本等贡献时，群体共祖是多少？当前公母配种的后代近交能否为零？说明两者差异。

解答。群体共祖为 $\frac{1}{2} \times 4 \times (1/4)^2 = 1/8$ 。公母之间关系为零时，当前后代近交可以为零。群体共祖包括自身对角和所有来源组合，后代近交只取决于实际父母配对。有限来源集中与当前近亲配对是不同对象。

习题 36.5 配种运输。两公两母等份额，只有两对对角组合的关系为零点二五，交叉组合为零。求随机、纯交叉和纯对角配种的平均后代近交。

解答。随机配种四个单元各占四分之一，平均近交为两项 $0.25 \times 0.25/2$ 之和，即零点零六二五。纯交叉为零；纯对角两项各占二分之一，平均为零

点一二五。三种方案边际相同，因此加性目标均值和群体共祖相同。

习题 36.6 整数化。四亲本连续解在上限零点一八时，直接舍入得到贡献零点四二五、零点零七五、零点三五、零点一五。为什么不合格？给出一个目标九点七五且满足上限的替代方案。

解答。代入关系二次型得到共祖零点一八一五六二五，超过上限。可取零点四、零点一、零点三五、零点一五，对应二十后代时父系十六与四、母系十四与六，共祖零点一七七五，目标九点七五。应在整数层重新检验，不能仅保证计数加和正确。

习题 36.7 风险分散。两候选预测均值一点二和一、误差方差零点六四和零点零四且独立，性别内份额和为一。为什么只按可靠度最高者全部使用也未必是均值—方差目标的最优解？

解答。第二只误差较小，但第一只均值较高。目标同时考虑均值与方差时，内部混合可能获得更好折中；例如风险权重零点五时，第一只份额约零点三五三，第二只约零点六四七。可靠度排序只考虑一部分信息，不能替代完整目标与协方差计算。

习题 36.8 下尾决策。方案甲九成概率目标一点二、一成概率负零点八；方案乙总为零点九。分别按均值和最差十分之一平均评价，哪个更好？能否说一个方案普遍优越？

解答。甲均值为 1，高于乙的零点九；但甲下尾为负零点八，低于乙的零点九。没有普遍优越结论，取决于对较差结果的容忍程度。风险选择应明确，而不是以某个统计指标掩盖价值判断。

习题 36.9 无可行解。对八只公羊分别要求最低基因贡献零点零八，同时父系总贡献为二分之一，会怎样？若软件长时间运行，应该先调整求解器还是检查条件？

解答。最低贡献合计零点六四，已经超过父系总量，所以无可行解。应先检查并修正相互矛盾的约束，不应通过放宽求解容差让错误条件表面通过。更复杂的关系冲突则可先求最小共祖或最低约束违反量进行诊断。

习题 36.10 长期解释。当前最低亲缘配种达到零近交，是否证明可以

把全部后代集中在少数最佳亲本？提出两个需要继续监测的量。

解答。不能。少数亲本集中会使未来候选者共享祖先，下一代可能难以继续找到无亲缘配对。应继续监测实际祖先贡献与群体共祖、近交增长及其分布，也应观察遗传变异和稀缺家系存续。短期零近交只说明当前配对条件，不是长期多样性保证。

模型诊断、失败分析与可检验的研究设计

37.1 诊断的起点是区分错误层次

一份遗传评定结果不理想，可能来自身份连接错误、性状定义不一致、信息泄漏、协方差假设不合适、参数估计不稳定、数值求解失败，或者育种目标本身没有被清楚表达。把这些情况都称为“模型精度不高”，会使修复失去方向。数据错位需要修正对应关系，方差尺度错误需要核对单位和参数，目标冲突则需要决策者重新讨论约束，三者都不能靠增加模型复杂度自动解决。

诊断应按照因果距离与检查成本组织。先检查最靠近记录事实的身份、时间、单位和数量，再检查矩阵与参数化，随后研究残差、校准和预测分布，最后才讨论复杂遗传架构。这个顺序并不贬低高级方法，而是避免用高级方法解释本来属于资料管理的错误。第35章的候选错配实验已经说明，矩阵数值完全合法时，生物学对应仍然可以错误。

诊断也需要明确参照。某个指标与理论值不同，可能是模型失配，也可能是有限样本波动，或者理论值针对另一个条件对象。一次八十只验证动物的覆盖率偏离九成，不足以自动证明区间错误；三十次重复持续明显不足，则提供更强证据。应把随机波动、系统偏差和计算错误分开，不因某张图“不够漂亮”就随意改动资料。

一个有效的诊断问题应该包含可区分的候选解释。例如“某家系长期高估”至少可以来自共同环境遗漏、亲本登记错误、选择性记录或真实遗传基准变化。不同解释对应不同检查：核查栏位与寄养、比较基因型亲缘、恢复未测个体名册、检查基础群体。只说“加入更多协变量看看”缺少明确证伪

路径，也容易造成事后模型选择。

应区分探索性诊断与最终性能评估。探索可以帮助发现问题并改进流程，但一旦根据验证结果反复修改模型，原验证集就不再是独立的最终检验。可以保留新的外部批次，或在嵌套设计中把开发与评估分开。否则诊断越勤奋，报告的乐观偏倚反而可能越大。

本章以第 34—36 章的教学实验为基础，但重点不在重复结果，而在解释怎样判断结果值得相信、怎样定位失败，以及怎样把一个方法想法写成能被推翻的研究问题。所有新增数值例子都明确区分代数算例、实际运行的模拟和真实文献证据，不把一种证据冒充另一种。

诊断最终应服务决策。某种轻微非正态偏离可能对均值预测几乎没有影响，却影响极端尾部配种风险；某种小幅平均偏差可能不改变排序，却改变经济收益估计。判断问题是否需要修复，应联系目标用途，而不是只看统计检验是否显著。对育种系统而言，最重要的是识别会改变关键行动的失配。

37.2 表型残差、育种值误差与未来结果

混合模型至少涉及三类不同误差。模型残差 e 描述在固定与随机遗传部分之外的表型变化；育种值预测误差为 $u - \hat{u}$ ；未来表型预测误差还包括未来环境、固定效应估计和可能的未来环境水平。它们具有不同方差，不能共享一个未经说明的“标准误”标签。

在简单模型中，若未来个体的固定均值已知、遗传预测误差与未来环境独立，则未来表型误差方差是 PEV 加残差方差。若均值未知或未来记录与训练环境相关，还需要加入相应协方差项。将育种值 PEV 直接用于预测未来体重区间，通常会漏掉环境变异；将未来表型误差反过来作为遗传值不确定性，又会夸大某些目标的误差。

同样要区分目标真值与验证代理。模拟中可以直接比较真实 u 和预测 $\hat{u}$ ，真实群体中通常只能使用后续记录、后裔表现或后来的高信息评定。这些代理也有误差，并可能与原预测共享资料。相关较高可能部分来自共享信息，相关较低也可能来自代理噪声。报告必须说明代理如何形成，而不是简单把

某一系列命名为“真实育种值”。

预测值变化也不等于预测错误。新记录加入后，合理评定会更新个体 EBV；变化较大可能说明原来信息有限，也可能说明新信息与旧信息不相容。需要同时查看旧 PEV、新增信息量和资料更正。如果原区间很宽，后来预测发生较大变化并不意外；如果原区间很窄却经常被后续信息推翻，则值得检查不确定性表达。

模型残差还可分为边际残差和条件残差。边际残差扣除固定部分，仍包含随机遗传效应；条件残差再扣除预测随机效应。前者适合检查总协方差结构，后者更接近观察未解释记录，但已经经过拟合和收缩，不是原始独立环境误差。把两种残差混用，会导致错误的方差和正态性判断。

在多性状或重复测定中，误差结构还具有跨记录与跨性状关联。某只动物多个性状的预测可能共享相同家系信息，多个后代的误差可能共同受父系估计影响。只报告单个标准误差容易掩盖组合风险。若最终目标是群体平均、指数或配种方案，应直接形成目标线性组合的误差方差，而不是把个体指标机械拼接。

诊断的第一张说明表可以列出每个量的定义、条件信息和单位。例如表型残差以千克计，PEV 以千克平方计，可靠度为无量纲，覆盖率是重复事件比例。这样的表看似基础，却能够防止许多高层误解。尤其在跨团队交流时，名称相似不意味着统计对象相同。

37.3 残差经过拟合以后为何不再独立

设边际模型为 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ ，其中 $\boldsymbol{\varepsilon}$ 协方差为 $\mathbf{V}$ 。广义最小二乘估计固定效应后，残差受到同一组估计参数的约束。例如含截距时，某种加权残差和为零；这些约束使残差之间相关。即使原始环境误差独立，拟合残差也不能直接当作独立原始误差样本。

在混合模型中，条件残差还扣除了收缩后的随机效应。记 $\mathbf{B} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}$ ，定义

$$\mathbf{P}_V = \mathbf{V}^{-1} - \mathbf{V}^{-1}\mathbf{X}\mathbf{B}\mathbf{X}'\mathbf{V}^{-1}.$$

它满足 $\mathbf{P}_V \mathbf{X} = \mathbf{0}$ 和 $\mathbf{P}_V \mathbf{V} \mathbf{P}_V = \mathbf{P}_V$, 因此能把固定效应空间与剩余随机变异的处理联系起来。

若残差协方差为 $\mathbf{R}$, 条件拟合残差可以写为 $\hat{\mathbf{e}} = \mathbf{R} \mathbf{P}_V \mathbf{y}$ 。因此其协方差为 $\mathbf{R} \mathbf{P}_V \mathbf{R}$, 一般不等于 $\mathbf{R}$ 。这个结果解释了为什么直接将 $\hat{e}_i$ 除以原始残差标准差, 未必得到方差为一的独立量。高信息记录和低信息记录的拟合残差还可能受到不同程度影响。

对每个分量按 $\mathbf{R} \mathbf{P}_V \mathbf{R}$ 的对角标准化, 可以改善边际尺度, 但仍不能消除残差间相关。若希望在理想高斯模型下得到独立标准化对比, 可以先对白化后的固定效应空间作正交投影。设 $\mathbf{V} = \mathbf{L} \mathbf{L}'$, 令 $\mathbf{Q}_\perp$ 的列张成 $\mathbf{L}^{-1} \mathbf{X}$ 的正交补且正交归一, 则

$$\mathbf{r} = \mathbf{Q}_\perp' \mathbf{L}^{-1} \mathbf{y}.$$

当 $\mathbf{V}$ 已知且模型高斯时, $\mathbf{r}$ 服从均值零、单位协方差的正态分布。它的维度为记录数减固定效应秩, 体现了拟合固定效应消耗的自由度。

这个构造用于理解诊断原则, 不意味着实际分析必须把每个残差都转成难以对应原记录的正交坐标。正交残差便于检查理论分布, 原记录尺度的残差便于定位具体动物、设备和场站。两者服务不同目的, 可以配合使用。为了得到漂亮的独立图而失去问题定位能力, 也不是理想诊断。

当 $\mathbf{V}$ 由同一资料估计时, 上述精确分布会改变。估计步骤本身消耗信息, 并可能让残差看起来比真实情况更符合模型。可以使用与完整拟合流程一致的参数自助法, 重新生成资料、重新估计方差、重新形成诊断统计量, 以获得相应参考分布。只固定估计出的方差而忽略再估计, 检验的对象就不同。

正态性检验的小概率值也需要结合规模解释。样本很大时, 极小且对目标无实质影响的偏离也可能显著; 样本很小时, 严重尾部问题又可能缺乏检出力。应同时查看量化残差、尾部比例、分组模式和预测后果, 不把一个检验结果当作模型全部有效性的判决。

如果残差对日龄呈系统曲线, 可能需要更合适的年龄函数; 如果某设备批次整体偏移, 首先检查测量过程; 如果同窝残差持续相关, 可能遗漏共同

环境。诊断图应引导具体可检验解释，而不是只得出“数据不正态”这一宽泛结论。不同模式需要不同修复，不应一律通过删除极端值处理。

37.4 相关很高为什么仍可能严重失准

考虑五个真实育种值负二、负一、零、一、二，某模型预测为真实值的两倍再加零点五。两列相关恰为一，排序完全正确；但预测平均偏高零点五，幅度扩大一倍。真实值对预测值的回归斜率为零点五、截距为负零点二五，均方根误差为一点五。这个完全确定的例子说明，高相关不能保证绝对遗传水平或差异幅度正确。

如果这些预测被用于经济收益计算，扩大一倍的幅度会把候选者差异和预期收益夸大；如果用于概率约束，平均偏移也会改变达到底线的判断。对只需要粗略排序的任务，问题可能较轻；对高强度推广、配种份额或收益预测，则可能很重要。诊断必须联系实际用途，而不是把相关作为唯一通行证。

校准回归的截距和斜率需要明确方向。本章使用 $u = a + b\hat{u} + \epsilon$ ，理想参照为 $a = 0, b = 1$ 。若改成回归 $\hat{u}$ 对 u ，得到的斜率表达另一个问题，尤其存在误差时二者不互为倒数。文献和软件输出可能使用不同约定，比较之前应核对定义。

校准截距还依赖遗传基准。若所有 EBV 统一平移，排序不变，但相对于某基础群体的截距改变。两版评定采用不同基准时，应先转换到共同尺度，再判断是否存在系统偏差。不能把一个有意的基准调整误当作模型整体高估，也不能用重新归零掩盖对未来群体均值的真实偏差。

斜率估计受验证范围影响。若只在已经初筛的优秀候选中验证，预测值变化范围可能很窄，斜率会变得不稳定；少数极端个体也可能具有较大影响。应报告验证群体选择规则，并考察高影响点，而不是看到某个不理想斜率就立即对所有 EBV 作事后线性校正。校正参数本身也需要独立验证。

第 35 章残差方差低估的实验给出一个更接近模型应用的例子：相关仍约零点六一，斜率却约零点六一，覆盖率不足。这个结果说明方差尺度错误可以在不彻底破坏排序的情况下损害决策幅度。真实项目出现类似模式时，

应检查性状单位、关系矩阵尺度、遗传方差和环境分量，而不只寻找更高相关的算法。

校准也不等同于因果有效。一个预测在当前群体中平均正确，不能据此推断改变某个标记或管理因素会产生对应因果效应。预测模型利用的相关可能来自亲缘、群体结构和环境联系。诊断报告应避免把“预测校准”扩展成“已经识别生物学机制”，特别在解释复杂机器学习特征时。

可以把校准看作一组问题：总体均值是否相容，预测幅度是否相容，不同信息量个体的区间是否相容，重要亚群是否存在系统偏差。单一回归线只是入口。若目标是个体排序、群体趋势和风险约束同时使用，最好分别检查这些用途对应的校准对象。

37.5 预测区间覆盖率的一个精确算例

假设预测误差真实服从均值零、标准差二的正态分布，模型却以标准差一报告九成区间。报告区间半宽为一点六四四八五，真实误差落入其中的概率为

$$2\Phi(1.64485/2) - 1 \approx 0.58917.$$

名义九成区间实际只覆盖约百分之五十八点九。这个差异不是因为点预测一定有均值偏差，而是误差尺度低估了一半。点预测相关可以保持不变，区间却严重过窄。

若标准差正确为一，同样分位数给出九成覆盖。由此可以看出，覆盖率是对整个区间构造的检查，涉及中心、尺度和分布形状。中心偏移、方差错误和尾部过厚都可能导致不足，单看覆盖率本身不能识别是哪一种原因。应配合标准化误差均值、离散程度和尾部模式分析。

覆盖率还具有抽样误差。在相互独立的重复事件下，真实覆盖概率为 p 、重复数为 R 时，覆盖估计的标准误约为 $\sqrt{p(1-p)/R}$ 。若 $p = 0.9$ ，一百次独立重复的标准误为零点零三，一千次约为零点零零九四九。想区分九成与八成九覆盖，需要比展示一个大致趋势更多的独立信息。

遗传评定中的个体通常不独立。一个验证群体的动物共享亲本、环境和




图 37.1 模型与真实误差尺度不一致的精确正态算例。虚线是模型报告的九成区间边界，着色部分仅占真实误差分布约百分之五十八点九二

同一组拟合参数，覆盖事件可能相关。因此不能机械地把三十次模拟中的两千四百只验证羊当作两千四百个独立伯努利事件。可以以完整重复为单位汇总覆盖率并估计波动，或采用尊重群体结构的方法分析个体层结果。

平均覆盖率达标也可能掩盖区间分配不合理。模型可以对低信息个体过窄、对高信息个体过宽，整体恰好平均到九成。应按预测标准差、记录数、家系或部署相关亚群检查，但避免把样本很少的细组结果当作确定结论。一个好的区间不仅平均诚实，还应在重要条件下大致合理。

区间宽度必须与覆盖一起报告。把所有区间无限扩大总能提高覆盖，却失去决策价值；追求极窄区间而不顾覆盖则制造虚假确定性。可以比较在相近覆盖下的平均宽度，或使用明确的区间评分，但评分规则也应符合目标。对极端优秀候选的选择，尾部行为可能比全群平均宽度更重要。

本章的正态算例有意保持简单，使误差尺度问题能够精确计算。真实分布可能偏态、多峰或受到选择截断，正态分位数未必适用。此时可以考虑条件模拟、后验分位数或其他经验证的区间形式，但都需要说明条件信息和覆盖目标。更灵活的区间形式不自动保证校准，仍需独立检验。

37.6 参数不确定性与插件式 PEV

在前面的教学基准中，遗传和残差方差已知，PEV 公式只针对指定参数条件下的预测误差。真实研究通常先估计方差，再代入 BLUP 公式；参考频率、系谱和填充基因型也可能不确定。这些额外来源不一定全部被常规 PEV 包含。报告一个精确小数并不会消除参数估计误差。

贝叶斯条件方差分解提供清楚的思路。若 θ 表示方差等参数，可以把总条件方差写为两个分量之和：

$$\text{Var}(\mathbf{u} | \mathbf{y}) = \mathbf{V}_{within} + \mathbf{V}_{between}.$$

$$\mathbf{V}_{within} = E_{\theta|\mathbf{y}} [\text{Var}(\mathbf{u} | \mathbf{y}, \theta)].$$

$$\mathbf{V}_{between} = \text{Var}_{\theta|\mathbf{y}} [E(\mathbf{u} | \mathbf{y}, \theta)].$$

第一项平均参数给定时的误差，第二项描述不同合理参数导致预测均值变化。只在一个点估计处计算条件方差，通常没有显式表达第二项，而且第一项也未必等于在点估计处的值。

这不意味着任何频率学插件式 PEV 都必然以同样方向低估真实误差。参数估计、边界、偏差和非线性可以产生复杂影响，需要按完整流程研究。可以通过参数自助法反复生成资料、重新估计参数和预测，或者在合理后验模型中传播参数不确定性。关键是让评估过程包含实际部署会执行的步骤。

参数不确定性在小群体和弱连通资料中尤其值得关注。某个遗传相关估计接近一或负一，可能反映信息有限而非真实接近完美相关；某个方差分量估计为零，可能是边界结果。将这些点估计当作精确事实送入多性状或风险优化，可能产生极端权重和过度集中的方案。

参考频率不确定性也有不同层次。若频率来自一个很大的独立参考群体，其误差可能较小；若来自很少基础动物，频率抽样会影响中心化和关系尺度。填充基因型的确定性剂量与概率分布又包含不同信息。是否需要传播这些误差，应根据目标和影响评估，而不是一律认为“已有一个矩阵，所以矩阵已知”。

系谱不确定性更不适合简单加一个统一噪声方差。不同候选父母关系会系统改变多个动物的协方差，影响具有结构性。可以在可信的候选系谱情景下重算，比较预测和决策敏感性；若关键结果依赖尚未确认的亲本，应优先取得鉴定信息。统计上的精细处理不能替代可以直接核实的重要事实。

参数敏感性分析应有依据。随意把每个参数上下改变百分之十可能方便，却未必代表合理不确定范围；不同参数之间还可能相关。可以利用估计协方差、剖面似然、后验样本或明确生物学区间构造情景。分析时既看点预测变化，也看 PEV、校准和最终贡献方案，而不只汇报一个平均相关。

对使用者的解释应保持具体：当前区间包含哪些不确定性，哪些来自给定参数模型，哪些尚未传播，哪些可通过补充测定减少。这样的说明比笼统称为“高可信预测”更有帮助，也为下一步数据采集提供方向。若主要不确定性来自某个关键方差或身份信息，增加无关记录未必是最有效的改进。

37.7 方差分量边界与弱信息

方差分量必须非负，相关参数必须形成合法协方差矩阵，所以其估计空间带有边界。遗传方差估计为零，不一定说明性状绝对没有遗传变异，也可能是样本不足、关系结构缺乏对比或模型分量难以区分。估计接近边界时，常规对称正态近似和标准误解释需要谨慎，不能把软件输出的一个小数当作毫无不确定性的结论。

两个随机效应若具有几乎相同的关联结构，资料可能只对它们的总方差有较强信息，而无法精确分开。例如每只母羊只产生一窝、每窝后代又只在一个栏位时，母体、共同窝和栏位效应容易混淆。模型可以写出多个方差，但实际资料未必支持全部辨识。增加随机效应名称不会创造新的独立比较。

可以通过剖面似然、参数相关或不同起点的结果观察弱信息方向。如果某两个方差一增一减而似然几乎不变，说明存在平坦谷地。此时只报告某一个最优点会掩盖不确定性，应考虑简化模型、改进设计或给出范围。若使用先验稳定估计，也应说明结果对先验的依赖，而不是把先验提供的信息归为数据证据。

协方差矩阵接近奇异时，多性状模型可能出现接近正负一的遗传相关。这个结果可能有生物学原因，例如性状间存在接近确定的代数关系；也可能来自有限样本和过度参数化。首先检查性状是否由共同组成量派生、单位和记录是否一致，再讨论是否需要约束相关。简单把相关截为零点九九虽然方便，却改变了模型并需要说明。

方差估计异常还可能是遗漏结构的补偿。若共同环境没有建模，加性方差可能吸收家系相似性；若测量误差被低估，模型也可能扩大遗传差异；若固定效应分组不合理，某些系统偏差会进入随机部分。诊断不应只问估计值是否落在允许区间，还应问它是否在替代一个缺失的过程。

一个实用策略是比较有明确嵌套关系的模型，并关注关键预测是否稳定，而不是只看似然提高。加入共同窝效应后，遗传方差降低并不自动说明新模型更真实；需要检查设计是否支持分离、预测验证是否改善，以及新分量是否具有合理模式。多个模型在现有资料上同样相容时，应承认辨识不足，而不是强行选出唯一生物学解释。

边界问题的检验分布也可能不同于普通无约束参数。若零方差位于参数空间边界，不能机械使用与一般回归系数相同的参考分布。具体检验需要依据模型和假设选择，必要时用参数模拟获得参考。书中强调这一原则，是为了避免把常规软件默认输出当作适用于所有方差分量问题的通用答案。

对数据采集而言，弱信息诊断可以转化为设计建议。若母体与直接遗传效应难以分离，增加跨代、跨母体或适当交叉信息可能比单纯扩大同一结构的窝内记录更有效；若场站完全孤立，增加连接个体可能比继续累积组内样本更有价值。统计诊断的终点不应只是宣布“估计不稳定”，还应指出怎样获得更能区分解释的资料。

37.8 可识别性、连通性与数值病态

参数是否可识别，首先是模型与数据结构问题。若两个固定效应列完全相同，数据只能识别它们的和，不能分别估计各自作用。给模型加约束可以选取一个数值表示，却不会增加原始信息。可估对比有时仍然明确，例如某

些组间差异可以识别，而单个组效应依赖参考编码；报告应围绕可估对象解释。

数值病态与严格不可识别不同。当两列几乎相同，矩阵可能满秩，但很小的数据扰动就引起较大参数变化。条件数可以提示这种敏感性，却不能单独告诉我们生物学原因。可能是协变量高度相关、环境与家系接近混淆、单位尺度差异巨大，或者某个类别样本极少。诊断需要回到设计矩阵与记录分布。

缩放可以改善某些数值问题，但不能消除真实的信息不足。把年龄从日改为中心化月龄，可以减少截距与斜率的数值相关；如果所有年龄几乎相同，仍然无法可靠估计完整生长曲线。标准化后求解成功，不等于原来缺乏的年龄覆盖已经出现。应区分计算稳定性改善与科学可识别性改善。

遗传连通性也不是简单的是否同处一个连通图。两个场站可能仅靠一个低信息亲属联系，图论上连通，估计上却很弱。需要结合关系强度、记录精度和目标对比考察。某个连接个体的删除若使跨场预测大幅变化，说明结论依赖少量桥梁信息，应在设计和报告中明确。

可以进行针对性的删除诊断，但删除单位应与问题一致。逐个删除记录有助于发现极端测量影响；逐家系删除能检查结论是否由少数遗传来源支撑；逐场站删除则考察迁移与环境依赖。这些诊断不是为了挑选删除后表现最好的数据集，而是评估结果对信息结构的敏感性。最终分析仍需按预定资格与清理规则进行。

对年轻候选者的比较，关注目标差的预测误差方差往往比单个参数标准误差更直接。即使某些固定效应参数依赖编码，特定育种值对比仍可能估得较好；反过来，模型整体似然稳定，也不保证跨孤立群体的候选排名可靠。诊断应围绕实际选择对比，而不是只看全局条件数。

如果多个合理参数化给出相同预测与目标对比，单个系数的差异未必具有生物学意义。若它们给出不同预测，应检查约束、基准和方差处理是否真正等价。可识别性讨论的目的不是制造形式困难，而是防止把参数化选择误读为遗传事实。

当信息不足无法通过现有资料解决时，应明确输出范围。可以仅在连通子群内比较，或者给跨群体差异更宽不确定性，并提出补充连接设计。强行给所有动物一个精确总排名虽然方便，却可能掩盖不可支持的比较。承认哪些比较尚不可靠，是专业评定的一部分。

37.9 无信号负对照揭示预处理泄漏

为了直接观察信息泄漏，本章运行一个与遗传结构无关的负对照。每次生成一百二十条相互独立的标准正态表型和五百个相互独立的标准正态特征，所有特征与表型在生成总体中没有关系。前八十条作为训练，后四十条作为验证，共进行二百次重复，随机种子固定为二四零零二。这里不存在任何真实遗传信号。

比较两种筛选流程。正确流程只在八十条训练记录中寻找与表型绝对相关最大的一个特征，再用训练资料拟合截距和该特征的线性系数；错误流程先用全部一百二十条表型寻找最佳特征，然后仍然只用前八十条估计系数。两者最后都在后四十条计算预测相关，看起来都保留了一个验证集，区别只在筛选步骤使用了什么资料。

二百次重复的结果如下。相关是纯噪声表型的验证相关，不能称为真实育种值准确度；表中数值用于展示流程偏差。

筛选资料	验证相关均值	验证 RMSE 均值
仅训练记录	0.0115	1.0537
全部记录	0.3000	0.9605

正确流程相关接近零，符合没有信号的生成事实；错误流程却获得约零点三的平均“验证相关”。原因不是模型发现了隐藏规律，而是筛选时已经利用验证表型挑选了偶然关联。后续系数只在训练集估计，并不能撤销前一步泄漏。这个例子说明，验证独立性必须覆盖整个处理流程，而不只是最后一次回归拟合。

五百个候选特征提供了足够多的偶然相关机会。若候选特征更多、筛选




图 37.2 二百次无信号负对照的验证相关分布。每个点为独立重复；使用全部表型筛选的流程因验证信息污染而产生系统性正相关，不能解释为真实预测信号

更灵活或反复查看验证表现，乐观程度可能进一步改变。相反，即使只有少数特征，只要筛选或校正使用了未来结果，也会破坏原来的评估含义。不能根据某个步骤被称为“预处理”就认定它不涉及学习。

在基因组研究中，对应风险包括先用全体表型挑选显著位点、先估计全体表型校正值、先选择最有利的组学模块，再进行看似独立的交叉验证。无监督步骤也需要根据部署时可用资料判断，但使用验证表型筛选显然改变了问题。正确做法是把所有依赖结果的步骤放在训练循环内，并将锁定流程送入最终外部评估。

负对照的作用不是证明真实资料中一定发生了同样程度的泄漏，而是检验流程在应当没有信号时是否仍会产生系统成功。可以打乱结果标签、使用无关时间段或构造不应预测目标的特征，但每种负对照都要保留适当结构。若简单打乱破坏了家系或时间依赖，得到的参照可能与实际零假设不同。

反向时间检查也很有价值。一个声称预测决策前结果的特征，如果只有决策后才产生，即使统计关联真实，也不能用于当时部署。未来诊断标签、最终淘汰原因和事后质量等级都可能携带目标信息。数据字典中的事件时间、获知时间和派生依赖关系，是防止这类泄漏的重要工具。

如果发现泄漏，应重新运行完整开发流程，而不只是从最终模型中删除一个字段。因为泄漏可能已经影响特征选择、超参数、异常值规则和模型类别。原验证集也可能被反复使用，必要时需要新的独立资料。修复的目标是恢复可解释的评估条件，而不是让原来的高分尽可能保留下来。

读者可以改变候选特征数量或训练比例，观察筛选机会与验证污染的关系。改变设计以后应重新报告实验条件。

37.10 非高斯性状、极端值与稳健处理

连续正态模型适合解释许多遗传评定原理，但并不覆盖所有性状。存活、受胎、疾病状态、窝产数和有大量零值的记录可能具有二项、计数、阈值或混合结构。若直接套用正态残差，预测范围、方差关系和区间含义都可能不合适。选择模型时应从记录生成过程出发，而不是先决定算法再寻找可勉强输入的数值编码。

二元性状的观测尺度方差依赖事件概率，不能简单把所有个体视为同方差连续记录。阈值模型中的潜在责任度又与观测概率具有不同尺度。一个潜在尺度遗传力不能未经转换直接解释为观测发生率的比例，更不能与连续体重遗传力作表面比较。诊断应确认模型输出最终如何映射到用户关心的概率或风险。

计数资料中的零也可能有不同来源。某母羊没有产羔，可能因为没有配种机会、配种失败或妊娠损失；一个固定周期计数为零，与根本未暴露于风险过程不同。零膨胀或门槛模型可以表达某些结构，但模型名称不能替代对过程的理解。若资料没有记录配种暴露，很多机制仍然无法识别。

极端值需要先核查真实性。单位错误、重复上传和设备故障应按事实修正；真实但罕见的生物学表现不应只因影响模型而自动删除。删去真实极端个体会改变目标群体，并可能丢失重要遗传信号。稳健方法的作用是在明确目标下减轻异常影响，而不是把所有不符合模型预期的记录当作错误。

变换可以改善某些分布问题，但也改变解释。对数变换后的平均不等于原尺度平均，回变换需要考虑非线性和误差分布；对比例作变换也可能在边

界处产生困难。若最终育种目标以原尺度利润或概率表达,模型预测需要经过适当转换并验证。仅凭残差图更接近正态,不足以证明变换后的决策更合理。

稳健损失、厚尾分布和混合模型可以作为候选方法,但比较应使用相同目标和真实部署指标。有时一个方法改善了中间范围预测,却低估极端优秀个体;另一个更适合尾部但平均 RMSE 略高。应根据选择强度和错误代价评价,而不是让单一全群指标决定所有用途。

分布失配与环境异方差也要分开。残差尾部较厚可能来自多个方差不同的管理组混合,而不必是每组都厚尾。如果资料中存在明确的年龄或设备方差差异,建模异方差可能比更换全局残差分布更有解释力。反之,若极端误差在各组都出现,厚尾模型可能更合适。诊断需要比较这些可区分解释。

对于复杂分布,模拟检验尤其有帮助。可以从拟合模型生成与原设计相同的资料,比较零比例、极端分位数、家系聚集和组内变化等统计量。若模型系统不能重现某种重要模式,应研究原因。这样的检查关注模型能否生成关键资料特征,而不只是要求某张残差图满足一个理想形状。

37.11 群体变化、环境变化与模型迁移

一个模型在原群体中校准良好,进入新群体后可能失效。变化可以发生在标记频率、连锁不平衡、遗传效应、环境分布、性状定义或记录选择过程。将所有变化统称为“域偏移”虽然方便,却不能指导修复。应先识别哪些关系改变,以及目标仍然是同一性状还是已经变成另一种实际测量。

亲缘距离是迁移难度的重要部分。训练群体包含候选者父母时,预测可以利用近亲信息;新群体没有这种联系时,更多依赖标记与因果变异之间可迁移的关联。随机个体验证通常保留较近关系,不能自动代表跨品种或跨地区应用。验证设计必须模拟预定迁移跨度。

环境改变也可能影响性状表达。某基因型在高营养条件下表现较好,在资源受限环境中未必保持相同排序;疾病压力和管理制度变化也可能改变目标。基因型与环境互作模型能够表达部分差异,但需要足够的跨环境连接。

若每个家系只在一个环境出现，复杂互作模型仍然面临辨识困难。

测定制度变化常被低估。更换设备、调整日龄窗口或改变病例定义，会使同名性状分布改变。模型可能把这类变化当作遗传趋势或群体迁移。应保存制度版本，并在重叠期进行可比性检查。没有重叠资料时，对前后差异的解释需要更加谨慎，不能只靠一个年度固定效应宣布问题已解决。

可以用滚动时间验证检查实际部署表现：在每个历史截止日只使用当时可得资料预测下一批，再随新信息评估。这样能够观察性能是否随时间下降，并识别某次制度或群体变化附近的异常。它比一次随机切分更接近持续运行系统，但仍需处理迟报资料、事后修订和重复调参的问题。

模型更新不一定越频繁越好。频繁根据小批次噪声改变参数，可能使结果波动并增加验证污染；长期不更新又可能忽视真实群体变化。可以预先规定监测指标和更新触发条件，例如持续校准偏移、目标分布超出训练范围或新群体进入。触发之后仍需独立评估更新流程，而不是只看训练拟合改善。

迁移失败时，补充少量目标群体记录有时比增加源群体数据更有信息价值，但具体程度依赖关系结构与性状。应通过设计比较不同采样策略，而不是只追求总样本量。代表性、连通性和目标环境覆盖，往往决定新增记录能否真正改善预测。

对于无法支持的外推，模型应表达更大的不确定性或限制使用范围。一个数值输出不等于可靠预测。专业系统需要能够识别候选者是否远离训练资料、是否缺少关键环境覆盖，并把这一信息传递给决策者。诚实说明适用边界，比在所有输入上强行给出同样精细的排名更有价值。

37.12 数值失败与统计失败的分离

数值失败包括矩阵分解失败、迭代不收敛、溢出、非有限值和约束明显违反；统计失败则是程序正常运行却产生失准、偏差或不适用的结论。两者需要不同处理。提高迭代上限可能解决尚未收敛的问题，却不能修复身份错配；改变模型可能改善校准，却不能为一个实现错误的求解器提供理论解释。

首先检查输入尺度与矩阵结构。协方差应对称，方差尺度应为正，设计

矩阵需要符合参数化要求，标记与动物顺序应一致。矩阵分解失败时，不应立即加一个很大的对角常数继续运行，因为这可能改变模型并掩盖结构错误。应区分极小舍入问题、真实半正定低秩和实质性非法矩阵。

条件数很大时，求解结果可能对舍入敏感。可以通过缩放、适当分解、稀疏结构或迭代预条件改善数值表现，但应核对目标预测是否保持一致。显式求逆通常不是必要的，求解线性系统更合适。若需要对角 PEV，也应选择与规模相容的方法，并说明是否采用近似。

迭代收敛标准不应只看相邻参数变化。某些算法在平坦区域参数变化很小，却离最佳解仍有距离；另一些参数化使尺度很大，相同绝对阈值不合理。可以结合目标函数、梯度或残差方程检查，并在小问题上与直接解比较。不同求解器的成功状态具有各自定义，不能当作统一科学认证。

优化问题还要独立检查可行性。最优贡献结果应满足性别总量、上下限和共祖约束；配种矩阵应满足行列边际及禁配。数值上略微违反可能在预定容差内，但执行时仍需要整数化和重新核验。若约束超出具有实际意义的阈值，不能因为求解器返回成功就接受。

程序中的异常处理应保留失败原因。把所有失败值替换为零，会污染性能汇总；把失败重复直接删除，会形成选择性结果。应分别记录输入错误、模型不可识别、数值不收敛和不支持的场景，并报告完整流程在这些情况下采取什么策略。生产系统的后备方法也是整体性能的一部分。

独立等价核验可以定位问题。本篇使用标记方程与协方差形式比较 GBLUP，预测和 PEV 达到舍入一致；这种检查针对尺度和实现。另用验证表型扰动检查直接泄漏，针对信息访问。再用已知真值重复模拟检查统计行为。三项证据各自覆盖不同风险，不应因为其中一项通过就省略其余重要检查。

代码优化也需要守住同一统计问题。近似求解、低秩截断或随机算法可能显著节省资源，但应说明误差如何影响 EBV、PEV 和关键选择。只比较运行速度而不比较达到的精度，不能证明某实现更有效。对低影响的舍入差可以容忍，对改变高使用份额候选者的近似误差则需进一步评估。

最终日志应保留任务配置、软件版本、输入摘要、收敛状态和关键检查结果。日志不必堆满每次迭代的全部细节，但应足以重建失败。一个只能输出“成功”或“失败”的系统，很难支持科学诊断；能够说明哪个条件被违反、哪一步开始异常，才能把计算问题转化为可处理的工作。

37.13 把方法想法写成可证伪的研究问题

一个研究问题应允许结果不支持新方法。例如“引入某种功能注释能否在跨家系预测中改善校准与目标收益”可以被检验；“设计一个显著优于所有方法的先进模型”则预先规定了必须成功的答案。科学研究需要明确在哪些条件下预期有效、什么结果会削弱这种预期，以及失败是否提供对机制的认识。

先定义估计对象，再选择指标。若目标是未来一代候选者真实育种值的相关，模拟可直接估计；若目标是新场站未来表型误差，则还涉及环境均值；若目标是最优贡献方案的实际遗传收益，则需要将预测送入同一决策规则。不同对象不能用一个“准确率”概括，也不能在某项结果不理想时临时换成另一项。

应区分统计差异与实际价值。一个极大数据集可能检出很小的相关提升，但改善是否足以补偿分型、测定或计算成本，需要另外评估。反过来，样本较少时一个有实际意义的改善可能没有足够精度确认。研究可以预先规定最小有意义差异，并报告估计范围，而不是把显著与不显著当作唯一结论。

方法比较还要说明参考条件。新方法使用额外组学数据，基准只用常规标记，比较的是完整信息方案而不只是算法；若两者资料相同但模型结构不同，才更接近算法比较。额外信息有价值本身是合理结论，但应把信息成本与模型贡献分开，避免让名称掩盖比较对象。

主终点和次终点最好预先排序。可以把未来群体校准后的目标收益作为主终点，把相关、RMSE、覆盖、计算成本和失败率作为解释性指标。若同时检验很多性状、群体和参数组合，只挑最有利结果，会产生选择性证据。完整报告并不要求每张探索图都进入主文，但应保留分析范围和选择规则。

对二十个相互独立、各用百分之五错误概率的零假设检验，至少出现一次假阳性的概率为 $1 - 0.95^{20}$ ，约百分之六十四点二。真实研究中的检验往往相关，数值不一定相同，但这个算例说明“总能找到一个显著结果”并不难。多重比较、选择模型和寻找最优场景都需要透明处理，不能把筛选后的结果当作事前唯一假设。

一个方法研究还应提出竞争性解释。例如功能注释模型改善预测，可能因为注释捕捉真实因果结构，也可能因为它改变了正则化、利用了外部群体信息或与训练数据存在重叠。可以设置随机注释、相同维度无功能权重、跨来源注释和严格外部验证等对照，区分这些解释。对照应保留关键结构，不能故意设置一个很弱的陪衬。

最终结论应按证据范围表达。若只在高遗传力、近亲训练和完全分型场景中有效，就说明这些条件，而不是泛化到全部动物育种。若结果与预期相反，可以分析模型何处失配并提出下一步检验。一个明确揭示适用边界的研究，往往比一个没有失败场景的宣传式比较更有长期价值。

37.14 模拟设计中的因素、层次与停止规则

模拟不是随意生成一批数据后运行模型，而是一种受控实验。生成机制规定真值和资料结构，拟合机制规定研究者可用信息，评估机制规定如何比较。三者应分别写清，特别要避免把生成器知道的参数偷偷交给某个拟合方法。理想参数方法可以作为参照，但需要与可部署流程分层报告。

可以把一个扩展研究设计成若干具有明确作用的因素：训练规模控制信息量，遗传力控制表型信噪比，遗传架构控制效应分布，群体分离程度控制迁移难度。并不需要把所有可能因素一次穷尽。先选择与假设最相关的少数条件，再用附加情景检查鲁棒性，通常比一个无法解释的巨大组合网格更有效。

例如一个尚待实施的设计可以设三个训练规模、三个遗传力、两种效应架构，再设有无共同环境，共三十六个场景。若每场景五百次重复、比较三种方法，至少需要五万四千次拟合。这个数量只是计划计算，不是本书已完

成的实验。明确区分计划与已运行结果，有助于避免把研究方案写成已有证据。

因素水平应来自科学问题而不只来自计算方便。若真实目标是小群体肉羊评定，只研究极大训练集可能错过关键困难；若新方法专为稀有变异设计，却只模拟常见等效位点，也不能充分检验主张。可以包含理想匹配场景，但同时应设置合理偏离，观察方法对假设错误是否敏感。

重复层次要与随机来源对应。资料重复包括基础群体、遗传效应、环境和测量过程；算法随机性包括初始化、抽样和随机优化。若两者混在一起，无法判断不稳定来自样本还是算法。可以在部分资料重复内增加多个算法运行，估计各层变异，再决定是否需要更稳定的求解或更多独立数据。

停止规则应在观察结果前规定。可以预设总重复数，也可以根据主要方法差的蒙特卡洛标准误达到目标精度后停止，但要设定最小与最大次数并完整报告规则。不能看到新方法领先就提前结束，落后就继续抽样，直到得到有利均值。这样的选择会改变结果分布，削弱推断。

失败处理也应事先写入。若某方法不收敛，是记为失败并报告、使用预定后备方法，还是在规定次数内重启，都应一致执行。不同方法允许的重试次数和调参预算应有理由。删除失败重复后只报告成功部分，会把方法适用性问题隐藏起来。

模拟报告应保存每个场景的真值、输入参数、种子规则、方法配置和重复层结果。只公布图表均值无法检查异常或重算其他合理指标。另一方面，也不必把所有中间矩阵都无差别保存；可以保留生成器和足以重建关键结果的记录。复现资料的设计应与计算成本和科学风险相匹配。

Morris 等的模拟研究组织建议可以帮助避免遗漏目标、生成机制、估计对象、方法和性能度量 (Morris 等, 2019)。真正落实到统计遗传学，还需要补充亲缘、选择历史、信息时点和遗传基准等领域结构。通用框架提供次序，专业知识决定每一步如何具体化。

37.15 相关个体下的标准误与重抽样

独立单位的选择决定不确定性估计。假设有一千条记录，分成一百个家系，每家系十条；家系内记录方差相同、相关为零点三，不同家系独立。总体均值方差相对于独立记录情形的膨胀因子为

$$D = 1 + (m - 1)\rho = 1 + 9 \times 0.3 = 3.7.$$

因此标准误约增加到独立假设的 $\sqrt{3.7} \approx 1.924$ 倍，描述性有效样本量约为一千除以三点七，即二百七十点三。记录很多并不意味着拥有同样多的独立证据。

这个公式来自交换相关的简化群组模型，不能直接替代真实遗传关系矩阵下的所有精度计算。实际家系大小可能不同，跨家系也可能有关联，固定效应和选择还会改变结构。它的作用是说明忽略相关通常会夸大有效信息，而不是给所有育种资料一个统一折减系数。

自助法应根据推断目标选择重抽样单位。逐记录抽样适合独立记录设定，却可能破坏重复测定和家系结构；按动物抽样保留同一个体记录，但未必保留跨动物亲缘；按家系、场站或时间块抽样各自对应不同的变异来源。没有一种重抽样方式能够不加条件地适用于全部遗传评定。

在带关系矩阵的模型中，重抽样还涉及身份和协方差。不能把重复抽到的同一个动物简单当成新的独立遗传个体；也不能复制表型却保留错误的矩阵索引。某些问题更适合参数自助法，在给定设计与关系下生成新的随机效应和残差，再执行完整拟合。非参数与参数方法的假设不同，应根据问题选择并说明。

方法差通常应采用成对分析。若同一重复上模型甲和乙的性能分别为 $T_{A,r}$ 与 $T_{B,r}$ ，先形成 $d_r = T_{A,r} - T_{B,r}$ ，再计算均值和标准误。共享资料往往使两个性能高度相关，忽略这种配对会损失比较效率，或者错误处理变异。

一个五次重复的教学差值为零点零四、零点零二、负零点零一、零点零三和零点零二。均值为零点零二，重复间标准差约零点零一八七一，均值的蒙特卡洛标准误约零点零零八三七。这个小例子只说明计算方法，五次重复通常不足以稳定评估复杂方法，更不能因为均值为正就宣布普遍改进。

若使用真实资料的交叉验证折，折间并不总是独立。训练集合大量重叠，验证动物也可能有亲缘，简单把折数当作独立样本数可能低估标准误。重复切分可以观察稳定性，但不能凭借生成很多相互重叠的切分无限增加独立证据。应根据资料结构和目标，采用合适的比较设计或外部重复。

置信区间、重复间标准差和蒙特卡洛标准误应分别标注。标准差描述场景重复的波动，标准误描述有限重复对平均性能的估计精度，现实外推不确定性又是另一层。增加重复数可以减少蒙特卡洛误差，却不能弥补生成模型不真实或目标群体未覆盖。把这几种不确定性混成一个“误差条”，会使图表难以解释。

37.16 真实资料验证与后续评定的使用

真实育种值不可见时，验证必须使用间接证据。后续更丰富记录形成的评定可以作为重要参照，但仍然是预测，不是无误差真值。它与早期评定通常共享系谱、基因型和部分表型，因此两者高相关不能直接当作早期评定的真实准确度。需要利用嵌套信息结构和相应假设作解释。

若部分资料信息集合包含于完整资料集合，并且两次预测都是相容模型下的条件期望，则完整预测在给定部分资料后的期望等于部分预测。这种投影性质支持某些偏差与离散度检查。它并不要求完整预测已经等于真实育种值，也不意味着任意两个软件输出都满足同样关系；模型、基准或资料处理改变时需要重新检查。

Legarra 和 Reverter 提出了利用部分与完整资料评定关系研究群体准确度和偏差的 LR 方法 (Legarra 和 Reverter, 2018)，并于二〇一九年发布更正。正式使用相关表达时，应同时核对原文与更正 (Legarra 和 Reverter, 2019)，不能把未经核实的二手公式直接用于报告。本章仅强调其验证逻辑，不将某个简单相关系数冒充完整 LR 估计。

后续表型也需要谨慎校正。如果用包含验证记录的全资料模型估计固定效应，再把校正表型拿来验证早期预测，会产生信息重叠。校正方式可能影响偏差和斜率解释，尤其在管理组样本少、遗传趋势与环境变化混淆时。应

明确校正参数来自哪里，必要时将校正纳入训练流程或采用更适合的验证设计。

验证候选的选择过程不能省略。若只有早期预测最高者获得后代测定，后续资料集中在选择后的狭窄群体，直接计算相关与斜率会受到范围和选择影响。保留选择依据及未入选者信息，有助于建立更恰当分析。最理想的验证设计未必是完全随机放弃育种目标，而是通过合理的测定安排获得能够支持比较的资料。

前瞻性验证具有特别价值。先冻结模型和候选预测，再等待预定时间的新资料，能够减少事后调整空间。但它仍需处理实际记录缺失、淘汰和环境变化，不能只分析最后成功完成测定者。验证方案应提前规定资格、终点、退出处理和数据审核规则，使结果能够按原问题解释。

跨场站验证可以检验迁移，但也可能同时改变测定制度与遗传背景。若性能下降，应通过分层和辅助资料分析来源，而不立即把全部差异归因于遗传距离。相反，如果在一个新场站成功，也不能据此保证所有环境都可迁移。外部验证应覆盖拟部署范围中的关键变化，而不是只选择最方便取得资料的合作点。

真实证据与模拟证据最好互补。模拟可以检验某个验证估计量在已知真值下的偏差，真实资料则检验模型在实际记录过程中的表现。两者一致时结论更有说服力；不一致时，需要研究生成机制遗漏了什么，或现实验证是否存在代理和选择问题。不能因为真实结果不符合模拟预期，就自动认为真实资料质量差。

37.17 四个可继续推进的研究方向

第一个方向是信息时点一致的多组学增量价值。问题可以定义为：在候选决策前真正可得的组学资料，是否在已有系谱、标记和常规表型之外改善未来一代目标。需要将组学采样日期、处理批次和特征筛选全部纳入截止日，并设置同等调参预算的基准。主要终点不仅是相关，还包括校准、成本和约束后决策收益。

这个方向的竞争性解释包括真实生物学信息、批次与环境代理、样本选择以及外部训练资料重叠。可以设置随机特征集、批次保留对照和跨批次验证,观察改善是否仍然存在。若优势只在随机个体切分中出现,而在按时间或场站验证中消失,就应重新解释其应用价值。研究不应预先承诺多组学必然优于常规资料。

第二个方向是小群体方差不确定性怎样传递到配种决策。可以比较已知参数、插件估计和完整不确定性传播三种流程,保持同一候选集合与目标。终点包括区间覆盖、贡献敏感性、真实目标损失和近交约束违反风险。这样能够回答复杂不确定性处理是否产生实际决策价值,而不只展示后验区间看起来更完整。

该方向需要明确区分遗传多样性风险与预测风险。某个方案可能更保守地使用低信息动物,却增加祖先集中;另一个方案保留稀缺来源,却增加短期目标不确定性。可以把两种风险分别列为约束或前沿,避免用一个综合惩罚掩盖冲突。模拟中真值可用于评价,真实资料则需要后续记录和长期监测。

第三个方向是低密度标记下未观测遗传背景的表达。第 35 章表明,在独立位点教学条件下,把少量标记当作全部遗传协方差会严重低估不确定性。后续研究可以加入真实连锁结构、不同面板选择、频率估计和部分分型,比较合理背景模型与简单关系模型。研究目标是识别何种协方差表达在何种信息条件下相容,而不是寻找一个普适标记数量阈值。

这个方向应使用独立或公开授权的真实基因型结构作补充,但不能把模拟表型称为真实生产验证。真实基因型加模拟表型可以检验在该遗传结构下的行为,真实表型验证则提供另一层证据。两者的数据来源与生成部分应在每张表中说明,避免“使用真实数据”这一笼统说法掩盖模拟成分。

第四个方向是面向长期实施的决策稳定性。可以比较固定权重、情景权重、均值—方差与下尾风险方案,在多个世代和实际繁殖能力下的目标、亲缘和执行偏差。需要记录连续解到整数方案的损失、繁殖失败造成的实现贡献变化,以及后续更新是否能够修正偏差。这个问题把预测、优化和生产过程连接起来,比只比较一代最优目标更接近育种系统。

长期研究不能只重复同一个静态候选分布。亲本选择会改变后代基因频率、家系结构和信息积累,测定决策也会影响下一次评定。应明确模拟哪些反馈、忽略哪些反馈,并用可管理的层次逐步增加复杂性。若模型规模过大而无法解释每一层,研究可能失去检验价值;清楚的中等复杂度设计往往更适合发现机制。

四个方向都可以形成可证伪假设、预定对照和明确终点,也都允许结论是某种新信息或新方法在特定条件下没有实际增益。这样的结论并非失败,它可以指导资源配置,避免在无效方向上扩大投入。研究的成熟不在于保证每次得到积极结果,而在于使积极或消极结果都具有可解释价值。

37.17.1 区分新表示、新假设与新信息

评价方法创新时,应先判断改变发生在哪一层。把同一个混合模型改写为核形式、标记形式或谱形式,可能带来计算优势和解释便利,但若数学上严格等价,就不应声称凭空增加了统计信息。第 35 章用两种形式核验相同预测,正是这种等价性的例子。计算贡献可以很重要,但需要以效率、稳定性或可扩展性证据说明。

如果新方法改变了先验、协方差结构或损失函数,它提出的是新统计假设或新决策偏好。应解释这种改变为什么适合目标问题,以及在何种偏离下可能失败。一个正交化步骤可以减少数值相关,却不自动使生物学作用因果独立;一个核分解可以划分预测空间,却不自动证明每个分量对应唯一遗传机制。

若加入功能注释、长读长变异或传感器信息,则可能提供新资料,但仍需要检验它相对于现有信息的增量价值。新增数据与已有标记高度重叠时,名义维度增加不一定带来实质信息;新增资料如果来自决策之后,还可能不符合目标部署。创新主张应与实际可得信息相联系,而不是以数据类型新颖作为充分证据。

一种清楚的研究报告可以分别列出表示改变、假设改变和信息改变,并设置能够隔离各项作用的对照。这样即使最终预测提升不大,也可能识别出显著计算收益或更可信的不确定性;如果提升很大,也能够解释究竟来自何

处。把所有变化捆绑后冠以一个新名称，会使结果难以被其他研究者验证和继承。

对数量遗传学而言，重要进展常常不是再增加一个预测器，而是澄清在选择、亲缘和有限资料下什么能够识别、什么仍依赖假设。能够证明某种比较不可能从现有资料唯一回答，并设计能打破混淆的新测定，同样具有方法价值。把可识别性、信息增量与决策后果同时纳入研究，能使创新更接近学科的基础问题。

37.18 后验复制必须对应真正要预测的未来对象

后验预测检查常被概括为“从拟合模型生成资料，与实际资料比较”。这句话只有在复制对象明确时才足够。重复测定同一动物、测定一个同家系新动物、测定一个无亲缘新动物，涉及不同层级的共享随机效应；即使它们使用同一个表型名称，预测分布也不相同。诊断应从未来观测机制开始，而不是从某个软件默认的模拟命令开始。

考虑最简单的高斯层级模型：动物育种值先验方差为 τ^2 ，观测误差方差为 σ^2 ，当前记录为 $y = u + e$ 。给定方差参数时，后验均值与方差为

$$\begin{aligned} m_u &= \frac{\tau^2}{\tau^2 + \sigma^2} y, \\ C_u &= \frac{\tau^2 \sigma^2}{\tau^2 + \sigma^2}. \end{aligned}$$

如果下一次测量同一动物，且新误差与已有资料独立，则复制记录共享同一个未知育种值。对后验育种值和新误差积分，得到

$$y_{\text{same}} | y \sim N(m_u, C_u + \sigma^2).$$

如果下一次测量一个在模型中完全无亲缘的新动物，且总体均值和方差已知，新动物的育种值不从当前个体记录获得信息，因而

$$y_{\text{new}} | y \sim N(0, \tau^2 + \sigma^2).$$

取两种方差均为一，当前记录为三。同一动物未来记录的预测均值为一点五、方差一点五；无亲缘新动物未来记录的均值为零、方差为二。若用后

一个分布检查前一个部署任务，会丢掉已有个体信息；若用前一个分布检查真正的新动物，则会把不属于它的记录当作已知证据。模型正确并不足以保证诊断问题正确。

存在永久环境效应时，同一动物未来记录还共享该效应；如果未来记录属于另一个栏位，则栏位效应可能重新抽取。一般预测方差应按层级相加，并保留可能存在的交叉协方差。

$$\text{Var}(y_* | D) = E\{\text{Var}(y_* | \mathbf{u}, \theta, D) | D\} + \text{Var}\{E(y_* | \mathbf{u}, \theta, D) | D\}.$$

第一项通常包含未来观测噪声，第二项包含对遗传值、环境效应和参数的当前不确定性。若未来噪声与历史噪声相关，就必须在第一个条件分布中使用相应条件协方差，不能直接放入原始残差方差。尤其是传感器高频率序列，下一时刻误差往往已经可以由刚刚观察到的误差部分预测。

后验预测检查选择的统计量也应对应假设。总体均值偏离、家系内部离散、同栏动物同步波动和极端负尾，分别检查不同层面。一个模型能重现总体直方图，不意味着能重现家系协方差；能重现每只动物自身平均值，也不意味着能够预测新家系。可以针对一个统计量 T 计算复制尾部概率，但这种概率使用了数据形成后验，通常不能当作独立检验下的均匀分布显著性水平。

$$p_{rep} = P\{T(y^{rep}) \geq T(y) | y\}.$$

后验复制在这里是模型检查工具，而不是自动校准的拒绝检验。一个中间概率只说明该统计量在当前后验复制中不显得极端，不能证明模型所有部分正确。若为了得到中间概率反复挑选统计量或改变数据处理，就进一步丧失了明确的错误率解释。应优先用生物学与观测机制预定统计量，并配合真正留出的未来资料检查预测。

在肉羊教学实验中，可以分别保存“给定本次系谱和基因型”的条件复制，以及“重新生成下一群体”的外层复制。前者检查当前群体的拟合与区间，后者研究群体结构变化下的稳健性。将两者放入同一张图时，需要明确颜色或分面所代表的随机层，不能把更多随机来源造成的宽分布误判为当前模型精度低，也不能把固定全部遗传结构得到的窄分布当作跨群体保证。

37.19 条件创新诊断与严格预测评分

相关资料的残差检查，最清楚的起点是条件创新。设一组待验证记录的预测分布为已知均值 μ 、正定协方差 $\mathbf{V}$ 的多元正态分布。按事前规定顺序逐条预测，每一步只允许使用之前已经揭示的记录。第 i 条记录的条件均值与方差由高斯条件公式给出。

$$\begin{aligned} m_i &= \mu_i + \mathbf{V}_{i,<i} \mathbf{V}_{<i,<i}^{-1} (\mathbf{y}_{<i} - \mu_{<i}), \\ s_i^2 &= V_{ii} - \mathbf{V}_{i,<i} \mathbf{V}_{<i,<i}^{-1} \mathbf{V}_{<i,i}. \end{aligned}$$

标准化创新 $z_i = (y_i - m_i) / s_i$ 在模型正确且参数已知时相互独立，均为标准正态。这个结论比“每个边际标准化残差都近似正态”更强，因为它还检查协方差能否解释资料之间的依赖。它与对协方差作三角分解后的白化等价，但序贯写法更容易连接信息到达顺序。

$$z_i = \frac{y_i - m_i}{s_i}, \quad \mathbf{z} \sim N(\mathbf{0}, \mathbf{I}).$$

独立算例取两条标准化记录相关零点八，实际观测都为一。第一条创新为一；第二条在已知第一条以后，条件均值为零点八、条件标准差为零点六，因此创新只有三分之一。直接画边际残差会得到两个同样大小的正残差，却不能区分第二条有多少已经被第一条解释。

$$z_2 = \frac{1 - 0.8 \times 1}{\sqrt{1 - 0.8^2}} = \frac{1}{3}.$$

顺序改变时，单个创新的归属会改变，但全部条件密度的乘积仍等于同一个联合密度。因此，如果目的是联合模型检查，可以比较不同顺序下不变的总评分；如果目的是在线部署，顺序必须遵守实际时间，不能根据未来记录选择一个使当前残差更好看的排列。固定效应和方差由同一批验证资料估计时，独立标准正态结论也不再精确，应使用独立拟合或完整流程模拟校准。

覆盖率是重要指标，却不足以判断区间是否有效利用信息。任意扩大区间能够提高覆盖，却可能失去使用价值。正态预测的负对数评分同时惩罚过

窄、过宽和中心偏移。

$$\ell(y; m, v) = \frac{1}{2} \log(2\pi v) + \frac{(y - m)^2}{2v}.$$

若真实分布为 $N(m_0, v_0)$ ，使用均值 m 、方差 v 的预测，期望评分超过真实分布评分的部分为

$$E(\ell - \ell_0) = \frac{1}{2} \left[\log \frac{v}{v_0} + \frac{v_0 + (m - m_0)^2}{v} - 1 \right] \geq 0.$$

非负性可以由对方差比的基本不等式和均值平方项直接看出，所以该评分在指定预测类别中鼓励正确中心与尺度。若真实方差为一、中心正确，却使用方差四，期望负对数评分多约零点三一八一四七。虽然宽区间看起来更“安全”，评分仍揭示其信息效率损失。反过来，低估方差会让少数极端误差受到很大惩罚，这正对应过度自信的风险。

在上述两记录例子中，将第一条边际密度与第二条条件密度相乘，联合对数预测密度约为负一点八八二六零七。逐项分解可以指出哪一条新记录与已有信息最不相容，但不能把它自动解释为数据错误；模型遗漏一个共同环境变化也会产生同样信号。应进一步检查创新随场站、时间和家系的结构，而不是只按最大的绝对值删除记录。

不同模型的预测评分应在完全相同的验证目标和单位下比较。连续变量换单位会给对数密度增加一个共同常数，因此同一资料上的模型评分差可以保持，但不同单位的原始评分不宜直接排列。未来表型密度与育种值后验密度也属于不同目标，不能混在一张“预测质量”表里求平均。评分严格的前提，是被评分的概率对象本身已经定义正确。

37.20 离散表型的随机化分位残差与条件校准

繁殖成功、疾病指示和少量计数具有离散分布，普通残差只有几个可能取值。即使模型完全正确，残差图也可能呈现几条曲线，不能把这种离散结构当作正态性失败。一个直接办法是使用预测分布的累计概率，将每个离散概率质量展开为相应区间，再通过独立均匀随机数填入该区间。Dunn 和 Smyth 提出的随机化分位残差采用这一思路 (Dunn 与 Smyth, 1996)。

令 F_i 为第 i 个结果在允许信息下的正确预测分布函数, $F_i(y_i^-)$ 表示严格小于观察值的概率, V_i 为独立标准均匀变量, 定义

$$U_i = F_i(y_i^-) + V_i\{F_i(y_i) - F_i(y_i^-)\}.$$

当预测分布正确且连续化规则适当时, U_i 具有均匀边际分布, 再取标准正态分位得到

$$R_i = \Phi^{-1}(U_i).$$

随机化不是对原始表型添加生物噪声, 也不会改变拟合目标; 它只是为离散概率残差形成连续诊断坐标。若资料相互独立且分布参数已知, 变换后的残差独立标准正态; 若动物相关, 应使用合适的条件预测分布, 或者在完整相关模型复制下评价残差统计量, 不能只因为每个边际变换看似正常就宣称残差独立。

伯努利算例最能展示这个机制。设成功概率为零点二。结果为零时, 随机化概率均匀分布在零至零点八; 结果为一时, 均匀分布在零点八至一。

$$U | Y = 0 \sim Unif(0, 0.8), \quad U | Y = 1 \sim Unif(0.8, 1).$$

因为两种结果本身以零点八和零点二的概率出现, 混合后整个单位区间的密度恰好为一。如果把随机数固定为二分之一, 则只会得到零点四或零点九两个值, 不再是均匀分布; 固定中点可以作为某种确定性摘要, 却不能继续使用精确连续残差的参考分布。为了保证复算, 应该固定并记录随机种子, 而不是删掉随机化步骤后保留原理论解释。

概率预测还有一个无需正态化的严格损失: 伯努利结果的平方误差评分。设真实成功概率为 p_0 , 报告概率为 p , 则

$$E\{(Y - p)^2\} = p_0(1 - p_0) + (p - p_0)^2.$$

真实概率零点二时, 正确报告的期望评分为零点一六; 报告零点五时为零点二五。差零点零九正是概率偏差的平方。这说明预测概率并非只需给出正确排序; 把所有概率向二分之一拉近或推远, 会影响决策所依赖的绝对风险, 即使排序保持不变。

平均校准仍不等于条件校准。若两个同样大的亚群真实成功概率为零点一和零点三，统一报告零点二可以使总体观察比例与平均预测一致，却在两个亚群中方向相反地失准。可以用预定亚群函数 g 构造残差矩条件。

$$E\{(Y - p(X))g(X)\} = 0.$$

正确条件概率应对所有合适的已知函数满足这类关系；实际诊断只能选择有限的、与部署相关的函数，例如场站、年龄段、预测概率区间和记录来源。不能根据同一验证资料反复搜索最显著的分组，再把常规单次检验阈值当作有效错误率。若分组本身需要学习，应使用独立资料或嵌套验证。

随机化分位残差与概率评分回答互补问题。前者便于显示分布形状和结构性偏离，后者给出明确的总体预测损失；二者都不能替代对风险集合的核查。如果“未配种”被错误记为“配种失败”，再精确的伯努利诊断也只检查错误定义的结果。统计残差的参考分布成立于观测机制已经正确编码的前提下，数据字典和概率模型在这里仍然紧密相连。

37.21 模拟校准检验算法，也必须检验信息是否被使用

贝叶斯模型的计算检查与现实适用性检查是两件事。模拟校准先从声明的先验抽取参数，再从同一个似然生成资料，然后由待检查算法输出后验样本。由于完整生成机制已知，它可以寻找实现错误、抽样偏差和近似推断失真。Talts 等提出的模拟校准框架将这种检查组织为可重复的计算流程 (Talts 等, 2018)。通过它并不说明先验和似然已经适合真实育种群体。

设真实模拟参数为 $\theta^{(0)}$ ，生成资料为 y ，算法产生 M 个后验抽样 $\theta^{(1)}, \dots, \theta^{(M)}$ 。在连续参数、精确独立后验抽样条件下，给定资料，生成真值本身与后验样本具有交换性。因此真值在全部样本中的秩应均匀分布。

$$R = \sum_{m=1}^M I\{\theta^{(m)} < \theta^{(0)}\}, \quad P(R = r) = \frac{1}{M+1}.$$

秩直方图可以显示某些偏差：算法分布过窄、过宽或位置偏移都可能改变秩形状。但这些图形解释不能机械一一对应错误原因，多种错误可以产生

相似形状，不同错误也可能互相抵消。抽样自相关、离散参数和并列值还需要相应处理，不能把名义后验样本数直接当作独立抽样数。

一个尤其重要的反例是：只检查参数的无条件边际秩，并不足以证明算法真正使用了数据。考虑 $\theta \sim N(0,1)$ 、 $y | \theta \sim N(\theta,1)$ 。正确后验为

$$\theta | y \sim N(y/2, 1/2).$$

错误算法完全忽略资料，每次都输出独立先验样本 $N(0,1)$ 。跨全部模拟重复来看，生成真值仍来自同一个先验，错误输出也来自该先验，且彼此独立，所以参数边际秩仍可均匀。这个结论可以直接由交换性推出，无需依赖偶然的模拟图形。它不是否定模拟校准，而是说明有限诊断统计量的能力边界。

如果只看边际覆盖，错误算法的先验区间也可以在先验平均意义下具有正确覆盖，却完全没有利用记录提高精度。应进一步检查资料条件下的校准和信息效率。对上述高斯模型，正确条件均值为 $y/2$ ，忽略资料的均值为零，对应总体平方风险分别为二分之一和一。

$$E\{(\theta - y/2)^2\} = \frac{1}{2}, \quad E(\theta^2) = 1.$$

还可以用一个包含数据的矩条件识别差别。对线性报告均值 ay ，真实误差与资料的协方差为

$$E\{(\theta - ay)y\} = 1 - 2a.$$

正确算法的 $a = 1/2$ 使该矩为零，忽略资料的 $a = 0$ 则使其为一。按观测值正负或大小预先分层，也会发现错误算法的条件均值失准。这些检查直接评价后验是否响应证据，而不是只评价跨所有资料混合后的一个边际分布。

本节的独立计算以固定种子生成两万次先验预测资料，每次保留十九个抽样。正确算法与忽略资料算法的二十个边际秩频数都围绕一千波动，但相应均值预测的模拟平方误差约零点四九六四与零点九九八八，与理论二分之一和一相符。这是人工构造的算法负对照，不能作为任何真实遗传架构的性能结论。其价值在于证明一个看似漂亮的诊断图可能同时被一个有用算法和一个无用算法通过。

对于多性状混合模型，校准对象可以包含个体效应、遗传对比、方差分量、后验预测和最终配种收益。只检查某个边际方差分量，可能漏掉动物排序或跨性状协方差错误；只检查每个坐标，又可能漏掉联合方向。应由实际用途选择有代表性的标量函数，并同时保留解析可解的小模型核验。诊断越接近关键决策对象，越容易发现对实际应用有影响的计算偏差。

模拟生成器与推断程序也不能共享同一个未经独立验证的错误变换。如果两端都把性状单位误乘同一个因子，内部校准可能通过，而与真实数据接口仍然不相容。单位变换、条件矩和极端边界应有独立计算依据。计算验证的强度来自互不完全依赖的证据，而不是把同一段代码在不同位置调用多次。

条件诊断的分层规则应在检查前确定，并确保每层有足够重复。如果为了得到平坦秩图而不断合并或拆分资料区间，便可能掩盖真实偏差。对高维遗传模型，可以先在低维解析子模型中验证数据响应，再检查真实目标方向的条件校准；这比一次画出成千上万坐标的边际秩图更容易解释。针对特定方差边界、低信息家系和极端记录另外设置生成场景，也有助于发现仅在先验尾部出现的计算失败。

37.22 研究功效、蒙特卡洛精度与等效性必须分别规划

“运行多少次模拟”没有统一答案，因为研究可能要估计平均性能、发现指定差异，或者证明差异小到没有实际意义。三者分别涉及估计精度、检验功效和等效性范围。若不先区分目标，一个没有显著差异的结果可能被误解为方法相同，一个很精确但极小的差异也可能被包装为实用突破。

设每个独立群体重复给出两方法的配对损失差 D_r ，其均值为 δ 、标准差为 σ_D 。平均差的蒙特卡洛标准误为

$$MCSE(\bar{D}) = \frac{\sigma_D}{\sqrt{R}}.$$

如果只要求九成五区间的半宽不超过 h ，正态近似规划为 $R \geq (z_{0.975}\sigma_D/h)^2$ 。如果目标是在双侧显著性水平零点零五下，以约八成功效发

现差异 δ ，常用规划近似为

$$R \geq \left\{ \frac{(z_{0.975} + z_{0.8}) \sigma_D}{|\delta|} \right\}^2.$$

独立算例取有意义差异零点零二、配对差标准差零点零八，规划结果向上取整为一百二十六次独立重复。只有三十次时，即使该差异真实存在，正态近似功效也只有约零点二七八；一百二十六次时约零点八零一。三十次没有显著结果，因而并不能支持两方法没有重要差异。

$$Power(R) = \Phi \left(\frac{\delta \sqrt{R}}{\sigma_D} - z_{0.975} \right) + \Phi \left(-\frac{\delta \sqrt{R}}{\sigma_D} - z_{0.975} \right).$$

若两种方法分别使用独立资料，且各自损失标准差都为零点零八，差的标准差成为 $\sqrt{2}$ 倍，规划次数上升到二百五十二。这个比较假设配对设计中的差标准差确为零点零八，而不是由单个方法标准差自动推出。应通过先验经验或预先限定的试运行估计它，并对估计不确定性做敏感性规划。

等效性问题要求先给出实际可接受差异界限 Δ 。要支持两方法在该界限内等效，需要让适当置信区间完全位于 $(-\Delta, \Delta)$ ，而不是只要求包含零。对于两个单侧检验各取显著性水平零点零五，常用对应的是九成双侧区间。

$$\left[\bar{D} - z_{0.95} \frac{s_D}{\sqrt{R}}, \bar{D} + z_{0.95} \frac{s_D}{\sqrt{R}} \right] \subset (-\Delta, \Delta).$$

这里的界限应来自遗传进展、成本或部署后果，而不应在看到标准误之后选择一个刚好通过的范围。若差异区间很宽，结论应是证据不足；若区间很窄并位于实用界限内，才有理由说在规定用途上差异足够小。统计显著性和实际意义由此各有清楚位置。

覆盖率研究又是另一种样本量问题。若独立事件的目标覆盖为零点九，要以单侧水平零点零五、约八成功效发现下降到零点八五，两个伯努利方差的正态规划为

$$n \geq \frac{\left[z_{0.95} \sqrt{0.9(0.1)} + z_{0.8} \sqrt{0.85(0.15)} \right]^2}{(0.9 - 0.85)^2}.$$

向上取整约需二百五十三个独立事件。相关动物不能直接当作独立事件：若四十个相互独立家系，每家十只，覆盖指示在家系内交换相关零点一，简单设计效应为一点九，四百只动物只相当于约二百一十点五个独立事件。这个近似只是指定相关模型下的信息摘要，真实亲缘网络仍需按完整重复或适合的聚类方法评价。

$$n_{eff} = \frac{400}{1 + 9(0.1)} \approx 210.526.$$

功效规划中的方差、相关和差异都可能估计不准。因此正式研究最好预设合理范围，报告最乐观与较保守条件下所需规模，并说明哪一个条件决定实际预算。若采用中期查看结果后继续增加重复，应事先规定停止准则，区分以精度为目标的序贯计算与以显著性为目标的反复试探。后者不能继续使用未经调整的固定样本检验解释。

最后还要区分科学抽样误差和蒙特卡洛误差。增加模拟重复可以使某个生成场景下的平均性能估得极精确，却不能证明这个场景代表真实肉羊群体；增加真实场站和独立世代可以改善外部证据，却未必修复计算实现错误。一个完整研究设计应分别给出场景覆盖、独立现实单位、内部计算重复和决策相关终点，让每种不确定性都有对应的证据来源。

上述功效数值采用正态规划，适合解释重复次数与可检出差异的关系。实际重复很少、损失差偏态或方差需要不稳定地估计时，应通过分析方法一致的模拟规划或适当的小样本分布复核。若预定比较多个新方法，应把主要比较与探索比较分开，必要时调整多重检验或同时区间；不能用许多次单独检验中的最好结果代替预先指定的研究结论。规划越具体，最终没有达到预期效果时的解释反而越清楚，因为证据不足、效果太小和方法失效可以分别讨论。

37.23 习题与详细解答

习题 37.1 误差对象。某羊 EBV 的 PEV 为四，未来一次表型的独立环境方差为六，固定均值已知。未来表型预测误差方差是多少？若固定均值也需估计，能否仍只相加这两个数？

解答。在给定独立条件下为十。若固定均值未知，还要考虑其估计误差以及与遗传预测误差之间可能的协方差，不能无条件沿用简单相加。PEV 描述遗传值预测误差，不是未来全部表型波动。

习题 37.2 完美相关的陷阱。真实值为负二、负一、零、一、二，预测为真实值两倍加零点五。求相关、真实值对预测值的斜率和截距、RMSE，并解释决策风险。

解答。相关为一，斜率为零点五，截距为负零点二五，RMSE 为一点五。排序虽然完全一致，但平均水平和差异幅度错误。如果用于经济收益、概率底线或使用份额，可能夸大候选差异，因此不能只报告相关。

习题 37.3 区间尺度。真实误差标准差二，模型报告标准差一的九成正态区间，实际覆盖是多少？若点预测无偏，是否仍可能出现这种问题？

解答。覆盖为 $2\Phi(1.64485/2) - 1$ ，约百分之五十八点九。即使点预测无偏，只要误差尺度低估，区间也会过窄。覆盖不足还可能由偏差或尾部失配造成，所以需要进一步诊断。

习题 37.4 残差独立性。为什么拟合残差不能直接当作原始独立环境误差进行检验？按各自标准差标准化后是否一定独立？

解答。固定效应估计施加了投影约束，随机效应预测又引入收缩与共享信息，因此拟合残差协方差通常不同于原残差协方差。逐分量标准化只能调整边际方差，不能消除非对角相关。需要相应白化或与完整拟合一致的模拟参照。

习题 37.5 家系相关。一千条记录分为一百个等大小家系，家系内相关零点三、家系间独立。按交换相关近似，设计效应、标准误膨胀倍数和有效样本量是多少？

解答。每家系十条，设计效应为三点七，标准误倍数约一点九二四，有效样本量约二百七十点三。这个结果依赖等大小与交换相关假设，不能直接替代一般遗传关系模型的精度计算，但说明了记录数不等于独立信息量。

习题 37.6 泄漏负对照。在没有任何真实信号的资料中，为什么先用全部表型筛选特征、再仅用训练集估计系数，仍会得到乐观验证？正确流程应

怎样改变?

解答。验证表型已经参与挑选偶然关联,之后只在训练集拟合不能撤销这一选择。应把特征筛选放在每个训练循环内,所有依赖结果的预处理同样处理,最终用未参与开发的资料评估锁定流程。本章二百次负对照中,两种流程平均相关约为零点零一二和零点三零零。

习题 37.7 参数不确定性。在贝叶斯方差分解中,为什么仅在一个参数点估计处计算条件方差不能代表全部不确定性?是否可以据此断言所有插件 PEV 都必然低估同样幅度?

解答。完整条件方差还包括不同合理参数导致预测均值变化的方差,并对参数条件方差作平均。插件值通常没有表达全部这些来源。但频率学插件误差的方向与大小还受估计偏差、边界和非线性影响,不能作统一幅度断言,应按完整流程模拟或采用相应传播方法。

习题 37.8 成对模拟误差。五次方法差为零点零四、零点零二、负零点零一、零点零三、零点零二。求均值、样本标准差与蒙特卡洛标准误。能否仅凭均值为正宣布新方法普遍优越?

解答。均值零点零二,标准差约零点零一八七一,蒙特卡洛标准误约零点零零八三七。五次重复很少,且结论还依赖生成场景;均值为正不足以宣称普遍优越。应增加预定精度所需重复,并报告适用条件及其他重要指标。

习题 37.9 多重探索。二十个独立零假设检验各使用百分之五错误概率,至少一次假阳性的概率是多少?这对反复挑选最优场景有什么启示?

解答。概率为 $1 - 0.95^{20}$, 约百分之六十四点二。实际检验可能相关,但大量探索总会增加偶然有利结果的机会。应预定主问题、完整报告比较范围,并在独立资料中验证筛选出的发现,不能把事后唯一展示的结果当作事前唯一检验。

习题 37.10 证据链设计。一个新风险优化方法在一次模拟中获得较低近交和较高预测目标。提出至少四项还需完成的检查,才能支持较强应用主张。

解答。首先确认预测与关系矩阵身份、基准和单位一致;其次在多次预

定重复中比较真实而非仅预测目标及其不确定性；再次检查连续解、整数化和实际配种约束；还需比较合理基准、不同遗传结构与参数错设，报告失败和计算成本，并在独立真实资料或前瞻性计划中取得相应证据。一次模拟的成功只能支持该设定下的行为，不能替代整个证据链。

附录 A 扩展模型与补充推导

A.1 从方差分析表回到协方差结构

经典教材常用父系半同胞方差分析引入遗传力。设每头公畜有相同数量的后代，公畜互不相关，各后代母本互不相关且不重复，记录已适当校正固定效应。模型为 $y_{ij} = \mu + s_i + e_{ij}$ 。在只有加性遗传产生半同胞相似性、随机交配且无共同饲养混杂的条件下，公畜方差为加性遗传方差的四分之一。若每头公畜有 k 个后代，则公畜间均方的期望是 $\sigma_e^2 + k\sigma_s^2$ ，公畜内均方的期望是 σ_e^2 。

$$\widehat{\sigma_s^2} = \frac{MS_s - MS_e}{k}, \quad \hat{h}^2 = \frac{4\widehat{\sigma_s^2}}{\widehat{\sigma_s^2} + \widehat{\sigma_e^2}}. \quad (A.1)$$

式中残差并不等于纯环境方差，它包含父系公畜效应未解释的遗传差异。在每头公畜 10 个后代、 $MS_s = 18$ 、 $MS_e = 8$ 的教学例中，公畜方差估计为 1，表型方差估计为 9，遗传力为 4/9。如果把分母误写成 $4\widehat{\sigma_s^2} + \widehat{\sigma_e^2}$ ，就把剩余遗传变异重复计算了。

不平衡资料中，平均后代数一般不能简单代替式中的 k 。重复母本、亲缘相关或同一父系集中饲养都会改变协方差结构。方差分析在这里的价值，是帮助理解“哪些个体共享哪些随机成分”；当设计复杂时，应回到完整模型，而不是继续修补简单均方公式。若公畜间均方小于公畜内均方，负的矩估计提示抽样波动或模型不匹配，不能直接把它解释为负的遗传方差。

A.2 母体与外祖母效应怎样进入记录

早期生长同时受到羔羊自身基因、母羊提供的子宫和泌乳环境、以及管理条件影响。把母体影响全部当作残差，会让与母本共同变化的因素进入直接遗传效应。最基本的直接与母体模型写为：

$$y_i = x_i' \beta + u_i + m_{d(i)} + p_{d(i)} + e_i. \quad (A.2)$$

其中 $d(i)$ 是个体 i 的母本, m 表示母体加性遗传效应, p 表示母本永久环境效应。若直接与母体遗传效应相关, 定义 $\text{Cov}(u_i, m_j) = A_{ij}\sigma_{um}$ 。在记录层面, 其方差必须包括 $2A_{i,d(i)}\sigma_{um}$ 。非近交且父母无关时, $A_{i,d(i)} = 1/2$, 因此这个交叉项是 σ_{um} , 而非 $2\sigma_{um}$ 。这是把遗传效应层面的相关与记录层面的协方差混淆时容易出现的错误。

在教学设定 $\sigma_u^2 = 4$ 、 $\sigma_m^2 = 1$ 、 $\sigma_{um} = -0.5$ 、 $\sigma_p^2 = 0.8$ 、 $\sigma_e^2 = 5$ 下, 遗传协方差块是正定的, 单条非近交后代记录的方差为 $4 + 1 - 0.5 + 0.8 + 5 = 10.3$ 。若忽略交叉项, 便得到 10.8; 若误用两倍, 则得到 9.8。三个数值都看似合理, 只有设计矩阵与协方差的逐项展开能够判断哪一个正确。

若考虑外祖母遗传效应, 可再加入 $q_{d(d(i))}$ 。这并不等于已有足够信息同时估计直接、母体和外祖母方差。增加模型项需要相应的跨代资料、亲缘结构和对环境的区分能力。每增加一项, 都应考察它所引起的记录协方差形状, 是否与已有项几乎相同。如果两项只在极少数记录上产生不同模式, 似然会十分平坦, 参数即使收敛也可能难以解释。

A.3 胎儿效应与细胞质效应的识别

围产期性状可能受胎儿基因型影响, 例如胎儿大小会影响产犊或产羔难度。此时要明确被记录的对象: 是母本的分娩表现、胎儿的出生表现, 还是同一次分娩的两个不同性状。母本记录上的胎儿效应设计矩阵应连接到胎儿, 而不能因记录归属于母本就把所有随机效应连接到母本。若用胎儿父本效应近似胎儿遗传贡献, 需要同时说明传递系数及未显式建模的母本遗传部分。

细胞质谱系通常沿母系传递。设 W 把动物连接到母系谱系, 模型增加 Wc , 且 $\text{Var}(c) = \sigma_c^2 I$, 则观测协方差增加 $\sigma_c^2 WW'$ 。如果每个母系谱系恰好只出现在一个牧场, 在随机牧场模型中, WW' 可能与牧场或共同环境的协方差模式非常相似; 牧场作为固定效应时, 则应检查扣除牧场均值后还剩多少谱系信息。母系嵌套于牧场并不一律导致不可识别, 但缺少跨场分布会削弱区分能力。估计出的“细胞质方差”也可能吸收母系共用环境与未记录管

理差异。

要强化识别，需要在数据形成阶段创造区分信息，例如同母系跨场分布、跨世代重复观测，或者具有明确设计的胚胎移植研究。此类设计仍需考虑供体、受体和养母效应。用模型名称命名一个方差项，不能代替对该项生物来源的鉴定。这一原则也适用于后来的微生物组、表观组和社会遗传效应模型。

A.4 社会遗传效应改变选择目标

群养条件下，一个动物的基因可能影响同伴的采食、攻击或生长。设群大小恒为 n ，个体自身的直接遗传效应为 $u_{D,i}$ ，对每个同伴的社会遗传效应为 $u_{S,i}$ ，且同伴作用可加，则对群体生产表现有意义的总育种值为：

$$T_i = u_{D,i} + (n-1)u_{S,i}. \quad (\text{A.3})$$

其方差为 $\sigma_D^2 + 2(n-1)\sigma_{DS} + (n-1)^2\sigma_S^2$ 。在 $n=5$ 、 $\sigma_D^2=1$ 、 $\sigma_S^2=0.1$ 、 $\sigma_{DS}=-0.15$ 的教学设定下，总育种值方差为 1.4。直接与社会效应负相关时，只选择个人成绩最好的个体，可能同时增加对同伴的不利影响。

式 (A.3) 依赖固定群大小、加性同伴作用及目标群结构。若群大小变化，或者社会影响随密度、熟悉程度和环境而变化，目标本身也随之变化。研究设计需要记录谁与谁共同生活、共同生活的时间以及群组如何形成。随机分群有助于区分基因型与群环境，而按大小或成绩分群可能引入选择性的同伴组合。把组平均表型机械地分配给每个成员，会制造看似充分、实际高度重复的信息。

A.5 回溯指数可以解释什么

已经发布的指数常有固定权重。若已知指数信息协方差 P 、信息与目标性状的协方差 C ，并假设这些权重确实是某个无约束线性育种目标下的最优解，则有 $Pb = Ca$ 。回溯经济权重就是反过来由 b 求 a 。

$$\hat{a} = (C'C)^{-1}C'Pb, \quad \text{rank}(C) = q. \quad (\text{A.4})$$

这里 q 为目标性状数, 式 (A.4) 只是满列秩条件下的最小二乘回溯; 当 Pb 不在 C 的列空间中时, 残差不为零, 所求权重只能近似重建现行指数。实际应用可根据误差结构选择加权最小二乘。若 C 不满列秩, 多个经济权重向量会给出同一个指数, 必须报告不可识别的方向。指数权重只确定到共同正比例时, 回溯经济权重也只能确定相对尺度。

以 $P = I$ 、 $C = \text{diag}(0.5, 0.25)$ 、 $b = (1, 1)'$ 为例, 回溯得到 $a = (2, 4)'$ 。相等的指数系数并不表示相等的经济权重, 因为信息与目标之间的相关程度不同。反过来, 回溯的权重只是“能解释这个指数的隐含权重”, 不能据此声称育种组织实际以这个价格评价性状。如果现行指数包含约束、分阶段选择或人为权重, 回溯还必须反映这些决策机制。

A.6 非线性目标与预测不确定性

当经济价值在最适点附近下降时, 用后验均值直接代入经济函数会遗漏不确定性。设希望性状 u 接近目标 u_0 , 损失为 $L(u) = (u - u_0)^2$ 。给定信息后的期望损失为:

$$E\{L(u) | y\} = \{E(u | y) - u_0\}^2 + \text{Var}(u | y). \quad (\text{A.5})$$

假设目标为 0, 候选甲的条件均值为 0.2、条件方差为 0.9, 候选乙的条件均值为 0.5、条件方差为 0.1。按均值距离看, 甲较好; 按期望平方损失看, 甲为 0.94、乙为 0.35, 乙较好。这个例子并不说明应普遍偏好可靠度高的动物, 而是说明: 最优排序依赖真实决策损失, 预测均值不是所有目标的充分决策摘要。

对一般光滑价值函数 $v(u)$, 在条件均值 μ 附近展开二阶项, 可得到近似 $E\{v(u) | y\} \approx v(\mu) + \frac{1}{2} \text{tr}\{\nabla^2 v(\mu) \Sigma\}$ 。这要求局部近似适当且相关矩存在。阈值、强偏态或尾部风险主导的目标, 宜采用条件分布抽样直接计算期望价值, 并检查数值误差。第 17、18 和 36 章的约束决策可在这一框架下扩展。




图 A.1 非线性目标下的预测不确定性。两候选的期望平方损失分别为 0.94 和 0.35；柱形分解对应均值偏差与条件方差。

附录 B 术语对照与概念辨析

B.1 核心概念

加性遗传值 additive genetic value 给定群体中由等位基因平均效应相加得到的遗传量，通常称育种值。统计加性依赖基因频率和群体结构，分子过程并不必然可加。见第 9 章。

平均效应 average effect 把基因型值对等位基因计数作适当回归时得到的效应，不等同于基因编辑一个碱基后的普遍因果效应。见第 9、31 章。

连锁不平衡 linkage disequilibrium 不同位点等位基因的联合频率偏离独立乘积的现象。它使标记能够追踪附近的遗传信号，也使这种追踪关系可能在群体间改变。见第 9、27、29 章。

同祖同源 identity by descent 两个等位基因拷贝来源于共同祖先的同一拷贝。与仅仅具有相同观测状态的 identity by state 不同。见第 12、26 章。

亲缘系数 kinship coefficient 通常指从两个个体各随机抽取一个等位基因拷贝同祖同源的概率。非特殊倍性和常规基因组假设下，与加性亲缘矩阵元素相差因子 2。见第 12 章。

可估性 estimability 某个固定效应线性函数可以由观测无偏估计的性质。设计矩阵不满秩时，参数本身可能不可估，但某些对比仍可估。见第 2、21 章。

连接性 connectedness 不同管理组之间具有支持遗传比较的信息联系。连接不足会使场间环境差异与遗传差异难以分开。见第 12、22 章。

选择指数 selection index 利用若干信息的加权线性组合预测预先定义的育种目标。权重由目标、信息协方差及其与目标的协方差共同决定。见第 15、16 章。

综合育种目标 aggregate genotype 按经济或目标价值权重汇总多个真实育种值的量。目标的定义先于信息的选择。见第 16 章。

限制性选择指数 restricted selection index 在某些性状的预期响应受到约束时求得的指数。约束响应、约束指数系数与约束候选个体名单是不同问题。见第 17 章。

选择强度 selection intensity 入选群体在标准化选择标准上的均值优势。在截断正态选择下可由选择比例求得，实际选配和多阶段选择可能不满足简单公式。见第 18 章。

Bulmer 效应 Bulmer effect 选择诱导位点之间统计关联，使加性遗传方差在短期发生变化的现象。与等位基因耗失或近交引起的变化需要区分。见第 18 章。

最佳线性无偏预测 BLUP 在给定均值与协方差模型下，在线性无偏预测类中最小化预测误差方差的方法。其无偏性是相对于模型总体的边际性质。见第 21 章。

经验最佳线性无偏预测 EBLUP 以估计的方差参数代替已知参数所得到的预测。插件式误差方差不自动包含方差参数估计的不确定性。见第 21、23 章。

限制最大似然 REML 依据消去固定效应后的信息估计方差组分的方法。它不会自动解决数据缺乏连接或随机效应难以区分的问题。见第 23 章。

预测误差方差 prediction error variance 预测量与其目标之差的方差。评定报告应说明方差参数是否按已知处理、以及使用哪种基础方差。见第 21、29 章。

可靠度 reliability 在相应校准线性预测条件下，常指预测与真实育种值相关的平方。公式 $1 - PEV / \text{Var}(u)$ 的使用要求与模型和目标一致。见第 15、21、29 章。

阈值模型 threshold model 以潜在连续倾向超过阈值来描述分类表型的模型。潜在尺度遗传力与观测尺度遗传力不能直接混用。见第 24 章。

随机回归 random regression 把个体随年龄、时间或环境变化的反应

表示为一组随机回归系数。协方差由基函数和系数协方差共同决定。见第 24、32 章。

基因组最佳线性无偏预测 GBLUP 利用基因组关系矩阵描述育种值协方差的 BLUP。其效果依赖矩阵定义、群体联系、训练表型和验证方式。见第 27 章。

单步基因组评定 single-step genomic evaluation 在统一模型中整合系谱、基因型和表型信息，使未分型动物也参与评定。其关键包括矩阵基础的一致性与选择信息的适当处理。见第 28 章。

元基础群体 metafounder 以带有组间关系的基础群体表示，描述系谱基础群体间的遗传联系。它不是简单给所有未知亲本赋同一个编号。见第 28 章。

预测相关 predictivity 通常指预测育种值与可观察验证指标之间的相关，常用指标包括校正表型。必须写明验证指标，不能自动称为与真实育种值的准确度。见第 29 章。

校准 calibration 预测尺度与实际差异是否一致。相关系数对统一正比例缩放不敏感，而校准斜率可以揭示这种尺度失配。见第 29、35 章。

数据泄漏 data leakage 实际决策时不可用的信息进入模型拟合或评价过程。重复个体、未来记录、全数据表型校正和验证集调参均可能造成泄漏。见第 29、34、37 章。

跨群体迁移 transfer across populations 把一个或多个群体得到的预测关系用于其他群体。标记频率、连锁不平衡、性状定义和环境差异都会影响迁移。见第 29 章。

泛基因组 pangenome 表达某一群体或物种集合基因组序列多样性的表示体系，可采用序列集合或图结构。泛基因组资源的丰富程度并不直接等于育种预测的改进幅度。见第 30 章。

结构变异 structural variant 较大尺度的插入、缺失、重复、倒位等序列结构差异。变异检出、分型、插补和表型关联是相关但不同的任务。见第 30 章。

功能先验 functional prior 用调控、表达、保守性或实验注释等信息调整效应分布假设。先验可能有用，也可能传入错误或群体不适用的信息。见第 31 章。

共定位 colocalization 判断两个关联信号是否可能由相同因果变异驱动的分析。结果依赖局部遗传结构、样本、先验和允许的因果信号数。见第 31 章。

基因与环境互作 genotype by environment interaction 基因型的表现差异随环境变化。它可能体现为遗传方差变化，也可能体现为排序改变。见第 32 章。

韧性 resilience 个体受扰动后保持或恢复功能的能力。波动小、疾病少、生长快和恢复快是不同可测量构件，不能仅用一个未经验证的残差指标概括。见第 32 章。

基因组基础模型 genomic foundation model 利用广泛序列或功能数据训练、可用于多个下游任务的模型。分子功能预测与家畜复杂性状育种值预测有不同的训练目标和证据要求。见第 33 章。

最优贡献选择 optimum contribution selection 在预期遗传收益与遗传多样性约束之间优化亲本贡献。贡献优化确定使用多少，配种优化确定谁与谁交配。见第 18、36 章。

群体共祖 group coancestry 在规定贡献权重与关系矩阵下衡量亲本基因库整体相关程度的量。它通常不等同于某一实际配种方案的后代平均近交系数。见第 18、36 章。

后验预测 posterior predictive distribution 给定数据后对未来可观察结果的分布。它一般同时包含潜在效应和新观测噪声的不确定性，与仅针对育种值的分布不同。见第 31、33、37 章。

B.2 概率与线性模型补充术语

条件期望 conditional expectation 在给定信息之后对随机量的最佳平方误差预测。它是信息的函数，不是把未知随机量简单替换为总体均值。

联合正态情形下常呈线性形式，一般情形下可以是非线性的。见第 1、21 章。

正交投影 orthogonal projection 在一个指定函数空间中寻找与目标距离最小的元素。预测误差与可用线性信息正交，是选择指数方程的一种几何解释；正交所用内积由概率模型决定。见第 1、2、15 章。

全方差公式 law of total variance 把总体方差分解为给定信息后仍然存在的平均条件方差与条件均值之间的方差。两项分别刻画未解释的变异和信息已经能够区分的变异，前提是相应二阶矩存在。见第 1 章。

偏相关 partial correlation 在线性消除其他指定变量影响以后，两个残差之间的相关。它有助于判断一项信息在已有信息之外是否仍有线性增量，但不自动具有因果含义。见第 1、15、31 章。

正定矩阵 positive definite matrix 任何非零向量所形成的二次型都严格大于零的对称矩阵。协方差矩阵正定意味着不存在方差严格为零的非平凡线性组合；半正定允许这类退化方向。见第 2 章。

广义逆 generalized inverse 对奇异矩阵问题使用的广义代数逆。不同广义逆可能给出不同参数表示，而可估函数的值仍可唯一。使用广义逆不能把一个非法协方差结构变成合法模型。见第 2、21 章。

条件数 condition number 衡量输入扰动可能被线性系统放大的程度。条件数大时，小的记录、舍入或参数误差可能导致明显的系数变化，但预测值的稳定性还取决于所关心方向。见第 2、28 章。

舒尔补 Schur complement 在分块矩阵消元时得到的剩余矩阵。条件协方差、混合模型消元和新增信息的有效方差都可以用舒尔补表达；它既是计算工具，也是信息分解工具。见第 2、15、21 章。

白化 whitening 通过协方差分解将相关、异方差误差变换为单位协方差形式。白化不会凭空增加样本量，其有效性依赖所用协方差矩阵是否适当。见第 2、21 章。

收缩 shrinkage 相对于仅由自身资料得到的估计，把不确定效应向模型基准或先验中心移动。收缩强度取决于信号与噪声的相对大小，不等于把所有个体乘以同一个固定常数。见第 15、21、27 章。

似然 likelihood 把已观察数据视为固定、把未知参数视为变量时得到的相对支持函数。似然不是参数本身的概率分布；后验分布还需要先验和归一化。见第 23、27 章。

可识别性 identifiability 不同参数值能够在观测分布上被区分的性质。样本有限时估计不稳定，与结构上不可识别不是同一问题；增加迭代次数不能解决结构混淆。见第 22—24 章。

B.3 遗传与育种决策补充术语

基因型值 genotypic value 指定基因型在所规定环境分布下的平均表现。它可以包含加性、显性和互作成分，未必能按相同方式传递给后代，因而不等同于育种值。见第 9 章。

孟德尔抽样 Mendelian sampling 子代育种值相对于双亲平均育种值的随机偏离，来自配子抽取和重组。其条件方差受亲本近交和模型假设影响，同胞间的基因组差异提供了识别它的额外信息。见第 12、26、35 章。

近交衰退 inbreeding depression 近交程度增加时某些性状均值下降的现象，常与有害隐性变异暴露有关。近交系数是关系或纯合的指标，近交衰退则是性状均值响应，两者不可直接互换。见第 9、18、22 章。

有效群体大小 effective population size 用理想群体的遗传漂变或近交速度表示实际群体遗传动态的尺度。它不等于存栏数，性别比例、贡献不均、世代重叠及历史变化均会产生影响。见第 18 章。

世代间隔 generation interval 在指定选择路径上，亲本产生用于下一代繁殖的后代时的平均年龄。年度遗传进展需要结合各路径的选择强度、准确度和世代间隔，不能只比较一次选择的预测精度。见第 18 章。

边际经济价值 marginal economic value 在其他条件 and 生产约束按模型固定时，某一目标性状遗传均值发生微小变化所带来的经济变化率。它依赖价格、资源约束、生产阶段和系统边界。见第 16 章。

期望遗传响应 expected genetic response 在明确选择规则和遗传模型下，后代群体遗传均值的预期变化。它是重复情形的平均量，不承诺每个

实际世代都实现相同结果。见第 16—18 章。

帕累托前沿 Pareto frontier 在多个目标之间，无法不损害某一目标而进一步改善另一目标的可行方案集合。它揭示取舍结构，但不会自动替决策者确定应选择的方案。见第 17、36 章。

影子价格 shadow price 在优化问题中，约束边界小幅放宽所带来的最优目标改善率。它是局部量，依赖当前最优点及约束是否活跃，不能当作全范围恒定经济价值。见第 17、18、36 章。

配种分配 mate allocation 在给定亲本名单或贡献约束下分配具体交配组合。它可以控制后代近交、遗传缺陷风险或互补性；仅有贡献比例并不能唯一确定配种结果。见第 18、36 章。

基群 base population 用于定义关系、遗传均值或遗传方差的参考群体。它可以是明确历史群体，也可以是模型上的基准；不同基群下的数值不能未经转换直接比较。见第 12、26、28 章。

遗传趋势 genetic trend 按出生年份、世代或其他时间单位汇总的遗传水平变化。它必须与环境趋势、评定基准改变和资料选择效应区分，必要时在统一评定模型中重新计算。见第 18、29、37 章。

B.4 基因组与研究设计补充术语

等位基因剂量 allele dosage 根据基因型概率得到的等位基因拷贝数条件均值。它保留了比硬判定更平滑的信息，但若只使用剂量均值，通常没有完整传递基因型不确定性。见第 26、30 章。

基因型填充 genotype imputation 利用参考单倍型、亲缘或连锁信息推断未观测基因型。评价应考虑位点频率、群体代表性和下游任务；总体一致率可能掩盖稀有等位基因的低质量。见第 26、30 章。

单倍型 haplotype 一条染色体片段上共同传递的一组等位基因。分相决定哪些等位基因位于同一拷贝；单倍型块的定义依赖群体、标记密度与算法。见第 26、30 章。

连锁不平衡衰减 linkage disequilibrium decay 等位基因之间关联随

遗传距离、重组或世代变化而减弱的现象。它影响标记追踪因果变异的能力,也影响跨群体和跨世代预测的可迁移性。见第 9、29、30 章。

岭回归 ridge regression 在平方误差目标中加入效应平方和惩罚的线性回归方法。与相应正态随机效应模型具有密切联系;与 GBLUP 的等价要求设计、尺度和惩罚参数一致。见第 27、35 章。

核矩阵 kernel matrix 由样本间相似性函数形成的半正定矩阵。它可以用于表示随机效应协方差;选择一个复杂核函数并不自动保证其捕捉到了具有遗传解释的相似性。见第 27、30、33 章。

超参数 hyperparameter 控制先验分布、惩罚、模型结构或学习程序的参数。超参数选择属于训练过程,应与最终验证资料隔离,不能通过反复查看测试结果来调优。见第 27、29、33 章。

APY 算法 algorithm for proven and young 利用核心与非核心动物之间的条件关系近似构造基因组逆矩阵的方法。近似质量取决于核心信息与剩余条件结构,而不只取决于所选核心动物数量。见第 28 章。

嵌套交叉验证 nested cross-validation 用内部划分选择模型和超参数,用外部划分估计整个选择流程的预测性能。它避免把调参得到的乐观性混入最终评价,但不能自动消除不合适的亲缘或时间划分。见第 29、33、37 章。

外部验证 external validation 在独立于模型开发流程的群体、地点、时间段或研究中检验预测。独立性的具体维度应当说明,外部资料也需要检查性状定义和测量尺度是否相容。见第 29、37 章。

分布漂移 distribution shift 训练与应用环境中的变量分布、条件关系或测量机制发生变化。它可能来自品种、环境、选择和设备改变,不同漂移机制需要不同的诊断与应对。见第 29、32、37 章。

遗传相关 genetic correlation 两个性状、环境或时间点的遗传效应之间的标准化协方差。估计依赖对应模型;表型相关较高并不要求遗传相关较高,遗传相关也可能随群体和定义改变。见第 16、24、32 章。

表达数量性状位点 eQTL 与基因表达差异相关的基因组位点。关联可

以受组织、细胞状态和环境影响；eQTL 与复杂性状信号重叠不是完整的因果链证明。见第 31 章。

孟德尔随机化 Mendelian randomization 借助遗传工具变量研究暴露与结果关系的因果推断框架。工具相关性、独立性与排除限制是核心条件，水平多效性、选择和群体结构可能破坏解释。见第 31 章。

反应规范 reaction norm 基因型或个体对环境梯度变化的表现函数。在随机回归框架中可以由随机截距、斜率或更高阶基函数表达；环境范围之外的外推需要特别谨慎。见第 32 章。

预测区间 prediction interval 对某个未来随机量给出的区间预测。区间必须写明针对育种值、校正表型还是原始表型，不同目标包含的不确定性成分不同。见第 29、35、37 章。

蒙特卡洛标准误 Monte Carlo standard error 由于模拟重复次数有限而产生的统计量估计误差。增加模拟重复有助于减小该误差，却不会改善生成模型与真实育种系统之间的相似程度。见第 35、37 章。

模拟校准 simulation-based calibration 在已知生成机制下检查推断程序能否恢复预期概率性质的一类方法。校准通过支持程序在该生成机制下的正确性，不等于证明实际资料符合该机制。见第 37 章。

可重复性 reproducibility 在资料、代码、参数、软件环境和操作记录可获得时，能够重新产生相同或约定容差内结果的性质。可重复结果仍可能依赖错误假设，因此需要与有效性和可迁移性分别检验。见第 34、37 章。

附录 C 按问题查阅的方法索引

本索引按研究和生产中常见的问题组织。列出的章节是主要入口；判断一个方法能否使用时，还应同时检查目标、信息截止日、性状定义与群体基准。基础推导与实际案例之间可以往返阅读。

C.1 概念与数据问题

需要回答的问题	主要章节	应先检查的条件
表现好的动物是否一定具有高育种值	第 1、9、21 章	表型组成、环境校正与遗传目标
预测误差为何与记录方差不同	第 1、15、21 章	预测对象、条件信息及协方差
两条高度相关的记录是否值得同时使用	第 1、2、15 章	条件增量与测量成本
矩阵能求逆是否代表模型合理	第 2、21、26 章	正定性、尺度和数据生成假设
估计不收敛是算法还是设计问题	第 2、22、23 章	可识别性、边界、梯度与曲率
相同遗传力是否对应相同遗传机制	第 9、23 章	群体频率、环境方差和模型定义
不同场之间为什么无法公平比较	第 12、22、29 章	遗传连接、组内变异与历史记录
一个个体出现多次怎样组织数据	第 24、34 章	主键、记录单位、时间和重复效应
缺失记录能否直接删除	第 1、22、34 章	缺失机制与选择过程

需要回答的问题	主要章节	应先检查的条件
多个来源的样本如何避免错配	第 26、30、34 章	身份、参考基因组、链方向与单位

C.2 目标与长期决策

需要回答的问题	主要章节	应先检查的条件
哪些性状属于目标，哪些只是信息	第 15、16 章	边际价值与信息获取时点
惩罚饲料消耗后为何耗料仍会增加	第 16、17 章	性状间遗传协方差与相对权重
如何使某项性状的预期响应不下降	第 17 章	约束可行性与指数响应
性状有最适值时怎样考虑不确定性	第 17、36 章	目标函数曲率与预测分布
精度较低的方案是否可能更优	第 18、35 章	世代间隔、强度、成本与年度进展
首代的优势能否一直线性外推	第 9、18 章	漂变、近交、选择关联与频率变化
如何比较经济收益和遗传多样性	第 17、18、36 章	贡献定义、关系尺度及约束水平
最优贡献结果如何变成配种名单	第 18、36 章	性别份额、容量、整数性及后代近交
如何避免减排强度下降但总量上升	第 16、32 章	分母变化与生产系统边界
权重和预测都不确定时怎样决策	第 17、36、37 章	参数联合不确定性与方案稳定性

C.3 模型与遗传评定

需要回答的问题	主要章节	应先检查的条件
选择指数与 BLUP 有什么联系	第 15、21 章	均值是否已知及无偏约束
随机效应预测为什么向均值收缩	第 1、21、27 章	信息精度与先验协方差
没有自身记录的动物如何获得预测	第 12、21、22 章	亲缘路径、组别联系与可用记录
母体遗传与共同环境能否分开	第 22 章	亲缘结构、跨代记录及寄养信息
应用公畜模型还是动物模型	第 21、22 章	数据组织、配种结构和目标对象
怎样估计方差组分而少受均值影响	第 23 章	固定效应空间、限制似然和边界
多性状模型何时增加信息	第 16、24、27 章	遗传相关、残差相关与缺失格局
二分类性状怎样定义遗传力	第 24 章	潜在尺度、发生率和抽样方式
年龄曲线或环境反应怎样预测	第 24、32 章	基函数、覆盖范围与曲线协方差
大规模模型怎样兼顾速度与正确性	第 2、28、34 章	稀疏结构、数值容差及统计不变量

C.4 基因组与新数据

需要回答的问题	主要章节	应先检查的条件
高填充一致率是否意味着稀有位点可靠	第 26、30 章	频率分层、剂量相关与错误类别
系谱与基因组关系能否直接拼接	第 26、28 章	基群、中心化和尺度匹配
GBLUP 与标记岭回归为何应得到相同结果	第 27、35 章	编码、惩罚和方差尺度对应
贝叶斯变量选择何时会有潜在优势	第 27、37 章	效应结构、先验与有效样本量
未分型动物能否利用基因组信息	第 28 章	统一关系模型与条件传播路径
跨品种模型为什么可能失效	第 9、29、30 章	连锁相位、频率、性状和环境差异
序列位点越多是否必然更准确	第 26、30 章	信息冗余、分型误差与验证设计
组学层面的关联是否具有育种价值	第 31 章	遗传成分、信息时点与条件增量
基础模型能否直接输出家畜育种值	第 33 章	训练物种、任务输出与独立验证
应如何比较深度学习和混合模型	第 27、29、33 章	同等数据、调参预算和分组验证

C.5 验证与研究设计

需要回答的问题	主要章节	应先检查的条件
相关很高但排序差异被夸大是何原因	第 29、35 章	校准斜率、均值偏差与尺度

需要回答的问题	主要章节	应先检查的条件
随机交叉验证能否代表未来应用	第 29、34 章	亲缘共享、时间截断与应用对象
参数已知时的 PEV 能否作为最终区间	第 21、23、37 章	方差参数误差和模型失配
没有真实育种值怎样评估模型	第 29 章	后代信息、LR 条件及替代验证指标
新模型的小幅优势是否可靠	第 29、33、37 章	重复划分、配对比较与不确定性
残差是否可以按独立回归直接检验	第 21、37 章	残差相关、收缩和估计步骤
模拟应怎样支持方法创新	第 35、37 章	可推翻的假设、失败情景与重复误差
生产使用前应做哪些外部检查	第 29、34、37 章	新场、新年份和群体迁移
评定更新后变化很大是否一定有错误	第 28、29、37 章	新增信息、基准调整与算法版本
研究结果怎样让别人独立复算	第 34、35 章；配套程序	数据字典、代码、环境与核验数值

参考文献

- Abdollahi-Arpanahi R, Lourenco D, Misztal I. 2022. A comprehensive study on size and definition of the core group in the proven and young algorithm for single-step GBLUP. *Genetics Selection Evolution*, 54:34. DOI 10.1186/s12711-022-00726-6
- Ahlinder J, Waldmann P. 2026. Uncertainty-aware breeding decisions: MCMC-based optimum contribution selection increases breeding decision robustness. *Genetics*, advance article, iyag205. DOI 10.1093/genetics/iyag205
- Aitken AC. 1936. IV.—On least squares and linear combination of observations. *Proceedings of the Royal Society of Edinburgh*, 55: 42–48. DOI 10.1017/S0370164600014346
- Albert JH, Chib S. 1993. Bayesian analysis of binary and polychotomous response data. *Journal of the American Statistical Association*, 88(422): 669–679. DOI 10.1080/01621459.1993.10476321
- Almasy L, Blangero J. 1998. Multipoint quantitative-trait linkage analysis in general pedigrees. *American Journal of Human Genetics*, 62: 1198–1211.
- AlphaGenome Atlas team, Google DeepMind. 2026. AlphaGenome Atlas: A predictive map of every possible DNA letter change in the human genome. 官方资源说明. 发布日期 2026-09-08, 访问日期 2026-09-29.
- Avsec Ž, Latysheva N, Cheng J, et al. 2026. Advancing regulatory variant effect prediction with AlphaGenome. *Nature*, 649: 1206–1218. DOI 10.1038/s41586-025-10014-0
- Azam S, Sahu A, Pandey NK, et al. 2025. Constructing a draft Indian cattle pangenome using short-read sequencing. *Communications Biology*, 8: 605. DOI 10.1038/s42003-025-07978-0
- Bateson W, Saunders ER, Punnett RC. 1905. Experimental studies in the physiology of heredity. *Reports to the Evolution Committee of the Royal Society*, II: 1–55, 80–99.
- Beavis WD. 1994. The power and deceit of QTL experiments: lessons from comparative QTL studies. *Proceedings of the Forty-Ninth Annual Corn and Sorghum Industry Research Conference*. Washington DC: American Seed Trade Association, 250–266.
- Benjamini Y, Hochberg Y. 1995. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society Series B*, 57: 289–300.

- Benke A, Urbany C, Stich B. 2015. Genome-wide association mapping of iron homeostasis in the maize association population. *BMC Genetics*, 16: 1.
- Bermann M, Aguilar I, Álvarez Munera A, Bauer J, Splíchal J, Lourenco D, Misztal I. 2024a. Approximation of reliabilities for random-regression single-step genomic best linear unbiased predictor models. *JDS Communications*, 5(6): 582–586. DOI 10.3168/jdsc.2023-0513
- Bermann M, Legarra A, Alvarez Munera A, Misztal I, Lourenco D. 2024b. Confidence intervals for validation statistics with data truncation in genomic prediction. *Genetics Selection Evolution*, 56:18. DOI 10.1186/s12711-024-00883-w
- Bijma P, Muir WM, Van Arendonk JAM. 2007. Multilevel selection 1: Quantitative genetics of inheritance and response to selection. *Genetics*, 175(1): 277–288. DOI 10.1534/genetics.106.062711
- Boddicker N, Waide EH, Rowland RRR, Lunney JK, Garrick DJ, Reecy JM, Dekkers JCM. 2012. Evidence for a major QTL associated with host response to porcine reproductive and respiratory syndrome virus challenge. *Journal of Animal Science*, 90: 1733–1746.
- Botstein D, White RL, Skolnick M, Davis RW. 1980. Construction of a genetic linkage map in man using restriction fragment length polymorphisms. *American Journal of Human Genetics*, 32: 314–331.
- Box GEP, Muller ME. 1958. A note on the generation of random normal deviates. *Annals of Mathematical Statistics*, 29: 610–611.
- Boyle EA, Li YI, Pritchard JK. 2017. An expanded view of complex traits: from polygenic to omnigenic. *Cell*, 169: 1177–1186.
- Brix G, Durrant MG, Ku J, et al. 2026. Genome modelling and design across all domains of life with Evo 2. *Nature*, 652: 1349–1361. DOI 10.1038/s41586-026-10176-5
- Bulik-Sullivan BK, Loh PR, Finucane HK, Ripke S, Yang J, Patterson N, Daly MJ, Price AL, Neale BM. 2015. LD Score regression distinguishes confounding from polygenicity in genome-wide association studies. *Nature Genetics*, 47: 291–295.
- Bulmer MG. 1971. The effect of selection on genetic variability. *American Naturalist*, 105: 201–211.
- Bulmer MG. 1971. The Effect of Selection on Genetic Variability. *The American Naturalist*, 105(943): 201–211. DOI 10.1086/282718
- Bulmer MG. 1980. *The Mathematical Theory of Quantitative Genetics*. Oxford: Clarendon Press.
- Burrows PM. 1972. Expected selection differentials for directional selection. *Biomet-*

rics, 28: 1091–1100.

Cerón-Rojas JJ, Pérez-Rodríguez P, Howard R, Vitale P, Crossa J. 2026. Maximum likelihood sampling properties of the estimator of the Smith selection index vector of coefficients. *Crop Science*, 66(1): e70216. DOI 10.1002/csc2.70216

Cheng J, Taylor KR, Nicolaisen L, Pan J, Bycroft C, Perino M, Ward T, Hawkes G, Covill LE, Weilert M, Thomas RW, Latysheva N, et al. 2026. AlphaGenome Atlas: in silico mutagenesis of the entire human genome improves prioritization and interpretation of non-coding variants. *medRxiv*, preprint v1, 发布于 2026-09-20. DOI 10.64898/2026.09.16.26363192

Christensen OF, Lund MS. 2010. Genomic prediction when some animals are not genotyped. *Genetics Selection Evolution*, 42:2. DOI 10.1186/1297-9686-42-2

Churchill GA, Doerge RW. 1994. Empirical threshold values for quantitative trait mapping. *Genetics*, 138: 963–971.

Cockerham CC. 1954. An extension of the concept of partitioning hereditary variance for analysis of covariances among relatives when epistasis is present. *Genetics*, 39: 859–882.

Comstock RE, Robinson HF, Harvey PH. 1949. A breeding procedure designed to make maximum use of both general and specific combining ability. *Agronomy Journal*, 41: 360–367.

Cook RD. 1977. Detection of Influential Observation in Linear Regression. *Technometrics*, 19(1): 15–18. DOI 10.1080/00401706.1977.10489493

Cox DR. 1972. Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2): 187–202. DOI 10.1111/j.2517-6161.1972.tb00899.x

Daetwyler HD, Villanueva B, Woolliams JA. 2008. Accuracy of predicting the genetic risk of disease using a genome-wide approach. *PLoS ONE*, 3: e3395.

Darvasi A, Soller M. 1997. A simple method to calculate resolving power and confidence interval of QTL map location. *Behavior Genetics*, 27: 125–132.

Darwin C. 1876. *The Effects of Cross and Self Fertilisation in the Vegetable Kingdom*. London: John Murray.

Dempster AP, Laird NM, Rubin DB. 1977. Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society Series B*, 39: 1–38.

Dempster ER, Lerner IM. 1950. Heritability of threshold characters. *Genetics*, 35: 212–236.

- Devlin B, Roeder K. 1999. Genomic control for association studies. *Biometrics*, 55: 997–1004.
- Dickerson GE. 1969. Experimental approaches in utilising breed resources. *Animal Breeding Abstracts*, 37: 191–202.
- Dickerson GE. 1973. Inbreeding and heterosis in animals. *Proceedings of the Animal Breeding and Genetics Symposium in Honor of Dr. Jay L. Lush*. Champaign: American Society of Animal Science, 54–77.
- Dong Q, Liu H, Li X, Wei W, Zhao S, Cao J. 2014. A genome-wide association study of five meat quality traits in Yorkshire pigs. *Frontiers of Agricultural Science and Engineering*, 1(2): 137–143.
- Ducrocq V, Quaas RL, Pollak EJ, Casella G. 1988. Length of productive life of dairy cows. 1. Justification of a Weibull model. *Journal of Dairy Science*, 71(11): 3061–3070. DOI 10.3168/jds.S0022-0302(88)79906-3
- Dunn PK, Smyth GK. 1996. Randomized Quantile Residuals. *Journal of Computational and Graphical Statistics*, 5(3): 236–244. DOI 10.2307/1390802
- East EM. 1908. Inbreeding in corn. *Report of the Connecticut Agricultural Experiment Station for 1907*: 419–428.
- Efron B. 1979. Bootstrap methods: another look at the jackknife. *Annals of Statistics*, 7: 1–26.
- Elston RC, Stewart J. 1971. A general model for the genetic analysis of pedigree data. *Human Heredity*, 21: 523–542.
- Falconer DS, Mackay TFC. 1996. *Introduction to Quantitative Genetics*. 4th ed. Harlow: Longman. ISBN 9780582243026.
- Falconer DS. 1965. The inheritance of liability to certain diseases, estimated from the incidence among relatives. *Annals of Human Genetics*, 29: 51–76.
- Fernando RL, Dekkers JCM, Garrick DJ. 2014. A class of Bayesian methods to combine large numbers of genotyped and non-genotyped animals for whole-genome analyses. *Genetics Selection Evolution*, 46:50. DOI 10.1186/1297-9686-46-50
- Fisher RA. 1918. The Correlation between Relatives on the Supposition of Mendelian Inheritance. *Transactions of the Royal Society of Edinburgh*, 52: 399–433. DOI 10.1017/S0080456800012163
- Fisher RA. 1922. On the mathematical foundations of theoretical statistics. *Philosophical Transactions of the Royal Society of London Series A*, 222: 309–368.
- Foss E, Lande R, Stahl FW, Steinberg CM. 1993. Chiasma interference as a function of

genetic distance. *Genetics*, 133: 681–691.

Franklin IR. 1980. Evolutionary change in small populations. In: Soulé ME, Wilcox BA (eds). *Conservation Biology: An Evolutionary-Ecological Perspective*. Sunderland: Sinauer, 135–149.

Fujii J, Otsu K, Zorzato F, de Leon S, Khanna VK, Weiler JE, O'Brien PJ, MacLennan DH. 1991. Identification of a mutation in porcine ryanodine receptor associated with malignant hyperthermia. *Science*, 253: 448–451.

Galton F. 1886. Regression towards mediocrity in hereditary stature. *Journal of the Anthropological Institute of Great Britain and Ireland*, 15: 246–263.

Garrick DJ, Taylor JF, Fernando RL. 2009. Deregressing estimated breeding values and weighting information for genomic regression analyses. *Genetics Selection Evolution*, 41:55. DOI 10.1186/1297-9686-41-55

Gautason E, Sahana G, Guldbrandtsen B, Berg P. 2023. Impact of kinship matrices on genetic gain and inbreeding with optimum contribution selection in a genomic dairy cattle breeding program. *Genetics Selection Evolution*, 55: 48. DOI 10.1186/s12711-023-00826-x

Gelman A. 2006. Prior distributions for variance parameters in hierarchical models (comment on article by Browne and Draper). *Bayesian Analysis*, 1(3): 515–533. DOI 10.1214/06-BA117A

Gianola D, Foulley JL. 1983. Sire evaluation for ordered categorical data with a threshold model. *Génétique, Sélection, Évolution*, 15(2): 201–224. DOI 10.1186/1297-9686-15-2-201

Gianola D, van Kaam JBCHM. 2008. Reproducing kernel Hilbert spaces regression methods for genomic assisted prediction of quantitative traits. *Genetics*, 178(4):2289–2303. DOI 10.1534/genetics.107.084285

Gibson G. 2012. Rare and common variants: twenty arguments. *Nature Reviews Genetics*, 13: 135–145.

Gilmour AR, Thompson R, Cullis BR. 1995. Average information REML: An efficient algorithm for variance parameter estimation in linear mixed models. *Biometrics*, 51(4): 1440–1450. DOI 10.2307/2533274

Gilmour AR. 2019. Average information residual maximum likelihood in practice. *Journal of Animal Breeding and Genetics*, 136(4): 262–272. DOI 10.1111/jbg.12398

Goddard ME. 2009. Genomic selection: prediction of accuracy and maximisation of long term response. *Genetica*, 136: 245–257.

Goffinet B. 1983. Selection on selected records. *Genetics Selection Evolution*, 15: 91–98.

Golub GH, Van Loan CF. 2013. *Matrix Computations*. 4th ed. Baltimore: Johns Hopkins University Press. DOI 10.56021/9781421407944

González-Recio O, López-Paredes J, Ouatahar L, Charfeddine N, Ugarte E, Alenda R, Jiménez-Montero JA. 2020. Mitigation of greenhouse gases in dairy cattle via genetic selection: 2. Incorporating methane emissions into the breeding goal. *Journal of Dairy Science*, 103(8): 7210–7221. DOI 10.3168/jds.2019-17598

Gowane G, Hidalgo J, Hollifield MK, Misztal I, Lourenco D. 2026a. Genetic parameters via predictivity in large populations under strong genomic selection. *Genetics Selection Evolution*, 58:39. DOI 10.1186/s12711-026-01054-9

Gowane G, Hidalgo J, Hollifield MK, Misztal I, Lourenco D. 2026b. Correction: Genetic parameters via predictivity in large populations under strong genomic selection. *Genetics Selection Evolution*, 58:71. DOI 10.1186/s12711-026-01089-y

Griffing B. 1956. Concept of general and specific combining ability in relation to diallel crossing systems. *Australian Journal of Biological Sciences*, 9: 463–493.

Grisart B, Coppieters W, Farnir F, Karim L, Ford C, Berzi P, Cambisano N, Mni M, Reid S, Simon P, Spelman R, Georges M, Snell R. 2002. Positional candidate cloning of a QTL in dairy cattle: identification of a missense mutation in the bovine DGAT1 gene with major effect on milk yield and composition. *Genome Research*, 12: 222–231.

Gudbjartsson DF, Walters GB, Thorleifsson G, et al. 2008. Many sequence variants affecting diversity of adult human height. *Nature Genetics*, 40: 609–615.

Guo X, Henryon M, Börner V, Ostersen T, Christensen OF. 2026. Modest contribution of metabolomic data to genomic prediction of breeding values for feed conversion ratio in pigs. *Genetics Selection Evolution*, 58: 44. DOI 10.1186/s12711-026-01064-7

Habier D, Fernando RL, Dekkers JCM. 2007. The Impact of Genetic Relationship Information on Genome-Assisted Breeding Values. *Genetics*, 177(4): 2389–2397. DOI 10.1534/genetics.107.081190

Haldane JBS. 1919. The combination of linkage values, and the calculation of distances between the loci of linked factors. *Journal of Genetics*, 8: 299–309.

Haley CS, Knott SA, Elsen JM. 1994. Mapping quantitative trait loci in crosses between outbred lines using least squares. *Genetics*, 136: 1195–1207.

Haley CS, Knott SA. 1992. A simple regression method for mapping quantitative trait loci in line crosses using flanking markers. *Heredity*, 69: 315–324.

Hardy GH. 1908. Mendelian proportions in a mixed population. *Science*, 28: 49–50.

Harris DL. 1964. Genotypic covariances between inbred relatives. *Genetics*, 50: 1319–1348.

- Harville D. 1976. Extension of the Gauss-Markov theorem to include the estimation of random effects. *The Annals of Statistics*, 4(2): 384–395. DOI 10.1214/aos/1176343414
- Harville DA. 1977. Maximum likelihood approaches to variance component estimation and to related problems. *Journal of the American Statistical Association*, 72(358): 320–338. DOI 10.1080/01621459.1977.10480998
- Haseman JK, Elston RC. 1972. The investigation of linkage between a quantitative trait and a marker locus. *Behavior Genetics*, 2: 3–19.
- Hayes BJ, Visscher PM, Goddard ME. 2009. Increased accuracy of artificial selection by using the realized relationship matrix. *Genetics Research*, 91: 47–60.
- Hazel LN. 1943. The genetic basis for constructing selection indexes. *Genetics*, 28(6): 476–490. DOI 10.1093/genetics/28.6.476
- Henderson CR, Quaas RL. 1976. Multiple trait evaluation using relatives' records. *Journal of Animal Science*, 43(6): 1188–1197. DOI 10.2527/jas1976.4361188x
- Henderson CR. 1953. Estimation of variance and covariance components. *Biometrics*, 9: 226–252.
- Henderson CR. 1975a. Best linear unbiased estimation and prediction under a selection model. *Biometrics*, 31(2): 423–447. DOI 10.2307/2529430
- Henderson CR. 1975b. Rapid method for computing the inverse of a relationship matrix. *Journal of Dairy Science*, 58(11): 1727–1730. DOI 10.3168/jds.S0022-0302(75)84776-X
- Henderson CR. 1976. A Simple Method for Computing the Inverse of a Numerator Relationship Matrix Used in Prediction of Breeding Values. *Biometrics*, 32(1): 69–83. DOI 10.2307/2529339
- Higham NJ. 2002. *Accuracy and Stability of Numerical Algorithms*. 2nd ed. Philadelphia: Society for Industrial and Applied Mathematics. DOI 10.1137/1.9780898718027
- Hill WG, Goddard ME, Visscher PM. 2008. Data and Theory Point to Mainly Additive Genetic Variance for Complex Traits. *PLoS Genetics*, 4(2): e1000008. DOI 10.1371/journal.pgen.1000008
- Hill WG, Robertson A. 1968. Linkage disequilibrium in finite populations. *Theoretical and Applied Genetics*, 38: 226–231.
- Hill WG, Weir BS. 2011. Variation in actual relationship as a consequence of Mendelian sampling and linkage. *Genetics Research*, 93: 47–64.
- Hill WG. 1974. Prediction and evaluation of response to selection with overlapping generations. *Animal Production*, 18(2): 117–139. DOI 10.1017/S0003356100017372

- Hill WG. 1981. Estimation of effective population size from data on linkage disequilibrium. *Genetical Research*, 38: 209–216.
- Hill WG. 1982. Rates of change in quantitative traits from fixation of new mutations. *Proceedings of the National Academy of Sciences USA*, 79: 142–145.
- Hiltpold M, Trépos R, Douhard F. 2026. Breeding for sheep robustness: simulation of the consequences of ewe-lamb energy allocation trade-offs. *Genetics Selection Evolution*, 58: 30. DOI 10.1186/s12711-026-01047-8
- Hindorff LA, Sethupathy P, Junkins HA, Ramos EM, Mehta JP, Collins FS, Manolio TA. 2009. Potential etiologic and functional implications of genome-wide association loci for human diseases and traits. *Proceedings of the National Academy of Sciences USA*, 106: 9362–9367.
- Hoerl AE, Kennard RW. 1970. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1): 55–67. DOI 10.1080/00401706.1970.10488634
- International Schizophrenia Consortium. 2009. Common polygenic variation contributes to risk of schizophrenia and bipolar disorder. *Nature*, 460: 748–752.
- Jacquard A. 1974. *The Genetic Structure of Populations*. Berlin: Springer-Verlag.
- Jahnel RE, Langhammer M. 2026. A random regression model for total litter weight in mice. *Journal of Animal Science*, 104: skag060. DOI 10.1093/jas/skag060
- Jansen RC. 1993. Interval mapping of multiple quantitative trait loci. *Genetics*, 135: 205–211.
- Johannes F, Colot V, Jansen RC. 2008. Epigenome dynamics: a quantitative genetics perspective. *Nature Reviews Genetics*, 9: 883–890.
- Johannes F, Porcher E, Teixeira FK, et al. 2009. Assessing the impact of transgenerational epigenetic variation on complex traits. *PLoS Genetics*, 5: e1000530.
- Johannsen W. 1903. *Über Erblichkeit in Populationen und in reinen Linien*. Jena: Gustav Fischer.
- Kackar RN, Harville DA. 1984. Approximations for standard errors of estimators of fixed and random effects in mixed linear models. *Journal of the American Statistical Association*, 79(388): 853–862. DOI 10.1080/01621459.1984.10477102
- Kang HM, Sul JH, Service SK, Zaitlen NA, Kong SY, Freimer NB, Sabatti C, Eskin E. 2010. Variance component model to account for sample structure in genome-wide association studies. *Nature Genetics*, 42: 348–354.
- Kang HM, Zaitlen NA, Wade CM, Kirby A, Heckerman D, Daly MJ, Eskin E. 2008. Efficient control of population structure in model organism association mapping. *Ge-*

netics, 178: 1709–1723.

Kao CH, Zeng ZB, Teasdale RD. 1999. Multiple interval mapping for quantitative trait loci. *Genetics*, 152: 1203–1216.

Kempthorne O, Nordskog AW. 1959. Restricted selection indices. *Biometrics*, 15(1): 10–19. DOI 10.2307/2527598

Kempthorne O. 1954. The correlation between relatives in a random mating population. *Proceedings of the Royal Society of London Series B*, 143: 103–113.

Kimura M. 1962. On the probability of fixation of mutant genes in a population. *Genetics*, 47: 713–719.

Kingman JFC. 1982. The coalescent. *Stochastic Processes and their Applications*, 13: 235–248.

Kirkpatrick M, Lofsvold D, Bulmer M. 1990. Analysis of the inheritance, selection and evolution of growth trajectories. *Genetics*, 124(4): 979–993. DOI 10.1093/genetics/124.4.979

Knott SA, Elsen JM, Haley CS. 1996. Methods for multiple-marker mapping of quantitative trait loci in half-sib populations. *Theoretical and Applied Genetics*, 93: 71–80.

Kosambi DD. 1944. The estimation of map distances from recombination values. *Annals of Eugenics*, 12: 172–175.

Lande R, Arnold SJ. 1983. The measurement of selection on correlated characters. *Evolution*, 37: 1210–1226.

Lander E, Kruglyak L. 1995. Genetic dissection of complex traits: guidelines for interpreting and reporting linkage results. *Nature Genetics*, 11: 241–247.

Lander ES, Botstein D. 1989. Mapping Mendelian factors underlying quantitative traits using RFLP linkage maps. *Genetics*, 121: 185–199.

Lander ES, Green P. 1987. Construction of multilocus genetic linkage maps in humans. *Proceedings of the National Academy of Sciences USA*, 84: 2363–2367.

Lango Allen H, Estrada K, Lettre G, et al. 2010. Hundreds of variants clustered in genomic loci and biological pathways affect human height. *Nature*, 467: 832–838.

Legarra A, Bermann M, Mei Q, Christensen OF. 2024a. Redefining and interpreting genomic relationships of metafounders. *Genetics Selection Evolution*, 56:34. DOI 10.1186/s12711-024-00891-w

Legarra A, Bermann M, Mei Q, Christensen OF. 2024b. Estimating genomic relationships of metafounders across and within breeds using maximum likelihood, pseudo-expectation-maximization maximum likelihood and increase of relationships. *Genet-*

ics Selection Evolution, 56:35. DOI 10.1186/s12711-024-00892-9

Legarra A, Christensen OF, Vitezica ZG, Aguilar I, Misztal I. 2015. Ancestral relationships using metafounders: finite ancestral populations and across population relationships. *Genetics*, 200(2):455–468. DOI 10.1534/genetics.115.177014

Legarra A, Reverter A. 2018. Semi-parametric estimates of population accuracy and bias of predictions of breeding values and future phenotypes using the LR method. *Genetics Selection Evolution*, 50:53. DOI 10.1186/s12711-018-0426-6

Legarra A, Reverter A. 2019. Correction to: Semi-parametric estimates of population accuracy and bias of predictions of breeding values and future phenotypes using the LR method. *Genetics Selection Evolution*, 51:69. DOI 10.1186/s12711-019-0511-5

Lei J, G'Sell M, Rinaldo A, Tibshirani RJ, Wasserman L. 2018. Distribution-Free Predictive Inference for Regression. *Journal of the American Statistical Association*, 113(523): 1094–1111. DOI 10.1080/01621459.2017.1307116

Lettre G, Jackson AU, Gieger C, et al. 2008. Identification of ten loci associated with height highlights new biological pathways in human growth. *Nature Genetics*, 40: 584–591.

Lewandowski D, Kurowicka D, Joe H. 2009. Generating random correlation matrices based on vines and extended onion method. *Journal of Multivariate Analysis*, 100(9): 1989–2001. DOI 10.1016/j.jmva.2009.04.008

Lewontin RC. 1964. The interaction of selection and linkage. I. General considerations; heterotic models. *Genetics*, 49: 49–67.

Li N, Stephens M. 2003. Modeling linkage disequilibrium and identifying recombination hotspots using single-nucleotide polymorphism data. *Genetics*, 165(4):2213–2233. DOI 10.1093/genetics/165.4.2213

Li Z, Albrechtsen A, Davies RW. 2026. Flexible read-aware genotype imputation from sequence using biobank sized reference panels. *Nature Communications*, 17:524. DOI 10.1038/s41467-025-67218-1

Louis TA. 1982. Finding the observed information matrix when using the EM algorithm. *Journal of the Royal Statistical Society Series B*, 44: 226–233.

Lynch M, Walsh B. 1998. *Genetics and Analysis of Quantitative Traits*. Sunderland, MA: Sinauer Associates. ISBN 9780878934812.

MacLeod IM, Bowman PJ, Vander Jagt CJ, Haile-Mariam M, Kemper KE, Chamberlain AJ, Schrooten C, Hayes BJ, Goddard ME. 2016. Exploiting biological priors and sequence variants enhances QTL discovery and genomic prediction of complex traits. *BMC Genomics*, 17:144. DOI 10.1186/s12864-016-2443-6

- Madsen MD, Granleese T, Hergenhahn R, Aliloo H, Aldridge MN, Clark SA. 2026. The genetic relationships between different definitions of emissions outputs and feedlot production traits. *Genetics Selection Evolution*, 58: 65. DOI 10.1186/s12711-026-01086-1
- Maher B. 2008. Personal genomes: the case of the missing heritability. *Nature*, 456: 18–21.
- Manolio TA, Collins FS, Cox NJ, et al. 2009. Finding the missing heritability of complex diseases. *Nature*, 461: 747–753.
- Mendel G. 1866. Versuche über Pflanzen-Hybriden. *Verhandlungen des naturforschenden Vereines in Brünn*, 4: 3–47.
- Meuwisen T, Yu X, Berg P. 2026. Genomic estimates of Identity-By-Descent relationships in large scale data sets. *Genetics Selection Evolution*, 58:20. DOI 10.1186/s12711-026-01038-9
- Meuwissen T H E. 1997. Maximizing the response of selection with a predefined rate of inbreeding. *Journal of Animal Science*, 75(4):934–940. DOI 10.2527/1997.754934x
- Meuwissen THE, Hayes BJ, Goddard ME. 2001. Prediction of total genetic value using genome-wide dense marker maps. *Genetics*, 157(4):1819–1829. DOI 10.1093/genetics/157.4.1819
- Meuwissen THE, Solberg TR, Shepherd R, Woolliams JA. 2009. A fast algorithm for BayesB type of prediction of genome-wide estimates of genetic value. *Genetics Selection Evolution*, 41: 2.
- Misztal I, Legarra A, Aguilar I. 2014. Using recursion to compute the inverse of the genomic relationship matrix. *Journal of Dairy Science*, 97(6):3943–3952. DOI 10.3168/jds.2013-7752
- Misztal I, Lourenco D, Legarra A. 2020. Current status of genomic evaluation. *Journal of Animal Science*, 98(4): skaa101. DOI 10.1093/jas/skaa101
- Morgan TH. 1911. Random segregation versus coupling in Mendelian inheritance. *Science*, 34: 384.
- Morris T P, White I R, Crowther M J. 2019. Using simulation studies to evaluate statistical methods. *Statistics in Medicine*, 38(11):2074–2102. DOI 10.1002/sim.8086
- Morton NE. 1955. Sequential tests for the detection of linkage. *American Journal of Human Genetics*, 7: 277–318.
- Nguyen TQ, Martínez-Álvaro M, Lima J, Gorjanc G, Cleveland MA, Roehe R. 2026. Optimisation of selection for methane mitigation by integrating production traits with ruminal microbiome-driven breeding in beef cattle. *Genetics Selection Evolution*, 58:

47. DOI 10.1186/s12711-026-01053-w

Nilsson-Ehle H. 1909. Kreuzungsuntersuchungen an Hafer und Weizen. Lunds Universitets Årsskrift, Ny Följd, Afd. 2, 5(2): 1–122.

Ogunbawo AR, Hidalgo J, Mulim HA, Carrara ER, Ventura HT, Souza NO, Lourenco D, Oliveira HR. 2025. Applying the algorithm for Proven and young in GWAS Reveals high polygenicity for key traits in Nellore cattle. *Frontiers in Genetics*, 16:1549284. DOI 10.3389/fgene.2025.1549284

Osorio-Gallardo T, van Putten A, Janssen D, Schrauf MF, Giersberg MF, Rodenburg TB, Bijma P. 2026. From pixels to breeding values: genetic analysis of detection and movement traits in laying hens using automated tracking data of ArUco-marked birds. *Genetics Selection Evolution*, 58: 28. DOI 10.1186/s12711-026-01043-y

Paneru U, Moghaddar N, van der Werf J. 2024. Comparison between multiple-trait and random regression models for genetic evaluation of weight traits in Australian meat sheep. *Journal of Animal Science*, 102: skae038. DOI 10.1093/jas/skae038

Pardo AM, Legarra A, Vitezica ZG, Forneris NS, Maizon DO, Munilla S. 2024. On the ability of the LR method to detect bias when there is pedigree misspecification and lack of connectedness. *Genetics Selection Evolution*, 56:74. DOI 10.1186/s12711-024-00943-1

Patterson HD, Thompson R. 1971. Recovery of inter-block information when block sizes are unequal. *Biometrika*, 58(3): 545–554. DOI 10.1093/biomet/58.3.545

PLINK 项目. 2026. Input filtering—PLINK 2.0. 在线技术文档. (访问日期: 2026-09-29)

.

Pooley CM, Marion G, Bishop SC, Bailey RI, Doeschl-Wilson AB. 2020. Estimating individuals' genetic and non-genetic effects underlying infectious disease transmission from temporal epidemic data. *PLOS Computational Biology*, 16(12): e1008447. DOI 10.1371/journal.pcbi.1008447

Powell JE, Visscher PM, Goddard ME. 2010. Reconciling the analysis of IBD and IBS in complex trait studies. *Nature Reviews Genetics*, 11: 800–805.

Price AL, Patterson NJ, Plenge RM, Weinblatt ME, Shadick NA, Reich D. 2006. Principal components analysis corrects for stratification in genome-wide association studies. *Nature Genetics*, 38: 904–909.

Price GR. 1970. Selection and covariance. *Nature*, 227: 520–521. DOI 10.1038/227520a0

Price GR. 1970. Selection and covariance. *Nature*, 227: 520–521.

Pritchard JK. 2001. Are rare variants responsible for susceptibility to complex diseases? *American Journal of Human Genetics*, 69: 124–137.

- Purcell S, Neale B, Todd-Brown K, et al. 2007. PLINK: A tool set for whole-genome association and population-based linkage analyses. *American Journal of Human Genetics*, 81(3):559–575. DOI 10.1086/519795
- Rizopoulos D, Taylor JMG. 2024. Optimizing dynamic predictions from joint models using super learning. *Statistics in Medicine*, 43(7): 1315–1328. DOI 10.1002/sim.10010
- Rizopoulos D. 2011. Dynamic predictions and prospective accuracy in joint models for longitudinal and time-to-event data. *Biometrics*, 67(3): 819–829. DOI 10.1111/j.1541-0420.2010.01546.x
- Robertson A. 1959. The sampling variance of the genetic correlation coefficient. *Biometrics*, 15: 469–485.
- Robertson A. 1960. A theory of limits in artificial selection. *Proceedings of the Royal Society of London Series B*, 153: 234–249.
- Robertson A. 1961. Inbreeding in artificial selection programmes. *Genetical Research*, 2: 189–194.
- Robertson A. 1966. A mathematical model of the culling process in dairy cattle. *Animal Production*, 8: 95–108.
- Rockafellar RT, Uryasev S. 2000. Optimization of conditional value-at-risk. *Journal of Risk*, 2(3): 21–41. DOI 10.21314/jor.2000.038
- Rubinacci S, Hofmeister RJ, Sousa da Mota B, Delaneau O. 2023. Imputation of low-coverage sequencing data from 150,119 UK Biobank genomes. *Nature Genetics*, 55:1088–1090. DOI 10.1038/s41588-023-01438-3
- Ryan CV, Purfield DC, Kenny D, Crosson P, Evans RD. 2025. Refining Irish breeding goals for sustainable suckler systems through the incorporation of an enteric methane emissions trait. *Livestock Science*, 302: 105837. DOI 10.1016/j.livsci.2025.105837
- Sabeti PC, Reich DE, Higgins JM, et al. 2002. Detecting recent positive selection in the human genome from haplotype structure. *Nature*, 419: 832–837.
- Sahana VN, Gowane GR, Nayee N, Khan KD, Yadav A, Paul R, Vohra V, Alex R. 2025. Shared SNP effects across breeds increase the genomic prediction accuracy for numerically small breeds. *Scientific Reports*, 15:31421. DOI 10.1038/s41598-025-15733-y
- Santana ML, Brito LF, Cardoso DF, Piccoli ML, Bignardi AB. 2026. Genetics of growth resilience- and uniformity-related indicators derived from sparse body weight data in Angus–Brangus cattle under (sub)tropical conditions. *Genetics Selection Evolution*, 58: 51. DOI 10.1186/s12711-026-01073-6
- Satoh M. 2024. Characteristics of restricted selection indices and geometrical interpretation of restricted breeding values. *Journal of Animal Breeding and Genetics*, 141(3):

353–363. DOI 10.1111/jbg.12845

Schlüter-Bartram J-S, Heinrich F, Gültas M, Schmitt AO. 2026. Genomic solutions to metadata challenges: a case study on the 1000 Bull Genomes Project. *Genetics Selection Evolution*, 58: 36. DOI 10.1186/s12711-026-01061-w

Self SG, Liang KY. 1987. Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, 82(398): 605–610. DOI 10.1080/01621459.1987.10478472

Shull GH. 1908. The composition of a field of maize. *Report of the American Breeders' Association*, 4: 296–301.

Silventoinen K, Sammalisto S, Perola M, et al. 2003. Heritability of adult body height: a comparative study of twin cohorts in eight countries. *Twin Research*, 6: 399–408.

Slatkin M. 2009. Epigenetic inheritance and the missing heritability problem. *Genetics*, 182: 845–850.

Smith HF. 1936. A discriminant function for plant selection. *Annals of Eugenics*, 7(3): 240–250. DOI 10.1111/j.1469-1809.1936.tb02143.x

Sorensen DA, Wang CS, Jensen J, Gianola D. 1994. Bayesian analysis of genetic change due to selection using Gibbs sampling. *Genetics Selection Evolution*, 26(4): 333–360. DOI 10.1186/1297-9686-26-4-333

Sprague GF, Tatum LA. 1942. General vs. specific combining ability in single crosses of corn. *Journal of the American Society of Agronomy*, 34: 923–932.

Stam P. 1993. Construction of integrated genetic linkage maps by means of a new computer package: JoinMap. *The Plant Journal*, 3: 739–744.

Stephens M, Smith NJ, Donnelly P. 2001. A new statistical method for haplotype reconstruction from population data. *American Journal of Human Genetics*, 68: 978–989.

Stich B, Möhring J, Piepho HP, Heckenberger M, Buckler ES, Melchinger AE. 2008. Comparison of mixed-model approaches for association mapping. *Genetics*, 178: 1745–1754.

Storey JD, Tibshirani R. 2003. Statistical significance for genomewide studies. *Proceedings of the National Academy of Sciences USA*, 100: 9440–9445.

Strandén I, Garrick DJ. 2009. Technical note: Derivation of equivalent computing algorithms for genomic predictions and reliabilities of animal merit. *Journal of Dairy Science*, 92(6): 2971–2975. DOI 10.3168/jds.2008-1929

Strandén I, Mäntysaari EA, Lidauer MH, Thompson R, Gao H. 2024. A computationally efficient algorithm to leverage average information REML for (co)variance

- component estimation in the genomic era. *Genetics Selection Evolution*, 56: 73. DOI 10.1186/s12711-024-00939-x
- Sturtevant AH. 1913. The linear arrangement of six sex-linked factors in *Drosophila*, as shown by their mode of association. *Journal of Experimental Zoology*, 14: 43–59.
- Sun G, Zhu C, Kramer MH, Yang SS, Song W, Piepho HP, Yu J. 2010. Variation explained in mixed-model association mapping. *Heredity*, 105: 333–340.
- Sved JA. 1971. Linkage disequilibrium and homozygosity of chromosome segments in finite populations. *Theoretical Population Biology*, 2: 125–141.
- Talts S, Betancourt M, Simpson D, Vehtari A, Gelman A. 2018. Validating Bayesian Inference Algorithms with Simulation-Based Calibration. arXiv:1804.06788, preprint v2, 修订于 2020-10-21. DOI 10.48550/arXiv.1804.06788
- Tang Z, Xiong X, Zhang H, Yin D, Fu Y, Zhao Y, Li J, Quan Y, Zhou X, Li X, Yin L, Zhao S, Liu X. 2026. Improving genomic prediction accuracy of complex traits by integrating massive types of functional annotation information. *Nature Communications*, 17: 5686. DOI 10.1038/s41467-026-72470-0
- Taskinen M, Mäntysaari EA, Strandén I. 2017. Single-step SNP-BLUP with on-the-fly imputed genotypes and residual polygenic effects. *Genetics Selection Evolution*, 49:36. DOI 10.1186/s12711-017-0310-9
- Tiezzi F, Panetto JCC, Callegaro S, Jiang J, Zanotti A, Ablondi M, Cipolat-Gotet C, Finocchiaro R, Cassandro M, Van Kaam J, Maltecca C. 2026. Heat-load-dependent inbreeding depression for production traits in Italian Holstein cattle. *Genetics Selection Evolution*, 58: 60. DOI 10.1186/s12711-026-01069-2
- Tsiatis AA, Davidian M. 2004. Joint modeling of longitudinal and time-to-event data: An overview. *Statistica Sinica*, 14(3): 809–834. <https://www3.stat.sinica.edu.tw/statistica/J14N3/J14N39/J14N39.html>
- Van der Werf JH, Goddard ME, Meyer K. 1998. The use of covariance functions and random regressions for genetic evaluation of milk production based on test day records. *Journal of Dairy Science*, 81(12): 3300–3308. DOI 10.3168/jds.S0022-0302(98)75895-3
- Van Laere AS, Nguyen M, Braunschweig M, et al. 2003. A regulatory mutation in IGF2 causes a major QTL effect on muscle growth in the pig. *Nature*, 425: 832–836.
- Van Vleck LD. 1993. *Selection Index and Introduction to Mixed Model Methods*. Boca Raton: CRC Press.
- VanRaden PM. 2008. Efficient methods to compute genomic predictions. *Journal of Dairy Science*, 91(11):4414–4423. DOI 10.3168/jds.2007-0980
- Visscher PM, Hemani G, Vinkhuyzen AAE, et al. 2014. Statistical power to detect ge-

netic (co)variance of complex traits using SNP data in unrelated samples. *PLoS Genetics*, 10: e1004269.

Visscher PM, Hill WG, Wray NR. 2008. Heritability in the genomics era: concepts and misconceptions. *Nature Reviews Genetics*, 9: 255–266.

Visscher PM, Medland SE, Ferreira MAR, et al. 2006. Assumption-free estimation of heritability from genome-wide identity-by-descent sharing between full siblings. *PLoS Genetics*, 2: e41.

Wainschtein P, Jain D, Zheng Z, et al. 2022. Assessing the contribution of rare variants to complex trait heritability from whole-genome sequence data. *Nature Genetics*, 54: 263–273.

Wakefield J. 2009. Bayes factors for genome-wide association studies: comparison with P-values. *Genetic Epidemiology*, 33: 79–86.

Waldmann P. 2025. Genomic optimum contribution selection and mate allocation using JuMP. *Bioinformatics Advances*, 5(1):vbaf259. DOI 10.1093/bioadv/vbaf259

Walsh B, Visscher PM, Lynch M, eds. 2025. *Genetics and Analysis of Quantitative Traits: Foundations*. 2nd ed. Oxford: Oxford University Press. DOI 10.1093/oso/9780192898180.001.0001

Wang X, Shi S, Ali Khan MY, Zhang Z, Zhang Y. 2024. Improving the accuracy of genomic prediction in dairy cattle using the biologically annotated neural networks framework. *Journal of Animal Science and Biotechnology*, 15:87. DOI 10.1186/s40104-024-01044-1

Waples RS, Do C. 2008. LDNE: a program for estimating effective population size from data on linkage disequilibrium. *Molecular Ecology Resources*, 8: 753–756.

Weedon MN, Lango H, Lindgren CM, et al. 2008. Genome-wide association analysis identifies 20 loci that influence adult height. *Nature Genetics*, 40: 575–583.

Weinberg W. 1908. Über den Nachweis der Vererbung beim Menschen. *Jahreshefte des Vereins für vaterländische Naturkunde in Württemberg*, 64: 368–382.

Weir BS, Hill WG. 1980. Effect of mating structure on variation in linkage disequilibrium. *Genetics*, 95: 477–488.

Weller JL, Kashi Y, Soller M. 1990. Power of daughter and granddaughter designs for determining linkage between marker loci and quantitative trait loci in dairy cattle. *Journal of Dairy Science*, 73: 2525–2537.

Wientjes YCJ, Bijma P, Vandenplas J, Calus MPL. 2017. Multi-population genomic relationships for estimating current genetic variances within and genetic correlations between populations. *Genetics*, 207(2): 503–515. DOI 10.1534/genetics.117.300152

- Wigginton JE, Cutler DJ, Abecasis GR. 2005. A note on exact tests of Hardy-Weinberg equilibrium. *American Journal of Human Genetics*, 76(5):887–893. DOI 10.1086/429864
- Wilkinson M D, Dumontier M, Aalbersberg I J, et al. 2016. The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*, 3:160018. DOI 10.1038/sdata.2016.18
- Wilks SS. 1938. The large-sample distribution of the likelihood ratio for testing composite hypotheses. *Annals of Mathematical Statistics*, 9: 60–62.
- Willham RL. 1963. The covariance between relatives for characters composed of components contributed by related individuals. *Biometrics*, 19(1): 18–27. DOI 10.2307/2527570
- Willham RL. 1972. The role of maternal effects in animal breeding: III. Biometrical aspects of maternal effects in animals. *Journal of Animal Science*, 35(6): 1288–1293. DOI 10.2527/jas1972.3561288x
- Williams D. 1991. *Probability with Martingales*. Cambridge: Cambridge University Press. DOI 10.1017/CBO9780511813658
- Wood AR, Esko T, Yang J, et al. 2014. Defining the role of common variation in the genomic and biological architecture of adult human height. *Nature Genetics*, 46: 1173–1186.
- Woolliams JA, Bijma P, Villanueva B. 1999. Expected genetic contributions and their impact on gene flow and genetic gain. *Genetics*, 153(2): 1009–1020. DOI 10.1093/genetics/153.2.1009
- Woolliams JA, Bijma P. 2000. Predicting rates of inbreeding in populations undergoing selection. *Genetics*, 154: 1851–1864.
- Wray NR, Goddard ME, Visscher PM. 2007. Prediction of individual genetic risk to disease from genome-wide association studies. *Genome Research*, 17: 1520–1528.
- Wray NR, Woolliams JA, Thompson R. 1990. Methods for predicting rates of inbreeding in selected populations. *Theoretical and Applied Genetics*, 80: 503–512.
- Wray NR, Yang J, Hayes BJ, Price AL, Goddard ME, Visscher PM. 2013. Pitfalls of predicting complex traits from SNPs. *Nature Reviews Genetics*, 14: 507–515.
- Wright S. 1922. Coefficients of inbreeding and relationship. *American Naturalist*, 56: 330–338.
- Wright S. 1922. Coefficients of Inbreeding and Relationship. *The American Naturalist*, 56(645): 330–338. DOI 10.1086/279872

- Wright S. 1931. Evolution in Mendelian populations. *Genetics*, 16: 97–159.
- Wright S. 1951. The genetical structure of populations. *Annals of Eugenics*, 15: 323–354.
- Yang J, Benyamin B, McEvoy BP, Gordon S, Henders AK, Nyholt DR, Madden PA, Heath AC, Martin NG, Montgomery GW, Goddard ME, Visscher PM. 2010. Common SNPs explain a large proportion of the heritability for human height. *Nature Genetics*, 42: 565–569.
- Yang J, Manolio TA, Pasquale LR, et al. 2011. Genome partitioning of genetic variation for complex traits using common SNPs. *Nature Genetics*, 43: 519–525.
- Yang J, Wientjes YCJ, Calus MPL, Duenk P. 2026. Impact of QTL number, heritability and reference population size on the benefit of machine learning models over GBLUP in genomic prediction. *Genetics Selection Evolution*, 58: 49. DOI 10.1186/s12711-026-01065-6
- Yang L, Gao Y, Kuhn KL, Bhowmik N, Li W, Zanton G, Fang L, Cole JB, Li C, Baldwin VI RL, Van Tassell CP, Rosen BD, Ma L, Smith TPL, Liu GE. 2026a. Phased-assembly-driven pangenome graphs for structural variant genotyping and complex trait mapping in dairy cattle. *Nature Communications*, 17: 2186. DOI 10.1038/s41467-026-68807-4
- Yang L, Wang J, Kuhn K, et al. 2026b. Pangenome-based structural variant imputation enables large-scale genotype-phenotype studies in dairy cattle. *Nature Communications*, 17: 8281. DOI 10.1038/s41467-026-75219-x
- Yang T, Wu W, Xue Y, Zhou L, Kang H, Liu J. 2026. Gsformer: a dual-architecture deep learning framework with CNN-self-attention and sparse-attention for genomic selection. *Genetics Selection Evolution*, 58: 38. DOI 10.1186/s12711-026-01055-8
- Ye C, Benegas G, Albors C, Li JC, Prillo S, Fields PD, Clarke B, Song YS. 2026. Predicting genome-wide functional constraints with GPN-Star. *Nature*, advance online publication, 2026-09-09. DOI 10.1038/s41586-026-11005-5
- Yengo L, Vedantam S, Marouli E, et al. 2022. A saturated map of common genetic variants associated with human height. *Nature*, 610: 704–712.
- Yu J, Pressoir G, Briggs WH, et al. 2006. A unified mixed-model method for association mapping that accounts for multiple levels of relatedness. *Nature Genetics*, 38: 203–208.
- Yule GU. 1902. Mendel's laws and their probable relations to intra-racial heredity. *New Phytologist*, 1: 193–207, 222–238.
- Zeng ZB. 1994. Precision mapping of quantitative trait loci. *Genetics*, 136: 1457–1468.
- Zhang Z, Ersoz E, Lai CQ, et al. 2010. Mixed linear model approach adapted for

genome-wide association studies. *Nature Genetics*, 42: 355–360.

Zuk O, Hechter E, Sunyaev SR, Lander ES. 2012. The mystery of missing heritability: genetic interactions create phantom heritability. *Proceedings of the National Academy of Sciences USA*, 109: 1193–1198.

索引

B

半同胞 147, 165, 180, 235, 271, 285,
299, 338, 618, 1048, 1083, 1112,
1229
Beavis 效应 192
贝叶斯 .. 13, 108, 147, 188, 579, 654, 701,
797, 891, 1085, 1221
标记辅助选择 102, 192, 199
表示学习 1033
表型相关 . 259, 619, 910, 956, 1008, 1125,
1242
BLUP 109, 348, 578, 653, 714,
813, 848, 875, 1034, 1092, 1115,
1153, 1198
Bonferroni 校正 186, 208
Bulmer 效应 231, 264, 348

C

参考群体 212, 220, 306, 496, 625,
697, 747, 804, 855, 892, 915, 974,
1048, 1095, 1188, 1198
长期选择 ... 174, 221, 348, 370, 424, 529,
614, 935, 1013
Cholesky 分解 46
重复力 ... 19, 99, 259, 335, 411, 697, 892
重组率 92, 147, 163, 221, 1114
重组损失 559, 631
错误发现率 208, 928

D

单倍型 94, 141, 167, 192, 228, 291,
307, 355, 514, 755, 799, 894, 918,
1039, 1114, 1241
等位基因频率 108, 117, 189, 203,
220, 259, 288, 306, 355, 497, 539,
594, 632, 743, 747, 838, 893, 920,
1052, 1084, 1175
动物模型 60, 269, 286, 310, 341, 585, 613,
716, 737, 848, 1247
多性状模型 .. 19, 347, 592, 675, 693, 797,
850, 1085, 1200
多重检验 110, 233, 928, 1225
多组学 241, 804, 953, 1213

E

EM 算法 110, 184
二项分布 332

F

方差分析 82, 335, 1229
方差组分 59,
92, 198, 226, 268, 280, 344, 505,
561, 595, 637, 653, 893, 1236
泛基因组 922, 1046, 1237
反应规范 239, 435, 711, 994
Fisher 219, 1254
复合区间作图 190

G

GBLUP 813, 898, 1048, 1092, 1115, 1153,
1207

公畜模型 613, 1247

GREML 739

广义逆 ... 26, 41, 245, 462, 588, 657, 824,
1086, 1239

广义遗传力 89, 267

H

Henderson 60, 302, 581, 694, 1257

后验分布 489, 673, 1240

环境方差 ... 3, 45, 220, 265, 335, 526, 611,
637, 653, 724, 1225

环境相关 ... 234, 270, 520, 724, 735, 1015,
1047, 1192

互补性 428, 499, 555, 1047, 1241

混合模型方程 58, 83, 581, 671, 832, 1073

J

交叉验证 20, 104, 393, 726, 767, 791, 874,
963, 1069, 1203

加性方差 ... 115, 220, 263, 296, 335, 359,
410, 520, 547, 561, 625, 653, 694,
805, 1111, 1200

加性关系矩阵 498

截断选择 149, 264, 360, 935

近交衰退 ... 123, 226, 263, 370, 497, 539,
1013, 1240

近交系数 82, 123, 255, 295, 539, 561, 648,
772, 1238

基因型频率 117, 245, 855, 896

基因型值 ... 89, 219, 259, 360, 625, 1235

基因与环境互作 211, 234, 313, 994, 1275

基因组关系矩阵 ... 56, 413, 499, 737, 932,
1237

基因组控制 204

基因组选择 193, 212, 496, 893

基因组预测 78, 141, 174, 212, 239,
264, 373, 562, 743, 769, 789, 891,
1044

矩阵求逆 68

K

可估函数 310, 1239

可靠性 78, 389, 596, 916, 976, 1015, 1046,
1136, 1172

L

LD 分数回归 741

连锁不平衡 51, 141, 179, 197, 220,
259, 355, 497, 594, 738, 772, 798,
893, 915, 961, 1036, 1130, 1175,
1205

连锁图谱 166, 1275

岭回归 797, 1034, 1092, 1248

LOD 值 93, 166

轮回杂交 558

M

母体效应 ... 3, 41, 104, 228, 269, 285, 336,
427, 619, 966

P

平均替代效应 220, 259, 804, 932

平均效应 115, 219, 263, 1235

Q

亲缘系数 295, 380, 620, 1165
 亲子回归 100, 336
 期望 4, 59, 81, 120, 187, 204,
 226, 287, 307, 336, 355, 373, 417,
 455, 500, 547, 560, 579, 613, 654,
 695, 737, 747, 800, 861, 874, 939,
 1021, 1097, 1116, 1151, 1212
 全基因组关联研究 ... 106, 192, 198, 289
 全基因组序列 83, 915, 1275
 全同胞 11, 173, 180, 235, 284,
 299, 344, 382, 543, 586, 620, 773,
 1112, 1157
 缺失遗传力 211, 289, 736
 区间作图 97, 170, 182
 群体分层 106, 236, 740, 767, 844

R

REML 97, 201, 346, 657, 739, 1132, 1236

S

上位方差 232, 259, 344, 737
 上位效应 626
 深度学习 1033, 1248
 世代间隔 26, 212, 232, 313, 384, 496, 813,
 935, 990, 1113, 1175, 1240
 似然比检验 104, 191
 双列杂交 343
 数量性状位点 83, 115, 964, 1275
 SNP 遗传力 264, 738
 随机回归模型 347, 376

T

特殊配合力 560
 条件期望 . 14, 88, 395, 529, 606, 690, 725,
 774, 900, 1097, 1119, 1212

W

Wright 295, 1267

X

显性方差 223, 262, 335, 547, 625
 显性关系矩阵 625
 先验分布 789, 1242
 狭义遗传力 234, 339
 协方差 7, 43, 81, 149, 219, 264,
 277, 295, 335, 360, 373, 413, 455,
 505, 547, 571, 613, 653, 693, 737,
 767, 789, 835, 881, 942, 953, 993,
 1033, 1076, 1115, 1152, 1191
 系谱 23, 60, 123, 198, 226, 277,
 295, 345, 377, 499, 547, 565, 577,
 613, 735, 747, 817, 831, 873, 933,
 1075, 1112, 1165, 1198
 选择差 251, 356, 414, 495, 618, 836
 选择反应 26, 192, 219, 259, 277, 335,
 355, 414, 539, 811, 896, 915, 974,
 1007, 1151
 选择强度 26, 232, 316, 392, 421, 454, 496,
 935, 1052, 1205
 选择指数 . 4, 82, 242, 355, 373, 431, 453,
 495, 580, 710, 973, 1010, 1239

Y

一般配合力 222, 560
 遗传力 89, 115, 174, 200,
 220, 259, 277, 335, 356, 375, 413,

580, 617, 662, 697, 735, 809, 893,
1062, 1130, 1153, 1204
遗传漂变 125, 224, 497, 1240
遗传趋势 44, 254, 313, 496, 577, 676, 708,
778, 836, 884, 1003, 1086, 1206
遗传相关 .. 19, 45, 99, 237, 270, 313, 335,
364, 376, 414, 454, 515, 565, 592,
632, 666, 694, 741, 850, 885, 932,
956, 994, 1153, 1198
赢家诅咒 191, 208
有效群体大小 ... 123, 224, 317, 367, 507,
539, 845, 935, 1013, 1159
预测误差方差 26, 311, 394, 576, 624, 727,
779, 852, 880, 1119, 1201
育种者方程 359
育种值 3, 41, 83, 212, 219, 259,
277, 298, 335, 355, 373, 414, 455,
495, 560, 571, 613, 653, 694, 743,
747, 792, 831, 873, 917, 953, 993,
1033, 1074, 1111, 1165, 1192

Z

杂种优势 ... 203, 227, 263, 427, 539, 555,
631
正态分布 . 18, 88, 346, 360, 379, 495, 573,
657, 716, 1097, 1196
置换检验 110, 186, 208
致因变异 142, 179, 209, 738, 930
主成分分析 51, 956, 1080
准确度 20, 88, 232, 259, 374,
417, 473, 495, 565, 585, 618, 697,
743, 916, 953, 1010, 1033, 1073,
1125, 1187, 1202
综合育种目标 221, 413, 1122
最大似然 59, 167, 184, 346, 389, 653, 701,
809
最佳线性无偏预测 83, 578
最优贡献选择 ... 225, 316, 370, 456, 497,
1151
组内相关 687, 1068
作图函数 163

后记

本书的结构，借鉴了国际上数量遗传学研究生课程的经典体系：从数学与统计基础讲起，经过单位点与两位点的群体模型、连锁图谱、数量性状位点定位、遗传方差与亲属相似性、遗传参数估计，一直讲到选择、近交与杂交。这一体系的精髓，在于要求学习者把公式一个一个地推导出来，把资料一行一行地算出来。在选择指数与混合模型方面，亨德森与范弗莱克的教学传统则表明：经典理论与现代方法之间并没有鸿沟，基因组时代的大多数新问题，都可以在期望、协方差与遗传传递的语言中得到清楚的表述。

本书力求把这两方面的内容融为一体：既保留经典数量遗传学严谨的推演传统，又讨论基因组、序列、多组学与人工智能带来的新问题。写作过程中，我反复提醒自己三件事：一是推导要完整，不让读者在关键处“跳步”；二是数字要能复算，书中的每一个算例都应能由读者独立重现；三是结论要有边界，说明它在什么条件下成立，在什么条件下可能失效。这三条做得是否到位，有待读者检验。

数量遗传学是一门不断发展的学科。本书完成之时，全基因组序列正在成为常规资料，基因编辑与合成生物学正在改变“遗传变异”的含义，大规模表型组与环境组资料正在使基因与环境互作的研究从描述走向预测。可以预期，未来十年的数量遗传学将与今天大不相同。但我相信，本书所阐述的那些基本思想——群体的视角、方差的分解、亲属的协方差、选择的反应、信息的价值与不确定性——仍将是理解和驾驭这些新变化的基础。

感谢所有在学习、研究与写作中给予帮助的老师、同事与学生。感谢家人长期的理解与支持。

梅步俊

二〇二六年十月

数量遗传学研究连续变异性状的遗传规律，是动植物育种与复杂性状遗传研究的理论基础。本书以“从孟德尔群体到基因组育种”为主线，系统阐述群体遗传结构与连锁不平衡、遗传连锁图谱与数量性状位点定位、全基因组关联研究、遗传方差分解与亲属相似性、遗传参数估计、选择理论与选择指数、遗传漂变与近交、杂种优势与杂交育种、最佳线性无偏预测与混合模型、基因组遗传力与基因组预测，以及多组学、基因与环境互作和智能育种等前沿方向。

全书十篇三十七章，重要公式均给出完整推导，每章配有数值例题、习题与参考解答，计算程序与资料按章独立提供。可作为遗传育种、数量遗传学与统计基因组学专业研究生教材，亦可供相关领域科研人员参考。

