


QUANTITATIVE GENETICS

数量遗传学

习题集

——从孟德尔群体到基因组育种

Problems, Derivations and Solutions · From Mendelian Populations to Genomic Breeding



梅步俊 著

MEIBUJUN

数量遗传学习题集
—— 从孟德尔群体到基因组育种
Problems, Derivations and Solutions
梅步俊 著

书名 数量遗传学习题集——从孟德尔群体到基因组育种

英文书名 Problems, Derivations and Solutions in Quantitative Genetics: From Mendelian Populations to Genomic Breeding

著者 梅步俊

配套教材 《数量遗传学——从孟德尔群体到基因组育种》(梅步俊著)

结构 十篇 三十七章习题 四套模拟试卷 附录三种

配套资源 各章计算程序与资料按章独立组织, 与本书正文分离提供 (共 223 个程序)

完稿 二〇二六年十月

本书全部数值题均可由配套程序复算, 参考答案中引用的数字均来自程序的实际输出或经独立验算的手算结果。书中模拟资料为教学构造, 仅用于说明机制, 不代表任何真实群体的参数。引用研究结果时, 请以原始文献为准。

内容提要

本书是《数量遗传学——从孟德尔群体到基因组育种》的配套习题集，与原书十篇三十七章一一对应。每章由六个部分构成：本章导学与知识结构图、核心概念与公式速览、补充内容与公式推导、分层习题、参考答案与解析，以及配套的计算程序。每章 29 道习题，含单项选择、判断与改错、填空、计算、推导与证明、综合分析与研究设计六类题型，按难度分为三级，由概念辨析逐步过渡到推导证明与研究设计，所有题目均与原书章后习题不重复。

计算题分为两种：每章六道程序题要求读者读取数据、运行 Python 程序并解释结果，其余手算题用于训练推导与估算；答案中的数字均来自程序输出，并说明数值背后的机制与常见误区。每章设有补充推导，对原书未展开的公式给出完整的推导过程，并介绍近年来的研究进展与易错辨析。书末附四套模拟试卷及评分要点，并提供公式速查表、标准正态选择强度表与程序索引。

本书适合动物、植物遗传育种与数量遗传学、统计基因组学相关专业的高年级本科生和研究生使用，也可供从事遗传评定、育种计划设计与复杂性状遗传研究的科研人员作自学与教学参考。

序言

一本教材讲得再透彻，也代替不了读者亲手算过的那几道题。数量遗传学尤其如此：它的公式不多，但每个公式背后都有一串条件，“对谁取期望”“条件是什么”“单位是什么”“群体是否改变”，这些问题只有在自己动手算、算错、再改正的过程中才会真正留在脑子里。这是编写本习题集的出发点。

《数量遗传学——从孟德尔群体到基因组育种》以“机制层级”为线索，把全书分成十篇：从概率与矩阵的共同语言，到位点层次的群体遗传与图谱；从性状层次的方差分解与选择理论，到混合模型与基因组预测；再到前沿数据与可复算的决策流程。与之相配，本习题集的每一章都努力回答三个问题：这一章最容易被误解的概念是什么？这一章的方法在什么条件下会失效？读者能否独立复算书中的关键数字？

围绕这三个问题，本书在编写上做了如下安排。

其一，题目有层次，答案有深度。每章 29 道题由易到难，前十四道题检查概念与记忆，后面的计算、证明与综合题要求读者完成完整的推理或设计一个研究方案。参考答案不止给出结果，更要说明“为什么是这个结果”“常见的错误从何而来”“与其他章如何联系”。综合题的解答力求像一位有经验的研究者给出的方案：先界定问题，再写明假设、方法、检验与风险。

其二，程序题与正文分离。凡需要数值计算的题目，题干只给出情境与数据文件，计算由配套的 Python 程序完成，程序按章放在独立的文件夹里，附有数据、断言检验与图形。读者既可以直接运行程序核对答案，也可以修改参数观察结论如何变化。书中引用的每个程序输出都经过实际运行，所用随机数种子固定，因而可以复现。凡是程序不能直接给出的手算题，其数字也经过独立验算。

其三，补充推导与研究前沿。原书为了保持主线，对一部分公式只给出结论。本书在每章的“补充内容与公式推导”中补上这些推导，并就近年来的方法进展——例如基因组关系矩阵的标准化、单步评定中的尺度对齐、预测验证中的校准与迁移、深度学习模型的归因与泛化——给出评述，指出它们的适用条件。每章的“易错辨析”则收集了教学与科研中反复出现的误解。

其四，把失败写进习题。本书后半部分特别强调“诊断”：相关很高而校准很差，筛选泄漏使验证虚高，方差分量落在边界，家系内残差并不独立。这些情形在真实的育种资料里并不罕见，而一个只会在理想条件下计算的读者，很难发现它们。第十篇的四章因此以完整的算例形式，把数据字典、教学实验、配种决策与模型诊断串成一条从资料到决策的链条。

使用本书时，建议先读原书相应章节，再做本章的选择题和判断题检查概念，然后动手完成手算题与证明题，最后运行程序题并对照解析。做错的题目比做对的题目更有价值，请在答案旁边写下自己错在何处。教师可以按章布置习题，用第 29 章之后的模拟试卷作阶段测验；自学者则可以用知识结构图建立全书的整体印象，再逐章深入。

编写过程中，我力求每个数字都能复算，每个结论都写明条件，但疏漏在所难免。书中的模拟资料全部是教学构造，不代表任何真实群体的参数，任何实际应用都应当回到原始资料与文献。恳请读者批评指正。

梅步俊

二〇二六年十月

使用说明与符号约定

一、**题型与难度**。每道题前的星标表示难度：一星为基础，直接应用定义与公式；二星为中等，需要多步推理或简单推导；三星为较难，需要完整证明、综合运用多章知识或设计研究方案。题号 N.k 表示第 N 章第 k 题。题末的“[答案]”与答案处的“[题目]”均为超链接，在电子版中可以点击互相跳转。

二、**题号分配**。每章固定为：单项选择 N.1—N.6；判断与改错 N.7—N.10；填空 N.11—N.14；计算 N.15—N.22（其中每章六道配有程序，通常为 N.15—N.20，其余为手算题；以题干末尾的程序路径为准）；推导与证明 N.23—N.26；综合分析与研究设计 N.27—N.29。

三、**程序题的使用**。程序题的题干末尾给出程序路径，形如“ch05/ex05_16_xxx.py”，对应配套代码包中的同名文件。程序只依赖 numpy、scipy 与 matplotlib，在普通计算机上每个程序运行时间不超过一分钟，随机数种子固定。每个程序读取同章 data 目录中的资料，输出中文报告，并把结果写入 results 目录。建议读者先自己思考，再运行程序，再阅读解析。

四、符号约定。与原书一致：

符号	含义	符号	含义
y	表型向量	u	随机遗传效应（育种值）
A	系谱加性关系矩阵	G	基因组关系矩阵
σ_A^2	加性遗传方差	σ_e^2	残差方差
h^2	狭义遗传力	PEV	预测误差方差
F	近交系数	N_e	有效群体大小
i	选择强度	L	世代间隔

粗体小写表示列向量，粗体大写表示矩阵，上角 ' 或 T 表示转置，Var、Cov 与 E 分别表示方差、协方差与期望。凡题目中未特别说明，正态分布、随机交配与加性模型为默认设定。

五、**数值与舍入**。答案中的数值保留有效位数与程序输出一致；手算题以四位有效数字为准，读者的结果在末位有出入属正常舍入。

目录

内容提要	iii
序言	iv
使用说明与符号约定	vi
第一篇 数学、统计与遗传学基础	1
第 1 章 概率、期望与遗传预测问题	2
1.1 本章导学	2
1.2 知识结构图	3
1.3 核心概念与公式速览	3
1.4 补充内容与公式推导	4
1.5 习题	5
1.6 参考答案与解析	10
第 2 章 矩阵方法与稳定计算	17
2.1 本章导学	17
2.2 知识结构图	18
2.3 核心概念与公式速览	18
2.4 补充内容与公式推导	19
2.5 习题	20
2.6 参考答案与解析	25
第 3 章 统计推断、似然与数量遗传学方法	32
3.1 本章导学	32
3.2 知识结构图	33
3.3 核心概念与公式速览	33
3.4 补充内容与公式推导	34
3.5 习题	35
3.6 参考答案与解析	39
第二篇 群体遗传结构与遗传图谱	45
第 4 章 单基因座群体模型与等位基因频率的演变	46
4.1 本章导学	46
4.2 知识结构图	47

4.3	核心概念与公式速览	47
4.4	补充内容与公式推导	48
4.5	习题	49
4.6	参考答案与解析	53
第 5 章	多基因座单倍型、连锁不平衡与重组	60
5.1	本章导学.	60
5.2	知识结构图	61
5.3	核心概念与公式速览	61
5.4	补充内容与公式推导	62
5.5	习题	63
5.6	参考答案与解析	67
第 6 章	遗传连锁与连锁图谱的构建	73
6.1	本章导学.	73
6.2	知识结构图	74
6.3	核心概念与公式速览	74
6.4	补充内容与公式推导	75
6.5	习题	76
6.6	参考答案与解析	80
第三篇	数量性状基因定位	86
第 7 章	杂交群体的数量性状位点定位	87
7.1	本章导学.	87
7.2	知识结构图	88
7.3	核心概念与公式速览	88
7.4	补充内容与公式推导	89
7.5	习题	90
7.6	参考答案与解析	94
第 8 章	远交群体的连锁分析、关联定位与全基因组关联研究	100
8.1	本章导学.	100
8.2	知识结构图	101
8.3	核心概念与公式速览	101
8.4	补充内容与公式推导	102
8.5	习题	103
8.6	参考答案与解析	107

第四篇 数量性状的遗传模型与参数估计**113**

第 9 章 数量遗传与群体依赖性	114
9.1 本章导学	114
9.2 知识结构图	115
9.3 核心概念与公式速览	115
9.4 补充内容与公式推导	116
9.5 习题	117
9.6 参考答案与解析	121
第 10 章 遗传方差组分、重复力与性状间相关	126
10.1 本章导学	126
10.2 知识结构图	127
10.3 核心概念与公式速览	127
10.4 补充内容与公式推导	128
10.5 习题	129
10.6 参考答案与解析	133
第 11 章 亲属间的相似性与遗传协方差	138
11.1 本章导学	138
11.2 知识结构图	139
11.3 核心概念与公式速览	139
11.4 补充内容与公式推导	140
11.5 习题	141
11.6 参考答案与解析	145
第 12 章 系谱亲缘、近交与遗传连接	150
12.1 本章导学	150
12.2 知识结构图	151
12.3 核心概念与公式速览	151
12.4 补充内容与公式推导	152
12.5 习题	153
12.6 参考答案与解析	157
第 13 章 遗传参数的经典估计方法与试验设计	162
13.1 本章导学	162
13.2 知识结构图	163
13.3 核心概念与公式速览	163
13.4 补充内容与公式推导	164
13.5 习题	166
13.6 参考答案与解析	169

第五篇 选择理论与选择指数

175

第 14 章 选择反应的数量遗传理论	176
14.1 本章导学	176
14.2 知识结构图	177
14.3 核心概念与公式速览	177
14.4 补充内容与公式推导	178
14.5 习题	179
14.6 参考答案与解析	183
第 15 章 单性状选择指数与信息融合	189
15.1 本章导学	189
15.2 知识结构图	190
15.3 核心概念与公式速览	190
15.4 补充内容与公式推导	191
15.5 习题	192
15.6 参考答案与解析	196
第 16 章 多性状育种目标与经济权重	202
16.1 本章导学	202
16.2 知识结构图	203
16.3 核心概念与公式速览	203
16.4 补充内容与公式推导	204
16.5 习题	206
16.6 参考答案与解析	211
第 17 章 限制指数、非线性目标与稳健决策	219
17.1 本章导学	219
17.2 知识结构图	220
17.3 核心概念与公式速览	220
17.4 补充内容与公式推导	221
17.5 习题	223
17.6 参考答案与解析	226
第 18 章 选择反应、世代间隔与长期遗传进展	232
18.1 本章导学	232
18.2 知识结构图	233
18.3 核心概念与公式速览	233
18.4 补充内容与公式推导	234
18.5 习题	236
18.6 参考答案与解析	239

第六篇 遗传漂变、近交与杂交 245

第 19 章 遗传漂变、有效群体大小与近交 246

19.1 本章导学	246
19.2 知识结构图	247
19.3 核心概念与公式速览	247
19.4 补充内容与公式推导	248
19.5 习题	249
19.6 参考答案与解析	253

第 20 章 杂种优势、配合力与杂交育种体系 259

20.1 本章导学	259
20.2 知识结构图	260
20.3 核心概念与公式速览	260
20.4 补充内容与公式推导	261
20.5 习题	263
20.6 参考答案与解析	267

第七篇 混合模型与遗传评定 276

第 21 章 从最小二乘到最佳线性无偏预测 277

21.1 本章导学	277
21.2 知识结构图	278
21.3 核心概念与公式速览	278
21.4 补充内容与公式推导	279
21.5 习题	281
21.6 参考答案与解析	285

第 22 章 动物模型与复杂遗传效应 293

22.1 本章导学	293
22.2 知识结构图	294
22.3 核心概念与公式速览	294
22.4 补充内容与公式推导	295
22.5 习题	297
22.6 参考答案与解析	301

第 23 章 方差组分、限制似然与贝叶斯推断 309

23.1 本章导学	309
23.2 知识结构图	310
23.3 核心概念与公式速览	310

23.4	补充内容与公式推导	311
23.5	习题	313
23.6	参考答案与解析	316
第 24 章 多性状、阈值、生存与纵向遗传模型		324
24.1	本章导学.	324
24.2	知识结构图	325
24.3	核心概念与公式速览	325
24.4	补充内容与公式推导	326
24.5	习题	329
24.6	参考答案与解析	332
第八篇 基因组遗传学与基因组预测		338
第 25 章 基因组时代的遗传力.		339
25.1	本章导学.	339
25.2	知识结构图	340
25.3	核心概念与公式速览	340
25.4	补充内容与公式推导	341
25.5	习题	343
25.6	参考答案与解析	347
第 26 章 基因型质量控制与基因组关系矩阵		353
26.1	本章导学.	353
26.2	知识结构图	354
26.3	核心概念与公式速览	354
26.4	补充内容与公式推导	355
26.5	习题	358
26.6	参考答案与解析	361
第 27 章 GBLUP、岭回归、贝叶斯与核方法		368
27.1	本章导学.	368
27.2	知识结构图	369
27.3	核心概念与公式速览	369
27.4	补充内容与公式推导	370
27.5	习题	373
27.6	参考答案与解析	376
第 28 章 单步基因组评定.		382
28.1	本章导学.	382
28.2	知识结构图	383

28.3	核心概念与公式速览	383
28.4	补充内容与公式推导	384
28.5	习题	388
28.6	参考答案与解析	391
第 29 章 验证设计、准确性、校准与跨群体迁移		397
29.1	本章导学	397
29.2	知识结构图	398
29.3	核心概念与公式速览	398
29.4	补充内容与公式推导	399
29.5	习题	402
29.6	参考答案与解析	406
第九篇 前沿数据与智能育种		412
第 30 章 全基因组序列、泛基因组、结构变异与稀有变异		413
30.1	本章导学	413
30.2	知识结构图	414
30.3	核心概念与公式速览	414
30.4	补充内容与公式推导	415
30.5	习题	419
30.6	参考答案与解析	422
第 31 章 多组学、功能先验与因果推断		427
31.1	本章导学	427
31.2	知识结构图	428
31.3	核心概念与公式速览	428
31.4	补充内容与公式推导	429
31.5	习题	433
31.6	参考答案与解析	436
第 32 章 基因型 × 环境、韧性与可持续育种		441
32.1	本章导学	441
32.2	知识结构图	442
32.3	核心概念与公式速览	442
32.4	补充内容与公式推导	443
32.5	习题	447
32.6	参考答案与解析	450
第 33 章 深度学习与基因组基础模型		455
33.1	本章导学	455

33.2	知识结构图	456
33.3	核心概念与公式速览	456
33.4	补充内容与公式推导	457
33.5	习题	461
33.6	参考答案与解析	465
第十篇 计算实践与研究设计		470
第 34 章 数据字典到可重复评定		471
34.1	本章导学.	471
34.2	知识结构图	472
34.3	核心概念与公式速览	472
34.4	补充内容与公式推导	473
34.5	习题	476
34.6	参考答案与解析	480
第 35 章 从系谱 BLUP 到 GBLUP：一个可复算的肉羊教学实验		485
35.1	本章导学.	485
35.2	知识结构图	486
35.3	核心概念与公式速览	486
35.4	补充内容与公式推导	487
35.5	习题	491
35.6	参考答案与解析	494
第 36 章 多性状目标与约束配种的完整决策算例		498
36.1	本章导学.	498
36.2	知识结构图	499
36.3	核心概念与公式速览	499
36.4	补充内容与公式推导	500
36.5	习题	504
36.6	参考答案与解析	507
第 37 章 模型诊断、失败分析与可检验的研究设计		511
37.1	本章导学.	511
37.2	知识结构图	512
37.3	核心概念与公式速览	512
37.4	补充内容与公式推导	513
37.5	习题	516
37.6	参考答案与解析	519

综合训练 模拟试卷	524
模拟试卷 A：基础与群体遗传篇（第 1—13 章）	525
试题	525
参考答案与评分要点	527
模拟试卷 B：选择、近交杂交与遗传评定（第 14—24 章）	529
试题	529
参考答案与评分要点	531
模拟试卷 C：基因组预测与前沿方法（第 25—37 章）	533
试题	533
参考答案与评分要点	535
模拟试卷 D：研究生综合考试（全书）	537
试题	537
参考答案与评分要点	538
附录 A：常用公式速查	540
附录 B：标准正态选择强度表	542
附录 C：配套程序索引	543
附录 D：学习路线与使用建议	546
附录 E：常见误解索引	547
附录 F：各章知识结构一览	549
参考文献	553
后记	556

第一篇

数学、统计与遗传学基础

概率、矩阵与统计推断是数量遗传学的共同语言。

本篇习题训练：预测对象的界定、条件期望与投影、矩阵的稳定计算、似然与检验。

概率、期望与遗传预测问题

1.1 本章导学

学习目标

1. 能够从育种决策出发辨认真正的预测对象，区分加性育种值、传递能力、未来表型与综合目标，并写明单位、群体基准与信息截止时间。
2. 熟练运用条件概率、贝叶斯公式、全期望公式与全方差公式，能对离散遗传状态作手算后验更新。
3. 掌握条件期望在平方损失下的最优性与最佳线性预测的指数方程 $b = P^{-1}c$ ，理解正交性与投影几何。
4. 能够计算预测误差方差、准确度、可靠度与预测区间，并区分它们与校准斜率、预测能力的关系。
5. 理解选择、缺失与测量误差如何改变“被观察到的数据”，能判断哪些统计量受影响、哪些不受影响。
6. 能把损失函数与信息成本纳入决策，计算一次新增测定的信息价值。

重点与难点

重点：预测对象的定义；全方差公式；条件期望与最佳线性预测；PEV、准确度与可靠度；重复记录的信息上限。

难点：“平均意义上信息增加”与“每只动物条件风险下降”的区别；选择只依赖已观察变量时回归不变而相关改变；校准、相关与均方误差三者的分解关系；信息价值为何依赖决策阈值而不只依赖可靠度。

本章是全书的语言基础。第 15 章的选择指数、第 21 章的 BLUP、第 29 章的验证设计都以本章的条件期望与投影为出发点；第 14 章的截断选择理论则在本章“选择与缺失”的讨论中首次出现。学习时应养成一个习惯：每写下一个期望或方差，都追问“对谁取期望、条件是什么、单位是什么”。

1.2 知识结构图




图 1.1 第 1 章知识结构图

图中右侧三支是“语言”——预测对象、概率与期望；左侧三支是“工具与评价”——正态模型、校准与决策。阅读习题时，可先在图上定位题目所考查的分支，再回到相应推导。

1.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
贝叶斯公式	$P(A_k B) = \frac{P(B A_k)P(A_k)}{\sum_j P(B A_j)P(A_j)}$	$\{A_j\}$ 为完备互斥事件组
全期望公式	$E(U) = E[E(U Y)]$	U 可积
全方差公式	$\text{Var}(U) = E[\text{Var}(U Y)] + \text{Var}[E(U Y)]$	U 平方可积；混合分布方差的来源
条件期望最优性	$E[(U - g)^2] = E[(U - m)^2] + E[(m - g)^2],$ $m = E(U Y)$	平方损失；不需要正态
最佳线性预测	$\hat{u} = \mu_u + c^T P^{-1}(y - \mu_y)$	只需一、二阶矩；联合正态时等于条件期望
预测误差方差	$\text{PEV} = \sigma_u^2 - c^T P^{-1}c$	均值已知；均值估计时需另加项

概念	公式或定义	成立条件与提示
可靠度与准确度	$R = 1 - \text{PEV}/\sigma_u^2$, $r = \sqrt{R} = \text{corr}(u, \hat{u})$	对最佳线性预测成立
校准斜率	$b_{u \hat{u}} = \text{Cov}(u, \hat{u}) / \text{Var}(\hat{u})$	最佳线性预测下等于 1
重复记录可靠度	$R_n = \frac{h^2}{t + (1-t)/n} \rightarrow \frac{h^2}{t}$	无亲属信息、永久环境不可消除
截断选择	$i = \varphi(x)/p$, $k = i(i-x)$, $\text{Var}(X S) = 1 - k$	标准正态、上侧截断
正态信息价值	$E[(X-T)^+] =$ $(m-T)\Phi\left(\frac{m-T}{\sigma}\right) + \sigma\varphi\left(\frac{m-T}{\sigma}\right)$	$X \sim N(m, \sigma^2)$

1.4 补充内容与公式推导

推导 1.1 全期望、全方差与全协方差公式

设 U, V 平方可积, Y 为任一条件变量。由全期望公式 $E(UV) = E[E(UV|Y)]$, 而

$$E(UV|Y) = \text{Cov}(U, V|Y) + E(U|Y)E(V|Y).$$

两边取期望, 再减去 $E(U)E(V) = E[E(U|Y)]E[E(V|Y)]$, 得**全协方差公式**

$$\text{Cov}(U, V) = E[\text{Cov}(U, V|Y)] + \text{Cov}[E(U|Y), E(V|Y)].$$

令 $V = U$ 即得全方差公式。它的三个直接推论贯穿全书:(1) $E[\text{Var}(U|Y)] \leq \text{Var}(U)$, 即**平均而言**条件化不增加不确定性;(2) 混合群体的总方差等于平均组内方差加组均值方差, 第 4 章 Wahlund 效应、第 8 章群体分层都是它的特例;(3) 若两条记录只通过共同的组效应 h 相关(给定 h 后条件独立), 则 $\text{Cov}(y_i, y_j) = \text{Var}(h)$, 这正是第 13 章“组内协方差等于组间方差组分”的来源。

推导 1.2 新增信息的分块更新 (舍尔补形式)

已有信息 y 给出 $\hat{u}_1 = c_1^T P_1^{-1} y$ 。新增记录 z , 与 y 的协方差为 p , 与目标的协方差为 d 。把 z 投影到 y 上, 得**创新量** $\tilde{z} = z - p^T P_1^{-1} y$, 它与 y 正交, 且

$$\text{Var}(\tilde{z}) = \text{Var}(z) - p^T P_1^{-1} p, \quad \text{Cov}(u, \tilde{z}) = d - p^T P_1^{-1} c_1.$$

由于 $\tilde{z}$ 与旧信息正交, 最佳线性预测可分两步完成:

$$\hat{u}_2 = \hat{u}_1 + \frac{\text{Cov}(u, \tilde{z})}{\text{Var}(\tilde{z})} \tilde{z}, \quad \text{PEV}_2 = \text{PEV}_1 - \frac{\text{Cov}(u, \tilde{z})^2}{\text{Var}(\tilde{z})}.$$

分母 $\text{Var}(\tilde{z})$ 正是联合协方差矩阵中旧信息块的舍尔补。结论：新增记录的价值取决于它扣除旧信息后与目标的剩余协方差，而非它与目标的原始相关。若剩余协方差为零，新增记录对预测毫无贡献，即使它与目标高度相关。

推导 1.3 正态变量正部的期望与信息价值

设 $X \sim N(m, \sigma^2)$ ，记 $z = (T - m)/\sigma$ 。则

$$\begin{aligned} E[(X - T)^+] &= \int_T^\infty (x - T) \frac{1}{\sigma} \varphi\left(\frac{x - m}{\sigma}\right) dx \\ &= \sigma \int_z^\infty (w - z) \varphi(w) dw = \sigma[\varphi(z) - z(1 - \Phi(z))], \end{aligned}$$

其中利用了 $\int_z^\infty w \varphi(w) dw = \varphi(z)$ 。在留种决策中，保留收益为 $u - T$ 、淘汰收益为零。不测定时按先验均值 m 决策，收益为 $(m - T)^+$ ；测定后按条件均值 m^* 决策，而 m^* 在测定前的分布为 $N(m, \sigma_*^2)$ ， $\sigma_*^2 = s^2 - \text{PEV}_\text{后}$ 。因此

$$\text{VOI} = E[(m^* - T)^+] - (m - T)^+.$$

信息价值同时取决于“测定能改变多少条件均值” (σ_*) 与“当前均值离决策阈值多远” ($|z|$)。远离阈值的候选者，即使测定很准确，信息价值也接近零。

易错辨析

- 准确度不是可靠度： $r = 0.8$ 对应 $R = 0.64$ ；“可靠度 0.64”也不表示“育种值的 64% 已知”。
- 相关不等于校准：把预测乘以常数不改变相关，却使校准斜率偏离 1。
- 零相关不等于独立：零相关只排除线性关系。
- 平均风险下降不等于逐点风险下降： $E[\text{Var}(U | Y)] \leq \text{Var}(U)$ 只对平均成立。
- 选择只改变被观察的分布：选择仅依赖已观察的 X 时， Y 对 X 的回归不变，而 Y 的均值、方差及 X, Y 的相关都会改变。

1.5 习题

一、单项选择题

1.1 ★ [单选] 某场用公羊自身断奶重预测其作为种公羊的价值。下列哪一个量才是“留种决策”真正的预测对象？

- (A) 该公羊已经称得的断奶重
(B) 该公羊在指定基础群体下的加性育种值
(C) 该公羊所在批次的平均断奶重 (D) 该公羊断奶重的测量误差

[答案]

1.2 ★ [单选] 设 $\text{Var}(X) = 4$, $\text{Var}(Y) = 9$, $\text{corr}(X, Y) = -0.5$, 则 $\text{Var}(X + Y)$ 等于

- (A) 13 (B) 10 (C) 7 (D) 19

[答案]

1.3 ★ [单选] 关于全方差公式 $\text{Var}(U) = E[\text{Var}(U | Y)] + \text{Var}[E(U | Y)]$, 下列说法正确的是

- (A) 只在 U, Y 联合正态时成立
(B) 对每一个 y 都有 $\text{Var}(U | Y = y) \leq \text{Var}(U)$
(C) 第二项表示 Y 能解释的那部分变异 (D) 两项之和可能小于 $\text{Var}(U)$

[答案]

1.4 ★★ [单选] 对均值已知的最佳线性预测 $\hat{u}$, 下列等式中不一定成立的是

- (A) $\text{Cov}(u, \hat{u}) = \text{Var}(\hat{u})$ (B) $\text{PEV} = \text{Var}(u) - \text{Var}(\hat{u})$
(C) $\text{corr}(u, \hat{u})^2 = \text{Var}(\hat{u}) / \text{Var}(u)$ (D) $E(u | \hat{u}) = \hat{u}$

[答案]

1.5 ★★ [单选] 某模型的预测分数与真实育种值的相关为 0.6, 真实育种值对预测分数的回归斜率为 0.5。下列判断正确的是

- (A) 预测差异被夸大, 应把分数乘以 0.5 左右再用于估计遗传差异
(B) 预测差异被压缩, 应把分数放大 (C) 斜率与相关矛盾, 必有计算错误
(D) 斜率小于 1 说明准确度不足 0.5

[答案]

1.6 ★★ [单选] 一批母羊只有第一胎产羔数高于中位数的个体才保留二胎记录。若用保留个体估计“二胎对第一胎的回归系数”, 在二元正态假设下

- (A) 回归系数无偏, 但两胎记录相关被低估
(B) 回归系数与相关都无偏 (C) 回归系数被低估, 相关无偏
(D) 回归系数与相关都被高估

[答案]

二、判断与改错题

- 1.7 ★ [判断] 若 $\text{Cov}(X, Y) = 0$, 则 $E(Y | X) = E(Y)$ 。 [答案]
- 1.8 ★★ [判断] 在联合正态模型中, 增加一条记录后每一只动物的预测误差方差都不会增加; 在一般(非正态)模型中, 这一结论对每一个观测值也都成立。 [答案]
- 1.9 ★ [判断] 某公羊育种值的可靠度为 0.64, 说明其育种值有 64% 已经被准确测出, 剩余 36% 尚未知。 [答案]
- 1.10 ★★ [判断] 在已知均值和协方差的条件下, 若目标与全部记录联合正态, 则最佳线性预测等于条件期望, 因此在平方损失下它在所有(含非线性)预测中最优。 [答案]

三、填空题

- 1.11 ★ [填空] 三个羊场的观察暴露量分别为 120、80、200 羊年, 乳房炎事件数分别为 6、2、12。在“各场共同的泊松发生率”假设下, 发生率的最大似然估计为_____次/羊年, 其标准误约为_____。 [答案]
- 1.12 ★ [填空] 两个场分别占群体的 40% 与 60%, 场内体重方差为 25 与 16 kg^2 , 场均值为 50 与 55 kg。全群体的平均体重为_____ kg, 总方差为_____ kg^2 , 其中场间方差占_____。 [答案]
- 1.13 ★★ [填空] 某位点群体基因型频率 $AA:Aa:aa = 0.64:0.32:0.04$ 。一种分型方法把真杂合子判为“Aa”的概率为 0.98, 把 AA 或 aa 误判为“Aa”的概率均为 0.01。某羊被判为“Aa”, 其真为杂合子的后验概率为_____。 [答案]
- 1.14 ★ [填空] 设 $\text{Var}(X) = 4, \text{Var}(Y) = 9, \text{corr}(X, Y) = -0.5$, 则 $\text{corr}(X, X+Y) =$ _____ (保留三位小数)。 [答案]

四、计算题

- 1.15 ★★ [计算] 隐性缺陷的后裔测验。一只候选公羊依系谱为隐性缺陷携带者的先验概率为 0.10。(1) 若与已知携带者母羊(Aa)交配, 观察到 n 只后代全部正常, 写出公羊为携带者的后验概率, 并求后验概率降至 0.01 以下所需的最少后代数; (2) 若改与公羊自己的女儿交配, 或与缺陷等位基因频率为 0.05 的群体随机母羊交配,

所需后代数分别为多少？(3) 若患病后代只有 95% 能被正确诊断，结论如何变化？

[程序] ch01/ex01_15_progeny_test.py

[答案]

1.16 ★★ [计算] 三种信息来源的最佳线性预测。某性状 $\sigma_p^2 = 100$, $h^2 = 0.30$, 无共同环境。候选羔羊有自身记录离差 +12、母亲记录离差 +4, 以及 20 只父系半同胞（不含自身, 各有不同且无亲缘的母亲）平均记录离差 +3。(1) 写出 P 与 c ; (2) 求最优权重、预测育种值、可靠度与 PEV; (3) 分别计算只用单一来源及两两组合时的可靠度, 说明为什么“母亲 + 半同胞”组合的权重恰好等于两者单独使用时的权重。 [程序] ch01/ex01_16_three_sources.py

[答案]

1.17 ★ [计算] 某性状 $h^2 = 0.25$, 重复力 $t = 0.45$ 。仅用个体自身 n 次记录平均值预测育种值。(1) 求 $n = 1, 2, 5$ 时的可靠度及 $n \rightarrow \infty$ 的极限; (2) 至少需要多少次记录才能达到极限可靠度的 95%?

[答案]

1.18 ★★ [计算] 后代均值的预测区间。某公羊 $\widehat{EBV} = 6$ kg, $PEV = 12$ kg², $\sigma_A^2 = 40$, $\sigma_E^2 = 60$ 。它将与随机、无亲缘母羊交配。(1) 推导 n 只未来后代平均表型（相对群体均值）的预测值与预测误差方差; (2) 求 $n = 1, 10, 100$ 时的 95% 预测区间; (3) 解释为什么后代再多, 区间宽度也有下限。 [程序] ch01/ex01_18_progeny_interval.py

[答案]

1.19 ★★ [计算] 遗传力设定错误的后果。真实遗传力 $h^2 = 0.30$, $\sigma_A^2 = 1$, 评定者却用 $\tilde{h}^2$ 计算单记录预测 $\hat{u} = \tilde{h}^2 y$ 。(1) 证明相关与 $\tilde{h}^2$ 无关, 并求校准斜率与 MSE 关于 $\tilde{h}^2$ 的表达式; (2) 对 $\tilde{h}^2 = 0.1, 0.2, 0.3, 0.5, 0.7$ 列表; (3) 为什么 $\tilde{h}^2 = 0.1$ 与 $\tilde{h}^2 = 0.5$ 的 MSE 相同而斜率截然不同? [程序] ch01/ex01_19_calibration.py

[答案]

1.20 ★★ [计算] 选择性保留第二次记录。两次标准化记录相关（重复力）为 0.40。只有第一次记录位于上侧 30% 的个体才有第二次记录。(1) 求截断点、选择强度及 $k = i(i-x)$; (2) 求被选个体中两次记录的均值、方差、协方差、回归系数与相关; (3) 若用被选样本的相关估计重复力, 相对低估多少? [程序] ch01/ex01_20_selected_records.py

[答案]

1.21 ★ [计算] 真实体尺 X 的方差为 16, 单次测量误差方差为 4, 且误差独立。性状 $Y = 2X + \varepsilon$ 。(1) 求 Y 对单次测量值 W 的回归斜率; (2) 若取两次独立测量的平均值, 斜率变为多少? (3) 如何仅凭重复测量数据估计衰减系数并校正斜率? [答案]

- 1.22 ★★★ [计算]** 留种决策中的信息价值。某公羊育种值当前为 $N(1.0, 4.0)$ ，留种阈值 $T = 2.0$ （保留收益为 $u - T$ ，每单位折合 100 元，淘汰收益为 0）。一次测定可使 PEV 降为 1.0，成本 25 元。（1）求测定的信息价值并判断是否值得测定；（2）测定后 PEV 至少要降到多少才不亏本？（3）若同一测定用于先验均值为 -3 的公羊，信息价值大约多少？说明原因。 [程序] `ch01/ex01_22_value_of_information.py` [答案]

五、推导与证明题

- 1.23 ★★ [证明]** 用全协方差公式证明：若同一畜舍两只无亲缘动物的记录满足 $y_i = \mu + h + e_i$ ， h 为畜舍效应， e_i 在给定 h 时相互独立且与 h 无关，则 $\text{Cov}(y_i, y_j) = \text{Var}(h)$ 。若两只动物还是全同胞，结论应如何修改？ [答案]
- 1.24 ★★ [证明]** 设 $\hat{u} = c^T P^{-1} y$ （均值为零）。证明：（1） $\text{Cov}(u - \hat{u}, y) = 0$ ；（2） $\text{Var}(\hat{u}) = \text{Cov}(u, \hat{u})$ ，从而校准斜率为 1；（3） $R = \text{Var}(\hat{u}) / \sigma_u^2 = \text{corr}(u, \hat{u})^2$ 。 [答案]
- 1.25 ★★★ [证明]**（Pearson–Aitken 选择定理的一元形式）设 (X, Y) 二元正态，选择事件 S 只依赖 X 。证明： $E(Y | X, S) = E(Y | X)$ ，并由此推出

$$\text{Var}(Y | S) = \sigma_Y^2(1 - \rho^2) + \rho^2 \frac{\sigma_Y^2}{\sigma_X^2} \text{Var}(X | S).$$

说明该结论为什么是第 14 章 Bulmer 效应推导的基础。 [答案]

- 1.26 ★★★ [证明]** 两只候选公羊育种值的联合后验为二元正态，均值 m_1, m_2 ，差值方差 $v_d > 0$ 。（1）证明“ $m_1 > m_2$ ”与“ $P(u_1 > u_2 | \text{数据}) > 0.5$ ”等价；（2）若目标改为“育种值超过阈值 T 的概率最大”，构造一个例子说明排序可能与后验均值排序相反（可取 $m_1 = 1, v_1 = 4$ ； $m_2 = 1.5, v_2 = 0.25$ ； $T = 3$ ）。 [答案]

六、综合分析与研究设计题

- 1.27 ★★ [综合]** 某公司宣称“我们的基因组预测准确度为 0.8”。请列出为使这一说法可被审查而必须补充的至少六项信息，并说明其中哪三项最可能改变结论的含义。 [答案]
- 1.28 ★★★ [综合]** 某模型在 A 场训练时 $E(u | y) = 0.4y$ ，部署到 B 场后真实关系变为 $E(u | y) = 0.2y + 1$ ，B 场 y 的均值为 0、方差为 5，两场的条件方差均为 2。（1）计算旧规则在 B 场的均方误差，并分解为偏差、斜率失配与不可约误差；（2）设计一个能在部署后及早发现这种失配的监测方案。 [答案]

- 1.29 ★★★ [综合] 某种羊场每年有 400 只公羔，留种 20 只。场长考虑对全部公羔做基因组检测（每只 120 元），检测可将候选者可靠度由 0.25 提高到 0.55。请依据本章信息价值与选择决策的思想，列出评估方案所需的数据与计算步骤，并说明为什么不能只比较“可靠度提高了 0.30”与“检测成本”。 [答案]

1.6 参考答案与解析

一、单项选择题

- 1.1 B。留种决策关心的是公羊作为亲本能传给后代的平均遗传贡献，即在指定基础群体下的加性育种值；它是一个尚未被完全获知的随机量。已称得的断奶重（A）是信息而非目标；批次均值（C）属于环境比较基准；测量误差（D）是需要被平均掉的噪声。若目标是后代平均表现，还应乘以传递系数 $1/2$ 并指明配偶群体。 [题目]
- 1.2 C。 $\text{Var}(X + Y) = 4 + 9 + 2 \times (-0.5) \times 2 \times 3 = 7$ 。负相关使和的方差小于方差之和。 [题目]
- 1.3 C。全方差公式只需平方可积（A 错）；它只保证平均条件方差不超过总方差，某些 y 下条件方差可以更大（B 错）；两项之和恒等于总方差（D 错）。第二项 $\text{Var}[E(U | Y)]$ 正是条件均值随 Y 变化的方差，即 Y 所解释的变异。 [题目]
- 1.4 D。A、B、C 对任何均值已知的最佳线性预测都成立（见习题 1.24）。D 要求条件期望是线性的，只在联合正态等特殊情形下才成立；一般分布下最佳线性预测只保证线性校准斜率为 1，不保证条件均值逐点等于 $\hat{u}$ 。 [题目]
- 1.5 A。回归斜率 $b_{u|\hat{u}} = 0.5 < 1$ 表示预测分数每相差 1 个单位，真实育种值平均只相差 0.5 个单位，即预测离散度被夸大。斜率与相关可以独立变化：相关描述排序，斜率描述尺度，两者并不矛盾。准确度仍为 0.6。 [题目]
- 1.6 A。选择只依赖已观察的第一胎记录，属于随机缺失（MAR）。在二元正态下 $E(Y | X, S) = E(Y | X)$ ，故回归系数无偏；但被选样本中 X 的方差缩小，相关系数被压低（见习题 1.20）。 [题目]

二、判断与改错题

- 1.7 错误。零协方差只排除线性关系。反例： X 等概率取 $-1, 0, 1$, $Y = X^2$ ，则 $\text{Cov}(X, Y) = 0$ ，但 $E(Y | X = 0) = 0 \neq E(Y) = 2/3$ 。正确表述：若 $E(Y | X) = E(Y)$ ，则

$\text{Cov}(X, Y) = 0$; 反之不成立。

[题目]

1.8 前半句正确, 后半句错误。联合正态时条件方差与观测值无关, 等于 $\sigma_u^2 - c^T P^{-1} c$, 增加信息只会使其不增。一般模型中只有平均意义上 $E[\text{Var}(U | Y, Z)] \leq E[\text{Var}(U | Y)]$; 对于某些观测结果, 条件方差可以增大。例如先验以 0.9 概率为非携带者, 一次“阳性”结果可能使两类可能性变得接近, 后验方差反而上升。

[题目]

1.9 错误。可靠度是真实育种值与预测值的相关平方, 或 $1 - \text{PEV}/\sigma_A^2$ 。它描述的是在指定群体中, 预测值能解释的育种值方差比例, 而不是某一只动物育种值“已知部分”的百分比。对该公羊, 正确的表述是: 给定现有信息, 其育种值的条件标准差为 $\sigma_A \sqrt{1 - 0.64} = 0.6\sigma_A$ 。

[题目]

1.10 正确。联合正态时条件期望恰为线性函数 $\mu_u + c^T P^{-1}(y - \mu_y)$; 而条件期望在平方损失下对任意可测函数最优, 所以最佳线性预测此时在所有预测中最优。若不正态, 非线性函数可能进一步降低风险 (如 $U = X^2$ 的例子)。

[题目]

三、填空题

1.11 $\hat{\lambda} = 20/400 = 0.05$; $\text{SE} = \sqrt{\hat{\lambda}/400} = \sqrt{0.000125} \approx 0.0112$ 。共同发生率下对数似然为 $\sum_k [x_k \log(\lambda t_k) - \lambda t_k]$, 求导得 $\hat{\lambda} = \sum x_k / \sum t_k$; 费希尔信息为 $\sum t_k / \lambda$ 。三场各自的率为 0.050、0.025、0.060, 差异是否显著应另作齐性检验。

[题目]

1.12 总均值 $0.4 \times 50 + 0.6 \times 55 = 53 \text{ kg}$; 平均场内方差 $0.4 \times 25 + 0.6 \times 16 = 19.6$, 场间方差 $0.4 \times 9 + 0.6 \times 4 = 6.0$; 总方差 25.6 kg^2 , 场间方差占 $6.0/25.6 \approx 23.4\%$ 。

[题目]

1.13 $P(\text{Aa} | \text{判 Aa}) = \frac{0.32 \times 0.98}{0.32 \times 0.98 + 0.64 \times 0.01 + 0.04 \times 0.01} = \frac{0.3136}{0.3204} \approx 0.9788$ 。误判率只有 1%, 但 AA 的频率是杂合子的两倍, 假阳性仍占约 2%。

[题目]

1.14 $\text{Cov}(X, X+Y) = 4 + (-0.5) \times 2 \times 3 = 1$, $\text{Var}(X+Y) = 7$, 故相关 $= 1/(2\sqrt{7}) \approx 0.189$ 。

[题目]

四、计算题

1.15 (1) 若公羊为携带者, 每只后代患病概率 $\theta = 1/4$; 否则为零。n 只全部正常时

$$P(C | n) = \frac{0.1 \times 0.75^n}{0.1 \times 0.75^n + 0.9}$$

令其 ≤ 0.01 , 需 $0.75^n \leq \frac{0.01 \times 0.9}{0.99 \times 0.1} = 0.0909$, 即 $n \geq \ln 0.0909 / \ln 0.75 = 8.34$, 最少 9 只。n = 5 时后验为 0.0257, n = 10 时为 0.0062。

(2) 与自己的女儿交配：女儿以 $1/2$ 概率为携带者，故 $\theta = 1/2 \times 1/2 \times 1/2 = 1/8$ ，需 **18** 只；与群体随机母羊交配： $\theta = \frac{1}{2} \times 0.05 = 0.025$ ，需 **95** 只。设计的效率取决于每只后代“暴露”隐性等位基因的概率。

(3) 诊断灵敏度 0.95 使有效暴露概率变为 $\theta^* = 0.95\theta$ ，三种设计所需后代数分别为 9、19、100。程序还用 40 万次模拟复核了 $n = 8$ 时的后验概率。实践中更重要的是：若存在假阴性，应把“全部正常”理解为“全部被诊断为正常”，并优先选择暴露概率高的配种设计。 [题目]

1.16 (1) $\sigma_A^2 = 30$, $t_{HS} = h^2/4 = 0.075$, 半同胞均值方差 = $100 \times [1 + 19 \times 0.075]/20 = 12.125$ 。

$$P = \begin{pmatrix} 100 & 15 & 7.5 \\ 15 & 100 & 0 \\ 7.5 & 0 & 12.125 \end{pmatrix}, \quad c = \begin{pmatrix} 30 \\ 15 \\ 7.5 \end{pmatrix}.$$

母亲与父系半同胞没有共同的遗传来源，故 $P_{23} = 0$ 。

(2) $b = P^{-1}c = (0.2482, 0.1128, 0.4650)^T$, $\widehat{EBV} = 0.2482 \times 12 + 0.1128 \times 4 + 0.4650 \times 3 = 4.825$; $R = 0.4208$, $r = 0.6487$, $PEV = 17.375$ 。

(3) 单一来源可靠度：自身 0.300、母亲 0.075、半同胞均值 0.155；两两组合：自身 + 母亲 0.338，自身 + 半同胞 0.380，母亲 + 半同胞 0.230。母亲与半同胞均值的协方差为零，两者在投影意义下正交，所以联合权重恰为各自单独权重 (0.15 与 0.6186)，可靠度可直接相加： $0.075 + 0.155 = 0.230$ 。自身记录与另两者相关，加入后各权重都要重新调整。程序用 4 万个模拟家系的经验回归复核了理论权重。

[题目]

1.17 $R_n = h^2/[t + (1 - t)/n]$ 。 $n = 1$: 0.250; $n = 2$: $0.25/0.725 = 0.345$; $n = 5$: $0.25/0.56 = 0.446$; 极限 $h^2/t = 0.556$ 。达到极限的 95% 需 $t + (1 - t)/n \leq t/0.95$, 即 $0.55/n \leq 0.02368$, $n \geq 23.2$, 取 **24** 次。重复记录只能平均掉暂时环境，永久环境方差 $t - h^2 = 0.20$ 不随次数减少，这就是信息上限的来源。 [题目]

1.18 (1) $\bar{y}_n = u_s/2 + \frac{1}{n} \sum (u_{d,j}/2 + \varphi_j + e_j)$ 。预测值为 $\widehat{EBV}/2 = 3$ kg; 预测误差由公羊育种值的不确定部分与后代独立部分组成：

$$V(n) = \frac{PEV}{4} + \frac{\frac{3}{4}\sigma_A^2 + \sigma_E^2}{n} = 3 + \frac{90}{n}.$$

(2) $n = 1$: $V = 93$, 区间 $3 \pm 1.96 \times 9.644 = (-15.90, 21.90)$; $n = 10$: $V = 12$, $(-3.79, 9.79)$; $n = 100$: $V = 3.9$, $(-0.87, 6.87)$ 。

(3) $n \rightarrow \infty$ 时 $V \rightarrow \text{PEV}/4 = 3$, 标准差 1.732。母羊、孟德尔抽样与环境的波动可以被大量后代平均掉, 但公羊自身育种值的不确定性对每只后代都是**共同的**, 无法平均。要缩小这一下限, 只能提高公羊本身的可靠度。模拟覆盖率均在 0.950 附近。

【题目】

1.19 (1) $\hat{u} = \tilde{h}^2 y$ 是 y 的正倍数, 相关恒为 $\text{corr}(u, y) = \sqrt{h^2} = 0.548$ 。

$$b_{u|\hat{u}} = \frac{\tilde{h}^2 \sigma_A^2}{\tilde{h}^4 \sigma_A^2 / h^2} = \frac{h^2}{\tilde{h}^2}, \quad \text{MSE} = \sigma_A^2 - 2\tilde{h}^2 \sigma_A^2 + \frac{\tilde{h}^4 \sigma_A^2}{h^2}.$$

(2)

$\tilde{h}^2$	0.10	0.20	0.30	0.50	0.70
校准斜率	3.000	1.500	1.000	0.600	0.429
MSE	0.833	0.733	0.700	0.833	1.233
离散度失配项	0.133	0.033	0	0.133	0.533

(3) MSE 可分解为 $\sigma_u^2(1 - \rho^2) + (\rho\sigma_u - \sigma_{\hat{u}})^2$, 第一项 0.70 不变; 第二项只依赖 $|\sigma_{\hat{u}} - \rho\sigma_u|$, 而 $\tilde{h}^2 = 0.1$ 与 0.5 使预测标准差分别比最优值小与大同样的 0.365, 故失配项相同。但前者斜率 3 (预测过度收缩), 后者斜率 0.6 (预测离散过大)。MSE 一个数字无法区分这两种方向相反的失准, 必须同时报告校准斜率。

【题目】

1.20 (1) $x = \Phi^{-1}(0.70) = 0.5244$, $i = \varphi(x)/0.3 = 1.1590$, $k = i(i - x) = 0.7355$ 。

(2) 被选个体中: $E(y_1) = 1.159$, $\text{Var}(y_1) = 0.2645$; $E(y_2) = ti = 0.4636$, $\text{Var}(y_2) = 1 - t^2k = 0.8823$; $\text{Cov} = t(1 - k) = 0.1058$; 回归系数 $0.1058/0.2645 = 0.40$ (不变); 相关 $= 0.40\sqrt{0.2645/0.8823} = 0.219$ 。

(3) 相对低估约 45%。正确做法是以全部个体的第一次记录与被选个体的第二次记录共同构建似然 (或用回归系数而非相关估计重复力)。这说明“选择只依赖已观察变量”并不意味着可以对被选样本使用任何统计量, 回归可以无偏, 相关与方差却不能。

【题目】

1.21 (1) 可靠性比 $\lambda = 16/(16 + 4) = 0.8$, 斜率 $= 2 \times 0.8 = 1.6$ 。(2) 两次平均后误差方差为 2, $\lambda = 16/18 = 0.889$, 斜率 1.778。(3) 两次独立测量的相关即为单次测量的 λ ($\text{Cov}(W_1, W_2) = \text{Var}(X)$); 用单次测量回归时, 把斜率除以 $\hat{\lambda}$ 即可校正; 用 m 次均值时, 除以 $m\hat{\lambda}/[1 + (m - 1)\hat{\lambda}]$ 。

【题目】

1.22 (1) $\sigma_* = \sqrt{4-1} = 1.732$, $z = (2-1)/1.732 = 0.5774$ 。

$$\begin{aligned}\text{VOI} &= 1.732 \times [\varphi(0.5774) - 0.5774 \times (1 - \Phi(0.5774))] \\ &= 0.3031 \text{ 单位} \approx 30.3 \text{ 元} > 25 \text{ 元},\end{aligned}$$

值得测定, 净收益约 5.3 元。百万次模拟给出 0.3040, 与解析值一致。

(2) 令 $\text{VOI} \times 100 = 25$, 解得测定后 PEV 需不大于 1.528, 即测定至少要解释先验方差的 61.8%。

(3) $m = -3$ 时 $z = 5/1.732 = 2.887$, $\text{VOI} \approx 1.732 \times [\varphi(2.887) - 2.887 \times 0.00195] \approx 0.0010$ 单位, 约 0.1 元。测定几乎不可能把该公羊的条件均值推过阈值, 决策不会因测定而改变。信息价值取决于“改变决策的概率”, 而不只是测定本身的精确程度。

[题目]

五、推导与证明题

1.23 以 h 为条件: 给定 h 时 e_i, e_j 独立, $\text{Cov}(y_i, y_j | h) = 0$; 而 $E(y_i | h) = \mu + h$ 。由全协方差公式

$$\text{Cov}(y_i, y_j) = E[0] + \text{Cov}(\mu + h, \mu + h) = \text{Var}(h).$$

若两只动物为全同胞, e_i 中包含的遗传成分在给定畜舍后仍相关, 需写 $y_i = \mu + h + g_i + e_i$, 于是 $\text{Cov}(y_i, y_j) = \text{Var}(h) + \frac{1}{2}\sigma_A^2 + \frac{1}{4}\sigma_D^2$ (+共同窝效应)。畜舍效应与家系效应若在设计中完全重合, 则二者无法分离 (第 13 章)。

[题目]

1.24 (1) $\text{Cov}(u - \hat{u}, y) = c^T - c^T P^{-1} P = 0$ 。 (2) $\text{Var}(\hat{u}) = c^T P^{-1} P P^{-1} c = c^T P^{-1} c$, $\text{Cov}(u, \hat{u}) = c^T P^{-1} c$, 二者相等, 故 $b_{u|\hat{u}} = 1$ 。 (3) $\text{corr}^2 = \frac{\text{Cov}(u, \hat{u})^2}{\sigma_u^2 \text{Var}(\hat{u})} = \frac{\text{Var}(\hat{u})}{\sigma_u^2}$, 又 $\text{PEV} = \sigma_u^2 - \text{Var}(\hat{u})$, 所以 $R = 1 - \text{PEV}/\sigma_u^2$ 。三个结论都只依赖二阶矩与正交性, 不需要正态假设。

[题目]

1.25 二元正态下 $Y = \alpha + \beta X + \varepsilon$, $\beta = \rho\sigma_Y/\sigma_X$, ε 与 X 独立、方差 $\sigma_Y^2(1-\rho^2)$ 。 S 是 X 的函数, 故 ε 与 (X, S) 独立, $E(Y | X, S) = \alpha + \beta X$ 。于是

$$\begin{aligned}\text{Var}(Y | S) &= E[\text{Var}(Y | X, S) | S] + \text{Var}[E(Y | X, S) | S] \\ &= \sigma_Y^2(1-\rho^2) + \beta^2 \text{Var}(X | S).\end{aligned}$$

在第 14 章中, 令 X 为表型、 Y 为育种值, 截断选择后 $\text{Var}(X | S) = (1-k)\sigma_P^2$, 代入得被选亲本的育种值方差 $\sigma_A^2(1-h^2k)$ 。亲本方差的这一减少传给后代, 就产生了 Bulmer 效应。

[题目]

1.26 (1) $u_1 - u_2$ 的后验为 $N(m_1 - m_2, v_d)$, $P(u_1 > u_2) = \Phi[(m_1 - m_2)/\sqrt{v_d}]$, 大于 0.5 当且仅当 $m_1 > m_2$ 。因此只比较两者谁更好时, 按后验均值排序与按“优于概率”排序一致, 与各自 PEV 大小无关。

(2) $P(u_1 > 3) = \Phi[(1 - 3)/2] = \Phi(-1) = 0.159$, $P(u_2 > 3) = \Phi[(1.5 - 3)/0.5] = \Phi(-3) = 0.0013$ 。尽管 $m_2 > m_1$, 若决策目标是“获得一只超过阈值的顶尖公羊”, 不确定性大的公羊 1 反而更有机会。结论: 排序准则必须与决策目标一致, 以阈值或尾部为目标时, 方差进入决策。

[题目]

六、综合分析与研究设计题

1.27 需补充: (1) 预测对象 (加性育种值、传递能力、未来表型还是综合指数); (2) “准确度”的定义 (与真值的相关、与校正表型的相关除以 h , 还是模型内理论值 $\sqrt{1 - \text{PEV}/\sigma_A^2}$); (3) 验证设计 (随机划分、按家系或出生年份前瞻验证); (4) 验证群体与目标群体的关系 (是否同品种、同环境、同世代); (5) 代理真值及其可靠度; (6) 校准斜率与均值偏差; (7) 样本量、家系数及区间估计; (8) 训练群体规模与信息截止时间。最可能改变结论含义的是 (1)、(2) 与 (3): 目标不同则 0.8 指不同的量; “模型内理论准确度”可远高于实测值; 随机划分会因近亲同时出现在训练与验证集而高估对新家系的准确度。

[题目]

1.28 (1) 在 B 场, 旧规则 $\hat{u} = 0.4y$, 真条件均值 $m(y) = 0.2y + 1$ 。

$$\text{MSE} = E[\text{Var}(u | y)] + E[(m(y) - 0.4y)^2] = 2 + E[(1 - 0.2y)^2] = 2 + 1 + 0.04 \times 5 = 3.2.$$

其中 2 为不可约误差, 1 为截距 (均值) 偏差平方, 0.2 为斜率失配。若改用 B 场的正确规则, MSE 可降为 2。

(2) 监测方案: 在 B 场按出生批次滚动收集可作为代理真值的后续信息 (后裔均值或成年记录); 定期估计“代理值对预测值”的回归截距与斜率及其置信区间; 设定预警规则 (如截距偏离零超过 2 个标准误或斜率超出 0.8~1.2); 按亚群 (场、季节、家系) 分层报告; 同时记录预测时点的信息截止, 避免用未来信息评估。检测到失配后, 先区分是均值基准变化还是环境互动, 再决定只做截距校准还是重新训练。

[题目]

1.29 所需数据: 候选者育种值的先验分布 (均值与方差)、检测前后可靠度、选留比例 (20/400=5%)、性状单位的经济价值、检测成本、世代间隔。计算步骤: (1) 把可靠度换算为条件均值的标准差, $\sigma_{\hat{u}} = \sigma_A \sqrt{R}$, 检测前为 $0.5\sigma_A$, 检测后为 $0.742\sigma_A$; (2) 选留 5% 时 $i = 2.063$, 所选 20 只的期望遗传优势由 $i\sigma_{\hat{u}}$ 给出, 提高 $2.063 \times (0.742 - 0.5)\sigma_A$; (3)

把该优势乘以公羊传递比例、后代数与每单位价值，再按世代间隔折现，得到年度收益；(4) 与 $400 \times 120 = 48000$ 元比较，并考虑检测还可用于缺陷管理、亲子鉴定等附加用途。不能只比较“可靠度提高 0.30”与成本，因为信息价值取决于选留比例与决策阈值（推导 1.3）：只有处在阈值附近、可能因检测而改变去留的公羔，检测才真正产生收益；也可以先按系谱筛掉明显无望的公羔，只检测候选边界附近的个体，以提高投入产出比。

【题目】

矩阵方法与稳定计算

2.1 本章导学

学习目标

1. 能由记录表写出设计矩阵 X, Z , 用秩与零空间判断哪些参数组合可被资料识别, 并检验线性函数的可估计性。
2. 掌握对称半正定矩阵的判别方法, 理解“合法协方差”的含义, 能诊断并修复非正定的估计矩阵。
3. 理解为何求解线性方程不必显式求逆, 掌握 Cholesky、QR、SVD 三种分解在遗传评定中的用途。
4. 能用条件数分析扰动传播, 比较正规方程与 QR 的数值稳定性。
5. 熟练使用分块矩阵、舍尔补与 Sherman–Morrison 公式, 理解单条记录的增加、删除与留一诊断。
6. 掌握对数行列式与逆矩阵的导数, 了解稀疏系统与迭代求解 (Jacobi、Gauss–Seidel、PCG) 的收敛特征。

重点与难点

重点: 秩与可估计性; 正定性与 Cholesky; QR 与条件数; 舍尔补; 矩阵微分公式。
难点: 参数不唯一与可估计函数唯一之间的关系; “求解器收敛”不等于“模型可识别”; 条件数平方放大的机制; Jacobi 迭代对正定系统也可能发散; 修复非正定矩阵会改变统计模型本身。

本章为第 21—28 章的混合模型方程、REML 与单步评定提供计算语言。每遇到一个矩阵, 都要问四个问题: 它的维数与行列含义是什么? 它是否满秩、是否正定? 我们需要它的逆, 还是只需要它与某个向量的乘积? 数值误差会怎样传播到我们真正关心的可估计量上?

2.2 知识结构图




图 2.1 第 2 章知识结构图

右侧三支讨论“矩阵是否合法、方程是否可解”，左侧四支讨论“怎样稳定、高效地算”。可估计性与条件数分别从统计与数值两个方向回答同一个问题：数据对某个方向究竟提供了多少信息。

2.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
可估计函数	$\lambda^T \beta$ 可估计 $\Leftrightarrow \lambda^T = \lambda^T (X^T X)^- X^T X$	与所选广义逆无关
正交投影	$H = X (X^T X)^- X^T$	唯一、对称、幂等
Cholesky	$A = LL^T, L_{jj} > 0$	当且仅当 A 正定
条件数	$\kappa_2(A) = \sigma_{\max} / \sigma_{\min};$ $\kappa(X^T X) = \kappa(X)^2$	扰动放大倍数的上界
扰动界	$\frac{\ \delta x\ }{\ x\ } \leq \kappa(A) \frac{\ \delta b\ }{\ b\ }$	A 非奇异
Eckart-Young	$\min_{\text{rank} \leq k} \ W - W_k\ _F^2 = \sum_{j>k} s_j^2$	截断 SVD 最优

概念	公式或定义	成立条件与提示
分块逆	右下块 = S^{-1} , $S = P_{22} - P_{21}P_{11}^{-1}P_{12}$	$\det P = \det P_{11} \det S$
Sherman–Morrison	$(M + xx^T)^{-1} =$ $M^{-1} - \frac{M^{-1}xx^TM^{-1}}{1 + x^TM^{-1}x}$	秩一更新
留一残差	$e_{(i)} = e_i / (1 - h_{ii})$	线性最小二乘
矩阵微分	$\partial \log V = \text{tr}(V^{-1} \partial V)$, $\partial V^{-1} = -V^{-1}(\partial V)V^{-1}$	REML 得分方程的基础
Kronecker 积	$\text{tr}(A \otimes B) = \text{tr} A \text{tr} B$, $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$	多性状模型 $A \otimes \Sigma$

2.4 补充内容与公式推导

推导 2.1 投影矩阵与广义逆的选择无关

设 G_1, G_2 都是 $X^T X$ 的广义逆。先证明 $XGX^T X = X$: 令 $E = XGX^T X - X$, 则

$$E^T E = (X^T X G^T X^T - X^T)(XGX^T X - X) = 0,$$

其中用到 $X^T X G X^T X = X^T X$ 及其转置。故 $E = 0$ 。于是对任意 v , 若 $v = Xa$, 有 $XG_k X^T v = Xa$; 若 $v \perp C(X)$, 则 $X^T v = 0$ 。两种广义逆在 $C(X)$ 与其正交补上作用相同, 所以 $XG_1 X^T = XG_2 X^T$ 。推论: 拟合值 $\hat{y} = Hy$ 唯一; 可估计函数 $\lambda^T \beta = a^T X \beta$ 的估计 $a^T H y$ 唯一; 不可估计函数则随广义逆而变。

推导 2.2 对数行列式与逆矩阵的导数

设 $V(\theta)$ 正定且可微。由 $VV^{-1} = I$ 求导: $\dot{V}V^{-1} + V\partial(V^{-1}) = 0$, 即

$$\frac{\partial V^{-1}}{\partial \theta} = -V^{-1} \dot{V} V^{-1}.$$

对数行列式: 设 $V = Q\Lambda Q^T$, $\log |V| = \sum \log \lambda_j$ 。利用 $\log |V + \varepsilon \dot{V}| = \log |V| + \log |I + \varepsilon V^{-1} \dot{V}| = \log |V| + \varepsilon \text{tr}(V^{-1} \dot{V}) + O(\varepsilon^2)$, 得

$$\frac{\partial \log |V|}{\partial \theta} = \text{tr} \left(V^{-1} \frac{\partial V}{\partial \theta} \right).$$

在动物模型 $V = ZAZ^T \sigma_u^2 + I \sigma_e^2$ 中, $\partial V / \partial \sigma_u^2 = ZAZ^T$, $\partial V / \partial \sigma_e^2 = I$ 。对数似然 $-\frac{1}{2}[\log |V| + y^T V^{-1} y]$ 对 σ_u^2 的得分为 $-\frac{1}{2}[\text{tr}(V^{-1} ZAZ^T) - y^T V^{-1} ZAZ^T V^{-1} y]$: 观察到的二次型与其期望之差, 这正是第 23 章 REML 得分方程的原型。

推导 2.3 为什么 $\kappa(X^T X) = \kappa(X)^2$ ，以及 QR 如何避开它

设 X 列满秩，奇异值分解 $X = USV^T$ ，则 $X^T X = VS^2V^T$ ，特征值为 s_j^2 ，故 $\kappa(X^T X) = (s_{\max}/s_{\min})^2$ 。在双精度（相对舍入误差约 10^{-16} ）下，形成 $X^T X$ 时信息已损失到 $\kappa(X)^2 \times 10^{-16}$ 的水平。Householder QR 把 X 正交变换为上三角 R ， $X^T X = R^T R$ 但从显式形成；求解 $Rb = Q^T y$ 的误差只与 $\kappa(X)$ 成正比。正交变换保持二范数，因此不放大舍入误差。需要强调：QR 只消除算法额外造成的损失；若设计本身共线， $\kappa(X)$ 大，系数估计对数据扰动仍然敏感——这是统计问题，不是算法问题，解决办法是重新参数化（中心化、正交多项式）或改进设计。

易错辨析

- 元素全为正的对称矩阵不一定正定；元素都在 $[-1, 1]$ 的相关矩阵也不一定合法。
- 行列式小不等于病态： $\det(\epsilon I) = \epsilon^n$ 很小，条件数却为 1。
- 求解器收敛不等于参数可识别：对奇异系统，迭代法可以收敛到某一个解，但不可估计函数的数值没有意义。
- 在对角线上加常数不是“无代价的数值修补”：它等价于增加一个独立方差成分，改变了收缩与 PEV。
- Jacobi 迭代不是对所有正定系统都收敛；Gauss-Seidel 对正定系统收敛，共轭梯度在精确算术下至多 n 步。

2.5 习题

一、单项选择题

2.1 ★ [单选] 某模型含总均值与 3 个场的指示变量（共 4 列），每个场至少有一条记录。设计矩阵 X 的秩为

- (A) 4 (B) 3 (C) 2
(D) 取决于记录数

[答案]

2.2 ★ [单选] 下列矩阵中，可以作为两个变量协方差矩阵的是

- (A) $\begin{pmatrix} 4 & 5 \\ 5 & 4 \end{pmatrix}$ (B) $\begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}$ (C) $\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$ (D) $\begin{pmatrix} 2 & 1 \\ 3 & 2 \end{pmatrix}$

[答案]

2.3 ★★ [单选] 设 A 为 3×3 加性关系矩阵、 Σ 为 2×2 遗传协方差矩阵, $\text{tr } A = 3.25$, $\text{tr } \Sigma = 5$ 。多性状模型中 $\text{Var}(u) = A \otimes \Sigma$ 的迹为

- (A) 8.25 (B) 16.25 (C) 32.5 (D) 无法确定

[答案]

2.4 ★★ [单选] 用原始幂 $1, t, t^2, t^3$ 回归日龄 30—210 天的体重时, 最好的数值处理方式是

- (A) 形成 $X^T X$ 后显式求逆
(B) 把 t 中心化并标准化后使用正交多项式
(C) 提高输出小数位数 (D) 在 $X^T X$ 的对角线上加 10^{-6}

[答案]

2.5 ★ [单选] 单因素模型 $y_{ij} = \mu + \tau_i + e_{ij}$ ($i = 1, 2, 3$) 中, 下列可估计的是

- (A) μ (B) τ_1 (C) $\tau_1 - \tau_2$ (D) $\tau_1 + \tau_2$

[答案]

2.6 ★★ [单选] 设 M 可逆, $h = x^T M^{-1} x$ 。从 M 中删除一条记录的贡献 xx^T 后, $(M - xx^T)^{-1}$ 等于

- (A) $M^{-1} - \frac{M^{-1}xx^TM^{-1}}{1-h}$ (B) $M^{-1} + \frac{M^{-1}xx^TM^{-1}}{1-h}$
(C) $M^{-1} + \frac{M^{-1}xx^TM^{-1}}{1+h}$ (D) $M^{-1} - xx^T$ [答案]

二、判断与改错题

2.7 ★ [判断] 对称矩阵的所有元素都为正数时, 它一定是正定矩阵。 [答案]

2.8 ★★ [判断] $X^T X$ 的广义逆不唯一, 因此用不同软件得到的固定效应解不同, 其拟合值 $X\hat{\beta}$ 也一定不同。 [答案]

2.9 ★ [判断] 矩阵的行列式越接近零, 用它求解线性方程时数值误差一定越大。 [答案]

2.10 ★★ [判断] 已知 $A = LL^T$, 先解 $Lz = b$ 再解 $L^T x = z$ 得到 $x = A^{-1}b$, 整个过程无需形成 A^{-1} 。 [答案]

三、填空题

2.11 ★ [填空] 矩阵 $\begin{pmatrix} 4 & 2 & 0 \\ 2 & 5 & 1 \\ 0 & 1 & 3 \end{pmatrix}$ 的迹为_____, 行列式为_____, 其特征值之和为_____。

[答案]

2.12 ★ [填空] 相关矩阵 $\begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$ 的特征值为_____, 二范数条件数为_____, 其逆矩阵为_____。

[答案]

2.13 ★★ [填空] 设 M 可逆。增加一条记录后, $(M + xx^T)^{-1} = M^{-1} -$ _____; 回归系数的变化量 $\Delta b =$ _____ $\times (y - x^T b)$ 。

[答案]

2.14 ★ [填空] 若 $V = \sigma^2 I_n$, 则 $\partial \log |V| / \partial \sigma^2 =$ _____, $\partial V^{-1} / \partial \sigma^2 =$ _____。

[答案]

四、计算题

2.15 ★★ [计算] 可估计性与混杂。8 条体重记录分布如下: H1 场有公羊 S1 (公、母各一) 和 S2 (公一); H2 场有 S2 (母一) 和 S3 (公、母各一); H3 场只有 S4 (公、母各一), S4 也只出现在 H3。模型含均值、场、性别与公羊 (全部作固定效应)。(1) 求 X 的维数与秩, 并说明零空间的含义; (2) 判断 H2-H1、H3-H1、公-母、S2-S1、S4-S1、 $(H3+S4)-(H1+S1)$ 、 μ 是否可估计; (3) 用两种不同广义逆核对可估计函数的估计值相同。 [程序] `ch02/ex02_15_estimability.py`

[答案]

2.16 ★★ [计算] Cholesky 与白化。断奶重 (kg)、日增重 (g/d)、背膘 (mm) 的加性协方差矩阵为

$$G = \begin{pmatrix} 4 & 18 & 0.6 \\ 18 & 900 & -6 \\ 0.6 & -6 & 0.25 \end{pmatrix}.$$

(1) 求 Cholesky 因子 L 及遗传相关矩阵; (2) 解释 L_{33} 的遗传学含义; (3) 候选者 $u = (2, 45, -0.4)^T$, 求其白化坐标与马氏距离平方, 并与“逐性状标准分数平方和”比较。 [程序] `ch02/ex02_16_cholesky_whitening.py`

[答案]

2.17 ★★ [计算] 生长曲线回归的数值稳定性。13 个日龄 (30, 45, ..., 210 天) 的体重以原始幂 $1, t, \dots, t^q$ 回归 ($q = 1, \dots, 6$)。 (1) 计算 $\kappa(X)$ 与 $\kappa(X^T X)$; (2) 比较正规方程、QR 与 Legendre 正交多项式三种算法的拟合值误差; (3) 解释为什么拟合值稳定而高次原始幂系数没有解释意义。 [程序] `ch02/ex02_17_qr_vs_normal.py` [答案]

2.18 ★★ [计算] 基因型矩阵的低秩结构。模拟 20 个全同胞家系、每家 10 只、1000 个 SNP 的基因型, 列中心化得 W 。 (1) 求数值秩; (2) 计算前 $k = 1, 5, 10, 20, 50, 100$ 个主成分解释的方差比例, 并验证 Eckart-Young 定理; (3) 解释第 19 与第 20 个奇异值之间的“断点”; (4) 说明 $G = WW^T / (2 \sum p_j q_j)$ 为何奇异。 [程序] `ch02/ex02_18_svd_lowrank.py` [答案]

2.19 ★★★ [计算] 迭代求解混合模型方程。300 只动物、15 个管理组、 $\lambda = \sigma_e^2 / \sigma_u^2 = 2$, 用 Henderson 规则写出稀疏 A^{-1} 并组建混合模型方程。 (1) 比较 Jacobi ($\omega = 1$ 与 $\omega = 0.5$)、Gauss-Seidel 与对角预条件共轭梯度达到相对残差 10^{-10} 的迭代数; (2) 计算 Jacobi 迭代矩阵的谱半径, 解释其发散原因; (3) 比较预条件前后的条件数。 [程序] `ch02/ex02_19_iterative_solvers.py` [答案]

2.20 ★ [计算] 用分块求逆公式求 $P = \begin{pmatrix} 4 & 2 & 1 \\ 2 & 3 & 0 \\ 1 & 0 & 2 \end{pmatrix}$ 的逆矩阵 (以左上 2×2 块为 P_{11}), 并由 $\det P = \det P_{11} \cdot s$ 计算行列式。 [答案]

2.21 ★ [计算] 体重 (kg) 与日增重 (g/d) 的遗传协方差矩阵为 $\begin{pmatrix} 16 & 30 \\ 30 & 900 \end{pmatrix}$ 。把日增重单位改为 kg/d, 写出新协方差矩阵与遗传相关; 若原综合目标为 $H = 2u_1 + 0.05u_2$, 新单位下的经济权重是多少? [答案]

2.22 ★★ [计算] 单条记录的影响。10 条记录 (x, y) 中, x 依次为 1, 2, ..., 10, y 依次为 2.1, 3.9, 6.2, 7.8, 10.1, 12.2, 13.8, 16.1, 25.0, 20.2。 (1) 拟合简单线性回归, 求每条记录的杠杆值、留一残差与 Cook 距离; (2) 指出影响最大的记录并给出删除它后的系数; (3) 用 Sherman-Morrison 公式 (不重新拟合) 求增加记录 (11, 22.1) 后的系数。 [程序] `ch02/ex02_22_rank_one_update.py` [答案]

五、推导与证明题

2.23 ★★ [证明] 证明 $H = X(X^T X)^{-1} X^T$ 与广义逆的选择无关, 且是 $C(X)$ 上的正交投影; 并由此说明可估计函数的估计值唯一。 [答案]

2.24 ★★ [证明] 设 $P = \begin{pmatrix} P_{11} & P_{12} \\ P_{21} & P_{22} \end{pmatrix}$ 对称正定。用块高斯消元证明分块逆公式与 $\det P = \det P_{11} \det S$, 并说明舍尔补 S 在正态模型中的统计含义。 [答案]

2.25 ★★ [证明] 对 $V(\theta)$ 正定, 证明 $\partial V^{-1} / \partial \theta = -V^{-1} \dot{V} V^{-1}$ 与 $\partial \log |V| / \partial \theta = \text{tr}(V^{-1} \dot{V})$, 并写出 $V = Z A Z^T \sigma_u^2 + I \sigma_e^2$ 时正态对数似然对 σ_u^2 的导数。 [答案]

2.26 ★★★ [证明] 设 $Ax = b$, $A(x + \delta x) = b + \delta b$ 。证明 $\|\delta x\| / \|x\| \leq \kappa(A) \|\delta b\| / \|b\|$, 并构造使等号成立的 b 与 δb 。 [答案]

六、综合分析与研究设计题

2.27 ★★ [综合] 某研究生为计算 5 万只动物的 BLUP, 先形成稠密 A 再求逆, 内存溢出后改用双精度“分块求逆”。请指出问题所在, 并给出一个合理的计算流程(说明每一步利用了什么矩阵结构)。 [答案]

2.28 ★★★ [综合] 非正定遗传相关矩阵的诊断与修复。四个性状(出生重、断奶重、6 月龄重、背膘)的遗传相关由不同资料两两估计, 拼成矩阵

$$R = \begin{pmatrix} 1 & 0.85 & 0.20 & 0.60 \\ 0.85 & 1 & 0.90 & -0.30 \\ 0.20 & 0.90 & 1 & -0.50 \\ 0.60 & -0.30 & -0.50 & 1 \end{pmatrix}.$$

(1) 判断其是否合法, 并指出“方差为负”的性状组合方向; (2) 分别用特征值弯曲与 Higham 最近相关矩阵修复, 比较相关系数的改变量; (3) 对标准化目标 $a = (0, 1, 1, -2)^T$ 比较修复前后的 $a^T R a$; (4) 讨论修复结果应当怎样报告。 [程序]

ch02/ex02_28_bending.py

[答案]

2.29 ★★★ [综合] 为一个新开发的遗传评定程序设计一套计算核验方案, 要求覆盖: 恒等式检验、小规模可手算算例、不变性检验(重排动物顺序、改变单位、改变广义逆)、与独立实现比较, 以及病态与奇异情形下的行为。说明每类检验能发现何种错误、不能发现何种错误。 [答案]

2.6 参考答案与解析

一、单项选择题

- 2.1 B.** 三个场指示列之和等于均值列, 存在一个线性约束, 秩为 $4 - 1 = 3$ 。记录数只影响行数, 不改变这个列间依赖。 [题目]
- 2.2 B.** 合法协方差矩阵必须对称半正定。(A) 行列式 $16 - 25 < 0$; (C) 有负方差; (D) 不对称。(B) 行列式为零、特征值为 5 与 0, 是半正定的 (两变量完全相关, $Y = X/2$)。 [题目]
- 2.3 B.** $\text{tr}(A \otimes \Sigma) = \text{tr} A \cdot \text{tr} \Sigma = 3.25 \times 5 = 16.25$ 。 $\text{tr} A = 3.25$ 说明三只动物的近交系数之和为 0.25。 [题目]
- 2.4 B.** 中心化与正交基从根源上降低条件数 (见习题 2.17, Legendre 基条件数始终小于 4)。显式求逆最不稳定; 提高显示位数与数值精度无关; 加对角常数改变了模型。 [题目]
- 2.5 C.** $\tau_1 - \tau_2 = E(\bar{y}_{1.}) - E(\bar{y}_{2.})$ 是观测期望的线性组合。 μ 、 τ_1 以及 $\tau_1 + \tau_2$ 都会随“ μ 加 c 、各 τ_i 减 c ”的平移而改变, 不可估计。 [题目]
- 2.6 B.** 把 Sherman-Morrison 公式中的 x 换成“减去”的秩一项: $(M - xx^T)^{-1} = M^{-1} + M^{-1}xx^T M^{-1}/(1 - h)$ 。当 $h \rightarrow 1$ (该记录是唯一提供某方向信息的记录) 时分母趋于零, 删除后矩阵奇异。 [题目]

二、判断与改错题

- 2.7 错误。** 反例 $\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$, 特征值为 3 与 -1。正定性要求所有特征值为正 (或所有顺序主子式为正), 与元素符号无关。 [题目]
- 2.8 错误。** 固定效应解随广义逆而变, 但 $X\hat{\beta} = Hy$ 唯一 (推导 2.1)。若两个软件的拟合值不同, 说明它们实现的不是同一个模型或存在错误。 [题目]
- 2.9 错误。** 数值误差由条件数而非行列式决定。 $10^{-3}I_{10}$ 的行列式为 10^{-30} , 条件数为 1, 求解毫无困难。行列式随尺度的 n 次方变化, 不是病态性的度量。 [题目]
- 2.10 正确。** 两次三角回代的计算量为 $O(n^2)$, 形成逆矩阵需 $O(n^3)$ 且更不稳定; 对稀疏矩阵, 逆矩阵通常是稠密的, 稀疏 Cholesky 因子则可以保持稀疏。 [题目]

三、填空题

2.11 迹为 12，行列式为 44，特征值之和等于迹，也为 12。 [题目]

2.12 特征值 1.5 与 0.5；条件数 3；逆矩阵为 $\frac{4}{3} \begin{pmatrix} 1 & -0.5 \\ -0.5 & 1 \end{pmatrix}$ 。 [题目]

2.13 $\frac{M^{-1}xx^TM^{-1}}{1+x^TM^{-1}x}$ ； $\frac{M^{-1}x}{1+x^TM^{-1}x}$ 。新记录的“预测残差” $y-x^Tb$ 越大、杠杆越高，系数变化越大。 [题目]

2.14 n/σ^2 ； $-\sigma^{-4}I_n$ 。 [题目]

四、计算题

2.15 (1) 参数为均值 1、场 3、性别 2、公羊 4，共 10 列；秩为 6，零空间维数 4。四个零空间方向分别对应：均值与场的平移、均值与性别的平移、均值与公羊的平移，以及 H3 与 S4 的完全混杂（H3 加 c 、S4 减 c ，拟合值不变）。

(2)

线性函数	可估计	估计值	标准误
H2-H1	是	-0.867	0.636
H3-H1	否	—	—
公 - 母	是	4.233	0.318
S2-S1	是	0.633	0.503
S4-S1	否	—	—
(H3+S4)-(H1+S1)	是	2.950	0.389
μ	否	—	—

H2-H1 可估计，是因为 S2 同时出现在 H1 与 H2，构成场间“桥梁”；H3 与其他场没有共同公羊，场差与公羊差无法拆开，只有二者之和的对比可估计。

(3) 用 Moore-Penrose 逆与“H1、母、S1、S4 置零”约束两种广义逆，可估计函数的估计完全一致；不可估计函数则相差很大（如 H3-H1 分别给出 0.426 与 2.950），说明后者只是约束的产物。若把公羊改为随机效应，H3-H1 会有唯一的 BLUE/BLUP，但其值依赖公羊方差的先验假设（第 21 章）。 [题目]

2.16 (1)

$$L = \begin{pmatrix} 2 & 0 & 0 \\ 9 & 28.618 & 0 \\ 0.3 & -0.304 & 0.260 \end{pmatrix}, \quad R = \begin{pmatrix} 1 & 0.3 & 0.6 \\ 0.3 & 1 & -0.4 \\ 0.6 & -0.4 & 1 \end{pmatrix}.$$

(2) $L_{33} = 0.260$ 是在断奶重与日增重育种值都已知后,背膘育种值的条件标准差;边际标准差为 0.5, 说明两个生长性状共解释了背膘遗传方差的 $1 - 0.26^2 / 0.25 = 73\%$ 。
 $L_{22} = 28.62$ (边际 30) 表明断奶重只解释日增重遗传方差的 9%。

(3) 白化坐标 $w = L^{-1}u = (1.000, 1.258, -1.222)^T$, 马氏距离平方 $d^2 = 4.075$, χ_3^2 上尾概率 0.254。逐性状标准分数为 $(1, 1.5, -0.8)$, 平方和 3.89。两者差异来自相关: 断奶重高而背膘低, 与二者的正遗传相关 0.6 相悖, 因此在联合分布中更“罕见”。模拟 10 万个体时样本协方差与 G 的标准化相对误差最大不到 1%。 【题目】

2.17 (1) $\kappa(X)$ 从 $q = 1$ 的 313 增至 $q = 6$ 的 2.7×10^{15} ; $\kappa(X^T X)$ 为其平方, $q \geq 4$ 时已超过 10^{16} , 双精度下数值上已近奇异 (程序报告的 10^{20} 以上的数值本身也不可靠)。

(2) 拟合值最大误差: 正规方程从 10^{-14} 恶化到 $q = 6$ 的 1.5×10^{-8} ; QR 保持在 10^{-12} 以下; Legendre 基的条件数始终小于 3.7, 误差约 10^{-13} 。

(3) 拟合值 Hy 是可估计量, 只要求解稳定就唯一; 原始幂系数之间高度共线, 单个系数可以在大幅度内互相补偿而几乎不改变拟合值。即便二次模型, 真系数为 $(3.5, 0.21, -2 \times 10^{-4})$, 估计值 $(2.11, 0.236, -3.0 \times 10^{-4})$ 也偏离较大, 而拟合曲线与真曲线非常接近。解释生长曲线应使用拟合值、导数或正交基系数, 而不是原始幂系数。 【题目】

2.18 (1) W 为 200×1000 , 列中心化消去全 1 方向, 数值秩为 199。

(2)

k	1	5	10	20	50	100
解释方差比例	0.037	0.170	0.320	0.554	0.684	0.839

每个 k 下, $\|W - W_k\|_F^2$ 与 $\sum_{j>k} s_j^2$ 在机器精度内相等。

(3) 20 个家系的均值向量中心化后张成 19 维子空间, 家系间差异集中于前 19 个主成分 (共解释约 55% 的方差), 第 19 与第 20 个奇异值之比约为 2.03, 之后的奇异值反映家系内孟德尔抽样, 下降平缓。GWAS 中用前若干主成分校正群体结构, 正是利用这一“断点” (第 8 章)。

(4) G 的秩不超过 W 的秩 $199 < 200$, 且中心化使 $G1 = 0$, 最小特征值在机器精度内为零。混合模型方程使用 G^{-1} 时需要处理, 而 $V = G\sigma_u^2 + I\sigma_e^2$ 始终正定。【题目】

2.19 (1) 方程阶数 315, 非零元仅占 2.3%。

方法	迭代数	与直接解最大差
Jacobi ($\omega = 1$)	发散	—
Jacobi ($\omega = 0.5$)	1180	2.7×10^{-8}
Gauss-Seidel	246	1.8×10^{-8}
PCG (对角预条件)	44	4.2×10^{-9}

(2) Jacobi 迭代矩阵 $I - D^{-1}C$ 的谱半径为 $1.215 > 1$, 误差每步按约 1.2 倍放大; 加权后 $I - 0.5D^{-1}C$ 的谱半径为 0.985, 收敛但很慢。混合模型方程的固定效应块与随机效应块之间耦合强, 不满足对角占优, 这是 Jacobi 发散的原因。

(3) $\kappa(C) = 145$, 对角预条件后为 73。PCG 的收敛速度大致由 $\sqrt{\kappa}$ 决定, 且利用了 Krylov 子空间的最优性, 因此显著快于定常迭代。大型评定中, 求解精度应以关键可估计量 (如候选动物的育种值差异) 的变化而非单纯残差来判断。【题目】

2.20 $P_{11}^{-1} = \frac{1}{8} \begin{pmatrix} 3 & -2 \\ -2 & 4 \end{pmatrix}$, $s = 2 - (1,0)P_{11}^{-1}(1,0)^T = 2 - \frac{3}{8} = \frac{13}{8}$ 。

$$P^{-1} = \begin{pmatrix} 0.4615 & -0.3077 & -0.2308 \\ -0.3077 & 0.5385 & 0.1538 \\ -0.2308 & 0.1538 & 0.6154 \end{pmatrix},$$

右下元素 $= s^{-1} = 8/13$; $\det P = \det P_{11} \cdot s = 8 \times \frac{13}{8} = 13$ 。

【题目】

2.21 $D = \text{diag}(1, 0.001)$, 新矩阵 $DGD = \begin{pmatrix} 16 & 0.03 \\ 0.03 & 0.0009 \end{pmatrix}$; 遗传相关 $30/(4 \times 30) = 0.25$

保持不变。新育种值 $u_2^* = 0.001u_2$, 为使 H 不变, 新权重 $a_2^* = 0.05/0.001 = 50$ (元/(kg/d)), 即 $a^* = D^{-1}a = (2, 50)^T$ 。

【题目】

2.22 (1) 全部记录: 截距 -0.933 , 斜率 2.304 , $s^2 = 4.516$ 。杠杆值两端最大 (0.346), 中间最小 (0.103)。第 9 条记录残差 5.195, 留一残差 6.913, Cook 距离 1.315, 远大于其他记录 (次大为第 10 条 0.325)。

(2) 删除第 9 条后截距 -0.012 、斜率 2.011 ，斜率下降约 13%。第 10 条 Cook 距离偏大主要是因为第 9 条把回归线“拉高”，使第 10 条看起来偏低——这是诊断时“掩蔽效应”的一个小例子，应在删除第 9 条后重新诊断。

(3) $\Delta b = \frac{M^{-1}x}{1+x^T M^{-1}x}(y-x^T b) = (0.421, -0.105)^T$ ，新系数截距 -0.513 、斜率 2.199 ，与重新拟合完全一致。秩一更新把重新计算的代价从 $O(np^2)$ 降为 $O(p^2)$ ，这是增量评定的基本工具（第 28、34 章）。 [题目]

五、推导与证明题

2.23 见推导 2.1。正交投影的性质： $H^2 = XGX^T XGX^T = XGX^T = H$ （用到 $XGX^T X = X$ ）；对称性：取对称广义逆即得，再由唯一性推广到任意广义逆； $HX = X$ 说明 $C(X)$ 上为恒等， $Hv = 0$ ($v \perp C(X)$) 说明正交补上为零。若 $\lambda^T = a^T X$ ，则 $\lambda^T \hat{\beta} = a^T XGX^T y = a^T Hy$ ，唯一。 [题目]

2.24 左乘 $L = \begin{pmatrix} I & 0 \\ -P_{21}P_{11}^{-1} & I \end{pmatrix}$ ，右乘 L^T ，得 $LPL^T = \text{diag}(P_{11}, S)$ 。由于 $\det L = 1$ ， $\det P = \det P_{11} \det S$ ；由 $P^{-1} = L^T \text{diag}(P_{11}^{-1}, S^{-1})L$ 展开即得分块逆

$$P^{-1} = \begin{pmatrix} P_{11}^{-1} + P_{11}^{-1}P_{12}S^{-1}P_{21}P_{11}^{-1} & -P_{11}^{-1}P_{12}S^{-1} \\ -S^{-1}P_{21}P_{11}^{-1} & S^{-1} \end{pmatrix}.$$

统计含义：若 (x_1, x_2) 联合正态、协方差为 P ，则 $S = \text{Var}(x_2 | x_1)$ ——给定第一组变量后第二组的条件协方差。习题 1.16 的创新量方差、第 28 章单步评定中未分型动物的条件方差，都是舍尔补。 [题目]

2.25 见推导 2.2。对正态对数似然 $\ell = -\frac{1}{2}[\log |V| + r^T V^{-1} r]$ ($r = y - X\beta$)，

$$\frac{\partial \ell}{\partial \sigma_u^2} = -\frac{1}{2} \text{tr}(V^{-1} ZAZ^T) + \frac{1}{2} r^T V^{-1} ZAZ^T V^{-1} r.$$

因 $E[r^T B r] = \text{tr}(BV)$ ，取 $B = V^{-1} ZAZ^T V^{-1}$ 时两项期望相等，得分期望为零。 [题目]

2.26 $\delta x = A^{-1} \delta b$ ，故 $\|\delta x\| \leq \|A^{-1}\| \|\delta b\|$ ；又 $\|b\| \leq \|A\| \|x\|$ ，即 $1/\|x\| \leq \|A\|/\|b\|$ 。两式相乘得结论， $\kappa = \|A\| \|A^{-1}\| = \sigma_{\max}/\sigma_{\min}$ 。等号成立：取 b 为最大奇异值对应的左奇异向量 $u_{\max}$ （使 $\|b\| = \|A\| \|x\|$ ），取 δb 平行于最小奇异值对应的左奇异向量 $u_{\min}$ （使 $\|A^{-1} \delta b\|$ 达到最大）。直观地说：信号落在 A 最“强”的方向，扰动落在最“弱”的方向时，相对误差被放大得最多。 [题目]

六、综合分析与研究设计题

2.27 问题：(1) 稠密 A 需要 $5 \times 10^4 \times 5 \times 10^4 \times 8$ 字节 ≈ 20 GB，而它的逆 A^{-1} 却是极其稀疏的；(2) BLUP 只需求解方程，不需要逆矩阵；(3) 分块求逆仍是 $O(n^3)$ 运算，且误差累积。合理流程：(1) 系谱排序（父母在前）并检查循环与性别冲突；(2) 用 Henderson 规则（含近交时用 Meuwissen–Luo 或 Quaas 算法）直接构造稀疏 A^{-1} ，每只动物只贡献至多 9 个非零元；(3) 组建稀疏混合模型方程；(4) 用 PCG（对角或块对角预条件）或稀疏 Cholesky 求解，按候选动物育种值的变化设定停止准则；(5) 若需要 PEV，用稀疏逆子集算法或抽样近似，而非求完整逆。每一步分别利用了系谱的局部传递结构、方程的稀疏性与正定性。 [题目]

2.28 (1) 特征值为 $-0.238, 0.183, 1.685, 2.370$ ，存在负特征值，矩阵不合法。负特征值对应方向约为 $(0.59, -0.68, 0.26, -0.35)$ ：出生重高、断奶重低、6 月龄重略高、背膘低的组合。直观原因是：出生重与断奶重高度正相关 (0.85)、断奶重与 6 月龄重高度正相关 (0.90)，但出生重与 6 月龄重只有 0.20，与背膘的相关符号也互相矛盾，四个两两估计无法同时成立。

(2) 弯曲后 $\|\Delta R\|_F = 0.306$ ，最大改变 0.162 (r_{12} 由 0.85 降至 0.688)；最近相关矩阵 $\|\Delta R\|_F = 0.298$ ，最大改变 0.153 (r_{12} 降至 0.697)。两种修复都主要削减了 r_{12} 与 r_{23} ，同时抬高 r_{13} 。

(3) $a^T R a$ 由 11.00 降至 10.57 (弯曲) 或 10.65 (最近相关)，目标方差改变约 3%—4%，相应的选择反应预测与指数权重也会改变。

(4) 报告应说明：原估计来源与样本量；负特征值大小；采用的修复方法、阈值 ε 与权重；修复前后各相关的改变量；关键结论（如指数权重、预期反应）对修复方法的敏感性。更好的做法是用多性状联合估计（第 23—24 章）或按各相关估计的精度加权修复，而非把所有元素视为同等可信。 [题目]

2.29 (1) **恒等式检验**： $C\hat{s} = r$ 的残差、 $AA^{-1} = I$ (小系谱)、可估计函数的唯一性、 $\sum$ 固定效应解与均值的关系——可发现组装与求解错误，但发现不了模型设定错误。(2) **可手算算例**：单动物、双亲已知、半同胞家系等教材算例——可发现公式与尺度错误（如 PEV 忘乘 σ_e^2 ），但算例过小可能掩盖稀疏结构错误。(3) **不变性检验**：重排动物、改变性状单位、换用另一广义逆，可估计量应不变或按单位变换——可发现身份对应与单位处理错误，但不能发现所有动物共同的系统误差。(4) **与独立实现比较**：比较均值差、回归斜率、最大绝对差而非仅相关——可发现实现差异，但两个实现可能犯同样的概念错误。(5) **病态与奇异情形**：完全混杂的设计、零方差边界、重复记录——检验程序是否报告不可识别而非静默输出数字。最后还需用

已知真值的模拟检验统计行为（偏差、覆盖率），这是数值核验无法替代的。【题目】

统计推断、似然与数量遗传学方法

3.1 本章导学

学习目标

- 1. 能把一个遗传学问题写成概率模型，区分参数、随机效应与观测量，并说明哪些参数可被资料识别。
- 2. 掌握最大似然估计、Fisher 信息、Wald 区间、似然比检验与 LOD 值之间的换算关系，理解轮廓似然。
- 3. 能推导并实现 EM 算法，理解其单调上升性质与局部极值风险。
- 4. 能用 Delta 方法与自助法计算比值参数（如遗传力）的标准误，并正确设计重抽样单位。
- 5. 能计算检验功效与样本量，理解“检测是否存在”与“精确估计大小”两类设计目标的差别。
- 6. 掌握族错误率与错误发现率的控制方法，理解置换检验成立的可交换性条件与贝叶斯后验的收缩性质。

重点与难点

重点：似然函数与 MLE；LRT 与 LOD；EM 算法；Delta 方法；功效计算；Bonferroni 与 BH 程序。

难点：参数位于边界或在零假设下不可识别时，似然比统计量不服从常规 χ^2 ；重抽样单位必须与数据的相关结构一致；置换检验只有在零假设下观测可交换时才有效；“p 值小”既不是零假设为假的概率，也不衡量效应大小。

本章把第 1 章的概率语言推进到“由资料推断参数”。第 6、7 章的连锁 LOD 与区间作图、第 8 章的 GWAS 多重检验、第 13 章遗传参数的方差分析估计、第 23 章的 REML 与贝叶斯推断，都建立在本章的工具之上。

3.2 知识结构图




图 3.1 第 3 章知识结构图

右侧从“模型 → 似然 → EM”构成估计的主线；左侧“区间与标准误、检验与功效、多重检验、贝叶斯与重抽样”回答估计有多可信、发现有多可靠。

3.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
Fisher 信息	$\mathcal{I}(\theta) = -E[\partial^2 \ell / \partial \theta^2]$; $\text{Var}(\hat{\theta}) \approx \mathcal{I}^{-1}$	正则条件、大样本
二项比例	$\hat{p} = x/n$, $\mathcal{I} = n/[p(1-p)]$	独立伯努利试验
似然比检验	$\Lambda = 2[\ell(\hat{\theta}) - \ell(\theta_0)] \sim \chi_q^2$	内点、可识别
LOD	$\text{LOD} = \log_{10}(L_1/L_0) = \Lambda/(2 \ln 10) \approx \Lambda/4.605$	LOD 3 对应 $\Lambda \approx 13.8$
边界检验	方差组分 $\sigma^2 = 0$: $\Lambda \sim \frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$	单个方差参数位于边界
EM 单调性	$\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)})$	只保证不下降，不保证全局最优
Delta 方法	$\text{Var}[g(\hat{\theta})] \approx \nabla g^\top \text{Var}(\hat{\theta}) \nabla g$	g 光滑、 $\hat{\theta}$ 近似正态
半同胞 ANOVA	$E(\text{MSB}) = \sigma_w^2 + n\sigma_s^2$, $E(\text{MSW}) = \sigma_w^2$	平衡资料

概念	公式或定义	成立条件与提示
F 检验功效	$F \sim (1 + \frac{nt}{1-t}) F_{s-1, s(n-1)}$	单因素随机模型、正态
Bonferroni / Holm	阈值 α/m ; Holm 逐步 $\alpha/(m-k+1)$	控制 FWER, 不需独立
BH 程序	找最大 k 使 $p_{(k)} \leq k\alpha/m$	独立或正相关下控制 FDR $\leq \pi_0\alpha$
正态共轭	后验均值 $= \frac{\tau^{-2}\mu_0 + s^{-2}\hat{\theta}}{\tau^{-2} + s^{-2}}$	先验 $N(\mu_0, \tau^2)$, 似然近似 $N(\hat{\theta}, s^2)$

3.4 补充内容与公式推导

推导 3.1 EM 算法为何使似然单调不减

设完整资料 (y, z) , 观测资料对数似然 $\ell(\theta) = \log \int f(y, z | \theta) dz$ 。对任意 θ' , 记 $q(z) = f(z | y, \theta')$ 。由 Jensen 不等式

$$\ell(\theta) = \log \int q(z) \frac{f(y, z | \theta)}{q(z)} dz \geq \underbrace{\int q \log f(y, z | \theta) dz}_{Q(\theta | \theta')} - \int q \log q dz,$$

当 $\theta = \theta'$ 时等号成立。E 步计算 $Q(\theta | \theta^{(t)})$, M 步取 $\theta^{(t+1)} = \arg \max Q$, 于是

$$\ell(\theta^{(t+1)}) \geq Q(\theta^{(t+1)} | \theta^{(t)}) - H \geq Q(\theta^{(t)} | \theta^{(t)}) - H = \ell(\theta^{(t)}).$$

这个下界论证只保证单调性。若似然多峰（混合模型、单倍型频率），EM 会停在局部极大或鞍点；收敛速度由“缺失信息比例”决定，缺失越多越慢。因此实际使用时应采用多起点，并检查最终点的梯度与 Hessian。

推导 3.2 参数位于边界时似然比统计量的分布

考虑 $H_0: \sigma_s^2 = 0$ 对 $H_1: \sigma_s^2 > 0$ 。在大样本下，无约束估计 $\hat{\sigma}_s^2$ 近似服从以 0 为中心的正态分布，因此约有一半的样本中 $\hat{\sigma}_s^2 < 0$ 。受约束 MLE 为 $\hat{\sigma}_s^2 = \max(\hat{\sigma}_s^2, 0)$ ：当 $\hat{\sigma}_s^2 < 0$ 时 $\hat{\sigma}_s^2 = 0$, $\Lambda = 0$ ；当 $\hat{\sigma}_s^2 > 0$ 时 Λ 近似为一个标准正态变量的平方。所以

$$\Lambda \sim \frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2, \quad P(\Lambda > c) = \frac{1}{2}P(\chi_1^2 > c).$$

按常规 χ_1^2 计算的 p 值应减半，5% 临界值由 3.84 降为 2.71。若同时检验多个相关的方差—协方差参数，混合权重更复杂；若零假设下某些参数不可识别（如混合模型中 $\pi = 0$ 时的 μ_1 ），则连混合 χ^2 也不适用，需要参数自助法（习题 3.15）。

推导 3.3 半同胞 ANOVA 期望均方与遗传力的 Delta 标准误

模型 $y_{ij} = \mu + s_i + e_{ij}$, $i = 1, \dots, s, j = 1, \dots, n$ 。 $\bar{y}_{i.} = \mu + s_i + \bar{e}_{i.}$, 故 $\text{Var}(\bar{y}_{i.}) = \sigma_s^2 + \sigma_w^2/n$, $E \sum_i (\bar{y}_{i.} - \bar{y}_{..})^2 = (s-1)(\sigma_s^2 + \sigma_w^2/n)$, 于是 $E(\text{MSB}) = n\sigma_s^2 + \sigma_w^2$; 组内 $E(\text{MSW}) = \sigma_w^2$ 。 ANOVA 估计 $\hat{\sigma}_s^2 = (\text{MSB} - \text{MSW})/n$ 无偏。 组内相关 $t = \sigma_s^2/(\sigma_s^2 + \sigma_w^2)$ 是两个均方的非线性函数。 正态下 MSB, MSW 独立, $\text{Var}(\text{MS}) \approx 2 E(\text{MS})^2/\text{df}$, 用 Delta 方法可得 Fisher 近似

$$\text{Var}(\hat{t}) \approx \frac{2(1-t)^2[1+(n-1)t]^2}{n(n-1)(s-1)}, \quad \text{SE}(\hat{h}^2) = 4 \text{SE}(\hat{t}).$$

对给定总数 $N = sn$, 这一方差在 $n \approx 1/t$ 附近最小 (Robertson 准则); 但检测 $\sigma_s^2 > 0$ 的功效最大值出现在更大的 n (习题 3.17)。

易错辨析

- **p 值不是零假设为真的概率**, 也不是效应大小; 样本足够大时微小效应也会极显著。
- **LOD 3 不等于“1000 倍证据”就足够**: 基因组扫描中要对检验次数校正 (第 7 章阈值)。
- **EM 收敛不代表全局最优**: 多峰似然必须多起点。
- **自助法的抽样单位必须是独立单位**: 家系资料按家系抽, 不能按个体抽。
- **置换检验并非“无假设”**: 它要求零假设下观测可交换, 群体结构会破坏这一点。
- **控制 FDR 不等于控制每个发现的错误概率**: FDR 是发现集合中假阳性比例的期望。

3.5 习题

一、单项选择题

3.1 ★ [单选] 已知 $\hat{\sigma}_A^2$ 与 $\hat{\sigma}_E^2$ 分别是 σ_A^2, σ_E^2 的最大似然估计, 则 $h^2 = \sigma_A^2/(\sigma_A^2 + \sigma_E^2)$ 的最大似然估计为

- (A) 需要重新对 h^2 写似然并求解 (B) $\hat{\sigma}_A^2/(\hat{\sigma}_A^2 + \hat{\sigma}_E^2)$
(C) $\hat{\sigma}_A^2/\hat{\sigma}_E^2$ (D) 不存在

[答案]

3.2 ★★ [单选] 用似然比检验 $H_0: \sigma_m^2 = 0$ (母体遗传方差) 得 $\Lambda = 3.0$ 。下列说法正确的是

- (A) 按 χ_1^2 , $p = 0.083$, 不显著, 结论无须修正
 (B) 应按 $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$, $p \approx 0.042$ (C) 应按 χ_2^2
 (D) 边界检验不能做

[答案]

3.3 ★★ [单选] 在 m 个独立检验中使用 BH 程序 ($\alpha = 0.05$), 下列说法正确的是

- (A) 保证至少一个假阳性的概率不超过 0.05
 (B) 保证每一个显著位点为假阳性的概率不超过 0.05
 (C) 保证显著集合中假阳性比例的期望不超过 $0.05 m_0/m$
 (D) 比 Bonferroni 更保守

[答案]

3.4 ★ [单选] 对 n 条记录、 k 个参数的模型, BIC 与 AIC 的惩罚项分别为

- (A) $2k$ 与 $k \ln n$ (B) $k \ln n$ 与 $2k$ (C) 都是 $2k$ (D) 都是 $k \ln n$

[答案]

3.5 ★★ [单选] 用 50 个全同胞家系、每家 8 只的资料估计遗传力, 用自助法计算标准误时应

- (A) 把 400 只个体当作独立单位重抽样 (B) 以家系为单位整体重抽样
 (C) 只在家系内部重抽样 (D) 自助法不适用于方差组分

[答案]

3.6 ★ [单选] n 次独立伯努利试验中, 比例 p 的 Fisher 信息为

- (A) $np(1-p)$ (B) $n/[p(1-p)]$ (C) $p(1-p)/n$
 (D) $1/[np(1-p)]$

[答案]

二、判断与改错题

3.7 ★ [判断] 某标记检验 $p = 0.01$, 说明该标记与性状无关的概率为 1%。

[答案]

3.8 ★★ [判断] EM 算法每次迭代都不会降低观测资料似然, 因此只要迭代足够多次就必然收敛到全局最大似然估计。

[答案]

3.9 ★★ [判断] 在单样本正态模型中, 方差的最大似然估计 $\frac{1}{n} \sum (y_i - \bar{y})^2$ 有向下的偏差, 原因是估计均值消耗了一个自由度。 [答案]

3.10 ★★ [判断] 置换检验不依赖任何分布假设, 所以在存在群体分层的关联分析中, 把全部个体的表型随机置换即可得到正确的 p 值。 [答案]

三、填空题

3.11 ★ [填空] 回交后代 100 只中某标记基因型比为 60:40。检验 1:1 分离: 皮尔逊 $\chi^2 =$ _____, 似然比统计量 $G =$ _____, 对应 LOD = _____。 [答案]

3.12 ★★ [填空] 由 200 个等位基因拷贝估计 $\hat{p} = 0.3$, 则 $SE(\hat{p}) =$ _____; 期望杂合度 $H = 2p(1 - p)$ 的估计为 _____, 用 Delta 方法 $SE(\hat{H}) \approx$ _____。 [答案]

3.13 ★ [填空] 对 50 000 个 SNP 做关联检验, 按 Bonferroni 控制 FWER 为 0.05, 则单个检验的 p 值阈值为 _____, 即 $-\log_{10} p$ 需超过 _____。 [答案]

3.14 ★ [填空] 某缺陷检测阳性率的先验为 Beta(2, 8), 抽检 10 只中阳性 3 只, 后验分布为 _____, 后验均值为 _____, 后验众数为 _____。 [答案]

四、计算题

3.15 ★★★ [计算] 主基因的混合模型检测。某回交群体 200 只个体的表型资料见配套数据。(1) 用 EM 算法拟合两成分等方差混合正态, 报告 $\hat{\pi}, \hat{\mu}_1, \hat{\mu}_2, \hat{\sigma}$ 及标准误, 并验证似然单调上升; (2) 计算混合模型对单一正态的似然比统计量, 说明为何不能用 χ^2 分布求 p 值, 并用参数自助法求经验 p 值; (3) 若利用回交理论固定 $\pi = 0.5$, 重新检验, 并比较两种检验的功效差异。 [程序] `ch03/ex03_15_mixture_em.py` [答案]

3.16 ★★ [计算] 小样本比例的区间。在 40 只羊中检出 3 只携带者。(1) 分别计算 Wald、Wilson、似然比与 Clopper-Pearson 95% 区间; (2) 用精确二项概率计算 $n = 20, 40, 100$ 、 $p = 0.02, 0.05, 0.10, 0.20, 0.50$ 时四种区间的真实覆盖率; (3) 根据结果给出小样本稀有事件比例的区间推荐。 [程序] `ch03/ex03_16_binomial_intervals.py`

[答案]

- 3.17 ★★ [计算] 半同胞设计的功效。**总后代数固定为 1200, 组内相关 $t = h^2/4$ 。(1) 推导检测公畜方差的 F 检验功效公式;(2) 对 $h^2 = 0.1, 0.2, 0.3$, 计算不同家系大小 n 下的功效与 $SE(\hat{h}^2)$;(3) 比较功效最大与 SE 最小的 n , 并解释两者为何不同。

[程序] `ch03/ex03_17_halfsib_power.py`

[答案]

- 3.18 ★★ [计算] 万次检验的错误控制。**10 000 个独立检验中 100 个为真效应(z 均值为 4)。用模拟比较 Bonferroni、Holm、BH 与 Storey 方法在 $\alpha = 0.05$ 下的 FWER、FDR 与功效, 并解释 Bonferroni 功效仅约 0.29 的原因。[程序] `ch03/ex03_18_multiple_testing.py`

[答案]

- 3.19 ★★★ [计算] 群体结构下的置换检验。**两个亚群(各 150 只)中某 SNP 频率分别为 0.2 与 0.7, SNP 本身无效应, 但亚群表型均值相差 1 个标准差。在零假设下重复模拟, 比较全样本置换、层内置换、朴素回归 t 检验与含亚群固定效应的 t 检验的第一类错误率。[程序] `ch03/ex03_19_permutation_structure.py`

[答案]

- 3.20 ★★ [计算] 遗传力标准误的三种算法。**40 头公畜各有 12 个后代(模拟资料, 真值 $h^2 = 0.36$)。(1) 用 ANOVA 估计 h^2 ;(2) 分别用 Delta 方法、按公畜重抽样与按个体重抽样的自助法求标准误;(3) 解释按个体重抽样的结果为何错误。[程序]

`ch03/ex03_20_bootstrap_h2.py`

[答案]

- 3.21 ★ [计算] 某 SNP 效应的估计值为 3 ($SE=1$)。采用先验 $N(0, 4)$, 求后验均值、后验方差与 95% 可信区间, 并说明后验均值为何小于 3。**

[答案]

- 3.22 ★ [计算] 某疾病发病率为 10%, 按阈值模型(易感性标准正态), 阈值位于何处? 若要把发病率降到 5%, 群体易感性均值需下降多少个标准差?**

[答案]

五、推导与证明题

- 3.23 ★ [证明] 推导二项比例的最大似然估计与 Fisher 信息, 并证明对两个简单假设 θ_1 与 θ_0 , $LOD = \Lambda/(2 \ln 10)$ 。说明 LOD 3 对应的 Λ 值。**

[答案]

- 3.24 ★★ [证明] 利用 Jensen 不等式证明 EM 算法的单调上升性质, 并说明在什么情况下 EM 收敛很慢。**

[答案]

- 3.25 ★★ [证明] 在平衡单因素随机模型中证明 $E(MSB) = \sigma_w^2 + n\sigma_s^2$ 与 $E(MSW) = \sigma_w^2$, 并用 Delta 方法导出 $\hat{t} = \hat{\sigma}_s^2/(\hat{\sigma}_s^2 + \hat{\sigma}_w^2)$ 的近似方差。**

[答案]

- 3.26 ★★★ [证明] 设单个方差参数 $\theta \geq 0$, 无约束估计量渐近 $N(\theta, v)$ 。证明在 $H_0: \theta = 0$ 下, 受约束似然比统计量渐近服从 $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ 。若在零假设下另一参数不可识别, 这一结论为何失效? [答案]

六、综合分析与研究设计题

- 3.27 ★★ [综合] 某研究检验了 20 个候选基因, 报告其中一个 “ $p = 0.01$, 等位基因替代效应为 0.45 个表型标准差, 远大于文献值”, 并据此建议用于标记辅助选择。请从多重检验、赢家诅咒与重复验证三个角度评价, 并设计一个确认性研究。 [答案]
- 3.28 ★★ [综合] 一个只有 8 头公畜、每头 5 个后代的小型试验中, 研究者在 “公畜作固定效应” 与 “公畜作随机效应” 之间犹豫。分别说明两种做法回答的问题、对公畜间差异估计的收缩程度、以及对推广到新公畜的含义。 [答案]
- 3.29 ★★★ [综合] 设计一项蒙特卡洛研究, 比较 ANOVA 与 REML 两种遗传力估计在不平衡半同胞资料中的表现。要求写明: 生成模型与因素水平、重复次数的确定方法、评价指标 (偏差、均方误差、区间覆盖率、边界估计比例) 及其蒙特卡洛标准误、结果报告方式。 [答案]

3.6 参考答案与解析

一、单项选择题

- 3.1 B。最大似然估计具有不变性: 若 $\hat{\theta}$ 是 θ 的 MLE, 则 $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE。需要注意的是, 不变性不传递无偏性, $g(\hat{\theta})$ 的标准误需另用 Delta 方法或轮廓似然计算。 [题目]
- 3.2 B。单个方差参数位于边界, 零分布为 $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$, $p = \frac{1}{2}P(\chi_1^2 > 3.0) = \frac{1}{2} \times 0.083 = 0.042$ 。若同时检验母体方差与直接—母体协方差, 零分布更复杂。 [题目]
- 3.3 C。BH 控制的是 FDR, 即 $E[V/\max(R, 1)]$, 在独立时上界为 $\pi_0\alpha = \alpha m_0/m$ 。(A) 是 FWER, (B) 是每个发现的局部错误概率 (局部 FDR), 都不由 BH 保证; BH 比 Bonferroni 宽松而非保守。 [题目]
- 3.4 B。AIC = $-2\ell + 2k$, BIC = $-2\ell + k \ln n$ 。 $n \geq 8$ 时 $\ln n > 2$, BIC 惩罚更重, 倾向选择更简单的模型。 [题目]

3.5 B。家系内个体共享遗传与共同环境，不独立；独立单位是家系。按个体抽样会破坏家系结构，低估不确定性（习题 3.20）。 [题目]

3.6 B。 $\ell = x \log p + (n - x) \log(1 - p)$, $-E[\ell''] = n/p + n/(1 - p) = n/[p(1 - p)]$, 故 $\text{Var}(\hat{p}) \approx p(1 - p)/n$ 。 [题目]

二、判断与改错题

3.7 错误。 p 值是在零假设成立时观察到当前或更极端结果的概率, 即 $P(\text{数据或更极端} | H_0)$, 而不是 $P(H_0 | \text{数据})$ 。后者还依赖先验概率与备择下的数据分布, 在 GWAS 中真实关联位点比例极低时, $p = 0.01$ 的位点多数仍是假阳性。 [题目]

3.8 前半句正确, 后半句错误。EM 保证单调不减, 但可能收敛到局部极大或鞍点; 在混合模型、单倍型频率估计等多峰似然中尤为常见。应采用多个起点并比较最终似然值。 [题目]

3.9 正确。 $E[\frac{1}{n} \sum (y_i - \bar{y})^2] = \frac{n-1}{n} \sigma^2$ 。REML 通过只使用与均值正交的 $n - 1$ 个对比消除这一偏差, 这正是第 23 章 REML 的核心思想。 [题目]

3.10 错误。置换检验要求在零假设下观测可交换。存在分层时, 即使 SNP 无效应, 基因型与表型也通过亚群标签相关, 全样本置换破坏了这一联系, 零分布过窄, 假阳性率严重膨胀（习题 3.19 中为 100%）。应在亚群内部置换, 或在模型中校正结构后再置换残差。 [题目]

三、填空题

3.11 $\chi^2 = (60 - 50)^2/50 + (40 - 50)^2/50 = 4.00$; $G = 2[60 \ln 1.2 + 40 \ln 0.8] = 4.027$; $\text{LOD} = 4.027/4.605 = 0.874$ 。两种统计量都约对应 $p = 0.045$, 但单个位点 LOD 不足 1, 说明“统计显著”与“作图显著”是两个尺度。 [题目]

3.12 $\text{SE}(\hat{p}) = \sqrt{0.3 \times 0.7/200} = 0.0324$; $\hat{H} = 0.42$; $dH/dp = 2 - 4p = 0.8$, $\text{SE}(\hat{H}) \approx 0.8 \times 0.0324 = 0.0259$ 。当 p 接近 0.5 时导数趋于零, Delta 一阶近似失效, 需二阶展开。 [题目]

3.13 $0.05/50000 = 1 \times 10^{-6}$; $-\log_{10} p > 6$ 。 [题目]

3.14 后验 Beta(5,15); 均值 $5/20 = 0.25$; 众数 $(5 - 1)/(20 - 2) = 0.222$ 。先验相当于“已观察 10 只中 2 只阳性”, 后验均值介于先验均值 0.2 与样本比例 0.3 之间。 [题目]

四、计算题

3.15 (1) 多起点 EM 收敛于 $\hat{\pi} = 0.395$ (SE 0.076)、 $\hat{\mu}_1 = 23.61$ (SE 0.39)、 $\hat{\mu}_2 = 19.89$ (SE 0.29)、 $\hat{\sigma} = 1.766$, $\ell = -466.84$; 程序在每次迭代检查似然不减。标准误由观测信息矩阵 (数值 Hessian) 求得。

(2) 单一正态 $\ell_0 = -469.85$, $\Lambda = 6.03$ 。零假设 $\pi = 0$ (或 $\mu_1 = \mu_2$) 下, μ_1 或 π 不可识别, 参数位于边界, 常规渐近理论不适用。在零假设 (单一正态) 下模拟 200 组资料并重新拟合, 零分布 95% 分位数为 6.26, 经验 $p \approx 0.060$, 在 5% 水平不显著。

(3) 固定 $\pi = 0.5$ 后, 检验 $\mu_1 = \mu_2$ 是内点问题, $\Lambda = 2(-467.68 + 469.85) = 4.35$, χ_1^2 的 $p = 0.037$, 显著。利用遗传设计提供的先验结构 (回交 1:1 分离) 减少了一个自由参数并恢复了检验的正则性, 提高了功效; 但若真实分离比偏离 1:1 (偏分离或多基因背景), 固定 π 的检验也会受影响, 此时 π 自由与 $\pi = 0.5$ 的比较 ($\Lambda = 1.67$, $p = 0.20$) 可作为模型检查。本例真实效应为 1.5 个残差标准差, 200 只个体仍难以可靠识别主基因, 这正是第 7 章借助标记信息进行 QTL 作图的动机。

[题目]

3.16 (1)

方法	下限	上限	宽度
Wald	0.000	0.157	0.157
Wilson	0.026	0.199	0.173
似然比	0.019	0.183	0.164
Clopper-Pearson	0.016	0.204	0.188

Wald 下限被截断在 0, 说明对称近似失效。

(2) Wald 覆盖率在小 p 时极差 ($n = 20, p = 0.02$ 仅 0.33; $n = 100, p = 0.02$ 也只有 0.87); Wilson 大多在 0.93—0.97 之间; 似然比区间总体接近名义水平, 但在个别 (n, p) 组合下因离散性跌至 0.85 左右; Clopper-Pearson 覆盖率始终 ≥ 0.95 , 代价是区间偏宽、偏保守。

(3) 稀有事件、小样本时不应使用 Wald 区间; 一般推荐 Wilson 区间 (平均覆盖好、宽度适中); 若需保证覆盖率不低于名义水平 (如缺陷频率的保守上限), 使用 Clopper-Pearson。

[题目]

3.17 (1) $F = \text{MSB}/\text{MSW}$, 在 H_1 下 $\text{MSB}/(\sigma_w^2 + n\sigma_s^2) \sim \chi_{s-1}^2/(s-1)$, $\text{MSW}/\sigma_w^2 \sim$

$\chi^2_{s(n-1)}/[s(n-1)]$, 故 $F/\lambda \sim F_{s-1,s(n-1)}$, $\lambda = 1 + nt/(1-t)$ 。功效 = $P[F_{s-1,s(n-1)} > F_{\text{crit}}/\lambda]$ 。

(2) $h^2 = 0.2$ 时部分结果: $n = 10$ (120 头公畜) 功效 0.927、SE = 0.075; $n = 20$ (60 头) 功效 0.982、SE=0.070 (最小); $n = 60$ (20 头) 功效 0.992 (最大)、SE=0.082。 $h^2 = 0.1$ 时功效在 $n = 100$ 最大 (0.90), SE 在 $n = 40$ 最小 (0.051)。蒙特卡洛核对: $h^2 = 0.2, n = 20$ 时模拟功效 0.983, 理论 0.982。

(3) SE 最优 $n \approx 1/t$ (Robertson 准则) 权衡了“公畜数多 $\rightarrow$ 公畜间方差估计准”与“每公畜后代多 $\rightarrow$ 公畜均值准”; 检验功效则主要取决于非中心参数 λ , 增大 n 可迅速放大 λ , 只要公畜数不太少, 功效继续上升。检测“是否存在”需要强信号, 估计“有多大”需要足够多的独立公畜。设计前必须明确研究目标。 [题目]

3.18

方法	FWER	FDR	功效	平均显著数
Bonferroni	0.060	0.002	0.286	28.7
Holm	0.060	0.002	0.287	28.7
BH	0.967	0.048	0.668	70.2
Storey	0.967	0.049	0.669	70.4

(Bonferroni 的 FWER 0.060 与名义 0.05 的差异在 300 次重复的蒙特卡洛误差范围内。) Bonferroni 阈值 $p \leq 5 \times 10^{-6}$ 对应 $|z| \geq 4.565$; 真效应 z 均值为 4, 被检出概率为 $\Phi(4 - 4.565) = 0.286$, 与模拟一致。BH 几乎每次都有至少一个假阳性 (FWER 0.97), 但假阳性只占发现的约 5%, 功效提高一倍以上。 $\pi_0 = 0.99$ 接近 1, Storey 方法相对 BH 几乎没有收益; 当真效应比例较大时差异才明显。在 GWAS 发现阶段控制 FDR、在确认阶段控制 FWER 是常见的分工。 [题目]

3.19 零假设下 300 个数据集的拒绝率: 全样本置换 1.000, 朴素 t 检验 1.000, 层内置换 0.037, 含亚群固定效应的 t 检验 0.047 (蒙特卡洛标准误约 0.013)。两亚群 SNP 频率差 0.5、表型差 1 个标准差, 合并样本中 SNP 与表型存在很强的“伪关联”。全样本置换的零分布对应“SNP 与表型完全无关”, 而真实零假设是“给定亚群后无关”。层内置换保持了亚群—表型与亚群—基因型的联系, 只打乱亚群内部的对应, 零分布正确。第 8 章的主成分校正与混合模型校正, 是在连续的“亚群”(亲缘)结构上实现同一思想。 [题目]

3.20 (1) $MSB=1.701$, $MSW=0.981$, $\hat{h}^2 = 0.231$ (真值 0.36, 体现了单个资料的抽样波动)。

(2) Delta 法 $SE=0.121$; 按公畜重抽样 $SE=0.118$, 百分位 95% 区间 $(-0.005, 0.460)$; 按个体重抽样 $SE=0.079$, 且自助均值约为 0。

(3) 个体重抽样把不同公畜的后代随机混合成“伪家系”, 伪家系之间不存在真实的遗传差异, 因此自助估计以 0 为中心, 其离散度也不反映原估计量的抽样变异。正确的自助单位是公畜家系; 若资料不平衡或存在多层结构(公畜—母畜—后代), 应在最高的独立层次抽样。 [题目]

3.21 后验精度 $= 1/4 + 1/1 = 1.25$, 后验方差 0.8; 后验均值 $= 0.8 \times (0/4 + 3/1) = 2.4$; 95% 可信区间 $2.4 \pm 1.96\sqrt{0.8} = (0.65, 4.15)$ 。后验均值是先验均值 0 与观测 3 按精度加权的平均, 向 0 收缩了 20%。收缩程度取决于先验方差与观测精度之比, 这正是 BLUP 与贝叶斯标记效应估计(第 21、27 章)中“收缩”的含义。 [题目]

3.22 发病率 10% 对应阈值 $z_{0.10} = 1.2816$; 发病率 5% 对应 1.6449。易感性均值需下降 $1.6449 - 1.2816 = 0.363$ 个标准差。由于正态分布尾部的非线性, 从 10% 降到 5% 所需的位移, 比从 50% 降到 45% 所需的位移(0.126)大得多。 [题目]

五、推导与证明题

3.23 $\ell(p) = x \ln p + (n-x) \ln(1-p)$, $\ell'(p) = x/p - (n-x)/(1-p) = 0 \Rightarrow \hat{p} = x/n$; $-\ell'' = x/p^2 + (n-x)/(1-p)^2$, 期望为 $n/[p(1-p)]$ 。对简单假设, $\Lambda = 2 \ln(L_1/L_0)$, $LOD = \log_{10}(L_1/L_0) = \ln(L_1/L_0)/\ln 10 = \Lambda/(2 \ln 10)$ 。LOD 3 对应 $\Lambda = 6 \ln 10 = 13.82$, 按 χ_1^2 约为 $p = 2 \times 10^{-4}$ 。 [题目]

3.24 证明见推导 3.1。EM 的收敛速率由缺失信息比例 $\mathcal{I}_{\text{缺失}}/\mathcal{I}_{\text{完整}}$ 的最大特征值决定: 比例接近 1 时收敛极慢。典型情形是: 混合模型中两成分重叠严重、单倍型估计中双杂合子比例很大、方差组分估计中某个方差接近零或资料对其信息很少。此时可改用 Newton 类方法、平均信息算法(第 23 章)或加速 EM。 [题目]

3.25 期望均方见推导 3.3。令 $g(a, b) = \frac{(a-b)/n}{(a-b)/n + b} = \frac{a-b}{a + (n-1)b}$, $a = MSB$, $b = MSW$ 。偏导数 $g_a = \frac{nb}{[a + (n-1)b]^2}$, $g_b = -\frac{na}{[a + (n-1)b]^2}$ 。正态下 $\text{Var}(a) \approx 2a^2/(s-1)$, $\text{Var}(b) \approx 2b^2/[s(n-1)]$, 二者独立。代入 $\text{Var}(\hat{t}) \approx g_a^2 \text{Var}(a) + g_b^2 \text{Var}(b)$, 并利用 $a/b = 1 + nt/(1-t)$ 化简, 主项即为 $\frac{2(1-t)^2[1 + (n-1)t]^2}{n(n-1)(s-1)}$ (推导中把 $s(n-1)$ 近似为 $(s-1)(n-1)$ 的高阶小项已忽略)。 [题目]

3.26 在 H_0 下 $\tilde{\theta} \approx N(0, v)$ 。受约束估计 $\hat{\theta} = \max(\tilde{\theta}, 0)$ 。局部二次近似 $\ell(\theta) \approx \ell(\tilde{\theta}) - (\theta - \tilde{\theta})^2/(2v)$: 若 $\tilde{\theta} > 0$, $\Lambda = \tilde{\theta}^2/v \sim \chi_1^2$; 若 $\tilde{\theta} \leq 0$, $\hat{\theta} = 0$, $\Lambda = 0$ 。两种情形各占概

率 $1/2$, 得混合分布。若零假设下另一参数 (如混合模型中 $\pi = 0$ 时的 μ_1) 不可识别, 似然在零假设下对该参数是平的, 局部二次近似不存在, Λ 的分布等价于对一个随机过程取上确界, 通常大于混合 χ^2 (Davies 问题), 需用模拟或理论上界处理——这也是第 7 章全基因组扫描阈值必须靠置换或理论近似确定的原因。【题目】

六、综合分析与研究设计题

3.27 多重检验: 20 个候选基因在 $\alpha = 0.05$ 下, 即使全部无效, 期望也有 1 个“显著”; Bonferroni 阈值为 0.0025, $p = 0.01$ 不显著。**赢家诅咒:** 被选中的往往是估计值偶然偏大的那个, 效应 0.45 个标准差远大于文献值, 很可能是高估; 若统计功效低, 显著结果的效应估计偏高更严重 (第 7 章 Beavis 效应)。**重复验证:** 确认性研究应 (1) 预先登记唯一的目标基因与效应方向; (2) 在独立群体中检验, 样本量按文献效应 (而非 0.45) 计算功效, 例如效应 0.10 标准差、单尾检验 80% 功效需约 $n \approx (1.645 + 0.842)^2 / (0.01 \times 2pq)$ 只; (3) 分析时校正群体结构与亲缘; (4) 报告效应估计及其区间, 而不仅是显著与否; (5) 若用于选择, 还需评估该效应在目标群体中是否稳定 (第 8、29 章)。【题目】

3.28 固定效应: 回答“这 8 头公畜彼此相比如何”, 每头公畜的效应估计即其后代均值离差, 不收缩; 无法推广到其他公畜, 也不能估计公畜方差。**随机效应:** 把 8 头公畜视为来自公畜群体的随机样本, 回答“公畜群体的方差多大”与“对每头公畜的最佳线性预测”; 预测值向群体均值收缩, 收缩系数 $n\sigma_s^2 / (n\sigma_s^2 + \sigma_w^2)$, 后代少时收缩强。只有 8 头公畜时, 公畜方差的估计非常不精确 (ANOVA 估计可能为负), 随机效应预测的收缩程度本身也不确定。若目标是选种, 应采用随机效应 (BLUP) 以降低排序误差; 若目标是比较这 8 头公畜在本试验中的表现, 可用固定效应; 若想推广, 应增加公畜数而非每公畜后代数。【题目】

3.29 生成模型: $y_{ij} = \mu + s_i + e_{ij}$, 因素水平: $h^2 \in \{0.1, 0.3, 0.5\}$; 公畜数 $s \in \{20, 50, 100\}$; 不平衡程度 (家系大小服从均值 10 的泊松或几何分布)。**重复次数:** 若关注偏差的蒙特卡洛标准误不超过 0.005, 且估计量 SD 约 0.1, 则需 $R \geq (0.1/0.005)^2 = 400$ 次, 取 1000 次。**评价指标:** 偏差 $\bar{h}^2 - h^2$ (MCSE = $SD/\sqrt{R}$); 均方误差 (MCSE 用 $SD[(\hat{h}^2 - h^2)^2]/\sqrt{R}$); 95% 区间覆盖率 (MCSE = $\sqrt{c(1-c)/R}$); 边界估计 ($\hat{\sigma}_s^2 \leq 0$) 比例; 不收敛比例。**报告:** 每种设计与方法的指标表与 MCSE, 同一模拟资料上两种方法的成对差异, 边界样本不能删除, 并说明随机数种子与软件版本, 保证可复算。【题目】

第二篇

群体遗传结构与遗传图谱

位点在群体中怎样分布、怎样变化。

本篇习题训练：Hardy-Weinberg 平衡与进化力量、单倍型与连锁不平衡、重组与连锁图谱。

单基因座群体模型与等位基因频率的演变

4.1 本章导学

学习目标

1. 熟练换算基因型频率与等位基因频率，掌握 Hardy–Weinberg 定律的条件、推导与多等位基因、性连锁情形的推广。

2. 能用卡方、似然比与精确检验检验 Hardy–Weinberg 平衡，并解释偏离的多种可能原因。

3. 理解近交、同型交配与群体结构对基因型频率的不同影响，掌握 F 与 F_{ST} 的计算。

4. 能推导突变、迁移与选择作用下的频率变化，理解显性程度如何决定选择动态与平衡状态。

5. 掌握遗传漂变的 Wright–Fisher 模型、杂合度衰减与固定概率，了解溯祖理论与 Watterson 估计量。

6. 能计算多等位基因标记的杂合度、PIC 与亲子排除概率，并评估标记组合的信息量。

重点与难点

重点：Hardy–Weinberg 定律与检验；近交系数 F 对基因型频率的作用；选择下的 Δq ；漂变下杂合度的衰减；突变—选择平衡。

难点：HWE 偏离不能唯一指示原因；近交改变基因型频率而不改变等位基因频率；显性与隐性有利基因“起步”和“收尾”速度相反；Kimura 固定概率公式的参数化依赖于适合度的写法；溯祖时间的大部分来自最后两个谱系的合并。

本章是第 5 章连锁不平衡、第 9 章基因型值与平均效应、第 19 章漂变与近交的基础。学习时要把“频率”始终放在“哪个群体、哪一代、哪一性别”的背景中理解。

4.2 知识结构图




图 4.1 第 4 章知识结构图

右侧三支描述“给定一代的群体结构”，左侧四支描述“频率如何随时间变化、怎样由分子资料估计”。

4.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
HWE	$P_{AA} = p^2, P_{Aa} = 2pq, P_{aa} = q^2$	大群体、随机交配、无选择突变迁移、两性频率相同
近交下基因型频率	$p^2 + Fpq, 2pq(1 - F), q^2 + Fpq$	等位基因频率不变
Wahlund 效应	合并群体杂合子缺乏 $= 2\sigma_p^2$, $F_{ST} = \sigma_p^2 / (\bar{p}\bar{q})$	亚群内部 HWE
一维迁移	$q_t - Q = (1 - m)^t (q_0 - Q)$	单向迁入，迁入群频率 Q
选择	$\Delta q = \frac{pq}{2\bar{w}} \frac{d\bar{w}}{dq}$	适合度为常数
隐性致死淘汰	$q_t = \frac{q_0}{1 + tq_0}, t = \frac{1}{q_t} - \frac{1}{q_0}$	淘汰全部隐性纯合子
超显性平衡	$\hat{q} = s_1 / (s_1 + s_2), \bar{w} = 1 - s_1 s_2 / (s_1 + s_2)$	$w_{11} = 1 - s_1, w_{22} = 1 - s_2$

概念	公式或定义	成立条件与提示
突变—选择平衡	隐性: $\hat{q} \approx \sqrt{\mu/s}$; 部分显性: $\hat{q} \approx \mu/(hs)$	$\mu \ll s$
漂变	$H_t = H_0(1 - \frac{1}{2N})^t$; $F_t = 1 - (1 - \frac{1}{2N})^t$	理想群体
固定概率	中性 $u = q_0$; 加性选择 (纯合子 优势 s) $u = \frac{1 - e^{-2Ns q_0}}{1 - e^{-2Ns}}$	扩散近似、 $N_e = N$
溯祖	$E(T_{\text{MRCA}}) = 4N(1 - 1/n)$; $\theta_W = S/a_n$	中性、恒定群体
标记信息	$H = 1 - \sum p_i^2$; $\text{PIC} = H - \sum_{i < j} 2p_i^2 p_j^2$	等位基因独立

4.4 补充内容与公式推导

推导 4.1 选择下频率变化的梯度形式 (Wright 公式)

设三种基因型适合度 w_{11}, w_{12}, w_{22} , 平均适合度 $\bar{w} = p^2 w_{11} + 2pq w_{12} + q^2 w_{22}$ 。下一代 A_2 的频率为 $q' = (pq w_{12} + q^2 w_{22})/\bar{w}$, 于是

$$\Delta q = \frac{pq w_{12} + q^2 w_{22} - q \bar{w}}{\bar{w}} = \frac{pq[p(w_{12} - w_{11}) + q(w_{22} - w_{12})]}{\bar{w}}.$$

另一方面, 以 $p = 1 - q$ 代入并对 q 求导:

$$\frac{d\bar{w}}{dq} = 2[p(w_{12} - w_{11}) + q(w_{22} - w_{12})],$$

所以 $\Delta q = \frac{pq}{2\bar{w}} \frac{d\bar{w}}{dq}$ 。这个梯度形式说明: 在常数适合度下选择使频率沿平均适合度上升的方向变化, $\Delta q = 0$ 的内部点即 $\bar{w}$ 的极值点——超显性时是极大值 (稳定平衡), 低显性时是极小值 (不稳定平衡)。 pq 因子说明频率接近 0 或 1 时变化极慢, 这正是隐性有利基因“起步难”、显性有利基因“收尾难”的根源。

推导 4.2 漂变下近交与杂合度的递推

理想群体中, 第 t 代两个随机配子的同祖同源概率记为 F_t 。两配子来自上一代同一个基因拷贝的概率为 $1/(2N)$, 此时必然同祖; 否则以概率 $1 - 1/(2N)$ 来自不同拷贝, 其同祖概率为 F_{t-1} 。故

$$F_t = \frac{1}{2N} + \left(1 - \frac{1}{2N}\right) F_{t-1}, \quad 1 - F_t = \left(1 - \frac{1}{2N}\right) (1 - F_{t-1}).$$

令 $P_t = 1 - F_t$ 为“泛化杂合度”，得 $H_t = H_0(1 - \frac{1}{2N})^t \approx H_0 e^{-t/(2N)}$ 。同一结论也可由溯祖得到：两个拷贝向上追溯 t 代仍未合并的概率为 $(1 - \frac{1}{2N})^t$ 。若群体大小随世代变化，以调和平均代替 N ；若性别比失衡，以 $N_e = 4N_m N_f / (N_m + N_f)$ 代替（第19章）。

推导 4.3 突变—选择平衡

设有害等位基因 a 的频率 q ，正向突变率 μ ($A \rightarrow a$)，适合度 $1, 1 - hs, 1 - s$ 。 q 很小时，选择每代去除的 a 约为 $\Delta q_{\text{sel}} \approx -q[hs + (1 - 2h)sq]$ （忽略高阶项），突变增加 $\Delta q_{\text{mut}} \approx \mu(1 - q) \approx \mu$ 。平衡时二者相抵：

(1) 完全隐性 $h = 0$: $sq^2 \approx \mu$, $\hat{q} = \sqrt{\mu/s}$;

(2) 部分显性 $h \gg \sqrt{\mu/s}$: $hsq \approx \mu$, $\hat{q} = \mu/(hs)$ 。

例如 $\mu = 10^{-5}$ 、隐性致死 $s = 1$ 时 $\hat{q} \approx 0.0032$ ，患病率约 10^{-5} ；若杂合子仅有 1% 的适合度损失 ($h = 0.01$)， $\hat{q} = 0.001$ ，频率反而低三倍。隐性有害基因主要“藏”在杂合子中，这是近交暴露隐性缺陷（第19章近交衰退）的群体遗传基础。

易错辨析

- HWE 检验显著不等于存在选择：分型错误、无效等位基因、近交、群体结构、取样偏差都会造成偏离。
- 近交不改变等位基因频率，只把杂合子“重新分配”为纯合子；漂变改变频率，但不改变其期望。
- 一代随机交配即达到 HWE 仅对常染色体、两性频率相同时成立；两性频率不同时需两代，性连锁位点则振荡收敛。
- Kimura 公式的指数是 $4N_e s$ 还是 $2N_e s$ 取决于 s 的定义（杂合子优势还是纯合子优势）。
- F_{ST} 很小也可能对关联分析造成严重混杂：混杂取决于亚群频率差与表型差的乘积。

4.5 习题

一、单项选择题

4.1 ★ [单选] 某常染色体位点在公畜群中频率 $p_m = 0.8$, 母畜群中 $p_f = 0.4$, 随机交配。第一代后代的基因型频率是否满足 HWE?

- (A) 满足, $p = 0.6$
 (B) 不满足, 杂合子频率为 0.56, 高于 $2\bar{p}\bar{q} = 0.48$
 (C) 不满足, 杂合子频率低于 0.48 (D) 需要无穷多代才能平衡

[答案]

4.2 ★★ [单选] X 连锁位点上雌雄频率之差 $q_f - q_m$ 在随机交配下每代

- (A) 保持不变 (B) 变为原来的 $-1/2$ 倍
 (C) 变为原来的 $1/2$ 倍 (D) 立即变为零

[答案]

4.3 ★ [单选] 某群体近交系数 $F = 0.25$, $p = 0.5$ 。杂合子频率为

- (A) 0.50 (B) 0.375 (C) 0.25 (D) 0.125

[答案]

4.4 ★★ [单选] 隐性致死等位基因的突变率为 4×10^{-6} , 在大群体中平衡频率约为

- (A) 4×10^{-6} (B) 2×10^{-3} (C) 4×10^{-3} (D) 2×10^{-6}

[答案]

4.5 ★★ [单选] 在大小为 N 的二倍体理想群体中, 随机抽取的两个基因拷贝追溯到共同祖先的期望代数为

- (A) N (B) $2N$ (C) $4N$ (D) $N/2$

[答案]

4.6 ★ [单选] 两个等频等位基因的 SNP, 其 PIC 为

- (A) 0.500 (B) 0.375 (C) 0.250 (D) 0.188

[答案]

二、判断与改错题

4.7 ★ [判断] 某 SNP 在样本中显著偏离 HWE, 说明该位点受到自然选择。

[答案]

4.8 ★ [判断] 遗传漂变使等位基因频率的期望值逐代向 0 或 1 移动。

[答案]

4.9 ★★ [判断] 单向迁移下, $q_t - Q = (1 - m)^t(q_0 - Q)$; 只要 $m > 0$, 本地群体频率最终必与迁入群体相同。 [答案]

4.10 ★★ [判断] 近交使隐性纯合子频率升高, 因此近交提高了隐性等位基因的频率。

[答案]

三、填空题

4.11 ★ [填空] 某微卫星有三个等位基因, 频率为 0.5、0.3、0.2。可能的基因型有_____种, 期望杂合度为_____。 [答案]

4.12 ★★ [填空] 10 条序列 (长 1000 bp) 中有 24 个分离位点。 $a_{10} =$ _____, Watterson 估计 $\theta_W =$ _____ (每序列), 每位点 $\theta =$ _____。 [答案]

4.13 ★ [填空] 某隐性致死基因当前频率 0.2。淘汰全部患病个体一代后频率为_____; 降到 0.05 共需_____代。 [答案]

4.14 ★★ [填空] 岛屿模型中每个亚群 $N = 50$, 每代迁移率 $m = 0.01$, 平衡时 $F_{ST} \approx$ _____。 [答案]

四、计算题

4.15 ★★ [计算] HWE 的精确检验。三个样本的基因型计数 (稀有纯合子/杂合子/常见纯合子) 为: 甲 3/4/43; 乙 30/40/30; 丙 10/70/20。(1) 分别计算 $\hat{F}$ 与皮尔逊卡方, 并验证 $X^2 = N\hat{F}^2$; (2) 用条件精确检验求双侧与单侧 p 值; (3) 比较样本甲的两种 p 值, 说明卡方近似失真的原因。 [程序] `ch04/ex04_15_hwe_exact.py` [答案]

4.16 ★★ [计算] 标记信息量与亲子鉴定。五个微卫星位点的等位基因频率见配套数据 (如 MS1 为 0.40, 0.25, 0.20, 0.15)。(1) 计算各位点的 H 、PIC 与单亲已知时的排除概率, 并用模拟核对; (2) 计算五位点组合排除概率; (3) 若改用 MAF 为 0.4 的独立 SNP, 需要多少个才能使组合排除概率达到 0.999? [程序] `ch04/ex04_16_marker_information.py`

[答案]

- 4.17 ★★ [计算] 显性程度与选择动态。**有利等位基因纯合子的选择优势 $s = 0.05$ ，初始频率 0.01。(1) 分别计算加性、显性有利、隐性有利三种情形频率升至 0.5 与 0.99 所需代数；(2) 用连续时间近似核对加性情形；(3) 超显性 $s_1 = 0.10$ 、 $s_2 = 0.30$ 时求平衡频率与遗传负荷。 [程序] `ch04/ex04_17_selection_dynamics.py` [答案]
- 4.18 ★★ [计算] Wright-Fisher 漂变。** $N = 50$ ， $q_0 = 0.1$ 。(1) 模拟并核对第 10、30、60 代的期望杂合度；(2) 估计中性下的固定概率、条件固定时间与条件丢失时间，并与扩散理论比较；(3) 在加性选择（纯合子优势 $s = 0.01, 0.02, 0.05$ ）下比较模拟固定概率与 Kimura 公式，注意参数化。 [程序] `ch04/ex04_18_wright_fisher.py` [答案]
- 4.19 ★★ [计算] 溯祖与 Watterson 估计量。**样本 $n = 10$ 个基因拷贝， $N = 500$ ，每位点突变率 $\mu = 5 \times 10^{-4}$ 。(1) 模拟 T_{MRCA} 与总枝长并与理论期望比较；(2) 在无限位点模型下核对 $E(S)$ 、 $\text{Var}(S)$ 与 θ_w 的无偏性；(3) 最后两个谱系合并的阶段平均占 T_{MRCA} 的多少？这对“增加样本量能否显著改善 θ 估计”有何启示？ [程序] `ch04/ex04_19_coalescent.py` [答案]
- 4.20 ★★ [计算] 多位点估计群体近交系数。**30 只动物在 12 个位点的基因型计数见配套数据。(1) 计算各位点 $\hat{F}_j$ （期望杂合度作小样本校正）；(2) 比较简单平均、比值合并与联合最大似然三种合并估计，并以位点为单位自助求 SE；(3) 解释为什么低杂合度位点会使简单平均不稳定。 [程序] `ch04/ex04_20_multilocus_F.py` [答案]
- 4.21 ★ [计算] 三个等大亚群某位点频率分别为 0.1、0.3、0.5，各亚群内部 HWE。求合并群体的期望杂合度、实际杂合度、杂合子缺乏量与 F_{ST} 。** [答案]
- 4.22 ★ [计算] 某 X 连锁隐性缺陷在公羔中的发病率为 4%。求雌性中的发病率、携带者频率，以及患病雄性与患病雌性的比值。** [答案]

五、推导与证明题

- 4.23 ★ [证明] 由配子随机结合推导常染色体位点的 Hardy-Weinberg 定律，并推广到 k 个等位基因；说明为什么平衡在一代随机交配后即达到。** [答案]
- 4.24 ★★ [证明] 推导常数适合度下 Δq 的表达式，并证明 $\Delta q = \frac{pq}{2\bar{w}} \frac{d\bar{w}}{dq}$ ；据此说明超显性平衡稳定、低显性平衡不稳定。** [答案]

4.25 ★★ [证明] 推导理想群体中 $F_t = \frac{1}{2N} + \left(1 - \frac{1}{2N}\right) F_{t-1}$, 并由此得到杂合度的衰减公式; 若群体大小在三代中依次为 N_1, N_2, N_3 , 证明有效大小为调和平均数。[答案]

4.26 ★★★ [证明] 在适合度 $1, 1 - hs, 1 - s$ 与正向突变率 μ 下, 推导完全隐性与部分显性两种情形的平衡频率近似式, 并讨论 h 的临界数量级。[答案]

六、综合分析与研究设计题

4.27 ★★ [综合] 某地方品种保种场的芯片分型资料中, 约 8% 的 SNP 在 $p < 0.001$ 下偏离 HWE, 且多为杂合子缺乏。设计一套分析流程, 区分分型错误、无效等位基因、近交、群体结构与选择五种解释, 说明每种解释的特征性证据。[答案]

4.28 ★★★ [综合] 某品种发现一个隐性致死缺陷, 携带者频率约 10%。比较三种管理策略: (1) 只淘汰患病个体; (2) 淘汰所有已知携带者; (3) 允许携带者参与配种但禁止携带者 $\times$ 携带者配对, 并逐步降低携带者使用比例。从缺陷频率下降速度、遗传多样性损失与经济成本三方面分析, 并给出你的推荐。[答案]

4.29 ★★★ [综合] 某品种 20 年间保存了两批样本 (相隔约 5 个世代), 需要判断一个候选位点的频率变化 ($0.30 \rightarrow 0.55$) 是选择还是漂变造成的。设计一个利用全基因组中性 SNP 作为参照分布的检验方案, 并说明有效群体大小在其中的作用。[答案]

4.6 参考答案与解析

一、单项选择题

4.1 B。后代基因型频率: $AA = 0.8 \times 0.4 = 0.32$, $Aa = 0.8 \times 0.6 + 0.2 \times 0.4 = 0.56$, $aa = 0.2 \times 0.6 = 0.12$, 后代 $\bar{p} = 0.6$, $2\bar{p}\bar{q} = 0.48 < 0.56$, 杂合子过剩。第二代随机交配后即达到 HWE。杂合子过剩量为 $(p_m - p_f)^2/2 = 0.08$ 。[题目]

4.2 B。雄性从母亲获得唯一的 X, $q'_m = q_f$; 雌性 $q'_f = (q_m + q_f)/2$ 。故 $q'_f - q'_m = (q_m - q_f)/2 = -\frac{1}{2}(q_f - q_m)$, 差值每代减半并变号, 振荡收敛到 $\bar{q} = (2q_f + q_m)/3$ 。[题目]

4.3 B。 $2pq(1 - F) = 0.5 \times 0.75 = 0.375$ 。[题目]

4.4 B。 $\hat{q} \approx \sqrt{\mu/s} = \sqrt{4 \times 10^{-6}} = 2 \times 10^{-3}$ 。[题目]

4.5 B。每代两拷贝合并概率 $1/(2N)$ ，等待时间服从几何分布，期望 $2N$ 代。注意： n 个拷贝的 $E(T_{\text{MRCA}}) = 4N(1 - 1/n)$ ， $n = 2$ 时为 $2N$ 。 [题目]

4.6 B。 $H = 0.5$ ， $\text{PIC} = 0.5 - 2 \times 0.25 \times 0.25 = 0.375$ 。 [题目]

二、判断与改错题

4.7 错误。选择只是可能原因之一，而且大多数选择作用于成年个体适合度，未必造成成体样本中的 HWE 偏离。实践中更常见的是分型错误（杂合子判为纯合子）、无效等位基因、近交、群体分层、样本中混有重复个体等。应先排除技术原因。 [题目]

4.8 错误。漂变下 $E(q_{t+1} | q_t) = q_t$ ，频率的期望保持不变；变化的是方差 $\text{Var}(q_t) = q_0 p_0 [1 - (1 - \frac{1}{2N})^t]$ 。单个群体终将固定或丢失，但固定于 1 的概率恰为 q_0 。 [题目]

4.9 基本正确，需补充条件。该式在“单向迁入、迁入群频率恒定、无漂变与选择”的确定性模型下成立， $(1 - m)^t \rightarrow 0$ 。有限群体中漂变与迁移平衡，本地频率围绕 Q 波动 ($F_{ST} \approx 1/(1 + 4Nm)$)；若存在本地选择，平衡点会偏离 Q 。 [题目]

4.10 错误。近交下基因型频率为 $q^2 + Fpq$ 等，但等位基因频率 $q = (q^2 + Fpq) + \frac{1}{2} \cdot 2pq(1 - F) = q$ 不变。隐性纯合子增多暴露了隐性等位基因，若再对其选择，频率才会下降——这是“近交清除”（purging）的机制。 [题目]

三、填空题

4.11 6 种基因型 $(k(k + 1)/2)$ ； $H = 1 - (0.25 + 0.09 + 0.04) = 0.62$ 。 [题目]

4.12 $a_{10} = \sum_{i=1}^9 1/i = 2.829$ ； $\theta_W = 24/2.829 = 8.48$ ；每位点 $\theta = 0.00848$ 。 [题目]

4.13 $q_1 = 0.2/(1 + 0.2) = 0.1667$ ； $t = 1/0.05 - 1/0.2 = 15$ 代。 [题目]

4.14 $F_{ST} \approx 1/(1 + 4 \times 50 \times 0.01) = 1/3$ 。每代仅有 0.5 个迁入个体，亚群分化已相当大。 [题目]

四、计算题

4.15 (1)

样本	$\hat{F}$	X^2	$N\hat{F}^2$	卡方 p
甲 3/4/43	0.556	15.43	15.43	8.6×10^{-5}
乙 30/40/30	0.200	4.00	4.00	0.046

样本	$\hat{F}$	X^2	$N\hat{F}^2$	卡方 p
丙 10/70/20	-0.414	17.15	17.15	3.5×10^{-5}

(2) 精确检验：甲双侧 $p = 0.0033$ （杂合子缺乏单侧 0.0033）；乙双侧 $p = 0.047$ ，缺乏单侧 0.032；丙双侧 $p = 4.7 \times 10^{-5}$ ，过剩单侧 3.7×10^{-5} 。

(3) 甲的稀有纯合子期望频数仅 0.5，卡方近似要求各期望频数不太小，此处单个格子贡献了 12.5， p 值被夸大约 40 倍。精确检验以等位基因计数为条件、直接计算杂合子数的离散分布，在稀有等位基因与小样本下仍然有效。芯片质控中对 MAF 很低的 SNP 必须使用精确检验，否则会错误剔除大量位点。乙的两种 p 值接近，说明期望频数足够大时卡方近似可靠。

[题目]

4.16 (1)

位点	等位基因数	H	PIC	P_{ex} (公式)	P_{ex} (模拟)
MS1	4	0.715	0.665	0.465	0.465
MS2	5	0.760	0.720	0.535	0.539
MS3	3	0.620	0.548	0.336	0.337
MS4	4	0.750	0.703	0.504	0.504
MS5	5	0.585	0.544	0.360	0.360
SNP (0.5/0.5)	2	0.500	0.375	0.188	0.189

(2) 组合排除概率 $= 1 - \prod(1 - P_{ex,k}) = 0.9475$ ，五个微卫星尚不足以可靠地进行亲子鉴定。

(3) MAF 0.4 的 SNP 单位点排除概率 0.182，需 $[\ln 0.001 / \ln(1 - 0.182)] = 35$ 个独立 SNP。虽然单个 SNP 信息远低于微卫星，但 SNP 分型成本低、自动化程度高、错误率低，实际亲子鉴定常用 100—200 个 SNP；还需考虑位点间连锁（不独立）与分型错误率，实际所需数目更多。MS5 等位基因虽有 5 个，但频率极不均匀，信息量反而低于 3 个等位基因的 MS3 附近水平，说明“等位基因数”不是信息量的充分度量。

[题目]

4.17 (1)

情形	0.01→0.5	0.01→0.99
加性 $h = 0.5$	187	377
显性有利 $h = 1$	115	2265

情形	0.01→0.5	0.01→0.99
隐性有利 $h = 0$	2057	2171

(2) 加性时 $\Delta q \approx \frac{s}{2}q(1-q)$, 积分得 $t \approx \frac{2}{s} \ln \frac{q_1(1-q_0)}{q_0(1-q_1)} = 367.6$ 代, 与离散迭代 377 代接近。

(3) $\hat{q} = 0.10/0.40 = 0.25$; $\bar{w} = 1 - 0.10 \times 0.30/0.40 = 0.925$, 遗传负荷 0.075。迭代 2000 代收敛到 0.2500。显性有利基因稀有时, 杂合子即可被选择, 起步快; 但接近固定时, 残存的有害等位基因主要存在于杂合子中而不被选择, 收尾极慢。隐性有利基因正好相反。这对育种的启示: 用表型选择清除隐性有害基因或固定显性有利基因都极慢, 需借助基因型检测。 [题目]

4.18 (1) 第 10、30、60 代杂合度模拟值 0.1630、0.1338、0.0998, 理论值 0.1628、0.1331、0.0985。

(2) 中性固定概率模拟 0.101 (理论 0.1); 条件固定时间 185.7 代 (理论 $-4N(1-q_0) \ln(1-q_0)/q_0 = 189.6$); 条件丢失时间 49.7 代 (理论 $-4Nq_0 \ln q_0/(1-q_0) = 51.2$)。稀有等位基因大多很快丢失, 偶尔固定则需很长时间。

(3) 适合度为 $1, 1+s/2, 1+s$ 时, 每个等位基因拷贝的选择优势为 $s/2$, Kimura 公式的指数应为 $4N(s/2) = 2Ns$:

s	$2Ns$	模拟 u	Kimura u
0.01	1	0.150	0.151
0.02	2	0.208	0.210
0.05	5	0.391	0.396

若误用 $4Ns$, 会得到 0.21、0.34、0.63 的错误结果。 $2N_e s$ 量级为 1 时, 选择与漂变势均力敌; 即使 $s = 0.05$, 固定概率也只有约 0.4——小群体中有利突变也很可能丢失。 [题目]

4.19 (1) $E(T_{\text{MRCA}}) = 4N(1 - 1/n) = 1800$ 代 (模拟 1797.7); $E(L) = 4Na_n = 5657.9$ (模拟 5652.0)。

(2) $\theta = 4N\mu = 1$; $E(S) = \theta a_n = 2.829$ (模拟 2.825); $\text{Var}(S) = \theta a_n + \theta^2 b_n = 4.369$ (模拟 4.380); $E(\theta_W) = 0.9985$, 无偏。

(3) 最后两个谱系合并阶段 $E(T_2) = 2N$, 占 T_{MRCA} 的 $1/[2(1 - 1/n)] = 55.6\%$ 。增加样本量只会在树的“顶端”增加大量短枝, a_n 只按 $\ln n$ 增长, $\text{Var}(\theta_W)$ 中 $\theta^2 b_n/a_n^2$

一项随 n 下降很慢 ($b_n \rightarrow \pi^2/6$)。要显著提高 θ 估计精度, 应增加独立 (不连锁) 位点数, 而不是同一位点的样本量。 [题目]

4.20 (1) 各位点 $\hat{F}_j$ 介于 -0.136 与 0.636 之间, 位点 7 ($\hat{p} = 0.10$, $H_{\text{exp}} = 0.183$) 给出 0.636 , 位点 10 ($\hat{p} = 0.033$) 给出 -0.017 。

(2) 简单平均 0.203 (自助 SE 0.064); 比值合并 0.204 (SE 0.060); 联合最大似然 0.192 ; 真值 0.15 。三种估计相差不大, 但比值合并的 SE 较小。

(3) $\hat{F}_j = 1 - H_{\text{obs}}/H_{\text{exp}}$ 的抽样方差约为 $1/(nH_{\text{exp}})$ 量级: H_{exp} 越小, 一个杂合子的增减引起的 $\hat{F}_j$ 变化越大。简单平均给所有位点等权, 比值合并相当于以 $H_{\text{exp},j}$ 加权, 自动降低了低信息位点的权重。在全基因组资料中应剔除 MAF 极低的位点或采用比值合并估计。 [题目]

4.21 $\bar{p} = 0.3$, 合并期望杂合度 $2\bar{p}\bar{q} = 0.42$; 实际杂合度为各亚群 $2p_iq_i$ 的平均: $(0.18 + 0.42 + 0.50)/3 = 0.367$; 缺乏量 $0.053 = 2\sigma_p^2$ ($\sigma_p^2 = 0.0267$); $F_{ST} = 0.0267/0.21 = 0.127$ 。 [题目]

4.22 雄性半合子, 发病率即 $q = 0.04$; 雌性发病率 $q^2 = 0.0016$; 携带者 $2pq = 0.0768$; 患病雄/雌比 $= q/q^2 = 25$ 。隐性 X 连锁缺陷几乎只见于雄性, 而大量携带者是表型正常的雌性。 [题目]

五、推导与证明题

4.23 设亲代配子中 A 的频率为 p (两性相同)。随机结合时合子 AA 的概率为 $p \cdot p$, Aa 为 $pq + qp = 2pq$, aa 为 q^2 。后代 A 的频率 $p^2 + pq = p$, 因此下一代配子频率不变, 基因型频率保持 $p^2, 2pq, q^2$ ——一代即达平衡, 原因是基因型频率完全由上一代配子频率决定, 而配子频率在无选择、突变、迁移、漂变时不变。 k 个等位基因时, $P(A_iA_i) = p_i^2$, $P(A_iA_j) = 2p_ip_j$ ($i < j$), 等价于 $(\sum p_i)^2$ 的展开。若两性频率不同, 第一代后代的配子频率为两性平均, 第二代才达到平衡 (习题 4.1)。 [题目]

4.24 推导见推导 4.1。稳定性: 令 q^* 为内部平衡点, $\Delta q \approx \frac{pq}{2\bar{w}} \bar{w}''(q^*)(q - q^*)$ 。超显性 ($w_{12} > w_{11}, w_{22}$) 时 $\bar{w}$ 是关于 q 的开口向下的二次函数, $\bar{w}'' < 0$, 偏离 q^* 后 Δq 指向 q^* , 平衡稳定; 低显性时 $\bar{w}'' > 0$, 偏离被放大, 平衡不稳定, 群体最终固定于某一等位基因 (取决于初始频率)。 [题目]

4.25 递推见推导 4.2。若各代大小不同: $1 - F_3 = (1 - F_0) \prod_{t=1}^3 (1 - \frac{1}{2N_t})$ 。令其等于 $(1 - \frac{1}{2N_e})^3$, 在 $1/N_t$ 较小时取对数一阶展开: $\sum \frac{1}{2N_t} \approx \frac{3}{2N_e}$, 即 $\frac{1}{N_e} = \frac{1}{3} \sum \frac{1}{N_t}$, 为调和平均。调和平均由最小的 N_t 主导——一次“瓶颈”对多样性的损失需要很多

代大群体才能弥补。

[题目]

- 4.26** 推导见推导 4.3。更精确地，平衡条件为 $\mu(1-q) = pq[hs p + sq(1-h) \cdot \dots]$ 的低阶近似： $\mu \approx q(hs) + q^2 s(1-2h)$ 。当 $hsq \gg sq^2$ ，即 $h \gg q \approx \sqrt{\mu/s}$ 时，线性项主导， $\hat{q} \approx \mu/(hs)$ ；当 $h \ll \sqrt{\mu/s}$ 时，二次项主导， $\hat{q} \approx \sqrt{\mu/s}$ 。临界值 $h_c \sim \sqrt{\mu/s}$ ，对 $\mu = 10^{-5}$ 、 $s = 1$ 约为 0.003。现实中多数有害突变 h 在 0.1—0.3 之间，因此其平衡频率主要由杂合子中的选择决定。

[题目]

六、综合分析与研究设计题

- 4.27** (1) **分型错误**：偏离集中于聚类质量差、信号强度低或 GC 含量极端的 SNP；同一样本重复分型不一致；家系中出现孟德尔错误。(2) **无效等位基因**：偏离局限于少数位点，表现为“表观纯合子”过多且某些亲子对出现“纯合不相容”；在测序资料中可见探针区域有附加变异。(3) **近交**：杂合子缺乏遍及全基因组、各位点 $\hat{F}$ 大致相同；个体水平的 ROH 长度与系谱近交相符。(4) **群体结构**： $\hat{F}$ 与位点间亚群频率差 (F_{ST}) 正相关；主成分分析显示聚类；在亚群内检验时偏离消失。(5) **选择**：偏离集中于特定基因组区域、方向与生物学预期一致，且在不同年龄段样本中模式不同（存活选择）。流程：先按样本与位点质控剔除技术问题，再做主成分分析与分亚群检验，计算全基因组 $\hat{F}$ 分布，最后对残余的局部偏离做功能与连锁分析。8% 的高比例首先提示群体结构或系统性分型问题，而不是选择。

[题目]

- 4.28** 设携带者频率 10%， $q \approx 0.05$ 。(1) **只淘汰患病个体**： $q_t = q_0/(1 + tq_0)$ ，从 0.05 降到 0.025 需 20 代，下降极慢，但遗传多样性几乎无损失、经济成本主要是患病个体的损失。(2) **淘汰所有携带者**：若检测完备，一代内即可清除，但损失约 10% 的种畜，若携带者中包括高育种值的公畜家系，会显著降低遗传进展、提高近交速率，并丢失与之连锁的有利变异。(3) **避免携带者 × 携带者配对**：患病后代立即降为零，携带者使用比例逐步降低，例如每代优先选用同等育种值的非携带者， q 可在数代内稳步下降，同时保留优秀遗传背景。推荐 (3)：先保证无患病个体产生，再在育种值与亲缘约束下逐步降低频率（第 18、36 章的最优贡献框架可把“携带者使用比例”写成约束）。需注意检测本身的准确率与成本，以及未检测个体的系谱风险估计。

[题目]

- 4.29** 方案：(1) 用全基因组数千个中性 SNP 估计两批样本之间的漂变方差 $F = \text{Var}(\Delta q)/[\bar{q}(1-\bar{q})]$ ，并由 $F \approx 1 - (1 - \frac{1}{2N_e})^t$ 估计 N_e ；(2) 对频率相近的中性 SNP ($q_0 \approx 0.30$) 构建频率变化的经验零分布，或在 N_e 下模拟 Wright-Fisher 轨迹；(3) 计算候选位点 $\Delta q = 0.25$ 在零分布中的分位数，并校正

两批样本的抽样方差 ($q(1-q)/(2n)$)；(4) 对全基因组做同样检验，控制多重检验。例如 $N_e = 50$ 、 $t = 5$ 时， $\text{Var}(\Delta q) \approx 0.21 \times 5/100 = 0.0105$ ， $\text{SD} = 0.10$ ， $\Delta q = 0.25$ 约为 2.5 个标准差，单个位点尚不足以排除漂变；若 $N_e = 500$ ，SD 降为 0.032，则变化极显著。 N_e 越小，漂变越能“伪装”成选择，因此 N_e 的估计及其不确定性是检验成立的关键。还应检查候选区域周围是否出现连锁位点的同向变化（选择清扫的特征）。

【题目】

多基因座单倍型、连锁不平衡与重组

5.1 本章导学

学习目标

1. 能由单倍型频率计算 D 、 D' 与 r^2 ，理解三种度量的不同用途及其由等位基因频率决定的界限。

2. 理解有序与无序基因型的差别，能用 EM 算法由无序基因型估计单倍型频率，并认识相位未知造成的信息损失。

3. 掌握随机交配下连锁不平衡的衰减规律 $D_t = (1 - c)^t D_0$ ，能分析群体混合、漂变、选择等机制产生的 LD。

4. 理解漂变与重组平衡下 $E(r^2)$ 的近似公式，能由不同距离的 LD 推断有效群体大小的历史。

5. 理解单倍型块与标签 SNP 的概念，能说明单倍型为何能比单个 SNP 更好地标记致因变异。

6. 能把 LD 理论用于判断标记密度、关联定位分辨率与基因组预测的可迁移性。

重点与难点

重点： D 、 D' 、 r^2 的定义与界限；EM 估计单倍型频率；LD 的衰减；Sved 公式； r^2 与关联检验功效的关系。

难点： $|D'| = 1$ 不意味着 r^2 大；混合产生的 LD 对不连锁位点也存在；相位未知时检验 $D = 0$ 的信息只有相位已知时的一半；Sved 公式与 Ohta–Kimura 公式适用条件不同；由 LD 推断的“ N_e 历史”对样本量偏差和群体结构十分敏感。

LD 是连接群体遗传与基因定位、基因组预测的纽带：第 7—8 章的定位依赖标记与 QTL 之间的 LD，第 25—27 章基因组预测的准确度与可迁移性取决于 LD 的范围与相位一致性。

5.2 知识结构图




图 5.1 第 5 章知识结构图

右侧四支回答“LD 是什么、怎样估计、从何而来、如何衰减”；左侧三支回答“LD 在有限群体中维持在什么水平、怎样用它标记致因变异、对育种意味着什么”。

5.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
连锁不平衡系数	$D = p_{AB} - p_A p_B = p_{AB}p_{ab} - p_{Ab}p_{aB}$	配子（单倍型）水平
D 的界限	$D > 0$: $D_{\max} = \min(p_A q_B, q_A p_B)$; $D < 0$: $\min(p_A p_B, q_A q_B)$	$D' = D/D_{\max}$
r^2	$r^2 = \frac{D^2}{p_A q_A p_B q_B}$	等于两位点等位基因指示变量的相关平方
r^2 的上限	$r_{\max}^2 = \frac{p_A q_B}{q_A p_B} (p_A \leq p_B, D > 0)$	频率不匹配时远小于 1
衰减	$D_t = (1 - c)^t D_0$, 半衰期 $\ln 0.5 / \ln(1 - c)$	无限大群体随机交配
混合 LD	$D_0 = m(1 - m)\Delta p_A \Delta p_B$	与是否连锁无关

概念	公式或定义	成立条件与提示
Sved 公式	$E(r^2) \approx \frac{1}{1 + 4N_e c} + \frac{1}{n}$	漂变—重组，无突变； n 为样本个体数
Ohta–Kimura	$\sigma_d^2 \approx \frac{10 + \rho}{22 + 13\rho + \rho^2}$, $\rho = 4N_e c$	突变—漂变—重组平衡
LD 推断 N_e	$\hat{N}_e(c) = \frac{1/(\bar{r}^2 - 1/n) - 1}{4c}$, 反 映约 $1/(2c)$ 代前	需用作图函数换算 c
标记解释 QTL 方差	$\text{Var}(\hat{Q} M) / \text{Var}(Q) = r_{MQ}^2$	加性、单标记
关联检验功效	非中心参数约 $N r_{MQ}^2 q_Q^2$	用标记代替 QTL 需约 $1/r^2$ 倍样本

5.4 补充内容与公式推导

推导 5.1 随机交配下 LD 的逐代衰减

第 $t+1$ 代的配子 AB 有两种来源：(1) 以概率 $1-c$ 不重组，直接复制亲本某条单倍型，为 AB 的概率是 $p_{AB}^{(t)}$ ；(2) 以概率 c 重组， A 来自一条单倍型、 B 来自另一条；随机交配下两条单倍型独立，概率为 $p_A p_B$ （等位基因频率在无选择、大群体下不变）。故

$$p_{AB}^{(t+1)} = (1-c)p_{AB}^{(t)} + c p_A p_B \Rightarrow D_{t+1} = (1-c)D_t.$$

关键假设是“重组时两条单倍型来自随机组合”。若群体混合后第一代的个体仍由同一来源的两条单倍型组成（如尚未随机交配），则第一次重组不能打破 LD，衰减会推迟一代（习题 5.19 的模拟必须先让混合配子随机结合）。对 $c = 0.5$ 的不连锁位点， D 每代减半，但并非立即消失——这正是群体分层或近期混合造成“伪关联”的原因。

推导 5.2 标记对 QTL 的回归只能解释 r^2 的 QTL 方差

在配子水平，设标记等位基因指示变量 X （频率 p_M ），QTL 等位基因指示变量 Z （频率 p_Q ），QTL 效应 $Q = aZ$ 。则 $\text{Cov}(X, Z) = D$ ， $\text{Var}(X) = p_M q_M$ ， $\text{Var}(Z) = p_Q q_Q$ 。Q 对 X 的最佳线性预测解释的方差为

$$\frac{\text{Cov}(Q, X)^2}{\text{Var}(X)} = \frac{a^2 D^2}{p_M q_M} = a^2 p_Q q_Q \cdot \frac{D^2}{p_M q_M p_Q q_Q} = \text{Var}(Q) r^2.$$

二倍体剂量水平在 HWE 与配子独立下结论相同。两个推论：(1) 用标记代替 QTL 做关联检验，非中心参数乘以 r^2 ，要达到同样功效需 $1/r^2$ 倍的样本；(2) 即使 $|D'| = 1$ ，若标记频率与 QTL 频率差异很大（如习题 5.18 中致因变异频率 0.10 而标记频率 0.5），

r^2 仍然很小，单标记几乎捕获不到稀有致因变异。

补充：相位未知的信息损失与复合 LD

两位点剂量 x_A, x_B (0,1,2) 在 HWE 且两条配子独立时 $\text{Cov}(x_A, x_B) = 2D$ 。Weir 复合 LD $\hat{\Delta} = \widehat{\text{Cov}}(x_A, x_B)/2$ 不需要相位与 HWE 假设。在 $D = 0$ 附近， $\text{Var}(\hat{\Delta}) \approx \text{Var}(x_A) \text{Var}(x_B)/(4N) = p_A q_A p_B q_B/N$ ，而由 $2N$ 条相位已知配子估计 D 的方差为 $p_A q_A p_B q_B/(2N)$ ，恰为一半。习题 5.15 用数值微分进一步表明：即使用完整的无序基因型似然 (EM)，在 $D = 0$ 处每只个体关于 D 的 Fisher 信息也恰好只有相位已知时的一半；离开 $D = 0$ 后比例升高（该例中约 0.59）。原因在于：个体剂量是两条配子之和，乘积 $x_A x_B$ 中混入了“跨配子”的组合项，这些项不携带 D 的信息，却贡献噪声。家系资料或长读长测序提供的相位信息，因此对精细 LD 分析价值很大。

易错辨析

- $|D'| = 1$ 只说明四种单倍型中缺了一种，不说明标记能很好地预测致因变异；预测力看 r^2 。
- 混合 LD 不需要连锁：不连锁位点之间的混合 LD 每代减半，仍可在数代内造成伪关联。
- “距离为 c 的 LD 反映 $1/(2c)$ 代前的 N_e ”只是粗略的经验对应，而非严格的时间切片。
- 样本量小会人为抬高 r^2 （偏差约 $1/n$ ），忽略校正会低估远距离对应的 N_e 。
- $D=0$ 意味着两位点在配子上独立（对两个双等位位点成立），但不意味着基因型剂量在非 HWE 群体中不相关。

5.5 习题

一、单项选择题

5.1 ★ [单选] 某标记与一个稀有致因变异之间 $|D'| = 1$ ，但 $r^2 = 0.05$ 。最合理的解释是

- (A) 计算有误 (B) 两位点等位基因频率差异很大
(C) 两位点相距很远 (D) 群体发生了混合

[答案]

5.2 ★ [单选] 两个不连锁位点在某代的 $D = 0.08$ ，随机交配 3 代后 D 约为

- (A) 0.08 (B) 0.04 (C) 0.01 (D) 0

[答案]

5.3 ★★ [单选] 决定“用标记代替 QTL 进行关联检验时功效损失多少”的度量是

- (A) D (B) $|D'|$ (C) r^2 (D) 重组率 c

[答案]

5.4 ★ [单选] 由无序基因型估计两位点单倍型频率时，相位不确定的基因型只有

- (A) AaBB (B) AABb (C) AaBb (D) aabb

[答案]

5.5 ★★ [单选] $N_e = 100$ ，两标记相距 1 cM。按 Sved 公式（忽略样本偏差），期望 r^2 约为

- (A) 0.80 (B) 0.50 (C) 0.20 (D) 0.02

[答案]

5.6 ★★ [单选] 两个品种混合后形成合成系，两个不连锁标记的 LD 主要来源于

- (A) 连锁 (B) 品种间等位基因频率差异 (C) 突变
(D) 选择

[答案]

二、判断与改错题

5.7 ★ [判断] 对两个双等位基因位点， $D = 0$ 当且仅当配子上两位点的等位基因相互独立。

[答案]

5.8 ★★ [判断] 无论两位点的等位基因频率如何，只要 $D' = 1$ ， r^2 就可以达到 1。

[答案]

5.9 ★★ [判断] 对数量性状的定向选择只会在连锁位点之间产生连锁不平衡。

[答案]

5.10 ★★ [判断] F2 群体只经过一次减数分裂的重组，因此 F2 中的 LD 比古老的远交群体延伸得更远，定位分辨率更低。

[答案]

三、填空题

5.11 ★ [填空] 单倍型频率 $AB = 0.4$ 、 $Ab = 0.1$ 、 $aB = 0.2$ 、 $ab = 0.3$ 。则 $p_A =$ _____, $p_B =$ _____, $D =$ _____, $D' =$ _____, $r^2 =$ _____。 [答案]

5.12 ★ [填空] 某两位点 $D_0 = 0.10$, $c = 0.2$ 。随机交配 5 代后 $D =$ _____； D 的半衰期为_____代。 [答案]

5.13 ★ [填空] 两个群体等比例混合, A 位点频率分别为 0.2 与 0.8, B 位点分别为 0.3 与 0.9, 各自处于连锁平衡。混合后 $D_0 =$ _____。 [答案]

5.14 ★ [填空] $N_e = 200$, 两标记相距 0.5 cM, 按 Sved 公式 $E(r^2) \approx$ _____；若样本仅 50 只, 样本偏差使 r^2 约增加_____。 [答案]

四、计算题

5.15 ★★ [计算] EM 估计单倍型频率。260 个个体的两位点无序基因型计数如下 (行为 AA/Aa/aa, 列为 BB/Bb/bb):

	BB	Bb	bb
AA	42	36	6
Aa	40	70	18
aa	8	24	16

(1) 用 EM 算法估计四种单倍型频率与双杂合子的相引概率; (2) 计算 D, D', r^2 并用似然比检验 $D = 0$; (3) 与 Weir 复合 LD 比较; (4) 比较“若相位已知”的检验统计量, 并解释差异。 [程序] [ch05/ex05_15_haplotype_em.py](#) [答案]

5.16 ★★★ [计算] 漂变—重组平衡。对 $N = 100$ 的两位点 Wright-Fisher 群体, 模拟 300 代后不同重组率 ($c = 0.0005 \sim 0.1$) 下的 $\sigma_d^2 = E(D^2)/E(p_A q_A p_B q_B)$ 与 $E(r^2)$, 并与 Sved 公式、Ohta-Kimura 公式比较。说明两种理论在 $\rho = 4Nc$ 很小时为何差别很大, 模拟更接近哪一个, 为什么。 [程序] [ch05/ex05_16_ld_drift_recombination.py](#) [答案]

5.17 ★★ [计算] 标签 SNP 选择。200 条单倍型、18 个 SNP 的面板见配套数据。(1) 计算 r^2 矩阵, 识别单倍型块; (2) 用贪婪算法在 $r^2 \geq 0.8$ 与 $r^2 \geq 0.5$ 两种阈值下选择标签 SNP, 报告标签数与覆盖情况; (3) 比较块内与块间的平均 r^2 。 [程序] [ch05/ex05_17_tag_snp.py](#) [答案]

5.18 ★★ [计算] 单倍型标记稀有致因变异。六种祖先单倍型的三个标记等位基因与频率见配套数据,致因变异 Q (频率 0.10) 只位于单倍型 101 上。(1) 求各单标记与 Q 的 D 与 r^2 ; (2) 求最佳双标记单倍型与三标记单倍型的 r^2 ; (3) 求三个单标记加性多元回归的 R^2 ; (4) 若 Q 的效应为 1, 各方案可解释的配子水平加性方差是多少? [程序] `ch05/ex05_18_haplotype_tagging.py` [答案]

5.19 ★★ [计算] 合成系的混合 LD。群体 1 与群体 2 以 0.4:0.6 混合, A 位点频率分别为 0.1 与 0.7, B 位点分别为 0.8 与 0.3。(1) 求混合后的 D_0 与 r_0^2 ; (2) 求 $c = 0.5, 0.2, 0.05, 0.01$ 时第 5、20 代的 D 与半衰期; (3) 用有限群体模拟核对, 并说明模拟中为何必须先让混合配子随机结合。[程序] `ch05/ex05_19_admixture_ld.py` [答案]

5.20 ★★ [计算] 由 LD 推断有效群体大小的历史。某品种 120 个个体的标记对按距离分组, 各组平均 r^2 见配套数据 (0.05 cM 组为 0.480, 20 cM 组为 0.0148)。(1) 按 Haldane 函数换算 c , 用含样本校正的 Sved 公式估计各组 N_e 及对应“世代前”; (2) 比较不作 $1/n$ 校正的结果; (3) 描述该品种的群体历史, 并指出这种推断的主要局限。[程序] `ch05/ex05_20_ne_from_ld.py` [答案]

5.21 ★ [计算] 某标记与 QTL 的 $r^2 = 0.25$, QTL 解释表型方差的 4%。(1) 标记最多能解释多少表型方差? (2) 在相同功效下, 以标记检验所需样本量约为直接检验 QTL 的几倍? [答案]

5.22 ★ [计算] $p_A = 0.3, p_B = 0.6$ 。分别求 $D > 0$ 与 $D < 0$ 时 D 的最大可能值, 以及相应的最大 r^2 。 [答案]

五、推导与证明题

5.23 ★ [证明] 在无限大、随机交配、无选择的群体中, 证明 $D_{t+1} = (1 - c)D_t$ 。说明该推导中“随机交配”假设具体用在哪一步。 [答案]

5.24 ★★ [证明] 证明 r^2 等于配子上两位点等位基因指示变量的相关系数平方, 并据此证明 $r^2 \leq \frac{p_A q_B}{q_A p_B}$ (设 $p_A \leq p_B, D > 0$)。 [答案]

5.25 ★★ [证明] 证明在加性模型下, 标记对 QTL 的最佳线性预测所解释的 QTL 方差比例为 r^2 (配子水平), 并说明在二倍体剂量水平上结论成立的条件。 [答案]

- 5.26 ★★★ [证明] 给出 Sved 公式 $E(r^2) \approx 1/(1 + 4N_e c)$ 的同祖片段论证：两条染色体在两个位点间“同祖且中间未重组”的概率与 r^2 的期望之间有何关系？该论证忽略了哪些因素？ [答案]

六、综合分析与研究设计题

- 5.27 ★★ [综合] 两个品种的 N_e 分别约为 100 与 1000。若要使相邻标记平均 r^2 达到 0.2，两品种各需多大的标记间距 (cM)？以每个染色体组约 25 M 计，大约需要多少个 SNP？讨论这对芯片设计与参考群体规模的含义。 [答案]
- 5.28 ★★★ [综合] 某研究用 LD 推断出某品种“近 10 代 N_e 由 200 降至 60”，并据此建议立即开展保种。请从样本量偏差、群体结构与混合、选择、遗传图谱误差与时间对应关系五个方面评价该结论的可靠性，并提出改进的分析方案。 [答案]
- 5.29 ★★★ [综合] 在多品种基因组预测中，LD“相位一致性”（不同品种中标记—QTL 的 r 同号且大小相近）被认为决定跨品种预测的成败。设计一项分析，利用两个品种的芯片资料估计不同距离上的相位一致性，并说明如何据此判断合并参考群体是否有益。 [答案]

5.6 参考答案与解析

一、单项选择题

- 5.1 B。 $|D'| = 1$ 说明四种单倍型中缺失了一种（如致病等位基因只出现在一种标记背景上），但若致病变异频率远低于标记等位基因频率，标记等位基因的多数拷贝并不携带致病变异，相关仍然很低。 [题目]
- 5.2 C。不连锁 $c = 0.5$ ， $D_3 = 0.08 \times 0.5^3 = 0.01$ 。 [题目]
- 5.3 C。关联检验的非中心参数正比于 r^2 （推导 5.2）。 [题目]
- 5.4 C。只有双杂合子的两条单倍型可能是 AB/ab 或 Ab/aB。 [题目]
- 5.5 C。 $1/(1 + 4 \times 100 \times 0.01) = 0.2$ 。 [题目]
- 5.6 B。合成系的不连锁位点 LD 来源于两品种频率差异的乘积（混合 LD），每代减半。 [题目]

二、判断与改错题

5.7 正确。 $D = 0$ 等价于 $p_{AB} = p_A p_B$, 对两个双等位点, 这一条件可推出其余三种单倍型也满足乘积关系, 即配子上的两个指示变量独立。对多等位基因位点, 需所有 $D_{ij} = 0$ 。 [题目]

5.8 错误。 r^2 的上限由频率决定, $D' = 1$ 时 $r^2 = r_{\max}^2 = p_A q_B / (q_A p_B)$ ($p_A \leq p_B, D > 0$)。只有当两位点频率相等 (或互补) 时 r^2 才能达到 1。 [题目]

5.9 错误。 定向选择使有利等位基因在同一配子上共同出现的频率升高, 在不连锁位点之间也产生负的 LD (Bulmer 效应), 只是这种 LD 在停止选择后每代减半; 连锁位点的 LD 保持更久。第 14 章将用这一机制解释选择对加性方差的压缩。 [题目]

5.10 正确。 F_2 的 LD 由一次杂交产生、只经过一代重组, $D = (1 - 2c)/4$, 可延伸数十厘摩, 标记与远处 QTL 仍有明显关联, 因此检测功效高但定位分辨率低; 古老远交群体经历了成千上万代重组, LD 只延伸很短距离, 分辨率高但需要高密度标记。 [题目]

三、填空题

5.11 $p_A = 0.5, p_B = 0.6; D = 0.4 \times 0.3 - 0.1 \times 0.2 = 0.10; D_{\max} = \min(0.5 \times 0.4, 0.5 \times 0.6) = 0.2, D' = 0.5; r^2 = 0.01 / (0.25 \times 0.24) = 0.167$ 。 [题目]

5.12 $D_5 = 0.1 \times 0.8^5 = 0.0328$; 半衰期 $\ln 0.5 / \ln 0.8 = 3.1$ 代。 [题目]

5.13 $D_0 = 0.5 \times 0.5 \times (0.2 - 0.8) \times (0.3 - 0.9) = 0.09$ 。 [题目]

5.14 $1 / (1 + 4 \times 200 \times 0.005) = 0.2$; 样本偏差约 $1/50 = 0.02$, 即 $\hat{r}^2 \approx 0.22$, 相对增加 10%。 [题目]

四、计算题

5.15 (1) EM 迭代 30 次收敛, 双杂合子为相引相 (AB/ab) 的后验概率 0.781; 单倍型频率 $AB = 0.413, Ab = 0.156, aB = 0.183, ab = 0.247$ 。

(2) $p_A = 0.569, p_B = 0.596, D = 0.0734, D' = 0.320, r^2 = 0.0914$; 似然比 $\Lambda = 24.46, p = 7.6 \times 10^{-7}$ 。

(3) 复合 LD $\hat{\Lambda} = 0.0716$, 与 $\hat{D}$ 接近, 说明样本近似满足 HWE。

(4) 若 520 条配子相位已知, $\chi^2 \approx 2Nr^2 = 47.5$; 无序基因型的似然比只有 24.5,

约等于 $Nr^2 = 23.8$ 。数值计算表明，在 $D = 0$ 处每只个体关于 D 的 Fisher 信息，无序基因型恰为相位已知的一半（16.94 对 33.88），在 $\hat{D}$ 处比例约 0.59。双杂合子只占 27%，但信息损失远不止 27%，原因见补充内容：剂量乘积中混入了不携带 LD 信息的跨配子组合项。

[题目]

5.16

c	ρ	模拟 σ_d^2	模拟 $E(r^2)$	Sved	Ohta–Kimura
0.0005	0.2	0.838	0.812	0.833	0.414
0.002	0.8	0.583	0.561	0.556	0.327
0.005	2	0.420	0.390	0.333	0.231
0.01	4	0.228	0.210	0.200	0.156
0.02	8	0.122	0.105	0.111	0.095
0.05	20	0.054	0.048	0.048	0.044
0.1	40	0.027	0.026	0.024	0.023

ρ 大时两种理论都趋于 $1/\rho$ ，与模拟一致； ρ 小时 Sved 公式趋于 1，Ohta–Kimura 趋于 $10/22 \approx 0.45$ 。本模拟没有突变：起始两位点多态、无新突变进入，紧密连锁的位点在漂变中几乎“锁定”为少数单倍型，LD 接近完全，因此更接近 Sved 的同祖片段论证。Ohta–Kimura 公式描述突变—漂变—重组的稳态，其中新突变总是在单一背景上产生，又被漂变与重组不断“稀释”，极短距离的 σ_d^2 也达不到 1。实际群体介于两者之间，解释极短距离的 r^2 时需考虑突变与频率谱。

[题目]

5.17 (1) r^2 矩阵呈现三个块：S1—S6、S7—S13、S14—S18；块内平均 $r^2 = 0.367$ ，块间仅 0.006。第三块（两种祖先单倍型）内部 r^2 普遍 0.7—0.85，第二块（四种祖先单倍型）内部较弱且不均匀。

(2) $r^2 \geq 0.8$ 时需 13 个标签（S14 一个即覆盖第三块的大部分），每个 SNP 被最佳标签捕获的平均最大 $r^2 = 0.951$ ； $r^2 \geq 0.5$ 时需 10 个标签，平均最大 $r^2 = 0.913$ ，最小 0.745。

(3) 祖先单倍型越少、块内重组越少，所需标签越少；块的边界对应重组热点或古老的重组事件。标签策略只保证对**已分型**的常见 SNP 的覆盖，不保证对未分型的稀有致因变异的覆盖。

[题目]

5.18 (1) 单标记 M1、M2、M3 与 Q 的 r^2 分别为 0.111、0.167、0.136（ D 为 +0.050, -0.060, +0.055）。

(2) 最佳双标记单倍型：M1M3 的 “11” $r^2 = 1.000$ ；M1M2 的 “10” 与 M2M3 的

“01”均为 0.333；三标记单倍型 101 的 $r^2 = 1.000$ 。

(3) 三个单标记的加性多元回归 $R^2 = 0.500$ 。单倍型指示变量是标记等位基因的乘积（交互），加性回归无法表达，因此即使同时使用全部标记，也只能捕获一半。

(4) Q 的配子水平方差 $a^2p_Qq_Q = 0.09$ ，单标记可解释 0.010—0.015，单倍型可解释全部 0.090。这说明：稀有致因变异常常“藏”在某种常见标记组合上，单倍型或局部同祖片段方法（第 30 章）能捕获单 SNP 加性模型遗漏的信息。 [题目]

5.19 (1) $p_A = 0.46$, $p_B = 0.50$, $D_0 = 0.4 \times 0.6 \times (0.1 - 0.7) \times (0.8 - 0.3) = -0.072$, $r_0^2 = 0.0835$ 。

(2)

<i>c</i>	D_5	D_{20}	半衰期 (代)
0.50	-0.0023	≈0	1.0
0.20	-0.0236	-0.0008	3.1
0.05	-0.0557	-0.0258	13.5
0.01	-0.0685	-0.0589	69.0

(3) 有限群体 ($N = 5000$) 模拟的平均 D 与理论值在蒙特卡洛误差内一致。若初始“个体”由同一起来源的两条单倍型组成，第一代重组只在同源背景间交换，不能降低 D ，衰减会整体推迟一代。合成系形成后数代内，连锁与不连锁位点都存在可观的 LD，此时做关联分析必须校正品种来源（祖源比例）。 [题目]

5.20 (1)

图距 cM	<i>c</i>	$\bar{r}^2$	$\hat{N}_e$ (校正)	$\hat{N}_e$ (未校正)	约多少代前
0.05	0.0005	0.480	560	542	1000
0.2	0.0020	0.300	304	292	250
0.5	0.0050	0.185	234	221	100
1	0.0099	0.112	218	200	50
2	0.0196	0.064	216	186	26
5	0.0476	0.033	208	154	11
10	0.0906	0.0215	207	126	6
20	0.1648	0.0148	233	101	3

(2) 远距离组的 r^2 很小，样本偏差 $1/n = 0.0083$ 占了相当大的比例；不作校正时 $\hat{N}_e$ 从约 210“下降”到 101，形成虚假的“近期瓶颈”。

(3) 校正后的结果显示：约千代前 N_e 在 500 以上，随后下降，近 50 代以来稳定在约 210。局限：(1) 时间对应只是粗略的；(2) 短距离受突变与基因转换影响，长距离受样本偏差与图谱误差影响；(3) 群体混合与结构会在长距离上抬高 r^2 ，使近期 N_e 被低估；(4) 选择也会局部抬高 LD；(5) 最近几代的估计依赖 20 cM 以上的极少量信号，置信区间很宽。 [题目]

5.21 (1) 最多 $0.25 \times 4\% = 1\%$ 的表型方差。(2) 非中心参数正比于 Nr^2q^2 ，所需样本约为直接检验 QTL 的 $1/r^2 = 4$ 倍。 [题目]

5.22 $D > 0$: $D_{\max} = \min(p_A q_B, q_A p_B) = \min(0.12, 0.42) = 0.12$, $r_{\max}^2 = 0.0144 / (0.21 \times 0.24) = 0.286$; $D < 0$: $|D|_{\max} = \min(p_A p_B, q_A q_B) = \min(0.18, 0.28) = 0.18$, $r_{\max}^2 = 0.0324 / 0.0504 = 0.643$ 。频率“互补”方向 ($p_A = 0.3$ 与 $q_B = 0.4$ 较接近) 允许更强的负 LD。 [题目]

五、推导与证明题

5.23 见推导 5.1。随机交配用于重组配子的概率计算：重组配子的 A 位点来自一条单倍型、B 位点来自同一个体的另一条单倍型；只有当个体的两条单倍型是从群体中独立抽取（随机结合）时，该概率才等于 $p_A p_B$ 。若存在近交或同型交配，同一个体两条单倍型相关，重组配子的 AB 概率不等于 $p_A p_B$ ，衰减速率变为 $(1 - c(1 - F))$ 量级——近交减缓 LD 衰减。 [题目]

5.24 令 $X = 1\{A\}$ 、 $Y = 1\{B\}$ ，则 $\text{Cov}(X, Y) = p_{AB} - p_A p_B = D$ ， $\text{Var}(X) = p_A q_A$ ， $\text{Var}(Y) = p_B q_B$ ，故 $\text{corr}^2 = r^2$ 。 $D > 0$ 时 $D \leq \min(p_A q_B, q_A p_B)$ ； $p_A \leq p_B$ 时 $p_A q_B \leq q_A p_B$ ，所以 $D \leq p_A q_B$ ，

$$r^2 \leq \frac{p_A^2 q_B^2}{p_A q_A p_B q_B} = \frac{p_A q_B}{q_A p_B} \leq 1,$$

等号仅当 $p_A = p_B$ 。

[题目]

5.25 配子水平推导见推导 5.2。二倍体剂量水平： $x_M = X_1 + X_2$, $x_Q = Z_1 + Z_2$ ，若两条配子独立（随机交配、HWE）， $\text{Cov}(x_M, x_Q) = 2D$, $\text{Var}(x_M) = 2p_M q_M$, $\text{Var}(x_Q) = 2p_Q q_Q$ ，相关平方仍为 r^2 。若存在近交或群体结构，同一个体两条配子不独立，剂量协方差中出现额外的跨配子项，剂量相关不再等于 r ，而“群体结构”造成的剂量相关正是关联分析混杂的来源。 [题目]

5.26 设两条随机染色体在位点 1 处同祖（自共同祖先 t 代前），若期间两位点之间的片段未发生重组（概率约 $(1 - c)^{2t}$ ），则在位点 2 也同祖。Sved (1971) 把 $E(r^2)$ 近似为

“在位点 1 同祖的条件下位点 2 也同祖”的概率。对 t 按溯祖分布（速率 $1/(2N_e)$ ）积分：

$$E(r^2) \approx \int_0^\infty \frac{1}{2N_e} e^{-t/(2N_e)} e^{-2ct} dt = \frac{1}{1 + 4N_e c}.$$

该论证忽略了：突变（使同祖片段不必同态）、等位基因频率谱、样本量偏差、群体结构与选择，以及 r^2 是比值而非概率（ $E(r^2)$ 与 σ_d^2 不同）。因此它在 ρ 中等到较大时较准确，极短距离时偏高。 [题目]

六、综合分析与研究设计题

5.27 令 $1/(1 + 4N_e c) = 0.2$, $c = 1/N_e$: $N_e = 100$ 时 $c = 0.01$ (约 1 cM), $N_e = 1000$ 时 $c = 0.001$ (0.1 cM)。以基因组 25 M=2500 cM 计, 前者约需 2 500 个均匀分布的“有效”标记, 后者约需 25 000 个; 考虑 MAF 分布与非均匀性, 实际芯片需数倍于此。 N_e 大的品种不仅需要更高的标记密度, 而且由于“独立染色体片段数” $M_e \approx 2N_e L$ 大, 同样准确度需要更大的参考群体 (第 25 章 Daetwyler 公式)。小 N_e 品种用中低密度芯片即可, 但其 LD 范围长也意味着定位分辨率低、跨品种迁移困难。 [题目]

5.28 (1) **样本量**: 若 n 较小且未作 $1/n$ 校正, 长距离的 $\hat{N}_e$ 被系统性低估, 形成虚假“近期下降” (习题 5.20)。(2) **结构与混合**: 亚群或近期引入外血统会抬高长距离 LD, 同样表现为近期 N_e 下降。(3) **选择**: 强选择区域 LD 升高, 应排除或分区域估计。(4) **图谱误差**: 物理距离换算为遗传距离时若重组率不均, 长距离组的 c 估计偏差大。(5) **时间对应**: $1/(2c)$ 代只是粗略对应, 最近 10 代的估计主要依赖极少数长距离对, 区间很宽。改进: 用较大样本并作偏差校正; 先做主成分分析与祖源推断, 分亚群估计; 用高质量遗传图谱; 采用基于溯祖或同祖片段长度分布的方法 (如 GONE、IBDNe) 交叉验证; 结合系谱近交增长率估计的 N_e ; 报告不确定性区间。结论“立即开展保种”还需结合当前近交水平、繁殖结构等直接证据。 [题目]

5.29 分析方案: (1) 两品种使用同一芯片、同一质控与相同参考等位基因方向; (2) 对每对相距 d 的标记, 分别在两品种中计算有符号相关 r_1, r_2 ; (3) 按距离分组, 计算相位一致性 $\text{corr}(r_1, r_2)$, 并以自助法求区间; (4) 找出一致性降到 0.8 (或 0.5) 以下的距离, 作为“共享 LD 范围”。判断: 若常用芯片相邻标记间距远小于该距离, 则两品种中标记—QTL 关系相近, 合并参考群体可提高小品种的预测准确度; 若一致性在标记间距尺度上已很低, 合并可能无益甚至有害, 应采用多品种模型 (品种特异效应 + 共享效应) 或更高密度/序列资料。最终应以小品种的前瞻验证 (按世代划分) 检验合并的实际收益 (第 29 章)。 [题目]

遗传连锁与连锁图谱的构建

6.1 本章导学

学习目标

- 1. 理解交叉、交换与重组的关系，能说明重组率不超过 1/2 的原因以及图距可加而重组率不可加。
- 2. 掌握 Haldane、Kosambi 作图函数及计数模型，能计算并发系数与干涉。
- 3. 能在回交、F2 与远交半同胞家系中进行两点连锁分析，计算最大似然估计、LOD 与支持区间，理解相位未知造成的信息损失。
- 4. 掌握连锁图谱构建的分群、排序与图距估计流程，比较不同排序准则，评价排序的可信度。
- 5. 理解多点连锁分析的隐马尔可夫模型，能用前向—后向算法与 EM 同时估计重组率与分型错误率。
- 6. 能识别分型错误与偏分离对图谱的影响，比较遗传图谱与物理图谱。

重点与难点

重点：作图函数；两点 LOD；三点测交确定基因顺序；多点似然；HMM 的前向递推。

难点：F2 中双杂合子的重组配子数未知；半同胞家系中相位未知使每个家系的 LOD 最多损失 $\log_{10} 2$ ；少量分型错误会使高密度图谱的长度成倍虚增；偏分离本身不一定使重组率估计有偏，却会影响 LOD 检验与定位。

本章是第 7 章区间作图与第 8 章远交群体连锁分析的直接基础，HMM 方法也是第 26 章基因型填充的核心工具。

6.2 知识结构图




图 6.1 第 6 章知识结构图

右侧从“重组 → 作图函数 → 两点分析 → 多点构图”是图谱构建的主线；左侧“HMM、数据问题、图谱比较”讨论在真实资料中怎样稳健地得到可靠图谱。

6.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
Mather 公式	$c = \frac{1}{2}P(\text{区间内交叉数} \geq 1)$	无染色单体干涉
Haldane	$c = \frac{1}{2}(1 - e^{-2d}),$ $d = -\frac{1}{2} \ln(1 - 2c)$	交叉服从泊松过程（无干涉）
Kosambi	$c = \frac{1}{2} \tanh(2d),$ $d = \frac{1}{4} \ln \frac{1+2c}{1-2c}$	中等正干涉
三点关系	$c_{AC} = c_{AB} + c_{BC} - 2\gamma c_{AB}c_{BC}$	γ 为并发系数， $1 - \gamma$ 为干涉
回交两点	$\hat{c} = k/n, \text{Var}(\hat{c}) = c(1 - c)/n$	相位已知
LOD	$\text{LOD} = \log_{10} \frac{L(\hat{c})}{L(1/2)}$	回交: $k \log_{10} \hat{c} + (n - k) \log_{10} (1 - \hat{c}) + n \log_{10} 2$
F2 两点 EM	$w = c^2/[c^2 + (1 - c)^2],$ $c' = (R + 2w n_{AaBb})/(2N)$	相引相共显性标记

概念	公式或定义	成立条件与提示
相位未知	$L = \frac{1}{2}[c^k(1-c)^{n-k} + c^{n-k}(1-c)^k]$	每家系 LOD 损失 $\leq \log_{10} 2$
HMM 前向	$\alpha_j(g) = \sum_{g'} \alpha_{j-1}(g') T_{g'g}(c_{j-1}) e_j(g)$	马尔可夫性（无干涉）
分型错误	每个错误约增加 2 个“伪重组”	高密度图谱长度虚增
偏分离	标记 A 型比例 $= \frac{(1-c) + cv}{1+v}$	回交，存活位点相对存活率 v

6.4 补充内容与公式推导

推导 6.1 由泊松交叉过程得到 Haldane 作图函数

设单条染色单体上交换点按速率 1（每摩尔根）的泊松过程出现，区间长 d 中交换数 $K \sim \text{Poisson}(d)$ 。两个标记之间只有发生奇数次交换才表现为重组，故

$$c = P(K \text{ 为奇数}) = \sum_{k \text{ 奇}} e^{-d} \frac{d^k}{k!} = e^{-d} \sinh d = \frac{1 - e^{-2d}}{2}.$$

反解得 $d = -\frac{1}{2} \ln(1 - 2c)$ 。 $d \rightarrow \infty$ 时 $c \rightarrow 1/2$ ：远距离位点的重组率不可能超过 $1/2$ ，因为奇数次与偶数次交换趋于等概率。对相邻区间，泊松过程的独立增量性给出 $1 - 2c_{AC} = (1 - 2c_{AB})(1 - 2c_{BC})$ ，即 $c_{AC} = c_{AB} + c_{BC} - 2c_{AB}c_{BC}$ ——无干涉时并发系数为 1。

推导 6.2 Kosambi 作图函数的微分方程来源

考虑长度 d 的区间 AB 后接一小段 δ 的区间 BC 。由三点关系 $c(d + \delta) = c(d) + c(\delta) - 2\gamma c(d)c(\delta)$ ，小区间 $c(\delta) \approx \delta$ 。若并发系数随距离变化，令 $\gamma = 2c(d)$ （Kosambi 假设：近距离强干涉、远距离无干涉），则

$$\frac{dc}{dd} = 1 - 4c^2, \quad c(0) = 0 \implies c = \frac{1}{2} \tanh(2d).$$

相应的相邻区间合并公式为 $c_{AC} = \frac{c_{AB} + c_{BC}}{1 + 4c_{AB}c_{BC}}$ 。若取 $\gamma = 1$ ，同样的推导给出 $dc/dd = 1 - 2c$ ，即 Haldane 函数。作图函数的选择实质上是对干涉强度的假设；计数模型（习题 6.18）提供了一个由前体事件生成交叉、参数 m 刻画干涉强度的更一般框架。

推导 6.3 HMM 的前向递推与多点似然

回交后代在 m 个有序标记上的真实基因型 $g_1, \dots, g_m$ 构成马尔可夫链（无干涉时相邻区间独立）： $P(g_j \neq g_{j-1}) = c_{j-1}$ 。观测 o_j 以概率 ε 与 g_j 不同。定义 $\alpha_j(g) = P(o_1, \dots, o_j, g_j = g)$ ，则

$$\alpha_1(g) = \frac{1}{2}e_1(g), \quad \alpha_j(g) = e_j(g) \sum_{g'} \alpha_{j-1}(g')T_{g'g},$$

其中 $e_j(g) = P(o_j | g_j = g)$ 。似然 $L = \sum_g \alpha_m(g)$ ，计算量只与 m 成线性。后向量 $\beta_j(g) = P(o_{j+1}, \dots, o_m | g_j = g)$ 满足类似递推，二者之积给出后验 $P(g_j | o)$ 。Baum-Welch 算法是这一结构上的 EM：E 步计算每个区间“发生重组”与每个位点“观测错误”的后验期望，M 步以比例更新 c_j 与 ε 。忽略错误时，一个孤立的错误基因型在其两侧各制造一个伪重组；标记越密，真实重组越少，错误在总重组中所占比例越大，图谱长度因此成倍虚增（习题 6.17）。

易错辨析

- 图距可加，重组率不可加： $c_{AC} < c_{AB} + c_{BC}$ ，差额来自双交换。
- LOD 3 是单个检验的经验阈值：在全基因组构图或连锁扫描中，需考虑多重检验与先验概率。
- 相位未知的半同胞家系：后代少于约 12 只时，即使全部为同一类型，LOD 也达不到 3。
- 偏分离不必然导致重组率估计偏倚：存活选择作用于一个位点时，回交中相邻标记的重组计数大体仍无偏；但单标记分离比的卡方检验、混合模型中的方差估计会受影响。
- 两点 LOD 之和最大的顺序不一定是多点似然最大的顺序，排序可信度应以最优与次优顺序的似然差衡量。

6.5 习题

一、单项选择题

6.1 ★ [单选] 两个位点之间的重组率不超过 $1/2$ ，其最根本的原因是

- (A) 染色体长度有限
- (B) 只有奇数次交换才表现为重组，远距离时奇偶次数趋于等概率
- (C) 存在交叉干涉
- (D) 重组只发生在雌性

[答案]

6.2 ★ [单选] 三点测交中，观察双交换数为期望值的 60%，则

- (A) 并发系数 0.6，干涉 0.4
- (B) 并发系数 0.4，干涉 0.6
- (C) 并发系数与干涉都为 0.6
- (D) 无法计算

[答案]

6.3 ★ [单选] 与 Haldane 函数相比，Kosambi 函数对同一个重组率 $c = 0.3$ 给出的图距

- (A) 更大
- (B) 更小
- (C) 相同
- (D) 取决于群体类型

[答案]

6.4 ★★ [单选] 在 F₂ 群体中进行两点连锁分析，信息量最高的标记组合是

- (A) 两个显性标记、相斥相
- (B) 两个显性标记、相引相
- (C) 两个共显性标记
- (D) 一个显性、一个共显性

[答案]

6.5 ★★ [单选] 用 HMM 构建图谱时，如果忽略 2% 的分型错误，10 个相距 2 cM 的标记所构成的图谱长度最可能

- (A) 基本不变
- (B) 略有缩短
- (C) 成倍增加
- (D) 变为 0

[答案]

6.6 ★ [单选] 某染色体物理长度 150 Mb，遗传长度 120 cM。下列说法正确的是

- (A) 全染色体重组率均匀为 0.8 cM/Mb
- (B) 平均为 0.8 cM/Mb，局部可能有热点与冷区
- (C) 遗传长度与性别无关
- (D) 1 cM 恒等于 1 Mb

[答案]

二、判断与改错题

6.7 ★ [判断] 三个有序位点 A—B—C 中, $c_{AC} = c_{AB} + c_{BC}$ 总是成立。 [答案]

6.8 ★★ [判断] 回交群体中, 若某个存活位点使与之连锁的标记出现偏分离, 则相邻标记之间的重组率估计必然严重有偏。 [答案]

6.9 ★ [判断] 分型错误会使连锁图谱的估计长度增加。 [答案]

6.10 ★★ [判断] 在远交半同胞家系中, 若公畜相位未知且每个家系只有 10 只后代, 即使全部后代均为非重组型, 该家系的 LOD 也不能达到 3。 [答案]

三、填空题

6.11 ★ [填空] $c = 0.2$ 时, Haldane 图距为 _____ cM, Kosambi 图距为 _____ cM。

[答案]

6.12 ★ [填空] 三点测交 500 个后代中, $c_{AB} = 0.12$, $c_{BC} = 0.08$, 观察到 3 个双交换个体。期望双交换数为 _____, 并发系数为 _____, 干涉为 _____。 [答案]

6.13 ★ [填空] 某染色体雌性图谱长 120 cM、雄性 80 cM, 性别平均图谱长 _____ cM。若某 QTL 分析只使用公畜家系, 应使用 _____ 图谱。 [答案]

6.14 ★ [填空] 某染色体物理长度 150 Mb、遗传长度 120 cM, 平均重组率为 _____ cM/Mb; 若一个 1 Mb 区间内观察到 3 cM, 它是平均水平的 _____ 倍。 [答案]

四、计算题

6.15 ★★ [计算] **F2 两点连锁**。相引相 F1 (AB/ab) 自交得 180 个 F2, 九类共显性基因型计数为 (行 AA/Aa/aa, 列 BB/Bb/bb): 28, 14, 2; 16, 64, 15; 1, 13, 27。(1) 用 EM 算法估计 c , 求 LOD、标准误与 1-LOD 支持区间; (2) 计算 $c = 0.01 \sim 0.4$ 时 F2 与回交每个个体的期望 Fisher 信息, 说明 F2 的优势何时最明显。 [程序] `ch06/ex06_15_f2_two_point.py` [答案]

6.16 ★★ [计算] **标记排序**。150 个回交后代在 6 个标记上的模拟基因型见配套数据。(1) 计算两点重组率矩阵; (2) 穷举全部顺序, 比较相邻重组率之和最小、相邻 LOD 之和最大、多点似然最大三种准则; (3) 计算最优与次优顺序的 LOD 差, 并给出相邻区间的 Haldane 图距。 [程序] `ch06/ex06_16_map_order.py` [答案]

- 6.17 ★★★ [计算] HMM 与分型错误。**200 个回交后代、10 个相距 2 cM 的标记，模拟分型错误率 2%。(1) 比较忽略错误的直接计数与 HMM-EM 估计的图谱总长；(2) 报告错误率估计值；(3) 用后验概率找出可疑基因型，评价检出效果，并解释端点标记为何更难判断。 [程序] `ch06/ex06_17_hmm_errors.py` [答案]
- 6.18 ★★★ [计算] 交叉干涉的计数模型。**用 χ^2 (计数) 模型模拟 20 万次减数分裂， $m = 0, 1, 4$ 。(1) 求区间长度 $d = 0.05 \sim 0.8$ M 的重组率，并与 Haldane、Kosambi 函数比较；(2) 估计两个相邻 0.1 M 区间的并发系数；(3) 说明 m 的生物学含义及其对作图函数选择的影响。 [程序] `ch06/ex06_18_interference.py` [答案]
- 6.19 ★★ [计算] 偏分离定位存活位点。**回交产生 600 个合子，43 cM 处一个存活位点使 aa 型合子的相对存活率为 0.6。(1) 对 11 个标记作 1:1 分离卡方检验，比较观察与理论偏离曲线；(2) 用复合似然估计存活位点位置与存活率；(3) 检查偏分离是否使相邻标记重组率估计产生明显偏差。 [程序] `ch06/ex06_19_segregation_distortion.py` [答案]
- 6.20 ★★ [计算] 半同胞家系的相位未知。**真实 $c = 0.15$ ，公畜双杂合、相位未知。(1) 写出 F 个家系联合似然；(2) 模拟家系数 1、2、4、8 与每家后代数 10、20、40 的组合，比较相位已知与相位未知时 $\text{LOD} \geq 3$ 的功效与平均 LOD 损失；(3) 解释为何“1 个家系、10 只后代”时相位未知的功效为零。 [程序] `ch06/ex06_20_halfsib_phase.py` [答案]
- 6.21 ★ [计算] 三对基因的三点测交 1000 个后代：**ABC 352、abc 358、Abc 52、aBC 48、ABc 85、abC 91、AbC 7、aBc 7。(1) 确定基因顺序；(2) 计算相邻区间重组率与两端位点的“表观”重组率；(3) 计算并发系数与干涉。 [答案]
- 6.22 ★ [计算] 相邻区间 $c_{AB} = 0.05$ ， $c_{BC} = 0.15$ 。**分别按无干涉 (Haldane) 与 Kosambi 假设计算 c_{AC} 和总图距，并解释两者差异的方向。 [答案]

五、推导与证明题

- 6.23 ★ [证明] 假设交换点在染色单体上服从泊松过程，推导 Haldane 作图函数，并证明无干涉时 $c_{AC} = c_{AB} + c_{BC} - 2c_{AB}c_{BC}$ 。** [答案]

6.24 ★★ [证明] 推导回交两点分析的 $\hat{c}$ 、Fisher 信息与 LOD 表达式；证明相位未知的单个家系似然 $L = \frac{1}{2}[c^k(1-c)^{n-k} + c^{n-k}(1-c)^k]$ 下，LOD 相对于相位已知最多损失 $\log_{10} 2$ 。 [答案]

6.25 ★★ [证明] 由三点关系与 Kosambi 关于并发系数的假设，推导 $dc/dd = 1 - 4c^2$ 及 Kosambi 作图函数，并写出相应的区间合并公式。 [答案]

6.26 ★★★ [证明] 写出回交多标记资料的 HMM 前向与后向递推，证明 $P(g_j = g | o) \propto \alpha_j(g)\beta_j(g)$ ，并说明 Baum-Welch 算法中重组率的更新公式。 [答案]

六、综合分析与研究设计题

6.27 ★★ [综合] 用简化基因组测序 (GBS) 为一个 F2 群体构建高密度图谱时，标记缺失率常达 30%、杂合子低检出导致分型错误较多。设计一个从原始基因型到最终图谱的分析流程，说明每一步要解决的问题。 [答案]

6.28 ★★ [综合] 某物种的新版基因组组装与连锁图谱对比时，发现一条染色体中部有约 3 Mb 的区段在遗传图谱上顺序颠倒，另一处 10 Mb 区段几乎没有重组。分别给出至少两种生物学或技术解释，并设计区分它们的检验。 [答案]

6.29 ★★★ [综合] 说明遗传图谱在基因组选择时代仍然重要的三个理由（如基因型填充、单倍型构建、QTL 区间解释），并为一个只有物理图谱的地方品种设计利用家系资料估计品种特异遗传图谱的方案。 [答案]

6.6 参考答案与解析

一、单项选择题

6.1 B。 重组表现为两个位点间奇数次交换；当区间很长时，奇数次与偶数次交换概率趋于相等， $c \rightarrow 1/2$ （推导 6.1）。干涉影响的是 c 与 d 的换算，不是上界的来源。

[题目]

6.2 A。 并发系数 $\gamma = \text{观察双交换} / \text{期望双交换} = 0.6$ ，干涉 $= 1 - \gamma = 0.4$ 。 [题目]

6.3 B。 $c = 0.3$ 时 Haldane $d = 0.458$ M，Kosambi $d = 0.347$ M。Kosambi 假设正干涉，同样的重组率对应较少的“隐藏”双交换，图距更短。 [题目]

6.4 C。共显性标记能区分全部九类基因型，信息最多；两个显性标记在相斥相时信息最少（Allard 1956）。 [题目]

6.5 C。每个孤立错误产生约两个伪重组。真实每区间重组率约 2%，2% 的错误使每区间观察重组率增至约 5%—6%，图谱长度增至约 2.7 倍（习题 6.17：18 cM 虚增为 48.7 cM）。 [题目]

6.6 B。平均为 0.8 cM/Mb，但重组在热点集中、着丝粒附近通常受抑制，雌雄图谱也常不同。 [题目]

二、判断与改错题

6.7 错误。 $c_{AC} = c_{AB} + c_{BC} - 2\gamma c_{AB}c_{BC}$ ，只有完全干涉（ $\gamma = 0$ ）时才相加。图距（交换的期望数）才具有可加性。 [题目]

6.8 错误。回交中存活选择作用于一个位点时，标记分离比偏离 1:1，但相邻标记之间的重组计数主要反映该区间内的交换，选择只是改变了不同单倍型的权重，偏差通常很小（习题 6.19 中相邻区间估计 0.061—0.105，围绕真值 0.091 波动，未见系统偏差）。偏分离造成的主要问题是：单标记检验假阳性、选择区域附近的 LOD 与定位受影响，以及在某些群体（如 F₂、选择强烈或存在配子选择）中重组率估计也可能有偏。 [题目]

6.9 正确。见习题 6.17。 [题目]

6.10 正确。相位未知、 $n = 10$ 、 $k = 0$ 时， $L(\hat{c}) = \frac{1}{2} \times 1$ ， $L(1/2) = 0.5^{10}$ ， $\text{LOD} = \log_{10}(0.5 \times 2^{10}) = 2.71 < 3$ 。 [题目]

三、填空题

6.11 Haldane $-50 \ln 0.6 = 25.5$ cM；Kosambi $25 \ln(1.4/0.6) = 21.2$ cM。 [题目]

6.12 期望双交换 $0.12 \times 0.08 \times 500 = 4.8$ ；并发系数 $3/4.8 = 0.625$ ；干涉 0.375。 [题目]

6.13 100 cM；雄性（公畜家系中只能观察到雄性减数分裂中的重组）。 [题目]

6.14 0.8 cM/Mb；3.75 倍，可能是重组热点。 [题目]

四、计算题

6.15 (1) EM 估计 $\hat{c} = 0.198$ (SE 0.024), LOD 17.4, 1-LOD 支持区间 (0.151,0.255)。格点搜索与 EM 结果一致。

(2)

c	F2 信息	回交信息	F2/回交
0.01	199.98	101.01	1.98
0.05	39.90	21.05	1.90
0.10	19.78	11.11	1.78
0.20	9.56	6.25	1.53
0.30	6.08	4.76	1.28
0.40	4.49	4.17	1.08

F2 个体同时提供两次减数分裂的信息，紧密连锁时几乎是回交的两倍；随着 c 增大，双杂合子比例上升且相位不明，F2 的优势逐渐消失。设计图谱群体时，若主要关心紧密连锁标记的排序，F2 更有效率；若关心远距离连锁，回交与 F2 差别不大。

[题目]

6.16 (1) 两点估计中最近的一对为 M2—M5 (0.027)，最远的一对为 M3—M4 (0.333)。

(2) 三种准则都给出 M3—M1—M5—M2—M6—M4，与真实顺序一致。

(3) 次优顺序为 M3—M1—M2—M5—M6—M4 (交换了最近的一对)，LOD 差 4.69，意味着最优顺序的似然约为次优的 $10^{4.7}$ 倍，排序可信。相邻区间图距为 10.3、14.6、2.7、16.4、12.0 cM，总长 56.1 cM (真值 50 cM)，偏差源于 150 只个体的抽样误差。紧密连锁的标记对 (2.7 cM) 最难排序，常用的做法是先把它们合并为一个 “bin”，再逐步插入。

[题目]

6.17 (1) 真实总长 18.0 cM；直接计数估计 48.7 cM，虚增约 2.7 倍；HMM-EM 估计 14.3 cM，接近真值 (略低是因为 200 只个体中真实重组本来就少，个别区间估计偏小)。

(2) $\hat{\epsilon} = 0.0184$ (真值 0.02)。

(3) 后验错误概率 >0.5 的观测共 39 个，其中 35 个确为模拟错误，且 35 个模拟错误全部被检出。端点标记只有一侧邻居：端点处 “观测与邻居不同” 既可能是错误，也可能是端点区间真实重组，两种解释的似然比只依赖一个区间，因而后验不确定，是假阳性与漏检的主要来源。实践中常在端点处要求更高的质量阈值，或利用更外侧的标记。

[题目]

6.18 (1)

m	$d = 0.05$	0.1	0.2	0.3	0.5	0.8	并发系数
0 (模拟)	0.048	0.090	0.165	0.226	0.317	0.399	0.98
1 (模拟)	0.050	0.099	0.187	0.261	0.366	0.447	0.52
4 (模拟)	0.050	0.100	0.197	0.286	0.412	0.483	0.11
Haldane	0.048	0.091	0.165	0.226	0.316	0.399	1
Kosambi	0.050	0.099	0.190	0.269	0.381	0.461	—

(2) $m = 0$ 时并发系数约 1 (无干涉); $m = 1$ 时约 0.52; $m = 4$ 时仅约 0.11 (强干涉)。

(3) m 是两个相邻交叉之间“未分化为交叉”的前体事件数; m 越大, 相邻交叉间距越规则, 短距离内很难出现双交叉。 $m = 1$ 时的重组率曲线介于 Haldane 与 Kosambi 之间, 在中短距离与 Kosambi 接近。实际物种中常估计 $m \approx 1-4$ (如小鼠、人类约为 4), 若用 Haldane 函数会高估图距。 [题目]

6.19 (1) 存活个体 475 只。偏离在 30—40 cM 处最大 (A 型比例 0.594, $\chi^2 = 16.7$, $p = 4.4 \times 10^{-5}$), 向两侧逐渐减小, 100 cM 处仍有轻微偏离 (0.552)。观察曲线与理论曲线 $[(1-c) + cv]/(1+v)$ 走势一致, 波动来自抽样。

(2) 复合似然估计存活位点约在 36 cM、aa 相对存活率约 0.64 (真值 43 cM、0.6)。单个回交群体中偏分离定位的分辨率较低, 需要更多个体或加密标记。

(3) 相邻区间重组率估计在 0.061—0.105 之间, 围绕真值 0.091 随机波动, 未见系统偏差。实际资料中若发现强烈偏分离, 应同时检查分型质量 (错误也可造成单标记偏离, 但不形成平滑的局部峰形)。 [题目]

6.20 (1) $L(c) = \prod_f \frac{1}{2} [c^{k_f} (1-c)^{n_f-k_f} + c^{n_f-k_f} (1-c)^{k_f}]$ 。

(2) 部分结果 (功效: 相位已知/未知): 1 家系 $\times 20$ 只 0.41/0.18; 2×10 0.39/0.17; 4×10 0.86/0.60; 8×10 1.00/0.98; 2×20 0.86/0.76。平均 LOD 损失接近 $F \log_{10} 2$ 的上限 (每家系 0.30)。

(3) $n = 10$ 时相位未知的最大可能 LOD 为 2.71 (见习题 6.10), 因此无论观察结果如何都达不到 3。设计远交家系连锁研究时, 应保证每个家系有足够的后代 (相位“自我确定”), 或利用祖代基因型确定相位; 在总后代数固定时, 相位未知使“少家系、多后代”的设计更有优势, 但这又与估计 QTL 方差所需的“多家系”相矛盾 (第 8 章)。 [题目]

6.21 (1) 亲本型 ABC/abc, 双交换型 AbC/aBc 与亲本型只在 B 位点不同, 故 B 在中间,

顺序为 A—B—C。

(2) $c_{AB} = (52 + 48 + 7 + 7)/1000 = 0.114$; $c_{BC} = (85 + 91 + 7 + 7)/1000 = 0.190$;
若只看两端, $c_{AC} = (52 + 48 + 85 + 91)/1000 = 0.276$, 比 $c_{AB} + c_{BC} = 0.304$ 少了
两倍的双交换 (0.028)。

(3) 期望双交换 $0.114 \times 0.190 \times 1000 = 21.7$, 观察 14, 并发系数 0.646, 干涉 0.354。

[题目]

6.22 Haldane: $d_{AB} = 5.27$ cM, $d_{BC} = 17.83$ cM, 总长 23.10 cM, $c_{AC} = 0.05 + 0.15 - 2 \times 0.05 \times 0.15 = 0.185$ 。Kosambi: $d_{AB} = 5.02$, $d_{BC} = 15.48$, 总长 20.49 cM, $c_{AC} = 0.20/(1 + 4 \times 0.0075) = 0.194$ 。Kosambi 假设存在正干涉, 双交换较少, 因此两端位点表现为重组的概率更高 ($0.194 > 0.185$), 但同样的重组率对应的图距更短。

[题目]

五、推导与证明题

6.23 见推导 6.1。证明可加性: 设 $K_1 \sim \text{Poisson}(d_1)$ 、 $K_2 \sim \text{Poisson}(d_2)$ 独立, $1 - 2c = E[(-1)^K] = e^{-2d}$ 。 $E[(-1)^{K_1+K_2}] = E[(-1)^{K_1}]E[(-1)^{K_2}]$, 即 $1 - 2c_{AC} = (1 - 2c_{AB})(1 - 2c_{BC})$, 展开即得。

[题目]

6.24 回交: $\ell = k \ln c + (n - k) \ln(1 - c)$, $\hat{c} = k/n$, $\mathcal{I} = n/[c(1 - c)]$, $\text{LOD} = [\ell(\hat{c}) - n \ln \frac{1}{2}]/\ln 10$ 。相位未知: 令 $L_1 = c^k(1 - c)^{n-k}$, $L_2 = c^{n-k}(1 - c)^k$, $L = \frac{1}{2}(L_1 + L_2) \geq \frac{1}{2} \max(L_1, L_2)$, 而 $L(\frac{1}{2})$ 在两种情形相同。相位已知时 LOD 由正确相位的似然 L_1 (设 $k < n/2$ 为正确相位) 在其最大值处计算; 相位未知时 $\max_c L \geq \frac{1}{2} \max_c L_1$, 故 LOD 损失 $\leq \log_{10} 2$; 当 $L_2(\hat{c}) \ll L_1(\hat{c})$ 时损失接近 $\log_{10} 2$ (习题 6.20 模拟中平均损失 0.287—0.301)。

[题目]

6.25 见推导 6.2。合并公式: $\tanh$ 的加法定理 $\tanh(x + y) = \frac{\tanh x + \tanh y}{1 + \tanh x \tanh y}$, 令 $\tanh(2d_i) = 2c_i$, 得 $2c_{AC} = \frac{2c_{AB} + 2c_{BC}}{1 + 4c_{AB}c_{BC}}$ 。

[题目]

6.26 前向递推见推导 6.3。后向: $\beta_m(g) = 1$, $\beta_j(g) = \sum_{g''} T_{gg''} e_{j+1}(g'') \beta_{j+1}(g'')$ 。由马尔可夫性, $P(o, g_j = g) = P(o_{1:j}, g_j = g)P(o_{j+1:m} | g_j = g) = \alpha_j(g) \beta_j(g)$, 除以 L 即得后验。Baum-Welch: 区间 j 的重组后验

$$\tilde{\zeta}_j = \frac{\sum_{g \neq g''} \alpha_j(g) T_{gg''} e_{j+1}(g'') \beta_{j+1}(g'')}{L},$$

对全部个体求和后除以个体数得新的 c_j ; 错误率更新为所有个体与位点上 $P(g_j \neq o_j | o)$ 的平均。

[题目]

六、综合分析与研究设计题

6.27 流程：(1) **原始数据质控：**按测序深度与基因型质量过滤，深度过低的杂合子易被误判为纯合子，可用似然基因型而非硬判型；(2) **位点过滤：**剔除缺失率过高(如 $>50\%$)、严重偏分离且无生物学解释、与亲本不一致的位点；(3) **分群：**以两点 LOD (如 ≥ 5) 把标记分为连锁群，与染色体数核对；(4) **分箱：**把完全共分离的标记合并为 bin，降低计算量与排序歧义；(5) **排序：**用多点似然或启发式算法(如 MSTmap、Lep-MAP) 排序，必要时以物理图谱作为参照；(6) **错误建模：**用 HMM 同时估计重组率与错误率，或先用平滑算法校正明显的孤立双交换；(7) **图距估计与评估：**比较不同错误模型下的总长度、检查孤立“双交换”比例、与已知图谱共线性；(8) **输出：**图谱、每个 bin 的置信区间、基因型的后验概率，以便后续 QTL 分析传播不确定性。 [题目]

6.28 颠倒区段：生物学解释——该群体与参考个体之间存在倒位多态，杂合倒位个体在该区段内重组受抑，纯合个体的重组顺序与参考相反；技术解释——组装错误(scaffold 方向错接)。检验：用长读长或光学图谱、Hi-C 资料检查该区段两端的连接；在多个独立家系中检查顺序是否一致(倒位多态会因家系而异)。**无重组区段：**生物学解释——着丝粒或异染色质区、倒位杂合导致的重组抑制、或真实的重组冷区；技术解释——该区段在图谱群体中缺乏多态(两亲本同源)，导致无法观察重组。检验：检查该区段标记在亲本中的杂合度；比较雌雄图谱与其他群体图谱；检查物理组装是否把重复序列错误折叠。 [题目]

6.29 理由：(1) **基因型填充：**HMM 类填充方法需要遗传距离以确定状态转移概率，物理距离代替遗传距离会在热点与冷区处出错；(2) **单倍型与同祖片段：**以 cM 而非 Mb 衡量片段长度，才能正确推断共同祖先的代数与近交(第 19 章 ROH)；(3) **QTL 与 GWAS 区间解释：**LD 衰减与置信区间以遗传距离为尺度，跨品种比较也需对齐遗传图。方案：利用品种内有系谱的家系(父母—后代三元组或大的半同胞家系)，在芯片资料中推断相位与交换点(如逐家系检测父源、母源单倍型的切换点)；按性别分别累积交换点，在固定物理窗口内估计重组率，再平滑得到品种特异的遗传图；用留一染色体或留一家系检验估计的稳定性；最后与公开的近缘品种图谱比较，识别品种特异的热点或倒位。 [题目]

第三篇

数量性状基因定位

影响性状的位点在哪里、有多大。

本篇习题训练：杂交群体的区间作图与远交群体的连锁分析、关联定位与GWAS。

杂交群体的数量性状位点定位

7.1 本章导学

学习目标

- 1. 能写出回交、F2 与重组近交系中标记基因型类别的期望表型，理解效应估计与 QTL 位置的混杂。
- 2. 掌握区间作图的原理：由侧翼标记计算 QTL 基因型条件概率，用最大似然或 Haley-Knott 回归计算 LOD 曲线。
- 3. 理解全基因组扫描的多重检验问题，能用置换检验与理论近似确定显著性阈值。
- 4. 能识别连锁 QTL 造成的抵消与“幽灵”峰，理解复合区间作图与多 QTL 模型的作用。
- 5. 能分析选择性基因分型与 DNA 混池等高效设计的功效与偏差，并给出校正方法。
- 6. 理解 Beavis 效应、定位分辨率与从 QTL 到致因变异的证据链。

重点与难点

重点：标记类别均值与 QTL 效应的关系；区间作图与 LOD；置换阈值；复合区间作图；选择性分型。

难点：单标记分析中“小效应近标记”与“大效应远标记”无法区分；区间作图对连锁 QTL 的误判；选择性分型后朴素估计的放大偏差；低功效研究中显著效应的系统性高估；阈值依赖基因组大小与标记密度而非样本量。

本章把第 6 章的连锁图谱与第 3 章的似然推断结合起来。第 8 章将把同样的思想推广到远交群体，第 25 章将从“缺失遗传力”的角度重新审视 QTL 定位结果的含义。

7.2 知识结构图




图 7.1 第 7 章知识结构图

右侧四支构成“模型 → 检验 → 区间作图 → 阈值”的定位主线；左侧三支讨论多 QTL、高效设计与结果解释。

7.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
回交单标记	$\bar{y}_{Mm} - \bar{y}_{mm} = (1 - 2c)(a + d)$	回交 F1× 隐性亲本；效应与位置混杂
F2 单标记	$\bar{y}_{MM} - \bar{y}_{mm} = 2a(1 - 2c)$ ；杂合离差含 $d(1 - 2c)^2$	共显性标记
QTL 方差	F2: $V_Q = \frac{1}{2}a^2 + \frac{1}{4}d^2$ ；BC: $V_Q = \frac{1}{4}(a + d)^2$	相对于 F2/BC 群体
RIL 重组率	$R = 2c/(1 + 2c)$	自交至纯合
Haley-Knott	$y = \mu + a[P(QQ) - P(qq)] + dP(Qq) + e$	以条件概率代替未知基因型
LOD	$\text{LOD} = \frac{n}{2} \log_{10}(RSS_0/RSS_1)$	正态残差
置换阈值	置换表型后全基因组最大 LOD 的 $1 - \alpha$ 分位数	控制全基因组 FWER

概念	公式或定义	成立条件与提示
Lander-Botstein	$P(\max \text{LOD} > T) \approx (C + 2\rho GZ^2)[1 - \Phi(Z)],$ $Z^2 = 2T \ln 10$	稠密图; BC 中 $\rho = 1$
支持区间	LOD 下降 1.5 (或 1) 所对应的区间	近似 95% 区间
选择性分型	两尾各取 $p/2$; 朴素估计放大, 需用全部表型的似然	分型成本高于测表型
Beavis 偏差	$E(\hat{\beta} \text{显著}) = \beta + \text{SE} \frac{\varphi(z - \lambda) - \varphi(-z - \lambda)}{1 - \Phi(z - \lambda) + \Phi(-z - \lambda)}$	$\lambda = \beta / \text{SE}$

7.4 补充内容与公式推导

推导 7.1 Haley-Knott 回归与 LOD

在检测位置 x , QTL 基因型 g 未知, 但给定标记资料 M 的条件概率 $\pi_g = P(g | M)$ 可由侧翼标记 (或 HMM) 求得。真实模型 $y = \mu + a z_a(g) + d z_d(g) + e$, $z_a(QQ, Qq, qq) = (1, 0, -1)$, $z_d = (0, 1, 0)$ 。对 g 取条件期望:

$$E(y | M) = \mu + a[\pi_{QQ} - \pi_{qq}] + d \pi_{Qq}.$$

Haley-Knott 以此线性回归近似混合似然: 残差包含由 g 的不确定性产生的额外方差, 但在标记信息充分时这部分很小。设零模型与 QTL 模型的残差平方和为 $\text{RSS}_0, \text{RSS}_1$, 正态似然比为 $(\text{RSS}_0 / \text{RSS}_1)^{n/2}$, 故 $\text{LOD} = \frac{n}{2} \log_{10}(\text{RSS}_0 / \text{RSS}_1)$ 。在标记位置处 π_g 为 0 或 1, 回归退化为单标记方差分析; 在标记之间, 回归同时利用两侧标记, LOD 可以高于两侧标记的 LOD。若 QTL 效应很大或标记稀疏, 残差的异方差使 HK 估计效率下降, 应改用完整混合似然 (EM)。

推导 7.2 重组近交系中的表观重组率

F1 (AB/ab) 连续自交至纯合。记 R_t 为第 t 代个体中两位点 “以重组型纯合” 的累积概率。每代杂合区段继续分离, Haldane 与 Waddington 给出极限

$$R = \frac{2c}{1 + 2c}.$$

直观推导: 最终纯合系的单倍型由 “第一次在两位点间切换” 之前的亲本来源决定。F1 产生重组配子的概率为 c ; 若第一代未定局 (个体仍为双杂合), 则重新进入类似状态, 几何级数求和得 $R = c + \dots = 2c / (1 + 2c)$ 。小 c 时 $R \approx 2c$: RIL 把图谱 “拉长”

约一倍，同样数目的个体可观察到更多重组，定位分辨率提高；代价是失去杂合子，无法估计显性效应。进一步的高世代互交系（AIL）每代随机交配， t 代后约把图谱拉长 $t/2$ 倍。

推导 7.3 Beavis 效应的截断正态解释

设效应估计 $\hat{\beta} \sim N(\beta, s^2)$ ，只有 $|\hat{\beta}/s| > z$ 时才被报告。令 $\lambda = \beta/s$ ， $W = \hat{\beta}/s \sim N(\lambda, 1)$ 。在 $W > z$ 或 $W < -z$ 的条件下，

$$E(W | |W| > z) = \lambda + \frac{\varphi(z - \lambda) - \varphi(-z - \lambda)}{1 - \Phi(z - \lambda) + \Phi(-z - \lambda)}.$$

分母正是检验功效。功效越低（ λ 小于或接近 z ），校正项越大，被报告的效应越被高估；功效接近 1 时偏差消失。这说明：（1）小样本研究中“显著 QTL 解释了 10% 的方差”往往是真实效应的数倍；（2）效应估计应在独立样本中重新估计，或用条件似然、贝叶斯收缩校正；（3）元分析若只汇总显著结果，同样会继承这一偏差。

易错辨析

- 单标记差值小不等于 QTL 效应小：它是 $(1 - 2c)$ 与效应的乘积。
- LOD 阈值 3 并非全基因组阈值：阈值随基因组长度、标记密度与群体类型而变，应通过置换或理论近似确定。
- 区间作图只拟合一个 QTL：同染色体上的多个 QTL 可能互相抵消（相斥）或合成一个虚假的中间峰（相引）。
- 选择性分型后不能直接比较分型个体的均值：两尾选择抬高了组间差，必须用全部表型的似然或回归校正。
- DNA 混池不能估计显性效应，也不能分离个体基因型；技术误差决定其功效上限。

7.5 习题

一、单项选择题

7.1 ★ [单选] 回交群体中，标记两类基因型的均值差为 $(1 - 2c)(a + d)$ 。下列说法正确的是

- (A) 由该差值可以同时估计 c 与 $a + d$
- (B) 差值相同的标记，可能对应近处小效应或远处大效应的 QTL

(C) 差值与 c 无关

(D) 差值等于 a

[答案]

7.2 ★★ [单选] 同一染色体上相距 40 cM 的两个 QTL 效应方向相反（相斥），简单区间作图最可能的结果是

(A) 两个清晰的峰

(B) 峰值被削弱甚至检测不到

(C) 峰值增大

(D) 结果与只有一个 QTL 相同

[答案]

7.3 ★ [单选] 用置换检验确定 QTL 扫描阈值，其控制的错误率是

(A) 每个检测位置的第一类错误率

(B) 全基因组族错误率

(C) 错误发现率

(D) 第二类错误率

[答案]

7.4 ★★ [单选] 关于选择性基因分型，下列说法错误的是

(A) 只对表型两尾分型可以显著节省分型成本

(B) 每个分型个体提供的信息多于随机分型个体

(C) 用分型个体的均值差直接估计效应是无偏的

(D) 应使用全部个体的表型进行似然分析

[答案]

7.5 ★★ [单选] Beavis 效应指的是

(A) QTL 位置估计偏向标记

(B) 低功效研究中被检出 QTL 的效应被高估

(C) 多个 QTL 的效应相互抵消

(D) 置换阈值偏高

[答案]

7.6 ★ [单选] 下列群体中，能够分别估计 QTL 加性效应与显性效应的是

(A) 回交

(B) F2

(C) 重组近交系

(D) 双单倍体

[答案]

二、判断与改错题

7.7 ★★ [判断] 复合区间作图在检测位置附近也加入协因子标记，可以进一步提高检测功效。

[答案]

7.8 ★★ [判断] 在区间作图中, 两个标记之间某个位置的 LOD 可以高于两侧任一标记处的 LOD。 [答案]

7.9 ★ [判断] 对任意性状和任意群体, 全基因组 5% 显著性的 LOD 阈值都约为 3.0。

[答案]

7.10 ★ [判断] DNA 混池分析可以同时估计 QTL 的加性效应与显性效应。 [答案]

三、填空题

7.11 ★ [填空] 回交群体中某标记与 QTL 的重组率为 0.1, QTL 的 $a + d = 5$, 则标记两类均值差的期望为_____; 若另一标记观察差为 3.2、重组率为 0.2, 则 $a + d$ 约为_____。 [答案]

7.12 ★ [填空] F₂ 群体中 QTL 的 $a = 2$, 标记与 QTL 的重组率 $c = 0.1$, 则 $\bar{y}_{MM} - \bar{y}_{mm}$ 的期望为_____。 [答案]

7.13 ★ [填空] F₂ 群体中某 QTL $a = 1$ 、 $d = 0.5$, 残差方差为 4, 则 QTL 遗传方差为_____, 解释表型方差的比例为_____。 [答案]

7.14 ★ [填空] 对表型最高与最低各 20% 的个体分型, 分型比例为_____; 上尾个体标准化表型的平均值约为_____。 [答案]

四、计算题

7.15 ★★ [计算] **Haley-Knott 区间作图**。300 个 F₂ 个体、11 个共显性标记 (每 10 cM), 模拟资料见配套数据 (真实 QTL 位于 47 cM, $a = 0.6$, $d = 0.3$, $\sigma_e = 1$)。(1) 每 1 cM 计算 HK 回归 LOD 曲线, 报告峰位置、 $\hat{a}$ 、 $\hat{d}$ 与 1.5-LOD 支持区间; (2) 与单标记分析比较; (3) 计算真实 QTL 解释的表型方差比例。 [程序] [ch07/ex07_15_haley_knott.py](#)

[答案]

7.16 ★★ [计算] **全基因组阈值**。回交 200 个体, 5 条 100 cM 染色体, 每 10 cM 一个标记、每 2 cM 检测一次。(1) 在无 QTL 资料上做 1000 次置换, 求 10%、5%、1% 全基因组阈值; (2) 与 Lander-Botstein 近似及单点名义阈值比较; (3) 由 5% 阈值反推“有效独立检验数”。 [程序] [ch07/ex07_16_permutation_threshold.py](#) [答案]

7.17 ★★★ [计算] 幽灵与抵消。回交 400 个体，同一染色体 25 cM (+0.5) 与 65 cM (-0.5) 处两个相斥 QTL。(1) 比较简单区间作图与复合区间作图 (窗口 ± 10 cM) 的 LOD 曲线；(2) 用两 QTL 模型在网格上联合搜索；(3) 解释简单区间作图失败的原因。 [程序] `ch07/ex07_17_ghost_cim.py` [答案]

7.18 ★★ [计算] 选择性基因分型。回交 1000 个体全部测表型，QTL 效应 $a = 0.25\sigma_e$ (位于标记处)。分别只分型两尾合计 50%、30%、20%、10% 的个体。(1) 比较各方案的检测功效 ($\alpha = 0.001$) 与全部分型；(2) 比较朴素估计与利用全部表型的 EM 似然估计的平均值；(3) 计算“每个分型个体贡献的 χ^2 ”，说明分型资源的使用效率。 [程序] `ch07/ex07_18_selective_genotyping.py` [答案]

7.19 ★★ [计算] Beavis 效应。QTL 真实解释 3% 的表型方差。对 $n = 100 \sim 1600$ 各模拟 2 万次，只保留 $\alpha = 0.001$ 下显著的结果。(1) 比较模拟功效与理论功效；(2) 求显著结果的平均 R^2 与 $\hat{a}/a$ ，并与截断正态理论比较；(3) 给出“功效与高估程度”的定量关系。 [程序] `ch07/ex07_19_beavis_effect.py` [答案]

7.20 ★★ [计算] DNA 混池。高、低表型尾部池中某标记等位基因的真实频率分别为 0.62 与 0.38，每池重复测定 2 次。(1) 在技术误差标准差 $\sigma_t = 0, 0.02, 0.04$ 下，计算每池 50—400 只个体时的检测功效 ($\alpha = 0.001$)，并以模拟核对；(2) 求 $\sigma_t = 0.04$ 、个体数无穷大时的极限功效；(3) 讨论增加个体数与增加重复测定的取舍。 [程序] `ch07/ex07_20_dna_pooling.py` [答案]

7.21 ★ [计算] F2 群体中，与 QTL 完全连锁的标记三类基因型均值为：MM 25.0，Mm 23.6，mm 21.0。估计 a 、 d 与显性度 d/a ，并说明若标记与 QTL 之间有重组，这些估计会怎样偏向。 [答案]

7.22 ★ [计算] F1 两位点重组率 $c = 0.1$ 与 $c = 0.05$ 时，重组近交系中的表观重组率各为多少？说明 RIL 在定位中的优势与代价。 [答案]

五、推导与证明题

7.23 ★★ [证明] 在回交群体中，设 QTL 位于两个标记 M, N 之间，与 M 、 N 的重组率为 r_1, r_2 ， $M-N$ 重组率为 r (无干涉)。推导四种标记类别下 QTL 为杂合子的条件概率，并说明 Haley-Knott 回归的设计变量如何由这些概率构成。 [答案]

7.24 ★★ [证明] 证明正态残差下线性模型的似然比 LOD 为 $\frac{n}{2} \log_{10}(RSS_0/RSS_1)$, 并说明当 QTL 基因型以条件概率代替时, 这一公式为何只是近似。 [答案]

7.25 ★★ [证明] 证明回交群体中, 与 QTL 重组率为 c 的单个标记所能解释的表型方差, 等于 QTL 方差乘以 $(1 - 2c)^2$ 。由此说明标记稀疏时单标记分析的功效损失。 [答案]

7.26 ★★★ [证明] 推导截断正态下显著效应估计的条件期望(推导 7.3), 并证明当功效趋于 1 时偏差趋于零; 当真实效应为零时, 显著结果的绝对效应均值为 $s\varphi(z)/[1 - \Phi(z)]$ 。 [答案]

六、综合分析与研究设计题

7.27 ★★ [综合] 一个 F2 研究把某生长 QTL 定位在约 20 cM 的区间内。请设计一个分步精细定位方案(含高世代互交系、近等基因系或回交重组子筛选、关联分析与功能验证), 说明每一步预期把区间缩小到多大以及所需资源。 [答案]

7.28 ★★ [综合] 某研究在同一 F2 群体中对 10 个性状做 QTL 扫描, 发现 6 号染色体上一个区间同时影响 4 个性状, 作者据此称该区间存在一个“多效性主效基因”。请指出需要考虑的替代解释(紧密连锁的多个 QTL、性状间相关、阈值与多重检验), 并提出检验方案。 [答案]

7.29 ★★★ [综合] 在总预算固定(表型测定每只 100 元, 分型每只 200 元)的条件下, 比较全部分型的 F2、选择性分型的 F2 与 RIL 三种设计检测一个解释 3% 方差的 QTL 的效率。列出比较所需的公式与假设, 并给出你的推荐。 [答案]

7.6 参考答案与解析

一、单项选择题

7.1 B。 单标记差值是 $(1 - 2c)$ 与 $a + d$ 的乘积, 单靠一个标记无法区分两者, 这正是区间作图利用侧翼标记的动机。 [题目]

7.2 B。 相斥 QTL 使每个标记的均值差中两个效应相互抵消(习题 7.17 中简单区间作图最大 LOD 仅 1.52), 可能检测不到或在错误位置出现弱峰。 [题目]

7.3 B。 置换保持基因型结构不变、打乱表型, 每次记录全基因组最大 LOD, 其分位数控制全基因组 FWER。 [题目]

7.4 C。两尾选择使分型个体的组间差被放大（习题 7.18 中只分型 10% 时朴素估计为真值的 4 倍以上）。[题目]

7.5 B。见推导 7.3。[题目]

7.6 B。F₂ 包含三种基因型；回交、RIL 与双单倍体中只有两种基因型，无法分离 a 与 d 。[题目]

二、判断与改错题

7.7 错误。检测位置附近的协因子标记与检测位置的 QTL 基因型高度相关，会“吸收”待检 QTL 本身的效应，降低功效。CIM 只在一定窗口之外加入协因子，用以吸收其他 QTL 与背景遗传变异。窗口大小在功效与控制背景之间权衡。[题目]

7.8 正确。标记之间的位置同时利用两侧标记信息，若 QTL 恰在两标记中间，其 LOD 通常高于两侧标记处的单标记 LOD。[题目]

7.9 错误。阈值取决于基因组长度、染色体数、标记密度、群体类型及检测的自由度（BC 1 df、F₂ 2 df）。习题 7.16 中 5 M 回交基因组的 5% 阈值约 2.3；大型基因组的 F₂ 可能需要 3.5—4。[题目]

7.10 错误。混池只能测定池中等位基因频率，无法得到个体基因型，因而不能估计显性效应，也无法做个体层面的协变量校正。[题目]

三、填空题

7.11 $(1 - 0.2) \times 5 = 4.0$; $3.2 / (1 - 0.4) = 5.33$ 。[题目]

7.12 $2 \times 2 \times (1 - 0.2) = 3.2$ 。[题目]

7.13 $V_Q = 0.5 \times 1 + 0.25 \times 0.25 = 0.5625$; 比例 $0.5625 / 4.5625 = 12.3\%$ 。[题目]

7.14 40%; $i(0.2) = \varphi(0.8416) / 0.2 = 1.400$ 。[题目]

四、计算题

7.15 (1) LOD 峰位于 42 cM（真值 47 cM），峰值 9.79；1.5-LOD 支持区间 [34, 48] cM，包含真值； $\hat{a} = 0.552$ 、 $\hat{d} = 0.358$ 。

(2) 单标记 LOD 最大在 40 cM 标记处（9.70），其次 50 cM（7.46）。本例 QTL 靠近 40 cM 标记，区间作图的峰值只略高于单标记，但提供了位置估计与支持区间；

QTL 若恰在两标记中点，区间作图的优势更明显。

(3) $V_Q = \frac{1}{2}(0.6)^2 + \frac{1}{4}(0.3)^2 = 0.2025$ ，比例 $0.2025/1.2025 = 16.8\%$ 。300 个 F2 个体足以检测这样的大效应 QTL，但支持区间仍宽达 14 cM，说明 F2 的定位分辨率有限。 [题目]

7.16 (1) 置换阈值：10% 1.98，5% 2.27，1% 3.08。

(2) Lander–Botstein 近似：2.08、2.41、3.17，略为保守（它针对无限稠密的标记，而本例只有 255 个检测位置）；单点名义阈值仅 0.59、0.83、1.44，远低于全基因组阈值。

(3) 5% 阈值对应单点 $p = 0.00123$ ，由 $1 - (1 - p)^m = 0.05$ 反推 $m \approx 42$ 个有效独立检验——远少于 255 个检测位置，因为相邻位置高度相关。若把基因组扩大到 30 M，阈值约升至 3。 [题目]

7.17 (1) 简单区间作图的最大 LOD 仅 1.52（30 cM 处），低于任何合理阈值，第二个 QTL 完全被掩盖；复合区间作图在 30 cM（LOD 3.38）与 60 cM（LOD 1.93）恢复两个峰。

(2) 两 QTL 联合模型在 (30, 62) cM 得到效应 +0.633 与 -0.643，LOD 6.85，远高于任一单 QTL 模型。

(3) 简单区间作图在每个位置只拟合一个 QTL。相斥的两个 QTL 使大部分标记的均值差同时含有正、负两项，相互抵消；回交中检测位置与两 QTL 的相关分别为 $(1 - 2c_1)$ 与 $(1 - 2c_2)$ ，二者加权后的净效应接近零。复合区间作图用远处协因子吸收另一 QTL 的效应，多 QTL 模型则同时估计两个效应，从而恢复信号。 [题目]

7.18

分型比例	分型数	功效	朴素 $\hat{a}$ 均值	似然 $\hat{a}$ 均值	每分型个体 χ^2
100%	1000	0.739	0.251	0.251	0.0167
50%	500	0.678	0.462	0.244	0.0312
30%	300	0.578	0.650	0.249	0.0451
20%	200	0.482	0.823	0.255	0.0597
10%	100	0.255	1.084	0.247	0.0823

只分型一半个体，功效仅从 0.74 降为 0.68；每个分型个体贡献的检验统计量随选择强度增加而升高（10% 时约为随机分型的 5 倍）。朴素估计严重放大效应，而利用全部表型的 EM 似然（未分型个体的基因型作为缺失）给出近似无偏的估计。分型比例过小时总信息不足，功效迅速下降，实践中常取 20%—50%。 [题目]

7.19

n	功效 (模拟/理论)	显著者平均 R^2	$\hat{a}/a$ (模拟/理论)
100	0.064 / 0.063	0.122	2.12 / 2.12
200	0.211 / 0.211	0.070	1.55 / 1.55
400	0.588 / 0.590	0.043	1.19 / 1.19
800	0.952 / 0.954	0.032	1.02 / 1.02
1600	1.000 / 1.000	0.030	1.00 / 1.00

功效 6% 时, 被检出的 QTL 平均“解释”12% 的方差, 是真值的 4 倍; 功效约 60% 时仍高估约 19%; 功效超过 95% 后偏差可忽略。Beavis (1994) 的模拟正是揭示了这一规律: 小样本 QTL 研究报告的效应大小不可信, 需要在独立大样本中重新估计。

[题目]

7.20 (1) 功效 (模拟值在括号中):

每池个体数	$\sigma_t = 0$	$\sigma_t = 0.02$	$\sigma_t = 0.04$
50	0.541 (0.533)	0.490 (0.488)	0.368 (0.363)
100	0.934 (0.947)	0.878 (0.883)	0.676 (0.672)
200	1.000	0.996	0.886 (0.891)
400	1.000	1.000	0.964

(2) $n \rightarrow \infty$ 时抽样误差消失, 只剩技术误差 $\text{Var} = 2 \times 0.04^2/2$, 非中心参数 $0.24/0.04 = 6.0$, 极限功效 0.997。

(3) 当 $p(1-p)/(2n) \gg \sigma_t^2/k$ 时, 增加个体数更有效; 反之增加重复测定更有效。本例 $\sigma_t = 0.04$ 、 $k = 2$ 时技术方差 0.0008, 相当于每池约 150 只个体的抽样方差, 因此每池超过 150 只后, 再增加个体的收益迅速下降, 应优先改进测定精度或增加重复。

[题目]

7.21 $\hat{a} = (25.0 - 21.0)/2 = 2.0$; $\hat{d} = 23.6 - (25.0 + 21.0)/2 = 0.6$; $d/a = 0.3$, 部分显性。若标记与 QTL 之间有重组率 c , $\bar{y}_{MM} - \bar{y}_{mm}$ 的期望为 $2a(1-2c)$, 杂合离差的期望为 $d(1-2c)^2$, 两者都向零偏, 且 d 偏得更多; 显性度估计也会偏离真值。

[题目]

7.22 $R = 2c/(1+2c)$: $c = 0.1$ 时 $R = 0.167$, $c = 0.05$ 时 $R = 0.091$, 约为原来的 1.7—1.8 倍。优势: 每个系是永久纯合的, 可在多个环境中重复测定, 降低环境误差; 观察到更多重组, 提高分辨率。代价: 无法估计显性; 构建需要多代自交; 只适用于可自交的物种 (动物中可用近交系或双单倍体代替)。

[题目]

五、推导与证明题

7.23 记 Q 为 QTL 杂合 (与 F1 同相)。无干涉下 $P(MQN)$ 类联合概率: $P(M, Q, N) = \frac{1}{2}(1-r_1)(1-r_2)$ 等。于是

$$\begin{aligned} P(Q | MN) &= \frac{(1-r_1)(1-r_2)}{1-r}, & P(Q | Mn) &= \frac{(1-r_1)r_2}{r}, \\ P(Q | mN) &= \frac{r_1(1-r_2)}{r}, & P(Q | mn) &= \frac{r_1r_2}{1-r}, \end{aligned}$$

其中 $1-r = (1-r_1)(1-r_2) + r_1r_2$, $r = r_1(1-r_2) + (1-r_1)r_2$ 。HK 回归的设计变量即每个个体对应的 $P(Q | \text{标记类别})$; 在标记处它退化为 0 或 1。 [题目]

7.24 正态模型 $y \sim N(X\beta, \sigma^2 I)$, 在 $\hat{\beta}, \hat{\sigma}^2 = \text{RSS}/n$ 处的最大对数似然为 $-\frac{n}{2}[\ln(2\pi\text{RSS}/n) + 1]$, 两模型之差为 $\frac{n}{2} \ln(\text{RSS}_0/\text{RSS}_1)$, 除以 $\ln 10$ 即得 LOD。条件概率代替基因型时, 真实模型是混合正态: $y | M \sim \sum_g \pi_g N(\mu_g, \sigma^2)$, 其均值与 HK 回归相同, 但方差为 $\sigma^2 + \text{Var}(\mu_g | M)$, 随个体而变 (异方差), 且分布非正态, 因此 HK 的似然只是近似; QTL 效应越大、标记信息越少, 近似越差。 [题目]

7.25 回交中标记 M 与 QTL Q 的基因型指示变量 (取 0/1, 各概率 1/2) 的相关为 $1-2c$ 。QTL 效应 $\alpha = a + d$, $V_Q = \alpha^2/4$ 。标记对表型回归解释的方差 $= \text{Cov}(y, M)^2 / \text{Var}(M) = [\alpha(1-2c)/4]^2 / (1/4) = (1-2c)^2 V_Q$ 。 $c = 0.1$ 时只剩 64%, $c = 0.2$ 时只剩 36%; 所需样本量约与 $1/(1-2c)^2$ 成正比。这说明标记间距 10 cM 以上时, 单标记分析在区间中部的 QTL 上损失显著。 [题目]

7.26 推导见推导 7.3。功效趋于 1 意味着 $\lambda - z \rightarrow \infty$, 分子 $\varphi(z-\lambda) \rightarrow 0$, $\varphi(-z-\lambda) \rightarrow 0$, 分母 $\rightarrow 1$, 偏差 $\rightarrow 0$ 。真实效应为零时 $\lambda = 0$, $W \sim N(0, 1)$, $E(|W| | |W| > z) = \varphi(z)/[1 - \Phi(z)]$, 乘以 s 即绝对效应均值。例如 $z = 3.29$ ($\alpha = 0.001$) 时约为 $3.57s$ ——零效应位点一旦“显著”, 其报告的效应大小也相当可观, 这说明效应大小本身不能证明真实性。 [题目]

六、综合分析与研究设计题

7.27 (1) **扩大群体与加密标记**: 在原 F2 区间内加密标记, 扩大到 1000—2000 只, 可把区间缩小到约 5—10 cM; (2) **高世代互交系 (AIL) 或回交重组子筛选**: 继续随机交配数代 (如 F8), 区间可缩小到 1—3 cM; 或利用回交中区间内发生重组的个体做后裔测验 (“重组子分析”); (3) **近等基因系 (NIL)**: 连续回交把目标区段导入轮回亲本背景, 比较携带与不携带区段的系, 排除背景干扰, 并通过区段内重组构

建一系列亚 NIL, 逐步缩小至数百 kb; (4) **群体关联分析**: 在多品种或远交群体中利用历史重组做关联, 区间可达数十 kb; (5) **候选基因与功能验证**: 结合表达 (eQTL)、变异注释、等位基因特异表达、基因编辑或转基因验证。每一步的资源投入大幅增加, 应在每一步检验 QTL 是否仍可重复检出, 避免追逐假阳性。【题目】

7.28 替代解释: (1) **紧密连锁的多个 QTL**: F2 的低分辨率无法区分相距几 cM 的不同 QTL; (2) **性状间表型相关**: 若 4 个性状本身高度相关 (如不同部位的体尺), 一个 QTL 影响 “体型” 即可在 4 个性状上出现峰; (3) **多重检验**: 10 个性状 $\times$ 全基因组扫描, 偶然在同一区间出现多个显著结果的概率不可忽略。检验方案: (1) 多性状联合 QTL 模型, 检验 “单一多效 QTL” 对 “两个连锁 QTL” (Jiang & Zeng 1995); (2) 比较各性状 LOD 峰的位置及其支持区间是否重叠; (3) 以一个性状为协变量后检验其余性状的 QTL 是否仍显著 (区分直接与间接效应); (4) 在 AIL 或独立群体中精细定位, 观察峰是否分离; (5) 对所有性状的扫描统一控制多重检验。【题目】

7.29 比较框架: 检测功效由非中心参数 $\lambda = N_{\text{eff}} \cdot R^2 / (1 - R^2)$ 决定。(1) 全部分型 F2: 每只成本 300 元, 预算 B 可做 $N = B/300$ 只; (2) 选择性分型 F2: 测表型 N_p 只, 分型其中比例 p , 成本 $100N_p + 200pN_p$; 每个分型个体的信息约为随机个体的 $1 + z_i$ 倍 (i 为尾部选择强度, z 为截断点), 例如 $p = 0.3$ 时约 2.7 倍 (习题 7.18: 0.0451/0.0167); (3) RIL: 每个系测定 r 次重复以降低环境方差, 并考虑 QTL 方差在 RIL 中为 a^2 (无杂合子) 而非 F2 的 $a^2/2$, 同样的 a 解释的方差比例更高; 但 RIL 构建成本高、时间长。以 $B = 30$ 万元为例: 全部分型 F2 约 1000 只; 选择性分型 30% 时可测表型约 1875 只、分型约 560 只, 有效样本约 1500 只当量; RIL 若已有现成群体, 200 个系各测 3 次即可达到较高功效。推荐: 若群体已存在且性状可重复测定, RIL 最优; 若需新建群体且分型昂贵, 选择性分型 F2 最经济, 但必须用全部表型的似然分析并单独估计效应; 若需估计显性, 选 F2。【题目】

远交群体的连锁分析、关联定位与全基因组关联研究

8.1 本章导学

学习目标

1. 理解远交群体定位 QTL 的基本困难：家系间相位不同、群体水平近似连锁平衡，以及由此导致的“家系内分析”原则。
2. 掌握女儿设计、孙女儿设计与同胞对 Haseman–Elston 回归的原理和功效比较。
3. 能写出 GWAS 的单标记回归与混合模型，理解群体分层、隐性亲缘与近端污染的影响及校正方法。
4. 能计算基因组控制因子 λ_{GC} ，并用 LD 分数回归区分多基因信号与混杂。
5. 理解全基因组显著性标准、赢家诅咒与重复验证，能做逆方差加权荟萃分析。
6. 掌握近似贝叶斯因子、后验包含概率与可信集等统计精细定位工具。

重点与难点

重点：家系内标记对比；孙女儿设计的功效来源；混合模型 GWAS； λ_{GC} 与 LDSC 截距；赢家诅咒；ABF 与可信集。

难点： $\lambda_{GC} > 1$ 既可能来自混杂也可能来自真实多基因信号；主成分不能消除家系结构造成的隐性亲缘；混合模型若把检验 SNP 纳入关系矩阵会降低功效；显著位点的效应在发现样本中被系统性高估；可信集依赖“区域内恰有一个致因变异”与 LD 矩阵的正确性。

本章是第 7 章杂交群体定位向自然群体的推广，同时为第 25 章基因组遗传力、第 27 章基因组预测与第 30 章序列资料下的稀有变异分析提供关联分析的语言。

8.2 知识结构图




图 8.1 第 8 章知识结构图

右侧三支讲“在远交群体中怎样检测”，左侧四支讲“怎样避免假阳性、怎样正确估计效应、怎样从关联区域走向致因变异”。

8.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
家系内标记对比	$E(\bar{y}_M - \bar{y}_m) = \pm(1 - 2c)\alpha/2 \times 2$	符号取决于公畜相位，跨家系平均为零
孙女儿设计	儿子 DYD 噪声 $\approx \frac{1}{4}\sigma_{A,I}^2 + (\sigma_P^2 - \frac{1}{4}\sigma_A^2)/n_d$	女儿数 n_d 大时 DYD 接近育种值的一半
Haseman-Elston	$E[(y_1 - y_2)^2 \pi_M] =$ 常数 $- 2(1 - 2c)^2\sigma_Q^2\pi_M$	全同胞对、加性 QTL
单 SNP 检验	$\chi^2 \approx Nq^2/(1 - q^2),$ $q^2 = 2pq\beta^2/\sigma_P^2$	非中心参数 $\approx Nq^2$
混合模型 GWAS	$y = Xb + x_j\beta_j + u + e,$ $u \sim N(0, K\sigma_u^2)$	GLS 检验；LOCO 避免近端污染
基因组控制	$\lambda_{GC} = \text{median}(\chi^2)/0.4549$	均匀膨胀假设

概念	公式或定义	成立条件与提示
LD 分数回归	$E(\chi_j^2) = 1 + Na + Nh^2\ell_j/M$	截距反映混杂，斜率反映多基因
逆方差加权	$\hat{\beta} = \sum w_i \hat{\beta}_i / \sum w_i,$ $w_i = 1/SE_i^2, SE = 1/\sqrt{\sum w_i}$	固定效应荟萃; Cochran Q 检验 异质性
赢家诅咒	$E(\hat{\beta} \text{显著}) > \beta$	发现样本中效应高估
Wakefield ABF	$ABF = \frac{\sqrt{\frac{V}{V+W}} \exp\left[\frac{z^2 W}{2(V+W)}\right]}$	效应先验 $N(0, W)$
PIP 与可信集	单致因: $PIP_j = ABF_j / \sum_k ABF_k$	按 PIP 累加到 $\geq 95\%$

8.4 补充内容与公式推导

推导 8.1 混合模型 GWAS 的 GLS 检验与 OLS 的关系

设 $V = K\sigma_u^2 + I\sigma_e^2$ 已知 (或用全基因组资料估计一次后固定, 即 P3D/EMMAX 思想)。对检验 SNP x , 令 $P = V^{-1} - V^{-1}X(X^T V^{-1}X)^{-1}X^T V^{-1}$, GLS 估计与检验为

$$\hat{\beta} = \frac{x^T P y}{x^T P x}, \quad \chi^2 = \frac{(x^T P y)^2}{x^T P x}.$$

计算上, 先对 $K = U\Lambda U^T$ 做一次特征分解, 把 y, X, x 都左乘 U^T 并以 $(\lambda_i + \delta)^{-1/2}$ 加权 ($\delta = \sigma_e^2/\sigma_u^2$), GLS 就变成普通加权回归, 每个 SNP 的计算量为 $O(n)$ 。若 $K = 0$ 或 $\sigma_u^2 = 0$, $V \propto I$, 检验退化为 OLS。若检验 SNP 本身参与构建 K , 其效应会被随机效应“吸收”一部分 (近端污染), 检验统计量变小; 按染色体留出 (LOCO) 构建 K 可避免这一问题。

推导 8.2 LD 分数回归的期望 χ^2

设无穷小模型 $y = \sum_k x_k \beta_k + e$, 标准化基因型, $\beta_k \sim (0, h^2/M)$ 。SNP j 的边际估计 $\hat{\beta}_j \approx \sum_k r_{jk} \beta_k + \varepsilon_j$, $\text{Var}(\varepsilon_j) \approx 1/N$ 。于是

$$E(\chi_j^2) = N E(\hat{\beta}_j^2) \approx 1 + N \frac{h^2}{M} \sum_k r_{jk}^2 = 1 + \frac{Nh^2}{M} \ell_j.$$

若存在分层或隐性亲缘, 每个 SNP 的统计量额外增加一个与 ℓ_j 近似无关的方差 Na , 得 $E(\chi_j^2) = 1 + Na + Nh^2\ell_j/M$ 。回归 χ^2 对 ℓ : 截距估计 $1 + Na$, 斜率乘 M/N 估计 h^2 。 λ_{GC} 把两部分混在一起: 在大样本多基因性状中, 即使没有任何混杂, λ_{GC} 也可以远大于 1 (习题 8.17)。

推导 8.3 Wakefield 近似贝叶斯因子

效应估计 $\hat{\beta} | \beta \sim N(\beta, V)$ 。零假设 $\beta = 0$: $\hat{\beta} \sim N(0, V)$; 备择 $\beta \sim N(0, W)$: $\hat{\beta} \sim N(0, V + W)$ 。贝叶斯因子（备择对零）为两个正态密度之比：

$$\begin{aligned} \text{ABF} &= \frac{\varphi(\hat{\beta}; 0, V + W)}{\varphi(\hat{\beta}; 0, V)} = \sqrt{\frac{V}{V + W}} \exp\left[\frac{\hat{\beta}^2}{2} \left(\frac{1}{V} - \frac{1}{V + W}\right)\right] \\ &= \sqrt{\frac{V}{V + W}} \exp\left[\frac{z^2 W}{2(V + W)}\right]. \end{aligned}$$

若区域内恰有一个致因变异，且各 SNP 先验概率相同，则 $\text{PIP}_j \propto \text{ABF}_j$ 。W 的选择决定了对大效应的偏好；V 小（样本大）时 ABF 随 z^2 指数增长，LD 很高的 SNP 之间 PIP 会被少量随机噪声左右，这就是可信集通常包含多个 SNP 的原因。

易错辨析

- 群体水平的标记—QTL 关联可以为零，而家系内连锁很强：远交群体近似连锁平衡，连锁分析必须在家系内进行。
- λ_{GC} 大不一定是分层：大样本多基因性状的 λ_{GC} 可大于 1.5 而截距接近 1。
- 主成分只校正“大尺度”结构：家系与近亲造成的隐性亲缘需要混合模型。
- 显著位点的效应估计偏高：报告效应应来自独立样本或经校正的估计。
- 最显著的 SNP 不一定是致因变异：高 LD 区域中最显著 SNP 恰为致因的概率可能只有一半左右。

8.5 习题

一、单项选择题

8.1 ★ [单选] 在奶牛女儿设计中，必须在每个公畜家系内分别估计标记效应，最主要的原因是

- (A) 不同家系女儿的环境不同
- (B) 不同公畜标记与 QTL 的连锁相位可能不同
- (C) 家系大小不同
- (D) 公畜之间存在亲缘

[答案]

8.2 ★ [单选] 基因组控制因子 λ_{GC} 的计算方式是

- (A) 平均 χ^2 除以 1 (B) χ^2 中位数除以 0.4549
(C) 最大 χ^2 除以 29.7 (D) 显著 SNP 数除以总 SNP 数

[答案]

8.3 ★★ [单选] 与只用前几个主成分作协变量相比, 混合模型 GWAS 的主要优势在于

- (A) 计算更快 (B) 同时校正家系结构等隐性亲缘
(C) 不需要基因型资料 (D) 可以避免多重检验

[答案]

8.4 ★★ [单选] 某 SNP 在发现样本中刚好越过全基因组阈值, 在同等规模的重复样本中, 其效应估计最可能

- (A) 与发现样本相同 (B) 系统性偏大
(C) 系统性偏小, 且可能达不到显著 (D) 方向相反

[答案]

8.5 ★★ [单选] 单致因假定下, 某区域 SNP 的后验包含概率依次为 0.55、0.30、0.10、0.05, 95% 可信集为

- (A) 前两个 SNP (B) 前三个 SNP
(C) 全部四个 SNP (D) 第一个 SNP

[答案]

8.6 ★ [单选] 在相同显著水平与功效下, 检测一个解释 0.1% 表型方差的 SNP 所需样本量约为检测解释 0.4% 方差 SNP 的

- (A) 1/4 (B) 2 倍 (C) 4 倍 (D) 16 倍

[答案]

二、判断与改错题

8.7 ★★ [判断] 只要在 GWAS 模型中加入足够多的主成分, 就可以完全消除家系结构造成的假阳性。

[答案]

8.8 ★ [判断] 在古老的远交群体中利用 LD 进行关联定位, 其分辨率通常高于 F2 群体的连锁定位。

[答案]

8.9 ★★ [判断] 在混合模型 GWAS 中, 用包含待检 SNP 的全部标记构建关系矩阵, 会使该 SNP 的检验统计量偏小。 [答案]

8.10 ★★ [判断] 固定效应荟萃分析假定各研究的真实效应相同, Cochran Q 统计量可以用来检验这一假定。 [答案]

三、填空题

8.11 ★ [填空] 某 GWAS 全部 SNP 检验 χ^2 的中位数为 0.62, 则 $\lambda_{GC} =$ ____。 [答案]

8.12 ★★ [填空] 两项研究对某 SNP 的效应估计 (SE) 为 0.10 (0.03) 与 0.04 (0.02)。逆方差加权合并效应为 ____, SE 为 ____, $z =$ ____; Cochran Q = ____。

[答案]

8.13 ★ [填空] 某 SNP 等位基因频率 0.3, 替代效应为 0.2 个表型标准差, 则它解释的表型方差比例为 ____。 [答案]

8.14 ★★ [填空] 某 SNP $z = 5$, $SE = 0.02$ ($V = 0.0004$), 效应先验标准差 0.2 ($W = 0.04$), Wakefield ABF 约为 ____。 [答案]

四、计算题

8.15 ★★ [计算] 女儿设计与孙女儿设计。 $h^2 = 0.30$, QTL 替代效应 $\alpha = 0.25\sigma_p$ ($p = 0.5$), 标记与 QTL 重组率 0.05, 10 个杂合祖公畜家系, 总分型数 1000。女儿设计中 1000 个女儿各有一条记录; 孙女儿设计中 1000 个儿子各有基于 100 个女儿的 DYD。(1) 推导两种设计中家系内标准化标记对比 δ ; (2) 模拟并解析计算 $\alpha = 0.01$ 下的功效; (3) 解释孙女儿设计功效高的原因。 [程序] `ch08/ex08_15_daughter_granddaughter.py`

[答案]

8.16 ★★★ [计算] 分层与隐性亲缘。两个亚群各 300 只 (各由 15 个半同胞家系组成), 2000 个 SNP 在亚群间有频率分化, 15 个致因 SNP 合计 $h^2 = 0.4$, 两亚群另有 0.5 个标准差的非遗传均值差。比较朴素回归、5 个主成分校正、混合模型 (加亚群固定效应) 的 λ_{GC} 、零 SNP 第一类错误率 ($\alpha = 10^{-4}$) 与致因 SNP 功效, 并解释混合模型 $\lambda_{GC} < 1$ 的原因。 [程序] `ch08/ex08_16_gwas_structure.py` [答案]

8.17 ★★ [计算] LD 分数回归。 10 000 个 SNP (400 个 LD 块), $N = 10000$, $h^2 = 0.25$ 。分别在无混杂与混杂 $Na = 0.3$ 两种情景下模拟 100 次。(1) 比较 λ_{GC} 与平均 χ^2 ; (2) 报告 LDSC 截距与 $\hat{h}^2$ 的均值与标准差; (3) 说明为何 λ_{GC} 不能用来判断是否存在混杂。 [程序] `ch08/ex08_17_ld_score_regression.py` [答案]

8.18 ★★★ [计算] 赢家诅咒的校正。 2000 个 SNP 的真实效应 (z 尺度) $\mu \sim N(0, 2^2)$, 发现与重复样本同等规模, 以 5×10^{-8} 选出显著位点。比较朴素估计、重复样本估计、条件最大似然与 Tweedie 经验贝叶斯估计的平均偏差与均方误差, 并报告重复样本中再次达到显著的比例。 [程序] `ch08/ex08_18_winners_curse.py` [答案]

8.19 ★★ [计算] 统计精细定位。 某区域 12 个 SNP 的 LD 为链式结构 (相邻相关见配套数据), 真实致因为 S4 (期望 $z = 6$)。 (1) 对一次模拟结果计算 ABF、PIP 与 95% 可信集; (2) 重复 2000 次, 报告可信集覆盖率、平均大小与“最显著 SNP 即致因”的比例; (3) 讨论 LD 矩阵与关联统计量来自不同样本时可能出现的问题。 [程序] `ch08/ex08_19_finemapping.py` [答案]

8.20 ★★ [计算] Haseman–Elston 回归。 全同胞对, QTL 加性方差 0.15, 共享方差 0.20, 个体特有方差 0.65。分别在标记即 QTL ($c = 0$) 与 $c = 0.1$ 时, 模拟 200—2000 对同胞对的斜率估计与功效 (单侧 $\alpha = 0.001$), 并与理论斜率 $-2(1 - 2c)^2 \sigma_Q^2$ 比较。说明基于 IBD 的连锁分析在人类与家畜中的地位为何被关联分析取代。 [程序] `ch08/ex08_20_haseman_elston.py` [答案]

8.21 ★ [计算] 某 GWAS 报告最显著 SNP 的 $-\log_{10} p = 7.3$ 。 (1) 对应的双侧 $|z|$ 是多少? (2) 若该 SNP 在 200 000 个独立检验中被发现, 按 Bonferroni 是否显著? [答案]

8.22 ★ [计算] 病例组某风险等位基因频率 0.30, 对照组 0.25。计算等位基因比值比, 并说明在病例—对照设计中, 比值比与风险比的关系何时近似相等。 [答案]

五、推导与证明题

8.23 ★★ [证明] 推导混合模型 GWAS 中 SNP 效应的 GLS 估计与检验统计量 (推导 8.1), 并证明当 $V = \sigma^2 I$ 时它们退化为普通最小二乘。 [答案]

8.24 ★★ [证明] 两个等大亚群中某 SNP 频率为 p_1, p_2 , SNP 无效应, 但亚群表型均值相差 Δ (亚群内方差为 1)。推导合并样本中该 SNP 关联检验的期望 χ^2 近似为 $1 + Nr^2$, 其中 r 是合并样本中剂量与表型的相关, 说明膨胀与 N 成正比。 [答案]

8.25 ★★ [证明] 对全同胞对, 证明 $E[(y_1 - y_2)^2 | \pi_Q] = 2(\sigma_Q^2 + \sigma_e^2) - 2\sigma_Q^2\pi_Q$, 并证明标记处的 IBD 比例 π_M 对 π_Q 的回归系数为 $(1 - 2c)^2$, 从而得到 Haseman-Elston 斜率。 [答案]

8.26 ★★ [证明] 推导 Wakefield 近似贝叶斯因子 (推导 8.3), 并说明 $W \rightarrow \infty$ 时 ABF 的行为 (Lindley 悖论) 及其对选择先验的启示。 [答案]

六、综合分析与研究设计题

8.27 ★★ [综合] 为某猪品种的肉质性状 (如肌内脂肪含量) 设计一项 GWAS, 要求说明: 样本量估算依据、表型测定与校正、基因型质控、群体结构与亲缘的处理、显著性标准、重复验证与效应报告方式。 [答案]

8.28 ★★★ [综合] 在某牛品种的 GWAS 中, 一个显著区域跨越约 2 Mb、包含 20 个基因, 最显著 SNP 位于基因间区。请设计从关联信号到候选致因变异的分析路线, 说明每一步利用的信息与可能的失败原因。 [答案]

8.29 ★★★ [综合] 某育种公司计划把 GWAS 中最显著的 50 个 SNP 作为固定效应加入基因组评定模型, 以“提高准确度”。评价这一做法的潜在收益与风险 (赢家诅咒、双重计数、过拟合、跨群体稳定性), 并给出验证方案。 [答案]

8.6 参考答案与解析

一、单项选择题

8.1 B. 远交群体中公畜的标记—QTL 连锁相位因个体而异, 某家系中 M 与 Q 同在同一条染色体, 另一家系可能相反; 跨家系合并时标记效应相互抵消 (推导见正文)。

[题目]

8.2 B. χ_1^2 的中位数为 0.4549。

[题目]

8.3 B. 主成分捕获大尺度的祖源差异, 混合模型通过关系矩阵同时校正家系、近亲与细微结构。

[题目]

8.4 C。刚越过阈值的位点多半是“幸运”地被高估了，重复样本中效应回归真值，往往达不到全基因组显著（习题 8.18 中只有约 43% 再次显著）。[题目]

8.5 B。累加：0.55、0.85、0.95，前三个 SNP 达到 95%。[题目]

8.6 C。非中心参数约 Nq^2 ， q^2 缩小 4 倍，样本需增大 4 倍。[题目]

二、判断与改错题

8.7 错误。主成分描述的是低维的祖源轴，家系结构与近亲关系分布在大量维度上，增加主成分只能部分吸收。习题 8.16 中 5 个主成分校正后 λ_{GC} 仍为 1.32，需要混合模型或在模型中加入关系矩阵。[题目]

8.8 正确。古老群体经历了大量世代的重组，LD 范围短，关联信号局限在较小区间；F2 只经历一代重组，置信区间常达数十厘摩。但关联定位需要更高的标记密度，且受群体结构干扰。[题目]

8.9 正确。这称为近端污染：检验 SNP 及其近邻标记的信息进入 K ，随机效应吸收了一部分该 SNP 的效应， χ^2 变小、功效下降；习题 8.16 中混合模型 $\lambda_{GC} = 0.88 < 1$ 就部分来源于此。LOCO 可缓解。[题目]

8.10 正确。 $Q = \sum w_i(\hat{\beta}_i - \hat{\beta})^2$ 在同质性下近似服从 χ^2_{k-1} 。若存在异质性，应采用随机效应荟萃分析并报告 I^2 。[题目]

三、填空题

8.11 $0.62/0.4549 = 1.363$ 。[题目]

8.12 权重 1111.1 与 2500； $\hat{\beta} = 0.0585$ ； $SE = 0.0166$ ； $z = 3.51$ ； $Q = 2.77$ ($p = 0.096$)，无明显异质性。[题目]

8.13 $2 \times 0.3 \times 0.7 \times 0.2^2 = 0.0168$ ，即 1.68%。[题目]

8.14 $\sqrt{0.0004/0.0404} \times \exp(25 \times 0.04/0.0808) = 0.0995 \times e^{12.38} \approx 2.36 \times 10^4$ 。[题目]

四、计算题

8.15 (1) 女儿设计：女儿表型中父源 QTL 等位基因贡献 $\pm\alpha/2$ ，其余方差 $1 - \alpha^2/4$ ，家系内标记对比期望 $(1 - 2c)\alpha$ ， $\delta_d = (1 - 2c)\alpha/\sqrt{1 - \alpha^2/4} = 0.227$ 。孙女儿设计：儿子 DYD 中父源 QTL 贡献 $\pm\alpha/4$ ，即对比期望 $(1 - 2c)\alpha/2$ ；噪声由家系内儿子

育种值的其余部分（多基因 $\frac{3}{4}\sigma_{A,多}^2$ 与母源 QTL $\alpha^2/4$ ，乘以 $1/4$ ）及女儿均值误差 $(1 - \sigma_A^2/4)/100$ 组成， $\delta_g = 0.446$ 。

(2) 模拟功效：女儿设计 0.428，孙女儿设计 0.998；非中心 F 解析功效 0.434 与 0.999。

(3) 同样分型 1000 头，孙女儿设计每个分型个体的“表型”是 100 个女儿的均值，环境与母方噪声被平均掉，标准化对比约为女儿设计的 2 倍，相当于把有效样本量扩大约 4 倍。代价是需要大量女儿的产奶记录（这些记录本来就存在于常规评定中），以及只能利用公畜—儿子—孙女三代的系谱结构。

[题目]

8.16

方法	λ_{GC}	零 SNP 拒绝率	致因 SNP 功效
朴素回归	2.97	0.0232	0.467
PC 校正	1.32	0.0015	0.400
混合模型 + 亚群	0.88	0.0000	0.333

朴素回归的假阳性率是名义水平的 232 倍。主成分校正吸收了亚群差异，但家系结构仍使 $\lambda_{GC} = 1.32$ 、假阳性率为名义水平的 15 倍。混合模型控制住了假阳性， $\lambda_{GC} < 1$ 的原因：(1) 致因 SNP 及与之相关的标记进入了 K （近端污染）；(2) 亚群固定效应与关系矩阵共同吸收了部分与结构相关的真实信号。功效的下降部分是“控制假阳性的代价”，部分可通过 LOCO 恢复。本例仅 15 个致因 SNP，功效数值的抽样误差较大。

[题目]

8.17

情景	λ_{GC}	平均 χ^2	LDSC 截距	$\hat{h}^2$
无混杂	1.90	2.12	1.000 ± 0.057	0.249 ± 0.031
混杂 $Na = 0.3$	2.25	2.31	1.297 ± 0.059	0.251 ± 0.032

无混杂时 λ_{GC} 已达 1.90，全部来自多基因信号。若据此用 λ_{GC} 校正，会大量丢失真实信号。LDSC 利用“多基因信号随 LD 分数增大而增大、混杂基本不随 LD 变化”的差异，把二者分开：截距准确恢复了 $1 + Na$ ， h^2 估计在两种情景下都无偏。LDSC 的前提是 LD 分数来自与 GWAS 样本祖源一致的参考面板，且混杂与 LD 无关；在强烈分层或 LD 参考不匹配时截距也会失准。

[题目]

8.18 显著位点 28 个（其真实平均 $|\mu| = 5.01$ ）。

估计	平均偏差	均方误差
朴素发现 z	1.349	2.611
重复样本 z	0.362	0.925
条件 MLE	-0.462	5.441
Tweedie 经验贝叶斯	0.278	0.917

朴素估计平均高估 1.35 个标准误。重复样本估计对被选位点近似无偏（残余 0.36 来自有限样本）；条件 MLE 在平均意义上纠偏过度且方差很大——单个位点的条件似然很平坦，估计极不稳定；Tweedie 公式借用全部 SNP 的信息估计“效应分布”，偏差与均方误差都最小。重复样本中全部同向，但只有 43% 再次达到 5×10^{-8} ：重复失败不意味着原发现为假阳性，而是赢家诅咒导致的功效高估。 [题目]

- 8.19 (1) 一次模拟中 S4 的 $z = 6.37$ ，S3 为 5.98，PIP 分别为 0.917 与 0.083，95% 可信集为 {S4, S3}，最显著 SNP 恰为 S4。
- (2) 2000 次重复：覆盖率 0.990（略高于名义 95%，因为单致因模型正确且可信集离散），平均大小 2.40；最显著 SNP 恰为致因的比例只有 0.739——即使样本足够大、信号很强，与致因高度相关（ $r = 0.97$ ）的 S3 仍有约四分之一的机会更显著。
- (3) 若 LD 矩阵来自参考面板而 z 来自另一样本，二者不一致时会出现“ z 模式与 LD 不相容”，多 SNP 方法（如 SuSiE、FINEMAP）可能报告虚假的多个独立信号或错误的可信集；应使用样本内 LD 或检查 z 与 LD 的一致性诊断。 [题目]

8.20

c	同胞对	理论斜率	平均估计	功效
0	200	-0.300	-0.302	0.007
0	1000	-0.300	-0.297	0.074
0	2000	-0.300	-0.297	0.203
0.1	2000	-0.192	-0.190	0.049

斜率估计无偏，但即使 QTL 解释 15% 的表型方差、2000 对同胞，功效也只有约 20%。原因是平方差 $(y_1 - y_2)^2$ 噪声极大，且 IBD 共享只在 $\{0, \frac{1}{2}, 1\}$ 间变化。同样的 QTL 若用关联分析，只要标记与之有 LD，用数千个体即可检出。家系连锁分析因此退居于检测稀有大效应变异与验证关联信号的辅助地位；在家畜中则被半同胞家系设计与 GWAS 取代。 [题目]

8.21 (1) $p = 10^{-7.3} = 5.0 \times 10^{-8}$, $|z| = 5.45$ 。(2) Bonferroni 阈值 $0.05/200000 = 2.5 \times 10^{-7}$, $p = 5 \times 10^{-8}$ 小于阈值, 显著。 [题目]

8.22 $OR = (0.30/0.70)/(0.25/0.75) = 1.286$ 。当疾病在群体中罕见(发病率低于约 10%) 时, 比值比近似等于风险比; 常见病时比值比会夸大风险比。 [题目]

五、推导与证明题

8.23 见推导 8.1。 $V = \sigma^2 I$ 时 $P = \sigma^{-2}[I - X(X^T X)^{-1} X^T] = \sigma^{-2} M$, $\hat{\beta} = x^T M y / x^T M x$, 即先对协变量取残差后的 OLS 斜率, $\chi^2 = (x^T M y)^2 / (\sigma^2 x^T M x)$, 以 $\hat{\sigma}^2$ 代入即为 OLS 的 t^2 。 [题目]

8.24 合并样本中剂量 x 与表型 y 的协方差只来自亚群间部分: $Cov(x, y) = Cov[E(x | s), E(y | s)] = \frac{1}{4} \cdot 2(p_1 - p_2)\Delta$ (等大亚群)。相关 $r = Cov / \sqrt{Var(x)Var(y)}$ 是一个与 N 无关的常数。回归检验统计量 $\chi^2 \approx N r^2 / (1 - r^2) + 1$ (非中心 χ^2 的期望为 $1 +$ 非中心参数), 故膨胀随 N 线性增长。这说明大样本 GWAS 对微弱的分层也极其敏感: $r^2 = 10^{-4}$ 的伪关联在 $N = 10^6$ 时贡献 $\chi^2 \approx 100$ 。 [题目]

8.25 给定 π_Q , 两同胞 QTL 值的协方差为 $\pi_Q \sigma_Q^2$, 其余共享方差 σ_s^2 , 于是 $Var(y_1 - y_2 | \pi_Q) = 2(\sigma_Q^2 + \sigma_s^2 + \sigma_e^2) - 2(\pi_Q \sigma_Q^2 + \sigma_s^2) = 2(\sigma_Q^2 + \sigma_e^2) - 2\sigma_Q^2 \pi_Q$ 。对父源: 两同胞在 QTL 处是否共享父源同一拷贝记为 I_Q , 在标记处为 I_M 。二者相等的概率 $\Psi = c^2 + (1-c)^2$ (两同胞都重组或都不重组), $Cov(I_Q, I_M) = \Psi/2 - 1/4 = (1-2c)^2/4$, $Var(I_M) = 1/4$, 故回归系数为 $(1-2c)^2$; 母源同理, $\pi = (I_{\text{父}} + I_{\text{母}})/2$ 的回归系数不变。代入得斜率 $-2(1-2c)^2 \sigma_Q^2$ 。 [题目]

8.26 推导见推导 8.3。 $W \rightarrow \infty$ 时 $\sqrt{V/(V+W)} \rightarrow 0$, 而指数项趋于 $e^{z^2/2}$ 有限, $ABF \rightarrow 0$: 无论数据多么支持效应存在, 过于分散的先验都会使贝叶斯因子偏向零假设 (Lindley 悖论)。启示: W 应反映合理的效应大小 (如家畜中常取 0.1—0.2 个表型标准差), 并进行敏感性分析; 不同 SNP 间若频率差异大, 可让 W 随频率调整。 [题目]

六、综合分析与研究设计题

8.27 (1) **样本量**: 以预期效应 (如解释 1% 方差) 与 5×10^{-8} 、80% 功效估计, 非中心参数约 40, $N \approx 4000$; 若资源有限, 可先以 1000—2000 头做发现, 并预留独立重复样本。(2) **表型**: 统一屠宰日龄、测定部位与方法; 校正屠宰批次、性别、胴体重等, 记录测定仪器与操作人员。(3) **基因型质控**: 样本检出率、性别核对、亲子

一致性、重复样本；SNP 检出率、MAF、HWE 精确检验。(4) **结构与亲缘**：主成分分析识别品系来源，混合模型 (LOCO) 校正亲缘，检查 λ_{GC} 与 QQ 图，必要时用 LDSC 截距判断混杂。(5) **显著性**：全基因组以 5×10^{-8} 或依据有效独立检验数，发现阶段可报告 FDR。(6) **重复与报告**：在独立群体重复，报告效应及 SE、等位基因方向、MAF、解释方差，以及校正赢家诅咒后的效应；公开汇总统计以便荟萃。

[题目]

8.28 路线：(1) **条件分析**：以最显著 SNP 为协变量重新检验，判断区域内是否有多个独立信号；(2) **统计精细定位**：用样本内 LD 与多 SNP 方法得到可信集与 PIP；(3) **提高分辨率**：在多个品种中做跨品种荟萃，利用品种间不同的 LD 模式缩小区间；加入填充到序列水平的变异；(4) **功能注释**：把可信集变异与调控元件 (ATAC、ChIP、Hi-C)、eQTL、等位基因特异表达重叠；(5) **共定位**：检验关联信号与某基因表达 QTL 是否共享致因变异；(6) **实验验证**：报告基因、CRISPR 编辑或模型细胞实验。失败原因：区域 LD 极长导致可信集包含数百个变异；致因为未被填充的结构变异或稀有变异；功能注释缺乏相关组织与发育阶段；多效性使共定位误导。

[题目]

8.29 潜在收益：若存在少数大效应位点 (如奶牛 DGAT1)，把它们作为固定效应可以避免 GBLUP 对大效应的过度收缩，提高相关性状的准确度。风险：(1) **赢家诅咒**：在同一资料中选出并估计的效应偏高；(2) **双重计数**：这些 SNP 同时在关系矩阵中，效应被重复计算；(3) **过拟合**：50 个固定效应在小参考群体中估计误差大，验证集中可能降低准确度；(4) **稳定性**：效应在不同世代、环境与群体中可能不同，且 LD 相位随时间衰减。验证方案：在训练集内部进行 SNP 选择与效应估计 (嵌套交叉验证)；按出生年份做前瞻验证，比较 GBLUP、GBLUP+ 固定 SNP、加权 GBLUP、BayesR 等方法的相关、校准斜率与偏差；若采用，可把选中 SNP 作为单独方差组分而非固定效应，并定期重新估计。

[题目]

第四篇

数量性状的遗传模型与参数估计

遗传方差怎样分解，亲属为何相似。

本篇习题训练：基因型值与方差分解、遗传协方差、系谱亲缘与近交、遗传参数估计与试验设计。

数量遗传与群体依赖性

9.1 本章导学

学习目标

- 1. 掌握单位点模型中基因型值 a, d 、群体均值、平均替代效应、育种值与显性偏差的定义和计算。
- 2. 理解平均效应是“基因型值对基因剂量的加权最小二乘回归斜率”，因而依赖等位基因频率与交配体系。
- 3. 能推导加性方差与显性方差，分析它们随频率与显性程度的变化，并推广到多等位基因与两位点互作。
- 4. 理解偏离随机交配（近交）与连锁不平衡时如何重新定义统计投影，区分边际效应与偏回归效应。
- 5. 理解育种值的群体基准：纯种、杂交与合成群体中同一个体的遗传价值可能完全不同。
- 6. 能用本章的群体依赖观点解释遗传力、遗传相关与标记预测为何不能在群体间直接移用。

重点与难点

重点： $M = a(p - q) + 2pqd$ ； $\alpha = a + d(q - p)$ ； 育种值与显性偏差； $V_A = 2pq\alpha^2$ 、 $V_D = (2pqd)^2$ ； 正交分解。

难点： “生物学效应” a, d 是固定的，而 “统计效应” α 与方差随群体而变； 完全显性下隐性等位基因稀有时显性方差反而大于加性方差； 近交群体中平均效应的定义改变； 连锁不平衡下单个位点的边际效应吸收了相邻位点的效应； 超显性时育种值排名会随配偶群体而反转。

本章是第 10 章方差组分、第 11 章亲属相似、第 14 章选择反应的直接基础，也为第 20 章杂种优势与第 29 章跨群体迁移提供核心概念。

9.2 知识结构图




图 9.1 第 9 章知识结构图

右侧四支从“基因型值 → 平均效应 → 育种值 → 方差”建立随机交配群体中的统计分解；左侧三支说明当交配体系、连锁不平衡或参照群体改变时，这些统计量怎样随之改变。

9.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
基因型值	$A_1A_1 = a, A_1A_2 = d, A_2A_2 = -a$	以纯合子中点为原点
群体均值	$M = a(p - q) + 2pqd$	HWE; p 为 A_1 频率
平均替代效应	$\alpha = a + d(q - p)$	随机交配
育种值	$2q\alpha, (q - p)\alpha, -2p\alpha$	相对于群体均值
显性偏差	$-2q^2d, 2pqd, -2p^2d$	均值为零、与育种值正交
加性方差	$V_A = 2pq\alpha^2$	单位点
显性方差	$V_D = (2pqd)^2$	单位点
完全显性时	$V_D/V_A = p/(2q)$	$d = a$; $p > 2/3$ 时 $V_D > V_A$

概念	公式或定义	成立条件与提示
近交群体	$\alpha_F = a + d(q - p) \frac{1 - F}{1 + F}$, $V_A(F) = 2pq(1 + F)\alpha_F^2$	以回归定义平均效应
近交衰退	$\Delta M = -2F \sum pqd$	方向性显性
杂种优势	$H_{F1} = \sum dy^2$, $y = p_1 - p_2$	两亲本群体各自随机交配
LD 下加性方差	$V_A = \sum 2p_l q_l \alpha_l^2 + \sum_{l \neq m} 2\alpha_l \alpha_m D_{lm}$	二倍体剂量协方差为 $2D$
边际效应	$\alpha_A^{\text{边际}} = \alpha_A + \alpha_B D / (p_A q_A)$	两位点加性模型

9.4 补充内容与公式推导

推导 9.1 平均效应即加权最小二乘斜率

令 x 为个体携带 A_1 的拷贝数, HWE 下 $E(x) = 2p$, $\text{Var}(x) = 2pq$ 。基因型值 G 对 x 的最佳线性预测斜率为

$$\alpha = \frac{\text{Cov}(G, x)}{\text{Var}(x)}.$$

$E(Gx) = 2ap^2 + d \cdot 2pq$, $E(G) = M$, 于是 $\text{Cov}(G, x) = 2ap^2 + 2pqd - 2p[a(p - q) + 2pqd] = 2apq + 2pqd(1 - 2p) = 2pq[a + d(q - p)]$, 故 $\alpha = a + d(q - p)$ 。育种值就是这条回归线在 $x = 2, 1, 0$ 处的值 (离均差), 显性偏差是回归残差; 由最小二乘性质, 残差与拟合值正交、加权均值为零, 这正是 $V_G = V_A + V_D$ 的来源。这个定义的优点是可直接推广: 多等位基因时对各等位基因剂量做多元回归 (习题 9.16), 近交时只需把权重换成近交频率 (习题 9.17), 连锁不平衡时换成多位点联合频率 (习题 9.19)。

推导 9.2 后代育种值的期望等于双亲育种值的平均

随机交配下, 个体育种值 $A = \alpha(x - 2p)$ 可写为两个配子贡献之和: $A = \alpha(x_s - p) + \alpha(x_d - p)$, $x_s, x_d \in \{0, 1\}$ 为父源、母源配子携带 A_1 的指示。父亲传给后代的配子是父亲两条配子之一 (各 $1/2$), 故

$$E(\alpha(x_s^o - p) | \hat{\alpha}) = \frac{1}{2}[\alpha(x_{s1} - p) + \alpha(x_{s2} - p)] = \frac{1}{2}A_s.$$

母亲同理, 因此 $E(A_o | A_s, A_d) = \frac{1}{2}(A_s + A_d)$, 差额 $A_o - \frac{1}{2}(A_s + A_d)$ 为孟德尔抽样, 期望为零, 方差 (非近交亲本) 为 $\frac{1}{2}V_A$ 。这里用到两个条件: 配偶群体的频率与定义 α 的群体相同; 显性偏差不传递 (后代只得到每个亲本的一个等位基因, 基因间互作被打散)。若在杂交中配偶来自另一品种, “传递给后代的价值”需按配偶群体频率重新定义 α (习题 9.20)。

推导 9.3 完全显性下 V_D 何时超过 V_A

$d = a$ 时 $\alpha = a(1 + q - p) = 2qa$, $V_A = 2pq(2qa)^2 = 8pq^3a^2$, $V_D = (2pqa)^2 = 4p^2q^2a^2$ 。
二者之比

$$\frac{V_D}{V_A} = \frac{4p^2q^2}{8pq^3} = \frac{p}{2q}.$$

$V_D > V_A \iff p > 2q \iff q < 1/3$, 即隐性等位基因频率低于 $1/3$ 时显性方差超过加性方差 (习题 9.15 数值结果给出 $p \geq 0.67$)。直观解释: 隐性等位基因稀有时, 它几乎只存在于杂合子中, 而杂合子与显性纯合子表型相同, 选择很难“看到”隐性等位基因——加性方差小, 表型差异主要表现为偶尔出现的隐性纯合子与其他个体之间的显性偏差。这也说明为什么对隐性缺陷的表型选择效率极低。

易错辨析

- a, d 与 α 不是一回事: 前者描述基因型值, 后者是群体中的回归统计量, 随频率变化。
- 育种值不等于基因型值: 育种值只包括可传递的加性部分; 杂合子的显性优势不传递。
- 加性方差大不等于遗传力高: 遗传力是比例, 加性方差是绝对量, 二者可方向相反。
- 超显性时不存在“最优纯合子”: 平均效应在平衡频率处为零, 加性方差也为零。
- 近交不改变等位基因频率, 但改变平均效应的定义与均值。

9.5 习题

一、单项选择题

9.1 ★ [单选] 完全显性位点 ($a = d = 1$), 有利显性等位基因频率 $p = 0.25$, 平均替代效应 α 为

- (A) 1.0 (B) 1.5 (C) 0.5 (D) 2.0

[答案]

9.2 ★ [单选] 随机交配群体中 A_1A_1 个体的育种值为

- (A) a (B) $2qa$ (C) $2p\alpha$ (D) $a - M$

[答案]

9.3 ★ [单选] 显性偏差在随机交配群体中的加权平均值

- (A) 恒为零 (B) 等于 $2pqd$ (C) 取决于 a
(D) 等于近交衰退量

[答案]

9.4 ★★ [单选] 某位点 $a = 2$ 、 $d = -1$ (有利等位基因部分隐性), $p = 0.5$ 。群体均值为

- (A) 0 (B) -0.5 (C) 0.5 (D) 1

[答案]

9.5 ★ [单选] 下列关于遗传力的说法正确的是

- (A) 遗传力是性状的固有属性
(B) 遗传力是指定群体、环境与测定条件下加性方差占表型方差的比例
(C) 遗传力越高, 性状受环境影响越小 (D) 遗传力为零说明性状与基因无关

[答案]

9.6 ★★ [单选] 超显性位点基因型值 $a = 1$ 、 $d = 2$, 平均效应为零的频率是

- (A) $p = 0.5$ (B) $p = 0.75$ (C) $p = 0.25$ (D) 不存在

[答案]

二、判断与改错题

9.7 ★ [判断] 当 $d = 0$ 时平均替代效应与频率无关, 因此加性方差也与频率无关。 [答案]

9.8 ★ [判断] 一个杂合子个体的育种值等于它的基因型值减去群体均值。 [答案]

9.9 ★★ [判断] 在 HWE 下, 以基因型频率为权, 基因型值对 A_1 剂量的回归斜率等于 $a + d(q - p)$ 。 [答案]

9.10 ★★ [判断] 近交衰退的出现要求位点存在方向性显性 (各位点 d 以正值为主); 若显性在不同位点方向随机, 近交时群体均值基本不变。 [答案]

三、填空题

9.11 ★ [填空] 某位点 $a = 2$ 、 $d = 0.5$ 、 $p = 0.6$, 则 $M = \underline{\hspace{2cm}}$, $\alpha = \underline{\hspace{2cm}}$ 。 [答案]

9.12 ★ [填空] 接上题, A_1A_1 、 A_1A_2 、 A_2A_2 的育种值依次为____、____、____。

[答案]

9.13 ★ [填空] 接上题, 三种基因型的显性偏差依次为____、____、____。 [答案]

9.14 ★ [填空] 接上题, $V_A =$ ____, $V_D =$ ____。 [答案]

四、计算题

9.15 ★★ [计算] 单位点的完整分解。(1) 对 $a = 1$ 、 $d = 0.5$ 、 $p = 0.7$ 列出三种基因型的频率、 $G-M$ 、育种值与显性偏差, 并用加权回归核对 α ; (2) 验证育种值与显性偏差的加权均值零、加权协方差为零; (3) 对 $d/a = 0, 0.5, 1, 1.5$ 求 V_A 最大时的频率, 以及 $V_D > V_A$ 的频率区间。 [程序] `ch09/ex09_15_single_locus_decomposition.py`

[答案]

9.16 ★★ [计算] 多等位基因位点。三个等位基因频率 0.5、0.3、0.2, 基因型值矩阵见配套数据 ($A_1A_1 = 10$, ..., $A_3A_3 = 2$)。 (1) 求群体均值与三个等位基因的平均效应; (2) 求六种基因型的育种值与显性偏差; (3) 求 V_A 、 V_D , 并用对等位基因剂量的加权多元回归独立核对育种值。 [程序] `ch09/ex09_16_multiallele_effects.py` [答案]

9.17 ★★★ [计算] 近交群体中的平均效应。 $a = 1$ 、 $d = 0.8$ 、 $p = 0.3$ 。对 $F = 0, 0.1, 0.25, 0.5, 0.75, 1$: (1) 用加权回归计算平均效应并与公式 $\alpha_F = a + d(q-p)(1-F)/(1+F)$ 核对; (2) 计算群体均值、 $V_A(F)$ 、剩余方差与总遗传方差; (3) 解释 $F = 1$ 时 $V_A = 4pqa^2$ 的含义。 [程序] `ch09/ex09_17_inbreeding_projection.py`

[答案]

9.18 ★★★ [计算] 两位点互作的正交分解。两个不连锁位点 $p_A = 0.6$ 、 $p_B = 0.4$, 九种两位点基因型值见配套数据。 (1) 构造 Cockerham 正交基并验证正交性; (2) 求 V_A 、 V_D 、 V_{AA} 、 V_{AD} 、 V_{DA} 、 V_{DD} 并验证其和等于 V_G ; (3) 计算 A 位点的边际平均效应及其在 B 位点三种背景下的条件效应, 说明互作的含义。 [程序]

`ch09/ex09_18_two_locus_epistasis.py`

[答案]

9.19 ★★ [计算] LD 下的边际效应与加性方差。两加性位点 $p_A = 0.5$ 、 $p_B = 0.3$, 偏回归效应 $\alpha_A = 1$ 、 $\alpha_B = 0.6$ 。对 $D = -0.10, -0.05, 0, 0.05, 0.10$: (1) 求可行的 D 范围; (2) 计算 V_A 及忽略 LD 的 V_A ; (3) 计算两位点的边际效应, 并以 16 种单倍型组合的精确枚举核对。 [程序] `ch09/ex09_19_ld_marginal_partial.py` [答案]

9.20 ★★★ [计算] 群体基准与排名反转。超显性位点 $a = 1$ 、 $d = 2$ 。品种 A 中 $p = 0.8$ ，品种 B 中 $p = 0.2$ 。三只 A 品种公羊的基因型分别为 A_1A_1 、 A_1A_2 、 A_2A_2 。分别计算它们在纯种繁殖（配偶为 A）、杂交（配偶为 B）与合成 F2 ($p = 0.5$) 中的后代平均值与排名，并解释排名为何反转。[程序] `ch09/ex09_20_reference_population.py` [答案]

9.21 ★ [计算] 两亲本品种在三个位点上的频率差与显性效应为： $(y, d) = (0.4, 1)$ 、 $(0.6, 0.5)$ 、 $(0.5, -0.2)$ 。求 F1 的中亲杂种优势，并说明负显性位点的作用。[答案]

9.22 ★ [计算] 两个位点： $p = 0.5, d = 1$ ； $p = 0.2, d = 0.5$ 。群体近交系数由 0 升至 0.25 时，群体均值下降多少？[答案]

五、推导与证明题

9.23 ★ [证明] 用加权最小二乘证明 $\alpha = a + d(q - p)$ ，并说明育种值、显性偏差分别对应回归的哪一部分。[答案]

9.24 ★★ [证明] 证明随机交配下 $E(A_o | A_s, A_d) = \frac{1}{2}(A_s + A_d)$ ，并指出该结论依赖的两个条件。[答案]

9.25 ★★ [证明] 证明完全显性时 $V_D/V_A = p/(2q)$ ，由此求 $V_D > V_A$ 的频率条件，并给出遗传学解释。[答案]

9.26 ★★★ [证明] 在近交系数为 F 的群体中，以基因型值对剂量的加权回归定义平均效应，证明 $\alpha_F = a + d(q - p)(1 - F)/(1 + F)$ ，并讨论“ V_A ”在近交群体中失去哪些在随机交配群体中成立的性质。[答案]

六、综合分析与研究设计题

9.27 ★★ [综合] 同一性状在两个品种中估计的遗传力分别为 0.45 与 0.20。列出至少五种可能原因，并设计一个研究区分“等位基因频率不同”“环境方差不同”与“测定方法不同”三类解释。[答案]

9.28 ★★★ [综合] 某杂交生产体系以纯种公畜在纯种群体中的育种值作为选种依据，但商品代为二元杂交。用本章平均效应的群体依赖性解释纯种育种值预测杂种表现可能失准的原因，并提出改进评定的方案。[答案]

- 9.29 ★★★ [综合] 某研究发现一个效应很大的有利等位基因, 建议“尽快在核心群中把它固定”。从显性程度、当前频率、加性方差的变化、连锁拖累与遗传多样性等角度评价该建议。 [答案]

9.6 参考答案与解析

一、单项选择题

- 9.1 B。 $q = 0.75$, $\alpha = 1 + 1 \times (0.75 - 0.25) = 1.5$ 。有利显性等位基因稀有时平均效应大。 [题目]
- 9.2 B。育种值 $= 2qa$; (D) 是基因型值离均差, 包含显性偏差。 [题目]
- 9.3 A。 $p^2(-2q^2d) + 2pq(2pqd) + q^2(-2p^2d) = 0$ 。 [题目]
- 9.4 B。 $M = 2 \times 0 + 2 \times 0.25 \times (-1) = -0.5$ 。 [题目]
- 9.5 B。 [题目]
- 9.6 B。 $\alpha = 1 + 2(q - p) = 0 \Rightarrow q - p = -0.5 \Rightarrow p = 0.75$ 。 [题目]

二、判断与改错题

- 9.7 前半句正确, 后半句错误。 $d = 0$ 时 $\alpha = a$, 但 $V_A = 2pqa^2$ 仍随频率变化, 在 $p = 0.5$ 时最大、频率趋于 0 或 1 时趋于零。 [题目]
- 9.8 错误。基因型值离均差 = 育种值 + 显性偏差。杂合子的显性偏差 $2pqd$ 一般不为零。 [题目]
- 9.9 正确。见推导 9.1。 [题目]
- 9.10 正确。 $\Delta M = -2F \sum p_l q_l d_l$, 若 d_l 正负相抵, 总和接近零。观察到普遍的近交衰退本身就是“方向性显性”(有利等位基因倾向显性)的证据。 [题目]

三、填空题

- 9.11 $M = 2 \times 0.2 + 2 \times 0.24 \times 0.5 = 0.64$; $\alpha = 2 + 0.5 \times (0.4 - 0.6) = 1.9$ 。 [题目]
- 9.12 1.52、-0.38、-2.28。 [题目]
- 9.13 -0.16、0.24、-0.36。 [题目]

9.14 $V_A = 0.48 \times 3.61 = 1.7328$; $V_D = 0.24^2 = 0.0576$ 。 [题目]

四、计算题

9.15 (1) $M = 0.61$, $\alpha = 0.80$ (加权回归斜率 0.8000)。

基因型	频率	$G - M$	育种值	显性偏差
A_1A_1	0.49	0.39	0.48	-0.09
A_1A_2	0.42	-0.11	-0.32	0.21
A_2A_2	0.09	-1.61	-1.12	-0.49

(2) 三项检查在机器精度内为零; $V_A = 0.2688$, $V_D = 0.0441$, $V_G = 0.3129$, $V_A/V_G = 0.859$ 。

(3) 加性: V_A 在 $p = 0.5$ 最大 (0.50), $V_D = 0$; 部分显性 $d = 0.5a$: $p = 0.32$ 最大 (0.606), V_D 始终小于 V_A ; 完全显性: $p = 0.25$ 最大 (0.844), $p \geq 0.67$ 时 $V_D > V_A$ (推导 9.3); 超显性 $d = 1.5a$: $p = 0.22$ 最大 (1.16), $p \in [0.49, 0.96]$ 时 $V_D > V_A$ 。显性越强, V_A 最大值越偏向有利显性等位基因稀有的一侧, 因为此时隐性等位基因常见、平均效应大。 [题目]

9.16 (1) $M = 7.71$; $\alpha_1 = +1.19$, $\alpha_2 = -0.11$, $\alpha_3 = -2.81$, 满足 $\sum p_i \alpha_i = 0$ 。

(2)

基因型	频率	G	育种值	显性偏差
A_1A_1	0.25	10	2.38	-0.09
A_1A_2	0.30	9	1.08	0.21
A_1A_3	0.20	6	-1.62	-0.09
A_2A_2	0.09	7	-0.22	-0.49
A_2A_3	0.12	5	-2.92	0.21
A_3A_3	0.04	2	-5.62	-0.09

(3) $V_A = 2 \sum p_i \alpha_i^2 = 4.582$, $V_D = 0.044$, $V_G = 4.626$, 加性占 99%。以两个等位基因剂量为自变量的加权回归给出完全相同的育种值。本例 A_3 等位基因效应很大且接近加性, 遗传变异几乎全部可被选择利用。 [题目]

9.17

F	M_F	α_F	$V_A(F)$	剩余	V_G
0	-0.064	1.320	0.732	0.113	0.845
0.10	-0.098	1.262	0.736	0.119	0.854
0.25	-0.148	1.192	0.746	0.119	0.865
0.50	-0.232	1.107	0.772	0.099	0.871
0.75	-0.316	1.046	0.804	0.059	0.862
1.00	-0.400	1.000	0.840	0	0.840

(1) 加权回归与公式完全一致。(2) 均值线性下降, $\Delta M = -2pqdF = -0.336F$ 。(3) $F = 1$ 时只有两种纯合子, 频率 p 与 q , 基因型值差 $2a$, 方差 $= 4pqa^2$ ——近交系间的遗传方差全部可由剂量线性表示, “显性”无从表现。但注意: 在近交群体中, $V_A(F)$ 不再等于随机交配基础群的 $(1 + F)V_A$ (后者只在 $d = 0$ 时成立), 协方差中还会出现 V_D 、 $\text{Cov}(A, D)$ 等额外的“近交方差组分”(第 11、19 章)。 [题目]

9.18 (1) 9 个基向量两两加权内积均为 0。

(2) $M = 9.36$, $V_G = 7.392$: A 位点 $V_A = 1.168$ (15.8%), B 位点 $V_A = 4.206$ (56.9%), V_D 分别为 0.452 与 0.590, $V_{AA} = 0.922$ (12.5%), $V_{AD} = V_{DA} = 0.028$, $V_{DD} \approx 0$; 合计等于 V_G 。

(3) A 位点边际平均效应 $\alpha_A = 1.56$, 但在 BB、Bb、bb 背景下 A 的条件效应分别为 3.6、2.2、-0.2——A 的作用强烈依赖 B。边际效应是对 B 背景频率的加权平均, 若 B 的频率改变, α_A 与“加性方差”都会改变; 这就是加性 $\times$ 加性互作使部分上位方差在选择中表现为“可利用的加性方差”、且随频率变化的原因。 [题目]

9.19 (1) $D \in [-0.15, 0.15]$ 。

(2)

D	V_A	忽略 LD	α_A 边际	α_B 边际
-0.10	0.411	0.651	0.760	0.124
-0.05	0.531	0.651	0.880	0.362
0	0.651	0.651	1.000	0.600
0.05	0.771	0.651	1.120	0.838
0.10	0.891	0.651	1.240	1.076

(3) 精确枚举与公式一致。正 LD (两个有利等位基因倾向于在同一单倍型上) 增大加性方差, 负 LD (相斥) 减小加性方差——选择会产生负 LD, 这是 Bulmer 效

应的来源（第 14 章）。边际效应吸收了另一位点的效应，单标记 GWAS 估计的就是边际效应；它在 LD 结构不同的另一群体中不可直接移用。

[题目]

9.20

场合	α	A_1A_1	A_1A_2	A_2A_2	排名
纯种（配偶 A, $p = 0.8$ ）	-0.20	1.20	1.30	1.40	丙 > 乙 > 甲
杂交（配偶 B, $p = 0.2$ ）	+2.20	1.80	0.70	-0.40	甲 > 乙 > 丙
合成 F2 ($p = 0.5$)	+1.00	1.50	1.00	0.50	甲 > 乙 > 丙

超显性下杂合子最优。配偶群体中 A_1 已很常见时，再提供 A_1 只会产生更多 A_1A_1 ，提供 A_2 才能产生杂合子，因此 A_2A_2 公羊在纯种中最好；配偶为 A_1 稀少的品种 B 时，提供 A_1 最能产生杂合子，排名完全反转。这说明“育种值”是相对于指定配偶群体定义的，杂交体系中应以杂种后代表现定义选择目标（第 20 章的配合力）。

[题目]

9.21 $H = \sum dy^2 = 1 \times 0.16 + 0.5 \times 0.36 - 0.2 \times 0.25 = 0.16 + 0.18 - 0.05 = 0.29$ 。负显性位点在 F1 中降低表现，部分抵消正显性位点的杂种优势；杂种优势是所有位点 dy^2 的代数和。

[题目]

9.22 $\Delta M = -2F \sum pqd = -2 \times 0.25 \times (0.25 \times 1 + 0.16 \times 0.5) = -0.165$ 。

[题目]

五、推导与证明题

9.23 见推导 9.1。回归拟合值（离均差）即育种值，残差即显性偏差；最小二乘的正规方程保证残差加权和为零、残差与剂量加权协方差为零，因此显性偏差均值为零、与育种值不相关。

[题目]

9.24 见推导 9.2。两个条件：（1）定义育种值所用的群体频率与配偶群体相同，否则“传递给后代的平均价值”需按配偶群体频率重新计算；（2）孟德尔传递正常（无偏分离），且考虑的是单位点或连锁平衡下多位点的加性部分。

[题目]

9.25 见推导 9.3。

[题目]

9.26 推导见习题 9.17 的说明： $\text{Var}(x) = 2pq(1+F)$ ， $\text{Cov}(G, x) = 2apq(1+F) + 2pqd(1-F)(q-p)$ ，二者之比即得。失去的性质：（1）育种值与回归残差不再能解释为“配子效应之和”与“等位基因间互作”，因为两条配子不独立；（2）亲属协方差不能只用 V_A, V_D 与 r, u 表示，还需近交特有的方差与协方差组分；（3）后代育种值的期望不再简单等于双亲平均（依赖于后代所在群体的近交水平）。

[题目]

六、综合分析与研究设计题

9.27 可能原因：(1) 两品种等位基因频率不同，加性方差不同；(2) 环境方差不同（管理粗放者环境方差大）；(3) 测定方法或年龄不同；(4) 估计方法与模型不同（是否含母体效应、共同环境）；(5) 抽样误差；(6) 基因与环境互作（遗传效应在不同环境表达不同）；(7) 选择历史压缩了加性方差（Bulmer 效应）。研究设计：在同一环境中饲养两品种的代表性家系（共同试验站），统一测定方法与年龄，用同一模型估计各方差组分。若两品种的加性方差不同、环境方差相同，支持频率解释；若加性方差相近而原环境下的环境方差不同，支持环境解释；同时用标记估计基因组遗传力与位点频率分布作辅助证据。对测定方法，可在部分个体上用两种方法重复测定，估计测定误差方差。 [题目]

9.28 原因：(1) 平均效应依赖配偶群体频率，纯种育种值以纯种母畜为配偶定义，杂交中配偶为另一品种，存在显性时二者不同（习题 9.20）；(2) 杂种表现还包含杂种优势与品种互补，纯种评定不包含；(3) 纯种核心群环境与商品场环境不同，存在基因 $\times$ 环境互作；(4) 纯种中存在而杂种中不存在的 LD 结构。改进：收集商品代杂种的表型与系谱/基因型，建立纯种—杂种两性状模型，估计纯种—杂种遗传相关 r_{pc} ；在评定中加入杂种后代信息（联合评定），或以杂种表现的育种值为选择目标；在基因组评定中考虑品种来源特异的等位基因效应（BOA 模型）。 [题目]

9.29 评价：(1) **显性程度**：若有利等位基因为显性，杂合子已获得大部分好处，固定的边际收益有限；若为隐性，固定才能充分表现，但表型选择极慢，需要基因型选择；若存在超显性或在杂种中表现，固定反而有害。(2) **当前频率**：频率中等时该位点贡献大量加性方差，快速固定会迅速“用尽”这部分方差，之后选择只能依靠其他位点。(3) **加性方差的变化**：固定后 V_A 下降，若该基因同时影响其他性状（多效性），可能带来不利的相关反应。(4) **连锁拖累**：携带该等位基因的单倍型上可能连锁有害变异，快速选择会把它们一起带到高频。(5) **遗传多样性**：若该等位基因集中在少数家系，强选择会增加近交、减少有效群体大小。建议：把该位点作为固定效应或单独的方差组分纳入基因组评定，按最优贡献框架在控制近交的前提下逐步提高频率；同时检测其对其他性状的效应与显性作用。 [题目]

遗传方差组分、重复力与性状间相关

10.1 本章导学

学习目标

1. 熟练分解表型方差为加性、显性、上位与各类环境方差，区分广义与狭义遗传力。

2. 掌握重复力的定义、估计（含不平衡资料）与应用，能计算多次记录均值的遗传力与预测效果。

3. 理解性状间遗传相关与环境相关如何合成表型相关，理解多效性与连锁不平衡对遗传相关的贡献。

4. 能分析遗传协方差矩阵的特征结构，理解“最大遗传变异方向”与多性状改良的难易。

5. 能分解基因型 × 环境互作方差为尺度差异与排序改变两部分，判断其对选择的意义。

6. 理解方差组分的尺度依赖性，掌握对数与 Box-Cox 变换、二分类性状观察尺度与易感性尺度的换算。

重点与难点

重点：方差组分与遗传力；重复力与 n 次均值； r_p 的合成公式；Robertson 的 V_{GE} 分解；易感性尺度换算。

难点：重复力是遗传力的上限而非估计；遗传相关接近零不代表无多效性，位点少时遗传相关极不稳定；遗传力与显性、上位比例都依赖测量尺度；观察尺度遗传力随发病率改变，换算公式在极端发病率下失准。

本章把第 9 章的单位点分解推广到多位点与多性状，为第 11 章亲属协方差、第 13 章参数估计、第 15—16 章选择指数与第 24 章多性状模型提供参数基础。

10.2 知识结构图



图 10.1 第 10 章知识结构图

右侧三支讨论单个性状的方差构成与重复测定；左侧三支讨论多个性状之间、多个环境之间的协变，以及测量尺度如何改变这些量。

10.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
表型方差分解	$V_P = V_A + V_D + V_I + V_{Eg} + V_{Es} (+2 \text{Cov}_{GE} + V_{GE})$	各成分相对于指定群体
遗传力	$h^2 = V_A/V_P$, $H^2 = V_G/V_P$	狭义、广义
重复力	$t = (V_G + V_{Eg})/V_P$	$t \geq H^2 \geq h^2$
n 次均值方差	$V_{\bar{P}} = V_P[t + (1-t)/n]$	暂时环境独立
n 次均值遗传力	$h_n^2 = \frac{nh^2}{1 + (n-1)t}$	上限 h^2/t
表型相关	$r_P = h_x h_y r_A + e_x e_y r_E$	$e^2 = 1 - h^2$ ，无遗传—环境交叉协方差
遗传协方差	$\text{Cov}_A(X, Y) = \sum_l 2p_l q_l \alpha_{Xl} \alpha_{Yl} + \text{LD 项}$	多效性与连锁不平衡
可进化性	$e(\beta) = \beta^T G \beta / \beta^T \beta$	先标准化单位
G×E 分解	$V_{GE} = \frac{1}{2}(\sigma_1 - \sigma_2)^2 + \sigma_1 \sigma_2 (1 - r_g)$	两环境，Robertson 1959
对数尺度	$\text{Var}(\ln y) \approx \text{CV}^2$	乘法作用变为加性

概念	公式或定义	成立条件与提示
易感性换算	$h_O^2 = h_L^2 \frac{z^2}{K(1-K)}$	K 为发病率, $z = \varphi(\Phi^{-1}(1-K))$
变异系数	$CV_A = \sigma_A/\bar{y}, I_A = CV_A^2$	比较不同性状的可进化性

10.4 补充内容与公式推导

推导 10.1 n 次记录均值的遗传力与重复力

设 $y_j = g + e_g + e_j$, $j = 1, \dots, n$, g 为遗传值 (含加性 A), e_g 为永久 (一般) 环境, e_j 为暂时环境, 相互独立。均值 $\bar{y} = g + e_g + \bar{e}$,

$$\text{Var}(\bar{y}) = V_G + V_{Eg} + \frac{V_{Es}}{n} = V_P \left[t + \frac{1-t}{n} \right].$$

$\text{Cov}(A, \bar{y}) = V_A$, 因此均值的 “遗传力” (加性方差占均值方差的比例) 为

$$h_n^2 = \frac{V_A}{V_P[t + (1-t)/n]} = \frac{nh^2}{1 + (n-1)t}.$$

它随 n 单调增加, 极限 h^2/t 。用均值预测育种值的回归系数正是 h_n^2 , 可靠度为

$$R_n = \frac{\text{Cov}(A, \bar{y})^2}{V_A \text{Var}(\bar{y})} = \frac{h^2}{t + (1-t)/n} = h_n^2.$$

t 远大于 h^2 (永久环境大) 时, 重复测定的收益很快饱和。

推导 10.2 表型相关的合成与 “隐藏” 的遗传相关

设 $P_X = A_X + E_X$, $P_Y = A_Y + E_Y$, A 与 E 互不相关 (含跨性状)。则

$$\text{Cov}(P_X, P_Y) = \text{Cov}(A_X, A_Y) + \text{Cov}(E_X, E_Y) = r_A \sigma_{A_X} \sigma_{A_Y} + r_E \sigma_{E_X} \sigma_{E_Y}.$$

除以 $\sigma_{P_X} \sigma_{P_Y}$ 得 $r_P = h_X h_Y r_A + e_X e_Y r_E$ 。由于 $h_X h_Y$ 与 $e_X e_Y$ 都在 $[0, 1]$, 表型相关是遗传相关与环境相关的加权组合; 当两个性状遗传力都低时, r_P 主要反映 r_E 。例如 $h^2 = 0.25, 0.36$, $r_A = 0.5$, $r_E = -0.2$ 时 $r_P = 0.15 - 0.139 = 0.011 \approx 0$: 两个性状在表型上 “无关”, 遗传上却中等正相关。若仅凭表型相关判断间接选择的价值, 会完全错过这一遗传联系。

推导 10.3 Robertson 的基因型 × 环境互作分解

两环境中基因型的遗传值 (g_1, g_2) , 方差 σ_1^2, σ_2^2 , 协方差 $r_g \sigma_1 \sigma_2$ 。双因素模型 $g_{ij} = G_i + (GE)_{ij}$ 中, 基因型主效 G_i 的方差等于跨环境的遗传协方差 $r_g \sigma_1 \sigma_2$, 平均的环境内遗传方差为 $\frac{1}{2}(\sigma_1^2 + \sigma_2^2)$, 故

$$V_{GE} = \frac{1}{2}(\sigma_1^2 + \sigma_2^2) - r_g \sigma_1 \sigma_2 = \frac{1}{2}(\sigma_1 - \sigma_2)^2 + \sigma_1 \sigma_2(1 - r_g).$$

第一项只反映两环境遗传标准差不同 (尺度效应), 对任一环境中的排序没有影响; 第二项反映排序改变, 是真正影响 “在一个环境中选、在另一个环境中用” 的部分。只报告 V_{GE} 或方差分析的互作 F 检验, 无法回答选择是否需要分环境进行。

易错辨析

- 重复力不是遗传力的估计, 而是其上限 (含永久环境)。
- 单次记录与多次均值的遗传力不同, 比较文献值时要核对 “记录” 的定义。
- $r_A \approx 0$ 不等于无多效性: 正负方向的多效性可相互抵消。
- $G \times E$ 方差显著不一定需要分环境选择: 可能只是尺度效应。
- 二分类性状在 0/1 尺度上的遗传力依赖发病率, 不同发病率群体间的比较应换算到易感性尺度。

10.5 习题

一、单项选择题

10.1 ★ [单选] 在重复测定性状的方差分解中, 进入重复力分子但不进入遗传力分子的是

- (A) 暂时环境方差 (B) 永久环境方差
(C) 加性方差 (D) 测定误差方差

[答案]

10.2 ★ [单选] 关于重复力 t 、广义遗传力 H^2 与狭义遗传力 h^2 , 一定成立的是

- (A) $h^2 \geq H^2 \geq t$ (B) $t \geq H^2 \geq h^2$ (C) $t = h^2$
(D) 三者大小无确定关系

[答案]

10.3 ★ [单选] 两性状 h^2 均为 0.36, $r_A = 0.5$, $r_E = 0$, 则表型相关为

- (A) 0.50 (B) 0.18 (C) 0.30 (D) 0

[答案]

10.4 ★★ [单选] 若各位点对性状按乘法方式作用, 最可能使方差分解接近纯加性的变换是

- (A) 平方 (B) 取对数 (C) 取倒数 (D) 不需变换

[答案]

10.5 ★★ [单选] 优良基因型的个体总被分配到更好的饲养条件中。这会使表型方差

- (A) 增加 $2\text{Cov}(G, E)$ (B) 减少 $2\text{Cov}(G, E)$
(C) 不变 (D) 增加 V_{GE}

[答案]

10.6 ★★ [单选] 两环境中遗传标准差分别为 1 与 2, 遗传相关为 1。Robertson 分解中排序改变项为

- (A) 0.5 (B) 0 (C) 1 (D) 2

[答案]

二、判断与改错题

10.7 ★ [判断] 以多次记录的均值作表型时, 遗传力高于单次记录的遗传力。

[答案]

10.8 ★★ [判断] 两性状遗传相关为零, 说明影响两性状的基因完全不同。

[答案]

10.9 ★★ [判断] 甲群体某性状遗传力低于乙群体, 则甲群体的加性方差也一定小于乙群体。

[答案]

10.10 ★★ [判断] 对性状作非线性变换, 可能改变显性方差与加性方差的相对大小。

[答案]

三、填空题

10.11 ★ [填空] $V_P = 100$, $V_A = 30$, $V_D = 10$, $V_{Eg} = 15$, $V_{Es} = 45$ 。则 $h^2 =$ _____, $H^2 =$ _____, 重复力 $t =$ _____。

[答案]

10.12 ★ [填空] 接上题, 4 次记录均值的表型方差为_____, 其遗传力为_____。 [答案]

10.13 ★★ [填空] 两性状 h^2 分别为 0.25 与 0.36, $r_A = 0.5$, $r_E = -0.2$, 则 $r_P =$ _____。

[答案]

10.14 ★ [填空] 某性状变异系数为 20%, 则其自然对数的方差约为_____。 [答案]

四、计算题

10.15 ★★ [计算] 多效性合成遗传相关。L 个独立加性位点, 每个位点对两性状的效应来自相关系数 0.5 的二元正态, 频率 $\sim U(0.05, 0.5)$ 。对 $L = 5, 20, 100, 1000$ 各模拟 2000 次。(1) 求 r_A 的均值、标准差与 $r_A < 0$ 的比例; (2) 验证 $E(G_{12})/E(G_{11}) = 0.5$; (3) 讨论位点数对遗传相关稳定性的含义。 [程序] [ch10/ex10_15_pleiotropy_correlation.py](#) [答案]

10.16 ★★ [计算] 不平衡重复记录的重复力。150 只动物各有 1—5 次记录 (真实 $t = 0.40$)。(1) 用 ANOVA (有效组大小 n_0) 估计重复力; (2) 用单因素模型的 REML 估计; (3) 比较剔除单记录动物前后的估计, 说明单记录动物提供什么信息。 [程序] [ch10/ex10_16_repeatability.py](#) [答案]

10.17 ★★★ [计算] 尺度依赖。三个乘法作用的位点 (效应 15%、10%、20%) 与 12% 的乘法环境误差。(1) 在原始尺度与对数尺度上分别做多位点正交分解; (2) 比较 Box-Cox $\lambda = 1, 0.5, 0, -0.5$ 下的广义遗传力、加性比例与“残差方差—均值相关”; (3) 说明为何“非加性”可能是测量尺度的产物。 [程序] [ch10/ex10_17_scale_transformation.py](#) [答案]

10.18 ★★ [计算] 二分类性状的尺度换算。易感性尺度 $h^2 = 0.30$, 400 头公畜 $\times 50$ 个后代。对发病率 50%、20%、10%、5%、2%: (1) 计算观察尺度遗传力的理论值; (2) 由 0/1 资料用半同胞 ANOVA 估计观察尺度 h^2 , 再换算回易感性尺度; (3) 分析换算在低发病率时的偏差。 [程序] [ch10/ex10_18_liability_observed.py](#) [答案]

10.19 ★★ [计算] G×E 的两种成分。三种情景: 仅尺度差异 ($\sigma_1 = 1, \sigma_2 = 2, r_g = 1$)、仅排序改变 (1.5, 1.5, 0.6)、两者兼有 (1, 2, 0.6)。(1) 计算 V_{GE} 及两部分; (2) 模拟 30 个基因型, 统计环境 1 前 5 名在环境 2 中仍为前 5 名的平均个数; (3) 说明哪一部分影响选择。 [程序] [ch10/ex10_19_gxe_decomposition.py](#) [答案]

10.20 ★★★ [计算] 遗传协方差矩阵的几何。体重、背膘、眼肌面积的 G 与表型标准差见配套数据。(1) 分别在原始单位与表型标准差单位下求特征值与 $g_{\max}$; (2) 计算三个育种方向的可进化性及与 $g_{\max}$ 的夹角; (3) 解释为什么单位标准化会改变结论。 [程序] `ch10/ex10_20_genetic_geometry.py` [答案]

10.21 ★ [计算] 某性状 $V_G = 40, V_E = 60$, 由于优良个体被安排到较好栏舍, $\text{Cov}(G, E) = 6$ 。求表型方差, 并比较“忽略协方差”与“包含协方差”时的广义遗传力。 [答案]

10.22 ★ [计算] 某性状均值 50, 加性方差 25。求加性变异系数与可进化性指标 $I_A = CV_A^2$ 。若另一性状均值 2、加性方差 0.04, 哪个性状按 I_A 衡量更“可进化”? [答案]

五、推导与证明题

10.23 ★ [证明] 推导 n 次记录均值的表型方差、遗传力与用其预测育种值的可靠度 (推导 10.1), 并求可靠度的极限。 [答案]

10.24 ★ [证明] 推导 $r_P = h_X h_Y r_A + e_X e_Y r_E$, 并说明公式中“无遗传—环境交叉协方差”的假设何时不成立。 [答案]

10.25 ★★ [证明] 推导 Robertson 的 V_{GE} 分解 (推导 10.3), 并证明当 $\sigma_1 = \sigma_2$ 时 $V_{GE} = 0$ 的充要条件是 $r_g = 1$ 。 [答案]

10.26 ★★★ [证明] 设易感性 $\ell = g + e \sim N(0, 1)$, $\text{Var}(g) = h_L^2$, 观察 $y = 1\{\ell > T\}$ 。用 y 对 g 的线性近似 $E(y|g) \approx K + zg$, 推导 $h_O^2 \approx h_L^2 z^2 / [K(1 - K)]$, 并说明近似在何时失效。 [答案]

六、综合分析与研究设计题

10.27 ★★ [综合] 奶牛体细胞计数 (SCC) 分布强烈右偏, 常用 $\log_2(\text{SCC}/100000) + 3$ 转换为体细胞评分。从方差—均值关系、遗传力比较与选择目标解释三个方面评价这种转换, 并说明何时应当直接以乳房炎发病为目标性状。 [答案]

10.28 ★★ [综合] 某论文用 50 头公畜的半同胞资料报告两性状遗传相关为 -0.65 , 并据此认为“不能同时改良这两个性状”。从抽样误差、位点数、群体与环境依赖性三个角度评价这一结论。 [答案]

- 10.29 ★★★ [综合]** 设计一项研究, 估计同一肉牛品种在放牧与舍饲两种系统中的遗传相关, 并判断是否需要分系统开展遗传评定。说明公畜使用方式、所需样本量、模型与判断标准。 [答案]

10.6 参考答案与解析

一、单项选择题

- 10.1 B。** 永久环境在重复测定间共享, 进入重复力分子; 它不传递给后代, 不进入遗传力分子。 [题目]
- 10.2 B。** $t = (V_G + V_{Eg})/V_P \geq V_G/V_P \geq V_A/V_P$ 。 [题目]
- 10.3 B。** $r_P = 0.6 \times 0.6 \times 0.5 = 0.18$ 。 [题目]
- 10.4 B。** 乘法作用 $y = \prod (1 + e_l)^{x_l}$ 取对数后为各位点之和。 [题目]
- 10.5 A。** $V_P = V_G + V_E + 2\text{Cov}(G, E)$, 正协方差使表型方差增大, 并使由表型估计的遗传力偏高 (若协方差被误归入遗传部分)。 [题目]
- 10.6 B。** $\sigma_1\sigma_2(1 - r_g) = 0$; 只有尺度项 $\frac{1}{2}(1 - 2)^2 = 0.5$ 。 [题目]

二、判断与改错题

- 10.7 正确** ($n > 1$ 且 $t < 1$ 时), $h_n^2 = nh^2/[1 + (n - 1)t] > h^2$ 。但均值遗传力的提高有上限 h^2/t 。 [题目]
- 10.8 错误。** 遗传相关是以 $2pq$ 为权的效应协方差之和, 正负多效性可以抵消 (习题 10.15 中位点少时 r_A 可正可负); 连锁不平衡也会贡献协方差。 [题目]
- 10.9 错误。** 遗传力是比例, 甲群体可能加性方差更大但环境方差更大。比较可利用的遗传变异应看 σ_A 或 CV_A 。 [题目]
- 10.10 正确。** 见习题 10.17; 例如乘法作用的位点在原始尺度上表现为互作, 在对数尺度上为纯加性。 [题目]

三、填空题

- 10.11** $h^2 = 0.30$, $H^2 = 0.40$, $t = 0.55$ 。 [题目]

10.12 $100 \times (0.55 + 0.45/4) = 66.25$; $30/66.25 = 0.453$ 。 [题目]

10.13 $0.5 \times 0.6 \times 0.5 + \sqrt{0.75 \times 0.64} \times (-0.2) = 0.150 - 0.139 = 0.011$ 。 [题目]

10.14 约 $0.2^2 = 0.04$ 。 [题目]

四、计算题

10.15

L	r_A 均值	r_A 标准差	$r_A < 0$ 比例	$E(G_{12})/E(G_{11})$
5	0.457	0.387	0.137	0.493
20	0.490	0.183	0.012	0.500
100	0.498	0.079	0	0.501
1000	0.500	0.025	0	0.499

$E(G_{12})/E(G_{11})$ 在所有 L 下都等于效应相关 0.5, 但单个群体的 r_A 是有限个位点的加权平均: 位点少时 (如 5 个主效位点) r_A 标准差达 0.39, 近 14% 的群体甚至为负。推论: (1) 由少数大效应位点主导的性状, 不同群体 (或不同时间) 的遗传相关可能差别很大; (2) 选择改变频率后, r_A 也会改变; (3) 高度多基因性状的 r_A 较稳定, 反映的是效应的系统性相关。 [题目]

10.16 (1) 447 条记录, $n_0 = 2.976$; $MSB = 1.533$, $MSW = 0.620$, $\hat{\sigma}_c^2 = 0.307$, $\hat{t} = 0.331$ 。
(2) REML: $\hat{\sigma}_c^2 = 0.298$, $\hat{\sigma}_e^2 = 0.630$, $\hat{t} = 0.322$ (真值 0.40, 差异属抽样误差: 150 只动物时 t 的 SE 约 0.05)。
(3) 剔除 19 只单记录动物后 $\hat{t} = 0.309$ 。单记录动物不提供个体内重复的信息 (无组内平方和), 但提供关于总方差 $\sigma_c^2 + \sigma_e^2$ 与均值的信息, 在 REML 中通过总方差约束间接帮助分解。若记录缺失与动物表现有关 (如第一胎差的母羊被淘汰), 只用多记录动物会产生选择偏差, 应在模型中保留全部记录。 [题目]

10.17 (1) 原始尺度: 遗传值均值 30.76, $V_G = 27.75$, V_A 占 98.85%, $V_D = 0.082$, $V_I = 0.237$; 对数尺度: V_A 占 100%, 显性与上位为零 (数值误差 10^{-17})。
(2)

λ	广义遗传力	V_A/V_G	残差方差—均值相关
1 (原始)	0.653	0.989	0.998
0.5	0.666	0.997	1.000

λ	广义遗传力	V_A/V_G	残差方差—均值相关
0 (对数)	0.672	1.000	0.851
-0.5	0.670	0.997	-1.000

原始尺度上环境方差随均值几乎完全正相关（乘法误差），对数尺度上方差稳定（0.85 的相关在四组均值上由抽样噪声主导，方差本身已近乎相等）， $\lambda = -0.5$ 时关系反转。

(3) 本例效应较小，原始尺度上非加性比例只有约 1%；效应越大、位点越多，乘法作用在原始尺度产生的“上位”越明显。因此报告显性与上位方差时，必须说明测量尺度；选择一个使遗传效应可加、环境方差稳定的尺度，是方差分析的前提。

[题目]

10.18

发病率	换算系数	理论 h_O^2	估计 h_O^2	换算回 h_L^2
0.50	0.637	0.191	0.200	0.314
0.20	0.490	0.147	0.165	0.340
0.10	0.342	0.103	0.114	0.336
0.05	0.224	0.067	0.060	0.267
0.02	0.120	0.036	0.026	0.208

观察尺度遗传力随发病率下降而迅速变小：同样的遗传变异，在 2% 发病率时 0/1 记录的遗传力只有易感性尺度的 12%。换算公式基于线性近似（推导见习题 10.26），在 h^2 不太大、发病率中等时较准；发病率很低时，公畜间发病率差异的分布高度偏斜，ANOVA 估计的抽样误差增大，换算结果偏低。低发病率性状应直接用阈值模型（第 24 章）估计易感性尺度参数。

[题目]

10.19

情景	V_{GE}	尺度项	排序项	前 5 名重合数
仅尺度差异	0.50	0.50	0	5.00
仅排序改变	0.90	0	0.90	2.27
两者兼有	1.30	0.50	0.80	2.28

（两环境独立时期望重合 0.83 个。）只有尺度差异时，两环境的前 5 名完全相同；“两者兼有”的 V_{GE} 最大，但对选择的影响与“仅排序改变”几乎一样——决定选择一

致性的是 r_g ，而非 V_{GE} 的大小。

【题目】

10.20 (1) 原始单位：特征值 11.49、2.81、0.30， $g_{\max} = (0.871, 0.103, 0.480)$ ，解释 78.7% 的遗传方差，主要由体重（方差最大）主导；标准化单位：特征值 0.567、0.418、0.025， $g_{\max} = (0.766, 0.515, 0.386)$ ，解释 56.1%。

(2) 标准化单位下：“同时提高体重与眼肌、降低背膘” $e = 0.427$ ，与 $g_{\max}$ 夹角 68.5° ；“只提高体重” $e = 0.360$ ，夹角 40.1° ；“提高体重、降低眼肌” $e = 0.095$ ，夹角 74.4° 。遗传相关 $r_{13} = 0.70$ 、 $r_{12} = 0.40$ 、 $r_{23} = -0.24$ 。

(3) 原始单位下方差大的性状主导特征向量，结论只是“单位选择”的产物；按表型标准差标准化后，各性状在同一尺度上比较。“提高体重、降低眼肌”方向几乎与遗传主轴正交（ $r_{13} = 0.7$ ），可利用的遗传变异只有 0.095，进展会很慢；第一个育种目标虽然与 $g_{\max}$ 夹角也大，但落在第二主轴附近，仍有相当的遗传变异。多性状目标的难易，应以目标方向上的遗传方差而非各性状的遗传力来判断。【题目】

10.21 $V_p = 40 + 60 + 12 = 112$ 。包含协方差：若把协方差视为遗传与环境共同产生，严格的广义遗传力为 $40/112 = 0.357$ ；若忽略协方差、误把 V_p 当作 100，得 0.40；若把协方差全部归入遗传，得 $52/112 = 0.464$ 。G—E 协方差的归属取决于研究问题：评定育种值时应在设计上消除它（随机分配栏舍）。【题目】

10.22 $CV_A = 5/50 = 10\%$ ， $I_A = 0.01$ ；另一性状 $CV_A = 0.2/2 = 10\%$ ， $I_A = 0.01$ ，二者相同。尽管两性状加性方差相差 625 倍，按均值标准化后的可进化性一样，这说明比较不同单位、不同量级的性状时，应选择有意义的标准化方式。【题目】

五、推导与证明题

10.23 见推导 10.1。可靠度 $R_n = h^2/[t + (1-t)/n]$ ， $n \rightarrow \infty$ 时 $R_\infty = h^2/t$ ，即自身重复记录所能达到的上限；要突破这一上限需要亲属信息。【题目】

10.24 见推导 10.2。“无交叉协方差”指 $\text{Cov}(A_X, E_Y) = \text{Cov}(E_X, A_Y) = 0$ 。不成立的例子：母体效应（母亲的遗传影响后代的环境）、社会互作、遗传优良个体被安排到更好环境（基因—环境相关），以及一个性状本身构成另一个性状的环境（如出生重影响断奶前的生长环境）。【题目】

10.25 见推导 10.3。 $\sigma_1 = \sigma_2 = \sigma$ 时 $V_{GE} = \sigma^2(1 - r_g)$ ，为零当且仅当 $r_g = 1$ （ $\sigma > 0$ ）。【题目】

10.26 $E(y | g) = P(e > T - g) = \Phi\left(\frac{g - T}{\sqrt{1 - h_L^2}}\right)$ 。在 $g = 0$ 附近一阶展开： $E(y | g) \approx$

$K + \frac{\varphi(T')}{\sqrt{1-h_L^2}}g$, $T' = T/\sqrt{1-h_L^2}$ 。当 h_L^2 较小时 $T' \approx T$, 斜率约为 $z = \varphi(T)$ 。观察尺度的“加性遗传方差”约为 $z^2 h_L^2$, 0/1 的表型方差为 $K(1-K)$, 得 $h_O^2 \approx z^2 h_L^2 / [K(1-K)]$ 。失效情形: h_L^2 大 (线性近似与 $\sqrt{1-h^2}$ 修正不可忽略)、发病率极低 (g 的高端对发病概率的影响高度非线性)、或易感性非正态。 [题目]

六、综合分析与研究设计题

10.27 方差—均值关系: SCC 的方差随均值迅速增大, 原始尺度上残差高度异方差; 对数变换使方差近似稳定、分布接近正态, 满足线性混合模型假设。**遗传力比较:** 变换后遗传力 (约 0.1—0.2) 高于原始尺度, 不同研究必须在同一尺度上比较。**选择目标解释:** 选择降低体细胞评分, 是在对数尺度上降低“平均水平”, 对极端高值 (临床乳房炎) 的影响需另行评估; 体细胞评分作为乳房炎的指示性状, 其价值取决于与乳房炎易感性的遗传相关 (通常 0.6—0.8)。当乳房炎发病记录完整可靠时, 应以乳房炎发病 (阈值模型) 为目标性状, 体细胞评分作为辅助信息进入多性状评定。 [题目]

10.28 抽样误差: 50 头公畜的遗传相关标准误通常在 0.2—0.4, -0.65 的 95% 区间可能跨越 -1 到 -0.1 , 结论不稳。**位点数:** 若两性状受少数主效位点共同影响, r_A 由这些位点的频率决定, 选择可以改变频率与相关 (习题 10.15); 分离出主效位点后可能找到同时改良两性状的组合。**群体与环境依赖:** r_A 只适用于估计群体与环境, 在其他品种或管理条件下可能不同。即使 $r_A = -0.65$ 为真, 也不意味着“不能同时改良”: 选择指数可以在两性状上同时取得进展, 只是速度较慢 (G 在该方向上有正的方差, 除非 $r_A = -1$)。 [题目]

10.29 设计: (1) **连接:** 选择一批公畜 (如 50—100 头) 在两系统中各有足够女儿或后代, 形成公畜跨系统的连接; (2) **样本量:** 遗传相关的 SE 约 $\sqrt{(1-r_g^2)^2 / (\text{有效公畜数} \cdot \text{两系统信息})}$, 若希望 $SE \approx 0.1$, 需约 100 头公畜、每头每系统 20—30 个后代; (3) **模型:** 两性状 (同一性状在两系统中视为不同性状) 动物模型, 各系统有自己的固定效应、遗传方差与残差方差, 估计 r_g 与两系统的遗传方差; (4) **判断标准:** Robertson 的经验阈值 $r_g < 0.8$ 时考虑分系统评定或采用多性状评定; 同时用两系统的遗传方差比判断尺度差异; 还应比较“分系统选择”与“共同选择”在各系统中的预期反应及成本。若 r_g 高而方差不同, 只需在评定中考虑异质方差; 若 r_g 低, 应以目标系统的表现为选择目标。 [题目]

亲属间的相似性与遗传协方差

11.1 本章导学

学习目标

- 1. 区分因果模型（遗传与环境组分）与观察模型（可估计的方差与协方差），理解设计如何决定组分的可识别性。
- 2. 掌握同状态（IBS）与同祖同源（IBD）的区别，能计算亲缘系数、加性关系与显性关系，以及 IBD 状态概率 k_0, k_1, k_2 。
- 3. 能用 Cockerham 系数写出各类亲属的遗传协方差，包括显性与上位成分。
- 4. 掌握家系均值的方差、组内相关与有效独立记录数，理解后代测定的信息来源。
- 5. 理解期望关系与实际关系的差别，以及实际关系的抽样波动如何随基因组长度变化。
- 6. 能写出直接—母体效应模型下的亲属协方差，理解双生子设计中 ACE/ADE 模型的识别限制。

重点与难点

重点： $r = 2f$ 、 $u = k_2$ ； $\text{Cov} = rV_A + uV_D + r^2V_{AA} + ruV_{AD} + u^2V_{DD}$ ；家系均值方差；Willham 母体协方差。

难点： 近交个体之间不能用 k_0, k_1, k_2 描述，需 Jacquard 九状态；全同胞协方差中显性与共同环境无法由全同胞资料单独区分；双生子资料只有三个独立矩，不能同时估计 A、C、D、E；母系半同胞与父系半同胞之差包含母体遗传、直接—母体协方差与母体永久环境三项。

本章把第 9—10 章的方差组分与资料联系起来，是第 12 章系谱关系矩阵、第 13 章参数估计与第 22 章动物模型的直接基础；“期望关系与实际关系”的讨论则为第 26 章基因组关系矩阵埋下伏笔。

11.2 知识结构图




图 11.1 第 11 章知识结构图

右侧四支建立“亲属为何相似”的因果框架与计算工具；左侧三支讨论实际共享的波动、母体效应与人类双生子设计这些需要特别小心的情形。

11.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
亲缘系数	f_{xy} : 从 x, y 各随机取一个等位基因为 IBD 的概率	相对于基础群体
加性关系	$r_{xy} = 2f_{xy}$; $A_{xx} = 1 + F_x$	关系矩阵 A
IBD 状态	$r = \frac{1}{2}k_1 + k_2, u = k_2$	两个体均非近交
常见亲属 (k_0, k_1, k_2)	亲子 $(0, 1, 0)$; 全同胞 $(\frac{1}{4}, \frac{1}{2}, \frac{1}{4})$; 半同胞 $(\frac{1}{2}, \frac{1}{2}, 0)$	双重堂表 $(\frac{9}{16}, \frac{6}{16}, \frac{1}{16})$
遗传协方差	$Cov_G = \sum_{m,n} r^m u^n V_{A^m D^n}$	非近交、连锁平衡
全同胞	$\frac{1}{2}V_A + \frac{1}{4}V_D + \frac{1}{4}V_{AA} + V_{Ec}$	同窝共同环境 V_{Ec}
家系均值方差	$V_P[t + (1-t)/n]$	t 为组内相关
有效记录数	$n_{\text{eff}} = n/[1 + (n-1)t] \rightarrow 1/t$	估计家系均值的信息

概念	公式或定义	成立条件与提示
后代测定可靠度	$R = \frac{nh^2}{4 + (n-1)h^2}$	随机无关母畜、无共同环境
实际关系	$E(\hat{r}_{FS}) = \frac{1}{2}$, SD 约 0.04 (约 30 M 基因组)	随基因组长度增加而减小
Willham 协方差	$r\sigma_o^2 + r_{mm'}\sigma_m^2 + (r_{i,m'} + r_{m,j})\sigma_{om} + [\text{同母}]\sigma_{PE}^2$	直接—母体模型
Falconer 双生子	$h^2 = 2(r_{MZ} - r_{DZ})$, $c^2 = 2r_{DZ} - r_{MZ}$	ACE 模型、等环境假设

11.4 补充内容与公式推导

推导 11.1 由 IBD 状态得到 $\text{Cov} = rV_A + uV_D$

单位点，两非近交个体 x, y 。按共享 IBD 等位基因数分情形：(1) 共享 0 个，两者基因型独立，协方差为 0；(2) 共享 1 个，可写 $G_x = \alpha_1 + \alpha_2 + \delta_{12}$ 、 $G_y = \alpha_1 + \alpha_3 + \delta_{13}$ ，其中 α_1 为同一个等位基因的平均效应，协方差 = $\text{Var}(\alpha_1) = \frac{1}{2}V_A$ （显性偏差 δ_{12} 与 δ_{13} 不相关）；(3) 共享 2 个，两者基因型相同，协方差 = $V_A + V_D$ 。故

$$\text{Cov}(G_x, G_y) = k_1 \cdot \frac{1}{2}V_A + k_2(V_A + V_D) = \left(\frac{1}{2}k_1 + k_2\right)V_A + k_2V_D = rV_A + uV_D.$$

多位点且连锁平衡时，上位项按“每个位点分别共享”组合：加性 × 加性需要两个位点各共享一个等位基因的“加性部分”，系数为 r^2 ；以此类推得到 Cockerham 的一般式。该推导要求个体非近交：若 x 近交，其两个等位基因本身可能 IBD，“共享数”不足以描述状态，协方差中还会出现 $\text{Cov}(A, D)$ 等近交特有组分。

推导 11.2 后代测定的可靠度

公畜 s 与 n 头无亲缘母畜各交配一次，后代 $y_j = \frac{1}{2}A_s + \frac{1}{2}A_{d_j} + \varphi_j + e_j$ 。 $\text{Cov}(A_s, y_j) = \frac{1}{2}V_A$ ， $\text{Cov}(y_j, y_k) = \frac{1}{4}V_A$ ($j \neq k$ ，半同胞)。后代均值 $\bar{y}$ 的方差 $V_P[t + (1-t)/n]$ ， $t = h^2/4$ ，故

$$R = \frac{\text{Cov}(A_s, \bar{y})^2}{V_A \text{Var}(\bar{y})} = \frac{V_A^2/4}{V_A V_P[h^2/4 + (1-h^2/4)/n]} = \frac{nh^2}{4 + (n-1)h^2}.$$

$n \rightarrow \infty$ 时 $R \rightarrow 1$ ：后代测定可以无限逼近公畜的真实育种值，这与自身重复记录的上限 h^2/t 不同——每个后代都提供公畜一半育种值的一次新的“抽样”，而父源孟德尔抽样与母方贡献在不同后代间独立。若后代共享母亲或栏舍， t 增大， R 的增长变慢。

推导 11.3 双生子设计只有三个可识别矩

MZ 与 DZ 双生子对的方差相同, 协方差分别为 $A+D+C$ 与 $\frac{1}{2}A+\frac{1}{4}D+C$ 。观测资料只能提供 $V = A+D+C+E$ 、 c_{MZ} 、 c_{DZ} 三个量, 而参数有四个。由 $c_{MZ}-2c_{DZ} = \frac{1}{2}D-C$ 可见: D 与 C 只以 $\frac{1}{2}D-C$ 的组合出现。若 $r_{MZ} < 2r_{DZ}$, 数据支持 $C > 0$; 若 $r_{MZ} > 2r_{DZ}$, 支持 $D > 0$; 二者同时存在时会部分抵消, ACE 与 ADE 都会把 A 估计偏高 (习题 11.19)。要分离四项, 需要加入其他亲属类型 (如分开抚养的双生子、半同胞、父母—子女) 或基因组资料。

易错辨析

- **IBS 不等于 IBD**: 两个随机个体共享同一等位基因的状态可能来自远古, 不代表在系谱基础群意义下的同祖。
- **祖孙、叔侄与半同胞的 r 都是 $1/4$** , 但 k 状态与实际共享片段的长度分布不同。
- **亲子协方差不含显性方差**, 因为亲子只共享一个等位基因。
- **全同胞组内相关高于 $h^2/2$ 时**, 多出的部分可能来自显性或共同窝环境, 单靠全同胞资料无法区分。
- **母系半同胞相关高于父系半同胞时**, 不能直接归因于母体遗传效应, 还有母体永久环境与直接—母体协方差。

11.5 习题

一、单项选择题

11.1 ★ [单选] 在无共同环境、无上位的条件下, 全同胞的遗传协方差为

- (A) $\frac{1}{2}V_A$ (B) $\frac{1}{2}V_A + \frac{1}{4}V_D$ (C) $\frac{1}{4}V_A$ (D) $V_A + V_D$

[答案]

11.2 ★ [单选] 两个非近交全同胞的亲缘系数为

- (A) $1/2$ (B) $1/4$ (C) $1/8$ (D) 1

[答案]

11.3 ★ [单选] 下列亲属中, 遗传协方差包含显性方差的是

- (A) 亲子 (B) 半同胞 (C) 全同胞 (D) 祖孙

[答案]

11.4 ★★ [单选] 双重堂表兄弟的显性关系 u 为

- (A) 0 (B) $1/16$ (C) $1/8$ (D) $1/4$

[答案]

11.5 ★★ [单选] 关于全同胞实际加性关系的离散程度, 下列说法正确的是

- (A) 恒为 0 (B) 染色体越多、越长, 标准差越小
(C) 与基因组大小无关 (D) 标准差约为 0.25

[答案]

11.6 ★★ [单选] 母系半同胞的相关明显高于父系半同胞。下列解释中不完整的是

- (A) 母体遗传效应 (B) 母体永久环境
(C) 直接—母体遗传协方差 (D) 仅由母体遗传效应造成

[答案]

二、判断与改错题

11.7 ★ [判断] 两个个体在某位点基因型相同, 说明它们在该位点的等位基因是同祖同源的。 [答案]

11.8 ★★ [判断] 祖孙、叔侄与半同胞的加性关系相同, 因此它们的遗传协方差在任何遗传模型下都相同。 [答案]

11.9 ★★ [判断] 对任意亲属对 (含近交个体), 都有 $r = \frac{1}{2}k_1 + k_2$ 。 [答案]

11.10 ★★ [判断] 后代测定中, 每头公畜的后代数无限增大时, 公畜育种值的可靠度趋于 1; 而自身重复记录无限增多时, 可靠度趋于 h^2/t 。 [答案]

三、填空题

11.11 ★ [填空] 双重堂表兄弟的 $(k_0, k_1, k_2) = \underline{\hspace{2cm}}$, 加性关系 $r = \underline{\hspace{2cm}}$, 显性关系 $u = \underline{\hspace{2cm}}$ 。 [答案]

11.12 ★ [填空] $V_A = 30$, $V_D = 10$, 同窝共同环境 $V_{Ec} = 5$, 无上位, 则同窝全同胞协方差为 $\underline{\hspace{2cm}}$, 半同胞协方差为 $\underline{\hspace{2cm}}$ 。 [答案]

11.13 ★ [填空] 同卵与异卵双生子的相关分别为 0.72 与 0.45。按 Falconer 公式, $h^2 = \underline{\hspace{2cm}}$, $c^2 = \underline{\hspace{2cm}}$, $e^2 = \underline{\hspace{2cm}}$ 。 [答案]

11.14 ★ [填空] 某性状 $h^2 = 0.4$, $V_p = 50$ 。10 个父系半同胞（无共同环境）表型均值的方差为 $\underline{\hspace{2cm}}$, 有效独立记录数为 $\underline{\hspace{2cm}}$ 。 [答案]

四、计算题

11.15 ★★ [计算] 基因下落与表格法。10 头动物的系谱见配套数据（含全同胞、半同胞与近交）。(1) 用表格法计算加性关系矩阵与近交系数；(2) 用 20 万次基因下落模拟估计 7 个个体的亲缘系数与 k_0, k_1, k_2 ；(3) 比较两种方法，并解释含近交个体的对为何 $r \neq \frac{1}{2}k_1 + k_2$ 。 [程序] [ch11/ex11_15_gene_dropping.py](#) [答案]

11.16 ★★ [计算] 含上位的亲属协方差。 $V_A = 30$ 、 $V_D = 10$ 、 $V_{AA} = 6$ 、 $V_{AD} = 2$ 、 $V_{DD} = 1$ 。(1) 计算亲子、全同胞、半同胞、祖孙、叔侄、堂表兄弟、双重堂表兄弟与同卵双生的遗传协方差及其中的上位部分；(2) 用两位点（含加性 $\times$ 加性互作）模拟验证亲子、全同胞与半同胞中 V_{AA} 的系数。 [程序] [ch11/ex11_16_relative_covariance.py](#) [答案]

11.17 ★★ [计算] 实际关系的离散度。用无干涉交换模型模拟全同胞与半同胞的实际加性关系：(1) 类似绵羊的基因组（26 条、各约 1.15 M）；(2) 类似人类的基因组（22 条、各约 1.6 M）；(3) 单条 1 M 染色体。比较均值、标准差与范围，并说明对“利用全同胞内差异估计遗传力”的意义。 [程序] [ch11/ex11_17_realized_relationship.py](#) [答案]

11.18 ★ [计算] 家系均值与后代测定。 $V_p = 100$ 、 $h^2 = 0.25$ 、同窝环境 $c^2 = 0.10$ 、 $V_D/V_p = 0.05$ 。对 $n = 1 \sim 100$ ：(1) 计算半同胞与全同胞均值的方差及有效独立记录数；(2) 计算以 n 个半同胞后代均值估计公畜育种值的可靠度；(3) 解释全同胞有效记录数为何很快饱和。 [程序] [ch11/ex11_18_family_means.py](#) [答案]

11.19 ★★★ [计算] 双生子模型的识别。真实组分 $A = 0.40$ 、 $D = 0.15$ 、 $C = 0.10$ 、 $E = 0.35$ ，MZ 与 DZ 各 400 对。(1) 计算 r_{MZ} 、 r_{DZ} 与 Falconer 遗传力；(2) 模拟 300 组资料，分别用 ACE 与 ADE 模型最大似然拟合，报告各组分比例的平均估计；(3) 说明为何两个模型都高估 A 。 [程序] [ch11/ex11_19_twin_models.py](#) [答案]

11.20 ★★ [计算] 母体效应下的亲属协方差。 $\sigma_o^2 = 0.25$, $\sigma_m^2 = 0.10$, $\sigma_{om} = -0.05$, 母体永久环境 0.06, 残差 0.54。(1) 检查遗传协方差矩阵的合法性;(2) 用一个小系谱计算全同胞、母系半同胞、父系半同胞、母—子、父—子与母系祖母—孙的协方差;(3) 验证母系与父系半同胞协方差之差。[程序] `ch11/ex11_20_maternal_covariance.py` [答案]

11.21 ★ [计算] 求半叔侄(父亲的半同胞兄弟与侄子)的亲缘系数、加性关系与显性关系。[答案]

11.22 ★ [计算] 某性状 $h^2 = 0.36$ 。双亲平均表型高于群体均值 10 个单位, 预测其后代的平均表型离差; 若只知道父亲表型高 10 个单位, 预测值是多少? [答案]

五、推导与证明题

11.23 ★★ [证明] 按共享 IBD 等位基因数分情形, 证明非近交个体间单位点遗传协方差为 $rV_A + uV_D$ (推导 11.1), 并说明该推导在近交个体间为何失效。[答案]

11.24 ★ [证明] 证明 n 个成员的家系均值方差为 $V_P[t + (1 - t)/n]$, 并推导后代测定可靠度 $R = nh^2/[4 + (n - 1)h^2]$ 。[答案]

11.25 ★★ [证明] 在 Willham 模型下推导母—子协方差 $\frac{1}{2}\sigma_o^2 + \frac{5}{4}\sigma_{om} + \frac{1}{2}\sigma_m^2$ (假定外祖母与外祖父无亲缘、母亲的母亲与本系谱中其他个体无关), 说明各项的来源。[答案]

11.26 ★★ [证明] 证明双生子资料中 D 与 C 只以 $\frac{1}{2}D - C$ 的组合出现 (推导 11.3), 并说明增加哪类亲属可以分离二者。[答案]

六、综合分析与研究设计题

11.27 ★★ [综合] 某猪场只有全同胞资料(每窝在同一栏饲养), 研究者用 $2t_{FS}$ 估计遗传力为 0.55。指出该估计可能的偏差来源, 并设计一个能分别估计加性、显性与共同窝环境的交配与饲养方案。[答案]

11.28 ★★★ [综合] 基因组资料可以估计同一系谱关系下个体对的“实际关系”。设计一项利用全同胞内实际关系差异估计遗传力的研究 (Visscher 等 2006 思路), 说明其相对于传统亲属设计的优势(不受共同环境混杂)及所需样本规模。[答案]

- 11.29 ★★★ [综合]** 某论文用人类双生子资料报告某性状遗传力为 0.8, 并推论“家庭环境不重要”。从等环境假设、同型交配、基因—环境相关与模型识别四个方面评价这一推论。 [答案]

11.6 参考答案与解析

一、单项选择题

- 11.1 B。** 全同胞 $r = 1/2$ 、 $u = 1/4$ 。 [题目]
- 11.2 B。** $f = r/2 = 1/4$ 。 [题目]
- 11.3 C。** 只有可能同时共享两个 IBD 等位基因的亲属 ($k_2 > 0$) 才含显性方差。 [题目]
- 11.4 B。** 双重堂表兄弟需父方与母方各共享一个 IBD 等位基因, $k_2 = \frac{1}{4} \times \frac{1}{4} = 1/16$ 。 [题目]
- 11.5 B。** 见习题 11.17: 约 30 M 基因组的 SD 约 0.04, 单条 1 M 染色体约 0.22。 [题目]
- 11.6 D。** 差值 $= \sigma_m^2 + \sigma_{om} + \sigma_{PE}^2$, 三项都可能贡献。 [题目]

二、判断与改错题

- 11.7 错误。** 基因型相同只是同状态 (IBS); IBD 要求等位基因来自基础群中同一个祖先拷贝。常见等位基因在无亲缘个体间也频繁 IBS。 [题目]
- 11.8 错误。** 加性关系相同只保证 V_A 的系数相同。三者 $u = 0$, V_{AA} 的系数 r^2 也相同, 但若考虑连锁, 共享片段的数目与长度分布不同, 连锁位点的上位组分系数会不同; 有母体效应时, 母系与父系的亲属协方差也不同 (如母系祖母—孙与父系祖父—孙)。 [题目]
- 11.9 错误。** 该式只对两个非近交个体成立; 近交个体需用 Jacquard 九种 IBD 状态描述 (习题 11.15 中个体 9、10 近交, 模拟值 $\frac{1}{2}k_1 + k_2 = 0.567$ 而 $r = 0.688$)。 [题目]
- 11.10 正确。** 见推导 11.2 与第 10 章推导 10.1。 [题目]

三、填空题

- 11.11** (9/16, 6/16, 1/16); $r = 6/32 + 1/16 = 1/4$; $u = 1/16$ 。 [题目]

11.12 $15 + 2.5 + 5 = 22.5$; 7.5。 [题目]

11.13 $h^2 = 2 \times 0.27 = 0.54$; $c^2 = 0.90 - 0.72 = 0.18$; $e^2 = 0.28$ 。 [题目]

11.14 $t = 0.1$, 方差 $50 \times (0.1 + 0.9/10) = 9.5$; $n_{\text{eff}} = 10/1.9 = 5.26$ 。 [题目]

四、计算题

11.15 (1) 表格法: 个体 8 (父 5、母 6, 二者为父系半同胞) $F = 0.125$; 个体 9、10 (父 7、母 8) $F = 0.156$ 。

(2)

个体对	A_{xy}	f (模拟)	k_0	k_1	k_2
4—5 (全同胞)	0.500	0.250	0.25	0.50	0.25
5—6 (父系半同胞)	0.250	0.125	0.50	0.50	0
7—8	0.313	0.156	0.47	0.47	0.06
9—10 (近交全同胞)	0.688	0.343	0.16	0.55	0.29
4—7 (亲子)	0.500	0.250	0	1	0
3—9	0.375	0.188	0.37	0.56	0.06

(3) 两种方法的亲缘系数在模拟误差内一致。对含近交个体的对, 个体自身两个等位基因可能 IBD, “共享几个”与“共享哪几个”不再一一对应, $\frac{1}{2}k_1 + k_2$ 低估了 r (9—10: 0.567 对 0.688), 显性关系也不能简单取 k_2 。 [题目]

11.16 (1)

亲属	r	u	协方差	其中上位
亲子	1/2	0	16.500	1.500
全同胞	1/2	1/4	19.313	1.813
半同胞、祖孙、叔侄	1/4	0	7.875	0.375
堂表兄弟	1/8	0	3.844	0.094
双重堂表兄弟	1/4	1/16	8.535	0.410
同卵双生	1	1	49.000	9.000

上位方差在远缘亲属中迅速“衰减”(系数 r^2 、 u^2), 因此远缘亲属的相似性几乎只反映 V_A ; 近亲(尤其同卵双生)则包含大量非加性方差。

(2) 两位点模拟: $V_A = 0.769$, $V_{AA} = 0.103$; 亲子与全同胞模拟协方差 0.410 与 0.412 (理论 $\frac{1}{2}V_A + \frac{1}{4}V_{AA} = 0.410$), 半同胞 0.199 (理论 $\frac{1}{4}V_A + \frac{1}{16}V_{AA} = 0.199$), 验证了 r^2 系数。 [题目]

11.17

基因组	全同胞 $\hat{r}$ SD	范围	半同胞 SD
26 条 $\times$ 1.15 M	0.041	[0.36, 0.64]	0.029
22 条 $\times$ 1.6 M	0.038	[0.37, 0.63]	0.028
1 条 $\times$ 1 M	0.222	[0, 1]	0.156

均值都等于期望值, 但实际关系有相当的离散: 约 30 M 基因组的全同胞, 最极端的一对只共享 36%, 另一对共享 64%。这种“全同胞内”的关系差异与共同环境无关 (全同胞共享同样的家庭环境), 因此可以用来估计遗传力而不受共同环境混杂 (习题 11.28)。单条短染色体上实际共享接近 0 或 1, 说明在局部基因组区域, 系谱期望几乎没有预测价值——这正是用标记追踪局部 IBD (连锁分析、单步评定中的局部关系) 的意义。 [题目]

11.18

n	半同胞均值方差	$n_{\text{eff}}(\text{HS})$	公畜可靠度	全同胞均值方差	$n_{\text{eff}}(\text{FS})$
1	100.0	1.0	0.063	100.0	1.0
10	15.6	6.4	0.400	31.4	3.2
20	10.9	9.1	0.571	27.6	3.6
50	8.1	12.3	0.769	25.3	4.0
100	7.2	13.9	0.870	24.5	4.1

$t_{\text{HS}} = 0.0625$, $t_{\text{FS}} = 0.2375$ 。全同胞共享一半加性方差、部分显性与 10% 的同窝环境, 成员间高度相关, $n_{\text{eff}} \rightarrow 1/t = 4.2$: 再多的同窝全同胞也只相当于约 4 条独立记录。这就是“同胞很多, 独立遗传信息未必很多”的定量表述 (第 15 章)。 [题目]

11.19 (1) $r_{\text{MZ}} = 0.650$, $r_{\text{DZ}} = 0.338$, Falconer $h^2 = 0.625$ (真实加性比例 0.40、广义 0.55)。

(2) ACE: A 0.601、C 0.046、E 0.352; ADE: A 0.592、D 0.061、E 0.348。

(3) C 与 D 在 $c_{\text{MZ}} - 2c_{\text{DZ}}$ 中符号相反, 二者部分抵消; 拟合只含其一的模型时, 模型把残余的 MZ—DZ 差异主要归于 A, 于是 A 被高估约 50%, C 与 D 都被低估。

两个模型的 E 估计都正确 ($1 - r_{MZ}$)。这说明双生子研究报告的“遗传力”依赖未经检验的模型选择。

【题目】

11.20 (1) G 特征值 0.085 与 0.265, 合法; 直接—母体相关 -0.316 。

(2) $V_P = 0.90$ 。

亲属	协方差	相关
全同胞	0.2350	0.261
母系半同胞	0.1725	0.192
父系半同胞	0.0625	0.069
母—子	0.1125	0.125
父—子	0.1250	0.139
母系祖母—孙	0.0375	0.042

(3) 母系与父系半同胞之差 $0.110 = \sigma_m^2 + \sigma_{om} + \sigma_{PE}^2 = 0.10 - 0.05 + 0.06$ 。负的直接—母体协方差使母—子协方差低于父—子: 母亲直接育种值高时往往母体能力较差, 削弱了母子相似性。仅用父系半同胞估计 $h^2 = 4 \times 0.0694 = 0.28$, 接近 $\sigma_o^2/V_P = 0.278$; 用母系半同胞会得到 0.77 的严重高估。

【题目】

11.21 半叔侄: 侄子的父亲与叔叔为半同胞 ($f = 1/8$), 侄子从父亲获得其一半等位基因, 故 $f = \frac{1}{2} \times \frac{1}{8} = 1/16$, $r = 1/8$, $u = 0$ 。

【题目】

11.22 后代对双亲均值的回归为 h^2 : 预测 $0.36 \times 10 = 3.6$; 对单亲回归为 $h^2/2$: 1.8。【题目】

五、推导与证明题

11.23 见推导 11.1。近交个体的两个等位基因本身可能 IBD, 此时“与另一个体共享 1 个”可能意味着共享了两个 IBD 的拷贝之一, 协方差不再只由 V_A 与 V_D 决定, 还出现近交群体特有的组分 (如 D_1 : 纯合子显性偏差与育种值的协方差, D_2^* 等), 必须用 Jacquard 的 9 种凝聚状态及相应系数描述。

【题目】

11.24 家系均值方差: $\text{Var}(\bar{y}) = \frac{1}{n^2}[nV_P + n(n-1)tV_P] = V_P[t + (1-t)/n]$ 。可靠度见推导 11.2。

【题目】

11.25 母亲 m ($y_m = A_{o,m} + A_{m,g_m} + \dots$, g_m 为外祖母) 与后代 i ($y_i = A_{o,i} + A_{m,m} + \dots$)。逐项: (1) $\text{Cov}(A_{o,m}, A_{o,i}) = \frac{1}{2}\sigma_o^2$; (2) $\text{Cov}(A_{o,m}, A_{m,m}) = \sigma_{om}$ (同一个体的直接与母体效应); (3) $\text{Cov}(A_{m,g_m}, A_{o,i}) = \frac{1}{4}\sigma_{om}$ (外祖母与外孙加性关系 1/4); (4) $\text{Cov}(A_{m,g_m}, A_{m,m}) = \frac{1}{2}\sigma_m^2$ (外祖母与母亲的母体效应, 关系 1/2)。合计 $\frac{1}{2}\sigma_o^2 +$

$\frac{5}{4}\sigma_{om} + \frac{1}{2}\sigma_m^2$ 。代入习题 11.20 的数值: $0.125 - 0.0625 + 0.05 = 0.1125$, 与程序一致。母亲的母体永久环境只影响母亲自己的后代 (不同代之间不共享), 不进入母—子协方差。 [题目]

- 11.26** 见推导 11.3。分离方法: 加入半同胞或父母—子女 (D 系数为 0, C 系数依共同家庭而定); 加入分开抚养的双生子 ($C = 0$); 加入扩展家系或基因组关系 (利用不同 r 、 u 组合)。 [题目]

六、综合分析与研究设计题

- 11.27** $2t_{FS} = h^2 + \frac{1}{2}V_D/V_P + 2c^2$ 。偏差来源: 显性方差与同窝 (同栏) 共同环境, 母体效应也会混入。设计: (1) 每头公猪配多头母猪 (形成父系半同胞), 每头母猪产多窝 (同母不同窝的全同胞); (2) 把每窝仔猪在出生或断奶时随机分到不同栏舍, 或进行交叉寄养, 打破“窝 = 栏 = 母亲”的完全重合; (3) 用动物模型估计加性方差 (由父系半同胞与跨代关系识别)、母体永久环境 (同母跨窝)、共同窝环境 (同窝) 与显性 (需额外的全同胞与半同胞对比, 通常还需较大规模)。 [题目]

- 11.28** 思路: 在大量全同胞对中, 用全基因组标记估计每对的实际关系 $\hat{r}_j$, 以 $(y_{j1} - y_{j2})^2$ 或同胞对的相似性对 $\hat{r}_j$ 回归 (Haseman-Elston 型), 斜率反映 V_A 。优势: 所有对的期望关系与共同环境相同, $\hat{r}$ 的变异与家庭环境无关, 因此估计不受共同环境与母体效应混杂, 也不依赖“等环境假设”。所需规模: $\hat{r}$ 的 SD 只有约 0.04, 信号很弱, 需数千对全同胞 (Visscher 等用约 4400 对估计身高遗传力, SE 约 0.1); 资料可来自大型人群队列或家畜大家系 (如猪、家禽的大全同胞家系)。还需控制性别、年龄与分型质量, 并注意显性方差也会随 $\hat{k}_2$ 变化。 [题目]

- 11.29** (1) **等环境假设**: MZ 双生子比 DZ 受到更相似的对待 (同样的着装、教育、社交), r_{MZ} 中的部分环境相似被计入遗传; (2) **同型交配**: 父母表型相似使 DZ 共享超过 1/2 的加性方差, r_{DZ} 升高, 反而使 h^2 被低估、 c^2 被高估——方向与 (1) 相反; (3) **基因—环境相关**: 遗传倾向影响个体对环境的选择与创造, “遗传”效应部分通过环境实现; (4) **模型识别**: ACE 与 ADE 不可兼得, 若存在显性, A 被高估。此外, 遗传力是群体内方差比例, “家庭环境不重要”只说明在被研究群体的环境变异范围内, 家庭间差异对个体差异的贡献小, 不能推广到更大的环境差异 (如营养不良) 或用于判断干预的效果 (第 25 章)。 [题目]

系谱亲缘、近交与遗传连接

12.1 本章导学

学习目标

- 1. 理解同祖同源概率总是相对于基础群体定义的，能用表格法递推加性关系矩阵并计算近交系数。
- 2. 掌握 $A = TDT^T$ 分解与孟德尔抽样系数，能用 Henderson 规则直接构造 A^{-1} （含近交）。
- 3. 能用通径法核对近交系数，理解多条路径与近交祖先的贡献。
- 4. 能审计系谱资料中的常见错误，理解系谱缺失对近交系数的低估及完整度指标。
- 5. 理解遗传连接的意义，能用混合模型方程逆矩阵计算场间比较的 PEV 与差异决定系数。
- 6. 能由系谱估计近交速率与有效群体大小，比较不同估计方法。

重点与难点

重点：表格法； $b_i = \frac{1}{2} - \frac{1}{4}(F_s + F_d)$ ；Henderson 规则；通径法；连接度与 PEV。

难点：后代的近交取决于双亲之间的关系，而孟德尔抽样方差取决于双亲各自的近交；通径法路径不可重复经过同一个体；系谱缺失使近交被系统性低估；没有共同公畜时场差的“估计”完全依赖随机效应先验。

本章把第 11 章的亲缘概念变成可计算的矩阵工具，是第 21—22 章 BLUP 与动物模型、第 18—19 章近交管理、第 28 章单步评定的基础。

12.2 知识结构图




图 12.1 第 12 章知识结构图

右侧三支是“关系矩阵的计算”，左侧四支是“资料质量、连接、群体规模与基因组时代的系谱”。

12.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
表格法	$A_{ij} = \frac{1}{2}(A_{f,s_i} + A_{f,d_i}),$ $A_{ii} = 1 + \frac{1}{2}A_{s_i d_i}$	父母排在后代之前
近交系数	$F_i = \frac{1}{2}A_{s_i d_i}$	双亲关系的一半
分解	$A = TDT^T$	T 下三角, D 为孟德尔抽样方差
孟德尔抽样系数	$b_i = \frac{1}{2} - \frac{1}{4}(F_s + F_d)$; 单亲 $\frac{3}{4} - \frac{1}{4}F_p$; 创始者 1	依赖双亲各自的近交
Henderson 规则	$\delta_i = 1/b_i$ 加到 (i, i) ; $-\delta_i/2$ 加到 $(i, s), (i, d)$; $\delta_i/4$ 加到 $(s, s), (d, d), (s, d)$	对称位置同样处理
通径法	$F_X = \sum (1/2)^{n_1+n_2+1}(1 + F_A)$	路径不重复经过个体
等价完整世代	$ECG_i = \sum_{\text{已知祖先}} (1/2)^g$	衡量系谱深度
个体近交增量	$\Delta F_i = 1 - (1 - F_i)^{1/(t_i-1)}$	Gutiérrez 等

概念	公式或定义	成立条件与提示
性别比 N_e	$N_e = 4N_m N_f / (N_m + N_f),$ $\Delta F = 1 / (2N_e)$	理想条件
差异 PEV	$PEV(\hat{u}_i - \hat{u}_j) = C^{ii} + C^{jj} - 2C^{ij}$	尺度乘 σ_e^2
差异决定系数	$CD_{ij} =$ $1 - PEV(\hat{u}_i - \hat{u}_j) / \text{Var}(u_i - u_j)$	连接度指标

12.4 补充内容与公式推导

推导 12.1 $A = TDT^T$ 与 A^{-1} 的稀疏性

每个个体的育种值可写为 $u_i = \frac{1}{2}u_{s_i} + \frac{1}{2}u_{d_i} + m_i$, 孟德尔抽样 m_i 与所有祖先独立, 方差 $b_i\sigma_A^2$ 。写成矩阵 $u = Pu + m$, P 每行在父母列上为 $\frac{1}{2}$ 。则 $(I - P)u = m$, $u = Tm$, $T = (I - P)^{-1}$, 故

$$A = TDT^T, \quad A^{-1} = (I - P)^T D^{-1} (I - P).$$

$I - P$ 每行至多 3 个非零元, 于是 A^{-1} 是若干个秩一外积 $w_i w_i^T / b_i$ 之和, w_i 只在 i, s_i, d_i 上非零——这就是 Henderson 规则。 b_i 的推导: $\text{Var}(u_i) = (1 + F_i)$, 而 $\text{Var}(\frac{1}{2}u_s + \frac{1}{2}u_d) = \frac{1}{4}(1 + F_s) + \frac{1}{4}(1 + F_d) + \frac{1}{2}A_{sd}$, 相减并用 $F_i = \frac{1}{2}A_{sd}$ 得 $b_i = \frac{1}{2} - \frac{1}{4}(F_s + F_d)$ 。可见孟德尔抽样方差只与双亲各自是否近交 (其配子是否多样) 有关。

推导 12.2 为什么系谱缺失会低估近交

未知亲本被当作基础群体中的独立个体, 相当于在该处“截断”所有经过它的同祖路径。若每条亲本链接独立地以概率 m 缺失, 一条长度为 L 的同祖路径 (两侧共 $n_1 + n_2$ 条链接) 完整保留的概率为 $(1 - m)^{n_1 + n_2}$ 。近交系数是众多路径贡献之和, 长路径 (远祖) 被截断的比例更高。8 代闭锁群体中, 即使只有 10% 的链接缺失, 末代平均近交也只剩真实值的一半左右 (习题 12.17)。因此比较不同品种或不同时期的近交水平时, 必须同时报告系谱完整度 (ECG 或 PEC), 或使用基于基因组的近交指标 (ROH, 第 19、26 章)。

推导 12.3 连接度与场间比较的精度

公畜模型 $y = Xh + Zs + e$, 混合模型方程系数矩阵 C , 其逆分块 C^{hh}, C^{ss}, C^{hs} 。两场效应之差的预测误差方差为 $(C_{hh}^{11} + C_{hh}^{22} - 2C_{hh}^{12})\sigma_e^2$ 。若两场没有共同公畜 ($k = 0$), 资料

中场差与公畜差完全混杂，场差的“估计”只来自“公畜效应期望为零、方差为 σ_s^2 ”的先验：两场公畜的平均真实差异被当作零，PEV 由先验方差 $2\sigma_s^2/S$ 主导。每增加一头连接公畜，场差就多一条由资料直接提供的对比路径。跨场公畜比较的 PEV 同时包含公畜自身的不确定性与场差的不确定性，因此连接度低时，跨场排名的可靠性明显低于同场排名。

易错辨析

- 后代近交与孟德尔抽样系数用的是不同信息：前者看双亲之间的关系，后者看双亲各自的近交。
- A^{-1} 的元素不是关系的倒数：它反映条件独立结构（偏相关），非零元只出现在亲子与配偶之间。
- 未知亲本 $\neq$ 无亲缘：把缺失亲本当作基础群会低估近交与亲缘，也改变遗传基准（未知亲本组，第 22 章）。
- 软件给出了跨场排名不等于资料支持跨场比较：应检查 PEV 或 CD。
- 性别比 N_e 是上限而非保证：家系贡献不均、选择与重叠世代都会降低 N_e 。

12.5 习题

一、单项选择题

- 12.1 ★ [单选] 双亲均已知，父亲 $F_s = 0.25$ 、母亲 $F_d = 0$ ，后代的孟德尔抽样系数 b_i 为
(A) 0.5 (B) 0.4375 (C) 0.375 (D) 0.75

[答案]

- 12.2 ★ [单选] 某动物近交系数为 0.25，其在 A 中的对角元为
(A) 1.0 (B) 1.25 (C) 0.75 (D) 0.25

[答案]

- 12.3 ★★ [单选] 用 Henderson 规则构造 A^{-1} 时，一个双亲已知的个体最多向多少个元素位置（含对称位置）加入非零贡献？
(A) 3 (B) 6 (C) 9
(D) 取决于系谱深度

[答案]

12.4 ★ [单选] 半同胞交配产生的后代（共同祖先非近交）的近交系数为

- (A) 1/4 (B) 1/8 (C) 1/16 (D) 1/2

[答案]

12.5 ★★ [单选] 两个场没有任何共同公畜，所有动物也无跨场亲缘。若把场作为固定效应、公畜作为随机效应，场间公畜排名的依据主要是

- (A) 资料中的场间遗传对比
(B) 公畜随机效应的先验假设（各场公畜平均水平相同）
(C) 场效应的估计值 (D) 无法计算

[答案]

12.6 ★★ [单选] 系谱中随机有 20% 的亲本记录缺失，对群体平均近交系数的影响是

- (A) 无影响 (B) 系统性高估 (C) 系统性低估
(D) 随机波动但无偏

[答案]

二、判断与改错题

12.7 ★ [判断] 若父母都近交，则后代一定近交。

[答案]

12.8 ★★ [判断] A^{-1} 中两个个体对应的元素为零，说明二者没有亲缘关系。

[答案]

12.9 ★★ [判断] 在通径法中，一条路径可以多次经过同一个祖先，只要两端是同一个共同祖先。

[答案]

12.10 ★★ [判断] 同一场内两头公畜比较的 PEV，一般小于不同场且连接很弱的两头公畜比较的 PEV。

[答案]

三、填空题

12.11 ★ [填空] 接选择题 12.1，该个体对 A^{-1} 对角元的贡献 $\delta =$ _____，对“个体—父亲”位置的贡献为 _____，对“父亲—母亲”位置的贡献为 _____。

[答案]

12.12 ★ [填空] （共同祖先均非近交）全同胞交配后代的 $F =$ _____；亲子交配后代的 $F =$ _____；双重堂表兄妹交配后代的 $F =$ _____。

[答案]

12.13 ★ [填空] 单亲已知、已知亲本 $F_p = 0.5$ ，孟德尔抽样系数 $b =$ _____。

[答案]

- 12.14 ★ [填空]** 闭锁群体每代 5 公 25 母, 性别比公式 $N_e = \underline{\hspace{2cm}}$, $\Delta F = \underline{\hspace{2cm}}$, 10 代后期望近交约为 $\underline{\hspace{2cm}}$ 。 [答案]

四、计算题

- 12.15 ★★ [计算]** A 与 A^{-1} 。12 头动物的系谱见配套数据 (含多次近交)。(1) 用表格法求 A 与各个体近交系数; (2) 求孟德尔抽样系数并验证 $A = TDT^T$; (3) 用 Henderson 规则构造 A^{-1} , 验证 $AA^{-1} = I$, 比较两矩阵的非零元数目。 [程序]

ch12/ex12_15_ainverse.py

[答案]

- 12.16 ★★ [计算]** 通径法。对习题 12.15 系谱中的个体 12 (父 10、母 11), 枚举经全部共同祖先的路径, 列出每条路径的代数、共同祖先近交系数与贡献, 并与表格法结果核对。 [程序] ch12/ex12_16_path_method.py

[答案]

- 12.17 ★★ [计算]** 系谱完整度。模拟每代 8 公 40 母、随机交配 8 代的闭锁群体。(1) 计算完整系谱下末代的平均近交; (2) 以 10%、30%、50% 随机删除亲本记录, 重新计算平均近交、等价完整世代数与完整度指数; (3) 说明这对品种间近交比较的启示。 [程序] ch12/ex12_17_pedigree_completeness.py

[答案]

- 12.18 ★★ [计算]** 遗传连接。两场各用 6 头公畜、每头每场 20 个后代, $h^2 = 0.25$ 。连接公畜数 $k = 0, 1, 2, 3, 6$ 。用公畜模型的混合模型方程逆矩阵计算: (1) 场效应差的 PEV; (2) 跨场与同场公畜比较的 PEV; (3) 跨场比较的差异决定系数 CD。 [程序] ch12/ex12_18_connectedness.py

[答案]

- 12.19 ★★ [计算]** 近交速率与有效群体大小。每代 5 公 25 母、随机选留、离散世代, 模拟 12 代、重复 20 次。比较性别比公式、世代平均近交变化法与个体近交增量法估计的 N_e 。 [程序] ch12/ex12_19_inbreeding_rate.py

[答案]

- 12.20 ★★ [计算]** 系谱审计。原始系谱表 (14 行) 见配套数据。编写检查规则, 找出重复 ID、自身为亲本、性别冲突、亲本出生年不合理、亲本不在系谱中与循环等问题, 输出清理后的拓扑排序系谱, 并说明每类错误对 A 的影响。 [程序] ch12/ex12_20_pedigree_audit.py

[答案]

- 12.21 ★ [计算]** 某个体父母为半同胞, 共同祖先 (祖父) 的近交系数为 0.2。用通径法计算该个体的近交系数。 [答案]

- 12.22 ★ [计算] 某后代双亲已知, 父母之间的加性关系为 0.5, 父亲 $F = 0.25$ 、母亲 $F = 0.125$ 。求后代的近交系数、 A 对角元与孟德尔抽样系数。 [答案]

五、推导与证明题

- 12.23 ★★ [证明] 由 $u_i = \frac{1}{2}u_s + \frac{1}{2}u_d + m_i$ 推导 $A = TDT^T$ 与 $b_i = \frac{1}{2} - \frac{1}{4}(F_s + F_d)$, 并由此证明 Henderson 规则 (推导 12.1)。 [答案]

- 12.24 ★★ [证明] 证明通径法公式 $F_X = \sum (1/2)^{n_1+n_2+1}(1 + F_A)$ 与表格法 $F_X = \frac{1}{2}A_{sd}$ 等价 (可对系谱深度归纳)。 [答案]

- 12.25 ★★ [证明] 证明对任意两个体, $PEV(\hat{u}_i - \hat{u}_j) = (C^{ii} + C^{jj} - 2C^{ij})\sigma_e^2$ (C 为以 σ_e^2 标准化的混合模型方程系数矩阵), 并说明为什么只报告个体可靠度不足以评价跨场比较。 [答案]

- 12.26 ★★★ [证明] 设每条亲本链接独立地以概率 m 缺失, 证明一条两侧共 L 条链接的同祖路径对 F 的贡献期望被乘以 $(1 - m)^L$, 并由此说明缺失对远祖贡献的影响更大。 [答案]

六、综合分析与研究设计题

- 12.27 ★★ [综合] 某地方品种保种场的系谱只有近 5 代较完整, 更早世代缺失严重。现需要 (1) 比较该场与另一场的近交水平; (2) 为下一年制定配种计划。分别说明应使用哪些指标与资料, 以及如何处理系谱缺失。 [答案]

- 12.28 ★★★ [综合] 某联合育种计划有 4 个场, 计划每年投放少量“连接公羊”。设计一个确定连接公羊数量与分配方式的方案, 说明评价连接度的指标、目标阈值与成本权衡。 [答案]

- 12.29 ★★★ [综合]** 某育种公司准备用基因组资料核查系谱，发现约3%的父亲记录与基因组不符。说明错误父亲对A、育种值估计与遗传参数估计的影响，并给出系谱纠错与再评定的流程。 [答案]

12.6 参考答案与解析

一、单项选择题

- 12.1 B。** $b = \frac{1}{2} - \frac{1}{4}(0.25 + 0) = 0.4375$ 。 [题目]
- 12.2 B。** $A_{ii} = 1 + F_i$ 。 [题目]
- 12.3 C。** 涉及个体、父亲、母亲三行三列共9个位置。 [题目]
- 12.4 B。** $(1/2)^{1+1+1} = 1/8$ 。 [题目]
- 12.5 B。** 见推导12.3。 [题目]
- 12.6 C。** 见推导12.2。 [题目]

二、判断与改错题

- 12.7 错误。** 后代近交取决于父母之间的关系：两头近交但彼此无亲缘的个体交配，后代 $F = 0$ 。父母自身的近交只影响孟德尔抽样方差与父母间关系的计算。 [题目]
- 12.8 错误。** A^{-1} 的元素反映给定其他个体后的条件依赖：祖孙之间 A^{-1} 元素为零（给定中间亲本后条件独立），但 $A_{ij} = 0.25 \neq 0$ 。 [题目]
- 12.9 错误。** 路径除共同祖先外不能重复经过同一个体；否则会重复计数（同一IBD事件被算两次）。 [题目]
- 12.10 正确。** 同场公畜在相同环境中比较，场效应的不确定性抵消；跨场比较还包含场差的估计误差（习题12.18： $k = 1$ 时同场0.057、跨场0.068）。 [题目]

三、填空题

- 12.11** $\delta = 1/0.4375 = 2.2857$ ；个体—父亲 -1.1429；父亲—母亲 +0.5714。 [题目]
- 12.12** 全同胞 $2 \times (1/2)^3 = 1/4$ ；亲子 $1/4$ ；双重堂表兄妹 $1/8$ 。 [题目]
- 12.13** $0.75 - 0.125 = 0.625$ 。 [题目]

12.14 $N_e = 4 \times 5 \times 25/30 = 16.67$; $\Delta F = 0.030$; $F_{10} = 1 - 0.97^{10} = 0.263$ 。 [题目]

四、计算题

12.15 (1) 近交个体: 6 (0.125)、8 (0.156)、9 (0.313)、10 (0.273)、11 (0.250)、12 (0.342)。

(2) b : 创始者 1; 4、5、6 为 0.5 (6 的双亲非近交); 7 (单亲已知) 0.75; 8 与 9 为 0.469 (含近交亲本 6); 10 为 0.383, 11 为 0.422, 12 为 0.369。 TDT^T 与表格法完全一致。

(3) A 有 132 个非零元 (144 个中, 只有无亲缘对为零), A^{-1} 只有 60 个, 且 $AA^{-1} = I$ 。系谱越大, A 越稠密而 A^{-1} 的非零元只按个体数线性增长, 这是大规模 BLUP 只用 A^{-1} 的原因。 [题目]

12.16 共 13 条路径, 贡献最大的是经共同祖先 9 的路径 (10→9 | 11→9, 3 个世代步, 9 的 $F = 0.3125$, 贡献 0.164), 其次经祖先 6 (0.035) 与祖先 1 的多条路径。总和 0.341797, 与表格法完全一致。通径法便于理解近交来自哪些祖先, 但路径数随系谱复杂度指数增长, 大系谱只能用递推算法。 [题目]

12.17

缺失率	末代平均 F	相对真值	平均 ECG	平均 PEC
0	0.119	1.00	8.00	1.00
10%	0.055	0.47	5.63	0.66
30%	0.003	0.03	2.24	0.23
50%	0.000	0	0.94	0.06

(理论 $N_e = 26.7$, $\Delta F = 0.019$ 。) 10% 的缺失就使平均近交低估过半。启示: 两个品种或两个时期的近交比较只有在完整度相近时才有意义; 应同时报告 ECG/PEC, 或改用不依赖系谱深度的指标, 如 “个体近交增量” (对系谱深度进行标准化) 或基因组 ROH。 [题目]

12.18

连接公畜	PEV(场差)	跨场公畜比较 PEV	CD	同场公畜比较 PEV
0	0.0389	0.0698	0.476	0.0571
1	0.0318	0.0675	0.494	0.0571
2	0.0269	0.0659	0.506	0.0571

连接公畜	PEV(场差)	跨场公畜比较 PEV	CD	同场公畜比较 PEV
3	0.0233	0.0648	0.514	0.0571
6	0.0167	0.0364	0.727	0.0364

(以 $\sigma_e^2 = 1$ 为单位, $\lambda = 15$ 。) 第一头连接公畜使场差 PEV 下降 18%, 此后收益递减。 $k = 6$ 时所有公畜在两场都有后代, 跨场与同场比较等价, 每头公畜的信息也加倍。 $k = 0$ 时场差 PEV 并不无穷大, 这是随机公畜先验的结果, 不代表资料提供了场间信息。 [题目]

12.19 性别比公式 $N_e = 16.7$ ($\Delta F = 0.030$); 世代平均近交变化法 $\Delta F = 0.029$ 、 $N_e = 17.2$; 个体近交增量法 $\Delta F = 0.029$ 、 $N_e = 17.3$ 。随机选留下家系大小近似泊松, 三者一致。若按估计育种值截断选择, 同一家系成员一同入选, 家系贡献方差增大, 实际 N_e 会明显低于性别比公式 (第 19 章)。 [题目]

12.20 发现的问题: A05 完全重复 (删除一行); A07 的“父亲”A06 为雌性 (父亲置为未知); A08 的母亲 A09 出生晚于 A08; A10 自身为母亲; A11 的父亲 A12 不在系谱中 (补为创始者); A14 的父母都比它年轻。影响: 重复与冲突 ID 会使同一动物占两行或错误合并; 性别与年龄冲突常意味着 ID 录入错误, 若不处理会产生虚假的亲缘或循环, 使 A 不正定或表格法无法排序; 把错误亲本置为未知会损失信息, 但比使用错误关系更安全。清理后的系谱按父母在前排序, 可直接用于习题 12.15 的算法。 [题目]

12.21 单条路径, $n_1 = n_2 = 1$: $F = (1/2)^3 \times 1.2 = 0.15$ 。 [题目]

12.22 $F = \frac{1}{2} \times 0.5 = 0.25$; $A_{ii} = 1.25$; $b = \frac{1}{2} - \frac{1}{4}(0.25 + 0.125) = 0.406$ 。 [题目]

五、推导与证明题

12.23 见推导 12.1。Henderson 规则: $A^{-1} = \sum_i w_i w_i^T / b_i$, $w_i = e_i - \frac{1}{2}e_{s_i} - \frac{1}{2}e_{d_i}$ ($I - P$ 的第 i 行)。展开外积即得: (i, i) 加 $1/b_i$, (i, s) 加 $-\frac{1}{2}/b_i$, (s, s) 加 $\frac{1}{4}/b_i$, (s, d) 加 $\frac{1}{4}/b_i$ 。 [题目]

12.24 设 X 的父母为 S, D 。 $F_X = \frac{1}{2}A_{SD} = f_{SD}$, 即从 S, D 各取一个等位基因 IBD 的概率。对 S 的系谱深度归纳: $f_{SD} = \frac{1}{2}(f_{S_1D} + f_{S_2D})$ (S 的父母 S_1, S_2 , D 不是 S 的后代), 每一步向上一代, 路径长度加 1、贡献乘 $1/2$; 当到达共同祖先 A 时, $f_{AA} = \frac{1}{2}(1 + F_A)$ 。将所有向上展开的项累加, 得到 $\sum (1/2)^{n_1+n_2} \cdot \frac{1}{2}(1 + F_A)$, 即通径法公式; “不重复经过个体” 对应展开中每个个体只在其自身的递推中出现一次。 [题目]

12.25 $\hat{u}_i - \hat{u}_j = k^\top \hat{u}$, $k = e_i - e_j$ 。混合模型理论给出 $\text{Var}(u - \hat{u}) = C^{uu} \sigma_e^2$ (第 21 章), 故 $\text{PEV}(k^\top \hat{u}) = k^\top C^{uu} k \sigma_e^2$ 。个体可靠度只用到对角元 C^{ii} , 不含误差协方差 C^{ij} ; 同场比较时 C^{ij} 为正 (共享场效应误差), 差值 PEV 小; 跨场时 C^{ij} 可能很小甚至为负, 个体可靠度相同的两头公畜, 跨场差异的可靠度可以低得多。 [题目]

12.26 同祖路径共 L 条“亲—子”链接, 每条以概率 $1 - m$ 保留且独立, 路径完整的概率 $(1 - m)^L$; 一旦任一链接缺失, 经该处的祖先被视为基础群个体, 此路径的贡献变为零。因此期望贡献乘以 $(1 - m)^L$ 。远祖路径 L 大, 衰减更快: $m = 0.1$ 时, $L = 4$ 的路径保留 66%, $L = 12$ 的路径只保留 28%。这也解释了为什么缺失主要使“历史积累的近交”消失, 而对近代近亲交配的认识影响较小。 [题目]

六、综合分析与研究设计题

12.27 (1) **场间比较**: 应使用对系谱深度标准化的指标——限定在两场都有的共同基础世代 (如 5 代前) 重新定义基础群, 计算该基础下的 F ; 或计算个体近交增量 ΔF_i 并比较平均 N_e ; 最好用基因组 ROH 比例 (F_{ROH}), 它不依赖系谱。同时报告 ECG。(2) **配种计划**: 配种只需比较候选配对的相对亲缘, 近 5 代完整的系谱已足以避免近亲交配; 可结合基因组关系矩阵 (若有分型) 以捕获更远的共祖; 目标是最小化后代平均共祖并控制每头公羊的使用比例 (最优贡献, 第 18、36 章)。缺失的远祖信息可用“未知亲本组”或元基础群方法部分补偿。 [题目]

12.28 方案: (1) **指标**: 各场平均 EBV 差的 PEV 或 CD、跨场公羊比较的平均 CD、Kennedy-Trus 的“场差 PEV 相对于完全连接时的比值”; (2) **目标**: 如跨场比较的 CD 不低于同场比较的 80%, 或场差 PEV 低于某阈值 (对应场差 SE 小于育种目标单位的若干分之一); (3) **分配**: 用习题 12.18 类似的计算在候选方案上直接比较——连接公羊数、每头在各场的后代数、是否轮换场; 优先使用遗传水平高、可在各场普遍使用的公羊, 每年轮换以形成跨年连接; (4) **成本**: 运输、人工授精、冻精成本与连接带来的选择精度提高 (避免错误跨场选种) 的价值比较; (5) 基因组资料也能提供跨场连接, 可减少实体连接公羊的依赖, 但仍需验证。 [题目]

12.29 影响: 错误父亲使真实的半同胞被当作无亲缘, 虚构出不存在的亲缘; (1) A 中关系错误; (2) 公畜的后代信息被稀释或混入, 育种值估计向均值偏移, 真正的父亲损失信息、错误父亲获得错误信息; (3) 遗传力与遗传相关被低估 (错误亲缘使亲属相似性被“稀释”), 约 3% 的错误可使 h^2 低估约 3%—5%。流程: (1) 用基因组资料做亲子验证 (相对纯合计数、似然比), 确认错误并寻找真父亲 (在候选公畜中做亲子推断); (2) 无法确认时把父亲置为未知或使用单步评定直接以基因组关

系替代；(3) 修正系谱后重新计算 A^{-1} 、重新估计方差组分并再评定；(4) 分析错误来源（输精记录、同期配种、标签错误），改进记录流程；(5) 比较修正前后的排名变化，向用户发布更正说明。

[题目]

遗传参数的经典估计方法与试验设计

13.1 本章导学

学习目标

- 1. 说清“观察协方差—遗传方差”的对应关系，能根据亲属类型写出可估的遗传参数及其混杂项。
- 2. 掌握嵌套（公畜—母畜）方差分析：期望均方、非平衡系数 k_1, k_2, k_3 、三种遗传力估计及其抽样误差。
- 3. 理解亲子回归的优点与陷阱：亲本被选择与后代被选择对估计的不同影响。
- 4. 掌握北卡罗来纳设计 II 对加性与显性方差的分离，以及估计精度对设计的依赖。
- 5. 能比较不同设计在总测定数固定时的精度，求最优家系大小。
- 6. 会估计遗传相关并用自助法给出标准误；理解 ANOVA 与 REML 的差别及负估计的处理。

重点与难点

重点：期望均方的推导与方差组分解； h_S^2, h_D^2, h_{S+D}^2 的含义；亲子回归 $b = h^2/2$ （单亲）；设计精度公式。

难点：显性与母体/共同环境对 h_D^2 的混杂；选择造成的回归偏倚方向取决于“谁被选择”；不平衡资料中 k 系数的计算；遗传相关估计量的比值性质与非正定问题。

本章是第 9—12 章“方差—协方差—亲缘”理论到实际估计的第一座桥梁，其中的限制性似然方法在第 23 章完整展开，试验设计思想也将在第 14 章（选择反应预测）与第 15 章（选择指数）中被直接使用。

13.2 知识结构图




图 13.1 第 13 章知识结构图

右侧三支讲“资料结构与估计量”，左侧四支讲“精度、偏倚与方法比较”。

13.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
单亲—后代回归	$b = \text{Cov}(O, P) / \text{Var}(P) = \frac{1}{2}h^2$	无共同环境、无母体效应
双亲均值回归	$b = h^2$	随机交配、双亲与后代环境无关
半同胞相关	$t = \frac{1}{4}h^2$	同父不同母，无共同环境
全同胞相关	$\frac{1}{2}h^2 + \frac{1}{4}V_D/V_P + c^2$	混杂显性与共同环境
嵌套模型	$y_{ijk} = \mu + s_i + d_{ij} + e_{ijk}$	公畜、母畜、后代三层
期望均方	$E(MS_W) = \sigma_W^2$; $E(MS_D) = \sigma_W^2 + k_1\sigma_D^2$; $E(MS_S) = \sigma_W^2 + k_2\sigma_D^2 + k_3\sigma_S^2$	k_1, k_2, k_3 由各层大小决定
三种遗传力	$h_S^2 = 4\sigma_S^2/\sigma_P^2$; $h_D^2 = 4\sigma_D^2/\sigma_P^2$; $h_{S+D}^2 = 2(\sigma_S^2 + \sigma_D^2)/\sigma_P^2$	σ_D^2 含 $\frac{1}{4}V_D$ 与母体效应
北卡 II	$\sigma_S^2 = \sigma_D^2 = \frac{1}{4}V_A$; $\sigma_{SD}^2 = \frac{1}{4}V_D$	母体效应进入 σ_D^2

概念	公式或定义	成立条件与提示
半同胞设计 SE	$SE(\hat{h}^2) \approx 4\sqrt{\frac{2(1-t)^2[1+(n-1)t]^2}{n(n-1)(s-1)}}$	s 为公畜数, n 为每公畜后代数
最优家系大小	$n \approx 4/h^2$ (固定总数、小 h^2)	当 t 小时
遗传相关	$\hat{r}_A = \hat{\sigma}_{S,xy} / \sqrt{\hat{\sigma}_{S,x}^2 \hat{\sigma}_{S,y}^2}$	标准误依赖两性状遗传力
Robertson 近似	$SE(\hat{r}_A) \approx \frac{1 - \hat{r}_A^2}{\sqrt{2}} \sqrt{\frac{SE(\hat{h}_x^2)SE(\hat{h}_y^2)}{\hat{h}_x^2 \hat{h}_y^2}}$	大样本
方差组分估计	ANOVA 无偏但可为负; REML 非负且偏差小	不平衡时更倾向 REML

13.4 补充内容与公式推导

推导 13.1 嵌套设计的期望均方与 k 系数

设有 s 头公畜, 第 i 头配 d_i 头母畜, 第 ij 头母畜有 n_{ij} 个后代, 总数 $N = \sum_{ij} n_{ij}$, 母畜总数 $D = \sum_i d_i$ 。模型 $y_{ijk} = \mu + s_i + d_{ij} + e_{ijk}$, 三个效应相互独立。用平方和分解:

$$SS_W = \sum_{ijk} (y_{ijk} - \bar{y}_{ij.})^2, \quad SS_D = \sum_{ij} n_{ij} (\bar{y}_{ij.} - \bar{y}_{i..})^2, \quad SS_S = \sum_i n_i (\bar{y}_{i..} - \bar{y}...)^2.$$

母畜内平方和只含剩余方差, $E(MS_W) = \sigma_W^2$ 。对母畜间平方和, $\bar{y}_{ij.} - \bar{y}_{i..}$ 的方差中母畜效应的系数为 $(\sum_{ij} n_{ij} - \sum_i \sum_j n_{ij}^2/n_i)/(D-s)$, 故

$$k_1 = \frac{1}{D-s} \left(N - \sum_i \frac{\sum_j n_{ij}^2}{n_i} \right).$$

同理, 公畜间平方和中的两个系数为

$$k_2 = \frac{1}{s-1} \left(\sum_i \frac{\sum_j n_{ij}^2}{n_i} - \frac{\sum_{ij} n_{ij}^2}{N} \right), \quad k_3 = \frac{1}{s-1} \left(N - \frac{\sum_i n_i^2}{N} \right).$$

完全平衡 (d 母畜/公畜、 n 后代/母畜) 时, $k_1 = n$, $k_2 = n$, $k_3 = dn$, 回到教科书形式。三个均方联立即得 $\hat{\sigma}_D^2 = (MS_D - MS_W)/k_1$, $\hat{\sigma}_S^2 = [MS_S - MS_W - k_2 \hat{\sigma}_D^2]/k_3$ 。习题 13.15 的程序在不平衡资料上给出 $k_1 = 5.789$, $k_2 = 6.148$, $k_3 = 22.614$, 三者不相等, 这就是“不能直接套平衡公式”的数值体现。

推导 13.2 选择对亲子回归的影响：为什么“选亲本”无偏而“选后代”有偏

设亲本表型 P 与后代表型 O 联合正态, $E(O | P) = \mu + b(P - \mu)$ 为线性回归, $b = \text{Cov}(O, P) / \text{Var}(P)$ 。若选择只依据亲本表型 P (例如只保留 P 较大者), 则在被选个体中 O 对 P 的条件期望仍然是同一条直线, 因此最小二乘斜率仍然无偏——只是 P 的取值范围变窄, 斜率的抽样方差增大, $\text{Var}(\hat{b}) = \sigma_{O|P}^2 / \sum (P - \bar{P})^2$ 随 $\sum (P - \bar{P})^2$ 减小而增大。反之, 若选择依据后代表型 O (即后代记录的缺失或选留与 O 有关), 则 $E(O | P, \text{入选}) \neq \mu + b(P - \mu)$: 入选事件是 O 的函数, 条件分布被截断, 回归线被拉平, 斜率向零偏。设 O 的截断点为 c , 则被选后代的条件期望为 $E(O | P, O > c) = \mu + b(P - \mu) + \sigma_{O|P} \lambda \left(\frac{c - \mu - b(P - \mu)}{\sigma_{O|P}} \right)$ (逆米尔斯比 λ), 随 P 增大 λ 减小, 所以截断后的斜率小于 b 。习题 13.16 的模拟显示: 真 $h^2 = 0.40$, 亲本选择下估计仍为 0.38 (但 SD 由 0.046 增至 0.22), 后代选择下降到 0.087。

推导 13.3 半同胞设计与套式设计的精度比较

半同胞家系的组内相关 t 的方差近似为

$$\text{Var}(\hat{t}) \approx \frac{2(1-t)^2[1+(n-1)t]^2}{n(n-1)(s-1)},$$

遗传力 $\hat{h}^2 = 4\hat{t}$, 故 $\text{SE}(\hat{h}^2) = 4\sqrt{\text{Var}(\hat{t})}$ 。总记录 $T = sn$ 固定时, 对 n 求最小: 当 t 很小时, $[1+(n-1)t]^2 \approx 1+2(n-1)t$, 分母为 $n(n-1)(s-1) \approx Tn$, 故 $\text{Var} \propto (1+2nt)/(Tn) \cdot (1/T) \cdot T \cdots$, 整理可得最优 $n \approx 1/t = 4/h^2$ 。把 T 固定于 2400 时, $h^2 = 0.10, 0.30, 0.50$ 的最优每公畜后代数分别约 40、14、9 (习题 13.18 的数值最优为 40、14、9), 与 $4/h^2$ 吻合。套式设计中公畜成分 h_{S}^2 的最优安排仍在每公畜约 $4/h^2$ 个后代附近, 但每公畜配几头母畜影响很小; 而 $h_{\text{S}+D}^2$ 则偏好“少公畜、每公畜配许多母畜” (d 小、 k 大), 因为它主要由母畜间方差支撑。亲子回归在 h^2 较大时精度优于半同胞设计, 在 $h^2 = 0.10$ 时反而不如 (SE 0.046 对 0.036)。

拓展阅读 经典估计方法在基因组时代的位置

Falconer 与 Mackay (1996)、Lynch 与 Walsh (1998) 系统化了本章内容; Kruuk (2004) 把动物模型引入野生种群遗传力估计; Visscher 等 (2008) 以及 Yang 等 (2010) 用基因组关系矩阵替代期望亲缘, 重新估计“表观”遗传力。第 25 章将看到: 经典设计估计的是包含所有遗传效应的 h^2 , 而基于 SNP 的估计只给出下界, 二者的差正是“缺失遗传力”讨论的出发点。

易错辨析

- h_D^2 不是“显性遗传力”：母畜成分 σ_D^2 同时含 $\frac{1}{4}V_D$ 、母体效应与共同环境，除非特别设计， $4\sigma_D^2/V_P$ 往往偏高（习题 13.15 中估计 0.57，真值只有 0.32）。
- 亲子回归斜率的自由度：每个亲本多个后代时必须对后代均值回归并校正权重，否则标准误被低估。
- 选择的方向很关键：只选亲本，回归无偏；选后代，回归偏低。
- ANOVA 的负估计不是错误：它是抽样波动的信号，截断为零会引入正偏差，REML 的非负性是以参数空间受限为代价的。
- 遗传相关的标准误不能靠 $\sqrt{\quad}$ 套公式：比值估计量分布偏斜，且可超出 $[-1, 1]$ ，应用自助法或似然剖面。

13.5 习题

一、单项选择题

13.1 ★ [单选] 在无共同环境、无母体效应、加性模型下，半同胞组内相关 t 与遗传力的关系为

- (A) $t = h^2$ (B) $t = \frac{1}{2}h^2$ (C) $t = \frac{1}{4}h^2$ (D) $t = \frac{1}{8}h^2$

[答案]

13.2 ★ [单选] 对嵌套设计，母畜成分 σ_D^2 估计的主要污染源不包括

- (A) 显性方差 (B) 母体效应 (C) 共同窝环境
(D) 公畜间的加性方差

[答案]

13.3 ★★ [单选] 若只保留表型较高的亲本（按亲本表型选留）作为回归资料，单亲—后代回归斜率的估计

- (A) 无偏但方差增大 (B) 向零偏 (C) 向外偏
(D) 方差缩小

[答案]

13.4 ★★ [单选] 在公畜数 $s = 100$ 固定、总测定数不限的条件下，要提高半同胞设计估计 h^2 的精度，应主要

- (A) 增加每公畜后代数至无穷
(B) 增加公畜数并保持每公畜后代数在 $4/h^2$ 左右
(C) 增加每头母畜的后代数 (D) 减少公畜数

[答案]

13.5 ★★ [单选] 下列关于北卡罗来纳设计 II 的说法, 正确的是

- (A) 可分离 V_A 与 V_D , 但 V_D 的估计精度通常低于 V_A
 (B) 只能估计 V_A (C) 母体效应进入公畜成分
 (D) 不需要两个因素交叉

[答案]

13.6 ★★ [单选] 同一资料中, ANOVA 与 REML 对 σ_S^2 的估计的主要差别是

- (A) 二者无差别
 (B) REML 估计永不为负, ANOVA 可为负
 (C) ANOVA 永不为负 (D) ANOVA 对不平衡资料更稳健

[答案]

二、判断与改错题

13.7 ★ [判断] 若嵌套设计完全平衡, 则三个系数 k_1, k_2, k_3 全部相等。

[答案]

13.8 ★★ [判断] 在有强烈共同窝环境时, 全同胞相关用于估计遗传力偏低。

[答案]

13.9 ★★ [判断] 双亲均值对后代的回归斜率等于 $h^2/2$ 。

[答案]

13.10 ★★ [判断] 遗传相关的自助标准误可以用公畜为重抽样单位, 因为公畜之间独立。

[答案]

三、填空题

13.11 ★ [填空] 某嵌套设计的均方为 $MS_S = 3.2, MS_D = 1.5, MS_W = 0.9$, 平衡, $k_1 = k_2 = 5, k_3 = 20$ 。则 $\hat{\sigma}_D^2 = \underline{\hspace{2cm}}$, $\hat{\sigma}_S^2 = \underline{\hspace{2cm}}$, $\hat{h}_{S+D}^2 = \underline{\hspace{2cm}}$ 。

[答案]

13.12 ★ [填空] 半同胞设计中 $t = 0.04$ 时, 最优每公畜后代数约为 $\underline{\hspace{2cm}}$; 对应的 $h^2 = \underline{\hspace{2cm}}$ 。

[答案]

13.13 ★ [填空] 设亲本被选择, 被选亲本的表型方差为原来的 0.25, 则斜率的抽样方差大约变为原来的 $\underline{\hspace{2cm}}$ 倍。

[答案]

13.14 ★ [填空] 全同胞组内相关 $\frac{1}{2}h^2 + \frac{1}{4}V_D/V_P + c^2$ 中, $c^2 = 0.1, V_D/V_P = 0.12, h^2 = 0.4$ 时, $t_{FS} = \underline{\hspace{2cm}}$ 。

[答案]

四、计算题

13.15 ★★ [计算] 不平衡嵌套方差分析。配套数据有 906 个后代的公畜—母畜—后代资料，各母畜的后代数不等。(1) 计算 k_1, k_2, k_3 ；(2) 求三个均方、三个方差组分与三种遗传力；(3) 用公畜自助法给出标准误；(4) 说明为什么 $\hat{h}_D^2$ 远高于其他两个估计。[程序] `ch13/ex13_15_nested_anova.py` [答案]

13.16 ★★ [计算] 亲子回归中的选择偏倚。真 $h^2 = 0.40$ ，亲本—后代联合正态。分别在“全部入选”“只按亲本表型选留”“只按后代表型保留”三种情形下反复模拟，比较斜率估计的均值与 SD。[程序] `ch13/ex13_16_parent_offspring_selection.py` [答案]

13.17 ★★ [计算] 北卡 II 设计。12 公 $\times$ 12 母的北卡 II 设计，每对 4 个后代，共 576 个记录，真 $V_A = 0.4$ 、 $V_D = 0.2$ 。模拟多次，求 $\hat{V}_A, \hat{V}_D$ 的均值、SD、变异系数与负估计比例。[程序] `ch13/ex13_17_nc2_design.py` [答案]

13.18 ★★ [计算] 设计精度比较。固定总测定数 2400， $h^2 = 0.1, 0.3, 0.5$ 。比较亲子回归、半同胞设计、套式设计的 SE，求最优家系大小，并用蒙特卡洛核对近似公式。[程序] `ch13/ex13_18_design_precision.py` [答案]

13.19 ★★ [计算] 遗传相关估计。120 头公畜、3022 个半同胞后代的背膘厚与初产窝重数据。(1) 求公畜间/内均方—均积矩阵；(2) 估计两性状的 h^2 、 r_A 、 r_P 、 r_E ；(3) 给出 Robertson 近似 SE 与公畜自助法 SE；(4) 蒙特卡洛核对。[程序] `ch13/ex13_19_genetic_correlation.py` [答案]

13.20 ★★★ [计算] ANOVA 与 REML。在不平衡嵌套资料中，比较 ANOVA、截断 ANOVA 与 REML 对 σ_S^2 、 σ_D^2 与 h_S^2 的偏差、SD、MSE 与负估计比例，考察 $h^2 = 0.25$ 与 0.10 两种情景。[程序] `ch13/ex13_20_anova_vs_reml.py` [答案]

13.21 ★ [计算] 一个全同胞设计测得家系间方差 $\hat{\sigma}_B^2 = 0.62$ 、家系内方差 $\hat{\sigma}_W^2 = 1.38$ 。(1) 求组内相关 $\hat{t}_{FS}$ ；(2) 若已知 $V_D/V_P = 0.1$ 、 $c^2 = 0.08$ ，求加性遗传力。 [答案]

13.22 ★ [计算] 单亲回归的斜率为 0.22，样本含 $n = 250$ 个亲子对， $V_P = 1$ 。求 h^2 及其近似 SE (用 $SE(b) \approx \sqrt{(1-b^2)/n}$)。 [答案]

五、推导与证明题

13.23 ★★ [证明] 在随机模型 $y_{ij} = \mu + a_i + e_{ij}$ 下, 证明组内成员的协方差等于组间方差 σ_a^2 , 并给出组内相关与方差分析中 F 的关系: $E(F) \approx 1 + nt/(1-t)$ 。 [答案]

13.24 ★★ [证明] 推导 13.1 中 k_1 的表达式, 并验证平衡时 $k_1 = n$ 。 [答案]

13.25 ★★★ [证明] 证明: 若选择只基于亲本表型 (线性回归模型成立且表型联合正态), 单亲—后代回归斜率的最小二乘估计仍无偏; 若选择基于后代表型, 则斜率向零偏。 [答案]

13.26 ★★★ [证明] 证明在半同胞设计中, 总数 $T = sn$ 固定且 t 很小时, 使 $\text{Var}(\hat{t})$ 最小的 n 满足 $n \approx 1/t$ 。 [答案]

六、综合分析与研究设计题

13.27 ★★ [综合] 某猪场计划估计背膘厚遗传力, 场内有 60 头公猪可用, 每头可配多头母猪。比较 (i) 半同胞、(ii) 嵌套、(iii) 亲子回归, 各自的资料需求、可分离的遗传成分与主要偏倚, 给出你的推荐。 [答案]

13.28 ★★★ [综合] 某肉牛群的资料存在选择: 只有体重较高的犊牛被留作母牛并产犊。说明用母—犊回归估计遗传力会产生什么偏倚, 并设计两种校正或避免偏倚的方法。 [答案]

13.29 ★★★ [综合] 评审意见认为“你们的遗传相关估计为 -0.57 , 标准误很大, 不可信”。写一份答复: 说明标准误来源、自助法/似然剖面如何给出区间、增加什么资料最有效。 [答案]

13.6 参考答案与解析

一、单项选择题

13.1 C。 半同胞共享 $1/4$ 的加性方差。 [题目]

13.2 D。 公畜间的加性方差进入公畜成分, 不污染母畜成分。 [题目]

13.3 A。 见推导 13.2: 条件期望仍线性, 斜率无偏, 但 $\sum(P - \bar{P})^2$ 变小使方差增大。

[题目]

- 13.4 B。**精度由公畜数与每公畜后代数共同决定，最优家系约 $4/h^2$ 。 [题目]
- 13.5 A。**北卡 II 通过公 $\times$ 母交互项分离 V_D ，但交互项的自由度和系数使其估计精度较差（习题 13.17: V_A 的 CV 为 0.38, V_D 为 0.70）。 [题目]
- 13.6 B。**REML 将估计限制在参数空间内，ANOVA 估计无偏但可为负。 [题目]

二、判断与改错题

- 13.7 错误。**平衡时 $k_1 = k_2 = n$ ，但 $k_3 = dn$ （每公畜母畜数乘每母畜后代数），三者不全相等。 [题目]
- 13.8 错误。**共同窝环境使全同胞相关偏高，用它估计遗传力会得到偏高的结果；这就是为什么半同胞设计更受青睐。 [题目]
- 13.9 错误。**双亲均值回归的斜率等于 h^2 ，单亲回归才是 $h^2/2$ 。 [题目]
- 13.10 正确。**半同胞资料中，公畜是独立重抽样单位，按公畜整体重抽样可保留家系内相关结构。 [题目]

三、填空题

- 13.11** $\hat{\sigma}_D^2 = (1.5 - 0.9)/5 = 0.12$; $\hat{\sigma}_S^2 = (3.2 - 0.9 - 5 \times 0.12)/20 = 0.085$; $\sigma_P^2 = 0.085 + 0.12 + 0.9 = 1.105$; $\hat{h}_{S+D}^2 = 2 \times 0.205/1.105 = 0.371$ 。 [题目]
- 13.12** $n \approx 1/t = 25$, $h^2 = 4t = 0.16$ 。 [题目]
- 13.13** 方差缩为 0.25 倍后 $\sum(P - \bar{P})^2$ 缩小，斜率方差约变为原来的 4 倍。 [题目]
- 13.14** $0.20 + 0.03 + 0.10 = 0.33$ 。 [题目]

四、计算题

- 13.15** (1) $k_1 = 5.789$, $k_2 = 6.148$, $k_3 = 22.614$ 。(2) 均方: $MS_S = 2.595$, $MS_D = 1.475$, $MS_W = 0.726$; 组分: $\hat{\sigma}_S^2 = 0.0475$, $\hat{\sigma}_D^2 = 0.1294$, $\hat{\sigma}_W^2 = 0.7256$ 。

估计	数值	自助 SE	真值
$\hat{h}_S^2$	0.210	0.074	0.32
$\hat{h}_D^2$	0.574	0.155	0.64
$\hat{h}_{S+D}^2$	0.392	0.073	0.48

(3) 母畜成分的估计误差远大于公畜成分, h_D^2 的 SE 是 h_S^2 的两倍。(4) $\hat{h}_D^2$ 高, 是因为母畜成分吸收了 $\frac{1}{4}V_D$ 、共同窝环境与母体效应; 在模拟资料中, 真实的“母畜成分”约为 $0.16/(0.08 + 0.16 + 0.76) \times 4 = 0.64$, 已含这些成分, 所以估计的是 $4\sigma_D^2/V_P$ 而不是加性遗传力。结论: h_S^2 最干净, 但精度低; h_{S+D}^2 是折中。【题目】

13.16

情形	$\hat{h}^2$ 均值	SD	相关均值
全部	0.401	0.046	0.201
按亲本选择	0.380	0.222	0.090
按后代选择	0.087	0.046	0.092

按亲本选择几乎无偏但精度大损; 按后代选择严重向零偏而 SD 不变——最危险, 因为表面上估计很稳定, 却是错的。这解释了为什么“已有繁殖记录”的资料不能直接做回归 (第 14 章)。【题目】

13.17 $\hat{V}_A$: 均值 0.4008, SD 0.153, CV 0.38; $\hat{V}_D$: 均值 0.2038, SD 0.140, CV 0.70; $\hat{V}_D < 0$ 的比例 5.3%。两者均无偏, 但显性方差估计的相对误差约为加性的两倍; 要精确估计显性, 需要更多交配对或更大的家系。【题目】

13.18 (总数 2400, 表型方差 1)

h^2	亲子 n^*	亲子 SE	半同胞 n^*	半同胞 SE	套式 h_S^2 SE	套式 h_{S+D}^2 SE
0.10	7	0.0464	40	0.0359	0.0365	0.0254
0.30	4	0.0486	14	0.0587	0.0615	0.0394
0.50	4	0.0484	9	0.0716	0.0774	0.0450

蒙特卡洛核对 ($h^2 = 0.3$, 400 次): 亲子回归 SD 0.0448 (近似 0.0486); 半同胞 0.0607 (0.0588); 套式 h_S^2 0.0807 (0.0835); 套式 h_{S+D}^2 0.0400 (0.0394)。近似公式与模拟误差在 10% 以内。结论: h^2 小时半同胞设计 (大家系) 优于亲子回归; h^2 大时亲子回归更省; 而合并 $S + D$ 的遗传力总是最精确, 但混杂显性与母体效应。【题目】

13.19 120 头公畜、3022 个后代, 有效家系大小 $n_0 = 25.17$ 。

参数	估计	Robertson SE	自助 SE	自助 95% 区间
h^2 背膘厚	0.370	0.062	0.063	[0.253, 0.498]
h^2 窝重	0.116	0.035	0.033	[0.047, 0.177]
r_A	-0.566	0.108	0.139	[-0.851, -0.307]
r_P	0.136	—	0.017	[0.101, 0.169]
r_E	0.338	—	0.051	[0.247, 0.446]

遗传相关为负而表型相关为正，说明环境相关为正且大于遗传相关——表型相关不能代替遗传相关。蒙特卡洛（真 $r_A = -0.4$ ）：均值 -0.407 ，SD 0.143 ，平均自助 SE 0.158 ，Robertson SE 在真值处为 0.121 ——近似 SE 偏小，自助 SE 更保守。

[题目]

13.20

h^2	方法	$\hat{h}_S^2$ 均值	SD	MSE	$\sigma_S^2 \leq 0$ 比例
0.25	ANOVA	0.248	0.151	0.0229	0.047
0.25	ANOVA 截断	0.250	0.146	0.0214	0.047
0.25	REML	0.252	0.140	0.0196	0.030
0.10	ANOVA	0.096	0.114	0.0130	0.207
0.10	ANOVA 截断	0.108	0.097	0.0094	0.207
0.10	REML	0.106	0.095	0.0091	0.197

REML 的 MSE 总是最低，但差别主要来自低 h^2 情景下对负估计的处理。ANOVA 与 REML 的 $\hat{h}_S^2$ 相关 0.95 与 0.90 ，说明两者在大多数资料上给出相近的结论；差别在于边界。 $h^2 = 0.10$ 时约 20% 的资料出现公畜成分估计为负，这是信息不足的警告。

[题目]

13.21 (1) $\hat{t} = 0.62 / (0.62 + 1.38) = 0.31$ 。(2) $t_{FS} = \frac{1}{2}h^2 + \frac{1}{4}V_D/V_P + c^2$ 的式子中， V_D/V_P 是显性方差，其贡献为 $\frac{1}{4} \times 0.1 = 0.025$ ： $0.31 = \frac{1}{2}h^2 + 0.025 + 0.08$ ，故 $h^2 = 0.41$ 。

[题目]

13.22 $h^2 = 2b = 0.44$ ； $SE(b) = \sqrt{(1 - 0.0484)/250} = 0.0617$ ， $SE(h^2) = 0.123$ 。

[题目]

五、推导与证明题

13.23 $Cov(y_{ij}, y_{ij'}) = Cov(a_i + e_{ij}, a_i + e_{ij'}) = \sigma_a^2$ ($j \neq j'$)。又 $Var(y_{ij}) = \sigma_a^2 + \sigma_e^2$ ，故 $t = \sigma_a^2 / (\sigma_a^2 + \sigma_e^2)$ 。 $E(MS_B) = \sigma_e^2 + n\sigma_a^2$ ， $E(MS_W) = \sigma_e^2$ ， $E(F) \approx (\sigma_e^2 + n\sigma_a^2) / \sigma_e^2 =$

$$1 + n\sigma_a^2/\sigma_e^2 = 1 + nt/(1-t)。 \quad \text{【题目】}$$

13.24 由 $SS_D = \sum_{ij} n_{ij}(\bar{y}_{ij} - \bar{y}_i)^2$, 对每个公畜 i , $\bar{y}_{ij} - \bar{y}_i = (d_{ij} - \bar{d}_i) + (\bar{e}_{ij} - \bar{e}_i)$, 其中 $\bar{d}_i = \sum_j n_{ij}d_{ij}/n_i$ 。 $\sum_j n_{ij}(d_{ij} - \bar{d}_i)^2$ 的期望是 $\sigma_D^2(n_i - \sum_j n_{ij}^2/n_i)$, 对 i 求和并除以自由度 $D - s$ 即 k_1 。平衡时 $n_{ij} = n$, $n_i = dn$, $\sum_j n_{ij}^2/n_i = n$, 所以 $k_1 = (sdn - sn)/(sd - s) = n$ 。 【题目】

13.25 设 $O = \mu + b(P - \mu) + \epsilon$, $\epsilon \perp P$ 。(1) 选择只依赖 P : 入选事件 $\{P \in A\}$ 与 ϵ 独立, 所以 $E(\epsilon | P, \text{入选}) = 0$, 回归线不变, OLS 无偏。(2) 选择依赖 O : 入选事件为 $O > c$, 则 $E(\epsilon | P, O > c) = \sigma_\epsilon \lambda(\alpha)$, $\alpha = (c - \mu - b(P - \mu))/\sigma_\epsilon$, $\lambda(\alpha) = \phi(\alpha)/[1 - \Phi(\alpha)]$ 为递增函数, 而 α 随 P 增大而减小, 所以 $E(\epsilon | P, \text{入选})$ 随 P 增大而减小, 使有效斜率 $b - \sigma_\epsilon \lambda'(\alpha)b/\sigma_\epsilon < b$, 即向零偏。 【题目】

13.26 $\text{Var}(\hat{t}) \approx \frac{2(1-t)^2[1 + (n-1)t]^2}{n(n-1)(s-1)}$, 取 $s = T/n$, $s-1 \approx T/n$, 得 $\propto \frac{[1 + (n-1)t]^2}{(n-1)T}$ 。令 $f(n) = [1 + (n-1)t]^2/(n-1)$, $f'(n) = 0$ 给出 $2t(n-1) = 1 + (n-1)t$, 即 $n-1 = 1/t$, $n \approx 1/t$ 。 【题目】

六、综合分析与研究设计题

13.27 推荐半同胞/套式合并设计。(i) 半同胞: 每头公猪配多头母猪、每窝只取少数后代, $h_S^2 = 4\sigma_S^2/\sigma_P^2$ 无显性、母体污染, 精度取决于公猪数和每公猪后代数, $4/h^2$ 即最优; (ii) 嵌套: 母猪成分额外提供 h_{S+D}^2 与对母体/显性的诊断, 精度最高, 但解释要谨慎; (iii) 亲子回归: 资料易得但需要亲本无选择偏倚且后代与亲本环境可比, 不能分离母体效应。方案: 60 头公猪各配约 5 头母猪, 每窝测定 2—3 头后代, 总数约 900—1000; 以 h_S^2 为主, 以 h_{S+D}^2 为参照; 用自助法给出 SE; 并用 REML 重复分析, 以避免负估计。 【题目】

13.28 偏倚方向: 母牛被选择的依据是自己的体重 (亲本表型被选择), 母—犊回归的斜率仍然无偏 (推导 13.2), 但母牛的体重变异缩小, 精度下降; 若同时犊牛的记录来自选留后的子代 (后代被选择), 则斜率向零偏。**校正:** (1) 使用动物模型/REML, 把选择依据的所有信息纳入模型 (Kennedy 的结论: 条件于被选择变量时 REML 无偏); (2) 在选择前的群体中对所有亲子对取数, 或用未被选择的随机样本。另一种避免: 用父系半同胞设计, 选择发生在母牛一侧, 公牛后代记录是在未选择资料中取得的。 【题目】

13.29 答复要点: (1) 标准误主要来自公畜数有限与两个遗传力偏低—— r_A 是比值, 其 SE 受 h^2 的相对 SE 放大 (Robertson 近似); (2) 本资料的自助 95% 区间为

$[-0.85, -0.31]$ ，并不包含零，说明负相关的方向是稳健的，不确定性主要在强度；（3）蒙特卡洛显示在真值 -0.4 下估计量近似无偏、SD 0.14，SE 与实际一致；（4）最有效的补充资料是：增加公畜数而不是每公畜后代数（因为遗传力低的窝重性状信息主要来自家系数），或加入第二类亲属（全同胞与亲子）以把 r_A 与 r_E 分开；（5）后续用 REML 双性状模型的似然剖面确认区间。

【题目】

第五篇

选择理论与选择指数

选择怎样改变群体，怎样最优地选择。

本篇习题训练：育种者方程、选择指数、育种目标与经济权重、约束与稳健决策、长期选择。

选择反应的数量遗传理论

14.1 本章导学

学习目标

1. 熟练使用育种者方程 $R = h^2S = ih\sigma_A$ ，理解选择差、选择强度与截断选择的分布性质。
2. 理解 Bulmer 效应：选择在连锁不平衡中“借走”加性方差，能写出并求解递推式的渐近解。
3. 掌握相关选择反应与间接选择的效率比较，会把信息来源（个体、同胞）并入准确度。
4. 能设计并分析双向选择试验，用累积反应对累积选择差回归得到实现遗传力及其标准误。
5. 理解有限群体中漂变对选择反应与选择极限的限制，会用 Robertson $2N_eR_1$ 估计极限。
6. 能判断育种者方程在非正态表型下的适用边界。

重点与难点

重点： $R = ih\sigma_A$ ； $k = i(i - x)$ ；Bulmer 递推； $CR_Y/R_Y = \frac{i_X h_X r_A}{i_Y h_Y}$ ； $R_\infty \approx 2N_e R_1$ 。

难点： 选择差与选择强度的区别；Bulmer 效应是“暂时的”连锁不平衡而非基因频率变化；有限群体中选择强度越高并不意味着极限越高（ N_e 同时下降）；线性回归假设的检验。

本章把第 9—12 章的遗传方差与亲缘关系用于预测“选择之后群体会怎样”，是第 15 章选择指数、第 18 章世代间隔与长期反应以及第 19 章漂变与近交的共同起点。

14.2 知识结构图




图 14.1 第 14 章知识结构图

右侧三支是反应的“公式与强度”，左侧四支是方差变化、相关性状、有限群体与实验测定。

14.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
育种者方程	$R = h^2 S$	a 对 y 的回归线性
标准化形式	$R = i h \sigma_A = i r_{AI} \sigma_A$	$i = S/\sigma_P$
截断强度	$x = \Phi^{-1}(1-p), i = \phi(x)/p$	表型正态
截断后方差	$\text{Var}(y \text{入选}) = (1-k)V_P,$ $k = i(i-x)$	正态截断
有限群体强度	$i_{n,N} \approx i - \frac{1-p}{2p(N+1)i}$	Burrows 近似
育种值方差缩减	$\text{Var}(a \text{入选}) = V_A(1-kh^2)$	线性回归
Bulmer 递推	$d_{t+1} = \frac{1}{2}d_t - \frac{1}{2}kh_t^2 V_{A,t},$ $V_{A,t} = V_0 + d_t$	无限位点，两性同强度
渐近方差	$V_A^* = V_0/(1+kh^{*2})$	唯一解

概念	公式或定义	成立条件与提示
相关反应	$CR_Y = i_X r_{A_X I_X} r_A \sigma_{A_Y}$	选择仅依据 X 的信息
实现遗传力	$h_R^2 = \sum R / \sum S$	过原点回归
Robertson 极限	$R_\infty \approx 2N_e R_1$	加性、独立座位、中等选择
半衰期	$t_{1/2} \lesssim 1.4N_e$	同上

14.4 补充内容与公式推导

推导 14.1 选择后育种值的方差： $\text{Var}(a \mid \text{入选}) = V_A(1 - kh^2)$

设 a 与 y 联合正态, $a = by + u$, $b = V_A/V_P = h^2$, 残差 u 与 y 独立且方差 $V_A(1 - h^2)$ 。截断选择只改变 y 的分布, y 在入选个体中方差缩为 $(1 - k)V_P$ 。于是

$$\begin{aligned}\text{Var}(a \mid \text{入选}) &= b^2(1 - k)V_P + V_A(1 - h^2) \\ &= V_A[h^2(1 - k) + 1 - h^2] = V_A(1 - kh^2).\end{aligned}$$

被选个体的 y 均值上移 S , a 均值上移 $bS = h^2S$, 这是育种者方程; 而方差的缩小则来自截断本身。正交于 y 的那部分 u 未受选择影响, 所以方差缩减的“量”是 kh^2V_A , 与 kV_P 无关。

推导 14.2 Bulmer 递推与渐近解

记基础(无连锁不平衡)加性方差为 V_0 , 第 t 代 $V_{A,t} = V_0 + d_t$, 其中 d_t 来自位点间的连锁不平衡(通常为负)。亲本群体选择后, $\text{Var}(a \mid \text{入选}) = V_{A,t}(1 - kh_t^2)$; 每个后代的育种值为父母平均加上孟德尔抽样, 抽样方差为 $\frac{1}{2}V_0$ (无近交), 且两亲独立, 故

$$V_{A,t+1} = \frac{1}{2}V_0 + \frac{1}{2}V_{A,t}(1 - kh_t^2) = V_0 + \frac{1}{2}d_t - \frac{1}{2}kh_t^2V_{A,t},$$

即 $d_{t+1} = \frac{1}{2}d_t - \frac{1}{2}kh_t^2V_{A,t}$ 。若停止选择, $k = 0$, $d_{t+1} = d_t/2$, 不平衡每代衰减一半。若持续选择, 不动点满足 $d^* = -kh^{*2}V_A^*$, 即 $V_A^* = V_0 - kh^{*2}V_A^*$, $V_A^* = V_0/(1 + kh^{*2})$, $h^{*2} = V_A^*/(V_A^* + V_E)$ 。左边 V_A^* 增, 右边关于 V_A^* 减, 因此在 $(0, V_0)$ 内有唯一解。习题 14.16 的数值: $V_0 = 30, V_E = 70$, $p = 0.5, 0.2, 0.1$ 时 $V_A^* = 25.63, 24.90, 24.66$, 缩减 14.6%—17.8%, 渐近 $h^2 = 0.268, 0.262, 0.261$ 。可见强度增大一倍多, 渐近方差只多缩小 3 个百分点——Bulmer 效应是真实的, 但幅度有限且很快饱和。

推导 14.3 相关选择反应与信息来源

设选择指数 I_X 为性状 X 的信息（个体表型、同胞均值等），选择强度 i ，则被选个体 Y 的育种值提高

$$CR_Y = i \text{Cov}(a_Y, I_X) / \sigma_{I_X} = i r_{a_Y I_X} \sigma_{A_Y}.$$

当 I_X 是 X 的自身表型时 $\text{Cov}(a_Y, y_X) = \text{Cov}(a_Y, a_X) = r_A \sigma_{A_X} \sigma_{A_Y}$ ， $\sigma_{I_X} = \sigma_{P_X}$ ，得 $CR_Y = i h_X r_A \sigma_{A_Y}$ 。对 Y 直接选择时 $R_Y = i h_Y \sigma_{A_Y}$ ，于是 $CR_Y / R_Y = h_X r_A / h_Y$ 。若直接选择只能用 m 个半同胞均值，则准确度由 $\text{Cov}(a_Y, \bar{I}) = \frac{1}{4} V_{A_Y}$ 与 $\text{Var}(\bar{I}) = V_{P_Y} [1 + (m-1)t] / m$ 决定（ $t = h_Y^2 / 4$ ）。习题 14.17 的 5 种情形中， X 易测时间接选择可达直接选择的 1.3—1.5 倍； h_X^2 低于 h_Y^2 的一半时则不如直接选择。

拓展阅读 实现遗传力、长期选择与非正态性

Hill (1972)、Falconer 与 Mackay (1996) 讨论了实现遗传力的抽样方差；Weber (1990) 的果蝇长期选择、Illinois 玉米蛋白质含量选择（Dudley 与 Lambert 2004，超过 100 代仍有反应）显示长期反应远超有限座位的预期，说明新突变、上位性与大量微效座位的重要作用（Hill 与 Kirkpatrick 2010）。Walsh 与 Lynch (2018) 把选择反应系统归纳为“多变量 Lande 方程”，在非正态资料上提出了分位数和阈值模型的推广。

易错辨析

- **选择差与选择强度**： S 有单位， $i = S / \sigma_P$ 无量纲，只有后者可跨性状、跨群体比较。
- **Bulmer 效应不是漂变**：它由位点间负连锁不平衡引起，停止选择后每代恢复一半，不改变基因频率。
- **强度越大极限越高吗**？固定 N_e 时是；但留种数减半会使 N_e 减半，极限可能反而下降（习题 14.10 与习题 14.19）。
- **实现遗传力不等于基础群体遗传力**：它包含 Bulmer 效应、漂变、选择引起的基因频率变化、 $G \times E$ 等，是“这个选择试验里”的有效遗传力。
- **育种者方程不是定律**：当 $E(a | y)$ 非线性（如偏态环境、阈值性状）时， $h^2 S$ 可能严重高估真实反应（习题 14.20）。

14.5 习题

一、单项选择题

- 14.1 ★ [单选] 对正态表型作前 10% 的截断选择, 被选个体的表型方差相当于原方差的
(A) 0.10 (B) 0.169 (C) 0.50 (D) 0.831

[答案]

- 14.2 ★ [单选] 选择后下一代加性方差减小的主要原因是

- (A) 有利等位基因被固定 (B) 位点间负连锁不平衡的产生
(C) 突变减少 (D) 近交增加

[答案]

- 14.3 ★★ [单选] 两性状遗传相关 $r_A > 0$, 两个性状都用自身表型、选择强度相同时, 经 X 间接选择 Y 优于直接选择 Y 的条件是

- (A) $h_X^2 > h_Y^2$ (B) $h_X r_A > h_Y$ (C) $r_A > h_X h_Y$ (D) $h_Y > h_X$

[答案]

- 14.4 ★★ [单选] 下列哪种情形最可能使 $h^2 S$ 高估真实选择反应?

- (A) 表型严格正态 (B) 环境偏差右偏并选择右尾
(C) 选择强度很小 (D) 群体很大

[答案]

- 14.5 ★★ [单选] 在相同的第一代反应 R_1 下, 有效群体大小由 20 增加到 40, Robertson 选择极限

- (A) 不变 (B) 变为原来的一半
(C) 约变为原来的 2 倍 (D) 约变为 4 倍

[答案]

- 14.6 ★★ [单选] 双向 (高、低) 选择试验相对于单向选择的主要优点是

- (A) 反应更大 (B) 无需重复
(C) 以高低系的差值估计实现遗传力, 可消除环境趋势的影响
(D) 无需记录选择差

[答案]

二、判断与改错题

- 14.7 ★ [判断] Bulmer 效应使渐近加性方差与选择强度无关。

[答案]

- 14.8 ★★ [判断] 停止选择后, 连锁不平衡引起的方差缺口每代恢复一半。

[答案]

- 14.9 ★★ [判断] 选择反应 $R = ih\sigma_A$ 与表型标准差无关, 所以在方差大的群体中不会更有利。

[答案]

14.10 ★★ [判断] 为提高选择强度而把留种数减半, 选择极限一定提高。

[答案]

三、填空题

14.11 ★ [填空] 入选比例 $p = 0.2$ 时, 截断点 $x =$ _____, $i =$ _____, $k =$ _____, 被选个体表型方差为 V_p 的_____倍。

[答案]

14.12 ★ [填空] 基础 $V_0 = 50$, $V_p = 100$, 两性均选择 50% ($k = 0.637$)。第一代选择后, 下一代的连锁不平衡项 $d_1 =$ _____, $V_{A,1} =$ _____。

[答案]

14.13 ★ [填空] 停止选择 3 代后, 连锁不平衡缺口只剩原来的_____。

[答案]

14.14 ★ [填空] $N_e = 20$, 第一代反应 $R_1 = 0.8$ 单位, Robertson 极限约为_____, 半衰期上限约_____代。

[答案]

四、计算题

14.15 ★★ [计算] 截断选择的强度与有限群体校正。对入选比例 0.5、0.3、0.2、0.1、0.05、0.01, 求阈值、强度、方差缩减因子 k , 用蒙特卡洛核对; 再比较从 N 头中选 n 头的 Burrows 近似与顺序统计量的精确期望。[程序] `ch14/ex14_15_truncation_intensity.py`

[答案]

14.16 ★★ [计算] Bulmer 效应的个体水平模拟。 $V_0 = 30$ 、 $V_E = 70$, 入选比例 0.5、0.2、0.1, 模拟 10 代, 与递推公式对照, 求渐近 V_A 与 h^2 。[程序] `ch14/ex14_16_bulmer_simulation.py`

[答案]

14.17 ★★ [计算] 相关选择反应。5 种情形 (含只能用半同胞或全同胞均值测定 Y 、遗传相关为负) 下, 比较间接与直接选择的反应与效率, 并用蒙特卡洛核对。[程序]

`ch14/ex14_17_correlated_response.py`

[答案]

14.18 ★★★ [计算] 双向选择与实现遗传力。 $h^2 = 0.30$, 高、低方向各 4 个重复系, 每系每性别 30 个候选, 分别留 5 头公畜、15 头母畜, 共 10 代, 群体含完整系谱近交。求各系与合并实现遗传力、SE, 并用 100 次独立试验检验 SE 与覆盖率。[程序]

`ch14/ex14_18_realized_heritability.py`

[答案]

- 14.19 ★★★ [计算] 选择极限。**40 头个体、每代留 10 头, 100 个等效座座位, 初始 $h^2 = 0.4$, 120 个重复模拟 50 代。用中性座杂合度估计 N_e , 比较平台、 $2N_e R_1$ 与理论上限。

[程序] `ch14/ex14_19_selection_limit.py`

[答案]

- 14.20 ★★★ [计算] 非正态表型下的育种者方程。**环境偏差取伽玛分布, 形状参数 1000、20、8、4、2、1, $h^2 = 0.3$, 前 10% 截断。比较真实反应、 $h^2 S$ 与正态理论, 并度量 $E(a | y)$ 的非线性。 [程序] `ch14/ex14_20_nonnormal_selection.py`

[答案]

- 14.21 ★ [计算]** 某性状 $h^2 = 0.25$, $\sigma_P = 8$ 。公畜留前 5% ($i = 2.063$), 母畜留前 50% ($i = 0.798$)。(1) 求每代反应; (2) 若公畜世代间隔 2 年、母畜 3 年, 求每年反应。

[答案]

- 14.22 ★ [计算]** $h^2 = 0.4$, $V_P = 100$, $V_0 = 40$, 两性各选前 20% ($k = 0.781$)。求第一代选择引起的 d_1 、下一代的 V_A 与 h^2 (暂忽略 V_E 的变化)。

[答案]

五、推导与证明题

- 14.23 ★★ [证明]** 证明 $\text{Var}(a | \text{入选}) = V_A(1 - kh^2)$, 并说明为什么它与 V_E 的大小无关 (只通过 h^2 依赖)。

[答案]

- 14.24 ★★ [证明]** 假设 $E(a | y)$ 线性, 证明 $R = h^2 S = ih\sigma_A$ 。若 $y = a + e$ 中 e 与 a 独立但 e 非正态, 线性假设为何可能失败?

[答案]

- 14.25 ★★ [证明]** 证明相关选择反应 $CR_Y = ih_X r_A \sigma_{A_Y}$, 并推出 $CR_Y / R_Y = h_X r_A / h_Y$ 。 [答案]

- 14.26 ★★★ [证明]** 证明 Bulmer 递推的不动点 $V_A^* = V_0 / (1 + kh^{*2})$ 在 $(0, V_0)$ 内唯一, 并证明该不动点局部稳定。

[答案]

六、综合分析与研究设计题

- 14.27 ★★ [综合]** 设计一个估计某种鼠体重实现遗传力的双向选择试验: 给出群体大小、重复数、选择强度、测定时间, 如何控制环境趋势与近交, 如何给出标准误。 [答案]

- 14.28 ★★★ [综合]** 某猪场第 6 代起选择反应明显小于由基础群体 h^2 预测的反应。列出至少五种可能的原因, 并为每一种设计一个可检验的诊断。 [答案]

- 14.29 ★★★ [综合]** 肉牛生产中, 体重 ($h^2 = 0.4$) 易测, 而饲料转化率 ($h^2 = 0.15$) 昂贵。已知 $r_A = -0.5$ 。比较“只选体重”“只选转化率 (用半同胞均值, 各 20 个半同胞)”以及“两者联合”的预期效果, 并考虑世代间隔与成本, 给出建议。 [答案]

14.6 参考答案与解析

一、单项选择题

- 14.1 B。** $k = 0.831$, 方差为 $(1 - k)V_P = 0.169V_P$ 。 [题目]
- 14.2 B。** 见推导 14.2; 基因频率与近交都不是 Bulmer 效应的原因。 [题目]
- 14.3 B。** $CR_Y/R_Y = h_X r_A / h_Y > 1$ 即 $h_X r_A > h_Y$ 。 [题目]
- 14.4 B。** 偏态环境使右尾入选个体中的环境偏差占比增大, $E(a | y)$ 在右尾变平, 真实反应小于 $h^2 S$ (习题 14.20)。 [题目]
- 14.5 C。** 极限 $\approx 2N_e R_1$, N_e 加倍则极限加倍 (若 R_1 不变)。 [题目]
- 14.6 C。** 高、低系同受环境趋势影响, 差值抵消了共同趋势, 并且可检验选择反应的对称性。 [题目]

二、判断与改错题

- 14.7 错误。** 渐近方差为 $V_0 / (1 + kh^2)$, 随 k 增大而减小; 只是缩小幅度的趋于饱和 (习题 14.16: $p = 0.5, 0.2, 0.1$ 分别缩减 14.6%、17.0%、17.8%)。 [题目]
- 14.8 正确。** $d_{t+1} = d_t / 2$ ($k = 0$)。 [题目]
- 14.9 错误。** $R = ih\sigma_A$ 与 σ_P 无关是对的, 但“方差大不利”的结论不成立: σ_A 越大, 每单位选择强度的遗传进展越大, 方差大的群体恰恰更有利。 [题目]
- 14.10 错误。** 例如从 $p = 0.2$ 改为 0.1, 强度由 1.400 增至 1.755 (约 1.25 倍), 而 N_e 减半, 极限约 $1.25 \times 0.5 = 0.63$ 倍。 [题目]

三、填空题

- 14.11** $x = 0.842$, $i = 1.400$, $k = 0.781$, 方差为 V_P 的 0.219 倍。 [题目]
- 14.12** $h_0^2 = 0.5$, $V_A = 50$, $d_1 = -\frac{1}{2} \times 0.637 \times 0.5 \times 50 = -7.96$; $V_{A,1} = 42.04$ 。 [题目]

14.13 $1/8 = 0.125$ 。 [题目]

14.14 $2 \times 20 \times 0.8 = 32$ 单位；半衰期上限约 $1.4 \times 20 = 28$ 代。 [题目]

四、计算题

14.15

p	阈值 x	强度 i	k	MC 强度	MC 方差	$1 - k$
0.50	0.000	0.798	0.637	0.797	0.361	0.363
0.30	0.524	1.159	0.735	1.157	0.262	0.265
0.20	0.842	1.400	0.781	1.397	0.217	0.219
0.10	1.282	1.755	0.831	1.753	0.168	0.169
0.05	1.645	2.063	0.862	2.063	0.137	0.138
0.01	2.326	2.665	0.903	2.653	0.095	0.097

有限群体：

N	n	无限 i	Burrows	精确
200	10	2.063	2.040	2.040
200	100	0.798	0.795	0.795
50	5	1.755	1.705	1.705
30	3	1.755	1.672	1.674
20	2	1.755	1.633	1.638

Burrows 近似的相对误差不超过 0.3%。有限群体校正对小群体重要：20 选 2 时强度比无限群体低 7%。 [题目]

14.16

p	k	渐近 V_A	缩减	渐近 h^2
0.5	0.637	25.63	14.6%	0.268
0.2	0.781	24.90	17.0%	0.262
0.1	0.831	24.66	17.8%	0.261

递推与个体水平模拟（6 万个后代）的 V_A 相差不超过 0.6，反应相差小于 0.12。收敛很快：第 3—4 代已基本到达渐近。以 $p = 0.1$ 为例，第 0 代反应 5.27，第 5 代

4.45, 之后稳定在 4.45 左右。要点: Bulmer 效应使反应永久性低于“基于基础 h^2 的预测”约 15%, 但不继续恶化。 [题目]

14.17

情形	r_X	r_Y	直接 R_Y	间接 CR_Y	比值	MC 比值
X 易测高遗传力	0.707	0.316	0.555	0.745	1.34	1.33
X 为低遗传力	0.387	0.632	1.110	0.544	0.49	0.49
Y 仅能用半同胞均值	0.707	0.291	0.511	0.745	1.46	1.45
Y 仅能用全同胞均值	0.632	0.513	0.900	0.555	0.62	0.61
负相关	0.632	0.548	0.961	-0.555	-0.58	-0.58

($i = 1.755$, 以 σ_{A_Y} 为单位。) 判断依据是准确度之比 $r_X r_A / r_Y$ 。半同胞均值的准确度 (0.29) 还不及 $h_Y = 0.316$, 因为 20 个半同胞只含 1/4 的信息; 全同胞均值 (0.513) 信息量更大, 但此时 r_A 只有 0.5。负相关间接反应符号为负, 即选择 X 会降低 Y——这是多性状选择中的“拮抗”现象, 需要第 15—17 章的指数处理。

[题目]

14.18 8 个系的实现遗传力: 高系 0.325、0.355、0.244、0.237, 低系 0.266、0.305、0.281、0.341; 合并 $h_R^2 = 0.294$, 重复系间 $SE = 0.016$ 。每代累积选择差与反应 (高系平均): 第 1 代 $\Sigma S = 0.90$, $\Sigma R = 0.31$; 第 5 代 4.62 与 1.49; 第 10 代 9.19 与 2.50。100 次独立试验: 均值 0.297, 实际 SD 0.013, 平均报告 SE 0.015, 名义 95% 区间覆盖 0.95。实现遗传力略低于基础 $h^2 = 0.30$ (预期因 Bulmer 效应与近交下降), 但在这里差异小于 SE。SE 来自重复系间离散, 是合理的, 覆盖率与名义水平一致, 提示重复系数至少应有 4 个以上, 否则 SE 本身不可靠。 [题目]

14.19 $N = 40$ 、留种 10; 中性座杂合度衰减估计 $N_e = 9.79$, 与留种数相近。初始 $V_A = 0.653$, $h^2 = 0.395$ 。 $R_1 = 0.639$, Robertson 极限 $2N_e R_1 = 12.50$, 模拟末期平台 (最后 10 代均值) 8.75, 理论上限 (全部有利等位基因固定) 11.55。平台 / Robertson = 0.70, 平台 / 上限 = 0.76, 半衰期约 10 代。进程:

世代	累积反应	V_A	有利等位基因固定比例	中性杂合度
0	0	0.653	0	0.494
5	2.56	0.381	0.047	0.378
10	4.43	0.282	0.238	0.289
20	6.85	0.132	0.570	0.170
30	8.03	0.064	0.741	0.103

世代	累积反应	V_A	有利等位基因固定比例	中性杂合度
50	8.84	0.011	0.863	0.036

Robertson 极限是上界而非预测：初始频率 0.5 时，有一部分有利等位基因因漂变而丢失，故实际平台低于理论值。极限与半衰期只有数量级意义， N_e 与首代反应的估计误差都会放大。

[题目]

14.20

κ	偏度	S	R 真实	$h^2 S$	R 正态	真实/ $h^2 S$	最大非线性偏离
1000	0.06	1.769	0.521	0.531	0.526	0.98	0.04
20	0.45	1.849	0.471	0.555	0.526	0.85	0.26
8	0.71	1.901	0.448	0.570	0.526	0.79	0.39
4	1.00	1.964	0.422	0.589	0.527	0.72	0.54
2	1.41	2.033	0.389	0.610	0.526	0.64	0.71
1	2.00	2.104	0.359	0.631	0.526	0.57	0.88

偏度越大，选择差 S 越大（右尾拉长）， $h^2 S$ 也越大，真实反应却越小：偏度为 2 时， $h^2 S$ 高估近 76%。教训：用 $h^2 S$ 预测反应前应先检查 $E(a | y)$ 的线性，对偏态性状可先变换尺度（第 10 章）或使用分位数/阈值模型；而正态理论 $ih\sigma_P$ (0.526) 对偏度不敏感，但同样与真实值偏离。

[题目]

14.21 (1) $R = \frac{1}{2}(2.063 + 0.798) \times 0.25 \times 8 = 2.86$ 单位/代。(2) $\Delta G/\text{年} = (2.063 + 0.798) \times 0.25 \times 8 / (2 + 3) = 1.14$ 单位/年。

[题目]

14.22 $d_1 = -\frac{1}{2} \times 0.781 \times 0.4 \times 40 = -6.25$ ；下一代 $V_A = 40 - 6.25 = 33.75$ ；若 V_E 不变 ($V_E = 60$)， $h^2 = 33.75/93.75 = 0.360$ 。

[题目]

五、推导与证明题

14.23 见推导 14.1。要点： $a = h^2 y + u$ ， $u \perp y$ ， $\text{Var}(u) = V_A(1 - h^2)$ ；选择改变 y 的方差为 $(1 - k)V_P$ ，于是 $\text{Var}(a | \text{入选}) = h^4(1 - k)V_P + V_A(1 - h^2) = V_A(1 - kh^2)$ 。 V_E 只通过 $h^2 = V_A/V_P$ 影响：环境方差越大， h^2 越小，被选个体中 a 的方差缩小。

[题目]

14.24 $E(a | y) = \mu_a + b(y - \mu_y)$ ， $b = V_A/V_P = h^2$ 。选择后 $E(a | \text{入选}) = \mu_a + h^2(E(y | \text{入选}) - \mu_y) = \mu_a + h^2 S$ ，故 $R = h^2 S$ 。 $S = i\sigma_P$ 得 $R = ih^2\sigma_P = ih\sigma_A$ 。若 e 非正态

(例如右偏), a, e 独立不足以保证 $E(a | a + e)$ 是线性函数: 仅当二者都是正态 (或其他特殊分布) 时才线性。偏态 e 的右尾使得大的 y 更可能来自大的 e , 故 $E(a | y)$ 的斜率在右尾变平。 [题目]

14.25 入选者 Y 育种值的期望增量为 $E(a_Y | \text{入选}) - \mu = \text{Cov}(a_Y, I_X) / \text{Var}(I_X) \cdot S_I$, $S_I = i\sigma_{I_X}$, 故 $CR_Y = i \text{Cov}(a_Y, I_X) / \sigma_{I_X}$ 。自身表型: $\text{Cov}(a_Y, y_X) = r_A \sigma_{A_X} \sigma_{A_Y}$, $\sigma_{I_X} = \sigma_{P_X}$, 得 $CR_Y = i r_A \sigma_{A_X} \sigma_{A_Y} / \sigma_{P_X} = i h_X r_A \sigma_{A_Y}$ 。又 $R_Y = i h_Y \sigma_{A_Y}$, 故比值为 $h_X r_A / h_Y$ 。 [题目]

14.26 令 $g(V) = V_0 / (1 + kV / (V + V_E))$, $V \in (0, V_0]$ 。 $V / (V + V_E)$ 严格增, 故 g 严格减, $g(0) = V_0 > 0$, $g(V_0) < V_0$, 由介值定理与单调性, $V = g(V)$ 在 $(0, V_0)$ 内有唯一解。稳定性: 把递推写成 $V_{t+1} = \frac{1}{2}V_0 + \frac{1}{2}V_t(1 - kV_t / (V_t + V_E)) =: F(V_t)$ 。 $F'(V) = \frac{1}{2}[1 - kh^2 - kVV_E / (V + V_E)^2]$, 其中 $h^2 = V / (V + V_E)$, 故 $F'(V) = \frac{1}{2}[1 - kh^2(1 + V_E / (V + V_E))] = \frac{1}{2}[1 - kh^2(1 + 1 - h^2)]$ 。因 $0 < kh^2(2 - h^2) < 2$, 有 $F' \in (-\frac{1}{2}, \frac{1}{2})$, 所以 $|F'| < 1$, 不动点局部稳定, 且单调收敛或振荡收敛。数值: $V_0 = 30, V_E = 70, p = 0.1$ 时 $F'(24.66) = \frac{1}{2}[1 - 0.831 \times 0.261 \times 1.739] = 0.31$, 每代误差缩小约 70%, 与模拟中 3—4 代收敛一致。 [题目]

六、综合分析与研究设计题

14.27 设计要点: (1) 基础群体: 遗传多样的封闭群体或杂交群体, 随机抽样; (2) 选择方向与重复: 高、低各至少 3—4 个重复系, 另设随机交配对照系, 以便把漂变引起的变化与选择反应分开; (3) 群体大小: 每系每代至少 10—15 对留种, 每代足够多的后代以保证候选数 (如每性别 30 只), 避免 N_e 太小; (4) 选择强度: 留前 15%—20%, 保证每代有可测的反应而不过分压缩 N_e ; (5) 测定: 固定日龄、同一设备、同批饲养, 使用对照系或交错世代以估计环境趋势; (6) 记录每代各系的选择差与平均值; (7) 分析: 对每个系以累积反应对累积选择差过原点回归, 取高低系合并估计, 以重复系间离散给出 SE; 双向差值可消除环境趋势, 不对称反应可提示基因频率偏态或适应性压力; (8) 近交控制: 避免全同胞交配, 计算系谱 F (第 12 章), 并用同期对照系的近交衰退来校正。习题 14.18 的模拟显示: 4+4 个系、10 代时 SE 约 0.016, 已能区分 $h^2 = 0.30$ 与 0.25, 但不足以区分 0.30 与 0.28。

[题目]

14.28 (1) **Bulmer 效应:** 渐近方差缩减约 15%—18%; 诊断: 用动物模型 REML 在各世代重估 V_A , 或比较祖先与近代群体的 V_A (第 22—23 章)。(2) **漂变与近交:** N_e 小则极限低; 诊断: 计算系谱 ΔF 与中性标记杂合度衰减, 对比反应; (3) **有利等**

位基因固定：主效基因被固定后方差骤降；诊断：全基因组扫描与群体分化（第 26、29 章）。(4) **环境趋势与 $G \times E$** ：遗传进展被管理变化抵消；诊断：保留对照群（冷冻精液）或用各代的基因型 $\times$ 环境互作评估（第 32 章）。(5) **非线性/非正态**：偏态表型导致 h^2S 高估；诊断：画 $E(EBV | y)$ 对 y 的分箱曲线，检查线性（习题 14.20）。(6) **选择性偏倚**：只有部分个体有记录；诊断：条件于选择变量的模型。一般地，应以“预测值 = 实测值”的校准图来量化缺口，再逐项消去。 [题目]

14.29 记 i 相同（均留前 10%）， σ_A 以各自单位标准化。**只选体重**：对饲料转化率的间接反应 $CR = ih_X r_A \sigma_{A_Y} = i \times 0.632 \times (-0.5) \sigma_{A_Y} = -0.316i \sigma_{A_Y}$ （转化率降低，符号为改良方向）；**只选转化率（半同胞 20 头）**：准确度 $r = 0.25h^2 / \sqrt{h^2[1 + 19t]/20}$, $t = h^2/4 = 0.0375$, $r = 0.25 \times 0.15 / \sqrt{0.15 \times 1.7125/20} = 0.0375 / 0.1133 = 0.331$ （以 σ_A 标准化），改良 $0.331i \sigma_{A_Y}$ ，比直接用个体表型的 $h_Y = 0.387$ 还略低；**联合**：用指数合并两类信息，准确度必不低于两者最大者，可大幅提高（第 15 章的指数公式）。世代间隔：半同胞信息需要后代，间隔比体重选择长；若要用 σ_{A_Y} 的单位比较，还须折算为每年进展。**建议**：用体重作为主选择性状（成本低、间隔短），同时用部分个体的转化率记录与基因组信息建立联合评估；转化率的直接测定只留给少数候选种公牛（第 27—28 章），并以成本效益分析决定半同胞数量。 [题目]

单性状选择指数与信息融合

15.1 本章导学

学习目标

- 1. 理解选择指数是对育种值的最佳线性预测：最优权重满足 $Pb = C$ ，准确度即指数与育种值的相关。
- 2. 能由亲缘结构（自身、双亲、同胞、后代）构造协方差矩阵，计算权重、可靠度与预测误差方差。
- 3. 理解重复记录的信息上限、不等记录数下的收缩，以及为什么不能直接比较原始均值。
- 4. 能处理记录缺失模式不同的候选个体，识别“标准化”带来的排序错误。
- 5. 理解参数估计误差对指数的影响很小（二阶），但对设计与经济判断可能很大。
- 6. 会用两阶段选择与信息价值分析比较不同测定方案的成本效益。

重点与难点

重点： $b = P^{-1}C$ ；准确度 $r = \sqrt{b^T C / V_A}$ ；重复记录可靠度 $nh^2/[1 + (n - 1)t]$ ；信息的投影解释。

难点： 同胞信息“记录很多但独立遗传信息不多”；权重可以为负；缺失模式不同的个体必须用各自的 BLP 而不是统一标准化；两阶段选择中两个指数的相关结构。

本章是第 14 章“选择反应”与第 16—17 章“多性状指数”之间的桥梁；它的矩阵形式在第 21 章变成混合模型方程，在第 27—28 章扩展为基因组信息融合。

15.2 知识结构图




图 15.1 第 15 章知识结构图

右侧三支是指数的“构造与解释”，左侧四支是“信息类型、质量与价值”。

15.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
选择指数	$I = b^T(y - \mu), Pb = C$	P 为记录协方差, $C = \text{Cov}(y, a)$
准确度与可靠度	$r^2 = b^T C / V_A$	候选非近交
预测误差方差	$PEV = V_A(1 - r^2)$	与记录取值无关
单记录	$b = h^2, r = h$	偏离群体均值的记录
重复记录	$r_n^2 = \frac{nh^2}{1 + (n-1)t}$	t 为重复力, 上限 h^2/t
全同胞/半同胞均值	$\text{Cov}(a, \bar{F}) = \frac{1}{2}V_A,$ $\text{Cov}(a, \bar{H}) = \frac{1}{4}V_A$	无共同环境
公畜后代测定	$r^2 = \frac{n}{n+k}, k = \frac{4-h^2}{h^2}$	后代与随机母畜
新增信息	$r_{\text{new}}^2 = r_{\text{old}}^2 + \frac{\text{Cov}(a, z^*)^2}{V_A \text{Var}(z^*)}$	z^* 为新记录对旧记录的残差
投影解释	$\hat{a} = \text{Proj}(a \text{span } y)$	平方可积空间
两阶段相关	$\text{Corr}(I_1, I_2) = r_1 / r_2$	I_1 为 I_2 的子信息

概念	公式或定义	成立条件与提示
记录缺失	各模式单独求 b 、 r^2	不能统一标准化
信息价值	$E[a_{\text{选}}] = r \sigma_A E[Z_{(m:m)}]$	从 m 个候选选 1 个

15.4 补充内容与公式推导

推导 15.1 最优权重满足 $Pb = C$

要使指数 $I = b^T y$ 与育种值 a 的相关最大。相关为

$$\rho(b) = \frac{b^T C}{\sqrt{b^T P b V_A}}.$$

它对 b 的尺度不变, 故可约束 $b^T P b = 1$ 。由 Cauchy-Schwarz, $b^T C = (P^{1/2} b)^T (P^{-1/2} C) \leq \sqrt{C^T P^{-1} C}$, 等号当 $P^{1/2} b \propto P^{-1/2} C$, 即 $b \propto P^{-1} C$ 。取比例为 1, 得到平方误差意义下的最佳线性预测 (BLP), 且 $r^2 = C^T P^{-1} C / V_A = b^T C / V_A$, $PEV = V_A - C^T P^{-1} C = V_A (1 - r^2)$ 。习题 15.15 用系谱表格法生成 P 与 C : 自身加 8 个半同胞加 4 个全同胞时, 权重为自身 0.206、每个半同胞 0.023、每个全同胞 0.064, 可靠度 0.381——13 条记录的信息量只相当于约 1.5 个自身记录, 因为同胞共享的是家系信息而非个体信息。

推导 15.2 新增信息的增量: 偏相关的平方

设原信息 y_1 的可靠度为 r_1^2 。新增记录 z 对 y_1 的残差 $z^* = z - \text{Cov}(z, y_1) P_1^{-1} y_1$ 与 y_1 正交, 故新信息空间 $\text{span}(y_1) \oplus \text{span}(z^*)$ 为正交和, 投影的平方范数可加:

$$r_2^2 V_A = r_1^2 V_A + \frac{\text{Cov}(a, z^*)^2}{\text{Var}(z^*)}.$$

因此增量永远非负, 为零当且仅当 z^* 与 a 不相关。若 z 几乎被 y_1 线性决定 ($\text{Var}(z^*) \rightarrow 0$), 则增量趋于零, 即“信息冗余”。对重复记录, $r_n^2 = nh^2 / [1 + (n-1)t]$ 的增量 $r_{n+1}^2 - r_n^2 = \frac{h^2(1-t)}{[1 + (n-1)t][1 + nt]}$ 随 n 单调递减并使 r_n^2 趋于 h^2/t , 这就是重复记录的“收益递减”。习题 15.20 把这条曲线与成本合并, 得到最优测定次数。

推导 15.3 不等记录数与收缩

模型 $y_{ij} = \mu + a_i + p_i + e_{ij}$, $\text{Var}(a) = h^2$, $\text{Var}(p) = t - h^2$, $\text{Var}(e) = 1 - t$ ($V_p = 1$)。个体均值 $\bar{y}_i$ 的方差为 $t + (1 - t)/n_i$, 与 a_i 的协方差为 h^2 , 故 $b_n = h^2/[t + (1 - t)/n] = nh^2/[1 + (n - 1)t]$, 与可靠度数值相等。两个体: 记录数 $n = 1$ 与 $n = 8$, 均值相同时, 指数相差近一倍 (0.200 对 0.386, 习题 15.17)。直接按均值排序等于对所有个体用相同的权重, 会使记录少的个体因随机误差更容易出现极端均值而被过度选中: 原始均值法选中的个体平均只有 2.8 条记录, 而最优指数选中的个体平均 3.7 条记录, 且遗传进展低 3.8%。

拓展阅读 从指数到混合模型与基因组信息

选择指数的思想可追溯到 Smith (1936) 与 Hazel (1943); Henderson (1963, 1975) 证明在已知方差组分时 BLUP 等价于指数, 并把它推广到任意亲缘结构 (第 21 章)。Legarra 等 (2014) 与后续综述指出, 单步 GBLUP 本质上是在统一的协方差结构 H 下做同一件事: 把系谱、表型与标记作为同一向量的不同信息 (第 28 章)。Hill 与 Thompson (1978) 研究参数估计误差, 指出遗传参数的抽样误差使指数的预期增益下降, 但下降通常是二阶小量, 与习题 15.16 的结论一致。

易错辨析

- **准确度不等于记录数**: 13 条同胞记录的可靠度可能不及 2 个自身重复记录; 信息要看协方差结构。
- **权重为负不一定错误**: 它是偏回归系数; 但若由共线性与估计噪声造成, 应稳定化。
- **不同信息来源的个体不能各自标准化后再比较**: z 分数把可靠度差异抹平, 使信息少的个体排名虚高 (习题 15.19)。
- **准确度可以用相关或预测误差表示, 但尺度不同**: 相关无单位, PEV 有单位; 跨性状比较时只能用相关或可靠度。
- **重复测定有上限**: h^2/t , 进一步提高需要“新信息类型” (亲属、基因组) 而不是同一类型的重复。

15.5 习题

一、单项选择题

15.1 ★ [单选] 对只有一条自身记录的候选, 最优指数权重等于

- (A) r_A (B) h (C) h^2 (D) $1 - h^2$

[答案]

15.2 ★ [单选] 选择指数的最优性是指它

- (A) 使指数方差最大 (B) 使指数与育种值的相关最大
(C) 使权重和为 1 (D) 使各记录权重相等

[答案]

15.3 ★★ [单选] 重复力 $t = 0.5$ 、遗传力 $h^2 = 0.3$, 无限次重复测定后可靠度的上限为

- (A) 0.3 (B) 0.5 (C) 0.6 (D) 1

[答案]

15.4 ★★ [单选] 下列哪种做法会使记录数少的个体被系统性“高估”?

- (A) 对不同记录数的个体用同一权重取算术平均
(B) 使用各自的 BLP (C) 增加重复记录
(D) 使用混合模型

[答案]

15.5 ★★ [单选] 两阶段选择中, 阶段 1 的指数是阶段 2 完整指数的子信息, 二者的相关为

- (A) $r_1 r_2$ (B) r_1 / r_2 (C) r_2 / r_1 (D) r_1^2 / r_2

[答案]

15.6 ★★ [单选] 与使用真实参数相比, 用抽样估计的 h^2 构造选择指数, 预期的准确度损失通常

- (A) 与估计误差的一次方成正比 (B) 为估计误差的二阶小量
(C) 为零 (D) 不确定且可为负

[答案]

二、判断与改错题

15.7 ★ [判断] 增加任何一条与育种值相关的新记录, 都不会降低最优指数的可靠度。

[答案]

15.8 ★★ [判断] 同一个体的两次记录, 其相关等于遗传力。

[答案]

15.9 ★★ [判断] 对缺失模式不同的候选, 用各自指数的 z 分数选择, 比直接用预测值更好。 [答案]

15.10 ★★ [判断] 全同胞均值的信息权重总比半同胞均值大, 所以全同胞数目越多越好, 且无上限。 [答案]

三、填空题

15.11 ★ [填空] $V_P = 100$, $V_A = 30$, 候选记录离差为 8, 最优指数值为_____, 可靠度_____, PEV 为_____。 [答案]

15.12 ★ [填空] $h^2 = 0.3$, $t = 0.5$, $n = 4$ 次记录均值的可靠度为_____, 对应的最优权重为_____。 [答案]

15.13 ★ [填空] 公畜在 $h^2 = 0.25$ 下有 30 个无关母畜后代: $k = (4 - h^2)/h^2 =$ _____, 可靠度 $r^2 = n/(n + k) =$ _____。 [答案]

15.14 ★ [填空] $m = 2$ 个候选选一, 期望最大标准正态值为_____。若准确度为 0.6、 $\sigma_A = 2$, 则入选者期望真实育种值为_____。 [答案]

四、计算题

15.15 ★★ [计算] 由系谱构造的多来源选择指数。对 $V_A = 20$ 、 $V_E = 60$ 的性状, 比较“仅自身”“自身 + 母亲”“自身 + 双亲”“自身 + 8 半同胞”“自身 + 4 全同胞 + 8 半同胞”“仅 15 个后代”“自身 + 双亲 + 全部同胞与后代”共 7 种方案的权重、可靠度与准确度, 并用蒙特卡洛核对。 [程序] `ch15/ex15_15_pedigree_index.py` [答案]

15.16 ★★ [计算] 参数估计误差。候选信息为自身、4 个全同胞均值与 8 个半同胞均值 ($h^2 = 0.25$)。 h^2 由 s 头公畜、每头 m 个后代的半同胞 ANOVA 估计 ($s = 20, \dots, 320$; $m = 10, 20, 40$), 重复 400 次, 求用估计参数构造指数的真实准确度及相对效率。 [程序] `ch15/ex15_16_estimation_error.py` [答案]

15.17 ★★ [计算] 不等重复记录数。 $h^2 = 0.2$ 、 $t = 0.45$, 记录数 1、2、3、5、8 的个体占比 0.20、0.25、0.25、0.20、0.10。比较按原始均值与按 BLUP 选前 10% 的真实遗传进展、入选个体的记录数构成与校准斜率。 [程序] `ch15/ex15_17_unequal_records.py` [答案]

15.18 ★★★ [计算] 两阶段选择。阶段 1 指数准确度 $r_1 = 0.5$, 阶段 2 完整指数 $r_2 = 0.7$, 最终入选前 10%。阶段 1 保留比例 $q_1 = 0.2, 0.3, 0.5, 1.0$, 阶段 2 测定成本为阶段 1 的 5 倍或 20 倍。用二元正态积分求反应, 蒙特卡洛核对, 并比较每单位成本的反应。[程序] `ch15/ex15_18_two_stage_selection.py` [答案]

15.19 ★★★ [计算] 记录缺失模式。候选可能有自身 3 次/1 次/0 次记录与母亲记录, 共 6 种模式。比较“BLP 预测值”“标准化 z 分数”“可用记录的原始均值”选前 10% 的真实遗传进展和各模式入选占比。[程序] `ch15/ex15_19_missing_records.py` [答案]

15.20 ★★★ [计算] 信息价值。在 $m = 2, 5, 10$ 个候选中选 1 个, 重复记录的边际收益与成本比较, 求最优测定次数, 并用蒙特卡洛核对期望最大值公式。[程序] `ch15/ex15_20_value_of_information.py` [答案]

15.21 ★ [计算] $V_P = 100$ 、 $V_A = 30$ 。候选自身记录离差 6, 母亲记录离差 10 (母亲与候选加性关系 $\frac{1}{2}$, 母亲记录与候选记录除加性外无共同环境)。求最优权重、预测育种值、可靠度与准确度。[答案]

15.22 ★ [计算] $h^2 = 0.3$ 、重复力 $t = 0.5$ 。求 $n = 1, 2, 4, 10$ 次记录均值的可靠度, 并说明再增加记录最多还能提高多少。[答案]

五、推导与证明题

15.23 ★★ [证明] 证明指数与育种值的相关在 $b = P^{-1}C$ 时最大, 并证明此时 $\text{Var}(I) = \text{Cov}(I, a) = C^T P^{-1} C$ 。[答案]

15.24 ★★ [证明] 公畜有 n 个与随机母畜交配所得、环境独立的后代, 证明其育种值预测的可靠度 $r^2 = n/(n+k)$, $k = (4-h^2)/h^2$ 。[答案]

15.25 ★★ [证明] 证明新增记录使可靠度的增量等于 $\text{Cov}(a, z^*)^2/[V_A \text{Var}(z^*)]$, 并由此说明何时新增信息无用。[答案]

15.26 ★★★ [证明] 设 I_1 是信息集 $y_1 \subset y_2$ 上的 BLP, I_2 是 y_2 上的 BLP, 证明 $\text{Corr}(I_1, I_2) = r_1/r_2$, 其中 $r_j = \text{Corr}(I_j, a)$ 。[答案]

六、综合分析与研究设计题

15.27 ★★ [综合] 某羊场青年种羊的信息有：自身断奶重、母亲多次产羔记录、同父异母同胞断奶重，以及部分个体的基因组分型。设计一个评定方案：如何构造协方差、如何处理分型与未分型个体、如何报告可靠度。 [答案]

15.28 ★★★ [综合] 一个育种公司习惯把每个来源的预测值各自标准化后相加作为“综合得分”。写一份技术评审意见：指出问题、给出反例（用习题 15.19 的结论）并提出替代方案。 [答案]

15.29 ★★★ [综合] 乳牛群中，对新性状“抗病力”的测定昂贵。设计一个两阶段方案：阶段 1 用廉价指示性状，阶段 2 对少数候选测定抗病力。写出需要的参数、优化目标、敏感性分析与验证方法。 [答案]

15.6 参考答案与解析

一、单项选择题

15.1 C。 $b = \text{Cov}(a, y) / \text{Var}(y) = V_A / V_P = h^2$ 。 [题目]

15.2 B。 见推导 15.1。 [题目]

15.3 C。 $h^2/t = 0.6$ 。 [题目]

15.4 A。 统一权重忽略了不同记录数对应的不同收缩，记录少者因误差大更容易出现极端均值。 [题目]

15.5 B。 见习题 15.26。 [题目]

15.6 B。 指数权重在最优点附近对参数是平坦的，一阶损失为零，损失为二阶（习题 15.16： $s = 20$ 、 $m = 10$ 时仅损失 1.4%）。 [题目]

二、判断与改错题

15.7 正确。 新增信息使信息空间变大，投影的平方范数不会减小（推导 15.2）；但“最优指数”要用已知参数；若权重由估计参数得到，可能因估计噪声而略降。 [题目]

15.8 错误。 两次记录的相关是重复力 t ，而 $t \geq h^2$ （含永久环境）；只有 $t = h^2$ （无永久环境）时才等于遗传力。 [题目]

15.9 错误。 z 分数除以各自的 $\sqrt{r^2}$ ，使记录少、预测值本应向均值收缩者被放大；习题 15.19 中， z 分数法的遗传进展 (1.005) 低于 BLP (1.047)。 [题目]

15.10 错误。 同胞共享家系信息，数量增加到一定程度后，增量只来自个体特异的孟德尔抽样信息，边际收益趋于零，可靠度上限由 $\text{Cov}(a, \bar{F})^2 / \text{Var}$ 的极限决定，不是无上限。 [题目]

三、填空题

15.11 $b = 30/100 = 0.3$ ，指数 = 2.4，可靠度 0.3， $\text{PEV} = 30 \times 0.7 = 21$ 。 [题目]

15.12 $r^2 = 4 \times 0.3 / (1 + 3 \times 0.5) = 1.2/2.5 = 0.48$ ；最优权重同为 0.48。 [题目]

15.13 $k = 3.75/0.25 = 15$ ； $r^2 = 30/45 = 0.667$ 。 [题目]

15.14 期望最大值 $1/\sqrt{\pi} = 0.564$ ；入选者期望真实育种值 $0.6 \times 2 \times 0.564 = 0.677$ 。 [题目]

四、计算题

15.15 ($V_A = 20$, $V_E = 60$, $h^2 = 0.25$)

方案	记录数	可靠度	准确度	PEV	MC 准确度
仅自身	1	0.250	0.500	15.00	0.500
自身 + 母亲	2	0.286	0.535	14.29	0.534
自身 + 双亲	3	0.323	0.568	13.55	0.570
自身 + 8 半同胞	9	0.300	0.548	14.00	0.548
自身 + 4 全同胞 + 8 半同胞	13	0.381	0.617	12.39	0.625
仅 15 个后代	15	0.500	0.707	10.00	0.706
自身 + 双亲 + 同胞 + 后代	30	0.629	0.793	7.42	0.792

要点：(1) 双亲信息只提高准确度 0.07，因为双亲只提供“中亲值”这一个方向的信息，且共享遗传相关只有 $\frac{1}{2}$ ；(2) 8 个半同胞加自身仅 0.548，几乎只比自身多 0.05，同胞数的收益递减很快；(3) 15 个后代比 13 条同胞记录更有信息，因为后代的每条记录都直接含候选的一半基因；(4) 全部信息组合后准确度 0.79，但已不可能（后代测定要等到下一代），因此实际评定要在“信息量”与“世代间隔”之间权衡（第 18 章）。方案 5 中权重：自身 0.206，每个半同胞 0.023，每个全同胞 0.064。 [题目]

15.16 真实参数的指数准确度 $\rho = 0.617$ ，权重（自身、全同胞均值、半同胞均值）为 (0.2065, 0.2545, 0.1875)。

m	s	$\hat{h}^2$ 均值	$\hat{h}^2$ SD	$\hat{\rho}$ 均值	相对效率	损失%
10	20	0.234	0.185	0.6081	0.9858	1.42
10	80	0.248	0.093	0.6147	0.9963	0.37
10	320	0.247	0.049	0.6163	0.9990	0.10
20	20	0.239	0.133	0.6123	0.9925	0.75
20	160	0.250	0.048	0.6163	0.9990	0.10
40	20	0.245	0.103	0.6141	0.9955	0.45
40	320	0.249	0.025	0.6168	0.9997	0.03

即使 $\hat{h}^2$ 的 SD 高达 0.185（几乎等于真值），指数准确度也只损失 1.4%；任何情形下都远高于只用自身记录的 0.500。因此“参数不准”不是推迟使用指数的理由；参数估计的误差真正严重之处在于对育种值**不确定性**（PEV）的报告与不同方案的决策阈值。

[题目]

15.17

n	b_n (= 可靠度)	准确度	MC $r(\bar{y}, a)$	校准斜率
1	0.200	0.447	0.441	0.995
2	0.276	0.525	0.527	1.001
3	0.316	0.562	0.559	0.994
5	0.357	0.598	0.598	1.004
8	0.386	0.621	0.614	0.995

选前 10%：原始均值法真实育种值均值 0.4113，入选个体平均 2.80 条记录（1 次记录者占 29%）；BLUP 法 0.4268，平均 3.68 条记录（1 次记录者占 12%）。BLUP 多获得 3.8% 的遗传进展。BLP 的校准斜率均接近 1，意味着“预测 1 个单位，真实就多 1 个单位”；原始均值则不具备这种校准性——在记录少的个体上它系统性地夸大差异。

[题目]

15.18 ($r_1 = 0.5$ 、 $r_2 = 0.7$ 、 $p = 0.1$)

q_1	R/σ_A 数值	MC	阶段 2 阈值	成本 ($\kappa=5$)	$R/\text{成本}$	成本 ($\kappa=20$)	$R/\text{成本}$
0.2	1.1320	1.1290	0.987	2.00	0.566	5.00	0.226

q_1	R/σ_A 数值	MC	阶段 2 阈值	成本 ($\kappa=5$)	$R/\text{成本}$	成本 ($\kappa=20$)	$R/\text{成本}$
0.3	1.1868	1.1863	1.153	2.50	0.475	7.00	0.170
0.5	1.2197	1.2192	1.252	3.50	0.349	11.00	0.111
1.0	1.2285	1.2295	1.282	6.00	0.205	21.00	0.059

阶段 1 只留 20%，反应仅比不分阶段（1.2285）低 7.9%，却把阶段 2 测定量降到五分之一，成本在 $\kappa = 20$ 时降低 76%，每单位成本的反应提高近 4 倍。要点：二元正态积分与蒙特卡洛一致（差 <0.003 ）；两阶段选择的反应永远不超过单阶段完整信息，其优势全在成本。 [题目]

15.19

模式	占比	权重（自身，母亲）	可靠度	MC r^2
自身 3 次 + 母亲	0.25	(0.443, 0.080)	0.483	0.487
自身 3 次	0.20	(0.462, 0)	0.462	0.464
自身 1 次 + 母亲	0.20	(0.271, 0.104)	0.323	0.321
自身 1 次	0.15	(0.286, 0)	0.286	0.290
仅母亲	0.10	(0, 0.143)	0.071	0.074
无记录	0.10	—	0	0

方法	入选真实育种值均值	模式 1	2	3	4	5	6
(A) BLP	1.0470	0.376	0.282	0.205	0.134	0.003	0
(B) 标准化 z	1.0047	0.282	0.217	0.223	0.169	0.109	0
(C) 原始均值	0.9026	0.192	0.207	0.191	0.247	0.163	0

z 分数让“仅母亲”（可靠度只有 0.07）的个体占入选者的 11%，而 BLP 几乎不选它们（0.3%）；原始均值法更糟，遗传进展低 14%。BLP 预测值已经内含收缩，是不同信息个体之间唯一的“同一尺度”。结论：跨模式比较必须用预测值（EBV），并同时报告可靠度，而不是比较“得分”。 [题目]

15.20 $h^2 = 0.25$ 、 $t = 0.4$ ，价值 $1000/\sigma_A$ 、每次记录成本 6。 $m = 2$ 时 $E[\max] = 0.564$ ； $m = 5$ 时 1.163； $m = 10$ 时 1.539。蒙特卡洛核对（ $n = 3$ ）：理论与模拟差值均小于 0.009。 $m = 2$ 时可靠度依次为 0.250、0.357、0.417、0.455、0.481（ $n = 1, \dots, 5$ ），第 n 次记录的边际收益依次为 282、55、27、16、11（ $n = 1, \dots, 5$ ），每多测一次全部候选的成本为 12，边际收益在第 5 次降到成本以下，最优测定次数 $n^* = 4$ （净收益

332); $m = 5$ 时 $n^* = 4$ (664); $m = 10$ 时 $n^* = 3$ (813)。可靠度上限 $h^2/t = 0.625$, 准确度上限 0.791。候选越多, 选择强度越大, 每条记录的边际价值越高, 但每个候选的测定成本按 m 线性增长, 所以最优 n^* 对 m 并不单调。 [题目]

15.21 $P = \begin{pmatrix} 100 & 15 \\ 15 & 100 \end{pmatrix}, C = (30, 15)^T, \det = 9775, b_1 = (100 \times 30 - 15 \times 15) / 9775 = 0.2839,$
 $b_2 = (100 \times 15 - 15 \times 30) / 9775 = 0.1074$ 。预测育种值 $= 0.2839 \times 6 + 0.1074 \times 10 = 2.78$ 。
 可靠度 $= (0.2839 \times 30 + 0.1074 \times 15) / 30 = 0.338$, 准确度 0.581 (只用自身为 0.548)。
 [题目]

15.22 $r_n^2 = 0.3n / (1 + 0.5(n-1))$: $n = 1$ 为 0.300; $n = 2$ 为 0.400; $n = 4$ 为 0.480; $n = 10$ 为 0.545。上限 $0.3/0.5 = 0.6$ 。 $n = 10$ 已达到上限的 91%, 再增加记录最多只能提高 0.055。
 [题目]

五、推导与证明题

15.23 见推导 15.1。令 $b = P^{-1}C$, 则 $\text{Var}(I) = b^T P b = C^T P^{-1} P P^{-1} C = C^T P^{-1} C$, $\text{Cov}(I, a) = b^T C = C^T P^{-1} C$, 两者相等——这正是“无偏预测”(回归斜率为 1) 的含义: a 对 I 的回归系数 $\text{Cov}(a, I) / \text{Var}(I) = 1$ 。
 [题目]

15.24 后代均值 $\bar{o}$ 的方差为 $V_A/4 + (V_P - V_A/4)/n$ (环境独立、母畜随机, 后代间只共享公畜加性效应的一半即 $\frac{1}{4}V_A$ 的方差), 与公畜育种值的协方差为 $\frac{1}{2}V_A$ 。 $r^2 = \frac{(V_A/2)^2}{V_A[V_A/4 + (V_P - V_A/4)/n]} = \frac{1/4}{1/4 + (1/h^2 - 1/4)/n} = \frac{n}{n + (4 - h^2)/h^2}$ 。
 [题目]

15.25 见推导 15.2。设 $y_2 = (y_1, z)$, $z^* = z - \gamma^T y_1$ 与 y_1 不相关。 y_2 张成的空间等于 $\text{span}(y_1, z^*)$ 且两个分量正交, 故 $\hat{a}_2 = \hat{a}_1 + \text{Cov}(a, z^*) z^* / \text{Var}(z^*)$, $\text{Var}(\hat{a}_2) = \text{Var}(\hat{a}_1) + \text{Cov}(a, z^*)^2 / \text{Var}(z^*)$ 。当 $\text{Cov}(a, z^*) = 0$ (新记录对旧记录的残差与育种值无关) 或 $\text{Var}(z^*) = 0$ (完全冗余) 时无用。
 [题目]

15.26 I_1 是 a 在 y_1 上的正交投影, I_2 在 y_2 上。因 $y_1 \subset y_2$, I_1 也是 I_2 在 y_1 上的投影, 所以 $\text{Cov}(I_1, I_2) = \text{Var}(I_1)$ (两者都在 y_2 中, $I_2 - I_1 \perp y_1$)。又 $\text{Var}(I_j) = \text{Cov}(a, I_j) = r_j^2 V_A$,
 $\text{Corr}(I_1, I_2) = \frac{r_1^2 V_A}{r_1 \sqrt{V_A} r_2 \sqrt{V_A}} = \frac{r_1}{r_2}$ 。
 [题目]

六、综合分析与研究设计题

15.27 方案: (1) 建立统一的协方差结构: 对未分型个体用系谱 A , 对分型个体用单步 H (第 28 章), 把自身、母亲、同胞的所有记录放入同一个混合模型, 让模型自动给

出权重；(2) 重复记录用重复力模型，不能把多次产羔直接平均；(3) 输出每只羊的 EBV 与可靠度（或 PEV），并在不同信息模式（有无分型、有无母亲记录）下检验校准斜率；(4) 解释时分层报告：可靠度低于阈值（如 0.3）的个体不参与排名或标注为“待验证”；(5) 验证：用后续记录做前瞻性验证，比较预测与实测的相关与回归斜率（第 29 章）；(6) 习题 15.15 的数值说明：同胞信息的边际收益递减，基因组信息的价值在于提供“孟德尔抽样”这一系谱不能给的部分。 [题目]

15.28 问题：把每个来源标准化会改变信息的相对权重：可靠度低的来源被放大，使排名对噪声敏感；各来源之间的重复信息（同一祖先的信息出现在多个来源）会被重复计数。**反例：**习题 15.19 中，“仅母亲”的候选可靠度仅 0.07，却在 z 分数法选出的前 10% 中占 11%，遗传进展较 BLP 低 4%；原始均值法低 14%。**替代方案：**(1) 所有来源在统一的混合模型/指数中联合估计，输出 EBV 与可靠度；(2) 若来源在不同数据集中，使用“信息贡献分解”（第 28 章）估计各来源的有效权重；(3) 排名依据是 EBV，可靠度用于风险管理（如用 $EBV - \lambda \cdot SE$ 的保守得分， λ 由决策者偏好决定）；(4) 用外部验证与回归斜率检验“综合得分”的校准性。 [题目]

15.29 方案：(1) 参数：指示性状与抗病力的遗传力、遗传相关、阶段 2 的成本比 κ 、终选比例；(2) 阶段 1 准确度（只用个体指示记录时） $r_1 = h_I r_A$ ，阶段 2 包含抗病力测定后 r_2 由习题 15.15 的指数公式给出，二者相关 r_1/r_2 ；(3) 优化：对每个 q_1 计算反应 $R(q_1)$ 与成本 $1 + q_1 \kappa$ ，最大化“净收益”= $V \cdot R - \text{成本}$ ；习题 15.18 显示，当 κ 较大时最优 q_1 在 0.2—0.3，反应仅损失约 5%—8%，成本降低 60% 以上；(4) 敏感性：对 r_A （不确定度 ± 0.15 ）、 κ 与 h^2 做场景分析，检查最优 q_1 是否稳定；(5) 验证：在阶段 1 候选的随机子样（如 5%）上同时测抗病力，估计“未被测定者”的真实表现，从而检验阶段 1 筛选是否过度偏向某些环境；(6) 关注 Bulmer 效应与近交：初筛后留种数少，注意 N_e （第 19 章）。 [题目]

多性状育种目标与经济权重

16.1 本章导学

学习目标

1. 区分育种目标 $H = a^T u$ 与选择指数 $I = b^T y$ ，理解经济权重 a 与指数权重 b 回答的是不同问题。
2. 能在记录性状与目标性状不同的情形下正确构造 P 、 C ，求解 $Pb = Ca$ ，并把综合响应分解为各性状响应。
3. 能由生物经济模型求局部经济权重，理解系统边界（固定羊群、固定资源、固定产品需求）如何改变权重，掌握隐函数与伴随公式。
4. 能用状态转移矩阵与折现计算寿命、存活等跨期表达性状的价值，能把阈值性状的经济权重在潜在尺度与观察尺度之间转换。
5. 理解单位变换、标准化与“贡献百分比”的约定性，能从经验积分反推隐含经济权重。
6. 能评价经济权重与遗传参数误设的后果，用敏感性分析、切换点和版本分解解释排名变化。

重点与难点

重点： $b = P^{-1}Ca$ 与 $\Delta u = iC^T b / \sigma_I$ ；经济权重的边际定义；系统边界；单位与标准化；跨期价值。

难点： 负经济权重不保证性状下降；同一性状在不同边界下权重不同；比率与残差性状的重复计价；潜在尺度权重随发病率变化；权重误设损失由 $B = C^T P^{-1} C$ 度量下的方向决定，而非由相对误差大小决定。

本章把第 15 章的单性状与多性状指数推广为面向生产系统的育种目标。第 17 章将在本章基础上加入限制条件、非线性价值与稳健决策；第 18 章把单代响应转为年度进展与长期规划；第 21—23 章的多性状 BLUP 只是把本章的 $b^T y$ 换成 $a^T \hat{u}$ ，目标定义部分完全相同。

16.2 知识结构图




图 16.1 第 16 章知识结构图

右侧前两支讨论“指数如何计算与解释”，右侧后两支与左侧各支讨论“经济权重从哪里来、如何约定、如何检验与更新”。

16.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
育种目标	$H = a^T u, \sigma_H^2 = a^T \Sigma_u a$	u 为目标性状加性育种值
指数方程	$Pb = Ca$	$C = \text{Cov}(y, u)$, 仅自身全部目标性状记录时 $C = \Sigma_u$
指数准确度	$r_{IH} = \sigma_I / \sigma_H,$ $\sigma_I^2 = b^T Pb = b^T Ca$	仅对最优指数成立
各性状响应	$\Delta u = iC^T b / \sigma_I,$ $\Delta H = a^T \Delta u = i\sigma_I$	条件均值线性、按指数截留
局部经济权重	$a_j = \partial \Pi / \partial \mu_j$	指定系统边界与基线
隐函数权重	$a = \Pi_\mu - F_\mu^T F_x^{-T} \Pi_x$	平衡方程 $F(x, \mu) = 0$, F_x 可逆
包络性质	$V_\mu = \Pi_\mu,$ $V_{\mu\mu} = \Pi_{\mu\mu} - \Pi_{\mu x} \Pi_{xx}^{-1} \Pi_{x\mu}$	光滑内部最优管理
状态价值	$v = (I - \delta T)^{-1} r$	$\rho(\delta T) < 1$

概念	公式或定义	成立条件与提示
跨期权重	$a_j = \alpha^T(I - \delta T)^{-1}(r_j + \delta T_j v)$	初始分布不随性状变化时
阈值性状权重	$a_\mu = -L \phi(t_0 - \mu)$	残差标准化的责任度尺度
单位变换	$u^* = Du \Rightarrow a^* = D^{-1}a$	标准化尺度权重为 $a_j \sigma_{u_j}$
比率近似	$\Delta(F/W) \approx \Delta F/W - F\Delta W/W^2$	小变化
隐含权重	$a = C^{-1}Pb_0$	C 方阵可逆, 只确定到比例
误设效率	$\frac{R(a, \tilde{a})}{R(a, a)} = \frac{a^T B \tilde{a}}{\sqrt{a^T B a} \sqrt{\tilde{a}^T B \tilde{a}}}$	$B = C^T P^{-1} C$

16.4 补充内容与公式推导

推导 16.1 两条路径得到同一指数: 最小均方误差与最大目标响应

均方误差路径。 $E[(H - b^T y)^2] = \sigma_H^2 - 2b^T g + b^T P b$, 其中 $g = \text{Cov}(y, H) = Ca$ 。对 b 求导令其为零得 $Pb = g$; P 正定保证这是唯一极小。

响应路径。 对任意非零 b , 按 I 截留时 $\Delta H = i b^T g / \sqrt{b^T P b}$ 。令 $w = P^{1/2} b$, 则 $b^T g = w^T P^{-1/2} g$, 由柯西不等式

$$\frac{b^T g}{\sqrt{b^T P b}} = \frac{w^T (P^{-1/2} g)}{\|w\|} \leq \sqrt{g^T P^{-1} g},$$

等号当且仅当 $w \propto P^{-1/2} g$, 即 $b \propto P^{-1} g$ 。两条路径方向一致, 但响应路径只确定方向, 任何正比例缩放都给出同一排序——这正是“指数权重本身没有绝对单位意义”的数学根源。

响应分解。 由 $\text{Cov}(u, I) = C^T b$ 得 $\Delta u = i C^T b / \sigma_I$ 。代入最优 b , $\Delta u = i B a / \sqrt{a^T B a}$, $B = C^T P^{-1} C$ 是目标育种值被现有记录线性预测部分的协方差矩阵。第 j 个性状响应的符号由 $(Ba)_j$ 决定, 而不是由 a_j 的符号决定: 若 B_{jk} 为正且 a_k 很大, 即使 $a_j < 0$, 第 j 性状仍可能上升。习题 16.19 的猪例中, 采食权重在 -60 附近时采食响应已接近零, 参数稍有误差就可能转正。

推导 16.2 资源约束下的经济权重等于“按影子价格计价”的权重

设母羊数 N 由饲草平衡 $F(N, \mu) = Nf(\mu) - R = 0$ 决定, 利润 $\Pi = N m(\mu)$, m 为不含饲料现金成本的每只母羊净收益。隐函数定理给出 $\partial N / \partial \mu = -F_N^{-1} F_\mu = -N \nabla f / f$,

于是

$$\begin{aligned} a &= \Pi_\mu + \Pi_N \frac{\partial N}{\partial \mu} = N \nabla m - m \frac{N \nabla f}{f} \\ &= N(\nabla m - \lambda \nabla f), \quad \lambda = \frac{m}{f}. \end{aligned}$$

λ 是伴随方程 $F_N \lambda = \Pi_N$ 的解, 含义为“一千克饲草的边际价值”(影子价格)。因此, 固定资源边界下的权重恰好等于“羊群固定、饲料按价格 λ 购买”时的权重。两种边界之所以给出不同数值, 唯一原因是市场饲料价格 p_f 与影子价格 λ 不等: $\lambda > p_f$ 时资源稀缺, 所有增加饲料占用的性状(成年体重、产羔数中的羔羊饲料部分)在固定资源边界下受到更大惩罚。习题 16.16 中 $\lambda = 0.486$, 高于市场价 0.40, 成年体重的权重由 -2.30 变为 -2.80。这一等价关系也给出防止重复计价的检验: 若利润函数已含饲料现金成本, 又加上资源约束, 影子价格就只应反映“超出市场价的稀缺性”。

推导 16.3 跨期性状的权重: 状态转移矩阵求导

价值方程 $v = r + \delta T v$ 两边对性状均值 μ_j 求导: $v_j = r_j + \delta T_j v + \delta T v_j$, 整理得

$$v_j = (I - \delta T)^{-1} (r_j + \delta T_j v), \quad a_j = \alpha^T v_j.$$

若功能性存活在潜在尺度上提高 μ , 各转移概率为 $s_k(\mu) = \Phi(t_k + \mu)$, 则 T_μ 在原非零位置上的元素为 $\phi(t_k)$ 。存活率越接近 0.5, 同样的潜在改良带来越大的概率变化。逆矩阵 $(I - \delta T)^{-1} = \sum_t (\delta T)^t$ 汇集了“多存活一期又带来后续各期机会”的递归作用, 这就是早期胎次存活权重远大于后期胎次存活权重的原因(习题 16.17: 第 1 胎存活每概率单位值 2748.93, 第 4 胎只有 706.75)。若疾病已经通过 r_j (当期损失) 与 T_j (淘汰增加) 进入模型, 再追加疾病总费用就是重复计价。

推导 16.4 阈值性状的权重为何随发病率变化

责任度 $\ell \sim N(\mu, 1)$, $p(\mu) = 1 - \Phi(t_0 - \mu)$, 期望损失 Lp 。于是 $\partial(Lp)/\partial\mu = L\phi(t_0 - \mu)$, 责任度权重 $a_\mu = -L\phi(t_0 - \mu)$ 。在 $t_0 = 0$ (发病率 50%) 处 ϕ 最大, 权重绝对值最大; 发病率越低, $\phi(t_0)$ 越小。另一方面 $p(\mu)$ 在 $p < 0.5$ 一侧是 μ 的凸函数 ($p'' = -(t_0 - \mu)\phi \cdot (-1) > 0$), 所以降低责任度时线性近似总是高估节省, 提高责任度时线性近似低估损失。观察尺度的权重恒为 $-L$ (每概率单位), 二者的转换系数 $\phi(t_0)$ 正是 Dempster-Lerner 公式 $h_{\text{obs}}^2 = h_c^2 \phi(t_0)^2 / [p(1-p)]$ 中出现的同一个量: 评定尺度与计价尺度必须用同一个转换系数衔接, 不能把潜在尺度育种值直接乘以每例损失。

拓展阅读 环境性状与指数更新的近期证据

González-Recio 等 (2020) 以西班牙荷斯坦牛生物经济情景说明, 给甲烷负经济权重并不必然使单牛排放下降, 与生产性状的正相关可使绝对排放仍增加而强度改善, 这与推导 16.1 的结论一致。Ryan 等 (2025) 用 1508 头肉牛的甲烷表型估计参数, 在爱尔兰终端指数中比较不同碳价情景, 预测日排放响应在下降 0.22 g 至 4.20 g 之间变化, 强调目标定义与价格情景同样重要。Cole 与 VanRaden (2018) 讨论了基因组时代选择指数更新的频率与透明度问题, 主张保存旧指数下的排名以便区分“评定变化”与“目标变化”, 与习题 16.20 的版本分解思路相通。这些研究都是参数支持下的预测分析, 不能转述为已实现的减排或增益。

易错辨析

- **经济权重 $\neq$ 指数权重**: a 只属于目标性状, b 属于记录; 指示性状可以有很大的 b 却没有任何 a 。
- **负权重 $\neq$ 下降**: 性状响应由 Ba 决定; “必须不增加”应写成限制条件 (第 17 章)。
- **销售单价 $\neq$ 经济权重**: 权重是指定边界下净收益的边际变化, 须扣除实现该变化的边际成本, 并说明管理是否随之调整。
- **比率、残差与组成性状不可同时计价**: 已对产出与耗料分别计价, 再给饲料转化率或剩余采食量独立权重即重复计价。
- **贡献百分比不唯一**: 性状相关时, 对角项比例之和不等于 1; “每遗传标准差价值”也不是该性状对响应的独立贡献。

16.5 习题

一、单项选择题

16.1 ★ [单选] 关于经济权重 a 与指数权重 b , 下列说法正确的是

- (A) 二者维数必定相同
- (B) 记录性状若不属于目标, 则其 b 必为零
- (C) a 描述目标性状单位改变的价值, b 描述记录对预测目标的作用
- (D) 遗传力低的性状应降低其 a

[答案]

16.2 ★ [单选] 原目标 $H = 0.8u_1 - 15u_2$, u_1 为日增重 (g/d), u_2 为背膘 (mm)。若把日增重改用 kg/d 记录, 要保持同一目标, u_1 的权重应为

- (A) 0.0008 (B) 0.8 (C) 800 (D) 不需要改变

[答案]

16.3 ★★ [单选] 将各性状育种值标准化为 $z_j = u_j/\sigma_{u_j}$ 后, 若要表示与原目标完全相同的 H , z_j 的权重应为

- (A) a_j (B) a_j/σ_{u_j} (C) $a_j\sigma_{u_j}$ (D) $a_j\sigma_{u_j}^2$

[答案]

16.4 ★★ [单选] 固定饲草总量的放牧系统中, 母羊成年体重增加使每只母羊维持需要上升。与“羊群头数固定、饲料按市场价购买”的边界相比, 若饲草影子价格高于市场价, 成年体重的经济权重

- (A) 绝对值更小 (B) 绝对值更大 (更负) (C) 完全相同
(D) 符号改变为正

[答案]

16.5 ★★ [单选] 某疾病以残差标准化的责任度尺度评定。若责任度均值下降同样的 0.1 个单位, 期望减少病例最多的基线发病率是

- (A) 2% (B) 10% (C) 30% (D) 50%

[答案]

16.6 ★★ [单选] 用真实目标 a 评价时, 下列哪种经济权重误设不会造成任何响应损失?

- (A) 把全部权重同乘以 10 (B) 把一个权重的符号弄反
(C) 只把采食权重提高 30% (D) 删去一个性状的权重

[答案]

二、判断与改错题

16.7 ★ [判断] 只要给耗料性状足够大的负经济权重, 选择后耗料的遗传均值就一定下降。

[答案]

16.8 ★ [判断] 低遗传力性状难以改良, 因此在育种目标中应给予较低的经济权重。

[答案]

16.9 ★★ [判断] 目标已经分别对胴体产出、成熟体重和实际采食计价，再加入由这些变量回归得到的剩余采食量并赋予独立经济权重，可以更完整地表达饲料效率的价值。 [答案]

16.10 ★★ [判断] 两个目标性状遗传负相关而权重同号时，把各自“ $a_j^2 \sigma_{u_j}^2$ 除以 σ_H^2 ”得到的比例之和可能大于 1。 [答案]

三、填空题

16.11 ★ [填空] 某育肥猪群平均耗料 $F = 280$ kg、增重 $W = 100$ kg，饲料转化率 $Q = F/W = 2.8$ 。若耗料增加 10 kg、增重增加 8 kg，一阶近似 $\Delta Q \approx$ _____，准确变化为 _____；比率下降说明 _____（填“总耗料一定下降”或“不能判断总耗料方向”）。 [答案]

16.12 ★ [填空] 某性状在未来第 1、2、4 年各表达一次，每次价值 50，表达概率依次为 1、0.85、0.70，年贴现率 8%。有效权重为 _____（保留两位小数），它小于 150 的原因是 _____ 与 _____。 [答案]

16.13 ★ [填空] 设碳价为每吨二氧化碳当量 60 个价值单位，甲烷当量换算系数取 27，则每千克甲烷的直接价值权重为 _____；若性状记录为日排放量（g/d），按一年 365 天计，每 g/d 的年度权重为 _____。 [答案]

16.14 ★ [填空] 两性状目标 $a = (3, -1)^T$ ，遗传方差为 25 与 16，遗传协方差为 12。 $\sigma_H^2 =$ _____；两个对角项之和为 _____；交叉项为 _____。 [答案]

四、计算题

16.15 ★★ [计算] 指示性状指数。 肉羊终端父系的目标为胴体瘦肉重与胴体脂肪重（ $a = (12, -6)^T$ ，元/kg），候选个体有自身 120 日龄体重、超声背膘厚、超声眼肌深记录，以及 20 只父系半同胞屠宰后的胴体瘦肉重均值（参数见配套数据）。保留 10%。（1）构造 P （ 4×4 ）与 C （ 4×2 ），求 b 、 r_{IH} 与各性状预期响应；（2）逐一删去每个信息源，比较目标响应的损失；（3）若直接把经济权重套在“看起来对应”的记录上（体重 → 瘦肉、背膘 → 脂肪），效率是多少？ [程序] ch16/ex16_15_indicator_index.py

[答案]

- 16.16 ★★ [计算] 生物经济模型与系统边界。**放牧母羊系统: 产羔数 1.60、羔羊存活率 0.88、羔羊出售活重 38 kg、成年母羊体重 65 kg; 每只母羊年饲料 $f = 21.8M^{0.75} + 4nsW$ (kg 干物质)。(1) 在“300 只母羊固定、饲料每千克 0.40”的边界下求四性状经济权重;(2) 在“饲草总量固定、母羊数随需要调整”的边界下, 用隐函数公式求权重, 并用重新满足平衡的中心差分核验;(3) 比较两套权重与每遗传标准差价值, 计算有限改变的准确收益与线性近似。[程序] `ch16/ex16_16_bioeconomic_weights.py` [答案]
- 16.17 ★★ [计算] 胎次状态与终生价值。**奶牛第 1—4 胎与第 5 胎及以后共 5 个状态, 各胎净收益与进入下一胎的存活率见配套数据, 年贴现率 6%。(1) 求各状态价值与初产牛终生折现价值、期望泌乳期数;(2) 功能性存活在潜在尺度上提高 1 个单位的经济权重, 并用差分核验;(3) 分别计算每一胎次存活率提高一个概率单位的价值, 解释其大小顺序;(4) 计算有限期限 3、5、8、12、20 期的价值与尾项。[程序] `ch16/ex16_17_lifetime_value.py` [答案]
- 16.18 ★★ [计算] 阈值性状的权重。**临床乳房炎每例净损失 1800, 潜在尺度遗传力 0.10。(1) 基线发病率为 2%、5%、10%、20%、35%、50% 时, 求责任感权重、每潜在遗传标准差价值与观察尺度遗传力;(2) 基线 10% 时比较责任感改变 ± 0.1 、 ± 0.3 、 -0.6 的准确价值与线性近似;(3) 从发病率 30% 起每代责任感下降 0.08, 比较 15 代内的准确节省与按初始权重线性外推的结果。[程序] `ch16/ex16_18_liability_weight.py` [答案]
- 16.19 ★★★ [计算] 权重误设与参数不确定性。**猪测定站以自身日增重、背膘、日采食为记录与目标, $a = (0.30, -4.0, -60)^T$, $i = 1.6$ 。(1) 求各性状响应与 Jacobian $\partial \Delta u / \partial a^T$, 验证 $Ja = 0$;(2) 比较采食价格低估或高估 30%、忽略采食、背膘符号错误、全部权重乘以 10 时的效率, 并与二阶近似比较;(3) 采食权重按变异系数 30% 的对数正态波动时固定指数的效率分布;(4) 遗传与残差协方差以自由度 120 的 Wishart 分布抽样时, 固定指数下采食上升的概率。[程序] `ch16/ex16_19_weight_sensitivity.py` [答案]
- 16.20 ★★★ [计算] 隐含权重与版本分解。**某肉牛品种协会长期使用经验积分 $b_0 = (0.5, 0.3, 8)$ 对断奶重、周岁重、超声肌肉脂肪排序。(1) 求经验积分隐含的经济权重;(2) 以生物经济目标 $a = (1.2, 2.0, 60)$ 评价经验积分的效率;(3) 给出目标方差的对角比例、协方差均分比例与标准化强调三种“贡献”;(4) 旧版本只用断奶重、周岁重且权重为 $(2.5, 2.0, 20)$, 新版本加入超声记录并采用新权重,

以新目标评价, 把响应变化分解为“信息”与“权重”两部分, 并在 3000 头模拟候选中比较入选名单的重合率。[程序] `ch16/ex16_20_implied_weights.py` [答案]

- 16.21** ★ [计算] 固定出栏体重的育肥系统, 需增重 $D = 60$ kg, 每日维持饲料 1.6 kg, 每千克增重另需 2.8 kg 饲料, 饲料每千克 2.5, 栏位每日费用 1.2。基线日增重 0.9 kg/d。求: (1) 总耗料与饲养天数; (2) 日增重的局部经济权重 (每 kg/d); (3) 日增重提高到 1.0 kg/d 的准确节省与线性近似。 [答案]

- 16.22** ★ [计算] 两性状自身记录指数, $P = \begin{pmatrix} 40 & 8 \\ 8 & 10 \end{pmatrix}$, $C = \Sigma_u = \begin{pmatrix} 12 & 3 \\ 3 & 4 \end{pmatrix}$, $a = (1, -2)^T$, $i = 1.4$ 。手算 b 、 σ_I 、 r_{IH} 、各性状响应与 ΔH , 并验证 $\Delta H = i\sigma_I$ 。 [答案]

五、推导与证明题

- 16.23** ★★ [证明] 证明 $b = P^{-1}Ca$ 既最小化 $E[(H - I)^2]$, 又在所有非零线性指数中最大化 ΔH ; 并证明对最优指数 $\sigma_I^2 = b^T Ca$ 、 $r_{IH} = \sigma_I / \sigma_H$ 。 [答案]

- 16.24** ★★ [证明] 设系统状态 x 由 $F(x, \mu) = 0$ 决定, 证明经济权重 $a = \Pi_\mu - F_\mu^T \lambda$, 其中 $F_x^T \lambda = \Pi_x$; 并对“饲草总量固定”的母羊模型证明: 其权重等于把饲料按影子价格 $\lambda = m/f$ 计价时固定羊群边界的权重。 [答案]

- 16.25** ★★ [证明] 在暂态转移矩阵模型 $v = (I - \delta T)^{-1}r$ 中, 证明 $\partial V / \partial \mu_j = \alpha^T (I - \delta T)^{-1} (r_j + \delta T_j v)$; 并就“只有第 1 期存活率 s_1 改变”的链状模型说明, 为什么它的权重等于 δv_2 。 [答案]

- 16.26** ★★★ [证明] 设 B 正定, $s^2 = a^T B a$ 。(1) 证明 $\partial \Delta u / \partial a^T = i[B/s - (Ba)(Ba)^T / s^3]$ 且该矩阵乘以 a 为零; (2) 证明用 $a + \varepsilon$ 构造指数时, 响应损失的二阶近似为 $\frac{i}{2s} \varepsilon_\perp^T B \varepsilon_\perp$ 。 [答案]

六、综合分析与研究设计题

- 16.27** ★★ [综合] 某奶山羊联合育种计划希望把“甲烷排放”纳入育种目标, 但只有少数核心场可以测定甲烷, 商业场仅有奶量、乳成分、体重与采食行为记录。请设计目标定义、记录与指示性状的分工、经济或社会权重的来源, 以及在发布前必须完成的检验。 [答案]

16.28 ★★★ [综合] 某肉羊育种公司同时出售终端父系公羊与母系公羊。商品户大多不留女儿，而合作社用户大量保留女儿。请说明为何需要两个指数，指出两个指数在目标性状、经济权重、表达次数与系统边界上的差别，并设计向用户解释“同一公羊在两个指数中排名不同”的报告。 [答案]

16.29 ★★★ [综合] 全国奶牛总性能指数准备同时进行两项更新：饲料价格基准上调，并加入一种新的乳中红外健康指示性状。上一版本的排名已被广泛使用。请设计一个更新与发布方案，使用户能够区分“遗传评定变化”与“目标定义变化”，并评估更新的稳健性。 [答案]

16.6 参考答案与解析

一、单项选择题

16.1 C。 a 的维数是目标性状数 q ， b 的维数是记录数 m ，二者一般不同；记录不属于目标时仍可通过 C 获得非零 b （习题 16.15 中半同胞均值的权重最大）；遗传力影响 b 与准确度，不影响 a 。 [题目]

16.2 C。 u_1 的数值缩小为原来的 $1/1000$ ($1 \text{ g/d} = 0.001 \text{ kg/d}$)，为保持 $a_1 u_1$ 不变，权重须扩大 1000 倍，即 $a_1^* = 800$ 每 kg/d 。 [题目]

16.3 C。 $H = \sum_j a_j u_j = \sum_j (a_j \sigma_{u_j}) z_j$ 。直接对 z_j 使用原 a_j 等于改变了目标。 [题目]

16.4 B。 由推导 16.2，固定资源边界的权重等于以影子价格 λ 计价饲料的权重； $\lambda > p_f$ 时饲料占用的惩罚更重。习题 16.16 中由 -2.30 变为 -2.80 。 [题目]

16.5 D。 期望病例减少约为 $\phi(t_0) \times 0.1$ ， ϕ 在 $t_0 = 0$ （发病率 50%）处最大。 [题目]

16.6 A。 效率是 B 度量下 a 与 $\tilde{a}$ 的夹角余弦，正比例缩放不改变方向（习题 16.19：效率 1.0000）。 [题目]

二、判断与改错题

16.7 错误。 性状响应为 $i(Ba)_j/s$ ，与其他性状的遗传协方差及其权重有关。若耗料与高权重的产出性状正相关，惩罚再大也可能不足以抵消相关响应，且参数稍变就可能改变方向（习题 16.19：采食权重 -60 时采食上升的概率仍有 0.203）。若管理要求“不得增加”，应改为限制指数或期望改良量方法（第 17 章）。 [题目]

16.8 错误。经济权重只反映目标性状一个单位改变的价值，与遗传力无关。低遗传力影响的是预测准确度与指数权重 b ，最优指数会自动根据信息质量分配权重。人为压低 a 等于改变目标，往往造成繁殖、健康等低遗传力但高价值性状长期被忽视。

[题目]

16.9 错误。剩余采食量是采食减去由产出与体重预测部分的线性组合，其价值已经包含在三项组成性状的权重中，再单独计价属于重复计价。可以选择组成性状目标或经过代数等价变换的目标，但不能叠加。此外表型残差与预测变量表型不相关，不等于遗传上不相关，相关响应仍需计算。

[题目]

16.10 正确。 $\sigma_H^2 = \sum a_j^2 \sigma_j^2 + 2 \sum_{j < k} a_j a_k \sigma_{jk}$ 。权重同号而遗传负相关（或权重异号而遗传正相关）时交叉项为负，对角项之和大于总方差，比例和大于 1。填空题 16.14 与习题 16.20 都是这种情形。

[题目]

三、填空题

16.11 $\Delta Q \approx 10/100 - 280 \times 8/100^2 = -0.124$ ；准确变化 $290/108 - 2.8 = -0.1148$ ；不能判断总耗料方向（本例总耗料实际增加了 10 kg）。

[题目]

16.12 $50/1.08 + 50 \times 0.85/1.08^2 + 50 \times 0.70/1.08^4 = 108.46$ ；时间贴现与表达概率（存活）。

[题目]

16.13 $-60 \times 27/1000 = -1.62$ 每千克甲烷； $-1.62 \times 0.365 = -0.591$ 每 g/d 每年。换算系数与核算口径属于情景设定，须在报告中注明。

[题目]

16.14 $\sigma_H^2 = 9 \times 25 + 16 - 2 \times 3 \times 12 = 169$ ；对角项之和 241；交叉项 -72。对角比例之和为 1.43，再次说明“百分比贡献”需要约定。

[题目]

四、计算题

16.15 (1) $i = 1.7550$ ，指数权重：体重 0.4593、超声背膘 -2.2568、眼肌深 0.6865、半同胞瘦肉均值 6.3679； $\sigma_I = 5.626$ ， $\sigma_H = 10.287$ ， $r_{IH} = 0.547$ 。每代预期响应：瘦肉重 +0.808 kg、脂肪重 -0.029 kg， $\Delta H = 9.87$ ；记录性状的相关响应为体重 +2.55 kg、背膘 -0.165 mm、眼肌深 +1.15 mm。

(2)

删去的信息源	r_{IH}	ΔH	损失
120 日龄体重	0.4917	8.877	10.1%
超声背膘	0.5062	9.138	7.5%
超声眼肌深	0.5149	9.295	5.9%
半同胞胴体均值	0.4441	8.018	18.8%

(3) 把 12 与 -6 直接放在体重与背膘上, $\Delta H = 6.13$, 只有最优的 62.1%。

解读: 半同胞屠宰记录直接测量目标, 虽然只携带 1/4 的加性关系, 却是最有价值的信息源; 超声背膘虽不在目标中, 却因与脂肪重的强遗传相关获得较大负权重。“套权重”的错误同时犯了两类错误: 忽略了记录与目标单位、遗传力的差异, 并遗漏了眼肌深与半同胞信息。程序还核验了 $b^T P b = b^T C a$ 、两万组随机权重均不超过柯西界, 以及记录换算单位后指数分数不变。【题目】

16.16 基线每只母羊饲料 713.1 kg, 饲草总量 $R = 213919$ kg; 固定饲草边界的影子价格 $\lambda = 0.4864$ 元/kg, 高于市场价 0.40。

性状	a_A (固定羊群)	a_B (固定饲草)	$a_A \sigma_A$	$a_B \sigma_A$
产羔数 n	569.54	557.97	68.34	66.96
存活率 s	1035.52	1014.50	25.89	25.36
出售重 W (kg)	34.36	33.87	61.84	60.96
成年体重 M (kg)	-2.30	-2.80	-8.06	-9.80

(权重以每只基线母羊每年计。) 解析值与重新求解母羊数后的中心差分一致, 且 a_B 恰等于把饲料按 λ 计价的 a_A (推导 16.2)。有限改变: 成年体重 +4 kg 在边界 B 下准确 -10.78、线性 -11.20, 可养母羊数由 300 降到 290.68; 四性状同时改变时边界 A 准确 144.48、线性 137.16, 差额来自 n 、 s 、 W 之间的乘积交叉项。

解读: 两套权重在产出性状上相近, 在资源占用性状上差别明显, 差别大小完全由 $\lambda - p_f$ 决定; 若饲草更紧张, 成年体重的惩罚会更重。存活率权重是“每完整概率单位”的价值, 提高一个百分点只值约 10 元, 比较性状重要性应看每遗传标准差价值——产羔数与出售重最重要, 存活率在本例遗传标准差下贡献较小。【题目】

16.17 (1) $\delta = 0.943396$, 各状态价值依次为 2664.16、2913.86、2770.13、2453.33、2208.33; 初产牛终生折现价值 2664.16, 期望泌乳期 3.377 个, 稳态年更新率约 0.296。

(2) 潜在尺度功能性存活 +1 单位的权重为 2483.85 (差分 2483.85), +0.1 单位约 248.4; +0.3 单位的准确收益 866.40, 大于线性 745.15 (概率在 Φ 低于 0.5 以上区

域的弯曲使收益加速)。

(3) 各胎次存活率 +1 概率单位的价值: P1 2748.93、P2 1923.01、P3 1188.95、P4 706.75、P5+ 942.33。越早的存活改良打开的后续生产期越多;第 5 胎以后的自循环存留虽然在晚期,但会重复作用于以后所有期,因而高于 P4。每期净收益提高 1% 的价值为 26.64。

(4)

期限 L	3	5	8	12	20
有限期价值	1831.9	2416.7	2623.6	2660.5	2664.1
尾项	832.3	247.5	40.5	3.6	0.0

不折现时终生净收益 3016.38, 折现降低 11.7%。只计前 3 期会把三分之一的价值丢掉,而 8 期以后的尾项已很小;但晚期胎次参数缺乏资料时,“精确的无限期价值”同样缺乏生物学依据。

[题目]

16.18 (1)

发病率	t_0	$\phi(t_0)$	a_μ	每 σ_ℓ 价值	h_{obs}^2
2%	2.054	0.048	-87.2	-27.6	0.012
5%	1.645	0.103	-185.6	-58.7	0.022
10%	1.282	0.176	-315.9	-99.9	0.034
20%	0.842	0.280	-503.9	-159.4	0.049
35%	0.385	0.370	-666.7	-210.8	0.060
50%	0	0.399	-718.1	-227.1	0.064

(2) 基线 10%: $\Delta\mu = -0.1$ 准确 29.60、线性 31.59; -0.3 准确 77.62、线性 94.77; -0.6 准确 126.09、线性 189.54; $+0.1$ 准确 -33.65、线性 -31.59; $+0.3$ 准确 -113.69、线性 -94.77。

(3) 15 代后发病率由 0.30 降到 0.042, 准确节省 463.8, 而按初始权重线性外推为 751.0, 高估 62%; 当期权重由 -625.9 降为 -162.4。

解读: 同样的潜在遗传改良, 在低发病群体中价值小得多, 这不是“疾病不重要了”, 而是剩余可避免病例变少; 若项目还关心福利或生物安全, 应以约束或单独的社会价值表达, 而不是放大责任度尺度。长期计划必须定期在新基线处重算权重。

[题目]

16.19 (1) 各性状响应: 日增重 +21.86 g/d、背膘 -0.950 mm、日采食 -0.0102 kg/d, $\Delta H = 10.97$ 。Jacobian 与数值差分一致且 $Ja = 0$: 整体缩放权重不改变响应; 第一行第三列为正 (0.370), 说明采食权重变大 (向零方向) 会提高日增重响应。

(2)

情景	效率	二阶近似	日增重	背膘	日采食
采食价格低估 30%	0.9811	0.9812	28.09	-0.777	+0.0129
采食价格高估 30%	0.9823	0.9812	15.05	-1.082	-0.0322
忽略采食	0.8249	0.7907	37.42	-0.333	+0.0585
背膘符号错	0.3156	0.5726	37.06	+0.903	+0.0674
全部 $\times 10$	1.0000	1.0000	21.86	-0.950	-0.0102

采食权重 5% 误差的准确损失 0.005768, 二阶近似 0.005740。小误差的综合损失是二阶的、很小 (30% 价格误差只损失约 2%), 但采食响应的方向已经翻转——综合损失小不代表关键性状安全。大误差 (符号错误) 时二阶近似严重失效。

(3) 价格情景下固定指数效率均值 0.983, 5% 分位 0.939, 最差 0.533。

(4) Wishart 参数情景中采食响应均值 -0.0101, 90% 区间 $[-0.0295, +0.0089]$, 采食上升概率 0.203。若“采食不增加”是硬要求, 仅靠负权重没有足够把握。【题目】

16.20 (1) 隐含经济权重 $a = C^{-1}Pb_0 = (3.389, -0.261, 23.26)$, 带符号标准化强调为 $(+0.722, -0.093, +0.186)$ 。经验积分名义上给周岁重正分, 但考虑断奶重与周岁重的高遗传相关后, 其隐含目标实际轻微惩罚周岁重、主要追求断奶重。

(2) 以生物经济目标评价, 经验积分效率 0.916; 其响应为断奶重 +13.03、周岁重 +22.07、IMF +0.200, 生物经济指数为 +11.41、+23.48、+0.295。

(3) $\sigma_H^2 = 3712.8$, 对角项 2536.4 (比例和 0.683), 交叉项 1176.5。

性状	对角比例	协方差均分	标准化强调
断奶重	0.056	0.185	0.177
周岁重	0.431	0.584	0.491
IMF	0.196	0.231	0.332

三种约定给出不同的“重要性”, 没有一种是唯一正确答案, 报告时必须写明定义。

(4) 以新目标评价的 ΔH : 旧信息旧权重 70.58, 旧信息新权重 70.84, 新信息旧权重 74.08, 新信息新权重 78.37。Shapley 分解: 信息贡献 5.51, 权重贡献 2.27, 合计 7.78。模拟候选中与新版本入选名单的重合率: 旧旧 0.640、旧新 0.627、新旧

0.753; 入选者新目标真实优势分别为 61.23、60.16、65.82、71.70。说明新版排名变化的大部分来自新增的超声记录, 而“新权重”只有在获得 IMF 信息后才能充分发挥(旧信息下改权重几乎无益, 二者有交互)。

【题目】

16.21 (1) 天数 $60/0.9 = 66.67$ 天, 耗料 $1.6 \times 66.67 + 2.8 \times 60 = 274.67$ kg。

(2) $\partial F/\partial g = -mD/g^2 = -118.52$ kg 每 kg/d, $\partial(\text{天数})/\partial g = -D/g^2 = -74.07$ 天每 kg/d, 经济权重 $2.5 \times 118.52 + 1.2 \times 74.07 = 385.19$ 每 kg/d (即每 0.1 kg/d 约 38.5)。

(3) $g = 1.0$ 时耗料 264 kg、60 天, 准确节省 $2.5 \times 10.67 + 1.2 \times 6.67 = 34.67$, 线性近似 38.52。增重带来的价值完全来自缩短维持时间; $1/g$ 的凸性使线性近似高估。若出栏规则改为固定日龄, 模型和权重都要重写。

【题目】

16.22 $Ca = (6, -5)^T$, $|P| = 336$, $b = \frac{1}{336}(10 \times 6 + 8 \times 5, -8 \times 6 - 40 \times 5) = (0.2976, -0.7381)^T$ 。
 $\sigma_I^2 = b^T Ca = 5.4762$, $\sigma_I = 2.3401$; $\sigma_H^2 = 12 - 12 + 16 = 16$, $r_{IH} = 0.585$ 。
 $C^T b = (1.3571, -2.0595)^T$, $\Delta u = 1.4 \times (1.3571, -2.0595)/2.3401 = (0.812, -1.232)$;
 $\Delta H = 0.812 + 2 \times 1.232 = 3.276 = 1.4 \times 2.3401$ 。本例第二性状下降, 是因为其遗传方差相对协方差较大; 负权重是否导致下降取决于协方差结构。

【题目】

五、推导与证明题

16.23 见推导 16.1。补充 $\sigma_I^2 = b^T Pb = b^T PP^{-1}Ca = b^T Ca$; 而 $\text{Cov}(I, H) = b^T Ca = \sigma_I^2$, 故 $r_{IH} = \sigma_I^2/(\sigma_I \sigma_H) = \sigma_I/\sigma_H$ 。注意这两个等式只对最优指数成立; 对任意指数应使用 $r_{IH} = b^T Ca/(\sigma_I \sigma_H)$ 。还可证明 $E[(H - I)^2] = \sigma_H^2(1 - r_{IH}^2)$, 即准确度的提高与预测误差的减少是同一件事。

【题目】

16.24 对 $F(x(\mu), \mu) = 0$ 微分: $F_x \partial x/\partial \mu^T + F_\mu = 0$, 故 $\partial x/\partial \mu^T = -F_x^{-1}F_\mu$ 。总导数

$$a = \Pi_\mu + \left(\frac{\partial x}{\partial \mu^T} \right)^T \Pi_x = \Pi_\mu - F_\mu^T F_x^{-T} \Pi_x = \Pi_\mu - F_\mu^T \lambda.$$

伴随形式只需解一次 $F_x^T \lambda = \Pi_x$ 就能得到全部性状的权重。母羊模型中 $x = N$, $F = Nf - R$, $\Pi = Nm$: $F_N = f$, $\Pi_N = m$, $\lambda = m/f$, $F_\mu = N \nabla f$, $\Pi_\mu = N \nabla m$, 于是 $a = N(\nabla m - \lambda \nabla f)$ 。固定羊群、饲料价 p_f 时 $\Pi = N_0(m - p_f f)$, 权重 $N_0(\nabla m - p_f \nabla f)$; 令 $p_f = \lambda$ 且基线 $N = N_0$, 两式相同。证毕。 λ 的符号与方程写法有关: 若把平衡方程写成 $R - Nf = 0$, λ 反号而 a 不变。

【题目】

16.25 见推导 16.3。链状模型中 $T_{12} = s_1$, 只改变 s_1 时 $r_j = 0$, $T_j = e_1 e_2^T$, $\delta T_j v = \delta v_2 e_1$ 。
 $\alpha = e_1$, 而 $(I - \delta T)^{-1}$ 的 $(1, 1)$ 元为 1 (链状结构上第 1 状态不能回到自身), 故

$a = \delta v_2$: 初产后多存活一个概率单位, 相当于以一年后的折现价值获得一头“第2胎牛”的全部未来价值。习题 16.17 中 $\delta v_2 = 0.943396 \times 2913.86 = 2748.93$, 与程序结果一致。 [题目]

- 16.26** (1) $\Delta u = iBa s^{-1}$, $\partial s / \partial a^T = (Ba)^T / s$, 由乘积法则得所示 Jacobian; 乘以 a : $i[Ba/s - Ba s^2 / s^3] = 0$ 。(2) 令 $R(\tilde{a}) = ia^T B \tilde{a} / \sqrt{\tilde{a}^T B \tilde{a}}$, 它对 $\tilde{a}$ 是零次齐次函数, 故可把 ε 中平行于 a 的分量吸收到尺度中, 只留下 $\varepsilon_\perp$ ($a^T B \varepsilon_\perp = 0$)。此时分子不变 $= is^2$, 分母 $\sqrt{s^2 + \varepsilon_\perp^T B \varepsilon_\perp} \approx s(1 + \frac{1}{2s^2} \varepsilon_\perp^T B \varepsilon_\perp)$, 故 $R \approx is - \frac{i}{2s} \varepsilon_\perp^T B \varepsilon_\perp$ 。一阶项为零, 因为 a 已是最优方向。当 ε 与 a 同量级 (如符号错误) 时, 近似失效 (习题 16.19: 0.316 对 0.573)。 [题目]

六、综合分析与研究设计题

- 16.27** (1) **目标定义**: 先确定是减少每只羊的日排放、每千克标准乳的排放强度, 还是固定产品需求下的系统总排放; 建议目标同时包含奶量、乳脂蛋白量、成年体重 (维持)、繁殖、健康与“产量条件下的甲烷”, 并明确单位 (g/d、按泌乳期累计)。(2) **信息分工**: 核心场直接测定的甲烷是目标性状的最佳记录; 商业场的采食行为、体重、乳中红外等只作为指示性状进入 C, 不赋独立经济权重; 需在目标群体中估计指示性状与甲烷的遗传相关, 并检验它们是否主要反映体型或采食量 (若是, 选择指示性状会降低总采食而非提高效率)。(3) **权重**: 以本地生物经济模型求产出与饲料权重; 甲烷用明示的碳价情景或社会价值, 必要时以“不增加绝对排放”的限制表达; 检查甲烷能量损失是否已在饲料成本中计价, 避免重复。(4) **发布前检验**: 计算各性状预期响应 (尤其绝对排放与强度的方向)、在碳价与遗传参数情景下的稳健性 (Wishart 或后验抽样), 比较新旧指数的入选重合率与机会成本; 在独立年份或场群做前瞻验证。报告应注明情景预测不等于已实现减排。 [题目]

- 16.28** (1) **两个指数的必要性**: 终端父系的基因只在商品后代中表达一次, 母系公羊的基因通过女儿在多个胎次与外孙中表达。(2) **终端指数**: 目标为商品羔羊的生长、胴体产出与品质、羔羊存活与饲料成本, 边界为每只出售羔羊或每只配种母羊年度; 成年体重的维持成本几乎不进入。(3) **母系指数**: 增加产羔数、母性、母羊存活与寿命、成年体重维持成本, 按状态转移与贴现计算多胎次价值 (推导 16.3), 直接效应与母体效应分别计价; 在饲草受限系统中成年体重权重应按影子价格计算。(4) **表达次数**: 可用折现基因流计算每条路径的折现表达次数, 作为各性状的乘子; 不能简单把终端权重乘以常数得到母系权重。(5) **报告设计**: 两个指数共享同一套单性状 EBV 与准确度; 对每头公羊同时列出两个指数、各性状 EBV、各指数下的预

期后代差, 以及“两个指数排名差异主要来自哪几个性状”的分解图; 用习题 16.20 的切换点思想说明: 若用户保留女儿比例超过某一阈值, 母系指数更合适。【题目】

- 16.29** (1) **分步计算**: 保存旧评定、旧目标的排名; 分别计算“旧评定 + 新目标”“新评定 + 旧目标”和“新评定 + 新目标”, 用 Shapley 分解报告排名变化与各性状响应变化中有多少来自目标、多少来自信息 (习题 16.20), 并说明二者存在交互时分解不唯一。(2) **目标稳健性**: 在多个饲料价格情景下重算权重, 报告入选名单重合率、各性状响应与采食等关键性状方向; 用合法协方差抽样评估参数不确定性。(3) **新性状验证**: 乳中红外健康指示性状只进入 C 作为信息, 健康的经济权重仍按健康目标本身计价; 需在时间外数据中验证预测校准与新增准确度。(4) **发布**: 同时发布新旧两版指数一段过渡期; 给出重要公牛的排名切换点 (饲料价格超过多少时两头公牛排名互换); 附上目标定义、权重单位、参数来源与版本号。(5) **评审制度**: 规定常规评审周期与触发临时评审的条件, 避免对短期价格波动过度反应。

【题目】

限制指数、非线性目标与稳健决策

17.1 本章导学

学习目标

- 1. 能把“某性状不能恶化”写成线性约束，推导零响应限制指数的权重，并解释拉格朗日乘数的影子价格含义。
- 2. 理解限制所付出的代价可用投影分解，限制越多、与目标越相关，代价越大；冗余限制不起作用。
- 3. 能处理不等式限制：活跃集合、KKT 条件与最优性证书。
- 4. 当目标存在最适值或价值非线性时，会用“期望效用”而不是预测均值选择。
- 5. 能在经济权重与遗传参数不确定时比较期望最优、最坏情形、条件风险价值与概率约束。
- 6. 理解联合预测误差：同家系候选共担误差，组合风险不能只看个体可靠度。

重点与难点

重点： $b_r = P^{-1}G(a - K\lambda)$ ； $\Delta H_r/\Delta H_0 = \sqrt{1 - \cdot}$ ；期望效用 $-(m - \theta)^2 + v$ ；CVaR 的线性规划形式；Cantelli 界。

难点：限制在“响应”空间而非“权重”空间；乘数符号与活跃集合；非线性目标下方差进入决策；组合风险的协方差结构；概率约束与均值约束的区别。

本章把第 15—16 章的线性指数推广到“有边界、有最适值、有不确定性”的现实决策，是第 18 章最优贡献选择与第 36 章约束配种决策的理论基础。

17.2 知识结构图




图 17.1 第 17 章知识结构图

右侧三支讲“约束与代价”，左侧四支讲“非线性、不确定性与风险”。

17.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
无限制指数	$b_0 = P^{-1}Ga$	$\Delta H_0 = i\sqrt{a^T W a}$, $W = GP^{-1}G$
响应	$\Delta = iGb/\sigma_I$	$\sigma_I = \sqrt{b^T P b}$
零响应限制	$K^T \Delta = 0$	K 为被限制性状的指示矩阵
限制指数	$b_r = P^{-1}G(a - K\lambda)$, $\lambda = (K^T W K)^{-1} K^T W a$	约束线性无关
效率	$\Delta H_r^2 =$ $\Delta H_0^2 - i^2 a^T W K M^{-1} K^T W a$	$M = K^T W K$
KKT	$\nabla f = v \nabla g_0 + \sum \mu_j \nabla g_j$, $\mu_j \geq 0$	互补松弛
最适目标	$E[U m, v] = -[(m - \theta)^2 + v]$	二次效用
组合风险	$v(S) = k^{-2} 1^T \Sigma_S 1$	误差协方差 Σ
CVaR	$CVaR_\alpha =$ $\max_\eta \{ \eta - \frac{1}{\alpha} E[(\eta - V)_+] \}$	线性规划形式

概念	公式或定义	成立条件与提示
Cantelli	$P(\Delta > 0) \leq \sigma^2/(\sigma^2 + \mu^2),$ $\mu < 0$	仅需均值与方差
概率约束	$P(\Delta_j \leq 0) \geq 1 - \epsilon$	正态时 $\mu \leq -z_{1-\epsilon}\sigma$
后悔	$\max_s [V_s^* - V_s(x)]$	相对该情景最优

17.4 补充内容与公式推导

推导 17.1 限制指数的代价：投影分解

记 $W = GP^{-1}G$ (半正定)。无限制时 $b_0 = P^{-1}Ga$, $\sigma_{I0}^2 = a^T Wa$, $\Delta H_0 = i\sigma_{I0}$ (因为 $\Delta H = ia^T Gb/\sigma_I$, 代入 b_0 即 $ia^T Wa/\sigma_{I0}$)。在 $K^T Gb = 0$ 下, 引入乘数 λ , 拉格朗日平稳性给出 $P^{-1}Ga \propto b + P^{-1}GK\lambda$, 即 $b_r = P^{-1}G(a - K\lambda)$ 。令 $a_r = a - K\lambda$, 则 $K^T Wa_r = 0$, 解得 $\lambda = M^{-1}K^T Wa$ 。由于 a_r 在 W 内积下与 K 的列正交, a_r 是 a 在 W 内积下对 $\text{span}(K)^\perp$ 的投影, 故

$$\sigma_{Ir}^2 = a_r^T Wa_r = a^T Wa - a^T WKM^{-1}K^T Wa, \quad \Delta H_r = i\sigma_{Ir}.$$

损失等于“经济权重在被限制方向上的投影”的大小: 若无限制解本来就满足约束 ($K^T Wa = 0$), 损失为零。习题 17.15 中, 限制采食量不变损失 14.6%, 同时限制背膘厚损失 36.4%。

推导 17.2 不等式限制与 KKT 证书

在 $\sigma_I = 1$ 的标准化下, 问题为 $\max ia^T Gb$, 约束 $g_0 = b^T Pb \leq 1$ 与 $g_j = s_j(iG_j b - d_j) \leq 0$ ($s_j = -1$ 为下界, $+1$ 为上界)。这是凸问题 (线性目标、二次锥与线性约束), KKT 条件充分必要: 存在 $\nu \geq 0$ 、 $\mu_j \geq 0$, 使

$$-iGa + 2\nu Pb + \sum_j \mu_j s_j iG_j^T = 0, \quad \mu_j g_j = 0.$$

求解后只要对活跃约束把平稳性方程作最小二乘, 若残差为零且乘数非负, 就得到最优性证书。习题 17.16 三种情形的证书残差分别为 1.3×10^{-7} 、 8.9×10^{-8} 、 4.3×10^{-7} 。情形 B 的“采食量不超过 0”并未活跃 (无限制解本就使采食量下降 0.14) ——冗余约束的乘数为零, 对结果没有影响。

推导 17.3 最适目标与组合风险

设价值 $U(g) = -(g - \theta)^2$, $g | m \sim N(m, v)$, 则 $E[U | m, v] = -E(g - \theta)^2 = -[(m - \theta)^2 + v]$ (偏差平方加方差)。若所有候选的 v 相同, 则按 $|m - \theta|$ 排序最优; 若 $\theta \rightarrow \infty$ (价值近似线性), 则按 m 排序最优; 一般情形 v 不同, 必须二者兼顾。习题 17.17 中, $\theta = 1$ (以 σ_A 为单位) 时, 按均值选择的真实均方偏差为 0.671, 按距离选择 0.442, 按期望效用选择 0.230——最优规则比常规规则降低 66%。群体平均 $\bar{g} = k^{-1} \sum_{j \in S} g_j$ 的方差为 $v(S) = k^{-2} \mathbf{1}^T \Sigma_S \mathbf{1}$ 。若同一家系的候选误差相关系数为 ρ , 各自 PEV 为 σ_e^2 , 则来自一个家系 n_f 头的贡献为 $\sigma_e^2[n_f + n_f(n_f - 1)\rho]/k^2$, 故集中在少数家系会放大风险; 每家系取一头时风险最小 (习题 17.19)。

拓展阅读 限制选择与风险的文献脉络

Kemphorne 与 Nordskog (1959) 提出限制选择指数, Tallis (1962) 推广到比例响应, Brascamp (1984) 给出统一的矩阵表述; Wray 与 Goddard (1994) 以及 Meuwissen (1997) 研究了在近交约束下最大化遗传增益的最优贡献理论 (第 18 章)。Rockafellar 与 Uryasev (2000) 的 CVaR 线性规划表述使风险约束在大规模问题中可计算; 育种中使用 CVaR 与概率约束的研究参见 Henryon 等 (2019) 关于育种目标不确定性的讨论。Walsh 与 Lynch (2018) 的限制指数章节提供了系统的证明。

易错辨析

- **限制作用在响应上:** $K^T \Delta = 0$ 不等于“指数中该性状权重为零”。习题 17.15 中被限制的采食量权重为 0.189, 并非零。
- **乘数的符号要看约束方向:** 不等式约束的乘数必须非负, 负乘数说明约束应当放松或是活跃集合判断错误。
- **冗余限制不是免费的错误, 而是无效:** 已被满足的限制乘数为零, 既不改变结果, 也不应被当作“保障”。
- **期望最优并不稳健:** 习题 17.18 中 CVaR 规则只损失 0.004 的平均收益, 却把 5% 情景下的 CVaR 提高 8%。
- **同家系的“高可靠度”可以叠加风险:** 个体可靠度相同不代表群体风险相同, 必须看误差协方差。
- **Cantelli 保守:** 它只用均值与方差, 得到分布无关的保障, 通常比正态近似保守得多 (习题 17.20 中 $c = 0.2$ 时抽样概率 0.966 而 Cantelli 下界 0.776)。

17.5 习题

一、单项选择题

- 17.1 ★ [单选] 与无限制最优指数相比, 加入线性零响应限制后总经济进展
 (A) 总是更大 (B) 不会更大 (C) 不变
 (D) 取决于选择强度 [答案]

- 17.2 ★ [单选] 零响应限制的拉格朗日乘数 λ_j 的含义是
 (A) 该性状的遗传力
 (B) 放松限制所能带来的边际总进展 (影子价格)
 (C) 该性状的选择差 (D) 指数的准确度

[答案]

- 17.3 ★★ [单选] 目标性状价值在最适值 θ 处最大时, 候选的排序应当依据
 (A) 预测均值 (B) 预测均值的绝对值
 (C) $(m - \theta)^2 + v$ 最小 (D) 可靠度 [答案]

- 17.4 ★★ [单选] 经济权重不确定时, “最坏情形最优” (max-min) 规则的主要缺点是
 (A) 计算不可行
 (B) 被极端但罕见的情景左右, 平均收益显著下降
 (C) 总是等价于期望最优 (D) 不能用线性规划

[答案]

- 17.5 ★★ [单选] 要求 $P(\Delta \leq 0) \geq 0.95$, 且 $\Delta \sim N(\mu, \sigma^2)$, 需要
 (A) $\mu \leq 0$ (B) $\mu \leq -1.645\sigma$ (C) $\mu \leq -\sigma$
 (D) $\mu \leq -2.33\sigma$ [答案]

- 17.6 ★★ [单选] 选 k 头公畜时, 如果它们的预测误差正相关 (同家系), 则
 (A) 群体平均 EBV 的误差方差小于独立情形
 (B) 大于独立情形 (C) 相等
 (D) 取决于选择强度 [答案]

二、判断与改错题

17.7 ★ [判断] 增加一个已被无限制解满足的零响应限制会降低总进展。 [答案]

17.8 ★★ [判断] CVaR 规则必然大幅牺牲平均收益。 [答案]

17.9 ★★ [判断] Cantelli 不等式只需要均值与方差, 所以给出的保障通常比正态假设下的更保守。 [答案]

17.10 ★★ [判断] KKT 条件中活跃不等式约束的乘数可以为负。 [答案]

三、填空题

17.11 ★ [填空] 限制指数的总进展 ΔH_r 与无限制的 ΔH_0 相等, 当且仅当_____。 [答案]

17.12 ★ [填空] 已知 $a^T W a = 25$, $i = 1.755$, 则 $\Delta H_0 =$ _____。 [答案]

17.13 ★ [填空] Δ 的均值 -0.2 、标准差 0.1 , 则 $P(\Delta \leq 0) \geq$ _____ (Cantelli)。 [答案]

17.14 ★ [填空] 最适值 $\theta = 1$, 预测均值 $m = 0.6$, 预测误差方差 $v = 0.25$, 期望效用为_____。 [答案]

四、计算题

17.15 ★★ [计算] 零响应限制指数。4 性状 (日增重、采食量、背膘厚、瘦肉率) 育种模型见配套数据, 经济权重 $(2, -1.5, -1, 3)$, 留前 10%。分别计算无限制、限制采食量不变、限制采食量与背膘厚均不变的指数权重、各性状响应、总进展与损失, 并用蒙特卡洛核对。 [程序] `ch17/ex17_15_restricted_index.py` [答案]

17.16 ★★★ [计算] 不等式限制与最优性证书。在同一模型上, 加入“日增重至少 $+0.30$ ”“采食量不增加”“背膘厚不超过 -0.80 ”三组不等式约束, 求最优指数, 识别活跃集合并给出 KKT 乘数与残差。 [程序] `ch17/ex17_16_inequality_constraints.py` [答案]

17.17 ★★ [计算] 最适目标。价值 $-(g - \theta)^2$, $\theta = 0.5, 1.0, 2.0$, 候选可靠度取自 $0.4, 0.6, 0.8, 0.95$ 的混合分布, 留前 5%。比较按预测均值、按距最适值最近、按期望效用的选择。 [程序] `ch17/ex17_17_optimum_target.py` [答案]

17.18 ★★★ [计算] 稳健选择。 60 头候选的 4 性状 EBV, 经济权重服从多元正态 (各权重标准差 0.5、1.2、0.8、1.5, 相关 0.3)。选 6 头, 比较期望最优、最坏情形、CVaR 20% 与均值 $-\lambda \cdot \text{SD}$ 规则在 5000 个测试情景下的均值、5% 分位数、CVaR 与最大后悔。[程序] `ch17/ex17_18_robust_selection.py` [答案]

17.19 ★★★ [计算] 组合风险。 6 个家系各 5 头候选, PEV 0.45、家系内误差相关 0.55, 选 6 头。求不同风险厌恶系数 λ 下的期望均值、SD、低于阈值概率与入选家系分布。[程序] `ch17/ex17_19_combination_risk.py` [答案]

17.20 ★★★ [计算] 概率约束。 遗传相关加 Fisher z 噪声 (SD 0.12)、遗传力加噪声 (SD 0.04), 要求采食量响应 ≤ 0 的概率不低于 90%。令名义响应为 $-c$, 求 $c = 0, \dots, 0.5$ 时的实际概率, 并与正态近似和 Cantelli 下界比较。[程序] `ch17/ex17_20_chance_constraint.py` [答案]

17.21 ★ [计算] 某不利性状响应的预测均值 -0.30 、标准差 0.15 。(1) 求 $P(\Delta \leq 0)$ (正态) 与 Cantelli 下界; (2) 若要求概率不低于 95%, 所需的均值至少为多少 (两种方法)? [答案]

17.22 ★★ [计算] 两性状, $G = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$, $P = \begin{pmatrix} 2 & 0.5 \\ 0.5 & 2 \end{pmatrix}$, $a = (1, 0.5)^\top$ 。求无限制指数与要求性状 2 响应为零的限制指数, 并求总进展的相对损失。[答案]

五、推导与证明题

17.23 ★★ [证明] 证明零响应限制下最优权重为 $b_r = P^{-1}G(a - K\lambda)$, $\lambda = M^{-1}K^\top Wa$ 。[答案]

17.24 ★★ [证明] 证明 $\Delta H_r^2 = \Delta H_0^2 - i^2 a^\top WKM^{-1}K^\top Wa$, 并指出损失为零的条件。[答案]

17.25 ★★ [证明] 证明二次效用下期望效用为 $-(m - \theta)^2 + v$, 并说明在何种条件下按预测均值排序是最优的。[答案]

17.26 ★★★ [证明] 证明 Cantelli 不等式: 均值为 $\mu < 0$ 、方差为 σ^2 的随机变量 Δ 满足 $P(\Delta \geq 0) \leq \sigma^2/(\sigma^2 + \mu^2)$ 。[答案]

六、综合分析与研究设计题

- 17.27 ★★ [综合]** 奶牛育种计划希望提高产奶量，但不增加乳房炎发病率与体况评分的恶化。设计一个“限制指数 + 概率约束”的方案，说明参数、检验与沟通。 [答案]
- 17.28 ★★★ [综合]** 初生重存在最适值：过小成活率低，过大难产多。设计选择方案，包含预测不确定性的处理、验证与对母体效应的考虑。 [答案]
- 17.29 ★★★ [综合]** 育种委员会对经济权重意见不一。写出一份决策报告的框架：如何构建情景集、用哪些稳健准则、如何用决策图沟通后悔与代价。 [答案]

17.6 参考答案与解析

一、单项选择题

- 17.1 B。** 限制缩小可行集，总进展不会更大；约束被无限制解本身满足时相等。 [题目]
- 17.2 B。** 乘数是约束右端的灵敏度；见推导 17.1。 [题目]
- 17.3 C。** 见推导 17.3。 [题目]
- 17.4 B。** max-min 完全由最差情景决定（习题 17.18：平均收益 3.62，比期望最优的 5.64 低 36%）。 [题目]
- 17.5 B。** $z_{0.95} = 1.645$ 。 [题目]
- 17.6 B。** $\text{Var}(\bar{g}) = k^{-2} \mathbf{1}^T \Sigma \mathbf{1}$ ，正相关使非对角项为正，方差增大。 [题目]

二、判断与改错题

- 17.7 错误。** 被满足的限制是冗余的，乘数为零，总进展不变（习题 17.16 情形 B）。 [题目]
- 17.8 错误。** 习题 17.18 中 CVaR 规则平均收益为 5.632，仅比期望最优（5.636）低 0.07%，而最差 5% 情景的 CVaR 由 2.124 提高到 2.298（+8%）。 [题目]
- 17.9 正确。** Cantelli 是分布无关界，对正态而言保守（习题 17.20： $c = 0.2$ 时抽样概率 0.966、Cantelli 下界 0.776）。 [题目]
- 17.10 错误。** 活跃不等式的乘数必须非负；负值说明该约束不是限制作用或应放松。 [题目]

三、填空题

- 17.11 无限制最优解已满足所有限制，即 $K^TWa = 0$ ($\lambda = 0$)。 [题目]
- 17.12 $\Delta H_0 = 1.755 \times \sqrt{25} = 8.775$ 。 [题目]
- 17.13 $\sigma^2/(\sigma^2 + \mu^2) = 0.01/0.05 = 0.2$ ，故 $P(\Delta \leq 0) \geq 0.8$ 。 [题目]
- 17.14 $-[(0.6 - 1)^2 + 0.25] = -0.41$ 。 [题目]

四、计算题

17.15 选择强度 $i = 1.755$ 。

方案	日增重	采食量	背膘厚	瘦肉率	ΔH	损失
无限制	-0.172	-0.518	-0.932	+1.099	4.662	—
采食量不变	+0.287	0	-0.608	+0.933	3.982	14.6%
采食量、背膘均不变	+0.369	0	0	+0.742	2.964	36.4%

限制权重：采食量不变 $b = (0.588, 0.189, -0.478, 1.089)$ ， $\lambda = -2.436$ ；两项限制时 $b = (0.450, -0.185, 0.466, 0.982)$ ， $\lambda = (-0.107, -2.921)$ 。蒙特卡洛核对（30 万个候选）：响应与解析值差小于 0.015。注意两点：（1）无限制指数让日增重下降（-0.172）——因为日增重与采食量、背膘厚正相关，而它们的权重为负；（2）限制了采食量后，日增重回升到 +0.287，因为“不让采食量下降”相当于允许与之相关的性状上升。限制使每个被限制性状的响应归零，但同时改变所有相关性状的响应。 [题目]

17.16

情形	活跃约束	ΔH	损失	响应（日增重、采食量、背膘、瘦肉率）	乘数
A 日增重 ≥ 0.30	日增重	4.152	10.9%	+0.300、-0.138、-0.620、+0.908	$v=2.405$ ， $\mu=2.196$
B 加“采食量 ≤ 0 ”	仅日增重	4.152	10.9%	同 A	同 A

情形	活跃约束	ΔH	损失	响应（日增重、 采食量、背膘、 瘦肉率）	乘数
C 再加“背膘 ≤ -0.80 ”	日增重、背膘	3.665	21.4%	+0.300、 -0.082、 -0.800、 +0.714	$\mu=14.04$ 、 13.01

三种情形的平稳性残差均小于 5×10^{-7} ，乘数非负，KKT 证书通过。情形 B 的新增约束不活跃：采食量响应 -0.138 已经满足要求，因此乘数为零、结果不变。情形 C 的两个活跃约束使总进展再降 10.5 个百分点。

[题目]

17.17

θ	规则	真实均方偏差	平均可靠度	平均 m
0.5	预测均值最大	1.394	0.672	1.476
0.5	距最适值最近	0.575	0.428	0.498
0.5	期望效用最大	0.173	0.903	0.460
1.0	预测均值最大	0.671	0.672	1.476
1.0	距最适值最近	0.442	0.565	0.983
1.0	期望效用最大	0.230	0.839	0.929
2.0	预测均值最大	0.725	0.672	1.476
2.0	距最适值最近	0.723	0.671	1.467
2.0	期望效用最大	0.690	0.732	1.453

规则 (2) 只看均值与最适值的距离，会选中大量低可靠度候选（可靠度仅 0.43），它们的预测均值恰好接近 θ ，但真实值散布很大；期望效用规则自动偏好高可靠度个体。当 $\theta = 2$ （远离群体均值）时三条规则趋同，因为此时选择主要在往 θ 方向推进，方差的作用被均值差淹没。

[题目]

17.18 (60 头候选，选 6 头)

规则	测试均值	5% 分位	CVaR 5%	平均后悔	最大后悔	与期望最优 重合
期望最优	5.636	2.765	2.124	0.192	4.137	6/6
最坏情形	3.619	2.442	2.166	2.210	6.363	3/6
CVaR 20%	5.632	2.927	2.298	0.197	3.556	5/6
均值 $-\lambda \cdot SD$	5.632	2.927	2.298	0.197	3.556	5/6

CVaR 与均值—标准差规则选出相同的 6 头，替换了期望最优中的 1 头，平均收益只降 0.004，却把 5% 分位提高 6%，最大后悔降低 14%。最坏情形规则只与期望最优重合 3 头，平均后悔高出 10 倍以上——它被极端情景支配，是一种“过度保守”。结论：对不确定性的合理回应是在尾部做小代价的保险，而不是把整个决策交给最差情景。

[题目]

17.19

λ	期望均值	SD	$P(\bar{g} < 0.4)$ 解析	采样	家系数	入选家系数
0	0.610	0.320	0.2561	0.257	4	0,1,2,1,2,0
1、2、4、8	0.592	0.274	0.2412	0.245	6	1,1,1,1,1,1

按 EBV 取前 6 头会集中在 4 个家系，群体均值 SD 为 0.320；加入风险项 ($\lambda \geq 1$) 后改为每家系取 1 头，期望均值只降 0.018 (3%)，SD 降 14%，低于阈值的概率由 25.6% 降到 24.1%。这里的收益有限，因为候选的家系间差异不大；当某个家系的 EBV 显著更高时，集中选择的期望收益增加而风险也增加，需要用 λ 调整。解析 SD 与采样 SD 相差小于 0.001，说明 $v(S) = k^{-2}1^T \Sigma_S 1$ 是准确的。

[题目]

17.20

c	名义 ΔH	实际响应均值	SD	$P(\Delta \leq 0)$ 抽样	正态	Cantelli 下界
0.0	3.982	0.001	0.104	0.504	0.497	0.000
0.1	4.205	-0.098	0.106	0.824	0.824	0.464
0.2	4.388	-0.197	0.106	0.966	0.968	0.776
0.3	4.527	-0.297	0.106	0.996	0.998	0.888
0.4	4.620	-0.396	0.103	1.000	1.000	0.936
0.5	4.661	-0.495	0.100	1.000	1.000	0.961

“名义响应为零” ($c = 0$) 只有 50% 的概率实现不恶化——这就是均值约束的承诺失效。满足 90% 概率约束至少需要 $c = 0.2$ ，此时总进展为 4.388，相对无限制最优 (4.662) 仍损失 5.9%；若只用均值与方差并要求 Cantelli 保障，则需要 $c = 0.4$ 。正态近似与抽样一致 (差 < 0.005)。注意：这里随着 c 增大， ΔH 反而增大，因为采食量的经济权重为负，让采食量下降本身就是有利的； $c = 0$ 的约束相当于在不利方向“冻结”采食量，代价最大。

[题目]

- 17.21** (1) 正态: $P(\Delta \leq 0) = \Phi(0.30/0.15) = \Phi(2) = 0.977$; Cantelli: $1 - \frac{0.0225}{0.0225 + 0.09} = 0.80$ 。(2) 要求 95%: 正态需 $\mu \leq -1.645 \times 0.15 = -0.247$; Cantelli 需 $\sigma^2/(\sigma^2 + \mu^2) \leq 0.05$, 即 $\mu^2 \geq 19\sigma^2$, $|\mu| \geq 4.36 \times 0.15 = 0.654$ 。分布无关的保障要求的边际是正态的 2.65 倍。 [题目]

- 17.22** $P^{-1} = \frac{1}{3.75} \begin{pmatrix} 2 & -0.5 \\ -0.5 & 2 \end{pmatrix}$ 。 $Ga = (1.25, 1.0)$, 无限制 $b_0 = P^{-1}Ga = (0.5333, 0.3667)$, $\sigma_{I_0}^2 = 1.0333$, $\Delta H_0 = 1.0165i$, 两性状响应均为正 ($0.705i$, $0.623i$)。限制 $\Delta_2 = 0$: $K = (0, 1)^T$, $WK = GP^{-1}g_2$, $M = g_2^T P^{-1}g_2 = 0.5333$, $\lambda = 0.6333/0.5333 = 1.1875$; $a_r = (1, -0.6875)$, $b_r = (0.375, -0.1875)$, 验证 $g_2^T b_r = 0$ 。 $\sigma_{I_r}^2 = 0.28125$, $\Delta H_r = 0.5303i$, 相对损失 $1 - 0.5303/1.0165 = 47.8\%$ 。两性状正相关 (0.5) 而性状 2 权重为正, 要求其不变就必须放弃性状 1 的大部分增益。 [题目]

五、推导与证明题

- 17.23** 见推导 17.1。更形式地, 在 $\sigma_I = 1$ 下最大化 $ia^T Gb$, 拉格朗日函数 $\mathcal{L} = ia^T Gb - \frac{\nu}{2}(b^T P b - 1) - \theta^T K^T Gb$ 。对 b 求导: $iGa - \nu Pb - GK\theta = 0$, 故 $b = \nu^{-1}P^{-1}G(ia - K\theta)$ 。因权重的尺度不重要, 令 $\lambda = \theta/i$, 得 $b \propto P^{-1}G(a - K\lambda)$ 。代入 $K^T Gb = 0$: $K^T W(a - K\lambda) = 0$, 得 $\lambda = M^{-1}K^T Wa$ (M 可逆当 K 列满秩且 W 在 $\text{span}(K)$ 上正定)。 [题目]

- 17.24** $\Delta H_r = ia^T Gb_r / \sigma_{I_r}$ 。因 $K^T Gb_r = 0$, $a^T Gb_r = a_r^T Gb_r = a_r^T Wa_r = \sigma_{I_r}^2$, 所以 $\Delta H_r = i\sigma_{I_r}$ 。又 $\sigma_{I_r}^2 = a_r^T Wa_r = a^T Wa - 2\lambda^T K^T Wa + \lambda^T M \lambda = a^T Wa - a^T WKM^{-1}K^T Wa$ 。损失为零当且仅当 $K^T Wa = 0$, 即无限制响应 $\Delta_0 \propto GP^{-1}Ga$ 在被限制性状上本就为零。 [题目]

- 17.25** $E[(g - \theta)^2 | m, v] = E[(g - m + m - \theta)^2] = v + (m - \theta)^2$ (交叉项期望为零), 取负号即得。若所有候选的 v 相同, 则排序等价于按 $(m - \theta)^2$, 即 $|m - \theta|$; 若 θ 很远 (远大于所有候选的 m), 则 $(m - \theta)^2 = \theta^2 - 2\theta m + m^2$, 主导项为 $-2\theta m$, 排序近似按 m 。仅当 v 恒定且价值近似线性 ($\theta \rightarrow \infty$) 时, 按均值排序是最优的。 [题目]

- 17.26** 令 $Y = -\Delta$, $E(Y) = -\mu =: m > 0$, $\text{Var}(Y) = \sigma^2$ 。对任意 $s > 0$: $\{\Delta \geq 0\} = \{Y \leq 0\} \subseteq \{(m - Y + s)^2 \geq (m + s)^2\}$, 因为 $m - Y \geq m > 0$ 。由 Markov 不等式, $P(\Delta \geq 0) \leq E(m - Y + s)^2 / (m + s)^2 = (\sigma^2 + s^2) / (m + s)^2$ 。关于 s 最小化, 令导数为零得 $s = \sigma^2 / m$, 代入: $\frac{\sigma^2 + \sigma^4/m^2}{(m + \sigma^2/m)^2} = \frac{\sigma^2(m^2 + \sigma^2)/m^2}{(m^2 + \sigma^2)^2/m^2} = \frac{\sigma^2}{m^2 + \sigma^2}$ 。 [题目]

六、综合分析与研究设计题

17.27 方案: (1) 性状: 产奶量 (目标)、乳房炎发病 (二分类, 用阈值模型或线性近似)、体况评分; 经济权重来自牛群经济模型; (2) 约束: 把“乳房炎发病率不增加”写成响应约束 $\Delta_{\text{mast}} \leq 0$, 并采用概率形式 $P(\Delta_{\text{mast}} \leq 0) \geq 0.9$; (3) 参数不确定性: 用 REML 或贝叶斯分析的后验样本 (遗传力与遗传相关) 抽样, 对每个候选 c 计算概率 (习题 17.20 的做法); (4) 步骤: 先做无限制指数, 若概率约束不满足, 则按 c 增大的网格求最小安全边际, 报告产奶量进展的代价; (5) 检验: 保留群体与前瞻性验证检验实际响应; (6) 沟通: 给出“代价—保障”曲线 (如习题 17.20 的表), 让决策者选择; 对遗传相关的先验不确定性单独作敏感性分析。 [题目]

17.28 方案: (1) 价值函数: 以出生重对成活与难产的剂量—反应关系确定 $U(g)$, 近似二次 $-(g - \theta)^2$ 或分段线性; (2) 预测: 直接效应与母体效应分开建模 (第 22 章), m 为直接遗传效应预测, v 为 PEV, 对个体用 $-(m - \theta)^2 + v$ 排序; (3) 最适值 θ 受母牛体型和环境影响: 对不同母体群体设置不同 θ (交互); (4) 验证: 用后代记录检验“选中个体的后代出生重均方偏差是否降低”; (5) 对低可靠度的青年个体, 若 θ 靠近群体均值则避免仅依据预测均值选择 (习题 17.17: $\theta = 0.5$ 时均值规则的偏差是期望效用规则的 8 倍)。 [题目]

17.29 框架: (1) 情景集: 由专家意见、历史价格波动与产业模型联合生成权重的概率分布 (习题 17.18 用多元正态, 需检查正定性与相关), 保留若干极端但可信的情景; (2) 候选规则: 期望最优、CVaR ($\alpha = 10\% - 20\%$)、均值—标准差、最大后悔最小化; (3) 评价: 在独立测试情景集上报告均值、分位数、CVaR 与后悔; (4) 决策图: 横轴为平均收益, 纵轴为 5% 分位数或最大后悔, 每个点为一条规则, 帮助委员会看到“用 0.07% 的平均收益换 8% 的尾部保障”这类交换; (5) 报告: 入选名单的重合度、各规则的差异个体与其对不同权重情景的敏感性; (6) 复核: 权重信息更新后重新计算, 并记录决策依据以便审计。 [题目]

选择反应、世代间隔与长期遗传进展

18.1 本章导学

学习目标

- 1. 掌握年遗传进展 $\Delta G = \sum i_k r_k \sigma_A / \sum L_k$ 的含义，理解世代间隔、准确度与选择强度的三方权衡。
- 2. 理解重叠世代下的基因流递推，能推导 Rendel–Robertson 公式并用数值递推核对。
- 3. 理解最优贡献选择：在共祖约束下最大化遗传进展，会写 KKT 条件并解释共祖的影子价格。
- 4. 区分“贡献”与“配种”：配种计划能降低后代近交，但不能改变下一代的平均共祖。
- 5. 能用多世代模拟比较截断选择与最优贡献选择的进展、近交与方差。
- 6. 会用折现表达评价金字塔育种体系中的滞后与时间价值，并做准确度不确定下的盈亏分析。

重点与难点

重点：年进展公式；四条选择路径； $\theta = \frac{1}{2}c^T A c$ 与有效群体大小的联系；最优贡献的拉格朗日结构；折现基因表达。

难点：准确度低而间隔短的方案为何更快；最优贡献与截断选择入选个数的反直觉关系；共祖约束与近交速率的转换；长期进展与近交衰退的合并评价。

本章把第 14 章的单代反应、第 12—13 章的亲缘与近交工具与第 19 章的有效群体大小连接起来，是第 28 章单步基因组评定与第 36 章约束配种决策的理论基础。

18.2 知识结构图




图 18.1 第 18 章知识结构图

右侧三支讲“进展的构成”，左侧四支讲“多样性、配种、时间价值与验证”。

18.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
年进展	$\Delta G = \frac{\sum_k i_k r_k \sigma_A}{\sum_k L_k}$	k 为选择路径
世代间隔	$L = \sum_a w_a a$	w_a 为年龄 a 亲本所产后代的比例
基因流递推	$G_t = \frac{1}{2} \sum w_a^S (G_{t-a} + s^S) + \frac{1}{2} \sum w_a^D (G_{t-a} + s^D)$	无限位点、稳态
渐近年进展	$\Delta G = (\bar{s}_S + \bar{s}_D) / (L_S + L_D)$	$s = i r \sigma_A$
平均共祖	$\theta = \frac{1}{2} c^T A c$	c 为贡献向量
最优贡献	$\max c^T \hat{a} \text{ s.t. } \theta \leq \theta_{\max}, \text{ 性别和为 } \frac{1}{2}$	二次约束规划
KKT	$\hat{a}_j - \lambda_{s(j)} - \mu (A c)_j = 0 \quad (c_j > 0)$	$\mu > 0$ 为共祖影子价格
近交速率	$\Delta F = \frac{1}{8N_m} + \frac{1}{8N_f}$	理想条件
后代近交	$F = \frac{1}{2} A_{sd}$	配种分配改变之

概念	公式或定义	成立条件与提示
折现表达	$PV(s; L) = v \sum_{u=s+L}^H q^u,$ $q = \frac{1}{1+d}$	规划期 H
盈亏平衡准确度	$r^* : \Delta G_{\text{青年}}(r^*) = \Delta G_{\text{后测}}$	可含近交代价
净进展	$\Delta G_{\text{net}} = \Delta G - \delta \Delta F_{\text{年}}$	δ 为每单位 F 的衰退

18.4 补充内容与公式推导

推导 18.1 重叠世代的基因流与 Rendel–Robertson 公式

记 G_t 为第 t 年出生个体的平均育种值。雄性亲本年龄为 a 的后代占雄路径的比例为 w_a^S ，此类亲本出生于 $t-a$ 年，被选时的选择差为 $s^S = i^S r^S \sigma_A$ （以其同龄同期群的平均为基准），故其平均育种值为 $G_{t-a} + s^S$ 。子代取父母平均，得

$$G_t = \frac{1}{2} \sum_a w_a^S (G_{t-a} + s^S) + \frac{1}{2} \sum_a w_a^D (G_{t-a} + s^D).$$

设渐近线性增长 $G_t = \Delta G \cdot t + c$ ，代入得 $\Delta G t = \frac{1}{2} \sum_a w_a^S [\Delta G(t-a)] + \frac{1}{2} \sum_a w_a^D [\Delta G(t-a)] + \frac{1}{2}(\bar{s}^S + \bar{s}^D)$ ，其中 $\bar{s} = \sum_a w_a s$ 。整理： $\Delta G (\frac{1}{2}L_S + \frac{1}{2}L_D) = \frac{1}{2}(\bar{s}^S + \bar{s}^D)$ ，即

$$\Delta G = \frac{\bar{s}^S + \bar{s}^D}{L_S + L_D}.$$

这就是年进展 = 两条路径的平均选择差之和除以世代间隔之和。习题 18.15 用 80 年递推的末期斜率与该公式核对，四种策略的差别都小于 10^{-4} 。每代进展大不等于年进展大：后裔测定公牛的每代进展 0.810 大于基因组青年公牛的 0.797，但年进展只有 0.152 对 0.225 ($L_S = 6.15$ 对 2.60)。

推导 18.2 最优贡献的 KKT 结构

令 $c = (c_M, c_F)$ ， $1_M^T c_M = 1_F^T c_F = \frac{1}{2}$ 。拉格朗日函数

$$\mathcal{L} = c^T \hat{a} - \mu (\frac{1}{2} c^T A c - \theta_{\max}) - \lambda_M (1_M^T c_M - \frac{1}{2}) - \lambda_F (1_F^T c_F - \frac{1}{2}) + \eta^T c.$$

对 c_j 求导： $\hat{a}_j - \mu (Ac)_j - \lambda_{s(j)} + \eta_j = 0$ ， $\eta_j \geq 0$ ， $\eta_j c_j = 0$ 。于是活跃候选满足 $\hat{a}_j = \lambda_{s(j)} + \mu (Ac)_j$ ：个体的育种值与它同当前贡献群体的亲缘之和成线性关系；非活跃候选满足“育种值低于其亲缘代价”。 $(Ac)_j$ 是候选 j 与整个“贡献群体”的平均亲缘，因此高 EBV 但与高贡献者近亲的候选会被压低贡献。 μ 同时是共祖约束的影子价格，即效率前沿的斜率 $\partial(\text{进展})/\partial \theta_{\max}$ 。习题 18.16： $\mu = 12.03$ ， $\lambda_{\text{雄}} = 0.220$ ，

$\lambda_{\text{雌}} = 0.086$, 活跃候选的平稳性残差 4.8×10^{-8} , 非入选候选的最大“EBV 减去惩罚”为 $-0.019 \leq 0$, KKT 证书通过。

推导 18.3 配种分配改变的是 F , 不是 θ

设下一代雄、雌亲本的贡献为 c_M, c_F (各和为 $\frac{1}{2}$)。后代群体的平均共祖 (任取两个后代各随机取一个等位基因的概率同源) 为 $\theta = \frac{1}{2}c^T A c$, 只依赖贡献, 与父母如何配对无关: 每个后代的等位基因来自雄、雌亲本的概率由 c 唯一确定。后代自身的近交系数 $F_o = \frac{1}{2}A_{sd}$ 则取决于配对。随机配对时 $E(F_o) = \sum_{s,d} \frac{n_s}{N} \frac{n_d}{N} \cdot \frac{1}{2}A_{sd} = 2c_M^T A_{MF} c_F$; 而 $\theta = \frac{1}{2}c_M^T A_{MM} c_M + c_M^T A_{MF} c_F + \frac{1}{2}c_F^T A_{FF} c_F$ 。最小化 F_o 的指派只改变总和中的交叉项分配, 不影响 θ , 所以它能使后代“暂时”无近交, 但再下一代的近交由 θ 决定, 近交最终仍会累积——这是为什么必须在“选留”阶段而不是“配种”阶段控制长期近交。习题 18.17: 避免近交的配种使后代 F 降到 0, 随机配种期望 0.026。

拓展阅读 最优贡献选择与基因组育种的实践

Meuwissen (1997) 与 Grundy 等 (1998) 提出了最优贡献选择的实用算法; Williams 等 (2015) 总结了遗传多样性管理的框架; Pryce 等 (2012) 与 Daetwyler 等 (2013) 讨论了基因组选择下青年公牛的世代间隔缩短与 ΔF 上升的权衡; Sonesson 等 (2012) 与 Meuwissen 等 (2020) 把基因组关系矩阵用于最优贡献, 以控制“基因组近交”(ROH 长度) 而非系谱近交。对牛业的现实数据, Wiggans 等 (2017) 观察到基因组评定使世代间隔缩短约一半。

易错辨析

- 世代间隔缩短不一定提高年进展: 必须同时考虑准确度下降 (习题 18.20: 青年公牛需 $r > 0.38$ 才能与后裔测定持平)。
- 最优贡献不是“多选一些”: 习题 18.16 中最优贡献在同样共祖水平下只选 18 头, 截断选择选 28 头; 它让少数高 EBV 且低亲缘的个体贡献更多。
- 配种计划不能替代选留约束: 它只把近交推迟 (习题 18.17), 不改变下一代的平均共祖。
- 近交速率要看有效数而非实际数: 8 头公畜、2000 头母畜的 N_e 约为 $4N_m = 32$ 而非 2008。
- 折现不能忽略时间: 在 5% 折现率下, 金字塔每多一年滞后使单位改良的现值下降 9.2% (习题 18.19)。

18.5 习题

一、单项选择题

18.1 ★ [单选] 年遗传进展等于

- (A) 每代进展乘以世代间隔 (B) 每代进展除以世代间隔
(C) 选择差除以表型标准差 (D) 每代进展与近交速率之比

[答案]

18.2 ★★ [单选] 准确度较低的青年公牛策略可能获得更大的年进展, 主要原因是

- (A) 选择强度必然更高 (B) 世代间隔显著缩短
(C) 近交更少 (D) 加性方差更大

[答案]

18.3 ★★ [单选] 在与截断选择相同的平均共祖水平下, 最优贡献选择的平均育种值

- (A) 一定更低 (B) 不会更低 (C) 与截断选择相同
(D) 取决于配种方式

[答案]

18.4 ★★ [单选] 最优贡献的拉格朗日乘数 μ 表示

- (A) 性别比 (B) 共祖约束的影子价格 (C) 遗传力
(D) 选择强度

[答案]

18.5 ★★ [单选] 两头候选公畜 EBV 相同, 但 A 与已高贡献者近亲, B 无亲缘。最优贡献通常使

- (A) A 的贡献大于 B (B) B 的贡献大于 A
(C) 两者相同 (D) 都为零

[答案]

18.6 ★★ [单选] 折现率为 5%, 核心群到商品群的滞后增加 3 年, 单位遗传改良的折现表达 (长期) 约乘以

- (A) 0.95 (B) 0.86 (C) 0.50 (D) 1.0

[答案]

二、判断与改错题

18.7 ★ [判断] 世代间隔缩短必然提高年遗传进展。

[答案]

18.8 ★★ [判断] 最优贡献选择入选的个体数总是多于截断选择。 [答案]

18.9 ★★ [判断] 随机配对时, 后代平均近交系数等于按贡献加权的 $\frac{1}{2}A_{sd}$ 平均。 [答案]

18.10 ★★ [判断] 采用避免近交的配种计划就可以永久消除近交的累积。 [答案]

三、填空题

18.11 ★ [填空] 每代 5 头公畜、25 头母畜的理想群体: $N_e = \underline{\hspace{2cm}}$, $\Delta F = \underline{\hspace{2cm}}$ (用 $1/(2N_e)$), $\Delta F = 1/(8N_m) + 1/(8N_f)$ 给出 $\underline{\hspace{2cm}}$ 。 [答案]

18.12 ★ [填空] 公畜路径 $i = 1.8$ 、 $r = 0.8$ 、 $L = 3$ 年, 母畜路径 $i = 0.9$ 、 $r = 0.5$ 、 $L = 4$ 年, 则年进展 $\Delta G = \underline{\hspace{2cm}}\sigma_A$ 。 [答案]

18.13 ★ [填空] 折现率 5%, 滞后 3 年, 折现因子 $q^3 = \underline{\hspace{2cm}}$ 。 [答案]

18.14 ★ [填空] 交配的两亲本间加性关系为 0.125, 后代近交系数 $F = \underline{\hspace{2cm}}$ 。 [答案]

四、计算题

18.15 ★★ [计算] 基因流与年进展。四种策略(后裔测定公牛、基因组青年公牛、青年公牛 + 基因组选母、仅表型选择)的公、母路径参数见配套数据。用基因流递推迭代 80 年, 估计末期斜率, 与解析公式核对, 比较每代进展与年进展, 并求青年公牛策略与后裔测定持平所需准确度。 [程序] `ch18/ex18_15_gene_flow.py` [答案]

18.16 ★★★ [计算] 最优贡献选择。80 头候选(40 雄 40 雌)的 A 与 EBV 见数据。比较截断选择(8 雄 20 雌)与相同平均共祖下的最优贡献解, 核对 KKT, 并画出不同 $\theta_{\max}$ 的效率前沿。 [程序] `ch18/ex18_16_optimum_contribution.py` [答案]

18.17 ★★★ [计算] 配种计划。以习题 18.16 的最优贡献(每头母畜至多 6 个后代)产生 100 个后代, 用指派算法求最小近交配种, 并与随机配对和最相似配对比较。 [程序] `ch18/ex18_17_mating_plan.py` [答案]

18.18 ★★★ [计算] 多世代模拟。每代 30 雄 30 雌, $h^2 = 0.3$, 系谱 BLUP 评定。比较截断选择(8 雄 16 雌)与 $\Delta F^* = 0.015$ 的最优贡献选择 10 代的进展、近交与方差(4 次重复)。 [程序] `ch18/ex18_18_multigeneration_ocs.py` [答案]

- 18.19** ★★ [计算] 金字塔折现表达。核心—扩繁—商品三层滞后 0、2、4 年，规划期 20 年，折现率 0、5%、10%，比较三种方案（后裔测定、基因组青年公牛、青年公牛 + 基因组选母）的现值收益与成本。 [程序] [ch18/ex18_19_pyramid_discount.py](#) [答案]
- 18.20** ★★ [计算] 青年公牛对后裔测定公牛。考虑准确度不确定 ($r \sim N(0.55, 0.08^2)$) 与近交衰退 ($\delta = 3\sigma_A/\text{单位 } F$)，求盈亏平衡准确度、青年策略占优的概率，以及不同使用年龄下的 r^* 。 [程序] [ch18/ex18_20_young_vs_proven.py](#) [答案]
- 18.21** ★ [计算] 青年公牛策略：公畜路径 $i = 1.9$ 、 $r = 0.6$ 、 $L = 2.6$ 年；母畜路径 $i = 0.8$ 、 $r = 0.45$ 、 $L = 4.5$ 年。求年进展，并与后裔测定方案 (0.152) 比较。 [答案]
- 18.22** ★ [计算] 每代 10 头公畜、40 头母畜。求 N_e 、每代近交增量与 8 代后的近交系数。 [答案]

五、推导与证明题

- 18.23** ★★ [证明] 由基因流递推 $G_t = \frac{1}{2} \sum w_a^S (G_{t-a} + s^S) + \frac{1}{2} \sum w_a^D (G_{t-a} + s^D)$ 推导渐近年进展 $(\bar{s}^S + \bar{s}^D)/(L_S + L_D)$ 。 [答案]
- 18.24** ★★ [证明] 写出最优贡献问题的 KKT 条件，证明对于入选候选 $\hat{a}_j - \lambda_{s(j)} = \mu(Ac)_j$ 并解释其育种意义。 [答案]
- 18.25** ★★ [证明] 证明随机配对的期望后代近交系数为 $\sum_{s,d} \frac{n_s}{N} \frac{n_d}{N} \frac{1}{2} A_{sd}$ ，并说明为什么避免近交的配种不改变下一代群体的平均共祖。 [答案]
- 18.26** ★★★ [证明] 设折现因子 $q = 1/(1+d)$ ，规划期 $H \rightarrow \infty$ ，改良永久表达，证明单位改良的折现表达为 $vq^L/(1-q)$ ，并推出每增加一年滞后使其下降的比例为 $d/(1+d)$ 。 [答案]

六、综合分析与研究设计题

- 18.27** ★★ [综合] 某地方羊品种仅有 30 头公羊、300 头母羊，需要兼顾保种与选育。设计基于最优贡献与最小共祖配种的年度方案，说明约束选择、数据需求与监测指标。 [答案]

18.28 ★★★ [综合] 某奶牛育种联盟考虑从后裔测定转向基因组青年公牛。写一份风险与收益分析：包含盈亏平衡准确度、近交代价、验证计划与逐步过渡的设计。 [答案]

18.29 ★★★ [综合] 某猪育种公司有核心群—扩繁群—商品群三层结构。说明如何用折现表达比较“提高核心群选择准确度”与“缩短基因传递滞后”两种投资，并设计敏感性分析。 [答案]

18.6 参考答案与解析

一、单项选择题

18.1 B. 年进展 = 每代进展 / 世代间隔（取各路径加权）。 [题目]

18.2 B. 见习题 18.15：青年公牛 $L_S = 2.6$ 对后裔测定的 6.15。 [题目]

18.3 B. 最优贡献在相同约束下最大化进展，截断选择是其可行解之一，故不会更低（习题 18.16：+55.8%）。 [题目]

18.4 B. μ 是放松共祖约束一单位所能增加的进展。 [题目]

18.5 B. A 与高贡献者近亲，会被 $\mu(Ac)_j$ 压低（推导 18.2）。 [题目]

18.6 B. $q^3 = 1/1.05^3 = 0.864$ 。 [题目]

二、判断与改错题

18.7 错误。 世代间隔缩短若伴随准确度下降，年进展可能下降；习题 18.20 给出所需最低准确度。 [题目]

18.8 错误。 习题 18.16：最优贡献只选 18 头，而截断选择选 28 头。最优贡献让每头入选个体的贡献不同，并非“多选”。 [题目]

18.9 正确。 见推导 18.3。 [题目]

18.10 错误。 配种分配只改变后代的 F ，不改变下一代群体的平均共祖，近交仍由 θ 累积，只是推迟出现。 [题目]

三、填空题

18.11 $N_e = 4 \times 5 \times 25/30 = 16.67$; $1/(2N_e) = 0.030$; $1/40 + 1/200 = 0.030$, 二者相同。

[题目]

18.12 $(1.8 \times 0.8 + 0.9 \times 0.5)/(3 + 4) = 1.89/7 = 0.270 \sigma_A$ 。 [题目]

18.13 $1/1.05^3 = 0.864$ 。 [题目]

18.14 $F = \frac{1}{2} \times 0.125 = 0.0625$ 。 [题目]

四、计算题

18.15

策略	$L_{\text{公}}$	$L_{\text{母}}$	每代进展	年进展 (解析)	年进展 (递推)	相对仅表型
后裔测定公牛	6.15	4.50	0.810	0.1521	0.1521	1.20
基因组青年公牛	2.60	4.50	0.797	0.2246	0.2246	1.77
青年公牛 + 基因组选母	2.60	3.15	0.975	0.3391	0.3391	2.67
仅表型选择	3.85	4.50	0.530	0.1269	0.1269	1.00

解析式与递推完全一致。基因组青年公牛的每代进展略低于后裔测定，年进展却高 48%；加上基因组选母（缩短 L_D 并提高 r_D ）后进展再提高 51%。青年公牛策略与后裔测定持平所需的准确度仅 $r^* = 0.379$ （强度 1.9）——而基因组评定通常可达 0.5—0.7。 [题目]

18.16 截断选择（8 雄 20 雌）： $\theta = 0.0632$ ，平均 EBV 1.0748；全部候选等贡献（无选择） $\theta = 0.0358$ ，平均 EBV 0.2102。最优贡献在 $\theta_{\text{max}} = 0.0632$ 下：进展 1.6742（+55.8%），入选 18 头（雄 11、雌 7）。KKT： $\mu = 12.03$ ， $\lambda_{\text{雄}} = 0.220$ ， $\lambda_{\text{雌}} = 0.086$ ，残差 4.8×10^{-8} ，非入选候选的最大“EBV 减惩罚”为 -0.019。效率前沿：

θ_{max}	进展	入选数
0.0379	1.178	38
0.0474	1.427	27
0.0569	1.591	21

$\theta_{\max}$	进展	入选数
0.0664	1.711	18
0.0759	1.807	16
0.0854	1.889	14
0.0949	1.962	13
0.1043	2.025	11
0.1138	2.082	9

进展随 $\theta_{\max}$ 单调增但边际递减：从 0.038 到 0.047 (+0.0095) 多获得 0.248，而从 0.104 到 0.114 (+0.0095) 只多 0.057。前沿的斜率正是影子价格 μ 的体现： $\theta_{\max} = 0.0569 \rightarrow 0.0664$ 的平均斜率为 12.6，与 $\mu = 12.03$ 吻合。 [题目]

18.17 100 个后代：入选公畜 8 头（交配次数 44、27、13、7、6、1、1、1），母畜 19 头（每头至多 6 个后代）。

方案	平均 F	最大 F	$F > 0.0625$ 比例	不同亲本对数
最小近交配对	0.0000	0.0000	0	24
随机配对（500 次均值）	0.0262 (SD 0.0045)	—	—	—
最相似配对	0.0725	0.1250	0.58	29

随机配对期望的解析值 0.0262 与 500 次排列均值相差不到 10^{-4} 。最小近交的指派使所有后代 $F = 0$ ，最相似配对则使 58% 后代的 F 超过 0.0625。配种可以把后代近交控制到零，但不改变 θ （推导 18.3），因此下一代的近交风险取决于选留阶段而不是配种阶段。 [题目]

18.18 (4 次重复均值)

世代	截断 ΔG	F	V_A	OCS ΔG	F	V_A
2	0.544	0.0297	0.251	0.483	0.0135	0.282
4	0.960	0.0809	0.200	0.983	0.0391	0.277
6	1.519	0.1312	0.229	1.486	0.0686	0.279
8	2.059	0.1785	0.181	1.974	0.0921	0.264
10	2.489	0.2270	0.177	2.485	0.1209	0.268

10 代后截断选择与最优贡献选择的进展相同（2.489 对 2.485，差 0.1%），但近交系数前者 0.227、后者 0.121，等效每代 ΔF 为 0.0254 对 0.0128（降低 50%）；加性

方差也被保存得更好 (0.177 对 0.268, 相对基础 0.30)。OCS 在最初几代进展略低, 随后追平。注意 $\Delta F^* = 0.015$ 的目标被达到 (实际 0.0128); 截断选择的 $\Delta F = 0.025$ 已接近 “危险” 阈值 (通常认为 >0.02 需干预)。

[题目]

18.19 折现表达 (核心群第 0 年的 1 单位改良, 规划期 20 年, 永久表达, $v = 10$):

折现率	滞后 2 年	滞后 4 年	滞后 6 年	滞后 8 年
0	190.0	170.0	150.0	130.0
5%	115.1	97.4	81.3	66.8
10%	76.0	60.3	47.2	36.5

净现值 (现值收益 - 成本现值):

折现率	后裔测定	基因组青年公牛	青年公牛 + 基因组选母
0	78.3	242.0	362.8
5%	24.9	111.6	166.9
10%	3.5	53.6	79.9

折现率越高, 后裔测定的净现值越低 (10% 时只剩 3.5), 因为它既有额外 2 年滞后又成本最高。金字塔每增加 1 年滞后, 在 5% 折现率下使单位改良的折现表达下降 9.2%。三个方案的排序在所有折现率下不变, 说明结论对折现假设稳健。

[题目]

18.20 后裔测定: $\Delta G = 0.1521/\text{年}$, $\Delta F = 0.00119/\text{年}$, 净进展 0.1486。青年公牛 ($r = 0.55$): $\Delta G = 0.1979$, $\Delta F = 0.00442/\text{年}$, 净进展 0.1846。盈亏平衡准确度: 不计近交 $r^* = 0.379$; 计入近交代价 $r^* = 0.415$ 。准确度不确定下 ($r \sim N(0.55, 0.08^2)$): 年进展更大的概率 0.984; 年净进展更大的概率 0.955; 青年策略净进展均值 0.1846 (SD 0.0214)。

使用年龄 L_S	r^* (不计近交)	r^* (计近交)
2.0	0.331	0.368
2.6	0.379	0.415
3.0	0.411	0.446
3.5	0.451	0.486
4.0	0.491	0.525
5.0	0.571	0.603

青年公牛使用年龄越大,需要的准确度越高:使用到5岁时已需0.57以上。近交代价把盈亏平衡点提高约0.035。青年策略的近交速率是后裔测定的3.7倍(0.0044对0.0012/年),所以关键不在“进展是否更大”,而在“是否能在接受的 ΔF 内保持优势”。

[题目]

18.21 $\Delta G = (1.9 \times 0.6 + 0.8 \times 0.45) / (2.6 + 4.5) = 1.50 / 7.1 = 0.211 \sigma_A / \text{年}$,比后裔测定的0.152高39%。

[题目]

18.22 $N_e = 4 \times 10 \times 40 / 50 = 32$; $\Delta F = 1 / (2 \times 32) = 0.0156$; 8代后 $F = 1 - (1 - 0.0156)^8 = 0.118$ 。

[题目]

五、推导与证明题

18.23 见推导18.1。设 $G_t = \Delta G t + c$ (渐近线性),代入递推并比较系数:左边 $\Delta G t$,右边 $\Delta G t - \Delta G(\frac{1}{2}L_S + \frac{1}{2}L_D) + \frac{1}{2}(\bar{s}^S + \bar{s}^D) + c - c$,其中 $L = \sum w_a a$ 。令两边相等得 $\Delta G(L_S + L_D) = \bar{s}^S + \bar{s}^D$ 。

[题目]

18.24 令 $\eta_j \geq 0$ 为 $c_j \geq 0$ 的乘数, $\mu \geq 0$ 为共祖约束乘数。平稳性: $\hat{a}_j - \mu(Ac)_j - \lambda_{s(j)} + \eta_j = 0$ 。互补松弛: $\eta_j c_j = 0$, 故 $c_j > 0$ 时 $\eta_j = 0$, 得 $\hat{a}_j - \lambda_{s(j)} = \mu(Ac)_j$ 。育种含义: 入选个体的“超额育种值” $\hat{a}_j - \lambda$ 必等于它同当前贡献群体的平均亲缘乘以影子价格。亲缘越近的候选必须有越高的EBV才值得入选; 与贡献群体无亲缘的候选只需EBV略高于 λ 。

[题目]

18.25 随机配对时,后代的父亲为 s 的概率为 n_s / N (N 为后代数),母亲为 d 的概率为 n_d / N , 独立; $F_o = \frac{1}{2} A_{sd}$, 取期望即得。下一代平均共祖 θ' : 任取两个后代各取一个等位基因,该等位基因来自雄亲本 s 的概率为 $c_s = n_s / (2N)$, 来自雌亲本 d 的概率为 $c_d = n_d / (2N)$ 。两个独立抽取的等位基因IBD概率为 $\sum_{j,k} c_j c_k f_{jk}$ (f 为共祖系数 $= \frac{1}{2} A$), 即 $\frac{1}{2} c^T A c$, 只与贡献有关,不随配对而变。

[题目]

18.26 $PV = v \sum_{u=L}^{\infty} q^u = v q^L / (1 - q)$ 。因 $q = 1 / (1 + d)$, $1 - q = d / (1 + d)$ 。滞后增加一年, $q^{L+1} / q^L = q$, 下降比例为 $1 - q = d / (1 + d)$ 。 $d = 5\%$ 时为4.8%; 有限规划期内因后期截断,下降比例更大(习题18.19中9.2%)。

[题目]

六、综合分析与研究设计题

18.27 方案: (1) 数据: 系谱(至少5代完整)、基因分型(如有,用基因组关系矩阵)、各个体的EBV(体重、繁殖、抗病); (2) 选留: 每年在候选集上求最优贡献,约束 $\Delta F \leq 0.01 / \text{代}$ (保种目标), 性别约束各1/2, 限制每头公羊至多使用 k 只母羊

(受自然交配能力限制); (3) 配种: 用指派算法最小化后代 F , 同时避免全同胞与半同胞配种 (习题 18.17); (4) 监测: 每年报告 θ 、 $N_e = 1/(2\Delta F)$ 、等效世代、近交系数分布与 ROH; (5) 风险管理: 设置“冻精库”保留稀有血统 (即保留未被选中的家系贡献); (6) 校准: 每 3 年对比模拟与实际 ΔF , 如实际更高则降低约束; (7) 注意: 30 头公羊的 $N_e \leq 4N_m = 120$ 的上限只在平均使用时成立, 不均衡使用时 N_e 会远小于该值。

[题目]

18.28 风险与收益: (1) 收益: 习题 18.15 显示年进展由 0.152 升至 0.225 (+48%); (2) 盈亏平衡: $r^* = 0.38$ (不计近交)、0.415 (计近交), 实际准确度需在目标性状上通过独立验证 (第 29 章), 以前瞻性验证的回归斜率与相关为准; (3) 准确度的不确定性: 若 $r \sim N(0.55, 0.08^2)$, 年净进展更大的概率为 95.5%, 意味着仍有 4.5% 的情景劣于后裔测定, 应设置检查点; (4) 近交代价: 青年策略 ΔF / 年为后裔测定的 3.7 倍; 必须用最优贡献约束 ΔF (习题 18.18: 同样进展 ΔF 可降 50%); (5) 过渡: 先在 20% 的配种中使用青年公牛, 保留后裔测定的参照; (6) 验证计划: 保留群 (不含基因组选择) 与追踪后代表现, 用后裔测定结果更新参考群; (7) 经济分析: 用折现表达 (习题 18.19) 计算净现值, 在 5%—10% 折现率下对比, 并做对成本与准确度的敏感性分析。

[题目]

18.29 折现比较: (1) 两种投资的收益差别体现在两条路径: 提高核心群准确度 r 提高 ΔG (线性, $\Delta G \propto r$); 缩短滞后 L 提高每单位改良的折现表达 (指数, q^L)。 (2) 习题 18.19: 在 5% 折现率下, 从滞后 6 年降到 4 年使单位改良的折现表达由 81.3 升至 97.4 (+20%); 而 r 从 0.55 升到 0.66 也是 +20% 的进展。用两个方案的成本折算每单位现值收益即可比较。 (3) 敏感性: 折现率 0—10%、规划期 10—30 年、价值 v 的 $\pm 30\%$ 、准确度不确定 (用蒙特卡洛); (4) 约束: 缩短滞后通常伴随更多投资于扩繁群的基础设施, 需把年成本折现加入; (5) 报告: 用“每单位现值收益的成本”与“盈亏平衡折现率”呈现, 并说明结论对折现假设稳健的范围 (习题 18.19 中三方案的排序在 0—10% 都不变)。

[题目]

第六篇

遗传漂变、近交与杂交

小群体与交配体系有何遗传后果。

本篇习题训练：有效群体大小、近交衰退、杂种优势与杂交育种体系。

遗传漂变、有效群体大小与近交

19.1 本章导学

学习目标

1. 理解有限群体中近交系数的递推 $F_t = 1 - (1 - \frac{1}{2N_e})^t$ ，掌握由家系大小方差、性比、世代重叠求有效群体大小的方法。
2. 能区分系谱近交、实现近交和基因组近交（ROH、 F_{HOM} 、 F_{GRM} 、 F_{UNI} ），理解各自的参照与偏倚。
3. 理解近交对均值（衰退）与遗传方差（系内下降、系间上升）的影响，并会处理显性与隐性有害等位基因的特殊情形。
4. 理解清除（purging）：缓慢近交与快速近交在相同 F 下的适合度差异，及“清除近交系数”的预测。
5. 能把长期遗传贡献同时用于预测近交速率与遗传进展。
6. 会评估近交衰退估计的偏倚与标准误：浅系谱的衰减偏倚、家系相关的影响。

重点与难点

重点： $N_e = 4N/(V_k + 2)$ ； $E(M) = M_0 - 2p_0q_0dF$ ；系内加性方差 $(1 - F)V_{A0}$ 、系间方差 $2FV_{A0}$ ； $\Delta F \approx \frac{1}{4} \sum r_i^2$ ；ROH 与片段长度的年龄解释。

难点： 有害隐性位点上的系内加性方差可在中等 F 暂时上升；清除不是“消除有害基因”；实现近交与系谱期望之差；浅系谱与测量误差。

本章承接第 12 章的关系与近交矩阵、第 14 章的选择反应，并为第 26 章基因组关系矩阵与第 36 章约束配种决策提供近交控制的概念工具。

19.2 知识结构图




图 19.1 第 19 章知识结构图

右侧三支是群体规模与近交的“动力学”，左侧四支是“遗传后果、测量与管理”。

19.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
近交递推	$F_t = \frac{1}{2N} + (1 - \frac{1}{2N})F_{t-1}$	理想群体
近交增量	$\Delta F = 1/(2N_e)$	一阶近似
性比	$N_e = \frac{4N_m N_f}{N_m + N_f}$	其余理想
家系大小方差	$N_e \approx \frac{4N}{V_k + 2}$	V_k 为留种家系大小方差
长期贡献	$\Delta F \approx \frac{1}{4} \sum_i r_i^2$	Woolliams-Bijma
近交衰退	$E(M) = M_0 - 2p_0 q_0 dF$	对 F 线性
系内加性方差	$E(V_{A,w}) = (1 - F)V_{A0}$	无显性
系间方差	$\text{Var}(M) = 2FV_{A0}$	无显性
近交负荷	$\delta = \sum s(1 - 2h)p_0 q_0$	有害位点
清除系数	$g_t = [(1 - \frac{1}{2N})g_{t-1} + \frac{1}{2N}](1 - 2dF_{t-1})$	$d = s(1 - 2h)/2$

概念	公式或定义	成立条件与提示
ROH 片段年龄	代数 $\approx 100/(2L)$ (L 单位 cM)	片段越长越近
衰减偏倚	$b_{\text{obs}} = b \frac{\text{Cov}(F, x)}{\text{Var}(x)}$	x 为带误差的近交指标

19.4 补充内容与公式推导

推导 19.1 家系大小方差与有效群体大小

考虑 N 个个体、大小恒定的世代，每个个体留下的后代数 k_i 均值为 2，方差 V_k 。两个随机抽取的后代的等位基因来自同一亲本的概率为 $\sum_i k_i(k_i - 1)/[2N(2N - 1)] \cdot 2 \cdot \frac{1}{2}$ 的量级；经整理，同源于同一亲本等位基因的概率为 $\frac{1}{2N} \cdot \frac{V_k + 2}{4} \cdot 2$ 。更直接的做法：近交增量 $\Delta F = \frac{1}{2N_e}$ 等于“两个等位基因来自同一亲本的同一配子”的概率，即 $\frac{E[k(k - 1)]}{2N \cdot 2N} \cdot \dots$ 。最终的标准结果为

$$N_e = \frac{4N - 2}{V_k + 2} \approx \frac{4N}{V_k + 2}.$$

$V_k = 2$ (泊松) 时 $N_e \approx N$ ； $V_k = 0$ (每个亲本恰好留下两个后代) 时 $N_e \approx 2N$ ； $V_k > 2$ (优秀家系多留) 时 $N_e < N$ 。习题 19.15 的模拟 ($N = 40$)：泊松 $\bar{V}_k = 1.905$ ，预测 $N_e = 41.0$ ，实现 41.1；等量留种 $V_k = 0$ ，预测 80，实现 78；偏斜留种 $\bar{V}_k = 7.73$ ，预测 16.4，实现 16.5，即 N_e 只有 N 的 41%。

推导 19.2 漂变对均值与方差的影响

单位点基因型值 $A_1A_1 = a$ 、 $A_1A_2 = d$ 、 $A_2A_2 = -a$ ， A_1 频率 p 。系均值 $M = a(p - q) + 2pqd$ 。漂变使系间 $E(p) = p_0$ ， $E(pq) = p_0q_0(1 - F)$ ，故

$$E(M) = a(p_0 - q_0) + 2dp_0q_0(1 - F) = M_0 - 2p_0q_0dF.$$

近交衰退对 F 线性，斜率 $-2p_0q_0d$ ，仅当 $d \neq 0$ 时存在。系内加性方差 $V_{A,w} = 2pq\alpha^2$ ， $\alpha = a + d(q - p)$ 。无显性时 $\alpha = a$ ， $E(V_{A,w}) = 2a^2E(pq) = (1 - F)V_{A0}$ ；系间方差 $\text{Var}(M) = 4a^2 \text{Var}(p) = 4a^2 \cdot 2p_0q_0F \cdot \frac{1}{2} = 2FV_{A0}$ (用 $\text{Var}(p) = p_0q_0F$)。两者相加 $E(V_{A,w}) + \text{Var}(M) = (1 + F)V_{A0}$ ：总加性方差在系统层面反而增加。当存在显性并且 A_1 稀少时， α 随 p 变化，系内加性方差可在中等 F 时上升——习题 19.16：完全隐性、 $q_0 = 0.1$ 时，系内加性方差在 $F = 0.537$ 达到初始的 10.08 倍。

推导 19.3 测量误差与近交衰退的衰减

设真实模型 $y = \mu + bF + e$, 观察到带误差的指标 $x = F + u$ 或任意与 F 相关的指标。最小二乘斜率为 $\hat{b}_x = \text{Cov}(y, x) / \text{Var}(x) = b \text{Cov}(F, x) / \text{Var}(x) + \text{Cov}(e, x) / \text{Var}(x)$ 。当 $e \perp x$ 时, 衰减系数 $\lambda = \text{Cov}(F, x) / \text{Var}(x)$ 。若 $x = F_{\text{PED}}$ 仅包含近交的期望部分, 则 $\text{Cov}(F, x) = \text{Var}(x)$ 但 $\text{Cov}(F, x) \leq \text{Var}(F)$ ——此时 $\lambda = 1$ 无衰减 (经典 Berkson 误差); 若 $x = F_{\text{HOM}}$ 等带随机误差的估计量, $\lambda < 1$ 。习题 19.18: 以真实近交回归得 $b = -41.95$ (SE 2.11), $F_{\text{ROH} \geq 1\text{cM}}$ 几乎无偏 (-41.88), 系谱 F 得 -26.14 ($\lambda = 0.70$), 样本频率的 F_{GRM} 只有 -25.36 ($\lambda = 0.53$)。参照频率的选择决定偏倚: 用创始者频率的 F_{GRM} 为 -36.91 ($\lambda = 0.86$)。

拓展阅读 基因组近交与保护遗传学

Keller 等 (2011)、Kardos 等 (2016) 提出 F_{ROH} 比系谱近交更能反映实现近交; Hedrick 与 Garcia-Dorado (2016) 回顾了清除的理论与实证; Bosse 等 (2019) 与 Pérez-Pereira 等 (2022) 在猪与牛中用 ROH 分层研究衰退的片段长度依赖; Caballero 等 (2017) 与 García-Dorado (2012) 给出清除系数的预测公式。Meuwissen 等 (2020) 指出基因组选择会增加每代的 ΔF , 需要在育种计划中显式控制。

易错辨析

- 有效群体大小不是实际头数: 等量留种使 N_e 接近 $2N$, 偏斜留种可使 N_e 降到 $0.4N$ 。
- 近交衰退不是“有害基因的存在”本身: 它要求位点存在显性 ($d \neq 0$); 加性位点无衰退。
- 快速近交与缓慢近交的相同 F 并不等价: 慢近交使有害隐性等位基因被选择清除 (习题 19.17: $F = 0.40$ 时适合度 0.542 对 0.471)。
- 浅系谱会使近交被低估且衰退被稀释: 习题 19.20 的浅系谱使衰退估计向零偏约 18%。
- ROH 的长度反映共祖的时间: 长片段来自近祖先, 短片段来自远祖先; 只用长片段会错过古老近交。

19.5 习题

一、单项选择题

- 19.1 ★ [单选] 当每个亲本恰好留下两个后代 ($V_k = 0$) 时, 近似的有效群体大小为
(A) $N/2$ (B) N (C) $2N$ (D) $4N$

[答案]

- 19.2 ★ [单选] 下列哪种情形一般会使近交增量 ΔF 变大?

- (A) 家系大小方差增大 (B) 性比趋于均衡
(C) 世代间隔缩短到零 (D) 每代个体数增加

[答案]

- 19.3 ★★ [单选] 相同的近交系数下, 更容易出现“清除”效应的是

- (A) 快速近交 (B) 缓慢近交 (C) 二者相同
(D) 与近交速率无关

[答案]

- 19.4 ★★ [单选] 在检出实现近交的变异方面, 最敏感的是

- (A) 系谱近交 F_{PED} (B) 基因组 ROH 比例
(C) 世代数 (D) 近交系数的期望值

[答案]

- 19.5 ★★ [单选] 用仅含近三代的浅系谱 F 回归估计近交衰退, 结果往往

- (A) 无偏 (B) 向零偏 (衰减)
(C) 向远离零的方向偏 (D) 符号相反

[答案]

- 19.6 ★★ [单选] 完全隐性有害位点、隐性等位基因频率低时, 漂变使系内加性方差

- (A) 单调下降 (B) 在中等 F 暂时上升 (C) 不变
(D) 单调上升

[答案]

二、判断与改错题

- 19.7 ★ [判断] 无显性时, 系内加性方差的期望为 $(1 - F)V_{A0}$ 。

[答案]

- 19.8 ★★ [判断] 家系指数选择的近交速率与随机留种相同。

[答案]

- 19.9 ★★ [判断] 用样本等位基因频率计算的 F_{HOM} 均值可以为负。

[答案]

- 19.10 ★★ [判断] 快速近交与缓慢近交在相同近交系数下, 适合度相同。

[答案]

三、填空题

19.11 ★ [填空] $N = 60$, 留种家系大小方差 $V_k = 4$, $N_e \approx$ _____。 [答案]

19.12 ★ [填空] $N_e = 20$, 10 代后近交系数 $F_{10} =$ _____。 [答案]

19.13 ★ [填空] $N_e = 50$, $\Delta F =$ _____; 达到 $F = 0.2$ 约需_____代。 [答案]

19.14 ★ [填空] $F = 0.4$ 时, 无显性性状的系内加性方差为 V_{A0} 的_____倍, 系间方差为_____倍。 [答案]

四、计算题

19.15 ★★ [计算] 家系大小方差与 N_e 。每代 20 公 20 母, 比较泊松留种、等量留种与偏斜留种 (伽玛权重) 下的 V_k 、预测与实现 N_e 及末代近交, 重复 40 次。 [程序] `ch19/ex19_15_family_size_ne.py` [答案]

19.16 ★★★ [计算] 漂变下方差的再分配。 $N_e = 10$, 用 Wright-Fisher 转移矩阵精确计算完全隐性 ($q_0 = 0.1$, $a = d = 1$) 与部分显性 ($q_0 = 0.2$, $a = 1$, $d = 0.5$) 情形下, 系内加性与显性方差、系间方差、系均值衰退随世代的变化。 [程序] `ch19/ex19_16_variance_redistribution.py` [答案]

19.17 ★★★ [计算] 清除。近致死位点 (60 个, $q_0 = 0.02$, $s = 1$, $h = 0.02$) 与轻度有害位点 (200 个, $q_0 = 0.10$, $s = 0.05$, $h = 0.2$), 比较 $N = 8$ 与 $N = 30$ 的快速与缓慢近交以及无选择对照, 与“清除近交系数”预测对照。 [程序] `ch19/ex19_17_purging.py` [答案]

19.18 ★★★ [计算] 基因组近交。5 公 15 母、8 代的小群体, 4 条 1 M 染色体共 6000 个 SNP, 计算 F_{PED} 、 F_{ROH} 、 F_{HOM} 、 F_{GRM} 、 F_{UNI} , 比较其与真实 IBD 近交的相关及近交衰退估计。 [程序] `ch19/ex19_18_genomic_inbreeding.py` [答案]

19.19 ★★★ [计算] 长期遗传贡献。每代 10 公 40 母, 比较随机、表型与家系指数选留, 核对 $\Delta F \approx \frac{1}{4} \sum r_i^2$ 与 $\Delta G \approx \sum r_i m_i$ 。 [程序] `ch19/ex19_19_long_term_contributions.py` [答案]

- 19.20** ★★★ [计算] 近交衰退的估计。闭锁群体 (6 公 18 母, 每代 96 个后代) 仅对最后三代有记录, 真实 $b = -1.5$ 。比较完整系谱与浅系谱 (第 5 代前视为未知) 下的 OLS 与 GLS 估计的偏倚、SE 与覆盖率。[程序] [ch19/ex19_20_depression_estimation.py](#) [答案]
- 19.21** ★ [计算] 每代 12 头公畜、36 头母畜的闭锁群体。求 N_e 、 ΔF 以及近交系数达到 0.10 所需的代数。 [答案]
- 19.22** ★ [计算] 某猪场产仔数的近交衰退为每单位 F 减少 3.5 头。母猪 $F = 0.15$ 与 $F = 0.05$ 的差异是多少? 若 5000 头母猪的平均 $F = 0.08$, 每年因近交损失多少头仔猪 (每头母猪年产 2.2 窝)? [答案]

五、推导与证明题

- 19.23** ★★ [证明] 由 N 个个体的世代、每个亲本留下后代数 k 的均值 2、方差 V_k , 推导 $N_e \approx 4N/(V_k + 2)$ 。 [答案]
- 19.24** ★★ [证明] 证明在漂变 (对 $E(p) = p_0$) 下, 系均值的期望 $E(M) = M_0 - 2p_0q_0dF$, 并说明为什么衰退对 F 线性。 [答案]
- 19.25** ★★ [证明] 证明无显性时 $E(V_{A,w}) = (1 - F)V_{A0}$ 、 $\text{Var}(M) = 2FV_{A0}$, 并说明二者之和。 [答案]
- 19.26** ★★★ [证明] 证明用带测量误差的近交指标 x 回归的斜率满足 $\hat{b}_x = b \frac{\text{Cov}(F, x)}{\text{Var}(x)} + \frac{\text{Cov}(e, x)}{\text{Var}(x)}$, 并分析经典误差与 Berkson 误差下的差异。 [答案]

六、综合分析与研究设计题

- 19.27** ★★ [综合] 某濒危地方羊品种仅有 12 头公羊、80 头母羊, 系谱只有近 4 代。设计一个保种计划: 包括 N_e 估计、近交监测指标与配种规则。 [答案]
- 19.28** ★★★ [综合] 某猪公司想用基因组数据评估产仔数的近交衰退。给出分析方案: 近交指标的选择、模型、对家系相关的处理、片段长度分层与验证。 [答案]
- 19.29** ★★★ [综合] 某小型育种群发现一个隐性致死等位基因 (携带者频率 8%)。比较 “全面淘汰携带者” “基因检测后避免携带者 $\times$ 携带者配种” “清除” 三种策略的近交与进展后果。 [答案]

19.6 参考答案与解析

一、单项选择题

- 19.1 C。** $N_e \approx 4N/(0 + 2) = 2N$ 。 [题目]
- 19.2 A。** $N_e = 4N/(V_k + 2)$, V_k 越大, N_e 越小, ΔF 越大。 [题目]
- 19.3 B。** 缓慢近交使选择有时间清除有害隐性等位基因 (习题 19.17)。 [题目]
- 19.4 B。** ROH 反映实现近交, 系谱 F 只给期望 (习题 19.18: F_{ROH} 与真实 IBD 近交相关 0.999, F_{PED} 仅 0.303)。 [题目]
- 19.5 B。** 浅系谱使 F 被低估并含误差, 回归向零衰减 (习题 19.20)。 [题目]
- 19.6 B。** 见习题 19.16 与推导 19.2。 [题目]

二、判断与改错题

- 19.7 正确。** 推导 19.2。 [题目]
- 19.8 错误。** 家系指数选择使同一家系成员一起入选, V_k 增大, ΔF 增大 (习题 19.19: 随机 0.0146, 表型 0.0166, 家系指数 0.0248)。 [题目]
- 19.9 正确。** 以样本频率为参照时, F_{HOM} 均值趋于 0 (本题模拟为 -0.031), 负值只表示“比样本平均杂合更多”。 [题目]
- 19.10 错误。** 缓慢近交下选择清除了部分有害等位基因, 在相同 F 下适合度更高 (习题 19.17: $F = 0.40$ 时 0.542 对 0.471)。 [题目]

三、填空题

- 19.11** $4 \times 60/(4 + 2) = 40$ 。 [题目]
- 19.12** $1 - (1 - 1/40)^{10} = 0.224$ 。 [题目]
- 19.13** $\Delta F = 1/(2 \times 50) = 0.01$; $t = \ln(0.8)/\ln(0.99) = 22.2$, 约 22 代。 [题目]
- 19.14** 系内 $(1 - F) = 0.6$ 倍, 系间 $2F = 0.8$ 倍。 [题目]

四、计算题

- 19.15** ($N = 40$, 20 代, 40 次重复)

方案	平均 V_k	预测 N_e	实现 ΔF	实现 N_e	N_e/N	末代 F
泊松	1.905	41.0	0.0122	41.1	1.03	0.208
等量	0.000	80.0	0.0064	78.0	1.95	0.114
偏斜	7.733	16.4	0.0302	16.5	0.41	0.439

公式 $4N/(V_k + 2)$ 与实现值的偏差都小于 30% (实际上最大不足 5%)。等量留种使 20 代后近交仅 0.114, 而偏斜留种达 0.439——同样 40 头个体, 近交相差近 4 倍。结论: 保种的关键是控制家系大小差异, 而不是单纯增加头数。 【题目】

19.16 ($N_e = 10$) 完全隐性 ($q_0 = 0.1, a = d = 1, V_{A0} = 0.0072, V_{D0} = 0.0324, M_0 = 0.98$):

t	F	系内 V_A ($/V_{A0}$)	系间方差	衰退
2	0.098	3.56	0.51	-0.0176
6	0.265	7.92	3.64	-0.0477
10	0.401	9.95	8.67	-0.0722
15	0.537	10.08 (最大)	15.79	-0.0966
30	0.785	6.03	33.01	-0.1414

(方差栏以 V_{A0} 为单位) 部分显性 ($q_0 = 0.2, d = 0.5$): 系内加性方差最大为 1.111 倍 ($F = 0.185$)。两种情形下衰退都等于理论值 $-2p_0q_0dF$ (精确到 10^{-10}); 无显性时系内为 $(1 - F)V_{A0}$ 、系间为 $2FV_{A0}$ 。结论: 低频隐性有害等位基因下, 近交使隐性纯合子出现, 系内加性方差暂时上升至原来的 10 倍, 这是“漂变能增加可选择的变异”的典型例子, 但最终下降。 【题目】

19.17 近致死位点: $\delta = 1.129, d = 0.480$; 轻度有害位点: $\delta = 0.540, d = 0.015$ 。

F	快速近交 $N = 8$	不消除预测	缓慢近交 $N = 30$
0.20	$W = 0.486$ (致死 $q = 0.0160$)	0.421	0.535 ($q = 0.0105$)
0.40	0.471 ($q = 0.0085$)	0.301	0.542 ($q = 0.0057$)

无选择对照中模拟 W 平均高于逐位点预测 6.3% (个体近交的变异使 $E[\exp(-\delta F_i)] > \exp(-\delta EF_i)$, 是 Jensen 不等式); 近致死与轻度有害纯合子频率与 $q_0^2 + p_0q_0F$ 的偏差不超过 2.13 个标准误。结论: 缓慢近交保留了更高的适合度, 致死等位基因频率下降更少但已被选择压低; 快速近交 ($N = 8$) 还出现 18 次候选不足 N 个存活者的情形——说明过小群体的生存瓶颈。 【题目】

19.18 (末代 300 个体, 400 cM、6000 SNP)

指标	均值	与真实相关	衰退估计 b	λ
F_{PED}	0.2282	0.303	-26.14	0.701
F_{true}	0.2224	1.000	-41.95	1.000
$F_{\text{ROH} \geq 1\text{cM}}$	0.2310	0.999	-41.88	0.998
$F_{\text{ROH} \geq 4\text{cM}}$	0.2154	0.998	-41.23	0.980
F_{HOM}	-0.0308	0.993	-31.04	0.741
F_{GRM} (样本频率)	-0.0308	0.674	-25.36	0.534
F_{GRM} (创始频率)	0.3059	0.989	-36.91	0.864
F_{UNI}	-0.0322	0.925	-39.78	0.909

按片段长度分层的真实 IBD 贡献: [1,4) cM 0.0101, [4,8) 0.0278, [8,16) 0.0495, ≥ 16 0.1344, 长片段与“近祖先”对应(代数 $\approx 100/(2L)$): 25、8.8、4.4、1.2 代。系谱期望与实现近交均值接近 (0.2282 对 0.2224), 但个体水平 $\text{SD}(F_{\text{true}} - F_{\text{PED}}) = 0.107$ ——系谱近交丢失了几乎所有个体差异。 【题目】

19.19 每代 10 公 40 母, $h^2 = 0.3$:

方案	实现 ΔF	$\frac{1}{4} \sum r^2$	实现 ΔG	$\sum r \cdot m$	$\sum r^2$ /随机	有贡献者
随机	0.0146	0.0136	0.021	0.050	1.00	35.6
表型	0.0166	0.0158	0.514	0.566	1.16	34.1
家系指数	0.0248	0.0239	0.532	0.594	1.76	24.1

性别比公式 $N_e = 32.0$ 、 $\Delta F = 0.0156$ 。家系指数选择的进展只比表型选择多 3.5%, 但 ΔF 高 49% (0.0248 对 0.0166) ——“选更多同家系个体”换来的是近交的快速累积, 而不是更高的进展。长期贡献预测 $\frac{1}{4} \sum r^2$ 与实现 ΔF 的偏差在 5% 以内; $\sum rm$ 略高估实现 ΔG (8%—11%), 因为忽略了 Bulmer 效应。 【题目】

19.20 (真实 $b = -1.5$, 300 次重复, 平均 F : 完整 0.151, 浅系谱 0.027, 二者相关 0.766)

方法	$\hat{b}$ 均值	偏倚	SD	平均 SE	覆盖率
OLS-完整	-1.526	-0.026	1.311	1.020	0.88
OLS-浅系谱	-1.243	+0.257	1.455	1.146	0.88
GLS-完整	-1.516	-0.016	1.081	1.072	0.95
GLS-浅系谱	-1.231	+0.269	1.183	1.214	0.94

三点结论：(1) 浅系谱使估计向零偏约 17%—18% (衰减偏倚)，所有标准误之外的系统误差；(2) OLS 忽略家系间的相关，SE 偏小 (1.02 对实际 SD 1.31)，覆盖率仅 0.88；GLS 通过 A 校正了这一点，SE (1.07) 与 SD (1.08) 一致，覆盖率 0.95；(3) GLS 也比 OLS 更精确 (SD 1.08 对 1.31)。但这种精度提升仍无法消除浅系谱的偏倚——测量误差必须通过更深的系谱或基因组近交指标解决。 [题目]

19.21 $N_e = 4 \times 12 \times 36/48 = 36$; $\Delta F = 1/72 = 0.0139$; $t = \ln(0.9)/\ln(1 - 0.0139) = 7.6$, 约 8 代。 [题目]

19.22 $(0.15 - 0.05) \times 3.5 = 0.35$ 头仔猪/窝。平均 $F = 0.08$ 时每窝少 0.28 头，每头母猪每年少 $0.28 \times 2.2 = 0.62$ 头，5000 头共 3080 头仔猪/年。 [题目]

五、推导与证明题

19.23 设 N 个个体各自留下 k_i 个后代 ($\sum k_i = 2N$)。下一代某个体的两个等位基因来自同一亲本的同一个等位基因的概率，即近交增量 ΔF 的主要贡献： $\Delta F \approx \frac{\sum_i k_i(k_i - 1)}{(2N)^2}$ 。... 对于泊松情形可得 $1/(2N)$ 。一般地，令第 i 个亲本对下一代的贡献为 $k_i/(2N)$ (个体数 N)， $\Delta F \approx \frac{1}{2} \sum_i (k_i/2N)^2 \cdot \frac{1}{2} \dots$ 。用 $\sum k_i^2 = N(V_k + 4)$ (因均值 2, $E(k^2) = V_k + 4$): $\sum (k_i/2N)^2 = N(V_k + 4)/(4N^2) = (V_k + 4)/(4N)$ 。近交增量 $\Delta F = \frac{1}{4} \sum_i (\text{长期贡献})^2$ (推导 19.4 的特例) $\times 2$ (两亲本) 后得 $\Delta F = (V_k + 2)/(8N) \dots$ 经与 $\Delta F = 1/(2N_e)$ 对照得 $N_e = 4N/(V_k + 2)$ 。具体地，泊松 $V_k = 2$ 给 $\Delta F = 1/(2N)$ 作校准，得到的标准表达为 $N_e = (4N - 2)/(V_k + 2)$ 。数值核对见习题 19.15。 [题目]

19.24 $M = a(p - q) + 2pqd = a(2p - 1) + 2dp(1 - p)$ 。取期望： $E(p) = p_0$, $E[p(1 - p)] = p_0q_0 - \text{Var}(p) = p_0q_0(1 - F)$ (用 $\text{Var}(p) = p_0q_0F$)。故 $E(M) = a(2p_0 - 1) + 2dp_0q_0(1 - F) = M_0 - 2dp_0q_0F$ 。对 F 线性是因为 M 对 p 是二次函数，二次项的期望由 $\text{Var}(p) \propto F$ 决定，而 $E(p)$ 不变。若 $d = 0$, M 对 p 线性， $E(M) = M_0$ 不变，无衰退。 [题目]

19.25 无显性： $\alpha = a$, $V_{A,w} = 2pqa^2$, 期望 $2a^2p_0q_0(1 - F) = (1 - F)V_{A0}$ ($V_{A0} = 2a^2p_0q_0$)。系均值 $M = a(2p - 1)$, $\text{Var}(M) = 4a^2 \text{Var}(p) = 4a^2p_0q_0F = 2FV_{A0}$ 。二者之和 $(1 + F)V_{A0}$ ：总加性方差 = 系内期望 + 系间方差，在加性模型下随 F 增加 (例如 $F = 0.4$ 时为 1.4 倍)；这是“近交使遗传变异从系内转移到系间，并总体上放大”的定量表达。 [题目]

19.26 $y = \mu + bF + e$, $\text{Cov}(y, x) = b \text{Cov}(F, x) + \text{Cov}(e, x)$, 除以 $\text{Var}(x)$ 得所述等式。经典误差 $x = F + u$, $u \perp F, e$: $\text{Cov}(F, x) = \text{Var}(F)$, $\text{Var}(x) = \text{Var}(F) + \text{Var}(u)$,

$\lambda = \text{Var}(F)/[\text{Var}(F) + \text{Var}(u)] < 1$, 衰减。Berkson 误差 $F = x + u$, $u \perp x$: $\text{Cov}(F, x) = \text{Var}(x)$, $\lambda = 1$, 无衰减但方差增大。系谱近交 $F_{\text{PED}} = E(F \mid \text{系谱})$ 属 Berkson 型 (无衰减); 浅系谱则同时包含“系统低估”, 其 x 与 F 的关系为 $F = \beta x + \epsilon$ 型, 衰减系数为 $\text{Cov}(F, x)/\text{Var}(x)$, 可小于 1 (习题 19.20: 约 0.82)。

[题目]

六、综合分析与研究设计题

19.27 方案: (1) N_e : 用性比公式 (12、80: $N_e = 4 \times 12 \times 80/92 = 41.7$) 为上限, 再用系谱估计的实际 ΔF (世代平均法与个体增量法) 修正; (2) 近交监测: 每年报告 F_{PED} 与系谱完整度指标 (ECG、PEC, 第 12 章), 可能时用低密度 SNP 估计 F_{ROH} 与亲缘关系; (3) 配种: 每年用最优贡献 (第 18 章) 限制 $\Delta F \leq 0.01$, 每头公羊的使用上限 (如不超过母羊数的 15%), 避免全同胞和半同胞交配, 利用最小共祖配种; (4) 扩大有效含量: 保留冻精、使用“公羊轮换”以延长世代间隔; (5) 风险: 对近 4 代之前的系谱缺失, 不宜用 F_{PED} 对比其他品种; (6) 目标: $N_e \geq 50$ 或每代 $\Delta F < 1\%$ (保护遗传学的常用准则)。

[题目]

19.28 方案: (1) 指标: F_{ROH} (按长度分层, 如 > 8 、1–8 Mb) 为的首选, 辅以 F_{UNI} ; F_{GRM} 使用创始群体/参考群体频率, 不用样本频率 (习题 19.18); (2) 模型: $y = \mu + bF + \text{其他固定效应} + a + e$, 用含基因组关系矩阵 G 的混合模型 (GLS) 处理家系相关, 避免 OLS 的 SE 偏小 (习题 19.20); (3) 分层: 把 F_{ROH} 拆为不同长度区间, 分别估计衰退, 长片段对应近期近交, 预期效应更大; (4) 验证: 用另一世代做样本外检验; 用置换或自助 (按家系) 估计 SE; (5) 解释: 衰退是群体特定的, 需要与基础群体对照; (6) 结论报告: 每单位 F_{ROH} 的产仔数下降 (置信区间) 与每代 ΔF 目标下的预期损失。

[题目]

19.29 比较: (1) 全面淘汰携带者: 消除致死等位基因的危害, 但携带者频率 8% 意味着淘汰 8% 个体, 且若携带者含有高遗传价值, 则进展下降; 还会降低 N_e (家系丢失); (2) 基因检测后避免携带者 $\times$ 携带者配种: 致死纯合子完全避免 (1/4 的携带者交配后代死亡), 保留全部遗传变异, 不增加 ΔF ; 成本是检测费用, 但长期隐性频率不降低, 需持续检测; (3) 清除: 依赖自然选择, 对致死等位基因有效, 但慢 (8% 携带者对应 $q = 0.04$, 每代损失约 q^2), 且在小群体中易被漂变固定; 快速近交会增大这一风险 (习题 19.17: 快速近交下近致死 q 迅速下降但群体几乎无法维持)。**推荐:** 用检测避免有风险的配种, 同时用最优贡献控制 ΔF , 携带者不淘汰; 对不再需要该等位基因的核心群体, 可在两三代内用标记辅助选择降低其频

率。

[题目]

杂种优势、配合力与杂交育种体系

20.1 本章导学

学习目标

1. 能由单位点基因型值模型推出中亲杂种优势 $H_{F_1} = \sum d_k y_k^2$ ，并解释方向性显性与亲本频率差缺一不可。
2. 掌握 F_2 及随机交配后代杂种优势减半的机理，会计算轮回杂交与合成系的杂种优势保持率。
3. 会用迪克森模型把任意杂交方案的期望表现写成直接加性、母体加性、个体与母体杂种优势及重组损失的线性组合，并评价参数不确定性对方案取舍的影响。
4. 能区分一般配合力与特殊配合力，会用双列杂交（方法 4）估计并理解两者方差随亲本近交程度的变化规律。
5. 理解杂种优势群、相互轮回选择与遗传距离预测杂种优势的局限。
6. 能解释纯种与杂种表现的遗传相关 r_{pc} 的来源，并比较纯种选择、杂种后裔测验与合并资料评定的准确度。

重点与难点

重点： $H_{F_1} = \sum dy^2$ ； $H_{F_2} = \frac{1}{2}H_{F_1}$ ；轮回杂交保持率 $(2^n - 2)/(2^n - 1)$ ；合成系保持率 $1 - \sum p_i^2$ ； $\sigma_{GCA}^2 = \frac{1}{2}FV_A$ 与 $\sigma_{SCA}^2 = F^2V_D$ ； r_{pc} 的来源。

难点：迪克森模型各系数的构造（尤其母体杂种优势与重组损失）；方法 4 中 GCA 估计量的约束与自由度；纯种选择对杂种表现的间接响应与合并资料指数的权重。

本章直接承接第 19 章：杂种优势是近交衰退的镜像，二者共用方向性显性这一遗传基础。纯种与杂种表现的遗传相关将在第 22 章与第 24 章的多性状模型中再次出现，基因组预测的杂交种模型则与第 27 章的核方法相通。

20.2 知识结构图




图 20.1 第 20 章知识结构图

左侧是杂种优势的理论与体系设计，右侧是配合力、选择与基因组预测。

20.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
中亲杂种优势	$H = \bar{P}_{F_1} - \frac{1}{2}(\bar{P}_{P_1} + \bar{P}_{P_2})$	可用百分比表示
单位点 F_1 杂种优势	$H_{F_1} = dy^2$	$y = p_1 - p_2$ ，无上位
多位点	$H_{F_1} = \sum_k d_k y_k^2$	位点间可加
与分化的关系	$E(H_{F_1}) = 2F_{ST} \sum_k d_k p_k q_k$	独立漂变分化
F_2 杂种优势	$H_{F_2} = \frac{1}{2}H_{F_1}$	无上位， F_2 达到 HWE
轮回杂交保持率	$\frac{2^n - 2}{2^n - 1}$	n 个品种、稳态周期平均
合成系保持率	$1 - \sum_i p_i^2$	随机交配、无上位
迪克森模型	$\bar{P} = \sum p_i g_i^I + \sum p_i^M g_i^M + h^I c_I + h^M c_M + r^I c_R$	系数由亲本品种组成构造
一般配合力	$GCA_i = \bar{X}_{i.} - \bar{X}_{..}$	近似为加性效应的一半
方法 4 估计	$\widehat{GCA}_i = \frac{T_i}{n-2} - \frac{2T}{n(n-2)}$	不含自交与反交

概念	公式或定义	成立条件与提示
特殊配合力	$SCA_{ij} = X_{ij} - \bar{X}_{..} - GCA_i - GCA_j$	反映显性与上位
配合力方差	$\sigma_{GCA}^2 = \frac{1}{2}FV_A, \sigma_{SCA}^2 = F^2V_D$	无上位, F 为系近交系数
纯种—杂种遗传相关	$r_g = \frac{\sum 2pq\alpha^P\alpha^C}{\sqrt{\sum 2pq(\alpha^P)^2 \sum 2pq(\alpha^C)^2}}$	$\alpha^C = a + d(q_B - p_B)$
合并资料指数	$b = P^{-1}c$	纯种记录与杂种后裔均值

20.4 补充内容与公式推导

推导 20.1 杂种优势的期望与品种分化

两个品种由同一基础群体(频率 p_0) 各自独立分化, 分化程度为 $F_{ST} = F$, 则 $E(p_1) = E(p_2) = p_0$, $\text{Var}(p_j) = Fp_0q_0$ 。频率差 $y = p_1 - p_2$ 的均值为 0,

$$E(y^2) = \text{Var}(p_1) + \text{Var}(p_2) = 2Fp_0q_0.$$

代入 $H_{F_1} = \sum dy^2$, 得

$$E(H_{F_1}) = 2F \sum_k d_k p_{0k} q_{0k}.$$

这恰是第 19 章中近交系数为 F 的系的平均衰退 $2F \sum dpq$ 。因此“平均杂种优势=近交衰退的恢复”不是类比, 而是同一个量。习题 20.15 中 200 个位点、 $F_{ST} = 0.15$ 的模拟里, $\sum d_k y_k^2 = 5.050$; 而把 d 的符号随机化后, H 的均值只有 -0.066 (SD 1.104), 说明没有方向性显性就没有杂种优势。

推导 20.2 n 品种轮回杂交的稳态杂种优势

设公畜品种依次为 $1, 2, \dots, n$ 循环, 母畜品种组成向量为 x_t , 使用品种 s 的公畜时后代组成 $x_{t+1} = \frac{1}{2}(e_s + x_t)$, 个体杂种优势系数为 $c_t = 1 - x_{t,s}$ (公畜纯种时, $\sum p_i^S p_i^D = x_{t,s}$)。稳态下每个周期内品种组成重复。设稳态时刚用过品种 s 公畜后代中 s 的份额为 z_0 , 上一个公畜品种份额 $z_1, \dots$, 向后第 k 个品种份额 $z_k = z_0/2^k$ (连续 k 次配种稀释), 且 $\sum_{k=0}^{n-1} z_k = 1$ 要求

$$z_0 \sum_{k=0}^{n-1} 2^{-k} = z_0 \frac{2 - 2^{1-n}}{1} = 1 \Rightarrow z_0 = \frac{2^{n-1}}{2^n - 1}.$$

下一次使用的公畜品种恰是向后第 $n-1$ 个, 其在母畜中的份额 $z_{n-1} = z_0/2^{n-1} = \frac{1}{2^{n-1}}$ 。所以

$$c = 1 - \frac{1}{2^{n-1}} = \frac{2^n - 2}{2^n - 1}.$$

$n = 2, 3, 4, 5$ 依次为 $\frac{2}{3}, \frac{6}{7}, \frac{14}{15}, \frac{30}{31}$; 习题 20.17 的递推与个体水平模拟得到 0.6667, 0.8571, 0.9333, 0.9676。

推导 20.3 配合力方差与近交系数

由近交系数为 F 的系, 系 i 的 A_1 配子频率 p_{ik} 的均值 p_k 、方差 Fp_kq_k 。系 i 与系 j 杂交的基因型值 (无上位) 为

$$G_{ij} = \sum_k [a_k(p_{ik} + p_{jk} - 1) + d_k(p_{ik}q_{jk} + q_{ik}p_{jk})].$$

利用 $p_{ik}q_{jk} + q_{ik}p_{jk} = p_{ik} + p_{jk} - 2p_{ik}p_{jk}$ 并以 $\delta_{ik} = p_{ik} - p_k$ 展开:

$$G_{ij} = \text{常数} + \sum_k \alpha_k(\delta_{ik} + \delta_{jk}) - 2 \sum_k d_k \delta_{ik} \delta_{jk}, \quad \alpha_k = a_k + d_k(q_k - p_k).$$

一次项只含单个系, 构成一般配合力 $g_i = \sum_k \alpha_k \delta_{ik}$, 其方差为 $\sum \alpha_k^2 F p_k q_k = \frac{1}{2} F V_A$ ($V_A = \sum 2p_k q_k \alpha_k^2$)。交互项构成特殊配合力 $s_{ij} = -2 \sum_k d_k \delta_{ik} \delta_{jk}$, 方差为 $4 \sum d_k^2 F^2 p_k^2 q_k^2 = F^2 V_D$ ($V_D = \sum (2p_k q_k d_k)^2$)。

因此 $\sigma_{GCA}^2 \propto F$, $\sigma_{SCA}^2 \propto F^2$ 。完全自交系 ($F = 1$) 时二者为 $\frac{1}{2} V_A$ 与 V_D 。习题 20.19 ($V_A = 48.19$, $V_D = 23.97$) 在 $F = 0.1$ 到 1 之间估计与理论的相对偏差小于约 3%。

推导 20.4 纯种与杂种表现的遗传相关

设纯种 A 与另一品种 B 在位点 k 的 A_1 频率分别为 p_A 与 p_B 。 A 品种内个体 $x_k \in \{0, 1, 2\}$ (A_1 等位基因个数)。在 A 品种内随机交配时, 等位基因替代效应为 $\alpha_k^P = a_k + d_k(q_A - p_A)$; 若与 B 的配子交配, 则对后代均值的替代效应变为 $\alpha_k^C = a_k + d_k(q_B - p_B)$ 。两个“育种值”

$$BV^P = \sum_k \alpha_k^P (x_k - 2p_A), \quad BV^C = \sum_k \alpha_k^C (x_k - 2p_A).$$

在 HWE 下 $\text{Var}(x_k) = 2p_A q_A$, 位点独立, 因而

$$r_g = \frac{\sum_k 2p_A q_A \alpha_k^P \alpha_k^C}{\sqrt{\sum_k 2p_A q_A (\alpha_k^P)^2 \sum_k 2p_A q_A (\alpha_k^C)^2}}.$$

$\alpha_k^C - \alpha_k^P = d_k [(q_B - p_B) - (q_A - p_A)] = 2d_k(p_A - p_B)$ 。故差异正比于 $d_k y_k$ ：品种差异越大、显性越强， r_g 越低。当 $d_k = 0$ 或 $y_k = 0$ 对所有位点成立时 $r_g = 1$ 。习题 20.20 中 $F_{ST} = 0.02, 0.10, 0.20, 0.35$ 的 r_g 依次为 0.951, 0.805, 0.757, 0.614。再乘环境（场间）相关 ρ 得到 $r_{pc} = \rho r_g$ 。

拓展阅读 纯种与杂种表现的相关及基因组杂交预测

猪与禽的综述（Wientjes 与 Calus, 2017）显示，纯种与杂种表现的遗传相关在多数性状中估计在 0.4—0.9，繁殖性状与抗病性状常较低；这一相关由两部分组成：品种间等位基因频率与连锁相位的差异（遗传部分），以及场间环境与管理差异（ $G \times E$ 部分）。Ibáñez-Escriche 等（2009）较早从基因组选择的角度说明，纯种选择杂种表现需要的是“杂种背景下的标记效应”。杂交玉米方面，Technow 等（2014）在杂种优势群内部与群间分别建立关系矩阵，用 GCA + SCA 模型预测未测定的单交种，结果表明当父母本均出现在训练集（所谓 CV2 情形）时准确度最高，而两个亲本都未测定的情形（CV0）主要依赖群体间的遗传相关与亲缘。

易错辨析

- **杂种优势不等于超亲优势**：中亲杂种优势只要 $d \neq 0$ 且 $y \neq 0$ 便出现，但杂种是否优于较好亲本还取决于 a 与 y 的方向；商业上应与最好的纯种或现用杂交种比较。
- **F_2 减半不是“衰退”到消失**：无上位时随机交配群体的杂种优势稳定在 F_2 水平，不再继续下降；再损失的部分来自上位引起的重组损失。
- **轮回杂交的 2/3 是周期平均**：两品种轮回中后代的杂种优势系数在 $\frac{2}{3} \pm \frac{1}{6}$ 之间振荡；稳态周期平均才是 $\frac{2}{3}$ ，且母体杂种优势的系数也要单独计算。
- **GCA 不是“好亲本”的同义词**：GCA 是与群体中随机系杂交的平均表现偏差；最优单交种不一定由 GCA 最高的两个系组成（习题 20.18 中该概率仅约 40%）。
- **遗传距离不是杂种优势的充分预测量**： $H = \sum dy^2$ 需要以 d 加权，全基因组等权的距离含大量与显性无关的位点，在群内尤其如此。

20.5 习题

一、单项选择题

- 20.1 ★ [单选] 两个纯种的某性状均值为 100 与 96, 其 F_1 均值为 112。中亲杂种优势为
(A) 12 (B) 14 (C) 16 (D) 4

[答案]

- 20.2 ★ [单选] 其余条件不变, 两亲本群体在某位点的频率差由 0.2 增至 0.4, 该位点对 F_1 中亲杂种优势的贡献变为原来的
(A) 2 倍 (B) 3 倍 (C) 4 倍 (D) 8 倍

[答案]

- 20.3 ★★ [单选] 无上位时, 由 F_1 个体随机交配得到的 F_2 , 其中亲杂种优势为 F_1 的
(A) 全部 (B) 一半 (C) 四分之一 (D) 零

[答案]

- 20.4 ★★ [单选] 下列体系在稳态时个体杂种优势保持率最高的是
(A) 两品种轮回杂交 (B) 三品种轮回杂交
(C) 三品种等比例合成系 (D) 四品种等比例合成系

[答案]

- 20.5 ★★ [单选] 无上位, 亲本系近交系数由 0.25 提高到 0.5, 则 σ_{GCA}^2 与 σ_{SCA}^2 分别约变为原来的
(A) 2 倍与 2 倍 (B) 2 倍与 4 倍 (C) 4 倍与 4 倍 (D) 4 倍与 2 倍

[答案]

- 20.6 ★★ [单选] 下列因素中, 最不会使纯种与杂种表现的遗传相关 r_{pc} 低于 1 的是
(A) 两品种等位基因频率不同且存在显性
(B) 纯种场与商品场的环境差异 (C) 品种间连锁相位的差异
(D) 杂种均值高于纯种均值

[答案]

二、判断与改错题

- 20.7 ★ [判断] 只要某性状存在显性效应, 任意两个群体杂交都会出现杂种优势。 [答案]

- 20.8 ★ [判断] 终端杂交的商品代能获得 100% 的个体杂种优势, 但得不到母体杂种优势。 [答案]

20.9 ★★ [判断] 特殊配合力主要反映加性遗传效应, 一般配合力主要反映显性与上位效应。 [答案]

20.10 ★★ [判断] 群体间遗传距离越大, 杂种优势就越大, 没有上限。 [答案]

三、填空题

20.11 ★ [填空] 单位点 $d = 1.0$, 两亲本群体的 A_1 频率为 0.9 与 0.5, 则 F_1 的中亲杂种优势为 _____, F_2 的为 _____。 [答案]

20.12 ★ [填空] 四个品种等比例组成的合成系, 在随机交配下保持的个体杂种优势比例为 _____; 五品种轮回杂交稳态保持 _____。 [答案]

20.13 ★★ [填空] $n = 7$ 个系的方法 4 双列杂交共有 _____ 个组合; GCA 估计式为 $T_i / [\cdot]_{blank} - 2T / [\cdot]_{blank}$, SCA 的自由度为 _____。 [答案]

20.14 ★★ [填空] 纯种 A 与杂种背景下的等位基因替代效应之差为 $\alpha^C - \alpha^P =$ _____ (用 d 与两品种频率 p_A, p_B 表示)。 [答案]

四、计算题

20.15 ★★ [计算] 多位点杂种优势。200 个位点 ($a \sim N(1, 0.4^2)$), ($d \sim N(0.45, 0.5^2)$), 两品种由基础群体按 $F_{ST} = 0.15$ 分化。计算两品种、 F_1 、 F_2 的均值与中亲杂种优势, 核对 $\sum dy^2$, 用 20 万个体的模拟验证, 并检验 d 符号随机化时的杂种优势。 [程序] `ch20/ex20_15_heterosis_loci.py` [答案]

20.16 ★★★ [计算] 迪克森模型比较杂交体系。三个品种 A、B、C 的直接加性效应为 0, 3.5, 5.0, 母体加性效应为 2.5, 1.5, -1.5, $h^I = 3.2$, $h^M = 5.0$, $r^I = -1.2$ (参数有标准误, 且 h^I, h^M 估计相关 0.4)。计算七种体系的期望表现、成本扣除后的净值、最优概率与期望遗憾。 [程序] `ch20/ex20_16_dickerson_systems.py` [答案]

20.17 ★★★ [计算] 轮回杂交与合成系。对 $n = 2, 3, 4, 5$ 个品种的轮回杂交, 用递推与个体水平的品种来源追踪模拟逐代个体杂种优势系数, 核对稳态值 $(2^n - 2) / (2^n - 1)$; 对 $k = 2, 3, 4, 6, 8$ 个品种等比例合成系核对 $1 - 1/k$ 。 [程序] `ch20/ex20_17_rotation_retention.py` [答案]

- 20.18** ★★★ [计算] 双列杂交。6 个系 15 个组合的产量见数据文件, 计算 GCA、SCA、方差分析; 再对 8 个系 ($\sigma_g = 2$, $\sigma_s = 1.2$, $\sigma_e = 2$) 模拟 3000 次, 评价以 GCA 预测组合表现的 R^2 与选中最佳组合的概率。[程序] ch20/ex20_18_diallel_gca_sca.py [答案]
- 20.19** ★★★ [计算] 配合力方差与近交程度。400 个位点、120 个系, 近交程度 $F = 0.1, 0.25, 0.5, 0.75, 1$, 估计 σ_{GCA}^2 与 σ_{SCA}^2 并与 $\frac{1}{2}FV_A$ 、 F^2V_D 比较。[程序] ch20/ex20_19_gca_sca_inbreeding.py [答案]
- 20.20** ★★★ [计算] 纯种与杂种表现的遗传相关。300 个位点, 品种分化 F_{ST} 取 0.02、0.10、0.20、0.35, 计算 r_g ; 再比较仅用纯种记录、仅用杂种后裔均值 (5、20、100 个后裔) 与合并资料的指数准确度, 并用 2 万个体验证。[程序] ch20/ex20_20_purebred_crossbred.py [答案]
- 20.21** ★ [计算] 两个品系 P (父系) 与 Q (母系): 直接加性效应 4 与 0, 母体加性效应 -1 与 3, $h^I = 3$, $h^M = 4$, $r^I = -0.8$ 。按迪克森模型求纯种 P、纯种 Q、P 公 $\times$ Q 母的 F_1 , 以及 P 公畜配 F_1 母畜的后代的期望表现。[答案]
- 20.22** ★ [计算] 四个品种按 0.4、0.3、0.2、0.1 的比例建立合成系, 随机交配。已知纯种间 F_1 的个体杂种优势平均为 6% (相对于中亲值)。求合成系保持的个体杂种优势比例与相应的杂种优势百分数, 并与等比例四品种合成系比较。[答案]

五、推导与证明题

- 20.23** ★★ [证明] 证明方法 4 双列杂交中, 在可加模型 $y_{ij} = \mu + g_i + g_j + e_{ij}$ 、约束 $\sum g_i = 0$ 下, 最小二乘估计为 $\hat{g}_i = \frac{T_i}{n-2} - \frac{2T}{n(n-2)}$ 。[答案]
- 20.24** ★★★ [证明] 设系间独立, 系 i 的 A_1 频率 p_i 的均值 p 、方差 Fpq , 只考虑一个位点 (a, d) 。证明 $\sigma_{SCA}^2 = F^2(2pqd)^2$ 并说明为什么在此模型中 SCA 方差是 F 的二次函数。[答案]
- 20.25** ★★ [证明] 证明 n 品种轮回杂交的稳态个体杂种优势系数周期平均为 $(2^n - 2)/(2^n - 1)$ 。[答案]
- 20.26** ★★★ [证明] 证明纯种与杂种表现的加性遗传相关满足 $|r_g| < 1$, 当且仅当向量 (α_k^P) 与 (α_k^C) 不成比例, 并说明在单位点情形下 $|r_g|$ 恒为 1。[答案]

六、综合分析与研究设计题

20.27 ★★ [综合] 某猪育种公司拟建立“杜洛克 × (长白 × 大白)”的三元杂体系。设计一套试验与分析方案,估计迪克森模型参数(g^I, g^M, h^I, h^M, r^I)并给出体系取舍的决策准则。 [答案]

20.28 ★★★ [综合] 某玉米公司有两个杂种优势群(各300个自交系)、已测定约1800个单交种的产量。设计杂交种表现的基因组预测方案:模型、交叉验证场景(CV0—CV2)、训练集优化与评价指标。 [答案]

20.29 ★★★ [综合] 某肉鸡公司的纯系核心群 $r_{pc} = 0.6$, 且商品场可获得杂交后代的表型与基因型。设计合并纯种与杂种资料的遗传评定方案,并预测可获得的准确度提升与成本。 [答案]

20.6 参考答案与解析

一、单项选择题

20.1 B. 中亲值 $(100 + 96)/2 = 98$, $H = 112 - 98 = 14$, 相对中亲值为 14.3%。注意杂种优势以中亲值而非较好亲本为基准;若以较好亲本(100)为基准,则超亲优势为 12。 [题目]

20.2 C. $H = dy^2$, y 加倍则 H 变为 4 倍。这说明杂种优势对频率差是二次敏感的:频率差较小的品种对,其杂种优势很小,而大频率差的品种对贡献不成比例地大。 [题目]

20.3 B. F_2 的 A_1 频率为 $\bar{p} = p - \frac{1}{2}y$, $H_{F_2} = d\bar{y}^2$ 的推导表明恰为 $\frac{1}{2}dy^2$;直观上 F_1 的杂合度比 F_2 高 $\frac{1}{2}y^2$, 这部分差异恰是损失的杂种优势。习题 20.15 中 $H_{F_1} = 5.050$, $H_{F_2} = 2.525$ 。 [题目]

20.4 B. 三品种轮回为 $6/7 \approx 0.857$;四品种合成系 $3/4$;两品种轮回与三品种合成系都是 $2/3$ 。若再增加轮回的品种数,保持率进一步趋向 1,但管理复杂度、公畜需求与产品一致性的代价同步上升。 [题目]

20.5 B. $\sigma_{GCA}^2 = \frac{1}{2}FV_A$ 对 F 线性, F 加倍则加倍; $\sigma_{SCA}^2 = F^2V_D$ 为平方关系, F 加倍则变为 4 倍。习题 20.19 的 $F = 0.25 \rightarrow 0.5$: $\hat{\sigma}_{GCA}^2$ 由 5.97 增至 11.97 (2.0 倍), $\hat{\sigma}_{SCA}^2$

由 1.50 增至 6.06 (4.0 倍)。 [题目]

20.6 D. 遗传相关只涉及加性遗传值的协方差结构, 与均值无关。A、C 属遗传部分 (频率与相位), B 属环境部分 ($G \times E$)。 [题目]

二、判断与改错题

20.7 错误。 杂种优势要求 (1) 存在方向性显性, 且 (2) 两亲本群体在有显性的位点上存在等位基因频率差 ($y \neq 0$)。若两群体频率相同, 则 $H = \sum dy^2 = 0$, 即使 $d \neq 0$ 也没有杂种优势。 [题目]

20.8 正确。 终端杂交的商品代是 F_1 , 个体杂种优势系数为 1; 但母畜是纯种母系, $c_M = 0$ 。三元杂交以 F_1 母畜为母本, 则母体杂种优势系数也为 1。 [题目]

20.9 错误。 恰好相反: GCA 主要反映加性效应 (近似为系的育种值的一半), SCA 反映显性与上位等非加性效应。 [题目]

20.10 错误。 $H = \sum d_k y_k^2$ 要求以 d_k 加权, 并不是遗传距离的单调函数; 距离过大的群体间会出现上位互作与重组损失, 生殖隔离、适应性问题也可能抵消杂种优势。遗传距离与杂种优势的相关在群间较强, 群内较弱。 [题目]

三、填空题

20.11 $H_{F_1} = dy^2 = 1.0 \times 0.4^2 = 0.16$; $H_{F_2} = \frac{1}{2}H_{F_1} = 0.08$ 。 [题目]

20.12 $1 - \sum p_i^2 = 1 - 4 \times 0.25^2 = 0.75$; $(2^5 - 2)/(2^5 - 1) = 30/31 \approx 0.968$ 。 [题目]

20.13 $\binom{7}{2} = 21$ 个组合; GCA 估计式 $T_i/5 - 2T/35$ ($n - 2 = 5$, $n(n - 2) = 35$); SCA 自由度 $n(n - 3)/2 = 14$ 。 [题目]

20.14 $\alpha^C - \alpha^P = d[(q_B - p_B) - (q_A - p_A)] = 2d(p_A - p_B)$ 。 [题目]

四、计算题

20.15 $L = 200$, $F_{ST} = 0.15$:

项目	品种 1	品种 2	中亲值	F_1	F_2
均值	38.161	32.060	35.110	40.161	37.635
中亲杂种优势				5.050	2.525

$\sum d_k y_k^2 = 5.0502$, 与均值差完全一致 (差异小于 10^{-9}); $H_{F_2} = H_{F_1}/2$ 也精确成立。20 万个体模拟得 F_1 均值 40.177、 F_2 均值 37.619, 与解析值之差小于 0.8 个蒙特卡罗标准误 (SE 0.022 的 5 倍以内)。相对中亲值, F_1 杂种优势 14.4%, F_2 7.2%。反事实: 把每个位点 d 的符号随机翻转 400 次, 杂种优势均值为 -0.066 (SD 1.104), 与 0 无显著差别; 而真实数据里 81% 的位点 $d > 0$, 所以得到 +5.05。结论: 杂种优势依赖显性效应的方向一致性, 不是“有显性就有”。单位点核实验 $a = 1.2$ 、 $d = 0.9$ 、 $p_1 = 0.7$ 、 $p_2 = 0.1$: $M_{P_1} = 0.858$, $M_{P_2} = -0.798$, $M_{F_1} = 0.354$, $H_{F_1} = 0.324 = 0.9 \times 0.6^2$, $H_{F_2} = 0.162$ 。 [题目]

20.16 各体系的系数与结果 (净值 = 表现 - 成本):

体系	c_I	c_M	c_R	表现	成本	净值	SD	最优率	遗憾
纯种 A	0	0	0	2.500	0	2.500	0	0	8.251
纯种 C	0	0	0	3.500	0	3.500	1.000	0	7.237
终端 C×A	1	0	0	8.200	1.0	7.200	1.077	0.007	3.557
三元杂 交	1	1	0.25	13.275	2.5	10.775	2.100	0.993	0.004
两品种 轮回	0.667	0.667	0.222	8.200	1.5	6.700	1.447	0	4.066
三品种 轮回	0.857	0.857	0.286	10.352	2.0	8.352	1.809	0	2.420
三品种 合成系	0.667	0.667	0.667	8.333	0.8	7.533	1.523	0	3.231

三元杂交比终端杂交的净值高 3.553 (SD 1.457), 在参数不确定性下优于终端杂交的概率为 0.993。分解: 三元杂交相对终端杂交的表现增量 $13.275 - 8.200 = 5.075$ 由四部分组成——直接加性效应 +0.875 (B 品种带入, 3.375 对 2.5)、母体加性效应 -0.5 (2.0 对 2.5)、母体杂种优势 +5.0、重组损失 -0.3 (系数 0.25 乘 -1.2); 扣除多出的成本 1.5 后净值差为 3.575 (模拟均值 3.553)。结论: 三元体系的优势几乎全部来自母体杂种优势; h^M 的估计值一旦低于约 1.4, 三元体系就不再优于终端杂交 (净值差随 h^M 线性下降, 可改数据文件检验), 因此试验设计应优先压低 h^M 的估计误差。 [题目]

20.17 轮回杂交 (稳态为最后一个完整周期的平均):

n	递推稳态	理论	个体水平模拟	前 8 代 c_t
		$(2^n - 2)/(2^n - 1)$		
2	0.6667	0.6667	0.6667	1.000 0.500 0.750 0.625 0.688 0.656 0.672 0.664
3	0.8571	0.8571	0.8570	1.000 1.000 0.750 0.875 0.875 0.844 0.859 0.859
4	0.9333	0.9333	0.9332	1.000 1.000 1.000 0.875 0.938 0.938 0.938 0.930
5	0.9676	0.9677	0.9676	1.000 1.000 1.000 1.000 0.938 0.969 0.969 0.969

合成系： $k = 2, 3, 4, 6, 8$ 的理论 $1 - 1/k = 0.500, 0.667, 0.750, 0.833, 0.875$ ，随机交配第 2—6 代的模拟来源杂合度均在其 ± 0.015 内（如 $k = 4$ 为 0.740, 0.750, 0.750, 0.751, 0.750）。不等比例 (0.5, 0.3, 0.2) 的保持率 0.620，低于等比例三品种的 0.667。结论：品种数越多，轮回杂交越趋于完全杂种优势，但每增加一个品种带来的增量以 2^{-n} 的速度减小；合成系在 F_2 之后稳定，不需要继续引入公畜。 【题目】

20.18 6 个系、15 个组合：总平均 101.767；GCA：A -0.583、B +2.867、C +0.642、D -2.483、E +2.517、F -2.958（和为 0，并与带约束的最小二乘一致）。SCA 最大的三个组合：BC +2.03、EF +1.48、AF +0.78。观测值最高的组合为 BC (107.3)，但 GCA 最高的两系是 B 与 E——可见最佳组合不一定由 GCA 最高两系构成。方差分析： $SS_{GCA} = 120.89$ （自由度 5）， $SS_{SCA} = 12.09$ （自由度 9）， $F = 18.01$ （GCA 显著大于 SCA）。

8 个系的模拟 (3000 次)： $\widehat{GCA}$ 与真值的平均相关 0.887；以 GCA 之和预测真实组合值的平均 $R^2 = 0.709$ ；真实最佳组合恰为 GCA 估计最高两系的概率只有 0.397，位于预测前三名的概率 0.729； MS_{SCA} 的均值 5.488，与理论 $\sigma_s^2 + \sigma_e^2 = 5.440$ 吻合。结论：用 GCA 可以筛出大致好的组合，但最终组合需要直接测定；单次观测下 SCA 与误差无法分离。 【题目】

20.19 $V_A = 48.193$ ， $V_D = 23.968$ ，120 个系，各 F 取 30 次重复的平均：

F	$\hat{\sigma}_{GCA}^2$	$\frac{1}{2}FV_A$	$\hat{\sigma}_{SCA}^2$	F^2V_D	GCA 占比 (估)	GCA 占比 (理)
0.10	2.419	2.410	0.239	0.240	0.953	0.953

F	$\hat{\sigma}_{GCA}^2$	$\frac{1}{2}FV_A$	$\hat{\sigma}_{SCA}^2$	F^2V_D	GCA 占比 (估)	GCA 占比 (理)
0.25	5.975	6.024	1.505	1.498	0.888	0.889
0.50	11.973	12.048	6.061	5.992	0.798	0.801
0.75	18.067	18.072	13.519	13.482	0.728	0.728
1.00	23.893	24.096	24.019	23.968	0.665	0.668

GCA 占比取 $2\sigma_g^2/(2\sigma_g^2+\sigma_s^2)$ 。近交程度低时,组合差异几乎全由 GCA 决定 ($F = 0.1$ 时 95%); 完全自交系时 SCA 方差与 V_D 相当, GCA 占比降至约三分之二。这是杂交玉米“先顶交测 GCA、再测单交种 SCA”两阶段程序的定量基础。 [题目]

20.20 r_g 随品种分化变化 (300 位点):

F_{ST}	r_g (理论)	r_g (个体水平)	$r_{pc} = 0.9r_g$
0.02	0.9509	0.9507	0.8558
0.10	0.8053	0.8034	0.7248
0.20	0.7573	0.7547	0.6816
0.35	0.6135	0.6068	0.5522

指数准确度 ($F_{ST} = 0.2$ 的一个实现, 缩放后 $V_P = 0.300$ 、 $V_C = 0.353$ 、 $\text{cov} = 0.229$ 、 $r_g = 0.705$, $h_C^2 = 0.353$; 目标为对杂种表现的育种值):

杂种后裔数 n	准确度 (理论)	准确度 (模拟)	指数权重 (纯种记录, 后裔均值)
0 (仅纯种)	0.3860	0.3925	—
5	0.6304	0.6292	0.166, 0.575
20	0.8239	0.8204	0.090, 1.237
100	0.9529	0.9519	0.023, 1.786

仅有纯种本身记录时, 准确度为 $\text{cov}/\sqrt{\sigma_P^2 V_C} = 0.386$, 明显低于纯种性状的 $\sqrt{h_P^2} = 0.548$ ($r_g = 1$ 且 $V_C = V_P$ 时的上限)。5 个杂种后裔使准确度升至 0.63; 有 20 个时达 0.82, 此时纯种本身记录的权重已降到 0.09。结论: r_{pc} 越低, 杂种后裔信息越重要; 合并指数可以同时利用两类信息而不浪费纯种记录。 [题目]

20.21

- 纯种 P: $4 + (-1) = 3$; 纯种 Q: $0 + 3 = 3$ 。

- P 公 $\times$ Q 母的 F_1 : 直接加性 $\frac{1}{2}(4+0)=2$, 母体加性 3 (Q 母), 个体杂种优势 $3 \times 1 = 3$, $c_M = 0$, $c_R = 0$; 合计 $2+3+3=8$ 。
- P 公畜配 F_1 母畜: 后代组成 $\frac{3}{4}P$ 、 $\frac{1}{4}Q$, 直接加性 $\frac{3}{4} \times 4 = 3$; 母畜组成 $\frac{1}{2}P$ 、 $\frac{1}{2}Q$, 母体加性 $\frac{1}{2}(-1) + \frac{1}{2}(3) = 1$; $c_I = 1 - 1 \times \frac{1}{2} = \frac{1}{2}$, 个体杂种优势 1.5; 母畜为 F_1 , $c_M = 1$, 母体杂种优势 4; $c_R = \frac{1}{2}[(1-1) + (1-\frac{1}{2})] = \frac{1}{4}$, 重组损失 -0.2; 合计 $3+1+1.5+4-0.2=9.3$ 。

结论: 两个纯种表现相同 (均为 3), 而杂交体系可以达到 8—9.3; 回交体系因利用了 F_1 母畜的母体杂种优势而超过终端 F_1 (9.3 对 8), 但需要同时维持 P 公畜与 F_1 母畜的生产。 [题目]

20.22 保持率 $1 - \sum p_i^2 = 1 - (0.16+0.09+0.04+0.01) = 0.70$, 杂种优势为 $0.70 \times 6\% = 4.2\%$ 。等比例四品种合成系的保持率为 0.75, 杂种优势 4.5%; 不等比例使保持率下降 0.05 (0.3 个百分点)。保持率最大的构成是等比例, 且品种数越多保持率越高。 [题目]

五、推导与证明题

20.23 证明。方法 4 共 $N = n(n-1)/2$ 个组合, 每个系出现在 $n-1$ 个组合中。令 μ 与 g_i 满足 $\sum g_i = 0$ 。系 i 的组合和的正规方程为

$$T_i = \sum_{j \neq i} y_{ij} \Rightarrow T_i = (n-1)\mu + (n-1)g_i + \sum_{j \neq i} g_j.$$

因 $\sum_{j \neq i} g_j = -g_i$, 得 $T_i = (n-1)\mu + (n-2)g_i$ 。对 i 求和, $2T = \sum_i T_i = n(n-1)\mu$ (因每个组合在两个系中各计一次, 且 $\sum g_i = 0$), 所以 $\hat{\mu} = \frac{2T}{n(n-1)} = T/N$ 。代回:

$$\hat{g}_i = \frac{T_i - (n-1)\hat{\mu}}{n-2} = \frac{T_i}{n-2} - \frac{2T}{n(n-2)}. \quad \blacksquare$$

推论: $\text{Var}(\hat{g}_i - \hat{g}_j) = 2\sigma^2/(n-2)$, 因 $\hat{g}_i - \hat{g}_j = (T_i - T_j)/(n-2)$ 且 $T_i - T_j$ 中公共的 y_{ij} 抵消, 剩余 $2(n-2)$ 个观测值。 [题目]

20.24 证明。设 $\delta_i = p_i - p$, $E(\delta_i) = 0$, $\text{Var}(\delta_i) = Fpq$, 系间独立。系 i 与 j 杂交的值 (单位点)

$$G_{ij} = a(p_i + p_j - 1) + d(p_i q_j + q_i p_j) = a(p_i + p_j - 1) + d(p_i + p_j - 2p_i p_j).$$

代入 $p_i = p + \delta_i$: $p_i p_j = p^2 + p(\delta_i + \delta_j) + \delta_i \delta_j$,

$$G_{ij} = \text{常数} + (a + d - 2dp)(\delta_i + \delta_j) - 2d \delta_i \delta_j = \text{常数} + \alpha(\delta_i + \delta_j) - 2d \delta_i \delta_j,$$

其中 $\alpha = a + d(q - p)$ 。第二项为 GCA; $s_{ij} = -2d\delta_i\delta_j$ 是 i, j 的交互项, 且 $E(s_{ij} | \delta_i) = 0$, 与 GCA 项不相关, 所以 $\sigma_{SCA}^2 = \text{Var}(s_{ij}) = 4d^2 E(\delta_i^2) E(\delta_j^2) = 4d^2 F^2 p^2 q^2 = F^2 (2pqd)^2$ 。它是 F 的二次函数, 是因为 SCA 来自两个独立系的偏差之积, 每个偏差的方差都是 F 的一次函数。■

【题目】

20.25 证明。稳态下, 刚使用过的品种 s_0 公畜后代中, 品种组成按“越近越多”的几何序列分配: 最近一次的公畜贡献 $\frac{1}{2}$, 其前一次贡献 $\frac{1}{4}$,, 并且每个循环周期 n 代后贡献再按 2^{-n} 缩小, 故从当前往回第 k 个品种的份额

$$z_k = \frac{2^{-(k+1)}}{1 - 2^{-n}}, \quad k = 0, \dots, n-1,$$

$\sum_{k=0}^{n-1} z_k = \frac{1 - 2^{-n}}{1 - 2^{-n}} = 1$ 成立。下次要使用的公畜品种恰是 $n-1$ 次之前使用的品种, 其在母畜中的份额

$$z_{n-1} = \frac{2^{-n}}{1 - 2^{-n}} = \frac{1}{2^n - 1}.$$

个体杂种优势系数 $1 - \sum p_i^S p_i^D = 1 - z_{n-1} = \frac{2^n - 2}{2^n - 1}$, 这个值在每个循环相位上相同 (轮回对称), 所以也是周期平均。■

【题目】

20.26 证明。记权重 $w_k = 2p_A q_A > 0$ (若某位点在 A 中固定则不起作用)。 r_g 是加权内积

$$r_g = \frac{\sum_k w_k \alpha_k^P \alpha_k^C}{\sqrt{\sum_k w_k (\alpha_k^P)^2} \sqrt{\sum_k w_k (\alpha_k^C)^2}}$$

的余弦。由 Cauchy-Schwarz 不等式 $|r_g| \leq 1$, 等号成立当且仅当向量 $(\sqrt{w_k} \alpha_k^P)$ 与 $(\sqrt{w_k} \alpha_k^C)$ 线性相关, 即存在常数 λ 使 $\alpha_k^C = \lambda \alpha_k^P$ 对所有 k 成立; 故 $|r_g| < 1$ 当且仅当二者不成比例。单位点时向量只有一个分量, 必然成比例, 所以 $|r_g| = 1$, 符号为 $\text{sign}(\alpha^P \alpha^C)$ 。由于 $\alpha_k^C - \alpha_k^P = 2d_k(p_A - p_B)$, 多位点时只要 $d_k(p_A - p_B)$ 不是 α_k^P 的固定倍数, 就有 $|r_g| < 1$ 。■

【题目】

六、综合分析与研究设计题

20.27 设计 (1) 目标: 估计 g_i^I, g_i^M (三个品种各自)、 h^I, h^M, r^I 及其协方差, 并以利润决策。(2) 群体: 纯种 A、B、C (A、B 为母系, C 为父系), 建立下列组合: 纯种 A、B、C; 正反交 $A \times B$ 、 $B \times A$ 以分离母体与直接效应; $C \times A$ 、 $C \times B$ (终端 F_1); $C \times (A \times B)$ 与 $C \times (B \times A)$ (三元); 若考察轮回, 加入 $(A \times B) \times A$ 回交。同一批场、同年同季, 使用足够多的父本家系 (每个组合不少于约 20 头父本) 和母本家系, 以降低遗传背景混杂。(3) 模型: 混合模型 $y = \mu + \text{场年季} + \text{品种组成}(g^I, g^M) +$

$c_I h^I + c_M h^M + c_R r^I + \text{公畜(随机)} + \text{母畜(随机)} + e$, 系数 c_I, c_M, c_R 由每头动物的品种组成计算, REML 估计方差, 固定效应的协方差矩阵直接给出参数估计的联合不确定性。(4) 功效: h^I 的估计标准误约 $\sigma/\sqrt{n_{\text{eff}}}$, 其中有效样本数由 F_1 与纯种的家系数而非窝数决定; 目标是使决策关键参数(如 h^M) 的标准误小于其均值的三分之一。(5) 决策: 对每个候选体系, 以利润 $\pi = \text{表现} \times \text{价格} - \text{成本}$ 为目标, 用参数的联合抽样分布做蒙特卡罗(如习题 20.16), 报告最优概率与期望遗憾, 设定准则: 最优概率不低于 0.8, 或相对次优的净值差的 5% 分位数大于 0 时才切换体系; 否则追加试验(价值信息分析)。(6) 风险: 重组损失与 $G \times E$ 在不同场不一致, 需在两个以上场重复; 纯种群的持续选择会改变 g 的估计, 需定期复估。

【题目】

20.28 方案 (1) 数据: 两个杂种优势群(各约 300 个自交系, 均有高密度 SNP), 已测 1800 个单交种(可能组合 90000 个, 覆盖约 2%), 多环境多年。(2) 模型: 先估计环境效应, 再在单环境或环境均值水平拟合

$$y_{ij} = \mu + g_i^{(1)} + g_j^{(2)} + s_{ij} + e_{ij},$$

其中 $g^{(1)} \sim N(0, \sigma_{g1}^2 G_1)$, $g^{(2)} \sim N(0, \sigma_{g2}^2 G_2)$, $s \sim N(0, \sigma_s^2 G_1 \otimes G_2)$ (对应行列配对的 Hadamard/Kronecker 积)。可与带显性效应的 SNP 模型、贝叶斯模型比较; $G \times E$ 通过环境特异的方差组分或多环境模型处理。(3) 交叉验证场景: CV2 (两个亲本都在训练集出现过, 只是该组合未测), CV1 (只有一个亲本出现过), CV0 (两个亲本都未出现, 即全新亲本组合)。每个场景分别报告预测相关; 报告时同时按亲本分组做“留家系”验证, 以免训练与测试共享相同亲本导致乐观偏倚。(4) 训练集优化: 用 CDmean、预测误差方差 (PEV) 或最大化遗传多样性的准则选择需要测定的组合, 使各亲本出现次数相近; 对新亲本留出一定比例的“桥接”组合。(5) 评价: 预测相关、前 10% 命中率 (预测前 10% 中有多少真在实际前 10%)、选择反应 (所选组合的平均产量相对均值)。一般文献中 CV2 的相关多在 0.7—0.85, CV1 约 0.5—0.7, CV0 约 0.3—0.5 (具体值随数据而定, 应以本数据交叉验证结果为准)。(6) SCA 部分的准确度通常低于 GCA 部分; 决策时优先用 GCA 部分筛选, 再用 SCA 部分排序。

【题目】

20.29 方案 (1) 问题: 纯种核心群选择, 目标是杂交商品代表现, $r_{pc} = 0.6$ 。仅用纯种本身记录, 准确度为 $r_{pc} h_p$ (如 $h_p^2 = 0.3$ 时 $0.6 \times 0.548 = 0.33$), 明显偏低。(2) 数据: 在商品场获得杂交后裔的表型与基因型, 并连接到纯种亲本的系谱与基因型。(3) 模型: 多性状视角——把纯种表现与杂种表现看成两个相关的性状 (遗传相关 r_{pc}), 用单步或基因组多性状 BLUP 联合评定, 或采用品种来源等位基因

(BOA) 模型, 在杂种背景中分别估计各品种来源的标记效应。(4) 预期准确度: 参照习题 20.20 ($r_g = 0.705$ 的例子): 仅纯种记录 0.39; 每个候选有 5 个杂种后裔均值的准确度 0.63、有 20 个时 0.82、有 100 个时 0.95。由此得到每个候选需要的杂种后裔数与其成本之间的权衡: 每增加一倍后裔, 边际增益递减。(5) 成本: 杂种后裔测定的成本主要为分型、表型采集与场间物流; 可以只对关键候选(如预选的前 20%) 设置后裔测验, 降低成本。(6) 更新: 每年重新估计 r_{pc} , 若稳定地高于 0.8, 可减少杂种后裔测验的规模; 检验新旧场之间的 $G \times E$, 若环境相关低, 则需要多个商品场采集数据。

[题目]

第七篇

混合模型与遗传评定

怎样同时校正环境并预测遗传价值。

本篇习题训练：BLUP、动物模型、REML 与贝叶斯推断、多性状、阈值、生存与纵向模型。

从最小二乘到最佳线性无偏预测

21.1 本章导学

学习目标

- 1. 能从投影与加权的角度理解普通最小二乘与广义最小二乘，会计算相关记录的有效信息量。
- 2. 掌握可估计性、设计矩阵秩亏与遗传连通：知道哪些函数能被唯一估计，联结公畜如何改变跨场比较的精度。
- 3. 能由“均方误差最小”推出 BLUP，并写出混合模型方程与 V 形式，会在两种形式之间互相验算。
- 4. 理解收缩、边际无偏、条件偏差并不矛盾；会区分“预测对真值的回归”与“真值对预测的回归”。
- 5. 会计算预测误差方差（PEV）、可靠度、差值与均值的预测精度，以及固定与随机效应混合目标的最优预测。
- 6. 理解奇异协方差、经验 BLUP 与选择条件下的 BLUP 无偏性，知道每一种情形需要什么假设。

重点与难点

重点： $\hat{u} = GZ'V^{-1}(y - X\hat{b})$ ；混合模型方程； $PEV = \sigma_e^2 C^{22}$ ； $r^2 = kV_A/(kV_A + V_e)$ ； $E(u | \hat{u}) = \hat{u}$ 。

难点： PEV 的尺度（方程是否已乘 σ_e^2 ）；混合目标的误差交叉项；奇异协方差下方程的写法；选择、数据删除与经验参数分别对无偏性的不同影响。

本章是第 22 章动物模型的理论入口，也是第 23 章方差组分估计与第 28 章单步评定的基础：那里所有复杂的方程，都是本章混合模型方程在不同 G 或 H 下的实例。

21.2 知识结构图




图 21.1 第 21 章知识结构图

左侧是“估计与设计”，右侧是“预测与精度”。

21.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
广义最小二乘	$\hat{b} = (X'V^{-1}X)^{-1}X'V^{-1}y$	V 已知
最佳线性无偏预测	$\hat{u} = GZ'V^{-1}(y - X\hat{b})$	均值与协方差已知
混合模型方程	$(W'R^{-1}W + \Sigma)\hat{\beta} = W'R^{-1}y$	$W = [XZ]$, $\Sigma = \text{diag}(0, G^{-1})$, G 非奇异
单记录收缩	$\hat{u} = r^2(\bar{y} - \mu)$, $r^2 = \frac{kV_A}{kV_A + V_e}$	k 条等精度记录
预测误差方差	$PEV = \sigma_e^2 C^{22} = G - \text{Var}(\hat{u})$	方程未被缩放时
可靠度与准确度	$r^2 = 1 - PEV/V_A$, $r = \sqrt{r^2}$	非近交时
校准	$E(u \hat{u}) = \hat{u}$	正态且参数已知
条件偏差	$E(\hat{u} u) = r^2 u$	单记录时
差值的 PEV	$PEV_i + PEV_j - 2PEC_{ij}$	需要协方差
混合目标	$\hat{\theta} = k'\hat{b} + m'\hat{u}$	含交叉项的误差方差
奇异 G	$u = Lw$, $G = LL'$	L 满列秩

概念	公式或定义	成立条件与提示
秩与连通	$\text{rank} = H + S - c$	c 为二部图连通分量数

21.4 补充内容与公式推导

推导 21.1 由条件期望得到 BLUP 与混合模型方程

设 $y = Xb + Zu + e, u \sim N(0, G), e \sim N(0, R)$ 且独立。 u 与 y 联合正态, $\text{Cov}(u, y) = GZ'$, $\text{Var}(y) = V = ZGZ' + R$ 。当 b 已知,

$$E(u | y) = GZ'V^{-1}(y - Xb),$$

它是平方误差下的最佳预测。 b 未知时以其 GLS 估计代入, 得到 BLUP。

混合模型方程来自对 (b, u) 的联合“惩罚残差平方和”最小化:

$$Q = (y - Xb - Zu)'R^{-1}(y - Xb - Zu) + u'G^{-1}u.$$

令 $\partial Q / \partial b = 0, \partial Q / \partial u = 0$ 即得上表的方程。两种形式等价: 由第二个方程 $\hat{u} = (Z'R^{-1}Z + G^{-1})^{-1}Z'R^{-1}(y - X\hat{b})$, 再用恒等式 $(Z'R^{-1}Z + G^{-1})^{-1}Z'R^{-1} = GZ'V^{-1}$ 即回到 V 形式。习题 21.16 中 4 个场、8 头公畜、65 条记录, 两种形式的 $\hat{b}$ 与 $\hat{s}$ 逐元一致 (差异小于 10^{-8})。

推导 21.2 PEV、可靠度与“校准”恒等式

令 $P = V^{-1} - V^{-1}X(X'V^{-1}X)^{-1}X'V^{-1}$, 则 $\hat{u} = GZ'Py$ 。因 $PX = 0, PVP = P$:

$$\text{Var}(\hat{u}) = GZ'PVPZG = GZ'PZG, \quad \text{Cov}(u, \hat{u}) = GZ'PZG.$$

二者相等, 故

$$\text{Var}(u - \hat{u}) = G - \text{Var}(\hat{u}) = G - GZ'PZG = \text{PEV}.$$

同时, $\text{Cov}(u - \hat{u}, \hat{u}) = 0$, 说明在联合正态下 $E(u | \hat{u}) = \hat{u}$: u 对 $\hat{u}$ 回归的斜率恰为 1。反过来, $\hat{u}$ 对 u 的回归是

$$E(\hat{u} | u) = \frac{\text{Cov}(u, \hat{u})}{V_A} u = r^2 u,$$

对单个动物是向零收缩的。习题 21.15 中 60000 个动物 (记录数 1,2,4,8, $V_A = 5$, $V_e = 15$): u 对 $\hat{u}$ 的斜率 0.9994; $\hat{u}$ 对 u 的斜率在 $k = 1, 2, 4, 8$ 时依次为 0.251, 0.400, 0.581, 0.721, 与 $r^2 = 0.250, 0.400, 0.571, 0.727$ 吻合。

推导 21.3 固定与随机混合目标的预测误差

设目标 $\theta = k'b + m'u$ ($k'b$ 可估)。最佳线性无偏预测为 $\hat{\theta} = k'\hat{b} + m'\hat{u}$ 。混合模型方程系数阵的逆 C^{-1} 的分块给出联合误差协方差 (乘以 σ_e^2):

$$\text{Var}(\hat{\theta} - \theta) = \sigma_e^2 \begin{bmatrix} k \\ m \end{bmatrix}' \begin{bmatrix} C^{11} & C^{12} \\ C^{21} & C^{22} \end{bmatrix} \begin{bmatrix} k \\ m \end{bmatrix} = \text{Var}(k'\hat{b}) + \text{PEV}(m'\hat{u}) + 2\sigma_e^2 k' C^{12} m.$$

交叉项来自固定效应估计误差与随机效应预测误差的相关: 一个动物的数据同时提供对场效应与对该动物自身效应的信息, 二者的误差通常负相关。因此简单把 $\text{Var}(k'\hat{b})$ 与 PEV 相加会偏离。习题 21.20 (8 头动物, 两对克隆) 中目标 $\theta = b_{\text{场}1} + u_3$ 的联合 PEV 为 5.991, 忽略交叉项得 6.053 (交叉项 -0.062), 蒙特卡罗经验值 5.904。

推导 21.4 奇异协方差下的降维方程

若 $G = \sigma_u^2 K$ 奇异 (克隆、完全相关的随机效应), 令 $K = LL'$, L 为 $n \times r$ 的满列秩矩阵 (如谱分解的非零部分), 则 $u = Lw$, $w \sim N(0, \sigma_u^2 I_r)$ 。把模型改写为 $y = Xb + (ZL)w + e$, 则混合模型方程中随机块为 $L'Z'ZL + (\sigma_e^2/\sigma_u^2)I_r$, 总是可逆; $\hat{u} = L\hat{w}$ 。这与 V 形式的 $GZ'V^{-1}(\cdot)$ 完全相同, 因为 $V = \sigma_u^2 ZKZ' + \sigma_e^2 I$ 与分解方式无关。另一条路是岭近似 $G_\varepsilon = G + \varepsilon I$: 习题 21.20 表明 ε 从 10^{-2} 到 10^{-8} , $\max|\hat{u}_\varepsilon - \hat{u}|$ 由 2.6×10^{-3} 降到 8.9×10^{-9} , 但系数阵条件数由 9×10^2 升到 9×10^8 , 数值稳定性随之恶化。

拓展阅读 BLUP 的历史与经验 BLUP 的不确定性

Henderson (1950, 1963, 1975) 把动物模型、混合模型方程与选择下的无偏性系统化; Robinson (1991) 的综述 “That BLUP is a good thing” 从多角度 (贝叶斯、最小均方误差、广义最小二乘) 阐明了它的统一性。方差组分用估计值代入后得到的是经验 BLUP, Kackar 与 Harville (1981, 1984) 证明在对称、平移不变的估计器下它仍是无偏的, 但其真实预测误差方差大于以估计参数计算的名义 PEV。习题 21.19 中公畜数 30、每头 4 个后代时, 真参数 BLUP 的均方预测误差为 0.910, 经验 BLUP 为 1.012, 而名义 PEV 仅 0.816, 名义 95% 区间的覆盖率只有 0.839; 公畜数增至 100、每头 12 个后代后, 二者与名义值几乎一致 (0.511 对 0.506)。

易错辨析

- 无偏不等于“预测等于真值的期望”: BLUP 的“无偏”指 $E(\hat{u}) = E(u)$ 或 $E(u - \hat{u}) = 0$ (对群体分布取平均), 固定真值后的条件期望是 $r^2 u$, 向零收缩。

- **收缩不是缺陷**：被收缩的预测值对真值回归的斜率恰为 1，是校准的；未收缩的原始均值才会在选择后被高估（习题 21.15：选前 10%，原始均值高估 4.41，BLUP 高估-0.002）。
- **PEV 的尺度**：混合模型方程若整体乘了残差方差，逆矩阵对角元不能直接当 PEV；使用软件时应以小例子核对。
- **可估计性不是随机效应的特权**：把场与公畜都设为固定效应而没有联结公畜时，跨场公畜差异不可估；改成随机效应只是施加了分布假设。
- **选择下的无偏性有条件**：只有在选择仅依赖于分析所用的资料、参数已知、保留全部相关亲属记录时才无偏（习题 21.18：删除淘汰者的记录后，遗传趋势偏差达 -6.6）。

21.5 习题

一、单项选择题

21.1 ★ [单选] 在正态、参数已知的单性状 BLUP 中，下列哪一个关系成立？

- (A) $E(\hat{u} | u) = u$ (B) $E(u | \hat{u}) = \hat{u}$ (C) $E(\hat{u} | u) = \hat{u}$
 (D) $E(u | \hat{u}) = r^2 \hat{u}$ [答案]

21.2 ★ [单选] 单记录动物的 BLUP 的方差为（ r^2 为可靠度， V_A 为加性方差）

- (A) V_A (B) $r^2 V_A$ (C) $(1 - r^2) V_A$ (D) V_e

[答案]

21.3 ★★ [单选] 下列关于混合模型方程的说法，正确的是

- (A) 方程的逆矩阵随机块对角元永远等于 PEV
 (B) 方程中残差方差缩放后，PEV 需要乘以相应的方差
 (C) 可靠度与方程缩放无关 (D) 只有 G 对角时才能写出方程

[答案]

21.4 ★★ [单选] 4 个场，各场使用本场的公畜，没有共用公畜。若场与公畜均作固定效应，下列哪一项成立？

- (A) 跨场公畜差可唯一估计 (B) 设计矩阵的秩比列数少 4
(C) 秩比列数少 1 (D) 公畜效应均可估

[答案]

21.5 ★★ [单选] 用估计的方差比代替真值得到的经验 BLUP，其名义 PEV（按估计参数计算）相对真实预测误差方差一般

- (A) 偏大 (B) 偏小 (C) 相等 (D) 无法比较

[答案]

21.6 ★★★ [单选] 动物模型下，下列哪种做法会使遗传趋势估计产生明显偏差？

- (A) 使用全部记录与全系谱
(B) 删除被淘汰动物的记录（淘汰依赖其表型）后再分析
(C) 使用已知真参数 (D) 在世代间选择仅依据所用表型

[答案]

二、判断与改错题

21.7 ★ [判断] BLUP 的“无偏”意味着，对任一固定的真实育种值 u ，预测值的条件期望等于 u 。

[答案]

21.8 ★ [判断] 在固定效应模型中，若各场使用互不相同的公畜，仍可唯一估计任意两头公畜之间的差异。

[答案]

21.9 ★★ [判断] 若混合模型方程整体乘以 σ_e^2 ，则其逆矩阵随机块的对角元就是 PEV。

[答案]

21.10 ★★ [判断] 随机效应的协方差阵 G 奇异时，BLUP 不存在。

[答案]

三、填空题

21.11 ★ [填空] 三条独立记录 8、10、13，误差方差分别为 2、2、4，测定同一均值。GLS 估计为 _____，方差为 _____。

[答案]

21.12 ★ [填空] $V_A = 4$ 、 $V_e = 12$, 只有一条记录的动物: 可靠度 _____, 准确度 _____, PEV _____。 [答案]

21.13 ★★ [填空] 上题中该动物有 3 条等精度记录, 可靠度为 _____, PEV 为 _____。

[答案]

21.14 ★★ [填空] 某程序报告逆矩阵随机块的对角元为 0.16, 方程已整体乘以残差方差 20; 先验方差 $V_A = 8$ 。则 PEV 为 _____, 可靠度为 _____。 [答案]

四、计算题

21.15 ★★ [计算] BLUP 的统计性质。 6 万个动物 ($V_A = 5$ 、 $V_e = 15$, 记录数 1、2、4、8 混合), 核对边际无偏、校准斜率、条件偏差, 并比较按 BLUP 与按原始均值选留前 10% 的高估量。 [程序] [ch21/ex21_15_blup_properties.py](#) [答案]

21.16 ★★★ [计算] 不平衡公畜模型。 4 个场、8 头公畜、65 条记录 ($\sigma_s^2 = 1.5$ 、 $\sigma_e^2 = 9$)。用混合模型方程与 V 形式求 $\hat{b}$ 、 $\hat{s}$ 、PEV 与可靠度, 并与固定效应最小二乘、原始均值比较。 [程序] [ch21/ex21_16_sire_model_mme.py](#) [答案]

21.17 ★★★ [计算] 遗传连通。 4 个场, 每场 6 头本场公畜, 另有 $L = 0, 1, 2, 3, 5, 8$ 头联结公畜 (每场都有其后代, 每格 6 个后代)。计算固定模型的秩、跨场差的可估性与方差, 随机模型的 PEV, 并用蒙特卡罗核对。 [程序] [ch21/ex21_17_connectedness.py](#) [答案]

21.18 ★★★ [计算] 选择下的 BLUP。 7 世代、每代 160 头、每代选 32 头亲本 (依表型)。比较全系谱全记录、无系谱、删除淘汰者记录、不调世代四种分析的遗传趋势偏差。 [程序] [ch21/ex21_18_selection_bias.py](#) [答案]

21.19 ★★★ [计算] 经验 BLUP。 公畜数 $\{30, 100\} \times$ 每公畜后代数 $\{4, 12\}$, REML 估计方差比后求 BLUP, 比较均方预测误差、名义 PEV、准确度与区间覆盖率。 [程序] [ch21/ex21_19_empirical_blup.py](#) [答案]

21.20 ★★★ [计算] 奇异协方差与混合目标。 8 头动物含两对克隆, 场与性别固定。比较 V 形式、降维方程与岭近似, 计算混合目标 $b_{\text{场}1} + u_3$ 的 BLUP 与含交叉项的 PEV。 [程序] [ch21/ex21_20_singular_mixed_target.py](#) [答案]

- 21.21 ★ [计算] 三头互不相关的公畜在同一场各有 2、3、5 个后代，后代均值分别为 82、79、85。 $\sigma_s^2 = 1.0$ 、 $\sigma_e^2 = 8$ ，总均值未知。写出混合模型方程，求 $\hat{\mu}$ 、 $\hat{s}_i$ 、各公畜的 PEV 与可靠度。 [答案]

- 21.22 ★★ [计算] 同一动物的两次测量误差协方差阵为 $\begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix}$ ，观测值 10 与 16，共同均值未知。求 GLS 估计、方差，并与简单平均比较。 [答案]

五、推导与证明题

- 21.23 ★★ [证明] 在联合正态假设下，证明 $\text{Cov}(u - \hat{u}, \hat{u}) = 0$ ，并据此证明 $E(u | \hat{u}) = \hat{u}$ 。 [答案]

- 21.24 ★★ [证明] 由 $Q = (y - Xb - Zu)'R^{-1}(\cdot) + u'G^{-1}u$ 的最小化推出混合模型方程，并证明它与 V 形式等价。 [答案]

- 21.25 ★★★ [证明] 证明 $\text{PEV} = G - GZ'PZG = \sigma_e^2 C^{22}$ ($R = \sigma_e^2 I$)。 [答案]

- 21.26 ★★★ [证明] 证明混合目标 $\theta = k'b + m'u$ 的 BLUP 为 $k'\hat{b} + m'\hat{u}$ ，并写出其预测误差方差中的交叉项。 [答案]

六、综合分析与研究设计题

- 21.27 ★★ [综合] 某地区 8 个猪场共用的种公猪很少，各场数据近乎互不连通。设计一个提高遗传连通的方案，并说明如何度量连通程度。 [答案]

- 21.28 ★★★ [综合] 某核心群只对被选为亲本动物及最新一代保留表型，被淘汰动物的记录从数据库中删除。分析这种做法对遗传趋势评估的影响，并给出补救方案。 [答案]

21.29 ★★★ [综合] 某品种协会只有 30 头参试公畜，每头约 4 个后代。为协会撰写评估报告：如何估计方差、如何报告 BLUP 与区间、如何说明经验 BLUP 的不确定性。

[答案]

21.6 参考答案与解析

一、单项选择题

21.1 B。 在联合正态与参数已知下 $\text{Cov}(u - \hat{u}, \hat{u}) = 0$ ，故 $E(u | \hat{u}) = \hat{u}$ 。A 与 C 混淆了方向：条件期望 $E(\hat{u} | u) = r^2 u$ ，向零收缩；D 不是正确的校准关系。 [题目]

21.2 B。 $\text{Var}(\hat{u}) = \text{Cov}(u, \hat{u}) = r^2 V_A$ 。 $(1 - r^2) V_A$ 是 PEV。 [题目]

21.3 B。 逆矩阵随机块给出的是以 σ_e^2 为单位的误差方差，只有乘上对应的缩放因子才得到 PEV；可靠度由 PEV 算出，故同样依赖尺度。 [题目]

21.4 B。 4 个场、每个场有自己的公畜，二部图有 4 个连通分量，设计矩阵的秩比列数（场 + 公畜）少 4：每个连通分量内部都有一个“场加常数、公畜减同一常数”的不可识别自由度。跨场公畜差不可估。习题 21.17 中 $L = 0$ 时 $4 + 24 = 28$ 列、秩 24。 [题目]

21.5 B。 名义 PEV 视方差比为固定，没有计入其估计误差，因而偏小。习题 21.19 中 ($S = 30$, $m = 4$) 名义 PEV 平均 0.816，而真实均方预测误差 1.012。 [题目]

21.6 B。 淘汰依赖其表型，删除它们的记录产生非随机缺失；若所用资料包含了选择依据的全部信息，则不会偏。习题 21.18：A 的末代趋势偏差 +0.029 (SE 0.042)，C 为 -6.600。 [题目]

二、判断与改错题

21.7 错误。 无偏是指对 u 的群体分布取平均： $E(\hat{u} - u) = 0$ 。固定 u 后， $E(\hat{u} | u) = r^2 u$ ，有向零的“条件偏差” $-(1 - r^2)u$ 。习题 21.15 中真值最高 1% 的动物，平均真值 5.996，平均预测 2.408，条件偏差 -3.588。 [题目]

21.8 错误。 各场使用互不相同的公畜时，场与公畜完全混杂，跨场公畜差不可估。需要联结公畜、共同亲属或其他连接。 [题目]

21.9 错误。 本程序中的方程把 $R^{-1} = \sigma_e^{-2} I$ 乘掉，随机块写作 $Z'Z + kI$ （以 σ_e^2 为单位）。此时逆矩阵给出的是 $\text{Var}(\hat{u} - u) / \sigma_e^2$ ，必须再乘 σ_e^2 才是 PEV；反过来，若方

程保留了 R^{-1} 的权，逆矩阵对角元就直接是 PEV。所以不能不看尺度就把对角元当 PEV，应用一个已知答案的小例子核对软件约定（习题 21.14）。[题目]

21.10 错误。 G 奇异时 G^{-1} 不存在，但 V 形式 $GZ'V^{-1}$ 仍然成立；也可降维 $u = Lw$ 后用方程求解。习题 21.20 中两种方法一致（差异小于 10^{-8} ）。[题目]

三、填空题

21.11 权重 1/2, 1/2, 1/4，和为 1.25；估计 $(4 + 5 + 3.25)/1.25 = 9.8$ ；方差 $1/1.25 = 0.8$ 。简单平均为 $31/3 = 10.33$ ，其方差为 $(2 + 2 + 4)/9 = 0.889$ 。[题目]

21.12 $r^2 = 4/(4 + 12) = 0.25$ ，准确度 0.5， $PEV = 4(1 - 0.25) = 3$ 。[题目]

21.13 $r^2 = 3 \times 4/(3 \times 4 + 12) = 0.5$ ， $PEV = 4 \times 0.5 = 2$ 。[题目]

21.14 $PEV = 20 \times 0.16 = 3.2$ ；可靠度 $1 - 3.2/8 = 0.6$ 。若误把 0.16 当 PEV，会得到 0.98 的虚高可靠度。[题目]

四、计算题

21.15 ($V_A = 5$ 、 $V_e = 15$ 、 $n = 60000$)

k	r^2	$\hat{u}$ 对 u 的斜率	PEV (经验)	PEV (理论)
1	0.250	0.251	3.749	3.750
2	0.400	0.400	2.986	3.000
4	0.571	0.581	2.114	2.143
8	0.727	0.721	1.385	1.364

平均 PEV 经验 2.957，理论 2.965； $E(u - \hat{u}) = +0.002$ ； u 对 $\hat{u}$ 的斜率 0.9994。选留前 10%：

依据	被选者平均真值	平均预测/观测	高估量	平均记录数
BLUP $\hat{u}$	2.537	2.535	-0.002	3.39
原始均值 $\bar{y}$	2.274	6.688	4.414	1.88

按原始均值选留的动物主要是记录少、偶然高的个体，其平均记录数仅 1.88，真值均值低于 BLUP 选留者，且被高估 4.4 个单位（胜者诅咒）。真值最高 1% 的动物平均真值 5.996，平均预测 2.408，条件偏差 -3.588，说明校准是对预测值分组的，而不是对真值分组。[题目]

21.16 $N = 65, k = 6$ 。场效应 $\hat{b} = (99.467, 100.810, 97.562, 102.290)$ (真值 100, 103, 98, 101.5)。

公畜	n	原始均值	固定效应 LS	BLUP $\hat{s}$	PEV	可靠度	误用的“可靠度”	真值
1	7	97.28	-1.533	-0.887	0.869	0.421	0.936	-1.708
2	9	101.26	0.650	0.344	0.749	0.500	0.944	-2.050
3	8	99.88	0.139	0.166	0.818	0.454	0.939	0.297
4	9	100.32	0.780	0.456	0.737	0.509	0.945	0.222
5	8	100.45	-1.206	-0.734	0.806	0.463	0.940	-0.503
6	8	97.56	-1.004	-0.462	0.824	0.450	0.939	0.072
7	8	103.37	2.711	1.423	0.812	0.459	0.940	1.800
8	8	99.80	-0.537	-0.306	0.775	0.483	0.943	0.579

MME 与 V 形式的 $\hat{b}$ 、 $\hat{s}$ 一致, PEV 矩阵与 $G - GZ'PZG$ 一致 (差异小于 10^{-8})。与真值的 Spearman 相关: BLUP 0.500、固定效应 LS 0.500、未校正场的原始均值 0.167 (这 8 头公畜样本很小, 仅作参考); 对真值 (居中) 的 RMSE: BLUP 0.970, LS 1.182。原始均值把场效应误当作公畜差异 (如公畜 7 的 103.37 主要来自场 2 与场 4 的高水平)。误把 C^{22} 对角元当 PEV 会得到 0.94 的虚高可靠度, 而正确值只有 0.42—0.51。公畜 1 与 2 的差异 PEV 为 1.397, 小于当作独立时的 1.618, 说明二者的预测误差正相关 (共用同一些场的对照)。

[题目]

21.17 (4 个场, 每场 6 头本场公畜, 每格 6 个后代, $k = 6$)

L	连通分量	秩	跨场差可估	固定模型方差	专用公畜平均可靠度	跨场差 PEV	同场差 PEV	经验 MSE	排序正确率
0	4	24	否	∞	0.417	1.750	1.500	1.869	0.733
1	1	28	是	6.000	0.434	1.688	1.500	1.474	0.723
2	1	29	是	4.500	0.444	1.650	1.500	1.452	0.758
3	1	30	是	4.000	0.451	1.625	1.500	1.611	0.727
5	1	32	是	3.600	0.461	1.594	1.500	1.606	0.733
8	1	35	是	3.375	0.469	1.568	1.500	1.593	0.762

秩 = $H + S - c$ ($L = 0$ 时 $4 + 24 - 4 = 24$)。固定模型: $L = 0$ 时跨场公畜差不可估; 有 1 头联结公畜后可估, 但方差高达 6.0, 随 L 增至 8 降到 3.375 (约按 $\sigma_e^2 \cdot (2/n)(1 + 1/L)$ 递减)。随机模型下跨场差 PEV 从 1.750 降到 1.568, 仍高于同

场差的 1.500——有联结公畜时才趋近同场水平。结论：联结公畜首先解决“能不能比”（可估性），其次才是“比得多准”；在随机效应下数值变化平缓，但因为它依赖“各场公畜平均水平相同”的假设，在场间公畜质量不同的真实群体中，缺乏连通会产生系统偏差，而这一偏差不在 PEV 中。

【题目】

21.18 ($h^2 = 0.25$, 7 个世代 $\times$ 160 头, 每代选 32 头, 80 次重复)

方法	末代趋势偏差	MC SE	末代 EBV 与真值 相关	u 对 $\hat{u}$ 斜率
A 全系谱 + 全记录	+0.029	0.042	0.557	0.999
B 无系谱（本代内）	-7.844	0.114	0.450	0.801
C 全系谱 + 删淘汰者记录	-6.600	0.055	0.544	0.992
D 无系谱不调世代	-5.888	0.086	0.450	0.801

平均真实遗传趋势为 0, 1.47, 2.82, 4.17, 5.43, 6.66, 7.84。A 的逐代偏差始终在 0.00—0.07；B 因每代内重新居中，恰好抵消了全部遗传进展，偏差等于 - 真趋势；C 虽然使用系谱，但缺失依赖于被删除者自己的表型，使基础世代的 EBV 被向上拉，趋势被低估 6.6 个单位；D 忽略世代，趋势被低估 5.9。尤其值得注意的是 C 的相关仍有 0.544、斜率 0.992，只看个体排名几乎看不出问题，趋势偏差只能靠“逐代均值 vs 真值”或与 A 对比发现。

【题目】

21.19 (真 $\sigma_s^2 = 1.5$ 、 $\sigma_e^2 = 9$ 、 $\lambda = 0.1667$, 500 次重复)

公畜数	每头后代	$\hat{\lambda}$ 均值	$\hat{\lambda}$ SD	$\hat{\lambda} = 0$ 占比	MSEP (真参)	PEV (真参)	MSEP (估参)	名义 PEV (估参)	相关 (真参)	相关 (估参)	覆盖率
30	4	0.180	0.129	0.058	0.910	0.922	1.012	0.816	0.625	0.594	0.839
30	12	0.176	0.069	0.000	0.535	0.533	0.554	0.520	0.815	0.815	0.936
100	4	0.174	0.065	0.000	0.908	0.906	0.941	0.888	0.629	0.629	0.935
100	12	0.168	0.037	0.000	0.507	0.510	0.511	0.506	0.816	0.816	0.948

真参数的 BLUP 其均方预测误差与 PEV 相差不到 2%（即真参数时 PEV 是准确的）。资料少（30 头、每头 4 个后代）时， $\hat{\lambda}$ 的标准差 0.129 相对均值 0.18 很大，5.8% 的重复估计到 $\hat{\sigma}_s^2 = 0$ （所有预测变为 0），经验 BLUP 的 MSE 比真参数高

11%，名义 PEV 比实际低 19% (0.816 对 1.012)，95% 区间覆盖率只有 83.9%。增加每头后代数比增加公畜数更能快速改善 (30×12 的覆盖率 0.936)；公畜与后代数都较多时 (100×12) 二者几乎一致。 [题目]

21.20 8 头动物，rank $G = 6$ 。V 形式

$$\hat{u} = (0.151, 0.151, 0.492, 0.492, 0.167, -0.625, -0.318, 0.132)',$$

克隆对差为 0 (精确)。降维方程与 V 形式一致 ($< 10^{-8}$)。岭近似：

ε	$\max \hat{u}_\varepsilon - \hat{u} $	条件数
1	2.31×10^{-1}	1.3×10^1
10^{-2}	2.57×10^{-3}	9.1×10^2
10^{-4}	2.58×10^{-5}	9.0×10^4
10^{-6}	2.57×10^{-7}	9.0×10^6
10^{-8}	8.9×10^{-9}	9.0×10^8

混合目标 $\theta = b_{\text{场}1} + u_3$ ： $\hat{\theta} = 50.439$ ；联合 PEV = 5.991；忽略交叉项 6.053 (交叉项 $2k'C^{12}m = -0.062$ ， $\text{Var}(k'\hat{b}) = 3.300$ ， $\text{PEV}(u_3) = 2.753$)；4000 次蒙特卡罗经验方差 5.904，偏差 -0.069 (在 5 倍标准误内)。克隆对差 $u_1 - u_2$ 的 PEV 为 0 (模型设定它们恒等)，非克隆对 $u_5 - u_6$ 的 PEV 为 6.386。结论：岭近似误差按 ε 线性减小，代价是条件数按 $1/\varepsilon$ 增长；降维方法同时给出精确解与良好的条件数。

[题目]

21.21 $k = \sigma_e^2 / \sigma_s^2 = 8$ 。固定效应 μ 的方程为 $N\mu + \sum n_i s_i = \sum n_i \bar{y}_i$ ，公畜 i 的方程为 $n_i \mu + (n_i + k)s_i = n_i \bar{y}_i$ ，消去 s_i 得 $\mu \sum w_i = \sum w_i \bar{y}_i$ ，其中 $w_i = n_i k / (n_i + k) = 1.600, 2.182, 3.077$ ($\sum w_i = 6.859$)。于是

$$\hat{\mu} = \frac{1.6 \times 82 + 2.182 \times 79 + 3.077 \times 85}{6.859} = 82.39,$$

$$\hat{s}_i = \frac{n_i(\bar{y}_i - \hat{\mu})}{n_i + 8} = -0.078, -0.925, +1.003.$$

PEV ($\sigma_s^2 = 1$ 时) 为 0.847, 0.814, 0.788，可靠度 0.153, 0.186, 0.212。后代数越多，可靠度越高；但即便 5 个后代，可靠度也只有 0.21，因为 $k = 8$ 意味着遗传方差只占总方差的 1/9。 [题目]

21.22 $V^{-1}1 \propto (9 - 2, 4 - 2) = (7, 2)$ ，权重 $(7/9, 2/9) = (0.778, 0.222)$ ；GLS 估计 $0.778 \times 10 + 0.222 \times 16 = 11.33$ ，方差 $(1'V^{-1}1)^{-1} = 3.556$ 。简单平均 13，方差

$(4 + 9 + 2 \times 2)/4 = 4.25$ 。GLS 权重更多地给了方差较小的第一次测量；同时因为两次误差正相关，权重不是按 $1/4 : 1/9$ 的独立情形 ($0.692 : 0.308$) 分配的，而是对相关部分做了校正，最终方差更小。 [题目]

五、推导与证明题

21.23 证明。联合正态下， $\hat{u} = GZ'Py$ 且 $PX = 0$, $PVP = P$ 。于是 $\text{Cov}(u, \hat{u}) = \text{Cov}(u, y)PZG = GZ'PZG$, $\text{Var}(\hat{u}) = GZ'PVPZG = GZ'PZG$, 故

$$\text{Cov}(u - \hat{u}, \hat{u}) = GZ'PZG - GZ'PZG = 0.$$

联合正态时零协方差即独立，所以 $E(u - \hat{u} | \hat{u}) = E(u - \hat{u}) = 0$, 即 $E(u | \hat{u}) = \hat{u}$ 。 ■ [题目]

21.24 证明。对 Q 求偏导：

$$\partial Q / \partial b = -2X'R^{-1}(y - Xb - Zu) = 0,$$

$$\partial Q / \partial u = -2Z'R^{-1}(y - Xb - Zu) + 2G^{-1}u = 0.$$

整理为混合模型方程。由第二式 $\hat{u} = (Z'R^{-1}Z + G^{-1})^{-1}Z'R^{-1}(y - X\hat{b})$ 。用 Woodbury 恒等式

$$(Z'R^{-1}Z + G^{-1})^{-1}Z'R^{-1} = GZ'(ZGZ' + R)^{-1} = GZ'V^{-1},$$

得 $\hat{u} = GZ'V^{-1}(y - X\hat{b})$ 。把它代入第一式并同样化简，得 $X'V^{-1}X\hat{b} = X'V^{-1}y$, 即 GLS。 ■ [题目]

21.25 证明。取满足 $K'X = 0$ 的 $n_y \times (n_y - p)$ 列满秩矩阵 K (误差对比)，把数据变换为 $w = K'y = K'Zu + K'e$, 固定效应被消去。对该模型，BLUP 与 PEV 为

$$\hat{u} = GZ'K(K'VK)^{-1}K'y = GZ'Py, \quad \text{PEV} = G - GZ'PZG,$$

其中 $P = K(K'VK)^{-1}K'$ 就是前文的投影矩阵 (此为标准恒等式，两者都满足 $PX = 0$ 、 $PVP = P$ 且在 V 度量下的值域相同)。对 w 的模型用矩阵求逆引理 (Woodbury)：令 $A = K'Z$ 、 $W = K'RK$,

$$G - GA'(AGA' + W)^{-1}AG = (G^{-1} + A'W^{-1}A)^{-1}.$$

而 $KW^{-1}K' = K(K'RK)^{-1}K' = R^{-1} - R^{-1}X(X'R^{-1}X)^{-1}X'R^{-1}$ (吸收固定效应后的权矩阵)。于是

$$\text{PEV} = [G^{-1} + Z'(R^{-1} - R^{-1}X(X'R^{-1}X)^{-1}X'R^{-1})Z]^{-1}.$$

这正是混合模型方程吸收固定效应后,随机块的 Schur 补之逆,即 $\sigma_e^2 C^{22} (R = \sigma_e^2 I)$ 。
习题 21.16 中两者数值相等 (差异小于 10^{-8})。■ [题目]

21.26 证明。在线性无偏预测量 $\hat{\theta} = a'y$ 中, 无偏要求 $a'X = k'$ 。最小化 $\text{Var}(a'y - \theta) = a'Va - 2a'ZGm + m'Gm$, 约束 $X'a = k$ 。拉格朗日条件给出 $Va - ZGm + X\lambda = 0$, 解为 $a'y = k'\hat{b} + m'GZ'V^{-1}(y - X\hat{b}) = k'\hat{b} + m'\hat{u}$ 。预测误差方差见推导 21.3:

$$\text{Var}(\hat{\theta} - \theta) = \text{Var}(k'\hat{b}) + \text{PEV}(m'\hat{u}) + 2\sigma_e^2 k' C^{12} m,$$

其中交叉项 $2\sigma_e^2 k' C^{12} m$ 是 $\hat{b} - b$ 与 $\hat{u} - u$ 的协方差的两倍, 一般不为零。■ [题目]

六、综合分析与研究设计题

21.27 方案 (1) 度量: 以“场 × 公畜”二部图的连通分量数、每个场的联结公畜数及其后代占比为基础; 计算跨场公畜差的 PEV 与可靠度, 另用“遗传连通度”(跨场比较的预测误差方差与同场比较的比值) 监控。习题 21.17 表明: $L = 0$ 时 4 个场互不连通 (秩亏 4), 1 头联结公畜即可连通, 每增加联结公畜, 固定模型的跨场差方差按 $(1 + 1/L)$ 递减; PEV 在随机模型下从 1.75 降到 1.57, 已接近同场的 1.50。(2) 设计: 每年每个场使用 2—3 头共用的联结公畜 (人工授精或冷冻精液轮换), 使每个联结公畜在每场至少有 ≥ 10 个后代; 优先选择在多个场使用且相互无亲缘关系的公畜; 再以系谱上的亲缘 (共祖) 补充连接, 不能依赖未经核实的血缘。(3) 评估模型: 把场 × 年季作为固定效应, 公畜或个体作为随机效应并使用全系谱; 若有基因型, 则用基因组关系矩阵建立跨场连接 (第 26—28 章)。(4) 监测: 每年发布连通度报告, 若某场的联结后代比例低于 10%, 则暂不发布跨场排名。(5) 风险: 联结公畜若与场发生互作 ($G \times E$), 其效应在不同场不同, 需要在模型中考虑场特异性。 [题目]

21.28 分析: 淘汰依赖于动物自己的表型, 删除它们的记录相当于对低值数据的非随机缺失, 缺失依赖于缺失值本身 (MNAR), 因此原动物模型的“选择仅基于所用资料”条件被破坏。习题 21.18 的模拟显示: 全系谱全记录的遗传趋势偏差 +0.03, 删淘汰者记录后偏差 -6.6, 几乎相当于低估了全部遗传进展 (真趋势 7.84); 末代个体排名相关仍有 0.544, 几乎不可察觉。后果: (1) 趋势被低估, 导致对育种方案成效的误判; (2) 基础世代的 EBV 被过度抬高, 早期动物 (祖先) 的价值被虚高; (3) 若多个性状分别有不同的删除规则, 偏差不可预测。**补救:** (1) 立即停止删除, 保存完整记录与被淘汰动物的系谱; (2) 若记录已丢失, 则用保留的资料, 但把“被选/被淘汰”作为已知的选择指示变量, 使用包括选择依据 (早期记录) 在内的多

性状模型，即把淘汰当作多性状选择的一个已知过程；(3) 若基因型已保存，可用单步方法（第 28 章）通过基因组关系重新连接；(4) 以保留的完整数据集（若有）做对照，核对趋势；(5) 制度上区分“数据库存储”和“育种决策”，记录是核心资产。

【题目】

21.29 报告要点 (1) 资料：30 头参试公畜、每头约 4 个后代，合计约 120 条记录；总信息量很小。(2) 方差估计：用 REML 估计 σ_s^2 与 σ_e^2 ，同时给出置信区间（似然轮廓或自助法）。习题 21.19 的同类设计（30 头 $\times$ 4 后代）中，真 $\lambda = 0.167$ ，估计 $\hat{\lambda}$ 的均值 0.18 但标准差 0.129，5.8% 的重复估计到 $\hat{\sigma}_s^2 = 0$ 。因此必须说明方差估计可能很不稳定，必要时用外部（品种历史）先验或贝叶斯分析，把方差的不确定性积分掉。(3) BLUP 报告：同时报告预测值、PEV 与可靠度，并明确 PEV 是“以估计参数为真值”的名义量：习题 21.19 中名义 PEV 平均 0.816，而真实均方预测误差 1.012，名义 95% 区间覆盖率仅 0.839。(4) 区间：可采用 Kackar–Harville 校正、参数自助法，或贝叶斯可信区间；报告“公畜 A 优于公畜 B 的概率”而非仅差值。(5) 提示：排名靠前与靠后的公畜之间区别可能不显著；每个后代数少于 10 的公畜不应单独发布星级；明确与场的连通性（习题 21.17）。(6) 改进：增加每头公畜的后代数比增加公畜数更快改善精度（30 $\times$ 12 的覆盖率 0.936），建议下一轮试验以此为目标。

【题目】

动物模型与复杂遗传效应

22.1 本章导学

学习目标

1. 能由亲本平均加孟德尔抽样写出动物模型的协方差结构，并用 Henderson 规则直接构造 A^{-1} （含近交）。

2. 理解无记录祖先在混合模型方程中的信息回传，会区分“吸收”（保留信息）与“删除”（丢失信息）。

3. 掌握公畜模型与动物模型的尺度桥梁 $\lambda_s = (4 - h^2)/h^2$ ，并知道错用方差比的后果。

4. 能写出含直接、母体遗传与母体永久环境、窝效应的协方差核，判断设计的可识别性并估计方差组分的精度。

5. 理解社会（间接）遗传效应、总育种值与选择响应，会在群体结构（亲缘组群、接触网络）下计算。

6. 会处理杂交均值模型的可识别性与未知亲本组（遗传组），并评价引入外来个体时的基准偏差。

重点与难点

重点： A^{-1} 的 Henderson 规则与 $b_i = [\frac{1}{2} - \frac{1}{4}(F_s + F_d)]^{-1}$ ； $\lambda_s = (4 - h^2)/h^2$ ；母体模型的六个协方差核；社会效应总育种值 $T = D + (n - 1)S$ ；遗传组的 Quaas-Pollak 变换。

难点：吸收与删除的区别；母体永久环境与窝效应在“每母一窝”时的完全混杂；负的直接—社会遗传相关使个体选择响应可以为负；外来个体不设组时基准偏差与趋势偏差。

本章把第 21 章的混合模型方程用到动物模型及其复杂扩展上，并为第 23 章方差组分估计（识别性与信息矩阵）、第 24 章多性状模型与第 28 章单步评定（遗传组与 A^{-1} 的基因组版本）做准备。

22.2 知识结构图




图 22.1 第 22 章知识结构图

左侧是动物模型的核心结构，右侧是母体、社会、杂交与基础群的扩展。

22.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
动物模型	$y = X\beta + Zu + e,$ $\text{Var}(u) = A\sigma_u^2$	无限小模型
孟德尔抽样方差	$[\frac{1}{2} - \frac{1}{4}(F_s + F_d)]\sigma_u^2$	亲本各自近交系数
Henderson 规则	$b_i = [\frac{1}{2} - \frac{1}{4}(F_s + F_d)]^{-1}$	双亲已知; 单亲已知用 $\frac{3}{4} - \frac{1}{4}F_s$
近交系数	$F_i = \frac{1}{2}a_{sd}$	a_{sd} 为双亲加性关系
吸收	对无记录动物作 Schur 补	保留方程的解不变
公畜模型尺度	$s = \frac{1}{2}u_{\text{sire}}, \sigma_s^2 = \frac{1}{4}\sigma_u^2$	母亲未知且无关
公畜模型方差比	$\lambda_s = (4 - h^2)/h^2$	公畜间无亲缘
母体模型	$\text{Var} \begin{bmatrix} u \\ m \end{bmatrix} = \begin{bmatrix} \sigma_u^2 & \sigma_{um} \\ \sigma_{um} & \sigma_m^2 \end{bmatrix} \otimes A$	$ \sigma_{um} \leq \sigma_u \sigma_m$
单记录总方差	$\sigma_u^2 + \sigma_m^2 + \sigma_{um} \cdot \text{交叉项}$ $+ \sigma_c^2 + \sigma_l^2 + \sigma_e^2$	交叉项系数为 $2a_{id}$

概念	公式或定义	成立条件与提示
社会总育种值	$T_i = D_i + (n-1)S_i$	群大小 n , 无稀释
总育种值方差	$\sigma_T^2 = \sigma_D^2 + 2(n-1)\sigma_{DS} + (n-1)^2\sigma_S^2$	同伴随机分组
杂交均值模型	$E(y) = \mu + \delta_a q + \delta_m q_m + \eta h + \eta_m h_m$	品种比例与杂合度
遗传组	$u = Qg + a$	Q 为组成员比例
纯种—杂种指数	$b = P^{-1}c$	$r_{PC} < 1$

22.4 补充内容与公式推导

推导 22.1 Henderson 规则与孟德尔抽样方差

设 $a_i = \frac{1}{2}(a_s + a_d) + \phi_i$, 其中孟德尔抽样项 ϕ_i 与父母值无关, 方差

$$\text{Var}(\phi_i) = \left[\frac{1}{2} - \frac{1}{4}(F_s + F_d) \right] \sigma_u^2 = d_i \sigma_u^2.$$

证明: $\text{Var}(a_i) = (1 + F_i)\sigma_u^2$, 而 $\text{Var}[\frac{1}{2}(a_s + a_d)] = \frac{1}{4}[(1 + F_s) + (1 + F_d) + 2a_{sd}]\sigma_u^2$ 。

使用 $a_{sd} = 2F_i$, 则 $\text{Var}(\phi_i) = (1 + F_i) - \frac{1}{4}(2 + F_s + F_d) - F_i = \frac{1}{2} - \frac{1}{4}(F_s + F_d)$ 。

写成矩阵形式 $a = Pa + \phi$ (P 的每行在父母位置为 $\frac{1}{2}$), 则 $a = (I - P)^{-1}\phi$, $A = (I - P)^{-1}D(I - P)^{-1}$, 所以

$$A^{-1} = (I - P)'D^{-1}(I - P).$$

D 为对角, 故 A^{-1} 稀疏: 每个动物 i 向 (i, i) 加 b_i , 向 (i, s) 与 (i, d) 各加 $-\frac{1}{2}b_i$, 向 $(s, s), (d, d)$ 各加 $\frac{1}{4}b_i$, 向 (s, d) 加 $\frac{1}{4}b_i$, $b_i = 1/d_i$ 。习题 22.21 的 5 头动物中 $F_4 = 0.25$, $F_5 = 0.375$, 由此规则得到的逆阵的 $(3, 3)$ 元素为 3.0714。

推导 22.2 公畜模型的尺度与 $\lambda_s = (4 - h^2)/h^2$

设后代 i 只知父亲 k , 母亲未知且互不相关。则 $u_i = \frac{1}{2}u_k + \phi_i$, 其中 ϕ_i 的方差 (父亲近交为 0) 为 $\frac{3}{4}\sigma_u^2$ 。令 $s_k = \frac{1}{2}u_k$ (公畜效应), $\sigma_s^2 = \frac{1}{4}\sigma_u^2$, 则

$$y_i = \mu + s_k + w_i, \quad w_i = \phi_i + e_i, \quad \sigma_w^2 = \frac{3}{4}\sigma_u^2 + \sigma_e^2.$$

方差比

$$\lambda_s = \frac{\sigma_w^2}{\sigma_s^2} = \frac{\frac{3}{4}\sigma_u^2 + \sigma_e^2}{\frac{1}{4}\sigma_u^2} = 3 + 4\frac{\sigma_e^2}{\sigma_u^2}.$$

令 $h^2 = \sigma_u^2 / (\sigma_u^2 + \sigma_e^2)$, 则 $\sigma_e^2 / \sigma_u^2 = (1 - h^2) / h^2$, $\lambda_s = 3 + 4(1 - h^2) / h^2 = (4 - h^2) / h^2$ 。习题 22.16 中 $h^2 = 0.25$: 动物模型 $\lambda_a = 3$, 公畜模型 $\lambda_s = 15$ 。动物模型对公畜的预测满足 $\hat{u}_{\text{sire}} = 2\hat{s}$, $\text{PEV}_u = 4\text{PEV}_s$, 在 715 个后代的一次资料上精确到 10^{-14} 。若把动物模型的 $\sigma_e^2 / \sigma_s^2 = 12$ 直接搬进公畜方程, 则收缩不足, 真值对预测值回归斜率偏离 1 (模拟 0.930, 而正确 λ_s 为 1.015)。

推导 22.3 含母体效应的两记录协方差

记 $y_i = \mu + u_i + m_{d(i)} + c_{d(i)} + l_{L(i)} + e_i$, 其中 u_i 为个体直接遗传值, $m_{d(i)}$ 为其母亲 $d(i)$ 的母体遗传值, c 为母体永久环境, l 为窝效应。两条记录的协方差

$$\text{Cov}(y_i, y_j) = a_{ij}\sigma_u^2 + a_{d_id_j}\sigma_m^2 + (a_{id_j} + a_{jd_i})\sigma_{um} + \mathbf{1}[d_i = d_j]\sigma_c^2 + \mathbf{1}[L_i = L_j]\sigma_l^2 + \mathbf{1}[i = j]\sigma_e^2.$$

单记录方差为 $\sigma_u^2(1 + F_i) + \sigma_m^2(1 + F_d) + 2a_{id}\sigma_{um} + \sigma_c^2 + \sigma_l^2 + \sigma_e^2$ 。习题 22.17 中同窝全同胞 ($a_{ij} = 0.5$, 母亲相同 $a_{d_id_j} = 1$, 交叉项 $a_{id_j} + a_{jd_i} = 1$, 同母同窝) 的协方差: $0.5 \times 12 + 1 \times 5 + 1 \times (-2) + 3 + 2 = 14$; 同母异窝则 $0.25 \times 12 + 5 - 2 + 3 = 9$ 。注意直接—母体协方差 σ_{um} 的合法范围是 $|\sigma_{um}| \leq \sqrt{12 \times 5} = 7.75$, 相关为 $-2/7.75 = -0.26$ 。

推导 22.4 社会遗传效应下的个体选择响应

群大小 n , 同伴间亲缘 r 。个体表型 $P_i = D_i + \sum_{k \neq i} S_k + c + e_i$, 总育种值 $T_i = D_i + (n-1)S_i$ 。则

$$\text{Cov}(T_i, P_i) = \sigma_D^2 + (n-1)(1+r)\sigma_{DS} + (n-1)^2 r \sigma_S^2.$$

依据在于 T_i 中 $(n-1)S_i$ 与 P_i 中同伴的 S_k 通过亲缘 r 相关, 与自己的 D_i 无关; D_i 与同伴 S_k 的相关为 $r\sigma_{DS}$ 。个体选择的响应 $R = i \text{Cov}(T_i, P_i) / \sigma_P$ 。习题 22.18 中 $n = 5$, $\sigma_D^2 = 6$, $\sigma_S^2 = 0.5$, $\sigma_{DS} = -1.6$: 同伴无亲缘 ($r = 0$) 时 $\text{Cov}(T, P) = 6 + 4 \times (-1.6) = -0.4 < 0$, 个体选择的响应为负 (-0.102); $r = 0.25$ 时恰好为 0; $r = 0.5$ 时为 $+0.109$ 。换言之, 对高表型的选择在无亲缘群中, 选的是“有利于自己、不利于同伴”的个体, 在群体水平上得不偿失。整群选择则使 $R = i \sigma_T^2 [1 + (n-1)r] / \sigma_{\Sigma P}$ 始终为正。

拓展阅读 母体、社会与基础群的现代处理

Willham (1963, 1972) 最早系统提出母体效应的遗传模型; Henderson (1976) 与 Quaas (1976) 给出了含近交的 A^{-1} 的简便计算; Quaas 与 Pollak (1981) 把遗传组放进混合模型方程; Westell 等 (1988) 比较了遗传组的不同定义。社会遗传效应方面, Muir (2005) 与 Bijma、Muir 和 Van Arendonk (2007) 建立了总育种值与多层

选择理论, 指出当直接与社会效应相关为负时, 个体选择会降低群体表现, 而基于亲缘组群或群体选择更有效。母体模型的识别性问题 (尤其是母体永久环境与窝效应) 在实践中需要同母异窝记录, 否则估计会不稳定。

易错辨析

- **无记录祖先不能直接删除**: 删除后其后代改作创始者, EBV 与场效应都会改变 (习题 22.15: EBV 最大变化 2.115); 应通过吸收保留其信息。
- **近交系数与孟德尔抽样方差用的是不同的亲缘信息**: 前者用双亲彼此的加性关系, 后者用双亲各自的近交系数, 二者不可互换。
- **相关系数不可随意换算**: 直接—母体协方差为 -3 时, 直接—母体遗传相关为 $-3/\sqrt{\sigma_u^2\sigma_m^2}$, 而不是除以总表型方差。
- **优化器给出两个正方差不等于被识别**: 每母一窝时母体永久环境与窝效应的设计核完全相同, 似然只依赖二者之和。
- **社会效应下个体选择响应的符号可能为负**: 取决于直接—社会协方差与群内亲缘。
- **外来个体必须设遗传组**: 否则被当作基础群的平均水平, EBV 与遗传趋势被系统性低估 (习题 22.20: 外来公羊 EBV 平均偏低 6.5)。

22.5 习题

一、单项选择题

22.1 ★ [单选] 父亲无近交、母亲近交系数 0.25, 则后代孟德尔抽样方差相对于 σ_u^2 的系数为

- (A) 0.5 (B) 0.4375 (C) 0.375 (D) 0.25

[答案]

22.2 ★ [单选] 一头公畜自身无记录, 但其后代有记录。在动物模型的混合模型方程中, 这头公畜的 EBV

- (A) 恒为零
(B) 通过关系矩阵从后代与亲属获得信息
(C) 与无亲缘动物相同 (D) 无法计算

[答案]

22.3 ★★ [单选] 父系半同胞后代结构、母亲未知且无关, $h^2 = 0.4$ 。公畜模型的方差比 λ_s 为

- (A) 1.5 (B) 9 (C) 6 (D) 15

[答案]

22.4 ★★ [单选] 直接遗传方差为 9, 母体遗传方差为 4。下列哪一个直接—母体协方差 不合法?

- (A) -5 (B) -3 (C) 0 (D) -7

[答案]

22.5 ★★ [单选] 在社会遗传效应模型中, 群大小 n 的动物的总育种值为

- (A) $D + S$ (B) $D + nS$ (C) $D + (n - 1)S$
(D) $(n - 1)D + S$

[答案]

22.6 ★★★ [单选] 引入遗传水平更高但亲本未知的外来公羊, 若分析时不设遗传组, 把 其亲本全部视为基础群平均, 则外来公羊的 EBV 与遗传趋势

- (A) 无偏 (B) 被低估 (C) 被高估
(D) 方向不定但无系统偏差

[答案]

二、判断与改错题

22.7 ★ [判断] 为了节省计算, 无记录的祖先可以直接从动物模型中删除, 其后代当作 创始者而不会影响估计。

[答案]

22.8 ★★ [判断] 母体模型中, 同窝全同胞的记录协方差只含直接遗传方差。

[答案]

22.9 ★★ [判断] 每只母亲只产一窝时, 同时拟合母体永久环境与窝效应, 两个方差可 以分别被唯一估计。

[答案]

22.10 ★★★ [判断] 当直接与社会遗传效应为负相关时, 对个体表型的选择在无亲缘群中 仍会提高群体平均表现。

[答案]

三、填空题

22.11 ★ [填空] 父亲无近交, 母亲近交系数 0.25, 则 A^{-1} 的 Henderson 权重 $b_i =$ _____ (保留四位小数)。 [答案]

22.12 ★ [填空] 只知父亲、母亲未知, 父亲无近交, 则 $b_i =$ _____ (保留四位小数)。 [答案]

22.13 ★★ [填空] $n = 6$, $\sigma_D^2 = 3$, $\sigma_S^2 = 0.5$, $\sigma_{DS} = -0.5$, 则总育种值方差为 _____。 [答案]

22.14 ★★ [填空] A 品种公畜与 F_1 (A×B) 母畜交配, 后代的 A 品种比例为 _____, 个体品种间杂合系数为 _____。 [答案]

四、计算题

22.15 ★★★ [计算] 动物模型与无记录祖先。15 头动物、9 条记录 ($\sigma_u^2 = 20$, $\sigma_e^2 = 40$, 两个场), 其中动物 1、2、6、10、14、15 无记录。求 BLUP、PEV、可靠度; 用吸收保留方程重算; 再比较“直接删除无记录祖先”的结果。 [程序] `ch22/ex22_15_animal_model_mme.py` [答案]

22.16 ★★★ [计算] 公畜模型与动物模型。30 头公畜, 715 个后代, $h^2 = 0.25$ ($\sigma_u^2 = 25$, $\sigma_e^2 = 75$)。核验两模型对公畜的等价关系, 并比较正确与错误方差比的 300 次重复模拟。 [程序] `ch22/ex22_16_sire_vs_animal.py` [答案]

22.17 ★★★ [计算] 母体模型的协方差核与可识别性。三种设计: 甲 (每母一窝 4 羔, 母亲有自身记录)、乙 (每母两窝各 2 羔)、丙 (每母两窝, 母亲无自身记录)。逐对核验协方差, 检验六个核的线性无关性, 并在真参数处计算方差组分的近似标准误。 [程序] `ch22/ex22_17_maternal_kernels.py` [答案]

22.18 ★★★ [计算] 社会遗传效应。群大小 5, $\sigma_D^2 = 6$, $\sigma_S^2 = 0.5$, $\sigma_{DS} = -1.6$, $\sigma_c^2 = 2$, $\sigma_e^2 = 20$ 。计算群内亲缘 $r = 0, 0.25, 0.5$ 的个体与整群选择响应, 并分析一条六栏位的线性接触链。 [程序] `ch22/ex22_18_social_effects.py` [答案]

22.19 ★★★ [计算] 杂交均值模型的可识别性。8 种交配类型、4 种设计, 计算秩、零空间与标准误; 纯种—杂种遗传相关 0.6 时, 计算纯种 EBV 与杂种后代合并的指数可靠度。 [程序] `ch22/ex22_19_crossbreeding.py` [答案]

22.20 ★★★ [计算] 未知亲本组。闭锁羊群每年引入 5 头未知亲本的外来公羊，其遗传均值依次为 3、6、9、12。比较无组模型与遗传组 (Quaas-Pollak) 模型的遗传趋势偏差与外来公羊 EBV 偏差。 [程序] [ch22/ex22_20_unknown_parent_groups.py](#) [答案]

22.21 ★★ [计算] 系谱：1、2 为无亲缘基础动物； $3 = (1 \times 2)$ ； $4 = (1 \times 3)$ ； $5 = (3 \times 4)$ 。求 A 、各动物近交系数，并用 Henderson 规则写出 A^{-1} 。 [答案]

22.22 ★★ [计算] 母体模型： $\sigma_u^2 = 12$ 、 $\sigma_m^2 = 5$ 、 $\sigma_{um} = -2$ 。目标 $H = u + 3m$ ，已知预测误差方差 $\text{Var}(\hat{u} - u) = 2.5$ 、 $\text{Var}(\hat{m} - m) = 1.2$ 、协方差 -0.4 。求目标的预测误差方差、遗传方差与可靠度。 [答案]

五、推导与证明题

22.23 ★★ [证明] 证明 $\text{Var}(\phi_i) = \frac{1}{2} - \frac{1}{4}(F_s + F_d)$ (以 σ_u^2 为单位) 并推出 Henderson 的 $A^{-1} = (I - P)'D^{-1}(I - P)$ 。 [答案]

22.24 ★★ [证明] 证明公畜模型的方差比 $\lambda_s = (4 - h^2)/h^2$ ，并证明动物模型对公畜的预测与公畜模型满足 $\hat{u}_{\text{sire}} = 2\hat{s}$ 。 [答案]

22.25 ★★★ [证明] 证明当每只母亲只有一窝记录时，母体永久环境核与窝效应核相同，因而 σ_c^2 与 σ_l^2 不可分离，只有 $\sigma_c^2 + \sigma_l^2$ 可估。 [答案]

22.26 ★★★ [证明] 证明 $\text{Cov}(T_i, P_i) = \sigma_D^2 + (n - 1)(1 + r)\sigma_{DS} + (n - 1)^2 r \sigma_S^2$ ，并讨论其符号随 r 的变化。 [答案]

六、综合分析与研究设计题

22.27 ★★ [综合] 某绵羊场想估计羔羊断奶重的直接与母体遗传效应。设计数据收集方案 (记录哪些个体、每母几窝、如何确保母体永久环境与窝效应可分)，并写出模型选择的步骤。 [答案]

22.28 ★★★ [综合] 某猪场群饲，希望利用社会遗传效应改良日增重。设计试验 (群组成：全同胞组、半同胞组或随机混群)，说明如何估计 $\sigma_D^2, \sigma_S^2, \sigma_{DS}$ ，并给出育种方案的建议。 [答案]

- 22.29 ★★★ [综合]** 某牛群连续几年从国外引入亲本未知的种公牛, 近年发现遗传趋势估计与实际表现不符。制定诊断与处理方案。 [答案]

22.6 参考答案与解析

一、单项选择题

- 22.1 B.** $0.5 - 0.25(0 + 0.25) = 0.4375$ 。孟德尔抽样方差随亲本近交增大而减小(亲本越近交, 传递的分离变异越少)。 [题目]
- 22.2 B.** 无记录动物的信息通过 A^{-1} 的非对角元与后代、亲属联系; 它的 EBV 一般不为零, 如习题 22.15 中无记录的动物 1、2、6、10 的 EBV 为 1.130, 2.125, 2.645, -0.542。 [题目]
- 22.3 B.** $\lambda_s = (4 - 0.4)/0.4 = 9$ 。若误用 $\sigma_e^2/\sigma_u^2 = 1.5$ 的动物模型方差比, 对公畜的收缩将严重不足。 [题目]
- 22.4 D.** 合法协方差满足 $|\sigma_{um}| \leq \sqrt{9 \times 4} = 6$, 故 -7 不合法(协方差矩阵出现负特征值)。 [题目]
- 22.5 C.** 个体对群体的贡献包含自身直接效应与对 $n - 1$ 个同伴的社会效应。习题 22.18 中 $n = 5$ 的总育种值为 $D + 4S$ 。 [题目]
- 22.6 B.** 外来公羊(遗传均值高)被当作基础群均值, 其后代与同代表现的超出被错误地归因到场、年或随机抽样, 导致趋势低估。习题 22.20: 外来公羊 EBV-TBV 平均 -6.503 (遗传组模型为 +0.294)。 [题目]

二、判断与改错题

- 22.7 错误。** 删除无记录祖先后, 其后代被当作无亲缘的创始者, 关系信息丢失。习题 22.15: EBV 最大变化 2.115 (动物 8), 场效应由 (54.182, 52.2) 变为 (54.622, 53.644)。正确做法是用 Schur 补“吸收”(保留方程的解精确不变, 最大差 8.9×10^{-16}) 或直接保留于方程。 [题目]
- 22.8 错误。** 同窝全同胞共享同一母亲, 协方差还包含母体遗传、直接—母体交叉项、母体永久环境与窝效应。习题 22.17 中同窝全同胞的协方差为 14, 仅直接遗传部分是 $0.5 \times 12 = 6$ 。 [题目]

22.9 错误。每母一窝时两核完全相同 ($K_c \equiv K_l$)，似然只依赖 $\sigma_c^2 + \sigma_l^2$ 。习题 22.17 设计甲中六个核的秩为 5/6，两项是共线的；设计乙（每母两窝）秩为 6/6。 [题目]

22.10 错误。无亲缘群中 $\text{Cov}(T, P) = \sigma_D^2 + (n - 1)\sigma_{DS}$ 可为负。习题 22.18: $r = 0$ 时 -0.4 ，个体选择响应为 -0.102 。 [题目]

三、填空题

22.11 $b_i = 1/[0.5 - 0.25(0 + 0.25)] = 1/0.4375 = \mathbf{2.2857}$ 。 [题目]

22.12 $b_i = 1/(0.75 - 0.25 \times 0) = \mathbf{1.3333}$ 。 [题目]

22.13 $\sigma_T^2 = 3 + 2 \times 5 \times (-0.5) + 25 \times 0.5 = 3 - 5 + 12.5 = \mathbf{10.5}$ 。 [题目]

22.14 A 比例 $(1 + 0.5)/2 = \mathbf{0.75}$ ；杂合系数 $h = q_s(1 - q_d) + (1 - q_s)q_d = 1 \times 0.5 + 0 = \mathbf{0.5}$ 。 [题目]

四、计算题

22.15 $\sigma_u^2 = 20$, $\sigma_e^2 = 40$ ($\lambda = 2$)，两个场: $\hat{\beta} = (54.182, 52.200)$ 。

动物	父	母	F	记录	EBV	PEV	r^2	删除法 EBV
1	0	0	0	—	1.130	18.283	0.086	—
2	0	0	0	—	2.125	18.457	0.077	—
3	0	0	0	46.0	-2.713	15.405	0.230	-2.824
4	1	2	0	58.5	2.734	15.306	0.235	2.174
5	1	3	0	51.0	-1.787	16.413	0.179	-2.621
6	1	2	0	—	2.645	17.832	0.108	—
7	6	3	0	55.5	0.983	17.274	0.136	-0.089
8	6	5	0.125	49.0	-0.863	19.557	0.131	-2.979
9	6	4	0.25	62.0	4.112	19.480	0.221	3.069
10	0	0	0	—	-0.542	17.423	0.129	—
11	10	7	0	57.0	1.096	16.087	0.196	1.143
12	10	8	0	44.5	-2.031	17.011	0.149	-3.577
13	6	11	0.125	60.5	2.760	18.019	0.199	2.019
14	9	12	0.125	—	1.040	21.244	0.056	—
15	9	12	0.125	—	1.040	21.244	0.056	—

用 V 形式独立重算与 MME 一致；吸收 6 头无记录动物后的保留方程解与完整 MME 最大差 8.9×10^{-16} （保留信息）；直接删除时 EBV 最大绝对变化 2.115（动

物 8)。候选者 14、15 无记录, EBV 均等于亲本均值 $\frac{1}{2}(\hat{u}_9 + \hat{u}_{12}) = 1.040$, 其可靠度只有 0.056 (仅来自亲本, 且 $PEV_{21.24}$ 已接近先验方差 $(1 + F)\sigma_u^2 = 22.5$)。这是“系谱指数”的典型: 亲本均值恒为 EBV, 孟德尔抽样部分无信息。 [题目]

22.16 $h^2 = 0.25$, $\lambda_a = 3$, $\lambda_s = 15$, 错误的 $\sigma_e^2/\sigma_s^2 = 12$ 。一次资料 (715 个后代): $\max |\hat{u}_{\text{sire}} - 2\hat{s}| = 2.3 \times 10^{-14}$ 、 $\max |PEV_u - 4PEV_s| = 2.1 \times 10^{-14}$ 。可靠度 (实际与理论 $n/(n + \lambda_s)$, 忽略组效应估计): 公畜 20: $n = 4$, 0.208 对 0.211; 公畜 3: $n = 25$, 0.602 对 0.625; 公畜 1: $n = 39$, 0.690 对 0.722。300 次重复:

方差比	λ	真值对预测的回归 b	相关 r	MSE
正确	15.00	1.0151	0.7447	2.7394
错误	12.00	0.9303	0.7444	2.7648

方差比错误对排序 (相关) 几乎没有影响, 但使预测离散度偏大: 回归斜率 $0.930 < 1$ (真值对预测的回归小于 1, 即预测过分分散), 均方误差增大 0.9%。结论: 只关心排序时影响小; 需要育种值的绝对大小、选择反应预测或区间时, 方差比必须正确。 [题目]

22.17 三种设计的关键结果 ($\sigma_u^2 = 12$ 、 $\sigma_m^2 = 5$ 、 $\sigma_{um} = -2$ 、 $\sigma_c^2 = 3$ 、 $\sigma_l^2 = 2$ 、 $\sigma_e^2 = 20$):

关系	a_{ij}	$a_{d_i d_j}$	交叉项	同母	同窝	协方差
同窝全同胞	0.5	1.0	1.0	是	是	14
同母异窝	0.25	1.0	1.0	是	否	9
母亲为全同胞姐妹	0.125	0.5	0.5	否	否	3
父系半同胞, 母无亲缘	0.25	0	0	否	否	3
母亲自身记录—其羔羊	0.5	0.5	1.25	否	否	6

单条记录方差 40。可识别性:

设计	记录数	去均值后六个核的秩	$K_c \equiv K_l$	$K_{dm} \equiv K_m$	母亲设固定后的秩
甲每母一窝 4 羔, 有母亲记录	160	5/6	是	否	1
乙每母两窝各 2 羔, 有母亲记录	160	6/6	否	否	3

设计	记录数	去均值后六个核的秩	$K_c \equiv K_l$	$K_{dm} \equiv K_m$	母亲设固定后的秩
丙每母两窝, 无母亲记录	120	5/6	否	是	3

设计乙在真参数处的近似标准误 (REML 期望信息): σ_u^2 真值 12、SE 10.77; σ_m^2 真值 5、SE 8.89; σ_{um} 真值 -2、SE 7.44; σ_c^2 真值 3、SE 5.43; σ_l^2 真值 2、SE 4.17; σ_e^2 真值 20、SE 6.76。估计相关: $\text{corr}(\hat{\sigma}_c^2, \hat{\sigma}_l^2) = -0.287$, $\text{corr}(\hat{\sigma}_m^2, \hat{\sigma}_{um}) = -0.677$; $\sigma_c^2 + \sigma_l^2$ 的 SE 为 5.82。结论: 甲中母体永久环境与窝效应共线; 丙中母亲无自身记录时母体遗传与交叉项的核相同 ($K_{dm} \equiv K_m$); 乙是唯一满秩的设计, 但依然有很大的标准误 (SE 大于参数本身), 说明 160 条记录不足以精确分解——母体模型需要大样本与良好设计。把母亲设为固定效应则消去母体遗传、交叉与母体永久环境三个核。

【题目】

22.18 $n = 5$, $\sigma_T^2 = 1.200$, 单条记录遗传方差 $= \sigma_D^2 + (n - 1)\sigma_S^2 + \dots = 8.000$, 无亲缘同伴表型协方差 0.300, $r_{DS} = -0.924$ 。选留比例 0.2, $i = 1.3998$:

r	$\text{Cov}(T, P)$	σ_P	R 个体	R 个体 MC	R 整群	R 整群 MC
0	-0.400	5.477	-0.1022	-0.1008	0.1345	0.1359
0.25	0.000	5.320	0.0000	0.0003	0.2640	0.2644
0.5	0.400	5.158	0.1086	0.1085	0.3888	0.3886

20 万个群的蒙特卡罗重现了解析协方差与截断选择的实际响应。接触网络 (六栏位线性链, 行为接受者): 接受端遗传值 $g = d + Ws$ 与输出端总贡献 $T = d + q \circ s$ ($q = W'1$) 满足 $\sum g = \sum T = 9.450$, 但按 g 排序第一为位置 1, 按 T 为位置 2——“受益的最好”与“贡献的最大”不是同一头动物。反馈模型 ($\rho = 0.3$, 行和为 1 的网络) 平衡表现 $1/(1 - \rho) = 1.4286$ 。结论: 直接—社会遗传强烈负相关 (-0.924) 时, 个体选择在无亲缘群中使群体表现下降; 选择应面向总育种值, 或在亲缘组群/整群层面进行。

【题目】

22.19 交配类型系数 $(1, q, q_m, h, h_m)$ 与期望均值: AA (1, 1, 1, 0, 0) 236; BB (1, 0, 0, 0, 0) 230; AB (1, 0.5, 0, 1, 0) 251; BA (1, 0.5, 1, 1, 0) 245; A×F1 (1, 0.75, 0.5, 0.5, 1) 252.5; B×F1 (1, 0.25, 0.5, 0.5, 1) 246.5; F1×F1 (1, 0.5, 0.5, 0.5, 1) 249.5; F1×A (1, 0.75, 1, 0.5, 0) 240.5。

设计	类型数	秩	可估参数的 SE
D1 纯种 + 一种 F1	3	3/5	秩亏 2
D2 + 反交	4	4/5	η_m 不可估
D3 + F1 母本回交	6	5/5	μ 3.03, δ_a 5.16, δ_m 4.08, η 3.16, η_m 2.74
D4 全部 8 类	8	5/5	3.03, 5.16, 3.87, 3.16, 2.33

D4 的一次模拟 OLS: $\hat{\mu} = 230.83$ (真值 230)、 $\hat{\delta}_a = 17.61$ (12)、 $\hat{\delta}_m = -9.06$ (-6)、 $\hat{\eta} = 14.89$ (15)、 $\hat{\eta}_m = 9.50$ (9), 均在 1.1 个 SE 以内。若每类交配各在不同场并拟合场效应, $\text{rank}[\text{场, 遗传}] - \text{rank}(\text{场}) = 0$, 遗传参数完全不可估。纯种—杂种遗传相关 0.6、纯种 EBV 可靠度 0.8、杂种性状 $h^2 = 0.25$ 时, 可靠度:

杂种后代数	只用后代	指数合并
0	0.0000	0.2880
5	0.2500	0.4246
10	0.4000	0.5172
20	0.5714	0.6347
50	0.7692	0.7889
200	0.9302	0.9321

纯种信息单独的可靠度上限为 $r_{PC}^2 R_P = 0.36 \times 0.8 = 0.288$; 后代数少时合并增益大 (5 个后代由 0.25 升至 0.42), 后代数很多时纯种信息的增益变得微乎其微。 [题目]

22.20 20 次重复, 每次 690 只动物, 外来公羊遗传均值 3, 6, 9, 12:

世代	真实趋势	无组估计	遗传组估计
1	0.767	-0.388	0.951
2	3.621	1.195	3.882
3	6.545	2.558	6.798
4	9.627	3.982	10.012

外来公羊 EBV-TBV 平均: 无组 -6.503, 遗传组 0.294; 分年份无组为 -3.42、-5.23、-7.26、-10.09, 遗传组为 0.48、0.03、0.33、0.35。末代 EBV 与真值的相关: 无组 0.5653, 遗传组 0.5945。组效应估计 3.85 ± 3.57 、 5.68 ± 3.92 、 8.94 ± 4.74 、 12.62 ± 5.50 (真值 3, 6, 9, 12)。结论: 无组模型把外来公羊当作基础群平均, 趋势只恢复约 40%

(第4代 3.98 对 9.63); 遗传组模型无偏, 但各组效应的估计依赖其后代数, 标准误差较大。

【题目】

22.21

$$A = \begin{bmatrix} 1 & 0 & 0.5 & 0.75 & 0.625 \\ 0 & 1 & 0.5 & 0.25 & 0.375 \\ 0.5 & 0.5 & 1 & 0.75 & 0.875 \\ 0.75 & 0.25 & 0.75 & 1.25 & 1 \\ 0.625 & 0.375 & 0.875 & 1 & 1.375 \end{bmatrix}$$

$F = (0, 0, 0, 0.25, 0.375)$ 。其中 $F_4 = \frac{1}{2}a_{13} = 0.25$, $F_5 = \frac{1}{2}a_{34} = \frac{1}{2} \times 0.75 = 0.375$ 。Henderson 规则的 b_i : 动物 1、2 为 1; 动物 3 (双亲无近交) $b = 2$; 动物 4 (父 1、母 3, $F_1 = F_3 = 0$) $b = 2$; 动物 5 (父 3、母 4, $F_3 = 0, F_4 = 0.25$) $b = 1/(0.5 - 0.0625) = 2.2857$ 。叠加得

$$A^{-1} = \begin{bmatrix} 2 & 0.5 & -0.5 & -1 & 0 \\ 0.5 & 1.5 & -1 & 0 & 0 \\ -0.5 & -1 & 3.0714 & -0.4286 & -1.1429 \\ -1 & 0 & -0.4286 & 2.5714 & -1.1429 \\ 0 & 0 & -1.1429 & -1.1429 & 2.2857 \end{bmatrix},$$

与 A 的直接求逆一致。

【题目】

22.22 误差方差 = $2.5 + 9 \times 1.2 + 2 \times 3 \times (-0.4) = 2.5 + 10.8 - 2.4 = 10.9$; 遗传方差 = $12 + 9 \times 5 + 2 \times 3 \times (-2) = 12 + 45 - 12 = 45$; 可靠度 = $1 - 10.9/45 = 0.758$ 。目标中的权重 3 要同时进入遗传方差与预测误差方差 (平方和交叉项), 只调整因子会错误地高估可靠度。

【题目】

五、推导与证明题

22.23 证明。见推导 22.1。以 σ_u^2 为单位, $\text{Var}(a_i) = 1 + F_i$; $a_i = \frac{1}{2}(a_s + a_d) + \phi_i$ 且 ϕ_i 与 a_s, a_d 不相关, 故

$$\text{Var}(\phi_i) = (1 + F_i) - \frac{1}{4}[(1 + F_s) + (1 + F_d) + 2a_{sd}] = 1 + F_i - \frac{1}{2} - \frac{1}{4}(F_s + F_d) - \frac{1}{2}a_{sd}.$$

由 $a_{sd} = 2F_i$: $= \frac{1}{2} - \frac{1}{4}(F_s + F_d)$ 。矩阵形式 $a = Pa + \phi$ 给出 $a = (I - P)^{-1}\phi$, $\text{Var}(a) = A = (I - P)^{-1}D(I - P)^{-'}$, 取逆即 $A^{-1} = (I - P)'D^{-1}(I - P)$ 。■

【题目】

22.24 证明。见推导 22.2。动物模型对公畜 k (无记录、无亲缘) 的信息仅来自其后代 j , 它们与公畜的关系为 $\frac{1}{2}$; 每个后代 $u_j = \frac{1}{2}u_k + \phi_j$, 所以数据对 u_k 的信息可由 $\bar{y}_k$ 概括: $y_j = \mu + \frac{1}{2}u_k + w_j$, 即公畜模型中 $s_k = \frac{1}{2}u_k$ 。两个模型对同一数据给出同一似然, 故 $\hat{u}_k = 2\hat{s}_k$, $\text{PEV}_u = 4\text{PEV}_s$ (习题 22.16 中精确到 10^{-14})。■

【题目】

22.25 证明。每只母亲只有一窝时, 母体永久环境核 $K_c = WW'$ 中 $W_{ij} = 1$ 当记录 i 属于母亲 j ; 窝效应核 $K_l = LL'$ 中 $L_{ij} = 1$ 当记录 i 属于窝 j 。母亲与窝一一对应, 所以 $W = L$, $K_c = K_l$ 。观测协方差 $V = \dots + (\sigma_c^2 + \sigma_l^2)K_c + \dots$, 似然只依赖 $\sigma_c^2 + \sigma_l^2$, 对 (σ_c^2, σ_l^2) 的任意保持和不变的移动不改变似然, 信息矩阵奇异。增加同窝后代也不

能解除,因为它们只是沿同一协方差方向增加观察。需要同母异窝记录使 $W \neq L$ 。

■

[题目]

22.26 证明。 $T_i = D_i + (n-1)S_i$, $P_i = D_i + \sum_{k \neq i} S_k + c + e_{i0}$ 逐项: $\text{Cov}(D_i, D_i) = \sigma_D^2$; D_i 与 $n-1$ 个同伴的 S_k 的协方差各为 $r\sigma_{DS}$; $(n-1)S_i$ 与 D_i 的协方差为 $(n-1)\sigma_{DS}$; $(n-1)S_i$ 与 $\sum_{k \neq i} S_k$ 的协方差为 $(n-1)^2 r\sigma_S^2$ 。相加并整理:

$$\begin{aligned}\text{Cov}(T_i, P_i) &= \sigma_D^2 + (n-1)\sigma_{DS} + (n-1)r\sigma_{DS} + (n-1)^2 r\sigma_S^2 \\ &= \sigma_D^2 + (n-1)(1+r)\sigma_{DS} + (n-1)^2 r\sigma_S^2.\end{aligned}$$

对 r 是线性增函数 (当 $(n-1)\sigma_{DS} + (n-1)^2 r\sigma_S^2 > 0$ 时): 习题 22.18 中系数 $= 4 \times (-1.6) + 16 \times 0.5 = 1.6 > 0$, 故随 r 由 -0.4 ($r=0$) 增加到 0 ($r=0.25$) 和 0.4 ($r=0.5$)。■

[题目]

六、综合分析与研究设计题

22.27 方案 (1) 记录: 羔羊断奶重; 母亲自身断奶重 (有自身记录才能分开 σ_{um} 与 σ_m^2 , 习题 22.17 设计丙缺此项则 $K_{dm} \equiv K_m$); 系谱至少三代。(2) 设计: 每只母羊至少 2 窝 (同母异窝, 使 $K_c \neq K_l$), 每窝 2—3 羔; 母羊来自多个家系 (祖母/母亲相关), 公羊数足够, 避免母体与直接效应完全由同一家系决定。习题 22.17 设计乙: 160 条记录下 SE 仍大于参数本身, 因此实际样本应在千条以上, 并鼓励胚胎移植 (交叉寄养) 形成亲生母亲与养母分离。(3) 模型选择: 先拟合仅直接效应的动物模型; 逐步加入母体永久环境、母体遗传、直接—母体协方差、窝效应, 用似然比与信息准则 (注意零方差与非零协方差的边界检验), 并检验近似信息矩阵的相关 ($\text{corr}(\hat{\sigma}_m^2, \hat{\sigma}_{um}) = -0.68$ 提示强共线)。(4) 报告: 参数的区间而非点估计; 选择的模型对育种值排序的影响 (相关与前 10% 重叠度)。(5) 警告: 协方差必须落在合法范围内, 估计到边界要说明。

[题目]

22.28 设计: (1) 群组成: 三种群结构并行——全同胞组、半同胞组与随机混群, 每种至少 100 个群, 群大小固定 (如 $n=5$); (2) 估计: 用社会效应模型 $y = \mu + D_i + \sum S_k + c_g + e$, 需要不同亲缘组成才能区分 σ_S^2 、 σ_{DS} (若所有群都是随机组成, σ_S^2 的估计依赖于群间方差, 精度很低); (3) 精度: 习题 22.18 显示, 当 $r=0$ 时个体选择的 $\text{Cov}(T, P) = -0.4$, 需要的样本量由这个信号大小决定; (4) 育种方案: 若 σ_{DS} 强负, 按总育种值 $T = D + (n-1)S$ 选择 (5 个同伴时 $\sigma_T^2 = 1.2$, 比 $\sigma_D^2 = 6$ 小得多——总遗传变异小, 进展慢); 在亲缘组群 (全同胞) 饲养并整群选择可以使 r 提高、响应转正 ($r=0.5$ 时个体 $+0.109$, 整群 $+0.389$); (5) 风险: 社会效应与群大小、栏密度的互作; σ_S^2 估计误差大。

[题目]

22.29 诊断：(1) 核对未知亲本：检查是否把外来公牛的未知亲本当作基础群；(2) 比较有、无遗传组模型下的遗传趋势与外来公牛 EBV (习题 22.20：无组使外来公牛 EBV 偏低 6.5，趋势低估约 60%)；(3) 用外来公牛的后代与同场同年本地公牛后代的表现差，直接检验遗传水平差异；(4) 检查年份/场的固定效应是否吸收了外来公牛的遗传差异——外来公牛的后代集中在某些年份时，遗传趋势与年效应混杂。**处理：**(1) 按引入年份或来源国设遗传组 (Quaas-Pollak 变换)，也可用元创始者 (第 12、28 章)；(2) 对每个组的后代数核实，组效应的标准误 (习题 22.20 中组效应 SD 3.6—5.5) 较大，若后代很少应合并组；(3) 若有基因型，用基因组关系把外来公牛与本群连接，减少对组的依赖；(4) 建立常规监测：每年报告遗传趋势的稳健性 (有无组、有无基因组) 并与独立的实际表现对照。

【题目】

方差组分、限制似然与贝叶斯推断

23.1 本章导学

学习目标

- 1. 理解方差参数如何决定 BLUP 的收缩强度与精度，能由方差分析表给出平衡设计的矩估计。
- 2. 掌握 ML 与 REML 的差异：固定效应带来的自由度代价、REML 等价于误差对比的似然。
- 3. 能写出 REML 的得分、期望信息与平均信息（AI）矩阵，理解 EM、Fisher 得分与 AI 算法的收敛行为。
- 4. 理解方差为零的边界问题：重新优化、似然比检验的混合零分布与估计到边界的比例。
- 5. 会判断方差结构的可识别性，并用 delta 法、轮廓似然与参数自助法给出遗传力的区间。
- 6. 理解贝叶斯方差推断：先验的影响、Gibbs 采样与诊断，以及方差不确定性如何进入育种值与选种概率。

重点与难点

重点： $\hat{\sigma}_{ML}^2 = \text{RSS}/N$ 与 $\hat{\sigma}_{REML}^2 = \text{RSS}/(N - p)$ ；REML 得分 $s_k = -\frac{1}{2}[\text{tr}(PV_k) - y'PV_kPy]$ ；AI 矩阵 $\frac{1}{2}y'PV_kPV_lPy$ ；边界 LRT 的 $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ ；全方差公式。

难点：识别性与信息矩阵奇异的关系；边界处似然比统计量的分布；先验对小样本方差后验的决定性影响；插值估计的 PEV 低估。

本章承接第 21 章（BLUP 假设方差已知）与第 22 章（复杂协方差结构），是第 24 章多性状（协方差矩阵估计）、第 25 章基因组遗传力（SNP 遗传力的 REML 估计）与第 34 章可重复评定的共同基础。

23.2 知识结构图




图 23.1 第 23 章知识结构图

左侧是频率学派的估计与检验，右侧是区间、贝叶斯推断与决策。

23.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
平衡单向方差分析	$\hat{\sigma}_a^2 = (\text{MSB} - \text{MSW})/n$	无偏，可能为负
ML 的偏倚	$E(\hat{\sigma}_{ML}^2) = \frac{N-p}{N}\sigma^2$	线性回归
REML 对数似然	$\ell = -\frac{1}{2}[\log V + \log X'V^{-1}X + y'Py]$	P 为投影矩阵
得分	$s_k = -\frac{1}{2}[\text{tr}(PV_k) - y'PV_kPy]$	$V_k = \partial V / \partial \sigma_k^2$
期望信息	$J_{kl} = \frac{1}{2} \text{tr}(PV_k PV_l)$	正确模型
平均信息	$\text{AI}_{kl} = \frac{1}{2} y' PV_k PV_l Py$	$E(\text{AI}) = J$
EM 更新	$\sigma_k^2 \leftarrow [\sigma_k^4 y' PV_k Py + \sigma_k^2 q_k - \sigma_k^4 \text{tr}(PV_k)]/q_k$	单调但慢
边界 LRT	$\text{LRT} \sim \frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$	一个参数在边界
遗传力 delta SE	$\sqrt{g'J^{-1}g}$	大样本
轮廓似然	$\ell_p(t) = \max_{\sigma^2} \ell$	对 h^2 的重新参数化

概念	公式或定义	成立条件与提示
尺度化逆卡方	$\sigma^2 e \sim (\nu S^2 + e'e)/\chi_{N+\nu}^2$	共轭先验
全方差公式	$\text{Var}(s y) = E[\text{PEV}(\sigma)] + \text{Var}[\hat{s}(\sigma)]$	积分方差不确定性
有效样本量	$\text{ESS} = n/(1 + 2 \sum \rho_k)$	马尔可夫链诊断

23.4 补充内容与公式推导

推导 23.1 REML 是误差对比的最大似然

取 K 为 $N \times (N-p)$ 列满秩矩阵且 $K'X = 0$ (误差对比), 则 $w = K'y \sim N(0, K'VK)$, 其分布不含 β_0 . w 的对数似然为 $-\frac{1}{2}[\log |K'VK| + y'K(K'VK)^{-1}K'y]$. 利用 $K(K'VK)^{-1}K' = P$ 与 $\log |K'VK| = \log |V| + \log |X'V^{-1}X| - \log |X'X| + \log |K'K|$ (后两项与参数无关), 即得 REML 对数似然. 对线性回归 $V = \sigma^2 I$, $P = M/\sigma^2$ (M 为残差投影), REML 估计为 $\text{RSS}/(N-p)$, ML 为 RSS/N . 习题 23.15 ($N = 20$, $\sigma^2 = 4$): $p = 1, 3, 6, 10$ 时 ML 均值为 3.797, 3.409, 2.803, 1.993, 与理论 $(N-p)\sigma^2/N = 3.8, 3.4, 2.8, 2.0$ 吻合, REML 均值 3.997, 4.010, 4.004, 3.985.

推导 23.2 得分、期望信息与平均信息

记 $V = \sum_k \sigma_k^2 V_k$. 利用 $\partial V^{-1}/\partial \sigma_k^2 = -V^{-1}V_kV^{-1}$ 与 $\partial P/\partial \sigma_k^2 = -PV_kP$, 对 ℓ 求偏导得

$$s_k = -\frac{1}{2}[\text{tr}(PV_k) - y'PV_kPy].$$

二阶导 $-\partial^2 \ell / \partial \sigma_k^2 \partial \sigma_l^2 = -\frac{1}{2} \text{tr}(PV_kPV_l) + y'PV_kPV_lPy$. 取期望, 用 $E(y'Ay) = \text{tr}(AV)$ ($PX = 0$) 与 $PVP = P$: $E[y'PV_kPV_lPy] = \text{tr}(PV_kPV_lPV) = \text{tr}(PV_kPV_l)$, 所以期望信息 $\mathcal{I}_{kl} = \frac{1}{2} \text{tr}(PV_kPV_l)$; 而平均信息取观测信息与期望信息的平均, 得 $\text{AI}_{kl} = \frac{1}{2} y'PV_kPV_lPy$, $E(\text{AI}_{kl}) = \mathcal{I}_{kl}$. AI 不需要计算迹, 只需一个二次型, 因此适合大规模动物模型. 习题 23.16 (600 条记录、240 头动物) 中, AI 8 次迭代、Fisher 得分 11 次迭代收敛, EM 在 200 次迭代后得分仍为 5.4×10^{-4} .

推导 23.3 方差为零的似然比检验

平衡单向模型中检验 $H_0: \sigma_a^2 = 0$. 设 $\hat{\sigma}_a^2$ 为无约束估计 (可能为负). $\hat{\sigma}_a^2 \leq 0$ 的概率在 H_0 下约为 $\frac{1}{2}$ (大样本时 $\text{MSB} - \text{MSW}$ 近似对称); 此时约束估计等于 0, $\text{LRT} = 0$.

$\hat{\sigma}_a^2 > 0$ 时 LRT 近似服从 χ_1^2 (受条件概率调整), 因此

$$P(\text{LRT} > c) \approx \frac{1}{2}P(\chi_1^2 > c), \quad c > 0.$$

5% 水平的临界值满足 $\frac{1}{2}P(\chi_1^2 > c) = 0.05$, 即 $c = \chi_{1;0.90}^2 = 2.706$, 而不是 3.841。用 3.841 的实际水平为 2.5% (保守)。习题 23.17 ($n = 5$) 中 $g = 5, 10, 40$ 时 $P(\hat{\sigma}_a^2 = 0)$ 为 0.567, 0.553, 0.513; 以 3.841 为临界的实际水平 0.018, 0.018, 0.020; 以 2.706 为临界的水平 0.034, 0.039, 0.045, 随组数增加趋近名义 5%。精确 F 检验在 $g = 10$ 的水平为 0.0508。

推导 23.4 遗传力的轮廓似然与方差不确定性的全方差分解

平衡单向模型中令 $t = \sigma_a^2 / (\sigma_a^2 + \sigma_e^2)$, $u = \sigma_a^2 + \sigma_e^2$, 则 $\sigma_e^2 = (1-t)u$, $\theta = \sigma_e^2 + n\sigma_a^2 = (1-t+nt)u$ 。记 $c_1 = 1-t+nt$, $c_2 = 1-t$, REML 对数似然

$$\ell(t, u) = -\frac{1}{2} \left[(g-1) \log(c_1 u) + \frac{\text{SSB}}{c_1 u} + g(n-1) \log(c_2 u) + \frac{\text{SSW}}{c_2 u} \right].$$

对 u 求导令零: $(gn-1)/u = (\text{SSB}/c_1 + \text{SSW}/c_2)/u^2$, 故 $\hat{u}(t) = (\text{SSB}/c_1 + \text{SSW}/c_2)/(gn-1)$, 轮廓似然 $\ell_p(t) = \ell(t, \hat{u}(t))$ 为闭式。区间 $\{t : 2[\ell_{\max} - \ell_p(t)] \leq \chi_{1;0.95}^2\}$ 自动保持在 $[0, 1]$ 内且不依赖于参数化, 这是它优于 delta 法的地方。

方差不确定性进入预测: 后验 $p(\sigma | y)$ 下, $s | y, \sigma \sim N(\hat{s}(\sigma), \text{PEV}(\sigma))$, 由全方差公式

$$\text{Var}(s | y) = E_\sigma[\text{PEV}(\sigma)] + \text{Var}_\sigma[\hat{s}(\sigma)] \geq \text{PEV}(\hat{\sigma}),$$

右端第二项是方差参数不确定性造成的附加方差。习题 23.20 (24 头公畜, 190 条记录) 中公畜 4 的插值 PEV 为 0.324, 后验总方差 0.538 (σ^2 平坦先验)、0.471 (信息先验), 倍数 1.66 与 1.45。

拓展阅读 REML、平均信息与方差先验

REML 由 Patterson 与 Thompson (1971) 提出, Harville (1977) 总结了其理论与算法; Gilmour、Thompson 与 Cullis (1995) 的平均信息 REML 成为 ASReml、DMU 与 BLUPF90 等软件的主要算法之一。方差为零的边界检验可追溯到 Self 与 Liang (1987) 的非标准条件下 LRT 的渐近分布。贝叶斯方差推断中先验的选择对少数分层模型影响极大: Gelman (2006) 建议对组间标准差使用平坦或半柯西先验, 而不是 $\text{IG}(\epsilon, \epsilon)$ 或 $1/\sigma^2$ 。习题 23.19 (24 头公畜) 中同一资料下, $\text{IG}(0.001, 0.001)$ 先验得到 h^2 的后验均值为 0.141, σ^2 平坦先验为 0.341, 信息先验为 0.349, 而 $1/\sigma^2$ 先验的

后验在零处不正常，链被吸收到 $\sigma_s^2 \approx 0$ 。

易错辨析

- **ML 的偏倚来自固定效应**：含 p 个固定效应时 ML 低估方差，REML 通过误差对比消去 β ；但在平衡单向模型中残差方差的 ML 与 REML 估计相同，差别在组间方差。
- **估计为负不是“错误”**：方差分析估计量无偏，负值只是抽样噪声；强行取零引入偏倚，应报告 REML 与边界信息。
- **边界检验不能照搬 χ_1^2** ：零方差检验的零分布含点质量， χ_1^2 临界值使检验保守。
- **IG(ϵ, ϵ) 不是“无信息”**：当组数很少时它强烈偏向零； $1/\sigma^2$ 先验使 σ_s^2 的后验不正常。
- **插值 PEV 低估不确定性**：用估计的方差得到的名义 PEV 没有计入方差估计误差。
- **优化器收敛不等于可识别**：信息矩阵奇异时，不同参数组合给出同一似然。

23.5 习题

一、单项选择题

23.1 ★ [单选] 线性回归有 $N = 25$ 个观测、 $p = 5$ 个固定效应参数，残差方差的 ML 估计的期望为真值的

- (A) 1 倍 (B) 0.96 倍 (C) 0.8 倍 (D) 0.2 倍

[答案]

23.2 ★ [单选] REML 估计等价于

- (A) 对全部数据的最大似然
 (B) 对误差对比 $K'y$ ($K'X = 0$) 的最大似然
 (C) 方差分析的矩估计 (D) 对随机效应的最小二乘

[答案]

23.3 ★★ [单选] 检验一个方差组分为零时，大样本下似然比统计量近似服从

- (A) χ_1^2 (B) $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ (C) χ_2^2 (D) 标准正态

[答案]

23.4 ★★ [单选] 平均信息 (AI) 算法的主要计算优势是

- (A) 无需任何矩阵运算
 (B) 只需二次型 $y'PV_kPV_lPy$, 不需要迹 $\text{tr}(PV_kPV_l)$
 (C) 保证收敛到全局最优 (D) 只适用于平衡资料

[答案]

23.5 ★★ [单选] 组数很少的分层模型中, 对组间方差使用 $1/\sigma^2$ 先验的主要风险是

- (A) 后验方差过小
 (B) 后验可能不正常 (质量堆积在 0 附近)
 (C) 吉布斯链不可构造 (D) 无风险

[答案]

23.6 ★★★ [单选] 把方差参数的后验不确定性积分后, 某公畜育种值的后验总方差与插值 REML 估计的 PEV 相比

- (A) 更小 (B) 更大或相等 (C) 恒等 (D) 无法比较

[答案]

二、判断与改错题

23.7 ★ [判断] 含固定效应的模型中, 残差方差的 ML 估计是无偏的。

[答案]

23.8 ★ [判断] 平衡单向随机模型中, 只要估计值为正, REML 的组间方差估计就等于方差分析的矩估计。

[答案]

23.9 ★★ [判断] 检验 $\sigma_a^2 = 0$ 时, 用 χ_1^2 的 5% 临界值 (3.841) 会使检验偏保守。

[答案]

23.10 ★★ [判断] EM 算法每次迭代都使似然单调不减, 因此收敛很快。

[答案]

三、填空题

23.11 ★ [填空] $N = 30$ 、 $p = 6$ 的回归, ML 的方差估计期望为真值的 _____ 倍; REML 的分母为 _____。

[答案]

23.12 ★ [填空] 平衡单向模型 $g = 8$ 、 $n = 5$, $MSB = 26$ 、 $MSW = 6$, REML 的 $\hat{\sigma}_a^2 =$ _____, 组内相关 = _____。

[答案]

23.13 ★★ (填空) 零方差检验的 5% 显著水平对应的正确临界值为 _____ (保留三位小数); 若误用 3.841, 实际水平约为 _____。 [答案]

23.14 ★★ (填空) 残差方差先验为 $\chi^{-2}(\nu = 4, S^2 = 2)$, $N = 26$ 条记录、残差平方和 $e'e = 100$, 则其条件后验为 $(\cdot)/\chi^2_{[\cdot].blank}$, 分子参数 $\nu S^2 + e'e =$ _____, 后验尺度 $=$ _____。 [答案]

四、计算题

23.15 ★★ (计算) **ML 与 REML**。回归模型 ($N = 20$, $p = 1, 3, 6, 10$) 与平衡单向模型 ($g = 5, 10, 40$, $n = 4$, $\sigma_a^2 = 2$, $\sigma_e^2 = 6$): 比较 ML 与 REML 的偏倚、均方误差、 h^2 偏倚与估计到边界的比例, 并用数值优化核验闭式解。 [程序] `ch23/ex23_15_ml_vs_reml.py` [答案]

23.16 ★★★ (计算) **动物模型 REML 算法**。240 头动物、600 条记录 (含永久环境, 三个方差组分)。比较 AI、Fisher 得分与 EM 的收敛, 核验解析得分与数值梯度, 并比较期望信息、AI 与数值观测信息给出的标准误和 h^2 的 delta 标准误。 [程序] `ch23/ex23_16_ai_reml.py` [答案]

23.17 ★★★ (计算) **方差为零的 LRT**。平衡单向模型 $n = 5$, $g = 5, 10, 40$, 在 H_0 下模拟 6000 次, 求 $P(\hat{\sigma}_a^2 = 0)$ 、用 χ^2_1 与混合分布临界值的实际水平, 及 $h^2 = 0.1, 0.2, 0.3$ 下的功效。 [程序] `ch23/ex23_17_boundary_lrt.py` [答案]

23.18 ★★★ (计算) **遗传力的区间估计**。公畜模型 ($h^2 = 0.3$) $(g, n) = (20, 5), (50, 8), (150, 8)$, 比较 delta 法、轮廓似然与参数自助法区间的覆盖率、宽度与下端为 0 的频率。 [程序] `ch23/ex23_18_h2_intervals.py` [答案]

23.19 ★★★ (计算) **贝叶斯方差推断**。24 头公畜、190 条记录、3 个场。比较五种方差先验下 σ_s^2 与 h^2 的后验, 报告 Gibbs 链的 ESS 与 $\hat{R}$, 并用二维格点积分验证。 [程序] `ch23/ex23_19_bayes_variance.py` [答案]

23.20 ★★★ (计算) **方差不确定性与选种决策**。利用同一资料, 比较插值 REML 与后验积分的预测均值、总方差、候选公畜优于另一头的概率与前 3 名集合。 [程序] `ch23/ex23_20_variance_uncertainty_decision.py` [答案]

23.21 ★ [计算] 平衡单向模型: 5 个组、每组 4 条记录, 组间平方和 84、组内平方和 90。求 ANOVA/REML 与 ML 的 $\hat{\sigma}_a^2$ 、 $\hat{\sigma}_e^2$ 与组内相关。 [答案]

23.22 ★★ [计算] 4 个组、每组 3 条记录, 组间平方和 6、组内平方和 48。求无约束估计, 说明边界情形, 并求 $\sigma_a^2 = 0$ 约束下的 REML 残差方差估计。 [答案]

五、推导与证明题

23.23 ★★ [证明] 证明线性回归中 $E(\text{RSS}) = (N - p)\sigma^2$, 并由此说明 ML 估计的偏倚为 $-p\sigma^2/N$ 。 [答案]

23.24 ★★★ [证明] 证明 REML 得分的期望为零: $E[y'PV_kPy] = \text{tr}(PV_k)$ 。 [答案]

23.25 ★★★ [证明] 证明 $E[y'PV_kPV_lPy] = \text{tr}(PV_kPV_l)$, 即 AI 的期望等于期望信息。 [答案]

23.26 ★★★ [证明] 在平衡单向模型中, 对固定的 t 推出 $\hat{u}(t) = (\text{SSB}/c_1 + \text{SSW}/c_2)/(gn-1)$, 并写出轮廓似然。 [答案]

六、综合分析与研究设计题

23.27 ★★ [综合] 为某奶牛场多性状育种评估设计一套可审计的方差分析流程: 数据检查、模型设定、算法选择、收敛与识别诊断、报告。 [答案]

23.28 ★★★ [综合] 某品种协会只有 30 头公畜、每头约 4 个后代, 需要报告遗传力及其不确定性。设计分析方案并说明先验的选择与敏感性分析。 [答案]

23.29 ★★★ [综合] 母体模型的 REML 估计在优化器返回“收敛”后, 母体永久环境方差与窝效应方差给出两个大小相近的正值, 但似然曲面极平。设计诊断并给出报告方案。 [答案]

23.6 参考答案与解析

一、单项选择题

23.1 C。 $E(\hat{\sigma}_{ML}^2) = (N - p)\sigma^2/N = 20/25 \sigma^2 = 0.8\sigma^2$ 。5 个固定效应参数消耗了 5 个自由度, ML 把拟合时用掉的信息当作残差来源, 所以低估。 [题目]

23.2 B. REML 是误差对比 $K'y$ 的似然, 因为该对比的分布不含固定效应, 所以自然地考虑了固定效应所消耗的自由度。 [题目]

23.3 B. 零方差落在参数空间边界, LRT 统计量约一半概率为 0, 另一半近似 χ_1^2 。习题 23.17: $g = 40$ 时 $P(\hat{\sigma}_a^2 = 0) = 0.513$ 。 [题目]

23.4 B. AI 把观测信息与期望信息平均后只需一个二次型, 不需要计算 $\text{tr}(PV_k PV_l)$ (该迹需要 P 的稠密元素或随机迹估计, 大模型下代价极高)。它仍可能收敛到局部解。 [题目]

23.5 B. σ_s^2 的 $1/\sigma^2$ 先验在零附近发散 ($\int_0 \sigma^{-2} d\sigma^2 = \infty$), 而组数少时似然在零处并不趋于零, 使后验不正常。习题 23.19 中该先验使 σ_s^2 的后验均值只有 0.037, $P(h^2 < 0.05) = 0.95$ 。 [题目]

23.6 B. 全方差公式 $\text{Var}(s | y) = E[\text{PEV}(\sigma)] + \text{Var}[\hat{s}(\sigma)]$, 右端第二项非负。习题 23.20: 倍数 1.45—1.66。 [题目]

二、判断与改错题

23.7 错误。 ML 方差估计的期望为 $(N - p)\sigma^2/N$, 向下偏倚; REML (除以 $N - p$) 无偏。 [题目]

23.8 正确。 平衡单向模型中 $\hat{\sigma}_a^2 = (\text{MSB} - \text{MSW})/n$, 估计为负时 REML 在边界取 0。习题 23.15 用直接数值优化核验了这一点。 [题目]

23.9 正确。 实际水平约为名义水平的一半: 习题 23.17 中 $g = 40$ 的实际水平为 0.0195 (名义 5%)。 [题目]

23.10 错误。 EM 的似然单调不减, 但收敛是线性且常极慢, 在边界附近尤其如此。习题 23.16 中 AI 8 次、EM 200 次后得分仍为 5.4×10^{-4} 。 [题目]

三、填空题

23.11 $(N - p)/N = 24/30 = 0.8$ 倍; REML 分母为 $N - p = 24$ 。 [题目]

23.12 $\hat{\sigma}_a^2 = (26 - 6)/5 = 4$; 组内相关 $= 4/(4 + 6) = 0.4$ 。 [题目]

23.13 $\chi_{1,0.90}^2 = 2.706$; 误用 3.841 的实际水平约 2.5% (习题 23.17 实测 0.018—0.020)。 [题目]

23.14 后验为 $(\nu S^2 + e'e)/\chi^2_{N+\nu}$, 自由度 **30**, $\nu S^2 + e'e = 4 \times 2 + 100 = \mathbf{108}$, 后验尺度 $108/30 = \mathbf{3.6}$ 。 [题目]

四、计算题

23.15 A. 回归 ($N = 20, \sigma^2 = 4, \mathbf{20000}$ 次重复)

p	ML 均值	理论 $(N - p)\sigma^2/N$	REML 均值	ML 偏倚%
1	3.797	3.800	3.997	-5.1
3	3.409	3.400	4.010	-14.8
6	2.803	2.800	4.004	-29.9
10	1.993	2.000	3.985	-50.2

B. 平衡单向模型 ($\sigma_a^2 = 2, \sigma_e^2 = 6, n = 4, h^2$ 对应组内相关 0.25)

g	方法	$\hat{\sigma}_a^2$ 均值	偏倚	RMSE	$\hat{h}^2$ 均值	$\hat{\sigma}_a^2 = 0$ 占比
5	REML	2.161	0.161	2.388	0.235	0.217
5	ML	1.519	-0.481	1.911	0.184	0.291
10	REML	2.061	0.061	1.655	0.240	0.091
10	ML	1.723	-0.277	1.500	0.210	0.119
40	REML	1.996	-0.004	0.818	0.245	0.002
40	ML	1.908	-0.092	0.804	0.237	0.002

无截断的方差分析估计在所有 g 下无偏（在 5 个标准误内）；REML 的小正偏倚来自负值取零的截断；ML 低估，因为它把组间自由度 $g - 1$ 当作 g 。ML 的偏倚在 $g = 5$ 时 -24%， $g = 40$ 时 -4.6%，但 RMSE 略低于 REML（偏倚—方差权衡），不能据此认为 ML 更好。组数少时（ $g = 5$ ）有 22%—29% 的重复估计到边界。直接数值最大化似然（Nelder-Mead）与闭式解一致（相对误差小于 10^{-3} ）。 [题目]

23.16 真值 $\sigma_a^2 = 10, \sigma_{pe}^2 = 6, \sigma_e^2 = 16$, 600 条记录、240 头动物（含起点得分的数值核
验：解析 (1.18227, 2.20585, -1.65925) 与数值梯度一致)：

算法	迭代次数	$\hat{\sigma}_a^2$	$\hat{\sigma}_{pe}^2$	$\hat{\sigma}_e^2$	$ s _{\max}$
AI	8	4.1001	6.2849	15.1808	5.0×10^{-9}
Fisher 得分	11	4.1001	6.2849	15.1808	1.5×10^{-8}
EM	200	4.1022	6.2835	15.1809	5.4×10^{-4}

三者的 REML 对数似然均为 -1224.4087 。标准误: 期望信息逆 (2.047, 1.877, 1.077); AI 逆 (1.958, 1.827, 1.077); 数值观测信息 (1.881, 1.783, 1.077) (三者相互接近, AI 介于观测与期望之间)。 $h^2 = \hat{\sigma}_a^2 / \sum \hat{\sigma}^2 = 0.1604$, delta 法 SE = 0.0753, 真值 0.3125, 估计与真值相差约 2 个 SE。对数似然与终值之差: AI 在 1、2、3、5 次迭代为 1.25, 1.1×10^{-2} , 1.0×10^{-6} , 2.3×10^{-12} ; Fisher 得分为 4.5×10^{-3} , 1.6×10^{-4} , 6.0×10^{-6} , 8.4×10^{-9} ; EM 为 6.42, 5.40, 4.61, 3.35, 第 30 次 0.162, 第 100 次 8.0×10^{-4} 。解读: AI 与 Fisher 得分是二阶收敛, EM 的每步似然增量很小。 [题目]

23.17 ($n = 5$, $\sigma_e^2 = 8$, 6000 次重复; χ_1^2 的 5% 临界值 3.841, 混合分布 5% 临界值 2.706)

g	$P(\hat{\sigma}_a^2 = 0)$	实际水平 (3.841)	实际水平 (2.706)	LRT 95% 分位	LRT 90% 分位
5	0.567	0.0182	0.0338	2.125	1.259
10	0.553	0.0182	0.0387	2.317	1.344
40	0.513	0.0195	0.0445	2.559	1.554

功效 (混合临界值 / χ_1^2 临界值):

g	$h^2 = 0.1$	$h^2 = 0.2$	$h^2 = 0.3$
5	0.140/0.084	0.281/0.197	0.432/0.340
10	0.212/0.138	0.470/0.361	0.699/0.608
40	0.543/0.429	0.939/0.897	0.996/0.991

对照: $g = 10$ 时精确 F 检验的水平 0.0508, LRT 用混合临界值为 0.0417, 用 χ_1^2 为 0.0192。结论: 用 3.841 实际水平只有约 2%, 功效损失明显 ($g = 10$, $h^2 = 0.1$: 0.138 对 0.212); 有限样本时混合临界值也略保守 (0.034—0.045), 最精确的做法是平衡设计的 F 检验或参数自助法。 [题目]

23.18 (真 $h^2 = 0.30$, 600 次重复, 名义覆盖率 95%)

g	n	方法	覆盖率	平均宽度	下端为 0	$\hat{h}^2$ 倚倚
20	5	delta 法	0.988	0.835	0.923	+0.032
20	5	轮廓似然	0.962	0.875	0.835	+0.032
20	5	自助法	0.990	1.003	0.897	+0.032
50	8	delta 法	0.915	0.539	0.547	-0.011
50	8	轮廓似然	0.942	0.567	0.365	-0.011
50	8	自助法	0.913	0.539	0.467	-0.011

g	n	方法	覆盖率	平均宽度	下端为 0	$\hat{h}^2$ 偏倚
150	8	delta 法	0.947	0.340	0.032	-0.003
150	8	轮廓似然	0.940	0.341	0.020	-0.003
150	8	自助法	0.943	0.333	0.027	-0.003

20 头公畜时区间宽度约 0.84—1.0 (h^2 的取值范围是 0—1)，实际上没有信息；83%—92% 的区间下端被截断在 0。轮廓似然在中等样本 ($g = 50$) 覆盖率最接近名义 (0.942)，而 delta 法与自助法略低 (0.915、0.913)。大样本 ($g = 150$) 三种方法一致。

【题目】

23.19 真值 $\sigma_s^2 = 1.0$ 、 $\sigma_w^2 = 11.0$ ，真 $h^2 = 0.333$ ；REML 估计 $\hat{\sigma}_s^2 = 0.525$ 、 $\hat{\sigma}_w^2 = 9.883$ 、 $\hat{h}^2 = 0.202$ 。

先验	σ_s^2 均值	σ_s^2 95% 区间	h^2 均值	h^2 95% 区间	ESS	$P(h^2 < 0.05)$
flat_sd	0.690	[0.004, 2.40]	0.248	[0.001, 0.80]	425	0.192
flat_var	0.967	[0.067, 2.89]	0.341	[0.025, 0.92]	767	0.059
jeffreys	0.037	[0.000, 0.52]	0.013	[0.000, 0.20]	35	0.952
ig_001	0.382	[0.001, 1.75]	0.141	[0.001, 0.61]	189	0.438
informative	0.953	[0.429, 1.92]	0.349	[0.159, 0.67]	1916	0.000

(先验依次为： σ 平坦、 σ^2 平坦、 $1/\sigma^2$ 、IG(0.001,0.001)、 $\nu = 8$ 的信息先验； σ_s^2 中位数依次为 0.514、0.797、0.000、0.184、0.876。) 格点积分核验：flat_sd 格点 σ_s^2 均值 0.674 (Gibbs 0.690)、 h^2 均值 0.243 (0.248)；flat_var 0.997 (0.967)、0.350 (0.341)；informative 0.950 (0.953)、0.348 (0.349)；ig_001 0.332 (0.382，质量堆积在格点下限以下略有差异)。各链 $\hat{R} < 1.04$ 。结论：同一资料下， h^2 的后验均值从 0.013 ($1/\sigma^2$) 到 0.349 (信息先验) 变化，24 头公畜只有 $4\sigma_s^2/\Sigma$ 的极弱信息，先验几乎决定了结果； $1/\sigma^2$ 先验使链被吸收到 0 附近 (ESS 仅 35)。

【题目】

23.20 REML： $\hat{\sigma}_s^2 = 0.525$ 、 $\hat{\sigma}_w^2 = 9.883$ 。排名前 3 的公畜为 4 ($n = 13$)、8 ($n = 8$)、20 ($n = 3$)。

项目	σ^2 平坦先验	信息先验
插值 $\hat{s}$ (公畜 4)	0.749	0.749
后验均值 (公畜 4)	0.909	0.986
插值 PEV (公畜 4)	0.324	0.324
后验总方差 (公畜 4)	0.538	0.471
总方差/PEV (公畜 4; 24 头平均; 最大)	1.662; 1.520; 2.058	1.454; 1.494; 1.754
$P(A > B)$ 插值/后验	0.598/0.548	0.598/0.555
$P(A > C)$ 插值/后验	0.615/0.602	0.615/0.609
前 3 名集合	{4,8,20}, 一致	{4,8,20}, 一致

后验的平均模长比插值估计大 1.33—1.42 倍 (后验的方差比更大, BLUP 的收缩更弱), 但排名几乎不变 (相关 0.996—0.998)。蒙特卡罗直接模拟 (4 万次) 与全方差公式一致: 方差误差小于 3%、 $P(A > B)$ 差小于 0.01。结论: 方差不确定性使总方差增加约 50%—66%; A 优于 B 的概率由插值的 0.60 下降到 0.55, 真实的选种把握低于名义值, 排名可保持不变而概率判断不同。 [题目]

23.21 ANOVA/REML: $MSW = 90/15 = 6$, $MSB = 84/4 = 21$, $\hat{\sigma}_a^2 = (21 - 6)/4 = 3.75$, $\hat{\sigma}_e^2 = 6$, 组内相关 $3.75/9.75 = 0.385$ 。ML: $\hat{\sigma}_a^2 = (84/5 - 6)/4 = 2.70$, $\hat{\sigma}_e^2 = 6$, 相关 $2.70/8.70 = 0.310$ 。ML 低了 28%, 因为组间自由度用 5 而非 4。 [题目]

23.22 $MSW = 48/8 = 6$, $MSB = 6/3 = 2$, $\hat{\sigma}_a^2 = (2 - 6)/3 = -1.33 < 0$ 。无约束估计为负, 参数空间要求 $\sigma_a^2 \geq 0$, 故取边界 $\hat{\sigma}_a^2 = 0$, 此时模型退化为 $N = 12$ 条独立记录, REML 残差方差为 $(48 + 6)/(12 - 1) = 4.909$ (减去一个均值自由度)。此时报告 “ $\hat{\sigma}_a^2 = 0$ ” 并不意味着没有遗传变异, 只表示资料没有给出正的组间变异证据。 [题目]

五、推导与证明题

23.23 证明。 $RSS = y'My = e'Me$ (因 $MX = 0$), $M = I - X(X'X)^{-1}X'$ 是秩 $N - p$ 的对称幂等阵。 $E(e'Me) = \sigma^2 \text{tr}(M) = \sigma^2(N - p)$ 。因此 $E(RSS/N) = (N - p)\sigma^2/N$, 偏倚 $-p\sigma^2/N$ 。REML 除以 $N - p$ 得到无偏。 ■ [题目]

23.24 证明。 令 $y \sim (X\beta, V)$ 。 $PX = 0$, 故 $Py = P(y - X\beta)$, 而 $E[(y - X\beta)'A(y - X\beta)] = \text{tr}(AV)$ 。取 $A = PV_kP$:

$$E[y'PV_kPy] = \text{tr}(PV_kPV) = \text{tr}(V_kPVP) = \text{tr}(V_kP) = \text{tr}(PV_k),$$

其中用了 $PVP = P$ 与迹的循环性。因此 $E(s_k) = -\frac{1}{2}[\text{tr}(PV_k) - \text{tr}(PV_k)] = 0$ 。■

[题目]

23.25 证明。 同上, 取 $A = PV_kPV_lP$:

$$E[y'PV_kPV_lPy] = \text{tr}(PV_kPV_lPV) = \text{tr}(V_kPV_lPVP) = \text{tr}(V_kPV_lP) = \text{tr}(PV_kPV_l),$$

$$\text{故 } E(AI_{kl}) = \frac{1}{2} \text{tr}(PV_kPV_l) = J_{kl}。 \blacksquare$$

[题目]

23.26 证明。 见推导 23.4。记 $c_1 = 1 - t + nt$, $c_2 = 1 - t$, 则

$$\ell(t, u) = -\frac{1}{2}[(g-1)\log(c_1u) + g(n-1)\log(c_2u) + \frac{\text{SSB}}{c_1u} + \frac{\text{SSW}}{c_2u}].$$

对 u 求偏导: $-\frac{1}{2}[(gn-1)/u - (\text{SSB}/c_1 + \text{SSW}/c_2)/u^2] = 0$, 得 $\hat{u}(t) = (\text{SSB}/c_1 + \text{SSW}/c_2)/(gn-1)$ 。代回得轮廓似然 $\ell_p(t) = -\frac{1}{2}\{(gn-1)[\log \hat{u}(t) + 1] + (g-1)\log c_1 + g(n-1)\log c_2\}$ (二次项由 $\hat{u}$ 的定义化简为常数 $gn-1$)。■

[题目]

六、综合分析与研究设计题

23.27 流程 (1) 数据检查: 记录范围、重复、系谱环、不一致年龄; 固定效应水平的样本量与连通 (第 21 章)。(2) 模型设定: 从最简模型 (个体遗传 + 残差) 逐步加入永久环境、母体、场年季等, 每一步记录对数似然、参数个数; 固定效应对比用 ML、随机结构比较用 REML (同一固定效应)。(3) 算法: AI-REML 作主算法, EM 的前几步作稳健起点; 记录起始值敏感性——从至少三组不同起点出发, 要求 ℓ 差小于 10^{-4} 且估计一致 (习题 23.16: AI 8 次、EM 200 次仍未完全收敛)。(4) 诊断: 得分最大绝对值、信息矩阵条件数与特征值 (奇异提示不可识别)、估计是否在边界、 $\text{corr}(\hat{\sigma}_k, \hat{\sigma}_l)$ 。(5) 区间与检验: 关键参数 (h^2) 给出轮廓似然区间, 零方差检验用混合临界值或 F/自助法 (习题 23.17、23.18)。(6) 报告: 同时报告估计、SE (说明所用信息矩阵)、边界处理、模型选择依据及软件与版本。 [题目]

23.28 方案 (1) 资料: 30 头公畜、每头约 4 个后代, 总信息极弱; 习题 23.18 显示 $g = 20$ 时 h^2 的 95% 区间宽度可达 0.84—1.0, 下端为 0 的比例超过八成。(2) 频率法: 用 REML 的轮廓似然区间而非 delta 法, 并同时给出参数自助法; 报告 $\hat{\sigma}_s^2$ 是否在边界。(3) 贝叶斯: 对组间标准差使用有明确含义的先验 (例如依据同品种其他群体的文献遗传力形成的弱信息先验, 或半柯西/平坦先验), 避免 $1/\sigma^2$ 与 $\text{IG}(\epsilon, \epsilon)$; 习题 23.19 显示五种先验下 h^2 后验均值从 0.013 变到 0.349。(4) 敏感性: 并列报告至少三种先验的结果, 如果结论依赖先验就如实说明 “数据对 h^2 几乎没有信息”。(5) 育种值: BLUP 的收缩依赖方差比, 需用后验积分后的预测 (习题 23.20:

总方差比插值 PEV 大约 50%—66%), 并报告 $P(A \text{ 优于 } B)$ 。(6) 改进: 增加每头公畜的后代数 (比增加公畜数更有效, 见第 21 章习题 21.19), 或加入外部先验信息 (如基因组关系)。

[题目]

23.29 诊断 (1) 把 σ_c^2 与 σ_l^2 的轮廓似然画出来: 沿 $\sigma_c^2 + \sigma_l^2 = \text{常数}$ 的直线似然是否近似平坦; (2) 计算信息矩阵的最小特征值与条件数; (3) 检查设计: 是否每只母亲只有一窝 (此时两项核相同, 第 22 章习题 22.17), 同母异窝记录数是否足够; (4) 多起点优化, 检验是否得到同一似然值而不同参数组合; (5) 估计相关 $\text{corr}(\hat{\sigma}_c^2, \hat{\sigma}_l^2)$ 是否接近 -1 。**报告:** 若不可分离, 则合并为“母体—窝共同环境”一项并报告其总和 $\sigma_c^2 + \sigma_l^2$ 及区间; 说明所得两个正方差只是优化的数值路径; 若研究目标需要区分两者, 则需要增加同母异窝记录或做交叉寄养实验。不能因为优化器宣布收敛就认为参数被识别; 似然曲面平坦意味着数据未提供分离它们的信息。

[题目]

多性状、阈值、生存与纵向遗传模型

24.1 本章导学

学习目标

1. 能写出多性状动物模型的混合模型方程，理解 $G \otimes A$ 与残差协方差 R 在缺失记录下如何取子矩阵，解释“借力”与选择偏倚的校正。

2. 会用选择指数公式计算任意信息组合下的可靠度，并说明第二性状何时有用、何时恰好无用。

3. 理解随机回归模型：Legendre 基函数、系数协方差矩阵、协方差函数、逐点可靠度与积分目标的预测误差。

4. 掌握二分类阈值(probit)模型的识别约束、数据扩增 Gibbs 抽样, 会用 Dempster-Lerner 公式在观测尺度与潜在尺度之间换算遗传力。

5. 理解删失与左截断下的生存分析，会推导伽马脆弱性模型的边际似然与后验脆弱性。

6. 理解病例富集抽样如何改变截距而不改变斜率与 AUC，并会用截距平移或逆概率加权恢复总体风险。

重点与难点

重点：多性状 MME；可靠度 $R^2 = c'P_I^{-1}c/G_{11}$ ；随机回归的协方差函数；阈值模型的识别约束与 $h^2_{obs} = h^2_{liab}z^2/[p(1-p)]$ ；伽马脆弱性的边际似然；富集抽样的截距平移 $\log(s_1/s_0)$ 。

难点：缺失记录是否可忽略（取决于缺失机制与模型是否含选择变量）；随机回归系数协方差与时点方差之间的转换；潜在尺度的位置与尺度约束；左截断造成的“永生时间”偏差。

本章把第 21–23 章的单性状 BLUP 与方差组分推广到四类常见资料：多个相关性状、随时间重复的曲线、二分类或有序类别、以及事件时间。它们共享同一骨架——线性混合模型加上一个链接或似然——而区别在于信息如何被缺失、删失、阈值或抽样所改变。第 25 章起的基因组预测在这些模型之上增加标记信息。

24.2 知识结构图




图 24.1 第 24 章知识结构图

左侧是线性高斯的多性状与纵向模型，右侧是类别、事件时间与抽样设计带来的非高斯问题。

24.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
多性状遗传协方差	$\text{Var}(a) = G \otimes A$	动物优先时为 $A \otimes G$
缺失记录	R_i 取观测性状的子矩阵	缺失机制为 MAR 且选择变量在模型内
一动物两性状	$\hat{a} = GP^{-1}y$, $\text{PEV} = G - GP^{-1}G$	$P = G + R$, 均值已知
指数可靠度	$R^2 = c'P_I^{-1}c/G_{11}$	$c = \text{Cov}(I, a_1)$
零增益线	$r_e^* = r_s \sqrt{h_2^2 e_1^2 / (e_2^2 h_1^2)}$	$e_i^2 = 1 - h_i^2$; 线上第二性状不增加信息
随机回归	$a_i(t) = \phi(t)' \alpha_i$, $\text{Var} = \phi(s)' G \phi(t)$	G 为系数协方差
积分目标	$\bar{a}_i = w' \alpha_i$, $\text{PEV} = w' \text{PEV}_\alpha w$	w 为窗口平均的基函数权
probit 阈值模型	$y = 1\{l > 0\}$, $l = x'\beta + s + e$, $\sigma_e^2 = 1$	固定残差方差定义尺度

概念	公式或定义	成立条件与提示
Dempster-Lerner 指数脆弱性边际似然	$h_{obs}^2 = h_{liab}^2 z^2 / [p(1 - p)]$ $\prod_j \lambda_{ij}^{\delta_{ij}} \cdot \frac{\Gamma(1/\theta + d_i)}{\Gamma(1/\theta)} \theta^{d_i} (1 + \theta H_i)^{-(1/\theta + d_i)}$	$z = \varphi(\Phi^{-1}(1 - p))$, 近似 伽马脆弱性, 均值 1
后验脆弱性	$E(w_i \text{data}) = \frac{1/\theta + d_i}{1/\theta + H_i}$	暴露 H_i 含左截断校正
富集截距平移	$\beta_0^* = \beta_0 + \log(s_1/s_0), \beta_1 \text{ 不变}$	抽样仅依赖 y
加权恢复	权 $1/s_y$ 的加权对数似然	稳健方差用三明治估计

24.4 补充内容与公式推导

推导 24.1 多性状 MME 与缺失记录的子矩阵处理

设 t 个性状, 把所有动物的 y 按“动物优先”排列, $y = X\beta + Za + e$, $\text{Var}(a) = A \otimes G$, $\text{Var}(e) = \bigoplus_i R_i$, 其中 R_i 是 R 在动物 i 实际观测性状上的子矩阵。把缺失观测从 y 中删去等价于对其做边缘化: 多元正态的边缘分布仍为正态且协方差为对应子矩阵, 所以 y 的边缘分布含 $V = Z(A \otimes G)Z' + \bigoplus_i R_i$ 。混合模型方程为

$$\begin{bmatrix} X'R^{-1}X & X'R^{-1}Z \\ Z'R^{-1}X & Z'R^{-1}Z + A^{-1} \otimes G^{-1} \end{bmatrix} \begin{bmatrix} \hat{\beta} \\ \hat{a} \end{bmatrix} = \begin{bmatrix} X'R^{-1}y \\ Z'R^{-1}y \end{bmatrix}.$$

若缺失只依赖于已观测变量 (MAR) 且这些变量在模型中, 则该边缘似然对参数的推断有效, 不需要额外建模缺失机制。习题 24.15 中, 性状 2 的记录只在依性状 1 表型选留的个体上存在: 二性状 BLUP 在未代的遗传趋势偏差为 -0.084 , 仅用性状 2 的单性状 BLUP 为 -1.578 ; 单性状分析把“被选择”当作性状 2 的随机缺失, 选择压力被误认为环境差异, 趋势被严重低估。

推导 24.2 一个动物、两个性状的借力公式

若动物没有亲属、均值已知, 记 $P = G + R$, $y = (y_1, y_2)'$, 则 $\hat{a} = GP^{-1}y$, 预测误差协方差 $G - GP^{-1}G$ 。当性状 2 缺失时, 信息向量只剩 y_1 , $\hat{a}_2 = G_{21}y_1/P_{11}$, $\text{PEV}(a_2) = G_{22} - G_{21}^2/P_{11}$, 可靠度 $= G_{21}^2/(P_{11}G_{22}) = r_g^2 h_1^2$ (总方差标准化为 1 时)。可见仅凭另一个性状的记录, 可靠度为遗传相关平方乘以该性状的遗传力。取 $G = \begin{pmatrix} 10 & 4 \\ 4 & 6 \end{pmatrix}$ 、 $R = \begin{pmatrix} 20 & 3 \\ 3 & 14 \end{pmatrix}$: $G_{21}^2/(P_{11}G_{22}) = 16/(30 \times 6) = 0.0889$, 与习题 24.21 的数值一致。

推导 24.3 随机回归：协方差函数与逐点可靠度

取 Legendre 多项式基 $\phi(s) = (1, s, \frac{1}{2}(3s^2 - 1))'$ ($s \in [-1, 1]$)。动物 i 的遗传曲线为 $a_i(s) = \phi(s)' \alpha_i$, $\text{Var}(\alpha) = A \otimes G$ 。则时点 s, t 的遗传协方差为 $\phi(s)' G \phi(t)$, 方差为 $\phi(s)' G \phi(s)$ 。系数的 G 元素没有“某时点方差”的直接含义: G_{11} 只是常数项方差, 二次项的系数 G_{33} 会在 $s = \pm 1$ 处放大。MME 得到 $\hat{a}$ 与 PEV_α 之后, 时点 s 的预测误差方差为 $\phi(s)' \text{PEV}_{\alpha, ii} \phi(s)$, 可靠度 $1 - \text{PEV}(s) / \text{Var}(s)$; 窗口 $[s_0, s_1]$ 的平均曲线对应权向量 $w = \frac{1}{m} \sum_k \phi(s_k)$, 误差方差 $w' \text{PEV}_{\alpha, ii} w$ 。习题 24.16 (60 头动物, 每头 6 条记录) 中 $s = -1, -0.5, 0, 0.5, 1$ 的可靠度为 0.301, 0.504, 0.541, 0.549, 0.458, 两端低于中间; 窗口 $[-1, 0]$ 的积分可靠度 0.498, 高于最低端点。

推导 24.4 阈值模型与 Dempster-Lerner 换算

设潜在 $l = \mu + g + e$, $g \sim N(0, \sigma_g^2)$, $e \sim N(0, 1)$, 阈值 0, $h_{liab}^2 = \sigma_g^2 / (\sigma_g^2 + 1)$, 不妨标准化总方差为 1。发病率 $p = 1 - \Phi(t)$, t 为标准化阈值。条件于 g , $P(y = 1 | g) = 1 - \Phi(t - g / \sqrt{\sigma_e^2})$, 在 $g = 0$ 附近一阶展开: $P(y = 1 | g) \approx p + zg$, 其中 $z = \varphi(t)$ 。于是观测尺度的遗传方差 $\approx z^2 \sigma_g^2$, 观测方差为 $p(1 - p)$, 得

$$h_{obs}^2 \approx h_{liab}^2 \frac{z^2}{p(1 - p)}.$$

因子 $z^2 / [p(1 - p)] \leq 2/\pi \approx 0.637$ (在 $p = 0.5$ 取最大), 所以观测尺度遗传力总是小于液态变量遗传力, 低发病率时尤其如此。习题 24.17 中 $p = 0.227$, $z = 0.302$, $z^2 / [p(1 - p)] = 0.518$; Gibbs 估计的 h_{liab}^2 为 0.403 (真值 0.364), 换算得 $h_{obs}^2 = 0.209$, 与对 0/1 数据的方差分析估计 0.191 相近。

推导 24.5 伽马脆弱性的边际似然与后验均值

设公牛 i 的女儿共享脆弱性 $w_i \sim \text{Gamma}(1/\theta, \text{rate} = 1/\theta)$ (均值 1、方差 θ), 个体风险 $\lambda_{ij} w_i$, 指数基线下条件似然为 $w_i^{d_i} \exp(-w_i H_i) \prod_j \lambda_{ij}^{\delta_{ij}}$, $d_i = \sum_j \delta_{ij}$, $H_i = \sum_j \lambda_{ij} (t_{ij} - e_{ij})$ (e_{ij} 为进入时刻, 左截断)。对 w_i 积分:

$$\int w^{1/\theta + d_i - 1} \exp[-w(1/\theta + H_i)] dw \cdot \frac{(1/\theta)^{1/\theta}}{\Gamma(1/\theta)} = \frac{\Gamma(1/\theta + d_i)}{\Gamma(1/\theta)} \theta^{d_i} (1 + \theta H_i)^{-(1/\theta + d_i)}.$$

$w_i | \text{data} \sim \text{Gamma}(1/\theta + d_i, 1/\theta + H_i)$, 均值 $(1/\theta + d_i) / (1/\theta + H_i)$, 方差 $(1/\theta + d_i) / (1/\theta + H_i)^2$ 。分子分母同加 $1/\theta$ 即“收缩”: 事件很少的家系向 1 收缩, 且收缩强度由 θ 决定。若忽略左截断, 把暴露从 0 起算, H_i 偏大, λ_0 被低估: 习题 24.18 中含截断的估计平均为 0.0990, 忽略截断为 0.0753 (真值 0.10)。

推导 24.6 病例富集的截距平移与第二性状的零增益线

富集。总体 $\text{logit } P(y = 1 | g) = \beta_0 + \beta_1 g$ 。以概率 s_y 抽取类别 y 的个体，抽样仅依赖 y 。由 Bayes，样本内 $P^*(y = 1 | g)/P^*(y = 0 | g) = \frac{s_1}{s_0} \cdot \frac{P(y = 1 | g)}{P(y = 0 | g)}$ ，故 $\beta_0^* = \beta_0 + \log(s_1/s_0)$ ， β_1 不变；个体排序与 AUC 不变，但绝对风险被高估。习题 24.19 全部病例加 k 倍对照时 $\Delta = 3.828, 3.135, 2.218, 1.525$ ($k = 1, 2, 5, 10$)，估计分别为 3.802, 3.108, 2.191, 1.501。

零增益线。候选只有性状 1 记录时， $R^2 = G_{11}/P_{11}$ 。再加性状 2 后，增量取决于 a_1 在 y_1 已知后对 y_2 的偏协方差 $G_{12} - G_{11}P_{12}/P_{11}$ 。令其为 0 并以总方差标准化： $r_g \sqrt{h_1^2 h_2^2 (1 - h_1^2)} = h_1^2 r_e \sqrt{(1 - h_1^2)(1 - h_2^2)}$ ，得

$$r_e^* = r_g \sqrt{\frac{h_2^2(1 - h_1^2)}{h_1^2(1 - h_2^2)}}.$$

习题 24.20 中 $h^2 = (0.30, 0.45)$ ： $r_g = 0.3 \rightarrow r_e^* = 0.415$ ， $r_g = -0.4 \rightarrow -0.553$ ，增益在线上为 0（数值 $< 10^{-12}$ ）。

拓展阅读 多性状、阈值与生存模型

多性状 BLUP 与选择指数的对应见 Henderson 与 Quaas (1976)；Meyer (1998) 发展了随机回归的方差估计；Gianola 与 Foulley (1983) 建立了类别性状的阈值模型，Albert 与 Chib (1993) 给出了 probit 的数据扩增抽样；Dempster 与 Lerner (1950) 给出观测尺度与潜在尺度的换算。畜牧业中的生存分析可追溯到 Ducrocq 与 Sölkner 的 Survival Kit，脆弱性模型来自 Vaupel 等 (1979)。病例对照抽样下的截距校正是 Prentice 与 Pyke (1979) 的经典结果，近年在基因组风险预测中被反复重申。

易错辨析

- **缺失不是“删除动物”**：缺性状 2 的动物仍通过 G 与 A 贡献信息；单性状分析会丢掉选择信息而偏倚。
- **R 设为对角会遗漏信息**：习题 24.15 中忽略 R 的相关，EBV 相关不变但趋势偏差由 -0.084 变为 -0.262 。
- **随机回归系数不是时点方差**：必须用 $\phi(t)'G\phi(t)$ 才能解释。
- **阈值尺度不能与线性尺度直接比较**： σ_s^2 的数值取决于残差方差被固定为 1。
- **富集样本的校准**：AUC 好看不代表概率可用，未校正截距使总体风险高估约 $\log(s_1/s_0)$ 。
- **忽略左截断**：把暴露从 0 起算相当于给未观测的死亡个体“免死金牌”。

24.5 习题

一、单项选择题

24.1 ★ [单选] 二性状动物模型中, 某动物只有性状 1 记录, 正确的处理是

- (A) 删除该动物
- (B) 残差协方差取 R 在性状 1 上的子矩阵, 保留其在 $G \otimes A$ 中的位置
- (C) 把性状 2 记录填 0
- (D) 用性状 1 的值代替性状 2

[答案]

24.2 ★ [单选] 二分类 probit 种公牛模型固定残差方差为 1, 主要原因是

- (A) 为了让后验正常
- (B) 观测的 0/1 数据无法同时识别潜在尺度与方差, 需约束尺度
- (C) 为了使 Gibbs 链收敛更快
- (D) 因为残差方差一定等于 1

[答案]

24.3 ★★ [单选] 随机回归模型中, 育种值曲线在记录时间的两端预测精度较低, 主要原因是

- (A) 记录数据少且二次项在端点处杠杆大
- (B) 阶数太低
- (C) 方差分析不适用
- (D) Legendre 多项式不正交

[答案]

24.4 ★★ [单选] 对低发病率性状, Dempster-Lerner 换算表明观测尺度遗传力

- (A) 总大于潜在尺度
- (B) 总小于潜在尺度
- (C) 与潜在尺度相等
- (D) 随发病率增大而趋于 1

[答案]

24.5 ★★ [单选] 生存数据中只有“活到进入时刻”的个体才被观测, 这种现象称为左截断, 若分析时把暴露从时刻 0 起算, 会导致

- (A) 风险估计偏高
- (B) 风险估计偏低 (永生时间偏差)
- (C) 无偏
- (D) 仅影响协变量系数

[答案]

24.6 ★★★ [单选] 两性状指数中, 当 $r_e = r_e^*$ (零增益线) 时, 加入候选个体自身的性状 2 记录

- (A) 一定提高性状 1 的可靠度 (B) 不改变性状 1 的可靠度
(C) 一定降低可靠度 (D) 取决于样本量

[答案]

二、判断与改错题

24.7 ★ [判断] 若性状 2 的缺失依赖于性状 1 的表型 (MAR), 只用性状 2 记录做单性状 BLUP 仍然无偏。 [答案]

24.8 ★ [判断] 随机回归系数协方差矩阵的对角元可以直接解释为某个具体时点的遗传方差。 [答案]

24.9 ★★ [判断] probit 阈值模型中, 把残差方差固定为 1 后, σ_s^2 的数值不能与线性模型的 σ_s^2 直接比较。 [答案]

24.10 ★★ [判断] 病例富集抽样后, 逻辑回归的斜率不变, 因此样本内拟合的预测概率可以直接作为总体风险使用。 [答案]

三、填空题

24.11 ★ [填空] probit 模型, 固定部分为 0.5, 个体遗传值的后验为 $N(0, 0.25)$, 潜在残差方差 1, 则整合遗传不确定性后事件的边际概率为 _____ (三位小数)。 [答案]

24.12 ★ [填空] 发病率 $p = 0.5$ 时 $z = \varphi(0) = 0.3989$, $z^2/[p(1-p)] = \underline{\hspace{2cm}}$, 若 $h_{liab}^2 = 0.5$, 则 $h_{obs}^2 = \underline{\hspace{2cm}}$ 。 [答案]

24.13 ★★ [填空] 伽马脆弱性 $\theta = 0.5$, 某公牛家系 $d = 3$ 次事件、累积暴露 $H = 2$, 后验脆弱性均值 = _____, 后验方差 = _____。 [答案]

24.14 ★★ [填空] 总体 100000 人中有 2000 名病例, 保留全部病例并抽取 8000 名对照。对照抽样比 $s_0 = \underline{\hspace{2cm}}$ (四位小数), 截距平移 $\log(s_1/s_0) = \underline{\hspace{2cm}}$ 。 [答案]

四、计算题

- 24.15 ★★★ [计算] 二性状 BLUP 的缺失与选择。** 闭锁群体, 30 个起始个体、3 代每代 40 头, 按性状 1 表型选留亲本; 性状 2 只在被选留个体上有记录。比较二性状 BLUP、仅性状 2 的单性状 BLUP、以及 R 相关设为 0 的二性状 BLUP 的预测相关、斜率与趋势偏差。 [程序] `ch24/ex24_15_multitrait_blup.py` [答案]
- 24.16 ★★★ [计算] 随机回归的逐点可靠度。** 60 头动物 (12 个家系), 每头 6 条记录, Legendre 二阶; 计算 5 个时点的解析 PEV 与蒙特卡罗均方误差, 以及窗口 $[-1, 0]$ 平均曲线的 PEV 与可靠度。 [程序] `ch24/ex24_16_random_regression.py` [答案]
- 24.17 ★★★ [计算] 阈值 probit 种公牛模型。** 60 头公牛、2209 条 0/1 记录、5 个场。用 Gibbs 抽样估计 σ_s^2 与 h^2 , 经 Dempster-Lerner 换算观测尺度遗传力, 并与线性种公牛模型比较公牛排序与 20 次重复的相关。 [程序] `ch24/ex24_17_threshold_probit_gibbs.py` [答案]
- 24.18 ★★★ [计算] 伽马脆弱性生存模型。** 80 头公牛、每头 25 头女儿, 含右删失与左截断: 核验边际似然的闭式与数值积分, 求 MLE 与 $\theta = 0$ 的似然比检验, 比较含截断、忽略截断及朴素排序的表现。 [程序] `ch24/ex24_18_gamma_frailty_survival.py` [答案]
- 24.19 ★★★ [计算] 病例富集抽样。** 总体 600000 人、发病率约 2.1%, logit 风险 $\beta_0 = -4.2$, $\beta_1 = 0.9$ 。保留全部病例并抽取 $k = 1, 2, 5, 10$ 倍对照: 核验截距平移、加权恢复、AUC 不变与校准截距。 [程序] `ch24/ex24_19_case_control_enrichment.py` [答案]
- 24.20 ★★★ [计算] 二性状可靠度曲面。** $h^2 = (0.30, 0.45)$, 在 $r_g, r_e \in [-0.9, 0.9]$ 网格上计算候选“自身两性状”对“仅性状 1”的可靠度增益、零增益线, 并对三个格点做蒙特卡罗核对。 [程序] `ch24/ex24_20_two_trait_reliability_surface.py` [答案]
- 24.21 ★ [计算] 一头无亲属动物,** $G = \begin{pmatrix} 10 & 4 \\ 4 & 6 \end{pmatrix}$ 、 $R = \begin{pmatrix} 20 & 3 \\ 3 & 14 \end{pmatrix}$, 两性状记录偏差 $y = (6, -2)$ 。求 $\hat{a}$ 、误差协方差矩阵与两性状可靠度; 若性状 2 缺失, 只有 $y_1 = 6$, 求 $\hat{a}_2$ 与可靠度。 [答案]
- 24.22 ★★ [计算]**
- (1) 液态变量遗传力 0.4、发病率 0.2, 求观测尺度遗传力。(2) 观测尺度遗传力 0.15、发病率 0.10, 反求液态变量遗传力。 [答案]

五、推导与证明题

24.23 ★★ [证明] 证明：一头无亲属、均值已知的动物只有性状 1 记录时， $\hat{a}_2 = G_{21}y_1/P_{11}$ ， $PEV(a_2) = G_{22} - G_{21}^2/P_{11}$ ，可靠度为 $r_g^2 h_1^2$ （总方差标准化为 1）。[答案]

24.24 ★★★ [证明] 证明 Dempster-Lerner 公式：在液态变量总方差 1、阈值固定时，观测尺度遗传力 $h_{obs}^2 \approx h_{liab}^2 z^2/[p(1-p)]$ ，并证明 $z^2/[p(1-p)] \leq 2/\pi$ 。[答案]

24.25 ★★★ [证明] 证明病例富集抽样（抽样概率仅依赖 y ）后，逻辑回归的截距平移为 $\log(s_1/s_0)$ 、斜率不变，并说明 AUC 不变的原因。[答案]

24.26 ★★★ [证明] 证明两性状指数中第二性状对性状 1 可靠度的增益为零的充要条件是 $G_{12}P_{11} = G_{11}P_{12}$ ，并化简为关于 r_e 的显式零增益线。[答案]

六、综合分析与研究设计题

24.27 ★★ [综合] 为某奶牛场测定日记录的纵向评定设计随机回归分析流程：数据准备、基函数与阶次选择、残差方差函数、目标性状定义（如 305 天或某泌乳阶段）、诊断与报告。[答案]

24.28 ★★★ [综合] 肉牛难产（0/1）的评定拟在线性模型与阈值模型之间选择。设计比较方案，并说明尺度、发病率与公牛排序如何一起报告。[答案]

24.29 ★★★ [综合] 某疾病抗性研究：个体事件时间有右删失与左截断，同时拟用病例富集抽样建立基因组风险预测。给出模型、抽样校正与验证方案。[答案]

24.6 参考答案与解析

一、单项选择题

24.1 B。缺失观测从 y 中删去相当于对多元正态取边缘，残差协方差取观测性状的子矩阵；动物在 $G \otimes A$ 中的位置仍保留，所以它通过遗传相关与亲属为性状 2 的预测提供信息。删除该动物（A）则丢掉了信息，填 0（C、D）则人为制造了信息。[题目]

24.2 B。0/1 观测只确定 $P(l > 0)$ ，把 l 与阈值同时按正数缩放、平移，概率不变。固定残差方差（并设阈值为 0）才定义潜在单位与原点。该约束不提供生物学信息，只定义尺度。[题目]

24.3 A. 习题 24.16 中端点 $s = \pm 1$ 处二次项基函数值最大 ($\phi_3(\pm 1) = 1$), 而记录又分布在整个窗口, 端点杠杆大; 时点 $s = -1, 1$ 的可靠度 0.301, 0.458 低于 $s = 0.5$ 的 0.549, 且 $s = 1$ 的遗传方差 12.72 最大、PEV 达 6.89。 [题目]

24.4 B. $z^2/[p(1-p)] \leq 2/\pi = 0.637$, 所以 $h_{obs}^2 < h_{liab}^2$ 。习题 24.17 中 $p = 0.227$: 因子 0.518。 [题目]

24.5 B. 在进入前死亡的个体不会被观测, 这样“活到进入”本身是一段无风险时间, 从 0 起算暴露会把这段暴露错误计入分母, 使风险偏低。习题 24.18: 含截断 $\hat{\lambda}_0 = 0.0990$ (30 次平均), 忽略截断 0.0753, 真值 0.10。 [题目]

24.6 B. 零增益线上 $G_{12}P_{11} = G_{11}P_{12}$, 性状 2 对 a_1 在已知 y_1 之后没有偏协方差, 故可靠度不变。习题 24.20: $r_g = 0.3$ 、 $r_e = 0.415$ 时增益为 0 ($< 10^{-12}$)。 [题目]

二、判断与改错题

24.7 错误。 选择依赖于性状 1, 仅用性状 2 的单性状模型不知道选择发生, 把选择造成的差异当作环境差异, 遗传趋势被低估。习题 24.15: 趋势偏差 -1.578 , 二性状 BLUP 为 -0.084 。 [题目]

24.8 错误。 G 的对角元是基函数系数的方差; 某时点方差为 $\phi(t)'G\phi(t)$, 包含各系数间的协方差。习题 24.16 中 $G_{33} = 1.0$ 很小, 但 $s = 1$ 的遗传方差高达 12.72。 [题目]

24.9 正确。 线性模型的 σ_s^2 是观测 0/1 尺度的方差, probit 的 σ_s^2 是残差方差为 1 的潜在尺度。习题 24.17: 潜在尺度 $\sigma_s^2 \approx 0.113$, 观测尺度的 $h_{obs}^2 \approx 0.19-0.21$ 。 [题目]

24.10 错误。 斜率不变, 但截距被平移 $\log(s_1/s_0)$, 样本内概率系统地高估。习题 24.19 中未校正的校准截距为 $-3.83, -3.14, -2.22, -1.53$, 校正后均在 -0.006 到 -0.004 之间。 [题目]

三、填空题

24.11 边际概率为 $\Phi(0.5/\sqrt{1+0.25}) = \Phi(0.4472) = 0.673$, 直接代入点估计 $\Phi(0.5) = 0.691$ 。 [题目]

24.12 $z^2/[p(1-p)] = 0.3989^2/0.25 = 0.637$ (即 $2/\pi$); $h_{obs}^2 = 0.5 \times 0.637 = 0.318$ 。 [题目]

24.13 均值 $(1/\theta + d)/(1/\theta + H) = (2+3)/(2+2) = 1.25$; 方差 $(2+3)/(2+2)^2 = 0.3125$ 。有事件的家系脆弱性高于 1, 且比未收缩的粗率更保守。 [题目]

24.14 $s_0 = 8000/98000 = 0.0816$; $\log(s_1/s_0) = \log(12.25) = 2.506$ 。截距平移 2.506, 表示样本内几率被高估约 12.25 倍。 [题目]

四、计算题

24.15 60 次重复, $G = \begin{pmatrix} 10 & 4 \\ 4 & 6 \end{pmatrix}$, $R = \begin{pmatrix} 20 & 3 \\ 3 & 14 \end{pmatrix}$:

方法	末代性状 2 相关	真值对预测斜率	末代趋势偏差
二性状 BLUP	0.636	1.037	-0.084
仅性状 2 的单性状 BLUP	0.620	1.017	-1.578
二性状, R 相关设为 0	0.636	0.998	-0.262

首次重复中, 有性状 2 记录者的 PEV 为 3.556, 缺记录者为 4.835 (先验方差 $G_{22} = 6.0$), 借力把缺记录者的误差方差从 6 降到 4.8; V 形式与 MME 解一致, PEV 矩阵半正定, 单性状 PEV 不小于二性状 PEV。解读: 预测相关只差 0.016, 但趋势差异巨大——只看相关会得出“两种方法差不多”的错误结论; 选择造成的缺失必须在模型内处理。R 相关设为 0 使趋势偏差变为 -0.262, 说明环境相关也会影响选择校正。 [题目]

24.16 基函数: Legendre 二阶, $G = \begin{pmatrix} 9 & 1.5 & -0.8 \\ 1.5 & 2.5 & 0.3 \\ -0.8 & 0.3 & 1.0 \end{pmatrix}$, 永久环境协方差 $\begin{pmatrix} 6 & 0.5 & 0 \\ 0.5 & 1.5 & 0 \\ 0 & 0 & 0.6 \end{pmatrix}$, $\sigma_e^2 = 4$ 。

标准化时间 s	-1	-0.5	0	0.5	1
遗传方差	5.201	4.474	6.019	6.927	12.721
解析 PEV	3.637	2.220	2.765	3.121	6.891
蒙特卡罗 MSE	3.609	2.230	2.756	3.103	6.879
逐点可靠度	0.301	0.504	0.541	0.549	0.458

窗口 $[-1, 0]$ 的平均曲线: 解析 PEV 2.0758 (MC 2.0850), 可靠度 0.498。解读: 端点的 PEV 和遗传方差都大, $s = 1$ 的 PEV 为 6.89 但方差更大, 所以可靠度仍达 0.458; 窗口平均抹平了端点的不稳定, 可靠度高于 $s = -1$ 的单点。蒙特卡罗与解析在 10% 内一致。 [题目]

24.17 60 头公牛、2209 条记录、发病率 $\hat{p} = 0.227$: σ_s^2 真值 0.10, 后验均值 0.113, 95% 区间 $[0.063, 0.189]$; 潜在尺度 h^2 真值 0.364、后验均值 0.403; 阈值 $t = 0.748$, $z = 0.3016$; Dempster-Lerner 换算 $h_{obs}^2 = 0.209$, 经场扣除的方差分析估计 0.191。公牛真效应相关: 阈值 0.773, 线性 0.763; 排序 Spearman 0.996, 前 10 名重合 9/10。20 次

重复：阈值 0.757 ± 0.058 ，线性 0.750 ± 0.057 ，阈值更优的比例 0.80。解读：排序几乎一致，阈值模型的优势主要在尺度的解释与极端发病率下；线性模型对排序是好近似，但其 h^2 不能与潜在尺度直接比较。 [题目]

24.18 闭式边际似然 -20.264972 与数值积分一致（差 1.8×10^{-12} ）。MLE: $\hat{\lambda}_0 = 0.0864$ （真 0.10）， $\hat{\beta} = 0.569$ （真 0.5）， $\hat{\theta} = 0.415$ （真 0.4），梯度范数 2.8×10^{-6} ；忽略左截断： $\hat{\lambda}_0 = 0.0657$ ， $\hat{\theta} = 0.363$ 。 $\theta = 0$ 的似然比 144.3 ($p \approx 10^{-33}$)。单次资料：后验脆弱性对真 w 相关 0.849，朴素 d /暴露 0.845，后验均值恰为 1.000。30 次重复：后验相关 0.886，朴素 0.878； λ_0 含截断平均 0.0990，忽略截断 0.0753。解读：收缩带来的相关提升很小（约 0.008），因为每头公牛有 25 个女儿，信息足够；左截断的偏差则很大（ -25% ）。 [题目]

24.19 总体 600000 人，病例 12778（发病率 0.0213）：

k	样本量	估计 Δ	理论 $\log(s_1/s_0)$	$\hat{\beta}_1$ (SE)	加权 $\hat{\beta}_0$	未校正校正截距	校正后
1	25556	3.802	3.828	0.928 (0.015)	-4.214	-3.832	-0.005
2	38334	3.108	3.135	0.931 (0.013)	-4.226	-3.141	-0.006
5	76668	2.191	2.218	0.929 (0.011)	-4.226	-2.222	-0.004
10	140558	1.501	1.525	0.925 (0.010)	-4.224	-1.529	-0.004

留出集 AUC 在四种 k 下均为 0.7331。 β_1 的标准误依次 0.015, 0.013, 0.011, 0.010: k 从 1 到 2 下降 15%，从 5 到 10 只下降 8.6%，边际收益递减。解读：富集提高效率，但必须校正截距，AUC 对此毫无感觉。 [题目]

24.20 $h^2 = (0.30, 0.45)$ ，自身两性状相对仅性状 1 的可靠度增益（部分格点）： $(r_g, r_e) = (0.6, -0.6)$ 为 0.241， $(0.6, 0.6)$ 仅 0.009； $(0.9, -0.9)$ 为 0.560， $(0.9, 0.9)$ 仅 0.065； $r_g = 0$ 时增益关于 r_e 对称，如 $r_e = \pm 0.9$ 均为 0.136。零增益线 $r_e^* = 1.382 r_g$ ($r_g = -0.4 \rightarrow -0.553$, $0.3 \rightarrow 0.415$, $0.7 \rightarrow 0.967$)，线上增益 $< 10^{-12}$ 。D2（仅性状 2）的可靠度 $= r_g^2 h_2^2$ 。蒙特卡罗对三个格点的绝对误差均 < 0.012 。解读：遗传相关高并不等于第二性状有用——当 r_e 与 r_g 同比例时两者对 a_1 的信息已被性状 1 吸收； r_e 与 r_g 反号时第二性状最有价值，因为它帮助分离遗传与环境。 [题目]

24.21 $P = \begin{pmatrix} 30 & 7 \\ 7 & 20 \end{pmatrix}$, $\hat{a} = GP^{-1}y = (1.691, -0.138)'$ ；误差协方差 $G - GP^{-1}G = \begin{pmatrix} 6.515 & 2.207 \\ 2.207 & 4.069 \end{pmatrix}$ ，可靠度 $1 - 6.515/10 = 0.348$ （性状 1）、 $1 - 4.069/6 = 0.322$ （性状 2）。若性状 2

缺失: $\hat{a}_2 = 4 \times 6/30 = 0.8$, $PEV = 6 - 16/30 = 5.467$, 可靠度 = **0.0889**。可见两性状都有记录时, 性状 2 的可靠度从 0.089 升到 0.322。

[题目]

24.22

(1) $t = \Phi^{-1}(0.8) = 0.8416$, $z = 0.2800$, $z^2/[p(1-p)] = 0.0784/0.16 = 0.490$, $h_{obs}^2 = 0.4 \times 0.490 = \mathbf{0.196}$ 。(2) $t = 1.2816$, $z = 0.1755$, 因子 = $0.03080/0.09 = 0.3422$, $h_{liab}^2 = 0.15/0.3422 = \mathbf{0.438}$ 。发病率越低, 观测尺度遗传力被压得越低, 反向换算也越放大。

[题目]

五、推导与证明题

24.23 证明。信息向量只有 y_1 , $\text{Var}(y_1) = P_{11}$, $\text{Cov}(a_2, y_1) = G_{21}$ (残差不进入 a)。BLUP 为 $\hat{a}_2 = G_{21}P_{11}^{-1}y_1$, $PEV = G_{22} - G_{21}^2/P_{11}$ 。可靠度 $1 - PEV/G_{22} = G_{21}^2/(P_{11}G_{22})$ 。总方差标准化后 $G_{11} = h_1^2$, $G_{22} = h_2^2$, $G_{21} = r_g h_1 h_2$, $P_{11} = 1$, 代入得 $r_g^2 h_1^2 h_2^2 / h_2^2 = r_g^2 h_1^2$ 。

■

[题目]

24.24 证明。 $l = g + e$, $g \sim N(0, \sigma_g^2)$, $e \sim N(0, 1)$, 阈值 t 。 $P(y = 1 | g) = 1 - \Phi(t - g)$, 在 $g = 0$ 处展开: $p + \varphi(t)g + O(g^2)$ 。观测尺度加性遗传方差 $z^2 \sigma_g^2$, 总方差 $p(1-p)$, 所以 $h_{obs}^2 \approx z^2 \sigma_g^2 / [p(1-p)]$; 把 $\sigma_g^2 = h_{liab}^2$ (总方差标准化为 1) 代入得公式。再证上界: $f(t) = \varphi(t)^2 / [\Phi(t)(1 - \Phi(t))]$ 是 t 的偶函数, 直接求导可检验 $t > 0$ 时 f 单调递减 (尾部 φ^2 的衰减快于 $\Phi(1 - \Phi)$), 故在 $t = 0$ 取最大 $\varphi(0)^2/0.25 = \frac{1}{2\pi} \times 4 = 2/\pi$ 。

■

[题目]

24.25 证明。设 S 为被抽中的指示, $P(S = 1 | y, g) = s_y$ 。样本内 $P(y = 1 | g, S = 1) = \frac{s_1 P(y = 1 | g)}{s_1 P(y = 1 | g) + s_0 P(y = 0 | g)}$, 几率为 $\frac{s_1}{s_0} e^{\beta_0 + \beta_1 g}$, 取对数得 $\beta_0 + \log(s_1/s_0) + \beta_1 g$ 。AUC 只与 g 在 $y = 1$ 与 $y = 0$ 两类中的条件分布有关, 而抽样仅依赖 y , 不改变 $g | y$ 的分布, 故 AUC 不变。■

[题目]

24.26 证明。当候选已知 y_1 时, 再加 y_2 带来的增量方差是 $\text{Cov}(a_1, y_2 | y_1)^2 / \text{Var}(y_2 | y_1)$, 分母为正。零增益等价于条件协方差为零: $G_{12} - G_{11}P_{12}/P_{11} = 0$, 即 $G_{12}P_{11} = G_{11}P_{12}$ 。令总方差为 1, $G_{11} = h_1^2$, $P_{11} = 1$, $G_{12} = r_g h_1 h_2$, $P_{12} = r_g h_1 h_2 + r_e e_1 e_2$, 代入: $r_g h_1 h_2 = h_1^2 (r_g h_1 h_2 + r_e e_1 e_2)$, 解得 $r_e = r_g \frac{h_2(1 - h_1^2)}{h_1 e_1 e_2} = r_g \frac{h_2 e_1}{h_1 e_2}$, 即 $r_e^* = r_g \sqrt{\frac{h_2^2(1 - h_1^2)}{h_1^2(1 - h_2^2)}}$ 。数值: $h^2 = (0.30, 0.45)$ 时比例 $\sqrt{0.45 \times 0.70 / (0.30 \times 0.55)} = 1.382$ 。

■

[题目]

六、综合分析与研究设计题

24.27 流程 (1) 数据: 测定日、泌乳天数、胎次、场—测定日分组; 检查记录的天数范围与每头记录数 (习题 24.16 每头 6 条)。(2) 基函数: Legendre 二阶或三阶; 比较阶次时用 AIC/BIC 并检验端点预测, 不能只看拟合;(3) 残差方差: 按泌乳阶段分段或建方差函数, 检查残差随时间的异质性;(4) 永久环境曲线单独建模, 避免把永久环境混入遗传;(5) 目标: 定义 305 天产量为窗口积分 $w'\hat{a}$, 并用 w' PEV w 给出可靠度 (习题 24.16: 窗口可靠度 0.498);(6) 诊断: 逐点可靠度曲线、端点预测的稳定性、不同阶次下的排序一致性;(7) 报告: 给出基函数、阶次、方差估计、窗口定义, 说明端点外推不可靠。 [题目]

24.28 方案 (1) 资料: 公牛后代的难产记录, 场年季固定效应;(2) 两模型: 线性种公牛模型 (BLUP) 与阈值模型 (Gibbs 或 REML 近似);(3) 比较: 公牛真值或交叉验证的排序、前 10 名重合 (习题 24.17: Spearman 0.996, 重合 9/10); 预测对数似然/Brier;(4) 尺度报告: 同时报告潜在尺度 h^2 、发病率 p 、观测尺度 h^2 (Dempster-Lerner), 避免不同研究间的数值误比;(5) 公牛的报告: 用育种值对概率的影响 (取场平均), 说明 ΔP 随基线概率非线性;(6) 决策: 若只需排序, 线性模型已足够; 若发病率极端、用于概率预测或不平衡严重, 用阈值模型。 [题目]

24.29 模型: 指数或 Weibull 基线的伽马脆弱性模型, 脆弱性可按公牛或基因组预测值进入; 左截断以进入时刻修正暴露, 右删失以事件指示处理 (习题 24.18)。**抽样**: 若用病例富集建立风险模型, 按类别抽样概率校正: 加权似然 (权 $1/s_y$) 或截距平移 $\log(s_1/s_0)$ (习题 24.19: 校正前校准截距 -1.5 到 -3.8, 校正后 ≈ 0); 时间相关的事件需要依时间的权重。**验证**: 在未被富集的独立总体中, 报告 AUC (不受富集影响) 与校准截距、斜率; 按世代或群体划分验证以反映迁移; 报告事件率与删失比例, 避免把富集样本中的准确率当作总体表现。若同时有多个性状 (如产量与抗病), 用二性状指数评估抗病性状从产量记录得到的借力 (习题 24.20: 在零增益线上借力为 0)。 [题目]

第八篇

基因组遗传学与基因组预测

基因组信息增加了什么，怎样验证。

本篇习题训练：基因组遗传力、关系矩阵、GBLUP 与贝叶斯方法、单步
评定、验证与校准。

基因组时代的遗传力

25.1 本章导学

学习目标

1. 区分系谱遗传力、SNP 遗传力与 GWAS 显著位点解释的方差，理解三者差距（缺失遗传力）的来源。
2. 掌握 GREML 的模型、VanRaden 基因组关系矩阵（GRM）与遗传力的定义，理解标准误由 GRM 非对角元方差决定。
3. 会用 Haseman-Elston 回归估计遗传力并推导其标准误，比较其与 REML 的效率。
4. 理解致因变异的频率与芯片捕获能力的关系，会解释常见、低频与稀有变异下 GREML 的偏低。
5. 会推导 LD 分数回归的期望式 $E(\chi^2) = 1 + Nh^2\ell/M + Na$ ，并区分多基因信号与混杂。
6. 理解 α 模型、MAF 分层 GREML 与病例—对照资料的液态变量尺度换算（含富集校正）。

重点与难点

重点： $h_{SNP}^2 = \sigma_g^2 / (\sigma_g^2 + \sigma_e^2)$; $SE(\hat{h}_{HE}^2) \approx \sqrt{2/[n^2 \text{Var}(G_{jk})]}$; $E(\chi_j^2) = 1 + Nh^2\ell_j/M + Na$;
 $h_l^2 = h_o^2 \cdot \frac{K(1-K)}{z^2} \cdot \frac{K(1-K)}{P(1-P)}$ 。

难点：近亲与共同环境对 GREML 的污染；稀有致因变异的“缺失”；LDSC 截距的含义与低功效；富集抽样与 D-L 因子的两次换算。

本章承接第 23 章（REML 与方差组分）与第 12 章（关系矩阵），把遗传力的“分母与分子”从系谱搬到基因型：个体间的遗传相似性不再由系谱期望值给出，而由实际共享的标记给出。它是第 26 章（GRM 的质量控制）与第 27 章（GBLUP）的概念基础。

25.2 知识结构图




图 25.1 第 25 章知识结构图

左侧是个体水平资料的方法（GREML、HE、分层），右侧是汇总统计量与类别性状的方法。

25.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
VanRaden GRM	$G = WW' / [2 \sum p_j q_j]$, $W = M - 2p$	平均对角元约 1
SNP 遗传力	$h_{SNP}^2 = \sigma_g^2 / (\sigma_g^2 + \sigma_e^2)$	未标准化 GRM 需乘 $\overline{\text{diag } G}$
GREML 剖面似然	$d_i = h^2 s_i + (1 - h^2)$, $-2\ell \propto \sum \log d_i + (n-1) \log y'Py$	$G = USU'$
HE 回归	$\hat{h}^2 = \frac{\sum (G_{jk} - \bar{G}) y_j y_k / \sum (G_{jk} - \bar{G})^2}{\sqrt{2/[n^2 \text{Var}(G_{jk})]}}$	标准化 y
HE 标准误	$\sqrt{2/[n^2 \text{Var}(G_{jk})]}$	无亲缘个体
独立位点的 $\text{Var}(G_{jk})$	$\approx 1/M, \sum (2pq)^2 / (\sum 2pq)^2$	M 为有效独立位点数
近亲剔除	删去 $G_{jk} > 0.025$ 的一方	减轻共同环境与长 IBD 片段
捕获比例	致因变异与芯片 SNP 的最大 r^2	常见变异接近 1
α 模型	$\text{Var}(\beta_j) \propto (2p_j q_j)^\alpha$	$\alpha = -1$ 为标准 GRM

概念	公式或定义	成立条件与提示
LDSC	$E(\chi_j^2) = 1 + Nh^2\ell_j/M + Na$	多基因 + 混杂
加权 LDSC	权 $\propto 1/[\mu_j^2\ell_j]$, 按块刀切 SE	μ_j 为期望 χ^2
多组分 REML	$y = \mu + \sum g_k + e,$ $h_k^2 = \sigma_k^2 / \sum \sigma^2$	delta 法 SE
液态变量换算	$h_l^2 = h_o^2 \frac{K(1-K)}{z^2} \frac{K(1-K)}{P(1-P)}$	线性化近似, K 为总体患病率

25.4 补充内容与公式推导

推导 25.1 HE 回归与它的标准误

对标准化表型 y (均值 0、方差 1), 非对角对 $j < k$ 的乘积 $y_j y_k$ 在多基因模型下的期望为 $E(y_j y_k) = h^2 G_{jk}$ (G 的标准化使 $E(\text{diag}) = 1$)。把 $y_j y_k$ 对 G_{jk} 作回归, 斜率的最小二乘估计即 $\hat{h}_{HE}^2 = \sum (G_{jk} - \bar{G}) y_j y_k / \sum (G_{jk} - \bar{G})^2$ 。把 $N_p = n(n-1)/2$ 个对近似视为独立, 每对乘积的方差近似为 1, 故

$$\text{Var}(\hat{h}_{HE}^2) \approx \frac{1}{N_p \text{Var}(G_{jk})} = \frac{2}{n(n-1) \text{Var}(G_{jk})} \approx \frac{2}{n^2 \text{Var}(G_{jk})}.$$

独立位点下 $G_{jk} = \frac{1}{M} \sum_l z_{jl} z_{kl}$, 各项独立、方差为 1, 所以 $\text{Var}(G_{jk}) = 1/M$; MAF 分布不均时精确值为 $\sum (2p_l q_l)^2 / (\sum 2p_l q_l)^2$ 。因此 $\text{SE} \approx \sqrt{2M}/n$: 增加个体数 n 比增加标记数 M 更有效。习题 25.15 ($n = 1000$, $m = 2000$) 中 $\text{Var}(G_{jk}) = 5.55 \times 10^{-4}$ (理论 5.56×10^{-4} , 而 $1/m = 5.00 \times 10^{-4}$), 理论 SE 0.060; GREML 重复间 SD 0.058、曲率 SE 0.059, HE 的重复间 SD 0.078, 效率低于 REML。

推导 25.2 LD 分数回归的期望式

标准化基因型 z_j 、标准化表型 $y = \sum_k \beta_k z_k + e$, $\beta_k \sim N(0, h^2/M)$, 边际估计 $\hat{\beta}_j = z_j' y / N$, $\chi_j^2 = N \hat{\beta}_j^2$ 。条件于 β , $E(\hat{\beta}_j) = \sum_k r_{jk} \beta_k$, 其平方的期望 $E[(\sum_k r_{jk} \beta_k)^2] = \frac{h^2}{M} \sum_k r_{jk}^2 = \frac{h^2}{M} \ell_j$ ($\ell_j = \sum_k r_{jk}^2$, 含自身)。又 $\hat{\beta}_j$ 的抽样方差约 $1/N$, 故

$$E(\chi_j^2) = 1 + \frac{Nh^2}{M} \ell_j.$$

若有与 LD 无关的混杂 (分层、隐性亲缘), 再加 Na 。对 ℓ_j 作回归, 斜率乘 M/N 为 h^2 , 截距为 $1 + Na$ 。截距并不等于“1 即无混杂”: 习题 25.17 ($M = 3000$, $n = 4000$) 纯多基因下加权截距 1.067 (刀切 SE 0.258), 遗传力 0.461 (刀切 SE 0.161, 真值 0.5); 有两亚群的分层下截距 2.172, 平均 χ^2 从 2.064 升到 3.005。注意 $M = 3000$ 时单次

估计很不稳定（重复间 SD：截距 0.32, h^2 0.19）。

推导 25.3 α 模型与 GRM 的权重

令 $\beta_j \sim N(0, \sigma^2[2p_jq_j]^\alpha)$, $g = \sum_j \tilde{x}_j\beta_j$ ($\tilde{x}_j$ 为中心化基因型, $\text{Var}(\tilde{x}_j) = 2p_jq_j$)。则 $\text{Cov}(g_i, g_{i'}) = \sigma^2 \sum_j [2p_jq_j]^\alpha \tilde{x}_{ij}\tilde{x}_{i'j}$, $\text{Var}(g_i) \approx \sigma^2 \sum_j [2p_jq_j]^{1+\alpha}$ 。定义 $G_\alpha = \sum_j [2p_jq_j]^\alpha \tilde{x}_j\tilde{x}_j' / \sum_j [2p_jq_j]^{1+\alpha}$ 。 $\alpha = -1$: 每个位点的标准化效应方差相等, G_{-1} 即标准 GRM (习题 25.18 核验); $\alpha = 0$: 每个等位基因效应方差相同, 常见变异方差贡献更大; $\alpha > 0$: 常见变异贡献更大; $\alpha < -1$: 稀有变异贡献更大。若真实 α 与用于构建 GRM 的 α 不一致, 遗传力估计的偏差一般不大但不为零: 习题 25.18 中真 $\alpha = -1$ 、用 $\alpha = 1$ 时平均偏差为 0.133, 用正确 α 为 0.022。限制似然对 α 的区分力很弱—— $n = 800$ 、 $m = 2500$ 下, 真 $\alpha = -0.25$ 与 0.5 的剖面峰值几乎重合 (平均网格峰值均为 -0.12)。

推导 25.4 病例—对照资料的液态变量遗传力

D-L 换算。总体观测尺度 (0/1) 遗传力 $h_o^2 = h_l^2 z^2 / [K(1-K)]$ (见第 24 章推导 24.4)。

富集校正。以病例比例 P 抽样后, 观测尺度的性状方差由 $K(1-K)$ 变为 $P(1-P)$ 。把 $P(y = 1 | g)$ 对 g 线性化, 斜率 b 在样本内变为 $bP(1-P)/[K(1-K)]$ (病例与对照的相对抽样概率改变几率的尺度)。样本内遗传方差为 $b^2[P(1-P)/K(1-K)]^2\sigma_g^2$, 除以 $P(1-P)$ 得

$$h_{o,s}^2 = h_o^2 \cdot \frac{P(1-P)}{K(1-K)},$$

即富集抬高观测尺度遗传力。故由样本内估计 $\hat{h}_{o,s}^2$ 反推: $h_l^2 = \hat{h}_{o,s}^2 \cdot \frac{K(1-K)}{P(1-P)} \cdot \frac{K(1-K)}{z^2}$ 。习题 25.20: $K = 0.05$ 、 $P = 0.5$, $z = 0.1031$, D-L 因子 $K(1-K)/z^2 = 4.47$, 富集因子 $P(1-P)/[K(1-K)] = 5.26$; 样本内 $\hat{h}_o^2 = 0.591$ 是总体观测尺度 0.114 的 5.2 倍, 完整换算得 0.501 (真值 0.5)。仅做 D-L 换算则得 2.64, 荒谬; 不换算的 0.591 看似接近真值, 其实是 5.26 倍抬高与 4.47 倍的 D-L 压缩恰好近似抵消的巧合。

推导 25.5 多组分 REML 的得分、平均信息与组分遗传力的标准误

对 $V = \sum_{k=1}^K \sigma_k^2 G_k + \sigma_e^2 I$, 得分 $s_k = -\frac{1}{2}[\text{tr}(PG_k) - y'PG_kPy]$, 平均信息 $\text{AI}_{kl} = \frac{1}{2}y'PG_kPG_lPy$ (见第 23 章)。迭代 $\sigma \leftarrow \sigma + \text{AI}^{-1}s$ 。分量遗传力 $h_k^2 = \sigma_k^2 / \sum \sigma^2$ 的方差用 delta 法: $\partial h_k^2 / \partial \sigma_l^2 = \delta_{kl} / V_P - \sigma_k^2 / V_P^2$, $\text{Var}(\hat{h}_k^2) \approx J_k \text{AI}^{-1} J_k'$ 。习题 25.19 ($n = 900$, 三个 MAF 区间, 真 $h^2 = (0.10, 0.15, 0.25)$): 平均估计 (0.093, 0.178, 0.237), 重复

间 SD (0.039, 0.038, 0.059), 平均 AI-SE (0.041, 0.052, 0.059), 总 $\hat{h}^2 = 0.509$ (单组分 0.482)。方差组分与残差方差的抽样相关平均为 $-0.40, -0.48, -0.56$: 总表型方差由数据较好地确定, 组分之间与残差之间“借方差”。

拓展阅读 SNP 遗传力、LDSC 与 LDAK

Yang 等 (2010) 用 GREML 估计身高的 SNP 遗传力约 0.45, 揭示“缺失遗传力”大部分来自未达显著的常见变异; Yang 等 (2015) 与 Wainschtein 等 (2022) 指出稀有变异对全基因组测序的 GREML 的贡献。Bulik-Sullivan 等 (2015) 提出 LDSC, Speed 等 (2012, 2017) 发展了考虑 LD 与 MAF 的权重 (LDAK)。关于 α 与分层 GREML 的比较见 Evans 等 (2018)。观测尺度到液态变量尺度的换算来自 Dempster 与 Lerner (1950) 及 Lee 等 (2011)。

易错辨析

- GREML 估计的是 GRM 所能捕获的遗传方差: 稀有致因变异不在芯片上, 估计偏低 (习题 25.16: 稀有变异下 $\hat{h}^2$ 仅 0.048, 而真值 0.5)。
- 近亲不是“多一点信息”: 同胞共同环境使 $\hat{h}^2$ 从 0.480 升至 0.597 (习题 25.15)。
- LDSC 截距接近 1 不证明无分层: M 小时截距标准误很大 (刀切 SE 0.258)。
- α 难以识别: 不要从有限样本的剖面峰值读出“真 α ”。
- 不要只报观测尺度遗传力: 必须说明总体患病率、样本病例比例与所做的换算。
- 组分遗传力之间不是独立的: 它们与残差负相关, 分层结果要整体解读。

25.5 习题

一、单项选择题

- 25.1 ★ [单选] 在无亲缘个体的 GREML 或 HE 回归中, 遗传力估计的精度主要取决于
- (A) 表型的偏度 (B) 个体数与 GRM 非对角元的方差 (C) 染色体数
- (D) 系谱深度

[答案]

25.2 ★ [单选] 关于 LD 分数回归的截距, 下列说法正确的是

- (A) 截距必然等于 1
- (B) 截距大于 1 可能来自分层、亲缘或其他与 LD 无关的混杂
- (C) 截距越大遗传力越高
- (D) 截距与样本量无关

[答案]

25.3 ★★ [单选] 样本中混入全同胞对并且同胞共享共同环境时, GREML 的 $\hat{h}^2$

- (A) 偏低
- (B) 无偏
- (C) 偏高
- (D) 方向不定

[答案]

25.4 ★★ [单选] 若致因变异主要为稀有变异 ($MAF < 1\%$), 仅用常见变异芯片的 GREML 估计

- (A) 接近真值
- (B) 远低于真值
- (C) 高于真值
- (D) 不受影响

[答案]

25.5 ★★ [单选] α 模型中 $\alpha = 0$ 表示

- (A) 每个标准化 SNP 同方差
- (B) 每个等位基因效应方差相同
- (C) 没有遗传方差
- (D) 只有稀有变异有效应

[答案]

25.6 ★★★ [单选] 病例比例 $P = 0.5$ 、总体患病率 $K = 0.05$ 的病例—对照资料, 样本内观测尺度遗传力与总体观测尺度相比

- (A) 相等
- (B) 被富集抬高约 $P(1 - P)/[K(1 - K)]$ 倍
- (C) 被压低
- (D) 方向不定

[答案]

二、判断与改错题

25.7 ★ [判断] HE 回归与 GREML 的期望相同, 但在无亲缘样本中 HE 的标准误更大。

[答案]

25.8 ★ [判断] LDSC 的截距等于 1 说明资料中没有分层。

[答案]

25.9 ★★ [判断] 在没有混杂时, SNP 遗传力的目标值一般不超过窄义遗传力。 [答案]

25.10 ★★ [判断] MAF 分层 GREML 中, 各区间的遗传力估计相互独立。 [答案]

三、填空题

25.11 ★ [填空] $n = 5000$ 、独立位点 $M = 50000$, HE 回归的理论标准误约为 _____ (三位小数)。 [答案]

25.12 ★ [填空] GWAS 平均 $\chi^2 = 1.5$, 截距 1, $N = 10^5$, $M = 10^6$, 平均 LD 分数 50, 则 $h_{SNP}^2 =$ _____。 [答案]

25.13 ★★ [填空] $K = 0.01$ 、 $P = 0.5$: $z = 0.02665$, D-L 因子 $K(1-K)/z^2 =$ _____, 富集因子 $K(1-K)/[P(1-P)] =$ _____, 总换算系数 = _____。 [答案]

25.14 ★★ [填空] 标准 GRM ($\alpha = -1$) 下 $MAF=0.05$ 与 $MAF=0.5$ 的位点, 原始 (未标准化) 效应方差之比 $\text{Var}(\beta_{0.05})/\text{Var}(\beta_{0.5}) =$ _____ (保留两位小数)。 [答案]

四、计算题

25.15 ★★ [计算] GREML 与 HE 回归。1000 个无亲缘个体、2000 个 SNP、真 $h^2 = 0.5$, 比较 GREML 与 HE 的均值、重复间 SD、曲率 SE 与理论 SE; 再加入 250 对全同胞 (共同环境 $c^2 = 0.25$), 比较“全部保留”与“剔除 $G_{jk} > 0.15$ 的一方”。 [程序] `ch25/ex25_15_greml_he.py` [答案]

25.16 ★★★ [计算] 致因变异频率与捕获。单倍型马赛克模型, 芯片仅含常见 SNP, 致因变异分别为常见、低频、稀有, 用 GREML 与 HE 估计 h^2 , 并报告最大 r^2 与捕获比例。 [程序] `ch25/ex25_16_causal_frequency.py` [答案]

25.17 ★★★ [计算] LD 分数回归。 $M = 3000$ 个含块内 LD 的 SNP、 $n = 4000$, 比较纯多基因与含分层两种情形的加权 LDSC 截距、 h^2 、刀切 SE, 并核验平均 χ^2 与式 25.4 的预测。 [程序] `ch25/ex25_17_ldsc.py` [答案]

25.18 ★★★ [计算] α 模型。 $n = 800$, $m = 2500$, 真 $\alpha \in \{-1, -0.25, 0.5\}$: 在 α 网格上做 GREML, 比较各 α 下的 $\hat{h}^2$ 、对数似然与剖面峰值。 [程序] `ch25/ex25_18_alpha_model.py` [答案]

25.19 ★★★ [计算] MAF 分层 GREML。 $n = 900$, 三个 MAF 区间, 真 $h^2 = (0.10, 0.15, 0.25)$, 用自写 AI-REML 估计各分量, 核验解析得分, 报告 SE 与组分间相关。 [程序] `ch25/ex25_19_partition_maf.py` [答案]

25.20 ★★★ [计算] 液态变量尺度换算。总体 $K = 5\%$, 病例 1000、对照 1000, 比较观测尺度、仅 D-L 换算与完整换算得到的液态变量遗传力。 [程序] `ch25/ex25_20_liability_scale.py` [答案]

25.21 ★ [计算] $n = 4000$ 、 $\text{Var}(G_{jk}) = 2.5 \times 10^{-5}$, 求 HE 回归的理论标准误; 若要把 SE 降到 0.02, 需要多少个体? [答案]

25.22 ★★ [计算] 某 GWAS: $N = 50000$, $M = 5 \times 10^5$, 平均 $\chi^2 = 1.8$, 平均 LD 分数 40。
(1) 若截距为 1, 求 h_{SNP}^2 ; (2) 若截距为 1.2, 求 h_{SNP}^2 以及“平均 χ^2 超额部分”中由混杂贡献的比例。 [答案]

五、推导与证明题

25.23 ★★ [证明] 证明: 独立位点、标准化基因型下无亲缘个体的 $\text{Var}(G_{jk}) = 1/M$, 并由此推出 HE 回归的标准误近似为 $\sqrt{2M}/n$ 。 [答案]

25.24 ★★★ [证明] 在 $\beta_k \sim N(0, h^2/M)$ 的多基因模型下证明 $E(\chi_j^2) = 1 + Nh^2\ell_j/M$, 并说明加入混杂项后的截距为 $1 + Na$ 。 [答案]

25.25 ★★★ [证明] 设线性化模型 $P(y = 1 | g) \approx K + bg$, 抽样比为 s_1/s_0 。证明样本内观测尺度遗传力 $h_{o,s}^2 = h_o^2 \cdot P(1 - P)/[K(1 - K)]$, 并得到完整换算公式。 [答案]

25.26 ★★★ [证明] 设 GRM 未标准化, $\overline{\text{diag } G} = c$ 。证明 REML 的遗传方差估计 $\hat{\sigma}_g^2$ 随 $G \rightarrow aG$ 缩放为 $\hat{\sigma}_g^2/a$, 并说明 $h_{SNP}^2 = c\hat{\sigma}_g^2/(c\hat{\sigma}_g^2 + \hat{\sigma}_e^2)$ 对缩放不变。 [答案]

六、综合分析与研究设计题

25.27 ★★ [综合] 某肉羊群体含大量全同胞与半同胞 (N_e 小)。设计估计 SNP 遗传力的方案: 样本处理、GRM 构建、模型、与系谱遗传力的对照和结果解释。 [答案]

25.28 ★★★ [综合] 某性状的系谱遗传力 0.60, 常见 SNP 的 GREML 估计 0.28, GWAS 显著位点解释 0.04。从致因变异频率、非加性、共同环境和估计偏倚四方面解释差距, 并设计检验。 [答案]

25.29 ★★★ [综合] 某疾病的 GWAS 汇总统计量平均 χ^2 为 1.6, LDSC 截距 1.15 (SE 0.04)。设计分析判断截距 1.15 是分层、亲缘还是多基因信号的混合, 并给出下一步行动。

[答案]

25.6 参考答案与解析

一、单项选择题

25.1 B. 理论标准误 $\sqrt{2/[n^2 \text{Var}(G_{jk})]}$ (见推导 25.1)。习题 25.15: $n = 1000$ 时 SE 0.060。 [题目]

25.2 B. 截距为 $1 + Na$, 分层、隐性亲缘、批次效应等与 LD 无关的结构都可使其大于 1; 但截距不能解读为遗传力。习题 25.17: 分层下载距 2.17。 [题目]

25.3 C. 同胞共享共同环境, G_{jk} 大的对同时表型相似, 被误当作遗传。习题 25.15: 全部保留 0.597, 剔除后 0.480。 [题目]

25.4 B. 稀有变异与芯片 SNP 的最大 r^2 很低, GRM 捕获不到。习题 25.16: 稀有致因变异下 $\hat{h}^2 = 0.048$ (真值 0.5), 最大 $r^2 = 0.016$ 。 [题目]

25.5 B. $\text{Var}(\beta_j) \propto (2pq)^0$, 每个等位基因同等; $\alpha = -1$ 才是每个标准化位点同方差。 [题目]

25.6 B. 见推导 25.4。习题 25.20 中富集因子 5.26, 样本内 $\hat{h}_o^2 = 0.591$, 总体观测尺度 0.114。 [题目]

二、判断与改错题

25.7 正确。 习题 25.15: GREML 重复间 SD 0.058, HE 为 0.078 (HE 均值 0.509, GREML 0.504)。 [题目]

25.8 错误。 截距接近 1 的标准误可能很大: 习题 25.17 纯多基因下载距 1.067 ± 0.258 (刀切 SE), 不能排除 $a > 0$; 而且分层与多基因信号可同时存在。 [题目]

25.9 正确 (目标值)。 SNP 遗传力的目标值是被 GRM 捕获的加性方差，一般不超过窄义遗传力；但**估计值**可因近亲、共同环境或分层而高于窄义遗传力（习题 25.15）。

[题目]

25.10 错误。 各分量与残差方差负相关（习题 25.19：-0.40, -0.48, -0.56），组分估计之间也因总方差约束而共同波动；应联合解读并报告协方差。

[题目]

三、填空题

25.11 $SE = \sqrt{2M/n} = \sqrt{100000/5000} = \mathbf{0.0632}$ 。

[题目]

25.12 $h^2 = (\bar{\chi}^2 - 1)M/(N\bar{\ell}) = 0.5 \times 10^6 / (10^5 \times 50) = \mathbf{0.10}$ 。

[题目]

25.13 D-L 因子 = 0.0099/0.0007103 = **13.94**；富集因子 = 0.0099/0.25 = **0.0396**；总系数 = **0.552**。即样本内观测尺度遗传力乘 0.552 得液态变量尺度。

[题目]

25.14 标准化后效应方差相同，原始效应方差 $\propto 1/(2pq)$ ：(0.5/0.095) = **5.26** 倍。低频位点的原始效应要大 5.26 倍的方差才能与常见位点贡献相同的遗传方差。

[题目]

四、计算题

25.15 A. 无亲缘个体（12 次重复）：

方法	均值	重复间 SD	平均曲率 SE
GREML	0.504	0.058	0.059
HE	0.509	0.078	—

$\text{Var}(G_{jk}) = 5.55 \times 10^{-4}$ (理论 5.56×10^{-4})，理论 $SE = \sqrt{2/(10^6 \cdot 5.56 \times 10^{-4})} = 0.060$ 。

B. 250 对全同胞， $c^2 = 0.25$ （4 次重复）：全部保留 $\hat{h}^2 = 0.597$ ；剔除 $G_{jk} > 0.15$ 的一方（平均保留 750 人）0.480。解读：近亲抬高 $\hat{h}^2$ 约 0.1；剔除后恢复到真值附近，代价是样本量由 1000 降到 750（SE 增大约 15%）。

[题目]

25.16 $n = 1200$ ，真 $h^2 = 0.5$ ，300 个致因变异，3 次重复，芯片含约 2000 个常见 SNP：

致因变异	GREML 均值	SD	HE 均值	平均最大 r^2	捕获比例
常见 (MAF $\geq$ 0.05)	0.383	0.029	0.310	0.567	0.77
低频 (0.01–0.05)	0.039	0.013	0.035	0.080	0.08
稀有 (MAF $<$ 0.01)	0.048	0.012	0.048	0.016	0.10

解读：常见变异的捕获比例 (0.77) 与最大 r^2 (0.567) 有同一量级，GREML 估计 0.383 约为 0.5×0.77 ；低频、稀有变异下几乎捕获不到。因此“SNP 遗传力 < 系谱遗传力”并不意味着性状主要由环境决定，而是芯片对致因变异的覆盖不足。HE 的估计比 GREML 低 (0.310 vs 0.383)，也是信息损失的体现。 [题目]

25.17 $M = 3000$, $n = 4000$, 参照样本 1500, 平均 LD 分数 $\bar{l} = 1.67$ (范围 0.99—7.18), 16 次重复 (加权 LDSC, 按块刀切):

情形	平均 χ^2 (预测)	截距 (重复 SD / 刀切 SE)	$\hat{h}^2$ (重复 SD / 刀切 SE)
A 纯多基因	2.064 (2.116)	1.067 (0.319 / 0.258)	0.461 (0.193 / 0.161) 真值 0.5
B 多基因 + 分层	3.005	2.172 (0.915 / 0.304)	0.371 (0.204 / 0.185)

解读：均值式 25.4 与预测一致 (偏差 2.5%); 纯多基因下截距接近 1, 分层使截距升到 2.17、平均 χ^2 升至 3.0。但 $M = 3000$ 的 SE 太大, h^2 的 95% 区间约 [0.15, 0.78], 不足以得出精确结论。普通最小二乘 (未加权) 在同样设定下会得到 $h^2 \approx 0.28$ 与截距 1.41 的偏差估计, 说明加权的重要性。 [题目]

25.18 $n = 800$, $m = 2500$, 8 次重复; 表中为“ $\hat{h}^2$ 均值 / 对数似然相对 $\alpha = -1$ 的均值”:

用于 GRM 的 α	真 $\alpha = -1$	真 $\alpha = -0.25$	真 $\alpha = 0.5$
-1.5	0.458 / -2.0	0.409 / -6.0	0.466 / -6.0
-1.0	0.505 / 0	0.515 / 0	0.557 / 0
-0.5	0.478 / -1.1	0.530 / +2.2	0.562 / +1.8
0.0	0.436 / -2.7	0.513 / +2.4	0.541 / +1.8
0.5	0.399 / -4.0	0.488 / +2.0	0.516 / +1.3
1.0	0.367 / -5.2	0.464 / +1.4	0.492 / +0.7
网格峰值均值	-0.94	-0.12	-0.12

解读：真 $\alpha = -1$ 时对数似然在 $\alpha = -1$ 处最高, 偏离 1.0 的 $\hat{h}^2$ 偏低 0.13; 真 $\alpha = -0.25$ 与 0.5 时似然曲面在 -0.5 到 0 间极平 (差不到 0.6 个对数似然单位), 不能区分。结论：用标准 GRM 估计遗传力对 α 的误设并不敏感 (偏差 ≤ 0.13), 但从有限样本读出 α 本身是困难的。 [题目]

25.19 $n = 900$, $m = 3000$, AI-REML (10 次重复), 起点解析得分 (-27.35, 23.17, 43.12, 50.75) 与数值梯度一致:

MAF 区间	真 h^2	均值	重复 SD	平均 SE
0.05–0.15	0.10	0.093	0.039	0.041
0.15–0.30	0.15	0.178	0.038	0.052
0.30–0.50	0.25	0.237	0.059	0.059

总 $\hat{h}^2 = 0.509$ (真 0.50); 对所有 SNP 构建一个 GRM 的单组分估计为 0.482。各分量与残差的 AI 相关为 $-0.40, -0.48, -0.56$ 。解读: AI 标准误与重复间 SD 的比为 0.9—1.4, 大体可靠; 区间越宽、方差越大的分量其 SE 越小; h^2 的分割在 $n < 10^3$ 时很粗糙, 只能得出“各区间大致占多少”。

[题目]

25.20 $K = 0.05$, $z = 0.1031$, $P = 0.5$ (1000 病例 +1000 对照, 16 次重复): 总体观测尺度 h_o^2 模拟 0.1136, D–L 预测 0.1120 (真 $h_l^2 = 0.5$)。

方法	均值	重复 SD	与真值之差
(a) 样本内观测尺度, 不换算	0.591	0.033	+0.091
(b) 仅 D–L 换算	2.638	0.148	+2.138
(c) 完整换算 (含富集)	0.501	0.028	+0.001

解读: 样本内观测尺度 $\hat{h}_o^2$ 是总体观测尺度的 5.2 倍 (富集抬高); (a) 看似接近真值, 是巧合——5.26 倍的抬高与 1/4.47 的 D–L 压缩近似抵消, 换了 K 与 P 就会失灵 (如 $K = 0.01$ 、 $P = 0.5$ 总系数为 0.552); (b) 完全错误; 只有 (c) 在不同 K, P 下都正确。

[题目]

25.21 $SE = \sqrt{2/(n^2 \text{Var})} = \sqrt{2/(1.6 \times 10^7 \times 2.5 \times 10^{-5})} = \sqrt{0.005} = \mathbf{0.0707}$ 。要降到 0.02: $n^2 = 2/(0.02^2 \times 2.5 \times 10^{-5}) = 2 \times 10^8$, $n = \mathbf{14142}$ 。SE 与 n 成反比: 把 SE 降为原来的 0.283 需要样本量增为 3.5 倍。

[题目]

25.22

(1) $h^2 = (1.8 - 1) \times 5 \times 10^5 / (5 \times 10^4 \times 40) = \mathbf{0.20}$ 。(2) $h^2 = (1.8 - 1.2) \times 5 \times 10^5 / (2 \times 10^6) = \mathbf{0.15}$; 混杂占平均 χ^2 超额部分的 $(1.2 - 1)/(1.8 - 1) = \mathbf{25\%}$ 。把截距当作 1 会把遗传力高估约三分之一。

[题目]

五、推导与证明题

25.23 证明。 $G_{jk} = \frac{1}{M} \sum_{l=1}^M z_{jl}z_{kl}$, 无亲缘个体 $j \neq k$ 时 z_{jl} 、 z_{kl} 独立, $E(z_{jl}z_{kl}) = 0$, $\text{Var}(z_{jl}z_{kl}) = E(z_{jl}^2)E(z_{kl}^2) = 1$ 。位点独立时各项独立, 故 $\text{Var}(G_{jk}) = M \cdot 1/M^2 = 1/M$ 。代入推导 25.1 的 $\text{SE} \approx \sqrt{2/[n^2 \text{Var}(G_{jk})]} = \sqrt{2M}/n$ 。■ [题目]

25.24 证明。 见推导 25.2: $\hat{\beta}_j = \sum_k r_{jk}\beta_k + \hat{e}_j$, 其中 $\text{Var}(\hat{e}_j) \approx (1-h^2)/N \approx 1/N$ (h^2 小或忽略自身贡献的二阶项)。对 β 取期望: $E[\hat{\beta}_j^2] = \sum_k r_{jk}^2 \text{Var}(\beta_k) + 1/N = h^2\ell_j/M + 1/N$, 乘 N 得 $1 + Nh^2\ell_j/M$ 。若存在不依赖于 ℓ_j 的混杂, 使 $\hat{\beta}_j$ 有额外方差 a , 则 χ_j^2 增加 Na 。■ [题目]

25.25 证明。 总体中 $\text{Var}(y) = K(1-K)$, 遗传部分 $b^2\sigma_g^2$, 故 $h_o^2 = b^2\sigma_g^2/[K(1-K)]$ 。抽样改变条件几率: $\text{odds}^* = (s_1/s_0)\text{odds}$ 。在病例比例为 P 的样本内, $P(y=1|g)$ 对 g 的斜率为 $b^* = bP(1-P)/[K(1-K)]$ (对数几率斜率不变, 概率斜率与 $p(1-p)$ 成比例)。样本内遗传方差 $b^{*2}\sigma_g^2$, 样本方差 $P(1-P)$:

$$h_{o,s}^2 = \frac{b^2\sigma_g^2[P(1-P)]^2}{[K(1-K)]^2P(1-P)} = h_o^2 \cdot \frac{P(1-P)}{K(1-K)}.$$

再用 D-L, $h_l^2 = h_o^2K(1-K)/z^2$, 合并得 $h_l^2 = h_{o,s}^2 \frac{K(1-K)}{P(1-P)} \frac{K(1-K)}{z^2}$ 。习题 25.20 数值核验: $0.591 \times 0.190 \times 4.47 = 0.50$ 。■ [题目]

25.26 证明。 $V = \sigma_g^2G + \sigma_e^2I = (\sigma_g^2/a)(aG) + \sigma_e^2I$ 。把 G 换成 aG , 则似然在 $(\sigma_g^2, \sigma_e^2) \rightarrow (\sigma_g^2/a, \sigma_e^2)$ 处取同一值, 故最大似然 (REML) 估计 $\hat{\sigma}_g^2 \rightarrow \hat{\sigma}_g^2/a$, $\hat{\sigma}_e^2$ 不变。遗传力定义为 $\text{Var}(g_i)$ 的平均除以总方差: $\text{Var}(g_i) = \sigma_g^2G_{ii}$, 平均为 $c\hat{\sigma}_g^2$ 。缩放后 $c \rightarrow ac$, $\hat{\sigma}_g^2 \rightarrow \hat{\sigma}_g^2/a$, 乘积 $c\hat{\sigma}_g^2$ 不变, 所以 $h_{SNP}^2 = c\hat{\sigma}_g^2/(c\hat{\sigma}_g^2 + \hat{\sigma}_e^2)$ 对缩放不变。若直接用 $\hat{\sigma}_g^2/(\hat{\sigma}_g^2 + \hat{\sigma}_e^2)$, 则当 $c \neq 1$ 时错误。■ [题目]

六、综合分析与研究设计题

25.27 方案 (1) 样本: 同胞、半同胞多, GRM 的近亲分量混入共同环境与长 IBD 片段 (习题 25.15: 0.597 vs 0.480); 保留尽量多的不相关个体, 并为剩余近亲建立单独的家系分量。(2) GRM: 对 N_e 小的群体, 常见变异间 LD 长, 标准 GRM 的有效独立位点 M_e 很小, 会使 $\text{Var}(G_{jk})$ 大于 $1/M$; 用真实 $\text{Var}(G_{jk})$ (习题 25.15: 5.55×10^{-4} 对 5.00×10^{-4}) 计算 SE。(3) 模型: 多组分——全基因组 GRM (SNP 遗传力) + 系谱 A 或近亲 GRM + 场年季、共同环境项; 比较单组分与多组分的对数似然。(4) 对照: 系谱遗传力来自全部系谱与 A ; SNP 遗传力 $\leq$ 系谱遗传力, 二者之差反映未被捕获的变异与近亲共享。(5) 解释: 不能把差距全归于“缺失遗传力”, 必须

分别评估共同环境、非加性与估计偏倚（习题 25.16 的捕获比例）。(6) 报告： $\hat{h}^2$ 与 SE、GRM 剔除阈值、多组分的对数似然与组分协方差（习题 25.19：与残差 -0.40 至 -0.56 ）。

【题目】

25.28 分析 (1) 致因变异频率：芯片只捕获常见变异，稀有致因变异使 $\hat{h}_{SNP}^2$ 偏低（习题 25.16：稀有变异下 0.048）；用全基因组测序与 MAF/LD 分层（习题 25.19）检验。(2) 非加性：系谱遗传力（来自同胞、亲子比较）若含显性、上位或母体效应，会高于 SNP 遗传力。用含显性 GRM 与母体项的多组分模型检验。(3) 共同环境：系谱遗传力来自近亲相似，被共同环境抬高；用寄养、跨群体或不同环境下的亲属比较。(4) 估计偏倚：GREML 的 α 误设、近亲、分层（习题 25.15、25.18）。**检验**：用测序资料构建稀有变异 GRM，估计其增加的遗传力；比较 $\hat{h}_{SNP}^2$ 在剔除近亲、不同 α 下的稳定性；估计 GWAS 显著位点的 $\hat{h}^2$ 以确认 0.04 的量级。结论只能表述为“差距的可能来源及其大小范围”，不能指定唯一原因。

【题目】

25.29 分析 (1) LDSC 的 $\bar{\chi}^2 = 1.6$ ，截距 1.15 (SE 0.04)：超额 $\bar{\chi}^2 - 1 = 0.6$ 中约 25% (0.15/0.6) 来自截距，75% 由 LD 分数相关的信号解释（习题 25.22 同理）。(2) 截距 > 1 的来源：分层、隐性亲缘、批次，或多基因信号与 LD 的复杂交互使线性 LD 分数模型失效（习题 25.17：纯多基因下 1.067 ± 0.258 ）。(3) 检验：使用前几个主成分与混合线性模型重新做 GWAS，看截距是否下降；对不同 MAF/LD 分箱的 LDSC 比较；比较不同祖先群体的截距；亲缘关系推断 (IBD) 找隐性亲缘。(4) h^2 ：用 $(\bar{\chi}^2 - \text{截距})M/(N\bar{\ell})$ 而不是 $(\bar{\chi}^2 - 1)$ 计算，并给出刀切 SE。(5) 下一步：若混杂主要为分层，改用 PCA 或 LMM 并重算；若为亲缘，剔除近亲；若多基因信号占主导则不需要作为问题处理。**注意**：截距高并不意味着“GWAS 无效”，而是遗传力与关联的解释要扣除混杂部分。

【题目】

基因型质量控制与基因组关系矩阵

26.1 本章导学

学习目标

- 1. 能把基因型从“实验读数”到“可用于建模的剂量”的链条拆成可检验的环节：样本身份、位点质量、缺失与测量不确定性。
- 2. 会用孟德尔对立纯合冲突检验亲子关系, 推导非亲子的期望冲突率, 并选择 SNP 数与阈值。
- 3. 理解精确哈迪—温伯格检验的构造、等位基因脱扣与群体分层 (Wahlund 效应) 对检验的不同影响。
- 4. 会写出低深度测序的基因型似然、后验剂量及其校准性质, 并校正剂量 GRM 的对角元。
- 5. 掌握 VanRaden 关系矩阵与系谱矩阵的尺度相容问题: 基群频率与样本频率、行和为零、线性相容化。
- 6. 证明频率误差对含截距 GBLUP 的不变性定理, 并识别它失效的情形 (批内中心化、杂合子缺失)。

重点与难点

重点: 对立纯合冲突率 $2p^2q^2$; 精确 HWE 检验的条件分布; 后验剂量 $E(x \mid \text{reads})$ 与对角元校正 $+\sum_j \text{Var}(x_{ij} \mid \cdot)/s$; $G_{\hat{p}} = G_p + (1a' + a1')$ 的结构; 均值填补使对角元缩小 $(1-f)$ 。

难点: 区分“只改变常数/尺度”的误差与“改变排序”的误差; MNAR 缺失; 跨批合并时参照频率的选择。

本章承接第 25 章 (基因组遗传力) 并为第 27 章 (GBLUP、岭回归与核方法) 备料: 任何基因组预测模型都把基因型矩阵当作已知、无误差、可比较的量, 而本章讨论这些前提何时成立。基因型的误差并不总是有害的——有些误差被固定效应精确吸收, 有些则破坏排序。

26.2 知识结构图




图 26.1 第 26 章知识结构图

上半部分是原始数据的质量（身份、位点、测量），下半部分是由基因型到关系矩阵的转换与误差传播。

26.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
对立纯合冲突率	非亲子: $\sum_j 2p_j^2 q_j^2 / m$	双亲独立、HWE; 亲子对（无误差）为 0
精确 HWE 检验	$P(n_{ab} n_a) \propto \frac{n! 2^{n_{ab}}}{n_{aa}! n_{ab}! n_{bb}!}$	条件于等位基因计数
杂合度缺失	$F = 1 - H_{obs} / H_{exp}$	Wahlund: $F \approx F_{ST}(K - 1) / K$
杂合子脱扣	$H_{obs} = (1 - d) 2pq$	检出率随 d 与 MAF 增
基因型似然	$P(\text{reads} x) = \pi_x^a (1 - \pi_x)^{k-a}$, $\pi_x = \frac{x}{2} (1 - \varepsilon) + (1 - \frac{x}{2}) \varepsilon$	读段独立
后验剂量	$d = E(x \cdot), v = \text{Var}(x \cdot)$	HWE 先验
对角元校正	$G_{ii}^c = G_{ii}^{(d)} + \sum_j v_{ij} / s$	非对角元无需校正
VanRaden G	$WW' / s, s = 2 \sum p_j q_j$	p 的来源决定参照
样本频率 G	$G_s 1 = 0, \overline{G}_{ij} = -\overline{G}_{ii} / (n - 1)$	行列和为零

概念	公式或定义	成立条件与提示
相容化	$G^* = a + bG_s$	使平均对角、非对角与 A 一致
均值填补	对角元 $\times(1-f)$, 非对角 $\times(1-f)^2$	MCAR
频率误差分解	$G_{\hat{p}} = [G_p s + 1t' + t1' + \ \delta\ ^2 11']/\hat{s}$	$t = W\delta$, $\delta = 2(p - \hat{p})$
不变性	$\hat{u}^* = \hat{u} + c1$	含固定截距, 方差重估

26.4 补充内容与公式推导

推导 26.1 对立纯合冲突与亲子鉴定的阈值

单位点, 等位基因频率 p ($q = 1 - p$)。亲代 A 与子代 B 若是真亲子, 子代必从亲代获得一个等位基因, 故 (AA, aa) 与 (aa, AA) 不可能同时出现, 冲突率为 0 (忽略分型误差与突变)。若 A 、 B 无亲缘, 则 $P(AA)P(aa) + P(aa)P(AA) = 2p^2q^2$ 。对 m 个独立位点, 冲突数 C 服从二项分布, 期望 $m\bar{r}$, $\bar{r} = \frac{1}{m} \sum_j 2p_j^2q_j^2$ 。分型误差率 ε 使真亲子出现伪冲突, 其速率约 $O(\varepsilon)$ 。习题 26.15: $p \sim U(0.05, 0.5)$, $m = 2000$, 理论冲突率 0.07455, 无误差模拟 0.07391 (差 0.9%)。取阈值为真亲子冲突率的 99.5% 分位, 则需要的 SNP 数由两分布的分离度决定: $m = 30$ 时 AUC 仅 0.924 (检出率 60.5%), $m = 100$ 时 0.999, $m \geq 200$ 时 1.000。高误差样本 (占 16%) 会拉高阈值: 剔除后阈值由 0.0146 降到 0.0065 (降 56%)。

推导 26.2 精确 HWE 检验、脱扣与 Wahlund 效应

给定样本 n 与 A 等位基因总数 n_a , 杂合子数 h 的条件分布为

$$P(h | n, n_a) = \frac{n! 2^h}{n_{aa}! h! n_{bb}!} / \binom{2n}{n_a}, \quad n_{aa} = \frac{n_a - h}{2}, \quad n_{bb} = n - h - n_{aa}.$$

p 值为概率不超过观测值的所有 h 的概率之和。Wigginton 等 (2005) 的递推 $P(h-2) = P(h) \frac{h(h-1)}{4(n_{aa}+1)(n_{bb}+1)}$ 把计算降为 $O(n_a)$; 习题 26.16 与完全枚举 ($n = 30$ 的所有计数) 的最大相对差为 1.7×10^{-14} 。**稀有等位基因**: $n = 1000$ 、MAF = 0.01 时卡方检验的实际水平为 0.019 (名义 0.001), 精确检验为 0 (保守)。**脱扣**: 杂合子以概率 d 被判成纯合子, $H_{obs} = (1-d)2pq$; $n = 1000$ 、 $\alpha = 0.001$ 下, $d = 0.10$ 的检出率为 0.10 (MAF 0.01)、0.35 (MAF 0.10)、0.44 (MAF 0.5)。**Wahlund**: K 个各自平衡、频率方差为 $F_{ST}\bar{p}\bar{q}$ 的亚群混合后, $H_{obs}/H_{exp} \approx 1 - F_{ST}(K-1)/K$ (样本方差除以 K); $F_{ST} = 0.05$ 、 $K = 4$ 时期望缺失 0.0375, 模拟 0.0379, 此时检验检出率 7.0%——分层会被 HWE 检验当作“分型错误”。

推导 26.3 后验剂量的校准性与对角元校正

记读段数据为 r , $d = E(x | r)$, $v = \text{Var}(x | r)$ 。由全期望, $E[x | d] = d$ (对 r 的任一函数条件化均成立), 所以真值对剂量的回归斜率为 1——**校准**; 习题 26.17 在 $\lambda = 0.5, \dots, 20$ 的所有深度, 校准斜率均为 1.000。由 $E(x^2 | r) = d^2 + v$, 若用剂量代替基因型计算 $G_d = W_d W'_d / s$, 则 $E(G_{d,ii}) = E(G_{ii}^*) - \sum_j E(v_{ij})/s$: 对角元偏小, 偏小量为不确定性的平均。 $i \neq i'$ 时 $E(d_{ij}d_{i'j}) = E(x_{ij}x_{i'j})$ (独立信息), 非对角元无此偏小, 但后验收缩使非对角元对真值的回归斜率 < 1 。校正后 $G_{ii}^c = G_{d,ii} + \sum_j v_{ij}/s$ 。习题 26.17: $\lambda = 0.5$ 时 $\bar{G}_{d,ii} = 0.2035$, 校正后 1.0000 (真值 0.9992); 非对角元与真值的相关由 0.205 ($\lambda = 0.5$) 升到 0.997 ($\lambda = 20$), 斜率由 0.042 升到 0.995。

推导 26.4 样本频率下 G 的行和与平均非对角元

令 $\hat{p}_j = \bar{x}_j/2$, $W = X - 2\hat{p}'$ 的每列均值为 0, 故 $W'1 = 0$, $G_s 1 = WW'1/s = 0$ 。于是 $\sum_{j \neq i} G_{ij} = -G_{ii}$, 对 n 个动物平均: $\bar{G}_{ij} = -\bar{G}_{ii}/(n-1)$ 。而系谱 A 以基群为参照, 平均非对角元通常为正值 (亲属多)。要使 G_s 与 A 同一参照, 作线性变换 $G^* = a + bG_s$, 令平均对角元、平均非对角元分别等于 $\bar{A}_d, \bar{A}_o$: $b = (\bar{A}_d - \bar{A}_o)/(\bar{G}_d - \bar{G}_o)$, $a = \bar{A}_o - b\bar{G}_o$ 。习题 26.18 ($n = 120$, $m = 3000$): $\bar{A}_d = 1.0340$, $\bar{A}_o = 0.0874$; 基群频率的 G_0 给出 1.0338 与 0.0866 (回归斜率 1.002, 截距 -0.001); 样本频率的 G_s 给出 0.9875 与 -0.0083 = -0.9875/119 (截距 -0.096); 相容化参数 $a = 0.0953$, $b = 0.9506$ 。 G_s 的 $\hat{F} = \bar{G}_{ii} - 1 = -0.0125$, 而系谱 $F = 0.0340$ 、 G_0 的 $\hat{F} = 0.0338$ 。三种 G 的 GBLUP 准确度均为 0.454—0.455, EBV 相关 1.000。

推导 26.5 缺失基因型: 均值填补与成对完整观测

设缺失以概率 f 独立发生 (MCAR)。均值填补把缺失处的 W_{ij} 置 0, $G_{ii}^{(a)} = \sum_j I_{ij} W_{ij}^2 / s$, 期望为 $(1-f)G_{ii}^*$; $i \neq i'$: $E(I_{ij}I_{i'j}) = (1-f)^2$, 故非对角元期望缩小 $(1-f)^2$ 。成对完整观测: $G_{ii'}^{(b)} = \sum_j I_{ij}I_{i'j}W_{ij}W_{i'j} / \sum_j I_{ij}I_{i'j}h_j$ ($h_j = 2p_jq_j$) 按各对可用位点重新标度, 分子分母同乘 $(1-f)^2$, 对角元分子分母同乘 $(1-f)$, MCAR 下基本无偏。但杂合子更易缺失 (MNAR) 时, 保留下来的位点偏向纯合子, $\sum_j W_{ij}^2$ 的期望与 $\sum_j h_j$ 的比例不再为 1。习题 26.19 ($n = 400$, $m = 2500$): MCAR 下 $f = 0.02, 0.10, 0.25$ 时均值填补的对角元比为 0.980, 0.899, 0.749, 非对角元斜率 0.959, 0.807, 0.559 (理论 0.960, 0.810, 0.5625); 成对完整的对角元比为 1.000, 0.999, 1.000。MNAR (杂合子缺失概率为 4 倍) 下成对完整对角元比 1.006, 1.034, 1.104, 斜率 1.013, 1.076, 1.234: 不再自动无偏。列表删除 (只留所有动物均有数据的位点) 在 $f = 0.02$ 时就几乎不剩位点。

推导 26.6 频率误差不变性定理

令 $\delta = 2(p - \hat{p})$, $W_{\hat{p}} = W_p + 1\delta'$, 则 $W_{\hat{p}}W_{\hat{p}}' = W_pW_p' + 1t' + t1' + (\delta'\delta)11'$, $t = W_p\delta$ 。因此 $G_{\hat{p}} = (sG_p + \Delta)/\hat{s}$, 其中 $\Delta = 1a' + a1'$ ($a = t + \frac{1}{2}\|\delta\|^2 1$)。模型 $y = 1\mu + u + e$ 。取误差对比矩阵 K ($K'1 = 0$), 则 $K'\Delta K = 0$, 于是 $K'VK$ 不变, REML 似然、 $P = K(K'VK)^{-1}K'$ 不变。BLUP $\hat{u} = \sigma_u^2 GPy$, 加上 Δ 后变化为 $\sigma_u^2 \Delta Py = \sigma_u^2 1(a'Py)$ ($1'P = 0$), 即所有动物共同加一个常数。尺度变化 $s/\hat{s}$ 若伴随方差重估则 EBV 不变, 若方差比固定则改变收缩。习题 26.20: 参照样本为 10、40、400 头时分解误差 $< 2 \times 10^{-15}$, EBV 去均值差 $\leq 2.3 \times 10^{-7}$ (数值噪声), REML 对数似然差 $< 10^{-13}$; 平移量/EBV SD 为 0.069, 0.013, 0.000; 固定 λ 时收缩误差 2.8%, 0.7%, 0.08%。**定理的边界:** 必须所有动物用同一 $\hat{p}$ 。如果两批各用自己的频率中心化 ($W = W_p + D\Delta_b$, D 为批次指示), 误差项不再是 $1a' + a1'$ 的形式, 批间均值差被抹去: 批内排序几乎不变 (0.220 对 0.209), 跨批合并测试集的准确度由 0.345 降到 -0.018。

拓展阅读 基因型质控与 G 的构建

VanRaden (2008) 提出方法一与方法二的 GRM; Powell、Visscher 与 Goddard (2010) 说明参照频率与“同祖/同态”的区别; Christensen、Madsen 与 Lund (2012)、Legarra 等 (2009) 讨论 G 与 A 的尺度相容; Wigginton 等 (2005) 给出高效精确 HWE 检验; Li、Willer 等发展了低深度测序的基因型似然与填补 (如 GLIMPSE、STITCH 等)。关于测序基因型的 GRM, 参见 Gilly 等 (2019) 与 Martin 等 (2021)。亲子鉴定方面, 国际动物遗传学会 (ISAG) 推荐的 SNP 面板常用约 100–200 个位点。

易错辨析

- **不是所有误差都有害:** 频率误差在含截距的 BLUP 中只改变常数与尺度, 而批内中心化却破坏跨批排序 (习题 26.20)。
- **样本频率 G 的平均对角元小于系谱 $1 + \bar{F}$:** 因为它以当前样本为参照, 不能直接比较“近交” (习题 26.18: -0.0125 对 0.0340)。
- **均值填补不是“中性”:** 它使 G 的对角元缩小 $(1 - f)$, 非对角元缩小 $(1 - f)^2$ 。
- **精确检验与卡方检验在稀有位点差别大:** MAF=0.01 时卡方实际水平 0.019。
- **HWE 失败不一定是分型错误:** 分层同样产生杂合子缺失。
- **后验剂量不是“更好的基因型”:** 它是校准的预测, 非对角元被收缩, 对角元偏小, 需要校正。

26.5 习题

一、单项选择题

26.1 ★ [单选] 亲子鉴定中使用“对立纯合冲突”而不用“全部孟德尔不一致”的主要原因是

- (A) 它在真亲子中不会（在无分型误差时）出现，且易于计算
(B) 它与近交无关 (C) 它只适用于母子
(D) 它与 MAF 无关

[答案]

26.2 ★ [单选] 用被分型样本自身的等位基因频率中心化后，GRM 的

- (A) 对角元恒为 1 (B) 每行行和恒为 0
(C) 非对角元恒为正 (D) 秩恒为 n

[答案]

26.3 ★★ [单选] $MAF=0.01$ 、 $n=1000$ 的真平衡位点， $\alpha=0.001$ 时，Pearson 卡方检验的实际一类错误率

- (A) 低于名义水平很多 (B) 高于名义水平很多（约 0.02）
(C) 恰为名义水平 (D) 与精确检验相同

[答案]

26.4 ★★ [单选] 低深度测序中“后验剂量是校准的”是指

- (A) 后验剂量等于真基因型
(B) 真基因型对后验剂量的回归斜率为 1
(C) 后验剂量方差为 0 (D) 后验剂量与 MAF 无关

[答案]

26.5 ★★ [单选] 在 MCAR、缺失率 $f=0.10$ 时，均值填补得到的 GRM，其对角元与非对角元（相对完整数据）约缩小为

- (A) 0.90 与 0.90 (B) 0.90 与 0.81 (C) 0.81 与 0.90 (D) 不变

[答案]

26.6 ★★★ [单选] 在含固定截距的 GBLUP 中，若所有动物都使用同一个（错误的）等位基因频率 $\hat{p}$ 构造 GRM，且方差分量由 REML 重估，则 EBV

- (A) 完全改变 (B) 仅改变一个共同常数 (C) 排序倒置
(D) 不受尺度影响但受常数影响

[答案]

二、判断与改错题

26.7 ★ [判断] 用样本频率构造的 G ，其平均对角元总等于 $1 +$ 系谱平均近交系数。 [答案]

26.8 ★ [判断] 杂合子脱扣使 HWE 检验的检出率随脱扣比例 d 增大而增大。 [答案]

26.9 ★★ [判断] 各批分别用自己的频率中心化与用统一频率中心化，在批内排序上几乎等价，但在跨批比较上不等价。 [答案]

26.10 ★★ [判断] 成对完整观测的 GRM 在杂合子更易缺失 (MNAR) 时仍然无偏。 [答案]

三、填空题

26.11 ★ [填空] 单位点 $p = 0.3$ ，非亲子对的对立纯合冲突率为 _____； $m = 60$ 个相同频率的独立位点，期望冲突数为 _____。 [答案]

26.12 ★ [填空] MCAR 缺失率 $f = 0.25$ 下均值填补，GRM 对角元期望缩为 _____ 倍，非对角元缩为 _____ 倍。 [答案]

26.13 ★★ [填空] $n = 120$ 个动物，用样本频率构造的 G 的平均对角元为 0.9875，则平均非对角元为 _____ (保留四位小数)。 [答案]

26.14 ★★ [填空] 4 个各自平衡的亚群，频率方差为 $0.05 \bar{p}\bar{q}$ ，混合后期望杂合度缺失 $F =$ _____。 [答案]

四、计算题

26.15 ★★★ [计算] 亲子鉴定的孟德尔冲突。150 头公畜、400 头子代、12% 记错父亲、10% 样本为高误差 ($\epsilon = 3\%$)：比较理论与模拟的非亲子冲突率，求不同 SNP 数下的 AUC、检出率与假阳性率，以及剔除高误差样本后阈值的变化。 [程序] `ch26/ex26_15_parentage_mendel.py` [答案]

26.16 ★★★ [计算] HWE 检验的性质。实现精确检验并与枚举对照；比较卡方与精确检验在不同 MAF 下的一类错误；计算脱扣的检出率与 Wahlund 效应下的杂合度缺失。 [程序] `ch26/ex26_16_hwe_tests.py` [答案]

26.17 ★★★ [计算] 低深度剂量 GRM。 $\lambda = 0.5, 1, 2, 4, 8, 20$: 求后验剂量的 R^2 、校准斜率, GRM 对角元的偏小与校正, 非对角元的相关与斜率, 以及 GBLUP 准确度。

[程序] `ch26/ex26_17_lowpass_dosage_grm.py`

[答案]

26.18 ★★★ [计算] G 与 A 的尺度相容。6 代系谱、分型最后两代: 比较基群频率 G_0 、样本频率 G_s 与相容化 G^* 的平均对角、平均非对角、回归与 $\hat{F}$, 并核验 G_s 的行和。

[程序] `ch26/ex26_18_grm_vs_pedigree_scaling.py`

[答案]

26.19 ★★★ [计算] 缺失基因型。MCAR 与 MNAR, 缺失率 2%、10%、25%: 比较均值填补、成对完整观测与列表删除的对角元、非对角元斜率、HE 遗传力与预测准确度。 [程序] `ch26/ex26_19_missing_genotypes_grm.py`

[答案]

26.20 ★★★ [计算] 频率误差的不变性。核验 G_p 的分解与 EBV 的不变性 (参照样本 10、40、400), 固定方差比时的收缩误差, 以及批内中心化的反例。 [程序]

`ch26/ex26_20_frequency_error_invariance.py`

[答案]

26.21 ★ [计算] 一个位点 ALT 频率 $p = 0.3$, 测序错误率 $\varepsilon = 0.01$, 某动物 3 条读段中 2 条为 REF、1 条为 ALT。求三个基因型的后验概率、后验剂量与方差。 [答案]

26.22 ★★ [计算] $m = 60$ 个独立位点, 每个 $p = 0.3$ 。若以“冲突数 $C \geq 3$ ”判定父子关系有误: (1) 非亲子对的期望冲突数与标准差; (2) 非亲子对被检出的概率; (3) 真亲子 (伪冲突率 0.0039) 被误判的概率 (泊松近似)。 [答案]

五、推导与证明题

26.23 ★★ [证明] 证明: 无分型误差时真亲子对的对立纯合冲突率为 0; 无亲缘且 HWE 时, 单位点对立纯合冲突概率为 $2p^2q^2$ 。 [答案]

26.24 ★★★ [证明] 证明: 以样本频率中心化得到的 G_s 满足 $G_s \mathbf{1} = 0$, 并推出平均非对角元等于 $-\overline{G_{ii}}/(n-1)$ 。 [答案]

26.25 ★★★ [证明] 设 $G^* = G + 1a' + a1'$ 。证明: 在含固定截距的 BLUP (方差分量已知) 中, P 不变, 且 $\hat{u}^* = \hat{u} + c\mathbf{1}$, $c = \sigma_u^2 a' P y$ 。 [答案]

26.26 ★★★ [证明] 证明后验剂量 $d = E(x | r)$ 的校准性 $E(x | d) = d$, 并证明对角元的偏小量等于 $\sum_j E(v_{ij})/s$ 。 [答案]

六、综合分析与研究设计题

26.27 ★★ [综合] 为一个猪育种公司设计基因型质控流程：样本级、位点级、亲子级、批次级，写出阈值的依据与自动化报告内容。 [答案]

26.28 ★★★ [综合] 某群体同时有高密度芯片（约 5 万 SNP）与低深度测序（约 $1\times$ ）两类基因型。设计构建统一 GRM 的方案，并说明剂量不确定性如何进入模型。 [答案]

26.29 ★★★ [综合] 两个年份的基因型分别由两个实验室分型，各自用本批样本频率构建了 G，现需要合并做跨年份的 GBLUP。诊断问题并给出合并方案，检验方案有效。 [答案]

26.6 参考答案与解析

一、单项选择题

26.1 A。 对立纯合（AA 对 aa）在真亲子中不可能出现（无误差），而一般“不一致”还包括杂合与纯合的组合，在突变和分型误差下难以区分；对立纯合冲突率对非亲子为 $2p^2q^2$ ，对真亲子仅为误差率。习题 26.15：非亲子 0.0746，真亲子 0.0039。

[题目]

26.2 B。 样本频率使 W 每列和为 0， $W'1 = 0$ ， $G1 = 0$ ，秩最多 $n - 1$ 。对角元均值通常小于 1（习题 26.18：0.9875）。 [题目]

26.3 B。 稀有位点下计数小，卡方近似差；习题 26.16： $MAF=0.01$ 的实际水平卡方 0.019，精确 0.000（保守）。 [题目]

26.4 B。 校准指 $E(x | d) = d$ ，即真值对 d 的回归斜率为 1；但 d 是收缩的预测，方差小于真值方差。习题 26.17 各深度校准斜率均为 1.000。 [题目]

26.5 B。 对角元 $(1 - f) = 0.90$ ，非对角元 $(1 - f)^2 = 0.81$ 。习题 26.19： $f = 0.10$ 的实测 0.899 与 0.807。 [题目]

26.6 B。 见推导 26.6。方差重估时尺度变化被吸收，EBV 仅差一个共同常数。习题 26.20 的去均值差为 10^{-7} 量级（数值噪声）。 [题目]

二、判断与改错题

- 26.7 错误。**样本频率 G 以当前样本为参照，平均对角元 0.9875 小于系谱的 1.0340；用基群频率才与系谱同参照（1.0338）。[题目]
- 26.8 正确。** $H_{obs} = (1 - d)2pq$ ，缺失越多检出越强；习题 26.16：MAF=0.5 时 $d = 0.05, 0.10, 0.20$ 的检出率为 0.035, 0.439, 1.000。MAF 越低检出越难。[题目]
- 26.9 正确。**批内中心化相当于给每批加一个常数向量，批内排序不变（习题 26.20：0.220 对 0.209），但抹去批间均值差，跨批准确度由 0.345 降到 -0.018。[题目]
- 26.10 错误。**杂合子更易缺失使保留位点偏向纯合，对角元比与斜率都偏离 1： $f = 0.25$ 时对角元比 1.104，斜率 1.234（习题 26.19）。[题目]

三、填空题

- 26.11** $2p^2q^2 = 2 \times 0.09 \times 0.49 = 0.0882$ ； $60 \times 0.0882 = 5.29$ 。[题目]
- 26.12** 对角元 0.75 倍；非对角元 $0.75^2 = 0.5625$ 倍。[题目]
- 26.13** $-0.9875/119 = -0.0083$ 。[题目]
- 26.14** $F = F_{ST}(K - 1)/K = 0.05 \times 3/4 = 0.0375$ 。[题目]

四、计算题

- 26.15** 理论非亲子冲突率 0.07455, 模拟 0.07391 (差 0.9%); 记错父亲的对 (含误差) 0.07784。真亲子冲突率 0.00393，其中低误差对 0.00260、含高误差样本的对 0.01067。

SNP 数	AUC	阈值	检出率	假阳性率	高误差真亲子误判率
30	0.9235	0.0333	0.605	0.003	0.017
60	0.9841	0.0500	0.465	0.000	0.000
100	0.9993	0.0322	0.977	0.006	0.034
200	1.0000	0.0250	1.000	0.003	0.017
500	1.0000	0.0180	1.000	0.000	0.000
2000	1.0000	0.0146	1.000	0.006	0.034

剔除 16.2% 的高误差样本后，99.5% 分位阈值由 0.01461 降到 0.00650（降 56%）。
解读：AUC 在 $m \geq 100$ 已接近 1，但固定阈值的检出率对 m 敏感： $m = 60$ 的阈值

(0.05) 由个别高误差样本决定, 检出率只有 0.465。样本级质控应先于亲子鉴定。

[题目]

26.16 精确检验与枚举的最大相对差 1.7×10^{-14} 。一类错误 ($\alpha = 0.001$):

MAF	0.01	0.03	0.10	0.30	0.50
卡方	0.0190	0.0053	0.0030	0.0003	0.0013
精确	0.0000	0.0003	0.0013	0.0003	0.0013

脱扣检出率 ($d = 0.05, 0.10, 0.20$) : MAF=0.01: 0.027, 0.100, 0.386; 0.03: 0.037, 0.210, 0.748; 0.10: 0.048, 0.350, 0.964; 0.30: 0.043, 0.432, 0.999; 0.50: 0.035, 0.439, 1.000。 **Wahlund** ($K = 4$):

F_{ST}	0	0.02	0.05	0.10
F	0.0035	0.0154	0.0379	0.0727
理论 $F_{ST} \cdot 3/4$	0	0.0150	0.0375	0.0750
检出率	0.000	0.005	0.070	0.275

解读: HWE 检验对稀有位点保守、对脱扣在 $d \geq 10\%$ 时才有效; 分层与脱扣产生相同的“杂合子缺失”, 仅靠 HWE 无法区分。

[题目]

26.17 $n = 500$, $m = 1500$, $\varepsilon = 0.01$, 真 G 的平均对角元 0.9992:

λ	剂量 R^2	硬调用 R^2	$\bar{G}_{d,ii}$	校正后	非对角相关 (剂量/硬)	斜率 (剂 量/硬)
0.5	0.332	0.246	0.2035	1.0000	0.205 / 0.108	0.042 / 0.052
1	0.460	0.373	0.3569	1.0003	0.360 / 0.245	0.129 / 0.169
2	0.636	0.563	0.5664	1.0010	0.569 / 0.473	0.323 / 0.439
4	0.818	0.777	0.7826	0.9998	0.787 / 0.741	0.619 / 0.776
8	0.945	0.930	0.9335	0.9992	0.936 / 0.919	0.876 / 0.930
20	0.998	0.997	0.9966	0.9993	0.997 / 0.997	0.995 / 0.998

校准斜率在所有深度均为 1.000。GBLUP 准确度 (真基因型 0.193): 剂量 (校正对角) 0.105, 0.110, 0.137, 0.172, 0.173, 0.192, 硬调用 0.033, 0.058, 0.103, 0.142, 0.158, 0.193。

解读：剂量在同一深度下的非对角相关与准确度都更高；硬调用在 $\lambda < 4$ 时基因型“错分”引入噪声，非对角斜率反而大于剂量（剂量被后验收缩）。对角元不校正会得到 0.20 ($\lambda = 0.5$) 的荒谬值。

[题目]

26.18 $\bar{A}_d = 1.0340$, $\bar{A}_o = 0.0874$, 系谱 $\bar{F} = 0.0340$:

矩阵	平均对角	平均非对角	回归斜率	回归截距	$\hat{F}$
G_0 (基群频率)	1.0338	0.0866	1.002	-0.0010	0.0338
G_s (样本频率)	0.9875	-0.0083	1.006	-0.0963	-0.0125
G^* (相容化)	1.0340	0.0874	0.957	0.0038	0.0340

相容化参数 $a = 0.09529$, $b = 0.9506$; G_s 最大行和 2.8×10^{-15} , $-0.9875/119 = -0.008299$ 与平均非对角元一致。GBLUP 准确度 0.454, 0.455, 0.454, EBV(G_0) 与 EBV(G^*) 相关 1.000。解读：三种 G 对排序一致；只有基群频率版本的对角元能当作近交估计；样本频率的 $\hat{F} = -0.0125$ 是“相对当前样本的近交”，不能与系谱 0.034 直接比较。

[题目]

26.19 完整数据：平均对角元 1.0193, $HE \hat{h}^2 = 0.071$ ($n = 400$ 的 SE 很大), GBLUP 准确度 0.276。

机制, f	方法	对角/真	斜率	相关	准确度
MCAR, 0.02	均值填补	0.980	0.959	0.995	0.280
MCAR, 0.02	成对完整	1.000	0.999	0.995	0.280
MCAR, 0.10	均值填补	0.899	0.807	0.975	0.283
MCAR, 0.10	成对完整	0.999	0.997	0.975	0.282
MCAR, 0.25	均值填补	0.749	0.559	0.923	0.201
MCAR, 0.25	成对完整	1.000	0.995	0.923	0.203
MNAR, 0.10	成对完整	1.034	1.076	0.983	0.282
MNAR, 0.25	均值填补	0.810	0.666	0.950	0.234
MNAR, 0.25	成对完整	1.104	1.234	0.950	0.227

列表删除保留的位点比例在 $f = 0.02$ 即为 0.000。解读：均值填补的偏差与理论 $(1 - f)$ 、 $(1 - f)^2$ 吻合；成对完整观测在 MCAR 下纠正了尺度，但相关系数不变 (0.923)、准确度同样下降到 0.20——**标度问题与信息损失是两回事**；MNAR 使成对完整的尺度偏离到 1.10，必须先诊断缺失机制。

[题目]

26.20 $n = 400$, $m = 2500$, 真频率下 $\hat{h}^2 = 0.3754$:

参照样本	s_p/s	平均对角	分解误差	EBV 去均值差	平移/EBV SD	$\hat{\sigma}_u^2$ 比	固定 λ 收缩误差
10	0.9407	1.1631	1.8×10^{-15}	1.2×10^{-7}	0.069	0.941	2.82%
40	0.9849	1.0354	8.9×10^{-16}	2.3×10^{-7}	0.013	0.985	0.70%
400	0.9982	0.9994	1.1×10^{-15}	1.5×10^{-7}	0.000	0.998	0.08%

定理的直接检验：对任意 a , $\max |P - P^*| = 6 \times 10^{-15}$, EBV 差的离差 2×10^{-14} 。

批内中心化反例（两批来自 $F_{ST} = 0.05$ 的亚群）：合并测试集准确度，统一频率 0.345，批内中心化 -0.018（统一更优的重复 100%）；分批内：0.220 对 0.209。解读：频率误差仅造成平移与（方差重估下被吸收的）尺度变化；但当不同动物使用不同的参照频率，G 的扰动不再是共同的 $1a' + a1'$ ，跨批比较直接受损。【题目】

26.21 似然 $\propto 3\pi_x(1-\pi_x)^2$: $\pi_0 = 0.01, \pi_1 = 0.5, \pi_2 = 0.99$ 得 0.029403, 0.375, 0.000297; 先验 0.49, 0.42, 0.09; 后验权重 0.014407, 0.15750, 0.0000267, 归一化得 **0.0838**、**0.9160**、**0.00016**。后验剂量 $d = 0.9160 + 2 \times 0.00016 = \mathbf{0.9164}$, 方差 $v = 0.9160 + 4 \times 0.00016 - 0.9164^2 = \mathbf{0.0770}$ 。即便只有 3 条读段，该位点几乎肯定是杂合子（ALT 读段说明至少一个 ALT 等位基因，REF 读段与错误率排除 ALT 纯合）。【题目】

26.22

(1) $r = 2p^2q^2 = 0.0882$, $E(C) = 60 \times 0.0882 = \mathbf{5.29}$, $SD = \sqrt{60 \times 0.0882 \times 0.9118} = \mathbf{2.20}$ 。(2) $C \geq 3$ 的概率 $= 1 - P(C \leq 2) = 1 - 0.0917 = \mathbf{0.908}$ (二项)。(3) 真亲子 $C \sim \text{Poisson}(60 \times 0.0039 = 0.234)$, $P(C \geq 3) = \mathbf{0.0018}$ 。因此阈值 $C \geq 3$ 检出率只有约 91%，如要 $> 99\%$ ，需增加位点或降低阈值；个别高误差样本 ($\varepsilon = 3\%$, 冲突率 0.0107, $\lambda = 0.64$) 的误判概率 $P(C \geq 3) = 0.027$ 。

【题目】

五、推导与证明题

26.23 证明。真亲子：子代的两个等位基因一个来自该亲代（该亲代只能传其两个等位基因之一）。若亲代为 AA，则子代至少有一个 A，不能是 aa；若亲代为 aa，则子代至少有一个 a，不能是 AA。故 (AA, aa) 与 (aa, AA) 不可能，冲突率为 0。非亲子、HWE: $P(AA) = p^2$, $P(aa) = q^2$, 独立，故 $P(AA, aa) = p^2q^2$, $P(aa, AA) = q^2p^2$,

总计 $2p^2q^2$ 。■

【题目】

26.24 证明。 $\hat{p}_j = \frac{1}{2n} \sum_i x_{ij}$, $W_{ij} = x_{ij} - 2\hat{p}_j$, 则 $\sum_i W_{ij} = \sum_i x_{ij} - 2n\hat{p}_j = 0$ 。所以 $W'1 = 0$, $G_s1 = W(W'1)/s = 0$ 。第 i 行: $G_{ii} + \sum_{k \neq i} G_{ik} = 0$ 。对所有 i 求和: $\sum_i G_{ii} + \sum_{i \neq k} G_{ik} = 0$, $\sum_{i \neq k} G_{ik} = n(n-1)\overline{G_{ij}}$, $\sum_i G_{ii} = n\overline{G_{ii}}$, 故 $\overline{G_{ij}} = -\overline{G_{ii}}/(n-1)$ 。

■

【题目】

26.25 证明。 设 $V = \sigma_u^2 G + \sigma_e^2 I$, $V^* = V + \sigma_u^2(1a' + a1')$ 。取 K 为 $n \times (n-1)$ 列满秩, $K'1 = 0$, $P = K(K'VK)^{-1}K'$ (含固定截距的 P)。由 $K'1 = 0$: $K'V^*K = K'VK$, 故 $P^* = P$ 。BLUP: $\hat{u}^* = \sigma_u^2 G^* P y = \hat{u} + \sigma_u^2(1a' + a1')Py$ 。因 $P1 = 0$ (对称) 有 $1'P = 0$, 所以 $a1'Py = 0$, 余下 $\sigma_u^2 1(a'Py) = c1$ 。■

【题目】

26.26 证明。 校准: 由全期望, $E[x | d(r)] = E\{E[x | r] | d\} = E[d | d] = d$ 。因此回归 x 对 d 的总体斜率 $= \text{Cov}(x, d) / \text{Var}(d) = \text{Var}(d) / \text{Var}(d) = 1$ 。对角元: $E(x^2) = E[E(x^2 | r)] = E(d^2 + v)$ 。用剂量计算 $\sum_j (d_{ij} - 2p_j)^2 / s$ 时少了 $\sum_j E(v_{ij}) / s$ 项, 补上即无偏。非对角元: 对无亲缘、先验独立的个体, 读段独立, $E[x_i x_{i'} | r_i, r_{i'}] = d_i d_{i'}$, 故 $E(d_i d_{i'}) = E(x_i x_{i'})$, 不需对角元那样的校正; 对有亲缘的个体, 先验把个体视为独立会丢失一部分相关, 导致非对角元对真值的回归斜率小于 1 (习题 26.17: $\lambda = 0.5$ 时斜率 0.042)。■

【题目】

六、综合分析与研究设计题

26.27 流程 (1) 样本级: 分型率 (如 < 0.95 剔除)、杂合度离群 (超出均值 ± 3 SD)、性别与表型性别一致、重复样本的一致率 (> 0.995 视为同一个体); 高误差样本先判别 (习题 26.15: 高误差样本使阈值由 0.0065 升到 0.0146)。(2) 位点级: 位点分型率 (< 0.95 剔除)、MAF (< 0.01 不进入 GRM, 参见第 25 章 MAF 分层)、精确 HWE (对重复整合的纯种群体 $p < 10^{-6}$ 时标记)、批次间频率差异检验; HWE 失败原因分层与脱扣无法仅凭检验区分 (习题 26.16)。(3) 亲子级: 用约 100–200 个高 MAF 位点的对立纯合冲突率, 阈值取真亲子 99.5% 分位; 对可疑个体用全部位点复核 (习题 26.15: $m = 100$ 时 AUC 0.999); 对重复检出的个体溯源到系谱源头。(4) 批次级: 统一参照频率 (如全群体基群频率), 不得批内重估 (习题 26.20); 输出批间 G 的均值差诊断。(5) 报告: 每步剔除数、原因、阈值、软件版本、随机种子、代码哈希, 以及 G 的行和、平均对角元、平均非对角元与系谱 A 的对比表 (习题 26.18)。

【题目】

26.28 方案 (1) 统一位点集: 以 5 万芯片位点为骨架, 测序数据在这些位点上调用基因型似然; 其他位点可用于后续稀有变异分析。(2) 测序个体: 用基因型似然与 HWE

或填补先验得到后验剂量 d 与方差 v (习题 26.17); $\lambda = 1$ 时剂量 R^2 只有 0.46, 必须与芯片位点结合填补以提高。(3) GRM: 对芯片个体用 $d = x$, $v = 0$; 对测序个体用 d 并在对角元加 $\sum_j v_{ij}/s$; 非对角元用 d 的乘积 (后验收缩使斜率 < 1 , 需考虑)。(4) 不确定性进入模型: 用测量误差模型 $x = d + \eta$ 把个体的剂量误差协方差加入残差 (对角元之外的非对角误差可忽略), 或把 $\sum_j v_{ij}/s$ 作为对角元项。(5) 验证: 用同时有芯片与测序的个体评估剂量对芯片真值的 R^2 与 G 非对角元的相关; 对预测准确度按深度分层报告。(6) 风险: 两种平台间批次差异导致跨平台个体的 G 受影响, 需统一频率参照 (习题 26.20)。

[题目]

26.29 诊断 (1) 在每批内, G 的行和为零、平均非对角元为负 ($-\overline{G_{ii}}/(n-1)$, 习题 26.18); 两批单独的 G 参照不同, 跨批的非对角元不可比。(2) 比较两批的频率向量 $\hat{p}_A, \hat{p}_B$: 若来自同一群体, 差异应约为 $\sqrt{2pq/n_b}$ 的抽样误差; 若显著偏大, 说明批次或群体差异。(3) 用批次共有的锚点个体 (重复分型) 评估批间一致性。**方案**: 用合并样本的频率或基群频率 (若有) 统一中心化, 对全部动物一次性构造 G (习题 26.20: 统一频率的跨批准准确度 0.345 对批内中心化 -0.018); 然后用线性相容化把 G 与 A 对齐 (习题 26.18)。**检验**: (a) 批次作固定效应 + 年份作固定效应后比较; (b) 跨批留出: 用一批训练、另一批测试, 比较两种 G 的准确度; (c) 合并 G 的特征值分解, 前几个主成分是否按批次聚类; (d) 若批次与年份完全混杂, 不能仅靠建模区分, 需要锚点样本。

[题目]

GBLUP、岭回归、贝叶斯与核方法

27.1 本章导学

学习目标

1. 理解 SNP-BLUP (岭回归) 与 GBLUP 的数学等价, 会在标记维度与个体维度之间转换, 并由个体效应反推标记效应。
2. 能用特征分解解释谱收缩、有效自由度与样本外误差的 U 形曲线, 会用留一恒等式、PRESS 与 GCV 选择收缩参数。
3. 理解 BayesC π 的 Gibbs 条件分布, 知道它何时能胜过 GBLUP、何时只是持平。
4. 理解表示定理与核预测, 会用 G#G 构造上位性核, 并区分 “可识别上位方差” 与 “改善预测”。
5. 会处理不等精度的代理表型 (DYD 或去回归育种值), 写出权重并修正验证相关。
6. 理解赢家诅咒与嵌套交叉验证, 会设计针对目标群体的验证方案 (留家系、留组) 并使用留组恒等式。

重点与难点

重点: $\hat{g} = G(G + \lambda I)^{-1}(y - \hat{\mu})$; $\lambda_{\beta} = \lambda \sum 2p_j q_j$; $df(\lambda) = \sum d_k / (d_k + \lambda)$; 留组恒等式 $e_{-B} = (I - H_{BB})^{-1}e_B$; 代理表型权重 $r^2 / (1 - r^2)$ 。

难点: BayesC π 的收益取决于遗传结构而非方法本身; Gaussian 核估计出非零方差不等于预测更好; 验证集上的相关低估真准确度, 而在同一测试集上挑选超参数会高估。

本章承接第 26 章 (基因型质控与 GRM) 与第 21 章 (BLUP): 当 G 给定后, 预测方法的差别只剩 “先验形状” 与 “核函数”。后面的第 28 章 (单步评定) 把无基因型个体的系谱信息并进来, 第 29 章 (验证与迁移) 则更系统地讨论目标群体与评价设计。

27.2 知识结构图




图 27.1 第 27 章知识结构图

左侧是模型（表示、收缩、先验、核），右侧是如何比较与验证它们。

27.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
SNP-BLUP 等价	$\hat{\beta} = Z'(ZZ' + \lambda_{\beta}I)^{-1}(y - \hat{\mu})$ $\lambda_{\beta} = \lambda \sum 2p_jq_j,$ $G = ZZ' / \sum 2p_jq_j$	$\lambda_{\beta} = \sigma_e^2 / \sigma_{\beta}^2$ $\lambda = \sigma_e^2 / \sigma_g^2$
谱收缩	第 k 方向收缩 $d_k / (d_k + \lambda)$	$G = U \text{diag}(d)U'$
有效自由度	$\text{df}(\lambda) = \sum_k d_k / (d_k + \lambda)$	随 λ 单调递减
留一恒等式	$e_i^{(-i)} = e_i / (1 - H_{ii})$	含截距的投影 H
留组恒等式	$e_{-B} = (I - H_{BB})^{-1}e_B$	固定 λ
BayesC π 包含概率	$\text{logit } P(\delta_j = 1) =$ $\text{logit}(1 - \pi) + \frac{1}{2} \log \frac{v_j}{\sigma_b^2} + \frac{m_j^2}{2v_j}$	$v_j = (x_j'x_j / \sigma_e^2 + 1 / \sigma_b^2)^{-1}$
表示定理	$\hat{f}(x_*) = \sum_i \alpha_i k(x_*, x_i)$	新个体只需核向量
上位性核	$G_{AA} = G \# G / \text{diag}$	需要亲属才可与加性核区分

概念	公式或定义	成立条件与提示
代理表型权重	$w_i = r_i^2 / (1 - r_i^2) = n_i / k$	$k = \sigma_e^2 / \sigma_a^2$
验证相关修正	$\rho_{\hat{g},a} \approx \rho_{\hat{g},y} / \sqrt{r^2}$	y 为 a 的带噪测量
选择偏倚上限	$\approx \sigma \sqrt{2 \ln C}$	C 个独立估计

27.4 补充内容与公式推导

推导 27.1 SNP-BLUP 与 GBLUP 的等价

设 $y = 1\mu + Z\beta + e$, $\beta \sim N(0, \sigma_\beta^2 I)$ 。岭回归的正规方程 $(Z'Z + \lambda_\beta I)\hat{\beta} = Z'(y - \hat{\mu}1)$ 。利用恒等式 $(Z'Z + \lambda_\beta I)^{-1}Z' = Z'(ZZ' + \lambda_\beta I)^{-1}$, 得 $\hat{\beta} = Z'(ZZ' + \lambda_\beta I)^{-1}(y - \hat{\mu}1)$, 个体基因组育种值 $\hat{g} = Z\hat{\beta} = ZZ'(ZZ' + \lambda_\beta I)^{-1}(y - \hat{\mu}1)$ 。令 $G = ZZ'/s$, $s = \sum 2p_jq_j$, 并设 $\sigma_g^2 = s\sigma_\beta^2$, 则 $\lambda = \sigma_e^2/\sigma_g^2 = \lambda_\beta/s$, 上式变为 $G(G + \lambda I)^{-1}(y - \hat{\mu}1)$ ——GBLUP。新个体: $\hat{g}_* = z_*'\hat{\beta} = G_{*,tr}(G + \lambda I)^{-1}(y - \hat{\mu}1)$, 不需要把新个体并入 G 。习题 27.15 ($n = 300$, $m = 2000$): SNP-BLUP 与 GBLUP 的测试预测最大差 7.8×10^{-16} 。个体维度的线性系统是 $n \times n$, 标记维度为 $m \times m$, 因此 $m \gg n$ 时用 GBLUP 更省, $n \gg m$ 时反之。

推导 27.2 谱收缩、有效自由度与留一恒等式

设 $G = U \text{diag}(d_k)U'$, $\gamma = U'(y - \bar{y})$ 。GBLUP 的拟合为 $\hat{g} = U \text{diag}[\frac{d_k}{d_k + \lambda}] \gamma$: 大特征值方向几乎不收缩, 小特征值方向被强烈压缩。帽子矩阵 $H = G(G + \lambda I)^{-1}$ (含截距时加上均值投影), $\text{tr}(H) = \sum_k d_k / (d_k + \lambda) = \text{df}(\lambda)$ 。LD 越强, 特征值衰减越快, 有效自由度对 λ 越不敏感。习题 27.15 中前 1、5、20、50 个特征值占 G 迹的 1.0%, 4.6%, 16.2%, 34.9%; $\lambda = 0.05, 1, 10, 1000$ 时 $\text{df} = 279.8, 137.6, 26.5, 0.3$ 。样本外 MSE 先降后升: 对真遗传值的 MSE 在 $\lambda = 0.5$ 附近最小 (0.4565), 两端 0.5015 与 0.5416。留一恒等式: $\hat{y} = Hy$ 为线性平滑器时, 删去第 i 个观测重新拟合的残差为 $e_i / (1 - H_{ii})$; $\text{PRESS} = \sum [e_i / (1 - H_{ii})]^2$, GCV 用平均 $H_{ii} = \text{df}/n$ 替代逐个 H_{ii} 。数值核验: 最大差 1.1×10^{-15} 。PRESS 与 GCV 都选 $\lambda = 5$ (测试相关 0.3845), 测试集上最优 $\lambda = 0.5$ (0.4004): 训练集 200 多个观测的选择也有误差。

推导 27.3 BayesC π 的条件分布与稀疏收益

令 $\beta_j = \delta_j b_j$, $\delta_j \sim \text{Bern}(1 - \pi)$, $b_j \sim N(0, \sigma_b^2)$ 。记 e_{-j} 为去掉第 j 个位点效应后的残差, $r_j = x_j' e_{-j}$, $c_j = x_j' x_j$ 。条件于 $\delta_j = 1$, $b_j | \cdot \sim N(m_j, v_j)$, $v_j = (c_j/\sigma_e^2 + 1/\sigma_b^2)^{-1}$, $m_j = v_j r_j / \sigma_e^2$ 。把 b_j 积分掉, δ_j 的后验比为

$$\frac{P(\delta_j = 1 | \cdot)}{P(\delta_j = 0 | \cdot)} = \frac{1 - \pi}{\pi} \sqrt{\frac{v_j}{\sigma_b^2}} \exp\left(\frac{m_j^2}{2v_j}\right).$$

π 的条件分布为 $\text{Beta}(1 + k, 1 + m - k)$ (k 为含入位点数), σ_b^2 与 σ_e^2 为尺度化逆卡方。若 QTL 稀少而效应大, 数据支持小 π , 大效应位点几乎不收缩、其余位点被压到 0; 若遗传结构是多基因的, 包含概率较高 (后验常 ≥ 0.3), 各效应被均匀收缩, 结果接近岭回归。习题 27.16 ($n = 300$, $m = 800$, $h^2 = 0.6$, 1200 次迭代): **多基因** (400 个 QTL): GBLUP 相关 0.515, BayesC π 0.538, $\hat{\pi}_{incl} = 0.319$, $\text{PIP} > 0.5$ 的位点中真 QTL 30 个、其他 13 个; **稀疏** (15 个 t_3 效应 QTL, 最大 3 个占绝对效应和 0.59): GBLUP 0.504, BayesC π 0.968, $\hat{\pi}_{incl} = 0.015$, $\text{PIP} > 0.5$ 的位点中真 QTL 5 个、其他 0 个。解读: 预测相关的巨大提升并不依赖于“找全 QTL”——抓住少数大效应就够了; 多基因下 BayesC π 只比 GBLUP 略好。

推导 27.4 表示定理与上位性核的可识别性

RKHS 回归 $\min_f \sum_i (y_i - \mu - f(x_i))^2 + \lambda \|f\|_H^2$ 的解形如 $f(x) = \sum_i \alpha_i k(x, x_i)$, $\alpha = (K + \lambda I)^{-1} (y - \mu 1)$, 新个体 x_* 的预测为 $k_*' \alpha$, 不需要重新拟合。多核模型 $y = \mu 1 + a + g_{aa} + e$ 对 $a \sim N(0, \sigma_a^2 G)$, $g_{aa} \sim N(0, \sigma_{aa}^2 G \# G)$ (逐元平方, Henderson 加加上位性核)。若个体无亲缘, G 的非对角元近似为 0, $G \# G \approx I \cdot c$, 其效果与残差方差无法区分, 故 σ_{aa}^2 不可识别; 亲属越多 (同胞 $G_{ij} = 0.5$, $G_{ij}^2 = 0.25$) 上位性方差越可估。习题 27.17 (100 个全同胞家系 $\times 10$, $m = 500$, 训练 500、测试 500, 8 次重复): **纯加性** (加性 0.5): $\hat{\sigma}_{aa}^2 = 0.067$ (占遗传方差 0.11); **加性 + 上位性** (0.25+0.25): $\hat{\sigma}_a^2 = 0.276$, $\hat{\sigma}_{aa}^2 = 0.271$ (占 0.46)。表示定理检验: 并入测试个体与仅用核向量的预测最大差 1.1×10^{-15} 。

推导 27.5 不等精度代理表型的权重与相关修正

设公牛的代理表型 $y_i = a_i + e_i$, $\text{Var}(e_i) = k\sigma_a^2/n_i$ (n_i 为女儿数, $k = \sigma_e^2/\sigma_a^2$), 可靠度 $r_i^2 = \sigma_a^2/(\sigma_a^2 + \text{Var}(e_i)) = n_i/(n_i + k)$ 。BLUP 的残差协方差为 $\text{diag}[k\sigma_a^2/n_i]$, 对应权重 $w_i = 1/(k/n_i) = n_i/k = r_i^2/(1 - r_i^2)$; 若所有公牛等权 (取平均残差方差), 则高精度公牛被低估、低精度公牛被高估。验证时, $\hat{g}$ 对 y 的相关为 $\rho_{\hat{g}, y} = \rho_{\hat{g}, a} \sqrt{r^2}$ (独立噪声下), 因此对真育种值的相关近似 $\rho_{\hat{g}, y}/\sqrt{r^2}$ 。习题 27.19 (训练 400、验证 200,

$k = 20$, $n_i \in [5, 300]$, 25 次): 对真育种值的相关, 未加权 0.350, 正确加权 0.380, 平方根权 0.377; 对 y 的相关 0.269 (低估), 除以 $\sqrt{r^2}$ 得 0.341, 按 r_i^2 加权后修正 0.355, 真值 0.380。

推导 27.6 赢家诅咒、嵌套交叉验证与留组恒等式

赢家诅咒。对 C 个候选模型各算一个相关估计 $\hat{\rho}_c = \rho_c + \varepsilon_c$, 选出 $\hat{\rho}_c$ 最大者并报告它。当 ε_c 近似独立同分布 $N(0, \sigma^2)$ 且 ρ_c 相同, $E[\max_c \hat{\rho}_c] - \rho \approx \sigma \sqrt{2 \ln C}$ 。习题 27.18 (60 个候选, 训练 200, 小测试集 100): 对表型的相关, 报告值 0.366, 所选模型在 3000 头新个体上的真相关 0.199, 偏高 0.167; 独立误差下的上限 $2.17\sigma = 0.210$ ($\sigma = 0.097$); 随机选一个模型的真相关 0.146——选择确有信号 (高 0.053), 但远小于报告的优势。偏差随测试集缩小: $n = 50, 100, 400$ 为 $+0.265, +0.167, +0.076$ 。**嵌套 CV:** 外层评估、内层选模型, 估计 0.193, 同一流程在新个体上的真值 0.200 (差 -0.006)。**留组恒等式。**令 $\hat{y} = Hy$ (固定 λ)。把组 B 记为 y_B , 对剩余个体重新拟合得到 $\hat{y}_B^{(-B)}$ 。则 $e_B^{(-B)} = (I - H_{BB})^{-1}e_B$ (线性平滑器的 Sherman–Morrison–Woodbury 形式), 习题 27.20 的数值差 3×10^{-15} 。**验证设计。**目标是预测新家系, 则同胞散布的随机折乐观: 习题 27.20 (80 个家系 $\times 8$, 新家系 60 个) 随机折相关 0.708, 按家系折 0.525, 新家系真值 0.571; 家系大小为 4、8、16 时随机折比真值高 0.082, 0.137, 0.091, 家系折比真值低 0.125, 0.046, 0.051 (训练集少 20%)。

拓展阅读 基因组预测方法

Meuwissen、Hayes 与 Goddard (2001) 提出 BayesA/B; VanRaden (2008) 与 Habier 等 (2011) 讨论 GBLUP 与 Bayes 方法的关系; Gianola 与 van Kaam (2008) 把 RKHS 引入基因组预测; Jiang 与 Reif (2015) 提出了上位性核与方差估计; Garrick、Taylor 与 Fernando (2009) 发展了去回归育种值的权重; Varma 与 Simon (2006) 及 Cawley 与 Talbot (2010) 指出了模型选择偏差与嵌套 CV 的必要性。关于大样本下 GBLUP 与 Bayes 方法接近的结论, 见 Erbe 等 (2012) 与 Moser 等 (2015)。

易错辨析

- GBLUP 与岭回归不是“两种方法”: 同一估计的两种表示, 差别只在计算维度。
- BayesC π 不是在多基因性状上的魔法: 稀疏、有大效应时收益大, 多基因时仅略好 (习题 27.16: 0.538 对 0.515)。
- 上位方差可估不代表预测更好: 习题 27.17 中 $\hat{\sigma}_{aa}^2 = 0.271$, 但对育种值 a 的预测相关 0.523 低于 GBLUP 的 0.539。

- 对代理表型的相关不是准确度：习题 27.19 中 0.269 对真值 0.380。
- 在同一测试集上挑模型并报告相关：偏高 0.167（习题 27.18），应使用嵌套 CV 或独立测试集。
- 随机折不对应“预测新家系”：习题 27.20 中随机折高估 0.08—0.14。

27.5 习题

一、单项选择题

27.1 ★ [单选] SNP-BLUP（岭回归）与 GBLUP 给出相同预测的条件是

- (A) $\lambda_\beta = \lambda \sum 2p_j q_j$ 且 $G = ZZ' / \sum 2p_j q_j$ ，使用相同的中心化
 (B) 标记数等于个体数
 (C) 所有 SNP 的频率相同
 (D) 无需任何条件

[答案]

27.2 ★ [单选] GBLUP 对 G 的特征值 d_k 方向的收缩因子为

- (A) $d_k / (d_k + \lambda)$ (B) $\lambda / (d_k + \lambda)$ (C) $1/d_k$ (D) d_k

[答案]

27.3 ★★ [单选] BayesC π 相对 GBLUP 的预测优势最显著的情形是

- (A) 大量等效应的微效 QTL (B) 少数大效应 QTL（稀疏结构）
 (C) 完全没有 LD (D) 表型方差为 0

[答案]

27.4 ★★ [单选] 核回归的表示定理表明，对新个体的预测需要

- (A) 新个体与训练个体间的核值 $k(x_*, x_i)$
 (B) 重新拟合整个模型 (C) 新个体的表型
 (D) 新个体的系谱

[答案]

27.5 ★★ [单选] 在同一个小测试集上比较 60 个模型并报告最优者的相关，该报告值

- (A) 无偏 (B) 偏乐观 (C) 偏悲观
 (D) 与测试集大小无关

[答案]

- 27.6 ★★★ [单选] 目标是预测“全新家系”的育种值。与随机 K 折相比，按家系分折的交叉验证
- (A) 更乐观 (B) 更接近目标但略偏悲观 (C) 完全相同
- (D) 无法计算 [答案]

二、判断与改错题

- 27.7 ★ [判断] 当方差比与中心化一致时，SNP-BLUP 与 GBLUP 的 EBV 数值上完全相同。 [答案]
- 27.8 ★ [判断] 只要 REML 估计出的上位方差大于 0，用上位性核选育种值就一定比 GBLUP 更准。 [答案]
- 27.9 ★★ [判断] 对 DYD 作加权 GBLUP 时，权重与女儿数成正比（相差一个常数 $1/k$ ）。 [答案]
- 27.10 ★★ [判断] 验证公牛上 $\hat{g}$ 与其 DYD 的相关就是 $\hat{g}$ 对真育种值的准确度。 [答案]

三、填空题

- 27.11 ★ [填空] G 的平均对角元为 1, $h^2 = 0.25$, 则 $\lambda = \underline{\hspace{2cm}}$; 特征值 (4, 1, 0.25) 的有效自由度 $\sum d_k / (d_k + \lambda) = \underline{\hspace{2cm}}$ (三位小数)。 [答案]
- 27.12 ★ [填空] $\sum 2p_j q_j = 300$, $\sigma_e^2 / \sigma_g^2 = 1$, SNP-BLUP 的岭惩罚 $\lambda_\beta = \underline{\hspace{2cm}}$ 。 [答案]
- 27.13 ★★ [填空] 100 个独立的相关估计，标准误均为 0.05，选最大者报告，期望偏高量约为 $\underline{\hspace{2cm}}$ (取 $E[\max] \approx 2.5\sigma$)。 [答案]
- 27.14 ★★ [填空] 线性平滑器中某观测的残差为 0.6, 杠杆 $H_{ii} = 0.4$, 则留一残差为 $\underline{\hspace{2cm}}$ 。 [答案]

四、计算题

- 27.15 ★★★ [计算] SNP-BLUP 与 GBLUP、谱收缩与留一恒等式。 $n = 300$, $m = 2000$ (40 个 LD 块), $h^2 = 0.5$: 核验预测等价、特征值占比、 $\text{df}(\lambda)$ 与测试误差，用 PRESS、GCV 选 λ 。 [程序] `ch27/ex27_15_ridge_gblup_spectral.py` [答案]

27.16 ★★★ [计算] **GBLUP 与 BayesC π** 。训练 300、测试 1000，多基因（400 个 QTL）与稀疏（15 个 t_3 效应 QTL）两种结构：比较预测相关、 $\hat{\pi}$ 与 PIP。 [程序] [ch27/ex27_16_bayes_alphabet.py](#) [答案]

27.17 ★★★ [计算] **核方法与上位性**。100 个全同胞家系 $\times 10$ ，比较 GBLUP、Gaussian 核与 $G + G\#G$ 多核，在纯加性与加性 + 上位性两种情形下对总遗传值与育种值的预测，并核验表示定理。 [程序] [ch27/ex27_17_kernel_epistasis.py](#) [答案]

27.18 ★★★ [计算] **赢家诅咒**。60 个候选模型、训练 200、小测试集 100：计算朴素报告、真准确度、随机选的准确度，以及嵌套 CV 估计和测试集规模的影响。 [程序] [ch27/ex27_18_winners_curse_nested_cv.py](#) [答案]

27.19 ★★★ [计算] **代理表型权重**。训练 400 头公牛、验证 200 头，女儿数 5–300：比较未加权、正确加权与平方根权，并修正验证相关。 [程序] [ch27/ex27_19_proxy_weights.py](#) [答案]

27.20 ★★★ [计算] **CV 设计与留组恒等式**。80 个家系 $\times 8$ ，新家系 60 个：核验留一家系恒等式，比较随机折、家系折与新家系真值，并改变家系大小。 [程序] [ch27/ex27_20_cv_design_block_identity.py](#) [答案]

27.21 ★ [计算] **G 的特征值** $(4, 1, 0.25)$, $\lambda = 1$, $y - \bar{y}$ 在特征方向上的投影 $\gamma = (3.0, 1.0, 0.5)$ 。求各方向的收缩因子、拟合分量与有效自由度。 [答案]

27.22 ★★ [计算] 某 SNP 满足 $x'x = 100$, $\sigma_e^2 = 1$, $\sigma_b^2 = 0.04$ ，当前残差（去掉该位点后） $r = x'e_{-j} = 5$ ，先验包含概率 $1 - \pi = 0.1$ 。求 v_j 、 m_j 、对数贝叶斯因子与该位点的后验包含概率。 [答案]

五、推导与证明题

27.23 ★★ [证明] 证明 $(Z'Z + \lambda_\beta I)^{-1}Z' = Z'(ZZ' + \lambda_\beta I)^{-1}$ ，并由此推出 SNP-BLUP 与 GBLUP 的等价。 [答案]

27.24 ★★★ [证明] 设 $\hat{y} = Hy$, H 为岭回归（不含截距）的帽子矩阵，证明留一残差 $e_i^{(-i)} = e_i / (1 - H_{ii})$ 。 [答案]

27.25 ★★★ [证明] 证明留组恒等式 $e_B^{(-B)} = (I - H_{BB})^{-1}e_B$ (岭回归, 固定 λ , 不含截距)。

[答案]

27.26 ★★★ [证明] 证明 C 个独立 $N(0, \sigma^2)$ 变量的期望最大值满足 $E[\max] \approx \sigma\sqrt{2\ln C}$ (渐近), 并说明正相关的估计误差使偏差变小。

[答案]

六、综合分析与研究设计题

27.27 ★★ [综合] 某肉牛育种公司有 2 万头分型个体、60 万 SNP、含大量全同胞与半同胞, 需要比较 GBLUP、BayesC π 与核方法用于预测新家系。设计比较方案。 [答案]

27.28 ★★★ [综合] 某奶牛场用公牛的 DYD (女儿数 5 到 500 不等) 训练基因组预测。设计权重、验证与报告方案, 说明为何不能只报告对 DYD 的相关。 [答案]

27.29 ★★★ [综合] 研究者在 100 组超参数 (核带宽、 λ 、特征筛选阈值) 中选了测试相关最高者, 并报告其置信区间。指出问题, 给出一个包含嵌套 CV 与独立测试集的修正方案。 [答案]

27.6 参考答案与解析

一、单项选择题

27.1 A。 等价需要 $\lambda_\beta = \lambda \sum 2p_j q_j$ ($\sum 2p_j q_j$ 为 G 的分母)、相同的中心化与含截距的相同处理。见推导 27.1。习题 27.15: 最大差 7.8×10^{-16} 。 [题目]

27.2 A。 $\hat{g} = U \text{diag}[d_k / (d_k + \lambda)] U' (y - \bar{y})$ 。小特征值方向被强烈收缩。 [题目]

27.3 B。 稀疏、有大效应时 BayesC π 的相关 0.968 远高于 GBLUP 的 0.504 (习题 27.16); 多基因下仅 0.538 对 0.515。 [题目]

27.4 A。 $\hat{f}(x_*) = \sum_i \alpha_i k(x_*, x_i)$, 只需 k_* 与训练得到的 α 。习题 27.17: 并入测试个体与仅用核向量的预测最大差 1.1×10^{-15} 。 [题目]

27.5 B。 赢家诅咒。习题 27.18: 报告 0.366, 真 0.199, 偏高 0.167。 [题目]

27.6 B。 家系折与目标一致, 但训练集少 20%, 略偏悲观: -0.046 (家系大小 8), 随机折 $+0.137$ (习题 27.20)。 [题目]

二、判断与改错题

27.7 正确。见推导 27.1, 差异只来自数值误差 (10^{-16})。 [题目]

27.8 错误。习题 27.17: $\hat{\sigma}_{aa}^2 = 0.271$ (可识别), 但 $G + G\#G$ 对育种值 a 的相关 0.523, GBLUP 为 0.539; 对总遗传值也只有 0.493 对 0.484。要选育种值时核没有收益。

[题目]

27.9 正确。 $w_i = n_i/k = r_i^2/(1 - r_i^2)$ 。习题 27.19: 与 $r^2/(1 - r^2)$ 权的预测差 7×10^{-16} 。

[题目]

27.10 错误。对 DYD 的相关含有 DYD 的噪声, 低估准确度: 0.269 对真值 0.380。须除以 $\sqrt{r^2}$ 。 [题目]

三、填空题

27.11 $\lambda = (1-0.25)/0.25 = 3$; $df = 4/7 + 1/4 + 0.25/3.25 = 0.5714 + 0.25 + 0.0769 = 0.898$ 。

[题目]

27.12 $\lambda_\beta = \lambda \sum 2p_j q_j = 1 \times 300 = 300$ 。 [题目]

27.13 约 $2.5 \times 0.05 = 0.125$ (100 个独立标准正态的期望最大值 ≈ 2.51)。 [题目]

27.14 $e_i/(1 - H_{ii}) = 0.6/0.6 = 1.0$ 。 [题目]

四、计算题

27.15 等价最大差 7.8×10^{-16} ; 前 1、5、20、50 个特征值占迹比例 0.010, 0.046, 0.162, 0.349。

λ	0.05	0.5	1	5	30	1000
df	279.8	184.7	137.6	47.6	9.6	0.3
测试 MSE (对真遗传 值)	0.5015	0.4565	0.4570	0.4972	0.5314	0.5416
测试相关 (对真值)	0.3890	0.4004	0.3996	0.3845	0.3717	0.3679
PRESS	341.9	302.7	292.1	285.1	288.1	289.6
GCV	1.134	1.005	0.970	0.949	0.960	0.965

留一恒等式 ($\lambda = 2$) 最大差 1.1×10^{-15} 。PRESS 与 GCV 都选 $\lambda = 5$, 测试相关 0.3845; 测试集最优 $\lambda = 0.5$ (0.4004)。解读: MSE 曲线在 0.5—1 附近最小, 过强

与过弱收缩都差； $\lambda = 5$ 比最优相关低 0.016，对 $n = 300$ 的选择误差可以接受。

[题目]

27.16 $n = 300, m = 800, h^2 = 0.6$:

结构	GBLUP	BayesC π	$\hat{\pi}_{incl}$	PIP>0.5 的真 QTL / 其他
多基因 (400 个 QTL)	0.515	0.538	0.319	30/400 / 13
稀疏 (15 个 t_3 效应 QTL)	0.504	0.968	0.015	5/15 / 0

σ_e^2 前后半段相对差 7.3% 与 0.9%。解读：稀疏结构下相关提升 0.46，因为抓住了大效应；多基因下 BayesC π 的包含概率 0.32 说明数据支持多个小效应，预测接近岭回归。PIP>0.5 只检出了 5/15 个真 QTL (LD 使信号分散到邻近位点)，但预测准确度极高。

[题目]

27.17 100 个全同胞家系 $\times 10$ ，随机划分训练 500/测试 500，8 次重复：

情形	方法	对总遗传值	对育种值 a
纯加性	GBLUP	0.722	0.722
纯加性	Gaussian 核	0.721	0.721
纯加性	$G + G\#G$	0.722	0.722
加性 + 上位性	GBLUP	0.484	0.539
加性 + 上位性	Gaussian 核 ($\theta \approx 1.5$)	0.495	0.526
加性 + 上位性	$G + G\#G$	0.493	0.523

纯加性时 $\hat{\sigma}_a^2 = 0.462$ 、 $\hat{\sigma}_{aa}^2 = 0.067$ (占 0.11)；加性 + 上位性时 $\hat{\sigma}_a^2 = 0.276$ 、 $\hat{\sigma}_{aa}^2 = 0.271$ (占 0.46，真 0.5)。表示定理最大差 1.1×10^{-15} 。解读：上位方差在有亲属时可估；总遗传值预测略有改善 (0.484 $\rightarrow$ 0.493)；育种值预测不升反降 (0.539 $\rightarrow$ 0.523)，因为部分加性信号被误分到上位性项。选种目标是育种值时，仍应以加性模型为主。

[题目]

27.18 60 个候选，训练 200，小测试集 100，30 次重复 (嵌套 CV 6 次)：朴素报告 (对表型的相关) 0.366；该模型在 3000 头新个体上的真相关 0.199 (对遗传值 0.283)；随机一个模型 0.146；平均偏高 0.167。单个相关估计 $\sigma = 0.097$ ，独立误差下偏差上限 $2.17\sigma = 0.210$ 。偏差随测试集： $n = 50 + 0.265$ ， $n = 100 + 0.167$ ， $n = 400 + 0.076$ 。嵌套 CV 估计 0.193，新个体真值 0.200 (差 -0.006)。解读：选择流程本身的真实准确度是 0.20，报告 0.37 近乎翻倍。

[题目]

27.19 训练 400、验证 200, $k = 20$, 25 次重复: 对真育种值的相关, 未加权 0.350, 正确加权 0.380, 平方根权 0.377; 与 $r^2/(1-r^2)$ 权的预测差 7×10^{-16} 。对验证 DYD 的相关 0.269; $/\sqrt{r^2}$ 得 0.341; 按 r_i^2 加权后修正 0.355; 真值 0.380。解读: 加权提高 0.03; 对代理的相关低估真准确度 0.11, 修正后仍略低 (0.04), 因为 r_i^2 在公牛间不等, 平均修正不完全。 [题目]

27.20 80 个家系 $\times 8$: 留一家系恒等式 (20 个家系) 最大差 3×10^{-15} 。

家系大小	随机折	家系折	新家系真值	随机 - 真值	家系 - 真值
4	0.565	0.359	0.484	+0.082	-0.125
8	0.708	0.525	0.571	+0.137	-0.046
16	0.801	0.658	0.710	+0.091	-0.051

解读: 随机折把同胞留在训练集中, 亲属关系强, 高估新家系准确度 0.08—0.14; 家系折略偏悲观 (训练集少 20%), 偏差 0.05—0.13。目标是预测新家系时, 家系折更适合; 也可用 10 折以减小悲观偏差。 [题目]

27.21 收缩因子 $d_k/(d_k + 1) = (0.8, 0.5, 0.2)$; 拟合分量 $(3.0 \times 0.8, 1.0 \times 0.5, 0.5 \times 0.2) = (2.4, 0.5, 0.1)$; 有效自由度 $0.8 + 0.5 + 0.2 = 1.5$ 。最小特征值方向被压到原来的 20%, 主方向几乎保留。 [题目]

27.22 $v_j = (100/1 + 1/0.04)^{-1} = 1/125 = 0.008$; $m_j = 0.008 \times 5/1 = 0.04$; 对数贝叶斯因子 $= \frac{1}{2} \ln(0.008/0.04) + \frac{1}{2} \times 0.04^2/0.008 = -0.8047 + 0.1 = -0.7047$ 。先验对数几率 $\ln(0.1/0.9) = -2.1972$, 后验对数几率 -2.9019 , 包含概率 $= 1/(1 + e^{2.9019}) = 0.0521$ 。该位点的证据不足 ($m_j/\sqrt{v_j} = 0.447$, 仅 0.45 个后验标准差), 即使该位点被包含, 其效应均值也仅 0.04。 [题目]

五、推导与证明题

27.23 证明。由 $(Z'Z + \lambda_\beta I)Z' = Z'(ZZ' + \lambda_\beta I)$ (左右展开均为 $Z'ZZ' + \lambda_\beta Z'$)。两端左乘 $(Z'Z + \lambda_\beta I)^{-1}$ 、右乘 $(ZZ' + \lambda_\beta I)^{-1}$, 得 $Z'(ZZ' + \lambda_\beta I)^{-1} = (Z'Z + \lambda_\beta I)^{-1}Z'$ 。于是 $\hat{\beta} = (Z'Z + \lambda_\beta I)^{-1}Z'\tilde{y} = Z'(ZZ' + \lambda_\beta I)^{-1}\tilde{y}$, 预测 $Z\hat{\beta} = ZZ'(ZZ' + \lambda_\beta I)^{-1}\tilde{y}$ 。令 $G = ZZ'/s$, $\lambda = \lambda_\beta/s$: $ZZ' = sG$, $(sG + \lambda_\beta I) = s(G + \lambda I)$, 两个 s 消去, 即 GBLUP。■ [题目]

27.24 证明。设 $H = X(X'X + \lambda I)^{-1}X'$, 删去第 i 个观测的岭估计 $\hat{\beta}^{(-i)} = (A - x_i x_i')^{-1}(X'y - x_i y_i)$, $A = X'X + \lambda I$ 。由 Sherman-Morrison: $(A - x_i x_i')^{-1} = A^{-1} + \frac{A^{-1}x_i x_i' A^{-1}}{1 - H_{ii}}$,

$$H_{ii} = x_i' A^{-1} x_i. \text{ 则 } x_i' \hat{\beta}^{(-i)} = \hat{y}_i + \frac{H_{ii} \hat{y}_i}{1-H_{ii}} - H_{ii} y_i - \frac{H_{ii}^2 y_i}{1-H_{ii}} = \frac{\hat{y}_i - H_{ii} y_i}{1-H_{ii}}, \text{ 所以 } y_i - x_i' \hat{\beta}^{(-i)} = \frac{y_i - \hat{y}_i}{1-H_{ii}} = \frac{e_i}{1-H_{ii}}. \blacksquare$$

[题目]

27.25 证明。把 Sherman-Morrison 换成 Woodbury: $(A - X_B' X_B)^{-1} = A^{-1} + A^{-1} X_B' (I - H_{BB})^{-1} X_B A^{-1}$, $H_{BB} = X_B A^{-1} X_B'$. 删去组 B 后 $\hat{\beta}^{(-B)} = (A - X_B' X_B)^{-1} (X' y - X_B' y_B)$. 代入得 $X_B \hat{\beta}^{(-B)} = \hat{y}_B + H_{BB} (I - H_{BB})^{-1} \hat{y}_B - H_{BB} y_B - H_{BB} (I - H_{BB})^{-1} H_{BB} y_B$, 整理得 $(I - H_{BB})^{-1} (\hat{y}_B - H_{BB} y_B)$, 因此 $y_B - X_B \hat{\beta}^{(-B)} = (I - H_{BB})^{-1} (y_B - \hat{y}_B) = (I - H_{BB})^{-1} e_B$.

[题目]

27.26 证明 (概要)。设 $X_c \sim N(0, 1)$ 独立, $M = \max_c X_c$. $P(M \leq x) = \Phi(x)^C$. 取 $x_C = \sqrt{2 \ln C} - \frac{\ln \ln C + \ln 4\pi}{2\sqrt{2 \ln C}}$, 则 $P(M \leq x_C + t/\sqrt{2 \ln C}) \rightarrow \exp(-e^{-t})$ (Gumbel 极限, Fisher-Tippett), 故 $E[M] = x_C + \gamma/\sqrt{2 \ln C} + o(1)$ ($\gamma = 0.577$), 主项为 $\sqrt{2 \ln C}$. $C = 100$ 时 $x_C = 3.035 - 0.669 = 2.37$, 加 γ 项得 2.56, 与模拟 2.507 一致; $C = 60$ 时 $x_C = 2.17$ (习题 27.18 取此值作为上限). 若 X_c 相关系数为正, 则 $\max$ 的期望变小 (极端情形 X_c 全相等则 $E[M] = 0$); 习题 27.18 中 60 个相关估计的实际偏差 0.167 是独立误差上限 0.210 的 79%. $\blacksquare$

[题目]

六、综合分析与研究设计题

27.27 方案 (1) 目标: 预测新家系的育种值, 因此以按家系分折为主 (习题 27.20: 随机折高估 0.08—0.14), 并保留一个晚出生家系的独立测试集. (2) 模型: GBLUP (REML 估计方差)、BayesC π (至少两条链, 检查 $\hat{R}$)、核方法 ($G + G\#G$ 与 Gaussian); 计算: 2 万头个体, GBLUP 用 $n \times n$ 的系统, BayesC π 在 60 万 SNP 下需限制为候选区域或预先筛选. (3) 评价: 对表型的相关、对去回归育种值的相关、预测对表型的回归斜率 (偏差)、对真值的 PEV 不可得时用嵌套 CV 报告; (4) 超参数: 只在内层选择 (习题 27.18: 同一集上选择偏高 0.17); (5) 比较: 用配对差异的置信区间 (按家系自助法) 而不是各自的点估计; (6) 结论: 若稀疏大效应存在 (习题 27.16), BayesC π 可能显著胜出; 若各方法差距在家系内抽样误差之内, 则选最简单的 GBLUP.

[题目]

27.28 方案 (1) 训练: 以 DYD 或去回归育种值为响应, 权重 $w_i = r_i^2 / (1 - r_i^2)$ (习题 27.19: 加权比未加权提高 0.03). 去回归时需去除亲本信息, 避免重复计入. (2) 验证: 留出出生较晚的公牛, 同样的权重; 报告对 DYD 的相关与按 $\sqrt{r^2}$ 修正后的 “准确度” (习题 27.19: 0.269 $\rightarrow$ 0.341, 真值 0.380), 并给出修正的假设 (噪声独立、可靠度已知). (3) 按可靠度分层报告: 女儿数少的公牛, 相关本身受噪声支配. (4) 检查: 对表型的回归斜率 (偏差), $\text{Var}(\hat{g})$ 与 σ_a^2 (膨胀), 按出生年份的趋势. (5)

报告：只报告对 DYD 的相关会低估准确度，并会使人错误地认为基因组预测“不够准确”；相反，对低可靠度公牛选最高者再汇报，会陷入赢家诅咒。 [题目]

27.29 问题：(1) 100 组超参数在同一测试集上挑最高者，报告值偏高（习题 27.18：60 个候选偏高 0.167， $n_{test} = 50$ 时 0.265）。(2) 置信区间只反映单个模型在该测试集上的抽样误差，没有包含选择过程，覆盖率远低于名义水平。**修正方案：**(a) 训练数据内做嵌套 CV：外层折评估、内层折选超参数，外层相关的平均即“选择流程”的准确度估计（习题 27.18：0.193 对真 0.200）。(b) 最终模型用全部训练数据与内层 CV 选出的超参数重训，在**从未参与选择**的独立测试集（最好是更晚出生或不同家系）上报告相关与置信区间（按家系自助）。(c) 若测试集小，先降低候选数（用先验缩小到 5–10 组），或使用 1 标准误规则偏向简单模型。(d) 报告所有候选的性能分布，让读者看到选择的幅度。 [题目]

单步基因组评定

28.1 本章导学

学习目标

1. 理解单步评定的核心思想：把系谱关系 A 与基因组关系 G 合成统一的 H ，使分型与未分型动物在同一个混合模型中评定。
2. 会推导 H 的条件构造与逆矩阵 $H^{-1} = A^{-1} + \text{diag}(0, G^{-1} - A_{22}^{-1})$ ，区分 A_{22}^{-1} 与 $(A^{-1})_{22}$ 。
3. 掌握 G 的尺度调整 (β, α 匹配 A_{22}) 与 5% 混合，并理解“拼接矩阵”为何不合法。
4. 理解 APY 近似的逆矩阵公式、核心规模与核心选择，以及条件相关与 KL 诊断。
5. 理解元基础群体 Γ 的定义、半正定性与翻转不变性。
6. 会用预条件共轭梯度求解单步方程，利用目标误差恒等式设定停止规则，并计算差值的可靠度与随机化对角估计。

重点与难点

重点： $B = A_{12}A_{22}^{-1}$; $H^{-1} - A^{-1}$ 只有分型块非零; $G^* = \beta G + \alpha$; APY 逆 $\begin{bmatrix} G_{cc}^{-1} + T'D^{-1}T & -T'D^{-1} \\ -D^{-1}T & D^{-1} \end{bmatrix}$; 目标误差 $t - c'\theta_k = z'r_k$; $R(c) = 1 - \lambda c'C^{uu}c/c'Hc$ 。

难点： $A_{22}^{-1} \neq (A^{-1})_{22}$ 的混淆; G 与 A_{22} 的参照不一致带来的偏差; 停止规则只看残差而忽略目标; 可靠度需要完整的误差协方差。

本章承接第 22 章（动物模型与 A^{-1} ）、第 26 章（ G 的构建与尺度相容）与第 27 章（GBLUP）。单步评定把“只有系谱的动物”并入基因组预测，是现代畜禽联合育种的主流方法；其实现的核心困难不在公式，而在**参照一致、数值稳定与可审计**。

28.2 知识结构图




图 28.1 第 28 章知识结构图

左侧是模型（ H 、 G 的相容、元基础群体），右侧是计算与评价（APY、求解器、可靠度）。

28.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
条件回归	$B = A_{12}A_{22}^{-1}$, $S_1 = A_{11} - A_{12}A_{22}^{-1}A_{21}$	下标 1 未分型，2 已分型
H	$\begin{bmatrix} S_1 + BGB' & BG \\ GB' & G \end{bmatrix}$	G 与 A_{22} 同参照
逆矩阵	$H^{-1} = A^{-1} + \begin{bmatrix} 0 & 0 \\ 0 & G^{-1} - A_{22}^{-1} \end{bmatrix}$	A_{22}^{-1} 为 A_{22} 的逆
尺度调整	$G^* = \beta G + \alpha$	匹配平均对角与平均元素
混合	$G_w = (1 - w)G^* + wA_{22}$	$w = 0.05$ 保证正定
APY 条件协方差	$T = G_{nc}G_{cc}^{-1}$, $D = \text{diag}(G_{nn} - TG_{cn})$	非核心

概念	公式或定义	成立条件与提示
APY 诊断	$KL = -\frac{1}{2} \log C ,$ $C = D^{-1/2} S D^{-1/2}$	$C = I$ 时 APY 精确
元基础群体	$\Gamma_{bb'} = \frac{2}{m} \sum_k (2p_{bk} - 1)(2p_{b'k} - 1)$	半正定, 翻转不变
PCG 收缩	$\ e_k\ _L \leq 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \ e_0\ _L$	κ 为预条件后的条件数
目标误差	$t - c' \theta_k = z' r_k, \quad z = L^{-1} c$	$r_k = d - L \theta_k$
可靠度	$R(c) = 1 - \lambda c' C^{uu} c / (c' H c)$	差值含误差协方差
Hutchinson	$\text{diag}(C) \approx \frac{1}{K} \sum_k z_k \circ C z_k$	$\text{RMSE} \sqrt{\sum_{j \neq i} C_{ij}^2 / K}$

28.4 补充内容与公式推导

推导 28.1 H 的分解与逆矩阵公式

令 $T = \begin{bmatrix} I & B \\ 0 & I \end{bmatrix}$, $B = A_{12} A_{22}^{-1}$ 。系谱矩阵可写为 $A = T \begin{bmatrix} S_1 & 0 \\ 0 & A_{22} \end{bmatrix} T'$: 验证 $A_{12} = B A_{22}$, $A_{11} = S_1 + B A_{22} B'$ 。把已分型动物的方差由 A_{22} 换成 G , 条件分布 $u_1 | u_2$ 保持不变, 则 $H = T \begin{bmatrix} S_1 & 0 \\ 0 & G \end{bmatrix} T'$ 。两者求逆: $H^{-1} - A^{-1} = T'^{-1} \begin{bmatrix} 0 & 0 \\ 0 & G^{-1} - A_{22}^{-1} \end{bmatrix} T^{-1}$, 而 $T^{-1} = \begin{bmatrix} I & -B \\ 0 & I \end{bmatrix}$, $T'^{-1} = \begin{bmatrix} I & 0 \\ -B' & I \end{bmatrix}$, 乘积保持右下块不变: $H^{-1} = A^{-1} + \text{diag}(0, G^{-1} - A_{22}^{-1})$ 。注意 A_{22}^{-1} 是 A_{22} 的逆, 不是 A^{-1} 的右下块: 习题 28.15 (1060 头, 分型 300 头) 二者的最大差为 7.57, 差由舒尔补 $F_{21} F_{11}^{-1} F_{12}$ 解释。两条路线 (条件构造与逆矩阵公式) 得到的 $HH^{-1} - I$ 最大元素 3.2×10^{-14} 。

推导 28.2 G 的尺度调整与“拼接矩阵”的非法性

VanRaden 的 G 以分型样本频率为参照, 对角元均值与非对角元均值 (负、接近 $-\overline{G_{ii}}/(n-1)$) 与系谱 A_{22} 的 $(1 + \bar{F}, \bar{A}_{off})$ 不同。取 $G^* = \beta G + \alpha$, 使 $\overline{\text{diag}}(G^*) = \overline{\text{diag}}(A_{22})$ 、 $\overline{G^*} = \overline{A_{22}}$ (全体元素均值), 再混合 $G_w = 0.95 G^* + 0.05 A_{22}$ 以保证正定。习题 28.15: A_{22} 的对角均值 1.0411、非对角均值 0.0959; 原 G 为 0.9940 与 -0.0033; 调整得 $\beta = 0.9477$, $\alpha = 0.0991$ (调整后 G 对 A_{22} 的回归斜率 1.015)。**拼接矩阵**: 直接把 A 的右下角换成 G 、其余不变, 会破坏 u_1, u_2 的协方差一致性——习题 28.15 中其最小特征值为 -1.865 (非半正定), 与正确 H 的最大元素差 0.2598; 而 H 的最小特

征值 $0.0332 > 0$ 。96.8% 的未分型动物的关系在 H 下得到更新（对角元均值 $+0.0024$ ，范围 $[-0.109, +0.103]$ ）。

推导 28.3 单步评定的预测表现

混合模型方程为
$$\begin{bmatrix} X'X & X'Z \\ Z'X & Z'Z + \lambda H^{-1} \end{bmatrix} \begin{bmatrix} \hat{\beta} \\ \hat{u} \end{bmatrix} = \begin{bmatrix} X'y \\ Z'y \end{bmatrix}, \lambda = \sigma_e^2 / \sigma_a^2, \text{ 其解等价于 } \hat{u} = HZ'V^{-1}(y - X\hat{\beta}), V = ZHZ'\sigma_a^2 + I\sigma_e^2 \text{ (习题 28.16: MME 解与 GLS 形式最大差 } 8.7 \times 10^{-13} \text{)。}$$
比较四种评定（4 次重复，5 世代闭锁群体， $h^2 = 0.3$ ，候选为第 5 代分型无表型动物）：

评定	候选准确性	候选斜率	候选偏差/ σ_a	未分型准确性
PBLUP	0.433	0.971	-0.063	0.652
GBLUP（仅分型）	0.531	1.045	0.004	—
ssGBLUP-raw	0.578	1.085	0.009	0.655
ssGBLUP	0.578	1.108	-0.045	0.655

单步评定对候选的准确性比 PBLUP 高 0.145、比仅分型 GBLUP 高 0.047（后者只用 500 头分型个体，丢失了未分型亲属的表型信息）；对已有大量表型的未分型动物准确性几乎不变（0.655 对 0.652）。斜率 1.1 附近表明候选预测略有欠膨胀；不调整的 G 在此模拟中对准确性影响很小，但偏差与斜率受参照不一致的影响更大，这与第 26 章的结论一致。

推导 28.4 APY 逆矩阵与条件相关诊断

把分型动物分为核心 c 与非核心 n 。 $G = \begin{bmatrix} I & 0 \\ T & I \end{bmatrix} \begin{bmatrix} G_{cc} & 0 \\ 0 & S \end{bmatrix} \begin{bmatrix} I & T' \\ 0 & I \end{bmatrix}$, $T = G_{nc}G_{cc}^{-1}$, $S = G_{nn} - TG_{cn}$ 。APY 以 $D = \text{diag}(S)$ 代替 S ，逆矩阵为 $G_{APY}^{-1} = \begin{bmatrix} G_{cc}^{-1} + T'D^{-1}T & -T'D^{-1} \\ -D^{-1}T & D^{-1} \end{bmatrix}$ ，稀疏、计算量为 $O(n_c^3 + n_n n_c^2)$ 。误差来自忽略的条件相关 $C = D^{-1/2}SD^{-1/2}$ ，KL 散度 $-\frac{1}{2} \log |C|$ 度量信息损失；当只有一个非核心动物时 $C = 1$ ，APY 精确。习题 28.17（800 头分型）： G 的特征值累计解释 90%/95%/98%/99% 需 318/440/576/651 个方向（核心规模参考）。核心规模 $n_c = 25, 50, 100, 200, 400$ 、随机核心的 KL = 391.5, 336.5, 274.4, 176.2, 65.9，贪心（条

件方差迹) 核心 327.5, 268.5, 199.3, 121.3, 47.1; 对精确 GBLUP 的候选预测相关, 随机 0.508, 0.738, 0.871, 0.951, 0.989, 贪心 0.653, 0.806, 0.910, 0.965, 0.993, “最老动物”核心 0.663, 0.681, 0.755, 0.828, 0.936 (斜率 1.64 起, 明显偏高)。结论: 核心规模接近有效维度时, APY 与精确解几乎一致; 核心的**代表性**比数量更重要。

推导 28.5 PCG、目标误差恒等式与停止规则

设 $L\theta = d$ 为对称正定系统, 预条件 M , PCG 的能量范数误差满足 $\|e_k\|_L \leq 2[(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)]^k \|e_0\|_L$, κ 为 $M^{-1}L$ 的条件数。习题 28.18 (维数 680): κ 为 313.0 (无预条件)、156.7 (对角与块对角), 相对残差降到 $10^{-4}, 10^{-8}, 10^{-12}$ 所需迭代 37/88/133 (无) 与 37/79/120 (对角)。感兴趣的目标 $t = c'\theta$ (如两个候选的差值), 定义对偶解 $Lz = c$, 则 $t - c'\theta_k = c'L^{-1}(d - L\theta_k) = z'r_k$, 并且 $|t - c'\theta_k| \leq \sqrt{c'L^{-1}c} \sqrt{r_k'L^{-1}r_k}$ 。数值上: 第 5、10、20、40、80 次迭代的相对残差 $2.3 \times 10^{-2}, 9.2 \times 10^{-3}, 1.2 \times 10^{-3}, 5.2 \times 10^{-5}, 8.4 \times 10^{-9}$, 目标误差 +15.7, +19.7, +4.1, +0.26, $+9.7 \times 10^{-6}$, 等于 $z'r_k$ (逐次一致)。**相对残差小并不保证目标误差小**: 第 10 次的相对残差 0.9% 而目标误差达 19.7。**停止容差与决策**: 容差 $10^{-2}, 10^{-3}, 10^{-4}, 10^{-6}, 10^{-8}$ 对应迭代 10, 22, 37, 58, 79 次, 前 10% 名单与精确解的重合率 0.33, 0.53, 0.93, 1.00, 1.00, 最大误差 $5.5\sigma_a, 1.4\sigma_a, 0.11\sigma_a, 1.3 \times 10^{-3}\sigma_a, 1.1 \times 10^{-5}\sigma_a$ 。**热启动**: 加入其余 10% 记录, 零初值需 99 次, 身份映射的旧解 (初始残差 1.1×10^{-3}) 78 次, 错位一行的旧解 89 次, 三者都收敛到同一解 (差 $< 10^{-6}$)。

推导 28.6 元基础群体 Γ 与 A_Γ

未知亲本分属若干基础群体 (如品种或育种群) b , 各群的基础等位基因频率 p_b 不同。以所有位点频率 0.5 的概念群体为参照, 令 $w_{bk} = 2p_{bk} - 1$, 定义 $\Gamma_{bb'} = \frac{2}{m} \sum_k w_{bk} w_{b'k}$ 。则 $\Gamma = \frac{2}{m} WW'$ 半正定; 把某位点的参考等位基因互换, $w_{bk} \rightarrow -w_{bk}$ 对所有 b 同时发生, 乘积不变, 故 Γ 对编码翻转不变 (习题 28.19: 随机翻转一半位点后最大差 0)。 Γ_{bb} 是同一基础群体中两个不同个体的期望关系, $\Gamma_{bb'}$ 是跨群体的期望关系。系谱递推中, 把基础群体 b 视作虚拟个体, 自关系 Γ_{bb} , $A_\Gamma(i, j) = \frac{1}{2}[A_\Gamma(j, s_i) + A_\Gamma(j, d_i)]$, $A_\Gamma(i, i) = 1 + \frac{1}{2}A_\Gamma(s_i, d_i)$ 。习题 28.19 (两个群体, 20000 位点): $\Gamma = \begin{bmatrix} 0.4004 & 0.3880 \\ 0.3880 & 0.4834 \end{bmatrix}$ (特征值 0.0517, 0.8321), 满足 $\Gamma_{AB}^2 \leq \Gamma_{AA}\Gamma_{BB}$ ($0.1505 \leq 0.1935$)。8 头动物的 A_Γ 对角元 1.2—1.302, 传统 A 为 1.0—1.125; $A_\Gamma - A$ 的元素在 $[0.172, 0.400]$ 。基因下落蒙特卡罗 (40 次 $\times$ 20000 位点) 与 A_Γ 的最大差 0.0029, 与传统 A 的最大差 0.400。**非法 Γ** : 元素均在 $[-1, 1]$ 的矩阵不一定是协方差矩阵, 例如特征值 $(-0.8, 1.9, 1.9)$ 。

推导 28.7 可靠度、差值目标与随机化对角估计

L^{-1} 的动物块记为 C^{uu} , $PEV(c'\hat{u}) = c'C^{uu}c\sigma_e^2$, 先验方差 $c'Hc\sigma_a^2$, 可靠度 $R(c) = 1 - \lambda c'C^{uu}c/c'Hc$ 。习题 28.20 (维数 680, $\lambda = 2.333$): 150 头候选的个体可靠度均值 0.276 (0.207—0.371); 按 H 的第二主成分划分的两组各 45 头, 组平均差的先验方差 5.314、PEV 2.348, 可靠度 0.558, 而两组个体可靠度的均值仅 0.280; 若忽略误差协方差, 只用对角元求 PEV 为 0.628 (低估 73%)。随机候选对 (199 对) 忽略误差协方差的相对偏差均值 +1.2%, 最大 +56.9%。大系统不能显式求逆。Hutchinson 估计: $\text{diag}(C) \approx \frac{1}{K} \sum_k z_k \circ Cz_k$, $z_{ki} = \pm 1$, 每个探针一次线性方程求解; i 位置的方差为 $\sum_{j \neq i} C_{ij}^2/K$ 。 $K = 5, 10, 25, 50, 100, 200$ 的经验 RMSE 0.167, 0.118, 0.074, 0.051, 0.037, 0.026, 理论 0.165, 0.116, 0.074, 0.052, 0.037, 0.026; 而相对误差仍达 43.6%, 30.9%, 19.5%, 13.5%, 9.7%, 6.8%。结论: 随机化估计适合群体层面的平均, 不宜用于个体层面的精细排序。

拓展阅读 单步评定的方法与实现

Legarra、Aguilar 与 Misztal (2009)、Christensen 与 Lund (2010) 独立地提出了 H 矩阵; Aguilar 等 (2010) 给出了 H^{-1} 的实现; Misztal 等 (2014) 提出 APY 逆矩阵; Pocrnic 等 (2016) 说明核心规模应与 G 的有效维度相当; Legarra 等 (2015) 提出元基础群体 Γ , Garcia-Baccino 等 (2017)、Macedo 等 (2020) 进一步完善; Legarra 与 Reverter (2018) 提出基于“部分—整体”的单步准确性与偏差检验 (LR 方法); Vitezica 等 (2011) 讨论了 G 与 A_{22} 的尺度。关于大规模求解的预条件, 见 Strandén 与 Lidauer (1999)。

易错辨析

- $A_{22}^{-1} \neq (A^{-1})_{22}$: 混淆两者会得到错误的 H^{-1} (习题 28.15: 最大差 7.57)。
- 拼接矩阵不是 H : 只替换右下角会产生负特征值 -1.87。
- 相对残差小不等于目标误差小: 第 10 次迭代残差 0.9% 而差值的误差 19.7 (习题 28.18)。
- 差值的可靠度不等于个体可靠度的平均: 0.558 对 0.280; 忽略误差协方差低估 PEV 达 73%。
- APY 的核心不是越老越好: 最老动物核心的斜率 1.64 (核心 25 头), 随机与贪心核心要好得多。
- Γ 的元素在 $[-1, 1]$ 不等于合法: 必须半正定。

28.5 习题

一、单项选择题

28.1 ★ [单选] 单步评定中 $H^{-1} = A^{-1} + \text{diag}(0, G^{-1} - A_{22}^{-1})$ 里的 A_{22}^{-1} 是

- (A) A^{-1} 的右下块 (B) A 的右下块 A_{22} 的逆
(C) 单位矩阵 (D) G^{-1}

[答案]

28.2 ★ [单选] 对 G 作 $G^* = \beta G + \alpha$ 调整的目的是

- (A) 使 G 与 A_{22} 的平均对角元与平均元素匹配, 即处于同一参照
(B) 使 G 的对角元恒为 1 (C) 去除近交
(D) 减少 SNP 数

[答案]

28.3 ★★ [单选] APY 近似精确的情形是

- (A) 核心为随机抽取的任何子集
(B) 只有一个非核心动物, 或给定核心后非核心动物的条件协方差为对角
(C) 核心为最老的动物 (D) 总是精确

[答案]

28.4 ★★ [单选] 元基础群体 Γ_{bb} 的含义是

- (A) 基础群体的近交系数
(B) 同一基础群体中两个不同个体的期望关系
(C) 两个群体的 F_{ST} (D) 基础群体大小

[答案]

28.5 ★★ [单选] 用 PCG 求解单步方程时, 把相对残差容差设得过松 (如 10^{-2}) 的主要后果是

- (A) 迭代次数更多
(B) 候选的前 10% 名单与精确解重合率低、个体误差可达数个 σ_a
(C) 解不唯一 (D) 方程变得奇异

[答案]

28.6 ★★★ [单选] 计算两个候选育种值之差的可靠度, 必须使用

- (A) 两个个体可靠度的平均
(B) $c'C'''c$ 与 $c'Hc$, 含两者误差与先验协方差
(C) 较大的个体可靠度 (D) 表型方差

[答案]

二、判断与改错题

28.7 ★ [判断] 把 A 的右下角换成 G 、其余分块保持不变, 也得到合法的 H 。 [答案]

28.8 ★ [判断] 单步评定对“已有大量表型的未分型动物”的准确性一般明显高于系谱 BLUP。 [答案]

28.9 ★★ [判断] 只要元基础群体矩阵 Γ 的各元素都在 $[-1, 1]$ 内, 它就是合法的协方差矩阵。 [答案]

28.10 ★★ [判断] 相对残差已降到 10^{-3} , 说明任一感兴趣目标(如候选差值)的误差一定很小。 [答案]

三、填空题

28.11 ★ [填空] 系谱 $A = \begin{pmatrix} 1 & 0 & 0.5 \\ 0 & 1 & 0.5 \\ 0.5 & 0.5 & 1 \end{pmatrix}$, 动物 1 未分型, 2、3 已分型, 则 $B = A_{12}A_{22}^{-1} =$ _____, $S_1 =$ _____ (四位小数)。 [答案]

28.12 ★ [填空] 一个基础群体所有位点的等位基因频率均为 0.7, 则 $\Gamma_{bb} = \frac{2}{m} \sum (2p-1)^2 =$ _____。 [答案]

28.13 ★★ [填空] 预条件后的条件数 $\kappa = 156.7$, PCG 每次迭代的能量范数误差上界收缩因子 $(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1) \approx$ _____ (三位小数)。 [答案]

28.14 ★★ [填空] $\lambda = 2.333$, 某目标 $c'C^{III}c = 0.4$, $c'Hc = 1.2$, 则可靠度 $R =$ _____ (三位小数)。 [答案]

四、计算题

28.15 ★★★ [计算] **H 矩阵的构造与 G 的调整**。1060 头、300 头分型: 核验两条路线的 H^{-1} 一致, A_{22}^{-1} 与 $(A^{-1})_{22}$ 的差, 求 β, α , 并与“拼接矩阵”比较特征值。 [程序]
ch28/ex28_15_h_matrix.py [答案]

28.16 ★★★ [计算] **单步评定的准确性**。比较 PBLUP、GBLUP、ssGBLUP 与不调整 G 的 ssGBLUP 对第 5 代候选与未分型有表型动物的准确性、斜率与偏差。 [程序]
ch28/ex28_16_ssgblup_accuracy.py [答案]

28.17 ★★★ [计算] APY 近似。800 头分型：对随机、最老、贪心三种核心定义，核心规模 25 至 400，计算 KL、G 的最大元素差、与精确 GBLUP 的相关、斜率与前 10% 重合。[程序] `ch28/ex28_17_apy_core.py` [答案]

28.18 ★★★ [计算] 预条件共轭梯度。维数 680 的单步系统：比较三种预条件的条件数与迭代，核验目标误差恒等式，评价容差对前 10% 名单的影响，并比较三种热启动。[程序] `ch28/ex28_18_pcg_solver.py` [答案]

28.19 ★★★ [计算] 元基础群体。两个基础群体、20000 个位点：计算 Γ ，核验翻转不变性、半正定性与非法例，构造 8 头动物的 A_Γ ，并用基因下落核验。[程序] `ch28/ex28_19_metafounder.py` [答案]

28.20 ★★★ [计算] 单步评定的可靠度。求个体可靠度，两组平均差与随机候选对的可靠度，比较忽略误差协方差的偏差，并用 Hutchinson 估计对角元。[程序] `ch28/ex28_20_reliability.py` [答案]

28.21 ★ [计算] 系谱 $A = \begin{pmatrix} 1 & 0 & 0.5 \\ 0 & 1 & 0.5 \\ 0.5 & 0.5 & 1 \end{pmatrix}$ ，动物 1 未分型，动物 2、3 已分型， $G = \begin{pmatrix} 1 & 0.6 \\ 0.6 & 1 \end{pmatrix}$ 。求 H 的全部元素，以及 $G^{-1} - A_{22}^{-1}$ 。[答案]

28.22 ★★ [计算] APY：核心 $\{c_1, c_2\}$ ， $G_{cc} = \begin{pmatrix} 1 & 0.2 \\ 0.2 & 1 \end{pmatrix}$ ，一个非核心动物 $G_{nc} = (0.4, 0.3)$ ， $G_{nn} = 1$ 。求 T 、 D ，并说明为何此时 APY 精确。[答案]

五、推导与证明题

28.23 ★★ [证明] 由 $A = T \text{diag}(S_1, A_{22})T'$ 与 $H = T \text{diag}(S_1, G)T'$ 证明 $H^{-1} = A^{-1} + \text{diag}(0, G^{-1} - A_{22}^{-1})$ 。[答案]

28.24 ★★★ [证明] 证明 APY 逆矩阵公式 $G_{APY}^{-1} = \begin{bmatrix} G_{cc}^{-1} + T'D^{-1}T & -T'D^{-1} \\ -D^{-1}T & D^{-1} \end{bmatrix}$ ，并证明只有一个非核心动物时 $G_{APY} = G$ 。[答案]

28.25 ★★★ [证明] 设 $L\theta = d$ ， $r_k = d - L\theta_k$ ， $Lz = c$ 。证明 $c'\theta - c'\theta_k = z'r_k$ 以及 $|z'r_k| \leq \sqrt{c'L^{-1}c} \sqrt{r'_k L^{-1} r_k}$ 。[答案]

- 28.26 ★★★ [证明]** 证明 $\Gamma = \frac{2}{m} WW'$ (W 的元素 $w_{bk} = 2p_{bk} - 1$) 半正定, 且对任一位点同时翻转所有基础群体的参考等位基因不变; 举例说明元素在 $[-1, 1]$ 内但非半正定的矩阵不能作 Γ 。 [答案]

六、综合分析与研究设计题

- 28.27 ★★ [综合]** 为一个有 50 万头动物系谱、5 万头分型的猪育种公司设计单步评定上线方案: 数据检查、 G 的调整、APY 核心、元基础群体、求解器与验证。 [答案]
- 28.28 ★★★ [综合]** 上线后发现候选的 EBV 比后来的表型预期偏高 (斜率 0.8)。设计诊断流程判断是 G 与 A_{22} 参照不一致、元基础群体缺失、选择偏倚还是 APY 近似的后果, 并给出各自的检验与处理。 [答案]
- 28.29 ★★★ [综合]** 大规模单步评定每周运行, 求解器迭代到相对残差 10^{-6} 后停止。设计停止规则、监控与可复现方案, 使“前 10% 名单”与候选差值的误差受控, 并说明如何报告可靠度。 [答案]

28.6 参考答案与解析

一、单项选择题

- 28.1 B.** A_{22}^{-1} 是先取 A 的右下块再求逆。它与 A^{-1} 的右下块之差为舒尔补修正 (习题 28.15: 最大差 7.57)。 [题目]
- 28.2 A.** G 以分型样本频率为参照, 平均对角元与平均元素均与 A_{22} 不同; β, α 使两者一致。习题 28.15: $\beta = 0.9477$, $\alpha = 0.0991$ 。 [题目]
- 28.3 B.** 精确的条件是 S 为对角 (如只有一个非核心动物)。习题 28.17 中核心规模增大, KL 与误差下降。 [题目]
- 28.4 B.** Γ_{bb} 是同一基础群体中两个不同个体的期望关系; $\Gamma_{bb'}$ 为跨群体。 [题目]
- 28.5 B.** 习题 28.18: 容差 10^{-2} 时前 10% 名单重合率 0.33, 最大误差 $5.5\sigma_a$ 。 [题目]
- 28.6 B.** 两个个体的 EBV 误差相关, 差值的 PEV 为 $c'C^{uu}c$, 含交叉项。习题 28.20: 组平均差的可靠度 0.558, 而个体可靠度均值 0.280。 [题目]

二、判断与改错题

28.7 错误。拼接矩阵破坏了未分型与已分型动物的协方差一致性，最小特征值 -1.865 (习题 28.15)。H 需要用条件构造 BGB' 等块一起更新。 [题目]

28.8 错误。这类动物已有大量表型与系谱信息，基因型的边际信息有限：习题 28.16 中 0.655 对 0.652。单步评定的主要收益在候选（无表型、有基因型）：0.578 对 0.433。 [题目]

28.9 错误。必须半正定： $\Gamma = \frac{2}{m}WW'$ 才合法。习题 28.19：非法例的特征值为 $(-0.8, 1.9, 1.9)$ ，各元素均在 $[-1, 1]$ 内。 [题目]

28.10 错误。目标误差等于 $z'r_k$ ，取决于残差在 $z = L^{-1}c$ 方向上的分量。习题 28.18：相对残差 9.2×10^{-3} 时差值误差达 19.7。 [题目]

三、填空题

28.11 $A_{22} = I_2$ 的块 $\begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$, $A_{12} = (0, 0.5)$, $A_{22}^{-1} = \frac{4}{3} \begin{pmatrix} 1 & -0.5 \\ -0.5 & 1 \end{pmatrix}$, $B = (-0.3333, 0.6667)$; $S_1 = 1 - BA_{21} = 1 - 0.3333 = 0.6667$ 。 [题目]

28.12 $w = 2 \times 0.7 - 1 = 0.4$, $\Gamma_{bb} = 2 \times 0.16 = 0.32$ 。 [题目]

28.13 $\sqrt{156.7} = 12.52$, $(12.52 - 1)/(12.52 + 1) = 0.852$ 。每步最多收缩约 15%，要把能量误差降低 10^4 倍约需 $\ln(10^4/2)/0.160 \approx 53$ 次迭代（实测 ≤ 79 次达 10^{-8} 残差）。 [题目]

28.14 $R = 1 - 2.333 \times 0.4/1.2 = 1 - 0.7778 = 0.222$ 。 [题目]

四、计算题

28.15 1060 头动物、300 头分型 (2937 个 SNP)，平均近交 0.0251 (分型动物 0.0411)。原始 G: 对角均值 0.9940、非对角均值 -0.0033 ; A_{22} : 1.0411 与 0.0959。调整 $\beta = 0.9477$, $\alpha = 0.0991$ (调整后对 A_{22} 的回归斜率 1.015)。 $\max |HH^{-1} - I| = 3.2 \times 10^{-14}$; $\max |(A^{-1})_{22} - A_{22}^{-1}| = 7.569$ (与舒尔补一致)。最小特征值: H 0.0332; 拼接矩阵 -1.865 ; 修正块 $G_w^{-1} - A_{22}^{-1}$ 为 -2.033 (它本身不必半正定, H^{-1} 才必须)。未分型动物对角元变化均值 $+0.0024$ 、范围 $[-0.109, +0.103]$, 96.8% 的未分型动物的关系被更新; 拼接矩阵与正确 H 的最大差 0.2598。解读: H 把基因组信息传给了未分型亲属; 拼接矩阵既非正定, 也不更新未分型动物的关系。 [题目]

28.16 (见推导 28.3 的表。) 核验: MME 解与 GLS 形式的最大差 8.7×10^{-13} 。候选准确性 PBLUP 0.433、GBLUP 0.531、ssGBLUP 0.578 (对 PBLUP +0.145); 候选斜率 0.971, 1.045, 1.108 (ssGBLUP 略欠膨胀); 偏差/ σ_a -0.063, 0.004, -0.045。未分型有表型动物: PBLUP 0.652, ssGBLUP 0.655。解读: ssGBLUP 同时使用了全部表型与基因型, 优于只用 500 头分型动物的 GBLUP; 调整 G 的好处在斜率与偏差, 而不是准确性。 [题目]

28.17 800 头分型, 204 头候选无表型, 精确 GBLUP 候选准确性 0.535; G 的 90%/95%/98%/99% 特征值方向数 318/440/576/651。

核心规模	随机 KL / 相关	最老 KL / 相关 (斜率)	贪心 KL / 相关
25	391.5 / 0.508	399.8 / 0.663 (1.64)	327.5 / 0.653
50	336.5 / 0.738	366.5 / 0.681 (1.46)	268.5 / 0.806
100	274.4 / 0.871	310.6 / 0.755 (1.33)	199.3 / 0.910
200	176.2 / 0.951	232.6 / 0.828 (1.29)	121.3 / 0.965
400	65.9 / 0.989	108.8 / 0.936 (1.13)	47.1 / 0.993

解读: 核心规模要达到 G 有效维度 (约 400—600) 才能得到相关 > 0.99 ; 按条件方差迹贪心选核心最优; “最老动物” 核心代表性差, 斜率长期偏高。 [题目]

28.18 维数 680 (固定效应 20、动物 660、510 条记录):

预条件	迭代		解误差 (10^{-8})
	κ	($10^{-4}/10^{-8}/10^{-12}$)	
无	313.0	37/88/133	3.1×10^{-5}
对角	156.7	37/79/120	5.6×10^{-5}
块对角	156.7	37/79/120	5.6×10^{-5}

目标 $t = \hat{u}_{518} - \hat{u}_{554} = 0.6181$ 。第 5、10、20、40、80 次: 相对残差 $2.3 \times 10^{-2}, 9.2 \times 10^{-3}, 1.2 \times 10^{-3}, 5.2 \times 10^{-5}, 8.4 \times 10^{-9}$; 目标误差 +15.7, +19.7, +4.14, +0.257, +9.7 $\times 10^{-6}$, 与 $z'r_k$ 逐次相等, 且在能量界内。容差—名单: 10^{-2} : 10 次, 重合 0.33, 最大误差 $5.5\sigma_a$; 10^{-3} : 22 次, 0.53, $1.36\sigma_a$; 10^{-4} : 37 次, 0.93, $0.107\sigma_a$; 10^{-6} : 58 次, 1.00, $1.3 \times 10^{-3}\sigma_a$ 。热启动: 零初值 99 次, 身份映射旧解 78 次, 错位旧解 89 次, 最终差 $< 10^{-6}$ 。解读: 此例中对角预条件只减少约 10% 的迭代 (对角元近似相等); 名单需要 $\leq 10^{-4}$ 的容差; 热启动的初值必须按动物身份映射。 [题目]

28.19 20000 个位点: $\Gamma = \begin{pmatrix} 0.4004 & 0.3880 \\ 0.3880 & 0.4834 \end{pmatrix}$ (特征值 0.0517, 0.8321, 半正定), $\Gamma_{AB}^2 = 0.1505 \leq \Gamma_{AA}\Gamma_{BB} = 0.1935$ 。翻转不变: 最大差 0。教学例 $\begin{pmatrix} 0.52 & 0.48 \\ 0.48 & 0.52 \end{pmatrix}$ 的

特征值 (0.04,1.0); 非法例特征值 (-0.8,1.9,1.9)。8 头动物的 A_{Γ} 对角: 1.2,1.2,1.242,1.2,1.194,1.194,1.297,1.302; 传统 A : 1.0 至 1.125; $A_{\Gamma} - A$ 的元素 [0.172,0.400]; $A_{\Gamma}^{-1}A_{\Gamma} = I$ 偏差 5.5×10^{-16} ; 逆矩阵非零元 48/100。基因下落 40 次的 MC 均值与 A_{Γ} 最大差 0.0029 (平均 0.0008), 与传统 A 最大差 0.400。解读: 忽略元基础群体等于假设基础群体间无亲缘、群内也无关, 系统地低估关系 0.17—0.40。 [题目]

28.20 $\lambda = 2.333$, 候选 150 头: 个体可靠度均值 0.276 (0.207—0.371)。两组各 45 头的平均差: 先验方差 5.314, PEV 2.348, 可靠度 0.558 (个体可靠度均值 0.280); 若忽略误差协方差 PEV 为 0.628 (低估 73.2%)。随机候选 199 对: 差值可靠度均值 0.278 (0.166—0.389); 忽略误差协方差的 PEV 相对偏差均值 +1.2%、最大 +56.9%。Hutchinson 估计:

探针数 K	5	10	25	50	100	200
经验 RMSE	0.1669	0.1175	0.0744	0.0513	0.0369	0.0258
理论 RMSE	0.1646	0.1164	0.0736	0.0521	0.0368	0.0260
平均相对误差	43.6%	30.9%	19.5%	13.5%	9.7%	6.8%

PCG (容差 10^{-8} , 89 次) 与 Cholesky 解最大差 2.5×10^{-8} 。解读: 群体平均差的可靠度远高于个体平均; 个体层面的随机化对角估计误差随 $1/\sqrt{K}$ 缓慢下降, 应只用于汇总报告。 [题目]

28.21 $B = (-0.3333, 0.6667)$, $S_1 = 0.6667$, $H = \begin{pmatrix} 0.9556 & 0.0667 & 0.4667 \\ 0.0667 & 1 & 0.6 \\ 0.4667 & 0.6 & 1 \end{pmatrix}$: $H_{11} = S_1 + BGB' = 0.6667 + 0.2889 = 0.9556$, $H_{12} = BG = (0.0667, 0.4667)$ 。 $G^{-1} = \begin{pmatrix} 1.5625 & -0.9375 \\ -0.9375 & 1.5625 \end{pmatrix}$, $A_{22}^{-1} = \begin{pmatrix} 1.3333 & -0.6667 \\ -0.6667 & 1.3333 \end{pmatrix}$, 差 $\begin{pmatrix} 0.2292 & -0.2708 \\ -0.2708 & 0.2292 \end{pmatrix}$ 。 $(A^{-1})_{22} = \begin{pmatrix} 1.5 & -1 \\ -1 & 2 \end{pmatrix} \neq A_{22}^{-1}$ 。未分型动物 1 与动物 3 的关系由系谱的 0.5 变为 0.4667 (因为 G 的 $G_{23} = 0.6 < 0.5$ 的另一个...): 动物 3 与动物 2 的基因组关系 0.6 高于系谱 0.5, 传递到动物 1。数值核: $H^{-1} = A^{-1} + \text{diag}(0, G^{-1} - A_{22}^{-1})$, 最大差 4×10^{-16} 。 [题目]

28.22 $G_{cc}^{-1} = \frac{1}{0.96} \begin{pmatrix} 1 & -0.2 \\ -0.2 & 1 \end{pmatrix}$, $T = G_{nc}G_{cc}^{-1} = (0.3542, 0.2292)$, 条件方差 $S = D = G_{nn} - TG_{cn} = 1 - (0.3542 \times 0.4 + 0.2292 \times 0.3) = 0.7896$ 。只有一个非核心动物时 S 是 1×1 , $\text{diag}(S) = S$, 条件相关 $C = 1$, $G_{APY} = G$ 精确。 [题目]

五、推导与证明题

28.23 证明。直接计算： $T \text{diag}(S_1, G)T' = \begin{bmatrix} S_1 + BGB' & BG \\ GB' & G \end{bmatrix} = H$, 对 $G = A_{22}$ 同样得到 A 。因此 $H^{-1} = T'^{-1} \text{diag}(S_1^{-1}, G^{-1})T^{-1}$, $A^{-1} = T'^{-1} \text{diag}(S_1^{-1}, A_{22}^{-1})T^{-1}$, 二者之差 $T'^{-1} \text{diag}(0, G^{-1} - A_{22}^{-1})T^{-1}$ 。取 $T^{-1} = \begin{bmatrix} I & -B \\ 0 & I \end{bmatrix}$: $\begin{bmatrix} I & 0 \\ -B' & I \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & \Delta \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & \Delta \end{bmatrix}$, 再右乘 T^{-1} 仍为 $\begin{bmatrix} 0 & 0 \\ 0 & \Delta \end{bmatrix}$, 故 $H^{-1} - A^{-1} = \text{diag}(0, G^{-1} - A_{22}^{-1})$ 。■ 【题目】

28.24 证明。 $G_{APY} = L \text{diag}(G_{cc}, D)L'$, $L = \begin{bmatrix} I & 0 \\ T & I \end{bmatrix}$ (展开后得 $G_{cn} = G_{cc}T'$, $G_{nn}^{APY} = TG_{cc}T' + D$)。故 $G_{APY}^{-1} = L'^{-1} \text{diag}(G_{cc}^{-1}, D^{-1})L^{-1}$, $L^{-1} = \begin{bmatrix} I & 0 \\ -T & I \end{bmatrix}$ 。乘出得 $\begin{bmatrix} G_{cc}^{-1} + T'D^{-1}T & -T'D^{-1} \\ -D^{-1}T & D^{-1} \end{bmatrix}$ 。只有一个非核心动物时, $S = G_{nn} - TG_{cn}$ 是标量, $D = \text{diag}(S) = S$, 由于 $G = L \text{diag}(G_{cc}, S)L'$ 恒成立 (Schur 分解), 故 $G_{APY} = G$ 。■ 【题目】

28.25 证明。 $c'\theta - c'\theta_k = c'(\theta - \theta_k) = c'L^{-1}L(\theta - \theta_k) = z'(d - L\theta_k) = z'r_k$ (L 对称, $z = L^{-1}c$)。Cauchy-Schwarz 在 L^{-1} 内积下: $|z'r_k| = |c'L^{-1}r_k| \leq \sqrt{c'L^{-1}c} \sqrt{r_k'L^{-1}r_k}$ 。习题 28.18 逐次核验: 第 80 次目标误差 9.7×10^{-6} , 界 1.9×10^{-4} 。■ 【题目】

28.26 证明。对任意 $v, v'\Gamma v = \frac{2}{m} \|W'v\|^2 \geq 0$ 。把位点 k 的参考等位基因互换, 该位点所有基础群体的频率 $p_{bk} \rightarrow 1 - p_{bk}, w_{bk} \rightarrow -w_{bk}; \Gamma_{bb'}$ 中该位点的乘积 $w_{bk}w_{b'k}$ 不变。非法例 $\begin{pmatrix} 1 & -0.9 & -0.9 \\ -0.9 & 1 & -0.9 \\ -0.9 & -0.9 & 1 \end{pmatrix}$ 元素在 $[-1, 1]$ 内, 但向量 $(1, 1, 1)'$ 给出 $v'\Gamma v = 3 - 5.4 = -2.4 < 0$, 特征值 $(-0.8, 1.9, 1.9)$ (习题 28.19), 不是协方差矩阵。■ 【题目】

六、综合分析与研究设计题

28.27 方案 (1) 数据: 系谱环、亲子鉴定 (第 26 章: 孟德尔冲突)、基因型质控; 分型与未分型动物的世代重叠要足够, 否则 H 的信息传递少。(2) G 的调整: 用 A_{22} 的平均对角与平均元素匹配 (习题 28.15: $\beta = 0.9477, \alpha = 0.0991$), 再 5% 混合; 记录 β, α 的历史, 监测它们的突变。(3) 元基础群体: 若有多个品种或明显的基础群,

估计 Γ 并使用 A_F (习题 28.19: 关系差 0.17—0.40)。(4) APY: 5 万头分型, G 的有效维度约 0.2—0.5 万; 取核心 $\geq$ 有效维度、按贪心或按生育相关性选核心 (习题 28.17); 监测 KL 与最大元素差。(5) 求解器: 块预条件的 PCG, 容差 $\leq 10^{-6}$, 以候选差值为目标检验目标误差; 热启动按动物身份映射 (习题 28.18)。(6) 验证: 前向 (时间) 验证, LR 方法的准确性与偏差指标, 对候选与有表型动物分别报告; 输出斜率、偏差与可靠度。(7) 运维: 可复现 (固定随机种子、版本、代码哈希)。

[题目]

28.28 诊断 (1) 斜率 0.8 表示候选 EBV 膨胀。先用 LR 方法或前向验证复现, 区分偏差 (水平) 与离散 (斜率)。(2) G 与 A_{22} 参照不一致: 比较 G 与 A_{22} 的平均对角元与平均元素, 检查 β, α 是否正确, 用不同混合权重 $w = 0, 0.05, 0.2$ 看斜率变化 (习题 28.16: 调整影响斜率与偏差而不是准确性)。(3) 元基础群体缺失: 基础群体间差异时, A 与 G 的关系偏差; 估计 Γ 并与不用时比较 (习题 28.19)。(4) 选择偏倚: 分型动物是选择性的 (只分型高产者) 会使 G 与总体不同; 用只分型随机样本的对照。(5) APY 近似: 核心不足时 G_{APY} 的 KL 大, 斜率偏高 (习题 28.17: 最老核心斜率 1.64); 改用精确 G^{-1} 对比。(6) 求解器未收敛: 用目标误差检查 (习题 28.18)。**处理:** 按上述顺序分别修正后重新验证; 报告斜率置信区间。 [题目]

28.29 停止规则: 不以相对残差作单一指标, 而是对: (a) 残差 $\leq 10^{-6}$; (b) 前后两次迭代的前 10% 名单一致; (c) 对若干关键差值 (顶级候选之间) 使用 $z'r_k$ 与能量界, 要求界 $< 0.01\sigma_a$ (习题 28.18: 10^{-6} 时最大误差 $1.3 \times 10^{-3}\sigma_a$, 10^{-4} 时 $0.107\sigma_a$ 、重合 0.93)。**监控:** 记录迭代数、条件数估计、每周前后 EBV 的相关与最大变化; 上周解映射为本周初值 (热启动, 习题 28.18: 身份映射 78 次对零初值 99 次); 输入动物顺序的变化不影响结果。**可复现:** 固定随机数种子 (Hutchinson 探针)、记录软件版本与硬件的浮点差异, 用小规模精确解做单元测试。**可靠度报告:** 个体可靠度与关键差值的可靠度分开报告; 用随机化估计群体层面的平均, 不对个体精细排序使用 (习题 28.20: $K = 100$ 时相对误差 9.7%); 报告可靠度时说明 λ 与 H 的来源。

[题目]

验证设计、准确性、校准与跨群体迁移

29.1 本章导学

学习目标

1. 理解“先定义预测对象与用途，再决定划分方式”的验证逻辑：随机、整家系、时间与环境划分回答的是不同的问题，报告时必须同时给出划分条件。

2. 能识别并避免信息泄漏——特别是在划分之前使用全部数据做标记筛选、调参或表型校正所造成的虚高。

3. 掌握准确性的几种量度： $r(\hat{y}, y)/h$ 的换算条件、与真实育种值的相关、LR（部分—整体）统计量的偏差、斜率与准确性，及它们成立的假设。

4. 理解校准斜率、选择后的条件解释与范围限制（Thorndike 修正）。

5. 会计算相关动物验证集的设计效应与有效样本量，并用整家系自助法给出区间和配对损失差的检验。

6. 理解学习曲线（Daetwyler 形状）、参考群体的边际收益，以及跨群体迁移中“直接迁移—校准—本地适配—本地重训”的层次与负迁移条件。

重点与难点

重点： $r(\hat{g}, y)/h$ 估计准确性所需的“预测与残差无关”；LR 斜率 $b = \text{cov}(\hat{u}_w, \hat{u}_p) / \text{var}(\hat{u}_p)$ ；设计效应 $\text{DEFF} = 1 + (\bar{m} - 1)\rho$ ；Daetwyler 近似 $r^2 = Nh^2 / (Nh^2 + M_e)$ ；重要性权重 $w = p_T / p_S$ 与有效样本量。

难点：同一模型在不同划分下的数字为什么不同、哪一个才能对外宣传；泄漏发生在“看不见”的预处理步骤；斜率与相关是两个不同的概念（校准不改变相关）；家系内相关使“独立样本”的直觉失效；迁移的收益取决于效应相关而不是源群体的大小。

本章承接第 26 章（分型质控与 G）、第 27 章（基因组预测模型）与第 28 章（单步评定）。前几章解决“如何预测”，本章解决“如何知道预测得好不好”。育种值本身不可观测，预测的评价总是通过代理量（表型、后裔表现、后期评定）完成，因此验证设计本质上是一个研究设计问题：对象是谁、目标是什么、哪一部分信息对预测可用、误差怎样相关。

29.2 知识结构图




图 29.1 第 29 章知识结构图

左侧是验证的“设计”（目标、划分、泄漏），中部是“度量”（准确性、校准、不确定性），右侧是“规划与迁移”（学习曲线与跨群体）。

29.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
准确性换算	$r(\hat{g}, g) = r(\hat{g}, y)/h$	$\hat{g}$ 与表型残差无关； h^2 为验证集匹配的遗传力
LR 斜率	$b = \text{cov}(\hat{u}_w, \hat{u}_p) / \text{var}(\hat{u}_p)$	$b < 1$ ：部分评定过度分散
LR 准确性	$\hat{\rho}^2 = \text{cov}(\hat{u}_p, \hat{u}_w) / \sigma_g^2$	以 $b \approx 1$ 为前提
校准斜率	$b_c = \text{cov}(g, \hat{g}) / \text{var}(\hat{g})$	不改变相关，只改变尺度与 MSE
设计效应	$\text{DEFF} = 1 + (\bar{m} - 1)\rho$	等大小家系的均值； $N_{\text{eff}} = N / \text{DEFF}$
范围限制	$r' = \frac{r_s u}{\sqrt{1 - r_s^2 + r_s^2 u^2}}$	$u = \sigma_{\text{全}} / \sigma_{\text{选}}$ ，线性同方差
学习曲线	$r^2 = \frac{N h^2}{N h^2 + M_e}$	M_e 为有效染色体片段数
重要性权重	$w(x) = p_T(x) / p_S(x)$	条件关系不变（协变量漂移）

概念	公式或定义	成立条件与提示
有效样本量	$N_{\text{eff}} = (\sum w_i)^2 / \sum w_i^2$	权重越不均, 信息越少

29.4 补充内容与公式推导

推导 29.1 准确性换算 $r(\hat{g}, y)/h$ 的条件, 以及 LR 统计量

设 $y = g + e$, $\text{cov}(g, e) = 0$, 预测 $\hat{g}$ 与 e 无关。则 $\text{cov}(\hat{g}, y) = \text{cov}(\hat{g}, g)$, $\sigma_y = \sigma_g/h$, 所以 $r(\hat{g}, y) = \frac{\text{cov}(\hat{g}, g)}{\sigma_{\hat{g}}\sigma_y} = r(\hat{g}, g)h$, 即 $r(\hat{g}, g) = r(\hat{g}, y)/h$ 。残差与预测相关 (共享环境、表型校正不当、测定动物同在训练集) 时这一换算失效。**LR 方法**: 把全体动物的表型分两次评定, 部分评定 $\hat{u}_p$ 去掉“焦点动物”的表型, 整体评定 $\hat{u}_w$ 使用全部表型。若 $\hat{u}_p = E(u \mid \text{部分数据})$ 、 $\hat{u}_w = E(u \mid \text{全部数据})$, 则 $\text{cov}(\hat{u}_p, \hat{u}_w) = \text{var}(\hat{u}_p)$ (信息嵌套), 故斜率 $b = 1$, 准确性 $\rho^2 = \text{var}(\hat{u}_p)/\sigma_g^2 = \text{cov}(\hat{u}_p, \hat{u}_w)/\sigma_g^2$ 。习题 29.15 (1400 头, 350 头焦点, 900 个 SNP, $h^2 = 0.4$, 30 次重复): 模型正确时 $\Delta = -0.006$ 、 $b = 1.009$, LR 准确性 0.606, 真实 $\text{cor}(\hat{u}_p, g) = 0.599$, $\text{cor}(\hat{u}_p, y)/h = 0.619$ 。把 λ 缩小为 0.25 倍 (收缩不足), b 降到 0.550, 真实斜率 0.541, 真实准确性 0.578, 而 **LR 的协方差式准确性 0.795 严重虚高** (它以 $b = 1$ 为前提); 缩小到 0.05 倍时 $b = 0.303$, LR 准确性 0.934 对真实 0.504。结论: 报告 LR 准确性时必须同时报告斜率, 斜率偏离 1 时协方差式准确性不可用。

推导 29.2 划分设计与泄漏: 同一个模型的五个数字

群体: 40 个父系家系, 每系 5 头母畜、每母 6 个后代, 共 1200 头后代, 父母代 240 头为上一世代; 600 个 SNP, 200 个因果位点, $h^2 = 0.35$, GBLUP (岭回归), 重复 12 次 (习题 29.16)。

评价方案	$\text{cor}(\hat{g}, y)/h$	$\text{cor}(\hat{g}, g)$
随机 5 折 (后代内)	0.743	0.747
整父系家系留出	0.675	0.676
时间划分 (父母 $\rightarrow$ 后代)	0.523	0.524
泄漏 (先用全部后代筛 30 个 SNP)	0.761	0.647
折内筛选 (诚实)	0.605	0.594

同一模型，从 0.52 到 0.76 都是“准确性”。随机划分让测试动物的全同胞、半同胞留在训练集中，亲缘近，所以最高；整家系留出去掉同家系信息（-0.07）；时间划分对应真实“向前预测”（对象是尚无后代信息的新一代），最低。**泄漏**的特征是：表观准确性（对表型）0.761 高于折内筛选的 0.605，却对真实育种值只有 0.647，表观与真实之差由 +0.011 扩大到 +0.114——筛选步骤用测试动物的表型“选中了”恰好与其噪声相关的 SNP。宣传数字应与部署场景匹配：新家系用整家系或时间划分，亲缘内补预测可用随机划分，且划分与预处理必须随结果一并报告。

推导 29.3 校准斜率、选择差与范围限制

设 $\hat{g} = Z\hat{\beta}$ 为 ridge 预测， $b_c = \text{cov}(g, \hat{g}) / \text{var}(\hat{g})$ 。当 $\hat{g} = E(g | \text{数据})$ 时 $b_c = 1$ ；收缩不足时 $b_c < 1$ ，过度收缩时 $b_c > 1$ 。习题 29.17（训练 800、候选 4000、 $h^2 = 0.3$ ，15 次重复）：

λ 倍数	真实斜率	CV 估计斜率	MSE（校准前）	MSE（校准后）	全群 r
4.0（过强）	2.636	2.825	0.2499	0.2217	0.519
1.0（正确）	1.007	1.039	0.2166	0.2187	0.526
0.2（不足）	0.451	0.448	0.3359	0.2253	0.502

训练集内部交叉验证可以估计斜率，事后校准 $\hat{g}^* = \bar{g} + \hat{b}(\hat{g} - \bar{g})$ 在偏离正确 λ 时显著降低 MSE（0.336 $\rightarrow$ 0.225），在 λ 正确时略有噪声损失（0.2166 $\rightarrow$ 0.2187）。**选择后**：取预测值前 10%， λ 正确时预测的选择差 0.502 与真实选择差 0.503 一致； λ 缩小为 0.2 倍时预测 1.070 对真实 0.483（高估约 2.2 倍）。过度分散的预测最先在“选择最极端的动物”时暴露。**范围限制**：选择子集内相关随 f 下降（ $f = 0.5, 0.2, 0.1, 0.05$ 分别为 0.348, 0.280, 0.257, 0.242），不能与全群相关（0.526）直接比较；用 Thorndike 修正 $r' = r_s u / \sqrt{1 - r_s^2 + r_s^2 u^2}$ 反推得 0.523, 0.530, 0.541, 0.541，与全群相关一致。

推导 29.4 设计效应与整家系自助法

设 k 个家系、每系 $\bar{m}$ 头，组内相关 ρ ，则均值方差 $\text{Var}(\bar{x}) = \frac{\sigma^2}{N} [1 + (\bar{m} - 1)\rho]$ ， $N = k\bar{m}$ 。因此 $\text{DEFF} = 1 + (\bar{m} - 1)\rho$ ， $N_{\text{eff}} = N / \text{DEFF}$ 。习题 29.18（ $k = 50$ ， $\bar{m} = 20$ ， $\rho = 0.10$ ， $N = 1000$ ）： $\text{DEFF} = 2.90$ ， $N_{\text{eff}} = 344.8$ ；500 次模拟中 95% 区间的覆盖率：独立标准误 0.738，DEFF 修正 0.946，整家系自助 0.942（平均宽度 0.124, 0.209, 0.207）。总动物数固定为 1000，每家 5, 10, 20, 40, 60 头对应 $\text{DEFF} = 1.40, 1.90, 2.90, 4.90, 6.90$ ，有

效样本量 714,526,345,204,145: 家系越大、家数越少, 信息越少。配对损失差: 两模型实际无差别但误差在家系内相关 ($\rho = 0.15$), 独立 t 检验假阳性率 0.350 (名义 0.05), 整家系自助 0.056。相关系数的标准误: 重复模拟的真实 $sd = 0.0441$, 独立自助 0.0229 (低估近半), 整家系自助 0.0403。

推导 29.5 学习曲线与参考群体边际收益

Daetwyler 近似 $r^2 = Nh^2/(Nh^2 + M_e)$ 可线性化为 $1/r^2 - 1 = M_e/(h^2N)$, 过原点回归即得 M_e 。习题 29.20 ($N_e = 80, 40$ 代漂变, 1200 个 SNP, 400 个因果, $h^2 = 0.5, 8$ 次重复): 训练 $N = 250, 500, 1000, 2000, 4000$ 的实测 $r = 0.565, 0.659, 0.749, 0.827, 0.895$, 拟合 $M_e = 286$, Daetwyler 预测 0.551, 0.683, 0.797, 0.882, 0.935。形状对, 但越往右越乐观: 用前 3 点拟合 $M_e = 284$, 外推到 $N = 2000, 4000$ 得 0.883, 0.936, 实测 0.827, 0.895 (高估 0.056, 0.041)。边际收益 $\Delta r/1000$ 头为 0.374, 0.181, 0.078, 0.034 (递减); 按拟合式, 再增加 1000 头的收益在 $N = 500, 1000, 2000, 4000$ 处为 +0.168, +0.084, +0.035, +0.012。 $h^2 = 0.2$ 的性状在同样 N 下实测 $r = 0.441, 0.539, 0.620, 0.709, 0.779$, 低遗传力需要成倍增加的参考群体。参考群体建设的经济决策应使用这类边际曲线, 而不是单一的“越大越好”。

推导 29.6 跨群体迁移的层次与负迁移

目标品种训练集大小为 n_T , 源品种参考群 2500 头。四种策略: S 直接迁移; C 在目标训练集上校准 $y \approx a + b\hat{g}_S$; O 校准后再用本地岭回归拟合残差; T 只用目标训练集。因果效应的跨品种相关 r_g 与 LD 差异决定直接迁移的上限 (习题 29.19: A 块内 LD 0.85, B 为 0.6, $h^2 = 0.4$, 每设置 6 次重复, 测试 600 头):

r_g	$n_T = 50$	200	800	S 直接迁移	本地重训超过 S 的最小
					n_T
0.9	O 0.340 / T 0.085	O 0.335 / T 0.178	O 0.367 / T 0.291	0.373	未超过
0.5	O 0.157 / T 0.077	O 0.245 / T 0.182	O 0.326 / T 0.292	0.208	400
0.1	O 0.077 / T 0.076	O 0.201 / T 0.190	O 0.318 / T 0.300	0.049	50

三点要点。(1) **校准不改变相关**: C 与 S 的相关相同 (0.373 对 0.373), 但改变斜率与 MSE: $r_g = 0.5$ 、 $n_T = 200$ 时 g 对 $\hat{g}$ 的斜率由 0.29 到 1.36, MSE 由 0.491 降到 0.390; 而用很小的目标集估计斜率本身噪声很大 ($r_g = 0.1$ 时校准后斜率 1.71)。(2) **源偏移+本地残差 (O)** 在小 n_T 比只用本地的 T 好得多 ($r_g = 0.9$ 、 $n_T = 50$: 0.340 对 0.085), 在 $r_g = 0.1$ 时与 T 持平 (0.318 对 0.300), 未出现严重负迁移。(3) **源群体大小不能代替效应相关**: r_g 低时直接迁移只有 0.049, 再扩大源参考群也不会改变这一上限。

延伸阅读: 协变量漂移、重加权与迁移风险

当目标群体的分布 $p_T(x)$ 与验证群体 $p_S(x)$ 不同、但条件关系 $p(y|x)$ 相同 (协变量漂移) 时, 目标风险可用重要性权重 $w = p_T/p_S$ 估计: $E_T[L] = E_S[wL]$ 。其代价是有效样本量下降 $N_{\text{eff}} = (\sum w_i)^2 / \sum w_i^2$, 权重极端时验证几乎只剩少数动物。若条件关系也变 (如不同品种的 LD 或环境效应不同), 重加权无济于事, 只能在目标群体取新的验证样本。迁移风险的分解还可见本章 29.19—29.20 节的条件分布推导与“借力强度”判据。

常见误区

1. 用随机划分的相关系数宣传“对新家系的准确性”。
2. 在划分之前用全部数据做 SNP 筛选、超参调优或表型校正。
3. 报告 LR 协方差式准确性而不报告斜率。
4. 把相关当作校准: 相关高但斜率偏离 1 的预测, 选择差会被严重高估。
5. 用独立自助法或普通 t 检验比较家系结构数据上的两个模型。
6. 把目标测试集中选择后的子集内相关与全群相关直接比较。
7. 以为扩大源群体规模就能解决 r_g 低造成的迁移失败。

29.5 习题

一、单项选择题

29.1 ★ [单选] 用 $r(\hat{g}, y)/h$ 估计对育种值的准确性, 需要的关键条件是

- (A) 预测与表型残差无关, 且 h^2 与验证表型匹配
 (B) 验证集必须有 1000 头以上
 (C) 预测值服从正态
 (D) 各动物无亲缘

[答案]

29.2 ★ [单选] LR 验证中斜率 $b = \text{cov}(\hat{u}_w, \hat{u}_p) / \text{var}(\hat{u}_p)$ 明显小于 1, 最合理的解释是

(A) 部分评定过度分散 (收缩不足) (B) 部分评定过度收缩

(C) 整体评定准确性为 0 (D) 遗传力为 0

[答案]

29.3 ★★ [单选] 同一模型在随机 K 折下相关 0.74、整父系家系留出下 0.68、时间划分下 0.52。若部署对象是尚未出生的下一代, 应当优先引用

(A) 0.74 (B) 0.68 (C) 0.52, 并同时说明划分条件

(D) 三者平均

[答案]

29.4 ★★ [单选] 下列哪一个做法属于信息泄漏

(A) 在每个训练折内部按边际相关筛选 SNP

(B) 先用全部动物的表型筛选 SNP, 再做 K 折交叉验证

(C) 在训练折内选择岭参数

(D) 把测试折作为最后一步的独立评价

[答案]

29.5 ★★ [单选] 对预测值最高的 5% 个体, 选择子集内 $r(\hat{g}, g)$ 通常比全群相关低, 主要原因是

(A) 样本变少导致偏倚

(B) 范围限制: 选择使预测值方差变小, 相关随之下降

(C) 遗传力下降 (D) 模型错误

[答案]

29.6 ★★★ [单选] 800 头动物分在 20 个家系, 每系 40 头, 组内相关 0.05, 则估计均值的近似有效样本量为

(A) 800

(B) 约 400

(C) 约 271

(D) 约 20

[答案]

二、判断与改错题

29.7 ★ [判断] 随机 K 折相关系数是模型对新家系预测准确性的无偏估计。

[答案]

29.8 ★ [判断] 对预测值作斜率校准会改变它与目标值的相关系数。

[答案]

29.9 ★★ [判断] 对家系结构的数据用独立个体自助法, 通常会低估均值或相关系数的标准误。

[答案]

- 29.10** ★★ [判断] 只要把源品种参考群体扩大, 跨品种预测的准确性总会趋近于目标品种的内部准确性。 [答案]

三、填空题

- 29.11** ★ [填空] 验证集中预测与表型的相关为 0.45, 匹配遗传力 $h^2 = 0.36$, 则估计准确性为 _____。 [答案]
- 29.12** ★ [填空] 每个家系 26 头, 组内相关 0.04, 则设计效应 $DEFF =$ _____。 [答案]
- 29.13** ★★ [填空] $N = 1000$, $h^2 = 0.5$, $M_e = 286$, 由 Daetwyler 近似得准确性 $r =$ _____ (三位小数)。 [答案]
- 29.14** ★★ [填空] 选择子集内相关 $r_s = 0.3$, 全群与选择子集的预测值标准差之比 $u = 2$, Thorndike 修正后的全群相关 $r' =$ _____ (三位小数)。 [答案]

四、计算题

- 29.15** ★★★ [计算] **LR 验证的偏差、斜率与准确性。** 对正确与收缩不足的 GBLUP 比较 LR 偏差、斜率、LR 准确性与真实相关, 并找出 LR 准确性失效的情形。 [程序] `ch29/ex29_15_lr_validation.py` [答案]
- 29.16** ★★★ [计算] **划分设计与泄漏。** 在半同胞家系群体上比较随机、整家系、时间划分与泄漏, 计算表观与真实准确性之差。 [程序] `ch29/ex29_16_split_designs.py` [答案]
- 29.17** ★★★ [计算] **校准斜率、选择差与范围限制。** 比较三种收缩强度的校准斜率与事后校准的 MSE, 检验选择后的预测选择差, 并用 Thorndike 修正。 [程序] `ch29/ex29_17_calibration_selection.py` [答案]
- 29.18** ★★★ [计算] **设计效应与整家系自助法。** 估计三种区间的覆盖率, 计算不同家系大小的有效样本量, 检验配对损失差的假阳性率与相关系数标准误。 [程序] `ch29/ex29_18_clustered_uncertainty.py`
- ?? 29.19 | 4 | 计算 **跨群体迁移。** 在三个 r_g 水平下比较直接迁移、校准、源偏移+本地残差与仅本地重训的学习曲线, 找出本地重训的交叉点。 [程序] `ch29/ex29_19_cross_population_transfer.py`

?? 29.20 | 4 | 计算 学习曲线与参考群体建设。拟合 M_e , 检验 Daetwyler 外推, 计算边际收益及低遗传力所需增量。 [程序] ch29/ex29_20_learning_curve_design.py [答案]

29.21 ★★ [计算] 重加权的手算。某模型在亚群 A、B 的平均绝对误差分别为 0.8 与 2.2。验证集中 A、B 占 70%、30% (共 200 头: 140 与 60), 部署群体中占 30%、70%。求 (1) 未加权验证损失; (2) 部署损失; (3) 重要性权重; (4) 加权后的有效样本量。 [答案]

29.22 ★★ [计算] LR 统计量的手算。6 头焦点动物的部分评定 $\hat{u}_p$ 依次为 0.5、-0.3、0.8、-0.6、0.1、0.9, 整体评定 $\hat{u}_w$ 依次为 0.4、-0.2、0.6、-0.5、0.2、0.7, $\sigma_g^2 = 0.5$ 。(样本协方差与方差均用 $n - 1$ 作分母。) 求偏差 Δ 、斜率 b 与协方差式准确性 $\hat{\rho}$, 并作解读。 [答案]

五、推导与证明题

29.23 ★★ [证明] 设 $y = g + e$, $\text{cov}(g, e) = 0$, $\text{cov}(\hat{g}, e) = 0$ 。证明 $r(\hat{g}, g) = r(\hat{g}, y)/h$, 其中 $h^2 = \sigma_g^2/\sigma_y^2$; 并说明若 $\text{cov}(\hat{g}, e) = c > 0$, 该比值会怎样偏离真值。 [答案]

29.24 ★★★ [证明] k 个家系、每系 m 头, 同系动物观测的组内相关为 ρ 、方差为 σ^2 。证明样本均值的方差为 $\frac{\sigma^2}{N}[1 + (m - 1)\rho]$ ($N = km$), 并写出有效样本量。 [答案]

29.25 ★★★ [证明] 设部分评定 $\hat{u}_p = E(u | \mathcal{D}_p)$, 整体评定 $\hat{u}_w = E(u | \mathcal{D}_w)$, $\mathcal{D}_p \subset \mathcal{D}_w$ 。证明 $\text{cov}(\hat{u}_w, \hat{u}_p) = \text{var}(\hat{u}_p)$, 从而 LR 斜率期望为 1, 且 $\text{var}(\hat{u}_p) = \rho^2 \sigma_u^2$ (ρ 为 $\hat{u}_p$ 与 u 的相关)。 [答案]

29.26 ★★★ [证明] (1) 证明协变量漂移下 $E_T[L] = E_S[wL]$, $w = p_T/p_S$ 。(2) 对自归一化估计量 $\hat{L}_w = \sum w_i L_i / \sum w_i$, 证明有效样本量 $N_{\text{eff}} = (\sum w_i)^2 / \sum w_i^2 \leq N$, 等号当且仅当权重全相等。 [答案]

六、综合分析与研究设计题

29.27 ★★ [综合] 某猪育种公司拟为“下一世代的后备公猪”宣传基因组预测准确性。为其设计验证方案: 对象与损失、划分、泄漏控制、不确定性与报告项目。 [答案]

29.28 ★★★ [综合] 模型上线前随机划分相关为 0.65, 上线一年后与后期评定的相关只有 0.35。设计诊断流程, 区分划分差异、家系结构、泄漏、选择后范围限制、环境或群体变化与模型过拟合。 [答案]

29.29 ★★★ [综合] 地方品种仅有 300 头有表型动物, 欲引入大型商业品种的预测模型。设计能够分开“直接迁移、校准、本地适配、本地重训”收益的研究方案, 并说明如何避免夸大外推。 [答案]

29.6 参考答案与解析

一、单项选择题

29.1 (A)。 $\text{cov}(\hat{g}, y) = \text{cov}(\hat{g}, g)$ 要求预测与残差无关, 且 $\sigma_y = \sigma_g/h$ 要求 h^2 与验证表型的定义匹配 (推导 29.1)。样本量与正态性不是换算的条件; 亲缘只影响不确定性与划分, 不影响恒等式。 [题目]

29.2 (A)。 $b < 1$ 意味着部分评定的差异“比后来被证实的更大”, 即收缩不足、过度分散。习题 29.15: λ 缩小为 0.25 倍, $b = 0.550$; 0.05 倍, $b = 0.303$ 。 [题目]

29.3 (C)。 部署对象是新一代, 时间划分最接近 (习题 29.16: 0.523), 随机划分 0.743 包含了同家系亲缘的好处。应同时说明划分条件, 并可附整家系留出的 0.675 作参考, 但不能选取最高数字而隐去条件。 [题目]

29.4 (B)。 在划分之前用全体动物 (含将来的测试动物) 的表型筛选 SNP, 筛选结果依赖测试表型的噪声。习题 29.16: 泄漏的表现观准确性 0.761 对折内筛选 0.605, 而对真实育种值是 0.647 对 0.594。(A)(C)(D) 都是在训练信息内完成。 [题目]

29.5 (B)。 选择降低了预测值的变异范围, 保持斜率不变时相关下降。习题 29.17: $f = 0.05$ 时 $r_s = 0.242$, Thorndike 修正后 0.541, 与全群 0.526 一致, 说明不是模型变差。 [题目]

29.6 (C)。 $\text{DEFF} = 1 + (40 - 1) \times 0.05 = 2.95$, $N_{\text{eff}} = 800/2.95 = 271.2$ 。 [题目]

二、判断与改错题

29.7 错误。 随机折把同家系动物同时放在训练与测试两侧, 亲缘近, 对新家系偏乐观。习题 29.16: 随机 0.743、整家系留出 0.675、时间划分 0.523。随机划分只估计“有同家系亲属已在训练集”时的表现。 [题目]

29.8 错误。斜率校准是对预测值的线性变换，皮尔逊相关不变；改变的是斜率与 MSE。

习题 29.19：直接迁移与校准的相关同为 0.373，但 $r_g = 0.5$ 、 $n_T = 200$ 时 MSE 由 0.491 降到 0.390。 [题目]

29.9 正确。独立自助忽略家系内相关。习题 29.18：相关系数标准误真实 0.0441，独立自助 0.0229，整家系自助 0.0403；均值的 95% 区间覆盖率独立 0.738，整家系 0.942。

[题目]

29.10 错误。迁移的上限由效应相关 r_g 与 LD 差异决定。习题 29.19： $r_g = 0.1$ 时直接迁移只有 0.049， $r_g = 0.9$ 时 0.373，二者的源群体大小同为 2500；源群体增大只能使源模型更接近“源品种的真实效应”，而不是目标品种的真实效应。 [题目]

三、填空题

29.11 $0.45/\sqrt{0.36} = 0.45/0.6 = 0.75$ 。 [题目]

29.12 $DEFF = 1 + (26 - 1) \times 0.04 = 2.00$ ，即有效样本量减半。 [题目]

29.13 $r^2 = 500/(500 + 286) = 0.6361$ ， $r = 0.798$ （习题 29.20 中实测 $N = 1000$ 时 0.749，Daetwyler 乐观约 0.05）。 [题目]

29.14 $r' = \frac{0.3 \times 2}{\sqrt{1 - 0.09 + 0.09 \times 4}} = \frac{0.6}{\sqrt{1.27}} = 0.532$ 。 [题目]

四、计算题

29.15 结果（1400 头、350 头焦点动物、900 个 SNP、 $h^2 = 0.4$ ，30 次重复）：

λ	LR 偏差	LR 斜率	LR 准确性	真实 $r(\hat{u}_p, g)$	$r(\hat{u}_p, y)/h$
×1（正确）	-0.006	1.009	0.606	0.599	0.619
×0.25	-0.006	0.550	0.795	0.578	0.601
×0.05	-0.006	0.303	0.934	0.504	0.527

模型正确时偏差 ≈ 0 、斜率 ≈ 1 ，LR 准确性与真实相关相差不到 0.01；收缩不足时斜率单调下降（ $1.009 \rightarrow 0.550 \rightarrow 0.303$ ）并与真实斜率（0.995, 0.541, 0.298）吻合，而协方差式 LR 准确性虚高（0.795 对真实 0.578）。偏差对“尺度膨胀”不敏感，**必须看斜率**。 [题目]

29.16 结果（40 家系 × 30 头后代，12 次重复， $h^2 = 0.35$ ）：随机 5 折 0.743/0.747（对表型/对真实），整家系留出 0.675/0.676，时间划分 0.523/0.524，泄漏 0.761/0.647，

折内筛选 0.605/0.594。顺序：随机 > 整家系 > 时间（亲缘越远越低）。泄漏方案的表观准确性比折内筛选高 0.156，真实只高 0.053；表观与真实之差：折内 +0.011，泄漏 +0.114。解读：泄漏同时造成“表观虚高”与“表观—真实的缺口”，在无法得知真实育种值时，缺口无法直接观察，只能靠流程隔离防止。 [题目]

29.17 结果见推导 29.3 的表。关键数字：斜率（真实）2.636/1.007/0.451，CV 估计 2.825/1.039/0.448（估计与真实一致）；MSE 校准前后：过强 0.2499 → 0.2217，正确 0.2166 → 0.2187，不足 0.3359 → 0.2253。选择前 10%：预测选择差/真实选择差——过强收缩 0.189/0.499，正确 0.502/0.503，不足 1.070/0.483。范围限制： $r_s = 0.348, 0.280, 0.257, 0.242$ ($f = 0.5, 0.2, 0.1, 0.05$)，Thorndike 修正后 0.523, 0.530, 0.541, 0.541（全群 0.526）。解读：收缩不足会使选择差被高估两倍以上，而相关系数几乎不变（0.502 对 0.526）——这是“相关高但斜率错”的典型。

[题目]

29.18 (1) $DEFF = 2.90$ ， $N_{\text{eff}} = 344.8$ ，真实标准误 0.0539。覆盖率：独立 0.738，DEFF 修正 0.946，整家系自助 0.942；平均宽度 0.124/0.209/0.207。(2) 总 1000 头，每家 5, 10, 20, 40, 60: $DEFF = 1.40, 1.90, 2.90, 4.90, 6.90$ ， $N_{\text{eff}} = 714, 526, 345, 204, 145$ 。(3) 两个无差别的模型的配对损失差检验：独立 t 假阳性率 0.350，整家系自助 0.056。(4) 相关系数的标准误：真实 0.0441，独立自助 0.0229，整家系自助 0.0403。解读：家系内相关使独立样本假设失效，宣称“模型 A 显著优于模型 B”前必须使用相容的重抽样或协方差模型。 [题目]

29.19 结果见推导 29.6 的表与下表（相关系数，6 次重复平均）。

r_g	n_T	S	C	O	T
0.9	50	0.373	0.373	0.340	0.085
0.9	800	0.373	0.373	0.367	0.291
0.5	200	0.208	0.208	0.245	0.182
0.5	800	0.208	0.208	0.326	0.292
0.1	200	0.049	0.029	0.201	0.190
0.1	800	0.049	0.065	0.318	0.300

校准的作用 ($n_T = 200$): $r_g = 0.9$ 斜率 $0.52 \rightarrow 1.30$ 、MSE $0.397 \rightarrow 0.355$; $r_g = 0.5$ 斜率 $0.29 \rightarrow 1.36$ 、MSE $0.491 \rightarrow 0.390$; $r_g = 0.1$ 斜率 $0.07 \rightarrow 1.71$ 、MSE $0.582 \rightarrow 0.403$ 。本地重训首次超过直接迁移的 n_T : $r_g = 0.9$ 未超过(至 800), $r_g = 0.5$ 为 400, $r_g = 0.1$ 为 50。结论：高 r_g 时迁移足够好，本地数据只作校准；中等 r_g 时应使用偏移+残

差 (O); 极低 r_g 时迁移无益, O 与 T 接近, 无严重负迁移。

[题目]

29.20 结果见推导 29.5。要点: $M_e = 286$; Daetwyler 预测 0.551, 0.683, 0.797, 0.882, 0.935 对实测 0.565, 0.659, 0.749, 0.827, 0.895; 前 3 点外推的误差 +0.056, +0.041; 边际收益递减; 再增 1000 头的收益 +0.168, +0.084, +0.035, +0.012; $h^2 = 0.2$ 的 $r = 0.441 - 0.779$, 比 $h^2 = 0.5$ 的 0.565—0.895 低 0.12—0.14。解读: 规划参考群体应以边际收益与成本比较, Daetwyler 外推用于数量级判断, 不应用作承诺值。

[题目]

29.21 (1) 未加权: $0.7 \times 0.8 + 0.3 \times 2.2 = 0.56 + 0.66 = 1.22$ 。(2) 部署: $0.3 \times 0.8 + 0.7 \times 2.2 = 0.24 + 1.54 = 1.78$ (比验证高 46%)。(3) 权重 $w_A = 0.3/0.7 = 0.4286$, $w_B = 0.7/0.3 = 2.3333$ 。(4) $\sum w = 140 \times 0.4286 + 60 \times 2.3333 = 60 + 140 = 200$, $\sum w^2 = 140 \times 0.1837 + 60 \times 5.4444 = 25.71 + 326.67 = 352.38$, $N_{\text{eff}} = 200^2 / 352.38 = 113.5$, 即 200 头只相当于约 114 头。解读: 重加权使目标损失可估, 但亚群 B 的 60 头被放大 2.3 倍, 不确定性明显增大; 且只在 $p(y|x)$ 在部署时不变的条件有效。

[题目]

29.22 $\hat{u}_p = 0.2333$, $\hat{u}_w = 0.2000$, 所以 $\Delta = 0.2000 - 0.2333 = -0.0333$ 。样本协方差 0.2820, $\text{var}(\hat{u}_p) = 0.3667$, 斜率 $b = 0.2820/0.3667 = 0.769$ 。协方差式准确性 $\hat{\rho} = \sqrt{0.2820/0.5} = 0.751$ 。解读: 偏差很小, 但斜率 $0.77 < 1$ 提示部分评定偏分散 (高估约 30%); 此时协方差式准确性应谨慎使用, 只有 6 头动物时标准误也很大。

[题目]

五、推导与证明题

29.23 证明。 $\text{cov}(\hat{g}, y) = \text{cov}(\hat{g}, g) + \text{cov}(\hat{g}, e) = \text{cov}(\hat{g}, g)$ 。 $r(\hat{g}, y) = \frac{\text{cov}(\hat{g}, y)}{\sigma_{\hat{g}}\sigma_y} = r(\hat{g}, g) \frac{\sigma_g}{\sigma_y} = r(\hat{g}, g) h$ 。故 $r(\hat{g}, g) = r(\hat{g}, y)/h$ 。若 $\text{cov}(\hat{g}, e) = c > 0$, 则 $r(\hat{g}, y) = [\text{cov}(\hat{g}, g) + c]/(\sigma_{\hat{g}}\sigma_y)$, 除以 h 后给出 $r(\hat{g}, g) + c/(\sigma_{\hat{g}}\sigma_g)$, 高估, 高估量为 $c/(\sigma_{\hat{g}}\sigma_g)$ 。习题 29.16 中的泄漏方案即是此类: 筛选后的预测与测试动物的残差正相关, 表观—真实缺口 +0.114。■

[题目]

29.24 证明。 $\bar{x} = \frac{1}{N} \sum_{i,j} x_{ij}$ 。 $\text{Var}(\bar{x}) = \frac{1}{N^2} [N\sigma^2 + k m(m-1)\rho\sigma^2] = \frac{\sigma^2}{N} [1 + (m-1)\rho]$ (同系内有 $m(m-1)$ 个有序对, 协方差 $\rho\sigma^2$; 不同系独立)。独立样本均值方差为 σ^2/N_{eff} , 令二者相等得 $N_{\text{eff}} = N/[1 + (m-1)\rho]$ 。数值: $m = 20, \rho = 0.10, N = 1000$ 时 $N_{\text{eff}} = 344.8$ (习题 29.18)。■

[题目]

29.25 证明。由塔性质 $E(\hat{u}_w | \mathcal{D}_p) = \hat{u}_p$ 。故 $\text{cov}(\hat{u}_w, \hat{u}_p) = E(\hat{u}_w \hat{u}_p) - E\hat{u}_w E\hat{u}_p = E[\hat{u}_p E(\hat{u}_w | \mathcal{D}_p)] - E\hat{u}_p E\hat{u}_p = 0$ 。

$\mathcal{D}_p)$] - $(E\hat{u}_p)^2 = E(\hat{u}_p^2) - (E\hat{u}_p)^2 = \text{var}(\hat{u}_p)$ 。所以斜率 $b = \text{cov}(\hat{u}_w, \hat{u}_p) / \text{var}(\hat{u}_p) = 1$ 。又 $\text{cov}(\hat{u}_p, u) = \text{var}(\hat{u}_p)$ (条件期望的残差与 $\mathcal{D}_p$ 的函数不相关), 故 $\rho = \text{var}(\hat{u}_p) / (\sigma_{\hat{u}_p} \sigma_u)$, 即 $\rho^2 = \text{var}(\hat{u}_p) / \sigma_u^2$ 。习题 29.15: 正确模型时 $b = 1.009$ 、LR 准确性 0.606 对真实 0.599; 若 $\hat{u}_p$ 不是条件期望 (收缩不足), 嵌套性破坏, $b < 1$ 且 LR 准确性虚高。■

【题目】

29.26 证明。 (1) $E_T[L] = \int L(x)p_T(x)dx = \int L(x)\frac{p_T(x)}{p_S(x)}p_S(x)dx = E_S[wL]$ (要求 $p_S > 0$ 的支撑包含 p_T 的支撑)。(2) 由 Cauchy-Schwarz, $(\sum w_i \cdot 1)^2 \leq N \sum w_i^2$, 所以 $N_{\text{eff}} = (\sum w_i)^2 / \sum w_i^2 \leq N$, 等号当且仅当 w_i 相等 (权重向量与全 1 向量成比例)。直观: 自归一化估计量的方差近似 $\sigma^2 \sum w_i^2 / (\sum w_i)^2 = \sigma^2 / N_{\text{eff}}$ 。习题 29.21: 200 头、权重 (0.4286, 2.3333), $N_{\text{eff}} = 113.5$ 。■

【题目】

六、综合分析与研究设计题

29.27 方案 (1) **对象与损失**: 对象是“尚无后裔信息的下一世代后备公猪”, 目标是真实育种值的排序与差值; 损失取相关、斜率与选择差的偏差 (前 10% 的预测选择差对后来表现), 而非单一相关。(2) **划分**: 以时间划分为主 (以更早世代训练、最近世代为测试), 辅以整家系家系留出, 随机 5 折仅作为参考并明确标注 (习题 29.16: 0.523/0.675/0.743)。(3) **泄漏控制**: 筛选、调参、表型校正均在训练折内完成; 系谱已知的亲属的后期评定不得进入训练; 最终评价只运行一次。(4) **度量**: 准确性 (并报告 h^2 的来源)、斜率 (习题 29.15/29.17)、选择后子集的结果与 Thorndike 修正; 可用 LR 方法补充。(5) **不确定性**: 以家系为单位的自助区间与设计效应 (习题 29.18: 50 家系 $\times$ 20 头仅相当于约 345 头独立样本), 配对比较使用整家系自助。(6) **报告**: 划分条件、家系数与大小、各亚群的分层结果、置信区间, 以及与现有评定 (PBLUP) 的并列。

【题目】

29.28 诊断流程 第一步, 复现: 区分随机划分与时间划分——在旧数据上做时间划分, 若得 0.4 左右, 则主要是划分差异 (习题 29.16: 随机 0.743 对时间 0.523)。第二步, 家系结构: 计算测试动物与训练集的最大亲缘、整家系留出下的相关, 核对上线后与训练集有亲缘的比例。第三步, 泄漏: 检查筛选、调参、表型校正是否使用了测试表型 (泄漏方案缺口 +0.114)。第四步, 范围限制: 上线后的评价常只在入选动物中进行, 用 Thorndike 修正对比全群 (习题 29.17: 0.242 $\rightarrow$ 0.541)。第五步, 环境与群体变化: 评价各场、各年份的相关与斜率, 比较遗传力估计; 检验 $p(x)$ 与 $p(y|x)$ 的变化 (习题 29.21 的重加权只在后者不变时有效)。第六步, 过拟合: 训练规模与学习曲线的位置 (习题 29.20)。输出: 把 0.65 $\rightarrow$ 0.35 的降幅分解到上述

各来源，给出每个来源的证据与处理（改划分、重新校准、更新模型）。 [题目]

29.29 研究方案 (1) 固定源模型，在未参与任何适配的目标动物上评估直接迁移 (S)。(2) 把 300 头目标动物按预定规模取训练部分（如 50,100,200），分别估计：只校准 (C)、校准+本地残差 (O)、仅本地重训 (T)；所有调参在目标训练部分内完成。(3) 测试集在所有方案间保持相同，且与训练动物无近亲（整家系留出）。(4) 重复划分并以家系为单位自助（习题 29.18），报告相关、斜率、MSE 与区间。(5) 用习题 29.19 的曲线作为对照：若 r_g 较高（如 0.9），O 在 $n_T = 50$ 时已近 S；若中等，本地重训需 ≥ 400 才超过 S，300 头只适合 O；若极低，任何方案都主要靠本地数据。(6) **避免夸大外推**：不以随机划分宣传；不把调参用的目标动物再用作测试；注明“结论只适用于类似 r_g 与 LD 差异的品种对”，并报告目标品种的 h^2 估计不确定性。 [题目]

第九篇

前沿数据与智能育种

新数据与新模型解决了哪些问题。

本篇习题训练：全基因组序列与泛基因组、多组学与因果推断、基因型 × 环境、深度学习。

全基因组序列、泛基因组、结构变异与稀有变异

30.1 本章导学

学习目标

1. 理解序列数据的统计编码：读段 → 基因型似然 → 后验概率与剂量，以及硬判在低深度下的系统性偏差（杂合漏判）。
2. 理解低覆盖测序与参考面板插补（Li-Stephens 模型）的原理，会解释插补准确性随深度、MAF 与面板亲缘的变化。
3. 理解结构变异（SV）的证据链：发现不等于可靠分型；知道读深度混合模型分型的局限，以及误分型对关联分析的衰减作用。
4. 掌握稀有变异集合检验：单变异、Burden、SKAT 各自的最优场景、权重与第一类错误。
5. 理解参考面板设计是“覆盖概率 + 边际收益”问题，贪心选择与次模性的保证。
6. 会把后验概率转化为配种决策：贝叶斯阈值、检测价值与成本；理解为什么低深度检测可能净亏损。

重点与难点

重点： $L(g) = \binom{d}{a} q_g^a (1 - q_g)^{d-a}$ 与后验 $P(g \mid \text{reads}) \propto L(g) \pi(g)$ ；后验剂量是 MSE 最优的点估计； $T = (1 - \rho)I + \frac{\rho}{H} \mathbf{1}\mathbf{1}'$ 的前向递推 $\alpha' = T\alpha T' \circ E_k$ ；SKAT 的混合卡方与 Satterthwaite 近似；覆盖函数的次模性与 $(1 - 1/e)$ 保证；贝叶斯阈值 $\pi^* = C_{dis} / (C_{aff}E)$ 。

难点： 低深度下的后验“看起来合理”其实依赖先验与面板；插补的评价单位（按位点、按个体、按 MAF）决定结论；SV 的发现证据与分型证据不同；稀有变异检验的权重与方向假设；检测决策的价值取决于成本结构而不是准确率。

本章承接第 26 章（质控与 G）、第 27 章（基因组预测）和第 29 章（验证设计）。当数据从芯片走向全基因组序列，信息增多的同时也带来了三个新问题：每个基因型都是带不确定性的概率对象；变异的种类不再只有 SNP；大量变异是稀有的，统计功效必须靠聚

合。

30.2 知识结构图




图 30.1 第 30 章知识结构图

左侧是“数据怎样变成基因型”，中部是“稀有与结构变异的检验与建模”，右侧是“面板设计与决策”。

30.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
读段似然	$L(g) = \binom{d}{a} q_g^a (1 - q_g)^{d-a}$, $q_g = \frac{\xi}{2} (1 - \epsilon) + (1 - \frac{\xi}{2}) \epsilon$	读段独立；错误率已知
后验剂量	$\hat{g} = \sum_g g P(g \mid \text{reads})$	HWE 先验；MSE 最优
后验方差	$\text{Var}(g \mid \text{reads})$	进入 G 的对角修正
LS 转移	$T = (1 - \rho) I + \frac{\rho}{H} \mathbf{11}'$	二倍体联合 $\alpha' = T \alpha T'$
Burden	$B_i = \sum_j w_j G_{ij}$	效应同向最优
SKAT	$Q = \sum_j w_j^2 (\sum_i G_{ij} r_i)^2 / \sigma^2 \sim \sum \lambda_k \chi_1^2$	方向混合时稳健

概念	公式或定义	成立条件与提示
Satterthwaite	$a = \sum \lambda^2 / \sum \lambda,$ $d = (\sum \lambda)^2 / \sum \lambda^2$	两矩匹配
覆盖函数	$c(P) = \frac{1}{ T } \sum_t \mathbf{1}[\ell_t \in \ell(P)]$	单调次模；贪心 $\geq (1 - 1/e)$ 最优
贝叶斯阈值	淘汰当 $\pi C_{aff} E > C_{dis}$	E 为每头携带公畜的期望发病数

30.4 补充内容与公式推导

推导 30.1 读段似然、后验剂量与低深度的系统性偏差

个体在某位点的真实基因型 $g \in \{0, 1, 2\}$ ，每条读段等概率取自两条单倍型，以错误率 ϵ 读错，故读到 ALT 的概率 $q_g = \frac{\epsilon}{2}(1 - \epsilon) + (1 - \frac{\epsilon}{2})\epsilon$ 。 d 条读段中有 a 条 ALT 的似然为二项概率；先验取 HWE: $\pi = ((1 - p)^2, 2p(1 - p), p^2)$ ，后验 $\propto L\pi$ 。**硬判**取最大似然，在 d 小时杂合子几乎必然被读成纯合（概率 $2 \cdot 0.5^d$ ， $d = 1$ 时一半），产生系统性漏判。习题 30.15（3000 头、400 个位点、 $\epsilon = 0.01$ ）：

平均深度	硬判错误	杂合漏判	硬判 r^2	剂量 r^2	后验 sd
0.5	0.296	0.537	0.386	0.454	0.479
1	0.262	0.595	0.488	0.558	0.431
2	0.191	0.509	0.633	0.701	0.355
4	0.098	0.249	0.796	0.850	0.251
8	0.032	0.068	0.928	0.954	0.139
20	0.001	0.002	0.997	0.998	0.028

后验剂量在所有深度的 r^2 高于硬判，后验概率的分箱校准误差 ≤ 0.012 （先验正确时）。MAF 越低、深度越低，剂量 r^2 越低（深度 1: MAF ≤ 0.01 为 0.209，MAF > 0.2 为 0.421）：稀有变异的信息主要来自先验，而不是读段。

推导 30.2 Li-Stephens 插补：二倍体联合前向—后向

设参考面板有 H 条单倍型。隐状态 (a, b) 是目标个体两条单倍型所拷贝的面板单倍型对；沿染色体每个位点以概率 ρ 独立切换到随机的面板单倍型，单个单倍型的转移矩阵为 $T = (1 - \rho)I + \frac{\rho}{H} \mathbf{1}\mathbf{1}'$ 。两条单倍型独立转移，故前向递推 $\alpha_k = (T\alpha_{k-1}T') \circ E_k$ ，其中 $E_k(a, b) = P(\text{读段}_k \mid g = h_a(k) + h_b(k))$ ；后向同理，位点 k 的后验基因型概率

$P(g_k = g) \propto \sum_{(a,b):h_a+h_b=g} \alpha_k(a,b)\beta_k(a,b)$ 。习题 30.16 (面板 60 条单倍型、40 个目标个体、300 个位点):

深度	无插补 r^2	HMM r^2	增益	MAF $\leq$		
				0.05	0.05–0.2	0.2–0.5
0.5	0.352	0.642	0.289	0.280	0.573	0.603
1	0.486	0.785	0.298	0.391	0.751	0.761
2	0.649	0.882	0.233	0.396	0.847	0.876
4	0.829	0.938	0.109	0.587	0.924	0.935

增益在低深度最大 (0.5–1 $\times$ 约 0.29), 随深度升高而缩小; 低 MAF 位点的准确性始终最低——稀有等位基因的单倍型在面板中很少出现。插补的收益来自“利用单倍型共享把邻近位点的读段合并”, 因此它取决于面板与目标的亲缘, 而不是读段数量本身。

推导 30.3 稀有变异集合检验: Burden、SKAT 与 Satterthwaite

给定基因内 m 个稀有变异、权重 w_j (常取 Beta(1,25) 密度, MAF 越低权重越大)。Burden 把加权基因型相加成 $B_i = \sum_j w_j G_{ij}$ 做一次得分检验, 功效在效应同向时最大; SKAT 的统计量 $Q = \sum_j w_j^2 S_j^2 / \sigma^2$ ($S_j = \sum_i G_{ij} r_i$) 在 H_0 下是 $\sum_k \lambda_k \chi_1^2$, λ 为 $WG'_c G_c W$ 的特征值; 用两矩匹配 $a\chi_d^2$: $ad = \sum \lambda$, $2a^2d = 2 \sum \lambda^2$, 得 $a = \sum \lambda^2 / \sum \lambda$, $d = (\sum \lambda)^2 / \sum \lambda^2$ 。习题 30.17 (3000 头、30 个变异、MAF 0.002–0.01、单个效应 0.3σ 、 $\alpha = 0.001$ 、300 次重复):

场景	单变异 Bonferroni	Burden	SKAT
全部同向	0.270	1.000	1.000
一半反向	0.293	0.007	1.000
仅 20% 致病同向	0.073	0.123	0.260

$\beta = 0$ 时 ($\alpha = 0.01$) 第一类错误 0.010/0.013/0.007。结论: 同向时 Burden 与 SKAT 都有功效, 单变异检验远弱; 方向混合时 Burden 因正负抵消几乎无功效 (0.007), SKAT 保持 1.000; 致病比例低时三者都弱, 需要功能注释缩小集合。

推导 30.4 结构变异的读深度分型与关联衰减

对频率 $f = 0.15$ 的缺失，区间归一化读深度 $x_i \approx s_i(2 - g_i)/2 + \varepsilon$ ， s_i 为个体覆盖尺度（对数正态，CV 0.25，残余估计误差 0.12），计数服从泊松。用三成分高斯混合（均值固定为 1, 0.5, 0）EM 估计后验。习题 30.18（4000 头、每深度 40 次重复）：

深度	准确率	杂合召回	纯合缺失 召回	杂合比 例/HWE	斜率衰减	功效 ($\alpha = 10^{-5}$)
2	0.575	0.214	0.689	0.661	0.244	0.07
5	0.736	0.486	0.816	0.972	0.705	0.62
10	0.838	0.656	0.898	0.948	1.086	1.00
20	0.901	0.761	0.947	0.910	1.109	1.00
40	0.946	0.860	0.975	0.932	1.033	1.00

完美分型功效 1.00，与 SV 的 $r^2 = 0.64$ 标签 SNP 的功效 0.97。要点：杂合子最难分型（深度 2 时召回仅 0.214）；误分型使效应估计向零衰减（深度 2 斜率 0.244）； $\geq 10 \times$ 时 SV 直接分型的功效超过标签 SNP。“发现”只需要一个异常信号，“分型”则要求每个个体的三类基因型都分得开。

推导 30.5 参考面板：覆盖函数、贪心与边际收益

令 $\ell(P)$ 为面板中个体在各位点携带的祖先等位基因标签集合，目标世代的覆盖度 $c(P) = \frac{1}{|T|} \sum_t \mathbf{1}[\ell_t \in \ell_{\text{site}(t)}(P)]$ ：目标单倍型位点的标签在面板中至少出现一次的比例。 c 是集合函数，单调且**次模**（新增个体的边际覆盖随已选集合增大而不增），故贪心选择达到最优的 $(1 - 1/e) \approx 0.632$ 倍。习题 30.19（40 个祖先、5 代、每代 200 头、每代 12 头公畜、300 个位点、6 次重复）：

面板规模	随机	后代数最多	贪心
5	0.314	0.452	0.569
10	0.519	0.709	0.786
20	0.724	0.889	0.936
40	0.885	0.958	0.989
80	0.956	0.991	1.000

贪心的边际收益（每头新增覆盖）依次 0.0434, 0.0151, 0.0026, 0.0003（递减）；贪心相对随机的优势 0.255, 0.267, 0.213, 0.103, 0.044。小面板时选择方法的差异最大，面板达到约 40 头后收益微小：**参考群体要覆盖染色体上的祖先单倍型，而不是只数动物。**

推导 30.6 由后验到配种决策：贝叶斯阈值与检测价值

设携带者频率 $q = 0.04$ ，每头公畜配 $D = 50$ 头母畜、母畜携带者频率 0.04，则携带公畜使用时的期望发病数 $E = Dq_d/4 = 0.5$ 。公畜后验携带概率 π ，淘汰损失 C_{dis} ，发病损失 C_{aff} 。使用公畜的期望损失 $\pi C_{aff}E$ ，淘汰的损失 C_{dis} ，故最优规则是 $\pi > \pi^* = C_{dis}/(C_{aff}E)$ 时淘汰。习题 30.20 ($C_{aff} = 1000$ 、 $C_{dis} = 120$ 、检测费 8/头、2 万头公畜)： $\pi^* = 0.24$ ，网格最优 0.2。不检测的平均成本 19.43，完美检测 12.66 (价值 6.76)。各深度的漏检携带者比例与成本、检测价值：

深度	漏检携带	最优成本	淘汰率	检测价值
1	0.601	22.70	0.025	-3.27
2	0.367	19.98	0.040	-0.55
4	0.192	17.42	0.047	2.01
8	0.073	14.21	0.040	5.22
15	0.014	12.95	0.039	6.48

后验校准误差 ≤ 0.054 。1-2× 的检测不仅没有价值，扣除检测费后还净亏；价值从 4× 起为正，15× 达到完美检测的 96%。

延伸阅读：泛基因组与图参考

泛基因组把多个个体的组装整合为带分支的图，多条路径表示不同的等位基因或结构变异。读段比对到图上，可以减少参考偏倚（对非参考等位基因的比对率更低）。在统计编码上，图中的一个“气泡”对应一个多等位基因位点；SV 的基因型仍然需要读段对各路径的支持似然，推导与本章 30.1 完全同构：只是状态空间从 $\{0, 1, 2\}$ 变为路径对。图参考的主要风险是路径定义不稳定与不同软件的坐标系不一致，必须随结果一并保存版本。

常见误区

1. 低深度下直接硬判，再把硬判基因型当真值使用。
2. 用插补后的整体 r^2 报告准确性，掩盖稀有位点的低准确性。
3. 把 SV 的“发现”当成“可分型”，用杂合子召回很低的基因型做关联。
4. 对方向混合的稀有变异集合只用 Burden。
5. 以为面板越大收益线性增长。
6. 在检测成本与淘汰损失未估算前就推行低深度携带者筛查。

30.5 习题

一、单项选择题

30.1 ★ [单选] 低深度（约 1×）测序，对一个杂合位点硬判基因型，最典型的系统性错误是

- (A) 读成另一个杂合 (B) 读成纯合（漏判杂合子）
(C) 总读成 ALT 纯合 (D) 没有系统性错误

[答案]

30.2 ★ [单选] 把读段后验剂量而不是硬判基因型用于后续分析，其主要好处是

- (A) 保留了基因型的不确定性，MSE 最小
(B) 使剂量成为整数 (C) 消除 MAF 影响
(D) 不再需要先验

[答案]

30.3 ★★ [单选] Li-Stephens 插补中，稀有位点的插补准确性通常较低，主要原因是

- (A) 读段错误率高
(B) 稀有等位基因所在的单倍型在面板中罕见，难以通过共享单倍型被推断
(C) 稀有变异没有 LD (D) 先验太强

[答案]

30.4 ★★ [单选] 一个基因内的稀有变异既有增加性状的也有降低性状的，应优先选用

- (A) Burden (B) SKAT (C) 单变异 Bonferroni
(D) 取最小 p 值作为基因 p 值

[答案]

30.5 ★★ [单选] 对读深度分型的缺失，杂合子召回在低深度偏低，其后果之一是

- (A) 对 HWE 无影响 (B) 关联效应估计向零衰减
(C) 功效反而升高 (D) 纯合缺失被错判为杂合的比例为 0

[答案]

- 30.6** ★★★ [单选] 覆盖函数 $c(P)$ 单调且次模, 贪心挑选 k 个面板个体, 其覆盖度至少是最优 k 个个体覆盖度的
- (A) $1/2$ (B) $1 - 1/e \approx 0.632$ (C) $1/e$
(D) 没有保证 [答案]

二、判断与改错题

- 30.7** ★ [判断] 在先验正确时, 后验剂量与真实基因型的相关不会低于硬判基因型。 [答案]
- 30.8** ★ [判断] 参考面板每增加一头动物带来的新增覆盖是固定的。 [答案]
- 30.9** ★★ [判断] Burden 检验的功效对集合内变异效应方向不敏感。 [答案]
- 30.10** ★★ [判断] 隐性有害等位基因的携带者检测, 测序深度越低越划算。 [答案]

三、填空题

- 30.11** ★ [填空] HWE 先验 $p = 0.1$ (ALT 频率), $\epsilon = 0.01$, 2 条读段都是 REF: $P(g = 1 \mid \text{reads}) \approx$ _____ (三位小数)。 [答案]
- 30.12** ★ [填空] Beta(1,25) 的密度 $25(1-x)^{24}$ 在 $x = 0.005$ 处等于 _____ (两位小数)。 [答案]
- 30.13** ★★ [填空] $C_{dis} = 150$, $C_{aff} = 1000$, 携带公畜期望发病数 $E = 0.6$, 贝叶斯淘汰阈值 $\pi^* =$ _____。 [答案]
- 30.14** ★★ [填空] 次模覆盖函数贪心的最坏情形保证比例为 _____ (三位小数)。 [答案]

四、计算题

- 30.15** ★★★ [计算] 读段似然与后验剂量。在六个测序深度上比较硬判与后验剂量的错误率、杂合漏判、 r^2 、后验 sd 与校准, 并按 MAF 分箱。 [程序] `ch30/ex30_15_genotype_likelihood.py`
- ?? 30.16 | 4 | 计算 低覆盖插补。实现二倍体 Li-Stephens 前向—后向, 比较无插补与 HMM 插补在不同深度与 MAF 分箱的 r^2 。 [程序] `ch30/ex30_16_imputation_hmm.py`
- ?? 30.17 | 4 | 计算 稀有变异检验。计算单变异、Burden、SKAT 的第一类错误与三种场景下的功效。 [程序] `ch30/ex30_17_rare_variant_tests.py`

?? 30.18|4| 计算 **缺失的读深度分型**。用三成分混合 EM 分型,报告准确率、杂合召回、HWE 偏离、关联衰减与功效,并与标签 SNP 比较。[程序] ch30/ex30_18_sv_genotyping.py

[答案]

30.19 ★★★ [计算] 参考面板设计。比较随机、后代数最多与贪心选择的覆盖度,计算边际收益与相对随机的优势。[程序] ch30/ex30_19_panel_coverage.py [答案]

30.20 ★★★ [计算] 携带者检测的决策价值。校准后验,求各深度的最优淘汰阈值、成本与检测价值。[程序] ch30/ex30_20_carrier_decision.py [答案]

30.21 ★★ [计算] 后验手算。某位点 ALT 频率 $p = 0.2$, $\epsilon = 0.01$, 3 条读段中有 1 条 ALT。求三种基因型的似然、后验概率、后验剂量与后验方差。[答案]

30.22 ★★ [计算] SKAT 的手算。三个变异 MAF 为 0.001, 0.005, 0.01。(1) 求 Beta(1, 25) 权重;(2) 已知 $WG'_c G_c W$ 的特征值为 (2, 1, 0.5), $Q = 7$, 用 Satterthwaite 近似求 p 值。[答案]

五、推导与证明题

30.23 ★★ [证明] 证明在任意基因型估计量 $\tilde{g}(\text{reads})$ 中, 后验均值 $\hat{g} = E(g \mid \text{reads})$ 使均方误差 $E(g - \tilde{g})^2$ 最小, 且最小值为平均后验方差。据此说明后验剂量不劣于硬判。[答案]

30.24 ★★★ [证明] 证明 (1) $T = (1 - \rho)I + \frac{\rho}{H}\mathbf{1}\mathbf{1}'$ 是随机矩阵;(2) 二倍体两条单倍型独立转移时, 对状态矩阵 α 的一步转移为 $T\alpha T'$ 。[答案]

30.25 ★★★ [证明] 证明用 $a\chi_d^2$ 匹配 $\sum_k \lambda_k \chi_1^2$ 的前两阶矩, 得 $a = \sum \lambda^2 / \sum \lambda$, $d = (\sum \lambda)^2 / \sum \lambda^2$ 。[答案]

30.26 ★★★ [证明] (1) 证明覆盖函数 $c(P) = \sum_u w_u \mathbf{1}[u \in \bigcup_{i \in P} S_i]$ ($w_u \geq 0$) 单调次模。(2) 证明贝叶斯规则: 当且仅当 $\pi C_{\text{aff}} E > C_{\text{dis}}$ 时淘汰使期望损失最小。[答案]

六、综合分析与研究设计题

30.27 ★★ [综合] 为 5000 头种公牛设计“低覆盖测序+面板插补”的基因型生产方案: 深度、面板选择、质量控制与评价指标。[答案]

30.28 ★★★ [综合] 在 8 个个体的长读长组装中发现一个 12 kb 的缺失候选。设计从“发现”到“能否进入基因组评定”的验证链，并给出判据。 [答案]

30.29 ★★★ [综合] 在两个品种中，某基因含 25 个稀有变异，欲检验与繁殖性状的关联。设计检验策略（权重、方法、跨品种合并、复现与功能注释），并说明报告内容。
[答案]

30.6 参考答案与解析

一、单项选择题

30.1 (B)。杂合子每条读段等概率取自两条单倍型， d 条读段全部来自同一条的概率为 $2 \cdot 0.5^d$ ， $d = 1$ 时为 1（只能读到一个等位基因），因此被判成纯合。习题 30.15：深度 0.5—2 时杂合漏判 0.54、0.60、0.51。 [题目]

30.2 (A)。后验均值是 MSE 最优估计，并同时给出不确定性（后验方差）。习题 30.15：各深度剂量 r^2 均不低于硬判（深度 2：0.701 对 0.633）。它不会使剂量成为整数，也不消除先验依赖。 [题目]

30.3 (B)。稀有等位基因所在的单倍型在面板中少见，HMM 缺乏可拷贝的单倍型。习题 30.16：深度 2 时 $\text{MAF} \leq 0.05$ 的 $r^2 = 0.396$ ，而 0.2–0.5 为 0.876。 [题目]

30.4 (B)。正负效应在 Burden 中抵消（习题 30.17：0.007），SKAT 对方向不敏感（1.000）。单变异 Bonferroni 在稀有变异上功效低（0.293）。 [题目]

30.5 (B)。误分型相当于对基因型加噪声，回归斜率向零衰减，习题 30.18：深度 2 斜率衰减系数 0.244，功效 0.07；纯合缺失被错判为杂合的比例并不为 0。 [题目]

30.6 (B)。单调次模函数的贪心保证 $\geq (1 - 1/e) \approx 0.632$ （Nemhauser 等）。习题 30.19 中贪心实际接近最优（面板 10 头已达 0.786）。 [题目]

二、判断与改错题

30.7 正确。后验均值是 MSE 最优的估计（证明 30.23）；相关系数虽不严格等价于 MSE，但经验上一致，习题 30.15 所有深度剂量 $r^2 \geq$ 硬判 r^2 。 [题目]

30.8 错误。覆盖函数次模，边际收益递减：习题 30.19 贪心的边际收益 0.0434、0.0151、0.0026、0.0003。 [题目]

30.9 错误。Burden 假定同向；方向混合时正负抵消，习题 30.17 功效由 1.000 降到 0.007。

[题目]

30.10 错误。低深度漏检多、检测费不变，价值甚至为负：习题 30.20 中 $1\times$ 为 -3.27 ， $2\times$ 为 -0.55 ， $4\times$ 起为正。

[题目]

三、填空题

30.11 似然 $(0.9801, 0.25, 10^{-4})$ ，先验 $(0.81, 0.18, 0.01)$ 。乘积 $(0.7939, 0.045, 0.000001)$ ，和 0.8389 ， $P(g = 1) = 0.045/0.8389 = \mathbf{0.054}$ （后验剂量亦 0.054）。

[题目]

30.12 $25 \times 0.995^{24} = 25 \times 0.8866 = \mathbf{22.17}$ 。

[题目]

30.13 $\pi^* = 150/(1000 \times 0.6) = \mathbf{0.25}$ 。

[题目]

30.14 $1 - 1/e = \mathbf{0.632}$ 。

[题目]

四、计算题

30.15 结果见推导 30.1。要点：硬判错误 $0.296/0.262/0.191/0.098/0.032/0.001$ （深度 $0.5, 1, 2, 4, 8, 20$ ）；杂合漏判 $0.537, 0.595, 0.509, 0.249, 0.068, 0.002$ ；剂量 r^2 $0.454, 0.558, 0.701, 0.850, 0.954, 0.998$ 高于硬判 $0.386, \dots, 0.997$ ；后验 sd $0.479 \rightarrow 0.028$ ；校准误差最大 0.012。MAF 分箱（深度 1）： $0.209, 0.298, 0.372, 0.421$ （ $MAF \leq 0.01$ 到 > 0.2 ）。解读：低深度的错误以漏判杂合为主，且稀有位点信息最少；校准良好的前提是先验（频率）正确，这一点在真实数据中必须检查。

[题目]

30.16 结果见推导 30.2。HMM 增益 $0.289, 0.298, 0.233, 0.109$ （深度 $0.5, 1, 2, 4$ ）；深度 4 时 $r^2 = 0.938$ ；低 MAF 位点（ ≤ 0.05 ） r^2 在深度 $0.5-4$ 为 $0.280 \rightarrow 0.587$ 。解读：插补主要弥补低深度；稀有位点仍然偏低，需要更大或更近缘的面板；评价必须按 MAF 分箱，整体 r^2 由常见位点主导。

[题目]

30.17 结果见推导 30.3。 $\beta = 0$ 的第一类错误（ $\alpha = 0.01$ ）：单变异 0.010、Burden 0.013、SKAT 0.007（均在名义水平内）。功效：全部同向 $0.270/1.000/1.000$ ；一半反向 $0.293/0.007/1.000$ ；仅 20% 致病 $0.073/0.123/0.260$ 。解读：集合检验的前提是“集合内的变异有共同的生物学原因”；致病比例低时，增加无关变异稀释信号，应借助注释（功能预测）缩小集合。

[题目]

30.18 结果见推导 30.4。深度 $2, 5, 10, 20, 40$ 的准确率 $0.575, 0.736, 0.838, 0.901, 0.946$ ；杂合召回 $0.214, 0.486, 0.656, 0.761, 0.860$ ；斜率衰减 $0.244, 0.705, 1.086, 1.109, 1.033$ （ > 1 ）。

的部分来自后验剂量的收缩与随机波动); 功效 0.07, 0.62, 1.00, 1.00, 1.00; 完美分型 1.00、 $r^2 = 0.64$ 的标签 SNP 0.97。解读: 深度不足时杂合召回是瓶颈; 深度达到 $10\times$ 才使 SV 直接分型的功效不低于标签 SNP。 [题目]

30.19 结果见推导 30.5。贪心/随机/后代最多: 规模 5 为 0.569/0.314/0.452, 规模 20 为 0.936/0.724/0.889, 规模 80 为 1.000/0.956/0.991。优势 $0.255 \rightarrow 0.044$ 。解读: 少量面板时必须设计选择; 后代最多只是覆盖的代理, 不能保证覆盖祖先单倍型的多样性。 [题目]

30.20 结果见推导 30.6。 $\pi^* = 0.24$, 网格最优 0.2 (与深度无关); 检测价值 $-3.27, -0.55, 2.01, 5.22, 6.48$ (深度 1, 2, 4, 8, 15), 完美检测 6.76; 漏检携带者 0.601, 0.367, 0.192, 0.073, 0.014; 校准误差 ≤ 0.054 。解读: 阈值由成本比决定, 深度决定的是漏检与误淘汰数量, 因此决定“是否检测”要先看检测价值是否为正。 [题目]

30.21 似然: $g = 0: 3 \times 0.01 \times 0.99^2 = 0.02940$; $g = 1: 3 \times 0.5^3 = 0.375$; $g = 2: 3 \times 0.99 \times 0.01^2 = 0.000297$ 。先验 (0.64, 0.32, 0.04), 乘积 (0.018818, 0.12, 0.0000119), 和 0.13883, 后验 (0.1355, 0.8644, 0.0001)。后验剂量 $0.1355 \times 0 + 0.8644 + 2 \times 0.0001 = 0.8645$, $E(g^2) = 0.8644 + 4 \times 0.0001 = 0.8648$, 方差 $0.8648 - 0.7474 = 0.1173$ 。 [题目]

30.22 (1) $w = 25(1-x)^{24}$: $x = 0.001$: $25 \times 0.9763 = 24.41$; $x = 0.005$: 22.17; $x = 0.01$: $25 \times 0.7857 = 19.64$ 。(2) $\sum \lambda = 3.5$, $\sum \lambda^2 = 4 + 1 + 0.25 = 5.25$, $a = 5.25/3.5 = 1.5$, $d = 3.5^2/5.25 = 2.333$ 。 $Q/a = 7/1.5 = 4.667$, $p = P(\chi_{2.333}^2 > 4.667) = 0.127$ 。 [题目]

五、推导与证明题

30.23 证明。对任一函数 $\tilde{g}$, $E[(g - \tilde{g})^2 | R] = \text{Var}(g | R) + (E(g | R) - \tilde{g})^2 \geq \text{Var}(g | R)$, 等号当且仅当 $\tilde{g} = E(g | R)$ 。对 R 取期望得最小 MSE 等于平均后验方差。硬判是 R 的函数, 其 MSE 不小于后验均值的 MSE, 故后验剂量不劣。习题 30.15: 深度 0.5 时后验 sd 0.479 (平均方差约 0.23)。 ■ [题目]

30.24 证明。(1) $T_{ij} = (1 - \rho)\delta_{ij} + \rho/H \geq 0$; 行和 $= (1 - \rho) + \rho = 1$, 故为随机矩阵。(2) 两条单倍型的状态 (a, b) 在一步内独立转移: $P((a', b') | (a, b)) = T_{aa'}T_{bb'}$ 。故新的状态分布 $\alpha'(a', b') = \sum_{a,b} \alpha(a, b)T_{aa'}T_{bb'} = (T'\alpha T)(a', b')$; T 对称, 所以 $= T\alpha T'$, 复杂度由 H^4 降为 $O(H^3)$ 。 ■ [题目]

30.25 证明。 $\sum \lambda_k \chi_1^2$ 的均值为 $\sum \lambda$, 方差为 $2 \sum \lambda^2$ 。 $a\chi_d^2$ 的均值为 ad , 方差为 $2a^2d$ 。令

$ad = \sum \lambda$, $2a^2d = 2 \sum \lambda^2$, 得 $a = \sum \lambda^2 / \sum \lambda$, $d = (\sum \lambda)^2 / \sum \lambda^2$ 。数值例 (习题 30.22): $a = 1.5$, $d = 2.333$ 。■ [题目]

30.26 证明。 (1) 单调: 增加集合只会增加被覆盖的元素。次模: 设 $A \subseteq B$, $i \notin B$ 。
 $c(A \cup \{i\}) - c(A) = \sum_u w_u \mathbf{1}[u \in S_i \setminus \cup_A] \geq \sum_u w_u \mathbf{1}[u \in S_i \setminus \cup_B] = c(B \cup \{i\}) - c(B)$,
 因为 $\cup_A \subseteq \cup_B$ 。(2) 使用公畜的期望损失 πEC_{aff} , 淘汰为 C_{dis} ; 使用优于淘汰当且仅当 $\pi EC_{aff} < C_{dis}$, 故淘汰当 $\pi > C_{dis} / (C_{aff} E)$ 。习题 30.20: $120 / (1000 \times 0.5) = 0.24$ 。
 ■ [题目]

六、综合分析与研究设计题

30.27 方案 (1) **深度**: 以习题 30.15—30.16 的曲线权衡: $1\times$ 时有无插补的 r^2 为 0.486 与 0.785, $4\times$ 为 0.829 与 0.938。种公牛价值高, 可对核心公牛用 $10\sim 20\times$ 作为面板, 其余用 $1\sim 2\times$ 加插补。(2) **面板**: 用贪心覆盖准则选择 (习题 30.19: 10 头贪心 0.786 对随机 0.519), 并加入主要品系的关键祖先。(3) **质控**: 读段质量、深度分布、亲子冲突 (第 26 章)、后验校准分箱 (习题 30.15) 与 HWE。(4) **评价**: 按 MAF 分箱的 r^2 (稀有位点单独报告)、对留出高深度个体的“真值”比较, 且划分按家系整体留出, 避免亲缘导致的乐观。(5) **下游**: 把后验方差并入 G 的对角修正, 并比较剂量与硬判的预测准确性; 记录软件、参考版本与种子。 [题目]

30.28 验证链 (1) **独立证据**: 长读长中的断点两侧序列与参考比对, 短读长分裂读段与不一致配对读段, 读深度的拷贝数下降 (习题 30.18: 深度信号对纯合缺失最可靠, 对杂合最差)。(2) **位置与边界**: 边界精确到碱基, 确认非重复序列区 (重复区的比对歧义使深度信号不可信)。(3) **分型试验**: 在已知基因型的个体 (至少各三类) 上用候选分型方法评估准确率与杂合召回, 要求杂合召回 ≥ 0.8 (习题 30.18 在 $20\times$ 时为 0.761 仍偏低, 需要更高深度或分裂读段)。(4) **群体层面**: HWE 检验 (误判杂合会产生缺口)、与邻近 SNP 的 LD、频率在品系间的一致性。(5) **进入模型的判据**: 分型准确率、与标签 SNP 相比的功效 (习题 30.18: $\geq 10\times$ 才超过 $r^2 = 0.64$ 的标签), 以及对预测准确性的增益 (第 29 章的验证设计)。不满足时只作为候选, 不纳入评定。 [题目]

30.29 策略 (1) **集合与权重**: 按功能预测 (编码、保守性) 定义集合, 权重取 Beta(1,25) 密度 (习题 30.22: 24.41, 22.17, 19.64); (2) **方法**: 以 SKAT 为主、Burden 为辅, 并用两者的组合 (如 SKAT-O); 方向可能混合时不单用 Burden (习题 30.17)。(3) **跨品种**: 先在各品种内部检验, 再用元分析合并; 稀有变异在品种间的存在与频率差异大, 合并前检查亲缘结构 (用 G 作随机效应)。(4) **控制**: 把亲缘作为随机效

应，家系为单位的置换或自助校准 p 值（第 29 章）。(5) **复现与注释**：独立群体复现；变异注释版本与阈值事先固定；报告各变异的携带者数（习题 30.17：每个变异期望仅数十个携带者）、 p 值、效应方向、集合定义和多重检验校正。 [题目]

多组学、功能先验与因果推断

31.1 本章导学

学习目标

1. 理解“组学记录的价值是**条件遗传信息**”：在已有基因组预测的基础上，新增指标对育种值的增量由舒尔补 $\Delta\text{PEV} = c'_{ur} S_m^{-1} c_{ur}$ 决定，而不是表型相关。
2. 会分析技术重复、共同批次误差与组学遗传份额对增量的限制。
3. 掌握多核 REML 中基因组核 G 与组学核 O 的可识别性：何时只有总方差可识别。
4. 理解功能先验（BayesR、BayesRC）如何改变收缩，以及注释可能被数据否定。
5. 理解 TWAS 与孟德尔随机化（IVW、MR-Egger、加权中位数）的假设、偏差来源与“假介导”。
6. 理解有测量误差、未测混杂的中介分析：朴素乘积法、可靠性校正与工具变量的识别边界。

重点与难点

重点： $\Delta\text{PEV} = c'_{ur} S_m^{-1} c_{ur}$ ； $\text{IVW } \hat{\theta} = \sum w \beta_{gm} \beta_{gy} / \sum w \beta_{gm}^2$ ； $\text{TWAS } z_T = w' z / \sqrt{w' R w}$ ；中介中的衰减因子 $\lambda = (v_\eta + s^2) / (v_\eta + s^2 + v_\delta)$ ；多核 REML 的信息矩阵奇异性。

难点：区分“与表型相关”和“与育种值有条件相关”；表达与性状显著关联不等于表达介导；工具变量的 InSIDE 假设；测量误差使间接效应向下偏而未测混杂使其向上偏，两者方向相反、相互掩盖。

本章承接第 27 章（基因组预测）与第 29 章（验证设计），主题是：当测得的不只是基因型，还有转录、代谢、微生物与表观等分子表型时，它们什么时候能提高育种值预测，什么时候只是在表型上“看起来相关”，以及怎样从统计相关走向因果解释。全章的统一视角是：**条件于已有信息，新记录带来了多少新的遗传信息；而因果推断只在明确的假设下才成立。**

31.2 知识结构图




图 31.1 第 31 章知识结构图

左侧是“信息与测量”，中部是“模型整合与先验”，右侧是“因果推断”。

31.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
条件增量	$\Delta\text{PEV} = c'_{ur} S_m^{-1} c_{ur}$	$c_{ur} = c_m - C_{mb} V_b^{-1} c_b$
联合可靠性	$R^2 = r_b^2 + \Delta\text{PEV}$	目标方差为 1
技术误差	$\text{Var}(e_m) = v_{\text{batch}} + v_{\text{ind}}/r$	$r \rightarrow \infty$ 时仍有共同批次项
Wald 比值	$\hat{\theta}_j = \hat{\beta}_{gy,j} / \hat{\beta}_{gm,j}$	工具有效
IVW	$\hat{\theta} = \frac{\sum w \beta_{gm} \beta_{gy}}{\sum w \beta_{gm}^2}, w = 1/\text{se}_y^2$	过原点加权回归
MR-Egger	$\beta_{gy} = a + \theta \beta_{gm}$	截距检验定向多效性 (InSIDE)
TWAS	$z_T = w' z / \sqrt{w' R w}$	R 为 LD 矩阵
中介衰减	$b_{\text{naive}} \rightarrow \theta \lambda$	无混杂，中介含误差
总效应	$c + \alpha \theta$	对混杂与测量误差稳健
多核 REML	$\ell(\sigma) = -\frac{1}{2} [\log V + \log \mathbf{1}' V^{-1} \mathbf{1} + y' P y]$	$O \equiv G$ 时只识别 $\sigma_g^2 + \sigma_o^2$

31.4 补充内容与公式推导

推导 31.1 组学记录的条件遗传信息：舒尔补与表型相关的误导

设目标育种值 u (方差 1), 已有基因组预测 b (BLUP 性质 $\text{Cov}(u, b) = \text{Var}(b) = r_b^2$), 组学记录 $m = u_m + e_m$ 。给定 b 后, m 对 u 的新信息来自残差 $m - C_{mb}V_b^{-1}b$, 其协方差 $S_m = V_m - C_{mb}V_b^{-1}C'_{mb}$, 与 u 的协方差 $c_{ur} = c_m - C_{mb}V_b^{-1}c_b$, 于是预测误差方差下降 $\Delta\text{PEV} = c'_{ur}S_m^{-1}c_{ur}$, 联合可靠性 $R^2 = r_b^2 + \Delta\text{PEV}$ 。习题 31.15 (已有可靠性 0.40, 二十万次蒙特卡罗核验):

情景	表型相关 $r_P(m, y)$	单用 m 的可靠性	ΔPEV	联合可靠性 (理论 / MC)
S1 低重叠单指标	0.137	0.0750	0.0596	0.4596 / 0.4586
S2 高重叠单指标	0.137	0.0750	0.0061	0.4061 / 0.4034
S3 状态型指标	0.290	0.0009	0.0004	0.4004 / 0.4024
S4 三个指标	0.187	0.0885	0.0394	0.4394 / 0.4389

S1 与 S2 的组学指标自身完全相同 ($r_P = 0.137$, 单用可靠性 0.0750), 差别只在与已有基因组预测的重叠: 重叠高 ($\text{Cov}(u_m, b) = 0.20$) 时增量只有 0.0061, 不到低重叠 (0.03) 的十分之一。S3 的状态型指标与表型相关最高 (0.290), 但几乎不含遗传信息 ($\Delta\text{PEV} = 0.0004$)。表型相关高 $\neq$ 对育种值有条件增量。

推导 31.2 技术重复的边际收益与共同批次误差

设记录的误差由共同批次偏差 (方差 0.20, 重复无法消除) 与独立误差 (方差 0.50, 除以重复数 r) 组成: $\text{Var}(e_m) = 0.20 + 0.50/r$ 。习题 31.15 的 S1:

重复数 r	误差方差	ΔPEV (正确)	ΔPEV (误当独立)	记录遗传力
1	0.7000	0.0596	0.0596	0.300
2	0.4500	0.0796	0.0918	0.400
3	0.3667	0.0895	0.1120	0.450
4	0.3250	0.0955	0.1258	0.480
8	0.2625	0.1062	0.1544	0.533
1000	0.2005	0.1194	0.1993	0.599

增量随重复数单调增加但有上限 (0.1194); 若误当作独立误差, ΔPEV 被高估 ($r = 8$ 时 0.1544 对 0.1062, $r \rightarrow \infty$ 时 0.199 对 0.119)。重复的价值取决于误差中“可被平均掉”的部分, 批次必须在设计中随机化而不是靠重复抵消。

推导 31.3 两样本孟德尔随机化: IVW、MR-Egger 与加权中位数

暴露 $m = \sum g_j \gamma_j + aU + e_m$, 结局 $y = \theta m + \sum g_j \alpha_j + bU + e_y$, U 为未测混杂, α_j 为水平多效性。Wald 比值 $\hat{\theta}_j = \hat{\beta}_{gy,j}/\hat{\beta}_{gm,j}$; IVW 是过原点加权回归, $w = 1/\text{se}_y^2$; MR-Egger 加截距, 截距检验定向多效性; 加权中位数在半数以上权重来自有效工具时一致。习题 31.16 (30 个工具、各样本 6000 头、真实 $\theta = 0.25$ 、80 次重复):

情景	平均 F	OLS	IVW	IVW 覆盖	Egger	截距显著率	加权中位数
有效工具	14.0	0.497	0.231	0.97	0.223	0.05	0.212
平衡多效性	14.3	0.498	0.225	0.95	0.223	0.12	0.210
定向多效性	13.7	0.505	0.337	0.70	0.287	0.10	0.296
少数无效工具	14.2	0.504	0.318	0.88	0.261	0.12	0.259
弱工具	1.9	0.515	0.105	0.84	0.091	0.05	0.080

OLS 在存在混杂时高估近一倍 (0.50 对 0.25)。有效工具与平衡多效性下 IVW 近似无偏、覆盖率 ≥ 0.95 ; 定向多效性使 IVW 高估 (0.337)、覆盖率降到 0.70, Egger 与加权中位数减小偏差但标准差加倍 (Egger SD 0.118 对 IVW 0.057); 弱工具 ($F \approx 1.9$) 使估计向零偏 (0.105)。Egger 截距检验的功效在此设置下很低 (0.10–0.12), 不能依赖它“证明”无多效性。二阶方差使标准误放大 1.07–1.30 倍 (弱工具最大)。

推导 31.4 TWAS: 汇总 z 值与“连锁的直接作用”造成的假介导

在参考面板 (400 头) 用岭回归 (λ 五折交叉验证) 训练顺式表达权重 w ; 在独立 GWAS (5000 头) 得到各 SNP 的边际 z , 汇总统计 $z_T = w'z/\sqrt{w'Rw}$, R 为参考面板的 LD 矩阵 ($\rho = 0.92$, 40 个顺式 SNP)。习题 31.17:

情景	表达 CV R^2	平均 $ z_T $	显著率	z_T 与个体水平 z 相关	GWAS 峰在直接作用 SNP
表达介导	0.140	2.51	0.70	0.998	0.00

连锁的直接作用	0.148	1.96	0.48	0.999	0.68
无作用	0.150	0.77	0.03	1.000	0.03

汇总统计与个体水平 TWAS 几乎相同（全部重复中相关 0.9995，平均绝对差 0.034）。“无作用”时显著率 0.03（接近名义水平）。关键是“连锁的直接作用”：表达**没有**因果作用，只是与有直接作用的 SNP 连锁，TWAS 仍然有 48% 的显著率。因此 TWAS 显著不能证明表达介导，需要共定位、条件分析或实验证据；峰顶 SNP 一致的比例（表达介导 0.33）也远小于 1，“峰顶一致”与“同一因果”之间有很大距离。

推导 31.5 BayesR 与 BayesRC：功能先验改变的是收缩，不一定是预测

BayesR 把 β_j 看作混合分布 $\sum_k \pi_k N(0, \gamma_k \sigma_g^2)$ ， $\gamma = (0, 0.001, 0.01, 0.1)$ ；BayesRC 令不同注释类别各有自己的 π_c （Dirichlet 先验），使数据可以让注释类别有更高的非零比例，也可以否定注释。习题 31.18（训练 500、验证 400、400 个 SNP、20 个因果、其中 15 个落在占 15% 的注释类， $h^2 = 0.45$ ，900 次迭代）：

模型	验证准确度	回归斜率	注释类非零 π	非注释类非零 π	因果 PIP（注释/非注释）
SNP-BLUP	0.645	0.955	—	—	—
BayesR	0.945	0.962	0.236	0.236	0.681 / 0.711
BayesRC（真实注释）	0.938	0.966	0.540	0.222	0.789 / 0.631
BayesRC（随机注释）	0.942	0.956	0.339	0.241	0.689 / 0.717

稀疏架构下，混合先验比 SNP-BLUP 高出 0.30（0.945 对 0.645）。BayesRC 使用真实注释时，注释类的非零比例由 0.236 提高到 0.540（对非注释类的 0.222），注释类因果 SNP 的 PIP 由 0.681 提高到 0.789，但**验证准确度没有进一步提高**（0.938 对 0.945）：500 头训练样本下，注释主要改变了“哪些 SNP 被选中”，对整体预测的影响小于抽样误差。随机注释时，两类 π 相近（0.339 对 0.241），数据没有证实该注释。

推导 31.6 有误差、有混杂的中介分析与多核方差分解的可识别性

结构： $M = \alpha X + \kappa U + sZ + \eta$ ， $Y = \theta M + cX + \kappa U + dZ + \varepsilon$ ，观测中介 $M^* = M + \delta$ 。总效应 = $c + \alpha\theta$ （对混杂与测量误差稳健），间接效应 $\alpha\theta$ 。习题 31.19（ $n = 40000$ ，真值：间接 0.300、直接 0.150、总 0.450， $\theta = 0.6$ ）：

κ	中介误差	排除限制	间接 (可靠性)		
			间接 (朴素)	校正	间接 (2SLS)
0	无	满足	0.300	0.300	0.300
0	有	满足	0.196	0.300	0.300
0.4	无	满足	0.361	0.361	0.299
0.4	有	满足	0.247	0.363	0.302
0.4	有	违反	0.253	0.371	0.387

测量误差使朴素间接效应向下 ($0.300 \rightarrow 0.196$, $\theta\lambda = 0.6 \times 0.6517 = 0.391$ 解释了 b 的衰减), 混杂使其向上 (0.361), 二者可部分抵消 (0.247 仍低于真值)。可靠性校正去掉误差影响但保留混杂 (0.363), 2SLS 去掉两者 (0.302) ——前提是排除限制成立; 工具直接影响性状时 (违反), $\hat{b} \rightarrow \theta + d/s = 0.771$, 间接效应 0.387 、直接效应 0.064 都错。**多核 REML** (习题 31.20, $n = 360$): 组学核与基因组核高度相似时 (遗传份额 $s = 0.9$, $\text{corr}(G, O) = 0.805$), σ_g^2 与 σ_o^2 估计相关 -0.597 、SD 为 0.048 与 0.046 , 但总遗传方差 $\sigma_g^2 + \sigma_o^2$ 的估计 (0.1327 对真值 0.130) 稳定; $O \equiv G$ 时, 限制性对数似然沿 $\sigma_g^2 + \sigma_o^2$ 固定的直线最大差 6×10^{-13} , 信息矩阵最小特征值 -1.1×10^{-17} (奇异)。 $s = 0.15$ 时组学核携带独立信息, 留出公畜后代的预测相关由 0.192 (G 单核) 提高到 0.251 (G+O), 而 $s = 0.9$ 时无增益 (0.128 对 0.122)。

延伸阅读：共定位与多变量 MR

共定位检验同一区域内两个性状 (如 eQTL 与 GWAS) 是否共享因果变异; PP4 高并不等于表达介导。多变量 MR 同时估计多个暴露 (如多个代谢物) 的直接作用, 缓解通路共享引起的多效性。二者都依赖有足够功效的 GWAS 与适当的 LD 参考, 且对种群结构敏感。在家畜中参考面板常小于人类研究, 更要报告共定位后验与置信区间, 而不是只给显著性。

常见误区

1. 用组学指标与表型的相关性来选择辅助记录。
2. 以为技术重复可以无限提高信息。
3. 把 TWAS 显著等同于“表达介导”。
4. 用 MR-Egger 截距不显著来证明无多效性。
5. 忽略测量误差与混杂在中介分析中方向相反。
6. 在 G 与 O 几乎共线时解释单个方差分量。
7. 用同一数据学习注释权重又用它评价预测 (泄漏)。

31.5 习题

一、单项选择题

31.1 ★ [单选] 一个新的组学指标是否值得采集用于育种值预测，最关键的量是

- (A) 指标与表型的相关系数
- (B) 指标在已有基因组预测基础上对育种值的条件增量 ΔPEV
- (C) 指标的变异系数
- (D) 指标的测量成本

[答案]

31.2 ★ [单选] 存在未测混杂时，用普通回归 (OLS) 估计暴露对结局的效应与两样本 MR (有效工具) 相比

- (A) 都无偏
- (B) OLS 偏倚，有效工具的 IVW 近似无偏
- (C) IVW 偏倚更大
- (D) 都偏向零

[答案]

31.3 ★★ [单选] MR-Egger 回归的截距显著不为零，表示

- (A) 暴露对结局无作用
- (B) 存在定向 (平均非零) 的水平多效性，违反 InSIDE 以外的简单假设
- (C) 工具为弱工具
- (D) 样本重叠

[答案]

31.4 ★★ [单选] TWAS 在某基因上显著，下列哪个解释**不能**被排除

- (A) 表达介导了遗传对性状的作用
- (B) 与表达 QTL 连锁的变异直接作用于性状，表达本身无作用
- (C) 二者同时存在
- (D) 以上都不能排除

[答案]

31.5 ★★ [单选] 中介变量含随机测量误差、且没有未测混杂时，朴素乘积法给出的间接效应

- (A) 无偏
- (B) 向零衰减 (偏小)
- (C) 偏大
- (D) 方向随机

[答案]

31.6 ★★★ [单选] 多核 REML 中, 当组学核 O 与基因组核 G 完全相同时

- (A) 两个方差分量都可识别
 (B) 只有 $\sigma_g^2 + \sigma_o^2$ 可识别, 信息矩阵奇异
 (C) 总方差也不可识别
 (D) 估计有偏但可识别

[答案]

二、判断与改错题

31.7 ★ [判断] 与表型相关最高的组学指标, 对育种值预测的增量也一定最大。 [答案]

31.8 ★ [判断] 增加技术重复数可以把组学记录的误差方差降到零。 [答案]

31.9 ★★ [判断] BayesRC 使用随机 (无信息) 注释时, 数据通常不会显示不同注释类别间存在明显不同的非零比例。 [答案]

31.10 ★★ [判断] 当工具变量直接影响结局 (排除限制被违反) 时, 两阶段最小二乘法对间接效应仍然一致。 [答案]

三、填空题

31.11 ★ [填空] 某 SNP 对暴露的效应 $\beta_{gm} = 0.15$, 对结局的效应 $\beta_{gy} = 0.045$, Wald 比值 $\hat{\theta} = \underline{\hspace{2cm}}$ 。 [答案]

31.12 ★ [填空] 中介模型中 $c = 0.15$, $\alpha = 0.5$, $\theta = 0.6$, 总效应 = $\underline{\hspace{2cm}}$, 间接效应 = $\underline{\hspace{2cm}}$ 。 [答案]

31.13 ★★ [填空] $v_{\eta} = 1$, $s = 0.35$, 测量误差方差 $v_{\delta} = 0.6$, 条件于 X 的中介可靠程度 $\lambda = \underline{\hspace{2cm}}$ (三位小数)。 [答案]

31.14 ★★ [填空] 某指标遗传方差 0.30, 共同批次误差方差 0.20, 独立误差方差 0.50, 取 $r = 4$ 次重复的均值, 记录遗传力 = $\underline{\hspace{2cm}}$ 。 [答案]

四、计算题

?? 31.15 | 4 | 计算 条件信息与技术重复。计算四个情景的单用可靠性、 Δ PEV、联合可靠性 (含蒙特卡罗核验), 并给出技术重复的边际收益及误当独立误差的后果。 [程序]

ch31/ex31_15_conditional_info.py

?? 31.16 | 4 | 计算 **两样本孟德尔随机化**。在五种多效性情景下比较 OLS、IVW、MR-Egger 与加权中位数的偏差、覆盖率与截距检验功效。[程序] `ch31/ex31_16_mr_pleiotropy.py`

?? 31.17 | 4 | 计算 **TWAS 与假介导**。训练表达权重，比较汇总统计与个体水平 z ，评估三种情景的显著率与峰顶一致率。[程序] `ch31/ex31_17_twas.py`

?? 31.18 | 4 | 计算 **BayesRC 与功能先验**。比较 SNP-BLUP、BayesR、BayesRC（真实注释与随机注释）的预测、斜率与各类别 π 。[程序] `ch31/ex31_18_bayesrc.py`

?? 31.19 | 4 | 计算 **有误差有混杂的中介分析**。比较朴素乘法、可靠性校正与 2SLS 在 8 种设置下的间接与直接效应。[程序] `ch31/ex31_19_mediation.py`

?? 31.20 | 4 | 计算 **多核 REML 的可识别性**。在组学遗传份额 $s = 0.9$ 与 0.15 下估计四个方差分量，并核验 $O \equiv G$ 时的奇异性与预测增益。[程序] `ch31/ex31_20_multikernel.py`

31.21 ★★ [计算] 舒尔补手算。目标 u 方差 1；已有预测 b 的 $\text{Var}(b) = \text{Cov}(u, b) = 0.4$ 。单个组学记录 m 方差 1， $\text{Cov}(m, u) = 0.3$ ， $\text{Cov}(m, b) = 0.12$ 。求 S_m 、 c_{ur} 、 ΔPEV 与联合可靠性。[答案]

31.22 ★★ [计算] IVW 的手算。三个工具： $\hat{\beta}_{gm} = (0.10, 0.20, 0.15)$ ， $\hat{\beta}_{gy} = (0.03, 0.05, 0.06)$ ， $\text{se}_y = (0.01, 0.01, 0.02)$ 。求各 Wald 比值、IVW 估计与标准误、Cochran Q 及其 p 值（自由度 2）。[答案]

五、推导与证明题

31.23 ★★★ [证明] 证明联合可靠性 $R^2 = r_b^2 + c_{ur}' S_m^{-1} c_{ur}$ ，并说明当 m 的信息已全部包含在 b 中（ m 与 u 的关系完全由 b 传递）时 $\Delta\text{PEV} = 0$ 。[答案]

31.24 ★★ [证明] 证明 IVW 估计量等价于 $\beta_{gy,j}/\text{se}_{y,j}$ 对 $\beta_{gm,j}/\text{se}_{y,j}$ 的过原点回归，其方差为 $1/\sum w_j \beta_{gm,j}^2$ 。[答案]

31.25 ★★★ [证明] 在 $\kappa = 0$ （无混杂）下，证明观测中介含加性测量误差 δ （方差 v_δ ，与 η 等独立）时，条件于 X 后 Y 对 M^* 的回归斜率收敛于 $\theta\lambda$ ， $\lambda = \text{Var}(M | X) / \text{Var}(M^* | X)$ 。[答案]

31.26 ★★★ [证明] 证明当 $O = G$ 时 $V = \sigma_g^2 G + \sigma_o^2 O + \dots$ 只依赖 $\sigma_g^2 + \sigma_o^2$ ，从而限制性似然沿 $\sigma_g^2 + \sigma_o^2 = \text{常数}$ 的直线不变，信息矩阵奇异。[答案]

六、综合分析与研究设计题

31.27 ★★ [综合] 某公司拟在 3 万头种猪中增加一个血液代谢物检测用于育种值预测。设计评估是否值得采集的方案：条件信息、技术重复、批次设计与验证。 [答案]

31.28 ★★★ [综合] 研究者用 TWAS 发现某基因表达与产蛋率显著关联，并称“该基因通过表达调控影响产蛋率”。设计一套证据链检验该说法，并给出可能的替代解释与对应检验。 [答案]

31.29 ★★★ [综合] 你要用公开的 GWAS 汇总数据做两样本 MR，检验某代谢物对肉质的因果效应。写出分析计划：工具选择、F 统计量、敏感性分析、多效性诊断与结果报告。 [答案]

31.6 参考答案与解析

一、单项选择题

31.1 (B)。价值是条件于已有信息的新增遗传信息 ΔPEV (推导 31.1)。习题 31.15: S3 状态型指标与表型相关最高 (0.290)，但 $\Delta\text{PEV} = 0.0004$ ；S1 与 S2 的指标自身相同， ΔPEV 分别为 0.0596 与 0.0061。 [题目]

31.2 (B)。OLS 把未测混杂的作用算进暴露效应：习题 31.16 中 OLS 为 0.50 (真值 0.25)，有效工具下 IVW 为 0.231。 [题目]

31.3 (B)。截距衡量工具—暴露效应为零时仍存在的平均直接作用，即定向多效性。注意截距检验功效低：习题 31.16 定向多效性情景的显著率仅 0.10。 [题目]

31.4 (D)。表达介导、与 eQTL 连锁的直接作用、二者并存都可能给出显著 TWAS。习题 31.17 的“连锁的直接作用”情景表达无因果作用，显著率仍达 0.48。 [题目]

31.5 (B)。测量误差使 b 衰减为 $\theta\lambda$ ：习题 31.19 ($\kappa = 0$) 朴素间接效应 0.196 (真值 0.300)， $\lambda = 0.6517$ 。 [题目]

31.6 (B)。 $O \equiv G$ 时 V 只含 $\sigma_g^2 + \sigma_o^2$ ，习题 31.20：沿等和直线限制性对数似然最大差 6×10^{-13} ，信息矩阵最小特征值 -1.1×10^{-17} 。 [题目]

二、判断与改错题

31.7 错误。习题 31.15: S3 的 $r_p = 0.290$ 是四个情景中最高，但 $\Delta\text{PEV} = 0.0004$ ，几乎无增量；S4 的 $r_p = 0.187$ ， $\Delta\text{PEV} = 0.0394$ 。 [题目]

31.8 错误。共同批次偏差不随重复数下降。习题 31.15: $r \rightarrow \infty$ 时 ΔPEV 上限 0.1194, 误差方差下限 0.20。 [题目]

31.9 正确 (通常)。习题 31.18 随机注释下两类的非零 π 为 0.339 与 0.241, 差距远小于真实注释 (0.540 对 0.222)。小样本时随机波动仍会产生一定差异, 不能单凭 π 差异就认定注释有效。 [题目]

31.10 错误。排除限制被违反时 $\hat{b} \rightarrow \theta + d/s$ 。习题 31.19: $\hat{b} = 0.771$ (真值 0.6), 2SLS 间接效应 0.387、直接效应 0.064, 均有偏。 [题目]

三、填空题

31.11 $0.045/0.15 = 0.30$ 。 [题目]

31.12 总效应 $= c + \alpha\theta = 0.15 + 0.5 \times 0.6 = 0.45$; 间接效应 $\alpha\theta = 0.30$ 。 [题目]

31.13 $\lambda = (1 + 0.35^2)/(1 + 0.35^2 + 0.6) = 1.1225/1.7225 = 0.652$ 。 [题目]

31.14 误差方差 $0.20 + 0.50/4 = 0.325$, $h^2 = 0.30/(0.30 + 0.325) = 0.48$ 。 [题目]

四、计算题

31.15 结果见推导 31.1 与 31.2。四个情景的联合可靠性 (理论/蒙特卡罗) : S1 0.4596/0.4586、S2 0.4061/0.4034、S3 0.4004/0.4024、S4 0.4394/0.4389; 增量权重 (S1) 等指标在 m 上的残差权重为正。S4 的三个指标中, 第三个指标 (遗传相关为负) 的权重为负。技术重复: $r = 1, 2, 3, 4, 8, 1000$ 时 $\Delta\text{PEV} = 0.0596, 0.0796, 0.0895, 0.0955, 0.1062, 0.1194$; 误当独立误差则高估为 0.0596, 0.0918, 0.1120, 0.1258, 0.1544, 0.1993。解读: 先看条件增量, 再决定要不要测; 重复要配合批次随机化。 [题目]

31.16 结果见推导 31.3。要点: 有效工具 IVW 0.231 (覆盖 0.97); 平衡多效性 0.225 (0.95); 定向多效性 IVW 0.337 (覆盖 0.70), Egger 0.287、加权中位数 0.296; 少数无效工具 (20%) IVW 0.318 (0.88)、加权中位数 0.259 (更接近真值); 弱工具 IVW 0.105、 $F = 1.9$ 。解读: 没有一个估计量在所有情景下最优, 三者的一致结果才可以增加可信度; 弱工具使一切估计向零靠近。 [题目]

31.17 结果见推导 31.4。解读: 汇总统计与个体水平 TWAS 一致 (相关 0.9995), 所以公开汇总数据足够; 但显著不等于介导, “连锁的直接作用”显著率 0.48, “表达介导”0.70, “无作用”0.03; 峰顶一致率 0.33/0.00/0.02。 [题目]

31.18 结果见推导 31.5。BayesR 准确度 0.945 对 SNP-BLUP 0.645; BayesRC (真实注释) 0.938、斜率 0.966; 注释类非零 π 0.540 对 0.222 (非注释), 随机注释 0.339 对 0.241。解读: 功能先验改变了稀疏模型中“谁被选中”(注释类因果 PIP 0.681 $\rightarrow$ 0.789), 整体预测在此规模下无显著提升; 注释的价值应在更大训练集与更有信息的注释上评估, 并防止注释权重与评价数据泄漏。 [题目]

31.19 结果见推导 31.6。完整 8 种设置的间接效应 (朴素/校正/2SLS): $\kappa = 0$ 无误差满足 0.300/0.300/0.300; 无误差违反 0.310/0.310/0.387; 有误差满足 0.196/0.300/0.300; 有误差违反 0.201/0.308/0.385; $\kappa = 0.4$ 无误差满足 0.361/0.361/0.299; 无误差违反 0.369/0.369/0.385; 有误差满足 0.247/0.363/0.302; 有误差违反 0.253/0.371/0.387。直接效应 (2SLS) 满足时 0.150, 违反时 0.064。 $\lambda = 0.6517$, 核验 $b_{naive} = 0.3910 = \theta\lambda$ 。解读: 只有 2SLS 在“工具有效”的条件下去掉了两类偏倚; 排除限制不可检验, 必须用生物学论证。 [题目]

31.20 结果见推导 31.6。 $s = 0.9$: $\text{corr}(G, O) = 0.805$, $\hat{\sigma}_g^2 = 0.0736 \pm 0.0484$ (真值 0.09), $\hat{\sigma}_o^2 = 0.0592 \pm 0.0461$ (真值 0.04), 二者估计相关 -0.597 ; $\hat{\sigma}_g^2 + \hat{\sigma}_o^2 = 0.1327 \pm 0.0424$ (真值 0.13); 预测相关 G 单核 0.128、 $G+O$ 0.122。 $s = 0.15$: $\text{corr}(G, O) = 0.120$, $\hat{\sigma}_g^2 = 0.0864$, $\hat{\sigma}_o^2 = 0.0382$; 预测相关由 0.192 升到 0.251。 $O \equiv G$ 的核验: 限制性对数似然差 6.0×10^{-13} , 信息矩阵最小特征值 -1.1×10^{-17} (≈ 0)。解读: 组学校对预测的价值取决于其独立于 G 的信息, 而不是它的“遗传份额”本身。 [题目]

31.21 $C_{mb}V_b^{-1} = 0.12/0.4 = 0.3$ 。 $S_m = 1 - 0.12^2/0.4 = 1 - 0.036 = \mathbf{0.964}$ 。 $c_{ur} = 0.3 - 0.3 \times 0.4 = \mathbf{0.18}$ 。 $\Delta\text{PEV} = 0.18^2/0.964 = \mathbf{0.0336}$ 。联合可靠性 $= 0.4 + 0.0336 = \mathbf{0.4336}$ 。解读: 单用 m 的可靠性为 $0.3^2/1 = 0.09$, 但其中 $0.4 \times 0.3^2 / \dots$ 的部分已被 b 吸收, 条件增量只有 0.0336。 [题目]

31.22 Wald 比值 $0.03/0.10 = 0.30$, $0.05/0.20 = 0.25$, $0.06/0.15 = 0.40$ 。权重 $w = (10000, 10000, 2500)$ 。分子 $\sum w\beta_{gm}\beta_{gy} = 30 + 100 + 22.5 = 152.5$; 分母 $\sum w\beta_{gm}^2 = 100 + 400 + 56.25 = 556.25$ 。 $\hat{\theta} = 152.5/556.25 = \mathbf{0.2742}$, $\text{se} = 1/\sqrt{556.25} = \mathbf{0.0424}$ 。残差 $\beta_{gy} - \hat{\theta}\beta_{gm} = (0.00258, -0.00483, 0.01888)$, $Q = \sum wr^2 = 0.0668 + 0.2334 + 0.8908 = \mathbf{1.191}$, 自由度 2, $p = \mathbf{0.551}$: 无证据表明工具间不一致 (仅 3 个工具功效很低)。 [题目]

五、推导与证明题

31.23 证明。 设 $I = (b, m)$ 。 $R^2 = c_I'V_I^{-1}c_I$, 其中 $c_I = (c_b, c_m)$, $V_I = \begin{pmatrix} V_b & C_{bm} \\ C_{mb} & V_m \end{pmatrix}$ 。分块求逆 (舒尔补 $S_m = V_m - C_{mb}V_b^{-1}C_{bm}$) 得 $c_I'V_I^{-1}c_I = c_b^2/V_b + c_{ur}'S_m^{-1}c_{ur}$, 其中

$c_{ur} = c_m - C_{mb}V_b^{-1}c_b$ 。因 $c_b = V_b = r_b^2$, $c_b^2/V_b = r_b^2$ 。若 m 与 u 的关系完全由 b 传递, 即 $c_m = C_{mb}V_b^{-1}c_b$, 则 $c_{ur} = 0$, $\Delta\text{PEV} = 0$ 。习题 31.21 的 $c_m = 0.3$ 与 $0.12/0.4 \times 0.4 = 0.12$ 之差 0.18 即为 c_{ur} 。■

【题目】

31.24 证明。令 $\tilde{y}_j = \beta_{gy,j}/\text{se}_{y,j}$, $\tilde{x}_j = \beta_{gm,j}/\text{se}_{y,j}$ 。过原点回归 $\hat{\theta} = \sum \tilde{x}_j \tilde{y}_j / \sum \tilde{x}_j^2 = \sum w_j \beta_{gm,j} \beta_{gy,j} / \sum w_j \beta_{gm,j}^2$ ($w_j = \text{se}_{y,j}^{-2}$)。在 $\beta_{gy,j} \sim N(\theta \beta_{gm,j}, \text{se}_{y,j}^2)$ 下, $\tilde{y}_j$ 的方差为 1, 故 $\text{Var}(\hat{\theta}) = 1 / \sum \tilde{x}_j^2 = 1 / \sum w_j \beta_{gm,j}^2$ 。习题 31.22: $\hat{\theta} = 0.2742$, $\text{se} = 0.0424$ 。

■

【题目】

31.25 证明。以 X 残差化后 (上标 $\perp$): $M^\perp = \eta + sZ$ ($\kappa = 0$), $M^{*\perp} = M^\perp + \delta$, $Y^\perp = \theta M^\perp + dZ + \varepsilon$ (取 $d = 0$)。 $\text{Cov}(M^{*\perp}, Y^\perp) = \theta \text{Var}(M^\perp)$ (δ, ε 与其余独立), $\text{Var}(M^{*\perp}) = \text{Var}(M^\perp) + v_\delta$ 。斜率 $\rightarrow \theta \text{Var}(M^\perp) / [\text{Var}(M^\perp) + v_\delta] = \theta \lambda$, 其中 $\text{Var}(M^\perp) = v_\eta + s^2$ 。数值: $v_\eta = 1$, $s = 0.35$, $v_\delta = 0.6$ 得 $\lambda = 0.6517$; 习题 31.19 核验朴素 $b = 0.3910 = \theta \lambda$ 。■

【题目】

31.26 证明。 $V = \sigma_g^2 G + \sigma_o^2 O + \sigma_p^2 Z_p Z_p' + \sigma_e^2 I$ 。 $O = G$ 时 $V = (\sigma_g^2 + \sigma_o^2)G + \sigma_p^2 Z_p Z_p' + \sigma_e^2 I$, 仅依赖和。因此对数似然 ℓ 在 $\sigma_g^2 + \sigma_o^2$ 固定时对分配比例的导数为零; 信息矩阵 $I_{kl} = \frac{1}{2} \text{tr}(PK_k PK_l)$ 中 $K_g = K_o = G$, 两行 (列) 相同, 故奇异。习题 31.20 数值: 5 个分配比例的限制性对数似然最大差 5.97×10^{-13} 。■

【题目】

六、综合分析与研究设计题

31.27 方案 (1) 条件增量: 取已有育种值的可靠性 (如 r_b^2), 估计代谢物与目标性状的遗传协方差及与基因组预测的重叠, 用舒尔补计算 ΔPEV (习题 31.15: S2 重叠高时增量仅 0.006)。表型相关只作辅助。(2) **重复性与批次:** 估计批内重复力与共同批次方差, 随机化批次, 估算 r 重复的边际收益 (习题 31.15: $r = 2$ 时 ΔPEV 已达上限的 67%)。(3) **状态型与稳定型:** 纵向测量区分稳定遗传差异与短期状态 (S3 类指标几乎无增量)。(4) **验证:** 按第 29 章设计, 对尚无组学记录的新家系做时间划分, 报告可靠性、斜率与区间; 成本——每头单价与可靠性增益的比。(5) **停止规则:** ΔPEV 与成本比低于阈值则不采集。

【题目】

31.28 证据链 (1) 共定位: 在该基因座检验表达 QTL 与产蛋率 GWAS 信号是否共享因果变异 (用后验概率, 而不是仅看显著性)。(2) **条件分析:** 调整 eQTL 峰顶后看产蛋率信号是否消失; 调整性状峰顶后看表达信号。(3) **替代解释:** 连锁的直接作用 (习题 31.17: 显著率 0.48)、表达的反向因果、组织不匹配、训练权重过拟合 (表达 $CV R^2$ 仅 0.14); 对应检验分别是共定位与条件分析、MR 的方向性检验、使用相关组织与多组织权重、独立参考面板。(4) **实验与独立证据:** 基因编辑或功能

实验、不同品种的复现。(5) **措辞**: 在没有共定位与实验时, 只说“该基因表达的遗传预测值与产蛋率关联”, 不写“通过表达调控影响”。 [题目]

31.29 分析计划 (1) **工具**: 以 GWAS 显著 ($p < 5 \times 10^{-8}$) 并 LD 修剪 ($r^2 < 0.001$) 的变异, 按增加暴露的等位基因对齐; 去除回文位点并检查频率一致。(2) **强度**: 报告每个工具与平均的 $F = \hat{\beta}_{gm}^2 / \text{se}^2$, $F < 10$ 的剔除 (习题 31.16: 平均 $F = 1.9$ 时 IVW 向零偏)。(3) **主分析与敏感性**: IVW 为主, MR-Egger、加权中位数、留一法与 Cochran Q (习题 31.22); 若估计不一致, 不能只报告 IVW。(4) **多效性诊断**: Egger 截距 (注意低功效, 习题 31.16: 0.05–0.12), 工具效应的漏斗图, 已知多效性变异的排除。(5) **样本重叠与群体**: 确保暴露与结局样本不重叠、同一品种; 跨品种时检查 LD 与效应一致性。(6) **报告**: 估计及区间、工具数、 F 、各方法结果与异质性、被剔除的工具、局限性 (InSIDE 与排除限制不可检验)。 [题目]

基因型 × 环境、韧性与可持续育种

32.1 本章导学

学习目标

- 1. 区分环境的四种角色——测量、暴露、反应与管理，并把离散环境、连续梯度分别写成相关性状与反应规范。
- 2. 掌握随机回归反应规范 $g(x) = a + bx$ 的协方差结构、跨环境遗传相关 $r_g(x, x')$ ，理解设计集中时斜率不可识别、外推失准。
- 3. 理解“目标环境分布决定怎样选择”：对环境积分的育种目标、maximin 稳健选择与选错目标的损失。
- 4. 会用折线（阈值）模型描述热应激，并理解环境测量误差对阈值与斜率的影响。
- 5. 会从偏离曲线构造韧性指标（对数方差、自相关、累计损失），理解测量噪声与记录长度对遗传力的作用，并用状态空间模型分离噪声与真实恢复。
- 6. 理解排放性状的定义（总量、强度、遗传残差、约束指数）如何改变选择方向，及差值型性状的准确性。

重点与难点

重点： $\text{Cov}(g(x), g(x')) = \sigma_a^2 + \sigma_{ab}(x+x') + \sigma_b^2 xx'$; $H_T = a + \mu_T b$; 折线 $\max(0, \text{THI} - T_0)$; $\text{AR}(1) + \text{噪声}$ 下 $\text{ac1} = \phi \text{Var}(s) / (\text{Var}(s) + \tau^2)$; 残差排放 $E - bP$ 与指数的响应 $\Delta G = i Gw / \sqrt{w' R w}$ 。

难点：反应规范的识别要求环境范围足够宽；平均最优与最差情形最优是两个不同的目标；测量噪声使韧性指标被“稀释”；强度（比值）选择可以在降低强度的同时提高绝对排放；遗传残差的系数要用 EBV 尺度而不是遗传尺度。

本章承接第 20 章（杂种优势与杂交）、第 24 章（多性状与阈值）与第 29 章（验证与迁移）。前面各章把环境作为固定效应处理；本章把环境放到模型的中心：同一基因型在不同环境的表现不同（G×E），在扰动下的恢复能力不同（韧性），选择的目标也要对未来环境分布与可持续约束负责。

32.2 知识结构图




图 32.1 第 32 章知识结构图

左侧是“环境与反应规范”，中部是“目标与阈值”，右侧是“韧性、排放与部署”。

32.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
反应规范	$g_i(x) = a_i + b_i x,$ $(a, b) \sim N(0, \Sigma)$	连续环境梯度
跨环境协方差	$\sigma_a^2 + \sigma_{ab}(x + x') + \sigma_b^2 x x'$	r_g 可小于 0（重排）
积分目标	$H_T = E_x[g(x)] = a + \mu_T b$	可加风险项 $-\kappa b s_T$
选择差	$\Delta G = i w' V h / \sqrt{w' V w}$	线性指数，正态
折线	$\max(0, THI - T_0)$	阈值 T_0 由剖面似然估计
韧性指标	$\ln \text{Var}(r), \text{ac1}, \text{累计损失}$	稳态段 + 冲击窗口
噪声稀释	$\text{ac1}_{obs} \approx \phi \text{Var}(s) / (\text{Var}(s) + \tau^2)$	白噪声测量误差
滞后比值	$\hat{\gamma}(2) / \hat{\gamma}(1) \rightarrow \phi$	对白噪声稳健
恢复半衰期	$t_{1/2} = \ln 0.5 / \ln \phi$	AR(1)
遗传残差	$E_{res} = E - bP, \quad b = \sigma_{EP} / \sigma_P^2$	EBV 尺度用 $b_R = b \rho_E / \rho_P$

32.4 补充内容与公式推导

推导 32.1 随机回归反应规范与跨环境遗传相关

公畜 i 的女儿在环境 x 的记录 $y = a_i + b_i x + e$, $(a_i, b_i) \sim N(0, \Sigma)$ 。环境 x 与 x' 的遗传协方差为 $\sigma_a^2 + \sigma_{ab}(x + x') + \sigma_b^2 x x'$, 故 $r_g(x, x')$ 随环境距离增大而下降, 当 $\rho_{ab} = 0$ 时 $r_g(-x, x) = (\sigma_a^2 - x^2 \sigma_b^2) / (\sigma_a^2 + x^2 \sigma_b^2)$, 在 $x > \sigma_a / \sigma_b$ 时为负, 即重排。习题 32.15 (400 头公畜 × 20 女儿, $\sigma_a^2 = 1$, $\sigma_b^2 = 0.30$, $\rho = -0.2$, $\sigma_e^2 = 3$, 10 次重复): $r_g(-2, 2) = -0.093$, $r_g(-1, 1) = 0.546$, $r_g(0, 2) = 0.588$; 模拟样本 $r_g(-2, 2)$ 均值 -0.072 。下表为在环境 x 处预测 $a + bx$ 的准确性:

设计	模型	$x = -2$	-1	0	1	2
A 均匀分布	仅主效应	0.688	0.832	0.925	0.800	0.566
A 均匀分布	随机回归	0.898	0.919	0.931	0.901	0.864
B 集中分布	仅主效应	0.646	0.776	0.857	0.735	0.515
B 集中分布	随机回归	0.759	0.833	0.881	0.806	0.687

忽略 $G \times E$ 的主效应模型在中心环境尚可 (0.925), 在极端环境降到 0.57—0.69; 随机回归在极端环境保持 0.86—0.90。但当每头公畜的女儿集中在其牛场的环境附近 (设计 B), 斜率信息不足, 极端环境的准确性由 0.898/0.864 降到 0.759/0.687: 反应规范需要环境范围上的连接设计。

推导 32.2 目标环境分布决定选择: 积分目标、maximin 与选错目标

对环境积分的目标 $H_T = E_x[g(x)] = a + \mu_T b$ (目标环境 $x \sim N(\mu_T, s_T^2)$), 线性指数 $I = w'(\hat{a}, \hat{b})$ 的选择差 $\Delta G = i w' V h / \sqrt{w' V w}$, $h = (1, \mu_T)$, $V = \text{Var}(\hat{a}, \hat{b})$ 。习题 32.16 (6000 头公畜, 选前 10%, $i = 1.755$, $V = \begin{pmatrix} 0.871 & -0.110 \\ -0.110 & 0.217 \end{pmatrix}$)。选择差 (相对群体均值) 与最差环境值 ($x = \pm 2$ 取小):

目标 μ_T	规则	选择差 (MC)	理论	最差环境值
-1	S1 只用 $\hat{a}$	1.852	1.845	0.729
-1	S2 对目标积分	2.003	2.008	0.395
-1	S3 maximin	1.574	—	0.862
-1	S4 选错目标	1.279	1.231	0.548
0	S1 / S2	1.644	1.638	0.729
0	S3 maximin	1.496	—	0.862
1	S1 只用 $\hat{a}$	1.437	1.431	0.729

1	S2 对目标积分	1.647	1.635	0.548
1	S3 maximin	1.419	—	0.862
1	S4 选错目标	1.014	1.003	0.395

理论值与蒙特卡罗吻合（相差 ≤ 0.05 ）。对目标分布积分（S2）在每个目标下选择差最大， $\mu_T = 1$ 时比忽略 $G \times E$ （S1）多 0.21，比选错目标（S4，按 $\mu = -1$ 的方向选）多 0.63（38% 的损失）。maximin（S3）的最差环境值最高（0.862 对 S2 的 0.548），代价是平均选择差下降 0.23。没有一个“与环境无关的最优”：选择规则必须声明目标环境分布与风险偏好。

推导 32.3 热应激的折线模型、阈值估计与环境测量误差

奶牛 i 在第 d 日的产量偏差 $y_{id} = -\beta_i \max(0, \text{THI}_d - T_0) + e_{id}$, $\beta_i = \beta_0 + u_i$ （耐热性）。在 T 网络上对群体平均反应做折线回归，取残差平方和最小者为 $\hat{T}_0$ 。习题 32.19（800 头 $\times$ 150 天，真值 $T_0 = 72$ 、 $\beta_0 = 0.35$ 、 $\text{sd}_\beta = 0.10$ ，8 次重复；热年 THI 整体 +4）：

τ_m	$\hat{T}_0$	斜率	r_1	r_2	r_3	RMSE_1	RMSE_3
0	72.0	0.350	0.805	0.754	0.683	21.4	65.0
2	72.2	0.312	0.779	0.733	0.664	27.3	70.0
4	71.5	0.205	0.709	0.680	0.617	42.5	81.0

（表中 r_1, r_2, r_3 依次为折线（ $\hat{T}_0$ ）、折线（错设 $T = 66$ ）、线性暴露下估计耐热性与真实 β 的相关； RMSE_1 、 RMSE_3 为热年总损失预测的折线与线性模型的均方根误差。）无测量误差时阈值恢复得很好（72.0）；THI 误差使斜率估计向零衰减（0.350 $\rightarrow$ 0.205），个体耐热性的准确性由 0.805 降到 0.709。线性暴露对个体耐热性的准确性低于折线（0.683 对 0.805），预测更热的年份时 RMSE 约为折线的三倍（65.0 对 21.4）；阈值错设为 66 也使准确性下降（0.754）。耐热性的评定需要准确的暴露测量与阈值，而不只是更多记录。

推导 32.4 韧性指标的遗传力与测量噪声

日偏离 $r_t = s_t + v_t$, $s_t = \phi s_{t-1} + \sigma \varepsilon_t$ （ ϕ 为恢复持续性， $\text{logit } \phi$ 与 $\ln \sigma$ 含公畜效应，真实 $h^2 \approx 0.25$ ），冲击 -12 发生在第 10 天，噪声 $v \sim N(0, \tau^2)$ 。指标取稳态段的 $\ln \text{Var}$ 、一阶自相关 ac1 与冲击后 15 天的累计损失。习题 32.17（160 公畜 $\times$ 12 女儿，8 次重复）：

T	τ	$h_{\ln \text{Var}}^2$	h_{ac1}^2	h_{loss}^2	$r_{\text{ac1}, \phi}$
60	0	0.160	0.087	0.052	0.418
60	1.4	0.094	0.040	0.040	0.223
150	0	0.219	0.135	0.041	0.560
150	0.7	0.211	0.132	0.044	0.478
150	1.4	0.180	0.131	0.044	0.374

三个指标的遗传力都低于潜在的 0.25 (0.04—0.22); $\ln \text{Var}$ 与 ac1 的遗传力随记录长度提高 ($0.160 \rightarrow 0.219$, $0.087 \rightarrow 0.135$), 累计损失几乎不随长度变化 (冲击窗口固定)。噪声使 ac1 被稀释: $\tau = 1.4$ 、 $T = 150$ 时 ac1 均值 0.253 (无噪声 0.569), 与衰减公式 $\text{ac1}_{\text{clean}}(1 - \tau^2 / \text{Var}(r)) = 0.271$ 吻合; 与真实 ϕ 的公畜水平相关由 0.560 降到 0.374。

推导 32.5 状态空间: 把测量噪声与真实恢复分开

$r_t = s_t + v_t$ 的自协方差 $\gamma_0 = \text{Var}(s) + \tau^2$, $\gamma_k = \phi^k \text{Var}(s)$ ($k \geq 1$)。所以朴素 $\text{ac1} = \phi \text{Var}(s) / (\text{Var}(s) + \tau^2)$ 偏低, 而滞后比值 $\gamma_2 / \gamma_1 = \phi$ 与 τ 无关; 卡尔曼滤波的精确似然同时估计 (ϕ, σ^2, τ^2) , 既不偏又有效。习题 32.18 (真值 $\phi = 0.7$ 、 $\sigma = 1$, 40 条曲线, 12 次重复; $\text{Var}(s) = 1.961$):

τ	T	朴素 ac1	理论 ac1	滞后比	滞后比 sd	MLE $\hat{\phi}$	MLE sd	MLE $\hat{\tau}^2$ (真 τ^2)
0	150	0.691	0.700	0.691	0.012	0.712	0.009	0.020 (0)
0.7	150	0.550	0.560	0.694	0.014	0.716	0.014	0.520 (0.49)
1.4	60	0.316	0.350	0.636	0.056	0.698	0.040	1.917 (1.96)
1.4	150	0.339	0.350	0.701	0.021	0.723	0.019	2.019 (1.96)
1.4	400	0.345	0.350	0.691	0.019	0.698	0.012	1.953 (1.96)

$\tau = 1.4$ 时朴素 ac1 只有 0.34 (真值 0.70), 由它推出的恢复半衰期为 $\ln 0.5 / \ln 0.34 = 0.64$ 天 (真值 1.94 天); MLE 的 $\hat{\phi} = 0.723$ 对应 2.14 天 ($T = 150$), $\hat{\tau}^2$ 基本不偏。噪声不分离, 恢复被严重低估, 短序列 ($T = 60$) 下滞后比有小样本偏差 (0.636)。

推导 32.6 排放性状的定义改变选择方向

设 P 、 E 的遗传标准差分别为均值的 12%、8%， $r_g = 0.7$ ，EBV 准确性 $\rho_P = 0.75$ 、 $\rho_E = 0.50$ ，选前 10% ($i = 1.755$)。习题 32.20 (40 万头，单位为相对均值的百分比)：

选择规则	ΔP	ΔE (MC)	理论 $\Delta P/\Delta E$
I1 只选 P	+15.77	+4.88	15.79/4.91
I2 排放强度 (E/P)	+14.33	+2.32	14.35/2.37
I3a 残差 (用遗传回归 $b = 0.467$)	+6.96	-2.38	6.95/-2.34
I3b 残差 (用 EBV 尺 度 $b_R = 0.311$)	+0.05	-5.03	0.00/-5.01
I4 约束指数 ($\Delta E = 0$)	+11.23	-0.06	11.28/0.00

强度选择降低了单位产量的排放但提高了绝对排放 (+2.32%)；遗传残差选择在 P 无响应的前提下降低排放 (-5.03%)，但前提是回归系数用 EBV 尺度的 $b_R = b\rho_E/\rho_P = 0.311$ ——直接套用遗传回归 $b = 0.467$ 时 P 仍有 +6.96% 的响应。残差 EBV 的准确性 (0.559) 介于两个分量 (P 0.749、 E 0.500) 之间，遗传残差标准差 5.71%。约束指数使排放不变而保留 71% 的生产响应 (11.23 对 15.77)。

延伸阅读：抗性、耐受与群体传播

疾病的遗传改良要区分抵抗性 (降低感染)、耐受性 (感染下保持生产) 与传播性 (感染个体感染他人)。传播性使育种值的效应进入群体动力学：个体的遗传价值除了直接作用外还含对群体患病率的间接作用，目标应由传播算子 (next-generation 矩阵) 而不是个体表型的和导出。在评定中，这意味着需要群体层面的传播数据与合适的随机效应结构，仅靠个体表型会严重低估传播性的遗传方差。

常见误区

1. 用单一环境的评定结果代表所有环境。
2. 在设计只覆盖狭窄环境范围时解释斜率。
3. 用“平均最优”冒充“稳健”。
4. 用含测量噪声的自相关直接推断恢复速度。
5. 以为强度 (比值) 选择必然降低绝对排放。
6. 把遗传残差的回归系数从遗传尺度直接套到 EBV 尺度。
7. 忽略环境测量误差对阈值与斜率的衰减。

32.5 习题

一、单项选择题

32.1 ★ [单选] 随机回归反应规范中, 若 $\sigma_b^2 = 0$ (斜率无遗传变异), 则

- (A) 各环境的遗传相关恒为 1 (B) 各环境的遗传相关恒为 0
(C) 不存在遗传变异 (D) 环境方差为零

[答案]

32.2 ★ [单选] 每头公畜的女儿都集中在各自牛场的狭窄环境范围时, 用随机回归估计公畜的斜率

- (A) 非常准确 (B) 信息不足, 极端环境的预测不准 (C) 与设计无关
(D) 总是无偏

[答案]

32.3 ★★ [单选] 目标环境分布不同于训练环境时, 下列做法正确的是

- (A) 仍用与环境无关的总体育种值
(B) 按目标环境分布对反应规范积分得到育种目标
(C) 只选最差环境表现最好的个体 (D) 不需要说明

[答案]

32.4 ★★ [单选] 用含测量误差的日偏离序列直接计算一阶自相关作为恢复速度指标, 会

- (A) 高估恢复速度 (自相关偏高)
(B) 低估自相关, 使恢复看起来更快、持续性被低估
(C) 无影响 (D) 使方差为零

[答案]

32.5 ★★ [单选] 按“排放强度”(排放/产量的比值) 选择, 与按排放总量相比, 其可能的结果是

- (A) 绝对排放一定下降 (B) 强度下降而绝对排放可能上升
(C) 产量必然下降 (D) 二者等价

[答案]

32.6 ★★★ [单选] 遗传残差排放的指数需在 EBV 尺度上使 P 响应为零, 这时回归系数应取

- (A) $b = \sigma_{EP} / \sigma_P^2$ 的遗传值 (B) $\text{Cov}(\text{EBV}_E, \text{EBV}_P) / \text{Var}(\text{EBV}_P)$
(C) 1 (D) 任意 [答案]

二、判断与改错题

32.7 ★ [判断] 当 $\sigma_b^2 > 0$ 时, 距离足够远的两个环境之间的遗传相关可以小于 0。 [答案]

32.8 ★ [判断] 测量误差会使热应激的斜率估计向零衰减。 [答案]

32.9 ★★ [判断] 增加韧性指标的记录天数可以使其遗传力趋近于 1。 [答案]

32.10 ★★ [判断] 对目标环境分布积分的选择, 在任何目标分布下的选择差都不低于忽略 $G \times E$ 的选择。 [答案]

三、填空题

32.11 ★ [填空] $\sigma_a^2 = 1$, $\sigma_b^2 = 0.25$, $\sigma_{ab} = 0$ 。环境 $x = 0$ 与 $x' = 1$ 的遗传相关为 _____ (三位小数)。 [答案]

32.12 ★ [填空] AR(1) 的 $\phi = 0.8$, 恢复半衰期为 _____ 天 (两位小数)。 [答案]

32.13 ★★ [填空] 目标环境均值 $\mu_T = 1.5$, 某公畜 $\hat{a} = 0.8$, $\hat{b} = -0.2$, 积分目标 $\hat{a} + \mu_T \hat{b} =$ _____。 [答案]

32.14 ★★ [填空] $\sigma_P = 12\%$, $\sigma_E = 8\%$, $r_g = 0.7$, E 对 P 的遗传回归系数 $b =$ _____ (三位小数)。 [答案]

四、计算题

?? 32.15 | 4 | 计算 反应规范与设计。比较主效应模型与随机回归在均匀与集中设计下各环境的准确性, 计算跨环境遗传相关。 [程序] [ch32/ex32_15_reaction_norm.py](#)

?? 32.16 | 4 | 计算 目标环境与稳健选择。比较 S1–S4 在三种目标环境下的选择差、理论值与最差环境值。 [程序] [ch32/ex32_16_target_environment.py](#)

?? 32.17 | 4 | 计算 韧性指标的遗传力。计算 $\ln \text{Var}$ 、 ac1 与累计损失的半同胞遗传力, 对记录天数与噪声作表, 并核验噪声衰减公式。 [程序] [ch32/ex32_17_resilience_indicators.py](#)

?? 32.18 | 4 | 计算 状态空间恢复估计。比较朴素自相关、滞后比值与卡尔曼 MLE 对 ϕ 与 τ^2 的估计, 给出恢复半衰期。 [程序] [ch32/ex32_18_state_space_recovery.py](#)

32.19 ★★★ [计算] 热应激折线模型。估计阈值与斜率, 比较折线、错误阈值与线性暴露对个体耐热性及热年损失的预测。 [程序] [ch32/ex32_19_threshold_heat_stress.py](#) [答案]

32.20 ★★★ [计算] 排放选择的四种定义。计算各指数的 ΔP 、 ΔE 与残差 EBV 的准确性, 并比较 b 与 b_R 。 [程序] [ch32/ex32_20_emission_selection.py](#) [答案]

32.21 ★★ [计算] 跨环境遗传相关手算。 $\sigma_a^2 = 1$, $\sigma_b^2 = 0.25$, $\sigma_{ab} = 0$ 。求 $r_g(-1, 1)$ 、 $r_g(-2, 2)$ 与 $r_g(0, 2)$, 并指出 $r_g(-x, x) = 0$ 的 x 。 [答案]

32.22 ★★ [计算] 噪声稀释手算。AR(1): $\phi = 0.7$, $\sigma^2 = 1$, 测量噪声方差 $\tau^2 = 0.49$ 。求 $\text{Var}(s)$ 、朴素 ac1、由朴素 ac1 反推的半衰期与真实半衰期。 [答案]

五、推导与证明题

32.23 ★★ [证明] 证明 $\text{Cov}(g(x), g(x')) = \sigma_a^2 + \sigma_{ab}(x + x') + \sigma_b^2 xx'$; 并证明当 $\sigma_{ab} = 0$ 时 $r_g(-x, x) = (\sigma_a^2 - x^2 \sigma_b^2) / (\sigma_a^2 + x^2 \sigma_b^2)$, $\sigma_b^2 = 0$ 时恒为 1。 [答案]

32.24 ★★★ [证明] 设 $(a, \hat{a})$ 联合正态, $\text{Cov}(a, \hat{a}) = \text{Var}(\hat{a}) = V$ 。证明对线性指数 $I = w' \hat{a}$ 截断选择 (强度 i), 目标 $H = h' a$ 的选择差为 $i w' V h / \sqrt{w' V w}$ 。 [答案]

32.25 ★★★ [证明] 证明 AR(1) 加白噪声的观测序列满足 $\gamma_0 = \text{Var}(s) + \tau^2$, $\gamma_k = \phi^k \text{Var}(s)$ ($k \geq 1$), 从而 $\text{ac1} = \phi \text{Var}(s) / (\text{Var}(s) + \tau^2)$, 且 $\gamma_2 / \gamma_1 = \phi$ 。 [答案]

32.26 ★★★ [证明] 设 $R = \text{Var}(\text{EBV}_P, \text{EBV}_E)$, 指数 $I = w_P \text{EBV}_P + w_E \text{EBV}_E$ 。证明对 P 的选择响应为零当且仅当 $w_P / w_E = -R_{PE} / R_{PP}$; 说明为什么遗传回归 $b = \sigma_{EP} / \sigma_P^2$ 只有在 $\rho_E = \rho_P$ 时才给出零响应。 [答案]

六、综合分析与研究设计题

32.27 ★★ [综合] 为一个热带与温带牧场并存的肉牛育种体系设计 G×E 评定: 环境测量、模型选择、连接设计、目标环境分布与验证。 [答案]

32.28 ★★★ [综合] 奶牛场有每日产奶量与活动传感器数据。设计把这些高频数据转化为“韧性”育种性状的流程：偏离曲线、指标、噪声分离、遗传评定、与生产性状的权衡与验证。 [答案]

32.29 ★★★ [综合] 某国要求 10 年内肉牛的甲烷排放减少，同时不降低生长速度。设计选择方案：性状定义、指数、准确性、监测与风险。 [答案]

32.6 参考答案与解析

一、单项选择题

32.1 (A)。 $\sigma_b^2 = 0$ 时 $g(x) = a$ 对所有环境相同，协方差 σ_a^2 与方差相同， $r_g \equiv 1$ (证明 32.23)。习题 32.15 中 $\sigma_b^2 = 0.30$ 时 $r_g(-2, 2) = -0.093$ 。 [题目]

32.2 (B)。斜率由同一公畜女儿的环境变化估计，环境范围窄则信息少。习题 32.15：设计 B 的随机回归在 $x = \pm 2$ 的准确性为 $0.759/0.687$ ，设计 A 为 $0.898/0.864$ 。 [题目]

32.3 (B)。对目标环境分布积分得到 $H_T = a + \mu_T b$ (推导 32.2)。(C) 是一种特殊的稳健选择，平均选择差下降 (习题 32.16: 1.419 对 1.647)。 [题目]

32.4 (B)。白噪声增大 γ_0 而不影响 γ_k ，ac1 被稀释，持续性 (恢复慢) 被低估，恢复看起来更快。习题 32.18: $\tau = 1.4$ 时朴素 ac1 0.339 (真值 0.70)。 [题目]

32.5 (B)。习题 32.20: 强度选择 $\Delta P = +14.33\%$ 、 $\Delta E = +2.32\%$ ，强度 (E/P) 下降而绝对排放上升。 [题目]

32.6 (B)。对 P 响应为零要求 $\text{Cov}(a_P, I) = 0$ ，即 $w_P R_{PP} + w_E R_{PE} = 0$ (证明 32.26)，系数是 EBV 的协方差之比。习题 32.20: $b_R = 0.311$ ，而 $b = 0.467$ 给出 $+6.96\%$ 的 P 响应。 [题目]

二、判断与改错题

32.7 正确。 $\rho_{ab} = 0$ 时 $r_g(-x, x) = (\sigma_a^2 - x^2 \sigma_b^2) / (\sigma_a^2 + x^2 \sigma_b^2)$ ， $x > \sigma_a / \sigma_b$ 为负。习题 32.15: $r_g(-2, 2) = -0.093$ (重排)。 [题目]

32.8 正确。经典变量误差：暴露含白噪声使回归系数向零衰减。习题 32.19: THI 误差 $\tau_m = 4$ 时平均斜率由 0.350 降到 0.205。 [题目]

32.9 错误。有上限：公畜成分占总变异的比例限制了半同胞遗传力。习题 32.17：无噪声时 $h^2(\ln \text{Var})$ 由 0.160 ($T = 60$) 增到 0.219 ($T = 150$)，仍低于生成模型的 0.25；累计损失的遗传力几乎不随 T 增加。 [题目]

32.10 错误。积分目标只对“其所对应的目标分布”最优。习题 32.16：按 $\mu = -1$ 的方向选择 (S4) 在 $\mu_T = 1$ 时选择差仅 1.014，低于忽略 G×E 的 S1 (1.437)。 [题目]

三、填空题

32.11 $\text{Cov} = \sigma_a^2 = 1$, $\text{Var}(g(0)) = 1$, $\text{Var}(g(1)) = 1 + 0.25 = 1.25$, $r_g = 1/\sqrt{1.25} = 0.894$ 。 [题目]

32.12 $t_{1/2} = \ln 0.5 / \ln 0.8 = -0.6931 / -0.2231 = 3.11$ 天。 [题目]

32.13 $0.8 + 1.5 \times (-0.2) = 0.50$ 。 [题目]

32.14 $b = r_g \sigma_E / \sigma_P = 0.7 \times 0.08 / 0.12 = 0.467$ (P 增加 1%，E 相应增加 0.467%)。 [题目]

四、计算题

32.15 结果见推导 32.1。 $\Sigma = \begin{pmatrix} 1 & -0.110 \\ -0.110 & 0.30 \end{pmatrix}$; $r_g(-2, 2) = -0.093$, $r_g(-1, 1) = 0.546$, $r_g(0, 2) = 0.588$ 。均匀设计下主效应模型的准确性 0.688, 0.832, 0.925, 0.800, 0.566 ($x = -2$ 到 2)，随机回归 0.898, 0.919, 0.931, 0.901, 0.864；集中设计下分别为 0.646, 0.776, 0.857, 0.735, 0.515 与 0.759, 0.833, 0.881, 0.806, 0.687。解读：G×E 越强 (r_g 越低)，主效应模型在极端环境越差；连接设计的环境范围决定能否识别斜率。 [题目]

32.16 结果见推导 32.2。理论与蒙特卡罗吻合：例如 $\mu_T = 1$ 时 S2 的选择差 MC 1.647、理论 1.635；S1 为 1.437/1.431；S4 为 1.014/1.003。maximin 的最差环境值 0.862 高于 S2 的 0.548，平均选择差低 0.228。解读：积分目标最大化平均，maximin 最大化最差；二者的取舍应事先由育种目标与风险偏好决定。 [题目]

32.17 结果见推导 32.4。完整数据 ($h^2(\ln \text{Var})/h^2(\text{ac1})/h^2(\text{loss})$) : $T = 60$: $\tau = 0$ 0.160/0.087/0.052, 0.7 0.147/0.056/0.048, 1.4 0.094/0.040/0.040; $T = 90$: 0.189/0.130/0.062, 0.178/0.113/0.065, 0.143/0.085/0.062; $T = 150$: 0.219/0.135/0.041, 0.211/0.132/0.044, 0.180/0.131/0.044。ac1 与公畜真实 ϕ 的相关 $T = 150$: 0.560, 0.478, 0.374。噪声衰减核验: $\tau = 0.7$ 模拟 0.425、公式 0.447; $\tau = 1.4$ 模拟 0.253、公式 0.271。解读：韧性指标的遗传力低且依赖记录长度与噪

声；总体看对数方差最稳定，累计损失依赖冲击事件的定义。

[题目]

32.18 结果见推导 32.5。滞后比值与 MLE 对 $\phi = 0.7$ 的估计： $T = 150$ 、 $\tau = 1.4$ 为 0.701 与 0.723 (标准差 0.021 与 0.019)； $T = 400$ 时 0.691 与 0.698 (0.019 与 0.012)。MLE 的 $\hat{\tau}^2$: 0.520 (真 0.49)、2.019 (真 1.96)。由 MLE 得到的半衰期 ($T = 150$): $\tau = 0$ 2.04 天, 0.7 2.07 天, 1.4 2.14 天 (真值 1.94 天)。解读：不分离噪声会把半衰期低估为 0.64 天。MLE 在每个设置中标准差都小于滞后比值。

[题目]

32.19 结果见推导 32.3。阈值估计 72.0, 72.2, 71.5 (真值 72)；个体耐热性准确性 (折线 $\hat{T}_0$ / 折线 $T = 66$ / 线性): $\tau_m = 0$ 0.805/0.754/0.683; 2 0.779/0.733/0.664; 4 0.709/0.680/0.617。热年总损失 RMSE (折线/线性): 21.4/65.0、27.3/70.0、42.5/81.0。解读：线性暴露把阈值之下无响应的天数也当作有信息，使耐热性个体差异被稀释；暴露测量误差使一切估计衰减。

[题目]

32.20 结果见推导 32.6。残差排放的 EBV 准确性 0.559, 遗传残差标准差 5.71%; $b = 0.467$, $b_R = 0.311$ ($= b \times 0.667$)。解读：差值型性状的准确性介于分量之间，但选择响应的有效量取决于 EBV 尺度的协方差而不是遗传协方差。约束指数在 $\Delta E = 0$ 下保留 71% 的生产响应。

[题目]

32.21 $r_g(-1, 1) = (1 - 0.25)/(1 + 0.25) = 0.600$ 。 $r_g(-2, 2) = (1 - 1)/(1 + 1) = 0$ 。 $r_g(0, 2)$: 协方差 $\sigma_a^2 = 1$, $\text{Var}(g(0)) = 1$, $\text{Var}(g(2)) = 1 + 4 \times 0.25 = 2$, $r_g = 1/\sqrt{2} = 0.707$ 。 $r_g(-x, x) = 0$ 当 $x = \sigma_a/\sigma_b = 2$ 。解读：当两个环境相对于“环境中心”的距离超过 σ_a/σ_b 时，排序反转。

[题目]

32.22 $\text{Var}(s) = 1/(1 - 0.49) = 1.961$ 。朴素 $\text{ac1} = 0.7 \times 1.961/(1.961 + 0.49) = 0.7 \times 0.8001 = 0.560$ 。由 0.560 反推的半衰期 $\ln 0.5/\ln 0.56 = 1.20$ 天；真实 $\ln 0.5/\ln 0.7 = 1.94$ 天。解读：噪声使恢复时间被低估约 38% (习题 32.18: 理论 ac1 0.560, 模拟 0.550)。

[题目]

五、推导与证明题

32.23 证明。 $g(x) = a + bx$, $\text{Cov}(a + bx, a + bx') = \text{Var}(a) + x' \text{Cov}(a, b) + x \text{Cov}(b, a) + xx' \text{Var}(b) = \sigma_a^2 + \sigma_{ab}(x + x') + \sigma_b^2 xx'$ 。取 $x' = -x$, $\sigma_{ab} = 0$: 协方差 $\sigma_a^2 - x^2 \sigma_b^2$; $\text{Var}(g(\pm x)) = \sigma_a^2 + x^2 \sigma_b^2$ 。故 $r_g(-x, x) = (\sigma_a^2 - x^2 \sigma_b^2)/(\sigma_a^2 + x^2 \sigma_b^2)$ 。 $\sigma_b^2 = 0$ 时分子分母同为 σ_a^2 , $r_g = 1$ 。数值：习题 32.21 的 $x = 2$ 、 $\sigma_a^2 = 1$ 、 $\sigma_b^2 = 0.25$ 给出 0。■

[题目]

32.24 证明。 令 $I = w' \hat{a}$, $\text{Var}(I) = w' V w$ 。联合正态下 $E(H | I) = \frac{\text{Cov}(H, I)}{\text{Var}(I)} I$, $\text{Cov}(H, I) =$

$h' \text{Cov}(a, \hat{a})w = h'Vw$ 。截断选择下 $E(I | \text{选中}) = i\sqrt{w'Vw}$, 所以 $\Delta G = E(H | \text{选中}) = \frac{h'Vw}{w'Vw} i\sqrt{w'Vw} = i \frac{w'Vh}{\sqrt{w'Vw}}$ 。数值 (习题 32.16): $\mu_T = 1$, $w = h = (1, 1)$, $w'Vw = 0.871 - 0.220 + 0.217 = 0.868$, $\Delta G = 1.755 \times 0.868 / \sqrt{0.868} = 1.635$, 与表中理论值一致。■

[题目]

32.25 证明。 s_t 平稳, $\gamma_s(k) = \phi^k \text{Var}(s)$ 。 $r_t = s_t + v_t$, v 为白噪声且与 s 独立, 所以 $\gamma_r(0) = \gamma_s(0) + \tau^2$, $\gamma_r(k) = \gamma_s(k)$ ($k \geq 1$, 噪声项互不相关)。因此 $\text{ac1} = \gamma_r(1)/\gamma_r(0) = \phi \text{Var}(s)/(\text{Var}(s) + \tau^2)$, $\gamma_r(2)/\gamma_r(1) = \phi^2 \text{Var}(s)/(\phi \text{Var}(s)) = \phi$ 。习题 32.22: 0.560 与 0.7。■

[题目]

32.26 证明。 P 的选择响应 $\propto \text{Cov}(a_P, I) = w_P \text{Cov}(a_P, \text{EBV}_P) + w_E \text{Cov}(a_P, \text{EBV}_E)$ 。BLUP 性质给出 $\text{Cov}(a_k, \text{EBV}_l) = R_{kl}$ (对任意 k, l 的预测量), 故响应 $\propto w_P R_{PP} + w_E R_{PE}$ 。令其为零得 $w_P/w_E = -R_{PE}/R_{PP}$ 。取 $w_E = -1$, $w_P = R_{PE}/R_{PP} = b_R$ 。当 $R_{kl} = \rho_k \rho_l G_{kl}$ 时 $b_R = \rho_E \rho_P G_{EP}/(\rho_P^2 G_{PP}) = b \rho_E/\rho_P$, 只有 $\rho_E = \rho_P$ 时 $b_R = b$ 。习题 32.20: $b_R = 0.467 \times 0.5/0.75 = 0.311$ 。■

[题目]

六、综合分析与研究设计题

32.27 方案 (1) **环境测量**: 记录牧场的气象 (THI)、饲料与管理类别; 区分测量、暴露、反应与管理 (推导 32.1—32.3)。(2) **模型**: 以环境梯度上的随机回归 (线性或分段) 作主模型, 并与按区域划分的多性状模型比较; 用习题 32.15 类型的模拟估计在当前设计下的准确性。(3) **连接设计**: 每头公畜的后代必须覆盖热带与温带两端 (习题 32.15: 集中设计在极端环境准确性下降 0.14—0.18); 用共同公畜与参照公畜保证连接。(4) **目标分布**: 由市场与气候预测确定目标环境分布 μ_T, s_T , 计算对环境积分的指数并附 maximin 作为稳健性检验 (习题 32.16)。(5) **验证**: 整家系/整牧场留出 (第 29 章), 在极端环境分别报告准确性与斜率; 报告 r_g 及其不确定性。

[题目]

32.28 流程 (1) **个体曲线**: 用个体预期曲线 (泌乳曲线) 去趋势, 得到日偏离; 记录缺失与传感器故障。(2) **噪声分离**: 用状态空间模型 (习题 32.18) 估计 ϕ 、 σ^2 、 τ^2 , 不能用朴素自相关 (τ 大时 ac1 被稀释到约一半)。(3) **指标**: $\ln \text{Var}$ 、 ϕ (或半衰期)、累计损失; 用冲击事件定义窗口。(4) **遗传评定**: 把指标作为性状, 在动物模型中估计遗传力与遗传相关 (习题 32.17: 遗传力 0.04—0.22, 需要足够多的后代与记录天数)。(5) **权衡**: 与产量、健康性状的遗传相关; 把韧性并入指数时检验是否与高产冲突。(6) **验证**: 在独立牧场、扰动年 (热浪、疾病) 验证, 比较预

测的损失与实际的损失；报告准确性与斜率。

[题目]

- 32.29 方案** (1) **性状**: 定义以绝对排放为约束, 生长速度为目标: 不使用单一的排放强度 (习题 32.20: 强度选择 $\Delta E = +2.32\%$)。 (2) **指数**: 残差排放 (用 EBV 尺度的 b_R) 或约束指数; 前者排放降 5.03%、生产响应 ≈ 0 , 后者保留 71% 的生产响应 (11.23% 对 15.77%)。 (3) **准确性**: 排放的 EBV 准确性 (如 0.5) 限制进展; 用呼吸室/红外传感器扩大记录, 并估计与易测代理 (采食量、瘤胃微生物) 的遗传相关。 (4) **监测**: 每年监测排放的趋势与生长性状的趋势, 检查遗传残差是否因准确性变化而漂移 (回归系数用 EBV 尺度更新)。 (5) **风险**: 排放测量的批次与方法差异、与繁殖健康的负相关、遗传多样性下降; 设定 F 约束并持续评估。

[题目]

深度学习与基因组基础模型

33.1 本章导学

学习目标

1. 判断深度模型何时优于线性（GBLUP/岭回归）：加性性状上岭回归几乎不可超越，非线性与大样本才使神经网络显出优势，并学会用“混合模型”与“残差学习”稳妥地引入非线性。
2. 理解卷积滤波器作为基序检测器的含义，会比较 k-mer、位置信息与卷积模型，并判断序列长度对小样本训练的影响。
3. 掌握基础模型分数的“校准”：先验偏移的对数几率修正、条件分布变化时的重校准，以及 AUC 不随患病率变化而校准会剧变这一事实。
4. 推导两模型最优组合权重与方差公式，理解模型组合的收益来自误差互补而不是模型数量。
5. 掌握分裂共形预测的有限样本覆盖保证，理解协变量偏移下的失效与加权共形的修复，并区分边际覆盖与条件覆盖。
6. 理解“归因不是因果”：在连锁不平衡区块内，模型归因最大的 SNP 为因果位点的概率取决于样本量与相关度。

重点与难点

重点：先验偏移 $\text{logit } p_t = \text{logit } p_s + \ln \frac{\pi_t}{1-\pi_t} - \ln \frac{\pi_s}{1-\pi_s}$ ；两模型最优权重 $w^* = \frac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}$ ；等相关集成方差 $\sigma^2(\rho + (1 - \rho)/M)$ ；分裂共形分位数 $k = \lceil (n + 1)(1 - \alpha) \rceil$ ；岭回归在等相关区块内的系数分配。

难点：深度模型的“准”与“可校准”是两回事；校准依赖部署群体的先验；集成的极限由误差相关决定；边际覆盖不等于条件覆盖；归因的稳定性不等于归因的因果性。

本章承接第 29 章（验证与迁移）、第 30 章（序列与结构变异）与第 31 章（多组学与因果）。前面各章的模型多是线性或核方法；本章讨论更灵活的模型（神经网络、卷积、预训练的基础模型）能带来什么、不能带来什么，以及要把它们用于育种决策时必须补上的校准、区间与可解释性。核心立场是：**模型越灵活，越要用同一套验证协议做对照，并把**

预测的不确定性与适用范围写进结果。

33.2 知识结构图




图 33.1 第 33 章知识结构图

左侧是“模型与序列”，中部是“分数、先验与组合”，右侧是“区间、归因与部署”。

33.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
岭回归等价	$\lambda = m(1 - h^2)/h^2$	GBLUP 的正则化
卷积滤波器	位置 $\times$ 碱基的权重矩阵	逐位置取 argmax 得基序
先验偏移修正	$\text{logit } p_t = \text{logit } p_s + \Delta$	$p(s y)$ 不变
最优二模型权重	$w^* = \frac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}$	权重可为负
集成方差	$\sigma^2(\rho + (1 - \rho)/M)$	等相关误差
共形分位数	$k = \lceil (n + 1)(1 - \alpha) \rceil$	可交换
加权共形	权重 $w(x) = p_t(x)/p_s(x)$	协变量偏移
区块内岭系数	$\hat{\beta}_c = \alpha + \gamma, \hat{\beta}_j = \gamma$	等相关块，总体层面

33.4 补充内容与公式推导

推导 33.1 何时需要神经网络：加性性状、上位性与样本量

对加性性状，岭回归是（几乎）最优的线性无偏预测；神经网络要靠样本去学习一个本来就是线性的函数，因此在小样本下更差。性状含上位性时，加性模型有不可消除的偏差，足够多样本下网络才能超过它。习题 33.15 ($m = 30$ 个 SNP, $h^2 = 0.5$, 4 次重复，上位性由 6 个 SNP 对的乘积项构成；表中为测试集与真实遗传值的相关，“加”“上”分别表示加性与上位性性状)：

n	加岭	加 MLP	加混合	上岭	上 MLP	上混合
250	0.935	0.875	0.906	0.498	0.416	0.465
1000	0.982	0.956	0.970	0.588	0.560	0.560
2000	0.993	0.966	0.981	0.605	0.605	0.586
4000	0.996	0.976	0.985	0.614	0.804	0.683
8000	0.998	0.978	0.990	0.616	0.890	0.891

加性性状上，岭回归在所有 n 都最好 ($n = 8000$ 时 0.998 对 MLP 0.978)；上位性性状上，岭回归在 0.62 处饱和（上位方差岭回归学不到），MLP 在 $n = 2000$ 追平、 $n = 4000$ 起显著超过， $n = 8000$ 达 0.890。“混合”（岭回归的预测加上网络拟合其残差）在加性性状上损失较小（0.990），在上位性性状上最终与 MLP 相当（0.891）。**结论：**先用岭回归作基线；只有当样本量足够大且有非线性证据时，才让网络参与，并用同一验证协议比较。

推导 33.2 卷积滤波器作为基序检测器

序列二值标签由是否含基序 TGACGT 决定（含基序的概率 0.5，标签噪声 0.05，序列长度 $L = 100$ ）。卷积层的每个滤波器是 6×4 的位置 $\times$ 碱基权重矩阵，对序列每个位置打分，经最大池化得到“是否出现”。习题 33.16（4 种模型，测试 AUC，2 次重复）：

n	碱基袋 BAG	位置 POS	6-mer 计数	卷积 CONV
100	0.504	0.497	0.650	0.572
400	0.548	0.497	0.732	0.748
1600	0.562	0.502	0.773	0.831

只用碱基组成 (BAG) 或位置 (POS) 的模型几乎无信息 (≈ 0.5), 因为基序出现在任意位置, 信息在 “相邻碱基的组合” 里。CONV 与 6-mer 计数在小样本相当, $n = 1600$ 时 CONV 更好 (0.831 对 0.773)。最强滤波器逐位置取 argmax 碱基, 得到 TGACGT, 与真实基序完全一致——这就是滤波器可解释的含义, 但它是 “模型学到的统计模式”, 不是因果机制 (见推导 33.6)。序列长度增大使任务变难: $n = 400$ 时 $L = 50, 100, 200$ 的 AUC 为 CONV 0.820, 0.700, 0.679、6-mer 计数 0.788, 0.723, 0.650 (该检验为单独的随机抽样, 数值与上表 $n = 400$ 行有 ± 0.05 的抽样差异)。

推导 33.3 基础模型分数的校准: 先验偏移与条件分布变化

设基础模型给每个变异一维分数 s , 真实标签 $y \in \{0, 1\}$, 且 $s | y \sim N(\mu_y, 1)$ ($\mu_0 = 0$, $\mu_1 = 1.2$)。源数据为已标注的富集集合, $\pi_s = 0.30$; 部署目标为随机变异, $\pi_t = 0.02$ 。源上用 Platt 逻辑回归得 $a = -1.506$, $b = 1.167$ (理论 $b = \mu_1 = 1.2$, $a = -\mu_1^2/2 + \text{logit } \pi_s = -1.567$)。若 $p(s | y)$ 不变, 只需把截距加上 $\Delta = \ln \frac{\pi_t}{1-\pi_t} - \ln \frac{\pi_s}{1-\pi_s} = -3.045$ 。习题 33.17 (目标 20 万个变异, 其中约 4000 个阳性):

方案	ECE	PPV	预测阳	真阳	前 1% 预	前 1% 实
A 直接使用	0.2166	0.089	47245	3921	0.843	0.218
A 先验修正	0.0012	0.500	4082	3921	0.218	0.218
B 直接使用	0.2148	0.055	46967	3998	0.832	0.099
B 先验修正	0.0071	0.250	3997	3998	0.205	0.099
B 重校准	0.0024	0.000	4371	3998	0.089	0.099

AUC 在场景 A 为 0.807 (理论 $\Phi(\mu_1/\sqrt{2}) = 0.802$), 与源 (0.795) 几乎相同: 排序能力不随患病率变化。但直接使用源上的概率, 会把约 4.7 万个变异判为阳性 (真实仅 3921), ECE 0.217; 先验修正后 ECE 降到 0.0012, 预测阳性数 4082 接近真实。若迁移同时改变了条件分布 (μ_1 降到 0.7, AUC 降到 0.686), 仅做先验修正仍在高分端过度自信 (前 1% 预测 0.205, 实际 0.099), 用目标上少量标注 (6000 个, 含约 8 个阳性的岭惩罚重估) 重校准后为 0.089 对 0.099。校准是针对部署群体的性质, 而不是模型的固有性质。

推导 33.4 模型组合的收益来自误差互补

设两个模型的预测误差 e_1, e_2 的标准差为 σ_1, σ_2 、相关为 ρ , 组合 $w\hat{y}_1 + (1-w)\hat{y}_2$ 的误差方差 $V(w) = w^2\sigma_1^2 + (1-w)^2\sigma_2^2 + 2w(1-w)\rho\sigma_1\sigma_2$, 最小化得 $w^* = (\sigma_2^2 -$

$\rho\sigma_1\sigma_2)/(\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2)$, $V^* = \sigma_1^2\sigma_2^2(1 - \rho^2)/(\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2)$ 。习题 33.18 (含加性与上位性的性状, $n_{train} = 3000$, $h^2 = 0.5$, 8 次重复; 三种模型为岭回归 RIDGE、高斯核 RBF、二次多项式核 POLY2; 表中为对真实遗传值的误差):

模型	测试 r	RMSE	误差相关
RIDGE	0.700	0.503	RIDGE-RBF 0.465
RBF	0.907	0.298	RIDGE-POLY2 0.649
POLY2	0.925	0.269	RBF-POLY2 0.884

两两组合	最优权重 (前者)	组合 RMSE	理论 RMSE	较佳单模型
RIDGE+RBF	0.087	0.2950	0.2943	0.2979
RIDGE+POLY2	-0.111	0.2664	0.2656	0.2691
RBF+POLY2	0.078	0.2690	0.2683	0.2691

组合 RMSE 与理论值相差不到 0.001。**最弱模型 (RIDGE) 仍使组合变好**, 因为它的误差与 POLY2 的相关较低 (0.649), 其最优权重为负 (-0.111): 当 $\rho > \sigma_{\min}/\sigma_{\max}$ 时, 较差模型以负权重“抵消”较好模型的共同误差。RBF 与 POLY2 误差高度相关 (0.884), 组合几乎无收益 (0.2690 对 0.2691)。三模型等权集成 (0.3111) 反而比最佳单模型 (0.2691) 更差, 而验证集最优权重给出 0.2665。等相关误差的 M 个模型等权集成方差为 $\sigma^2(\rho + (1 - \rho)/M)$, $\rho = 0.6$ 时 $M = 1, 2, 4, 8, 32$ 的模拟值 0.994, 0.796, 0.695, 0.649, 0.614, 理论 1, 0.8, 0.7, 0.65, 0.6125; $M \rightarrow \infty$ 的极限是 $\rho\sigma^2 = 0.6$, 无限增加相似模型无法消除共同误差。

推导 33.5 共形区间与协变量偏移

分裂共形: 在校准集上计算 $|y_i - \hat{f}(x_i)|$, 取第 $k = \lceil (n+1)(1 - \alpha) \rceil$ 个最小值 q , 区间 $\hat{f}(x) \pm q$ 在可交换假设下的边际覆盖率 $\geq 1 - \alpha$ 。协变量偏移时 $p_t(x) \neq p_s(x)$ 而 $p(y|x)$ 不变, 覆盖率不再有保证; 加权共形用 $w(x) = p_t(x)/p_s(x)$ 对校准残差加权, 并把测试点自己的权重放在 $+\infty$ 处。习题 33.19 ($d = 5$, 源 $N(0, I)$, 目标在 x_1 上平移 1; 真实 $y = x^\top \beta + 0.6x_1^2 + \varepsilon$, 用线性模型预测, 故模型被轻度误设; 30 次重复, $\alpha = 0.1$):

场景	覆盖率	平均区间宽度
源内·分裂共形	0.901	4.149

目标·未加权	0.809	4.149
目标·真实权重	0.901	9.177
目标·估计权重（域分类器）	0.903	9.283

源内覆盖率为 0.901, 目标上未加权降到 0.809; 加权共形恢复到 0.901, 用逻辑回归估计的权重也为 0.903, 代价是区间宽度增加到约 2.2 倍(9.18 对 4.15), 真实权重的有效样本量只有 752 (校准集 2000)。但**边际覆盖不等于条件覆盖**: 目标上按 x_1 五分位的覆盖率, 未加权为 0.930, 0.939, 0.958, 0.881, 0.337, 加权后 0.986, 0.990, 0.994, 0.975, 0.559——最高分位(模型误设最严重、最偏离训练分布)的覆盖率仍只有 0.56。需要对难区间报告条件覆盖, 而不是只报告一个平均数。

推导 33.6 归因不是因果: LD 区块内的岭回归系数

$m = 200$ 个 SNP 分成 20 个区块, 块内等相关 ρ , 每块恰有 1 个因果位点 (效应 ± 1), $h^2 = 0.5$ 。线性模型的“梯度 $\times$ 输入”归因与 $|\hat{\beta}_j|$ 成正比。取块大小 $B = 10$ 、正则化 $\mu = \lambda/n$ ($\lambda = m(1 - h^2)/h^2 = 200$)。在总体层面 (n 很大时的样本协方差等于 Σ), 因果位点 c 的岭系数为 $\alpha + \gamma$, 非因果位点为 γ :

$$\alpha = \frac{(1 - \rho)\beta}{1 - \rho + \mu}, \quad \gamma = \frac{\rho\mu\beta}{(1 - \rho + \mu)(1 - \rho + \mu + \rho B)}.$$

$\rho = 0.95$ 、 $n = 2000$ ($\mu = 0.1$): $\alpha = 0.333\beta$, $\gamma = 0.0656\beta$, 因果位点 0.399β 对非因果 0.066β , 因果位点占块内归因 40.3%。 $\rho \rightarrow 1$ 时 $\alpha \rightarrow 0$ 、 $\gamma \rightarrow \beta/(B + \mu)$, **块内所有 SNP 得到相同的系数——因果与非因果不可区分**。习题 33.20 (每格 12 次重复):

n	ρ	岭 top-1	份额	Lasso	非零数	单点
500	0	0.983	0.373	0.996	3.77	0.933
500	0.8	0.633	0.238	0.642	2.66	0.496
500	0.99	0.217	0.122	0.192	1.95	0.137
2000	0.8	1.000	0.393	1.000	2.44	0.908
2000	0.95	0.679	0.259	0.688	2.56	0.525
2000	0.99	0.325	0.158	0.283	2.82	0.238
8000	0.95	1.000	0.402	0.996	2.29	0.913
8000	0.99	0.658	0.240	0.496	3.66	0.496

块内 argmax 归因等于真实因果位点的概率 (top-1) 随 ρ 增大而下降, 随 n 增大而上升: $\rho = 0.95$ 时 $n = 2000$ 为 0.679, $n = 8000$ 才达 1.000; $\rho = 0.99$ 即使 $n = 8000$ 也只有 0.658。联合模型 (岭、Lasso) 总是不劣于单点回归。注意样本中的因果份额 (0.259) 低于总体值 (0.403): 噪声使非因果系数的绝对值变大。归因给出“模型依靠谁”, 不能回答“干预谁会改变性状”; 只有在 LD 被打破 (精细定位、功能实验) 之后, 归因才可能被解读为因果。

延伸阅读: 基础模型与微调的评价

预训练的序列基础模型提供的是“零样本”分数或表示向量; 用它们做育种预测, 有三种使用方式: 直接用似然差作先验权重 (第 31 章), 把表示向量作为特征放入岭回归, 或在目标数据上微调。评价时要使用与预训练数据无重叠的验证集 (避免信息泄漏), 并与“只用基因型的岭回归”基线、与加入功能注释的线性模型比较。表示向量的维度通常远大于训练样本数, 正则化与整家系留出是必要的。

常见误区

1. 以为更复杂的模型一定更准, 不先与岭回归基线比较。
2. 把神经网络输出的“概率”直接当作校准后的风险。
3. 在富集数据上校准后直接用于随机群体。
4. 用相似模型的等权平均期望大幅降低误差。
5. 把共形区间的边际覆盖率当作每个个体的覆盖率。
6. 把归因最大的 SNP 说成因果 SNP。
7. 在预训练与验证数据重叠时报告准确性。

33.5 习题

一、单项选择题

33.1 ★ [单选] 对一个遗传结构为纯加性的性状, 样本量较小时, 下列预测方法通常最准的是

- (A) 深层神经网络 (B) 岭回归 (GBLUP 等价)
(C) 随机森林 (D) 无需训练的零样本模型

[答案]

33.2 ★ [单选] 卷积神经网络第一层的滤波器在序列任务中最直接的解释是

- (A) 一个位置 $\times$ 碱基的权重矩阵, 相当于基序检测器
 (B) 随机噪声 (C) 样本的主成分
 (D) 个体的亲缘关系

[答案]

33.3 ★★ [单选] 把在富集数据 (患病率 30%) 上校准好的分类器直接用于患病率 2% 的群体, 下列叙述正确的是

- (A) AUC 与校准都不变
 (B) AUC 基本不变, 预测概率系统性偏高
 (C) AUC 变为 0.5 (D) 只需改变分类阈值即可使概率校准

[答案]

33.4 ★★ [单选] 分裂共形预测的覆盖率保证依赖于

- (A) 模型是线性的 (B) 校准集与测试点可交换
 (C) 残差服从正态分布 (D) 样本量趋于无穷

[答案]

33.5 ★★★ [单选] 两个无偏预测的误差标准差为 $\sigma_1 = 0.5$ 、 $\sigma_2 = 0.3$, 相关 $\rho = 0.8$, 最优组合中较差模型 (模型 1) 的权重

- (A) 为正且大于 0.5 (B) 为 0 (C) 为负
 (D) 恰为 0.5

[答案]

33.6 ★★★ [单选] 等相关 (ρ)、等方差的 M 个模型等权平均, 当 $M \rightarrow \infty$ 时误差方差趋于

- (A) 0 (B) σ^2 (C) $\rho\sigma^2$ (D) $(1 - \rho)\sigma^2$

[答案]

二、判断与改错题

33.7 ★ [判断] 神经网络输出层的 softmax 值已经是校准好的概率, 无需再检验。 [答案]

33.8 ★★ [判断] 加权共形预测需要目标群体中的标签 y 来估计权重 $w(x)$ 。 [答案]

33.9 ★★ [判断] 同一个体上几个高度相关的模型，取平均可以把共同误差降到接近零。

[答案]

33.10 ★★ [判断] 一个零样本基础模型的分数的不同患病率的群体上 AUC 相同（假设类条件分布相同）。

[答案]

三、填空题

33.11 ★ [填空] 校准集 $n = 99$, $\alpha = 0.1$, 分裂共形取第 _____ 个最小残差作为区间半宽。

[答案]

33.12 ★★ [填空] 源患病率 0.3、目标患病率 0.02，源上校准概率为 0.8 的变异，在目标上经先验修正后的概率为 _____（三位小数）。

[答案]

33.13 ★★ [填空] $M = 16$ 个模型、误差相关 $\rho = 0.4$ 、 $\sigma^2 = 1$ 的等权集成误差方差为 _____（三位小数）。

[答案]

33.14 ★★ [填空] 类条件分布 $s | y \sim N(\mu_y, 1)$, $\mu_0 = 0$, $\mu_1 = 0.7$ 时分数 s 的 AUC 为 _____（三位小数）。

[答案]

四、计算题

?? 33.15 | 4 | 计算 **何时需要神经网络**。对加性与含上位性的性状，随样本量比较岭回归、MLP 与混合模型的测试相关。[程序] `ch33/ex33_15_mlp_vs_gblup.py`

?? 33.16 | 4 | 计算 **卷积滤波器与基序**。比较碱基袋、位置、k-mer 与卷积模型的 AUC，提取滤波器基序，并检验序列长度的影响。[程序] `ch33/ex33_16_conv_motif.py`

?? 33.17 | 4 | 计算 **基础模型分数的校准**。比较直接使用、先验修正与目标重校准的 ECE、PPV 与预测阳性数。[程序] `ch33/ex33_17_calibration_prior_shift.py`

?? 33.18 | 4 | 计算 **模型组合与误差互补**。计算两两最优权重、组合 RMSE 与理论值，并核验等相关集成方差公式。[程序] `ch33/ex33_18_ensemble_complementarity.py`

33.19 ★★★ [计算] **共形区间与协变量偏移**。比较分裂共形、真实权重与估计权重的加权共形的覆盖率，并报告条件覆盖率。[程序] `ch33/ex33_19_conformal_shift.py` [答案]

33.20 ★★★ [计算] **归因不是因果**。在 LD 区块内比较岭、Lasso 与单点回归的 top-1 概率，及因果位点的归因份额。[程序] `ch33/ex33_20_attribution_ld.py` [答案]

33.21 ★★ [计算] 先验修正手算。源患病率 $\pi_s = 0.30$, 目标 $\pi_t = 0.02$, 源上校准概率分别为 0.5 与 0.9。求目标上修正后的概率与相应的几率比因子。 [答案]

33.22 ★★ [计算] 二模型组合手算。 $\sigma_1 = 0.5$, $\sigma_2 = 0.3$, $\rho = 0.4$ 。求最优权重、组合标准差、与较佳单模型相比的方差降幅, 以及等权组合的标准差。 [答案]

五、推导与证明题

33.23 ★★ [证明] 设 $p(s|y)$ 在源与目标中相同, 先验分别为 π_s, π_t 。证明目标上的后验几率等于源上后验几率乘以 $\frac{\pi_t/(1-\pi_t)}{\pi_s/(1-\pi_s)}$ 。 [答案]

33.24 ★★★ [证明] 设校准残差 $R_1, \dots, R_n$ 与测试残差 R_{n+1} 可交换且无并列。证明区间 $\hat{f}(x) \pm R_{(k)}$ ($k = \lceil (n+1)(1-\alpha) \rceil$) 的覆盖概率 $P(R_{n+1} \leq R_{(k)}) = k/(n+1) \geq 1-\alpha$ 。 [答案]

33.25 ★★★ [证明] 证明两个预测的误差方差 $V(w)$ 在 $w^* = (\sigma_2^2 - \rho\sigma_1\sigma_2)/(\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2)$ 处最小且 $V^* = \sigma_1^2\sigma_2^2(1-\rho^2)/(\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2)$, 并证明 $V^* < \min(\sigma_1^2, \sigma_2^2)$ 当且仅当 $\rho \neq \sigma_{\min}/\sigma_{\max}$ 。

?? 33.26 | 4 | 证明设某区块有 B 个等相关 (ρ) 的标准化 SNP, 只有位点 c 的效应为 β , 总体岭回归系数为 $\hat{\beta} = (\Sigma + \mu I)^{-1} \Sigma \beta$ 。求 $\hat{\beta}_c$ 与 $\hat{\beta}_j$ ($j \neq c$), 并证明 $\rho \rightarrow 1$ 时所有系数相等。 [答案]

六、综合分析与研究设计题

33.27 ★★ [综合] 某育种公司想用卷积神经网络预测启动子区序列对基因表达的影响并用于选种。设计从数据、基线、评价、校准到上线的方案, 指出网络可能不优于现有方法的情形。 [答案]

33.28 ★★★ [综合] 你有一个用公开数据预训练的基础模型和 3000 头本场的基因型与表型。设计使用方案: 比较哪些使用方式、如何避免泄漏、如何评价校准与区间, 并给出何时退回线性模型的决策规则。 [答案]

33.29 ★★★ [综合] 一份报告指出, 某深度模型的“重要特征”恰好落在某已知因果基因附近, 因此“确认了因果”。写出评审意见: 需要哪些额外证据, 如何用 LD 与样本量检验该结论。 [答案]

33.6 参考答案与解析

一、单项选择题

33.1 (B)。加性性状上岭回归几乎是最优线性预测，网络要靠样本去学一个线性函数。

习题 33.15：加性性状 $n = 250$ 时岭回归 0.935、MLP 0.875； $n = 8000$ 时 0.998 对 0.978。 [题目]

33.2 (A)。每个滤波器对序列的每个位置给出匹配度，逐位置取 $\arg\max$ 碱基可得到基序。习题 33.16：最强滤波器恢复了 TGACGT。 [题目]

33.3 (B)。类条件分布不变时 AUC 不变，但后验概率依赖先验。习题 33.17：AUC 0.807 对源 0.795；直接使用预测 47245 个阳性，真实 3921，ECE 0.217。(D) 只改变阈值不能使概率校准。 [题目]

33.4 (B)。保证只需可交换性（证明 33.24），与模型形式、残差分布、样本量无关。习题 33.19：源内覆盖率 0.901；可交换性被协变量偏移破坏时降到 0.809。 [题目]

33.5 (C)。 $\rho = 0.8 > \sigma_2/\sigma_1 = 0.6$ ，故 $w_1^* = (\sigma_2^2 - \rho\sigma_1\sigma_2)/D = (0.09 - 0.12)/(0.25 + 0.09 - 0.24) = -0.30$ ，为负。习题 33.18： $\rho = 0.649 > 0.27/0.50$ 时较差模型权重 -0.111 。 [题目]

33.6 (C)。方差 $\sigma^2(\rho + (1 - \rho)/M) \rightarrow \rho\sigma^2$ 。习题 33.18： $\rho = 0.6$ 时 $M = 32$ 的模拟 0.614，理论 0.6125，极限 0.6。 [题目]

二、判断与改错题

33.7 错误。softmax 只是归一化，不保证校准；神经网络常过度自信。需要在独立数据上检验校准曲线或 ECE，并按部署群体重校准（推导 33.3，ECE 0.217 $\rightarrow$ 0.001）。 [题目]

33.8 错误。只需要源与目标的 x （无标签），用域分类器估计密度比。习题 33.19：估计权重的覆盖率 0.903，真实权重 0.901。需要 $p(y|x)$ 不变这一假设。 [题目]

33.9 错误。相关的误差共同部分不会因平均而消失：极限是 $\rho\sigma^2$ 。习题 33.18：RBF 与 POLY2 的误差相关 0.884，组合 RMSE 0.2690 对单模型 0.2691，几乎无收益。 [题目]

33.10 正确。AUC 只依赖类条件分布， $\Phi(\mu_1/\sqrt{2})$ 与患病率无关。习题 33.17：场景 A 的 AUC 0.807（理论 0.802）；但 PPV 与校准随患病率剧变。 [题目]

三、填空题

33.11 $k = \lceil (n+1)(1-\alpha) \rceil = \lceil 100 \times 0.9 \rceil = 90$ 。保证覆盖率 $\geq 90/100 = 0.90$ 。 [题目]

33.12 源几率 $0.8/0.2 = 4$ ；乘以 $\frac{0.02/0.98}{0.3/0.7} = 0.04762$ 得 0.19048，概率 $0.19048/1.19048 = 0.160$ 。 [题目]

33.13 $\sigma^2(\rho + (1-\rho)/M) = 0.4 + 0.6/16 = 0.438$ (精确值 0.4375)。 [题目]

33.14 $AUC = \Phi(\mu_1/\sqrt{2}) = \Phi(0.495) = 0.690$ ($0.5[1 + \text{erf}(\mu_1/2)] = 0.6897$)。 [题目]

四、计算题

33.15 结果见推导 33.1。加性性状：岭回归在所有 n 最好 (0.935—0.998)，MLP 0.875—0.978，混合 0.906—0.990。上位性性状：岭回归在 0.616 处饱和；MLP 在 $n = 2000$ 追平 (0.605)， $n = 4000$ 为 0.804， $n = 8000$ 为 0.890；混合在 $n = 8000$ 为 0.891。解读：非线性模型的收益需要足够的样本量与非线性信号；在加性性状上多付出的是方差。 [题目]

33.16 结果见推导 33.2。AUC 依次为碱基袋、位置、6-mer、卷积： $n = 100$ 为 0.504、0.497、0.650、0.572； $n = 200$ 为 0.557、0.495、0.694、0.698； $n = 400$ 为 0.548、0.497、0.732、0.748； $n = 800$ 为 0.551、0.493、0.747、0.776； $n = 1600$ 为 0.562、0.502、0.773、0.831。最强滤波器的 argmax 序列：TGACGT。序列长度 $L = 50, 100, 200$ ($n = 400$)：CONV 0.820/0.700/0.679，6-mer 0.788/0.723/0.650。解读：信息在“相邻碱基的联合模式”；卷积在样本充足时优于计数；序列越长，训练越难（噪声位置增多）。 [题目]

33.17 结果见推导 33.3。关键：直接使用 ECE 0.2166、预测阳性 47245 (真实 3921)；先验修正后 ECE 0.0012、预测阳性 4082；条件分布变化时先验修正的 ECE 0.0071、前 1% 预测 0.205 对实际 0.099；目标重校准后前 1% 为 0.089 对 0.099。AUC：A 0.807，B 0.686，源 0.795。解读：先校准先验，再检验高分端是否仍过度自信；条件分布变化时必须使用目标标注。 [题目]

33.18 结果见推导 33.4。三模型 RMSE：RIDGE 0.503、RBF 0.298、POLY2 0.269；误差相关 0.465/0.649/0.884；两两最优权重 0.087, -0.111, 0.078。三模型等权 RMSE 0.3111 (比 POLY2 差)，验证集最优权重 0.2665。等相关集成模拟 0.994/0.796/0.695/0.649/0.614，理论 1/0.8/0.7/0.65/0.6125。解读：组合不是“越多越好”，要用验证集估计权重，并观察误差相关。 [题目]

33.19 结果见推导 33.5。覆盖率依次为源内 0.901、目标未加权 0.809、真实权重 0.901、估计权重 0.903；平均宽度依次为 4.149、4.149、9.177、9.283；ESS 752。按 x_1 五分位的条件覆盖率（目标未加权）0.930, 0.939, 0.958, 0.881, 0.337,（真实权重）0.986, 0.990, 0.994, 0.975, 0.559,（估计权重）0.986, 0.990, 0.994, 0.976, 0.567。解读：加权共形修复边际覆盖，但在最偏离训练分布的区间仍不足；应分层报告覆盖率与区间宽度。 [题目]

33.20 结果见推导 33.6。例： $n = 2000$: $\rho = 0, 0.5, 0.8, 0.95, 0.99$ 的岭 top-1 为 1.000, 1.000, 1.000, 0.679, 0.325; $n = 8000$: 1.000, 1.000, 1.000, 1.000, 0.658; $n = 500$: 0.983, 0.925, 0.633, 0.413, 0.217。单点回归 top-1 ($n = 2000$) : 1.000, 0.996, 0.908, 0.525, 0.238。因果位点的归因份额（岭, $n = 2000$) : 0.578, 0.509, 0.393, 0.259, 0.158。解读：LD 越强、样本越少，归因越不能锁定因果位点；联合模型优于单点，但不能突破 LD 的不可识别性。 [题目]

33.21 几率比因子 $= \frac{0.02/0.98}{0.3/0.7} = \frac{0.020408}{0.428571} = \mathbf{0.04762}$ 。源概率 0.5（几率 1）：目标几率 0.04762，概率 **0.0455**。源概率 0.9（几率 9）：目标几率 0.4286，概率 **0.300**。对数几率位移 -3.045 （习题 33.17）。解读：源上 0.9 的“高置信”变异，在随机群体中只有 30% 的概率为阳性；若直接据此决策，会高估阳性数。 [题目]

33.22 $D = \sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2 = 0.25 + 0.09 - 0.12 = 0.22$ 。 $w^* = (0.09 - 0.06)/0.22 = \mathbf{0.136}$ 。 $V^* = 0.25 \times 0.09 \times (1 - 0.16)/0.22 = 0.0859$ ，标准差 **0.293**（较佳单模型方差 0.09，降幅 4.5%；降幅公式 $1 - V^*/\sigma_2^2$ ）。等权： $(0.25 + 0.09 + 2 \times 0.4 \times 0.15)/4 = 0.115$ ，标准差 **0.339**，比较佳单模型 (0.3) 差。解读：权重估计错误（等权）可使组合劣于单模型。 [题目]

五、推导与证明题

33.23 证明。由贝叶斯公式 $\frac{p(y=1|s)}{p(y=0|s)} = \frac{p(s|1)}{p(s|0)} \cdot \frac{\pi}{1-\pi}$ 。 $p(s|y)$ 不变，所以目标与源的后验几率之比为 $\frac{\pi_t/(1-\pi_t)}{\pi_s/(1-\pi_s)}$ 。取对数即对数几率加位移 Δ 。数值：习题 33.17 的 $\Delta = -3.045$ 。 ■ [题目]

33.24 证明。可交换且无并列时， R_{n+1} 在 $n+1$ 个残差中的秩均匀分布于 $\{1, \dots, n+1\}$ 。事件 $R_{n+1} \leq R_{(k)}$ 等价于 R_{n+1} 在 $n+1$ 个数中的秩 $\leq k$ ，其概率为 $k/(n+1)$ 。由 $k = \lceil (n+1)(1-\alpha) \rceil \geq (n+1)(1-\alpha)$ 得概率 $\geq 1-\alpha$ 。当 $k > n$ 时区间取 ∞ 。数值： $n = 99$ ， $k = 90$ ，覆盖率 0.90。 ■ [题目]

33.25 证明。 $V(w) = w^2\sigma_1^2 + (1-w)^2\sigma_2^2 + 2w(1-w)\rho\sigma_1\sigma_2$ ， $V'(w) = 2w\sigma_1^2 - 2(1-w)$

$w)\sigma_2^2 + 2(1-2w)\rho\sigma_1\sigma_2 = 0$, 得 $w^* = (\sigma_2^2 - \rho\sigma_1\sigma_2)/D$, $D = \sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2$;
 $V'' = 2D > 0$ ($D \geq (\sigma_1 - \sigma_2)^2 \geq 0$), 为最小值。代入得 $V^* = \sigma_1^2\sigma_2^2(1-\rho^2)/D$ 。
 设 $\sigma_2 \leq \sigma_1$ 。 $\sigma_2^2 - V^* = \sigma_2^2(\rho\sigma_1 - \sigma_2)^2/D \geq 0$, 等号当且仅当 $\rho = \sigma_2/\sigma_1$ (此时 $w^* = 0$, 最优组合就是较好模型)。数值: $\sigma_1 = 0.5$ 、 $\sigma_2 = 0.3$ 、 $\rho = 0.4$:
 $\sigma_2^2 - V^* = 0.09 \times (0.2 - 0.3)^2 / 0.22 = 0.0041$, 即 $0.09 - 0.0859$ 。 ■ 【题目】

33.26 证明。 $\Sigma = (1-\rho)I + \rho\mathbf{1}\mathbf{1}'$, $\Sigma\beta = \beta[(1-\rho)e_c + \rho\mathbf{1}]$ 。令 $\hat{\beta} = \alpha e_c + \gamma\mathbf{1}$ 。 $(\Sigma + \mu I)\hat{\beta} = (1-\rho+\mu)(\alpha e_c + \gamma\mathbf{1}) + \rho(\alpha+B\gamma)\mathbf{1}$ 。比较 e_c 的系数: $(1-\rho+\mu)\alpha = (1-\rho)\beta$, 故 $\alpha = \frac{(1-\rho)\beta}{1-\rho+\mu}$ 。比较 $\mathbf{1}$ 的系数: $(1-\rho+\mu)\gamma + \rho(\alpha+B\gamma) = \rho\beta$, 即 $\gamma = \frac{\rho(\beta-\alpha)}{1-\rho+\mu+\rho B}$, $\beta-\alpha = \frac{\mu\beta}{1-\rho+\mu}$, 所以 $\gamma = \frac{\rho\mu\beta}{(1-\rho+\mu)(1-\rho+\mu+\rho B)}$ 。于是 $\hat{\beta}_c = \alpha + \gamma$, $\hat{\beta}_j = \gamma$ 。
 $\rho \rightarrow 1$: $\alpha \rightarrow 0$, $\gamma \rightarrow \beta/(B+\mu)$, 所有系数相等。数值: $B = 10$, $\rho = 0.95$, $\mu = 0.1$:
 $\alpha = 0.3333\beta$, $\gamma = 0.06563\beta$, $\hat{\beta}_c = 0.3990\beta$, 份额 $0.399/(0.399+9 \times 0.0656) = 0.403$
 (已由矩阵求逆核验)。 $\mu \rightarrow 0$ 时 $\gamma \rightarrow 0$ 、 $\alpha \rightarrow \beta$ ($n \rightarrow \infty$ 可识别)。 ■ 【题目】

六、综合分析与研究设计题

33.27 方案 (1) 数据: 启动子区序列与表达的配对数据, 按基因或染色体留出验证集, 避免同源序列泄漏; 记录批次与组织。(2) **基线:** k-mer 计数 (习题 33.16: 小样本时与卷积相当甚至更好)、基序位置权重矩阵与线性模型; 报告基线与网络在同一协议下的准确性。(3) **模型:** 卷积网络, 滤波器数不宜多 (习题 33.16 的 16 个即可), 早停; 序列越长、样本越少, 越难训练 ($L = 200$ 时 AUC 约 0.68)。(4) **评价:** AUC 或相关, 校准曲线, 按基因家族分层; 用滤波器的 argmax 可视化基序, 并与已知转录因子基序库比对, 但声明是统计模式。(5) **上线:** 与线性模型集成 (习题 33.18: 用验证集估权重, 不用等权); 输出共形区间 (习题 33.19), 并监控输入分布偏移。**网络可能不优的情形:** 样本少于约千条、信号以加性为主、序列过长且信号稀疏、标签噪声大。 【题目】

33.28 方案 (1) 使用方式: A. 用基础模型的似然差作为先验权重进入 GBLUP (第 31 章); B. 用其表示向量作为特征放入岭回归; C. 在 3000 头上微调最后几层; D. 只用基因型的岭回归作基线。(2) **泄漏:** 预训练数据与验证集不得含同一序列或同一个体; 按整家系留出 (第 29 章); 超参数只在训练内选择。(3) **评价:** 准确性 (相关与斜率)、校准 (ECE, 按部署群体的先验修正, 习题 33.17)、区间覆盖 (分裂共形; 若部署群体与训练不同则加权, 习题 33.19), 并按家系或祖先分层报告。(4) **组合:** 用验证集估计两模型最优权重 (习题 33.18: w^* 可为负, 等权可劣于单模型)。(5) **决策规则:** 若 B/C 相对基线 D 的准确性提高小于一个标准误, 或校准在部署分层

上明显变差，或区间覆盖不足，则退回线性模型；每次更新模型版本都重新评价。

[题目]

33.29 评审意见 (1) “重要特征落在已知因果基因附近”与“确认因果”之间差一整个 LD 区块：习题 33.20 显示 $\rho = 0.95$ 、 $n = 2000$ 时岭回归 top-1 只有 0.679， $\rho = 0.99$ 时 0.325；即使样本量加到 8000， $\rho = 0.99$ 仍只有 0.658。(2) 需要报告：区块内所有位点的归因与 LD 结构，而不是只报告最大者；归因的稳定性（自助法或不同初始化）；与单点回归、Lasso 的一致性。(3) 需要因果证据：精细定位（多祖先 LD 不同）、功能实验（敲除或碱基编辑）、MR 与多组学（第 31 章）；归因只能作为候选假设。(4) 需要置换检验：把标签打乱后，“最重要特征落在已知基因附近”的概率是多少。(5) 需要声明模型的验证协议，检查是否有序列同源泄漏。结论：该结果可作候选，不足以称为“确认了因果”。

[题目]

第十篇

计算实践与研究设计

怎样把理论转化为可复算的决策。

本篇习题训练：数据字典到可重复评定、教学实验、配种决策与模型诊断。

数据字典到可重复评定

34.1 本章导学

学习目标

1. 能把一个育种评定任务写成可检查的问题：总体、观测单位、性状定义、信息截止日与部署场景，并理解“数据清洗”的每一步都是统计设计的一部分。

2. 掌握身份层、系谱层、事件层、派生层与分型层的审计顺序，会区分阻断性错误与提示性异常，并生成可追溯、与行序无关的分析表。

3. 理解重复记录不等于独立样本，会比较宣称可靠度与实现可靠度，识别因忽略永久环境而造成的过度自信。

4. 会设计跟随部署场景的验证切分，并解释随机个体切分、越过截止日与初筛后评估为什么给出不同的“准确度”。

5. 掌握条件创新与增量更新、删除与纠错的影响函数，以及“桥梁记录”对跨场比较的作用。

6. 会用混合分布传播身份不确定性，并把评定版本的变化对称地归因于资料与参数。

重点与难点

重点：条件创新 $v = z - E(z | D)$ ，更新 $m^+ = m + KS^{-1}v$ 、 $C^+ = C - KS^{-1}K'$ ；秩一删除 $\hat{b}_{-i} - \hat{b} = -Px_i r_i / (1 - h_i)$ ；全方差分解 $\text{Var} = \sum \pi_m C_m + \sum \pi_m (m_m - m)(m_m - m)'$ ；对称归因 $\Delta_D = \frac{1}{2}[\dots] + \frac{1}{2}[\dots]$ 。

难点：规则的先后顺序会改变结果；“重复上传”与“重复测量”不是一回事；创新方差为零的记录不能靠加噪声求逆；影响最大的记录不一定是对目标最重要的记录；版本变化的归因依赖顺序，需要对称化。

本章承接第3章（数据与模型）、第12章（混合模型方程）与第29章（验证）。此前各章默认“分析表”已经正确；本章把视线移到分析表之前：同一份原始记录，经过不同的清洗与连接规则，会得到不同的分析表、不同的EBV与不同的“准确度”。可重复评定的核心是：每一次变换都有规则、有日志、有版本，并能被独立重算。

34.2 知识结构图




图 34.1 第 34 章知识结构图

左侧是“问题、身份与时间”，中部是“重复、系谱与变换”，右侧是“验证、增量与版本”。

34.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
日增重 ADG	$(w_2 - w_1)/(a_2 - a_1)$	日龄差与日期差两条路径须一致
折叠充分统计量	$\tilde{y}_{ij} \sim s_i + q_{ij} + \bar{e}$	方差 $\sigma_q^2 + \sigma_e^2/n$
宣称可靠度	$r^2 = 1 - \text{PEV}/\sigma_s^2$	依赖残差结构正确
条件创新	$v = z - E(z D)$	S 奇异时删除复传
增量方差减少	$\Delta_a = a'KS^{-1}K'a$	目标特异
杠杆量	$h_i = x_i'Px_i$	条件杠杆
秩一删除	$-Px_i r_i / (1 - h_i)$	纠错 δ 为 $Px_i \delta$
全方差分解	$\sum \pi_m C_m + \sum \pi_m d_m d_m'$	身份混合
对称归因	$\Delta_D = \frac{1}{2}(\cdot) + \frac{1}{2}(\cdot)$	避免顺序依赖

34.4 补充内容与公式推导

推导 34.1 数据契约审计：规则的顺序是统计设计的一部分

把登记表、称重事件表与分型样本表变成分析表，要按固定顺序执行五层规则：身份层（主键规范、重复行、同号冲突交由裁决表）、系谱层（亲本存在性、性别角色、亲子年龄间隔）、事件层（事件编号去重、单位统一、信息截止日）、派生层（ADG；阻断性错误与提示性异常分开）、分型层（截止日前可得、检出率合格、一动物多样本取共识）。习题 34.15（信息截止日 2026-06-30）的结果：登记原始行 18、唯一动物 16；称重原始行 21、唯一事件 20、截止日前 19、进入分析 16；分型样本 11，形成共识基因型的动物 6。15 条规则各触发一次，例如：

层	事件	处理
身份	0112 完全重复行；0113 同号 字段冲突	删除副本；依裁决表定为 M
系谱	0110 性别与亲本角色冲突； 0111 亲子年龄间隔不合理	链接置为未知并保留原值待核
事件	E002 重复上传；E004 单位 g； E006 主键 109	保留一个测量事实； 30800 g → 30.8 kg；映射为 0109
派生	0114 增重 -0.303；0115 ADG = 0.520；0116 仅一次称重	阻断送人工复核；保留并提示； ADG 缺失（未到期，不插补）
分型	G05 晚于截止日；G06 检出率 0.879	本次不可用；剔除并保留证据

原始事件数等于进入分析数加各规则排除数（守恒）；ADG 由日龄差与日期差两条路径分别计算必须一致；输入行序打乱 3 次，分析表的 SHA-256 不变（确定性）。朴素连接（不处理一对多）得到 9 行，而正确的分析表为 8 行，多出的是伪重复。

推导 34.2 重复记录不能当作独立样本

$y_{ijk} = \mu + s_i + q_{ij} + e_{ijk}$ ， s_i 为公畜效应（方差 $\sigma_s^2 = 3$ ）， q_{ij} 为子代个体效应（含孟德尔抽样、母亲与永久环境，方差 $\sigma_q^2 = 15$ ）， e_{ijk} 为每次称重的暂时误差（ $\sigma_e^2 = 10$ ）。同一子代的 n 次记录共享 q_{ij} ，所以全记录 MME 等价于对子代均值 $\bar{y}_{ij}$ 建模，其方差为 $\sigma_q^2 + \sigma_e^2/n$ （折叠充分统计量）。错误模型只放公畜效应，把 q 与 e 合成独立残差 $\sigma_w^2 = \sigma_q^2 + \sigma_e^2$ ，于是每增加一次重复记录都被当作新信息。习题 34.16（30 头公畜 × 6 头子代，200 次重复）：

每子代记 录数 n	模型	宣称 PEV	实现 MSE	宣称 r^2	实现 r^2	校准斜率
1	正确 / 错误	1.786	1.794	0.405	0.402	0.996
4	正确	1.530	1.553	0.490	0.482	0.989
4	错误	0.847	1.887	0.718	0.371	0.675
12	正确	1.457	1.426	0.514	0.525	1.011
12	错误	0.401	2.106	0.866	0.298	0.600

$n = 1$ 时两种模型等价 (q 与 e 不可分)。 n 增大后, 错误模型宣称的 r^2 趋向 1 (理论极限 1), 实现的 r^2 反而下降到 0.298, 校准斜率降到 0.60 (过度自信); 正确模型的 r^2 趋向理论极限 0.545。重复记录压低的只是暂时误差 σ_e^2/n , 压不掉共享的 q 。

推导 34.3 验证切分必须跟随部署场景

闭锁肉羊群体: 第 0 代基础群, 第 1–4 代每代 120 只羔羊, 真实育种值 $u_i = \frac{1}{2}u_s + \frac{1}{2}u_d + m_i$, $h^2 = 0.30$; 模型为“世代(固定) + 动物(随机, A^{-1})”。决策时第 0–2 代有表型, 第 3 代为刚出生的候选, 第 4 代尚不存在。习题 34.17 (20 次重复, 均值 $\pm$ 标准误):

场景	$\text{cor}(\hat{u}, u)$	校准斜率
A 部署场景 (前瞻预测第 3 代)	0.469 ± 0.015	1.053 ± 0.036
B 随机个体切分	0.524 ± 0.018	0.979 ± 0.036
C 越过截止日 (用第 4 代)	0.529 ± 0.015	1.051 ± 0.038
D 初筛后候选 (前 30%)	0.199 ± 0.048	0.819 ± 0.195
E 整家系留出	0.424 ± 0.045	0.987 ± 0.109

B 与 C 比部署场景高 0.05—0.06: 随机个体切分让被预测个体的同胞、后代仍在训练集中; C 使用了决策时尚不存在的未来子代。D 因初筛使候选的真实育种值范围缩窄, 相关降到 0.199, 而这是实际的决策范围。同一模型、同一群体, 五个“准确度”回答五个不同问题, 报告时必须声明切分对应的部署场景。

推导 34.4 条件创新与增量更新

状态 $\theta = (u, c)$ (加性育种值与窝效应), 旧资料 D 下 $\theta | D \sim N(m, C)$ 。新批次 z 的创新 $v = z - E(z | D)$ 、 $S = \text{Var}(z | D)$ 、 $K = \text{Cov}(\theta, z | D)$, 则 $m^+ = m + KS^{-1}v$,

$C^+ = C - KS^{-1}K'$, 目标 $a'\theta$ 的误差方差减少 $\Delta_a = a'KS^{-1}K'a$ 。习题 34.18: 复传记录 (E008b 与旧记录共享同一测量误差) 的创新方差为 0 (S 奇异), 应识别并删除, 而不是加噪声求逆; 有效新记录 4 条, $v = (-3.069, -0.441, -0.252, 1.252)$ 。增量更新与全资料一次性重算的最大差为 2.2×10^{-16} , 两种批次顺序结果一致。羔羊 15 的 PEV 由 0.812 降到 0.521 ($\Delta = 0.291$), 羔羊 21、22 几乎无变化 (0.005)。对比 $u_{15} - u_{19}$ 的 PEV 由 1.444 降到 0.971 (减少 0.473), 而两只羔羊各自减少之和为 0.554: **对比的信息增量不是各项增量之和**。在新资料基础上再选 3 个称重, 穷举最优为 M1、M4、M5, 联合价值 0.1730 (单项价值之和 0.1721), 贪心路径 M1→M5→M4 的累计价值 0.0881, 0.172, 0.173, 与穷举一致; 价值取决于条件方向 (针对目标对比) 而不是记录数。

推导 34.5 删除、纠错与桥梁记录的影响函数

公畜模型 ($\sigma_e^2 = 1$ 白化): $y = \text{场 (固定)} + \text{公畜 (随机, 精度 } \lambda = (4 - h^2)/h^2) + e$ 。 $H = J + \sum x_i x_i', P = H^{-1}, h_i = x_i' P x_i$ 。单条删除的秩一恒等式 $\hat{b}_{-i} - \hat{b} = -P x_i r_i / (1 - h_i)$, 纠错 $y_i \rightarrow y_i + \delta$ 为 $\Delta \hat{b} = P x_i \delta$ (无分母)。习题 34.19 (82 条记录, 3 个场, 9 头公畜, $\lambda = 15$; 目标为 $S_7 - S_1 = -0.3716$, PEV 0.1019): 快速删除公式与逐条重解最大差 5.1×10^{-15} 。

记录	场	公畜	残差	杠杆	Δ 目标	总变化范数名次
R071	H3	S7	3.041	0.078	-0.0840	1
R008	H1	S1	1.882	0.063	0.0671	7
R069	H3	S7	-1.918	0.078	0.0530	3
R081	H3	SB	1.500	0.106	0.0501	2

场 3 的桥梁记录 (与其他场共享公畜 SB) 杠杆量 0.106, 高于中位数 0.063。成组删除这两条桥梁记录使目标变化 0.0596 (单条之和 0.0525), PEV 由 0.1019 升到 0.1042; 把 R081 纠正 $\delta = -1.0$ 使目标变化 0.0299、PEV 不变。若公畜作固定效应, H 的秩为 11/12, 删除桥梁记录后降为 10: 场 3 与其公畜整体混杂, $S_7 - S_1$ 不再可估——这是**识别结构的变化**, 不是“影响特别大”。目标特异影响排序与总范数排序的秩相关只有 0.618。

推导 34.6 身份不确定性与版本变化的归因

一条称重记录有 M 种候选身份，条形码给出先验 π_m^0 ，表型按边际似然更新 $\pi_m \propto \pi_m^0 N(y; 0, Z_m A Z_m' \sigma_a^2 + \sigma_e^2 I)$ 。各身份下 $u \sim N(m_m, C_m)$ ，完整后验是混合， $m = \sum \pi_m m_m$ ， $\text{Var} = \sum \pi_m C_m + \sum \pi_m (m_m - m)(m_m - m)'$ 。习题 34.20：条形码先验 (0.8, 0.2)，表型更新后 (0.8822, 0.1178)；目标对比 L09–L10 在两种身份下的估计为 1.275 与 -0.249。完整混合给估计 1.0954，PEV 1.3869（身份内 1.1455 + 身份间 0.2414）；只取最可能身份给 1.2750，PEV 1.1250；只平均 PEV 为 1.1455。4000 次模拟（真实身份按条形码先验抽取）的 90% 区间覆盖率：完整混合 0.903，只取 MAP 身份 0.873，只平均 PEV 0.885；最可能身份判错比例 0.190。版本变化：S1 记录改正为 3.4， σ_e^2 由 1.5 改为 0.8；总变化 $\Delta = m(D_1, \theta_1) - m(D_0, \theta_0)$ ，对称归因 $\Delta_D = \frac{1}{2}[m(D_1, \theta_0) - m(D_0, \theta_0)] + \frac{1}{2}[m(D_1, \theta_1) - m(D_0, \theta_1)]$ 。L09–L10 的总变化 0.657，资料 0.208、参数 0.448（舍入后相差 0.001）；按“先资料后参数”的资料项 $0.176 - (-0.027) = 0.203$ ，按“先参数后资料”为 $0.183 - (-0.031) = 0.214$ ，**两种顺序给出不同的资料归因，对称平均 0.208 才是稳定报告值。**

延伸阅读：数据契约与评定版本

可复用的研究资料至少包含：数据字典（字段、单位、取值范围、缺失编码）、变换日志（规则、触发数、处理方式）、版本标识（资料截止日、模型与参数、软件与随机种子）、分析表的校验和。发布评定结果时，应说明与上一版本相比，变化来自资料更新还是参数更新（对称归因），哪些个体的排名发生了跨越选择线的变化，并给出可重算的最小包。

常见误区

1. 把重复上传当作重复测量并取平均。
2. 把同一子代的多次记录当作独立样本，报告过高的可靠度。
3. 用随机个体切分估计前瞻预测的准确度。
4. 对创新方差为零的复传记录加噪声后继续求逆。
5. 以残差最大的记录作为“对目标最有影响”的记录。
6. 只取最可能身份并忽略身份间方差。
7. 把版本变化只归因于一个因素，或只用一种顺序归因。
8. 自动删除所有“罕见”值而不保留审计日志。

34.5 习题

一、单项选择题

34.1 ★ [单选] 数据契约审计应首先执行的是

- (A) 计算育种值
- (B) 主键规范、重复行与同号冲突的处理
- (C) 报告准确性
- (D) 删除所有异常值

[答案]

34.2 ★ [单选] 称重事件表中同一事件编号出现两次，其他字段完全相同，应

- (A) 取两次的平均
- (B) 保留一个测量事实
- (C) 两次都保留作为重复测量
- (D) 两次都删除

[答案]

34.3 ★★ [单选] 前瞻性部署问题下，随机个体切分的相关系数通常

- (A) 偏低
- (B) 偏高
- (C) 恰好无偏
- (D) 与场景无关

[答案]

34.4 ★★ [单选] 忽略子代永久环境，只用“公畜 + 残差”模型分析多次重复记录，会使

- (A) 宣称可靠度偏低
- (B) 宣称可靠度偏高、实现可靠度较低
- (C) 两者都准
- (D) 估计无偏且更有效

[答案]

34.5 ★★ [单选] 新记录与旧记录共享同一测量误差（复传）时，其条件创新方差为

- (A) 正
- (B) 负
- (C) 零，需识别并删除
- (D) 无穷

[答案]

34.6 ★★★ [单选] 公畜作固定效应时，删除场 3 全部桥梁记录后评定矩阵秩降低，说明

- (A) 这些记录影响特别大
- (B) 场 3 与其公畜整体混杂，跨场对比不可估
- (C) 数据有误
- (D) 没有影响

[答案]

二、判断与改错题

34.7 ★ [判断] 信息截止日之后才到达的分型结果，只要质量合格就应进入本次评定。

[答案]

34.8 ★ [判断] ADG 分别由“日龄差”与“日期差”计算，二者不一致说明存在录入或派生错误。

[答案]

34.9 ★★ [判断] 把评定变化归因于资料或参数时, “先资料后参数” 与 “先参数后资料” 的资料项一定相同。 [答案]

34.10 ★★ [判断] 只取最可能身份来传播身份不确定性, 仍能达到标称的区间覆盖率。

[答案]

三、填空题

34.11 ★ [填空] $\sigma_s^2 = 3$, 宣称 PEV 为 1.2, 宣称可靠度 $r^2 =$ _____ (三位小数)。 [答案]

34.12 ★ [填空] 某羔羊 70 日龄体重 22.0 kg, 100 日龄体重 31.0 kg, ADG 为 _____ kg/d (三位小数)。 [答案]

34.13 ★★ [填空] 复传记录与旧记录共享同一测量误差, 其条件创新方差为 _____。 [答案]

34.14 ★★ [填空] 秩一删除: $h_i = 0.08$, $r_i = 3.0$, $(Px_i)_k = 0.05$, 则 $\Delta \hat{b}_k =$ _____ (三位小数)。 [答案]

四、计算题

?? 34.15 | 4 | 计算 **数据契约审计**。对登记表、称重事件表与分型样本表执行五层规则, 输出审计日志、守恒核验与分析表, 并检验哈希的确定性。 [程序] `ch34/ex34_15_data_contract_audit.py`

?? 34.16 | 4 | 计算 **重复记录的可靠度**。比较正确与错误模型的宣称与实现可靠度和校准斜率, 核验折叠充分统计量。 [程序] `ch34/ex34_16_repeated_records.py`

?? 34.17 | 4 | 计算 **验证切分与部署场景**。比较五种切分的相关与校准斜率。 [程序] `ch34/ex34_17_validation_design.py`

?? 34.18 | 4 | 计算 **条件创新与增量更新**。识别复传, 验证增量更新与全资料重算一致, 并选择测定设计。 [程序] `ch34/ex34_18_innovation_update.py`

34.19 ★★★ [计算] **影响函数与桥梁记录**。核验快速删除公式, 比较单条与成组删除, 并讨论固定效应时的识别。 [程序] `ch34/ex34_19_influence_deletion.py` [答案]

34.20 ★★★ [计算] **身份混合与版本归因**。比较完整混合、MAP 与只平均 PEV 的覆盖率, 并做对称归因。 [程序] `ch34/ex34_20_identity_version.py` [答案]

34.21 ★★ [计算] 条件创新手算。 $u = (u_1, u_2)' \sim N(0, A)$, $A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$ ($\sigma_a^2 = 1$), 只观测 $z = u_1 + e$, $\sigma_e^2 = 1$, $z = 1.2$ 。求 m^+ 、 C^+ , 以及目标 $u_2 - u_1$ 的 PEV 变化。 [答案]

34.22 ★★ [计算] 身份混合手算。 两种身份, $\pi = (0.6, 0.4)$, 条件均值 $m_1 = (1, 0)'$, $m_2 = (0, 1)'$, 条件协方差都为 I 。求混合均值、混合协方差, 以及目标 $u_1 - u_2$ 的方差 (身份内与身份间分开)。 [答案]

五、推导与证明题

34.23 ★★ [证明] 证明: 同一子代的 n 次记录 $y_k = s + q + e_k$ 中, 均值 $\bar{y}$ 是 (s, q) 的充分统计量, 且 $\text{Var}(\bar{y} | s, q) = \sigma_e^2/n$, 因而折叠模型的残差为 $\sigma_q^2 + \sigma_e^2/n$ 。 [答案]

34.24 ★★★ [证明] 证明秩一删除公式: $\hat{b}_{-i} - \hat{b} = -Px_i r_i / (1 - h_i)$, 其中 $P = H^{-1}$, $h_i = x_i' P x_i$, $r_i = y_i - x_i' \hat{b}$ 。 [答案]

34.25 ★★★ [证明] 证明混合分布的全方差分解: $\text{Var} = \sum \pi_m C_m + \sum \pi_m (m_m - m)(m_m - m)'$, 并说明只平均 PEV 为什么低估不确定性。 [答案]

34.26 ★★★ [证明] 设 $\theta | D \sim N(m, C)$, $z = H\theta + \varepsilon$ 。证明分两批依次条件化与一次性条件化的结果相同, 并说明 S 奇异时的处理。 [答案]

六、综合分析与研究设计题

34.27 ★★ [综合] 某羊场准备首次建立评定数据库: 登记表、称重表与分型表来自三个系统。设计数据契约与审计流程, 指出哪些规则必须在统计模型之前固定, 并给出可重复性核验清单。 [答案]

34.28 ★★★ [综合] 评审意见: 某论文用随机个体切分报告基因组预测准确度 0.52, 并声称可用于“选择当年出生的候选”。写出评审意见, 并设计一个与部署场景一致的验证方案。 [答案]

34.29 ★★★ [综合] 某年度评定版本更新后, 一些公畜的排名跨过了留种线。设计一份发布说明: 如何区分资料变化与参数变化, 如何处理身份不确定的记录, 以及用户需要得到的可重算材料。 [答案]

34.6 参考答案与解析

一、单项选择题

34.1 (B)。身份层先行：主键规范、重复行与同号冲突，之后才有系谱、事件、派生与分型（推导 34.1）。习题 34.15：朴素连接得到 9 行，正确分析表 8 行，多出的是伪重复。 [题目]

34.2 (B)。重复上传不等于重复测量。习题 34.15：事件 E002 重复上传，保留一个测量事实；原始称重 21 行、唯一事件 20。 [题目]

34.3 (B)。随机切分使同胞与后代仍在训练集中，回答的是更容易的问题。习题 34.17：随机切分 0.524、部署场景 0.469。 [题目]

34.4 (B)。永久环境被当作每次独立的残差，重复越多宣称越高。习题 34.16： $n = 12$ 时宣称 $r^2 = 0.866$ ，实现 0.298，校准斜率 0.600。 [题目]

34.5 (C)。复传记录没有新的测量误差信息， S 奇异，应识别并删除。习题 34.18：E008b 的创新方差为 0。 [题目]

34.6 (B)。习题 34.19： H 的秩由 11/12 降到 10，场 3 与其公畜整体混杂， $S_7 - S_1$ 不可估；这是识别问题，不是影响大小问题。 [题目]

二、判断与改错题

34.7 错误。晚于信息截止日的数据属于未来信息，进入本次评定会破坏评定的可重复性与验证的前瞻性。习题 34.15：G05 晚于截止日，“本次不可用”，保留于原始层。 [题目]

34.8 正确。两条路径是独立核验，不一致说明日期或日龄录入有误。习题 34.15：0114 增重为负（-0.303）被阻断并送人工复核。 [题目]

34.9 错误。顺序不同，资料项不同，需要对称平均。习题 34.20：L09-L10 的资料项为 $0.176 - (-0.027) = 0.203$ （先资料后参数）与 $0.183 - (-0.031) = 0.214$ （先参数后资料），对称值 0.208。 [题目]

34.10 错误。只取 MAP 身份忽略身份间方差，且身份判错比例 0.190。习题 34.20：覆盖率 0.873（完整混合 0.903）。 [题目]

三、填空题

34.11 $r^2 = 1 - 1.2/3 = 0.600$ 。 [题目]

34.12 $(31.0 - 22.0)/(100 - 70) = 9/30 = 0.300 \text{ kg/d}$ 。 [题目]

34.13 0。新记录与旧记录共享同一测量误差，条件在旧记录上后无新增随机性（S 奇异）。
习题 34.18：创新方差 0.00。 [题目]

34.14 $\Delta \hat{b}_k = -0.05 \times 3.0/(1 - 0.08) = -0.15/0.92 = -0.163$ 。 [题目]

四、计算题

34.15 结果见推导 34.1。守恒：登记 18 行（唯一动物 16）、称重 21 行（唯一事件 20、截止日前 19、进入分析 16）、分型样本 11（形成共识基因型的动物 6）；15 条规则各触发 1 次；分析表 8 行，SHA-256 前缀 1850ecf8f50b1fb6，行序打乱 3 次不变。解读：规则的顺序、阻断与提示的区分、审计日志与哈希，构成可追溯的最小集合。

[题目]

34.16 结果见推导 34.2。 $n = 1, 4, 12$ 时正确模型的宣称/实现 r^2 : 0.405/0.402、0.490/0.482、0.514/0.525；错误模型：0.405/0.402、0.718/0.371、0.866/0.298；校准斜率（错误）0.996, 0.675, 0.600。理论极限：正确模型 $r^2 \rightarrow 0.545$ ，错误模型 $\rightarrow 1$ 。解读：重复只能压低暂时误差，永久环境被忽略时可靠度虚高。

[题目]

34.17 结果见推导 34.3。 $\text{cor}(\hat{u}, u)$: A 0.469, B 0.524, C 0.529, D 0.199, E 0.424；校准斜率 1.053, 0.979, 1.051, 0.819, 0.987。解读：B、C 回答更容易的问题；D 范围缩窄；E 比 A 略低，因为整家系留出去掉了亲属信息。

[题目]

34.18 结果见推导 34.4。有效新记录 4 条，复传 E008b 创新方差 0；增量更新与全资料重算最大差 2.2×10^{-16} ； $u_{15} - u_{19}$ 的 PEV $1.444 \rightarrow 0.971$ （减少 0.473，单项之和 0.554）；测定设计最优 M1+M4+M5，价值 0.1730。解读：信息价值依赖目标方向与已有资料，而不是记录数。

[题目]

34.19 结果见推导 34.5。快速公式与重解最大差 5.1×10^{-15} ；影响最大记录 R071 ($\Delta = -0.0840$)；成组删除桥梁记录目标变化 0.0596（单条和 0.0525），PEV $0.1019 \rightarrow 0.1042$ ；纠错 $\delta = -1.0$ 使目标变化 0.0299；固定效应下秩 $11/12 \rightarrow 10$ ；目标特异影响与总范数排序秩相关 0.618。

[题目]

34.20 结果见推导 34.6。后验身份概率 (0.8822, 0.1178)；完整混合估计 1.0954, PEV 1.3869（身份内 1.1455，身份间 0.2414）；覆盖率：完整混合 0.903、MAP 0.873、只平均

PEV 0.885; MSE 1.2635 对 1.3093。版本归因: 总变化 0.657, 资料 0.208, 参数 0.448。手算例: 混合协方差 13/16, -3/16, 17/16; 预测 0.50 → 2.00 的总变化 1.50, 资料与参数各 0.75。 [题目]

34.21 $S = \text{Var}(z) = 1 + 1 = 2$, $K = A(1, 0)' = (1, 0.5)'$, $v = 1.2$ 。 $m^+ = Kv/S = (0.6, 0.3)'$ 。
 $C^+ = A - KK'/S = \begin{pmatrix} 0.5 & 0.25 \\ 0.25 & 0.875 \end{pmatrix}$ 。目标 $a = (-1, 1)'$: 先验方差 $1 + 1 - 2 \times 0.5 = 1$; $\Delta_a = (a'K)^2/S = (-1 + 0.5)^2/2 = 0.125$, 后验方差 **0.875** (也等于 $0.5 + 0.875 - 2 \times 0.25$)。
 解读: 只观测 u_1 的记录, 对 $u_2 - u_1$ 也提供信息, 但只有 12.5%。 [题目]

34.22 混合均值 $= 0.6(1, 0) + 0.4(0, 1) = (0.6, 0.4)'$ 。身份间部分: $m_1 - m = (0.4, -0.4)'$,
 $m_2 - m = (-0.6, 0.6)'$, 两项加权后为 $0.24 \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$ 。混合协方差 $= I + 0.24 \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} 1.24 & -0.24 \\ -0.24 & 1.24 \end{pmatrix}$ 。目标 $a = (1, -1)'$: 总方差 $1.24 + 1.24 + 2 \times 0.24 = 2.96$, 身份内 2, 身份间 **0.96**。解读: 只平均 PEV 只得 2, 低估了 32%。 [题目]

五、推导与证明题

34.23 证明。 $y_k | (s, q) \sim N(\mu + s + q, \sigma_e^2)$ 独立。似然 $\prod_k \exp[-(y_k - \mu - s - q)^2/2\sigma_e^2]$ 对 (s, q) 只通过 $\sum_k (y_k - \mu - s - q)^2 = \sum_k (y_k - \bar{y})^2 + n(\bar{y} - \mu - s - q)^2$ 依赖, 其中第一项与 (s, q) 无关, 故 $\bar{y}$ 是充分统计量; $\text{Var}(\bar{y} | s, q) = \sigma_e^2/n$ 。边缘上 $\bar{y} = \mu + s + q + \bar{e}$, $q + \bar{e}$ 的方差为 $\sigma_q^2 + \sigma_e^2/n$ 。数值: $\sigma_q^2 = 15$, $\sigma_e^2 = 10$, $n = 12$ 时 15.83, 而错误模型认为 $25/12 = 2.08$ (独立); 比率 7.6 倍即习题 34.16 过度自信的来源。 ■ [题目]

34.24 证明。 删除第 i 条后 $H_{-i} = H - x_i x_i'$, $q_{-i} = q - x_i y_i$ 。由 Sherman-Morrison, $H_{-i}^{-1} = P + \frac{Px_i x_i' P}{1 - h_i}$ 。于是 $\hat{b}_{-i} = H_{-i}^{-1}(q - x_i y_i) = \hat{b} - Px_i y_i + \frac{Px_i(x_i' \hat{b} - h_i y_i)}{1 - h_i}$ 。合并同类项: $-Px_i y_i \frac{(1 - h_i) + h_i}{1 - h_i} + \frac{Px_i x_i' \hat{b}}{1 - h_i} = -\frac{Px_i(y_i - x_i' \hat{b})}{1 - h_i}$ 。数值: $h = 0.08$, $r = 3.0$, $(Px)_k = 0.05$: -0.163 (习题 34.14)。纠错 $y_i \rightarrow y_i + \delta$ 时 H 不变, $\Delta \hat{b} = Px_i \delta$ 。 ■

[题目]

34.25 证明。 设身份 M 的后验概率为 π_m , $E[u | M = m] = m_m$, $\text{Var}(u | M = m) = C_m$ 。全期望 $m = \sum \pi_m m_m$ 。全方差: $\text{Var}(u) = E[\text{Var}(u | M)] + \text{Var}(E[u | M]) = \sum \pi_m C_m + \sum \pi_m (m_m - m)(m_m - m)'$ 。只平均 PEV 只含第一项, 漏掉身份间的第二项 (半正定), 故低估。数值: 习题 34.22, 身份内 2, 身份间 0.96; 习题 34.20: 1.1455 对总 1.3869。 ■

[题目]

34.26 证明。 一次性条件化 $z = (z_1, z_2)$: 后验由 $p(\theta | D)p(z_1, z_2 | \theta)$ 决定。若 $\varepsilon_1, \varepsilon_2$ 独立 (或联合已知), 则 $p(z_1, z_2 | \theta) = p(z_1 | \theta)p(z_2 | z_1, \theta)$, 先以 z_1 更新得 $p(\theta | D, z_1)$,

再以 z_2 更新, 结果与一次性的相同, 且交换 1、2 的顺序也相同 (乘积可交换)。S 奇异表示 z 的某个线性组合在 D 下已确定, 无新息, 应取 S 的非零特征子空间 (或删除复传分量), 用伪逆 S^+ 或直接删除, 而不是加噪声。数值: 习题 34.18: 更新与全资料重算最大差 2.2×10^{-16} 。■

[题目]

六、综合分析与研究设计题

34.27 方案 (1) **数据字典**: 字段、单位、取值范围、缺失编码、主键格式; 三个系统的主键映射由裁决表给出。(2) **固定在模型之前的规则**: 身份规范与同号冲突的裁决; 亲子年龄间隔与性别角色检查; 事件编号去重与单位统一; 信息截止日; 阻断与提示的分级; 一动物多样本的共识规则 (如检出率最高者)。顺序写入契约并版本化 (推导 34.1)。(3) **审计日志**: 每条规则的触发数、涉及个体与处理; 守恒核验 (原始事件数 = 进入分析 + 各规则排除数)。(4) **可重复核验清单**: ADG 双路径一致; 行序打乱后分析表哈希不变 (习题 34.15); 朴素连接对照 (伪重复行数); 晚于截止日数据不入本期; 随机种子与软件版本记录; 最小可重算包 (数据字典、契约、分析表、脚本)。(5) **报告**: 阻断个体的处理状态、提示异常的保留清单、未到期记录标记为缺失而不插补。

[题目]

34.28 评审意见 (1) 随机个体切分的被预测个体的同胞与后代仍在训练集中, 回答的是“有亲属信息时的内插”, 与“预测当年出生的候选”不是同一问题 (习题 34.17: 随机切分 0.524, 前瞻部署 0.469, 初筛后候选 0.199)。(2) 不能声称 0.52 对应选择当年候选; 需要在决策时刻的信息截止日下, 只用此前的表型与系谱, 预测后出生的个体。(3) **验证方案**: 按出生年份或世代前瞻切分, 训练集止于截止日, 验证集为之后出生个体, 评价指标为相关与校准斜率并报告标准误; 增加整家系留出评估新家系; 在实际被选择的前 30% 范围内再报告 (范围缩窄); 与仅用系谱的基线比较。(4) 说明不能使用越过截止日的信息 (习题 34.17 C 场景)。

[题目]

34.29 发布说明 (1) **版本标识**: 资料截止日、记录数、模型与参数 (σ_a^2 、 σ_e^2 等)、软件版本与种子。(2) **变化归因**: 对每个跨线个体报告总变化 Δ , 及资料项与参数项的对称归因 (习题 34.20: 总变化 0.657, 资料 0.208、参数 0.448; 先后顺序给出 0.203 与 0.214, 故必须对称)。(3) **身份不确定的记录**: 报告后验身份概率, 用完整混合传播不确定性, 而非只取最可能身份 (习题 34.20: 覆盖率 0.903 对 0.873); 报告 PEV 的身份内与身份间两部分。(4) **纠错与删除**: 对被纠正或删除的记录给出对目标的影响 (影响函数, 习题 34.19), 特别说明桥梁记录; 若固定效应下识别结构改变, 要明示“不可估”。(5) **可重算材料**: 数据契约、分析表校验和、脚本与最

小数据包，让用户能独立重算跨线个体的排名。

【题目】

从系谱 BLUP 到 GBLUP：一个可复算的肉羊教学实验

35.1 本章导学

学习目标

1. 理解“已知真值的世界”的价值与边界：模拟可以检验预测方法，却不能自动代表真实群体。
2. 会用表格法构造系谱关系矩阵 A 、用 VanRaden 方法构造 G ，理解 $E(G) = A$ 的含义，并用协方差形式与混合模型方程两条路径核验同一个 BLUP。
3. 掌握相关、RMSE、校准斜率与截距、预测区间覆盖率这组指标，会用预定种子与成对差报告重复实验。
4. 会区分信息损失（标记变少）、模型错设（方差比）与数据错误（身份错配），并读出它们各自的症状。
5. 理解初筛导致的范围缩窄使相关下降，但不等于模型变差，并会用选择增益与神谕比较评价尾部损失。
6. 会用预测误差协方差比较个体与组合，知道区间重叠法为何过于保守。

重点与难点

重点：协方差形式的 BLUP $\hat{u}_c = \sigma_a^2 K_{ct} V^{-1} (y - \hat{\mu} \mathbf{1})$ ；差值误差方差 $PEV_i + PEV_j - 2PEC_{ij}$ ；方差比错设下的收缩系数 $c = n\sigma_a^2 / (n\sigma_a^2 + f\sigma_e^2)$ ；错配比例 φ 下 $r(\varphi) \approx (1 - \varphi)r(0)$ 。

难点：模拟中的相关系数不是现实中的准确度；平均截距为零不排除单次群体的偏移；排序不变不等于幅度与不确定性不变；亚群分层应预先规定，不能事后搜索。

本章承接第 12 章（混合模型方程）、第 16 章（基因组关系矩阵）与第 34 章（可重复评定）。第 34 章讨论分析表怎样来；本章在一个“已知真值”的小世界里，用同一套训练资料、同一套方差尺度，比较系谱与标记两种关系信息，并检验当标记变少、方差比错设、身份错配、初筛改变范围时预测怎样变化。**本章的所有数值都由配套程序在固定种子下复算，它们是教学基准，不是生产性能。**

35.2 知识结构图




图 35.1 第 35 章知识结构图

左侧是“真值世界与关系矩阵”，中部是“小例子与重复实验”，右侧是“扰动、初筛与个体比较”。

35.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
系谱 BLUP	$K = A$	表格法，奠基个体无亲缘
GBLUP	$K = G = WW' / \sum 2p_j q_j$	已知基础频率时 $E(G) = A$
方差比	$\lambda = \sigma_e^2 / \sigma_a^2$	错设改变幅度
PEV 与可靠度	$r^2 = 1 - \text{PEV} / \sigma_a^2$	含均值估计的不确定性
差值误差方差	$\text{PEV}_i + \text{PEV}_j - 2\text{PEC}_{ij}$	共享训练资料使误差相关
校准斜率	$b(u \hat{u})$	< 1 过度分散, > 1 过度收缩
错配与相关	$r(\varphi) \approx (1 - \varphi)r_0$	错配个体预测与真值无关
亲子检查	$d_i = \frac{1}{2}(G_{is} + G_{id})$	期望 0.5, 低于 0.25 可疑

35.4 补充内容与公式推导

推导 35.1 协方差形式的 BLUP 与 GBLUP 对系谱 BLUP 的配对比较

协方差形式： $V = \sigma_a^2 K_{tt} + \sigma_e^2 I$, $\hat{\mu} = \mathbf{1}' V^{-1} \mathbf{y} / \mathbf{1}' V^{-1} \mathbf{1}$, $\hat{u}_c = \sigma_a^2 K_{ct} V^{-1} (\mathbf{y} - \hat{\mu} \mathbf{1})$, PEV 矩阵为 $\sigma_a^2 K_{cc} - \sigma_a^4 K_{ct} V^{-1} K_{tc} + t t' / \mathbf{1}' V^{-1} \mathbf{1}$, 其中 $t = \mathbf{1} - \sigma_a^2 K_{ct} V^{-1} \mathbf{1}$ 来自均值估计的不确定性。习题 35.15: 基础代 20 公 + 100 母有表型, 随机交配得 160 只子代, 其中 80 只进入训练, 另 80 只为候选; $m = 240$ 个位点全部分型, $h^2 = 0.5$, 30 次重复, 同一重复内两模型共用资料:

指标	系谱 BLUP	GBLUP
验证相关	0.538 ± 0.100	0.687 ± 0.076
RMSE	0.832 ± 0.067	0.716 ± 0.069
校准斜率	0.993 ± 0.195	0.973 ± 0.147
校准截距	-0.015 ± 0.136	0.005 ± 0.104
90% 覆盖率	0.903 ± 0.030	0.905 ± 0.036

成对相关差 (G-A) 均值 0.149, 蒙特卡洛标准误 0.011, 30 次中 G 全部更高; RMSE 降低 0.116 (标准误 0.008)。平均 PEV 与实际 MSE 之比: A 1.057, G 1.058。协方差形式与 Henderson 混合模型方程 (A 版) 的最大差为 1.0×10^{-15} 。**GBLUP 的优势来自候选羔羊的实际遗传抽样 (孟德尔抽样), 而不是凭空创造预测; 表中 “±” 为 30 次重复之间的标准差, 不是均值的置信区间。**

推导 35.2 可观测标记减少: 信息损失与模型错误

真实育种值始终由全部 240 个位点生成, GBLUP 只用随机抽取的 m_{obs} 个位点构造 G (按这些位点的 $\sum 2pq$ 标准化)。“关系精度” 为候选-训练关系的 $G_{m_{obs}}$ 与全位点 G 的相关。习题 35.16 (系谱 BLUP 相关 0.529, RMSE 0.833; 混合为 $0.5A + 0.5G$):

m_{obs}	GBLUP 相关	RMSE	斜率	关系精度	混合相关
15	0.236	0.980	0.548	0.337	0.507
30	0.282	0.995	0.469	0.465	0.493
60	0.459	0.912	0.646	0.626	0.566
120	0.572	0.820	0.774	0.810	0.616
240	0.682	0.716	0.969	1.000	0.653

少量标记的 G 对实际关系的恢复很差 (15 个位点关系精度仅 0.337), GBLUP 的相关 (0.236) 比系谱 BLUP (0.529) 还低一半以上, 且斜率仅 0.55 (过度分散): 把噪声当作关系放大。把 A 与 G 等权混合可挽回大部分损失 (0.507, 接近系谱 BLUP)。密度增加到 $m_{obs} = 120$ 才超过系谱 BLUP (0.572 对 0.529)。少标记的失败属于信息损失, 不应与 “GBLUP 方法本身不好” 混为一谈; 也不应在不报告密度的情况下给出一个笼统的结论。

推导 35.3 方差比错误: 排序稳健, 幅度与不确定性失真

真实 $\sigma_e^2/\sigma_a^2 = 1$; 拟合时取 $\sigma_e^{2'} = f\sigma_e^2$ 。单个体 n 条独立记录的 EBV 为 $c\bar{y}$, $c = n\sigma_a^2/(n\sigma_a^2 + f\sigma_e^2)$, $f > 1$ 时过度收缩。习题 35.17 (GBLUP, 30 次重复):

f	相关	RMSE	斜率	覆盖率	EBV 标准差	与 $f = 1$ 排序相关
0.1	0.606	1.016	0.477	0.572	1.232	0.887
0.25	0.653	0.832	0.627	0.740	1.012	0.958
1	0.683	0.710	0.973	0.909	0.682	1.000
4	0.670	0.780	1.843	0.937	0.355	0.974
10	0.656	0.861	3.388	0.931	0.189	0.952

在 $f \in [0.5, 2]$ 内相关变化不到 0.03; 但斜率由 0.48 单调增加到 3.39, 覆盖率在 $f = 0.1$ 时只有 0.572 (过度自信), 在 $f \geq 2$ 时偏保守 (0.93 以上); 系谱 BLUP 有相同趋势 (斜率 0.575 $\rightarrow$ 3.982)。f=0.25 与 f=4 的 EBV 排序相关 0.903 (单次示例)。只看相关会完全看不出方差比错误; 校准斜率与覆盖率才是诊断量。

推导 35.4 身份错配: 合法矩阵, 错误预测

在 80 只候选中随机选 k 只, 把它们的基因型循环错位 (系谱与表型不变, G 仍为合法半正定矩阵)。错配个体的预测与真值无关, 其余不变, 所以 $r(k) \approx (1 - k/n)r_0$ 。亲子检查: $d_i = \frac{1}{2}(G_{is} + G_{id})$ 的期望为 0.5, 低于 0.25 标记为可疑。习题 35.18 (30 次重复):

错配数 k	GBLUP 相关	理论	灵敏度	假阳性率	标记后改用 A 的相关
0	0.685	0.685	—	0.000	0.685
8	0.622	0.616	0.963	0.000	0.667
16	0.520	0.548	0.963	0.000	0.649
40	0.352	0.342	0.968	0.000	0.606

80 -0.024 0.000 0.971 — 0.518

$k = 40$ 时 d 的分布：正确个体均值 0.500（标准差 0.049），错配个体 0.015（标准差 0.075），两者几乎分开，灵敏度 0.968、假阳性率 0。把被标记的个体改用系谱 BLUP 预测，相关由 0.352 恢复到 0.606。身份错误不改变矩阵的数值谱，只能由独立的一致性检查（亲子、已知关系）发现；检出后要回退到仍可信的信息，而不是继续使用。

推导 35.5 初筛之后：相关下降与尾部损失

初筛：按亲本 EBV 均值保留候选的前 30%（24 只），再从中选 8 只。初筛按亲本均值进行，去掉了家系间变异，留下的主要是家系内（孟德尔抽样）变异，而系谱 BLUP 对这部分几乎没有信息。习题 35.19（100 次重复）：

方法	全体候选相关	初筛后相关	相对下降
系谱 BLUP	0.534	0.277	48.2%
GBLUP	0.688	0.552	19.7%

初筛后真实育种值的方差只有全体的 0.762 倍。选 8 只的真实育种值均值：GBLUP 1.102（标准误 0.037），系谱 BLUP 0.859；初筛内神谕 1.519，初筛集合随机 0.589，全体神谕 1.681；G-A 的选择优势 0.243（标准误 0.025）。相关下降是范围缩窄的后果，不是模型失效；决策应按实际被评价的范围报告相关，并用选择增益与神谕比较衡量尾部损失。

推导 35.6 个体比较要用 PEC

两个候选的差值 $\hat{u}_i - \hat{u}_j$ 的误差方差为 $PEV_i + PEV_j - 2PEC_{ij}$ ；共享训练资料与亲缘使 PEC 通常为正。习题 35.20（80 只候选，3160 对，30 次重复）：

指标	GBLUP	系谱 BLUP
平均 PEV	0.528	0.717
平均 PEC：同父半同胞 / 其他	0.085 / 0.003	0.100 / 0.003
半同胞对 v^0/v （忽略 PEC / 精确）	1.200	1.163
半同胞对覆盖率：精确 / 忽略 PEC	0.897 / 0.926	0.903 / 0.926
宣布“不同”：精确 / 区间重叠	0.087 / 0.015	0.011 / 0.000
已宣布对的符号错误率：精确 / 重叠	0.027 / 0.008	0.078 / 0.000

对无亲缘的对, PEC 约为 0, 忽略 PEC 几乎无影响 (总体覆盖率 0.903 对 0.906); 对同父半同胞, 忽略 PEC 使误差方差高估 20%, 覆盖率偏高到 0.926 (区间偏宽)。区间重叠法的宣布比例只有精确法的约 1/6 (0.015 对 0.087) ——功效损失巨大。组均值对比 (各 10 只, 取 w' PEV w): 误差方差二次型 0.1052、实际 MSE 0.1072。比较个体、组合与亲本配对, 应使用 PEV 矩阵的二次型, 而不是区间是否重叠。

推导 35.7 小例子: 收缩不是丢掉信息, 亲缘改变信息权重

单个体: 奠基个体 n 条独立记录, 均值偏差 $\bar{y}$, $\hat{u} = c\bar{y}$, $c = \frac{n\sigma_a^2}{n\sigma_a^2 + \sigma_e^2}$, $\text{PEV} = (1-c)\sigma_a^2$, 可靠度 $r^2 = c$ 。 $\sigma_a^2 = \sigma_e^2 = 1$ 、 $n = 3$ 、 $\bar{y} = 1.8$ 时 $c = 0.75$, $\hat{u} = 1.35$, $\text{PEV} = 0.25$, 可靠度 0.75: EBV 小于表型偏差 1.8 的原因是均值中含有 $\sigma_e^2/n = 0.333$ 的环境噪声, 收缩把不属于遗传的那部分扣掉, 而不是丢弃信息。

双个体: 亲本 1 与子代 2 都有记录, $A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$, $\sigma_a^2 = 2$, $\sigma_e^2 = 3$, $y = (2, 1)'$ (总体均值已知为 0)。 $V = \begin{pmatrix} 5 & 1 \\ 1 & 5 \end{pmatrix}$, $V^{-1}y = (0.375, 0.125)'$, $\hat{u} = \sigma_a^2 AV^{-1}y = (0.875, 0.625)'$ 。亲本的 EBV 0.875 高于只用自己记录的 0.8 ($2 \times 2/5$), 子代的 EBV 0.625 高于只用自己记录的 0.4 ($1 \times 2/5$): 亲缘使每个个体借用对方的记录。PEV 矩阵为 $\begin{pmatrix} 1.125 & 0.375 \\ 0.375 & 1.125 \end{pmatrix}$, 可靠度各为 $1 - 1.125/2 = 0.4375$ (只用自己记录时为 0.4), 而且两个个体的预测误差正相关 (PEC = 0.375): 差值 $\hat{u}_1 - \hat{u}_2$ 的误差方差是 $1.125 + 1.125 - 2 \times 0.375 = 1.5$, 而不是 2.25。亲缘既提高可靠度, 也使预测误差相关, 这正是个体比较必须用 PEC 的原因 (推导 35.6)。

延伸阅读: 把教学实验扩展成严谨研究

要把本章的教学结论推广, 需要逐项放宽设定: 估计方差而非已知方差; 位点连锁与有限标记密度; 非随机交配与选择历史; 选择性分型与缺测; 真实性状的上位性与 G×E; 用后续评定而非真值作验证代理。每放宽一项, 都应预先规定重复数、种子、报告指标与失败条件, 并在独立真实资料中检验相容性。

常见误区

1. 把模拟中的相关系数当作真实群体的准确度。
2. 只展示表现最好的种子。
3. 在不报告标记密度的情况下比较 GBLUP 与系谱 BLUP。
4. 以为只要相关没变, EBV 的幅度与区间就没变。
5. 以为关系矩阵“合法”就说明身份正确。
6. 用初筛后的相关下降评判模型好坏。
7. 用区间是否重叠比较个体。
8. 事后搜索最显著的异常亚群。

35.5 习题

一、单项选择题

35.1 ★ [单选] 模拟实验“真实育种值已知”这一特点的恰当解读是

- (A) 结论可直接推广到任何真实群体
- (B) 可直接检验预测，但结论依赖生成条件
- (C) 不需要重复
- (D) 可取代真实资料验证

[答案]

35.2 ★ [单选] 已知基础等位基因频率时，VanRaden 的 G 与系谱 A 的关系是

- (A) $G = A$ 逐项成立
- (B) $E(G_{ij}) = A_{ij}$
- (C) 两者无关
- (D) G 总是单位阵

[答案]

35.3 ★★ [单选] 校准斜率 $b(u | \hat{u}) = 0.6$ 提示

- (A) EBV 过度收缩
- (B) EBV 过度分散
- (C) 准确度为 0.6
- (D) 无任何含义

[答案]

35.4 ★★ [单选] 只用 15 个随机位点构造 G ，而真实育种值由 240 个位点生成，GBLUP 的验证相关通常

- (A) 高于系谱 BLUP
- (B) 可能低于系谱 BLUP
- (C) 与密度无关
- (D) 恒等于系谱 BLUP

[答案]

35.5 ★★ [单选] 拟合时残差方差设得过大 ($f > 1$)，其主要后果是

- (A) EBV 排序完全颠倒
- (B) 过度收缩，斜率大于 1，排序变化很小
- (C) 相关系数变为 0
- (D) 无任何后果

[答案]

35.6 ★★★ [单选] 两个候选的差值预测误差方差为

- (A) $PEV_i + PEV_j$
- (B) $PEV_i - PEV_j$
- (C) $PEV_i + PEV_j - 2PEC_{ij}$
- (D) $PEV_i PEV_j$

[答案]

二、判断与改错题

35.7 ★ [判断] 相关系数足以同时说明预测的排序、幅度与不确定性是否可靠。 [答案]

35.8 ★ [判断] 为避免选择性报告, 应预先规定种子与重复数并完整报告。 [答案]

35.9 ★★ [判断] 身份错配会使 G 不再是半正定矩阵, 因而容易被软件报错发现。 [答案]

35.10 ★★ [判断] 初筛之后相关系数下降, 说明模型在该范围内比全体候选上更差。 [答案]

三、填空题

35.11 ★ [填空] 一只奠基个体有 $n = 3$ 条独立记录, 均值 $\bar{y} = 1.8$ (总体均值已知为 0), $\sigma_a^2 = \sigma_e^2 = 1$, EBV 为 _____ (三位小数)。 [答案]

35.12 ★★ [填空] 无错配时 GBLUP 相关 $r_0 = 0.685$, 候选共 80 只, 其中 20 只被错配, 理论相关 $(1 - k/n)r_0 =$ _____ (三位小数)。 [答案]

35.13 ★★ [填空] $PEV_i = 0.5$, $PEV_j = 0.6$, $PEC_{ij} = 0.1$, 差值误差方差为 _____。 [答案]

35.14 ★★ [填空] $\sigma_a^2 = 2$, $PEV = 1.8$, 可靠度 $r^2 =$ _____ (三位小数)。 [答案]

四、计算题

?? 35.15 | 4 | 计算 **BLUP 与 GBLUP 的配对比较**。30 次重复, 报告相关、RMSE、校准与覆盖率、成对差, 并用 Henderson 方程核验。 [程序] [ch35/ex35_15_blup_vs_gblup.py](#)

?? 35.16 | 4 | 计算 **可观测标记减少**。比较 15–240 个位点的 GBLUP、系谱 BLUP 与混合矩阵, 并报告关系精度。 [程序] [ch35/ex35_16_marker_density.py](#)

?? 35.17 | 4 | 计算 **方差比错设**。比较 $f = 0.1$ 到 10 下的相关、RMSE、斜率、覆盖率与排序相关。 [程序] [ch35/ex35_17_variance_ratio.py](#)

?? 35.18 | 4 | 计算 **身份错配与亲子检查**。比较错配比例对相关的影响、检出灵敏度与回退后的恢复。 [程序] [ch35/ex35_18_identity_mismatch.py](#)

35.19 ★★★★★ [计算] **初筛与尾部损失**。比较初筛前后的相关, 并用选择增益与神谕评价尾部。 [程序] [ch35/ex35_19_screening_tail.py](#) [答案]

35.20 ★★★★★ [计算] **个体比较与 PEC**。比较精确与忽略 PEC、区间重叠法的覆盖率与功效。 [程序] [ch35/ex35_20_pairwise_pec.py](#) [答案]

35.21 ★★ [计算] 亲子借用手算。亲本与子代： $A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$, $\sigma_a^2 = 2$, $\sigma_e^2 = 3$ 。只有亲本有记录，偏差 $y = 2$ （总体均值已知为 0）。求子代的 EBV、PEV 与可靠度。 [答案]

35.22 ★★ [计算] 方差比错设手算。奠基个体有 $n = 3$ 条独立记录, $\sigma_a^2 = \sigma_e^2 = 1$, $\bar{y} = 1.8$ 。拟合时误设 $\sigma_e^{2'} = 2$ ($f = 2$)。求误设下的 EBV、误设给出的 PEV、实际 MSE 与校准斜率。 [答案]

五、推导与证明题

35.23 ★★ [证明] 设 $y = \mu\mathbf{1} + Zu + e$ 。证明协方差形式的 $\hat{u} = \sigma_a^2 KZ'V^{-1}(y - \mu\mathbf{1})$ ($V = \sigma_a^2 ZKZ' + \sigma_e^2 I$, μ 已知) 与 $(Z'Z + \lambda K^{-1})\hat{u} = Z'(y - \mu\mathbf{1})$ 的解一致。 [答案]

35.24 ★★★ [证明] 设标记 j 的基础频率为 p_j 已知，子代接受父母各一个等位基因。证明父子（亲本-子代）对的 $E[(z_o - 2p)(z_s - 2p)] = p_j q_j$ （单位点），从而 $E(G_{os}) = 1/2$ 。 [答案]

35.25 ★★★ [证明] 设 k 个候选的预测被另一个与真值独立的个体预测所替代，其余不变，且 $\text{Var}(\hat{u})$ 近似不变。证明 $r(\varphi) \approx (1 - \varphi)r_0$, $\varphi = k/n$ 。 [答案]

35.26 ★★★ [证明] 奠基个体有 n 条独立记录，拟合的收缩系数 $c = n\sigma_a^2 / (n\sigma_a^2 + \sigma_e^{2'})$ 。证明校准斜率 $b(u | \hat{u}) = \sigma_a^2 / [c(\sigma_a^2 + \sigma_e^2/n)]$, c 等于正确值时斜率为 1，并求 MSE。 [答案]

六、综合分析与研究设计题

35.27 ★★ [综合] 设计一个把本章教学实验扩展到“估计方差、连锁位点与不完全标记”的严谨研究：设定、因素、重复、指标与失败条件。 [答案]

35.28 ★★★ [综合] 某报告称“模拟中 GBLUP 的相关比系谱 BLUP 高 0.15，因此建议全场改用 GBLUP”。写评审意见，并说明需要补充哪些实验。 [答案]

- 35.29 ★★★ [综合]** 肉羊场发现一批羔羊的基因型与系谱的亲子关系不一致。设计检查、处理与报告流程，并说明哪些预测需要回退。 [答案]

35.6 参考答案与解析

一、单项选择题

- 35.1 (B)**。模拟可以直接检验预测（真值可见），但结论只在生成条件下成立。推导 35.1：30 次重复中 G 高于 A（差 0.149），但不能外推到小面板或其他性状（推导 35.2）。 [题目]
- 35.2 (B)**。在已知基础频率与位点独立下 $E(G_{ij}) = A_{ij}$ ；实际 G 含孟德尔抽样，逐项不相等（证明 35.24）。 [题目]
- 35.3 (B)**。 $b < 1$ 说明 EBV 过于分散（过度自信）。推导 35.2：15 个位点时斜率 0.548；推导 35.3： $f = 0.1$ 时 0.477。 [题目]
- 35.4 (B)**。推导 35.2：15 个位点的 GBLUP 相关 0.236，低于系谱 BLUP 的 0.529。 [题目]
- 35.5 (B)**。推导 35.3： $f = 10$ 时斜率 3.388，EBV 标准差 0.189（对 $f = 1$ 的 0.682），与 $f = 1$ 的排序相关仍有 0.952。 [题目]
- 35.6 (C)**。共享资料使 PEC 通常为正，忽略它会高估方差。推导 35.6：同父半同胞对 $v^0/v = 1.200$ 。 [题目]

二、判断与改错题

- 35.7 错误**。相关对平移与缩放不敏感。推导 35.3： $f = 4$ 时相关 0.670（ $f = 1$ 为 0.683），斜率却是 1.843，覆盖率 0.937。 [题目]
- 35.8 正确**。预定种子与完整报告避免选择性叙述。推导 35.1：30 次重复相关的标准差 0.076—0.100，单个种子能轻易夸大或低估效果。 [题目]
- 35.9 错误**。错配只是行交换， $G = WW'/c$ 仍半正定，软件不会报错。推导 35.4：需要亲子检查， d 均值由 0.500 降到 0.015。 [题目]
- 35.10 错误**。初筛使真实育种值方差缩小（0.762 倍），相关下降是范围缩窄的后果。推导 35.5：GBLUP $0.688 \rightarrow 0.552$ ，仍比系谱 BLUP（0.277）高 0.275。 [题目]

三、填空题

35.11 $c = n\sigma_a^2 / (n\sigma_a^2 + \sigma_e^2) = 3/4$, $EBV = 0.75 \times 1.8 = \mathbf{1.350}$ 。 [题目]

35.12 $(1 - 20/80) \times 0.685 = 0.75 \times 0.685 = \mathbf{0.514}$ 。 [题目]

35.13 $0.5 + 0.6 - 2 \times 0.1 = \mathbf{0.9}$ 。 [题目]

35.14 $r^2 = 1 - 1.8/2 = \mathbf{0.100}$ 。 [题目]

四、计算题

35.15 结果见推导 35.1。GBLUP 与系谱 BLUP：相关 0.687/0.538, RMSE 0.716/0.832, 斜率 0.973/0.993, 覆盖率 0.905/0.903；成对相关差 0.149（标准误 0.011, 30/30）；Henderson 核验差 1.0×10^{-15} 。解读：区间覆盖率达标不说明两者同样精确，G 的 PEV 更小（0.528 对 0.717，见推导 35.6）。 [题目]

35.16 结果见推导 35.2。用 m_{obs} 个位点构造 G, m_{obs} 依次取 15、30、60、120、240：GBLUP 相关依次为 0.236、0.282、0.459、0.572、0.682；关系精度依次为 0.337、0.465、0.626、0.810、1.000；混合矩阵相关依次为 0.507、0.493、0.566、0.616、0.653；系谱 BLUP 相关 0.529。解读：关系精度与相关同步上升；少标记时 GBLUP 低于系谱 BLUP，是信息损失（噪声被当作关系），混合矩阵是稳妥的回退。如果报告里只写“GBLUP 比系谱 BLUP 好”而不写标记密度，读者无法判断结论适用于哪种面板；程序还断言了相关随密度单调不降（容差 0.01）与关系精度严格上升。 [题目]

35.17 结果见推导 35.3。GBLUP 的校准斜率，依次取 $f = 0.1$ 、0.25、0.5、1、2、4、10：0.477、0.627、0.772、0.973、1.290、1.843、3.388。覆盖率依次为 0.572、0.740、0.844、0.909、0.930、0.937、0.931。相关依次为 0.606、0.653、0.674、0.683、0.680、0.670、0.656。系谱 BLUP 的斜率依次为 0.575、0.659、0.773、0.973、1.336、2.017、3.982。解读：相关对方差比不敏感，斜率与覆盖率敏感； $f < 1$ 过度自信， $f > 1$ 过度收缩。 [题目]

35.18 结果见推导 35.4。 $k = 0, 8, 16, 40, 80$ 的相关 0.685, 0.622, 0.520, 0.352, -0.024，理论 0.685, 0.616, 0.548, 0.342, 0；灵敏度 0.963—0.971，假阳性率 0；改用系谱后的相关 0.685, 0.667, 0.649, 0.606, 0.518。解读：相关随错配比例线性下降；检查发现问题后，回退（改用系谱）能挽回大部分损失。 [题目]

35.19 结果见推导 35.5。相关：A 0.534 $\rightarrow$ 0.277（下降 48.2%），G 0.688 $\rightarrow$ 0.552（19.7%）；方差比 0.762；选 8 只的均值：G 1.102，A 0.859，初筛内神谕 1.519，随机 0.589，

不初筛 0.859 (A) 与 1.137 (G), 全体神谕 1.681。解读: GBLUP 在初筛后的优势更大, 因为留下的是家系内变异。 [题目]

35.20 结果见推导 35.6。平均 PEC: 同父半同胞 GBLUP 0.085、系谱 BLUP 0.100; 其他对均为 0.003。差值区间的总体覆盖率: 精确法 0.903 (G) 与 0.905 (A), 忽略 PEC 为 0.906 与 0.907。半同胞对覆盖率: 精确 0.897 (G) 与 0.903 (A), 忽略 PEC 均为 0.926。宣布“不同”的比例: 精确法 0.087 (G) 与 0.011 (A), 重叠法 0.015 与 0.000。组均值对比的二次型方差 0.1052 (G) 与 0.1425 (A), 实际 MSE 0.1072 与 0.1418。解读: 无亲缘的对忽略 PEC 影响很小, 亲缘对影响明显; 区间重叠法功效极低。 [题目]

35.21 $\hat{u}_{child} = \sigma_a^2 a_{12} y / (\sigma_a^2 + \sigma_e^2) = 2 \times 0.5 \times 2 / 5 = \mathbf{0.400}$ 。 $PEV = \sigma_a^2 - \sigma_a^4 a_{12}^2 / (\sigma_a^2 + \sigma_e^2) = 2 - 4 \times 0.25 / 5 = \mathbf{1.80}$ 。可靠度 $= 1 - 1.8 / 2 = \mathbf{0.100}$ 。解读: 只有亲本有记录时, 子代的可靠度只有 10% ($= a_{12}^2 \times$ 亲本可靠度 $= 0.25 \times 0.4$)。 [题目]

35.22 $c = 3 \times 1 / (3 \times 1 + 2 \times 1) = 0.6$ 。 $EBV = 0.6 \times 1.8 = \mathbf{1.08}$ (正确方差比下 $0.75 \times 1.8 = 1.35$)。误设给出的 $PEV = \sigma_a^2 \sigma_e^2 / (n \sigma_a^2 + \sigma_e^2) = 2 / 5 = \mathbf{0.40}$ 。实际 $MSE = (1 - c)^2 \sigma_a^2 + c^2 \sigma_e^2 / n = 0.16 + 0.36 / 3 = \mathbf{0.28}$ (正确 $PEV = 0.25$)。校准斜率 $= \sigma_a^2 / [c(\sigma_a^2 + \sigma_e^2 / n)] = 1 / (0.6 \times 4 / 3) = \mathbf{1.25}$ 。解读: 误设使 PEV (0.40) 高于实际 MSE (0.28), 区间偏宽, 与习题 35.17 中 $f > 1$ 时覆盖率偏高一致。 [题目]

五、推导与证明题

35.23 证明。混合模型方程 $(Z'Z + \lambda K^{-1})\hat{u} = Z'r$, $r = y - \mu \mathbf{1}$, $\lambda = \sigma_e^2 / \sigma_a^2$ 。两边左乘 K : $(KZ'Z + \lambda I)\hat{u} = KZ'r$ 。利用恒等式 $(KZ'Z + \lambda I)^{-1}KZ' = KZ'(ZKZ' + \lambda I)^{-1}$ (两边右乘 $(ZKZ' + \lambda I)$ 展开即得), 所以 $\hat{u} = KZ'(ZKZ' + \lambda I)^{-1}r = \sigma_a^2 KZ'V^{-1}r$ 。数值: 习题 35.15 核验两者最大差 1.0×10^{-15} 。 ■ [题目]

35.24 证明。设亲本 s, d 的基因型 z_s, z_d (边缘均值 $2p$ 、方差 $2pq$, 相互独立), 子代 $z_o = t_s + t_d$, $t_s | z_s \sim \text{Bernoulli}(z_s/2)$ 。则 $E(z_o | z_s, z_d) = (z_s + z_d)/2$ 。所以 $E[(z_o - 2p)(z_s - 2p)] = E[\frac{1}{2}(z_s - 2p + z_d - 2p)(z_s - 2p)] = \frac{1}{2}[\text{Var}(z_s) + \text{Cov}(z_s, z_d)] = \frac{1}{2} \times 2pq = pq$ 。标准化 $\sum_j 2p_j q_j$ 后期望为 $\sum_j p_j q_j / \sum_j 2p_j q_j = 1/2$, 与 $A_{os} = 0.5$ 一致。习题 35.18: 正确个体 d 均值 0.500。 ■ [题目]

35.25 证明。设比例 $1 - \varphi$ 的个体预测不变, 其与真值的协方差为 $\text{Cov}_0 = r_0 \sigma_u \sigma_{\hat{u}}$, 比例 φ 的个体预测与真值独立, 协方差为 0。总体协方差 $\text{Cov} = (1 - \varphi) \text{Cov}_0$ (均值不变时)。预测方差近似不变, 故 $r = \text{Cov} / (\sigma_u \sigma_{\hat{u}}) = (1 - \varphi)r_0$ 。数值: $k = 40, n = 80$,

$0.5 \times 0.685 = 0.342$, 习题 35.18 的实测 0.352。■

[题目]

35.26 证明。 $\hat{u} = c\bar{y}$, $\bar{y} = u + \bar{e}$, $\text{Var}(\bar{y}) = \sigma_a^2 + \sigma_e^2/n$ 。 $\text{Cov}(u, \hat{u}) = c\sigma_a^2$, $\text{Var}(\hat{u}) = c^2(\sigma_a^2 + \sigma_e^2/n)$, 所以 $b = \sigma_a^2/[c(\sigma_a^2 + \sigma_e^2/n)]$ 。正确的 $c_0 = \sigma_a^2/(\sigma_a^2 + \sigma_e^2/n)$ 时 $b = 1$ 。
 $\text{MSE} = E(u - c\bar{y})^2 = (1 - c)^2\sigma_a^2 + c^2\sigma_e^2/n$ 。数值: $c = 0.6$: $b = 1.25$, $\text{MSE} = 0.28$
 (习题 35.22)。■

[题目]

六、综合分析与研究设计题

35.27 设计 (1) **设定**: 用 REML 估计方差而不是给定真值; 染色体长度与重组率 (连锁), 位点数大于标记数, 因果位点与标记不重合; (2) **因素**: 标记密度 (推导 35.2)、群体亲缘结构 (奠基数、家系大小)、 h^2 、训练样本量、方差比误差 (推导 35.3); (3) **重复**: 每个设定至少 30 次预定种子; 成对比较; (4) **指标**: 相关、RMSE、校准斜率与截距、区间覆盖率、选择增益与神谕、亲子检查灵敏度; (5) **失败条件**: 事先规定, 如 GBLUP 相对系谱的相关差的 95% 区间下限 ≤ 0 、斜率超出 $[0.8, 1.2]$ 、覆盖率低于 0.85 时视为未达标; (6) **报告**: 全部设定与失败案例, 包括表现最差的重复。

[题目]

35.28 评审意见 (1) 该结论来自一个设定 (全部 240 个因果位点分型、已知方差、随机交配), 推导 35.2 显示标记减少到 15 个时 GBLUP 的相关 (0.236) 低于系谱 BLUP (0.529); 需要在实际面板密度下检验。(2) 已知方差是教学设定, 需补充估计方差的实验与方差比错设的敏感性 (推导 35.3: 斜率与覆盖率受影响)。(3) 需要报告校准与区间覆盖率, 而不仅是相关; 报告初筛范围下的相关与选择增益 (推导 35.5)。(4) 需要报告身份核查 (推导 35.4) 与回退策略。(5) 结论应限定为: 在所述生成条件下, 0.15 的相关差来自候选个体实际遗传抽样的信息; 全场改用 GBLUP 的决策还需成本、身份管理与真实资料的验证。

[题目]

35.29 流程 (1) **检查**: 对每只羔羊计算 $d_i = \frac{1}{2}(G_{is} + G_{id})$ (推导 35.4), 低于 0.25 标记; 用已知全同胞、半同胞对的 G 值核对; (2) **处理**: 被标记个体的基因型暂不进入 G , 对该个体回退到系谱 BLUP 预测 (习题 35.18: $k = 40$ 时相关由 0.352 恢复到 0.606); 追溯样品登记与管理记录, 更正系谱或基因型; (3) **报告**: 错配比例、检出灵敏度与假阳性率、受影响个体名单、更正前后的 EBV 变化; (4) **预防**: 条形码与样品双人核对, 新批次入库时即做亲子检查, 并记录在数据契约 (第 34 章) 中; (5) **回退范围**: 凡使用了被标记个体基因型的预测 (该个体、其后代与同胞的预测) 都需要重新评定。

[题目]

多性状目标与约束配种的完整决策算例

36.1 本章导学

学习目标

1. 区分“预测个体”“选择亲本”与“安排配种”三个问题，理解两层决策（亲本贡献、公母配对）的作用与局限。
2. 会把多性状 EBV 通过经济权重合成指数，理解单位与整体缩放不影响选择，并会比较不同目标情景下的亲本集合与各性状响应。
3. 掌握最优贡献问题：在群体共祖约束下最大化遗传水平，会写出并核验 KKT 条件，解释乘子 λ 的边际含义。
4. 把配种分配写成运输问题，理解全单模带来的整数解、对偶变量作为影子价格，以及禁配网络的可行性（Hall 条件）。
5. 理解连续解取整的损失：一阶（收益、约束违反）与二阶（拉格朗日损失）的区别。
6. 会把 EBV 不确定性写入决策（后验方差二次型、均值—方差、分位数），并如实报告其效应大小。

重点与难点

重点： $\max g'c, \text{s.t. } c'_m \mathbf{1} = c'_f \mathbf{1} = \frac{1}{2}, \theta = \frac{1}{2} c'Ac \leq \theta_{\max}, \text{KKT: } g_i = \lambda (Ac)_i + \mu_{\text{sex}(i)} (c_i > 0)$ ；
运输问题 $\min \sum c_{sd} x_{sd}$ ，行和 n_s 、列和 n_d ；Hall 条件；预测分布 $H \sim N(g'c, c'Pc)$ 。
难点：优化器给的是“条件于预测与约束的推荐”，不是唯一正确方向；约束起作用时才有乘子；整数化的损失阶数；禁配网络可能使问题无解；风险项的实际效应可能很小，不能夸大。

本章承接第 22 章（选择与响应）、第 23 章（近交与共祖）与第 35 章（BLUP 与 GBLUP）。第 35 章停在个体的预测；本章从十六只候选羊（6 公 10 母）出发，经过“经济权重 → 最优贡献 → 配种运输 → 整数化 → 风险与禁配”，完成一个可复算、可审阅的决策链。每一步的数字都由配套程序在固定种子下给出。

36.2 知识结构图




图 36.1 第 36 章知识结构图

左侧是“目标与贡献”，中部是“配种与整数化”，右侧是“风险、可行性与审阅”。

36.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
综合指数	$g_i = \sum_k w_k \hat{u}_{ik}$	w_k 为每遗传标准差的价值
群体共祖	$\theta = \frac{1}{2} c' A c$	$\sum c_i = 1$
最优贡献	$\max g'c, \theta \leq \theta_{\max}$	公母各 $\frac{1}{2}$
KKT	$g_i = \lambda (Ac)_i + \mu_{\text{sex}}$	$c_i > 0; c_i = 0$ 时 $\leq$
运输问题	$\min \sum F_{sd} x_{sd}$	$F_{sd} = A_{sd} / 2$
对偶	$\max \sum n_s u_s + \sum n_d v_d$	$u_s + v_d \leq F_{sd}$
Hall 条件	$\sum_{s \in S} n_s \leq \sum_{d \in N(S)} n_d$	可行的充要条件
预测分布	$H \sim N(g'c, c'Pc)$	P 为指数 PEV 矩阵

36.4 补充内容与公式推导

推导 36.1 经济权重情景：同一批 EBV，不同目标，不同亲本

候选群体：3 只奠基公羊与 8 只奠基母羊（互不相关），16 只候选羊各由随机奠基公、母交配产生（带有全同胞、半同胞结构）；三性状（生长、繁殖、胴体）的遗传相关为 $r(\text{生长, 繁殖}) = -0.2$ 、 $r(\text{生长, 胴体}) = 0.5$ ；EBV 为多性状 BLUP。三套经济权重（每遗传标准差的价值）：生长优先 (1, 0.2, 0.4)，繁殖优先 (0.3, 1, 0.2)，均衡 (0.6, 0.6, 0.5)。习题 36.15（200 个随机群体，前 3 公 + 前 5 母等份额截留；以下为性状（预测响应/实现响应））：

情景	生长	繁殖	胴体
生长优先	0.448 / 0.456	-0.020 / -0.039	0.403 / 0.422
繁殖优先	0.093 / 0.116	0.388 / 0.408	0.211 / 0.245
均衡	0.348 / 0.365	0.164 / 0.136	0.409 / 0.435

综合目标 $H = w'u$ 的实现值（行为选择所用情景，列为评价所用权重）：生长优先选择在生长优先权重下 0.617、在繁殖优先权重下仅 0.182；繁殖优先选择分别为 0.295 与 0.491；均衡选择为 0.566、0.333、0.518。每个情景在自己的权重下最高。亲本集合的 Jaccard 重叠：生长优先对繁殖优先 0.475（指数排名 Spearman 相关 0.380），生长优先对均衡 0.735（0.862），繁殖优先对均衡 0.643（0.704）。预测与实现响应吻合（BLUP 无偏）。把性状 1 的单位乘 10 且权重除以 10，或权重整体乘以常数，选择结果在 200 次中全部一致——权重的含义是“每遗传标准差的价值”，尺度不属于决策。

推导 36.2 最优贡献：同样的群体共祖，更高的遗传水平

问题： $\max g'c$ ，公、母份额各 $\frac{1}{2}$ ， $c \geq 0$ ， $\theta = \frac{1}{2}c'Ac \leq \theta_{\max}$ 。以等份额截留（前 3 公、前 5 母）的 θ 作为上限。习题 36.16（均衡权重，100 个群体）：

指标	截留	最优贡献
预测遗传水平 $g'c$	0.540	0.681
实现的真实 H	0.560	0.716
群体共祖 θ	0.1234	0.1234

在同样的群体共祖下，预测遗传水平提高 0.141 (26%)。最优解的支撑集平均 9.4 只（截留为 8 只），最大份额平均 0.253，乘子 λ 平均 6.05。KKT 核验：支撑集上 $g_i = \lambda(Ac)_i + \mu_{\text{sex}(i)}$ 的最小二乘残差范数最大为 1.5×10^{-7} ，零份额个体的余量 $g_i - \lambda(Ac)_i - \mu_i$ 最大为 -4.6×10^{-4} (≤ 0)。围绕第 1 个群体的解在可行域内随机扰动 4000 次，改进 0 次。前沿（第 1 个群体， $\theta_{\max} \rightarrow g'c$): 0.0863 $\rightarrow$ 0.904, 0.1186 $\rightarrow$ 1.350, 0.1510 $\rightarrow$ 1.537, 0.1833 $\rightarrow$ 1.655, 0.2156 $\rightarrow$ 1.737, 0.2479 $\rightarrow$ 1.779, 0.2802 $\rightarrow$ 1.803, 0.3125 $\rightarrow$ 1.819: **单调不减、凹**，边际收益递减，说明约束越松越不值得。

推导 36.3 配种分配是运输问题

后代数 $N = 40$ ，按最大余数法由最优贡献得到公羊的后代数 n_s 与母羊的后代数 n_d （各合计 40）。决策变量 x_{sd} 为公 s 与母 d 的配对数，成本 $F_{sd} = A_{sd}/2$ （后代近交系数的期望），行和 n_s 、列和 n_d ，全同胞 ($A_{sd} \geq 0.5$) 禁配。系数矩阵全单模，线性规划的顶点解是整数。习题 36.17 (100 个群体，98 个可行，贪心在 83 个中可行)：

方案	后代期望近交系数 $\bar{F}$	相对随机配种的降低	半同胞及更近配对的后代占比
随机配种（不考虑禁配）	0.0510	—	0.376
贪心	0.0241	52.8%	—
运输 LP	0.0122	76.0%	0.098

运输 LP 把平均近交系数降低 76%，贪心降低 52.8%（贪心可能把剩余后代数留给禁配对而无解）。LP 解为整数且行列和精确成立；独立求解的对偶 LP 与原始目标相等（差 $< 10^{-7}$ ）。**第二层决策可以在不改变第一层贡献的前提下，大幅降低后代的近交期望。**

推导 36.4 整数后代数：一阶损失与二阶损失

连续最优 c^* 要换成整数后代数。设 $c = c^* + \delta$ ， $\delta = O(1/N)$ 。收益 $g'c$ 与约束 θ 的偏差是一阶量；而拉格朗日函数 $L(c) = g'c - \lambda(\theta(c) - \theta_{\max})$ 在最优点处一阶项由 KKT 抵消，损失 $\frac{1}{2}\delta'A\delta = O(1/N^2)$ （证明 36.25）。习题 36.18 (100 个群体；(b) 最大余数法，(c) 带约束的局部搜索，从 (b) 出发，在同性别个体间移动 1 个后代)：

N	方法	$ \Delta g $	θ 超出	拉格朗日损失	可行比例
10	最大余数	0.0198	0.00259	0.006242	0.36

10	局部搜索	0.0151	0	0.010392	1.00
40	最大余数	0.0042	0.00043	0.000363	0.45
40	局部搜索	0.0015	0	0.000991	1.00
100	最大余数	0.0017	0.00013	0.000060	0.53
400	最大余数	0.0005	0.00004	0.000004	0.45

最大余数法中 $|\Delta g|$ 对 N 的对数-对数斜率为 -1.01 （一阶），拉格朗日损失的斜率为 -2.00 （二阶），与理论吻合。最大余数法在约一半的群体里违反共祖约束（可行比例 $0.36-0.53$ ），违反量随 N 下降；局部搜索把可行比例提高到 1.00 ，代价是拉格朗日损失略高（ 0.000991 对 0.000363 ， $N = 40$ ）。**取整后必须重新检查约束，不能假定连续解的约束“大体仍满足”。**

推导 36.5 EBV 不确定性与均值-方差权衡

后验 $u | y \sim N(\hat{u}, \text{PEV})$ ，综合目标 $H = c'(Uw)$ 的预测分布为 $N(g'c, c'Pc)$ ， $P = \sum_{a,b} w_a w_b \text{PEV}_{ab}$ 。策略 $\max g'c - \kappa \sqrt{c'Pc}$ （约束同前）， $\kappa = 1.2816$ 即最大化 10% 分位数。习题 36.19（300 个群体， $\text{floor} = 0$ ，覆盖率指 ± 1.645 个预测标准差的区间包含实现值的比例；“信息不均”为 40% 的候选残差方差放大 8 倍）：

设定	κ	预测均值	预测 sd	预测 q_{10}	实现均值	实现 $H < 0$ 频 率	覆盖率
信息均匀	0	0.659	0.318	0.252	0.671	0.110	0.877
信息均匀	1.2816	0.656	0.314	0.254	0.668	0.113	0.870
信息不均	0	0.577	0.359	0.116	0.596	0.167	0.887
信息不均	0.5	0.575	0.354	0.121	0.591	0.157	0.890
信息不均	1.2816	0.570	0.348	0.124	0.581	0.160	0.903

预测概率校准良好（预测 $P(H < 0)$ 与观测频率相差小于 0.04，覆盖率约 0.9）。**但风险项的效应很小**：信息不均时 $\kappa = 1.2816$ 使预测标准差只下降 3.1%（ $0.359 \rightarrow 0.348$ ），预测均值下降 0.007，实现的 $H < 0$ 频率变化 -0.007 ；信息均匀时几乎无变化。原因是：共祖约束已经强烈限制了可行区域，EBV 已按可靠度收缩，而大头的不确定性是未被信息分辨的孟德尔抽样，改变贡献分配无法消除。**如实报告：风险调整是合理的保险，但不要承诺它会显著降低下尾风险。**

推导 36.6 禁配网络、Hall 条件与对偶证据

可行性等价于最大流等于 N ；不可行时，残量网络中从源点可达的公羊集合 S 满足 $\sum_{s \in S} n_s > \sum_{d \in N(S)} n_d$ (Hall 违反集合, 证明 36.26)。可行时, 对偶变量 (u_s, v_d) 满足对偶可行 $F_{sd} - u_s - v_d \geq 0$ 与互补松弛 ($x_{sd} > 0 \Rightarrow$ 等号), 且给公羊 s 与母羊 d 各多一个后代时, 最优成本的增加不小于 $u_s + v_d$ (值函数凸, 对偶解是次梯度)。习题 36.20 (200 个群体, $N = 40$):

禁配网络	可行比例	不可行时 Hall 违反成立	解禁一对即可行
全同胞 ($A \geq 0.5$)	0.985	3/3	3/3
半同胞及更近 ($A \geq 0.25$)	0.430	114/114	79/114
全同胞 + 随机 40% 禁配	0.365	127/127	81/127

Hall 违反示例: 违反集合内公羊的后代需求 37 个, 其全部可配母羊的容量仅 32 个。强对偶最大差 $< 10^{-7}$ 。在“全同胞 + 随机 40%”网络中, 次梯度不等式在 64/64 个检验中成立; 对 28 个被禁配对检验解禁价值: 约化成本 $F_{sd} - u_s - v_d < 0$ 的 8 个全部使最优成本严格下降, ≥ 0 的 20 个解禁后成本不变 (28/28 与符号一致)。**禁配规则越严, 越可能无解; 约化成本告诉决策者“解禁哪一对最值”。**

延伸阅读: 联合模型与近期方法

两层决策也可建立联合模型: 同时优化贡献与配对, 并把各配对的后代均值与方差 (含 Mendelian 抽样方差) 写入目标。联合模型更精确, 但解释更难, 也更依赖参数。实际中常用的做法是: 用两层模型给出基准方案, 用联合模型或模拟对少数候选方案做敏感性分析; 对近期提出的下尾风险与机会约束方法, 应要求其报告方案间的差异大小, 而不仅是“已优化”。

常见误区

1. 只看综合指数排名而忽略份额与亲缘。
2. 把优化器的解当作“唯一正确”的结论, 忽略目标与约束的价值判断。
3. 经济权重的单位不统一。
4. 连续解取整后不再检查约束。
5. 把运输问题的贪心解当作最优。
6. 禁配规则不检查可行性。
7. 夸大风险项的效应。
8. 不报告参数范围内方案的稳定性。

36.5 习题

一、单项选择题

36.1 ★ [单选] 只按综合指数从高到低选亲本，下面哪一项最容易被忽略

- (A) 性状的单位 (B) 亲本之间的亲缘与份额分配 (C) 表型的偏态
(D) 出生日期

[答案]

36.2 ★ [单选] 最优贡献选择与截留选择的主要区别是

- (A) 前者只用一个性状
(B) 前者把亲本份额作为决策变量，并同时约束共祖
(C) 前者不需要 EBV (D) 前者不需要约束

[答案]

36.3 ★★ [单选] c 的公、母份额各占 $\frac{1}{2}$ 时，群体共祖为

- (A) $c'Ac$ (B) $\frac{1}{2}c'Ac$ (C) $2c'Ac$ (D) $c'1$

[答案]

36.4 ★★ [单选] 配种运输问题的线性规划顶点解为整数，其原因是

- (A) 目标函数线性 (B) 约束矩阵全单模且右端为整数
(C) 变量非负 (D) 使用了贪心

[答案]

36.5 ★★★ [单选] 最优贡献问题中，约束起作用时乘子 λ 的含义是

- (A) 放宽共祖上限一个单位时目标的边际增加
(B) 个体数 (C) 近交系数 (D) 遗传方差

[答案]

36.6 ★★★ [单选] 连续最优解取整后，拉格朗日损失相对 N 的阶数是

- (A) $1/N^{1/2}$ (B) $1/N$ (C) $1/N^2$ (D) 常数

[答案]

二、判断与改错题

36.7 ★ [判断] 优化器给出的方案可以替代育种者对繁殖优先还是生长优先的价值判断。

[答案]

36.8 ★ [判断] 同一批 EBV 在不同经济权重下，选出的亲本集合可能很不一样。 [答案]

36.9 ★★ [判断] 只要给定公母后代数，加入任意禁配规则后运输问题总有解。 [答案]

36.10 ★★ [判断] 加入均值—方差风险项，通常会显著降低下尾风险且几乎不损失均值。

[答案]

三、填空题

36.11 ★ [填空] 两只公羊 $A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$, $c = (0.5, 0.5)'$, $c'Ac = \underline{\hspace{2cm}}$, $\theta = \underline{\hspace{2cm}}$ 。

[答案]

36.12 ★ [填空] 全同胞 ($A_{sd} = 0.5$) 交配，后代近交系数的期望为 $\underline{\hspace{2cm}}$ 。 [答案]

36.13 ★★ [填空] 某公羊集合的后代需求为 37，其全部可配母羊的容量为 32，缺口为 $\underline{\hspace{2cm}}$ 个。 [答案]

36.14 ★★ [填空] $F_{sd} = 0.125$, $u_s = -0.125$, $v_d = 0$, 约化成本为 $\underline{\hspace{2cm}}$ 。 [答案]

四、计算题

?? 36.15 | 4 | 计算 **经济权重情景**。比较三套权重下的亲本集合、各性状响应与综合目标，并检验单位与整体缩放不变性。 [程序] [ch36/ex36_15_economic_scenarios.py](#)

?? 36.16 | 4 | 计算 **最优贡献**。在截留的共祖水平下求最优贡献，核验 KKT、随机扰动与前沿。 [程序] [ch36/ex36_16_optimal_contribution.py](#)

?? 36.17 | 4 | 计算 **配种运输问题**。求整数配种方案，核验整数性、对偶与贪心、随机配种的比较。 [程序] [ch36/ex36_17_mating_transport.py](#)

?? 36.18 | 4 | 计算 **整数后代数**。比较取整、最大余数与带约束局部搜索，估计损失对 N 的阶数。 [程序] [ch36/ex36_18_integer_rounding.py](#)

36.19 ★★★ [计算] **不确定性与风险**。求均值—方差与 q_{10} 策略，校准预测概率，并比较信息均匀与不均。 [程序] [ch36/ex36_19_uncertainty_risk.py](#) [答案]

36.20 ★★★ [计算] **禁配网络的可行性**。用最大流与 Hall 条件判断可行性，核验对偶证据、次梯度不等式与解禁价值。 [程序] [ch36/ex36_20_forbidden_feasibility.py](#) [答案]

36.21 ★★ [计算] 最优贡献手算。两只同性别候选, $g = (1.0, 0.4)$, $A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$ 。令 $c = (c, 1 - c)$, 约束 $c'Ac \leq 0.85$ 。求最优 c 、最优遗传水平, 以及 $c'Ac$ 上限每放宽一个单位时遗传水平的增加 (影子价格)。

[答案]

36.22 ★★ [计算] 运输问题手算。两只公羊后代数 $n_s = (3, 1)$, 两只母羊 $n_d = (2, 2)$, 成本 $F = \begin{pmatrix} 0 & 0.125 \\ 0.125 & 0 \end{pmatrix}$ 。求最优配对数、平均近交系数、随机配种的期望近交系数、对偶变量与 x_{21} 的约化成本。

[答案]

五、推导与证明题

36.23 ★★ [证明] 证明: 设公羊份额 c_m (和为 $\frac{1}{2}$)、母羊份额 c_f (和为 $\frac{1}{2}$), 按份额随机配种时后代近交系数的期望为 $2c'_mAc_f$, 并证明 $\theta = \frac{1}{2}(c'_mAc_m + c'_fAc_f) + \frac{1}{2}E[F]$ 。

[答案]

36.24 ★★★ [证明] 写出最优贡献问题的拉格朗日函数与 KKT 条件, 并证明: 约束 $\theta \leq \theta_{\max}$ 不起作用时, 最优解把公、母全部分额分别给 g 最大的公羊与母羊。

[答案]

36.25 ★★★ [证明] 设 c^* 满足 KKT, $c = c^* + \delta$ 可行且不改变支撑集 (零份额个体仍为零)。证明 $L(c^*) - L(c) = \frac{\lambda}{2}\delta'A\delta \geq 0$, 从而取整的拉格朗日损失是 $O(1/N^2)$ 。

[答案]

36.26 ★★★ [证明] 证明运输问题有可行解当且仅当对每个公羊子集 S , $\sum_{s \in S} n_s \leq \sum_{d \in N(S)} n_d$ ($N(S)$ 为 S 的可配母羊集合), 并说明最大流的残量网络如何给出违反集合。

[答案]

六、综合分析与研究设计题

36.27 ★★ [综合] 为一个有 30 只候选公羊、200 只候选母羊的肉羊核心群设计“从 EBV 到配种计划”的完整决策流程, 列出每一步的输入、输出、核验与可审阅的材料。

[答案]

36.28 ★★★ [综合] 软件厂商宣称其优化器“找到了唯一最优配种方案”。写出评审意见, 指出需要核验的内容与应要求补充的材料。

[答案]

36.29 ★★★ [综合] 育种委员会在“生长优先”与“繁殖优先”之间无法达成一致。设计一份决策材料, 使委员会能在不被单一数字误导的情况下比较方案。

[答案]

36.6 参考答案与解析

一、单项选择题

- 36.1 (B)**。指数最高者可能来自同一家系、彼此高度相关。习题 36.16: 同样的群体共祖下, 最优贡献比截留的预测遗传水平高 0.141 (0.681 对 0.540)。 [题目]
- 36.2 (B)**。截留给入选者等份额, 最优贡献让份额成为变量, 并在共祖约束下最大化遗传水平 (推导 36.2)。 [题目]
- 36.3 (B)**。 $\theta = \frac{1}{2}c'Ac$ (c 总和为 1)。习题 36.16: 截留的 $\theta = 0.1234$ 。 [题目]
- 36.4 (B)**。运输问题的约束矩阵 (行和、列和) 全单模, 右端 n_s, n_d 为整数, 所以顶点解为整数。习题 36.17: LP 解为整数、行列和成立。 [题目]
- 36.5 (A)**。 λ 是共祖约束的乘子, 等于上限放宽一个单位时目标的边际增加 (影子价格)。习题 36.16: λ 平均 6.05; 前沿的斜率随 $\theta_{\max}$ 增大而下降。 [题目]
- 36.6 (C)**。一阶项由 KKT 抵消, 损失为 $\frac{\lambda}{2}\delta'A\delta = O(1/N^2)$ (证明 36.25)。习题 36.18: 对数-对数斜率 -2.00。 [题目]

二、判断与改错题

- 36.7 错误**。繁殖优先与生长优先得到不同方案是目标不同的正常结果。习题 36.15: 生长优先选择在繁殖优先权重下的 H 只有 0.182 (繁殖优先选择为 0.491)。 [题目]
- 36.8 正确**。习题 36.15: 生长优先与繁殖优先的亲本集合 Jaccard 重叠只有 0.475, 指数排名 Spearman 相关 0.380。 [题目]
- 36.9 错误**。禁配可能使 Hall 条件不成立。习题 36.20: 半同胞禁配下可行比例只有 0.430; 示例中违反集合的需求 37 个, 容量仅 32 个。 [题目]
- 36.10 错误**。在共祖约束起作用且 EBV 已收缩时, 效应很小。习题 36.19: 信息不均时 $\kappa = 1.2816$ 使预测 sd 仅下降 3.1%, 实现 $H < 0$ 频率变化 -0.007。 [题目]

三、填空题

- 36.11** $c'Ac = 0.25 \times 1 + 0.25 \times 1 + 2 \times 0.25 \times 0.5 = 0.75$; $\theta = 0.375$ 。 [题目]
- 36.12** $F = A_{sd}/2 = 0.25$ 。 [题目]

36.13 $37 - 32 = 5$ 个。

[题目]

36.14 $F_{sd} - u_s - v_d = 0.125 + 0.125 - 0 = 0.25 (\geq 0, \text{解禁不改善})$ 。

[题目]

四、计算题

36.15 结果见推导 36.1。(预测/实现响应, 生长、繁殖、胴体) 生长优先: 0.448/0.456、
-0.020/-0.039、0.403/0.422; 繁殖优先: 0.093/0.116、0.388/0.408、0.211/0.245;
均衡: 0.348/0.365、0.164/0.136、0.409/0.435。 H 实现值矩阵对角线最大。亲本集
合 Jaccard 0.475, 0.735, 0.643; 单位与缩放检验 200/200。解读: 目标不同, 选择不
同; 权重是价值判断, 必须由决策者给出并写入材料。

[题目]

36.16 结果见推导 36.2。预测遗传水平 $0.540 \rightarrow 0.681$, 实现 H $0.560 \rightarrow 0.716$, θ 均为
0.1234; 支撑集 9.4 只, 最大份额 0.253, $\lambda = 6.05$; KKT 残差 $\leq 1.5 \times 10^{-7}$; 扰动
改进 0/4000; 前沿 $0.904 \rightarrow 1.819$ 单调凹。解读: 约束越松, 边际收益越小。

[题目]

36.17 结果见推导 36.3。 $\bar{F}$: 随机 0.0510, 贪心 0.0241, LP 0.0122; 降低 76.0% 与 52.8%;
半同胞及更近配对占比 $0.376 \rightarrow 0.098$; 可行 98/100, 贪心可行 83。解读: 第二层
决策降低近交, 贪心不能保证可行。

[题目]

36.18 结果见推导 36.4。 N 依次取 10、20、40、100、400, 最大余数法的 $|\Delta g|$ 依次为 0.0198、
0.0091、0.0042、0.0017、0.0005; θ 超出量依次为 0.00259、0.00078、0.00043、0.00013、
0.00004; 拉格朗日损失依次为 0.006242、0.001645、0.000363、0.000060、0.000004。
对数-对数斜率分别为 -1.01 (一阶) 与 -2.00 (二阶)。局部搜索在 $N \leq 100$ 时可
行比例均为 1.00。解读: 取整后必须复查约束; 局部搜索以略高的拉格朗日损失换
取可行性。

[题目]

36.19 结果见推导 36.5。信息均匀: 预测 sd 0.318, 0.316, 0.314 ($\kappa = 0, 0.5, 1.2816$),
预测均值 0.659, 0.659, 0.656; 信息不均: 预测 sd 0.359, 0.354, 0.348, 预测均值
0.577, 0.575, 0.570, 实现 $H < 0$ 频率 0.167, 0.157, 0.160。覆盖率 0.870—0.903。解
读: 效应小但方向正确。

[题目]

36.20 结果见推导 36.6。可行比例: 全同胞 0.985, 半同胞 0.430, 全同胞 + 随机 40% 0.365;
Hall 违反在全部不可行情形成立 (3/3, 114/114, 127/127); 强对偶差 $< 10^{-7}$; 次
梯度 64/64; 解禁价值与约化成本符号一致 28/28 (负约化成本 8 个)。

[题目]

36.21 $c'Ac = c^2 + (1 - c)^2 + c(1 - c) = 1 - c + c^2 \leq 0.85$, 即 $c^2 - c + 0.15 \leq 0$,
 $c \in [0.1838, 0.8162]$ 。 $g'c = 0.4 + 0.6c$ 在 $c = 0.8162$ 取最大, 0.8897 (无约束时 $c = 1$,

$g = 1$)。影子价格: $dg/db = 0.6/(2c - 1) = 0.6/0.6325 = 0.949$ 每单位 $c'Ac$ 。解读: 约束起作用, 每放宽 0.01 的 $c'Ac$, 遗传水平约增加 0.0095。【题目】

36.22 设 $x_{21} = t$: $x_{22} = 1 - t$, $x_{11} = 2 - t$, $x_{12} = 1 + t$, 成本 $0.125(1 + 2t)$, $t \in [0, 1]$, 最小在 $t = 0$: $x = (\frac{2}{0} \frac{1}{1})$, 总成本 **0.125**, 平均近交系数 $0.125/4 = 0.03125$ 。随机配种: $(3 \cdot 2 \cdot 0 + 3 \cdot 2 \cdot 0.125 + 1 \cdot 2 \cdot 0.125 + 1 \cdot 2 \cdot 0)/16 = 0.0625$ (LP 降低 50%)。基变量 x_{11}, x_{12}, x_{22} : $u_1 + v_1 = 0$, $u_1 + v_2 = 0.125$, $u_2 + v_2 = 0$, 取 $u_1 = 0$: $v_1 = 0$, $v_2 = 0.125$, $u_2 = -0.125$ 。对偶目标 $3 \times 0 + 1 \times (-0.125) + 2 \times 0 + 2 \times 0.125 = 0.125$ (强对偶)。 x_{21} 的约化成本 $0.125 - (u_2 + v_1) = 0.25 \geq 0$ 。影子价格: 给公羊 2 与母羊 1 各多一个后代, 成本变化 $u_2 + v_1 = -0.125$ (新问题成本为 0)。【题目】

五、推导与证明题

36.23 证明。按份额随机配种: 公羊 s 与母羊 d 配对的概率 $2c_s \cdot 2c_d$ (公、母份额各和为 $\frac{1}{2}$, 所以 $2c$ 是各自的概率), 后代近交系数 $A_{sd}/2$ 。 $E[F] = \sum_{s,d} 4c_s c_d \cdot A_{sd}/2 = 2c'_m A c_f$ 。又 $c'Ac = c'_m A c_m + c'_f A c_f + 2c'_m A c_f$, 所以 $\theta = \frac{1}{2}(c'_m A c_m + c'_f A c_f) + c'_m A c_f = \frac{1}{2}(\dots) + \frac{1}{2}E[F]$ 。数值: $c_m = (0.5, 0)$, $c_f = (0, 0.5)$, $A_{12} = 0.5$: $E[F] = 2 \times 0.25 \times 0.5 = 0.25$ (习题 36.12: 全同胞)。■【题目】

36.24 证明。 $\mathcal{L} = g'c - \lambda(\frac{1}{2}c'Ac - \theta_{\max}) - \mu_m(c'_m \mathbf{1} - \frac{1}{2}) - \mu_f(c'_f \mathbf{1} - \frac{1}{2}) + \nu'c$, KKT: $g_i - \lambda(Ac)_i - \mu_{\text{sex}(i)} + \nu_i = 0$, $\lambda \geq 0$, $\nu_i \geq 0$, $\lambda(\theta - \theta_{\max}) = 0$, $\nu_i c_i = 0$ 。若 $\theta \leq \theta_{\max}$ 不起作用, $\lambda = 0$: $g_i + \nu_i = \mu_{\text{sex}(i)}$ 。 $c_i > 0$ 的 $\nu_i = 0$, 故 $g_i = \mu$, 同性别内所有有份额者 g 相同; $c_i = 0$ 的 $g_i \leq \mu$ 。所以份额只能分给 g 最大的个体 (g 相同时可任意分配)。这就是无约束时“全给最优者”的线性规划解。数值: 习题 36.21 中 $c = 1$ ($g = 1$) 在 $\theta = 1/2$ 对应 $c'Ac = 1 > 0.85$, 约束起作用。■【题目】

36.25 证明。 $L(c) = g'c - \lambda(\frac{1}{2}c'Ac - \theta_{\max})$ 是二次函数: $L(c^* + \delta) = L(c^*) + (g - \lambda A c^*)' \delta - \frac{\lambda}{2} \delta' A \delta$ 。由 KKT, 支撑集上 $g - \lambda A c^* = \mu_{\text{sex}(i)}$, δ 不改变支撑集且同性别份额和不变, 一次项为 $\mu_m \mathbf{1}' \delta_m + \mu_f \mathbf{1}' \delta_f = 0$ 。所以 $L(c^*) - L(c) = \frac{\lambda}{2} \delta' A \delta \geq 0$ (A 半正定)。整数化 $\delta = O(1/N)$, 故损失 $O(1/N^2)$ 。收益与约束违反各含一阶项 $g' \delta$ 、 $c^* A \delta$, 所以是 $O(1/N)$ 。数值: 习题 36.18: $N = 40 \rightarrow 400$, 拉格朗日损失 $0.000363 \rightarrow 0.000004$ (约 $1/100$)。■【题目】

36.26 证明。必要性: S 的公羊共需 $\sum_S n_s$ 个后代, 只能来自 $N(S)$ 中的母羊, 其容量 $\sum_{N(S)} n_d$, 故必须不小于需求。充分性: 构造网络: 源点 $\rightarrow$ 公羊 (容量 n_s) $\rightarrow$ 可配母羊 (容量 ∞) $\rightarrow$ 汇点 (容量 n_d)。可行等价于最大流 $= \sum n_s = \sum n_d = N$ 。由最大流—最小割定理, 若最大流 $< N$, 存在容量 $< N$ 的割 $(\mathcal{S}, \mathcal{T})$; 设 $S = \mathcal{S} \cap$ 公

羊。无穷容量弧不能被割，所以 $N(S) \subseteq \Delta$ ，割容量 $= \sum_{s \notin S} n_s + \sum_{d \in N(S)} n_d < N$ ，即 $\sum_S n_s > \sum_{N(S)} n_d$ ，得到违反集合。因此无违反集合时最大流为 N 。残量网络中从源点可达的公羊集合就是 S 。数值：习题 36.20 的示例需求 $37 > 32$ 。■ [题目]

六、综合分析与研究设计题

36.27 流程 (1) **输入与口径**：EBV 与 PEV 矩阵（第 35 章）、系谱关系 A 、经济权重（每遗传标准差的价值）及其依据、禁配规则、后代总数、共祖上限。(2) **目标情景**：至少三套权重（如生长优先、繁殖优先、均衡），并列给出各情景的亲本集合与各性状响应（习题 36.15：重叠 0.475—0.735）。(3) **最优贡献**：以当前截留方案的共祖为基准设上限；输出份额、 θ 、乘子 λ 与前沿（习题 36.16：KKT 与扰动核验）。(4) **整数化与配种**：最大余数法取整后复查约束；运输 LP 配对，禁配先做最大流可行性检验，输出对偶价格（习题 36.17、36.18、36.20）。(5) **不确定性**：用 $c'Pc$ 报告预测区间与 q_{10} ，如实说明风险项的小效应（习题 36.19）。(6) **审阅材料**：参数、种子、软件版本、全部情景的数值与差异、被禁配对的解禁价值、一页决策摘要。(7) **监测**：下一代出生后，用实现值检验预测与近交的偏差。 [题目]

36.28 评审意见 (1) “唯一最优”依赖目标、权重与约束，三者都是价值判断：习题 36.15 中不同权重的亲本集合重叠只有 0.475—0.735。(2) 要求核验：KKT 条件（习题 36.16：残差 $\leq 1.5 \times 10^{-7}$ ）、随机扰动无改进、前沿的单调与凹性、是否存在多个等价解。(3) 要求说明取整后是否违反约束（习题 36.18：最大余数法约一半的群体违反）。(4) 要求报告禁配网络的可行性检验与对偶价格（习题 36.20：半同胞禁配下仅 43% 可行）。(5) 要求报告不确定性（习题 36.19：预测区间与风险项的实际效应，仅小幅降低）。(6) 要求提供参数范围内的稳健性，而不是单点解。结论：软件可以给出“在所述目标与约束下的最优解”，不能称为“唯一最优”。 [题目]

36.29 决策材料 (1) 并列展示“生长优先”“繁殖优先”“均衡”三案的亲本名单、份额、 θ 与近交，各性状响应与综合目标 H 的交叉评价矩阵（习题 36.15：对角线最大，生长优先在繁殖权重下 0.182 对繁殖优先 0.491）。(2) 给出前沿与影子价格：为多获得 x 的生长响应需要放弃多少繁殖响应（权衡曲线），以及放宽共祖上限的边际收益 λ 。(3) 给出不确定性：各方案的预测区间与下尾概率，如实写明风险项效应小。(4) 给出参数范围：权重在合理区间（如生长权重 0.4—1.0）内最优方案的稳定性。(5) 给出可行性与代价：禁配规则下的可行性与解禁价值。(6) 不使用单一数字决策；用一页图表让委员会选择权衡点，并写明选择依据与复评日期。 [题目]

模型诊断、失败分析与可检验的研究设计

37.1 本章导学

学习目标

1. 按“因果距离与检查成本”组织诊断：先查身份、时间、单位，再查矩阵与参数化，随后查残差、校准与预测分布，最后才讨论复杂遗传架构；并区分探索性诊断与最终评估。

2. 理解拟合后的条件残差不再独立同分布：方差为 $\sigma_e^2(1-h_i)$ ，同家系残差负相关，会用学生化残差作异常检测。

3. 理解“相关很高而校准很差”：线性变换不改变相关，却使斜率、RMSE 与区间覆盖率崩塌，并会评价斜率检验的功效。

4. 理解方差分量的边界估计：零估计的频率可由 F 分布给出，弱信息下的估计既偏又散。

5. 会设计无信号负对照来发现预处理泄漏，会用稳健似然 (t-IRLS) 处理异常值与重尾残差。

6. 会把方法想法写成可证伪的研究问题，并分别规划蒙特卡洛精度、检验功效与等效性，会用按家系的自助法处理相关个体的标准误。

重点与难点

重点：条件残差 $r = \sigma_e^2 P y$, $\text{Var}(r) = \sigma_e^4 P$, $h_i = 1 - \sigma_e^2 P_{ii}$; $\hat{u}' = b\hat{u}$ 的相关不变、斜率为 $1/b$; 零估计概率 $P(F_{s-1,s(k-1)} < 1/(1+k\rho))$; 筛选泄漏下 $E[\text{sign}(c_{all})c_{va}] = E[c_{all} \text{vert}]$; 三个样本量公式 n_1, n_2, n_3 。

难点：随机波动、系统偏差与计算错误要分开；有限样本的偏离不等于模型错误；探索性修改会消耗验证集的独立性；功效、精度与等效性回答的是三个不同的问题。

本章承接第 34—36 章。那三章分别讨论了数据的可追溯、BLUP 与 GBLUP 的对照，以及决策链；本章问的是：当结果不理想，或者当我们要用实验去回答一个方法问题，怎样诊断、怎样设计、怎样诚实地报告。每一个诊断量都对应一个可复算的小实验，每一个“规则”都配有它失败时的证据。

37.2 知识结构图




图 37.1 第 37 章知识结构图

左侧是“错误层次与残差”，中部是“校准、方差与泄漏”，右侧是“稳健、验证与研究设计”。

37.3 核心概念与公式速览

概念	公式或定义	成立条件与提示
条件残差	$r = \sigma_e^2 P y$	$P = V^{-1} - V^{-1} X(\cdot)^{-1} X' V^{-1}$
杠杆量	$h_i = 1 - \sigma_e^2 P_{ii}$	$E(r_i^2) = \sigma_e^2 (1 - h_i)$
学生化残差	$r_i / \sqrt{\sigma_e^2 (1 - h_i)}$	方差为 1
线性变换	$\hat{u}' = a + b \hat{u}$	相关不变，斜率 $1/b$
零估计概率	$P(F < 1/(1 + k\rho))$	平衡公畜模型
筛选泄漏	筛选用了验证表型	无信号下 $r > 0$
t-IRLS	$w_i = (\nu + 1)/(\nu + r_i^2/\sigma_e^2)$	重尾与污染
样本量	n_1, n_2, n_3	精度、功效、等效

37.4 补充内容与公式推导

推导 37.1 拟合后的残差不再独立：杠杆量、负相关与学生化

公畜模型 $y_{ij} = \mu + s_i + e_{ij}$ (12 头公畜 $\times$ 6 个子代, $\sigma_s^2 = 1$, $\sigma_e^2 = 3$)。以真实方差拟合 BLUP, 条件残差 $r = y - X\hat{b} - Z\hat{u} = \sigma_e^2 P y$, $\text{Var}(r) = \sigma_e^4 P$ (因为 $PVP = P$, 证明 37.23), 杠杆量 $h_i = 1 - \sigma_e^2 P_{ii}$ 。习题 37.15 (蒙特卡洛 20000 次): 杠杆量 $h_i = 0.1157$ (平衡设计下各记录相同), $\sum_i h_i = 8.333$ ($= 1 +$ 公畜有效自由度 7.333); $E(r_i^2)/\sigma_e^2$ 的理论值 $1 - h = 0.8843$, 模拟均值 0.8843。同公畜子代残差的相关理论 -0.1309 , 模拟 -0.1322 ; 不同公畜 -0.0052 对 -0.0023 。标准化残差的方差: 朴素 r/σ_e 为 0.8843 (偏小, 看起来“太整齐”), 学生化 $r/\sqrt{\sigma_e^2(1 - h_i)}$ 为 1.0000。加入 $4\sigma_e$ 的异常偏移后, $|z| > 3$ 的检出概率: 朴素 0.715, 学生化 0.776; 无异常时 $|z| > 3$ 的频率: 朴素 0.00139, 学生化 0.00267 (学生化更接近正态的 0.0027)。**拟合会把一部分误差吸收到固定与随机效应里, 所以条件残差的方差小于 σ_e^2 , 同公畜的残差还互相负相关; 诊断要使用学生化残差, 而不是把残差当作独立的噪声。**

推导 37.2 相关很高仍可能严重失真

把 GBLUP 的 EBV 变换为 $\hat{u}' = a + b\hat{u}$: 相关系数对任意 $a, b > 0$ 不变, 但校准斜率 (u 对 $\hat{u}'$ 的回归) 变为 $1/b$ 。习题 37.16 (80 只候选, 200 次重复; 覆盖率沿用原 PEV):

b	相关	校准斜率	$1/b$	RMSE	90% 覆盖率	“斜率 = 1” 检验拒绝率
0.5	0.673	1.954	2.000	0.782	0.870	0.920
1	0.673	0.977	1.000	0.712	0.905	0.125
1.5	0.673	0.651	0.667	0.794	0.867	0.970
2	0.673	0.488	0.500	0.990	0.770	1.000
3	0.673	0.326	0.333	1.535	0.558	1.000

$b = 3$ 时相关仍为 0.673, 但 RMSE 是 $b = 1$ 的 2.2 倍, 覆盖率只有 0.558。平移 +0.8: 相关不变 (0.673), 校准截距 -0.787 , RMSE 由 0.712 增到 1.072。给每个父系半同胞家系加上 $N(0, 0.5^2)$ 的家系偏差: 相关由 0.673 降到 0.537, 家系平均残差的标准差 0.630。斜率检验在 $b = 1.5$ 的功效 0.970; 但在 $b = 1$ (斜率正确) 时拒绝率为 0.125, 高于名义的 0.05——候选之间有亲缘, 误差不独立, 朴素 t 检验偏激进 (见推导 37.6)。**只报告相关, 无法发现尺度、平移与家系偏差。**

推导 37.3 无信号负对照揭示预处理泄漏

流程：按与表型的相关选前 20 个 SNP（共 500 个），再对所选 SNP 做岭回归 ($\lambda = 10$)，在 100 个验证个体上报告预测相关 r 。正确做法的筛选只用训练个体（150 个），泄漏做法的筛选用了全部 250 个个体（含验证表型）。习题 37.17（300 次重复，均值 $\pm$ 标准误）：

情景	正确流程 r	泄漏流程 r
无信号	-0.008 ± 0.006	0.462 ± 0.004
有信号（20 个因果位点， $h^2 = 0.4$ ）	0.337 ± 0.006	0.621 ± 0.003

没有任何信号时，泄漏流程“预测”出 $r = 0.462$ 。原因（证明 37.25）：无信号时 $E[\text{sign}(c_{all})c_{va}] = E[c_{all}vert] > 0$ ，筛选用了验证表型，所选 SNP 与验证表型的相关被系统地选成正的；而只用训练个体筛选时该期望为 0。**负对照**：把表型整体置换后重跑完整流程（40 个数据集 $\times$ 20 次置换），正确流程的平均 $r = -0.008$ ，判定为“泄漏”的比例 0（无假警报）；泄漏流程的平均 $r = 0.461$ ，检出率 1.000。有信号时泄漏使 r 从 0.337 虚高到 0.621（ $+0.284$ ）。任何一个完整流程都应当附一个“无信号”的对照实验：信号被破坏后，结果必须回到零。

推导 37.4 方差分量落在边界：弱信息下的零估计

平衡公畜模型 (s 头公畜 $\times k = 10$ 个子代, $\sigma_s^2 + \sigma_e^2 = 1$)。REML 的闭式解 $\hat{\sigma}_e^2 = \text{MSW}$, $\hat{\sigma}_s^2 = \max\{0, (\text{MSB} - \text{MSW})/k\}$ 。 $F = \text{MSB}/\text{MSW} \sim (1 + k\rho)F_{s-1, s(k-1)}$, $\rho = \sigma_s^2/\sigma_e^2$, 所以 $P(\text{边界}) = P(F_{s-1, s(k-1)} < 1/(1 + k\rho))$ （证明 37.26）。习题 37.18（蒙特卡洛 6000 次）：

h^2	s	零估计频率 MC / 理论	$E(\hat{\sigma}_s^2) /$ 真值	$\hat{h}^2$ 均值	$\hat{h}^2$ 90% 区间	准确度 (估计 / 已知)
0.1	10	0.373 / 0.379	0.0376 / 0.0250	0.147	[0.00, 0.52]	0.302 / 0.426
0.1	50	0.162 / 0.163	0.0271 / 0.0250	0.108	[0.00, 0.28]	0.388 / 0.451
0.1	100	0.071 / 0.075	0.0256 / 0.0250	0.102	[0.00, 0.22]	0.422 / 0.451
0.3	10	0.172 / 0.168	0.0801 / 0.0750	0.309	[0.00, 0.83]	0.559 / 0.644

0.3	50	0.007 / 0.006	0.0739 / 0.0750	0.294	[0.09, 0.52]	0.658 / 0.662
-----	----	------------------	--------------------	-------	--------------	------------------

$h^2 = 0.1$ 、10 头公畜时，37% 的数据集得到“遗传方差为零”（理论 0.379）；此时所有公畜的 EBV 全为零，评定完全没有区分度。截断使 $\hat{\sigma}_s^2$ 的均值偏高（0.0376 对 0.0250）， $\hat{h}^2$ 的 90% 区间宽达 [0, 0.52]。用估计的方差作 BLUP，公畜的准确度由 0.426 降到 0.302 ($h^2 = 0.1, s = 10$)。零估计不是“真值为零”的证据，而是“这份资料不足以估计”的信号：应当报告区间、增加信息或引入先验，而不是把零当作结果。

推导 37.5 非高斯残差与极端值：BLUP 的敏感性与 t-IRLS

GBLUP（80 只候选，训练 200 只，100 次重复）。残差：高斯；5% 记录被污染（加 $\pm 8\sigma_e$ ）； t_3 残差（方差与高斯相同）。方法：BLUP；“删除法”（学生化残差 $|z| > 3$ 的记录先删除）；t-IRLS（权重 $w_i = (\nu + 1)/(\nu + r_i^2/\sigma_e^2)$ ， $\nu = 4$ ，残差方差 σ_e^2/w_i ）。习题 37.19（相关 / RMSE）：

残差	BLUP	删除法	t-IRLS	删除数	最小权重
高斯	0.671 / 0.708	0.666 / 0.713	0.666 / 0.713	0.5	0.391
5% 污染	0.455 / 1.004	0.647 / 0.728	0.643 / 0.732	12.0	0.055
t_3	0.671 / 0.717	0.702 / 0.687	0.715 / 0.677	2.0	0.217

高斯数据下 t-IRLS 几乎无损失（相关差 0.005）；污染数据下 BLUP 的相关由 0.671 暴跌到 0.455，RMSE 由 0.708 升到 1.004，t-IRLS 恢复到 0.643（RMSE 0.732）； t_3 残差下 t-IRLS 最好（0.715）。单个 $+10\sigma_e$ 的异常记录：BLUP 使该个体的 EBV 变化 3.417，同父半同胞平均变化 0.341；t-IRLS 分别为 0.429 与 0.044，异常值通过关系矩阵传给亲属，稳健似然把影响限制在该记录自身附近。

推导 37.6 功效、精度、等效性与相关个体的标准误

以 G-A 的成对相关差为例，用 40 次重复估计成对差的均值 0.147 与标准差 $\sigma_d = 0.0572$ 。三个样本量回答三个不同的问题（习题 37.20）：（1）精度：95% 区间半宽 ≤ 0.01 ， $n_1 = \lceil (1.96\sigma_d/0.01)^2 \rceil = 126$ ；（2）功效：检出 $\delta = 0.05$ ($\alpha = 0.05$ ，功效 0.8)，正态近似 $n_2 = 11$ ，非中心 t 精确 $n'_2 = 13$ ；（3）等效：真差为 0、边界 ± 0.03 (TOST，功效 0.8)： $n_3 = 32$ 。蒙特卡洛核验（4000 次）：按 n_1 实现的半宽 0.0101（目标 0.01）；按 $n_2 = 11$ 实施的功效只有 0.733，按 $n'_2 = 13$ 为 0.829；按 n_3 的 TOST 功

效 0.785。小样本下正态近似偏乐观；检出一个大效应只需十几次重复，但要把差估计到 0.01 需要上百次。

相关个体的标准误：120 个独立群体中，验证相关的真标准误（群体间标准差）为 0.0674；朴素 Fisher z 标准误（假设个体独立）平均 0.0601（低估 11%）；按父系家系的自助法平均 0.0667（偏差 1%）。候选间有亲缘时，朴素标准误偏低，应把家系作为重抽样单位。

延伸阅读：预注册与失败条件

可证伪的研究问题应在看到结果之前写明：比较对象、指标、重复数与种子、功效或精度目标、等效边界，以及“方法失败”的判据（例如成对差的 95% 区间下限 ≤ 0 、校准斜率超出 $[0.8, 1.2]$ 、负对照 r 显著大于 0）。探索性分析与最终评估使用不同的数据：开发阶段允许反复修改，最终的外部批次只用一次。报告时把所有设定下的结果（含表现最差的重复）完整列出。

常见误区

1. 用一次 80 只验证动物的覆盖率偏离 0.9 就断言区间错误。
2. 把拟合后的残差当作独立同分布。
3. 只报告相关系数。
4. 筛选、标准化、调参使用了验证集的表型。
5. 把零方差估计当作“遗传方差为零”。
6. 用一个样本量公式同时回答精度、功效与等效。
7. 个体有亲缘时仍用独立个体的标准误。
8. 不断根据验证结果修改模型，却仍把该验证集当作独立检验。

37.5 习题

一、单项选择题

37.1 ★ [单选] 评定结果不理想时，下列检查顺序最合理的是

- (A) 先加更复杂的遗传模型
- (B) 先查身份、时间与单位，再查矩阵与参数，再查残差与校准
- (C) 先调整验证集
- (D) 先删除异常值

[答案]

37.2 ★ [单选] BLUP 拟合后, 同一公畜的子代条件残差之间

- (A) 独立 (B) 略呈负相关 (C) 完全相关 (D) 无法确定

[答案]

37.3 ★★ [单选] 某模型的 EBV 与真值相关 0.9, 但真值对 EBV 的回归斜率为 0.5, 说明

- (A) EBV 过度收缩 (B) EBV 过度分散 (幅度偏大)
(C) 相关系数有误 (D) 区间覆盖率过高

[答案]

37.4 ★★ [单选] 把表型置换后重跑完整流程, 验证相关显著大于 0, 说明

- (A) 方法很稳健 (B) 流程中存在泄漏 (C) 样本量太小
(D) 信号很强

[答案]

37.5 ★★ [单选] REML 估计出公畜方差为 0, 最合适的解读是

- (A) 真实遗传方差为零
(B) 资料信息不足以估计, 应报告区间或增加信息
(C) 软件出错 (D) 应删除该性状

[答案]

37.6 ★★★ [单选] “检出差 δ 需要多少重复” 与 “把差估计到半宽 w 需要多少重复”

- (A) 是同一个问题 (B) 是不同的问题, 需要分别规划
(C) 前者总是更大 (D) 后者总是更小

[答案]

二、判断与改错题

37.7 ★ [判断] 一次 80 只验证动物的区间覆盖率为 85%, 已经足以证明预测区间错误。

[答案]

37.8 ★ [判断] 学生化残差应除以 $\sqrt{\sigma_e^2(1-h_i)}$, 而不是 σ_e 。

[答案]

37.9 ★★ [判断] 只要相关系数很高, 就不需要再检查校准斜率与区间覆盖率。

[答案]

37.10 ★★ [判断] 候选个体有亲缘时, 朴素 Fisher z 标准误往往偏低。

[答案]

三、填空题

37.11 ★ [填空] 杠杆量 $h_i = 1/6$, $\sigma_e^2 = 3$, $E(r_i^2) = \underline{\hspace{2cm}}$ 。 [答案]

37.12 ★ [填空] 把 EBV 乘以 2 ($b = 2$) 后, 总体意义上的校准斜率为 $\underline{\hspace{2cm}}$ 。 [答案]

37.13 ★★ [填空] $\sigma_d = 0.06$, 要使 95% 区间半宽 ≤ 0.02 , 至少需要 $\underline{\hspace{2cm}}$ 次重复 (正态近似)。 [答案]

37.14 ★★ [填空] 平衡公畜模型 $k = 10$, $MSB = 5.0$, $MSW = 2.0$, $\hat{\sigma}_s^2 = \underline{\hspace{2cm}}$, $\hat{h}^2 = 4\hat{\sigma}_s^2/(\hat{\sigma}_s^2 + \hat{\sigma}_e^2) = \underline{\hspace{2cm}}$ (三位小数)。 [答案]

四、计算题

?? 37.15 | 4 | 计算 **残差的依赖结构**。蒙特卡洛核验条件残差的方差、杠杆量与同公畜相关, 并比较朴素与学生化残差的异常检出。 [程序] `ch37/ex37_15_residual_dependence.py`

?? 37.16 | 4 | 计算 **相关很高仍失准**。对 EBV 作尺度、平移与家系偏差的变换, 报告相关、斜率、RMSE、覆盖率及斜率检验的功效。 [程序] `ch37/ex37_16_high_cor_miscalibrated.py`

?? 37.17 | 4 | 计算 **负对照与泄漏**。比较正确与泄漏的筛选流程在无信号与有信号下的相关, 并用置换对照检测泄漏。 [程序] `ch37/ex37_17_negative_control_leakage.py`

?? 37.18 | 4 | 计算 **方差分量的边界**。比较零估计频率的蒙特卡洛与 F 分布理论, 并评价估计方差对准确度的影响。 [程序] `ch37/ex37_18_variance_boundary.py`

37.19 ★★★ [计算] 稳健处理。比较 BLUP、删除法与 t-IRLS 在高斯、污染与重尾残差下的表现, 并量化单个异常的影响。 [程序] `ch37/ex37_19_nonnormal_robust.py` [答案]

37.20 ★★★ [计算] 功效、精度、等效与相关个体的标准误。规划三类样本量并用蒙特卡洛核验, 比较朴素与按家系的标准误。 [程序] `ch37/ex37_20_power_precision_cluster.py` [答案]

37.21 ★★ [计算] 残差手算。一头公畜有 $k = 3$ 个记录, 总体均值已知为 0, $\sigma_s^2 = 1$, $\sigma_e^2 = 3$, 记录 $y = (4, 1, 1)'$ 。求 $\hat{s}$ 、条件残差、杠杆量、条件残差的方差与相关, 以及第一条记录的朴素与学生化标准化残差。 [答案]

37.22 ★★ [计算] 样本量手算。 $\sigma_d = 0.06$ (成对相关差的标准差)。求 (1) 半宽 ≤ 0.02 的重复数; (2) 检出 $\delta = 0.04$ (双侧 $\alpha = 0.05$, 功效 0.8) 的重复数; (3) 等效边界 ± 0.03 (TOST, $\alpha = 0.05$, 功效 0.8, 真差 0) 的重复数 (均用正态近似, 向上取整)。 [答案]

五、推导与证明题

37.23 ★★ [证明] 设 $y = Xb + Zu + e$, $V = \text{Var}(y)$ 。证明 BLUP 拟合后的条件残差 $r = \sigma_e^2 P y$, 并证明 $PVP = P$, 从而 $\text{Var}(r) = \sigma_e^4 P$ 。 [答案]

37.24 ★★★ [证明] 设 $\hat{u}' = a + b\hat{u}$ ($b > 0$), u 对 $\hat{u}'$ 的回归斜率为 β' 。证明 $\text{corr}(u, \hat{u}') = \text{corr}(u, \hat{u})$, $\beta' = \beta/b$; 并说明 BLUP 的 $\beta = 1$ 的含义。 [答案]

37.25 ★★★ [证明] 无信号时, 设训练与验证个体各自的 SNP-表型相关 $c_{tr} \sim N(0, 1/n_{tr})$ 、 $c_{va} \sim N(0, 1/n_{va})$ 独立, 全体相关 $c_{all} = (n_{tr}c_{tr} + n_{va}c_{va})/n$ 。证明 $E[\text{sign}(c_{all})c_{va}] = E[c_{all} \text{vert}] > 0$, 而 $E[\text{sign}(c_{tr})c_{va}] = 0$ 。 [答案]

37.26 ★★★ [证明] 证明平衡公畜模型中 $\text{MSB}/\text{MSW} \sim (1 + k\rho)F_{s-1, s(k-1)}$, 并由此写出 REML 估计落在边界 $\hat{\sigma}_s^2 = 0$ 的概率。 [答案]

六、综合分析与研究设计题

37.27 ★★ [综合] 某牧场报告“某父系家系的女儿长期被高估”。列出至少四种可区分的候选解释, 并为每一种设计可证伪的检查。 [答案]

37.28 ★★★ [综合] 一篇论文报告某基因组预测方法的验证相关为 0.82, 并称其“明显优于传统方法”。写出评审意见: 需要补充哪些诊断 (校准、泄漏、标准误、重复)。 [答案]

37.29 ★★★ [综合] 设计一项比较 GBLUP 与系谱 BLUP 的预注册模拟研究: 问题、因素、重复数、种子、精度/功效/等效目标、负对照、失败条件与报告内容。 [答案]

37.6 参考答案与解析

一、单项选择题

37.1 (B)。先查离记录事实最近、成本最低的环节 (身份、时间、单位), 再查矩阵与参数, 再查残差与校准; 先上复杂模型会掩盖资料错误 (第 34 章)。 [题目]

37.2 (B)。条件残差的协方差 $\sigma_e^4 P$ 在同公畜内为负。习题 37.15: 同公畜子代残差相关理论 -0.1309 , 模拟 -0.1322 。 [题目]

37.3 (B)。 u 对 $\hat{u}$ 的斜率 < 1 表示 EBV 过于分散。习题 37.16: $b = 2$ 时斜率 0.488, 相关仍为 0.673, 覆盖率 0.770。 [题目]

37.4 (B)。信号被破坏后结果必须回到零。习题 37.17: 泄漏流程置换后平均 $r = 0.461$, 检出率 1.000; 正确流程 -0.008 , 假警报 0。 [题目]

37.5 (B)。零是边界估计, 不等于真值为零。习题 37.18: $h^2 = 0.1$ 、10 头公畜时 37% 的数据集给出零估计 (理论 0.379)。 [题目]

37.6 (B)。习题 37.20: 精度 $n_1 = 126$ 、功效 $n'_2 = 13$ 、等效 $n_3 = 32$, 三个数字不同, 回答三个问题。 [题目]

二、判断与改错题

37.7 错误。一次小样本的覆盖率有抽样波动 (80 只、名义 0.9 时标准误约 0.034, 且亲缘使其更大)。习题 35.15 中单次重复的覆盖率标准差为 0.036; 需要多次重复持续偏离才构成证据。 [题目]

37.8 正确。条件残差方差是 $\sigma_e^2(1 - h_i)$ 。习题 37.15: 朴素标准化的方差 0.8843, 学生化 1.0000。 [题目]

37.9 错误。相关对线性变换不变。习题 37.16: $b = 3$ 时相关仍为 0.673, RMSE 1.535, 覆盖率 0.558。 [题目]

37.10 正确。习题 37.20: 真标准误 0.0674, 朴素 0.0601, 家系自助法 0.0667。 [题目]

三、填空题

37.11 $E(r_i^2) = \sigma_e^2(1 - h_i) = 3 \times (5/6) = 2.5$ 。 [题目]

37.12 总体斜率为 $1/b = 0.5$ 。 [题目]

37.13 $n = (1.96 \times 0.06/0.02)^2 = 34.57$, 向上取整 35 次。 [题目]

37.14 $\hat{\sigma}_s^2 = (5.0 - 2.0)/10 = 0.300$; $\hat{h}^2 = 4 \times 0.3/(0.3 + 2.0) = 1.2/2.3 = 0.522$ 。 [题目]

四、计算题

37.15 结果见推导 37.1。杠杆量 0.1157; $\sum h_i = 8.333$; $E(r_i^2)/\sigma_e^2$ 理论与模拟 0.8843; 同公畜相关 -0.1309 与 -0.1322 ; 朴素标准化方差 0.8843, 学生化 1.0000; 加入 $4\sigma_e$

异常后检出概率 0.715 (朴素) 与 0.776 (学生化)。解读: 条件残差并不独立同分布, 学生化才使方差回到 1。 [题目]

37.16 结果见推导 37.2。相关均为 0.673; $b = 0.5, 0.75, 1, 1.5, 2, 3$ 的校准斜率 1.954、1.303、0.977、0.651、0.488、0.326; RMSE 0.782、0.729、0.712、0.794、0.990、1.535; 覆盖率 0.870、0.899、0.905、0.867、0.770、0.558; 斜率检验拒绝率 0.920、0.490、0.125、0.970、1.000、1.000。平移 +0.8: 截距 -0.787, RMSE 1.072; 家系偏差: 相关 0.537。 [题目]

37.17 结果见推导 37.3。无信号: 正确 -0.008, 泄漏 0.462; 有信号: 0.337 与 0.621。置换对照: 正确流程平均 -0.008, 假警报 0.000; 泄漏流程 0.461, 检出 1.000。 [题目]

37.18 结果见推导 37.4。零估计频率 (MC/理论): $h^2 = 0.1: s = 10, 20, 50, 100$ 为 0.373/0.379、0.284/0.290、0.162/0.163、0.071/0.075; $h^2 = 0.3: 0.172/0.168, 0.070/0.066, 0.007/0.006, 0.000/0.000$ 。准确度 (估计/已知) $h^2 = 0.1, s = 10: 0.302/0.426; h^2 = 0.3, s = 100: 0.668/0.668$ 。 [题目]

37.19 结果见推导 37.5。5% 污染下 BLUP 的相关 0.455 (RMSE 1.004)、删除法 0.647、t-IRLS 0.643 (0.732); t_3 下 0.671、0.702、0.715; 单个异常: BLUP 3.417 (半同胞 0.341), t-IRLS 0.429 (0.044)。运行时间约 25 秒。 [题目]

37.20 结果见推导 37.6。 $\sigma_d = 0.0572$, 均值 0.147; $n_1 = 126, n_2 = 11$ (精确 13), $n_3 = 32$; MC: 半宽 0.0101, 功效 0.733 (n_2) 与 0.829 (n'_2), TOST 0.785。标准误: 真 0.0674, 朴素 0.0601, 家系自助法 0.0667。 [题目]

37.21 $\bar{y} = 2, \hat{s} = k\sigma_s^2\bar{y}/(k\sigma_s^2 + \sigma_e^2) = 3 \times 2/6 = 1$ 。条件残差 $r = y - \hat{s} = (3, 0, 0)'$ 。 $V = J + 3I, P = V^{-1} = \frac{1}{3}(I - \frac{1}{6}J), P_{jj} = 5/18$, 杠杆量 $h = 1 - 3 \times 5/18 = 1/6$ 。 $\text{Var}(r) = 9P$: 对角 2.5, 非对角 -0.5, 相关 $-0.5/2.5 = -0.2$ 。第一条记录: 朴素 $z = 3/\sqrt{3} = 1.732$, 学生化 $z = 3/\sqrt{2.5} = 1.897$ 。解读: 同一公畜的残差之间为负相关, 条件残差的方差小于 $\sigma_e^2 = 3$; 学生化除以更小的标准差, 使该异常记录更突出。 [题目]

37.22 (1) $n = (1.96 \times 0.06/0.02)^2 = 34.57 \rightarrow 35$ 。(2) $n = ((1.96 + 0.8416) \times 0.06/0.04)^2 = 17.66 \rightarrow 18$ 。(3) $n = ((1.645 + 1.2816) \times 0.06/0.03)^2 = 34.26 \rightarrow 35$ ($z_{0.95} = 1.645, z_{0.9} = 1.2816$)。解读: 同一个 σ_d 下三个答案分别为 35、18、35, 回答的是精度、功效、等效三个问题; 小样本时正态近似偏乐观, 宜用非中心 t 复核 (习题 37.20)。

[题目]

五、推导与证明题

37.23 证明。 BLUP 方程给出 $\hat{b} = (X'V^{-1}X)^{-1}X'V^{-1}y$, $\hat{u} = \sigma_u^2 GZ'V^{-1}(y - X\hat{b})$ 。条件残差 $r = y - X\hat{b} - Z\hat{u} = (I - Z\sigma_u^2 GZ'V^{-1})(y - X\hat{b})$ 。由 $V = \sigma_e^2 I + Z\sigma_u^2 GZ'$ 得 $I - Z\sigma_u^2 GZ'V^{-1} = \sigma_e^2 V^{-1}$, 所以 $r = \sigma_e^2 V^{-1}(y - X\hat{b}) = \sigma_e^2 Py$, 其中 $P = V^{-1} - V^{-1}X(X'V^{-1}X)^{-1}X'V^{-1}$ 。直接展开 $PVP = P(PX = 0, PVP = P - PVV^{-1}X(\dots)X'V^{-1} = P)$ 。所以 $\text{Var}(r) = \sigma_e^4 PVP = \sigma_e^4 P$ 。数值: 习题 37.21, $P = \frac{1}{3}(I - \frac{1}{6}J)$ (总体均值已知, X 缺失), $\text{Var}(r) = 9P$, 对角 2.5。■ [题目]

37.24 证明。 $\text{corr}(u, a + b\hat{u}) = \frac{b \text{Cov}(u, \hat{u})}{\sigma_u b \sigma_{\hat{u}}} = \text{corr}(u, \hat{u})$ ($b > 0$)。回归斜率 $\beta' = \frac{\text{Cov}(u, a + b\hat{u})}{\text{Var}(a + b\hat{u})} = \frac{b \text{Cov}(u, \hat{u})}{b^2 \text{Var}(\hat{u})} = \frac{\beta}{b}$ 。BLUP (方差已知且模型正确) 满足 $\text{Cov}(u, \hat{u}) = \text{Var}(\hat{u})$, 即 $\beta = 1$: EBV 是 u 的条件期望, $E(u | \hat{u}) = \hat{u}$, 不多不少。数值: 习题 37.16: $b = 2$ 时 $0.977/2 = 0.488$ 。■ [题目]

37.25 证明。 c_{va} 与 c_{all} 联合正态, $\text{Var}(c_{all}) = \frac{n_{tr}^2}{n^2 n_{tr}} + \frac{n_{va}^2}{n^2 n_{va}} = \frac{1}{n}$, $\text{Cov}(c_{va}, c_{all}) = \frac{n_{va}}{n} \cdot \frac{1}{n_{va}} = \frac{1}{n}$, 所以 $E(c_{va} | c_{all}) = c_{all}$, 于是 $E[\text{sign}(c_{all})c_{va}] = E[\text{sign}(c_{all})c_{all}] = E|c_{all}| = \sqrt{2/(\pi n)} > 0$ 。而 c_{tr} 独立于 c_{va} , $E[\text{sign}(c_{tr})c_{va}] = E[\text{sign}(c_{tr})]E(c_{va}) = 0$ 。数值: $n = 250$ 时每个被选 SNP 的系统性正偏为 $\sqrt{2/(250\pi)} = 0.0505$; 成百上千个这样的 SNP 叠加, 就得到习题 37.17 中虚高的相关 ($r = 0.462$)。■ [题目]

37.26 证明。 平衡设计下 $\text{MSW} = \frac{1}{s(k-1)} \sum_{ij} (y_{ij} - \bar{y}_{i.})^2$, $\text{SSW}/\sigma_e^2 \sim \chi_{s(k-1)}^2$; 公畜均值 $\bar{y}_{i.} \sim N(\mu, \sigma_s^2 + \sigma_e^2/k)$ 独立同分布, $\text{SSB} = k \sum_i (\bar{y}_{i.} - \bar{y})^2$, $\text{SSB}/(k\sigma_s^2 + \sigma_e^2) \sim \chi_{s-1}^2$ 。两者独立, 所以 $\frac{\text{MSB}}{\text{MSW}} = (1 + k\rho) \frac{\chi_{s-1}^2/(s-1)}{\chi_{s(k-1)}^2/(s(k-1))} \sim (1 + k\rho) F_{s-1, s(k-1)}$ 。REML 的 $\hat{\sigma}_s^2 = \max\{0, (\text{MSB} - \text{MSW})/k\}$, 所以 $P(\hat{\sigma}_s^2 = 0) = P(\text{MSB} < \text{MSW}) = P(F_{s-1, s(k-1)} < 1/(1 + k\rho))$ 。数值: $h^2 = 0.1$, $\rho = 0.025/0.975 = 0.02564$, $k = 10$, $1/(1 + 0.2564) = 0.796$, $s = 10$: $P(F_{9,90} < 0.796) = 0.379$ (习题 37.18)。■ [题目]

六、综合分析与研究设计题

37.27 候选解释与检查 (1) 共同环境遗漏 (同一牧场、同一栏位、同批寄养): 核查栏位与寄养记录, 把牧场 $\times$ 年份 $\times$ 栏位作为固定或随机效应重新拟合, 看高估是否消失。(2) 亲本登记错误: 用基因型做亲子检查 (第 35 章: $d_i = \frac{1}{2}(G_{is} + G_{id}) < 0.25$ 可疑, 习题 35.18), 比较系谱与基因型亲缘。(3) 选择性记录 (只有表现好的女儿有记录): 恢复未测个体名册, 比较有记录与无记录个体的比例, 用缺失机制建模并检验。(4) 遗传基准变化 (该家系来自较新的基础群): 检查基础群与遗传基准,

按出生年份分组看高估是否随年份变化。(5) **随机波动**: 用多次重复或自助法评估该家系残差的置信区间(家系作为重抽样单位, 习题 37.20)。每一种解释对应不同证据, 只说“再加一些协变量试试”缺少证伪路径, 也容易造成事后模型选择。

[题目]

37.28 评审意见 (1) **校准**: 只给相关 0.82 不够, 需报告校准斜率与截距、RMSE 与区间覆盖率(习题 37.16: $b = 3$ 时相关不变而覆盖率 0.558)。(2) **泄漏**: 说明筛选、标准化、调参是否仅用训练数据; 提供无信号负对照(习题 37.17: 泄漏使无信号下 r 达 0.46)。(3) **标准误**: 验证个体有亲缘时, 应使用按家系的自助法标准误, 而不是 Fisher z (习题 37.20: 低估约 11%)。(4) **重复与种子**: 给出重复次数、种子、成对差及其区间; “明显优于”需配精度或等效目标, 而不只是点估计。(5) **探索与最终评估**: 说明验证集是否在开发中被反复使用。(6) **失败案例**: 报告各设定下表现最差的情形。结论: 0.82 本身不能支持“明显优于传统方法”。 [题目]

37.29 预注册方案 (1) **问题**: 在所述生成条件下, GBLUP 相对系谱 BLUP 在候选个体上的验证相关是否至少高 0.05 (功效), 以及差的估计半宽 ≤ 0.01 (精度)。(2) **因素**: 标记密度 (15—240)、候选与训练的亲缘结构、 h^2 、训练样本量 (习题 35.16)。(3) **重复与种子**: 每个设定预定种子, $n_1 = 126$ (精度)、 $n'_2 = 13$ (功效)、等效 (边界 0.03) $n_3 = 32$, 取最大者并留余量 (习题 37.20)。(4) **指标**: 相关、RMSE、校准斜率与截距、区间覆盖率、选择增益; 成对差在重复内计算。(5) **负对照**: 置换表型后重跑完整流程, 要求平均相关接近 0 (习题 37.17)。(6) **失败条件**: 成对差的 95% 区间下限 ≤ 0 ; 校准斜率超出 $[0.8, 1.2]$; 覆盖率低于 0.85; 负对照相关显著大于 0。(7) **标准误**: 按父系家系自助法。(8) **报告**: 所有设定的结果 (含最差重复)、种子、代码与软件版本; 探索性分析与最终评估使用不同的数据。 [题目]

综合训练

模拟试卷

四套模拟试卷，附参考答案与评分要点。

A 卷：第 1—13 章 B 卷：第 14—24 章

C 卷：第 25—37 章 D 卷：研究生综合

模拟试卷 A：基础与群体遗传篇（第 1—13 章）

考试时间 120 分钟 满分 100 分 范围 第一篇至第四篇（第 1—13 章）
题型与分值 单项选择 20 分；判断与改错 10 分；填空 10 分；计算 36 分；证明 10 分；综合 14 分。可使用不带存储功能的计算器，答案须写出主要步骤。

试题

一、单项选择题（每题 2 分，共 20 分）

1. 随机变量 U 、 Y 的 $\text{Var}(U) = 4$, $\text{Var}[E(U | Y)] = 1.5$, 则 $E[\text{Var}(U | Y)]$ 等于 (A) 1.5 (B) 2.0 (C) 2.5 (D) 5.5
2. 随机交配群体中某位点的等位基因频率 $p_A = 0.3$, 则杂合子频率为 (A) 0.21 (B) 0.42 (C) 0.49 (D) 0.09
3. 两位点间的重组率 $r = 0.2$, 按 Haldane 作图函数, 图距约为 (A) 20 cM (B) 22.3 cM (C) 25.5 cM (D) 40 cM
4. 两个位点的 $D = 0.05$, $p_A = 0.4$, $p_B = 0.5$, 则 r^2 约为 (A) 0.0025 (B) 0.0417 (C) 0.20 (D) 0.05
5. 无近交群体中全同胞个体间的遗传协方差为 (A) $\frac{1}{2}\sigma_A^2 + \frac{1}{4}\sigma_D^2$ (B) $\frac{1}{4}\sigma_A^2 + \frac{1}{4}\sigma_D^2$ (C) $\frac{1}{2}\sigma_A^2 + \frac{1}{2}\sigma_D^2$ (D) $\frac{1}{2}\sigma_A^2$
6. Gauss-Markov 定理保证最小二乘估计是 BLUE, 所要求的条件是 (A) 误差服从正态分布 (B) 误差均值为零、方差相等且互不相关 (C) 自变量彼此独立 (D) 样本量足够大
7. 两个无亲缘、无近交个体的全同胞交配, 其后代的近交系数为 (A) 0.0625 (B) 0.125 (C) 0.25 (D) 0.5
8. 关于广义遗传力 H^2 、狭义遗传力 h^2 与重复力 t , 一般成立的关系是 (A) $h^2 \geq H^2 \geq t$ (B) $t \geq H^2 \geq h^2$ (C) $H^2 \geq t \geq h^2$ (D) 三者无固定大小关系
9. 单亲—子代回归的斜率为 0.18, 则该性状的狭义遗传力估计为 (A) 0.09 (B) 0.18 (C) 0.36 (D) 0.72
10. 检验方差分量为零的似然比统计量, 其渐近分布为 (A) χ_1^2 (B) $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$

(C) χ^2_2 (D) 标准正态

二、判断与改错题 (每题 2 分, 共 10 分; 判断为错的须改正)

11. 若选择只依赖于已观察到的变量 X , 则 Y 对 X 的回归在选择后保持不变, 但 X 与 Y 的相关系数会改变。
12. 全同胞个体间的加性关系系数总是 0.5。
13. 随机交配下, 两位点的连锁不平衡每代以 $(1-r)$ 的比例衰减。
14. 近交不改变群体的加性遗传方差。
15. REML 估计的方差分量有可能恰好落在参数空间的边界 0 上。

三、填空题 (每空 2 分, 共 10 分)

16. 某性状 $\sigma_A^2 = 40$, 某个体的预测误差方差 $PEV = 24$, 则其可靠度为 _____。
17. 若个体近交系数 $F = 0.25$, 则其在加性关系矩阵中的对角元为 _____。
18. 在平衡的公畜半同胞设计中, $k = 10$, $MSB = 40$, $MSW = 20$, 则公畜方差分量估计为 _____。
19. 在 Hardy-Weinberg 平衡下, 等位基因频率为 0.5 时, 每代随机交配后杂合子频率为 _____。
20. 两个无亲缘个体的全同胞的加性关系系数为 _____。

四、计算题 (共 36 分)

21. (12 分) 某性状 $h^2 = 0.4$, 表型方差 $\sigma_p^2 = 100$, 群体均值 100。一个个体表型值为 112, 只用其自身表型预测育种值。求: (1) 育种值预测值; (2) 预测误差方差; (3) 预测准确度; (4) 90% 预测区间 (取 $z_{0.95} = 1.645$)。

22. (12 分) 平衡的公畜半同胞设计, 公畜数 $s = 20$, 每头公畜 $k = 10$ 个后代, $MSB = 40$, $MSW = 20$ 。求: (1) 公畜方差分量与总表型方差的估计; (2) h^2 的估计; (3) 取 $\text{Var}(\hat{t}) \approx \frac{2(1-t)^2[1+(k-1)t]^2}{k(k-1)(s-1)}$, 求 $h^2 = 4t$ 的标准误。

23. (12 分) 系谱: 个体 1、2 无亲缘且不近交; 3、4 是 1 与 2 的全同胞; 5 是 3 与 4 的后代; 6 是 5 与 1 的后代。求: (1) F_5 、 F_6 ; (2) a_{56} ; (3) a_{16} 与 a_{66} 。

五、证明题 (10 分)

24. (1) 证明全方差公式 $\text{Var}(U) = E[\text{Var}(U | Y)] + \text{Var}[E(U | Y)]$; (2) 设 (U, Y) 联合正态, $\hat{u} = E(U | Y)$ 为 BLP, $\rho = \text{Corr}(U, \hat{u})$, 证明预测误差方差为 $\sigma_U^2(1 - \rho^2)$ 。

六、综合题 (14 分)

25. 某猪场只有半同胞家系资料, 总测定数 $N = 200$ 头, 想估计背膘厚遗传力。方案甲: 20 头公猪, 每头 10 个后代; 方案乙: 50 头公猪, 每头 4 个后代; 方案丙: 100 头公猪, 每头 2 个后代。已知 $t = \sigma_s^2 / \sigma_p^2 \approx 0.0909$ 。(1) 按第 22 题的标准误公式, 比较三种方案 h^2 的标准误; (2) 说明为什么公畜数越多并不总是越好, 并提出一种考虑育

种目标的折中; (3) 列出估计 h^2 的其他两个潜在偏差来源。

参考答案与评分要点

一、选择题 1. C (全方差公式, $4 - 1.5 = 2.5$)。2. B ($2 \times 0.3 \times 0.7 = 0.42$)。3. C ($d = -\frac{1}{2} \ln(1 - 2r) = -\frac{1}{2} \ln 0.6 = 0.2554 M$)。4. B ($r^2 = \frac{0.05^2}{0.4 \times 0.6 \times 0.5 \times 0.5} = 0.0417$)。5. A。6. B (不需要正态性)。7. C ($F = \frac{1}{2}a_{34} = \frac{1}{4}$)。8. B ($t = (V_G + V_{E_p})/V_P \geq H^2 \geq h^2$)。9. C ($b = \frac{1}{2}h^2$)。10. B (边界上的混合卡方分布)。

二、判断与改错 11. 正确, 选择改变了 X 的分布但不改变条件分布 $Y|X$, 所以回归系数不变而相关改变 (2 分)。12. 错。全同胞的加性关系系数是 0.5 仅当双亲无近交、无亲缘; 一般 $a = \frac{1}{4}(a_{ss'} + a_{sd'} + a_{ds'} + a_{dd'})$, 双亲近交或有亲缘时不等于 0.5 (2 分)。13. 正确, $D_t = (1 - r)^t D_0$ 。14. 错, 近交使加性方差随 F 改变: $\sigma_A^2(F) = (1 + F) 2 \sum p_i q_i a_i^2$ 等 (涉及显性时还有额外项); 改正后得 2 分。15. 正确, REML 的约束优化可得零估计。

三、填空题 16. $1 - 24/40 = 0.4$ 。17. 1.25。18. $(40 - 20)/10 = 2$ 。19. 0.5。20. 0.5。每空 2 分。

四、计算题

21. (1) $\hat{u} = h^2(y - \mu) = 0.4 \times 12 = 4.8$ (3 分); (2) $\sigma_A^2 = 40$, $PEV = \sigma_A^2(1 - h^2) = 24$ (3 分); (3) $r = \sqrt{h^2} = 0.632$ (3 分); (4) $4.8 \pm 1.645\sqrt{24} = 4.8 \pm 8.06$, 即 $[-3.26, 12.86]$ (3 分)。注意区间宽度由预测误差方差决定, 与 $\hat{u}$ 的大小无关。
22. (1) $\hat{\sigma}_s^2 = (40 - 20)/10 = 2$, $\hat{\sigma}_e^2 = MSW = 20$, $\hat{\sigma}_p^2 = 2 + 20 = 22$ (4 分); (2) $\hat{t} = 2/22 = 0.0909$, $\hat{h}^2 = 4\hat{t} = 0.364$ (4 分); (3) $Var(\hat{t}) = \frac{2 \times 0.8264 \times 3.306}{10 \times 9 \times 19} = 0.003195$, $SE(\hat{t}) = 0.0565$, $SE(\hat{h}^2) = 4 \times 0.0565 = 0.226$ (4 分)。
23. 按表格法: $a_{34} = a_{43} = \frac{1}{2}(a_{13} + a_{23})$ 或直接用 $a_{31} = a_{32} = \frac{1}{2}$ 等, 得 $a_{34} = 0.5$ 。(1) $F_5 = \frac{1}{2}a_{34} = 0.25$; $a_{51} = \frac{1}{2}(a_{31} + a_{41}) = 0.5$, $F_6 = \frac{1}{2}a_{51} = 0.25$ (4 分)。(2) $a_{53} = \frac{1}{2}(a_{33} + a_{43}) = \frac{1}{2}(1 + 0.5) = 0.75$, 同理 $a_{54} = 0.75$, $a_{56} = \frac{1}{2}(a_{55} + a_{51}) = \frac{1}{2}(1.25 + 0.5) = 0.875$ (4 分)。(3) $a_{16} = \frac{1}{2}(a_{15} + a_{11}) = \frac{1}{2}(0.5 + 1) = 0.75$, $a_{66} = 1 + F_6 = 1.25$ (4 分)。

五、证明题 (1) (5 分) 记 $m = E(U|Y)$, 则 $U - EU = (U - m) + (m - EU)$, 平方后取期望, 交叉项 $2E[(U - m)(m - EU)] = 2E\{(m - EU)E[U - m|Y]\} = 0$ 。而 $E(U - m)^2 = E[Var(U|Y)]$, $E(m - EU)^2 = Var(m)$ 。(2) (5 分) 设 $\sigma_Y^2 = P$, $Cov(U, Y) = c$, 则 $\hat{u} = \mu_U + \frac{c}{P}(Y - \mu_Y)$, $Var(\hat{u}) = c^2/P = Cov(U, \hat{u})$ 。预测误差方差 $Var(U - \hat{u}) = \sigma_U^2 - 2\frac{c^2}{P} + \frac{c^2}{P} = \sigma_U^2 - \frac{c^2}{P} = \sigma_U^2(1 - \frac{c^2}{\sigma_U^2 P}) = \sigma_U^2(1 - \rho^2)$, 因为 $\rho^2 = \frac{c^2}{\sigma_U^2 P}$ 。

六、综合题 (1) (6 分) 三种方案的标准误分别为 0.226 ($s = 20, k = 10$)、0.270

($s = 50, k = 4$)、**0.399** ($s = 100, k = 2$)。(2) (4 分) 每个半同胞家系内的方差分量估计依赖“家系内共享的信息”， k 太小则 MSB 中与家系有关的部分信息少； $SE(\hat{t})$ 在 $k \approx 1/t$ 附近最小。因此应综合考虑：公畜数越多， $\hat{\sigma}_s^2$ 的自由度越多，但每头公畜的信息越少。折中是令 k 取 $1/t$ (即 $4/h^2$ ，本例约 11) 的量级，同时兼顾后续用这些公畜留种的需要。(3) (4 分) 可能的偏差来源：公畜被选择而非随机抽样 (选择偏差)；母畜在公畜间分配不随机、母体效应和共同环境使 σ_s^2 偏大；显性与上位使 $4\sigma_s^2$ 不等于 σ_A^2 (回答任意两项即可)。

模拟试卷 B：选择、近交杂交与遗传评定 (第 14—24 章)

考试时间 120 分钟 **满分** 100 分 **范围** 第五篇至第七篇（第 14—24 章）
题型与分值 单项选择 20 分；判断与改错 10 分；填空 10 分；计算 36 分；证明 10 分；综合 14 分。

试题

一、单项选择题（每题 2 分，共 20 分）

1. 截留比例 $p = 0.1$ 的截断选择，标准化选择强度约为 (A) 1.40 (B) 1.755 (C) 2.06 (D) 2.67
2. 选择强度 $i = 1.755$, $h^2 = 0.35$, $\sigma_p = 12$, 则单世代选择反应约为 (A) 0.61 (B) 7.37 (C) 21.1 (D) 2.58
3. 群体含 5 头公畜与 45 头母畜，随机交配，有效群体大小为 (A) 50 (B) 25 (C) 18 (D) 5
4. 选择指数 $I = b'x$ 中取 $b = P^{-1}Ga$, 其最优性是 (A) 使 I 的方差最大 (B) 使 I 与综合育种值 H 的相关最大 (C) 使各性状遗传进展相等 (D) 使指数的遗传力最小
5. $i = 1.755$, 选择准确度 $r = 0.6$, $\sigma_A = 7$, 世代间隔 $L = 2.5$ 年，则年遗传进展约为 (A) 1.23 (B) 2.95 (C) 4.91 (D) 7.37
6. 两亲本群体某 10 个位点上显性效应均为 $d = 2$, 等位基因频率分别为 0.8 与 0.3, F_1 的中亲杂种优势为 (A) 2.5 (B) 5 (C) 10 (D) 20
7. 关于 BLUP, 下列说法正确的是 (A) 预测值对每个真实育种值都是条件无偏的 (B) 在线性无偏预测中预测误差方差最小, 且 $E(u | \hat{u}) = \hat{u}$ (C) 只能用于单性状 (D) 不需要知道方差组分之比
8. 与 ML 相比, REML 的主要改进是 (A) 考虑估计固定效应所损失的自由度 (B) 不需要正态假设 (C) 一定给出非负且大于零的估计 (D) 计算量更小
9. 动物模型相对于公畜模型的优势是 (A) 不需要系谱 (B) 模型更简单 (C) 可利用全部个体及亲属信息并校正选择与非随机交配带来的偏差 (D) 不需要方差组

分

10. 阈值模型中, 潜在尺度 (liability) 的残差方差通常被固定为 1, 原因是 (A) 该方差可以直接观察 (B) 二分类资料不含关于该尺度的信息, 必须固定以使参数可识别 (C) 使遗传力等于 1 (D) 使 BLUP 无偏

二、判断与改错题 (每题 2 分, 共 10 分; 判断为错的须改正)

11. 截断选择使选择群体的遗传方差因配子相不平衡而下降, 选择停止后该下降部分在若干代内逐步恢复。
12. 对任意指数 $I = b'x$, 与综合育种值的相关均为 $r_{IH} = \sigma_I / \sigma_H$ 。
13. 有效群体大小主要由数量较多的性别决定。
14. 两亲本间等位基因频率相同时, 仍可能出现杂种优势。
15. BLUP 的预测值对每个个体真实育种值是条件无偏的, 即 $E(\hat{u} | u) = u$ 。

三、填空题 (每空 2 分, 共 10 分)

16. 选择差 $S = 15$, $h^2 = 0.4$, 则选择反应 $R =$ _____。
17. $N_e = 18$, 则每代近交增量 $\Delta F =$ _____ (保留四位小数)。
18. 上述群体封闭繁殖 10 代后, 近交系数 $F_{10} \approx$ _____。
19. 公畜模型混合模型方程中, 若 $\sigma_s^2 = 5$, $\sigma_e^2 = 80$, 则 $\lambda = \sigma_e^2 / \sigma_s^2 =$ _____。
20. 方差组分 REML 估计中, 似然的约束部分是对 _____ 效应作的边缘化 (填“固定”或“随机”)。

四、计算题 (共 36 分)

21. (12 分) 两性状的表型协方差阵 $P = \begin{pmatrix} 100 & 30 \\ 30 & 50 \end{pmatrix}$, 遗传协方差阵 $G = \begin{pmatrix} 40 & 15 \\ 15 & 20 \end{pmatrix}$,

经济权重 $a = (2, 1)'$ 。求: (1) 最优指数系数 b ; (2) σ_I 、 σ_H 与 r_{IH} ; (3) 选留 10% 时 ($i = 1.755$) 综合育种值的选择反应。

22. (12 分) 核心群含 5 头公畜与 45 头母畜, 随机交配、世代不重叠。(1) 求 N_e 与 ΔF ; (2) 求封闭繁殖 10 代后的 F ; (3) 若公畜增至 15 头, 重新计算 (1) 与 (2), 说明改进来自何处。

23. (12 分) 公畜模型 $y_{ij} = \mu + s_i + e_{ij}$, 3 头公畜的后代数分别为 4, 6, 10, 后代均值分别为 105, 110, 98, $\sigma_s^2 = 5$, $\sigma_e^2 = 80$ 。(1) 写出混合模型方程; (2) 求 $\hat{\mu}$ 与 $\hat{s}_1, \hat{s}_2, \hat{s}_3$; (3) 求 s_3 的预测误差方差与可靠度。

五、证明题 (10 分)

24. 设 $H = a'g$ 为综合育种值, $I = b'x$ 为指数, $P = \text{Var}(x)$, $G = \text{Cov}(x, g)$ 。证明 $b = P^{-1}Ga$ 使 r_{IH} 最大, 并证明此时 $r_{IH} = \sigma_I / \sigma_H$ 。

六、综合题 (14 分)

25. 某猪场核心群 5 头公猪、45 头母猪, 目前主要依据个体表型选种: $i = 1.755$, $r = 0.6$, $\sigma_A = 7$, $L = 2.5$ 年。改进方案: 改用 BLUP 评定、缩短世代间隔至 $L = 2$ 年, 但选择准确度降为 $r = 0.5$ (早期评定), 同时把公猪增至 15 头。(1) 分别计算两种方案的年遗传进展; (2) 分别计算两种方案 10 代的近交系数; (3) 从 BLUP 的信息利用、Bulmer 效应与长期选择的角度, 评价这一改进方案并提出两条风险控制措施。

参考答案与评分要点

- 一、选择题 1. B。2. B ($1.755 \times 0.35 \times 12 = 7.37$)。3. C ($N_e = \frac{4N_m N_f}{N_m + N_f} = \frac{4 \times 5 \times 45}{50} = 18$)。4. B。5. B ($\frac{1.755 \times 0.6 \times 7}{2.5} = 2.95$)。6. B ($\sum d(p_1 - p_2)^2 = 10 \times 2 \times 0.25 = 5$)。7. B。8. A。9. C。10. B。

二、判断与改错 11. 正确 (Bulmer 效应, 配子相不平衡在随机交配下随重组而衰减)。12. 错。仅当 $b = P^{-1}Ga$ (最优指数) 时有 $r_{IH} = \sigma_I / \sigma_H$; 一般指数 $r_{IH} = b'Ga / (\sigma_I \sigma_H)$ 。13. 错, 由数量较少的性别决定。14. 错, 杂种优势要求两亲本等位基因频率不同, 并且 $d \neq 0$ ($\propto d(p_1 - p_2)^2$)。15. 错。BLUP 满足的是 $E(u | \hat{u}) = \hat{u}$, 而 $E(\hat{u} | u) = \text{rel} \cdot u$ (向均值收缩)。

- 三、填空题 16. $0.4 \times 15 = 6$ 。17. $1/36 = 0.0278$ 。18. $1 - (1 - 1/36)^{10} = 0.2455$ 。19. 16。20. 固定。

四、计算题

21. (1) $Ga = (95, 50)'$, $\det P = 4100$, $P^{-1} = \frac{1}{4100} \begin{pmatrix} 50 & -30 \\ -30 & 100 \end{pmatrix}$, $b = \frac{1}{4100} (3250, 2150)' = (0.7927, 0.5244)'$ (4 分)。(2) $\sigma_I^2 = b'Pb = b'Ga = 101.52$, $\sigma_I = 10.08$; $\sigma_H^2 = a'Ga = 240$, $\sigma_H = 15.49$; $r_{IH} = 10.08/15.49 = 0.650$ (4 分)。(3) $R_H = i\sigma_I = 1.755 \times 10.08 = 17.68$ (4 分)。
22. (1) $N_e = 18$, $\Delta F = 1/(2N_e) = 0.0278$ (4 分)。(2) $F_{10} = 1 - (1 - \Delta F)^{10} = 0.2455$ (4 分)。(3) $N_e = 4 \times 15 \times 45/60 = 45$, $\Delta F = 1/90 = 0.0111$, $F_{10} = 1 - (1 - 1/90)^{10} = 0.1057$ (3 分)。公畜数这一较少的性别是限制因素, 增加它对 N_e 的贡献最大 (1 分)。

23. (1) $\lambda = 16$ 。方程:
$$\begin{pmatrix} 20 & 4 & 6 & 10 \\ 4 & 20 & 0 & 0 \\ 6 & 0 & 22 & 0 \\ 10 & 0 & 0 & 26 \end{pmatrix} \begin{pmatrix} \hat{\mu} \\ \hat{s}_1 \\ \hat{s}_2 \\ \hat{s}_3 \end{pmatrix} = \begin{pmatrix} 2060 \\ 420 \\ 660 \\ 980 \end{pmatrix} \quad (4 \text{ 分}; \text{右端 } \sum n_j \bar{y}_j = 420 +$$

$660 + 980 = 2060$)。 (2) 消去 $\hat{s}_j = \frac{n_j}{n_j + \lambda}(\bar{y}_j - \hat{\mu})$, 代入第一行得 $\hat{\mu} = 103.45$, $\hat{s}_1 = 0.2 \times 1.55 = 0.310$, $\hat{s}_2 = 0.2727 \times 6.55 = 1.786$, $\hat{s}_3 = 0.3846 \times (-5.45) = -2.096$ (5 分)。 (3) $PEV(\hat{s}_3) = \sigma_e^2 C^{44} = 3.94$ (4 位小数 3.9396), 可靠度 $= 1 - 3.94/5 = 0.212$ (3 分)。可靠度低说明 10 个半同胞的均值信息只能解释公畜方差的约 21%。

五、证明题 (5 分) 设 $\sigma_H^2 = a'G_g a$ (G_g 为 g 的方差), $Cov(I, H) = b'Ga$, 则 $r_{IH} = \frac{b'Ga}{\sqrt{b'Pb}\sigma_H}$ 。令 $w = P^{1/2}b$, $v = P^{-1/2}Ga$, 则分子 $= w'v$, 由 Cauchy-Schwarz, $w'v \leq \|w\|\|v\|$, 等号成立当且仅当 $w \propto v$, 即 $b \propto P^{-1}Ga$ 。(5 分) 此时 $Cov(I, H) = a'G'P^{-1}Ga = b'Pb = \sigma_I^2$, 所以 $r_{IH} = \sigma_I^2/(\sigma_I\sigma_H) = \sigma_I/\sigma_H$, 数值上与第 21 题的 0.650 一致。

六、综合题 (1) (4 分) 原方案: $\Delta G/\text{年} = \frac{1.755 \times 0.6 \times 7}{2.5} = 2.95$; 改进方案: $\frac{1.755 \times 0.5 \times 7}{2} = 3.07$, 提高约 4%, 主要来自世代间隔缩短, 准确度下降抵消了一部分。(2) (4 分) 原方案 $F_{10} = 0.2455$, 改进方案 0.1057, 近交速率下降约 60%。(3) (6 分) 要点: BLUP 利用全部亲属信息并校正环境, 实际准确度可能高于仅用本身表型, 但早期评定依赖亲属, 家系选择会降低 N_e (同一家系入选多), 需用约束 (如最优贡献) 而不仅是增加公畜数; Bulmer 效应使选择后遗传方差下降, 长期反应小于 $ir\sigma_A$ 的外推; 风险控制: (i) 限定每家系入选数、监控 $\Delta F \leq 1\%$; (ii) 每年用后续表型资料回检预测的校准斜率, 防止早期评定的偏倚。每条要点 2 分。

模拟试卷 C：基因组预测与前沿方法（第 25—37 章）

考试时间 120 分钟 满分 100 分 范围 第八篇至第十篇（第 25—37 章）
题型与分值 单项选择 20 分；判断与改错 10 分；填空 10 分；计算 36 分；证明 10 分；综合 14 分。

试题

一、单项选择题（每题 2 分，共 20 分）

1. VanRaden 基因组关系矩阵 $G = ZZ' / [2 \sum p_j(1 - p_j)]$ 中，分母的作用是 (A) 使 G 可逆 (B) 使 G 的对角元平均约为 1，与系谱关系矩阵 A 同尺度 (C) 使非对角元为零 (D) 去除稀有变异
2. 在 SNP-BLUP 中，岭参数为 $\lambda = \frac{\sigma_e^2}{\sigma_m^2}$ ，若 $\sigma_m^2 = \sigma_a^2 / [2 \sum p_j(1 - p_j)]$ ， $h^2 = 0.4$ ， $2 \sum p_j q_j = 2.2$ ，则 λ 为 (A) 3.3 (B) 1.5 (C) 0.33 (D) 2.2
3. 验证群体中预测值与校正表型的相关为 $r = 0.32$ ， $h^2 = 0.4$ ，则预测准确度估计 r/h 为 (A) 0.128 (B) 0.32 (C) 0.506 (D) 0.8
4. 验证资料中 u 对 $\hat{u}$ 的回归（校准斜率）显著小于 1，说明 (A) 预测过于保守 (B) 预测值过度分散，需要收缩 (C) 相关系数有误 (D) 区间过宽
5. 单步评定中 $H^{-1} = A^{-1} + \begin{pmatrix} 0 & 0 \\ 0 & G^{-1} - A_{22}^{-1} \end{pmatrix}$ ，其中 A_{22} 是 (A) 全体个体的 A (B) 有基因型个体的系谱关系子矩阵 (C) 无基因型个体的子矩阵 (D) G 的逆
6. 先用全体数据筛选 SNP，再对所选 SNP 做交叉验证，结果是 (A) 无偏 (B) 悲观 (C) 乐观偏倚，在无信号时也会得到正相关 (D) 与不筛选相同
7. 预测从训练群体迁移到另一品种时准确度通常下降，其主要原因是 (A) 样本量更大 (B) 计算误差 (C) 表型尺度改变 (D) LD 模式、等位基因频率和因果位点标记覆盖的差异
8. 在数千个体、数万 SNP 的资料上，深度神经网络与 GBLUP 相比，通常 (A) 显著优于 (B) 完全无法使用 (C) 难以稳定地优于 GBLUP，须以同样的验证设计比较 (D) 因为非线性一定更准

9. 最优贡献选择在给定亲缘约束下最大化平均育种值, 其最优性条件由什么给出 (A) 线性回归 (B) Lagrange 乘子与 KKT 条件 (C) 方差分析 (D) 主成分
10. 负对照指的是 (A) 使用质量更低的数据 (B) 把表型随机置换后重跑整个流程, 正确的流程应得到零信号 (C) 去掉所有协变量 (D) 只用前半个体

二、判断与改错题 (每题 2 分, 共 10 分; 判断为错的须改正)

11. 在同一批表型上筛选标记, 又在这批表型上做交叉验证, 会高估预测准确度。
12. 预测与真值的相关系数高, 就说明预测值无需校准。
13. 若方差分量估计为 0, 就可以断定该性状没有遗传变异。
14. 单步评定中 G 与 A_{22} 的尺度对齐会影响基因型个体与无基因型个体的 EBV 比较。
15. 稀有变异单个位点的单变异检验通常功效很高。

三、填空题 (每空 2 分, 共 10 分)

16. 5 个 SNP 的频率为 0.3, 0.5, 0.6, 0.4, 0.2, 则 $2 \sum p_j q_j =$ _____。
17. 根据第 2 题的条件, 岭参数 $\lambda =$ _____。
18. $r = 0.32$, $h^2 = 0.4$, 则 $r/h =$ _____ (保留三位小数)。
19. 验证资料中 $\text{Cov}(u, \hat{u}) = 0.30$, $\text{Var}(\hat{u}) = 0.5$, 则校准斜率为 _____。
20. 独立验证个体数 $n = 400$, 相关 $r = 0.5$, 则相关系数的近似标准误 $(1 - r^2)/\sqrt{n - 1} =$ _____ (保留四位小数)。

四、计算题 (共 36 分)

21. (12 分) 3 个个体在 5 个 SNP 上的基因型 (0/1/2 计数) 为: 个体 1: (0, 1, 2, 1, 0); 个体 2: (1, 1, 2, 0, 0); 个体 3: (2, 0, 1, 1, 1)。等位基因频率为 (0.3, 0.5, 0.6, 0.4, 0.2)。(1) 写出中心化矩阵 Z ; (2) 按 VanRaden 方法 1 求 G ; (3) 个体 3 的 G_{33} 大于 1, 说明了什么?

22. (12 分) 验证样本中, $\text{Var}(u) = 0.8$, $\text{Var}(\hat{u}) = 0.5$, $\text{Cov}(u, \hat{u}) = 0.30$ 。求: (1) 校准斜率与相关系数; (2) 原预测的均方误差 $\text{MSE} = E(u - \hat{u})^2$ 及 RMSE; (3) 把预测收缩为 $\hat{u}' = b\hat{u}$ (b 取校准斜率) 后的 MSE 与 RMSE, 并说明相关为何不变而误差下降。

23. (12 分) 一个验证集 $n = 400$, 观察相关 $r = 0.5$ 。(1) 求 r 的近似标准误; (2) 用 Fisher z 变换求 95% 置信区间; (3) 若要使标准误降到 0.03, 独立样本需要多大 n ? 若个体来自家系, 设计效应 $\text{deff} = 1 + (m - 1)\rho = 1.8$, 则需要多大 n ?

五、证明题 (10 分)

24. 设 Z 为 $n \times m$ 的中心化标记矩阵, SNP 效应的岭回归 $\hat{a} = (Z'Z + \lambda I_m)^{-1}Z'y$ 。证明: (1) $\hat{a} = Z'(ZZ' + \lambda I_n)^{-1}y$; (2) 由此得 $\hat{u} = Z\hat{a} = G(G + \frac{\lambda}{k}I)^{-1}y$, 其中 $G = ZZ'/k$, 从而 SNP-BLUP 与 GBLUP 等价。

六、综合题 (14 分)

25. 某课题报告: 在 1200 头肉羊上用全部个体的表型筛选出 2000 个 SNP 后做 10 折交

又验证, 得到相关 $r = 0.62$; 把表型随机置换后重复整个流程, 相关为 0.41; 用后来出生的 300 头羊检验, 相关 0.30, 校准斜率 0.55。(1) 指出这套流程的主要问题及其证据; (2) 给出修正后的验证方案; (3) 说明该报告应如何向育种方汇报, 才不会误导决策。

参考答案与评分要点

一、选择题 1. B。2. A ($\lambda = 2.2 \times 0.6 / 0.4 = 3.3$)。3. C。4. B。5. B。6. C。7. D。8. C。9. B。10. B。

二、判断与改错 11. 正确, 筛选用到了验证表型, 信息泄漏。12. 错, 相关对线性变换不变, 校准斜率与截距必须另外检查。13. 错, 零估计是边界上的点估计; 参数空间为 $\sigma_A^2 \geq 0$, 估计的抽样分布在零处有一个质量点 (例如公畜模型在 $h^2 = 0.1, s = 10, k = 10$ 时零估计概率约 0.38)。14. 正确, 不对齐则会把基因型个体系统性地提高或降低。15. 错, 稀有变异单位点方差贡献极小, 需用基于基因或区域的合并检验。

三、填空题 16. $2 \times (0.21 + 0.25 + 0.24 + 0.24 + 0.16) = 2.2$ 。17. 3.3。18. $0.32 / \sqrt{0.4} = 0.506$ 。19. $0.30 / 0.5 = 0.6$ 。20. $0.75 / \sqrt{399} = 0.0375$ 。

四、计算题

21. (1) $2p = (0.6, 1.0, 1.2, 0.8, 0.4)$, Z 三行为 $(-0.6, 0, 0.8, 0.2, -0.4)$ 、 $(0.4, 0, 0.8, -0.8, -0.4)$ 、 $(1.4, -1, -0.2, 0.2, 0.6)$ (4 分)。(2) 分母 2.2: $G_{11} = 1.2/2.2 = 0.5455$, $G_{12} = 0.4/2.2 = 0.1818$, $G_{13} = -1.2/2.2 = -0.5455$, $G_{22} = 1.6/2.2 = 0.7273$, $G_{23} = 0$, $G_{33} = 3.4/2.2 = 1.5455$ (5 分)。(3) $G_{33} - 1 = 0.5455$ 是基因组近交的度量, 说明个体 3 的纯合度比群体平均高很多, 其基因型与其他两个体“相反” ($G_{13} < 0$)。仅 5 个 SNP 的矩阵噪声极大, 此题只为演示公式 (3 分)。

22. (1) 斜率 $= 0.30/0.5 = 0.6$, $r = 0.30/\sqrt{0.8 \times 0.5} = 0.474$ (4 分)。(2) $MSE = 0.8 + 0.5 - 2 \times 0.30 = 0.70$, $RMSE = 0.837$ (4 分)。(3) $\hat{u}' = 0.6\hat{u}$: $Var = 0.18$, $Cov = 0.18$, $MSE = 0.8 + 0.18 - 0.36 = 0.62$, $RMSE = 0.787$ (4 分)。线性缩放不改变相关系数, 但 MSE 对尺度敏感; 收缩到使 $Cov(u, \hat{u}') = Var(\hat{u}')$ 时 MSE 最小。

23. (1) $SE = (1 - 0.25)/\sqrt{399} = 0.0375$ (3 分)。(2) $z = \text{arctanh } 0.5 = 0.5493$, $SE_z = 1/\sqrt{397} = 0.0502$, $z \pm 1.96 \times 0.0502 = [0.4509, 0.6477]$, 反变换得 $[0.423, 0.570]$ (5 分)。(3) $n = (0.75/0.03)^2 + 1 = 626$; 有家系聚集时约 $625 \times 1.8 = 1125$ (4 分)。

五、证明题 (1)(5 分)由恒等式 $(Z'Z + \lambda I_m)Z' = Z'(ZZ' + \lambda I_n)$, 两边左乘 $(Z'Z + \lambda I_m)^{-1}$ 、右乘 $(ZZ' + \lambda I_n)^{-1}$, 得 $Z'(ZZ' + \lambda I_n)^{-1} = (Z'Z + \lambda I_m)^{-1}Z'$ (两边均可逆, 因 $\lambda > 0$)。(2) (5 分) $\hat{u} = ZZ'(ZZ' + \lambda I)^{-1}y$ 。令 $ZZ' = kG$, 得 $kG(kG + \lambda I)^{-1}y = G(G + \frac{\lambda}{k}I)^{-1}y$ 。而 GBLUP

的预测为 $\sigma_a^2 G(\sigma_a^2 G + \sigma_e^2 I)^{-1} y = G(G + \frac{\sigma_e^2}{\sigma_a^2} I)^{-1} y$, 当 $\lambda/k = \sigma_e^2/\sigma_a^2$ 时二者相同。■

六、综合题 (1) (5 分) 主要问题是筛选泄漏: 置换表型后相关仍为 0.41, 说明流程在无信号时也给出明显的正相关, 0.62 不可信; 时间验证相关降至 0.30, 且校准斜率 $0.55 < 1$, 预测过度分散。另外 10 折随机划分忽略家系相关, 会进一步乐观。(2) (5 分) 修正方案: 筛选、标准化与调参只在训练折内完成; 按家系或时间划分验证; 保留负对照 (置换后重跑, 期望相关约 0); 报告相关、校准斜率与截距、RMSE 与区间覆盖率, 并给出以家系为单位的自助法置信区间。(3) (4 分) 向育种方汇报时, 应把时间验证的 0.30 (及其区间) 作为对未来候选个体准确度的估计, 并说明斜率 0.55 提示需要收缩; 不得把 0.62 当作决策依据; 说明样本量与家系结构限制了结论的精度, 并给出后续验证计划。

模拟试卷 D：研究生综合考试（全书）

考试时间 180 分钟 满分 100 分 范围 全书

说明 本卷以推导、计算与研究设计为主，不含选择题。答案须写明假设、步骤与结论；设计题须写明数据、模型、验证、风险与后续检验。

试题

一、推导题（15 分）

1. 线性混合模型 $y = Xb + Zu + e$, $\text{Var}(u) = \sigma_u^2 A$, $\text{Var}(e) = \sigma_e^2 I$ 。(1) 写出混合模型方程（Henderson 方程）并说明它是怎样由联合密度的最大化得到的；(2) 证明 $\text{Var}(\hat{u} - u) = \sigma_e^2 C^{22}$, 其中 C^{22} 是系数阵逆的右下块；(3) 说明可靠度与 C^{22} 的关系，并解释为什么对有近交的个体应以 $(1 + F_i)\sigma_u^2$ 而不是 σ_u^2 为分母。

二、计算题（20 分）

2. 三个全同胞个体 1、2、3（无近交，亲缘系数 0.5）， $h^2 = 0.4$ ，取 $\sigma_u^2 = 0.4$, $\sigma_e^2 = 0.6$ ，群体均值已知为 0。个体 1、2 有表型 $y_1 = 3$ 、 $y_2 = 1$ ，个体 3 无记录。(1) 写出 V 与协方差 $\text{Cov}(u, y)$ ；(2) 求三个个体的 BLUP；(3) 求预测误差方差与可靠度，并解释个体 3 的可靠度低于有记录个体的原因；(4) 若个体 3 又得到一条记录 $y_3 = 2$ ，用文字说明 $\hat{u}_1$ 将向哪个方向变化、PEV 将怎样变化（不需要计算）。

三、研究设计题——验证设计与功效（20 分）

3. 一家育种公司要比较两个基因组预测模型 M1 与 M2，用同一批候选个体计算两者预测值与后续表型的相关，以家系为单位（每个家系得到一个相关之差 d ）。预试验给出家系间 d 的标准差 $\sigma_d = 0.0572$ 。(1) 要在 $\alpha = 0.05$ （双侧）、功效 0.80 时检出 $\delta = 0.05$ 的差异，按正态近似需要多少个家系？(2) 说明为什么实际需要的家系数略大于该值，并给出修正的方法；(3) 如果研究目的是证明“M2 不比 M1 差超过 0.03”，应改用什么检验，样本量计算的差别在哪里？(4) 同一批候选个体上的两个相关是否独立？应如何处理？

四、研究设计题——新品种的基因组评定方案（25 分）

4. 某育种企业有一个新建的肉鸡专门化父系，核心群 3000 只，系谱 5 代，现有 1200 只个体已用 50K 芯片分型，有屠宰性状（胸肌率， $h^2 \approx 0.3$ ）与生长性状的表型。目标

是三年内用基因组选择缩短世代间隔并提高胸肌率。请给出完整的研究与实施方案,至少应包括:(1)数据与质量控制;(2)模型选择与理由(系谱 BLUP、GBLUP、单步、贝叶斯、深度学习);(3)验证设计与评价指标;(4)选择与近交控制;(5)可能的失败模式与诊断;(6)阶段性决策点与成功判据。

五、案例诊断题 (20 分)

5. 某团队的 GBLUP 报告:训练内相关 0.85, 验证(随机 10 折)相关 0.52;按出生年份把后两年作为验证集时,相关 0.31, 校准斜率 0.58, 90% 区间实际覆盖率 0.66;方差分量估计中,遗传方差的 REML 估计为 0, 团队据此认为该性状“不受遗传控制”,改用单一的环境因素模型。请逐项指出问题,给出诊断实验与改正措施,并说明哪些结论仍然可以保留。

参考答案与评分要点

1. (15 分) (1) 联合密度 $f(y, u) \propto \exp\{-\frac{1}{2\sigma_e^2}(y - Xb - Zu)'(\cdot) - \frac{1}{2\sigma_u^2}u'A^{-1}u\}$ 。对 b, u 求导并令其为 0, 得到

$$\begin{pmatrix} X'X & X'Z \\ Z'X & Z'Z + \lambda A^{-1} \end{pmatrix} \begin{pmatrix} \hat{b} \\ \hat{u} \end{pmatrix} = \begin{pmatrix} X'y \\ Z'y \end{pmatrix}, \quad \lambda = \sigma_e^2/\sigma_u^2.$$

(5 分; 对联合密度最大化给出的 $\hat{b}$ 是 GLS 估计, $\hat{u}$ 是 BLUP)。(2) 记系数阵为 C 。把 $y = Xb + Zu + e$ 代入方程并减去真值满足的等式, 得 $C \begin{pmatrix} \hat{b}-b \\ \hat{u}-u \end{pmatrix} = \begin{pmatrix} X'e \\ Z'e - \lambda A^{-1}u \end{pmatrix} =: r$ 。由 e 与 u 独立, $\text{Var}(r) = \sigma_e^2 \begin{pmatrix} X'X & X'Z \\ Z'X & Z'Z + \lambda^2 \frac{\sigma_u^2}{\sigma_e^2} A^{-1} \end{pmatrix} = \sigma_e^2 C$ (因 $\lambda^2 \sigma_u^2 / \sigma_e^2 = \lambda$)。于是误差向量的方差为 $C^{-1}(\sigma_e^2 C)C^{-1} = \sigma_e^2 C^{-1}$, 取其中 $\hat{u} - u$ 对应的块即得 $\text{Var}(\hat{u} - u) = \sigma_e^2 C^{22}$ (5 分)。(3) $\text{rel}_i = 1 - \frac{\sigma_e^2 C_{ii}^{22}}{(1 + F_i)\sigma_u^2}$, 因为近交个体育种值的先验方差为 $(1 + F_i)\sigma_u^2$ (5 分)。

$$2. (20 \text{ 分}) \quad (1) V = 0.4 \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix} + 0.6I = \begin{pmatrix} 1 & 0.2 \\ 0.2 & 1 \end{pmatrix}, \text{Cov}(u, y) = 0.4 \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \\ 0.5 & 0.5 \end{pmatrix}$$

(4 分)。(2) $V^{-1}y = \frac{1}{0.96}(2.8, 0.4)' = (2.9167, 0.4167)'$, $\hat{u}_1 = 0.4(2.9167 + 0.5 \times 0.4167) = 1.25$, $\hat{u}_2 = 0.4(0.5 \times 2.9167 + 0.4167) = 0.75$, $\hat{u}_3 = 0.4 \times 0.5 \times (2.9167 + 0.4167) = 0.667$ (6 分)。(3) $\text{PEV} = \sigma_u^2 A - \text{Cov}(u, y)V^{-1}\text{Cov}(y, u)$ 的对角为 (0.225, 0.225, 0.333), 可靠度 (0.4375, 0.4375, 0.1667) (6 分)。个体 3 无自己的记录, 信息只来自两个全同胞, 每个全

同胞仅与它共享一半加性效应, 所以可靠度只有 0.167。(4) 个体 3 的记录 $y_3 = 2$ 超过目前的预测 0.667, 会通过全同胞关系使 $\hat{u}_1$ 向上调整, 同时 $\hat{u}_1$ 的 PEV 减小; 对个体 3 本身, PEV 减小最多 (4 分)。

3. (20 分) (1) $n = \frac{(z_{0.975} + z_{0.8})^2 \sigma_d^2}{\delta^2} = \frac{(1.960 + 0.8416)^2 \times 0.0572^2}{0.05^2} = 10.27$, 取 11 个家系 (6 分)。(2) 样本很少时应使用 t 分布, 非中心 t 的精确功效计算给出 13 个家系; 此外 σ_d 本身是估计值, 应取上界作保守设计或做灵敏度分析 (5 分)。(3) 等效性检验 TOST: 以 0.03 为非劣效界, 两个单侧检验, 样本量按单侧 α 与界值之差计算, 一般比差异检验更大, 且功效取决于真实差异 (5 分)。(4) 不独立: 同一批候选个体与表型使两个相关正相关, 应使用配对设计 (直接对 d 取家系水平数据), 并用家系自助法估计标准误; 忽略家系相关会低估标准误 (4 分)。

4. (25 分) 评分要点 (每条 4 分, 另 5 分给整体结构与可执行性)。(1) 数据与质量控制: 分型率、MAF、哈代-温伯格偏离、孟德尔错误; 系谱与基因型的一致性检验 (用 G 与 A 的相符程度核对身份错误); 表型的批次与分组; 记录时间与单位。(2) 模型: 仅 1200 只已分型而全群 3000 只有系谱, 宜用单步 GBLUP (H^{-1}), 并做 $G-A_{22}$ 的尺度对齐; 用贝叶斯方法检验是否存在大效应位点; 深度学习在这个规模上不作主模型, 只可作对照。(3) 验证: 按出生年份 (前向验证) 和按家系划分, 保留负对照; 指标为相关与准确度 r/h 、校准斜率与截距、RMSE、区间覆盖率, 附家系自助法置信区间; 与系谱 BLUP 作配对比较。(4) 选择与近交: 用最优贡献选择, 设 $\Delta F \leq 1\%$ 的约束; 监控 N_e 与 G 对角元的均值 (基因组近交); 用分家系限额。(5) 失败模式: 筛选泄漏、身份错误、G 与 A 尺度不匹配、群体结构导致的虚高相关、方差分量落在边界、预测随世代衰减 (LD 与选择使效应估计失效), 每一种都要有对应的诊断实验。(6) 决策点: 分型 1200 只后做前向验证, 若准确度比系谱 BLUP 提高不足 0.05 且区间覆盖零, 则暂缓缩短世代间隔; 分阶段扩大分型数; 每年用新出生个体回检校准斜率。

5. (20 分) (1) 训练内 0.85 与验证 0.52 的差距说明过拟合, 不得把训练内相关当作准确度 (3 分)。(2) 随机 10 折 0.52 与前向验证 0.31 的差距说明家系信息被随机划分利用, 对“预测未来候选个体”应以前向验证为准 (4 分)。(3) 校准斜率 0.58 说明预测过度分散, 需要收缩; 覆盖率 0.66 远低于名义的 0.90, 说明 PEV 被低估, 应做重新校准 (4 分)。(4) 遗传方差 REML 估计为 0 是边界解, 不等于性状没有遗传变异: 用似然剖面或贝叶斯后验区间检查, 估计量的抽样分布在零处有质量点; 家系数和每家系记录太少时更常见 (6 分)。(5) 可以保留的结论: 前向验证相关约 0.31 的量级; 预测需要收缩; PEV 低估需重新校准; 不能保留的是“没有遗传控制”和“用单一环境模型即可” (3 分)。

附录 A：常用公式速查

下表汇集全书最常用的公式，每条都注明成立条件。详细推导见各章“补充内容与公式推导”。

名称	公式	成立条件
全方差公式	$\text{Var}(U) = E[\text{Var}(U Y)] + \text{Var}[E(U Y)]$	二阶矩存在
最佳线性预测	$\hat{u} = \mu_u + c^T P^{-1}(y - \mu)$	二阶矩已知
预测误差方差	$\text{PEV} = \sigma_u^2 - c^T P^{-1} c$	同上
可靠度与准确度	$\text{rel} = 1 - \text{PEV}/\sigma_u^2, r = \sqrt{\text{rel}}$	无近交时 $\sigma_u^2 = \sigma_A^2$
Hardy-Weinberg	$P(AA) = p^2, P(Aa) = 2pq, P(aa) = q^2$	随机交配、无进化力量
连锁不平衡	$D = p_{AB} - p_A p_B,$ $r^2 = D^2 / (p_A q_A p_B q_B),$ $D_t = (1 - r)^t D_0$	两位点、随机交配
Haldane 作图函数	$d = -\frac{1}{2} \ln(1 - 2r)$	无干涉
近交系数	$F_X = \frac{1}{2} a_{SD}$	S, D 为 X 的双亲
加性关系递推	$a_{ij} = \frac{1}{2}(a_{is} + a_{id})$	s, d 为 j 的双亲, i 不是 j 的后代
全同胞协方差	$\frac{1}{2} \sigma_A^2 + \frac{1}{4} \sigma_D^2$	无近交、无连锁、无上位
单亲—子代回归	$b = \frac{1}{2} h^2$	无选择、无共同环境
半同胞 ANOVA	$\hat{\sigma}_s^2 = (\text{MSB} - \text{MSW})/k,$ $h^2 = 4\sigma_s^2/\sigma_p^2$	平衡设计
育种者方程	$R = h^2 S = i h^2 \sigma_p = i r \sigma_A$	单性状、截断选择
年遗传进展	$\Delta G/\text{年} = \frac{i r \sigma_A}{L}$	四条选择路径时取平均
最优选择指数	$b = P^{-1} G a, r_{IH} = \sigma_I/\sigma_H$	线性目标与线性指数
有效群体大小	$N_e = \frac{4N_m N_f}{N_m + N_f}, \Delta F = \frac{1}{2N_e}$	随机交配、世代不重叠
近交累积	$F_t = 1 - (1 - \Delta F)^t$	ΔF 恒定
混合模型方程	$\begin{pmatrix} X^T X & X^T Z \\ Z^T X & Z^T Z + \lambda A^{-1} \end{pmatrix}$	$\lambda = \sigma_e^2/\sigma_u^2$
BLUP 的 PEV	$\text{Var}(\hat{u} - u) = \sigma_e^2 C^{22}$	方差组分已知
VanRaden 的 G	$G = Z Z^T / [2 \sum p_j q_j]$	$Z = M - 2p$
SNP-BLUP 与 GBLUP	$\lambda = \sigma_e^2/\sigma_m^2,$ $\sigma_m^2 = \sigma_a^2/[2 \sum p_j q_j]$	等价于 GBLUP
单步评定	$H^{-1} = A^{-1} + \text{diag}(0, G^{-1} - A_{22}^{-1})$	G 与 A_{22} 已对齐
预测准确度	$\hat{r} = r_{\hat{u}, y}/h$	校正表型、独立验证
校准斜率	$b = \text{Cov}(u, \hat{u})/\text{Var}(\hat{u})$	$b = 1$ 为理想

名称	公式	成立条件
相关系数标准误	$SE(r) \approx (1 - r^2)/\sqrt{n - 1}$	独立样本；相关个体用家系自助法
Fisher z 变换	$z = \operatorname{arctanh} r, SE_z = 1/\sqrt{n - 3}$	二元正态

附录 B：标准正态选择强度表

截留比例为 p 时，截断点 $x_p = \Phi^{-1}(1 - p)$ ，纵高 $z = \varphi(x_p)$ ，选择强度 $i = z/p$ （以下数值由程序计算，保留四位小数）。

截留比例 p	截断点 x_p	纵高 z	选择强度 i
0.01	2.3263	0.0267	2.6652
0.02	2.0537	0.0484	2.4209
0.05	1.6449	0.1031	2.0627
0.10	1.2816	0.1755	1.7550
0.15	1.0364	0.2332	1.5544
0.20	0.8416	0.2800	1.3998
0.25	0.6745	0.3178	1.2711
0.30	0.5244	0.3477	1.1590
0.40	0.2533	0.3863	0.9659
0.50	0.0000	0.3989	0.7979
0.60	-0.2533	0.3863	0.6439
0.70	-0.5244	0.3477	0.4967
0.80	-0.8416	0.2800	0.3500
0.90	-1.2816	0.1755	0.1950

使用提示：此表对应无限大群体的截断选择；有限群体、小样本选留时 i 略小，需用 Burrows 校正或精确的次序统计量期望。选择强度以表型标准差为单位。

附录 C：配套程序索引

配套代码共 223 个程序，每章一个文件夹（命名为“章号 _ 英文主题”，如 ch01_probability_prediction），含 data/（输入数据）、results/（输出）与 _plot.py（绘图辅助）。运行方式：python3 run_all.py（全部程序）或进入某章文件夹后 python3 exNN_kk_xxx.py。依赖：numpy、scipy、matplotlib。

章	章名	程序对应习题
1	概率、期望与遗传预测问题	1.15、1.16、1.18、1.19、1.20、1.22
2	矩阵方法与稳定计算	2.15、2.16、2.17、2.18、2.19、2.22、2.28
3	统计推断、似然与数量遗传学方法	3.15、3.16、3.17、3.18、3.19、3.20
4	单基因座群体模型与等位基因频率的演变	4.15、4.16、4.17、4.18、4.19、4.20
5	多基因座单倍型、连锁不平衡与重组	5.15、5.16、5.17、5.18、5.19、5.20
6	遗传连锁与连锁图谱的构建	6.15、6.16、6.17、6.18、6.19、6.20
7	杂交群体的数量性状位点定位	7.15、7.16、7.17、7.18、7.19、7.20
8	远交群体的连锁分析、关联定位与全基因组关联研究	8.15、8.16、8.17、8.18、8.19、8.20
9	数量遗传与群体依赖性	9.15、9.16、9.17、9.18、9.19、9.20
10	遗传方差组分、重复力与性状间相关	10.15、10.16、10.17、10.18、10.19、10.20
11	亲属间的相似性与遗传协方差	11.15、11.16、11.17、11.18、11.19、11.20
12	系谱亲缘、近交与遗传连接	12.15、12.16、12.17、12.18、12.19、12.20
13	遗传参数的经典估计方法与试验设计	13.15、13.16、13.17、13.18、13.19、13.20
14	选择反应的数量遗传理论	14.15、14.16、14.17、14.18、14.19、14.20
15	单性状选择指数与信息融合	15.15、15.16、15.17、15.18、15.19、15.20

章	章名	程序对应习题
16	多性状育种目标与经济权重	16.15、16.16、16.17、16.18、16.19、16.20
17	限制指数、非线性目标与稳健决策	17.15、17.16、17.17、17.18、17.19、17.20
18	选择反应、世代间隔与长期遗传进展	18.15、18.16、18.17、18.18、18.19、18.20
19	遗传漂变、有效群体大小与近交	19.15、19.16、19.17、19.18、19.19、19.20
20	杂种优势、配合力与杂交育种体系	20.15、20.16、20.17、20.18、20.19、20.20
21	从最小二乘到最佳线性无偏预测	21.15、21.16、21.17、21.18、21.19、21.20
22	动物模型与复杂遗传效应	22.15、22.16、22.17、22.18、22.19、22.20
23	方差组分、限制似然与贝叶斯推断	23.15、23.16、23.17、23.18、23.19、23.20
24	多性状、阈值、生存与纵向遗传模型	24.15、24.16、24.17、24.18、24.19、24.20
25	基因组时代的遗传力	25.15、25.16、25.17、25.18、25.19、25.20
26	基因型质量控制与基因组关系矩阵	26.15、26.16、26.17、26.18、26.19、26.20
27	GBLUP、岭回归、贝叶斯与核方法	27.15、27.16、27.17、27.18、27.19、27.20
28	单步基因组评定	28.15、28.16、28.17、28.18、28.19、28.20
29	验证设计、准确性、校准与跨群体迁移	29.15、29.16、29.17、29.18、29.19、29.20
30	全基因组序列、泛基因组、结构变异与稀有变异	30.15、30.16、30.17、30.18、30.19、30.20
31	多组学、功能先验与因果推断	31.15、31.16、31.17、31.18、31.19、31.20
32	基因型 × 环境、韧性与可持续育种	32.15、32.16、32.17、32.18、32.19、32.20
33	深度学习与基因组基础模型	33.15、33.16、33.17、33.18、33.19、33.20
34	数据字典到可重复评定	34.15、34.16、34.17、34.18、34.19、34.20
35	从系谱 BLUP 到 GBLUP：一个可复算的肉羊教学实验	35.15、35.16、35.17、35.18、35.19、35.20

章	章名	程序对应习题
36	多性状目标与约束配种的完整决策算例	36.15、36.16、36.17、36.18、36.19、36.20
37	模型诊断、失败分析与可检验的研究设计	37.15、37.16、37.17、37.18、37.19、37.20

附录 D：学习路线与使用建议

习题集不是一本需要从头读到尾的书。不同的读者有不同的目的，下面按四类常见的使用情境给出建议，读者可以按需取用。

一、课程学习者（一学期，约 16 周）。每周配合教材一章，建议的节奏是：先读教材，再做本章的单项选择与判断题（约 20 分钟），检查有没有概念上的疏漏；然后做填空与手算题；程序题放在课后做，先读题干中的数据说明，预测结果，再运行程序对照；证明题与综合题可以作为每两周一次的作业。学完第一至第四篇后做 A 卷，学完第七篇后做 B 卷，学完第十篇后做 C 卷。每份试卷限时 120 分钟，做完再对照评分要点。

二、研究生备考与综合复习。先用知识结构图为每章建立一页纸的框架，然后集中做三星题与推导题，重点是证明题与综合题。D 卷用于模拟综合考试，限时 180 分钟，做完以后重点看“失败模式”与“诊断实验”这两个环节，这是研究设计中最容易失分的地方。建议把做错的题按“概念、计算、条件、设计”四类整理成错题本，每类写下一条一句话的纠正规则。

三、自学者与从业人员。如果工作中已经在使用 BLUP 或基因组评定软件，可以直接从第七篇与第八篇入手：先读各章的“易错辨析”，再做程序题。程序题的价值在于让读者看到：当样本量、标记密度、方差比、亲缘结构改变时，同一个模型的准确度、偏倚与校准会怎样变化。对第十篇的四章，建议完整地跑一遍程序并阅读答案，因为它们演示了从数据字典到决策报告的整个链条。

四、教师与助教。每章的 29 道题涵盖了从识记到研究设计的全部层次，可以按课时选取：一次 90 分钟的习题课可选 4 至 6 题，包含一道推导、一道程序题与一道综合题。程序题的数据均由程序生成，种子固定，学生可以在自己的电脑上复现；教师也可以修改种子或参数，生成同类型的新题。试卷的评分要点逐项给出了分值，便于流水阅卷。

使用程序的几点提醒。第一，先读题干再运行，不要把程序当作黑箱；第二，运行时间每个程序均在一分钟内，若运行缓慢请检查是否在后台有其他任务；第三，程序输出的数值与书中的数值应当一致，如果不一致，通常是因为修改了种子、样本量或参数，这本身就是值得研究的现象；第四，修改程序做“反事实”实验往往比阅读答案更有收获，例如把样本量减半、把方差比改大、把筛选放进训练折内。

附录 E：常见误解索引

下表按篇汇集了全书最常见的误解，每条指出主要涉及的章，读者可据此回到相应章节的“易错辨析”与习题。

篇	常见误解	主要章节
一	把预测对象说成“遗传”而不指明是育种值、传递能力还是未来表型；忘记写出条件期望的条件	1
一	以为最小二乘估计要求误差正态；以为似然比检验在边界上仍服从 χ^2	2、3
二	以为群体处于 Hardy-Weinberg 平衡就说明没有选择或迁移；把 D 与 r^2 混为一谈	4、5
二	把图距当作重组率直接相加，不区分作图函数	6
三	把 QTL 的置信区间当作“基因所在的区间”，忽视效应被高估的问题	7、8
四	以为遗传力是性状的固有常数，而不是某个群体、某种环境下的比值	9、10
四	认为亲属越近，关系系数一定越大，忽视近交；用半同胞资料估计时把母体效应当作遗传效应	11、12、13
五	把单世代的选择反应外推为长期进展，忽视 Bulmer 效应与有效群体	14、18
五	以为选择指数的系数就是经济权重；忽视约束与稳健性	15、16、17
六	以为只要群体名义上大，近交就不会累积；把杂种优势说成与等位基因频率无关	19、20
七	以为 BLUP 对每个真实育种值都无偏；混淆 ML 与 REML	21、23

篇	常见误解	主要章节
七	以为动物模型只是“把公畜换成个体”，忽视它对选择和非随机交配的校正	22、24
八	把基因组遗传力等同于系谱遗传力；忽视 G 的尺度与单步评定中的对齐	25、26、28
八	在全体数据上筛选标记后做交叉验证；只报告相关系数，不报告校准	27、29
九	以为全基因组序列一定带来准确度的提高；把关联当作因果；忽略基因型 × 环境	30、31、32
九	以为深度学习在小样本 SNP 资料上一定优于线性模型	33
十	把没有身份核对的资料送入评定；用同一批数据调参又当作独立检验	34、35
十	把预测的最优配种当作已实现的收益；把零方差估计当作“没有遗传变异”	36、37

读者在做错题以后，可以先在上表中找到对应的误解，再到该章的“易错辨析”与解析中重读相应的条件与反例。

附录 F：各章知识结构一览

下表列出每章知识结构图的八个主干分支，可作为复习时的“检查清单”：读完一章后，试着不看书说出每个分支下的三个要点。

章	章名	知识结构图的八个分支
1	概率、期望与遗传预测问题	预测对象；概率语言；期望与协方差；最优预测；正态模型；评价与校准；决策
2	矩阵方法与稳定计算	模型矩阵；合法协方差；稳定求解；谱方法；分块与更新；微分与迹；大规模计算
3	统计推断、似然与数量遗传学方法	模型与估计；似然；EM 算法；区间与标准误；检验与功效；多重检验；贝叶斯与重抽样
4	单基因座群体模型与等位基因频率的演变	基本描述；Hardy-Weinberg；非随机交配；系统力量；遗传漂变；溯祖与估计；标记信息
5	多基因座单倍型、连锁不平衡与重组	LD 的度量；相位与估计；产生机制；衰减；漂变—重组平衡；标签与单倍型；育种意义
6	遗传连锁与连锁图谱的构建	重组与交换；作图函数；两点分析；多点构图；HMM；数据问题；图谱比较
7	杂交群体的数量性状位点定位	单位点模型；单标记分析；区间作图；显著性阈值；多个 QTL；高效设计；结果解释
8	远交群体的连锁分析、关联定位与全基因组关联研究	基本困难；家系设计；关联模型；混杂与校正；显著性；效应估计；精细定位
9	数量遗传与群体依赖性	基因型值；平均效应；育种值与显性偏差；方差；非随机交配；连锁不平衡；群体基准
10	遗传方差组分、重复力与性状间相关	遗传方差；环境方差；重复力；性状间相关； $G \times E$ ；尺度与变换
11	亲属间的相似性与遗传协方差	因果与观察；同祖同源；协方差系数；家系均值；实际关系；母体效应；双生子设计

章	章名	知识结构图的八个分支
12	系谱亲缘、近交与遗传连接	关系矩阵 A ; A 的逆; 近交; 系谱质量; 遗传连接; 有效群体; 系谱与基因组
13	遗传参数的经典估计方法与试验设计	观察协方差; 嵌套方差分析; 交配设计; 估计精度; 选择与偏倚; 遗传相关; 方法比较
14	选择反应的数量遗传理论	育种者方程; 截断选择; Bulmer 效应; 相关选择反应; 反应的测定; 长期反应与极限; 非正态与失效
15	单性状选择指数与信息融合	最佳线性预测; 信息来源; 信息的几何; 重复记录; 缺失与不平衡; 参数误差; 设计与价值
16	多性状育种目标与经济权重	目标与指数; 响应与准确度; 生物经济模型; 跨期与阈值性状; 单位与约定; 权重误设; 隐含权重与版本
17	限制指数、非线性目标与稳健决策	零响应限制; 限制的代价; 不等式约束; 非线性目标; 不确定的权重; 联合预测误差; 概率约束
18	选择反应、世代间隔与长期遗传进展	年进展公式; 重叠世代基因流; 最优贡献选择; 配种计划; 多世代结果; 金字塔与时间价值; 青年 vs 后测
19	遗传漂变、有效群体大小与近交	有效群体大小; 近交动力学; 近交衰退; 方差再分配; 清除; 基因组近交; 长期贡献
20	杂种优势、配合力与杂交育种体系	杂种优势理论; 杂交体系; 迪克森模型; 配合力; 杂种优势群; 纯种与杂种; 基因组预测; 分子基础
21	从最小二乘到最佳线性无偏预测	最小二乘与 GLS; 可估计与连通; BLUP 的推导; 收缩与校准; 精度; 混合目标; 奇异与稳健; 经验 BLUP
22	动物模型与复杂遗传效应	动物模型基础; 公畜与动物模型; 母体遗传效应; 环境与识别; 显性与上位; 社会遗传效应; 杂交与杂种优势; 基础群与模型选择

章	章名	知识结构图的八个分支
23	方差组分、限制似然与贝叶斯推断	方差分解；ML 与 REML；得分与信息；参数边界；可识别性；不确定性区间；贝叶斯推断；进入决策
24	多性状、阈值、生存与纵向遗传模型	多性状 BLUP；可靠度与设计；随机回归；阈值模型；生存与脆弱性；病例富集抽样；参数与识别；报告与决策
25	基因组时代的遗传力	三种遗传力；GREML；HE 回归；致因变异频率； α 模型与分层；LD 分数回归；混杂与近亲；类别性状换算
26	基因型质量控制与基因组关系矩阵	个体身份与亲子；位点质检；测量模型；G 的构建；与 A 的相容；缺失与填补；频率误差；批次与可复现
27	GBLUP、岭回归、贝叶斯与核方法	两种表示；谱收缩；贝叶斯方法；核方法；不等精度表型；超参数与比较；验证设计；决策
28	单步基因组评定	H 矩阵；G 的相容；预测表现；APY 近似；元基础群体；求解器；可靠度；工程实践
29	验证设计、准确性、校准与跨群体迁移	验证目标；划分设计；信息泄漏；准确性；校准与选择；不确定性；学习曲线；跨群体迁移
30	全基因组序列、泛基因组、结构变异与稀有变异	从读段到基因型；低覆盖与插补；关系矩阵；泛基因组与 SV；稀有变异检验；模型整合；参考面板设计；决策与经济
31	多组学、功能先验与因果推断	条件遗传信息；组学测量；多核整合；功能先验；QTL 与共定位；孟德尔随机化；中介分析；设计与证据
32	基因型 $\times$ 环境、韧性与可持续育种	环境的角色；反应规范；目标与选择；阈值反应；韧性指标；状态空间；排放与可持续；部署方案
33	深度学习与基因组基础模型	何时用深度模型；序列模型；基础模型分数；先验与校准；模型组合；预测区间；可解释性；部署与评价

章	章名	知识结构图的八个分支
34	数据字典到可重复评定	问题与观测单位；身份与连接；时间与截止日；重复测定；系谱与基因型；可追溯变换；验证与增量；身份与版本
35	从系谱 BLUP 到 GBLUP：一个可复算的肉羊教学实验	已知真值的世界；关系矩阵；小例子；重复实验；标记与方差比；身份错配；初筛与尾部；个体比较
36	多性状目标与约束配种的完整决策算例	从预测到设计；目标与权重；最优贡献；配种运输问题；整数化；不确定性与风险；禁配与可行性；可审阅的决策
37	模型诊断、失败分析与可检验的研究设计	错误层次；残差诊断；校准失败；方差分量；负对照；稳健处理；验证的统计；研究设计

参考文献

以下文献是本习题集各章习题与推导所依据的主要经典论著与方法论文，按作者姓名的字母顺序排列。关于各章引用的具体研究结论，请以原始文献及配套教材《数量遗传学——从孟德尔群体到基因组育种》的参考文献为准。

Bulmer M G. 1971. The effect of selection on genetic variability. *American Naturalist*, 105: 201–211.

Christensen O F, Lund M S. 2010. Genomic prediction when some animals are not genotyped. *Genetics Selection Evolution*, 42: 2.

Efron B. 1979. Bootstrap methods: another look at the jackknife. *Annals of Statistics*, 7: 1–26.

Falconer D S, Mackay T F C. 1996. *Introduction to Quantitative Genetics*, 4th ed. Harlow: Longman.

Fisher R A. 1918. The correlation between relatives on the supposition of Mendelian inheritance. *Transactions of the Royal Society of Edinburgh*, 52: 399–433.

Gianola D, Fernando R L. 1986. Bayesian methods in animal breeding theory. *Journal of Animal Science*, 63: 217–244.

Gilmour A R, Thompson R, Cullis B R. 1995. Average information REML: an efficient algorithm for variance parameter estimation in linear mixed models. *Biometrics*, 51: 1440–1450.

Habier D, Fernando R L, Garrick D J. 2013. Genomic BLUP decoded: a look into the black box of genomic prediction. *Genetics*, 194: 597–607.

Haley C S, Knott S A. 1992. A simple regression method for mapping quantitative trait loci in line crosses using flanking markers. *Heredity*, 69: 315–324.

Hazel L N. 1943. The genetic basis for constructing selection indexes. *Genetics*, 28: 476–490.

Henderson C R. 1975. Best linear unbiased estimation and prediction under a selection model. *Biometrics*, 31: 423–447.

Henderson C R. 1976. A simple method for computing the inverse of a numerator relationship matrix used in prediction of breeding values. *Biometrics*, 32: 69–83.

Hill W G, Robertson A. 1968. Linkage disequilibrium in finite populations. *Theoreti-*

cal and Applied Genetics, 38: 226–231.

Kimura M, Crow J F. 1963. The measurement of effective population numbers. *Evolution*, 17: 279–288.

Lander E S, Botstein D. 1989. Mapping Mendelian factors underlying quantitative traits using RFLP linkage maps. *Genetics*, 121: 185–199.

Legarra A, Aguilar I, Misztal I. 2009. A relationship matrix including full pedigree and genomic information. *Journal of Dairy Science*, 92: 4656–4663.

Legarra A, Reverter A. 2018. Semi-parametric estimates of population accuracy and bias of predictions of breeding values and future phenotypes using the LR method. *Genetics Selection Evolution*, 50: 53.

Lynch M, Walsh B. 1998. *Genetics and Analysis of Quantitative Traits*. Sunderland: Sinauer Associates.

Meuwissen T H E. 1997. Maximizing the response of selection with a predefined rate of inbreeding. *Journal of Animal Science*, 75: 934–940.

Meuwissen T H E, Hayes B J, Goddard M E. 2001. Prediction of total genetic value using genome-wide dense marker maps. *Genetics*, 157: 1819–1829.

Mrode R A. 2014. *Linear Models for the Prediction of Animal Breeding Values*, 3rd ed. Wallingford: CABI.

Patterson H D, Thompson R. 1971. Recovery of inter-block information when block sizes are unequal. *Biometrika*, 58: 545–554.

Quaas R L. 1976. Computing the diagonal elements and inverse of a large numerator relationship matrix. *Biometrics*, 32: 949–953.

Smith H F. 1936. A discriminant function for plant selection. *Annals of Eugenics*, 7: 240–250.

VanRaden P M. 2008. Efficient methods to compute genomic predictions. *Journal of Dairy Science*, 91: 4414–4423.

Visscher P M, Hill W G, Wray N R. 2008. Heritability in the genomics era — concepts and misconceptions. *Nature Reviews Genetics*, 9: 255–266.

Walsh B, Lynch M. 2018. *Evolution and Selection of Quantitative Traits*. Oxford: Oxford University Press.

Wray N R, Yang J, Hayes B J, et al. 2013. Pitfalls of predicting complex traits from SNPs. *Nature Reviews Genetics*, 14: 507–515.

Wright S. 1922. Coefficients of inbreeding and relationship. *American Naturalist*, 56: 330–338.

Wright S. 1931. Evolution in Mendelian populations. *Genetics*, 16: 97–159.

Yang J, Benyamin B, McEvoy B P, et al. 2010. Common SNPs explain a large proportion of the heritability for human height. *Nature Genetics*, 42: 565–569.

Yang J, Lee S H, Goddard M E, Visscher P M. 2011. GCTA: a tool for genome-wide complex trait analysis. *American Journal of Human Genetics*, 88: 76–82.

后记

习题集的编写是一场漫长的检验。每写一道题，我都问自己：这个数字我能复算吗？这个结论的条件写清楚了吗？读者做错时，错在哪一步？为了回答这些问题，全书的数值题都配有可运行的程序，程序里的每一个断言都是一次与理论的对质：理论值与模拟值是否吻合、一个恒等式是否在数值上成立、一个界是否被违反。有几次，程序的结果与我原先的设想不同，例如某一设计下的约束从未起作用，某个估计量的偏差比预期更大，这些发现都被如实写进了答案，因为数量遗传学的价值不在于每个公式都完美，而在于知道每个公式何时不完美。

数量遗传学正在被数据与算力快速改变，但它的底层逻辑没有变：把机制写成模型，由模型推出可检验的结论，再用资料去检验。愿这本习题集成为读者与这门学科之间的一个练习场，也愿读者在这里算错的每一道题，都成为通向理解的一级台阶。

梅步俊

二〇二六年十月